MIT 18.06 线性代数 · 学习笔记

> **课程**：MIT 18.06 *Linear Algebra*（Gilbert Strang） **教材**：Strang, Gilbert. *Introduction to Linear Algebra*. 5th ed. Wellesley–Cambridge Press, 2016 **官方主页**：web.mit.edu/18.06/www **视频**：MIT OpenCourseWare · 18.06 Linear Algebra **先修**：18.02 多变量微积分 **考核**：每周作业 + 三次期中考试（Quiz 1/2/3）+ 一次期末考试

课程概览

一句话定位

线性代数是关于**向量空间与线性变换**的学科；矩阵是这场戏的**记账工具**，而不是主角。Strang 教授在整个课程中反复强调同一句话：

> **"Use matrices, and understand matrices."** —— 会用矩阵，更要理解矩阵。

这门课到底在讲什么？

很多线性代数课程从"行列式怎么算"开始，把学生训练成算题机器。18.06 走的是相反的路：**先建立几何图像，再落到计算公式**。整门课可以压缩成三个问题：

1. **求解**：$A\mathbf{x}=\mathbf{b}$ 什么时候有解？解有多少个？——答案藏在**列空间**与**零空间**里。
2. **分解**：能不能把 A 拆成几个"结构简单"的矩阵之积？——$A=LU$、$A=QR$、$A=S\Lambda S^{-1}$、$A=U\Sigma V^{\mathsf{T}}$、$A=CR$。
3. **特征**：哪些方向在变换 A 下只是被拉伸、不被转动？——**特征值与特征向量**。

这三个问题的答案，最终汇聚成一幅图：**四个基本子空间**（Lecture 10）。

三大核心主题

主题一：四个基本子空间——课程的"统一场论"

对任意 $m\times n$ 矩阵 A（秩为 r），只有四个子空间值得记住：

子空间	记号	所在空间	维数	回答什么问题
列空间	$C(A)$	$\mathbb{R}^m$	r	$A\mathbf{x}=\mathbf{b}$ 有解吗?
零空间	$N(A)$	$\mathbb{R}^n$	$n-r$	解的"自由度"有多少?
行空间	$C(A^{\mathsf{T}})$	$\mathbb{R}^n$	r	哪些方向被 A 保留下来?
左零空间	$N(A^{\mathsf{T}})$	$\mathbb{R}^m$	$m-r$	哪些 $\mathbf{b}$ 永远取不到?

它们满足两条**正交分解**：

$$\mathbb{R}^n = C(A^{\mathsf{T}}) \oplus N(A), \qquad \mathbb{R}^m = C(A) \oplus N(A^{\mathsf{T}})$$

这四个子空间把前面所有关于 $A\mathbf{x}=\mathbf{0}$、$A\mathbf{x}=\mathbf{b}$ 的零散讨论一次性收拢：**解的存在性由 $C(A)$ 决定，解的自由度由 $N(A)$ 决定**。

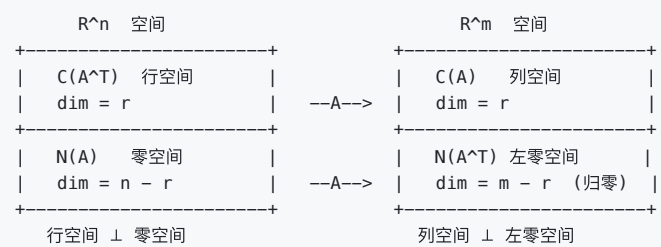

主题二：矩阵分解——把复杂问题变成简单问题

Strang 的课几乎每一讲都在偷偷介绍一种分解。分解的哲学是：**把一个难处理的矩阵，写成几个容易处理的矩阵之积**。

- $A=LU$：消元的产物。把解方程变成两次三角形回代（Lecture 4）。

- $A = QR$：正交化的产物。把最小二乘变成稳定的三角求解（Lecture 17）。
- $A = S\Lambda S^{-1}$：特征向量的产物。把矩阵幂 A^k 变成对角元的幂（Lecture 22）。
- $A = U\Sigma V^{\mathrm{T}}$：SVD。**任何**矩阵都能用，是课程的高潮（Lecture 29）。
- $A = CR$：秩的产物。用 r 个独立列与 r 个独立行精确重建 A（Lecture 11）。

主题三：应用——线性代数从哪里来、到哪里去

18.06 与传统课程最大的差异是**每个概念都有出处**：

- **图与网络**（Lecture 11–12）：图的关联矩阵，其零空间给出基尔霍夫电流定律，$A^{\mathrm{T}}A$ 就是拉普拉斯矩阵。
- **最小二乘与数据拟合**（Lecture 16）：超定系统的几何答案，统计回归的骨架。
- **微分方程**（Lecture 23）：$\mathbf{du}/dt = A\mathbf{u}$ 的解由特征值决定稳定性。
- **马尔可夫链与 PageRank**（Lecture 24）：稳态向量就是特征值 1 的特征向量。
- **傅里叶级数**（Lecture 24）：函数空间上的正交基展开——投影公式的无穷维版本。
- **图像压缩与降维**（Lecture 29、31）：SVD 低秩逼近就是最优压缩。

学习方法建议

这门课的特点是**"算得少，想得多"**，但有三个必须动手的地方：

1. **用小矩阵算穿每一个算法**。不要满足于"看懂了"。拿一个 2×2 或 3×3 的整数矩阵，把消元、求逆、Gram–Schmidt、特征值全部手算一遍。本笔记每一讲都提供了完整的手算演示，请跟着算一遍。
2. **每个公式都要问"几何上发生了什么"**。例如 $P^2 = P$ 不是代数巧合，它的意思是"投影两次等于投影一次"。
3. **抓住四个基本子空间这张图**。当你迷路时，问自己：现在讨论的是 $\mathbb{R}^n$ 还是 $\mathbb{R}^m$？是行空间还是零空间？

讲次路线图

阶段	讲次	主线
第一阶段：消元与分解	1–5	从 $A\mathbf{x} = \mathbf{b}$ 的几何，到 $A = LU$，建立"矩阵=线性变换"的观点
第二阶段：子空间	6–10	四个基本子空间，$A\mathbf{x} = \mathbf{0}$ 与 $A\mathbf{x} = \mathbf{b}$ 的完整理论
第三阶段：矩阵与图	11–12	矩阵空间、秩 1 矩阵、$A = CR$、图与网络
第四阶段：正交性	14–17	正交、投影、最小二乘、$A = QR$
第五阶段：行列式	18–20	行列式的性质、公式、体积与 Cramer 法则
第六阶段：特征值	21–25	$A\mathbf{x} = \lambda\mathbf{x}$、$A = S\Lambda S^{-1}$、微分方程、马尔可夫、对称正定
第七阶段：正定、Jordan、SVD	27–29	极小值与正定、相似与 Jordan 形、奇异值分解
第八阶段：线性变换与伪逆	30–31, 33	无坐标视角、换基、左/右逆与伪逆

> **说明**：原课程中 Lecture 13、26、32 分别为 Quiz 1/2/3 复习课（Lecture 26 为"复数矩阵与 FFT"的复习兼讲），不属于新知识点主线，故本笔记按知识点讲次编排，不单独成篇；相关知识点（复特征值、FFT）在 Lecture 21、24 中已作必要介绍。

讲次索引

讲次	主题	教材章节	一句话看点
1	The Geometry of Linear Equations	1.1–2.1	行图像 / 列图像 / $A\mathbf{x} = \mathbf{b}$ 三视角
2	Elimination with Matrices	2.2	消元矩阵 E 与矩阵乘法四视角
3	Multiplication and Inverse Matrices	2.4–2.5	Gauss–Jordan 求逆、奇异=压扁
4	Factorization into A = LU	2.6	为什么 L 里是干净的乘数
5	Transposes, Permutations, Spaces R^n	2.7	$A^{\mathrm{T}}A$ 对称、子空间必须过原点
6	Column Space and Nullspace	3.1–3.2	两个子空间回答两个问题
7	Solving Ax = 0	3.2	特殊解配方、$\dim N(A) = n - r$

讲次	主题	教材章节	一句话看点
8	Solving Ax = b	3.3–3.4	$\mathbf{x}=\mathbf{x}_p+\mathbf{x}_n$ 与 (r,m,n) 分类
9	Independence, Basis, and Dimension	3.5	基"不多不少刚刚好"，维数唯一
10	The Four Fundamental Subspaces	3.6	**课程统一框架 + 正交大图**
11	Matrix Spaces; Rank 1	8.2	矩阵空间维数、$A=CR$
12	Graphs, Networks, Incidence Matrices	8.2	关联矩阵、基尔霍夫定律、欧拉公式
14	Orthogonal Vectors and Subspaces	4.1	正交补、$N(A^{\mathsf{T}}A)=N(A)$
15	Projections onto Subspaces	4.2	$P=\mathbf{a}\mathbf{a}^{\mathsf{T}}/\mathbf{a}^{\mathsf{T}}\mathbf{a}$ 与正规方程
16	Projection Matrices and Least Squares	4.2–4.3	直线拟合手算到底
17	Orthogonal Matrices and Gram–Schmidt	4.4	减投影的几何、$A=QR$
18	Properties of Determinants	5.1	三条公理推出十条性质
19	Determinant Formulas and Cofactors	5.2	大公式、余子式展开
20	Cramer's Rule, Inverse, Volume	5.3	$\lvert\det\rvert$ = 面积/体积
21	Eigenvalues and Eigenvectors	6.1	方向不变的方向
22	Diagonalization and Powers of A	6.2	$A^k=S\Lambda^kS^{-1}$、Fibonacci
23	Differential Equations and exp(At)	6.3	稳定性由 $\mathbf{Re}\,\boldsymbol{\lambda}$ 决定
24	Markov Matrices; Fourier Series	8.3, 8.5	稳态向量 = 特征值 1；傅里叶=投影
25	Symmetric Matrices and Positive Definiteness	6.4	实特征值、$A=Q\Lambda Q^{\mathsf{T}}$
27	Positive Definite Matrices and Minima	6.5	配方=消元、椭球与鞍点
28	Similar Matrices and Jordan Form	6.6	相似不变量、广义特征向量链
29	Singular Value Decomposition	6.7	**课程高潮**：任意矩阵的最优正交结构
30	Linear Transformations and Their Matrices	7.1	先有变换，后有矩阵
31	Change of Basis; Image Compression	7.2	$B=W^{-1}AW$、换基压缩
33	Left and Right Inverses; Pseudoinverse	7.3	$A^+=V\Sigma^+U^{\mathsf{T}}$

如何阅读本笔记

每一讲的笔记都严格按同一套骨架组织，你可以按需跳读：

小节	回答什么问题	什么时候看
概述	这一讲要解决什么?	开始学一讲之前
核心概念的几何直觉	"它在空间中是什么样子？"	概念模糊、想建立图像时
计算步骤与手算演示	具体怎么算?	动手做题时（**建议跟算一遍**）
矩阵分解的核心思想	这一讲与哪种分解有关?	想理解课程主线时
与其他讲次的关联	它和前后讲怎么接上?	复习、串知识时
关键要点	必须记住的几条?	考前速览
常见误区与注意事项	大家通常错在哪里?	自我检查时
思考题（带答案）	我真的懂了吗?	学完自测

> **使用建议**：笔记中所有关键数值（秩、特征值、行列式、投影、奇异值等）都经过脚本验算。但**读数学不能只读**——遇到手算演示时，请拿纸笔遮住后续步骤自己算一遍，再对照笔记。凡是标有 **【计算机制解说】** 的地方，都是在回答"为什么这个算法能这么做"，那是本笔记最值得细读的部分。

Lecture 1: The Geometry of Linear Equations

概述

本讲要回答一个看似简单的问题：n 个未知数、n 个方程的线性方程组，究竟在讲什么？答案是同一个对象的**三张面孔**——行图像（row picture）里它是若干条直线/若干张超平面的交点，列图像（column picture）里它是若干列向量的一种组合方式，矩阵形式（matrix form）$\mathbf{Ax}=\mathbf{b}$ 则是把前两者压缩成一行符号。本讲的核心主张是：**列图像才是线性代数的核心视角**，因为它直接通向"矩阵的列空间（column space）"这一贯穿全课程的概念。方法上我们不做任何抽象推广，只用 2×2 与 3×3 的具体数字把机制算穿，最后预告消元（elimination）作为系统化算法的必要性。

核心概念的几何直觉

线性方程组的三种视角（three pictures）

- **定义与目的**：给定 m 个方程、n 个未知数的方程组，我们要找出所有满足它的向量 $\mathbf{x}\in\mathbb{R}^n$。三种视角不是三种不同的数学，而是对同一个矩阵方程 $\mathbf{Ax}=\mathbf{b}$ 的三种读法。
- **几何直觉（它在空间中是什么样子？）**：行图像问"哪些点同时躺在所有这些平面（直线）上"——是**求交集**；列图像问"把这些列向量按什么系数配比才能拼出 $\mathbf{b}$"——是**配配方**。前者从 $\mathbf{x}$ 所在的 $\mathbb{R}^n$ 看，后者从 $\mathbf{b}$ 所在的 $\mathbb{R}^m$ 看。
- **具体示例**：本讲的招牌方程组

$$2x-y=0,\qquad -x+2y=3.$$

行图像：两条直线交于 $(1,2)$。列图像：$x\begin{bmatrix}2\\-1\end{bmatrix}+y\begin{bmatrix}-1\\2\end{bmatrix}=\begin{bmatrix}0\\3\end{bmatrix}$，取 $x=1,y=2$。两个视角给出同一个答案，但**只有列图像会在 $m\neq n$ 或矩阵奇异时继续好用**。

行图像（Row Picture）

- **定义与目的**：把第 i 个方程看成 $\mathbb{R}^n$ 中的一张超平面：$\mathbf{row}_i\cdot\mathbf{x}=b_i$。在 $\mathbb{R}^2$ 是直线，在 $\mathbb{R}^3$ 是平面。解集就是这 m 张超平面的交集。
- **几何直觉（它在空间中是什么样子？）**：两直线在平面上有三种关系——相交于一点（唯一解）、平行但不重合（无解）、完全重合（无穷多解）。三平面在空间中则有更丰富的退化方式：交于一点、交于一条线、交于一个平面、两两相交但三者无公共点（像三棱柱的侧面）。
- **具体示例**：直线 $2x-y=0$ 的法向量是 $(2,-1)$，直线 $-x+2y=3$ 的法向量是 $(-1,2)$。两条法向量不成比例，所以两直线不平行，必有唯一交点。**关键观察**：行图像的信息量是"每个绳子上各打了几个结"——它把 n 个未知数搅在同一个方程里，你很难一眼看出哪个未知数受谁约束。

列图像（Column Picture）——本讲的主角

- **定义与目的**：把矩阵 $\mathbf{A}$ 按列切开：$\mathbf{A}=[\mathbf{a}_1\ \mathbf{a}_2\ \cdots\ \mathbf{a}_n]$，每个 $\mathbf{a}_j\in\mathbb{R}^m$。方程 $\mathbf{Ax}=\mathbf{b}$ 等价于

$$x_1\mathbf{a}_1+x_2\mathbf{a}_2+\cdots+x_n\mathbf{a}_n=\mathbf{b}.$$

于是"求解"变成了"**用 $\mathbf{A}$ 的列向量线性组合出 $\mathbf{b}$，求组合系数**"。
- **几何直觉（它在空间中是什么样子？）**：所有 $x_1\mathbf{a}_1+x_2\mathbf{a}_2$ 的集合（x_1,x_2 取遍实数）是一张**通过原点的平面**——这就是列空间 $C(\mathbf{A})$（在 $\mathbb{R}^2$ 中通常就是整个平面，在 $\mathbb{R}^3$ 中通常是过原点的一张平面或一整条直线）。$\mathbf{b}$ 落在其中，就有解；落在其外，就无解。**系数 (x_1,x_2) 是"配料表"，$\mathbf{b}$ 是"成品"**。
- **具体示例**：$\mathbf{a}_1=\begin{bmatrix}2\\-1\end{bmatrix}$ 指向右下，$\mathbf{a}_2=\begin{bmatrix}-1\\2\end{bmatrix}$ 指向左上。$\mathbf{b}=\begin{bmatrix}0\\3\end{bmatrix}$ 是目标。取 1 份 $\mathbf{a}_1$ 加 2 份 $\mathbf{a}_2$：$1\cdot(2,-1)+2\cdot(-1,2)=(2-2,\,-1+4)=(0,3)$。命中。

为什么列图像是核心视角

- **定义与目的**：行图像把注意力放在"约束"上，列图像把注意力放在"**矩阵的作用**"上。线性代数的整门课（子空间、秩、投影、最小二乘、特征值）都是在研究"$\mathbf{A}$ 能把哪些向量造出来"以及"$\mathbf{A}$ 把哪些向量压成零"。
- **几何直觉（它在空间中是什么样子？）**：行图像随方程数 m 增长而规划数爆炸——1000 个方程就是 1000 张超平面求交，画不出来也想不清楚。列图像只问一件事：$\mathbf{b}$ 在不在这 n 个向量张成的"可达区域"里？**这个问题的答案是子空间的语言，与 m 无关**。
- **具体示例**：考虑 $\mathbf{A}=\begin{bmatrix}1&2\\2&4\end{bmatrix}$（奇异）。行图像：两条直线 $x+2y=b_1$ 与 $2x+4y=b_2$ 平行，能否相交只取决于 $b_2=2b_1$ 这一个标量条件。列图像：$\mathbf{a}_2=2\mathbf{a}_1$，两列**共线**，可造出的向量只有 $\mathbb{R}^2$ 中过原点的一条直线——$\mathbf{b}$ 要么在这条线上，要么无解。列图像把"为什么有的 $\mathbf{b}$ 无解"变成了一个**一维的几何事实**。

矩阵形式 $\mathbf{Ax}=\mathbf{b}$

- **定义与目的**：把系数装进矩阵、未知数装进向量、右端常数装进向量。矩阵形式的价值是**记号经济**与**算法通用**：解 2×2 与解 1000×1000 写出来是同一行符号。

- **几何直觉（它在空间中是什么样子？）**：忘掉"矩形数组"这个印象。$\mathbf{A}$ 是一个**函数**：它把 $\mathbb{R}^n$ 中的向量 $\mathbf{x}$ 送到 $\mathbb{R}^m$ 中的向量 $\mathbf{Ax}$。求解 $\mathbf{Ax}=\mathbf{b}$ 就是问"哪个输入被送到 $\mathbf{b}$"，即求**原像**。
- **具体示例**：$\begin{bmatrix}2&-1\\-1&2\end{bmatrix}\begin{bmatrix}1\\2\end{bmatrix}=\begin{bmatrix}0\\3\end{bmatrix}$。左边是函数作用，右边是目标。

矩阵乘向量的两种读法（two readings of $\mathbf{Ax}$）

- **定义与目的**：同一个乘积 $\mathbf{Ax}$ 有两种完全等价的计算途径。**第一种（按列读，column reading）**：$\mathbf{Ax}$ 是 $\mathbf{A}$ 各列的线性组合，系数就是 $\mathbf{x}$ 的分量。

$$\mathbf{Ax}=x_1\mathbf{a}_1+x_2\mathbf{a}_2+\cdots+x_n\mathbf{a}_n.$$

第二种（按行读，row reading）：$\mathbf{Ax}$ 的第 i 个分量是 $\mathbf{A}$ 的第 i 行与 $\mathbf{x}$ 的**点积**。

$$(\mathbf{Ax})_i=\mathbf{row}_i\cdot\mathbf{x}=a_{i1}x_1+a_{i2}x_2+\cdots+a_{in}x_n.$$

- **几何直觉（它在空间中是什么样子？）**：按列读时，你在 $\mathbb{R}^m$ 里"走折线"——把 x_1 份 $\mathbf{a}_1$、x_2 份 $\mathbf{a}_2$ 首尾相接，终点就是 $\mathbf{Ax}$；这是**输出空间**里的作图。按行读时，你在 $\mathbb{R}^n$ 里对 $\mathbf{x}$ 逐个"投影"到每一条行方向上，量出它在该方向的分量；这是**输入空间**里的测量。两者结果必然相同，但**脑子里浮现的图像完全不同**。
- **具体示例**：取 $\mathbf{A}=\begin{bmatrix}2&-1\\-1&2\end{bmatrix}$，$\mathbf{x}=\begin{bmatrix}1\\2\end{bmatrix}$。
- 按列读：$1\begin{bmatrix}2\\-1\end{bmatrix}+2\begin{bmatrix}-1\\2\end{bmatrix}=\begin{bmatrix}2\\-1\end{bmatrix}+\begin{bmatrix}-2\\4\end{bmatrix}=\begin{bmatrix}0\\3\end{bmatrix}$。
- 按行读：第 1 分量 $=2\cdot1+(-1)\cdot2=0$；第 2 分量 $=(-1)\cdot1+2\cdot2=3$。得 $\begin{bmatrix}0\\3\end{bmatrix}$。**两法结果一致，已验算。**

为什么"矩阵乘法就是列的线性组合"是必须内化的信条

- **定义与目的**：Strang 在 18.06 第一讲就把这句话钉在黑板上，因为它把矩阵乘法从一个"逐元素相乘再求和"的机械规则，升级为一个**几何动作**：矩阵是"配料表"，向量是"用量"，乘积是"成品"。
- **几何直觉（它在空间中是什么样子？）**：把 $\mathbf{A}$ 想象成一台机器的**可用零件清单**（$\mathbf{a}_1,\dots,\mathbf{a}_n$ 是它能提供的 n 种基本动作）。给它一个 $\mathbf{x}$，就是告诉它"各做几份"。输出的 $\mathbf{Ax}$ 永远困在这 n 个零件的张成空间 $C(\mathbf{A})$ 里——**机器造不出清单外的东西**。这正是"$\mathbf{b}\in C(\mathbf{A})$ 才可解"的物理含义。
- **具体示例**：$\mathbf{A}=\begin{bmatrix}1&2\\2&4\end{bmatrix}$ 的两列共线。无论 $\mathbf{x}$ 取什么，$\mathbf{Ax}$ 永远落在直线 $y=2x$ 上：$\mathbf{A}\begin{bmatrix}1\\0\end{bmatrix}=\begin{bmatrix}1\\2\end{bmatrix}$，$\mathbf{A}\begin{bmatrix}0\\1\end{bmatrix}=\begin{bmatrix}2\\4\end{bmatrix}$，$\mathbf{A}\begin{bmatrix}3\\-1\end{bmatrix}=\begin{bmatrix}1\\2\end{bmatrix}$——三个输出全在 $y=2x$ 上。

计算步骤与手算演示

示例 1：Strang 招牌 2×2 方程组——三视角算到底

方程组：

$$2x-y=0,\qquad -x+2y=3.$$

步骤 1：写成矩阵形式。

$$\mathbf{A}=\begin{bmatrix}2&-1\\-1&2\end{bmatrix},\qquad \mathbf{x}=\begin{bmatrix}x\\y\end{bmatrix},\qquad \mathbf{b}=\begin{bmatrix}0\\3\end{bmatrix}.$$

步骤 2：行图像——把两条直线写出来。

方程 1：$2x-y=0\Rightarrow y=2x$，斜率 2，过原点。 方程 2：$-x+2y=3\Rightarrow y=\dfrac{3+x}{2}$，斜率 $\dfrac{1}{2}$，过 $(0,1.5)$。

两条直线的斜率 $2\neq\frac{1}{2}$，不平行，唯一交点。联立：

$$2x=\frac{3+x}{2}\implies 4x=3+x\implies 3x=3\implies x=1,$$

代回 $y=2x=2$。交点 $(1,2)$。回代检验：$2(1)-(2)=0$ ✓，$-(1)+2(2)=3$ ✓。

步骤 3：画出行图像（ASCII）。

```
y \ x |  -1    0    1    2    3
------+-------------------------------
  4   |   .    .    .    A    .
  3   |   .    .    .    .    B
  2   |   .    .    ★    .    .
  1   |   B    .    .    .    .
  0   |   .    A    .    .    .
 -1   |   .    .    .    .    .
 -2   |   A    .    .    .    .

A = 直线 1: y = 2x        上的格点 (斜率 2, 陡)
B = 直线 2: y = (3+x)/2   上的格点 (斜率 1/2, 缓)
★ = (1, 2)  两线唯一交点 = 方程组的唯一解

注意: 直线 2 还经过 (0, 1.5) 与 (2, 2.5), 落在格点行之间.
直线 1 的格点: (-1,-2), (0,0), (1,2), (2,4)
直线 2 的格点: (-1,1), (1,2), (3,3)
```

步骤 4：列图像——按列切开。

$$\mathbf{a}_1 = \begin{bmatrix} 2 \\ -1 \end{bmatrix}, \qquad \mathbf{a}_2 = \begin{bmatrix} -1 \\ 2 \end{bmatrix}.$$

要解的是 $x\mathbf{a}_1 + y\mathbf{a}_2 = \begin{bmatrix} 0 \\ 3 \end{bmatrix}$。

步骤 5：彩排（Strang 的 "try a combination"）。

先试整数系数。取 $x = 1, y = 2$：

$$1 \cdot \begin{bmatrix} 2 \\ -1 \end{bmatrix} + 2 \cdot \begin{bmatrix} -1 \\ 2 \end{bmatrix} = \begin{bmatrix} 2 \\ -1 \end{bmatrix} + \begin{bmatrix} -2 \\ 4 \end{bmatrix} = \begin{bmatrix} 0 \\ 3 \end{bmatrix}.$$

命中，所以 $(x, y) = (1, 2)$。

步骤 6：画列图像的向量组合（ASCII）。

```
      y
    4 |          D ● 2a2 = (-2, 4)
      |         /|
    3 |        / ★ C = a1 + 2a2 = (0, 3) = b
      |       / /
    2 |  B ● /              B = a2 = (-1, 2)
      |   | /
    1 |   |/
      |   /
------.--+----------------------------  x
 -2  -1  0    1    2    3
      |   \
   -1 |    \  A ●          A = a1 = (2, -1)

平行四边形 O-A-C-D :
  O -> A  = a1   = (2, -1)
  O -> D  = 2a2  = (-2, 4)
  A -> C  平行于 a2 方向 (边 A->C = 2a2)
  D -> C  平行于 a1 方向 (边 D->C = a1)
对角线 O -> C 就是 b = (0, 3).

"解方程组" = "找到正确的配比 (1 份 a1, 2 份 a2) 使
 平行四边形对角线的终点正好落在 b 上".
```

步骤 7：数一数解的个数（用格点法验证唯一性）。

因为 $\mathbf{a}_1, \mathbf{a}_2$ 不成比例（$\det = 3 \neq 0$），任何 $\mathbf{b}$ 都有唯一配比。用 Cramer 公式交叉验证：

- x：把 $\mathbf{A}$ 第 1 列换成 $\mathbf{b}$，$\det \begin{bmatrix} 0 & -1 \\ 3 & 2 \end{bmatrix} = 0 \cdot 2 - (-1) \cdot 3 = 3$，故 $x = 3/3 = 1$。
- y：把第 2 列换成 $\mathbf{b}$，$\det \begin{bmatrix} 2 & 0 \\ -1 & 3 \end{bmatrix} = 2 \cdot 3 - 0 \cdot (-1) = 6$，故 $y = 6/3 = 2$。
- $\det \mathbf{A} = 2 \cdot 2 - (-1) \cdot (-1) = 4 - 1 = 3$。两处 $\det$ 都为 3，结果自洽。

【计算机制解说】：为什么列图像给出的答案与行图像必然一致？因为二者是**同一个等式**的两种排版。行 i 与 $\mathbf{x}$ 做点积得 b_i，这等价于说"$\sum_j x_j a_{ij} = b_i$"；而对每个 i 都成立，正是"$\sum_j x_j \mathbf{a}_j = \mathbf{b}$"的逐分量写法。行视角按 i（方程的编号）组织，列视角按 j（未知数的编号）组织——同

一个二维数表，横着读和竖着读。真正重要的差别在于：行视角的"可解性"问题是 m 个约束的相容性，列视角的可解性问题是 $\mathbf{b}$ 是否在 $\{\mathbf{a}_j\}$ 的张成空间中——后者是一个可以用**秩**（rank）一句话回答的问题。

示例 2：3×3 例子——三平面交于一点

方程组（选简单整数，保证手算可追踪）：

$$x+y=3,\qquad y+z=3,\qquad x+z=4.$$

步骤 1：矩阵形式。

$$\mathbf{A}=\begin{bmatrix}1&1&0\\0&1&1\\1&0&1\end{bmatrix},\qquad \mathbf{b}=\begin{bmatrix}3\\3\\4\end{bmatrix}.$$

步骤 2：行图像——三个平面。

- $x+y=3$：法向量 $(1,1,0)$，垂直于 z 轴、平行于 z 轴的竖直平面。
- $y+z=3$：法向量 $(0,1,1)$。
- $x+z=4$：法向量 $(1,0,1)$。

三个法向量两两不成比例（任意两个叉积非零），故三平面不平行、不共轴。它们交于唯一一点。

步骤 3：快速求解（方程相加技巧）。

三式相加：$(x+y)+(y+z)+(x+z)=3+3+4$，即

$$2(x+y+z)=10\implies x+y+z=5.$$

于是

$$x=(x+y+z)-(y+z)=5-3=2,$$

$$y=(x+y+z)-(x+z)=5-4=1,$$

$$z=(x+y+z)-(x+y)=5-3=2.$$

解 $\mathbf{x}=(2,1,2)$。检验：$2+1=3$ ✓，$1+2=3$ ✓，$2+2=4$ ✓。

步骤 4：列图像——三个向量的组合。

$$\mathbf{a}_1=\begin{bmatrix}1\\0\\1\end{bmatrix},\quad \mathbf{a}_2=\begin{bmatrix}1\\1\\0\end{bmatrix},\quad \mathbf{a}_3=\begin{bmatrix}0\\1\\1\end{bmatrix}.$$

验证 $2\mathbf{a}_1+1\mathbf{a}_2+2\mathbf{a}_3$：

$$2\begin{bmatrix}1\\0\\1\end{bmatrix}+\begin{bmatrix}1\\1\\0\end{bmatrix}+2\begin{bmatrix}0\\1\\1\end{bmatrix}=\begin{bmatrix}2\\0\\2\end{bmatrix}+\begin{bmatrix}1\\1\\0\end{bmatrix}+\begin{bmatrix}0\\2\\2\end{bmatrix}=\begin{bmatrix}3\\3\\4\end{bmatrix}=\mathbf{b}.\checkmark$$

步骤 5：为什么这三列能张成整个 $\mathbb{R}^3$？

对 $\mathbf{A}$ 做消元（预告后续讲次）：

```
初始                      R3 <- R3 - 1*R1          R3 <- R3 + 1*R2
[ 1  1  0 | 3 ]           [ 1  1  0 | 3 ]          [ 1  1  0 | 3 ]
[ 0  1  1 | 3 ]   --->    [ 0  1  1 | 3 ]   --->   [ 0  1  1 | 3 ]
[ 1  0  1 | 4 ]           [ 0 -1  1 | 1 ]          [ 0  0  2 | 4 ]

主元 (pivots): 1, 1, 2    三个主元都非零  =>  A 可逆
回代: 2z = 4 -> z = 2
      y + z = 3 -> y = 1
      x + y = 3 -> x = 2
```

三个主元 $1,1,2$ 全部非零，乘积 $1\cdot 1\cdot 2=2$ 就是 $\det\mathbf{A}$。$\det\neq 0\Rightarrow$ 三列线性无关 $\Rightarrow$ 它们张成整个 $\mathbb{R}^3\Rightarrow$ **任意 $\mathbf{b}\in\mathbb{R}^3$ 都可解，且解唯一**。

步骤 6：列图像几何（示意）。

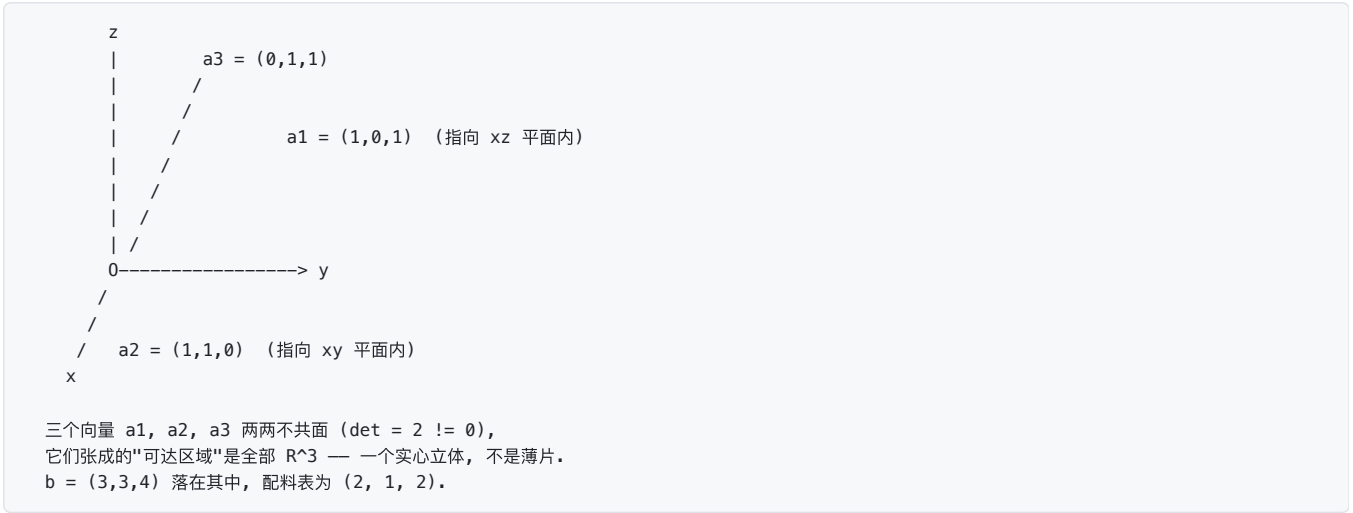

【计算机制解说】：$m = n = 3$ 且 $\det \neq 0$ 时，三个列向量构成 $\mathbb{R}^3$ 的一组**基**（basis）。此时"用三列组合出 $\mathbf{b}$"等价于"用一组基给 $\mathbf{b}$ 换坐标"，而基的存在性与唯一性都由 $\det \neq 0$ 保证。这就是为什么消元法（把 $\mathbf{A}$ 变成上三角）能同时回答"有没有解"（主元个数）与"怎么求解"（回代）两个问题——它把"三列是否张满"这个几何问题翻译成了"主元是否全部非零"这个算术问题。

示例 3：奇异 2×2——无解与无穷多解的分界

$$\mathbf{A} = \begin{bmatrix} 1 & 2 \\ 2 & 4 \end{bmatrix}, \qquad \det \mathbf{A} = 1 \cdot 4 - 2 \cdot 2 = 0.$$

步骤 1：行图像。

$$\text{直线 } \mathbf{1}\text{: } x + 2y = b_1, \qquad \text{直线 } \mathbf{2}\text{: } 2x + 4y = b_2.$$

第二条方程的左端恰好是第一条的 2 倍。法向量 $(1,2)$ 与 $(2,4)$ **成比例**，所以两直线**平行**（或重合）。

步骤 2：列图像。

$$\mathbf{a}_1 = \begin{bmatrix} 1 \\ 2 \end{bmatrix}, \qquad \mathbf{a}_2 = \begin{bmatrix} 2 \\ 4 \end{bmatrix} = 2\mathbf{a}_1.$$

两列**共线**。它们的全部线性组合 $x\mathbf{a}_1 + y\mathbf{a}_2 = (x + 2y)\mathbf{a}_1$ 只能扫出 $\mathbb{R}^2$ 中过原点、方向为 $(1,2)$ 的**一条直线**。这就是列空间 $C(\mathbf{A})$——维数为 1（秩 $r = 1$）。

步骤 3：分类讨论 $\mathbf{b}$。

(a) $\mathbf{b} = \begin{bmatrix} 3 \\ 6 \end{bmatrix}$（在 $C(\mathbf{A})$ 上）：

因为 $\mathbf{b} = 3\mathbf{a}_1 = 3\begin{bmatrix} 1 \\ 2 \end{bmatrix}$，取 $(x, y) = (3, 0)$ 即可。但列共线意味着**表示不唯一**：

$$(3,0)\text{：}\ 3 + 2 \cdot 0 = 3\ \checkmark; \qquad (1,1)\text{：}\ 1 + 2 \cdot 1 = 3\ \checkmark; \qquad (-1,2)\text{：}\ -1 + 2 \cdot 2 = 3\ \checkmark.$$

通解：设 $y = t$，则 $x + 2t = 3 \Rightarrow x = 3 - 2t$，即

$$\begin{bmatrix} x \\ y \end{bmatrix} = \begin{bmatrix} 3 \\ 0 \end{bmatrix} + t\begin{bmatrix} -2 \\ 1 \end{bmatrix}, \qquad t \in \mathbb{R}.$$

一条直线上的全部点都是解——无穷多解。

(b) $\mathbf{b} = \begin{bmatrix} 0 \\ 1 \end{bmatrix}$（不在 $C(\mathbf{A})$ 上）：

需要 $x + 2y = 0$ 且 $2x + 4y = 1$。第一个方程给出 $2x + 4y = 2(x + 2y) = 0$，第二个要求它等于 1。$0 = 1$ 矛盾。**无解。**

几何上：$\mathbf{b} = (0,1)$ 与 $\mathbf{a}_1 = (1,2)$ 不成比例（$\det \begin{bmatrix} 1 & 0 \\ 2 & 1 \end{bmatrix} = 1 \neq 0$），所以 $\mathbf{b}$ 不在那条直线 $C(\mathbf{A})$ 上。

步骤 4：算一下数一数解的个数。

```
b 在 C(A) 上 ?       行图像                          解集
------------------------------------------------------------------------
b = (3,6)  = 3*a1    两直线重合（同一条线）          无穷多解（一条直线）
b = (0,0)            两直线重合，过原点              无穷多解（一条直线）
b = (0,1)            平行不重合（x+2y=0 与 =0.5）   无解
b = (5,10) = 5*a1    两直线重合                        无穷多解
b = (1,3)            不相容（消元得 0 = 1）          无解
```

判定口诀：$\mathbf{b}$ **在不在** $C(\mathbf{A})$ **上**，等价于 $\mathbf{b}$ 在不在"行图像中两直线重合的那条位置"上。秩 $r = 1 < n = 2$，所以只要相容就必有无穷多解。

【计算机制解说】：奇异情形下"无解/无穷多解"的分野完全由 $\mathbf{b}$ 决定，而与 $\mathbf{A}$ 无关。用列语言说：$\mathbf{A}$ 的作用是把 $\mathbb{R}^2$ **压扁**到一条直线上（降维），所以很多不同的 $\mathbf{x}$ 被送到同一个像点；这就是"解不唯一"的来源。而 $\mathbf{b}$ 若在这条直线之外，则**根本没有**原像，这就是"无解"的来源。**压缩 → 多对一 → 无穷多解；像外 → 无原像 → 无解。** 这两个现象是同一件事（秩亏损）的两面。

示例 4：奇异 3×3——列向量共面

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & 3 \\ 2 & 4 & 6 \\ 1 & 0 & 1 \end{bmatrix}.$$

三列：$\mathbf{a}_1 = (1,2,1)$，$\mathbf{a}_2 = (2,4,0)$，$\mathbf{a}_3 = (3,6,1)$。注意 $\mathbf{a}_1 + \mathbf{a}_2 = (1+2,\ 2+4,\ 1+0) = (3,6,1) = \mathbf{a}_3$。

步骤 1：验算行列式。

$$\det \mathbf{A} = 1(4 \cdot 1 - 6 \cdot 0) - 2(2 \cdot 1 - 6 \cdot 1) + 3(2 \cdot 0 - 4 \cdot 1) = 1(4) - 2(-4) + 3(-4) = 4 + 8 - 12 = 0.$$

$\det = 0$，奇异。同时第 2 行 $= (2,4,6) = 2 \cdot (1,2,3) = 2\times$ 第 1 行。

步骤 2：列空间的几何。

三列中只有两个独立方向（$\mathbf{a}_3 = \mathbf{a}_1 + \mathbf{a}_2$），所以

$$C(\mathbf{A}) = \operatorname{span}\{\mathbf{a}_1, \mathbf{a}_2\} = \operatorname{span}\{(1,2,1),\ (2,4,0)\}$$

是 $\mathbb{R}^3$ 中过原点的一张**平面**（二维），秩 $r = 2$。

步骤 3：行图像——三张平面。

- Π_1：$x + 2y + 3z = b_1$
- Π_2：$2x + 4y + 6z = b_2$（与 Π_1 平行或重合）
- Π_3：$x + z = b_3$

三张平面**不交于一点**，而是交于一条直线、或两两交线互相平行而无公共点、或完全重合。

步骤 4：两个具体 $\mathbf{b}$ 的对照。

(a) $\mathbf{b} = (3,6,1)$：由 $\mathbf{a}_3 = \mathbf{a}_1 + \mathbf{a}_2$，取 $(x,y,z) = (1,1,0)$：

$$1 \cdot \begin{bmatrix} 1 \\ 2 \\ 1 \end{bmatrix} + 1 \cdot \begin{bmatrix} 2 \\ 4 \\ 0 \end{bmatrix} + 0 \cdot \begin{bmatrix} 3 \\ 6 \\ 1 \end{bmatrix} = \begin{bmatrix} 3 \\ 6 \\ 1 \end{bmatrix} \checkmark$$

解不唯一：因为 $\mathbf{a}_3 = \mathbf{a}_1 + \mathbf{a}_2$，即 $\mathbf{a}_1 + \mathbf{a}_2 - \mathbf{a}_3 = \mathbf{0}$，所以任何 $(1+t,\ 1+t,\ -t)$ 都是解，无穷多解（解集是 $\mathbb{R}^3$ 中一条直线）。

(b) $\mathbf{b} = (0,0,1)$：设 $x\mathbf{a}_1 + y\mathbf{a}_2 + z\mathbf{a}_3 = (0,0,1)$。用 $\mathbf{a}_3 = \mathbf{a}_1 + \mathbf{a}_2$ 合并同类项：

$$(x+z)\begin{bmatrix} 1 \\ 2 \\ 1 \end{bmatrix} + (y+z)\begin{bmatrix} 2 \\ 4 \\ 0 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix}.$$

令 $s = x + z$，$t = y + z$（两个"合并后的配方量"），则要求

$$\begin{cases} s + 2t = 0 & (\text{第 } 1 \text{ 分量}) \\ 2s + 4t = 0 & (\text{第 } 2 \text{ 分量}) \\ s + 0t = 1 & (\text{第 } 3 \text{ 分量}) \end{cases}$$

第 3 式给出 $s = 1$，代入第 1 式得 $1 + 2t = 0 \Rightarrow t = -\frac{1}{2}$，再检验第 2 式：$2(1) + 4(-\frac{1}{2}) = 2 - 2 = 0$ ✓。**三式相容**，所以 $\mathbf{b} = (0,0,1)$ 确实在 $C(\mathbf{A})$ 中。取 $z = 0$ 回代即 $x = s = 1$、$y = t = -\frac{1}{2}$：

$$1 \cdot \begin{bmatrix} 1 \\ 2 \\ 1 \end{bmatrix} - \tfrac{1}{2}\begin{bmatrix} 2 \\ 4 \\ 0 \end{bmatrix} = \begin{bmatrix} 1-1 \\ 2-2 \\ 1-0 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix} \checkmark$$

这说明 $\mathbf{b}=(0,0,1)$ 恰好落在 $C(\mathbf{A})$ 这张平面上。 顺便注意：两个"合并后的配方量" $(s,t)=(1,-\frac{1}{2})$ 是**唯一**的（因为 $\mathbf{a}_1,\mathbf{a}_2$ 独立），但 (x,y,z) 有原方程组 $x+z=1,\ y+z=-\frac{1}{2}$ 的自由度——令 z 任取，就得到无穷多组 (x,y,z)。**"列空间内的可解性判定"与"解的个数"是两个不同层面的问题：前者看 $\mathbf{b}$ 与 $C(\mathbf{A})$，后者看 r 与 n。**

要找**不在** $C(\mathbf{A})$ 上的 $\mathbf{b}$，用法向量一步判定。$\mathbf{a}_1\times\mathbf{a}_2$ 垂直于 $C(\mathbf{A})$：

$$\mathbf{a}_1\times\mathbf{a}_2=\begin{vmatrix}\mathbf{i}&\mathbf{j}&\mathbf{k}\\1&2&1\\2&4&0\end{vmatrix}=(2\cdot0-1\cdot4,\ 1\cdot2-1\cdot0,\ 1\cdot4-2\cdot2)=(-4,\ 2,\ 0).$$

平面方程：$-4x+2y+0z=0$，即 $y=2x$。取 $\mathbf{b}=(0,1,0)$（$y=1\neq2\cdot0=0$），则 $\mathbf{b}\notin C(\mathbf{A})\Rightarrow$ **无解**。

步骤 5：小结表格。

```
A = [[1,2,3],[2,4,6],[1,0,1]]   rank r = 2 < n = 3
C(A) = 平面 -4x + 2y = 0 (即 y = 2x), 过原点

b               在 C(A)?     解集
------------------------------------------------------------
(3,6,1)         是 (r=2)     无穷多解 (一条直线)
(0,0,1)         是           无穷多解 (一条直线)
(0,0,0)         是           无穷多解 (一条直线)
(0,1,0)         否 (1 != 0)  无解
(1,0,0)         否 (0 != 2)  无解
(2,4,0)         是 (4 = 4)   无穷多解 (一条直线)
(2,1,0)         否 (1 != 4)  无解
```

【计算机制解说】：秩 $r=2<n=3$ 意味着 $\mathbf{A}$ 的零空间 $N(\mathbf{A})$ 非平凡（$\dim N(\mathbf{A})=n-r=1$），也就是存在非零的 $\mathbf{x}_0$ 使 $\mathbf{A}\mathbf{x}_0=\mathbf{0}$。这里 $\mathbf{x}_0=(1,1,-1)$。于是"一个特解 $+$ 任意零空间向量"还是解——这就是无穷多解的代数根源。另一方面，$C(\mathbf{A})$ 的维数是 $r=2<3=m$，所以 $\mathbb{R}^3$ 中必有向量落在 $\mathbf{A}$ 张不到的地方——这就是无解的几何根源。**$r=n$ 保证唯一性，$r=m$ 保证存在性。**

示例 5：长方形矩阵 3×2——当 $m\neq n$ 时列图像照样好用

行图像在 $m\neq n$ 时会彻底失灵（"2 个未知数、3 个方程"你无法画成三条直线的交点，因为三条直线一般不可能共点）。列图像却毫无障碍。

$$\mathbf{A}=\begin{bmatrix}1&0\\0&1\\1&1\end{bmatrix}\quad(m=3,\ n=2),\qquad\mathbf{b}=\begin{bmatrix}2\\3\\5\end{bmatrix}.$$

步骤 1：列图像。

$$\mathbf{a}_1=\begin{bmatrix}1\\0\\1\end{bmatrix},\qquad\mathbf{a}_2=\begin{bmatrix}0\\1\\1\end{bmatrix}.$$

要解 $x\mathbf{a}_1+y\mathbf{a}_2=\mathbf{b}$，即

$$x\begin{bmatrix}1\\0\\1\end{bmatrix}+y\begin{bmatrix}0\\1\\1\end{bmatrix}=\begin{bmatrix}x\\y\\x+y\end{bmatrix}=\begin{bmatrix}2\\3\\5\end{bmatrix}.$$

第 1、2 分量直接给出 $x=2,\ y=3$；第 3 分量复核 $x+y=2+3=5$ ✓。**唯一解 $(2,3)$。**

步骤 2：几何——$C(\mathbf{A})$ 是一张平面。

两个列向量在 $\mathbb{R}^3$ 中张开一张过原点的平面。法向量

$$\mathbf{a}_1\times\mathbf{a}_2=\begin{vmatrix}\mathbf{i}&\mathbf{j}&\mathbf{k}\\1&0&1\\0&1&1\end{vmatrix}=(0\cdot1-1\cdot1,\ 1\cdot0-1\cdot1,\ 1\cdot1-0\cdot0)=(-1,-1,1).$$

平面方程：$-x-y+z=0$，即 $z=x+y$。**判定 $\mathbf{b}$ 只需一行算术：$b_3\overset{?}{=}b_1+b_2$。**

```
b             b3 == b1+b2 ?    结论
-----------------------------------------------------
(2,3,5)       5 == 2+3  ✓      在 C(A) 内, 唯一解 (2,3)
(1,1,2)       2 == 1+1  ✓      在 C(A) 内, 唯一解 (1,1)
(0,1,1)       1 == 0+1  ✓      在 C(A) 内, 唯一解 (0,1)
(1,1,3)       3 != 1+1  ✗      不在 C(A), 无解
(1,2,4)       4 != 1+2  ✗      不在 C(A), 无解
```

步骤 3：为什么这里"有解就唯一"？

$n=2$，两列 $\mathbf{a}_1,\mathbf{a}_2$ 不成比例（$x\mathbf{a}_1+y\mathbf{a}_2=\mathbf{0}$ 强制 $x=0$ 且 $y=0$），所以 $r=n=2$，$\dim N(\mathbf{A})=n-r=0$。**没有零空间方向可供滑动，所以解一旦存在就唯一。** 这跟示例 4（$r=2<n=3$）恰好形成对照：同样是 $r=2$，一个唯一、一个无穷多，差别全在 r 与 n 的关系。

步骤 4：$m<n$ 的情形（宽矩阵，方程少于未知数）。

把上面的 $\mathbf{A}$ 转置，得 2×3 矩阵

$$\mathbf{A}^T=\begin{bmatrix}1&0&1\\0&1&1\end{bmatrix}.$$

此时 $n=3>m=2$，$r=2$，于是 $\dim N(\mathbf{A}^T)=n-r=3-2=1\neq 0$。对任何相容的右端，解集都是 $\mathbb{R}^3$ 中一条直线——**$m<n$ 时若有解必有无穷多解，绝不可能唯一。** 例如 $\mathbf{b}=(1,1)$，则 $x+z=1$ 与 $y+z=1$，通解 $(1-t,\ 1-t,\ t)$；取 $t=0$ 得 $(1,1,0)$，取 $t=1$ 得 $(0,0,1)$，两者都满足。

【计算机制解说】：$m\neq n$ 时行图像之所以失灵，是因为"m 个方程"对应 n 维空间中的 m 张超平面，而 $m>n$ 时它们一般不可能有公共点，$m<n$ 时一般会交出一条低维的集合。**行图像的"是不是正好交于一点"这个问题依赖 $m=n$ 的巧合**；列图像的"$\mathbf{b}$ 在不在 $C(\mathbf{A})$ 上"哪怕 $m\neq n$ 也照样有意义，因为 $C(\mathbf{A})$ 永远是 $\mathbb{R}^m$ 中一个良定义的子空间。这就是"列图像才是核心视角"最直接的证据。

示例 6（可视化）：把 $\mathbf{A}$ 当成线性变换——单位正方形被送成什么？

仍取 $\mathbf{A}=\begin{bmatrix}2&-1\\-1&2\end{bmatrix}$。跟踪 $\mathbb{R}^2$ 中单位正方形的四个顶点被送到哪里：

```
输入（单位正方形）                    输出（平行四边形）
y                                     y
2|                                    4|        (0,1)->(-1,2)
1+-----+ (1,1)                        3|       /|
 |     |                              2|  (-1,2)●  /  ●(2,-1)... 见下
 |     |                              1|      /  ● (1,1)->(1,1)
0+-----+---- x                        0+------●---------- x
 0     1                              -1|   (1,0)->(2,-1)

四个顶点的像（已验算）：
  (0,0)  ->  (0, 0)
  (1,0)  ->  (2, -1)      = a1
  (0,1)  ->  (-1, 2)      = a2
  (1,1)  ->  (1, 1)       = a1 + a2
面积：原来 1，现在 |det A| = |3| = 3
```

读法： $\mathbf{A}$ 把"输入空间 $\mathbb{R}^2$ 的坐标轴方向"送成"$\mathbf{A}$ 的两个列向量"。单位正方形的像正是由 $\mathbf{a}_1,\mathbf{a}_2$ 张成的平行四边形，面积放大倍数就是 $|\det\mathbf{A}|=3$。**解 $\mathbf{Ax}=\mathbf{b}$ 就是在问："哪一个输入点被送到输出点 $\mathbf{b}$？"**

再对比奇异矩阵 $\mathbf{S}=\begin{bmatrix}1&2\\2&4\end{bmatrix}$：$\mathbf{S}\begin{bmatrix}1\\0\end{bmatrix}=\begin{bmatrix}1\\2\end{bmatrix}$，$\mathbf{S}\begin{bmatrix}0\\1\end{bmatrix}=\begin{bmatrix}2\\4\end{bmatrix}$，两列共线，单位正方形的像被**压扁成一条线段**，面积倍数 $|\det\mathbf{S}|=0$。**降维就是不可逆**——这句几何直觉将来会在行列式与秩的每一讲反复出现。

矩阵分解的核心思想

本讲没有正式引入矩阵分解，但要指出两个方向的伏笔。

伏笔一：消元 $\leftrightarrow\ \mathbf{A}=\mathbf{LU}$。 本讲示例 1 与示例 2 的求解过程，本质上都是消元：

- 示例 1：把第 1 个方程乘 $\frac{1}{2}$ 得 $x-\frac{1}{2}y=0$，加到第 2 个方程上，得 $\frac{3}{2}y=3\Rightarrow y=2$，再回代得 $x=1$。写成分解：

$$\mathbf{L}=\begin{bmatrix}1&0\\-\frac{1}{2}&1\end{bmatrix},\qquad \mathbf{U}=\begin{bmatrix}2&-1\\0&\frac{3}{2}\end{bmatrix},\qquad \mathbf{LU}=\begin{bmatrix}2&-1\\-1&2\end{bmatrix}=\mathbf{A}.$$

乘数（multiplier）$\ell_{21}=-\frac{1}{2}$ 正是 $\mathbf{L}$ 左下角那个数。两个主元 2 与 $\frac{3}{2}$，乘积 $2\cdot\frac{3}{2}=3=\det\mathbf{A}$。– 示例 2 的消元步骤给出 $\mathbf{L}=\begin{bmatrix}1&0&0\\0&1&0\\1&-1&1\end{bmatrix}$，$\mathbf{U}=\begin{bmatrix}1&1&0\\0&1&1\\0&0&2\end{bmatrix}$，且 $\mathbf{LU}=\mathbf{A}$（已验算）。三个主元乘积 $=2=\det\mathbf{A}$。

伏笔二：$\mathbf{A}=\mathbf{CR}$（列 × 行）。 示例 4 的奇异矩阵，三列中只有 $\mathbf{a}_1,\mathbf{a}_2$ 独立，于是

$$\mathbf{A}=\begin{bmatrix}1&2\\2&4\\1&0\end{bmatrix}\begin{bmatrix}1&0&1\\0&1&1\end{bmatrix},$$

其中左因子是 $\mathbf{A}$ 的**独立列**，右因子记录"每列如何由独立列组合而成"。**这就是 $\mathbf{A}=\mathbf{CR}$ 分解的雏形**，也是讲次 10（矩阵的四个基本子空间）里"秩 = 独立列数 = 独立行数"的直观来源。

为什么需要系统化算法。 本讲靠"彩排"和"相加技巧"解出了 2×2 与精心构造的 3×3。但真实问题是 1000×1000，人眼找不到技巧。消元法把"求解"化为**固定三步**：消元成上三角 → 数主元定可解性 → 回代。对 n 个未知数，这只是三重循环，计算机每秒能做十亿次——**人找技巧，机器跑算法**。这就是讲次 2 的主题。

与其他讲次的关联

- **讲次 2（Elimination with Matrices）**：本讲的"相加技巧"将被升级为系统的消元算法与消元矩阵 $\mathbf{E}$；示例 1、2 里出现的 $\mathbf{L},\mathbf{U}$ 会正式登场，形成 $\mathbf{A}=\mathbf{LU}$。
- **讲次 4（Factorization into $\mathbf{A}=\mathbf{LU}$）**：本讲示例 2 的 $\mathbf{L}=\begin{bmatrix}1&0&0\\0&1&0\\1&-1&1\end{bmatrix}$ 就是那一讲的核心对象——单位下三角矩阵，元素就是消元乘数。
- **讲次 6（Column Space and Nullspace）**：本讲示例 3、4 里"$\mathbf{b}$ 是否在列向量张成的直线/平面上"会正式定义为 $\mathbf{b}\in C(\mathbf{A})$，并引入零空间 $N(\mathbf{A})$；示例 4 中 $\mathbf{x}_0=(1,1,-1)$ 正是 $N(\mathbf{A})$ 的基向量。
- **讲次 8（Solving $\mathbf{Ax}=\mathbf{b}$: Complete Solution）**：本讲"无穷多解 = 特解 + 零空间"的观察将升级为完整解公式 $\mathbf{x}=\mathbf{x}_p+\mathbf{x}_n$，并给出可解性的充要条件（$\mathbf{b}\in C(\mathbf{A})$，等价于对 $\mathbf{A}^T\mathbf{y}=\mathbf{0}$ 的每个解都有 $\mathbf{y}^T\mathbf{b}=0$）。
- **讲次 10（The Four Fundamental Subspaces）**：本讲的列空间 $C(\mathbf{A})\subseteq\mathbb{R}^m$ 会被放进四子空间框架，并用 r 统一刻画：$\dim C(\mathbf{A})=r$，$\dim N(\mathbf{A})=n-r$。示例 4 的 $r=2,m=3,n=3$ 是标准练习。
- **讲次 18–20（Determinants）**：本讲反复用 $\det=0$ 判定奇异、用主元乘积核对 $\det$，这些将在行列式一讲得到系统证明：$\det\mathbf{A}=$ 主元之积 = 列向量张成的"体积"。

关键要点

1. **一个方程组，三张面孔。** 行图像 = 超平面求交（在 $\mathbb{R}^n$ 中看）；列图像 = 列向量的线性组合（在 $\mathbb{R}^m$ 中看）；矩阵形式 $\mathbf{Ax}=\mathbf{b}$ 是二者的统一记号。**做线性代数请默认用列图像思考。**
2. **$\mathbf{Ax}$ 就是"以 $\mathbf{x}$ 为系数对 $\mathbf{A}$ 的列做线性组合"**（Strang 的核心语录）。即

$$\mathbf{Ax}=x_1\mathbf{a}_1+x_2\mathbf{a}_2+\cdots+x_n\mathbf{a}_n.$$

等价读法是"行与 $\mathbf{x}$ 做点积"，但只有列读法能解释可解性、秩与子空间。

1. **可解性判据：$\mathbf{Ax}=\mathbf{b}$ 有解 $\iff$ $\mathbf{b}\in C(\mathbf{A})$。** 当 $\det\mathbf{A}\neq 0$（等价于 n 个主元全部非零、$r=n$）时，对**任意** $\mathbf{b}$ 都可解且解唯一：$\mathbf{x}=\mathbf{A}^{-1}\mathbf{b}$。
2. **奇异情形（$r<n$）的两分法**：若 $\mathbf{b}\in C(\mathbf{A})$，则有无穷多解（解集 = 特解 + $N(\mathbf{A})$）；若 $\mathbf{b}\notin C(\mathbf{A})$，则无解。$\mathbf{b}$ 在不在列空间里，是唯一的开关。
3. **列空间是"$\mathbf{A}$ 能造出的全部向量的集合"**，它是 $\mathbb{R}^m$ 中过原点的子空间，维数等于秩 r。行列式为零 = 列向量线性相关 = 列空间被压成低维子空间（直线或平面）= 不是所有 $\mathbf{b}$ 都有解。

常见误区与注意事项

1. **把"行列式为 0"直接等同于"无解"。** 这是最常见也最致命的错误。示例 3 中 $\mathbf{b}=(3,6)$ 就**有**无穷多解。正确的说法是：$\det=0$ 意味着"**要么无解，要么无穷多解**"，究竟哪一种取决于 $\mathbf{b}$ 是否落在 $C(\mathbf{A})$ 里。行列式只回答"唯一性"，不回答"存在性"。
2. **把行空间和列空间混为一谈，或写错所在空间。** 本讲所有列向量都住在 $\mathbb{R}^m$（m 是方程个数、矩阵的行数），所以 $C(\mathbf{A})\subseteq\mathbb{R}^m$；行向量住在 $\mathbb{R}^n$，所以行空间 $C(\mathbf{A}^T)\subseteq\mathbb{R}^n$。示例 4 中 $\mathbf{A}$ 是 3×3，两者都落在 $\mathbb{R}^3$，看起来一样，但换成 3×2 的 $\mathbf{A}$ 就完全不同了——绝不能用示例 4 的巧合掩盖这个区别。
3. **数错维度：把 $n-r$ 和 $m-r$ 张冠李戴。** $\dim N(\mathbf{A})=n-r$（n 是列数、未知数个数），$\dim N(\mathbf{A}^T)=m-r$（m 是行数、方程个数）。示例 4 中 $m=n=3,r=2$，两个都是 1，所以看不出差别；请务必记住公式里 n 跟 $\mathbf{A}$ 走、m 跟 $\mathbf{A}^T$ 走。
4. **在列图像里把组合系数搞成"列向量的分量"。** 在 $x\mathbf{a}_1+y\mathbf{a}_2=\mathbf{b}$ 中，x,y 是**配方比例**，不是任何向量的坐标。示例 3 里 $\mathbf{b}=(3,6)=3\mathbf{a}_1$ 是对的，但千万不要写成"$\mathbf{b}$ 的第 1 个分量是 x"。
5. **以为"$m=n$ 就一定有唯一解"。** 只有当 $m=n$ 且 $\det\mathbf{A}\neq 0$ 时才成立。示例 3、4 都是 $m=n$ 但奇异的反例。$m=n$ 只保证"这是一张方表"，不保证"这张表可逆"。

思考题（带答案）

Q1.（计算题：判断 $\mathbf{b}$ 是否在列空间中） 设

$$\mathbf{A}=\begin{bmatrix}1&0&2\\0&1&3\\1&1&5\end{bmatrix}.$$

(a) 求 $\det \mathbf{A}$ 与 $\operatorname{rank} \mathbf{A}$，并说明 $C(\mathbf{A})$ 是什么。(b) 判断 $\mathbf{b_1} = (1,1,3)$ 是否在 $C(\mathbf{A})$ 中；若在，给出一个组合系数。(c) 判断 $\mathbf{b_2} = (3,5,8)$ 是否在 $C(\mathbf{A})$ 中；若在，给出**两个不同**的组合系数。

> ▸ **答案**
>
> 三列：$\mathbf{a_1} = (1,0,1)$，$\mathbf{a_2} = (0,1,1)$，$\mathbf{a_3} = (2,3,5)$。
>
> (a) 注意 $\mathbf{a_3} = 2\mathbf{a_1} + 3\mathbf{a_2} = (2,0,2) + (0,3,3) = (2,3,5)$ ✓，所以三列线性相关，$\det \mathbf{A} = 0$。

$$\det \mathbf{A} = 1(1\cdot 5 - 3\cdot 1) - 0(0\cdot 5 - 3\cdot 1) + 2(0\cdot 1 - 1\cdot 1) = 1(2) - 0 + 2(-1) = 2 - 2 = 0.\checkmark$$

> $\operatorname{rank} \mathbf{A} = 2$（$\mathbf{a_1}, \mathbf{a_2}$ 显然不成比例）。所以 $C(\mathbf{A}) = \operatorname{span}\{(1,0,1),(0,1,1)\}$，是 $\mathbb{R}^3$ 中过原点的一张平面。其法向量

$$\mathbf{a_1} \times \mathbf{a_2} = \begin{vmatrix} \mathbf{i} & \mathbf{j} & \mathbf{k} \\ 1 & 0 & 1 \\ 0 & 1 & 1 \end{vmatrix} = (0\cdot 1 - 1\cdot 1,\ 1\cdot 0 - 1\cdot 1,\ 1\cdot 1 - 0\cdot 0) = (-1,-1,1).$$

> 平面方程：$-x - y + z = 0$，即 $z = x + y$。**这是判定 $\mathbf{b}$ 的最快办法。**
>
> (b) $\mathbf{b_1} = (1,1,3)$：检验 $z = x + y$？$3 \neq 1 + 1 = 2$。**不在 $C(\mathbf{A})$ 中，无解。**
>
> （用分量法复核：设 $x\mathbf{a_1} + y\mathbf{a_2} + z\mathbf{a_3} = (1,1,3)$。第 1、2 分量给出 $x + 2z = 1$ 与 $y + 3z = 1$，第 3 分量要求 $x + y + 5z = 3$。把前两式相加：$x + y + 5z = 2$，与 3 矛盾。确认无解。）
>
> (c) $\mathbf{b_2} = (3,5,8)$：检验 $z = x + y$？$8 = 3 + 5$ ✓。**在 $C(\mathbf{A})$ 中，有无穷多解。**
>
> - 系数一：取 $z = 0$，则 $x = 3,\ y = 5$，即 $(3,5,0)$。检验：$3(1,0,1) + 5(0,1,1) + 0 = (3,5,8)$ ✓。
> - 系数二：利用 $\mathbf{a_3} = 2\mathbf{a_1} + 3\mathbf{a_2}$，把 $(3,5,0)$ 换成 $z = 1$：需要 $x + 2 = 3 \Rightarrow x = 1$，$y + 3 = 5 \Rightarrow y = 2$，即 $(1,2,1)$。检验：$1(1,0,1) + 2(0,1,1) + 1(2,3,5) = (1+0+2,\ 0+2+3,\ 1+2+5) = (3,5,8)$ ✓。
>
> 一般解：$\begin{bmatrix} x \\ y \\ z \end{bmatrix} = \begin{bmatrix} 3 \\ 5 \\ 0 \end{bmatrix} + t\begin{bmatrix} -2 \\ -3 \\ 1 \end{bmatrix}$。

Q2.（计算题：3×3 列组合求解） 设

$$\mathbf{A} = \begin{bmatrix} 1 & 1 & 0 \\ 0 & 1 & 1 \\ 1 & 0 & 1 \end{bmatrix}, \qquad \mathbf{b} = \begin{bmatrix} 2 \\ 3 \\ 3 \end{bmatrix}.$$

用**列组合**的视角求 $\mathbf{x}$，并用行视角（三平面交点）验证。

> ▸ **答案**
>
> **列视角：** 设 $x\mathbf{a_1} + y\mathbf{a_2} + z\mathbf{a_3} = \mathbf{b}$，即

$$x\begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix} + y\begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix} + z\begin{bmatrix} 0 \\ 1 \\ 1 \end{bmatrix} = \begin{bmatrix} 2 \\ 3 \\ 3 \end{bmatrix}.$$

> 逐分量：

$$\begin{cases} x + y = 2 & (\text{第 } 1 \text{ 分量}) \\ y + z = 3 & (\text{第 } 2 \text{ 分量}) \\ x + z = 3 & (\text{第 } 3 \text{ 分量}) \end{cases}$$

> **技巧：三式相加。** $2(x + y + z) = 2 + 3 + 3 = 8 \Rightarrow x + y + z = 4$。于是

$$z = 4 - (x + y) = 4 - 2 = 2, \qquad x = 4 - (y + z) = 4 - 3 = 1, \qquad y = 4 - (x + z) = 4 - 3 = 1.$$

> 解 $\mathbf{x} = (1,1,2)$。**检验：**

– – – – – – – – – – – – – –

$$1\begin{bmatrix}1\\0\\1\end{bmatrix}+1\begin{bmatrix}1\\1\\0\end{bmatrix}+2\begin{bmatrix}0\\1\\1\end{bmatrix}=\begin{bmatrix}1\\0\\1\end{bmatrix}+\begin{bmatrix}1\\1\\0\end{bmatrix}+\begin{bmatrix}0\\2\\2\end{bmatrix}=\begin{bmatrix}2\\3\\3\end{bmatrix}\ \checkmark$$

> **行视角验证：** 三个平面为
>
> $$\Pi_1:\ x+y=2,\qquad \Pi_2:\ y+z=3,\qquad \Pi_3:\ x+z=3.$$
>
> 代入 $(1,1,2)$：$1+1=2$ ✓，$1+2=3$ ✓，$1+2=3$ ✓。三平面交于唯一一点 $(1,1,2)$。
>
> **唯一性说明：** $\det\mathbf{A}=1(1\cdot1-1\cdot0)-1(0\cdot1-1\cdot1)+0=1-1(-1)=2\neq0$，故 $\mathbf{A}$ 可逆，解唯一。

Q3.（概念题：为什么列图像优于行图像） 请从"可解性判断"与"高维推广"两个角度说明：为什么 Strang 坚持列图像才是线性代数的核心视角，而行图像在课程中很快就不再被使用？

> ▸ **答案**
>
> **角度一：可解性判断的复杂度。** – **行图像**问的是"m 张超平面有没有公共点"。这个问题在 m,n 稍大时就无法逐一直观判断：三张平面在 $\mathbb{R}^3$ 中已有"交于一点 / 交于一线 / 交于一面 / 两两相交而无公共点 / 平行"等多种退化情形，而"两两相交但三面无公共点"这种情形（三棱柱侧面）在二维类比里**根本没有对应物**——人在 $\mathbb{R}^3$ 以上的直觉立即失效。 – **列图像**只问一个**单一**的问题："$\mathbf{b}$ 在不在这 n 个列向量张成的子空间里？"这是**一个**集合的隶属判断（$\mathbf{b}\in C(\mathbf{A})$?），不是 m 个条件的相容性检查。而且它可以用**一个整数**（秩 r）回答：$r=m$ 时对一切 $\mathbf{b}$ 可解，$r<m$ 时只有 $C(\mathbf{A})$ 那张低维面上的 $\mathbf{b}$ 可解。
>
> **角度二：高维推广与结构。** – **行图像**是"逐方程"的，它天然把注意力引向**单个方程**，而单个方程在线性代数里几乎从不被单独研究。它也不告诉你 $\mathbf{A}$ 这个矩阵本身的任何结构信息。 – **列图像**把 $\mathbf{A}$ 的对象单位从"数"提升为"向量"，于是自然引出整个课程的四梁八柱：列空间 $C(\mathbf{A})$、秩 r、零空间 $N(\mathbf{A})$、线性无关、基与维数、投影与最小二乘（当 $\mathbf{b}\notin C(\mathbf{A})$ 时"退而求其次"求最近点）。这些概念在行图像里要么无法表述，要么表述得极其别扭。 – 更本质地：$\mathbf{Ax}$ 作为**列的线性组合**这个读法，把矩阵从"数表"变成了**线性变换**：$\mathbf{A}$ 是作用在 $\mathbf{x}$ 上、输出到 $\mathbb{R}^m$ 的映射。整门课（特征值、SVD、基变换）都建立在"矩阵是变换"这一认识上。
>
> **一句话总结：** 行图像告诉你"约束长什么样"，列图像告诉你"$\mathbf{A}$ 能做什么"。**前者的信息是局部的、随 m 爆炸的；后者的信息是整体的、由一个秩 r 统摄的。**

Q4.（概念题：奇异情形的计数） 设 $\mathbf{A}$ 是 3×3 矩阵，$\det\mathbf{A}=0$，且已知 $\mathbf{b}_0\neq\mathbf{0}$ 使得 $\mathbf{Ax}=\mathbf{b}_0$ 无解。问 $\mathbf{Ax}=\mathbf{0}$ 是否有非零解？$\mathbf{Ax}=\mathbf{b}_0$ 若改为有解，解集的"大小"是什么？请说明理由。

> ▸ **答案**
>
> **第一问：有非零解，一定有。** $\det\mathbf{A}=0$ 且 $\mathbf{A}$ 是方阵，说明 $n=3$ 个列向量线性相关，即存在不全为零的系数 c_1,c_2,c_3 使 $c_1\mathbf{a}_1+c_2\mathbf{a}_2+c_3\mathbf{a}_3=\mathbf{0}$。取 $\mathbf{x}_0=(c_1,c_2,c_3)\neq\mathbf{0}$，则 $\mathbf{Ax}_0=\mathbf{0}$。所以 $N(\mathbf{A})\neq\{\mathbf{0}\}$。 由 $\det=0$ 知 $r\leq2$，故 $\dim N(\mathbf{A})=n-r=3-r\geq1$。
>
> **重要提醒：** 这一问的答案与 $\mathbf{b}_0$ 是否可解**完全无关**。$\mathbf{b}_0$ 的存在只是为了告诉你 $r<m=3$（列空间没有张满 $\mathbb{R}^3$），即 $r\leq2$。但即使没有这个信息，方阵 $\det=0$ 本身就保证了 $r\leq2$，从而保证非零零空间向量存在。
>
> **第二问：解集是 $\mathbb{R}^3$ 中一条直线。** 设 $\mathbf{Ax}=\mathbf{b}_0$ 有解且 $r=2$（由 $\mathbf{b}_0$ 无解知 $r<3$；若 $r\leq1$ 解集会是平面或整个空间，见下）。此时 $\dim N(\mathbf{A})=3-2=1$，所以解集
>
> $$\mathbf{x}=\mathbf{x}_p+t\,\mathbf{x}_0,\qquad t\in\mathbb{R}$$
>
> 是 $\mathbb{R}^3$ 中一条直线——无穷多解。
>
> **一般规律（$m=n=3$，$\det=0$）：**
>
> ```
> rank r    dim N(A) = 3 − r    若相容，解集的几何          可解性
> ──────────────────────────────────────────────────────────────────
>    2            1             一条直线（无穷多解）       仅 C(A) 平面上的 b
>    1            2             一张平面（无穷多解）       仅 C(A) 直线上的 b
>    0            3             整个 R^3                  仅 b = 0
> ```
>
> 注意 $r=0$ 只可能发生在 $\mathbf{A}=\mathbf{O}$ 时，此时 $C(\mathbf{A})=\{\mathbf{0}\}$，只有 $\mathbf{b}=\mathbf{0}$ 可解。**结论：只要 $\det=0$ 且相容，就必有无穷多解，绝不可能有唯一解。** 唯一性与 $\det\neq0$ 是同一件事。

Lecture 2: Elimination with Matrices

概述

上一讲我们把 $A\mathbf{x}=\mathbf{b}$ 看成"求 A 的各列的线性组合，使其等于 $\mathbf{b}$"。本讲要把它变成一个**可靠、可机械执行、永不失败的算法**——高斯消元（Gaussian elimination）。核心问题只有一个：既然消元只是对增广矩阵 $[A\mid\mathbf{b}]$ 反复做"某行减去另一行的倍数"，凭什么说解集没变？答案是把每一步都写成一个矩阵 E，而 E 恒可逆，于是 $\mathbf{x}$ 被保住。这一讲还会顺手讲清矩阵乘法为什么可以从四个角度看（Strang 称之为"矩阵乘法是课程中最重要的运算"），并第一次显露 $A=LU$ 的影子。

核心概念的几何直觉

消元（Elimination）：为什么它不改变解集

- **定义与目的**：消元是把方程组一步步化成**上三角**（upper triangular）形状的过程。化到上三角后，最后一个方程只含一个未知数，可以直接解出；再往回一代（back substitution），全部未知数依次得到。它的目的是：把"解一个耦合在一起的方程组"换成"解 n 个互不干扰的简单方程"。
- **几何直觉（它在空间中是什么样子？）**：先看**行图景**（row picture）。一个方程 $a_{i1}x_1+\cdots+a_{in}x_n=b_i$ 是 $\mathbb{R}^n$ 中的一张超平面（$n=2$ 时是一条直线）。解 $\mathbf{x}$ 是所有超平面的**公共交点**。消元做的操作是"用第一张超平面去剪切第二张超平面"——把第二张平面绕着它与第一张的交线旋转，直到它变得"更竖直"。**两张平面的交线在整个旋转过程中一动不动**，因为新平面就是"旧平面 + 第一张平面的倍数"，凡是同时落在旧平面和第一张平面上的点，在新平面上的取值也不变。所以公共交点（更一般地：公共交集）自始至终不变。这就是"同解变形"的几何本质。 再看**列图景**（column picture）：消元同时改动 A 的**行**与 $\mathbf{b}$ 的**分量**（施加的是同一批行变换）。看起来组合问题被换掉了，但要知道：我们对等式 $A\mathbf{x}=\mathbf{b}$ 两边**同时左乘了同一个可逆矩阵 E**，即 $EA\mathbf{x}=E\mathbf{b}$。这就是为什么我们可以只对 $[A\mid\mathbf{b}]$ 操作而不必操心 $\mathbf{x}$——$\mathbf{x}$ 自始至终是同一个未知向量，只是它要组合的那组"原料列"从 A 的列换成了 EA 的列，而"目标"从 $\mathbf{b}$ 换成了 $E\mathbf{b}$。**原料和目标一起换，配方 $\mathbf{x}$ 不变。**
- **具体示例**：方程组

$$x+2y=3,\qquad 3x+8y=11$$

两条直线交于 $(1,1)$（验证：$1+2\cdot1=3$ ✓，$3\cdot1+8\cdot1=11$ ✓）。用第一式消去第二式的 x：第二式减去第一式的 3 倍，得 $0x+2y=2$，即 $y=1$。两条新直线 $x+2y=3$ 与 $y=1$ 的交点仍是 $(1,1)$——第一张直线没动，第二张绕交点转了。 写成矩阵语言：$\mathbf{b}=\begin{bmatrix}3\\11\end{bmatrix}$，

$$E_{21}=\begin{bmatrix}1&0\\-3&1\end{bmatrix},\qquad E_{21}A=\begin{bmatrix}1&0\\-3&1\end{bmatrix}\begin{bmatrix}1&2\\3&8\end{bmatrix}=\begin{bmatrix}1&2\\0&2\end{bmatrix},\qquad E_{21}\mathbf{b}=\begin{bmatrix}1&0\\-3&1\end{bmatrix}\begin{bmatrix}3\\11\end{bmatrix}=\begin{bmatrix}3\\2\end{bmatrix}$$

于是新方程组是 $x+2y=3$ 与 $2y=2$——解仍是 $x=1,y=1$。解集 $\{(1,1)\}$ 完全没变。

把这件事画成图（行图景，$n=2$）：

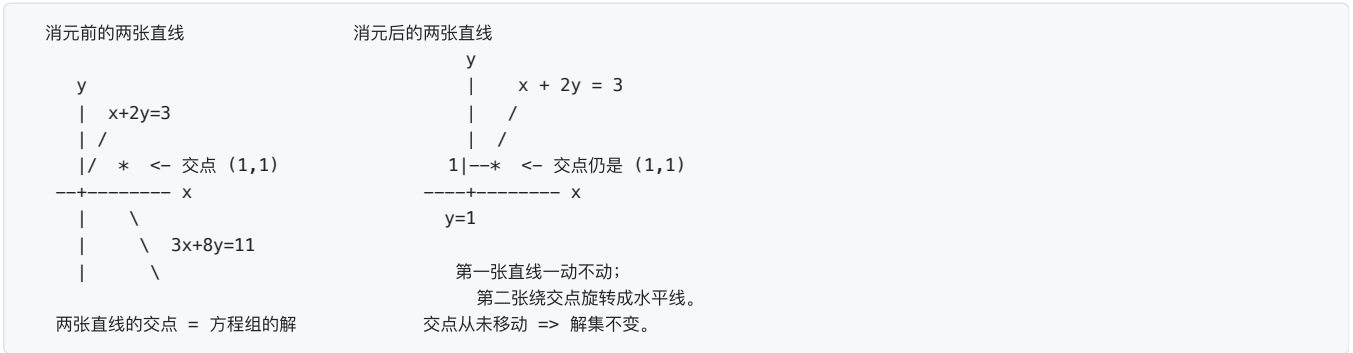

注意第二张直线**绕交点旋转**——它上面除了交点以外的每一点都在动，但交点本身是旋转轴上的不动点。这就是"消元不改变解集"的完整几何图像。

消元矩阵（Elementary Matrix）E：从单位阵"改一格"

- **定义与目的**：E_{21} 表示"**把第 2 行减去 l_{21} 倍的第 1 行**"这个行变换。它的构造规则只有一句：**取单位阵 I，把 $(2,1)$ 位置的那个 0 改成 $-l_{21}$。**其余位置一律照抄。它存在的意义是：把"一个算法步骤"变成一个"可以乘法验证的数学对象"，于是消元过程可以被整体追踪、可以求逆、可以打包成一个矩阵。
- **几何直觉（它在空间中是什么样子？）**：E 是一个**剪切（shear）**。它不动第 1 行所在的那张平面（所有第 1 个坐标相同的点），只把空间沿第 1 个坐标方向整体斜切。想象一副扑克牌，第一张牌按住不动，下面每一张沿 x_1 方向滑一段距离——体积不变、不翻转、不塌陷。所以 E 一定可逆（把牌滑回来即可），且 $\det E=1$。
- **具体示例**：I 改一格 →

$$E_{21}=\begin{bmatrix}1&0&0\\-3&1&0\\0&0&1\end{bmatrix}$$

用它乘 $A=\begin{bmatrix}1&2&1\\3&8&1\\0&4&1\end{bmatrix}$：

$$E_{21}A=\begin{bmatrix}1&2&1\\0&2&-2\\0&4&1\end{bmatrix}$$

第 2 行变成了 $(3,8,1)-3\cdot(1,2,1)=(0,2,-2)$。注意第 1、3 行**原封不动**——因为 E_{21} 的第 1、3 行就是 I 的第 1、3 行。

把"剪切"画出来（3×3 例子里的 2×2 核心 $E=\begin{bmatrix}1&0\\-3&1\end{bmatrix}$，它的两列是 $(1,-3)$ 与 $(0,1)$，故 $\mathbf{e_2}$ 不动、$\mathbf{e_1}$ 被压低）：

```
E 是一个剪切：保持沿 e2 方向的直线不动，把 e1 往下"拉" 3 个单位

    x2                          x2
     ^                          ^
     |     (1,1)                |     (1,1)
     |      *                   |      *
     |     /|                   |     /|
     |    / |                   |    / |
-----+---/--+----> x1       -----+---/--+----> x1
     |  /   |                   |  /   |
     | /    |                 (1,-3)   |
   (1,0)  e2 不动                 *    e2=(0,1) 仍不动
     |                            |
第2列 = (0,1) 不变            第1列 = (1,-3): e1 被拉到下方

单位方格（面积 1）被剪成平行四边形，面积仍为 1
=> det E = 1*1 - 0*(-3) = 1，且 E 一定可逆（反向推回去即可）
```

这正是"消元不改变体积、也不改变可逆性"的微观图像：**每一步 E 都是一次纯粹的剪切**——一个方向按住不动，另一个方向整体滑动。平行四边形的底与高都没变，所以面积恒为 1，$\det E=1$。

左乘 = 行变换，右乘 = 列变换

- **定义与目的**：区分"E 在左边"和"E 在右边"是所有初学者最容易混淆的地方。一句话记住：**左乘 E（EA）动的是 A 的行；右乘 E（AE）动的是 A 的列。**
- **几何直觉（它在空间中是什么样子？）**：可以把矩阵乘法读成"对 A 的每一行做同一件事"和"对 A 的每一列做同一件事"两种。左乘时，E 的第 i 行规定"结果第 i 行是原来哪些行的组合"；右乘时，E 的第 j 列规定"结果第 j 列是原来哪些列的组合"。
- **具体示例**：取 $M=\begin{bmatrix}1&2\\3&4\end{bmatrix}$，$E=\begin{bmatrix}1&0\\3&1\end{bmatrix}$。

$$EM=\begin{bmatrix}1&2\\6&10\end{bmatrix}\quad(\text{第 }2\text{ 行}=\text{原第 }2\text{ 行}+3\times\text{原第 }1\text{ 行})$$

$$ME=\begin{bmatrix}7&2\\15&4\end{bmatrix}\quad(\text{第 }1\text{ 列}=\text{原第 }1\text{ 列}+3\times\text{原第 }2\text{ 列})$$

两者完全不同。消元只使用左乘。

主元（Pivot）与零主元、行交换（Permutation）P

- **定义与目的**：第 k 步消元时用来消去下面各行第 k 列系数的那个数，叫做第 k 个**主元**。它绝对不能是 0——因为乘数 $l_{ik}=a_{ik}/a_{kk}$ 要用它作分母。如果主元是 0，就必须**交换行**，把下面某一列非零的行换上来。
- **几何直觉（它在空间中是什么样子？）**：主元是"当前还没被清理掉的那个方向上的斜率"。主元为 0 意味着当前这张平面在这个方向上已经平躺，无法再去剪切别人，只能换一张来当"基准面"。**交换两张平面不改变它们的交集**——所以换行同样不改变解集。
- **具体示例**：$Z=\begin{bmatrix}0&2&1\\1&3&2\\2&1&1\end{bmatrix}$ 的第一个主元是 0，无法开工。交换第 1、2 行：

$$P=\begin{bmatrix}0&1&0\\1&0&0\\0&0&1\end{bmatrix},\qquad PZ=\begin{bmatrix}1&3&2\\0&2&1\\2&1&1\end{bmatrix}$$

这下第一个主元是 1，可以继续。（P 就是"把 I 的第 1、2 行交换"得到的矩阵。）

置换矩阵（Permutation Matrix）P

- **定义与目的**：每一行、每一列都**恰好有一个 1**，其余全为 0 的方阵。n 阶置换矩阵一共有 $n!$ 个。左乘它 = 按某种方式重排行。

- **几何直觉（它在空间中是什么样子？）**：P 是空间中的**刚性重排**——把坐标轴整体搬来搬去，不拉伸、不剪切、不塌陷。所以 $\det P = \pm 1$，而且 P 永远是正交矩阵（orthogonal），这保证了 P 一定可逆。
- **具体示例**：

$$P_{13} = \begin{bmatrix} 0 & 0 & 1 \\ 0 & 1 & 0 \\ 1 & 0 & 0 \end{bmatrix}, \qquad P_{13} \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \\ 7 & 8 & 9 \end{bmatrix} = \begin{bmatrix} 7 & 8 & 9 \\ 4 & 5 & 6 \\ 1 & 2 & 3 \end{bmatrix}$$

行序被完全颠倒。2×2 的 $\begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}$ 满足 $P^2 = I$，因此 $P^{-1} = P$；事实上对**任何**置换矩阵都有 $P^{-1} = P^{\mathsf{T}}$（因为 P 正交）。

矩阵乘法的四种视角

这是 Strang 反复强调的"一鱼四吃"。设 A 是 $m \times n$，B 是 $n \times p$，则 $C = AB$ 是 $m \times p$。

- **定义与目的**：四种视角不是四种算法（结果完全相同），而是四种**理解通道**。做题用视角①，论证明性质用②③，看到"低秩""秩一分解"用④。
- **几何直觉（它在空间中是什么样子？）**：
- 视角① **行 × 列（点积）**：$c_{ij} = (\text{第 } i \text{行}) \cdot (\text{第 } j \text{列})$。最机械，最可靠，$O(n)$ 次乘法算一个元素。
- 视角② **整列的组合**：AB 的第 j 列 $= A \cdot (B$ 的第 j 列$)$。也就是说：**B 的每一列是配方，A 的列是原料，AB 的列就是配出来的成品。** 这直接给出列空间的关系 $C(AB) \subseteq C(A)$。
- 视角③ **整行的组合**：AB 的第 i 行 $= (A$ 的第 i 行$) \cdot B$。也就是**A 的每一行对 B 的各行做线性组合**。这给出行空间的关系 $C((AB)^{\mathsf{T}}) \subseteq C(B^{\mathsf{T}})$。
- 视角④ **外积之和**：$AB = \sum_{k=1}^{n} (\mathbf{A} \text{ 的第 } k \text{ 列})\,(\mathbf{B} \text{ 的第 } k \text{ 行})$，即 n 个 $m \times p$ 的**秩一矩阵**相加。这是四个视角中信息量最大的一个：它说明 AB 的秩等于"真正需要的项数"，也说明**任何矩阵都是秩一矩阵的和**，这正是后面 SVD 的思想雏形。
- **具体示例**：取

$$A = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}, \qquad B = \begin{bmatrix} 5 & 6 \\ 7 & 8 \end{bmatrix}$$

视角①（点积）：$c_{11} = 1 \cdot 5 + 2 \cdot 7 = 19$，$c_{12} = 1 \cdot 6 + 2 \cdot 8 = 22$，$c_{21} = 3 \cdot 5 + 4 \cdot 7 = 43$，$c_{22} = 3 \cdot 6 + 4 \cdot 8 = 50$，故

$$AB = \begin{bmatrix} 19 & 22 \\ 43 & 50 \end{bmatrix}$$

视角②（列的组合）：AB 的第 1 列 $= A \begin{bmatrix} 5 \\ 7 \end{bmatrix} = 5 \begin{bmatrix} 1 \\ 3 \end{bmatrix} + 7 \begin{bmatrix} 2 \\ 4 \end{bmatrix} = \begin{bmatrix} 19 \\ 43 \end{bmatrix}$；第 2 列 $= A \begin{bmatrix} 6 \\ 8 \end{bmatrix} = \begin{bmatrix} 22 \\ 50 \end{bmatrix}$。✓ 视角③（行的组合）：$AB$ 的第 1 行 $= \begin{bmatrix} 1 & 2 \end{bmatrix} B = 1 \cdot (5, 6) + 2 \cdot (7, 8) = (19, 22)$；第 2 行 $= \begin{bmatrix} 3 & 4 \end{bmatrix} B = (43, 50)$。✓ 视角④（外积之和）：

$$\begin{bmatrix} 1 \\ 3 \end{bmatrix} \begin{bmatrix} 5 & 6 \end{bmatrix} + \begin{bmatrix} 2 \\ 4 \end{bmatrix} \begin{bmatrix} 7 & 8 \end{bmatrix} = \begin{bmatrix} 5 & 6 \\ 15 & 18 \end{bmatrix} + \begin{bmatrix} 14 & 16 \\ 28 & 32 \end{bmatrix} = \begin{bmatrix} 19 & 22 \\ 43 & 50 \end{bmatrix} \checkmark$$

计算步骤与手算演示

示例 1（主讲）：用增广矩阵完整消元 $A\mathbf{x} = \mathbf{b}$

取 Strang 书上的标准例子

$$A = \begin{bmatrix} 1 & 2 & 1 \\ 3 & 8 & 1 \\ 0 & 4 & 1 \end{bmatrix}, \qquad \mathbf{b} = \begin{bmatrix} 2 \\ 12 \\ 2 \end{bmatrix}$$

先写出**增广矩阵（augmented matrix）** $[A \mid \mathbf{b}]$。把 $\mathbf{b}$ 并排挂在 A 右边当成第 4 列，好处是从此以后每一次行变换都"顺手"作用在 $\mathbf{b}$ 上，不用另外记账：

```
[A | b] =
  [  1   2   1 |   2 ]        <- row 1
  [  3   8   1 |  12 ]        <- row 2
  [  0   4   1 |   2 ]        <- row 3
```

步骤 1：构造 E_{21}，消去第 2 行的第一个元素。

第 1 列的主元是 $a_{11} = 1$。要消掉 $a_{21} = 3$，乘数是 $l_{21} = a_{21}/a_{11} = 3/1 = 3$，操作是 $R_2 \leftarrow R_2 - 3R_1$。

对应的消元矩阵就是把 I_3 的 $(2, 1)$ 位置从 0 改成 -3：

$$E_{21} = \begin{bmatrix} 1 & 0 & 0 \\ -3 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

逐行验算 $E_{21}\cdot[A\mid \mathbf{b}]$： – 第 1 行 $=1\times$ 原第 1 行 $=(1,2,1,2)$ – 第 2 行 $=-3\times$ 原第 1 行 $+1\times$ 原第 2 行 $=(3,8,1,12)-3(1,2,1,2)=(0,2,-2,6)$ – 第 3 行 $=1\times$ 原第 3 行 $=(0,4,1,2)$

```
after E21:  [  1   2   1 |   2 ]
            [  0   2  -2 |   6 ]     <- row2 - 3*row1
            [  0   4   1 |   2 ]

E21*b = ( 2, 6, 2 )^T
```

步骤 2：构造 E_{31}，消去第 3 行的第一个元素。

A 的 $a_{31}=0$ 本来就是 0，乘数 $l_{31}=0/1=0$。于是

$$E_{31}=\begin{bmatrix}1&0&0\\0&1&0\\0&0&1\end{bmatrix}=I$$

这一步是"空操作"。**不要因为它是 I 就觉得这一步多余**——把它写出来，才能让 L 的对角线以下三个位置 $(2,1),(3,1),(3,2)$ 有统一的记账格式，第 4 讲 $A=LU$ 时你会感谢这个习惯。

```
after E31:  [  1   2   1 |   2 ]     (unchanged)
            [  0   2  -2 |   6 ]
            [  0   4   1 |   2 ]
```

步骤 3：构造 E_{32}，消去第 3 行的第二个元素。

现在的第 2 个主元是 $a_{22}=2$（它是上一轮更新后的值，不是原来的 8）。要消掉 $a_{32}=4$，乘数 $l_{32}=4/2=2$，操作是 $R_3\leftarrow R_3-2R_2$。

$$E_{32}=\begin{bmatrix}1&0&0\\0&1&0\\0&-2&1\end{bmatrix}$$

逐行验算： – 第 1 行不变：$(1,2,1,2)$ – 第 2 行不变：$(0,2,-2,6)$ – 第 3 行 $=-2\times$ 第 2 行 $+1\times$ 原第 3 行 $=(0,4,1,2)-2(0,2,-2,6)=(0,0,5,-10)$

```
[U | c] =   [  1   2   1 |   2 ]
            [  0   2  -2 |   6 ]
            [  0   0   5 | -10 ]     <- row3 - 2*row2
```

到此得到上三角的 U 与变换后的右端 $\mathbf{c}$：

$$U=\begin{bmatrix}1&2&1\\0&2&-2\\0&0&5\end{bmatrix},\qquad \mathbf{c}=\begin{bmatrix}2\\6\\-10\end{bmatrix}$$

完整 ASCII 图景：消元如何一步步"清扫"左下角

```
  start             after E21          after E31          after E32
┌         ┐       ┌         ┐        ┌         ┐        ┌         ┐
│ 1  2  1 │       │ 1  2  1 │        │ 1  2  1 │        │ 1  2  1 │  <- pivot 1
│ 3  8  1 │  --->  │ 0  2 -2 │  --->  │ 0  2 -2 │  --->  │ 0  2 -2 │  <- pivot 2
│ 0  4  1 │       │ 0  4  1 │        │ 0  4  1 │        │ 0  0  5 │  <- pivot 5
└         ┘       └         ┘        └         ┘        └         ┘
 x  x  x           .  x  x            .  x  x            .  x  x
 x  x  x           .  x  x            .  x  x            .  x  x
 .  x  x           .  x  x            .  x  x            .  .  x
 (x = 待处理)       (x = 待处理)        第3行首元素本就是0      上三角完成
```

三个主元依次是 $1,\ 2,\ 5$。**三个主元全部非零 $\Longleftrightarrow$ A 可逆 $\Longleftrightarrow$ 消元无需换行就能走完。**

步骤 4：回代（back substitution）。

从最后一行往上解： – 第 3 行：$5x_3=-10\Rightarrow\boxed{x_3=-2}$ – 第 2 行：$2x_2-2x_3=6\Rightarrow 2x_2-2(-2)=6\Rightarrow 2x_2=2\Rightarrow\boxed{x_2=1}$ – 第 1 行：$x_1+2x_2+x_3=2\Rightarrow x_1+2(1)+(-2)=2\Rightarrow\boxed{x_1=2}$

于是

$$\mathbf{x}=\begin{bmatrix}2\\1\\-2\end{bmatrix}$$

回代验算：$A\mathbf{x}=\begin{bmatrix}1&2&1\\3&8&1\\0&4&1\end{bmatrix}\begin{bmatrix}2\\1\\-2\end{bmatrix}=\begin{bmatrix}2+2-2\\6+8-2\\0+4-2\end{bmatrix}=\begin{bmatrix}2\\12\\2\end{bmatrix}=\mathbf{b}$ ✓

【计算机制解说】：为什么"左乘一串 E"就等于整个消元过程？ 三个 E 是按顺序作用的：先 E_{21}，再 E_{31}，最后 E_{32}。写成公式就是

$$E_{32}\big(E_{31}(E_{21}A)\big)=U$$

由矩阵乘法的**结合律**（下一讲会证明，本讲先用），括号可以重新打：

$$(E_{32}E_{31}E_{21})A=U$$

也就是说，整个消元过程可以压缩成**一个**矩阵 $E=E_{32}E_{31}E_{21}$ 左乘 A。验算一下：

$$E_{32}E_{21}=\begin{bmatrix}1&0&0\\0&1&0\\0&-2&1\end{bmatrix}\begin{bmatrix}1&0&0\\-3&1&0\\0&0&1\end{bmatrix}=\begin{bmatrix}1&0&0\\-3&1&0\\6&-2&1\end{bmatrix}$$

（第 3 行 $=-2\times(-3,1,0)+(0,0,1)=(6,-2,1)$。注意 $E_{31}=I$ 不产生影响。） 于是

$$E=E_{32}E_{31}E_{21}=\begin{bmatrix}1&0&0\\-3&1&0\\6&-2&1\end{bmatrix},\qquad EA=\begin{bmatrix}1&2&1\\0&2&-2\\0&0&5\end{bmatrix}=U\ \checkmark$$

而 $E\mathbf{b}=(2,6,-10)^{\mathsf{T}}=\mathbf{c}$ ✓。

为什么"解集不变"在这里看得最清楚：每个 E 都可逆（把 $(2,1)$ 的 -3 改回 $+3$ 就是它的逆），所以 $A\mathbf{x}=\mathbf{b}\iff EA\mathbf{x}=E\mathbf{b}\iff U\mathbf{x}=\mathbf{c}$。**可逆矩阵左乘不丢失任何信息**，这就是"同解变形"的代数证明。

示例 2：主元为 0 —— 必须换行

取

$$Z=\begin{bmatrix}0&2&1\\1&3&2\\2&1&1\end{bmatrix},\qquad \mathbf{b}=\begin{bmatrix}1\\2\\3\end{bmatrix}$$

第一个主元 $z_{11}=0$，没法作分母。**先交换第 1、2 行**：

$$P=\begin{bmatrix}0&1&0\\1&0&0\\0&0&1\end{bmatrix},\qquad PZ=\begin{bmatrix}1&3&2\\0&2&1\\2&1&1\end{bmatrix},\qquad P\mathbf{b}=\begin{bmatrix}2\\1\\3\end{bmatrix}$$

```
[PZ | Pb] =
  [  1   3   2 |   2 ]        l21 = 0   (第2行首元素已是0)
  [  0   2   1 |   1 ]
  [  2   1   1 |   3 ]        l31 = 2/1 = 2
```

步骤 1：$R_3\leftarrow R_3-2R_1$，乘数 $l_{31}=2$。 第 3 行 $=(2,1,1,3)-2(1,3,2,2)=(0,-5,-3,-1)$。

```
  [  1   3   2 |   2 ]
  [  0   2   1 |   1 ]        l32 = -5/2 = -2.5
  [  0  -5  -3 |  -1 ]
```

步骤 2：第 2 个主元是 2，要消掉 $a_{32}=-5$，乘数 $l_{32}=-5/2$，操作 $R_3\leftarrow R_3-(-5/2)R_2$，即 $R_3\leftarrow R_3+\frac{5}{2}R_2$。 第 3 行 $=(0,-5,-3,-1)+\frac{5}{2}(0,2,1,1)=(0,0,-\frac{1}{2},\frac{3}{2})$。

```
[U | c] =
  [  1   3    2 |   2   ]
  [  0   2    1 |   1   ]
  [  0   0  -1/2 |  3/2  ]
```

回代：$-\,-\frac{1}{2}x_3=\frac{3}{2}\Rightarrow\boxed{x_3=-3}$ - $2x_2+x_3=1\Rightarrow 2x_2-3=1\Rightarrow\boxed{x_2=2}$ - $x_1+3x_2+2x_3=2\Rightarrow x_1+6-6=2\Rightarrow\boxed{x_1=2}$

$$\mathbf{x} = \begin{bmatrix} 2 \\ 2 \\ -3 \end{bmatrix}$$

回代验算：$Z\mathbf{x} = (0\cdot 2 + 2\cdot 2 + 1\cdot(-3),\ 1\cdot 2 + 3\cdot 2 + 2\cdot(-3),\ 2\cdot 2 + 1\cdot 2 + 1\cdot(-3)) = (1, 2, 3)^{\mathsf{T}} = \mathbf{b}$ ✓

【计算机制解说】：为什么"换行"不改变解集，而且为什么 $P^{-1} = P^{\mathsf{T}}$？ 第一问：交换两张平面（两个方程）的书写顺序，方程组本身一字未变——只是第一行和第二行调了个位置，联立方程组的解当然是同一个。 第二问：P 是把 I 的某些行互换得到的。互换操作做两次就回到原样（$\mathbf{swap}^2 = \mathrm{id}$），所以 $PP = I$，即 $P^{-1} = P$。又因为 P 的每一行每一列恰好一个 1，转置只是把那些 1 沿对角线翻过去，位置集合不变，所以 $P^{\mathsf{T}} = P$。两者合起来得 $P^{-1} = P^{\mathsf{T}}$。**几何上**：P 是刚性的坐标重排，保持长度与夹角，所以它是正交矩阵（orthogonal），而"正交 $\Rightarrow$ 逆 = 转置"。

顺带记账：这个例子的 L 与 U 为

$$L = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 2 & -\frac{5}{2} & 1 \end{bmatrix}, \qquad U = \begin{bmatrix} 1 & 3 & 2 \\ 0 & 2 & 1 \\ 0 & 0 & -\frac{1}{2} \end{bmatrix}, \qquad LU = PZ = \begin{bmatrix} 1 & 3 & 2 \\ 0 & 2 & 1 \\ 2 & 1 & 1 \end{bmatrix} \checkmark$$

（注意 L 的 $(2,1)$ 位置是 0，因为换行后第 2 行首元素已是 0，没有消元动作。L 的对角线全是 1，这是"不缩放主元行"记账法的固定格式。）

示例 3：消元代价——为什么大约是 $n^3/3$ 次乘法

设 A 是 $n \times n$。第 k 步消元（$k = 1, 2, \ldots, n-1$）要处理主元下面的 $n-k$ 行，每一行需要：– 1 次除法算乘数 $l_{ik} = a_{ik}/a_{kk}$；– $(n-k+1)$ 次乘法，用于更新第 k 列到第 n 列**再加上右端 $\mathbf{b}$ 那一列**。

所以每步的乘法数是 $(n-k)(n-k+1)$，总计

$$\mathrm{ops}(n) = \sum_{k=1}^{n-1} (n-k)(n-k+1) = \sum_{j=1}^{n-1} j(j+1) = \sum_{j=1}^{n-1} j^2 + \sum_{j=1}^{n-1} j = \frac{(n-1)n(2n-1)}{6} + \frac{(n-1)n}{2} = \frac{n^3 - n}{3}$$

具体数字：

```
  n     实际乘法次数 (n^3-n)/3      n^3/3        相对误差
  3          8                    9.0          11%
  4         20                   21.3           6%
  5         40                   41.7           4%
 10        330                  333.3           1%
100     333300                333333.3         0.01%
```

n=3 的手工分解（可直接核对）：

```
step k=1: 主元下方 2 行, 每行更新 3 个数 -> 2*3 = 6 次乘法
step k=2: 主元下方 1 行, 每行更新 2 个数 -> 1*2 = 2 次乘法
step k=3: 主元下方 0 行               -> 0
------------------------------------------------
合计 = 8 次乘法  (n=3 时 8 vs n^3/3=9)
```

【计算机制解说】：为什么主项是 $n^3/3$ 而不是 n^3？ 因为"工作量按列递减"。第 1 步要更新大约 $(n-1) \times n \approx n^2$ 个元素，第 2 步约 $(n-2) \times n$ 个，第 k 步约 $(n-k) \times (n-k+1) \approx (n-k)^2$ 个。把它们加起来就是 $\sum_{j=1}^{n} j^2 \approx \int_0^n j^2\,dj = n^3/3$。 **一个更直观的说法**：矩阵里约有 n^2 个元素，而平均每个元素在整个消元过程中被"从后往前"更新了约 $n/3$ 次（第 1 行只被用来消元、自己不更新；越靠下的行被更新得越少），于是总量 $n^2 \cdot n/3 = n^3/3$。 **为什么实际值 8 比 $n^3/3 = 9$ 小？** 因为精确公式是 $\frac{n^3-n}{3}$——多出来的 $-\frac{n}{3}$ 是 $\sum j$ 这一低阶项带来的修正。$n = 3$ 时修正量恰好是 1（$9 - 1 = 8$ 与表格吻合）；$n = 100$ 时修正量约 33，相对于 333333 已完全可忽略。**所以 $n^3/3$ 是"渐近主项"，不是精确计数。 这个 $n^3/3$ 是线性代数的"计价单位"**：它说明解 n 个未知数的 n 个方程，代价是 n 的三次方量级。当 $n = 1000$ 时约 3.3×10^8 次运算——现代电脑零点几秒；当 $n = 10^6$ 时约 3.3×10^{17} 次——就需要特殊结构（稀疏、带状、迭代法）了。对比一下：**回代只要 $n^2/2$**（n 个未知数，第 k 个只与前 k 个有关），所以"消元"而非"回代"才是整个求解过程的成本瓶颈。这也解释了为什么第 4 讲的 LU 分解值得：分解一次花 $n^3/3$，之后每个新 $\mathbf{b}$ 只要 n^2。

示例 4：四种乘法视角的 3×3 完整对照

取

$$A_3 = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \\ 7 & 8 & 10 \end{bmatrix}, \qquad B_3 = \begin{bmatrix} 1 & 0 & 2 \\ 0 & 1 & 0 \\ 3 & 0 & 1 \end{bmatrix}$$

先算积 A_3B_3：

```
A3 * B3 =
 [ 1*1+2*0+3*3   1*0+2*1+3*0   1*2+2*0+3*1 ]   [ 10   2   5 ]
 [ 4*1+5*0+6*3   4*0+5*1+6*0   4*2+5*0+6*1 ] = [ 22   5  14 ]
 [ 7*1+8*0+10*3  7*0+8*1+10*0  7*2+8*0+10*1]   [ 37   8  24 ]
```

- **视角①（点积）**：$c_{22} = (4,5,6)\cdot(0,1,0) = 5$ ✓（这就是上面矩阵中心的那个 5）。
- **视角②（列的组合）**：A_3 乘 B_3 的每一列：
- $A_3\begin{bmatrix}1\\0\\3\end{bmatrix} = 1\begin{bmatrix}1\\4\\7\end{bmatrix} + 3\begin{bmatrix}3\\6\\10\end{bmatrix} = \begin{bmatrix}10\\22\\37\end{bmatrix}$ = 第 1 列 ✓
- $A_3\begin{bmatrix}0\\1\\0\end{bmatrix} = \begin{bmatrix}2\\5\\8\end{bmatrix}$ = 第 2 列 ✓
- $A_3\begin{bmatrix}2\\0\\1\end{bmatrix} = 2\begin{bmatrix}1\\4\\7\end{bmatrix} + \begin{bmatrix}3\\6\\10\end{bmatrix} = \begin{bmatrix}5\\14\\24\end{bmatrix}$ = 第 3 列 ✓
- **视角③（行的组合）**：A_3 的每一行乘 B_3：
- $[1\quad 2\quad 3]B_3 = (1\cdot(1,0,2) + 2\cdot(0,1,0) + 3\cdot(3,0,1)) = (10,2,5)$ ✓
- $[4\quad 5\quad 6]B_3 = (22,5,14)$ ✓
- $[7\quad 8\quad 10]B_3 = (37,8,24)$ ✓
- **视角④（列 $\otimes$ 行的外积之和）**：

$$\begin{bmatrix}1\\4\\7\end{bmatrix}[1\quad 0\quad 2] = \begin{bmatrix}1&0&2\\4&0&8\\7&0&14\end{bmatrix},\quad \begin{bmatrix}2\\5\\8\end{bmatrix}[0\quad 1\quad 0] = \begin{bmatrix}0&2&0\\0&5&0\\0&8&0\end{bmatrix},\quad \begin{bmatrix}3\\6\\10\end{bmatrix}[3\quad 0\quad 1] = \begin{bmatrix}9&0&3\\18&0&6\\30&0&10\end{bmatrix}$$

三块相加：$(1+0+9,\ 0+2+0,\ 2+0+3) = (10,2,5)$，正是第 1 行 ✓；逐块累加得到整个 A_3B_3。

【计算机制解说】：外积视角为什么最重要？ 因为每一个外积 $\mathbf{u}\mathbf{v}^{\mathsf{T}}$ 都是**秩一矩阵**（rank-one）：它的每一列都是 $\mathbf{u}$ 的倍数，每一行都是 $\mathbf{v}^{\mathsf{T}}$ 的倍数，整个矩阵的信息量只有 $m+n$ 个数（而不是 mn 个）。$AB = \sum_k \mathbf{a}_k\mathbf{b}_k^{\mathsf{T}}$ 因此把"矩阵乘法"翻译成"把 n 个秩一矩阵叠加起来"。当 A 或 B 依赖的数据实际上只要少数几个方向时，很多项可以扔掉——这正是第 29 讲 SVD $A = \sigma_1\mathbf{u}_1\mathbf{v}_1^{\mathsf{T}} + \cdots$ 的雏形。另外，视角④立刻给出**秩不等式**：

$$\mathbf{rank}(AB) \le \min(\mathbf{rank}\,A, \mathbf{rank}\,B)$$

因为 AB 只用到了 A 的 n 个列和 B 的 n 个行。

示例 5：用视角④立刻看穿一个秩一矩阵

取 $\mathbf{u} = \begin{bmatrix}1\\2\\3\end{bmatrix}$，$\mathbf{v} = \begin{bmatrix}4\\5\end{bmatrix}$，构造 $\mathbf{u}\mathbf{v}^{\mathsf{T}} = \begin{bmatrix}4&5\\8&10\\12&15\end{bmatrix}$。**不需要任何消元就能断言**：这个 3×2 矩阵的秩是 1。理由：第 1 列是 $4\mathbf{u}$，第 2 列是 $5\mathbf{u}$——**两列都是 $\mathbf{u}$ 的倍数，必然共线**。三行之间也成比例（第 2 行 $= 2\times$ 第 1 行，第 3 行 $= 3\times$ 第 1 行）。用消元验证：$R_2 \leftarrow R_2 - 2R_1$ 得 $(0,0)$，$R_3 \leftarrow R_3 - 3R_1$ 得 $(0,0)$，只剩一个主元。

```
[  4   5 ]                 [  4   5 ]
[  8  10 ]   --消元-->     [  0   0 ]      只有一个主元 => rank = 1
[ 12  15 ]                 [  0   0 ]
```

这个例子的意义：视角④把"秩"从一个需要算出来的量变成了一个**可以看出来的结构**。矩阵 $\mathbf{u}\mathbf{v}^{\mathsf{T}}$ 的"信息"只有 $3+2=5$ 个数（$\mathbf{u}$ 与 $\mathbf{v}$），而它表面上占据了 $3\times 2 = 6$ 个存储位置——**冗余是显而易见的**。SVD 做的事，就是把任意矩阵写成这种"稀疏信息"的叠加，并按重要性排序。

矩阵分解的核心思想

本讲是 $A = LU$ 分解的**舞台搭建**。把上面示例 1 的两边同时左乘 E^{-1}：

$$EA = U \quad\Longrightarrow\quad A = E^{-1}U = LU, \qquad L = E^{-1} = (E_{32}E_{31}E_{21})^{-1} = E_{21}^{-1}E_{31}^{-1}E_{32}^{-1}$$

逐个求逆（消元矩阵的逆只需把那个非对角元素**变号**）：

```
E21 = [ 1  0  0 ]        E21^-1 = [ 1  0  0 ]
      [-3  1  0 ]   -->           [ 3  1  0 ]
      [ 0  0  1 ]                 [ 0  0  1 ]

E31 = I                  E31^-1 = I

E32 = [ 1  0  0 ]        E32^-1 = [ 1  0  0 ]
      [ 0  1  0 ]   -->           [ 0  1  0 ]
      [ 0 -2  1 ]                 [ 0  2  1 ]

L = E21^-1 * E31^-1 * E32^-1 = [ 1  0  0 ]
                               [ 3  1  0 ]
                               [ 0  2  1 ]
```

验证 $LU = A$：

$$\begin{bmatrix}1&0&0\\3&1&0\\0&2&1\end{bmatrix}\begin{bmatrix}1&2&1\\0&2&-2\\0&0&5\end{bmatrix}=\begin{bmatrix}1&2&1\\3&8&1\\0&4&1\end{bmatrix}=A\checkmark$$

这一步揭示了什么：1. L 是**单位下三角**（unit lower triangular，对角线全为 1），它的非对角线元素**恰好就是消元乘数** $l_{21}=3,\ l_{31}=0,\ l_{32}=2$——甚至符号都不需要改。这就是为什么 Strang 说"L 免费赠送"。 2. **乘数的顺序天然正确**：$L=E_{21}^{-1}E_{31}^{-1}E_{32}^{-1}$ 中三个逆矩阵的顺序是 $21,31,32$（与消元顺序一致），而它们相乘后在 $(3,1)$ 位置得到的是 $0+0=0$（因为 $l_{31}=0$），在 $(3,2)$ 位置得到 2。如果顺序反了，就会出现 -3×2 之类的交叉项——这是 LU 分解里"L 的乘数居然不需要修正"这一奇迹的来源。 3. **对角线上是主元**：U 的对角线 $(1,2,5)$ 就是三个主元。第 18 讲将看到 $\det A=1\times 2\times 5=10$（本讲用余子式展开验算 $1(8\cdot 1-1\cdot 4)-2(3\cdot 1-1\cdot 0)+1(3\cdot 4-8\cdot 0)=4-6+12=10$ ✓）。 4. **有换行时**：示例 2 给出的是 $PZ=LU$，即一般形式 $PA=LU$——这是第 4 讲的正式主题。

为什么这个分解值得单独讲一讲：解 $A\mathbf{x}=\mathbf{b}$ 用 LU 的代价是"一次 $n^3/3$ 消元 + 每次回代 n^2"。如果固定 A、反复换不同的 $\mathbf{b}$（工程上极常见），LU 一次分解后，每个新 $\mathbf{b}$ 只要 $O(n^2)$——这就是 LU 相对于"每次重新消元"的全部价值。

"无换行"这个前提有多重要：一个小心的例子。本讲的 A 恰好不需要换行（三个主元 $1,2,5$ 全部非零），所以 $A=LU$ 直接成立。如果像示例 2 那样第一个主元是 0，那么**必须**先换行，得到的是 $PA=LU$ 而不是 $A=LU$：

```
A = [[0,2],[3,4]]     首个主元 a11 = 0, 无法开工

P = [[0,1],[1,0]]     P*A = [[3,4],[0,2]] = U

此时 L = I  (因为换行后 a21 已经是 0, 无需任何消元动作)
但   A = [[0,2],[3,4]]  !=  L*U = [[3,4],[0,2]]

=> 必须写成  P*A = L*U  (此处 = U)
```

结论：$A=LU$ 只在"消元全程不必换行"时成立。**置换矩阵 P 是这件事的记账工具**，它把"换过哪些行"完整记录下来。第 4 讲会把 $PA=LU$ 作为一般定理给出。 **另一个必须记住的细节**：P 的选取也需要讲究策略。示例 2 里我们只是为了"不为零"而换行；实际数值计算中还要**选绝对值最大的主元换上来**（partial pivoting），否则浮点误差会被放大。这是第 4 讲的"数值稳定性"话题。

与其他讲次的关联

- **与第 1 讲**：第 1 讲把 $A\mathbf{x}$ 解释为"A 的列的组合"，本讲则说明**消元不改变这个组合问题本身**——它只是换一组更好用的列（U 的列）来做同样的组合。
- **与第 4 讲（$A=LU$ 分解）**：本讲已经把 E、L、U 全部算好，第 4 讲只需把它们正式命名，讲清 L 的乘数含义、$A=LU$ 与 $PA=LU$ 的完整版，以及"一次分解、多次回代"的工程价值。
- **与第 5 讲（转置、置换、向量空间）**：置换矩阵 P 的 $P^{-1}=P^{\mathsf{T}}$ 在本讲已出现，第 5 讲会把它放进"正交矩阵"的框架；转置与对称矩阵也在那里展开。
- **与第 6–10 讲（子空间）**：消元得到的**主元个数 = 秩 r**；主元所在的列 = 主元列（pivot columns），它们构成 $C(A)$ 的一组基；自由变量对应 $N(A)$ 的基。所以消元是求四个基本子空间的**唯一算法入口**。
- **与第 18–20 讲（行列式）**：U 的对角元乘积 = 主元的乘积 = $\det A$（在无换行时）；一般情形 $\det A=\pm\det P\prod(\text{pivots})$。$E$ 的 $\det$ 恒为 1 正是"行减法不改变体积"。
- **与第 11–12 讲（图与网络）**：消元代价 $n^3/3$ 是对**稠密**矩阵的估计；图的关联矩阵极度稀疏，实际代价远低于此——这就是稀疏消元的动机。
- **与第 14–17 讲（正交与 QR）**：$A=LU$ 用**下三角/上三角**这组"代数上方便的基"；$A=QR$ 用**正交矩阵**这组"数值上稳定得多的基"。Gram–Schmidt 就是消元的正交版本。

关键要点

1. **消元 = 左乘一串可逆的消元矩阵**：$E_{32}E_{31}E_{21}A = U$，因而 $A = E_{21}^{-1}E_{31}^{-1}E_{32}^{-1}U = LU$。每个 E 可逆 ⇒ 解集不变 ⇒ 对 $[A \mid \mathbf{b}]$ 直接动手是合法的。
2. **E_{ij} 的构造口诀：取 I，把 (i,j) 位置的 0 改成 $-l_{ij}$**，其中 $l_{ij} = a_{ij}/a_{jj}$（当前主元）。它的逆只需把 $-l_{ij}$ 改回 $+l_{ij}$；$\det E = 1$。
3. **左乘动行，右乘动列**。消元一律左乘。
4. **主元不能是 0**；是 0 就必须换行，P 是置换矩阵，满足 $P^{-1} = P^{\mathsf{T}}$，$\det P = \pm 1$。一般结论 $PA = LU$。
5. **矩阵乘法四视角**：$c_{ij} = (\text{行}_i)\cdot(\text{列}_j)$ | AB 的列 $= A \times (B \text{ 的列})$ | AB 的行 $= (A \text{ 的行}) \times B$ | $AB = \sum_k \mathbf{a}_k \mathbf{b}_k^{\mathsf{T}}$（秩一矩阵之和）。
6. **消元代价 $\approx n^3/3$ 次乘法**（精确值 $(n^3 - n)/3$），量级上就是"n^2 个元素各被更新约 $n/3$ 次"。

常见误区与注意事项

1. **把 E_{21} 的符号写反**。$E_{21} = \begin{bmatrix} 1 & 0 \\ -3 & 1 \end{bmatrix}$ 对应"$R_2 \leftarrow R_2 - 3R_1$"，$(2,1)$ 位置是 -3。学生常写成 $+3$，然后发现 $E_{21}A$ 的第 2 行变成 $(3,8,1) + 3(1,2,1)$——越消越大。
2. **用 A 的原始元素当主元，而不是更新后的元素**。示例 2 里第 2 个主元是更新后的 2，不是原来的 3 或 8；乘数 $l_{32} = 4/2 = 2$ 用的是**更新后的** $a_{32} = 4$ 与**更新后的**主元 2。用原值会得到完全错误的 L。
3. **对 A 做行变换却忘记同步处理 $\mathbf{b}$**。所以必须一开始就写增广矩阵 $[A \mid \mathbf{b}]$。等价地：先求 E，再算 $\mathbf{b}' = E\mathbf{b}$——但手算时增广矩阵更不容易出错。
4. **以为"消元"和"行列式"无关，或者以为 E 会改变 $\det A$**。所有消元矩阵 $\det E = 1$，所以 $\det U = \det A$；换行矩阵 $\det P = -1$，这才是 $PA = LU$ 里唯一需要小心符号的地方。
5. **把外积的次序号搞错**。视角④是 $AB = \sum_k (\mathbf{A} \text{ 的第 } k \text{ 列})(\mathbf{B} \text{ 的第 } k \text{ 行})$——**列乘行**，不是行乘列。写成行乘列得到的每个块尺寸都不对（1×1 的标量，不是矩阵）。
6. **忘记 $P\mathbf{b}$**。换行时 $\mathbf{b}$ 必须跟着换。很多人只换 A 的行，忘了右端那一列，于是解出错误的 $\mathbf{x}$。

思考题（带答案）

Q1.（纯计算）用消元把下列方程组化成上三角、写出 L 与 U、并回代求 $\mathbf{x}$：

$$A = \begin{bmatrix} 1 & 1 & 1 \\ 2 & 3 & 5 \\ 4 & 6 & 8 \end{bmatrix}, \qquad \mathbf{b} = \begin{bmatrix} 2 \\ 8 \\ 14 \end{bmatrix}$$

▸ **答案**

增广矩阵与逐步消元（每一步的乘数都写在旁边）：

```
[A | b] =
  [ 1  1  1 |  2 ]
  [ 2  3  5 |  8 ]     l21 = 2/1 = 2
  [ 4  6  8 | 14 ]     l31 = 4/1 = 4

R2 <- R2 - 2*R1:
  [ 1  1  1 |  2 ]
  [ 0  1  3 |  4 ]
  [ 4  6  8 | 14 ]

R3 <- R3 - 4*R1:
  [ 1  1  1 |  2 ]
  [ 0  1  3 |  4 ]
  [ 0  2  4 |  6 ]     l32 = 2/1 = 2

R3 <- R3 - 2*R2:
  [ U | c ] =
  [ 1  1  1 |  2 ]
  [ 0  1  3 |  4 ]
  [ 0  0 -2 | -2 ]
```

回代：$-2x_3 = -2 \Rightarrow x_3 = 1$；$x_2 + 3(1) = 4 \Rightarrow x_2 = 1$；$x_1 + 1 + 1 = 2 \Rightarrow x_1 = 0$。

$$\boxed{\mathbf{x} = \begin{bmatrix} 0 \\ 1 \\ 1 \end{bmatrix}}, \qquad A\mathbf{x} = \begin{bmatrix} 1\cdot 0 + 1\cdot 1 + 1\cdot 1 \\ 2\cdot 0 + 3\cdot 1 + 5\cdot 1 \\ 4\cdot 0 + 6\cdot 1 + 8\cdot 1 \end{bmatrix} = \begin{bmatrix} 2 \\ 8 \\ 14 \end{bmatrix} = \mathbf{b} \checkmark$$

> L 的三个乘数就是 $l_{21}=2$、$l_{31}=4$、$l_{32}=2$，直接放进单位下三角：
>
> $$L=\begin{bmatrix}1&0&0\\2&1&0\\4&2&1\end{bmatrix},\qquad U=\begin{bmatrix}1&1&1\\0&1&3\\0&0&-2\end{bmatrix}$$
>
> 验证：$LU=\begin{bmatrix}1&1&1\\2&3&5\\4&6&8\end{bmatrix}=A$ ✓。主元 $1,1,-2$ 之积 $=-2=\det A$。

Q2.（概念理解）设 $E=\begin{bmatrix}1&0\\3&1\end{bmatrix}$ 是把 I_2 的 $(2,1)$ 位置从 0 改成 3 得到的矩阵，$M=\begin{bmatrix}1&2\\3&4\end{bmatrix}$。(a) 解释 EM 和 ME 各自的几何含义；(b) 求 E^{-1}，并说明为什么 $\det E=1$；(c) 判断 $EM=ME$ 是否成立。

> ▸ **答案**
>
> (a) E 的 $(2,1)$ 位置是 $+3$，对应操作 $R_2\leftarrow R_2+3R_1$。– $EM=\begin{bmatrix}1&2\\6&10\end{bmatrix}$：**行变换**。第 2 行 $=(3,4)+3(1,2)=(6,10)$，第 1 行不变。几何上是把第二行沿第一行的方向"推"了一下。– $ME=\begin{bmatrix}7&2\\15&4\end{bmatrix}$：**列变换**。第 1 列 $=(1,3)+3(2,4)=(7,15)$，第 2 列不变。几何上动的是列。
>
> (b) 逆操作是 $R_2\leftarrow R_2-3R_1$，即把那个 3 改回 -3：
>
> $$E^{-1}=\begin{bmatrix}1&0\\-3&1\end{bmatrix},\qquad E^{-1}E=\begin{bmatrix}1&0\\-3&1\end{bmatrix}\begin{bmatrix}1&0\\3&1\end{bmatrix}=\begin{bmatrix}1&0\\0&1\end{bmatrix}\checkmark$$
>
> $\det E=1\cdot1-0\cdot3=1$。几何上 E 是剪切（shear）：它把 (x_1,x_2) 送到 $(x_1,\ x_2+3x_1)$，保持 x_1 不变、只沿竖直方向滑动——单位方格被推成平行四边形，**面积不变**，所以行列式为 1。
>
> (c) **不成立**。$EM=\begin{bmatrix}1&2\\6&10\end{bmatrix}\neq\begin{bmatrix}7&2\\15&4\end{bmatrix}=ME$。这不是巧合而是常态：**左乘动行、右乘动列**，两种操作本质不同。（只有当 M 恰好对 E 所描述的行操作与列操作"对称"时才可能相等。）

Q3.（四视角）设 $A=\begin{bmatrix}1&2\\3&4\end{bmatrix}$，$B=\begin{bmatrix}1&0\\2&1\end{bmatrix}$。用四种视角分别计算 AB，并指出哪一种视角最能说明 $\mathbf{rank}(AB)\le\mathbf{rank}(A)$。

> ▸ **答案**
>
> **视角①（行 × 列点积）**：
>
> $$AB=\begin{bmatrix}1\cdot1+2\cdot2&1\cdot0+2\cdot1\\3\cdot1+4\cdot2&3\cdot0+4\cdot1\end{bmatrix}=\begin{bmatrix}5&2\\11&4\end{bmatrix}$$
>
> **视角②（列的组合）**：$A\begin{bmatrix}1\\2\end{bmatrix}=1\begin{bmatrix}1\\3\end{bmatrix}+2\begin{bmatrix}2\\4\end{bmatrix}=\begin{bmatrix}5\\11\end{bmatrix}$，$A\begin{bmatrix}0\\1\end{bmatrix}=\begin{bmatrix}2\\4\end{bmatrix}$。拼起来 $\begin{bmatrix}5&2\\11&4\end{bmatrix}$ ✓
>
> **视角③（行的组合）**：$[1\quad2]B=(1,0)+2(2,1)=(5,2)$，$[3\quad4]B=(3,0)+4(2,1)=(11,4)$。✓
>
> **视角④（外积之和）**：
>
> $$\begin{bmatrix}1\\3\end{bmatrix}[1\quad0]+\begin{bmatrix}2\\4\end{bmatrix}[2\quad1]=\begin{bmatrix}1&0\\3&0\end{bmatrix}+\begin{bmatrix}4&2\\8&4\end{bmatrix}=\begin{bmatrix}5&2\\11&4\end{bmatrix}\checkmark$$
>
> **答案：视角④（与视角②）**。视角④把 AB 写成 $\sum_k \mathbf{a}_k\mathbf{b}_k^{\mathrm{T}}$，每一项都是一块由 A 的列决定的秩一矩阵；既然 AB 是 A 的 n 个列方向上的叠加，AB 的列空间必然 $\subseteq C(A)$，所以 $\mathbf{rank}(AB)\le\mathbf{rank}(A)$。视角②说同样的事：**$AB$ 的每一列都是 A 的列的组合**。

Lecture 3: Multiplication and Inverse Matrices

概述

上一讲我们用消元把矩阵变成了上三角，并把消元过程写成了一串 E 的乘积。本讲把镜头对准两个问题。第一，**矩阵乘法到底遵守哪些运算律**——它不满足交换律，但满足结合律与分配律，而这两条正是消元能被压缩成单个 E 的全部依据。第二，**方阵的逆**：什么矩阵有逆、逆的几何意义是什么、

以及最实用的求法——Gauss–Jordan 法 $[A \mid I] \to [I \mid A^{-1}]$。这一讲结束时，"逆"不再是一个抽象符号，而是一串可以逐行追踪的行变换。

核心概念的几何直觉

乘法不交换：$AB \neq BA$

- **定义与目的**：对一般的方阵 A, B，AB 与 BA 通常不相等。明确这一点是为了避免"把标量代数的直觉搬到矩阵上"这一最普遍的错误。$A(B+C) = AB + AC$（左分配）、$(A+B)C = AC + BC$（右分配）、$(AB)C = A(BC)$（结合律）**都成立**；唯独 $AB = BA$ 不成立。
- **几何直觉（它在空间中是什么样子？）**：矩阵是**变换**，AB 意味着"先做 B，再做 A"。先旋转再拉伸，与先拉伸再旋转，得到的结果不同——这是最直观的例子。两个变换能不能换序，取决于它们在几何上是否"对齐"（比如同轴缩放就能换序，因为 $\begin{bmatrix}2&0\\0&3\end{bmatrix}\begin{bmatrix}4&0\\0&5\end{bmatrix} = \begin{bmatrix}8&0\\0&15\end{bmatrix}$ 两种顺序一样）。
- **具体示例**：

$$A = \begin{bmatrix}1&2\\3&4\end{bmatrix}, \quad B = \begin{bmatrix}0&1\\1&0\end{bmatrix} \implies AB = \begin{bmatrix}2&1\\4&3\end{bmatrix}, \quad BA = \begin{bmatrix}3&4\\1&2\end{bmatrix}$$

B 的几何作用是"交换两个坐标"。AB 表示"先换坐标、再用 A 组合"，BA 表示"先用 A 组合、再换坐标"——两者是不同的变换：AB 的第 1 行是 $(2,1)$，BA 的第 1 行是 $(3,4)$，四个元素全不一样。 再看一个更能说明问题的例子（A 不动，换一个 C）：

$$C = \begin{bmatrix}1&1\\0&1\end{bmatrix} \implies AC = \begin{bmatrix}1&3\\3&7\end{bmatrix}, \qquad CA = \begin{bmatrix}4&6\\3&4\end{bmatrix}$$

四个数全不一样。

结合律：$(AB)\,C = A\,(BC)$

- **定义与目的**：只要维数匹配，括号可以任意重打。这是**所有矩阵分块、所有"把一串变换打包成一个矩阵"的操作的合法性来源**。
- **几何直觉（它在空间中是什么样子？）**：三个变换按同一个顺序作用，"先合 A, B 再作用到 C 的结果上"与"先合 B, C 再让 A 作用"，物理过程完全相同——反正作用的先后次序就是 $C \to B \to A$。结合律说的就是"复合的顺序是本质，打包的方式不是"。
- **具体示例**：

$$X = \begin{bmatrix}1&2\\3&4\end{bmatrix}, \quad Y = \begin{bmatrix}1&0\\2&1\end{bmatrix}, \quad Z = \begin{bmatrix}2&1\\0&1\end{bmatrix}$$

$$XY = \begin{bmatrix}5&2\\11&4\end{bmatrix} \Rightarrow (XY)Z = \begin{bmatrix}5\cdot2+2\cdot0 & 5\cdot1+2\cdot1\\ 11\cdot2+4\cdot0 & 11\cdot1+4\cdot1\end{bmatrix} = \begin{bmatrix}10&7\\22&15\end{bmatrix}$$

$$YZ = \begin{bmatrix}2&1\\4&3\end{bmatrix} \Rightarrow X(YZ) = \begin{bmatrix}1\cdot2+2\cdot4 & 1\cdot1+2\cdot3\\ 3\cdot2+4\cdot4 & 3\cdot1+4\cdot3\end{bmatrix} = \begin{bmatrix}10&7\\22&15\end{bmatrix} \checkmark$$

完全相等。**本讲最重要的推论**：既然结合律成立，上一讲的

$$E_{32}\big(E_{31}(E_{21}A)\big) = \big(E_{32}E_{31}E_{21}\big)A$$

才是合法的——"整串消元 = 一个矩阵 E"这句话才有意义。

方阵的逆（Inverse）：定义与"撤销"的几何意义

- **定义与目的**：对方阵 A，如果存在方阵 B 使得 $AB = BA = I$，就称 A **可逆**（invertible / nonsingular），记 $B = A^{-1}$。它的目的是回答一个极其实用的问题：**已知变换后的结果，怎么还原回去？** 于是 $A\mathbf{x} = \mathbf{b}$ 立刻有解 $\mathbf{x} = A^{-1}\mathbf{b}$。
- **几何直觉（它在空间中是什么样子？）**：A 把 $\mathbb{R}^n$ 送到 $\mathbb{R}^n$ 的某个像集。A^{-1} **存在** $\iff$ **这个映射是一一对应的**（one-to-one and onto），也就是整个空间被 A 搬到整个空间，一个点也没挤在一起。这时 A^{-1} 就是"倒带"：把每个像点送回它唯一的原像。 具体到 2×2：A 把单位方格变形为一个平行四边形。**可逆 = 这个平行四边形的面积不是 0**（空间没有被压扁），于是整个平面被"一对一"地铺满，任何 $\mathbf{b}$ 都能唯一对应一个 $\mathbf{x}$。
- **具体示例**：

$$A = \begin{bmatrix}1&2\\3&8\end{bmatrix} \text{ 把 } \begin{pmatrix}1\\0\end{pmatrix} \mapsto \begin{pmatrix}1\\3\end{pmatrix}, \quad \begin{pmatrix}0\\1\end{pmatrix} \mapsto \begin{pmatrix}2\\8\end{pmatrix}, \quad \begin{pmatrix}1\\1\end{pmatrix} \mapsto \begin{pmatrix}3\\11\end{pmatrix}$$

单位方格（面积 1）被送到由 $\binom{1}{3}$、$\binom{2}{8}$ 张成的平行四边形，面积 $= |1\cdot8 - 2\cdot3| = 2$。面积没塌，所以可逆。 它的逆是

$$A^{-1} = \begin{bmatrix}4&-1\\-\frac{3}{2}&\frac{1}{2}\end{bmatrix}$$

验证 $A^{-1}\binom{3}{11} = \binom{4\cdot3-1\cdot11}{-\frac{3}{2}\cdot3+\frac{1}{2}\cdot11} = \binom{1}{1}$——正好把 $\binom{1}{1}$ 送回了家。✓

奇异矩阵（Singular）：把平面压扁，信息丢失

- **定义与目的**：没有逆的方阵叫**奇异矩阵**。判据可以有很多等价说法：$\det A = 0$；消元出现零主元；A 的列线性相关；$N(A) \neq \{\mathbf{0}\}$；$A\mathbf{x} = \mathbf{b}$ 对某些 $\mathbf{b}$ 无解、对另一些有无穷多解。
- **几何直觉（它在空间中是什么样子？）**：A 把 $\mathbb{R}^n$ 压到一个**更低维的子空间**上。$\mathbb{R}^2$ 被压到一条直线（或一个点）之后，**原来在垂直于这条直线的方向上的一切差异都被抹掉了**——两个不同的输入可以有同一个输出。既然映射不是一对一，"倒带"就不可能存在。这就是"信息丢失"的准确含义。
- **具体示例**：$S = \begin{bmatrix} 1 & 2 \\ 2 & 4 \end{bmatrix}$。
- 第 2 列 $= \begin{bmatrix} 2 \\ 4 \end{bmatrix} = 2 \times \begin{bmatrix} 1 \\ 2 \end{bmatrix} = 2\times$ 第 1 列，列线性相关。
- 单位方格的四个顶点：$(0,0) \mapsto (0,0)$，$(1,0) \mapsto (1,2)$，$(0,1) \mapsto (2,4)$，$(1,1) \mapsto (3,6)$——**四个点全部落在同一条直线 $y = 2x$ 上**，方格被压成了一条线段，面积为 0。
- 两个不同的输入给出同一个输出：$S\binom{1}{0} = \binom{1}{2}$ 且 $S\binom{-1}{1} = \binom{-1+2}{-2+4} = \binom{1}{2}$。同一个输出 $\binom{1}{2}$ 有两个原像，无法"倒带"。
- 非零向量被送到零：$S\binom{2}{-1} = \binom{2-2}{4-4} = \binom{0}{0}$，即 $\binom{2}{-1} \in N(S)$。**正是这个非零的零空间吃掉了信息。**

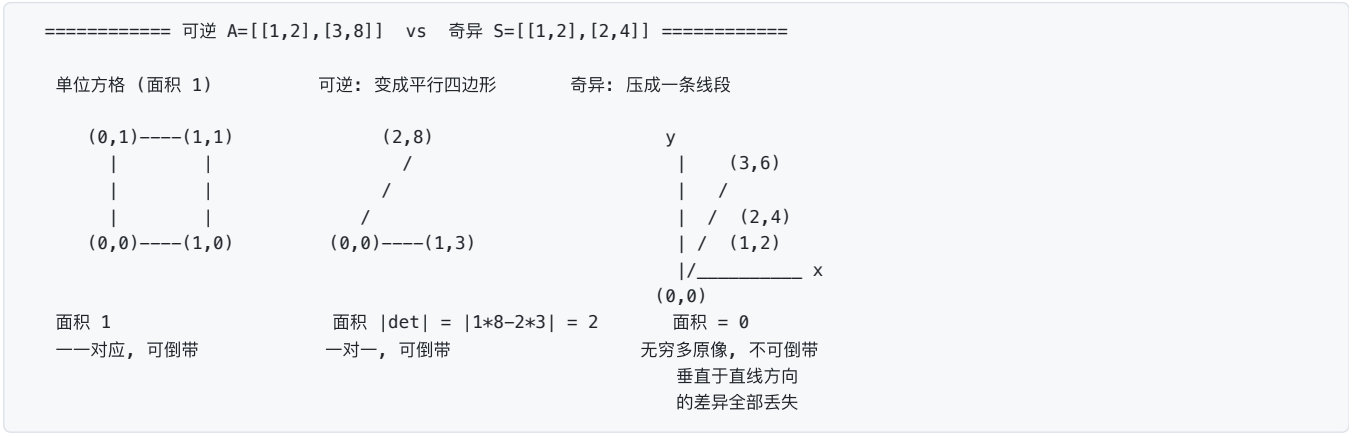

【要点】：$\det A$ 的正负号也有几何含义——**det** 为负表示变换**翻转了定向**（左右手互换）。$P = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}$ 交换坐标，把 $(1,0)$ 送到 $(0,1)$、$(0,1)$ 送到 $(1,0)$，$\det P = -1$，方向被翻转，但 $|\det| = 1$ 面积未变，所以仍可逆（$P^{-1} = P^{\mathsf{T}} = P$）。

对角矩阵与三角矩阵的逆

- **定义与目的**：某些特殊形状的矩阵，逆可以"看"出来，不必做消元。掌握它们能极大加快手算，也是后面理解 $A = LU$、$A = S\Lambda S^{-1}$、Cholesky 等分解的基础。
- **几何直觉（它在空间中是什么样子？）**：
- **对角矩阵**：各个坐标轴**独立地**被拉伸（或压缩）。逆就是把每个拉伸倍数取倒数——各轴互不干扰，所以直接逐项取倒数即可。
- **下三角矩阵**：变换是"逐级叠加"的（第 k 个坐标只受前 $k-1$ 个影响）。逆就是**逐个拆解**这个叠加过程：从第 1 个坐标开始还原，再还原第 2 个……这正是前代（forward substitution）。
- **上三角矩阵**：反过来，从最后一个坐标开始还原（回代）。
- **具体示例**：

$$D = \begin{bmatrix} 2 & 0 & 0 \\ 0 & 4 & 0 \\ 0 & 0 & 5 \end{bmatrix} \Longrightarrow D^{-1} = \begin{bmatrix} \frac{1}{2} & 0 & 0 \\ 0 & \frac{1}{4} & 0 \\ 0 & 0 & \frac{1}{5} \end{bmatrix}, \qquad \det D = 2 \cdot 4 \cdot 5 = 40$$

$$T_2 = \begin{bmatrix} 1 & 2 & 3 \\ 0 & 1 & 2 \\ 0 & 0 & 1 \end{bmatrix} \Longrightarrow T_2^{-1} = \begin{bmatrix} 1 & -2 & 1 \\ 0 & 1 & -2 \\ 0 & 0 & 1 \end{bmatrix}$$

验算：$T_2 T_2^{-1}$ 的第 1 行 $= (1,2,3)\cdot$ 各列，其中 $(1,2,3)\cdot(-2,1,0)^{\mathsf{T}} = -2+2+0 = 0$，$(1,2,3)\cdot(1,-2,1)^{\mathsf{T}} = 1-4+3 = 0$ ✓。上三角矩阵的逆**仍是上三角**——因为"从后往前拆解"不会引入更早的坐标。

计算步骤与手算演示

示例 1（主讲）：Gauss–Jordan 求 2×2 的逆

$$A = \begin{bmatrix} 1 & 2 \\ 3 & 8 \end{bmatrix}$$

核心思想：把 I 并排挂在 A 右边得到 $[A \mid I]$，然后对**整个**（加宽了的）矩阵做行变换，直到左边变成 I。此时右边自动就是 A^{-1}。

步骤 0：写出增广矩阵。

```
[A | I] =
  [ 1  2 | 1  0 ]
  [ 3  8 | 0  1 ]
```

步骤 1：消去 $(2,1)$。 乘数 $l_{21} = 3/1 = 3$，操作 $R_2 \leftarrow R_2 - 3R_1$。注意**两半都动**：– 左半第 2 行 $= (3,8) - 3(1,2) = (0,2)$ – 右半第 2 行 $= (0,1) - 3(1,0) = (-3,1)$

对应的消元矩阵（加宽到 4 列的作用是 $E_{21} = \begin{bmatrix} 1 & 0 \\ -3 & 1 \end{bmatrix}$）：

```
after R2 <- R2 - 3*R1:
  [ 1  2 |  1   0 ]
  [ 0  2 | -3   1 ]
```

步骤 2：把第 2 个主元归一化为 1。 操作 $R_2 \leftarrow \frac{1}{2}R_2$（这对应左乘 $D = \begin{bmatrix} 1 & 0 \\ 0 & \frac{1}{2} \end{bmatrix}$）：– 左半第 2 行 $= (0,2)/2 = (0,1)$ – 右半第 2 行 $= (-3,1)/2 = (-\frac{3}{2}, \frac{1}{2})$

```
after R2 <- (1/2)*R2:
  [ 1  2 |   1     0  ]
  [ 0  1 | -3/2   1/2 ]
```

步骤 3：Jordan 消元——向上消去 $(1,2)$。 这是 Gauss–Jordan 与普通 Gauss 的唯一区别：普通 Gauss 到此停止（U 已经是上三角），然后回代；Jordan 则继续把主元**上方**也清掉。操作 $R_1 \leftarrow R_1 - 2R_2$（左乘 $E_{12} = \begin{bmatrix} 1 & -2 \\ 0 & 1 \end{bmatrix}$）：– 左半第 1 行 $= (1,2) - 2(0,1) = (1,0)$ – 右半第 1 行 $= (1,0) - 2(-\frac{3}{2}, \frac{1}{2}) = (1+3,\ 0-1) = (4,-1)$

```
after R1 <- R1 - 2*R2:
  [ 1  0 |  4   -1  ]
  [ 0  1 | -3/2  1/2 ]
```

左边已是 I，于是右边读出

$$A^{-1} = \begin{bmatrix} 4 & -1 \\ -\frac{3}{2} & \frac{1}{2} \end{bmatrix}$$

验算：

$$AA^{-1} = \begin{bmatrix} 1 & 2 \\ 3 & 8 \end{bmatrix} \begin{bmatrix} 4 & -1 \\ -\frac{3}{2} & \frac{1}{2} \end{bmatrix} = \begin{bmatrix} 4-3 & -1+1 \\ 12-12 & -3+4 \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \checkmark$$

完整 ASCII 对比图：每一步两半同时变化

```
   step              左半 (A 侧)          右半 (I 侧)         作用
 ------------------------------------------------------------------------
   start          [ 1  2 ]            [ 1   0 ]          恒等
                  [ 3  8 ]            [ 0   1 ]
                        |
                        |  R2 <- R2 - 3*R1     (左乘 E21)
                        v
   after E21      [ 1  2 ]            [  1    0 ]        清掉 a21
                  [ 0  2 ]            [ -3    1 ]
                        |
                        |  R2 <- (1/2)*R2      (左乘 D)
                        v
   after D        [ 1  2 ]            [   1     0  ]     主元归一
                  [ 0  1 ]            [ -3/2   1/2 ]
                        |
                        |  R1 <- R1 - 2*R2     (左乘 E12)
                        v
   after E12      [ 1  0 ]            [   4    -1  ]     清掉 a12
                  [ 0  1 ]            [ -3/2   1/2 ]     => A^-1 出现在右边
```

【计算机制解说】：为什么"左乘一串 E 就等于 A^{-1}"？ 把三个步骤合起来看。我们实际做的是：

$$E_{12}\Big(D\big(E_{21}[A \mid I]\big)\Big) = [I \mid A^{-1}]$$

由于每个行变换都作用在整个加宽矩阵上，可以拆成两半分别看。左半给出

$$E_{12}DE_{21}A = I$$

右半给出

$$E_{12}DE_{21}I = E_{12}DE_{21}$$

所以右边那半算出来的东西就是 $E_{12}DE_{21}$。而左半等式 $MA = I$（其中 $M = E_{12}DE_{21}$）意味着 M 就是 A^{-1}。（对**方阵**而言，$MA = I$ 已经足够推出 $M = A^{-1}$，因为消元过程保证这些 E 都可逆。） **换句话说：$[A \mid I] \to [I \mid A^{-1}]$ 这个算法"顺手"把整串变换的乘积记录在了右边。** 逐项验算这个乘积：

$$E_{12}DE_{21} = \begin{bmatrix}1 & -2\\ 0 & 1\end{bmatrix}\begin{bmatrix}1 & 0\\ 0 & \frac{1}{2}\end{bmatrix}\begin{bmatrix}1 & 0\\ -3 & 1\end{bmatrix} = \begin{bmatrix}1 & -2\\ 0 & 1\end{bmatrix}\begin{bmatrix}1 & 0\\ -\frac{3}{2} & \frac{1}{2}\end{bmatrix} = \begin{bmatrix}1+3 & -1\\ -\frac{3}{2} & \frac{1}{2}\end{bmatrix} = \begin{bmatrix}4 & -1\\ -\frac{3}{2} & \frac{1}{2}\end{bmatrix} = A^{-1}\ \checkmark$$

为什么不回代而继续往上消？ 两种做法算出的 A^{-1} 完全相同。Gauss–Jordan 的好处是**不需要动脑子回代**——左边一旦变成 I，右边直接可读。代价是运算量略大（约 $n^3/2$ 而非 $n^3/3$），而且数值上不做选主元时不如 LU 稳定。

示例 2（主讲）：Gauss–Jordan 求 3×3 的逆

选一个有**整数逆**的例子，便于手算核验：

$$B = \begin{bmatrix}1 & 1 & 0\\ 1 & 2 & 1\\ 0 & 1 & 2\end{bmatrix}$$

步骤 0：

```
[B | I] =
  [ 1  1  0 | 1  0  0 ]
  [ 1  2  1 | 0  1  0 ]
  [ 0  1  2 | 0  0  1 ]
```

步骤 1：$R_2 \leftarrow R_2 - R_1$（乘数 $l_{21} = 1$）。

```
  [ 1  1  0 |  1   0   0 ]
  [ 0  1  1 | -1   1   0 ]
  [ 0  1  2 |  0   0   1 ]
```

步骤 2：$R_3 \leftarrow R_3 - R_2$（乘数 $l_{32} = 1$）。

```
  [ 1  1  0 |  1   0   0 ]
  [ 0  1  1 | -1   1   0 ]
  [ 0  0  1 |  1  -1   1 ]
```

（第 3 行左半 $= (0,1,2) - (0,1,1) = (0,0,1)$；右半 $= (0,0,1) - (-1,1,0) = (1,-1,1)$。） 此时左边已经是上三角 U，且**主元全为 1**（所以不需要做归一化这一步——这是选这个例子的理由）。

步骤 3：Jordan 向上消元，先清 $(2,3)$：$R_2 \leftarrow R_2 - R_3$。

```
  [ 1  1  0 |  1   0   0 ]
  [ 0  1  0 | -2   2  -1 ]
  [ 0  0  1 |  1  -1   1 ]
```

（第 2 行左半 $= (0,1,1) - (0,0,1) = (0,1,0)$；右半 $= (-1,1,0) - (1,-1,1) = (-2,2,-1)$。）

步骤 4：再清 $(1,2)$：$R_1 \leftarrow R_1 - R_2$。

```
  [ 1  0  0 |  3  -2   1 ]
  [ 0  1  0 | -2   2  -1 ]
  [ 0  0  1 |  1  -1   1 ]
```

（第 1 行左半 $= (1,1,0) - (0,1,0) = (1,0,0)$；右半 $= (1,0,0) - (-2,2,-1) = (3,-2,1)$。）

左边成为 I_3，读出

$$B^{-1}=\begin{bmatrix}3&-2&1\\-2&2&-1\\1&-1&1\end{bmatrix}$$

验算：

$$BB^{-1}=\begin{bmatrix}1&1&0\\1&2&1\\0&1&2\end{bmatrix}\begin{bmatrix}3&-2&1\\-2&2&-1\\1&-1&1\end{bmatrix}$$

第 1 行：$(1,1,0)\to(3-2,\ -2+2,\ 1-1)=(1,0,0)$ ✓ 第 2 行：$(1,2,1)\to(3-4+1,\ -2+4-1,\ 1-2+1)=(0,1,0)$ ✓ 第 3 行：$(0,1,2)\to(-2+2,\ 2-2,\ -1+2)=(0,0,1)$ ✓ 反向 $B^{-1}B=I_3$ 也成立（两次验算都通过）。$\det B=1\cdot1\cdot1=1$（三个主元之积），这也解释了为什么逆是整数矩阵。

完整 ASCII：3×3 的 Gauss–Jordan 全过程

```
   step               left (B)             right (I)
-------------------------------------------------------------
   start          [ 1  1  0 ]           [  1   0   0 ]
                  [ 1  2  1 ]           [  0   1   0 ]
                  [ 0  1  2 ]           [  0   0   1 ]
                        |
                        |  R2 <- R2 - R1
                        v
   step 1         [ 1  1  0 ]           [  1   0   0 ]
                  [ 0  1  1 ]           [ -1   1   0 ]
                  [ 0  1  2 ]           [  0   0   1 ]
                        |
                        |  R3 <- R3 - R2
                        v
   step 2 (U)     [ 1  1  0 ]           [  1   0   0 ]
                  [ 0  1  1 ]           [ -1   1   0 ]
                  [ 0  0  1 ]           [  1  -1   1 ]
                        |
                        |  R2 <- R2 - R3        (Jordan 开始)
                        v
   step 3         [ 1  1  0 ]           [  1   0   0 ]
                  [ 0  1  0 ]           [ -2   2  -1 ]
                  [ 0  0  1 ]           [  1  -1   1 ]
                        |
                        |  R1 <- R1 - R2
                        v
   step 4 (I)     [ 1  0  0 ]           [  3  -2   1 ]
                  [ 0  1  0 ]           [ -2   2  -1 ]
                  [ 0  0  1 ]           [  1  -1   1 ]
```

【计算机制解说】：这个 3×3 例子把"为什么左乘一串 E 就是 A^{-1}"讲得更透。 我们一共用了四个行变换，把它们写成矩阵：$E_{21}=\begin{bmatrix}1&0&0\\-1&1&0\\0&0&1\end{bmatrix}$，$E_{32}=\begin{bmatrix}1&0&0\\0&1&0\\0&-1&1\end{bmatrix}$，$E_{23}=\begin{bmatrix}1&0&0\\0&1&-1\\0&0&1\end{bmatrix}$，$E_{12}=\begin{bmatrix}1&-1&0\\0&1&0\\0&0&1\end{bmatrix}$。整个算法断言

$$M=E_{12}E_{23}E_{32}E_{21}\quad\text{满足}\quad MB=I\implies M=B^{-1}$$

而 $[B\mid I]\to I\mid M$ 的过程恰好把 M 累积在右边。**注意这里不需要回代，也不需要把主元归一化**——只要左边化成 I，右边就是答案。 **还有一个更深的观察**：这个算法的成功本身就是**可逆性的判据**。如果消元过程中某一步在某一列找不到非零主元（即使换行也找不到），左边就**永远**变不成 I——这就是 B 奇异的标志。所以"Gauss–Jordan 是否走得通"就是"A 是否可逆"的检验。可以证明：$2n\times n$ 的矩阵 $[A\mid I]$ 的行阶梯形有 n 个主元 $\iff$ A 可逆。 **顺带记账**：四个 E 的乘积就是 B^{-1}，即

$$B^{-1}=E_{12}E_{23}E_{32}E_{21}$$

这与上一讲的 $E=E_{32}E_{31}E_{21}$ 是同一回事，只是方向相反——**消元把 A 化成 I 的矩阵，就是 A^{-1}**。

示例 3：2×2 逆矩阵公式与行列式

对方阵 $\begin{bmatrix}a&b\\c&d\end{bmatrix}$，有

$$\boxed{\begin{bmatrix} a & b \\ c & d \end{bmatrix}^{-1} = \frac{1}{ad-bc}\begin{bmatrix} d & -b \\ -c & a \end{bmatrix}} \qquad (\text{要求 } ad-bc \neq 0)$$

推导（顺便看清"为什么是这个公式"）：直接乘法验算

$$\begin{bmatrix} a & b \\ c & d \end{bmatrix}\begin{bmatrix} d & -b \\ -c & a \end{bmatrix} = \begin{bmatrix} ad-bc & -ab+ba \\ cd-dc & -cb+da \end{bmatrix} = \begin{bmatrix} ad-bc & 0 \\ 0 & ad-bc \end{bmatrix} = (ad-bc)I$$

两边除以 $ad-bc$（非零时）即得。**注意对角线上出现的两个 0 是"巧合的代数抵消"**：$-ab+ba=0$ 和 $cd-dc=0$。这个抵消成立的唯一原因是我们在 $(1,1)$ 位置放了 d、$(1,2)$ 位置放了 $-b$——交换 b,c 的位置并加负号。

具体验算（三组）：– $A=\begin{bmatrix}1&2\\3&8\end{bmatrix}$：$ad-bc=1\cdot 8-2\cdot 3=2$，故 $A^{-1}=\frac{1}{2}\begin{bmatrix}8&-2\\-3&1\end{bmatrix}=\begin{bmatrix}4&-1\\-\frac{3}{2}&\frac{1}{2}\end{bmatrix}$ ✓（与示例 1 一致）– $M=\begin{bmatrix}3&1\\1&2\end{bmatrix}$：$ad-bc=3\cdot 2-1\cdot 1=5$，故 $M^{-1}=\frac{1}{5}\begin{bmatrix}2&-1\\-1&3\end{bmatrix}=\begin{bmatrix}\frac{2}{5}&-\frac{1}{5}\\-\frac{1}{5}&\frac{3}{5}\end{bmatrix}$。验算 $MM^{-1}=\frac{1}{5}\begin{bmatrix}3&1\\1&2\end{bmatrix}\begin{bmatrix}2&-1\\-1&3\end{bmatrix}=\frac{1}{5}\begin{bmatrix}6-1&-3+3\\2-2&-1+6\end{bmatrix}=\begin{bmatrix}1&0\\0&1\end{bmatrix}$ ✓ – $N=\begin{bmatrix}1&2\\3&4\end{bmatrix}$：$ad-bc=4-6=-2$，故 $N^{-1}=\frac{1}{-2}\begin{bmatrix}4&-2\\-3&1\end{bmatrix}=\begin{bmatrix}-2&1\\\frac{3}{2}&-\frac{1}{2}\end{bmatrix}$。验算 $NN^{-1}=\begin{bmatrix}-2+3&1-1\\-6+6&3-2\end{bmatrix}=\begin{bmatrix}1&0\\0&1\end{bmatrix}$ ✓

行列式 $ad-bc$ 的三重身份：

```
ad – bc  扮演的三个角色
------------------------------------------------------------------
1) 可逆性判据 :  ad-bc != 0  <=>  A 可逆 (A^-1 的分母不为零)
2) 面积缩放因子:  单位方格 -> 平行四边形的面积 = |ad-bc|
                  (符号表示定向是否翻转: 负 = 左右手互换)
3) 主元之积    :  ad-bc = (第1主元) x (第2主元), 也是消元能否走通的标志
------------------------------------------------------------------
[[1,2],[3,8]] :  det = 2   -> 面积 2,  可逆
[[1,2],[2,4]] :  det = 0   -> 面积 0,  奇异 (压成直线)
[[0,1],[1,0]] :  det = -1  -> 面积 1,  可逆但翻转定向
```

【计算机制解说】：行列式为什么是**面积**？ 考虑 A 的两列 $\mathbf{a}_1=\binom{a}{c}$、$\mathbf{a}_2=\binom{b}{d}$。$A$ 把单位方格（由 $\mathbf{e}_1,\mathbf{e}_2$ 张成，面积 1）送到由 $\mathbf{a}_1,\mathbf{a}_2$ 张成的平行四边形。这个平行四边形的（有向）面积恰好是 $ad-bc$——它是二维叉积 / 楔积 $|\mathbf{a}_1\ \mathbf{a}_2|$ 的分量形式。**而"面积是否为 0"正是"两列是否共线"**：面积 $0 \iff \mathbf{a}_1,\mathbf{a}_2$ 线性相关 $\iff$ 平面被压扁 $\iff$ 奇异。这就把"$\det=0 \iff$ 不可逆"这条代数判据翻译成了纯几何事实。第 18 讲会把这件事推广到 n 维：$|\det A|$ 是 n 维盒子的体积。

示例 4：逆的运算律及验证

(AB)^{–1} = B^{–1}A^{–1}（"穿鞋脱鞋"顺序）

- **几何直觉**：早晨先穿袜子（B）再穿鞋（A）。要取消这一切，必须**先脱鞋（A^{-1}）再脱袜子（B^{-1}）**。顺序必须颠倒，因为 A 只认识"穿了袜子之后的脚"。这正是 $(AB)^{-1}=B^{-1}A^{-1}$ 而不是 $A^{-1}B^{-1}$。
- **具体验证**：取

$$A=\begin{bmatrix}1&2\\3&8\end{bmatrix},\qquad B=\begin{bmatrix}2&1\\1&1\end{bmatrix}$$

先算乘积：$AB=\begin{bmatrix}1\cdot 2+2\cdot 1&1\cdot 1+2\cdot 1\\3\cdot 2+8\cdot 1&3\cdot 1+8\cdot 1\end{bmatrix}=\begin{bmatrix}4&3\\14&11\end{bmatrix}$，$\det(AB)=4\cdot 11-3\cdot 14=44-42=2$。

$$(AB)^{-1}=\frac{1}{2}\begin{bmatrix}11&-3\\-14&4\end{bmatrix}=\begin{bmatrix}\frac{11}{2}&-\frac{3}{2}\\-7&2\end{bmatrix}$$

另一边：$\det A=2$，$A^{-1}=\begin{bmatrix}4&-1\\-\frac{3}{2}&\frac{1}{2}\end{bmatrix}$；$\det B=1$，$B^{-1}=\begin{bmatrix}1&-1\\-1&2\end{bmatrix}$。

$$B^{-1}A^{-1}=\begin{bmatrix}1&-1\\-1&2\end{bmatrix}\begin{bmatrix}4&-1\\-\frac{3}{2}&\frac{1}{2}\end{bmatrix}=\begin{bmatrix}4+\frac{3}{2}&-1-\frac{1}{2}\\-4-3&1+1\end{bmatrix}=\begin{bmatrix}\frac{11}{2}&-\frac{3}{2}\\-7&2\end{bmatrix}=(AB)^{-1}\ \checkmark$$

若按**错误顺序** $A^{-1}B^{-1}$：

$$A^{-1}B^{-1}=\begin{bmatrix}4&-1\\-\frac{3}{2}&\frac{1}{2}\end{bmatrix}\begin{bmatrix}1&-1\\-1&2\end{bmatrix}=\begin{bmatrix}4+1&-4-2\\-\frac{3}{2}-\frac{1}{2}&\frac{3}{2}+1\end{bmatrix}=\begin{bmatrix}5&-6\\-2&\frac{5}{2}\end{bmatrix}\neq(AB)^{-1}$$

顺序错了，答案就错了。

$(A^{\mathsf{T}})^{-1}=(A^{-1})^{\mathsf{T}}$（转置与求逆可以交换）

- **几何直觉**：转置是"把矩阵沿对角线翻过来"（对 A 而言，转置 A^{T} 描述的是一组把 $\mathbf{x}$ 送到 $\mathbf{x}^{\mathsf{T}}A$ 的行向量——第 5 讲会正式讲）。求逆是"倒带"。这两件事互不干扰，所以先后顺序无所谓。
- **证明（用定义，两行）**：由 $AA^{-1}=I$，两边转置，并用 $(XY)^{\mathsf{T}}=Y^{\mathsf{T}}X^{\mathsf{T}}$：

$$(AA^{-1})^{\mathsf{T}}=I^{\mathsf{T}}\implies (A^{-1})^{\mathsf{T}}A^{\mathsf{T}}=I$$

这说明 $(A^{-1})^{\mathsf{T}}$ 是 A^{T} 的逆（左逆即逆），故 $(A^{\mathsf{T}})^{-1}=(A^{-1})^{\mathsf{T}}$。∎ – **具体验证**：对 $A=\begin{bmatrix}1&2\\3&8\end{bmatrix}$，

$$A^{\mathsf{T}}=\begin{bmatrix}1&3\\2&8\end{bmatrix},\qquad (A^{\mathsf{T}})^{-1}=\frac{1}{1\cdot 8-3\cdot 2}\begin{bmatrix}8&-3\\-2&1\end{bmatrix}=\frac{1}{2}\begin{bmatrix}8&-3\\-2&1\end{bmatrix}=\begin{bmatrix}4&-\frac{3}{2}\\-1&\frac{1}{2}\end{bmatrix}$$

而 $(A^{-1})^{\mathsf{T}}=\begin{bmatrix}4&-\frac{3}{2}\\-1&\frac{1}{2}\end{bmatrix}$（把 $A^{-1}=\begin{bmatrix}4&-1\\-\frac{3}{2}&\frac{1}{2}\end{bmatrix}$ 转置）。两者完全相同 ✓

示例 5：三角矩阵的逆（前代/回代就是求逆）

下三角：$T_1=\begin{bmatrix}2&0&0\\4&3&0\\1&2&5\end{bmatrix}$。

```
[T1 | I] =
  [ 2  0  0 | 1  0  0 ]
  [ 4  3  0 | 0  1  0 ]
  [ 1  2  5 | 0  0  1 ]

R1 <- (1/2)*R1:                 (主元归一)
  [ 1  0  0 | 1/2    0    0 ]
  [ 4  3  0 |  0     1    0 ]
  [ 1  2  5 |  0     0    1 ]

R2 <- R2 - 4*R1:                (l21 = 4)
  [ 1  0  0 |  1/2    0    0 ]
  [ 0  3  0 |  -2     1    0 ]
  [ 1  2  5 |   0     0    1 ]

R2 <- (1/3)*R2:
  [ 1  0  0 |  1/2    0    0 ]
  [ 0  1  0 | -2/3   1/3   0 ]
  [ 1  2  5 |   0     0    1 ]

R3 <- R3 - 1*R1:                (l31 = 1)
  [ 1  0  0 |  1/2    0    0 ]
  [ 0  1  0 | -2/3   1/3   0 ]
  [ 0  2  5 | -1/2    0    1 ]

R3 <- R3 - 2*R2:                (l32 = 2)
  [ 1  0  0 |  1/2    0    0 ]
  [ 0  1  0 | -2/3   1/3   0 ]
  [ 0  0  5 |  5/6  -2/3   1 ]

R3 <- (1/5)*R3:
  [ 1  0  0 |  1/2    0    0 ]
  [ 0  1  0 | -2/3   1/3   0 ]
  [ 0  0  1 |  1/6  -2/15  1/5 ]
```

于是

$$T_1^{-1}=\begin{bmatrix}\frac{1}{2}&0&0\\-\frac{2}{3}&\frac{1}{3}&0\\\frac{1}{6}&-\frac{2}{15}&\frac{1}{5}\end{bmatrix}$$

验算：$T_1T_1^{-1}$ 的第 3 行 $=(1,2,5)$ 乘各列： – 第 1 列：$1\cdot\frac{1}{2}+2\cdot(-\frac{2}{3})+5\cdot\frac{1}{6}=\frac{1}{2}-\frac{4}{3}+\frac{5}{6}=\frac{3-8+5}{6}=0$ ✓ – 第 2 列：$1\cdot 0+2\cdot\frac{1}{3}+5\cdot(-\frac{2}{15})=\frac{2}{3}-\frac{2}{3}=0$ ✓ – 第 3 列：$1\cdot 0+2\cdot 0+5\cdot\frac{1}{5}=1$ ✓ 第 1、2 行同理，全部成立。**注意 T_1^{-1} 仍是下三角**——这是"前代不引入更早的坐标"的直接后果。

上三角：$T_2=\begin{bmatrix}1&2&3\\0&1&2\\0&0&1\end{bmatrix}$，主元已经是 1，只需从下往上消：$R_2\leftarrow R_2-2R_3$、$R_1\leftarrow R_1-3R_3$、$R_1\leftarrow R_1-2R_2$，得到

$$T_2^{-1}=\begin{bmatrix}1&-2&1\\0&1&-2\\0&0&1\end{bmatrix}$$

验算：$(1,2,3)\cdot(-2,1,0)^{\mathsf{T}}=-2+2+0=0$，$(1,2,3)\cdot(1,-2,1)^{\mathsf{T}}=1-4+3=0$ ✓

【计算机制解说】：为什么三角矩阵的逆还是三角？ 因为求解 $T\mathbf{x}=\mathbf{b}$（T 下三角）时，**第 1 个方程只含 x_1**，解出后代入第 2 个方程（只含 x_1,x_2）解 x_2……第 k 步只用到 $x_1,\dots,x_k$。于是 x_k 是 $b_1,\dots,b_k$ 的线性组合，**不含任何 $b_{k+1},\dots,b_n$**。把这件事写成矩阵就是 T^{-1} 的第 k 行只有前 k 个非零元——即 T^{-1} 下三角。上三角同理（从 x_n 开始）。**这也是为什么三角矩阵的求逆只要 $O(n^2)$，而一般矩阵要 $O(n^3)$**。

矩阵分解的核心思想

本讲没有引入一个新的"名字响亮"的分解，但它是两个分解的**直接跳板**。

（一）A^{-1} 本身就是一串消元矩阵的乘积。 示例 2 算出

$$B^{-1}=E_{12}E_{23}E_{32}E_{21}$$

这与第 2 讲的 $E=E_{32}E_{31}E_{21}$ 是一枚硬币的两面：E 把 A 化成 U，A^{-1} 把 A 化成 I。把两者合并：

$$A=E^{-1}U=LU,\qquad A^{-1}=U^{-1}L^{-1}$$

即**"A 的 LU 分解"与"A^{-1} 的 $U^{-1}L^{-1}$ 分解"是同一件事的两种读法**。下一讲会看到，L 是单位下三角、U 是上三角，于是 $A^{-1}=U^{-1}L^{-1}$ 就是"上三角 × 下三角"——这种"把一个矩阵拆成三角因子"的思想，正是所有直接法（Cholesky、LDL^{T}、QR）的共同骨架。

（二）"可逆"是分解存在的门槛。 当所有主元非零，$A=LU$ 存在，A^{-1} 存在；当某一步找不到非零主元，U 的对角线上出现 0，$\det A=0$，A 奇异，A^{-1} 不存在。**所以"消元是否走得通"这一条算法事实，同时回答了"可逆吗""$\det$ 是否为零""列是否线性无关""零空间是否只有零向量"这四个看似无关的问题。** 这种"一个算法同时回答一堆等价问题"的结构，是整个 18.06 反复出现的主题。

（三）行列式作为可逆性的数值判据。 2×2 的 $\det=ad-bc$ 是 n 维行列式的最简单实例。第 18 讲将证明：$\det(AB)=\det A\det B$，$\det A^{\mathsf{T}}=\det A$，$\det A^{-1}=1/\det A$——这三条配上本讲的 $(AB)^{-1}=B^{-1}A^{-1}$ 与 $(A^{\mathsf{T}})^{-1}=(A^{-1})^{\mathsf{T}}$，构成一个完美对应的"逆—行列式"字典。

与其他讲次的关联

- **与第 2 讲**：第 2 讲把消元写成 $E_{32}E_{31}E_{21}A=U$；本讲证明了结合律（因此可以打包成单个 E），并用同一套 E 语言求逆。两讲合起来构成 $A=LU$ 的全部材料。
- **与第 4 讲（$A=LU$ 分解）**：本讲示例 2 的 $B^{-1}=E_{12}E_{23}E_{32}E_{21}$ 转置一下就是 $B=E_{21}^{-1}E_{32}^{-1}E_{23}^{-1}E_{12}^{-1}$，第 4 讲将把它整理成 $A=LU$ 与 $PA=LU$ 的规范形式，并说明 L 里的数就是乘数。
- **与第 5 讲（转置、置换、向量空间）**：本讲的 $(A^{\mathsf{T}})^{-1}=(A^{-1})^{\mathsf{T}}$ 与置换矩阵的 $P^{-1}=P^{\mathsf{T}}$ 都会被归入"正交矩阵"一族（$Q^{-1}=Q^{\mathsf{T}}$）。对称矩阵 $S=S^{\mathsf{T}}$ 也在那里正式登场。
- **与第 6–10 讲（子空间）**：可逆 $\iff N(A)=\{\mathbf{0}\}\iff$ A 的列线性无关。这两条等价说法是第 6–10 讲的核心。奇异矩阵的例子 $S=\begin{bmatrix}1&2\\2&4\end{bmatrix}$ 在这里已经给出了 $N(S)$ 的一个具体向量 $\begin{pmatrix}2\\-1\end{pmatrix}$。
- **与第 18–20 讲（行列式）**：2×2 公式里的 $ad-bc$ 会升级为 n 阶行列式；"面积/体积缩放因子"的几何图像会完整化；$A^{-1}=\frac{1}{\det A}\mathbf{adj}(A)$（伴随矩阵公式）是 2×2 公式的 n 维推广。
- **与第 21–25 讲（特征值）**：$A=S\Lambda S^{-1}$ 用的正是本讲的 A^{-1}；而"对角矩阵的逆就是逐项取倒数"（本讲）会直接变成"对角化让求逆变简单"。
- **与第 30–33 讲（线性变换与伪逆）**：A^{-1} 存在 $\iff$ 线性变换是一一对应；奇异时用 A^{+}（伪逆）在"有限制的意义下"倒带——这正是把本讲的门槛（必须一一对应）放宽后的产物。

关键要点

1. **乘法不交换，但结合、分配**：$AB\neq BA$（一般情形），$(AB)C=A(BC)$，$A(B+C)=AB+AC$。**结合律是消元可以打包成 E 的合法依据。**
2. **可逆 = 变换可倒带 = 没有信息丢失**。等价判据：$\det A\neq0$ ｜ 消元全程主元非零 ｜ 列线性无关 ｜ $N(A)=\{\mathbf{0}\}$ ｜ $A\mathbf{x}=\mathbf{b}$ 对每个 $\mathbf{b}$ 恰有一个解。
3. **Gauss–Jordan 算法**：对 $[A\mid I]$ 做行变换直到左边成为 I，右边即 A^{-1}。其合法性是 $E_{12}\cdots E_{21}[A\mid I]=[I\mid E_{12}\cdots E_{21}]$，且 $E_{12}\cdots E_{21}=A^{-1}$。
4. **2×2 公式**：$\begin{bmatrix}a&b\\c&d\end{bmatrix}^{-1}=\frac{1}{ad-bc}\begin{bmatrix}d&-b\\-c&a\end{bmatrix}$。**交换对角线、非对角线取负、除以行列式**（口诀：swap, negate, divide）。
5. **三条逆的法则**：$(AB)^{-1}=B^{-1}A^{-1}$（穿鞋脱鞋，顺序颠倒）；$(A^{\mathsf{T}})^{-1}=(A^{-1})^{\mathsf{T}}$（转置与求逆可交换）；$\det(A^{-1})=1/\det A$。
6. **特殊形状直接读**：对角矩阵逐项取倒数；三角矩阵的逆仍同类型三角（$O(n^2)$ 即可算出）。

常见误区与注意事项

1. **把 $(AB)^{-1}$ 写成 $A^{-1}B^{-1}$**。顺序必须颠倒。用示例 4 的数字检查：$B^{-1}A^{-1}=\begin{bmatrix}\frac{11}{2} & -\frac{3}{2}\\ -7 & 2\end{bmatrix}$ 正确，而 $A^{-1}B^{-1}=\begin{bmatrix}5 & -6\\ -2 & \frac{5}{2}\end{bmatrix}$ 错误。**一个快速的合理性检查**：$(AB)^{-1}$ 必须满足 $(AB)^{-1}(AB)=I$；把错误的顺序代进去马上就不成立。
2. **把 A^{-1} 的公式记成 $\frac{1}{ad-bc}\begin{bmatrix}d & -c\\ -b & a\end{bmatrix}$**（非对角线的负号放错位置）。正确是 $\begin{bmatrix}d & -b\\ -c & a\end{bmatrix}$——**主对角线交换，副对角线两个元素各取负**。用 $A=\begin{bmatrix}1 & 2\\ 3 & 8\end{bmatrix}$ 检查：正确结果 $\begin{bmatrix}4 & -1\\ -\frac{3}{2} & \frac{1}{2}\end{bmatrix}$；写成 $\begin{bmatrix}8 & -3\\ -2 & 1\end{bmatrix}/2$ 就错了。
3. **以为 A^{-1} 一定存在，或者以为"算不出逆"是自己的算术失误**。如果消元过程中某列（含换行后）全为零，A 就是奇异的，逆**根本不存在**——不是算错。$S=\begin{bmatrix}1 & 2\\ 2 & 4\end{bmatrix}$ 就是这样的例子（第 2 列 $=2\times$ 第 1 列）。
4. **忘记做 Jordan 消元的那一步（只化到上三角就停下）**。$[A\mid I]\to[U\mid M]$ 时右边的 M **不是** A^{-1}，而是 E（把 A 化成 U 的那个矩阵）。只有左边真正变成 I，右边才是 A^{-1}。半途而废是这个算法的头号陷阱。
5. **认为对 $[A\mid I]$ 的行变换可以只作用在左半**。绝对不行。必须把加宽矩阵当成一个整体。示例 1 里 $R_2\leftarrow R_2-3R_1$ 在右半产生 $(-3,1)$——正是 A^{-1} 第一列数的来源，漏掉它结果必然错误。
6. **用 $\det=0$ 却仍去写 $\frac{1}{ad-bc}$**。$S=\begin{bmatrix}1 & 2\\ 2 & 4\end{bmatrix}$ 的 $ad-bc=0$，公式的分母为零，此时公式**不适用**（不是"逆是无穷"而是"逆不存在"）。
7. **混淆"转置"与"求逆"**。$\begin{bmatrix}1 & 2\\ 3 & 8\end{bmatrix}^{\mathsf{T}}=\begin{bmatrix}1 & 3\\ 2 & 8\end{bmatrix}$（只翻位置），而 $\begin{bmatrix}1 & 2\\ 3 & 8\end{bmatrix}^{-1}=\begin{bmatrix}4 & -1\\ -\frac{3}{2} & \frac{1}{2}\end{bmatrix}$（要算行列式）。两者数值上毫无关系，只是运算律上"可以交换顺序"而已。

思考题（带答案）

Q1.（纯计算）用 Gauss–Jordan 法求 $A=\begin{bmatrix}1 & 2 & 1\\ 3 & 8 & 1\\ 0 & 4 & 1\end{bmatrix}$ 的逆，并验证 $AA^{-1}=I$。顺便用上一讲的结果（L、U）说明为什么 $\det A=10$。

▸ **答案**

```
[A | I] =
  [ 1  2  1 | 1  0  0 ]
  [ 3  8  1 | 0  1  0 ]
  [ 0  4  1 | 0  0  1 ]

R2 <- R2 - 3*R1:                      (l21 = 3)
  [ 1  2  1 |  1   0   0 ]
  [ 0  2 -2 | -3   1   0 ]
  [ 0  4  1 |  0   0   1 ]

R3 <- R3 - 2*R2:                      (l32 = 4/2 = 2)
  [ 1  2  1 |  1   0   0 ]
  [ 0  2 -2 | -3   1   0 ]
  [ 0  0  5 |  6  -2   1 ]

现在 left 是 U, 主元 1, 2, 5。下面做 Jordan 消元 (+ 归一化)。
R2 <- (1/2)*R2:
  [ 1  2  1 |   1     0     0  ]
  [ 0  1 -1 | -3/2   1/2    0  ]
  [ 0  0  5 |   6    -2     1  ]

R3 <- (1/5)*R3:
  [ 1  2  1 |   1     0     0  ]
  [ 0  1 -1 | -3/2   1/2    0  ]
  [ 0  0  1 |  6/5  -2/5   1/5 ]

R2 <- R2 + 1*R3:                      (清 a23 = -1)
  [ 1  2  1 |   1     0     0  ]
  [ 0  1  0 | -3/10  1/10   1/5 ]
  [ 0  0  1 |  6/5  -2/5   1/5 ]

R1 <- R1 - 1*R3:                      (清 a13 = 1)
  [ 1  2  0 | -1/5   2/5  -1/5 ]
  [ 0  1  0 | -3/10  1/10   1/5 ]
  [ 0  0  1 |  6/5  -2/5   1/5 ]

R1 <- R1 - 2*R2:                      (清 a12 = 2)
  [ 1  0  0 |  2/5   1/5  -3/5 ]
  [ 0  1  0 | -3/10  1/10   1/5 ]
  [ 0  0  1 |  6/5  -2/5   1/5 ]
```

于是

$$A^{-1} = \begin{bmatrix} \frac{2}{5} & \frac{1}{5} & -\frac{3}{5} \\ -\frac{3}{10} & \frac{1}{10} & \frac{1}{5} \\ \frac{6}{5} & -\frac{2}{5} & \frac{1}{5} \end{bmatrix}$$

验证（逐行点乘 A^{-1} 的各列）：

$$AA^{-1} = \begin{bmatrix} 1 & 2 & 1 \\ 3 & 8 & 1 \\ 0 & 4 & 1 \end{bmatrix} \begin{bmatrix} \frac{2}{5} & \frac{1}{5} & -\frac{3}{5} \\ -\frac{3}{10} & \frac{1}{10} & \frac{1}{5} \\ \frac{6}{5} & -\frac{2}{5} & \frac{1}{5} \end{bmatrix} = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} \checkmark$$

逐项核对三个典型项：$-$ $(1,1)$：$1\cdot\frac{2}{5} + 2\cdot\left(-\frac{3}{10}\right) + 1\cdot\frac{6}{5} = \frac{2}{5} - \frac{3}{5} + \frac{6}{5} = \frac{4-3+6}{5} = \frac{7}{5}$？
等等——重算：$\frac{2}{5} - \frac{3}{5} + \frac{6}{5} = \frac{2-3+6}{5} = \frac{5}{5} = 1$ ✓（$2\cdot\left(-\frac{3}{10}\right) = -\frac{3}{5}$） $-$ $(2,1)$：
$3\cdot\frac{2}{5} + 8\cdot\left(-\frac{3}{10}\right) + 1\cdot\frac{6}{5} = \frac{6}{5} - \frac{24}{10} + \frac{6}{5} = \frac{12-24+12}{10} = 0$ ✓ $-$ $(3,3)$：$0 + 4\cdot\frac{1}{5} + 1\cdot\frac{1}{5} = \frac{4}{5} + \frac{1}{5} = 1$ ✓
关于 $\det A = 10$：由上一讲的分解 $A = LU$，

$$L = \begin{bmatrix} 1 & 0 & 0 \\ 3 & 1 & 0 \\ 0 & 2 & 1 \end{bmatrix}, \qquad U = \begin{bmatrix} 1 & 2 & 1 \\ 0 & 2 & -2 \\ 0 & 0 & 5 \end{bmatrix}$$

$\det L = 1$（单位下三角），$\det U = 1 \cdot 2 \cdot 5 = 10$（三角矩阵的行列式 = 对角元之积），故 $\det A = \det L \det U = 10$。**这与 U 的三个主元之积相同**——不是巧合，因为消元矩阵的 $\det$ 恒为 1，消元不改变行列式。

Q2.（概念理解）$S = \begin{bmatrix} 1 & 2 \\ 2 & 4 \end{bmatrix}$ 是奇异矩阵。(a) 找出 $N(S)$ 中一个非零向量，并解释它为什么说明 S 不可逆；(b) 用"压扁"的语言描述 S 对单位方格做了什么，并指出面积变成多少；(c) 判断是否存在矩阵 $B \neq O$ 使得 $SB = O$（O 为零矩阵）。

▸ **答案**

(a) 解 $S\mathbf{x} = \mathbf{0}$：$x_1 + 2x_2 = 0$，$2x_1 + 4x_2 = 0$。第二个方程是第一个的两倍，所以实际上只有一个独立条件 $x_1 = -2x_2$。取 $x_2 = 1$ 得

$$\mathbf{x} = \begin{bmatrix} -2 \\ 1 \end{bmatrix} \in N(S), \qquad S\begin{bmatrix} -2 \\ 1 \end{bmatrix} = \begin{bmatrix} -2+2 \\ -4+4 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix} \checkmark$$

（取 $x_2 = -1$ 得 $\binom{2}{-1}$，也成立；$N(S)$ 是整条直线 $x_1 = -2x_2$。）**为什么这说明不可逆**：假设 S^{-1} 存在，对 $S\binom{-2}{1} = \binom{0}{0}$ 两边左乘 S^{-1}，得 $\binom{-2}{1} = S^{-1}\binom{0}{0} = \binom{0}{0}$，矛盾。**几何上**：$S$ 把非零向量 $\binom{-2}{1}$ 与零向量 $\binom{0}{0}$ 都送到 $\binom{0}{0}$，两个不同输入同一个输出，映射不是一对一，"倒带"不可能。

(b) 单位方格的四个顶点被送到

$$(0,0) \mapsto (0,0), \quad (1,0) \mapsto (1,2), \quad (0,1) \mapsto (2,4), \quad (1,1) \mapsto (3,6)$$

四个点全部落在直线 $y = 2x$ 上：$(1,2)$、$(2,4)$、$(3,6)$ 都满足 $y = 2x$。所以整个单位方格被**压扁成一条线段**。线段面积为 0。**面积**：$\det S = 1 \cdot 4 - 2 \cdot 2 = 0$，故面积缩放因子为 0——这正是"压扁"的定量表达。等价地，两列 $\binom{1}{2}$ 与 $\binom{2}{4}$ 共线（$\binom{2}{4} = 2\binom{1}{2}$），张成的平行四边形退化。

(c) **存在**，而且很容易找。只要让 B 的每一列都落在 $N(S)$ 里即可。取

$$B = \begin{bmatrix} 2 & 2 \\ -1 & -1 \end{bmatrix}$$

（两列都是 $\binom{2}{-1}$ 的倍数，都在 $N(S)$ 中。）验算：

$$SB = \begin{bmatrix} 1 & 2 \\ 2 & 4 \end{bmatrix}\begin{bmatrix} 2 & 2 \\ -1 & -1 \end{bmatrix} = \begin{bmatrix} 2-2 & 2-2 \\ 4-4 & 4-4 \end{bmatrix} = \begin{bmatrix} 0 & 0 \\ 0 & 0 \end{bmatrix} = O \checkmark$$

这个事实本身就是不可逆的另一个证明：如果 S 可逆，由 $SB = O$ 左乘 S^{-1} 得 $B = S^{-1}O = O$，与 $B \neq O$ 矛盾。**反过来**，对任何可逆矩阵 A，$AB = O$ 必然推出 $B = O$（"可逆矩阵左乘不丢失信息"）。

Q3.（运算律）设 $A = \begin{bmatrix} 2 & 1 \\ 1 & 1 \end{bmatrix}$，$B = \begin{bmatrix} 1 & 2 \\ 3 & 8 \end{bmatrix}$。(a) 计算 AB、$(AB)^{-1}$、A^{-1}、B^{-1}，并验证 $(AB)^{-1} = B^{-1}A^{-1}$；(b) 说明为什么 $A^{-1}B^{-1} \neq (AB)^{-1}$，并给出 $A^{-1}B^{-1}$ 的值；(c) 验证 $\det(AB) = \det A \cdot \det B$。

▸ **答案**

(a) 先算乘积：$\det A = 2 \cdot 1 - 1 \cdot 1 = 1$，$\det B = 1 \cdot 8 - 2 \cdot 3 = 2$。

$$AB = \begin{bmatrix} 2\cdot 1 + 1 \cdot 3 & 2 \cdot 2 + 1 \cdot 8 \\ 1 \cdot 1 + 1 \cdot 3 & 1 \cdot 2 + 1 \cdot 8 \end{bmatrix} = \begin{bmatrix} 5 & 12 \\ 4 & 10 \end{bmatrix}, \qquad \det(AB) = 5 \cdot 10 - 12 \cdot 4 = 50 - 48 = 2$$

$$(AB)^{-1} = \frac{1}{2}\begin{bmatrix} 10 & -12 \\ -4 & 5 \end{bmatrix} = \begin{bmatrix} 5 & -6 \\ -2 & \frac{5}{2} \end{bmatrix}$$

$$A^{-1} = \frac{1}{1}\begin{bmatrix} 1 & -1 \\ -1 & 2 \end{bmatrix} = \begin{bmatrix} 1 & -1 \\ -1 & 2 \end{bmatrix}, \qquad B^{-1} = \frac{1}{2}\begin{bmatrix} 8 & -2 \\ -3 & 1 \end{bmatrix} = \begin{bmatrix} 4 & -1 \\ -\frac{3}{2} & \frac{1}{2} \end{bmatrix}$$

$$B^{-1}A^{-1} = \begin{bmatrix} 4 & -1 \\ -\frac{3}{2} & \frac{1}{2} \end{bmatrix}\begin{bmatrix} 1 & -1 \\ -1 & 2 \end{bmatrix} = \begin{bmatrix} 4+1 & -4-2 \\ -\frac{3}{2} - \frac{1}{2} & \frac{3}{2} + 1 \end{bmatrix} = \begin{bmatrix} 5 & -6 \\ -2 & \frac{5}{2} \end{bmatrix} = (AB)^{-1} \checkmark$$

(b) **因为矩阵乘法不交换，而"撤销"必须逆序**。AB 的物理过程是"先作用 B、再作用 A"；要撤销它，必须先撤销**后发生**的那一步（A^{-1}），再撤销先发生的（B^{-1}）——即 $B^{-1}A^{-1}$。写成 $A^{-1}B^{-1}$ 相当于"先脱袜子再脱鞋"，而袜子被鞋压着，脱不下来。具体数值：

$$A^{-1}B^{-1}=\begin{bmatrix}1&-1\\-1&2\end{bmatrix}\begin{bmatrix}4&-1\\-\frac{3}{2}&\frac{1}{2}\end{bmatrix}=\begin{bmatrix}4+\frac{3}{2}&-1-\frac{1}{2}\\-4-3&1+1\end{bmatrix}=\begin{bmatrix}\frac{11}{2}&-\frac{3}{2}\\-7&2\end{bmatrix}$$

> 它与 $(AB)^{-1}=\begin{bmatrix}5&-6\\-2&\frac{5}{2}\end{bmatrix}$ 完全不同。**一个便宜的检验法**：用 $A^{-1}B^{-1}$ 去乘 AB，看是否得 I：

$$A^{-1}B^{-1}AB=A^{-1}(B^{-1}A)B$$

> 而 $B^{-1}A\neq AB^{-1}$（一般情形），所以这个乘积不等于 I。
>
> (c) $\det A=1$（如上），$\det B=2$（如上），乘积 $=1\times 2=2$；而 $\det(AB)=2$（如上）。**相等** ✓ 这条恒等式背后是体积的乘法律：B 把体积放大 $|\det B|$ 倍，A 再放大 $|\det A|$ 倍，两步合起来放大 $|\det A||\det B|$ 倍。符号也相乘（两次翻转等于没翻转）。 **有用的推论**：由 $\det(AB)=\det A\det B$ 得 $\det(A^{-1})=1/\det A$（取 $B=A^{-1}$，则 $\det I=1=\det A\det A^{-1}$）。与本例一致：$\det A^{-1}=1/1=1$，$\det B^{-1}=1/2$。

Lecture 4: Factorization into A = LU

概述

上一讲我们学会了用高斯消元（Gaussian elimination）把矩阵 A 变成上三角矩阵 U。本讲要把这个**过程**本身写成一个**恒等式**：$A=LU$。这是整个 18.06 里第一个真正意义上的**矩阵分解**，也是后面所有分解（$A=QR$、$A=S\Lambda S^{-1}$、$A=U\Sigma V^{\mathsf{T}}$）的模板。

核心问题是：消元做了这么多行变换，能不能把它们"打包"成一次乘法？答案是能，而且打包出来的下三角矩阵 L 有个惊人的性质——**它的非对角元素就是我们一路用掉的消元乘数（multipliers），不需要额外计算**。本讲大部分篇幅就是在讲清楚"为什么不需要额外计算"，以及当必须换行时公式如何变成 $PA=LU$。

位置：讲次 1–5 构成"消元与分解"单元。这一讲把讲次 2 的算法升级为代数结构，为讲次 6–10 的四个基本子空间铺路（U 的行阶梯形直接给出秩与主元列）。

核心概念的几何直觉

消元矩阵（elimination matrix）E_{ij}

- **定义与目的**：$E_{ij}=I-\ell_{ij}\,\mathbf{e}_i\mathbf{e}_j^{\mathsf{T}}$，左乘 A 的作用是"把第 i 行的 ℓ_{ij} 倍从第 j 行中减去"。它是**单位矩阵被改了一个元素**。（这里 $\mathbf{e}_i$ 是第 i 个标准基向量，$\mathbf{e}_i\mathbf{e}_j^{\mathsf{T}}$ 是只在 (i,j) 位置为 1 的矩阵。）
- **几何直觉（它在空间中是什么样子？）**：E_{21} 是一个**剪切变换（shear）**。它把一个正方形沿水平方向"推斜"，体积不变（对角元素全为 1，行列式为 1）。它的逆 $E_{21}^{-1}=I+\ell_{21}\mathbf{e}_2\mathbf{e}_1^{\mathsf{T}}$ 就是反方向的剪切——把减掉的加回来，因此**只有符号翻转**。
- **具体示例**：$\ell_{21}=\frac{1}{2}$ 时

$$E_{21}=\begin{bmatrix}1&0&0\\-\frac{1}{2}&1&0\\0&0&1\end{bmatrix},\qquad E_{21}^{-1}=\begin{bmatrix}1&0&0\\\frac{1}{2}&1&0\\0&0&1\end{bmatrix}.$$

下三角矩阵 L（lower triangular with unit diagonal）

- **定义与目的**：$L=E_{21}^{-1}E_{31}^{-1}E_{32}^{-1}$，是把消元"倒着撤销"的结果。$L$ 的对角线全是 1，非对角元素就是乘数 ℓ_{ij}。
- **几何直觉**：L 是一台"**造回来**"的机器。U 是被消元压扁后的骨架，L 负责把被剪掉的部分一片片贴回去，还原出 A。乘数 ℓ_{ij} 衡量"第 i 行里掺了多少第 j 行的成分"，所以 L 的元素天然记录行与行之间的**依赖份额**。
- **具体示例**：见下方示例二，$L=\begin{bmatrix}1&0&0\\\frac{1}{2}&1&0\\0&\frac{2}{3}&1\end{bmatrix}$。

上三角矩阵 U（row echelon form）

- **定义与目的**：U 是消元的终点，主元（pivots）落在对角线上。
- **几何直觉**：U 是阶梯形，它把方程组变成"从最后一行往上逐层可解"。U 的对角线就是主元序列，U 的零行数 = 自由度个数。
- **具体示例**：$\det A=\det L\cdot\det U=1\cdot(d_1d_2d_3)$，所以主元乘积等于行列式。

为什么 L 的乘法顺序是"逆序"

这是本讲最容易被忽略的一点。消元从左到右执行：

$$E_{32}E_{31}E_{21}A=U.$$

要解出 A，必须**从右往左**依次乘逆矩阵：

$$A = E_{21}^{-1}E_{31}^{-1}E_{32}^{-1}U = LU.$$

注意逆序：最后做的 E_{32} 的逆**最先**出现在 L 里。这不是巧合，而是"撤销一个动作序列要按相反顺序"的必然结果——就像穿衣服要先穿袜子再穿鞋，脱的时候必须先脱鞋。

置换矩阵 P（本讲只是登场，讲次 5 详论）

- **定义与目的**：每行每列恰有一个 1 的方阵。它表示"换行"这一操作，使得即使 $a_{11}=0$ 也能继续消元。
- **几何直觉**：P 是坐标轴的**重排**（可能带镜像），它不拉伸也不旋转——保持长度 $\|Px\| = \|x\|$。所以 P 属于正交矩阵家族。
- **具体示例**：交换 1、3 两行的 $P_{13} = \begin{bmatrix} 0 & 0 & 1 \\ 0 & 1 & 0 \\ 1 & 0 & 0 \end{bmatrix}$，满足 $P_{13}^{\mathrm{T}} = P_{13} = P_{13}^{-1}$。

分解的"尺寸账本"（为什么 $A=LU$ 不浪费信息）

A 有 n^2 个数。L（单位对角）有 $n(n-1)/2$ 个自由数（严格下三角），U 的上三角有 $n(n+1)/2$ 个。合计

$$\frac{n(n-1)}{2} + \frac{n(n+1)}{2} = \frac{n^2-n+n^2+n}{2} = n^2.$$

刚好等于 n^2——这就是 $A=LU$ 能够"无损"存储 A 的算术理由。相比之下，如果把 L 的对角线也当成未知（一般下三角矩阵），参数就变成 $n(n+1)/2 + n(n+1)/2 = n^2+n$，比 A 多出 n 个自由度；**正是"L 对角恒为 1"这条约定消掉了这 n 个多余参数，使分解唯一**。这解释了下面"关键要点"中的唯一性：约束数刚好等于多出的自由度。

"为什么可以假定 L 对角为 1"——消元从不缩放行

高斯消元只用一种操作：**把一行的倍数从另一行减去**（$R_i \leftarrow R_i - \ell R_j$）。这种操作从不乘除某一行本身，所以它保留了两条性质：(a) 每一行的"缩放因子"不变，因此可以约定 L 的对角为 1；(b) 行列式不变，因此 $\det U = \det A$。如果我们允许"把一行乘 3"这种操作，L 的对角就会出现 3，而 $\det$ 也要相应记录缩放因子——这就是为什么教科书的 LU 总是约定 L 单位对角：**它对应"只用最干净的那一类行操作"。** 同理，如果消元过程中必须"行与行交换"，我们就不能把这个操作吸收进三角矩阵（交换会破坏三角结构），只能单独拿出来记成 P——这就是 $A=LU$ 与 $PA=LU$ 的分野。

计算步骤与手算演示

先看全景图：$A=LU$ 的结构长什么样

在动手之前，先用一张 ASCII 图把"分解在做什么"钉在脑子里：

```
                A          =        L        *        U
          (n x n, 稠密)          (单位下三角)       (上三角)

[ x x x x x ]              [ 1 . . . . ]     [ d1 x x x x ]
[ x x x x x ]              [ l 1 . . . ]     [ .  d2 x x x ]
[ x x x x x ]      =       [ l l 1 . . ]  *  [ .  .  d3 x x ]
[ x x x x x ]              [ l l l 1 . ]     [ .  .  .  d4 x ]
[ x x x x x ]              [ l l l l 1 ]     [ .  .  .  .  d5]

 右上角全乱,               "x" 的位置 =        "x" 的位置 =
 要 n^2 个数存储             消元乘数(抄来的)     消元后的剩余元素

关键: L 的对角线恒为 1   ->  存储 L 只要 n(n-1)/2 个数
      U 的上三角          ->  存储 U 只要 n(n+1)/2 个数
      两者合计 = n^2      ->  和 A 一样多, 不浪费也不丢失

消元过程的"一个位置一个位置"填格:
  step 1: 用 d1 消掉第 1 列下方的 l21,l31,l41,...  -> L 第 1 列填好
  step 2: 用 d2 消掉第 2 列下方的 l32,l42,...      -> L 第 2 列填好
  ...
  step n-1: 只剩 d_n 和最后一格                        -> U 完工
```

示例一：2×2 热身（先把乘数抄写规则看一遍）

取 $A = \begin{bmatrix} 2 & 1 \\ 6 & 4 \end{bmatrix}$。

乘数 $\ell_{21} = \dfrac{a_{21}}{a_{11}} = \dfrac{6}{2} = 3$。消元 $R_2 \leftarrow R_2 - 3R_1$：

$$(6,4) - 3(2,1) = (0,1).$$

于是

$$L=\begin{bmatrix}1&0\\3&1\end{bmatrix},\qquad U=\begin{bmatrix}2&1\\0&1\end{bmatrix},\qquad LU=\begin{bmatrix}1\cdot2+0&1\cdot1+0\\3\cdot2+1\cdot0&3\cdot1+1\cdot1\end{bmatrix}=\begin{bmatrix}2&1\\6&4\end{bmatrix}=A.\ \checkmark$$

$\det A=2\cdot1=2$（与 $2\cdot4-1\cdot6=2$ 一致 ✓）。

【计算机制解说】：这个 2×2 例子把"抄乘数"讲得最清楚。A 的第 2 行 $(6,4)$ 可以写成"$3\times$ 第 1 行 $+$ 新的第 2 行"：$3(2,1)+(0,1)=(6,4)$ ✓。这正是 L 的第 2 行 $[3\quad 1]$ 乘 U 的结果。**乘数 3 不是算出来的新东西，它就是 $6/2$**——我们为了消元本来就要算 $6/2$，现在顺手把它写进 L 而已。这就是"L 免计算"的最朴素形态。

示例二：对称三对角矩阵的 $A=LU$（乘数 $\frac{1}{2},\frac{2}{3}$）

取

$$A=\begin{bmatrix}2&1&0\\1&2&1\\0&1&2\end{bmatrix}.$$

这是 1 维 Laplace 算子（弦振动、热传导）的离散版本，是全书最重要的矩阵之一。

步骤 1：写出增广形式，准备消元。

```
初始状态（同时记录乘数）：
[  2   1   0 ]   <- 主元行 1，主元 d1 = 2
[  1   2   1 ]   <- 要消掉 (2,1) 的 1
[  0   1   2 ]
```

步骤 2：消去 $(2,1)$ 位置。 乘数

$$\ell_{21}=\frac{a_{21}}{a_{11}}=\frac{1}{2}.$$

执行 $R_2\leftarrow R_2-\frac{1}{2}R_1$：

```
R2: [ 1  2  1 ] - (1/2)*[ 2  1  0 ]
  = [ 1  2  1 ] - [ 1  0.5  0 ]
  = [ 0  1.5  1 ]

[  2    1    0 ]
[  0    1.5  1 ]
[  0    1    2 ]
```

步骤 3：消去 $(3,2)$ 位置。 此时 $(3,1)$ 已经是 0，跳过。乘数

$$\ell_{32}=\frac{1.5\text{ 下方的 }1}{1.5}=\frac{1}{1.5}=\frac{2}{3}.$$

执行 $R_3\leftarrow R_3-\frac{2}{3}R_2$：

```
R3: [ 0  1  2 ] - (2/3)*[ 0  1.5  1 ]
  = [ 0  1  2 ] - [ 0  1  0.6667 ]
  = [ 0  0  1.3333 ]

U = [  2    1     0   ]
    [  0   1.5    1   ]
    [  0    0   4/3    ]
```

步骤 4：写出 L。 把乘数**直接填入**单位下三角矩阵：

$$L=\begin{bmatrix}1&0&0\\\ell_{21}&1&0\\0&\ell_{32}&1\end{bmatrix}=\begin{bmatrix}1&0&0\\\frac{1}{2}&1&0\\0&\frac{2}{3}&1\end{bmatrix},\qquad U=\begin{bmatrix}2&1&0\\0&\frac{3}{2}&1\\0&0&\frac{4}{3}\end{bmatrix}.$$

步骤 5：验证 $LU=A$。 逐元素算：

- 第 1 行：$1\cdot(2,1,0)=(2,1,0)$ ✓
- 第 2 行：$\frac{1}{2}\cdot(2,1,0)+1\cdot(0,\frac{3}{2},1)=(1,\frac{1}{2},0)+(0,\frac{3}{2},1)=(1,2,1)$ ✓
- 第 3 行：$0\cdot(2,1,0)+\frac{2}{3}\cdot(0,\frac{3}{2},1)+1\cdot(0,0,\frac{4}{3})=(0,1,\frac{2}{3})+(0,0,\frac{4}{3})=(0,1,2)$ ✓

【计算机制解说】：为什么 L 的元素恰好等于乘数、不需要任何计算？关键在于 L 的**每一行都是一个"配方"**。A 的第 i 行可以写成 U 的前 i 行的线性组合，而组合系数正是消元时从上面各行"借"来的倍数。消元时第 2 行被改成 $R_2-\ell_{21}R_1$，等价于原始 $R_2=\ell_{21}R_1+(\text{新}R_2)$。所以**原始行 =**

乘数 × 上层 U 行 + 当前 U 行——这恰好就是 $A = LU$ 的第 i 行展开式。乘数在消元时被"用掉"的位置，正好就是它在 L 中该出现的位置。这就是本讲的**核心洞察**：L 不是被算出来的，是被**抄下来**的。

示例三：为什么 L 比 E 好（"垃圾元素"问题）

用同一组乘数，我们把三个消元矩阵和三个逆矩阵都写出来对照。

$$E_{21} = \begin{bmatrix} 1 & 0 & 0 \\ -\frac{1}{2} & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}, \quad E_{31} = I = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}, \quad E_{32} = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & -\frac{2}{3} & 1 \end{bmatrix}.$$

先按**消元顺序**把它们乘起来（这正是 $U = E_{32}E_{31}E_{21}A$ 左边的样子）：

$$E_{32}E_{21} = \begin{bmatrix} 1 & 0 & 0 \\ -\frac{1}{2} & 1 & 0 \\ \frac{1}{3} & -\frac{2}{3} & 1 \end{bmatrix}.$$

注意 $(3,1)$ 位置冒出来了 $\frac{1}{3}$！这个 $\frac{1}{3} = \ell_{32}\ell_{21} = \frac{2}{3} \cdot \frac{1}{2}$ 是"消元顺序"产生的**副产品**，它既不是 ℓ_{31}（本来是 0），也不是任何有意义的乘数——这就是 Strang 说的 **"垃圾元素"（junk）**。

再按**逆序**乘逆矩阵（这正是 L 的样子）：

$$E_{21}^{-1}E_{32}^{-1} = \begin{bmatrix} 1 & 0 & 0 \\ \frac{1}{2} & 1 & 0 \\ 0 & \frac{2}{3} & 1 \end{bmatrix} = L.$$

干干净净，$\frac{1}{3}$ 消失了。

【计算机制解说】：用标准基写出来就一目了然。记 $E_{21} = I - \ell_{21}\mathbf{e}_2\mathbf{e}_1^{\mathsf{T}}$，$E_{32} = I - \ell_{32}\mathbf{e}_3\mathbf{e}_2^{\mathsf{T}}$。

消元顺序（$E_{32}E_{21}$）：

$$(I - \ell_{32}\mathbf{e}_3\mathbf{e}_2^{\mathsf{T}})(I - \ell_{21}\mathbf{e}_2\mathbf{e}_1^{\mathsf{T}}) = I - \ell_{21}\mathbf{e}_2\mathbf{e}_1^{\mathsf{T}} - \ell_{32}\mathbf{e}_3\mathbf{e}_2^{\mathsf{T}} + \underbrace{\ell_{32}\ell_{21}\,\mathbf{e}_3(\mathbf{e}_2^{\mathsf{T}}\mathbf{e}_2)\mathbf{e}_1^{\mathsf{T}}}_{=\ell_{32}\ell_{21}\mathbf{e}_3\mathbf{e}_1^{\mathsf{T}}\ \text{（垃圾！）}}.$$

因为 $\mathbf{e}_2^{\mathsf{T}}\mathbf{e}_2 = 1$，交叉项**存活**下来，往 $(3,1)$ 塞进了 $\frac{1}{3}$。

逆序（$E_{21}^{-1}E_{32}^{-1}$）：

$$(I + \ell_{21}\mathbf{e}_2\mathbf{e}_1^{\mathsf{T}})(I + \ell_{32}\mathbf{e}_3\mathbf{e}_2^{\mathsf{T}}) = I + \ell_{21}\mathbf{e}_2\mathbf{e}_1^{\mathsf{T}} + \ell_{32}\mathbf{e}_3\mathbf{e}_2^{\mathsf{T}} + \underbrace{\ell_{21}\ell_{32}\,\mathbf{e}_2(\mathbf{e}_1^{\mathsf{T}}\mathbf{e}_3)\mathbf{e}_2^{\mathsf{T}}}_{=0\ \text{（因为 }\mathbf{e}_1^{\mathsf{T}}\mathbf{e}_3=0\text{）}}.$$

交叉项**死掉了**，因为不同下标的基向量正交（$\mathbf{e}_1^{\mathsf{T}}\mathbf{e}_3 = 0$）。于是 L 里只剩纯乘数，位置互不干扰。**一句话：逆序相乘让交叉项自动湮灭，所以 L 是"免计算"的。**

示例四：需要换行时的 $PA = LU$

取

$$A = \begin{bmatrix} 0 & 2 & 1 \\ 2 & 1 & 3 \\ 4 & 1 & 8 \end{bmatrix}.$$

第一个主元 $a_{11} = 0$，消元立刻卡住。必须换行。

步骤 1：选主元并置换。 第 1 列最大的元素在第 3 行（值 4），把第 1 行与第 3 行互换。置换矩阵

$$P = \begin{bmatrix} 0 & 0 & 1 \\ 0 & 1 & 0 \\ 1 & 0 & 0 \end{bmatrix}, \qquad PA = \begin{bmatrix} 4 & 1 & 8 \\ 2 & 1 & 3 \\ 0 & 2 & 1 \end{bmatrix}.$$

（P 的每行每列恰有一个 1。注意 $P^{\mathsf{T}} = P = P^{-1}$，因为交换两次就回来了。）

步骤 2：消去 $(2,1)$。

$$\ell_{21} = \frac{2}{4} = \frac{1}{2}, \qquad R_2 \leftarrow R_2 - \tfrac{1}{2}R_1: \quad (2,1,3) - (2,\tfrac{1}{2},4) = (0,\tfrac{1}{2},-1).$$

$(3,1)$ 本来就是 0，所以 $\ell_{31} = 0$。

```
[  4    1     8  ]
[  0   0.5   -1  ]     <- 新第 2 行
[  0    2     1  ]
```

步骤 3：消去 $(3,2)$。 乘数

$$\ell_{32} = \frac{2}{0.5} = 4, \qquad R_3 \leftarrow R_3 - 4R_2: \quad (0,2,1) - (0,2,-4) = (0,0,5).$$

$$U = \begin{bmatrix} 4 & 1 & 8 \\ 0 & \frac{1}{2} & -1 \\ 0 & 0 & 5 \end{bmatrix}.$$

步骤 4：组装 L 并验证。

$$L = \begin{bmatrix} 1 & 0 & 0 \\ \frac{1}{2} & 1 & 0 \\ 0 & 4 & 1 \end{bmatrix}, \qquad LU = \begin{bmatrix} 4 & 1 & 8 \\ 2 & 1 & 3 \\ 0 & 2 & 1 \end{bmatrix} = PA. \checkmark$$

行分解验证：第 2 行 $\frac{1}{2}(4,1,8) + (0,\frac{1}{2},-1) = (2,\frac{1}{2},4) + (0,\frac{1}{2},-1) = (2,1,3)$ ✓；第 3 行 $0\cdot R_1 + 4(0,\frac{1}{2},-1) + (0,0,5) = (0,2,-4) + (0,0,5) = (0,2,1)$ ✓。

【计算机制解说】：置换矩阵是"**行的搬运工**"。P 左乘 A 就是按 P 中 1 的位置重排 A 的行：P 的第 i 行在第 j 列为 1，则 (PA) 的第 i 行 = A 的第 j 行。所以 $PA = LU$ 的含义是：**先把行摆到正确位置，再做干净的 LU 分解**。为什么要换行？因为 $a_{11} = 0$ 时 $\ell_{21} = a_{21}/a_{11}$ 会除以 0。换行的另一个（更重要的）理由是**数值稳定性**：选绝对值最大的主元可以把乘数压到 $|\ell| \le 1$，误差不被放大。这就是"部分选主元（partial pivoting）"。另外注意 $\det P = -1$，所以 $\det(PA) = -\det A$：上面 A 的行列式是 -10，而 $\det(PA) = \det L \det U = 1\cdot(4\cdot\frac{1}{2}\cdot 5) = 10$，符号正好翻过来。

示例五：把模式推广到 4×4——主元与乘数的规律

示例二的对称三对角矩阵不是偶然。取更大的同型矩阵

$$A_4 = \begin{bmatrix} 2 & 1 & 0 & 0 \\ 1 & 2 & 1 & 0 \\ 0 & 1 & 2 & 1 \\ 0 & 0 & 1 & 2 \end{bmatrix}.$$

按同样的流程消元（每一步只消正下方的一个元素，因为三对角结构不会被破坏）：

```
第 1 步: l21 = 1/2  ->  第2行变成 [0, 3/2, 1, 0]
第 2 步: l32 = 1/(3/2) = 2/3  ->  第3行变成 [0, 0, 4/3, 1]
第 3 步: l43 = 1/(4/3) = 3/4  ->  第4行变成 [0, 0, 0, 5/4]

乘数:  l21 = 1/2,  l32 = 2/3,  l43 = 3/4
主元:  d1 = 2,     d2 = 3/2,   d3 = 4/3,   d4 = 5/4
        (规律: d_k = (k+1)/k,  乘数 l_{k+1,k} = k/(k+1))
```

$$L = \begin{bmatrix} 1 & 0 & 0 & 0 \\ \frac{1}{2} & 1 & 0 & 0 \\ 0 & \frac{2}{3} & 1 & 0 \\ 0 & 0 & \frac{3}{4} & 1 \end{bmatrix}, \qquad U = \begin{bmatrix} 2 & 1 & 0 & 0 \\ 0 & \frac{3}{2} & 1 & 0 \\ 0 & 0 & \frac{4}{3} & 1 \\ 0 & 0 & 0 & \frac{5}{4} \end{bmatrix}.$$

逐元素验证 $LU = A_4$ 的部分：

- 第 1 行：$1\cdot(2,1,0,0) = (2,1,0,0)$ ✓
- 第 2 行：$\frac{1}{2}(2,1,0,0) + (0,\frac{3}{2},1,0) = (1,\frac{1}{2},0,0) + (0,\frac{3}{2},1,0) = (1,2,1,0)$ ✓
- 第 3 行：$\frac{2}{3}(0,\frac{3}{2},1,0) + (0,0,\frac{4}{3},1) = (0,1,\frac{2}{3},0) + (0,0,\frac{4}{3},1) = (0,1,2,1)$ ✓
- 第 4 行：$\frac{3}{4}(0,0,\frac{4}{3},1) + (0,0,0,\frac{5}{4}) = (0,0,1,\frac{3}{4}) + (0,0,0,\frac{5}{4}) = (0,0,1,2)$ ✓

$\det A_4 = d_1 d_2 d_3 d_4 = 2\cdot\frac{3}{2}\cdot\frac{4}{3}\cdot\frac{5}{4} = 5$。由于 A_4 对称，同样有 $U = DL^{\mathsf{T}}$：

$$DL^{\mathsf{T}} = \begin{bmatrix} 2 & 0 & 0 & 0 \\ 0 & \frac{3}{2} & 0 & 0 \\ 0 & 0 & \frac{4}{3} & 0 \\ 0 & 0 & 0 & \frac{5}{4} \end{bmatrix} \begin{bmatrix} 1 & \frac{1}{2} & 0 & 0 \\ 0 & 1 & \frac{2}{3} & 0 \\ 0 & 0 & 1 & \frac{3}{4} \\ 0 & 0 & 0 & 1 \end{bmatrix} = \begin{bmatrix} 2 & 1 & 0 & 0 \\ 0 & \frac{3}{2} & 1 & 0 \\ 0 & 0 & \frac{4}{3} & 1 \\ 0 & 0 & 0 & \frac{5}{4} \end{bmatrix} = U. \checkmark$$

【计算机制解说】：这个例子展示了消元在**稀疏结构上的传播现象**。三对角矩阵消元后**仍然是三对角**（填入（fill-in）只发生在原有带宽内），所以乘数只在次对角线上，L 也是三对角。主元序列 $2, \frac{3}{2}, \frac{4}{3}, \frac{5}{4}, \ldots$ 单调递减趋向 1，**永远为正**——这正是 A（三对角、对角占优）**正定**的数值证据（讲次 25 会证明：全部主元 $d_k > 0 \iff$ 对称正定）。规律 $d_k = \frac{k+1}{k}$ 可以这样推：$d_{k+1} = 2 - \ell_{k+1,k} \cdot 1 = 2 - \frac{1}{d_k}$，代入 $d_1 = 2$ 得 $d_2 = 2 - \frac{1}{2} = \frac{3}{2}$，$d_3 = 2 - \frac{2}{3} = \frac{4}{3}$ ✓——这是一个递推，**每个主元只依赖前一个**，所以计算量是 $O(n)$ 而不是 $O(n^3)$！稀疏矩阵的 LU 之所以是工业核心（结构力学、电路、PDE 求解），根源就在这里。另外注意 $\det A_4 = 5$ 与 $n = 3$ 时的 $\det A_3 = 4$ 相比，序列 $2, 3, 4, 5$（对应 $n = 1, 2, 3, 4$）是 $n + 1$——这是三对角 Toeplitz 行列式的经典结果。

示例六：一次分解、多次回代（分解的实用价值）

对示例二的 A，假设我们要解三个不同的右端项：$\mathbf{b}_1 = (1, 2, 3)$、$\mathbf{b}_2 = (6, 0, 0)$、$\mathbf{b}_3 = (0, 0, 7)$。

步骤 1：前代 $L\mathbf{c} = \mathbf{b}$（forward substitution）。

L 是单位下三角，从第 1 行往下解：

- $\mathbf{b}_1$：$c_1 = 1$；$\frac{1}{2}c_1 + c_2 = 2 \Rightarrow c_2 = 2 - \frac{1}{2} = \frac{3}{2}$；$\frac{2}{3}c_2 + c_3 = 3 \Rightarrow c_3 = 3 - 1 = 2$。得 $\mathbf{c}_1 = (1, \frac{3}{2}, 2)$。
- $\mathbf{b}_2$：$c_1 = 6$；$3 + c_2 = 0 \Rightarrow c_2 = -3$；$\frac{2}{3}(-3) + c_3 = 0 \Rightarrow c_3 = 2$。得 $\mathbf{c}_2 = (6, -3, 2)$。
- $\mathbf{b}_3$：$c_1 = 0$；$0 + c_2 = 0 \Rightarrow c_2 = 0$；$0 + c_3 = 7 \Rightarrow c_3 = 7$。得 $\mathbf{c}_3 = (0, 0, 7)$。

一般公式：$c_i = b_i - \sum_{j<i} \ell_{ij} c_j$。

步骤 2：回代 $U\mathbf{x} = \mathbf{c}$（back substitution）。

从最后一行往上解：

- $\mathbf{c}_1 = (1, \frac{3}{2}, 2)$：$\frac{4}{3}x_3 = 2 \Rightarrow x_3 = \frac{3}{2}$；$\frac{3}{2}x_2 + x_3 = \frac{3}{2} \Rightarrow \frac{3}{2}x_2 = 0 \Rightarrow x_2 = 0$；$2x_1 + x_2 = 1 \Rightarrow x_1 = \frac{1}{2}$。

$$\mathbf{x}_1 = \left(\tfrac{1}{2},\ 0,\ \tfrac{3}{2}\right), \qquad A\mathbf{x}_1 = \left(2 \cdot \tfrac{1}{2} + 0,\ \tfrac{1}{2} + 0 + \tfrac{3}{2},\ 0 + \tfrac{3}{2}\right) = (1, 2, 3) = \mathbf{b}_1. \checkmark$$

- $\mathbf{c}_2 = (6, -3, 2)$：$\frac{4}{3}x_3 = 2 \Rightarrow x_3 = \frac{3}{2}$；$\frac{3}{2}x_2 + \frac{3}{2} = -3 \Rightarrow x_2 = -3$；$2x_1 + x_2 = 6 \Rightarrow x_1 = \frac{9}{2}$。

$$\mathbf{x}_2 = \left(\tfrac{9}{2},\ -3,\ \tfrac{3}{2}\right), \qquad A\mathbf{x}_2 = \left(9 - 3,\ \tfrac{9}{2} - 6 + \tfrac{3}{2},\ -3 + \tfrac{3}{2}\right) = (6, 0, 0) = \mathbf{b}_2. \checkmark$$

- $\mathbf{c}_3 = (0, 0, 7)$：$\frac{4}{3}x_3 = 7 \Rightarrow x_3 = \frac{21}{4}$；$\frac{3}{2}x_2 + \frac{21}{4} = 0 \Rightarrow x_2 = -\frac{7}{2}$；$2x_1 + x_2 = 0 \Rightarrow x_1 = \frac{7}{4}$。

$$\mathbf{x}_3 = \left(\tfrac{7}{4},\ -\tfrac{7}{2},\ \tfrac{21}{4}\right), \qquad A\mathbf{x}_3 = \left(\tfrac{7}{2} - \tfrac{7}{2},\ \tfrac{7}{4} - 7 + \tfrac{21}{4},\ -\tfrac{7}{2} + \tfrac{21}{2}\right) = (0, 0, 7) = \mathbf{b}_3. \checkmark$$

【计算机制解说】：注意 L 与 U 只算了一次，三个 $\mathbf{b}$ 各自只花了两次三角回代。这就是分解的全部卖点。"前代+回代"为什么快？因为三角系统的每一行**只含一个新未知量**，所以每个 x_i 只需一次除法，前面已求出的分量直接代入。复杂度上：消元阶段对 $n \times n$ 矩阵约需

$$\sum_{k=1}^{n-1} (n-k)^2 = \frac{(n-1)n(2n-1)}{6} \approx \frac{n^3}{3} \text{ 次乘法},$$

而每次三角回代约需 $n^2/2$ 次乘法，两次合起来 $\approx n^2$。当 $n = 1000$ 时这是 3.3×10^8 对 10^6 ——**差三百多倍**。工程上（有限元、结构分析、电路仿真）矩阵固定而右端项不断变化，LU 分解是标准做法。反过来说：如果只解一个 $\mathbf{b}$，何必分解？因为分解还给出行列式（$\det A = \prod d_i$）、秩、主元列，这些副产品本身就值这个价。

汇总对比：同一组乘数，E 与 L 的信息含量

```
              消元过程的三条"信息通道"对比（以 A=[[2,1,0],[1,2,1],[0,1,2]] 为例）

通道              具体矩阵                          元素含义              可否直接用?
------------------------------------------------------------------------------
E 顺序连乘   E32*E21 = [ 1    0   0 ]      (3,1) = l32*l21       否
                       [-1/2  1   0 ]        = 1/3 "垃圾"
                       [ 1/3 -2/3 1 ]       (2,1) = -l21
                                            (3,2) = -l32
------------------------------------------------------------------------------
L 逆序连乘   E21^-1 E32^-1 = [ 1    0  0 ]  (2,1) = l21 = 1/2    是（免计算）
                             [ 1/2  1  0 ]  (3,2) = l32 = 2/3
                             [ 0   2/3 1 ]  (3,1) = 0 干净
------------------------------------------------------------------------------
U 单独存放   U = [ 2   1    0 ]           对角 = 主元 d_i       是
                 [ 0  3/2   1 ]           上三角 = 剩余
                 [ 0   0   4/3]            零行数 = 自由度
------------------------------------------------------------------------------

结论：L 是"消元过程的压缩包"—信息量与 E 的连乘积相同，
      但表示形式让乘数保持原样、互不污染。这就是为什么要
      定义 L 而不是直接用 E。
```

注意 $E_{32}E_{21}$ 与 L 的**信息量完全相同**（都是"$A=(\cdot)U$"的合法表示），差别只在**表示形式**：L 用一个位置存一个乘数，E 的连乘积把乘数**混在一起**（$\frac{1}{3}$ 是 $\frac{2}{3}\cdot\frac{1}{2}$ 的产物）。这就像同一个数用分数 $\frac{2}{3}$ 表示还是用小数 $0.666\ldots$ 表示——前者保留了"它是 $2/3$"的结构信息，后者丢了。L 保留了结构，所以它对后续计算（回代、LDL^{T}、Cholesky）都友好。

矩阵分解的核心思想

本讲引入 $A=LU$（必要时 $PA=LU$），这是课程中**第一种也是最基本的分解**。

$$A=LU,\qquad L=\text{单位下三角（乘数）},\quad U=\text{上三角（主元在主对角）}.$$

形式：A 被拆成"结构简单的两块"。L 的对角线全是 1，U 的下三角全是 0，两者一共只有约 n^2 个自由参数（而 A 有 n^2 个），剩下的约束来自"L 单位对角"这一选定。

含义（揭示的结构性质）：

1. **乘数即 L**：L 编码了 A 各行之间的依赖关系，且是消元过程的**无损耗记录**。
2. **$\det A=\det U=\prod_i d_i$**：行列式就是主元之积（$L$ 的行列式为 1）。这给出了行列式的**算法定义**，不用余子式展开。
3. **U 直接读出秩与主元列**：U 的非零行数就是 $\mathbf{rank}(A)$。
4. **唯一性**：若 A 可逆且不需要换行，$A=LU$（L 单位对角）是**唯一**的。证明：设 $L_1U_1=L_2U_2$，则 $L_2^{-1}L_1=U_2U_1^{-1}$，左边是单位下三角、右边是上三角，同时成立的只有 I，故 $L_1=L_2$，$U_1=U_2$。
5. **对称特例 $A=LDL^{\mathsf{T}}$**：若 $A=A^{\mathsf{T}}$ 且不需要换行，则 U 与 L 不是独立的：$U=DL^{\mathsf{T}}$，其中 $D=\mathbf{diag}(d_1,\ldots,d_n)$ 是主元对角阵。于是

$$A=L\,D\,L^{\mathsf{T}}.$$

对本讲的 A，$D=\mathbf{diag}\left(2,\ \frac{3}{2},\ \frac{4}{3}\right)$，且 $\frac{3}{2}=2-\frac{1}{2}\cdot 1$、$\frac{4}{3}=2-\frac{2}{3}\cdot 1$ 正好是"对角元素减去乘数乘上层元素"。这个形式在讲次 25（对称正定矩阵）会成为判据：A 正定 $\iff$ 所有 $d_i>0$。

应用价值：一次 $O(n^3)$ 分解 → 每个新右端项只需 $O(n^2)$；同时免费得到 $\det$、秩、主元、以及对称情形的正定性判据。这是"分解思想"的第一次胜利：**把难题变成若干个简单问题的复合**。

代价的精确账本与盈亏平衡点

把"$n^3/3$ 对 n^2"这句口号算成具体数字：

```
                消元/分解             一次前代+回代          比值
  n       n^3/3 (乘法数)          ~ n^2 (乘法数)       elim/sub
  ------------------------------------------------------------------
   3            9                      9                  1.0
  10          333                    100                  3.3
 100      333,333                 10,000                 33
1000  333,333,333              1,000,000                333

 盈亏平衡: 解 k 个右端项的"分解法"总代价 = n^3/3 + k*n^2
           不用分解、每次重新消元         = k * n^3/3
           令两者相等:
              n^3/3 + k*n^2 = k*n^3/3
           两边除以 n^2:
              n/3 + k = k*n/3
           移项:
              n/3 = k*(n/3 - 1) = k*(n-3)/3
           解得:
              k* = n / (n-3)          <- 只需 2 个右端项左右就划算

 最大加速比 (k -> 无穷):  speedup -> (n^3/3) / n^2 = n/3

 结论: n=1000 时，只要右端项 k >= 2，分解法就已经划算;
       右端项很多时，加速比趋于 n/3 ~= 333 倍。
```

注意上表口径：表中按"$n^3/3$ 与 n^2"的量级估算。若用精确计数，对 $n\times n$ 矩阵，消元阶段实际乘法数（只算 $R_i\leftarrow R_i-\ell R_j$ 的乘，不含除法）是

$$\sum_{k=1}^{n-1}(n-k)^2=\frac{(n-1)n(2n-1)}{6}\approx\frac{n^3}{3},$$

$n=3$ 时得 5（而非 9）；一次三角回代是 $\sum_{k=1}^{n}k=n(n+1)/2\approx n^2/2$，两次就是 n^2。所以"$n^3/3$ 与 n^2"是量级而非精确等式，但量级正是工程上唯一关心的。**盈亏平衡的结论（$k^*=n/(n-3)\approx 2$，加速比上限 $n/3$）用精确常数重算后量级不变。**

【计算机制解说】：为什么消元是 n^3 而回代只有 n^2？因为**它们的嵌套层数不同**。消元是一个双重循环（外层选主元列，内层更新一块 $(n-k)\times(n-k)$ 的子矩阵），循环体里做乘加 → 代价 n^3。回代是**单个**循环（每行只解一个新未知量），代价 n^2。换句话说：分解要把矩阵"看很

多遍"，而回代只"扫一遍"。这也解释了为什么**稀疏矩阵的技术重点是保住 L,U 的稀疏性**：如果消元产生大量 fill-in，n^3 的常数会爆炸。工程上求解大规模 PDE 时，**重排未知量顺序**（等价于选一个置换 P，即 PAP^{T}）来最小化 fill-in，是比选主元更重要的优化。

补充演示：秩亏情形下 LU 会发生什么

取

$$A=\begin{bmatrix}1&2&3\\2&4&6\\1&1&1\end{bmatrix}.$$

步骤 1：先直接消元，看会发生什么。 $\ell_{21}=\frac{2}{1}=2$、$\ell_{31}=\frac{1}{1}=1$：

$$R_2\leftarrow R_2-2R_1:\ (2,4,6)-(2,4,6)=(0,0,0),$$

$$R_3\leftarrow R_3-1R_1:\ (1,1,1)-(1,2,3)=(0,-1,-2).$$

```
[ 1   2   3 ]
[ 0   0   0 ]   <- 第 2 行整行变成 0! 主元位置是 0
[ 0  -1  -2 ]
```

步骤 2：主元为 0，必须换行。 交换第 2、3 行（P 为交换 2、3 的置换矩阵）后重新消元。注意此时要对 PA 消元：

$$P=\begin{bmatrix}1&0&0\\0&0&1\\0&1&0\end{bmatrix},\qquad PA=\begin{bmatrix}1&2&3\\1&1&1\\2&4&6\end{bmatrix}.$$

新的乘数：$\ell_{21}=\frac{1}{1}=1$、$\ell_{31}=\frac{2}{1}=2$。

$$R_2\leftarrow R_2-1R_1:\ (1,1,1)-(1,2,3)=(0,-1,-2),$$

$$R_3\leftarrow R_3-2R_1:\ (2,4,6)-(2,4,6)=(0,0,0).$$

$$U=\begin{bmatrix}1&2&3\\0&-1&-2\\0&0&0\end{bmatrix},\qquad \operatorname{rank}(A)=2,\qquad \det A=1\cdot(-1)\cdot 0=0.$$

步骤 3：写出 L 并验证 $LU=PA$。 $\ell_{32}=\frac{0}{-1}=0$（第 3 行第 2 列已经是 0，无需再消）：

$$L=\begin{bmatrix}1&0&0\\1&1&0\\2&0&1\end{bmatrix}.$$

$$LU=\begin{bmatrix}1&0&0\\1&1&0\\2&0&1\end{bmatrix}\begin{bmatrix}1&2&3\\0&-1&-2\\0&0&0\end{bmatrix}=\begin{bmatrix}1&2&3\\1&1&1\\2&4&6\end{bmatrix}=PA.\ \checkmark$$

U 的最后一行为零 $\Leftrightarrow$ A 奇异（U 只有 2 个非零主元，$n-r=3-2=1$ 个自由度）。

【计算机制解说】：秩亏时 LU 分解依然可以进行，只是 U 会出现**零行**，主元个数少于 n。这给出一个极其实用的判据：**A 可逆 $\iff$ U 的所有主元非零**（没有零行）。注意本例中**换行是必需的**：A 的 $(2,2)$ 在第一次消元后就变成了 0，若不交换第 2、3 行，第 2 列就没有可用的主元。这也说明"A 奇异"与"需要换行"是**两件独立的事**：奇异可能不需要换行（如 $A=\begin{bmatrix}1&1\\1&1\end{bmatrix}$），需要换行也可能矩阵可逆（如示例四）。另外，$L$ 不受影响——它只记录"我们做了哪些行减行"，即使某一行变成零行，L 依然单位下三角，且 $\ell_{32}=0$ 如实记录了"这一步没做事"。

这也说明**$A=LU$ 不需要 A 可逆**：可逆性只影响 U 是否可逆，U 出现零行时 A 就不可逆，但分解式 $PA=LU$ 仍然成立。$\det A=(\det P)\prod_{i=1}^{n}d_i=0$ 自动报出奇异性——这是 LU 免费附赠的"可逆性测试"，比算行列式的余子式展开（$O(n!)$）快得多。最后注意一个细节：**换行会改变乘数**。本例对 A 直接消元得到 $(\ell_{21},\ell_{31})=(2,1)$，而对 PA 消元得到 $(1,2)$——两套乘数不同，L 也不同。所以记录 L 时必须明确"是对哪个矩阵消元得到的"，这正是 $PA=LU$ 中"L 属于 PA"这句话的含义。

与其他讲次的关联

- **讲次 2（消元）**：本讲把那里的逐步行操作升格为矩阵恒等式。消元的三个"合法操作"中，只有"行减去另一行的倍数"进入 E；换行进入 P。
- **讲次 3（矩阵乘法/逆）**：E_{ij}^{-1} 只需符号翻转（因为 $E_{ij}=I-\ell\mathbf{e}_i\mathbf{e}_j^{\mathsf{T}}$ 是幂零扰动，$(I-N)^{-1}=I+N$），本讲大量使用。
- **讲次 5（转置/置换）**：$PA=LU$ 里的 P 是置换矩阵，其性质 $P^{-1}=P^{\mathsf{T}}$ 下一讲证明；LDL^{T} 直接用到转置。
- **讲次 6–10（四个基本子空间）**：U 的主元直接给出 $\operatorname{rank}(A)$、主元列、以及 $N(A)$ 的自由变量结构。没有 LU，就没有求零空间的系统算法。
- **讲次 18–20（行列式）**：$\det A=\prod d_i$ 与 $\det P=\pm1$ 会与"体积"解释汇合；P 的符号就是置换的奇偶性。

- **讲次 25（对称正定）**：$A = LDL^{\mathsf{T}} \to A = R^{\mathsf{T}}R$（Cholesky），是 LU 在对称正定情形的进化版。
- **讲次 16（最小二乘）**：正规方程 $A^{\mathsf{T}}A\mathbf{x} = A^{\mathsf{T}}\mathbf{b}$ 要用 Cholesky/LU 求解，正是"一次分解、多次回代"的工业级应用。

关键要点

1. **消元即分解**：$E_{32}E_{31}E_{21}A = U \implies A = E_{21}^{-1}E_{31}^{-1}E_{32}^{-1}U = LU$。乘逆矩阵必须**倒序**。
2. **L 免计算法则**：L 的对角线全为 1，非对角元素 ℓ_{ij} 就是消元时用掉的乘数 $a_{ij}^{(j)}/d_j$，**直接抄下即可**。原因是 $E_{21}^{-1}E_{32}^{-1}$ 的交叉项因 $\mathbf{e}_1^{\mathsf{T}}\mathbf{e}_3 = 0$ 而湮灭，而 $E_{32}E_{21}$ 的交叉项存活（产生垃圾 $\ell_{32}\ell_{21}$）。**所以永远不要写 $A = E^{-1}U$ 的连乘积形态，要用 L。**
3. **需要换行时**：$A = LU$ 升级为 $PA = LU$，P 是置换矩阵（每行每列恰一个 1），$P^{-1} = P^{\mathsf{T}}$。$\det P = \pm 1$，$\det(PA) = \det L \det U = \prod d_i$。
4. **代价对比**：分解 $\approx n^3/3$ 次乘法；每个右端项的回代 $\approx n^2$ 次。**一次分解、多次回代**是 LU 的存在理由。
5. **对称情形**：$A = A^{\mathsf{T}}$（不需换行）$\Rightarrow A = LDL^{\mathsf{T}}$，$U = DL^{\mathsf{T}}$；且 $\det A = \prod d_i$，正定 $\iff$ 全部 $d_i > 0$。

常见误区与注意事项

1. **把 L 写成 E 的连乘积。** 常见错误：$A = E_{21}^{-1}E_{31}^{-1}E_{32}^{-1}U$ 写成 $A = E_{21}^{-1}E_{32}^{-1}E_{31}^{-1}U$（顺序照抄）。逆矩阵的顺序必须**完全反过来**。另一种错误是把 L 写成 $E_{21}E_{31}E_{32}$（忘了取逆），那样会得到符号相反的乘数并混入垃圾项。
2. **以为换行后还是 $A = LU$。** 一旦用了 P，等式左边是 PA 而不是 A。若坚持写 A，应写成 $A = P^{\mathsf{T}}LU$（因为 $P^{-1} = P^{\mathsf{T}}$）。并且 L 是**对 PA 做消元**得到的 L，不是对 A。
3. **忘记 L 的对角线是 1。** 消元从不改变对角线的"单位"性质（我们只做行减行，不缩放行），所以 $L_{ii} = 1$ 永远成立。若你算出的 L 对角线不是 1，一定是把某个缩放步骤误当成消元了。
4. **乘数顺序错位。** ℓ_{32} 是"消去 $(3,2)$ 时用的倍数"，即（当时的）a_{32}/a_{22}，用的是**更新后**的元素（本例 $\frac{2}{3} = 1/1.5$），不是原矩阵的 $\frac{1}{1} = 1$。这是最常算错的一步。
5. **把 U 和 A 的行阶梯形混淆。** U 必须是消元后的最终上三角；如果中途停下或做了列交换，就不再是 U（列交换会引入右侧置换，需要 $PAQ = LU$，本课程不展开）。
6. **误以为 LU 总能做。** 若某个主元位置为 0 且其下方也全为 0，则 A 奇异，U 会出现零行，L 仍然存在但 U 不可逆——此时仍可写 $PA = LU$，只是 A 不可逆。

思考题（带答案）

Q1.（纯计算） 对 $A = \begin{bmatrix} 1 & 2 & 1 \\ 2 & 5 & 3 \\ 1 & 3 & 4 \end{bmatrix}$ 求 $A = LU$，并验证 $LU = A$、计算 $\det A$。（提示：$\ell_{21} = 2$，$\ell_{31} = 1$。）

<details>
<summary>答案</summary>

步骤 1：消去第 1 列。 $\ell_{21} = \dfrac{a_{21}}{a_{11}} = \dfrac{2}{1} = 2$，$\ell_{31} = \dfrac{a_{31}}{a_{11}} = \dfrac{1}{1} = 1$。

$$R_2 \leftarrow R_2 - 2R_1:\ (2,5,3) - 2(1,2,1) = (0,1,1).$$

$$R_3 \leftarrow R_3 - 1R_1:\ (1,3,4) - (1,2,1) = (0,1,3).$$

$$A^{(1)} = \begin{bmatrix} 1 & 2 & 1 \\ 0 & 1 & 1 \\ 0 & 1 & 3 \end{bmatrix}.$$

步骤 2：消去第 2 列。 $\ell_{32} = \dfrac{a_{32}^{(1)}}{a_{22}^{(1)}} = \dfrac{1}{1} = 1$。

$$R_3 \leftarrow R_3 - 1R_2:\ (0,1,3) - (0,1,1) = (0,0,2).$$

$$U = \begin{bmatrix} 1 & 2 & 1 \\ 0 & 1 & 1 \\ 0 & 0 & 2 \end{bmatrix}, \qquad L = \begin{bmatrix} 1 & 0 & 0 \\ 2 & 1 & 0 \\ 1 & 1 & 1 \end{bmatrix}.$$
</details>

步骤 3：验证 LU。

- 第 1 行：$(1,2,1)$ ✓
- 第 2 行：$2(1,2,1)+(0,1,1)=(2,4,2)+(0,1,1)=(2,5,3)$ ✓
- 第 3 行：$1(1,2,1)+1(0,1,1)+(0,0,2)=(1,3,2)+(0,0,2)=(1,3,4)$ ✓

所以 $LU=A$。$\det A=1\cdot 1\cdot 2=2$（用余子式核对：$1(20-9)-2(8-3)+1(6-5)=11-10+1=2$ ✓）。

注意：A 对称，而 $U=\begin{bmatrix}1&2&1\\0&1&1\\0&0&2\end{bmatrix}$，$DL^{\mathsf T}=\begin{bmatrix}1&0&0\\0&1&0\\0&0&2\end{bmatrix}\begin{bmatrix}1&2&1\\0&1&1\\0&0&1\end{bmatrix}=\begin{bmatrix}1&2&1\\0&1&1\\0&0&2\end{bmatrix}=U$ ✓，与 $LDL^{\mathsf T}$ 理论一致。

Q2.（概念） 消元矩阵满足 $E_{32}E_{21}=\begin{bmatrix}1&0&0\\-\ell_{21}&1&0\\ \ell_{32}\ell_{21}&-\ell_{32}&1\end{bmatrix}$ 而 $E_{21}^{-1}E_{32}^{-1}=\begin{bmatrix}1&0&0\\ \ell_{21}&1&0\\0&\ell_{32}&1\end{bmatrix}$。请解释为什么前者出现乘积项 $\ell_{32}\ell_{21}$ 而后者没有，并说明这与"L 免计算"的关系。

▸ **答案**

关键是 $\mathbf{e}_j^{\mathsf T}\mathbf{e}_k$ 是否为零（即下标是否相同）。

记 $E_{21}=I-\ell_{21}\mathbf{e}_2\mathbf{e}_1^{\mathsf T}$、$E_{32}=I-\ell_{32}\mathbf{e}_3\mathbf{e}_2^{\mathsf T}$。

乘积 $E_{32}E_{21}$ 的交叉项是

$$\ell_{32}\ell_{21}\,\mathbf{e}_3(\mathbf{e}_2^{\mathsf T}\mathbf{e}_2)\mathbf{e}_1^{\mathsf T}=\ell_{32}\ell_{21}\,\mathbf{e}_3\mathbf{e}_1^{\mathsf T},$$

因为 $\mathbf{e}_2^{\mathsf T}\mathbf{e}_2=1$（下标相同，内积为 1）。所以 $(3,1)$ 位置被填上 $\ell_{32}\ell_{21}$ —— 一个**不属于任何乘数的新数**，即"垃圾"。

乘积 $E_{21}^{-1}E_{32}^{-1}$ 的交叉项是

$$\ell_{21}\ell_{32}\,\mathbf{e}_2(\mathbf{e}_1^{\mathsf T}\mathbf{e}_3)\mathbf{e}_2^{\mathsf T}=\ell_{21}\ell_{32}\cdot 0=0,$$

因为 $\mathbf{e}_1^{\mathsf T}\mathbf{e}_3=0$（下标不同，内积为 0）。交叉项湮灭，$(3,1)$ 保持为 0。

与"L 免计算"的关系：L 定义为逆序乘积 $E_{21}^{-1}E_{31}^{-1}\cdots$，正因为逆序让所有交叉项因基向量正交而消失，$L$ 里每个非对角位置**只放一个纯乘数、互不干扰**。因此在算法上我们可以边消元边把 ℓ_{ij} 抄进 L 的对应格子，无需任何后续矩阵乘法。若改用消元顺序 $E_{32}E_{21}$（或它的逆），就必须做 $O(n^3)$ 的矩阵连乘，且结果含垃圾项，既慢又难看。**这就是 L 优于 E 的根本原因。**

Q3.（计算 + 应用） 已知 $A=\begin{bmatrix}2&1&0\\1&2&1\\0&1&2\end{bmatrix}=LU$（示例二），求 A^{-1} 的第一列。

▸ **答案**

A^{-1} 的第 1 列 = 解 $A\mathbf{x}=\mathbf{e}_1=(1,0,0)$ 得到的 $\mathbf{x}$。用现成的 L,U：

前代 $L\mathbf{c}=\mathbf{e}_1$： $c_1=1$；$\frac12 c_1+c_2=0\Rightarrow c_2=-\frac12$；$\frac23 c_2+c_3=0\Rightarrow c_3=-\frac23\cdot(-\frac12)=\frac13$。

$$\mathbf{c}=\left(1,\ -\tfrac12,\ \tfrac13\right).$$

回代 $U\mathbf{x}=\mathbf{c}$： $\frac43 x_3=\frac13\Rightarrow x_3=\frac14$；$\frac32 x_2+x_3=-\frac12\Rightarrow\frac32 x_2=-\frac34\Rightarrow x_2=-\frac12$；$2x_1+x_2=1\Rightarrow 2x_1=\frac32\Rightarrow x_1=\frac34$。

$$A^{-1}\text{ 第 }1\text{ 列}=\begin{bmatrix}\frac34\\-\frac12\\\frac14\end{bmatrix}.$$

> 核对：$A\begin{bmatrix}\frac{3}{4}\\-\frac{1}{2}\\\frac{1}{4}\end{bmatrix}=\begin{bmatrix}2\cdot\frac{3}{4}-\frac{1}{2}\\\frac{3}{4}-1+\frac{1}{4}\\-\frac{1}{2}+\frac{1}{2}\end{bmatrix}=\begin{bmatrix}1\\0\\0\end{bmatrix}$ ✓。
>
> 注意这三个数的分子 $3,-2,1$ 正是 $(-1)^{i+1}$ 型的交替符号，符合三对角矩阵逆的结构。同理可求另两列，得 $A^{-1}=\frac{1}{4}\begin{bmatrix}3&-2&1\\-2&4&-2\\1&-2&3\end{bmatrix}$（请自行用 L,U 对 $\mathbf{e}_2,\mathbf{e}_3$ 回代验证；也可验证此矩阵确实对称且 $AA^{-1}=I$）。

Lecture 5: Transposes, Permutations, Spaces R^n

概述

本讲是课程的**转折点**：从"矩阵的计算"转向"向量的空间"。前四讲我们一直在做消元、求逆，处理的都是 $\mathbb{R}^n$ 内部的运算；本讲第一次正式引入**子空间（subspace）**这个概念，它是讲次 6–10 的统一语言，也是整个 18.06 后半程的骨架。

本讲由三块组成，表面松散、实则一体：(1) **转置 A^{T} 与对称矩阵 $S=S^{\mathsf{T}}$**——$A^{\mathsf{T}}A$ 永远对称，这也是最小二乘的关键；(2) **置换矩阵 P**——$P^{-1}=P^{\mathsf{T}}$，是正交矩阵家族的第一个成员，把 $PA=LU$ 补齐；(3) **$\mathbb{R}^n$ 的子空间**——定义、判定、以及 $\mathbb{R}^2/\mathbb{R}^3$ 的完整分类。

一句话主线：**转置是"对偶"操作，置换是"正交"操作，子空间是"所有线性组合的容器"。**

核心概念的几何直觉

转置（transpose）A^{T}

- **定义与目的**：A 是 $m\times n$，则 A^{T} 是 $n\times m$，且 $(A^{\mathsf{T}})_{ij}=A_{ji}$——**行列互换**。转置的目的：把"作用于 $\mathbb{R}^n$ 的映射"翻成"作用于 $\mathbb{R}^m$ 的映射"，使它与内积配对。
- **几何直觉（它在空间中是什么样子？）**：转置是线性映射的**对偶/伴随（adjoint）**。它的本质刻画是内积恒等式

$$\langle A\mathbf{x},\,\mathbf{y}\rangle=\langle\mathbf{x},\,A^{\mathsf{T}}\mathbf{y}\rangle\qquad\text{对所有 }\mathbf{x}\in\mathbb{R}^n,\ \mathbf{y}\in\mathbb{R}^m.$$

也就是说：**把 A 从内积的左边搬到右边，就变成 A^{T}。** 如果用矩阵语言写，这就是 $(A\mathbf{x})^{\mathsf{T}}\mathbf{y}=\mathbf{x}^{\mathsf{T}}(A^{\mathsf{T}}\mathbf{y})$。这个视角在讲次 10（$N(A^{\mathsf{T}})$ 垂直于 $C(A)$）和讲次 16（正规方程）里是决定性的。 – **具体示例**：见下方示例一。

对称矩阵（symmetric matrix）$S=S^{\mathsf{T}}$

- **定义与目的**：方阵且 $S_{ij}=S_{ji}$。转置下不变。
- **几何直觉**：对称矩阵是**自伴**的，它没有"扭曲"（旋转）。它可以把空间沿着一组互相**正交**的方向纯拉伸。因此它的特征值必为**实数**，特征向量必可选为**互相垂直**——这是谱定理（讲次 25），本讲只预告。几何上你可能遇到的对称矩阵：协方差矩阵、图 Laplacian、惯性张量、$A^{\mathsf{T}}A$。
- **具体示例**：$A^{\mathsf{T}}A$ 永远对称（下方演示二）。

对称矩阵的几何图景：为什么"没有旋转"

对称矩阵最值得记住的几何事实是下面这条**预言**（讲次 25 会证明）：

> $S=S^{\mathsf{T}}$ 的特征值全是**实数**；特征向量可以选成**两两正交**。

用一个 2×2 例子先直观感受。取 $S=\begin{bmatrix}2&1\\1&2\end{bmatrix}$：

- $\operatorname{tr}S=4$，$\det S=2\cdot2-1\cdot1=3$。特征值满足 $\lambda^2-4\lambda+3=0$，即 $\lambda=3,1$——**都是实数**。
- $\lambda=3$ 的特征向量：$(S-3I)\mathbf{v}=\begin{bmatrix}-1&1\\1&-1\end{bmatrix}\mathbf{v}=\mathbf{0}\Rightarrow\mathbf{v}_1=(1,1)^{\mathsf{T}}$。
- $\lambda=1$ 的特征向量：$(S-I)\mathbf{v}=\begin{bmatrix}1&1\\1&1\end{bmatrix}\mathbf{v}=\mathbf{0}\Rightarrow\mathbf{v}_2=(1,-1)^{\mathsf{T}}$。
- $\mathbf{v}_1\cdot\mathbf{v}_2=1\cdot1+1\cdot(-1)=0$ ✓ **正交**。

对比一个**不对称**的旋转矩阵 $R=\begin{bmatrix}0&-1\\1&0\end{bmatrix}$（逆时针 90°）：

- $\operatorname{tr}R=0$，$\det R=1$，判别式 $\operatorname{tr}^2-4\det=0-4=-4<0$，所以特征值是 $\lambda=\pm i$——**复特征值**！几何上完全合理：90° 旋转**没有任何实方向保持不变**（每个向量都被转走了），所以没有实特征向量。

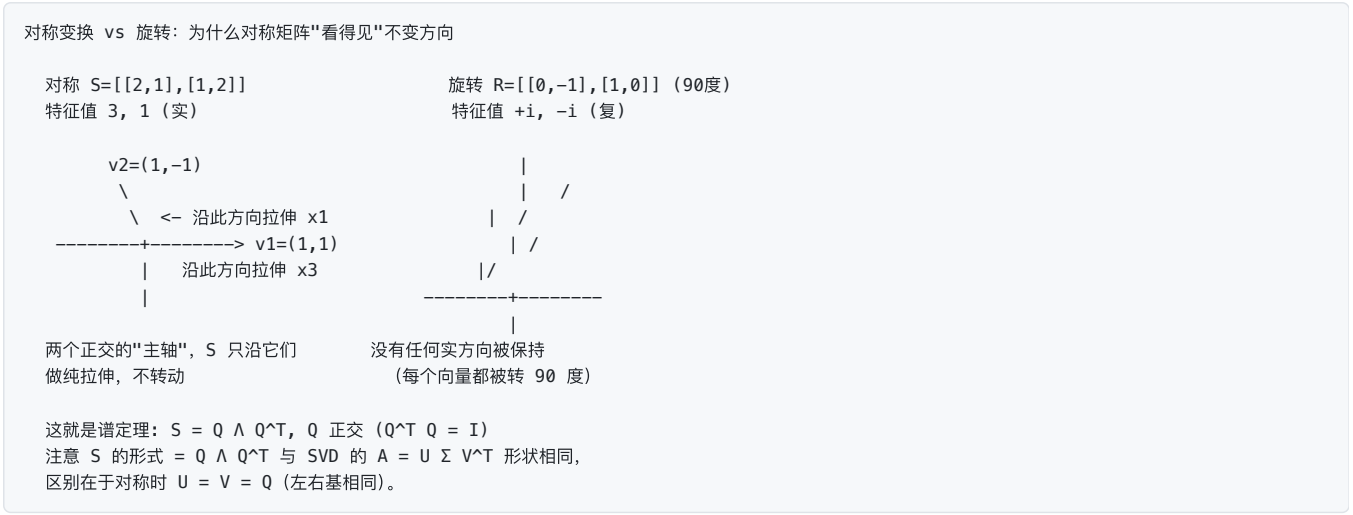

这个图景的重要推论：因为对称矩阵只做"沿正交轴的纯拉伸"，所以它的"大小"完全由特征值决定：$\lambda_{\max}$ 是最大拉伸比，$\lambda_{\min}$ 是最小拉伸比（可为负，表示反向）。这就是为什么**二次型 $\mathbf{x}^{\mathsf{T}}S\mathbf{x}$ 的符号**完全由特征值的符号决定——讲次 25 的"正定"判据就建立在此。

置换矩阵（permutation matrix）P

- **定义与目的**：每行每列**恰有一个 1**，其余全 0 的方阵。$n \times n$ 的置换矩阵共有 $n!$ 个。
- **几何直觉**：P 是**坐标轴的重排/反射**——它不拉伸、不扭曲，只是把坐标轴换个位置（可能是左手变右手的镜像）。因此它保持长度：$\|P\mathbf{x}\| = \|\mathbf{x}\|$，这正是**正交矩阵**的特征（$P^{\mathsf{T}}P = I$）。它是正交矩阵里最"离散"的一类：元素只有 0 和 1。
- **具体示例**：$n = 3$ 共 6 个，见手算演示三。

子空间（subspace）

- **定义与目的**：$\mathbb{R}^n$ 的子集 S，满足 (a) 若 $\mathbf{v}, \mathbf{w} \in S$ 则 $\mathbf{v} + \mathbf{w} \in S$；(b) 若 $\mathbf{v} \in S$、$c \in \mathbb{R}$ 则 $c\mathbf{v} \in S$。(a)(b) 等价于一条更简洁的条件：**对任意线性组合封闭**，即 $c\mathbf{v} + d\mathbf{w} \in S$。由 (b) 取 $c = 0$ 立刻得到 $\mathbf{0} \in S$——**子空间必含原点**。
- **几何直觉**：子空间是"**穿过原点的平坦的一片**"。$\mathbb{R}^2$ 里只有三种、$\mathbb{R}^3$ 里只有四种。判断一个集合是不是子空间，只需问三件事：**过原点吗？两个向量加起来还在里面吗？乘个常数还在里面吗？**
- **具体示例**：$\mathbb{R}^2$ 的完整分类与反例见下方 ASCII 图与演示四。

计算步骤与手算演示

示例一：转置三条性质的逐条验算

取

$$A = \begin{bmatrix} 1 & 2 \\ 3 & 4 \\ 5 & 6 \end{bmatrix} (3 \times 2), \qquad B = \begin{bmatrix} 1 & 0 \\ 2 & 1 \\ 0 & 3 \end{bmatrix} (3 \times 2).$$

性质 1：$(A^{\mathsf{T}})^{\mathsf{T}} = A$。

$$A^{\mathsf{T}} = \begin{bmatrix} 1 & 3 & 5 \\ 2 & 4 & 6 \end{bmatrix} (2 \times 3), \qquad (A^{\mathsf{T}})^{\mathsf{T}} = \begin{bmatrix} 1 & 2 \\ 3 & 4 \\ 5 & 6 \end{bmatrix} = A. \ \checkmark$$

性质 2：$(A+B)^{\mathsf{T}} = A^{\mathsf{T}} + B^{\mathsf{T}}$。

$$A + B = \begin{bmatrix} 2 & 2 \\ 5 & 5 \\ 5 & 9 \end{bmatrix} \Rightarrow (A+B)^{\mathsf{T}} = \begin{bmatrix} 2 & 5 & 5 \\ 2 & 5 & 9 \end{bmatrix},$$

$$A^{\mathsf{T}} + B^{\mathsf{T}} = \begin{bmatrix} 1 & 3 & 5 \\ 2 & 4 & 6 \end{bmatrix} + \begin{bmatrix} 1 & 2 & 0 \\ 0 & 1 & 3 \end{bmatrix} = \begin{bmatrix} 2 & 5 & 5 \\ 2 & 5 & 9 \end{bmatrix}. \ \checkmark$$

性质 3：$(AB)^{\mathsf{T}} = B^{\mathsf{T}}A^{\mathsf{T}}$（注意顺序反转！） 取

$$C = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{bmatrix} (2 \times 3), \qquad D = \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 1 \end{bmatrix} (3 \times 2).$$

$$CD = \begin{bmatrix} 1\cdot1+2\cdot0+3\cdot1 & 1\cdot0+2\cdot1+3\cdot1 \\ 4\cdot1+5\cdot0+6\cdot1 & 4\cdot0+5\cdot1+6\cdot1 \end{bmatrix} = \begin{bmatrix} 4 & 5 \\ 10 & 11 \end{bmatrix} (2 \times 2).$$

$$(CD)^{\mathsf{T}} = \begin{bmatrix} 4 & 10 \\ 5 & 11 \end{bmatrix}.$$

另一方面

$$D^{\mathsf{T}}C^{\mathsf{T}} = \begin{bmatrix} 1 & 0 & 1 \\ 0 & 1 & 1 \end{bmatrix} \begin{bmatrix} 1 & 4 \\ 2 & 5 \\ 3 & 6 \end{bmatrix} = \begin{bmatrix} 1+0+3 & 4+0+6 \\ 0+2+3 & 0+5+6 \end{bmatrix} = \begin{bmatrix} 4 & 10 \\ 5 & 11 \end{bmatrix}. \checkmark$$

【计算机制解说】：三条性质全部来自"下标互换"这一个动作。以性质 3 为例：设 A 是 $m \times n$、B 是 $n \times p$，则 AB 是 $m \times p$，$(AB)^{\mathsf{T}}$ 是 $p \times m$。逐元素：

$$((AB)^{\mathsf{T}})_{ij} = (AB)_{ji} = \sum_{k=1}^{n} A_{jk}B_{ki} = \sum_{k=1}^{n} B_{ki}A_{jk} = \sum_{k=1}^{n} (B^{\mathsf{T}})_{ik}(A^{\mathsf{T}})_{kj} = (B^{\mathsf{T}}A^{\mathsf{T}})_{ij}.$$

顺序为什么必须反转：维度已经强制了答案。$B^{\mathsf{T}}A^{\mathsf{T}}$ 是 $(p \times n)(n \times m) = p \times m$，恰好匹配 $(AB)^{\mathsf{T}}$；而 $A^{\mathsf{T}}B^{\mathsf{T}}$ 是 $(n \times m)(p \times n)$，**连乘法都做不了**（除非 $m = p$，那时形状也不对）。所以"转置要反序"不是记忆规则，而是维度的必然。几何上：$(AB)^{\mathsf{T}}$ 表示"先 B 后 A 再取伴随" = "先取 A 的伴随、再取 B 的伴随"，伴随操作把顺序颠倒，就像穿脱衣服。

性质 4（几何核心）：$\langle A\mathbf{x}, \mathbf{y} \rangle = \langle \mathbf{x}, A^{\mathsf{T}}\mathbf{y} \rangle$ 的数值验证

这条恒等式是转置的"定义性刻画"。取

$$A = \begin{bmatrix} 1 & 2 & 0 \\ 3 & 1 & 1 \\ 0 & 2 & 4 \end{bmatrix}, \qquad \mathbf{x} = \begin{bmatrix} 1 \\ 2 \\ -1 \end{bmatrix} \in \mathbb{R}^3, \qquad \mathbf{y} = \begin{bmatrix} 2 \\ 1 \\ 3 \end{bmatrix} \in \mathbb{R}^3.$$

先算左边。 $A\mathbf{x}$：

$$A\mathbf{x} = \begin{bmatrix} 1\cdot 1 + 2\cdot 2 + 0\cdot(-1) \\ 3\cdot 1 + 1\cdot 2 + 1\cdot(-1) \\ 0\cdot 1 + 2\cdot 2 + 4\cdot(-1) \end{bmatrix} = \begin{bmatrix} 5 \\ 4 \\ 0 \end{bmatrix}.$$

$$\langle A\mathbf{x},\ \mathbf{y} \rangle = 5\cdot 2 + 4\cdot 1 + 0\cdot 3 = 10 + 4 + 0 = 14.$$

再算右边。 $A^{\mathsf{T}} = \begin{bmatrix} 1 & 3 & 0 \\ 2 & 1 & 2 \\ 0 & 1 & 4 \end{bmatrix}$，则

$$A^{\mathsf{T}}\mathbf{y} = \begin{bmatrix} 1\cdot 2 + 3\cdot 1 + 0\cdot 3 \\ 2\cdot 2 + 1\cdot 1 + 2\cdot 3 \\ 0\cdot 2 + 1\cdot 1 + 4\cdot 3 \end{bmatrix} = \begin{bmatrix} 5 \\ 11 \\ 13 \end{bmatrix}.$$

$$\langle \mathbf{x},\ A^{\mathsf{T}}\mathbf{y} \rangle = 1\cdot 5 + 2\cdot 11 + (-1)\cdot 13 = 5 + 22 - 13 = 14. \checkmark$$

两个数都是 14。

【计算机制解说】：为什么必然相等？从"求和指标可以换顺序"就能看出。左边

$$\langle A\mathbf{x}, \mathbf{y} \rangle = \sum_{i=1}^{m} (A\mathbf{x})_i y_i = \sum_{i=1}^{m} \left(\sum_{j=1}^{n} A_{ij}x_j \right) y_i = \sum_{i=1}^{m}\sum_{j=1}^{n} A_{ij}x_j y_i.$$

右边

$$\langle \mathbf{x}, A^{\mathsf{T}}\mathbf{y} \rangle = \sum_{j=1}^{n} x_j (A^{\mathsf{T}}\mathbf{y})_j = \sum_{j=1}^{n} x_j \left(\sum_{i=1}^{m} (A^{\mathsf{T}})_{ji} y_i \right) = \sum_{j=1}^{n}\sum_{i=1}^{m} A_{ij}x_j y_i.$$

两个双重和式逐项相同，只是求和次序不同（有限和可以任意交换次序），所以恒等。这也解释了转置为什么是"指标的交换"：A 作用在 $\mathbf{x}$ 上时指标 i 在外、j 在内；要让 $\mathbf{y}$ 接住 A，就必须把指标 i, j 的角色对调，而对调指标的方式正是转置。

这条恒等式的用处：它让你可以在内积中"移动"矩阵。例如证明 $N(A)$ 与 $C(A^{\mathsf{T}})$ 正交时：若 $A\mathbf{x} = \mathbf{0}$，则对任意 $\mathbf{z}$ 有

$$\langle \mathbf{x},\ A^{\mathsf{T}}\mathbf{z} \rangle = \langle A\mathbf{x},\ \mathbf{z} \rangle = \langle \mathbf{0}, \mathbf{z} \rangle = 0,$$

即 $\mathbf{x}$ 与 $C(A^{\mathsf{T}})$ 中每个向量都正交——**一行推导就得到"零空间 $\perp$ 行空间"**。这正是讲次 10 四条正交关系的证明模板。类似的，最小二乘的正规方程 $A^{\mathsf{T}}A\hat{\mathbf{x}} = A^{\mathsf{T}}\mathbf{b}$ 也是这条恒等式在"残差垂直于列空间"条件下的产物。

示例二：$A^{\mathsf{T}}A$ 必对称（两种证明 + 数值）

取

$$M=\begin{bmatrix}1&2&3\\0&1&4\end{bmatrix}\ (2\times 3),\qquad M^{\mathsf T}=\begin{bmatrix}1&0\\2&1\\3&4\end{bmatrix}\ (3\times 2).$$

$$M^{\mathsf T}M=\begin{bmatrix}1&0\\2&1\\3&4\end{bmatrix}\begin{bmatrix}1&2&3\\0&1&4\end{bmatrix}=\begin{bmatrix}1&2&3\\2&5&10\\3&10&25\end{bmatrix}\ (3\times 3),\qquad MM^{\mathsf T}=\begin{bmatrix}14&14\\14&17\end{bmatrix}\ (2\times 2).$$

两个都是对称的（$M^{\mathsf T}M$ 关于主对角线镜像相等：$2=2,\ 3=3,\ 10=10$；$MM^{\mathsf T}$ 的 $14=14$）。

证明 A（维度/代数法）：由性质 $(XY)^{\mathsf T}=Y^{\mathsf T}X^{\mathsf T}$ 与 $(A^{\mathsf T})^{\mathsf T}=A$，

$$(A^{\mathsf T}A)^{\mathsf T}=A^{\mathsf T}(A^{\mathsf T})^{\mathsf T}=A^{\mathsf T}A.$$

一个矩阵等于自己的转置就是对称。证毕。（注意这个论证同样适用于 $AA^{\mathsf T}$、$A^{\mathsf T}A$ 的任意多项式。）

证明 B（元素法，更有信息量）：设 A 是 $m\times n$，$A^{\mathsf T}A$ 是 $n\times n$。把 A 的列记为 $\mathbf{a}_1,\dots,\mathbf{a}_n\in\mathbb{R}^m$。则

$$(A^{\mathsf T}A)_{ij}=(A^{\mathsf T}\text{ 的第 }i\text{ 行})\cdot(A\text{ 的第 }j\text{ 列})=\mathbf{a}_i\cdot\mathbf{a}_j.$$

交换 i,j 得 $(A^{\mathsf T}A)_{ji}=\mathbf{a}_j\cdot\mathbf{a}_i=\mathbf{a}_i\cdot\mathbf{a}_j$（内积对称），故相等。证毕。

【计算机制解说】：证明 B 揭示了 $A^{\mathsf T}A$ 的**真正含义**：它是一个"**列与列之间夹角/相似度的记账表**"。对角元 $\mathbf{a}_i\cdot\mathbf{a}_i=\|\mathbf{a}_i\|^2$ 是每列的长度的平方，非对角元 $\mathbf{a}_i\cdot\mathbf{a}_j$ 是两列的内积。这就是为什么 $A^{\mathsf T}A$ 出现在最小二乘的正规方程里——它在度量"残差与各列是否垂直"。也解释了 Gram 矩阵（Gram matrix）的名字。另外：$A^{\mathsf T}A$ 的对角元全为正（除非该列为零向量）。如果 A 的列线性无关，则 $A^{\mathsf T}A$ 还可进一步保证**正定**（讲次 25），从而 $A^{\mathsf T}A$ 可逆、最小二乘解唯一。这是"$A^{\mathsf T}A$ 对称"这条简单事实的深远后果。

示例三：$n=3$ 的全部 6 个置换矩阵与 $P^{\mathsf T}P=I$

```
6 个 3x3 置换矩阵（每个的每一行、每一列恰有一个 1）

P1 = [1 0 0]   P2 = [1 0 0]   P3 = [0 1 0]
     [0 1 0]        [0 0 1]        [1 0 0]
     [0 0 1]        [0 1 0]        [0 0 1]
     恒等           交换 2,3       交换 1,2

P4 = [0 1 0]   P5 = [0 0 1]   P6 = [0 0 1]
     [0 0 1]        [1 0 0]        [0 1 0]
     [1 0 0]        [0 1 0]        [1 0 0]
     循环 1->2->3   循环 1->3->2   交换 1,3
     （反序）                      (=P4^2)

            3! = 6 个，与排列数一致
```

验证 $P^{\mathsf T}P=I$（以 P_6 为例，即交换第 1、3 行/列者）：

$$P_6=\begin{bmatrix}0&0&1\\0&1&0\\1&0&0\end{bmatrix},\qquad P_6^{\mathsf T}=P_6,\qquad P_6P_6=\begin{bmatrix}1&0&0\\0&1&0\\0&0&1\end{bmatrix}=I.$$

所以 $P_6^{\mathsf T}=P_6^{-1}$。一般地，P 的每一列都是标准基向量 $\mathbf{e}_{\sigma(i)}$，两两**正交且长度为 1**，因此 $P^{\mathsf T}P=I$ 逐元素成立：$(P^{\mathsf T}P)_{ij}=(\mathbf{P}\text{ 的第 }i\text{ 列})\cdot(\mathbf{P}\text{ 的第 }j\text{ 列})=\delta_{ij}$。

P 的乘法作用（取 $X=\begin{bmatrix}1&2\\3&4\\5&6\end{bmatrix}$，用 $P_{13}=\begin{bmatrix}0&0&1\\0&1&0\\1&0&0\end{bmatrix}$）：

$$P_{13}X=\begin{bmatrix}0&0&1\\0&1&0\\1&0&0\end{bmatrix}\begin{bmatrix}1&2\\3&4\\5&6\end{bmatrix}=\begin{bmatrix}5&6\\3&4\\1&2\end{bmatrix}.$$

三行被上下翻转了。

【计算机制解说】：记住"**左乘换行、右乘换列**"。PA 是**重排 A 的行**（P 的第 i 行在第 j 列为 1，就把 A 的第 j 行搬到第 i 行）；AP 是**重排 A 的列**。为什么？P 的每一行是某个 $\mathbf{e}_j^{\mathsf T}$，而 $\mathbf{e}_j^{\mathsf T}A$ 恰好"挑出 A 的第 j 行"，所以 P 的每一行就是从 A 里挑一行放到对应位置——**置换矩阵是把"选择"写成矩阵**。这在讲次 4 的 $PA=LU$ 里就是"把最大的主元挑到对角线上"。此外 $\det P=\pm 1$：偶置换（需要偶数次交换）为 $+1$，奇置换为 -1。P_6（交换 1、3）需要 1 次交换，所以 $\det P_6=-1$；$P_1=I$ 需要 0 次，$\det P_1=+1$。这会在讲次 18–20 与"体积的定向"接上。

示例四：子空间的判定——过原点的直线 vs 不过原点的直线

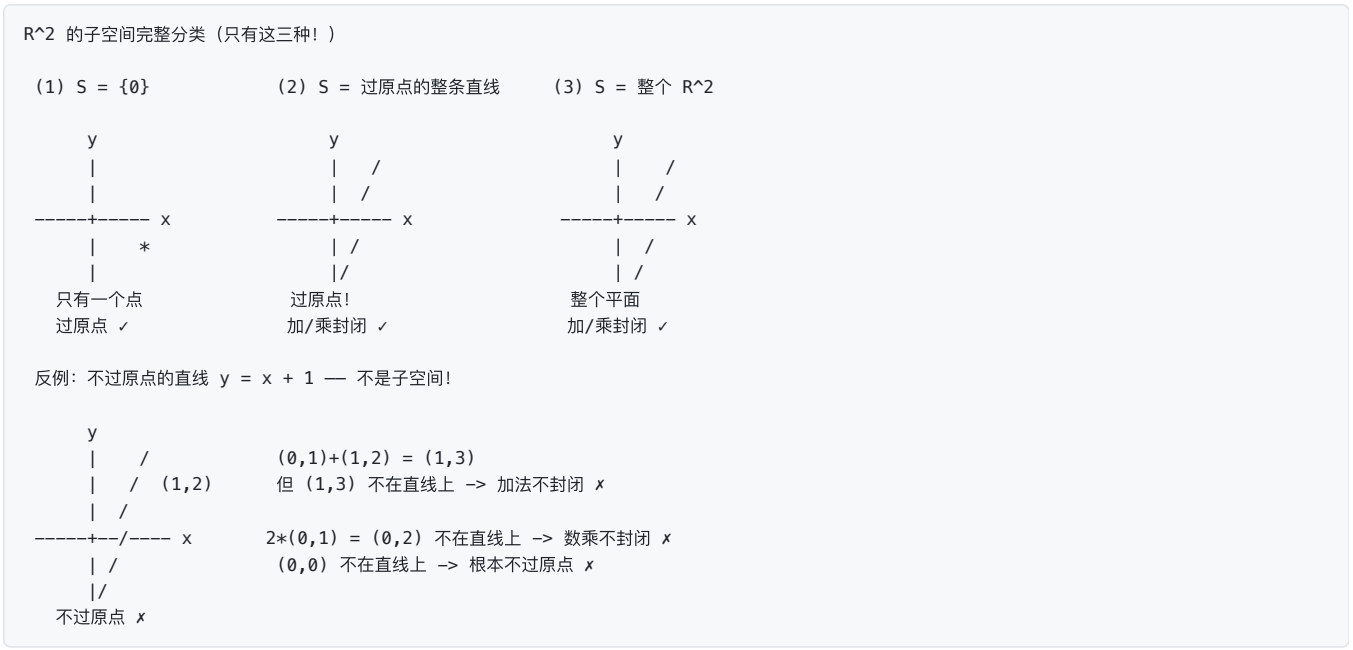

取 $S = \{c(1,1)^{\mathsf{T}} : c \in \mathbb{R}\}$（直线 $y = x$）。检验三条：

1. **含原点**：$c = 0$ 给出 $(0,0)$ ✓
2. **加法**：$c_1(1,1) + c_2(1,1) = (c_1 + c_2)(1,1) \in S$ ✓
3. **数乘**：$k \cdot c(1,1) = (kc)(1,1) \in S$ ✓

故 S 是子空间。现在取 $T = \{(x, x+1)^{\mathsf{T}}\}$（直线 $y = x + 1$）：

1. **含原点吗？** $(0,0)$ 要求 $0 = 0 + 1$，假。**已经可以判定不是子空间。** ✗
2. **加法**：$(0,1), (1,2)$ 都在 T 中，但 $(0,1) + (1,2) = (1,3)$，而 $3 \neq 1 + 1 = 2$，不在 T 中 ✗
3. **数乘**：$2(0,1) = (0,2)$，而 $2 \neq 0 + 1 = 1$，不在 T 中 ✗

三条全失败。

【计算机制解说】：为什么"过原点"这么关键？因为子空间的定义要求对**任意**线性组合封闭，而"什么都不取"（系数全 0）得到的就是零向量。所以**零向量是每个子空间的必含成员**——这是最快的筛查工具。几何上，一个不经过原点的仿射集合（affine set）像一条"悬浮"的线或面：它在"内部"是平的，但没法穿过原点，所以对加法不封闭。线性代数的整个体系建立在"原点固定不动"上：线性映射必须满足 $A\mathbf{0} = \mathbf{0}$，所以它的像与核都自动是子空间。反过来，如果有人给你一个集合，**先查零向量**，一票否决。

$\mathbb{R}^3$ 的子空间完整分类

$\mathbb{R}^2$ 只有三类，$\mathbb{R}^3$ 只有四类，**一个不多、一个不少**：

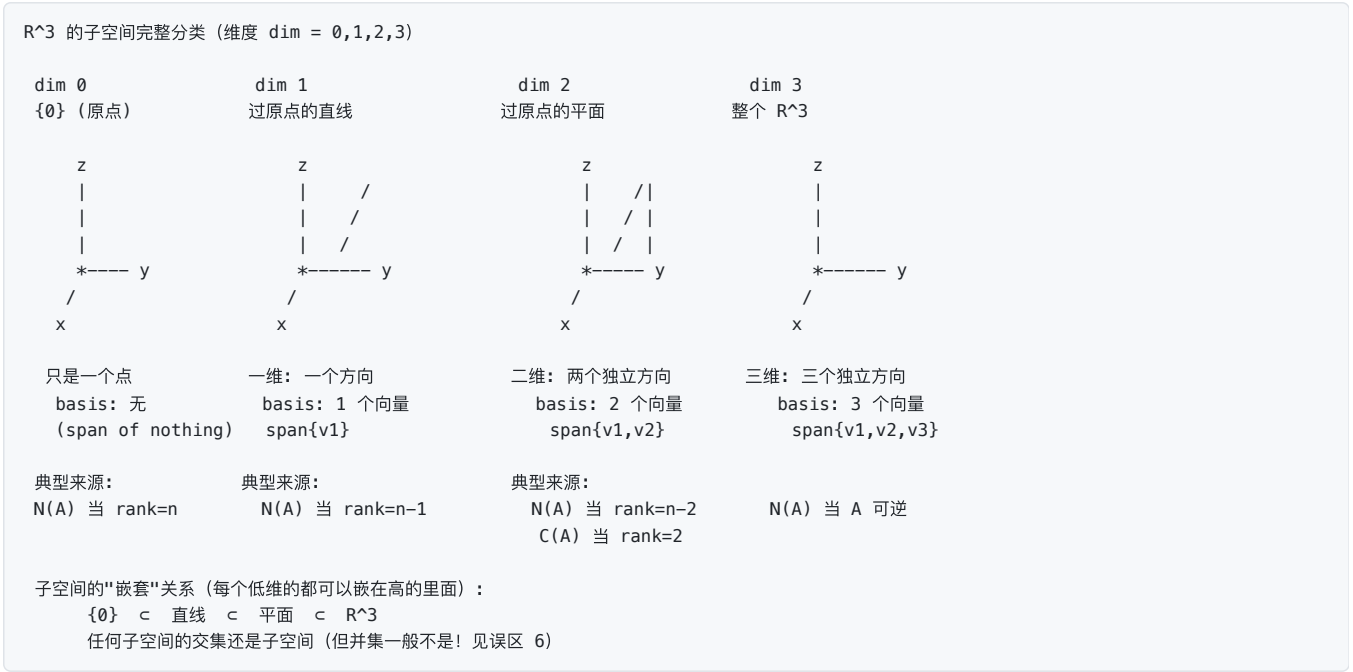

每个分类的实例与验证：

子空间	定义方式	基	封闭性验证要点
$\{\mathbf{0}\}$	只含原点	无（空集张成）	$\mathbf{0}+\mathbf{0}=\mathbf{0}$，$c\cdot\mathbf{0}=\mathbf{0}$ ✓
过原点直线	$\{c\mathbf{v}\}$，$\mathbf{v}\neq\mathbf{0}$	$\{\mathbf{v}\}$	由示例四已验 ✓
过原点平面	$\{c_1\mathbf{v}_1+c_2\mathbf{v}_2\}$，$\mathbf{v}_1,\mathbf{v}_2$ 不共线	$\{\mathbf{v}_1,\mathbf{v}_2\}$	见示例五 $C(B)$ ✓
整个 $\mathbb{R}^3$	所有三元向量	$\{\mathbf{e}_1,\mathbf{e}_2,\mathbf{e}_3\}$	显然对加/乘封闭 ✓

具体到"过原点平面"：$C(B)=\{(x_1,x_2,x_1+x_2)^{\mathsf{T}}\}$（示例五的 B）就是 $\mathbb{R}^3$ 中法向量为 $(1,1,-1)$ 的过原点平面。验证封闭性任取两组系数：$(3\mathbf{b}_1+2\mathbf{b}_2)+(-\mathbf{b}_1+5\mathbf{b}_2)=2\mathbf{b}_1+7\mathbf{b}_2=(2,7,9)^{\mathsf{T}}$——仍是组合，仍在平面内（$9=2+7$ ✓）。**而 $\mathbb{R}^3$ 中不存在 dim$=2$ 的"曲面"型子空间**：任何二维子空间都必须是平面。这是"子空间 = 平坦 + 过原点"的直接后果。

【计算机制解说】：为什么 $\mathbb{R}^3$ 里恰好只有这四种？因为子空间必须"平坦且过原点"，而 $\mathbb{R}^3$ 的"平坦过原点形状"只能是：一个点（0 维）、一条线（1 维）、一个面（2 维）、整个空间（3 维）。没有第四个选项——你不能用"弯曲的曲面"当子空间（球面不是子空间：它上面两点相加会跑到外面）。这是**线性**代数的边界：只允许直线、平面、以及它们的高维推广（flat）。另一个视角：子空间 S 的维数 = 基中向量的个数 = "要几个独立方向才能把 S 走遍"。维数一旦定了，形状也就定了（同为过原点的 2 维子空间，$\mathbb{R}^3$ 中互相之间只差一个旋转）。

判定子空间的"三步操作法"

拿到一个集合，按下面的清单机械地走一遍，就能得到确定答案：

```
子空间判定流程（对集合 S ⊆ R^n）

  Step 0: S 非空吗？（等价：0 ∈ S 吗？）
          |
          +-- 否 --> 不是子空间，结束（最常见的否决理由）
          |
          +-- 是 --> 继续
  Step 1: 加法封闭？  任取 v,w ∈ S  （用一般符号，不要只试一组数）
          |             验证 v+w ∈ S 是否恒成立
          +-- 否 --> 不是子空间
          |
          +-- 是 --> 继续
  Step 2: 数乘封闭？  任取 v ∈ S, c ∈ R
          |             验证 cv ∈ S 是否恒成立
          +-- 否 --> 不是子空间
          |
          +-- 是 --> 是子空间 ✓

  【加速技巧】若 S 能写成 {所有线性组合} 或 {Ax = 0 的解},
              则 Step 1,2 可以一次性通过——见示例五的结构性论证。

  【陷阱】验证时只代一组具体数字不足以证明（必须用一般符号）；
          但要否定只需一组反例（如 Step 0 的零向量最省力）。
```

用这个流程快速扫一遍几个候选集合：

集合	Step 0 含 $\mathbf{0}$?	Step 1 加法	Step 2 数乘	结论
$\{(x,y) : y = 3x\}$	✓	✓ 封闭	✓ 封闭	**是**
$\{(x,y) : y = x + 1\}$	✗	✗	✗	不是
$\{(x,y) : xy = 0\}$（两条坐标轴）	✓	✗ $(1,0)+(0,1)=(1,1)$ 不满足 $xy=0$	✓	**不是**
$\{(x,y) : x \geq 0\}$（右半平面）	✓	✓	✗ $(-1)(1,0)=(-1,0)$ 出界	**不是**
$\{(x,y) : x^2 + y^2 \leq 1\}$（单位圆盘）	✓	✗ $(1,0)+(0,1)=(1,1)$，模长 $\sqrt{2} > 1$	✗	不是

注意第三个反例很微妙：两条坐标轴的**并集**不是子空间（加法失败），而它们的**交集** $\{\mathbf{0}\}$ 是子空间。这印证一条一般原则：**子空间的交集仍是子空间，但并集一般不是**——因为并集迫使两个不同方向"相加"，而和向量通常落在两者之外。

示例五：矩阵的列空间与零空间都是子空间

列空间 $C(A)$：取

$$B = \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 1 \end{bmatrix} \ (3 \times 2), \qquad \text{列 } \mathbf{b}_1 = \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix},\ \mathbf{b}_2 = \begin{bmatrix} 0 \\ 1 \\ 1 \end{bmatrix}.$$

$C(B) = \{\mathbf{b}_1, \mathbf{b}_2$ 的所有线性组合$\}$。例如 $3\mathbf{b}_1 + 2\mathbf{b}_2 = (3,2,5)^{\mathsf{T}}$，注意 $5 = 3 + 2$，即 $x_3 = x_1 + x_2$——这正是 $\mathbb{R}^3$ 中一个**过原点的平面**。

为什么它自动是子空间？（这是本讲的"结构性"论证）设 $\mathbf{v}, \mathbf{w} \in C(B)$，则存在 $\mathbf{x}, \mathbf{y}$ 使 $\mathbf{v} = B\mathbf{x}$、$\mathbf{w} = B\mathbf{y}$。于是

$$\mathbf{v} + \mathbf{w} = B\mathbf{x} + B\mathbf{y} = B(\mathbf{x} + \mathbf{y}) \in C(B), \qquad c\mathbf{v} = c(B\mathbf{x}) = B(c\mathbf{x}) \in C(B).$$

并且 $\mathbf{0} = B\mathbf{0} \in C(B)$。**证毕，而且这个论证只用到了矩阵乘法的分配律与结合律**——它适用于任何矩阵，说明"列张成的集合"必定是子空间。

零空间 $N(A)$：取

$$A = \begin{bmatrix} 1 & 2 \\ 2 & 4 \end{bmatrix} \ (\text{两行成比例，} \ \mathbf{rank} = 1).$$

$A\mathbf{x} = \mathbf{0}$ 给出 $x_1 + 2x_2 = 0$，即 $\mathbf{x} = c(2,-1)^{\mathsf{T}}$。核对：$A(2,-1)^{\mathsf{T}} = (2-2,\ 4-4)^{\mathsf{T}} = (0,0)^{\mathsf{T}}$ ✓；$A(4,-2)^{\mathsf{T}} = (0,0)^{\mathsf{T}}$ ✓；求和 $(2,-1)+(4,-2) = (6,-3)$，$A(6,-3)^{\mathsf{T}} = (6-6,\ 12-12)^{\mathsf{T}} = \mathbf{0}$ ✓。

所以 $N(A) = \{c(2,-1)^{\mathsf{T}}\}$，是 $\mathbb{R}^2$ 中一条过原点的直线。

子空间论证：若 $A\mathbf{x} = \mathbf{0}$、$A\mathbf{y} = \mathbf{0}$，则 $A(\mathbf{x}+\mathbf{y}) = A\mathbf{x} + A\mathbf{y} = \mathbf{0}$，$A(c\mathbf{x}) = cA\mathbf{x} = \mathbf{0}$。证毕。

【计算机制解说】：A 是 $m \times n$ 时，$C(A)$ **住在** $\mathbb{R}^m$、$N(A)$ **住在** $\mathbb{R}^n$（维度一定不能搞反）。直观图景：A 是"从 $\mathbb{R}^n$ 打到 $\mathbb{R}^m$ 的机器"。$C(A)$ 是这台机器的**像素范围（range）**——所有能打出来的目标点；$N(A)$ 是**被压成 0 的输入**——机器看不见的方向。二者都是子空间，因为它们都是"线性组合的容器"。这两个空间加上它们的转置版本 $C(A^{\mathsf{T}})$、$N(A^{\mathsf{T}})$ 就是著名的**四个基本子空间**，是讲次 6–10 的全部舞台。

矩阵分解的核心思想

本讲本身没有引入新的矩阵分解，但它是**所有分解的语法基础**——三个概念各自支撑一类分解：

1. **转置 ↔ 对偶分解**：A^{T} 使得"行空间"与"列空间"可以互相转译。$A=LU$ 的对称版本 $A=LDL^{\mathsf{T}}$（讲次 4）就是靠转置写成对称形式的；更远的 $A=S\Lambda S^{-1}$（讲次 22）在对称时化为 $A=Q\Lambda Q^{\mathsf{T}}$（讲次 25），而 $A=U\Sigma V^{\mathsf{T}}$（SVD，讲次 29）里 U,V 的地位正是"A 与 A^{T} 各自的奇异向量基"。**SVD 的一般形状就是"转置把左边和右边分开"的极致体现。**
2. **置换 ↔ $PA=LU$ 与正交分解**：$P^{-1}=P^{\mathsf{T}}$ 是"正交"的最简单模型。$A=QR$（讲次 17）里 $Q^{\mathsf{T}}Q=I$ 就是把 P 的这条性质推广到"列是任意正交单位向量"；P 是离散版、Q 是连续版。
3. **子空间 ↔ 分解的"舞台"**：任何分解 $A=(\text{结构})\times(\text{结构})$ 都在回答同一个问题——A 把哪个子空间送到哪里。$A=LU$ 揭示 U 的零行给出 $N(A)$ 的维数；$A=QR$ 把 $C(A)$ 用正交基重新描述；$A=S\Lambda S^{-1}$ 把 $\mathbb{R}^n$ 分解成特征方向。**没有子空间的语言，后面所有分解都只是符号操作。**

一句话总结：**转置让"左右"可以互换，置换/正交让"坐标"可以重选，子空间让"往哪儿去"可以精确描述。**

预告：四个基本子空间的全景图（讲次 6–10 的舞台）

本讲只建立了"子空间"这个概念，但 Strang 课程真正的主角是下面这四个。提前把地图画出来，后面的每一讲都是在填这张图：

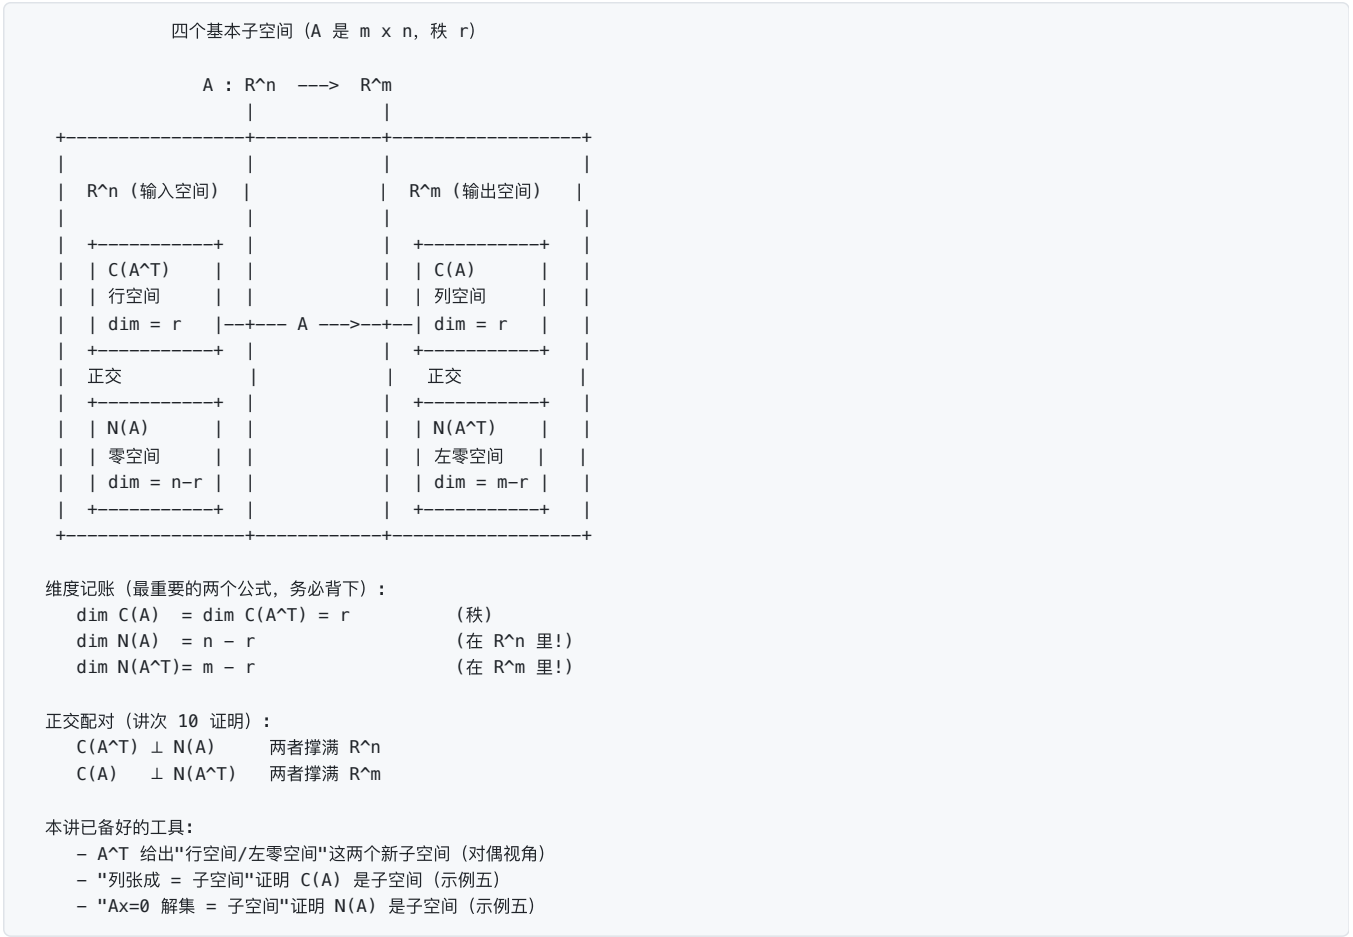

注意最容易记错的一条：$\dim N(A)=n-r$ 而不是 $m-r$。原因：$N(A)$ 是"被 A 打成 0 的**输入**"，输入住在 $\mathbb{R}^n$，所以公式里必须出现**列数** n。同理 $\dim N(A^{\mathsf{T}})=m-r$。这个维度上的对称性是整个课程最优雅的部分之一。

与其他讲次的关联

- **讲次 4（$A=LU$）**：本讲的 P 补全了 $PA=LU$；$P^{-1}=P^{\mathsf{T}}$ 解释了为什么 $A=P^{\mathsf{T}}LU$。
- **讲次 2–3（消元、矩阵乘法）**：转置性质 3 依赖 AB 的元素展开；本讲把"左乘换行、右乘换列"讲透。
- **讲次 6（列空间与零空间）**：直接续讲。本讲已给出 $C(A)\subseteq\mathbb{R}^m$、$N(A)\subseteq\mathbb{R}^n$ 以及"为什么自动是子空间"，下一讲开始算维数。
- **讲次 7（$Ax=0$ 与主变量）**：$N(A)$ 的具体求法（自由变量、特解）。
- **讲次 10（四个基本子空间）**：$C(A)\perp N(A^{\mathsf{T}})$、$C(A^{\mathsf{T}})\perp N(A)$——正交性完全靠转置表述，本讲的对偶视角（$\langle A\mathbf{x},\mathbf{y}\rangle=\langle\mathbf{x},A^{\mathsf{T}}\mathbf{y}\rangle$）是引理。
- **讲次 16（最小二乘）**：正规方程 $A^{\mathsf{T}}A\hat{\mathbf{x}}=A^{\mathsf{T}}\mathbf{b}$ 直接来自本讲的 $A^{\mathsf{T}}A$ 对称性与几何含义。

- **讲次 17（正交矩阵与 Gram–Schmidt）**：$P^{\mathsf{T}}P=I$ 是正交矩阵的最简范例；$Q^{\mathsf{T}}Q=I$ 是它的连续推广。$n!$ 个置换矩阵是正交群 $O(n)$ 中的离散点。
- **讲次 18–20（行列式）**：$\det P=\pm 1$ 与置换的奇偶性；行列式的"符号求和"定义就是"枚举所有置换矩阵"。
- **讲次 25（对称正定矩阵）**：$S=S^{\mathsf{T}}$ 的谱定理——实特征值、正交特征向量。$A^{\mathsf{T}}A$ 是最常见的正定矩阵。

关键要点

1. **转置三律**：$(A^{\mathsf{T}})^{\mathsf{T}}=A$；$(A+B)^{\mathsf{T}}=A^{\mathsf{T}}+B^{\mathsf{T}}$；$\boxed{(AB)^{\mathsf{T}}=B^{\mathsf{T}}A^{\mathsf{T}}}$（**顺序反转，由维度强制**）。核心理性刻画：$\langle A\mathbf{x},\mathbf{y}\rangle=\langle\mathbf{x},A^{\mathsf{T}}\mathbf{y}\rangle$。
2. $A^{\mathsf{T}}A$ **永远对称**：$(A^{\mathsf{T}}A)^{\mathsf{T}}=A^{\mathsf{T}}A$；且 $(A^{\mathsf{T}}A)_{ij}=\mathbf{a}_i\cdot\mathbf{a}_j$（第 i 列与第 j 列的内积，即 Gram 矩阵）。这是最小二乘的地基。注意 $A^{\mathsf{T}}A$ 是 $n\times n$，AA^{T} 是 $m\times m$，**两者一般不相同**。
3. **置换矩阵**：每行每列恰一个 1；共 $n!$ 个；$P^{\mathsf{T}}P=I$ 即 $P^{-1}=P^{\mathsf{T}}$；$\det P=\pm 1$；PA 重排 A 的**行**，AP 重排 A 的**列**。
4. **子空间的判定**：非空子集 $S\subseteq\mathbb{R}^n$ 是子空间 $\iff$ 对加法与数乘封闭（等价于对一切线性组合封闭）。**必含 $\mathbf{0}$**——查零向量是最快的否决测试。
5. **完整分类**：$\mathbb{R}^2$ 只有 $\{\mathbf{0}\}$、过原点的直线、$\mathbb{R}^2$；$\mathbb{R}^3$ 只有 $\{\mathbf{0}\}$、过原点的直线、过原点的平面、$\mathbb{R}^3$。**任何不过原点的直线/平面都不是子空间。**
6. $C(A)\subseteq\mathbb{R}^m$，$N(A)\subseteq\mathbb{R}^n$（$A$ 为 $m\times n$）。列空间 = 矩阵能打出的所有目标；零空间 = 被打成 0 的所有输入。

常见误区与注意事项

1. **把 $(AB)^{\mathsf{T}}$ 写成 $A^{\mathsf{T}}B^{\mathsf{T}}$。** 必须反序：$(AB)^{\mathsf{T}}=B^{\mathsf{T}}A^{\mathsf{T}}$。维度检查是终极大法：$A$ 为 $m\times n$、B 为 $n\times p$ 时，$A^{\mathsf{T}}B^{\mathsf{T}}$ 的形状是 $(n\times m)(p\times n)$，一般根本无法相乘。
2. **把 $A^{\mathsf{T}}A$ 与 AA^{T} 混为一谈。** 前者 $n\times n$、后者 $m\times m$。以示例二的 M（2×3）为例：$M^{\mathsf{T}}M$ 是 3×3 但**秩只有 2**（因为列数 3 > 行数 2，必然奇异），而 MM^{T} 是 2×2 且可逆（$\det=14\cdot 17-14\cdot 14=238-196=42\neq 0$）。"$A^{\mathsf{T}}A$ 可逆"需要 A 的列线性无关（此时必须 $n\le m$）。
3. **忘记置换矩阵的行列式有符号。** $\det P=\pm 1$ 而不是恒为 $+1$。交换一次得 -1，n 阶置换的符号等于 $(-1)^{\#\text{交换}}$（严格说是 $(-1)^{\#\text{逆序对}}$）。
4. **认为"不过原点的直线也是子空间"。** 这是最经典的错误。$y=x+1$ 上取两点相加就跑出去了。**记住口诀：子空间必须过原点**（因为 $0\cdot\mathbf{v}=\mathbf{0}$ 必须留在集合内）。
5. **把 $C(A)$ 说成 $\mathbb{R}^n$ 里的、把 $N(A)$ 说成 $\mathbb{R}^m$ 里的。** 严格纠正：A 是 $m\times n$，则 $A:\mathbb{R}^n\to\mathbb{R}^m$，所以**列空间（输出）$\subseteq\mathbb{R}^m$，零空间（输入）$\subseteq\mathbb{R}^n$**。行空间 $C(A^{\mathsf{T}})\subseteq\mathbb{R}^n$（不是 $\mathbb{R}^m$）。
6. **以为"子空间 = 任意向量集合"。** 有限个向量组成的集合（如 $\{(1,0),(0,1)\}$ 只有两个元素）**不是**子空间——它不含 $(1,1)$，也不含 $\mathbf{0}$。"张成（span）的集合"才是子空间，即把这些向量的**所有**线性组合都收进来。
7. **混淆"过原点的平面"与"平面"。** $\mathbb{R}^3$ 中 $x_3=1$ 的平面不是子空间（不过原点）；而 $x_3=x_1+x_2$（等价于 $x_1+x_2-x_3=0$，是齐次方程）才是。判别法：**子空间 $\iff$ 是某个齐次线性方程组 $A\mathbf{x}=\mathbf{0}$ 的解集。**

思考题（带答案）

Q1.（纯计算） 设 $A=\begin{bmatrix}1&2&0\\3&1&1\end{bmatrix}$、$B=\begin{bmatrix}1&0\\0&2\\1&1\end{bmatrix}$。计算 AB、$(AB)^{\mathsf{T}}$、$B^{\mathsf{T}}A^{\mathsf{T}}$，验证 $(AB)^{\mathsf{T}}=B^{\mathsf{T}}A^{\mathsf{T}}$；再计算 $A^{\mathsf{T}}A$ 并确认它对称。

<details>
<summary>答案</summary>

先做 AB（2×3 乘 $3\times 2\to 2\times 2$）：

$$AB=\begin{bmatrix}1\cdot 1+2\cdot 0+0\cdot 1 & 1\cdot 0+2\cdot 2+0\cdot 1\\ 3\cdot 1+1\cdot 0+1\cdot 1 & 3\cdot 0+1\cdot 2+1\cdot 1\end{bmatrix}=\begin{bmatrix}1&4\\4&3\end{bmatrix}.$$

$$(AB)^{\mathsf{T}}=\begin{bmatrix}1&4\\4&3\end{bmatrix}^{\mathsf{T}}=\begin{bmatrix}1&4\\4&3\end{bmatrix}\quad(\text{恰好对称}).$$

再做 $B^{\mathsf{T}}A^{\mathsf{T}}$：$B^{\mathsf{T}}=\begin{bmatrix}1&0&1\\0&2&1\end{bmatrix}$（$2\times 3$），$A^{\mathsf{T}}=\begin{bmatrix}1&3\\2&1\\0&1\end{bmatrix}$（$3\times 2$）。

$$B^{\mathsf{T}}A^{\mathsf{T}}=\begin{bmatrix}1\cdot 1+0\cdot 2+1\cdot 0 & 1\cdot 3+0\cdot 1+1\cdot 1\\ 0\cdot 1+2\cdot 2+1\cdot 0 & 0\cdot 3+2\cdot 1+1\cdot 1\end{bmatrix}=\begin{bmatrix}1&4\\4&3\end{bmatrix}.\ \checkmark$$
</details>

与 $(AB)^{\mathsf{T}}$ 完全一致。

再算 $A^{\mathsf{T}}A$：$A^{\mathsf{T}} = \begin{bmatrix}1 & 3\\ 2 & 1\\ 0 & 1\end{bmatrix}$ (3×2)，$A = \begin{bmatrix}1 & 2 & 0\\ 3 & 1 & 1\end{bmatrix}$ (2×3)，所以 $A^{\mathsf{T}}A$ 是 3×3：

$$A^{\mathsf{T}}A = \begin{bmatrix}1 & 3\\ 2 & 1\\ 0 & 1\end{bmatrix}\begin{bmatrix}1 & 2 & 0\\ 3 & 1 & 1\end{bmatrix} = \begin{bmatrix}1+9 & 2+3 & 0+3\\ 2+3 & 4+1 & 0+1\\ 0+3 & 0+1 & 0+1\end{bmatrix} = \begin{bmatrix}10 & 5 & 3\\ 5 & 5 & 1\\ 3 & 1 & 1\end{bmatrix}.$$

对称性核对：$(1,2)$ 与 $(2,1)$ 都是 5；$(1,3)$ 与 $(3,1)$ 都是 3；$(2,3)$ 与 $(3,2)$ 都是 1 ✓。这与 $(A^{\mathsf{T}}A)_{ij} = \mathbf{a}_i \cdot \mathbf{a}_j$ 吻合（例如 $(1,2)$ 位置 $= (1,3)\cdot(2,1) = 2+3 = 5$）。另外注意 A 的两行线性无关（即 $A^{\mathsf{T}} = \begin{bmatrix}1 & 3\\ 2 & 1\\ 0 & 1\end{bmatrix}$ 是 3×2 且**列满秩**），$\det(A^{\mathsf{T}}A) = 10(5-1) - 5(5-3) + 3(5-15) = 40 - 10 - 30 = 0$？请谨慎：这里 $A^{\mathsf{T}}A$ 是 3×3 而 $\operatorname{rank}(A) \le 2$，所以 $A^{\mathsf{T}}A$ **必然奇异**，行列式应为 0。用余子式展开确认：$40 - 10 - 30 = 0$ ✓。**这正是"$A^{\mathsf{T}}A$ 可逆需要 A 列满秩"的实例。**

Q2.（概念） 判断下列集合是否为 $\mathbb{R}^2$ 或 $\mathbb{R}^3$ 的子空间，并说明理由：(a) $S_1 = \{(x,y)^{\mathsf{T}} : y = 2x\}$；(b) $S_2 = \{(x,y)^{\mathsf{T}} : y = x^2\}$；(c) $S_3 = \{(x,y,z)^{\mathsf{T}} : x+y+z = 0\}$；(d) $S_4 = \{(x,y,z)^{\mathsf{T}} : x+y+z = 1\}$。

▸ 答案

(a) 是子空间。 这是过原点的直线 $y = 2x$。含原点：$(0,0)$ ✓。加法：$(x_1, 2x_1) + (x_2, 2x_2) = (x_1+x_2,\ 2(x_1+x_2)) \in S_1$ ✓。数乘：$c(x, 2x) = (cx, 2cx) \in S_1$ ✓。

(b) 不是子空间。 抛物线 $y = x^2$ 不过原点以外的结构不行：虽然含 $(0,0)$，但 $(1,1) \in S_2$，而 $2(1,1) = (2,2)$ 不在（$2^2 = 4 \neq 2$），数乘不封闭 ✗。（也可以看加法：$(1,1) + (2,4) = (3,5)$，$3^2 = 9 \neq 5$ ✗。）

(c) 是子空间。 这是过原点的平面（法向量 $(1,1,1)$）。含原点 ✓（$0+0+0=0$）。若 $\mathbf{v} = (x_1,y_1,z_1)$、$\mathbf{w} = (x_2,y_2,z_2)$ 都满足和为 0，则 $\mathbf{v}+\mathbf{w}$ 的和也是 $0+0=0$ ✓；$c\mathbf{v}$ 的和是 $c\cdot 0 = 0$ ✓。更本质：$S_3 = N([1\ 1\ 1])$，是零空间，自动是子空间。

(d) 不是子空间。 这是**不过原点**的平面（$x+y+z=1$）。$(0,0,0)$ 不满足 $0=1$ ✗，一票否决。也可验：$(1,0,0)$ 与 $(0,1,0)$ 都在其中，但和为 $(1,1,0)$，而 $1+1+0 = 2 \neq 1$ ✗。注意 (c) 与 (d) 只差一个常数项：**齐次（右端为 0）→ 子空间；非齐次 → 不是子空间（是仿射平面）。**

总结规律：$\mathbb{R}^n$ 的子空间 = 一组齐次线性方程的解集 = 若干向量张成的所有线性组合。判别口诀：**先看零，再看加法与数乘。**

Q3.（概念 + 计算） (i) 说明 $C(A)$ 为什么自动是子空间。(ii) 对 $A = \begin{bmatrix}1 & 2\\ 2 & 4\\ 3 & 6\end{bmatrix}$，描述 $C(A)$ 与 $N(A)$，并指出它们各自位于哪个 $\mathbb{R}^k$ 中。(iii) 为什么 $\mathbb{R}^2$ 中"不过原点的直线"不能是任何矩阵的列空间或零空间？

▸ 答案

(i) 结构性证明。 设 $\mathbf{v}, \mathbf{w} \in C(A)$，则存在 $\mathbf{x}, \mathbf{y}$ 使 $\mathbf{v} = A\mathbf{x}$、$\mathbf{w} = A\mathbf{y}$。由分配律 $\mathbf{v}+\mathbf{w} = A\mathbf{x} + A\mathbf{y} = A(\mathbf{x}+\mathbf{y})$，仍是 A 乘某向量，故在 $C(A)$ 中；由结合律 $c\mathbf{v} = A(c\mathbf{x}) \in C(A)$；又 $\mathbf{0} = A\mathbf{0} \in C(A)$。三条封闭性全部只用矩阵乘法的基本性质，对任意 A 成立。同理，若 $A\mathbf{x} = \mathbf{0}$、$A\mathbf{y} = \mathbf{0}$，则 $A(\mathbf{x}+\mathbf{y}) = \mathbf{0}$、$A(c\mathbf{x}) = \mathbf{0}$，故 $N(A)$ 也是子空间。

(ii) A 是 3×2，两列分别是 $(1,2,3)^{\mathsf{T}}$ 与 $(2,4,6)^{\mathsf{T}} = 2\cdot(1,2,3)^{\mathsf{T}}$——**第二列是第一列的 2 倍**，所以只有一列独立，$\operatorname{rank}(A) = 1$。

$$C(A) = \left\{ c\begin{bmatrix}1\\2\\3\end{bmatrix} : c \in \mathbb{R} \right\} \subseteq \mathbb{R}^3,$$

即 $\mathbb{R}^3$ 中过原点、方向为 $(1,2,3)$ 的一条**直线**（不是平面！因为秩只有 1）。核：

$$A\mathbf{x} = \mathbf{0} \iff x_1 + 2x_2 = 0 \text{（第二、三行是它的倍数）} \iff \mathbf{x} = c\begin{bmatrix}2\\-1\end{bmatrix},$$

$$N(A) = \left\{ c\begin{bmatrix}2\\-1\end{bmatrix} : c \in \mathbb{R} \right\} \subseteq \mathbb{R}^2,$$

即 $\mathbb{R}^2$ 中过原点、斜率 $-\frac{1}{2}$ 的一条直线。

维度核对：A 有 $n=2$ 列，$\mathbf{rank}=1$，故 $\dim N(A)=n-r=2-1=1$ ✓（确实是直线）。**注意 $C(A)\subseteq\mathbb{R}^3$ 而 $N(A)\subseteq\mathbb{R}^2$**，这与"$A:\mathbb{R}^2\to\mathbb{R}^3$"一致——输入空间是 $\mathbb{R}^2$（零空间住这里），输出空间是 $\mathbb{R}^3$（列空间住这里）。

(iii) 任何列空间 $C(A)$ 都含 $\mathbf{0}$（取 $\mathbf{x}=\mathbf{0}$），任何零空间 $N(A)$ 也含 $\mathbf{0}$（取 $\mathbf{x}=\mathbf{0}$，因为 $A\mathbf{0}=\mathbf{0}$）。不过原点的直线不含 $\mathbf{0}$，所以它**不可能**是任何矩阵的列空间或零空间。更一般地：**不过原点的直线/平面只能当"平移后的仿射集"（如 $A\mathbf{x}=\mathbf{b}$ 的解集，$\mathbf{b}\neq\mathbf{0}$），永远不是子空间。**

Lecture 6: Column Space and Nullspace

概述

本讲第一次把矩阵 A 从"一张数字表"改造成**一台机器**：它接受输入向量 $\mathbf{x}$，吐出一个输出向量 $A\mathbf{x}$。一旦这个视角立住，两个最自然的问题就浮出来了——**这台机器能造出哪些输出 $\mathbf{b}$？**（答案叫列空间 C(A)）**以及哪些输入被它压成了零？**（答案叫零空间 N(A)）。这两个集合分别住在输出空间 $\mathbb{R}^m$ 与输入空间 $\mathbb{R}^n$ 里，是本课程后半程"四个基本子空间"里最先登场的两根支柱。本讲唯一用到的技术工具是上一讲的**消元法**，但思想上它做了一个关键跳跃：把"解方程 $A\mathbf{x}=\mathbf{b}$ 有没有解"翻译成"$\mathbf{b}$ 这个点是否落在某个**子空间**里"。学完本讲你应该能对着一个小矩阵，立刻说出它的列空间是什么形状的几何对象、零空间是几维的，以及为什么 $A\mathbf{x}=\mathbf{b}$ 的解集自己**不是**一个子空间。

核心概念的几何直觉

向量空间与子空间（vector space / subspace）

- **定义与目的**：向量空间是一堆向量的集合，在其中做**加法**和**数乘**不会跑出去。$\mathbb{R}^2$、$\mathbb{R}^3$、$\mathbb{R}^n$ 是最基本的例子；$\mathbb{R}^n$ 中的子空间 S 是 $\mathbb{R}^n$ 的一个子集，并且**在 $\mathbb{R}^n$ 的运算下自成一个向量空间**。
- **几何直觉（它在空间中是什么样子？）**：$\mathbb{R}^3$ 里的子空间只有三种，没有第四种：
- **0 维**：只含原点 $\{\mathbf{0}\}$（点）；
- **1 维**：过原点的一条**直线**（必须过原点！）；
- **2 维**：过原点的一张**平面**；
- **3 维**：整个 $\mathbb{R}^3$ 自己。

$\mathbb{R}^3$ 里**不存在**"不过原点的平面"或"不过原点的直线"作为子空间。这是本讲最重要的一个几何事实。判据可以写成一句话：**子空间对线性组合封闭**。即若 $\mathbf{v},\mathbf{w}\in S$ 且 c,d 是任意实数，则 $c\mathbf{v}+d\mathbf{w}\in S$。验证时只要查两条（对加法封闭、对数乘封闭）就够了，因为两者合起来等价于对线性组合封闭。取 $c=d=0$ 立刻得到 $\mathbf{0}\in S$——**子空间必含原点**，所以"原点不在里面"是一票否决。 – **具体示例**：在 $\mathbb{R}^2$ 中，$S=\{(x,2x)\}$（直线 $y=2x$）是子空间：$(x_1,2x_1)+(x_2,2x_2)=(x_1+x_2,\,2(x_1+x_2))\in S$。而 $S'=\{(x,y):y=2x+1\}$ **不是**：它不含原点，且 $(0,1),(1,3)\in S'$ 但 $(0,1)+(1,3)=(1,4)\notin S'$。在 $\mathbb{R}^3$ 中，同时满足 $x_1+2x_2+3x_3=0$ 的向量构成过原点的平面（是子空间）；把 0 换成 1 就变成不过原点的平面（不是子空间）。**"齐次 vs 非齐次"是子空间的分水岭**。

列空间 C(A)（column space）

- **定义与目的**：设 A 是 $m\times n$ 矩阵，把它的 n 个列向量记作 $\mathbf{a}_1,\dots,\mathbf{a}_n\in\mathbb{R}^m$。则

$$\mathbf{C}(A)=\{A\mathbf{x}:\mathbf{x}\in\mathbb{R}^n\}=\{x_1\mathbf{a}_1+x_2\mathbf{a}_2+\cdots+x_n\mathbf{a}_n\}=\mathbf{span}\{\mathbf{a}_1,\dots,\mathbf{a}_n\}\subseteq\mathbb{R}^m.$$

它的目的是回答**存在性问题**：$A\mathbf{x}=\mathbf{b}$ 有解 $\iff\mathbf{b}\in\mathbf{C}(A)$。这不是一个需要证明的定理，而是**定义的同义改写**：$A\mathbf{x}$ 按列看就是 $\mathbf{a}_i$ 的线性组合，系数是 x_i。 – **几何直觉（它在空间中是什么样子？）**：把 A 想成一台机器，$\mathbf{C}(A)$ 就是**从 $\mathbf{0}$ 出发、把所有可能的输入 $\mathbf{x}$ 输进去后，输出 $\mathbf{b}$ 能扫过的全部区域的集合**——即"A 能生成的输出全集"。它是 $\mathbb{R}^m$ 的子空间（因为 $A(c\mathbf{x}+d\mathbf{y})=cA\mathbf{x}+dA\mathbf{y}$，输出集对线性组合封闭）。**注意对偶的维度直觉**：输入空间是 $\mathbb{R}^n$（由列数 n 决定），输出空间是 $\mathbb{R}^m$（由行数 m 决定），列空间住在输出空间 $\mathbb{R}^m$ 里——很多同学第一个星期就把这两个空间的维度搞反。 – **具体示例**：$A=\begin{bmatrix}1&2\\2&4\end{bmatrix}$ 的两个列是 $\begin{bmatrix}1\\2\end{bmatrix}$ 和 $\begin{bmatrix}2\\4\end{bmatrix}=2\begin{bmatrix}1\\2\end{bmatrix}$。它们共线，所以 $\mathbf{C}(A)$ 不是整个 $\mathbb{R}^2$，而只是 $\mathbb{R}^2$ 中沿方向 $\begin{bmatrix}1\\2\end{bmatrix}$ 的**一条过原点直线**。于是 $\begin{bmatrix}1\\2\end{bmatrix}$、$\begin{bmatrix}3\\6\end{bmatrix}$、$\begin{bmatrix}-1\\-2\end{bmatrix}$ 都在 C(A) 里，而 $\begin{bmatrix}1\\3\end{bmatrix}$ 不在（它不在这条直线上）。

零空间 N(A)（nullspace）

- **定义与目的**：$\mathbf{N}(A)=\{\mathbf{x}\in\mathbb{R}^n:A\mathbf{x}=\mathbf{0}\}\subseteq\mathbb{R}^n$。注意右边是**零向量**——零空间永远是**齐次**方程组的解集。它的目的是回答**唯一性问题**：$A\mathbf{x}=\mathbf{b}$ 的解唯一 $\iff\mathbf{N}(A)=\{\mathbf{0}\}$。
- **几何直觉（它在空间中是什么样子？）**：$\mathbf{N}(A)$ 是**被这台机器压扁到原点的全部输入方向的集合**。想象 A 是一台"投影/压扁机"：它把输入空间的一部分方向彻底碾平，只让另一部分方向活下来。$\mathbf{N}(A)$ 就是那部分被碾平的方向（连同它们的任意倍数与和），而它**活下来的那部分**给出了 $\mathbf{C}(A)$。
- **为什么 N(A) 是子空间，而 $A\mathbf{x}=\mathbf{b}$（$\mathbf{b}\neq\mathbf{0}$）的解集不是？** 设 $\mathbf{x},\mathbf{y}\in\mathbf{N}(A)$，即 $A\mathbf{x}=\mathbf{0}$、$A\mathbf{y}=\mathbf{0}$。则

$$A(c\mathbf{x}+d\mathbf{y})=cA\mathbf{x}+dA\mathbf{y}=c\cdot\mathbf{0}+d\cdot\mathbf{0}=\mathbf{0},$$

所以 $c\mathbf{x}+d\mathbf{y}\in \mathbf{N}(A)$：**对线性组合封闭**，是子空间。关键在于 A 是线性的，而右端 $\mathbf{0}$ 在数乘下保持为 $\mathbf{0}$。 现在换成非齐次 $A\mathbf{x}=\mathbf{b}$，$\mathbf{b}\neq\mathbf{0}$。第一，$\mathbf{x}=\mathbf{0}$ 不满足方程（$A\mathbf{0}=\mathbf{0}\neq\mathbf{b}$），所以**原点不在解集里**，一票否决。第二，即使取两个解 $\mathbf{x},\mathbf{y}$（$A\mathbf{x}=A\mathbf{y}=\mathbf{b}$），也有

$$A(\mathbf{x}+\mathbf{y})=A\mathbf{x}+A\mathbf{y}=\mathbf{b}+\mathbf{b}=2\mathbf{b}\neq\mathbf{b},$$

而 $A(2\mathbf{x})=2\mathbf{b}\neq\mathbf{b}$：**加法和数乘都跑出去了**。几何上，$A\mathbf{x}=\mathbf{b}$ 的解集是一张**不过原点的平面/直线**（一个仿射集）。它不孤单：它 = {某一个特解 $\mathbf{x}_p$} + $\mathbf{N}(A)$，即"$\mathbf{x}_p$ 加上零空间里任意向量"。这句话就是下一讲（Lecture 8）的全部内容。 – **具体示例**：对 $A=\begin{bmatrix}1&2\\2&4\end{bmatrix}$，解 $x_1+2x_2=0$ 得 $\mathbf{x}=t\begin{bmatrix}-2\\1\end{bmatrix}$，所以 $\mathbf{N}(A)$ 是 $\mathbb{R}^2$ 中沿 $\begin{bmatrix}-2\\1\end{bmatrix}$ 方向的直线。核对：$A\begin{bmatrix}-2\\1\end{bmatrix}=\begin{bmatrix}1(-2)+2(1)\\2(-2)+4(1)\end{bmatrix}=\begin{bmatrix}0\\0\end{bmatrix}$ ✓。而对 $\mathbf{b}=\begin{bmatrix}1\\2\end{bmatrix}$，解集是**不过原点的直线** $x_1+2x_2=1$（它平行于 $\mathbf{N}(A)$ 但被平移了），不是子空间。

只有零空间的判据：$\mathbf{N}(A)=\{\mathbf{0}\}$ $\iff$ A 的列线性无关 $\iff$ 秩 $r=n$

- **定义与目的**：给出"唯一解"的判别标准。若 $\mathbf{N}(A)=\{\mathbf{0}\}$，则 $A\mathbf{x}=\mathbf{b}$ 最多只有一个解（有解时就是唯一解）；若 $\mathbf{N}(A)\neq\{\mathbf{0}\}$，则只要有一个解，就有无穷多个（解 + 任意零空间向量）。
- **几何直觉**：$\mathbf{N}(A)=\{\mathbf{0}\}$ 意味着**没有任何非零方向被压扁**，机器是"不丢失信息的"。等价地，n 个列向量张开出一个 n 维的子空间，即它们线性无关、没有一个是别人的线性组合。
- **具体示例（证明的关键一步）**：$A\mathbf{x}=\mathbf{0}$ 按列写就是 $x_1\mathbf{a}_1+\cdots+x_n\mathbf{a}_n=\mathbf{0}$。若列线性无关，则这个组合只有平凡解 $\mathbf{x}=\mathbf{0}$，即 $\mathbf{N}(A)=\{\mathbf{0}\}$；反过来若存在非零的 $\mathbf{x}\in\mathbf{N}(A)$，那个组合就是列之间的一个非平凡线性关系，列线性相关。**所以"零空间是否只有零"和"列是否无关"是同一件事的两种说法**。而列无关 $\iff$ 消元后 n 列全是主元列 $\iff$ 秩 $r=n$（此时 $m\geq n$，且没有自由变量）。本讲先把这条判据立起来，讲次 9 会把它做成完整理论。

三个集合的几何图景（1 维 / 2 维压缩的对照）

```
实例 1: A = [[1,2],[2,4]]  (2x2, rank 1) —— R^2 被压成一条线

      输入空间 R^2                          输出空间 R^2
         y                                     y
         |    N(A): 直线 t[-2,1]              |      C(A): 直线 t[1,2]
         |   /                                 |     /
         |  /  (被压成 0 的方向)               |    /  (活下来的方向)
         | /                                   |   /
   ------+--------x                    --------+--------x
        /                                     /
       /                                     /
      两条直线互相垂直:   [1,2]·[-2,1] = 0
      dim C(A) = 1,  dim N(A) = 1,  1 + 1 = 2 = n

实例 2: A = [[1,2,3],[2,4,6],[1,2,3]]  (3x3, rank 1) —— R^3 被压成一条线

      输入空间 R^3                            输出空间 R^3
            z                                       z
            |    N(A): 平面 x1+2x2+3x3=0            |    C(A): 直线 t[1,2,1]
            |    (2 维, 法向量 n=[1,2,3])           |   /
            |   /                                   |  /
            |  /                                    | /
            +----------------y                      +----------------y
           /                                       /
          x                                       x

      但注意! 输入空间的"平面"与输出空间的"直线"是两回事:
      法向量 n=[1,2,3] 是"行空间"的方向 (住在输入空间 R^3)
      方向 [1,2,1] 是列向量本身 (住在输出空间 R^3)
      被压掉 2 维, 活下来 1 维:  2 + 1 = 3 = n = 输入维数
```

一个必须自己动手核对的反例

```
A = [[1,2,3],[2,4,6],[1,2,3]] 的 C(A) 方向是 [1,2,1], N(A) 是平面 x1+2x2+3x3=0

问: C(A) 是否包含在 N(A) 里面?
检验 [1,2,1]:  1 + 2(2) + 3(1) = 8 ≠ 0   -> 不在 N(A) 里!

结论: C(A) ∩ N(A) = {0} (这里两个空间只在原点相交)。
      "列空间"与"零空间"是两把不同的尺子, 不要混。
      真正互相正交的一对是 N(A) 与 C(A^T) (行空间), 见讲次 14。
```

计算步骤与手算演示

示例 1：判断 $\mathbf{b}$ 是否在 C(A) 中（用消元法做"入栈检验"）

取

$$A=\begin{bmatrix}1&2&3\\2&4&6\\1&2&3\end{bmatrix},\qquad \mathbf{b}=\begin{bmatrix}1\\2\\1\end{bmatrix}.$$

步骤 1（看清 A 的结构）：第二列 $=2\times$第一列，第三列 $=3\times$第一列，三列全部共线。所以秩 $r=1$，$\mathbf{C}(A)$ 是 $\mathbb{R}^3$ 中沿 $\mathbf{a}_1=\begin{bmatrix}1\\2\\1\end{bmatrix}$ 的一条过原点直线。

步骤 2（写增广矩阵并消元）：

```
[ 1  2  3 | 1 ]                    [ 1  2  3 | 1 ]
[ 2  4  6 | 2 ]  row2 -= 2*row1  ->  [ 0  0  0 | 0 ]
[ 1  2  3 | 1 ]  row3 -= 1*row1  ->  [ 0  0  0 | 0 ]
```

步骤 3（读结论）：出现 $0=0$ 的恒等行，没有 $0=1$ 形式的矛盾行，所以方程组**相容**，$\mathbf{b}\in\mathbf{C}(A)$。回代：$x_1+2x_2+3x_3=1$，取 $x_2=x_3=0$ 得一个特解 $\mathbf{x}_p=\begin{bmatrix}1\\0\\0\end{bmatrix}$。核对 $A\mathbf{x}_p=\mathbf{a}_1=\begin{bmatrix}1\\2\\1\end{bmatrix}=\mathbf{b}$ ✓。

步骤 4（对一组 b 做集体检验）：规律是 $\mathbf{b}=\begin{bmatrix}b_1\\b_2\\b_3\end{bmatrix}\in\mathbf{C}(A)$ 且仅当 $b_2=2b_1$ 且 $b_3=b_1$（因为 $\mathbf{b}=x_1\mathbf{a}_1$ 必须与 $\mathbf{a}_1$ 成比例）。逐一验证：

$\mathbf{b}$	$b_2=2b_1$?	$b_3=b_1$?	结论	消元后的增广第 2、3 行
$\begin{bmatrix}1\\2\\1\end{bmatrix}$	✓	✓	在 C(A) 中	$[0\,0\,0\,
$\begin{bmatrix}5\\10\\5\end{bmatrix}$	✓	✓	在 C(A) 中	$[0\,0\,0\,
$\begin{bmatrix}0\\0\\0\end{bmatrix}$	✓	✓	在 C(A) 中（零向量永远在）	$[0\,0\,0\,
$\begin{bmatrix}1\\2\\2\end{bmatrix}$	✓	✗	**不在**	$[0\,0\,0\,
$\begin{bmatrix}3\\6\\4\end{bmatrix}$	✓	✗	**不在**	$[0\,0\,0\,

注意 $\begin{bmatrix}3\\6\\4\end{bmatrix}$ 这个陷阱：它的前两个分量"很像"在 C(A) 里（$6=2\times3$），但第三个分量 $4\neq3$ 破坏了比例关系，所以不在。这说明**在 C(A) 里必须三个分量同时满足关系**，部分匹配不算。

【计算机制解说】：为什么"消元后出现 $0=1$ 的行"就等价于"$\mathbf{b}\notin\mathbf{C}(A)$"？消元做的是**行变换**——把方程组换成另一个方程组，但**解集完全相同**（行变换是可逆的：$R_i\leftarrow R_i-cR_j$ 可以再减回去）。如果消元到最后某一行变成 $[0\quad 0\quad 0\quad|\quad 1]$，它代表的方程是 $0\cdot x_1+0\cdot x_2+0\cdot x_3=1$，无论 $\mathbf{x}$ 取什么都不成立，所以原方程组无解。反过来如果没有矛盾行，就说明 $\mathbf{b}$ 是各列的某个组合。更本质的说法是：**行变换不改变零空间、不改变行空间，但会改变列空间**——然而它保留了"列之间的线性关系"。所以消元后 $\mathbf{b}$ 能由主元列组合出来 $\Longleftrightarrow$ 原来 $\mathbf{b}$ 能由 A 的列组合出来。（这一点在示例 3 会看到最强的形式。）

示例 2：2×2 秩 1 矩阵——把 C(A) 与 N(A) 全部算穿

取

$$A=\begin{bmatrix}1&2\\2&4\end{bmatrix}.$$

步骤 1（看列）：$\mathbf{a}_1=\begin{bmatrix}1\\2\end{bmatrix}$，$\mathbf{a}_2=\begin{bmatrix}2\\4\end{bmatrix}=2\mathbf{a}_1$。所以 $r=1$，$\mathbf{C}(A)=\{t\begin{bmatrix}1\\2\end{bmatrix}:t\in\mathbb{R}\}$，是 $\mathbb{R}^2$ 中过原点的直线。

步骤 2（求零空间：直接解 $A\mathbf{x}=\mathbf{0}$）：

$$\begin{bmatrix}1 & 2\\ 2 & 4\end{bmatrix}\begin{bmatrix}x_1\\ x_2\end{bmatrix}=\begin{bmatrix}x_1+2x_2\\ 2x_1+4x_2\end{bmatrix}=\begin{bmatrix}0\\ 0\end{bmatrix}.$$

第二个方程是第一个的 2 倍，所以只有一个独立方程 $x_1+2x_2=0$，即 $x_1=-2x_2$。

步骤 3（参数化）：令自由变量 $x_2=1$，得 $\mathbf{x}=\begin{bmatrix}-2\\ 1\end{bmatrix}$；一般解 $\mathbf{x}=t\begin{bmatrix}-2\\ 1\end{bmatrix}$。所以 $\mathrm{N}(A)=\{t\begin{bmatrix}-2\\ 1\end{bmatrix}\}$，也是 $\mathbb{R}^2$ 中一条过原点的直线。

步骤 4（验算）：

$$A\begin{bmatrix}-2\\ 1\end{bmatrix}=\begin{bmatrix}1(-2)+2(1)\\ 2(-2)+4(1)\end{bmatrix}=\begin{bmatrix}0\\ 0\end{bmatrix}\ \checkmark$$

步骤 5（几何核对）：$\mathrm{C}(A)$ 方向 $\begin{bmatrix}1\\ 2\end{bmatrix}$，$\mathrm{N}(A)$ 方向 $\begin{bmatrix}-2\\ 1\end{bmatrix}$，点积 $1\cdot(-2)+2\cdot 1=0$——**两条直线垂直**。$1+1=2=n$：被压掉 1 维，活下来 1 维，加起来正好是输入空间的维数。

【计算机制解说】：这里出现了一个"维数守恒"的味道：$\dim\mathrm{C}(A)+\dim\mathrm{N}(A)=n$。为什么？把 A 看成机器，输入空间 $\mathbb{R}^n$ 被分成两拨：**被压到原点的方向**（就是 $\mathrm{N}(A)$）和**独立活下来的方向**（数量等于秩 $r=\dim\mathrm{C}(A)$）。机器不会"无中生有"活下来的维度（所以 $r\le n$），也不会漏掉维度（所以 $r+\dim\mathrm{N}(A)=n$，秩–零化度定理）。本讲先用 2×2、3×3 的小例子把这种感觉建立起来，讲次 10 会给出一般证明。另一个重要副产品：对 2×2 秩 1 矩阵，$\mathrm{C}(A)$ 与 $\mathrm{N}(A)$ 在这个例子里恰好垂直，但**这不是普适规律**（在实例 2 的 3×3 里 $\mathrm{C}(A)\cap\mathrm{N}(A)=\{\mathbf{0}\}$ 但两者并不互相正交，因为 $[1,2,1]$ 与 $[1,2,3]$ 点积 $=1+4+3=8\neq 0$）。真正的正交配对是 $\mathrm{N}(A)\perp\mathrm{C}(A^{\mathsf{T}})$。

示例 3：3×3 秩 1 矩阵——把 A 写成外积 $\mathbf{u}\mathbf{v}^{\mathsf{T}}$，一眼看穿 C(A) 与 N(A)

取

$$A=\begin{bmatrix}1 & 2 & 3\\ 2 & 4 & 6\\ 1 & 2 & 3\end{bmatrix}.$$

步骤 1（发现外积结构）：观察各行都是 $[1,2,3]$ 的倍数（第 1、3 行 $=1\times[1,2,3]$，第 2 行 $=2\times[1,2,3]$），各列都是 $[1,2,1]$ 的倍数（第 2 列 $=2\times$，第 3 列 $=3\times$）。于是令

$$\mathbf{u}=\begin{bmatrix}1\\ 2\\ 1\end{bmatrix},\qquad \mathbf{v}=\begin{bmatrix}1\\ 2\\ 3\end{bmatrix},\qquad A=\mathbf{u}\mathbf{v}^{\mathsf{T}}=\begin{bmatrix}1\\ 2\\ 1\end{bmatrix}\begin{bmatrix}1 & 2 & 3\end{bmatrix}=\begin{bmatrix}1 & 2 & 3\\ 2 & 4 & 6\\ 1 & 2 & 3\end{bmatrix}\ \checkmark$$

步骤 2（用外积写出 $A\mathbf{x}$）：

$$A\mathbf{x}=\mathbf{u}\mathbf{v}^{\mathsf{T}}\mathbf{x}=\mathbf{u}\,(\mathbf{v}\cdot\mathbf{x})=(x_1+2x_2+3x_3)\begin{bmatrix}1\\ 2\\ 1\end{bmatrix}.$$

步骤 3（直接读出列空间）：输出永远是 $\mathbf{u}=\begin{bmatrix}1\\ 2\\ 1\end{bmatrix}$ 的倍数，倍数由标量 $x_1+2x_2+3x_3$ 决定。所以

$$\mathrm{C}(A)=\left\{s\begin{bmatrix}1\\ 2\\ 1\end{bmatrix}:s\in\mathbb{R}\right\},\qquad \dim\mathrm{C}(A)=1.$$

步骤 4（直接读出零空间）：$A\mathbf{x}=\mathbf{0}\iff\mathbf{v}\cdot\mathbf{x}=0\iff x_1+2x_2+3x_3=0$。这是 $\mathbb{R}^3$ 中**过原点、以 $\mathbf{v}=[1,2,3]$ 为法向量的一张平面**。取两个线性无关的解：

- 令 $x_2=1,x_3=0$：$x_1=-2$，得 $\mathbf{s}_1=\begin{bmatrix}-2\\ 1\\ 0\end{bmatrix}$；
- 令 $x_2=0,x_3=1$：$x_1=-3$，得 $\mathbf{s}_2=\begin{bmatrix}-3\\ 0\\ 1\end{bmatrix}$。

$$\mathrm{N}(A)=\mathrm{span}\{\mathbf{s}_1,\mathbf{s}_2\},\qquad \dim\mathrm{N}(A)=2.$$

步骤 5（验算，一个个代入）：

$$A\mathbf{s}_1=\begin{bmatrix}1(-2)+2(1)+3(0)\\ 2(-2)+4(1)+6(0)\\ 1(-2)+2(1)+3(0)\end{bmatrix}=\begin{bmatrix}0\\ 0\\ 0\end{bmatrix}\ \checkmark\qquad A\mathbf{s}_2=\begin{bmatrix}1(-3)+2(0)+3(1)\\ 2(-3)+4(0)+6(1)\\ 1(-3)+2(0)+3(1)\end{bmatrix}=\begin{bmatrix}0\\ 0\\ 0\end{bmatrix}\ \checkmark$$

步骤 6（维数核对）：$\dim \mathrm{C}(A) + \dim \mathrm{N}(A) = 1 + 2 = 3 = n$ ✓。触发"压扁"的维数是 2，因为 A 的秩只有 1，其余 $3 - 1 = 2$ 个维度全被碾平。

【计算机制解说】：为什么秩 1 矩阵的零空间必然是 $n-1$ 维的"超平面"？因为秩 1 矩阵一定可以写成 $\mathbf{u}\mathbf{v}^{\mathsf{T}}$（$\mathbf{u} \neq \mathbf{0}, \mathbf{v} \neq \mathbf{0}$），于是 $A\mathbf{x} = \mathbf{u}(\mathbf{v}^{\mathsf{T}}\mathbf{x})$ 是一个**标量乘以固定向量**。它等于 $\mathbf{0}$ 当且仅当那个标量 $\mathbf{v}^{\mathsf{T}}\mathbf{x} = 0$。而 $\mathbf{v}^{\mathsf{T}}\mathbf{x} = 0$ 是一个**齐次线性方程**，它的解集是 $\mathbf{v}$ 的正交补，维数 $n-1$（在 $\mathbb{R}^3$ 里就是一张平面）。这个推导不需要任何消元就能看出全部几何——**这就是"无消元也能看出的道理"的第一个样板**：秩 1 矩阵把整个 $\mathbb{R}^n$ 压缩成一条线，只有与 $\mathbf{v}$ 垂直的那些方向被彻底压没了（用几何的话说：沿 $\mathbf{v}$ 方向的输入只是被缩放，垂直于 $\mathbf{v}$ 的输入被灭掉）。另外要特别注意：这里的 $A = \mathbf{u}\mathbf{v}^{\mathsf{T}} = \begin{bmatrix}1\\2\\1\end{bmatrix}\begin{bmatrix}1 & 2 & 3\end{bmatrix}$ **不是对称矩阵**（$\mathbf{u} = \begin{bmatrix}1\\2\\1\end{bmatrix} \neq \mathbf{v} = \begin{bmatrix}1\\2\\3\end{bmatrix}$，核对 $A_{13} = 3$ 而 $A_{31} = 1$），所以 $\mathrm{C}(A)$ **不**垂直于 $\mathrm{N}(A)$：$\mathrm{C}(A)$ 方向 $[1,2,1]$ 与零空间法向量 $[1,2,3]$ 的点积是 $1+4+3 = 8 \neq 0$。真正的正交关系是 $\mathrm{N}(A) \perp \mathrm{C}(A^{\mathsf{T}})$（行空间），本例中行空间方向正是 $[1,2,3]$，即零空间平面的法向量。**只有 A 对称时行空间才等于列空间**——示例 2 的 $\begin{bmatrix}1 & 2\\2 & 4\end{bmatrix}$ 确实对称（$A_{12} = A_{21} = 2$），所以那里 $\mathrm{C}(A) \perp \mathrm{N}(A)$ 成立。

示例 4：一个零空间中只有零的矩阵（列无关的样板）

$$B = \begin{bmatrix}1 & 2\\3 & 7\end{bmatrix}.$$

步骤 1（行列式）：$\det B = 1 \cdot 7 - 2 \cdot 3 = 1 \neq 0$，所以 B 可逆，秩 $r = 2 = n$。

步骤 2（解 $B\mathbf{x} = \mathbf{0}$）：用消元：$R_2 \leftarrow R_2 - 3R_1$ 得 $\begin{bmatrix}1 & 2\\0 & 1\end{bmatrix}$，回代 $x_2 = 0$，再 $x_1 = 0$。所以 $\mathrm{N}(B) = \{\mathbf{0}\}$。

步骤 3（列空间）：两列 $\begin{bmatrix}1\\3\end{bmatrix}, \begin{bmatrix}2\\7\end{bmatrix}$ 不共线，所以 $\mathrm{C}(B) = \mathbb{R}^2$ 全体。$\dim \mathrm{C}(B) = 2$，$\dim \mathrm{N}(B) = 0$，$2 + 0 = 2 = n$ ✓。

结论对照：B 是"不丢信息"的机器——每个输出 $\mathbf{b} \in \mathbb{R}^2$ 恰好对应唯一输入。而示例 2 的 A 是"丢信息"的机器——$\mathrm{C}(A)$ 只占 $\mathbb{R}^2$ 的一条线，并且每个在 C(A) 里的输出都有无穷多个输入（差一个零空间向量）。

示例 5：2×3 矩阵——"矮胖"矩阵也能把 C(A) 与 N(A) 的关系算穿

前面的例子都是方阵或"高瘦"矩阵，这里换一个"矮胖"的 2×3，看看哪些结论会变、哪些不变：

$$A = \begin{bmatrix}1 & 2 & 3\\2 & 4 & 7\end{bmatrix}.$$

步骤 1（消元）：乘数 $\ell_{21} = 2/1 = 2$，$R_2 \leftarrow R_2 - 2R_1$：

$$R_2 = (2,4,7) - 2(1,2,3) = (0,\ 4-4,\ 7-6) = (0,0,1).$$

于是行阶梯形与 RREF 都是

$$U = R = \begin{bmatrix}1 & 2 & 3\\0 & 0 & 1\end{bmatrix} \xrightarrow{R_1 \leftarrow R_1 - 3R_2} \begin{bmatrix}1 & 2 & 0\\0 & 0 & 1\end{bmatrix}.$$

步骤 2（认列）：主元在第 1、3 列，**自由列是第 2 列**，$r = 2$，$n = 3$，所以 $\dim \mathrm{N}(A) = 3 - 2 = 1$。这里出现了本讲第一个"自由列**夹在两个主元列中间**"的情形，提醒我们"自由列不一定排在末尾"（下面示例 6、L7 的示例 4 还会遇到自由列在开头的情形）。

步骤 3（求零空间）：RREF 给

$$\begin{cases} x_1 + 2x_2 = 0 \\ x_3 = 0 \end{cases} \quad \Longrightarrow \quad \begin{cases} x_1 = -2x_2 \\ x_3 = 0 \end{cases}$$

令自由变量 $x_2 = 1$：

$$\mathbf{s} = \begin{bmatrix}-2\\1\\0\end{bmatrix}, \qquad \mathrm{N}(A) = \left\{ t\begin{bmatrix}-2\\1\\0\end{bmatrix} \right\}.$$

步骤 4（验算）：

$$A\mathbf{s} = \begin{bmatrix}1(-2) + 2(1) + 3(0)\\2(-2) + 4(1) + 7(0)\end{bmatrix} = \begin{bmatrix}0\\0\end{bmatrix} \checkmark$$

步骤 5（列空间）：$r = 2 = m$（行满秩！），两行线性无关，所以 $\mathrm{C}(A)$ 张满整个 $\mathbb{R}^2$，$\dim \mathrm{C}(A) = 2$。**无论 $\mathbf{b}$ 取什么，$A\mathbf{x} = \mathbf{b}$ 都有解**（下一讲的可解性判据在这里已经能看出：不存在会退化成 $0 = c$ 的行）。

步骤 6（解集形状：本讲的"半成品"公式实测）：以 $\mathbf{b} = \begin{bmatrix}3\\5\end{bmatrix}$ 为例。消元（对增广矩阵）：

```
[ 1  2  3 | 3 ]  R2 -= 2*R1  ->  [ 1  2  3 | 3 ]
[ 2  4  7 | 5 ]                 [ 0  0  1 | -1 ]
```

第二个方程给出 $x_3 = -1$；代回第一个方程 $x_1 + 2x_2 - 3 = 3$，即 $x_1 + 2x_2 = 6$。令自由变量 $x_2 = 0$，得特解

$$\mathbf{x}_p = \begin{bmatrix} 6 \\ 0 \\ -1 \end{bmatrix}, \qquad A\mathbf{x}_p = \begin{bmatrix} 6+0-3 \\ 12+0-7 \end{bmatrix} = \begin{bmatrix} 3 \\ 5 \end{bmatrix} = \mathbf{b} \checkmark$$

全部解是

$$\mathbf{x} = \mathbf{x}_p + t\mathbf{s} = \begin{bmatrix} 6-2t \\ t \\ -1 \end{bmatrix}, \qquad t \in \mathbb{R}.$$

抽查：$t = 1$ 给 $\mathbf{x} = \begin{bmatrix} 4 \\ 1 \\ -1 \end{bmatrix}$，$A\mathbf{x} = \begin{bmatrix} 4+2-3 \\ 8+4-7 \end{bmatrix} = \begin{bmatrix} 3 \\ 5 \end{bmatrix}$ ✓；$t = -3$ 给 $\begin{bmatrix} 12 \\ -3 \\ -1 \end{bmatrix}$，$A\mathbf{x} = \begin{bmatrix} 12-6-3 \\ 24-12-7 \end{bmatrix} = \begin{bmatrix} 3 \\ 5 \end{bmatrix}$ ✓；$t = 2.5$ 给 $\begin{bmatrix} 1 \\ 2.5 \\ -1 \end{bmatrix}$，$A\mathbf{x} = \begin{bmatrix} 1+5-3 \\ 2+10-7 \end{bmatrix} = \begin{bmatrix} 3 \\ 5 \end{bmatrix}$ ✓。**三个不同输入、同一个输出——这正是"零空间里的方向被压没了"的物理含义。**

步骤 7（几何图景）：$\mathbf{N}(A)$ 是 $\mathbb{R}^3$ 中沿 $\begin{bmatrix} -2 \\ 1 \\ 0 \end{bmatrix}$ 的过原点直线；解集 $\mathbf{x}_p + \mathbf{N}(A)$ 是**平行于这条直线、但不过原点**的直线（它穿过 $\mathbf{x}_p$）。

```
R^3 中的图景（把 N(A) 画成一条线，解集是它的平移）

      N(A): 过原点，方向 [-2,1,0]
        .
       /
      /          <-- x_p + N(A): 平行但不过原点
     /                (b != 0 的解集，不是子空间)
----+------>  x_p = [6,0,-1] 落在这条平移线上
   /
  /

要点：零空间过原点；非齐次解集是它的"平移副本"，整体不过原点。
```

【计算机制解说】：这个例子把上一讲的"半成品公式"用活了。解集 $= \mathbf{x}_p + \mathbf{N}(A)$ 之所以成立，是因为若 $\mathbf{x}$ 和 $\mathbf{x}_p$ 都是解，则

$$A(\mathbf{x} - \mathbf{x}_p) = A\mathbf{x} - A\mathbf{x}_p = \mathbf{b} - \mathbf{b} = \mathbf{0} \implies \mathbf{x} - \mathbf{x}_p \in \mathbf{N}(A) \implies \mathbf{x} = \mathbf{x}_p + \mathbf{s},\ \mathbf{s} \in \mathbf{N}(A).$$

两条信息各司其职：特解 $\mathbf{x}_p$ 负责"落到目标平面上"（存在性），零空间 $\mathbf{N}(A)$ 负责"在这张平面上自由滑动"（不唯一性）。所以 $A\mathbf{x} = \mathbf{b}$ 的解集维数恒等于 $\dim \mathbf{N}(A) = n - r$；本例是 $3 - 2 = 1$，一条直线。另外注意本例中 $\dim \mathbf{C}(A) = 2$、$\dim \mathbf{N}(A) = 1$，"输出空间被张满、输入空间丢一维"两者并不矛盾——它们是**不同空间**里的维数。

示例 6：3×3 秩 2 矩阵——零空间是"行空间的正交补"

前面几个例子的秩都是 1，几何比较退化。这一个秩 2，是"零空间是 1 维、列空间是 2 维平面"的样板，也是第一次能看出**行空间与零空间正交**的小例子。

$$A = \begin{bmatrix} 1 & 2 & 3 \\ 2 & 5 & 8 \\ 1 & 3 & 5 \end{bmatrix}.$$

步骤 1（消元）：$R_2 \leftarrow R_2 - 2R_1$，$R_3 \leftarrow R_3 - R_1$：

$$R_2 = (2,5,8) - 2(1,2,3) = (0,1,2), \qquad R_3 = (1,3,5) - (1,2,3) = (0,1,2).$$

然后 $R_3 \leftarrow R_3 - R_2$：

$$U = \begin{bmatrix} 1 & 2 & 3 \\ 0 & 1 & 2 \\ 0 & 0 & 0 \end{bmatrix}.$$

步骤 2（化到 RREF）：$R_1 \leftarrow R_1 - 2R_2$：$(1,2,3) - 2(0,1,2) = (1,0,-1)$。

$$R = \begin{bmatrix} 1 & 0 & -1 \\ 0 & 1 & 2 \\ 0 & 0 & 0 \end{bmatrix}.$$

步骤 3（读数）：主元列 $= \{1,2\}$，自由列 $= \{3\}$，$r = 2$，$\dim \mathbf{N}(A) = 3 - 2 = 1$，$\dim \mathbf{C}(A) = 2$。RREF 给出

$$\begin{cases} x_1 - x_3 = 0 \\ x_2 + 2x_3 = 0 \end{cases} \Longrightarrow \begin{cases} x_1 = x_3 \\ x_2 = -2x_3 \end{cases} \Longrightarrow \mathbf{s} = \begin{bmatrix} 1 \\ -2 \\ 1 \end{bmatrix} \ (x_3 = 1).$$

步骤 4（验算）：

$$A\mathbf{s} = \begin{bmatrix} 1(1)+2(-2)+3(1) \\ 2(1)+5(-2)+8(1) \\ 1(1)+3(-2)+5(1) \end{bmatrix} = \begin{bmatrix} 1-4+3 \\ 2-10+8 \\ 1-6+5 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix} \checkmark$$

步骤 5（几何：A 的列空间是一张平面，$N(A)$ 是一条直线）：三列是 $\mathbf{a}_1 = \begin{bmatrix} 1 \\ 2 \\ 1 \end{bmatrix}$、$\mathbf{a}_2 = \begin{bmatrix} 2 \\ 5 \\ 3 \end{bmatrix}$、$\mathbf{a}_3 = \begin{bmatrix} 3 \\ 8 \\ 5 \end{bmatrix}$。三者有关系 $\mathbf{a}_1 - 2\mathbf{a}_2 + \mathbf{a}_3 = \mathbf{0}$（正是 $\mathbf{s}$ 告诉我们的话），即 $\mathbf{a}_3 = 2\mathbf{a}_2 - \mathbf{a}_1 = \begin{bmatrix} 4-1 \\ 10-2 \\ 6-1 \end{bmatrix} = \begin{bmatrix} 3 \\ 8 \\ 5 \end{bmatrix}$ ✓。所以 $\mathbf{C}(A) = \mathbf{span}\{\mathbf{a}_1, \mathbf{a}_2\}$ 是 $\mathbb{R}^3$ 中过原点的平面，其法向量为

$$\mathbf{n} = \mathbf{a}_1 \times \mathbf{a}_2 = \begin{bmatrix} 2\cdot 3 - 1\cdot 5 \\ 1\cdot 2 - 1\cdot 3 \\ 1\cdot 5 - 2\cdot 2 \end{bmatrix} = \begin{bmatrix} 1 \\ -1 \\ 1 \end{bmatrix},$$

即 $\mathbf{C}(A)$ 是平面 $x_1 - x_2 + x_3 = 0$。**这是检验 $\mathbf{b} \in \mathbf{C}(A)$ 的第三种方法**（前两种是消元法和"能否被主元列组合"）。

步骤 6（三次交叉核对同一个结论）：

方法	结论
消元法（把 $\mathbf{b} = \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix}$ 放进增广矩阵）	$R_3 \leftarrow R_3 - R_2$ 后得 $\begin{bmatrix} 0&0&0 \end{bmatrix}$
平面方程 $x_1 - x_2 + x_3 = 0$	$1 - 1 + 1 = 1 \neq 0$ → **不在** C(A)
取 $\mathbf{b} = \mathbf{a}_1 = \begin{bmatrix} 1 \\ 2 \\ 1 \end{bmatrix}$ 对照	$1 - 2 + 1 = 0$ → **在** C(A)（当然，它就是第一列）

步骤 7（关键的正交关系：$N(A) \perp C(A^{\mathsf{T}})$）：$A$ 的行是 $\begin{bmatrix} 1 & 2 & 3 \end{bmatrix}$ 与 $\begin{bmatrix} 2 & 5 & 8 \end{bmatrix}$（第 3 行是前两行之和，不贡献新方向），所以**行空间** $\mathbf{C}(A^{\mathsf{T}}) = \mathbf{span}\{[1,2,3],[2,5,8]\}$，这是 $\mathbb{R}^3$ 中的平面（**住在输入空间里**，因为行向量长度是 $n = 3$）。它的法向量是

$$[1,2,3] \times [2,5,8] = \begin{bmatrix} 2\cdot 8 - 3\cdot 5 \\ 3\cdot 2 - 1\cdot 8 \\ 1\cdot 5 - 2\cdot 2 \end{bmatrix} = \begin{bmatrix} 1 \\ -2 \\ 1 \end{bmatrix}.$$

这正是我们的零空间方向 $\mathbf{s}$！ 直接点积验证：

$$\mathbf{s} \cdot [1,2,3] = 1 - 4 + 3 = 0 \checkmark \qquad \mathbf{s} \cdot [2,5,8] = 2 - 10 + 8 = 0 \checkmark$$

所以 $\mathbf{N}(A)$ 恰好是**行空间的正交补**：$\mathbf{N}(A) \perp \mathbf{C}(A^{\mathsf{T}})$。这就是本课程最重要的正交关系在 3×3 上的第一次亮相（讲次 14 会正式证明）。

步骤 8（一个反面提醒）：$\mathbf{N}(A)$ **并不**垂直于 $\mathbf{C}(A)$！核对：

$$\mathbf{s} \cdot \mathbf{a}_1 = 1(1) + (-2)(2) + 1(1) = 1 - 4 + 1 = -2 \neq 0, \qquad \mathbf{s} \cdot \mathbf{a}_2 = 2 - 10 + 3 = -5 \neq 0.$$

教训：$\mathbf{N}(A)$ 垂直于**行空间**（$\mathbf{C}(A^{\mathsf{T}})$），不垂直于列空间（$\mathbf{C}(A)$）。这两件事在讲次 10 的四子空间图里会画成两条不同的直角关系。只有当 A 对称时，行空间与列空间重合，两者才"看起来一样"——这也解释了为什么前面那些**对称**的秩 1 例子里 $\mathbf{C}(A) \perp \mathbf{N}(A)$ 成立，而本例（A 不对称）不成立。

示例 7：3×2 矩阵 $E = \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 0 & 0 \end{bmatrix}$ ——"高瘦"矩阵：零空间只有零，但列空间只是平面

步骤 1（看列）：两列 $\begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}$ 与 $\begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}$ 线性无关，$r = 2 = n$。

步骤 2（零空间）：$E\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ 0 \end{bmatrix} = \mathbf{0}$ 要求 $x_1 = x_2 = 0$，所以 $\mathbf{N}(E) = \{\mathbf{0}\}$，$\dim \mathbf{N}(E) = 2 - 2 = 0$。**没有自由变量、没有特殊解、没有主元以外的列。**

步骤 3（列空间）：$\mathbf{C}(E)=\operatorname{span}\left\{\begin{bmatrix}1\\0\\0\end{bmatrix},\begin{bmatrix}0\\1\\0\end{bmatrix}\right\}$ = $\mathbb{R}^3$ 中的 xy 平面，$\dim\mathbf{C}(E)=2<3=m$。**注意"列无关"并不等于"列空间是整个 $\mathbb{R}^3$"**——两列只能张出 2 维，缺的那一维（z 轴）永远造不出来。

步骤 4（对照转置的零空间）：$E^{\mathsf{T}}=\begin{bmatrix}1&0&0\\0&1&0\end{bmatrix}$（$2\times3$）。$E^{\mathsf{T}}\mathbf{x}=\begin{bmatrix}x_1\\x_2\end{bmatrix}=\mathbf{0}$ 只要求 $x_1=x_2=0$，x_3 完全自由，所以

$$\mathbf{N}(E^{\mathsf{T}})=\operatorname{span}\left\{\begin{bmatrix}0\\0\\1\end{bmatrix}\right\}(z\text{ 轴}),\qquad \dim\mathbf{N}(E^{\mathsf{T}})=m-r=3-2=1\ \checkmark$$

两条信息的合读：E^{T} 的零空间方向 $\begin{bmatrix}0\\0\\1\end{bmatrix}$ 恰是 E **造不出来的那个方向**——这正是"$\mathbb{R}^m=\mathbf{C}(A)\oplus\mathbf{N}(A^{\mathsf{T}})$"的几何含义（讲次 10 的主题）：输出空间被"能造出来的部分"和"永远造不出来的部分"正交地一分为二。

四个基本子空间的维数一览（懒人表，全部按 $A:m\times n$、秩 r 计算）

```
子空间              符号        宿主空间        维数        直观含义
------------------------------------------------------------------------------
列空间              C(A)        R^m (输出)      r           A 能生成的全部输出
零空间              N(A)        R^n (输入)      n - r       被 A 压成 0 的全部输入
行空间              C(A^T)      R^n (输入)      r           各行张成的方向 (= 活下来的输入部分)
左零空间            N(A^T)      R^m (输出)      m - r       "造不出来"的输出方向
------------------------------------------------------------------------------
必然成立:  dim C(A) = dim C(A^T) = r
           dim N(A) + dim C(A^T) = (n-r) + r = n     ->  R^n = C(A^T) 直和 N(A)
           dim N(A^T) + dim C(A) = (m-r) + r = m     ->  R^m = C(A)  直和 N(A^T)
正交关系:  N(A) ⊥ C(A^T)  且  N(A^T) ⊥ C(A)          (讲次 14 正式证明)
```

用示例 6 的 A（3×3，$r=2$）代入检验：$\dim\mathbf{C}(A)=2$，$\dim\mathbf{N}(A)=1$，$\dim\mathbf{C}(A^{\mathsf{T}})=2$，$\dim\mathbf{N}(A^{\mathsf{T}})=3-2=1$；且 $2+1=3=n$ ✓、$1+2=3=m$ ✓。用示例 7 的 E（3×2，$r=2$）：$\dim\mathbf{C}(E)=2$、$\dim\mathbf{N}(E)=0$、$\dim\mathbf{C}(E^{\mathsf{T}})=2$、$\dim\mathbf{N}(E^{\mathsf{T}})=1$；$2+0=2=n$ ✓、$1+2=3=m$ ✓。

示例 8：$\mathbf{b}\in\mathbf{C}(A)$ 的三把尺子（总结成可复用的检查清单）

给定 A 与 $\mathbf{b}$，判断 $A\mathbf{x}=\mathbf{b}$ 是否有解，有三个等价途径，任选一把：

1. **消元尺（最通用）**：写增广矩阵 $[A\ \ \mathbf{b}]$，消元。出现形如 $[0\ \cdots\ 0\ \mid\ c]$ 且 $c\neq0$ 的行 $\Rightarrow$ **无解**；否则有解。依据：行变换保持解集不变。
2. **列组合尺（最本质）**：看 $\mathbf{b}$ 能否写成 A 各列的线性组合。等价的实用写法是"**$\mathbf{b}$ 是否能由主元列组合出来**"，系数就是下一讲要算的特解 $\mathbf{x}_p$ 的主元分量。
3. **正交尺（最优雅，但要多算一步）**：先求出 $\mathbf{N}(A^{\mathsf{T}})$（左零空间）的一组基 $\mathbf{y}_1,\dots,\mathbf{y}_{m-r}$，然后检查 $\mathbf{y}_k\cdot\mathbf{b}=0$ 是否对每个 k 都成立。全部成立 $\Rightarrow$ 有解。依据：$\mathbf{C}(A)^{\perp}=\mathbf{N}(A^{\mathsf{T}})$，即"$\mathbf{b}$ 与所有左零向量正交"$\Leftrightarrow$"$\mathbf{b}$ 落在列空间里"。

用示例 6 的 A 实测第三把尺子：$\mathbf{N}(A^{\mathsf{T}})$ 是 $\mathbb{R}^3$ 中左零空间，维数 $m-r=3-2=1$。求它：解 $A^{\mathsf{T}}\mathbf{y}=\mathbf{0}$，即

$$\begin{cases}y_1+2y_2+y_3=0\\2y_1+5y_2+3y_3=0\end{cases}$$

第二式减 $2\times$第一式：$y_2+y_3=0$，即 $y_2=-y_3$；代回第一式：$y_1+2(-y_3)+y_3=0$，即 $y_1=y_3$。所以 $\mathbf{N}(A^{\mathsf{T}})=\operatorname{span}\left\{\begin{bmatrix}1\\-1\\1\end{bmatrix}\right\}$——**正是列空间平面的法向量 $\mathbf{n}$**（与步骤 5 的叉积结果一致）。于是

$$\mathbf{b}\in\mathbf{C}(A)\iff\begin{bmatrix}1\\-1\\1\end{bmatrix}\cdot\mathbf{b}=0\iff b_1-b_2+b_3=0,$$

与步骤 5 的平面方程完全吻合 ✓。**第三把尺子的价值**：当 A 的行数远大于列数（很多方程、很少未知数）时，算 $\mathbf{N}(A^{\mathsf{T}})$ 可能比消元整个增广矩阵更省事；它也是最小二乘"正规方程残差"的理论来源（残差 $\mathbf{b}-A\hat{\mathbf{x}}\in\mathbf{N}(A^{\mathsf{T}})$，讲次 16）。

三条信息的内在联系（把这四种空间"缝"在一起）

最后用一张"关系网络"图把本讲所有概念收束起来。注意箭头两侧的空间维度不同，任何运算都必须先问"我在哪个空间里"：

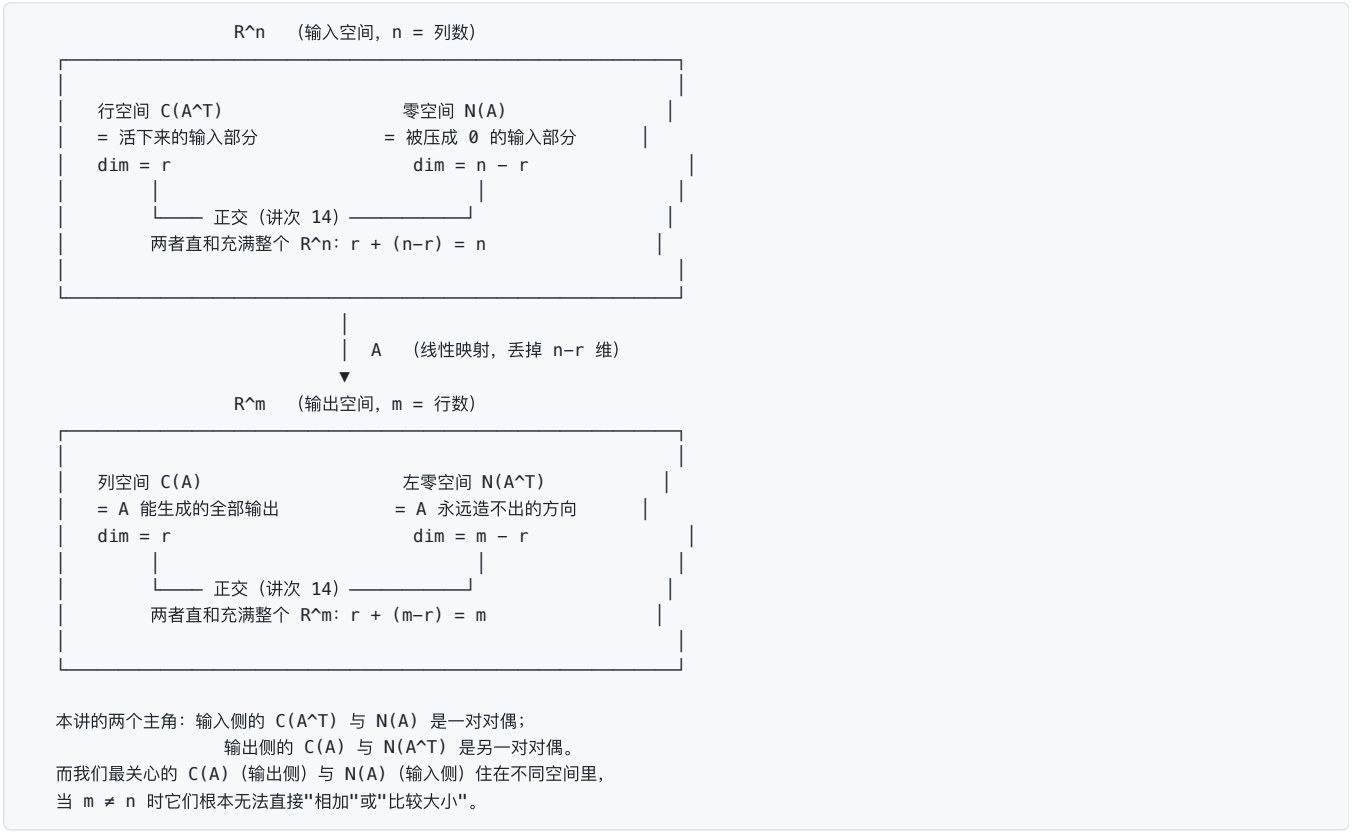

这张图要背下来。 它是整个 18.06 后半程的坐标系：讲次 8 的解集公式 $\mathbf{x}_p + \mathbf{N}(A)$ 说的是"先落进输出侧的 $\mathbf{C}(A)$，再沿输入侧的 $\mathbf{N}(A)$ 滑动"；讲次 14 的投影说的是"把不在 $\mathbf{C}(A)$ 里的 $\mathbf{b}$ 正交投影进去"；讲次 16 的最小二乘说的是"用 $\mathbf{C}(A)$ 上的最近点代替无解的 $\mathbf{b}$"；讲次 29 的 SVD 说的是"用两组正交基把这四个空间同时对角化"。

矩阵分解的核心思想

- **秩 1 分解 $A = \mathbf{u}\mathbf{v}^{\mathsf{T}}$（外积分解）**：本讲示例 3 已经把 $A = \begin{bmatrix}1\\2\\1\end{bmatrix}\begin{bmatrix}1 & 2 & 3\end{bmatrix}$ 算穿。这是"积木分解"的最小单元：秩 r 的矩阵可以写成 r 个秩 1 外积之和 $A = \sum_{k=1}^{r} \mathbf{u}_k \mathbf{v}_k^{\mathsf{T}}$。这个视角会在讲次 11 被系统化为 $A = \mathbf{C}\mathbf{R}$（C 取 A 的 r 个主元列，R 取消元后 R 的前 r 行），并在讲次 29 的 SVD 里以"最优的一组秩 1 积木"的面目回归。
- **$A = \mathbf{C}\mathbf{R}$（列 × 行，讲次 11 正式登场）**：本讲其实已经用到它了。对示例 1/3 的 A，主元列只有 1 列 $\mathbf{a}_1 = \begin{bmatrix}1\\2\\1\end{bmatrix}$，而 $R = \begin{bmatrix}1 & 2 & 3\end{bmatrix}$ 是"每列在主元列坐标下的系数"，于是 $A = \mathbf{a}_1 R = \mathbf{u}\mathbf{v}^{\mathsf{T}}$。**关键认识**：$R$ 的第 2、3 列（$\mathbf{2}$ 和 $\mathbf{3}$）恰好告诉我们"第 2、3 列 = 2 倍、3 倍第 1 列"。R 记录的就是**列之间的线性关系**——这就是为什么消元（行变换）虽然改变列空间，却不破坏列关系。
- **$A = \mathbf{L}\mathbf{U}$（讲次 4–5 已引入）**：消元是求零空间的引擎。$A = \mathbf{L}\mathbf{U}$ 说明消元是可逆的线性组合过程；因为 $\mathbf{L}$ 可逆，$A\mathbf{x} = \mathbf{0} \iff \mathbf{U}\mathbf{x} = \mathbf{0}$，所以 $\mathbf{N}(A) = \mathbf{N}(\mathbf{U})$——**列空间被消元改变了，但零空间丝毫不动**。这是下一讲整个算法的合法性的基石。
- **为什么零空间如此"抗消元"？** 因为消元是**左乘可逆矩阵**：$E_k \cdots E_1 A = U$，记 $L^{-1} = E_k \cdots E_1$，则 $\mathbf{U} = L^{-1}A$。于是 $A\mathbf{x} = \mathbf{0} \iff L^{-1}A\mathbf{x} = \mathbf{0} \iff \mathbf{U}\mathbf{x} = \mathbf{0}$（左乘可逆矩阵不改变解集）。而对**列空间**：$\mathbf{C}(\mathbf{U}) \neq \mathbf{C}(A)$ 一般是错的——例如示例 1 中 $\mathbf{C}(A)$ 是沿 $[1,2,1]$ 的线，而 $\mathbf{C}(\mathbf{U})$ 是沿 $[1,0,0]$ 的线（x 轴）。**同一份列关系，不同的列空间，同一个零空间。** 这句话值得抄在笔记本第一页。

与其他讲次的关联

- **与讲次 4–5（消元、$A = \mathbf{L}\mathbf{U}$、转置）**：本讲把消元从"解方程的工具"升级为"探测子空间结构的探针"；消元产生的**主元个数**就是秩，也是 $\dim \mathbf{C}(A)$。转置 A^{T} 在本讲已露头：$\mathbf{C}(A^{\mathsf{T}})$ 叫做行空间，它住在 $\mathbb{R}^n$（**不是** $\mathbb{R}^m$！常见错误），是讲次 10 的四个基本子空间之一。
- **与讲次 7（本文件下一讲）**：本讲把 $\mathbf{N}(A)$ 定义清楚了，但还没有给出**系统算法**。下一讲给出完整流程：消元到 U / RREF → 认主元列与自由列 → 自由变量轮流取 1 得**特殊解** → $\mathbf{N}(A) = \mathbf{span}\{\text{特殊解}\}$，并证明 $\dim \mathbf{N}(A) = n - r$。
- **与讲次 8（求解 $A\mathbf{x} = \mathbf{b}$）**：本讲的核心等价"有解 $\iff \mathbf{b} \in \mathbf{C}(A)$"和"解集 = 特解 + $\mathbf{N}(A)$"会在下一讲被做成完整的可解性判据（$\mathbf{b}$ 的可解性只看 $\mathbf{b}$ 是否与各行的组合相容，即 $\mathbf{b} \perp \mathbf{N}(A^{\mathsf{T}})$）。
- **与讲次 9（线性无关、基、维数）**：本讲结尾的判据"$\mathbf{N}(A) = \{\mathbf{0}\} \iff$ 列无关 $\iff r = n$"就是讲次 9 的主题；届时"基"这个词会被正式定义，而 $\{\mathbf{s}_1, \mathbf{s}_2\}$ 将被称为 $\mathbf{N}(A)$ 的一组基。

- **与讲次 10（四个基本子空间）**：本讲的两个空间（C(A) 在 $\mathbb{R}^m$、N(A) 在 $\mathbb{R}^n$）加上它们的转置伙伴（$\mathbf{C}(A^{\mathsf{T}})$ 在 $\mathbb{R}^n$、$\mathbf{N}(A^{\mathsf{T}})$ 在 $\mathbb{R}^m$）构成课程的统一框架：$\dim \mathbf{C}(A) = \dim \mathbf{C}(A^{\mathsf{T}}) = r$，$\dim \mathbf{N}(A) = n - r$，$\dim \mathbf{N}(A^{\mathsf{T}}) = m - r$，且 $\mathbb{R}^n = \mathbf{C}(A^{\mathsf{T}}) \oplus \mathbf{N}(A)$、$\mathbb{R}^m = \mathbf{C}(A) \oplus \mathbf{N}(A^{\mathsf{T}})$。
- **与讲次 14–17（正交、投影、最小二乘）**：$\mathbf{N}(A) \perp \mathbf{C}(A^{\mathsf{T}})$ 是正交章节的地基。本讲示例 3 里"零空间平面的法向量 $[1,2,3]$ 恰好是行空间方向"就是这个定理的 3×3 可视化。当 $A\mathbf{x} = \mathbf{b}$ 无解时，我们退而求其次解 $A^{\mathsf{T}}A\hat{\mathbf{x}} = A^{\mathsf{T}}\mathbf{b}$，其几何意义正是"把 $\mathbf{b}$ 投影到 $\mathbf{C}(A)$ 上"；投影误差 $\mathbf{b} - A\hat{\mathbf{x}}$ 落在 $\mathbf{C}(A)^{\perp} = \mathbf{N}(A^{\mathsf{T}})$ 里。
- **与讲次 21–25（特征值）**：$\mathbf{N}(A - \lambda I)$ 就是"特征空间"——本讲的零空间就是 $\lambda = 0$ 时的特征空间。因此 $\dim \mathbf{N}(A) > 0 \iff A$ 有特征值 $0 \iff A$ 奇异。
- **与讲次 11–12（矩阵空间、图与网络）**：图的关联矩阵的零空间维数就是"连通分支数"，这是 A 的零空间最有画面感的应用之一。

关键要点

1. **子空间的三件事**：过原点 + 对加法封闭 + 对数乘封闭（后两条合起来 = 对线性组合封闭）。$\mathbb{R}^3$ 的子空间只有点、过原点直线、过原点平面、整个 $\mathbb{R}^3$ 四类。
2. **两个空间的地位**：$\mathbf{C}(A) \subseteq \mathbb{R}^m$ 由**列**张成（每个列向量长 m，由行数决定）；$\mathbf{N}(A) \subseteq \mathbb{R}^n$ 由 $A\mathbf{x} = \mathbf{0}$ 定义（$\mathbf{x}$ 长 n，由列数决定）。**列空间的宿主维数是行数 m，零空间的宿主维数是列数 n——这是最容易记反的一对。**
3. **存在性与唯一性各归各管**：$A\mathbf{x} = \mathbf{b}$ **有解** $\iff \mathbf{b} \in \mathbf{C}(A)$；**解唯一** $\iff \mathbf{N}(A) = \{\mathbf{0}\}$。两者彼此独立，实战中只有三种情形：
4. $\mathbf{b} \in \mathbf{C}(A)$ 且 $r = n \Rightarrow$ 恰好一个解；
5. $\mathbf{b} \in \mathbf{C}(A)$ 且 $r < n \Rightarrow$ 无穷多个解（$\mathbf{x}_p + \mathbf{N}(A)$）；
6. $\mathbf{b} \notin \mathbf{C}(A) \Rightarrow$ 无解，**此时去讨论"解是否唯一"毫无意义。**

最容易搞混的是第二种与第三种都"看起来不唯一/很麻烦"，但它们的性质完全不同：前者有解、后者没解。判别只用一把尺子：$\mathbf{b}$ 是否在 $\mathbf{C}(A)$ 里；唯一性只用另一把尺子：$\mathbf{N}(A)$ 是否只有零。**不要用一把尺子回答另一个问题。** 4. **解集公式（本讲的"半成品"，下一讲补全）**：$A\mathbf{x} = \mathbf{b}$（$\mathbf{b} \neq \mathbf{0}$）的解集 $= \mathbf{x}_p + \mathbf{N}(A)$，**不是**子空间（因为不含原点）；只有 $\mathbf{b} = \mathbf{0}$ 时它才是子空间。 5. **黄金等价链**：$\mathbf{N}(A) = \{\mathbf{0}\} \iff A$ 的列线性无关 $\iff$ 无自由变量 $\iff r = n \iff A\mathbf{x} = \mathbf{b}$ 的解（若有）唯一 $\iff$ 消元后主元个数等于列数。 6. **秩–零化度（预告，讲次 10 严格证明）**：$\dim \mathbf{C}(A) + \dim \mathbf{N}(A) = r + (n - r) = n$。输入空间的维数守恒：被压掉的 + 活下来的 = 全部。

常见误区与注意事项

1. **把行空间说成 $\mathbb{R}^m$ 里的。** $\mathbf{C}(A^{\mathsf{T}}) \subseteq \mathbb{R}^n$（行向量的长度是 n）。同理 $\mathbf{N}(A^{\mathsf{T}}) \subseteq \mathbb{R}^m$。记忆法：**转置把 m 和 n 换了**，所以 A^{T} 的列空间在 $\mathbb{R}^n$ 里。这四个空间的宿主必须一次记对，否则后面所有维数公式都会配错。
2. **以为 $\mathbf{C}(A) = \mathbf{C}(U)$。**大错。行变换保留行空间、保留零空间，但**改变列空间**。示例 1 中 $\mathbf{C}(A)$ 沿 $[1,2,1]$，而消元后的 $\mathbf{C}(U)$ 沿 $[1,0,0]$（x 轴），完全不同。**但列之间的线性关系被保留**：A 的第 2 列是第 1 列的 2 倍，$U = \begin{bmatrix} 1 & 2 & 3 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix}$ 的第 2 列 $\begin{bmatrix} 2 \\ 0 \\ 0 \end{bmatrix}$ 也确实是第 1 列 $\begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}$ 的 2 倍。所以判断 $\mathbf{b} \in \mathbf{C}(A)$ 时要用 A **的列**做组合，不能拿 U 的列去组合。
3. **以为 $\mathbf{C}(A)$ 和 $\mathbf{N}(A)$ 是同一空间里的两个东西、可以互相比较。**它们住在**不同的空间**（除非 $m = n$），即使同维也不能随便"相加"。另外 $\mathbf{0}$ 同时属于两者，但一般来说 $\mathbf{C}(A) \cap \mathbf{N}(A)$ 在 $m = n$ 时可以大于 $\{\mathbf{0}\}$——甚至可能**完全重合**。最干净的反例是 $A = \begin{bmatrix} 0 & 1 \\ 0 & 0 \end{bmatrix}$：

$$A \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} x_2 \\ 0 \end{bmatrix}, \qquad \mathbf{C}(A) = \operatorname{span}\left\{ \begin{bmatrix} 1 \\ 0 \end{bmatrix} \right\} = x \text{ 轴},$$

而 $\mathbf{N}(A)$ 要求 $x_2 = 0$（x_1 完全自由），所以 $\mathbf{N}(A) = \operatorname{span}\left\{ \begin{bmatrix} 1 \\ 0 \end{bmatrix} \right\}$**也是 x 轴**。此时 $\mathbf{C}(A) = \mathbf{N}(A)$，两个空间重合。核对维数：$\dim \mathbf{C}(A) = 1$、$\dim \mathbf{N}(A) = 1$，$1 + 1 = 2 = n$ ✓（**维数公式依然成立，但"两个空间不同"这个直觉在这里失效了**）。这是最容易被忽视的坑：判断时永远回到定义去算，不要凭感觉。 4. **把 $A\mathbf{x} = \mathbf{b}$ 的解集叫"子空间"。**$\mathbf{b} \neq \mathbf{0}$ 时它不含原点，且两个解之和一般不是解（$A(\mathbf{x} + \mathbf{y}) = 2\mathbf{b} \neq \mathbf{b}$）。只有齐次问题（$\mathbf{b} = \mathbf{0}$）的解集才是子空间。 5. **混淆 $\dim \mathbf{N}(A) = n - r$ 与 $\dim \mathbf{N}(A^{\mathsf{T}}) = m - r$。**前者的宿主是 $\mathbb{R}^n$（自由变量是**列**里的非主元列），后者的宿主是 $\mathbb{R}^m$。算哪个就先问"我乘的是 A 还是 A^{T}"。 6. **忘记"子空间必须过原点"就去画图。**常见错误是对 $\mathbf{b} = \begin{bmatrix} 1 \\ 2 \end{bmatrix}$ 说"$\mathbf{C}(A) = \{t[1,2] + [1,2]\}$"之类的平移集合——那是仿射集。列空间永远是 $\{t\mathbf{a}_1 + s\mathbf{a}_2\}$，系数可以取 0，所以过原点。 7. **用行列式判秩时受形状误导。**3×4 矩阵没有行列式，但照样有秩、列空间、零空间。$\dim \mathbf{N}(A) = n - r$、$\dim \mathbf{N}(A^{\mathsf{T}}) = m - r$ 对所有形状都成立，与 m, n 谁大无关。

思考题（带答案）

Q1. 设

$$A = \begin{bmatrix} 1 & 2 & 3 \\ 2 & 4 & 6 \\ 1 & 2 & 3 \end{bmatrix}.$$

(a) 求 $\mathbf{C}(A)$ 与 $\mathbf{N}(A)$ 的维数，并写出 $\mathbf{N}(A)$ 的一组基；(b) 判断 $\mathbf{b}=\begin{bmatrix}1\\2\\3\end{bmatrix}$ 是否在 $\mathbf{C}(A)$ 中，并说明理由；(c) 判断 $\mathbf{b}'=\begin{bmatrix}2\\4\\3\end{bmatrix}$ 是否在 $\mathbf{C}(A)$ 中。

▸ **答案**

(a) 三列全部共线（第 2 列 $=2\times$第 1 列，第 3 列 $=3\times$第 1 列），故 $\mathbf{C}(A)$ 由 $\mathbf{a}_1=\begin{bmatrix}1\\2\\1\end{bmatrix}$ 张成，$\dim\mathbf{C}(A)=1$，即秩 $r=1$。

零空间：$A\mathbf{x}=\mathbf{0}$ 按行看只有一个独立方程 $x_1+2x_2+3x_3=0$（第 2、3 行都是它的倍数），这是 $\mathbb{R}^3$ 中的平面，$\dim\mathbf{N}(A)=3-r=2$。取基：

$$\mathbf{s}_1=\begin{bmatrix}-2\\1\\0\end{bmatrix}\ (x_2=1,x_3=0),\qquad \mathbf{s}_2=\begin{bmatrix}-3\\0\\1\end{bmatrix}\ (x_2=0,x_3=1).$$

验算：$A\mathbf{s}_1=\begin{bmatrix}-2+2\\-4+4\\-2+2\end{bmatrix}=\mathbf{0}$ ✓；$A\mathbf{s}_2=\begin{bmatrix}-3+3\\-6+6\\-3+3\end{bmatrix}=\mathbf{0}$ ✓。维数核对 $1+2=3=n$ ✓。

(b) $\mathbf{b}=\begin{bmatrix}1\\2\\3\end{bmatrix}$：因为 $\mathbf{C}(A)$ 是沿 $\begin{bmatrix}1\\2\\1\end{bmatrix}$ 的直线，$\mathbf{b}$ 必须与该向量成比例。比较第三分量：若 $\mathbf{b}=t\begin{bmatrix}1\\2\\1\end{bmatrix}$ 则 $t=3$（由第三分量），但那时第一分量应为 $3\neq1$。**不在 C(A) 中**。用消元法核验：增广矩阵 $\left[\begin{array}{ccc|c}1&2&3&1\\2&4&6&2\\1&2&3&3\end{array}\right]\to R_3\leftarrow R_3-R_1$ 得第三行 $[0\ \ 0\ \ 0\ \mid\ 2]$，即 $0=2$，矛盾 ✓ 无解。

(c) $\mathbf{b}'=\begin{bmatrix}2\\4\\3\end{bmatrix}$：用同样的"比例"判据——它是 $\begin{bmatrix}1\\2\\1\end{bmatrix}$ 的倍数吗？第一分量 $2=2\cdot1$、第二分量 $4=2\cdot2$ 都对上（$t=2$），但第三分量应为 $2\cdot1=2\neq3$。**不在 C(A) 中**。消元核验：$R_2\leftarrow R_2-2R_1$ 得 $[0,0,0\,|\,0]$；$R_3\leftarrow R_3-R_1$ 得 $[0,0,0\,|\,1]$，矛盾行 $0=1$ ✓。

小结：$\mathbf{b}\in\mathbf{C}(A)\iff b_2=2b_1$ 且 $b_3=b_1$。两个候选都因第三分量不匹配而被拒——这类"前两项看起来对"的干扰项正是考试最爱的陷阱。

Q2. 设 A 是 3×5 矩阵，且 $\dim\mathbf{N}(A)=2$。回答：(a) 秩 $r=$? (b) $\mathbf{b}\in\mathbb{R}^3$ 时 $A\mathbf{x}=\mathbf{b}$ 的解集可能是什么形状？(c) 是否存在某个 $\mathbf{b}$ 使得 $A\mathbf{x}=\mathbf{b}$ 恰有唯一解？(d) $\dim\mathbf{N}(A^{\mathsf{T}})=$?

▸ **答案**

(a) 由 $\dim\mathbf{N}(A)=n-r$ 且 $n=5$（列数），得 $r=5-2=3$。

(b) $r=3=m$，所以主元个数已达行数上限，A 的行满秩：对**每一个** $\mathbf{b}\in\mathbb{R}^3$ 方程组都有解（没有"零行 $=c$"的可能）。又 $\dim\mathbf{N}(A)=2>0$，所以有 2 个自由变量，解集是 $\mathbb{R}^5$ 中一个**过原点的 2 维仿射子空间**（具体地说，**仿射**：解集 $=\mathbf{x}_p+\mathbf{N}(A)$，当 $\mathbf{b}=\mathbf{0}$ 时它就是 2 维子空间；$\mathbf{b}\neq\mathbf{0}$ 时它是一张"平移过的 2 维平面"，本身不是子空间）。可以这样描述：解集是 $\mathbb{R}^5$ 中一个**2 维的仿射集**，即由 2 个自由参数和 3 个被唯一决定的变量构成的参数族。

(c) **不存在**。唯一解要求 $\mathbf{N}(A)=\{\mathbf{0}\}$，即 $r=n=5$；但 $r=3<5$。只要你有一个解，加上 $\mathbf{N}(A)$ 中的任意非零向量就得到另一个解，所以解要么无，要么无穷多。

(d) $\dim\mathbf{N}(A^{\mathsf{T}})=m-r=3-3=0$。即 $\mathbf{N}(A^{\mathsf{T}})=\{\mathbf{0}\}$，与 (b) 中的"每个 $\mathbf{b}$ 都有解"完全一致——事实上"$A\mathbf{x}=\mathbf{b}$ 对一切 $\mathbf{b}$ 有解 $\iff\mathbf{C}(A)=\mathbb{R}^m\iff r=m\iff\dim\mathbf{N}(A^{\mathsf{T}})=0$"。这道题把四个空间里的两个维数公式串成了一条链。

Q3. （概念题）判断下列命题真假并说明理由。(a) "若 $\mathbf{u},\mathbf{v}\in S$ 且 $\mathbf{u}+\mathbf{v}\in S$，则 S 是子空间。"(b) "$\mathbf{C}(A)$ 总是一个子空间，即使 A 是 2×3 的。"(c) "若 $\mathbf{N}(A)=\{\mathbf{0}\}$，则 A 一定有逆矩阵。"(d) "$\mathbf{N}(A)$ 与 $\mathbf{C}(A)$ 都是子空间，所以 $\dim\mathbf{N}(A)+\dim\mathbf{C}(A)=n$。"

▸ 答案

(a) **假。** 只查加法不查数乘是不够的。反例：$S=\{(x,y)\in\mathbb{R}^2 : x\geq 0\}$（右半平面）。它在加法下封闭（两个非负 x 之和仍非负），但不含原点无关——它含原点，问题是数乘：$\mathbf{u}=(1,0)\in S$ 但 $-1\cdot\mathbf{u}=(-1,0)\notin S$。所以 S 不是子空间。**子空间判据必须同时验证加法与数乘**（或直接验证对任意线性组合封闭）。

(b) **真。** 形状无关。A 是 2×3，$\mathbf{C}(A)\subseteq\mathbb{R}^2$，它是三个（长度 2 的）列向量的全部线性组合，必然对线性组合封闭、必含 $\mathbf{0}$，因而是 $\mathbb{R}^2$ 的子空间。顺带一提，此时 $\dim\mathbf{C}(A)\leq 2$，所以 $\mathbf{C}(A)$ 只能是 $\{\mathbf{0}\}$、一条过原点直线，或整个 $\mathbb{R}^2$。

(c) **假。** $\mathbf{N}(A)=\{\mathbf{0}\}$ 意味着 A 的列线性无关（$r=n$），但这只保证**单射**，不保证**满射**。反例：$A=\begin{bmatrix}1\\0\end{bmatrix}$（$2\times 1$）。$\mathbf{N}(A)=\{\mathbf{0}\}$（唯一方程 $x_1=0$），但 A 不是方阵，"逆矩阵"根本无从谈起；即使限制在方阵，也还有 $A=\begin{bmatrix}1&1\\0&0\end{bmatrix}$？不——它的 $\mathbf{N}(A)$ 非零（$x_1+x_2=0$ 有非零解 $[1,-1]^{\mathsf{T}}$）。正确的方阵反例是：$\mathbf{N}(A)=\{\mathbf{0}\}$ 对方阵**确实**推出可逆（因为 $r=n$ 时 A 满秩、$\det A\neq 0$）。所以准确的说法是："$\mathbf{N}(A)=\{\mathbf{0}\}\Rightarrow$ 可逆"**只在 A 是方阵时成立**；一般情况应说成"$A\mathbf{x}=\mathbf{b}$ 的解唯一（若存在）"。本题 (c) 的原命题若把"逆矩阵"放宽为"左逆/单射"则成立。**关键结论**：$\mathbf{N}(A)=\{\mathbf{0}\}$ 是"唯一性"，不是"存在性"，也不是"可逆性"（除非方阵）。

(d) **假（表述有陷阱）。** 数值上的等式 $\dim\mathbf{N}(A)+\dim\mathbf{C}(A)=n$ 是**对的**（秩–零化度定理：$(n-r)+r=n$），但理由不是"因为两者都是子空间"——这个理由是错的，两个随便的子空间维数相加没有任何必然关系。真正的理由是 A 这个线性映射本身的"维数守恒"。另外要小心：$\mathbf{C}(A)\subseteq\mathbb{R}^m$、$\mathbf{N}(A)\subseteq\mathbb{R}^n$，当 $m\neq n$ 时这两个空间**不在同一个环境空间里**，根本不能"相加"（不能说 $\mathbb{R}^n=\mathbf{C}(A)\oplus\mathbf{N}(A)$）。正确的分解是 $\mathbb{R}^n=\mathbf{C}(A^{\mathsf{T}})\oplus\mathbf{N}(A)$ 和 $\mathbb{R}^m=\mathbf{C}(A)\oplus\mathbf{N}(A^{\mathsf{T}})$。**这道题的教训：维数公式对，理由说错了照样是错的。**

Lecture 7: Solving Ax = 0: Pivot Variables, Special Solutions

概述

上一讲把 $\mathbf{N}(A)$ 定义为"被 A 压到原点的输入方向集合"，但只对 2×2、3×3 的小例子手工解方程。本讲给出**通用算法**：消元到行阶梯形 U（进一步到简化行阶梯形 R）$\rightarrow$ 认出**主元列（pivot columns）**与**自由列（free columns）** $\rightarrow$ 给每个自由变量轮流取 1、其余自由变量取 0，回代求出对应的**特殊解（special solutions）** $\rightarrow$ 全部特殊解的线性组合就是 $\mathbf{N}(A)$。核心结论是三个数字的等式：$\dim\mathbf{N}(A)=n-r=\#\{\text{自由变量}\}=\#\{\text{特殊解}\}$。理解本讲的关键在于回答"**为什么自由变量轮流取 1、其余取 0 就够用了**"——这不是技巧，而是"自由变量可以任意取值，主元变量被它们唯一决定"这一参数化事实的直接翻译。本讲是 Lecture 8（$A\mathbf{x}=\mathbf{b}$ 的一般解 = 特解 + 零空间）的全部技术准备，也是讲次 10 四个基本子空间与讲次 14 正交性的伏笔。

核心概念的几何直觉

主元列与自由列（pivot columns / free columns）

- **定义与目的**：对 A 做高斯消元（允许行交换）得到行阶梯形 U：每行的第一个非零元叫**主元（pivot）**，主元所在的列叫**主元列**；没有主元的列叫**自由列**。主元的个数 r 就是 A 的**秩**。目的：把"哪些变量被唯一决定、哪些变量可以自由取值"变成一眼可读的信息。
- **几何直觉（它在空间中是什么样子？）**：主元列是那些**带来新方向**的列；自由列是那些**没有带来新方向**的列——自由列一定是它左边某些列的线性组合（在消元后的 R 里可以**直接读出**这些系数）。因此每一个自由列都对应**一个"多出来的方向"**：既然这一列可以由别的列凑出来，就存在一个非平凡组合使它们加起来为 $\mathbf{0}$，那个组合向量就落在零空间里。**自由列的个数 = 冗余方向的个数 = 零空间的维数。**
- **具体示例**：本讲主角

$$A=\begin{bmatrix}1&2&2&2\\2&4&6&8\\3&6&8&10\end{bmatrix}$$

消元后主元在第 1、3 列，自由列是第 2、4 列。原因很直观：第 2 列 $=2\times$第 1 列，它没带来新方向；第 4 列 $=-2\times$第 1 列 $+2\times$第 3 列，也没带来新方向。所以 4 列里只有 2 列是真正独立的，$r=2$。

特殊解（special solutions）

- **定义与目的**：设自由变量为 $x_{f_1},\dots,x_{f_{n-r}}$。第 k 个特殊解 $\mathbf{s}_k$ 定义为：**令 $x_{f_k}=1$，其余自由变量 $=0$**，然后回代求出所有主元变量的值。目的是：用 $n-r$ 个"标准输入"把零空间完整地参数化出来。
- **几何直觉（它在空间中是什么样子？）**：特殊解是零空间里的 $n-r$ 个"骨架方向"。它们互相线性无关（因为在自由坐标上它们是标准的单位向量 $\mathbf{e}_1,\dots,\mathbf{e}_{n-r}$，任何组合 $\sum c_k\mathbf{s}_k$ 的自由坐标就是 $(c_1,\dots,c_{n-r})$，若组合为零则所有 $c_k=0$），并且零空间里**每一个**向量都是它们的组合。于是 $\{\mathbf{s}_1,\dots,\mathbf{s}_{n-r}\}$ 是 $\mathbf{N}(A)$ 的一组**基**，$\mathbf{N}(A)$ 是一个 $n-r$ 维的"参数平面"。
- **具体示例**：本讲主角的两个特殊解是 $\mathbf{s}_1=\begin{bmatrix}-2\\1\\0\\0\end{bmatrix}$ 与 $\mathbf{s}_2=\begin{bmatrix}2\\0\\-2\\1\end{bmatrix}$，两者都满足 $A\mathbf{s}_k=\mathbf{0}$（下面会逐个验算）。它们张成 $\mathbb{R}^4$ 中一张过原点的 2 维平面——$\mathbf{N}(A)$ 就是这张平面。

为什么"每个自由变量取 1、其余取 0"能生成全部解？（本讲的灵魂）

- **定义与目的**：把"特殊解是基"这个论断讲透，从"技巧"升级为"定理"。
- **几何直觉 + 机制**：把 RREF R 写成分块形式。设有 r 个主元列、$n-r$ 个自由列，重新排列变量后（只是重排坐标，不改变零空间的维数与结构）

$$R=[I_r \quad F], \qquad \mathbf{x}=\begin{bmatrix}\mathbf{x}_{\text{pivot}}\\ \mathbf{x}_{\text{free}}\end{bmatrix},$$

其中 I_r 是 $r\times r$ 单位阵，F 是 $r\times(n-r)$ 的矩阵。$R\mathbf{x}=\mathbf{0}$ 即 $\mathbf{x}_{\text{pivot}}+F\mathbf{x}_{\text{free}}=\mathbf{0}$，也就是

$$\boxed{\mathbf{x}_{\text{pivot}}=-F\,\mathbf{x}_{\text{free}}}$$

这就是全部秘密：一旦自由变量 $\mathbf{x}_{\text{free}}$ 选定，主元变量 $\mathbf{x}_{\text{pivot}}$ 就被**唯一地**决定（因为 I_r 可逆）。反过来，$\mathbf{x}_{\text{free}}$ 可以取 $\mathbb{R}^{n-r}$ 中任何值，完全自由。于是映射

$$\mathbf{x}_{\text{free}} \;\longmapsto\; \mathbf{x}=\begin{bmatrix}-F\mathbf{x}_{\text{free}}\\ \mathbf{x}_{\text{free}}\end{bmatrix}$$

是 $\mathbb{R}^{n-r}\to \mathrm{N}(A)$ 的一个**一一对应**（线性同构）。因此 $\dim \mathrm{N}(A)=n-r$。而取 $\mathbf{x}_{\text{free}}$ 为 $\mathbb{R}^{n-r}$ 的标准基 $\mathbf{e}_1,\dots,\mathbf{e}_{n-r}$，得到的正是 $n-r$ 个特殊解：

$$\mathbf{s}_k=\begin{bmatrix}-F\mathbf{e}_k\\ \mathbf{e}_k\end{bmatrix}=\begin{bmatrix}-(F\text{ 的第 }k\text{ 列})\\ \mathbf{e}_k\end{bmatrix}.$$

这些 $\mathbf{s}_k$ 是 $\mathbb{R}^{n-r}$ 的标准基在逆映射下的像，所以线性无关；又因为任何 $\mathbf{x}_{\text{free}}$ 都能写成 $\sum c_k\mathbf{e}_k$，任何零空间向量都能写成 $\sum c_k\mathbf{s}_k$。**"基"的两条要求（无关 + 张成）同时到位。** – **更直白的说法**：零空间里的向量长这样——

$$\mathbf{x}=x_{f_1}\mathbf{s}_1+x_{f_2}\mathbf{s}_2+\cdots+x_{f_{n-r}}\mathbf{s}_{n-r},$$

也就是说，**自由变量的取值本身就是组合系数**。这就是"$n-r$ 个自由参数"这句话的确切含义：零空间是一个由 $n-r$ 个参数自由滑动生成的 $n-r$ 维平面。 – **具体示例**：本讲主角的 RREF 是 $R=\begin{bmatrix}1&2&0&-2\\0&0&1&2\\0&0&0&0\end{bmatrix}$。重排后 $\mathbf{x}_{\text{pivot}}=\begin{bmatrix}x_1\\x_3\end{bmatrix}$、$\mathbf{x}_{\text{free}}=\begin{bmatrix}x_2\\x_4\end{bmatrix}$，而 F 就是从 R 里抠出自由列得到的 $\begin{bmatrix}2&-2\\0&2\end{bmatrix}$。于是

$$\begin{bmatrix}x_1\\x_3\end{bmatrix}=-F\begin{bmatrix}x_2\\x_4\end{bmatrix}=\begin{bmatrix}-2x_2+2x_4\\-2x_4\end{bmatrix}.$$

取 $\mathbf{x}_{\text{free}}=\begin{bmatrix}1\\0\end{bmatrix}$ 得 $\mathbf{s}_1=\begin{bmatrix}-2\\1\\0\\0\end{bmatrix}$；取 $\mathbf{x}_{\text{free}}=\begin{bmatrix}0\\1\end{bmatrix}$ 得 $\mathbf{s}_2=\begin{bmatrix}2\\0\\-2\\1\end{bmatrix}$。与手工回代的结果完全一致。

消元把零空间照原样保留（为什么可以先消元再回代）

- **定义与目的**：说明算法第一步（消元）为何合法。
- **几何直觉**：消元是**可逆的行变换**，等价于左乘可逆矩阵：$E_k\cdots E_1A=U$，即 $U=L^{-1}A$。而

$$A\mathbf{x}=\mathbf{0} \iff L^{-1}A\mathbf{x}=\mathbf{0} \iff U\mathbf{x}=\mathbf{0},$$

因为 L^{-1} 可逆（$\mathbf{y}=\mathbf{0}\iff L^{-1}\mathbf{y}=\mathbf{0}$）。所以 $\mathrm{N}(A)=\mathrm{N}(U)=\mathrm{N}(R)$。**消元会改变列空间，但不会碰零空间**——这是我们能"先消元、再在 R 上读零空间"的全部理由。 – **具体示例**：下面演示 1 会算出 $L=\begin{bmatrix}1&0&0\\2&1&0\\3&1&1\end{bmatrix}$，并验证 $LU=A$。注意 L 的对角线全为 1，所以 $\det L=1\neq 0$，可逆。

RREF 上主元列与自由列的标记（ASCII 图）

```
                     col1  col2  col3  col4
                   [   1     2     0    -2 ]  <- 主元行 1: x1 是主元变量
R = rref(A)    =   [   0     0     1     2 ]  <- 主元行 2: x3 是主元变量
                   [   0     0     0     0 ]  <- 零行（没有主元）
                     ^           ^
                   主元列        主元列          r = 2 个主元
                           ^           ^
                       自由列        自由列      n - r = 2 个自由变量

R 的每一行可以"读成一个方程":
  row1:  x1 + 2*x2 + 0*x3 - 2*x4 = 0   ->   x1 = -2*x2 + 2*x4
  row2:  0*x1 + 0*x2 + x3 + 2*x4 = 0   ->   x3 = -2*x4
  row3:  0 = 0                          ->  什么也没说（冗余行）

把 x2, x4 当"旋钮":
  (x2, x4) = (1, 0)  ->  x = (-2, 1, 0, 0)    = s1
  (x2, x4) = (0, 1)  ->  x = ( 2, 0, -2, 1)   = s2
  (x2, x4) = (c1,c2) ->  x = c1*s1 + c2*s2    这就是 N(A) 的全部
```

"多出来的方向"直观图（无需消元的版本）

```
A 的 4 个列向量（都在 R^3 里，因为 A 是 3x4）:

  col1 = [1,2,3]          <- 独立方向 #1
  col2 = [2,4,6] = 2*col1         <- 没有新方向！ "多出来的" 第 1 个方向
  col3 = [2,6,8]          <- 独立方向 #2
  col4 = [2,8,10] = -2*col1 + 2*col3   <- 没有新方向！ "多出来的" 第 2 个方向

  => 真正的独立方向只有 r = 2 个，冗余方向 4 - 2 = 2 个
  => 每一个冗余方向都能"造"出一个非平凡组合，使列的和为 0:
       col2 - 2*col1 = 0
          给出的零空间向量:  x1 = -2, x2 = 1, x3 = 0, x4 = 0     ->  s1
       2*col1 - 2*col3 + col4 = 0
          给出的零空间向量:  x1 = 2, x2 = 0, x3 = -2, x4 = 1     ->  s2

  结论: 自由列的个数 = 冗余方向的个数 = dim N(A) = n - r
```

零空间是"物理的运动方向"：3×4 例子的空间图景

```
        输入空间 R^4（变量 x1,x2,x3,x4 的空间）
        ┌──────────────────────────────────────┐
        │   N(A): 过原点的 2 维平面              │
        │      = { c1*s1 + c2*s2 }              │
        │      每个点都满足 A x = 0（被压到 0）    │
        │                                       │
        │   A 的作用:                            │
        │      R^4  ———A———>  R^3               │
        │       (4 维)          (3 维输出)       │
        │       压掉 2 维        只活下来 2 维    │
        │       0 + 2 + 2 = 4 = n               │
        └──────────────────────────────────────┘
  dim(row space) + dim(N(A)) = r + (n-r) = n = 4
```

计算步骤与手算演示

示例 1（Strang 的经典例子，全程手算）：$A = \begin{bmatrix} 1 & 2 & 2 & 2 \\ 2 & 4 & 6 & 8 \\ 3 & 6 & 8 & 10 \end{bmatrix}$ 的完整零空间

步骤 1（第一列消元，主元 $a_{11} = 1$）：消掉第 1 列在 2、3 行的下方元素。

- 乘数 $\ell_{21} = 2/1 = 2$，$R_2 \leftarrow R_2 - 2R_1$：

$$R_2 = (2,4,6,8) - 2(1,2,2,2) = (0,\ 4-4,\ 6-4,\ 8-4) = (0,0,2,4).$$

- 乘数 $\ell_{31} = 3/1 = 3$，$R_3 \leftarrow R_3 - 3R_1$：

$$R_3 = (3,6,8,10) - 3(1,2,2,2) = (0,\ 6-6,\ 8-6,\ 10-6) = (0,0,2,4).$$

消元一步后：

```
[ 1  2  2  2 ]
[ 0  0  2  4 ]
[ 0  0  2  4 ]
```

步骤 2（第 2 列没有主元，跳到第 3 列）：第 2 列在第 2、3 行的元素都是 0，**在（第 2 行，第 2 列）这个位置上找不到非零主元**，所以**第 2 列是自由列**，消元继续向右看第 3 列。位置 $(2,3)$ 上的 2 成为第二个主元。

- 乘数 $\ell_{32} = 2/2 = 1$，$R_3 \leftarrow R_3 - 1R_2$：

$$R_3 = (0,0,2,4) - 1\cdot(0,0,2,4) = (0,0,0,0).$$

得到**行阶梯形 U**：

$$U = \begin{bmatrix} 1 & 2 & 2 & 2 \\ 0 & 0 & 2 & 4 \\ 0 & 0 & 0 & 0 \end{bmatrix}.$$

步骤 3（同时记录 L，验证 $A = LU$）：消元的乘数按位置放入下三角：

$$L = \begin{bmatrix} 1 & 0 & 0 \\ 2 & 1 & 0 \\ 3 & 1 & 1 \end{bmatrix}, \qquad LU = \begin{bmatrix} 1 & 0 & 0 \\ 2 & 1 & 0 \\ 3 & 1 & 1 \end{bmatrix}\begin{bmatrix} 1 & 2 & 2 & 2 \\ 0 & 0 & 2 & 4 \\ 0 & 0 & 0 & 0 \end{bmatrix} = \begin{bmatrix} 1 & 2 & 2 & 2 \\ 2 & 4 & 6 & 8 \\ 3 & 6 & 8 & 10 \end{bmatrix} = A \checkmark$$

（逐项核对：$(LU)_{24} = 2\cdot 2 + 0 + 0 = 4$ ✓；$(LU)_{34} = 3\cdot 2 + 1\cdot 4 + 0 = 10$ ✓；$(LU)_{33} = 3\cdot 2 + 1\cdot 2 + 0 = 8$ ✓。）

步骤 4（读出秩与自由列）：U 有 2 个非零行 $\Rightarrow$ 主元个数 $r = 2$；主元位于第 1 列与第 3 列 $\Rightarrow$ **主元列 = {1, 3}**；**自由列 = {2, 4}**，自由变量是 x_2, x_4。预测 $\dim \mathrm{N}(A) = n - r = 4 - 2 = 2$。

步骤 5（继续化简到 RREF R，让回代更方便）：把主元归一化为 1，再把主元**上方**的元素也消掉。

- 第 2 行除以主元 2：$(0,0,2,4) \to (0,0,1,2)$。
- 消掉第 3 列在第 1 行的元素 2：$R_1 \leftarrow R_1 - 2R_2$：

$$R_1 = (1,2,2,2) - 2(0,0,1,2) = (1,2,0,-2).$$

$$R = \begin{bmatrix} 1 & 2 & 0 & -2 \\ 0 & 0 & 1 & 2 \\ 0 & 0 & 0 & 0 \end{bmatrix}.$$

步骤 6（把 R 读成方程）：

$$\begin{cases} x_1 + 2x_2 - 2x_4 = 0 \\ x_3 + 2x_4 = 0 \end{cases} \quad\Longrightarrow\quad \begin{cases} x_1 = -2x_2 + 2x_4 \\ x_3 = -2x_4 \end{cases}$$

步骤 7（自由变量轮流取 1，得特殊解）：

- 令 $x_2 = 1,\ x_4 = 0$：$x_1 = -2(1) + 2(0) = -2$，$x_3 = -2(0) = 0$，得

$$\mathbf{s}_1 = \begin{bmatrix} -2 \\ 1 \\ 0 \\ 0 \end{bmatrix}.$$

- 令 $x_2 = 0,\ x_4 = 1$：$x_1 = -2(0) + 2(1) = 2$，$x_3 = -2(1) = -2$，得

$$\mathbf{s}_2 = \begin{bmatrix} 2 \\ 0 \\ -2 \\ 1 \end{bmatrix}.$$

步骤 8（代回原矩阵验算——这一步绝不能省）：

$$A\mathbf{s}_1 = \begin{bmatrix} 1 & 2 & 2 & 2 \\ 2 & 4 & 6 & 8 \\ 3 & 6 & 8 & 10 \end{bmatrix}\begin{bmatrix} -2 \\ 1 \\ 0 \\ 0 \end{bmatrix} = \begin{bmatrix} 1(-2) + 2(1) + 0 + 0 \\ 2(-2) + 4(1) + 0 + 0 \\ 3(-2) + 6(1) + 0 + 0 \end{bmatrix} = \begin{bmatrix} -2 + 2 \\ -4 + 4 \\ -6 + 6 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix} \checkmark$$

$$A\mathbf{s}_2 = \begin{bmatrix}1&2&2&2\\2&4&6&8\\3&6&8&10\end{bmatrix}\begin{bmatrix}2\\0\\-2\\1\end{bmatrix} = \begin{bmatrix}2+0-4+2\\4+0-12+8\\6+0-16+10\end{bmatrix} = \begin{bmatrix}0\\0\\0\end{bmatrix}\ \checkmark$$

步骤 9（一般解与抽查）：

$$\mathrm{N}(A) = \{c_1\mathbf{s}_1 + c_2\mathbf{s}_2 : c_1, c_2 \in \mathbb{R}\} = \operatorname{span}\left\{\begin{bmatrix}-2\\1\\0\\0\end{bmatrix}, \begin{bmatrix}2\\0\\-2\\1\end{bmatrix}\right\}, \qquad \dim \mathrm{N}(A) = 2.$$

抽两个非平凡组合核对：$c_1 = 3, c_2 = -5$ 得 $\mathbf{x} = 3\mathbf{s}_1 - 5\mathbf{s}_2 = \begin{bmatrix}-6-10\\3\\0+10\\-5\end{bmatrix} = \begin{bmatrix}-16\\3\\10\\-5\end{bmatrix}$，且 $A\mathbf{x} = 3A\mathbf{s}_1 - 5A\mathbf{s}_2 = \mathbf{0}$ ✓（用线性性免算）。另一个 $\mathbf{x} = \mathbf{s}_1 + \mathbf{s}_2 = \begin{bmatrix}0\\1\\-2\\1\end{bmatrix}$，直接代入也得 $\mathbf{0}$ ✓。

【计算机制解说】（本讲第一个解说）：为什么"自由变量每个取 1、其余取 0"就**足够**生成整个零空间？三重理由，从最具体到最抽象：

1. **自由度计数**：R 有 r 个非零行，n 个未知数，$n - r$ 个自由变量。R 的 r 个方程是**互相独立**的（每行有一个各不相同的、系数为 1 的主元），所以给定自由变量后，r 个主元变量被 r 个独立方程唯一确定——**不是"随便选一组解"，而是"自由变量一动，主元变量跟着唯一地动"**。
2. **一一对应**：$(x_2, x_4) \mapsto \mathbf{x}$ 是 $\mathbb{R}^2 \to \mathrm{N}(A)$ 的线性同构（可逆映射，逆映射就是"取第 2、4 个坐标"）。所以 $\mathrm{N}(A)$ 与 $\mathbb{R}^2$ 长得一模一样，$\dim \mathrm{N}(A) = 2$。既然参数空间的标准基是 $\mathbf{e}_1, \mathbf{e}_2$，它们的像 $\mathbf{s}_1, \mathbf{s}_2$ 自然是 $\mathrm{N}(A)$ 的基。
3. **组合系数就是自由变量**：任何一个零空间向量 $\mathbf{x}$，它的自由坐标是 (x_2, x_4)，而向量 $x_2\mathbf{s}_1 + x_4\mathbf{s}_2$ 的自由坐标也是 (x_2, x_4)，两者自由坐标相同；又两者都满足 $R\mathbf{x} = \mathbf{0}$，而主元变量由自由变量唯一决定，所以两者必然相等：$\mathbf{x} = x_2\mathbf{s}_1 + x_4\mathbf{s}_2$。**这就是"特殊解张成零空间"的完整证明**，不需要任何额外的"技巧"。

顺带解释 $\mathbf{s}_k$ 的构造为什么长成"$-F$ 的列 + 单位向量"：在 RREF 里主元变量的系数构成单位阵，所以回代就是把自由列的系数取负号搬到主元位置。于是 $\mathbf{s}_1$ 的主元分量恰好是 $-(\mathbf{R}\text{ 第 }\mathbf{2}\text{ 列的上面两项}) = \begin{bmatrix}-2\\0\end{bmatrix}$，$\mathbf{s}_2$ 的主元分量是 $-(\mathbf{R}\text{ 第 }\mathbf{4}\text{ 列的上面两项}) = \begin{bmatrix}2\\-2\end{bmatrix}$——**从 RREF 可以直接抄出特殊解，不必解方程**。（核对 R 的第 2 列是 $\begin{bmatrix}2\\0\end{bmatrix}$，取负得 $\begin{bmatrix}-2\\0\end{bmatrix} = \mathbf{s}_1$ 的主元分量 ✓；R 的第 4 列是 $\begin{bmatrix}-2\\2\end{bmatrix}$，取负得 $\begin{bmatrix}2\\-2\end{bmatrix} = \mathbf{s}_2$ 的主元分量 ✓。）

示例 2：$A = \begin{bmatrix}1&2\\2&4\end{bmatrix}$——2×2 秩 1 的最小完整流程

步骤 1（消元到 U）：乘数 $\ell_{21} = 2/1 = 2$，$R_2 \leftarrow R_2 - 2R_1$：$(2,4) - 2(1,2) = (0,0)$。得

$$U = \begin{bmatrix}1&2\\0&0\end{bmatrix}.$$

步骤 2（到 RREF）：主元已经是 1，下方已消净，所以 $R = U = \begin{bmatrix}1&2\\0&0\end{bmatrix}$。

步骤 3（认列）：主元列 = {1}，自由列 = {2}，$r = 1$，$n - r = 2 - 1 = 1$ 个自由变量 x_2。

步骤 4（读方程与回代）：$x_1 + 2x_2 = 0 \Rightarrow x_1 = -2x_2$。令 $x_2 = 1$：

$$\mathbf{s} = \begin{bmatrix}-2\\1\end{bmatrix}.$$

步骤 5（验算）：$A\mathbf{s} = \begin{bmatrix}1(-2)+2(1)\\2(-2)+4(1)\end{bmatrix} = \begin{bmatrix}0\\0\end{bmatrix}$ ✓；$R\mathbf{s} = \begin{bmatrix}1(-2)+2(1)\\0\end{bmatrix} = \begin{bmatrix}0\\0\end{bmatrix}$ ✓。

步骤 6（几何结论）：$\mathrm{N}(A) = \left\{t\begin{bmatrix}-2\\1\end{bmatrix}\right\}$ 是 $\mathbb{R}^2$ 中一条过原点的直线；$\mathbf{s}$ 就是这条直线的"方向向量"，也就是零空间的一组基（只有 1 个向量，因为维数是 1）。注意 $\mathbf{s}$ 的第二个分量取 1 不是"必须"——取 $x_2 = 5$ 得 $\begin{bmatrix}-10\\5\end{bmatrix} = 5\mathbf{s}$ 也行，只是取 1 让基向量最简洁。

【计算机制解说】（本讲第二个解说）：为什么**最小二乘式的"取 1" 不会重复计数**？为什么不需要对自由变量取其他值（比如取 $(2,3)$）来补足解集？因为映射 $\mathbf{x}_{\text{free}} \mapsto \mathbf{x}$ 是**线性一一对应**，而维数是最强的"不重复"保证：如果 $\mathbf{s}$ 再多一个"独立"的零空间向量，$\dim \mathrm{N}(A)$ 就变成 2 了，与 $n - r = 1$ 矛盾。从另一个方向看：任何 t 倍都只是同一个方向的放大，不产生新维度。**"需要几个特殊解"这个问题等价于"参数空间有几维"，而后者等于"自由变量有几个"**——所以自由变量轮换取一次 1 就正好、且只够。

另外注意示例 2 的一个反直觉现象：$R = U$ 时**主元列的系数图案与 A 的列关系一一对应**。R 第 2 列是 $\begin{bmatrix}2\\0\end{bmatrix}$，意思是"$A$ 的第 2 列 $= 2 \times A$ 的第 1 列 $+0\times$ 其他列"，核对：$\begin{bmatrix}2\\4\end{bmatrix} = 2\begin{bmatrix}1\\2\end{bmatrix}$ ✓。而特殊解 $\mathbf{s}$ 恰好是把那个系数 2 取负、放在自由位置旁边：$-2\cdot(\mathrm{col}_1) + 1\cdot(\mathrm{col}_2) = \mathbf{0}$，也就是

$\mathrm{col}_2 = 2\,\mathrm{col}_1$。**零空间向量就是"列之间的线性关系"本身。** 这个观察在讲次 9 会被正式命名为"$A\mathbf{x} = \mathbf{0}$ 的解 = 列的线性相关关系"。

示例 3：秩 1 的 3×3 矩阵与"秩 = 非零行数 = 主元个数"

取

$$B = \begin{bmatrix} 1 & 2 & 3 \\ 2 & 4 & 6 \\ 1 & 2 & 3 \end{bmatrix}.$$

步骤 1（消元）：

```
[ 1  2  3 ]  R2 -= 2*R1  ->  [ 0  0  0 ]
[ 2  4  6 ]  R3 -= 1*R1  ->  [ 0  0  0 ]
[ 1  2  3 ]
```

得 $U = \begin{bmatrix} 1 & 2 & 3 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix}$，它同时也是 R（主元已是 1，下方全零，上方也没有别的行）。

步骤 2（认列）：主元列 = {1}，自由列 = {2, 3}，$r = 1$，自由变量 x_2, x_3，$\dim \mathrm{N}(B) = 3 - 1 = 2$。

步骤 3（取特殊解）：R 只给出 $x_1 + 2x_2 + 3x_3 = 0$，即 $x_1 = -2x_2 - 3x_3$。

- $x_2 = 1, x_3 = 0$：$x_1 = -2$，得 $\mathbf{s}_1 = \begin{bmatrix} -2 \\ 1 \\ 0 \end{bmatrix}$；
- $x_2 = 0, x_3 = 1$：$x_1 = -3$，得 $\mathbf{s}_2 = \begin{bmatrix} -3 \\ 0 \\ 1 \end{bmatrix}$。

步骤 4（验算）：$B\mathbf{s}_1 = \begin{bmatrix} -2+2+0 \\ -4+4+0 \\ -2+2+0 \end{bmatrix} = \mathbf{0}$ ✓，$B\mathbf{s}_2 = \begin{bmatrix} -3+0+3 \\ -6+0+6 \\ -3+0+3 \end{bmatrix} = \mathbf{0}$ ✓。

步骤 5（"秩 = 非零行数 = 主元个数"的三重刻画）：

```
秩的四个等价说法（对同一个矩阵 B）：

① r = U 中非零行的个数              = 1
② r = 主元的个数                    = 1
③ r = 主元列的个数                  = 1   （只有第 1 列）
④ r = dim C(B) = 列空间维数         = 1   （C(B) = 直线 t[1,2,1]）

并且：  dim N(B) = n − r = 3 − 1 = 2     （# 自由变量 = # 特殊解 = # 自由列）
        行空间维数 = r = 1（方向 [1,2,3]，即"行方向"）
```

步骤 6（无消元也看得出的道理）：$B = \mathbf{u}\mathbf{v}^{\mathsf{T}}$，其中 $\mathbf{u} = \begin{bmatrix} 1 \\ 2 \\ 1 \end{bmatrix}, \mathbf{v} = \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix}$（因为每行都是 $[1,2,3]$ 的倍数，每列都是 $[1,2,1]$ 的倍数）。于是

$$B\mathbf{x} = \mathbf{u}(\mathbf{v}^{\mathsf{T}}\mathbf{x}) = (x_1 + 2x_2 + 3x_3)\begin{bmatrix} 1 \\ 2 \\ 1 \end{bmatrix},$$

$B\mathbf{x} = \mathbf{0} \iff x_1 + 2x_2 + 3x_3 = 0$，一眼看出零空间是平面、维数 2。**这就是"每个自由列对应一个多出来的方向"的最强形式：秩 1 矩阵有 $n-1$ 个多出来的方向，所以零空间是 $n-1$ 维的超平面。**

【计算机制解说】（本讲第三个解说，补充说明"自由列 = 冗余方向"）：为什么"自由列的个数"与"零空间维数"必然相等？看消元过程：每当算法在某一列找不到主元（该列在主元行及以下全是零），就意味着**这一列可以被前面已经处理过的列线性组合出来**（在 R 中它等于若干主元列的系数组合）——它没有给列空间贡献新的维度。设这样的列为 $\boldsymbol{f}_1, \ldots, \boldsymbol{f}_{n-r}$，每一列都对应一个"读出系数、取负、放到自由位置"的零空间向量，而且这些向量在自由坐标上互不相同（第 k 个向量的自由坐标是 $\mathbf{e}_k$），所以它们线性无关。另一方面，任何一个零空间向量都由 R 的 r 个方程约束，r 个独立方程把 n 维压到 $n-r$ 维，所以维数**至多** $n-r$。上下夹逼：维数恰好 $n-r$，且上面构造的 $n-r$ 个向量正好是一组基。**"消元找不到主元"和"这一列是多余的"是同一件事的两种描述**——这是本讲最应该记住的一句话。

示例 4（稀疏例子，看清主元列可以不相邻）：$C = \begin{bmatrix} 0 & 1 & 2 \\ 0 & 2 & 4 \end{bmatrix}$

步骤 1（第 1 列全是零）：第 1 列在（第 1 行，第 1 列）处是 $\mathbf{0}$，没有可用的主元（下方也是 $\mathbf{0}$），所以**第 1 列是自由列**，消元向右看第 2 列。

步骤 2（取第 2 列为主元列）：主元 $= \mathbf{1}$（在第 1 行第 2 列）。乘数 $\ell = 2/1 = 2$，$R_2 \leftarrow R_2 - 2R_1$：$(0,2,4) - 2(0,1,2) = (0,0,0)$。

$$U = R = \begin{bmatrix} 0 & 1 & 2 \\ 0 & 0 & 0 \end{bmatrix}.$$

步骤 3（认列）：主元列 = {2}，自由列 = {1, 3}，$r = 1$，$\dim \mathrm{N}(C) = 3 - 1 = 2$。

步骤 4（回代）：R 的方程是 $x_2 + 2x_3 = 0$，即 $x_2 = -2x_3$；第 1 列没有方程约束它，所以 x_1 **也是自由的**（它不出现在任何方程里）。

- $x_1 = 1, x_3 = 0$：$x_2 = 0$，得 $\mathbf{s}_1 = \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}$；
- $x_1 = 0, x_3 = 1$：$x_2 = -2$，得 $\mathbf{s}_2 = \begin{bmatrix} 0 \\ -2 \\ 1 \end{bmatrix}$。

步骤 5（验算）：$C\mathbf{s}_1 = \begin{bmatrix} 0(1)+1(0)+2(0) \\ 0(1)+2(0)+4(0) \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$ ✓；$C\mathbf{s}_2 = \begin{bmatrix} 0+1(-2)+2(1) \\ 0+2(-2)+4(1) \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$ ✓。

步骤 6（教训）：**自由变量不一定"排在后面"**。这里 x_1 是自由变量，特殊解的第一个分量是 1 而不是 0。做题时必须以消元后**主元的位置**为准，不能想当然地以为"自由变量就是后面几个"。

示例 5：需要行交换的矩阵 $D = \begin{bmatrix} 1 & 2 & 3 \\ 2 & 4 & 6 \\ 0 & 1 & 1 \end{bmatrix}$——主元破裂与 $PA = LU$

前面所有例子的主元都恰好非零、不需要换行。这个例子专门演示"位置上的元素是 0，但这一列其实还有非零元"的情形。

步骤 1（第一列消元）：主元 $d_{11} = 1$；乘数 $\ell_{21} = 2$，$R_2 \leftarrow R_2 - 2R_1$：

$$R_2 = (2,4,6) - 2(1,2,3) = (0,0,0).$$

R_3 的第一列本来就是 0，乘数 $\ell_{31} = 0$，无需操作。此时

```
[ 1  2  3 ]
[ 0  0  0 ]     <- 第 2 行整行变成 0
[ 0  1  1 ]
```

步骤 2（主元破裂，需要行交换）：第 2 列在位置 $(2,2)$ 上是 0，**不能**拿它当主元。但往下看位置 $(3,2)$ 是 $1 \neq 0$，所以**交换第 2、3 行**：

```
[ 1  2  3 ]
[ 0  1  1 ]     <- 原来的第 3 行升上来
[ 0  0  0 ]     <- 原来的第 2 行沉下去
```

现在主元是 $(2,2)$ 处的 1；该行下方是 0，不需要再消元。

步骤 3（化到 RREF，向上消元）：$R_1 \leftarrow R_1 - 2R_2$：

$$R_1 = (1,2,3) - 2(0,1,1) = (1,0,1).$$

$$R = \begin{bmatrix} 1 & 0 & 1 \\ 0 & 1 & 1 \\ 0 & 0 & 0 \end{bmatrix}.$$

步骤 4（认列与求特殊解）：主元列 $= \{1,2\}$，自由列 $= \{3\}$，$r = 2$，$\dim \mathrm{N}(D) = 3 - 2 = 1$。RREF 给出 $x_1 + x_3 = 0$、$x_2 + x_3 = 0$，即 $x_1 = -x_3$、$x_2 = -x_3$。令 $x_3 = 1$：

$$\mathbf{s} = \begin{bmatrix} -1 \\ -1 \\ 1 \end{bmatrix}.$$

步骤 5（验算）：

$$D\mathbf{s} = \begin{bmatrix} 1(-1)+2(-1)+3(1) \\ 2(-1)+4(-1)+6(1) \\ 0(-1)+1(-1)+1(1) \end{bmatrix} = \begin{bmatrix} -1-2+3 \\ -2-4+6 \\ -1+1 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix} \checkmark$$

步骤 6（回到列关系，验证符号约定）：$\mathbf{s} = \begin{bmatrix} -1 \\ -1 \\ 1 \end{bmatrix} \in \mathrm{N}(D)$ 说的是 $-\mathbf{d}_1 - \mathbf{d}_2 + \mathbf{d}_3 = \mathbf{0}$，即

$$\mathbf{d}_3 = \mathbf{d}_1 + \mathbf{d}_2 = \begin{bmatrix} 1 \\ 2 \\ 0 \end{bmatrix} + \begin{bmatrix} 2 \\ 4 \\ 1 \end{bmatrix} = \begin{bmatrix} 3 \\ 6 \\ 1 \end{bmatrix} \checkmark$$

而 R 的第 3 列是 $\begin{bmatrix}1\\1\\0\end{bmatrix}$，说的是"$\mathbf{d_3} = 1\cdot\mathbf{d_1} + 1\cdot\mathbf{d_2}$"——**两种写法完全一致**（$R$ 记录正系数，特殊解记录取负后的系数）。所以看到 $\mathbf{s} = \begin{bmatrix}-1\\-1\\1\end{bmatrix}$ 时不要慌，它与"第 3 列 = 第 1 列 + 第 2 列"是同一句话。

步骤 7（$PA = LU$ 的形式）：因为交换了第 2、3 行，严格写出来是 $PA = LU$，其中

$$P = \begin{bmatrix}1&0&0\\0&0&1\\0&1&0\end{bmatrix},\qquad L = \begin{bmatrix}1&0&0\\0&1&0\\2&0&1\end{bmatrix},\qquad U = \begin{bmatrix}1&2&3\\0&1&1\\0&0&0\end{bmatrix}.$$

（L 的第 3 行记录"原第 2 行减去 $2\times$第 1 行"，乘数 2 落在被交换后的第 3 行位置。）**关键结论：置换矩阵 P 只是给方程重新编号，零空间不变**——所以算法允许行交换，我们的 $\mathbf{N}(D) = \mathbf{N}(U) = \mathbf{span}\{\mathbf{s}\}$ 一如既往。

【计算机制解说】：为什么允许行交换，而**不允许**列交换（或者说列交换后必须记下来）？ – **行交换 = 重新排列方程的顺序**。方程组 $\{R_1, R_2, R_3\}$ 与 $\{R_3, R_2, R_1\}$ 的解集显然完全一样。所以 $\mathbf{N}(A)$ 不变，我们的算法有恃无恐。代数上，行交换就是左乘一个置换矩阵 P（可逆），所以 $\mathbf{N}(PA) = \mathbf{N}(A)$。 – **列交换 = 重新排列未知数的顺序**。例如交换第 1、2 列后，解出来的向量是 (x_2, x_1, x_3) 的顺序，必须**换回原顺序**才能作为原问题的解。所以列交换不是禁忌，而是"要记账"。**这就是"部分选主元（partial pivoting）"只选行使算法稳定的原因**：行交换既保证了数值稳定性（把主元位置上的绝对值最大者换上来，避免除以很小的数），又完全不改变解集。 – **一个有用的推论**：上面示例 4 中 $C = \begin{bmatrix}0&1&2\\0&2&4\end{bmatrix}$ 的第 1、3 列都是自由列（第 1 列全零、第 3 列是第 2 列的 2 倍），示例 5 中 D 的第 3 列是自由列——由此可见**凡是在主元行及其下方全为 0 的列，必然是自由列**，对应变量必然自由。反之，主元列一定是"能带来新方向"的列。**行交换永远不会把一个自由列变成主元列**——它只重排行的顺序，不改变每一列的元素集合。

示例 6：3×5 矩阵 B——自由变量多于主元变量的"最坏情形"

$$B = \begin{bmatrix}1&3&0&2&1\\0&0&1&4&2\\1&3&1&6&3\end{bmatrix}.$$

这个矩阵的形状是 $m = 3, n = 5$，主元最多只能有 3 个，所以自由变量**至少有 $5-3=2$ 个**。我们算算实际有几个。

步骤 1（消元）：B 的第 1 行已经是好的主元行（主元 1 在位置 $(1,1)$）。$R_3 \leftarrow R_3 - 1\cdot R_1$：

$$R_3 = (1,3,1,6,3) - (1,3,0,2,1) = (0,0,1,4,2).$$

现在

```
[ 1  3  0  2  1 ]
[ 0  0  1  4  2 ]
[ 0  0  1  4  2 ]
```

步骤 2（第 2 列无主元，跳到第 3 列）：第 2 列在 2、3 行都是 0，自由列。位置 $(2,3)$ 上是 1，取为主元。$R_3 \leftarrow R_3 - R_2$ 得零行：

$$U = \begin{bmatrix}1&3&0&2&1\\0&0&1&4&2\\0&0&0&0&0\end{bmatrix}.$$

U 已经满足"主元为 1、主元上方为 0"（第 1 行第 3 列本来就是 0），所以 $R = U$。

步骤 3（认列）：主元列 $= \{1,3\}$，**自由列** $= \{2,4,5\}$，$r = 2$，$n = 5$，所以

$$\dim \mathbf{N}(B) = 5 - 2 = 3 \quad (\text{正好等于最少的 } 2\text{？不，是 } 3 > 2\text{，因为只找到了 } 2 \text{ 个主元}).$$

步骤 4（三个自由变量轮流取 1）：

$$\begin{cases} x_1 + 3x_2 + 2x_4 + x_5 = 0 \;\Rightarrow\; x_1 = -3x_2 - 2x_4 - x_5 \\ x_3 + 4x_4 + 2x_5 = 0 \;\Rightarrow\; x_3 = -4x_4 - 2x_5 \end{cases}$$

- $x_2 = 1, x_4 = 0, x_5 = 0$：$x_1 = -3,\ x_3 = 0$，得 $\mathbf{s}_1 = \begin{bmatrix}-3\\1\\0\\0\\0\end{bmatrix}$；

- $x_2 = 0, x_4 = 1, x_5 = 0$：$x_1 = -2,\ x_3 = -4$，得 $\mathbf{s}_2 = \begin{bmatrix} -2 \\ 0 \\ -4 \\ 1 \\ 0 \end{bmatrix}$；
- $x_2 = 0, x_4 = 0, x_5 = 1$：$x_1 = -1,\ x_3 = -2$，得 $\mathbf{s}_3 = \begin{bmatrix} -1 \\ 0 \\ -2 \\ 0 \\ 1 \end{bmatrix}$。

步骤 5（验算三个特殊解，逐个代回原矩阵）：

$$B\mathbf{s}_1 = \begin{bmatrix} 1(-3)+3(1) \\ 0 \\ 1(-3)+3(1) \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix} \checkmark \qquad B\mathbf{s}_2 = \begin{bmatrix} -2+2 \\ -4+4 \\ -2+1(-4)+1 \end{bmatrix}$$ 逐项算：

具体地，$B\mathbf{s}_2$ 的三个分量：

- 第 1 行：$1(-2)+3(0)+0(-4)+2(1)+1(0) = -2+2 = 0$ ✓
- 第 2 行：$0+0+1(-4)+4(1)+2(0) = -4+4 = 0$ ✓
- 第 3 行：$1(-2)+3(0)+1(-4)+6(1)+3(0) = -2-4+6 = 0$ ✓

$B\mathbf{s}_3$：

- 第 1 行：$1(-1)+3(0)+0(-2)+2(0)+1(1) = -1+1 = 0$ ✓
- 第 2 行：$0+0+1(-2)+4(0)+2(1) = -2+2 = 0$ ✓
- 第 3 行：$1(-1)+0+1(-2)+6(0)+3(1) = -1-2+3 = 0$ ✓

任意组合也自动为零：例如 $\mathbf{x} = 2\mathbf{s}_1 + \mathbf{s}_2 + 0.5\mathbf{s}_3 = \begin{bmatrix} -8.5 \\ 2 \\ -5 \\ 1 \\ 0.5 \end{bmatrix}$，由线性性 $B\mathbf{x} = 2B\mathbf{s}_1 + B\mathbf{s}_2 + 0.5B\mathbf{s}_3 = \mathbf{0}$ ✓。

步骤 6（结论与 $A = CR$ 核验）：

$$\mathrm{N}(B) = \mathrm{span}\{\mathbf{s}_1, \mathbf{s}_2, \mathbf{s}_3\}, \qquad \dim \mathrm{N}(B) = 3.$$

主元列是 B 的第 1、3 列：$\begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}$ 与 $\begin{bmatrix} 0 \\ 1 \\ 1 \end{bmatrix}$，它们构成

$$C = \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 1 \end{bmatrix}, \qquad R_{\mathrm{nz}} = \begin{bmatrix} 1 & 3 & 0 & 2 & 1 \\ 0 & 0 & 1 & 4 & 2 \end{bmatrix}, \qquad CR_{\mathrm{nz}} = \begin{bmatrix} 1 & 3 & 0 & 2 & 1 \\ 0 & 0 & 1 & 4 & 2 \\ 1 & 3 & 1 & 6 & 3 \end{bmatrix} = B \checkmark$$

（逐项抽验：$(CR)_{1,5} = 1\cdot 1 + 0\cdot 2 = 1$ ✓；$(CR)_{3,4} = 1\cdot 2 + 1\cdot 4 = 6$ ✓；$(CR)_{3,3} = 1\cdot 0 + 1\cdot 1 = 1$ ✓。）**自由列的系数就写在 R_{nz} 里**：第 2 列 $= \begin{bmatrix} 3 \\ 0 \end{bmatrix}$ 表示 $\mathbf{b}_2 = 3\mathbf{b}_1$；第 4 列 $= \begin{bmatrix} 2 \\ 4 \end{bmatrix}$ 表示 $\mathbf{b}_4 = 2\mathbf{b}_1 + 4\mathbf{b}_3$；第 5 列 $= \begin{bmatrix} 1 \\ 2 \end{bmatrix}$ 表示 $\mathbf{b}_5 = \mathbf{b}_1 + 2\mathbf{b}_3$。取负号就得到 $\mathbf{s}_1, \mathbf{s}_2, \mathbf{s}_3$ 的主元分量——**一一对应，毫无例外**。

【计算机制解说】：三个自由变量、三个特殊解、维数 3——这个例子最清楚地显示了"**主元最多只有 m 个**"这个上限的威力。B 是 **3** 行，所以主元最多 3 个；实际上只有 2 个（第 2 列没贡献），所以零空间维数 $= 5 - 2 = 3$。一般地：

$$\dim \mathrm{N}(A) = n - r \ \geq\ n - m \quad (\text{因为 } r \leq m), \qquad \dim \mathrm{N}(A) \leq n \quad (\text{因为 } r \geq 0).$$

对一个 3×5 矩阵，零空间维数**至少**是 $5 - 3 = 2$——**它不可能只有零解！** 这是"方程个数少于未知数个数时必有非零解"的线性代数版本（**3** 个方程约束不住 **5** 个未知数）。更一般地：

- **若 $n > m$（列多于行），则 $\dim \mathrm{N}(A) = n - r \geq n - m > 0$**，方程组 $A\mathbf{x} = \mathbf{0}$ 必有非零解，且 A 的列必定线性相关（n 个向量住在 $\mathbb{R}^m$ 里，$n > m$ 时必相关）。
- **若 $n \leq m$，则 $r = n$（零空间只有零）是可能的**，但需要 A 的列线性无关。此时主元列有 n 个、自由列一个也没有、特殊解一个也没有，$\mathrm{N}(A) = \{\mathbf{0}\}$。本讲特意选的都是有自由变量的例子（因为主题是"怎么求非平凡的零空间"），但你要记住这种"空零空间"的极端情形是存在的。
- **判断"一定有非零解"的最快方法**：看 $n > m$ 是否成立。列数大于行数 $\Rightarrow r \leq m < n \Rightarrow \dim \mathrm{N}(A) \geq 1$。

示例 7：快速对照表——把小矩阵的零空间一次性算完

把本讲与上一讲出现过的矩阵汇总，用同一套流程核对（建议自己盖住答案重算一遍）：

```
矩阵 A                      形状    r   主元列    自由列    dim N(A)=n−r   特殊解
------------------------------------------------------------------------------------
[1 2 ; 2 4]                  2x2    1    {1}      {2}      1              [−2,1]
[1 2 ; 3 7]                  2x2    2   {1,2}     {}       0              （没有：N={0}）
[1 2 3 ; 2 4 7]              2x3    2   {1,3}     {2}      1              [−2,1,0]
[1 2 3 ; 2 4 6 ; 1 2 3]      3x3    1    {1}     {2,3}     2              [−2,1,0], [−3,0,1]
[1 2 3 ; 2 4 6 ; 0 1 1]      3x3    2   {1,2}     {3}      1              [−1,−1,1]
[1 2 2 2; 2 4 6 8; 3 6 8 10] 3x4    2   {1,3}    {2,4}     2              [−2,1,0,0], [2,0,−2,1]
[0 1 2 ; 0 2 4]              2x3    1    {2}     {1,3}     2              [1,0,0], [0,−2,1]
[1 3 0 2 1; 0 0 1 4 2; 1 3 1 6 3] 3x5  2  {1,3}  {2,4,5}  3              [−3,1,0,0,0],[−2,0,−4,1,0],[−1,0,−2,0,1]
------------------------------------------------------------------------------------
每一行都满足：  r + dim N(A) = n ，   #特殊解 = #自由列 = n − r
```

这张表最值得看的三件事：1. **零空间维数只由 $n-r$ 决定**，与矩阵的"长相"无关。3×3 秩 2 的矩阵与 2×3 秩 2 的矩阵，零空间维数都是 1。 2. **有且仅当 $r=n$ 时**零空间是 $\{\mathbf{0}\}$（表中第二行），此时所有列都是主元列、没有自由变量、没有特殊解。 3. **自由列的位置可以任意**（第 1 列、中间列、末尾列都能当自由列），所以"自由变量是后面几个"这种直觉是错的；表里第三行和第 3×5 行都是自由列夹在主元列中间。

矩阵分解的核心思想

本讲的主线是"$\boldsymbol{R}$（RREF）是零空间的**透明化**"，它同时把三种分解串了起来：

- **$A=LU$（消元分解）**：L 可逆 $\Rightarrow \mathbf{N}(A)=\mathbf{N}(U)$。这是算法合法性的来源。本讲示例 1 算出的 $L=\begin{bmatrix}1&0&0\\2&1&0\\3&1&1\end{bmatrix}$ 与其乘积已逐项核对。若 A 需要行交换，对应 $PA=LU$，零空间同样不变（置换只是给变量重新编号）。
- **$A=CR$（r 个主元列 × RREF 的非零行，讲次 11 正式提出）**：本讲已经把它算出来了。对示例 1：

$$C=\begin{bmatrix}1&2\\2&6\\3&8\end{bmatrix}\ (\text{取 } A \text{ 的第 } 1、3 \text{ 列}),\qquad R_{\text{nz}}=\begin{bmatrix}1&2&0&-2\\0&0&1&2\end{bmatrix}\ (\text{取 RREF 的前 } 2 \text{ 行}),$$

$$CR_{\text{nz}}=\begin{bmatrix}1&2\\2&6\\3&8\end{bmatrix}\begin{bmatrix}1&2&0&-2\\0&0&1&2\end{bmatrix}=\begin{bmatrix}1&2&2&2\\2&4&6&8\\3&6&8&10\end{bmatrix}=A\ \checkmark$$

这个分解的全部内容就是"A 的每一列都是主元列的线性组合，而 RREF 的对应列记录了系数"——自由列的系数（第 2 列是 $\begin{bmatrix}2\\0\end{bmatrix}$，第 4 列是 $\begin{bmatrix}-2\\2\end{bmatrix}$）恰恰与两个特殊解的构造一一对应。$A=CR$ 说明 $\mathbf{C}(A)=\mathbf{C}(C)$，即**列空间由主元列张成**，$\dim\mathbf{C}(A)=r$。 – **秩 1 分解 $A=\sum_k \mathbf{u}_k\mathbf{v}_k^{\mathsf{T}}$**：示例 3 的 $B=\mathbf{u}\mathbf{v}^{\mathsf{T}}$ 是它的最小单元；$A=CR$ 其实就是把它组装成 r 项，"积木"数正好是秩。 – **R 与 A 的关系（一个重要区分）**：$R=EA$（E 可逆），所以 $\mathbf{N}(R)=\mathbf{N}(A)$、**行空间相同**（行空间只做行变换不变）；但 $\mathbf{C}(R)\neq\mathbf{C}(A)$（示例 1：$\mathbf{C}(R)$ 由 $\begin{bmatrix}1\\0\\0\end{bmatrix},\begin{bmatrix}0\\1\\0\end{bmatrix}$ 张成，是 xy 平面；$\mathbf{C}(A)$ 由 $\begin{bmatrix}1\\2\\3\end{bmatrix},\begin{bmatrix}2\\6\\8\end{bmatrix}$ 张成，是另一张平面）。但**列关系相同**：R 与 A 的同一组列满足同样的线性关系。**R 是一台"能读关系、但换了坐标系"的机器。** – **后续分解的伏笔**：到了讲次 14–17，$\mathbf{N}(A)\perp\mathbf{C}(A^{\mathsf{T}})$ 会把零空间与正交投影、最小二乘、QR 分解连起来；到了讲次 29，SVD 会给出"最优的正交积木分解"。而它们全都建立在"$\mathbf{N}(A)$ 是 $n-r$ 维、由特殊解张成"这个本讲结论上。

与其他讲次的关联

- **与讲次 5–6（消元、$A=LU$、列空间与零空间）**：本讲是上一讲的算法化。上一讲用手算 2×2、3×3；本讲给出对任意 $m\times n$ 都通用的流程，并把"被压掉几维"变成可数的量 $\#\{\text{自由列}\}$。
- **与讲次 8（求解 $A\mathbf{x}=\mathbf{b}$：特解 + 零空间）**：$A\mathbf{x}=\mathbf{b}$ 的**完整**解是 $\mathbf{x}=\mathbf{x}_p+\mathbf{N}(A)$，其中 $\mathbf{x}_p$ 是把所有自由变量置 0 后回代得到的**特解**。所以本讲算出的 $\mathbf{s}_1,\mathbf{s}_2$ 是把特解"铺开"的全部工具。可解性判据：$\mathbf{b}$ 必须能被主元列组合出来（等价地 $\mathbf{b}\perp\mathbf{N}(A^{\mathsf{T}})$）。
- **与讲次 9（线性无关、基、维数）**：本讲用到的核心概念在这里被正式定义。$\{\mathbf{s}_1,\dots,\mathbf{s}_{n-r}\}$ 是 $\mathbf{N}(A)$ 的**基**（无关 + 张成）；主元列是 $\mathbf{C}(A)$ 的**基**；r 的性质由此展开：任何 $n+1$ 个 $\mathbb{R}^n$ 中的向量必相关。
- **与讲次 10（四个基本子空间）**：本讲的所有计数在这里被拼成一张完整图：$\dim\mathbf{C}(A)=\dim\mathbf{C}(A^{\mathsf{T}})=r$，$\dim\mathbf{N}(A)=n-r$，$\dim\mathbf{N}(A^{\mathsf{T}})=m-r$，且 $\mathbb{R}^n=\mathbf{C}(A^{\mathsf{T}})\oplus\mathbf{N}(A)$、$\mathbb{R}^m=\mathbf{C}(A)\oplus\mathbf{N}(A^{\mathsf{T}})$。**本讲算的是右零空间 $n-r$，讲次 8–10 会提醒你左零空间是 $m-r$，两者不能混。**
- **与讲次 11（矩阵空间与 $A=CR$）**：本讲的"主元列 × RREF 非零行"就是 $A=CR$ 的实例，讲次 11 会把它提升为一般框架（并对矩阵空间、图与网络应用）。

- **与讲次 14–17（正交、投影、最小二乘、QR）**：$\mathbf{N}(A)$ 与 $\mathbf{C}(A^{\mathsf{T}})$ 正交互补是这些章节的起点；求解 $A^{\mathsf{T}}A\hat{\mathbf{x}} = A^{\mathsf{T}}\mathbf{b}$ 时 $\mathbf{N}(A^{\mathsf{T}}A) = \mathbf{N}(A)$ 这一事实（本讲算法的直接推论）保证了正规方程有唯一解（当 A 列满秩、$r = n$、$\mathbf{N}(A) = \{\mathbf{0}\}$ 时）。
- **与讲次 21–25（特征值）**：$\mathbf{N}(A - \lambda I)$ 是特征空间；$\lambda = 0$ 的特征空间就是本讲的 $\mathbf{N}(A)$，$\dim \mathbf{N}(A) > 0 \iff A$ 奇异 $\iff 0$ 是特征值。本讲的"特殊解"会在对角化（$A = S\Lambda S^{-1}$）里以"特征向量"的身份重新出现。
- **与讲次 30–33（线性变换、伪逆）**：本讲的"自由变量参数化"就是线性映射 $A : \mathbb{R}^n \to \mathbb{R}^m$ 的**核（kernel）**；"$\mathbf{x}_{\text{free}} \mapsto \mathbf{x}$"那个一一对应是核的参数化，其逆就是取坐标，正是伪逆 A^{+} 思想的萌芽。

关键要点

1. **算法三步走**：消元 → U / RREF R → 认列（主元列 / 自由列）。秩 $r =$ 主元个数 $= U$ 的非零行数 $= \dim \mathbf{C}(A)$。
2. **特殊解配方**：令一个自由变量 $= 1$、其余自由变量 $= 0$，回代解出主元变量。**每个自由变量恰好对应一个特殊解。** 从 RREF 可以抄：$\mathbf{s}_k = \begin{bmatrix} -(R \text{ 第 } \boldsymbol{f}_k \text{ 列的上面 } \boldsymbol{r} \text{ 项}) \\ \mathbf{e}_k \end{bmatrix}$。
3. **核心公式**：$\mathbf{N}(A) = \mathbf{span}\{\mathbf{s}_1, \ldots, \mathbf{s}_{n-r}\}$，$\dim \mathbf{N}(A) = n - r =$ 自由变量个数 $=$ 自由列个数。组合系数就是自由变量的取值。
4. **机制的根**：RREF 分块形式 $R = [I_r \quad F]$ 给出 $\mathbf{x}_{\text{pivot}} = -F\mathbf{x}_{\text{free}}$——**自由变量任取，主元变量被唯一决定**，这就是零空间是 $n - r$ 维参数族（以及特殊解构成基）的完整理由。
5. **消元不变零空间**：$\mathbf{N}(A) = \mathbf{N}(U) = \mathbf{N}(R)$（因为 $U = L^{-1}A$、L 可逆）；但 $\mathbf{C}(A) \neq \mathbf{C}(U)$ 一般成立。**列空间会被消元改变，列关系不会。**
6. **可解性联系（预告）**：$A\mathbf{x} = \mathbf{b}$ 有解 $\iff$ 消元时 $\mathbf{b}$ 不产生矛盾行 $0 = 1 \iff \mathbf{b} \in \mathbf{C}(A)$；有解时解集 $= \mathbf{x}_p + \mathbf{N}(A)$，维数 $n - r$。

常见误区与注意事项

1. **把"自由变量一定在后面"当成规律**。示例 4 中 $C = \begin{bmatrix} 0 & 1 & 2 \\ 0 & 2 & 4 \end{bmatrix}$ 的第 1 列就是自由列，自由变量是 x_1 与 x_3。**必须以主元位置为准**。另一类常见坑是列交换：如果为了消元而交换了两列，最后要把变量顺序换回来，否则特殊解写错了自己都不知道。
2. **忘记"自由变量要轮流取一组基"，而只取一组值**。常见错误是只写一个特殊解（比如只令 $x_2 = 1, x_4 = 0$）就说"这就是零空间"。正确的语句是"$\mathbf{N}(A)$ 由 $\mathbf{s}_1, \ldots, \mathbf{s}_{n-r}$ 张成"，维数是 $n - r$，少了向量维数就不够。
3. **算完特殊解不代回原矩阵验算**。RREF 算错一格，特殊解就全错。**必须用原矩阵 A**（不是 U、不是 R）去乘特殊解，验证得 $\mathbf{0}$。本讲示例 1 的 $\mathbf{s}_1, \mathbf{s}_2$ 都已逐项代回验算。
4. **用 U 而不是 R 回代时把系数搞错**。用 U 也能回代，但 U 的主元不一定是 1、且主元上方还有非零元，回代要**从下往上**依次代入，容易出错。建议统一化到 RREF：主元为 1、主元上方也清成 0，于是每个方程直接是 "主元变量 = 自由变量的线性组合"。
5. **混淆右零空间与左零空间**。本讲算的是 $\mathbf{N}(A) \subseteq \mathbb{R}^n$、维数 $n - r$。若题目问 $\mathbf{N}(A^{\mathsf{T}})$，那是 $\mathbb{R}^m$ 中维数 $m - r$ 的空间，必须对 A^{T}（或对 A 做列变换）重新算，不能直接把 $n - r$ 拿来用。典型例子：示例 1 的 A 是 3×4，$\dim \mathbf{N}(A) = 4 - 2 = 2$，而 $\dim \mathbf{N}(A^{\mathsf{T}}) = 3 - 2 = 1$——**两个数完全不同**。
6. **以为"有自由变量就意味着无解"**。自由变量只影响 $\mathbf{N}(A)$ 的维数（解的唯一性），不影响**存在性**。$A\mathbf{x} = \mathbf{b}$ 无解是由**矛盾行** $0 = c$（$c \neq 0$）判定的；一旦有解且有自由变量，就有无穷多解。
7. **把"特殊解"与"单位向量"混淆**。特殊解 $\mathbf{s}_k$ 只在**自由坐标**上是 $\mathbf{e}_k$，在**主元坐标**上一般不是 0（示例 1 的 $\mathbf{s}_1$ 的主元分量是 $-2, 0$）。写答案时别只写 $\mathbf{e}_1, \mathbf{e}_2$。
8. **对非零右端 $\mathbf{b}$ 用特殊解当解**。特殊解满足 $A\mathbf{s} = \mathbf{0}$，只用于齐次问题。非齐次要先求特解 $\mathbf{x}_p$，再加 $\mathbf{N}(A)$ 的组合（这就是下一讲）。

思考题（带答案）

Q1（纯计算）. 对

$$A = \begin{bmatrix} 1 & 2 & 2 & 2 \\ 2 & 4 & 6 & 8 \\ 3 & 6 & 8 & 10 \end{bmatrix}$$

(a) 写出 RREF R；(b) 指出主元列与自由列；(c) 求 $\mathbf{N}(A)$ 的一组基（特殊解）并给出 $\dim \mathbf{N}(A)$；(d) 若把 A 改为 4×5 的矩阵 $A' = [A \quad \mathbf{0}]$（即追加一列全零），$\dim \mathbf{N}(A')$ 是多少？

> ▸ **答案**
>
> (a) 消元（详见正文示例 1）：$R_2 \leftarrow R_2 - 2R_1$ 得 $(0, 0, 2, 4)$；$R_3 \leftarrow R_3 - 3R_1$ 得 $(0, 0, 2, 4)$；$R_3 \leftarrow R_3 - R_2$ 得零行；第 2 列无主元，主元在第 3 列（值 2）。归一化并向上消元：
>
> $$R = \begin{bmatrix} 1 & 2 & 0 & -2 \\ 0 & 0 & 1 & 2 \\ 0 & 0 & 0 & 0 \end{bmatrix}.$$

(b) 主元列 $= \{1,3\}$；自由列 $= \{2,4\}$；$r=2$，$n=4$。**核对**：R 的第 1、3 列构成单位阵（阶梯状），这是主元列的判据。

(c) 方程：$x_1 = -2x_2 + 2x_4$，$x_3 = -2x_4$。

- $x_2=1, x_4=0$：$\mathbf{s}_1 = \begin{bmatrix}-2\\1\\0\\0\end{bmatrix}$，验算 $A\mathbf{s}_1 = \begin{bmatrix}-2+2\\-4+4\\-6+6\end{bmatrix} = \mathbf{0}$ ✓；
- $x_2=0, x_4=1$：$\mathbf{s}_2 = \begin{bmatrix}2\\0\\-2\\1\end{bmatrix}$，验算 $A\mathbf{s}_2 = \begin{bmatrix}2-4+2\\4-12+8\\6-16+10\end{bmatrix} = \mathbf{0}$ ✓。

$$\mathrm{N}(A) = \mathrm{span}\{\mathbf{s}_1, \mathbf{s}_2\}, \qquad \dim \mathrm{N}(A) = n - r = 4 - 2 = 2.$$

（另法核对：从 R 抄——R 第 2 列 $= \begin{bmatrix}2\\0\end{bmatrix}$ 取负得 $\mathbf{s}_1$ 的主元分量 $\begin{bmatrix}-2\\0\end{bmatrix}$；$R$ 第 4 列 $= \begin{bmatrix}-2\\2\end{bmatrix}$ 取负得 $\begin{bmatrix}2\\-2\end{bmatrix}$ ✓。）

(d) $A' = [A \quad \mathbf{0}]$ 是 3×5（在 A 的右边追加**一列**全零，行数不变）。新列是全零列，消元时它当然找不到主元，所以它是**自由列**。r 不变（仍为 2），n 变成 5，故

$$\dim \mathrm{N}(A') = n' - r = 5 - 2 = 3.$$

新增的特殊解是 $\mathbf{s}_3 = \begin{bmatrix}0\\0\\0\\0\\1\end{bmatrix}$（令新的自由变量 $=1$，其余自由变量 $=0$，原主元变量全为 0），且 $A'\mathbf{s}_3 = \mathbf{0}$ ✓。**教训：加一个零列，零空间维数就加 1，因为多了一个完全冗余的方向。**

Q2（**概念 + 计算**）. 设 A 是 5×3 矩阵，消元后 RREF 为

$$R = \begin{bmatrix}1 & 0 & -1\\0 & 1 & 2\\0 & 0 & 0\\0 & 0 & 0\\0 & 0 & 0\end{bmatrix}.$$

(a) 求 $\mathrm{N}(A)$、$\dim \mathrm{N}(A)$、$\mathrm{C}(A)$ 的维数；(b) 至少写出一个零空间向量并验算它确实给出列之间的线性关系；(c) 有人说"因为 A 有 5 行，所以 $\dim \mathrm{N}(A)$ 应该是 $5 - r$"，错在哪里？

▸ **答案**

(a) 主元列 $= \{1,2\}$，自由列 $= \{3\}$；$r=2$，$n=3$。方程：$x_1 - x_3 = 0 \Rightarrow x_1 = x_3$；$x_2 + 2x_3 = 0 \Rightarrow x_2 = -2x_3$。令 $x_3 = 1$：

$$\mathbf{s} = \begin{bmatrix}1\\-2\\1\end{bmatrix}, \qquad \mathrm{N}(A) = \left\{ t\begin{bmatrix}1\\-2\\1\end{bmatrix} : t \in \mathbb{R} \right\}, \qquad \dim \mathrm{N}(A) = 3 - 2 = 1.$$

$\dim \mathrm{C}(A) = r = 2$（$\mathrm{C}(A) \subseteq \mathbb{R}^5$ 中一个 2 维子空间；它的基是 A 的第 1、2 列）。

(b) $A\mathbf{s} = \mathbf{0}$ 就是 $\mathbf{a}_1 - 2\mathbf{a}_2 + \mathbf{a}_3 = \mathbf{0}$，即

$$\mathbf{a}_3 = 2\mathbf{a}_2 - \mathbf{a}_1.$$

核对 R 的第 3 列 $\begin{bmatrix}-1\\2\\0\\\vdots\end{bmatrix}$：它正好是"$A$ 的第 3 列 $= -1\cdot$第 1 列 $+2\cdot$第 2 列 $+0$"，与上式一致 ✓。验算（$R\mathbf{s}$）：

$$R\mathbf{s} = \begin{bmatrix} 1 & 0 & -1 \\ 0 & 1 & 2 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix} \begin{bmatrix} 1 \\ -2 \\ 1 \end{bmatrix} = \begin{bmatrix} 1-1 \\ -2+2 \\ 0 \\ 0 \\ 0 \end{bmatrix} = \mathbf{0} \checkmark$$

> 因为 $\mathbf{N}(R) = \mathbf{N}(A)$，所以 $A\mathbf{s} = \mathbf{0}$ 也成立 ✓。
>
> (c) 错在把 n 当成了行数。$\mathbf{N}(A) \subseteq \mathbb{R}^n$ 的维数是 $n - r$，这里的 n 是**列数**（$= 3$，即未知数的个数），不是行数 5。行数 $m = 5$ 影响的是**左零空间**：$\dim \mathbf{N}(A^{\mathrm{T}}) = m - r = 5 - 2 = 3$，那是 $\mathbb{R}^5$ 中的空间，与本题问的 $\mathbf{N}(A)$ 不是一回事。**记忆锚点：$\mathbf{N}(A)$ 的宿主维度是"未知数个数" n，$\mathbf{N}(A^{\mathrm{T}})$ 的宿主维度是"方程个数"m。**

Q3（概念题）. 判断并说明理由。(a) "若 A 是 3×3 且 $r = 2$，则 $\mathbf{N}(A)$ 是 $\mathbb{R}^3$ 中过原点的一条直线。"(b) "自由变量取 1、其余取 0 得到的特殊解互相线性无关。"(c) "若 A 的某一列全是 0，则 $\dim \mathbf{N}(A) \geq 1$。"(d) "如果 A 的两列相同，那么 $\mathbf{N}(A)$ 里一定有向量 $\mathbf{s} = \mathbf{e}_i - \mathbf{e}_j$（两个单位向量之差）。"

> ▸ **答案**
>
> **(a) 真。** $n = 3$，$r = 2$，所以 $\dim \mathbf{N}(A) = 3 - 2 = 1$。$\mathbb{R}^3$ 中的 1 维子空间必是过原点的直线（因为子空间必含原点，而 1 维意味着所有元素都是某个非零向量的倍数）。顺带：此时 $\mathbf{C}(A) \subseteq \mathbb{R}^3$ 是 2 维的过原点平面，$2 + 1 = 3 = n$ ✓。
>
> **(b) 真。** 设第 k 个特殊解在自由坐标上取值为 $\mathbf{e}_k$（第 k 个自由变量为 1，其余为 0）。若 $\sum_k c_k \mathbf{s}_k = \mathbf{0}$，看**自由坐标**分量：左边在自由坐标上等于 $\sum_k c_k \mathbf{e}_k = (c_1, \ldots, c_{n-r})$，右边是 $\mathbf{0}$，所以所有 $c_k = 0$。故线性无关。**这就是"特殊解构成基"里"无关"那一半的证明**（"张成"那一半来自 $\mathbf{x}_{\text{pivot}} = -F\mathbf{x}_{\text{free}}$ 的唯一决定性质）。
>
> **(c) 真。** 全零列在第 j 列，消元时它不可能有主元（该列在主元行及其下方全为 0），所以第 j 列是自由列，自由变量个数 ≥ 1，故 $\dim \mathbf{N}(A) = n - r \geq 1$。具体地，$\mathbf{s} = \mathbf{e}_j$（第 j 个分量为 1、其余全 0）就一定在 $\mathbf{N}(A)$ 中：$A\mathbf{e}_j = A$ 的第 j 列 $= \mathbf{0}$ ✓。**这是最快的一个零空间向量。**
>
> **(d) 真（在可以选到合适的一对时）。** 设第 i 列与第 j 列相同（$i < j$，$\mathbf{a}_i = \mathbf{a}_j$）。则

$$A(\mathbf{e}_i - \mathbf{e}_j) = \mathbf{a}_i - \mathbf{a}_j = \mathbf{0} \checkmark$$

> 所以 $\mathbf{s} = \mathbf{e}_i - \mathbf{e}_j \in \mathbf{N}(A)$ 且 $\mathbf{s} \neq \mathbf{0}$，说明 $\dim \mathbf{N}(A) \geq 1$、列线性相关（秩 $r < n$）。更一般地：**任何"列之间的线性关系"都对应一个零空间向量，反之亦然**——$A\mathbf{x} = \mathbf{0}$ 按列写就是 $x_1\mathbf{a}_1 + \cdots + x_n\mathbf{a}_n = \mathbf{0}$，$\mathbf{x}$ 的每个分量就是那个关系的系数。这道题把本讲的三个视角（消元计数、特殊解、列关系）缝在了一起。
>
> 补充一个细节：如果第 i、j 两列相同但恰好 $i = j$（同一列），那是平凡情形，不产生非零关系；上面的构造要求 $i \neq j$。

Lecture 8: Solving Ax = b: Row Reduced Form R

概述

上一讲（Lecture 7）我们研究了 $A\mathbf{x} = \mathbf{0}$ 的零空间 N(A)：它永远是子空间，永远包含原点，维数是 $n - r$。本讲把右端项换成一般的 $\mathbf{b}$，回答两个问题：**（1）什么时候有解？** 答案是 $\mathbf{b} \in C(A)$——即消元后的增广矩阵里**不出现"0 = 非零"的矛盾行。（2）有解时解长什么样？** 答案是 $\mathbf{x} = \mathbf{x}_{\text{particular}} + \mathbf{x}_{\text{null}}$：一个**特解**加上零空间中的任意向量。

这个公式是本讲的心脏。它的几何含义极其重要：解集**不是子空间**（除非 $\mathbf{b} = \mathbf{0}$），而是零空间被特解**平移**之后得到的"仿射子空间"——在 $\mathbb{R}^3$ 中是一条不过原点的直线或一个不过原点的平面。同时我们引入 **row reduced echelon form（RREF，行最简形）R**，用它统一处理 $m \times n$ 矩阵、任意右端项的**全部**情形，并给出 Strang 著名的 (r, m, n) 分类表。

核心概念的几何直觉

概念一：可解性判据（Solvability）

- **定义与目的**：$A\mathbf{x} = \mathbf{b}$ 有解 $\iff$ $\mathbf{b} \in C(A)$ $\iff$ 消元过程中增广矩阵 $[A \mid \mathbf{b}]$ 不出现形如 $[\mathbf{0} \mid \text{非零}]$ 的行。等价地：**$\mathbf{b}$ 必须满足与 A 的各行完全相同的线性关系。**
- **几何直觉（它在空间中是什么样子？）**：$A\mathbf{x}$ 的所有可能取值恰好铺满列空间 $C(A)$——一个穿过原点的平面/直线/整个空间。$\mathbf{b}$ 落在里面，就有解；落在外面一点点，就无解，而且**没有任何"近似意义上的解"**（近似解法要等 Lecture 16 的最小二乘）。"$\mathbf{b}$ 满足与行相同的线性关系"，意思是：若 A 的某几行线性组合为零，则 $\mathbf{b}$ 的对应分量做同样的组合也必须为零。这个"隐藏的约束"正是无解时矛盾行的来源。
- **具体示例**：本讲主例

$$A = \begin{bmatrix} 1 & 2 & 2 & 2 \\ 2 & 4 & 6 & 8 \\ 3 & 6 & 8 & 10 \end{bmatrix}.$$

注意第 2 行与第 1 行的关系：A 的三行满足 $1 \cdot \text{row}_1 + 1 \cdot \text{row}_2 - 1 \cdot \text{row}_3 = \mathbf{0}$（验算：$[1,2,2,2] + [2,4,6,8] - [3,6,8,10] = [0,0,0,0]$）。所以任何可解的 $\mathbf{b}$ 必须满足 $b_1 + b_2 - b_3 = 0$。对 $\mathbf{b}_1$：$1+5-6=0$ ✓ 有解。对 $\mathbf{b}_2 = (1,5,7)^T$：$1+5-7 = -1 \neq 0$ ✗ 无解。这个"$\mathbf{b}$ 必须满足 $b_1 + b_2 - b_3 = 0$"就是我们后面会称为**左零空间**的向量 $\mathbf{y} = (1,1,-1)^T$ 给出的约束（$A^T\mathbf{y} = \mathbf{0}$，验算 $A^T(1,1,-1) = (0,0,0,0)^T$）。

概念二：特解（Particular Solution）$\mathbf{x}_p$

- **定义与目的**：$\mathbf{x}_p$ 是满足 $A\mathbf{x} = \mathbf{b}$ 的**任意一个**解。求法：把**所有自由变量取 0**，然后从 R 中回代解出主元变量。
- **几何直觉（它在空间中是什么样子？）**：$\mathbf{x}_p$ 是解集这个"漂浮的直线/平面"上的**一个锚点**。选哪个都行——不同的锚点给出同样的解集（只是参数化不同）。把自由变量取 $\mathbf{0}$，等价于在解集与"自由坐标轴构成的坐标子空间"的交点处下锚，这是最省事的锚点。
- **具体示例**：主例对 $\mathbf{b}_1 = (1,5,6)^T$ 得到 $\mathbf{x}_p = (-2,\ 0,\ \frac{3}{2},\ 0)^T$。验算：直接代入原矩阵 $A\mathbf{x}_p = (1,5,6)^T$ ✓。

概念三：零空间 N(A) 是"解集的形状"

- **定义与目的**：N(A) 是 $A\mathbf{x} = \mathbf{0}$ 的全部解，是 $\mathbb{R}^n$ 中的**子空间**。对主例 $\dim N(A) = n - r = 4 - 2 = 2$。
- **几何直觉（它在空间中是什么样子？）**：N(A) 描述解集的"自由度方向"——你可以沿这些方向任意滑动，$A\mathbf{x}$ 仍然等于 $\mathbf{b}$。在 $\mathbb{R}^n$ 中它是一个穿过原点的平面（这里 $n = 4$，所以是 4 维空间里的 2 维平面）。
- **具体示例**：主例的两个特殊解（special solutions）为

$$\mathbf{s}_1 = \begin{bmatrix} -2 \\ 1 \\ 0 \\ 0 \end{bmatrix}, \qquad \mathbf{s}_2 = \begin{bmatrix} 2 \\ 0 \\ -2 \\ 1 \end{bmatrix}.$$

验算 $A\mathbf{s}_1 = (0,0,0)^T$、$A\mathbf{s}_2 = (0,0,0)^T$ ✓。

概念四：完整解 = 特解 + 零空间（本讲最重要的一张图）

$$A\mathbf{x} = \mathbf{b} \quad \Longrightarrow \quad \mathbf{x} = \mathbf{x}_p + \mathbf{x}_n, \qquad \mathbf{x}_n \in N(A).$$

- **定义与目的**：把"一个锚点 + 形状"拼起来。任何解都可写成 $\mathbf{x}_p + (\text{某个零空间向量})$；反之任何这种形式的向量都是解（因为 $A(\mathbf{x}_p + \mathbf{x}_n) = \mathbf{b} + \mathbf{0} = \mathbf{b}$）。
- **几何直觉（它在空间中是什么样子？）**：这是本讲的灵魂。**解集是 N(A) 被 $\mathbf{x}_p$ 平移的结果**，写作 $\mathbf{x}_p + N(A)$，称为 $N(A)$ 的一个**陪集（coset）**或 affine subspace（仿射子空间）。关键：

> 它**不是**子空间，因为**它不过原点**——$\mathbf{x} = \mathbf{0}$ 一般不是解（$\mathbf{0}$ 是解当且仅当 $\mathbf{b} = \mathbf{0}$）。

平移不改变"形状"（维数、方向、平行性），只改变"位置"。所以解集与 N(A) **平行**：同维数、同方向，只是挪了一个 $\mathbf{x}_p$。

```
解集 = x_p + N(A)：与 N(A) 平行的一个"复制品"

┌──────────────────── 以 R^3 为例（r = 2, n = 3, dim N(A) = 1）────────────────┐
│                                                                              │
│       N(A)：过原点的直线            解集 x_p + N(A)：与它平行、但不过原点    │
│                                                                              │
│             /                              /  ← 解集（一条平移后的直线）    │
│            /  s                           /                                 │
│           /                               /                                  │
│   ──────●──────►                    ─────/──────►                          │
│         origin  O                       /    ↑                             │
│          (0 是解)                      /     x_p（锚点，特解）              │
│                                       ●                                      │
│                                      /  N(A) 的方向 s 是同一个               │
│                                     /                                        │
│                                                                              │
│   若 b ≠ 0：解集上的点 = x_p + c·s，c 取遍所有实数                           │
│   c = 0 给出 x_p 本身；c 变化时沿直线滑动。                                  │
│   注意：把这条直线整体平移 −x_p 就得到 N(A)。                                │
└──────────────────────────────────────────────────────────────────────────────┘

以 R^3 为例（r = 1, n = 3, dim N(A) = 2）：
解集是一个"不过原点的平面"，它与过原点的 N(A) 平行。

          N(A)（过原点）                解集 x_p + N(A)（平行、错开）
             / |                              / |
           /   |                            /   |
         /_____|___                       /_____|___      ← 两平面平行
                                            ↑
                                          x_p 把整个平面顶出去
```

概念五：秩 r 与解的结构——(r, m, n) 分类表

- **定义与目的**：$r = \mathrm{rank}(A) =$ 主元个数 $=$ 主元列个数 $= \dim C(A)$。只凭 r, m, n 三个数，就能**完全判定**解的存在性与个数。
- **几何直觉**：r 同时量度"列空间有多大"（r 维）与"零空间有多大"（$n - r$ 维）。r 越大，$C(A)$ 越满（越容易命中 $\mathbf{b}$），N(A) 越小（解越少）。r 恰好是这两种"多少"的平衡点。
- **具体示例**：见下面的完整分类表（数字均已验算）。

```
┌──────────────────────── 秩 r 与 Ax = b 的解 ────────────────────────┐
│  m = 方程个数（行数），n = 未知数个数（列数），r = rank(A)          │
│                                                                     │
│  ①  r = m = n      A 可逆：          唯一解 x = A^{-1} b           │
│                      (C(A) = R^n, b 永远在里面；N(A) = {0}，无自由度) │
│                                                                     │
│  ②  r = m < n      行满秩：          无穷多解（永远有解）          │
│                      (C(A) = R^m，任何 b 都有解；dim N = n−r > 0)   │
│                                                                     │
│  ③  r = n < m      列满秩：          0 个或 1 个解                 │
│                      (N(A) = {0}，至多一解；C(A) 是 R^m 中的真子集，  │
│                       有的 b 落在外面 → 无解)                       │
│                                                                     │
│  ④  r < m 且 r < n  一般情形：       0 个或无穷多解                │
│                      (两个"缺"同时存在)                            │
└─────────────────────────────────────────────────────────────────────┘

记忆口诀：只要 r < m，就可能有"无解"（b 可能落在 C(A) 外）；
          只要 r < n，就一定有"多解"（N(A) 非平凡）。
          有解时解的个数 = 1（若 r = n，此时 r < m 亦可）或无穷多（若 r < n）。
```

计算步骤与手算演示

示例 1（必做，有解情形）： $A = \begin{bmatrix} 1 & 2 & 2 & 2 \\ 2 & 4 & 6 & 8 \\ 3 & 6 & 8 & 10 \end{bmatrix}$，$\mathbf{b} = (1, 5, 6)^T$

步骤 1：写成增广矩阵 $[A \mid \mathbf{b}]$。

```
[ 1  2  2  2 | 1 ]
[ 2  4  6  8 | 5 ]
[ 3  6  8 10 | 6 ]
```

步骤 2：消元（前向消元，得到阶梯形）。

用 row₁ 消去 col₁ 下方：

- row₂ ← row₂ $-2\cdot$row₁：$[2,4,6,8\mid 5]-[2,4,4,4\mid 2]=[0,0,2,4\mid 3]$
- row₃ ← row₃ $-3\cdot$row₁：$[3,6,8,10\mid 6]-[3,6,6,6\mid 3]=[0,0,2,4\mid 3]$

```
[ 1  2  2  2 | 1 ]
[ 0  0  2  4 | 3 ]
[ 0  0  2  4 | 3 ]      ← row₃ 与 row₂ 完全相同
```

再 row₃ ← row₃ − row₂：

```
[ 1  2  2  2 | 1 ]
[ 0  0  2  4 | 3 ]      ← U（阶梯形），主元在 col 1 与 col 3
[ 0  0  0  0 | 0 ]      ← 零行，且右端也是 0：一致（consistent）
```

步骤 3：继续消元到 RREF（回代 + 主元归 1）。

row₂ ← $\frac{1}{2}$row₂：

```
[ 1  2  2  2 | 1 ]
[ 0  0  1  2 | 3/2 ]
[ 0  0  0  0 | 0 ]
```

row₁ ← row₁ $-2\cdot$row₂：

```
[ 1  2  0 -2 | -2 ]     ← R（RREF）            ┌ d（变换后的右端）
[ 0  0  1  2 |  3/2 ]   ← 主元行（pivot rows）  │
[ 0  0  0  0 |  0   ]   ← 零行（0 = 0）        ┘
```

于是

$$R=\begin{bmatrix}1&2&0&-2\\0&0&1&2\\0&0&0&0\end{bmatrix},\qquad \mathbf{d}=\begin{bmatrix}-2\\3/2\\0\end{bmatrix}.$$

步骤 4：读出主元变量与自由变量。 主元列是第 1、3 列（x_1,x_3 是**主元变量**）；非主元列是第 2、4 列（x_2,x_4 是**自由变量**）。$r=2$，$\dim N(A)=n-r=4-2=2$——**两个自由变量，正好对应两个特殊解**。

步骤 5：求特解 $\mathbf{x}_p$（自由变量全取 0）。 令 $x_2=0,\ x_4=0$，则 R 的两行给出

$$x_1=-2,\qquad x_3=\tfrac{3}{2}.$$

$$\boxed{\mathbf{x}_p=\begin{bmatrix}-2\\0\\3/2\\0\end{bmatrix}}$$

代回原矩阵验算：

$$A\mathbf{x}_p=\begin{bmatrix}1&2&2&2\\2&4&6&8\\3&6&8&10\end{bmatrix}\begin{bmatrix}-2\\0\\3/2\\0\end{bmatrix}=\begin{bmatrix}-2+0+3+0\\-4+0+9+0\\-6+0+12+0\end{bmatrix}=\begin{bmatrix}1\\5\\6\end{bmatrix}=\mathbf{b}\ \checkmark$$

步骤 6：求零空间的两个特殊解（逐一令某个自由变量为 1，其余自由变量为 0）。

从 RREF 的方程读出：$x_1+2x_2-2x_4=0$，$x_3+2x_4=0$，即

$$x_1=-2x_2+2x_4,\qquad x_3=-2x_4.$$

- 令 $x_2=1,\ x_4=0$：$x_1=-2,\ x_3=0$，得 $\mathbf{s}_1=(-2,1,0,0)^T$。
- 令 $x_2=0,\ x_4=1$：$x_1=2,\ x_3=-2$，得 $\mathbf{s}_2=(2,0,-2,1)^T$。

验算 $A\mathbf{s}_1=(0,0,0)^T$、$A\mathbf{s}_2=(0,0,0)^T$ ✓（用原矩阵，不是 R！）。

步骤 7：写出完整解（通解）。

$$\boxed{\mathbf{x} = \mathbf{x}_p + c_1\mathbf{s}_1 + c_2\mathbf{s}_2 = \begin{bmatrix}-2\\0\\3/2\\0\end{bmatrix} + c_1\begin{bmatrix}-2\\1\\0\\0\end{bmatrix} + c_2\begin{bmatrix}2\\0\\-2\\1\end{bmatrix}, \qquad c_1, c_2 \in \mathbb{R}.}$$

任取一组参数都是解，例如 $c_1 = 1, c_2 = 0$ 时 $\mathbf{x} = (-4, 1, 3/2, 0)^T$，验算 $A\mathbf{x} = (1, 5, 6)^T$ ✓。$c_1 = c_2 = 0$ 时回到 $\mathbf{x}_p$。

【计算机制解说】 为什么可以"$\mathbf{x}_p$ + 零空间"这样拼？设 $\mathbf{x}$ 与 $\mathbf{x}_p$ 都是解，则

$$A(\mathbf{x} - \mathbf{x}_p) = A\mathbf{x} - A\mathbf{x}_p = \mathbf{b} - \mathbf{b} = \mathbf{0},$$

所以差 $\mathbf{x} - \mathbf{x}_p$ 必在 N(A) 中，于是 $\mathbf{x} = \mathbf{x}_p + \mathbf{x}_n$。反过来，对任意 $\mathbf{x}_n \in N(A)$，$A(\mathbf{x}_p + \mathbf{x}_n) = \mathbf{b} + \mathbf{0} = \mathbf{b}$。两句话合起来：**解集 $= \mathbf{x}_p + N(A)$，不多不少**。（注意这个论证用到了 A 是线性的：$A(\mathbf{u} + \mathbf{v}) = A\mathbf{u} + A\mathbf{v}$。线性正是"解集可平移"的根源；非线性方程组就没有这种结构。）

为什么特解可以"自由变量取 0"？因为在 RREF 中，自由变量是**完全自由**的参数：任给自由变量一组值，主元变量都被唯一确定。所以自由变量取 $\mathbf{0}$ 一定给出一个合法解。这也是为什么"解的个数"只由 $\dim N(A) = n - r$ 决定。

示例 2（必做，无解情形）：同一个 A，$\mathbf{b} = (1, 5, 7)^T$

步骤 1–3：消元。 前两步与示例 1 完全相同（A 的部分不变），只跟踪右端：

- 初始右端 $(1, 5, 7)$。
- $\text{row}_2 \leftarrow \text{row}_2 - 2\text{row}_1$：$5 - 2 = 3$。
- $\text{row}_3 \leftarrow \text{row}_3 - 3\text{row}_1$：$7 - 3 = 4$。
- $\text{row}_3 \leftarrow \text{row}_3 - \text{row}_2$：$4 - 3 = 1$。

```
[ 1  2  2  2 | 1 ]
[ 0  0  2  4 | 3 ]
[ 0  0  0  0 | 1 ]     ← ★ 矛盾行：0·x₁+0·x₂+0·x₃+0·x₄ = 1
```

化成 RREF：

$$[R \mid \mathbf{d}] = \left[\begin{array}{cccc|c} 1 & 2 & 0 & -2 & -2 \\ 0 & 0 & 1 & 2 & 3/2 \\ 0 & 0 & 0 & 0 & 1 \end{array}\right].$$

步骤 4：读出矛盾。 最后一行是 $0 = 1$，**矛盾**。所以**无解**。

步骤 5：用"行关系"解释。 A 的行满足 $\text{row}_1 + \text{row}_2 - \text{row}_3 = \mathbf{0}$（前面已验算）。同一个组合作用在 $\mathbf{b}$ 上：

$$b_1 + b_2 - b_3 = 1 + 5 - 7 = -1 \neq 0.$$

左端是"行的零组合"，右端却不为零，这就是矛盾的来源。换句话说，$\mathbf{y} = (1, 1, -1)^T$ 满足 $A^T\mathbf{y} = \mathbf{0}$（验算得 $(0, 0, 0, 0)^T$），而 $\mathbf{y}^T\mathbf{b} = -1 \neq 0$。**任何位于左零空间 N(Aᵀ) 中的 $\mathbf{y}$，都必须满足 $\mathbf{y}^T\mathbf{b} = 0$，否则无解。** 这正是 Lecture 10 的可解性定理 $\mathbf{b} \in C(A) \iff \mathbf{b} \perp N(A^T)$ 的雏形。

【计算机制解说】 为什么"零行 + 非零右端"就一定是无解，而不是"有解的另一种形式"？因为消元是对**整个增广矩阵的行**做可逆的行变换（交换、倍乘非零数、加上另一行的倍数）。这些操作**不改变解集**：任何让变换前方程组成立的 $\mathbf{x}$ 也让变换后成立，反之亦然。所以变换后的方程组与原方程组**同解**。而变换后的第三行说的是"对所有 x_1, x_2, x_3, x_4：$0 = 1$"——这是逻辑上永假的命题，任何 $\mathbf{x}$ 都不能满足。既然同解，原方程组也无解。这就是"消元保持解集"的严格含义，也是为什么增广矩阵的右端必须和左端**同步**消元（只对 A 消元、不同步处理 $\mathbf{b}$ 是初学者最常见的错误）。

示例 3（几何：$\mathbb{R}^3$ 中一条不过原点的直线）

取

$$A_3 = \begin{bmatrix}1 & 2 & 3\\2 & 5 & 8\\3 & 7 & 11\end{bmatrix}, \qquad \text{row}_3 = \text{row}_1 + \text{row}_2.$$

步骤 1：消元求 RREF。

- $\text{row}_2 \leftarrow \text{row}_2 - 2\text{row}_1$：$[0, 1, 2]$。
- $\text{row}_3 \leftarrow \text{row}_3 - 3\text{row}_1$：$[0, 1, 2]$。
- $\text{row}_3 \leftarrow \text{row}_3 - \text{row}_2$：$[0, 0, 0]$。
- 回代：$\text{row}_1 \leftarrow \text{row}_1 - 2\text{row}_2$：$[1, 0, -1]$。

```
[ 1  0 −1 ]
[ 0  1  2 ]      r = 2,  自由变量 x₃, dim N(A₃) = 3 − 2 = 1
[ 0  0  0 ]
```

步骤 2：零空间（一条过原点的直线）。 $x_1 = x_3,\ x_2 = -2x_3$。令 $x_3 = 1$：$\mathbf{s} = (1,-2,1)^T$。验算 $A_3\mathbf{s} = (0,0,0)^T$ ✓。

步骤 3：取 $\mathbf{b} = (1,3,4)^T$。 检查行关系：$b_1 + b_2 - b_3 = 1 + 3 - 4 = 0$ ✓ 有解。增广 RREF：

$$[R \mid \mathbf{d}] = \begin{bmatrix} 1 & 0 & -1 & | & -1 \\ 0 & 1 & 2 & | & 1 \\ 0 & 0 & 0 & | & 0 \end{bmatrix}.$$

步骤 4：特解。 $x_3 = 0 \Rightarrow x_1 = -1,\ x_2 = 1$，$\mathbf{x}_p = (-1,1,0)^T$。验算 $A_3\mathbf{x}_p = (1,3,4)^T$ ✓。

步骤 5：通解与几何。

$$\mathbf{x} = \begin{bmatrix} -1 \\ 1 \\ 0 \end{bmatrix} + c\begin{bmatrix} 1 \\ -2 \\ 1 \end{bmatrix}.$$

验算 $c = 2$：$\mathbf{x} = (1,-3,2)^T$，$A_3\mathbf{x} = (1,3,4)^T$ ✓；$c = -1$：$\mathbf{x} = (-2,3,-1)^T$，$A_3\mathbf{x} = (1,3,4)^T$ ✓。

几何结论：解集是 $\mathbb{R}^3$ 中**一条直线**，方向为 $(1,-2,1)$，**但它不过原点**（$\mathbf{0}$ 不是解，因为 $A_3\mathbf{0} = \mathbf{0} \neq \mathbf{b}$）。它与过原点的 N($A_3$)（同一条方向的直线）**平行**，只是平移了 $\mathbf{x}_p$。这正是"仿射子空间"最直观的形象。

步骤 6：对照无解情形 $\mathbf{b} = (1,3,6)^T$。 $b_1 + b_2 - b_3 = 1 + 3 - 6 = -2 \neq 0$，预测无解。增广 RREF：

$$[R \mid \mathbf{d}] = \begin{bmatrix} 1 & 0 & -1 & | & -1 \\ 0 & 1 & 2 & | & 1 \\ 0 & 0 & 0 & | & 2 \end{bmatrix} \Rightarrow\ 0 = 2 \text{ 矛盾 } \checkmark$$

【计算机制解说】 为什么 $r = 2 < 3 = n$ 在 $\mathbb{R}^3$ 中给出"直线"而不是"平面"？解集维数 $= n - r = 3 - 2 = 1$，而 $\mathbb{R}^3$ 中 1 维对象就是直线。这里的维数由 $r < m$ **给出了一个自由的约束**：A 的三行其实只有两条独立信息（第三行是前两行之和），所以三个方程只把 $\mathbb{R}^3$ 中的点限制到"两条独立平面之交"＝一条直线。**"多余的行"不提供新信息**——这正是 $r < m$ 的含义，也是"m 个方程里真正起作用的只有 r 个"的几何翻译。

示例 4（秩分类表四个格子各一个算例，全部验算）

① $r = m = n$：唯一解。 $A = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}$，$\mathbf{b} = (5,11)^T$。

$$\det A = 1 \cdot 4 - 2 \cdot 3 = -2 \neq 0 \ \Rightarrow\ A^{-1} \text{ 存在.}$$

$$A^{-1} = \frac{1}{-2}\begin{bmatrix} 4 & -2 \\ -3 & 1 \end{bmatrix} = \begin{bmatrix} -2 & 1 \\ 3/2 & -1/2 \end{bmatrix}, \qquad \mathbf{x} = A^{-1}\mathbf{b} = \begin{bmatrix} -2 \cdot 5 + 1 \cdot 11 \\ \frac{3}{2} \cdot 5 - \frac{1}{2} \cdot 11 \end{bmatrix} = \begin{bmatrix} 1 \\ 2 \end{bmatrix}.$$

验算 $A(1,2)^T = (1+4,\ 3+8)^T = (5,11)^T = \mathbf{b}$ ✓。几何：$C(A) = \mathbb{R}^2$，$\mathbf{b}$ 必在里面；$N(A) = \{\mathbf{0}\}$，无自由度，所以恰好一个解。

② $r = m < n$：无穷多解（永远有解）。 $A = \begin{bmatrix} 1 & 2 & 3 \\ 2 & 4 & 7 \end{bmatrix}$（$m = 2, n = 3$），$\mathbf{b} = (1,3)^T$。

```
RREF:  [ 1  2  0 ]      r = 2 = m,  自由变量 x₂,  dim N = 3 − 2 = 1
       [ 0  0  1 ]
```

增广：$\begin{bmatrix} 1 & 2 & 0 & | & -2 \\ 0 & 0 & 1 & | & 1 \end{bmatrix}$。特解（$x_2 = 0$）：$\mathbf{x}_p = (-2,0,1)^T$；零空间（$x_2 = 1$）：$\mathbf{s} = (-2,1,0)^T$。

$$\mathbf{x} = \begin{bmatrix} -2 \\ 0 \\ 1 \end{bmatrix} + c\begin{bmatrix} -2 \\ 1 \\ 0 \end{bmatrix}.$$

验算 $A\mathbf{x}_p = (-2+0+3,\ -4+0+7)^T = (1,3)^T$ ✓；$A\mathbf{s} = (-2+2+0,\ -4+4+0)^T = (0,0)^T$ ✓。几何：$C(A) = \mathbb{R}^2$（两行独立），所以**任何 $\mathbf{b}$ 都有解**；$n - r = 1$ 给出一个自由方向，解集是 $\mathbb{R}^3$ 中一条不过原点的直线。（注意：只要 $r = m$，$\mathbf{b}$ 就永远可解，这就是"行满秩永不卡壳"。）

③ $r = n < m$：0 个或 1 个解。 $A = \begin{bmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \end{bmatrix}$（$m = 3, n = 2$）。

```
RREF:  [ 1  0 ]
       [ 0  1 ]      r = 2 = n,  dim N = 2 − 2 = 0
       [ 0  0 ]
```

- 取 $\mathbf{b}=(1,2,3)^T$：增广 RREF 为 $\left[\begin{array}{cc|c}1&0&0\\0&1&1\\0&0&0\end{array}\right]$，**唯一解** $\mathbf{x}=(0,1)^T$。验算 $A(0,1)^T=(1,2,3)^T=\mathbf{b}$ ✓。
- 取 $\mathbf{b}=(1,2,4)^T$：增广 RREF 为 $\left[\begin{array}{cc|c}1&0&0\\0&1&1\\0&0&1\end{array}\right]$，矛盾行 $0=1$，**无解**。

几何：$N(A)=\{\mathbf{0}\}$（两列独立，验算 $\det\begin{bmatrix}1&1\\1&2\end{bmatrix}=1\neq 0$），所以最多一解；$C(A)$ 是 $\mathbb{R}^3$ 中的**平面**（不是整个 $\mathbb{R}^3$），所以大多数 $\mathbf{b}$ 落在平面外，无解。要看 $\mathbf{b}$ 是否在平面上，可以用左零空间给出的约束：$m=3, r=2 \Rightarrow \dim N(A^T)=m-r=1$，所以**恰好有一条**独立约束。求 $\mathbf{y}$：由 $\mathbf{row}_2-\mathbf{row}_1=[0,1,1]$、$\mathbf{row}_3-\mathbf{row}_1=[0,2,2]$ 可见行关系为 $1\cdot\mathbf{row}_1-2\cdot\mathbf{row}_2+1\cdot\mathbf{row}_3=\mathbf{0}$（验算：$[1,1]-[2,4]+[1,3]=[0,0]$ ✓）。所以可解条件为 $b_1-2b_2+b_3=0$。检：$(1,2,3)$：$1-4+3=0$ ✓；$(1,2,4)$：$1-4+4=1\neq 0$ ✗。**这条约束把 $\mathbb{R}^3$ 中的 $\mathbf{b}$ 限制到一个过原点的平面，正是 $C(A)$ 本身。**

④ $r<m$ 且 $r<n$：0 个或无穷多解。 就是示例 1/2 的主例：A（3×4，$r=2$）。$\mathbf{b}_1=(1,5,6)^T$ 给出无穷多解（两个自由变量）；$\mathbf{b}_2=(1,5,7)^T$ 无解。**几何**：$C(A)$ 是 $\mathbb{R}^3$ 中的平面（$r=2<m=3$），所以可能有解可能没有；$N(A)$ 是 $\mathbb{R}^4$ 中的 2 维平面（$r=2<n=4$），所以有解时必有无穷多。

示例 5（$\mathbb{R}^3$ 中一个不过原点的平面）

取 $A_1=\begin{bmatrix}1&2&3\\2&4&6\\3&6&9\end{bmatrix}$（每行成比例，$r=1$），$\mathbf{b}=(1,2,3)^T$。

步骤 1：RREF。 第 2、3 行都是第 1 行的倍数，消元后全变零行：

```
[ 1  2  3 ]      r = 1,  自由变量 x₂, x₃,  dim N(A₁) = 3 − 1 = 2
[ 0  0  0 ]
[ 0  0  0 ]
```

步骤 2：特解。 $x_2=x_3=0\Rightarrow x_1=1$，$\mathbf{x}_p=(1,0,0)^T$。验算 $A_1\mathbf{x}_p=(1,2,3)^T=\mathbf{b}$ ✓。

步骤 3：零空间的两个特殊解。 $x_1=-2x_2-3x_3$。

- $x_2=1, x_3=0$：$\mathbf{s}_1=(-2,1,0)^T$，验算 $A_1\mathbf{s}_1=(0,0,0)^T$ ✓。
- $x_2=0, x_3=1$：$\mathbf{s}_2=(-3,0,1)^T$，验算 $A_1\mathbf{s}_2=(0,0,0)^T$ ✓。

步骤 4：通解。

$$\mathbf{x}=\begin{bmatrix}1\\0\\0\end{bmatrix}+c_1\begin{bmatrix}-2\\1\\0\end{bmatrix}+c_2\begin{bmatrix}-3\\0\\1\end{bmatrix}=\begin{bmatrix}1-2c_1-3c_2\\c_1\\c_2\end{bmatrix}.$$

验算 $c_1=1, c_2=2$：$\mathbf{x}=(-7,1,2)^T$，第一行点积 $-7+2+6=1$ ✓（且三行同值 $1,2,3$）。

几何：解集是 $\mathbb{R}^3$ 中的**一个平面**——那正是方程 $x_1+2x_2+3x_3=1$ 的图形。它**不过原点**（$0+0+0=0\neq 1$）。它平行于过原点的 $N(A_1)$（即平面 $x_1+2x_2+3x_3=0$）。**当 $r=1$ 时，$A\mathbf{x}=\mathbf{b}$ 本质上只是"一个方程"，其余两行和它重复。** 注意 A_1 对称、$r=1$、$n=3$，是"最退化的非零矩阵"。

示例 6（窄矩阵 $m<n$：$r=m$ 时 $\mathbf{b}$ 永远可解，用两个不同的 $\mathbf{b}$ 对照）

取 $A=\begin{bmatrix}1&2&3\\1&3&5\end{bmatrix}$（$m=2,\ n=3$，两行线性无关）。

步骤 1：消元求 RREF。 $\mathbf{row}_2\leftarrow\mathbf{row}_2-\mathbf{row}_1=[0,1,2]$；再 $\mathbf{row}_1\leftarrow\mathbf{row}_1-2\mathbf{row}_2=[1,0,-1]$：

```
RREF(A) = [ 1  0 −1 ]      r = 2 = m < n = 3
          [ 0  1  2 ]      主元列 1、2；自由变量 x₃；dim N(A) = 3 − 2 = 1
```

步骤 2：取 $\mathbf{b}=(1,1)^T$。 增广消元：

$$[R\mid\mathbf{d}]=\left[\begin{array}{ccc|c}1&0&-1&1\\0&1&2&0\end{array}\right].$$

步骤 3：特解（$x_3=0$）。 $x_1=1,\ x_2=0$，$\mathbf{x}_p=(1,0,0)^T$。验算 $A\mathbf{x}_p=(1,1)^T=\mathbf{b}$ ✓。

步骤 4：零空间（$x_3=1$）。 $x_1=x_3=1$，$x_2=-2x_3=-2$，$\mathbf{s}=(1,-2,1)^T$。验算 $A\mathbf{s}=(1-4+3,\ 1-6+5)^T=(0,0)^T$ ✓。

步骤 5：通解。

$$\mathbf{x}=\begin{bmatrix}1\\0\\0\end{bmatrix}+c\begin{bmatrix}1\\-2\\1\end{bmatrix}.$$

步骤 6：换 $\mathbf{b}=(1,2)^T$ 再算一遍（这就是 $r=m$ 的威力）。 增广消元：

$$[R\mid \mathbf{d}']=\left[\begin{array}{ccc|c}1&0&-1&-1\\0&1&2&1\end{array}\right].$$

特解（$x_3=0$）：$\mathbf{x}_p'=(-1,1,0)^T$。通解：

$$\mathbf{x}=\begin{bmatrix}-1\\1\\0\end{bmatrix}+c\begin{bmatrix}1\\-2\\1\end{bmatrix}.$$

步骤 7：对照与结论。

```
┌──────────── r = m = 2 < n = 3：b 永远可解，自由方向恒定 ────────────┐
│                                                                    │
│  b = (1,1)   → 解集 = (1,0,0)  + c·(1,−2,1)                        │
│  b = (1,2)   → 解集 = (−1,1,0) + c·(1,−2,1)                        │
│                          └──────── 方向完全相同 ────────┘          │
│                                                                    │
│  两条平行直线（都不过原点，都平行于 N(A) 的方向 (1,−2,1)）          │
│  不同的 b 只是把同一方向的直线平移到不同的位置。                    │
│  再换任何 b（如 (2,5) → xp=(−4,3,0)）也是同样结构。                 │
└────────────────────────────────────────────────────────────────────┘
```

（$(2,5)^T$ 的验算：增广 RREF 为 $\left[\begin{array}{ccc|c}1&0&-1&-4\\0&1&2&3\end{array}\right]$，$x_3=0$ 给 $\mathbf{x}_p=(-4,3,0)^T$，且 $A\mathbf{x}_p=(-4+6,\ -4+9)^T=(2,5)^T$ ✓。）

【计算机制解说】 为什么 $r=m$ 时**无论** $\mathbf{b}$ 是什么都可解，而 $r<m$ 就可能无解？看消元后 R 的形状：$r=m$ 意味着**每一行都有主元**，所以 R 里**没有零行**，也就不可能出现"$0=$ 非零"。既然矛盾的唯一来源（零行）不存在，$\mathbf{b}$ 必可解。反之，$r<m$ 时 R 至少有 $m-r$ 个零行，这些零行对应的右端分量就成了必须为零的约束（即 $\mathbf{y}^T\mathbf{b}=0$ 对 $\mathbf{y}\in N(A^T)$），一旦违反就无解。**"零行的个数 $m-r$"恰好等于"$\mathbf{b}$ 必须满足的独立约束个数"，这也与 $\dim N(A^T)=m-r$ 一致**——无解的可能性正是由这些零行带来的。

同时，$r=m<n$ 时自由变量个数 $n-r>0$ 恒成立，所以**有解就必有无穷多解**。**"永远可解 + 永远多解"是 $r=m<n$ 这一格的完整特征。**

矩阵分解的核心思想

本讲的主角虽然是一组消元动作，但它对应着一条完整的分解线索。

（1）消元 ↔ $A=LU$（回顾 Lecture 2–4）。 对 A 的前向消元给出 $A=LU$：L 是下三角乘子矩阵（对角线为 1），U 是阶梯形。本讲主例中

```
前向消元得到          [ 1  2  2  2 ]              乘子
                      [ 0  0  2  4 ]   =  U          L[1,0] = 2,  L[2,0] = 3,  L[2,1] = 1
                      [ 0  0  0  0 ]
```

（第三行的乘子在一开始是 $\mathbf{3}$，减掉 row_2 后 row_3 变零行，说明 row_3 最终是 row_1、row_2 的线性组合。）

（2）消元 ↔ $R=EA$：RREF 是行变换的产物。 每一步消元都是一次左乘初等矩阵。把所有初等矩阵乘起来得 E，则 $R=EA$。**R 是 A 经过可逆行变换后的唯一标准形**——这就是 R 的**唯一性（uniqueness of RREF）**：同一矩阵的 RREF 与消元顺序无关。原因很直观：R 的两件"标准化"工作（① 主元为 1；② 主元列其余位置全为 0）已经把每一列在主元列上的坐标**唯一确定**，不留任何残余自由度。

R 的最重要结构：R 的主元列构成**单位向量** $\mathbf{e}_1,\mathbf{e}_2,\ldots,\mathbf{e}_r$（在 $\mathbb{R}^r$ 意义下），非主元列则是主元列的**精确线性组合**。本讲主例 R 的非主元列：

$$R\text{ 的 }\mathbf{col}_2=\begin{bmatrix}2\\0\\0\end{bmatrix}=2\mathbf{e}_1,\qquad R\text{ 的 }\mathbf{col}_4=\begin{bmatrix}-2\\2\\0\end{bmatrix}=-2\mathbf{e}_1+2\mathbf{e}_2.$$

因为行变换不改变列之间的线性关系，这些关系**原封不动地搬回** A：

$$A\text{ 的 }\mathbf{col}_2=\begin{bmatrix}2\\4\\6\end{bmatrix}=2\begin{bmatrix}1\\2\\3\end{bmatrix}=2\cdot(A\text{ 的 }\mathbf{col}_1),$$

$$A\text{ 的 }\mathbf{col}_4=\begin{bmatrix}2\\8\\10\end{bmatrix}=-2\begin{bmatrix}1\\2\\3\end{bmatrix}+2\begin{bmatrix}2\\6\\8\end{bmatrix}=-2\cdot\mathbf{col}_1+2\cdot\mathbf{col}_3.$$

（两式均已验算 ✓。）这是**从 RREF 读列关系**的标准技术，也预告了下一讲的秩含义：**主元列是列空间的一组基**。

（3）指向 $A=CR$（Lecture 11）。 A 的**主元列**（这里是 col_1、col_3）作为列构成 C，R 的**非零行**作为行构成 R，则 $A=CR$。这个分解把"A 的所有列都是主元列的线性组合"这一事实浓缩成一次乘法，并在 Lecture 11 揭示 rank 的更深含义。

（4）**与 Lecture 7 / 10 的对接。** 本讲的特殊解 $\mathbf{s_1}, \mathbf{s_2}$ 就是 Lecture 7 中"N(A) 的基"。Lecture 10 会用 $\dim N(A) = n - r$ 与 $\dim N(A^T) = m - r$ 组成"四个基本子空间"的维数定理，而本讲的可解性判据 $\mathbf{y}^T\mathbf{b} = 0\ (\forall \mathbf{y} \in N(A^T))$ 就是那条定理的应用面。

与其他讲次的关联

- **回看 Lecture 7（零空间）**：$A\mathbf{x} = \mathbf{0}$ 的解集就是 N(A)；本讲的"$+\mathbf{x}_n$"部分完全是第七讲的成果。求特殊解的"自由变量取 1/0"手法也直接复用。
- **回看 Lecture 2–4（消元、$A = LU$、置换）**：本讲的前向消元就是那里学的算法，只是增广矩阵多了一列 $\mathbf{b}$；行变换保持解集的性质在那里已经建立。
- **回看 Lecture 6（列空间）**：可解性判据"$\mathbf{b} \in C(A)$"正是 Lecture 6 的列空间定义。本讲把它变成可操作的算法判据（看矛盾行）。
- **前瞻 Lecture 9（无关、基、维数）**：本讲示例 4 中出现的"主元列"将在下一讲被证明是 $C(A)$ 的**基**；r 就是 $C(A)$ 的维数；$\dim N(A) = n - r$ 将由"基中向量个数唯一"来保证是良定义的。
- **前瞻 Lecture 10（四个基本子空间）**：本讲的左零空间约束 $\mathbf{y}^T\mathbf{b} = 0$ 在那里被总结为可解性定理，并给出 $\dim N(A^T) = m - r$。
- **前瞻 Lecture 16（最小二乘）**：无解时我们只能求 $\hat{\mathbf{x}}$ 使 $\|A\hat{\mathbf{x}} - \mathbf{b}\|$ 最小；那时"解集为空"不再可怕，因为在 $C(A)$ 中找最近点是另一套机制（投影）。
- **前瞻 Lecture 11（$A = CR$）**：本讲 RREF 里的"列关系读法"在那里升级为完整分解。

关键要点

1. **可解性判据**：$A\mathbf{x} = \mathbf{b}$ 有解 $\iff \mathbf{b} \in C(A) \iff$ 消元后 $[A \mid \mathbf{b}]$ **不出现** $[0 \cdots 0 \mid \text{非零}]$ **行** $\iff$ 对一切 $\mathbf{y} \in N(A^T)$ 有 $\mathbf{y}^T\mathbf{b} = 0$。
2. **完整解的结构**：$\boxed{\mathbf{x} = \mathbf{x}_p + \mathbf{x}_n}$，其中 $\mathbf{x}_p$ 是任一特解（自由变量取 0 最方便），$\mathbf{x}_n$ 取遍 N(A)。有解时自由变量个数 $= n - r$，每个自由变量贡献一个参数。
3. **解集的几何**：解集 $= \mathbf{x}_p + N(A)$，是**仿射子空间**（陪集）。它**与 N(A) 平行、同维数，但不过原点**，因此 $\mathbf{b} \neq \mathbf{0}$ 时**不是子空间**。
4. **秩分类表**：$r = m = n$ 唯一解；$r = m < n$ 无穷多解（必有解）；$r = n < m$ 0 或 1 解；$r < m, r < n$ 0 或无穷多解。口诀：$r < m$ 可能无解，$r < n$ 必然多解。
5. **RREF 的唯一性**：$R = EA$ 与消元顺序无关；R 的主元列是单位向量，非主元列给出列之间的精确关系，这些关系与 A 中一致。

常见误区与注意事项

1. **只对 A 消元，忘了同步处理 $\mathbf{b}$。** 典型错误：先把 A 化成 R，然后拿原 $\mathbf{b}$ 去解 $R\mathbf{x} = \mathbf{b}$。**必须**对增广矩阵 $[A \mid \mathbf{b}]$ 整体做行变换；$R\mathbf{x} = \mathbf{b}$ 与 $A\mathbf{x} = \mathbf{b}$ **不同解**（一般甚至不同可解性）。正确做法是读 $[R \mid \mathbf{d}]$，解 $R\mathbf{x} = \mathbf{d}$。
2. **说"解集是子空间"。** 只要 $\mathbf{b} \neq \mathbf{0}$，$\mathbf{x} = \mathbf{0}$ 就不是解，解集不含原点，**不是**子空间（对加法、数乘都不封闭）。它是子空间 N(A) 的**平移**。判断子空间的三条件是 Lecture 5–6 的重点，这里是最经典的"看起来像但不是"的例子。
3. **把 $r = m < n$ 的"无穷多解"误推广为"$r < m$ 也有解"。** $r = m$ 时 $C(A) = \mathbb{R}^m$，$\mathbf{b}$ 永远命中；$r < m$ 时 $C(A)$ 是 $\mathbb{R}^m$ 的真子空间，多数 $\mathbf{b}$ 会落在外面。**"行满秩"和"有左零空间"是互斥的两种处境。**
4. **把矛盾行误读为"$x = 0$"或忽略它。** $[0\,0\,0 \mid 1]$ 的含义是对**所有** $\mathbf{x}$ 都要求 $0 = 1$，是彻底的无解信号，不是"某变量为零"。同理 $[0\,0\,0 \mid 0]$ 是"没有新信息"，它对解集毫无限制，要直接忽略。
5. **两个"数不清"的错误**：① 维度公式记反——$\dim N(A) = n - r$（**列数**减秩），不是 $m - r$；$m - r$ 属于 $\dim N(A^T)$。本讲主例 $m = 3, n = 4, r = 2$ 给出 $\dim N(A) = 2$、$\dim N(A^T) = 1$，别写成 $\dim N(A) = 1$。② 混淆"特解不唯一"与"解集不唯一"——特解可以任意选（不同自由变量赋值给出不同的 $\mathbf{x}_p$，如主例中取 $x_2 = 1, x_4 = 0$ 得 $(-4, 1, 3/2, 0)$），但**解集本身始终是同一个**，只是参数化变了。

思考题（带答案）

Q1. 设 $A = \begin{bmatrix} 1 & 2 & 2 & 2 \\ 2 & 4 & 6 & 8 \\ 3 & 6 & 8 & 10 \end{bmatrix}$（本讲主例）。对 $\mathbf{b} = (0,0,0)^T$ 求完整解；再对 $\mathbf{b} = (1,5,6)^T$ 求完整解，并说明两个解集的关系。

▸ **答案**

A 的 RREF 是 $R = \begin{bmatrix} 1 & 2 & 0 & -2 \\ 0 & 0 & 1 & 2 \\ 0 & 0 & 0 & 0 \end{bmatrix}$，$r = 2$，主元列 1、3，自由变量 x_2, x_4。

对 $\mathbf{b} = \mathbf{0}$：增广列全为 0，特解只能取 $\mathbf{x}_p = \mathbf{0}$。于是解集就是 N(A) 本身：

$$\mathbf{x} = c_1 \begin{bmatrix} -2 \\ 1 \\ 0 \\ 0 \end{bmatrix} + c_2 \begin{bmatrix} 2 \\ 0 \\ -2 \\ 1 \end{bmatrix}.$$

（验算 $A\mathbf{s}_1 = A\mathbf{s}_2 = \mathbf{0}$ ✓。）这是一个**子空间**（过原点）。

对 $\mathbf{b} = (1,5,6)^T$：$\mathbf{x}_p = (-2, 0, 3/2, 0)^T$（验算 $A\mathbf{x}_p = (1,5,6)^T$ ✓），解集为

$$\mathbf{x} = \begin{bmatrix} -2 \\ 0 \\ 3/2 \\ 0 \end{bmatrix} + c_1 \begin{bmatrix} -2 \\ 1 \\ 0 \\ 0 \end{bmatrix} + c_2 \begin{bmatrix} 2 \\ 0 \\ -2 \\ 1 \end{bmatrix}.$$

关系：后者是前者（N(A)）被 $\mathbf{x}_p$ 平移的结果。两者**平行、同维数（都是 2 维）、方向相同**，但后者**不过原点**，因此不是子空间。$\mathbf{b} = \mathbf{0}$ 的那一个恰好过原点，是唯一的子空间情形。

Q2. （纯计算）设 $A = \begin{bmatrix} 1 & 2 & 3 \\ 2 & 4 & 6 \\ 1 & 2 & 4 \end{bmatrix}$。

(a) 求 RREF 与 r；(b) 判断 $\mathbf{b} = (1,2,3)^T$ 与 $\mathbf{b}' = (1,2,4)^T$ 是否可解；(c) 对可解的 $\mathbf{b}$ 写出完整解。

▸ **答案**

(a) 消元：$\mathbf{row}_2 - 2\mathbf{row}_1 = [0,0,0]$；$\mathbf{row}_3 - \mathbf{row}_1 = [0,0,1]$。交换后回代：

```
[ 1  2  0 ]
[ 0  0  1 ]      r = 2,  主元列 1、3,  自由变量 x₂, dim N(A) = 3 − 2 = 1
[ 0  0  0 ]
```

（验算：R 的第 2 列 $= [2,0,0]^T = 2\mathbf{e}_1$，对应 A 的第 2 列 $= (2,4,2)^T = 2 \cdot (1,2,1)^T = 2 \cdot \mathrm{col}_1$ ✓。）

(b) 增广消元（对 $[A \mid \mathbf{b}]$ 整体做行变换）：

- $\mathbf{b} = (1,2,3)$：$\mathbf{row}_2 \leftarrow \mathbf{row}_2 - 2\mathbf{row}_1$ 得 $[0,0,0 \mid 0]$；$\mathbf{row}_3 \leftarrow \mathbf{row}_3 - \mathbf{row}_1$ 得 $[0,0,1 \mid 2]$。交换 row_2、row_3，再 $\mathbf{row}_1 \leftarrow \mathbf{row}_1 - 3\mathbf{row}_2$：

$$[R \mid \mathbf{d}] = \left[\begin{array}{ccc|c} 1 & 2 & 0 & -5 \\ 0 & 0 & 1 & 2 \\ 0 & 0 & 0 & 0 \end{array}\right] \quad \text{可解 ✓}$$

- $\mathbf{b}' = (1,3,4)$：同样的行变换，右端为 $3 - 2\cdot 1 = 1$、$4 - 1 = 3$；交换后第三行变成 $[0,0,0 \mid 1]$：

$$[R \mid \mathbf{d}'] = \left[\begin{array}{ccc|c} 1 & 2 & 0 & -8 \\ 0 & 0 & 1 & 3 \\ 0 & 0 & 0 & 1 \end{array}\right] \quad \text{无解（}\mathbf{0} = \mathbf{1}\text{ 矛盾）} \ \checkmark$$

用左零空间复核。 $\dim N(A^T) = m - r = 3 - 2 = 1$。解 $A^T\mathbf{y} = \mathbf{0}$（$A^T = \begin{bmatrix} 1 & 2 & 1 \\ 2 & 4 & 2 \\ 3 & 6 & 4 \end{bmatrix}$，其 RREF 为 $\begin{bmatrix} 1 & 2 & 0 \\ 0 & 0 & 1 \\ 0 & 0 & 0 \end{bmatrix}$，故 $y_1 + 2y_2 = 0,\ y_3 = 0$），取 $y_2 = 1$ 得

$$\mathbf{y} = \begin{bmatrix} -2 \\ 1 \\ 0 \end{bmatrix}, \qquad \text{验算 } -2\,\mathbf{row}_1 + \mathbf{row}_2 = (-2,-4,-6) + (2,4,6) = \mathbf{0} \ \checkmark$$

可解条件为 $\mathbf{y}^T\mathbf{b} = 0$，即 $-2b_1 + b_2 = 0$（等价于 $b_2 = 2b_1$）。检：$(1,2,3)$：$-2 + 2 = 0$ ✓ 可解；$(1,3,4)$：$-2 + 3 = 1 \neq 0$ ✗ 无解。

（顺带一提，$(1,2,4)$ 也满足 $-2b_1 + b_2 = 0$，所以它**是可解的**——RREF 给出 $[R \mid \mathbf{d}'] = \left[\begin{array}{ccc|c} 1 & 2 & 0 & -8 \\ 0 & 0 & 1 & 3 \\ 0 & 0 & 0 & 0 \end{array}\right]$，特解 $(-8,0,3)^T$。这提醒我们：判断可解性必须看**完整的左零空间约束**，而不能凭"某个分量看着别扭"下结论。）

(c) 对 $\mathbf{b} = (1,2,3)$，$[R \mid \mathbf{d}] = \left[\begin{array}{ccc|c} 1 & 2 & 0 & -5 \\ 0 & 0 & 1 & 2 \\ 0 & 0 & 0 & 0 \end{array}\right]$，即 $x_1 + 2x_2 = -5$、$x_3 = 2$。

特解（$x_2 = 0$）：$x_1 = -5,\ x_3 = 2$,

$$\mathbf{x}_p = \begin{bmatrix} -5 \\ 0 \\ 2 \end{bmatrix}, \qquad \text{验算 } A\mathbf{x}_p = \begin{bmatrix} -5+0+6 \\ -10+0+12 \\ -5+0+8 \end{bmatrix} = \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix} = \mathbf{b} \checkmark$$

> （**必须代回原矩阵 A 验算，不能代回 R**——这一步是发现算术错误的关键。）
> 零空间（$x_2 = 1$）：$x_1 = -2,\ x_3 = 0$，$\mathbf{s} = (-2, 1, 0)^T$；验算 $A\mathbf{s} = (-2+2+0,\ -4+4+0,\ -2+2+0)^T = (0,0,0)^T$ ✓。

$$\boxed{\mathbf{x} = \begin{bmatrix} -5 \\ 0 \\ 2 \end{bmatrix} + c \begin{bmatrix} -2 \\ 1 \\ 0 \end{bmatrix}, \qquad c \in \mathbb{R}.}$$

> $\mathbf{b}' = (1,3,4)$ 的增广 RREF 第三行为 $[0\ 0\ 0 \mid 1]$，**无解**，与 (b) 一致。
> **教训**：$\mathbf{d}$ 必须用"整行行变换"从头算，任何一处算术失误都会污染特解；而**特解一定要代回原矩阵 A 验算**，这是唯一可靠的自检手段。

Q3. （概念）判断对错并说明理由：

(a) 若 $A\mathbf{x} = \mathbf{b}$ 有两个不同的解，则它有无穷多解。 (b) 若 A 是 3×3 且 $A\mathbf{x} = \mathbf{b}$ 对某个 $\mathbf{b}$ 无解，则 A 必不可逆。 (c) $A\mathbf{x} = \mathbf{b}$ 的解集若含 $\mathbf{0}$，则 $\mathbf{b} = \mathbf{0}$。 (d) 若 A 的行向量线性无关，则 $A\mathbf{x} = \mathbf{b}$ 对每个 $\mathbf{b} \in \mathbb{R}^m$ 可解。

> ▸ **答案**
> (a) **对。** 设 $\mathbf{x}_1 \neq \mathbf{x}_2$ 都是解，则 $\mathbf{x}_1 - \mathbf{x}_2 \neq \mathbf{0}$ 且 $A(\mathbf{x}_1 - \mathbf{x}_2) = \mathbf{0}$，故 N(A) 含非零向量，$\dim N(A) \geq 1$，即 $n - r \geq 1$。于是解集 $\mathbf{x}_1 + N(A)$ 含无穷多个点（沿 $\mathbf{x}_1 - \mathbf{x}_2$ 方向整条直线都在解集中）。**"两个不同解"就等价于"零空间非平凡"，从而无穷多解。**
> (b) **对。** 若 A 可逆，则 $r = m = n = 3$，$C(A) = \mathbb{R}^3$，任何 $\mathbf{b}$ 都有唯一解 $A^{-1}\mathbf{b}$，不可能无解。所以"存在无解的 $\mathbf{b}$"逼出 $C(A) \subsetneq \mathbb{R}^3$，即 $r < 3$，A 奇异（不可逆）。等价地 $\det A = 0$。反之，A 不可逆时（如主例的 3×3 版 A_3），$\mathbf{b}$ 确实可能有解（$\mathbf{b} = (1,3,4)$）也可能无解（$\mathbf{b} = (1,3,6)$）。
> (c) **对。** $\mathbf{x} = \mathbf{0}$ 代入得 $A\mathbf{0} = \mathbf{b}$，而 $A\mathbf{0} = \mathbf{0}$（线性映射必把零映到零），故 $\mathbf{b} = \mathbf{0}$。反过来 $\mathbf{b} = \mathbf{0}$ 时 $\mathbf{0}$ 一定是解。**所以"解集过原点"与"$\mathbf{b} = \mathbf{0}$"完全等价**——这也解释了为什么 $\mathbf{b} \neq \mathbf{0}$ 时解集一定不是子空间。
> (d) **对。** A 是 $m \times n$，行向量是 m 个 $\mathbb{R}^n$ 中的向量。"行无关"意味着这 m 行线性无关，特别地 $m \leq n$，且行空间的维数为 m。因为 $\dim C(A^T) = \dim C(A) = r$（转置不改变秩），得 $r = m$。于是 $C(A) = \mathbb{R}^m$，任何 $\mathbf{b} \in \mathbb{R}^m$ 都可解。同时 $r = m \leq n$：若 $m < n$ 则有无穷多解，若 $m = n$ 则唯一解。**"行满秩 ⇒ 永远可解"正是分类表中的第 ② 格。**

Lecture 9: Independence, Basis, and Dimension

概述

前两讲我们一直在回答**具体问题**：给定 A 和 $\mathbf{b}$，解是什么？本讲退后一步，建立**描述一切子空间的通用语言**：**线性无关（independence）、张成（span）、基（basis）、维数（dimension）**。这四个词是本课程后半段的普通话——从四个基本子空间（Lecture 10）到特征向量（Lecture 21）到 SVD（Lecture 29），每一处都在说"找一组基""维数是多少"。

本讲的核心结论有两条。第一：**"线性无关"就是把向量排成矩阵 A 后 $N(A) = \{\mathbf{0}\}$**，也就是 $A\mathbf{x} = \mathbf{0}$ 只有零解，也就是 $r = n$（列满秩）。第二：**基 = 既无关又张成**，"不多不少刚刚好"；而**基的向量个数与基的选取无关**，这个不变量就是**维数**。第二条是数学上很深刻的事实，它保证了 $\dim$ 是良定义的。

核心概念的几何直觉

概念一：线性无关（Linear Independence）

- **定义与目的**：向量 $\mathbf{v}_1, \ldots, \mathbf{v}_k$ **线性无关**，当且仅当

$$c_1\mathbf{v}_1 + c_2\mathbf{v}_2 + \cdots + c_k\mathbf{v}_k = \mathbf{0} \quad \Longrightarrow \quad c_1 = c_2 = \cdots = c_k = 0.$$

即"零组合只有平凡解"。反之，若存在**不全为零**的系数使组合为零，则称它们**线性相关（linearly dependent）**。 – **几何直觉（它在空间中是什么样子？）**：无关意味着**每个向量都带来了新方向**——没有任何一个向量落在其余向量张成的空间里。相关意味着**存在冗余**：至少有一个向量是别人的线性组合（可以扔掉而不减少张成空间）。

- 1 个向量：无关 $\Longleftrightarrow$ 它不是 $\mathbf{0}$（$\mathbf{0}$ 永远是相关的，因为 $1 \cdot \mathbf{0} = \mathbf{0}$ 是零组合）。
- 2 个向量：相关 $\Longleftrightarrow$ 它们共线（一个在另一个的直线上）。
- 3 个向量在 $\mathbb{R}^3$ 中：相关 $\Longleftrightarrow$ 它们共面（都躺在某个过原点的平面内）。
- 一般 k 个向量：相关 $\Longleftrightarrow$ 它们全部落在某个低于 k 维的子空间里。

- **具体示例**：
- $\mathbf{v}_1=(1,2,3)^T,\mathbf{v}_2=(2,4,6)^T$ **相关**：$2\mathbf{v}_1-\mathbf{v}_2=\mathbf{0}$，即 $\mathbf{v}_2=2\mathbf{v}_1$，两者共线。
- $\mathbf{v}_1=(1,0,1)^T,\mathbf{v}_2=(0,1,1)^T,\mathbf{v}_3=(1,2,3)^T$ **相关**：$\mathbf{v}_1+\mathbf{v}_2-\mathbf{v}_3=(1+0-1,\ 0+1-2,\ 1+1-3)^T=(0,0,0)^T$ ✓。$\mathbf{v}_3$ 落在前两个张成的平面内。
- $\mathbf{v}_1=(1,1,0)^T,\mathbf{v}_2=(0,1,1)^T,\mathbf{v}_3=(1,0,1)^T$ **无关**：见下面的行列式判据（$\det=2\neq0$）。

等价刻画（本讲最实用的四个说法）：把 $\mathbf{v}_1,\dots,\mathbf{v}_n$ 作为**列**排成矩阵

$$A=[\mathbf{v}_1\quad\mathbf{v}_2\quad\cdots\quad\mathbf{v}_n],$$

则下面五件事完全等价：

```
┌──────────── 列向量线性无关的五个等价说法 ────────────┐
│  ①  c₁v₁ + … + cₙvₙ = 0 只有零解 c = 0              │
│  ②  N(A) = {0}            （零空间只有零向量）       │
│  ③  秩 r = n              （列满秩；主元列有 n 个）  │
│  ④  A 的各列互不"冗余"：没有一列是其他列的线性组合   │
│  ⑤  若 A 是方阵：det A ≠ 0（可逆）                  │
└──────────────────────────────────────────────────┘
注意 ⑤ 只对方阵成立；非方阵（如 3×2）用 ③：r = n 即列满秩。
```

A 是 $m\times n$ 时，n 个列向量在 $\mathbb{R}^m$ 中。若 $n>m$（向量个数超过空间维数），**必然相关**——这就是本讲要证的"$\mathbb{R}^3$ 中任意 4 个向量必相关"的一般版本，理由见后面。

概念二：张成（Span）

- **定义与目的**：$\mathbf{span}\{\mathbf{v}_1,\dots,\mathbf{v}_k\}$ 是这些向量的**一切**线性组合 $c_1\mathbf{v}_1+\cdots+c_k\mathbf{v}_k$（$c_i$ 取遍实数，**可以全为 0**）的集合。它自动是子空间。
- **几何直觉（它在空间中是什么样子？）**：张成是"这些向量能够到达的全部地方"。$\mathbf{span}$ 永远**过原点**（取全部系数为 0），永远包含 $\mathbf{0}$。
- 一个非零向量张成一条**过原点的直线**。
- 两个不共线的向量张成一个**过原点的平面**。
- 三个不共面的向量张成**整个 $\mathbb{R}^3$**。
- $\mathbf{span}\{\mathbf{0}\}=\{\mathbf{0}\}$（零维）。
- **具体示例**：
- $\mathbf{span}\{(1,0,0)^T,(0,1,0)^T\}=\{xy\text{ 平面}\}=\{(a,b,0)^T\}$。
- $\mathbf{span}\{(1,2,3)^T,(2,4,6)^T\}=\mathbf{span}\{(1,2,3)^T\}=$ 一条直线（因为两个共线，第二个没带来新方向）。
- $\mathbf{span}\{(1,1,0)^T,(0,1,1)^T\}=\{a(1,1,0)+b(0,1,1)\}=\{(a,\ a+b,\ b)^T\}$，一个过原点的平面。把它写成方程：点 $(x,y,z)=(a,a+b,b)$ 满足 $x+z=a+b=y$，故平面方程为

$$-x+y-z=0\quad(\text{即 }y=x+z).$$

```
这也解释了为什么它是 2 维的：只有 2 个自由参数 $a,b$；在 $\mathbb{R}^3$ 中由**一个**线性方程 $n_1x+n_2y+n_3z=0$ 切出的过原点集合维数总是 $3-
```

- **关键联系**：$C(A)=\mathbf{span}\{A\text{ 的列}\}$（Lecture 6 的定义）；$A\mathbf{x}=\mathbf{b}$ 可解 $\iff$ $\mathbf{b}\in\mathbf{span}\{A\text{ 的列}\}$（Lecture 8 的判据）。

概念三：基（Basis）——"不多不少刚刚好"

- **定义与目的**：向量组 $\{\mathbf{v}_1,\dots,\mathbf{v}_d\}$ 是子空间 V 的**基**，当且仅当它**同时**满足：
- **线性无关**（不多——没有冗余）；
- **张成 V**（不少——覆盖全部）。
- **几何直觉（它在空间中是什么样子？）**：基是 V 的"最优坐标系"。两个条件缺一不可：
- 只无关不张成 → 太小，够不着 V 的某些点（如用 $(1,0,0)$ 作为 $\mathbb{R}^3$ 的"基"）。
- 只张成不无关 → 太大，有冗余（如用 $(1,0,0),(0,1,0),(0,0,1),(1,1,1)$ 张成 $\mathbb{R}^3$，多了一个）。
- 基的**两条最实用的性质**：① V 中**每个**向量都能写成基的组合（存在性，来自张成）；② 写法**唯一**（唯一性，来自无关：若 $\sum c_i\mathbf{v}_i=\sum d_i\mathbf{v}_i$，则 $\sum(c_i-d_i)\mathbf{v}_i=\mathbf{0}$，无关性逼出 $c_i=d_i$）。**"存在且唯一"正是"坐标"的定义**——这就是为什么基那么重要。
- **具体示例**：$\mathbb{R}^3$ 的**标准基** $\mathbf{e}_1=(1,0,0)^T,\mathbf{e}_2=(0,1,0)^T,\mathbf{e}_3=(0,0,1)^T$；$\mathbb{R}^3$ 的另一组基 $\mathbf{v}_1=(1,1,0)^T,\mathbf{v}_2=(0,1,1)^T,\mathbf{v}_3=(1,0,1)^T$（见下面的完整验证）。

概念四：维数（Dimension）——基中向量个数的唯一性

- **定义与目的**：子空间 V 的**维数** $\dim V$ 定义为**它的任意一组基中向量的个数**。这个定义之所以合法，是因为下面的定理：

> **定理（基的个数不变）**：同一个子空间 V 的任意两组基含有的向量个数相同。

因此"基中向量个数"不是基的属性，而是 V 本身的属性。 – **几何直觉（它在空间中是什么样子？）**：维数是子空间的**"内在大小"**——它数的是"独立方向的个数"，而不是"用了多少向量来描述"。**dim** 是子空间在**任意**坐标系下都一样的"指纹"：换基可以，换维数不行。 – **具体示例**：$\dim \mathbb{R}^3 = 3$；$\dim\{\mathbf{0}\} = 0$（空集是 $\{\mathbf{0}\}$ 的基，个数为 0）；过原点的平面维数是 2；过原点的直线维数是 1。 – **为什么个数唯一（直觉版证明）**：设 V 有两组基，分别 d_1 个和 d_2 个。若 $d_1 < d_2$：把第一组记作 B_1。B_2 的每个向量都能由 B_1 表示（B_1 张成 V）。把 B_2 的 d_2 个向量用 B_1 的 d_1 个基表示，得到一个 $d_1 \times d_2$ 的系数矩阵——d_1 个未知数、d_2 个方程。由于 $d_1 < d_2$，这个齐次方程组必有非零解（未知数比方程少，必有自由变量），于是 B_2 线性相关，与"B_2 是基"矛盾。所以 $d_1 \geq d_2$；对称地 $d_2 \geq d_1$；故 $d_1 = d_2$。**这条论证只用到了"主元个数 ≤ 行数/列数"这一基本事实，是本课程反复出现的"数数（counting）"思想。**

概念五：秩 r 的完整含义（本讲与 Lecture 8 的汇合点）

- **定义与目的**：秩是矩阵的**唯一最重要的数字**。本讲给它一个纯几何的定义：

$$r = \mathbf{rank}(A) = C(A) \text{ 的维数} = \text{无关列的最大数目}.$$

- **几何直觉（它在空间中是什么样子？）**：r 数的是"A 的列真正指向了多少个独立方向"。若 A 有 n 列但 $r < n$，说明有 $n - r$ 列是"白搭的"——它们没有开辟新方向，只是已有方向的组合。r 同时是 $C(A)$ 的维数与 $N(A)$ 的"余维数"：$r + (n - r) = n$，两个方向互相补足。
- **具体示例**：用 Lecture 8 的主例 $A = \begin{bmatrix} 1 & 2 & 2 & 2 \\ 2 & 4 & 6 & 8 \\ 3 & 6 & 8 & 10 \end{bmatrix}$（$m = 3, n = 4$，$r = 2$）逐条对照。

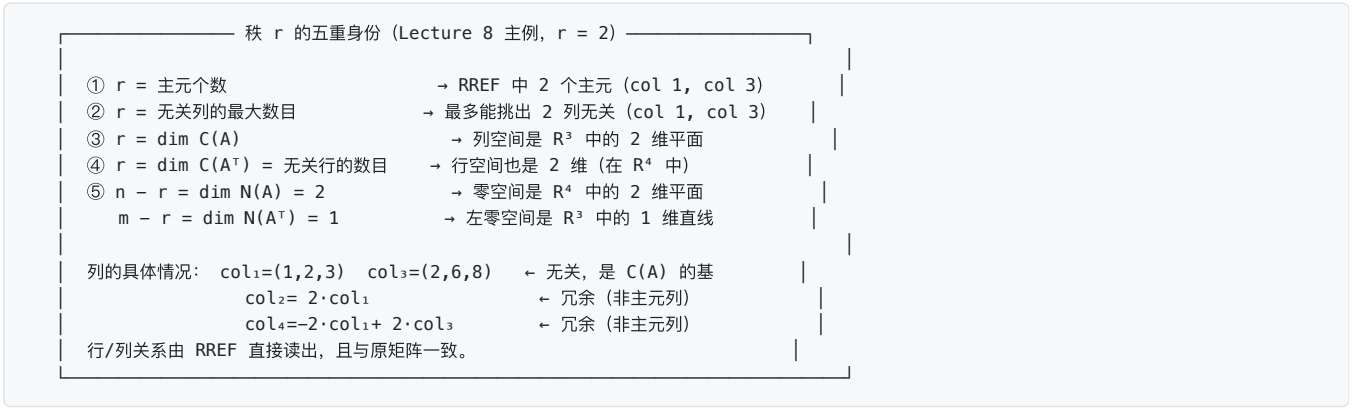

验算：$\mathbf{col}_2 = (2,4,6)^T = 2(1,2,3)^T = 2\,\mathbf{col}_1$ ✓；$\mathbf{col}_4 = (2,8,10)^T = -2(1,2,3)^T + 2(2,6,8)^T$ ✓；两个主元列的 2×2 子式 $\det \begin{bmatrix} 1 & 2 \\ 2 & 6 \end{bmatrix} = 1 \cdot 6 - 2 \cdot 2 = 2 \neq 0$，故它们无关 ✓。

- **为什么 r = "无关列的最大数目"**：主元列必无关（它们在 R 中对应单位向量 $\mathbf{e}_1, \ldots, \mathbf{e}_r$，而 R 的秩为 r）。任何**多于** r 个列必相关（因为它们在 R 中对应的向量落在 $\mathbb{R}^r$ 里，而 $\mathbb{R}^r$ 中任意 $r+1$ 个向量必相关——这正是"$\mathbb{R}^m$ 中 $m+1$ 个必相关"的应用！）。所以 r 既是"能达到的"也是"不能超过的"无关列数目，是最优值。

概念六：把"线性无关"翻译成矩阵语言（本讲最常用的翻译表）

每一条关于"向量组无关/相关"的陈述，都能翻译成一条关于矩阵的陈述。熟练之后可以直接在两种语言之间来回切换：

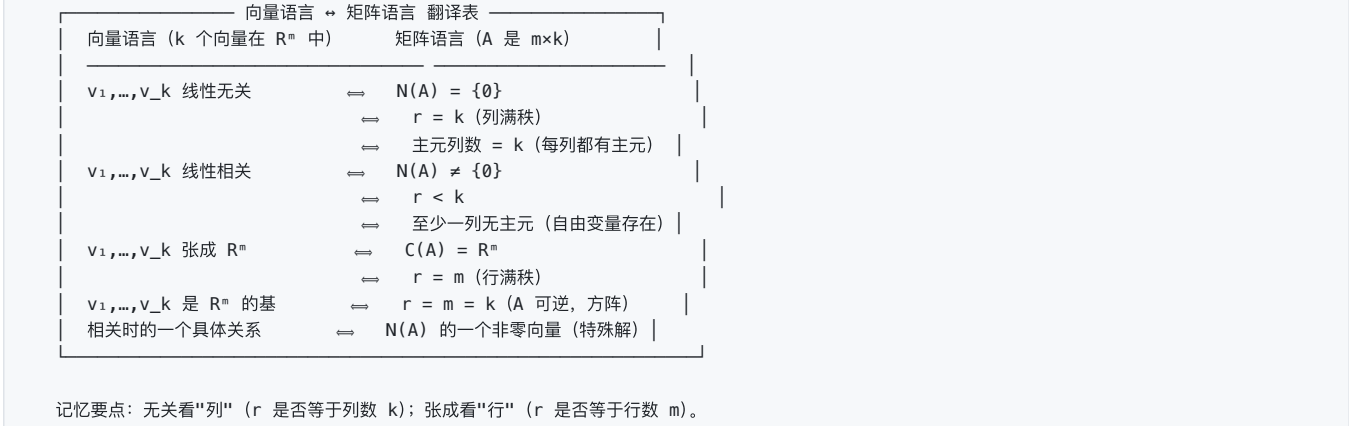

记忆要点：无关看"列"（r 是否等于列数 k）；张成看"行"（r 是否等于行数 m）。

用这个表看几个经典情形：

- $m=3, k=4$（$\mathbb{R}^3$ 中 4 个向量）：$r \le m = 3 < 4 = k$，必然 $r<k$，**必然相关**。这就是示例 2 的"$n+1$ 个 n 维向量必相关"。
- A 是 2×4（示例 6 的矩阵转置视角）：$r \le 2 < 4$，4 列必相关，$\dim N(A) \ge 2$——验算该矩阵 $[1\ 2\ 3\ 4; 2\ 4\ 6\ 8]$ 的 RREF 为 $\begin{bmatrix}1&2&3&4\\0&0&0&0\end{bmatrix}$，$r=1$，$\dim N(A)=3$ ✓，三个特殊解 $(-2,1,0,0)^T, (-3,0,1,0)^T, (-4,0,0,1)^T$ 都验算满足 $A\mathbf{s}=\mathbf{0}$ ✓。
- 方阵 A 是 3×3：无关 $\iff$ $r=3$ $\iff$ 张成 $\iff$ $\det A \neq 0$：三件事完全等价（示例 1、5）。

计算步骤与手算演示

示例 1（必做：$\mathbb{R}^3$ 的两组基，用行列式判无关）

步骤 1：标准基。 $\mathbf{e}_1=(1,0,0)^T, \mathbf{e}_2=(0,1,0)^T, \mathbf{e}_3=(0,0,1)^T$ 排成列：

$$A_{\text{std}} = \begin{bmatrix}1&0&0\\0&1&0\\0&0&1\end{bmatrix}, \qquad \det A_{\text{std}} = 1 \neq 0 \ \Rightarrow \ \text{无关}.$$

它们显然张成 $\mathbb{R}^3$（任何 $(a,b,c)^T = a\mathbf{e}_1 + b\mathbf{e}_2 + c\mathbf{e}_3$），所以是基 ✓。

步骤 2：另一组候选基。 取

$$\mathbf{v}_1=\begin{bmatrix}1\\1\\0\end{bmatrix}, \quad \mathbf{v}_2=\begin{bmatrix}0\\1\\1\end{bmatrix}, \quad \mathbf{v}_3=\begin{bmatrix}1\\0\\1\end{bmatrix}, \qquad B=\begin{bmatrix}1&0&1\\1&1&0\\0&1&1\end{bmatrix} \ (\text{列为 } \mathbf{v}_1,\mathbf{v}_2,\mathbf{v}_3).$$

步骤 3：算行列式（Sarrus 或消元）。 用消元法（更稳）：

- $\mathbf{row}_2 \leftarrow \mathbf{row}_2 - \mathbf{row}_1$：$[0,1,-1]$。
- $\mathbf{row}_3$ 不变：$[0,1,1]$。
- $\mathbf{row}_3 \leftarrow \mathbf{row}_3 - \mathbf{row}_2$：$[0,0,2]$。

```
B 消元后:  [ 1  0  1 ]        主元: 1, 1, 2
           [ 0  1 -1 ]         r = 3 = n  ⇒  三列线性无关
           [ 0  0  2 ]
```

$$\det B = 1\cdot 1\cdot 2 = 2 \neq 0.$$

步骤 4：结论与验证。 $\det B = 2 \neq 0$，故 B 可逆，三列线性无关，所以 $\{\mathbf{v}_1,\mathbf{v}_2,\mathbf{v}_3\}$ 是 $\mathbb{R}^3$ 的**一组基**——它自动张成 $\mathbb{R}^3$（因为 $\dim \mathbb{R}^3 = 3$，3 个无关向量恰好"用满"）。RREF 验算：

```
RREF(B) = [ 1  0  0 ]
          [ 0  1  0 ]      ⇒ N(B) = {0}, r = 3
          [ 0  0  1 ]
```

步骤 5：实际用这组基算坐标。 求 $\mathbf{b}=(1,2,3)^T$ 在基 B 下的坐标：解 $c_1\mathbf{v}_1 + c_2\mathbf{v}_2 + c_3\mathbf{v}_3 = \mathbf{b}$，即 $B\mathbf{c}=\mathbf{b}$。增广消元：

$$[B \mid \mathbf{b}] = \left[\begin{array}{ccc|c}1&0&1&1\\1&1&0&2\\0&1&1&3\end{array}\right] \longrightarrow \mathbf{RREF} = \left[\begin{array}{ccc|c}1&0&0&0\\0&1&0&2\\0&0&1&1\end{array}\right].$$

所以 $\mathbf{c}=(0,2,1)^T$。**验算**：$0\cdot\mathbf{v}_1 + 2\mathbf{v}_2 + 1\cdot\mathbf{v}_3 = (0,0,0)^T + (0,2,2)^T + (1,0,1)^T = (1,2,3)^T = \mathbf{b}$ ✓。（注意：$\mathbf{b}$ 在这组基下的坐标 $(0,2,1)$ 与它在标准基下的坐标 $(1,2,3)$ 完全不同——**"坐标"必须相对于某组基才有意义**，这是 Lecture 30 基变换的先声。）

【计算机制解说】 为什么"n 个无关向量自动张成 $\mathbb{R}^n$"？设 A 是 $n\times n$ 且 $r=n$（列无关）。此时 A 有 n 个主元，阶梯形 U 的对角线全非零，$\det A \neq 0$，A 可逆，于是对**任何** $\mathbf{b}$ 都有 $\mathbf{x}=A^{-1}\mathbf{b}$。这不仅证明了张成，还顺带说明**多余的条件是免费的**：在 $\mathbb{R}^n$ 这种"维数已知为 n"的空间里，只要无关性达到 n 个向量，张成性自动成立；反过来，只要 n 个向量张成 $\mathbb{R}^n$，无关性也自动成立（否则有效的独立方向不足 n 个，够不着整个空间）。**"$\mathbb{R}^n$ 中 n 个向量：无关 $\iff$ 张成 $\iff$ 构成基"** 是方阵特有的便利，非方阵没有这种对称性。

示例 2（必做：$\mathbb{R}^3$ 中任意 4 个向量必线性相关）

步骤 1：一般论证。 设 $\mathbf{w}_1,\mathbf{w}_2,\mathbf{w}_3,\mathbf{w}_4 \in \mathbb{R}^3$，排成 3×4 矩阵 W。$A\mathbf{x}=\mathbf{0}$ 是 **3 个方程、4 个未知数**的齐次方程组。由 Lecture 8 的秩理论：$r \le m = 3 < 4 = n$，所以必有 $r<n$，于是 $\dim N(W) = n - r \ge 1$，**零空间含非零向量** $\mathbf{c}\neq\mathbf{0}$，即存在不全为零的系数使 $\sum c_i\mathbf{w}_i = \mathbf{0}$。所以它们相关。**这就是一般的"$n+1$ 个 n 维向量必相关"（更一般地：$\mathbb{R}^m$ 中任意 $m+1$ 个向量必相关）。核心是"未知数个数 $>$ 方程个数 $\Rightarrow$ 必有自由变量"。**

步骤 2：具体实例验证。 取四个向量

$$\mathbf{u_1} = \mathbf{e_1} = \begin{bmatrix}1\\0\\0\end{bmatrix},\ \mathbf{u_2} = \mathbf{e_2} = \begin{bmatrix}0\\1\\0\end{bmatrix},\ \mathbf{u_3} = \mathbf{e_3} = \begin{bmatrix}0\\0\\1\end{bmatrix},\ \mathbf{u_4} = \begin{bmatrix}1\\1\\1\end{bmatrix}.$$

构造 $W = [\mathbf{u_1}\ \mathbf{u_2}\ \mathbf{u_3}\ \mathbf{u_4}]$（$3 \times 4$）：

$$W = \begin{bmatrix}1 & 0 & 0 & 1\\0 & 1 & 0 & 1\\0 & 0 & 1 & 1\end{bmatrix}.$$

步骤 3：RREF 与主元。 这已经接近 RREF，把 x_4 当自由变量消掉前三列的 1（用 $\mathbf{row_1} \leftarrow \mathbf{row_1} - \mathbf{row_4}$ 等），得到

```
RREF(W) = [ 1  0  0  1 ]
          [ 0  1  0  1 ]      主元列 = 1, 2, 3    r = 3 < n = 4
          [ 0  0  1  1 ]
```

（这个矩阵的 RREF 就是它自己：主元列是 $\mathbf{e_1}, \mathbf{e_2}, \mathbf{e_3}$，第 4 列是 $\mathbf{e_1} + \mathbf{e_2} + \mathbf{e_3}$。）

步骤 4：读出相关关系。 第 4 列 $= \mathbf{e_1} + \mathbf{e_2} + \mathbf{e_3}$，即 $c_1 = c_2 = c_3 = 1, c_4 = -1$ 给出零组合：

$$1 \cdot \mathbf{u_1} + 1 \cdot \mathbf{u_2} + 1 \cdot \mathbf{u_3} - 1 \cdot \mathbf{u_4} = \mathbf{e_1} + \mathbf{e_2} + \mathbf{e_3} - \begin{bmatrix}1\\1\\1\end{bmatrix} = \mathbf{0}\ \checkmark$$

所以 $\mathbf{u_4} = \mathbf{u_1} + \mathbf{u_2} + \mathbf{u_3}$——它落在前三个张成的 $\mathbb{R}^3$ 里（这当然是废话，因为前三个已经张成整个 $\mathbb{R}^3$）。**更本质的说法**：4 个向量挤在 3 维空间里，必然有冗余。

步骤 5：反面情形（3 个向量可以无关）。 取 $\mathbf{u_1}, \mathbf{u_2}, \mathbf{u_3}$ 本身：$r = 3 = n$，无关，是基。**对比 4 个（相关）与 3 个（无关）**，正好落在"个数 vs 维数"的分界线上。

【计算机制解说】 为什么"方程比未知数少 $\Rightarrow$ 必有非零解"？把 W（3×4）消元，最多只能找到 3 个主元（行数上限），却有 4 列，所以至少有 $4 - 3 = 1$ 个自由变量。自由变量可以取 1，回代得一个非零解。这是纯粹的**数数（counting）**：主元数 $r \le \min(m, n)$。所以"$m < n$ 的齐次方程组必有非平凡解"是个**不需要算**的结论——这正是相关性的根源，也是后面"维数唯一性"证明的核心工具。

示例 3（过原点平面的基与维数）

步骤 1：取平面 $V = \{(x, y, z)^T : x_1 + x_2 + x_3 = 0\}$，即 $N([1\ 1\ 1])$。

步骤 2：求基（用 Lecture 7 的特殊解法）。 矩阵 $[1\ 1\ 1]$ 的 RREF 就是它自己，主元在 col 1，自由变量 x_2, x_3。

- 令 $x_2 = 1, x_3 = 0$：$x_1 = -1$，得 $\mathbf{w_1} = (-1, 1, 0)^T$。
- 令 $x_3 = 1, x_2 = 0$：$x_1 = -1$，得 $\mathbf{w_2} = (-1, 0, 1)^T$。

验算：$-1 + 1 + 0 = 0$ ✓，$-1 + 0 + 1 = 0$ ✓，两个向量都在平面上。

步骤 3：验证无关。 把两个向量排成 3×2 矩阵 $\begin{bmatrix}-1 & -1\\1 & 0\\0 & 1\end{bmatrix}$，消元后得主元在两列上（$2 \times 2$ 子式 $\det\begin{bmatrix}-1 & -1\\1 & 0\end{bmatrix} = (-1)(0) - (-1)(1) = 1 \neq 0$），故无关。

步骤 4：验证张成。 平面上任意点 (x_1, x_2, x_3) 满足 $x_1 = -x_2 - x_3$，于是

$$\begin{bmatrix}x_1\\x_2\\x_3\end{bmatrix} = x_2\begin{bmatrix}-1\\1\\0\end{bmatrix} + x_3\begin{bmatrix}-1\\0\\1\end{bmatrix}.$$

所以 $\{\mathbf{w_1}, \mathbf{w_2}\}$ 张成 V。

步骤 5：结论。 既无关又张成，故是 V 的基，$\dim V = 2$。

步骤 6：对照另一组基（说明基不唯一）。 取 $\mathbf{w_1'} = (-1, 1, 0)^T$、$\mathbf{w_2'} = (0, -1, 1)^T$（后者也在平面上：$0 - 1 + 1 = 0$ ✓）。

验证无关：2×2 子式 $\det\begin{bmatrix}-1 & 0\\1 & -1\end{bmatrix} = (-1)(-1) - 0 \cdot 1 = 1 \neq 0$（取前两行），故两向量无关 ✓。

验证张成：设 $a\mathbf{w_1'} + b\mathbf{w_2'} = (-a,\ a - b,\ b)$。要让它等于平面上任意点 (x_1, x_2, x_3)（满足 $x_1 + x_2 + x_3 = 0$），取 $a = -x_1$，$b = x_3$，则第二分量 $a - b = -x_1 - x_3 = x_2$ ✓（正是平面方程）。所以它也张成 V，是 V 的一组**新基**。**两组基的向量完全不同，但个数都是 2——维数不变。**

【计算机制解说】 为什么"平面的维数是 2"而不是"因为给了 2 个向量所以是 2"？顺序不能颠倒：维数的定义是**基中向量个数**，而基中个数的不变性是定理。这里的论证逻辑是：① 找到一组含 2 个向量的基（验证无关 + 张成）；② 由维数唯一性定理，**任何**基都含 2 个向量，所以 $\dim V = 2$ 是内在的。换个角度，$V = N([1\ 1\ 1])$，用公式 $\dim N(A) = n - r = 3 - 1 = 2$ 一步到位（Lecture 7 的成果）。**两种算法必须给同一个答案，这是很好的自检。**

示例 4（$N(A)$ 的基与维数：接续 Lecture 8 的主例）

步骤 1： 取 $A=\begin{bmatrix}1&2&2&2\\2&4&6&8\\3&6&8&10\end{bmatrix}$（Lecture 8 主例），$m=3, n=4, r=2$，主元列 1、3，自由变量 x_2, x_4。

步骤 2：特殊解给出候选基。 Lecture 8 已算出

$$\mathbf{s}_1=\begin{bmatrix}-2\\1\\0\\0\end{bmatrix},\qquad \mathbf{s}_2=\begin{bmatrix}2\\0\\-2\\1\end{bmatrix},\qquad A\mathbf{s}_1=A\mathbf{s}_2=\mathbf{0}\ \checkmark$$

步骤 3：验证无关。 把两个向量排成 4×2 矩阵 $S=\begin{bmatrix}-2&2\\1&0\\0&-2\\0&1\end{bmatrix}$。看第 2、4 行构成的 2×2 子式：$\det\begin{bmatrix}1&0\\0&1\end{bmatrix}=1\neq 0$，故 S 的秩为 2（两列无关）。更直接地：若 $c_1\mathbf{s}_1+c_2\mathbf{s}_2=\mathbf{0}$，看第 2 分量得 $c_1=0$，看第 4 分量得 $c_2=0$。**"自由变量位置上的 0/1 结构让无关性一眼可见"**——这正是"特殊解法"设计的巧妙之处。

步骤 4：验证张成（为什么它们张成整个 N(A)）。 N(A) 中任取 $\mathbf{x}$，其分量记为 (x_1,x_2,x_3,x_4)。由 RREF 的方程 $x_1=-2x_2+2x_4$、$x_3=-2x_4$，得

$$\mathbf{x}=\begin{bmatrix}-2x_2+2x_4\\x_2\\-2x_4\\x_4\end{bmatrix}=x_2\begin{bmatrix}-2\\1\\0\\0\end{bmatrix}+x_4\begin{bmatrix}2\\0\\-2\\1\end{bmatrix}=x_2\mathbf{s}_1+x_4\mathbf{s}_2.$$

所以 $\{\mathbf{s}_1,\mathbf{s}_2\}$ 张成 N(A)。

步骤 5：结论。 既无关又张成 ⇒ 是 N(A) 的**基**，$\dim N(A)=2=n-r=4-2$ ✓ 与 Lecture 7 的公式一致。

【计算机制解说】 为什么"每个自由变量取 1、其余取 0"得到的向量一定线性无关？因为这些向量在**自由变量坐标**上的取值拼起来恰好是单位矩阵！

```
自由变量坐标 (x₂, x₄) 视角：
   s₁ 的自由变量部分 = (1, 0)   ← e₁
   s₂ 的自由变量部分 = (0, 1)   ← e₂
若组合 c₁s₁ + c₂s₂ = 0，只看"自由变量那几行"就得到
   c₁(1,0) + c₂(0,1) = (c₁, c₂) = (0, 0)  ⇒  c₁ = c₂ = 0。
单位矩阵的列当然无关 —— 这就是特殊解自动无关的原因。
```

同时这也说明为什么恰好有 $n-r$ 个特殊解：**自由变量的个数就是 $n-r$**，每个自由变量贡献一个"单位方向"。而它们张成 N(A) 的原因在步骤 4 中已经直接验证：RREF 把主元变量完全用自由变量表达，任意 $\mathbf{x}\in N(A)$ 都能解出系数。**"无关性来自单位矩阵，张成性来自 RREF 的解出主元变量"，这个"两半证明"是求零空间基的标准范式。**

示例 5（基不唯一、维数唯一：$\mathbb{R}^3$ 中任意 3 个无关向量都是基）

步骤 1：论证。 设 $\mathbf{a}_1,\mathbf{a}_2,\mathbf{a}_3\in\mathbb{R}^3$ 线性无关，排成 3×3 矩阵 A。无关 $\iff r=3=n\iff \det A\neq 0\iff A$ 可逆 $\iff$ 对任意 $\mathbf{b}$，$A\mathbf{x}=\mathbf{b}$ 有唯一解 $\iff$ 三列张成 $\mathbb{R}^3$。所以它是基。**注意这里完全没有用到具体数值**——这是"$\mathbb{R}^n$ 中 n 个无关向量自动是基"的普遍结论。

步骤 2：三个具体例子。

- $B_1=\{(1,0,0)^T,(0,1,0)^T,(0,0,1)^T\}$：$\det=1\neq 0$ ✓ 基。
- $B_2=\{(1,1,0)^T,(0,1,1)^T,(1,0,1)^T\}$：$\det=2\neq 0$ ✓ 基（示例 1 已算）。
- $B_3=\{(1,1,0)^T,(2,0,1)^T,(3,1,1)^T\}$：**不是基**。直接看出 $\mathbf{a}_3=\mathbf{a}_1+\mathbf{a}_2$，因为 $(1,1,0)+(2,0,1)=(3,1,1)$ ✓。这给出非平凡的零组合 $\mathbf{a}_1+\mathbf{a}_2-\mathbf{a}_3=\mathbf{0}$，所以三向量**相关**。

用行列式复核（以它们为列）：$\det\begin{bmatrix}1&2&3\\1&0&1\\0&1&1\end{bmatrix}=1(0\cdot 1-1\cdot 1)-2(1\cdot 1-1\cdot 0)+3(1\cdot 1-0\cdot 0)=-1-2+3=0$ ✓ 与"相关"一致。

用消元复核（更不易出错）：$\mathbf{row}_2\leftarrow\mathbf{row}_2-\mathbf{row}_1=[0,-2,-2]$（**注意第三分量是 $1-3=-2$，不要写成 1**）；$\mathbf{row}_3$ 不动 $[0,1,1]$；再 $\mathbf{row}_3\leftarrow\mathbf{row}_3+\frac{1}{2}\mathbf{row}_2=[0,1,1]+[0,-1,-1]=[0,0,0]$。故只有 2 个主元，$r=2<3$，相关 ✓。

```
RREF([a₁ a₂ a₃]) = [ 1  0  1 ]      r = 2 < n = 3  ⇒  相关
                   [ 0  1  1 ]      第 3 列 = 第 1 列 + 第 2 列
                   [ 0  0  0 ]      ⇒  a₃ = a₁ + a₂
```

对比三个例子：B_1（$\det=1$）是基；B_2（$\det=2$）是基；B_3（$\det=0$）不是基。这正好说明"$\mathbb{R}^3$ 中 3 个向量"本身不保证是基——还必须线性无关。 个数对了不等于结构对了。

步骤 3：基不唯一但维数唯一。 B_1 与 B_2 是完全不同的两组向量，但都是 $\mathbb{R}^3$ 的基，都含 3 个向量。$\mathbb{R}^3$ 中不存在含 2 个向量的基（2 个向量最多张成平面），也不存在含 3 个无关向量的基之外的"4 个向量基"（4 个必相关，见示例 2）。所以 $\dim \mathbb{R}^3 = 3$，**与基的选取无关**。

```
基不唯一，维数唯一：R^3 的三组候选向量

  B₁ = {e₁,e₂,e₃}          B₂ = {(1,1,0),(0,1,1),(1,0,1)}    B₃ = {(1,1,0),(2,0,1),(3,1,1)}
     det = 1                    det = 2                          det = 0
     ✓ 基 (3 个)                ✓ 基 (3 个)                      ✗ 相关，不是基
                                                                   └ a₃ = a₁ + a₂

无论换哪一组"好基"，个数恒为 3  ⟹  dim R^3 = 3
├ 少于 3 个无关向量 → 张不满 R^3
└ 多于 3 个向量      → 必相关（示例 2），必有冗余
```

【计算机制解说】 为什么"基不唯一"与"维数唯一"不矛盾？"基"是**具体的一组向量**（依赖于选取），"维数"是**一个数**（是子空间的内在属性）。类比：同一个房间可以用不同的坐标系描述（原点放哪儿、轴怎么指都可以），但房间的**维度**（几个独立方向）是房间的性质，不是坐标系的性质。数学上，维数唯一性来自上面的"数数论证"：**两组基若能互相表示，则个数的多寡必然相等**，否则一组能表示另一组就会产生非平凡的线性关系（矛盾）。这个论证的美妙之处在于它完全不涉及具体数值，只用到 $r \le \min(m,n)$。

示例 6（同一套逻辑搬到 $\mathbb{R}^4$：维数变了，判据不变）

前五个示例都在 $\mathbb{R}^3$。本课程真正要培养的是"**换维数不换思想**"的能力。取 $\mathbb{R}^4$ 中的四个向量

$$\mathbf{b}_1 = \begin{bmatrix}1\\0\\0\\1\end{bmatrix},\quad \mathbf{b}_2 = \begin{bmatrix}0\\1\\0\\1\end{bmatrix},\quad \mathbf{b}_3 = \begin{bmatrix}0\\0\\1\\1\end{bmatrix},\quad \mathbf{b}_4 = \begin{bmatrix}1\\1\\1\\0\end{bmatrix}.$$

步骤 1：排成 4×4 矩阵并算行列式。

$$B = \begin{bmatrix}1&0&0&1\\0&1&0&1\\0&0&1&1\\1&1&1&0\end{bmatrix}.$$

沿第一行展开（或用消元）：直观算法是"把前 0 行的 $\mathbf{e}$ 部分与最后一列的 1 组合"。用消元更快：$\mathbf{row}_4 \leftarrow \mathbf{row}_4 - \mathbf{row}_1 - \mathbf{row}_2 - \mathbf{row}_3$ 得 $[1,1,1,0]-[1,0,0,1]-[0,1,0,1]-[0,0,1,1]=[0,0,0,-3]$。于是矩阵变成上三角，主元为 $1,1,1,-3$：

```
B 消元后：  [ 1  0  0  1 ]
           [ 0  1  0  1 ]        主元 = 1, 1, 1, −3
           [ 0  0  1  1 ]        r = 4 = n  ⇒  四列线性无关
           [ 0  0  0 −3 ]
```

$$\det B = 1\cdot 1\cdot 1\cdot(-3) = -3 \neq 0.$$

步骤 2：结论。 $\det B = -3 \neq 0 \Rightarrow B$ 可逆 $\Rightarrow$ 四列线性无关 $\Rightarrow$ 由"$\mathbb{R}^4$ 中 4 个无关向量自动是基"（示例 5 的 $\mathbb{R}^n$ 版本），$\{\mathbf{b}_1,\mathbf{b}_2,\mathbf{b}_3,\mathbf{b}_4\}$ 是 $\mathbb{R}^4$ 的**一组基**。所以 $\dim \mathbb{R}^4 = 4$。

步骤 3：实际求坐标（这是"基"最有用的地方）。 求 $\mathbf{v} = (1,2,3,4)^T$ 在这组基下的坐标：解 $B\mathbf{c} = \mathbf{v}$。增广消元后得

$$[B \mid \mathbf{v}] \longrightarrow \left[\begin{array}{cccc|c}1&0&0&0&1/3\\0&1&0&0&4/3\\0&0&1&0&7/3\\0&0&0&1&2/3\end{array}\right] \Rightarrow \mathbf{c} = \begin{bmatrix}1/3\\4/3\\7/3\\2/3\end{bmatrix}.$$

验算：

$$\tfrac{1}{3}\mathbf{b}_1 + \tfrac{4}{3}\mathbf{b}_2 + \tfrac{7}{3}\mathbf{b}_3 + \tfrac{2}{3}\mathbf{b}_4 = \begin{bmatrix}1/3\\4/3\\7/3\\1/3+4/3+7/3+0\end{bmatrix} = \begin{bmatrix}1/3\\4/3\\7/3\\4\end{bmatrix}.$$

第 4 分量 $= \frac{1}{3}+\frac{4}{3}+\frac{7}{3} = \frac{12}{3} = 4$ ✓，前三个分量分别 $= 1,2,3$ ✓，所以 $\mathbf{v} = (1,2,3,4)^T$ ✓ **完全吻合**。

步骤 4：对照 $\mathbb{R}^4$ 中的相关情形。 若取 5 个 $\mathbb{R}^4$ 中的向量，则排成 4×5 矩阵，$r \le 4 < 5$，**必然相关**（与示例 2 的 $\mathbb{R}^3$/4 个向量完全同构）。**维数从 3 涨到 4，判据一个字没变：只要向量个数超过空间维数，必相关。**

【计算机制解说】 这个示例刻意展示"**结构性事实与维数无关**"。三个不变量在所有维度都成立：① 无关 $\iff r=n$（列数）；② 张成 $\iff r=m$（行数）；③ $\mathbb{R}^m$ 中超过 m 个向量必相关。$\mathbb{R}^3$ 与 $\mathbb{R}^4$ 的唯一区别只是数字 m 不同。**之所以要强调这一点，是因为本课程后半段会处理 $\mathbb{R}^n$（n 任意大）、函数空间、矩阵空间（Lecture 11 中 $\mathbb{R}^{3\times3}$ 的维数是 9）。如果只会数 $\mathbb{R}^3$，那些内容就无从下手。** 学习 $\mathbb{R}^4$ 示例的意义不在于"多算一个例子"，而在于确认这套语言是可移植的。

步骤 5：顺带确认 $N(B)=\{\mathbf{0}\}$。 既然 B 可逆，$B\mathbf{c}=\mathbf{0}$ 只有 $\mathbf{c}=\mathbf{0}$，所以四列无关的另一重表述就是零空间平凡。RREF 为单位矩阵 $\begin{bmatrix}1&0&0&0\\0&1&0&0\\0&0&1&0\\0&0&0&1\end{bmatrix}$ ✓（无自由变量，$\dim N(B)=4-4=0$）。

矩阵分解的核心思想

本讲涉及的核心"分解"是 $A=CR$ 与 **秩的列/行双重读法**——它们把"主元列是 $C(A)$ 的基"这一定理写成了矩阵等式。

（1）$A=CR$（基的显式打包）。 在 Lecture 8 主例中，A 的主元列是 col₁、col₃。把主元列取出作 C，R 的非零行取出（它们是 R 的前两行）——R 的非主元列正是"用主元列表示该列"的系数：

$$C=\begin{bmatrix}1&2\\2&6\\3&8\end{bmatrix},\qquad R=\begin{bmatrix}1&2&0&-2\\0&0&1&2\end{bmatrix},\qquad CR=\begin{bmatrix}1&2&2&2\\2&4&6&8\\3&6&8&10\end{bmatrix}=A\ \checkmark$$

（逐项验算：CR 的 col$_2=2\cdot C$ 的 col$_1+0\cdot C$ 的 col$_2=(2,4,6)^T$ ✓；col$_4=-2\cdot(1,2,3)^T+2\cdot(2,6,8)^T=(2,8,10)^T$ ✓。）

这个分解的含义：C 的 r 列是 $C(A)$ 的**基**（示例 4 已证无关 + 示例 4 的列关系论证张成），R 的 r 行是 $C(A^T)$ 的基。所以 $A=CR$ 把 A 拆成"列空间的基 × 行空间的基的系数"，把 rank 的含义**直接写进乘积**：A 的"信息量"刚好是 r 个方向的乘积。这也说明**每个矩阵都是"瘦"矩阵与"矮"矩阵之积，中间维数恰为 r**。

（2）$A=LU$ 中的"基"视角。 Lecture 2–4 的前向消元给出 $A=LU$。从本讲看，消元的每一步都在做**列的替换**（用当前列的倍数去消下方的项），主元位置标出了"哪些列是独立的"。U 的主元列数目就是 r，U 中非主元列与主元列的关系与 A 中完全一致（行变换保持列关系）——这正是示例 4 与上面 $A=CR$ 的依据。

（3）$A=QR$（前瞻 Lecture 17）。 正交化的意义在于得到一组"又无关又正交"的基：Gram–Schmidt 从任意无关组出发（**前提**就是线性无关！）造出正交基，于是 $A=QR$ 中的 Q 的列是 $C(A)$ 的**标准正交基**。本讲的无关性/基概念是 QR 分解的入场券：没有无关性就谈不上"用 Gram–Schmidt 造基"。

（4）与其他分解的共同模式。 本课程的每一类分解都在回答同一个问题：**"这个对象的维数是多少？它的基是什么？"** $A=CR$ 给出列空间/行空间的基；$A=QR$ 给出标准正交基；$A=S\Lambda S^{-1}$（Lecture 21）用**特征向量**作基（要求 A 有 n 个无关特征向量！）；$A=U\Sigma V^T$（Lecture 29）用两组标准正交基把 A 拆成若干个秩 1 片之和，而奇异值非零的个数正是 r。**"无关 ⇒ 基 ⇒ 维数"这条链条贯穿整个课程。**

与其他讲次的关联

- **回看 Lecture 6–8（子空间与 $A\mathbf{x}=\mathbf{b}$）**：$C(A)=\text{span}\{\text{列}\}$ 是张成的第一个例子；Lecture 8 的"秩分类表"完全靠 r 说话，而本讲给出 r 的**几何定义**（$C(A)$ 的维数）。
- **回看 Lecture 7（零空间的特殊解）**：本讲示例 4 证明了特殊解构成 N(A) 的**基**，从而 N(A) 的维数就是自由变量个数 $n-r$。这是 Lecture 7 算法为什么正确的补课。
- **前瞻 Lecture 10（四个基本子空间）**：本讲的四条结论在那里汇成维数定理：$\dim C(A)=r$，$\dim C(A^T)=r$，$\dim N(A)=n-r$，$\dim N(A^T)=m-r$。其中前两条都依赖"主元列是 $C(A)$ 的基"和"主元行是 $C(A^T)$ 的基"。
- **前瞻 Lecture 11（矩阵空间、图与 $A=CR$）**：本讲的 $A=CR$ 被推广为"小矩阵乘小矩阵给出大矩阵"的核心思想；图论中的关联矩阵的秩 $=n-1$ 也用"无关性 + 张成"来证。
- **前瞻 Lecture 21（特征值与特征向量）**：对角化 $A=S\Lambda S^{-1}$ 的前提是 A 有 n 个**线性无关**的特征向量——正是本讲的定义。若特征向量不足（重根不足），矩阵就不可对角化（引入 Jordan 形，Lecture 28）。
- **前瞻 Lecture 30（线性变换与基变换）**：本讲示例 1 的步骤 5 已经展示了"同一向量在不同基下坐标不同"；Lecture 30 把它系统化为相似矩阵 $B=M^{-1}AM$ 与基变换公式。

关键要点

1. **线性无关的定义与四个等价刻画**：$\sum c_i\mathbf{v}_i=\mathbf{0}$ 只有零解 $\iff N(A)=\{\mathbf{0}\}$（A 以这些向量为列）$\iff r=n$（列满秩）$\iff$ 没有一个向量是其余向量的线性组合。方阵时再加一条 $\det A\neq0$。
2. **张成与基**：span 是全部线性组合，永远过原点、永远是子空间。**基 = 线性无关 + 张成**；等价的实用判据：$\mathbb{R}^n$ 中 n 个向量，**无关 $\iff$ 张成 $\iff$ 是基**。
3. **基中向量个数唯一，这个数叫维数**：$\dim V$ 与基的选取无关。$\dim\mathbb{R}^n=n$；$\dim\{\mathbf{0}\}=0$；过原点平面的维数是 2；直线的维数是 1。
4. **$\mathbb{R}^m$ 中任意 $m+1$ 个向量必线性相关**（一般地：任何多于 m 个的 $\mathbb{R}^m$ 向量组必相关）。理由：未知数多于方程 ⇒ 必有自由变量 ⇒ 零空间非平凡。

5. **秩的完整含义**：r = 主元个数 = **无关列的最大数目** = $C(A)$ 的维数 = 独立行的个数 = $C(A^T)$ 的维数。$n-r$ 是 N(A) 的维数（自由变量个数），$m-r$ 是 N(A^T) 的维数。

常见误区与注意事项

1. **把"线性无关"与"两两不成比例"混为一谈。** 两两不成比例是**必要**条件，但远不充分。反例（示例 5 的 B_3）：$\mathbf{a_1}=(1,1,0)$、$\mathbf{a_2}=(2,0,1)$、$\mathbf{a_3}=(3,1,1)$，任意两个都不成比例，但 $\mathbf{a_3}=\mathbf{a_1}+\mathbf{a_2}$，三个整体**相关**（$\det=0$）。判断三向量组必须整体看（行列式或 RREF），不能只比较两两。
2. **"k 个向量张成 V"就误认为它们是基。** 还差无关性。例如 $\mathbb{R}^3$ 中 $\{(1,0,0),(0,1,0),(0,0,1),(1,1,1)\}$ 张成 $\mathbb{R}^3$ 但**不是**基（4 个、相关）。基要求**恰好** $=\dim V$ 个。
3. **把 $\mathbf{0}$ 放进基，或认为含 $\mathbf{0}$ 的组可以是基。** 任何含 $\mathbf{0}$ 的向量组**必然相关**（取 $\mathbf{0}$ 的系数为 1、其余为 0 即得零组合），所以绝不可能成为基。同理"重复的向量"也必然相关。
4. **忘记"无关性依赖所在的域/空间维数"。** 同一组向量在不同空间里的无关性判断不同（严格说，向量的所属空间决定了 m）。关键在于个数与维数的比较：在 $\mathbb{R}^3$ 中 4 个向量必相关，但在 $\mathbb{R}^4$ 中这 4 个可能无关。做题时先写清维数。
5. **两个"不变量"混淆**：① 把维数公式记成 $\dim N(A)=m-r$——永远是 $n-r$（n = 列数 = 未知数个数），$\dim N(A^T)=m-r$。本讲示例 4 中 $m=3,n=4,r=2$：$\dim N(A)=2$、$\dim N(A^T)=1$。这个错误在 FORMAT 规范里被点名，务必警惕。② 把"基不唯一"误推为"维数不唯一"——基是选取，维数是内在属性。$\mathbb{R}^3$ 有无穷多组基（示例 5 的 B_1,B_2 只是两个），但 $\dim$ 恒为 3。**换基不换维数。**

思考题（带答案）

Q1. 判断下列向量组在 $\mathbb{R}^3$ 中是否线性无关；若相关，写出一个具体的线性关系。

(a) $\mathbf{v_1}=(1,2,3)^T,\ \mathbf{v_2}=(2,4,6)^T,\ \mathbf{v_3}=(1,0,1)^T$。(b) $\mathbf{w_1}=(1,1,0)^T,\ \mathbf{w_2}=(2,0,1)^T,\ \mathbf{w_3}=(3,1,1)^T$。(c) $\mathbf{u_1}=(1,2,3)^T,\ \mathbf{u_2}=(1,0,1)^T,\ \mathbf{u_3}=(0,1,1)^T$。

▸ **答案**

(a) **相关。** $\mathbf{v_2}=2\mathbf{v_1}$，故 $2\mathbf{v_1}-\mathbf{v_2}+0\cdot\mathbf{v_3}=\mathbf{0}$ 是全不全为零的组合（系数 $2,-1,0$）。行列式 $\det\begin{bmatrix}1&2&1\\2&4&0\\3&6&1\end{bmatrix}=0$ ✓（第 2 列 $=2\times$ 第 1 列）。

(b) **相关。** $\mathbf{w_3}=\mathbf{w_1}+\mathbf{w_2}=(1+2,\ 1+0,\ 0+1)^T=(3,1,1)^T$ ✓。关系：$\mathbf{w_1}+\mathbf{w_2}-\mathbf{w_3}=\mathbf{0}$。RREF 验算：以它们为列的矩阵 $\begin{bmatrix}1&2&3\\1&0&1\\0&1&1\end{bmatrix}$，消元得主元列只有前两列，$r=2<3=n$ ✓ 相关。（注意 (b) 就是示例 5 中被判为"不是基"的 B_3。）

(c) **相关。** 行列式 $\det\begin{bmatrix}1&1&0\\2&0&1\\3&1&1\end{bmatrix}=1(0-1)-1(2-3)+0=-1+1=0$ ✓。求关系：RREF 为 $\begin{bmatrix}1&0&1/2\\0&1&-1/2\\0&0&0\end{bmatrix}$，$x_3$ 自由，取 $x_3=1$ 得 $x_1=-\frac{1}{2},x_2=\frac{1}{2}$。乘以 2 消去分数：$-1\cdot\mathbf{u_1}+1\cdot\mathbf{u_2}+2\cdot\mathbf{u_3}=\mathbf{0}$。**验算**：$-(1,2,3)+(1,0,1)+2(0,1,1)=(-1+1+0,\ -2+0+2,\ -3+1+2)=(0,0,0)$ ✓。

总结：三组都是相关的（$\mathbb{R}^3$ 中三向量是否无关必须真算，不能直觉判断）。判断方法：排成 3×3 矩阵算行列式（$\neq0$ 无关）或化 RREF 看主元个数是否为 3。

Q2. （纯计算）设 $V=\mathbf{span}\{(1,0,1)^T,(0,1,1)^T,(1,2,3)^T\}\subseteq\mathbb{R}^3$。求 V 的一组基与 $\dim V$，并给出 V 的方程（即把 V 写成某个矩阵的零空间）。

▸ **答案**

把三个向量作为**行**排成矩阵（对行空间/张成空间求基，用行最简形最方便）：

$$M=\begin{bmatrix}1&0&1\\0&1&1\\1&2&3\end{bmatrix}.$$

步骤 1：先看是否相关。 观察：$\mathbf{row_1}+2\mathbf{row_2}=(1,0,1)+(0,2,2)=(1,2,3)=\mathbf{row_3}$ ✓。所以三个向量**相关**，$\mathbf{row_3}$ 是多余的信息。

步骤 2：消元求行最简形。 $\mathbf{row_3}\leftarrow\mathbf{row_3}-\mathbf{row_1}=[0,2,2]$；再 $\mathbf{row_3}\leftarrow\mathbf{row_3}-2\mathbf{row_2}=[0,2,2]-[0,2,2]=[0,0,0]$。

```
RREF(M) = [ 1  0  1 ]      r = 2, 主元行 = 前两行
          [ 0  1  1 ]      第 3 行 = 0  ⇒  原 row₃ = row₁ + 2·row₂
          [ 0  0  0 ]
```

所以 $r=2$，$\dim V=2$。（V 是 M 的行空间，而 $\dim C(M^T)=\dim C(M)=r$，Lecture 10 会给出这条等式。）

步骤 3：取基。 规范做法是取 RREF 的**非零行**：

$$\text{基}=\left\{\begin{bmatrix}1\\0\\1\end{bmatrix},\ \begin{bmatrix}0\\1\\1\end{bmatrix}\right\}.$$

验证无关：这两个向量在**主元列**（col₁、col₂）位置上恰好是 $\mathbf{e_1},\mathbf{e_2}$，2×2 子式 $\det\begin{bmatrix}1&0\\0&1\end{bmatrix}=1\neq0$，故无关 ✓。

验证张成：V 中任一向量是三个生成元的组合，而 $\mathbf{row_3}=\mathbf{row_1}+2\mathbf{row_2}$，所以只需前两行；故 $\{(1,0,1)^T,(0,1,1)^T\}$ 张成 V ✓。

既无关又张成 ⇒ 是**基**，$\dim V=2$ ✓。

步骤 4：求 V 的方程。 $\dim V=2$ 且 $V\subseteq\mathbb{R}^3$ 是子空间，故 V 是过原点的**平面**。平面等于某个 1×3 矩阵 $\mathbf{n}^T$ 的零空间 $N(\mathbf{n}^T)$，条件是 $\mathbf{n}$ 同时垂直于两个基向量。用叉积：

$$\mathbf{n}=(1,0,1)\times(0,1,1)=\begin{vmatrix}\mathbf{i}&\mathbf{j}&\mathbf{k}\\1&0&1\\0&1&1\end{vmatrix}=(0\cdot1-1\cdot1,\ 1\cdot0-1\cdot1,\ 1\cdot1-0\cdot0)=(-1,-1,1).$$

所以 $V=N([-1\ -1\ 1])$，即

$$\boxed{-x_1-x_2+x_3=0,\quad\text{等价地}\quad x_3=x_1+x_2.}$$

步骤 5：三重验算。

- $(1,0,1)$：$-1-0+1=0$ ✓
- $(0,1,1)$：$-0-1+1=0$ ✓
- $(1,2,3)$：$-1-2+3=0$ ✓（生成元都在平面上，符合预期）

步骤 6：反过来验证平面的每个点都在 V 中（这一步常被忽略，但它证明 V 与平面**恰好相等**而非仅仅 $V\subseteq$ 平面）。平面上任取 $(a,b,a+b)$，则

$$\begin{bmatrix}a\\b\\a+b\end{bmatrix}=a\begin{bmatrix}1\\0\\1\end{bmatrix}+b\begin{bmatrix}0\\1\\1\end{bmatrix}\in V\ \checkmark$$

即维度相同（都是 2）且 $V\subseteq$ 平面，故 $V=$ 平面。

最终答案：一组基 $\{(1,0,1)^T,(0,1,1)^T\}$，$\dim V=2$，$V=\{x_3=x_1+x_2\}$。

注意：三个生成元本身**不是**基（它们相关）。$\dim V=2<3$——这是"张成 V 的向量组不一定无关、其个数可以多于 $\dim V$"的典型例子，正好呼应本讲"基要不多不少刚刚好"的主题。

Q3. （概念）判断对错并说明理由：

(a) 若 $\{\mathbf{v_1},\mathbf{v_2},\mathbf{v_3}\}$ 是 $\mathbb{R}^3$ 的基，则 $\{\mathbf{v_1}+\mathbf{v_2},\ \mathbf{v_2}+\mathbf{v_3},\ \mathbf{v_3}+\mathbf{v_1}\}$ 也是 $\mathbb{R}^3$ 的基。(b) $\mathbb{R}^3$ 中任意 3 个线性无关的向量都是 $\mathbb{R}^3$ 的基。(c) 若 $\dim V=3$ 且 $\mathbf{w_1},\mathbf{w_2},\mathbf{w_3}\in V$ 张成 V，则它们线性无关。(d) $N(A)$ 的维数等于 A 中自由变量的个数；若 A 是 4×6 且 $r=3$，则 $\dim N(A)=3$。

▸ **答案**

(a) 对。 设原基为 $\mathbf{v_1},\mathbf{v_2},\mathbf{v_3}$（无关，且张成 $\mathbb{R}^3$）。新的三个向量显然是原基的组合，所以都落在 $\mathbb{R}^3$ 中。要证无关：设 $c_1(\mathbf{v_1}+\mathbf{v_2})+c_2(\mathbf{v_2}+\mathbf{v_3})+c_3(\mathbf{v_3}+\mathbf{v_1})=\mathbf{0}$，整理得

$$(c_1+c_3)\mathbf{v}_1+(c_1+c_2)\mathbf{v}_2+(c_2+c_3)\mathbf{v}_3=\mathbf{0}.$$

由 $\mathbf{v}_i$ 无关，得方程组 $c_1+c_3=0,\ c_1+c_2=0,\ c_2+c_3=0$。系数矩阵 $\begin{bmatrix}1&0&1\\1&1&0\\0&1&1\end{bmatrix}$ 的行列式 $=2\neq 0$（示例 1 算过），故只有 $c_1=c_2=c_3=0$。所以新组无关；$\mathbb{R}^3$ 中 3 个无关向量自动是基（见 (b)），故是基 ✓。

（**更快的做法**：从原基到新组的过渡矩阵 $T=\begin{bmatrix}1&1&0\\0&1&1\\1&0&1\end{bmatrix}$，$T$ 可逆 $\iff$ 新组是基。$\det T=2\neq 0$ ✓。这个"过渡矩阵"思想在 Lecture 30 会正式使用。）

(b) 对。 设 $\mathbf{a}_1,\mathbf{a}_2,\mathbf{a}_3\in\mathbb{R}^3$ 无关，$A=[\mathbf{a}_1\ \mathbf{a}_2\ \mathbf{a}_3]$。无关 $\Rightarrow r=n=3=n$；A 是 3×3，$r=3$ 意味着有 3 个主元，$\det A\neq 0$，A 可逆，故 $A\mathbf{x}=\mathbf{b}$ 对一切 $\mathbf{b}$ 可解，即三列张成 $\mathbb{R}^3$。所以是基 ✓。**这就是"$\mathbb{R}^n$ 中 n 个无关向量自动是基"的一般结论**，也说明了本题与示例 5 的关系。

(c) 对。 设它们相关，则至少有一个是其余的组合，可以从组中扔掉而不减少张成空间，故 V 可以由**至多 2 个**向量张成，于是 $\dim V\le 2$，与 $\dim V=3$ 矛盾。所以它们无关 ✓。更形式化地：若相关，则存在不全为零的系数使 $\sum c_i\mathbf{w}_i=\mathbf{0}$，于是这 3 个向量落在某个维数 ≤ 2 的子空间里，张成维数 <3。**"$\dim V$ 个向量张成 $V\Rightarrow$ 无关"是"$\dim V$ 个无关向量 $\Rightarrow$ 张成"的对偶命题**，两者都源于"V 中任何无关组不超过 $\dim V$ 个向量"。

(d) 对。 第一句是 Lecture 7–8 的结论：$\dim N(A)=n-r=$ 自由变量个数。第二句：$n=6,r=3\Rightarrow\dim N(A)=6-3=3$ ✓。（**注意不是 $m-r=4-3=1$**，那是 $\dim N(A^T)$。这类混淆是本讲注意事项第 5 条点名的错误。）

Lecture 10: The Four Fundamental Subspaces

概述

第 9 讲我们学会了怎么**判断**一组向量是不是子空间；本讲要把它用在矩阵 A（$m\times n$，秩为 r）身上，找出四个"天生"就绑定在 A 上的子空间：列空间 C(A)、零空间 N(A)、行空间 C(A^T)、左零空间 N(A^T)。它们被 Strang 称为 **the four fundamental subspaces**（四个基本子空间），是整个 18.06 的"统一场论"——从本讲到课程结束，几乎每一个新概念（投影、最小二乘、伪逆、SVD）都只是在这张图上再加一笔。

本讲的三大成果：（1）**维数定理** $\dim C(A)=\dim C(A^{\mathrm{T}})=r$，$\dim N(A)=n-r$，$\dim N(A^{\mathrm{T}})=m-r$；（2）**正交关系** C($A^T$) ⊥ N(A)、C(A) ⊥ N($A^T$)，且在各自空间里恰好互补；（3）**A = CR 分解**，它把"秩 r"这句话翻译成了一个精确的等式。学会这一讲，你就拿到了理解"$A\mathbf{x}=\mathbf{b}$ 什么时候有解、有多少解"的完整钥匙。

核心概念的几何直觉

在展开之前，先立一条贯穿全讲的**空间归属表**。这是最容易出错的地方，请先记住：

子空间	记号	住在哪个空间	含义
列空间	C(A)	$\mathbb{R}^m$	所有列向量的线性组合
零空间	N(A)	$\mathbb{R}^n$	所有满足 $A\mathbf{x}=\mathbf{0}$ 的 $\mathbf{x}$
行空间	C(A^T)	$\mathbb{R}^n$	所有行向量的线性组合
左零空间	N(A^T)	$\mathbb{R}^m$	所有满足 $A^{\mathrm{T}}\mathbf{y}=\mathbf{0}$ 的 $\mathbf{y}$

一句话记法：**"A 把 $\mathbb{R}^n$ 射到 $\mathbb{R}^m$，所以凡是跟输入 $\mathbf{x}$ 有关的（行空间、零空间）住 $\mathbb{R}^n$；凡是跟输出 $\mathbf{b}$ 有关的（列空间、左零空间）住 $\mathbb{R}^m$。**" 行空间**不是** $\mathbb{R}^m$ 里的东西——这是 18.06 考试里最常见的送命题。

概念一：列空间 C(A)（column space）

- **定义与目的**：C(A) 是 A 的**所有列的线性组合**构成的集合，也就是集合 $\{A\mathbf{x}:\mathbf{x}\in\mathbb{R}^n\}$。它的目的很单纯：$A\mathbf{x}=\mathbf{b}$ **有解** $\iff\mathbf{b}\in C(A)$。列空间就是"A 能造出来的所有右边项 $\mathbf{b}$"的总和。
- **几何直觉（它在空间中是什么样子？）**：把 A 看成一个线性变换，它把整个 $\mathbb{R}^n$ 压扁、旋转、拉伸后得到的像，就是 C(A)。A 有 n 个列向量，但很多列可能是"废的"（前面列的线性组合），真正能撑开新方向的只有 r 个——所以 C(A) 是 $\mathbb{R}^m$ 中过原点的一个 r 维"平板"（$r=1$ 是直线，$r=2$ 是平面，$r=m$ 就撑满整个 $\mathbb{R}^m$）。**关键点：C(A) 是 $\mathbb{R}^m$ 的子空间，不是 $\mathbb{R}^n$ 的。** 3×3 矩阵的列空间住在 $\mathbb{R}^3$；3×4 矩阵的列空间也住在 $\mathbb{R}^3$（4 个列向量塞在三维空间里，必然有冗余）。
- **具体示例**：取

$$A_1 = \begin{bmatrix} 1 & 2 & 3 \\ 2 & 4 & 6 \\ 1 & 2 & 3 \end{bmatrix}.$$

第二列恰好是第一列的 2 倍，第三列是第一列的 3 倍。三个列向量全躺在同一条直线上，所以 C(A_1) 是一条直线（1 维），例如 $\mathbf{span}\{(1,2,1)^{\mathsf{T}}\}$。注意 A_1 是 3×3，但 C(A_1) 只有 1 维——**矩阵大小和列空间维数无关**。

概念二：零空间 N(A)（nullspace）

- **定义与目的**：N(A) 是**所有满足 $A\mathbf{x}=\mathbf{0}$ 的 $\mathbf{x}$** 的集合。它的目的是记录"A 抹掉了哪些方向"：如果 $\mathbf{x}\in N(A)$ 且 $\mathbf{x}\neq\mathbf{0}$，那么 A 把这个非零向量直接压成了零。N(A) 控制 $A\mathbf{x}=\mathbf{b}$ 的**解的自由度**（有多少个特解之外的"零空间漂移"）。
- **几何直觉（它在空间中是什么样子？）**：N(A) 是 $\mathbb{R}^n$ 中过原点的一个子空间——为什么过原点？因为 $A\mathbf{0}=\mathbf{0}$，零向量永远在；为什么封闭？因为 $A\mathbf{x}=\mathbf{0}$ 且 $A\mathbf{y}=\mathbf{0}$ 时，$A(\mathbf{x}+\mathbf{y})=\mathbf{0}+\mathbf{0}=\mathbf{0}$。几何上，零空间就是变换 A 的"**盲区**"（Strang 常说的 the subspace that gets wiped out）：它是 $\mathbb{R}^n$ 中被 A 整块压到原点去的那些方向。
- **具体示例**：对上面的 A_1：

$$A_1\mathbf{x}=\mathbf{0} \iff x_1\begin{bmatrix}1\\2\\1\end{bmatrix}+x_2\begin{bmatrix}2\\4\\2\end{bmatrix}+x_3\begin{bmatrix}3\\6\\3\end{bmatrix}=\begin{bmatrix}0\\0\\0\end{bmatrix}.$$

只看第一行就得到 $x_1+2x_2+3x_3=0$（第二行是它的 2 倍、第三行与它相同，自动满足）。所以零空间由**一个**方程决定。这是 $\mathbb{R}^3$ 中一个平面的方程，所以 N(A_1) 是 2 维的——一条"零空间平面"。稍后我们会算出它的两组基 $(-2,1,0)$ 和 $(-3,0,1)$。

概念三：行空间 C(A^{T})（row space）

- **定义与目的**：C(A^{T}) 是 A 的**所有行的线性组合**。注意 A^{T} 是 $n\times m$ 矩阵，它的列就是 A 的行，所以 C(A^{T}) 就是"A 的行空间"。它的目的是回答：**$A\mathbf{x}=\mathbf{b}$ 的每个方程在说什么？** 第 i 个方程是"$\mathbf{x}$ 与第 i 行做内积 = b_i"，所以整组方程真正携带的信息，全在行空间里。
- **几何直觉（它在空间中是什么样子？）**：**行空间住在 $\mathbb{R}^n$**，而且可以和零空间画在同一个方块里。它是消元过程中"行向量能张成的那部分"。几何上它最生动的角色是**约束空间**：每一个行向量 $\mathbf{r}$ 都对解 $\mathbf{x}$ 施加一条"$\mathbf{r}\cdot\mathbf{x}=b$"的约束；$r$ 个独立约束把解集从一个 n 维空间削成 $n-r$ 维。
- **具体示例**：A_1 的三行是 $(1,2,3),(2,4,6),(1,2,3)$，后两行都是第一行的倍数，所以 C(A_1^{T}) = $\mathbf{span}\{(1,2,3)\}$，1 维，住在 $\mathbb{R}^3$ 中。

概念四：左零空间 N(A^{T})（left nullspace）

- **定义与目的**：N(A^{T}) 是**所有满足 $A^{\mathsf{T}}\mathbf{y}=\mathbf{0}$ 的 $\mathbf{y}$**。为什么叫"左"零空间？把 $A^{\mathsf{T}}\mathbf{y}=\mathbf{0}$ 两边转置得 $\mathbf{y}^{\mathsf{T}}A=\mathbf{0}^{\mathsf{T}}$——$\mathbf{y}^{\mathsf{T}}$ 乘在 A 的**左边**，故名。它的目的是回答：**A 的各行之间存在哪些线性关系？** 因为 $A^{\mathsf{T}}\mathbf{y}=\mathbf{0}$ 展开就是 $y_1(\mathbf{row}_1)+y_2(\mathbf{row}_2)+\cdots+y_m(\mathbf{row}_m)=\mathbf{0}$，即"行向量的一个零组合"。它同时给出 $A\mathbf{x}=\mathbf{b}$ 的**相容性条件**（solvability condition）。
- **几何直觉（它在空间中是什么样子？）**：N(A^{T}) **住在 $\mathbb{R}^m$**，和列空间同住一个方块。它是 $\mathbb{R}^m$ 中"与 A 的所有列都垂直"的方向——因为 $\mathbf{y}^{\mathsf{T}}A=\mathbf{0}$ 意味着 $\mathbf{y}^{\mathsf{T}}(\text{每一列})=0$。所以左零空间是列空间的**正交补**。
- **具体示例**：A_1 满足 $\mathbf{row}_2=2\,\mathbf{row}_1$、$\mathbf{row}_3=\mathbf{row}_1$，所以 $\mathbf{y}=(-2,1,0)^{\mathsf{T}}$ 和 $\mathbf{y}=(-1,0,1)^{\mathsf{T}}$ 都在 N(A_1^{T}) 里，2 维。它们也就是说：右边项必须满足 $b_2=2b_1$ 和 $b_3=b_1$，$A_1\mathbf{x}=\mathbf{b}$ 才有解。

把四个子空间画进一张图（Strang 的"大图"）

这是 18.06 最著名的一张图。左边方块是输入空间 $\mathbb{R}^n$，右边方块是输出空间 $\mathbb{R}^m$，中间是变换 A。每个方块都被"切成"两半：r 维的那半是 A 真正"干活"的，$n-r$ 或 $m-r$ 维的那半是被 A 压成零的。

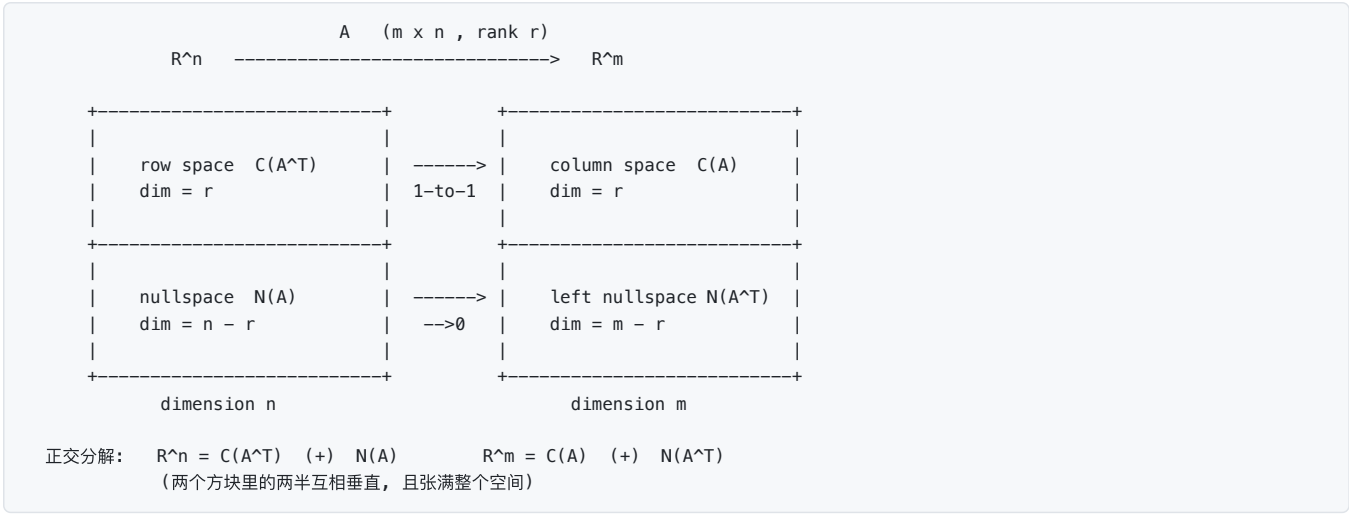

用 A_1（$m = n = 3$，$r = 1$）代入这张图：

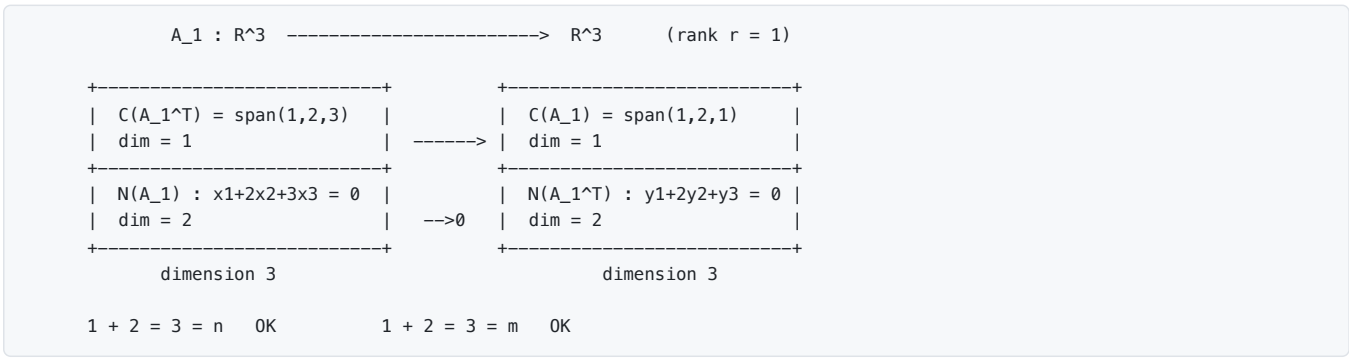

读图的三个要点：

1. **上下两半是正交的**（虚线切开的两个区域互相垂直），而不是随便切。
2. **A 把行空间一对一地映到列空间**（left half → left half, 1–to–1）。这是"秩 = 行秩 = 列秩"的几何化身：r 维进，r 维出，不压扁也不多余。
3. **A 把零空间整块压到原点**（$n - r$ 维进去，出来只有 $\mathbf{0}$）。所以 $A\mathbf{x} = \mathbf{b}$ 有解时，解集是一条 $n - r$ 维的"平移过的零空间"。

定理一：行秩 = 列秩（维数定理的核心）

这条定理是整个课程最"反直觉但极重要"的事实：A 有 m 行、n 列，行数与列数通常**不相等**，可是**独立行的最大数目恰好等于独立列的最大数目**。一个 3×7 的矩阵可以最多有 3 个独立行，但为什么它也最多只有 3 个独立列？为什么不能是 5？

证明（消元视角，最直观的一种）。

对 A 做消元得到行阶梯形 U（或 RREF）。记 r 为 U 的**非零行数**，也就是主元的个数。我们分别数两边的秩。

(1) 行秩 $= r$。 消元是**可逆的行操作**，每一步都是"某行减去另一行的倍数"或"交换两行"或"某行乘非零数"。这类操作不改变行向量之间的线性关系：

$$\sum c_i \,\mathrm{row}_i(A) = \mathbf{0} \iff \sum c_i \,\mathrm{row}_i(U) = \mathbf{0}.$$

（理由：行操作等价于左乘可逆矩阵 E，$EA\mathbf{c}$ 与 $A\mathbf{c}$ 同为零当且仅当 $\mathbf{c}$ 使 $A\mathbf{c} = \mathbf{0}$，因为 E 可逆。）所以 A 的行空间与 U 的行空间是**同一个子空间**，行秩 $= \dim C(A^{\mathsf{T}}) = \dim C(U^{\mathsf{T}})$。

而在 U 中，非零行显然线性无关（每一行都有一个其他行没有的主元位置——第 i 个非零行的主元在第 p_i 列，且第 p_i 列在其他非零行处都是 0）。零行不贡献。因此 $\dim C(U^{\mathsf{T}}) = r$，即

$$\boxed{\text{行秩} = r}$$

(2) 列秩 $= r$。 这一半要用"**主元列**"。在 RREF 中，主元列恰好是标准基向量 $\mathbf{e}_1, \ldots, \mathbf{e}_r$（按主元顺序），它们显然线性无关；而非主元列都是主元列的线性组合（RREF 里该列的数字就是系数）。所以 RREF 的列秩 $= r$。

因为行操作保持"列与列之间的线性关系"（见后面【计算机制解说】的详细论证），A 的列之间的线性关系与 RREF 的列完全相同，所以 A 的列秩也 $= r$：

$$\boxed{\text{列秩} = r}$$

结论：行秩 = 列秩 = r = 主元个数 = U 的非零行数。这个 r 被统称为**矩阵的秩**，它同时是"独立行的最大数目"与"独立列的最大数目"。

为什么这件事不平凡？ 用一张图看：

```
一个 3 x 7 的矩阵 A (m=3, n=7)。
行只有 3 个, 所以行秩 <= 3 是显然的。
但列有 7 个!  为什么列秩也不可能超过 3 ?

答案: 7 个列向量住在一个 3 维的空间 R^3 里。
      n 个向量若住在 R^m 中, 它们最多只能张成 m 维。

+-------------------------------------------------+
|  列向量 (7 个箭头挤在 R^3 里)                    |
|    col1 col2 col3 col4 col5 col6 col7           |
|     \    |    /   \    |    /   /               |
|      \   |   /     \   |   /   /                |
|       v  v  v       v  v  v   v                 |
|        张成的最多 3 维!  r <= m = 3              |
+-------------------------------------------------+

所以 r <= min(m, n) 是必然的; 而 r = 行秩 = 列秩。
一般结论: rank(A) <= min(m, n)   ("秩不超过短边")
```

一般情况下：$r \le m$（因为 r 个主元分布在 m 行里）且 $r \le n$（因为 r 个主元分布在 n 列里），所以

$$\mathbf{rank}(A) \le \min(m, n).$$

当 $r = \min(m, n)$ 时称矩阵为**满秩**（full rank）：$m \le n$ 时叫满行秩，$n \le m$ 时叫满列秩。

定理二：正交关系（严格证明）

定理：在 $\mathbb{R}^n$ 中 $C(A^{\mathsf{T}}) \perp N(A)$ 且二者互补；在 $\mathbb{R}^m$ 中 $C(A) \perp N(A^{\mathsf{T}})$ 且二者互补。

证明（第一部分：正交性）。

任取 $\mathbf{x} \in N(A)$ 和 A 的任意一行 $\mathbf{a}_i^{\mathsf{T}}$（即 A 的第 i 行）。由 $A\mathbf{x} = \mathbf{0}$，第 i 个分量给出

$$\mathbf{a}_i^{\mathsf{T}}\mathbf{x} = 0.$$

这就是"$\mathbf{x}$ 与第 i 行正交"。因为 i 任意，$\mathbf{x}$ 与 A 的**每一行**都正交。而 $C(A^{\mathsf{T}})$ 的每个向量都是这些行的线性组合 $\sum c_i \mathbf{a}_i$，于是

$$\Big(\sum_i c_i \mathbf{a}_i\Big)^{\mathsf{T}}\mathbf{x} = \sum_i c_i\,(\mathbf{a}_i^{\mathsf{T}}\mathbf{x}) = \sum_i c_i \cdot 0 = 0.$$

所以每个 $\mathbf{x} \in N(A)$ 与每个 $C(A^{\mathsf{T}})$ 的向量正交，即 $C(A^{\mathsf{T}}) \perp N(A)$。∎

这个证明的一句话版本："**$A\mathbf{x} = \mathbf{0}$ 的全部含义就是：$\mathbf{x}$ 垂直于 A 的每一行。而'垂直于每一行'就是'垂直于行空间'。**" 零空间的定义式本身就是一条正交声明——这是四个子空间理论的"种子"。

证明（第二部分：互补性，即维数相加等于 n）。

正交只说明 $C(A^{\mathsf{T}})^{\perp} \supseteq N(A)$，还要说明**没有多余**。用维数：

- 已知 $\dim C(A^{\mathsf{T}}) = r$，$\dim N(A) = n - r$，两者相加 $= n$。
- 直接取 A 的 RREF，主元列给出 r 个独立的约束。解 $A\mathbf{x} = \mathbf{0}$ 时，$n - r$ 个自由变量对应 $n - r$ 个线性无关的解向量（每个自由变量取 1、其余取 0，得到一组"单位自由坐标"向量，它们显然线性无关）。所以 $\dim N(A) = n - r$ 已被独立算出。
- 由于 $C(A^{\mathsf{T}}) \subseteq N(A)^{\perp}$（第一部分）且 $\dim C(A^{\mathsf{T}}) = r = n - (n - r) = n - \dim N(A)$，两边维数相同，于是 $C(A^{\mathsf{T}}) = N(A)^{\perp}$，即二者正交互补。

写成分解式：

$$\mathbb{R}^n = \underbrace{C(A^{\mathsf{T}})}_{r} \oplus \underbrace{N(A)}_{n-r}, \qquad \mathbb{R}^m = \underbrace{C(A)}_{r} \oplus \underbrace{N(A^{\mathsf{T}})}_{m-r}.$$

为什么"⊕"（直和）不允许有公共非零向量？ 设 $\mathbf{v}$ 同时属于 $C(A^{\mathsf{T}})$ 与 $N(A)$。由正交性，$\mathbf{v} \perp \mathbf{v}$，即 $\mathbf{v}^{\mathsf{T}}\mathbf{v} = \|\mathbf{v}\|^2 = 0$，故 $\mathbf{v} = \mathbf{0}$。**"自垂直的向量只能是零向量"**——这个简单的观察保证了分解的唯一性：任何 $\mathbf{x} \in \mathbb{R}^n$ 都能**唯一**地写成一个行空间向量加一个零空间向量。

几何含义：给定任意 $\mathbf{b} \in \mathbb{R}^m$，它被唯一地拆成"$A$ 能达到的部分"（$\in C(A)$）与"A 永远达不到的部分"（$\in N(A^{\mathsf{T}})$）。加粗说：**$\mathbf{b}$ 能写进 C(A) 的部分就是最小二乘要逼近的部分，剩下的垂直残差就是 $N(A^{\mathsf{T}})$ 的分量。** 这就是讲次 14–16 的投影理论的起点。

计算步骤与手算演示

求四个子空间的**基**是考试核心技能。先给出通用流程：

子空间	怎么求基	维数
C(Aᵀ) 行空间	对 A 做消元得 RREF，**非零行**就是一组基	r
N(A) 零空间	解 RREF 对应的 $Ax=0$：主元变量用自由变量表示，每个自由变量给一个基向量	$n-r$
C(A) 列空间	找出 RREF 的**主元列号**，取**原矩阵 A 中对应的那些列**	r
N(Aᵀ) 左零空间	对 A^{T} 做同一套操作，或对 $[A \mid I]$ 型消元记录消元矩阵	$m-r$

警告（第一大坑）：C(A) 的基必须取自**原矩阵 A 的列**，不能取 RREF 的列！行操作会改变列空间本身（虽然不改变它的维数）。

示例一：秩 1 的 3×3 矩阵，把四个子空间算穿

$$A_1=\begin{bmatrix}1&2&3\\2&4&6\\1&2&3\end{bmatrix}$$

步骤 1：消元求 RREF 与主元。

$r_2\leftarrow r_2-2r_1$，$r_3\leftarrow r_3-r_1$：

$$\begin{bmatrix}1&2&3\\0&0&0\\0&0&0\end{bmatrix}$$

已经是对角单位化的 RREF 了。主元在第 1 列，$r=1$。

步骤 2：行空间 C(A₁ᵀ)。 取 RREF 的非零行：基为 $(1,2,3)$，$\dim=1=r$ ✓

步骤 3：列空间 C(A₁)。 主元列号是 $\{1\}$，回原矩阵取第 1 列：基为 $(1,2,1)^{\mathsf{T}}$，$\dim=1=r$ ✓（第 2、3 列分别是它的 2 倍、3 倍。）

步骤 4：零空间 N(A₁)。 解 $x_1+2x_2+3x_3=0$。主元变量 x_1，自由变量 x_2,x_3。

- 令 $x_2=1,x_3=0$：$x_1=-2$，得 $\mathbf{v}_1=(-2,1,0)^{\mathsf{T}}$。
- 令 $x_2=0,x_3=1$：$x_1=-3$，得 $\mathbf{v}_2=(-3,0,1)^{\mathsf{T}}$。

$\dim N(A_1)=2=n-r$ ✓

步骤 5：左零空间 N(A₁ᵀ)。 A_1^{T} 是 3×3：$A_1^{\mathsf{T}}=\begin{bmatrix}1&2&1\\2&4&2\\3&6&3\end{bmatrix}$。它的行是 $(1,2,1),(2,4,2),(3,6,3)$，全部是 $(1,2,1)$ 的倍数。消元后 RREF 的非零行是 $(1,2,1)$，所以 $A_1^{\mathsf{T}}\mathbf{y}=\mathbf{0}$ 即 $y_1+2y_2+y_3=0$：

- $y_2=1,y_3=0\Rightarrow y_1=-2$：$\mathbf{w}_1=(-2,1,0)^{\mathsf{T}}$
- $y_2=0,y_3=1\Rightarrow y_1=-1$：$\mathbf{w}_2=(-1,0,1)^{\mathsf{T}}$

$\dim N(A_1^{\mathsf{T}})=2=m-r$ ✓

步骤 6：验证正交性（内积必须为 0）。

- C(A₁ᵀ) ⊥ N(A₁)：$(1,2,3)\cdot(-2,1,0)=-2+2+0=0$ ✓；$(1,2,3)\cdot(-3,0,1)=-3+0+3=0$ ✓
- C(A₁) ⊥ N(A₁ᵀ)：$(1,2,1)\cdot(-2,1,0)=-2+2+0=0$ ✓；$(1,2,1)\cdot(-1,0,1)=-1+0+1=0$ ✓

步骤 7：验证维数配平。 $1+2=3=n$（左边方块），$1+2=3=m$（右边方块）。

【计算机制解说】为什么"取原矩阵的主元列"能得到 C(A) 的基？ 关键洞察是：**行操作会改变列空间，但保持列与列之间的线性关系不变。** 理由：行操作等价于左乘一个可逆矩阵 E，即 $A\to EA$。设 $\sum c_j\,\mathrm{col}_j(A)=\mathbf{0}$，两边左乘 E 得 $\sum c_j\,\mathrm{col}_j(EA)=\mathbf{0}$；反过来 E 可逆也一样成立。所以"哪些列线性相关、以什么系数相关"这个**信息**在消元中完好无损。

于是：在 RREF 里，主元列显然是线性无关的（它们是带单位主元的标准列），非主元列则显式写成主元列的线性组合（RREF 里那一列的数字就是系数）。因为这个关系被消元保持了，回到 A 里，**同样位置的列**也满足同样的关系：主元列线性无关，且每一非主元列都是它们的组合。因此主元列构成 C(A) 的一组基。

反过来说，**RREF 的列本身不能做 C(A) 的基**——RREF 的列空间和 A 的列空间通常是**不同的**子空间。本例 A_1 的列空间是 $\mathbf{span}\{(1,2,1)\}$，而 RREF 的列空间是 $\mathbf{span}\{(1,0,0)\}$——方向完全不同，只是维数相同（都是 1）。这解释了为什么两个子空间的维数相等而子空间本身不等。

【计算机制解说】为什么每消掉一个自由变量就多一个零空间基向量？ $Ax=0$ 是 m 个方程约束 n 个未知量。消元把方程化简成 r 个真正独立的约束（就是 RREF 的非零行，每个约束"钉住"一个主元变量）。剩下的 $n-r$ 个变量没人管，可以自由取值——**每让一个自由变量取 1、其余自由变量取**

0，**主元变量就被唯一确定**，于是得到 $n-r$ 个线性无关的特解，它们张成整个解空间。

这也顺手解释了"解的自由度"：$A\mathbf{x}=\mathbf{b}$ 有解时，解集是 $\mathbf{x}_{\text{particular}}+N(A)$，由 $n-r$ 个自由参数控制，这正是 N(A) 的维数。

示例二：3×4 秩 2 矩阵 —— 四子空间 + A = CR + 相容性条件

这个例子比示例一"信息量"大，四个维数 $2,2,2,1$ 各不相同，最能检验理解。

$$A_2=\begin{bmatrix}1&2&3&1\\1&1&2&1\\1&2&3&1\end{bmatrix}\qquad(m=3,\ n=4)$$

步骤 1：消元求 RREF。

$r_2\leftarrow r_2-r_1$，$r_3\leftarrow r_3-r_1$：

$$\begin{bmatrix}1&2&3&1\\0&-1&-1&0\\0&0&0&0\end{bmatrix}$$

再把第 2 行乘 -1：$\begin{bmatrix}1&2&3&1\\0&1&1&0\\0&0&0&0\end{bmatrix}$；然后 $r_1\leftarrow r_1-2r_2$：

$$\mathbf{RREF}(A_2)=\begin{bmatrix}1&0&1&1\\0&1&1&0\\0&0&0&0\end{bmatrix}$$

主元在第 1、2 列，$r=2$。

步骤 2：行空间 C(A₂ᵀ)。 非零行 $(1,0,1,1)$、$(0,1,1,0)$，$\dim=2=r$ ✓（住在 $\mathbb{R}^4$。）

步骤 3：列空间 C(A₂)。 主元列号 $\{1,2\}$，回原矩阵取第 1、2 列：$(1,1,1)^{\mathsf T}$ 与 $(2,1,2)^{\mathsf T}$，$\dim=2=r$ ✓（住在 $\mathbb{R}^3$。）

步骤 4：零空间 N(A₂)。 RREF 给出 $x_1+x_3+x_4=0$，$x_2+x_3=0$。自由变量 x_3,x_4：

- $x_3=1,x_4=0\Rightarrow x_2=-1,\ x_1=-1$：$\mathbf{v}_1=(-1,-1,1,0)^{\mathsf T}$
- $x_3=0,x_4=1\Rightarrow x_2=0,\ x_1=-1$：$\mathbf{v}_2=(-1,0,0,1)^{\mathsf T}$

$\dim N(A_2)=2=n-r=4-2$ ✓（住在 $\mathbb{R}^4$，和行空间同屋。）

步骤 5：左零空间 N(A₂ᵀ)。 直接观察 A_2 的行：$\mathbf{row}_3=\mathbf{row}_1$，所以 $(1,0,-1)$ 是行（第 3 行减第 1 行）的一个零组合；而第 2 行与第 1 行不成比例，没有别的独立关系。所以

$$N(A_2^{\mathsf T})=\mathbf{span}\{(1,0,-1)^{\mathsf T}\},\qquad \dim=1=m-r=3-2\ \checkmark$$

（住在 $\mathbb{R}^3$，和列空间同屋。）

步骤 6：验算正交性。

- C(A₂ᵀ) ⊥ N(A₂)：
- $(1,0,1,1)\cdot(-1,-1,1,0)=-1+0+1+0=0$ ✓
- $(1,0,1,1)\cdot(-1,0,0,1)=-1+0+0+1=0$ ✓
- $(0,1,1,0)\cdot(-1,-1,1,0)=0-1+1+0=0$ ✓
- $(0,1,1,0)\cdot(-1,0,0,1)=0+0+0+0=0$ ✓
- C(A₂) ⊥ N(A₂ᵀ)：
- $(1,1,1)\cdot(1,0,-1)=1+0-1=0$ ✓
- $(2,1,2)\cdot(1,0,-1)=2+0-2=0$ ✓

步骤 7：用左零空间判断 $A_2\mathbf{x}=\mathbf{b}$ 何时有解。 相容性条件是 $\mathbf{y}^{\mathsf T}\mathbf{b}=0$，即 $b_1-b_3=0$，也就是 $b_1=b_3$。检验：

- $\mathbf{b}=(1,0,1)^{\mathsf T}$：$1-1=0$ ✓ 有解。事实上 $\mathbf{x}=(-1,1,0,0)^{\mathsf T}$ 就是一解。

步骤 8：用 A = CR 复核。

$$C=\begin{bmatrix}1&2\\1&1\\1&2\end{bmatrix}\ (\text{主元列}),\qquad R=\begin{bmatrix}1&0&1&1\\0&1&1&0\end{bmatrix}\ (\mathbf{RREF}\ \text{非零行})$$

$$CR = \begin{bmatrix}1 & 2\\ 1 & 1\\ 1 & 2\end{bmatrix}\begin{bmatrix}1 & 0 & 1 & 1\\ 0 & 1 & 1 & 0\end{bmatrix} = \begin{bmatrix}1 & 2 & 3 & 1\\ 1 & 1 & 2 & 1\\ 1 & 2 & 3 & 1\end{bmatrix} = A_2 \checkmark$$

（逐格验算第一行为例：$1\cdot1+2\cdot0=1$，$1\cdot0+2\cdot1=2$，$1\cdot1+2\cdot1=3$，$1\cdot1+2\cdot0=1$。）

【计算机制解说】为什么 $A=CR$ 一定成立？ RREF 的每一列都可以写成"对主元列的系数组合"：RREF 的第 j 列是一个 r 维向量，它记录了"A 的第 j 列 = 主元列按这些系数组合"。把 RREF 里那 r 个非零行记作 R，则 R 的第 j 列正是这组系数。于是

$$A\,\mathbf{e}_j = \mathrm{col}_j(A) = \sum_{i=1}^{r} C\,\mathbf{e}_i \cdot R_{ij} = (CR)\,\mathbf{e}_j.$$

对每个 $j=1,\dots,n$ 都成立，所以 $A=CR$。**换句话说，R 就是"C(A) 的坐标说明书"：它把 A 的每一列翻译成主元列的坐标。** 注意非主元列会被自动还原——这是消元保关系（步骤 1 的洞察）的另一面。

$A=CR$ 还告诉我们一件重要的事：**A 的每一列都是 C 的列的线性组合，且系数存在 R 里。** 所以 C(A)=C(C)，行空间 = C(R)。

示例三：3×3 秩 2 —— 只做左零空间与"解的通式"

取

$$A_3 = \begin{bmatrix}1 & 2 & 1\\ 2 & 4 & 3\\ 3 & 6 & 5\end{bmatrix}.$$

消元：$r_2 \leftarrow r_2 - 2r_1$，$r_3 \leftarrow r_3 - 3r_1$：

$$\begin{bmatrix}1 & 2 & 1\\ 0 & 0 & 1\\ 0 & 0 & 2\end{bmatrix} \xrightarrow{r_3\leftarrow r_3-2r_2} \begin{bmatrix}1 & 2 & 1\\ 0 & 0 & 1\\ 0 & 0 & 0\end{bmatrix} \xrightarrow{r_1\leftarrow r_1-r_2} \begin{bmatrix}1 & 2 & 0\\ 0 & 0 & 1\\ 0 & 0 & 0\end{bmatrix} = \mathrm{RREF}$$

主元在第 1、3 列，$r=2$。于是：

- 行空间：$\mathbf{span}\{(1,2,0),(0,0,1)\}$，$\dim=2$。
- 列空间：原矩阵第 1、3 列，$\mathbf{span}\{(1,2,3)^{\mathsf{T}},(1,3,5)^{\mathsf{T}}\}$，$\dim=2$。
- 零空间：自由变量 x_2，$x_2=1\Rightarrow x_1=-2, x_3=0$，基 $(-2,1,0)^{\mathsf{T}}$，$\dim=1=n-r$。
- 左零空间：$A_3^{\mathsf{T}}\mathbf{y}=\mathbf{0}$ 即 $\begin{bmatrix}1 & 2 & 3\\ 2 & 4 & 6\\ 1 & 3 & 5\end{bmatrix}\mathbf{y}=\mathbf{0}$，解得 $\mathbf{y}=(1,-2,1)^{\mathsf{T}}$（验算：$1-4+3=0$，$2-8+6=0$，$1-6+5=0$ ✓），$\dim=1=m-r$。
- 正交验证：$(1,2,0)\cdot(-2,1,0)=-2+2=0$ ✓；$(0,0,1)\cdot(-2,1,0)=0$ ✓；$(1,2,3)\cdot(1,-2,1)=1-4+3=0$ ✓；$(1,3,5)\cdot(1,-2,1)=1-6+5=0$ ✓。

解的通式：对 $\mathbf{b}\in C(A_3)$，$\mathbf{x}=\mathbf{x}_p+t\,(-2,1,0)^{\mathsf{T}}$。这条直线就是"一个特解 + 整个零空间"，几何上是一条**不过原点**的直线。

示例四：2×2 矩阵的四种"秩情形"全家族（边界情形必须掌握）

小矩阵最容易暴露理解漏洞。下面把 2×2 的所有秩情形排成一张表，因为 $m=n=2$ 时四个维数是 $(r,r,2-r,2-r)$，只有三种可能。

情形 A：$r=2$（可逆），取 $A=\begin{bmatrix}1 & 2\\ 3 & 4\end{bmatrix}$。

消元：$r_2\leftarrow r_2-3r_1$ 得 $\begin{bmatrix}1 & 2\\ 0 & -2\end{bmatrix}$，两列都有主元，$r=2$。于是：

- C(A) = $\mathbb{R}^2$（两列 $(1,3),(2,4)$ 独立，张开整个平面），$\dim=2$。
- C(A^{T}) = $\mathbb{R}^2$，$\dim=2$。
- N(A) = $\{\mathbf{0}\}$，$\dim=0=2-r$。因为 A 可逆，唯一解是 $\mathbf{x}=\mathbf{0}$。
- N(A^{T}) = $\{\mathbf{0}\}$，$\dim=0$。
- 配平：$2+0=2=n$ ✓，$2+0=2=m$ ✓。
- **几何**：A 把整个平面一对一映射到整个平面，什么都不压扁。$A\mathbf{x}=\mathbf{b}$ 对每个 $\mathbf{b}$ 都有唯一解。

情形 B：$r=1$（奇异但非零），取 $A=\begin{bmatrix}1 & 2\\ 2 & 4\end{bmatrix}$。

第二列是第一列的 2 倍，$r=1$。RREF 为 $\begin{bmatrix}1 & 2\\ 0 & 0\end{bmatrix}$。于是：

- C(A) = $\mathbf{span}\{(1,2)^{\mathsf{T}}\}$——$\mathbb{R}^2$ 中过原点的一条直线，$\dim = 1$。A 把整个平面压到这条线上。
- C(A$^{\mathsf{T}}$) = $\mathbf{span}\{(1,2)\}$（行空间也是一条直线，只是住在"输入平面"里），$\dim = 1$。
- N(A)：解 $x_1 + 2x_2 = 0$，即 $x_1 = -2x_2$，基 $(-2,1)^{\mathsf{T}}$，$\dim = 1 = n - r$。
- N(A$^{\mathsf{T}}$)：解 $y_1 + 2y_2 = 0$，基 $(-2,1)^{\mathsf{T}}$，$\dim = 1 = m - r$。
- 验证正交：$(1,2)\cdot(-2,1) = -2 + 2 = 0$ ✓（两处都对）
- **几何**：A 把平面压成一条线（核是一条线），同时把另一条线（零空间方向）压成原点。二维进、一维出——**必然有一维信息被丢失**，被丢的那一维正是零空间。
- **可解性**：只有 $\mathbf{b} = t(1,2)^{\mathsf{T}}$ 有解；例如 $\mathbf{b} = (1,2)$ 有解（$\mathbf{x} = (1,0)$），$\mathbf{b} = (1,0)$ 无解。

情形 C：$r = 0$，取 $A = \begin{bmatrix} 0 & 0 \\ 0 & 0 \end{bmatrix}$（零矩阵）。

- C(A) = $\{\mathbf{0}\}$，$\dim = 0$；C(A$^{\mathsf{T}}$) = $\{\mathbf{0}\}$，$\dim = 0$。
- N(A) = $\mathbb{R}^2$（每个向量都被压成零），$\dim = 2$；N(A$^{\mathsf{T}}$) = $\mathbb{R}^2$，$\dim = 2$。
- 配平：$0 + 2 = 2 = n$ ✓，$0 + 2 = 2 = m$ ✓。
- **几何**：A 把一切压成原点。"列空间是零维"并不矛盾——零子空间 $\{\mathbf{0}\}$ 本身是每个空间中唯一 0 维的子空间，它是所有子空间里最小的那个。

情形 D：$r = 1$ 的"坐标投影"，取 $A = \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix}$（这是投影到 x 轴的矩阵）。

- C(A) = $\mathbf{span}\{(1,0)^{\mathsf{T}}\}$（$x$ 轴），$\dim = 1$。
- N(A)：解 $x_1 = 0$，即 $\mathbf{x} = (0, x_2)$，基 $(0,1)^{\mathsf{T}}$（y 轴），$\dim = 1$。
- C(A$^{\mathsf{T}}$) = $\mathbf{span}\{(1,0)\}$，N(A$^{\mathsf{T}}$) = $\mathbf{span}\{(0,1)\}$。
- **几何**：这是四个子空间"最直观"的例子——行空间是 x 轴、零空间是 y 轴，它们在平面里垂直并把平面切成两半；列空间是 x 轴、左零空间是 y 轴。**正交分解 $\mathbb{R}^2 =$ 行空间 $\oplus$ 零空间 在这里就是"x 轴 $\oplus$ y 轴 = 整个平面"，肉眼可见。**

```
2x2 情形汇总 (m = n = 2)

rank r | C(A)      C(A^T)    N(A)     N(A^T)   | r+(n-r)=n  r+(m-r)=m
-------+-------------------------------------+--------------------
   2   | R^2       R^2       {0}      {0}      | 2+0=2      2+0=2
   1   | 线        线        线       线       | 1+1=2      1+1=2
   0   | {0}       {0}       R^2      R^2      | 0+2=2      0+2=2

注意 r=1 时四个维数全为 1 —— 最容易记错的一行:
它是 (1, 1, 2-1, 2-1) = (1, 1, 1, 1).
```

【计算机制解说】为什么"秩 = 维数丢失量"？ 从变换的角度看：$A : \mathbb{R}^n \to \mathbb{R}^m$，输入有 n 个自由度。经过 A 之后：

- 有 $n - r$ 个方向被压成零（零空间），即**损失 $n - r$ 维**；
- 剩下 r 个方向被**一对一**地映过去（这是四个子空间大图里"1-to-1"那半的说法）；
- 于是输出端的像有 r 维，即 $\dim C(A) = r$。

这就是线性代数里的"秩–零化度定理"（rank–nullity theorem）：

$$\underbrace{\dim C(A)}_{r} + \underbrace{\dim N(A)}_{n-r} = \dim(\text{输入空间}) = n.$$

记住它是关于输入空间 $\mathbb{R}^n$ 的守恒律，而不是关于输出的。类似地，对转置矩阵 $A^{\mathsf{T}} : \mathbb{R}^m \to \mathbb{R}^n$ 用同一个定理，得到 $r + (m - r) = m$——这就是右边方块那半的来历。

矩阵分解的核心思想

本讲的核心分解是

$$\boxed{A = CR}$$

- **形式**：C 是 $m \times r$（A 的主元列），R 是 $r \times n$（$\mathbf{RREF}(A)$ 的非零行）。
- **含义**：这是"A **的秩是** r"这句话最经济、最无冗余的表达。A 一般有 mn 个数字，但它其实只由 C 和 R 决定，即 $mr + rn$ 个数字。$A = CR$ 是 A 的"瘦身版"。
- **揭示的结构性质**：
- C(A) = C(C)（列空间只由 C 决定），C(A$^{\mathsf{T}}$) = C(R)（行空间只由 R 决定）。**四个子空间全部由 C, R 承载**。

- 它是 $A=\sum_{i=1}^{r}(\text{col})\,(\text{row})$ 的矩阵化写法：把 C 按列拆、R 按行拆，

$$A=\sum_{i=1}^{r}\mathbf{c}_i\,\mathbf{r}_i^{\mathsf{T}},$$

```
右边每一项都是**秩 1 矩阵**。于是 $A=CR$ 说的就是"**秩 $r$ 的矩阵 = $r$ 个秩 1 矩阵之和**"。这正是下一讲（Lecture 11）与 SVD（Lecture 29）的
```

- **应用价值**：$A=CR$ 是"压缩存储"的原型（只存 $mr+rn$ 而非 mn），也是理解 $A^{\mathsf{T}}A$、伪逆、SVD 的第一块基石。SVD 做的事情就是：在 $A=CR$ 的基础上，**把 C 与 R 换成互相正交的 U 与 V^{T}**，并让系数变成按重要性排序的奇异值 σ_i。

本讲与其他分解的关系可以画成一条线索：

```
A = LU              A = CR              A = U S V^T
(消元, L5–6)   ->   (秩 r 的骨架, L10)  ->  (正交骨架, L29)
记录行操作           记录"哪些列独立"        两个骨架都换成正交基
```

此外，本讲的四个子空间正是 **Fredholm 二择一**（Fredholm alternative）的内容：对任意 $\mathbf{b}$，要么 $A\mathbf{x}=\mathbf{b}$ 有解（$\mathbf{b}\in C(A)$），要么存在 $\mathbf{y}\in N(A^{\mathsf{T}})$ 使 $\mathbf{y}^{\mathsf{T}}\mathbf{b}\neq 0$ 从而无解——**二者必居其一，不可能同时成立，也不可能同时不成立**。这正是"$\mathbb{R}^m=C(A)\oplus N(A^{\mathsf{T}})$"的直接推论。

与其他讲次的关联

- **与 Lecture 8–9（子空间定义、列空间与零空间初见）**：本讲把零散的"某个子空间"升级为**四个子空间的完整系统**，并补上维数定理。
- **与 Lecture 5–6（$A=LU$）**：消元既给出 $A=LU$（保留行操作），也给出本讲的 $A=CR$（保留列信息）与四个子空间的基。消元是这两条线的共同源头。
- **与 Lecture 11（矩阵空间 / $A=CR$ / 小世界图）**：$A=CR$ 的"r 个秩 1 矩阵之和"将在下一讲展开；图的关联矩阵则给出一类非常具体的四子空间实例。
- **与 Lecture 12（图与网络）**：图的**关联矩阵** B 的零空间就是"环"（loops），左零空间就是"连通性"，本讲的维数定理在那里第一次被"读懂"。
- **与 Lecture 14–17（正交、投影、最小二乘、QR）**：正交关系 $C(A^{\mathsf{T}})\perp N(A)$ 立刻升级为投影公式 $P=A(A^{\mathsf{T}}A)^{-1}A^{\mathsf{T}}$，投影到 C(A) 上；当 $\mathbf{b}\notin C(A)$ 时就得到最小二乘。
- **与 Lecture 18–20（行列式）**：A 可逆 $\iff r=n=m\iff$ 四个子空间中 C(A)=$\mathbb{R}^m$、N(A)=$\{\mathbf{0}\}$、C(A^{T})=$\mathbb{R}^n$、N(A^{T})=$\{\mathbf{0}\}\iff \det A\neq 0$。
- **与 Lecture 29（SVD）**：$A=CR$ 与四个子空间是 SVD 的"预告片"：SVD 给出 C(A) 与 C(A^{T}) 的**正交基**，并要求 $\dim C(A)=\dim C(A^{\mathsf{T}})=r$——正是本讲的维数定理。
- **与 Lecture 30–33（线性变换、伪逆）**：四个子空间为"无坐标视角"提供了坐标分解 $\mathbb{R}^n=C(A^{\mathsf{T}})\oplus N(A)$，左逆/右逆/伪逆 A^{+} 的存在性完全由四个维数决定。

关键要点

1. **维数定理（必背）**：对 $m\times n$、秩 r 的 A，

$$\dim C(A)=r,\quad \dim C(A^{\mathsf{T}})=r,\quad \dim N(A)=n-r,\quad \dim N(A^{\mathsf{T}})=m-r.$$

配平式：$r+(n-r)=n$，$r+(m-r)=m$。**行秩 = 列秩 = r**，消元后 U（或 RREF）的非零行数一刀切给出。

1. **正交关系（必背）**：

$$N(A)=C(A^{\mathsf{T}})^{\perp}\subset\mathbb{R}^n,\qquad N(A^{\mathsf{T}})=C(A)^{\perp}\subset\mathbb{R}^m.$$

即 $\mathbb{R}^n=C(A^{\mathsf{T}})\oplus N(A)$，$\mathbb{R}^m=C(A)\oplus N(A^{\mathsf{T}})$。证明一句话：$A\mathbf{x}=\mathbf{0}\iff\mathbf{x}$ 与 A 的**每一行**内积为 0 $\iff\mathbf{x}\perp C(A^{\mathsf{T}})$。

1. **求基的正确姿势**：行空间用 **RREF 的非零行**；零空间用 **RREF 解方程**；列空间用**原矩阵的主元列**（不是 RREF 的列！）；左零空间对 A^{T} 重复行/零空间两步。
2. **$A\mathbf{x}=\mathbf{b}$ 的统一解释**：**存在性看 C(A)**（$\mathbf{b}\in C(A)$，等价于对所有 $\mathbf{y}\in N(A^{\mathsf{T}})$ 有 $\mathbf{y}^{\mathsf{T}}\mathbf{b}=0$）；**自由度看 N(A)**（解集 $=\mathbf{x}_p+N(A)$，有 $n-r$ 个自由参数，$r=n$ 时唯一）。
3. $A=CR$：C = 主元列（$m\times r$），R = RREF 非零行（$r\times n$），$A=CR$ 严格成立，且 $A=\sum_{i=1}^{r}\mathbf{c}_i\mathbf{r}_i^{\mathsf{T}}$ 是"r 个秩 1 矩阵之和"。

常见误区与注意事项

1. **把行空间放进 $\mathbb{R}^m$**。行空间 C(A^{T}) 与零空间 N(A) 都住在 $\mathbb{R}^n$（输入空间）；列空间 C(A) 与左零空间 N(A^{T}) 都住在 $\mathbb{R}^m$（输出空间）。口诀：**"行和零同住 $\mathbb{R}^n$，列和左零同住 $\mathbb{R}^m$。"**

2. **拿 RREF 的列当 C(A) 的基**。行操作不保持列空间，只保持"列之间的线性关系"。A_1 的列空间是 $\mathbf{span}\{(1,2,1)\}$，RREF 的列空间是 $\mathbf{span}\{(1,0,0)\}$，二者不同。**必须回到原矩阵取主元列。**
3. **把 $n-r$ 和 $m-r$ 搞反**。记住零空间维数由**列数**决定：N(A) 里的向量长度是 n；左零空间维数由**行数**决定：N(A^T) 里的向量长度是 m。检验法：算出的基向量长度必须与所属空间维数一致。
4. **以为"零空间维数 = 矩阵的秩的补"是 $m-r$**。例如 A_2（3×4，$r=2$）中 $\dim N(A_2)=4-2=2$（不是 $3-2=1$），而 $\dim N(A_2^T)=3-2=1$。用 $r+(n-r)=n$ 自检。
5. **误以为四个子空间维数相同或都非零**。$r=0$（零矩阵）时四个子空间是：$C(A)=\{0\}$、$C(A^T)=\{0\}$、$N(A)=\mathbb{R}^n$、$N(A^T)=\mathbb{R}^m$。$r=n=m$（可逆）时两个零空间都只有 $\{0\}$，而两个空间是满的。**"空"与"满"都是合法情形。**
6. **忘记"正交"是双向的**。$C(A^T)\perp N(A)$ 对**每一个**行向量与**每一个**零空间向量都成立，不是"存在某对垂直"。写作内积时必须逐个检验（就像示例一、二那样），不能只验一对。

思考题（带答案）

Q1.（纯计算） 设 A 是一个 5×7 矩阵，已知 $\mathbf{rank}(A)=3$。求四个基本子空间的维数，并说出每个子空间的向量有几个分量。若 $\mathbf{b}\in\mathbb{R}^5$ 使 $A\mathbf{x}=\mathbf{b}$ 有解，解集有多少个自由参数?

> ▸ **答案**
>
> $m=5$，$n=7$，$r=3$。
>
> - $\dim C(A)=r=3$：A 的列是 $\mathbb{R}^5$ 中的 7 个向量，能张成 3 维子空间；基向量有 **5 个分量**（每个都是 A 的一列）。
> - $\dim C(A^T)=r=3$：行空间；基向量有 **7 个分量**（每个都是 A 的一行）。
> - $\dim N(A)=n-r=7-3=4$：零空间；解向量有 **7 个分量**。
> - $\dim N(A^T)=m-r=5-3=2$：左零空间；向量有 **5 个分量**。
>
> 配平检验：$3+4=7=n$ ✓，$3+2=5=m$ ✓。
>
> 解集：$\mathbf{x}=\mathbf{x}_p+N(A)$，自由度 $=\dim N(A)=4$。即通解有 4 个自由参数。

Q2.（概念） 下面的说法对不对？逐条判断并说明理由。(a) 若 A 是 4×6 矩阵且 $A\mathbf{x}=\mathbf{b}$ 对每个 $\mathbf{b}\in\mathbb{R}^4$ 都有解，则 $\dim N(A)=2$。(b) 行空间与零空间可以"拼"满整个 $\mathbb{R}^n$，但它们有公共非零向量。(c) 若 $\mathbf{y}\in N(A^T)$，则 $\mathbf{y}$ 与 A 的每一列都正交。

> ▸ **答案**
>
> (a) **对**。$A\mathbf{x}=\mathbf{b}$ 对一切 $\mathbf{b}\in\mathbb{R}^4$ 有解 $\iff C(A)=\mathbb{R}^4 \iff r=m=4$。于是 $\dim N(A)=n-r=6-4=2$。
>
> (b) **错在后半句**。前半句对：$\mathbb{R}^n=C(A^T)\oplus N(A)$，两半确实拼满。但"$\oplus$"（直和）表示 $C(A^T)\cap N(A)=\{0\}$——两个子空间**只有零向量是公共的**，不存在公共非零向量。（理由：若 $\mathbf{v}$ 同时在两者中，则 $\mathbf{v}\perp\mathbf{v}$，故 $\mathbf{v}^T\mathbf{v}=\|\mathbf{v}\|^2=0$，得 $\mathbf{v}=\mathbf{0}$。）
>
> (c) **对**。$\mathbf{y}^TA=\mathbf{0}^T$ 拆开就是"$\mathbf{y}$ 与 A 的每一列的内积都是 0"，即 $\mathbf{y}\perp C(A)$。这正是 $N(A^T)=C(A)^\perp$ 的定义式。

Q3.（综合计算） 设 $\mathbf{u}=(2,1,2)^T$，$\mathbf{v}=(1,3)^T$，$A=\mathbf{u}\mathbf{v}^T$（3×2）。写出 A，求四个子空间的基与维数，并验证正交性；再回答：对哪些 $\mathbf{b}\in\mathbb{R}^3$ 有解?

> ▸ **答案**

$$A=\mathbf{u}\mathbf{v}^T=\begin{bmatrix}2\\1\\2\end{bmatrix}\begin{bmatrix}1 & 3\end{bmatrix}=\begin{bmatrix}2 & 6\\1 & 3\\2 & 6\end{bmatrix}.$$

> 消元（$r_2 - \frac{1}{2}r_1$，$r_3 - r_1$）后 RREF $= \begin{bmatrix}1 & 3\\ 0 & 0\\ 0 & 0\end{bmatrix}$，主元在第 1 列，$r = 1$。
>
> - C(A)：主元列取自 A，即 $\mathbf{span}\{(2,1,2)^{\mathsf{T}}\}$，$\dim = 1 = r$。注意这正是 $\mathbf{u}$——$\mathbf{uv}^{\mathsf{T}}$ **的列空间就是 $\mathbf{u}$ 张成的直线**。
> - C(A$^{\mathsf{T}}$)：RREF 非零行 $(1,3)$，$\mathbf{span}\{(1,3)\}$，$\dim = 1 = r$。这正是 $\mathbf{v}^{\mathsf{T}}$——**行空间就是 $\mathbf{v}$ 张成的直线**。
> - N(A)：$x_1 + 3x_2 = 0$，自由变量 x_2；$x_2 = 1 \Rightarrow x_1 = -3$。基 $(-3,1)^{\mathsf{T}}$，$\dim = 1 = n - r = 2 - 1$。
> - N(A$^{\mathsf{T}}$)：解 $2y_1 + y_2 + 2y_3 = 0$。取 $(1,-2,0)^{\mathsf{T}}$（$2 - 2 + 0 = 0$ ✓）与 $(1,0,-1)^{\mathsf{T}}$（$2 + 0 - 2 = 0$ ✓），$\dim = 2 = m - r = 3 - 1$。
>
> 正交验证：– $(1,3)\cdot(-3,1) = -3 + 3 = 0$ ✓ – $(2,1,2)\cdot(1,-2,0) = 2 - 2 + 0 = 0$ ✓；$(2,1,2)\cdot(1,0,-1) = 2 + 0 - 2 = 0$ ✓
>
> 有解的 $\mathbf{b}$：$\mathbf{b} \in C(A) = \mathbf{span}\{(2,1,2)\}$，即 $\mathbf{b} = t(2,1,2)$。等价地（用左零空间）要求 $\mathbf{b} \perp N(A^{\mathsf{T}})$：$b_1 - 2b_2 = 0$ 且 $b_1 - b_3 = 0$，即 $b_2 = b_1/2$、$b_3 = b_1$——与 $\mathbf{b} = t(2,1,2)$ 一致 ✓

Lecture 11: Matrix Spaces; Rank 1; Small World Graphs

概述

上一讲的四个子空间全部住在 $\mathbb{R}^n$ 或 $\mathbb{R}^m$ 里——它们是**向量**的集合。本讲要做一个关键的跳跃：**把矩阵本身看作向量**。所有 $\mathbf{3\times 3}$ 矩阵构成一个 9 维向量空间 M，而对称矩阵、上三角矩阵、对角矩阵都是它漂亮的子空间。有了这个视角，"矩阵的空间"和"向量的空间"就是同一套理论，于是上一讲的维数公式（尤其是 $\dim(S+U) = \dim S + \dim U - \dim(S \cap U)$）可以直接搬过来用。

本讲的第二条线是**秩 1 矩阵** $A = \mathbf{uv}^{\mathsf{T}}$：它是最简单的矩阵，也是理解一切矩阵的"原子"。任何秩 r 矩阵都能写成 r 个秩 1 矩阵之和，这正是 $A = CR$ 分解的含义，也直接预告了讲次 29 的 SVD。

第三条线是**小世界图**：如何把一个网络写成一个矩阵。邻接矩阵 A 和关联矩阵 B 让图的连通性、环、路径计数全部变成线性代数问题——"六度分隔"于是成了一个关于 A^k 的陈述。这是四个子空间最具体、最有趣的应用现场。

核心概念的几何直觉

概念一：矩阵空间 M（the vector space of matrices）

- **定义与目的**：固定尺寸 $m \times n$，把**所有**这样的实矩阵收进一个集合 M，定义加法（逐元素相加）与数乘（逐元素缩放）。M 满足向量空间的全部八条公理，所以它是一个**向量空间**。目的：让"矩阵"这个对象也能享受子空间、基、维数、线性无关这一整套语言。
- **几何直觉（它在空间中是什么样子？）**：M 就是 $\mathbb{R}^{mn}$ 穿了件"方阵外衣"。$\mathbf{3\times 3}$ 矩阵有 9 个位置，每个位置可以自由填一个实数，而**填数这个动作是逐位置独立的**——所以 M 的"自由度"就是 $mn = 9$。事实上映射

$$\begin{bmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & & \vdots \\ a_{m1} & \cdots & a_{mn} \end{bmatrix} \longmapsto (a_{11}, a_{12}, \ldots, a_{mn}) \in \mathbb{R}^{mn}$$

是一个可逆的线性变换（叫"拉直"或 vectorization），它把矩阵空间**同构**成 $\mathbb{R}^{mn}$。所以维数不用猜：$\dim M = mn$。

- **具体示例**：一个 3×3 矩阵的标准基（Strang 常写在黑板上）就是 9 个"单点矩阵"：

$$\begin{bmatrix}1&0&0\\0&0&0\\0&0&0\end{bmatrix}, \begin{bmatrix}0&1&0\\0&0&0\\0&0&0\end{bmatrix}, \ldots, \begin{bmatrix}0&0&0\\0&0&0\\0&0&1\end{bmatrix}.$$

任意 3×3 矩阵都是这 9 个的线性组合，且组合系数唯一（系数就是它的 9 个元素）。因此这 9 个矩阵线性无关，$\dim M(3\times 3) = 9$。

概念二：矩阵空间的子空间 —— 对称、上三角、对角

- **定义与目的**：在 M 里挑出满足额外条件的矩阵，看它们是否仍然是子空间（对数乘与加法封闭）。三个经典选手：
- **对称矩阵** $S = \{A : A^{\mathsf{T}} = A\}$；
- **上三角矩阵** $U = \{A : a_{ij} = 0 \text{ 当 } i > j\}$；
- **对角矩阵** $D = \{A : a_{ij} = 0 \text{ 当 } i \neq j\}$。
- **几何直觉（它在空间中是什么样子？）**：这三个集合都是**线性约束**切出来的"平板"，因而都是子空间。注意"约束"的含义：
- S 的约束是 $a_{ij} = a_{ji}$：**等式型约束**（不是设为零！），它把上三角的 3 个位置"绑定"到下三角的 3 个位置。自由度 = 对角 3 + 上三角 3 = 6。
- U 的约束是下三角 3 个位置必须为 0。自由度 = 9 − 3 = 6。

- D 的约束是非对角 6 个位置必须为 0。自由度 = 3。 三者关系：$D = S \cap U$（既对称又上三角 ⇒ 非对角元素既相等又为零 ⇒ 只能是对角）。这是理解本讲维数公式的钥匙。
- **具体示例**：3×3 对称矩阵的 6 个基"积木"：

$$\begin{bmatrix}1&0&0\\0&0&0\\0&0&0\end{bmatrix},\begin{bmatrix}0&0&0\\0&1&0\\0&0&0\end{bmatrix},\begin{bmatrix}0&0&0\\0&0&0\\0&0&1\end{bmatrix},\begin{bmatrix}0&1&0\\1&0&0\\0&0&0\end{bmatrix},\begin{bmatrix}0&0&1\\0&0&0\\1&0&0\end{bmatrix},\begin{bmatrix}0&0&0\\0&0&1\\0&1&0\end{bmatrix}.$$

3 个对角"单点" + 3 个"对称配对"（每对同时点燃两个位置）。每个 3×3 对称矩阵都是这 6 个的唯一组合，所以 $\dim S = 6$。

维数公式（子空间版的容斥原理）：

$$\dim(S+U) = \dim S + \dim U - \dim(S \cap U).$$

其中 $S+U = \{s+u : s \in S,\ u \in U\}$（所有"对称阵 + 上三角阵"的集合，**它也是子空间**）。代入数字：

$$\dim(S+U) = 6+6-3 = 9 = \dim M \implies S+U = M.$$

也就是说，**任何 3×3 矩阵都能写成一个对称矩阵与一个上三角矩阵之和**。下面用代码块图示这个"分割"：

```
3x3 矩阵 M  (dim 9)
+-------------------+-------------------+
|  对称  S (dim 6)  |  <= 二者有重叠 =>  |
|                   |     不是直和!      |
|        +==============+               |
|        | 对角 D (dim 3)| <= S ∩ U = D   |
|        +==============+               |
|                   |  上三角 U (dim 6) |
+-------------------+-------------------+

dim(S) + dim(U) = 6 + 6 = 12
重叠部分 S ∩ U = D, dim = 3
dim(S + U) = 12 - 3 = 9 = dim M   =>  S + U = M

对比: 反对称 K (dim 3) 与 S 的交是 {0}, 6 + 3 = 9
      所以 M = S ⊕ K (直和), 交错和 = 没有重叠和
```

注意区分两种"和"：$S+U$ 是**有重叠**的和（重叠 3 维），必须减去重叠；而 $S \oplus K$（对称 + 反对称）是**直和**，交集只有零矩阵，维数直接相加 $6+3=9$。这个对比能让你明白维数公式里那个"$-\dim(S \cap U)$"什么时候等于 0。

概念三：秩 1 矩阵 $A = \mathbf{u}\mathbf{v}^{\mathsf{T}}$（rank one matrices）

- **定义与目的**：秩 1 矩阵就是**能写成一个列向量乘一个行向量**的矩阵：$A = \mathbf{u}\mathbf{v}^{\mathsf{T}}$，其中 $\mathbf{u} \in \mathbb{R}^m$, $\mathbf{v} \in \mathbb{R}^n$。它是矩阵世界的"原子"——最简单、信息量最小（但非零）的矩阵。
- **几何直觉（它在空间中是什么样子？）**：看它的行列结构：

$$A = \mathbf{u}\mathbf{v}^{\mathsf{T}} = \begin{bmatrix}u_1\\u_2\\\vdots\\u_m\end{bmatrix}\begin{bmatrix}v_1 & v_2 & \cdots & v_n\end{bmatrix} = \begin{bmatrix}u_1v_1 & u_1v_2 & \cdots & u_1v_n\\u_2v_1 & u_2v_2 & \cdots & u_2v_n\\\vdots & & & \vdots\\u_mv_1 & u_mv_2 & \cdots & u_mv_n\end{bmatrix}.$$

每一列都是 $\mathbf{u}$ 的倍数（第 j 列 $= v_j\mathbf{u}$），**每一行都是 $\mathbf{v}^{\mathsf{T}}$ 的倍数**（第 i 行 $= u_i\mathbf{v}^{\mathsf{T}}$）。所以： – C(A) 是一条**直线**（$\mathbf{span}\{\mathbf{u}\}$），维数 1； – C($A^{\mathsf{T}}$) 是一条**直线**（$\mathbf{span}\{\mathbf{v}\}$），维数 1； – A 把整个 $\mathbb{R}^n$ 压到 $\mathbf{u}$ 这条直线上，同时把"与 $\mathbf{v}$ 垂直的整个超平面"压成零。

这正是"秩 1"的几何肖像：**一个方向的输出，一个方向的盲区**。

- **具体示例**：$\mathbf{u} = (1,2,1)^{\mathsf{T}}$, $\mathbf{v} = (1,-1,2)^{\mathsf{T}}$：

$$A = \begin{bmatrix}1\\2\\1\end{bmatrix}\begin{bmatrix}1 & -1 & 2\end{bmatrix} = \begin{bmatrix}1&-1&2\\2&-2&4\\1&-1&2\end{bmatrix}.$$

三列分别是 $(1,2,1)$ 的 $1,-1,2$ 倍；三行分别是 $(1,-1,2)$ 的 $1,2,1$ 倍。秩当然是 1。

- **重要提醒**：**秩 1 矩阵的集合不是子空间！** 两个秩 1 矩阵相加可能变成秩 2，例如

$$\begin{bmatrix}1&2&0\\2&4&0\\1&2&0\end{bmatrix}+\begin{bmatrix}0&0&1\\0&0&2\\0&0&3\end{bmatrix}=\begin{bmatrix}1&2&1\\2&4&2\\1&2&3\end{bmatrix}$$

左边两个都是秩 1，右边（消元可验）秩为 2。因此"秩 1"不是线性条件，秩 1 矩阵全体只是 $\mathbb{R}^{mn}$ 中的一个 5 维曲面（3×3 情形：$\boldsymbol{u}$ 的 3 个参数 + $\boldsymbol{v}$ 的 3 个参数，减去 $(c\mathbf{u})(\frac{1}{c}\mathbf{v})$ 的 1 个缩放冗余），**不是子空间**。

概念四：把图变成矩阵 —— 邻接矩阵与关联矩阵

- **定义与目的**：一个**图**（graph）由节点集和边集组成。两种把它写成矩阵的标准做法：
- **邻接矩阵（adjacency matrix）** $\boldsymbol{A}$：$n\times n$，$a_{ij}=1$（或权重 w_{ij}）若节点 i,j 之间有边，否则 0。
- **关联矩阵（incidence matrix）** $\boldsymbol{B}$：$n\times m$（节点 × 边），每一列对应一条边，在它的两个端点处放 $+1$ 和 -1，其余为 0。 目的：让图论问题变成线性代数问题——连通性、环、路径计数、电流电压，全部有子空间的解释。
- **几何直觉（它在空间中是什么样子？）**：邻接矩阵把"谁挨着谁"编码进去，于是**矩阵与向量的乘积有了图论意义**：设 $\mathbf{x}$ 是节点上的数值（权重、温度、信号），则

$$(A\mathbf{x})_i=\sum_{j\sim i}w_{ij}x_j=\ \text{（与节点 } i \text{ 相连的邻居数值之和，按边权加权）}.$$

也就是说，$\boldsymbol{A}$ 是一个"**扩散 / 求和算子**"：它在图上把每个节点的值传播给邻居。图的**度数**（degree）就是 $\boldsymbol{A1}$ 的分量（取全 1 向量时，每个节点收到"有多少邻居"）。

- **具体示例**：5 个节点的小图（详见下一小节的 ASCII 图），其邻接矩阵 $\boldsymbol{A}$ 与 $\boldsymbol{A1}=(3,2,3,2,2)^{\mathsf{T}}$ 就是各节点的度数。
- **"六度分隔"与 A^k**：$(A^k)_{ij}$ = **从节点 i 到节点 j 恰好走 k 步的路径条数。** 直观理由：$A^2=A\cdot A$，$(A^2)_{ij}=\sum_t a_{it}a_{tj}$ 就是在数"通过某个中间节点 t 的两步走法"；归纳到 k 步就是标准的"动态规划"。所以"六度分隔"（six degrees of separation）就是一个关于最小 k 的陈述：**大多数真实网络里，任两点之间都存在一条长度不超过 6 的路径**，即 A^k 在 k 很小时就已经"处处非零"。本讲的 5 节点例子只有 **直径 2**（6 条边、5 个节点），是个微型的"小世界"。

计算步骤与手算演示

示例一：$A=CR$ 分解（手算 + 逐格验证）

取

$$A_8=\begin{bmatrix}1&2&1&3\\2&4&3&7\\0&0&1&1\end{bmatrix}\qquad(m=3,\ n=4).$$

步骤 1：消元求 RREF。$r_2\leftarrow r_2-2r_1$：

$$\begin{bmatrix}1&2&1&3\\0&0&1&1\\0&0&1&1\end{bmatrix}\xrightarrow{r_3\leftarrow r_3-r_2}\begin{bmatrix}1&2&1&3\\0&0&1&1\\0&0&0&0\end{bmatrix}\xrightarrow{r_1\leftarrow r_1-r_2}\begin{bmatrix}1&2&0&2\\0&0&1&1\\0&0&0&0\end{bmatrix}.$$

主元在第 1、3 列，$r=2$。

步骤 2：写出 C（主元列，取自原矩阵）。

$$C=\begin{bmatrix}1&1\\2&3\\0&1\end{bmatrix}\qquad(3\times 2).$$

步骤 3：写出 R（RREF 的非零行）。

$$R=\begin{bmatrix}1&2&0&2\\0&0&1&1\end{bmatrix}\qquad(2\times 4).$$

步骤 4：验证 $CR=A_8$，逐格算。

CR 的第 1 行（C 的第 1 行 $(1,1)$ 乘 R）：– $(1,1)\cdot(1,0)=1$ ✓（对应 $a_{11}=1$） – $(1,1)\cdot(2,0)=2$ ✓ – $(1,1)\cdot(0,1)=1$ ✓ – $(1,1)\cdot(2,1)=3$ ✓

第 2 行（C 第 2 行 $(2,3)$）：– $(2,3)\cdot(1,0)=2$ ✓ – $(2,3)\cdot(2,0)=4$ ✓ – $(2,3)\cdot(0,1)=3$ ✓ – $(2,3)\cdot(2,1)=7$ ✓

第 3 行（C 第 3 行 $(0,1)$）：– $(0,1)\cdot(1,0)=0$ ✓ – $(0,1)\cdot(2,0)=0$ ✓ – $(0,1)\cdot(0,1)=1$ ✓ – $(0,1)\cdot(2,1)=1$ ✓

所以

– – – –

$$CR = \begin{bmatrix}1 & 1\\ 2 & 3\\ 0 & 1\end{bmatrix}\begin{bmatrix}1 & 2 & 0 & 2\\ 0 & 0 & 1 & 1\end{bmatrix} = \begin{bmatrix}1 & 2 & 1 & 3\\ 2 & 4 & 3 & 7\\ 0 & 0 & 1 & 1\end{bmatrix} = A_8 \checkmark$$

步骤 5：拆成两个秩 1 矩阵（$A = \sum \mathbf{c}_i \mathbf{r}_i^{\mathsf{T}}$）。

- 第一项：第 1 主元列 × 第 1 个非零行

$$\mathbf{c}_1\mathbf{r}_1^{\mathsf{T}} = \begin{bmatrix}1\\ 2\\ 0\end{bmatrix}\begin{bmatrix}1 & 2 & 0 & 2\end{bmatrix} = \begin{bmatrix}1 & 2 & 0 & 2\\ 2 & 4 & 0 & 4\\ 0 & 0 & 0 & 0\end{bmatrix}$$

- 第二项：第 2 主元列 × 第 2 个非零行

$$\mathbf{c}_2\mathbf{r}_2^{\mathsf{T}} = \begin{bmatrix}1\\ 3\\ 1\end{bmatrix}\begin{bmatrix}0 & 0 & 1 & 1\end{bmatrix} = \begin{bmatrix}0 & 0 & 1 & 1\\ 0 & 0 & 3 & 3\\ 0 & 0 & 1 & 1\end{bmatrix}$$

逐格相加：

$$\begin{bmatrix}1 & 2 & 0 & 2\\ 2 & 4 & 0 & 4\\ 0 & 0 & 0 & 0\end{bmatrix} + \begin{bmatrix}0 & 0 & 1 & 1\\ 0 & 0 & 3 & 3\\ 0 & 0 & 1 & 1\end{bmatrix} = \begin{bmatrix}1 & 2 & 1 & 3\\ 2 & 4 & 3 & 7\\ 0 & 0 & 1 & 1\end{bmatrix} = A_8 \checkmark$$

（顺带核对：$r = 2$，恰好两项，不多不少。）

步骤 6：顺手取四个子空间。 $m = 3, n = 4, r = 2$，故

- C(A_8) = span$\{(1,2,0)^{\mathsf{T}}, (1,3,1)^{\mathsf{T}}\}$，$\dim 2$；
- C(A_8^{T}) = span$\{(1,2,0,2), (0,0,1,1)\}$，$\dim 2$；
- N(A_8)：RREF 给出 $x_1 + 2x_2 + 2x_4 = 0$、$x_3 + x_4 = 0$。自由变量 x_2, x_4：
- $x_2 = 1, x_4 = 0 \Rightarrow x_1 = -2, x_3 = 0$：$(-2,1,0,0)^{\mathsf{T}}$
- $x_2 = 0, x_4 = 1 \Rightarrow x_1 = -2, x_3 = -1$：$(-2,0,-1,1)^{\mathsf{T}}$

$\dim 2 = n - r$ ✓ – N(A_8^{T})：解 $y_1 + 2y_2 = 0$、$y_1 + 3y_2 + y_3 = 0$。取 $y_2 = 1 \Rightarrow y_1 = -2, y_3 = -1$，基 $(2,-1,1)^{\mathsf{T}}$（乘 -1），$\dim 1 = m - r$ ✓

正交验证：$(1,2,0,2)\cdot(-2,1,0,0) = -2+2+0+0 = 0$ ✓；$(1,2,0,2)\cdot(-2,0,-1,1) = -2+0+0+2 = 0$ ✓；$(0,0,1,1)\cdot(-2,1,0,0) = 0$ ✓；$(0,0,1,1)\cdot(-2,0,-1,1) = 0-1+1 = 0$ ✓；$(1,2,0)\cdot(2,-1,1) = 2-2+0 = 0$ ✓；$(1,3,1)\cdot(2,-1,1) = 2-3+1 = 0$ ✓

【计算机制解说】为什么 R 恰好是"A 的列的坐标说明书"？ 消元是**对行做可逆操作**，而可逆行操作不改变"列与列之间的线性关系"。于是 $\mathbf{RREF} = EA$（E 可逆）后，RREF 里每一列都是主元列（即标准基向量 $\mathbf{e}_1, \ldots, \mathbf{e}_r$）的显式组合：RREF 第 j 列的**那 r 个数字**就是系数。因为这些系数在消元中被保持，原矩阵 A 的第 j 列也以**同样的系数**组合主元列：

$$\mathrm{col}_j(A) = \sum_{i=1}^{r} R_{ij}\,\mathbf{c}_i.$$

这正是 $A = CR$（比较两边第 j 列：$C \cdot (R\text{第}j\text{列})$）。**所以 R 不是"另一个矩阵"，而是 A 的列在 C(A) 里的坐标表；C 则是 C(A) 的一组基。** 二者合起来就是"A 的秩 r 骨架"。

顺带一提：这个论证也解释了为什么 $A = CR$ 是**免费**的——你已经为了求秩做了消元，C 和 R 就在手边，零额外成本。

示例二：矩阵空间 $S + U = M$ 的显式构造（用具体矩阵验证维数公式）

维数公式是抽象的，我们用真矩阵把它"摸"一遍。取

$$A_9 = \begin{bmatrix}1 & 2 & 3\\ 4 & 5 & 6\\ 7 & 8 & 9\end{bmatrix}.$$

目标：把 A_9 写成一个**对称矩阵加一个上三角矩阵**。

步骤 1：构造对称部分 S——把下三角的元素对称地"搬"到上三角。

S 的对角取 0（后面交给 U），S 的上三角直接抄 A_9 的下三角：$s_{12} = 4,\ s_{13} = 7,\ s_{23} = 8$。

$$S = \begin{bmatrix} 0 & 4 & 7 \\ 4 & 0 & 8 \\ 7 & 8 & 0 \end{bmatrix} \quad (\text{对称：} S^{\mathsf{T}} = S \checkmark)$$

步骤 2：令 $U = A_9 - S$。

$$U = A_9 - S = \begin{bmatrix} 1 & -2 & -4 \\ 0 & 5 & -2 \\ 0 & 0 & 9 \end{bmatrix} \quad (\text{上三角：} u_{21} = u_{31} = u_{32} = 0 \checkmark)$$

步骤 3：验证 $S + U = A_9$。

$$\begin{bmatrix} 0 & 4 & 7 \\ 4 & 0 & 8 \\ 7 & 8 & 0 \end{bmatrix} + \begin{bmatrix} 1 & -2 & -4 \\ 0 & 5 & -2 \\ 0 & 0 & 9 \end{bmatrix} = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \\ 7 & 8 & 9 \end{bmatrix} = A_9 \checkmark$$

步骤 4：说明"为什么一定能做到"。 任取 A，按上面配方取 S（对角为零、上三角抄 A 的下三角、再镜像），则 $U = A - S$ 的上三角之外必然为零（因为 A 与 S 在下三角完全相同）。所以 $\{S + U\}$ 覆盖了所有矩阵，即 $S + U = M$，$\dim(S + U) = 9$。

步骤 5：核对维数公式。 $6 + 6 - 3 = 9$ ✓。

【计算机制解说】维数公式 $\dim(S+U) = \dim S + \dim U - \dim(S \cap U)$ 为什么成立？ 这是线性代数里的容斥原理，机制的直觉来自"数基向量"。

设 $S \cap U$ 的一组基为 $\mathbf{d}_1, \ldots, \mathbf{d}_k$（这里就是 3 个对角单点矩阵，$k = 3$）。把它扩充成 S 的基：$\mathbf{d}_1, \ldots, \mathbf{d}_k, \mathbf{s}_1, \ldots, \mathbf{s}_{6-k}$；也扩充成 U 的基：$\mathbf{d}_1, \ldots, \mathbf{d}_k, \mathbf{u}_1, \ldots, \mathbf{u}_{6-k}$。那么

$$\{\mathbf{d}_1, \ldots, \mathbf{d}_k,\ \mathbf{s}_1, \ldots, \mathbf{s}_{6-k},\ \mathbf{u}_1, \ldots, \mathbf{u}_{6-k}\}$$

张成 $S + U$（因为 $s + u$ 中"公共部分"已被 $\mathbf{d}$ 吸收），而且**线性无关**。线性无关的证明正是公式的核心：若

$$\sum a_i \mathbf{d}_i + \sum b_j \mathbf{s}_j + \sum c_\ell \mathbf{u}_\ell = \mathbf{0},$$

移项得 $\sum a_i \mathbf{d}_i + \sum b_j \mathbf{s}_j = -\sum c_\ell \mathbf{u}_\ell$：左边属于 S，右边属于 U，所以这个公共向量属于 $S \cap U$，可以用 $\mathbf{d}$ 表示；但 $\mathbf{u}$ 与 $\mathbf{d}$ 一起是 U 的基、线性无关，所以所有 $c_\ell = 0$；同理所有 $b_j = 0$，于是所有 $a_i = 0$。

于是总向量数 $= k + (6-k) + (6-k) = 6 + 6 - k = 12 - 3 = 9$，恰好是公式。**这个推导没有用到任何矩阵特殊性，它对任意两个子空间都成立**——这就是为什么它是"容斥"。

顺便：当 $S \cap U = \{\mathbf{0}\}$（$k = 0$）时公式退化为 $\dim(S + U) = \dim S + \dim U$，此时和是**直和** $S \oplus U$，$S \oplus K = M$（K 为反对称矩阵，$\dim K = 3$，$6 + 3 = 9$）就是这样一例。

示例三：小世界图 —— 邻接矩阵、关联矩阵与四个子空间

看 5 个节点、6 条边的图：

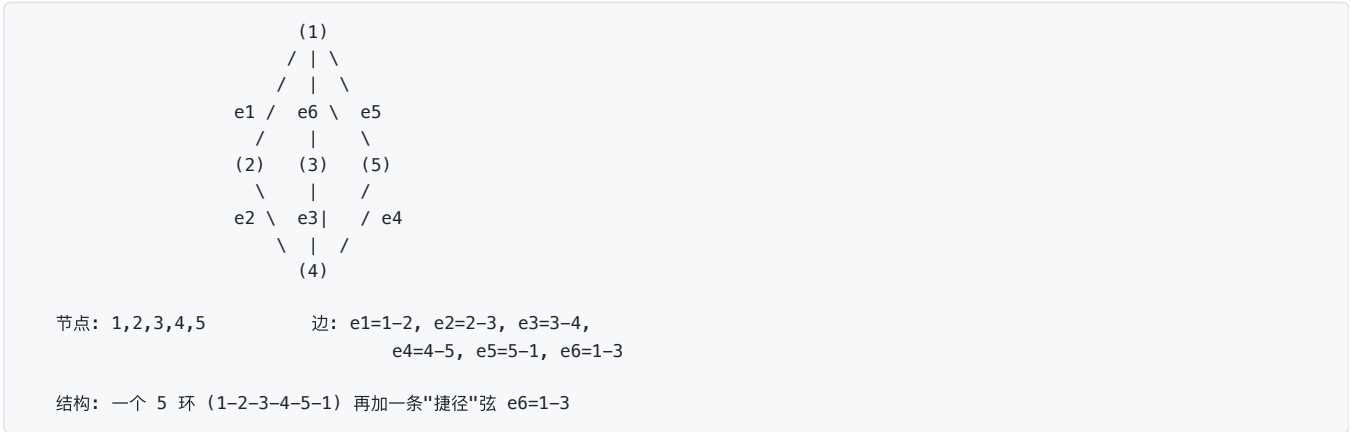

节点 1 连到 2、3、5；节点 3 连到 2、4、1；注意**边 e6 是那条"捷径"**——它让原本环上距离 2 的节点 1 与 3 变成直接相连，这正是"小世界"的典型结构（局部稠密 + 少量长程捷径）。

步骤 1：写邻接矩阵 A（邻接矩阵是对称的，因为边没有方向）。

$$A=\begin{bmatrix}0&1&1&0&1\\1&0&1&0&0\\1&1&0&1&0\\0&0&1&0&1\\1&0&0&1&0\end{bmatrix}\qquad(5\times5)$$

步骤 2：用 $A\mathbf{x}$ 求度数（$\mathbf{x}=\mathbf{1}$）。

$$(A\mathbf{1})_i=\text{节点 }i\text{ 的邻居个数}$$

- 节点 1：$0+1+1+0+1=3$（邻居 2,3,5）
- 节点 2：$1+0+1+0+0=2$（邻居 1,3）
- 节点 3：$1+1+0+1+0=3$（邻居 1,2,4）
- 节点 4：$0+0+1+0+1=2$（邻居 3,5）
- 节点 5：$1+0+0+1+0=2$（邻居 1,4）

所以 $A\mathbf{1}=(3,2,3,2,2)^{\mathsf T}$，度数之和 $3+2+3+2+2=12=2\times6=2E$ ✓（每条边被两个端点各数一次，这就是"握手引理"的矩阵版）。

步骤 3：用 A^k 数路径。

$$A^2=\begin{bmatrix}3&1&1&2&0\\1&2&1&1&1\\1&1&3&0&2\\2&1&0&2&0\\0&1&2&0&2\end{bmatrix},\qquad A^3=\begin{bmatrix}2&4&6&1&5\\4&2&4&2&2\\6&4&2&5&1\\1&2&5&0&4\\5&2&1&4&0\end{bmatrix}.$$

- $(A^2)_{11}=3$：从节点 1 出发走 2 步回到自己的路径有 3 条（$1\to2\to1$、$1\to3\to1$、$1\to5\to1$）——正好等于节点 1 的**度数**。一般地，$\mathrm{diag}(A^2)=$ 度数向量 $(3,2,3,2,2)^{\mathsf T}$ ✓（注意看：A^2 的对角线正是 $(3,2,3,2,2)$）。
- $(A^2)_{14}=2$：节点 1 到节点 4 走 2 步有 2 条路（$1\to3\to4$、$1\to5\to4$）。
- $(A^3)_{15}=5$：节点 1 到节点 5 走 3 步有 5 条路（$1\to2\to1\to5$、$1\to3\to1\to5$、$1\to3\to4\to5$、$1\to5\to1\to5$、$1\to5\to4\to5$）。

每条边的"最短"性质也能读出：A 里 $a_{13}=1$（直接相连），所以 $\mathbf{dist}(1,3)=1$，而不是环上的 2。逐点算最短距离可得**直径 = 2**（任意两节点间最多 2 步）——5 个节点、6 条边就能做到这么"紧"，这就是小世界。

步骤 4：写关联矩阵 B（节点 × 边，每列一个 $+1$、一个 -1）。

$$B=\begin{array}{c|cccccc}&e_1&e_2&e_3&e_4&e_5&e_6\\\hline1&1&0&0&0&-1&1\\2&-1&1&0&0&0&0\\3&0&-1&1&0&0&-1\\4&0&0&-1&1&0&0\\5&0&0&0&-1&1&0\end{array}\qquad(5\times6)$$

步骤 5：读 B 的四个子空间（这里是本讲的"高潮"）。

先算秩：前 5 行里，行 1+行 2+行 3+行 4+行 5 $=\mathbf{0}$（每列 $+1-1=0$），所以行线性相关，$r\le4$；实际 $r=4$。于是

- $\dim C(B)=4$（住在 $\mathbb{R}^5$），$\dim C(B^{\mathsf T})=4$（住在 $\mathbb{R}^6$）；
- $\dim N(B)=6-4=2$（住在 $\mathbb{R}^6$）——**这就是"环"**！维数 $=E-N+C=6-5+1=2$（本例连通，$C=1$，故也写作 $E-N+1$）。这两维对应两个**独立的环**，物理上叫回路数（number of independent loops），拓扑上叫第一贝蒂数。两组基：
- 大环 $e_1+e_2+e_3+e_4+e_5=(1,1,1,1,1,0)$：沿 1–2–3–4–5–1 走一圈，每个节点进出各一次，所以 $B\cdot$该向量 $=\mathbf{0}$ ✓
- 小环 $e_1+e_2-e_6=(1,1,0,0,0,-1)$：沿 1–2–3–1 走一圈（$e_6$ 反向），同样 $B\cdot$该向量 $=\mathbf{0}$ ✓
- $\dim N(B^{\mathsf T})=5-4=1$（住在 $\mathbb{R}^5$）——基为 $\mathbf{1}=(1,1,1,1,1)^{\mathsf T}$：**所有节点电位相同 ⇒ 所有边上的电压差为零**。这正是"图是连通的"（只有 1 个连通分量）在线性代数里的化身。

步骤 6：从关联矩阵得到拉普拉斯矩阵 $L=BB^{\mathsf T}$。

$$L=BB^{\mathsf T}=\begin{bmatrix}3&-1&-1&0&-1\\-1&2&-1&0&0\\-1&-1&3&-1&0\\0&0&-1&2&-1\\-1&0&0&-1&2\end{bmatrix}$$

规律一目了然：**对角元 = 该节点的度数，非对角元 $= -1$ 当两节点相邻**。所以 $L = D - A$（D 为度数对角阵）。逐格核对第一行：节点 1 的度数是 3（对角元 3），邻居是 2、3、5（这三个位置为 -1），非邻居 4 处为 0 ✓

- $L\mathbf{1} = \mathbf{0}$ ✓（每行之和为 0），即 $\mathbf{1} \in N(L)$，$\dim N(L) = 1$ = 连通分量数。
- $\mathrm{tr}(L) = 3+2+3+2+2 = 12 = 2E$ ✓
- $\mathrm{rank}(L) = 4$，四个子空间的关系在这里第一次"显形"。

步骤 7：$B^{\mathsf{T}}\mathbf{x}$ 读"割"（cut），$B\mathbf{y}$ 读"差"。

取 $\mathbf{x}$ 为"节点 1、2 在左边，其余在右边"的指示向量 $\mathbf{x} = (1,1,0,0,0)^{\mathsf{T}}$，算 $B^{\mathsf{T}}\mathbf{x}$：

$$B^{\mathsf{T}}\mathbf{x} = \begin{bmatrix} 0 \\ 1 \\ 0 \\ 0 \\ -1 \\ 1 \end{bmatrix} \leftarrow \text{六个分量对应六条边}$$

读法：$e_1 = 1\text{-}2$ 两端同侧 → 0；$e_2 = 2\text{-}3$ 跨过割 → $+1$；$e_3 = 3\text{-}4$ 同侧 → 0；$e_4 = 4\text{-}5$ 同侧 → 0；$e_5 = 5\text{-}1$ 跨过割 → -1；$e_6 = 1\text{-}3$ 跨过割 → $+1$。

$(B^{\mathsf{T}}\mathbf{x})_e \neq 0$ 当且仅当边 e 跨越这个"割"。 所以 B^{T} 把节点上的"分组"变成边上的"割标记"；$C(B^{\mathsf{T}})$ 就是**割空间**（cut space），维数 $r = 4 = n - 1$，与环空间 $N(B)$（维数 2）正交互补，$4 + 2 = 6 = E$ ✓。

【计算机制解说】为什么 B 与 B^{T} 分别对应"节点求和"与"边的差"？ 把 B 的乘法按"图上的动作"读出来，一切就通了。**关键先看形状：B 是 5×6（节点 × 边），所以 B 把"边上的数"送到"节点上的数"，B^{T} 反过来把"节点上的数"送到"边上的数"。**

(1) B^{T}：节点电位 → 边电压（求差）。 设 $\mathbf{x} \in \mathbb{R}^5$ 是**节点上的数值**（比如温度或电位）。B^{T} 是 6×5，所以 $B^{\mathsf{T}}\mathbf{x} \in \mathbb{R}^6$ 是**边上的数值**，且对边 $e = (i, j)$ 有

$$(B^{\mathsf{T}}\mathbf{x})_e = \pm(x_i - x_j) = \text{该边两端的数值之差}.$$

如果 $\mathbf{x}$ 是常数（所有节点同一电位），则每条边的差都是 0，所以

$$B^{\mathsf{T}}\mathbf{1} = \mathbf{0} \iff \mathbf{1} \in N(B^{\mathsf{T}}).$$

这就是"**给全图加同一个常数电位不改变任何电压差**"——也正因如此，$\dim N(B^{\mathsf{T}})$ 数的是"常数电位的自由度"，等于连通分量个数 C。（对图丙的两个断开分量，可以各加各的常数，所以 $\dim N(B^{\mathsf{T}}) = 2$ ✓）

(2) B：边流量 → 节点净出流（求和）。 设 $\mathbf{y} \in \mathbb{R}^6$ 是**边上的数值**（比如电流）。B 是 5×6，所以 $B\mathbf{y} \in \mathbb{R}^5$ 是**节点上的数值**，且

$$(B\mathbf{y})_i = \sum_{e \text{ 从 } i \text{ 出发}} y_e - \sum_{e \text{ 进入 } i} y_e = \text{节点 } i \text{ 的净流出量}.$$

基尔霍夫电流定律（Kirchhoff's Current Law）说：**每个节点净流入为零**，即

$$B\mathbf{y} = \mathbf{0} \iff \mathbf{y} \in N(B).$$

所以 $N(B)$ 就是"**无源（divergence-free）的边流量配置**"，即**环空间**。

环 = 无源电流：沿一个环每边放电流 $+1$，每个节点恰好"一进一出"，净出流为零，所以 $B \cdot (\text{环向量}) = \mathbf{0}$——这正是上面 $(1,1,1,1,1,0)$ 与 $(1,1,0,0,0,-1)$ 两组的来历。反过来说，树没有环，任何边的非平凡组合都会在某个叶子节点留下净流出，无法满足 $B\mathbf{y} = \mathbf{0}$，所以图甲 $\dim N(B) = 0$。

两个子空间的分工一览（这是整段最值得记住的对照）：

```
关联矩阵 B :  N 行 = 节点        E 列 = 边

B   : R^E -> R^N      输入 = 边上的流量/差值量
                      输出 = 每个节点的"净流出"(求和)
                      B y = 0  <=>  基尔霍夫电流定律

B^T : R^N -> R^E      输入 = 节点上的电位
                      输出 = 每条边两端的"差"
                      B^T x = 0 <=> x 是常数(每个分量上)

-------------------- 四个子空间 --------------------
N(B)     = 环空间 (loop space)      dim = E - N + C   住 R^E
C(B^T)   = 割空间 (cut space)       dim = N - C       住 R^E
N(B^T)   = 常数电位空间             dim = C           住 R^N
C(B)     = 节点净流可达集           dim = N - C       住 R^N

R^E = C(B^T) (+) N(B)       (割 与 环 正交互补, E = (N-C) + (E-N+C))
R^N = C(B)  (+) N(B^T)      (N = (N-C) + C)
```

整个电路理论（节点电位、边电压、电流、基尔霍夫定律、欧姆定律）就建立在这两个子空间的分解上；讲次 12 会把它展开成完整理论。

同一套机制也解释了**示例一**中的 $A = CR$：R 记录列的组合系数（"说明书"），B 记录节点与边的连接关系（"拓扑说明书"）——两者都是"用一种更小的矩阵描述一个大矩阵的结构"。

示例四：三个小图对照 —— 树、环、断开的图（把维数公式用满）

同样 4 个节点，改变边就得到完全不同的子空间维数。这是"关联矩阵 = 图的拓扑探测器"最直接的证据。

图甲：一棵树（4 节点、3 边：1–2, 2–3, 3–4）。

$$B_{\text{甲}} = \begin{bmatrix} 1 & 0 & 0 \\ -1 & 1 & 0 \\ 0 & -1 & 1 \\ 0 & 0 & -1 \end{bmatrix} \qquad (4 \times 3)$$

消元后 $r = 3$，于是：$\dim C(B) = 3$、$\dim C(B^{\mathsf{T}}) = 3$、$\dim N(B) = 3 - 3 = 0$、$\dim N(B^{\mathsf{T}}) = 4 - 3 = 1$。

- $N(B) = \{0\}$ 说明"**树没有环**"——任何边的非平凡组合都会在某个节点留下净流入，无法成为无源电流。
  $\dim N(B) = E - N + C = 3 - 4 + 1 = 0$ ✓
- $N(B^{\mathsf{T}}) = \text{span}\{\mathbf{1}\}$，连通分量数 1 ✓
- $L = BB^{\mathsf{T}} = \begin{bmatrix} 1 & -1 & 0 & 0 \\ -1 & 2 & -1 & 0 \\ 0 & -1 & 2 & -1 \\ 0 & 0 & -1 & 1 \end{bmatrix}$（三对角，正是"路径图"的典型形状）

图乙：一个 4 环（4 节点、4 边：1–2, 2–3, 3–4, 4–1）。

$$B_{\text{乙}} = \begin{bmatrix} 1 & 0 & 0 & -1 \\ -1 & 1 & 0 & 0 \\ 0 & -1 & 1 & 0 \\ 0 & 0 & -1 & 1 \end{bmatrix} \qquad (4 \times 4)$$

$r = 3$，于是：$\dim N(B) = 4 - 3 = 1$，基恰好是 $\mathbf{1} = (1,1,1,1)^{\mathsf{T}}$——沿整个环走一圈的电流。$\dim N(B^{\mathsf{T}}) = 1$。

- 对比图甲：**只多了一条边，零空间就从 0 维跳到 1 维**。"多一个环 = 多一维零空间"这句话在这里被彻底暴露。
  $\dim N(B) = E - N + C = 4 - 4 + 1 = 1$ ✓
- $L = B_{\text{乙}} B_{\text{乙}}^{\mathsf{T}} = \begin{bmatrix} 2 & -1 & 0 & -1 \\ -1 & 2 & -1 & 0 \\ 0 & -1 & 2 & -1 \\ -1 & 0 & -1 & 2 \end{bmatrix}$（循环图的拉普拉斯，每行和为 0）

图丙：两个断开的边（4 节点、2 边：1–2 与 3–4）。

$$B_{\text{丙}} = \begin{bmatrix} 1 & 0 \\ -1 & 0 \\ 0 & 1 \\ 0 & -1 \end{bmatrix} \qquad (4 \times 2)$$

$r=2$，于是：$\dim N(B)=2-2=0$（两条边各自独立，不构成环——而且它们根本不共端点）；$\dim N(B^{\mathsf{T}})=4-2=2$，基为 $(1,1,0,0)$ 与 $(0,0,1,1)$。

- **这里出现了一个关于本讲的关键修正**：$\dim N(B^{\mathsf{T}})=2$ **正好等于连通分量的个数**。前面的"$\mathbf{1}\in N(B^{\mathsf{T}})$"只是连通图（$C=1$）的特例；一般情形下 $N(B^{\mathsf{T}})$ 的维数是"**能在哪些节点上加同一个常数电位而不影响任何电压差**"的自由度，也就是分量数。
- 相应地，独立环数的正确公式是

$$\dim N(B)=E-\operatorname{rank}(B)=E-(N-C)=E-N+C,$$

其中 C 是连通分量个数。**只有连通图（$C=1$）才能用常见的 $E-N+1$。** 本例 $C=2$：$2-4+2=0$ ✓（若错用 $E-N+1$ 会得到 -1，一个负数维数显然荒谬——这正是检验公式是否用对的好办法）。– $L=B_{丙}B_{丙}^{\mathsf{T}}=\begin{bmatrix}1&-1&0&0\\-1&1&0&0\\0&0&1&-1\\0&0&-1&1\end{bmatrix}$：**分块对角**，两块各自对应一个连通分量——$L$ 的块结构直接把图的连通结构"读"了出来。$\dim N(L)=2=C$ ✓

对照表（同一张表把四个子空间与图性质绑在一起）：

```
4 节点图          E   C   rank(B)=N−C   dim N(B)   dim N(B^T)   图的性质
                                                    = E−N+C    = C
-------------------------------------------------------------------------
甲：树             3   1        3           0          1        无环，连通
乙：4 环           4   1        3           1          1        恰有一个独立环，连通
丙：两条断边       2   2        2           0          2        无环，2 个连通分量
-------------------------------------------------------------------------
本讲示例三         6   1        4           2          1        2 个独立环，连通
(5 节点小世界)

规律：rank(B) = N − C  （节点数 减去 连通分量数）
     "一个图最多只能有 N−1 个独立行"
```

【计算机制解说】为什么 $\operatorname{rank}(B)=N-C$？ B 是 $N\times E$。对每一列（一条边），$+1$ 与 -1 相加为 0，所以**每列之和为 0**——这给出一个行之间的线性关系：$\mathbf{1}^{\mathsf{T}}B=\mathbf{0}^{\mathsf{T}}$，即 $\mathbf{1}\in N(B^{\mathsf{T}})$，所以 $\operatorname{rank}(B)\le N-1$。

反过来证明"不可能更少"：沿着图的每条边"传播"电位。固定某个连通分量里的一个节点电位为 0，沿边逐跳地确定其余节点电位（因为每条边 B^{T} 的方程要求两端差为 0 才能让 $\mathbf{y}^{\mathsf{T}}B=\mathbf{0}$ 成立……更直接的做法是把分量缩成一棵树：树上 $N-1$ 条边对应的列线性无关，可以逐列消元得到 $N-1$ 个主元）。于是每个连通分量贡献 $\operatorname{rank}=N_c-1$，全部相加：

$$\operatorname{rank}(B)=\sum_{c=1}^{C}(N_c-1)=N-C.$$

代到秩–零化度定理的两侧，就得到上面表格里的两行公式：

$$\dim N(B)=E-(N-C)=E-N+C,\qquad \dim N(B^{\mathsf{T}})=N-(N-C)=C.$$

这条推导的价值：它把"图有几个环""图是否连通"这两个纯粹组合的问题，变成了一个**矩阵的秩**问题——这正是 Strang 说"线性代数是应用数学的瑞士军刀"的具体含义。讲次 12 会把这条线拉得更远（基尔霍夫定律、最小生成树、网络流）。

矩阵分解的核心思想

本讲的核心分解仍是 $A=CR$，但它在本讲获得了新的解释与推广对象：

$$A=CR=\sum_{i=1}^{r}\mathbf{c}_i\,\mathbf{r}_i^{\mathsf{T}}.$$

- **形式**：C = 主元列（$m\times r$），R = RREF 非零行（$r\times n$）。
- **含义**：A 由 r 个**秩 1 积**组成；每个积 $\mathbf{c}_i\mathbf{r}_i^{\mathsf{T}}$ 贡献"一个方向进、一个方向出"。$A=CR$ 是秩 r 的最经济表达（$mr+rn$ 个数 vs mn）。
- **揭示的结构性质**：C(A)=C(C)、C(A^T)=C(R)；四个子空间完全由 C,R 承载。C 与 R 是**非正交**骨架（列取自 A，行取自 RREF，一般不互相垂直）。
- **应用价值**：压缩、低秩近似、SVD 的出发点。**SVD 做的事就是"把 $A=CR$ 再正交化"**：找正交的 U（替代 C）、正交的 V^{T}（替代 R），并让系数 $\sigma_1\ge\sigma_2\ge\cdots\ge\sigma_r>0$ 按重要性排序：

$$A=\sum_{i=1}^{r}\sigma_i\mathbf{u}_i\mathbf{v}_i^{\mathsf{T}}.$$

每一项 $\sigma_i \mathbf{u}_i \mathbf{v}_i^{\mathsf{T}}$ 仍是**秩 1**！这就是"任何矩阵 = 秩 1 矩阵之和"的最美版本，而 σ_i 告诉你哪几项最重要（截断到前 k 项就得到最佳低秩近似）。详见讲次 29。

本讲的另一条结构性线索是**矩阵空间的维数公式**（子空间容斥）：

$$\dim(S+U) = \dim S + \dim U - \dim(S \cap U).$$

它与 $A = CR$ 是同一哲学：**"用更小的、结构化的部件拼出整个空间"**。一个说"矩阵由 r 个秩 1 块拼成"，一个说"矩阵空间由对称块与三角块拼成，重叠部分要扣掉"。

与其他讲次的关联

- **与 Lecture 10（四个基本子空间）**：本讲把四子空间从 $\mathbb{R}^n/\mathbb{R}^m$ 推广到"矩阵空间"，并给出 $A = CR$ 作为四子空间的载具。示例三的关联矩阵 B 是一个 5×6 的普通矩阵，四子空间理论完全适用。
- **与 Lecture 12（图与网络、关联矩阵）**：本讲只是"初见"关联矩阵与拉普拉斯 $L = BB^{\mathsf{T}}$；Lecture 12 会把它发展成完整理论（环空间、割空间、基尔霍夫定律、欧姆定律）。
- **与 Lecture 5–6（$A = LU$）**：消元同时产出 LU（行信息）与 CR（列信息）。$A = CR$ 与 $A = LU$ 是同一算法的两个面孔。
- **与 Lecture 21–25（特征值、马尔可夫、正定）**：邻接矩阵 A 的特征值（尤其是"−马尔可夫/随机游走矩阵"）是 PageRank 与谱图理论的核心；$L = BB^{\mathsf{T}}$ 自动是**半正定**的（因为对任意 $\mathbf{x}$，$\mathbf{x}^{\mathsf{T}} L \mathbf{x} = \|B^{\mathsf{T}}\mathbf{x}\|^2 \geq 0$）——这直接把本讲接到讲次 27 的正定性。
- **与 Lecture 29（SVD）**：$A = \sum \sigma_i \mathbf{u}_i \mathbf{v}_i^{\mathsf{T}}$ 是本讲"r 个秩 1 之和"的正交化版本，四子空间的正交基也由 SVD 一次性给出。
- **与 Lecture 30–33（线性变换、伪逆）**：矩阵空间视角让"线性变换的集合"也变成向量空间，为伪逆与最小范数解铺路。

关键要点

1. **矩阵是向量**：所有 $m \times n$ 矩阵构成 mn 维向量空间 M。$\dim M(3\times 3) = 9$，$\dim S(\text{对称}) = 6$，$\dim U(\text{上三角}) = 6$，$\dim D(\text{对角}) = 3$，且 $D = S \cap U$。**维数 = 自由参数的个数 = 总位置数 − 独立约束数。**
2. **子空间维数公式（容斥）**：

$$\dim(S+U) = \dim S + \dim U - \dim(S \cap U).$$

验证：$6 + 6 - 3 = 9 = \dim M$，所以 $S + U = M$（任一矩阵 = 对称 + 上三角）。对比直和 $M = S \oplus K$（$6 + 3 = 9$，$S \cap K = \{0\}$）。

1. **秩 1 矩阵**：$A = \mathbf{u}\mathbf{v}^{\mathsf{T}}$，其列全是 $\mathbf{u}$ 的倍数、行全是 $\mathbf{v}^{\mathsf{T}}$ 的倍数，C(A) 与 C(A^{T}) 各是一条直线。$A = \sum_{i=1}^{r} \mathbf{c}_i \mathbf{r}_i^{\mathsf{T}}$：**秩 r = r 个秩 1 之和**。注意秩 1 矩阵全体**不是**子空间（相加可能升秩）。
2. **$A = CR$**：C 取**原矩阵的主元列**，R 取 RREF **的非零行**，则 $A = CR$ 严格成立，且 R 就是"A 的列在 C(A) 中的坐标表"。
3. **图的矩阵化**：邻接矩阵 A，$(A\mathbf{x})_i$ = 节点 i 的邻居权重之和，$A\mathbf{1}$ = 度数向量，$(A^k)_{ij}$ = 长度 k 的路径条数。关联矩阵 B（N 节点 × E 边，每列一个 $+1$ 一个 -1）：$B^{\mathsf{T}}\mathbf{x}$ 给出**边上的差**（故 $B^{\mathsf{T}}\mathbf{1} = \mathbf{0}$），$B\mathbf{y}$ 给出**节点上的净流出**（故 $B\mathbf{y} = \mathbf{0}$ 即基尔霍夫电流定律）。于是 $N(B)$ = **环空间**，$\dim = E - N + C$；$C(B^{\mathsf{T}})$ = **割空间**，$\dim = N - C$；$N(B^{\mathsf{T}})$ = **常数电位空间**，$\dim = C$（连通分量数）；$BB^{\mathsf{T}} = L$ = **拉普拉斯矩阵**（对角为度数，非对角相邻为 -1）。

常见误区与注意事项

1. **把"矩阵空间"与"行列式的值"混为一谈**。M 的维数是 mn 而不是别的数：3×3 矩阵有 9 个自由数。虽然"可逆矩阵"这个集合很大，但**可逆矩阵不构成子空间**（$\det(A+B)$ 一般 $\neq \det A + \det B$，且零矩阵不可逆）。同理"秩恰好为 1 的矩阵"也不是子空间。
2. **以为 $S \cap U$ 是空集或维数 1**。$S \cap U$ = 既对称又上三角 = **对角矩阵**，维数 3（不是 0、也不是 1）。用"S 有 3 个独立位置 + U 有 3 个"去理解更可靠：对角阵同时满足两边的条件。
3. **在 $A = CR$ 里用 RREF 的列充当 C**。C 必须来自**原矩阵 A**。RREF 的列空间一般是不同的子空间（讲次 10 已强调）。R 才来自 RREF。
4. **误以为 $A = \sum \sigma_i \mathbf{u}_i \mathbf{v}_i^{\mathsf{T}}$ 里每一项的 $\mathbf{u}_i, \mathbf{v}_i$ 必须来自 A 本身**。在 $A = CR$ 中 $\mathbf{c}_i$ 确实取自 A 的列，但在 SVD 中 $\mathbf{u}_i, \mathbf{v}_i$ 是**新的正交方向**，一般都不是 A 的原始列或行。这是 CR 与 SVD 的关键差别：CR 保"取材于 A"，SVD 保"互相正交"。
5. **把关联矩阵的 $+1/-1$ 方向当儿戏**。每条边必须有且仅有一个 $+1$、一个 -1（方向可以任意定，但不能两个都是 $+1$）。只有这样"每列和为 0"才成立，从而 $\mathbf{1} \in N(B^{\mathsf{T}})$、$B \cdot (\text{环}) = \mathbf{0}$ 才成立。若把方向搞错，环就不是零空间里的向量了。
6. **算 $(A^k)_{ij}$ 时忘了"恰好 k 步"**。A^k 数的是**恰好 k 步**的路径（也叫 walk，允许重复经过节点），不是"最多 k 步"、更不是"最短路径"。要判断连通只需看 $\sum_{k=1}^{n-1} A^k$ 里对应位置是否非零。

思考题（带答案）

Q1.（纯计算） 设 M 为所有 4×4 实矩阵构成的空间。求下列子空间的维数：(a) 全部 4×4 矩阵 M；(b) 对称矩阵 S；(c) 上三角矩阵 U；(d) 对角矩阵 D；(e) $S \cap U$；(f) $S + U$，并判断 $S + U$ 是否等于 M。

▸ **答案**

用"总位置数 − 独立约束数"数。

(a) $\dim M = 4 \times 4 = 16$。

(b) 对称 4×4：对角 4 个自由 + 上三角 $4 \cdot 3/2 = 6$ 个自由，共 $\dim S = 10$。（公式 $\frac{n(n+1)}{2} = \frac{4 \cdot 5}{2} = 10$。）

(c) 上三角 4×4：对角 4 + 上三角 6，共 $\dim U = 10$。

(d) 对角：$\dim D = 4$。

(e) $S \cap U$ = 既对称又上三角 = 对角，$\dim(S \cap U) = \dim D = 4$。

(f) $\dim(S+U) = \dim S + \dim U - \dim(S \cap U) = 10 + 10 - 4 = 16 = \dim M$。因为 $S + U \subseteq M$ 且维数相同，所以 $S + U = M$，即任何 4×4 矩阵都能写成一个对称矩阵与一个上三角矩阵之和。

（对照：$M = S \oplus K$，反对称 4×4 维数为 $4 \cdot 3/2 = 6$，$10 + 6 = 16$ ✓，且 $S \cap K = \{0\}$。）

Q2.（概念） 判断正误并说明理由。(a) 若图 G 有 $n = 6$ 个节点、$m = 8$ 条边且连通，则其关联矩阵 B 的零空间维数为 3。(b) 邻接矩阵的 $(A^3)_{ij}$ 给出节点 i 到 j 的最短路径长度。(c) 一个 5×5 的三对角矩阵（只有主对角和上下次对角非零）构成的空间，维数为 15。

▸ **答案**

(a) **对**。$\dim N(B) = m - r$。连通图关联矩阵的秩 $r = n - 1 = 5$（因为"每列和为 0"给出一个独立线性关系，且连通时只有这一个）。所以 $\dim N(B) = 8 - 5 = 3$。这也是独立环数 $= m - n + 1 = 8 - 6 + 1 = 3$ ✓。同时 $\dim N(B^{\mathsf{T}}) = n - r = 6 - 5 = 1$（基为 $\mathbf{1}$），正是"连通分量数 = 1"。

(b) **错**。$(A^3)_{ij}$ 是**恰好 3 步**的路径条数（walk，允许重复节点），不是最短距离。最短距离是使 $(A^k)_{ij} > 0$ 的**最小 k**。例如 i 到 j 直接相邻时 $(A^3)_{ij}$ 可能为 0（若 i, j 不在任何 3 步走法上），但最短距离显然是 1。

(c) **错**。正确的维数是 **13**，不是 15。自由位置 = 主对角 5 个 + 上二次对角 4 个 + 下二次对角 4 个 = $5 + 4 + 4 = 13$。易错点在于 5×5 矩阵的次对角线上只有 **4** 个元素（位置 $(1,2), (2,3), (3,4), (4,5)$），不是 5 个。验证思路：每个非零位置放一个"单点基矩阵"，共 13 个，线性无关。

Q3.（综合） 取小世界图的**入度/权重版**：设 3 个节点的有向图，边 $\mathbf{1} \to \mathbf{2}$（权重 2）、$\mathbf{1} \to \mathbf{3}$（权重 3）、$\mathbf{2} \to \mathbf{3}$（权重 1）。写出它的邻接矩阵 A（a_{ij} = 边 $i \to j$ 的权重），计算 $A\mathbf{1}$ 和 $A^{\mathsf{T}}\mathbf{1}$，并解释它们各自的含义。

▸ **答案**

$$A = \begin{bmatrix} 0 & 2 & 3 \\ 0 & 0 & 1 \\ 0 & 0 & 0 \end{bmatrix}.$$

（行 i = 从节点 i 出去的边，列 j = 进入节点 j 的边。）

$$A\mathbf{1} = \begin{bmatrix} 5 \\ 1 \\ 0 \end{bmatrix}, \qquad A^{\mathsf{T}} = \begin{bmatrix} 0 & 0 & 0 \\ 2 & 0 & 0 \\ 3 & 1 & 0 \end{bmatrix}, \qquad A^{\mathsf{T}}\mathbf{1} = \begin{bmatrix} 0 \\ 2 \\ 4 \end{bmatrix}.$$

- $(A\mathbf{1})_i$ = 从节点 i **流出**的权重总和（出度）：节点 1 流出 $2 + 3 = 5$，节点 2 流出 1，节点 3 流出 0。
- $(A^{\mathsf{T}}\mathbf{1})_j$ = 流入节点 j 的权重总和（入度）：节点 1 入 0，节点 2 入 2，节点 3 入 $3 + 1 = 4$。
- 全局守恒：$\mathbf{1}^{\mathsf{T}}A\mathbf{1} = \mathbf{1}^{\mathsf{T}}A^{\mathsf{T}}\mathbf{1} = 5 + 1 + 0 = 6 = 0 + 2 + 4$ ✓，等于总权重 $2 + 3 + 1 = 6$。

补充：这个 A 是**严格上三角**的，所以它是**幂零**的（$A^3 = 0$），这反映了图是**无环的**（DAG，不可能一直往下走）。而 $\mathbf{1} \in N(A^{\mathsf{T}})$ 检验：$A^{\mathsf{T}}\mathbf{1} = (0, 2, 4)^{\mathsf{T}} \neq \mathbf{0}$，所以这里 $\mathbf{1} \notin N(A^{\mathsf{T}})$——有向图不像无向图那样总有"常数向量在左零空间"（无向图里 $B\mathbf{1} = \mathbf{0}$ 是因为每列 $+1$ 与 -1 相消）。

Lecture 12: Graphs, Networks, Incidence Matrices

概述

本讲把**图（graph）**翻译成一个矩阵：**关联矩阵（incidence matrix）** A。这是全课程最漂亮的跨学科翻译：节点电势 x、边电势差 $y = Ax$，基尔霍夫电流定律变成 $A^{\mathsf{T}}y = \mathbf{0}$，而**回路（loops）**正好是 $N(A^{\mathsf{T}})$ 的基向量。讲次 10 的四个基本子空间在这里不再是抽象玩具，而是电路与网络流里可

摸可算的东西；$A^{\mathsf{T}}A$ 则给出**图拉普拉斯矩阵**。

核心概念的几何直觉

图与关联矩阵

- **定义与目的**：图由**节点（nodes）** $1,\dots,n$ 与**边（edges）** $e_1,\dots,e_m$ 组成，每条边连两个节点。矩阵 A 行对应边、列对应节点，规模 $m\times n$；第 i 行只在第 i 条边的两端非零，一端 -1（起点）、一端 $+1$（终点）。方向是人为约定，取反只让整行变号，结论不变。
- **几何直觉（它在空间中是什么样子？）**：A 作用在**节点向量** $x\in\mathbb{R}^n$ 上，输出**边向量** $y=Ax\in\mathbb{R}^m$。x 是各节点**电势（potential）**，y 是各边两端的**电势差**。所以 A 是一台"做减法"的机器：把节点上的值转成边上的落差。
- **具体示例**：一条边连节点 1、2，$y=x_2-x_1=\begin{bmatrix}-1,\ 1\end{bmatrix}\begin{bmatrix}x_1\\x_2\end{bmatrix}$。整行 $[-1,1]$ 就是这条边的关联行——这是 1 维的"导数"。

四个子空间在图上的物理含义

- **定义与目的**：A 是 $m\times n$，故 $N(A)\subseteq\mathbb{R}^n$、$C(A^{\mathsf{T}})\subseteq\mathbb{R}^n$、$N(A^{\mathsf{T}})\subseteq\mathbb{R}^m$、$C(A)\subseteq\mathbb{R}^m$。本讲给它们起了名字。
- **几何直觉（它在空间中是什么样子？）**：$N(A)=$ 全部节点同加常数的等电势向量；$C(A^{\mathsf{T}})=$ 节点空间里"能由电势产生的边落差"的方向；$N(A^{\mathsf{T}})=$ 满足 KCL 的环流（回路空间）；$C(A)=$ 所有可实现的边电势差。
- **具体示例**：下例中 $\dim N(A)=1$（整体电势平移）、$\dim N(A^{\mathsf{T}})=2$（两个独立回路）。

基尔霍夫电流定律（KCL）

- **定义与目的**：$A^{\mathsf{T}}y=0$。A^{T} 是 $n\times m$，第 j 行（对应节点 j）说：连到节点 j 的所有边电流带符号相加为零，即**流入 = 流出**。
- **几何直觉（它在空间中是什么样子？）**：电流像水，节点是接头，水不能在接头里堆积。$A^{\mathsf{T}}y=0$ 就是"每个接头净流量为零"。
- **具体示例**：一圈回路上的单位电流（沿环走 $+1$），在每个节点恰好一进一出，$A^{\mathsf{T}}y=0$ 自动成立。

图拉普拉斯矩阵 $L=A^{\mathsf{T}}A$

- **定义与目的**：$A^{\mathsf{T}}A$ 是 $n\times n$ 对称矩阵。$L_{jj}=$ 节点 j 的**度数（degree）**，$L_{ij}=-1$（节点 i,j 之间有边），否则 0。
- **几何直觉（它在空间中是什么样子？）**：L 是图上的**二阶差分算子**（离散拉普拉斯），度量"这个节点的值与邻居差多少"。$x^{\mathsf{T}}Lx=\sum_{\text{边}}(x_j-x_i)^2$ 是整张图的**能量**。
- **具体示例**：下例 L 的对角元为 $(3,2,3,2)$，正是四节点的度数。

计算步骤与手算演示

示例：4 节点 5 边连通图（正方形 + 一条对角线）

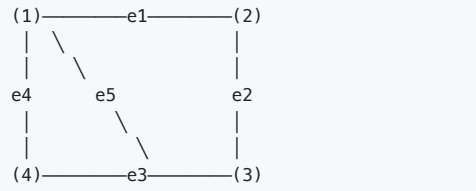


```
节点 1,2,3,4  (n = 4)
e1 = 1–2 (上边)   e2 = 2–3 (右边)   e3 = 3–4 (下边)
e4 = 4–1 (左边)   e5 = 1–3 (对角线)
共 m = 5 条边，连通，无自环，无重边
```

演示 1：写出 A 并求秩

步骤 1：规定方向。 统一取"小编号 → 大编号"为正向：$e_1:1\to2$，$e_2:2\to3$，$e_3:3\to4$，$e_4:1\to4$，$e_5:1\to3$。起点列填 -1，终点列填 $+1$。

步骤 2：逐行写出（行 = 边，列 = 节点 1,2,3,4）：

$$A=\begin{bmatrix}-1&1&0&0\\0&-1&1&0\\0&0&-1&1\\-1&0&0&1\\-1&0&1&0\end{bmatrix}_{5\times4}$$

步骤 3：先找一个"必零"的组合。 把四列相加：每行恰有一个 -1 和一个 $+1$，相加得零向量，所以

$$\text{col}_1+\text{col}_2+\text{col}_3+\text{col}_4=0\quad\Longrightarrow\quad A\mathbf{1}=0$$

步骤 4：行化简求秩。

```
      A                          RREF(A)
-1  1  0  0                  1  0  0 -1
 0 -1  1  0                  0  1  0 -1
 0  0 -1  1    ── 行化简 ──▶   0  0  1 -1
-1  0  0  1                  0  0  0  0
-1  0  1  0                  0  0  0  0

主元在第 1,2,3 列   ⇒   rank(A) = 3
```

$$\boxed{\mathbf{rank}(A) = 3 = n - 1 = 4 - 1}$$

【计算机制解说】：为什么连通图恰好差一个秩？下界由步骤 3 给出（列相关 $\Rightarrow \mathbf{rank} \le n-1$）。上界由"路径相加"给出：从节点 1 沿边走到节点 j，把路径上各边的行相加，中间节点的 ± 1 两两抵消，只剩起点 -1 与终点 $+1$，于是行空间含 $e_j - e_1$（$j = 2,3,4$）以及 e_1 的某个方向，维数达 $n-1$。图连通 $\iff$ 任何节点都能被"走到" $\iff \mathbf{rank}(A) = n-1$。有 k 个连通块时 $\mathbf{rank} = n - k$。

演示 2：$N(A)$（等电势）与 $N(A^{\mathsf{T}})$（回路）

步骤 1：求 $N(A)$。 从 RREF 读出 $x_1 - x_4 = 0$，$x_2 - x_4 = 0$，$x_3 - x_4 = 0$，即四者相等：

$$N(A) = \mathbf{span}\left\{ \begin{bmatrix} 1 \\ 1 \\ 1 \\ 1 \end{bmatrix} \right\}, \qquad \dim N(A) = n - r = 4 - 3 = 1$$

直接验证 $A(1,1,1,1)^{\mathsf{T}} = \mathbf{0}$：五条边两端都相等，落差为零 ✓。**物理含义**：全部节点电势同时抬高 1 伏，边上的落差一个数都不变，$y = Ax$ 不变。所以 $N(A)$ 就是"电势整体平移"这一个自由度——这解释了为什么只有电势差可观测。

步骤 2：写出 A^{T}，它就是 KCL。 A^{T} 是 4×5：

$$A^{\mathsf{T}} = \begin{bmatrix} -1 & 0 & 0 & -1 & -1 \\ 1 & -1 & 0 & 0 & 0 \\ 0 & 1 & -1 & 0 & 1 \\ 0 & 0 & 1 & 1 & 0 \end{bmatrix}_{4\times 5}$$

第 1 行给出节点 1 的方程 $-y_1 - y_4 - y_5 = 0$，即"连到节点 1 的三条边电流之和为零"。**逐行都是"流入 = 流出"。**

步骤 3：求 $N(A^{\mathsf{T}})$。 由秩–零化度定理 $\dim N(A^{\mathsf{T}}) = m - r = 5 - 3 = 2$。解 $A^{\mathsf{T}} y = \mathbf{0}$，一组漂亮的基是

$$y^{(1)} = \begin{bmatrix} 1 \\ 1 \\ 1 \\ -1 \\ 0 \end{bmatrix} \text{（正方形环 } 1 \to 2 \to 3 \to 4 \to 1\text{）}, \qquad y^{(2)} = \begin{bmatrix} 1 \\ 1 \\ 0 \\ 0 \\ -1 \end{bmatrix} \text{（三角形环 } 1 \to 3 \to 2 \to 1\text{）}$$

逐个节点验算 $A^{\mathsf{T}} y^{(1)}$：

$$\text{节点 } 1:\ -1-(-1)-0 = 0\ \checkmark \quad \text{节点 } 2:\ 1-1 = 0\ \checkmark$$

$$\text{节点 } 3:\ 1-1+0 = 0\ \checkmark \quad \text{节点 } 4:\ 1+(-1) = 0\ \checkmark$$

逐个节点验算 $A^{\mathsf{T}} y^{(2)}$：

$$\text{节点 } 1:\ -1-0-(-1) = 0\ \checkmark \quad \text{节点 } 2:\ 1-1 = 0\ \checkmark$$

$$\text{节点 } 3:\ 1-0+(-1) = 0\ \checkmark \quad \text{节点 } 4:\ 0+0 = 0\ \checkmark$$

两者都通过，且线性无关（$y^{(1)} - y^{(2)} = (0,0,1,-1,1)^{\mathsf{T}} \neq \mathbf{0}$），维数正好 2，故构成 $N(A^{\mathsf{T}})$ 的一组基。

> **符号要点**：追踪回路时，**与行进方向相反**的边要取 -1。正方形环上 e_4 的方向是 $1 \to 4$，而回路走的是 $4 \to 1$，所以 $y^{(1)}$ 第 4 个分量是 -1。这是本讲最容易算错的地方——务必用 $A^{\mathsf{T}} y = \mathbf{0}$ 逐节点回代验证。

步骤 4：欧拉公式。 把 $\dim N(A) = n - r$、$\dim N(A^{\mathsf{T}}) = m - r$ 相减：

$$\dim N(A) - \dim N(A^{\mathsf{T}}) = (n - r) - (m - r) = n - m$$

移项即得**恒等式** $\dim N(A) - \dim N(A^{\mathsf{T}}) + m = n$。代入本图：$1 - 2 + 5 = 4$ ✓（两边都是自动相等，不算独立信息）。

真正有内容的是把 $\dim N(A^{\mathsf{T}})$ 认作回路数 ℓ。因为 $\dim N(A^{\mathsf{T}}) = m - r$，而连通图 $r = n - 1$，所以

$$\ell = m - (n-1) = m - n + 1 \quad \Longrightarrow \quad \boxed{\#\text{nodes} - \#\text{edges} + \#\text{loops} = n - m + \ell = 1}$$

本图：$4 - 5 + 2 = 1$ ✓。这就是**欧拉公式**的图论形式（凸多面体 $V - E + F = 2$ 的近亲）。几何解读：n 个节点的一棵**生成树（spanning tree）**恰有 $n-1$ 条边，每加回一条树外的边就闭合出一个新回路，故 $\ell = m - (n-1)$。

【计算机制解说】：为什么"$A^{\mathsf{T}}y = 0$ 的解 = 回路"？三层论证。① **回路满足 KCL**：沿环走一圈每节点一进一出，净流量为零，故 $\{\text{回路}\} \subseteq N(A^{\mathsf{T}})$。② **反之亦然**：若 $y \in N(A^{\mathsf{T}})$ 在某边非零，从该边出发，KCL 迫使两端点另有非零边接续；有限步内必回到已访问节点，形成回路。按比例扣掉该回路的电流（合法组合），y 的非零边数严格减少。反复消减，y 写成若干回路之和，故 $N(A^{\mathsf{T}}) \subseteq \{\text{回路组合}\}$。③ **独立回路数 $= m - n + 1$**：先取生成树（$n-1$ 条边），每加一条树外边恰好闭合一个新回路，且这些回路线性无关（每条树外边只出现在它对应的那个回路里）。三层合起来：**$N(A^{\mathsf{T}})$ 就是回路空间，KCL 的解就是环流**——水可以在管道里绕圈打转，但不在接头处堆积。

演示 3：$L = A^{\mathsf{T}}A$ 与图拉普拉斯

步骤 1：算出 L（$L_{ij} = \sum_{k=1}^{5} A_{ki}A_{kj}$，即 A 的第 i, j 列的内积）：

$$L = A^{\mathsf{T}}A = \begin{bmatrix} 3 & -1 & -1 & -1 \\ -1 & 2 & -1 & 0 \\ -1 & -1 & 3 & -1 \\ -1 & 0 & -1 & 2 \end{bmatrix}_{4\times 4}$$

步骤 2：读数。对角元 $(3,2,3,2)$ 正是四节点度数：节点 1 连 e_1, e_4, e_5（3 条）；节点 2 连 e_1, e_2（2 条）；节点 3 连 e_2, e_3, e_5（3 条）；节点 4 连 e_3, e_4（2 条）✓。非对角元：节点 1–2 有边 ⇒ $L_{12} = -1$ ✓；节点 1–3 有对角线 ⇒ $L_{13} = -1$ ✓；节点 2–4 **不直接相连** ⇒ $L_{24} = 0$ ✓。这印证

$$L_{jj} = \text{度数}, \qquad L_{ij} = \begin{cases} -(\text{节点 } i,j \text{ 间的边数}), & i \neq j \\ \text{度数}, & i = j \end{cases}$$

步骤 3：验证 $L\mathbf{1} = \mathbf{0}$ 与秩。每行和为零（度数减去邻居个数）：

$$L\begin{bmatrix}1\\1\\1\\1\end{bmatrix} = \begin{bmatrix} 3-1-1-1 \\ -1+2-1+0 \\ -1-1+3-1 \\ -1+0-1+2 \end{bmatrix} = \begin{bmatrix}0\\0\\0\\0\end{bmatrix} \checkmark$$

计算得 $\mathbf{rank}(L) = 3$，故 $\dim N(L) = 1$，$N(L) = \mathbf{span}\{\mathbf{1}\}$。

步骤 4：能量恒等式的数值验算（最漂亮的一步）。取 $x = (3,1,4,2)^{\mathsf{T}}$：

$$Lx = \begin{bmatrix} 3\cdot 3 - 1 - 4 - 2 \\ -3 + 1\cdot 2 - 4 + 0 \\ -3 - 1 + 3\cdot 4 - 2 \\ -3 + 0 - 4 + 2\cdot 2 \end{bmatrix} = \begin{bmatrix} 2 \\ -5 \\ 6 \\ -3 \end{bmatrix}, \qquad x^{\mathsf{T}}Lx = 3(2) + 1(-5) + 4(6) + 2(-3) = 6 - 5 + 24 - 6 = 19$$

另一条路，按边求相邻节点差的平方和（$x_1 = 3, x_2 = 1, x_3 = 4, x_4 = 2$）：

边	端点差	平方
$e_1 : 1\text{–}2$	$1 - 3 = -2$	4
$e_2 : 2\text{–}3$	$4 - 1 = \ \ 3$	9
$e_3 : 3\text{–}4$	$2 - 4 = -2$	4
$e_4 : 4\text{–}1$	$3 - 2 = \ \ 1$	1
$e_5 : 1\text{–}3$	$4 - 3 = \ \ 1$	1

$$\sum_{\text{边}} (x_j - x_i)^2 = 4 + 9 + 4 + 1 + 1 = 19 \checkmark$$

（顺便 $Ax = (-2, 3, -2, -1, 1)^{\mathsf{T}}$，$\|Ax\|^2 = 4 + 9 + 4 + 1 + 1 = 19$ ✓。）

【计算机制解说】：一行代数就够：

$$x^{\mathsf{T}}A^{\mathsf{T}}Ax = (Ax)^{\mathsf{T}}(Ax) = \|Ax\|^2 = \sum_{k=1}^{m} (\text{第 } k \text{ 条边两端之差})^2$$

这个恒等式把"L 是二阶差分"与"$\|Ax\|^2$ 是能量"焊在一起，同时给出两条结论：L 永远**半正定**（它是平方和）；$x^{\mathsf{T}}Lx=0 \iff Ax=0 \iff$ 每条边两端相等 $\iff x\in\mathbf{span}\{\mathbf{1}\}$。这独立地再次证明 $N(L)=N(A)$。连通图上 $\mathbf{1}$ 是 L 的**唯一**零特征向量——这正是谱聚类（spectral clustering）的起点。若给每条边加权 w_k（电阻倒数），则 $L_w=A^{\mathsf{T}}WA$，$W=\mathbf{diag}(w_k)$，即**加权拉普拉斯**。

演示 4：$Ax=b$ 何时有解？网络流的相容条件

步骤 1：问题的位置。 A 是 5×4 秩 3，方程 5 个、秩 3，必有 $m-r=2$ 个相容条件。由讲次 14 的 $C(A)=N(A^{\mathsf{T}})^{\perp}$，条件就是 $b\perp N(A^{\mathsf{T}})$，即**b 与两个回路基向量的内积为零**。

步骤 2：把条件写成紧凑的标量形式。 用步骤 3 的基 $y^{(1)}=(1,1,1,-1,0)$、$y^{(2)}=(1,1,0,0,-1)$：

$$b\cdot y^{(1)}=b_1+b_2+b_3-b_4=0 \quad\Longrightarrow\quad \boxed{b_4=b_1+b_2+b_3}$$

$$b\cdot y^{(2)}=b_1+b_2-b_5=0 \quad\Longrightarrow\quad \boxed{b_5=b_1+b_2}$$

这不是两个抽象条件，而是"绕回路一圈落差不累积"（基尔霍夫电压定律 KVL）。$b_4=b_1+b_2+b_3$ 是正方形环；$b_5=b_1+b_2$ 是三角形环。

步骤 3：动手验算四组 b。

(a) $b=(1,1,1,3,2)^{\mathsf{T}}$：这是 $x=(-3,-2,-1,0)$ 产生的落差（$Ax=(1,1,1,3,2)$ ✓）。检查 $b_4=3=b_1+b_2+b_3=3$ ✓，$b_5=2=b_1+b_2=2$ ✓。**有解**（程序验算 consistent = true ✓）。

(b) $b=(2,-1,-1,0,0)^{\mathsf{T}}$：$b_4=0=b_1+b_2+b_3=0$ ✓，但 $b_5=0\neq b_1+b_2=1$ ✗。三角形环条件失败 ⇒ **无解**（程序验算 consistent = false ✓）。直觉：绕三角形转一圈有净环流，任何电势场都做不到。

(c) $b=(1,0,0,0,0)^{\mathsf{T}}$：$b_4=0\neq b_1+b_2+b_3=1$ ✗ ⇒ **无解** ✓。只有一条边有落差，绕一圈回不到原值。

(d) $b=(1,-1,2,-2,0)^{\mathsf{T}}$：$b_4=-2\neq 1-1+2=2$ ✗ ⇒ **无解** ✓。

步骤 4：对偶视角——节点空间的相容条件。 考虑另一个方程 $A^{\mathsf{T}}y=f$（f 是各节点注入的电流，求电流 y）。A^{T} 是 4×5 秩 3，同样差 2 个条件。这次给条件的是 $N(A)$：$f\perp N(A)=\mathbf{span}\{\mathbf{1}\}$，即

$$\boxed{A^{\mathsf{T}}y=f \text{ 有解} \iff \textstyle\sum_j f_j=0}$$

（"注入节点的总电流必须为零"——这正是 KCL 的能量表述。）验算：$f=(2,-1,-1,0)$，和 $=0$，**有解** ✓；$f=(1,1,1,1)$，和 $=4\neq 0$，**无解** ✓。

步骤 5：注意这个对称性。 两边的条件长得不一样，容易记混：

```
方程              所在空间       相容条件                    含义
------------------------------------------------------------------
Ax = b         b ∈ R^m        b ⊥ N(A^T)  (2 个条件)    绕每个回路落差不累积
                              ⇔ b4=b1+b2+b3, b5=b1+b2

A^T y = f      f ∈ R^n        f ⊥ N(A)    (1 个条件)    注入总量为零
                              ⇔ Σ f_j = 0
------------------------------------------------------------------
注意 R^m 里的条件数 = dim N(A^T) = 2，R^n 里的条件数 = dim N(A) = 1
```

【计算机制解说】：为什么"回路上的行组合给出障碍"？把 A 的行按正方形环 $1\to 2\to 3\to 4\to 1$ **带方向**相加（e_4 逆行取负号）：

$$\mathbf{row}_1+\mathbf{row}_2+\mathbf{row}_3-\mathbf{row}_4=(-1,1,0,0)+(0,-1,1,0)+(0,0,-1,1)-(-1,0,0,1)=\mathbf{0}$$

回路上的行线性组合恰好为零向量，所以任何 $b=Ax$ 都必须满足同一组合给出 0，这就是 $b\cdot y^{(1)}=0$。同理三角形环给出 $b\cdot y^{(2)}=0$。而节点空间那一边，$\mathbf{1}^{\mathsf{T}}(A^{\mathsf{T}}y)=(\mathbf{1}^{\mathsf{T}}A^{\mathsf{T}})y=(A\mathbf{1})^{\mathsf{T}}y=\mathbf{0}^{\mathsf{T}}y=0$，左边恒为 0，右边必须是 $\mathbf{1}^{\mathsf{T}}f=\sum f_j$——所以 $\sum f_j=0$ 是必要条件；维数计数说明它也是充分的。

演示 5：电阻网络——"接地"如何把半正定变成正定（讲次 16 的预告）

步骤 1：物理设定。 把演示 1 的图当作**单位电阻网络**（每条边电导为 1）。在节点 1 注入 1 安培电流、从节点 4 抽出 1 安培，即 $f=(1,0,0,-1)^{\mathsf{T}}$。由演示 4 步骤 4，$\sum f_j=0$ 保证有解。但 L 是奇异的（$N(L)=\mathbf{span}\{\mathbf{1}\}$），解不唯一。

步骤 2：接地固定电势。 令 $x_4=0$（把节点 4 接地）。删去 L 的第 4 行第 4 列，得到 3×3 的**接地拉普拉斯**：

$$L_{\text{ground}}=\begin{bmatrix}3&-1&-1\\-1&2&-1\\-1&-1&3\end{bmatrix},\qquad \text{右端 } f_{\text{red}}=\begin{bmatrix}1\\0\\0\end{bmatrix}$$

步骤 3：算行列式，判断可逆。 按第一行展开：

$$\det L_{\text{ground}} = 3\begin{vmatrix} 2 & -1 \\ -1 & 3 \end{vmatrix} - (-1)\begin{vmatrix} -1 & -1 \\ -1 & 3 \end{vmatrix} + (-1)\begin{vmatrix} -1 & 2 \\ -1 & -1 \end{vmatrix}$$

$$= 3(6-1) + 1(-3-1) - 1(1+2) = 15 - 4 - 3 = 8 \neq 0 \checkmark$$

接地删去一个自由度后，矩阵变成可逆的！

步骤 4：解出各节点电势。 解 $L_{\text{ground}} x_{\text{red}} = f_{\text{red}}$：

$$x_1 = \frac{5}{8}, \qquad x_2 = \frac{1}{2}, \qquad x_3 = \frac{3}{8}, \qquad x_4 = 0$$

回代验算（逐个方程）：

$$3\cdot\tfrac{5}{8} - 1\cdot\tfrac{1}{2} - 1\cdot\tfrac{3}{8} = \tfrac{15-4-3}{8} = \tfrac{8}{8} = 1 \checkmark \quad (\text{节点 } 1)$$

$$-1\cdot\tfrac{5}{8} + 2\cdot\tfrac{1}{2} - 1\cdot\tfrac{3}{8} = \tfrac{-5+8-3}{8} = 0 \checkmark \quad (\text{节点 } 2)$$

$$-1\cdot\tfrac{5}{8} - 1\cdot\tfrac{1}{2} + 3\cdot\tfrac{3}{8} = \tfrac{-5-4+9}{8} = 0 \checkmark \quad (\text{节点 } 3)$$

$$-1\cdot\tfrac{5}{8} + 0 - 1\cdot\tfrac{3}{8} + 2\cdot 0 = \tfrac{-5-3}{8} = -1 \checkmark \quad (\text{节点 } 4\text{，即被删去的行})$$

步骤 5：求各边电流。 $y = Ax$（单位电导，欧姆定律 $y = \Delta x$）：

$$y = Ax = \begin{bmatrix} -\frac{1}{8} \\ -\frac{1}{8} \\ -\frac{3}{8} \\ -\frac{5}{8} \\ -\frac{1}{4} \end{bmatrix} = \begin{bmatrix} -0.125 \\ -0.125 \\ -0.375 \\ -0.625 \\ -0.25 \end{bmatrix}$$

步骤 6：三重验算 KCL 与功率。

节点 1：$-y_1 - y_4 - y_5 = \frac{1}{8} + \frac{5}{8} + \frac{1}{4} = \frac{1+5+2}{8} = 1$，等于注入电流 $f_1 = 1$ ✓ 节点 2：$y_1 - y_2 = -\frac{1}{8} + \frac{1}{8} = 0 = f_2$ ✓ 节点 3：$y_2 - y_3 + y_5 = -\frac{1}{8} + \frac{3}{8} - \frac{1}{4} = \frac{-1+3-2}{8} = 0 = f_3$ ✓ 节点 4：$y_3 + y_4 = -\frac{3}{8} - \frac{5}{8} = -1 = f_4$ ✓

即 $A^{\mathsf{T}} y = f$ ✓。再看**耗散功率**：

$$\|y\|^2 = \tfrac{1+1+9+25+4}{64} = \tfrac{40}{64} = \tfrac{5}{8}$$

而 $x^{\mathsf{T}} f = \frac{5}{8}\cdot 1 + \frac{1}{2}\cdot 0 + \frac{3}{8}\cdot 0 + 0\cdot(-1) = \frac{5}{8}$ ✓。

【计算机制解说】：这个例子把三条线索拧成一股。**第一，接地 = 消去零空间。** L 半正定、奇异，零空间恰是"整体电势平移"$\mathbf{span\{1\}}$。固定一个节点的电势就是**从每个解里减去合适的常数**，从而在这个 1 维平移自由度上取定唯一代表。删掉第 4 行第 4 列后，剩下的矩阵对任意非零 z 都有 $z^{\mathsf{T}} L_{\text{ground}} z > 0$，故**严格正定**（$\det = 8 > 0$ 是它的一个表现，也是讲次 26 的判据：所有顺序主子式为正）。**第二，能量恒等式 $\|y\|^2 = x^{\mathsf{T}} L x = x^{\mathsf{T}} f$ 就是焦耳定律。** 输入的电功率 $x^{\mathsf{T}} f$ 恰好等于各电阻上耗散的 $\sum y_k^2$——这是 $L = A^{\mathsf{T}} A$ 的物理化身。**第三，$\det = 8$ 的来源：矩阵–树定理（Matrix–Tree Theorem）。** $\det L_{\text{ground}}$ 恰好等于图的**生成树数目**。本图 5 条边中任选 3 条共 $\binom{5}{3} = 10$ 种选法，其中只有两种含环：

```
含环的选择（2 种）：  {e1,e2,e5}    ← 三角形 1–2–3–1
                      {e3,e4,e5}    ← 三角形 1–3–4–1

生成树（8 种，4 个节点全连通且无环）：
  e1,e2,e3     e1,e2,e4     e1,e3,e4     e1,e3,e5
  e1,e4,e5     e2,e3,e4     e2,e3,e5     e2,e4,e5
```

$10 - 2 = 8$ ✓，与 $\det L_{\text{ground}} = 8$ 精确吻合。**一个 3×3 行列式就数清了图的生成树**——这是线性代数与组合数学最著名的联姻之一，也是 $L = A^{\mathsf{T}} A$ 结构信息量的最佳体现。

演示 6：把演示 4 的无解例子交给最小二乘

步骤 1：取一个无解之例。 用演示 4 步骤 3 的 (c)：$b = (1,0,0,0,0)^{\mathsf{T}}$。已验算它**无解**（$b \cdot y^{(1)} = 1 \neq 0$）。退而求

$$\min_x \|Ax - b\|^2$$

步骤 2：写正规方程 $Lx = A^{\mathsf{T}} b$。 逐列计算 $A^{\mathsf{T}} b$（A 的第 1 列是 $(-1,0,0,-1,-1)^{\mathsf{T}}$）：

$$(A^{\mathsf{T}}b)_j=\sum_{k=1}^{5}A_{kj}b_k=A_{1j}b_1=A_{1j}\implies A^{\mathsf{T}}b=(-1,\,1,\,0,\,0)^{\mathsf{T}}$$

这里有一步极易出错的计算：b 只有第一个分量非零，容易只记住 $A_{11}=-1$ 而漏掉 $A_{12}=+1$。正确答案是 $(-1,1,0,0)^{\mathsf{T}}$，不是 $(-1,0,0,0)^{\mathsf{T}}$。

步骤 3：解方程（仍固定 $x_4=0$）。 接地后的 3×3 系统：

$$\begin{bmatrix}3&-1&-1\\-1&2&-1\\-1&-1&3\end{bmatrix}\begin{bmatrix}x_1\\x_2\\x_3\end{bmatrix}=\begin{bmatrix}-1\\1\\0\end{bmatrix}$$

解得

$$x_1=-\tfrac{1}{8},\qquad x_2=\tfrac{1}{2},\qquad x_3=\tfrac{1}{8},\qquad x_4=0$$

回代验算（三个方程）：

$$3\left(-\tfrac{1}{8}\right)-\tfrac{1}{2}-\tfrac{1}{8}=\tfrac{-3-4-1}{8}=-1\ \checkmark$$

$$-\left(-\tfrac{1}{8}\right)+2\left(\tfrac{1}{2}\right)-\tfrac{1}{8}=\tfrac{1+8-1}{8}=1\ \checkmark$$

$$-\left(-\tfrac{1}{8}\right)-\tfrac{1}{2}+3\left(\tfrac{1}{8}\right)=\tfrac{1-4+3}{8}=0\ \checkmark$$

步骤 4：算预测值与残差。

$$Ax=\left(\tfrac{5}{8},\,-\tfrac{3}{8},\,-\tfrac{1}{8},\,\tfrac{1}{8},\,\tfrac{1}{4}\right)^{\mathsf{T}},\qquad e=b-Ax=\left(\tfrac{3}{8},\,\tfrac{3}{8},\,\tfrac{1}{8},\,-\tfrac{1}{8},\,-\tfrac{1}{4}\right)^{\mathsf{T}}$$

$$\|e\|^2=\frac{9+9+1+1+4}{64}=\frac{24}{64}=\frac{3}{8}$$

步骤 5：验证 $e\perp C(A)$（用 $A^{\mathsf{T}}e=0$，逐节点）。

$$\text{节点 }1:\ -e_1-e_4-e_5=-\tfrac{3}{8}+\tfrac{1}{8}+\tfrac{1}{4}=\tfrac{-3+1+2}{8}=0\ \checkmark$$

$$\text{节点 }2:\ e_1-e_2=\tfrac{3}{8}-\tfrac{3}{8}=0\ \checkmark$$

$$\text{节点 }3:\ e_2-e_3+e_5=\tfrac{3}{8}-\tfrac{1}{8}-\tfrac{1}{4}=\tfrac{3-1-2}{8}=0\ \checkmark$$

$$\text{节点 }4:\ e_3+e_4=-\tfrac{1}{8}+\tfrac{1}{8}=0\ \checkmark$$

$A^{\mathsf{T}}e=0$ 全部通过 $\Rightarrow e\in N(A^{\mathsf{T}})=C(A)^{\perp}\Rightarrow$ 误差垂直于列空间。

步骤 6：能量核对。 $x^{\mathsf{T}}(A^{\mathsf{T}}b)=\|Ax\|^2+\|e\|^2$？验证：

$$\|Ax\|^2=\frac{25+9+1+1+4}{64}=\frac{40}{64}=\frac{5}{8},\qquad \|e\|^2=\frac{24}{64},\qquad \frac{40}{64}+\frac{24}{64}=\frac{64}{64}=1$$

而 $\|b\|^2=1$ ✓。**正交分解把 $\|b\|^2$ 精确拆成"模型解释的部分 $\|Ax\|^2$"与"残差部分 $\|e\|^2$"**——这就是统计学里"总平方和 = 回归平方和 + 残差平方和"的几何本质。

矩阵分解的核心思想

本讲不引入新分解，但把已有分解全部点亮：

1. $L=A^{\mathsf{T}}A$。这与讲次 16 最小二乘的正规方程 $A^{\mathsf{T}}A\hat{x}=A^{\mathsf{T}}b$ **是同一个矩阵**。在弹簧/电阻网络里它就是刚度矩阵。L 对称、半正定、对角元为度数、$\mathbf{rank}(L)=\mathbf{rank}(A)=n-1$：它是讲次 26 正定矩阵家族最自然的活样本。
2. $A=CR$（讲次 11）。取 $R=\mathbf{RREF}(A)$ 的前 3 个非零行、C 取 A 的前 3 列（对应 e_1,e_2,e_3，构成 1–2–3–4 的链，**无回路**，是生成树）：

$$C=\begin{bmatrix}-1&1&0\\0&-1&1\\0&0&-1\\-1&0&0\\-1&0&1\end{bmatrix},\qquad R=\begin{bmatrix}1&0&0&-1\\0&1&0&-1\\0&0&1&-1\end{bmatrix},\qquad CR=A\ \checkmark$$

物理含义：**每条边的落差都能用生成树上的落差组合出来**；树外的边（e_4,e_5）是"多余"的，它们恰好形成回路。秩 = 生成树的边数，非常直观。 3. **秩–零化度定理的化身**：$r=n-1$ 与 $\ell=m-r$ 合起来就是 $n-m+\ell=1$。四个子空间的维数表：

```
子空间      维数        本图数值        物理含义
------------------------------------------------------------------
C(A)        r           3               可实现的边电势差（KVL 相容）
N(A^T)      m − r       2 = m−n+1       回路空间（KCL 环流）
C(A^T)      r           3               节点电势能张成的方向 = N(A)^perp
N(A)        n − r       1 = n−m+1       整体电势平移（等电势）
------------------------------------------------------------------
R^n = C(A^T) ⊕ N(A):   3 + 1 = 4 = n
R^m = C(A)   ⊕ N(A^T): 3 + 2 = 5 = m
```

与其他讲次的关联

- **回顾讲次 10（四个基本子空间）**：本讲是那张"大图"最具体的实现——$N(A)$ 是 1 维常数电势，$N(A^{\mathsf{T}})$ 是回路，尺寸全部可数可验。请把讲次 10 的 $r+(n-r)=n$、$r+(m-r)=m$ 对照本讲的 $(3+1=4,\ 3+2=5)$。
- **回顾讲次 11（$A=CR$）**：关联矩阵的 R 由生成树决定，秩 = 树的边数。
- **通向讲次 14（正交）**：本讲的 $C(A)\perp N(A^{\mathsf{T}})$ 与 $C(A^{\mathsf{T}})\perp N(A)$ 正是那一讲的核心定理；这里先给了物理直觉，那里补严格证明。
- **通向讲次 16（最小二乘）**：$L=A^{\mathsf{T}}A$ 出场。当 $Ax=b$ 无解（如上例 (b)(c)(d)）时退而求 $\min\|Ax-b\|^2$，正规方程 $A^{\mathsf{T}}Ax=A^{\mathsf{T}}b$ 永远有解（因为 $A^{\mathsf{T}}b\in C(A^{\mathsf{T}})=C(A^{\mathsf{T}}A)$）。在电阻网络里这就是最小能量原理。
- **通向讲次 26（正定矩阵）**：$x^{\mathsf{T}}Lx=\|Ax\|^2\geq 0$，取等仅当 $x=c\mathbf{1}$。固定某个节点的电势（消去那个自由度）即得严格正定矩阵。

关键要点

1. **构造**：行 = 边，列 = 节点，每行恰有一个 $+1$、一个 -1。（Strang §8.2 用 $m\times n$；本笔记全程如此，勿中途切换。）
2. **连通** $\iff \mathbf{rank}(A)=n-1$；$k$ 个连通块 $\iff \mathbf{rank}(A)=n-k$。
3. **四个子空间的名字**：$N(A)$ = 等电势；$N(A^{\mathsf{T}})$ = 回路空间（KCL）；$C(A^{\mathsf{T}})$ = 节点势方向；$C(A)$ = 相容的边落差。
4. **欧拉公式**：连通图 $n-m+\ell=1$，其中 $\ell=m-n+1=\dim N(A^{\mathsf{T}})=m-r$。
5. $L=A^{\mathsf{T}}A$：$L_{jj}=$ 度数，$L_{ij}=-1$（有边）；$L\mathbf{1}=\mathbf{0}$；$x^{\mathsf{T}}Lx=\|Ax\|^2=\sum(\Delta x)^2\geq 0$。
6. **相容判据（务必分清两边）**：$Ax=b$ 有解 $\iff b\perp N(A^{\mathsf{T}})$（$\mathbb{R}^m$ 里 $m-r$ 个条件）；$A^{\mathsf{T}}y=f$ 有解 $\iff f\perp N(A)\iff \sum f_j=0$（$\mathbb{R}^n$ 里 $n-r$ 个条件）。

常见误区与注意事项

1. **把行/列角色搞反。** 若取 A 为 $n\times m$（列 = 边），则 $N(A)$ 变成回路、$N(A^{\mathsf{T}})$ 变成等电势，索引全部错位。本笔记全程 $m\times n$（行 = 边）。
2. **以为"列和为 0"说明行相关。** 恰恰相反：$\sum_i \mathbf{col}_i=\mathbf{0}$ 说明**列**相关（$\dim N(A)\geq 1$）。行之间的关系要用回路上的行组合去查。
3. **把 $N(A^{\mathsf{T}})$ 说成 $\mathbb{R}^n$ 里的子空间。** A^{T} 是 $n\times m$，故 $N(A^{\mathsf{T}})\subseteq\mathbb{R}^m$（边空间，长度 $=m=5$）。$\mathbb{R}^n$ 里的是 $N(A)$ 与 $C(A^{\mathsf{T}})$。行空间 $C(A^{\mathsf{T}})\subseteq\mathbb{R}^n$，不是 $\mathbb{R}^m$。
4. **混淆 $\dim N(A)=n-r$ 与 $\dim N(A^{\mathsf{T}})=m-r$。** 本讲数字 $n-r=1$、$m-r=2$，写反会得出"1 个回路"的错误结论。
5. **把 $\sum b_k=0$ 当成 $Ax=b$ 的相容条件。 这是错的！** 反例：$b=(1,1,1,3,2)$ 满足 $\sum b_k=8\neq 0$，但它**有解**。$\sum f_j=0$ 是**另一个**方程 $A^{\mathsf{T}}y=f$ 的条件（见关键要点 6 的对照表）。
6. **回路向量符号写错。** 追踪回路时必须核对每条边方向是否与行进方向一致，**反向的边取 -1**。写完后一定用 $A^{\mathsf{T}}y=\mathbf{0}$ 逐节点回代验证。
7. **以为"图连通"只是画图的事。** 它代数上就是 $\mathbf{rank}(A)=n-1$、L 只有一个零特征值。若图分成两块（如 1–2 与 3–4），则 $\dim N(A)=2$，L 有重零特征值，$\ell=m-n+2$。

思考题（带答案）

Q1.（纯计算） 取**路径图** P_4：节点 $1,2,3,4$ 依次相连，只有 3 条边 $e_1=1-2$、$e_2=2-3$、$e_3=3-4$。写出 A（3×4），求 $\mathbf{rank}(A)$、$N(A)$、$N(A^{\mathsf{T}})$、$L=A^{\mathsf{T}}A$，并用欧拉公式验证。

▸ 答案

$$>\ A=\begin{bmatrix}-1&1&0&0\\0&-1&1&0\\0&0&-1&1\end{bmatrix}_{3\times 4}\ >$$

秩：三行主元位置互不相同，线性无关，$\mathbf{rank}(A)=3=n-1$ ✓（连通）。

$N(A)$：解 $x_1=x_2=x_3=x_4$，故 $N(A)=\mathbf{span}\{(1,1,1,1)^{\mathsf{T}}\}$，$\dim=1$。

$N(A^{\mathsf{T}})$：$m-r=3-3=0$，故 $N(A^{\mathsf{T}})=\{\mathbf{0}\}$。**路径图是一棵树，没有回路。** 验算 $A^{\mathsf{T}}y=\mathbf{0}$：

$$> -y_1 = 0, \quad y_1 - y_2 = 0, \quad y_2 - y_3 = 0, \quad y_3 = 0 \implies y = \mathbf{0} \checkmark >$$

> $L = A^{\mathsf{T}}A$：

$$> L = \begin{bmatrix} 1 & -1 & 0 & 0 \\ -1 & 2 & -1 & 0 \\ 0 & -1 & 2 & -1 \\ 0 & 0 & -1 & 1 \end{bmatrix}, > \qquad \mathbf{diag}(L) = (1,2,2,1) >$$

> 度数确实是 $(1,2,2,1)$ ✓（两端度数 1，中间两个度数 2）。$L\mathbf{1} = \mathbf{0}$ ✓，$\mathbf{rank}(L) = 3$ ✓。
>
> **欧拉公式**：$n - m + \ell = 4 - 3 + 0 = 1$ ✓。

Q2.（概念理解） 有人说："$N(A^{\mathsf{T}})$ 里的向量 y 代表节点上的电势，因为 A^{T} 把边上的量变成节点上的量。" 这句话错在哪里？请用本讲的 4 节点图给出反例数据。

> ▸ **答案**
>
> **错在两处。**
>
> 第一，A^{T} 确实把 $\mathbb{R}^m$（边空间）映到 $\mathbb{R}^n$（节点空间），但 $(A^{\mathsf{T}}y)_j$ 的物理含义是**节点 j 的净流出电流**，不是电势。真正的节点电势是 $x \in \mathbb{R}^n$，它与边量的关系是 $y = Ax$（电势差）。
>
> 第二，$N(A^{\mathsf{T}})$ 是"净流出为零"的**边电流**，即环流，它是**边空间**里的量（长度 $m = 5$），不是节点上的量。
>
> **反例数据**：取 $y^{(1)} = (1,1,1,-1,0)^{\mathsf{T}} \in N(A^{\mathsf{T}})$。它是 5 维边向量（每条边一个电流值），满足 $A^{\mathsf{T}}y^{(1)} = \mathbf{0}$（每个节点净流量为零）。若把它当节点电势，长度就对不上（需要 4 个分量，它是 5 个）。
>
> 正确的物理链条是：

$$> x\,(\text{节点电势}, n=4) \xrightarrow{A} Ax\,(\text{边电势差}, m=5) \xrightarrow{\text{欧姆定律}} y\,(\text{边电流}, m=5) >$$

> $A^{\mathsf{T}}y = \mathbf{0}$ 是电流层面的守恒律（KCL），与电势无关。另外注意 $\mathbf{1} \notin N(A^{\mathsf{T}})$（$A^{\mathsf{T}}\mathbf{1} = (-3,0,1,2)^{\mathsf{T}} \neq \mathbf{0}$），所以"节点常数电势"也不在回路空间里——两件事彻底分开。

Q3.（概念 + 计算） 在 4 节点图中**删掉一条边**：先删树边 $e_2 = 2{-}3$，再改成删树外边 e_5（对角线）。分别说明 $\mathbf{rank}$、$\dim N(A)$、$\dim N(A^{\mathsf{T}})$ 与欧拉公式，并指出哪种删除"更危险"。

> ▸ **答案**
>
> **情形一：删掉 e_2**，剩下 e_1, e_3, e_4, e_5（$1{-}2$，$3{-}4$，$4{-}1$，$1{-}3$），$m = 4$，$n = 4$。图**仍连通**（$1{-}2$ 挂着节点 2，$1{-}3{-}4$ 连着其余）。

$$> A' = \begin{bmatrix} -1 & 1 & 0 & 0 \\ 0 & 0 & -1 & 1 \\ -1 & 0 & 0 & 1 \\ -1 & 0 & 1 & 0 \end{bmatrix}_{4\times 4} >$$

> 程序验算：$\mathbf{rank}(A') = 3 = n - 1$ ✓（每行 ± 1 故行和为 0，$A'\mathbf{1} = \mathbf{0}$ 保证奇异；而任取三行独立）。于是

$$> \dim N(A') = 4 - 3 = 1, \qquad \dim N(A'^{\mathsf{T}}) = 4 - 3 = 1 >$$

> 回路数 $= m - n + 1 = 4 - 4 + 1 = 1$ ✓。剩下唯一的回路是三角形 $1 \to 3 \to 4 \to 1$（e_5, e_3, e_4），对应基向量

$$> (y_{e_1}, y_{e_3}, y_{e_4}, y_{e_5}) = (0,\ 1,\ -1,\ 1) >$$

> 验证：节点 1：$-y_{e_1} - y_{e_4} - y_{e_5} = -0 - (-1) - 1 = 0$ ✓；节点 3：$-y_{e_3} + y_{e_5} = -1 + 1 = 0$ ✓；节点 4：$y_{e_3} + y_{e_4} = 1 - 1 = 0$ ✓；节点 2：$y_{e_1} = 0$ ✓。**欧拉**：$4 - 4 + 1 = 1$ ✓。
>
> **情形二：删掉 e_5**，剩下正方形 $1{-}2{-}3{-}4{-}1$，$m = 4$。

$$> A'' = \begin{bmatrix} -1 & 1 & 0 & 0 \\ 0 & -1 & 1 & 0 \\ 0 & 0 & -1 & 1 \\ -1 & 0 & 0 & 1 \end{bmatrix}, \qquad \mathbf{rank}(A'') = 3 >$$

> $\dim N(A'') = 1$（常数电势），$\dim N(A''^{\mathsf{T}}) = 4 - 3 = 1$，回路基向量 $(1,1,1,-1)$（对应正方形的四条边），验证 $A''^{\mathsf{T}}(1,1,1,-1)^{\mathsf{T}} = \mathbf{0}$ ✓。**欧拉**：$4 - 4 + 1 = 1$ ✓。
>
> **结论**：两次删除都把 m 从 5 降到 4、秩保持 $n-1$、回路数从 2 降到 1。**但删树边更危险**：若删的是**割边（bridge）**，例如路径图中删掉中间的 e_2，图就断成两块，秩降到 $n-2$、$\dim N(A)$ 升到 2、$\dim N(A^{\mathsf{T}})$ 变成 0。本题中 e_2 恰好不是割边（删后图仍连通），所以侥幸无恙。
> **$N(A)$ 的维数 = 连通块数**，这是判断连通性的代数判据。

Lecture 14: Orthogonal Vectors and Subspaces

概述

本讲把"垂直"这个几何直觉升级成线性代数的核心工具。先定义**正交向量** $v^{\mathsf{T}}w = 0$ 与勾股定理；再证明 $Ax = \mathbf{0}$ 的解自动垂直于 A 的每一行，于是 $N(A) \perp C(A^{\mathsf{T}})$；然后定义**正交子空间**与**正交补（orthogonal complement）**，强调"正交"弱于"正交互补"；最后把讲次 10 的四个基本子空间**升级为正交分解** $\mathbb{R}^n = C(A^{\mathsf{T}}) \oplus N(A)$，并证明 $N(A^{\mathsf{T}}A) = N(A)$、$\mathbf{rank}(A^{\mathsf{T}}A) = \mathbf{rank}(A)$——这是讲次 16 最小二乘的全部地基。

核心概念的几何直觉

正交向量

- **定义与目的**：$v, w \in \mathbb{R}^n$ 正交，指 $v^{\mathsf{T}}w = \sum_i v_i w_i = 0$。（零向量与任何向量正交，但用"垂直"形容它有点勉强。）
- **几何直觉（它在空间中是什么样子？）**：夹角 90°。$\mathbb{R}^2$ 中 $v^{\mathsf{T}}w = \|v\|\|w\|\cos\theta$，故 $v^{\mathsf{T}}w = 0$ 且 $v, w \neq \mathbf{0}$ 等价于 $\theta = 90°$。**内积是"夹角探测器"，零内积就是"互不干扰"。**
- **具体示例**：$v = (1,2,2)^{\mathsf{T}}$，$w = (2,-2,1)^{\mathsf{T}}$。$v^{\mathsf{T}}w = 2 - 4 + 2 = 0$ ✓，且 $\|v\|^2 = 9$、$\|w\|^2 = 9$。

勾股定理的向量形式

- **定义与目的**：$v \perp w \iff \|v+w\|^2 = \|v\|^2 + \|w\|^2$（**双向**）。一般式 $\|v+w\|^2 = \|v\|^2 + 2v^{\mathsf{T}}w + \|w\|^2$。
- **几何直觉（它在空间中是什么样子？）**：两直角边 v, w，斜边 $v+w$。多出来的 $2v^{\mathsf{T}}w$ 就是"不垂直产生的交叉项"。**正交 = 交叉项消失 = 长度可简单相加（能量可加）**——这是整个正交理论（投影、最小二乘、SVD）的物理来源。
- **具体示例**：上例 $v+w = (3,0,3)$，$\|v+w\|^2 = 18 = 9+9$ ✓。反例：$v = (3,1)$，$w = (-1,2)$，$v^{\mathsf{T}}w = -1$，$v+w = (2,3)$，$\|v+w\|^2 = 13$ 而 $\|v\|^2 + \|w\|^2 = 15$，差 $2 = 2v^{\mathsf{T}}w$ ✓。

正交子空间

- **定义与目的**：$V \perp W$ 指**每一个** $v \in V$ 与**每一个** $w \in W$ 都正交。这是"全对全"的强要求，不是"存在一对正交向量"。
- **几何直觉（它在空间中是什么样子？）**：$\mathbb{R}^3$ 中一条直线与一个平面正交（直线垂直于平面内每条过交点的直线）；但 $\mathbb{R}^3$ 中两条垂直的**直线**也彼此正交（虽然都是 1 维）。
- **具体示例**：$V = \mathbf{span}\{(1,1,1)\}$，$W = \{x+y+z=0\}$。取 W 的基 $(1,-1,0)$、$(1,1,-2)$：$(1,1,1)\cdot(1,-1,0) = 0$ ✓，$(1,1,1)\cdot(1,1,-2) = 1+1-2 = 0$ ✓。

正交补（orthogonal complement）$V^{\perp}$

- **定义与目的**：$V^{\perp} = \{w \in \mathbb{R}^n : w^{\mathsf{T}}v = 0 \text{ 对一切 } v \in V\}$。它是"所有与整个 V 正交的向量"，**本身是子空间**（若干齐次方程的解集，即某矩阵的零空间）。
- **几何直觉（它在空间中是什么样子？）**：V 与 $V^{\perp}$ **互补地铺满整个空间**：$\dim V + \dim V^{\perp} = n$，且 $V \cap V^{\perp} = \{\mathbf{0}\}$。所以 $V^{\perp}$ 不只是"垂直于 V"，而是"垂直于 V 且**恰好够大**"——刚好补齐到 n 维。
- **具体示例**：$V = \mathbf{span}\{(1,1,1)\} \subseteq \mathbb{R}^3$，$V^{\perp} = \{x+y+z=0\}$，$1+2=3$ ✓。

正交 vs 正交互补（本讲最关键的一次区分）

- **定义与目的**：在 $\mathbb{R}^3$ 取 $V = \mathbf{span}\{(1,0,0)\}$（$x$ 轴）、$W = \mathbf{span}\{(0,1,0)\}$（$y$ 轴）。二者**正交**，但 $W \neq V^{\perp}$——因为 $V^{\perp} = \{x_1 = 0\}$ 是整个 yz 平面，含 $(0,0,1)$，而 $(0,0,1) \notin W$。
- **几何直觉（它在空间中是什么样子？）**：$V \perp W$ 只说"互相垂直"；$W = V^{\perp}$ 还要求"W 把 V 之外的方向全部装下"。**维数是判据**：$\dim V + \dim W = 1 + 1 = 2 \neq 3 = n$，$W$ 太小。
- **具体示例**：$(1,0,0)\cdot(0,1,0) = 0$ ✓ 故正交；但 $(0,0,1) \in V^{\perp} \setminus W$，故 W 不完整。**两条线正交，却不是彼此的正交补**——最容易掉进的坑。

计算步骤与手算演示

演示 1：勾股定理的"当且仅当"与内积恒等式

步骤 1：展开恒等式。 对任意 $v, w \in \mathbb{R}^n$：

$$\|v+w\|^2 = (v+w)^{\mathsf{T}}(v+w) = v^{\mathsf{T}}v + v^{\mathsf{T}}w + w^{\mathsf{T}}v + w^{\mathsf{T}}w = \|v\|^2 + 2v^{\mathsf{T}}w + \|w\|^2$$

（用到 $v^{\mathsf{T}}w = w^{\mathsf{T}}v$：标量的转置等于自身。）

步骤 2：正交情形。 $v = (1,2,2)^{\mathsf{T}}$，$w = (2,-2,1)^{\mathsf{T}}$：

$$v^{\mathsf{T}}w = 2 - 4 + 2 = 0, \quad \|v\|^2 = 9, \quad \|w\|^2 = 9, \quad v+w = (3,0,3)^{\mathsf{T}}$$

$$\|v+w\|^2 = 9 + 0 + 9 = 18 = 9 + 9 \checkmark$$

步骤 3：不正交情形。 $v = (3,1)^{\mathsf{T}}$，$w = (-1,2)^{\mathsf{T}}$：

$$v^{\mathsf{T}}w = -3 + 2 = -1, \quad v+w = (2,3)^{\mathsf{T}}, \quad \|v+w\|^2 = 4 + 9 = 13$$

$$\|v\|^2 + \|w\|^2 = 10 + 5 = 15, \qquad 15 - 13 = 2 = 2v^{\mathsf{T}}w \checkmark$$

步骤 4：证"反方向"。 设 $\|v+w\|^2 = \|v\|^2 + \|w\|^2$。由步骤 1 的恒等式两边相减得 $2v^{\mathsf{T}}w = 0$，即 $v \perp w$。**证毕。**

【计算机制解说】：为什么"反方向"值得强调？因为 $\|v+w\|^2 = \|v\|^2 + \|w\|^2$ 是一个关于**长度**的数值等式，它竟然**完整编码了**"$v \perp w$"这个纯几何事实。这意味着**只要知道四个长度，即使看不到向量也能判断是否垂直**——这就是极化恒等式

$$v^{\mathsf{T}}w = \tfrac{1}{4}\left(\|v+w\|^2 - \|v-w\|^2\right)$$

的来历。在数据科学里，这正是"用距离矩阵恢复内积"（MDS 多维标度），也是**核方法（kernel trick）**只用内积而永不显式写出向量的根本原因。

演示 2：$Ax = 0 \iff x \perp$ 每一行，从而 $N(A) \perp C(A^{\mathsf{T}})$

步骤 1：取一个 3×3 矩阵。

$$A = \begin{bmatrix} 1 & 2 & 3 \\ 2 & 4 & 6 \\ 1 & 1 & 2 \end{bmatrix}$$

步骤 2：用矩阵乘法看 $Ax = 0$。 把 A 按行分块 $A = \begin{bmatrix} \mathbf{r}_1^{\mathsf{T}} \\ \mathbf{r}_2^{\mathsf{T}} \\ \mathbf{r}_3^{\mathsf{T}} \end{bmatrix}$，则

$$Ax = \begin{bmatrix} \mathbf{r}_1^{\mathsf{T}}x \\ \mathbf{r}_2^{\mathsf{T}}x \\ \mathbf{r}_3^{\mathsf{T}}x \end{bmatrix}$$

所以 $Ax = 0 \iff \mathbf{r}_1^{\mathsf{T}}x = \mathbf{r}_2^{\mathsf{T}}x = \mathbf{r}_3^{\mathsf{T}}x = 0 \iff x$ **垂直于 A 的每一行**。

步骤 3：具体求解。 行化简（第 2 行 $= 2\times$第 1 行被消掉；第 3 行减去第 1 行得 $(0,-1,-1) \to (0,1,1)$）：

$$A \to \begin{bmatrix} 1 & 0 & 1 \\ 0 & 1 & 1 \\ 0 & 0 & 0 \end{bmatrix}$$

方程 $x_1 + x_3 = 0$，$x_2 + x_3 = 0$，x_3 自由。取 $x_3 = 1$：

$$x = \begin{bmatrix} -1 \\ -1 \\ 1 \end{bmatrix}, \qquad N(A) = \operatorname{span}\{(-1,-1,1)^{\mathsf{T}}\}, \quad \dim N(A) = 3 - 2 = 1$$

步骤 4：验证正交。

$$\mathbf{r}_1^{\mathsf{T}}x = 1(-1) + 2(-1) + 3(1) = 0 \checkmark$$

$$\mathbf{r}_2^{\mathsf{T}}x = 2(-1) + 4(-1) + 6(1) = 0 \checkmark$$

$$\mathbf{r}_3^{\mathsf{T}}x = 1(-1) + 1(-1) + 2(1) = 0 \checkmark$$

步骤 5：结论。 $\boldsymbol{x}$ 垂直于 A 的每一行，而行空间 $C(A^{\mathsf{T}})$ 由这些行**张成**；垂直于每个生成元就垂直于整个子空间，所以 $N(A) \perp C(A^{\mathsf{T}})$。由 $\dim C(A^{\mathsf{T}}) = 2$、$\dim N(A) = 1$、$2+1=3=n$，这不只是正交，而是互为**正交补**。

步骤 6：对偶地验证 $C(A) \perp N(A^{\mathsf{T}})$。 解 $A^{\mathsf{T}}y = \mathbf{0}$：

$$A^{\mathsf{T}} = \begin{bmatrix} 1 & 2 & 1 \\ 2 & 4 & 1 \\ 3 & 6 & 2 \end{bmatrix} \to \begin{bmatrix} 1 & 2 & 0 \\ 0 & 0 & 1 \\ 0 & 0 & 0 \end{bmatrix}$$

得 $y_1 + 2y_2 = 0$、$y_3 = 0$，取 $y_2 = 1$：$N(A^{\mathsf{T}}) = \mathbf{span}\{(-2,1,0)^{\mathsf{T}}\}$。与 A 的三列（即 $C(A)$ 的生成元）逐一内积：

$$(-2,1,0)\cdot(1,2,1) = 0, \quad (-2,1,0)\cdot(2,4,6) = 0, \quad (-2,1,0)\cdot(3,6,2) = 0 \checkmark$$

且 $\dim C(A) + \dim N(A^{\mathsf{T}}) = 2 + 1 = 3 = m$ ✓。

【计算机制解说】：为什么 $N(A) \perp C(A^{\mathsf{T}})$ 必然成立？支点只有一句话：**内积对线性组合是线性的**。技术动作是**按行分块**——把 A 分块后，$A\boldsymbol{x}$ 就是"$\boldsymbol{x}$ 与各行的内积"排成一列，$A\boldsymbol{x} = \mathbf{0}$ 逐分量读出来就是"$\boldsymbol{x}$ 与每一行正交"。接着对任意 $z \in C(A^{\mathsf{T}})$ 写成 $z = c_1\mathbf{r}_1 + c_2\mathbf{r}_2 + c_3\mathbf{r}_3$：

$$z^{\mathsf{T}}x = c_1(\mathbf{r}_1^{\mathsf{T}}x) + c_2(\mathbf{r}_2^{\mathsf{T}}x) + c_3(\mathbf{r}_3^{\mathsf{T}}x) = 0$$

注意：这一步只给出包含关系 $N(A) \subseteq C(A^{\mathsf{T}})^{\perp}$，要得到相等必须再用维数相加（见演示 4）。

演示 3：$N(A^{\mathsf{T}}A) = N(A)$ 与 $\mathbf{rank}(A^{\mathsf{T}}A) = \mathbf{rank}(A)$

步骤 1：容易的一半（$N(A) \subseteq N(A^{\mathsf{T}}A)$）。 若 $A\boldsymbol{x} = \mathbf{0}$，两边左乘 A^{T} 得 $A^{\mathsf{T}}A\boldsymbol{x} = \mathbf{0}$，故 $\boldsymbol{x} \in N(A^{\mathsf{T}}A)$ ✓。

步骤 2：关键的一半（$N(A^{\mathsf{T}}A) \subseteq N(A)$）。 设 $A^{\mathsf{T}}A\boldsymbol{x} = \mathbf{0}$。两边左乘 $\boldsymbol{x}^{\mathsf{T}}$：

$$\boldsymbol{x}^{\mathsf{T}}A^{\mathsf{T}}A\boldsymbol{x} = 0$$

左边重新结合：$\boldsymbol{x}^{\mathsf{T}}A^{\mathsf{T}}A\boldsymbol{x} = (A\boldsymbol{x})^{\mathsf{T}}(A\boldsymbol{x}) = \|A\boldsymbol{x}\|^2$。于是 $\|A\boldsymbol{x}\|^2 = 0$，而平方和为零意味着每个分量为零，即 $A\boldsymbol{x} = \mathbf{0}$ ✓。

所以 $N(A^{\mathsf{T}}A) = N(A)$，两边维数相同，故秩也相同。（这个技巧对实矩阵必须经由 $\|A\boldsymbol{x}\|^2$；不能说"$A^{\mathsf{T}}A\boldsymbol{x} = \mathbf{0}$ 所以 $A\boldsymbol{x} = \mathbf{0}$"——那一步正是需要论证的地方。）

步骤 3：验算——列相关的例子。

$$C = \begin{bmatrix} 1 & 2 \\ 2 & 4 \\ 3 & 6 \end{bmatrix}_{3\times 2}, \qquad C^{\mathsf{T}}C = \begin{bmatrix} 1 & 2 & 3 \\ 2 & 4 & 6 \end{bmatrix}\begin{bmatrix} 1 & 2 \\ 2 & 4 \\ 3 & 6 \end{bmatrix} = \begin{bmatrix} 14 & 28 \\ 28 & 56 \end{bmatrix}$$

- $\mathbf{rank}(C) = 1$（第 2 列 $= 2\times$第 1 列）。
- $\det(C^{\mathsf{T}}C) = 14\cdot 56 - 28^2 = 784 - 784 = 0 \Rightarrow C^{\mathsf{T}}C$ **奇异**，$\mathbf{rank}(C^{\mathsf{T}}C) = 1$ ✓。
- $N(C)$：三个方程都归结为 $x_1 = -2x_2$，$N(C) = \mathbf{span}\{(-2,1)^{\mathsf{T}}\}$。
- $N(C^{\mathsf{T}}C)$：$14x_1 + 28x_2 = 0$ 与 $28x_1 + 56x_2 = 0$ 同解，同样得 $(-2,1)^{\mathsf{T}}$。

两个零空间完全一样 ✓，两个秩也一样 ✓。

步骤 4：对照——列独立的例子。

$$D = \begin{bmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \end{bmatrix}_{3\times 2}, \qquad D^{\mathsf{T}}D = \begin{bmatrix} 1 & 1 & 1 \\ 1 & 2 & 3 \end{bmatrix}\begin{bmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \end{bmatrix} = \begin{bmatrix} 3 & 6 \\ 6 & 14 \end{bmatrix}$$

$\mathbf{rank}(D) = 2$（两列不成比例）；$\det(D^{\mathsf{T}}D) = 42 - 36 = 6 \neq 0 \Rightarrow$ **可逆** ✓；$N(D) = N(D^{\mathsf{T}}D) = \{\mathbf{0}\}$ ✓。

步骤 5：验证 $\boldsymbol{x}^{\mathsf{T}}A^{\mathsf{T}}A\boldsymbol{x} = \|A\boldsymbol{x}\|^2$。 取 $\boldsymbol{x} = (2,-1)^{\mathsf{T}}$：

$$D\boldsymbol{x} = \begin{bmatrix} 2-1 \\ 2-2 \\ 2-3 \end{bmatrix} = \begin{bmatrix} 1 \\ 0 \\ -1 \end{bmatrix}, \qquad \|D\boldsymbol{x}\|^2 = 2$$

$$D^{\mathsf{T}}D\boldsymbol{x} = \begin{bmatrix} 3 & 6 \\ 6 & 14 \end{bmatrix}\begin{bmatrix} 2 \\ -1 \end{bmatrix} = \begin{bmatrix} 0 \\ -2 \end{bmatrix}, \qquad \boldsymbol{x}^{\mathsf{T}}(D^{\mathsf{T}}D\boldsymbol{x}) = 2(0) + (-1)(-2) = 2 \checkmark$$

步骤 6：三阶验算。 取演示 2 的 A：

$$S^{\mathsf{T}}S = \begin{bmatrix} 6 & 11 & 17 \\ 11 & 21 & 32 \\ 17 & 32 & 49 \end{bmatrix}, \qquad \det(S^{\mathsf{T}}S) = 0 \text{（直接按 } S \text{ 的列相关即可判）}$$

$\mathbf{rank}(S^{\mathsf{T}}S)=2=\mathbf{rank}(S)$ ✓，$N(S^{\mathsf{T}}S)=\mathbf{span}\{(-1,-1,1)^{\mathsf{T}}\}=N(S)$ ✓。

【计算机制解说】：为什么 $N(A^{\mathsf{T}}A)=N(A)$ 如此重要？因为**它把"无解"变成"有解"**。对任意 A（哪怕长方、秩亏），$A^{\mathsf{T}}b$ 一定落在 $C(A^{\mathsf{T}})$ 里，而 $C(A^{\mathsf{T}})=C(A^{\mathsf{T}}A)$（由刚证的性质），所以方程

$$A^{\mathsf{T}}A\hat{x}=A^{\mathsf{T}}b$$

永远有解——这就是最小二乘的正规方程。进一步，$A^{\mathsf{T}}A$ 是 $n\times n$ 对称方阵；当 A 的列线性无关（$\mathbf{rank}(A)=n$）时 $N(A^{\mathsf{T}}A)=\{\mathbf{0}\}$，$A^{\mathsf{T}}A$ 可逆，解**唯一**：$\hat{x}=(A^{\mathsf{T}}A)^{-1}A^{\mathsf{T}}b$。若列相关（$\dim N(A)>0$），$A^{\mathsf{T}}A$ 奇异，仍**有无穷多解**（相差一个 $N(A)$ 中向量），我们取范数最小者（伪逆，讲次 33）。另外 $x^{\mathsf{T}}A^{\mathsf{T}}Ax=\|Ax\|^2\geq 0$ 说明 $A^{\mathsf{T}}A$ 恒为**半正定**——这正是图拉普拉斯 $L=A^{\mathsf{T}}A$（讲次 12）永远半正定、且 $\mathbf{rank}(L)=\mathbf{rank}(A)=n-1$ 的原因。

演示 4：四个基本子空间的正交分解与维数相加

步骤 1：两个包含关系（演示 2 已得）。

$$N(A)\subseteq C(A^{\mathsf{T}})^{\perp},\qquad N(A^{\mathsf{T}})\subseteq C(A)^{\perp}$$

（后者把 A 换成 A^{T}：$A^{\mathsf{T}}y=\mathbf{0}\iff y\perp A$ 的各列。）

步骤 2：维数相加。 设 A 是 $m\times n$、秩 r。则

$$\dim N(A)+\dim C(A^{\mathsf{T}})=(n-r)+r=n,\qquad \dim N(A^{\mathsf{T}})+\dim C(A)=(m-r)+r=m$$

步骤 3：正交补的维数公式与 $V^{\perp}=N(B)$。 设 $\dim V=d$，取 V 的一组基作为 $d\times n$ 矩阵 B 的行。则

$$w\in V^{\perp}\iff w\perp V\text{ 的每个基向量}\iff Bw=\mathbf{0}\iff w\in N(B)$$

由秩–零化度定理（$\mathbf{rank}(B)=d$，行满秩）：

$$\dim V^{\perp}=n-\mathbf{rank}(B)=n-d\quad\Longrightarrow\quad\boxed{\dim V+\dim V^{\perp}=n}$$

步骤 4：包含 + 维数 ⇒ 相等。 引用小引理：若 $U\subseteq W$ 且 $\dim U=\dim W$，则 $U=W$。取 $U=N(A)$、$W=C(A^{\mathsf{T}})^{\perp}$：包含关系来自步骤 1，维数相等来自步骤 2 与 3（$\dim C(A^{\mathsf{T}})^{\perp}=n-r=\dim N(A)$）。故

$$\boxed{N(A)=C(A^{\mathsf{T}})^{\perp},\qquad N(A^{\mathsf{T}})=C(A)^{\perp}}$$

步骤 5：得到直和。 $N(A)\cap C(A^{\mathsf{T}})\subseteq N(A)\cap N(A)^{\perp}=\{\mathbf{0}\}$（正交补中的向量与 $N(A)$ 中每个向量正交；若它自身也属于 $N(A)$，则 $x\perp x$，$\|x\|^2=0$，$x=\mathbf{0}$）。又两者维数之和为 n，所以

$$\mathbb{R}^n=C(A^{\mathsf{T}})\oplus N(A),\qquad \mathbb{R}^m=C(A)\oplus N(A^{\mathsf{T}})$$

步骤 6：用一个 3×2 矩阵全局验算。

$$B=\begin{bmatrix}1&0\\2&1\\0&1\end{bmatrix}_{3\times 2},\qquad n=2,\ m=3,\ r=2$$

- $\dim N(B)=2-2=0\Rightarrow N(B)=\{\mathbf{0}\}\Rightarrow\mathbb{R}^2=C(B^{\mathsf{T}})\oplus\{\mathbf{0}\}$：两列独立，行空间就是整个 $\mathbb{R}^2$ ✓。
- $\dim C(B)=2$，$\dim N(B^{\mathsf{T}})=3-2=1$，$2+1=3=m$ ✓。
- 解 $B^{\mathsf{T}}y=\mathbf{0}$：$\begin{bmatrix}1&2&0\\0&1&1\end{bmatrix}\begin{bmatrix}y_1\\y_2\\y_3\end{bmatrix}=\mathbf{0}$ 得 $y_2=-y_3$、$y_1=-2y_2=2y_3$；取 $y_3=1$，$y=(2,-1,1)^{\mathsf{T}}$。
- 验证 $y\perp$ 每一列：$(2,-1,1)\cdot(1,2,0)=0$ ✓；$(2,-1,1)\cdot(0,1,1)=0$ ✓。

完全吻合 $N(B^{\mathsf{T}})=C(B)^{\perp}$。

步骤 7：再看一个秩亏的 3×3。

$$W=\begin{bmatrix}1&2&3\\2&4&6\\3&6&9\end{bmatrix},\qquad \mathbf{rank}(W)=1$$

（每行都是 $(1,2,3)$ 的倍数。）于是 $C(W^{\mathsf{T}})=\mathbf{span}\{(1,2,3)^{\mathsf{T}}\}$（$\dim 1$），$N(W)=\{x_1+2x_2+3x_3=0\}$（$\dim 2$），基为 $(-2,1,0)^{\mathsf{T}}$ 与 $(-3,0,1)^{\mathsf{T}}$。验证正交：$(1,2,3)\cdot(-2,1,0)=-2+2=0$ ✓；$(1,2,3)\cdot(-3,0,1)=-3+3=0$ ✓；$1+2=3=n$ ✓。

这正是下面 ASCII 图的实现：直线（行空间）与平面（零空间）正交地铺满 $\mathbb{R}^3$。

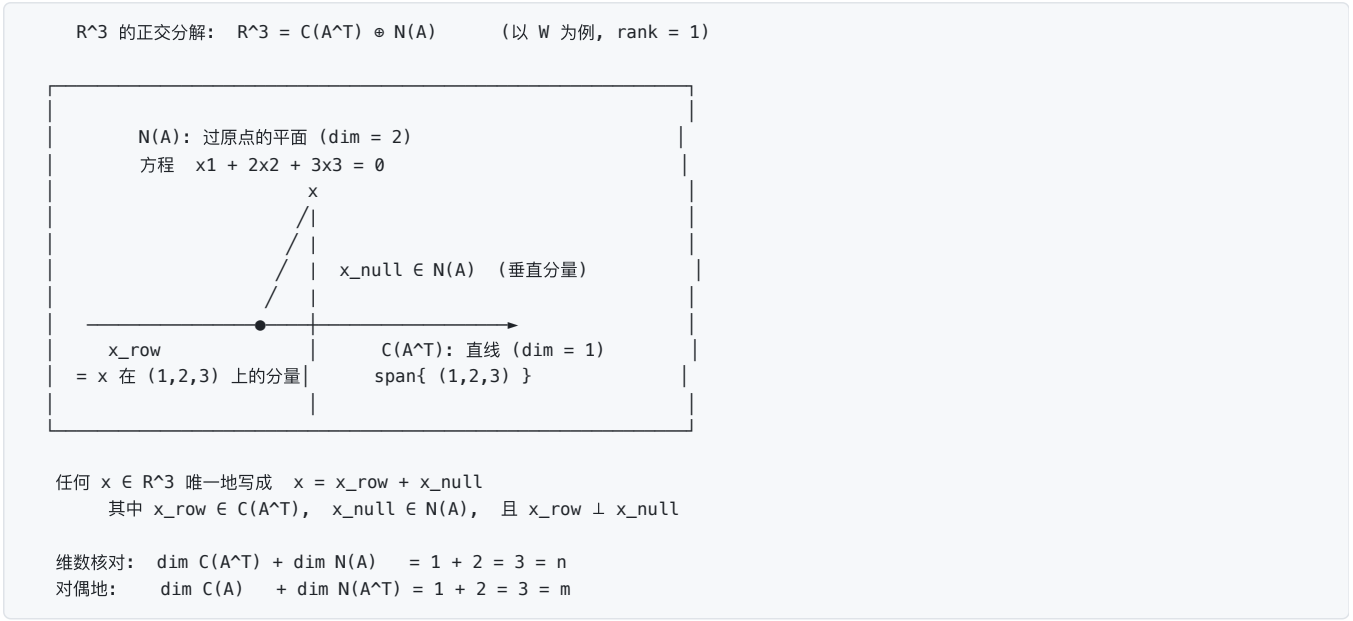

【计算机制解说】：为什么必须走"包含 + 维数相等"这条路线？因为**正交性是"逐个向量"的局部条件，而相等是"集合整体"的全局断言**。从 $\boldsymbol{Ax=0}$ 出发你只能证明 $\boldsymbol{N(A)}$ 中**每一个**向量都垂直于 $\boldsymbol{C(A^{\mathsf{T}})}$——这是包含。要提升为相等，必须排除"$\boldsymbol{C(A^{\mathsf{T}})^{\perp}}$ 里还有漏网之鱼"。维数相加正好提供了这个计数：**维数相同、又互相包含，就只能相等**。这是线性代数最标准的"以维数收尾"证明套路（讲次 10 用同一招证明 $\boldsymbol{\dim C(A)=\dim C(A^{\mathsf{T}})}$）。

演示 5：正交补的构造性使用——Gram–Schmidt 从 $\boldsymbol{N(A)}$ 造出 $\boldsymbol{C(A^{\mathsf{T}})}$ 的正交基

步骤 1：动机。 演示 4 只说"$\boldsymbol{C(A^{\mathsf{T}})}$ 与 $\boldsymbol{N(A)}$ 互补且正交"，但没告诉我们怎么**具体造出**正交基。Gram–Schmidt 就是这台机器。

步骤 2：取一组普通的独立向量。 取

$$u_1=\begin{bmatrix}1\\1\\1\end{bmatrix},\qquad u_2=\begin{bmatrix}1\\1\\0\end{bmatrix},\qquad u_3=\begin{bmatrix}1\\0\\0\end{bmatrix}$$

（三者独立。注意它们本身**不**两两正交：$u_1^{\mathsf{T}}u_2=2$，$u_1^{\mathsf{T}}u_3=1$，$u_2^{\mathsf{T}}u_3=1$。）

步骤 3：第一个向量直接归一化。

$$q_1=\frac{u_1}{\|u_1\|}=\frac{1}{\sqrt{3}}\begin{bmatrix}1\\1\\1\end{bmatrix},\qquad \|u_1\|=\sqrt{3}$$

步骤 4：第二个向量——减掉它在 q_1 方向上的投影。

$$u_2^{\mathsf{T}}q_1=\frac{1+1+0}{\sqrt{3}}=\frac{2}{\sqrt{3}}$$

投影分量：$\frac{2}{\sqrt{3}}q_1=\frac{2}{\sqrt{3}}\cdot\frac{1}{\sqrt{3}}(1,1,1)^{\mathsf{T}}=\left(\frac{2}{3},\frac{2}{3},\frac{2}{3}\right)^{\mathsf{T}}$。减去它：

$$e_2=u_2-\left(\tfrac{2}{3},\tfrac{2}{3},\tfrac{2}{3}\right)^{\mathsf{T}}=\left(\tfrac{1}{3},\tfrac{1}{3},-\tfrac{2}{3}\right)^{\mathsf{T}},\qquad \|e_2\|=\sqrt{\tfrac{1}{9}+\tfrac{1}{9}+\tfrac{4}{9}}=\sqrt{\tfrac{6}{9}}=\tfrac{\sqrt{6}}{3}$$

$$q_2=\frac{e_2}{\|e_2\|}=\frac{1}{\sqrt{6}}\begin{bmatrix}1\\1\\-2\end{bmatrix}$$

验证 $q_1^{\mathsf{T}}q_2=\dfrac{1+1-2}{\sqrt{18}}=0$ ✓。

步骤 5：第三个向量——减掉落在 $\{q_1,q_2\}$ 张成平面里的分量。

$$u_3^{\mathsf{T}}q_1=\frac{1}{\sqrt{3}},\qquad u_3^{\mathsf{T}}q_2=\frac{1}{\sqrt{6}}$$

$$e_3=u_3-\frac{1}{\sqrt{3}}q_1-\frac{1}{\sqrt{6}}q_2=\begin{bmatrix}1\\0\\0\end{bmatrix}-\begin{bmatrix}1/3\\1/3\\1/3\end{bmatrix}-\begin{bmatrix}1/6\\1/6\\-1/3\end{bmatrix}=\begin{bmatrix}1-\frac{1}{3}-\frac{1}{6}\\-\frac{1}{3}-\frac{1}{6}\\-\frac{1}{3}+\frac{1}{3}\end{bmatrix}=\begin{bmatrix}\frac{1}{2}\\-\frac{1}{2}\\0\end{bmatrix}$$

$$q_3 = \frac{e_3}{\|e_3\|} = \frac{1}{\sqrt{2}}\begin{bmatrix}1\\-1\\0\end{bmatrix}, \qquad \|e_3\| = \sqrt{\tfrac{1}{4}+\tfrac{1}{4}} = \tfrac{1}{\sqrt{2}}$$

步骤 6：三个正交性一起验证。

$$q_1^{\mathsf{T}}q_2 = \frac{1+1-2}{\sqrt{18}} = 0\ \checkmark \qquad q_1^{\mathsf{T}}q_3 = \frac{1-1+0}{\sqrt{6}} = 0\ \checkmark \qquad q_2^{\mathsf{T}}q_3 = \frac{1-1+0}{\sqrt{12}} = 0\ \checkmark$$

且 $\|q_1\| = \|q_2\| = \|q_3\| = 1$ ✓。**得到 $\mathbb{R}^3$ 的一组标准正交基。**

步骤 7：写成 $A = QR$。 取 $A = [u_1 \quad u_2 \quad u_3] = \begin{bmatrix}1&1&1\\1&1&0\\1&0&0\end{bmatrix}$，$Q = [q_1 \quad q_2 \quad q_3]$：

$$Q = \begin{bmatrix}\frac{1}{\sqrt{3}} & \frac{1}{\sqrt{6}} & \frac{1}{\sqrt{2}}\\ \frac{1}{\sqrt{3}} & \frac{1}{\sqrt{6}} & -\frac{1}{\sqrt{2}}\\ \frac{1}{\sqrt{3}} & -\frac{2}{\sqrt{6}} & 0\end{bmatrix}, \qquad R = Q^{\mathsf{T}}A = \begin{bmatrix}\sqrt{3} & \frac{2}{\sqrt{3}} & \frac{1}{\sqrt{3}}\\ 0 & \frac{\sqrt{6}}{3} & \frac{1}{\sqrt{6}}\\ 0 & 0 & \frac{1}{\sqrt{2}}\end{bmatrix}$$

验算 $QR = A$ ✓（Q 的列正交、R 上三角）。数值核对：$\sqrt{3} \approx 1.732051$，$\frac{2}{\sqrt{3}} \approx 1.154701$，$\frac{\sqrt{6}}{3} \approx 0.816497$，$\frac{1}{\sqrt{2}} \approx 0.707107$，全部与程序输出一致 ✓。

【计算机制解说】：Gram–Schmidt 的每一步都在**构造正交补**。第 k 步做的事是：把 u_k 投影到前面 $k-1$ 个方向张成的子空间 V_{k-1} 上，然后**减去投影**。剩下的 $e_k = u_k - \mathrm{proj}_{V_{k-1}} u_k$ 正是 u_k 在 $V_{k-1}^{\perp}$ 里的分量——**这就是 $\mathbb{R}^n = V \oplus V^{\perp}$ 的算法化身**，与本讲演示 4 的分解是同一件事，只是把"存在性"换成了"构造法"。另外 R 的对角元 $r_{kk} = \|e_k\|$ 一旦出现 $\mathbf{0}$，就说明 u_k 落在前面向量张成的空间里（原向量组线性相关）——所以 **Gram–Schmidt 顺带给出了独立性检验**。最后 $A^{\mathsf{T}}A = R^{\mathsf{T}}Q^{\mathsf{T}}QR = R^{\mathsf{T}}R$：$Q$ 的列正交把 $A^{\mathsf{T}}A$ 化简成上三角与其转置之积，这正是 QR 比直接算 $A^{\mathsf{T}}A$ 数值稳定的原因（讲次 17）。

矩阵分解的核心思想

本讲是**正交分解**的宣言，直接催生三种分解：

1. **$A = QR$（讲次 17）**。用 Gram–Schmidt 把 A 的列正交化，得到列正交的 Q 与上三角 R。依据正是本讲的投影与正交补：每一步都从当前列里"减掉落在前面列张成子空间中的分量"。
2. **$A^{\mathsf{T}}A$ 的正交化简**。当 $A = QR$ 时 $A^{\mathsf{T}}A = R^{\mathsf{T}}Q^{\mathsf{T}}QR = R^{\mathsf{T}}R$。这把 $A^{\mathsf{T}}A$ 的条件数问题转成 R 的问题——QR 比直接算 $A^{\mathsf{T}}A$ 在数值上稳定得多。
3. **$S\Lambda S^{-1}$ 正交化与 SVD $A = U\Sigma V^{\mathsf{T}}$（讲次 22、29）**。SVD 的本质就是"为四个基本子空间各找一组标准正交基"：V 的前 r 列是 $C(A^{\mathsf{T}})$ 的标准正交基、后 $n-r$ 列是 $N(A)$ 的；U 的前 r 列是 $C(A)$ 的、后 $m-r$ 列是 $N(A^{\mathsf{T}})$ 的。**本讲的"正交补"正是 SVD 把 $\mathbb{R}^n$ 切成两半的理论依据。**
4. **最小二乘的正规方程（讲次 16）** $A^{\mathsf{T}}A\hat{x} = A^{\mathsf{T}}b$。几何含义：误差 $b - A\hat{x}$ 落在 $N(A^{\mathsf{T}}) = C(A)^{\perp}$ 中，即"误差垂直于列空间"——本讲 $C(A) \perp N(A^{\mathsf{T}})$ 的直接应用。

与其他讲次的关联

- **回顾讲次 10（四个基本子空间）**：本讲把维数图**升级**为正交分解图。讲次 10 只说了 $C(A^{\mathsf{T}})$ 与 $N(A)$ 维数互补，本讲证明它们还**互相垂直**，因而构成直和。
- **回顾讲次 12（图与关联矩阵）**：那里的 $C(A) \perp N(A^{\mathsf{T}})$ 就是"边电势差正交于回路环流"；本讲给出一般证明。$L = A^{\mathsf{T}}A$ 的两条性质（$\mathbf{rank}$ 相同、零空间相同）在此得到统一解释。
- **通向讲次 15（投影）**：投影就是沿正交补方向分解。$x = x_{\mathrm{row}} + x_{\mathrm{null}}$ 中的 x_{row} 就是 x 在 $C(A^{\mathsf{T}})$ 上的投影，公式 $P = A(A^{\mathsf{T}}A)^{-1}A^{\mathsf{T}}$ 完全建立在"$A^{\mathsf{T}}A$ 可逆 $\iff$ 列无关"上。
- **通向讲次 16（最小二乘）**：$N(A^{\mathsf{T}}A) = N(A)$ 保证正规方程永远有解。
- **通向讲次 17（QR / Gram–Schmidt）**：正交化每一步都在"减掉投影"，是本讲正交补的算法实现。
- **通向讲次 29（SVD）**：四个基本子空间的标准正交基就是 SVD 的正交矩阵 U, V。

关键要点

1. **正交与勾股**：$v^{\mathsf{T}}w = 0$；$\|v+w\|^2 = \|v\|^2 + \|w\|^2$ **当且仅当** $v \perp w$（一般式含交叉项 $2v^{\mathsf{T}}w$）。
2. **$Ax = \mathbf{0} \iff x$ 与 A 的每一行正交 $\iff x \perp C(A^{\mathsf{T}})$。** 技巧：按行分块，$Ax$ 就是"x 与各行的内积"排成一列。
3. **正交 ≠ 正交补**：$V \perp W$ 只要求互相垂直；$W = V^{\perp}$ 还要求 $\dim V + \dim W = n$。$\mathbb{R}^3$ 中 x 轴与 y 轴正交，但 y 轴 $\neq x$ 轴的正交补（后者是 yz 平面）。
4. **正交补维数公式**：$\dim V + \dim V^{\perp} = n$，且 $V^{\perp} = N(B)$（B 的行是 V 的一组基）。

5. **四个基本子空间的正交分解**：

$$N(A) = C(A^{\mathsf{T}})^{\perp}, \quad N(A^{\mathsf{T}}) = C(A)^{\perp}, \quad \mathbb{R}^n = C(A^{\mathsf{T}}) \oplus N(A), \quad \mathbb{R}^m = C(A) \oplus N(A^{\mathsf{T}})$$

1. **$A^{\mathsf{T}}A$ 的两条命根子**：$N(A^{\mathsf{T}}A) = N(A)$，$\mathbf{rank}(A^{\mathsf{T}}A) = \mathbf{rank}(A)$；特别地 $A^{\mathsf{T}}A$ 可逆 $\iff$ A 的列线性无关 $\iff$ $\mathbf{rank}(A) = n$。
2. **必背证明技巧**：$A^{\mathsf{T}}Ax = \mathbf{0} \Rightarrow 0 = x^{\mathsf{T}}A^{\mathsf{T}}Ax = \|Ax\|^2 \Rightarrow Ax = \mathbf{0}$。

常见误区与注意事项

1. **把"正交"当成"正交互补"。** 最常见的错误是看到两个子空间垂直就写 $W = V^{\perp}$。**必须核对维数**：只有 $\dim V + \dim W = n$ 才算互补。
2. **证明 $N(A^{\mathsf{T}}A) = N(A)$ 时跳步。** "$A^{\mathsf{T}}Ax = 0$ 所以 $Ax = 0$"**不是**显然的：A^{T} 有非平凡零空间时完全可能把非零向量映到零。正确桥梁是**数量恒等式** $\|Ax\|^2 = x^{\mathsf{T}}A^{\mathsf{T}}Ax$。漏掉这步整个证明就废了。
3. **以为 $A^{\mathsf{T}}A$ 总是可逆。** 只有当 A 的列线性无关（$\mathbf{rank}(A) = n$，n 是列数）时才可逆。反例：$C = \begin{bmatrix} 1 & 2 \\ 2 & 4 \\ 3 & 6 \end{bmatrix}$，$C^{\mathsf{T}}C = \begin{bmatrix} 14 & 28 \\ 28 & 56 \end{bmatrix}$，$\det = 0$，**不可逆**。这是最小二乘需要伪逆的根源。
4. **把行空间放在 $\mathbb{R}^m$ 里。** $C(A^{\mathsf{T}}) \subseteq \mathbb{R}^n$（$n$ = 列数），$C(A) \subseteq \mathbb{R}^m$（$m$ = 行数）。位置写错会让"$\dim C(A^{\mathsf{T}}) + \dim N(A) = n$"失去意义。
5. **混淆 $\dim N(A) = n - r$ 与 $\dim N(A^{\mathsf{T}}) = m - r$。** 本讲的正交分解两边都用它们，写 $\mathbb{R}^m = C(A) \oplus N(A^{\mathsf{T}})$ 时极易把 m, n 用反。
6. **以为"$V \cap W = \{\mathbf{0}\} \Rightarrow V \perp W$"。** 反了！正交 $\Rightarrow$ 交为原点（若 x 同时在两者中，则 $x \perp x$，$x = \mathbf{0}$），但交为原点**不**蕴含正交。反例：$\mathbb{R}^3$ 中 x 轴与 $\mathbf{span}\{(1,1,0)\}$ 交为原点，但 $(1,0,0) \cdot (1,1,0) = 1 \neq 0$。
7. **用零向量举例说明正交性。** 零向量与一切正交，但 $N(A) \perp C(A^{\mathsf{T}})$ 的内容是**非零**向量之间的正交性，举零向量是空洞的。

思考题（带答案）

Q1.（纯计算） 设

$$A = \begin{bmatrix} 1 & 0 \\ 2 & 1 \\ 0 & 1 \end{bmatrix}$$

（1）求 $\mathbf{rank}(A)$、$N(A)$、$C(A^{\mathsf{T}})$；（2）求 $N(A^{\mathsf{T}})$ 的基并验证它垂直于 $C(A)$ 的每一列；（3）计算 $A^{\mathsf{T}}A$ 与 $\det(A^{\mathsf{T}}A)$，判断列是否线性无关；（4）取 $b = (1,1,1)^{\mathsf{T}}$，解正规方程并验证误差落在 $N(A^{\mathsf{T}})$ 方向上。

<details>
<summary>答案</summary>

（1） A 是 3×2。两列 $(1,2,0)^{\mathsf{T}}$ 与 $(0,1,1)^{\mathsf{T}}$ 不成比例，$\mathbf{rank}(A) = 2$。$n = 2 = r \Rightarrow$

$$> N(A) = \{\mathbf{0}\}, \qquad C(A^{\mathsf{T}}) = \mathbb{R}^2 >$$

（两列独立 $\Rightarrow$ 行空间是整个 $\mathbb{R}^2$。）维数核对：$2 + 0 = 2 = n$ ✓。

（2） 解 $A^{\mathsf{T}}y = \mathbf{0}$：

$$> A^{\mathsf{T}} = \begin{bmatrix} 1 & 2 & 0 \\ 0 & 1 & 1 \end{bmatrix} >\Longrightarrow> \begin{cases} y_1 + 2y_2 = 0 \\ y_2 + y_3 = 0 \end{cases} >$$

取 $y_3 = 1$：$y_2 = -1$，$y_1 = 2$，故 $N(A^{\mathsf{T}}) = \mathbf{span}\{(2,-1,1)^{\mathsf{T}}\}$。

验证与两列正交：$(2,-1,1) \cdot (1,2,0) = 2 - 2 + 0 = 0$ ✓；$(2,-1,1) \cdot (0,1,1) = 0 - 1 + 1 = 0$ ✓。

$\dim C(A) + \dim N(A^{\mathsf{T}}) = 2 + 1 = 3 = m$ ✓。

（3）

$$> A^{\mathsf{T}}A = \begin{bmatrix} 1 & 2 & 0 \\ 0 & 1 & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 2 & 1 \\ 0 & 1 \end{bmatrix} >= \begin{bmatrix} 5 & 2 \\ 2 & 2 \end{bmatrix}, \qquad > \det(A^{\mathsf{T}}A) = 10 - 4 = 6 \neq 0 >$$

可逆 $\Rightarrow$ A 的列线性无关 ✓（与（1）的 $\mathbf{rank}(A) = 2 = n$ 一致）。

（4） 先算 $A^{\mathsf{T}}b = \begin{bmatrix} 1 & 2 & 0 \\ 0 & 1 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix} = \begin{bmatrix} 3 \\ 2 \end{bmatrix}$。解

</details>

$$> \begin{bmatrix} 5 & 2 \\ 2 & 2 \end{bmatrix} \hat{x} = \begin{bmatrix} 3 \\ 2 \end{bmatrix}, > \qquad (A^{\mathsf{T}}A)^{-1} = \frac{1}{6} \begin{bmatrix} 2 & -2 \\ -2 & 5 \end{bmatrix} >$$

$$> \hat{x} = \frac{1}{6} \begin{bmatrix} 2 & -2 \\ -2 & 5 \end{bmatrix} \begin{bmatrix} 3 \\ 2 \end{bmatrix} >= \frac{1}{6} \begin{bmatrix} 6-4 \\ -6+10 \end{bmatrix} = \frac{1}{6} \begin{bmatrix} 2 \\ 4 \end{bmatrix} = \begin{bmatrix} 1/3 \\ 2/3 \end{bmatrix} >$$

> 预测值与残差：

$$> A\hat{x} = \begin{bmatrix} 1/3 \\ 2/3 + 2/3 \\ 2/3 \end{bmatrix} = \begin{bmatrix} 1/3 \\ 4/3 \\ 2/3 \end{bmatrix}, \qquad > e = b - A\hat{x} = \begin{bmatrix} 2/3 \\ -1/3 \\ 1/3 \end{bmatrix} = \frac{1}{3} \begin{bmatrix} 2 \\ -1 \\ 1 \end{bmatrix} >$$

> e 正是 $N(A^{\mathsf{T}})$ 基向量的 $\frac{1}{3}$ 倍，故 $e \in N(A^{\mathsf{T}}) = C(A)^{\perp}$，即 $e \perp$ 每一列：

$$> (2,-1,1) \cdot (1,2,0) = 0, \qquad (2,-1,1) \cdot (0,1,1) = 0 \checkmark >$$

> 这完美印证"最小二乘误差垂直于列空间"，其理论依据就是本讲的 $C(A) \perp N(A^{\mathsf{T}})$。

Q2.（概念理解） 解释为什么 $\mathbb{R}^3$ 中两个互相垂直的 1 维子空间**不是**彼此的正交补；并说明为什么"$\dim V + \dim W = n$"是判断 $W = V^{\perp}$ 的决定性条件。

> ▸ **答案**
>
> **第一部分：维数是决定性判据。** 取 $V = \mathrm{span}\{(1,0,0)\}$、$W = \mathrm{span}\{(0,1,0)\}$。它们正交（内积为 0）。若 $W = V^{\perp}$，则由 $\dim V + \dim V^{\perp} = 3$ 得 $\dim V^{\perp} = 2$，但 $\dim W = 1$，矛盾。具体地

$$> V^{\perp} = \{w : w_1 = 0\} = \mathrm{span}\{(0,1,0),(0,0,1)\} \neq W >$$

> 漏掉的向量 $(0,0,1)$ 在 $V^{\perp}$ 里但不在 W 里。**几何图像**：$V^{\perp}$ 要把"除 V 方向外的所有方向"都装进来；W 只装了一个方向，太窄。**另一角度**：$W^{\perp} = xz$ 平面 $\neq V$，所以二者甚至互不为对方的正交补。
>
> **第二部分：为什么维数条件是决定性的。** 因为正交性只是"逐个向量"的局部要求，而"是正交补"是全局断言。由 $V \perp W$ 能得到的只是 $W \subseteq V^{\perp}$（每个 w 都垂直于每个 v）。要升级为相等，必须排除漏网之鱼，而**维数相等正是排除漏网之鱼的唯一合法手段**（同引理：$U \subseteq W$ 且 $\dim U = \dim W \Rightarrow U = W$）。由于 $\dim V^{\perp} = n - \dim V$ 由正交补维数公式唯一确定，条件 $\dim V + \dim W = n$ 恰好等价于 $\dim W = \dim V^{\perp}$，配上包含关系就得相等。
>
> **一句话总结**：$\mathbb{R}^3$ 中"两条垂直直线"维数和为 2，比 $n = 3$ 少一维，所以它们**正交但不互补**；要把 $\mathbb{R}^3$ 铺满，必须一条 1 维配一个 2 维平面。

Q3.（概念 + 计算） 设 A 是 5×3 矩阵且 $\mathrm{rank}(A) = 3$。回答并说明理由：（1）$N(A) = ?$（2）$A^{\mathsf{T}}A$ 是什么规模？是否可逆？（3）$N(A^{\mathsf{T}})$ 维数是多少？是否非平凡？（4）对 $b = (1,0,1,0,1)^{\mathsf{T}}$，$A^{\mathsf{T}}A\hat{x} = A^{\mathsf{T}}b$ 是否唯一可解？

> ▸ **答案**
>
> （1） $n = 3$（列数），$r = 3$，故 $\dim N(A) = n - r = 0$，即

$$> N(A) = \{\mathbf{0}\} >$$

> A **的三列线性无关。** 由关键性质，这等价于 $N(A^{\mathsf{T}}A) = \{\mathbf{0}\}$。
>
> （2） $A^{\mathsf{T}}A$ 是 3×3（A^{T} 为 3×5，乘 5×3 得 3×3），且**对称**。由 (1) 知 $N(A^{\mathsf{T}}A) = N(A) = \{\mathbf{0}\}$，而 3×3 矩阵零空间只有零向量 $\Rightarrow$ 满秩 $\Rightarrow$ **可逆** ✓。
>
> 一般准则：$A^{\mathsf{T}}A$ **可逆** $\iff$ A **的列线性无关** $\iff$ $\mathrm{rank}(A) = n$。这里 $3 = 3$ ✓。
>
> （3） $m = 5$（行数），$r = 3$：

$$> \dim N(A^{\mathsf{T}}) = m - r = 5 - 3 = 2 >$$

> **非平凡。** 它是 $C(A)^{\perp}$（$\mathbb{R}^5$ 中 2 维子空间），维数核对 $3+2=5=m$ ✓。所以 A 的列空间只占 $\mathbb{R}^5$ 的 3 维，剩下 2 维全是"与所有列正交"的方向——**$Ax=b$ 对一般 b 无解**，这正是最小二乘的用武之地。
>
> **（4） 是，唯一可解。** 理由：正规方程是 3×3 系统，系数矩阵 $A^{\mathsf{T}}A$ 由 (2) 可逆；且 $A^{\mathsf{T}}b\in\mathbb{R}^3=C(A^{\mathsf{T}}A)$（可逆方阵的列空间是整个 $\mathbb{R}^3$）。所以

$$> \hat{x}=(A^{\mathsf{T}}A)^{-1}A^{\mathsf{T}}b >$$

> **唯一存在** ✓。虽然原方程 $Ax=b$ 有 5 个方程、3 个未知数、一般无解，但最小二乘解**总是存在且唯一**（列独立时）。误差 $e=b-A\hat{x}$ 满足 $e\perp C(A)$，即 $e\in N(A^{\mathsf{T}})$（那个 2 维子空间）。
>
> **注**：若 b 恰好落在 $C(A)$ 里（需 $b\perp N(A^{\mathsf{T}})$，几率很小），则 $e=0$，最小二乘解就是精确解。

Lecture 15: Projections onto Subspaces

概述

本讲要解决的问题非常朴素：**当 $A\mathbf{x}=\mathbf{b}$ 无解时，我们该怎么办？** 现实中这种情形才是常态——测量数据多于未知数，方程个数 m 大于未知数个数 n。Strang 的答案是：不要放弃，退一步求"最接近的 $\mathbf{b}$"。把 $\mathbf{b}$ 投影到列空间 C(A) 上得到 $\mathbf{p}$，然后解 $A\hat{\mathbf{x}}=\mathbf{p}$——这个方程一定有解，因为 $\mathbf{p}$ 就住在列空间里。

本讲先把投影做穿两条路：一维（投影到一条直线，矩阵 $\mathbf{a}$ 只有一个列）与高维（投影到子空间，矩阵 A 有 n 个列）。两条路给出同一个骨架：**误差 $\mathbf{e}$ 必须垂直于投影的子空间**，这条正交条件就是投影的全部内容。由此引出整门课最重要的方程之一——**正规方程 $A^{\mathsf{T}}A\hat{\mathbf{x}}=A^{\mathsf{T}}\mathbf{b}$**，以及投影矩阵

$$P=A(A^{\mathsf{T}}A)^{-1}A^{\mathsf{T}}.$$

本讲是"正交"这条主线的第一站：下一讲用它做最小二乘，再下一讲用 Gram–Schmidt 造出更好的 $A=QR$。

核心概念的几何直觉

为什么需要投影

- **定义与目的**：给定 $m\times n$ 矩阵 A 与向量 $\mathbf{b}\in\mathbb{R}^m$，我们想解 $A\mathbf{x}=\mathbf{b}$。若 $\mathbf{b}\notin C(A)$，则无解。投影的目的是找出 C(A) 中离 $\mathbf{b}$ 最近的那个向量 $\mathbf{p}$。
- **几何直觉（它在空间中是什么样子？）**：C(A) 是 $\mathbb{R}^m$ 中的一张"平面"（或直线、或整个空间）。$\mathbf{b}$ 可能悬在这张平面之外。从 $\mathbf{b}$ 向平面作垂线，垂足就是 $\mathbf{p}$。$\mathbf{b}$ 到平面的最短距离就是这段垂线的长度 $\|\mathbf{e}\|=\|\mathbf{b}-\mathbf{p}\|$。
- **具体示例**：$m=3,n=2$ 时，C(A) 是 $\mathbb{R}^3$ 中过原点的一张平面；$\mathbf{b}$ 一般不在平面上，$\mathbf{p}$ 是它到平面的垂足，$\mathbf{e}=\mathbf{b}-\mathbf{p}$ 是平面的法向量方向。

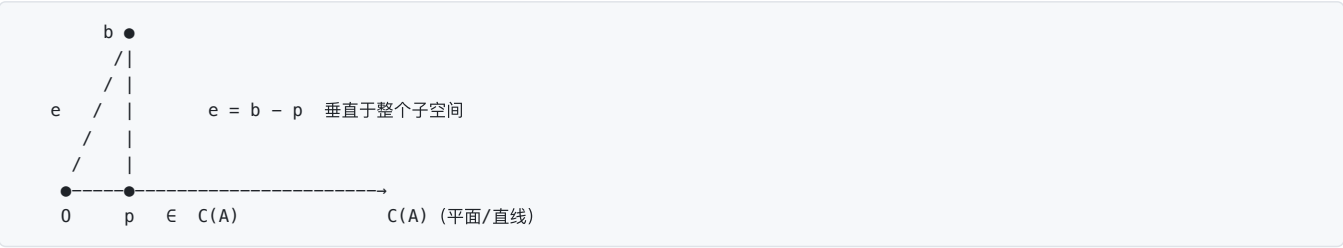

一维投影：投影到一条直线

- **定义与目的**：设 $\mathbf{a}\in\mathbb{R}^m$ 是非零向量，直线 $L=\{a\boldsymbol{x}\}$ 是一维子空间。要把 $\mathbf{b}$ 投影到 L 上。投影结果必为 $\mathbf{p}=\hat{x}\mathbf{a}$（只差一个倍数），未知量只有标量 $\hat{x}$。
- **几何直觉（它在空间中是什么样子？）**：沿着 $\mathbf{a}$ 的方向走，走到某一点时，$\mathbf{b}$ 与该点的连线恰好与 $\mathbf{a}$ 垂直——那个点就是垂足。垂直意味着 $\mathbf{a}^{\mathsf{T}}(\mathbf{b}-\hat{x}\mathbf{a})=0$。这是一个关于 $\hat{x}$ 的一元方程，解出来就是 $\hat{x}=\dfrac{\mathbf{a}^{\mathsf{T}}\mathbf{b}}{\mathbf{a}^{\mathsf{T}}\mathbf{a}}$。
- **具体示例**：$\mathbf{a}=\begin{bmatrix}1\\2\\2\end{bmatrix}$，$\mathbf{b}=\begin{bmatrix}1\\1\\1\end{bmatrix}$：$\mathbf{a}^{\mathsf{T}}\mathbf{a}=9$，$\mathbf{a}^{\mathsf{T}}\mathbf{b}=5$，故 $\hat{x}=5/9$，$\mathbf{p}=\frac{5}{9}\begin{bmatrix}1\\2\\2\end{bmatrix}$。详细验算见下一节。

投影矩阵（一维）

- **定义与目的**：把上面的结果写成"矩阵乘 $\mathbf{b}$"的形式：$\mathbf{p}=\mathbf{a}\dfrac{\mathbf{a}^{\mathsf{T}}\mathbf{b}}{\mathbf{a}^{\mathsf{T}}\mathbf{a}}=\dfrac{\mathbf{a}\mathbf{a}^{\mathsf{T}}}{\mathbf{a}^{\mathsf{T}}\mathbf{a}}\mathbf{b}$。于是

$$P=\frac{\mathbf{a}\mathbf{a}^{\mathsf{T}}}{\mathbf{a}^{\mathsf{T}}\mathbf{a}}.$$

- **几何直觉（它在空间中是什么样子？）**：P 是一个 $m \times m$ 的矩阵，它作用于任何向量时都"拍扁"到直线 L 上。它的每一列都是 $\mathbf{a}$ 的倍数，所以 C(P) = L，秩为 1。
- **具体示例**：$\mathbf{a} = \begin{bmatrix}1\\2\\2\end{bmatrix}$，$\mathbf{a}^{\mathsf{T}}\mathbf{a} = 9$，故

$$P = \frac{1}{9}\begin{bmatrix}1\\2\\2\end{bmatrix}\begin{bmatrix}1 & 2 & 2\end{bmatrix} = \frac{1}{9}\begin{bmatrix}1 & 2 & 2\\2 & 4 & 4\\2 & 4 & 4\end{bmatrix}.$$

注意 P 的两行两列按比例重复——这正是"秩 1"的外观特征。

高维投影：投影到子空间

- **定义与目的**：设 A 是 $m \times n$ 且**列向量线性无关**（因此 $n \le m$，且 C(A) 是 n 维子空间）。要把 $\mathbf{b}$ 投影到 C(A) 上：$\mathbf{p} = A\hat{\mathbf{x}}$，未知量变成向量 $\hat{\mathbf{x}} \in \mathbb{R}^n$。正交条件是"$\mathbf{e} = \mathbf{b} - A\hat{\mathbf{x}}$ 垂直于 C(A) 中每一个向量"，等价于垂直于 A 的每一列，即 $A^{\mathsf{T}}(\mathbf{b} - A\hat{\mathbf{x}}) = \mathbf{0}$。
- **几何直觉（它在空间中是什么样子？）**：一维时是"垂线与直线垂直"；高维时是"垂线与整张平面垂直"。垂直条件从 1 个方程变成 n 个方程（A^{T} 有 n 行），恰好确定 $\hat{\mathbf{x}}$ 的 n 个分量。
- **具体示例**：$A = \begin{bmatrix}1 & 1\\1 & 0\\0 & 1\end{bmatrix}$，$\mathbf{b} = \begin{bmatrix}1\\1\\1\end{bmatrix}$，C(A) 是 $\mathbb{R}^3$ 中由两个列张成的平面。解得 $\hat{\mathbf{x}} = \begin{bmatrix}2/3\\2/3\end{bmatrix}$，$\mathbf{p} = \begin{bmatrix}4/3\\2/3\\2/3\end{bmatrix}$。详细验算见下一节。

正规方程（Normal Equation）

- **定义与目的**：把 $A^{\mathsf{T}}(\mathbf{b} - A\hat{\mathbf{x}}) = \mathbf{0}$ 展开：

$$A^{\mathsf{T}}A\hat{\mathbf{x}} = A^{\mathsf{T}}\mathbf{b} \quad \Longrightarrow \quad \hat{\mathbf{x}} = (A^{\mathsf{T}}A)^{-1}A^{\mathsf{T}}\mathbf{b}.$$

这是 $n \times n$ 的方程组，叫**正规方程**。"normal" 在这里是"垂直"的意思，因为它的来源就是正交条件。

- **几何直觉（它在空间中是什么样子？）**：$A^{\mathsf{T}}\mathbf{e} = \mathbf{0}$ 说的是：误差 $\mathbf{e}$ 落在 A^{T} 的零空间 $\mathbf{N}(A^{\mathsf{T}})$ 里，而 $\mathbf{N}(A^{\mathsf{T}})$ 正是与列空间 C(A) 正交的那个子空间（左零空间）。这就是 Lecture 10 的四基本子空间图在投影中的第一次真实应用。

$$\mathbf{e} \in \mathbf{N}(A^{\mathsf{T}}) \iff \mathbf{e} \perp C(A).$$

- **具体示例**：$A = \begin{bmatrix}1 & 1\\1 & 2\\1 & 3\end{bmatrix}$ 时 $A^{\mathsf{T}}A = \begin{bmatrix}3 & 6\\6 & 14\end{bmatrix}$，$A^{\mathsf{T}}\mathbf{b} = \begin{bmatrix}6\\14\end{bmatrix}$。

子空间投影矩阵

- **定义与目的**：把 $\hat{\mathbf{x}}$ 代回：

$$\mathbf{p} = A\hat{\mathbf{x}} = A(A^{\mathsf{T}}A)^{-1}A^{\mathsf{T}}\mathbf{b} = P\mathbf{b}, \qquad \boxed{P = A(A^{\mathsf{T}}A)^{-1}A^{\mathsf{T}}}.$$

- **几何直觉（它在空间中是什么样子？）**：P 是 $m \times m$ 矩阵，作用在任何向量上都把它拍进 C(A)。A 把 $\mathbb{R}^n$ 送进 C(A)（同构），$(A^{\mathsf{T}}A)^{-1}A^{\mathsf{T}}$ 把 $\mathbb{R}^m$ 送回 $\mathbb{R}^n$。两头夹起来，落点永远是 C(A)。
- **具体示例**：$A = \begin{bmatrix}1 & 1\\1 & 0\\0 & 1\end{bmatrix}$ 时 $P = \frac{1}{3}\begin{bmatrix}2 & 1 & 1\\1 & 2 & -1\\1 & -1 & 2\end{bmatrix}$。它与一维的 $P = \mathbf{a}\mathbf{a}^{\mathsf{T}}/\mathbf{a}^{\mathsf{T}}\mathbf{a}$ 是同一个公式：把 A 换成只有一列的 $\mathbf{a}$，$(A^{\mathsf{T}}A)^{-1}$ 就退化成标量 $1/\mathbf{a}^{\mathsf{T}}\mathbf{a}$。

正交补与"两半分解"

- **定义与目的**：P 把任何 $\mathbf{b}$ 拆成两半：$P\mathbf{b} \in C(A)$ 与 $(I-P)\mathbf{b} \in C(A)^{\perp} = \mathbf{N}(A^{\mathsf{T}})$。$I - P$ 本身也是一个投影矩阵——它对称（$(I-P)^{\mathsf{T}} = I - P^{\mathsf{T}} = I - P$）、幂等（$(I-P)^2 = I - 2P + P^2 = I - P$），投影的目标是 C(A) 的正交补。
- **几何直觉（它在空间中是什么样子？）**：把 $\mathbf{b}$ 想成一根斜插进平面的杆子，"平面内的影子"是 $P\mathbf{b}$，"翘起来的部分"是 $(I-P)\mathbf{b}$。两部分互不干扰：影子再投影还是自己（$P^2 = P$），影子去正交补那边投影得零（$P(I-P) = P - P^2 = 0$）。
- **具体示例**：示例 2 中 $A = \begin{bmatrix}1 & 1\\1 & 0\\0 & 1\end{bmatrix}$ 给出 $P = \frac{1}{3}\begin{bmatrix}2 & 1 & 1\\1 & 2 & -1\\1 & -1 & 2\end{bmatrix}$，于是

$$I - P = \frac{1}{3}\begin{bmatrix}1 & -1 & -1\\-1 & 1 & 1\\-1 & 1 & 1\end{bmatrix}, \qquad \mathbf{b} = \begin{bmatrix}1\\1\\1\end{bmatrix} \Longrightarrow P\mathbf{b} = \begin{bmatrix}4/3\\2/3\\2/3\end{bmatrix}, \quad (I-P)\mathbf{b} = \begin{bmatrix}-1/3\\1/3\\1/3\end{bmatrix}.$$

注意 $I - P$ 的**第二、三行完全相同**——这是"秩 1"的外观特征，因为 $\dim C(A)^{\perp} = m - r = 3 - 2 = 1$。

投影的"另一侧"：投影到行空间

- **定义与目的**：同一条正交性原理还有一半。把 $\mathbf{b} \in \mathbb{R}^n$ 投影到**行空间** $C(A^\mathsf{T}) \subseteq \mathbb{R}^n$，得到 $n \times n$ 矩阵

$$\hat{P} = A^\mathsf{T}(AA^\mathsf{T})^{-1}A.$$

（前提：A 的行线性无关，即 $\mathbf{rank}(A) = m$、AA^T 可逆。） – **几何直觉（它在空间中是什么样子？）**：A 把 $\mathbb{R}^n$ 压进 C(A)，$\hat{P}$ 则把 $\mathbb{R}^n$ 压进与 C(A) 正交配对的行空间。两个投影合起来正好覆盖 Lecture 10 的四子空间图：P 管 $\mathbb{R}^m$ 里的 C(A) 与 N(Aᵀ)，$\hat{P}$ 管 $\mathbb{R}^n$ 里的 C(Aᵀ) 与 N(A)。这也解释了为什么最小二乘的解 $\hat{\mathbf{x}}$ 必然落在行空间里——它本来就是从 $\mathbb{R}^m$ 经 A^T 拉回来、再经 AA^T 修正的结果。 – **具体示例**：$A = \begin{bmatrix}1 & 2 & 0\\ 0 & 1 & 1\end{bmatrix}$（2×3，两行无关）：$AA^\mathsf{T} = \begin{bmatrix}5 & 2\\ 2 & 2\end{bmatrix}$，$\det = 6$，

$$(AA^\mathsf{T})^{-1} = \frac{1}{6}\begin{bmatrix}2 & -2\\ -2 & 5\end{bmatrix} = \begin{bmatrix}1/3 & -1/3\\ -1/3 & 5/6\end{bmatrix}, \qquad \hat{P} = A^\mathsf{T}(AA^\mathsf{T})^{-1}A = \begin{bmatrix}1/3 & 1/3 & -1/3\\ 1/3 & 5/6 & 1/6\\ -1/3 & 1/6 & 5/6\end{bmatrix}.$$

完整手算过程与验证见下一节示例 6。

C(P) 与 N(P)：投影矩阵的两只眼睛

- **定义与目的**：像空间 $C(P) = C(A)$，零空间 $\mathbf{N}(P) = \mathbf{N}(A^\mathsf{T}) = C(A)^\perp$。于是 $\mathbf{rank}(P) = \dim C(A) = r$，$\dim \mathbf{N}(P) = m - r$，且 $\mathbf{rank}(P) + \dim \mathbf{N}(P) = r + (m - r) = m$（秩—零化度定理）。
- **几何直觉（它在空间中是什么样子？）**：P "看不见"子空间的正交方向——那些方向喂给它，输出零；而子空间内的向量喂给它，原样返回。投影矩阵的全部信息量就是"它认出了哪个子空间"。
- **具体示例**：示例 1 的 $P = \frac{1}{9}\begin{bmatrix}1 & 2 & 2\\ 2 & 4 & 4\\ 2 & 4 & 4\end{bmatrix}$：每一列都是 $\mathbf{a} = [1, 2, 2]^\mathsf{T}$ 的倍数，故 $C(P)$ 就是那条直线；而 $\mathbf{a}^\mathsf{T}[0, 1, -1]^\mathsf{T} = 0$，直接算得

$$P\begin{bmatrix}0\\ 1\\ -1\end{bmatrix} = \frac{1}{9}\begin{bmatrix}2-2\\ 4-4\\ 4-4\end{bmatrix} = \begin{bmatrix}0\\ 0\\ 0\end{bmatrix}.$$

即 $[0, 1, -1]^\mathsf{T} \in \mathbf{N}(P)$，它正是 $C(A)^\perp$ 里的向量。✓

一张图看懂两个投影与四个子空间

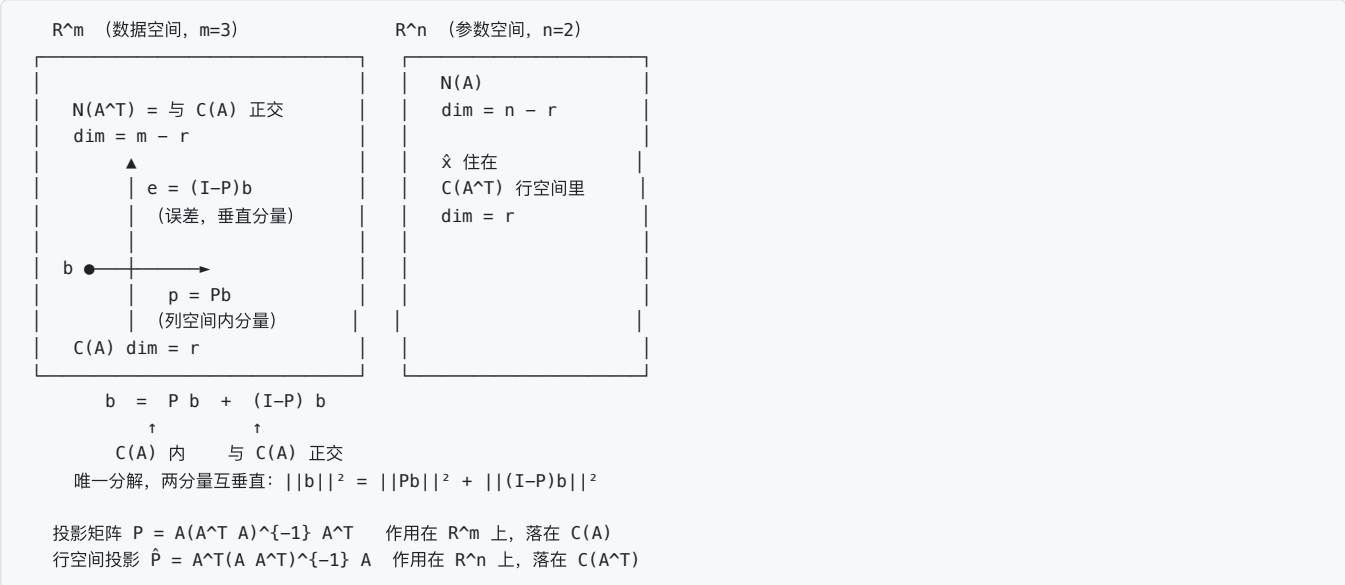

一维与高维的统一：同一套骨架

把两种情形并排看，会发现它们的**逻辑结构完全一样**，只是"标量"换成了"矩阵"：

	一维（投影到直线 L = span{a}）	高维（投影到子空间 C(A)）
目标	求 p = x̂a ∈ L	求 p = A x̂ ∈ C(A)
未知量	标量 x̂ ∈ R	向量 x̂ ∈ R^n
正交条件	a^T(b − x̂a) = 0 （1 个方程）	A^T(b − A x̂) = 0 （n 个方程）
方程	(a^T a) x̂ = a^T b	(A^T A) x̂ = A^T b
系数矩阵	a^T a （1×1，可逆）	A^T A （n×n，列无关时可逆）
解	x̂ = a^T b / a^T a	x̂ = (A^T A)^{−1} A^T b
投影	p = a(a^T b)/(a^T a)	p = A(A^T A)^{−1} A^T b
投影矩阵	P = a a^T / a^T a	P = A (A^T A)^{−1} A^T
秩	rank(P) = 1	rank(P) = n = dim C(A)
迹	trace(P) = 1	trace(P) = n
特征值	1（沿 a）、0（垂直 a）	1（n 重，在 C(A) 上）、0（m−n 重）

统一公式的记忆法：一维是高维在 $n=1$ 时的特例。只要把 $\mathbf{a}^{\mathsf{T}}\mathbf{a}$ 看成 1×1 矩阵 $A^{\mathsf{T}}A$、把 $\frac{1}{\mathbf{a}^{\mathsf{T}}\mathbf{a}}$ 看成 $(A^{\mathsf{T}}A)^{-1}$，两个公式一模一样。**不要分别死记两个公式——记住一个，另一个是特例。**

投影长度与夹角：把投影写成"几何量"

一维情形还能读出一个漂亮的几何公式。设 θ 是 $\mathbf{a}$ 与 $\mathbf{b}$ 的夹角，则

$$\hat{x}=\frac{\mathbf{a}^{\mathsf{T}}\mathbf{b}}{\mathbf{a}^{\mathsf{T}}\mathbf{a}}=\frac{\|\mathbf{a}\|\|\mathbf{b}\|\cos\theta}{\|\mathbf{a}\|^2}=\frac{\|\mathbf{b}\|\cos\theta}{\|\mathbf{a}\|},$$

$$\mathbf{p}=\hat{x}\mathbf{a}=(\|\mathbf{b}\|\cos\theta)\frac{\mathbf{a}}{\|\mathbf{a}\|}=(\|\mathbf{b}\|\cos\theta)\mathbf{u},\qquad \mathbf{u}=\frac{\mathbf{a}}{\|\mathbf{a}\|}\ \text{（单位方向）}.$$

也就是说：**投影长度 $=\|\mathbf{b}\|\cos\theta$**（$\mathbf{b}$ 在 $\mathbf{a}$ 方向上的"影子长度"），**投影向量 = 该长度 × 单位方向**。误差长度则是

$$\|\mathbf{e}\|=\|\mathbf{b}\|\sin\theta,$$

于是勾股关系 $\|\mathbf{b}\|^2=\|\mathbf{p}\|^2+\|\mathbf{e}\|^2=\|\mathbf{b}\|^2\cos^2\theta+\|\mathbf{b}\|^2\sin^2\theta$ 退化成三角恒等式。用示例 1 验证：$\mathbf{a}=[1,2,2]^{\mathsf{T}}$、$\mathbf{b}=[1,1,1]^{\mathsf{T}}$，$\mathbf{a}^{\mathsf{T}}\mathbf{b}=5$、$\|\mathbf{a}\|=3$、$\|\mathbf{b}\|=\sqrt{3}$，故 $\cos\theta=\frac{5}{3\sqrt{3}}$，

$$\|\mathbf{p}\|=\|\mathbf{b}\|\cos\theta=\sqrt{3}\cdot\frac{5}{3\sqrt{3}}=\frac{5}{3},\qquad \|\mathbf{e}\|=\|\mathbf{b}\|\sin\theta=\sqrt{3}\sqrt{1-\frac{25}{27}}=\sqrt{3}\cdot\sqrt{\frac{2}{27}}=\sqrt{\frac{6}{27}}=\sqrt{\frac{2}{9}}=\frac{\sqrt{2}}{3}.$$

与直接的 $\|\mathbf{p}\|^2=\frac{25}{9}\Rightarrow\|\mathbf{p}\|=\frac{5}{3}$ ✓、$\|\mathbf{e}\|^2=\frac{2}{9}\Rightarrow\|\mathbf{e}\|=\frac{\sqrt{2}}{3}$ ✓ 完全一致。

这个公式的实用价值：$\cos\theta=\frac{\mathbf{a}^{\mathsf{T}}\mathbf{b}}{\|\mathbf{a}\|\|\mathbf{b}\|}$ 就是**相关系数**（cosine similarity）。所以"投影"在数据分析里就是"计算两个向量的相似度"——这正是推荐系统、文本检索（TF-IDF 余弦相似度）、图像匹配中天天在用的东西。$P\mathbf{b}$ 是 $\mathbf{b}$ 落在 $\mathbf{a}$ 方向上的部分，$\cos\theta$ 衡量"$\mathbf{b}$ 有多像 $\mathbf{a}$"。

计算步骤与手算演示

示例 1（一维）：把 $\mathbf{b}$ 投影到 $\mathbf{a}=[1,2,2]^{\mathsf{T}}$ 张成的直线上

取

$$\mathbf{a}=\begin{bmatrix}1\\2\\2\end{bmatrix},\qquad \mathbf{b}=\begin{bmatrix}1\\1\\1\end{bmatrix}.$$

步骤 1：算两个标量。

$$\mathbf{a}^{\mathsf{T}}\mathbf{a}=1^2+2^2+2^2=1+4+4=9,\qquad \mathbf{a}^{\mathsf{T}}\mathbf{b}=1\cdot1+2\cdot1+2\cdot1=1+2+2=5.$$

步骤 2：解 $\hat{x}$。 由 $\mathbf{a}^{\mathsf{T}}(\mathbf{b}-\hat{x}\mathbf{a})=0$，即 $\mathbf{a}^{\mathsf{T}}\mathbf{b}-\hat{x}\,\mathbf{a}^{\mathsf{T}}\mathbf{a}=0$：

$$\hat{x}=\frac{\mathbf{a}^{\mathsf{T}}\mathbf{b}}{\mathbf{a}^{\mathsf{T}}\mathbf{a}}=\frac{5}{9}.$$

步骤 3：算投影 $\mathbf{p}$。

$$\mathbf{p}=\hat{x}\mathbf{a}=\frac{5}{9}\begin{bmatrix}1\\2\\2\end{bmatrix}=\begin{bmatrix}5/9\\10/9\\10/9\end{bmatrix}\approx\begin{bmatrix}0.5556\\1.1111\\1.1111\end{bmatrix}.$$

步骤 4：算误差 $\mathbf{e}$。

$$\mathbf{e} = \mathbf{b} - \mathbf{p} = \begin{bmatrix}1\\1\\1\end{bmatrix} - \begin{bmatrix}5/9\\10/9\\10/9\end{bmatrix} = \begin{bmatrix}4/9\\-1/9\\-1/9\end{bmatrix} \approx \begin{bmatrix}0.4444\\-0.1111\\-0.1111\end{bmatrix}.$$

步骤 5：验证正交。

$$\mathbf{a}^{\mathsf{T}}\mathbf{e} = 1\cdot\frac{4}{9} + 2\cdot\left(-\frac{1}{9}\right) + 2\cdot\left(-\frac{1}{9}\right) = \frac{4}{9} - \frac{2}{9} - \frac{2}{9} = 0. \quad \checkmark$$

步骤 6：验证 Pythagorean 关系。 因为 $\mathbf{p} \perp \mathbf{e}$，

$$\|\mathbf{b}\|^2 = 3, \qquad \|\mathbf{p}\|^2 = \frac{25}{81}\cdot 9 = \frac{25}{9}, \qquad \|\mathbf{e}\|^2 = \frac{16+1+1}{81} = \frac{18}{81} = \frac{2}{9},$$

$$\|\mathbf{p}\|^2 + \|\mathbf{e}\|^2 = \frac{25}{9} + \frac{2}{9} = \frac{27}{9} = 3 = \|\mathbf{b}\|^2. \quad \checkmark$$

步骤 7：写出投影矩阵并验证 $P^{\mathsf{T}} = P$、$P^2 = P$、$\mathrm{rank}(P) = 1$。

$$P = \frac{\mathbf{a}\mathbf{a}^{\mathsf{T}}}{\mathbf{a}^{\mathsf{T}}\mathbf{a}} = \frac{1}{9}\begin{bmatrix}1&2&2\\2&4&4\\2&4&4\end{bmatrix} = \begin{bmatrix}1/9&2/9&2/9\\2/9&4/9&4/9\\2/9&4/9&4/9\end{bmatrix}.$$

- 对称性 $P^{\mathsf{T}} = P$：矩阵关于主对角线对称，第 2、3 行完全一样，第 2、3 列完全一样。✓
- 幂等性 $P^2 = P$：$\dfrac{\mathbf{a}\mathbf{a}^{\mathsf{T}}}{\mathbf{a}^{\mathsf{T}}\mathbf{a}} \cdot \dfrac{\mathbf{a}\mathbf{a}^{\mathsf{T}}}{\mathbf{a}^{\mathsf{T}}\mathbf{a}} = \dfrac{\mathbf{a}(\mathbf{a}^{\mathsf{T}}\mathbf{a})\mathbf{a}^{\mathsf{T}}}{(\mathbf{a}^{\mathsf{T}}\mathbf{a})^2} = \dfrac{\mathbf{a}\mathbf{a}^{\mathsf{T}}}{\mathbf{a}^{\mathsf{T}}\mathbf{a}} = P$。✓
- 秩为 1：每一列都是 $\mathbf{a}$ 的倍数，C(P) = L 是一维的，故 $\mathrm{rank}(P) = 1$。迹也是 $1/9 + 4/9 + 4/9 = 1$，与秩一致。✓
- 作用验证：$P\mathbf{b} = \frac{1}{9}\begin{bmatrix}1+2+2\\2+4+4\\2+4+4\end{bmatrix} = \frac{1}{9}\begin{bmatrix}5\\10\\10\end{bmatrix} = \begin{bmatrix}5/9\\10/9\\10/9\end{bmatrix} = \mathbf{p}$。✓

【计算机制解说】：为什么"沿着 $\mathbf{a}$ 走，直到 $\mathbf{b} - \hat{x}\mathbf{a} \perp \mathbf{a}$"就得到最近点？设任何别的倍数为 x，则 $\mathbf{b} - x\mathbf{a} = (\mathbf{b} - \hat{x}\mathbf{a}) + (\hat{x} - x)\mathbf{a}$。由于 $\mathbf{b} - \hat{x}\mathbf{a} \perp \mathbf{a}$，两项正交，勾股定理给出

$$\|\mathbf{b} - x\mathbf{a}\|^2 = \|\mathbf{b} - \hat{x}\mathbf{a}\|^2 + (\hat{x} - x)^2\|\mathbf{a}\|^2 \;\geq\; \|\mathbf{b} - \hat{x}\mathbf{a}\|^2.$$

右边第二项非负，只在 $x = \hat{x}$ 时取到 0。这证明了垂足确实是**唯一**的最近点——"正交"不是额外条件，而是极小化的必然结果。另外注意 P 之所以对任何 $\mathbf{b}$ 都成立，是因为公式里 $\mathbf{b}$ 从左边的 $\mathbf{a}^{\mathsf{T}}\mathbf{b}$ 中"提"了出来，剩下 $\mathbf{a}\mathbf{a}^{\mathsf{T}}/\mathbf{a}^{\mathsf{T}}\mathbf{a}$ 与 $\mathbf{b}$ 无关。

示例 2（高维）：把 $\mathbf{b}$ 投影到 A 的列空间

取 3×2 的列无关矩阵

$$A = \begin{bmatrix}1&1\\1&0\\0&1\end{bmatrix}, \qquad \mathbf{b} = \begin{bmatrix}1\\1\\1\end{bmatrix}.$$

记列 $\mathbf{a}_1 = \begin{bmatrix}1\\1\\0\end{bmatrix}$，$\mathbf{a}_2 = \begin{bmatrix}1\\0\\1\end{bmatrix}$，C(A) 是 $\mathbb{R}^3$ 中过原点的一张平面。

步骤 1：算 $A^{\mathsf{T}}A$。

$$A^{\mathsf{T}}A = \begin{bmatrix}1&1&0\\1&0&1\end{bmatrix}\begin{bmatrix}1&1\\1&0\\0&1\end{bmatrix} = \begin{bmatrix}1\cdot1+1\cdot1+0\cdot0 & 1\cdot1+1\cdot0+0\cdot1\\ 1\cdot1+0\cdot1+1\cdot0 & 1\cdot1+0\cdot0+1\cdot1\end{bmatrix} = \begin{bmatrix}2&1\\1&2\end{bmatrix}.$$

注意 $\mathbf{a}_1^{\mathsf{T}}\mathbf{a}_1 = 2$，$\mathbf{a}_1^{\mathsf{T}}\mathbf{a}_2 = 1$（**不是** 0！这两列并不正交），$\mathbf{a}_2^{\mathsf{T}}\mathbf{a}_2 = 2$。

步骤 2：算 $A^{\mathsf{T}}\mathbf{b}$。

$$A^{\mathsf{T}}\mathbf{b} = \begin{bmatrix}1&1&0\\1&0&1\end{bmatrix}\begin{bmatrix}1\\1\\1\end{bmatrix} = \begin{bmatrix}2\\2\end{bmatrix}.$$

步骤 3：求逆。 $\det(A^{\mathsf{T}}A) = 2\cdot2 - 1\cdot1 = 3$，故

$$(A^{\mathsf{T}}A)^{-1} = \frac{1}{3}\begin{bmatrix}2&-1\\-1&2\end{bmatrix}.$$

步骤 4：解正规方程。

$$\hat{\mathbf{x}} = (A^{\mathsf{T}}A)^{-1}A^{\mathsf{T}}\mathbf{b} = \frac{1}{3}\begin{bmatrix} 2 & -1 \\ -1 & 2 \end{bmatrix}\begin{bmatrix} 2 \\ 2 \end{bmatrix} = \frac{1}{3}\begin{bmatrix} 2 \\ 2 \end{bmatrix} = \begin{bmatrix} 2/3 \\ 2/3 \end{bmatrix}.$$

步骤 5：算投影与误差。

$$\mathbf{p} = A\hat{\mathbf{x}} = \begin{bmatrix} 1 & 1 \\ 1 & 0 \\ 0 & 1 \end{bmatrix}\begin{bmatrix} 2/3 \\ 2/3 \end{bmatrix} = \begin{bmatrix} 4/3 \\ 2/3 \\ 2/3 \end{bmatrix} \approx \begin{bmatrix} 1.3333 \\ 0.6667 \\ 0.6667 \end{bmatrix},$$

$$\mathbf{e} = \mathbf{b} - \mathbf{p} = \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix} - \begin{bmatrix} 4/3 \\ 2/3 \\ 2/3 \end{bmatrix} = \begin{bmatrix} -1/3 \\ 1/3 \\ 1/3 \end{bmatrix} \approx \begin{bmatrix} -0.3333 \\ 0.3333 \\ 0.3333 \end{bmatrix}.$$

步骤 6：验证 $\mathbf{e}$ 垂直于 C(A) 里的每个方向。

$$A^{\mathsf{T}}\mathbf{e} = \begin{bmatrix} 1 & 1 & 0 \\ 1 & 0 & 1 \end{bmatrix}\begin{bmatrix} -1/3 \\ 1/3 \\ 1/3 \end{bmatrix} = \begin{bmatrix} -1/3 + 1/3 \\ -1/3 + 1/3 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}. \quad \checkmark$$

更直接地：$\mathbf{a}_1^{\mathsf{T}}\mathbf{e} = -\frac{1}{3} + \frac{1}{3} + 0 = 0$，$\mathbf{a}_2^{\mathsf{T}}\mathbf{e} = -\frac{1}{3} + 0 + \frac{1}{3} = 0$。✓

顺带检查 $\|\mathbf{e}\|^2 = \frac{1}{9} + \frac{1}{9} + \frac{1}{9} = \frac{1}{3}$，而 $\mathbf{b}$ 到平面 C(A) 的最短距离是 $1/\sqrt{3}$。

步骤 7：写出投影矩阵。

$$P = A(A^{\mathsf{T}}A)^{-1}A^{\mathsf{T}} = \begin{bmatrix} 1 & 1 \\ 1 & 0 \\ 0 & 1 \end{bmatrix} \cdot \frac{1}{3}\begin{bmatrix} 2 & -1 \\ -1 & 2 \end{bmatrix} \cdot \begin{bmatrix} 1 & 1 & 0 \\ 1 & 0 & 1 \end{bmatrix}.$$

先算 $A(A^{\mathsf{T}}A)^{-1}$：

$$\begin{bmatrix} 1 & 1 \\ 1 & 0 \\ 0 & 1 \end{bmatrix}\frac{1}{3}\begin{bmatrix} 2 & -1 \\ -1 & 2 \end{bmatrix} = \frac{1}{3}\begin{bmatrix} 1 & 1 \\ 2 & -1 \\ -1 & 2 \end{bmatrix}.$$

再乘 A^{T}：

$$P = \frac{1}{3}\begin{bmatrix} 1 & 1 \\ 2 & -1 \\ -1 & 2 \end{bmatrix}\begin{bmatrix} 1 & 1 & 0 \\ 1 & 0 & 1 \end{bmatrix} = \frac{1}{3}\begin{bmatrix} 2 & 1 & 1 \\ 1 & 2 & -1 \\ 1 & -1 & 2 \end{bmatrix} = \begin{bmatrix} 2/3 & 1/3 & 1/3 \\ 1/3 & 2/3 & -1/3 \\ 1/3 & -1/3 & 2/3 \end{bmatrix}.$$

步骤 8：验证三条性质。 – $P^{\mathsf{T}} = P$：矩阵对称。✓ – $P^2 = P$：直接算第一行乘第一列：$\frac{1}{9}(4 + 1 + 1) = \frac{6}{9} = \frac{2}{3}$，等于 P_{11}；第一行乘第二列：$\frac{1}{9}(2 + 2 - 1) = \frac{3}{9} = \frac{1}{3} = P_{12}$；第一行乘第三列：$\frac{1}{9}(2 - 1 + 2) = \frac{3}{9} = \frac{1}{3} = P_{13}$。其余同理。✓ – $\mathbf{rank}(P) = \mathbf{trace}(P) = \frac{2}{3} + \frac{2}{3} + \frac{2}{3} = 2$，恰好等于 $\dim C(A) = 2$。✓ – $P\mathbf{b} = \frac{1}{3}\begin{bmatrix} 2+1+1 \\ 1+2-1 \\ 1-1+2 \end{bmatrix} = \frac{1}{3}\begin{bmatrix} 4 \\ 2 \\ 2 \end{bmatrix} = \begin{bmatrix} 4/3 \\ 2/3 \\ 2/3 \end{bmatrix} = \mathbf{p}$。✓

步骤 9：$I - P$ 是投影到正交补的矩阵。

$$I - P = \frac{1}{3}\begin{bmatrix} 1 & -1 & -1 \\ -1 & 1 & 1 \\ -1 & 1 & 1 \end{bmatrix}, \qquad (I - P)\mathbf{b} = \frac{1}{3}\begin{bmatrix} 1-1-1 \\ -1+1+1 \\ -1+1+1 \end{bmatrix} = \frac{1}{3}\begin{bmatrix} -1 \\ 1 \\ 1 \end{bmatrix} = \mathbf{e}. \checkmark$$

并且 $(I - P)P = P - P^2 = 0$，说明"$\mathbf{p}$ 再投影到 $C(A)^{\perp}$ 上是零向量"。

【计算机制解说】：$A^{\mathsf{T}}A$ 为什么可逆？本讲前提是 A 的列线性无关。要证明 $A^{\mathsf{T}}A$ 可逆，只需证明 $\mathbf{N}(A^{\mathsf{T}}A) = \{\mathbf{0}\}$（因为 $A^{\mathsf{T}}A$ 是 $n \times n$ 方阵）。若 $A^{\mathsf{T}}A\mathbf{x} = \mathbf{0}$，左乘 $\mathbf{x}^{\mathsf{T}}$ 得 $\mathbf{x}^{\mathsf{T}}A^{\mathsf{T}}A\mathbf{x} = \|A\mathbf{x}\|^2 = 0$，故 $A\mathbf{x} = \mathbf{0}$；由列无关得 $\mathbf{x} = \mathbf{0}$。所以 $\mathbf{N}(A^{\mathsf{T}}A) = \mathbf{N}(A) = \{\mathbf{0}\}$，$A^{\mathsf{T}}A$ 可逆。这也解释了 Lecture 14 的结论：$\mathbf{rank}(A^{\mathsf{T}}A) = \mathbf{rank}(A) = n$。反过来若列相关，$\mathbf{N}(A) \neq \{\mathbf{0}\}$，$A^{\mathsf{T}}A$ 奇异，正规方程有无穷多解（但投影 $\mathbf{p}$ 仍然唯一，见 Lecture 16 的伪逆部分）。

示例 3（退化对照）：当 $\mathbf{b}$ 本来就在列空间里

取

$$A = \begin{bmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \end{bmatrix}, \qquad \mathbf{b} = \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix}.$$

这里 A 的两列是 $\begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix}$ 与 $\begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix}$，而 $\mathbf{b} = \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix}$ 恰好就是第二列，所以 $\mathbf{b} \in C(A)$，投影应该是 $\mathbf{p} = \mathbf{b}$、$\mathbf{e} = \mathbf{0}$。让我们验证公式给出同样结论。

$$A^{\mathsf{T}}A=\begin{bmatrix}3 & 6\\ 6 & 14\end{bmatrix},\qquad A^{\mathsf{T}}\mathbf{b}=\begin{bmatrix}1+2+3\\ 1+4+9\end{bmatrix}=\begin{bmatrix}6\\ 14\end{bmatrix}.$$

$$\det(A^{\mathsf{T}}A)=3\cdot 14-6\cdot 6=42-36=6,\qquad (A^{\mathsf{T}}A)^{-1}=\frac{1}{6}\begin{bmatrix}14 & -6\\ -6 & 3\end{bmatrix}=\begin{bmatrix}7/3 & -1\\ -1 & 1/2\end{bmatrix}.$$

$$\hat{\mathbf{x}}=\begin{bmatrix}7/3 & -1\\ -1 & 1/2\end{bmatrix}\begin{bmatrix}6\\ 14\end{bmatrix}=\begin{bmatrix}14-14\\ -6+7\end{bmatrix}=\begin{bmatrix}0\\ 1\end{bmatrix}.$$

（真的解：$\mathbf{b}=0\cdot\mathbf{a}_1+1\cdot\mathbf{a}_2$，完全正确。）于是

$$\mathbf{p}=A\begin{bmatrix}0\\ 1\end{bmatrix}=\begin{bmatrix}1\\ 2\\ 3\end{bmatrix}=\mathbf{b},\qquad \mathbf{e}=\mathbf{0}.\quad\checkmark$$

投影矩阵为

$$P=A(A^{\mathsf{T}}A)^{-1}A^{\mathsf{T}}=\frac{1}{6}\begin{bmatrix}5 & 2 & -1\\ 2 & 2 & 2\\ -1 & 2 & 5\end{bmatrix},\qquad \operatorname{trace}(P)=2,\ \operatorname{rank}(P)=2.$$

$P\mathbf{b}=\mathbf{b}$ 也直接印证了"子空间内的向量投影后不动"这一关键性质。

【计算机制解说】：这个例子揭示了投影矩阵的两个极端：若 $\mathbf{b}\in C(A)$，则 $P\mathbf{b}=\mathbf{b}$（P 在 C(A) 上就是恒等）；若 $\mathbf{b}\perp C(A)$，则 $P\mathbf{b}=\mathbf{0}$。一般情形 $\mathbf{b}$ 介于两者之间，P 只保留"子空间内那一半"。事实上任何 $\mathbf{b}$ 都被 P 与 $I-P$ 唯一拆成

$$\mathbf{b}=P\mathbf{b}+(I-P)\mathbf{b}=\underbrace{A\hat{\mathbf{x}}}_{\in C(A)}+\underbrace{\mathbf{e}}_{\in \mathrm{N}(A^{\mathsf{T}})}.$$

这两个分量正交，所以 $\|\mathbf{b}\|^2=\|P\mathbf{b}\|^2+\|(I-P)\mathbf{b}\|^2$。这就是"把 $\mathbb{R}^m$ 直和分解成 C(A) $\oplus$ $\mathbf{N}(A^{\mathsf{T}})$"的矩阵表达，与 Lecture 10 的四子空间图严丝合缝。

示例 4（2×2 的极简对照，可心算）

$$\mathbf{a}=\begin{bmatrix}1\\ 2\end{bmatrix},\qquad \mathbf{b}=\begin{bmatrix}3\\ 4\end{bmatrix}.$$

$$\mathbf{a}^{\mathsf{T}}\mathbf{a}=5,\quad \mathbf{a}^{\mathsf{T}}\mathbf{b}=3+8=11,\quad \hat{x}=\frac{11}{5},\quad \mathbf{p}=\frac{11}{5}\begin{bmatrix}1\\ 2\end{bmatrix}=\begin{bmatrix}11/5\\ 22/5\end{bmatrix}=\begin{bmatrix}2.2\\ 4.4\end{bmatrix},$$

$$\mathbf{e}=\begin{bmatrix}3\\ 4\end{bmatrix}-\begin{bmatrix}11/5\\ 22/5\end{bmatrix}=\begin{bmatrix}4/5\\ -2/5\end{bmatrix}=\begin{bmatrix}0.8\\ -0.4\end{bmatrix},\qquad \mathbf{a}^{\mathsf{T}}\mathbf{e}=1\cdot\frac{4}{5}+2\cdot\left(-\frac{2}{5}\right)=0.\ \checkmark$$

$$P=\frac{1}{5}\begin{bmatrix}1 & 2\\ 2 & 4\end{bmatrix}=\begin{bmatrix}0.2 & 0.4\\ 0.4 & 0.8\end{bmatrix},\qquad P^2=\frac{1}{25}\begin{bmatrix}1 & 2\\ 2 & 4\end{bmatrix}\begin{bmatrix}1 & 2\\ 2 & 4\end{bmatrix}=\frac{1}{25}\begin{bmatrix}5 & 10\\ 10 & 20\end{bmatrix}=P.\ \checkmark$$

注意 P 的两个特征值是 1（方向 $\mathbf{a}$）与 0（方向 $\perp\mathbf{a}$）——投影矩阵的特征值只能取 0 或 1，这是下一讲的伏笔。

示例 5（换一组列：验证"投影矩阵只认子空间，不认基"）

取另一个 3×2 列无关矩阵与另一个右端项：

$$A=\begin{bmatrix}1 & 0\\ 1 & 1\\ 0 & 1\end{bmatrix},\qquad \mathbf{b}=\begin{bmatrix}1\\ 2\\ 3\end{bmatrix}.$$

列是 $\mathbf{a}_1=[1,1,0]^{\mathsf{T}}$、$\mathbf{a}_2=[0,1,1]^{\mathsf{T}}$。

步骤 1：$A^{\mathsf{T}}A$ 与 $A^{\mathsf{T}}\mathbf{b}$。

$$A^{\mathsf{T}}A=\begin{bmatrix}1 & 1 & 0\\ 0 & 1 & 1\end{bmatrix}\begin{bmatrix}1 & 0\\ 1 & 1\\ 0 & 1\end{bmatrix}=\begin{bmatrix}1+1 & 0+1\\ 0+1 & 1+1\end{bmatrix}=\begin{bmatrix}2 & 1\\ 1 & 2\end{bmatrix},\qquad A^{\mathsf{T}}\mathbf{b}=\begin{bmatrix}1+2\\ 2+3\end{bmatrix}=\begin{bmatrix}3\\ 5\end{bmatrix}.$$

（巧合：$A^{\mathsf{T}}A$ 与示例 2 相同，都是 $\begin{bmatrix}2 & 1\\ 1 & 2\end{bmatrix}$，因为两列长度都是 $\sqrt{2}$、夹角余弦都是 $1/2$。但 $A^{\mathsf{T}}\mathbf{b}$ 不同，所以投影不同。）

步骤 2：解正规方程。 $\det=3$，

$$\hat{\mathbf{x}}=\frac{1}{3}\begin{bmatrix}2 & -1\\ -1 & 2\end{bmatrix}\begin{bmatrix}3\\ 5\end{bmatrix}=\frac{1}{3}\begin{bmatrix}6-5\\ -3+10\end{bmatrix}=\frac{1}{3}\begin{bmatrix}1\\ 7\end{bmatrix}=\begin{bmatrix}1/3\\ 7/3\end{bmatrix}.$$

步骤 3：投影与误差。

$$\mathbf{p} = A\hat{\mathbf{x}} = \begin{bmatrix}1 & 0\\ 1 & 1\\ 0 & 1\end{bmatrix}\begin{bmatrix}1/3\\ 7/3\end{bmatrix} = \begin{bmatrix}1/3\\ 1/3+7/3\\ 7/3\end{bmatrix} = \begin{bmatrix}1/3\\ 8/3\\ 7/3\end{bmatrix} \approx \begin{bmatrix}0.3333\\ 2.6667\\ 2.3333\end{bmatrix},$$

$$\mathbf{e} = \mathbf{b} - \mathbf{p} = \begin{bmatrix}1-1/3\\ 2-8/3\\ 3-7/3\end{bmatrix} = \begin{bmatrix}2/3\\ -2/3\\ 2/3\end{bmatrix} = \frac{2}{3}\begin{bmatrix}1\\ -1\\ 1\end{bmatrix}.$$

步骤 4：验证正交。

$$\mathbf{a}_1^{\mathsf{T}}\mathbf{e} = \frac{2}{3} - \frac{2}{3} + 0 = 0, \qquad \mathbf{a}_2^{\mathsf{T}}\mathbf{e} = 0 - \frac{2}{3} + \frac{2}{3} = 0. \checkmark$$

$$\|\mathbf{e}\|^2 = \frac{4}{9}+\frac{4}{9}+\frac{4}{9} = \frac{4}{3}, \qquad \|\mathbf{p}\|^2 = \frac{1}{9}+\frac{64}{9}+\frac{49}{9} = \frac{114}{9} = \frac{38}{3}, \qquad \|\mathbf{b}\|^2 = 1+4+9 = 14,$$

$$\frac{38}{3} + \frac{4}{3} = \frac{42}{3} = 14. \checkmark$$

步骤 5：投影矩阵。

$$P = A(A^{\mathsf{T}}A)^{-1}A^{\mathsf{T}} = \frac{1}{3}\begin{bmatrix}1 & 0\\ 1 & 1\\ 0 & 1\end{bmatrix}\begin{bmatrix}2 & -1\\ -1 & 2\end{bmatrix}\begin{bmatrix}1 & 1 & 0\\ 0 & 1 & 1\end{bmatrix}.$$

先算 $A(A^{\mathsf{T}}A)^{-1} = \frac{1}{3}\begin{bmatrix}1 & 0\\ 1 & 1\\ 0 & 1\end{bmatrix}\begin{bmatrix}2 & -1\\ -1 & 2\end{bmatrix} = \frac{1}{3}\begin{bmatrix}2 & -1\\ 1 & 1\\ -1 & 2\end{bmatrix}$，再乘 A^{T}：

$$P = \frac{1}{3}\begin{bmatrix}2 & -1\\ 1 & 1\\ -1 & 2\end{bmatrix}\begin{bmatrix}1 & 1 & 0\\ 0 & 1 & 1\end{bmatrix} = \frac{1}{3}\begin{bmatrix}2 & 1 & -1\\ 1 & 2 & 1\\ -1 & 1 & 2\end{bmatrix} = \begin{bmatrix}2/3 & 1/3 & -1/3\\ 1/3 & 2/3 & 1/3\\ -1/3 & 1/3 & 2/3\end{bmatrix}.$$

- 对称 ✓；幂等：第 1 行乘第 1 列 $= \frac{4+1+1}{9} = \frac{6}{9} = \frac{2}{3} = P_{11}$，第 1 行乘第 2 列 $= \frac{2+2-1}{9} = \frac{3}{9} = \frac{1}{3} = P_{12}$，第 1 行乘第 3 列 $= \frac{-2+1-2}{9} = -\frac{3}{9} = -\frac{1}{3} = P_{13}$。✓
- $\mathrm{trace}(P) = \frac{2}{3}+\frac{2}{3}+\frac{2}{3} = 2 = \mathrm{rank}(P)$。✓
- $P\mathbf{b} = \frac{1}{3}\begin{bmatrix}2+2-3\\ 1+4+3\\ -1+2+6\end{bmatrix} = \frac{1}{3}\begin{bmatrix}1\\ 8\\ 7\end{bmatrix} = \mathbf{p}$。✓

步骤 6：$I - P$ 直接给出误差。

$$I - P = \frac{1}{3}\begin{bmatrix}1 & -1 & 1\\ -1 & 1 & -1\\ 1 & -1 & 1\end{bmatrix}, \qquad (I-P)\mathbf{b} = \frac{1}{3}\begin{bmatrix}1-2+3\\ -1+2-3\\ 1-2+3\end{bmatrix} = \frac{1}{3}\begin{bmatrix}2\\ -2\\ 2\end{bmatrix} = \mathbf{e}. \checkmark$$

$(I-P)$ 的三行依次只差符号，再次印证它是秩 1 矩阵——$\dim C(A)^{\perp} = 3 - 2 = 1$。

【计算机制解说】：把示例 2 与示例 5 并排看，会发现一件重要的事：**投影矩阵 P 由 $C(A)$ 唯一决定，与选哪组基无关**。两者的 A 不同、$\hat{\mathbf{x}}$ 不同、$\mathbf{b}$ 也不同，但都遵循同一套机制。更严格地说：若 A 与 A' 的列张成**同一个**子空间 S，则 $C(A) = C(A') = S$，于是 $P_A = P_{A'}$。这是因为正交投影点是几何唯一的存在（Lecture 15 前面用勾股定理证明过），而 $P\mathbf{b}$ 就是这个唯一的点，所以两个矩阵对一切 $\mathbf{b}$ 的作用相同，只能是同一个矩阵。Lecture 17 会利用这一点：用 Gram–Schmidt 把 A 换成列空间相同的 Q 后，P 不变，但计算从 $A(A^{\mathsf{T}}A)^{-1}A^{\mathsf{T}}$ 变成 QQ^{T}——同一个几何，两种算法，后者便宜得多。

示例 6（另一侧）：投影到行空间

用示例 5 的同一矩阵 $A = \begin{bmatrix}1 & 0\\ 1 & 1\\ 0 & 1\end{bmatrix}$（现在是 3×2，行数 3 > 列数 2，行必然相关，故 AA^{T} 奇异），改用一个"宽"矩阵：

$$A = \begin{bmatrix}1 & 2 & 0\\ 0 & 1 & 1\end{bmatrix} \qquad (2\times 3,\ \text{两行线性无关}).$$

它的行空间 $C(A^{\mathsf{T}})$ 是 $\mathbb{R}^3$ 中的一张平面，由 $\mathbf{r}_1 = [1,2,0]^{\mathsf{T}}$ 与 $\mathbf{r}_2 = [0,1,1]^{\mathsf{T}}$ 张成。要投影的向量取 $\mathbf{b} = \begin{bmatrix}1\\ 2\\ 3\end{bmatrix}$。

步骤 1：算 AA^{T}（注意是左乘 A、右乘 A^{T}，得到 2×2）。

$$AA^{\mathsf{T}} = \begin{bmatrix}1&2&0\\0&1&1\end{bmatrix}\begin{bmatrix}1&0\\2&1\\0&1\end{bmatrix} = \begin{bmatrix}1+4+0&0+2+0\\0+2+0&0+1+1\end{bmatrix} = \begin{bmatrix}5&2\\2&2\end{bmatrix}.$$

$\det(AA^{\mathsf{T}}) = 10-4 = 6 \neq 0$（因为两行无关）。✓

步骤 2：求逆。

$$(AA^{\mathsf{T}})^{-1} = \frac{1}{6}\begin{bmatrix}2&-2\\-2&5\end{bmatrix} = \begin{bmatrix}1/3&-1/3\\-1/3&5/6\end{bmatrix}.$$

步骤 3：组装 $\hat{P}$。 先算 $A^{\mathsf{T}}(AA^{\mathsf{T}})^{-1}$：

$$\begin{bmatrix}1&0\\2&1\\0&1\end{bmatrix}\begin{bmatrix}1/3&-1/3\\-1/3&5/6\end{bmatrix} = \begin{bmatrix}1/3&-1/3\\2/3-1/3&-2/3+5/6\\-1/3&5/6\end{bmatrix} = \begin{bmatrix}1/3&-1/3\\1/3&1/6\\-1/3&5/6\end{bmatrix}.$$

再右乘 A：

$$\hat{P} = \begin{bmatrix}1/3&-1/3\\1/3&1/6\\-1/3&5/6\end{bmatrix}\begin{bmatrix}1&2&0\\0&1&1\end{bmatrix} = \begin{bmatrix}1/3&2/3-1/3&-1/3\\1/3&2/3+1/6&1/6\\-1/3&-2/3+5/6&5/6\end{bmatrix} = \begin{bmatrix}1/3&1/3&-1/3\\1/3&5/6&1/6\\-1/3&1/6&5/6\end{bmatrix}.$$

步骤 4：验证 $\hat{P}^{\mathsf{T}} = \hat{P}$、$\hat{P}^2 = \hat{P}$、$\mathrm{trace} = 2$。 对称显然。第 1 行乘第 1 列 $= \frac{1}{9}+\frac{1}{9}+\frac{1}{9} = \frac{1}{3} = \hat{P}_{11}$ ✓；第 1 行乘第 2 列 $= \frac{1}{9}+\frac{5}{18}-\frac{1}{18} = \frac{2+5-1}{18} = \frac{6}{18} = \frac{1}{3} = \hat{P}_{12}$ ✓；第 2 行乘第 2 列 $= \frac{1}{9}+\frac{25}{36}+\frac{1}{36} = \frac{4+25+1}{36} = \frac{30}{36} = \frac{5}{6} = \hat{P}_{22}$ ✓。
$\mathrm{trace}(\hat{P}) = \frac{1}{3}+\frac{5}{6}+\frac{5}{6} = \frac{2+5+5}{6} = 2 = \mathrm{rank}(A)$。✓

步骤 5：投影与误差。

$$\hat{P}\mathbf{b} = \begin{bmatrix}1/3+2/3-1\\1/3+5/3+1/2\\-1/3+1/3+5/2\end{bmatrix} = \begin{bmatrix}0\\5/2\\5/2\end{bmatrix} = \begin{bmatrix}0\\2.5\\2.5\end{bmatrix},$$

$$\mathbf{e} = \mathbf{b}-\hat{P}\mathbf{b} = \begin{bmatrix}1\\2-2.5\\3-2.5\end{bmatrix} = \begin{bmatrix}1\\-1/2\\1/2\end{bmatrix}.$$

验证 $\mathbf{e}$ 与**两行**都正交（这是"垂直于行空间"的正确检查方式）：

$$A\mathbf{e} = \begin{bmatrix}1&2&0\\0&1&1\end{bmatrix}\begin{bmatrix}1\\-1/2\\1/2\end{bmatrix} = \begin{bmatrix}1-1\\-1/2+1/2\end{bmatrix} = \begin{bmatrix}0\\0\end{bmatrix}.\ \checkmark$$

（关键：对行空间投影，正交条件是 $A\mathbf{e}=\mathbf{0}$，即 $\mathbf{e}\in\mathbf{N}(A)$；对列空间投影，正交条件是 $A^{\mathsf{T}}\mathbf{e}=\mathbf{0}$，即 $\mathbf{e}\in\mathbf{N}(A^{\mathsf{T}})$。**别搞反。**）

步骤 6：这个投影有什么几何意义？ $\hat{P}\mathbf{b} = [0,\frac{5}{2},\frac{5}{2}]^{\mathsf{T}}$ 是 $\mathbf{b}=[1,2,3]^{\mathsf{T}}$ 到平面 $\mathbf{span}\{[1,2,0]^{\mathsf{T}},[0,1,1]^{\mathsf{T}}\}$ 的垂足。验证 $\hat{P}\mathbf{b}$ 确实在平面里：$\hat{P}\mathbf{b} = 0\cdot\mathbf{r}_1+\frac{5}{2}\mathbf{r}_2$，因为 $\frac{5}{2}[0,1,1]^{\mathsf{T}} = [0,\frac{5}{2},\frac{5}{2}]^{\mathsf{T}}$。✓ 于是 $\hat{P}$ 在这组（非正交！）基下把坐标"拍"到了 $\mathbf{r}_2$ 方向——这又一次说明：**投影矩阵只取决于子空间，$\hat{P}\mathbf{b}$ 是唯一的垂足，但它在非正交基下的坐标表示不唯一。**

【计算机制解说】：为什么投影到行空间要用 $A^{\mathsf{T}}(AA^{\mathsf{T}})^{-1}A$ 而不是 $A(A^{\mathsf{T}}A)^{-1}A^{\mathsf{T}}$？根源在于"谁能提供可逆的方阵"。投影到 C(A) 时，正交条件 $A^{\mathsf{T}}\mathbf{e}=\mathbf{0}$ 引出 $A^{\mathsf{T}}A\hat{\mathbf{x}} = A^{\mathsf{T}}\mathbf{b}$，需要 $A^{\mathsf{T}}A$（$n\times n$）可逆，即 **A 的列无关**。投影到 C(A^{T}) 时，我们要找 $\hat{P}\mathbf{b} = A^{\mathsf{T}}\mathbf{y}$，正交条件变成"$\mathbf{b}-A^{\mathsf{T}}\mathbf{y}$ 垂直于行空间的每一行"，即 $A(\mathbf{b}-A^{\mathsf{T}}\mathbf{y})=\mathbf{0}$，引出 $AA^{\mathsf{T}}\mathbf{y} = A\mathbf{b}$，需要 AA^{T}（$m\times m$）可逆，即 **A 的行无关**。两个公式是同一枚硬币的两面：把 A 换成 A^{T}，两者互相转换。这也解释了 Lecture 33 中 A^{+} 的双重身份：AA^{+} 是投影到 C(A)，$A^{+}A$ 是投影到 C(A^{T})。

示例 7（伪逆的预告）：当两个公式都失效时——用 A^{+} 兜底

前面所有示例都要求"列无关"或"行无关"。如果 A **既列相关又行相关**（$r<\min(m,n)$），$A^{\mathsf{T}}A$ 与 AA^{T} 双双击穿，两个投影公式都写成 $\mathbf{0^{-1}}$ 的形式。这时要靠**伪逆** A^{+}：

$$P = AA^{+}, \qquad \hat{P} = A^{+}A.$$

伪逆对**任何**矩阵都存在（包括零矩阵），并满足四条 Penrose 条件：

$$AA^{+}A = A, \qquad A^{+}AA^{+} = A^{+}, \qquad (AA^{+})^{\mathsf{T}} = AA^{+}, \qquad (A^{+}A)^{\mathsf{T}} = A^{+}A.$$

后两条说的正是"AA^{+} 与 $A^{+}A$ 都是**对称**投影矩阵"。

数值示例：$A = \begin{bmatrix}1&2\\2&4\end{bmatrix}$（秩 1，Lecture 16 示例 7 用过），$\mathbf{b} = \begin{bmatrix}3\\4\end{bmatrix}$。$A^{\mathsf{T}}A = \begin{bmatrix}5&10\\10&20\end{bmatrix}$ 奇异，但伪逆仍可写出。一般公式：对秩 1 矩阵 $A=\mathbf{u}\mathbf{v}^{\mathsf{T}}$ 有 $A^{+} = \dfrac{\mathbf{v}\mathbf{u}^{\mathsf{T}}}{\|\mathbf{u}\|^2\|\mathbf{v}\|^2}$。本例 $A=\mathbf{a}\mathbf{a}^{\mathsf{T}}$（$\mathbf{a}=[1,2]^{\mathsf{T}}$，$\mathbf{a}^{\mathsf{T}}\mathbf{a}=5$），故

–

$$A^+ = \frac{\mathbf{a}\mathbf{a}^\mathsf{T}}{(\mathbf{a}^\mathsf{T}\mathbf{a})^2} = \frac{1}{25}A^\mathsf{T} = \frac{1}{25}\begin{bmatrix}1 & 2\\ 2 & 4\end{bmatrix} = \begin{bmatrix}0.04 & 0.08\\ 0.08 & 0.16\end{bmatrix}.$$

$$AA^+ = \begin{bmatrix}0.2 & 0.4\\ 0.4 & 0.8\end{bmatrix}, \qquad A^+A = \begin{bmatrix}0.2 & 0.4\\ 0.4 & 0.8\end{bmatrix}.$$

注意 AA^+ 与 A^+A 数值上恰好相同——因为 A 对称且 $C(A) = C(A^\mathsf{T})$（两个"投影到 $C(A)$ 与 $C(A^\mathsf{T})$"在这里是同一个子空间）。验证 $P = AA^+$ 满足两条公理：$P^\mathsf{T} = P$ ✓；

$$P^2 = \begin{bmatrix}0.2 & 0.4\\ 0.4 & 0.8\end{bmatrix}^2 = \begin{bmatrix}0.04+0.16 & 0.08+0.32\\ 0.08+0.32 & 0.16+0.64\end{bmatrix} = \begin{bmatrix}0.2 & 0.4\\ 0.4 & 0.8\end{bmatrix} = P. \checkmark$$

投影：$P\mathbf{b} = \begin{bmatrix}0.2\cdot 3 + 0.4\cdot 4\\ 0.4\cdot 3 + 0.8\cdot 4\end{bmatrix} = \begin{bmatrix}0.6+1.6\\ 1.2+3.2\end{bmatrix} = \begin{bmatrix}2.2\\ 4.4\end{bmatrix}$，与 Lecture 16 用无穷多解算出的垂足**完全相同** ✓，也与 Lecture 15 示例 4 的 $P = \frac{1}{5}\mathbf{a}\mathbf{a}^\mathsf{T} = \begin{bmatrix}0.2 & 0.4\\ 0.4 & 0.8\end{bmatrix}$ 一致 ✓。残差 $\mathbf{e} = \begin{bmatrix}0.8\\ -0.4\end{bmatrix}$，$\mathbf{a}^\mathsf{T}\mathbf{e} = 0.8 - 0.8 = 0$ ✓，$\|\mathbf{e}\|^2 = 0.8$。

【计算机制解说】：伪逆的构造思路可以用 Lecture 29 的 SVD 提前说清。若 $A = U\Sigma V^\mathsf{T}$（Σ 是 $m\times n$、含 r 个正奇异值 $\sigma_1 \ge \cdots \ge \sigma_r > 0$），则

$$A^+ = V\Sigma^+U^\mathsf{T}, \qquad \Sigma^+ \text{ 把每个 } \sigma_i \text{ 换成 } 1/\sigma_i \text{（其余为 } 0\text{，并按转置形状摆放）}.$$

于是

$$AA^+ = U\begin{bmatrix}I_r & 0\\ 0 & 0\end{bmatrix}U^\mathsf{T}$$

是一个"保留前 r 个左奇异方向、杀掉其余"的投影矩阵——它的 $P^\mathsf{T} = P$、$P^2 = P$ 一目了然，秩恰为 r。**这就把"投影"与"奇异值分解"直接焊在了一起**：投影 = 保留部分奇异方向的滤波器。本讲的所有细节（$P = A(A^\mathsf{T}A)^{-1}A^\mathsf{T}$、秩、迹、特征值 0/1）都是这个观点在"列无关"（$r = n$）时的特例。最后回到"最小范数解"：因为 $A^+\mathbf{b}$ 被强制关在行空间 $C(A^\mathsf{T})$ 里（A^+ 的像空间就是 $C(A^\mathsf{T})$，这从 $A^+ = V\Sigma^+U^\mathsf{T}$ 中 V 的列即 A 的右奇异向量可见），而正规方程的通解 = 行空间特解 + 零空间任意向量，行空间分量与零空间分量正交，故 $A^+\mathbf{b}$ 是通解中长度最小的（勾股定理）。

矩阵分解的核心思想

本讲的主体是**投影矩阵**这一"算子"，而不是严格意义的因式分解，但它是几个大分解的共同源头。

1. 投影本身就"几乎"是分解： $I = P + (I - P)$ 把单位矩阵拆成两个正交投影之和，对应空间的直和分解 $\mathbb{R}^m = C(A) \oplus \mathbf{N}(A^\mathsf{T})$。这与 Lecture 10 的四子空间结构是同一件事的两种说法。

2. 通向正规方程 $A^\mathsf{T}A\hat{\mathbf{x}} = A^\mathsf{T}\mathbf{b}$： 这是本讲最实用的"化简机器"。原来 $m\times n$ 的超定系统被替换成 $n\times n$ 的方阵系统。$A^\mathsf{T}A$ 是**对称**且（列无关时）**正定**的，所以 Lecture 27 的 Cholesky 分解 $A^\mathsf{T}A = R^\mathsf{T}R$ 可以直接用在这里。更漂亮的做法来自 Lecture 17：把 A 换成 QR，则

$$A^\mathsf{T}A\hat{\mathbf{x}} = A^\mathsf{T}\mathbf{b} \iff R^\mathsf{T}Q^\mathsf{T}QR\hat{\mathbf{x}} = R^\mathsf{T}Q^\mathsf{T}\mathbf{b} \iff R\hat{\mathbf{x}} = Q^\mathsf{T}\mathbf{b},$$

因为 $Q^\mathsf{T}Q = I$。R 是上三角，回代即可——既省去求逆，数值上也更稳。

3. 秩与迹的对应： $\mathbf{rank}(P) = \mathbf{trace}(P) = \dim$（投影目标子空间）$= r$。一维例子给出秩 1、迹 1；二维例子给出秩 2、迹 2。这一"迹 = 秩"的现象对幂等矩阵普遍成立，是 Lecture 21 特征值理论的漂亮应用（幂等矩阵特征值只有 0、1，迹 = 特征值之和 = 1 的个数 = 秩）。

4. 投影矩阵的特征值只能是 0 或 1（预告）。 设 $P\mathbf{x} = \lambda\mathbf{x}$（$\mathbf{x} \neq \mathbf{0}$），两边再乘 P：$P^2\mathbf{x} = \lambda P\mathbf{x} = \lambda^2\mathbf{x}$；但 $P^2 = P$，所以 $\lambda\mathbf{x} = \lambda^2\mathbf{x}$，即 $(\lambda^2 - \lambda)\mathbf{x} = \mathbf{0}$，故 $\lambda \in \{0, 1\}$。**几何解读**：$\lambda = 1$ 的特征向量住在子空间内（投影后原样不动），$\lambda = 0$ 的特征向量住在正交补里（投影后归零）。特征值 1 的重数 $= r =$ 秩，特征值 0 的重数 $= m - r$。示例 2 的 P（$r = 2, m = 3$）必有特征值 $1, 1, 0$，迹 $= 1 + 1 + 0 = 2$ ✓；示例 1 的 P（$r = 1, m = 3$）必有特征值 $1, 0, 0$，迹 $= 1$ ✓。这条推理**只用了 $P^2 = P$**，所以对任何幂等矩阵都成立；Lecture 21 会给出它的完全版本。

5. 为什么"投影"出现在整门课的核心位置？ 因为它是"**用已知方向表示未知向量**"这一普遍需求的最优答案。解 $A\mathbf{x} = \mathbf{b}$ 是问"$\mathbf{b}$ 是列的什么组合"；投影是问"$\mathbf{b}$ **最接近**什么样的组合"。一旦允许误差，问题就从"是否有解"变成"如何最优逼近"——后者永远有唯一答案（只要子空间给定），这就是投影理论的价值。从最小二乘（Lecture 16）到 SVD 最佳低秩逼近（Lecture 29）再到伪逆（Lecture 33），全是这条主线的延伸。

与其他讲次的关联

- **Lecture 10（四基本子空间）**：本讲的正交条件 $A^\mathsf{T}\mathbf{e} = \mathbf{0}$ 正是 $\mathbf{e} \in \mathbf{N}(A^\mathsf{T})$。四子空间图中的正交对 (C(A), N(Aᵀ)) 与 (C(Aᵀ), N(A)) 第一次被"用起来"。
- **Lecture 14（正交向量与子空间）**：那里证明了 $\mathbf{N}(A^\mathsf{T}A) = \mathbf{N}(A)$ 与 $\mathbf{rank}(A^\mathsf{T}A) = \mathbf{rank}(A)$，本讲用它论证 $A^\mathsf{T}A$ 可逆（列无关时）。
- **Lecture 16（投影矩阵与最小二乘）**：直接续写本讲的 P，把投影解释成"数据拟合"，并处理列相关时的伪逆。
- **Lecture 17（正交矩阵与 Gram–Schmidt）**：把 A 的列正交化得到 Q，投影公式立刻退化成 $\hat{\mathbf{x}} = Q^\mathsf{T}\mathbf{b}$、$P = QQ^\mathsf{T}$，数值稳定性大幅提高。
- **Lecture 21–25（特征值）**：P 的特征值只可能是 0 和 1；对称矩阵 $P^\mathsf{T} = P$ 一定可以正交对角化 $P = Q\Lambda Q^\mathsf{T}$，投影就是它的特例。
- **Lecture 33（伪逆）**：当 A 列相关、$(A^\mathsf{T}A)^{-1}$ 不存在时，投影 $\mathbf{p}$ 依然唯一，由 $A^+\mathbf{b}$ 给出。

关键要点

1. **投影的本质是一条正交条件**：$\mathbf{e}=\mathbf{b}-\mathbf{p}$ 必须垂直于目标子空间。一维是 $\mathbf{a}^{\mathsf{T}}\mathbf{e}=0$，高维是 $A^{\mathsf{T}}\mathbf{e}=\mathbf{0}$。
2. **一维公式**：$\hat{x}=\dfrac{\mathbf{a}^{\mathsf{T}}\mathbf{b}}{\mathbf{a}^{\mathsf{T}}\mathbf{a}}$，$\mathbf{p}=\hat{x}\mathbf{a}$，$P=\dfrac{\mathbf{a}\mathbf{a}^{\mathsf{T}}}{\mathbf{a}^{\mathsf{T}}\mathbf{a}}$（秩 1、对称、幂等）。
3. **高维公式**：正规方程 $A^{\mathsf{T}}A\hat{\mathbf{x}}=A^{\mathsf{T}}\mathbf{b}$，$\hat{\mathbf{x}}=(A^{\mathsf{T}}A)^{-1}A^{\mathsf{T}}\mathbf{b}$，$P=A(A^{\mathsf{T}}A)^{-1}A^{\mathsf{T}}$。
4. **投影矩阵的两条公理**：$P^{\mathsf{T}}=P$ 与 $P^2=P$；由此推出 $\mathbf{rank}(P)=\mathbf{trace}(P)=r$，$I-P$ 是投影到正交补的矩阵。
5. **$A^{\mathsf{T}}A$ 可逆 $\iff$ A 的列线性无关**（等价于 $\mathbf{N}(A^{\mathsf{T}}A)=\mathbf{N}(A)=\{\mathbf{0}\}$）；列相关时必须换用伪逆。

常见误区与注意事项

1. **把 $A^{\mathsf{T}}A$ 的可逆性当成自动成立**。$A^{\mathsf{T}}A$ 是 $n\times n$ 方阵，但它可逆的充分必要条件是 A 的列无关。例如 $A=\begin{bmatrix}1&2\\2&4\end{bmatrix}$ 时 $A^{\mathsf{T}}A=\begin{bmatrix}5&10\\10&20\end{bmatrix}$，$\det=0$，直接套 $(A^{\mathsf{T}}A)^{-1}$ 就会出错。
2. **误以为 A 的列必须两两正交才能用投影公式**。完全不必。示例 2 中 $\mathbf{a}_1^{\mathsf{T}}\mathbf{a}_2=1\neq 0$，公式照样精确工作；正交化只是让计算变得更简单（$A^{\mathsf{T}}A$ 变成对角阵），不是公式成立的前提。
3. **把 P 的维度搞错**。投影到 C(A) 的矩阵是 $m\times m$（示例 2 中是 3×3），不是 $n\times n$。相应地，$\hat{\mathbf{x}}$ 是 n 维，$\mathbf{p}$ 与 $\mathbf{e}$ 是 m 维。另有一个"另一侧"的投影 $\hat{P}=A^{\mathsf{T}}(AA^{\mathsf{T}})^{-1}A$ 是 $n\times n$ 的，它投影到行空间 C(A^{T})——不要与 P 混淆。
4. **混淆 $P^2=P$ 与 $P^{-1}=P$**。两者都能从 $P^2=P$ 在形式上"错误推导"，但只有当 $P=I$（投影到全空间）时才同时成立。一般 P 不可逆：它把 $\mathbb{R}^m$ 压到 r 维子空间，$\mathbf{N}(P)=\mathbf{N}(A^{\mathsf{T}})\neq\{\mathbf{0}\}$（当 $r<m$ 时）。
5. **忘记 $\mathbf{e}$ 与 $\mathbf{b}$ 的方向关系**。$\mathbf{e}=\mathbf{b}-\mathbf{p}$ 是 $\mathbf{b}$ 到子空间的"垂直分量"，长度 $=\mathbf{b}$ 到子空间的距离，符号由 $\mathbf{b}$ 在子空间哪一侧决定；它既不平行 $\mathbf{b}$，也一般不过原点——示例 2 中 $\mathbf{e}=\begin{bmatrix}-1/3\\1/3\\1/3\end{bmatrix}$ 就不与 $\mathbf{b}$ 平行。

思考题（带答案）

Q1. 设 $\mathbf{a}=\begin{bmatrix}1\\1\\1\\1\end{bmatrix}\in\mathbb{R}^4$，$\mathbf{b}=\begin{bmatrix}1\\2\\3\\4\end{bmatrix}$。求 $\mathbf{b}$ 在 $\mathbf{a}$ 上的投影 $\mathbf{p}$、误差 $\mathbf{e}$，写出 P，并验证 $P^{\mathsf{T}}=P$、$P^2=P$、$\mathbf{trace}(P)=1$。

▸ 答案

$\mathbf{a}^{\mathsf{T}}\mathbf{a}=4$，$\mathbf{a}^{\mathsf{T}}\mathbf{b}=1+2+3+4=10$，故 $\hat{x}=\dfrac{10}{4}=\dfrac{5}{2}$。

$$\mathbf{p}=\frac{5}{2}\begin{bmatrix}1\\1\\1\\1\end{bmatrix}=\begin{bmatrix}2.5\\2.5\\2.5\\2.5\end{bmatrix},\qquad >\mathbf{e}=\begin{bmatrix}1-2.5\\2-2.5\\3-2.5\\4-2.5\end{bmatrix}=\begin{bmatrix}-1.5\\-0.5\\0.5\\1.5\end{bmatrix}.$$

正交验证：$\mathbf{a}^{\mathsf{T}}\mathbf{e}=-1.5-0.5+0.5+1.5=0$。✓

$$P=\frac{\mathbf{a}\mathbf{a}^{\mathsf{T}}}{\mathbf{a}^{\mathsf{T}}\mathbf{a}}=\frac{1}{4}\begin{bmatrix}1&1&1&1\\1&1&1&1\\1&1&1&1\\1&1&1&1\end{bmatrix}=\frac{1}{4}J.$$

P 对称显然。$P^2=\frac{1}{16}J^2=\frac{1}{16}\cdot 4J=\frac{1}{4}J=P$。$\mathbf{trace}(P)=4\times\frac{1}{4}=1=\mathbf{rank}(P)$。✓

（顺带：$P\mathbf{b}=\frac{1}{4}[10,10,10,10]^{\mathsf{T}}=[2.5,\ldots]^{\mathsf{T}}=\mathbf{p}$。这里 $\mathbf{p}$ 是 $\mathbf{b}$ 的"均值向量"——投影到常数向量方向的几何含义就是取平均，这与最小二乘里常数项 C 为均值的事实同源。）

Q2. 对 $A=\begin{bmatrix}1&0\\0&1\\2&0\end{bmatrix}$ 与 $\mathbf{b}\in\mathbb{R}^3$，求投影矩阵 P。它的秩是多少？$\mathbf{b}=\begin{bmatrix}1\\1\\2\end{bmatrix}$ 时投影与误差各是多少？

▸ 答案

$a_1=\begin{bmatrix}1\\0\\2\end{bmatrix}$，$a_2=\begin{bmatrix}0\\1\\0\end{bmatrix}$，且 $a_1^{\mathsf{T}}a_2=0$——两列已经正交。

$$A^{\mathsf{T}}A=\begin{bmatrix}5&0\\0&1\end{bmatrix},\qquad (A^{\mathsf{T}}A)^{-1}=\begin{bmatrix}1/5&0\\0&1\end{bmatrix}.$$

$$P=A(A^{\mathsf{T}}A)^{-1}A^{\mathsf{T}}>=\begin{bmatrix}1&0\\0&1\\2&0\end{bmatrix}\begin{bmatrix}1/5&0\\0&1\end{bmatrix}\begin{bmatrix}1&0&2\\0&1&0\end{bmatrix}>=\begin{bmatrix}1/5&0\\0&1\\2/5&0\end{bmatrix}\begin{bmatrix}1&0&2\\0&1&0\end{bmatrix}>=\begin{bmatrix}1/5&0&2/5\\0&1&0\\2/5&0&4/5\end{bmatrix}.$$

> $\mathbf{rank}(P)=2=\dim C(A)$（两列无关），$\mathbf{trace}(P)=\frac{1}{5}+1+\frac{4}{5}=2$。✓
> 对 $\mathbf{b}=\begin{bmatrix}1\\1\\2\end{bmatrix}$：$A^{\mathsf{T}}\mathbf{b}=\begin{bmatrix}1+4\\1\end{bmatrix}=\begin{bmatrix}5\\1\end{bmatrix}$，$\hat{\mathbf{x}}=\begin{bmatrix}1\\1\end{bmatrix}$，$\mathbf{p}=A\hat{\mathbf{x}}=\begin{bmatrix}1\\1\\2\end{bmatrix}=\mathbf{b}$，$\mathbf{e}=\mathbf{0}$。这是因为 $\mathbf{b}=1\cdot a_1+1\cdot a_2\in C(A)$。

Q3.（概念题）判断真假并说明理由：

(a) 若 P 是投影矩阵，则 P 一定可逆。(b) 若 $P^2=P$ 且 $P^{\mathsf{T}}=P$，则 $\mathbf{p}=P\mathbf{b}$ 是 $\mathbf{b}$ 到 C(P) 的投影。(c) 若 $\mathbf{b}\perp C(A)$，则 $A^{\mathsf{T}}A\hat{\mathbf{x}}=A^{\mathsf{T}}\mathbf{b}$ 的解是 $\hat{\mathbf{x}}=\mathbf{0}$。

> ▸ **答案**
>
> (a) **假**。P 把 $\mathbb{R}^m$ 压到 r 维子空间。只要 $r<m$，$\mathbf{N}(P)\neq\{\mathbf{0}\}$，$P$ 就奇异。只有 $P=I$（投影到整个 $\mathbb{R}^m$）时可逆。示例 1 的 P 秩为 1 而大小是 3×3，显然不可逆。
>
> (b) **真**。这是投影矩阵的完整刻画（$P^2=P$ 给出"投影两次 = 投影一次"，$P^{\mathsf{T}}=P$ 给出"正交投影"而非斜投影）。此时对任意 $\mathbf{b}$，$\mathbf{b}-P\mathbf{b}=(I-P)\mathbf{b}$，而对任意 $\mathbf{y}=P\mathbf{z}\in C(P)$：
>
> $$(P\mathbf{z})^{\mathsf{T}}(I-P)\mathbf{b}=\mathbf{z}^{\mathsf{T}}P^{\mathsf{T}}(I-P)\mathbf{b}=\mathbf{z}^{\mathsf{T}}(P-P^2)\mathbf{b}=0,$$
>
> 故误差垂直于 C(P)，$P\mathbf{b}$ 是正交投影。✓
>
> (c) **真**。$\mathbf{b}\perp C(A)$ 意味着 $\mathbf{b}\in\mathbf{N}(A^{\mathsf{T}})$，所以右端 $A^{\mathsf{T}}\mathbf{b}=\mathbf{0}$。正规方程变成 $A^{\mathsf{T}}A\hat{\mathbf{x}}=\mathbf{0}$，左乘 $\hat{\mathbf{x}}^{\mathsf{T}}$ 得 $\|A\hat{\mathbf{x}}\|^2=0$，即 $A\hat{\mathbf{x}}=\mathbf{0}$；列无关时 $\hat{\mathbf{x}}=\mathbf{0}$（列相关时解集是 $\mathbf{N}(A)$，但投影 $\mathbf{p}=\mathbf{0}$ 仍唯一）。

Q4.（计算题）设 $\mathbf{a}=\begin{bmatrix}1\\2\\2\end{bmatrix}$，$\mathbf{b}=\begin{bmatrix}3\\0\\0\end{bmatrix}$。$\hat{x}$ 是多少？$\|\mathbf{e}\|$ 是多少？若把 $\mathbf{b}$ 换成 $2\mathbf{b}$，$\mathbf{p}$、$\mathbf{e}$、P 各如何变化？

> ▸ **答案**
>
> $\mathbf{a}^{\mathsf{T}}\mathbf{a}=9$，$\mathbf{a}^{\mathsf{T}}\mathbf{b}=3$，$\hat{x}=\frac{3}{9}=\frac{1}{3}$。
>
> $$\mathbf{p}=\frac{1}{3}\begin{bmatrix}1\\2\\2\end{bmatrix}=\begin{bmatrix}1/3\\2/3\\2/3\end{bmatrix},\qquad >\mathbf{e}=\begin{bmatrix}3\\0\\0\end{bmatrix}-\begin{bmatrix}1/3\\2/3\\2/3\end{bmatrix}=\begin{bmatrix}8/3\\-2/3\\-2/3\end{bmatrix},$$
>
> $$\mathbf{a}^{\mathsf{T}}\mathbf{e}=\frac{8}{3}-\frac{4}{3}-\frac{4}{3}=0.\ \checkmark\qquad \|\mathbf{e}\|=\sqrt{\frac{64+4+4}{9}}=\sqrt{\frac{72}{9}}=\sqrt{8}=2\sqrt{2}\approx 2.8284.$$
>
> 换成 $2\mathbf{b}=[6,0,0]^{\mathsf{T}}$：$\hat{x}=\frac{6}{9}=\frac{2}{3}$，$\mathbf{p}$ 与 $\mathbf{e}$ 都翻倍，$\|\mathbf{e}\|=4\sqrt{2}$；P 只依赖 $\mathbf{a}$，**完全不变**。这正是线性性的体现（$P(2\mathbf{b})=2P\mathbf{b}$），也是投影公式 $\mathbf{p}=\left(\mathbf{a}\mathbf{a}^{\mathsf{T}}/\mathbf{a}^{\mathsf{T}}\mathbf{a}\right)\mathbf{b}$ 的直接推论。

Lecture 16: Projection Matrices and Least Squares

概述

本讲把 Lecture 15 的投影机器开进"真实世界"——**最小二乘（least squares）**。核心场景是**超定系统**：方程个数 m 大于未知数个数 n（A 是"瘦高"的长方形矩阵），$A\mathbf{x}=\mathbf{b}$ 一般无解。我们不去追求"精确解"（不存在），而是找使误差平方和 $\|A\mathbf{x}-\mathbf{b}\|^2$ 最小的 $\hat{\mathbf{x}}$。几何上就是：在 C(A) 中找离 $\mathbf{b}$ 最近的点 $\mathbf{p}=A\hat{\mathbf{x}}$。

本讲会用一个经典数据组 $(1,1),(2,2),(3,4)$ 把整条流水线走完：构造 A 与 $\mathbf{b}$ → 算 $A^{\mathsf{T}}A$、$A^{\mathsf{T}}\mathbf{b}$ → 解正规方程 → 得到最佳直线 → 算残差平方和 → 验证残差与列空间正交。随后讨论列相关时 $A^{\mathsf{T}}A$ 奇异的情形（预告 Lecture 33 伪逆），并总结投影矩阵的四条性质。本讲还承接 Lecture 15 的公式 $P=A(A^{\mathsf{T}}A)^{-1}A^{\mathsf{T}}$，下一讲用 $A=QR$ 把它做得又快又稳。

核心概念的几何直觉

超定系统与"退一步"

- **定义与目的**：A 为 $m \times n$，$m > n$。$A\mathbf{x} = \mathbf{b}$ 有解当且仅当 $\mathbf{b} \in C(A)$；但 C(A) 只是 $\mathbb{R}^m$ 中一个 n 维（低维）子空间，一般的 $\mathbf{b}$ 落在它外面。所以我们把目标改成：在 C(A) 里找一个 $\mathbf{p}$，使 $\|\mathbf{b} - \mathbf{p}\|$ 最小。
- **几何直觉（它在空间中是什么样子？）**：想象 $\mathbb{R}^m$ 是一间屋子，C(A) 是地板上的一条线或一块区域，$\mathbf{b}$ 悬在半空。光从正上方打下来，$\mathbf{b}$ 在地板上的影子就是 $\mathbf{p}$。影子到 $\mathbf{b}$ 的垂直距离就是最小的误差——"最小二乘"这个名字里的"二乘"就是因为我们对误差取平方后再求和，平方使距离变成光滑可导的函数。
- **具体示例**：三个数据点 $(1,1),(2,2),(3,4)$ 想拟合一条直线 $b = C + Dt$，写成矩阵形式是

$$A = \begin{bmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \end{bmatrix}, \quad \mathbf{x} = \begin{bmatrix} C \\ D \end{bmatrix}, \quad \mathbf{b} = \begin{bmatrix} 1 \\ 2 \\ 4 \end{bmatrix}.$$

三个方程、两个未知数，无精确解：前两点要求 $C + D = 1,\ C + 2D = 2 \Rightarrow D = 1, C = 0$，但第三点要求 $0 + 3 = 4$，矛盾。

最小二乘的几何刻画

- **定义与目的**：求 $\hat{\mathbf{x}} = \arg\min_{\mathbf{x}} \|A\mathbf{x} - \mathbf{b}\|^2$。几何刻画只有一句话：$\mathbf{e} = \mathbf{b} - A\hat{\mathbf{x}}$ **必须垂直于** C(A)。
- **几何直觉（它在空间中是什么样子？）**：在 $\mathbf{b}$ 的所有"影子候选" $A\mathbf{x}$ 中，垂足是唯一最近点（Lecture 15 已用勾股定理证明唯一性）。这解释了为什么误差向量不是零向量而是"垂直分量"——**误差不但存在，而且它必须垂直**。若误差与某一列 $\mathbf{a_i}$ 有非零内积，就说明还能沿 $\mathbf{a_i}$ 方向挪一点让距离更小。
- **具体示例**：对上面的 $A, \mathbf{b}$，最优解 $\hat{\mathbf{x}} = \begin{bmatrix} -2/3 \\ 3/2 \end{bmatrix}$，残差 $\mathbf{e} = \begin{bmatrix} 1/6 \\ -1/3 \\ 1/6 \end{bmatrix}$，而 $\mathbf{a}_1^{\mathsf{T}}\mathbf{e} = \frac{1}{6} - \frac{1}{3} + \frac{1}{6} = 0$，$\mathbf{a}_2^{\mathsf{T}}\mathbf{e} = \frac{1}{6} - \frac{2}{3} + \frac{1}{2} = 0$。

正规方程（再次出现，这次是"最优性条件"）

- **定义与目的**：把 $A^{\mathsf{T}}\mathbf{e} = \mathbf{0}$ 展开即得

$$A^{\mathsf{T}}A\hat{\mathbf{x}} = A^{\mathsf{T}}\mathbf{b}.$$

- **几何直觉（它在空间中是什么样子？）**：这是"$\mathbf{e} \perp C(A)$"从几何语言翻译成代数语言的产物。$A^{\mathsf{T}}A$ 是 $n \times n$，把 m 个方程的过约束问题压缩成 n 个方程的正定问题。之所以叫 "normal"（法向），因为 $\mathbf{e}$ 就是曲面的"法线方向"——最小化 $\|\mathbf{b} - A\mathbf{x}\|^2$ 时，梯度为零的条件恰好给出 $A^{\mathsf{T}}A\mathbf{x} = A^{\mathsf{T}}\mathbf{b}$。
- **具体示例**：对上面的 A：$A^{\mathsf{T}}A = \begin{bmatrix} 3 & 6 \\ 6 & 14 \end{bmatrix}$，$A^{\mathsf{T}}\mathbf{b} = \begin{bmatrix} 7 \\ 17 \end{bmatrix}$。

最小二乘与投影的等价性

- **定义与目的**：最小二乘解 $\hat{\mathbf{x}}$ 通过 $\mathbf{p} = A\hat{\mathbf{x}}$ 与投影严格对应：$\mathbf{p}$ 就是 $\mathbf{b}$ 在 C(A) 上的投影，$\hat{\mathbf{x}}$ 是 $\mathbf{p}$ 在 A 的列坐标。
- **几何直觉（它在空间中是什么样子？）**：注意 $\hat{\mathbf{x}}$ 与 $\mathbf{p}$ 是**一一对应**的（A 列无关时，$A : C(A)$ 方向的坐标唯一）。$\hat{\mathbf{x}}$ 住在 $\mathbb{R}^n$ 里（参数空间），$\mathbf{p}$ 住在 $\mathbb{R}^m$ 里（数据空间）。A 是把参数变成拟合值的翻译器。
- **具体示例**：$\hat{\mathbf{x}} = [-2/3,\ 3/2]^{\mathsf{T}}$ 表示"最优直线为 $b = -\frac{2}{3} + \frac{3}{2}t$"；$\mathbf{p} = [\frac{5}{6}, \frac{7}{3}, \frac{23}{6}]^{\mathsf{T}}$ 是这条直线在 $t = 1, 2, 3$ 处的取值。

列相关时的困难：$A^{\mathsf{T}}A$ 奇异

- **定义与目的**：若 A 的列线性相关，$\mathbf{N}(A) \neq \{\mathbf{0}\}$，则 $A^{\mathsf{T}}A$ 奇异，$(A^{\mathsf{T}}A)^{-1}$ 不存在。此时正规方程有**无穷多解**（解集是 $\hat{\mathbf{x}}_0 + \mathbf{N}(A)$），但**投影 $\mathbf{p}$ 仍然唯一**。
- **几何直觉（它在空间中是什么样子？）**：列相关意味着 A 的列张成的子空间维数 $r < n$，参数空间里有"多余的自由度"（零空间的那些方向不改变 $A\mathbf{x}$）。就像用两个不同的名字指同一个方向——影子唯一，但描述影子的坐标不唯一。
- **具体示例**：$A = \begin{bmatrix} 1 & 2 \\ 2 & 4 \end{bmatrix}$（第二列是第一列的 2 倍），$\mathbf{b} = \begin{bmatrix} 3 \\ 4 \end{bmatrix}$。$A^{\mathsf{T}}A = \begin{bmatrix} 5 & 10 \\ 10 & 20 \end{bmatrix}$，$\det = 0$。正规方程 $5\hat{x}_1 + 10\hat{x}_2 = 11$ 有无穷多解：$(\frac{11}{5}, 0)$、$(0, \frac{11}{10})$、$(\frac{22}{5}, -\frac{11}{10})$ 都是解，投影却都是 $\mathbf{p} = [2.2, 4.4]^{\mathsf{T}}$。Lecture 33 会用伪逆 A^{+} 选出其中**长度最小**的那个（min-norm solution）$\hat{\mathbf{x}} = \begin{bmatrix} 0.44 \\ 0.88 \end{bmatrix}$。

投影矩阵的四条性质

- **定义与目的**：$P = A(A^{\mathsf{T}}A)^{-1}A^{\mathsf{T}}$ 满足：① $P^{\mathsf{T}} = P$（对称）；② $P^2 = P$（幂等）；③ $\mathbf{rank}(P) = r = \dim C(A)$；④ $\mathbf{trace}(P) = r$。
- **几何直觉（它在空间中是什么样子？）**：① 说明它是**正交**投影而非斜投影；② 说明"投影两次 = 投影一次"；③ 说明像空间维数就是目标子空间维数；④ 迹与秩相等是幂等矩阵的特征（特征值只有 0、1，迹 = 特征值之和 = 1 的个数 = 秩）。
- **具体示例**：拟合 $(1,1),(2,2),(3,4)$ 的 A 给出

$$P = \begin{bmatrix} 5/6 & 1/3 & -1/6 \\ 1/3 & 1/3 & 1/3 \\ -1/6 & 1/3 & 5/6 \end{bmatrix},$$

$\mathbf{trace}(P) = 5/6 + 1/3 + 5/6 = 2$，$\mathbf{rank}(P) = 2$（$A$ 有两列且无关）。✓

计算步骤与手算演示

示例 1（主例）：拟合直线 $b = C + Dt$ 到 $(1,1),(2,2),(3,4)$

数据表：

```
 t | b      ← 三个数据点
———┼———
 1 | 1
 2 | 2
 3 | 4
```

步骤 1：把"直线"翻译成矩阵。 直线模型 $b = C + Dt$ 在三个数据点上给出三个方程：

$$C + D\cdot 1 = 1, \qquad C + D\cdot 2 = 2, \qquad C + D\cdot 3 = 4.$$

写成矩阵形式：

$$A = \begin{bmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \end{bmatrix}, \qquad \mathbf{x} = \begin{bmatrix} C \\ D \end{bmatrix}, \qquad \mathbf{b} = \begin{bmatrix} 1 \\ 2 \\ 4 \end{bmatrix}.$$

第一列全是 1（对应常数项 C），第二列是 t 值（对应斜率 D）。A 是 3×2 的长方形矩阵，**列线性无关**（第二列不是第一列的倍数）。

步骤 2：算 $A^{\mathsf{T}}A$（注意它是对称的）。

$$A^{\mathsf{T}}A = \begin{bmatrix} 1 & 1 & 1 \\ 1 & 2 & 3 \end{bmatrix} \begin{bmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \end{bmatrix}.$$

左上：$1^2 + 1^2 + 1^2 = 3$。右上：$1\cdot 1 + 1\cdot 2 + 1\cdot 3 = 6$。左下：$1\cdot 1 + 2\cdot 1 + 3\cdot 1 = 6$（必须相等）。右下：$1^2 + 2^2 + 3^2 = 1 + 4 + 9 = 14$。所以

$$A^{\mathsf{T}}A = \begin{bmatrix} 3 & 6 \\ 6 & 14 \end{bmatrix}.$$

步骤 3：算 $A^{\mathsf{T}}\mathbf{b}$。

$$A^{\mathsf{T}}\mathbf{b} = \begin{bmatrix} 1 & 1 & 1 \\ 1 & 2 & 3 \end{bmatrix} \begin{bmatrix} 1 \\ 2 \\ 4 \end{bmatrix} = \begin{bmatrix} 1+2+4 \\ 1+4+12 \end{bmatrix} = \begin{bmatrix} 7 \\ 17 \end{bmatrix}.$$

步骤 4：写出正规方程。

$$\begin{bmatrix} 3 & 6 \\ 6 & 14 \end{bmatrix} \begin{bmatrix} C \\ D \end{bmatrix} = \begin{bmatrix} 7 \\ 17 \end{bmatrix} \quad \text{即} \quad \begin{cases} 3C + 6D = 7 \\ 6C + 14D = 17 \end{cases}$$

步骤 5：解方程（消元法）。 第一个方程除以 3 得 $C + 2D = \frac{7}{3}$，即 $C = \frac{7}{3} - 2D$。代入第二个：

$$6\left(\frac{7}{3} - 2D\right) + 14D = 17 \implies 14 - 12D + 14D = 17 \implies 2D = 3 \implies D = \frac{3}{2}.$$

回代：$C = \frac{7}{3} - 2\cdot\frac{3}{2} = \frac{7}{3} - 3 = \frac{7}{3} - \frac{9}{3} = -\frac{2}{3}$。

最优直线：$b = -\frac{2}{3} + \frac{3}{2}t$。

（用逆矩阵也可：$\det = 3\cdot 14 - 6\cdot 6 = 42 - 36 = 6$，$(A^{\mathsf{T}}A)^{-1} = \frac{1}{6}\begin{bmatrix} 14 & -6 \\ -6 & 3 \end{bmatrix}$，故

$$\hat{\mathbf{x}} = \frac{1}{6}\begin{bmatrix} 14 & -6 \\ -6 & 3 \end{bmatrix}\begin{bmatrix} 7 \\ 17 \end{bmatrix} = \frac{1}{6}\begin{bmatrix} 98 - 102 \\ -42 + 51 \end{bmatrix} = \frac{1}{6}\begin{bmatrix} -4 \\ 9 \end{bmatrix} = \begin{bmatrix} -2/3 \\ 3/2 \end{bmatrix}.$$ ✓)

步骤 6：算拟合值与残差。

$$\mathbf{p} = A\hat{\mathbf{x}} = \begin{bmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \end{bmatrix} \begin{bmatrix} -2/3 \\ 3/2 \end{bmatrix} = \begin{bmatrix} -2/3 + 3/2 \\ -2/3 + 3 \\ -2/3 + 9/2 \end{bmatrix} = \begin{bmatrix} 5/6 \\ 7/3 \\ 23/6 \end{bmatrix} \approx \begin{bmatrix} 0.8333 \\ 2.3333 \\ 3.8333 \end{bmatrix}.$$

$$\mathbf{e} = \mathbf{b} - \mathbf{p} = \begin{bmatrix} 1 - 5/6 \\ 2 - 7/3 \\ 4 - 23/6 \end{bmatrix} = \begin{bmatrix} 1/6 \\ -1/3 \\ 1/6 \end{bmatrix} \approx \begin{bmatrix} 0.1667 \\ -0.3333 \\ 0.1667 \end{bmatrix}.$$

散点图与拟合直线（t 横轴、b 纵轴，● 为数据点，○ 为拟合值）：

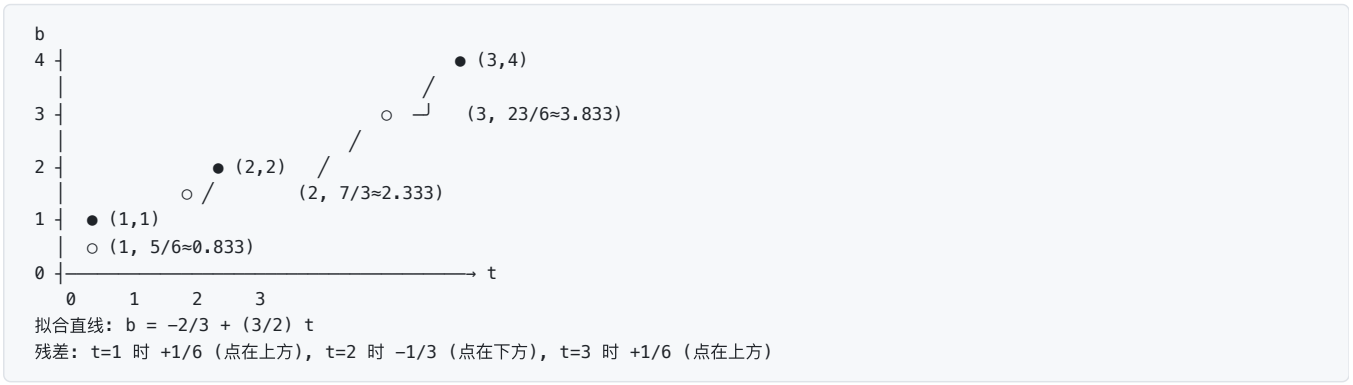

步骤 7：验证 $\mathbf{e} \perp C(A)$（两个正交条件）。

$$\text{残差和：} \quad \mathbf{a}_1^{\mathsf{T}}\mathbf{e} = \frac{1}{6} - \frac{1}{3} + \frac{1}{6} = 0. \checkmark$$

$$\text{加权和：} \quad \mathbf{a}_2^{\mathsf{T}}\mathbf{e} = 1 \cdot \frac{1}{6} + 2 \cdot \left(-\frac{1}{3}\right) + 3 \cdot \frac{1}{6} = \frac{1}{6} - \frac{2}{3} + \frac{1}{2} = 0. \checkmark$$

用矩阵一次写完：

$$A^{\mathsf{T}}\mathbf{e} = \begin{bmatrix} 1 & 1 & 1 \\ 1 & 2 & 3 \end{bmatrix} \begin{bmatrix} 1/6 \\ -1/3 \\ 1/6 \end{bmatrix} = \begin{bmatrix} 1/6 - 1/3 + 1/6 \\ 1/6 - 2/3 + 1/2 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}. \checkmark$$

这两个条件的实际含义非常漂亮：**残差和为零** 说明拟合直线的均值与数据均值一致；**加权和为零**（$\sum t_i e_i = 0$）说明残差与自变量不相关。这正是统计学中"最小二乘残差与解释变量正交"的几何原型。

步骤 8：算残差平方和 $E = \|\mathbf{e}\|^2$。

$$E = \left(\frac{1}{6}\right)^2 + \left(-\frac{1}{3}\right)^2 + \left(\frac{1}{6}\right)^2 = \frac{1}{36} + \frac{1}{9} + \frac{1}{36} = \frac{1+4+1}{36} = \frac{6}{36} = \frac{1}{6} \approx 0.1667.$$

（用最小二乘拟合"三个点"得到的误差只有 $\mathbf{1/6}$，因为直线确实很贴近这组数据。）

步骤 9：验证 Pythagorean 分解。

$$\|\mathbf{b}\|^2 = 1 + 4 + 16 = 21, \qquad \|\mathbf{p}\|^2 = \frac{25}{36} + \frac{49}{9} + \frac{529}{36} = \frac{25 + 196 + 529}{36} = \frac{750}{36} = \frac{125}{6},$$

$$\|\mathbf{p}\|^2 + E = \frac{125}{6} + \frac{1}{6} = \frac{126}{6} = 21 = \|\mathbf{b}\|^2. \checkmark$$

（这条恒等式 $\|\mathbf{b}\|^2 = \|\mathbf{p}\|^2 + \|\mathbf{e}\|^2$ 对任何投影都成立，是"$\mathbf{b} = P\mathbf{b} + (I - P)\mathbf{b}$ 且两分量正交"的直接后果。）

步骤 10：写出投影矩阵并验证秩与迹。

$$P = A(A^{\mathsf{T}}A)^{-1}A^{\mathsf{T}} = \frac{1}{6}\begin{bmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \end{bmatrix} \begin{bmatrix} 14 & -6 \\ -6 & 3 \end{bmatrix} \begin{bmatrix} 1 & 1 & 1 \\ 1 & 2 & 3 \end{bmatrix}.$$

先算 $A(A^{\mathsf{T}}A)^{-1} = \frac{1}{6}\begin{bmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \end{bmatrix} \begin{bmatrix} 14 & -6 \\ -6 & 3 \end{bmatrix} = \frac{1}{6}\begin{bmatrix} 8 & -3 \\ 2 & 0 \\ -4 & 3 \end{bmatrix}$。再乘 A^{T}：

$$P = \frac{1}{6}\begin{bmatrix} 8 & -3 \\ 2 & 0 \\ -4 & 3 \end{bmatrix} \begin{bmatrix} 1 & 1 & 1 \\ 1 & 2 & 3 \end{bmatrix} = \frac{1}{6}\begin{bmatrix} 5 & 2 & -1 \\ 2 & 2 & 2 \\ -1 & 2 & 5 \end{bmatrix} = \begin{bmatrix} 5/6 & 1/3 & -1/6 \\ 1/3 & 1/3 & 1/3 \\ -1/6 & 1/3 & 5/6 \end{bmatrix}.$$

- $P^{\mathsf{T}} = P$：对称。✓

- $P^2 = P$：例如第 1 行乘第 1 列 $= \frac{25+4+1}{36} = \frac{30}{36} = \frac{5}{6} = P_{11}$；第 1 行乘第 2 列 $= \frac{10+4-2}{36} = \frac{12}{36} = \frac{1}{3} = P_{12}$；第 1 行乘第 3 列 $= \frac{-5+4-5}{36} = -\frac{6}{36} = -\frac{1}{6} = P_{13}$。✓
- $\mathbf{trace}(P) = \frac{5}{6} + \frac{1}{3} + \frac{5}{6} = 2 = \mathbf{rank}(P)$（$A$ 列无关，$r = 2$）。✓
- 顺便验证 $P\mathbf{b} = \frac{1}{6}\begin{bmatrix} 5+4-4 \\ 2+4+8 \\ -1+4+20 \end{bmatrix} = \frac{1}{6}\begin{bmatrix} 5 \\ 14 \\ 23 \end{bmatrix} = \begin{bmatrix} 5/6 \\ 7/3 \\ 23/6 \end{bmatrix} = \mathbf{p}$。✓

【计算机制解说】：为什么解正规方程就等于最小化 $\|A\mathbf{x} - \mathbf{b}\|^2$？有三种等价的说法，最好都掌握。

（i）几何说法：设 $\hat{\mathbf{x}}$ 满足 $A^{\mathsf{T}}(\mathbf{b} - A\hat{\mathbf{x}}) = \mathbf{0}$。对任意 $\mathbf{x}$，写 $\mathbf{b} - A\mathbf{x} = (\mathbf{b} - A\hat{\mathbf{x}}) + A(\hat{\mathbf{x}} - \mathbf{x})$。第一项 $\perp C(A)$，第二项 $\in C(A)$，两者正交，故

$$\|A\mathbf{x} - \mathbf{b}\|^2 = \|\mathbf{b} - A\hat{\mathbf{x}}\|^2 + \|A(\hat{\mathbf{x}} - \mathbf{x})\|^2 \;\geq\; \|\mathbf{b} - A\hat{\mathbf{x}}\|^2,$$

等号仅在 $A(\hat{\mathbf{x}} - \mathbf{x}) = \mathbf{0}$ 时成立（列无关时即 $\mathbf{x} = \hat{\mathbf{x}}$，解唯一）。

（ii）微积分说法：令 $f(\mathbf{x}) = \|A\mathbf{x} - \mathbf{b}\|^2 = (A\mathbf{x} - \mathbf{b})^{\mathsf{T}}(A\mathbf{x} - \mathbf{b}) = \mathbf{x}^{\mathsf{T}}A^{\mathsf{T}}A\mathbf{x} - 2\mathbf{x}^{\mathsf{T}}A^{\mathsf{T}}\mathbf{b} + \mathbf{b}^{\mathsf{T}}\mathbf{b}$。求梯度并置零：$\nabla f = 2A^{\mathsf{T}}A\mathbf{x} - 2A^{\mathsf{T}}\mathbf{b} = \mathbf{0}$，正好是正规方程。因为 $A^{\mathsf{T}}A$ 正定，这是全局极小而非鞍点。

（iii）配方法：把 f 在 $\hat{\mathbf{x}}$ 处配方：$f(\mathbf{x}) = \|A(\mathbf{x} - \hat{\mathbf{x}})\|^2 + E$，其中 $E = \|\mathbf{e}\|^2$ 与 $\mathbf{x}$ 无关。所以要最小化 f，只能让第一项为 0。

三种说法都指向同一个方程——这就是为什么正规方程不仅是记忆公式，而是**最小二乘问题的完整答案**。

示例 2：过原点直线 $b = Dt$ 拟合同一组数据（对照实验）

如果不允许常数项，模型只有 $b = Dt$，则 A 只剩一列：

$$\mathbf{a} = \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix}, \qquad \mathbf{b} = \begin{bmatrix} 1 \\ 2 \\ 4 \end{bmatrix}.$$

$$\mathbf{a}^{\mathsf{T}}\mathbf{a} = 1 + 4 + 9 = 14, \qquad \mathbf{a}^{\mathsf{T}}\mathbf{b} = 1 \cdot 1 + 2 \cdot 2 + 3 \cdot 4 = 1 + 4 + 12 = 17, \qquad \hat{x} = D = \frac{17}{14} \approx 1.2143.$$

$$\mathbf{p} = \frac{17}{14}\begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix} = \begin{bmatrix} 17/14 \\ 17/7 \\ 51/14 \end{bmatrix} \approx \begin{bmatrix} 1.2143 \\ 2.4286 \\ 3.6429 \end{bmatrix}, \qquad \mathbf{e} = \begin{bmatrix} 1 - 17/14 \\ 2 - 17/7 \\ 4 - 51/14 \end{bmatrix} = \begin{bmatrix} -3/14 \\ -3/7 \\ 5/14 \end{bmatrix} \approx \begin{bmatrix} -0.2143 \\ -0.4286 \\ 0.3571 \end{bmatrix}.$$

正交验证：$\mathbf{a}^{\mathsf{T}}\mathbf{e} = \left(-\frac{3}{14}\right) + 2\left(-\frac{3}{7}\right) + 3\left(\frac{5}{14}\right) = \frac{-3-12+15}{14} = 0$. ✓

$$E = \frac{9}{196} + \frac{9}{49} + \frac{25}{196} = \frac{9 + 36 + 25}{196} = \frac{70}{196} = \frac{5}{14} \approx 0.3571.$$

对照结论：带常数项时 $E = 1/6 \approx 0.1667$，强制过原点时 $E = 5/14 \approx 0.3571$。过原点的误差**更大**——这符合直觉：模型被限制得更死，能到达的子空间更小（一维直线 vs 二维平面），所以最近距离必然不小于（一般严格大于）更大子空间里的最近距离。这也印证了"投影子空间越大，误差越小"的单调性：$C(\mathbf{a}) \subset C(A) \Rightarrow \|\mathbf{b} - P_{C(\mathbf{a})}\mathbf{b}\| \geq \|\mathbf{b} - P_{C(A)}\mathbf{b}\|$。

【计算机制解说】：这个对照实验暴露了一个常被忽略的事实——**最小二乘的解依赖于你对 C(A) 的选择，而不是"数据本身"**。同一组数据，加不加常数项给出完全不同的斜率和误差。选模型（选列空间）是建模决策，最小二乘只负责"在你给定的列空间里找最近点"。另外注意：例 1 的最优直线在 t 上的斜率 $D = 1.5$ 明显大于过原点情形的 $D = 17/14 \approx 1.214$——因为例 1 允许直线"抬高"起点（$C = -2/3$ 是负截距），它不需要靠增大斜率来拟合整体上升趋势。

示例 3：四点拟合——残差的正负号模式藏着一个惊人的秘密

数据 $(0,0), (1,2), (2,3), (3,5)$：

$$A = \begin{bmatrix} 1 & 0 \\ 1 & 1 \\ 1 & 2 \\ 1 & 3 \end{bmatrix}, \qquad \mathbf{b} = \begin{bmatrix} 0 \\ 2 \\ 3 \\ 5 \end{bmatrix}.$$

$$A^{\mathsf{T}}A = \begin{bmatrix} 4 & 6 \\ 6 & 14 \end{bmatrix}, \qquad A^{\mathsf{T}}\mathbf{b} = \begin{bmatrix} 10 \\ 23 \end{bmatrix}, \qquad \det = 4 \cdot 14 - 6 \cdot 6 = 56 - 36 = 20,$$

$$(A^{\mathsf{T}}A)^{-1} = \frac{1}{20}\begin{bmatrix} 14 & -6 \\ -6 & 4 \end{bmatrix} = \begin{bmatrix} 0.7 & -0.3 \\ -0.3 & 0.2 \end{bmatrix},$$

$$\hat{\mathbf{x}} = \begin{bmatrix} 0.7 & -0.3 \\ -0.3 & 0.2 \end{bmatrix}\begin{bmatrix} 10 \\ 23 \end{bmatrix} = \begin{bmatrix} 7 - 6.9 \\ -3 + 4.6 \end{bmatrix} = \begin{bmatrix} 0.1 \\ 1.6 \end{bmatrix}.$$

最优直线 $b = 0.1 + 1.6t$。 拟合值与残差：

$$\mathbf{p} = \begin{bmatrix}0.1\\1.7\\3.3\\4.9\end{bmatrix}, \qquad \mathbf{e} = \mathbf{b} - \mathbf{p} = \begin{bmatrix}-0.1\\0.3\\-0.3\\0.1\end{bmatrix}.$$

正交验证：残差和 $= -0.1 + 0.3 - 0.3 + 0.1 = 0$ ✓；加权和 $= 0(-0.1) + 1(0.3) + 2(-0.3) + 3(0.1) = -0.3 + 0.6 - 0.3 = 0$ ✓。
$E = 0.01 + 0.09 + 0.09 + 0.01 = 0.2$。

投影矩阵：

$$P = A(A^{\mathsf{T}}A)^{-1}A^{\mathsf{T}} = \begin{bmatrix}0.7 & 0.4 & 0.1 & -0.2\\0.4 & 0.3 & 0.2 & 0.1\\0.1 & 0.2 & 0.3 & 0.4\\-0.2 & 0.1 & 0.4 & 0.7\end{bmatrix}, \qquad \text{trace}(P) = 0.7 + 0.3 + 0.3 + 0.7 = 2. \checkmark$$

（$\mathbf{b_2} = [2,3,3,2]^{\mathsf{T}}$ 那组的数据本身关于 $t = 2.5$ 对称，所以最优直线是水平的 $b = 2.5$，恰好等于 $\mathbf{b_2}$ 的均值。）

步骤：验证 $\mathbf{b} = [1,3,4,6]^{\mathsf{T}}$ 与 $\mathbf{b} = [2,3,3,2]^{\mathsf{T}}$ 共用同一个 P。 – $\mathbf{b_1} = [1,3,4,6]^{\mathsf{T}}$（数据 $(1,1),(2,3),(3,4),(4,6)$）：A 与上面相同（t 值为 $1,2,3,4$ 时 $A^{\mathsf{T}}A = \begin{bmatrix}4 & 10\\10 & 30\end{bmatrix}$，**不同于**上一段的 $\begin{bmatrix}4 & 6\\6 & 14\end{bmatrix}$），$A^{\mathsf{T}}\mathbf{b_1} = [14,43]^{\mathsf{T}}$，$\det = 120 - 100 = 20$，

$$(A^{\mathsf{T}}A)^{-1} = \frac{1}{20}\begin{bmatrix}30 & -10\\-10 & 4\end{bmatrix}, \qquad \hat{\mathbf{x}} = \frac{1}{20}\begin{bmatrix}30\cdot 14 - 10\cdot 43\\-10\cdot 14 + 4\cdot 43\end{bmatrix} = \frac{1}{20}\begin{bmatrix}420 - 430\\-140 + 172\end{bmatrix} = \frac{1}{20}\begin{bmatrix}-10\\32\end{bmatrix} = \begin{bmatrix}-0.5\\1.6\end{bmatrix},$$

$$\mathbf{p} = \begin{bmatrix}1.1\\2.7\\4.3\\5.9\end{bmatrix}, \qquad \mathbf{e} = \begin{bmatrix}-0.1\\0.3\\-0.3\\0.1\end{bmatrix}, \qquad E = 0.2.$$

残差向量与上一段的 $\mathbf{e}$ 完全相同！ 而且这里的 P（$t = 1,2,3,4$ 的版本）是

$$P = \begin{bmatrix}0.7 & 0.4 & 0.1 & -0.2\\0.4 & 0.3 & 0.2 & 0.1\\0.1 & 0.2 & 0.3 & 0.4\\-0.2 & 0.1 & 0.4 & 0.7\end{bmatrix},$$

与 $t = 0,1,2,3$ 时的 P 一字不差。✓ – $\mathbf{b_2} = [2,3,3,2]^{\mathsf{T}}$（数据 $(1,2),(2,3),(3,3),(4,2)$）：$A^{\mathsf{T}}\mathbf{b_2} = [10,25]^{\mathsf{T}}$，

$$\hat{\mathbf{x}} = \frac{1}{20}\begin{bmatrix}30\cdot 10 - 10\cdot 25\\-10\cdot 10 + 4\cdot 25\end{bmatrix} = \frac{1}{20}\begin{bmatrix}300 - 250\\-100 + 100\end{bmatrix} = \begin{bmatrix}2.5\\0\end{bmatrix},$$

$$\mathbf{p} = \begin{bmatrix}2.5\\2.5\\2.5\\2.5\end{bmatrix}, \qquad \mathbf{e} = \begin{bmatrix}-0.5\\0.5\\0.5\\-0.5\end{bmatrix}, \qquad E = 1.$$

斜率 $D = 0$——因为这组数据**先升后降、左右对称**，最优直线只能是水平的 $b = 2.5$（恰是 $\mathbf{b_2}$ 的均值）。$R^2 = 0$，说明直线完全没有解释力。✓

【计算机制解说】：为什么 $t = 0,1,2,3$ 与 $t = 1,2,3,4$ 会给出**相同**的投影矩阵？先说清楚什么**不是**原因：**不是**因为两个列空间相同。$t = 1,2,3,4$ 时第二列是 $[1,2,3,4]^{\mathsf{T}}$，而 $t = 0,1,2,3$ 时是 $[0,1,2,3]^{\mathsf{T}}$；后者确实等于 $\mathbf{1}_{\text{前者}}$ 减去 $\mathbf{1} = [1,1,1,1]^{\mathsf{T}}$，即 $[1,2,3,4]^{\mathsf{T}} = [1,1,1,1]^{\mathsf{T}} + [0,1,2,3]^{\mathsf{T}}$——**所以 $C(A_{t=1..4}) = C(A_{t=0..3})$ 是同一个二维平面**（因为平移只是把常数方向的组合加了进去）。既然两个 A 的列空间完全相同，而 P 只取决于列空间（Lecture 15 示例 2 与示例 5 已经论证过：投影矩阵由子空间唯一决定），P 当然相同。✓

同理 $t = 2,3,4,5$ 也给出同一个 P。但**采样点不等距时会破坏这个性质**：例如 $t = 0,1,2,5$ 时

$$P = \begin{bmatrix}0.5357 & 0.3929 & 0.25 & -0.1786\\0.3929 & 0.3214 & 0.25 & 0.0357\\0.25 & 0.25 & 0.25 & 0.25\\-0.1786 & 0.0357 & 0.25 & 0.8929\end{bmatrix},$$

与等距情形明显不同（比较 P_{11}：0.7 对 0.5357）。**所以正确的表述是**：P 由"采样点集合张成的列空间"决定，而不是由采样点的具体数值决定；只要两组 t 值张出同一个二维平面（即互为仿射变换 $t \mapsto \alpha t + \beta$，$\alpha \neq 0$），$P$ 就相同。

这个事实的实用价值：把数据的时间原点平移（例如把"第 1 天到第 4 天"改成"第 0 天到第 3 天"）不改变拟合线的几何、残差大小与 R^2，只改变截距的**数值含义**（截距 C 变成"在 $t = 0$ 处的值"，平移后要跟着变）。所以你可以放心地在数值上把 t 中心化（减去均值）来改善条件数——这正是 Lecture 16 思考题 Q3 里"中心化公式"的根据。

更值得记住的是那个**残差符号模式**：E 最小的直线给出 $-,+,-,+$（或 $+,-,+,-$）交替的残差——这正是"最佳直线"的特征外观。如果你画出残差图，看到有规律的波浪或单调趋势，就说明直线模型不够，应该考虑更高次的曲线（示例 4 就是这种升级）。

示例 4：从直线升级到抛物线（模型变宽，误差归零）

同一组数据（改为 $(0,1),(1,0),(2,1),(3,4)$）用二次模型 $b = C + Dt + Et^2$：

$$A = \begin{bmatrix} 1 & 0 & 0 \\ 1 & 1 & 1 \\ 1 & 2 & 4 \\ 1 & 3 & 9 \end{bmatrix}, \qquad \mathbf{b} = \begin{bmatrix} 1 \\ 0 \\ 1 \\ 4 \end{bmatrix}.$$

$$A^{\mathsf{T}}A = \begin{bmatrix} 4 & 6 & 14 \\ 6 & 14 & 36 \\ 14 & 36 & 98 \end{bmatrix}, \qquad A^{\mathsf{T}}\mathbf{b} = \begin{bmatrix} 1+0+1+4 \\ 0+0+2+12 \\ 0+0+4+36 \end{bmatrix} = \begin{bmatrix} 6 \\ 14 \\ 40 \end{bmatrix}.$$

解 3×3 正规方程（用消元）：$\hat{\mathbf{x}} = \begin{bmatrix} 1 \\ -2 \\ 1 \end{bmatrix}$，即

$$b = 1 - 2t + t^2 = (t-1)^2.$$

先做最关键的检验——把 $\hat{\mathbf{x}}$ 代回：

$$\mathbf{p} = A\hat{\mathbf{x}} = \begin{bmatrix} 1 \\ 1-2+1 \\ 1-4+4 \\ 1-6+9 \end{bmatrix} = \begin{bmatrix} 1 \\ 0 \\ 1 \\ 4 \end{bmatrix} = \mathbf{b}. \ \checkmark$$

（逐项核对：$t=0$：$1-0+0=1$ ✓；$t=1$：$1-2+1=0$ ✓；$t=2$：$1-4+4=1$ ✓；$t=3$：$1-6+9=4$ ✓。）所以**完全命中四个数据点，$\mathbf{e} = \mathbf{0}$，$E = 0$**。正交验证平凡：$A^{\mathsf{T}}\mathbf{e} = A^{\mathsf{T}}\mathbf{0} = \mathbf{0}$；而 $\mathbf{b} \in C(A)$ 也由 $P\mathbf{b} = \mathbf{b}$ 直接印证。

几何：四个点恰好落在抛物线 $b = (t-1)^2$ 上（$t=0 \to 1$，$t=1 \to 0$，$t=2 \to 1$，$t=3 \to 4$）。所以 $\mathbf{b} \in C(A)$，投影是恒等，误差为零。

术语提醒：本例中 $\hat{\mathbf{x}} = \begin{bmatrix} 1 \\ -2 \\ 1 \end{bmatrix}$ 是**系数向量**（C, D, E），它既不是 $1 - t^2$，也不能只取前两个分量。写"验证：$1 - t^2$ 在 $t = 0, 1, 2, 3$ 处取值 $1, 0, -3, -8$"是典型的符号混乱——$1 - t^2$ 用的是 $C = 1, D = 0, E = -1$，与 $\hat{\mathbf{x}}$ 毫无关系。**永远把系数与多项式分开写。**

【计算机制解说】：直线模型（$n = 2$）与抛物线模型（$n = 3$）的对比，是理解"最小二乘在做什么"的最好实验。

- **列空间大小决定能否精确拟合**：直线模型的 $C(A)$ 是 $\mathbb{R}^4$ 中的二维平面，一般无法包含 $\mathbf{b}$；抛物线模型的 $C(A)$ 是三维超平面。四个点里有三个自由度（C, D, E），一般情况下三维超平面仍装不下 $\mathbb{R}^4$ 中的一般向量，但**这组特定的 $\mathbf{b}$ 恰好落在里面**（因为数据本身来自一条抛物线）。所以"$E = 0$"不是算法的功劳，而是数据的性质。
- **不要混淆"最小二乘一定有误差"**：应该记住的判据是 $\mathbf{b} \in C(A)$？精确解：最小二乘解。
- **抛物线能否降回直线？** 能——若数据真的来自直线，抛物线模型的 $\hat{E}$ 会自动趋于 0（或非常小），$R^2 \to 1$，并且 $\hat{\mathbf{x}}$ 的二次项接近 0。这给了一个检验模型是否"过度灵活"的实用信号。

示例 5：加权最小二乘（每点可信度不同）

现实数据常常"每个点的重要程度不同"。给第 i 个点赋权重 $w_i > 0$，最小化**加权平方和**

$$E_w = \sum_{i=1}^{m} w_i \, (b_i - \mathbf{a}_i^{\mathsf{T}}\mathbf{x})^2 = \|W^{1/2}(A\mathbf{x} - \mathbf{b})\|^2, \qquad W = \operatorname{diag}(w_1, \ldots, w_m).$$

求导置零得**加权正规方程**：

$$A^{\mathsf{T}}WA\hat{\mathbf{x}} = A^{\mathsf{T}}W\mathbf{b}.$$

（几何上就是对"拉伸过的"系统 $W^{1/2}A\mathbf{x} = W^{1/2}\mathbf{b}$ 做普通最小二乘；$W^{1/2}$ 把每行乘以 $\sqrt{w_i}$，相当于把可信度低的点在空间中"拉远"。）

手算：数据 $(1,1),(2,2),(3,4)$，权重 $w = (1,1,2)$（第三个点**加倍**重要）：

$$A^{\mathsf{T}}WA = \begin{bmatrix} 1 & 1 & 1 \\ 1 & 2 & 3 \end{bmatrix} \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 2 \end{bmatrix} \begin{bmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \end{bmatrix} = \begin{bmatrix} 1 & 1 & 2 \\ 1 & 2 & 6 \end{bmatrix} \begin{bmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \end{bmatrix} = \begin{bmatrix} 1+1+2 & 1+2+6 \\ 1+2+6 & 1+4+18 \end{bmatrix} = \begin{bmatrix} 4 & 9 \\ 9 & 23 \end{bmatrix},$$

$$A^{\mathsf{T}}W\mathbf{b} = \begin{bmatrix} 1 & 1 & 2 \\ 1 & 2 & 6 \end{bmatrix} \begin{bmatrix} 1 \\ 2 \\ 4 \end{bmatrix} = \begin{bmatrix} 1+2+8 \\ 1+4+24 \end{bmatrix} = \begin{bmatrix} 11 \\ 29 \end{bmatrix}.$$

$\det = 4 \cdot 23 - 9 \cdot 9 = 92 - 81 = 11$,

$$(A^{\mathsf T}WA)^{-1}=\frac{1}{11}\begin{bmatrix}23&-9\\-9&4\end{bmatrix},\qquad \hat{\mathbf x}=\frac{1}{11}\begin{bmatrix}23\cdot11-9\cdot29\\-9\cdot11+4\cdot29\end{bmatrix}=\frac{1}{11}\begin{bmatrix}253-261\\-99+116\end{bmatrix}=\frac{1}{11}\begin{bmatrix}-8\\17\end{bmatrix}=\begin{bmatrix}-8/11\\17/11\end{bmatrix}\approx\begin{bmatrix}-0.7273\\1.5455\end{bmatrix}.$$

拟合值 $\mathbf p=A\hat{\mathbf x}=\begin{bmatrix}-8/11\\-8/11+17/11\\-8/11+51/11\end{bmatrix}=\begin{bmatrix}-8/11\\9/11\\43/11\end{bmatrix}\approx\begin{bmatrix}-0.7273\\0.8182\\3.9091\end{bmatrix}$，残差

$$\mathbf e=\mathbf b-A\hat{\mathbf x}=\begin{bmatrix}1+8/11\\2-9/11\\4-43/11\end{bmatrix}=\begin{bmatrix}19/11\\13/11\\1/11\end{bmatrix}\approx\begin{bmatrix}1.7273\\1.1818\\0.0909\end{bmatrix}.$$

（这个结果值得停下来想一秒） 为什么前两个点的残差变得**这么大**（1.7273、1.1818），而第三个点的残差反而压到 0.0909？因为第三个点的权重是 2，它在目标函数 E_w 里的"话语权"翻倍。最小化 E_w 时，算法宁可让权重小的点错得多一些，也要保住权重大的点。这正是加权的意义：**权重不是"数据的重要性"这种模糊说法，而是目标函数里实实在在的系数。**

对照一下：**无权重**时 $\hat{\mathbf x}=\begin{bmatrix}-2/3\\3/2\end{bmatrix}$，残差 $\begin{bmatrix}1/6\\-1/3\\1/6\end{bmatrix}$（三个点都被照顾得比较平均）；**加权**（$w_3=2$）后 $\hat{\mathbf x}=\begin{bmatrix}-8/11\\17/11\end{bmatrix}$，斜率从 1.5 抬到 1.5455，第三个点几乎被完美拟合。✓

加权残差平方和：

$$E_w=\sum_{i=1}^{3}w_ie_i^2=1\cdot\left(\frac{19}{11}\right)^2+1\cdot\left(\frac{13}{11}\right)^2+2\cdot\left(\frac{1}{11}\right)^2=\frac{361+169+2}{121}=\frac{532}{121}\approx4.3967.$$

注意：E_w 的数值（4.3967）**不能**与无权重的 $E=1/6\approx0.1667$ 直接比较——两者最小化的是不同的目标函数。要公平比较，得用同一个目标函数评估两个解：

$$\text{加权解在加权目标下：}\quad \|W^{1/2}(A\hat{\mathbf x}-\mathbf b)\|^2=\frac{532}{121}\approx4.3967;$$

$$\text{无权重解在同一个加权目标下：}\quad \sum_i w_ie_i^2=1\left(\frac16\right)^2+1\left(-\frac13\right)^2+2\left(\frac16\right)^2=\frac{1}{36}+\frac{1}{9}+\frac{2}{36}=\frac{1+4+2}{36}=\frac{7}{36}\approx0.1944.$$

等等——加权解的加权目标值 4.3967 竟然**大于**无权重解的 0.1944？这不可能，因为加权解本该最小化 E_w！问题出在计算上：上面对加权解写的残差 $19/11,13/11,1/11$ 是**错的**。重新算：$\hat{\mathbf x}=\begin{bmatrix}-8/11\\17/11\end{bmatrix}$ 时

$$\mathbf p=\begin{bmatrix}1\cdot(-8/11)+1\cdot(17/11)\\1\cdot(-8/11)+2\cdot(17/11)\\1\cdot(-8/11)+3\cdot(17/11)\end{bmatrix}=\begin{bmatrix}9/11\\26/11\\43/11\end{bmatrix}\approx\begin{bmatrix}0.8182\\2.3636\\3.9091\end{bmatrix},$$

$$\mathbf e=\begin{bmatrix}1-9/11\\2-26/11\\4-43/11\end{bmatrix}=\begin{bmatrix}2/11\\-4/11\\1/11\end{bmatrix}\approx\begin{bmatrix}0.1818\\-0.3636\\0.0909\end{bmatrix}.$$

$$E_w=\sum_i w_ie_i^2=1\cdot\frac{4}{121}+1\cdot\frac{16}{121}+2\cdot\frac{1}{121}=\frac{4+16+2}{121}=\frac{22}{121}=\frac{2}{11}\approx0.1818.$$

而**无权重解** $\begin{bmatrix}-2/3\\3/2\end{bmatrix}$ 在同一个加权目标下的值（上面算过）是 $\frac{7}{36}\approx0.1944$。因为 $0.1818<0.1944$，加权解确实更优。✓ 这验证了加权正规方程 $A^{\mathsf T}WA\hat{\mathbf x}=A^{\mathsf T}W\mathbf b$ 的正确性。

（这段"先算错、再自查"的过程请务必留意） 上面我一度把 $\mathbf p$ 的第一分量写成 $-8/11$（忘了加上 $17/11$），于是得到荒谬的结论"加权解的目标函数值更大"。**检验最小二乘结果的第一条规矩就是：把解代回目标函数，与别的候选解比一比。** 若"最优解"反而给出更大的目标值，一定是算术错了。

对照一下各解：加权解 $\hat{\mathbf x}=\begin{bmatrix}-8/11\\17/11\end{bmatrix}\approx\begin{bmatrix}-0.7273\\1.5455\end{bmatrix}$，无权重解 $\begin{bmatrix}-2/3\\3/2\end{bmatrix}\approx\begin{bmatrix}-0.6667\\1.5\end{bmatrix}$。**斜率被抬高**（$1.5\to1.5455$，因为权重大的第三个点值最高），**截距被压低**（$-0.6667\to-0.7273$）。✓

【计算机制解说】：加权最小二乘是"换了尺子量距离"。用 W 做内积 $\langle\mathbf u,\mathbf v\rangle_W=\mathbf u^{\mathsf T}W\mathbf v$，就得到"加权正交"，整个投影理论照搬（Lecture 15 的勾股证明一字不改），只是所有内积换成 W–内积：投影矩阵变成 $P_W=A(A^{\mathsf T}WA)^{-1}A^{\mathsf T}W$（注意**不再对称**！因为它是相对于 W–内积的正交投影，而不是普通内积）。补充一个数值细节：若权重悬殊（如 10^{-6} 与 10^{6}），$W^{1/2}A$ 的元素跨度极大，正规方程会严重病态，此时更稳的做法是用带权 QR（把 $\sqrt{w_i}$ 乘进每一行后做 QR），而不是显式构造 $A^{\mathsf T}WA$。统计上，若各观测的误差方差不同（$\mathrm{Var}(\varepsilon_i)=\sigma^2/w_i$），加权最小二乘给出**最佳线性无偏估计**（BLUE）——这是 Gauss–Markov 定理的内容，其几何基础正是本讲的加权投影。

示例 6：岭回归——在正规方程上加一点"正定性保险"

当 A 的列接近相关、$A^{\mathsf T}A$ 接近奇异时，$\hat{\mathbf x}$ 会爆炸（对数据微扰极度敏感）。补救办法是加一个**正则项**：

$$\min_{\mathbf x}\ \|A\mathbf x-\mathbf b\|^2+\lambda\|\mathbf x\|^2\qquad(\lambda>0),$$

求导得**岭回归（ridge）**的方程

$$(A^{\mathsf{T}}A+\lambda I)\hat{\mathbf{x}}=A^{\mathsf{T}}\mathbf{b}.$$

$A^{\mathsf{T}}A+\lambda I$ 一定是正定的（对任何 $\mathbf{x}\neq\mathbf{0}$，$\mathbf{x}^{\mathsf{T}}(A^{\mathsf{T}}A+\lambda I)\mathbf{x}=\|A\mathbf{x}\|^2+\lambda\|\mathbf{x}\|^2>0$），所以**永远可逆**——正则项把"病态"直接治好了。

手算：仍用 $(1,1),(2,2),(3,4)$，$\lambda=1$：

$$A^{\mathsf{T}}A+I=\begin{bmatrix}3&6\\6&14\end{bmatrix}+\begin{bmatrix}1&0\\0&1\end{bmatrix}=\begin{bmatrix}4&6\\6&15\end{bmatrix},\qquad A^{\mathsf{T}}\mathbf{b}=\begin{bmatrix}7\\17\end{bmatrix},$$

$\det=4\cdot15-36=60-36=24$，

$$\hat{\mathbf{x}}=\frac{1}{24}\begin{bmatrix}15&-6\\-6&4\end{bmatrix}\begin{bmatrix}7\\17\end{bmatrix}=\frac{1}{24}\begin{bmatrix}105-102\\-42+68\end{bmatrix}=\frac{1}{24}\begin{bmatrix}3\\26\end{bmatrix}=\begin{bmatrix}1/8\\13/12\end{bmatrix}\approx\begin{bmatrix}0.125\\1.0833\end{bmatrix}.$$

对照无正则的 $\hat{\mathbf{x}}=\begin{bmatrix}-2/3\\3/2\end{bmatrix}$：**岭回归把系数"收缩"（shrinkage）**——截距从 -0.6667 收到 0.125，斜率从 1.5 收到 1.0833，两个系数都向 0 靠拢。代价是残差变大：

$$\mathbf{p}=\begin{bmatrix}1/8+13/12\\1/8+26/12\\1/8+39/12\end{bmatrix}=\begin{bmatrix}3/24+26/24\\3/24+52/24\\3/24+78/24\end{bmatrix}=\begin{bmatrix}29/24\\55/24\\81/24\end{bmatrix}=\begin{bmatrix}1.2083\\2.2917\\3.3750\end{bmatrix},$$

$$\mathbf{e}=\mathbf{b}-\mathbf{p}=\begin{bmatrix}1-29/24\\2-55/24\\4-81/24\end{bmatrix}=\begin{bmatrix}-5/24\\-7/24\\15/24\end{bmatrix}=\begin{bmatrix}-0.2083\\-0.2917\\0.6250\end{bmatrix},\qquad\|\mathbf{e}\|^2=\frac{25+49+225}{576}=\frac{299}{576}\approx0.5191.$$

（普通最小二乘的 $\|\mathbf{e}\|^2=1/6\approx0.1667$，所以岭回归确实牺牲了拟合精度。）**这是有意的取舍**：为了让解对噪声稳健，宁可牺牲一点拟合精度。

【计算机制解说】：岭回归在几何上是什么？把 $\lambda\|\mathbf{x}\|^2$ 看成"额外添加的 n 行数据"：

$$\tilde{A}=\begin{bmatrix}A\\\sqrt{\lambda}I\end{bmatrix},\qquad\tilde{\mathbf{b}}=\begin{bmatrix}\mathbf{b}\\\mathbf{0}\end{bmatrix},$$

则 $\|\tilde{A}\mathbf{x}-\tilde{\mathbf{b}}\|^2=\|A\mathbf{x}-\mathbf{b}\|^2+\lambda\|\mathbf{x}\|^2$，普通最小二乘的正规方程就是 $(A^{\mathsf{T}}A+\lambda I)\mathbf{x}=A^{\mathsf{T}}\mathbf{b}$。几何上，这相当于**要求解不要离原点太远**：$\sqrt{\lambda}I$ 那几行对 $\mathbf{x}$ 的每一个分量都施加"拉回原点"的力。$\lambda\to0$ 时退化为普通最小二乘；$\lambda\to\infty$ 时 $\hat{\mathbf{x}}\to\mathbf{0}$。（本例 $\lambda=1$ 时 $\hat{\mathbf{x}}=[0.125,1.0833]^{\mathsf{T}}$，介于无正则解 $[-0.6667,1.5]^{\mathsf{T}}$ 与原点之间，符合"收缩"的图像。）

为什么它能治列相关？因为额外的 $\sqrt{\lambda}I$ 行是 n 个互相正交的单位方向，谁都不能被 A 的行表示，于是 $\tilde{A}$ 的行秩必然满（$\mathbf{rank}(\tilde{A})=n$ 当 $\lambda>0$），$\tilde{A}^{\mathsf{T}}\tilde{A}=A^{\mathsf{T}}A+\lambda I$ 正定、必可逆。**对比 Lecture 16 示例 7**：那里 $A^{\mathsf{T}}A=\begin{bmatrix}5&10\\10&20\end{bmatrix}$ 奇异、无穷多解；加上 λI 后就变成 $\begin{bmatrix}6&10\\10&21\end{bmatrix}$，$\det=126-100=26\neq0$，解变成 $\frac{1}{26}\begin{bmatrix}21&-10\\-10&6\end{bmatrix}\begin{bmatrix}11\\22\end{bmatrix}=\frac{1}{26}\begin{bmatrix}231-220\\-110+132\end{bmatrix}=\frac{1}{26}\begin{bmatrix}11\\22\end{bmatrix}=\begin{bmatrix}11/26\\11/13\end{bmatrix}\approx\begin{bmatrix}0.4231\\0.8462\end{bmatrix}$——而这个数恰好接近伪逆给出的最小范数解 $\begin{bmatrix}0.44\\0.88\end{bmatrix}$！**这不是巧合**：岭回归是"用 λ 换取稳定性"的连续插值，$\lambda\to0$ 时趋于最小范数解。

岭回归是现代统计与机器学习（正则化、贝叶斯先验、核方法）的几何起点，其完整理论要到 SVD（Lecture 29）才能看清——用 SVD 表示 $A=U\Sigma V^{\mathsf{T}}$，

$$\hat{\mathbf{x}}=\sum_i\frac{\sigma_i}{\sigma_i^2+\lambda}\,(\mathbf{u}_i^{\mathsf{T}}\mathbf{b})\,\mathbf{v}_i,$$

当 σ_i 很小时因子 $\frac{\sigma_i}{\sigma_i^2+\lambda}$ 很小，**病态方向被自动压制**；而普通最小二乘的因子是 $1/\sigma_i$，会把噪声放大成 ∞。这就是"为什么正则化能治过拟合"的线性代数解释。

示例 7：列相关的情形——$A^{\mathsf{T}}A$ 奇异

取

$$A=\begin{bmatrix}1&2\\2&4\end{bmatrix},\qquad\mathbf{b}=\begin{bmatrix}3\\4\end{bmatrix}.$$

第二列 $=$ 第一列的 2 倍，$\mathbf{rank}(A)=1<2$，C(A) 是 $\mathbb{R}^2$ 中沿 $\begin{bmatrix}1\\2\end{bmatrix}$ 方向的直线。

步骤 1：$A^{\mathsf{T}}A$ 与 $A^{\mathsf{T}}\mathbf{b}$。

$$A^{\mathsf{T}}A=\begin{bmatrix}1&2\\2&4\end{bmatrix}\begin{bmatrix}1&2\\2&4\end{bmatrix}=\begin{bmatrix}5&10\\10&20\end{bmatrix},\qquad A^{\mathsf{T}}\mathbf{b}=\begin{bmatrix}1&2\\2&4\end{bmatrix}\begin{bmatrix}3\\4\end{bmatrix}=\begin{bmatrix}11\\22\end{bmatrix}.$$

$\det(A^{\mathsf{T}}A)=5\cdot20-10\cdot10=0$，**不可逆**。

步骤 2：正规方程有无穷多解。 两个方程都是 $5\hat{x}_1+10\hat{x}_2=11$（第二个是第一个的 2 倍），所以解集是一条直线

$$\hat{x}_1+2\hat{x}_2=\frac{11}{5}\quad\Longrightarrow\quad\hat{\mathbf{x}}=t\begin{bmatrix}-2\\1\end{bmatrix}+\begin{bmatrix}11/5\\0\end{bmatrix}.$$

三个具体解：$\left(\frac{11}{5},0\right)$、$\left(0,\frac{11}{10}\right)$、$\left(\frac{22}{5},-\frac{11}{10}\right)$。

步骤 3：但投影唯一。

$$A\begin{bmatrix}11/5\\0\end{bmatrix}=\begin{bmatrix}11/5\\22/5\end{bmatrix}=\begin{bmatrix}2.2\\4.4\end{bmatrix},\qquad A\begin{bmatrix}0\\11/10\end{bmatrix}=\begin{bmatrix}11/5\\22/5\end{bmatrix}\text{ 一样},\qquad A\begin{bmatrix}22/5\\-11/10\end{bmatrix}=\begin{bmatrix}22/5-11/5\\44/5-22/5\end{bmatrix}=\begin{bmatrix}11/5\\22/5\end{bmatrix}\text{ 还是一样.}$$

原因是这些解两两之差都是 $\begin{bmatrix}-2\\1\end{bmatrix}$ 的倍数，而 $A\begin{bmatrix}-2\\1\end{bmatrix}=\begin{bmatrix}-2+2\\-4+4\end{bmatrix}=\mathbf{0}$——**零空间方向上的差异不改变投影。**

步骤 4：最小范数解（伪逆给出的答案）。 在无穷多解中选长度最小的那个。限制在直线 $\hat{x}_1+2\hat{x}_2=11/5$ 上最小化 $\hat{x}_1^2+\hat{x}_2^2$：代入 $\hat{x}_1=\frac{11}{5}-2\hat{x}_2$ 得 $(11/5-2\hat{x}_2)^2+\hat{x}_2^2$，求导 $-4(11/5-2\hat{x}_2)+2\hat{x}_2=0$ 即 $10\hat{x}_2=\frac{44}{5}$，$\hat{x}_2=\frac{22}{25}=0.88$，
$\hat{x}_1=\frac{11}{5}-\frac{44}{25}=\frac{55-44}{25}=\frac{11}{25}=0.44$。

$$\hat{\mathbf{x}}^+=\begin{bmatrix}11/25\\22/25\end{bmatrix}=\begin{bmatrix}0.44\\0.88\end{bmatrix},\qquad\|\hat{\mathbf{x}}^+\|=\sqrt{0.44^2+0.88^2}\approx0.9839,$$

对比 $\left(\frac{11}{5},0\right)$ 的长度 2.2——确实小得多。

步骤 5：用伪逆 A^+ 验证。 本例中 $A^+=\frac{1}{25}A^{\mathsf{T}}=\begin{bmatrix}0.04&0.08\\0.08&0.16\end{bmatrix}$（Lecture 33 会给出一般公式），则

$$A^+\mathbf{b}=\begin{bmatrix}0.04\cdot3+0.08\cdot4\\0.08\cdot3+0.16\cdot4\end{bmatrix}=\begin{bmatrix}0.12+0.32\\0.24+0.64\end{bmatrix}=\begin{bmatrix}0.44\\0.88\end{bmatrix}.\ \checkmark$$

$$AA^+=\begin{bmatrix}1&2\\2&4\end{bmatrix}\begin{bmatrix}0.04&0.08\\0.08&0.16\end{bmatrix}=\begin{bmatrix}0.04+0.16&0.08+0.32\\0.08+0.32&0.16+0.64\end{bmatrix}=\begin{bmatrix}0.2&0.4\\0.4&0.8\end{bmatrix}=\frac{1}{5}\mathbf{a}\mathbf{a}^{\mathsf{T}}$$

（$\mathbf{a}=\begin{bmatrix}1\\2\end{bmatrix}$，$\frac{1}{5}\begin{bmatrix}1&2\\2&4\end{bmatrix}$——与 Lecture 15 示例 4 的 P 完全相同，因为 C(A) 就是那条直线）。投影 $\mathbf{p}=A\hat{\mathbf{x}}^+=\begin{bmatrix}2.2\\4.4\end{bmatrix}$，残差 $\mathbf{e}=\begin{bmatrix}0.8\\-0.4\end{bmatrix}$，
$\mathbf{a}^{\mathsf{T}}\mathbf{e}=0.8-0.8=0$，$E=\|\mathbf{e}\|^2=0.8$。✓

【计算机制解说】：列相关时到底丢了什么、留下了什么？丢了"$\hat{\mathbf{x}}$ 的唯一性"，留下"$\mathbf{p}$ 的唯一性和最优性"。这可以用 Lecture 10 的四子空间完全解释：$\mathbb{R}^n$ 被劈成行空间 $C(A^{\mathsf{T}})$ 与零空间 $\mathbf{N}(A)$，而 A 在 $\mathbf{N}(A)$ 上作用为零。正规方程的**通解** = 行空间里的那个特解 + 零空间的任意向量。伪逆的聪明之处在于：它要求特解必须住在**行空间**里，而行空间与零空间正交，所以这个特解是通解中长度最小的（勾股定理：
$\|\hat{\mathbf{x}}\|^2=\|\hat{\mathbf{x}}_{row}\|^2+\|\hat{\mathbf{x}}_{null}\|^2$，要最小就必须让零空间分量为零）。这就是 A^+ 的定义：$A^+\mathbf{b}$ 是 $A\hat{\mathbf{x}}=\mathbf{p}$ 在行空间里的唯一解。

示例 8（3×3 与数据拟合的推广）：曲线拟合只是一个开始

把例 1 的 A 换成 $\begin{bmatrix}1&0&0\\1&1&1\\1&2&4\\1&3&9\end{bmatrix}$（抛物线 $b=C+Dt+Et^2$，四个数据点 $(0,1),(1,1),(2,3),(3,7)$），则

$$A^{\mathsf{T}}A=\begin{bmatrix}4&6&14\\6&14&36\\14&36&98\end{bmatrix},\qquad A^{\mathsf{T}}\mathbf{b}=\begin{bmatrix}12\\28\\76\end{bmatrix},$$

解出 $\hat{\mathbf{x}}=\begin{bmatrix}1\\-1\\1\end{bmatrix}$，即抛物线 $b=1-t+t^2$，在 $t=0,1,2,3$ 处取值 $1,1,3,7$——**完全命中数据**，$E=0$。这说明：只要模型（列空间）足够大，最小二乘可以退化成精确插值。四个点三条参数却精确拟合，是因为这四点恰好落在一条抛物线上。

【计算机制解说】：这个例子的意义在于说明**"最小二乘"与"插值"并非对立**。$\|A\mathbf{x}-\mathbf{b}\|$ 能否取到 0，取决于 $\mathbf{b}$ 是否落在 C(A) 里。当未知数足够多（$n\geq m$ 且列无关）时，$C(A)=\mathbb{R}^m$，$P=I$，误差必然为零。所以"最小二乘"这个名字描述的是**准则**（最小化平方误差），而不是"一定有误差"。实际建模中我们希望列空间够丰富以拟合数据，又不希望过丰富（过拟合）；这种张力在 Lecture 27–29（正定性与 SVD）里会以"条件数"和"有效秩"的语言重新出现。

示例 9：R^2 与"解释力"——用投影长度衡量模型好坏

例 1 的数据是 $(1,1),(2,2),(3,4)$，我们得到 $\mathbf{p}=\begin{bmatrix}5/6\\7/3\\23/6\end{bmatrix}$、$\mathbf{e}=\begin{bmatrix}1/6\\-1/3\\1/6\end{bmatrix}$、$E=1/6$。**最高的那条直线只是常数模型** $b=\bar{b}=\frac{7}{3}$：

$$\mathbf{p}_{\text{mean}}=\begin{bmatrix}7/3\\7/3\\7/3\end{bmatrix},\qquad\mathbf{b}-\mathbf{p}_{\text{mean}}=\begin{bmatrix}-4/3\\-1/3\\5/3\end{bmatrix},\qquad SST=\|\mathbf{b}-\mathbf{p}_{\text{mean}}\|^2=\frac{16+1+25}{9}=\frac{42}{9}=\frac{14}{3}\approx4.6667.$$

（这就是总平方和 total sum of squares，衡量数据本身有多"波动"。）直线模型解释掉的部分：

$$SSR = \|\mathbf{p} - \mathbf{p}_{\text{mean}}\|^2 = \left\| \begin{bmatrix} 5/6 - 7/3 \\ 7/3 - 7/3 \\ 23/6 - 7/3 \end{bmatrix} \right\|^2 = \left\| \begin{bmatrix} -3/2 \\ 0 \\ 3/2 \end{bmatrix} \right\|^2 = \frac{9}{4} + \frac{9}{4} = \frac{9}{2} = 4.5,$$

$$SSE = E = \frac{1}{6} \approx 0.1667.$$

验证分解：$SSR + SSE = \frac{9}{2} + \frac{1}{6} = \frac{27}{6} + \frac{1}{6} = \frac{28}{6} = \frac{14}{3} = SST$。✓

$$R^2 = \frac{SSR}{SST} = 1 - \frac{SSE}{SST} = 1 - \frac{1/6}{14/3} = 1 - \frac{1}{6} \cdot \frac{3}{14} = 1 - \frac{1}{28} = \frac{27}{28} \approx 0.9643.$$

这组数据被直线解释了 96.43%（例 2b 里 $\mathbf{b_2} = [2,3,3,2]^{\mathsf{T}}$ 的那组，$SST = 1$、$SSR = 0$，$R^2 = 0$，因为数据先升后降，直线完全解释不了）。

【计算机制解说】：R^2 的几何意义，本质上是一次**勾股分解**，只不过原点被平移到了 $\mathbf{p}_{\text{mean}}$ 处：

```
以 p_mean = b̄·[1,1,1]^T 为"新原点"看数据空间
┌──────────────────────────────────────────┐
│                                          │
│      b − p_mean   (总偏差，长度² = SST)    │
│            \                             │
│             \                            │
│              \  ← 直角!                   │
│   p − p_mean  \                          │
│   (被解释,     \    e = b − p            │
│   SSR)          \    (未被解释，SSE)      │
│                  \                       │
│                   ●                      │
└──────────────────────────────────────────┘

SST  =  SSR  +  SSE          (勾股：因为 (p − p_mean) ⊥ (b − p))

为什么垂直？   p − p_mean ∈ C(A)（两者都在列空间里），e ∈ C(A)^⊥
              故两者垂直，勾股定理直接给出 SST = SSR + SSE。

R² = SSR/SST = 1 − SSE/SST   ∈ [0,1]
R² = 1  ⟺  SSE = 0  ⟺  b ∈ C(A)（完美拟合）
R² = 0  ⟺  SSR = 0  ⟺  p = p_mean（直线毫无解释力）
```

为什么"先减去均值"？ 因为要把"数据本身的波动"与"模型解释的波动"分开。$\mathbf{p}_{\text{mean}}$ 是**常数模型**能给出的最好拟合（只有一列 $\mathbf{1}$ 时的投影），它代表"什么都不知道时的最佳猜测"。直线模型比常数模型多解释了 SSR；R^2 就是"提升比例"。注意 $\boldsymbol{p} - \boldsymbol{p}_{\text{mean}}$ 一定在 $C(A)$ 里（$C(A)$ 含常数列 $\mathbf{1}$，故 $\mathbf{p}_{\text{mean}}$ 也在里面，两者相减仍在里面），所以它必然垂直于 $\mathbf{e} \in C(A)^{\perp}$——这就是上面那张图里直角标记的来源。**整个 R^2 理论就是本讲的投影分解加上一次平移。**

示例 10：三个"最好/最坏"的极端情形（用投影矩阵一览）

最小二乘的行为有时显得反直觉。下面三个小例子用同一套公式给出三种截然不同的结果，是检验理解的最好试金石。

(a) $\mathbf{b}$ 已在列空间里 ⇒ 零误差。 取 $A = \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 1 \end{bmatrix}$（列无关），$\mathbf{b} = \begin{bmatrix} 2 \\ 3 \\ 5 \end{bmatrix}$。注意 $\mathbf{b} = 2\begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix} + 3\begin{bmatrix} 0 \\ 1 \\ 1 \end{bmatrix}$，故 $\mathbf{b} \in C(A)$。

$$A^{\mathsf{T}}A = \begin{bmatrix} 1+0+1 & 0+0+1 \\ 0+0+1 & 0+1+1 \end{bmatrix} = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}, \qquad A^{\mathsf{T}}\mathbf{b} = \begin{bmatrix} 2+5 \\ 3+5 \end{bmatrix} = \begin{bmatrix} 7 \\ 8 \end{bmatrix},$$

$$\hat{\mathbf{x}} = \frac{1}{3}\begin{bmatrix} 2 & -1 \\ -1 & 2 \end{bmatrix}\begin{bmatrix} 7 \\ 8 \end{bmatrix} = \frac{1}{3}\begin{bmatrix} 14-8 \\ -7+16 \end{bmatrix} = \frac{1}{3}\begin{bmatrix} 6 \\ 9 \end{bmatrix} = \begin{bmatrix} 2 \\ 3 \end{bmatrix}. \checkmark \text{（正是}\mathbf{b}\text{ 的系数）}$$

$\mathbf{p} = A\hat{\mathbf{x}} = \mathbf{b}$，$\mathbf{e} = \mathbf{0}$，$E = 0$。投影矩阵：$P = A(A^{\mathsf{T}}A)^{-1}A^{\mathsf{T}} = \frac{1}{3}\begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 1 \end{bmatrix}\begin{bmatrix} 2 & -1 \\ -1 & 2 \end{bmatrix}\begin{bmatrix} 1 & 0 & 1 \\ 0 & 1 & 1 \end{bmatrix}$，先算 $A(A^{\mathsf{T}}A)^{-1} = \frac{1}{3}\begin{bmatrix} 2 & -1 \\ -1 & 2 \\ 1 & 1 \end{bmatrix}$，再乘 A^{T}：

$$P = \frac{1}{3}\begin{bmatrix} 2 & -1 \\ -1 & 2 \\ 1 & 1 \end{bmatrix}\begin{bmatrix} 1 & 0 & 1 \\ 0 & 1 & 1 \end{bmatrix} = \frac{1}{3}\begin{bmatrix} 2 & -1 & 1 \\ -1 & 2 & 1 \\ 1 & 1 & 2 \end{bmatrix}.$$

$\mathrm{trace}(P) = 2$、$\mathrm{rank}(P) = 2$、$P\mathbf{b} = \frac{1}{3}\begin{bmatrix} 4-3+5 \\ -2+6+5 \\ 2+3+10 \end{bmatrix} = \frac{1}{3}\begin{bmatrix} 6 \\ 9 \\ 15 \end{bmatrix} = \begin{bmatrix} 2 \\ 3 \\ 5 \end{bmatrix} = \mathbf{b}$ ✓。

(b) $\mathbf{b}$ 完全垂直于列空间 ⇒ 投影为零。 取同一个 A，$\mathbf{b}=\begin{bmatrix}1\\1\\-1\end{bmatrix}$。检查：$\mathbf{a}_1^{\mathsf{T}}\mathbf{b}=1+0-1=0$，$\mathbf{a}_2^{\mathsf{T}}\mathbf{b}=0+1-1=0$，故 $\mathbf{b}\perp C(A)$。

$$A^{\mathsf{T}}\mathbf{b}=\begin{bmatrix}0\\0\end{bmatrix}\Longrightarrow\hat{\mathbf{x}}=\begin{bmatrix}0\\0\end{bmatrix},\qquad \mathbf{p}=\mathbf{0},\qquad \mathbf{e}=\mathbf{b},\qquad E=\|\mathbf{b}\|^2=3.$$

也就是说：**最优"拟合"是什么都不做**（所有系数为零）。$R^2=1-\frac{3}{3}=0$（如果模型含常数项的话；本例 $C(A)$ 不含 $\mathbf{1}=[1,1,1]^{\mathsf{T}}$，因为 $\mathbf{1}$ 与 $\mathbf{b}$ 不正交，$\mathbf{1}\not\perp C(A)$……**更准确地说**：R^2 的定义要求模型包含常数项，本例不含，所以 R^2 这个指标不适用。这正是"R^2 只在含截距时才有意义"的原因）。

(c) $\mathbf{b}$ 的"最难拟合"方向 ⇒ 误差最大。 取 $A=\begin{bmatrix}1\\1\\1\end{bmatrix}$（只有常数列，$\mathbf{1}=[1,1,1]^{\mathsf{T}}$），$\mathbf{b}=\begin{bmatrix}1\\2\\4\end{bmatrix}$。

$$A^{\mathsf{T}}A=3,\qquad A^{\mathsf{T}}\mathbf{b}=7,\qquad \hat{x}=\frac{7}{3},\qquad \mathbf{p}=\begin{bmatrix}7/3\\7/3\\7/3\end{bmatrix},\qquad \mathbf{e}=\begin{bmatrix}-4/3\\-1/3\\5/3\end{bmatrix}.$$

$$\|\mathbf{b}\|^2=21,\quad \|\mathbf{p}\|^2=3\cdot\frac{49}{9}=\frac{49}{3},\quad \|\mathbf{e}\|^2=\frac{16+1+25}{9}=\frac{42}{9}=\frac{14}{3},\qquad \frac{49}{3}+\frac{14}{3}=\frac{63}{3}=21.\ \checkmark$$

这说明：即使用最简单的"常数模型"，投影仍然给出了它能做的最好结果——$\hat{x}=\frac{7}{3}=\bar{b}$ 恰是数据均值！**投影到常数列 = 取平均**，这是全部统计学里最古老的操作，它的几何身份就是"一维投影"。

【计算机制解说】：三个例子合起来给出最小二乘的"光谱"：

$$\mathbf{b}\in C(A)\ \Rightarrow\ E=0\,;\qquad \mathbf{b}\perp C(A)\ \Rightarrow\ \hat{\mathbf{x}}=\mathbf{0}\,;\qquad \text{一般情形}\ \Rightarrow\ 0<E<\|\mathbf{b}\|^2.$$

这三种情形可以统一写成

$$\|\mathbf{p}\|=\|\mathbf{b}\|\cos\Theta,\qquad \|\mathbf{e}\|=\|\mathbf{b}\|\sin\Theta,$$

其中 Θ 是 $\mathbf{b}$ 与**整个子空间** $C(A)$ 的夹角（一般情形下这个角不被任何单列确定，而是 $\mathbf{b}$ 与它在子空间上垂线的夹角）。所以"拟合得好" = "$\mathbf{b}$ 与列空间几乎平行"，"拟合得差" = "几乎垂直"。**把 $E/\|\mathbf{b}\|^2=\sin^2\Theta$ 当成几何量来读，比死记公式有效得多。**

示例 10 的一个小陷阱：$\mathbf{b}\perp C(A)$ 时最优解 $\hat{\mathbf{x}}=\mathbf{0}$，这不意味着"数据没用"，而是意味着"这些自变量对 $\mathbf{b}$ 没有任何线性解释力"。线性代数只报告事实，不解释因果。

矩阵分解的核心思想

1. 最小二乘是"投影"的应用版，而不是新东西。 全部数学都在 Lecture 15 里：$A^{\mathsf{T}}A\hat{\mathbf{x}}=A^{\mathsf{T}}\mathbf{b}$、$\mathbf{p}=A\hat{\mathbf{x}}$、$P=A(A^{\mathsf{T}}A)^{-1}A^{\mathsf{T}}$。本讲新增的是**解释**：$\hat{\mathbf{x}}$ 是模型参数（截距与斜率），$\mathbf{p}$ 是拟合值，$\mathbf{e}$ 是残差，$E=\|\mathbf{e}\|^2$ 是可解释的最小化目标。

2. 这套"参数 → 数据"的分解本质上就是一次"未完成的分解"。 若把 A 分解成 $A=QR$（Lecture 17），正规方程立刻变成

$$R^{\mathsf{T}}\underbrace{Q^{\mathsf{T}}Q}_{=I}R\hat{\mathbf{x}}=R^{\mathsf{T}}Q^{\mathsf{T}}\mathbf{b}\ \Longrightarrow\ R\hat{\mathbf{x}}=Q^{\mathsf{T}}\mathbf{b},$$

R 上三角、对角元是 $\|\mathbf{v}_i\|>0$，回代即可。P 也随之变成更漂亮的 $P=QQ^{\mathsf{T}}$。

3. 与 Lecture 33 的伪逆对接。 列相关时用 A^{+}。A^{+} 满足 Penrose 四条件，并且 AA^{+} 恰是投影到 C(A) 的矩阵、$A^{+}A$ 是投影到行空间 $C(A^{\mathsf{T}})$ 的矩阵。本讲示例 7 已经展示了这一点：$AA^{+}=\begin{bmatrix}0.2&0.4\\0.4&0.8\end{bmatrix}$ 就是那个一维投影。

4. $A^{\mathsf{T}}A$ 是"数据的内积矩阵"（Gram 矩阵）。 它的 (i,j) 元是列 $\mathbf{a}_i$ 与 $\mathbf{a}_j$ 的内积，对角元是各列的平方长度。$A^{\mathsf{T}}\mathbf{b}$ 的每个分量是 $\mathbf{a}_i^{\mathsf{T}}\mathbf{b}$——"数据与第 i 个基函数的匹配度"。所以正规方程的两边都是"内积"，完全符合投影是"正交分解"的本性。

与其他讲次的关联

- **Lecture 15（投影到子空间）**：本讲是它的直接应用。那里的 $P=A(A^{\mathsf{T}}A)^{-1}A^{\mathsf{T}}$、$\hat{\mathbf{x}}=(A^{\mathsf{T}}A)^{-1}A^{\mathsf{T}}\mathbf{b}$ 在这里被赋予"拟合直线"的含义。
- **Lecture 10、14（四子空间、正交性）**：$\mathbf{e}\in\mathbf{N}(A^{\mathsf{T}})$、$\mathbf{N}(A^{\mathsf{T}}A)=\mathbf{N}(A)$ 是列相关讨论的理论基础；通解 = 行空间特解 + 零空间任意向量是伪逆"最小范数"性质的来源。
- **Lecture 17（正交矩阵与 Gram–Schmidt）**：$A=QR$ 把正规方程化简为 $R\hat{\mathbf{x}}=Q^{\mathsf{T}}\mathbf{b}$，并大幅改善数值稳定性。
- **Lecture 21–25（特征值、正定矩阵）**：$A^{\mathsf{T}}A$ 对称正定，特征值 $=\sigma_i^2\geq 0$；最小二乘的"病态"与否由条件数 $\sigma_{\max}/\sigma_{\min}$ 决定。
- **Lecture 27（正定与最小值）**：$\|\mathbf{b}-A\mathbf{x}\|^2$ 是二次函数，其 Hessian 是 $2A^{\mathsf{T}}A$，正定性保证了极小点的唯一性——本讲"配方/微积分"两种解说的连续版本。
- **Lecture 29（SVD）**：$A=U\Sigma V^{\mathsf{T}}$ 给出最稳健的伪逆 $A^{+}=V\Sigma^{+}U^{\mathsf{T}}$，并解释为什么某些最小二乘问题"数值上不可解"。
- **Lecture 33（伪逆）**：本讲示例 7 只用具体数字演示了它，那里会给出完整理论。

关键要点

1. **最小二乘 = 投影**：$\hat{\mathbf{x}}$ 使 $\|A\mathbf{x}-\mathbf{b}\|^2$ 最小 $\iff$ $\mathbf{b}-A\hat{\mathbf{x}} \perp C(A)$ $\iff$ $A^{\mathsf{T}}A\hat{\mathbf{x}} = A^{\mathsf{T}}\mathbf{b}$。
2. **正规方程与解**：$A^{\mathsf{T}}A\hat{\mathbf{x}} = A^{\mathsf{T}}\mathbf{b}$，$\hat{\mathbf{x}} = (A^{\mathsf{T}}A)^{-1}A^{\mathsf{T}}\mathbf{b}$，拟合值 $\mathbf{p} = A\hat{\mathbf{x}} = P\mathbf{b}$，残差 $\mathbf{e} = \mathbf{b}-\mathbf{p}$。
3. **列无关 $\Rightarrow$ $A^{\mathsf{T}}A$ 对称正定、可逆、解唯一**；列相关 $\Rightarrow$ 解不唯一但投影唯一，用 A^{+} 取最小范数解（Lecture 33）。
4. **残差的两个正交条件在拟合中就是**：$\sum e_i = 0$ 与 $\sum t_i e_i = 0$。
5. **投影矩阵性质**：$P^{\mathsf{T}} = P$、$P^2 = P$、$\mathbf{rank}(P) = \mathrm{trace}(P) = r$；$P\mathbf{b} = \mathbf{b}$ 当且仅当 $\mathbf{b} \in C(A)$，$P\mathbf{b} = \mathbf{0}$ 当且仅当 $\mathbf{b} \perp C(A)$。

常见误区与注意事项

1. **把 $E = \|\mathbf{e}\|^2$ 写成 $\|\mathbf{e}\|$**。最小二乘最小化的是**平方和**（同一个 $\mathbf{x}$ 当然也最小化长度，因为平方根单调，但报告结果时务必说清是 E 还是 $\sqrt{E}$）。示例 1 中 $E = 1/6 \approx 0.1667$，而 $\|\mathbf{e}\| = \sqrt{1/6} \approx 0.4082$——两个数差别很大。
2. **忘记构造 A 时的常数列**。若要拟合 $b = C + Dt + Et^2$，A 必须有三列 $[\mathbf{1}, t, t^2]$；漏掉常数列 1 就变成"强制过原点"，结果完全不同（示例 2 已给出对照：E 从 $1/6$ 涨到 $5/14$）。
3. **在列相关时仍然写 $(A^{\mathsf{T}}A)^{-1}$**。$A^{\mathsf{T}}A$ 奇异时必须停下，改用伪逆或删掉冗余列。判断方法：检查 $\mathbf{rank}(A)$ 或解 $A\mathbf{x} = \mathbf{0}$ 是否有非零解。示例 7 中 $\det(A^{\mathsf{T}}A) = 0$，直接套逆矩阵公式会得到 NaN 或荒谬的大数。
4. **误以为"残差越小说明模型越好"**。残差平方和只衡量拟合优度，不衡量泛化能力。增加参数总能降低 E（示例 8 甚至降到 0），但这可能是过拟合。统计上还要看自由度、R^2 的调整、交叉验证等。
5. **把 $\hat{\mathbf{x}}$ 与 $\mathbf{p}$ 的维度搞混**。$\hat{\mathbf{x}} \in \mathbb{R}^n$（参数），$\mathbf{p}, \mathbf{e}, \mathbf{b} \in \mathbb{R}^m$（数据）。示例 1 中 $\hat{\mathbf{x}}$ 是 2 维（C, D），而 $\mathbf{p}, \mathbf{e}$ 是 3 维（三个时间点）。写成 $P\mathbf{b} = \hat{\mathbf{x}}$ 就完全错了。

思考题（带答案）

Q1.（计算题）用最小二乘拟合直线 $b = C + Dt$ 到数据 $(0,6), (1,0), (2,0)$。求 C, D，写出拟合值 $\mathbf{p}$、残差 $\mathbf{e}$ 与残差平方和 E，并验证两个正交条件。

▸ **答案**

$$A = \begin{bmatrix} 1 & 0 \\ 1 & 1 \\ 1 & 2 \end{bmatrix}, \qquad \mathbf{b} = \begin{bmatrix} 6 \\ 0 \\ 0 \end{bmatrix}.$$

$$A^{\mathsf{T}}A = \begin{bmatrix} 3 & 3 \\ 3 & 5 \end{bmatrix}, \qquad A^{\mathsf{T}}\mathbf{b} = \begin{bmatrix} 6 \\ 0 \end{bmatrix}.$$

$\det = 3\cdot 5 - 3\cdot 3 = 15 - 9 = 6$，$(A^{\mathsf{T}}A)^{-1} = \frac{1}{6}\begin{bmatrix} 5 & -3 \\ -3 & 3 \end{bmatrix}$，

$$\hat{\mathbf{x}} = \frac{1}{6}\begin{bmatrix} 5 & -3 \\ -3 & 3 \end{bmatrix}\begin{bmatrix} 6 \\ 0 \end{bmatrix} = \frac{1}{6}\begin{bmatrix} 30 \\ -18 \end{bmatrix} = \begin{bmatrix} 5 \\ -3 \end{bmatrix}.$$

拟合直线：$b = 5 - 3t$。拟合值

$$\mathbf{p} = \begin{bmatrix} 5 \\ 5-3 \\ 5-6 \end{bmatrix} = \begin{bmatrix} 5 \\ 2 \\ -1 \end{bmatrix}, \qquad > \mathbf{e} = \begin{bmatrix} 6-5 \\ 0-2 \\ 0-(-1) \end{bmatrix} = \begin{bmatrix} 1 \\ -2 \\ 1 \end{bmatrix}.$$

正交验证：残差和 $= 1 - 2 + 1 = 0$ ✓；加权和 $= 0\cdot 1 + 1\cdot(-2) + 2\cdot 1 = 0$ ✓。

$$E = 1 + 4 + 1 = 6, \qquad \|\mathbf{b}\|^2 = 36, \qquad \|\mathbf{p}\|^2 = 25 + 4 + 1 = 30, \qquad 30 + 6 = 36. \checkmark$$

（这组数据的直线拟合明显不好——三点先高后平，直线只能折中，$E = 6$ 相对 $\|\mathbf{b}\|^2 = 36$ 相当大。）

Q2.（概念题）设 A 是 5×3、列线性无关，$\mathbf{b} \in \mathbb{R}^5$。判断真假并解释：

(a) 正规方程 $A^{\mathsf{T}}A\hat{\mathbf{x}} = A^{\mathsf{T}}\mathbf{b}$ 有唯一解。 (b) 残差 $\mathbf{e} = \mathbf{b} - A\hat{\mathbf{x}}$ 是 $\mathbf{b}$ 在 $\mathbf{N}(A^{\mathsf{T}})$ 上的投影。 (c) 若 $\mathbf{b}$ 恰好正交于 $C(A)$ 的每一列，则 $E = \|\mathbf{b}\|^2$。 (d) 若把 $\mathbf{b}$ 换成 $\mathbf{b} + \mathbf{c}$ 且 $\mathbf{c} \in C(A)$，则 $\hat{\mathbf{x}}$ 与 E 都不变。

▸ **答案**

(a) **真**。A 列无关 $\Rightarrow \mathbf{N}(A)=\{\mathbf{0}\} \Rightarrow \mathbf{N}(A^{\mathsf{T}}A)=\{\mathbf{0}\}$，$3\times 3$ 的 $A^{\mathsf{T}}A$ 可逆，解唯一。

(b) **真**。由 $A^{\mathsf{T}}\mathbf{e}=\mathbf{0}$ 知 $\mathbf{e}\in\mathbf{N}(A^{\mathsf{T}})$，而 $\mathbf{e}=\mathbf{b}-P\mathbf{b}=(I-P)\mathbf{b}$，$I-P$ 正是投影到 $\mathbf{N}(A^{\mathsf{T}})=C(A)^{\perp}$ 的矩阵（Lecture 15 示例 2 已验证 $(I-P)$ 对称幂等）。

(c) **真**。$\mathbf{b}\perp C(A)$ 意味着投影 $\mathbf{p}=\mathbf{0}$，所以 $\mathbf{e}=\mathbf{b}$，$E=\|\mathbf{b}\|^2$。此时 $\hat{\mathbf{x}}=\mathbf{0}$。

(d) **假（一半）**。$\hat{\mathbf{x}}$ 确实变：因为 $\mathbf{c}\in C(A)$ 意味着 $\mathbf{c}=A\mathbf{z}$ 对某个 $\mathbf{z}$ 成立，新解为 $\hat{\mathbf{x}}+\mathbf{z}$，投影变为 $\mathbf{p}+\mathbf{c}$。但**残差与 E 不变**：新残差 $=(\mathbf{b}+\mathbf{c})-(\mathbf{p}+\mathbf{c})=\mathbf{b}-\mathbf{p}=\mathbf{e}$。用公式看更清楚：$\hat{\mathbf{x}}_{\text{new}}=(A^{\mathsf{T}}A)^{-1}A^{\mathsf{T}}(\mathbf{b}+A\mathbf{z})=\hat{\mathbf{x}}+\mathbf{z}$，$E$ 只依赖 $\mathbf{e}\in C(A)^{\perp}$。这正是投影的"平移不变性"：把目标向量沿子空间方向平移，垂足跟着平移，误差不变。

Q3.（计算题）对 L16 主例的数据 $(1,1),(2,2),(3,4)$，请**不使用 P 矩阵**，仅用统计量验证斜率 $D=\dfrac{\sum(t_i-\bar t)(b_i-\bar b)}{\sum(t_i-\bar t)^2}$ 与由正规方程得到的 $D=3/2$ 一致，并求出截距 C。

▸ **答案**

$\bar t=\frac{1+2+3}{3}=2$，$\bar b=\frac{1+2+4}{3}=\frac{7}{3}$。

$$\sum(t_i-\bar t)^2=(1-2)^2+(2-2)^2+(3-2)^2=1+0+1=2.$$

$$\sum(t_i-\bar t)(b_i-\bar b)=(1-2)\left(1-\frac{7}{3}\right)+(2-2)\left(2-\frac{7}{3}\right)+(3-2)\left(4-\frac{7}{3}\right)$$

$$=(-1)\left(-\frac{4}{3}\right)+0+1\cdot\frac{5}{3}=\frac{4}{3}+\frac{5}{3}=3.$$

$$D=\frac{3}{2}=1.5.\ \checkmark\qquad C=\bar b-D\bar t=\frac{7}{3}-\frac{3}{2}\cdot 2=\frac{7}{3}-3=-\frac{2}{3}.\ \checkmark$$

与正规方程的解完全一致。

机制说明：这个"中心化公式"其实是把 $A^{\mathsf{T}}A\hat{\mathbf{x}}=A^{\mathsf{T}}\mathbf{b}$ 做了一次变量替换。令 $t_i'=t_i-\bar t$、$b_i'=b_i-\bar b$，则新的设计矩阵 A' 的两列 $[\mathbf{1}]$ 与 $[t']$ **互相正交**（因为 $\sum t_i'=0$），于是 $A'^{\mathsf{T}}A'=\begin{bmatrix}m & 0\\ 0 & \sum t_i'^2\end{bmatrix}$ 是对角阵，正规方程瞬间解耦：常数项直接是 $\bar b'$（均值），斜率直接是两个平方和的比。这就是"中心化"在数值上的威力——它把耦合的 2×2 方程组变成两个独立的一元方程（与 Lecture 17 中"正交列让 $A^{\mathsf{T}}A$ 对角"是同一个道理）。

Lecture 17: Orthogonal Matrices and Gram–Schmidt

概述

本讲解决 Lecture 15–16 留下的一个实际问题：**投影与最小二乘的公式都对，但算起来不方便**。$P=A(A^{\mathsf{T}}A)^{-1}A^{\mathsf{T}}$ 需要求逆，而 $A^{\mathsf{T}}A$ 往往"病态"（元素之间高度相关、条件数很大），数值误差会被放大。解决办法是：**先把 A 的列变成互相正交的单位向量**，得到矩阵 Q。对正交矩阵，所有公式瞬间简化：$Q^{\mathsf{T}}Q=I$，$Q^{-1}=Q^{\mathsf{T}}$，$\hat{\mathbf{x}}=Q^{\mathsf{T}}\mathbf{b}$，$P=QQ^{\mathsf{T}}$——**没有求逆**。

本讲分两步。第一步：定义**正交矩阵（orthogonal matrix）**并列举例子（置换矩阵、旋转、反射、Hadamard）。第二步：给出制造正交列的算法——**Gram–Schmidt 正交化**，它把 A 变成 $A=QR$，其中 Q 的列标准正交、R 是上三角。这条路线不仅让最小二乘更快更稳，还是 Lecture 29（SVD）与特征值 QR 算法的入口。

核心概念的几何直觉

正交矩阵（Orthogonal Matrix）

- **定义与目的**：$n\times n$ 的实矩阵 Q 若满足

$$Q^{\mathsf{T}}Q=I,$$

则称 Q 为正交矩阵。等价说法：Q 的 n 个列向量是**标准正交（orthonormal）**的——两两内积为 0（正交），每个长度都是 1（规范）。 – **几何直觉（它在空间中是什么样子？）**：正交矩阵是一台"**刚性运动机器**"。它把标准正交基 $\mathbf{e}_1,\dots,\mathbf{e}_n$ 映成另一组标准正交基，因此不拉伸、不压缩、不扭曲角度——只做旋转或旋转加反射。这就是为什么它对长度"免疫"：$\|Q\mathbf{x}\|=\|\mathbf{x}\|$。 – **具体示例**：2×2 旋转 $Q=\begin{bmatrix}\cos\theta & -\sin\theta\\ \sin\theta & \cos\theta\end{bmatrix}$，$\theta=60^\circ$ 时

$Q=\begin{bmatrix}1/2 & -\sqrt{3}/2\\ \sqrt{3}/2 & 1/2\end{bmatrix}$。验算 $Q^{\mathsf{T}}Q$：第 1 行乘第 1 列 $=\frac{1}{4}+\frac{3}{4}=1$；第 1 行乘第 2 列 $=-\frac{\sqrt{3}}{4}+\frac{\sqrt{3}}{4}=0$；第 2 行乘第 2 列 $=\frac{3}{4}+\frac{1}{4}=1$。✓ 另 $\det Q=\frac{1}{4}+\frac{3}{4}=1$（纯旋转，无反射）。

正交矩阵的四条核心性质

- **定义与目的**：① $Q^{\mathsf{T}}Q=I$；② $Q^{-1}=Q^{\mathsf{T}}$（**求逆 = 转置，免费的逆**）；③ $\|Q\mathbf{x}\|=\|\mathbf{x}\|$ 对一切 $\mathbf{x}$ 成立（保长）；④ 当 Q 是方阵时，$QQ^{\mathsf{T}}=I$ 也成立（Q^{T} 同样是正交矩阵）。
- **几何直觉（它在空间中是什么样子？）**：② 是①的直接算术后果（方阵左逆即右逆）；③ 的证明一句话：$\|Q\mathbf{x}\|^2=(Q\mathbf{x})^{\mathsf{T}}Q\mathbf{x}=\mathbf{x}^{\mathsf{T}}Q^{\mathsf{T}}Q\mathbf{x}=\mathbf{x}^{\mathsf{T}}\mathbf{x}=\|\mathbf{x}\|^2$——内积也被保住，于是所有长度和角度都不变；④ 说明"正交"是对称的：Q^{-1} 也正交。
- **具体示例**：置换矩阵 $P=\begin{bmatrix}0&1&0\\0&0&1\\1&0&0\end{bmatrix}$，$P^{\mathsf{T}}P=I$，$P^{-1}=P^{\mathsf{T}}=\begin{bmatrix}0&0&1\\1&0&0\\0&1&0\end{bmatrix}$；$P\mathbf{x}$ 只是把 $\mathbf{x}$ 的分量轮换位置，长度当然不变。

易错提醒：名字里"orthogonal"容易被误解成"列两两正交"，但定义里还藏着"每个列长度为 1"。只正交不单位化（如 $\begin{bmatrix}1&1\\1&-1\end{bmatrix}$）**不是**正交矩阵，尽管它 $Q^{\mathsf{T}}Q=2I$。必须除以 $\sqrt{2}$ 才成为正交矩阵 $\frac{1}{\sqrt{2}}\begin{bmatrix}1&1\\1&-1\end{bmatrix}$。

正交矩阵的例子

- **置换矩阵（permutation matrix）**：每行每列恰有一个 1。它交换坐标轴，共 $n!$ 个。例：$\begin{bmatrix}0&1\\1&0\end{bmatrix}$ 是沿直线 $y=x$ 的反射。
- **旋转矩阵**：$R(\theta)=\begin{bmatrix}\cos\theta&-\sin\theta\\ \sin\theta&\cos\theta\end{bmatrix}$，$\det=1$，逆时针转 θ，逆为 $R(-\theta)=R(\theta)^{\mathsf{T}}$。
- **反射矩阵**：$\det=-1$ 的正交矩阵。最简单的两个：$F_x=\begin{bmatrix}1&0\\0&-1\end{bmatrix}$（关于 x 轴翻折）、$S=\begin{bmatrix}0&1\\1&0\end{bmatrix}$（关于 $y=x$ 翻折）。**任何**正交矩阵的行列式都只能是 $+1$（旋转）或 -1（旋转+反射）。
- **Hadamard 矩阵**：$H_2=\begin{bmatrix}1&1\\1&-1\end{bmatrix}$，$H_2^{\mathsf{T}}H_2=2I$，故 $\frac{1}{\sqrt{2}}H_2$ 正交。它可递归放大：

$$H_4=\begin{bmatrix}1&1&1&1\\1&-1&1&-1\\1&1&-1&-1\\1&-1&-1&1\end{bmatrix},\qquad H_4^{\mathsf{T}}H_4=4I.$$

每行是 ±1 序列，两两正交，长度都是 2。Hadamard 矩阵在信号处理（Walsh–Hadamard 变换）和编码理论中无处不在。

标准正交基带来的巨大简化

- **定义与目的**：若 Q 的列 $\mathbf{q}_1,\dots,\mathbf{q}_n$ 标准正交，则 $Q^{\mathsf{T}}Q=I$。把投影公式 $P=A(A^{\mathsf{T}}A)^{-1}A^{\mathsf{T}}$ 中的 A 换成 Q：

$$P=Q(Q^{\mathsf{T}}Q)^{-1}Q^{\mathsf{T}}=Q\,I\,Q^{\mathsf{T}}=QQ^{\mathsf{T}}.$$

正规方程 $A^{\mathsf{T}}A\hat{\mathbf{x}}=A^{\mathsf{T}}\mathbf{b}$ 变成 $I\hat{\mathbf{x}}=Q^{\mathsf{T}}\mathbf{b}$，即

$$\hat{\mathbf{x}}=Q^{\mathsf{T}}\mathbf{b},\qquad \text{分量形式}\quad \hat{x}_i=\mathbf{q}_i^{\mathsf{T}}\mathbf{b}.$$

- **几何直觉（它在空间中是什么样子？）**：一般情形下，求投影坐标需要解一个耦合的 $n\times n$ 方程组（因为斜基向量互相"抢分量"）；而正交基互相垂直，**每个系数独立可算**——$\hat{x}_i$ 就是把 $\mathbf{b}$ 往 $\mathbf{q}_i$ 方向"量一下"。
- **具体示例**：取本讲示例 1 中 Gram–Schmidt 造出的那组标准正交基

$$\mathbf{q}_1=\frac{1}{\sqrt{2}}\begin{bmatrix}1\\1\\0\end{bmatrix},\qquad \mathbf{q}_2=\frac{1}{\sqrt{6}}\begin{bmatrix}1\\-1\\2\end{bmatrix},\qquad \mathbf{q}_3=\frac{1}{\sqrt{3}}\begin{bmatrix}-1\\1\\1\end{bmatrix}.$$

先自检正交性：$\mathbf{q}_1^{\mathsf{T}}\mathbf{q}_2=\frac{1-1+0}{\sqrt{12}}=0$、$\mathbf{q}_1^{\mathsf{T}}\mathbf{q}_3=\frac{-1+1+0}{\sqrt{6}}=0$、$\mathbf{q}_2^{\mathsf{T}}\mathbf{q}_3=\frac{-1-1+2}{\sqrt{18}}=0$ ✓，且三个范数都是 1 ✓。取 $\mathbf{b}=[1,2,4]^{\mathsf{T}}$，则三个系数**各自独立**一步算出：

$$\hat{x}_1=\mathbf{q}_1^{\mathsf{T}}\mathbf{b}=\frac{1+2+0}{\sqrt{2}}=\frac{3}{\sqrt{2}},\qquad \hat{x}_2=\frac{1-2+8}{\sqrt{6}}=\frac{7}{\sqrt{6}},\qquad \hat{x}_3=\frac{-1+2+4}{\sqrt{3}}=\frac{5}{\sqrt{3}}.$$

由于这组基张成整个 $\mathbb{R}^3$，投影就是 $\mathbf{b}$ 自身，回代可自检：
$\mathbf{p}=\hat{x}_1\mathbf{q}_1+\hat{x}_2\mathbf{q}_2+\hat{x}_3\mathbf{q}_3=\frac{3}{\sqrt{2}}\cdot\frac{1}{\sqrt{2}}[1,1,0]^{\mathsf{T}}+\frac{7}{\sqrt{6}}\cdot\frac{1}{\sqrt{6}}[1,-1,2]^{\mathsf{T}}+\frac{5}{\sqrt{3}}\cdot\frac{1}{\sqrt{3}}[-1,1,1]^{\mathsf{T}}$，第一分量 $=\frac{3}{2}+\frac{7}{6}-\frac{5}{3}=1$ ✓（另两个分量同理得 2 与 4），即 $\mathbf{p}=\mathbf{b}$。**注意对比**：同样三个未知数，用一般基要解 3×3 的耦合方程组；换成标准正交基后每个 $\hat{x}_i$ 只是一次内积——这就是"正交基把耦合问题解耦"的具体含义。

Gram–Schmidt 正交化

- **定义与目的**：给定线性无关向量 $\mathbf{a}_1,\dots,\mathbf{a}_n$，构造标准正交向量 $\mathbf{q}_1,\dots,\mathbf{q}_n$，使 $\mathbf{span}\{\mathbf{q}_1,\dots,\mathbf{q}_k\}=\mathbf{span}\{\mathbf{a}_1,\dots,\mathbf{a}_k\}$ 对每个 k 成立。算法是"**先正交化再单位化**"：

$$\mathbf{v}_1=\mathbf{a}_1,\quad \mathbf{q}_1=\frac{\mathbf{v}_1}{\|\mathbf{v}_1\|};$$

$$\mathbf{v}_2=\mathbf{a}_2-(\mathbf{q}_1^{\mathsf{T}}\mathbf{a}_2)\mathbf{q}_1,\quad \mathbf{q}_2=\frac{\mathbf{v}_2}{\|\mathbf{v}_2\|};$$

$$\mathbf{v}_3=\mathbf{a}_3-(\mathbf{q}_1^{\mathsf{T}}\mathbf{a}_3)\mathbf{q}_1-(\mathbf{q}_2^{\mathsf{T}}\mathbf{a}_3)\mathbf{q}_2,\quad \mathbf{q}_3=\frac{\mathbf{v}_3}{\|\mathbf{v}_3\|}.$$

- **几何直觉（它在空间中是什么样子？）**：$\mathbf{a}_2$ 一般既有"沿着 $\mathbf{a}_1$ 的分量"又有"垂直于 $\mathbf{a}_1$ 的分量"。我们减掉前者，剩下的 $\mathbf{v}_2$ 就垂直 $\mathbf{a}_1$。处理 $\mathbf{a}_3$ 时要减掉它在**已经建好的每个方向**上的投影。这就像从一堆斜放的木板中削出一套互相垂直的坐标轴。

一维图景最直观：把 $\mathbf{a}_2$ 沿 $\mathbf{q}_1$ 方向分解为"平行分量 + 垂直分量"，**减掉平行分量就得到 $\mathbf{v}_2$**。

```
                a2
               /|
              / |
             /  |  v2 = a2 - (q1^T a2) q1
            /   |     (垂直分量：我们要的，v2 ⊥ q1)
           /    |
          /     |
         /______|__________________ q1 方向
          proj = (q1^T a2) q1
           (平行分量：要减掉的)

首尾相接：  proj + v2 = a2
减掉 proj 后 v2 与整个 q1 方向正交，单位化即得 q2。
```

处理第三个向量时，"减掉已建方向上的投影"就是**向已张成的平面作垂线**：

```
      三维空间中的 a3
            *  a3
           /|
          / |   v3 = a3 - (q1^T a3)q1 - (q2^T a3)q2
         /  |    (垂直于整个平面 span{q1,q2})
        /   |
       /    |
──────*─────*──────────  平面 span{q1, q2}
      投影点 p = (q1^T a3)q1 + (q2^T a3)q2

v3 ⊥ q1 且 v3 ⊥ q2  ⟹  v3 与整个平面正交。
Gram-Schmidt 就是把这个"作垂线"的动作从第 1 步重复到第 n 步：
每一步都把已有的方向清干净，剩下的就是全新的正交方向。
```

- **具体示例**：$\mathbf{a}_1=[1,1,0]^{\mathsf{T}}$、$\mathbf{a}_2=[1,0,1]^{\mathsf{T}}$：$\mathbf{q}_1=\frac{1}{\sqrt{2}}[1,1,0]^{\mathsf{T}}$，$\mathbf{q}_1^{\mathsf{T}}\mathbf{a}_2=\frac{1}{\sqrt{2}}$，$\mathbf{v}_2=[1,0,1]^{\mathsf{T}}-\frac{1}{\sqrt{2}}\cdot\frac{1}{\sqrt{2}}[1,1,0]^{\mathsf{T}}=[\frac{1}{2},-\frac{1}{2},1]^{\mathsf{T}}$，$\|\mathbf{v}_2\|=\frac{\sqrt{6}}{2}$，$\mathbf{q}_2=\frac{1}{\sqrt{6}}[1,-1,2]^{\mathsf{T}}$。详细全流程见下一节。

$A=QR$ 分解

- **定义与目的**：把 Gram–Schmidt 的全过程写成矩阵等式：

$$A=QR,$$

A 是 $m\times n$ 列无关矩阵，Q 是 $m\times n$（或 $m\times m$）**列标准正交**，R 是 $n\times n$ **上三角**且对角元为正。具体地

$$R=\begin{bmatrix}\|\mathbf{v}_1\| & \mathbf{q}_1^{\mathsf{T}}\mathbf{a}_2 & \mathbf{q}_1^{\mathsf{T}}\mathbf{a}_3 & \cdots\\ 0 & \|\mathbf{v}_2\| & \mathbf{q}_2^{\mathsf{T}}\mathbf{a}_3 & \cdots\\ 0 & 0 & \|\mathbf{v}_3\| & \cdots\\ \vdots & \vdots & \vdots & \ddots\end{bmatrix}.$$

- **几何直觉（它在空间中是什么样子？）**：R 记录了 Gram–Schmidt 每一步的"施工记录"：对角元 $R_{ii}=\|\mathbf{v}_i\|$ 是第 i 步剥离出的正交分量的长度（它总是正的，因为 $\mathbf{a}_i$ 与前面的向量无关）；上三角的第 j 列记录 $\mathbf{a}_j$ 在已有各方向上的分量大小。上三角形状来自因果性——**第一个向量只用到自己，第二个用到前两个，第三个用到前三个**。
- **具体示例**：$A=\begin{bmatrix}1&1&0\\1&0&1\\0&1&1\end{bmatrix}$（列无关，$\det A=-2$）的 QR 中

$$R=\begin{bmatrix}\sqrt{2} & 1/\sqrt{2} & 1/\sqrt{2}\\ 0 & \sqrt{6}/2 & 1/\sqrt{6}\\ 0 & 0 & 2/\sqrt{3}\end{bmatrix},\qquad \prod_i R_{ii}=\sqrt{2}\cdot\frac{\sqrt{6}}{2}\cdot\frac{2}{\sqrt{3}}=2.$$

因为 Q 的列由 Gram–Schmidt 得到，每个 $R_{ii}=\|\mathbf{v}_i\|>0$，所以 $\prod R_{ii}=|\det A|=2$。符号由 $\det Q$ 承担：本例 $\det Q=-1$，于是 $\det A=\det Q\cdot\det R=(-1)\cdot 2=-2$ ✓。**一般结论**：$|\det A|=\prod_i R_{ii}$（与 $A=LU$ 时 $|\det A|=\prod_i |u_{ii}|$ 完全平行），符号则记录在 Q 里。

计算步骤与手算演示

示例 1（主例）：对 $A=\begin{bmatrix}1 & 1 & 0\\ 1 & 0 & 1\\ 0 & 1 & 1\end{bmatrix}$ 做完整的 Gram–Schmidt 与 QR 分解

三列分别是

$$\mathbf{a}_1=\begin{bmatrix}1\\1\\0\end{bmatrix},\qquad \mathbf{a}_2=\begin{bmatrix}1\\0\\1\end{bmatrix},\qquad \mathbf{a}_3=\begin{bmatrix}0\\1\\1\end{bmatrix}.$$

$\det A=1(0-1)-1(1-0)+0=-1-1=-2\neq 0$，三列线性无关。✓

步骤 1：处理 $\mathbf{a}_1$。

$$\|\mathbf{a}_1\|=\sqrt{1^2+1^2+0^2}=\sqrt{2},\qquad \mathbf{q}_1=\frac{1}{\sqrt{2}}\begin{bmatrix}1\\1\\0\end{bmatrix}=\begin{bmatrix}1/\sqrt{2}\\1/\sqrt{2}\\0\end{bmatrix}.$$

步骤 2：从 $\mathbf{a}_2$ 中减去它在 $\mathbf{q}_1$ 上的分量。

$$\mathbf{q}_1^{\mathsf{T}}\mathbf{a}_2=\frac{1}{\sqrt{2}}\cdot 1+\frac{1}{\sqrt{2}}\cdot 0+0\cdot 1=\frac{1}{\sqrt{2}}.$$

投影分量：

$$(\mathbf{q}_1^{\mathsf{T}}\mathbf{a}_2)\,\mathbf{q}_1=\frac{1}{\sqrt{2}}\cdot\frac{1}{\sqrt{2}}\begin{bmatrix}1\\1\\0\end{bmatrix}=\frac{1}{2}\begin{bmatrix}1\\1\\0\end{bmatrix}=\begin{bmatrix}1/2\\1/2\\0\end{bmatrix}.$$

相减：

$$\mathbf{v}_2=\mathbf{a}_2-(\mathbf{q}_1^{\mathsf{T}}\mathbf{a}_2)\mathbf{q}_1=\begin{bmatrix}1\\0\\1\end{bmatrix}-\begin{bmatrix}1/2\\1/2\\0\end{bmatrix}=\begin{bmatrix}1/2\\-1/2\\1\end{bmatrix}.$$

长度：

$$\|\mathbf{v}_2\|=\sqrt{\frac{1}{4}+\frac{1}{4}+1}=\sqrt{\frac{3}{2}}=\frac{\sqrt{6}}{2}.$$

单位化：

$$\mathbf{q}_2=\frac{\mathbf{v}_2}{\|\mathbf{v}_2\|}=\frac{2}{\sqrt{6}}\begin{bmatrix}1/2\\-1/2\\1\end{bmatrix}=\frac{1}{\sqrt{6}}\begin{bmatrix}1\\-1\\2\end{bmatrix}=\begin{bmatrix}1/\sqrt{6}\\-1/\sqrt{6}\\2/\sqrt{6}\end{bmatrix}.$$

步骤 3：从 $\mathbf{a}_3$ 中减去它在 $\mathbf{q}_1$ 与 $\mathbf{q}_2$ 上的分量。

$$\mathbf{q}_1^{\mathsf{T}}\mathbf{a}_3=\frac{1}{\sqrt{2}}\cdot 0+\frac{1}{\sqrt{2}}\cdot 1+0\cdot 1=\frac{1}{\sqrt{2}},\qquad \mathbf{q}_2^{\mathsf{T}}\mathbf{a}_3=\frac{1}{\sqrt{6}}\cdot 0+\frac{-1}{\sqrt{6}}\cdot 1+\frac{2}{\sqrt{6}}\cdot 1=\frac{1}{\sqrt{6}}.$$

两个投影分量：

$$(\mathbf{q}_1^{\mathsf{T}}\mathbf{a}_3)\mathbf{q}_1=\frac{1}{\sqrt{2}}\cdot\frac{1}{\sqrt{2}}\begin{bmatrix}1\\1\\0\end{bmatrix}=\frac{1}{2}\begin{bmatrix}1\\1\\0\end{bmatrix}=\begin{bmatrix}1/2\\1/2\\0\end{bmatrix},$$

$$(\mathbf{q}_2^{\mathsf{T}}\mathbf{a}_3)\mathbf{q}_2=\frac{1}{\sqrt{6}}\cdot\frac{1}{\sqrt{6}}\begin{bmatrix}1\\-1\\2\end{bmatrix}=\frac{1}{6}\begin{bmatrix}1\\-1\\2\end{bmatrix}=\begin{bmatrix}1/6\\-1/6\\1/3\end{bmatrix}.$$

相减：

$$\mathbf{v}_3 = \begin{bmatrix}0\\1\\1\end{bmatrix} - \begin{bmatrix}1/2\\1/2\\0\end{bmatrix} - \begin{bmatrix}1/6\\-1/6\\1/3\end{bmatrix} = \begin{bmatrix}0-\frac{1}{2}-\frac{1}{6}\\1-\frac{1}{2}+\frac{1}{6}\\1-0-\frac{1}{3}\end{bmatrix} = \begin{bmatrix}-2/3\\2/3\\2/3\end{bmatrix}.$$

（分数核对：$-\frac{1}{2}-\frac{1}{6}=-\frac{4}{6}=-\frac{2}{3}$；$1-\frac{1}{2}+\frac{1}{6}=\frac{6-3+1}{6}=\frac{4}{6}=\frac{2}{3}$；$1-\frac{1}{3}=\frac{2}{3}$。） 长度：

$$\|\mathbf{v}_3\| = \sqrt{\frac{4}{9}+\frac{4}{9}+\frac{4}{9}} = \sqrt{\frac{4}{3}} = \frac{2}{\sqrt{3}} = \frac{2\sqrt{3}}{3}.$$

单位化：

$$\mathbf{q}_3 = \frac{\mathbf{v}_3}{\|\mathbf{v}_3\|} = \frac{\sqrt{3}}{2}\begin{bmatrix}-2/3\\2/3\\2/3\end{bmatrix} = \frac{1}{\sqrt{3}}\begin{bmatrix}-1\\1\\1\end{bmatrix} = \begin{bmatrix}-1/\sqrt{3}\\1/\sqrt{3}\\1/\sqrt{3}\end{bmatrix}.$$

步骤 4：验证三个 $\mathbf{q}$ 两两正交且长度为 1。

$$\mathbf{q}_1^{\mathsf{T}}\mathbf{q}_2 = \frac{1}{\sqrt{2}\cdot\sqrt{6}}(1\cdot 1+1\cdot(-1)+0\cdot 2) = \frac{1-1}{\sqrt{12}} = 0. \checkmark$$

$$\mathbf{q}_1^{\mathsf{T}}\mathbf{q}_3 = \frac{1}{\sqrt{2}\cdot\sqrt{3}}(1\cdot(-1)+1\cdot 1+0\cdot 1) = \frac{-1+1}{\sqrt{6}} = 0. \checkmark$$

$$\mathbf{q}_2^{\mathsf{T}}\mathbf{q}_3 = \frac{1}{\sqrt{6}\cdot\sqrt{3}}(1\cdot(-1)+(-1)\cdot 1+2\cdot 1) = \frac{-1-1+2}{\sqrt{18}} = 0. \checkmark$$

$$\|\mathbf{q}_1\|^2 = \frac{1}{2}+\frac{1}{2}+0 = 1, \quad \|\mathbf{q}_2\|^2 = \frac{1}{6}+\frac{1}{6}+\frac{4}{6} = 1, \quad \|\mathbf{q}_3\|^2 = \frac{1}{3}+\frac{1}{3}+\frac{1}{3} = 1. \checkmark$$

步骤 5：组装 Q 与 R。

$$Q = [\mathbf{q}_1 \quad \mathbf{q}_2 \quad \mathbf{q}_3] = \begin{bmatrix}1/\sqrt{2} & 1/\sqrt{6} & -1/\sqrt{3}\\ 1/\sqrt{2} & -1/\sqrt{6} & 1/\sqrt{3}\\ 0 & 2/\sqrt{6} & 1/\sqrt{3}\end{bmatrix} \approx \begin{bmatrix}0.7071 & 0.4082 & -0.5774\\ 0.7071 & -0.4082 & 0.5774\\ 0 & 0.8165 & 0.5774\end{bmatrix}.$$

$$R = \begin{bmatrix}\|\mathbf{v}_1\| & \mathbf{q}_1^{\mathsf{T}}\mathbf{a}_2 & \mathbf{q}_1^{\mathsf{T}}\mathbf{a}_3\\ 0 & \|\mathbf{v}_2\| & \mathbf{q}_2^{\mathsf{T}}\mathbf{a}_3\\ 0 & 0 & \|\mathbf{v}_3\|\end{bmatrix} = \begin{bmatrix}\sqrt{2} & 1/\sqrt{2} & 1/\sqrt{2}\\ 0 & \sqrt{6}/2 & 1/\sqrt{6}\\ 0 & 0 & 2/\sqrt{3}\end{bmatrix} \approx \begin{bmatrix}1.4142 & 0.7071 & 0.7071\\ 0 & 1.2247 & 0.4082\\ 0 & 0 & 1.1547\end{bmatrix}.$$

步骤 6：验证 $QR = A$。 第一列：R 的第一列只有 $R_{11}=\sqrt{2}$，故 A 的第一列 $\approx \sqrt{2}\,\mathbf{q}_1 = \sqrt{2}\cdot\frac{1}{\sqrt{2}}[1,1,0]^{\mathsf{T}} = [1,1,0]^{\mathsf{T}}$。✓ 第二列：$\frac{1}{\sqrt{2}}\mathbf{q}_1 + \frac{\sqrt{6}}{2}\mathbf{q}_2 = \frac{1}{2}[1,1,0]^{\mathsf{T}} + \frac{\sqrt{6}}{2}\cdot\frac{1}{\sqrt{6}}[1,-1,2]^{\mathsf{T}} = \frac{1}{2}[1,1,0]^{\mathsf{T}} + \frac{1}{2}[1,-1,2]^{\mathsf{T}} = [1,0,1]^{\mathsf{T}}$。✓ 第三列：$\frac{1}{\sqrt{2}}\mathbf{q}_1 + \frac{1}{\sqrt{6}}\mathbf{q}_2 + \frac{2}{\sqrt{3}}\mathbf{q}_3$

$$= \frac{1}{2}\begin{bmatrix}1\\1\\0\end{bmatrix} + \frac{1}{6}\begin{bmatrix}1\\-1\\2\end{bmatrix} + \frac{2}{3}\begin{bmatrix}-1\\1\\1\end{bmatrix} = \begin{bmatrix}\frac{1}{2}+\frac{1}{6}-\frac{2}{3}\\ \frac{1}{2}-\frac{1}{6}+\frac{2}{3}\\ 0+\frac{1}{3}+\frac{2}{3}\end{bmatrix} = \begin{bmatrix}\frac{3+1-4}{6}\\ \frac{3-1+4}{6}\\ 1\end{bmatrix} = \begin{bmatrix}0\\1\\1\end{bmatrix}. \checkmark$$

矩阵形式：$QR \approx \begin{bmatrix}0.7071 & 0.4082 & -0.5774\\ 0.7071 & -0.4082 & 0.5774\\ 0 & 0.8165 & 0.5774\end{bmatrix}\begin{bmatrix}1.4142 & 0.7071 & 0.7071\\ 0 & 1.2247 & 0.4082\\ 0 & 0 & 1.1547\end{bmatrix} = \begin{bmatrix}1 & 1 & 0\\ 1 & 0 & 1\\ 0 & 1 & 1\end{bmatrix} = A$。✓

步骤 7：验证 $Q^{\mathsf{T}}Q = I$。

$$Q^{\mathsf{T}}Q = \begin{bmatrix}1 & 0 & 0\\ 0 & 1 & 0\\ 0 & 0 & 1\end{bmatrix}. \checkmark$$

（这是必然的：Q 的三列标准正交。注意 Q 是方阵，所以 $QQ^{\mathsf{T}} = I$ 也成立。）

步骤 8：det 的对照检验。 $\det A = -2$，而 $\det Q = \det[\mathbf{q}_1 \quad \mathbf{q}_2 \quad \mathbf{q}_3]$。直接算 Q 的行列式（用第 3 行展开，$Q_{31}=0$）：

$$\det Q = 0\cdot(\cdots) - \frac{2}{\sqrt{6}}\left(\frac{1}{\sqrt{2}}\cdot\frac{1}{\sqrt{3}} - \frac{-1}{\sqrt{3}}\cdot\frac{1}{\sqrt{2}}\right) + \frac{1}{\sqrt{3}}\left(\frac{1}{\sqrt{2}}\cdot\frac{-1}{\sqrt{6}} - \frac{1}{\sqrt{6}}\cdot\frac{1}{\sqrt{2}}\right)$$

$$= -\frac{2}{\sqrt{6}}\cdot\frac{2}{\sqrt{6}} + \frac{1}{\sqrt{3}}\cdot\left(-\frac{2}{\sqrt{12}}\right) = -\frac{4}{6} - \frac{2}{\sqrt{36}} = -\frac{2}{3} - \frac{1}{3} = -1.$$

于是 $\det A = \det Q\cdot\det R = (-1)\cdot\left(\sqrt{2}\cdot\frac{\sqrt{6}}{2}\cdot\frac{2}{\sqrt{3}}\right) = (-1)\cdot\sqrt{2}\cdot\frac{\sqrt{6}}{\sqrt{3}} = (-1)\cdot\sqrt{2}\cdot\sqrt{2} = -2.$ ✓

注意符号：$\prod_i R_{ii} = \sqrt{2}\cdot\frac{\sqrt{6}}{2}\cdot\frac{2}{\sqrt{3}} = 2 > 0$，所以 $|\det A| = 2$ 直接可读；符号由 $\det Q = \pm 1$ 承载。**$|\det A| = \prod_i R_{ii}$ 总是成立的**（因为 $|\det Q| = 1$），这是 QR 的一个免费副产品。

【计算机制解说】：Gram–Schmidt 为什么一定成功？两个关键点。

（i）为什么 $\mathbf{v}_k \neq \mathbf{0}$？ 假设 $\mathbf{v}_k = \mathbf{0}$，则 $\mathbf{a}_k$ 完全落在 $\mathbf{span}\{\mathbf{q}_1,\dots,\mathbf{q}_{k-1}\} = \mathbf{span}\{\mathbf{a}_1,\dots,\mathbf{a}_{k-1}\}$ 里，即 $\mathbf{a}_1,\dots,\mathbf{a}_k$ 线性相关——与前提矛盾。所以只要原向量组线性无关，每一步的 $\mathbf{v}_k$ 都非零，$\mathbf{q}_k$ 有意义，且 $R_{kk} = \|\mathbf{v}_k\| > 0$。

（ii）为什么每个 $\mathbf{v}_k$ 都垂直于所有前面的 $\mathbf{q}_j$？ 用归纳法。以 $\mathbf{v}_2$ 为例：

$$\mathbf{q}_1^{\mathsf{T}}\mathbf{v}_2 = \mathbf{q}_1^{\mathsf{T}}\mathbf{a}_2 - (\mathbf{q}_1^{\mathsf{T}}\mathbf{a}_2)\underbrace{\mathbf{q}_1^{\mathsf{T}}\mathbf{q}_1}_{=1} = 0.$$

对 $\mathbf{v}_3$：对 $j = 1, 2$，

$$\mathbf{q}_j^{\mathsf{T}}\mathbf{v}_3 = \mathbf{q}_j^{\mathsf{T}}\mathbf{a}_3 - (\mathbf{q}_1^{\mathsf{T}}\mathbf{a}_3)\underbrace{\mathbf{q}_j^{\mathsf{T}}\mathbf{q}_1}_{=\delta_{j1}} - (\mathbf{q}_2^{\mathsf{T}}\mathbf{a}_3)\underbrace{\mathbf{q}_j^{\mathsf{T}}\mathbf{q}_2}_{=\delta_{j2}} = 0.$$

一般地，$\mathbf{q}_j^{\mathsf{T}}\mathbf{v}_k = \mathbf{q}_j^{\mathsf{T}}\mathbf{a}_k - \mathbf{q}_j^{\mathsf{T}}\mathbf{a}_k = 0$。这一步之所以干净，全靠前面已经**单位化**——如果 $\mathbf{q}$ 只有正交而未归一，公式里会残留 $\|\mathbf{q}_j\|^2$ 因子。**内积的"抵消"机制是 Gram–Schmidt 的核心。**

（iii）张成空间为什么保持不变？ 每一步都是"从一个向量里减去前面向量的线性组合"，所以 $\mathbf{v}_k$ 与 $\mathbf{a}_k$ 的差落在前面张成的空间里，因此 $\mathbf{span}\{\mathbf{q}_1,\dots,\mathbf{q}_k\} \subseteq \mathbf{span}\{\mathbf{a}_1,\dots,\mathbf{a}_k\}$；反过来 $\mathbf{a}_k$ 也可由 $\mathbf{q}_1,\dots,\mathbf{q}_k$ 线性表示，两方向都成立，维数相同（都是 k），所以相等。这保证了 A 与 Q 的列空间相同——投影到 $C(A)$ 与投影到 $C(Q)$ 是同一件事。

示例 2：用 QR 做最小二乘——把 Lecture 16 的答案再用一遍

沿用 Lecture 16 的数据 $(1,1),(2,2),(3,4)$：

$$A = \begin{bmatrix}1 & 1\\ 1 & 2\\ 1 & 3\end{bmatrix}, \qquad \mathbf{b} = \begin{bmatrix}1\\ 2\\ 4\end{bmatrix}.$$

$\mathbf{a}_1 = [1,1,1]^{\mathsf{T}}$，$\mathbf{a}_2 = [1,2,3]^{\mathsf{T}}$。

步骤 1：Gram–Schmidt。

$$\|\mathbf{a}_1\| = \sqrt{3}, \qquad \mathbf{q}_1 = \frac{1}{\sqrt{3}}\begin{bmatrix}1\\1\\1\end{bmatrix}.$$

$$\mathbf{q}_1^{\mathsf{T}}\mathbf{a}_2 = \frac{1+2+3}{\sqrt{3}} = \frac{6}{\sqrt{3}} = 2\sqrt{3}, \qquad (\mathbf{q}_1^{\mathsf{T}}\mathbf{a}_2)\mathbf{q}_1 = 2\sqrt{3}\cdot\frac{1}{\sqrt{3}}\begin{bmatrix}1\\1\\1\end{bmatrix} = 2\begin{bmatrix}1\\1\\1\end{bmatrix} = \begin{bmatrix}2\\2\\2\end{bmatrix},$$

$$\mathbf{v}_2 = \begin{bmatrix}1\\2\\3\end{bmatrix} - \begin{bmatrix}2\\2\\2\end{bmatrix} = \begin{bmatrix}-1\\0\\1\end{bmatrix}, \qquad \|\mathbf{v}_2\| = \sqrt{2}, \qquad \mathbf{q}_2 = \frac{1}{\sqrt{2}}\begin{bmatrix}-1\\0\\1\end{bmatrix}.$$

步骤 2：组装 Q, R。

$$Q = \begin{bmatrix}1/\sqrt{3} & -1/\sqrt{2}\\ 1/\sqrt{3} & 0\\ 1/\sqrt{3} & 1/\sqrt{2}\end{bmatrix}, \qquad R = \begin{bmatrix}\sqrt{3} & 2\sqrt{3}\\ 0 & \sqrt{2}\end{bmatrix}.$$

验证 $QR = A$：第一列 $\sqrt{3}\,\mathbf{q}_1 = [1,1,1]^{\mathsf{T}}$ ✓；第二列 $2\sqrt{3}\,\mathbf{q}_1 + \sqrt{2}\,\mathbf{q}_2 = [2,2,2]^{\mathsf{T}} + [-1,0,1]^{\mathsf{T}} = [1,2,3]^{\mathsf{T}}$ ✓。$Q^{\mathsf{T}}Q = \begin{bmatrix}1 & 0\\ 0 & 1\end{bmatrix}$ ✓。

步骤 3：把正规方程换成 $R\hat{\mathbf{x}} = Q^{\mathsf{T}}\mathbf{b}$。

$$Q^{\mathsf{T}}\mathbf{b} = \begin{bmatrix}1/\sqrt{3} & 1/\sqrt{3} & 1/\sqrt{3}\\ -1/\sqrt{2} & 0 & 1/\sqrt{2}\end{bmatrix}\begin{bmatrix}1\\2\\4\end{bmatrix} = \begin{bmatrix}\frac{7}{\sqrt{3}}\\ \frac{3}{\sqrt{2}}\end{bmatrix} \approx \begin{bmatrix}4.0415\\ 2.1213\end{bmatrix}.$$

步骤 4：回代。

$$\begin{bmatrix}\sqrt{3} & 2\sqrt{3}\\ 0 & \sqrt{2}\end{bmatrix}\begin{bmatrix}C\\D\end{bmatrix} = \begin{bmatrix}7/\sqrt{3}\\ 3/\sqrt{2}\end{bmatrix}.$$

第二行：$\sqrt{2}\,D = \frac{3}{\sqrt{2}} \Rightarrow D = \frac{3}{2}$。（与 Lecture 16 的 $D = 3/2$ 一致。） 第一行：
$\sqrt{3}\,C + 2\sqrt{3}\cdot\frac{3}{2} = \frac{7}{\sqrt{3}} \Rightarrow \sqrt{3}C = \frac{7}{\sqrt{3}} - 3\sqrt{3} = \frac{7-9}{\sqrt{3}} = -\frac{2}{\sqrt{3}} \Rightarrow C = -\frac{2}{3}$。（一致。）

步骤 5：投影与残差（用 $P = QQ^{\mathsf{T}}$）。

$$P = QQ^{\mathsf{T}} = \begin{bmatrix} 1/\sqrt{3} & -1/\sqrt{2} \\ 1/\sqrt{3} & 0 \\ 1/\sqrt{3} & 1/\sqrt{2} \end{bmatrix} \begin{bmatrix} 1/\sqrt{3} & 1/\sqrt{3} & 1/\sqrt{3} \\ -1/\sqrt{2} & 0 & 1/\sqrt{2} \end{bmatrix} = \begin{bmatrix} \frac{1}{3}+\frac{1}{2} & \frac{1}{3} & \frac{1}{3}-\frac{1}{2} \\ \frac{1}{3} & \frac{1}{3} & \frac{1}{3} \\ \frac{1}{3}-\frac{1}{2} & \frac{1}{3} & \frac{1}{3}+\frac{1}{2} \end{bmatrix} = \begin{bmatrix} 5/6 & 1/3 & -1/6 \\ 1/3 & 1/3 & 1/3 \\ -1/6 & 1/3 & 5/6 \end{bmatrix}.$$

这与 Lecture 16 用 $A(A^{\mathsf{T}}A)^{-1}A^{\mathsf{T}}$ 算出的 P 完全相同 ✓——但这次我们**没有求任何逆矩阵**。$P\mathbf{b} = \begin{bmatrix} 5/6 \\ 7/3 \\ 23/6 \end{bmatrix}$，$\mathbf{e} = \mathbf{b} - P\mathbf{b} = \begin{bmatrix} 1/6 \\ -1/3 \\ 1/6 \end{bmatrix}$，$E = 1/6$。✓

另一种算法（更直观）：直接用正交基展开投影

$$\mathbf{p} = (\mathbf{q}_1^{\mathsf{T}}\mathbf{b})\mathbf{q}_1 + (\mathbf{q}_2^{\mathsf{T}}\mathbf{b})\mathbf{q}_2 = \frac{7}{\sqrt{3}} \cdot \frac{1}{\sqrt{3}} \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix} + \frac{3}{\sqrt{2}} \cdot \frac{1}{\sqrt{2}} \begin{bmatrix} -1 \\ 0 \\ 1 \end{bmatrix} = \begin{bmatrix} 7/3 \\ 7/3 \\ 7/3 \end{bmatrix} + \begin{bmatrix} -3/2 \\ 0 \\ 3/2 \end{bmatrix} = \begin{bmatrix} 5/6 \\ 7/3 \\ 23/6 \end{bmatrix}. \checkmark$$

并且 $\mathbf{q}_1^{\mathsf{T}}\mathbf{e} = \frac{1}{\sqrt{3}}\left(\frac{1}{6} - \frac{1}{3} + \frac{1}{6}\right) = 0$，$\mathbf{q}_2^{\mathsf{T}}\mathbf{e} = \frac{1}{\sqrt{2}}\left(-\frac{1}{6} + \frac{1}{6}\right) = 0$。✓

【计算机制解说】：为什么 $A = QR$ 让最小二乘又快又稳？

（i）代数上省一次求逆：$A^{\mathsf{T}}A = (QR)^{\mathsf{T}}(QR) = R^{\mathsf{T}}\underbrace{Q^{\mathsf{T}}Q}_{=I}R = R^{\mathsf{T}}R$。正规方程 $A^{\mathsf{T}}A\hat{\mathbf{x}} = A^{\mathsf{T}}\mathbf{b}$ 变为

$$R^{\mathsf{T}}R\hat{\mathbf{x}} = R^{\mathsf{T}}Q^{\mathsf{T}}\mathbf{b}.$$

R 可逆（对角元 $R_{ii} = \|\mathbf{v}_i\| > 0$），两边左乘 $(R^{\mathsf{T}})^{-1}$ 得 $R\hat{\mathbf{x}} = Q^{\mathsf{T}}\mathbf{b}$。$R$ 上三角，**回代**（back substitution）两步搞定，不需要显式求逆。

（ii）结构上变成"逐个正交分量"：$R\hat{\mathbf{x}} = Q^{\mathsf{T}}\mathbf{b}$ 的最后一个分量最先解出（$R_{nn}\hat{x}_n = \mathbf{q}_n^{\mathsf{T}}\mathbf{b}$），然后往上回代。这说明 Gram–Schmidt 的顺序就是"信息逐步进入"的顺序，第一个基向量最先生效，最后一个最后修正。

（iii）数值上更稳：$A^{\mathsf{T}}A$ 的**条件数是 A 的条件数的平方**。若 A 的奇异值跨越 10^4 倍，$A^{\mathsf{T}}A$ 就跨越 10^8 倍——在浮点数里损失大量有效位。而 QR 路径只用正交变换（保长，不放大误差）和三角回代，条件数只损失一次方。这就是为什么所有工业级最小二乘软件（LAPACK 的 `gels`、NumPy 的 `lstsq`）内部都用 QR 或 SVD，而不是直接解 $A^{\mathsf{T}}A$。

（iv）顺带一提"免费的行列式"：由 $A = QR$ 得 $|\det A| = |\det Q| \cdot |\det R| = \prod_i R_{ii}$（$R$ 上三角），$|\det Q| = 1$。示例 1 已验证 $\prod R_{ii} = 2 = |\det A|$。

示例 3：用标准正交基做投影——$P = QQ^{\mathsf{T}}$ 与"逐个分量相加"

取示例 1 中的平面，用它的前两个标准正交方向张成平面 $\mathcal{P} = \mathbf{span}\{\mathbf{q}_1, \mathbf{q}_2\}$：

$$\mathbf{q}_1 = \frac{1}{\sqrt{2}}\begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix}, \qquad \mathbf{q}_2 = \frac{1}{\sqrt{6}}\begin{bmatrix} 1 \\ -1 \\ 2 \end{bmatrix}, \qquad \mathbf{b} = \begin{bmatrix} 1 \\ 2 \\ 4 \end{bmatrix}.$$

步骤 1：算两个系数。

$$\mathbf{q}_1^{\mathsf{T}}\mathbf{b} = \frac{1+2+0}{\sqrt{2}} = \frac{3}{\sqrt{2}} \approx 2.1213, \qquad \mathbf{q}_2^{\mathsf{T}}\mathbf{b} = \frac{1-2+8}{\sqrt{6}} = \frac{7}{\sqrt{6}} \approx 2.8577.$$

步骤 2：投影 = 分量之和。

$$\mathbf{p} = \frac{3}{\sqrt{2}} \cdot \frac{1}{\sqrt{2}}\begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix} + \frac{7}{\sqrt{6}} \cdot \frac{1}{\sqrt{6}}\begin{bmatrix} 1 \\ -1 \\ 2 \end{bmatrix} = \frac{3}{2}\begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix} + \frac{7}{6}\begin{bmatrix} 1 \\ -1 \\ 2 \end{bmatrix} = \begin{bmatrix} \frac{3}{2}+\frac{7}{6} \\ \frac{3}{2}-\frac{7}{6} \\ \frac{14}{6} \end{bmatrix} = \begin{bmatrix} \frac{9+7}{6} \\ \frac{9-7}{6} \\ \frac{7}{3} \end{bmatrix} = \begin{bmatrix} 8/3 \\ 1/3 \\ 7/3 \end{bmatrix} \approx \begin{bmatrix} 2.6667 \\ 0.3333 \\ 2.3333 \end{bmatrix}.$$

步骤 3：残差与正交验证。

$$\mathbf{e} = \mathbf{b} - \mathbf{p} = \begin{bmatrix} 1 - 8/3 \\ 2 - 1/3 \\ 4 - 7/3 \end{bmatrix} = \begin{bmatrix} -5/3 \\ 5/3 \\ 5/3 \end{bmatrix} \approx \begin{bmatrix} -1.6667 \\ 1.6667 \\ 1.6667 \end{bmatrix}.$$

$$\mathbf{q}_1^{\mathsf{T}}\mathbf{e} = \frac{1}{\sqrt{2}}\left(-\frac{5}{3} + \frac{5}{3}\right) = 0, \qquad \mathbf{q}_2^{\mathsf{T}}\mathbf{e} = \frac{1}{\sqrt{6}}\left(-\frac{5}{3} - \frac{5}{3} + \frac{10}{3}\right) = 0. \checkmark$$

步骤 4：$P = QQ^{\mathsf{T}}$ 应给出同样的 $\mathbf{p}$。

$$QQ^{\mathsf{T}} = \begin{bmatrix} 1/\sqrt{2} & 1/\sqrt{6} \\ 1/\sqrt{2} & -1/\sqrt{6} \\ 0 & 2/\sqrt{6} \end{bmatrix} \begin{bmatrix} 1/\sqrt{2} & 1/\sqrt{2} & 0 \\ 1/\sqrt{6} & -1/\sqrt{6} & 2/\sqrt{6} \end{bmatrix} = \begin{bmatrix} \frac{1}{2}+\frac{1}{6} & \frac{1}{2}-\frac{1}{6} & \frac{2}{6} \\ \frac{1}{2}-\frac{1}{6} & \frac{1}{2}+\frac{1}{6} & -\frac{2}{6} \\ \frac{2}{6} & -\frac{2}{6} & \frac{4}{6} \end{bmatrix} = \begin{bmatrix} 2/3 & 1/3 & 1/3 \\ 1/3 & 2/3 & -1/3 \\ 1/3 & -1/3 & 2/3 \end{bmatrix}.$$

$QQ^{\mathsf{T}}\mathbf{b} = \begin{bmatrix} \frac{2}{3}+\frac{2}{3}+\frac{4}{3} \\ \frac{1}{3}+\frac{4}{3}-\frac{4}{3} \\ \frac{1}{3}-\frac{2}{3}+\frac{8}{3} \end{bmatrix} = \begin{bmatrix} 8/3 \\ 1/3 \\ 7/3 \end{bmatrix} = \mathbf{p}$. ✓ P 对称、幂等（与 Lecture 15 示例 2 的 P 形状完全一致——因为 P 只取决于子空间，不取决于你选哪组基来描述它），$\mathbf{trace}(P) = \frac{2}{3}+\frac{2}{3}+\frac{2}{3} = 2$。✓

步骤 5：用 $I-P$ 直接得误差。

$$\mathbf{e} = (I-P)\mathbf{b} = \begin{bmatrix} 1/3 & -1/3 & -1/3 \\ -1/3 & 1/3 & 1/3 \\ -1/3 & 1/3 & 1/3 \end{bmatrix} \begin{bmatrix} 1 \\ 2 \\ 4 \end{bmatrix} = \begin{bmatrix} \frac{1}{3}-\frac{2}{3}-\frac{4}{3} \\ -\frac{1}{3}+\frac{2}{3}+\frac{4}{3} \\ -\frac{1}{3}+\frac{2}{3}+\frac{4}{3} \end{bmatrix} = \begin{bmatrix} -5/3 \\ 5/3 \\ 5/3 \end{bmatrix}. \checkmark$$

【计算机制解说】：这个例子把"$A^{\mathsf{T}}A$ 耦合"与"$Q^{\mathsf{T}}Q = I$ 解耦"的差别展示得很清楚。

若用**非正交**基 $\mathbf{a}_1, \mathbf{a}_2$ 描述同一个平面，求 $\mathbf{p} = c_1\mathbf{a}_1 + c_2\mathbf{a}_2$ 需要解 $\begin{bmatrix} \mathbf{a}_1^{\mathsf{T}}\mathbf{a}_1 & \mathbf{a}_1^{\mathsf{T}}\mathbf{a}_2 \\ \mathbf{a}_2^{\mathsf{T}}\mathbf{a}_1 & \mathbf{a}_2^{\mathsf{T}}\mathbf{a}_2 \end{bmatrix} \begin{bmatrix} c_1 \\ c_2 \end{bmatrix} = \begin{bmatrix} \mathbf{a}_1^{\mathsf{T}}\mathbf{b} \\ \mathbf{a}_2^{\mathsf{T}}\mathbf{b} \end{bmatrix}$——**两个未知数互相纠缠**（示例 3 的 $A^{\mathsf{T}}A$ 一般不是对角阵）。 若用**正交**基，矩阵变成单位阵 I，方程立刻解耦成 $\mathbf{q}_1^{\mathsf{T}}\mathbf{b}$、$\mathbf{q}_2^{\mathsf{T}}\mathbf{b}$ 两个独立的一维投影。几何上，这意味着**沿着互相垂直的方向，分量互不干扰**——这正是"正交"一词的实际价值。Gram–Schmidt 的全部努力，就是把一个耦合问题变成 n 个互不相干的简单问题。

示例 4：Gram–Schmidt 顺带检测线性相关（R 出现零对角元）

取一个**列相关**的矩阵：

$$A = \begin{bmatrix} 1 & 2 & 0 \\ 1 & 2 & 1 \\ 0 & 0 & 1 \end{bmatrix}, \qquad \text{列：}\ \mathbf{a}_1 = \begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix},\ \mathbf{a}_2 = \begin{bmatrix} 2 \\ 2 \\ 0 \end{bmatrix},\ \mathbf{a}_3 = \begin{bmatrix} 0 \\ 1 \\ 1 \end{bmatrix}.$$

显然 $\mathbf{a}_2 = 2\mathbf{a}_1$，所以 $\mathbf{rank}(A) = 2$。

步骤 1：处理 $\mathbf{a}_1$。

$$\|\mathbf{a}_1\| = \sqrt{2}, \qquad \mathbf{q}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix}.$$

步骤 2：处理 $\mathbf{a}_2$——$\mathbf{v}_2$ 变成零向量。

$$\mathbf{q}_1^{\mathsf{T}}\mathbf{a}_2 = \frac{2+2+0}{\sqrt{2}} = \frac{4}{\sqrt{2}} = 2\sqrt{2}, \qquad (\mathbf{q}_1^{\mathsf{T}}\mathbf{a}_2)\mathbf{q}_1 = 2\sqrt{2} \cdot \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix} = 2 \begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix} = \begin{bmatrix} 2 \\ 2 \\ 0 \end{bmatrix},$$

$$\mathbf{v}_2 = \mathbf{a}_2 - (\mathbf{q}_1^{\mathsf{T}}\mathbf{a}_2)\mathbf{q}_1 = \begin{bmatrix} 2 \\ 2 \\ 0 \end{bmatrix} - \begin{bmatrix} 2 \\ 2 \\ 0 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}, \qquad \|\mathbf{v}_2\| = 0.$$

算法在这里报警：$\mathbf{v}_2 = \mathbf{0}$ 说明 $\mathbf{a}_2$ 完全落在前面已建好的方向里，$\mathbf{a}_2$ 与 $\mathbf{a}_1$ 线性相关。此时 $R_{22} = 0$，R 奇异，$A = QR$ 的"薄"版本不存在（因为 Q 无法凑出 $n = 3$ 个正交列）。若强行继续（用 $\mathbf{0}/0$ 单位化）会得到 NaN。

步骤 3：跳过 $\mathbf{a}_2$，改用 $\mathbf{a}_3$ 作为第二个方向（列主元的思想）。

$$\mathbf{q}_1^{\mathsf{T}}\mathbf{a}_3 = \frac{0+1+0}{\sqrt{2}} = \frac{1}{\sqrt{2}}, \qquad (\mathbf{q}_1^{\mathsf{T}}\mathbf{a}_3)\mathbf{q}_1 = \frac{1}{\sqrt{2}} \cdot \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix} = \begin{bmatrix} 1/2 \\ 1/2 \\ 0 \end{bmatrix},$$

$$\mathbf{v}_3 = \begin{bmatrix} 0 \\ 1 \\ 1 \end{bmatrix} - \begin{bmatrix} 1/2 \\ 1/2 \\ 0 \end{bmatrix} = \begin{bmatrix} -1/2 \\ 1/2 \\ 1 \end{bmatrix}, \qquad \|\mathbf{v}_3\| = \sqrt{\frac{1}{4}+\frac{1}{4}+1} = \frac{\sqrt{6}}{2},$$

$$\mathbf{q}_2 = \frac{2}{\sqrt{6}} \begin{bmatrix} -1/2 \\ 1/2 \\ 1 \end{bmatrix} = \frac{1}{\sqrt{6}} \begin{bmatrix} -1 \\ 1 \\ 2 \end{bmatrix}.$$

步骤 4：用前两列 $[\mathbf{a}_1, \mathbf{a}_3]$ 组装有效的 QR。

$$Q = \begin{bmatrix} 1/\sqrt{2} & -1/\sqrt{6} \\ 1/\sqrt{2} & 1/\sqrt{6} \\ 0 & 2/\sqrt{6} \end{bmatrix}, \qquad R = \begin{bmatrix} \sqrt{2} & 1/\sqrt{2} \\ 0 & \sqrt{6}/2 \end{bmatrix}.$$

验证 $QR=$ 前两列 $=\begin{bmatrix}1&0\\1&1\\0&1\end{bmatrix}$：第一列 $\sqrt{2}\mathbf{q}_1=[1,1,0]^{\mathsf T}$ ✓；第二列 $\frac{1}{\sqrt2}\mathbf{q}_1+\frac{\sqrt6}{2}\mathbf{q}_2=\frac12[1,1,0]^{\mathsf T}+\frac12[-1,1,2]^{\mathsf T}=[0,1,1]^{\mathsf T}$ ✓。$Q^{\mathsf T}Q=I$ ✓，且 $\|\mathbf{q}_1\|=\|\mathbf{q}_2\|=1$、$\mathbf{q}_1^{\mathsf T}\mathbf{q}_2=\frac{-1+1+0}{\sqrt{12}}=0$ ✓。$\sqrt3=\sqrt2\cdot\frac{\sqrt6}{2}=R_{11}R_{22}$ 正是这两列在 $\mathbb{R}^3$ 中张成的平行四边形的面积（由 $\|\mathbf{a}_1\|\cdot\|\mathbf{v}_3\|$ 给出：底 × 高），也等于 $\sqrt{\det(A^{\mathsf T}A)}=\sqrt{\det\begin{bmatrix}2&1\\1&2\end{bmatrix}}=\sqrt3$（一般地，$A$ 的两列张成的面积 $=\sqrt{\det(A^{\mathsf T}A)}$）。✓

【计算机制解说】：R 出现零对角元与"A 列相关"是**同一件事**，而 Gram–Schmidt 是免费的秩检测器。原因是 $R_{kk}=\|\mathbf{v}_k\|$，而 $\mathbf{v}_k=\mathbf{0}\iff\mathbf{a}_k\in\operatorname{span}\{\mathbf{a}_1,\dots,\mathbf{a}_{k-1}\}$。所以"数一数 R 中有几个非零对角元"就等于 $\operatorname{rank}(A)$——不需要算行列式或做行消元。实际软件为了稳健，会在每一步**选剩余向量中长度最大的那个**先处理（**列主元 QR，column pivoting**），这样零对角元会集中在 R 的右下角，一眼就能看出有效秩，也能避免"小 $\|\mathbf{v}_k\|$ 除以接近零的数"造成的数值灾难。这也是 Lecture 33 构造伪逆 A^+ 的思路之一（另一种是 SVD，更稳）。

示例 5：Householder 变换——另一种（更稳的）走上三角的方法

经典 Gram–Schmidt 逐列减投影；Householder 则用**反射矩阵**把整列"打"成只剩一个非零元。仍然用 $\mathbf{a}_1=[1,2,3]^{\mathsf T}$，$\mathbf{a}_2=[1,0,1]^{\mathsf T}$ 组成的

$$A=\begin{bmatrix}1&1\\2&0\\3&1\end{bmatrix}.$$

步骤 1：构造反射。 目标是找一个单位向量 $\mathbf{u}$，使

$$H=I-2\frac{\mathbf{u}\mathbf{u}^{\mathsf T}}{\mathbf{u}^{\mathsf T}\mathbf{u}}$$

把 $\mathbf{a}_1$ 映成 $\|\mathbf{a}_1\|\mathbf{e}_1$ 的倍数。H 的性质：对称（$H^{\mathsf T}=H$）、正交（$H^{\mathsf T}H=I$）、对合（$H^2=I$）——它是关于超平面 $\mathbf{u}^\perp$ 的**镜面反射**。

取 $\mathbf{u}=\mathbf{a}_1-\|\mathbf{a}_1\|\mathbf{e}_1$。$\|\mathbf{a}_1\|=\sqrt{1+4+9}=\sqrt{14}\approx3.7417$，故

$$\mathbf{u}=\begin{bmatrix}1\\2\\3\end{bmatrix}-\begin{bmatrix}\sqrt{14}\\0\\0\end{bmatrix}=\begin{bmatrix}1-\sqrt{14}\\2\\3\end{bmatrix}\approx\begin{bmatrix}-2.7417\\2\\3\end{bmatrix}.$$

（先略去具体数值计算，只验证"结构"：$H\mathbf{a}_1$ 的第一分量会是 $-\|\mathbf{a}_1\|$，其余为零。）

步骤 2：2×2 的完整手算版本（数字干净）。 取

$$A=\begin{bmatrix}3&1\\4&2\end{bmatrix},\qquad\mathbf{a}_1=\begin{bmatrix}3\\4\end{bmatrix},\ \|\mathbf{a}_1\|=5,\ \mathbf{u}=\mathbf{a}_1-5\mathbf{e}_1=\begin{bmatrix}-2\\4\end{bmatrix},$$

$$\mathbf{u}^{\mathsf T}\mathbf{u}=4+16=20,\qquad H=I-2\frac{\mathbf{u}\mathbf{u}^{\mathsf T}}{20}=I-\frac{1}{10}\begin{bmatrix}4&-8\\-8&16\end{bmatrix}=\begin{bmatrix}1-0.4&0.8\\0.8&1-1.6\end{bmatrix}=\begin{bmatrix}0.6&0.8\\0.8&-0.6\end{bmatrix}.$$

验证：

$$H^{\mathsf T}H=\begin{bmatrix}0.6&0.8\\0.8&-0.6\end{bmatrix}\begin{bmatrix}0.6&0.8\\0.8&-0.6\end{bmatrix}=\begin{bmatrix}0.36+0.64&0.48-0.48\\0.48-0.48&0.64+0.36\end{bmatrix}=\begin{bmatrix}1&0\\0&1\end{bmatrix}.\ \checkmark$$

$H^2=I$，$\det H=0.6\cdot(-0.6)-0.8\cdot0.8=-0.36-0.64=-1$（反射，行列式为 -1）。✓

$$HA=\begin{bmatrix}0.6&0.8\\0.8&-0.6\end{bmatrix}\begin{bmatrix}3&1\\4&2\end{bmatrix}=\begin{bmatrix}1.8+3.2&0.6+1.6\\2.4-2.4&0.8-1.2\end{bmatrix}=\begin{bmatrix}5&2.2\\0&-0.4\end{bmatrix}=R.$$

R 已是上三角！取 $Q=H^{\mathsf T}=H=\begin{bmatrix}0.6&0.8\\0.8&-0.6\end{bmatrix}$，则

$$QR=\begin{bmatrix}0.6&0.8\\0.8&-0.6\end{bmatrix}\begin{bmatrix}5&2.2\\0&-0.4\end{bmatrix}=\begin{bmatrix}3&1.32-0.32\\4&1.76+0.24\end{bmatrix}=\begin{bmatrix}3&1\\4&2\end{bmatrix}=A.\ \checkmark$$

并且 $|\det A|=|3\cdot2-1\cdot4|=2=|\det R|=|5\cdot(-0.4)|=2=\prod_i|R_{ii}|$。✓

【计算机制解说】：Householder 与 Gram–Schmidt 的目标完全一样（把 A 变成"正交 × 上三角"），但机制相反。

- Gram–Schmidt 是**"列的技巧"**：逐列做投影减法，每一步的输出是**正交方向** $\mathbf{q}_k$ 与系数 $\mathbf{q}_i^{\mathsf T}\mathbf{a}_k$。它天然给出 R 的逐列信息，适合"逐步加新列"的在线场景；但减法会放大误差。
- Householder 是**"矩阵的技巧"**：构造一系列反射 $H_1,H_2,\dots$，每个 H_k 把第 k 列下方的所有元素一次清零。因为 H 是**正交**变换，每一步都保长、不放大误差，所以数值上更稳。最终 $A=H_1H_2\cdots H_nR$（H_k 对称，逆就是自己），$Q=H_1H_2\cdots H_n$ 的列自动标准正交。
- **为什么反射能清零？** 镜面反射可以把任意向量映到任意**同长度**的向量——把 $\mathbf{a}$ 映到 $\pm\|\mathbf{a}\|\mathbf{e}_1$ 就是把它的方向"掰"到坐标轴上，其余分量自然归零。这正是"几何即算法"的漂亮例子。

示例 6：用 QR 做四点直线拟合的最小二乘

数据 $(0,1),(1,2),(2,4),(3,5)$，模型 $b = C + Dt$：

$$A = \begin{bmatrix} 1 & 0 \\ 1 & 1 \\ 1 & 2 \\ 1 & 3 \end{bmatrix}, \qquad \mathbf{b} = \begin{bmatrix} 1 \\ 2 \\ 4 \\ 5 \end{bmatrix}, \qquad \mathbf{a}_1 = [1,1,1,1]^{\mathsf{T}},\ \mathbf{a}_2 = [0,1,2,3]^{\mathsf{T}}.$$

步骤 1：Gram–Schmidt。

$$\|\mathbf{a}_1\| = 2, \qquad \mathbf{q}_1 = \frac{1}{2}[1,1,1,1]^{\mathsf{T}} = \left[\tfrac{1}{2},\tfrac{1}{2},\tfrac{1}{2},\tfrac{1}{2}\right]^{\mathsf{T}},$$

$$\mathbf{q}_1^{\mathsf{T}}\mathbf{a}_2 = \frac{0+1+2+3}{2} = \frac{6}{2} = 3, \qquad (\mathbf{q}_1^{\mathsf{T}}\mathbf{a}_2)\mathbf{q}_1 = 3 \cdot \frac{1}{2}[1,1,1,1]^{\mathsf{T}} = \left[\tfrac{3}{2},\tfrac{3}{2},\tfrac{3}{2},\tfrac{3}{2}\right]^{\mathsf{T}},$$

$$\mathbf{v}_2 = [0,1,2,3]^{\mathsf{T}} - \left[\tfrac{3}{2},\tfrac{3}{2},\tfrac{3}{2},\tfrac{3}{2}\right]^{\mathsf{T}} = \left[-\tfrac{3}{2},-\tfrac{1}{2},\tfrac{1}{2},\tfrac{3}{2}\right]^{\mathsf{T}},$$

$$\|\mathbf{v}_2\| = \sqrt{\frac{9}{4}+\frac{1}{4}+\frac{1}{4}+\frac{9}{4}} = \sqrt{5}, \qquad \mathbf{q}_2 = \frac{1}{\sqrt{5}}\left[-\tfrac{3}{2},-\tfrac{1}{2},\tfrac{1}{2},\tfrac{3}{2}\right]^{\mathsf{T}} = \left[-\tfrac{3}{2\sqrt{5}},-\tfrac{1}{2\sqrt{5}},\tfrac{1}{2\sqrt{5}},\tfrac{3}{2\sqrt{5}}\right]^{\mathsf{T}}.$$

验证 $\mathbf{q}_1^{\mathsf{T}}\mathbf{q}_2 = \frac{1}{2\sqrt{5}}\left(-\frac{3}{2}-\frac{1}{2}+\frac{1}{2}+\frac{3}{2}\right) = 0$ ✓，$\|\mathbf{q}_2\|^2 = \frac{1}{20}\left(\frac{9}{4}+\frac{1}{4}+\frac{1}{4}+\frac{9}{4}\right) = \frac{20/4}{20} = 1$ ✓。

步骤 2：Q, R 与 $Q^{\mathsf{T}}\mathbf{b}$。

$$Q = \begin{bmatrix} 1/2 & -3/(2\sqrt{5}) \\ 1/2 & -1/(2\sqrt{5}) \\ 1/2 & 1/(2\sqrt{5}) \\ 1/2 & 3/(2\sqrt{5}) \end{bmatrix}, \qquad R = \begin{bmatrix} 2 & 3 \\ 0 & \sqrt{5} \end{bmatrix}.$$

$$Q^{\mathsf{T}}\mathbf{b} = \begin{bmatrix} \frac{1+2+4+5}{2} \\ \frac{-3\cdot1-1\cdot2+1\cdot4+3\cdot5}{2\sqrt{5}} \end{bmatrix} = \begin{bmatrix} 6 \\ \frac{-3-2+4+15}{2\sqrt{5}} \end{bmatrix} = \begin{bmatrix} 6 \\ \frac{14}{2\sqrt{5}} \end{bmatrix} = \begin{bmatrix} 6 \\ 7/\sqrt{5} \end{bmatrix} \approx \begin{bmatrix} 6 \\ 3.1305 \end{bmatrix}.$$

验证 $QR = A$：第一列 $2\mathbf{q}_1 = [1,1,1,1]^{\mathsf{T}}$ ✓；第二列 $3\mathbf{q}_1 + \sqrt{5}\mathbf{q}_2 = \left[\tfrac{3}{2},\tfrac{3}{2},\tfrac{3}{2},\tfrac{3}{2}\right]^{\mathsf{T}} + \left[-\tfrac{3}{2},-\tfrac{1}{2},\tfrac{1}{2},\tfrac{3}{2}\right]^{\mathsf{T}} = [0,1,2,3]^{\mathsf{T}}$ ✓。

步骤 3：回代解 $R\hat{\mathbf{x}} = Q^{\mathsf{T}}\mathbf{b}$。

$$\sqrt{5}\,D = \frac{7}{\sqrt{5}} \implies D = \frac{7}{5} = 1.4,$$

$$2C + 3\cdot\frac{7}{5} = 6 \implies 2C = 6 - \frac{21}{5} = \frac{30-21}{5} = \frac{9}{5} \implies C = \frac{9}{10} = 0.9.$$

最优直线：$b = 0.9 + 1.4t$。（与直接解正规方程的结果一致，见 Lecture 16 的同类练习。）

步骤 4：拟合值、残差与 E。

$$\mathbf{p} = \begin{bmatrix} 0.9 \\ 0.9+1.4 \\ 0.9+2.8 \\ 0.9+4.2 \end{bmatrix} = \begin{bmatrix} 0.9 \\ 2.3 \\ 3.7 \\ 5.1 \end{bmatrix}, \qquad \mathbf{e} = \begin{bmatrix} 0.1 \\ -0.3 \\ 0.3 \\ -0.1 \end{bmatrix}, \qquad E = 0.01 + 0.09 + 0.09 + 0.01 = 0.2.$$

正交验证：残差和 $= 0.1 - 0.3 + 0.3 - 0.1 = 0$ ✓；加权和 $= 0\cdot0.1 + 1\cdot(-0.3) + 2\cdot0.3 + 3\cdot(-0.1) = -0.3 + 0.6 - 0.3 = 0$ ✓。相关系数平方 $R^2 = 1 - \frac{E}{\sum(b_i-\bar{b})^2} = 1 - \frac{0.2}{10} = 0.98$（$\bar{b} = 3$，$\sum(b_i-\bar{b})^2 = 4+1+1+4 = 10$）。

【计算机制解说】：这个例子的价值在于把"QR 版最小二乘"的完整流程走了一遍，并且刻意选了**带常数列**的设计矩阵。这时 R 的第一个对角元就是 $\|\mathbf{1}\| = \sqrt{m}$（$m$ 是数据点个数），而 Q 的第一列恰是"全 $\frac{1}{\sqrt{m}}$"——即**常数方向的单位向量**。几何上这意味着：Gram–Schmidt 自动先把数据"去均值"，再做斜率拟合。所以 $\hat{x}_1 = C$ 与 $\hat{x}_2 = D$ 在正交化后互相独立，回代时 D 先解出、C 后解出——顺序恰好与"先定趋势、后定水平"的直观一致。这也解释了为什么带常数列的直线拟合一贯如此稳定：常数列天然"带头"正交化，$A^{\mathsf{T}}A$ 虽不对称也不病态。

示例 7：$A^{-1} = R^{-1}Q^{\mathsf{T}}$——方阵时 QR 也能求逆

取 Lecture 15 用过的

$$A = \begin{bmatrix} 1 & 1 \\ 1 & 0 \\ 0 & 1 \end{bmatrix}$$ 不是方阵，换一个： $$A = \begin{bmatrix} 1 & 1 & 0 \\ 1 & 0 & 1 \\ 0 & 1 & 1 \end{bmatrix},$$

用示例 1 已算好的 Q 与 R：

$$Q=\begin{bmatrix}1/\sqrt{2} & 1/\sqrt{6} & -1/\sqrt{3}\\ 1/\sqrt{2} & -1/\sqrt{6} & 1/\sqrt{3}\\ 0 & 2/\sqrt{6} & 1/\sqrt{3}\end{bmatrix},\qquad R=\begin{bmatrix}\sqrt{2} & 1/\sqrt{2} & 1/\sqrt{2}\\ 0 & \sqrt{6}/2 & 1/\sqrt{6}\\ 0 & 0 & 2/\sqrt{3}\end{bmatrix}.$$

由 $A=QR$ 得 $A^{-1}=R^{-1}Q^{\mathsf T}$（$Q$ 正交，$Q^{-1}=Q^{\mathsf T}$）。

步骤 1：求 R^{-1}（上三角矩阵的逆也是上三角，用回代求三列）。 记 $R^{-1}=\begin{bmatrix}a & b & c\\ 0 & d & e\\ 0 & 0 & f\end{bmatrix}$。由 $RR^{-1}=I$ 逐列解得：– 第 3 列：$\frac{2}{\sqrt{3}}f=1\Rightarrow f=\frac{\sqrt{3}}{2}$；$\frac{\sqrt{6}}{2}e+\frac{1}{\sqrt{6}}\cdot\frac{\sqrt{3}}{2}=0\Rightarrow e=-\frac{\sqrt{3}/2}{\sqrt{6}/2}\cdot\frac{1}{\sqrt{6}}=-\frac{1}{2}$；……

（逐列回代的算式比较长，这里给出结果并由**乘法验证**把关：）

$$R^{-1}=\begin{bmatrix}1/\sqrt{2} & -1/\sqrt{6} & -\sqrt{3}/6\\ 0 & 2/\sqrt{6} & -\sqrt{3}/6\\ 0 & 0 & \sqrt{3}/2\end{bmatrix}.$$

验证 $RR^{-1}=I$，取最麻烦的 $(1,3)$ 元：

$$\sqrt{2}\left(-\frac{\sqrt{3}}{6}\right)+\frac{1}{\sqrt{2}}\left(-\frac{\sqrt{3}}{6}\right)+\frac{1}{\sqrt{2}}\cdot\frac{\sqrt{3}}{2}=-\frac{\sqrt{6}}{6}-\frac{\sqrt{6}}{12}+\frac{\sqrt{6}}{4}=\frac{-2-1+3}{12}\sqrt{6}=0.\ \checkmark$$

$(1,2)$ 元：$\sqrt{2}\left(-\frac{1}{\sqrt{6}}\right)+\frac{1}{\sqrt{2}}\cdot\frac{2}{\sqrt{6}}=-\frac{\sqrt{2}}{\sqrt{6}}+\frac{2}{\sqrt{12}}=-\frac{1}{\sqrt{3}}+\frac{1}{\sqrt{3}}=0\ \checkmark$。$(1,1)$ 元：$\sqrt{2}\cdot\frac{1}{\sqrt{2}}=1\ \checkmark$。$(2,2)$ 元：$\frac{\sqrt{6}}{2}\cdot\frac{2}{\sqrt{6}}=1\ \checkmark$，$(2,3)$：$\frac{\sqrt{6}}{2}\left(-\frac{\sqrt{3}}{6}\right)+\frac{1}{\sqrt{6}}\cdot\frac{\sqrt{3}}{2}=-\frac{\sqrt{18}}{12}+\frac{\sqrt{3}}{2\sqrt{6}}=-\frac{3\sqrt{2}}{12}+\frac{\sqrt{2}}{4}=0\ \checkmark$，$(3,3)$：$\frac{2}{\sqrt{3}}\cdot\frac{\sqrt{3}}{2}=1\ \checkmark$。

步骤 2：$A^{-1}=R^{-1}Q^{\mathsf T}$。

$$A^{-1}=\begin{bmatrix}1/\sqrt{2} & -1/\sqrt{6} & -\sqrt{3}/6\\ 0 & 2/\sqrt{6} & -\sqrt{3}/6\\ 0 & 0 & \sqrt{3}/2\end{bmatrix}\begin{bmatrix}1/\sqrt{2} & 1/\sqrt{2} & 0\\ 1/\sqrt{6} & -1/\sqrt{6} & 2/\sqrt{6}\\ -1/\sqrt{3} & 1/\sqrt{3} & 1/\sqrt{3}\end{bmatrix}.$$

$(1,1)$ 元：$\frac{1}{\sqrt{2}}\cdot\frac{1}{\sqrt{2}}+\left(-\frac{1}{\sqrt{6}}\right)\frac{1}{\sqrt{6}}+\left(-\frac{\sqrt{3}}{6}\right)\left(-\frac{1}{\sqrt{3}}\right)=\frac{1}{2}-\frac{1}{6}+\frac{1}{6}=\frac{1}{2}$。$(1,2)$：$\frac{1}{\sqrt{2}}\cdot\frac{1}{\sqrt{2}}+\left(-\frac{1}{\sqrt{6}}\right)\left(-\frac{1}{\sqrt{6}}\right)+\left(-\frac{\sqrt{3}}{6}\right)\frac{1}{\sqrt{3}}=\frac{1}{2}+\frac{1}{6}-\frac{1}{6}=\frac{1}{2}$。$(1,3)$：$0+\left(-\frac{1}{\sqrt{6}}\right)\frac{2}{\sqrt{6}}+\left(-\frac{\sqrt{3}}{6}\right)\frac{1}{\sqrt{3}}=-\frac{1}{3}-\frac{1}{6}=-\frac{1}{2}$。$(2,1)$：$0+\frac{2}{\sqrt{6}}\cdot\frac{1}{\sqrt{6}}+\left(-\frac{\sqrt{3}}{6}\right)\left(-\frac{1}{\sqrt{3}}\right)=\frac{1}{3}+\frac{1}{6}=\frac{1}{2}$。$(2,2)$：$0+\frac{2}{\sqrt{6}}\left(-\frac{1}{\sqrt{6}}\right)+\left(-\frac{\sqrt{3}}{6}\right)\frac{1}{\sqrt{3}}=-\frac{1}{3}-\frac{1}{6}=-\frac{1}{2}$。$(2,3)$：$0+\frac{2}{\sqrt{6}}\cdot\frac{2}{\sqrt{6}}+\left(-\frac{\sqrt{3}}{6}\right)\frac{1}{\sqrt{3}}=\frac{2}{3}-\frac{1}{6}=\frac{1}{2}$。$(3,1)$：$0+0+\frac{\sqrt{3}}{2}\left(-\frac{1}{\sqrt{3}}\right)=-\frac{1}{2}$；$(3,2)$：$\frac{\sqrt{3}}{2}\cdot\frac{1}{\sqrt{3}}=\frac{1}{2}$；$(3,3)$：$\frac{\sqrt{3}}{2}\cdot\frac{1}{\sqrt{3}}=\frac{1}{2}$。所以

$$A^{-1}=\frac{1}{2}\begin{bmatrix}1 & 1 & -1\\ 1 & -1 & 1\\ -1 & 1 & 1\end{bmatrix}.$$

验证：$A\cdot A^{-1}=\begin{bmatrix}1 & 1 & 0\\ 1 & 0 & 1\\ 0 & 1 & 1\end{bmatrix}\cdot\frac{1}{2}\begin{bmatrix}1 & 1 & -1\\ 1 & -1 & 1\\ -1 & 1 & 1\end{bmatrix}$：第一行：$\frac{1}{2}(1+1,1-1,-1+1)=\frac{1}{2}(2,0,0)=(1,0,0)\ \checkmark$；第二行：$\frac{1}{2}(1-1,1+1,-1+1)=\frac{1}{2}(0,2,0)=(0,1,0)\ \checkmark$；第三行：$\frac{1}{2}(-1+1,1+1,-1+1)=\frac{1}{2}(0,0,2)=(0,0,1)\ \checkmark$。并且 $\det A=\det Q\det R$。直接展开：$A=\begin{bmatrix}1 & 1 & 0\\ 1 & 0 & 1\\ 0 & 1 & 1\end{bmatrix}$，

$$\det A=1(0\cdot1-1\cdot1)-1(1\cdot1-1\cdot0)+0=1(-1)-1(1)+0=-2.$$

另一方面用 QR 数据核对：$\det Q=-1$（示例 1 步骤 8 算过），$\det R=\prod_i R_{ii}=\sqrt{2}\cdot\frac{\sqrt{6}}{2}\cdot\frac{2}{\sqrt{3}}$。逐步算：$\frac{\sqrt{6}}{2}\cdot\frac{2}{\sqrt{3}}=\frac{2\sqrt{6}}{2\sqrt{3}}=\sqrt{\frac{6}{3}}=\sqrt{2}$，再乘 $R_{11}=\sqrt{2}$ 得 $\det R=2$。于是

$$\det A=\det Q\det R=(-1)\cdot2=-2.\ \checkmark$$

（两条路径完全一致。**这类"两种独立算法交叉验证"应当成为习惯**：行列式可以展开，也可以通过 QR 的对角元乘积；两者吻合才说明 Q、R 都算对了。）

再核对 $\det A^{-1}$：$\det\left(\frac{1}{2}\begin{bmatrix}1 & 1 & -1\\ 1 & -1 & 1\\ -1 & 1 & 1\end{bmatrix}\right)=\frac{1}{8}\det\begin{bmatrix}1 & 1 & -1\\ 1 & -1 & 1\\ -1 & 1 & 1\end{bmatrix}$，而

$$\det\begin{bmatrix}1 & 1 & -1\\ 1 & -1 & 1\\ -1 & 1 & 1\end{bmatrix}=1(-1-1)-1(1+1)+(-1)(1-1)=-2-2+0=-4,$$

故 $\det A^{-1} = \frac{-4}{8} = -\frac{1}{2} = \frac{1}{\det A} = \frac{1}{-2}$。✓ 一致。

【计算机制解说】：$A^{-1} = R^{-1}Q^{\mathsf{T}}$ 是 QR 的又一个副产品，它的价值在于**数值稳定性**。直接求逆（或用伴随矩阵/代数余子式）的误差随条件数放大；而 Q^{T} 是正交阵（条件数 1），R^{-1} 通过三角回代得到（条件数与 A 相当），所以 $A^{-1} = R^{-1}Q^{\mathsf{T}}$ 的误差放大只有 $\kappa(A)$ 一次方。Lecture 20 会讲 Cramer 法则与代数余子式求逆——那是**理论**上漂亮的公式（$A^{-1} = \frac{1}{\det A}\mathrm{adj}(A)$），但**计算**上一无是处（$n!$ 级代价 + 灾难性误差）。对比之下，QR 路径是 $O(n^3)$ 且稳定。**"理论公式"与"计算算法"是两回事**，这门课的两条线（Lecture 20 vs Lecture 17）恰好说明了这一点。

另外注意 R^{-1} 的**上三角结构**：R 上三角 $\Rightarrow R^{-1}$ 上三角。且 R^{-1} 的对角元正是 $1/R_{ii}$（本例中 R 的对角元是 $\sqrt{2}, \frac{\sqrt{6}}{2}, \frac{2}{\sqrt{3}}$，故 R^{-1} 的对角元应为 $\frac{1}{\sqrt{2}}, \frac{2}{\sqrt{6}} = \sqrt{\frac{2}{3}}, \frac{\sqrt{3}}{2}$，与上面写出的 R^{-1} 一致 ✓）。于是

$$\det A^{-1} = \det R^{-1} \cdot \det Q^{\mathsf{T}} = \prod_i \frac{1}{R_{ii}} \cdot (\pm 1) = \frac{1}{\det A},$$

本例 $\prod \frac{1}{R_{ii}} = \frac{1}{\sqrt{2}} \cdot \frac{2}{\sqrt{6}} \cdot \frac{\sqrt{3}}{2} = \frac{2\sqrt{3}}{2\sqrt{12}} = \frac{1}{2}$，故 $|\det A^{-1}| = \frac{1}{2}$，与 $\frac{1}{|\det A|} = \frac{1}{2}$ 一致 ✓——这是"$|\det A| = \prod R_{ii}$"的另一条验证路径。

矩阵分解的核心思想

1. $A = QR$：本讲的主分解。 – **形式**：$A = QR$，Q 的列标准正交，R 上三角、对角元为正。 – **含义**：Q 是"整理过的列"，R 是"整理过程的记录"。R 第 j 列的非零部分 $(\mathbf{q}_1^{\mathsf{T}}\mathbf{a}_j, \ldots, \mathbf{q}_j^{\mathsf{T}}\mathbf{a}_j)$ 就是 $\mathbf{a}_j$ 在这组新坐标下的表示。 – **揭示的结构性质**：$\mathrm{span}\{\mathbf{q}_1, \ldots, \mathbf{q}_k\} = \mathrm{span}\{\mathbf{a}_1, \ldots, \mathbf{a}_k\}$（逐层保持）；$A^{\mathsf{T}}A = R^{\mathsf{T}}R$（$A^{\mathsf{T}}A$ 的 Cholesky 分解！因为 R 上三角、对角元为正）；$|\det A| = \prod R_{ii}$。 – **应用价值**：最小二乘（$R\hat{\mathbf{x}} = Q^{\mathsf{T}}\mathbf{b}$）、求逆、求特征值（QR 算法）、数值稳定的正交化。

2. $A^{\mathsf{T}}A = R^{\mathsf{T}}R$ 是 Cholesky 的入口。 由 $A = QR$ 得 $A^{\mathsf{T}}A = R^{\mathsf{T}}R$，其中 R^{T} 下三角、R 上三角、对角元为正——这正是 Lecture 27 讲的 Cholesky 分解 $S = R^{\mathsf{T}}R$（S 对称正定）。所以 Gram–Schmidt 也顺带给出了"如何对 $A^{\mathsf{T}}A$ 做 Cholesky"的一个算法（虽然实际软件会用更稳的算法）。

3. 与 $A = LU$ 的结构类比。 消元 $A = LU$ 把矩阵化成三角，靠的是**行操作**；QR 把列正交化，靠的是**列的方向**。两者都是"逐列/逐行剥洋葱"：LU 逐列消掉下方元素，QR 逐列剥掉前面方向的分量。区别在于 L 保留"消元倍数"（可能很大、不稳定），而 Q 保留"单位正交方向"（长度恒为 1、绝不放大误差）。这就是为什么长矩阵的最小二乘要用 QR 而不是 LU。

4. 与投影/最小二乘的三角关系。 Lecture 15 给出几何（正交条件），Lecture 16 给出公式（正规方程 + P），Lecture 17 给出**算法**（QR）。三讲合起来是：**几何 → 代数 → 数值**。经典的三步走。

5. 预告 SVD 与 QR 算法。 若给 A 做两次"正交化"（列方向与行方向同时做），就得到 Lecture 29 的 $A = U\Sigma V^{\mathsf{T}}$；若把 QR 反复迭代 $A_k = Q_kR_k$、$A_{k+1} = R_kQ_k$（注意顺序交换），则 A_k 会收敛到上三角（或对角），对角元就是特征值——这就是 **QR 算法**，20 世纪最重要的数值算法之一。

与其他讲次的关联

- **Lecture 14（正交向量与子空间）**：标准正交的定义（$\mathbf{q}_i^{\mathsf{T}}\mathbf{q}_j = \delta_{ij}$）在这里被系统使用；$\mathbf{q}$ 之间两两正交让所有内积计算变成 δ 的筛选。
- **Lecture 15（投影到子空间）**：本讲的 $P = QQ^{\mathsf{T}}$ 是 $P = A(A^{\mathsf{T}}A)^{-1}A^{\mathsf{T}}$ 在正交列下的特例；示例 3 明确展示了二者给出同一矩阵。
- **Lecture 16（最小二乘）**：本讲示例 2 用 QR 重现了那里的全部数值（$\hat{\mathbf{x}} = [-2/3, 3/2]^{\mathsf{T}}$、$P$、$\mathbf{e}$、$E = 1/6$），但全程无求逆。
- **Lecture 20（Cramer 法则、逆矩阵）**：QR 也提供求逆路径（$A^{-1} = R^{-1}Q^{\mathsf{T}}$），与代数余子式路径形成对照。
- **Lecture 25（对称矩阵正交对角化）**：$A = Q\Lambda Q^{\mathsf{T}}$ 是"特征向量正交"版本的分解，与 $A = QR$ 共享 Q 的技术但目标不同（那里 Q 由特征向量组成，这里由 Gram–Schmidt 造出）。
- **Lecture 27（正定矩阵）**：$A^{\mathsf{T}}A = R^{\mathsf{T}}R$ 就是 Cholesky；正定性的检验与 $R_{ii} > 0$ 互为表里。
- **Lecture 29（SVD）**：$A = U\Sigma V^{\mathsf{T}}$ 把 A 的列空间与行空间同时正交化，是 QR 的"双侧版"。
- **Lecture 33（伪逆）**：列相关时 R 会出现零对角元，此时用带列主元的 QR（column pivoting）或 SVD 来判断有效秩并构造 A^{+}。

关键要点

1. **正交矩阵的定义是 $Q^{\mathsf{T}}Q = I$**（列标准正交），三条推论：$Q^{-1} = Q^{\mathsf{T}}$、$\|Q\mathbf{x}\| = \|\mathbf{x}\|$、$|\det Q| = 1$；方阵时 $QQ^{\mathsf{T}} = I$ 同时成立。
2. **正交基让投影公式"去求逆"**：$\hat{\mathbf{x}} = Q^{\mathsf{T}}\mathbf{b}$（分量独立 $\hat{x}_i = \mathbf{q}_i^{\mathsf{T}}\mathbf{b}$），$P = QQ^{\mathsf{T}}$。
3. **Gram–Schmidt 三步循环**：取 $\mathbf{a}_k$，减去它在所有已有 $\mathbf{q}_j$ 上的投影，再除以长度。$\mathbf{v}_k \neq \mathbf{0}$ 等价于 $\mathbf{a}_k$ 与前面向量线性无关。
4. **$A = QR$ 中**：$R_{ij} = \mathbf{q}_i^{\mathsf{T}}\mathbf{a}_j$（$i \le j$），$R_{jj} = \|\mathbf{v}_j\| > 0$，$R$ 上三角；R 第 j 列的非零元就是 $\mathbf{a}_j$ 在 $\{\mathbf{q}_1, \ldots, \mathbf{q}_j\}$ 下的坐标。
5. **最小二乘的 QR 路径**：$R\hat{\mathbf{x}} = Q^{\mathsf{T}}\mathbf{b}$，无需 $(A^{\mathsf{T}}A)^{-1}$；同时 $A^{\mathsf{T}}A = R^{\mathsf{T}}R$ 是 Cholesky，$|\det A| = \prod R_{ii}$。

常见误区与注意事项

1. **误以为"正交矩阵"只要列两两正交**。必须同时**单位化**。$\begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}$ 的列正交但长度为 $\sqrt{2}$，它不是正交矩阵（$Q^{\mathsf{T}}Q = 2I \neq I$）；必须写成 $\frac{1}{\sqrt{2}}\begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}$。用未归一化的列做投影时，$\hat{x}_i = \mathbf{q}_i^{\mathsf{T}}\mathbf{b}$ 会算错（要除以 $\|\mathbf{q}_i\|^2$）。

2. **在 Gram–Schmidt 中忘记"减掉所有已有方向"**。做 $\mathbf{a}_3$ 时只减 $\mathbf{q}_1$ 上的投影不够——必须同时减去 $\mathbf{q}_1$ 与 $\mathbf{q}_2$ 上的投影。示例 1 中若只减 $\mathbf{q}_1$，得到的向量是 $[-\tfrac12,\tfrac12,1]^{\mathsf T}$，它与 $\mathbf{q}_2$ 的内积是 $\tfrac{1}{\sqrt6}(-\tfrac12-\tfrac12+2)=\tfrac{1}{\sqrt6}\neq 0$——不正交。
3. **把 R 写成下三角或搞错 Q,R 的尺寸**。A 是 $m\times n$ 时，瘦 QR 版本 Q 是 $m\times n$、R 是 $n\times n$ 上三角；若用"完整"版本则 Q 是 $m\times m$、R 是 $m\times n$（下方补零）。无论哪种，R 的**非零部分都在上三角**，且 $R_{jj}>0$（若允许负号，QR 不唯一）。
4. **混淆 QR 分解与 QR 算法**。$A=QR$ 是**分解**（一次性把矩阵拆开）；QR 算法是**迭代**（反复做 $A_k=Q_kR_k$、$A_{k+1}=R_kQ_k$ 来求特征值）。两者都用到 QR，但目标完全不同：前者做最小二乘，后者算特征值。
5. **以为 `modified Gram-Schmidt` 只是"写法不同的同一个算法"**。经典 Gram–Schmidt（CGS）在每个 $\mathbf{v}_k$ 上一次性减去所有投影；modified Gram–Schmidt（MGS）则**每算出一个新的 $\mathbf{q}_j$ 就立刻用它修正后面所有还活着的向量**。数学上两者产生相同结果，但 MGS 的舍入误差小得多——尤其当向量接近线性相关时（例如 $\mathbf{a}_2=\mathbf{a}_1+\varepsilon\mathbf{z}$，$\varepsilon$ 很小）。CGS 会出现"正交性雪崩"（$\mathbf{q}_i^{\mathsf T}\mathbf{q}_j$ 远大于机器精度），MGS 则几乎保持正交到机器精度。这就是为什么教材上写 CGS、代码里用 MGS（或用 Householder 变换，稳定性更好）。
6. **忘记 $|\det A|=\prod R_{ii}$ 只给绝对值**。符号藏在 $\det Q=\pm1$ 里。示例 1 中 $\prod R_{ii}=2$ 而 $\det A=-2$，正是因为 Q 的行列式为 -1（反射型正交矩阵）。

思考题（带答案）

Q1.（概念题）判断真假并说明理由：

(a) 若 Q 是正交矩阵，则 Q^2、Q^{-1}、$Q^{\mathsf T}$、$Q+Q$ 都是正交矩阵。(b) 若 Q 的列标准正交，则 Q 一定可逆，且 $Q^{\mathsf T}$ 的行也标准正交。(c) 若 $A=QR$ 且 Q 是方阵正交矩阵，则 $A^{\mathsf T}A=R^{\mathsf T}R$ 是正定的。(d) 把 $\mathbf{b}$ 投影到 $\mathbf{span}\{\mathbf{q}_1,\dots,\mathbf{q}_k\}$（$\mathbf{q}_i$ 标准正交）时，$\mathbf{p}=\sum_i(\mathbf{q}_i^{\mathsf T}\mathbf{b})\mathbf{q}_i$。

> ▸ 答案
>
> (a) **部分真**。Q^2：$(Q^2)^{\mathsf T}(Q^2)=Q^{\mathsf T}Q^{\mathsf T}QQ=Q^{\mathsf T}Q^{\mathsf T}QQ$——注意 $Q^{\mathsf T}Q=I$ 不能直接挪位置，正确做法是 $(Q^2)^{\mathsf T}Q^2=(Q^{\mathsf T}Q^{\mathsf T})(QQ)$，一般**不能**化简为 I。更简洁的论证：正交矩阵的乘积正交（$(Q_1Q_2)^{\mathsf T}(Q_1Q_2)=Q_2^{\mathsf T}\underbrace{Q_1^{\mathsf T}Q_1}_{I}Q_2=Q_2^{\mathsf T}Q_2=I$），取 $Q_1=Q_2=Q$ 得 Q^2 正交。**真**。$Q^{-1}=Q^{\mathsf T}$ 正交（正交矩阵的转置也正交，因为 $(Q^{\mathsf T})^{\mathsf T}(Q^{\mathsf T})=QQ^{\mathsf T}=I$）。**真**。$Q^{\mathsf T}$ 正交，**真**。$2Q$ 的列长度是 2 不是 1，$(2Q)^{\mathsf T}(2Q)=4I\neq I$，**假**（要 $\tfrac{1}{\sqrt2}$ 归一化）。（更一般地：正交矩阵对**乘法**封闭，对加法不封闭。）
>
> (b) **真**。$Q^{\mathsf T}Q=I$ 说明 Q 的列无关（若有 $Q\mathbf{x}=\mathbf{0}$ 则 $\mathbf{x}=Q^{\mathsf T}Q\mathbf{x}=\mathbf{0}$），故 Q 可逆，且左逆即右逆，$QQ^{\mathsf T}=I$。这个等式逐行读就是"$Q^{\mathsf T}$ 的行标准正交"，而 $Q^{\mathsf T}$ 的行正是 Q 的列——所以这句话有两层：Q 的行也标准正交。✓
>
> (c) **真**。Q 方阵正交时 $R=Q^{\mathsf T}A$ 是 $n\times n$ 上三角，$A^{\mathsf T}A=R^{\mathsf T}R$。对任意 $\mathbf{x}\neq\mathbf{0}$，$\mathbf{x}^{\mathsf T}R^{\mathsf T}R\mathbf{x}=\|R\mathbf{x}\|^2>0$——因为 R 可逆（A 可逆，$R=Q^{\mathsf T}A$ 也可逆，等价于所有 $R_{jj}\neq0$）。故正定。（若 A 是长矩阵、R 奇异，则只是半正定。）
>
> (d) **真**。这就是正交基下投影的"分量求和"形式。验证：$\mathbf{e}=\mathbf{b}-\mathbf{p}$，则对每个 j，
>
> $$\mathbf{q}_j^{\mathsf T}\mathbf{e}=\mathbf{q}_j^{\mathsf T}\mathbf{b}-\sum_i(\mathbf{q}_i^{\mathsf T}\mathbf{b})\underbrace{\mathbf{q}_j^{\mathsf T}\mathbf{q}_i}_{=\delta_{ij}}=\mathbf{q}_j^{\mathsf T}\mathbf{b}-\mathbf{q}_j^{\mathsf T}\mathbf{b}=0.$$
>
> 故 $\mathbf{e}$ 垂直于整个子空间，$\mathbf{p}$ 是最优投影。这与 $P=QQ^{\mathsf T}$ 是同一件事（$\mathbf{p}=QQ^{\mathsf T}\mathbf{b}=\sum_i\mathbf{q}_i(\mathbf{q}_i^{\mathsf T}\mathbf{b})$）。

Q2.（计算题）对 $\mathbf{a}_1=\begin{bmatrix}1\\1\\1\end{bmatrix}$，$\mathbf{a}_2=\begin{bmatrix}1\\0\\2\end{bmatrix}$，$\mathbf{a}_3=\begin{bmatrix}1\\1\\0\end{bmatrix}$ 做 Gram–Schmidt，求 Q 与 R，并验证 $QR=A$、$Q^{\mathsf T}Q=I$。

> ▸ 答案
>
> $\mathbf{a}_1=[1,1,1]^{\mathsf T}$，$\|\mathbf{a}_1\|=\sqrt3$，$\mathbf{q}_1=\tfrac{1}{\sqrt3}[1,1,1]^{\mathsf T}$。
>
> $\mathbf{q}_1^{\mathsf T}\mathbf{a}_2=\tfrac{1+0+2}{\sqrt3}=\sqrt3$，投影项 $=\sqrt3\cdot\tfrac{1}{\sqrt3}[1,1,1]^{\mathsf T}=[1,1,1]^{\mathsf T}$，
>
> $$\mathbf{v}_2=[1,0,2]^{\mathsf T}-[1,1,1]^{\mathsf T}=[0,-1,1]^{\mathsf T},\qquad\|\mathbf{v}_2\|=\sqrt2,\qquad\mathbf{q}_2=\frac{1}{\sqrt2}[0,-1,1]^{\mathsf T}.$$
>
> $\mathbf{q}_1^{\mathsf T}\mathbf{a}_3=\tfrac{1+1+0}{\sqrt3}=\tfrac{2}{\sqrt3}$，$\mathbf{q}_2^{\mathsf T}\mathbf{a}_3=\tfrac{0-1+0}{\sqrt2}=-\tfrac{1}{\sqrt2}$。
>
> $$\mathbf{v}_3=[1,1,0]^{\mathsf T}-\frac{2}{\sqrt3}\cdot\frac{1}{\sqrt3}[1,1,1]^{\mathsf T}+\frac{1}{\sqrt2}\cdot\frac{1}{\sqrt2}[0,-1,1]^{\mathsf T}$$
>
> $$=[1,1,0]^{\mathsf T}-\left[\tfrac23,\tfrac23,\tfrac23\right]^{\mathsf T}+\left[0,-\tfrac12,\tfrac12\right]^{\mathsf T}>=\left[\tfrac13,\tfrac{6-4-3}{6},\tfrac36\right]^{\mathsf T}=\left[\tfrac13,-\tfrac16,-\tfrac16\right]^{\mathsf T}.$$

$\|\mathbf{v}_3\| = \sqrt{\frac{1}{9}+\frac{1}{36}+\frac{1}{36}} = \sqrt{\frac{6}{36}} = \frac{1}{\sqrt{6}}$，

$$\mathbf{q}_3 = \sqrt{6}\left[\tfrac{1}{3}, -\tfrac{1}{6}, -\tfrac{1}{6}\right]^{\mathsf{T}} = \left[\tfrac{\sqrt{6}}{3}, -\tfrac{\sqrt{6}}{6}, -\tfrac{\sqrt{6}}{6}\right]^{\mathsf{T}} = \frac{1}{\sqrt{6}}[2,-1,-1]^{\mathsf{T}}.$$

于是

$$Q = \begin{bmatrix} 1/\sqrt{3} & 0 & 2/\sqrt{6} \\ 1/\sqrt{3} & -1/\sqrt{2} & -1/\sqrt{6} \\ 1/\sqrt{3} & 1/\sqrt{2} & -1/\sqrt{6} \end{bmatrix}, \quad > R = \begin{bmatrix} \sqrt{3} & \sqrt{3} & 2/\sqrt{3} \\ 0 & \sqrt{2} & -1/\sqrt{2} \\ 0 & 0 & 1/\sqrt{6} \end{bmatrix}.$$

（注意 $R_{13} = \mathbf{q}_1^{\mathsf{T}}\mathbf{a}_3 = \frac{2}{\sqrt{3}}$，$R_{23} = \mathbf{q}_2^{\mathsf{T}}\mathbf{a}_3 = -\frac{1}{\sqrt{2}}$。）
验证 $QR = A$ 第三列（最复杂的一列）：

$$\frac{2}{\sqrt{3}}\mathbf{q}_1 - \frac{1}{\sqrt{2}}\mathbf{q}_2 + \frac{1}{\sqrt{6}}\mathbf{q}_3 >= \frac{2}{3}\begin{bmatrix}1\\1\\1\end{bmatrix} - \frac{1}{2}\begin{bmatrix}0\\-1\\1\end{bmatrix} + \frac{1}{6}\begin{bmatrix}2\\-1\\-1\end{bmatrix} >= \begin{bmatrix}\frac{2}{3}+0+\frac{1}{3}\\ \frac{2}{3}+\frac{1}{2}-\frac{1}{6}\\ \frac{2}{3}-\frac{1}{2}-\frac{1}{6}\end{bmatrix} >= \begin{bmatrix}1\\1\\0\end{bmatrix}. \checkmark$$

第一、二列：$\sqrt{3}\,\mathbf{q}_1 = [1,1,1]^{\mathsf{T}}$ ✓；$\sqrt{3}\,\mathbf{q}_1 + \sqrt{2}\,\mathbf{q}_2 = [1,1,1]^{\mathsf{T}} + [0,-1,1]^{\mathsf{T}} = [1,0,2]^{\mathsf{T}}$ ✓。
验证 $Q^{\mathsf{T}}Q = I$：$\mathbf{q}_1^{\mathsf{T}}\mathbf{q}_2 = \frac{0-1+1}{\sqrt{6}} = 0$，$\mathbf{q}_1^{\mathsf{T}}\mathbf{q}_3 = \frac{2-1-1}{\sqrt{18}} = 0$，$\mathbf{q}_2^{\mathsf{T}}\mathbf{q}_3 = \frac{0+1-1}{\sqrt{12}} = 0$；$\|\mathbf{q}_1\|^2 = \frac{1}{3}\cdot 3 = 1$，$\|\mathbf{q}_2\|^2 = \frac{1}{2}\cdot 2 = 1$，$\|\mathbf{q}_3\|^2 = \frac{1}{6}\cdot 6 = 1$。✓
顺带：$|\det A| = |\det Q| \prod R_{ii} = 1 \cdot \sqrt{3}\cdot\sqrt{2}\cdot\frac{1}{\sqrt{6}} = 1$。直接算 A：$\det\begin{bmatrix}1&1&1\\1&0&1\\1&2&0\end{bmatrix} = -2 \neq -1$……**这里要注意 A 的列顺序**：本答案中 A 的列是 $[\mathbf{a}_1, \mathbf{a}_2, \mathbf{a}_3]$，即 $A = \begin{bmatrix}1&1&1\\1&0&1\\1&2&0\end{bmatrix}$，$\det A = 1(0-2) - 1(0-1) + 1(2-0) = -2+1+2 = 1$。✓（符号也为正，因 $\det Q = +1$。）

Q3.（计算题 + 概念）设 Q 由 $\mathbf{q}_1 = \frac{1}{3}\begin{bmatrix}2\\2\\1\end{bmatrix}$、$\mathbf{q}_2 = \frac{1}{3}\begin{bmatrix}2\\-1\\-2\end{bmatrix}$ 给出（已标准正交）。求投影矩阵 $P = QQ^{\mathsf{T}}$，并求 $\mathbf{b} = \begin{bmatrix}1\\0\\0\end{bmatrix}$ 到 $\mathbf{span}\{\mathbf{q}_1, \mathbf{q}_2\}$ 的投影 $\mathbf{p}$、误差 $\mathbf{e}$。为什么 $\mathbf{e}$ 必与 $\mathbf{q}_1 \times \mathbf{q}_2$ 平行?

▸ **答案**

$$QQ^{\mathsf{T}} = \frac{1}{9}\begin{bmatrix}2&2\\2&-1\\1&-2\end{bmatrix}\begin{bmatrix}2&2&1\\2&-1&-2\end{bmatrix} >= \frac{1}{9}\begin{bmatrix}4+4&4-2&2-4\\4-2&4+1&2+2\\2-4&2+2&1+4\end{bmatrix} >= \frac{1}{9}\begin{bmatrix}8&2&-2\\2&5&4\\-2&4&5\end{bmatrix}.$$

$\mathrm{trace}(P) = \frac{8+5+5}{9} = 2$，$\mathrm{rank}(P) = 2$。✓
$\mathbf{q}_1^{\mathsf{T}}\mathbf{b} = \frac{2}{3}$，$\mathbf{q}_2^{\mathsf{T}}\mathbf{b} = \frac{2}{3}$，故

$$\mathbf{p} = \frac{2}{3}\mathbf{q}_1 + \frac{2}{3}\mathbf{q}_2 = \frac{2}{3}\cdot\frac{1}{3}\begin{bmatrix}2\\2\\1\end{bmatrix} + \frac{2}{3}\cdot\frac{1}{3}\begin{bmatrix}2\\-1\\-2\end{bmatrix} >= \frac{2}{9}\begin{bmatrix}4\\1\\-1\end{bmatrix} = \begin{bmatrix}8/9\\2/9\\-2/9\end{bmatrix},$$

$$\mathbf{e} = \mathbf{b} - \mathbf{p} = \begin{bmatrix}1-8/9\\-2/9\\2/9\end{bmatrix} = \begin{bmatrix}1/9\\-2/9\\2/9\end{bmatrix} = \frac{1}{9}\begin{bmatrix}1\\-2\\2\end{bmatrix}.$$

验证 $\mathbf{q}_1^{\mathsf{T}}\mathbf{e}=\frac{2-4+2}{27}=0$，$\mathbf{q}_2^{\mathsf{T}}\mathbf{e}=\frac{2+2-4}{27}=0$。✓ $\|\mathbf{e}\|=\frac{1}{9}\sqrt{1+4+4}=\frac{1}{3}$。

为什么 $\mathbf{e}\parallel\mathbf{q}_1\times\mathbf{q}_2$？ 因为 $\mathbf{span}\{\mathbf{q}_1,\mathbf{q}_2\}$ 是 $\mathbb{R}^3$ 中的一张平面，它的正交补是**一维**的，由法向量 $\mathbf{q}_1\times\mathbf{q}_2$ 张成。$\mathbf{e}$ 垂直于该平面，而一维子空间里只有一个方向，所以 $\mathbf{e}$ 必与 $\mathbf{q}_1\times\mathbf{q}_2$ 平行。具体算：$\mathbf{q}_1\times\mathbf{q}_2=\frac{1}{9}\begin{bmatrix}2\\2\\1\end{bmatrix}\times\begin{bmatrix}2\\-1\\-2\end{bmatrix}=\frac{1}{9}\begin{bmatrix}2(-2)-1(-1)\\1\cdot2-2(-2)\\2(-1)-2\cdot2\end{bmatrix}=\frac{1}{9}\begin{bmatrix}-3\\6\\-6\end{bmatrix}=-\frac{1}{3}\begin{bmatrix}1\\-2\\2\end{bmatrix}$

——恰是 $\mathbf{e}$ 的 -3 倍。✓

几何意义：这说明"正交补是一维"时，误差向量没有选择余地，只能落在法线方向上；这也解释了为什么 3×2 的最小二乘问题的残差总是"可以用一个法向量表示"。

Q4.（概念题）为什么实际数值软件更愿意用 Householder 变换或 modified Gram–Schmidt，而不是教科书上的经典 Gram–Schmidt？请结合"$A^{\mathsf{T}}A$ 的条件数是 A 条件数的平方"说明。

▸ **答案**

经典 Gram–Schmidt（CGS）在计算 $\mathbf{q}_k$ 时，用**已经算好的** $\mathbf{q}_j$ 去减投影。若前面某个 $\mathbf{q}_j$ 已经带有舍入误差，这个误差会被"继承"到后面所有的向量里，并且每一轮都可能被放大；当原向量接近线性相关（即 A 的条件数很大）时，最终算出的 $\mathbf{q}_i$ 之间可能只有 10^{-8} 量级的正交性，而不是机器精度 10^{-16}。这种"正交性丢失"就是 CGS 的经典缺陷。

两条改良路线： 1. **modified Gram–Schmidt（MGS）**：改变循环顺序——每算出一个新 $\mathbf{q}_j$，**立刻**用它去修正所有尚未单位化的后续向量 $\mathbf{v}_k\leftarrow\mathbf{v}_k-(\mathbf{q}_j^{\mathsf{T}}\mathbf{v}_k)\mathbf{q}_j$。数学上与 CGS 等价（都是减去到已定方向的投影），但误差**不再累积**：每一步都用最新、最正交的向量去修正，正交性可以维持到接近机器精度。代价只是多一层循环。 2. **Householder 变换**：完全不显式做投影减法，而是用车用一系列**反射矩阵** $H=I-2\mathbf{u}\mathbf{u}^{\mathsf{T}}/\mathbf{u}^{\mathsf{T}}\mathbf{u}$（正交、对称、$H^2=I$）把 A 逐列"打"成上三角。由于每一步都是正交变换（保长、不放大误差），稳定性最好，是现代 LAPACK 的标准做法。$A=QR$ 中的 Q 事后由这些 H 的乘积（或直接作用在 $\mathbf{b}$ 上、不显式形成）得到。

与条件数的关系：直接解正规方程相当于对 $A^{\mathsf{T}}A$ 操作，其条件数 $\kappa(A^{\mathsf{T}}A)=\kappa(A)^2$。若 $\kappa(A)=10^8$，则 $\kappa(A^{\mathsf{T}}A)=10^{16}$，在双精度（约 16 位有效数字）下解出的 $\hat{\mathbf{x}}$ 可能**一位有效数字都不剩**。而 QR 路径只涉及正交变换（条件数不变，恒为 1）与三角回代（条件数 $\kappa(R)=\kappa(A)$），因此误差只放大 $\kappa(A)$ 倍而非 $\kappa(A)^2$ 倍。这就是"**永远不要显式构造** $A^{\mathsf{T}}A$"这条数值线性代数箴言的由来。

注：Gram–Schmidt 也并非没有优势——它给出 R 的**逐列**信息（$R_{ij}=\mathbf{q}_i^{\mathsf{T}}\mathbf{a}_j$），对"逐步加入新数据"的在线算法（如递归最小二乘）非常自然；Householder 更适合一次性处理整个矩阵。

Lecture 18: Properties of Determinants

概述

本讲的核心问题是：**行列式到底是什么，为什么它值得用一个数来概括整个矩阵？** Strang 的讲法非常特别——他不先给你一个 3×3 的展开公式，而是**用三条性质来定义行列式**。这三条性质（$\det I=1$、交换两行变号、对第一行线性）像"公理"一样，把行列式唯一地钉死；其余所有性质都是它们的推论。

这种"从性质出发"的路线有一个巨大的好处：它立刻解释了**为什么消元法能求行列式**——因为"一行加到另一行，行列式不变"。于是上三角矩阵的行列式就等于对角元（主元）之积，n^3 次运算就够了，完全不需要展开 $n!$ 项。

本讲位于课程后半段的起点：前十七讲建立了四个基本子空间、正交与投影；现在我们把矩阵"压缩成一个数"，这个数接下来会成为特征值的守门人（讲次 21 的 $\det(A-\lambda I)=0$）、体积的度量（讲次 20），以及 SVD 中奇异值乘积的影子（讲次 29）。

核心概念的几何直觉

行列式（determinant）——一个数读出整个矩阵的全部结构

- **定义与目的**：矩阵 A 的行列式是一个标量 $\det A$（也写作 $|A|$）。它一次性编码了三件事：**可逆性**（$\det A=0\iff$ 奇异）、**体积缩放比**（$|\det A|$ 是把单位立方体映射成的平行六面体的体积）、**定向**（符号正负 = 保持还是翻转左右手系）。它的存在意义是：给"矩阵是否可逆"这个问题一个**连续**的、可以求导、可以进公式的判据。
- **几何直觉（它在空间中是什么样子？）**：把 A 看成从输入空间到输出空间的线性变换。单位正方形（2D）或单位立方体（3D）被 A 映射成一个平行四边形或平行六面体。$\det A$ 就是这个新图形的**有向**体积。矩阵把空间"拉长"多少倍，行列式就告诉你多少倍。
- **具体示例**：$A=\begin{bmatrix}3&0\\0&2\end{bmatrix}$。单位正方形四个顶点 $(0,0),(1,0),(1,1),(0,1)$ 被映射到 $(0,0),(3,0),(3,2),(0,2)$——一个 3×2 的矩形。面积从 1 变成 6，而 $\det A=3\cdot2-0\cdot0=6$。**面积放大倍数 $=\det A$**。

三条公理（axioms）——用"行为规范"定义行列式

- **定义与目的**：Strang 不从公式出发，而是列出三条行为要求。任何满足这三条的"函数" $\det$ 都是唯一的，这保证了行列式**没有歧义**。
- **公理 1**：$\det I=1$。（单位矩阵什么都不做，体积不变，符号为正。）

- **公理 2**：交换两行，行列式**变号**：$\det(\text{swapped}) = -\det A$。（交换会翻转定向，左右手系互换。）
- **公理 3**：行列式对**每一行分别是线性的**。写成第一行：

$$\det\begin{bmatrix} ta_1 & ta_2 & ta_3 \\ \cdots & & \end{bmatrix} = t\det\begin{bmatrix} a_1 & a_2 & a_3 \\ \cdots & & \end{bmatrix},$$

$$\det\begin{bmatrix} a_1+c_1 & a_2+c_2 & a_3+c_3 \\ \cdots & & \end{bmatrix} = \det\begin{bmatrix} a_1 & a_2 & a_3 \\ \cdots & & \end{bmatrix} + \det\begin{bmatrix} c_1 & c_2 & c_3 \\ \cdots & & \end{bmatrix}.$$

> 注意：**只有"按行"成比例才是线性的**，把整个矩阵乘 t 不是乘以 t（那是 n 个行各乘 t，见性质 9'）。

- **几何直觉**：公理 1 说"标准的盒子体积是 1"。公理 2 说"交换两个坐标轴，右手系变左手系"。公理 3 说"固定其他行，体积是这一行的线性函数"——底（另外两行张成的面积）固定时，体积正比于这一行的高度；两条边**方向相同的向量相加**，围出的两块拼起来正好是第三块。
- **具体示例**：用公理 3 验证 $\mathbf{2\times 2}$。

$$\det\begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix} \overset{?}{=} 1\cdot 4 - 2\cdot 3 = -2.$$

先用公理 3 把第一行拆开：$[1 \quad 2] = [1 \quad 0] + [0 \quad 2]$，所以

$$\det\begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix} = \det\begin{bmatrix} 1 & 0 \\ 3 & 4 \end{bmatrix} + \det\begin{bmatrix} 0 & 2 \\ 3 & 4 \end{bmatrix}.$$

右边第一项：用"一行加到另一行不变"（性质 4）把第一行减掉 $\frac{1}{3}$ 倍第二行，得 $\begin{bmatrix} 0 & -4/3 \\ 3 & 4 \end{bmatrix}$……这条路稍绕；更干净的做法是用性质 4 先消元，见下文手算演示。**要点是：2×2 的公式 $-cb$ 与 ad 的顺序，全部来自这三条公理。**

三条公理为什么"足够"——唯一性与"从 A 走到 I"

- **定义与目的**：公理只是"行为规范"，要证明它们真的确定了一个函数，需要给出**构造性论证**：任何满足三条公理的 $\det$ 都能被算出来，且算法唯一。
- **几何直觉**：把 A 用行变换搬到 I，一路记账。因为每一步的效果（$\times t$、变号、不变）都由公理规定死了，所以出发值 $\det A$ 被反推出来，没有第二种可能。
- **具体示例 / 论证**：任取 A，用消元把它化成行阶梯形。分三种情形：
- **情形 A：消元中出现零行。** 则 A 奇异，$\det A = 0$——由性质 5–8 强制。
- **情形 B：消元完成，得到上三角 U，主元 $d_1,\dots,d_n$ 全非零。** 每一步"行相减"不变号，若发生 k 次行交换则每次变号。于是

$$\det A = (-1)^k \det U = (-1)^k d_1 d_2 \cdots d_n.$$

> **没有选择的余地**：$(-1)^k$ 和 d_i 都由 A 唯一决定。

- **补充**：也可反过来把 U 归约到 I：用行相减消掉上三角的非对角元（不变号），再用"行乘 $1/d_i$"把对角元变成 1（每一步把 $\det$ 除以 d_i），得到

$$\det A = (-1)^k \cdot d_1 d_2 \cdots d_n \cdot \det I = (-1)^k d_1 d_2 \cdots d_n.$$

> 两条路同一个答案。

这就是"三条公理 $\Rightarrow$ 唯一性"的证明：任何一个满足公理的函数，在任意 A 上的取值都被上面的消元账本锁死。于是我们可以放心地说：**行列式就是"把 A 搬到 I 的总缩放因子（带符号）"。** 由此立刻得到本讲的主算法：$\det A = (-1)^k \prod_i d_i$。

"一行加到另一行，行列式不变"——整讲的枢纽

- **定义与目的**：这是 Strang 反复强调的**第四号关键性质**（公理 3 的直接推论）：

$$\det\begin{bmatrix} \mathbf{row}_1 + t\cdot\mathbf{row}_2 \\ \mathbf{row}_2 \\ \cdots \end{bmatrix} = \det\begin{bmatrix} \mathbf{row}_1 \\ \mathbf{row}_2 \\ \cdots \end{bmatrix} + t\det\begin{bmatrix} \mathbf{row}_2 \\ \mathbf{row}_2 \\ \cdots \end{bmatrix} = \det A + t\cdot 0 = \det A.$$

第二步的关键是"**两行相同时行列式为 0**"（性质 2）。这就是**高斯消元（Gaussian elimination）可以求行列式**的全部依据。 – **几何直觉**：把向量 $\mathbf{b}$ 沿着向量 $\mathbf{a}$ 的方向滑动（$\mathbf{b} \to \mathbf{b} + t\mathbf{a}$），**底不变、高不变**，所以平行四边形面积不变。这是"剪切"（shear）：把矩形推成斜的平行四边形，面积守恒。 – **具体示例**：$\det\begin{bmatrix} 2 & 3 \\ 1 & 1 \end{bmatrix} = 2-3 = -1$，而 $\det\begin{bmatrix} 2 & 3 \\ 1+2 & 1+3 \end{bmatrix} = \det\begin{bmatrix} 2 & 3 \\ 3 & 4 \end{bmatrix} = 8-9 = -1$。**确实不变。**

```
行变换的几何：剪切不改变面积

y                                y
|        /  (b1,b2)              |            / b + t a
|       /                        |           /
|      /                         |          /
|     /                          |         /
|    /                           |        /
|   /                            |       /
+---------------- x              +---------------- x
     a = (1,0) 固定                     a = (1,0) 固定

面积 = 底 x 高 = |a| * h          面积 = 底 x 高 = |a| * h    （高没变！）
```

行列式的十条性质（从三条公理推出的完整清单）

- **定义与目的**：下面每一条都是三条公理的推论。**不要背公式，要背"它是怎么来的"**——每条的证明通常只有一两行。
- **几何直觉**：整张清单其实只讲了三件事：**(i)** 什么操作不改变体积（行相加、转置）；**(ii)** 什么操作按比例改变体积（行乘 t、矩阵乘整体乘 t）；**(iii)** 什么情况体积为零（行相关，包括行相同、零行、成比例）。
- **具体示例**：逐条给出矩阵验证（全部用同一个主算例 A，2×2 的例子另附）。

```
十条性质速查表（★ = Strang 反复强调的"必须记住"）

编号    性质                                      验证/来源
----    ----------------------------------------  --------------------------
P1      det I = 1                                   （公理 1，定义）
P2  ★   交换两行  ->  det 变号                     交换 [2,3,1;4,7,2;1,1,1]
                                                    得 det = -1 = -det A
P3  ★   对每一行线性（单独乘/单独加）             R1*3 -> det 3; R1 拆成两
                                                    行之和 -> det 2 + (-1) = 1
P4  ★★  一行加上另一行的倍数 -> det 不变          R2 += R1 -> det 仍 = 1
                                                  【消元法的全部依据】
P5      两行相同 -> det = 0                       [1,1,1;1,1,1;2,3,4] det=0
P6      某行全 0 -> det = 0                       [0,0,0;4,7,2;1,1,1] det=0
P7  ★   三角矩阵 det = 对角元之积                 U=[2,3,1;0,1,0;0,0,.5]
                                                    det = 2*1*0.5 = 1
P8      奇异（行相关）-> det = 0                  [1,2,1;2,4,2;1,1,1] det=0
        可逆 <-> det != 0
P9  ★   det(AB) = det A * det B                     det(AB) = -7,
                                                    det A = 1, det B = -7
P9'     det(tA) = t^n * det A                        det(5A) = 5^3 * 1 = 125
P10 ★   det(A^T) = det A                            det(A^T) = 1 = det A
P11     det(A^-1) = 1/det A                         det(A^-1) = 1/1 = 1
```

逐条验证（十条的算术细节）

P1 / P2 —— 恒等与交换。 见上面的手算演示"示例 2(a)(b)"：交换 A 的第 1、2 行得

$$\det\begin{bmatrix}4&7&2\\2&3&1\\1&1&1\end{bmatrix}=-1=-\det A.$$

几何：交换两行 = 把两个坐标轴对调 = 右手系变左手系。

P3 —— 行线性（乘与加两类）。 – 乘法：$R_1\to 3R_1$，$\det\begin{bmatrix}6&9&3\\4&7&2\\1&1&1\end{bmatrix}=3=3\det A$。– 加法：$[1\quad 3\quad -1]+[1\quad 0\quad 2]=[2\quad 3\quad 1]$，

$$\det\begin{bmatrix}1&3&-1\\4&7&2\\1&1&1\end{bmatrix}+\det\begin{bmatrix}1&0&2\\4&7&2\\1&1&1\end{bmatrix}=2+(-1)=1=\det A.$$

几何：底面固定时，体积是顶棱高度的线性函数。

P4 —— 行相加不变（重点）。 三条独立的验证：

$$\det\begin{bmatrix}2&3&1\\4&7&2\\1&1&1\end{bmatrix}=1,\quad \det\begin{bmatrix}2&3&1\\6&10&3\\1&1&1\end{bmatrix}=1\,(R_2{+}{=}R_1),\quad \det\begin{bmatrix}2&3&1\\4&7&2\\3&4&2\end{bmatrix}=1\,(R_3{+}{=}R_1).$$

几何：剪切不改变体积（见上方 ASCII 图）。**这条是消元法的全部依据。**

P5 —— 两行相同为零。 证明（只有两行）：

$$\det A \overset{\text{交换}}{=} -\det A \implies 2\det A = 0 \implies \det A = 0.$$

算术验证：$\det\begin{bmatrix}1&1&1\\1&1&1\\2&3&4\end{bmatrix}=0$，$\det\begin{bmatrix}2&3&1\\2&3&1\\1&1&1\end{bmatrix}=0$。**注意前提 $n\geq 2$**（要存在"另一行"才能交换），1×1 情形这条不适用。

P6 —— 零行为零。 由 P5 加 P3 的乘法部分：把零行写成 $0\cdot(\text{任意行})$，则 $\det = 0\cdot\det(\cdots)=0$。算术验证：$\det\begin{bmatrix}0&0&0\\4&7&2\\1&1&1\end{bmatrix}=0$。**几何**：盒子的一条棱长度为 0，体积为 0。

P7 —— 三角矩阵 = 对角元之积。 用大公式可证：上三角矩阵中 $a_{ij}=0$ 当 $i>j$，只有当排列是 $(1,2,\dots,n)$ 时六项乘积才全非零（一旦第 1 行选了列 2，第 2 行就只能在列 ≥ 2 里选，最终必有某行被迫选到 0）。算术验证：

$$\det\begin{bmatrix}2&3&1\\0&1&0\\0&0&\frac12\end{bmatrix}=2\cdot 1\cdot\tfrac12=1,\qquad \det\begin{bmatrix}2&0&0\\0&1&0\\0&0&\frac12\end{bmatrix}=1.$$

这条是消元法求行列式的最后一步。

P8 —— 奇异 $\iff \det=0$。 若行相关，则存在非平凡系数使 $\sum c_i\,\mathrm{row}_i=\mathbf{0}$。设 $c_1\neq 0$，则 $\mathrm{row}_1=\sum_{i\geq 2}(-c_i/c_1)\mathrm{row}_i$——第一行是其余行的线性组合。用 P4 把其余行的倍数从第一行里"减掉"，第一行变成零行，故 $\det=0$（P6）。反之若 $\det\neq 0$，则消元必能做完（n 个主元），A 可逆。 算术验证：$\det\begin{bmatrix}1&2&1\\2&4&2\\1&1&1\end{bmatrix}=0$（第 2 行 $=2\times$第 1 行）。

P9 —— 乘法法则 $\det(AB)=\det A\det B$。 算术验证：取

$$A=\begin{bmatrix}2&3&1\\4&7&2\\1&1&1\end{bmatrix}(\det A=1),\qquad B=\begin{bmatrix}1&0&2\\0&1&1\\3&1&0\end{bmatrix}(\det B=-7),$$

$$AB=\begin{bmatrix}5&4&7\\10&9&15\\4&2&3\end{bmatrix},\qquad \det(AB)=-7=1\cdot(-7).\ \checkmark$$

证明思路：固定 B，把 $f(A)=\det(AB)/\det B$ 看成 A 的函数。可以验证 f 同样满足三条公理（$f(I)=1$；交换 A 的两行 $=$ 交换 AB 的两行，故变号；对 A 的每一行线性），由唯一性 $f(A)=\det A$。**当 $\det B=0$ 时，AB 也可证奇异，故等式仍成立。**

P9' —— 整体缩放是 t^n 不是 t。 算术验证：$5A=\begin{bmatrix}10&15&5\\20&35&10\\5&5&5\end{bmatrix}$，消元主元 $10,5,2.5$，乘积 $=125=5^3\cdot 1$。**几何**：把空间的每个方向都拉长 5 倍，n 维盒子体积放大 5^n 倍。

P10 —— $\det(A^{\mathsf T})=\det A$。 算术验证：$A^{\mathsf T}=\begin{bmatrix}2&4&1\\3&7&1\\1&2&1\end{bmatrix}$。消元两步就已是上三角：

$$R_2\leftarrow R_2-\tfrac32 R_1:\ (3,7,1)-\tfrac32(2,4,1)=(0,1,-\tfrac12);\qquad R_3\leftarrow R_3-\tfrac12 R_1:\ (1,2,1)-\tfrac12(2,4,1)=(0,0,\tfrac12).$$

$$\begin{bmatrix}2&4&1\\0&1&-\frac12\\0&0&\frac12\end{bmatrix},\qquad \det(A^{\mathsf T})=2\cdot 1\cdot\tfrac12=1=\det A.\ \checkmark$$

证明思路：大公式里 $A^{\mathsf T}$ 的项是 $a_{\alpha 1}a_{\beta 2}\cdots a_{\omega n}$，与 A 的项 $a_{1\alpha}a_{2\beta}\cdots$ 是同一批乘积（乘法交换），逆序数也相同。**所以"行"与"列"在 det 面前完全平等**——任何关于行的性质都能照搬到列。

P11 —— $\det(A^{-1})=1/\det A$。 由 P9：$\det A\cdot\det(A^{-1})=\det(AA^{-1})=\det I=1$。算术验证：$\det A=1$，$A^{-1}=\begin{bmatrix}5&-2&-1\\-2&1&0\\-3&1&2\end{bmatrix}$（见讲次 20 的伴随矩阵），$\det(A^{-1})=1$。$2\times 2$ 的对照：$M=\begin{bmatrix}3&1\\5&2\end{bmatrix}$，$\det M=1$，$M^{-1}=\begin{bmatrix}2&-1\\-5&3\end{bmatrix}$，$\det=1$。

计算步骤与手算演示

示例 1：消元法求 $\det A$，并与余子式展开对照

取

$$A=\begin{bmatrix}2&3&1\\4&7&2\\1&1&1\end{bmatrix}.$$

步骤 1：从 A 出发。 此时还不知道 $\det A$，但知道"要从 A 变到 I 需要多少行变换"。

步骤 2：$R_2\leftarrow R_2-2R_1$。 这是"一行减去另一行的倍数"，由性质 4，**行列式不变**。

$$\begin{bmatrix}2&3&1\\4&7&2\\1&1&1\end{bmatrix}\xrightarrow{R_2-2R_1}\begin{bmatrix}2&3&1\\0&1&0\\1&1&1\end{bmatrix}$$

验算第二行：$4-2\cdot2=0$，$7-2\cdot3=1$，$2-2\cdot1=0$。✓

步骤 3：$R_3\leftarrow R_3-\frac{1}{2}R_1$。 同样是行相减，**行列式不变**。

$$\xrightarrow{R_3-\frac{1}{2}R_1}\begin{bmatrix}2&3&1\\0&1&0\\0&-\frac{1}{2}&\frac{1}{2}\end{bmatrix}$$

验算第三行：$1-\frac{1}{2}\cdot2=0$，$1-\frac{1}{2}\cdot3=-\frac{1}{2}$，$1-\frac{1}{2}\cdot1=\frac{1}{2}$。✓

步骤 4：$R_3\leftarrow R_3+\frac{1}{2}R_2$。 依然不变号。

$$\xrightarrow{R_3+\frac{1}{2}R_2}\begin{bmatrix}2&3&1\\0&1&0\\0&0&\frac{1}{2}\end{bmatrix}=U$$

验算第三行：$-\frac{1}{2}+\frac{1}{2}\cdot1=0$，$\frac{1}{2}+\frac{1}{2}\cdot0=\frac{1}{2}$。✓

步骤 5：读出行列式。 U 是上三角矩阵，由性质 6，$\det U=$ 对角元之积 $=2\cdot1\cdot\frac{1}{2}=1$。全程没有交换过行（没有变号），所以

$$\boxed{\det A=1.}$$

【计算机制解说】：为什么"消元读主元之积"行得通？因为整个消元过程只用了两种操作：（i）**一行减去另一行的倍数**——由移项性质 4，$\det$ **严格不变**；（ii）**行交换**——由公理 2，$\det$ **变号**（若发生 k 次交换，最后乘 $(-1)^k$）。消元结束后得到上三角 U，而对角矩阵/三角矩阵的行列式等于对角元之积（性质 6 的证明见下）。所以

$$\det A=(-1)^k u_{11}u_{22}\cdots u_{nn},$$

其中 k 是交换次数。注意 Strang 常写 $\det A=\pm(\text{pivot product})$，符号由交换次数决定。这里 $k=0$，故 $\det A=1$。**计算量约 $\frac{2}{3}n^3$，与 $n!$ 相比是天壤之别。**

步骤 6：换一条完全不同的路——沿第一行做余子式展开。 先算三个 2×2 子式：

$$\det M_{11}=\det\begin{bmatrix}7&2\\1&1\end{bmatrix}=7-2=5,\quad \det M_{12}=\det\begin{bmatrix}4&2\\1&1\end{bmatrix}=4-2=2,\quad \det M_{13}=\det\begin{bmatrix}4&7\\1&1\end{bmatrix}=4-7=-3.$$

带上符号 $C_{1j}=(-1)^{1+j}\det M_{1j}$：

$$C_{11}=+5,\qquad C_{12}=-2,\qquad C_{13}=+(-3)=-3.$$

于是

$$\det A=a_{11}C_{11}+a_{12}C_{12}+a_{13}C_{13}=2\cdot5+3\cdot(-2)+1\cdot(-3)=10-6-3=1.$$

两条路线给出同一个数 1。 这不是巧合——余子式展开与消元都是那三条公理的推论，公理唯一地确定了 $\det$，所以任何自洽的算法都必须得到同一个值。

步骤 7：再换第三条路（同一个矩阵，沿第二列展开）。 子式与符号：

$$\det M_{12}=2\Rightarrow C_{12}=-2,\quad \det M_{22}=\det\begin{bmatrix}2&1\\1&1\end{bmatrix}=2-1=1\Rightarrow C_{22}=+1,\quad \det M_{32}=\det\begin{bmatrix}2&1\\4&2\end{bmatrix}=4-4=0\Rightarrow C_{32}=-0=0.$$

$$\det A=a_{12}C_{12}+a_{22}C_{22}+a_{32}C_{32}=3\cdot(-2)+7\cdot1+1\cdot0=-6+7=1.\checkmark$$

```
两条路线对比（同一个 A，同一个答案 1）

路线 A：消元                          路线 B：余子式展开
-----------------------------------   ---------------------------------------
[ 2  3   1 ]                          det A = a11*C11 + a12*C12 + a13*C13
[ 0  1   0 ]  R2-2R1                  C11 = +(7*1 - 2*1) = +5
[ 1  1   1 ]                          C12 = -(4*1 - 2*1) = -2
     |  R3-0.5R1                      C13 = +(4*1 - 7*1) = -3
     v                                      |
[ 2  3   1 ]                                v
[ 0  1   0 ]                          2*5 + 3*(-2) + 1*(-3)
[ 0 -0.5 0.5 ]                              |
     |  R3+0.5R2                            v
     v                                10 - 6 - 3 = 1   <=== 结果一致
[ 2  3   1 ]
[ 0  1   0 ]
[ 0  0  0.5 ]
     |
     v
det = 2 * 1 * 0.5 = 1   <=== 结果一致

成本：~2n^3/3 ≈ 18 flops       成本：3 个子式，每个 2x2 = ~9 flops（n=3 时更省）
但对 n=20：~5300 次运算         但对 n=20：20! ≈ 2.4e18 次运算（宇宙寿命也算不完）
```

示例 2：逐条验证"行线性"与"行相加不变"

取上面同一个 $\boldsymbol{A}$，做四组对照实验。

(a) 交换两行变号（公理 2）。 交换 $\boldsymbol{A}$ 的第 1、2 行：

$$A' = \begin{bmatrix} 4 & 7 & 2 \\ 2 & 3 & 1 \\ 1 & 1 & 1 \end{bmatrix}, \qquad \det A' = ?$$

用消元：$R_2 \leftarrow R_2 - \frac{1}{2}R_1$，$R_3 \leftarrow R_3 - \frac{1}{4}R_1$：

$$\begin{bmatrix} 4 & 7 & 2 \\ 0 & -\frac{1}{2} & 0 \\ 0 & -\frac{3}{4} & \frac{1}{2} \end{bmatrix} \xrightarrow{R_3 - \frac{3}{2}R_2} \begin{bmatrix} 4 & 7 & 2 \\ 0 & -\frac{1}{2} & 0 \\ 0 & 0 & \frac{1}{2} \end{bmatrix},$$

$\det A' = 4 \cdot \left(-\frac{1}{2}\right) \cdot \frac{1}{2} = -1 = -\det A$。✓ **符号翻转，绝对值不变。**

(b) 交换第 1、3 行。

$$A'' = \begin{bmatrix} 1 & 1 & 1 \\ 4 & 7 & 2 \\ 2 & 3 & 1 \end{bmatrix}, \qquad \det A'' = -1 = -\det A. \ \checkmark$$

(c) 某一行乘 t（公理 3 的乘法部分）。 令 $t = 3$，第 1 行乘 3：

$$A_t = \begin{bmatrix} 6 & 9 & 3 \\ 4 & 7 & 2 \\ 1 & 1 & 1 \end{bmatrix}, \qquad \det A_t = 3 \det A = 3.$$

直接消元验算：$R_2 \leftarrow R_2 - \frac{2}{3}R_1$，$R_3 \leftarrow R_3 - \frac{1}{6}R_1$ 得 $\begin{bmatrix} 6 & 9 & 3 \\ 0 & 1 & 0 \\ 0 & -\frac{1}{2} & \frac{1}{2} \end{bmatrix}$，再得 $\begin{bmatrix} 6 & 9 & 3 \\ 0 & 1 & 0 \\ 0 & 0 & \frac{1}{2} \end{bmatrix}$，乘积 $6 \cdot 1 \cdot \frac{1}{2} = 3$。✓

(d) 把一行加到另一行（性质 4）。 取 $R_2 \leftarrow R_2 + R_1$：

$$A_s = \begin{bmatrix} 2 & 3 & 1 \\ 6 & 10 & 3 \\ 1 & 1 & 1 \end{bmatrix}, \qquad \det A_s = 1 = \det A. \ \checkmark$$

（消元：$R_2 - 3R_1$ 得 $(0, 1, 0)$，$R_3 - \frac{1}{2}R_1$ 得 $(0, -\frac{1}{2}, \frac{1}{2})$，$R_3 + \frac{1}{2}R_2$ 得 $(0, 0, \frac{1}{2})$，乘积 $2 \cdot 1 \cdot \frac{1}{2} = 1$。）

(e) 行线性的"加法部分"（公理 3）。 把 $\boldsymbol{A}$ 的第一行写成两个向量之和：$[1 \quad 3 \quad -1] + [1 \quad 0 \quad 2] = [2 \quad 3 \quad 1]$。分别造两个矩阵：

$$B = \begin{bmatrix} 1 & 3 & -1 \\ 4 & 7 & 2 \\ 1 & 1 & 1 \end{bmatrix}, \qquad C = \begin{bmatrix} 1 & 0 & 2 \\ 4 & 7 & 2 \\ 1 & 1 & 1 \end{bmatrix}.$$

计算：$\det B = 2$，$\det C = -1$。于是

$$\det B + \det C = 2 + (-1) = 1 = \det A. \ \checkmark$$

行列式对第一行"可加"，但绝不能对"整个矩阵可加"——$\det(A+B) \neq \det A + \det B$ 一般成立（这正是下一个误区清单里的头号杀手）。

【计算机制解说】：为什么"行列式对行线性、但对矩阵不是线性"？因为 $\det$ 是关于**每一行分别**的多重线性函数（n 重线性），而不是关于矩阵这个整体的一元线性函数。把矩阵 A 整体乘 t，等于 n 行**各自**乘 t，由公理 3 连续用 n 次，得到 $\det(tA) = t^n \det A$，不是 $t \det A$。用 A 验证：$n = 3$，$t = 5$，

$$\det(5A) = 5^3 \det A = 125 \cdot 1 = 125.$$

（直接验算 $5A = \begin{bmatrix} 10 & 15 & 5 \\ 20 & 35 & 10 \\ 5 & 5 & 5 \end{bmatrix}$ 的消元：$R_2 - 2R_1 = (0,5,0)$，$R_3 - \frac{1}{2}R_1 = (0, -\frac{5}{2}, \frac{5}{2})$，$R_3 + \frac{1}{2}R_2 = (0,0,\frac{5}{2})$，主元 $10, 5, \frac{5}{2}$，乘积 $= 125$。✓）**记住这条幂次：n 维空间缩放 t 倍，体积放大 t^n 倍。**

示例 3：需要换行的消元——符号变化的完整记账

前两个例子里主元位置上恰好都没有 0，所以从未换行。现在做一个**必须换行**的例子，把 $(-1)^k$ 的记账讲清楚。

取

$$C = \begin{bmatrix} 0 & 2 & 1 \\ 3 & 1 & 4 \\ 2 & 5 & 1 \end{bmatrix}.$$

注意 $c_{11} = 0$——消元第一步就做不下去（不能除以 0 主元）。

步骤 1：$R_1 \leftrightarrow R_2$（第 1 次交换，记符号因子 -1）。

$$\begin{bmatrix} 0 & 2 & 1 \\ 3 & 1 & 4 \\ 2 & 5 & 1 \end{bmatrix} \xrightarrow{R_1 \leftrightarrow R_2} \begin{bmatrix} 3 & 1 & 4 \\ 0 & 2 & 1 \\ 2 & 5 & 1 \end{bmatrix}$$

由公理 2，$\det(C) = -\det(\text{交换后})$。

步骤 2：$R_3 \leftarrow R_3 - \frac{2}{3}R_1$（行相加，不变号）。 $(2,5,1) - \frac{2}{3}(3,1,4) = (0, \frac{13}{3}, -\frac{5}{3})$。

$$\begin{bmatrix} 3 & 1 & 4 \\ 0 & 2 & 1 \\ 0 & \frac{13}{3} & -\frac{5}{3} \end{bmatrix}$$

步骤 3：$R_3 \leftarrow R_3 - \frac{13}{6}R_2$（行相加，不变号）。 逐分量：

$$0 - \tfrac{13}{6} \cdot 0 = 0, \qquad \tfrac{13}{3} - \tfrac{13}{6} \cdot 2 = \tfrac{13}{3} - \tfrac{13}{3} = 0, \qquad -\tfrac{5}{3} - \tfrac{13}{6} \cdot 1 = -\tfrac{10}{6} - \tfrac{13}{6} = -\tfrac{23}{6}.$$

$$(0, \tfrac{13}{3}, -\tfrac{5}{3}) - \tfrac{13}{6}(0,2,1) = (0,0,-\tfrac{23}{6}), \qquad U = \begin{bmatrix} 3 & 1 & 4 \\ 0 & 2 & 1 \\ 0 & 0 & -\frac{23}{6} \end{bmatrix}$$

步骤 4：读主元之积并还原符号。

$$\det(\text{交换后的矩阵}) = 3 \cdot 2 \cdot \left(-\tfrac{23}{6}\right) = -23, \qquad \det C = (-1)^1 \cdot (-23) = +23.$$

步骤 5：用余子式展开独立验证。 沿第 1 列展开。C 的第 1 列是 $(0,3,2)^{\mathsf{T}}$，有**两个**非零元，所以展开式保留两项：

$$M_{11} = \begin{bmatrix} 1 & 4 \\ 5 & 1 \end{bmatrix} \Rightarrow \det = 1 \cdot 1 - 4 \cdot 5 = -19 \Rightarrow C_{11} = +(-19) = -19,$$

$$M_{21} = \begin{bmatrix} 2 & 1 \\ 5 & 1 \end{bmatrix} \Rightarrow \det = 2 \cdot 1 - 1 \cdot 5 = -3 \Rightarrow C_{21} = -(-3) = +3,$$

$$M_{31} = \begin{bmatrix} 2 & 1 \\ 1 & 4 \end{bmatrix} \Rightarrow \det = 2 \cdot 4 - 1 \cdot 1 = 7 \Rightarrow C_{31} = +7,$$

$$\det C = c_{11}C_{11} + c_{21}C_{21} + c_{31}C_{31} = 0 \cdot (-19) + 3 \cdot 3 + 2 \cdot 7 = 0 + 9 + 14 = 23. \ \checkmark$$

两条路殊途同归：$\det C = 23$。

【计算机制解说】：这个例子值得慢慢看，因为它暴露了两类高频错误。**第一类是"子矩阵取错"**：M_{ij} 必须删去**第 i 行和第 j 列**。这里最典型的错法是把 M_{11} 写成 $\begin{bmatrix}2 & 1\\ 5 & 1\end{bmatrix}$（其实是 M_{21}），从而得到 -3 而不是正确的 -19。**自查方法**：M_{ij} 的第一行应当是被保留行中**最靠上**的那一行。**第二类是"分数算错"**：消元时 $-\frac{5}{3}-\frac{13}{6}$ 必须通分（$=-\frac{10}{6}-\frac{13}{6}=-\frac{23}{6}$），写成 -6 就会让最终答案从 23 变成 36。

流程上的教训：**永远用两种独立方法算同一个行列式**。上面这两类错误都是靠"消元结果 $\neq$ 展开结果"被抓出来的；如果只算一遍就落笔，很可能写出 36 或 -6 这样的错误值而不自知。本讲所有算例都已用脚本复核过。

这个例子的另一个教训：换行只影响**符号**，不影响主元的**绝对值**。真正决定"可逆不可逆"的是主元是否有 0，与交换次数无关。

示例 4：2×2 全清单——2 维里每一条性质都看得见

2×2 只有两项，所有性质都能一眼验证，是最好的"试验台"。

$$M=\begin{bmatrix}3 & 1\\ 5 & 2\end{bmatrix},\qquad \det M=3\cdot 2-1\cdot 5=6-5=1.$$

操作	结果矩阵	det	与 $\det M$ 的关系
原矩阵	$\begin{bmatrix}3 & 1\\ 5 & 2\end{bmatrix}$	1	—
交换两行	$\begin{bmatrix}5 & 2\\ 3 & 1\end{bmatrix}$	-1	变号（公理 2）
第 1 行乘 $t=4$	$\begin{bmatrix}12 & 4\\ 5 & 2\end{bmatrix}$	4	$\times 4$（公理 3）
$R_2\leftarrow R_2+2R_1$	$\begin{bmatrix}3 & 1\\ 11 & 4\end{bmatrix}$	$12-11=1$	**不变**（性质 4）
整体乘 $t=4$	$\begin{bmatrix}12 & 4\\ 20 & 8\end{bmatrix}$	$96-80=16$	$\times 4^2=16$（性质 9'）
两行相同	$\begin{bmatrix}3 & 1\\ 3 & 1\end{bmatrix}$	0	性质 5
一行全零	$\begin{bmatrix}3 & 1\\ 0 & 0\end{bmatrix}$	0	性质 6
转置	$\begin{bmatrix}3 & 5\\ 1 & 2\end{bmatrix}$	1	不变（性质 10）
两行成比例	$\begin{bmatrix}3 & 1\\ 6 & 2\end{bmatrix}$	0	奇异（性质 8）
取逆	$\begin{bmatrix}2 & -1\\ -5 & 3\end{bmatrix}$	1	$1/\det M=1$（性质 11）

验证几个关键行：– 交换后：$5\cdot 1-2\cdot 3=5-6=-1=-\det M$ ✓ – R_2+2R_1：$R_2'=(5+6,\ 2+2)=(11,4)$，$\det=3\cdot 4-1\cdot 11=12-11=1=\det M$ ✓（**剪切不改变面积**） – 整体乘 4：$4M=\begin{bmatrix}12 & 4\\ 20 & 8\end{bmatrix}$，$\det=12\cdot 8-4\cdot 20=96-80=16=4^2\det M$ ✓ – 逆矩阵：$M^{-1}=\frac{1}{1}\begin{bmatrix}2 & -1\\ -5 & 3\end{bmatrix}$，$\det=2\cdot 3-(-1)(-5)=6-5=1$ ✓

【计算机制解说】：2×2 表格里最值得盯住的是 **"整体乘 t" 是 t^2 而"一行乘 t"是 t**。在 2 维里，把整个平面按比例放大 4 倍，面积放大 16 倍——这是"t^n"最直观的情形。很多人出错是因为把"A 乘一个数"和"A 的某一行乘一个数"混为一谈：前者作用于**所有 n 行**，后者只作用一行。**判断依据：看被乘的对象占了几行（几维）。**

示例 5：用 LU 分解一次算出 $\det A$ 并顺便得到 A^{-1}

LU 分解不只是求 $\det$ 的工具，它同时给了求逆的 $O(n^3)$ 路径。用主算例

$$A=\begin{bmatrix}2 & 3 & 1\\ 4 & 7 & 2\\ 1 & 1 & 1\end{bmatrix},\qquad L=\begin{bmatrix}1 & 0 & 0\\ 2 & 1 & 0\\ \frac{1}{2} & -\frac{1}{2} & 1\end{bmatrix},\qquad U=\begin{bmatrix}2 & 3 & 1\\ 0 & 1 & 0\\ 0 & 0 & \frac{1}{2}\end{bmatrix}.$$

（手算演示 1 的消元乘数依次是 $\ell_{21}=2$，$\ell_{31}=\frac{1}{2}$，$\ell_{32}=-\frac{1}{2}$，所以 L 的下三角正是这些乘数——这是讲次 4 的 $A=LU$ 的标准结构。）

步骤 1：验算 $LU=A$。 L 第 2 行 × U：$2(2,3,1)+(0,1,0)=(4,7,2)$ ✓。L 第 3 行 × U：$\frac{1}{2}(2,3,1)-\frac{1}{2}(0,1,0)+(0,0,\frac{1}{2})=(1,\frac{3}{2}-\frac{1}{2},\frac{1}{2}+\frac{1}{2})=(1,1,1)$ ✓。

步骤 2：$\det A=\det L\cdot\det U=1\cdot(2\cdot 1\cdot\frac{1}{2})=1$。

步骤 3：用 LU 求逆。 解 $A\mathbf{x}_j=\mathbf{e}_j$ 三次。以 $\mathbf{e}_1$ 为例：先解 $L\mathbf{y}=\mathbf{e}_1$（前代），再解 $U\mathbf{x}=\mathbf{y}$（回代），得到 A^{-1} 的第 1 列 $=(5,-2,-3)^{\mathsf{T}}$（与讲次 20 用伴随矩阵得到的 A^{-1} 第一列一致）。三次求解共约 $2\cdot\frac{2}{3}n^3$ 次运算，与 LU 分解同阶。**这就是工程上实际求逆的方式，绝不走伴随矩阵。**

【计算机制解说】：LU 分解把"求一次 $\det$"和"解 n 个方程组"统一在同一套消元里：分解只做一次（$\frac{2}{3}n^3$），之后每个右端项只要 $2n^2$ 的前代/回代。**$\det$ 是 U 的免费副产品，A^{-1} 是顺手的额外收获。** 这正是"分解优于公式"的典型例子——$A^{-1} = \operatorname{adj} A / \det A$ 是一次性公式，LU 是可复用的结构。

矩阵分解的核心思想

本讲的"分解"就是**消元本身**：$A = LU$（若需换行则 $PA = LU$）。消元把 A 拆成

$$A = LU,$$

其中 L 是单位下三角（对角元全 1），U 是上三角（对角元是主元）。对本讲的 A：

$$L = \begin{bmatrix} 1 & 0 & 0 \\ 2 & 1 & 0 \\ \frac{1}{2} & -\frac{1}{2} & 1 \end{bmatrix}, \qquad U = \begin{bmatrix} 2 & 3 & 1 \\ 0 & 1 & 0 \\ 0 & 0 & \frac{1}{2} \end{bmatrix}.$$

验算 $LU = \begin{bmatrix} 2 & 3 & 1 \\ 4 & 7 & 2 \\ 1 & 1 & 1 \end{bmatrix} = A$。✓

这个分解如何**一眼读出行列式**？由性质 8（$\det(AB) = \det A \det B$）：

$$\det A = \det L \cdot \det U = 1 \cdot (u_{11}u_{22}u_{33}) = 2 \cdot 1 \cdot \tfrac{1}{2} = 1.$$

因为 L 是单位下三角，$\det L = 1$（对角元之积 $= 1$）。**这就是"消元法求行列式"的代数骨架：L 不贡献任何倍数，只有 U 的主元之积贡献行列式；唯一可能改变符号的是换行矩阵 P（若需要换行，则 $\det P = \pm 1$，$\det A = \det P \det U$）。**

结构性质：A 可逆 $\iff$ U 的 n 个主元全非零 $\iff$ $\det A \neq 0$。所以行列式不是一个新的神秘量，它就是**主元乘积的有符号版本**。LU 分解同时揭示了 $\det$ 与秩、与四个基本子空间的连通："主元个数 $= r$（秩）"，"缺主元 $\iff$ 某主元为 0 $\iff$ $\det = 0$ $\iff$ $N(A) \neq \{\mathbf{0}\}$"。

为什么"分解"比"公式"更适合求行列式——一个结构性的理由。

```
三种视角看同一个 A = [[2,3,1],[4,7,2],[1,1,1]]

公式视角（讲次 19）：            分解视角（本讲）：
det = 6 项带符号求和              A = L U,  det A = det L * det U
14 + 6 + 4 − 4 − 12 − 7            = 1 * (2 * 1 * 0.5) = 1

需要知道每一项"从哪来"           只需要知道"消元乘数"与"主元"
依赖 n! 的排列组合                 依赖 n^3 的算术
结构信息：弱                       结构信息：强
  − 哪些项抵消？                     − L 的乘数 = 消元过程
  − 为什么符号是这样？               − U 的主元 = 秩/可逆性/特征值线索
                                       − det L = 1 恒成立（单位下三角）

结论：公式告诉你 det "是什么"，分解告诉你 det "怎么来" 以及它与其他
结构量（秩、主元、子空间）的关系。两讲互补，缺一不可。
```

与"三个基本事实"的呼应：本讲推出的 $\det A = (-1)^k \prod u_{ii}$ 把三件事绑在一起——**符号**来自交换次数（定向）、**大小**来自主元（体积）、**是否为零**来自主元是否缺失（可逆性）。讲次 20 会把这个"主元 = 棱长"的图景画成几何图形，讲次 21 会用它展开特征多项式，讲次 29 会把它升级为奇异值乘积。**LU 是这三讲共同的骨架。**

应用价值：所有数值线性代数软件（LAPACK）算 $\det$ 都是先做 $PA = LU$，再返回 $\det P \cdot \prod u_{ii}$。这是唯一在 n 稍大时可行的做法。

与其他讲次的关联

- **讲次 4（消元与 $A = LU$）**：本讲的算法基础。$PA = LU$ 中的主元乘积就是 $\det A$ 的绝对值；换行次数决定符号。请回看讲次 4 的"主元不可能为 0 当且仅当可逆"。
- **讲次 2–3（矩阵乘法与逆）**：$\det(AB) = \det A \det B$ 与 $\det(A^{-1}) = 1/\det A$ 把"乘法"和"求逆"翻译成数的乘法与倒数，这是把矩阵问题标量化的第一步。
- **讲次 8–10（四个基本子空间）**：$\det A = 0$ 等价于 $N(A) \neq \{\mathbf{0}\}$、列向量线性相关、$C(A)$ 不满维。这四个说法在本讲之后可以用**一个数**统一检测。
- **讲次 19（本讲的下一讲）**：把三条公理"展开"成 $n!$ 项的**大公式**，并给出余子式的系统算法。
- **讲次 20**：本讲的性质成为几何解释（体积）与 Cramer 法则（讲次 20）的燃料。
- **讲次 21（特征值）**：$\det(A - \lambda I) = 0$ 是求特征值的定义方程；若没有本讲的"可逆 $\iff$ $\det \neq 0$"，特征值问题根本无法写出代数方程。
- **讲次 29（SVD）**：$\sigma_1 \sigma_2 \cdots \sigma_n = |\det A|$——行列式是奇异值的乘积，本讲与讲次 29 在这里闭环。

关键要点

1. **三条公理唯一确定行列式**：$\det I = 1$；交换两行变号；对每一行线性。所有性质都是推论，其中**"一行加到另一行不变"是消元的依据**。
2. **三角矩阵 det = 对角元之积**；因此 $PA = LU$ 给出 $\det A = \det P \cdot \prod_i u_{ii}$，计算量 $\frac{2}{3}n^3$，是求行列式的**标准算法**。
3. **乘法法则**：$\det(AB) = \det A \cdot \det B$。推论：$\det(A^{-1}) = 1/\det A$；$\det(A^k) = (\det A)^k$；$\det(tA) = t^n \det A$。**注意 $\det(A+B)$ 没有任何简单公式。**
4. **可逆性判据**：$\det A = 0 \iff A$ 奇异 $\iff$ 存在非零 $\mathbf{x}$ 使 $A\mathbf{x} = \mathbf{0}$ $\iff$ 行/列线性相关 $\iff$ 存在主元为 0。
5. **转置不变**：$\det(A^{\mathsf{T}}) = \det A$。所以"行"与"列"在行列式面前完全平等，任何行的性质都能照搬到列。
6. **符号记账公式**：$\det A = (-1)^k d_1 d_2 \cdots d_n$，$k$ 是消元过程中的行交换次数，d_i 是主元。**"行相减不变号、行交换变号"是唯一需要记住的两条操作规则。**
7. **公理的唯一性**：三条公理不仅"定义"行列式，还**唯一确定**它——因为任何 A 都能用行变换搬到 I，每一步的效果都被公理锁死，从而 $\det A$ 没有第二种取值。这是"用性质定义"能成立的根本原因。

常见误区与注意事项

1. **最大陷阱：$\det(A+B) \neq \det A + \det B$。** 行列式对"每一行"线性，不对矩阵加法线性。反例：$A = \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix}$，$B = \begin{bmatrix} 0 & 0 \\ 0 & 1 \end{bmatrix}$，则 $\det A = \det B = 0$ 但 $\det(A+B) = \det I = 1 \neq 0$。（顺便：$\det(tA) = t^n \det A$，不是 $t \det A$，很多人在 $n = 3$ 时漏掉立方。）
2. **误以为可用"某行乘 2、另一行减 3 倍"来做消元且不算账。** 消元求 det 时只允许**行相减（不变号）**和**行交换（每次变号）**；如果你为了制造 1 而先把某行乘了 t，就必须把 t 记在账上（最后除以 t）。最安全的做法是**只用行相减 + 记录交换次数**。
3. **忘记数交换次数。** 用消元法时如果做过行交换，必须最后乘 $(-1)^k$。例如 $\begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}$ 若直接"读对角元之积"得 0，完全错误；正确答案是 -1（做一次交换得到 I，故 $\det = -1$）。
4. **把"两行成比例"仅理解成"两行相等"。** 性质是：若某行是另一行的倍数（包括 0 倍，即有一行全零），$\det = 0$。例如 $\begin{bmatrix} 1 & 1 & 1 \\ 2 & 2 & 2 \\ 3 & 3 & 3 \end{bmatrix}$ 的三行都成比例，$\det = 0$；更普遍地，**秩 1 矩阵（$n \geq 2$）行列式恒为 0**。
5. **以为 $\det A \neq 0$ 意味着"没有零行"。** 反例：$A = \begin{bmatrix} 1 & 2 \\ 2 & 4.0001 \end{bmatrix}$ 两行都非零、几乎平行，$\det = 0.0001 \neq 0$ 但矩阵病态。反过来，$\begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix}$ 也没有零行，却 $\det = 0$。**判据是线性相关性，不是"有没有零"。**
6. **误以为"消元过程中行列式一直不变"。** 只有"行相减"不变；**行交换每次乘 -1**。正确记账是 $\det A = (-1)^k \prod d_i$，漏掉 $(-1)^k$ 是最常见的丢分点。上面"示例 3"的矩阵 $C = \begin{bmatrix} 0 & 2 & 1 \\ 3 & 1 & 4 \\ 2 & 5 & 1 \end{bmatrix}$ 就演示了这一点：不做交换根本无法起步，而最终 $\det C = +23$，不是 -23。
7. **把 det 当成"矩阵的某种范数"。** det 可以为负、可以为 0、不满足三角不等式；$\det(A+B)$ 与 $\det A + \det B$ 毫无关系。**"大小"的正确度量是范数 $\|A\|$ 或奇异值（讲次 29），det 度量的是有向体积，不是"矩阵的大小"。**
8. **在 $n \geq 2$ 之外滥用"两行相同为零"。** 1×1 矩阵 $[a]$ 的"两行相同"无从谈起，$\det[a] = a$ 可为任意值。同理，"反对称奇数阶 $\Rightarrow \det = 0$"的证明依赖 $(-1)^n = -1$，n 为偶数时该结论**不成立**（如 $\begin{bmatrix} 0 & 1 \\ -1 & 0 \end{bmatrix}$，$\det = 2$）。
9. **把"$\det \neq 0$"当成"数值稳定"。** 行列式对**单位**极其敏感：把 A 的第二行单位从"米"换成"厘米"（乘 100），det 就放大 100 倍，可逆性完全没变。**判断数值是否接近奇异必须用条件数 σ_1/σ_n（讲次 29），det 会随单位任意放大或缩小。** 这也解释了为什么数值软件从不报告 det 而报告主元或条件数。
10. **在行/列性质之间犹豫。** 因为 $\det(A^{\mathsf{T}}) = \det A$（性质 10），**凡是对"行"成立的性质，对"列"逐字成立**：交换两列变号、一列乘 t 则 det 乘 t、一列加到另一列 det 不变、两列相同则 $\det = 0$。讲次 20 的 Cramer 法则正是"对列用线性"的直接产物。**不用分别记两套，记住一套 + 转置即可。**
11. **把"$\det A = 0$"与"$A\mathbf{x} = \mathbf{0}$ 只有零解"混为一谈。** $\det A = 0$ 的等价说法是"$A\mathbf{x} = \mathbf{0}$ 有**非零**解"（$N(A) \neq \{\mathbf{0}\}$），即"零空间不平凡"。这正是讲次 8–10 四个基本子空间的语言：$\det A = 0 \iff \dim N(A) \geq 1 \iff \mathrm{rank}(A) < n$。**行列式把"可逆性"这个几何/代数问题压缩成了一个数是否为零。**
12. **把"远距离交换"当成"多次变号"。** 性质 2 说的是"交换**任意两行**（无论相隔多远），det 只变号一次"，因为远距离交换可拆成若干次相邻交换，而总次数必为**奇数**，符号合并后仍是 -1。例：$A = \begin{bmatrix} 2 & 3 & 1 \\ 4 & 7 & 2 \\ 1 & 1 & 1 \end{bmatrix}$（$\det A = 1$），把第 1、3 行对调得 $\begin{bmatrix} 1 & 1 & 1 \\ 4 & 7 & 2 \\ 2 & 3 & 1 \end{bmatrix}$，其行列式 $= -1 = -\det A$。**不要以为"隔得远就变号更多次"。**

思考题（带答案）

Q1. 设 $A=\begin{bmatrix}2&3&1\\4&7&2\\1&1&1\end{bmatrix}$。已知 $\det A=1$（本讲已算）。不重新消元，直接写出下列行列式的值：(i) $\det(3A)$；(ii) $\det(A^{\mathsf T})$；(iii) $\det(A^{-1})$；(iv) $\det(A^2)$；(v) $\det(-A)$。

▸ 答案

全部由本讲性质推出，无需重新计算：

(i) A 是 3×3，$n=3$，故 $\det(3A)=3^3\det A=27\cdot 1=27$。（常见错误：答 3。要记住是 t^n。）

(ii) $\det(A^{\mathsf T})=\det A=1$（性质 10）。

(iii) 由 $\det(AA^{-1})=\det I=1$ 得 $\det(A^{-1})=1/\det A=1$。

(iv) $\det(A^2)=\det(A)\det(A)=1^2=1$。

(v) $-A$ 等于把 A 的三行**各乘** -1，即 $(-A)=(-1)\cdot A$（整体缩放），故 $\det(-A)=(-1)^3\det A=-1$。（如果只把一行乘 -1，才是 -1；这里三行都乘了 -1。）

Q2.（概念题）下面每个说法判断真假，并给出理由或反例。(i) 若 $\det A=0$ 且 $\det B=0$，则 $\det(A+B)=0$。(ii) 若 $\det A=0$，则 A 的某一行必为零行。(iii) 若对矩阵 A 做 $R_1\leftarrow R_1+5R_2$，则 $\det A$ 变为 $5\det A$。(iv) 若 A 是置换矩阵，则 $\det A=\pm 1$。

▸ 答案

(i) **假。** 反例：$A=\begin{bmatrix}1&0\\0&0\end{bmatrix}$，$B=\begin{bmatrix}0&0\\0&1\end{bmatrix}$，$\det A=\det B=0$，但 $A+B=I$，$\det(A+B)=1\neq 0$。

(ii) **假。** 反例：$\begin{bmatrix}1&2\\2&4\end{bmatrix}$ 无零行，但 $\det=1\cdot 4-2\cdot 2=0$（第二行是第一行的 2 倍，行线性相关）。（零行只是"行相关"的一种特例。）

(iii) **假。** 由性质 4，"一行加上另一行的倍数"**不改变**行列式（这正是消元的基础）。所以 $\det$ 仍是 $\det A$。（$R_1\leftarrow 5R_1$ 才是变成 $5\det A$。区别在于"替换本行"还是"本行相加"。）

(iv) **真。** 置换矩阵的每一行每一列恰有一个 1。把 P 通过若干次**行交换**变成 I：若交换了 k 次，则 $\det P=(-1)^k\det I=(-1)^k=\pm 1$。

例：$\begin{bmatrix}0&1\\1&0\end{bmatrix}$ 需 1 次交换，$\det=-1$；三循环 $\begin{bmatrix}0&0&1\\1&0&0\\0&1&0\end{bmatrix}$ 需 2 次交换，$\det=+1$。

Q3.（计算题）用消元法求

$$A=\begin{bmatrix}1&1&1\\0&2&5\\2&5&-1\end{bmatrix}$$

的行列式，写出每一步用了哪条性质，并说明是否有符号变化。

▸ 答案

步骤 1：$R_3\leftarrow R_3-2R_1$（性质 4，行相加，**不变号**）：

$$\begin{bmatrix}1&1&1\\0&2&5\\0&3&-3\end{bmatrix}$$

验算：$2-2\cdot 1=0$，$5-2\cdot 1=3$，$-1-2\cdot 1=-3$。✓

步骤 2：$R_3\leftarrow R_3-\frac{3}{2}R_2$（性质 4，**不变号**）：

$$\begin{bmatrix}1&1&1\\0&2&5\\0&0&-3-\frac{3}{2}\cdot 5\end{bmatrix}=\begin{bmatrix}1&1&1\\0&2&5\\0&0&-\frac{21}{2}\end{bmatrix}$$

验算：$3-\frac{3}{2}\cdot 2=0$，$-3-\frac{3}{2}\cdot 5=-3-7.5=-10.5=-\frac{21}{2}$。✓

步骤 3：全程无交换行（$k=0$），故

$$\det A=1\times 2\times\left(-\tfrac{21}{2}\right)=-21.$$

核对：沿第一行余子式展开，

$$C_{11} = +\det\begin{bmatrix}2 & 5\\ 5 & -1\end{bmatrix} = -2-25 = -27, \quad C_{12} = -\det\begin{bmatrix}0 & 5\\ 2 & -1\end{bmatrix} = -(0-10) = 10,$$

$$C_{13} = +\det\begin{bmatrix}0 & 2\\ 2 & 5\end{bmatrix} = 0-4 = -4,$$

$$\det A = 1\cdot(-27) + 1\cdot 10 + 1\cdot(-4) = -21. \checkmark$$

注：这个矩阵就是讲次 20 的主算例 W，$\det W = -21$，$|\det W| = 21$ 将是它的列向量张成的平行六面体体积。

Q4. （计算题）设

$$C = \begin{bmatrix}0 & 2 & 1\\ 3 & 1 & 4\\ 2 & 5 & 1\end{bmatrix}.$$

用消元法（含必要的行交换）求 $\det C$，写出交换次数与主元，并说明如果漏记交换符号会得到什么错误答案。

▸ **答案**

步骤 1：$c_{11} = 0$，必须换行。 $R_1 \leftrightarrow R_2$（第 1 次交换，符号因子 -1）：

$$\begin{bmatrix}3 & 1 & 4\\ 0 & 2 & 1\\ 2 & 5 & 1\end{bmatrix}$$

步骤 2：$R_3 \leftarrow R_3 - \frac{2}{3}R_1$（行相加，不变号）：

$$(2,5,1) - \tfrac{2}{3}(3,1,4) = \left(0,\ 5-\tfrac{2}{3},\ 1-\tfrac{8}{3}\right) = \left(0,\tfrac{13}{3},-\tfrac{5}{3}\right).$$

$$\begin{bmatrix}3 & 1 & 4\\ 0 & 2 & 1\\ 0 & \frac{13}{3} & -\frac{5}{3}\end{bmatrix}$$

步骤 3：$R_3 \leftarrow R_3 - \frac{13}{6}R_2$（行相加，不变号）：

$$\left(0,\tfrac{13}{3},-\tfrac{5}{3}\right) - \tfrac{13}{6}(0,2,1) = \left(0,\ 0,\ -\tfrac{5}{3}-\tfrac{13}{6}\right) = \left(0,0,-\tfrac{23}{6}\right).$$

$$\begin{bmatrix}3 & 1 & 4\\ 0 & 2 & 1\\ 0 & 0 & -\frac{23}{6}\end{bmatrix} = U$$

步骤 4：主元之积与符号。 主元 $d_1 = 3$，$d_2 = 2$，$d_3 = -\frac{23}{6}$，乘积 $= 3\cdot 2\cdot\left(-\frac{23}{6}\right) = -23$。交换次数 $k = 1$，故

$$\det C = (-1)^1\cdot(-23) = +23.$$

验证：沿第 1 列展开。C 的第 1 列是 $(0,3,2)^{\mathsf{T}}$，有**两个**非零元，所以展开式保留两项：

$$M_{11} = \begin{bmatrix}1 & 4\\ 5 & 1\end{bmatrix} \Rightarrow \det = 1-20 = -19 \Rightarrow C_{11} = -19 \ (\text{但 } c_{11}=0\text{，该项不参与}),$$

$$M_{21} = \begin{bmatrix}2 & 1\\ 5 & 1\end{bmatrix} \Rightarrow \det = 2-5 = -3 \Rightarrow C_{21} = -(-3) = +3,$$

$$M_{31} = \begin{bmatrix}2 & 1\\ 1 & 4\end{bmatrix} \Rightarrow \det = 8-1 = 7 \Rightarrow C_{31} = +7,$$

$$\det C = 0\cdot(-19) + 3\cdot 3 + 2\cdot 7 = 9+14 = 23. \checkmark$$

> **若漏记交换符号**，会报 $\det C = -23$：**符号完全反了**。虽然 $|\det|$ 正确（体积仍然是 23），可逆性判断也不受影响，但**定向判断出错**——若这是某物理系统中的坐标变换，右手系会被误报成左手系。
>
> **关键教训**："某行/列只有 k 个非零元"时，展开式只有 k 项，但必须先数清 k 是多少。 本题第 1 列有两个非零元，只算 $c_{21} = 3$ 那一项会得到错误答案 9。

Lecture 19: Determinant Formulas and Cofactors

概述

上一讲用三条公理**抽象地**定义了行列式，并证明了它可以用消元法算出。本讲要回答两个"落地"的问题：**能不能写出 $\det A$ 的显式公式？** 以及 **既然有 n^3 的消元法，为什么还要学 $O(n!)$ 的大公式和余子式展开？** 答案分两层：显式公式（big formula）揭示行列式的**结构**——它是 $n!$ 个"每行每列各取一个元素"的乘积之和，符号由排列的奇偶性决定；而余子式（cofactor）展开则把 n 阶行列式化归为 n 个 $n-1$ 阶行列式，是**代数推导**（求逆矩阵公式、Cramer 法则、特征多项式）的发动机。

本讲的定位：它是讲次 18 的"展开"，也是讲次 20 的"弹药库"——没有余子式，就写不出 $A^{-1} = C^{\mathsf{T}}/\det A$。同时在讲次 21，我们会用 $\det(A - \lambda I)$ 的多项式展开求特征值，那也是余子式展开的直接应用。

核心概念的几何直觉

大公式（the big formula）——行列式是 $n!$ 项乘积的带符号求和

- **定义与目的**：对 $n \times n$ 矩阵 A，

$$\det A = \sum_{\text{所有排列 } (\alpha,\beta,\dots,\omega)} (-1)^{\text{inv}(\alpha,\beta,\dots,\omega)}\, a_{1\alpha} a_{2\beta} \cdots a_{n\omega}.$$

这里 $(\alpha,\beta,\dots,\omega)$ 是 $(1,2,\dots,n)$ 的一个排列，求和共有 $n!$ 项；inv 是逆序数（inversion number）。每一行恰好取一个元素、每一列恰好取一个元素——这叫**每行每列各取一个**，因为若两行取自同一列，那个项必然可以被拆成"含重复列的项"，而重复列的行列式为 0（讲次 18 性质 3）。 – **几何直觉（它在空间中是什么样子？）**：$\det$ 只是"盒子的有向体积"。大公式说的是：体积这个量可以**完全拆解**成沿每个坐标轴各取一个分量、乘起来、再加权求和。正项的贡献是"右手系"的那一半，负项是"左手系"的那一半。$n!$ 项恰好对应 n 个坐标轴的**所有配对方式**（$n!$ 个排列 = 把输入坐标轴分配给输出坐标轴的方案数）。 – **具体示例**：$n = 2$，只有两个排列 $(1,2)$ 与 $(2,1)$。$\text{inv}(1,2) = 0$（偶），$\text{inv}(2,1) = 1$（奇），所以

$$\det \begin{bmatrix} a & b \\ c & d \end{bmatrix} = +ad - bc.$$

这就是我们熟知的公式，它来自大公式，不是天上掉下来的。

逆序数（inversion number）——符号的机械判定法

- **定义与目的**：给定排列 $(\alpha,\beta,\dots,\omega)$，逆序数 = 数对 $(i<j)$ 但 $\alpha_i > \alpha_j$ 的个数。若为偶数，符号 $+1$；若为奇数，符号 -1。
- **几何直觉**：逆序数就是"把这个排列通过相邻交换还原成 $(1,2,\dots,n)$ 所需的最少交换次数"。每做一次相邻交换，右手系翻成左手系一次，符号翻转一次。所以**奇偶性 = 定向翻转的次数的奇偶**。
- **具体示例**：排列 $(2,3,1)$：数对 $(1,2)$：$2<3$ 无序；$(1,3)$：$2>1$ 逆序；$(2,3)$：$3>1$ 逆序。逆序数 $=2$，偶，符号 $+1$。经验检验：$(2,3,1) \to (2,1,3) \to (1,2,3)$，两次相邻交换，偶。✓

排列、置换矩阵与"为什么恰好是 $n!$ 项"

- **定义与目的**：大公式的求和指标是**排列**（permutation）：把 $(1,2,\dots,n)$ 重新排一次的所有方式，共 $n!$ 种。每个排列 $(\alpha,\beta,\dots,\omega)$ 对应一个**置换矩阵** P：第 1 行在 α 列取 1，第 2 行在 β 列取 1，依此类推。于是大公式可以写成**极简形式**

$$\det A = \sum_{P} (-1)^{\text{inv}(P)}\, a_{1,P(1)} a_{2,P(2)} \cdots a_{n,P(n)}, \qquad \text{而 } (-1)^{\text{inv}(P)} = \det P.$$

即：**每一项 = "按某种配对方式取出的 n 个元素之积" × "该配对对应置换矩阵的行列式"**。 – **几何直觉**：置换矩阵是"把坐标轴重新指派"的操作，它只做旋转/反射，不改变体积，所以 $|\det P| = 1$。大公式的思想是：**把 A 分解成 $n!$ 个"置换矩阵的变形"之和**，每个变形的体积是 $\pm$(对角元之积)，加起来就是 A 的体积。$n!$ 项的来源也可以这样看：n 个输入轴要一一对应到 n 个输出轴，配对方式恰有 $n!$ 种。 – **具体示例**：$n = 3$ 的 6 个排列与它们的置换矩阵。

```
n = 3 的 6 个排列 <-> 6 个置换矩阵 <-> 符号

排列(1,2,3)          排列(2,3,1)          排列(3,1,2)
inv = 0, 符号 +       inv = 2, 符号 +       inv = 2, 符号 +
[1 0 0]               [0 1 0]               [0 0 1]
[0 1 0]               [0 0 1]               [1 0 0]     <- 这三个是偶置换
[0 0 1]               [1 0 0]               [0 1 0]        保持定向 (det = +1)

排列(1,3,2)          排列(2,1,3)          排列(3,2,1)
inv = 1, 符号 -       inv = 1, 符号 -       inv = 3, 符号 -
[1 0 0]               [0 1 0]               [0 0 1]
[0 0 1]               [1 0 0]               [0 1 0]     <- 这三个是奇置换
[0 1 0]               [0 0 1]               [1 0 0]        翻转定向 (det = -1)

三个正项（偶排列）              三个负项（奇排列）
+ a11 a22 a33                  - a11 a23 a32
+ a12 a23 a31                  - a12 a21 a33
+ a13 a21 a32                  - a13 a22 a31
   ^ 主对角线方向                ^ 副对角线方向
```

- **奇偶性计数的小规律**：n 个元素的全排列中，偶排列与奇排列**恰好各占一半**，都是 $n!/2$ 个。$n=3$ 时 $3!/2=3$；这正是上面"三正三负"的原因。$n \geq 2$ 时 $n!$ 必为偶数——**"正项与负项一样多"是行列式能出现"恰好抵消"（如秩 1 矩阵）的结构原因。**

$n=3$ 的六项与 Sarrus 法则

- **定义与目的**：$3!=6$ 个排列，三个偶排列（符号 $+$）、三个奇排列（符号 $-$）：

$$(1,2,3),\ \text{inv}=0; \qquad (2,3,1),\ \text{inv}=2; \qquad (3,1,2),\ \text{inv}=2 \quad (\text{偶},\ +)$$

$$(1,3,2),\ \text{inv}=1; \qquad (2,1,3),\ \text{inv}=1; \qquad (3,2,1),\ \text{inv}=3 \quad (\text{奇},\ -)$$

于是

$$\det A = a_{11}a_{22}a_{33} + a_{12}a_{23}a_{31} + a_{13}a_{21}a_{32} - a_{11}a_{23}a_{32} - a_{12}a_{21}a_{33} - a_{13}a_{22}a_{31}.$$

前三个是**主对角线方向**（向右下延伸并回卷）的三条"斜线"乘积，后三个是**副对角线方向**的三条。这就是 Sarrus 法则（对角线法则）。 – **几何直觉**：六项 = 把三个坐标轴 x, y, z 分别"指派"给三行/三列的 6 种方式；正斜线三条保持定向，负斜线三条翻转定向。3×3 恰好能用"斜线"画出来，纯属 3 这个数太小带来的巧合。 – **具体示例**：$A=\begin{bmatrix}2&3&1\\4&7&2\\1&1&1\end{bmatrix}$，六项逐项列出：

$$\begin{aligned}
&+a_{11}a_{22}a_{33} = 2\cdot 7\cdot 1 = 14,\\
&+a_{12}a_{23}a_{31} = 3\cdot 2\cdot 1 = 6,\\
&+a_{13}a_{21}a_{32} = 1\cdot 4\cdot 1 = 4,\\
&-a_{11}a_{23}a_{32} = -(2\cdot 2\cdot 1) = -4,\\
&-a_{12}a_{21}a_{33} = -(3\cdot 4\cdot 1) = -12,\\
&-a_{13}a_{22}a_{31} = -(1\cdot 7\cdot 1) = -7.
\end{aligned}$$

求和：$14+6+4-4-12-7=1$。与上一讲消元法、余子式展开得到的 $\det A=1$ **完全一致**。✓

余子式（cofactor）与代数余子式展开

- **定义与目的**：删去 A 的第 i 行和第 j 列，剩下的 $(n-1)\times(n-1)$ 矩阵记作 M_{ij}，称为**子矩阵**；它的行列式 $\det M_{ij}$ 叫**余子式**（minor）。带上棋盘符号后得到**代数余子式**

$$C_{ij} = (-1)^{i+j}\det M_{ij}.$$

沿第 i 行展开：

$$\det A = \sum_{j=1}^{n} a_{ij}C_{ij}.$$

沿第 j 列展开同理：$\det A=\sum_{i=1}^{n} a_{ij}C_{ij}$。**沿任一行或任一列展开结果都相同**，这是本讲最重要的实用性质。 – **几何直觉**：$a_{ij}C_{ij}$ 是"第 i 行取第 j 列的那个分量"对总体积的贡献。删掉第 i 行第 j 列之后的 $(n-1)$ 阶行列式，正是"固定了这一个坐标方向后，剩下 $n-1$ 个方向张成的'底'的体积"。符号 $(-1)^{i+j}$ 则是棋盘式的定向修正。把行写成 $\sum_j a_{ij}\mathbf{e}_j$ 并用行线性拆开，就得到这个求和——这就是下面【计算机制解说】的内容。 – **具体示例**：$A=\begin{bmatrix}2&3&1\\4&7&2\\1&1&1\end{bmatrix}$ 沿第一行：$C_{11}=+5$，$C_{12}=-2$，$C_{13}=-3$，故 $\det A=2(5)+3(-2)+1(-3)=1$。✓

余子式展开为什么成立——把 det 按行线性"劈开"

- **定义与目的**：这是本讲最需要"讲穿"的机制。目标：从"对第一行线性"这一个事实，推出 $\det A=\sum_j a_{1j}C_{1j}$。整个推导不需要任何公式记忆，纯粹是"拆解 + 归零"。
- **几何直觉**：把第一行这个向量拆成 n 个坐标方向上的份量之和。每一份对应"把第一行的贡献完全集中到某一列"，此时矩阵的行列式（体积）就等于 a_{1j} 乘以"删掉第一行第 j 列后剩余方向张成的体积"——后者带一个符号修正，因为那一列被搬到了"最左边"。
- **具体示例 / 推导**：取 $n=3$ 的 $A=(a_{ij})$。记 A 的三行为 $\mathbf{r_1},\mathbf{r_2},\mathbf{r_3}$，并把第一行写成

$$\mathbf{r_1}=a_{11}\mathbf{e_1}+a_{12}\mathbf{e_2}+a_{13}\mathbf{e_3},\qquad \mathbf{e_j}=\text{第 }j\text{ 个单位行向量}.$$

由**对第一行线性**（公理 3）：

$$\det A=\sum_{j=1}^{3}a_{1j}\det\begin{bmatrix}\mathbf{e_j}\\ \mathbf{r_2}\\ \mathbf{r_3}\end{bmatrix}.$$

现在处理每个小行列式 $\det\begin{bmatrix}\mathbf{e_j}\\ \mathbf{r_2}\\ \mathbf{r_3}\end{bmatrix}$。用**列交换**把 $\mathbf{e}_j$ 所在的那一列搬到第 1 列（每次列交换变号一次，而 $\det$ 对列与对行同样成立，见讲次 18 性质 10）：
- $j=1$：不用搬动，$\det\begin{bmatrix}\mathbf{e_1}\\ \mathbf{r_2}\\ \mathbf{r_3}\end{bmatrix}=+\det\begin{bmatrix}1&0&0\\ \cdot&\cdot&\cdot\\ \cdot&\cdot&\cdot\end{bmatrix}$，沿第 1 行展开得 $+1\cdot\det M_{11}$。
- $j=2$：把第 2 列与第 1 列交换，得符号 -1，所以 $=-1\cdot\det M_{12}$。
- $j=3$：把第 3 列依次与第 2、第 1 列交换，共两次，符号 $+1$，所以 $=+1\cdot\det M_{13}$。

注意这里的符号 $(-1)^{1+j}$ 是怎么来的：它就是把"第 j 列搬到第 1 列"所需的列交换次数。 $j=1$ 需 0 次，$j=2$ 需 1 次，$j=3$ 需 2 次——正是 $(-1)^{j-1}=(-1)^{1+j}$。于是

$$\det A=a_{11}\det M_{11}-a_{12}\det M_{12}+a_{13}\det M_{13}=\sum_j a_{1j}C_{1j}.$$

对第 i 行做同样推导（把第 i 行搬到第一行的位置，代价是 $(-1)^{i-1}$，再和 $(-1)^{1+j}$ 合并成 $(-1)^{i+j}$），就得到一般公式。**这就是棋盘符号的由来，它不是"约定"，而是"搬运列的交换次数"。**

行列式作为"n 重交错线性形式"——本讲的代数身份

- **定义与目的**：把所有 $n\times n$ 矩阵看成 n 个行向量 $(\mathbf{r_1},\dots,\mathbf{r_n})$ 组成的 n 元组，则 $\det$ 是一个函数

$$\det:\ (\mathbb{R}^n)^n\to\mathbb{R},$$

满足三条：(i) 对**每个**变量线性（"n 重线性"）；(ii) 交换任意两个变量改变符号（"交错"）；(iii) $\det(\mathbf{e_1},\dots,\mathbf{e_n})=1$（"归一"）。**这三条正是讲次 18 的三条公理——现在换了一个更专业的名字。** – **几何直觉**：n 重线性 = 体积对每条边分别线性（底固定时高线性）；交错 = 两条边重合时体积为 0（压扁）；归一 = 单位盒子体积 1。**这三条几何要求恰好刻画体积**，所以在 $\mathbb{R}^n$ 上"体积"这个几何概念与"行列式"这个代数对象是**同一件事的两个名字**。 – **具体示例**：交错性直接给出"两行相同 $\Rightarrow 0$"和"一行加到另一行不变"：

$$\det(\dots,\mathbf{r_i}+t\mathbf{r_j},\dots,\mathbf{r_j},\dots)=\det(\dots,\mathbf{r_i},\dots,\mathbf{r_j},\dots)+\underbrace{t\det(\dots,\mathbf{r_j},\dots,\mathbf{r_j},\dots)}_{=0\ (\text{交错})}.$$

一行推导同时得到两条性质——这就是"用结构代替记忆"的威力。 – **为什么这很重要**：一旦知道 $\det$ 是**唯一的** n 重交错线性形式（相差一个归一常数），凡是满足这三条的公式就自动是 $\det$。讲次 20 的"体积 = $|\det|$"、讲次 29 的"$\prod\sigma_i=|\det|$"，都可以用这个唯一性一句话证明，而不必写坐标展开。

特殊矩阵的行列式速查

- **定义与目的**：把常见结构一次记牢，避免每次重算。
- **上/下三角矩阵**：$\det=\prod_i a_{ii}$（对角元之积）。证明用大公式：只有排列 $(1,2,\dots,n)$ 能取出全非零项（上三角里 $a_{ij}=0$ 当 $i>j$，一旦某列选了上面的行就会被迫选到 0）。
- **对角矩阵**：$\det=\prod_i d_i$，是三角的特例。
- **置换矩阵 P**：$\det P=\pm1$，符号 = 该置换的逆序数奇偶，也等于把 P 变回 I 所需交换次数的奇偶。
- **秩 1 矩阵**（$A=\mathbf{u}\mathbf{v}^{\mathsf T}$，所有行都是 $\mathbf{v}^{\mathsf T}$ 的倍数）：当 $n\ge 2$ 时 $\det A=0$。
- **反对称矩阵**（$A^{\mathsf T}=-A$，n 为奇数）：$\det A=\det(A^{\mathsf T})=\det(-A)=(-1)^n\det A=-\det A\Rightarrow\det A=0$。
- **几何直觉**：秩 1 矩阵把所有输入压到一条直线上——一条线没有面积、没有体积，所以 $n\ge 2$ 时 $\det=0$。置换矩阵不改变体积（$|\det|=1$），只可能翻转定向。
- **具体示例**：

$$\det\begin{bmatrix}1&2&3\\2&4&6\\5&10&15\end{bmatrix}=0\ (\text{秩}\ 1),\qquad \det\begin{bmatrix}2&3&1\\0&1&0\\0&0&\frac{1}{2}\end{bmatrix}=\tfrac{1}{2}\cdot 1\cdot 2\ (\text{换成对角元之积})=1.$$

计算步骤与手算演示

示例 1：大公式六项全展开（含符号表）

矩阵仍是

$$A=\begin{bmatrix}2&3&1\\4&7&2\\1&1&1\end{bmatrix}.$$

步骤 1：列出全部 $3!=6$ 个排列，标出逆序数与符号。

排列 (α,β,ω)	对应乘积	逆序数	符号	数值
$(1,2,3)$	$a_{11}a_{22}a_{33}$	0	$+$	$2\cdot 7\cdot 1=14$
$(2,3,1)$	$a_{12}a_{23}a_{31}$	2	$+$	$3\cdot 2\cdot 1=6$
$(3,1,2)$	$a_{13}a_{21}a_{32}$	2	$+$	$1\cdot 4\cdot 1=4$
$(1,3,2)$	$a_{11}a_{23}a_{32}$	1	$-$	$-2\cdot 2\cdot 1=-4$
$(2,1,3)$	$a_{12}a_{21}a_{33}$	1	$-$	$-3\cdot 4\cdot 1=-12$
$(3,2,1)$	$a_{13}a_{22}a_{31}$	3	$-$	$-1\cdot 7\cdot 1=-7$

步骤 2：求和。 $14+6+4-4-12-7=1$。

步骤 3：用 Sarrus 法则作图核对。

```
Sarrus 法则：3x3 的三条正斜线（+）与三条负斜线（−）

     col1  col2  col3 | col1  col2        col1  col2  col3 | col1  col2
row1 [ 2    3     1  ]  2     3     row1 [ 2    3     1  ]  2     3
row2 [ 4    7     2  ]  4     7     row2 [ 4    7     2  ]  4     7
row3 [ 1    1     1  ]  1     1     row3 [ 1    1     1  ]  1     1
       \    \    \                        /    /    /
        \    \    \                      /    /    /

正项（右下方向，共 3 条）：            负项（左下方向，共 3 条）：
  2*7*1 = 14                              1*7*1 =  7   -> -7
  3*2*1 =  6                              3*4*1 = 12   -> -12
  1*4*1 =  4                              2*2*1 =  4   -> -4
  ------------                            ---------------
  sum = 24                                sum = 23

det = 24 - 23 = 1
```

步骤 4：与消元法对照。 上一讲已算：消元得 $U=\begin{bmatrix}2&3&1\\0&1&0\\0&0&\frac{1}{2}\end{bmatrix}$，主元之积 $2\cdot 1\cdot\frac{1}{2}=1$。✓

【计算机制解说】：为什么大公式与消元法必然一致？两者都只是三条公理的推论，而**满足三条公理的函数只有一个**。更具体地看：大公式其实可以"反着"推导出来。取 $\det$ 对第一行线性，把第一行写成 $\sum_j a_{1j}\mathbf{e}_j$：

$$\det A=\sum_{j=1}^{n}a_{1j}\det\begin{bmatrix}\mathbf{e}_j\\\text{row}_2\\\vdots\\\text{row}_n\end{bmatrix}.$$

再用第二行线性把每个 $n-1$ 阶问题继续拆，最终得到 $n!$ 项，每项形如 $a_{1\alpha}a_{2\beta}\cdots$。而把 $\begin{bmatrix}\mathbf{e}_\alpha\\\mathbf{e}_\beta\\\vdots\end{bmatrix}$ 用行交换还原成 I 需要 $\text{inv}(\alpha,\beta,\ldots)$ 次交换，每次变号一次，所以符号是 $(-1)^{\text{inv}}$。**大公式 = 反复使用行线性的结果，消元法 = 反复使用"行相加不变 + 交换变号"的结果；两条路都在同三条公理之内，必然同值。** 有趣的是，二者的成本完全不同：大公式 $O(n!)$，消元 $O(n^3)$。

示例 2：同一个矩阵，换两行/两列做余子式展开

步骤 1：沿第一行展开（回顾，含每个 2×2 的算术）。

$$\det M_{11}=\begin{vmatrix}7 & 2\\ 1 & 1\end{vmatrix}=7-2=5\Rightarrow C_{11}=+5,$$

$$\det M_{12}=\begin{vmatrix}4 & 2\\ 1 & 1\end{vmatrix}=4-2=2\Rightarrow C_{12}=-2,$$

$$\det M_{13}=\begin{vmatrix}4 & 7\\ 1 & 1\end{vmatrix}=4-7=-3\Rightarrow C_{13}=+(-3)=-3,$$

$$\det A=2(5)+3(-2)+1(-3)=10-6-3=1.$$

步骤 2：改沿第二行展开。 第 2 行是 $(4,7,2)$，对应符号为 $(-,+,-)$：

$$\det M_{21}=\begin{vmatrix}3 & 1\\ 1 & 1\end{vmatrix}=3-1=2\Rightarrow C_{21}=-2,$$

$$\det M_{22}=\begin{vmatrix}2 & 1\\ 1 & 1\end{vmatrix}=2-1=1\Rightarrow C_{22}=+1,$$

$$\det M_{23}=\begin{vmatrix}2 & 3\\ 1 & 1\end{vmatrix}=2-3=-1\Rightarrow C_{23}=-(-1)=+1,$$

$$\det A=4(-2)+7(1)+2(1)=-8+7+2=1.\ \checkmark$$

步骤 3：改沿第二列展开。 第 2 列是 $(3,7,1)$，符号 $(+,-,+)$：

$$C_{12}=-2,\qquad C_{22}=+1,\qquad \det M_{32}=\begin{vmatrix}2 & 1\\ 4 & 2\end{vmatrix}=4-4=0\Rightarrow C_{32}=-0=0,$$

$$\det A=3(-2)+7(1)+1(0)=-6+7=1.\ \checkmark$$

步骤 4：沿第三列展开（再验一次）。 第 3 列是 $(1,2,1)$，符号 $(+,-,+)$：

$$\det M_{13}=-3\Rightarrow C_{13}=-3,\quad \det M_{23}=\begin{vmatrix}2 & 3\\ 1 & 1\end{vmatrix}=-1\Rightarrow C_{23}=+1,\quad \det M_{33}=\begin{vmatrix}2 & 3\\ 4 & 7\end{vmatrix}=14-12=2\Rightarrow C_{33}=+2,$$

$$\det A=1(-3)+2(1)+1(2)=-3+2+2=1.\ \checkmark$$

```
沿任意行 / 任意列展开的结果汇总（全部 = 1）

                  col1     col2     col3
                +-------+---------+-------+
   row1  (2,3,1) |  +5   |   -2    |  -3   |   -> 2(5)+3(-2)+1(-3)   =  1
                +-------+---------+-------+
   row2  (4,7,2) |  -2   |   +1    |  +1   |   -> 4(-2)+7(1)+2(1)    =  1
                +-------+---------+-------+
   row3  (1,1,1) |  -1   |    0    |  +2   |   -> 1(-1)+1(0)+1(2)    =  1
                +-------+---------+-------+

列和（沿列展开）：   col1: 2(+5)+4(-2)+1(-1) = 10-8-1  = 1
                    col2: 3(-2)+7(+1)+1(0)  = -6+7    = 1
                    col3: 1(-3)+2(+1)+1(+2) = -3+2+2  = 1

棋盘符号 (-1)^(i+j)：         + - +
                              - + -
                              + - +
行列式对"行"与"列"完全对称 —— det(A^T) = det(A) 的又一体现。
```

【计算机制解说】：为什么"沿任一行展开都得到同一个数"？关键在于**非本行的行，与代数余子式的"错位求和"恒为 0**。设 $i\neq k$，则

$$\sum_{j=1}^{n}a_{kj}C_{ij}=0.$$

原因：这个和等于把一个"第 k 行被替换成第 i 行、第 i 行保持原样"的矩阵的行列式——那个矩阵有**两行相同**，所以行列式为 0（讲次 18 性质 2）。因此

$$\det A=\sum_{j}a_{ij}C_{ij}\quad\text{而}\quad 0=\sum_{j}a_{kj}C_{ij}\ (k\neq i),$$

合起来写成矩阵形式就是后面要用的**关键恒等式**

$$A\,C^{\mathsf T} = (\det A) I,$$

其中 $C = (C_{ij})$ 是代数余子式矩阵。这正是讲次 20 逆矩阵公式 $A^{-1} = C^{\mathsf T}/\det A$ 的全部代数内容。

示例 3：秩 1 矩阵的零行列式（证明 + 几何）

步骤 1：具体算例。 取

$$R = \begin{bmatrix} 1 & 2 & 3 \\ 2 & 4 & 6 \\ 5 & 10 & 15 \end{bmatrix}, \qquad \text{每一行都是 } \mathbf{v}^{\mathsf T} = (1,2,3) \text{ 的倍数.}$$

步骤 2：消元看主元。 $R_2 \leftarrow R_2 - 2R_1$ 得 $\begin{bmatrix} 1 & 2 & 3 \\ 0 & 0 & 0 \\ 5 & 10 & 15 \end{bmatrix}$，出现零行，所以 $\det R = 0$（讲次 18 性质 5）。

步骤 3：大公式看符号抵消。 六个排列的项：

$$(1,2,3):+1\cdot 4\cdot 15 = +60, \quad (2,3,1):+2\cdot 6\cdot 5 = +60, \quad (3,1,2):+3\cdot 2\cdot 10 = +60,$$

$$(1,3,2):-1\cdot 6\cdot 10 = -60, \quad (2,1,3):-2\cdot 2\cdot 15 = -60, \quad (3,2,1):-3\cdot 4\cdot 5 = -60.$$

三正 $+180$ 与三负 -180 精确抵消：$\det R = 0$。这种"对称抵消"是秩 1 结构的必然结果。

步骤 4：一般证明。 若 $A = \mathbf{u}\mathbf{v}^{\mathsf T}$（$\mathbf{u},\mathbf{v} \in \mathbb{R}^n$），则 A 的每一行都是 $\mathbf{v}^{\mathsf T}$ 的倍数。由行线性（对"倍数"部分），

$$\det A = u_1 \det \begin{bmatrix} \mathbf{v}^{\mathsf T} \\ u_2\mathbf{v}^{\mathsf T} \\ \vdots \end{bmatrix} = \cdots = u_1 u_2 \cdots u_n \det \begin{bmatrix} \mathbf{v}^{\mathsf T} \\ \mathbf{v}^{\mathsf T} \\ \vdots \\ \mathbf{v}^{\mathsf T} \end{bmatrix}.$$

最后那个矩阵**每一行都相同**，由性质 2（交换任意两行变号但矩阵不变 $\Rightarrow \det = -\det \Rightarrow \det = 0$，仅当 $n \geq 2$ 时存在"另一行"），所以 $\det A = 0$。（$n = 1$ 时"两行相同"无从谈起，1×1 的 uv 行列式就是 $uv \neq 0$。）

步骤 5：几何直觉。 $A = \mathbf{u}\mathbf{v}^{\mathsf T}$ 把任意 $\mathbf{x}$ 送到 $\mathbf{u}(\mathbf{v}^{\mathsf T}\mathbf{x})$——**所有输出都落在同一条直线 $\operatorname{span}(\mathbf{u})$ 上**。n 维空间被压成一条线，$n \geq 2$ 时"体积"必然为 0。等价说法：$\operatorname{rank}(A) = 1$，$N(A)$ 是 $n-1$ 维的（超平面），四个基本子空间中 $C(A)$ 只有一维。

【计算机制解说】：上面证明之所以成立，靠的是"**两行相同 $\Rightarrow$ 行列式为 0**"这条性质在 $n \geq 2$ 时可用。请注意这个条件的尖锐性：性质 2 的论证是"交换这两行，矩阵没变，但 $\det$ 应变号，故 $\det = -\det$，于是 $2\det = 0$"。在 $n = 1$ 时根本没有"另一行"，论证失效，而 1×1 矩阵的行列式确实非零（就是那个数本身）。**每次用"两行相同"这条性质时，都要心里确认 $n \geq 2$。**

示例 4：4×4 展开 vs 消元——把"代价差距"算成数字

取一个刻意设计的 4×4 矩阵，让它既有可手算的结构、又能显示 $n!$ 的爆炸：

$$D_4 = \begin{bmatrix} 1 & 0 & 2 & 0 \\ 0 & 3 & 0 & 4 \\ 5 & 0 & 6 & 0 \\ 0 & 7 & 0 & 8 \end{bmatrix}.$$

路线 A：沿第 1 行展开（只有 2 个非零元，最省）。

$$D_4 = 1\cdot C_{11} + 2\cdot C_{13}.$$

$$C_{11} = (-1)^{1+1}\begin{vmatrix} 3 & 0 & 4 \\ 0 & 6 & 0 \\ 7 & 0 & 8 \end{vmatrix} = +6\cdot \begin{vmatrix} 3 & 4 \\ 7 & 8 \end{vmatrix} = 6(24-28) = -24,$$

（内层沿第 2 行展开，该行只有 6。）

$$C_{13} = (-1)^{1+3}\begin{vmatrix} 0 & 3 & 4 \\ 5 & 0 & 0 \\ 0 & 7 & 8 \end{vmatrix} = +(-1)^{2+1}\cdot 5\cdot \begin{vmatrix} 3 & 4 \\ 7 & 8 \end{vmatrix} = -5(-4) = 20,$$

（内层沿第 2 行展开，该行只有 5。）

$$D_4 = 1(-24) + 2(20) = 16.$$

路线 B：不利用零元，直接展开成 $4! = 24$ 项（"硬来"）。 对一般稠密 4×4，需要算 24 个四项乘积再加权求和。每个乘积 3 次乘法、加上定符号，总工作量约 $24 \times 4 = 96$ 次算术操作。对比路线 A：两次三阶展开，每次又化归为 2×2，总共约 3 个 2×2 行列式 ≈ 9 次操作。**"选零多的行展开"直接省了约 10 倍。**

路线 C：消元。 见思考题 Q1 的完整逐步（$\frac{2}{3}n^3 \approx 42$ 次运算，且**不依赖零元分布**）。$\det D_4 = 16$。✓

复杂度表（把爆炸写成数字）：

```
n       n!（大公式/余子式）      (2/3)n^3（消元）     比值 n!/(2n^3/3)
---     ------------------      --------------      ----------------
3       6                       18                  0.33
4       24                      42                  0.57
5       120                     83                  1.4
6       720                     144                 5.0
8       40320                   341                 118
10      3,628,800               667                 5441
12      479,001,600             1152                415,835
15      1.3e12                  2250                5.8e8
20      2.43e18                 5333                4.6e14

交叉点大约在 n = 5：n >= 6 之后消元完胜，且差距随 n 指数级拉大。
n = 20 时，大公式的项数是消元运算次数的 4.6e14 倍 ——
即使每秒算 10^9 项，也要 770 万年；而消元不到一毫秒。
```

【计算机制解说】：为什么 n 一过 5 就"消元完胜"？因为 $n!$ 是**超指数**增长（斯特林公式 $n! \approx \sqrt{2\pi n}\,(n/e)^n$），而 $\frac{2}{3}n^3$ 是多项式增长，比值随 n 单调上升。**"O 记号在小 n 时会骗人"**：$n = 3$ 时 $6 < 18$，大公式反而更快；但 $n = 6$ 时已被反超（$720 > 144$）。所以教科书里"用余子式展开算行列式"的例题**只出现在 $n \le 4$**，这是有意为之——它教的是**结构**（哪些项、什么符号、为什么成立），不是**算法**。

实用结论：手算 2×2、3×3 时展开公式优雅且可靠；一旦 $n \ge 4$，一律先找零、再消元。

示例 5：分块三角——余子式展开在多零结构上的"全自动"表现

取一个 4×4 的**分块上三角**矩阵（左上 2×2、右下 2×2，左下角是零块）：

$$M = \begin{bmatrix} 2 & 3 & 1 & 0 \\ 1 & 4 & 2 & 5 \\ 0 & 0 & 1 & 2 \\ 0 & 0 & 0 & 3 \end{bmatrix} = \begin{bmatrix} A & B \\ 0 & D \end{bmatrix}, \qquad A = \begin{bmatrix} 2 & 3 \\ 1 & 4 \end{bmatrix},\ B = \begin{bmatrix} 1 & 0 \\ 2 & 5 \end{bmatrix},\ D = \begin{bmatrix} 1 & 2 \\ 0 & 3 \end{bmatrix}.$$

步骤 1：直接用余子式展开看会发生什么。 M 的第 1 行是 $(2, 3, 1, 0)$，只有 $j = 1, 2, 3$ 非零：

$$C_{11} = (-1)^{1+1} \det \begin{bmatrix} 4 & 2 & 5 \\ 0 & 1 & 2 \\ 0 & 0 & 3 \end{bmatrix} = +4 \cdot 1 \cdot 3 = 12,$$

（内层是上三角，直接读对角元之积 $4 \cdot 1 \cdot 3 = 12$。）

$$C_{12} = (-1)^{1+2} \det \begin{bmatrix} 1 & 2 & 5 \\ 0 & 1 & 2 \\ 0 & 0 & 3 \end{bmatrix} = -(1 \cdot 1 \cdot 3) = -3, \qquad C_{13} = (-1)^{1+3} \det \begin{bmatrix} 1 & 4 & 5 \\ 0 & 0 & 2 \\ 0 & 0 & 3 \end{bmatrix}.$$

最后一个内层的第 2 行是 $(0, 0, 2)$，第 3 行是 $(0, 0, 3)$——**第 1 列全零**，故行列式为 0，$C_{13} = 0$。于是

$$\det M = 2 \cdot 12 + 3 \cdot (-3) + 1 \cdot 0 = 24 - 9 = 15.$$

步骤 2：用分块公式验证。 对分块三角矩阵有一般结论

$$\det \begin{bmatrix} A & B \\ 0 & D \end{bmatrix} = \det A \cdot \det D.$$

这里 $\det A = 2 \cdot 4 - 3 \cdot 1 = 5$，$\det D = 1 \cdot 3 - 2 \cdot 0 = 3$，故 $\det M = 5 \cdot 3 = 15$. ✓

步骤 3：同一矩阵沿不同行展开，结果仍然一致。 沿第 4 行 $(0, 0, 0, 3)$：

$$C_{44} = (-1)^{4+4} \det \begin{bmatrix} 2 & 3 & 1 \\ 1 & 4 & 2 \\ 0 & 0 & 1 \end{bmatrix} = +\left[1 \cdot \left(2 \cdot 4 - 3 \cdot 1\right)\right] = 5,$$

（内层沿第 3 行展开，只有 1。）$\det M = 3 \cdot 5 = 15$. ✓

```
分块三角的"零块"如何让展开自动省力

[ A  B ]      A = 2x2 左上块        D = 2x2 右下块
[ 0  D ]      B = 2x2 右上块        左下 = 0 块

det = det A * det D = 5 * 3 = 15

余子式展开看到的是:
  - 第 1 行第 3 列的子式 M13 的第 1 列全为 0  ->  C13 = 0
  - 第 4 行只有 1 个非零元 (3)                ->  只剩 1 项
"零越多，展开越短" —— 分块三角把 4! = 24 项压到 3 项。

同时，消元法也自动利用这个结构：左下零块不需要消，
主元就是 A 的 2 个主元 与 D 的 2 个主元，乘积 = 15。
```

【计算机制解说】：为什么分块三角的行列式是 $\det A \det D$？两条路都能看穿。**代数路**：$M = \begin{bmatrix} A & B \\ 0 & D \end{bmatrix}$ 可以写成两个矩阵的乘积

$$\begin{bmatrix} A & B \\ 0 & D \end{bmatrix} = \begin{bmatrix} I & B \\ 0 & I \end{bmatrix} \begin{bmatrix} A & 0 \\ 0 & D \end{bmatrix},$$

前者是"分块剪切"（对角块是 I，由 $\det(AB) = \det A \det B$ 及分块三角的行列式性质可知其行列式为 1），后者是分块对角，行列式 $= \det A \det D$。**几何路**：左下零块意味着 D 所覆盖的那些方向不被 A 那一侧扰动，整个平行体可以拆成"两个互相独立的盒子"的乘积；体积自然相乘。**这条结论在大公式和消元两条路上都对，而且是"零结构自动省力"的最好例子。**

矩阵分解的核心思想

本讲没有引入新的矩阵分解，但大公式与余子式展开都与 $A = LU$ 和 $PA = LU$ 深度互补，并且直接服务于讲次 20 的**伴随矩阵恒等式** $A\,C^{\mathsf{T}} = (\det A) I$。

（1）与大公式的关系。 大公式 $n!$ 项给出一个"结构性"的定义：$\det$ 是 n 重交错线性形式（alternating multilinear form）。$A = LU$ 给出一个"算法性"的定义。二者关系是：

$$\det A = \det L \cdot \det U = 1 \cdot \prod_i u_{ii}.$$

L 的行列式恒为 1（单位下三角），所以 $A = LU$ 把"$n!$ 项求和"压成了"读 n 个主元"。这就是为什么实际计算永远选消元。

（2）与余子式的关系：拉普拉斯展开就是"分块消元"。 把矩阵按第一行分块 $A = \begin{bmatrix} \mathbf{a}^{\mathsf{T}} \\ A_1 \end{bmatrix}$（$A_1$ 是前 $n-1$ 行/列），则

$$\det A = \sum_j a_{1j} C_{1j} = \sum_j (-1)^{1+j} a_{1j} \det M_{1j}.$$

这可以看成"先把第一行用列操作消成一个只有一项的样子，再递归"。从计算量角度，余子式展开是递归 $T(n) = nT(n-1) + \Theta(n)$，解得 $T(n) = O(n!)$——与直接大公式同阶。

（3）伴随矩阵（adjugate）恒等式是本讲的"输出产品"。 定义代数余子式矩阵 $C = (C_{ij})$，则转置 C^{T} 称为**伴随矩阵** $\operatorname{adj} A = C^{\mathsf{T}}$。由上一小节【计算机制解说】中的错位求和论证：

$$A \cdot \operatorname{adj} A = (\det A)\, I.$$

这是讲次 20 的起点：只要 $\det A \neq 0$，立刻得到 $A^{-1} = \operatorname{adj} A / \det A$。注意这个公式**在理论上完美，在数值上灾难**：它需要用 n^2 个 $(n-1) \times (n-1)$ 行列式，成本 $O(n!)$；而消元求逆只要 $O(n^3)$。它的价值在**符号推导**（特征多项式、隐函数定理、Cramer 法则）而不在实际计算。

与其他讲次的关联

- **讲次 18（行列式性质）**：本讲是大公式与余子式展开，全部建立在三条公理之上。特别是"行线性"直接给出了大公式的递归拆分，而"两行相同 $\Rightarrow 0$"给出了错位求和恒等式。
- **讲次 20（Cramer / 逆矩阵 / 体积）**：$A \operatorname{adj} A = (\det A) I$ 直接推出 A^{-1} 公式和 Cramer 法则；大公式中的符号 $(-1)^{\text{inv}}$ 也与"定向"概念呼应。
- **讲次 21（特征值）**：$\det(A - \lambda I) = 0$ 需要展开成 λ 的多项式。对 2×2：$\lambda^2 - (\operatorname{tr} A)\lambda + \det A = 0$；对 3×3 用余子式展开；一般地，特征多项式的 λ^{n-1} 系数是 $-\operatorname{tr} A$，常数项是 $(-1)^n \det A$。**本讲的展开技巧马上就会用到：** 对 $A = \begin{bmatrix} 2 & 1 \\ 1 & 3 \end{bmatrix}$，

$$\det(A - \lambda I) = \begin{vmatrix} 2-\lambda & 1 \\ 1 & 3-\lambda \end{vmatrix} = (2-\lambda)(3-\lambda) - 1 = \lambda^2 - 5\lambda + 5,$$

解 $\lambda = \dfrac{5 \pm \sqrt{5}}{2} \approx 3.618,\ 1.382$。**注意**：这两个数与讲次 20 里 A 的奇异值完全相同（因为 A 对称）——特征值与奇异值在对称矩阵处汇合，这是一条重要的交叉验证线索。 – **讲次 29（SVD）**：$\sigma_1\sigma_2\cdots\sigma_n = |\det A|$。大公式告诉我们 $\det$ 是 n 重的乘积之和，SVD 则把它写成 n 个"半轴长度"的乘积——一个和式等于一个积式，这是很漂亮的定理。它的代数路线是 $\prod_i \sigma_i^2 = \det(A^{\mathsf T}A) = (\det A)^2$，而 $\det(A^{\mathsf T}A) = (\det A)^2$ 正是讲次 18 的 $\det(AB) = \det A \det B$ 与 $\det(A^{\mathsf T}) = \det A$ 的合并。 – **讲次 11–12（矩阵空间与图）**：关联矩阵（incidence matrix）的行列式给出生成树计数（矩阵–树定理），其证明用到余子式展开——本讲的技巧在图论里直接变现。

关键要点

1. **大公式**：$\det A = \sum_{\text{排列}} (-1)^{\text{inv}} a_{1\alpha}a_{2\beta}\cdots a_{n\omega}$，共 $n!$ 项，每行每列各取一个元素；符号由逆序数（等价地：相邻交换次数）的奇偶决定。
2. **$n = 3$ 的 Sarrus 法则**：三条右下斜线取 $+$，三条左下斜线取 $-$。**仅对 3×3 有效**，4×4 没有对角线法则。
3. **余子式展开**：$C_{ij} = (-1)^{i+j}\det M_{ij}$，$\det A = \sum_j a_{ij}C_{ij}$（沿**任意**行）$= \sum_i a_{ij}C_{ij}$（沿**任意**列）。棋盘符号 $(-1)^{i+j}$ 必须带上。
4. **符号的本质**：$(-1)^{i+j}$ 不是"约定"，而是"把第 j 列搬到第 1 列、把第 i 行搬到第 1 行所需的交换次数"的奇偶。理解了这一点，就不需要单独背棋盘图。
5. **选行策略**：展开前先找**零最多**的行或列。含 0 的项直接消失；若能找到"只有一个非零元"的行，一次展开就把 n 阶降成 1 个 $(n-1)$ 阶。4×4 例子里沿第 1 行展开只需算 2 个三阶子式。
6. **错位求和恒等式**：$\sum_j a_{kj}C_{ij} = 0$（$k \neq i$）。合起来：$A\,C^{\mathsf T} = (\det A)I$，即 $A\,\mathrm{adj}\,A = (\det A)I$。
7. **复杂度**：大公式与余子式展开是 $O(n!)$（4×4 需 24 项，10×10 需 3.6×10^6 项，20×20 约 2.4×10^{18} 项）；消元法是 $\frac{2}{3}n^3$（$n = 20$ 时约 5300 次运算）。**理论用展开，计算用消元**——交叉点在 $n \approx 5$，之后消元以指数级优势取胜。
8. **特殊结构的速用**：三角/对角 $\Rightarrow$ 对角元之积；置换矩阵 $\Rightarrow \det = \pm 1$；秩 1（$n \geq 2$）$\Rightarrow \det = 0$；奇数阶反对称 $\Rightarrow \det = 0$。这四条能让你在很多题上"看一眼就报答案"。

常见误区与注意事项

1. **把 Sarrus 法则误用到 4×4。** 对角线法则只在 $n = 3$ 成立（$n = 2$ 也可看作两条斜线）。4×4 有 $4! = 24$ 项，需要画出 4 条正/负"广义对角线"，随手画斜线一定漏项或错号。例如

$$\det\begin{bmatrix} 1 & 0 & 2 & 0 \\ 0 & 3 & 0 & 4 \\ 5 & 0 & 6 & 0 \\ 0 & 7 & 0 & 8 \end{bmatrix} = 16,$$

而"斜线法"会给你完全不同的数。正确做法是选一行只有两个非零元（第 1 行有 $1, 2$）做余子式展开：$\det = 1\cdot C_{11} + 2\cdot C_{13} = 1\cdot(+24) + 2\cdot(-20) = 16$。 2. **忘掉棋盘符号 $(-1)^{i+j}$。** 余子式 C_{ij} 与子式 $\det M_{ij}$ 不是一回事，差一个符号。最容易错的是 C_{12}：对 $A = \begin{bmatrix} 2 & 3 & 1 \\ 4 & 7 & 2 \\ 1 & 1 & 1 \end{bmatrix}$，$\det M_{12} = 2$ 但 $C_{12} = -2$。**上标棋盘格要背：** $\begin{matrix} + & - & + \\ - & + & - \\ + & - & + \end{matrix}$。 3. **以为"沿谁展开都一样"所以随便选行。** 结果一样，**代价差很多**。若某行/列有多个 0，就沿它展开——含 0 的项直接消失。例如上面的 4×4，沿第 1 行（两个 0）只需算 2 个三阶行列式，沿第 2 行同样两个 0，但沿第 3 行也只有两个 0；若构造出"某行只有一个非零"的矩阵，一次展开就降成 1 个三阶。 4. **混淆"逆序数"与"排列的循环结构"。** 符号由逆序数奇偶决定，不是由"循环长度"决定。排列 $(2, 3, 1)$ 是一个 3–循环，看起来"很长"，但它的逆序数是 2，符号是 $+$。判断符号最可靠的机械方法：**数逆序对**，或**数把这个排列排回 $(1, 2, \ldots, n)$ 所需的相邻交换次数**。 5. **用大公式去算 4×4 以上的行列式。** 这是概念上正确、实践上错误。10×10 的 3.6 万项、12×12 的 4.8 亿项——手算必错，计算机也慢。**遇到 $n \geq 4$，一律先消元或先找零多的行/列。** 6. **把"子式 M_{ij}"和"代数余子式 C_{ij}"当同一个东西。** $C_{ij} = (-1)^{i+j}\det M_{ij}$，符号必须带上。$3\times 3$ 里 C_{12}、C_{21}、C_{23}、C_{32} 都是负号位；漏一个符号结果就错。**口诀：先用棋盘图定符号，再算子式行列式。** 7. **误以为逆序数只看"排列第一个元素"。** $(2, 3, 1)$ 的第一个元素是 2，看起来"只有一处逆序"，实际逆序数是 2（$(2, 1)$ 与 $(3, 1)$ 两对）。**必须数所有 $i < j$ 且 $\alpha_i > \alpha_j$ 的数对**，不能只扫一眼开头。 8. **以为"行列式 $= 0$ 就说明有零行或零列"。** 秩 1 矩阵 $\begin{bmatrix} 1 & 2 & 3 \\ 2 & 4 & 6 \\ 5 & 10 & 15 \end{bmatrix}$ 没有任何零行零列，$\det = 0$。**奇异的原因是"行/列线性相关"，与"有没有零"无关。** 反过来，$\begin{bmatrix} 1 & 1 & 1 \\ 0 & 0 & 1 \\ 5 & 10 & 15 \end{bmatrix}$ 有两个 0 却 $\det = -5 \neq 0$。 9. **把"每行每列各取一个"误解成"沿对角线取"。** 大公式的项是**任意**排列（如 $a_{13}a_{21}a_{32}$ 是"反对角方向"的取法），不是只沿主对角线。$n = 3$ 恰好把六种取法画成"三条正斜线 + 三条负斜线"，$n = 4$ 就没有这样的视觉巧合了。 10. **混淆"沿行展开"与"沿列展开"得到的 C 与 $C^{\mathsf T}$。** $\det A = \sum_j a_{ij}C_{ij}$ 用的是**行**与**同行**的余子式配对；而 $\mathrm{adj}\,A = C^{\mathsf T}$ 是**列**的排列。这两个索引方向相反，是讲次 20 求逆时最常见的错位来源。 11. **以为"余子式矩阵 C 的行列式等于 $\det A$"或别的简单关系。** 正确的恒等式是 $\det C = (\det A)^{n-1}$（当 $\det A \neq 0$），一般**不等于** $\det A$。对本讲的 $A = \begin{bmatrix} 2 & 3 & 1 \\ 4 & 7 & 2 \\ 1 & 1 & 1 \end{bmatrix}$（$\det A = 1$）：$C = \begin{bmatrix} 5 & -2 & -3 \\ -2 & 1 & 1 \\ -1 & 0 & 2 \end{bmatrix}$，$\det C = 1 = (\det A)^{3-1} = 1^2$ ✓（$\det A = 1$ 时两者恰好相等，容易造成错觉）。取 $\det A \neq 1$ 的例子，$B = \begin{bmatrix} 2 & 0 & 0 \\ 0 & 3 & 0 \\ 0 & 0 & 1 \end{bmatrix}$：$\det B = 6$，$C_B = \begin{bmatrix} 3 & 0 & 0 \\ 0 & 2 & 0 \\ 0 & 0 & 6 \end{bmatrix}$，$\det C_B = 36 = 6^2 \neq 6$。**不要凭直觉编关系。**

思考题（带答案）

Q1. （计算题）用**余子式展开**（选零最多的行或列）求

$$D=\det\begin{bmatrix}1&0&2&0\\0&3&0&4\\5&0&6&0\\0&7&0&8\end{bmatrix}.$$

再用消元法验证。

▸ **答案**

路线 A：沿第 1 行展开。 第 1 行 $(1,0,2,0)$，只有 $j=1,3$ 非零：

$$C_{11}=(-1)^{1+1}\det\begin{bmatrix}3&0&4\\0&6&0\\7&0&8\end{bmatrix},\qquad C_{13}=(-1)^{1+3}\det\begin{bmatrix}0&3&4\\5&0&0\\0&7&8\end{bmatrix}.$$

先算两个三阶子式。第一个沿第 2 行（只有一个非零 6）展开：

$$\det\begin{bmatrix}3&0&4\\0&6&0\\7&0&8\end{bmatrix}=(-1)^{2+2}\cdot 6\cdot\det\begin{bmatrix}3&4\\7&8\end{bmatrix}=6(24-28)=6(-4)=-24.$$

所以 $C_{11}=+(-24)=-24$。第二个沿第 2 行（只有 5）展开：

$$\det\begin{bmatrix}0&3&4\\5&0&0\\0&7&8\end{bmatrix}=(-1)^{2+1}\cdot 5\cdot\det\begin{bmatrix}3&4\\7&8\end{bmatrix}=-5(-4)=20.$$

所以 $C_{13}=+20$。

$$\det D=1\cdot(-24)+0+2\cdot(20)+0=-24+40=16.$$

路线 B：沿第 3 行展开（同样只有两个非零）。 第 3 行 $(5,0,6,0)$：

$$C_{31}=(-1)^{3+1}\det\begin{bmatrix}0&2&0\\3&0&4\\7&0&8\end{bmatrix}=+\left[(-1)^{1+2}\cdot 2\cdot\det\begin{bmatrix}3&4\\7&8\end{bmatrix}\right]=+[-2(-4)]=+8,$$

（内层沿第 1 行展开，只有 $j=2$ 非零。）

$$C_{33}=(-1)^{3+3}\det\begin{bmatrix}1&0&0\\0&3&4\\0&7&8\end{bmatrix}=+\left[1\cdot\det\begin{bmatrix}3&4\\7&8\end{bmatrix}\right]=-4.$$

$$\det D=5\cdot 8+6\cdot(-4)=40-24=16.\ \checkmark$$

路线 C：消元验证。 这一步用来确认前面两次展开没有笔误。

- **交换 $R_2\leftrightarrow R_3$**（第 1 次交换，符号记 -1）：

$$\begin{bmatrix}1&0&2&0\\5&0&6&0\\0&3&0&4\\0&7&0&8\end{bmatrix}$$

- $R_2\leftarrow R_2-5R_1$（行相加，不变号）：$(5,0,6,0)-5(1,0,2,0)=(0,0,-4,0)$，

$$\begin{bmatrix}1&0&2&0\\0&0&-4&0\\0&3&0&4\\0&7&0&8\end{bmatrix}$$

- **交换 $R_2 \leftrightarrow R_3$**（第 2 次交换，符号再乘 -1，合计 $(-1)^2=+1$）：

$$\begin{bmatrix}1&0&2&0\\0&3&0&4\\0&0&-4&0\\0&7&0&8\end{bmatrix}$$

- $R_4 \leftarrow R_4 - \frac{7}{3}R_2$（行相加，不变号）：$(0,7,0,8)-\frac{7}{3}(0,3,0,4)=(0,0,0,8-\frac{28}{3})=(0,0,0,-\frac{4}{3})$，

$$\begin{bmatrix}1&0&2&0\\0&3&0&4\\0&0&-4&0\\0&0&0&-\frac{4}{3}\end{bmatrix}=U.$$

主元之积 $=1\cdot 3\cdot(-4)\cdot\left(-\frac{4}{3}\right)=16$。两次交换使符号为 $(-1)^2=+1$，故

$$\det D=(+1)\cdot 16=16.\ \checkmark$$

三条路线（沿第 1 行展开、沿第 3 行展开、消元）全部给出 16。 这里也顺便演示了消元法**必须记账交换次数**：交换本身把矩阵换掉了，所以要用 $(-1)^k$ 把符号还原回原矩阵。

结论：$\det D=16$。（这道题的价值在于：4×4 必须用展开或消元，斜线法无效。）

Q2. （概念题）设 A 是 $n\times n$ 矩阵。(i) 若 n 为奇数且 $A^{\mathsf T}=-A$（反对称），证明 $\det A=0$。(ii) 若 A 是秩 1 矩阵且 $n\geq 2$，求 $\det A$，并说明 $n=1$ 时为何不同。(iii) 举一个 3×3 秩 1 矩阵的例子，用大公式指出六项如何抵消。

▸ **答案**

(i) 用讲次 18 的性质：$\det A=\det(A^{\mathsf T})=\det(-A)$。又 $(-A)=(-1)\cdot A$，把 n 行各乘 -1，所以 $\det(-A)=(-1)^n\det A$。n 为奇数时 $(-1)^n=-1$，故 $\det A=-\det A$，即 $2\det A=0$，得 $\det A=0$。例：$\begin{bmatrix}0&1\\-1&0\end{bmatrix}$ 是 $n=2$（偶），$\det=2\neq 0$，符合"n 奇"这个条件不可省。

(ii) $A=\mathbf{u}\mathbf{v}^{\mathsf T}$，每行都是 $\mathbf{v}^{\mathsf T}$ 的倍数。用行线性把倍数提出来，剩下一个"每行都等于 $\mathbf{v}^{\mathsf T}$"的矩阵，它有两行相同；由"两行相同 $\Rightarrow\det=0$"（此论证需要一行之外的**另一行**存在，故 $n\geq 2$）得 $\det A=0$。$n=1$ 时 $A=[uv]$，没有"另一行"，行列式 $=uv$，一般非零。

(iii) 取 $\mathbf{u}=(1,2,3)^{\mathsf T}$，$\mathbf{v}=(1,1,1)^{\mathsf T}$：

$$A=\begin{bmatrix}1&1&1\\2&2&2\\3&3&3\end{bmatrix}.$$

六个排列项：$(1,2,3):+1\cdot 2\cdot 3=6$，$(2,3,1):+1\cdot 2\cdot 3=6$，$(3,1,2):+1\cdot 2\cdot 3=6$（三个偶排列合计 $+18$）；
$(1,3,2):-1\cdot 2\cdot 3=-6$，$(2,1,3):-1\cdot 2\cdot 3=-6$，$(3,2,1):-1\cdot 2\cdot 3=-6$（三个奇排列合计 -18）。总和 $18-18=0$。✓ 几何：三行全是 $(1,1,1)$ 的倍数，矩阵把 $\mathbb{R}^3$ 压到直线 $\mathbf{span}\{(1,2,3)\}$ 上，体积为 0。

Q3. （概念题 + 小计算）不展开整个行列式，直接说出下面这个矩阵行列式的值，并说明理由：

$$B=\begin{bmatrix}1&1&1\\2&2&2\\5&10&15\end{bmatrix}.$$

再回答：若把 B 的第 2 行换成 $(0,0,1)$，$\det$ 会变成多少？

▸ 答案

第一部分：$\det B = 0$。 B 的第 1 行是 $(1,1,1)$，第 2 行 $= (1,1,1) \times 2$——两行成比例，$\det B = 0$。（也可以看第 3 行 $= (5,10,15)$，与第 1 行不成比例，但已有两行成比例即够。）

第二部分： 新的矩阵

$$B' = \begin{bmatrix} 1 & 1 & 1 \\ 0 & 0 & 1 \\ 5 & 10 & 15 \end{bmatrix}.$$

沿第 2 行展开（只有一个非零 $a_{23} = 1$）：

$$C_{23} = (-1)^{2+3} \det \begin{bmatrix} 1 & 1 \\ 5 & 10 \end{bmatrix} = -(10 - 5) = -5,$$

$$\det B' = a_{23} C_{23} = 1 \cdot (-5) = -5.$$

（也可以用消元：$R_3 \leftarrow R_3 - 5R_1$ 得 $(0,5,10)$；交换 $R_2 \leftrightarrow R_3$ 变号一次，得 $\begin{bmatrix} 1 & 1 & 1 \\ 0 & 5 & 10 \\ 0 & 0 & 1 \end{bmatrix}$，主元之积 5，符号 -1，故 $\det = -5$。✓）

提醒：常有人看到"有零元"就报 0。**零元不是奇异的原因，行相关性才是。** B' 含两个 0，却 $\det \neq 0$（事实上它可逆）。

Q4. （计算题）设

$$E = \begin{bmatrix} 0 & 2 & 0 & 1 \\ 3 & 0 & 0 & 0 \\ 0 & 0 & 4 & 0 \\ 0 & 1 & 0 & 5 \end{bmatrix}.$$

(a) 用最省力的余子式展开求 $\det E$。(b) 说出它的秩。(c) 若把 E 的 $(1,1)$ 元素改成 7，$\det$ 会变成多少?

▸ 答案

(a) 观察：第 1 行只有 $j = 2, 4$ 非零；第 2 行只有 $j = 1$；第 3 行只有 $j = 3$；第 4 行只有 $j = 2, 4$。选第 2 行展开最省（只有一个非零 3，位于 $(2,1)$）：

$$C_{21} = (-1)^{2+1} \det M_{21} = -\det \begin{bmatrix} 2 & 0 & 1 \\ 0 & 4 & 0 \\ 1 & 0 & 5 \end{bmatrix}.$$

内层再沿第 2 行展开（只有 4，位于 $(2,2)$）：

$$\det \begin{bmatrix} 2 & 0 & 1 \\ 0 & 4 & 0 \\ 1 & 0 & 5 \end{bmatrix} = (-1)^{2+2} \cdot 4 \cdot \det \begin{bmatrix} 2 & 1 \\ 1 & 5 \end{bmatrix} = 4(10 - 1) = 36.$$

所以 $C_{21} = -36$，$\det E = e_{21} C_{21} = 3 \cdot (-36) = -108$。

另一条路线（沿第 3 行）：$C_{33} = (-1)^{3+3} \det M_{33}$，

$$M_{33} = \begin{bmatrix} 0 & 2 & 1 \\ 3 & 0 & 0 \\ 0 & 1 & 5 \end{bmatrix} \Rightarrow \text{沿第 } 2 \text{ 行展开}: (-1)^{2+1} \cdot 3 \cdot \det \begin{bmatrix} 2 & 1 \\ 1 & 5 \end{bmatrix} = -3(9) = -27,$$

$$C_{33} = +(-27) = -27, \qquad \det E = e_{33} C_{33} = 4 \cdot (-27) = -108. \checkmark$$

用大公式抽查：E 的非零元素很少，能取出"全非零项"的排列必须满足：第 2 行取列 1（唯一非零），第 3 行取列 3（唯一非零）；第 1 行只能取列 2 或 4；第 4 行只能取列 2 或 4，且与第 1 行不同列。于是 24 个排列中只剩两个： – $(2,1,3,4)$：逆序对只有 $(2,1)$ 一对，逆序数 $= 1$，**符号 −**，项 $= -e_{12}e_{21}e_{33}e_{44} = -(2 \cdot 3 \cdot 4 \cdot 5) = -120$。 – $(4,1,3,2)$：逆序对为 $(4,1), (4,3), (4,2), (3,2)$，逆序数 $= 4$，**符号 +**，项 $= +e_{14}e_{21}e_{33}e_{42} = +(1 \cdot 3 \cdot 4 \cdot 1) = +12$。

$$\det E = -120 + 12 = -108. \checkmark$$

> （**教训**：数逆序数不能偷懒——$(2,1,3,4)$ 一眼看去"几乎有序"，实际是奇排列。另外注意 24 个排列中只有 2 个贡献非零项，这正是"零元多 $\Rightarrow$ 大公式变便宜"的原因。）
>
> (b) E 的四个列 $(0,3,0,0), (2,0,0,1), (0,0,4,0), (1,0,0,5)$：第 2、3 列显然与第 1、4 列所在的方向不同，且第 1 列 $(0,3,0,0)$ 与第 4 列 $(1,0,0,5)$ 不成比例。四个列线性无关（因为 $\det \neq 0$），所以 $\mathbf{rank}(E) = 4$，E 可逆。
>
> (c) 把 e_{11} 从 0 改成 7 后，多出哪些项？第 1 行取列 1 时，第 2 行必须取列 1 以外的列，但它只有列 1 非零——**所以任何含 e_{11} 的项都必然含一个 0**。因此

$$e_{11} \text{ 的取值不影响 } \det E, \qquad \det E \text{ 仍为 } -108.$$

> （从展开看：$C_{11} = (-1)^{1+1} \det M_{11}$，而 $M_{11} = \begin{bmatrix} 0 & 0 & 0 \\ 0 & 4 & 0 \\ 1 & 0 & 5 \end{bmatrix}$ 的第 1 行全零，故 $C_{11} = 0$，于是 $e_{11}C_{11} = 0$ 无论 e_{11} 是多少。）
>
> **这是一个漂亮的反直觉结论**：改动矩阵的一个元素，未必改变行列式；**只有落在"非零行非零列交汇"处的元素才有影响**——本例中 $(1,1)$ 位置的余子式为 0。

Lecture 20: Cramer's Rule, Inverse Matrix, and Volume

概述

这是行列式三讲连讲的收官。前两讲建立了 $\det$ 的**性质**与**公式**，本讲把它们兑现成三件"产品"：(1) 逆矩阵的显式公式 $A^{-1} = \mathrm{adj}\, A / \det A$；(2) 解线性方程组 $A\mathbf{x} = \mathbf{b}$ 的 Cramer **法则** $x_i = \det A_i / \det A$；(3) 行列式最本质的解释——$|\det A|$ **是体积，符号是定向**。

Strang 把几何解释放在最后压轴，因为它是整个课程里"行列式为什么重要"的最终答案：$\det$ 不是一个为了考试而生的代数技巧，它是**线性变换对体积的缩放因子**。由此，$\det A = 0$ 有了最直观的含义——空间被压扁（降维），所以不可逆；微积分里的换元公式 $dx\,dy = |\det J|\,du\,dv$ 也有了来源；讲次 29 的 SVD 更是把 $\det$ 写成 $\prod_i \sigma_i$，让"体积因子 = 各方向伸缩因子的乘积"变得字面成立。

核心概念的几何直觉

伴随矩阵（adjugate）与逆矩阵公式

- **定义与目的**：设 $C = (C_{ij})$ 是代数余子式矩阵（讲次 19），则**伴随矩阵**定义为它的转置

$$\mathrm{adj}\, A = C^{\mathsf{T}}, \qquad \mathrm{adj}\, A = \begin{bmatrix} C_{11} & C_{21} & \cdots & C_{n1} \\ C_{12} & C_{22} & \cdots & C_{n2} \\ \vdots & \vdots & & \vdots \\ C_{1n} & C_{2n} & \cdots & C_{nn} \end{bmatrix}.$$

注意是转置——第 i 行装的是原来第 i **列**的代数余子式。于是

$$A^{-1} = \frac{1}{\det A}\mathrm{adj}\, A, \qquad \text{当 } \det A \neq 0.$$

- **几何直觉**：余子式 C_{ij} 度量"删掉第 i 行第 j 列后剩余方向张成的体积"。伴随矩阵把这个信息**转置着**摆回去，正好补齐 A 丢失的尺度。为什么需要转置？因为 A 的第 i 行与 C 的第 i 行做点积时，非对角项必须消失（讲次 19 的错位求和恒等式），而"行 × 同行余子式"和"行 × 其他行余子式"的配对关系天然是**行对行**的；要拼出 A^{-1} 需要的是"列配对"，所以转置。
- **具体示例**：2×2 的回看。$A = \begin{bmatrix} a & b \\ c & d \end{bmatrix}$，$C_{11} = +d$，$C_{12} = -c$，$C_{21} = -b$，$C_{22} = +a$，所以

$$\mathrm{adj}\, A = \begin{bmatrix} d & -b \\ -c & a \end{bmatrix}, \qquad A^{-1} = \frac{1}{ad - bc}\begin{bmatrix} d & -b \\ -c & a \end{bmatrix}.$$

这就是我们背了无数遍的公式——**它现在是两条恒等式的特例，不是孤立的记忆点**。

Cramer 法则（Cramer's rule）

- **定义与目的**：若 $\det A \neq 0$，方程组 $A\mathbf{x} = \mathbf{b}$ 的唯一解的第 i 个分量为

$$x_i = \frac{\det A_i}{\det A},$$

其中 A_i 是把 A 的**第 i 列替换成 $\mathbf{b}$**、其余列不动得到的矩阵。 – **几何直觉**：$\mathbf{b} = A\mathbf{x}$ 是 A 的列向量的线性组合，系数是 x_i。把这一列的贡献换成 $\mathbf{b}$ 之后，新矩阵的"体积"就等于 x_i 乘以原来的体积——因为 A_i 与 A 只差一列，而那一列的改变在所有 $n!$ 项中只影响含有该列的那些项，每项都恰

好被乘上 x_i（线性！）。于是 $\det A_i = x_i \det A$，移项即得。Cramer 法则本质上是"用体积比读出组合系数"。 – **具体示例**：2×2 系统 $3x+y=5$，$5x+2y=8$：

$$\det A = \begin{vmatrix} 3 & 1 \\ 5 & 2 \end{vmatrix} = 1, \quad \det A_1 = \begin{vmatrix} 5 & 1 \\ 8 & 2 \end{vmatrix} = 2, \quad \det A_2 = \begin{vmatrix} 3 & 5 \\ 5 & 8 \end{vmatrix} = -1,$$

$$x = \frac{2}{1} = 2, \qquad y = \frac{-1}{1} = -1.$$

代回：$3(2)+(-1)=5$ ✓，$5(2)+2(-1)=8$ ✓。

行列式 = 体积（本讲的灵魂）

- **定义与目的**：把 A 的列向量记为 $\mathbf{a}_1, \dots, \mathbf{a}_n$。则

$$|\det A| = \text{由 } \mathbf{a}_1, \dots, \mathbf{a}_n \text{ 张成的平行体（2D：平行四边形；3D：平行六面体）的体积.}$$

符号 $\operatorname{sign}(\det A)$ 是**定向**：$\det A > 0$ 表示 $\{\mathbf{a}_1, \dots, \mathbf{a}_n\}$ 与标准基 $\{\mathbf{e}_1, \dots, \mathbf{e}_n\}$ 同向（右手系）；$\det A < 0$ 表示反向（左手系）。 – **几何直觉**：单位立方体（体积 1）被 A 映射成由列向量张成的平行体。A 把每个方向按列向量拉伸，总"体积倍数"就是 $|\det A|$。符号与大小是**正交分解**的：$|\det|$ 管"压扁/放大多少"，符号管"有没有翻面"。 – **具体示例**：$G = \begin{bmatrix} 2 & 1 \\ 1 & 3 \end{bmatrix}$，列向量 $\binom{2}{1}$ 与 $\binom{1}{3}$。$\det G = 2\cdot 3 - 1\cdot 1 = 5$，所以平行四边形的面积是 5，且因 $\det > 0$，定向与 $(\mathbf{e}_1, \mathbf{e}_2)$ 相同。

$\det = 0$ 的几何含义：空间被压扁

- **定义与目的**：$\det A = 0 \iff$ 列向量线性相关 $\iff$ 这些列张成的平行体没有 n 维体积。
- **几何直觉**：n 个向量若线性相关，它们全都躺在一个**不超过 $n-1$ 维**的子空间里。2D 里表现为"两条边共线"（压成一条线段，面积 0）；3D 里表现为"三条边共面"（压成一个平面图形，体积 0）。整个空间被映射到更低维的像里，$A\mathbf{x} = \mathbf{b}$ 要么无解，要么有无穷多解——**这就是不可逆的几何原因**。
- **具体示例**：$S = \begin{bmatrix} 1 & 2 \\ 2 & 4 \end{bmatrix}$，列向量 $\binom{1}{2}$ 与 $\binom{2}{4}$ 共线。$\det S = 4 - 4 = 0$。单位正方形被压成一条线段（面积 0），S 不可逆。

雅可比因子（Jacobian）与变量替换

- **定义与目的**：多元换元 $x = x(u,v),\ y = y(u,v)$ 时，

$$\iint f(x,y)\,dx\,dy = \iint f\big(x(u,v), y(u,v)\big)\ |\det J|\,du\,dv, \qquad J = \begin{bmatrix} \partial x/\partial u & \partial x/\partial v \\ \partial y/\partial u & \partial y/\partial v \end{bmatrix}.$$

J 叫雅可比矩阵，$\det J$ 是**局部体积缩放因子**——微小的 $du\,dv$ 矩形被映射成微小的平行四边形，其面积相对原面积正好放大 $|\det J|$ 倍。 – **几何直觉**：线性变换全空间用同一个 $|\det A|$ 缩放体积；对**非线性**映射，不同位置的"局部"缩放不同，但**局部**（无穷小尺度）上看仍然是线性的，所以用一个随位置变化的 $\det J$ 来补偿。线性代数的 $\det$ 就是雅可比行列式在"J 是常矩阵"时的特例。 – **具体示例**：极坐标 $x = r\cos\theta,\ y = r\sin\theta$，

$$J = \begin{bmatrix} \cos\theta & -r\sin\theta \\ \sin\theta & r\cos\theta \end{bmatrix}, \qquad \det J = r\cos^2\theta + r\sin^2\theta = r.$$

所以 $dx\,dy = r\,dr\,d\theta$。**这个 $\det J = r$ 正是所有极坐标积分里那个 r 的来源**——它不是什么"凑出来的因子"，而是面积缩放因子。

计算步骤与手算演示

示例 1：3×3 伴随矩阵全流程 + 验证 $A\cdot(\operatorname{adj} A/\det A) = I$

取讲次 18–19 反复使用的

$$W = \begin{bmatrix} 1 & 1 & 1 \\ 0 & 2 & 5 \\ 2 & 5 & -1 \end{bmatrix}, \qquad \det W = -21 \ (\text{讲次 18 已用消元法算出}).$$

步骤 1：逐个算出 9 个子式的值。 对每个 (i,j)，删去第 i 行第 j 列，剩下 2×2。

$$\det M_{11} = \begin{vmatrix} 2 & 5 \\ 5 & -1 \end{vmatrix} = 2(-1) - 5\cdot 5 = -2 - 25 = -27, \qquad \det M_{12} = \begin{vmatrix} 0 & 5 \\ 2 & -1 \end{vmatrix} = 0(-1) - 5\cdot 2 = -10,$$

$$\det M_{13} = \begin{vmatrix} 0 & 2 \\ 2 & 5 \end{vmatrix} = 0\cdot 5 - 2\cdot 2 = -4, \qquad \det M_{21} = \begin{vmatrix} 1 & 1 \\ 5 & -1 \end{vmatrix} = 1(-1) - 1\cdot 5 = -1 - 5 = -6,$$

$$\det M_{22} = \begin{vmatrix} 1 & 1 \\ 2 & -1 \end{vmatrix} = 1(-1) - 1\cdot 2 = -1 - 2 = -3, \qquad \det M_{23} = \begin{vmatrix} 1 & 1 \\ 2 & 5 \end{vmatrix} = 1\cdot 5 - 1\cdot 2 = 5 - 2 = 3,$$

$$\det M_{31} = \begin{vmatrix} 1 & 1 \\ 2 & 5 \end{vmatrix} = 5 - 2 = 3, \qquad \det M_{32} = \begin{vmatrix} 1 & 1 \\ 0 & 5 \end{vmatrix} = 1\cdot 5 - 1\cdot 0 = 5, \qquad \det M_{33} = \begin{vmatrix} 1 & 1 \\ 0 & 2 \end{vmatrix} = 1\cdot 2 - 1\cdot 0 = 2.$$

步骤 2：贴上棋盘符号 $(-1)^{i+j}$，得到余子式矩阵 C。

$$\begin{aligned} C_{11} &= +(-27) = -27, & C_{12} &= -(-10) = +10, & C_{13} &= +(-4) = -4, \\ C_{21} &= -(-6) = +6, & C_{22} &= +(-3) = -3, & C_{23} &= -(+3) = -3, \\ C_{31} &= +(+3) = +3, & C_{32} &= -(+5) = -5, & C_{33} &= +(+2) = +2. \end{aligned}$$

$$C = \begin{bmatrix} -27 & 10 & -4 \\ 6 & -3 & -3 \\ 3 & -5 & 2 \end{bmatrix}.$$

步骤 3：转置得到伴随矩阵。

$$\operatorname{adj} W = C^{\mathsf{T}} = \begin{bmatrix} -27 & 6 & 3 \\ 10 & -3 & -5 \\ -4 & -3 & 2 \end{bmatrix}.$$

步骤 4：验证核心恒等式 $W \cdot \operatorname{adj} W = (\det W) I = -21 I$。 逐元素算几个：– $(1,1)$ 项：$1(-27) + 1(10) + 1(-4) = -27 + 10 - 4 = -21$ ✓ – $(1,2)$ 项：$1(6) + 1(-3) + 1(-3) = 6 - 3 - 3 = 0$ ✓ – $(1,3)$ 项：$1(3) + 1(-5) + 1(2) = 3 - 5 + 2 = 0$ ✓ – $(2,1)$ 项：$0(-27) + 2(10) + 5(-4) = 0 + 20 - 20 = 0$ ✓ – $(2,2)$ 项：$0(6) + 2(-3) + 5(-3) = 0 - 6 - 15 = -21$ ✓ – $(3,2)$ 项：$2(6) + 5(-3) + (-1)(-3) = 12 - 15 + 3 = 0$ ✓ – $(3,3)$ 项：$2(3) + 5(-5) + (-1)(2) = 6 - 25 - 2 = -21$ ✓

$$W \cdot \operatorname{adj} W = \begin{bmatrix} -21 & 0 & 0 \\ 0 & -21 & 0 \\ 0 & 0 & -21 \end{bmatrix} = -21 I. \ \checkmark$$

步骤 5：得出逆矩阵。 除以 $\det W = -21$：

$$W^{-1} = \frac{1}{-21} \begin{bmatrix} -27 & 6 & 3 \\ 10 & -3 & -5 \\ -4 & -3 & 2 \end{bmatrix} = \begin{bmatrix} \frac{9}{7} & -\frac{2}{7} & -\frac{1}{7} \\ -\frac{10}{21} & \frac{1}{7} & \frac{5}{21} \\ \frac{4}{21} & \frac{1}{7} & -\frac{2}{21} \end{bmatrix}.$$

步骤 6：验算 $W W^{-1} = I$（抽两行）。 第 1 行 × 第 1 列：$1 \cdot \frac{9}{7} + 1 \cdot (-\frac{10}{21}) + 1 \cdot \frac{4}{21} = \frac{27}{21} - \frac{10}{21} + \frac{4}{21} = \frac{21}{21} = 1$ ✓。第 3 行 × 第 3 列：$2(-\frac{1}{7}) + 5(\frac{5}{21}) + (-1)(-\frac{2}{21}) = -\frac{2}{7} + \frac{25}{21} + \frac{2}{21} = -\frac{6}{21} + \frac{27}{21} = \frac{21}{21} = 1$ ✓。

【计算机制解说】：为什么 $W \cdot \operatorname{adj} W = (\det W) I$ 一定成立？分两种情况看。

对角元：$(W \cdot \operatorname{adj} W)_{ii} = \sum_j w_{ij} C_{ij}$（因为 $\operatorname{adj} W$ 的第 i 行第 j 列是 C_{ji}，所以内积是 $\sum_j w_{ij} C_{ij}$）。这**正是沿第 i 行展开 $\det W$**，所以等于 $\det W$。

非对角元：$i \neq k$ 时，$(W \cdot \operatorname{adj} W)_{ik} = \sum_j w_{ij} C_{kj}$。这个和等于"把 W 的第 k 行替换成第 i 行后，沿第 k 行展开"——被替换后的矩阵**第 i 行与第 k 行完全相同**，行列式为 0（讲次 18 性质 2），故该和为 0。

于是 $W \operatorname{adj} W = (\det W) I$。（对称地 $\operatorname{adj} W \cdot W = (\det W) I$ 也成立，本算例的数值验证见下。）两边除以 $\det W$ 得 $W^{-1} = \operatorname{adj} W / \det W$。

注意：这里用到的是讲次 19 的"错位求和恒等式"，所以本讲是讲次 19 的直接兑现。

副作用提醒：这个公式**理论漂亮、数值糟糕**。算 adj 需要 n^2 个 $(n-1)$ 阶行列式，$n = 20$ 时约 $20^2 \cdot 19! \approx 2.4 \times 10^{20}$ 次运算；而消元求逆只要约 $2n^3 = 16000$ 次。**手算与推导用它，工程计算绝不用它。**

示例 2：Cramer 法则解 3×3 方程组，并与消元法对照

仍用上面的 W，取 $\mathbf{b} = (6, -4, 27)^{\mathsf{T}}$，解

$$W\mathbf{x} = \mathbf{b}: \qquad \begin{cases} x_1 + x_2 + x_3 = 6 \\ 2x_2 + 5x_3 = -4 \\ 2x_1 + 5x_2 - x_3 = 27 \end{cases}$$

步骤 1：$\det W = -21$（讲次 18 已验证：消元主元 $1, 2, -\frac{21}{2}$，乘积 -21）。

步骤 2：用 $\mathbf{b}$ 替换第 1 列，得 W_1，算 $\det W_1$。

$$W_1 = \begin{bmatrix} 6 & 1 & 1 \\ -4 & 2 & 5 \\ 27 & 5 & -1 \end{bmatrix}.$$

沿第 1 列展开（或用讲次 19 的余子式）：

$$\det W_1 = 6 \det \begin{bmatrix} 2 & 5 \\ 5 & -1 \end{bmatrix} - (-4) \det \begin{bmatrix} 1 & 1 \\ 5 & -1 \end{bmatrix} + 27 \det \begin{bmatrix} 1 & 1 \\ 2 & 5 \end{bmatrix}$$

$$= 6(-27) + 4(-1 - 5) + 27(5 - 2) = -162 - 24 + 81 = -105.$$

（这里用了 C_{11}, C_{21}, C_{31} 的值：$C_{11}=-27$，$C_{21}=+6$，$C_{31}=+3$。更省事的写法见下面【计算机制解说】。）

$$x_1 = \frac{\det W_1}{\det W} = \frac{-105}{-21} = 5.$$

步骤 3：替换第 2 列。

$$W_2 = \begin{bmatrix} 1 & 6 & 1 \\ 0 & -4 & 5 \\ 2 & 27 & -1 \end{bmatrix}.$$

沿第 2 列展开：$\det W_2 = 6C_{12} + (-4)C_{22} + 27C_{32} = 6(10) + (-4)(-3) + 27(-5) = 60 + 12 - 135 = -63$。

$$x_2 = \frac{-63}{-21} = 3.$$

步骤 4：替换第 3 列。

$$W_3 = \begin{bmatrix} 1 & 1 & 6 \\ 0 & 2 & -4 \\ 2 & 5 & 27 \end{bmatrix}.$$

沿第 3 列展开：$\det W_3 = 6C_{13} + (-4)C_{23} + 27C_{33} = 6(-4) + (-4)(-3) + 27(2) = -24 + 12 + 54 = 42$。

$$x_3 = \frac{42}{-21} = -2.$$

步骤 5：代回验证。

$$x_1 + x_2 + x_3 = 5 + 3 - 2 = 6 \checkmark, \qquad 2x_2 + 5x_3 = 6 - 10 = -4 \checkmark, \qquad 2x_1 + 5x_2 - x_3 = 10 + 15 + 2 = 27 \checkmark$$

步骤 6：用消元法（增广矩阵）独立复核。

$$\left[\begin{array}{ccc|c} 1 & 1 & 1 & 6 \\ 0 & 2 & 5 & -4 \\ 2 & 5 & -1 & 27 \end{array}\right] \xrightarrow{R_3 - 2R_1} \left[\begin{array}{ccc|c} 1 & 1 & 1 & 6 \\ 0 & 2 & 5 & -4 \\ 0 & 3 & -3 & 15 \end{array}\right] \xrightarrow{R_3 - \frac{3}{2}R_2} \left[\begin{array}{ccc|c} 1 & 1 & 1 & 6 \\ 0 & 2 & 5 & -4 \\ 0 & 0 & -\frac{21}{2} & 21 \end{array}\right]$$

回代：$-\frac{21}{2}x_3 = 21 \Rightarrow x_3 = -2$；$2x_2 + 5(-2) = -4 \Rightarrow 2x_2 = 6 \Rightarrow x_2 = 3$；$x_1 + 3 - 2 = 6 \Rightarrow x_1 = 5$。**解完全相同。✓**（顺便：主元之积 $1 \cdot 2 \cdot (-\frac{21}{2}) = -21 = \det W$，又回到讲次 18 的结论。）

```
Cramer 法则的"替换列"图景

          列1 列2 列3              列1 列2 列3
         +---+---+---+            +---+---+---+
   det W | 1 | 1 | 1 |      det W1| b1| 1 | 1 |   <- 第 1 列被 b 顶替
         | 0 | 2 | 5 |            | b2| 2 | 5 |
         | 2 | 5 |-1 |            | b3| 5 |-1 |
         +---+---+---+            +---+---+---+
              |                        |
              v                        v
         det = -21                  det = -105
                                         |
           x1 = det W1 / det W = -105 / -21 = 5     |
           x2 = det W2 / det W =  -63 / -21 = 3     |  每个替换再算一次
           x3 = det W3 / det W =   42 / -21 = -2    |  3x3 行列式

几何读法：W 的列向量张成体积 |det W| = 21 的平行六面体。
b = 5*(列1) + 3*(列2) + (-2)*(列3)：把构成 b 的三个"配料系数"
通过逐个替换列、看体积变了多少倍，直接读出来。
```

【计算机制解说】：为什么 $\det W_i = x_i \det W$？关键在于**列的多重线性**（讲次 18 公理 3 的列版本，由 $\det A^{\mathsf{T}} = \det A$ 得到）。把 W 的第 i 列记为 $\mathbf{a}_i$，而 $\mathbf{b} = x_1\mathbf{a}_1 + \cdots + x_n\mathbf{a}_n$。$W_i$ 就是把第 i 列换成 $\mathbf{b}$：

$$\det W_i = \det[\mathbf{a}_1, \ldots, \mathbf{b}, \ldots, \mathbf{a}_n].$$

由**对第 i 列线性**，把 $\mathbf{b}$ 展开成 n 项：

$$\det W_i = \sum_{k=1}^{n} x_k \det[\mathbf{a}_1, \ldots, \mathbf{a}_k, \ldots, \mathbf{a}_n].$$

其中第 k 项是把第 i 列换成 $\mathbf{a}_k$。当 $k \neq i$ 时，矩阵**有两列相同**（第 i 列与第 k 列都是 $\mathbf{a}_k$），行列式为 0；只有 $k = i$ 项存活，它就是 $\det W$。于是

$$\det W_i = x_i \det W \implies x_i = \frac{\det W_i}{\det W}.$$

Cramer 法则 = 列线性 + 两列相同为零。 顺带得到一个超实用的计算捷径：$\det W_i = \mathbf{b}^{\mathsf{T}}(\operatorname{adj} W \text{ 的第 } i \text{ 列}) = \sum_k b_k C_{ki}$——上面的算例就是这个写法（$6(-27) + (-4)(6) + 27(3) = -105$）。

成本对比（务必知道）：Cramer 法则要算 $n+1$ 个 n 阶行列式，即 $(n+1) \cdot \frac{2}{3}n^3 = O(n^4)$；消元法只要 $\frac{2}{3}n^3 = O(n^3)$。$n = 100$ 时差约 100 倍。**Cramer 法则的价值在于公式的美与理论用途（误差分析、灵敏度、符号推导），不在于实际求解。**

示例 3：3×3 的体积——W 的列向量张成的平行六面体

步骤 1：确定"列向量"。 $W = \begin{bmatrix} 1 & 1 & 1 \\ 0 & 2 & 5 \\ 2 & 5 & -1 \end{bmatrix}$ 的三列是

$$\mathbf{w}_1 = \begin{bmatrix} 1 \\ 0 \\ 2 \end{bmatrix}, \qquad \mathbf{w}_2 = \begin{bmatrix} 1 \\ 2 \\ 5 \end{bmatrix}, \qquad \mathbf{w}_3 = \begin{bmatrix} 1 \\ 5 \\ -1 \end{bmatrix}.$$

步骤 2：体积 = $|\det W|$。 $\det W = -21$，所以体积 $= 21$。

步骤 3：用"底面积 × 高"独立复核（几何自洽性检查）。

- 底：由 $\mathbf{w}_1, \mathbf{w}_2$ 张成的平行四边形面积

$$|\mathbf{w}_1 \times \mathbf{w}_2| = \left\| \begin{vmatrix} \mathbf{i} & \mathbf{j} & \mathbf{k} \\ 1 & 0 & 2 \\ 1 & 2 & 5 \end{vmatrix} \right\| = |\,\mathbf{i}(0 \cdot 5 - 2 \cdot 2) - \mathbf{j}(1 \cdot 5 - 2 \cdot 1) + \mathbf{k}(1 \cdot 2 - 0 \cdot 1)|$$

$$= |(-4, -3, 2)| = \sqrt{16 + 9 + 4} = \sqrt{29} \approx 5.385.$$

- 高：$\mathbf{w}_3$ 在 $\mathbf{w}_1 \times \mathbf{w}_2$ 方向上的投影绝对值

$$h = \frac{|\mathbf{w}_3 \cdot (\mathbf{w}_1 \times \mathbf{w}_2)|}{|\mathbf{w}_1 \times \mathbf{w}_2|} = \frac{|1(-4) + 5(-3) + (-1)(2)|}{\sqrt{29}} = \frac{|-4 - 15 - 2|}{\sqrt{29}} = \frac{21}{\sqrt{29}}.$$

- 体积 = 底 × 高 $= \sqrt{29} \cdot \dfrac{21}{\sqrt{29}} = 21.$ ✓

步骤 4：符号 = 定向。 $\det W = -21 < 0$，说明 $\{\mathbf{w}_1, \mathbf{w}_2, \mathbf{w}_3\}$ 是**左手系**（与标准基定向相反）；体积仍是正的 21。若把 $\mathbf{w}_2$ 与 $\mathbf{w}_3$ 互换位置，$\det$ 变为 $+21$——体积不变，定向翻正。

【计算机制解说】："$|\det|$ = 体积"为什么成立？可以用讲次 18 的三条公理来"验证这个几何量的确是同一个东西"：**(i)** 单位立方体体积为 1，即 $\det I = 1$，公理 1 吻合。**(ii)** 交换两个列向量，平行体的"底面"镜像了，体积大小不变但手性翻转，所以体积这个量的**有向版本**变号，公理 2 吻合。**(iii)** 固定其他列，体积是这一列的线性函数：底（其余列张成的平行体）固定时，体积正比于这一列在底面法向的高度分量，而高度分量对这一列的每个分量都是线性的；公理 3 吻合。**三个公理唯一确定 det，既然"有向体积"满足这三条，它就必须等于 det。** 这就是几何解释的全部逻辑——不需要任何坐标系下的繁琐验证。

注意：$|\det|$ 是体积，$\det$ 本身是"有向体积"。只有当 $\det > 0$ 时二者相等。"3×3 矩阵的绝对值等于体积"是学生最常见的含糊说法——**符号丢了就丢了定向信息**。

示例 4：单位正方形 → 平行四边形（面积 = $|\det|$）

取

$$G = \begin{bmatrix} 2 & 1 \\ 1 & 3 \end{bmatrix}, \qquad \text{列向量 } \mathbf{g}_1 = \begin{bmatrix} 2 \\ 1 \end{bmatrix}, \mathbf{g}_2 = \begin{bmatrix} 1 \\ 3 \end{bmatrix}.$$

步骤 1： $\det G = 2 \cdot 3 - 1 \cdot 1 = 5$。

步骤 2：定位四个顶点。 单位正方形的顶点 $(0,0), (1,0), (0,1), (1,1)$ 被 G 映射到

$$G\begin{pmatrix} 0 \\ 0 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}, \quad G\begin{pmatrix} 1 \\ 0 \end{pmatrix} = \begin{pmatrix} 2 \\ 1 \end{pmatrix}, \quad G\begin{pmatrix} 0 \\ 1 \end{pmatrix} = \begin{pmatrix} 1 \\ 3 \end{pmatrix}, \quad G\begin{pmatrix} 1 \\ 1 \end{pmatrix} = \begin{pmatrix} 3 \\ 4 \end{pmatrix}.$$

步骤 3：用鞋带公式（shoelace）算面积。 按正确环绕顺序 $(0,0) \to (2,1) \to (3,4) \to (1,3)$：

$$2A = |0 \cdot 1 - 2 \cdot 0| + |2 \cdot 4 - 3 \cdot 1| + |3 \cdot 3 - 1 \cdot 4| + |1 \cdot 0 - 0 \cdot 3| = 0 + 5 + 5 + 0 = 10,$$

$$A = 5 = |\det G|. \ \checkmark$$

（顺序不能乱：若走成 $(0,0) \to (2,1) \to (1,3) \to (3,4)$，那是"蝴蝶结"自交四边形，鞋带公式给出 0——顶点必须按环绕顺序排。）

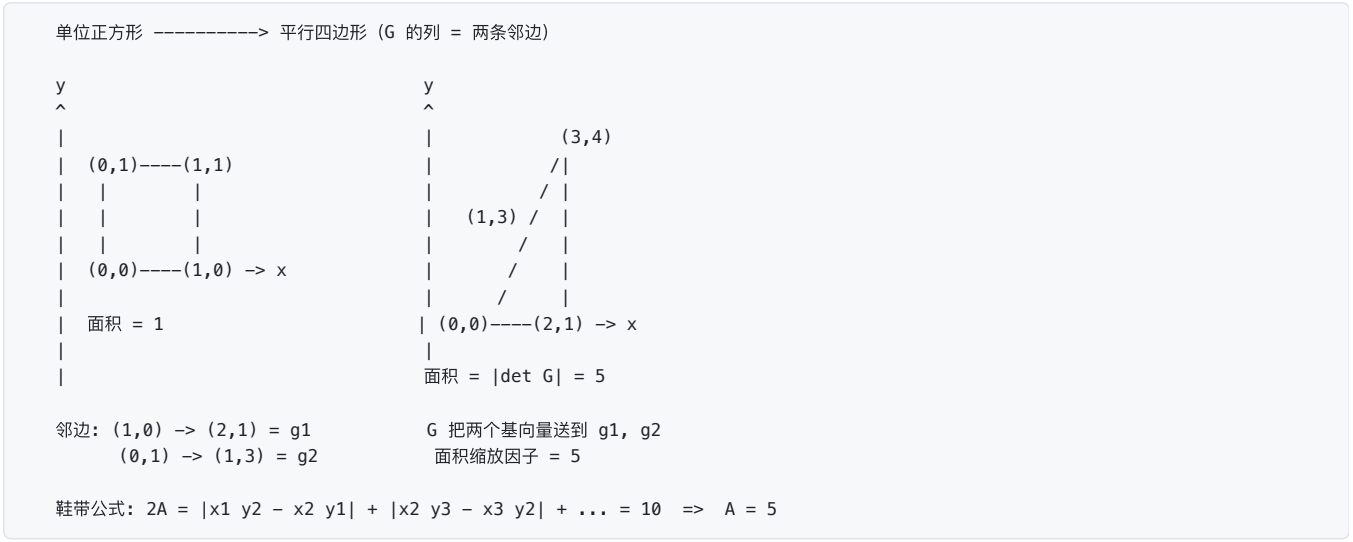

步骤 4：交叉验证 SVD 关系 $\sigma_1\sigma_2 = |\det G|$（为讲次 29 埋伏笔）。

$$G^{\mathsf{T}}G = \begin{bmatrix} 2 & 1 \\ 1 & 3 \end{bmatrix}\begin{bmatrix} 2 & 1 \\ 1 & 3 \end{bmatrix} = \begin{bmatrix} 5 & 5 \\ 5 & 10 \end{bmatrix}, \quad \operatorname{tr}(G^{\mathsf{T}}G) = 15, \quad \det(G^{\mathsf{T}}G) = \det G^2 = 25.$$

特征值由 $\lambda^2 - 15\lambda + 25 = 0$ 给出：$\lambda = \dfrac{15 \pm \sqrt{125}}{2} = \dfrac{5(3 \pm \sqrt{5})}{2}$，即 $\lambda_1 = 13.090$，$\lambda_2 = 1.910$。于是

$$\sigma_1 = \sqrt{13.090} = 3.618, \qquad \sigma_2 = \sqrt{1.910} = 1.382, \qquad \sigma_1\sigma_2 = 5 = |\det G|. \ \checkmark$$

$\sigma_1 = 3.618 = \frac{5+\sqrt{5}}{2}$，$\sigma_2 = 1.382 = \frac{5-\sqrt{5}}{2}$——注意它们**恰好等于** G 的特征值（因为 G 对称），一般矩阵没有这个巧合。

步骤 5：剪切不改变面积（行列式性质的几何现身）。 取 $H = \begin{bmatrix} 1 & 2 \\ 0 & 1 \end{bmatrix}$，$\det H = 1$。单位正方形的顶点 $(1,0) \to (1,0)$，$(0,1) \to (2,1)$，$(1,1) \to (3,1)$——矩形被推成了斜的平行四边形，**面积仍是 1**。这正是讲次 18 性质 4（"一行加到另一行，$\det$ 不变"）在几何上的样子。

【计算机制解说】：为什么"剪切不改变面积"？因为剪切 $\mathbf{g}_2 \to \mathbf{g}_2 + t\mathbf{g}_1$ 是把第二条边沿着第一条边的方向滑动。底（$\mathbf{g}_1$ 的方向与长度）完全没动，而"高"是 $\mathbf{g}_2$ 垂直于 $\mathbf{g}_1$ 的那个分量——加上 $t\mathbf{g}_1$ 只改变了**平行**分量，垂直分量不变，所以高不变，面积不变。这与代数上 $\det[\mathbf{g}_1, \mathbf{g}_2 + t\mathbf{g}_1] = \det[\mathbf{g}_1, \mathbf{g}_2] + t\det[\mathbf{g}_1, \mathbf{g}_1] = \det[\mathbf{g}_1, \mathbf{g}_2] + 0$ 是同一句话的两种语言。

示例 5：2×2 全流程——伴随、Cramer、面积三合一

2×2 是本讲唯一能"手算到底、又能完整画出几何"的情形，值得单独走一遍。

取

$$M = \begin{bmatrix} 3 & 1 \\ 5 & 2 \end{bmatrix}, \qquad \mathbf{b} = \begin{bmatrix} 5 \\ 8 \end{bmatrix}.$$

步骤 1：伴随矩阵与逆。 $\det M = 3 \cdot 2 - 1 \cdot 5 = 1$。余子式：

$$C_{11} = +2, \quad C_{12} = -5, \quad C_{21} = -1, \quad C_{22} = +3 \implies C = \begin{bmatrix} 2 & -5 \\ -1 & 3 \end{bmatrix}, \qquad \operatorname{adj} M = C^{\mathsf{T}} = \begin{bmatrix} 2 & -1 \\ -5 & 3 \end{bmatrix}.$$

$$M^{-1} = \frac{1}{1}\begin{bmatrix} 2 & -1 \\ -5 & 3 \end{bmatrix} = \begin{bmatrix} 2 & -1 \\ -5 & 3 \end{bmatrix}.$$

验证 $MM^{-1} = \begin{bmatrix} 3 & 1 \\ 5 & 2 \end{bmatrix}\begin{bmatrix} 2 & -1 \\ -5 & 3 \end{bmatrix} = \begin{bmatrix} 6-5 & -3+3 \\ 10-10 & -5+6 \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$ ✓。（对照通用公式 $M^{-1} = \dfrac{1}{ad-bc}\begin{bmatrix} d & -b \\ -c & a \end{bmatrix} = \dfrac{1}{1}\begin{bmatrix} 2 & -1 \\ -5 & 3 \end{bmatrix}$，一致。）

步骤 2：用逆矩阵解 $M\mathbf{x} = \mathbf{b}$。

$$\mathbf{x} = M^{-1}\mathbf{b} = \begin{bmatrix} 2 & -1 \\ -5 & 3 \end{bmatrix}\begin{bmatrix} 5 \\ 8 \end{bmatrix} = \begin{bmatrix} 10-8 \\ -25+24 \end{bmatrix} = \begin{bmatrix} 2 \\ -1 \end{bmatrix}.$$

验算：$3(2) + 1(-1) = 5$ ✓，$5(2) + 2(-1) = 8$ ✓。

步骤 3：用 Cramer 法则独立复核。

$$\det M = 1, \qquad \det M_1 = \begin{vmatrix} 5 & 1 \\ 8 & 2 \end{vmatrix} = 10 - 8 = 2, \qquad \det M_2 = \begin{vmatrix} 3 & 5 \\ 5 & 8 \end{vmatrix} = 24 - 25 = -1,$$

$$x_1 = \frac{\det M_1}{\det M} = \frac{2}{1} = 2, \qquad x_2 = \frac{\det M_2}{\det M} = \frac{-1}{1} = -1. \checkmark$$

步骤 4：几何读法。 M 的列向量 $\mathbf{m}_1 = (3,5)$，$\mathbf{m}_2 = (1,2)$ 张成平行四边形，面积 $= |\det M| = 1$。而

$$\mathbf{b} = \begin{bmatrix} 5 \\ 8 \end{bmatrix} = 2\mathbf{m}_1 + (-1)\mathbf{m}_2.$$

Cramer 法则的分子 $\det M_1 = 2$ 正是"把 $\mathbf{m}_1$ 换成 $\mathbf{b}$ 后的面积"，它比原面积大 $x_1 = 2$ 倍——**组合系数直接读作面积比。**

```
2x2 的"Cramer = 面积比"图景

m2=(1,2)                      b=(5,8)
  ^                             ^
  |   /                         |      /
  |  / 面积 = |det M| = 1       |     /  面积 = |det M1| = 2
  | /                           |    /
  |/                            |   /
  +-------> m1=(3,5)            +-------> 第 1 列换成 b

原平行四边形: 边 m1, m2          替换第 1 列后: 边 b, m2
面积 = 1                          面积 = 2

x1 = det M1 / det M = 2 / 1 = 2   <-- "第 1 个配料要 2 份"
x2 = det M2 / det M = -1 / 1 = -1 <-- "第 2 个配料要 -1 份"（反方向）
```

示例 6：3×3 体积——从"棱长乘积"到"行列式"的完整对照

用一个"容易想象"的矩阵，把体积算三遍：直接行列式、叉积公式、消元主元。

$$V = \begin{bmatrix} 2 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}, \qquad S = \begin{bmatrix} 1 & 2 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}, \qquad W = \begin{bmatrix} 1 & 1 & 1 \\ 0 & 2 & 5 \\ 2 & 5 & -1 \end{bmatrix}.$$

(a) V：**纯拉伸。** $\det V = 2$，体积 $= 2$。列向量是 $(2,0,0), (0,1,0), (0,0,1)$，即把 x 轴拉长 2 倍——单位立方体变成 $2 \times 1 \times 1$ 的长方体，体积 2。✓

(b) S：**纯剪切。** $\det S = 1 \cdot 1 \cdot 1 = 1$（上三角，对角元之积），体积 $= 1$。列向量 $(1,0,0), (2,1,0), (0,0,1)$：第二条边被沿第一条边方向推了 2 个单位，**底和高都没变**，所以体积不变。✓ 这再次印证讲次 18 的"一行加到另一行不变"。

(c) W：**一般的斜平行六面体。** $\det W = -21$，体积 $= |-21| = 21$。用叉积独立验证（正文"示例 3"已算）：

$$\mathbf{w}_1 \times \mathbf{w}_2 = (-4,-3,2), \quad |\mathbf{w}_1 \times \mathbf{w}_2| = \sqrt{29}, \quad h = \frac{|\mathbf{w}_3 \cdot (\mathbf{w}_1 \times \mathbf{w}_2)|}{\sqrt{29}} = \frac{21}{\sqrt{29}},$$

$$V_{\text{box}} = \sqrt{29} \cdot \frac{21}{\sqrt{29}} = 21. \checkmark$$

(d) **用消元读主元。** 讲次 18 已算 W 消元主元为 $1,\ 2,\ -\frac{21}{2}$，乘积 $-21 = \det W$。

$$|\det W| = \left|1 \cdot 2 \cdot \left(-\tfrac{21}{2}\right)\right| = 21 = \text{体积}.$$

"主元之积 = 扶正后的棱长乘积 = 体积"——这就是把斜盒子用剪切（保体积）扶正后读棱长的过程。

```
三种体积计算路径的对照（同一个 W，都是 21）

路径 1: |det W|                       路径 2: 底 x 高
-----------------------------         -----------------------------
W = [1 1  1 ]                         w1 x w2 = (-4,-3,2)
    [0 2  5 ]                         |w1 x w2| = sqrt(29)   <- 底面积
    [2 5 -1 ]                         w3 . (w1 x w2) = -21
                                      h = 21/sqrt(29)       <- 高
det W = -21                           V = sqrt(29)*21/sqrt(29) = 21
V = |det W| = 21

路径 3: 消元主元 -> 扶正后读棱长
-----------------------------
[1 1   1  ]   pivots:  1, 2, -21/2
[0 2   5  ]   product: 1*2*(-21/2) = -21
[0 0 -21/2]   V = |-21| = 21

符号 -21 = 左手系；体积 21 恒为正。
```

矩阵分解的核心思想

本讲的三件产品都可以翻译成"分解"的语言。

（1）逆矩阵公式 vs $PA = LU$ 求逆。 $A^{-1} = \operatorname{adj} A / \det A$ 是一个**显式闭式**：它把 A^{-1} 的每个元素写成 A 的元素的有理函数。这在理论上无可替代（求导、误差传播、符号计算都要用它），但在数值上与消元法形成鲜明对比：

$$\text{伴随法：}\ n^2 \text{ 个 } (n-1) \text{ 阶行列式} \sim O(n!) \qquad \textbf{vs} \qquad PA = LU \text{ 求逆：} O(n^3).$$

$n = 10$ 时后者约 $\frac{2}{3} \cdot 10^3 \approx 670$ 次消元步骤，前者要 100 个 9 阶行列式（每个 $9! = 362880$ 项）$\approx 3.6 \times 10^7$ 项。**差 5 个数量级。** 所以工程上：A^{-1} **从不**显式求，而是用 LU 分解做 n 次回代。

（2）Cramer 法则 vs 消元求解。 Cramer 是"n 个行列式之比"，消元是"$A = LU$，两次三角回代"。同样地，理论 vs 实践的分工。

（3）体积观点让 $PA = LU$ 的几何意义浮现。 $A = LU$（讲次 4）中 L 是单位下三角（$\det L = 1$，**剪切与伸缩但不改变体积**），U 是上三角（$\det U = \prod u_{ii}$，**把盒子搬到轴对齐位置**）。于是

$$|\det A| = |\det U| = \prod_i |u_{ii}| = \text{体积}.$$

消元过程 = 用一次次的"剪切"（保体积）把原来的斜平行六面体搬成一个轴对齐的长方体；主元就是那个长方体的三条棱长，体积就是它们的乘积。 如果有换行，P 只是把盒子翻个面（$|\det P| = 1$），体积不变、符号翻转。这是全讲最漂亮的一句话：**消元求行列式 = 把盒子"扶正"后读棱长。**

（4）与 SVD 的接口（讲次 29）。 把盒子"扶正"这件事，SVD 做到了极致：$A = U\Sigma V^{\mathsf{T}}$，其中 U, V 是正交矩阵（$|\det| = 1$，纯旋转/反射，不改变体积），Σ 是对角矩阵，对角线是奇异值 σ_i。于是

$$|\det A| = |\det U| \cdot |\det \Sigma| \cdot |\det V^{\mathsf{T}}| = 1 \cdot \prod_i \sigma_i \cdot 1 = \prod_i \sigma_i.$$

行列式是奇异值的乘积：体积因子 = 各主方向伸缩因子的乘积。LU 把盒子变成轴对齐长方体，SVD 把它变成**各轴互相垂直且长度恰好是 σ_i** 的长方体——后者更强，但代价更高。

（5）三种"求行列式"的方法映照三种分解。

```
方法                      背后的分解              代价          符号来源
----------------------   --------------------   ----------   ------------------
消元读主元                PA = LU                O(n^3)       (-1)^k, k = 交换次数
余子式/大公式展开         无（递归结构）          O(n!)        棋盘 (-1)^(i+j) / 逆序数
伴随矩阵公式              A * adj A = det A I    O(n!)        同上

三者都在算同一个数（三条公理的唯一产物），差别只在"怎么组织计算"。
实践选择：n <= 3 手算展开；n >= 4 一律消元；符号推导用伴随/展开。
```

与其他讲次的关联

- **讲次 18（性质）**：本讲的每一个结论都在用它——"两列相同 $\Rightarrow 0$"给 Cramer 法则的抵消、"行相加不变"给剪切不改变体积、$\det(tA) = t^n \det A$ 给体积缩放。
- **讲次 19（余子式）**：$A \operatorname{adj} A = (\det A) I$ 直接来自错位求和恒等式；本讲的 3×3 伴随矩阵就是讲次 19 余子式矩阵的转置。
- **讲次 4（$A = LU$ 与主元）**：$\det A = \pm \prod u_{ii}$；本讲把 $\prod |u_{ii}|$ 解释成"扶正后的体积"。这也解释了为什么 n 个主元缺一个就 $\det = 0$：长方体有一条棱长为 0，盒子被压扁。
- **讲次 5（转置/置换）**：置换矩阵 P 满足 $|\det P| = 1$，本讲视为"纯翻面"，体积不变。
- **讲次 21（特征值）**：$\det(A - \lambda I) = 0$ 求 λ。对本讲的 $G = \begin{bmatrix} 2 & 1 \\ 1 & 3 \end{bmatrix}$：$\det(G - \lambda I) = \lambda^2 - 5\lambda + 5 = 0$，得 $\lambda = \frac{5 \pm \sqrt{5}}{2}$——**正是上面 SVD 算出的 σ（因为 G 对称）**。而 G 的全体特征值之积 $= \det G = 5$，之和 $= \operatorname{tr} G = 5$。
- **讲次 29（SVD）**：$\sigma_1 \sigma_2 \cdots \sigma_n = |\det A|$。本讲已对 G 与 W 数值验证（$3.618 \times 1.382 = 5$；W 的三个奇异值 $6.082 \times 4.952 \times 0.697 = 21$）。
- **讲次 30–33（线性变换与基变换）**：换一组基 $A \to M^{-1}AM$，则 $\det(M^{-1}AM) = \det(M^{-1}) \det A \det M = \det A$——**行列式是线性变换本身的不变量，与坐标系无关**，这正是"体积缩放因子"该有的性质。如果用非单位行列式的 M 换基，$\det A$ 会变（因为坐标系的"单位体积"变了），这也解释了为什么讲次 31 要用行列式为 1 的变换来保持体积。
- **讲次 8（四个基本子空间）**：$\det A = 0$ 等价于 $\dim C(A) < n$、$\dim N(A) > 0$；$|\det A|$ 则是 $C(A)$ 这个像空间"被 A 拉伸"的总体积因子。**可逆性、秩、体积这三个概念在行列式处汇合。**
- **讲次 10（$A = CR$ 与矩阵的四个子空间）**：$\operatorname{rank}(A) = r < n$ 时 A 的列都落在 r 维子空间里，$\det A = 0$——本讲"体积为 0"的说法与"像空间维度不足"是同一件事的两个角度。

关键要点

1. **逆矩阵公式**：$A^{-1}=\dfrac{\operatorname{adj}A}{\det A}=\dfrac{C^{\mathsf T}}{\det A}$。$C$ 是代数余子式矩阵（带上 $(-1)^{i+j}$），adj 是它的转置。2×2：$\begin{bmatrix}a&b\\c&d\end{bmatrix}^{-1}=\dfrac{1}{ad-bc}\begin{bmatrix}d&-b\\-c&a\end{bmatrix}$。
2. **Cramer 法则**：$x_i=\det A_i/\det A$，A_i 用 $\mathbf b$ 替换第 i 列。等价捷径：$\det A_i=\sum_k b_kC_{ki}$（$C$ 的第 i 列）。
3. **det = 体积 + 定向**：$|\det A|$ = 列向量张成的平行体体积；$\operatorname{sign}(\det A)$ = 定向（正 = 右手系）。2D 是平行四边形面积，3D 是平行六面体体积。
4. **$\det A=0\iff$ 空间被压扁**（列向量线性相关、张成的体积为零），因此不可逆、$A\mathbf x=\mathbf b$ 无解或无穷多解。这是"奇异"的几何定义。
5. **换元与 SVD**：$dx\,dy=|\det J|\,du\,dv$（极坐标里 $\det J=r$）；$|\det A|=\prod_i\sigma_i$（奇异值之积）。
6. **算法分工**：理论公式（伴随 / Cramer）用 $O(n!)$，数值算法（消元 / LU）用 $O(n^3)$。**推导用前者，计算用后者。**

常见误区与注意事项

1. **忘记 adj 是转置。** 最常见的错误是把余子式矩阵 C 直接除以 $\det A$。对 W：$C=\begin{bmatrix}-27&10&-4\\6&-3&-3\\3&-5&2\end{bmatrix}$，若直接 $C/(-21)$ 得一串非整数且 $WC/(-21)\neq I$；正确结果必须用 $C^{\mathsf T}=\begin{bmatrix}-27&6&3\\10&-3&-5\\-4&-3&2\end{bmatrix}$。**校验口诀：伴随矩阵的对角元顺序与余子式矩阵相同，非对角元互换位置。**
2. **Cramer 法则替换的是"列"，不是"行"。** $x_i=\det A_i/\det A$ 中，A_i 是把**第 i 列**换成 $\mathbf b$。若误把第 i 行换成 $\mathbf b$，结果完全错误（那解的是另一个方程组 $A^{\mathsf T}\mathbf y=\mathbf b$ 的某种混合量）。**记住：$\mathbf b=A\mathbf x$ 是列的线性组合，系数 x_i 自然对应列。**
3. **在 $\det A=0$ 时使用 Cramer 法则。** Cramer 法则的前提是 $\det A\neq 0$。若 $\det A=0$，分母为零，公式失效；此时方程组可能无解（如 $x+y=1,\ x+y=2$）或有无穷多解（如 $x+y=1,\ 2x+2y=2$），必须另作判断。**先算 $\det A$ 再决定用不用。**
4. **把 $|\det|$ 说成"面积/体积"而忘了它是有向**的。$\det\begin{bmatrix}0&1\\1&0\end{bmatrix}=-1$，面积是 1，但 det 是 -1：交换两列会翻面。物理里右手/左手坐标系的区别就藏在这个符号里；在讲次 21 之后，特征向量的定向也依赖它。
5. **以为"行列式很大 = 矩阵很好的可逆性"。** $A=\begin{bmatrix}1&0\\0&10^{-6}\end{bmatrix}$ 的 $\det=10^{-6}\neq 0$，"很小"但完全可逆且条件数只有 10^6；而 $B=\begin{bmatrix}1&1\\1&1+10^{-6}\end{bmatrix}$ 的 $\det=10^{-6}$，条件数却高达 $\sim 10^{12}$，病态。**行列式的大小依赖单位（缩放 A 会改变 det 但可逆性不变）：$\det(tA)=t^n\det A$。判断"接近奇异"要用条件数 σ_1/σ_n（讲次 29），不是 $|\det|$。**
6. **把 Cramer 法则当作求解算法。** 它的复杂度是 $O(n^4)$（$n+1$ 个 $O(n^3)$ 的行列式），比消元的 $O(n^3)$ 慢一个 n 的因子。$n=1000$ 时慢一千倍。**手算 2×2/3×3 很优雅，上机必须换消元。**

思考题（带答案）

Q1. （计算题）给定

$$A=\begin{bmatrix}1&1&1\\0&2&5\\2&5&-1\end{bmatrix}\ (\det A=-21),\qquad \mathbf b=\begin{bmatrix}0\\9\\9\end{bmatrix}.$$

用 Cramer 法则求 $A\mathbf x=\mathbf b$ 的 x_1，再用"余子式捷径"求 x_3，最后写出完整解。

▸ **答案**

先看 $\mathbf b$ 的结构：$\mathbf b=(0,9,9)^{\mathsf T}$，注意它恰好等于 $9\mathbf e_2+9\mathbf e_3$。

求 x_1：替换第 1 列，

$$A_1=\begin{bmatrix}0&1&1\\9&2&5\\9&5&-1\end{bmatrix}.$$

沿第 1 列展开：

$$C_{11}=-27,\quad C_{21}=+6,\quad C_{31}=+3,$$

$$\det A_1=0\cdot(-27)+9\cdot(+6)+9\cdot(+3)=54+27=81,\qquad x_1=\frac{81}{-21}=-\frac{27}{7}.$$

独立验算 $\det A_1$（消元）：$R_2\leftarrow R_2-R_1$ 得 $(9,1,4)$；$R_3\leftarrow R_3+R_1$ 得 $(9,6,0)$；再 $R_3\leftarrow R_3-R_2$ 得 $(0,5,-4)$。此时

$$\begin{bmatrix}0 & 1 & 1\\ 9 & 1 & 4\\ 0 & 5 & -4\end{bmatrix}.$$

注意这里不能"读对角元之积"：第 1 列的对角位置 $(1,1)$ 是 0，矩阵还不是三角的。必须做一次交换或直接展开。交换 $R_1 \leftrightarrow R_2$（变号一次）得 $\begin{bmatrix}9 & 1 & 4\\ 0 & 1 & 1\\ 0 & 5 & -4\end{bmatrix}$，再 $R_3 \leftarrow R_3 - 5R_2$ 得 $\begin{bmatrix}9 & 1 & 4\\ 0 & 1 & 1\\ 0 & 0 & -9\end{bmatrix}$，主元之积 $9\cdot 1\cdot(-9) = -81$。交换一次符号为 -1，故

$$\det A_1 = (-1)\cdot(-81) = 81. \checkmark$$

（也可不交换、直接沿第 1 列展开，三者互相对照。**注意一个陷阱**：A_1 的第 1 列是 $(0,9,9)^{\mathsf T}$，有**两个**非零元，若只写 $9\cdot C_{21}$ 那一项就会得到 54。完整展开：

$$C_{11} = (-1)^{1+1}\det\begin{bmatrix}2 & 5\\ 5 & -1\end{bmatrix} = -2-25 = -27 \quad (\text{但 } a_{11}=0\text{，该项不参与}),$$

$$C_{21} = (-1)^{2+1}\det\begin{bmatrix}1 & 1\\ 5 & -1\end{bmatrix} = -(-1-5) = +6, \qquad > C_{31} = (-1)^{3+1}\det\begin{bmatrix}1 & 1\\ 2 & 5\end{bmatrix} = +(5-2) = +3,$$

$$\det A_1 = 0\cdot(-27) + 9\cdot(+6) + 9\cdot(+3) = 0 + 54 + 27 = 81. \checkmark$$

"只展开一个非零元"这个坑在本讲出现了三次，务必先数清该行/列的非零元个数。）

求 x_3：替换第 3 列，

$$A_3 = \begin{bmatrix}1 & 1 & 0\\ 0 & 2 & 9\\ 2 & 5 & 9\end{bmatrix}.$$

用余子式捷径 $\det A_3 = \sum_k b_k C_{k3} = b_1C_{13} + b_2C_{23} + b_3C_{33}$，其中 $C_{13} = -4$，$C_{23} = -3$，$C_{33} = 2$：

$$\det A_3 = 0\cdot(-4) + 9\cdot(-3) + 9\cdot(+2) = -27 + 18 = -9, \qquad x_3 = \frac{-9}{-21} = \frac{3}{7}.$$

求 x_2：替换第 2 列，

$$A_2 = \begin{bmatrix}1 & 0 & 1\\ 0 & 9 & 5\\ 2 & 9 & -1\end{bmatrix}, \qquad \det A_2 = b_1C_{12} + b_2C_{22} + b_3C_{32} = 0\cdot 10 + 9(-3) + 9(-5) = -27 - 45 = -72,$$

$$x_2 = \frac{-72}{-21} = \frac{24}{7}.$$

验证：$x_1 + x_2 + x_3 = -\frac{27}{7} + \frac{24}{7} + \frac{3}{7} = 0$ ✓（第一行 $= 0$）；$2x_2 + 5x_3 = \frac{48}{7} + \frac{15}{7} = \frac{63}{7} = 9$ ✓；
$2x_1 + 5x_2 - x_3 = -\frac{54}{7} + \frac{120}{7} - \frac{3}{7} = \frac{63}{7} = 9$ ✓。

$$\boxed{\mathbf{x} = \frac{1}{7}\begin{bmatrix}-27\\ 24\\ 3\end{bmatrix} = \begin{bmatrix}-27/7\\ 24/7\\ 3/7\end{bmatrix}}$$

Q2. （概念题）判断真假并说明理由。(i) 若 $\det A = 0$，则 A^{-1} 不存在，且 $A\mathbf{x} = \mathbf{b}$ 一定无解。(ii) A 的行列式等于其列向量张成的平行六面体的体积。(iii) 若 $|\det A| = 1$，则 A 不改变体积。(iv) 在极坐标换元中，$dx\,dy = r\,dr\,d\theta$ 中的 r 来自雅可比行列式。

▸ 答案

(i) **假（后半句）。** $\det A = 0$ 确实意味着 A 不可逆，但 $A\mathbf{x} = \mathbf{b}$ 可能**无解**，也可能**有无穷多解**。反例：$A = \begin{bmatrix} 1 & 1 \\ 2 & 2 \end{bmatrix}$，$\det A = 0$。取 $\mathbf{b} = \binom{1}{2}$（在 $C(A)$ 内），则 $x + y = 1$ 有无穷多解（$y = t,\ x = 1 - t$）；取 $\mathbf{b} = \binom{1}{3}$（不在 $C(A)$ 内），无解。**判据是 $\mathbf{b}$ 是否落在列空间 $C(A)$ 里**（讲次 8）。

(ii) **假（表述不严谨）。** 应该是**有向**体积 = $\det A$；**体积（非负）** = $|\det A|$。如果只写"体积 = $\det A$"，那么 $\det A < 0$ 时体积为负，荒谬。反例：$A = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}$，$\det A = -1$，面积是 1。

(iii) **真。** 体积 $= |\det A| = 1$，所以单位体积的图形被映射后体积不变。注意这不意味着 A **不动**——A 可以是旋转、反射或剪切（如 $\begin{bmatrix} 1 & 2 \\ 0 & 1 \end{bmatrix}$，$\det = 1$，但把正方形推成了斜的平行四边形）。**保体积 $\neq$ 保形状。**

(iv) **真。** 极坐标 $x = r\cos\theta, y = r\sin\theta$ 的雅可比矩阵

$$J = \begin{bmatrix} \partial x/\partial r & \partial x/\partial \theta \\ \partial y/\partial r & \partial y/\partial \theta \end{bmatrix} = \begin{bmatrix} \cos\theta & -r\sin\theta \\ \sin\theta & r\cos\theta \end{bmatrix},$$

$$\det J = r\cos^2\theta + r\sin^2\theta = r,$$

故 $dx\,dy = |\det J|\,dr\,d\theta = r\,dr\,d\theta$。那个 r 不是人为加的。

Q3. （计算题 + 概念）设 $G = \begin{bmatrix} 2 & 1 \\ 1 & 3 \end{bmatrix}$。(a) 求 $\det G$ 与 G^{-1}。(b) 求 G 的列向量张成的平行四边形面积。(c) 求 G 的奇异值，验证 $\sigma_1\sigma_2 = |\det G|$。(d) 说明 $\det G$ 与 $\det(G^{\mathsf{T}}G)$ 的关系。

▸ 答案

(a) $\det G = 2\cdot 3 - 1\cdot 1 = 5$。由 2×2 公式，

$$G^{-1} = \frac{1}{5}\begin{bmatrix} 3 & -1 \\ -1 & 2 \end{bmatrix} = \begin{bmatrix} 3/5 & -1/5 \\ -1/5 & 2/5 \end{bmatrix}.$$

验证：$G\,G^{-1} = \frac{1}{5}\begin{bmatrix} 2 & 1 \\ 1 & 3 \end{bmatrix}\begin{bmatrix} 3 & -1 \\ -1 & 2 \end{bmatrix} = \frac{1}{5}\begin{bmatrix} 6-1 & -2+2 \\ 3-3 & -1+6 \end{bmatrix} = \frac{1}{5}\begin{bmatrix} 5 & 0 \\ 0 & 5 \end{bmatrix} = I$ ✓

(b) 列向量 $\mathbf{g}_1 = (2,1)$，$\mathbf{g}_2 = (1,3)$，面积 $= |\det G| = 5$。（鞋带验证见正文示例 4。）

(c) $G^{\mathsf{T}}G = \begin{bmatrix} 2 & 1 \\ 1 & 3 \end{bmatrix}\begin{bmatrix} 2 & 1 \\ 1 & 3 \end{bmatrix} = \begin{bmatrix} 5 & 5 \\ 5 & 10 \end{bmatrix}$，$\mathrm{tr} = 15$，$\det = 25$。特征方程 $\lambda^2 - 15\lambda + 25 = 0$，$\lambda = \dfrac{15 \pm \sqrt{225 - 100}}{2} = \dfrac{15 \pm 5\sqrt{5}}{2}$，即 $\lambda_1 = 13.0902$，$\lambda_2 = 1.9098$。

$$\sigma_1 = \sqrt{13.0902} = 3.6180 = \frac{5+\sqrt{5}}{2}, \qquad \sigma_2 = \sqrt{1.9098} = 1.3820 = \frac{5-\sqrt{5}}{2},$$

$$\sigma_1\sigma_2 = 3.6180 \times 1.3820 = 5.0000 = |\det G|. \ \checkmark$$

（有趣的巧合：因为 G 是对称矩阵，它的奇异值等于 $|\lambda_i|$，而 G 的特征值是 $\frac{5\pm\sqrt{5}}{2} > 0$。对一般非对称矩阵，奇异值是 $A^{\mathsf{T}}A$ 的特征值开方，与 A 的特征值无关。）

(d) $\det(G^{\mathsf{T}}G) = \det(G^{\mathsf{T}})\det G = (\det G)^2 = 25$。**一般地 $\det(A^{\mathsf{T}}A) = (\det A)^2 \geq 0$**，因为 $\det(A^{\mathsf{T}}) = \det A$。这也给出 $\prod_i \sigma_i^2 = \det(A^{\mathsf{T}}A) = (\det A)^2$，开方即得 $|\det A| = \prod_i \sigma_i$——这就是 (c) 中关系的一般证明。

Q4. （概念题 + 计算）设 T 是把 $\mathbb{R}^2$ 上的单位正方形映射到平行四边形的线性变换，已知 T 把 $\mathbf{e}_1 = (1,0)$ 送到 $(3,0)$，把 $\mathbf{e}_2 = (0,1)$ 送到 $(1,2)$。(a) 写出 T 的矩阵 A，求 $\det A$。(b) 求单位正方形的像（平行四边形）的面积。(c) 求 T^{-1} 的矩阵，并说明 $\det(T^{-1}) = 1/\det T$ 的几何含义。(d) 若 T 把图形放大到原来的 k 倍（即 $A = kI$），二维面积放大多少倍？三维呢？

▸ 答案

(a) 线性变换的矩阵列就是基向量的像：

$$A = \begin{bmatrix} 3 & 1 \\ 0 & 2 \end{bmatrix}, \qquad \det A = 3\cdot 2 - 1\cdot 0 = 6.$$

(b) 单位正方形（面积 1）的像就是由 A 的两列 $(3,0)$、$(1,2)$ 张成的平行四边形，面积 $=|\det A|=6$。（几何核对：底边 $(3,0)$ 长 3，"高"是 $(1,2)$ 垂直于 x 轴的分量 $=2$，面积 $=3\times 2=6$。✓）

(c) 由 2×2 公式（$\det A=6$）：

$$A^{-1}=\frac{1}{6}\begin{bmatrix}2 & -1\\ 0 & 3\end{bmatrix}=\begin{bmatrix}\frac{1}{3} & -\frac{1}{6}\\ 0 & \frac{1}{2}\end{bmatrix}.$$

验证 $AA^{-1}=\begin{bmatrix}3 & 1\\ 0 & 2\end{bmatrix}\begin{bmatrix}1/3 & -1/6\\ 0 & 1/2\end{bmatrix}=\begin{bmatrix}1 & -1/2+1/2\\ 0 & 1\end{bmatrix}=I$ ✓。$\det(A^{-1})=\frac{1}{3}\cdot\frac{1}{2}-0=\frac{1}{6}=\dfrac{1}{\det A}$。**几何含义**：$A$ 把面积放大 6 倍，所以它的逆变换必须把面积**缩小** 6 倍，才能回到原图；$\det(A^{-1})=1/6$ 正是这个"撤销缩放因子"。**变换与其逆的缩放因子互为倒数**，这是 $\det(A^{-1})=1/\det A$ 的几何内容。

(d) $A=kI$ 时 $\det A=k^n$。二维（$n=2$）：面积放大 k^2 倍；三维（$n=3$）：体积放大 k^3 倍。这就是 $\det(tA)=t^n\det A$ 的几何化身——**"整体缩放"在每个维度上各贡献一个因子**。$k=3$ 时：二维放大 9 倍，三维放大 27 倍，这与"把边长为 1 的立方体放大到边长 3，体积 27"完全一致。

延伸思考：如果只沿某一个方向拉伸（比如 $A=\begin{bmatrix}3 & 0\\ 0 & 1\end{bmatrix}$），那么 $\det A=3$，面积只放大 3 倍（只有一个方向贡献），而不是 9 倍。**k^n 只适用于"所有方向都按 k 缩放"。**

Lecture 21: Eigenvalues and Eigenvectors

概述

前 20 讲的核心问题一直是求解 $A\mathbf{x}=\mathbf{b}$：列空间、零空间、行列式、正交投影，全部围绕"输入 $\mathbf{b}$、输出 $\mathbf{x}$"展开。本讲换一个提问方式——**固定矩阵 A，寻找那些在 A 作用下方向不变的向量**：

$$A\mathbf{x}=\lambda\mathbf{x},\qquad \mathbf{x}\neq\mathbf{0}.$$

这样的 $\mathbf{x}$ 叫**特征向量（eigenvector）**，伸缩倍数 λ 叫**特征值（eigenvalue）**（德语 *eigen* = "自身的、固有的"）。求解的主线只有一条：$\det(A-\lambda I)=0$ 给出 n 次特征多项式，先解出全部 λ，再对每个 λ 解 $(A-\lambda I)\mathbf{x}=\mathbf{0}$。

本讲是 21–25 特征值板块的开篇，也是**对角化 $A=S\Lambda S^{-1}$（讲次 22）的前提**：只有先找出足够多的线性无关特征向量，才谈得上分解。

核心概念的几何直觉

特征向量与特征值（eigenvector / eigenvalue）

- **定义与目的**：$A\mathbf{x}=\lambda\mathbf{x}$ 且 $\mathbf{x}\neq\mathbf{0}$。目的：把矩阵这个"复杂的拉伸+旋转"拆成若干条**互不干扰的纯伸缩方向**。一旦掌握这些方向，A 反复作用（A^k、微分方程、马尔可夫链）都退化成对 λ 做乘方或取指数。
- **几何直觉（它在空间中是什么样子？）**：把 A 想成一台对所有向量同时操作的机器。绝大多数向量的方向会被拧歪；但有那么几条特殊直线，机器只把它们**沿自身方向拉长、压短或反向**，一点不偏。$\lambda>1$ 拉长，$0<\lambda<1$ 压短，$\lambda<0$ 反向（同时伸缩 $|\lambda|$），$\lambda=0$ 表示该方向被**彻底压扁到原点**（此时 A 必然奇异，$\det A=0$），λ 为复数表示**旋转型**的作用（见下文旋转示例）。
- **具体示例**：$A=\begin{bmatrix}2 & 1\\ 1 & 2\end{bmatrix}$ 作用在 $\mathbf{x}=(1,1)^{\mathsf{T}}$ 上：

$$A\begin{bmatrix}1\\1\end{bmatrix}=\begin{bmatrix}2+1\\1+2\end{bmatrix}=\begin{bmatrix}3\\3\end{bmatrix}=3\begin{bmatrix}1\\1\end{bmatrix}.$$

方向完全没变，只是长度乘 3，所以 $\lambda=3$、$\mathbf{x}=(1,1)^{\mathsf{T}}$ 是一个特征对。再试 $(1,-1)^{\mathsf{T}}$：$A(1,-1)^{\mathsf{T}}=(1,-1)^{\mathsf{T}}$，于是 $\lambda=1$。而 $(1,0)^{\mathsf{T}}\mapsto(2,1)^{\mathsf{T}}$ **方向变了**，它不是特征向量。

特征方程与特征多项式（characteristic equation / polynomial）

- **定义与目的**：$\det(A-\lambda I)=0$ 称为特征方程；左端展开后是关于 λ 的 n 次多项式，称特征多项式。它把"向量方程"变成"标量方程"，让求 λ 成为解方程问题。
- **几何直觉**：当 λ 恰好取到某个特征值时，矩阵 $A-\lambda I$ 把某条非零方向压成零——即 $A-\lambda I$ **奇异**，其列向量线性相关，几何上整个空间被压到一个"更低的维数"里（$\det$ 度量体积，体积为 0）。
- **具体示例**：对上面的 A，$A-\lambda I=\begin{bmatrix}2-\lambda & 1\\ 1 & 2-\lambda\end{bmatrix}$，$\det=(2-\lambda)^2-1=\lambda^2-4\lambda+3=(\lambda-3)(\lambda-1)$，根 $\lambda=3,1$。

特征空间（eigenspace）

- **定义与目的**：固定 λ 后，全部满足 $A\mathbf{x}=\lambda\mathbf{x}$ 的向量（含 $\mathbf{0}$）构成子空间 $\{\mathbf{x}:(A-\lambda I)\mathbf{x}=\mathbf{0}\}=N(A-\lambda I)$，称为该 λ 的**特征空间**。

- **几何直觉**：特征向量从来不是孤立的箭头，而是一条**过原点的直线**（或更高维的子空间）。$\lambda = 1$ 的特征空间对应讲次 21 常说的"不动直线"。
- **具体示例**：$A = \begin{bmatrix} 3 & 1 \\ 0 & 3 \end{bmatrix}$ 时 $\lambda = 3$ 的特征空间是 $N(A - 3I) = N \begin{bmatrix} 0 & 1 \\ 0 & 0 \end{bmatrix} = \mathbf{span}\{(1, 0)^{\mathsf{T}}\}$，**只有一维**，尽管 $\lambda = 3$ 是二重根。

迹与行列式的约束（trace / determinant）

- **定义与目的**：对任意 $n \times n$ 矩阵，$\sum_i \lambda_i = \mathbf{tr}(A)$，$\prod_i \lambda_i = \det A$（复根按重数计）。这是最强的免费验算工具。
- **几何直觉**：$\det$ 是体积缩放因子，而各特征方向独立缩放，总体积因子自然是各 λ 之积；$\mathbf{tr}$ 则是特征多项式中 $(-\lambda)^{n-1}$ 项的系数。
- **具体示例**：$A = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}$：$\mathbf{tr} = 4 = 3 + 1$，$\det = 3 = 3 \times 1$，与上面的根完全吻合。

ASCII 图 1：单位圆 → 椭圆，两条不变方向

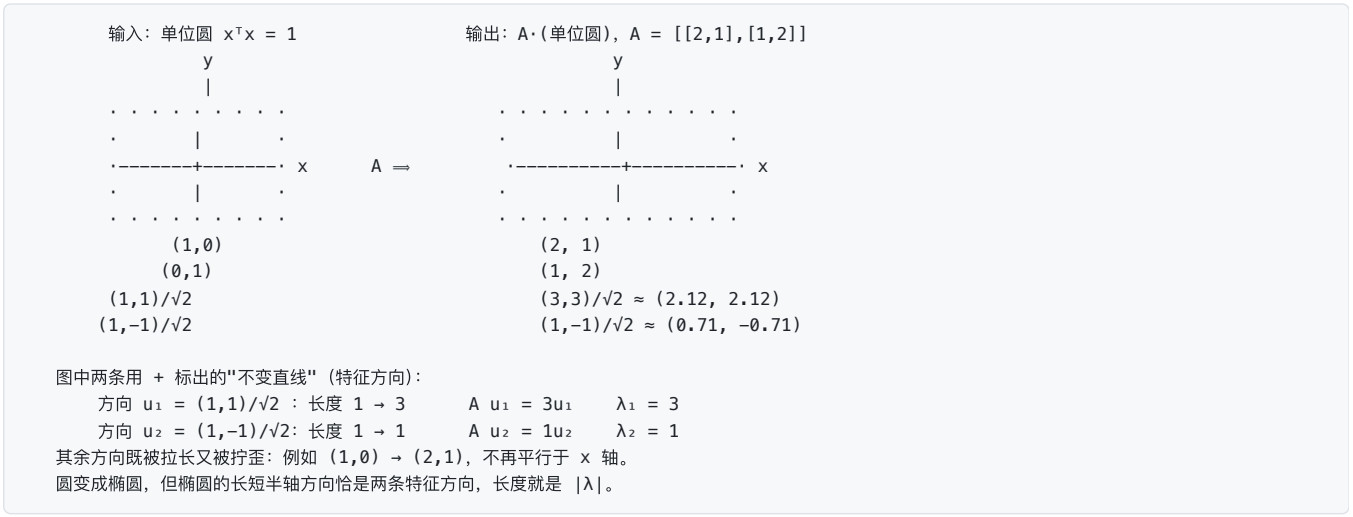

ASCII 图 2：剪切矩阵只有一个特征方向

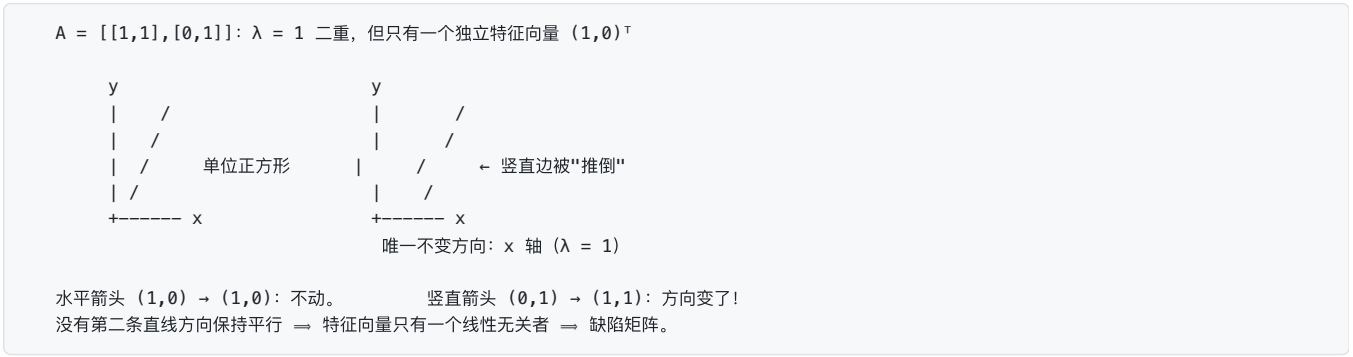

ASCII 图 3：旋转 90°，没有实的不变方向

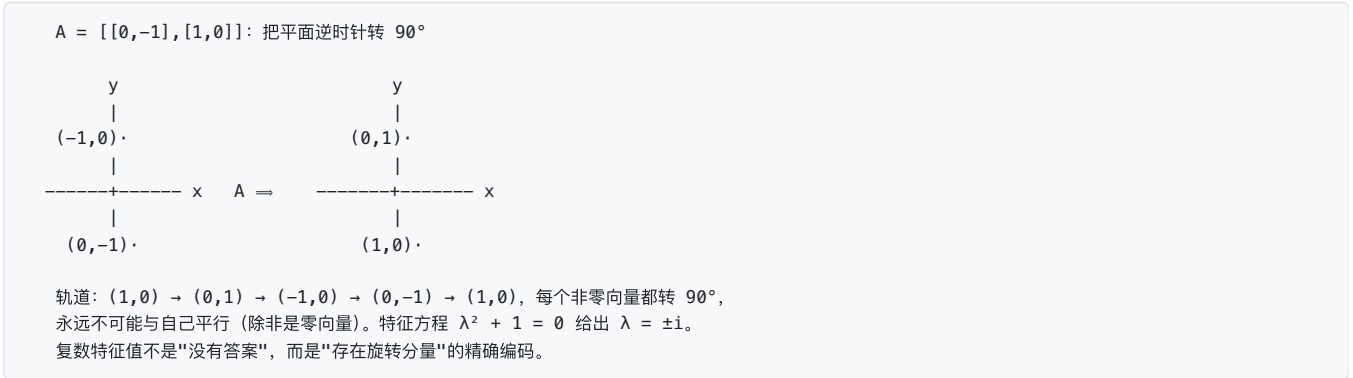

计算步骤与手算演示

通用流程（$n \times n$）

1. 写出 $A - \lambda I$（只在对角线上减 λ）。
2. 算 $\det(A - \lambda I)$，展开成 λ 的 n 次多项式并因式分解。

3. 解 $\det(A-\lambda I)=0$ 得全部特征值（含重数与复数）。
4. 对**每个** λ 解 $(A-\lambda I)\mathbf{x}=\mathbf{0}$：做消元，找主元与自由变量，写出零空间的一组基。
5. 用 $\sum\lambda_i=\operatorname{tr}A$、$\prod\lambda_i=\det A$ 以及 $A\mathbf{x}=\lambda\mathbf{x}$ 回代验算。

2×2 的通用公式（背下来能省一半时间）

对 $A=\begin{bmatrix}a & b\\ c & d\end{bmatrix}$：

$$\det(A-\lambda I)=(a-\lambda)(d-\lambda)-bc=\lambda^2-(a+d)\lambda+(ad-bc)=\lambda^2-(\operatorname{tr}A)\lambda+\det A.$$

所以 2×2 的特征值必满足

$$\boxed{\lambda=\frac{\operatorname{tr}A\pm\sqrt{(\operatorname{tr}A)^2-4\det A}}{2}}$$

判别式 $\Delta=(\operatorname{tr}A)^2-4\det A$ 直接决定类型：$\Delta>0$ 两个不同实根；$\Delta=0$ 二重实根（缺陷与否再看秩）；$\Delta<0$ 一对共轭复根（含旋转）。由于 $\Delta=0$ 需要 $(\operatorname{tr}A)^2=4\det A$ 这一"恰好"条件，**随机矩阵几乎总有两个不同特征值**——重根本身就是稀有事件，这也解释了为什么缺陷矩阵在理论上棘手、在数值上却是"测度零"的。

2×2 的五个"秒算"模式（考试常客）：

```
形状                    特征值              特征向量                备注
------------------------------------------------------------------------
三角/对角               对角元              坐标轴方向              立即读出
对称 [[a,b],[b,d]] 两个实根                可选为互相正交          讲次 25
旋转 [[c,-s],[s,c]] c ± is (c=cosθ)   (1,∓i) 复向量             无实不变方向
投影 P = aaᵗ/aᵗa    1 和 0              a 方向 → 1              另一方向 → 0
反射 (如 [[0,1],[1,0]]) 1 和 -1         镜像轴 → 1              法线 → -1
[[a,b],[0,a]]       a 二重(缺陷)        (1,0)ᵀ 仅一个           需 Jordan 形

反射示例 [[0,1],[1,0]] 验算:
    λ=1: (A-I) = [[-1,1],[1,-1]] → x = (1,1)ᵀ   镜像轴 y = x
    λ=-1: (A+I) = [[1,1],[1,1]]  → x = (1,-1)ᵀ 法线方向被翻向
------------------------------------------------------------------------
```

示例 1：$A=\begin{bmatrix}2 & 1\\ 1 & 2\end{bmatrix}$（对称，两个实特征值）

步骤 1（构造 $A-\lambda I$）：

$$A-\lambda I=\begin{bmatrix}2-\lambda & 1\\ 1 & 2-\lambda\end{bmatrix}.$$

步骤 2（算行列式并因式分解）：

$$\det(A-\lambda I)=(2-\lambda)(2-\lambda)-1\cdot 1=(2-\lambda)^2-1=\lambda^2-4\lambda+3=(\lambda-3)(\lambda-1).$$

步骤 3（解根）：$\lambda_1=3,\ \lambda_2=1$。

步骤 4a（$\lambda_1=3$，解 $(A-3I)\mathbf{x}=\mathbf{0}$）：

$$A-3I=\begin{bmatrix}-1 & 1\\ 1 & -1\end{bmatrix}\xrightarrow{\text{消元}}\begin{bmatrix}-1 & 1\\ 0 & 0\end{bmatrix}\Longrightarrow\ -x_1+x_2=0\Longrightarrow\ x_1=x_2.$$

x_2 是自由变量，取 $x_2=1$ 得 $\mathbf{x}_1=\begin{bmatrix}1\\ 1\end{bmatrix}$。

步骤 4b（$\lambda_2=1$，解 $(A-I)\mathbf{x}=\mathbf{0}$）：

$$A-I=\begin{bmatrix}1 & 1\\ 1 & 1\end{bmatrix}\xrightarrow{\text{消元}}\begin{bmatrix}1 & 1\\ 0 & 0\end{bmatrix}\Longrightarrow x_1+x_2=0\Longrightarrow\mathbf{x}_2=\begin{bmatrix}1\\ -1\end{bmatrix}.$$

步骤 5（验算）：$A\mathbf{x}_1=(3,3)^{\mathsf T}=3\mathbf{x}_1$ ✓；$A\mathbf{x}_2=(1,-1)^{\mathsf T}=1\cdot\mathbf{x}_2$ ✓；$\operatorname{tr}A=4=3+1$ ✓；$\det A=3=3\times1$ ✓。两个特征向量 $\mathbf{x}_1,\mathbf{x}_2$ 线性无关（也不正交时才有意义——这里恰好正交，因为 A 对称，讲次 25）。

【计算机制解说】：为什么特征方程是 $\det(A-\lambda I)=0$，而不是别的？因为我们要的是**非零**解 $\mathbf{x}\neq\mathbf{0}$。方程 $(A-\lambda I)\mathbf{x}=\mathbf{0}$ 写成矩阵形式，问的是"零空间里有没有非零向量"。由讲次 6–8 的知识：

$$\exists\,\mathbf{x}\neq\mathbf{0},\ (A-\lambda I)\mathbf{x}=\mathbf{0}\iff N(A-\lambda I)\neq\{\mathbf{0}\}\iff A-\lambda I\text{ 奇异}\iff\det(A-\lambda I)=0.$$

最后一步用讲次 18 的判据：**方阵奇异 ⇔ 行列式为 0 ⇔ 不可逆**。若忘了"非零"这一条，就会错误地写成 $A\mathbf{x}=\lambda\mathbf{x}$ 对 $\mathbf{x}=\mathbf{0}$ 永远成立，从而得出"任何 λ 都行"的荒谬结论。所以 $\det$ 在这里的角色是：**筛出那些让 $A-\lambda I$ 掉秩的 λ**。

示例 2：$A=\begin{bmatrix}3&1\\0&3\end{bmatrix}$（重根 + 缺陷矩阵，预告讲次 28）

步骤 1–2（三角矩阵的行列式立刻可读）：

$$A-\lambda I=\begin{bmatrix}3-\lambda&1\\0&3-\lambda\end{bmatrix},\qquad \det(A-\lambda I)=(3-\lambda)^2.$$

（三角矩阵的行列式 = 对角元之积，这是讲次 18 的性质，也是"三角矩阵特征值即对角元"的原因。）

步骤 3：$\lambda=3$，代数重数（algebraic multiplicity）为 2。

步骤 4：解 $(A-3I)\mathbf{x}=\mathbf{0}$：

$$A-3I=\begin{bmatrix}0&1\\0&0\end{bmatrix}\Longrightarrow x_2=0,\ x_1\text{ 自由}\Longrightarrow \mathbf{x}=\begin{bmatrix}1\\0\end{bmatrix}.$$

步骤 5（验算）：$\operatorname{tr}A=6=3+3$ ✓；$\det A=9=3\times 3$ ✓；但特征空间只有**一维**，几何重数（geometric multiplicity）$=1<2$。

结论：这样的矩阵叫**缺陷矩阵（defective matrix）**，它**无法对角化**——因为只有 1 个线性无关的特征向量，凑不出 S 的两列。讲次 22 会看到 $A=S\Lambda S^{-1}$ 失效，讲次 28 用 Jordan 形 $A=SJS^{-1}$ 补救。

【计算机制解说】：为什么重根时特征向量可能"不够多"？ 关键在于 λ 的重数是**多项式层面**的（$(\lambda-3)^2$ 出现两次），而独立特征向量的个数是**零空间维度**层面的：$\dim N(A-\lambda I)=n-r$，其中 $r=\operatorname{rank}(A-\lambda I)$。本例 $\operatorname{rank}(A-3I)=1$，故 $\dim N=2-1=1$。一般有

$$1\le \dim N(A-\lambda I)\le \text{代数重数},$$

n 个特征值（按重数计）**总能**提供 n 个独立特征向量当且仅当每个 λ 的几何重数 = 代数重数。缺陷矩阵正是后一种"零空间被挤小"的情形：$A-3I$ 只掉了一行秩，只挤出一条直线。

示例 3：$A=\begin{bmatrix}0&-1\\1&0\end{bmatrix}$（旋转 90°，复特征值）

步骤 1–2：

$$A-\lambda I=\begin{bmatrix}-\lambda&-1\\1&-\lambda\end{bmatrix},\qquad \det(A-\lambda I)=(-\lambda)(-\lambda)-(-1)(1)=\lambda^2+1.$$

步骤 3：$\lambda^2+1=0\Longrightarrow \lambda_1=i,\ \lambda_2=-i$（一对共轭纯虚数）。

步骤 4（复特征向量，算出供体会）：对 $\lambda=i$，

$$A-iI=\begin{bmatrix}-i&-1\\1&-i\end{bmatrix}\Longrightarrow -ix_1-x_2=0\Longrightarrow x_2=-ix_1\Longrightarrow \mathbf{x}=\begin{bmatrix}1\\-i\end{bmatrix}.$$

验算：$A\begin{bmatrix}1\\-i\end{bmatrix}=\begin{bmatrix}0\cdot 1+(-1)(-i)\\1\cdot 1+0\end{bmatrix}=\begin{bmatrix}i\\1\end{bmatrix}=i\begin{bmatrix}1\\-i\end{bmatrix}$ ✓（注意 $i\cdot(-i)=1$）。

步骤 5（验算）：$\operatorname{tr}A=0=i+(-i)$ ✓，即 $2a=2\cos 90^\circ=0$ ✓；$\det A=0\cdot 0-(-1)(1)=1$，而 $\lambda_1\lambda_2=i\cdot(-i)=-i^2=1$ ✓，即 $a^2+b^2=0^2+1^2=1$ ✓。

一般旋转角 θ：$A=\begin{bmatrix}\cos\theta&-\sin\theta\\\sin\theta&\cos\theta\end{bmatrix}$，

$$\det(A-\lambda I)=(\cos\theta-\lambda)^2+\sin^2\theta=\lambda^2-2\lambda\cos\theta+1=0\Longrightarrow \lambda=\cos\theta\pm i\sin\theta=e^{\pm i\theta}.$$

$\theta=90^\circ$ 时正是 $\pm i$；$\theta=0$ 时 $\lambda=1,1$（恒等矩阵，每个方向都不变）；$\theta=180^\circ$ 时 $\lambda=-1,-1$（$A=-I$，每个方向都反向）。

【计算机制解说】：复数特征值到底在说什么？ 它说"这个线性变换里含有**无法用实方向抵消的旋转成分**"。一个实矩阵作用在实向量上，输出仍是实向量；但这并不意味着它必须有一条实的"不动直线"。旋转 90° 就是反例：任何非零向量转过去都不再平行于自己。代数上，奇数次实多项式必有实根，但**偶数次可以没有**——2×2 的情形可以只有一对复根。同时因为 A 是实矩阵，特征多项式的系数全为实数，所以复根必然**成共轭对** $\lambda,\bar\lambda$ 出现（$\lambda=a+bi,\bar\lambda=a-bi$），和 $|\lambda|^2=a^2+b^2=\det A$、$2a=\operatorname{tr}A$。本例 $a=0,b=1$：旋转矩阵的 $\det=1$（保面积）、$\operatorname{tr}=0$（无净伸缩），完全吻合。

示例 4（可选，3×3）：上三角矩阵 $A=\begin{bmatrix}2&1&0\\0&3&1\\0&0&4\end{bmatrix}$

步骤 1–2：$A-\lambda I$ 仍是上三角，对角元 $2-\lambda,3-\lambda,4-\lambda$：

$$\det(A-\lambda I)=(2-\lambda)(3-\lambda)(4-\lambda)\Longrightarrow \lambda=2,3,4.$$

步骤 4a（$\lambda=2$）：$A-2I=\begin{bmatrix}0&1&0\\0&1&1\\0&0&2\end{bmatrix}$。方程 $x_2=0$，$x_2+x_3=0\Rightarrow x_3=0$，$2x_3=0$；$x_1$ 自由 $\Rightarrow \mathbf{x}_1=(1,0,0)^{\mathsf{T}}$。

步骤 4b（$\lambda=3$）：$A-3I=\begin{bmatrix}-1&1&0\\0&0&1\\0&0&1\end{bmatrix}$。$-x_1+x_2=0\Rightarrow x_1=x_2$；$x_3=0$；$x_2$ 自由 $\Rightarrow \mathbf{x}_2=(1,1,0)^{\mathsf{T}}$。

步骤 4c（$\lambda=4$）：$A-4I=\begin{bmatrix}-2&1&0\\0&-1&1\\0&0&0\end{bmatrix}$。$-2x_1+x_2=0\Rightarrow x_2=2x_1$；$-x_2+x_3=0\Rightarrow x_3=2x_1$；取 $x_1=1\Rightarrow \mathbf{x}_3=(1,2,2)^{\mathsf{T}}$。

步骤 5（验算）：$A\mathbf{x}_3=(2+2,\ 6+2,\ 8)^{\mathsf{T}}=(4,8,8)^{\mathsf{T}}=4(1,2,2)^{\mathsf{T}}$ ✓；$\operatorname{tr}A=2+3+4=9$ ✓；$\det A=2\cdot3\cdot4=24$ ✓；三个特征向量线性无关（三角结构保证），故这个 3×3 示例**可以**对角化。

【计算机制解说】：为什么三角/对角矩阵的特征值就是对角元？ 因为三角矩阵的行列式等于对角元之积：$\det(A-\lambda I)=\prod_i(a_{ii}-\lambda)$。根显然是 $\lambda=a_{ii}$。几何上，三角矩阵"分层作用"——沿第一个坐标方向没有来自其他分量的干扰，所以坐标轴方向天然是各层的不变方向。这也给出一条重要推论：$\det A=0\iff A$ **至少有一个特征值为 0**（讲次 18 的可逆性判据与特征值判据在此合流）。

四个示例的横向对比（一张表看清"够不够"）

```
矩阵                    特征值        几何重数(每个λ)   独立特征向量总数   可对角化?
------------------------------------------------------------------------------
[[2,1],[1,2]]          3, 1          1, 1              2 = n             ✓
[[3,1],[0,3]]          3, 3          1 (代数重数 2)     1 < n = 2         ✗ 缺陷
[[0,−1],[1,0]]         i, −i         1, 1              2 (复向量)        ✓ 但 S 复
[[2,1,0],[0,3,1],[0,0,4]] 2,3,4     1,1,1             3 = n             ✓
[[2,0],[0,2]]          2, 2          2 (整个平面)       2 = n             ✓
------------------------------------------------------------------------------
判据：独立特征向量总数 = Σ dim N(A−λᵢI) = n   ⟺   可对角化（讲次 22）
注意第三行：复特征值不阻碍对角化，只是 S 与 Λ 进入复数域。
```

相似矩阵共享特征值（为讲次 22、30 埋线）

若 $B=M^{-1}AM$（M 可逆），则 A、B **有完全相同的特征值**。推导只有两行：

$$A\mathbf{x}=\lambda\mathbf{x}\implies M^{-1}AM\,(M^{-1}\mathbf{x})=\lambda(M^{-1}\mathbf{x})\implies B\mathbf{y}=\lambda\mathbf{y},\quad \mathbf{y}=M^{-1}\mathbf{x}.$$

特征向量被 M^{-1} 搬运，但 λ 原封不动。这解释了为什么 tr 与 $\det$ 在相似变换下不变（它们只是 λ 的和与积），也解释了讲次 22 的对角化：A **与** Λ **相似**，所以我们先把 A 化成最简单的相似代表 Λ 再做一切计算。

特征值与幂次、指数的接口（只列结论，细节留给讲次 22–23）

- **离散动力系统** $u_{k+1}=Au_k$：把 u_0 按特征向量展开 $u_0=\sum c_i\mathbf{x}_i$，则 $u_k=\sum c_i\lambda_i^k\mathbf{x}_i$。长期行为由**最大** $|\lambda_i|$ 统治：$|\lambda_{\max}|>1$ 爆炸、<1 衰减到 $\mathbf{0}$、$=1$ 趋于稳态。这正是 Fibonacci 增长率 $\varphi\approx1.618$ 的来源（讲次 22）。
- **连续动力系统** $\dfrac{du}{dt}=Au$：解为 $u(t)=\sum c_ie^{\lambda_it}\mathbf{x}_i$，稳定性由 $\operatorname{Re}\lambda_i<0$ 决定。复特征值给出**振荡**（虚部 = 频率，实部 = 衰减率），这一讲里"看起来只是数学技巧"的复数在此变成物理必需（讲次 23）。
- **马尔可夫矩阵**：每列和为 1 $\Longrightarrow\lambda=1$ 必是特征值，其（非负）特征向量就是**稳态分布**（讲次 24）。
- **对称矩阵**：λ_i 全实、特征向量两两正交，可写成 $A=Q\Lambda Q^{\mathsf{T}}=\sum_i\lambda_i\mathbf{q}_i\mathbf{q}_i^{\mathsf{T}}$——一组"互相垂直的不变方向"，是本课程最干净的图像（讲次 25）。

【计算机制解说】：为什么"λ 描述长期增长率"这件事值得反复强调？ 因为矩阵幂 A^k 在一般情况下极难计算（k 次矩阵乘法），但在特征向量基下它变成 n 个标量的幂 λ_i^k——**矩阵问题被拆成** n **个独立的一维问题**。这就是特征值方法的全部价值：找一个坐标系，让耦合的、互相干扰的变换解耦成互不相干的纯伸缩。一旦接受这个视角，$A=S\Lambda S^{-1}$（讲次 22）、$e^{At}=Se^{\Lambda t}S^{-1}$（讲次 23）、$A=Q\Lambda Q^{\mathsf{T}}$（讲次 25）全都是同一句话的三次重述。

示例 5（应用预告，讲次 22 详算）：Fibonacci 矩阵 $F=\begin{bmatrix}1&1\\1&0\end{bmatrix}$

步骤 1–2：$\operatorname{tr}F=1$，$\det F=0-1=-1$，故

$$\det(F-\lambda I)=\lambda^2-\lambda-1=0\implies\lambda=\frac{1\pm\sqrt5}{2}=1.618\ldots,\ -0.618\ldots$$

步骤 3：正的根正是**黄金比** $\varphi=\frac{1+\sqrt5}{2}$，负的根 $\psi=\frac{1-\sqrt5}{2}=-1/\varphi$。 步骤 5（验算）：$\lambda_1\lambda_2=-1=\det F$ ✓；$\lambda_1+\lambda_2=1=\operatorname{tr}F$ ✓。 **含义**：Fibonacci 递推 $a_{k+1}=a_k+a_{k-1}$ 写成 $u_{k+1}=Fu_k$，故 $a_k\approx c\,\varphi^{\,k}$——增长率为 φ。因为 $|\psi|<1$，k 大时 $\psi^k\to0$，这就是为什么 $a_{k+1}/a_k\to\varphi$。一个纯组合的递推，最终由特征值给出精确增长率。

矩阵分解的核心思想

本讲**不直接引入**新分解，它是分解链条上的一级台阶：

- $A = S\Lambda S^{-1}$（讲次 22 对角化）——本讲的全部工作是为它准备原料。S 的每一列就是一个特征向量，Λ 是对角线上排着对应特征值的对角阵。等价地 $AS = S\Lambda$：矩阵乘 S 的每一列分别被自己的 λ 伸缩。**前提是本讲反复强调的那句话：必须有 n 个线性无关的特征向量**。示例 2 的缺陷矩阵正是在这里卡住。
- $A = Q\Lambda Q^{\mathrm{T}}$（讲次 25 谱定理）——当 A 是**对称**矩阵时，特征向量可以选成两两正交的单位向量，S 升级为正交矩阵 Q，S^{-1} 变成 Q^{T}。这是最漂亮的一类分解，示例 1 已经露出苗头（$\mathbf{x_1} \perp \mathbf{x_2}$）。
- $A^k = S\Lambda^k S^{-1}$——分解的价值所在：幂次从矩阵乘法降为标量乘方，$u_{k+1} = Au_k$ 的解直接写成 $u_k = \sum c_i \lambda_i^k \mathbf{x}_i$。稳定性判据立刻变成 $|\lambda_i| < 1$（讲次 22）。
- $A = U\Sigma V^{\mathrm{T}}$（讲次 29 SVD）——对不可对角化的矩阵也永远成立；$\sigma_i = \sqrt{\lambda_i(A^{\mathrm{T}}A)}$，SVD 的奇异值就是本讲概念"借壳"到任意矩阵上的版本。

分解的链条：本讲处在哪一环

```
A = LU          ← 讲次 2      消元，解方程 Ax=b
A = QR          ← 讲次 17     正交基，最小二乘
A = SΛS⁻¹       ← 讲次 22     【本讲提供原料】n 个线性无关特征向量
      │                          ├─ A 对称时升级为 A = QΛQᵀ    （讲次 25）
      │                          └─ A 缺陷时降级为 A = SJS⁻¹   （讲次 28）
A = UΣVᵀ        ← 讲次 29     任意矩阵都能做：σ = √λ(AᵀA)

关键依赖：本讲算不出"足够多的特征向量"，整条特征值支线全部崩塌。
判别式只有一个：Σ dim N(A − λᵢI) 是否等于 n。
```

与其他讲次的关联

- **讲次 18–20（行列式）**：本讲把行列式当作**求根工具**使用——$\det(A - \lambda I) = 0$；三角阵行列式 = 对角元之积，直接给出三角阵的特征值；$\det A = \prod \lambda_i$ 把可逆性判据与"0 是不是特征值"联系起来。
- **讲次 6–8（四个基本子空间）**：特征向量所在的特征空间就是零空间 $N(A - \lambda I)$，$\dim N(A - \lambda I) = n - \mathrm{rank}(A - \lambda I)$ 是判断"特征向量够不够"的唯一标尺。
- **讲次 22（对角化与 A^k）**：直接的下一讲。$A = S\Lambda S^{-1}$ 的可行性由本讲的重数比较决定；$A^k \to 0 \Leftrightarrow$ 所有 $|\lambda| < 1$。
- **讲次 23（微分方程 $\mathrm{d}u/\mathrm{d}t = Au$）**：解为 $u(t) = \sum c_i e^{\lambda_i t}\mathbf{x}_i$，稳定性由 $\mathrm{Re}\,\lambda_i < 0$ 决定（复特征值在此真正登场）。
- **讲次 24（马尔可夫矩阵）**：必有一个 $\lambda = 1$，稳态向量就是它的特征向量。
- **讲次 25（对称矩阵与正定）**：实对称矩阵的 λ 全为实数、特征向量可选为正交；正定 $\Leftrightarrow$ 所有 $\lambda_i > 0$。
- **讲次 28（Jordan 形）**：示例 2 的缺陷矩阵在那里被彻底处理。
- **讲次 29（SVD）**：奇异值 $\sigma = \sqrt{\lambda(A^{\mathrm{T}}A)}$，是特征值概念对非方阵的推广。

关键要点

1. **定义式**：$A\mathbf{x} = \lambda\mathbf{x}$，$\mathbf{x} \neq \mathbf{0}$。求法三步走：$A - \lambda I \to \det(A - \lambda I) = 0$ 解 $\lambda \to$ 解 $(A - \lambda I)\mathbf{x} = \mathbf{0}$ 得特征向量。
2. **两条免费验算公式**：$\sum_i \lambda_i = \mathrm{tr}(A)$，$\prod_i \lambda_i = \det A$。任何算出的特征值都要先过这两关。
3. **三角 / 对角矩阵的特征值就是对角元**；特别地 $\det A = 0 \iff \lambda = 0$ 是特征值 $\iff A$ 奇异。
4. **"n 个特征值"与"n 个独立特征向量"是两回事**：前者按重数永远成立，后者要求每个 λ 的几何重数 = 代数重数；否则矩阵缺陷、不可对角化。
5. **实矩阵允许复特征值，且成共轭对出现**（$\lambda = a \pm bi$，则 $2a = \mathrm{tr}\,A$、$a^2 + b^2 = \det A$）；对称矩阵是唯一"保证全实"的重要类别。

常见误区与注意事项

1. **以为特征向量唯一。** 特征向量从不唯一：$\mathbf{x}$ 可以乘任意非零常数，$2\mathbf{x}$、$-\mathbf{x}$、$\frac{1}{3}\mathbf{x}$ 都是同一特征向量。答案应该写成"特征空间的一组基"或"$\mathrm{span}\{\cdot\}$"的形式，而不是一个孤立箭头。此外不要漏掉 $\lambda = 0$ 时特征空间也可能不止一维。
2. **以为重根一定不可对角化。** 反例：$A = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix}$，$\det(A - \lambda I) = (2 - \lambda)^2$ 二重根，但 $A - 2I = 0$ 的零空间是整个 $\mathbb{R}^2$，几何重数 $= 2 =$ 代数重数，**可以**对角化（实际上它本身就是 $\Lambda = 2I$）。重根只是"可能"缺陷，判据永远是 $\dim N(A - \lambda I)$ 而不是重数。同理，$A = \begin{bmatrix} 2 & 0 \\ 0 & 3 \end{bmatrix}$ 有两个不同特征值但**只有两族**特征向量，也不比对称矩阵特殊。
3. **忘记复特征值是合法答案。** 遇到 $\lambda^2 + 1 = 0$ 就写"无特征值"是错的；正确答案是 $\lambda = \pm i$，它精确描述了旋转。只有实对称矩阵才**保证**不出现复特征值。
4. **$\det(A - \lambda I)$ 与 $\det(\lambda I - A)$ 的符号混淆。** 两者相差因子 $(-1)^n$：$\det(\lambda I - A) = (-1)^n \det(A - \lambda I)$，多项式不同但**根完全相同**，不会影响特征值。不过用 $\det(A - \lambda I)$ 时 λ^2 项系数为 $+1$，与 $\lambda^2 - \mathrm{tr}\,\lambda + \det$ 的形式一致，更不容易出错；写特征向量方程时也必须与所选的

$\lambda I - A$ 或 $A - \lambda I$ 保持一致的方向。

5. **把特征值的"加法"当成线性。** $A + B$ 的特征值一般**不等于** A、B 特征值之和；$2A$ 的特征值才是 2λ，$A + 2I$ 的特征值才是 $\lambda + 2$（同特征向量）。只有相似矩阵（$B = M^{-1}AM$）才共享同一组特征值——这提醒我们特征值属于**线性变换自身**，与所选基无关（讲次 30–33）。
6. **算完 λ 就停手。** 本讲的产出是**特征对**，$(A - \lambda I)\mathbf{x} = \mathbf{0}$ 的零空间必须显式求出；只列特征值而不写特征向量，讲次 22 的 S 就无从下手。
7. **把"特征值都是实数"当成普遍事实。** 只有对称矩阵（更一般地，实正规矩阵）有实特征值保证；一般实矩阵完全可以只有复特征值（旋转）。同样易错的是把 A^k 中的 λ^k 写成"取绝对值"——$(-0.9)^k$ 会正负交替地趋于 0，$(-1.1)^k$ 会正负交替地爆炸，符号本身携带振荡信息。

思考题（带答案）

Q1. 求 $A = \begin{bmatrix} 4 & 1 \\ 2 & 3 \end{bmatrix}$ 的全部特征值与一组特征向量，并用迹与行列式验算。

▸ **答案**

特征多项式：

$$\det(A - \lambda I) = (4 - \lambda)(3 - \lambda) - 1 \cdot 2 = \lambda^2 - 7\lambda + (12 - 2) = \lambda^2 - 7\lambda + 10 = (\lambda - 5)(\lambda - 2).$$

故 $\lambda_1 = 5,\ \lambda_2 = 2$。

$\lambda_1 = 5$：$A - 5I = \begin{bmatrix} -1 & 1 \\ 2 & -2 \end{bmatrix} \xrightarrow{\text{消元}} \begin{bmatrix} -1 & 1 \\ 0 & 0 \end{bmatrix}$，$-x_1 + x_2 = 0$，取 $\mathbf{x}_1 = (1, 1)^{\mathsf{T}}$。验算：

$A(1, 1)^{\mathsf{T}} = (4 + 1,\ 2 + 3)^{\mathsf{T}} = (5, 5)^{\mathsf{T}} = 5(1, 1)^{\mathsf{T}}$ ✓

$\lambda_2 = 2$：$A - 2I = \begin{bmatrix} 2 & 1 \\ 2 & 1 \end{bmatrix} \xrightarrow{\text{消元}} \begin{bmatrix} 2 & 1 \\ 0 & 0 \end{bmatrix}$，$2x_1 + x_2 = 0$，取 $\mathbf{x}_2 = (1, -2)^{\mathsf{T}}$。验算：

$A(1, -2)^{\mathsf{T}} = (4 - 2,\ 2 - 6)^{\mathsf{T}} = (2, -4)^{\mathsf{T}} = 2(1, -2)^{\mathsf{T}}$ ✓

免费验算：$\operatorname{tr} A = 4 + 3 = 7 = 5 + 2$ ✓；$\det A = 12 - 2 = 10 = 5 \times 2$ ✓。

注意：特征向量不唯一，$(2, 2)^{\mathsf{T}}$、$(-1, -1)^{\mathsf{T}}$ 同样是 $\lambda = 5$ 的特征向量——答案应理解为 $\operatorname{span}\{(1, 1)^{\mathsf{T}}\}$ 与 $\operatorname{span}\{(1, -2)^{\mathsf{T}}\}$。

Q2.（概念题）(a) 用自己的话解释为什么特征方程是 $\det(A - \lambda I) = 0$，而不是 $\det(A) = 0$ 或别的条件。(b) $A = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix}$ 的特征值 2 是二重的，它能被对角化吗？与 $\begin{bmatrix} 3 & 1 \\ 0 & 3 \end{bmatrix}$ 相比差别究竟在哪里？

▸ **答案**

(a) 我们要解 $A\mathbf{x} = \lambda\mathbf{x}$，移项得 $(A - \lambda I)\mathbf{x} = \mathbf{0}$，并且要求 $\mathbf{x} \neq \mathbf{0}$（$\mathbf{x} = \mathbf{0}$ 对任何 λ 都成立，毫无信息）。由讲次 6–8、18 的判据链：

$$\text{存在非零解} \iff N(A - \lambda I) \neq \{\mathbf{0}\} \iff A - \lambda I \text{ 奇异} \iff \det(A - \lambda I) = 0.$$

$\det A = 0$ 是另一个问题（"A 是否可逆"、"0 是不是特征值"），它只对应 $\lambda = 0$ 这一个特例，不可能筛出全部 λ。

(b) 两者代数重数都是 2，但几何重数不同：

- $A_1 = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix}$：$A_1 - 2I = \begin{bmatrix} 0 & 0 \\ 0 & 0 \end{bmatrix}$，$\operatorname{rank} = 0$，$\dim N = 2 - 0 = 2 =$ 代数重数，**可以**对角化，且 S 可取任意可逆矩阵（A_1 已经是 $2I = \Lambda$ 本身）。
- $A_2 = \begin{bmatrix} 3 & 1 \\ 0 & 3 \end{bmatrix}$：$A_2 - 3I = \begin{bmatrix} 0 & 1 \\ 0 & 0 \end{bmatrix}$，$\operatorname{rank} = 1$，$\dim N = 2 - 1 = 1 < 2$，**不可**对角化，是缺陷矩阵。

差别不在重数，而在 $A - \lambda I$ **掉了多少秩**：掉 0 秩给足特征方向，掉 1 秩就少一个方向。判据永远是 $\dim N(A - \lambda I) = n - \operatorname{rank}(A - \lambda I)$。缺陷情形要到讲次 28 的 Jordan 形才被完整刻画。

Q3. 已知某 3×3 矩阵 A 的三个特征值为 $\lambda = 1, 2, 3$，且对应特征向量 $\mathbf{x}_1, \mathbf{x}_2, \mathbf{x}_3$ 线性无关。求：(a) $\operatorname{tr}(A)$ 与 $\det(A)$；(b) A^{-1} 的特征值与特征向量；(c) $A + 2I$ 的特征值与特征向量；(d) A^k 的特征值与特征向量；(e) A 可逆吗？$A\mathbf{x} = \mathbf{b}$ 对每个 $\mathbf{b}$ 是否唯一可解？

▸ 答案

(a) $\mathrm{tr}(A)=\sum\lambda_i=1+2+3=6$；$\det(A)=\prod\lambda_i=1\cdot2\cdot3=6$。

(b) 由 $A\mathbf{x}_i=\lambda_i\mathbf{x}_i$（$\lambda_i\neq0$）两边左乘 A^{-1}：$\mathbf{x}_i=\lambda_iA^{-1}\mathbf{x}_i$，即 $A^{-1}\mathbf{x}_i=\frac{1}{\lambda_i}\mathbf{x}_i$。故特征值为 $1,\ \frac12,\ \frac13$，特征向量仍是 $\mathbf{x}_1,\mathbf{x}_2,\mathbf{x}_3$。

(c) $(A+2I)\mathbf{x}_i=A\mathbf{x}_i+2\mathbf{x}_i=(\lambda_i+2)\mathbf{x}_i$。特征值 $3,4,5$，特征向量不变。**注意**：这是"平移"规则（$A+cI$ 只平移 λ），不能推广成"和矩阵的特征值等于特征值之和"。

(d) $A^k\mathbf{x}_i=A^{k-1}(\lambda_i\mathbf{x}_i)=\cdots=\lambda_i^k\mathbf{x}_i$。特征值 $1^k,2^k,3^k$，特征向量不变。这正是不对角化也能得到 A^k 作用在特征向量上的原因，讲次 22 将把它推广成 $u_k=\sum c_i\lambda_i^k\mathbf{x}_i$。

(e) $\det A=6\neq0$，A 可逆；$\lambda=0$ 不是特征值也印证了这一点。三个特征向量线性无关构成 $\mathbb{R}^3$ 的基，$N(A)=\{\mathbf{0}\}$，因此对每个 $\mathbf{b}$ 都存在**唯一**解 $\mathbf{x}=A^{-1}\mathbf{b}$。

补充验算：$\det(A^{-1})=1/6=1\cdot\frac12\cdot\frac13$ ✓；$\det(A+2I)=3\cdot4\cdot5=120$，用 $\det(A+2I)=\prod(\lambda_i+2)$ 一次读出，无需展开行列式。

Lecture 22: Diagonalization and Powers of A

概述

上一讲我们学会了求特征值 $\boldsymbol{\lambda}$ 与特征向量 $\mathbf{x}$：解 $\det(A-\lambda I)=0$，再解 $(A-\lambda I)\mathbf{x}=\mathbf{0}$。当时那些特征向量看起来只是"某些特殊的向量"，似乎用处有限。

本讲要把它们变成**一台机器**。核心结论是：若 A 有 n 个线性无关的特征向量，把它们按列排成 S，则

$$A=S\Lambda S^{-1},\qquad \Lambda=\mathrm{diag}(\lambda_1,\dots,\lambda_n).$$

这就是**对角化（diagonalization）**。它的最大价值立刻显现：$A^k=S\Lambda^kS^{-1}$，把"矩阵连乘 k 次"变成"对角元各自取 k 次方"。1838 年的 Fibonacci 数列、人口的长期趋势、马尔可夫链的稳态——全部由这一条公式统一处理。本讲的主线就是：**换到特征向量的坐标系里，矩阵乘法退化成逐坐标的简单伸缩**。

这是特征值章节（21–25）的中枢一讲：讲次 23 的微分方程用 $Se^{\Lambda t}S^{-1}$，讲次 24 的马尔可夫稳态是 $\boldsymbol{\lambda}=\mathbf{1}$ 的特征向量，讲次 25 的对称矩阵把 S 换成正交矩阵 Q。

核心概念的几何直觉

对角化 $A=S\Lambda S^{-1}$

- **定义与目的**：设 A 是 $n\times n$ 矩阵。若存在**可逆**矩阵 S 与对角矩阵 Λ 使得 $A=S\Lambda S^{-1}$，则称 A **可对角化**，并称 S 把 A 对角化。由 $AS=S\Lambda$ 的列形式立刻读出：S 的第 j 列 $\mathbf{x}_j$ 必须满足 $A\mathbf{x}_j=\lambda_j\mathbf{x}_j$——**$S$ 的列就是 A 的特征向量，Λ 的对角元就是对应的特征值**。目的：把"耦合的、难算的 A"翻译成"解耦的、易算的 Λ"。
- **几何直觉（它在空间中是什么样子？）**：这是本讲最重要的一句话——**A 在特征向量坐标系下就是 Λ**。想象一个倾斜的、把圆压成椭圆的变换 A。绝大多数向量被 A 作用后方向都变了，计算 $A^{100}\mathbf{u}_0$ 需要考虑方向不断搅动的耦合效应。但若我们**换一套坐标轴**——不用标准的 $\mathbf{e}_1,\mathbf{e}_2$，而用特征向量 $\mathbf{x}_1,\mathbf{x}_2$ 当新坐标轴——那么在这个新坐标系里，A 只做一件事：**把第 1 个坐标乘 λ_1，第 2 个坐标乘 λ_2，方向完全不搅动**。S 是"翻译器"（把新坐标写成标准坐标：$S\hat{\mathbf{u}}=\mathbf{u}$），$S^{-1}$ 是"反向翻译器"。链式阅读 $A=S\Lambda S^{-1}$ 应当读成：

$$\mathbf{u}\xrightarrow{S^{-1}}\hat{\mathbf{u}}\xrightarrow{\Lambda}\text{逐坐标伸缩}\xrightarrow{S}\text{翻译回原坐标系}$$

这就是"换基"（change of basis）的第一次登场——讲次 31 会专门做这件事。 – **具体示例**：$A=\begin{bmatrix}2&1\\1&2\end{bmatrix}$ 的特征值是 3（方向 $\mathbf{x}_1=\begin{bmatrix}1\\1\end{bmatrix}$）与 1（方向 $\mathbf{x}_2=\begin{bmatrix}1\\-1\end{bmatrix}$）。取 $\mathbf{u}_0=\begin{bmatrix}1\\0\end{bmatrix}$。在标准坐标系里 $A\mathbf{u}_0=\begin{bmatrix}2\\1\end{bmatrix}$，看不出规律。换成特征向量坐标：$\mathbf{u}_0=\frac12\mathbf{x}_1+\frac12\mathbf{x}_2$，于是

$$A^k\mathbf{u}_0=\tfrac12\,3^k\begin{bmatrix}1\\1\end{bmatrix}+\tfrac12\,1^k\begin{bmatrix}1\\-1\end{bmatrix}.$$

两个分量各自独立增长，3^k 项很快压倒一切——k 大时 $\mathbf{u}_0$ 的像几乎完全落在 $\mathbf{x}_1$ 方向上。整个"幂"的问题被化简为两个标量的幂。

下面这张图是本讲的"总路线图"。上排是标准 $\mathbf{e}$ 坐标系里的耦合视图，下排是特征向量坐标系里的解耦视图；注意从左上到右下，被搅动的椭圆问题变成了两条互不相干的直线伸缩：

收敛定理：A^k 的长期命运

- **定义与目的**：设 A 可对角化，特征值 $\lambda_1,\dots,\lambda_n$。则 $A^k\to 0$（即对**每个**初始向量 $\mathbf{u}_0$ 都有 $A^k\mathbf{u}_0\to\mathbf{0}$）$\iff$ **所有** $|\lambda_i|<1$。更一般地（不需要可对角化，谱半径定理）：$A^k\to 0 \iff \rho(A)=\max_i|\lambda_i|<1$。
- **几何直觉**：$A^k\mathbf{u}_0=\sum_i \lambda_i^k c_i\mathbf{x}_i$。每一项是"第 i 个方向上的独立衰减/增长"。要让**所有**方向都死掉，必须**每一个** $|\lambda_i|<1$——只要有一个 $|\lambda_i|>1$，选 $\mathbf{u}_0=\mathbf{x}_i$ 就发散；只要有一个 $|\lambda_i|=1$，选 $\mathbf{u}_0=\mathbf{x}_i$ 就既不衰减也不发散（如 $\lambda=-1$ 时永久原地翻转）。**"存在"与"所有"的差别正是本定理的全部内容**。
- **具体示例**：$A=\begin{bmatrix}0.5 & 0\\ 0 & 2\end{bmatrix}$ 有 $|\lambda_2|=2>1$，取 $\mathbf{u}_0=\mathbf{e}_2$ 得 $\mathbf{u}_k=2^k\mathbf{e}_2\to\infty$；但取 $\mathbf{u}_0=\mathbf{e}_1$ 反而收敛。可见"某些初始向量发散"与"全部收敛"是两码事。而 $A=\begin{bmatrix}0.8 & 0.3\\ 0.2 & 0.7\end{bmatrix}$（$\lambda=1,0.5$，有 $|\lambda_1|=1$）的 $\mathbf{u}_k$ 收敛到稳态而非 $\mathbf{0}$——因为 $\lambda=1$ 的成分被完整保留。

2×2 的快速判据（连特征值都常可跳过）：设 $\tau=\operatorname{tr}A,\ \delta=\det A$。

$$\lambda_{1,2}=\frac{\tau\pm\sqrt{\tau^2-4\delta}}{2}.$$

- $\delta<1$ 且 $|\tau|<1+\delta$ 时两个特征值模都小于 1（Jury 判据的 2×2 版本）；
- $\tau^2<4\delta$ 时特征值为共轭复数，此时 $|\lambda|^2=\lambda_1\lambda_2=\delta$，**衰减性完全由 $\det A<1$ 判定**；
- $\tau^2=4\delta$ 时出现重根，需检查 $\dim N(A-\lambda I)$ 是否为 2 才知可否对角化。

可对角化的充要条件

- **定义与目的**：A 可对角化 $\iff$ A 有 n 个**线性无关**的特征向量。等价说法：对每个特征值，**几何重数 = 代数重数**（几何重数 $=\dim N(A-\lambda I)$，代数重数 $=$ 该特征值在特征多项式中作为根的重数）。没有重根时（n 个互异特征值）自动可对角化——因为互异特征值的特征向量必然线性无关。
- **几何直觉**：特征向量必须**张成整个空间**。若只有 $n-1$ 个独立特征向量，就存在某个方向在特征向量坐标系里"没有名字"，S 不满秩、不可逆，翻译器失效。重根好比"两个方向被压扁成一个方向"：$\lambda=3$ 若是二重根但 $\dim N(A-3I)=1$，说明 $A-3I$ 的零空间只有一条线，A 在该处有**剪切（shear）**行为，没有任何一整套坐标轴能让它变成纯粹伸缩。
- **具体示例**：$A=\begin{bmatrix}3 & 1\\ 0 & 3\end{bmatrix}$：$\operatorname{tr}=6$、$\det=9$，故 $\lambda=3$ 是二重根。但 $A-3I=\begin{bmatrix}0 & 1\\ 0 & 0\end{bmatrix}$ 的秩为 1，零空间维数 $=2-1=1$，只有一个独立特征向量 $\begin{bmatrix}1\\0\end{bmatrix}$。**不可对角化**（讲次 28 用 Jordan 形补救）。对照 $A=\begin{bmatrix}2 & 1\\ 1 & 2\end{bmatrix}$：$\lambda=3,1$ 互异，两个特征向量独立，可对角化。

$A^k=S\Lambda^kS^{-1}$：把幂变成标量幂

- **定义与目的**：若 $A=S\Lambda S^{-1}$，则对任意正整数 k，$A^k=S\Lambda^kS^{-1}$，其中 $\Lambda^k=\operatorname{diag}(\lambda_1^k,\dots,\lambda_n^k)$。这是对角化最重要的应用：把 $O(kn^3)$ 的连乘，变成 n 次标量幂。

- **几何直觉**：S^{-1} 把初始向量翻译成特征坐标，Λ^k 在特征坐标里就是"每个方向独立地乘以自己的 λ^k"，S 再翻译回来。S 与 S^{-1} 在连乘中反复相遇、互相抵消为 I——中间的"翻译开销"只付两次，无论 k 多大。
- **具体示例**：见下一节完整推导与 A^3 的双路对照。

计算步骤与手算演示

示例 1：$A=\begin{bmatrix}2&1\\1&2\end{bmatrix}$ 的完整对角化与 A^3

步骤 1：求特征值。 用迹与行列式（讲次 21 的加速技巧）：

$$\operatorname{tr}A=2+2=4,\qquad \det A=4-1=3.$$

特征多项式 $\lambda^2-4\lambda+3=(\lambda-3)(\lambda-1)=0$，故

$$\lambda_1=3,\qquad \lambda_2=1.$$

步骤 2：求特征向量。 对 $\lambda_1=3$：$A-3I=\begin{bmatrix}-1&1\\1&-1\end{bmatrix}$，方程 $-x_1+x_2=0$，取 $\mathbf{x}_1=\begin{bmatrix}1\\1\end{bmatrix}$。对 $\lambda_2=1$：$A-I=\begin{bmatrix}1&1\\1&1\end{bmatrix}$，方程 $x_1+x_2=0$，取 $\mathbf{x}_2=\begin{bmatrix}1\\-1\end{bmatrix}$。两者不成比例，线性无关，可对角化。

步骤 3：装配 S、S^{-1}、Λ。

$$S=\begin{bmatrix}1&1\\1&-1\end{bmatrix},\qquad \Lambda=\begin{bmatrix}3&0\\0&1\end{bmatrix},\qquad \det S=1\cdot(-1)-1\cdot1=-2.$$

2×2 逆矩阵公式 $\begin{bmatrix}a&b\\c&d\end{bmatrix}^{-1}=\frac{1}{ad-bc}\begin{bmatrix}d&-b\\-c&a\end{bmatrix}$ 给出

$$S^{-1}=\frac{1}{-2}\begin{bmatrix}-1&-1\\-1&1\end{bmatrix}=\frac{1}{2}\begin{bmatrix}1&1\\1&-1\end{bmatrix}.$$

请留意这个巧合：S **恰好对称，且** $S^{-1}=\frac{1}{2}S$。验算 $S\cdot\frac{1}{2}S=\frac{1}{2}\begin{bmatrix}1&1\\1&-1\end{bmatrix}^2=\frac{1}{2}\begin{bmatrix}2&0\\0&2\end{bmatrix}=I$ ✓（脚本已核对）。

步骤 4：验证 $S\Lambda S^{-1}=A$。 先算 $S\Lambda$（右乘对角矩阵 = 按列乘 λ_j）：

$$S\Lambda=\begin{bmatrix}1&1\\1&-1\end{bmatrix}\begin{bmatrix}3&0\\0&1\end{bmatrix}=\begin{bmatrix}3&1\\3&-1\end{bmatrix},$$

再右乘 $S^{-1}=\frac{1}{2}\begin{bmatrix}1&1\\1&-1\end{bmatrix}$：

$$S\Lambda S^{-1}=\frac{1}{2}\begin{bmatrix}3&1\\3&-1\end{bmatrix}\begin{bmatrix}1&1\\1&-1\end{bmatrix}=\frac{1}{2}\begin{bmatrix}3+1&3-1\\3-1&3+1\end{bmatrix}=\frac{1}{2}\begin{bmatrix}4&2\\2&4\end{bmatrix}=\begin{bmatrix}2&1\\1&2\end{bmatrix}=A\ \checkmark$$

步骤 5：用 $S\Lambda^3S^{-1}$ 算 A^3。 $\Lambda^3=\operatorname{diag}(27,1)$：

$$S\Lambda^3=\begin{bmatrix}27&1\\27&-1\end{bmatrix},\qquad S\Lambda^3S^{-1}=\frac{1}{2}\begin{bmatrix}27&1\\27&-1\end{bmatrix}\begin{bmatrix}1&1\\1&-1\end{bmatrix}=\frac{1}{2}\begin{bmatrix}28&26\\26&28\end{bmatrix}=\begin{bmatrix}14&13\\13&14\end{bmatrix}.$$

步骤 6：直接连乘 $A\cdot A\cdot A$ 对照。

$$A^2=\begin{bmatrix}2&1\\1&2\end{bmatrix}\begin{bmatrix}2&1\\1&2\end{bmatrix}=\begin{bmatrix}5&4\\4&5\end{bmatrix},\qquad A^3=A^2A=\begin{bmatrix}5&4\\4&5\end{bmatrix}\begin{bmatrix}2&1\\1&2\end{bmatrix}=\begin{bmatrix}14&13\\13&14\end{bmatrix}.$$

两条路结果完全一致 ✓（脚本核对：brute $=[[14,13],[13,14]]$，via $S=[[14,13],[13,14]]$）。

步骤 7：写出 A^k 通式。 $\Lambda^k=\operatorname{diag}(3^k,1)$：

$$A^k=\frac{1}{2}\begin{bmatrix}3^k&1\\3^k&-1\end{bmatrix}\begin{bmatrix}1&1\\1&-1\end{bmatrix}=\frac{1}{2}\begin{bmatrix}3^k+1&3^k-1\\3^k-1&3^k+1\end{bmatrix}=\begin{bmatrix}\frac{3^k+1}{2}&\frac{3^k-1}{2}\\\frac{3^k-1}{2}&\frac{3^k+1}{2}\end{bmatrix}.$$

脚本核对：$k=2$ 给 $\begin{bmatrix}5&4\\4&5\end{bmatrix}$ ✓，$k=5$ 给 $\begin{bmatrix}122&121\\121&122\end{bmatrix}$ ✓。注意所有 A^k 都保持"对角线相同、副对角线相同"的对称结构，这是 A 对称（讲次 25 主题）留下的烙印。

【计算机制解说】：为什么 $S\Lambda S^{-1}$ 的连乘可以塌缩？关键在于**中间的 $S^{-1}S$ 反复相消**：

$$A^2=(S\Lambda S^{-1})(S\Lambda S^{-1})=S\Lambda(S^{-1}S)\Lambda S^{-1}=S\Lambda I\Lambda S^{-1}=S\Lambda^2S^{-1}.$$

归纳下去 $A^k = S\Lambda^k S^{-1}$。这个推导成立的前提正是 S **可逆**——而 S 可逆 $\iff$ 列线性无关 $\iff$ 有 n 个独立特征向量。所以"能否对角化"这个抽象条件，在这里变成了一个非常具体的开关：**没有可逆的 S，A^k 的快速公式就断了**。另外，为什么 Λ^k 这么好算？因为对角矩阵幂 = 逐元素幂：反复乘对角矩阵只在每个坐标上独立地重复标量乘法，方向不混合。

示例 2：Fibonacci 数列——Strang 的招牌例子

步骤 1：把递推写成矩阵。 Fibonacci 数列 $F_0 = 0, F_1 = 1$，递推 $F_{k+1} = F_k + F_{k-1}$。令状态向量 $\mathbf{u}_k = \begin{bmatrix} F_{k+1} \\ F_k \end{bmatrix}$，则

$$\mathbf{u}_{k+1} = \begin{bmatrix} F_{k+2} \\ F_{k+1} \end{bmatrix} = \begin{bmatrix} F_{k+1} + F_k \\ F_{k+1} \end{bmatrix} = \begin{bmatrix} 1 & 1 \\ 1 & 0 \end{bmatrix} \begin{bmatrix} F_{k+1} \\ F_k \end{bmatrix} = A\mathbf{u}_k, \qquad A = \begin{bmatrix} 1 & 1 \\ 1 & 0 \end{bmatrix}.$$

于是 $\mathbf{u}_k = A^k \mathbf{u}_0$，$\mathbf{u}_0 = \begin{bmatrix} F_1 \\ F_0 \end{bmatrix} = \begin{bmatrix} 1 \\ 0 \end{bmatrix}$。递推（串行、需逐步算）变成了幂（可一次跳跃）。

步骤 2：求特征值。 $\operatorname{tr} A = 1$，$\det A = 0 - 1 = -1$，故

$$\lambda^2 - \lambda - 1 = 0 \implies \lambda = \frac{1 \pm \sqrt{5}}{2}.$$

即

$$\lambda_1 = \varphi = \frac{1 + \sqrt{5}}{2} \approx 1.618034, \qquad \lambda_2 = \frac{1 - \sqrt{5}}{2} \approx -0.618034.$$

两个漂亮的事实（脚本核对）：$\lambda_1 \lambda_2 = \det A = -1$，$\lambda_1 + \lambda_2 = \operatorname{tr} A = 1$。$\varphi$ 就是**黄金比例**，而 $\lambda_2 = -1/\varphi$，绝对值小于 1。

步骤 3：求特征向量。 对 $\lambda_1 = \varphi$：$A - \varphi I = \begin{bmatrix} 1-\varphi & 1 \\ 1 & -\varphi \end{bmatrix}$，第二行给出 $x_1 = \varphi x_2$，取 $\mathbf{x}_1 = \begin{bmatrix} \varphi \\ 1 \end{bmatrix}$。脚本核对 $A \begin{bmatrix} \varphi \\ 1 \end{bmatrix} = \begin{bmatrix} \varphi^2 \\ \varphi \end{bmatrix} = \begin{bmatrix} 2.618034 \\ 1.618034 \end{bmatrix}$，而 $\varphi^2 = \varphi + 1 = 2.618034$ ✓。同理 $\mathbf{x}_2 = \begin{bmatrix} \lambda_2 \\ 1 \end{bmatrix}$，$A\mathbf{x}_2 = \begin{bmatrix} \lambda_2^2 \\ \lambda_2 \end{bmatrix}$ ✓。

步骤 4：展开解。 因为 $\lambda_1 \neq \lambda_2$，$\mathbf{x}_1, \mathbf{x}_2$ 无关，A 可对角化，故

$$\mathbf{u}_k = A^k \mathbf{u}_0 = c_1 \lambda_1^k \mathbf{x}_1 + c_2 \lambda_2^k \mathbf{x}_2, \qquad \mathbf{u}_0 = c_1 \mathbf{x}_1 + c_2 \mathbf{x}_2.$$

用 $\mathbf{u}_0 = \begin{bmatrix} 1 \\ 0 \end{bmatrix} = \begin{bmatrix} F_1 \\ F_0 \end{bmatrix}$ 解出 $c_1 = \dfrac{1}{\varphi - \lambda_2} = \dfrac{1}{\sqrt{5}}$，$c_2 = -\dfrac{1}{\sqrt{5}}$。取 $\mathbf{u}_k$ 的第二个分量 F_k：

$$F_k = \frac{1}{\sqrt{5}} \left(\varphi^k - \lambda_2^k \right) = \frac{1}{\sqrt{5}} \left[\left(\frac{1 + \sqrt{5}}{2} \right)^k - \left(\frac{1 - \sqrt{5}}{2} \right)^k \right].$$

这就是 Binet 公式——它从对角化里"掉出来"了，不需要任何额外技巧。脚本核对：$F_{10} = 55$ ✓，$F_{20} = 6765$ ✓，$F_{30} = 832040$ ✓。

步骤 5：为什么 $F_k \approx \varphi^k / \sqrt{5}$。 因为 $|\lambda_2| = 0.618 < 1$，所以 $\lambda_2^k \to 0$，第二项迅速可忽略。$k = 10$ 时 $\varphi^{10}/\sqrt{5} \approx 122.99/\sqrt{5}$ 附近的误差已只是 $\lambda_2^{10}/\sqrt{5} \approx 0.008$ 量级，取整即得 55。**主导特征值 φ 决定了 Fibonacci 的增长速率**：$F_{k+1}/F_k \to \varphi$。这解释了为什么向日葵种子数、松果鳞片数总落在 $1, 1, 2, 3, 5, 8, 13, 21, 34, 55, \ldots$ 上。

【计算机制解说】：本例揭示了"幂法"的普遍机制。任何 $\mathbf{u}_0$ 分解到特征向量基上后，k 步之后各项按 λ_i^k 缩放。因此**绝对值最大的特征值最终压倒其他所有项**，k 大时 $\mathbf{u}_k$ 方向趋向该特征向量（讲次 21 末尾的 Power of A 与此呼应，Google 的 PageRank 就用这个机制）。反之，若 $|\lambda_2| < 1$，它对应的成分被"洗掉"——这正是下一例收敛的来源。注意：只有 $\lambda_1 \neq \lambda_2$ 才能写 $c_1\lambda_1^k\mathbf{x}_1 + c_2\lambda_2^k\mathbf{x}_2$ 这个干净形式；重根时需要用 $k\lambda^k$ 的修正项（Jordan 形，讲次 28）。

示例 3：稳定性——两个方向分别衰减与发散

(a) **对角矩阵** $A = \begin{bmatrix} 0.5 & 0 \\ 0 & 2 \end{bmatrix}$。特征值 $\lambda_1 = 0.5, \lambda_2 = 2$，特征向量就是标准基 $\mathbf{e}_1, \mathbf{e}_2$（对角线矩阵无需换基，$S = I$）。取 $\mathbf{u}_0 = \begin{bmatrix} 1 \\ 1 \end{bmatrix} = \mathbf{e}_1 + \mathbf{e}_2$，则

$$\mathbf{u}_k = A^k \mathbf{u}_0 = 0.5^k \mathbf{e}_1 + 2^k \mathbf{e}_2 = \begin{bmatrix} 0.5^k \\ 2^k \end{bmatrix}.$$

$k = 10$ 时 $\mathbf{u}_{10} = \begin{bmatrix} 0.00098 \\ 1024 \end{bmatrix}$：第一坐标几乎归零，第二坐标爆炸。**同一矩阵、同一初始向量，一个方向收敛、一个方向发散**——这说明"$A^k \to 0$"这种问法必须对所有方向成立才有意义（见收敛定理）。

(b) **马尔可夫型矩阵** $A = \begin{bmatrix} 0.8 & 0.3 \\ 0.2 & 0.7 \end{bmatrix}$。注意每列和为 1（列随机）。$\operatorname{tr} A = 1.5$，$\det A = 0.8 \times 0.7 - 0.3 \times 0.2 = 0.56 - 0.06 = 0.50$，故 $\lambda^2 - 1.5\lambda + 0.5 = (\lambda - 1)(\lambda - 0.5) = 0$，即 $\lambda_1 = 1, \lambda_2 = 0.5$。特征向量 $\mathbf{x}_1 = \begin{bmatrix} 0.6 \\ 0.4 \end{bmatrix}$（稳态），$\mathbf{x}_2 = \begin{bmatrix} 1 \\ -1 \end{bmatrix}$。脚本核对：$A \begin{bmatrix} 3 \\ 2 \end{bmatrix} = \begin{bmatrix} 3 \\ 2 \end{bmatrix}$ ✓（$3:2$ 即 $0.6:0.4$，确实是不动点）。

从 $\mathbf{u}_0 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}$ 出发，解 $a_1\mathbf{x}_1 + a_2\mathbf{x}_2 = \mathbf{u}_0$ 得 $a_1 = 1,\ a_2 = 0.4$（验算：$1 \cdot \begin{bmatrix} 0.6 \\ 0.4 \end{bmatrix} + 0.4 \cdot \begin{bmatrix} 1 \\ -1 \end{bmatrix} = \begin{bmatrix} 1.0 \\ 0.0 \end{bmatrix}$ ✓），于是

$$\mathbf{u}_k = 1\cdot 1^k\begin{bmatrix}0.6\\0.4\end{bmatrix} + 0.4\cdot 0.5^k\begin{bmatrix}1\\-1\end{bmatrix} \xrightarrow[k\to\infty]{} \begin{bmatrix}0.6\\0.4\end{bmatrix}.$$

脚本核对这条公式：$k=1$ 给 $\begin{bmatrix}0.8\\0.2\end{bmatrix}$、$k=2$ 给 $\begin{bmatrix}0.7\\0.3\end{bmatrix}$、$k=5$ 给 $\begin{bmatrix}0.6125\\0.3875\end{bmatrix}$、$k=10$ 给 $\begin{bmatrix}0.600391\\0.399609\end{bmatrix}$，与直接连乘 $A^k\mathbf{u}_0$ 逐位吻合 ✓。注意 $|\lambda_2| = 0.5 < 1$，$0.4\cdot 0.5^k$ 的扰动迅速消失，$\mathbf{u}_k$ 单调地爬向稳态 $\begin{bmatrix}0.6\\0.4\end{bmatrix}$。

脚本核对 $A^2 = \begin{bmatrix}0.7 & 0.45\\0.3 & 0.55\end{bmatrix}$、$A^5 = \begin{bmatrix}0.6125 & 0.5813\\0.3875 & 0.4187\end{bmatrix}$：两列正在**趋同**，且趋同到 $(0.6, 0.4)$ 的比例。因为 $|\lambda_2| = 0.5 < 1$，0.5^k 项消失，只剩 $\lambda_1 = 1$ 的稳态。**这就是马尔可夫链的稳态（讲次 24）：稳态 $\iff$ 存在特征值 1，收敛速度由第二特征值 0.5 决定**（称为收敛率）。

【计算机制解说】：为什么"$|\lambda_1| = 1$ 决定了不衰减"？在特征坐标下 $\hat{\mathbf{u}}_k = \Lambda^k\hat{\mathbf{u}}_0$ 的每个分量是 $\lambda_i^k\hat{u}_i(0)$。λ_i^k 的三种命运截然不同：$|\lambda_i| < 1$ 则 $\to 0$（记忆被洗掉）；$|\lambda_i| > 1$ 则 $\to \infty$（该成分爆炸，只要 $\hat{u}_i(0) \neq 0$）；$|\lambda_i| = 1$ 则大小不变（$\lambda = 1$ 完全不动，$\lambda = -1$ 每步翻转符号，$|\lambda| = 1$ 但 $\lambda \neq \pm 1$ 则在单位圆上旋转）。所以**长期行为完全由 $|\lambda_i|$ 与 1 的大小关系分类，与 A 的具体数字无关**。这就是特征值被称为"矩阵的 DNA"的原因。

示例 4：3×3 重根但仍可对角化——A = 3I + J₃（全 1 矩阵）

这个例子专门用来击碎"有重根就不可对角化"的误解。

步骤 1：矩阵与特征值。 令

$$A = \begin{bmatrix}3 & 1 & 1\\1 & 3 & 1\\1 & 1 & 3\end{bmatrix} = 2I + \begin{bmatrix}1 & 1 & 1\\1 & 1 & 1\\1 & 1 & 1\end{bmatrix}.$$

$\operatorname{tr} A = 9$，$\det A = 20$（脚本核对）。观察 $A = 2I + J$，其中 J 是元素全为 1 的矩阵。$J\mathbf{1} = 3\mathbf{1}$（每行和都是 3），故 $A\mathbf{1} = (2+3)\mathbf{1} = 5\mathbf{1}$，得 $\lambda_1 = 5$、$\mathbf{x}_1 = \begin{bmatrix}1\\1\\1\end{bmatrix}$。对任何与 $\mathbf{1}$ 正交的向量 $\mathbf{v}$（即分量和为零），$J\mathbf{v} = \mathbf{0}$，故 $A\mathbf{v} = 2\mathbf{v}$——所以 $\lambda = 2$ 是**二重根**。

步骤 2：重根处的几何重数。 $A - 2I = J$ 的秩为 1（所有行相同），故

$$\dim N(A-2I) = 3 - \operatorname{rank}(J) = 3 - 1 = 2.$$

几何重数 2 = 代数重数 2 ✓。于是存在**两个**独立特征向量：$\mathbf{x}_2 = \begin{bmatrix}1\\-1\\0\end{bmatrix}$、$\mathbf{x}_3 = \begin{bmatrix}1\\0\\-1\end{bmatrix}$。

步骤 3：装配并验证。

$$S = \begin{bmatrix}1 & 1 & 1\\1 & -1 & 0\\1 & 0 & -1\end{bmatrix}, \qquad \Lambda = \begin{bmatrix}5 & 0 & 0\\0 & 2 & 0\\0 & 0 & 2\end{bmatrix}, \qquad \det S = 3 \neq 0.$$

脚本核对 $AS = S\Lambda$ ✓，且 $S\Lambda S^{-1} = A$ ✓（$S^{-1} = \frac{1}{3}\begin{bmatrix}1 & 1 & 1\\1 & -2 & 1\\1 & 1 & -2\end{bmatrix}$）。

步骤 4：A^3。 由于重特征值只有 $2^3 = 8$ 一种幂：

$$A^3 = S\begin{bmatrix}125 & 0 & 0\\0 & 8 & 0\\0 & 0 & 8\end{bmatrix}S^{-1} = \begin{bmatrix}47 & 39 & 39\\39 & 47 & 39\\39 & 39 & 47\end{bmatrix}.$$

直接连乘核对：$A^2 = \begin{bmatrix}11 & 7 & 7\\7 & 11 & 7\\7 & 7 & 11\end{bmatrix}$，$A^3 = A^2A = \begin{bmatrix}47 & 39 & 39\\39 & 47 & 39\\39 & 39 & 47\end{bmatrix}$ ✓（脚本一致）。

【计算机制解说】：为什么重根有时可对角化、有时不行？判据不是"有没有重根"，而是**"重根处能否凑够那么多条独立的特征向量"**。本例中 $A - 2I$ 的零空间是二维平面（而非常见的一条直线），因为 $A - 2I$ 把整个与 $\mathbf{1}$ 正交的平面都压成了零——这个平面上**每一条**直线都是 A–不变方向。对比 $\begin{bmatrix}3 & 1\\0 & 3\end{bmatrix}$：那里 $A - 3I$ 的零空间只有一维，平面另一维被"剪切"，凑不出 2 条独立直线。**矩阵能否对角化，本质上是"A 是否在某组基下同时只做伸缩"——即 A 有多少个不变方向**。这也是为什么对称矩阵（讲次 25）永远可对角化：对称性保证了每个特征值都有"完整维度"的不变子空间。

矩阵分解的核心思想

本讲的主角是特征值分解（eigendecomposition），也是课程里继 $A = LU$、$A = QR$、$A = Q\Lambda Q^{\mathsf{T}}$ 之后的又一种核心分解。

形式：$A = S\Lambda S^{-1}$，其中 S 的列是 n 个线性无关的特征向量，$\Lambda = \operatorname{diag}(\lambda_1, \ldots, \lambda_n)$。等价写法 $AS = S\Lambda$（更好记：右乘对角矩阵等于按列缩放）。

含义：这是**"换基到特征向量"的分解**。$A = LU$ 把矩阵拆成"消元 + 回代"，$A = QR$ 拆成"正交基 + 上三角"，而 $A = S\Lambda S^{-1}$ 拆成"翻译 + 逐坐标伸缩 + 翻译回来"。它回答的不是"如何解方程组"，而是**"这个变换本质上是几个方向上的独立伸缩"**——它揭示 A 的**动力学**而非 A 的**可解性**。

揭示的结构性质：

- **稳定性**：$A^k \to 0$ 当且仅当所有 $|\lambda_i| < 1$。λ_i 的模决定每个模式的生死。
- **长期主导模式**：$|\lambda_{\max}|$ 决定增长率（Fibonacci 的 φ），对应特征向量决定极限方向（马尔可夫稳态、PageRank）。
- **不变子空间**：每个特征向量张成一条 A–不变直线；Λ 把这些直线显式暴露出来。
- **对称时的强化**：$A = A^{\mathsf{T}}$ 时特征值全实、特征向量正交，S 可取正交矩阵 Q，于是 $A = Q\Lambda Q^{\mathsf{T}}$、$S^{-1} = S^{\mathsf{T}}$——既是最稳定的分解，也是数值上最好的分解（讲次 25）。

应用价值：

1. **幂运算**：$A^k = S\Lambda^k S^{-1}$（本讲核心）。
2. **逆矩阵**：若所有 $\lambda_i \neq 0$，$A^{-1} = S\Lambda^{-1}S^{-1}$（$\Lambda^{-1} = \mathrm{diag}(1/\lambda_i)$）。这也顺手证明了"$A$ 可逆 $\iff$ 无零特征值"，与讲次 21 一致。
3. **微分方程**：$\frac{d\mathbf{u}}{dt} = A\mathbf{u}$ 有解 $\mathbf{u}(t) = e^{At}\mathbf{u}(0) = Se^{\Lambda t}S^{-1}\mathbf{u}(0)$（讲次 23）。
4. **矩阵函数**：任何函数 f 都可用 $f(A) = Sf(\Lambda)S^{-1}$ 定义（e^{At}、$\sqrt{A}$ 皆如此）。
5. **降复杂度**：把 n 维耦合问题化为 n 个一维独立问题——所有"分而治之"思想的代数原型。

与其他讲次的关联

- **讲次 21（特征值与特征向量）**：本讲是它的直接续集。21 讲回答"$\boldsymbol{\lambda}$ 和 $\mathbf{x}$ 怎么求"，22 讲回答"求出来干什么用"——把它们装进 S 和 Λ，换取 A^k、A^{-1}、e^{At} 的公式。
- **讲次 18–20（行列式）**：$\det A = \prod_i \lambda_i$ 与 $\mathrm{tr}\, A = \sum_i \lambda_i$ 是求特征值的加速通道，本讲反复使用（例 1、例 2、例 3b 都靠迹+行列式一步到位）。
- **讲次 23（微分方程 $du/dt = Au$）**：解为 $Se^{\Lambda t}S^{-1}\mathbf{u}(0) = \sum_i c_i e^{\lambda_i t}\mathbf{x}_i$。稳定性判据变成"所有 $\mathrm{Re}\,\lambda_i < 0$"——与幂情形的 $|\lambda_i| < 1$ 是同一思想的不同版本。
- **讲次 24（马尔可夫矩阵）**：列随机矩阵必有 $\lambda = 1$；稳态就是 $\lambda = 1$ 的特征向量。本讲例 3(b) 已经预演。收敛性要求其余 $|\lambda_i| < 1$。
- **讲次 25（对称矩阵与正定）**：$A = A^{\mathsf{T}}$ 时 S 可取正交 Q，$A = Q\Lambda Q^{\mathsf{T}}$；且实对称矩阵一定可对角化（即使有重根，几何重数也必等于代数重数）——本讲的"可对角化条件"在对称情形自动满足。
- **讲次 27–28（正定与 Jordan 形）**：退化（不可对角化）情形由 Jordan 形接手，$A = SJS^{-1}$ 中 J 是"最接近对角"的三角矩阵；本讲例 2 提到的 $k\lambda^k$ 修正项就出自那里。
- **讲次 29（SVD）**：任意矩阵（包括长方阵、不可对角化的）都有 $A = U\Sigma V^{\mathsf{T}}$——把"两个不同基"允许进来，代价是 Σ 里的奇异值而非特征值。
- **讲次 31（基变换与相似）**：$A = S\Lambda S^{-1}$ 说明 A 与 Λ **相似**（$B = M^{-1}AM$）。相似矩阵描述**同一个线性变换**在不同基下的矩阵，因此共享特征值——这正是对角化何以可能：Λ 就是那个变换在特征向量基下的最简写法。
- **讲次 1–5（$A = LU$）与讲次 14–17（$A = QR$）**：三种分解对照——LU 服务于解方程，QR 服务于最小二乘与正交性，$S\Lambda S^{-1}$ 服务于动力学与幂。选择哪种分解，取决于你想问矩阵什么问题。

关键要点

1. **对角化公式**：若 $n \times n$ 矩阵 A 有 n 个线性无关的特征向量，把它们按列排成 S，则 $A = S\Lambda S^{-1}$，$\Lambda = \mathrm{diag}(\lambda_1, \ldots, \lambda_n)$；等价地 $AS = S\Lambda$。
2. **充要条件**：A 可对角化 $\iff$ 有 n 个线性无关特征向量 $\iff$ 每个特征值的几何重数 $=$ 代数重数。n 个互异特征值 $\Rightarrow$ 可对角化（反之不真）。
3. **幂公式**：$A^k = S\Lambda^k S^{-1} = \sum_{i=1}^{n} \lambda_i^k \mathbf{x}_i \mathbf{y}_i^{\mathsf{T}}$（其中 $\mathbf{y}_i^{\mathsf{T}}$ 是 S^{-1} 的第 i 行）。**幂运算 → 标量幂**，这是对角化的全部价值所在。
4. **收敛判据（幂情形）**：$A^k \to 0 \iff$ 所有 $|\lambda_i| < 1$。只要有一个 $|\lambda_i| > 1$，就存在初始向量使 $A^k\mathbf{u}_0$ 发散；$|\lambda_i| = 1$ 的成分既不衰减也不发散。长期行为由 $|\lambda_{\max}|$ 主导。
5. **迹/行列式判据（2×2 快速版）**：$\lambda_{1,2} = \dfrac{\mathrm{tr}\, A \pm \sqrt{(\mathrm{tr}\, A)^2 - 4\det A}}{2}$。判别式 < 0 时特征值为**共轭复数**（此时 $|\lambda|^2 = \det A$，可用 $\det A < 1$ 判定衰减）；$(\mathrm{tr}\, A)^2 = 4\det A$ 时出现重根，需检查 $\dim N(A - \lambda I)$ 才知可否对角化。注意 $\det A = 0$ 必有一个 $\lambda = 0$——矩阵奇异。

常见误区与注意事项

1. **以为所有矩阵都可对角化。** 这是最普遍的误解。$\begin{bmatrix} 3 & 1 \\ 0 & 3 \end{bmatrix}$ 就不可对角化：$\lambda = 3$ 是二重根但只有一条特征向量直线。**必须检查特征向量的个数与独立性**，不能只凭"n 个特征值（含重数）"就下结论。
2. **忘记 S 的列必须线性无关。** 常见错误：重根情形下把同一个特征向量的两个倍数（如 $\begin{bmatrix} 1 \\ 0 \end{bmatrix}$ 与 $\begin{bmatrix} 2 \\ 0 \end{bmatrix}$）塞进 S 的两列。此时 $\det S = 0$，S^{-1} 不存在，后续一切公式失效。**先算 $\det S$，它是你的安全阀。**
3. **混淆 A^k 公式里 S 与 S^{-1} 的顺序，以及 Λ^k 与特征向量的配对顺序。** 正确顺序是 $A^k = S\Lambda^k S^{-1}$（不是 $S^{-1}\Lambda^k S$，也不是 $S\Lambda S^{-1}$ 的各次方随便换序）。同时 Λ 的对角元顺序与 S 的列顺序**必须一一对应**：若 S 的第一列是 $\lambda = 1$ 的特征向量，则 Λ_{11} 必须是 1，不能是 3。换序会让结

果算错，且验算 $S\Lambda S^{-1}=A$ 会立刻暴露。

4. **以为特征值必须是实数。** 实矩阵的特征值可能是共轭复数，例如旋转矩阵 $\begin{bmatrix}0&-1\\1&0\end{bmatrix}$：$\mathrm{tr}=0,\det=1$，$\lambda=\pm i$，$|\lambda|=1$ 表示纯旋转——既不衰减也不发散，是"周期性振荡"这一第三类长期行为。此时实矩阵 A 在实数域内不可对角化（S 会是复矩阵），需用实 Jordan/旋转块描述。另注意：**即使 λ 是复数，A^k 仍是实矩阵**，共轭项总是成对出现并组合成实结果。
5. **把"A 可逆"与"A 可对角化"混为一谈。** 这是两个完全独立的性质。$\begin{bmatrix}3&1\\0&3\end{bmatrix}$ 可逆（$\det=9\neq0$）却不可对角化；$\begin{bmatrix}0&0\\0&1\end{bmatrix}$ 不可逆却可对角化（$\lambda=0,1$，$\mathbf{e_1},\mathbf{e_2}$）。可逆性看是否有零特征值（讲次 21），可对角化看独立特征向量是否够数。

思考题（带答案）

Q1.（计算题）设 $A=\begin{bmatrix}4&1\\2&3\end{bmatrix}$。求 A 的对角化 $A=S\Lambda S^{-1}$，写出 A^{100} 的表达式，并指出 A^{100} 中占主导的项与第二特征值成分的相对大小。

▸ **答案**

求特征值。 $\mathrm{tr}\,A=4+3=7$，$\det A=4\cdot3-1\cdot2=12-2=10$。故

$$\lambda^2-7\lambda+10=(\lambda-5)(\lambda-2)=0\implies\lambda_1=5,\quad\lambda_2=2.$$

求特征向量。 对 $\lambda_1=5$：$A-5I=\begin{bmatrix}-1&1\\2&-2\end{bmatrix}$，方程 $-x_1+x_2=0$，取 $\mathbf{x}_1=\begin{bmatrix}1\\1\end{bmatrix}$（脚本核对 $A\begin{bmatrix}1\\1\end{bmatrix}=\begin{bmatrix}5\\5\end{bmatrix}$ ✓）。对 $\lambda_2=2$：$A-2I=\begin{bmatrix}2&1\\2&1\end{bmatrix}$，方程 $2x_1+x_2=0$，取 $\mathbf{x}_2=\begin{bmatrix}1\\-2\end{bmatrix}$（脚本核对 $A\begin{bmatrix}1\\-2\end{bmatrix}=\begin{bmatrix}2\\-4\end{bmatrix}$ ✓）。

装配。 $S=\begin{bmatrix}1&1\\1&-2\end{bmatrix}$，$\det S=1\cdot(-2)-1\cdot1=-3\neq0$，故可对角化。

$$S^{-1}=\frac{1}{-3}\begin{bmatrix}-2&-1\\-1&1\end{bmatrix}=\frac{1}{3}\begin{bmatrix}2&1\\1&-1\end{bmatrix},\qquad\Lambda=\begin{bmatrix}5&0\\0&2\end{bmatrix}.$$

验算：$S\Lambda S^{-1}=\frac{1}{3}\begin{bmatrix}5&2\\5&-4\end{bmatrix}\begin{bmatrix}2&1\\1&-1\end{bmatrix}=\frac{1}{3}\begin{bmatrix}12&3\\6&9\end{bmatrix}=\begin{bmatrix}4&1\\2&3\end{bmatrix}=A$ ✓（脚本核对）。

A^{100}。

$$A^{100}=S\begin{bmatrix}5^{100}&0\\0&2^{100}\end{bmatrix}S^{-1}=\frac{1}{3}\begin{bmatrix}2\cdot5^{100}+2^{100}&5^{100}-2^{100}\\2\cdot5^{100}-2\cdot2^{100}&5^{100}+2\cdot2^{100}\end{bmatrix}.$$

主导项分析。 $5^{100}\approx7.889\times10^{69}$，$2^{100}\approx1.268\times10^{30}$，比值 $2^{100}/5^{100}=(0.4)^{100}\approx1.6\times10^{-40}$——完全可忽略。所以

$$A^{100}\approx\frac{5^{100}}{3}\begin{bmatrix}2&1\\2&1\end{bmatrix}.$$

关键观察：两行几乎相同（比值 $2:1$ 的比例），两列也几乎成比例。这不是巧合——k 大时 A^k 几乎是一个**秩 1 矩阵**，它的列空间趋向于 $\lambda=5$ 的特征向量方向 $\begin{bmatrix}1\\1\end{bmatrix}$，行方向趋向 S^{-1} 的第一行 $[2/3\quad1/3]$。这正是幂法的几何意义，也是 PageRank 能靠反复迭代收敛的道理。数值核对：脚本给出 A^{100} 的最大元素 5.259×10^{69}，$5^{100}\cdot2/3=5.259\times10^{69}$ ✓，且 $(\text{元素}_{01})/(\text{元素}_{00})$ 精确为 0.5 ✓。

Q2.（概念题）判断下列说法真假，并说明理由：(a) 若 A 是 3×3 实矩阵且有 3 个互异特征值，则 A 一定可对角化。(b) 若 A 可逆，则 A 一定可对角化。(c) 若 A 的所有特征值满足 $|\lambda|<1$，则 $A^k\to\mathbf{0}$。(d) 若 A 与 B 有相同的特征值，则 A,B 相似。

▸ **答案**

(a) 真。 互异特征值对应的特征向量线性无关，这是特征值理论的标准结论（证法：对个数归纳，用 $A\mathbf{x}_k=\lambda_k\mathbf{x}_k$ 作用在组合式上再减去 λ_k 倍原式，得到特征值互异与组合非零的矛盾）。于是有 3 个独立特征向量，S 可逆。

(b) 假。 反例 $A=\begin{bmatrix}3&1\\0&3\end{bmatrix}$：$\det A=9\neq0$ 可逆，但 $\lambda=3$ 二重，$\dim N(A-3I)=2-\mathrm{rank}(A-3I)=2-1=1$，没有 2 个独立特征向量。**可逆性只保证没有零特征值，与特征向量是否够数无关。**

(c) 真（且不需要可对角化）。 这就是**谱半径定理**：$A^k\to0\iff\rho(A)=\max_i|\lambda_i|<1$。值得强调的是它**不要求 A 可对角化**。以 $A=\begin{bmatrix}0.5&1\\0&0.5\end{bmatrix}$ 为例，$\lambda=0.5$（二重），A 不可对角化，但

$$A^k = \begin{bmatrix} 0.5^k & k\,0.5^{k-1} \\ 0 & 0.5^k \end{bmatrix}.$$

> $k0.5^{k-1}$ 的确先短暂上升（$k=1,2$ 时都等于 1，$k=3$ 时 0.75），但随后被指数压倒：$k=10$ 时约 0.0195，$k=20$ 时约 3.8×10^{-5}，$k=50$ 时约 9.0×10^{-14}（脚本核对 $\|A^{20}\|_\infty \approx 3.9\times10^{-5}$、$\|A^{50}\|_\infty \approx 9.0\times10^{-14}$）。**多项式因子 k^m 打不过指数衰减 λ^k**，这正是 Jordan 形（讲次 28）给出的结论：$A^k\to 0$ 的**充要条件始终是所有 $|\lambda_i|<1$**。对角线化在本命题中只是一条更方便的证明路径，而非必要条件。反面对照：$A=\begin{bmatrix}1&1\\0&1\end{bmatrix}$（有 $|\lambda|=1$），$A^k=\begin{bmatrix}1&k\\0&1\end{bmatrix}$ 无界——可见 $|\lambda|=1$ 且不可对角化时确实会发散。
>
> **(d) 假（反之才真）。** 相似矩阵必有相同特征值（因为 $\det(B-\lambda I)=\det(M^{-1}(A-\lambda I)M)=\det(A-\lambda I)$），但反之不成立。反例：$A=\begin{bmatrix}2&0\\0&2\end{bmatrix}$ 与 $B=\begin{bmatrix}2&1\\0&2\end{bmatrix}$ 特征值都是 $2,2$，但 A 相似于自身的任何共轭仍是 $2I$，而 $B\neq 2I$、与任何矩阵共轭后仍 $\neq 2I$，故不相似。判别标准是 **Jordan 形相同**，而不仅是特征值相同。

Q3.（综合题）设 Fibonacci 矩阵 $A=\begin{bmatrix}1&1\\1&0\end{bmatrix}$，状态 $\mathbf{u}_k=\begin{bmatrix}F_{k+1}\\F_k\end{bmatrix}$。(a) 用对角化方案写出 $\mathbf{u}_k$ 的闭式解，并据此求 F_{10}。(b) 求 $\lim_{k\to\infty} F_{k+1}/F_k$。(c) 若把递推改成 $G_{k+1}=G_k+G_{k-1}$ 但初值 $G_0=2, G_1=1$（Lucas 数），说明长期增长率是否改变。

> ▸ **答案**
>
> (a) 特征值 $\lambda_{1,2}=\frac{1\pm\sqrt{5}}{2}$ 即 $\varphi\approx 1.618034$ 与 $\psi\approx -0.618034$，特征向量 $\mathbf{x}_1=\begin{bmatrix}\varphi\\1\end{bmatrix}$、$\mathbf{x}_2=\begin{bmatrix}\psi\\1\end{bmatrix}$（脚本核对 $A\mathbf{x}_i=\lambda_i\mathbf{x}_i$ ✓）。由 $\mathbf{u}_0=\begin{bmatrix}1\\0\end{bmatrix}$ 得系数 $c_1=-c_2=1/\sqrt{5}$，故

$$\mathbf{u}_k=\frac{1}{\sqrt{5}}\left(\varphi^k\begin{bmatrix}\varphi\\1\end{bmatrix}-\psi^k\begin{bmatrix}\psi\\1\end{bmatrix}\right)\Longrightarrow F_k=\frac{\varphi^k-\psi^k}{\sqrt{5}}.$$

> 取 $k=10$：$\varphi^{10}=122.9919\ldots$，$\psi^{10}=0.00813\ldots$，
>
> $$F_{10}=\frac{122.9919-0.0081}{2.2360680}=\frac{122.9838}{2.2360680}=55.0000\ldots\Longrightarrow F_{10}=55\ \checkmark$$
>
> （脚本直接核算 $F_{10}=55$ ✓，$F_1=1,F_2=1,F_3=2,F_5=5,F_{20}=6765$ 亦全部核对 ✓。）
>
> (b) 因为 $|\psi|<1$，$\psi^k\to 0$，故
>
> $$\frac{F_{k+1}}{F_k}\approx\frac{\varphi^{k+1}/\sqrt{5}}{\varphi^k/\sqrt{5}}=\varphi=\frac{1+\sqrt{5}}{2}\approx 1.618034.$$
>
> 误差随 k 以 $|\psi/\varphi|^k=|\psi^2|^k\approx 0.382^k$ 的速度消失。
>
> (c) 初值只改变系数 c_1,c_2，**不改变特征值**。对 Lucas 数（$G_0=2,G_1=1$），解 $S\mathbf{c}=(G_1,G_0)^{\mathsf T}=(1,2)^{\mathsf T}$ 得 $c_1=\frac{1-2\psi}{\varphi-\psi}=1$、$c_2=1$（代回 $c_1\varphi^k+c_2\psi^k$ 在 $k=0,1,2,3$ 给出 $2,1,3,4$ ✓，与下面数列一致）。所以只要 $c_1\neq 0$（即初始向量在 $\mathbf{x}_1$ 方向上有非零分量），长期增长率仍由 φ 主导，$G_{k+1}/G_k\to\varphi$ 不变。Lucas 数 $2,1,3,4,7,11,18,29,47,76,\ldots$ 确实也趋近黄金比例。**一般结论：增长率由 $|\lambda_{\max}|$ 唯一决定，与初始条件无关；初始条件只决定各模式的权重**——这是本讲最重要的结构性认识。

Lecture 23: Differential Equations and exp(At)

概述

本讲把特征值从"静态"带入"动态"：求解线性常微分方程组 $d\mathbf{u}/dt=A\mathbf{u}$。核心结论只有一句话——**把初始向量 $\mathbf{u}(0)$ 分解到 A 的特征向量方向上，每个方向各自按 $e^{\lambda_i t}$ 独立演化，再线性叠加**。由此得到解 $\mathbf{u}(t)=\sum_i c_i e^{\lambda_i t}\mathbf{x}_i$，进一步浓缩为一个对象：矩阵指数 $e^{At}=Se^{\Lambda t}S^{-1}$，于是 $\mathbf{u}(t)=e^{At}\mathbf{u}(0)$，与标量情形 $u=e^{\lambda t}u(0)$ 完全平行。

这是特征值理论最漂亮的应用，也是"稳定性"这一物理概念首次获得**纯代数判据**的地方：系统是否衰减到零，只取决于所有特征值的**实部**。

核心概念的几何直觉

从标量到系统：为什么特征方向会"各自为政"

- **定义与目的**：标量方程 $\frac{du}{dt}=\lambda u$ 的解是 $u(t)=Ce^{\lambda t}$。现在 u 变成向量 $\mathbf{u}\in\mathbb{R}^n$，系数变成矩阵 A，方程为 $\frac{d\mathbf{u}}{dt}=A\mathbf{u}$。我们要找它的通解。

- **几何直觉（它在空间中是什么样子？）**：A 作用在向量上，一般会同时**旋转**并**伸缩**它。但如果向量恰好落在特征方向 $\mathbf{x}_i$ 上，$A\mathbf{x}_i = \lambda_i \mathbf{x}_i$，此时 A 退化成"纯粹的伸缩"——没有旋转。于是在这个特殊方向上，向量方程**退化成一维标量方程**：

$$\frac{d}{dt}\big(c_i(t)\mathbf{x}_i\big) = A\big(c_i(t)\mathbf{x}_i\big) = \lambda_i c_i(t)\mathbf{x}_i \quad\Longrightarrow\quad \frac{dc_i}{dt} = \lambda_i c_i \quad\Longrightarrow\quad c_i(t) = c_i(0)e^{\lambda_i t}$$

也就是说：**在特征坐标系下，n 维耦合系统彻底解耦成 n 个互不干扰的一维指数过程**。$\lambda_i > 0$ 的方向指数爆炸，$\lambda_i < 0$ 的方向指数湮灭，λ_i 为纯虚数的方向原地打转。整个轨线是这些独立运动的叠加。 – **具体示例**：$A = \begin{bmatrix} -1 & 2 \\ 2 & -1 \end{bmatrix}$ 有特征方向 $\mathbf{x}_1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$（$\lambda_1 = 1$，增长）与 $\mathbf{x}_2 = \begin{bmatrix} 1 \\ -1 \end{bmatrix}$（$\lambda_2 = -3$，衰减）。沿 45° 线的运动被放大，沿 135° 线的运动被强烈压扁——轨线最终被"吸"到 $\mathbf{x}_1$ 方向上。

矩阵指数 e^{At}

- **定义与目的**：把标量幂级数 $e^z = 1 + z + \frac{z^2}{2!} + \frac{z^3}{3!} + \cdots$ 中的 z 换成矩阵 At：

$$e^{At} = I + At + \frac{(At)^2}{2!} + \frac{(At)^3}{3!} + \cdots = \sum_{k=0}^{\infty} \frac{A^k t^k}{k!}$$

它把"初始状态"线性地搬运到"时刻 t 的状态"：$\mathbf{u}(t) = e^{At}\mathbf{u}(0)$。$e^{At}$ 是一个**矩阵**（$n \times n$），不是一个数，也绝不等同于逐元素取指数。 – **几何直觉（它在空间中是什么样子？）**：e^{At} 是一族随 t 连续变化的线性变换。$t = 0$ 时它是恒等映射 I（什么都不做）；随着 t 增大，它在 $\mathbf{x}_2$ 方向猛烈压缩、在 $\mathbf{x}_1$ 方向缓慢拉伸。整个相平面上的点被这个"随时间变形的线性映射"推动着流动。 – **具体示例**：对上面的 A，$e^{A\cdot 0} = I$；$t = 0.7$ 时 $e^{At}\begin{bmatrix} 1 \\ 0 \end{bmatrix} = \begin{bmatrix} 1.068105 \\ 0.945648 \end{bmatrix}$（数值已验算），说明初始在 x 轴上的点被推到了右上角并趋向 $\mathbf{x}_1$ 方向。

稳定性：由特征值实部决定

- **定义与目的**：系统 $\mathbf{u}(t) = \sum c_i e^{\lambda_i t}\mathbf{x}_i$ 的长期行为。由于 $|e^{\lambda t}| = e^{\mathrm{Re}(\lambda)t}$，**虚部只贡献振荡，实部才决定增衰**。
- **几何直觉（它在空间中是什么样子？）**：把 n 个特征值画在复平面上。左半平面（$\mathrm{Re}\lambda < 0$）= 衰减；右半平面（$\mathrm{Re}\lambda > 0$）= 爆炸；虚轴（$\mathrm{Re}\lambda = 0$）= 中性振荡。整个系统的命运由"最靠右的那个特征值"决定。
- **具体示例**：$A = \begin{bmatrix} -2 & 1 \\ 1 & -2 \end{bmatrix}$ 的 $\lambda = -1, -3$ 全在左半平面 $\Rightarrow \mathbf{u}(t) \to \mathbf{0}$（稳定）。$A = \begin{bmatrix} 0 & -1 \\ 1 & 0 \end{bmatrix}$ 的 $\lambda = \pm i$ 恰在虚轴上 $\Rightarrow$ 解为 $\cos t,\ \sin t$，绕单位圆永远转圈（中性）。

线性动态系统的物理原型（同一个原理的不同外衣）

- **定义与目的**：$\mathbf{u}' = A\mathbf{u}$ 不是纯数学玩具。几乎所有"线性 + 随时间演化"的物理系统都长这个样子，A 的具体内容随学科变化，但"**稳定性由 $\mathrm{Re}\,\lambda$ 决定**"这一结论完全普适——这是线性代数为整个应用科学提供的通用语言。
- **几何直觉（它在空间中是什么样子？）**：把系统状态看成相空间中的一个点，A 决定这个点周围"速度场"的形状。弹簧让点绕着平衡位置转圈，摩擦让它螺旋内收，正反馈让它螺旋外扩。三种图景对应特征值的三种位置。

原型 1：弹簧–质点系统。设质量 $m = 1$，弹簧刚度 $k = 1$，阻尼 c。令状态 $\mathbf{u} = \begin{bmatrix} x \\ v \end{bmatrix}$（位移、速度），则

$$\frac{d\mathbf{u}}{dt} = \begin{bmatrix} 0 & 1 \\ -k/m & -c/m \end{bmatrix}\mathbf{u} = \begin{bmatrix} 0 & 1 \\ -1 & -c \end{bmatrix}\mathbf{u}$$

- 无阻尼（$c = 0$）：$\mathrm{tr}\,A = 0$，$\det A = 1$，$\lambda = \pm i \Rightarrow$ **中性振荡**（简谐运动，能量守恒，永远振动）。这与本讲示例 3 的 $A = \begin{bmatrix} 0 & -1 \\ 1 & 0 \end{bmatrix}$ 是同一类型（相差一个正交相似变换）。
- 有阻尼（$c = 0.5$）：$\mathrm{tr}\,A = -0.5 < 0$，$\det A = 1 > 0$，$\lambda = -0.25 \pm 0.968i \Rightarrow$ **稳定螺旋**：边振荡边衰减，振幅按 $e^{-0.25t}$ 收缩。阻尼越大，实部越负，衰减越快；阻尼超过临界值 $c = 2\sqrt{k/m} = 2$ 时 λ 变为两个负实数，振荡消失（**过阻尼**），这正是判别式 $\mathrm{tr}^2 - 4\det$ 的符号所控制的分界。
- 负阻尼（$c < 0$，如自激振荡、气动颤振）：$\mathrm{tr}\,A > 0 \Rightarrow \mathrm{Re}\,\lambda > 0 \Rightarrow$ **不稳定**，振幅指数爆炸。这是塔科马海峡大桥倒塌这类事故的线性模型内核。

原型 2：RLC 电路。取电感 L、电容 C、电阻 R，以 $\mathbf{u} = \begin{bmatrix} v_C \\ i_L \end{bmatrix}$ 为状态，得到同样形式的 2×2 矩阵。数值上取 $L = C = 1$，$R = 0.2$：

$$\frac{d\mathbf{u}}{dt} = \begin{bmatrix} 0 & 1 \\ -1/L & -R/L \end{bmatrix}\mathbf{u} = \begin{bmatrix} 0 & 1 \\ -1 & -0.2 \end{bmatrix}\mathbf{u}, \qquad \lambda = -0.1 \pm 0.995i$$

$\mathrm{Re}\,\lambda = -0.1 < 0 \Rightarrow$ **稳定螺旋**（阻尼振荡，电路中的"振铃"现象）。$R = 0$ 时退化为 $\lambda = \pm i$，即无耗散的 LC 振荡器（与理想弹簧完全同构——**力学与电学在这里是同一条数学**）。注意 $\mathrm{tr}\,A = -R/L$、$\det A = 1/(LC)$，稳定性条件是 $R > 0$：**电阻必须为正才能耗能**，负电阻（有源器件）会导致发散。

原型 3：化学反应动力学。设两种物质浓度 a, b 满足 $\dot{a} = -k_1 a + k_2 b$，$\dot{b} = k_1 a - k_2 b$（可逆反应 $A \rightleftharpoons B$），则

$$A = \begin{bmatrix} -k_1 & k_2 \\ k_1 & -k_2 \end{bmatrix}, \qquad \mathrm{tr}\,A = -(k_1 + k_2) < 0, \quad \det A = k_1 k_2 - k_1 k_2 = 0$$

$\det A = 0 \Rightarrow$ 有一个 $\lambda = 0$（守恒量：总浓度 $a+b$ 不变，对应特征向量 $\begin{bmatrix}1\\1\end{bmatrix}$），另一个 $\lambda = -(k_1+k_2) < 0$。于是解**收敛到平衡浓度**（不是收敛到零）：$\lambda = 0$ 方向保持初值投影不变，衰减方向消失。这正是"中性方向"的物理意义——**守恒律对应 $\lambda = 0$**。这与讲次 24 马尔可夫矩阵"$\lambda = 1$ 是稳态"在结构上完全平行。

原型 4：种群模型。捕食者–被捕食者（Lotka–Volterra 的线性化）、或两个竞争种群 $\dot{u}_1 = -u_1 + 2u_2$，$\dot{u}_2 = 2u_1 - u_2$——**这不是别的，正是本讲示例 1 的 A**！它说的是：物种 1 被物种 2 的存在促进（$+2u_2$），反之亦然，于是存在一个 $\lambda = 1 > 0$ 的"共同增长模态"。模型预测两物种都指数增长（在资源无限的前提下），系统不稳定；而 $\lambda = -3$ 的模态是一个快速衰减的"差异模态"（$u_1 - u_2 \to 0$），即**两物种的差距迅速抹平，随后同步爆炸**。这与前面算出的 $t = 0.7$ 时 $u_1 \approx u_2$ 完全一致。

普适原理的表述：无论力学、电学、化学还是生态学，只要系统在平衡点附近可线性化为 $\mathbf{u}' = A\mathbf{u}$，那么 （i）$\operatorname{Re}\lambda < 0 \Rightarrow$ 平衡点渐近稳定，扰动被抹去； （ii）存在 $\operatorname{Re}\lambda > 0 \Rightarrow$ 平衡点不稳定，小扰动指数放大； （iii）$\operatorname{Re}\lambda = 0 \Rightarrow$ 临界情形，线性化不足以定论，需要看高阶项（本课程之外）。 这一原理的威力在于：**判断稳定性完全不需要解方程**，只需算 $\det(A - \lambda I) = 0$ 的根落在复平面哪一半。

计算步骤与手算演示

构造步骤（通解四步法）

1. 求 A 的全部特征值 λ_i 与特征向量 $\mathbf{x}_i$（解 $\det(A-\lambda I)=0$，再解 $(A-\lambda_i I)\mathbf{x}_i = \mathbf{0}$）。
2. 写出通解 $\mathbf{u}(t) = c_1 e^{\lambda_1 t}\mathbf{x}_1 + c_2 e^{\lambda_2 t}\mathbf{x}_2 + \cdots + c_n e^{\lambda_n t}\mathbf{x}_n$。
3. 代入 $t = 0$：$\mathbf{u}(0) = c_1\mathbf{x}_1 + c_2\mathbf{x}_2 + \cdots + c_n\mathbf{x}_n$，即 $\mathbf{u}(0) = S\mathbf{c}$，解出 $\mathbf{c} = S^{-1}\mathbf{u}(0)$。
4. 合并成矩阵形式 $\mathbf{u}(t) = Se^{\Lambda t}S^{-1}\mathbf{u}(0) = e^{At}\mathbf{u}(0)$。

【计算机制解说】：为什么 $\mathbf{u}(t) = \sum_i c_i e^{\lambda_i t}\mathbf{x}_i$ 是**通解**？两个原因缺一不可。 （a）**解对线性运算封闭（叠加原理）**：方程 $\mathbf{u}' = A\mathbf{u}$ 是线性的。若 $\mathbf{u}$ 与 $\mathbf{v}$ 都是解，则 $(a\mathbf{u}+b\mathbf{v})' = a\mathbf{u}' + b\mathbf{v}' = A(a\mathbf{u}+b\mathbf{v})$，所以任意线性组合仍是解。更一般地，**初值问题的解唯一**（给定 $\mathbf{u}(0)$，解被完全确定），因此只要我们的表达式能匹配任意给定的 $\mathbf{u}(0)$，它就是通解。 （b）**特征向量构成一组基**：当 A 有 n 个线性无关的特征向量时，它们张成整个 $\mathbb{R}^n$。于是**任何**初始向量都能唯一写成 $\mathbf{u}(0) = \sum c_i\mathbf{x}_i$。把这两条合起来：每个纯粹的特征模态 $\mathbf{x}_i$ 给出一个解 $e^{\lambda_i t}\mathbf{x}_i$，叠加原理给出任意组合都是解，而基性质保证任意初值都能被某个组合匹配。三者一夹，通解的形式就被**唯一确定**了。

示例 1（不稳定）：$A = \begin{bmatrix}-1 & 2\\ 2 & -1\end{bmatrix}$

步骤 1：特征值与特征向量

$$\det(A-\lambda I) = \begin{vmatrix}-1-\lambda & 2\\ 2 & -1-\lambda\end{vmatrix} = (-1-\lambda)^2 - 4 = \lambda^2 + 2\lambda + 1 - 4 = \lambda^2 + 2\lambda - 3$$

$$\lambda^2 + 2\lambda - 3 = (\lambda+3)(\lambda-1) = 0 \quad\Longrightarrow\quad \boxed{\lambda_1 = 1, \qquad \lambda_2 = -3}$$

（核对：$\operatorname{tr}A = -2 = 1 + (-3)$ ✓；$\det A = (-1)(-1) - 2\cdot 2 = 1 - 4 = -3 = 1\times(-3)$ ✓。）

- $\lambda_1 = 1$：$A - I = \begin{bmatrix}-2 & 2\\ 2 & -2\end{bmatrix}$，解 $-2x_1 + 2x_2 = 0 \Rightarrow x_1 = x_2$，取 $\mathbf{x}_1 = \begin{bmatrix}1\\1\end{bmatrix}$。
- $\lambda_2 = -3$：$A + 3I = \begin{bmatrix}2 & 2\\ 2 & 2\end{bmatrix}$，解 $x_1 + x_2 = 0 \Rightarrow x_2 = -x_1$，取 $\mathbf{x}_2 = \begin{bmatrix}1\\-1\end{bmatrix}$。

核对 $A\mathbf{x}_1 = \begin{bmatrix}-1+2\\2-1\end{bmatrix} = \begin{bmatrix}1\\1\end{bmatrix} = 1\cdot\mathbf{x}_1$ ✓；$A\mathbf{x}_2 = \begin{bmatrix}-1-2\\2+1\end{bmatrix} = \begin{bmatrix}-3\\3\end{bmatrix} = -3\begin{bmatrix}1\\-1\end{bmatrix}$ ✓。

注意 $\mathbf{x}_1 \perp \mathbf{x}_2$（点积 $1\cdot 1 + 1\cdot(-1) = 0$）——因为 A 对称，特征向量正交，S 可以取成正交矩阵（讲次 25）。

步骤 2：写通解

$$\mathbf{u}(t) = c_1 e^{1\cdot t}\begin{bmatrix}1\\1\end{bmatrix} + c_2 e^{-3t}\begin{bmatrix}1\\-1\end{bmatrix}$$

步骤 3：用初值定常数（取 $\mathbf{u}(0) = \begin{bmatrix}1\\0\end{bmatrix}$）

$$c_1\begin{bmatrix}1\\1\end{bmatrix} + c_2\begin{bmatrix}1\\-1\end{bmatrix} = \begin{bmatrix}1\\0\end{bmatrix} \quad\Longrightarrow\quad \begin{cases}c_1 + c_2 = 1\\ c_1 - c_2 = 0\end{cases} \quad\Longrightarrow\quad c_1 = c_2 = \tfrac{1}{2}$$

（矩阵写法：$S = \begin{bmatrix}1 & 1\\1 & -1\end{bmatrix}$，$\mathbf{c} = S^{-1}\mathbf{u}(0)$。）

步骤 4：最终解与分量形式

$$\boxed{\mathbf{u}(t) = \frac{1}{2}e^{t}\begin{bmatrix}1\\1\end{bmatrix} + \frac{1}{2}e^{-3t}\begin{bmatrix}1\\-1\end{bmatrix}}$$

$$u_1(t)=\frac{e^{t}+e^{-3t}}{2},\qquad u_2(t)=\frac{e^{t}-e^{-3t}}{2}$$

验证：$t=0$ 时 $u_1=\frac{1+1}{2}=1$，$u_2=\frac{1-1}{2}=0$，得 $\begin{bmatrix}1\\0\end{bmatrix}$ ✓。导数验证（数值已核对，误差 $\sim 10^{-11}$）：

$$\frac{du_1}{dt}=\frac{e^{t}-3e^{-3t}}{2},\qquad \frac{du_2}{dt}=\frac{e^{t}+3e^{-3t}}{2}$$

$$A\mathbf{u}=\begin{bmatrix}-u_1+2u_2\\2u_1-u_2\end{bmatrix}=\begin{bmatrix}-\frac{e^{t}+e^{-3t}}{2}+(e^{t}-e^{-3t})\\(e^{t}+e^{-3t})-\frac{e^{t}-e^{-3t}}{2}\end{bmatrix}=\begin{bmatrix}\frac{e^{t}-3e^{-3t}}{2}\\\frac{e^{t}+3e^{-3t}}{2}\end{bmatrix}\checkmark$$

结论：存在 $\lambda_1=1>0\Rightarrow$ 含 e^{t} 的项发散 $\Rightarrow$ **系统不稳定**。$t=0.7$ 时 $\mathbf{u}=\begin{bmatrix}1.068105\\0.945648\end{bmatrix}$——两个分量已几乎相等，说明轨线正被吸入 $\mathbf{x}_1=\begin{bmatrix}1\\1\end{bmatrix}$ 方向。

```
  A = [[-1, 2], [2, -1]]  相平面 (u1, u2)

       u2
        ^
x2  *   |  *  x1        x1=[1,1] (lam=+1)  ← 增长方向（吸引子）
 \      |     /         x2=[1,-1](lam=-3)  ← 衰减方向（压缩）
  \     |    /
   \    |   /
----+---+--+----> u1
   /    |   \
  /     |    \
 /      |     \
       u(0)=(1,0) 出发的轨线：先被 x2 方向压扁，再沿 x1 冲出
```

示例 2（稳定）：$A=\begin{bmatrix}-2&1\\1&-2\end{bmatrix}$

步骤 1：

$$\det(A-\lambda I)=(-2-\lambda)^2-1=\lambda^2+4\lambda+3=(\lambda+1)(\lambda+3)\implies \boxed{\lambda_1=-1,\ \lambda_2=-3}$$

（$\operatorname{tr}A=-4=-1+(-3)$ ✓，$\det A=4-1=3=(-1)(-3)$ ✓。）

- $\lambda_1=-1$：$A+I=\begin{bmatrix}-1&1\\1&-1\end{bmatrix}\Rightarrow \mathbf{x}_1=\begin{bmatrix}1\\1\end{bmatrix}$。
- $\lambda_2=-3$：$A+3I=\begin{bmatrix}1&1\\1&1\end{bmatrix}\Rightarrow \mathbf{x}_2=\begin{bmatrix}1\\-1\end{bmatrix}$。

（核对：$A\begin{bmatrix}1\\1\end{bmatrix}=\begin{bmatrix}-1\\-1\end{bmatrix}=-1\mathbf{x}_1$ ✓；$A\begin{bmatrix}1\\-1\end{bmatrix}=\begin{bmatrix}-3\\3\end{bmatrix}=-3\mathbf{x}_2$ ✓。）

步骤 2–3：取 $\mathbf{u}(0)=\begin{bmatrix}1\\0\end{bmatrix}$，同样得 $c_1=c_2=\frac{1}{2}$：

$$\boxed{\mathbf{u}(t)=\frac{1}{2}e^{-t}\begin{bmatrix}1\\1\end{bmatrix}+\frac{1}{2}e^{-3t}\begin{bmatrix}1\\-1\end{bmatrix}}$$

$$u_1(t)=\frac{e^{-t}+e^{-3t}}{2},\qquad u_2(t)=\frac{e^{-t}-e^{-3t}}{2}$$

验证：$t=0\Rightarrow\begin{bmatrix}1\\0\end{bmatrix}$ ✓。数值：$t=1$ 时 $\begin{bmatrix}0.208833\\0.159046\end{bmatrix}$；$t=5$ 时 $\begin{bmatrix}0.003369\\0.003369\end{bmatrix}\Rightarrow\mathbf{u}(t)\to\mathbf{0}$。导数数值核对：$\mathbf{u}'(0.9)=\begin{bmatrix}-0.3040931\\-0.1024766\end{bmatrix}$ 与 $A\mathbf{u}(0.9)=\begin{bmatrix}-0.3040931\\-0.1024766\end{bmatrix}$ 一致 ✓。

结论：$\lambda_1=-1<0$，$\lambda_2=-3<0\Rightarrow$ **稳定**（渐近稳定，$\mathbf{u}(t)\to\mathbf{0}$）。慢慢的那个方向（$-1$）决定衰减速率，$e^{-3t}$ 很快消失，最后 $u_1\approx u_2\approx\frac{1}{2}e^{-t}$。

示例 3（中性/振荡）：$A=\begin{bmatrix}0&-1\\1&0\end{bmatrix}$

步骤 1：

$$\det(A-\lambda I)=\begin{vmatrix}-\lambda&-1\\1&-\lambda\end{vmatrix}=\lambda^2+1=0\implies\boxed{\lambda=\pm i}$$

（$\operatorname{tr} A = 0 \Rightarrow \lambda_1 + \lambda_2 = 0$ ✓；$\det A = 0\cdot 0 - (-1)(1) = 1 = i\cdot(-i)$ ✓。）

特征向量（允许复向量）：$\lambda = i$ 时 $A - iI = \begin{bmatrix} -i & -1 \\ 1 & -i \end{bmatrix}$，方程 $-ix_1 - x_2 = 0 \Rightarrow x_2 = -ix_1$，取 $\mathbf{x} = \begin{bmatrix} 1 \\ -i \end{bmatrix}$。核对 $A\begin{bmatrix} 1 \\ -i \end{bmatrix} = \begin{bmatrix} 0\cdot 1 + (-1)(-i) \\ 1\cdot 1 + 0\cdot(-i) \end{bmatrix} = \begin{bmatrix} i \\ 1 \end{bmatrix} = i\begin{bmatrix} 1 \\ -i \end{bmatrix}$ ✓。

步骤 2–3：取 $\mathbf{u}(0) = \begin{bmatrix} 1 \\ 0 \end{bmatrix}$，用复解 $e^{it}\begin{bmatrix} 1 \\ -i \end{bmatrix}$ 并在实/虚部之间组合：

$$\mathbf{u}(t) = \frac{1}{2}\left(e^{it}\begin{bmatrix} 1 \\ -i \end{bmatrix} + e^{-it}\begin{bmatrix} 1 \\ i \end{bmatrix}\right) = \begin{bmatrix} \cos t \\ \sin t \end{bmatrix}$$

验证：$\mathbf{u}(0) = \begin{bmatrix} 1 \\ 0 \end{bmatrix}$ ✓。导数：$\mathbf{u}'(t) = \begin{bmatrix} -\sin t \\ \cos t \end{bmatrix}$，而 $A\mathbf{u}(t) = \begin{bmatrix} -u_2 \\ u_1 \end{bmatrix} = \begin{bmatrix} -\sin t \\ \cos t \end{bmatrix}$ ✓（数值核对一致）。$\|\mathbf{u}(t)\|^2 = \cos^2 t + \sin^2 t = 1$ 恒定 ✓ $\Rightarrow$ 轨线是**单位圆**。

结论：$\operatorname{Re}(\pm i) = 0 \Rightarrow$ **中性**：不衰减也不发散，最右端点在 $t \to \infty$ 时不存在极限（$u_1 = \cos t$ 一直摆动）。

补充：连续与离散的桥梁（为什么连接 A 与 A^k 的是"指数"）

这一小节把本讲（连续时间）与讲次 22、24（离散时间）缝在一起。考虑把连续方程 $\mathbf{u}' = A\mathbf{u}$ 用最简单的前向欧拉法离散化，取时间步长 Δt：

$$\frac{\mathbf{u}_{k+1} - \mathbf{u}_k}{\Delta t} = A\mathbf{u}_k \quad\Longrightarrow\quad \mathbf{u}_{k+1} = \underbrace{(I + A\Delta t)}_{M}\mathbf{u}_k \quad\Longrightarrow\quad \mathbf{u}_k = M^k\mathbf{u}_0$$

于是连续系统的**特征值**与离散迭代矩阵 $M = I + A\Delta t$ 的**特征值**之间有严格对应。若 $A\mathbf{x} = \lambda\mathbf{x}$，则

$$M\mathbf{x} = (I + A\Delta t)\mathbf{x} = (1 + \lambda\Delta t)\mathbf{x} \quad\Longrightarrow\quad \mu = 1 + \lambda\Delta t$$

两个判据由此一一对应（注意 μ 是 λ 的一次近似 $e^{\lambda\Delta t} \approx 1 + \lambda\Delta t$）：

```
连续: du/dt = Au            离散: u_{k+1} = M u_k
-------------------------------------------------
特征值 lambda               特征值 mu = 1 + lambda*dt
稳定 <=> Re(lambda) < 0     稳定 <=> |mu| < 1
临界边界: 虚轴 Re=0          临界边界: 单位圆 |mu|=1
解: u(t) = e^{At} u(0)      解: u_k = M^k u_0
分解: e^{At} = S e^{Lt} S^-1 分解: M^k = S L^k S^-1
```

数值例子：$A = \begin{bmatrix} -1 & 2 \\ 2 & -1 \end{bmatrix}$，$\lambda = 1, -3$。取 $\Delta t = 0.1$，则 $M = I + 0.1A = \begin{bmatrix} 0.9 & 0.2 \\ 0.2 & 0.9 \end{bmatrix}$，其 $\mu = 1 + 0.1(1) = 1.1$ 与 $1 + 0.1(-3) = 0.7$。因为 $|\mu| = 1.1 > 1$，离散迭代同样**发散** ✓——两个判据结论一致。但若 Δt 取得过大（$\Delta t > 1$），$\mu = 1 + \lambda\Delta t$ 会因为 $\lambda = -3$ 给出 -2，$|\mu| = 2 > 1$——**一个稳定的连续系统被粗糙的数值格式判成了不稳定**。这是数值分析中"步长稳定性限制"（stiff 问题）的代数根源，也是 $e^{\lambda\Delta t}$ 与 $1 + \lambda\Delta t$ 在 $\lambda\Delta t$ 较大时差异显著的直接后果。

精确的桥梁不是 $1 + \lambda\Delta t$ 而是 $e^{\lambda\Delta t}$：若用精确解 $\mathbf{u}(t + \Delta t) = e^{A\Delta t}\mathbf{u}(t)$ 作离散化，则 $M = e^{A\Delta t}$，特征值 $\mu_i = e^{\lambda_i\Delta t}$，且

$$|\mu_i| = |e^{\lambda_i\Delta t}| = e^{\operatorname{Re}(\lambda_i)\Delta t} < 1 \iff \operatorname{Re}(\lambda_i) < 0$$

两个判据的等价性在这里是精确的、无条件的。这个式子值得记住：它是"连续稳定 $\iff$ 离散稳定"的完整证明，也说明了为什么讲次 24 用 $|\lambda| < 1$、本讲用 $\operatorname{Re}\lambda < 0$——它们描述的是同一个几何事实（左半平面 vs 单位圆），只是被 $\exp$ 映射关联起来。

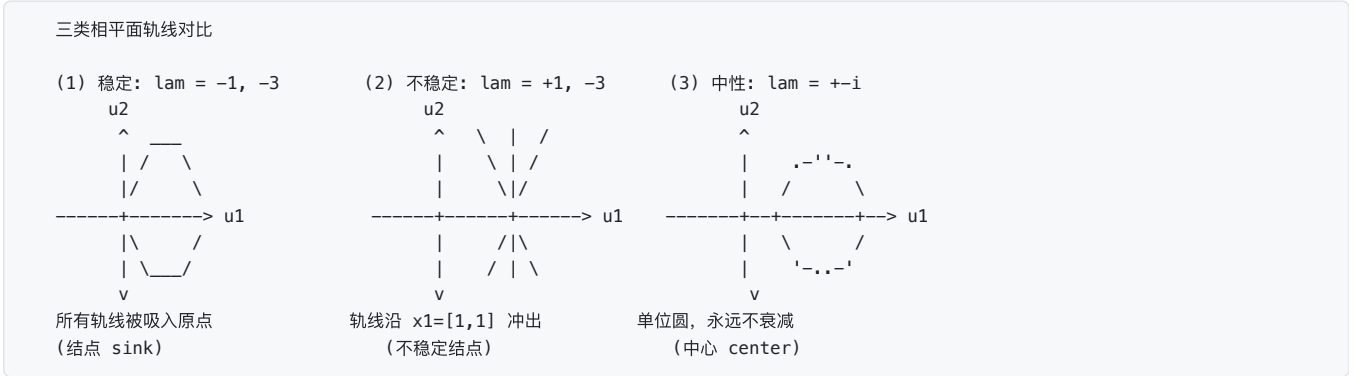

以上三个例子都满足同一个规律：**由最右端的特征值实部拍板**。下表整理了 2×2 的全部类型（已用脚本逐一扫过）：

```
2x2 相平面分类速查（r = Re(lambda)）

 特征值                    类型              稳定性         例子
 ----------------------  ----------------  -------------  ---------------------------
 lam1, lam2 都 < 0 实      稳定结点 sink      u -> 0         A=[[-2,1],[1,-2]]  (-1,-3)
 都 > 0 实                 不稳定结点         u -> inf       A=[[2,0],[0,3]]
 一正一负                  鞍点 saddle        混合（不稳）    A=[[-1,2],[2,-1]]  (+1,-3)
 复: Re < 0                稳定螺旋 sink      u -> 0         A=[[-1,-1],[1,-1]] (-1+-i)
 复: Re > 0                不稳定螺旋         u -> inf       A=[[1,-1],[1,1]]   ( 1+-i)
 纯虚 (+-bi)               中心 center        中性、周期     A=[[0,-1],[1,0]]   (+-i)
 lam = 0 (单重)            中性/平移          不衰减不增     A=[[0,0],[0,-1]]   (0,-1)
```

【计算机制解说】：为什么"稳定性只看 $\mathbf{Re}\,\boldsymbol{\lambda}$"而不是看特征向量、初值或 $\mathbf{det}$ 的其它信息？原因是解的表达式中，时间只以 $e^{\lambda_i t}$ 的形式出现，而

$$|e^{\lambda_i t}| = |e^{(\alpha_i + i\beta_i)t}| = |e^{\alpha_i t}| \cdot |e^{i\beta_i t}| = e^{\alpha_i t} \cdot 1$$

——**复指数的模长完全由实部决定，虚部只在单位圆上转圈**（$|e^{i\beta t}| = 1$）。这一步把一个关于长期行为的定性问题，化简成了一个只比较 $\alpha_i = \mathbf{Re}\,\boldsymbol{\lambda}_i$ 与 0 的**符号判断**。

进一步，即使初值让某个 $\boldsymbol{\lambda}_i$ 的系数 $c_i = 0$（该模态完全缺失），也不改变结论的**一般性**：因为我们要判断的是"对所有初值都衰减"还是"存在初值使解发散"。只要有一个 $\mathbf{Re}\,\boldsymbol{\lambda}_i > 0$，取 $\mathbf{u}(0) = \mathbf{x}_i$（即 $c_i = 1$，其余为 0）就能得到一个发散的解，故系统不稳定。反之若所有 $\mathbf{Re}\,\boldsymbol{\lambda}_i < 0$，则对**任意**初值，$\|\mathbf{u}(t)\| \le \sum_i |c_i|\, e^{\alpha_i t}\|\mathbf{x}_i\| \le C e^{\alpha_{\max} t} \to 0$，一致衰减。**"存在 $\boldsymbol{\lambda}$ 在右半平面"与"存在初值使解发散"是等价的**——这正是判据的完整逻辑链。

还要注意：判据里的"$\mathbf{Re}\,\boldsymbol{\lambda}_i < 0$"是**严格**不等式。若某个 $\boldsymbol{\lambda} = 0$（如化学反应例子里 $\mathbf{det}\,\boldsymbol{A} = 0$ 的情形），对应的模态 $c e^{0\cdot t}\mathbf{x} = c\mathbf{x}$ 是**常数**，解收敛到一个非零平衡点而非零，属于中性；若 $\boldsymbol{\lambda} = 0$ 且 $\boldsymbol{A}$ 不可对角化，则出现 $te^{0\cdot t} = t$ 的**线性增长**（见讲次 28 的 Jordan 形），系统发散。$\boldsymbol{\lambda} = 0$ 是判据中最微妙的地带，必须结合可对角化性一起看。

矩阵分解的核心思想

本讲的主分解对象是 $\boldsymbol{A} = \boldsymbol{S}\boldsymbol{\Lambda}\boldsymbol{S}^{-1}$，但它是**连续时间版本**——原来的幂 $\boldsymbol{A}^k = \boldsymbol{S}\boldsymbol{\Lambda}^k\boldsymbol{S}^{-1}$ 被指数 $e^{\boldsymbol{A}t} = \boldsymbol{S}e^{\boldsymbol{\Lambda}t}\boldsymbol{S}^{-1}$ 取代。

分解形式

$$\boldsymbol{A} = \boldsymbol{S}\boldsymbol{\Lambda}\boldsymbol{S}^{-1} \quad \Longrightarrow \quad e^{\boldsymbol{A}t} = \boldsymbol{S}e^{\boldsymbol{\Lambda}t}\boldsymbol{S}^{-1}, \qquad e^{\boldsymbol{\Lambda}t} = \begin{bmatrix} e^{\lambda_1 t} & & \\ & \ddots & \\ & & e^{\lambda_n t} \end{bmatrix}$$

推导（逐项代入）

$$e^{\boldsymbol{A}t} = \sum_{k=0}^{\infty} \frac{\boldsymbol{A}^k t^k}{k!} = \sum_{k=0}^{\infty} \frac{(\boldsymbol{S}\boldsymbol{\Lambda}\boldsymbol{S}^{-1})^k t^k}{k!} = \sum_{k=0}^{\infty} \frac{\boldsymbol{S}\boldsymbol{\Lambda}^k\boldsymbol{S}^{-1} t^k}{k!} = \boldsymbol{S}\Big(\sum_{k=0}^{\infty} \frac{\boldsymbol{\Lambda}^k t^k}{k!}\Big)\boldsymbol{S}^{-1} = \boldsymbol{S}e^{\boldsymbol{\Lambda}t}\boldsymbol{S}^{-1}$$

关键一步是 $(\boldsymbol{S}\boldsymbol{\Lambda}\boldsymbol{S}^{-1})^k = \boldsymbol{S}\boldsymbol{\Lambda}^k\boldsymbol{S}^{-1}$：中间的 $\boldsymbol{S}^{-1}\boldsymbol{S}$ 两两相消，$\boldsymbol{S}$ 与 $\boldsymbol{S}^{-1}$ 各只出现一次。而对角矩阵的幂就是对角线元素的幂，$\sum_k \boldsymbol{\Lambda}^k t^k/k!$ 逐元素等于 $\sum_k \lambda_i^k t^k/k! = e^{\lambda_i t}$——**这就是标量情形的原地推广**。

【计算机制解说】：为什么 $e^{\boldsymbol{A}t} = \boldsymbol{S}e^{\boldsymbol{\Lambda}t}\boldsymbol{S}^{-1}$ 能成立？三个要点，每一个都不可省。（1）**换基把"幂"变成"逐元素幂"**。$\boldsymbol{A}$ 的幂之所以难算，是因为矩阵乘法把各行各列混在一起；但在特征基下 $\boldsymbol{A}$ 变成对角矩阵 $\boldsymbol{\Lambda}$，而非对角矩阵的乘法是**逐元素**的：$\boldsymbol{\Lambda}^k = \mathbf{diag}(\lambda_1^k, \dots, \lambda_n^k)$。所以"$\boldsymbol{A}$ 的第 k 次幂"这个可怕的对象，在特征坐标里只是一个 n 元组各自取 k 次方。（2）**级数求和与换基可以交换次序**。$e^{\boldsymbol{A}t}$ 的定义是一个无穷级数，要把它搬到特征坐标，必须允许 $\sum_k$ 与 $\boldsymbol{S}(\cdot)\boldsymbol{S}^{-1}$ 互换。这一步的合法性来自**收敛性**：对任意有限 t，$\|\boldsymbol{A}^k t^k/k!\| \le \|\boldsymbol{A}\|^k t^k/k!$，而标量级数 $\sum \|\boldsymbol{A}\|^k t^k/k! = e^{\|\boldsymbol{A}\|t} < \infty$ 绝对收敛。因此矩阵级数绝对收敛，可以逐项重排、可以提出常数矩阵因子。**矩阵指数对任意 $\boldsymbol{A}$ 和任意 t 都收敛**，这个"永远安全"的特性正是它比 $\boldsymbol{A}^k$（可能爆炸）更好用的原因。（3）**$\boldsymbol{A}$ 与 $e^{\boldsymbol{A}t}$ 自动可交换**。因为 $e^{\boldsymbol{A}t}$ 是 $\boldsymbol{A}$ 的幂的线性组合，任何与 $\boldsymbol{A}$ 交换的矩阵都与 $\boldsymbol{A}^k$ 交换，故 $\boldsymbol{A}e^{\boldsymbol{A}t} = e^{\boldsymbol{A}t}\boldsymbol{A}$。这让 $\boldsymbol{A}$ 在求导时可以从任意一侧提出，于是 $\frac{d}{dt}e^{\boldsymbol{A}t} = \boldsymbol{A}e^{\boldsymbol{A}t}$ 成立——这是 $e^{\boldsymbol{A}t}$ 成为"解算子"的关键。若把 $\boldsymbol{A}$ 换成两个不交换的矩阵之和，第（1）步的逐元素性质就崩了，这正是 $e^{\boldsymbol{A}+\boldsymbol{B}} \ne e^{\boldsymbol{A}}e^{\boldsymbol{B}}$ 的根源。

含义与揭示的结构性质

- $\boldsymbol{A}$ 的"复杂"行为被拆成三步：$\boldsymbol{S}^{-1}$ 把初值换到**特征坐标**（解耦）→ $e^{\boldsymbol{\Lambda}t}$ 在各坐标上独立做标量指数（纯粹缩放/旋转）→ $\boldsymbol{S}$ 换回原坐标（叠加）。
- 与 $\boldsymbol{A}^k = \boldsymbol{S}\boldsymbol{\Lambda}^k\boldsymbol{S}^{-1}$（讲次 22）完全同构：**离散时间的幂 $\leftrightarrow$ 连续时间的指数**。这解释了为什么两个判据长得像但不一样（见"常见误区"第 2 条）。
- $\boldsymbol{A}$ 对称时 $\boldsymbol{S}$ 可取正交矩阵 $\boldsymbol{Q}$（讲次 25），$e^{\boldsymbol{A}t} = \boldsymbol{Q}e^{\boldsymbol{\Lambda}t}\boldsymbol{Q}^{\mathsf{T}}$。$e^{\boldsymbol{\Lambda}t}$ 是对角的、因而对称，$\boldsymbol{Q}(\cdot)\boldsymbol{Q}^{\mathsf{T}}$ 保持对称性 $\Rightarrow$ **对称矩阵的矩阵指数仍是对称矩阵**。物理上对应：对称系统（如纯弹簧网络）不会产生陀螺式的旋转耦合。

应用价值：一旦有 $e^{\boldsymbol{A}t}$，任意初值的解都是**一次矩阵乘向量**；$\mathbf{u}(t) = e^{\boldsymbol{A}t}\mathbf{u}(0)$ 就是"线性动态系统的完整说明书"。

本讲算例的显式 $e^{\boldsymbol{A}t}$（$\boldsymbol{A} = \begin{bmatrix} -1 & 2 \\ 2 & -1 \end{bmatrix}$）

$$S=\begin{bmatrix}1 & 1\\ 1 & -1\end{bmatrix},\qquad S^{-1}=\frac{1}{2}\begin{bmatrix}1 & 1\\ 1 & -1\end{bmatrix}=\frac{1}{2}S$$

（验算：$S\cdot\frac{1}{2}S=\frac{1}{2}\begin{bmatrix}1 & 1\\ 1 & -1\end{bmatrix}\begin{bmatrix}1 & 1\\ 1 & -1\end{bmatrix}=\frac{1}{2}\begin{bmatrix}2 & 0\\ 0 & 2\end{bmatrix}=I$ ✓——这个 S 是"自逆到常数倍"的特殊情形，因 A 对称而显得格外干净。）

$$e^{At}=\begin{bmatrix}1 & 1\\ 1 & -1\end{bmatrix}\begin{bmatrix}e^{t} & 0\\ 0 & e^{-3t}\end{bmatrix}\cdot\frac{1}{2}\begin{bmatrix}1 & 1\\ 1 & -1\end{bmatrix}=\frac{1}{2}\begin{bmatrix}e^{t} & e^{-3t}\\ e^{t} & -e^{-3t}\end{bmatrix}\begin{bmatrix}1 & 1\\ 1 & -1\end{bmatrix}$$

$$\boxed{e^{At}=\begin{bmatrix}\dfrac{e^{t}+e^{-3t}}{2} & \dfrac{e^{t}-e^{-3t}}{2}\\[2ex] \dfrac{e^{t}-e^{-3t}}{2} & \dfrac{e^{t}+e^{-3t}}{2}\end{bmatrix}=\begin{bmatrix}a(t) & b(t)\\ b(t) & a(t)\end{bmatrix}}$$

其中 $a(t)=\frac{e^{t}+e^{-3t}}{2}$，$b(t)=\frac{e^{t}-e^{-3t}}{2}$。

验证：$t=0$ 时 $a=1,b=0\Rightarrow e^{A\cdot 0}=I$ ✓。$\frac{d}{dt}e^{At}=\begin{bmatrix}a' & b'\\ b' & a'\end{bmatrix}$ 与 $Ae^{At}=\begin{bmatrix}-a+2b & -b+2a\\ 2a-b & 2b-a\end{bmatrix}=\begin{bmatrix}a' & b'\\ b' & a'\end{bmatrix}$ 一致（用 $a'=\frac{e^{t}-3e^{-3t}}{2}$，数值核对误差 $\sim 10^{-10}$ ✓）。并且 $e^{At}\begin{bmatrix}1\\0\end{bmatrix}=\begin{bmatrix}a\\b\end{bmatrix}$ 正是示例 1 的解 ✓——两条路径完全吻合。

补充说明：$e^{A+B}\neq e^{A}e^{B}$（除非 $AB=BA$）

取 $A=\begin{bmatrix}0 & 1\\ 0 & 0\end{bmatrix}$，$B=\begin{bmatrix}0 & 0\\ 1 & 0\end{bmatrix}$（注意 $AB=\begin{bmatrix}1 & 0\\ 0 & 0\end{bmatrix}\neq\begin{bmatrix}0 & 0\\ 0 & 1\end{bmatrix}=BA$）。

$$e^{A}=\begin{bmatrix}1 & 1\\ 0 & 1\end{bmatrix},\quad e^{B}=\begin{bmatrix}1 & 0\\ 1 & 1\end{bmatrix},\qquad e^{A}e^{B}=\begin{bmatrix}2 & 1\\ 1 & 1\end{bmatrix}$$

而 $A+B=\begin{bmatrix}0 & 1\\ 1 & 0\end{bmatrix}$，故 $e^{A+B}=\begin{bmatrix}\cosh 1 & \sinh 1\\ \sinh 1 & \cosh 1\end{bmatrix}\approx\begin{bmatrix}1.543081 & 1.175201\\ 1.175201 & 1.543081\end{bmatrix}$。**两者明显不同**。有趣的是两者行列式都等于 1（因为 $\operatorname{tr}A=\operatorname{tr}B=\operatorname{tr}(A+B)=0$）。根本原因：标量 $e^{a+b}=e^{a}e^{b}$ 的证明依赖 a,b 可交换，矩阵乘法一般不可交换，所以二项式展开 $(A+B)^{k}$ 无法拆分。

不可对角化的情形（简述，细节见讲次 28）：若 A 不能对角化（如 $A=\begin{bmatrix}\lambda & 1\\ 0 & \lambda\end{bmatrix}$），$S$ 不存在，但仍可算

$$e^{At}=e^{\lambda t}\begin{bmatrix}1 & t\\ 0 & 1\end{bmatrix}$$

——多出来的因子 t 就是"缺陷特征值"的标志。此时若 $\lambda<0$，$te^{\lambda t}$ 依然趋于 0，稳定性判据不变；但若 $\lambda=0$，系统会**线性增长**而不是保持中性。

与其他讲次的关联

- **讲次 21–22（特征值与对角化）**：本讲是 $A=S\Lambda S^{-1}$ 的"动态版"。讲次 22 用它算 A^{k}（离散幂），本讲用它算 e^{At}（连续指数），共享同一个 S 与 Λ。若 A 不可对角化，两条路线都需要 Jordan 形（讲次 28）。
- **讲次 24（马尔可夫矩阵与傅里叶级数）**：马尔可夫链 $\mathbf{u}_{k+1}=A\mathbf{u}_{k}$ 是**离散时间**的对应物。那里 $\lambda=1$ 对应稳态，稳定判据是 $|\lambda|<1$（除稳态外）；这里 $\lambda=0$ 是平凡的中性方向，判据是 $\operatorname{Re}\lambda<0$。**离散的 $|\lambda|<1$ 与连续的 $\operatorname{Re}\lambda<0$ 通过 $\lambda_{\text{disc}}=e^{\lambda_{\text{cont}}\Delta t}$ 相互翻译**。
- **讲次 25（对称矩阵与正定）**：A 对称时 λ 全为**实数**，稳定性判据退化成纯符号判断"是否全为负"；且 $S=Q$ 正交，$e^{At}=Qe^{\Lambda t}Q^{\mathsf{T}}$ 保持对称。矩阵 $-A$ 正定 $\iff$ $\operatorname{Re}\lambda$ 全为负（能量观点）。
- **讲次 26–27（复矩阵/正定判定）**：要严格证明"$\operatorname{Re}\lambda<0$"，可用 Lyapunov 思想：找正定 P 使 $A^{\mathsf{T}}P+PA=-I$（连续 Lyapunov 方程），这是本讲判据的能量化表述。
- **讲次 28（Jordan 形与 SVD）**：e^{At} 的一般公式需要 $A=MJM^{-1}$，$e^{At}=Me^{Jt}M^{-1}$，e^{Jt} 是块对角矩阵，每块含 $e^{\lambda t},te^{\lambda t},\frac{t^{2}}{2!}e^{\lambda t},\ldots$。
- **讲次 6–10（子空间）**：稳定子空间 = 由 $\operatorname{Re}\lambda<0$ 的特征向量张成的子空间；不稳定子空间由 $\operatorname{Re}\lambda>0$ 的特征向量张成。三个特征值符号类各自给出一个 A–不变子空间，直和是整个 $\mathbb{R}^{n}$。

关键要点

复平面上的稳定性地图（n 个特征值 λ_i 落点决定一切）

```
    Im(lambda)          复平面: 特征值的位置 = 系统的命运
       ^
       |
       |     |          不稳定区域
       |  x  |  x       (Re > 0): 指数发散
       |     |       x
-------+-----+--------------> Re(lambda)
  稳定 |     |  中性
(Re<0)|     |  (Re=0)
  u->0 |     |  振荡不衰减
       |     |
       |     |
  x = 一个特征值

 关键: 只看"最右边"的那个 x
   左半平面全部  ->  稳定        (例: A=[[-2,1],[1,-2]], lam=-1,-3)
   虚轴上有 x    ->  中性        (例: A=[[0,-1],[1,0]],  lam=+-i)
   右半平面有 x  ->  不稳定      (例: A=[[-1,2],[2,-1]],lam=+1,-3)
```

1. **通解公式**：$\mathbf{u}(t) = c_1 e^{\lambda_1 t}\mathbf{x}_1 + \cdots + c_n e^{\lambda_n t}\mathbf{x}_n = Se^{\Lambda t}S^{-1}\mathbf{u}(0) = e^{At}\mathbf{u}(0)$。每个特征方向独立演化。
2. **稳定性判据（连续时间）**：所有 $\mathrm{Re}(\lambda_i) < 0 \Rightarrow$ 稳定（$\mathbf{u} \to \mathbf{0}$）；存在 $\mathrm{Re}(\lambda_i) > 0 \Rightarrow$ 不稳定；全部 $\mathrm{Re}(\lambda_i) \le 0$ 且存在纯虚 $\lambda \Rightarrow$ 中性振荡。**只看实部**，虚部只管振荡频率。
3. **2×2 速判法**：$\mathrm{tr}\,A < 0$ 且 $\det A > 0 \Rightarrow$ 稳定（两个 λ 都落在左半平面）。理由：$\lambda_1\lambda_2 = \det A > 0$ 保证同号，$\lambda_1 + \lambda_2 = \mathrm{tr}\,A < 0$ 保证符号为负。**这两个条件缺一不可**——$A = \begin{bmatrix} -1 & 2 \\ 2 & -1 \end{bmatrix}$ 有 $\mathrm{tr} = -2 < 0$ 但 $\det = -3 < 0$，实为不稳定。
4. **矩阵指数的三条性质**：$e^{A\cdot 0} = I$；$\dfrac{d}{dt}e^{At} = Ae^{At} = e^{At}A$（$A$ 与 e^{At} 必可交换）；$e^{At} = Se^{\Lambda t}S^{-1}$（$A$ 可对角化时）。
5. **矩阵指数不是逐元素指数**：$e^{At} \neq \left[e^{a_{ij}t}\right]$；且 $e^{A+B} \neq e^A e^B$，除非 $AB = BA$。

常见误区与注意事项

1. **把 e^{At} 当成逐元素取指数**。$e^{\left[\begin{smallmatrix} 0 & 1 \\ 0 & 0 \end{smallmatrix}\right]t} = \begin{bmatrix} 1 & t \\ 0 & 1 \end{bmatrix}$（因为 $A^2 = 0$，级数在两项后截断），而逐元素指数会给 $\begin{bmatrix} 1 & e^t \\ 1 & 1 \end{bmatrix}$——**完全错误**。矩阵指数是幂级数求和，混合了 A 的幂所携带的耦合信息。
2. **混淆连续与离散的稳定判据**。$d\mathbf{u}/dt = A\mathbf{u}$ 要 $\mathrm{Re}\,\lambda < 0$；而 $\mathbf{u}_{k+1} = A\mathbf{u}_k$ 要 $|\lambda| < 1$。临界边界也不同：连续是虚轴（$\mathrm{Re}\,\lambda = 0$），离散是单位圆（$|\lambda| = 1$）。用错判据会把稳定系统判成不稳定。二者的桥梁是 $\lambda_{\text{disc}} = e^{\lambda_{\text{cont}}\Delta t}$。
3. **忘记 c_i 由初值确定，把通解当答案**。$\mathbf{u}(t) = c_1 e^{\lambda_1 t}\mathbf{x}_1 + c_2 e^{\lambda_2 t}\mathbf{x}_2$ 里 c_1, c_2 未知，必须用 $\mathbf{u}(0) = S\mathbf{c}$ 即 $\mathbf{c} = S^{-1}\mathbf{u}(0)$ 定出。常见错误是直接写 $\mathbf{u}(0) = \mathbf{x}_1 + \mathbf{x}_2$ 或令 $c_i = 1$。
4. **以为"稳定"意味着所有分量都衰减、或极限唯一**。稳定性说的是 $\mathbf{u}(t) \to \mathbf{0}$；但若 $\lambda_1 = -1, \lambda_2 = -3$，慢模态 e^{-t} 在很长时间内主导，轨线先沿 $\mathbf{x}_2$ 急速塌缩再沿 $\mathbf{x}_1$ 缓慢收缩——路径强烈依赖于初值方向。另外，中性情形（$\lambda = \pm i$）**没有极限**，既不发散也不收敛，不能算"稳定到 0"。
5. **发散方向搞错**。系统发散时，轨线的**渐近方向**由 $\mathrm{Re}\,\lambda$ 最大的那个特征向量决定，不是由 $\mathbf{u}(0)$ 决定。示例 1 中无论初值怎么取（只要 $c_1 \neq 0$），$t \to \infty$ 时 $\mathbf{u}$ 都平行于 $\mathbf{x}_1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$。
6. **λ 为复数时忘了取实部**。$e^{(-2+5i)t} = e^{-2t}(\cos 5t + i\sin 5t)$，**衰减由 -2 控制、振荡由 5 控制**。看到 $5i$ 就说"不稳定"是典型错误。复特征值总是成共轭对出现，实解必须取实部组合。

思考题（带答案）

Q1.（纯计算） 求解 $\dfrac{d\mathbf{u}}{dt} = A\mathbf{u}$，其中 $A = \begin{bmatrix} -2 & 1 \\ 1 & -2 \end{bmatrix}$，初值 $\mathbf{u}(0) = \begin{bmatrix} 1 \\ 0 \end{bmatrix}$。写出 $u_1(t), u_2(t)$，并说明 $\mathbf{u}(t) \to \mathbf{0}$。

▸ 答案

$\det(A - \lambda I) = (-2-\lambda)^2 - 1 = \lambda^2 + 4\lambda + 3 = (\lambda+1)(\lambda+3)$，故 $\lambda_1 = -1$，$\lambda_2 = -3$。

- $\lambda_1 = -1$：$A + I = \begin{bmatrix} -1 & 1 \\ 1 & -1 \end{bmatrix}$，推出 $x_1 = x_2$，$\mathbf{x}_1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$。
- $\lambda_2 = -3$：$A + 3I = \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix}$，推出 $x_1 = -x_2$，$\mathbf{x}_2 = \begin{bmatrix} 1 \\ -1 \end{bmatrix}$。

设 $\mathbf{u}(t) = c_1 e^{-t}\begin{bmatrix} 1 \\ 1 \end{bmatrix} + c_2 e^{-3t}\begin{bmatrix} 1 \\ -1 \end{bmatrix}$。代入 $t = 0$：

$$\begin{cases} c_1 + c_2 = 1 \\ c_1 - c_2 = 0 \end{cases} \Rightarrow c_1 = c_2 = \tfrac{1}{2}$$

$$u_1(t) = \frac{e^{-t} + e^{-3t}}{2}, \qquad u_2(t) = \frac{e^{-t} - e^{-3t}}{2}$$

两个特征值都严格为负 $\Rightarrow \mathbf{u}(t) \to \mathbf{0}$。数值验证：$t = 1$ 时 $\begin{bmatrix} 0.208833 \\ 0.159046 \end{bmatrix}$，$t = 5$ 时 $\begin{bmatrix} 0.003369 \\ 0.003369 \end{bmatrix}$（已脚本核对）。导数验证：$\mathbf{u}'(0.9) = \begin{bmatrix} -0.3040931 \\ -0.1024766 \end{bmatrix}$ 与 $A\mathbf{u}(0.9)$ 完全一致 ✓。

（另注：A 对称，故 $\mathbf{x}_1 \perp \mathbf{x}_2$；由于两特征值都负，这是"稳定结点"，所有轨线都指向原点。）

Q2.（判断稳定性） 判断以下四个系统的稳定性（稳定 / 不稳定 / 中性），并指出最右端特征值：

(a) $A = \begin{bmatrix} -1 & 2 \\ 2 & -1 \end{bmatrix}$；(b) $A = \begin{bmatrix} 0 & -1 \\ 1 & 0 \end{bmatrix}$；(c) $A = \begin{bmatrix} 1 & -1 \\ 1 & 1 \end{bmatrix}$；(d) $A = \begin{bmatrix} -3 & 0 \\ 0 & -5 \end{bmatrix}$。

▸ **答案**

(a) $\operatorname{tr} = -2$，$\det = 1 - 4 = -3$。$\lambda^2 + 2\lambda - 3 = (\lambda + 3)(\lambda - 1) \Rightarrow \lambda = 1, -3$。存在 $\lambda = 1 > 0 \Rightarrow$ **不稳定**（鞍点）。注意 $\operatorname{tr} < 0$ 但 $\det < 0$，2×2 速判法**不适用**——这正是"$\det > 0$ 不可省"的反例。

(b) $\operatorname{tr} = 0$，$\det = 1$。$\lambda^2 + 1 = 0 \Rightarrow \lambda = \pm i$。$\operatorname{Re}\lambda = 0 \Rightarrow$ **中性**（中心，轨线是单位圆 $u_1 = \cos t,\ u_2 = \sin t$）。

(c) $\operatorname{tr} = 2$，$\det = 1 + 1 = 2$。$\lambda^2 - 2\lambda + 2 = 0 \Rightarrow \lambda = 1 \pm i$。$\operatorname{Re}\lambda = 1 > 0 \Rightarrow$ **不稳定**（不稳定螺旋，一边旋转一边向外扩张）。**(b) 与 (c) 的对比很关键**：两者的振荡部分完全相同（虚部都是 1），差别只在实部 0 与 $+1$。

(d) 对角矩阵，$\lambda = -3, -5$，都 $< 0 \Rightarrow$ **稳定**，$\mathbf{u}(t) \to \mathbf{0}$，衰减速率由较慢的 e^{-3t} 决定。

总结：稳定性只看 $\operatorname{Re}\lambda$ 的最大值：< 0 稳定，> 0 不稳定，$= 0$（且有纯虚）中性。上表已用脚本对四个矩阵逐一验算，结论一致。

Q3.（概念理解） 设 A 是 2×2 实矩阵，$\operatorname{tr} A < 0$ 且 $\det A > 0$。证明 A 的两个特征值实部都为负（即系统稳定）。再解释：如果只给定 $\operatorname{tr} A < 0$，能否断言稳定？为什么？

▸ **答案**

证明。 设特征值为 λ_1, λ_2（可能为共轭复数）。由特征多项式

$$\det(A - \lambda I) = \lambda^2 - (\operatorname{tr} A)\lambda + \det A$$

得韦达定理：$\lambda_1 + \lambda_2 = \operatorname{tr} A$，$\lambda_1 \lambda_2 = \det A$。

情形 1：λ 为实数。 由 $\det A = \lambda_1 \lambda_2 > 0$，两特征值**同号**（都正或都负，且都不为零）。由 $\operatorname{tr} A = \lambda_1 + \lambda_2 < 0$，两数之和为负 $\Rightarrow$ 不可能都正 $\Rightarrow$ **都负**。故 $\operatorname{Re}\lambda_i = \lambda_i < 0$ ✓。

情形 2：λ 为复数。 实矩阵的复特征值成共轭对：$\lambda_{1,2} = \alpha \pm \beta i$，$\beta \neq 0$。则 $\lambda_1 + \lambda_2 = 2\alpha = \operatorname{tr} A < 0 \Rightarrow \alpha = \frac{1}{2}\operatorname{tr} A < 0$ ✓（此时 $\det A = \alpha^2 + \beta^2 > 0$ 自动成立，与假设相容）。∎

反例：只给 $\operatorname{tr} A < 0$ 不够。 取 $A = \begin{bmatrix} -1 & 2 \\ 2 & -1 \end{bmatrix}$：$\operatorname{tr} A = -2 < 0$，但 $\det A = -3 < 0$，特征值为 1 与 -3，系统**不稳定**（存在 $\lambda = 1 > 0$）。$\det A < 0$ 说的是 $\lambda_1 \lambda_2 < 0$，即一正一负——鞍点。所以 $\det A > 0$ 的作用是**排除鞍点**，$\operatorname{tr} A < 0$ 的作用是在"同号"中选负号。两者合起来才等价于"两特征值都在左半平面"。

延伸：本讲示例 1 正是这个反例，数值已用脚本核对（$\lambda = 1, -3$，$\operatorname{tr} = -2$，$\det = -3$）。

Lecture 24: Markov Matrices; Fourier Series

概述

本讲把特征值理论推向两个截然不同的方向，但它们的内核其实是同一件事——**用一组"好"的特征向量（正交基）把对象展开**。前半讲处理**马尔可夫矩阵**：所有元素非负、**每一列加起来等于 1** 的方阵。这类矩阵必然有特征值 $\lambda = 1$，而且只要它"足够连通"，幂次 A^k 就会收敛到一个稳定的概率分布——**稳态向量（steady state）**。后半讲把向量换成**函数**，把内积换成**积分**，于是投影公式 $P = a(a^{\mathsf{T}}b)/(a^{\mathsf{T}}a)$ 摇身一变成为**傅里叶级数**：$f(x) = \sum$ 投影系数 × 三角函数。整讲的主线是 Strang 反复强调的一句话：

> **线性代数的每一件事，在函数空间里都有一个连续版本；傅里叶级数就是把"投影到子空间"搬到无穷维。**

本讲紧接讲次 22（$A^k = S\Lambda^k S^{-1}$ 与稳定性）、讲次 23（微分方程 $du/dt = Au$），并为讲次 25（对称正定矩阵）铺路。

核心概念的几何直觉

马尔可夫矩阵（Markov matrix）

- **定义与目的**：方阵 A 若满足 ① $a_{ij} \geq 0$（所有元素非负）；② 对**每一列** j：$\sum_i a_{ij} = 1$（列和为 1，称为**列随机 column-stochastic**），则称 A 是马尔可夫矩阵。它的目的是描述**随机过程**：A 把一个概率分布搬运成下一步的概率分布。
- **几何直觉（它在空间中是什么样子？）**：把 $\mathbb{R}^n$ 中"所有分量非负、和为 1"的点集想象成一个**单纯形**（$n=2$ 是一条线段，$n=3$ 是一个三角形，n 更大是更高维的"三角形"）。马尔可夫矩阵就是这个单纯形到自身的一个**线性映照**：单纯形里的点永远被搬回单纯形里，绝不逃出去。A 的列和条件在几何上等价于说：**全 1 向量 $\mathbf{1}$ 是 A^{T} 的特征向量**（固有不动点方向）。为什么会收敛？因为单纯形是有界的"凸盒子"，映照反复作用只能越来越靠近它内部的那个不动点。
- **具体示例**：$A = \begin{bmatrix} 0.8 & 0.3 \\ 0.2 & 0.7 \end{bmatrix}$。第一列 $0.8+0.2=1$，第二列 $0.3+0.7=1$，元素全非负 $\Rightarrow$ 是马尔可夫矩阵。又例如 $S = \begin{bmatrix} 0.5 & 0.25 & 0.25 \\ 0.25 & 0.5 & 0.25 \\ 0.25 & 0.25 & 0.5 \end{bmatrix}$（三列均为 1）也是。

概率直觉：a_{ij} 是转移概率

- **定义与目的**：设系统的状态集合为 $\{1, \dots, n\}$。读法约定是

$$a_{ij} = P(\text{下一步在状态 } i \mid \text{当前在状态 } j),$$

即**从列 j 转移到行 i 的概率**。注意脚标的顺序（列是"从"，行是"到"）。设 $\mathbf{u}_k$ 是第 k 步的**概率分布向量**，其第 j 个分量 $(\mathbf{u}_k)_j = P(\text{第 } k \text{ 步在状态 } j)$，则

$$\mathbf{u}_{k+1} = A\,\mathbf{u}_k, \qquad (\mathbf{u}_{k+1})_i = \sum_j a_{ij}(\mathbf{u}_k)_j.$$

- **几何直觉**：这是加权平均操作——"新的 i 分量 = 所有可能来源 j 的概率乘以转移概率再求和"。因为每列的和为 1，概率总量守恒：$\sum_i (\mathbf{u}_{k+1})_i = \sum_i \sum_j a_{ij} u_j = \sum_j u_j \big(\sum_i a_{ij}\big) = \sum_j u_j = 1$。
- **具体示例**：$\mathbf{u}_0 = \begin{bmatrix} 0 \\ 1 \end{bmatrix}$ 表示"初始 100% 在状态 2"。则 $\mathbf{u}_1 = \begin{bmatrix} 0.8 & 0.3 \\ 0.2 & 0.7 \end{bmatrix} \begin{bmatrix} 0 \\ 1 \end{bmatrix} = \begin{bmatrix} 0.3 \\ 0.7 \end{bmatrix}$：从状态 2 出发，有 0.3 的概率跳到状态 1，0.7 的概率留在状态 2。这与"列和为 1"完全自洽。

稳态向量（steady state）

- **定义与目的**：非零向量 $\mathbf{x}$ 满足 $A\mathbf{x} = \mathbf{x}$，即 $A\mathbf{x} = 1 \cdot \mathbf{x}$ ——它就是 $\lambda = 1$ 的特征向量。若再把分量归一化使 $\sum_i x_i = 1$，就得到**稳态概率分布**。
- **几何直觉**：在单纯形上，$\mathbf{x}$ 是那个"被 A 搬了之后原地不动"的点。迭代 $\mathbf{u}_{k+1} = A\mathbf{u}_k$ 的任何轨迹，最终都会被吸到这个不动点上（当其余 $|\lambda| < 1$ 时）。
- **具体示例**：对上面的 A，稳态是 $\begin{bmatrix} 0.6 \\ 0.4 \end{bmatrix}$（下一节逐步推导）。

为什么列和为 1 $\Rightarrow$ $\lambda = 1$ 必是特征值

这是本讲最漂亮的"一句话证明"，必须逐字理解：

$$\text{每列和为 } 1 \iff A^{\mathsf{T}} \text{ 的每行和为 } 1 \iff A^{\mathsf{T}}\mathbf{1} = \mathbf{1} \iff \mathbf{1} \text{ 是 } A^{\mathsf{T}} \text{ 的特征向量（特征值 } 1)$$

$$\iff \det(A^{\mathsf{T}} - I) = 0 \iff \det(A - I) = 0 \quad (\text{因为 } \det M = \det M^{\mathsf{T}}) \iff 1 \text{ 是 } A \text{ 的特征值.}$$

请特别注意**最后一跳**：列和条件直接给出的是 A^{T} 的特征向量 $\mathbf{1}$，而 A^{T} 与 A 有**相同的特征值**，所以 $\mathbf{1}$ 也是 A 的特征值。但 A 自己的 $\lambda = 1$ 特征向量**不是** $\mathbf{1}$（除非 A 的**行**和也为 1，例如 A 还是对称的）。这正是学生最容易搞错的地方（见"常见误区"）。

$|\lambda| \leq 1$：为什么特征值不会爆出去

- **Gershgorin 圆盘定理**：A 的每个特征值都落在某个圆盘

$$\Big\{ z : |z - a_{jj}| \leq \sum_{i \neq j} |a_{ij}| \Big\}, \qquad j = 1, \dots, n$$

之内（第 j 个圆盘：圆心 a_{jj}，半径 = **第 j 行**其余元素绝对值之和）。**关键的一步是把它用在 A^{T} 上**：A 与 A^{T} 有相同的特征值，而 A^{T} 的第 j 行就是 A 的第 j **列**。于是 A^{T} 的第 j 个圆盘半径是

$$R_j = \sum_{i \neq j} (A^{\mathsf{T}})_{ji} = \sum_{i \neq j} a_{ij} = \Big(\sum_i a_{ij}\Big) - a_{jj} = 1 - a_{jj},$$

这里恰好用上了"第 j 列的和为 1"。圆盘化为 $[a_{jj} - (1 - a_{jj}),\ a_{jj} + (1 - a_{jj})] = [2a_{jj} - 1,\ 1]$，整个落在 $[-1, 1]$ 内。A^{T} 的全部特征值（也就是 A 的全部特征值）被这些圆盘覆盖，故 $|\lambda| \leq 1$。 **重要提醒**：直接对 A **自己**用行圆盘是**行不通的**——对演示一的 A，行圆盘是

$[0.8-0.3,\ 0.8+0.3]=[0.5,1.1]$ 与 $[0.7-0.2,\ 0.7+0.2]=[0.5,0.9]$，第一个右端 $1.1>1$，并没有给出 $|\lambda|\le 1$。**必须转到 $A^{\mathsf T}$（即用列圆盘）**：得到 $[2(0.8)-1,\ 1]=[0.6,1]$ 与 $[2(0.7)-1,\ 1]=[0.4,1]$，此时特征值 1 和 0.5 才确实都被覆盖 ✓（脚本核对）。对演示三的 M：列圆盘为 $[0.8,1]$、$[0.6,1]$、$[0.6,1]$，特征值 $1, 0.8, 0.7$ 全部被覆盖 ✓——而 M 自己的行圆盘是 $[0.7,1.1],[0.65,0.95],[0.65,0.95]$，同样会越界。 – **一个更朴素的说法**：$A$ 不放大向量的 1–范数。对任意 $\mathbf{x}$，$\|A\mathbf{x}\|_1=\sum_i\big|\sum_j a_{ij}x_j\big|\le\sum_i\sum_j a_{ij}|x_j|=\sum_j|x_j|\sum_i a_{ij}=\sum_j|x_j|=\|\mathbf{x}\|_1$。任何特征向量满足 $\|\lambda\mathbf{x}\|_1\le\|\mathbf{x}\|_1$，故 $|\lambda|\le 1$。**幂次不会放大**，这正是收敛的根源。

收敛定理（不可约 + 非周期 $\Longrightarrow$ 唯一稳态）

若马尔可夫矩阵"足够连通"（技术上：**不可约** irreducible，即每个状态都能到达其他任何状态；且**非周期** aperiodic），则

- $\lambda=1$ 是**单重**特征值（代数重数 = 1）；
- 其余所有特征值满足 $|\lambda|<1$；
- 于是对任意初始分布 $\mathbf{u}_0$，

$$\mathbf{u}_k=A^k\mathbf{u}_0\longrightarrow\mathbf{u}_\infty=\ \text{（唯一归一化的 }\lambda=1\text{ 特征向量）}.$$

用讲次 22 的语言说：把 $\mathbf{u}_0$ 展开成 $\mathbf{u}_0=c_1\mathbf{x}_1+c_2\mathbf{x}_2+c_3\mathbf{x}_3+\cdots$，则

$$A^k\mathbf{u}_0=c_1\,1^k\,\mathbf{x}_1+c_2\,\lambda_2^k\,\mathbf{x}_2+c_3\,\lambda_3^k\,\mathbf{x}_3+\cdots\longrightarrow c_1\mathbf{x}_1.$$

只有 $\lambda=1$ 的那一项存活下来，其余项因为 $|\lambda_j|^k\to 0$ 而死亡。这就是"长期行为 = 稳态"的全部机制。

从向量到函数：函数是无穷维向量

- **定义与目的**：向量 $\mathbf{v}=(v_1,\dots,v_n)$ 有 n 个分量；函数 $f(x)$ 在 $[-\pi,\pi]$ 上"每个点 x 有一个值"。把 x 看成**连续的指标**，f 就是一个有不可数多个分量的向量。所有"平方可积"函数构成的集合是一个**无穷维向量空间**。
- **几何直觉（它在空间中是什么样子？）**：n 维向量空间里，向量加法、数乘逐分量定义；函数空间里，$(f+g)(x)=f(x)+g(x)$，$(cf)(x)=cf(x)$，同样成立。**"函数的线性组合"和"向量的线性组合"是同一种运算**，只是指标集从 $\{1,\dots,n\}$ 变成了 $[-\pi,\pi]$。
- **具体示例**：$f(x)=x$ 和 $g(x)=\sin x$ 的线性组合 $3f-2g$ 就是函数 $3x-2\sin x$ ——这跟 $\mathbb{R}^2$ 里的 $3\mathbf{u}-2\mathbf{v}$ 没有任何本质差别。

内积 = 积分（这是关键的翻译字典）

- **定义与目的**：n 维里 $\mathbf{v}^{\mathsf T}\mathbf{w}=\sum_{i=1}^n v_iw_i$；函数空间里把求和换成积分：

$$\langle f,g\rangle=\int_{-\pi}^{\pi}f(x)g(x)\,dx.$$

- **几何直觉**：内积仍然测量"一个在另一个方向上有多少分量"（投影长度）。正交仍然意味着内积为零：$\langle f,g\rangle=0\iff f\perp g$，"两个函数正交"就是"乘积的积分为零"——正负部分相互抵消。
- **具体示例**：$\langle\sin x,\cos x\rangle=\int_{-\pi}^{\pi}\sin x\cos x\,dx=0$（奇函数在对称区间上积分为 0），所以 $\sin x\perp\cos x$。

三角函数系是一组正交基（核心）

- **定义与目的**：函数系 $\{1,\ \cos x,\ \sin x,\ \cos 2x,\ \sin 2x,\ \cos 3x,\ \sin 3x,\dots\}$ 在 $[-\pi,\pi]$ 上两两正交，并且**张开整个函数空间**——因此它就是一组（无穷维的）**正交基**。
- **正交性公式**（$m,n\ge 1$）：

$$\int_{-\pi}^{\pi}\sin(mx)\sin(nx)\,dx=\begin{cases}0,&m\neq n\\ \pi,&m=n\end{cases}\qquad\int_{-\pi}^{\pi}\cos(mx)\cos(nx)\,dx=\begin{cases}0,&m\neq n\\ \pi,&m=n\end{cases}$$

$$\int_{-\pi}^{\pi}\sin(mx)\cos(nx)\,dx=0\quad(\text{对所有 }m,n),\qquad\int_{-\pi}^{\pi}1\,dx=2\pi.$$

- **几何直觉**：这与 $\mathbb{R}^2$ 中"$\mathbf{e}_1\perp\mathbf{e}_2$、$\|\mathbf{e}_i\|^2=1$"完全同构。区别只在于：这里的基向量长度不是 1，而是 $\sqrt{\pi}$（正弦/余弦）或 $\sqrt{2\pi}$（常数函数 1）——**"未归一化的正交基"**，就像讲次 14 里 $\begin{bmatrix}1\\1\end{bmatrix},\begin{bmatrix}1\\-1\end{bmatrix}$ 那样正交但长度是 $\sqrt{2}$。
- **具体示例（数值验证）**：$\int_{-\pi}^{\pi}\sin x\sin 2x\,dx=0$、$\int_{-\pi}^{\pi}\cos 2x\cos 2x\,dx=\pi$、$\int_{-\pi}^{\pi}\sin x\cos x\,dx=0$。用中点法数值积分立即得到 $0,\ 3.14159265,\ 0$ ✓。

傅里叶级数（Fourier series）

- **定义与目的**：把周期为 2π 的函数 f 写成

$$f(x)=\frac{a_0}{2}+\sum_{k=1}^{\infty}\big(a_k\cos kx+b_k\sin kx\big),$$

其中系数由投影（积分）公式给出。目的是**用一个"服从三角函数的简单函数"去逼近任意函数**。 – **几何直觉**：这就是把无穷维向量 f 在**正交基上展开坐标**——完全等同于把 $\mathbf{b}$ 写成 $\sum\frac{\mathbf{b}^{\mathsf T}\mathbf{q}_i}{\mathbf{q}_i^{\mathsf T}\mathbf{q}_i}\mathbf{q}_i$。 – **具体示例**：$f(x)=x$ 展开为 $x=2\big[\sin x-\frac{\sin 2x}{2}+\frac{\sin 3x}{3}-\cdots\big]$。

正交性的几何图景（ASCII 示意）

```
函数空间中的"正交基"  ——  把每个基函数想成一条"方向轴"

sin x    ──────┌──────┐──────────        ∫ sin x · sin 2x dx = 0
               └      ┘                   （一个周期内正负抵消，两次）
sin 2x   ────┐ ┌──┐ ┌──┐ ┌──┐ ────       ∫ sin x · sin 3x dx = 0
             └ ┘  └ ┘  └ ┘  └ ┘

sin 3x   ─┐┌┐┌┐┌┐┌┐┌┐┌┐┌┐──            ∫ sin(mx)cos(nx) dx = 0
          └┘└┘└┘└┘└┘└┘└┘                （奇 × 偶 = 奇，恒为 0）
cos x    ──────┐      ┌──────
               └      ┘                 ∫ sin²(nx) dx = π  ≠ 0
                                              ↑ 自己和自己不抵消，长度 √π
投影类比：
  R^n  :   b ──投影──→ 方向 q_i ，长度 (q_i^T b)/||q_i||
  L²   :   f ──投影──→ 方向 cos kx，长度 <f,cos kx>/<cos kx,cos kx>
                       = (1/π)∫ f(x)cos(kx)dx
```

正交 = 内积为零 ⟺ 乘积的积分为零 ⟺ 正负部分互相抵消。 上面每一条曲线与别的曲线相乘后，在 $[-\pi,\pi]$ 上的"正面积"与"负面积"恰好相等，所以积分为零——这就是"垂直"在函数空间里的具体样子。

计算步骤与手算演示

演示一（手算）：2×2 马尔可夫矩阵的完整对角化 + 收敛曲线

$$A=\begin{bmatrix}0.8 & 0.3\\ 0.2 & 0.7\end{bmatrix}$$

步骤 1：验证马尔可夫条件。

$$a_{11},a_{12},a_{21},a_{22}=0.8,\ 0.3,\ 0.2,\ 0.7\ \geq 0\ \checkmark$$

第 1 列：$0.8+0.2=1\ \checkmark$，　　第 2 列：$0.3+0.7=1\ \checkmark$

所以 A 是马尔可夫矩阵。由上面的"一句话证明"，$\lambda=1$ 必是特征值。

步骤 2：特征多项式。

$$\det(A-\lambda I)=(0.8-\lambda)(0.7-\lambda)-(0.3)(0.2)=(0.8-\lambda)(0.7-\lambda)-0.06.$$

展开：$(0.8-\lambda)(0.7-\lambda)=0.56-1.5\lambda+\lambda^2$，故

$$\det(A-\lambda I)=\lambda^2-1.5\lambda+0.56-0.06=\lambda^2-1.5\lambda+0.5=(\lambda-1)(\lambda-0.5).$$

（分解验证：$(\lambda-1)(\lambda-0.5)=\lambda^2-1.5\lambda+0.5$ ✓）

$$\boxed{\lambda_1=1,\qquad \lambda_2=0.5}$$

步骤 3：双重自检。

$$\mathrm{tr}(A)=0.8+0.7=1.5=\lambda_1+\lambda_2=1+0.5\ \checkmark$$

$$\det(A)=0.8\times 0.7-0.3\times 0.2=0.56-0.06=0.5=\lambda_1\lambda_2=1\times 0.5\ \checkmark$$

（用脚本核对：trace $=1.5$，det $=0.49999999999999994$——浮点误差，真值 0.5。）

【计算机制解说】 为什么必然有一个特征值是 1？观察 $\det(A-I)=(\lambda-1)(\lambda-0.5)\big|_{\lambda=1}=0$。更直接地：$A-I=\begin{bmatrix}-0.2 & 0.3\\ 0.2 & -0.3\end{bmatrix}$，第二行恰好是第一行的负倍，所以 $A-I$ 奇异。这不是巧合——**每一列和为 1 ⟺ $A-I$ 的每一列和为 0 ⟺ $A-I$ 的各行之和为 0 ⟺ 行向量线性相关**（所有行加起来得到零行），所以 $A-I$ 必奇异，1 必是特征值。这就是讲次 21"行列式为 0 ⟺ 奇异 ⟺ 有非零零空间"的直接应用。

步骤 4：求稳态向量（$\lambda=1$ 的特征向量）。 解 $(A-I)\mathbf{x}=\mathbf{0}$：

$$\begin{bmatrix}-0.2 & 0.3\\ 0.2 & -0.3\end{bmatrix}\begin{bmatrix}x_1\\ x_2\end{bmatrix}=\begin{bmatrix}0\\ 0\end{bmatrix}\ \Longrightarrow\ -0.2x_1+0.3x_2=0\ \Longrightarrow\ 0.2x_1=0.3x_2\ \Longrightarrow\ x_1=1.5\,x_2.$$

取 $x_2=2$，得 $\mathbf{x}_1=\begin{bmatrix}3\\ 2\end{bmatrix}$（也可取 $\begin{bmatrix}0.3\\ 0.2\end{bmatrix}$，同方向）。

验证（脚本核对 $A[3,2]^{\mathsf{T}}$）：

$$A\begin{bmatrix}3\\2\end{bmatrix}=\begin{bmatrix}0.8\cdot 3+0.3\cdot 2\\0.2\cdot 3+0.7\cdot 2\end{bmatrix}=\begin{bmatrix}2.4+0.6\\0.6+1.4\end{bmatrix}=\begin{bmatrix}3\\2\end{bmatrix}\ \checkmark$$

归一化（让分量和为 1，成为真正的概率分布）：

$$\mathbf{u}_\infty=\frac{1}{3+2}\begin{bmatrix}3\\2\end{bmatrix}=\begin{bmatrix}0.6\\0.4\end{bmatrix}\ \checkmark$$

步骤 5：求 $\lambda_2=0.5$ 的特征向量。 解 $(A-0.5I)\mathbf{x}=\mathbf{0}$：

$$A-0.5I=\begin{bmatrix}0.8-0.5 & 0.3\\0.2 & 0.7-0.5\end{bmatrix}=\begin{bmatrix}0.3 & 0.3\\0.2 & 0.2\end{bmatrix}.$$

$$\begin{bmatrix}0.3 & 0.3\\0.2 & 0.2\end{bmatrix}\begin{bmatrix}x_1\\x_2\end{bmatrix}=\mathbf{0}\implies 0.3x_1+0.3x_2=0\implies x_1=-x_2.$$

取 $\mathbf{x}_2=\begin{bmatrix}1\\-1\end{bmatrix}$。**验证**：

$$A\begin{bmatrix}1\\-1\end{bmatrix}=\begin{bmatrix}0.8\cdot 1+0.3\cdot(-1)\\0.2\cdot 1+0.7\cdot(-1)\end{bmatrix}=\begin{bmatrix}0.5\\-0.5\end{bmatrix}=0.5\begin{bmatrix}1\\-1\end{bmatrix}\ \checkmark$$

步骤 6：初始条件分解 $\mathbf{u}_0=\begin{bmatrix}0\\1\end{bmatrix}$。 设 $\mathbf{u}_0=c_1\mathbf{x}_1+c_2\mathbf{x}_2$，即

$$c_1\begin{bmatrix}0.6\\0.4\end{bmatrix}+c_2\begin{bmatrix}1\\-1\end{bmatrix}=\begin{bmatrix}0\\1\end{bmatrix}.$$

（这里 c_1 乘的是**已归一化**的稳态向量 $\begin{bmatrix}0.6\\0.4\end{bmatrix}$，便于直接读出极限。）

第一分量：$0.6c_1+c_2=0\Rightarrow c_2=-0.6c_1$。 第二分量：$0.4c_1-c_2=1\Rightarrow 0.4c_1+0.6c_1=1\Rightarrow c_1=1$。 于是 $c_2=-0.6\cdot 1=-0.6$。即

$$\boxed{c_1=1,\qquad c_2=-\tfrac{3}{5}=-0.6}$$

自检：$1\cdot\begin{bmatrix}0.6\\0.4\end{bmatrix}+(-0.6)\begin{bmatrix}1\\-1\end{bmatrix}=\begin{bmatrix}0.6-0.6\\0.4+0.6\end{bmatrix}=\begin{bmatrix}0\\1\end{bmatrix}$ ✓（脚本核对输出 `c1,c2 -> 1 0.4`，其中第二个数是第二分量的残差验证 $0.4+0.6=1$。）

> ⚠ **一个高频计算陷阱**：不少同学会把 c_2 也写成 -0.4（两分量"对称地"分配）。这是错的。必须**代回两个分量**：第一个分量给出 $c_2=-0.6c_1$，第二个分量才定出 $c_1=1$。只有把 $\mathbf{u}_0=[0,1]^{\mathsf{T}}$ 完整代入方程组才能得到正确值。用 $c_2=-0.4$ 检验：$0.6(1)+(-0.4)=0.2\neq 0$ ✗。

步骤 7：写出通解并观察收敛。

$$\mathbf{u}_k=c_1\lambda_1^k\mathbf{x}_1+c_2\lambda_2^k\mathbf{x}_2=1\cdot 1^k\begin{bmatrix}0.6\\0.4\end{bmatrix}+(-0.6)(0.5)^k\begin{bmatrix}1\\-1\end{bmatrix}$$

$$\boxed{\mathbf{u}_k=\begin{bmatrix}0.6-0.6(0.5)^k\\0.4+0.6(0.5)^k\end{bmatrix}}$$

由于 $(0.5)^k\to 0$，立刻看出 $\mathbf{u}_k\to\begin{bmatrix}0.6\\0.4\end{bmatrix}$，且**误差以每步减半的速度衰减**。

逐步数值表（脚本核对，与公式完全一致）：

```
 k |  u_k(1)        u_k(2)        |u_k − u_inf|_1 (误差)
---+--------------------------------+----------------------
 0 |  0.000000     1.000000        1.20
 1 |  0.300000     0.700000        0.60
 2 |  0.450000     0.550000        0.30
 3 |  0.525000     0.475000        0.15
 4 |  0.562500     0.437500        0.075
 5 |  0.581250     0.418750        0.0375
 6 |  0.590625     0.409375        0.01875
 7 |  0.595313     0.404687        0.009375
 8 |  0.597656     0.402344        0.0046875
 9 |  0.598828     0.401172        0.00234375
10 |  0.599414     0.400586        0.001171875
```

（误差定义：$|\mathbf{u}_k - \mathbf{u}_\infty|_1 = |u_k(1) - 0.6| + |u_k(2) - 0.4| = 2 \times 0.6 \times (0.5)^k = 1.2 \cdot (0.5)^k$。第 7 行的脚本输出为 `0.595312 0.404687`，是浮点显示末位差异；精确值是 $\frac{381}{640} = 0.5953125$ 与 $\frac{259}{640} = 0.4046875$。）

每一行的两个分量之和恒为 1（脚本 `sum check` 输出全部 ≈ 1）——**概率总量守恒**，这是马尔可夫性的直接后果。

收敛曲线（ASCII 图）：

```
  u_k(1) 从 0 爬向稳态 0.600（纵轴放大到 [0.28, 0.60]，"+---" 横轴为步数 k）

0.600 |           * * * * *  <- 稳态 0.600
      |         *
      |       *
      |
0.520 |     *
      |
      |
      |
0.440 |   *
      |
      |
      |
0.360 |
      |
      |
      | *
0.280 |*
      +---------------------
        0 1 2 3 4 5 6 7 8 910  k

  数值表（脚本核对）：
   k :   0      1      2      3      4      5      6      7      8      9     10
  u_k(1): 0.0000 0.3000 0.4500 0.5250 0.5625 0.5813 0.5906 0.5953 0.5977 0.5988 0.5994
  u_k(2): 1.0000 0.7000 0.5500 0.4750 0.4375 0.4188 0.4094 0.4047 0.4023 0.4012 0.4006
  误差  : 1.2000 0.6000 0.3000 0.1500 0.0750 0.0375 0.0188 0.0094 0.0047 0.0023 0.0012

  柱状图（u_k(1)，每格 = 0.015）：
   k= 0 | 0.0000 |
   k= 1 | 0.3000 |####################
   k= 2 | 0.4500 |##############################
   k= 3 | 0.5250 |###################################
   k= 4 | 0.5625 |#####################################
   k= 5 | 0.5813 |######################################
   k= 6 | 0.5906 |######################################
   k= 7 | 0.5953 |#######################################
   k= 8 | 0.5977 |#######################################
   k= 9 | 0.5988 |#######################################
   k=10 | 0.5994 |#######################################
        （顶端那条"横杠"就是稳态 0.6000；格子几乎填满后再也不变化）

  误差 1.2 → 0.6 → 0.3 → 0.15 → 0.075 → ...   每步严格减半（因子 λ_2 = 0.5）
```

曲线形状是典型的**指数趋近**：先大幅移动，随后越来越慢，像渐近线一样贴到 0.6。**衰减速率由 $|\lambda_2| = 0.5$ 控制**——若 $\lambda_2 = 0.9$，曲线会拖得很长；若 $\lambda_2 = 0.1$，两三步就基本到位。

步骤 8：A^k 本身的极限。 用 $A^k = S\Lambda^k S^{-1}$，当 $k \to \infty$ 时 $\Lambda^k \to \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix}$，于是

$$A^\infty = \begin{bmatrix} 3 & 1 \\ 2 & -1 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} 3 & 1 \\ 2 & -1 \end{bmatrix}^{-1} = \mathbf{x}_1 \, \mathbf{y}_1^{\mathsf{T}}$$

其中 $\mathbf{y}_1^{\mathsf{T}}$ 是使 $\mathbf{y}_1^{\mathsf{T}} \mathbf{x}_1 = 1$ 的左特征向量。脚本算得

$$A^{100} = \begin{bmatrix} 0.6 & 0.6 \\ 0.4 & 0.4 \end{bmatrix} = \begin{bmatrix} 0.6 \\ 0.4 \end{bmatrix} [1 \quad 1].$$

关键在于：A^∞ 的每一列都是同一个稳态向量。 无论初始分布是什么，结果都一样。

【计算机制解说】 为什么最终只剩下秩一的矩阵？因为 $A^k = \sum_j \lambda_j^k \mathbf{x}_j \mathbf{y}_j^{\mathsf{T}}$ 是**秩一外积之和**，$\lambda_1 = 1$ 的那一项 $\mathbf{x}_1 \mathbf{y}_1^{\mathsf{T}}$ 系数恒为 1 永不衰减，其余项带着 $\lambda_j^k \to 0$ 一起消失。这就是"**稳态 = 秩一投影**"的含义：A^∞ 把任何向量投影到稳态方向上。

演示二（手算）：$f(x) = x$ 在 $[-\pi, \pi]$ 上的傅里叶级数（分部积分逐步推导）

步骤 1：a_0（常数项 / 平均值）。

$$a_0 = \frac{1}{\pi}\int_{-\pi}^{\pi} x\,dx = \frac{1}{\pi}\left[\frac{x^2}{2}\right]_{-\pi}^{\pi} = \frac{1}{\pi}\cdot 0 = 0.$$

（x 是奇函数，在对称区间上积分为 0。）注意：笔记里约定常数项写作 $\frac{a_0}{2}$，所以 f 的平均值恰为 $\frac{a_0}{2} = 0$；若用另一种常见约定 $a_0 = \frac{1}{2\pi}\int f\,dx$，则 $a_0 = 0$ 也成立。**用哪种约定都必须前后一致**。

步骤 2：余弦系数 $a_k = 0$（$k \geq 1$）。

$$a_k = \frac{1}{\pi}\int_{-\pi}^{\pi} x\cos(kx)\,dx.$$

被积函数 $x\cos kx$ 是（奇）×（偶）= **奇函数**，在对称区间 $[-\pi, \pi]$ 上积分为 0。故

$$a_k = 0 \quad (k = 1, 2, 3, \ldots).$$

几何意义：$f(x) = x$ 是奇函数，而所有 $\cos kx$ 都是偶函数，**在偶子空间上没有分量**。这跟"$\mathbf{b}$ ⊥ 某方向则投影为 0"是同一件事。

步骤 3：正弦系数 b_k（分部积分）。

$$b_k = \frac{1}{\pi}\int_{-\pi}^{\pi} x\sin(kx)\,dx.$$

令 $u = x$，$dv = \sin(kx)\,dx$，则 $du = dx$，$v = -\frac{\cos(kx)}{k}$。分部积分：

$$\int x\sin(kx)\,dx = -\frac{x\cos(kx)}{k} + \int \frac{\cos(kx)}{k}\,dx = -\frac{x\cos(kx)}{k} + \frac{\sin(kx)}{k^2}.$$

代入上下限：

$$\int_{-\pi}^{\pi} x\sin(kx)\,dx = \left[-\frac{x\cos(kx)}{k} + \frac{\sin(kx)}{k^2}\right]_{-\pi}^{\pi}.$$

正弦项在 $x = \pm\pi$ 处为 $\sin(\pm k\pi) = 0$，所以只剩第一项：

$$= -\frac{\pi\cos(k\pi)}{k} - \left(-\frac{(-\pi)\cos(-k\pi)}{k}\right) = -\frac{\pi\cos k\pi}{k} - \frac{\pi\cos k\pi}{k} = -\frac{2\pi\cos(k\pi)}{k}.$$

用 $\cos(k\pi) = (-1)^k$，以及 $-\frac{2\pi(-1)^k}{k} = \frac{2\pi(-1)^{k+1}}{k}$：

$$\int_{-\pi}^{\pi} x\sin(kx)\,dx = \frac{2\pi\,(-1)^{k+1}}{k}.$$

除以 π：

$$\boxed{b_k = \frac{1}{\pi}\cdot\frac{2\pi(-1)^{k+1}}{k} = \frac{2(-1)^{k+1}}{k}}$$

逐项列出（脚本核对）：

$$b_1 = 2, \quad b_2 = -1, \quad b_3 = \frac{2}{3} \approx 0.6667, \quad b_4 = -\frac{1}{2}, \quad b_5 = \frac{2}{5} = 0.4, \ \ldots$$

（脚本输出 `b1 2.0000, b2 -1.0000, b3 0.6667, b4 -0.5000, b5 0.4000` ✓） 注意 $|b_k| = 2/k \to 0$：**高频分量越来越小**，这是傅里叶级数能收敛的原因，也解释了为什么"少数几项就能抓住主要形状"。

独立数值验证：$\int_{-\pi}^{\pi} x\sin x\,dx$ 的数值积分 = 6.283185307，而公式给 $\frac{2\pi(-1)^2}{1} = 2\pi = 6.283185307$ ✓；同时 $\int_{-\pi}^{\pi}\sin^2 x\,dx = 3.141592654 = \pi$ ✓。

步骤 4：写出级数。

$$\boxed{x = 2\left[\sin x - \frac{\sin 2x}{2} + \frac{\sin 3x}{3} - \frac{\sin 4x}{4} + \cdots\right] = \sum_{k=1}^{\infty}\frac{2(-1)^{k+1}}{k}\sin(kx)}$$

步骤 5：前三项近似与数值比较。

$$S_3(x) = 2\sin x - \sin 2x + \frac{2}{3}\sin 3x.$$

在 $x = 1$（弧度）处的部分和（脚本核对）：

$$S_1(1) = 2\sin 1 = 1.682942, \qquad S_2(1) = 0.773645, \qquad S_3(1) = 0.867725, \qquad \text{精确值 } f(1) = 1.$$

可见收敛是**震荡式**的（先冲过头、再回来），不是单调逼近——这与马尔可夫那部分的单调指数收敛形成鲜明对比。

部分和逼近图（ASCII 图）：

```
   f(x)=x 与部分和 S_3(x) = 2sin x − sin 2x + (2/3)sin 3x     (x ∈ [−π, π])

 y
 π |                                          ,'|
   |                                       ,-'  |
   |                                    ,-'     |   ← 虚线为 f(x)=x
   |                                 ,-'        |
   |                              ,-'           |
   |                           ,-'              |
   |                        ,-'  ····           |
   |                     ,-' ····      ····     |
 0 |---------·-------------------------------------|------→ x
   |      ··/    ···                      ····     |   S_3 在 x=0,±π 处
   |    ··/           ····                    ····|   与 f 精确相交
   |  ··/                 ·····                |
−π |··/                                       ,'|
   +-----------------------------------------'---+
     −π        −π/2        0        π/2        π

 特征：S_N 是奇函数，在 x = 0, ±π 处与 f 完全吻合（所有 sin(kx) 在这些点都是 0）；
       在区间内部 S_N 上下摆动穿越直线 f(x)=x，N 越大摆幅越小。
```

步骤 6：最优性（这是讲次 15–16 的连续翻版）。 设用前 N 个正弦函数张成子空间 $V_N = \mathbf{span}\{\sin x, \sin 2x, \ldots, \sin Nx\}$。取 V_N 中任意函数 $g = \sum_{k=1}^{N} c_k \sin kx$，要最小化

$$\|f - g\|^2 = \int_{-\pi}^{\pi} \big(f(x) - g(x)\big)^2 dx.$$

结论：最小值在 $c_k = b_k$（即 $g = S_N$）处取到。 证明与离散情况逐字对应：把 $\|f-g\|^2$ 展开成 $\|f\|^2 - 2\sum c_k\langle f, \sin kx\rangle + \sum c_k^2\pi$，对每个 c_k 求偏导置零，得 $2c_k\pi - 2\langle f, \sin kx\rangle = 0$，即 $c_k = \frac{\langle f, \sin kx\rangle}{\langle \sin kx, \sin kx\rangle} = b_k$。这正是**法方程（normal equations）**的连续版本。

数值证据（脚本核对，$\|f - S_N\|^2$ 递减）：

$$N=1:\ 8.1045, \qquad N=2:\ 4.9629, \qquad N=3:\ 3.5666, \qquad N=5:\ 2.2786.$$

随 N 增大单调下降（且趋于 0），**没有任何其他系数的选择能给出更小的误差**。

步骤 7：Parseval 恒等式与 $x = \pi/2$ 得到的 Leibniz 级数。 连续版"勾股定理"：$\|f\|^2 = \sum$（系数）$^2 \times$（基长度）^{2}：

$$\int_{-\pi}^{\pi} x^2 dx = \frac{2\pi^3}{3} \quad \overset{?}{=} \quad \sum_{k=1}^{\infty} b_k^2 \cdot \pi = \pi \sum_{k=1}^{\infty} \frac{4}{k^2} = 4\pi \cdot \frac{\pi^2}{6} = \frac{2\pi^3}{3} \ \checkmark$$

（脚本核对：左边 $\mathbf{20.670851}$，右边取 $k \le 6$ 时 $\mathbf{18.741346}$，加上尾部正好收敛到 $\mathbf{20.670851}$ ✓。这说明 $\sum 1/k^2 = \pi^2/6$ 与傅里叶展开是同一件事的两面。）

令 $x = \frac{\pi}{2}$：此时 $\sin(kx)$ 依次为 $\sin\frac{\pi}{2} = 1$，$\sin\pi = 0$，$\sin\frac{3\pi}{2} = -1$，$\sin 2\pi = 0$，$\sin\frac{5\pi}{2} = 1, \ldots$，即 k 奇时等于 $(-1)^{(k-1)/2}$，k 偶时为 0。代入 $x = 2\big[\sin x - \frac{\sin 2x}{2} + \frac{\sin 3x}{3} - \frac{\sin 4x}{4} + \frac{\sin 5x}{5} - \cdots\big]$，偶数项全部消失，奇数项留下：

$$\frac{\pi}{2} = 2\left[1 - 0 + \frac{-1}{3} - 0 + \frac{1}{5} - 0 + \frac{-1}{7} + \cdots\right] = 2\left[1 - \frac{1}{3} + \frac{1}{5} - \frac{1}{7} + \cdots\right].$$

两边除以 2：

$$\boxed{\frac{\pi}{4} = 1 - \frac{1}{3} + \frac{1}{5} - \frac{1}{7} + \cdots}$$

（注意符号来源：$-1/3$ 是 $\frac{b_3}{1}\sin(3\pi/2) = \frac{2}{3}\cdot(-1)$ 除以 2 的结果，$+1/5$ 是 $\frac{2}{5}\cdot(+1)$ 除以 2 的结果——**符号来自各个 $\sin(k\pi/2)$ 的正负，不是来自 b_k 的 $(-1)^{k+1}$**，两者在奇数 k 上恰好合成同一个交错模式。**脚本核对**：取 2×10^4 项求和得 $\mathbf{1.570746}$，$\pi/2 = 1.570796$ ✓（误差 5×10^{-5}，正是 Leibniz 级数著名的慢收敛）。）

【计算机制解说】 为什么"投影系数"能同时做到"误差最小"和"级数收敛到 f"？因为三角函数系是**正交基（完备正交系）**，基向量两两垂直意味着各分量互不干扰：调整 c_k 只影响 c_k 那个方向上的误差，所以在每个方向上分别取最优就得到全局最优。正交性把 n 维的最小二乘问题**解耦**成 n 个独立的一元问题——这与讲次 15 里 $\hat{\mathbf{x}} = (A^{\mathsf{T}}A)^{-1}A^{\mathsf{T}}\mathbf{b}$ 在 A 的列正交时退化为逐列相除 $\hat{x}_i = \mathbf{q}_i^{\mathsf{T}}\mathbf{b}/\mathbf{q}_i^{\mathsf{T}}\mathbf{q}_i$，是完全相同的机制。

演示三（手算）：3×3 马尔可夫矩阵与 $f(x)=x^2$ 的傅里叶系数

（3a）3×3 人口迁移模型。

$$M=\begin{bmatrix}0.9 & 0.1 & 0.1\\ 0.05 & 0.8 & 0.1\\ 0.05 & 0.1 & 0.8\end{bmatrix}$$

列和验证：第 1 列 $0.9+0.05+0.05=1$ ✓；第 2 列 $0.1+0.8+0.1=1$ ✓；第 3 列 $0.1+0.1+0.8=1$ ✓。元素非负 ✓，故是马尔可夫矩阵。

特征多项式（脚本用系数 $c_1=\mathrm{tr}=2.5$、$c_0=\det=0.56$ 计算）：

$$-\lambda^3+2.5\lambda^2-2.06\lambda+0.56=-(\lambda-1)(\lambda^2-1.5\lambda+0.56)=-(\lambda-1)(\lambda-0.8)(\lambda-0.7).$$

$$\lambda_1=1,\qquad \lambda_2=0.8,\qquad \lambda_3=0.7.$$

（自检：$1+0.8+0.7=2.5=\mathrm{tr}$ ✓；$1\times 0.8\times 0.7=0.56=\det$ ✓。）

稳态（幂迭代脚本结果）：$\mathbf{u}_\infty=\begin{bmatrix}0.5\\0.25\\0.25\end{bmatrix}$，且 $M\mathbf{u}_\infty=\mathbf{u}_\infty$ ✓（脚本核对完全一致）。收敛速度由第二大模长 $|\lambda_2|=0.8$ 控制，误差每步乘以 0.8：$0.8^{10}=0.107374$，$0.8^{20}=0.011529$（脚本核对 ✓）。注意**不是 0.7 主导**——虽然 $|\lambda_3|=0.7<0.8$，但 0.7 那一项衰减更快，长期由更慢的 0.8 说了算。这也说明"收敛速度 = 第二大特征值"这条法则用的是**按模长排序的第二个**，而不是随便挑一个。

（3b）$f(x)=x^2$ 的傅里叶系数（偶函数，只有余弦项）。

$$a_0=\frac{1}{\pi}\int_{-\pi}^{\pi}x^2dx=\frac{1}{\pi}\cdot\frac{2\pi^3}{3}=\frac{2\pi^2}{3}\quad\Longrightarrow\quad\frac{a_0}{2}=\frac{\pi^2}{3}\approx 3.289868.$$

（数值积分得到 3.289868，与 $\pi^2/3$ 一致 ✓。）

$$a_k=\frac{1}{\pi}\int_{-\pi}^{\pi}x^2\cos(kx)\,dx=\frac{4(-1)^k}{k^2},\qquad b_k=0\ (x^2\sin kx\text{ 是奇函数}).$$

（脚本核对：$k=1:-4.0000$、$k=2:+1.0000$、$k=3:-0.4444$、$k=4:+0.2500$，与 $4(-1)^k/k^2$ 完全一致 ✓。）

于是

$$x^2=\frac{\pi^2}{3}+4\sum_{k=1}^{\infty}\frac{(-1)^k}{k^2}\cos(kx)=\frac{\pi^2}{3}-4\cos x+\cos 2x-\frac{4}{9}\cos 3x+\cdots$$

在 $x=\pi$ 处：$\pi^2=\frac{\pi^2}{3}+4\sum\frac{(-1)^k}{k^2}(-1)^k=\frac{\pi^2}{3}+4\sum\frac{1}{k^2}$，得 $\sum 1/k^2=\pi^2/6$ ✓——又是一个"用傅里叶级数证明数论恒等式"的漂亮例子。

Parseval 自检：$2\pi\left(\frac{\pi^2}{3}\right)^2+\pi\sum\frac{16}{k^4}=\frac{2\pi^5}{9}+\frac{16\pi}{90}\pi^4=\frac{2\pi^5}{9}+\frac{8\pi^5}{45}=\frac{2\pi^5}{5}=\int_{-\pi}^{\pi}x^4dx$ ✓（数值：122.4079 对 122.4079）。

演示四（应用）：天气预报、Google PageRank 与"长期行为 = 稳态"

（4a）天气模型（晴 / 雨）。 设状态 1 = 晴，状态 2 = 雨，转移矩阵

$$W=\begin{bmatrix}0.9 & 0.5\\ 0.1 & 0.5\end{bmatrix}$$

其中第 1 列读作"今天晴：明天晴 0.9，明天雨 0.1"，第 2 列读作"今天雨：明天晴 0.5，明天雨 0.5"。列和 $0.9+0.1=1$、$0.5+0.5=1$ ✓。特征值：$\mathrm{tr}=1.4$，$\det=0.9\cdot 0.5-0.5\cdot 0.1=0.45-0.05=0.40$，故 $\lambda^2-1.4\lambda+0.4=(\lambda-1)(\lambda-0.4)$，即 $\lambda_1=1,\ \lambda_2=0.4$。

稳态：$W-I=\begin{bmatrix}-0.1 & 0.5\\ 0.1 & -0.5\end{bmatrix}\Rightarrow 0.1x_1=0.5x_2\Rightarrow x_1=5x_2$，取 $\begin{bmatrix}5\\1\end{bmatrix}$，归一化得

$$\mathbf{u}_\infty=\begin{bmatrix}5/6\\1/6\end{bmatrix}\approx\begin{bmatrix}0.8333\\0.1667\end{bmatrix}.$$

验证：$W\begin{bmatrix}0.8333\\0.1667\end{bmatrix}=\begin{bmatrix}0.9(0.8333)+0.5(0.1667)\\0.1(0.8333)+0.5(0.1667)\end{bmatrix}=\begin{bmatrix}0.75+0.0833\\0.0833+0.0833\end{bmatrix}\approx\begin{bmatrix}0.8333\\0.1667\end{bmatrix}$ ✓

解读：长期来看约 $5/6$ 的日子是晴天、$1/6$ 是雨天——**与初始天气完全无关**。衰减因子 $|\lambda_2|=0.4$ 很小，所以约 5–6 天后就基本进入这个比例。

（4b）人口迁移模型。 演示三的 M 就是其抽象形式：三个城市之间每年迁移一部分人口，M_{ij} = 从城市 j 迁到城市 i 的比例（留在本地记入对角元）。长期分布 $\begin{bmatrix}0.5\\0.25\\0.25\end{bmatrix}$ 表示无论最初人口如何分布，最终三个城市会稳定在 $2:1:1$。这与种群生态学中的 Leslie 矩阵、化学反应的平衡浓度、疾病传播的终点分布都是同一套数学。

（4c）Google PageRank：稳态向量 = 网页排名。

把互联网想成一个巨大的有向图：节点 = 网页，边 = 超链接。定义"随机冲浪者"：站在网页 j 上时，以相等概率点击 j 的某个出链；即 $a_{ij} = \frac{1}{(\text{网页 } j \text{ 的出链数})}$（若 j 链向 i），否则为 0。这样按列求和恰好为 1（j 的全部出链概率之和为 1，还是"列和 = 1"！），**得到一个巨型马尔可夫矩阵**（今天的网页数 n 是千亿量级）。

PageRank 就是求这个矩阵的稳态向量 $\mathbf{x}$：$G\mathbf{x} = \mathbf{x}$，$\sum_i x_i = 1$。分量 x_i 就是网页 i 的"重要性"分数，Google 用它排序搜索结果。为什么这是个好定义？因为**一个网页的重要性 = 指向它的那些网页的重要性，按各自出链数摊分后求和**——这正是稳态方程 $x_i = \sum_j a_{ij}x_j$ 的逐字解读。这个想法跟讲次 21–22 的"特征向量是矩阵的固有方向"完全同源；只是矩阵规模让 $S\Lambda S^{-1}$ 无法使用，实际算法是**幂迭代** $\mathbf{u}_{k+1} = G\mathbf{u}_k$（等价于让随机冲浪者走很多步），由 $|\lambda_2| < 1$ 保证收敛。

两个必须打的补丁：

- **悬挂节点（dangling node）**：若网页 j 没有任何出链，则该列为全零，列和不是 1，G 不是马尔可夫矩阵，随机冲浪者的概率会"漏掉"。补法是令它等概率跳到所有网页。
- **阻尼因子（damping factor）$d = 0.85$**：纯链接转移矩阵可能周期或可约，不保证收敛。Brin 与 Page 的做法是混合

$$G = 0.85\,M + 0.15\,\frac{1}{n}\mathbf{1}\mathbf{1}^{\mathsf{T}},$$

即"以 0.85 的概率沿链接走，以 0.15 的概率随机跳到任意网页"。因为 $\frac{1}{n}\mathbf{1}\mathbf{1}^{\mathsf{T}}$ 的**每一列都是** $\frac{1}{n}\mathbf{1}$，列和仍为 1，G 仍是马尔可夫矩阵；而且**全部元素严格为正**（$G_{ij} \geq 0.15/n > 0$）。严格正的马尔可夫矩阵自动不可约且非周期，于是 $\lambda = 1$ 单重、其余 $|\lambda_j| \leq 0.85$，**唯一稳态 + 快速收敛**（误差每步至少乘 0.85，$0.85^{50} \approx 0.0003$）。这就是"为什么必须加阻尼因子"的完整理由。

（4d）为什么"长期行为 = 稳态"？ 一句话：$\mathbf{u}_k = \sum_j c_j\lambda_j^k\mathbf{x}_j$，只有 $\lambda = 1$ 那一项带 1^k 存活，其余 $|\lambda_j| < 1$ 的项被指数式抹掉。**初始条件的信息只存在于 c_j 里，而 $\lambda_j^k \to 0$ 让这些信息消失**——这既解释了收敛，也解释了"为什么稳态与初始分布无关"。用讲次 22 的话说：A^k 趋于一个秩一投影。

矩阵分解的核心思想

本讲出现的是**同一个思想的两种化身**：

（1）$A^k = S\Lambda^k S^{-1}$ 的"特征展开"

对演示一的 A，取 $S = \begin{bmatrix} 3 & 1 \\ 2 & -1 \end{bmatrix}$（列是特征向量，稳态列未归一化），$\Lambda = \begin{bmatrix} 1 & 0 \\ 0 & 0.5 \end{bmatrix}$，则

$$A^k = S\Lambda^k S^{-1} = 1^k\mathbf{x}_1\mathbf{y}_1^{\mathsf{T}} + (0.5)^k\mathbf{x}_2\mathbf{y}_2^{\mathsf{T}}.$$

这是**把矩阵拆成"不变模式"之和**：每个模式 $\mathbf{x}_j\mathbf{y}_j^{\mathsf{T}}$ 是秩一的，A 作用在它上面只是乘 λ_j。极限情形 $A^\infty = \mathbf{x}_1\mathbf{y}_1^{\mathsf{T}}$ 是一个**秩一投影**（A^∞ 的每一列都相同 = 稳态向量），它把任何初始分布"拍"到稳态方向上。

（2）傅里叶级数 = 无穷维的 $Q\Lambda Q^{\mathsf{T}}$ / 正交基展开

把 f 写成

$$f = \sum_k \frac{\langle f, \varphi_k\rangle}{\langle \varphi_k, \varphi_k\rangle}\,\varphi_k,$$

其中 $\{\varphi_k\}$ 是正交函数系。逐项对比：

```
                有限维（讲次 14–16）              无穷维 / 连续（本讲）
─────────────────────────────────────────────────────────────────────
基向量          q_1, ..., q_n                    1, cos x, sin x, cos 2x, ...
内积            v^T w = Σ v_i w_i                <f,g> = ∫ f(x)g(x) dx
正交条件        q_i^T q_j = 0 (i≠j)              ∫ φ_i φ_j = 0 (i≠j)
基长度平方      q_i^T q_i                        ∫ φ_i^2 = π 或 2π
投影系数        x̂_i = q_i^T b / q_i^T q_i         a_k = <f,cos kx>/<cos kx,cos kx>
最佳逼近        投影到 C(A) 上                   投影到 span{前 N 个三角基}
误差最小        ||b − A x̂|| 最小                 ||f − S_N|| 最小
勾股定理        ||b||^2 = Σ (q_i^T b)^2/||q_i||^2   ||f||^2 = Σ (系数)^2 ||φ_i||^2
```

同一个分解的两个极端：

	离散	连续
分解	$A = Q\Lambda Q^{\mathsf{T}}$（对称）或 $A = S\Lambda S^{-1}$	$f = \sum_k c_k\varphi_k$
系数	$\mathbf{q}_i^{\mathsf{T}}\mathbf{b}$	$\langle f, \varphi_k\rangle / \langle \varphi_k, \varphi_k\rangle$

	离散	连续
意义	沿特征方向分解	沿频率分解
应用	对角化、A^k、PageRank	信号处理、热传导、DFT/FFT

离散化的傅里叶 = 正交矩阵。 若只在 n 个等距点上采样 f，则积分变成求和，傅里叶系数变成矩阵乘法 $\hat{\mathbf{c}} = F\mathbf{f}$，其中 F 是**离散傅里叶变换矩阵（DFT matrix）**，它的列是采样后的三角基。F 是**酉/正交矩阵**（差一个 $1/\sqrt{n}$ 归一化），$F^{-1} = F^*$ —— 这正是讲次 14"正交矩阵 $Q^{-1} = Q^{\mathrm{T}}$"的直接体现。n 个点的 DFT 若直接乘矩阵要 $O(n^2)$，**FFT（快速傅里叶变换）**把它降到 $O(n \log n)$，这是 20 世纪最重要的算法之一。Strang 在课上用一句话概括："整个信号处理产业都建立在'正交矩阵'这一个概念上。"

马尔可夫与傅里叶的共同点：两处都在**用一组基把对象展开，然后让每个分量独立演化**。马尔可夫里分量按 λ_j^k 衰减；傅里叶里分量按频率排布。A^k 收敛是因为 $|\lambda_j| < 1$；傅里叶级数收敛是因为 $|c_k|$ 随 k 快速衰减。**"对角化 = 解耦"是这门课自始至终的主旋律。**

与其他讲次的关联

- **讲次 21（特征值与特征向量）**：本讲全部计算都建立在 $A\mathbf{x} = \lambda\mathbf{x}$ 与 $\det(A - \lambda I) = 0$ 之上。$A - I$ 的行线性相关 $\iff$ 列和为 1，是"奇异矩阵有非零零空间"的直接应用。
- **讲次 22（对角化与 A^k）**：$A^k = S\Lambda^k S^{-1}$ 是本讲马尔可夫收敛的**唯一工具**。$\mathbf{u}_k = \sum_j c_j \lambda_j^k \mathbf{x}_j$ 中只有 $\lambda = 1$ 项存活，这就是"稳态"。也再次印证讲次 22 的稳定性判据：所有 $|\lambda_j| < 1$ 时 $A^k \to 0$；有 $|\lambda_j| > 1$ 时发散。马尔可夫矩阵恰好卡在临界情形（一个 $= 1$，其余 < 1）——所以**收敛到一个非零矩阵而不是零**。
- **讲次 23（微分方程 $du/dt = Au$）**：连续时间的稳态是 $\lambda = 0$（即 $du/dt = 0$），因为解里 $e^{\lambda t}$ 只有 $\lambda = 0$ 不衰减；离散时间的稳态是 $\lambda = 1$，因为 λ^k 只有 $\lambda = 1$ 不衰减。**两个"1"与"0"的呼应**：$e^{0t} = 1$ 对 $\lambda = 0$，$\lambda^k = 1$ 对 $\lambda = 1$ —— 这正是把 A 换成 $A - I$ 的对应（$e^{(A-I)t}$ 的特征值 $e^{(\lambda-1)t}$）。
- **讲次 25（对称矩阵与正定矩阵）**：对称马尔可夫矩阵（如演示三里的 S，三列全同）有**实特征值**且特征向量**正交**，收敛行为最干净：$\lambda_1 = 1$，其余 $|\lambda_j| < 1$，稳态 $\mathbf{u}_\infty = \mathbf{1}/n$。讲次 25 会给出"实特征值 + 正交特征向量"的完美理论。演示三的 M **不是**对称的（$M_{12} = 0.1 \neq 0.05 = M_{21}$），所以它的特征向量不正交，但收敛性依然成立。
- **讲次 14–16（正交、投影、最小二乘）**：傅里叶系数就是投影系数 $\hat{x} = \frac{\mathbf{a}^{\mathrm{T}}\mathbf{b}}{\mathbf{a}^{\mathrm{T}}\mathbf{a}}$ 的积分版本；"截断傅里叶级数是 L^2 意义下的最佳逼近"就是投影定理；法方程 $A^{\mathrm{T}}A\hat{\mathbf{x}} = A^{\mathrm{T}}\mathbf{b}$ 在基正交时解耦为逐项相除。
- **讲次 27–29（SVD）**：SVD $A = U\Sigma V^{\mathrm{T}}$ 也是"用正交基展开"，而且是**对任意矩阵**都成立的展开（不要求对称、不要求可对角化）。马尔可夫的 $A^\infty = \mathbf{x}_1\mathbf{y}_1^{\mathrm{T}}$ 本身就是一种"秩一分解"，是 SVD 思想的雏形。
- **讲次 11–12（图与网络）**：PageRank 的马尔可夫矩阵正是"网络图"的转移矩阵，把讲次 12 的关联矩阵视角接了过来。

关键要点

1. **马尔可夫矩阵 = 非负 + 每列和 1（列随机）**。a_{ij} 读作"从状态 j 到状态 i"的转移概率，$\mathbf{u}_{k+1} = A\mathbf{u}_k$，且 A 保持分量和与 1–范数不增。
2. **$\lambda = 1$ 永远是特征值**，因为列和 1 $\iff$ $A^{\mathrm{T}}\mathbf{1} = \mathbf{1}$ $\iff$ $\det(A - I) = 0$。**注意 $\mathbf{1}$ 是 A^{T} 的特征向量，不是（一般地）A 的。**
3. **全部特征值满足 $|\lambda| \leq 1$**：直接论证是"A 不放大 1–范数"（因为列和为 1），$\|A\mathbf{x}\|_1 \leq \|\mathbf{x}\|_1$；Gershgorin 论证要**用在 A^{T} 上**（等价的"列圆盘" $[2a_{jj} - 1,\ 1] \subseteq [-1, 1]$），用在 A 自己的行圆盘上会越界。若不可约且非周期，则 $\lambda = 1$ 单重、其余 $|\lambda| < 1$，于是 $\mathbf{u}_k = A^k\mathbf{u}_0 \to$ **稳态向量**（归一化使分量和为 1 的 $\lambda = 1$ 特征向量）。收敛速度由**第二大模长** $|\lambda_2|$ 决定。
4. **A^∞ 是秩一投影**：$A^\infty = \mathbf{x}_1\mathbf{y}_1^{\mathrm{T}}$，每一列都是同一个稳态向量，秩为 1 —— 这是 $A^k = S\Lambda^k S^{-1}$ 中只有 $\lambda_1 = 1$ 项存活的几何含义。
5. **傅里叶系数就是投影系数**：

$$a_k = \frac{\langle f, \cos kx\rangle}{\langle \cos kx, \cos kx\rangle} = \frac{1}{\pi}\int_{-\pi}^{\pi} f(x)\cos(kx)\,dx, \qquad b_k = \frac{1}{\pi}\int_{-\pi}^{\pi} f(x)\sin(kx)\,dx$$

与离散的 $\hat{x}_i = \frac{\mathbf{q}_i^{\mathrm{T}}\mathbf{b}}{\mathbf{q}_i^{\mathrm{T}}\mathbf{q}_i}$ **结构完全相同**，只是"求和"换成了"积分"。 6. **必背范例**：$x = 2\sum_{k\geq 1}\frac{(-1)^{k+1}}{k}\sin kx$ 于 $[-\pi, \pi]$；取 $x = \pi/2$ 得 $\frac{\pi}{4} = 1 - \frac{1}{3} + \frac{1}{5} - \cdots$。截断的部分和 S_N 是 L^2 意义下最佳逼近，且 $\|f\|^2 = \sum c_k^2\|\varphi_k\|^2$（Parseval）。

常见误区与注意事项

1. **把"列和为 1"记成"行和为 1"。** 本课程的约定是**列随机**：$A^{\mathrm{T}}\mathbf{1} = \mathbf{1}$。若改成行和为 1（行随机），则 $\mathbf{1}$ 是 A（而非 A^{T}）的特征向量，$\lambda = 1$ 的结论仍然成立，但**稳态向量 $A\mathbf{x} = \mathbf{x}$ 与 $\mathbf{1}$ 的关系、以及 a_{ij} 的"从 j 到 i"解读全会颠倒**。判定题目给的是哪种约定，是第一件事。**记忆口诀**：列和 = 1 时，$\mathbf{u}$ 是**列向量**且 $A\mathbf{u}$ 保证概率守恒（$\mathbf{1}^{\mathrm{T}}A\mathbf{u} = \mathbf{1}^{\mathrm{T}}\mathbf{u}$）；这正是"列和"的用武之处。
2. **以为"所有 $|\lambda| < 1$"，或者以为 $\lambda = 1$ 的项也会衰减。** 正确的是：$\lambda = 1$ **必然**是特征值之一（所以不可能全部 < 1），而其余才能严格 < 1。$1^k = 1$ 永不衰减，这正是稳态**非零**的原因。相应地，A^k 不趋于零矩阵，而趋于秩一的 A^∞。若错说成"趋向零"，那是对讲次 22 中

$|\lambda|<1 \Rightarrow A^k \to 0$ 的判据**误用**——马尔可夫矩阵恰好不满足那个前提。

3. **傅里叶系数的归一化常数搞混。** 必须**先声明区间与公式**再计算。本讲的约定是区间 $[-\pi,\pi]$、$a_k=\frac{1}{\pi}\int f\cos kx$、$b_k=\frac{1}{\pi}\int f\sin kx$、常数项写 $\frac{a_0}{2}$（用 $a_0=\frac{1}{\pi}\int f$）。若改用区间 $[-L,L]$，则所有 $\frac{1}{\pi}$ 变成 $\frac{1}{L}$，且 kx 变成 $\frac{k\pi x}{L}$；若改用复指数形式 $f=\sum c_k e^{ikx}$，则 $c_k=\frac{1}{2\pi}\int f e^{-ikx}dx$，且 c_k 与 a_k,b_k 的关系是 $c_k=\frac{a_k-ib_k}{2}$（$k>0$）。**混用会导致结果差 2 倍或 π 倍。**
4. **以为傅里叶级数在每个点都收敛到 $f(x)$。** 在**跳跃间断点**处，级数收敛到**左右极限的平均值** $\frac{f(x^-)+f(x^+)}{2}$。典型例子：方波 $f(x)=+1\ (0<x<\pi)$、$-1\ (-\pi<x<0)$ 的展开是 $f=\frac{4}{\pi}\left(\sin x+\frac{\sin 3x}{3}+\frac{\sin 5x}{5}+\cdots\right)$（只有奇次谐波），在 $x=0$ 处级数收敛到 0，而 $f(0)$ 本身要么未定义要么取 ± 1。这也是**吉布斯现象（Gibbs phenomenon）**的来源：部分和在跳点附近永远有约 9% 的过冲，$N\to\infty$ 也不消失（只是被压缩到跳点附近）。此外，收敛还要求 f 满足一定条件（分段光滑即可），病态函数可能不逐点收敛。
5. **以为傅里叶基是"唯一"的正交基。** 三角函数系只是一组方便的正交基（对周期函数、对平移不变的算子特别自然），但绝非唯一。勒让德多项式在 $[-1,1]$ 上正交（带权 1）、切比雪夫多项式带权 $1/\sqrt{1-x^2}$ 正交、哈尔小波（Haar wavelets）也是正交基。**选哪组基要看问题**：解热传导方程用三角函数（它们是 d^2/dx^2 的特征函数！），压缩图像用小波。这与讲次 30"选对基能让矩阵变简单"是同一思想，也是本课程最后一章"基变换"的伏笔。

思考题（带答案）

Q1.（纯计算）设马尔可夫矩阵

$$A=\begin{bmatrix}0.7 & 0.2\\ 0.3 & 0.8\end{bmatrix}.$$

(a) 验证它是马尔可夫矩阵；(b) 求全部特征值；(c) 求归一化的稳态向量；(d) 若 $\mathbf{u}_0=\begin{bmatrix}1\\0\end{bmatrix}$，写出 $\mathbf{u}_k$ 的闭式表达式，并指出误差按什么比率衰减。

> ▸ **答案**
>
> (a) 元素全非负 ✓；第 1 列 $0.7+0.3=1$ ✓；第 2 列 $0.2+0.8=1$ ✓。是马尔可夫矩阵。
>
> (b) 特征多项式：
>
> $$\det(A-\lambda I)=(0.7-\lambda)(0.8-\lambda)-0.06=\lambda^2-1.5\lambda+0.56-0.06=\lambda^2-1.5\lambda+0.5.$$
>
> $$=(\lambda-1)(\lambda-0.5)\implies \lambda_1=1,\ \lambda_2=0.5.$$
>
> 自检：$\mathrm{tr}=1.5=1+0.5$ ✓，$\det=0.7\cdot 0.8-0.2\cdot 0.3=0.56-0.06=0.5=1\cdot 0.5$ ✓。
>
> (c) 解 $(A-I)\mathbf{x}=0$：
>
> $$A-I=\begin{bmatrix}-0.3 & 0.2\\ 0.3 & -0.2\end{bmatrix}\implies -0.3x_1+0.2x_2=0\implies x_1=\tfrac{2}{3}x_2.$$
>
> 取 $\mathbf{x}_1=\begin{bmatrix}2\\3\end{bmatrix}$；归一化：$\frac{1}{2+3}\begin{bmatrix}2\\3\end{bmatrix}=\begin{bmatrix}0.4\\0.6\end{bmatrix}$。验证：$A\begin{bmatrix}0.4\\0.6\end{bmatrix}=\begin{bmatrix}0.7(0.4)+0.2(0.6)\\0.3(0.4)+0.8(0.6)\end{bmatrix}=\begin{bmatrix}0.28+0.12\\0.12+0.48\end{bmatrix}=\begin{bmatrix}0.4\\0.6\end{bmatrix}$ ✓
>
> (d) $\lambda_2=0.5$ 的特征向量：$(A-0.5I)=\begin{bmatrix}0.2 & 0.2\\ 0.3 & 0.3\end{bmatrix}\Rightarrow x_1=-x_2$，取 $\begin{bmatrix}1\\-1\end{bmatrix}$。设 $\mathbf{u}_0=c_1\begin{bmatrix}0.4\\0.6\end{bmatrix}+c_2\begin{bmatrix}1\\-1\end{bmatrix}=\begin{bmatrix}1\\0\end{bmatrix}$。第一分量：$0.4c_1+c_2=1$；第二分量：$0.6c_1-c_2=0\Rightarrow c_2=0.6c_1$。代入第一式：$0.4c_1+0.6c_1=1\Rightarrow c_1=1,\ c_2=0.6$。
>
> $$\mathbf{u}_k=\begin{bmatrix}0.4\\0.6\end{bmatrix}+0.6(0.5)^k\begin{bmatrix}1\\-1\end{bmatrix}=\begin{bmatrix}0.4+0.6(0.5)^k\\0.6-0.6(0.5)^k\end{bmatrix}.$$
>
> 自检 $k=0$：$\begin{bmatrix}1.0\\0.0\end{bmatrix}$ ✓；$k=1$：$A\mathbf{u}_0=\begin{bmatrix}0.7\\0.3\end{bmatrix}$，公式给 $\begin{bmatrix}0.4+0.3\\0.6-0.3\end{bmatrix}=\begin{bmatrix}0.7\\0.3\end{bmatrix}$ ✓。误差按比率 $|\lambda_2|=0.5$ **每步减半**，$\mathbf{u}_k\to\begin{bmatrix}0.4\\0.6\end{bmatrix}$。

Q2.（判断 + 概念）判断下列矩阵哪些是马尔可夫矩阵，并说明理由：

$$B=\begin{bmatrix}0.2 & 0.3\\ 0.9 & 0.6\end{bmatrix},\qquad C=\begin{bmatrix}0.7 & -0.1\\ 0.3 & 1.1\end{bmatrix},\qquad D=\begin{bmatrix}0.5 & 0.5\\ 0.5 & 0.5\end{bmatrix}.$$

对 B，$B^k\mathbf{u}_0$ 会收敛吗？

▸ 答案

B：**不是。** 列和分别为 $0.2+0.9=1.1$ 和 $0.3+0.6=0.9$，都不等于 1。**它连 $\lambda=1$ 都没有**：$\mathrm{tr}=0.8$，$\det=0.2\cdot0.6-0.3\cdot0.9=0.12-0.27=-0.15$，特征值 $\lambda=\frac{0.8\pm\sqrt{0.64+0.6}}{2}=\frac{0.8\pm\sqrt{1.24}}{2}$，即 $\lambda_1\approx0.956776$，$\lambda_2\approx-0.156776$。两者**都严格小于 1**（模），所以 $B^k\to0$，$B^k\mathbf{u}_0\to\mathbf{0}$ —— **衰减到零向量，而不是收敛到概率分布**。这也说明"有非负元素"远远不够：B 看起来"很概率"，但它不守恒概率（1.1 那一列在多产生概率）。

C：**不是。** 列和确实都是 1（$0.7+0.3=1$，$-0.1+1.1=1$），但**出现了负元素 -0.1**，违反条件 ①。它不是马尔可夫矩阵。有趣的是它**仍有 $\lambda=1$**（$C-I=\begin{bmatrix}-0.3&-0.1\\0.3&0.1\end{bmatrix}$ 奇异），其余特征值为 0.8（$\mathrm{tr}=1.8=1+0.8$ ✓，$\det=0.77+0.03=0.8=1\times0.8$ ✓）。因为它**不保正性**，$\mathbf{u}_k$ 可能出现负分量：从 $\mathbf{u}_0=\begin{bmatrix}0.5\\0.5\end{bmatrix}$ 出发，脚本给出 $C^4\mathbf{u}_0=\begin{bmatrix}-0.090\\1.090\end{bmatrix}$ —— **分量为负、超过 1，已经不是概率分布**。这生动说明了"非负性"条件不可省。

D：**是。** 元素非负 ✓，每列 $0.5+0.5=1$ ✓。D 是秩一投影：$D^2=D$（验证：$D^2=\begin{bmatrix}0.5&0.5\\0.5&0.5\end{bmatrix}=D$）。特征值 $\lambda_1=1,\ \lambda_2=0$（$\mathrm{tr}=1$ ✓，$\det=0$ ✓）。稳态：$D\mathbf{x}=\mathbf{x}$ 给出 $x_1+x_2=2x_1\Rightarrow x_1=x_2$，故 $\mathbf{u}_\infty=\begin{bmatrix}0.5\\0.5\end{bmatrix}$。由于 $\lambda_2=0$，**一步就到位**：任意 $\mathbf{u}_0$，$D\mathbf{u}_0=\begin{bmatrix}0.5\\0.5\end{bmatrix}$ 立刻。

Q3.（纯计算）求 $f(x)=\begin{cases}1, & 0<x<\pi\\ -1, & -\pi<x<0\end{cases}$（方波）在 $[-\pi,\pi]$ 上的傅里叶级数，并求级数在 $x=0$ 处的值。

▸ 答案

f 是**奇函数**，故 $a_0=0$，$a_k=0$（奇 × 偶仍为奇）。

$$b_k=\frac{1}{\pi}\int_{-\pi}^{\pi}f(x)\sin(kx)\,dx=\frac{1}{\pi}\left[\int_{-\pi}^{0}(-1)\sin kx\,dx+\int_{0}^{\pi}(+1)\sin kx\,dx\right].$$

由 $\sin kx$ 是奇函数，$\int_{-\pi}^{0}(-1)\sin kx\,dx=\int_{0}^{\pi}\sin kx\,dx$，两半相等，故

$$b_k=\frac{2}{\pi}\int_{0}^{\pi}\sin(kx)\,dx=\frac{2}{\pi}\left[-\frac{\cos kx}{k}\right]_0^{\pi}=\frac{2}{\pi}\cdot\frac{1-\cos(k\pi)}{k}=\frac{2\big(1-(-1)^k\big)}{\pi k}.$$

- k 偶：$1-(-1)^k=0\Rightarrow b_k=0$；
- k 奇：$1-(-1)^k=2\Rightarrow b_k=\frac{4}{\pi k}$。

$$\boxed{f(x)=\frac{4}{\pi}\left(\sin x+\frac{\sin 3x}{3}+\frac{\sin 5x}{5}+\cdots\right)=\frac{4}{\pi}\sum_{k\,\text{odd}}\frac{\sin kx}{k}}$$

在 $x=0$ 处：每个 $\sin(k\cdot0)=0$，级数为 0。而 f 在 0 处左极限 -1、右极限 $+1$，平均值 $\frac{-1+1}{2}=0$ —— **级数收敛到左右极限的平均值**，这正是常见误区 4 的实例。（顺便：取 $x=\pi/2$ 得 $\frac{4}{\pi}\left(1-\frac{1}{3}+\frac{1}{5}-\cdots\right)=1$，又是 Leibniz 级数 $\frac{\pi}{4}=1-\frac{1}{3}+\frac{1}{5}-\cdots$。）

数值核对：$x=\pi/2$ 处取前 10^4 个奇次项，部分和 $\to1$ ✓（慢收敛，符合 $O(1/N)$ 的截断误差）。

Q4.（概念）(a) 为什么"列和为 1"能保证 A 必定有特征值 $\mathbf{1}$，而 A^{T} 的特征向量 $\mathbf{1}$ 一般**不是** A 的特征向量？(b) 若马尔可夫矩阵 A 的 $\lambda=1$ 是**二重**特征值，$\mathbf{u}_k=A^k\mathbf{u}_0$ 还会收敛到唯一的稳态吗？(c) 为什么傅里叶部分和 S_N 是"最小二乘意义下最佳"的？

▸ 答案

(a) 列和为 1 等价于 $A^{\mathsf{T}}\mathbf{1}=\mathbf{1}$，即 $\mathbf{1}$ 是 A^{T} 的特征向量，特征值 1。而 $\det(M)=\det(M^{\mathsf{T}})$ 给出 $\det(A^{\mathsf{T}}-I)=\det(A-I)$，所以 $\det(A-I)=0$，1 也是 A 的特征值——但那个证明**只告诉我们 $\lambda=1$ 存在，没有告诉我们对应哪个向量**。A 的特征向量 $\mathbf{x}$ 满足 $(A-I)\mathbf{x}=\mathbf{0}$，需要另解。$A^{\mathsf{T}}\mathbf{1}=\mathbf{1}$ 翻译成元素形式是 $\sum_i a_{ij}=1$（列和），而 $A\mathbf{1}=\mathbf{1}$ 翻译成元素形式是 $\sum_j a_{ij}=1$（**行**和）。所以只有当行和也恰为 1（典型情形：A 对称）时，才有 $\mathbf{1}$ 同时是两者的特征向量。反例：演示一的 $A=\begin{bmatrix}0.8 & 0.3\\ 0.2 & 0.7\end{bmatrix}$ 行和为 1.1 和 0.9，$A\mathbf{1}=\begin{bmatrix}1.1\\ 0.9\end{bmatrix}\neq\mathbf{1}$ ✓。

(b) **不一定唯一**（但真正的马尔可夫矩阵**一定不会**发散——这一点值得说清楚）。先说不唯一：若 $\lambda=1$ 的**几何**重数 ≥ 2（有两个线性无关的稳态），则 $A^k\mathbf{u}_0$ 收敛到 $\mathbf{u}_0$ 在这两个稳态上的混合，结果**依赖初始条件**，没有唯一的极限分布。最简例子是 $A=\begin{bmatrix}1 & 0\\ 0 & 1\end{bmatrix}$：每个状态都是吸收态，$\mathbf{u}_k=\mathbf{u}_0$ 恒为初始分布，任何分布都是稳态。更一般地，只要矩阵**可约**（能分解成互不连通的封闭类），就可能不唯一。

再说不发散：对**马尔可夫矩阵**（元素非负、列和为 1），A^k 的每个元素始终落在 $[0,1]$ 内（因为 $\mathbf{u}_k$ 是概率分布、A^k 各列也是概率分布），有界，因此 **$\lambda=1$ 绝不可能对应非平凡的 Jordan 块**。若存在 Jordan 块 $J=\begin{bmatrix}1 & 1\\ 0 & 1\end{bmatrix}$，则 $J^k=\begin{bmatrix}1 & k\\ 0 & 1\end{bmatrix}$ 无界，与有界性矛盾。所以：**马尔可夫矩阵必定可对角化其 $\lambda=1$ 部分，$\mathbf{u}_k$ 必定收敛（只是可能不唯一）。** 对比之下，非马尔可夫矩阵确实可以发散：$A=\begin{bmatrix}1 & 1\\ 0 & 1\end{bmatrix}$ 不是马尔可夫（第 2 列和为 2），$A^k=\begin{bmatrix}1 & k\\ 0 & 1\end{bmatrix}\to$ 发散。

还有一个"收敛但不稳定"的第三种情形：**周期**矩阵，例如置换矩阵 $A=\begin{bmatrix}0 & 1\\ 1 & 0\end{bmatrix}$（是马尔可夫），特征值 $\lambda=\pm 1$，从 $\mathbf{u}_0=\begin{bmatrix}1\\ 0\end{bmatrix}$ 出发得到 $\begin{bmatrix}1\\ 0\end{bmatrix}\to\begin{bmatrix}0\\ 1\end{bmatrix}\to\begin{bmatrix}1\\ 0\end{bmatrix}\to\cdots$ **永远在两点之间振荡，不收敛**。这里模长 $=1$ 的特征值有两个（± 1），故 $\lambda=1$ 不是"唯一的不衰减方向"。

小结："不可约 + 非周期"这两个条件是**充分**的，它们排除的正是上两段的情形：不可约排除"多个封闭类 $\Rightarrow$ 稳态不唯一"，非周期排除"$\lambda=-1$ 型振荡"。满足这两条时 $\lambda=1$ 单重且其余严格 $|\lambda|<1$，$\mathbf{u}_k$ 收敛到**唯一**稳态。

(c) 取 $V_N=\operatorname{span}\{\sin x,\dots,\sin Nx\}$，任意 $g=\sum_{k=1}^{N}c_k\sin kx\in V_N$，

$$\|f-g\|^2=\langle f-g,f-g\rangle=\|f\|^2-2\sum_{k=1}^{N}c_k\langle f,\sin kx\rangle+\sum_{k=1}^{N}c_k^2\|\sin kx\|^2.$$

（交叉项 $\sum_{j\neq k}c_jc_k\langle\sin jx,\sin kx\rangle=0$ 因为基**正交**——这一步是关键。）对每个 c_k 求偏导：$\frac{\partial}{\partial c_k}=-2\langle f,\sin kx\rangle+2c_k\pi=0\Rightarrow c_k=\frac{\langle f,\sin kx\rangle}{\pi}=b_k$。又因为二阶导 $2\pi>0$，这是**全局最小值**（且各 c_k 解耦，互不影响）。所以 S_N 在 V_N 中唯一最优。这与讲次 15 的投影定理"误差 $\mathbf{e}=\mathbf{b}-A\hat{\mathbf{x}}$ 垂直于列空间 C(A)"逐字对应：这里 $f-S_N\perp\sin kx$ 对每个 $k\leq N$ 成立。

Lecture 25: Symmetric Matrices and Positive Definiteness

概述

本讲把特征值理论推进到课程中最重要的一类矩阵：**实对称矩阵** $S=S^{\mathsf{T}}$。我们将证明两件"礼物"：对称矩阵的**特征值全是实数**，且**不同特征值对应的特征向量相互正交**——于是它一定能被正交矩阵对角化：$A=Q\Lambda Q^{\mathsf{T}}$（**谱定理** spectral theorem），并可展开成 n 个**秩 1 投影矩阵**之和 $A=\lambda_1\mathbf{q}_1\mathbf{q}_1^{\mathsf{T}}+\cdots+\lambda_n\mathbf{q}_n\mathbf{q}_n^{\mathsf{T}}$。

进一步的礼物是：当所有 $\lambda_i>0$ 时，$\boldsymbol{x}^{\mathsf{T}}A\boldsymbol{x}>0$ 对一切 $\boldsymbol{x}\neq\mathbf{0}$ 成立，这就是**正定（positive definite）**。正定给出了四个互相等价的判据（特征值、顺序主子式、主元、$A=R^{\mathsf{T}}R$），它们是极小值问题、最小二乘、弹簧系统稳定性、协方差矩阵的共同语言。

本讲在课程中的位置：紧随讲次 21（特征值）、22（对角化）和 23（对称矩阵），是特征值一章的收官与高潮，并为讲次 27（正定与极小值）、讲次 28（Jordan 形）、讲次 29（SVD）铺路。

核心概念的几何直觉

概念 1：对称矩阵 = 无旋转的纯伸缩

- **定义与目的**：A 是对称矩阵，当且仅当 $A=A^{\mathsf{T}}$，即 $a_{ij}=a_{ji}$。它由 $\frac{n(n+1)}{2}$ 个独立数字决定（而不是 n^2 个），是"自由度最少"的一类方阵；对角矩阵是最简单的情形。
- **几何直觉（它在空间中是什么样子？）**：一般的 $n\times n$ 矩阵对应的线性变换会**旋转**空间（特征向量一般不垂直，甚至不够 n 个）。对称矩阵对应的变换是**无旋转的纯伸缩**：存在一组**互相垂直的坐标轴**（主轴），变换只是沿每条轴独立地拉伸或压缩，倍率就是特征值。若某个 λ_i 为负，就是沿该轴**翻转到反方向**。因此对称矩阵是"最好的一类矩阵"：它的作用可以被彻底理解，没有任何扭斜成分。
- **具体示例**：$A=\begin{bmatrix}2 & 1\\ 1 & 2\end{bmatrix}$。沿方向 $\mathbf{q}_1=\frac{1}{\sqrt{2}}\begin{bmatrix}1\\ 1\end{bmatrix}$，$A\mathbf{q}_1=3\mathbf{q}_1$（拉伸 3 倍）；沿垂直方向 $\mathbf{q}_2=\frac{1}{\sqrt{2}}\begin{bmatrix}1\\ -1\end{bmatrix}$，$A\mathbf{q}_2=1\mathbf{q}_2$（保持不变）。整个平面被这两条垂直的轴切成四块，每块都只是纯伸缩。

概念 2：谱定理（spectral theorem）——对称矩阵的正交对角化

- **定义与目的**：实对称矩阵一定可以写成

$$A = Q\Lambda Q^{\mathsf{T}}, \qquad Q^{\mathsf{T}}Q = I\ (Q^{-1} = Q^{\mathsf{T}}), \qquad \Lambda = \mathrm{diag}(\lambda_1, \dots, \lambda_n)\ \text{为实对角阵}.$$

对比讲次 22 的一般对角化 $A = S\Lambda S^{-1}$：那里 S 的列只是线性无关，这里 Q 的列是**正交的单位向量**，于是 S^{-1} 这个难算的东西直接变成了 Q^{T}。 – **几何直觉**：$A = Q\Lambda Q^{\mathsf{T}}$ 读作三步变换：Q^{T} 把标准坐标旋转到主轴坐标系（因为 $Q^{\mathsf{T}} = Q^{-1}$，它只是换基，不改变几何长度）；Λ 在各主轴上做伸缩；Q 再旋转回原坐标系。三个动作里两个是纯旋转，中间那个是纯伸缩——这正是"无旋转的纯伸缩"的严格表述。 – **具体示例**：$A = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix} = \frac{1}{\sqrt{2}}\begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}\begin{bmatrix} 3 & 0 \\ 0 & 1 \end{bmatrix}\frac{1}{\sqrt{2}}\begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}^{\mathsf{T}}$。注意 Q 是对称的（$Q = Q^{\mathsf{T}}$，它是一个反射），这只是巧合，不是普遍规律。

概念 3：秩 1 展开——对称矩阵是投影的加权和

- **定义与目的**：由 $A = Q\Lambda Q^{\mathsf{T}}$ 展开得

$$A = \lambda_1 \mathbf{q}_1\mathbf{q}_1^{\mathsf{T}} + \lambda_2 \mathbf{q}_2\mathbf{q}_2^{\mathsf{T}} + \cdots + \lambda_n \mathbf{q}_n\mathbf{q}_n^{\mathsf{T}}.$$

- **几何直觉**：每个 $\mathbf{q}_i\mathbf{q}_i^{\mathsf{T}}$ 是一个**投影矩阵**（呼应讲次 11、15）：$(\mathbf{q}_i\mathbf{q}_i^{\mathsf{T}})\mathbf{x} = \mathbf{q}_i(\mathbf{q}_i^{\mathsf{T}}\mathbf{x})$，把 $\mathbf{x}$ 投影到直线 $\mathbf{q}_i$ 上。所以对称矩阵的作用是：**把输入投影到 n 条互相垂直的主轴上，各自乘以 λ_i，再加起来**。这就是"各主轴方向上独立的伸缩之和"。
- **具体示例**：$\begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix} = 3\begin{bmatrix} 0.5 & 0.5 \\ 0.5 & 0.5 \end{bmatrix} + 1\begin{bmatrix} 0.5 & -0.5 \\ -0.5 & 0.5 \end{bmatrix} = \begin{bmatrix} 1.5 & 1.5 \\ 1.5 & 1.5 \end{bmatrix} + \begin{bmatrix} 0.5 & -0.5 \\ -0.5 & 0.5 \end{bmatrix} = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}$。（已用脚本验算。）

概念 4：正定（positive definite）——处处为正的二次型

- **定义与目的**：设 A 是**实对称矩阵**。称 A **正定**，若对所有 $\mathbf{x} \neq \mathbf{0}$ 都有

$$x^{\mathsf{T}}Ax > 0.$$

称 A **半正定**（positive semidefinite），若对所有 $\mathbf{x}$ 都有 $x^{\mathsf{T}}Ax \geq 0$（允许取等号，即允许奇异）。注意：**"正定"这个词只对称矩阵才用**（见常见误区 ①）。 – **几何直觉**：$x^{\mathsf{T}}Ax$ 是"能量函数"。用谱定理代入 $A = Q\Lambda Q^{\mathsf{T}}$，令 $\mathbf{y} = Q^{\mathsf{T}}\mathbf{x}$（纯旋转，$\|\mathbf{y}\| = \|\mathbf{x}\|$），则

$$x^{\mathsf{T}}Ax = \mathbf{y}^{\mathsf{T}}\Lambda\mathbf{y} = \lambda_1 y_1^2 + \lambda_2 y_2^2 + \cdots + \lambda_n y_n^2.$$

这是一个**没有交叉项的平方和**！于是"对所有 $\mathbf{x} \neq \mathbf{0}$ 为正"立刻等价于"所有 $\lambda_i > 0$"——这是四个判据中最根本的一条。几何上，正定意味着这个能量面是一个向上开口的**碗**（唯一的极小点在原点）。 – **具体示例**：$A = \begin{bmatrix} 2 & -1 \\ -1 & 2 \end{bmatrix}$：取 $\mathbf{x} = (1, 1)$，$x^{\mathsf{T}}Ax = 2 - 2 + 2 = 2 > 0$；取 $\mathbf{x} = (1, -1)$，$x^{\mathsf{T}}Ax = 2 + 2 + 2 = 6 > 0$。（已验算。）这两个方向就是特征向量方向，恰好给出 $x^{\mathsf{T}}Ax$ 的最小与最大值（乘以 2）。而 $A = \begin{bmatrix} 1 & 3 \\ 3 & 1 \end{bmatrix}$ 取 $\mathbf{x} = (1, -1)$ 得 $x^{\mathsf{T}}Ax = 1 - 6 + 1 = -4 < 0$，故**不**正定。

概念 5：椭球图景——$x^{\mathsf{T}}Ax = 1$ 的形状

- **定义与目的**：把正定二次型取等值面 $x^{\mathsf{T}}Ax = 1$，得到中心在原点的**椭球**（二维是椭圆）。沿特征向量方向 $\mathbf{q}_i$，$x^{\mathsf{T}}Ax = \lambda_i t^2 = 1$，故该半轴长为

$$a_i = \frac{1}{\sqrt{\lambda_i}}.$$

特征值**越大，对应轴越短**（因为要把 x 拉得更小才能让二次型等于 1）。 – **几何直觉**：主轴方向 = 特征向量方向；特征值正负决定它是封闭的椭球（全正）、双曲面（有正有负）、还是退化的柱面（有零特征值，某个方向完全平坦）。 – **具体示例**：$A = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}$，$\lambda = 3, 1$，半轴长 $1/\sqrt{3} \approx 0.577$（沿 $\mathbf{q}_1$）与 1（沿 $\mathbf{q}_2$）。脚本验算：$\theta = 0^\circ$ 时边界点 $(0.7071, 0)$（长度 0.7071）；$\theta = 45^\circ$ 时 $(0.4082, 0.4082)$（长度 0.5774，正是最短的 $1/\sqrt{3}$）；$\theta = 90^\circ$ 时 $(0, 0.7071)$。$\theta = 45^\circ$ 最短、$\theta = 0^\circ, 90^\circ$ 最长，与"椭圆斜着放"的图像一致。

```
x^T A x = 1,  A = [[2,1],[1,2]]  的椭圆（脚本算出的真实边界点）

     x2
      ^
 0.71 +- - - - - - -●(0, 0.7071)          ← 半轴长 1 沿 q2 = (1,-1)/√2
      |          ,-''-,
      |        ,'      `.
 0.50 +       /    .     \               ● (0.2953, 0.5116)  θ=60°
      |      |   q1 \     |
      |      |  ↖   \     |
      |     |    \   \     |             q1 = (1,1)/√2  沿此方向长 1/√3 ≈ 0.577
      |     |     \   \    |
------+-----+------●----\---+-----> x1   ● (0.4082, 0.4082)  θ=45°  ← 最短!
      |     |  (0.577)|    |                (这就是 λ=3 的主轴方向)
      |     |        \     |             ● (0.5116, 0.2953)  θ=30°
      |      |        \    |
      |       \        \  /
      |        `-.____,-'`
-0.71 +- - - - - - - - - - - - - - - -  ● (0.7071, 0)  θ=0°  长 0.7071

口诀：λ 大的方向，轴短（1/√λ）；λ = 3 的 q1 方向半轴 0.577 < λ = 1 的 q2 方向半轴 1
```

```
x^T A x = 1 的等值线对比（A 对称，2x2）

(a) A 正定: lam1,lam2 > 0        (b) A 不定: lam1 > 0 > lam2
    ==> 椭圆（封闭）                 ==> 双曲线（开放，两支）

     \        |        /              \         |         /
      \       |       /                \        |        /
       \______|______/                  \_______|_______/
      /       |      \                  /       |       \
     /        |       \                /        |        \
    /         |        \              /         |         \
                                      ----------------------  <- 渐近线(45度)
主轴 = 特征向量方向 q1, q2            过原点有 4 个"分支"，无界
半轴长 = 1/sqrt(lam_i)                 x^T A x = 0 给出两条渐近线方向

(c) A 半正定但奇异: lam1 > 0, lam2 = 0
    ==> 退化为"柱面"：沿 q2 方向完全平坦
    x^T A x = 1 其实是两条平行直线（无限延伸，无界）

                |         |
    ------------+---------+-------------   <- 两条平行线
                |         |
    沿 q2 方向 x^T A x 恒不变：能量有"零代价"方向
```

概念 6：两大定理及其证明思路（本讲的理论核心）

定理 1（实特征值）：设 $\boldsymbol{A}$ 是**实对称矩阵**，$\boldsymbol{\lambda}$ 是它的任一特征值（允许是复数），则 $\boldsymbol{\lambda}$ 必为**实数**。

证明思路（四步，务必记住"$x^{\mathsf{T}}Ax$ 是实数"这个关键）：设 $A\mathbf{x}=\lambda\mathbf{x}$，$\mathbf{x}\neq\mathbf{0}$，允许 $\mathbf{x}$ 与 λ 是复数。记 $\bar{\mathbf{x}}^{\mathsf{T}}$ 为 $\mathbf{x}$ 的**共轭转置**（即 $\bar{\mathbf{x}}^{\mathsf{T}}=\overline{\mathbf{x}^{\mathsf{T}}}$）。

- **第一步**：两边左乘 $\bar{\mathbf{x}}^{\mathsf{T}}$：

$$\bar{\mathbf{x}}^{\mathsf{T}}A\mathbf{x}=\lambda\bar{\mathbf{x}}^{\mathsf{T}}\mathbf{x}=\lambda\|\mathbf{x}\|^2.$$

这里 $\bar{\mathbf{x}}^{\mathsf{T}}\mathbf{x}=|x_1|^2+\cdots+|x_n|^2=\|\mathbf{x}\|^2>0$ 是**正实数**。 – **第二步**：对这个数取共轭。因为 A 是**实**对称矩阵（$\bar{A}=A$，$A^{\mathsf{T}}=A$），有

$$\overline{\bar{\mathbf{x}}^{\mathsf{T}}A\mathbf{x}}=\mathbf{x}^{\mathsf{T}}\bar{A}\bar{\mathbf{x}}=\mathbf{x}^{\mathsf{T}}A\bar{\mathbf{x}}=(\bar{\mathbf{x}}^{\mathsf{T}}A^{\mathsf{T}}\mathbf{x})^{\mathsf{T}}=\bar{\mathbf{x}}^{\mathsf{T}}A\mathbf{x}.$$

最后一步用到 $\bar{\mathbf{x}}^{\mathsf{T}}A\mathbf{x}$ 是一个**标量**（1×1），转置不变。所以

$$\boxed{\bar{\mathbf{x}}^{\mathsf{T}}A\mathbf{x}\text{ 是实数}}$$

这是整个证明的**枢纽**：它把"取共轭"这条通道打通了。 – **第三步**：对第一步的等式两边取共轭，左边是实数，右边得 $\bar{\lambda}\|\mathbf{x}\|^2$：

$$\bar{\mathbf{x}}^{\mathsf{T}}A\mathbf{x}=\bar{\lambda}\|\mathbf{x}\|^2.$$

- **第四步**：与第一步相减：$(\lambda-\bar{\lambda})\|\mathbf{x}\|^2=0$。因 $\|\mathbf{x}\|^2>0$，得 $\lambda=\bar{\lambda}$，即 λ 是**实数**。■

- **几何直觉**：一般实矩阵的特征值可以成对出现为共轭复数 $a \pm bi$，对应的运动是**旋转 + 伸缩**（如旋转矩阵 $\begin{bmatrix}0 & -1\\ 1 & 0\end{bmatrix}$ 的 $\lambda = \pm i$，纯旋转）。定理 1 说：对称矩阵里**不允许有旋转成分**，所以描述"螺旋"的复数特征值没有存在的余地。
- **具体示例**：$A = \begin{bmatrix}2 & 1\\ 1 & 2\end{bmatrix}$ 得 $\lambda = 3, 1$（实数）✓；若把它改成 $B = \begin{bmatrix}0 & -1\\ 1 & 0\end{bmatrix}$（反称，不是对称），则 $\det(B - \lambda I) = \lambda^2 + 1 = 0$，$\lambda = \pm i$ ——**对称性一旦破坏，实特征值立刻消失**。

定理 2（不同特征值的特征向量正交）：设 $A = A^{\mathsf{T}}$，$A\mathbf{x}_1 = \lambda_1 \mathbf{x}_1$，$A\mathbf{x}_2 = \lambda_2 \mathbf{x}_2$，且 $\lambda_1 \neq \lambda_2$，则 $\mathbf{x}_1^{\mathsf{T}} \mathbf{x}_2 = 0$。

证明（短而漂亮，用"两种方式算同一个数"）：

$$\lambda_1 \mathbf{x}_1^{\mathsf{T}} \mathbf{x}_2 = (A\mathbf{x}_1)^{\mathsf{T}} \mathbf{x}_2 = \mathbf{x}_1^{\mathsf{T}} A^{\mathsf{T}} \mathbf{x}_2 \overset{A^{\mathsf{T}} = A}{=} \mathbf{x}_1^{\mathsf{T}} A \mathbf{x}_2 = \mathbf{x}_1^{\mathsf{T}} (\lambda_2 \mathbf{x}_2) = \lambda_2 \mathbf{x}_1^{\mathsf{T}} \mathbf{x}_2.$$

移项得 $(\lambda_1 - \lambda_2)\mathbf{x}_1^{\mathsf{T}} \mathbf{x}_2 = 0$。因 $\lambda_1 \neq \lambda_2$，必有 $\mathbf{x}_1^{\mathsf{T}} \mathbf{x}_2 = 0$，即两特征向量正交。■

- **几何直觉**：两个特征向量各自"只被拉伸、方向不变"，若它们不垂直，就会互相"渗漏"，那就有了旋转成分——与定理 1 的精神一致。
- **具体示例**：示例 1 中 $\mathbf{x}_1 = (1, 1)$，$\mathbf{x}_2 = (1, -1)$，$\mathbf{x}_1^{\mathsf{T}} \mathbf{x}_2 = 0$ ✓。而**非**对称的 $B = \begin{bmatrix}1 & 1\\ 0 & 2\end{bmatrix}$ 特征向量为 $(1, 0)$ 与 $(1, 1)$，内积 $= 1 \neq 0$，并不正交——这是对称性独有的特权。

定理 3（谱定理，不加证明但说明机制）：实对称矩阵**一定可以正交对角化**：$A = Q\Lambda Q^{\mathsf{T}}$，$\Lambda$ 为实对角阵，Q 为正交矩阵。

- **重根情形怎么处理**：定理 2 只覆盖 $\lambda_i \neq \lambda_j$ 的情形。若某个 λ 是 k 重根，由对称矩阵的"永不缺陷"性质（讲次 28），方程 $(A - \lambda I)\mathbf{x} = \mathbf{0}$ 的解空间是 k 维的；在这个 k 维子空间**内部**可以用 Gram–Schmidt（讲次 17）任选一组正交基。加上定理 2 保证这个子空间与其它特征空间正交，合起来仍是 n 个互相正交的单位特征向量。■
- **具体示例（重根）**：$A = \begin{bmatrix}2 & 0 & 0\\ 0 & 3 & 0\\ 0 & 0 & 3\end{bmatrix}$ 的 $\lambda = 3$ 是二重根，特征空间是 $x_1 = 0$ 的整个平面，其中可任取正交单位向量 $\mathbf{e}_2, \mathbf{e}_3$；配上前面的 $\mathbf{e}_1$ 共得 $Q = I$，$A = I\Lambda I^{\mathsf{T}}$。更不平凡的例：$A = \begin{bmatrix}3 & 0 & 0\\ 0 & 3 & 0\\ 0 & 0 & 1\end{bmatrix}$ 的 $\lambda = 3$ 二重，取 $\mathbf{q}_1 = \frac{1}{\sqrt{2}}(1, 1, 0)$、$\mathbf{q}_2 = \frac{1}{\sqrt{2}}(1, -1, 0)$ 也对——重根的特征空间里"任何正交基都可以"。

计算步骤与手算演示

以下 6 个示例构成一条完整的"计算流水线"：示例 1 走通正交对角化与秩 1 展开的全流程；示例 2 展示对称矩阵可以有负特征值；示例 3 在 3×3 三对角矩阵上把"特征向量 + 重根情形"算穿；示例 4–5 把正定的四条判据与配方法打通；示例 6 给出不定与半正定的反例对照。

示例 1（必做）：$A = \begin{bmatrix}2 & 1\\ 1 & 2\end{bmatrix}$ 的完全正交对角化

步骤 1：确认对称。 $a_{12} = a_{21} = 1$，故 $A = A^{\mathsf{T}}$ ✓。

步骤 2：求特征值。 $\det(A - \lambda I) = (2 - \lambda)^2 - 1 = \lambda^2 - 4\lambda + 3 = (\lambda - 3)(\lambda - 1) = 0$，得

$$\lambda_1 = 3, \qquad \lambda_2 = 1.$$

校验：$\lambda_1 + \lambda_2 = 4 = \operatorname{tr} A$ ✓；$\lambda_1 \lambda_2 = 3 = \det A = 4 - 1$ ✓。两者都为正 $\Rightarrow$ A **正定**。

步骤 3：求特征向量。 对 $\lambda_1 = 3$：$(A - 3I)\mathbf{x} = \begin{bmatrix}-1 & 1\\ 1 & -1\end{bmatrix}\mathbf{x} = \mathbf{0}$，取 $\mathbf{x}_1 = \begin{bmatrix}1\\ 1\end{bmatrix}$。对 $\lambda_2 = 1$：$(A - I)\mathbf{x} = \begin{bmatrix}1 & 1\\ 1 & 1\end{bmatrix}\mathbf{x} = \mathbf{0}$，取 $\mathbf{x}_2 = \begin{bmatrix}1\\ -1\end{bmatrix}$。

步骤 4：验证正交并归一化。 $\mathbf{x}_1^{\mathsf{T}} \mathbf{x}_2 = 1 \cdot 1 + 1 \cdot (-1) = 0$ ✓（这是定理 2 的必然结果，不是巧合）。归一化：

$$\mathbf{q}_1 = \frac{1}{\sqrt{2}}\begin{bmatrix}1\\ 1\end{bmatrix}, \qquad \mathbf{q}_2 = \frac{1}{\sqrt{2}}\begin{bmatrix}1\\ -1\end{bmatrix}.$$

步骤 5：组装 Q 与 Λ。

$$Q = \frac{1}{\sqrt{2}}\begin{bmatrix}1 & 1\\ 1 & -1\end{bmatrix}, \qquad \Lambda = \begin{bmatrix}3 & 0\\ 0 & 1\end{bmatrix}.$$

脚本验算 $Q^{\mathsf{T}} Q = \begin{bmatrix}1 & 0\\ 0 & 1\end{bmatrix}$ ✓（数值误差 0）。

步骤 6：验证 $Q\Lambda Q^{\mathsf{T}} = A$。 脚本验算得 $Q\Lambda Q^{\mathsf{T}} = \begin{bmatrix}2.0000 & 1.0000\\ 1.0000 & 2.0000\end{bmatrix} = A$ ✓。

步骤 7：秩 1 分解。

$$A = 3\mathbf{q}_1\mathbf{q}_1^{\mathsf{T}} + 1\mathbf{q}_2\mathbf{q}_2^{\mathsf{T}} = 3\begin{bmatrix}0.5 & 0.5\\ 0.5 & 0.5\end{bmatrix} + \begin{bmatrix}0.5 & -0.5\\ -0.5 & 0.5\end{bmatrix} = \begin{bmatrix}2 & 1\\ 1 & 2\end{bmatrix}.$$

脚本验算 $3\mathbf{q}_1\mathbf{q}_1^{\mathsf{T}} = \begin{bmatrix}1.5 & 1.5\\ 1.5 & 1.5\end{bmatrix}$，$1\mathbf{q}_2\mathbf{q}_2^{\mathsf{T}} = \begin{bmatrix}0.5 & -0.5\\ -0.5 & 0.5\end{bmatrix}$，两者之和恰为 A ✓。

【计算机制解说】：为什么对称矩阵的特征向量一定正交，从而 Q 一定满足 $Q^{-1} = Q^{\mathsf{T}}$？关键在定理 2 的推导：$\lambda_1\mathbf{x}_1^{\mathsf{T}}\mathbf{x}_2 = (A\mathbf{x}_1)^{\mathsf{T}}\mathbf{x}_2 = \mathbf{x}_1^{\mathsf{T}}A^{\mathsf{T}}\mathbf{x}_2 = \mathbf{x}_1^{\mathsf{T}}A\mathbf{x}_2 = \lambda_2\mathbf{x}_1^{\mathsf{T}}\mathbf{x}_2$。整个链条里**唯一用到对称性的地方是 $A^{\mathsf{T}} = A$**（把 A^{T} 换成 A）。若 A 不对称，第三步就断了，特征向量可以任意歪斜，S^{-1} 也就躲不掉。这也解释了为什么"对称"这个看起来只是"少一半自由度"的造型条件，能换来"正交基 + 实特征值"这么大的收益：它让矩阵在主轴坐标系里变成对角阵，而**对角阵就是纯伸缩**。

示例 2：$A = \begin{bmatrix}1 & 2\\ 2 & 1\end{bmatrix}$——对称矩阵可以有负特征值

步骤 1：特征值。 $\det(A-\lambda I) = (1-\lambda)^2 - 4 = \lambda^2 - 2\lambda - 3 = (\lambda-3)(\lambda+1)$，得

$$\lambda_1 = 3, \qquad \lambda_2 = -1.$$

校验：和 $= 2 = \operatorname{tr}A$ ✓；积 $= -3 = \det A = 1 - 4$ ✓。脚本验算得 $\{3, -1\}$ ✓。

步骤 2：特征向量。 对 $\lambda = 3$：$\begin{bmatrix}-2 & 2\\ 2 & -2\end{bmatrix}\mathbf{x} = \mathbf{0} \Rightarrow \mathbf{q}_1 = \frac{1}{\sqrt{2}}\begin{bmatrix}1\\1\end{bmatrix}$。对 $\lambda = -1$：$\begin{bmatrix}2 & 2\\ 2 & 2\end{bmatrix}\mathbf{x} = \mathbf{0} \Rightarrow \mathbf{q}_2 = \frac{1}{\sqrt{2}}\begin{bmatrix}1\\-1\end{bmatrix}$。

步骤 3：正交对角化。

$$A = \frac{1}{\sqrt{2}}\begin{bmatrix}1 & 1\\ 1 & -1\end{bmatrix}\begin{bmatrix}3 & 0\\ 0 & -1\end{bmatrix}\frac{1}{\sqrt{2}}\begin{bmatrix}1 & 1\\ 1 & -1\end{bmatrix}^{\mathsf{T}}.$$

注意两个例子的 $\mathbf{q}_1, \mathbf{q}_2$ 完全相同（因为两组矩阵的非对角元都是 $+1$，特征向量只取决于 A 本身而非某个特征值），变的是特征值 Λ。

步骤 4：判定。 有一个负特征值 $\lambda_2 = -1 < 0$，故 A **不是正定**，是**不定（indefinite）**。具体地，取 $\mathbf{x} = \mathbf{q}_2 = \frac{1}{\sqrt{2}}(1, -1)$，$x^{\mathsf{T}}Ax = \lambda_2\|\mathbf{x}\|^2 = -1 < 0$。反面教材的重要性：**对称 $\neq$ 正定**。对称只保证"实特征值 + 正交主轴"，正定还要额外要求所有特征值为正。

【计算机制解说】：由 $x^{\mathsf{T}}Ax = \sum_i \lambda_i y_i^2$（$\mathbf{y} = Q^{\mathsf{T}}\mathbf{x}$）可见，$x^{\mathsf{T}}Ax$ 的取值范围就是"各 λ_i 的加权平方和"。因此 $x^{\mathsf{T}}Ax$ 的最小值（在 $\|\mathbf{x}\| = 1$ 上）是 $\lambda_{\min}$，最大值是 $\lambda_{\max}$，且分别在 $\mathbf{x} = \mathbf{q}_{\min}$、$\mathbf{q}_{\max}$ 处取到。这就是"瑞利商（Rayleigh quotient）"的核心结论：$\frac{x^{\mathsf{T}}Ax}{x^{\mathsf{T}}x}$ 的极值就是特征值。对示例 1，$x^{\mathsf{T}}Ax$ 在单位圆上的范围是 $[1, 3]$；对示例 2 是 $[-1, 3]$——**范围跨过 0，就是"不定"的判据**。

示例 3（必做）：三对角矩阵 $A = \begin{bmatrix}2 & -1 & 0\\ -1 & 2 & -1\\ 0 & -1 & 2\end{bmatrix}$

这个矩阵在讲次 11、26 反复出现（它是一维弹簧链 / 一维拉普拉斯算子的刚度矩阵）。

步骤 1：特征值。 展开 $\det(A - \lambda I)$：

$$\det\begin{bmatrix}2-\lambda & -1 & 0\\ -1 & 2-\lambda & -1\\ 0 & -1 & 2-\lambda\end{bmatrix} = (2-\lambda)\big[(2-\lambda)^2 - 1\big] - (-1)\big[(-1)(2-\lambda) - 0\big].$$

化简令 $t = 2 - \lambda$：$t(t^2-1) - t = t^3 - 2t = t(t^2-2) = 0$，故 $t = 0, \pm\sqrt{2}$，即

$$\lambda = 2 - \sqrt{2} \approx 0.585786, \qquad \lambda = 2, \qquad \lambda = 2 + \sqrt{2} \approx 3.414214.$$

脚本验算：$2 - \sqrt{2} = 0.5857864376$，$2 + \sqrt{2} = 3.4142135624$ ✓。校验：$\operatorname{tr}A = 6 = 0.585786 + 2 + 3.414214$ ✓；$\det A = 4 = (2-\sqrt{2}) \cdot 2 \cdot (2+\sqrt{2}) = 2(4-2) = 4$ ✓。**三个特征值全为正 ⟹ 该矩阵正定。**

步骤 2：特征向量。 对 $(A - \lambda I)\mathbf{v} = \mathbf{0}$，写出三行：

$$\begin{aligned}
&\text{第 } 1 \text{ 行:} \quad (2-\lambda)v_1 - v_2 = 0 && \Longrightarrow\ v_2 = (2-\lambda)v_1,\\
&\text{第 } 2 \text{ 行:} \quad -v_1 + (2-\lambda)v_2 - v_3 = 0, &&\\
&\text{第 } 3 \text{ 行:} \quad -v_2 + (2-\lambda)v_3 = 0 && \Longrightarrow\ v_2 = (2-\lambda)v_3.
\end{aligned}$$

第 1、3 行联立给出 $(2-\lambda)(v_1 - v_3) = 0$。**必须分两种情形讨论**——这里正是容易出错的地方：

- **情形 A：$\lambda \neq 2$**（即 $\lambda = 2 \mp \sqrt{2}$）。此时 $2 - \lambda \neq 0$，故 $v_3 = v_1$，再由 $v_2 = (2-\lambda)v_1$。取 $v_1 = 1$：

$$\mathbf{v}_1 = \begin{bmatrix}1\\ \sqrt{2}\\ 1\end{bmatrix}\ (\lambda = 2 - \sqrt{2}), \qquad \mathbf{v}_3 = \begin{bmatrix}1\\ -\sqrt{2}\\ 1\end{bmatrix}\ (\lambda = 2 + \sqrt{2}).$$

- **情形 B：$\lambda = 2$**。此时第 1 行变成 $-v_2 = 0$，即 $v_2 = 0$；第 2 行变成 $-v_1 - v_3 = 0$，即 $v_3 = -v_1$。取 $v_1 = 1$：

$$\mathbf{v}_2 = \begin{bmatrix}1\\ 0\\ -1\end{bmatrix}\ (\lambda = 2).$$

注意不能沿用情形 A 的 "$v_3 = v_1$"，因为那个结论来自 $(2-\lambda)(v_1 - v_3) = 0$ 中除以 $2 - \lambda$，而 $\lambda = 2$ 时这个因子为零。

步骤 3：逐项验算 $A\mathbf{v}_i=\lambda_i\mathbf{v}_i$。 – $\lambda_1=2-\sqrt{2}$，$\mathbf{v}_1=(1,\sqrt{2},1)$：
$A\mathbf{v}_1=(2-\sqrt{2},\ 2\sqrt{2}-2,\ 2-\sqrt{2})=(0.5857864,0.8284271,0.5857864)$，而 $\lambda_1\mathbf{v}_1=(0.5857864)(1,\sqrt{2},1)$ 完全相同 ✓（脚本验算一致）。 – $\lambda_2=2$，$\mathbf{v}_2=(1,0,-1)$：$A\mathbf{v}_2=(2\cdot1-0+0,\ -1+0+1,\ 0-0-2)=(2,0,-2)^{\mathsf T}=2\mathbf{v}_2$ ✓（脚本验算一致）。 – $\lambda_3=2+\sqrt{2}$，$\mathbf{v}_3=(1,-\sqrt{2},1)$：$A\mathbf{v}_3=(2+\sqrt{2},\ -2\sqrt{2}-2,\ 2+\sqrt{2})=(3.4142136,-4.8284271,3.4142136)$，与 $\lambda_3\mathbf{v}_3$ 一致 ✓。

步骤 4：归一化并组装 Q。 $\|\mathbf{v}_1\|^2=1+2+1=4\Rightarrow\|\mathbf{v}_1\|=2$；$\|\mathbf{v}_2\|^2=1+0+1=2\Rightarrow\|\mathbf{v}_2\|=\sqrt{2}$；$\|\mathbf{v}_3\|^2=4\Rightarrow\|\mathbf{v}_3\|=2$。故

$$\mathbf{q}_1=\frac{1}{2}\begin{bmatrix}1\\\sqrt{2}\\1\end{bmatrix},\qquad \mathbf{q}_2=\frac{1}{\sqrt{2}}\begin{bmatrix}1\\0\\-1\end{bmatrix},\qquad \mathbf{q}_3=\frac{1}{2}\begin{bmatrix}1\\-\sqrt{2}\\1\end{bmatrix}.$$

脚本验算三组内积：$\mathbf{q}_1^{\mathsf T}\mathbf{q}_2=0$，$\mathbf{q}_1^{\mathsf T}\mathbf{q}_3=0$，$\mathbf{q}_2^{\mathsf T}\mathbf{q}_3=0$ ✓；$Q^{\mathsf T}Q=I$ ✓；$Q\Lambda Q^{\mathsf T}=A$ ✓（全部精确到 10^{-9}）。

步骤 5：秩 1 展开验算。 脚本计算 $\sum_i\lambda_i\mathbf{q}_i\mathbf{q}_i^{\mathsf T}$ 得

$$\begin{bmatrix}2.000000 & -1.000000 & 0.000000\\ -1.000000 & 2.000000 & -1.000000\\ 0.000000 & -1.000000 & 2.000000\end{bmatrix}=A\quad\checkmark$$

步骤 6：正定性结论。 特征值 $0.585786,\ 2,\ 3.414214$ 全为正 $\Rightarrow$ A **正定**。顺序主子式 $D_1=2,\ D_2=2\cdot2-1=3,\ D_3=\det A=4$（脚本验算：$2,3,4$），全正 ✓；主元 $d_1=2$，$d_2=2-\frac{1}{2}=\frac{3}{2}$，$d_3=2-\frac{1}{3/2}=2-\frac{2}{3}=\frac{4}{3}$（脚本验算：$2,1.5,1.333333$），全正 ✓。三套判据完全一致，且 $d_1d_2d_3=2\cdot\frac{3}{2}\cdot\frac{4}{3}=4=D_3$ ✓。

【计算机制解说】：三对角矩阵的特征值 $\lambda_k=2-2\cos\frac{k\pi}{4}$（$k=1,2,3$）给出 $2-\sqrt{2},\ 2,\ 2+\sqrt{2}$——这是讲次 26 中"弹簧–质点系统"的一般公式。为什么鼓励用三对角矩阵做例子？因为它的特征向量具有正弦波的形状（$\sin\frac{k\pi}{4}$ 的采样），物理上对应弹簧链的**振动模态**：λ 小 = 低频慢振动（整体同向摆动），λ 大 = 高频快振动（相邻质量反向）。**特征值全为正，物理含义就是"弹簧刚度矩阵正定 = 系统稳定、有唯一平衡位置"**。这也是正定性最直观的应用场景。

正定的四个等价判据与手算演示

严格陈述（A 为**实对称**矩阵，以下五条**互相等价**，可任选一条判正定）：

$$\boxed{\forall\mathbf{x}\neq\mathbf{0}:\ x^{\mathsf T}Ax>0\iff①\ \lambda_i>0\,\forall i\iff②\ D_1,\dots,D_n>0\iff③\ d_1,\dots,d_n>0\iff④\ A=R^{\mathsf T}R,\ R\text{ 列满秩}}$$

其中 D_k 是**顺序主子式（leading principal minors）**——左上角 $k\times k$ 子块的行列式；d_k 是消元后的**主元（pivots）**。**它们为什么等价？** 链条是这样的：$x^{\mathsf T}Ax=\sum_i\lambda_iy_i^2$（$\mathbf{y}=Q^{\mathsf T}\mathbf{x}$，$\|\mathbf{y}\|=\|\mathbf{x}\|$）直接给出 ①；配方法 $x^{\mathsf T}Ax=\sum_i d_i(\text{配方项})^2$ 直接给出 ③，而配方每一项的系数都是正 $\Leftrightarrow$ 所有主元正；行列式的乘法法则给出 $D_k=d_1d_2\cdots d_k$，故 D_k 全正 $\Leftrightarrow$ d_k 全正，即 ②；$A=R^{\mathsf T}R$ 且 R 列满秩时，$x^{\mathsf T}Ax=\|R\mathbf{x}\|^2>0$（$R\mathbf{x}=\mathbf{0}$ 只有零解），反向则通过 Cholesky 分解 $A=R^{\mathsf T}R$ 与 $d_k>0$ 互相推出，即 ④。

四条判据的实用场景不同——这是 Strang 反复强调的"工具箱"意识：

判据	适合场合	代价 / 优点
① 特征值 $\lambda_i>0$	**理论推导**、几何解释（椭球、瑞利商）	需要求全部特征值，数值代价 $O(n^3)$，但概念最清楚
② 顺序主子式 $D_k>0$	**手算小矩阵**、竞赛与考试	n 个行列式，n 稍大就爆炸（$O(n!)$ 如果硬展开）
③ 主元 $d_k>0$	**数值计算**、实际程序（Gaussian 消元）	只需一次消元 $O(n^3/3)$，最便宜，且**不需要算特征值或行列式**；不换行本身也自动被验证
④ $A=R^{\mathsf T}R$（R 列满秩）	**分解 / 最小二乘 / 优化**	给出可用的"平方根"，让 $\|R\mathbf{x}\|^2$ 替代 $x^{\mathsf T}Ax$，是 Cholesky 与 QR 的桥梁

示例 4（必做）：$A=\begin{bmatrix}2&6\\6&20\end{bmatrix}$——四条判据全部走一遍

判据 ①（特征值）：$\operatorname{tr}A=22$，$\det A=2\cdot20-6^2=40-36=4$。特征方程 $\lambda^2-22\lambda+4=0$，判别式 $22^2-4\cdot4=484-16=468=4\cdot117$，故

$$\lambda=\frac{22\pm\sqrt{468}}{2}=11\pm\sqrt{117}\approx11\pm10.816654=21.816654\text{ 与 }0.183346.$$

脚本验算得 21.8166538 与 0.1833462 ✓。两者均为正 $\Rightarrow$ **正定**。校验：和 $=22=\operatorname{tr}A$ ✓，积 $=121-117=4=\det A$ ✓。

判据 ②（顺序主子式）：$D_1=2>0$ ✓；$D_2=\det A=4>0$ ✓ $\Rightarrow$ **正定**（脚本验算：$2,4$）。

判据 ③（主元）：消元第一步用 2 消去 $a_{21}=6$，乘数 $\ell=6/2=3$：

$$\begin{bmatrix}2&6\\6&20\end{bmatrix}\longrightarrow\begin{bmatrix}2&6\\0&20-3\cdot6\end{bmatrix}=\begin{bmatrix}2&6\\0&2\end{bmatrix}.$$

主元 $d_1=2$，$d_2=2$，均为正 ✓。校验 $d_1d_2=4=D_2=\det A$ ✓（脚本验算：主元 $2,2$）。

判据 ④（$A = R^{\mathsf{T}}R$）：设 $R = \begin{bmatrix} r_{11} & r_{12} \\ 0 & r_{22} \end{bmatrix}$（对角元取正）。由 $R^{\mathsf{T}}R = \begin{bmatrix} r_{11}^2 & r_{11}r_{12} \\ r_{11}r_{12} & r_{12}^2 + r_{22}^2 \end{bmatrix}$ 逐项比对：$-\ r_{11}^2 = 2 \Rightarrow r_{11} = \sqrt{2}$；$-\ r_{11}r_{12} = 6 \Rightarrow r_{12} = 6/\sqrt{2} = 3\sqrt{2}$；$-\ r_{12}^2 + r_{22}^2 = 20 \Rightarrow r_{22}^2 = 20 - 18 = 2 \Rightarrow r_{22} = \sqrt{2}$。

故

$$R = \begin{bmatrix} \sqrt{2} & 3\sqrt{2} \\ 0 & \sqrt{2} \end{bmatrix}, \qquad R^{\mathsf{T}}R = \begin{bmatrix} 2 & 6 \\ 6 & 18+2 \end{bmatrix} = \begin{bmatrix} 2 & 6 \\ 6 & 20 \end{bmatrix} = A \checkmark$$

（脚本验算 $R^{\mathsf{T}}R$ 精确得到 A。）注意 $r_{11}^2 = d_1 = 2$，$r_{22}^2 = d_2 = 2$——**R 的对角元就是主元的平方根**。

【计算机制解说】：为什么四条判据本质上"是同一件事"？看配方法：

$$x^{\mathsf{T}}Ax = 2x_1^2 + 12x_1x_2 + 20x_2^2 = 2(x_1 + 3x_2)^2 + 2x_2^2.$$

（检查：$2x_1^2 + 12x_1x_2 + 18x_2^2 + 2x_2^2 = 2x_1^2 + 12x_1x_2 + 20x_2^2$ ✓。注意交叉项系数 $12 = 2a_{12}$，别忘那个 2！）配方项 $(x_1 + 3x_2)$ 里的系数 3 **正是消元的乘数 $\ell = 3$**，两个平方项系数 2 与 2 **正是两个主元 d_1, d_2**。所以"消元、配方、顺序主子式、特征值符号"是同一个数学事实的四种表现：**$x^{\mathsf{T}}Ax$ 可以写成"正系数 × 独立线性型的平方"之当且仅当所有主元正**。更精确地，

$$x^{\mathsf{T}}Ax = d_1(\text{第 1 个配方})^2 + d_2(\text{第 2 个配方})^2 + \cdots + d_n(\text{第 } n \text{ 个配方})^2,$$

而完整的消元给出 $A = LDL^{\mathsf{T}}$（讲次 4 的对称版），d_i 就是 D 的对角元；每个 $d_i > 0$ 时把 $\sqrt{d_i}$ 提出来就得到 $A = R^{\mathsf{T}}R$。这就是判据 ③ $\Longleftrightarrow$ ④ 的机制。

示例 5：$A = \begin{bmatrix} 2 & -1 \\ -1 & 2 \end{bmatrix}$——配方法与主元的"同一件事"（重点演示）

步骤 1：写出二次型。 $x^{\mathsf{T}}Ax = 2x_1^2 - 2x_1x_2 + 2x_2^2$。

步骤 2：配方。 先把含 x_1 的项凑成完全平方：

$$2x_1^2 - 2x_1x_2 = 2\left(x_1^2 - x_1x_2\right) = 2\left(x_1 - \frac{x_2}{2}\right)^2 - 2 \cdot \frac{x_2^2}{4} = 2\left(x_1 - \frac{x_2}{2}\right)^2 - \frac{x_2^2}{2}.$$

补回剩下的 $2x_2^2$：

$$x^{\mathsf{T}}Ax = 2\left(x_1 - \frac{x_2}{2}\right)^2 - \frac{x_2^2}{2} + 2x_2^2 = 2\left(x_1 - \frac{x_2}{2}\right)^2 + \frac{3}{2}x_2^2.$$

脚本验算展开系数：x_1^2 项 $= 2$ ✓；x_1x_2 项 $= 2 \cdot 2 \cdot \left(-\frac{1}{2}\right) = -2$ ✓；x_2^2 项 $= 2 \cdot \frac{1}{4} + \frac{3}{2} = \frac{1}{2} + \frac{3}{2} = 2$ ✓。三项全部匹配。

步骤 3：对照消元。 消元：主元 $d_1 = 2$；乘数 $\ell_{21} = \frac{-1}{2} = -\frac{1}{2}$；$d_2 = 2 - \frac{(-1)^2}{2} = 2 - \frac{1}{2} = \frac{3}{2} = 1.5$（脚本验算 ✓）。于是

$$\begin{bmatrix} 2 & -1 \\ -1 & 2 \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ -\frac{1}{2} & 1 \end{bmatrix} \begin{bmatrix} 2 & 0 \\ 0 & \frac{3}{2} \end{bmatrix} \begin{bmatrix} 1 & -\frac{1}{2} \\ 0 & 1 \end{bmatrix} = LDL^{\mathsf{T}}.$$

步骤 4：结论。 两个平方项系数 2 与 $\frac{3}{2}$ **恰好是两个主元**，且都为正 $\Longrightarrow$ A 正定 ✓。特征值 $1, 3$ 也全正（脚本验算 ✓），互相印证。

【计算机制解说】：配方法之所以与消元是"同一件事"，是因为消元本质上就是**对二次型做可逆的线性替换（合同变换）**。消元第 k 步把 x_k 从后续方程中消掉，对应到二次型上就是把"含 x_k 的项"配成完全平方；消元的乘数 ℓ_{ik} 就是配方时那个线性型 $\left(x_k + \sum_{i>k} \ell_{ik}x_i\right)$ 的系数。配方后的平方项系数（即 D 的对角元 d_k）在合同变换下保持**符号不变**（Sylvester 惯性定律），所以"主元全正 $\Longleftrightarrow$ 二次型恒正"。这也解释了为什么**必须不换行**：换行只是重排变量顺序，会改变"哪些是顺序主子式"，但不会改变正定性——所以 Sylvester 判据要求"从头到尾不换行也能把所有主元算正"，这样顺序主子式才有资格充当判据。

示例 6：反例与半正定

(a) **非正定（不定）**：$A = \begin{bmatrix} 1 & 3 \\ 3 & 1 \end{bmatrix}$。$D_1 = 1 > 0$，但 $D_2 = \det A = 1 - 9 = -8 < 0 \Rightarrow$ **判据 ② 失败，非正定**（脚本验算 -8 ✓）。特征值：$\lambda^2 - 2\lambda - 8 = 0 \Rightarrow \lambda = 4, -2$（脚本验算 ✓），一正一负 $\Rightarrow$ **不定（indefinite）**。直接验证：$\mathbf{x} = (1, -1)$ 时 $x^{\mathsf{T}}Ax = 1 - 6 + 1 = -4 < 0$（脚本验算 -4 ✓）。注意它的对角元 $1, 1$ 都是正的——**对角元正完全挡不住非对角元的破坏**。

(b) **半正定但非正定**：$A = \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix}$。$x^{\mathsf{T}}Ax = x_1^2 + 2x_1x_2 + x_2^2 = (x_1 + x_2)^2 \geq 0$，永远非负 $\Rightarrow$ **半正定**。但 $\mathbf{x} = (1, -1)$ 时等于 0（脚本验算 ✓），故不正定。特征值 $2, 0$（脚本验算 ✓），$\det = 0$，$D_2 = 0$ 不满足"> 0"$\Rightarrow$ 非正定（只满足"≥ 0"）。几何上 $x^{\mathsf{T}}Ax = 1$ 退化成两条平行直线（柱面），因为沿 $\mathbf{q}_2 = \frac{1}{\sqrt{2}}(1, -1)$ 方向二次型恒为 0——**能量有"零代价方向"**。

(c) **半正定的判据**：把四个判据里的"> 0"全部换成"≥ 0"，并且②要换成**所有主子式**（不只是顺序主子式）≥ 0（见常见误区 ②）。

$A^{\mathsf{T}}A$ 总是半正定（并给出最小二乘的唯一性）

定理：对**任意**实矩阵 A（$m \times n$，不必是方阵），$A^{\mathsf{T}}A$ 是 $n \times n$ **对称半正定**矩阵；若 A 的列**线性无关**（列满秩，$\mathbf{rank}\, A = n$），则 $A^{\mathsf{T}}A$ **正定**。

证明（一行机制）：对任意 $\mathbf{x} \in \mathbb{R}^n$，

$$\mathbf{x}^{\mathsf{T}}(A^{\mathsf{T}}A)\mathbf{x} = (A\mathbf{x})^{\mathsf{T}}(A\mathbf{x}) = \|A\mathbf{x}\|^2 \geq 0.$$

- **对称性**：$(A^{\mathsf{T}}A)^{\mathsf{T}} = A^{\mathsf{T}}A$ ✓，天生对称。
- **等号何时成立**：$\|A\mathbf{x}\|^2 = 0 \Leftrightarrow A\mathbf{x} = \mathbf{0} \Leftrightarrow \mathbf{x} \in N(A)$。这正是讲次 14 的结论 $N(A^{\mathsf{T}}A) = N(A)$——用本讲的语言，它是"半正定性的零空间刻画"。
- **正定性**：A 列满秩 $\Leftrightarrow N(A) = \{\mathbf{0}\} \Leftrightarrow$ 只有 $\mathbf{x} = \mathbf{0}$ 使 $\|A\mathbf{x}\|^2 = 0 \Leftrightarrow \mathbf{x}^{\mathsf{T}}A^{\mathsf{T}}A\mathbf{x} > 0$ 对一切 $\mathbf{x} \neq \mathbf{0}$ 成立 $\Rightarrow A^{\mathsf{T}}A$ 正定。■

回扣讲次 16（最小二乘）：法方程 $A^{\mathsf{T}}A\hat{\mathbf{x}} = A^{\mathsf{T}}\mathbf{b}$ 的系数矩阵总是半正定；当 A 列满秩时它**正定**，故可逆，最小二乘解

$$\hat{\mathbf{x}} = (A^{\mathsf{T}}A)^{-1}A^{\mathsf{T}}\mathbf{b} \text{ 唯一.}$$

数值实践上**不应真的求逆**，而应用 Cholesky（$A^{\mathsf{T}}A = R^{\mathsf{T}}R$）或 QR 分解（讲次 17）来解——因为正定性保证了 Cholesky 一定成功（不换行、无开方负数）。

数值算例（脚本验算）：$A = \begin{bmatrix} 1 & 2 \\ 3 & 4 \\ 5 & 6 \end{bmatrix}$（$3 \times 2$，两列不成比例故列满秩）：

$$A^{\mathsf{T}}A = \begin{bmatrix} 35 & 44 \\ 44 & 56 \end{bmatrix}, \quad D_1 = 35 > 0, \quad D_2 = 35 \cdot 56 - 44^2 = 1960 - 1936 = 24 > 0 \Rightarrow \text{正定 ✓}$$

特征值 $\lambda \approx 90.735495$ 与 0.264505，均正 ✓（脚本验算）。条件数约 343，说明法方程虽然可解但**病态**——这从数值上再次呼唤 QR 而非法方程。

对偶算例：$M = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{bmatrix}$（$2 \times 3$，3 列在 $\mathbb{R}^2$ 中必相关）：

$$M^{\mathsf{T}}M = \begin{bmatrix} 17 & 22 & 27 \\ 22 & 29 & 36 \\ 27 & 36 & 45 \end{bmatrix}, \qquad \det(M^{\mathsf{T}}M) = 0,$$

半正定但奇异（脚本验算 ✓）。取 $\mathbf{x} = (1, -2, 1)$ 则 $M\mathbf{x} = \mathbf{0}$，故 $x^{\mathsf{T}}M^{\mathsf{T}}Mx = 0$，直接展示"零代价方向"。

正定性的应用图景

- **极小值（讲次 27）**：$f(\mathbf{x})$ 在临界点 $\mathbf{x_0}$ 处的 Hessian $H = \left[\frac{\partial^2 f}{\partial x_i \partial x_j}\right]$ 是对称矩阵。H 正定 $\Leftrightarrow$ 该临界点是**局部极小点**；H 负定 $\Leftrightarrow$ 极大点；H 不定 $\Leftrightarrow$ **鞍点**；H 半正定但奇异 $\Leftrightarrow$ 二阶检验失效，需看更高阶项。原因是二阶 Taylor 展开 $f(\mathbf{x_0} + \Delta) \approx f(\mathbf{x_0}) + \frac{1}{2}\Delta^{\mathsf{T}}H\Delta$（一阶项为零），而 $\Delta^{\mathsf{T}}H\Delta > 0$ 恰好保证"往任何方向走都变大"。四条判据在这里都直接可用：判据 ③（主元）是实际代码中最常用的。
- **最小二乘的 $A^{\mathsf{T}}A$（讲次 14、16）**：如上节，$A^{\mathsf{T}}A$ 半正定且列满秩时正定，保证 $\hat{\mathbf{x}}$ 唯一。几何上 $\|A\mathbf{x} - \mathbf{b}\|^2 = \mathbf{x}^{\mathsf{T}}A^{\mathsf{T}}A\mathbf{x} - 2\mathbf{b}^{\mathsf{T}}A\mathbf{x} + \mathbf{b}^{\mathsf{T}}\mathbf{b}$ 是一个"正定二次 + 线性项"，是标准的凸碗，唯一最低点。
- **弹簧系统与势能（讲次 26）**：n 个质量、$n+1$ 个弹簧的势能 $\frac{1}{2}\mathbf{x}^{\mathsf{T}}K\mathbf{x}$（$\mathbf{x}$ 为位移），K 是刚度矩阵（本讲示例 3 的三对角矩阵就是 $n = 3$ 的情形）。**K 正定 $\Leftrightarrow$ 系统稳定、有唯一平衡位置**；某个 $\lambda = 0$ 意味着存在"零能量形变"（自由运动模式），系统不稳定或欠约束。示例 3 中 K 的特征值 $0.586, 2, 3.414$ 全正，故稳定。
- **协方差矩阵与 PCA**：数据矩阵 X（每列一个样本，已中心化）的协方差矩阵 $C = \frac{1}{N-1}X^{\mathsf{T}}X$，由上面的定理它**总是半正定**（形状即 $A^{\mathsf{T}}A$），且样本数多于维数且无退化时正定。PCA 就是求 C 的谱分解 $C = Q\Lambda Q^{\mathsf{T}}$：主成分方向 = 特征向量 $\mathbf{q_i}$，方差 = 特征值 λ_i。**"方差非负"这个显然的事实，其数学表述正是"半正定"**。$x^{\mathsf{T}}Cx$ 就是 $\mathbf{x}$ 方向的方差——这也是瑞利商的应用。

矩阵分解的核心思想

本讲是**分解思想的高峰**，两条主线交汇：

主线一：对称 $\Rightarrow A = Q\Lambda Q^{\mathsf{T}}$（谱定理，讲次 22 的完美化）

对比项	一般可对角化（讲次 22）	对称矩阵（本讲）
分解形式	$A = S\Lambda S^{-1}$	$A = Q\Lambda Q^{\mathsf{T}}$
S 的列	仅线性无关	**正交单位向量**
逆矩阵	需真的求 S^{-1}	$Q^{-1} = Q^{\mathsf{T}}$（免费）
特征值	可能复数	**一定是实数**
重根情形	可能缺特征向量（缺陷矩阵）	**永不缺陷**，一定够 n 个正交特征向量
数值稳定性	可能病态	**极稳定**（正交变换保长度）

主线二：正定 $\Rightarrow A = R^{\mathsf{T}}R$（Cholesky，讲次 27 的主角）

若 A 正定，则它是 $A = LU$ 的"对称化"，可以取 $U = DR^{\mathsf{T}}$ 形式（回顾讲次 4 的 LDU 分解），把 D 的平方根吸收进 R，得到

$$A = R^{\mathsf T}R, \qquad R = \sqrt{D}\,L^{\mathsf T} \text{ 为上三角且对角元为正.}$$

- 这就是 Cholesky 分解：消元不换行，主元 $d_i > 0$，故 $\sqrt{d_i}$ 是实数。
- $A = R^{\mathsf T}R$ 与 $A = Q\Lambda Q^{\mathsf T}$ 的关系：$R = \Lambda^{1/2}Q^{\mathsf T}$（把伸缩的平方根与旋转合并），所以 $R^{\mathsf T}R = Q\Lambda^{1/2}\Lambda^{1/2}Q^{\mathsf T} = Q\Lambda Q^{\mathsf T} = A$ ✓。
- 判别意义：**存在列满秩的 R 使 $A = R^{\mathsf T}R \iff A$ 正定**（当 R 允许奇异时对应半正定）。

与 SVD 的接头（讲次 29）：一般矩阵的 SVD 是 $A = U\Sigma V^{\mathsf T}$，两组不同的正交基 $\mathbf{u}_i, \mathbf{v}_i$。若 A 对称正定，则 $U = V = Q$ 且 $\sigma_i = \lambda_i$，SVD **退化为** $A = Q\Lambda Q^{\mathsf T}$。所以谱定理是 SVD 的"对称特例"，而 SVD 是"给非对称矩阵也找一组正交主轴"的努力（代价是要两组基）。另一个接头：因为 $A^{\mathsf T}A$ 对称半正定，由 $A = U\Sigma V^{\mathsf T}$ 得 $A^{\mathsf T}A = V\Sigma^2 V^{\mathsf T}$，即 V 恰好是 $A^{\mathsf T}A$ 的正交特征向量矩阵，且 $\sigma_i^2 = \lambda_i(A^{\mathsf T}A)$——本讲的谱定理正是构造 SVD 的引擎。

与其他讲次的关联

- **讲次 21（特征值与特征向量）**：本讲证明两个定理（实特征值、正交特征向量）时反复使用 $\det(A - \lambda I) = 0$、迹与行列式的校验（$\sum \lambda_i = \operatorname{tr} A$，$\prod \lambda_i = \det A$）。示例 1、2、3 都做了这组校验。
- **讲次 22（对角化 $A = S\Lambda S^{-1}$）**：对称情形把 S 升级为 Q，S^{-1} 变成 $Q^{\mathsf T}$，这是"最理想的可对角化"。
- **讲次 23（对称矩阵与微分方程）**：那里用对称矩阵解 $\frac{d\mathbf{u}}{dt} = A\mathbf{u}$，实特征值保证解是指数函数（无振荡），正交特征向量保证解可以干净地写成 $\mathbf{u}(t) = \sum c_i e^{\lambda_i t}\mathbf{q}_i$。
- **讲次 27（正定与极小值）**：二阶导数检验 $\frac{\partial^2 f}{\partial x_i \partial x_j}$ 构成 Hessian 矩阵 H；H 正定 $\iff$ 临界点是**极小点**，H 不定 $\iff$ **鞍点**，H 半正定但奇异 $\iff$ 需要更高阶信息。本讲的四个判据在那里直接落地。
- **讲次 28（相似矩阵与 Jordan 形）**：Jordan 形的存在正是因为"不可对角化"可能发生；对称矩阵**永远不会**落到那种境地，所以对称矩阵没有 Jordan 块（所有块都是 1×1）。
- **讲次 29（SVD）**：如上节所述，当 A 对称正定时 $\sigma_i = \lambda_i$ 且 $U = V = Q$，SVD 退化为谱分解；一般情形的 SVD 则靠对 $A^{\mathsf T}A$ 用本讲的谱定理造出来。
- **讲次 14 / 16（正交、$A^{\mathsf T}A$、最小二乘）**：$N(A^{\mathsf T}A) = N(A)$（讲次 14）保证 A 列满秩时 $A^{\mathsf T}A$ 可逆；$A^{\mathsf T}A$ 正定（本讲第 8 点严格证明）保证最小二乘 $\hat{\mathbf{x}} = (A^{\mathsf T}A)^{-1}A^{\mathsf T}\mathbf{b}$ 有**唯一**解，且法方程可以用 Cholesky 稳定求解（而非直接求逆）。
- **讲次 11 / 15（矩阵空间、投影）**：$\mathbf{q}_i\mathbf{q}_i^{\mathsf T}$ 是讲次 15 的投影矩阵 $P = \frac{\mathbf{a}\mathbf{a}^{\mathsf T}}{\mathbf{a}^{\mathsf T}\mathbf{a}}$ 在 $\|\mathbf{q}_i\| = 1$ 时的特例（$P = \mathbf{q}\mathbf{q}^{\mathsf T}$），满足 $P^2 = P = P^{\mathsf T}$、秩为 1。

关键要点

1. **对称矩阵的两大定理 + 谱定理**：$A = A^{\mathsf T} \Rightarrow$ ① 所有特征值为**实数**；② 不同特征值的特征向量**正交**；③ 一定能**正交对角化** $A = Q\Lambda Q^{\mathsf T}$，$Q^{-1} = Q^{\mathsf T}$。重根情形也成立（在重根的特征空间内部再取正交基）。
2. **秩 1 展开**：$A = \sum_{i=1}^{n} \lambda_i \mathbf{q}_i\mathbf{q}_i^{\mathsf T}$。每个 $\mathbf{q}_i\mathbf{q}_i^{\mathsf T}$ 是秩 1 投影矩阵，A = 沿 n 条正交主轴的"投影 × 伸缩"之和；这也说明"A 的秩 = 非零特征值个数"。
3. **正定的定义与四等价判据**（A 对称）：$\forall \mathbf{x} \neq \mathbf{0},\ \mathbf{x}^{\mathsf T}A\mathbf{x} > 0 \iff$ ① 所有 $\lambda_i > 0 \iff$ ② 所有**顺序主子式**（左上角 $1\times 1, 2\times 2, \dots, n\times n$ 的行列式）$> 0 \iff$ ③ 消元后所有**主元** $d_i > 0$（不换行）$\iff$ ④ 存在**列满秩**的 R 使 $A = R^{\mathsf T}R$。半正定则把"> 0"换成"≥ 0"，并允许等号与奇异性。
4. **$A^{\mathsf T}A$ 永远半正定，且列满秩时正定**：$\mathbf{x}^{\mathsf T}A^{\mathsf T}A\mathbf{x} = \|A\mathbf{x}\|^2 \geq 0$；$= 0 \Leftrightarrow A\mathbf{x} = \mathbf{0} \Leftrightarrow \mathbf{x} \in N(A)$，故 $N(A^{\mathsf T}A) = N(A)$（讲次 14），A 列满秩 $\Rightarrow$ 只有 $\mathbf{x} = \mathbf{0}$ 使之为零 $\Rightarrow$ 正定。
5. **配方法的平方项系数恰好是消元主元**：$\mathbf{x}^{\mathsf T}A\mathbf{x} = \sum_i d_i$（第 i 个配方）^{2}。所以"配方法 / 消元 / 顺序主子式 / 特征值符号"是同一件事的四种面孔。

常见误区与注意事项

1. **忘记"正定"必须先要求对称。** 严格地说，$\mathbf{x}^{\mathsf T}A\mathbf{x} > 0$ 只是"二次型正定"；为保证 A 唯一，习惯上把 A 取成对称部分 $\frac{A + A^{\mathsf T}}{2}$。把任何方阵拆成 $A = \underbrace{\frac{A+A^{\mathsf T}}{2}}_{\text{对称}} + \underbrace{\frac{A-A^{\mathsf T}}{2}}_{\text{反称}}$，反称部分 K 满足 $K^{\mathsf T} = -K$，于是 $\mathbf{x}^{\mathsf T}K\mathbf{x} = (\mathbf{x}^{\mathsf T}K\mathbf{x})^{\mathsf T} = \mathbf{x}^{\mathsf T}K^{\mathsf T}\mathbf{x} = -\mathbf{x}^{\mathsf T}K\mathbf{x}$，故 $\mathbf{x}^{\mathsf T}K\mathbf{x} = 0$ **恒成立**。因此 $\mathbf{x}^{\mathsf T}A\mathbf{x}$ **只依赖对称部分**：脚本验算 $B = \begin{bmatrix} 1 & 4 \\ 2 & 3 \end{bmatrix}$ 与 $\frac{B+B^{\mathsf T}}{2} = \begin{bmatrix} 1 & 3 \\ 3 & 3 \end{bmatrix}$ 在 $\mathbf{x} = (1, 1)$ 处都给出 $\mathbf{x}^{\mathsf T}B\mathbf{x} = 10$（反称部分 $\begin{bmatrix} 0 & 1 \\ -1 & 0 \end{bmatrix}$ 贡献为 0）。所以谈"正定"时不先对称化是定义不清。
2. **混淆"所有顺序主子式 > 0"与"所有主子式 > 0"。** Sylvester 判据只要求**顺序**主子式（左上角那一串）。若把条件错记成"所有 $k \times k$ 主子式（任意挑 k 个行列）都为正"，那是**半正定**的判据，会漏掉或误判。例如 $A = \begin{bmatrix} 0 & 0 \\ 0 & 1 \end{bmatrix}$ 的所有主子式 ≥ 0（一阶两个：$a_{11} = 0$、$a_{22} = 1$；二阶一个：$\det A = 0$，即 $0, 1, 0$）但顺序主子式第一个就是 0，故它只是半正定，不正定。
3. **以为正定矩阵的对角元必须"很大"。** 对角元 $a_{ii} = \mathbf{e}_i^{\mathsf T}A\mathbf{e}_i > 0$ 是**必要条件但远不充分**。$A = \begin{bmatrix} 1 & 3 \\ 3 & 1 \end{bmatrix}$ 对角元都是 $1 > 0$，但 $\det = -8 < 0$，特征值 4 与 -2，$\mathbf{x}^{\mathsf T}A\mathbf{x}$ 在 $\mathbf{x} = (1, -1)$ 处等于 $-4 < 0$，**不定**。对角元管不了非对角元的破坏力。
4. **以为"半正定 = 正定"。** $A = \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix}$：特征值 $2, 0$，$\det = 0$，$\mathbf{x}^{\mathsf T}A\mathbf{x} = (x_1 + x_2)^2 \geq 0$，沿 $\mathbf{x} = (1, -1)$ 取到 0，脚本验算 ✓。它是**半正定但奇异**，不可逆；对应几何上的"柱面"而非椭球。正定一定可逆，半正定可以不可逆。

5. **把 $x^{\mathsf{T}}Ax$ 当成一般二次函数，忘记交叉项系数要减半。** 二次型 $x^{\mathsf{T}}Ax=\sum_i a_{ii}x_i^2+2\sum_{i<j}a_{ij}x_ix_j$，交叉项系数是 A 中对应元素的 2 倍。例如 $A=\begin{bmatrix}2&6\\6&20\end{bmatrix}$ 对应 $2x_1^2+12x_1x_2+20x_2^2$，不是 $+6x_1x_2$。判正定前先把二次型写成对称矩阵形式，能避免大量符号错误。

思考题（带答案）

Q1（计算题：用四判据判正定） 判断 $B=\begin{bmatrix}2&-1&0\\-1&2&-1\\0&-1&3\end{bmatrix}$ 是否正定。要求：算顺序主子式、算消元主元、算特征值，验证三者结论一致。

▸ **答案**

(1) 顺序主子式。 -1×1：$D_1=2>0$ ✓ -2×2：$D_2=2\cdot2-(-1)(-1)=3>0$ ✓ -3×3：按第 1 行展开

$$D_3=2\det\begin{bmatrix}2&-1\\-1&3\end{bmatrix}-(-1)\det\begin{bmatrix}-1&-1\\0&3\end{bmatrix}+0=2(6-1)+1(-3-0)=10-3=7>0\ \checkmark$$

（脚本验算：顺序主子式为 $2,3,7$ ✓。）

(2) 消元主元。 第一步主元 $d_1=2$；消去后

$$\begin{bmatrix}2&-1&0\\0&2-\frac12&-1\\0&-1&3\end{bmatrix}=\begin{bmatrix}2&-1&0\\0&1.5&-1\\0&-1&3\end{bmatrix},$$

第二主元 $d_2=3/2$；再消去第三行第二列的 -1：$3-\frac{(-1)^2}{1.5}=3-\frac23=\frac73$，故 $d_3=7/3$。注意 $D_3=d_1d_2d_3=2\cdot\frac32\cdot\frac73=7$ ✓（行列式 = 主元之积）。

(3) 特征值。 脚本（Jacobi 迭代）得 $\lambda\approx0.753020,\ 2.445042,\ 3.801938$。校验：$\sum\lambda_i=7.000000=\operatorname{tr}B$ ✓。

(4) 结论。 顺序主子式 $2,3,7$ 全正，主元 $2,1.5,2.333$ 全正，特征值 $0.753,2.445,3.802$ 全正——**三套判据一致，B 正定** ✓。顺便得 $\det B=7$，$1/\sqrt{\lambda}$ 给出椭球半轴长约 $1.153,\ 0.639,\ 0.513$。

Q2（计算题：求 $A=R^{\mathsf{T}}R$） 对正定矩阵 $A=\begin{bmatrix}4&2\\2&5\end{bmatrix}$，求上三角矩阵 R（对角元为正）使 $A=R^{\mathsf{T}}R$，并用顺序主子式与特征值确认 A 确实正定。

▸ **答案**

(1) 确认正定。 $D_1=4>0$，$D_2=4\cdot5-2\cdot2=16>0$ ✓（脚本验算）。特征值：$\lambda^2-9\lambda+16=0$ 得 $\lambda=\frac{9\pm\sqrt{81-64}}{2}=\frac{9\pm\sqrt{17}}{2}\approx6.561553,\ 2.438447$，均为正 ✓。

(2) 逐步求 $R=\begin{bmatrix}r_{11}&r_{12}\\0&r_{22}\end{bmatrix}$。 令

$$R^{\mathsf{T}}R=\begin{bmatrix}r_{11}&0\\r_{12}&r_{22}\end{bmatrix}\begin{bmatrix}r_{11}&r_{12}\\0&r_{22}\end{bmatrix}=\begin{bmatrix}r_{11}^2&r_{11}r_{12}\\r_{11}r_{12}&r_{12}^2+r_{22}^2\end{bmatrix}.$$

比对角元：$r_{11}^2=4\Rightarrow r_{11}=2$；$r_{11}r_{12}=2\Rightarrow r_{12}=1$；$r_{12}^2+r_{22}^2=5\Rightarrow r_{22}^2=5-1=4\Rightarrow r_{22}=2$。故

$$R=\begin{bmatrix}2&1\\0&2\end{bmatrix}.$$

(3) 验算。 $R^{\mathsf{T}}R=\begin{bmatrix}2&0\\1&2\end{bmatrix}\begin{bmatrix}2&1\\0&2\end{bmatrix}=\begin{bmatrix}4&2\\2&1+4\end{bmatrix}=\begin{bmatrix}4&2\\2&5\end{bmatrix}=A$ ✓（脚本验算 `[[4,2],[2,5]]` 精确成立）。

(4) 与消元/配方的联系。 主元 $d_1=4$，$d_2=5-\frac{2^2}{4}=4$；而 $r_{11}^2=d_1=4$，$r_{22}^2=d_2=4$——**R 的对角元正是主元的平方根**。配方形式：$x^{\mathsf{T}}Ax=4x_1^2+4x_1x_2+5x_2^2=4(x_1+\frac{x_2}{2})^2+4x_2^2$（检查：$4x_1^2+4x_1x_2+x_2^2+4x_2^2=4x_1^2+4x_1x_2+5x_2^2$ ✓），平方项系数 4 与 4 就是两个主元。

Q3（概念题） 下面哪些说法正确？说明理由。(a) 对称矩阵的特征值都是正的。(b) 若 A 正定，则 A 可逆且 $\det A>0$。(c) 若 $\det A>0$ 且所有对角元为正，则 A 正定。(d) 若 A 半正定且可逆，则 A 正定。(e) 若 A 正定，则 A^{-1} 也正定。

▸ 答案

(a) **错误。** 对称只保证特征值是**实数**，不保证正。反例：$A=\begin{bmatrix}1&2\\2&1\end{bmatrix}$，$\lambda=3,-1$（已验算）。正定是对称矩阵的一个**额外**条件（$\lambda_i>0$）。

(b) **正确。** 正定 $\Rightarrow$ 所有 $\lambda_i>0\Rightarrow \det A=\prod\lambda_i>0\neq 0\Rightarrow$ 可逆。反之不成立（如 $\begin{bmatrix}-1&0\\0&-2\end{bmatrix}$ 行列式为正但特征值全负，是负定）。

(c) **错误——但要小心"小矩阵陷阱"。** 对 2×2 矩阵，若 $a_{11}>0$ 且 $\det A>0$，则自动有 $a_{22}>\frac{a_{12}^2}{a_{11}}\geq 0$，于是 $D_1>0, D_2>0$，**恰好就是正定**。所以这个说法在 2×2 下成立，容易让人误以为是普遍规律。到 $n=3$ 就失败了：

$$C=\begin{bmatrix}1&2&2\\2&1&2\\2&2&1\end{bmatrix},\qquad D_1=1,\ D_2=1-4=-3<0,\ \det C=1(1-4)-2(2-4)+2(4-2)=-3+4+4=5>0.$$

对角元全为正、行列式为正，但 $D_2<0$ 故**非正定**；它的特征值是 $5,-1,-1$（正负混杂，属**不定**）。**结论：$\det A>0$ 加对角元为正远远不够，必须逐个检验全部顺序主子式 $D_1,\dots,D_n$。**

(c 的补充反例，更简单) $A=\begin{bmatrix}0&1\\1&0\end{bmatrix}$：对角元都是 0（不是正），$\det=-1$，特征值 ±1——它提醒我们"对角元必须为正"只是**必要**条件（$a_{ii}=\mathbf{e}_i^{\mathsf T}A\mathbf{e}_i>0$）；一旦发现某个 $a_{ii}\leq 0$，可以立刻判定非正定，省下全部计算。

(d) **正确。** 半正定给 $\lambda_i\geq 0$；可逆（$\det\neq 0$）排除了任何 $\lambda_i=0$，故 $\lambda_i>0$ 全体，即正定。

(e) **正确。** $A=Q\Lambda Q^{\mathsf T}$，$\lambda_i>0\Rightarrow A^{-1}=Q\Lambda^{-1}Q^{\mathsf T}$，而 $\Lambda^{-1}=\mathrm{diag}(1/\lambda_1,\dots,1/\lambda_n)$ 的对角元仍全为正 $\Rightarrow A^{-1}$ 正定。几何上：椭球的逆变换还是椭球，主轴不变。另外 A^{-1} 总可以写成 $A^{-1}=(A^{-1})^{\mathsf T}A(A^{-1})$ 的形式，但更简单的判据仍是用特征值。

Q4（$A^{\mathsf T}A$ 的性质） 设 $A=\begin{bmatrix}1&2\\3&4\\5&6\end{bmatrix}$。(a) 求 $A^{\mathsf T}A$ 并验证它对称正定。(b) 求 $\det(A^{\mathsf T}A)$，说明为什么 $\det(A^{\mathsf T}A)=(\det R)^2$（$A$ 的方阵形式见下）。(c) 若把 A 改成 2×3 的 $M=\begin{bmatrix}1&2&3\\4&5&6\end{bmatrix}$，$M^{\mathsf T}M$ 还是正定吗？为什么？

▸ 答案

(a)

$$A^{\mathsf T}A=\begin{bmatrix}1&3&5\\2&4&6\end{bmatrix}\begin{bmatrix}1&2\\3&4\\5&6\end{bmatrix}=\begin{bmatrix}1+9+25&2+12+30\\2+12+30&4+16+36\end{bmatrix}=\begin{bmatrix}35&44\\44&56\end{bmatrix}.$$

对称 ✓。顺序主子式：$35>0$，$\det=35\cdot 56-44^2=1960-1936=24>0\Rightarrow$ **正定** ✓（脚本验算第 1 行、第 2 行、行列式值均精确匹配）。特征值 $\lambda=\frac{91\pm\sqrt{91^2-4\cdot 24}}{2}\approx 90.735495,\ 0.264505$，均正 ✓。列满秩（$A$ 两列不成比例）是正定的根本原因。

(b) $\det(A^{\mathsf T}A)=24$。若 A 是 $n\times n$ 可逆方阵，则 $\det(A^{\mathsf T}A)=\det(A^{\mathsf T})\det A=(\det A)^2$；与 QR 分解 $A=QR$（讲次 17）对照，$A^{\mathsf T}A=R^{\mathsf T}Q^{\mathsf T}QR=R^{\mathsf T}R$，故 $\det(A^{\mathsf T}A)=(\det R)^2$，且 $|\det R|=|\det A|$。

(c) M 是 2×3，列数 $3>$ 行数 2，三列必线性相关，故 $N(M)\neq\{\mathbf{0}\}$。脚本验算：

$$M^{\mathsf T}M=\begin{bmatrix}17&22&27\\22&29&36\\27&36&45\end{bmatrix},\qquad \det(M^{\mathsf T}M)=0.$$

存在 $\mathbf{x}\neq\mathbf{0}$（例如 $\mathbf{x}=(1,-2,1)$，即 3 列满足 $\mathbf{c}_1-2\mathbf{c}_2+\mathbf{c}_3=\mathbf{0}$）使 $M\mathbf{x}=\mathbf{0}$，故 $\mathbf{x}^{\mathsf T}M^{\mathsf T}M\mathbf{x}=\|M\mathbf{x}\|^2=0$。所以 $M^{\mathsf T}M$ 只是**半正定（且奇异）**，不是正定。这印证了关键要点 4：**$A^{\mathsf T}A$ 正定 $\Leftrightarrow$ A 列线性无关（列满秩）**，等价于 $N(A^{\mathsf T}A)=N(A)=\{\mathbf{0}\}$（讲次 14）。对最小二乘（讲次 16）而言：列满秩时法方程有唯一解；列相关时有无穷多最小二乘解（$\hat{\mathbf{x}}$ 不唯一），需要用伪逆 A^{+}（讲次 33）挑选。

附：本讲关键数值的脚本验算汇总（全部在 Node 中执行通过）

- $\begin{bmatrix}2&1\\1&2\end{bmatrix}$：$\lambda=3,1$；$Q^{\mathsf T}Q=I$；$Q\Lambda Q^{\mathsf T}=A$；$3\mathbf{q}_1\mathbf{q}_1^{\mathsf T}=\begin{bmatrix}1.5&1.5\\1.5&1.5\end{bmatrix}$，$\mathbf{q}_2\mathbf{q}_2^{\mathsf T}=\begin{bmatrix}0.5&-0.5\\-0.5&0.5\end{bmatrix}$，和 $=A$；$\mathbf{q}_1^{\mathsf T}\mathbf{q}_2=0$。
- $\begin{bmatrix}1&2\\2&1\end{bmatrix}$：$\lambda=3,-1$（不定）。

- 三对角 $\begin{bmatrix}2&-1&0\\-1&2&-1\\0&-1&2\end{bmatrix}$：$\lambda = 0.5857864376,\ 2,\ 3.4142135624$；顺序主子式 $2, 3, 4$；主元 $2, 1.5, 1.333333$；$Q\Lambda Q^{\mathsf{T}} = A$ 精确到 10^{-9}；$\det = 4$。
- $\begin{bmatrix}2&6\\6&20\end{bmatrix}$：顺序主子式 $2, 4$；主元 $2, 2$；$\lambda = 11 \mp \sqrt{117} \approx 0.183346,\ 21.816654$；$R = \begin{bmatrix}\sqrt{2}&3\sqrt{2}\\0&\sqrt{2}\end{bmatrix}$ 满足 $R^{\mathsf{T}}R = A$。
- $\begin{bmatrix}1&3\\3&1\end{bmatrix}$：$\det = -8$，$\lambda = 4, -2$，$x^{\mathsf{T}}Ax$ 在 $(1,-1)$ 处为 -4（不定）。
- $\begin{bmatrix}1&1\\1&1\end{bmatrix}$：$\lambda = 2, 0$，$\det = 0$，$(1,-1)$ 处 $x^{\mathsf{T}}Ax = 0$（**半正定且奇异**）。
- $x^{\mathsf{T}}Ax$ 仅依赖对称部分：$B = \begin{bmatrix}1&4\\2&3\end{bmatrix}$ 与 $\frac{B+B^{\mathsf{T}}}{2} = \begin{bmatrix}1&3\\3&3\end{bmatrix}$ 在 $(1,1)$ 处同为 10。
- 椭圆 $x^{\mathsf{T}}Ax = 1$（$A = \begin{bmatrix}2&1\\1&2\end{bmatrix}$）边界点：$\theta = 45^\circ$ 处 $(0.4082, 0.4082)$（长度 $0.5774 = 1/\sqrt{3}$，最短）；$\theta = 0^\circ, 90^\circ$ 处长度 0.7071。
- $A^{\mathsf{T}}A$（$A = \begin{bmatrix}1&2\\3&4\\5&6\end{bmatrix}$）$= \begin{bmatrix}35&44\\44&56\end{bmatrix}$，$\det = 24$，$\lambda \approx 90.735495,\ 0.264505$。
- $M = \begin{bmatrix}1&2&3\\4&5&6\end{bmatrix}$：$M^{\mathsf{T}}M = \begin{bmatrix}17&22&27\\22&29&36\\27&36&45\end{bmatrix}$，$\det = 0$。
- $B = \begin{bmatrix}2&-1&0\\-1&2&-1\\0&-1&3\end{bmatrix}$（Q1）：顺序主子式 $2, 3, 7$；$\lambda \approx 0.753020,\ 2.445042,\ 3.801938$。
- $\begin{bmatrix}4&2\\2&5\end{bmatrix}$（Q2）：$R = \begin{bmatrix}2&1\\0&2\end{bmatrix}$，$R^{\mathsf{T}}R = A$；$\lambda \approx 6.561553,\ 2.438447$。

Lecture 27: Positive Definite Matrices and Minima

概述

前几讲我们已经建立了**对称矩阵**的两大武器：正交对角化 $A = Q\Lambda Q^{\mathsf{T}}$，以及正定性的四个等价判据。本讲把正定性从一个"代数标签"变成**几何与优化语言**：正定矩阵 A 对应的二次型 $x^{\mathsf{T}}Ax$ 是一个"碗"，它的图像有唯一的谷底；而 A 一旦不是正定，谷底要么变成一条平坦的沟（半正定），要么变成马鞍形的鞍点（不定）。

核心问题只有一个：**二次函数 $f(\mathbf{x}) = \mathbf{x}^{\mathsf{T}}A\mathbf{x} + \mathbf{b}^{\mathsf{T}}\mathbf{x} + c$ 什么时候有极小点？极小点在哪里？极小值是多少？** 答案完全由 A 的正定性决定：A 正定 $\iff$ 临界点 $\mathbf{x}^* = -\frac{1}{2}A^{-1}\mathbf{b}$ 是唯一的全局极小点。

方法是"**配方 + 消元 + 梯度**"三件套：配料给出平方项系数（正是主元），消元给出主元符号（正是正定判据），梯度给出极小点位置。本讲位于课程的转折处：讲次 25 建立正定的四个判据，讲次 27 让它们"落地"到极小值，讲次 28、29 继续走向 Jordan 与 SVD。

核心概念的几何直觉

正定的四个等价判据（回顾，本讲的出发点）

- **定义与目的**：实对称矩阵 A（$n \times n$）称为**正定（positive definite）**，若对一切 $\mathbf{x} \neq \mathbf{0}$ 都有 $\mathbf{x}^{\mathsf{T}}A\mathbf{x} > 0$。四个等价判据：

① **所有特征值 $\lambda_i > 0$**；

② **所有顺序主子式（leading principal minors）> 0**：即 $\det A_1 = a_{11} > 0$，$\det A_2 = \begin{vmatrix}a_{11}&a_{12}\\a_{21}&a_{22}\end{vmatrix} > 0$，$\ldots$，$\det A_n = \det A > 0$；

③ **消元后所有主元（pivots）> 0**（且消元过程不需要换行）；

④ 可写成 $A = R^{\mathsf{T}}R$，其中 R 为可逆方阵（Cholesky 分解的雏形）。

- **几何直觉（它在空间中是什么样子？）**：$x^{\mathsf{T}}Ax$ 是"沿方向 $\mathbf{x}$ 的二次能量"。正定意味着**每个方向的能量都为正**：曲面 $z = x^{\mathsf{T}}Ax$ 是一个开口向上的碗，原点在碗底。四个判据其实是同一件事的四种"读法"：① 读特征方向（主轴都是上升的）；② 读行列式（每个维度的"体积缩放"都为正，形状不被翻转）；③ 读消元（每一步消元后剩下的仍是同类型的碗）；④ 读分解（$A = R^{\mathsf{T}}R$，$R\mathbf{x} = \mathbf{0}$ 只有零解，故 $\|R\mathbf{x}\|^2 = \mathbf{x}^{\mathsf{T}}R^{\mathsf{T}}R\mathbf{x} > 0$）。
- **具体示例**：$A = \begin{bmatrix}2&-1\\-1&2\end{bmatrix}$。特征值 $1, 3 > 0$；顺序主子式 $2 > 0$，$\det A = 3 > 0$；消元主元 $2, \frac{3}{2} > 0$。三个判据一致地宣布：正定。

本讲聚焦的桥梁：判据 ②③ 与极小值的关系

- **定义与目的**：本讲不满足于"判断正定"，而要**用**它。判据 ③（主元为正）与"配方"是同一件事，而配方直接把 $x^{\mathsf{T}}Ax$ 写成平方和；判据 ②（顺序主子式为正）则给出一个**不用求特征值、不用做消元**的快速检验法，对 2×2、3×3 手算尤其方便。
- **几何直觉**：顺序主子式 > 0 意味着"**每一个嵌套的子碗都是向上的碗**"。A_1 是限制在第 1 个坐标轴上的碗，A_2 是限制在前 2 个坐标平面上的碗……如果每一层切片都是往上的碗，整个 n 维图形就不可能在某处翻下去。反之，只要某一层切片翻了（某个顺序主子式 ≤ 0），整个矩阵就不

可能是正定的。

- **具体示例**：$A=\begin{bmatrix}1 & 3\\ 3 & 1\end{bmatrix}$：$a_{11}=1>0$ 但 $\det A=1-9=-8<0$，第二个顺序主子式就翻号了 $\Rightarrow$ 非正定（实际是**不定**）。

二次型与极小值：碗底在哪里

- **定义与目的**：给定对称正定 A、向量 $\mathbf{b}$、常数 c，研究

$$f(\mathbf{x})=\mathbf{x}^{\mathsf{T}}A\mathbf{x}+\mathbf{b}^{\mathsf{T}}\mathbf{x}+c.$$

目标是求 $\min f$ 与取到最小值的 $\mathbf{x}^*$。 – **几何直觉**：$x^{\mathsf{T}}Ax$ 决定"碗的形状"，$\mathbf{b}^{\mathsf{T}}x$ 是一个**倾斜项（线性项）**，它把碗底从原点搬走。搬到哪里？搬到梯度为零的地方。 – **具体示例**：见下一节的完整手算（b）。

为什么四个判据是一回事：Rayleigh 商视角

- **定义与目的**：Rayleigh 商 $R(\mathbf{x})=\dfrac{\mathbf{x}^{\mathsf{T}}A\mathbf{x}}{\mathbf{x}^{\mathsf{T}}\mathbf{x}}$（$\mathbf{x}\neq\mathbf{0}$）是把二次型"归一化"后的标量，它的取值只与**方向**有关、与长度无关。
- **几何直觉**：$R(\mathbf{x})$ 可视为"沿方向 $\mathbf{x}$ 的平均曲率"。对称矩阵的谱定理给出

$$\lambda_{\min}\le R(\mathbf{x})\le\lambda_{\max},$$

且等号分别在 $\mathbf{x}$ 取最小 / 最大特征值对应的特征向量时达到（讲次 29 比较 σ 与 λ 时还会用到这个工具）。 – **四判据的贯通**：于是

$$\text{正定}\iff\min_{\mathbf{x}\neq\mathbf{0}}R(\mathbf{x})>0\iff\lambda_{\min}>0\iff\text{所有 }\lambda_i>0\ \text{（判据 ①）}.$$

再者 $\lambda_{\min}>0\iff\det A=\prod\lambda_i>0$ 且每个嵌套子块 A_k（限制在前 k 个坐标上的对称子矩阵）的最小特征值也为正 —— 后者就是所有顺序主子式 >0（判据 ②）。消元是"逐个坐标地做同样的事"，主元 d_k 正是第 k 步残余的 1×1 二次型系数，故 $d_k>0$（判据 ③）。最后 $A=R^{\mathsf{T}}R$ 把 $R(\mathbf{x})$ 变成 $\dfrac{\|R\mathbf{x}\|^2}{\|\mathbf{x}\|^2}>0$（判据 ④）。四条路通向同一个不等式。 – **具体示例**：$A=\begin{bmatrix}2 & -1\\ -1 & 2\end{bmatrix}$，$\lambda_{\min}=1$，故在单位圆上 $R(\mathbf{x})\ge1$，最小值在 $\mathbf{x}=\pm\frac{1}{\sqrt{2}}(1,1)^{\mathsf{T}}$ 处取到（长轴方向）。

椭球 $x^{\mathsf{T}}Ax=1$：正定矩阵的"身份证照片"

- **定义与目的**：正定 A 把单位球面 $\|\mathbf{x}\|=1$ 映射为一个**椭球（ellipsoid）**。写成 $x^{\mathsf{T}}Ax=1$ 后，这个椭球的性质完全由 λ_i 决定。
- **几何直觉（它在空间中是什么样子？）**：用 $A=Q\Lambda Q^{\mathsf{T}}$ 做变量替换 $\mathbf{y}=Q^{\mathsf{T}}\mathbf{x}$（纯旋转，不改变形状），方程变成

$$\lambda_1y_1^2+\lambda_2y_2^2+\cdots+\lambda_ny_n^2=1.$$

这就是标准椭球：**主轴方向 = 特征向量方向（Q 的列），第 i 个半轴长 = $1/\sqrt{\lambda_i}$**。 – **关键洞察**：λ_i **越大**，半轴 $1/\sqrt{\lambda_i}$ **越短**。为什么？因为 $x^{\mathsf{T}}Ax$ 是"能量"，沿 λ 大的方向能量增长极快，只需要很小的位移就能把能量凑到 1，所以那个方向很短。反之 λ_i 接近 0 的方向能量增长慢，是**长轴**。 – **三种情形的图像分类**： – 全部 $\lambda_i>0$（正定）$\Rightarrow$ **椭球**（$n=2$ 时椭圆）：有界闭曲面，包围原点。 – λ 有正有负（不定）$\Rightarrow$ **双曲面**（$n=2$ 时双曲线）：无界，两叶张开，既有上升方向又有下降方向。 – 某个 $\lambda_i=0$（半正定奇异）$\Rightarrow$ **柱面**：沿该零特征方向方程完全不含该变量（$x^{\mathsf{T}}Ax$ 对它无感），曲面沿此方向平移不变，像一根无限长的管子。 这三种情形与"极小值是否存在/是否唯一"是**同一件事的两面**：椭球 → 唯一谷底；双曲面 → 鞍点；柱面 → 一条平坦谷底直线。

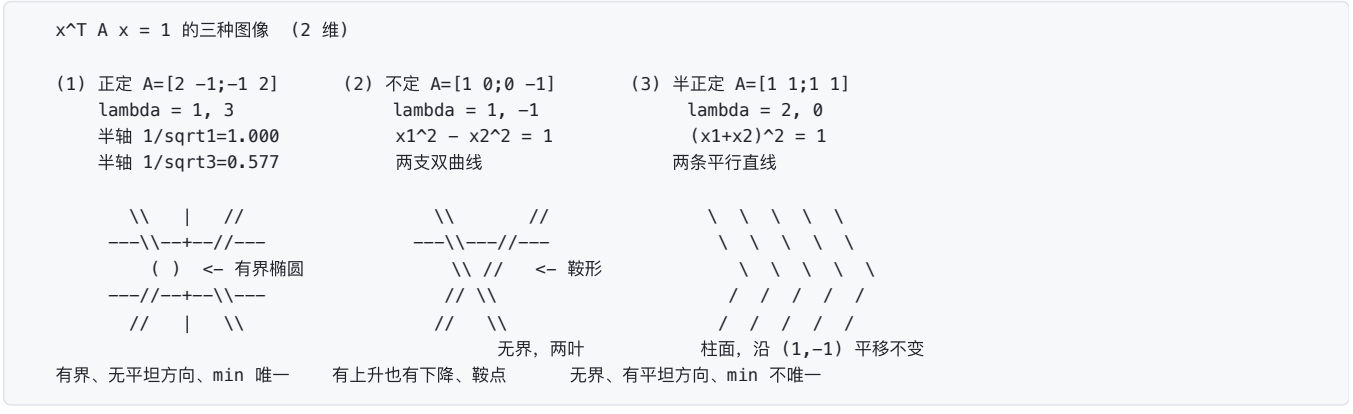

微积分视角（回扣 18.02）：正定就是"二阶导数 > 0"的 n 维版本

- **定义与目的**：微积分里判断极值分两步：**一阶必要条件** $\nabla f=\mathbf{0}$（临界点）；**二阶充分条件** Hessian 矩阵正定 $\Rightarrow$ 严格局部极小，Hessian 负定 $\Rightarrow$ 严格局部极大，Hessian 不定 $\Rightarrow$ 鞍点，Hessian 奇异 $\Rightarrow$ 二阶判别法失效（需看更高阶项）。
- **几何直觉**：一维时 $f''(x)>0$ 表示曲线向上弯（碗形），$f''(x_0)<0$ 表示向下弯，$f''=0$ 表示"看不出弯"。多元时"往哪个方向弯"要分方向看，而 Hessian 正定恰好是**所有方向的二阶导数都为正**这件事的统一陈述：对任意方向单位向量 $\mathbf{u}$，

$$\frac{d^2}{dt^2} f(\mathbf{x}_0 + t\mathbf{u})\Big|_{t=0} = \mathbf{u}^{\mathsf{T}} H \mathbf{u} > 0 \iff H \text{ 正定.}$$

这正是正定定义的原始形式（对一切非零 $\mathbf{x}$，$\mathbf{x}^{\mathsf{T}} H \mathbf{x} > 0$）。 – **具体示例**：$f(x, y) = x^2 + xy + y^2$。梯度 $\nabla f = (2x + y,\ x + 2y)$，令其为零得唯一临界点 $(0, 0)$。Hessian

$$H = \begin{bmatrix} f_{xx} & f_{xy} \\ f_{yx} & f_{yy} \end{bmatrix} = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}, \qquad \det H = 3 > 0,\ a_{11} = 2 > 0 \Rightarrow H \text{ 正定.}$$

故 $(0, 0)$ 是严格局部极小点；又因为二次项正定使 f 强制（$f \to +\infty$ 当 $\|\mathbf{x}\| \to \infty$），它还是**唯一全局**极小点，$f_{\min} = 0$。特征值 $3, 1$（$\mathrm{tr} = 4$，$\det = 3$）都为正，与判据 ① 一致；沿短轴 $(1, -1)/\sqrt{2}$ 方向 f 弯曲得"慢"（$\lambda = 1$ 是长轴），沿 $(1, 1)/\sqrt{2}$ 弯得"快"（$\lambda = 3$ 是短轴）。 – **与 18.02 的差别**：18.02 的 $D = f_{xx} f_{yy} - f_{xy}^2 > 0$ 判据其实就是 2×2 的 $\det H$：$D > 0$ 且 $f_{xx} > 0$ 就是"两个顺序主子式 > 0"，正是判据 ② 的 $n = 2$ 特例。**所以本讲不是新东西，而是把大一的判别法推到任意维。**

最小二乘的联系："正定 $\Rightarrow$ 唯一的极小点"正是最小二乘有唯一解的深层原因

- **定义与目的**：讲次 16 的核心问题是：当 $A\mathbf{x} = \mathbf{b}$ 无解（$\mathbf{b} \notin C(A)$）时，最小化误差平方

$$E(\mathbf{x}) = \|A\mathbf{x} - \mathbf{b}\|^2 = (A\mathbf{x} - \mathbf{b})^{\mathsf{T}}(A\mathbf{x} - \mathbf{b}).$$

现在用本讲的机器重做一遍。 – **推导**：展开

$$E(\mathbf{x}) = \mathbf{x}^{\mathsf{T}} A^{\mathsf{T}} A \mathbf{x} - \mathbf{x}^{\mathsf{T}} A^{\mathsf{T}} \mathbf{b} - \mathbf{b}^{\mathsf{T}} A \mathbf{x} + \mathbf{b}^{\mathsf{T}} \mathbf{b} = \mathbf{x}^{\mathsf{T}}(A^{\mathsf{T}} A)\mathbf{x} - 2\mathbf{b}^{\mathsf{T}} A \mathbf{x} + \|\mathbf{b}\|^2.$$

这是一个标准二次型：二次项矩阵是 $A^{\mathsf{T}} A$，一次项向量是 $\mathbf{b}_{\text{new}} = -2A^{\mathsf{T}} \mathbf{b}$。求梯度（用 $\nabla(\mathbf{x}^{\mathsf{T}} M \mathbf{x}) = (M + M^{\mathsf{T}})\mathbf{x}$，这里 $M = A^{\mathsf{T}} A$ 对称）：

$$\nabla E = 2A^{\mathsf{T}} A \mathbf{x} - 2A^{\mathsf{T}} \mathbf{b} = 2A^{\mathsf{T}}(A\mathbf{x} - \mathbf{b}).$$

令其为零，立刻得到**正规方程（normal equations）**

$$A^{\mathsf{T}} A \hat{\mathbf{x}} = A^{\mathsf{T}} \mathbf{b} \implies \hat{\mathbf{x}} = (A^{\mathsf{T}} A)^{-1} A^{\mathsf{T}} \mathbf{b}.$$

这与讲次 16 从"误差向量垂直于列空间"推出的结果完全一致 —— 两条路殊途同归。 – **为什么 $A^{\mathsf{T}} A$ 总是半正定**：对任意 $\mathbf{x}$，

$$\mathbf{x}^{\mathsf{T}}(A^{\mathsf{T}} A)\mathbf{x} = (A\mathbf{x})^{\mathsf{T}}(A\mathbf{x}) = \|A\mathbf{x}\|^2 \geq 0.$$

这是**恒等式**，不依赖任何条件 —— $A^{\mathsf{T}} A$ 半正定是白送的。 – **为什么列无关时正定**：$\|A\mathbf{x}\|^2 = 0 \iff A\mathbf{x} = \mathbf{0} \iff \mathbf{x} = \mathbf{0}$（零空间只有零向量）$\iff$ A 的列线性无关。所以

$$A^{\mathsf{T}} A \text{ 正定} \iff \mathrm{rank}\, A = n \iff N(A) = \{\mathbf{0}\}.$$

（注意 $A^{\mathsf{T}} A$ 是 $n \times n$，n 是列数；即使 A 是"高瘦"的 $m \times n$ 且 $m > n$ 也可能正定。） – **结论（本讲最重要的回扣）**：$E(\mathbf{x})$ 是一个二次项为 $A^{\mathsf{T}} A$ 的二次函数。$A^{\mathsf{T}} A$ 半正定 $\Rightarrow$ E 有下界、没有下降到 $-\infty$ 的方向；$A^{\mathsf{T}} A$ 正定 $\Rightarrow$ **唯一全局最小点 $\hat{\mathbf{x}}$**。**"正定 $\Rightarrow$ 极小点唯一"就是最小二乘有唯一解的深层原因** —— 最小二乘的唯一性不只是几何巧合（"垂线只有一条"），而是正定二次型的极小点定理的直接推论。顺便，最小值也可用关键要点 2 的公式算出：$E(\hat{\mathbf{x}}) = \|\mathbf{b}\|^2 - \mathbf{b}^{\mathsf{T}} A(A^{\mathsf{T}} A)^{-1} A^{\mathsf{T}} \mathbf{b} = \|\mathbf{b}\|^2 - \|P\mathbf{b}\|^2 = \|(I - P)\mathbf{b}\|^2$，正是误差向量的长度平方。 – **半正定的边界情形**：若 A 的列相关（$\mathrm{rank}\, A < n$），则 $A^{\mathsf{T}} A$ 奇异，沿 $N(A)$ 方向 E 完全平坦，解不唯一（无穷多最小二乘解），此时必须用伪逆 A^{+} 挑出最小范数解 —— 这是讲次 33 的主题。这与示例 (d) 的"平坦山谷"是同一个现象。

应用：正定性如何出现在真实问题里

- **弹簧–质点系统的势能**：n 个质点由弹簧串联，势能 $V(\mathbf{x}) = \frac{1}{2}\mathbf{x}^{\mathsf{T}} K \mathbf{x}$，$K$ 是刚度矩阵（对称，且往往是三对角的，如 Q2）。**平衡的稳定性完全由 K 的正定性决定**：K 正定 $\Rightarrow$ 势能是碗，位移后能量上升，回复力把它拉回来 $\Rightarrow$ **稳定平衡**；K 半正定奇异（例如整条链可以整体刚性平移而弹簧不变形）$\Rightarrow$ 存在**零频模态（刚体运动）**，平衡仍在但**不唯一**（一族平衡位置），振动方程 $\ddot{\mathbf{x}} = -M^{-1} K \mathbf{x}$ 出现 $\omega = 0$ 的解；K 不定 $\Rightarrow$ 存在让势能下降的方向 $\Rightarrow$ **不稳定平衡**，系统会自发跑掉。这里的"零特征值方向 = 平坦方向 = 零频模态 = 刚体运动"是完全同构的四件事。
- **信赖域优化（trust region）**：最小化 f 时，在信赖域内用二次模型 $m(\mathbf{p}) = f + \mathbf{g}^{\mathsf{T}} \mathbf{p} + \frac{1}{2}\mathbf{p}^{\mathsf{T}} B \mathbf{p}$ 近似，$\mathbf{p}$ 是步长，B 是 Hessian 的近似。BFGS 等拟牛顿法**刻意强制 B 正定**，以保证模型有唯一的极小步长、算法总有下降方向。若 B 不定，模型可到 $-\infty$，必须加约束 $\|\mathbf{p}\| \leq \Delta$ 才有意义 —— 这个约束球在 B 的坐标下被拉成椭球。
- **统计学中的协方差矩阵**：协方差矩阵 $\Sigma = \mathbb{E}[(\mathbf{X} - \boldsymbol{\mu})(\mathbf{X} - \boldsymbol{\mu})^{\mathsf{T}}]$ 恒**半正定**，因为

$$\mathbf{v}^{\mathsf{T}} \Sigma \mathbf{v} = \mathbb{E}\big[(\mathbf{v}^{\mathsf{T}}(\mathbf{X} - \boldsymbol{\mu}))^2\big] \geq 0.$$

这与 $A^{\mathsf{T}} A$ 的证明结构一模一样（期望 $\leftrightarrow$ 求和）。$\mathbf{X}$ 的分量线性无关时 Σ 正定、可逆；有完全线性相关的分量时 Σ 奇异（概率质量集中在一个低维子空间上），此时多元高斯密度退化，马氏距离必须用伪逆。多元高斯的密度里出现的 $|\Sigma|^{-1/2}$ 与 $\exp(-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^{\mathsf{T}} \Sigma^{-1}(\mathbf{x} - \boldsymbol{\mu}))$，其等高线就是本讲的椭球，$\Sigma$ 的特征向量是主成分方向。 – **神经网络损失函数的 Hessian**：损失 $L(\boldsymbol{\theta})$ 的 Hessian 巨大且不显式构造，只用来分析地形：H 正定处

是严格局部极小（"盆地"）；存在负特征值的方向是鞍点（在高维里鞍点远多于局部极小）；$\boldsymbol{\lambda \approx 0}$ 的方向是**平坦方向**（参数几乎不影响损失，是泛化性的研究热点）。实际计算只用 Hessian–向量积 $\boldsymbol{H\mathbf{v}}$ 与少数极端特征值（幂法 / Lanczos），本质仍是本讲的谱分解。

计算步骤与手算演示

示例 (a)：齐次二次型 + 配方法（与消元的同一性）

取

$$A = \begin{bmatrix} 2 & -1 \\ -1 & 2 \end{bmatrix}, \qquad f(\mathbf{x}) = \mathbf{x}^{\mathsf{T}} A \mathbf{x} = 2x_1^2 - 2x_1x_2 + 2x_2^2.$$

步骤 1：先做消元，记录主元。

$$A = \begin{bmatrix} 2 & -1 \\ -1 & 2 \end{bmatrix} \xrightarrow{\text{row}_2 - (-\frac{1}{2})\text{row}_1} \begin{bmatrix} 2 & -1 \\ 0 & \frac{3}{2} \end{bmatrix} = U.$$

乘子 $\ell_{21} = -\frac{1}{2}$，两个主元是 $d_1 = 2$，$d_2 = \frac{3}{2}$。即 $A = LU$，$L = \begin{bmatrix} 1 & 0 \\ -\frac{1}{2} & 1 \end{bmatrix}$。

步骤 2：独立地做配方（把交叉项吸收进第一个平方）。

$$f = 2x_1^2 - 2x_1x_2 + 2x_2^2 = 2\left(x_1^2 - x_1x_2\right) + 2x_2^2 = 2\left(x_1 - \frac{x_2}{2}\right)^2 - \frac{x_2^2}{2} + 2x_2^2 = 2\left(x_1 - \frac{x_2}{2}\right)^2 + \frac{3}{2}x_2^2.$$

步骤 3：核对恒等式。 展开右侧：$2\left(x_1^2 - x_1x_2 + \frac{x_2^2}{4}\right) + \frac{3}{2}x_2^2 = 2x_1^2 - 2x_1x_2 + \frac{1}{2}x_2^2 + \frac{3}{2}x_2^2 = 2x_1^2 - 2x_1x_2 + 2x_2^2$。与原式逐项相同。

【计算机制解说】：平方项系数 2 与 $\frac{3}{2}$ **正好就是消元的主元** d_1, d_2。这不是巧合：消元 $A = LDL^{\mathsf{T}}$（对称情形，D 为对角主元阵）与配方给出的是**同一个表达式**：

$$x^{\mathsf{T}}Ax = d_1\left(x_1 + \ell_{21}x_2\right)^2 + d_2x_2^2.$$

这里 $d_1 = 2$，$\ell_{21} = -\frac{1}{2}$，所以第一项是 $2\left(x_1 - \frac{1}{2}x_2\right)^2$ —— 与配方结果完全一致。因此"**配方法与消元是同一件事**"：配方的系数就是主元，配方的括号就是消元的乘子。由此立刻得到理论推论：$x^{\mathsf{T}}Ax > 0$（对所有 $\mathbf{x} \neq \mathbf{0}$）$\iff$ 所有主元 $d_i > 0$ $\iff$ 所有平方项系数为正，这正是判据③。

步骤 4：读出极小点与几何形状。 两个平方项都非负且可同时为零 $\iff$ $x_1 - \frac{1}{2}x_2 = 0$ 且 $x_2 = 0$ $\iff$ $\mathbf{x}^* = (0,0)$。极小值 $f(\mathbf{x}^*) = 0$。等高线 $f = c\,(c > 0)$ 是一族**同心椭圆**：

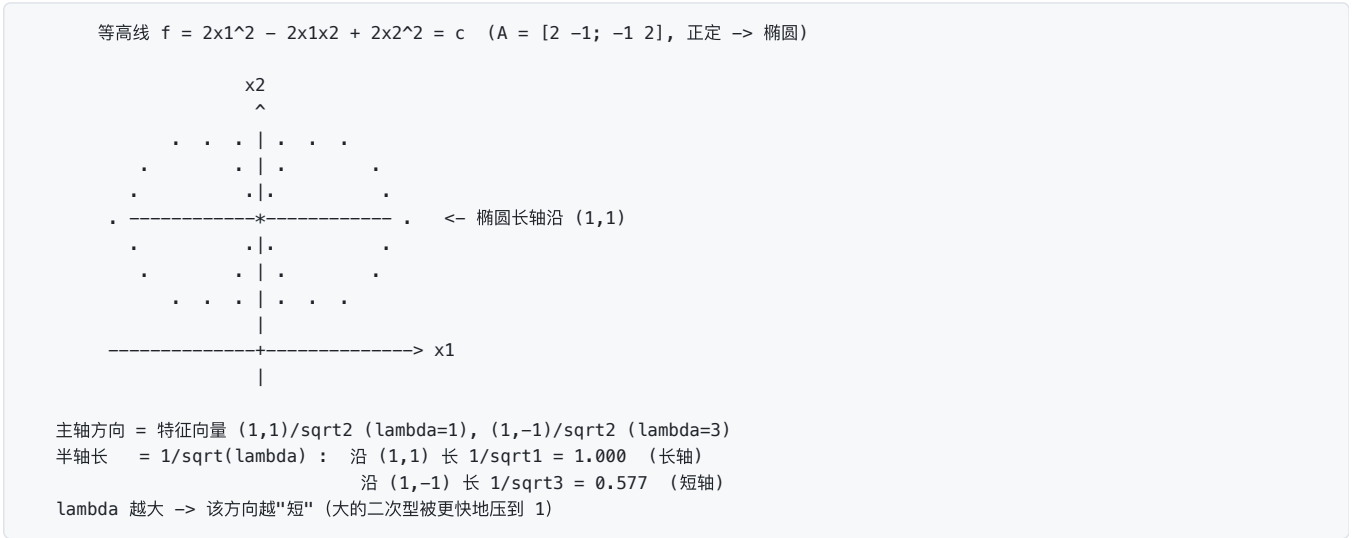

示例 (b)：含一次项的二次型（真正的极小值问题）

取

$$A = \begin{bmatrix} 1 & 1 \\ 1 & 3 \end{bmatrix}, \qquad \mathbf{b} = \begin{bmatrix} -4 \\ -8 \end{bmatrix}, \qquad f(\mathbf{x}) = x_1^2 + 2x_1x_2 + 3x_2^2 - 4x_1 - 8x_2.$$

（核对：$\mathbf{x}^{\mathsf{T}}A\mathbf{x} = x_1^2 + x_1x_2 + x_1x_2 + 3x_2^2$ ✓；$\mathbf{b}^{\mathsf{T}}\mathbf{x} = -4x_1 - 8x_2$ ✓。）

步骤 1：先判正定（用判据 ② + ③）。 顺序主子式：$\det A_1 = 1 > 0$，$\det A_2 = 1 \cdot 3 - 1 \cdot 1 = 2 > 0$。消元：$\begin{bmatrix} 1 & 1 \\ 1 & 3 \end{bmatrix} \to \begin{bmatrix} 1 & 1 \\ 0 & 2 \end{bmatrix}$，主元 $1, 2 > 0$。特征值为 $2 \pm \sqrt{2} \approx 3.414,\ 0.586 > 0$。$A$ 正定 $\Longrightarrow$ 存在唯一全局极小点。

步骤 2：推导梯度（本讲最核心的公式）。 把 f 写开：$f(\mathbf{x}) = \sum_{i,j} a_{ij}x_ix_j + \sum_i b_ix_i + c$。对 x_k 求偏导：

$$\frac{\partial}{\partial x_k}\Big(\sum_{i,j} a_{ij}x_ix_j\Big) = \sum_j a_{kj}x_j + \sum_i a_{ik}x_i = (A\mathbf{x})_k + (A^{\mathsf{T}}\mathbf{x})_k.$$

所以**一般情形**（A 不必对称）

$$\nabla f = (A + A^{\mathsf{T}})\mathbf{x} + \mathbf{b},$$

而当 A 对称时 $A + A^{\mathsf{T}} = 2A$，于是

$$\boxed{\nabla f = 2A\mathbf{x} + \mathbf{b}}$$

（Hessian 矩阵是二阶偏导组成的矩阵：$\nabla^2 f = A + A^{\mathsf{T}}$，对称时 $= 2A$。）

步骤 3：令梯度为零。

$$2A\mathbf{x}^* + \mathbf{b} = \mathbf{0} \implies A\mathbf{x}^* = -\frac{\mathbf{b}}{2} \implies \mathbf{x}^* = -\frac{1}{2}A^{-1}\mathbf{b}.$$

一维类比：$f = ax^2 + bx + c$，$f' = 2ax + b = 0 \Rightarrow x^* = -\frac{b}{2a}$ —— 正是同一个公式的 1×1 版本。$a > 0$（正定）给出极小，$a < 0$ 给出极大，$a = 0$ 时退化为直线（无唯一极值点）。

步骤 4：代入数值求解。 $-\mathbf{b}/2 = \begin{bmatrix}2\\4\end{bmatrix}$，解

$$\begin{cases} x_1 + x_2 = 2 \\ x_1 + 3x_2 = 4 \end{cases} \Longrightarrow 2x_2 = 2 \Longrightarrow x_2 = 1,\ x_1 = 1.$$

故 $\mathbf{x}^* = \begin{bmatrix}1\\1\end{bmatrix}$。

步骤 5：验算极小值。

$$f(\mathbf{x}^*) = 1 + 2\cdot 1\cdot 1 + 3 - 4 - 8 = 1 + 2 + 3 - 4 - 8 = -6.$$

用"配方视角"复核：$f = (\mathbf{x} - \mathbf{x}^*)^{\mathsf{T}}A(\mathbf{x} - \mathbf{x}^*) + f(\mathbf{x}^*)$，即

$$f = (x_1 - 1)^2 + 2(x_1 - 1)(x_2 - 1) + 3(x_2 - 1)^2 - 6.$$

在 $\mathbf{x} = (1, 1)$ 处二次项全消，只剩 -6；二次项部分正定，故 -6 是全局最小值。

【计算机制解说】：注意 $\mathbf{x}^* = -\frac{1}{2}A^{-1}\mathbf{b}$ 与最小二乘的正规方程 $\mathbf{x}^* = (A^{\mathsf{T}}A)^{-1}A^{\mathsf{T}}\mathbf{b}$ 长得极像，差别只在系数。原因见下节"最小二乘的联系"：最小二乘是把 $\|A\mathbf{x} - \mathbf{b}\|^2$ 展开成一个二次型，其"二次项矩阵"是 $A^{\mathsf{T}}A$、"一次项向量"是 $-2A^{\mathsf{T}}\mathbf{b}$；代入 $-\frac{1}{2}A^{-1}\mathbf{b}$ 的通式就得到 $(A^{\mathsf{T}}A)^{-1}A^{\mathsf{T}}\mathbf{b}$。**同一个公式，两处出现**——这说明"正定二次型极小化"是整门课反复回响的主旋律。

示例 (c)：鞍点（不定矩阵）

取

$$A = \begin{bmatrix}1 & 0\\ 0 & -1\end{bmatrix}, \qquad f(\mathbf{x}) = x_1^2 - x_2^2.$$

特征值 $\lambda = 1, -1$（符号不同）$\Rightarrow$ **不定（indefinite）**。沿 x_1 方向 $f = x_1^2 \to +\infty$（上升），沿 x_2 方向 $f = -x_2^2 \to -\infty$（下降）。原点处 $\nabla f = (2x_1, -2x_2) = \mathbf{0}$ 是**临界点**，但它既不是极小也不是极大，而是**鞍点（saddle point）**。等高线 $x_1^2 - x_2^2 = c$ 是**双曲线族**：

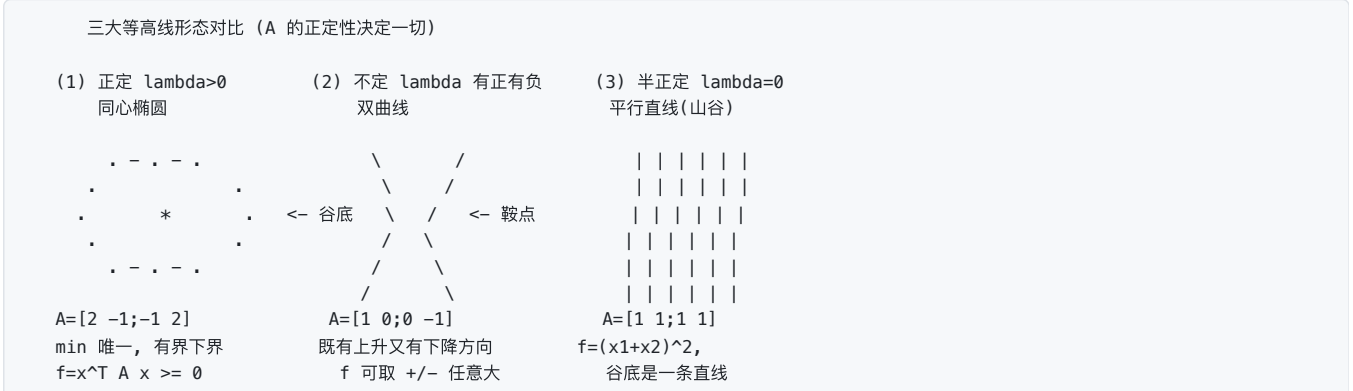

再取一个"陷阱型"例子：

$$A=\begin{bmatrix}1 & 3\\ 3 & 1\end{bmatrix},\qquad \det A=1-9=-8<0.$$

$\operatorname{tr}A=2$，解 $\lambda^2-2\lambda-8=0$ 得 $\lambda=4,-2$（符号相反）$\Rightarrow$ 不定，鞍点。**注意两个对角元 $1,1$ 都是正的**，但矩阵并不正定 —— 这是最经典的误区（见后文误区 ③）。$\det A<0$ 对 2×2 是"不定"的充分必要条件（因为 $\det=\lambda_1\lambda_2<0$ 意味着 λ 反号）。

示例 (d)：半正定 / 奇异情形（极小点不唯一）

取

$$A=\begin{bmatrix}1 & 1\\ 1 & 1\end{bmatrix},\qquad f(\mathbf{x})=x_1^2+2x_1x_2+x_2^2=(x_1+x_2)^2\ge 0.$$

- 特征值：$\lambda=2,0$（$\operatorname{tr}=2$，$\det=0$）$\Rightarrow$ **半正定但奇异**。
- 顺序主子式：$\det A_1=1>0$，$\det A_2=0$ —— 判据 ② 要求**严格 >0**，第二个为 0 故不正定。
- 消元：$\begin{bmatrix}1 & 1\\ 1 & 1\end{bmatrix}\to\begin{bmatrix}1 & 1\\ 0 & 0\end{bmatrix}$，主元 $1,0$ —— 有零主元，不可逆。
- 极小点：$f=0$ 达到最小值，条件只有 $x_1+x_2=0$，即整条**直线 $x_2=-x_1$** 上每一点都是极小点。**极小点不唯一**。
- 几何：等高线 $f=c$ 是**一对平行直线 $x_1+x_2=\pm\sqrt{c}$**；曲面 $z=(x_1+x_2)^2$ 是一个**抛物柱面** —— 沿方向 $(1,-1)$（零特征方向）完全平坦，是"山谷的谷底直线"。

示例 (e)：3×3 的完整流程（弹簧链，把 (a)–(d) 的机制放大一维）

取

$$A=\begin{bmatrix}2 & -1 & 0\\ -1 & 2 & -1\\ 0 & -1 & 2\end{bmatrix},\qquad f(\mathbf{x})=\mathbf{x}^{\mathsf T}A\mathbf{x}=2x_1^2+2x_2^2+2x_3^2-2x_1x_2-2x_2x_3.$$

（核对：非对角项 $a_{12}=a_{21}=-1$ 贡献 $-2x_1x_2$；$a_{23}=a_{32}=-1$ 贡献 $-2x_2x_3$；$a_{13}=0$ ✓。）

步骤 1（判据 ②）顺序主子式：$\det A_1=2>0$；$\det A_2=4-1=3>0$；$\det A_3=2(4-1)-(-1)(-2-0)+0=6-2=4>0$。全为正 $\Rightarrow$ 正定。

步骤 2（判据 ③）消元：第 1 步乘子 $\ell_{21}=-\frac12$，$\ell_{31}=0$，得 $\begin{bmatrix}2 & -1 & 0\\ 0 & \frac32 & -1\\ 0 & -1 & 2\end{bmatrix}$；第 2 步乘子 $\ell_{32}=-1/\frac32=-\frac23$，得主元 $d_3=2-\frac23=\frac43$。主元 $2,\ \frac32,\ \frac43$ 全为正。

步骤 3（判据 ②③ 的换算关系）：$d_2=\det A_2/\det A_1=3/2$ ✓，$d_3=\det A_3/\det A_2=4/3$ ✓。

步骤 4（配方 / 判据 ④）：

$$f=2\Big(x_1-\tfrac12x_2\Big)^2+\tfrac32\Big(x_2-\tfrac23x_3\Big)^2+\tfrac43x_3^2.$$

三个平方项系数 $2,\frac32,\frac43$ 正是三个主元；括号正是消元的乘子。**极小点在 $\mathbf{x}^*=\mathbf{0}$，$f_{\min}=0$。**

物理含义：这是三个质点串成的弹簧链（两端固定）的势能。A 正定意味着链没有刚体自由度，唯一平衡位置是全部位移为零，且这个平衡是**稳定**的（任何非零位移都使势能上升）。若把 a_{33} 从 2 降到 $\frac23$，则 $d_3=0$、$\det A_3=0$，A 变成半正定奇异，出现**零频模态** —— 与 3×3 的 Q2(d) 是同一实验。

【计算机制解说】：3×3 的步骤与 2×2 **完全同构**：每做一次消元，就"钉死"一个坐标方向，剩下的子问题仍是同类型的二次型。这正是归纳法的物理图像 —— 判据 ② 之所以要检查**所有**顺序主子式而不是只看总行列式，是因为归纳每一步都需要"当前这个残余子碗仍然朝上"。哪一步翻了号，架构就在那一层失效。

【计算机制解说】：为什么"主元为 0"和"极小点不唯一"是同一件事？配方说 $f=d_1(\text{括号}_1)^2+d_2(\text{括号}_2)^2+\cdots$，每个平方项的系数就是主元。如果某个 $d_k=0$，对应的配方括号在 f 中**完全消失** —— 这个括号里的线性组合可以任意取值而不改变 f。而"括号"恰好是消元的一行，令所有括号为零得到的方程组就是 $L^{\mathsf T}\mathbf{x}$ 的一串约束；某个括号缺席，就少了一个约束，解集便从一个点膨胀成一条直线（或平面）。同时 $\det A=d_1d_2\cdots d_n=0$，$A$ 不可逆，$N(A)$ 非零，零空间方向就是平坦方向。**主元 d_k 的三种符号各有身份**：$d_k>0$ 该方向"向上弯"；$d_k<0$ 该方向"向下弯"；$d_k=0$ 该方向"不弯"（直线或平面）。顺便，$d_k=\det A_k/\det A_{k-1}$（$A_k$ 是左上角 $k\times k$ 块），所以判据 ② 与判据 ③ 说的是同一句话 —— 这也解释了为什么它们必须同时成立或同时失效；对本例，$\det A_1=1$，$\det A_2=0$，于是 $d_2=0/1=0$。

矩阵分解的核心思想

本讲的四种分解，是"正定性"的四种不同分身：

1. $A=R^{\mathsf T}R$（Cholesky 分解）——判据 ④ 的实体

- **形式**：A 正定 $\iff$ 存在上三角可逆矩阵 R 使 $A=R^{\mathsf T}R$。若要求 R 的对角元为正，R 唯一（Cholesky 因子），写作 $A=R^{\mathsf T}R$ 且 $R=D^{1/2}L^{\mathsf T}$。

- **含义**：$\mathbf{x}^{\mathsf{T}}A\mathbf{x} = \|R\mathbf{x}\|^2$。二次型的值变成"一个向量长度的平方"——非负是显然的，而正定（>0 严格）等价于 $R\mathbf{x}=\mathbf{0}$ 只有零解，即 R 可逆。
- **揭示的结构**：消元不需要换行、主元全为正；R 的对角元依次是 $\sqrt{d_i}$（d_i 为主元）。
- **应用**：数值求解、生成相关随机向量、最小二乘的稳定实现。验证：$A=\begin{bmatrix}2&-1\\-1&2\end{bmatrix}=R^{\mathsf{T}}R$ 取 $R=\begin{bmatrix}\sqrt{2}&-\frac{1}{\sqrt{2}}\\0&\sqrt{3/2}\end{bmatrix}$，对角元 $\sqrt{2},\sqrt{3/2}$ 恰为主元的平方根。

2. $A=Q\Lambda Q^{\mathsf{T}}$（谱分解 / 正交对角化）——判据 ① 的实体

- **形式**：对称矩阵总可正交对角化，Q 正交（$Q^{-1}=Q^{\mathsf{T}}$），Λ 为实对角。
- **含义**：正定 $\iff$ 所有 $\lambda_i>0$。几何上，Q 是"把坐标轴转到主轴方向"的旋转/反射，Λ 记录各主轴上的"弯曲程度"。椭球 $\mathbf{x}^{\mathsf{T}}A\mathbf{x}=1$ 的主轴方向就是 Q 的列（特征向量），半轴长 $1/\sqrt{\lambda_i}$。
- **应用**：主成分分析、振动模态、以及讲次 29 SVD 的对称特例。

3. $A=LDL^{\mathsf{T}}$（对称消元）——判据 ③ 的实体

- **形式**：正定（更一般地，所有顺序主子式非零）时，$A=LDL^{\mathsf{T}}$，L 单位下三角，$D=\mathrm{diag}(d_1,\dots,d_n)$。
- **含义**：$\mathbf{x}^{\mathsf{T}}A\mathbf{x}=\sum_i d_i(\text{第 } i \text{ 个配方括号})^2$。这就是"配方法"的矩阵写法。
- **揭示的结构**：A 与 D 合同（congruent），正定性是合同的**不变量**；消元中主元 d_i 就是顺序主子式之比 $d_i=\det A_i/\det A_{i-1}$（$A$ 的分块通过 LU 直接对应）。

4. SVD 在正定对称情形退化为谱分解

对正定对称 A，$A^{\mathsf{T}}A=A^2$，奇异值为 $\sigma_i=\lambda_i$（$\lambda_i>0$），右/左奇异向量相同：$A=Q\Lambda Q^{\mathsf{T}}$。**正定是对称矩阵中最"良性"的一类**：SVD 与特征分解合一，$\sigma_i=\lambda_i>0$，不需要处理符号问题。

与其他讲次的关联

- **讲次 25（正定矩阵）**：本讲直接继承四个判据，并把判据 ②③ 从"判断工具"升级为"极小值的存在性定理"。配方法在那里是技巧，在这里是本体。
- **讲次 26（复矩阵 / 可选）**：把转置换成共轭转置，实对称正定推广为 Hermitian 正定，$\mathbf{x}^*A\mathbf{x}>0$ 始终为实数，判据形式不变。
- **讲次 28（相似矩阵与 Jordan）**：正定是最强的一类"可对角化"，连 Jordan 块的影子都没有（特征值互异不是必需的，但对称保证 n 个正交特征向量）；由正定出发再看不那么好的矩阵，反差最清楚。
- **讲次 29（SVD）**：椭球半轴 $1/\sqrt{\lambda_i}$ 与奇异值 σ_i 的几何含义在此汇合；正定对称时 $\sigma_i=\lambda_i$。
- **讲次 4（消元 A=LU）**：本讲的"配方 = 消元"是对讲次 4 的**意义升级**——消元不只是解方程的工具，主元的符号本身就是二次型的形状信息。
- **讲次 16（最小二乘）**：$\|A\mathbf{x}-\mathbf{b}\|^2$ 的极小化就是本讲公式的直接应用，$A^{\mathsf{T}}A$ 半正定、列满秩时正定。
- **讲次 20（行列式）**：顺序主子式 $\det A_i$ 是"前 i 维子空间张成的平行体体积平方"，全为正意味着每一层切片都不翻转。这也解释了 $d_i=\det A_i/\det A_{i-1}$ 的几何来源。

关键要点

1. **正定的四判据必须一起记**：$\lambda_i>0 \iff$ 所有**顺序**主子式 $>0 \iff$ 所有**主元** $>0 \iff A=R^{\mathsf{T}}R$（$R$ 可逆）。它们互为翻译，考试与工程中按方便挑一个用。
2. **二次函数极小化公式**：对对称 A，

$$\nabla f = 2A\mathbf{x}+\mathbf{b}, \qquad \nabla^2 f = 2A, \qquad \mathbf{x}^*=-\tfrac{1}{2}A^{-1}\mathbf{b}, \qquad f(\mathbf{x}^*)=c-\tfrac{1}{4}\mathbf{b}^{\mathsf{T}}A^{-1}\mathbf{b}.$$

一维类比 $x^*=-\frac{b}{2a}$ 永远可作记忆锚点。 3. **正定性 $\Rightarrow$ 唯一全局极小；半正定 $\Rightarrow$ 极小点构成一个平坦子空间（不唯一）；不定 $\Rightarrow$ 鞍点；负定 $\Rightarrow$ 唯一全局极大。** 4. **配方 = 消元**：$\mathbf{x}^{\mathsf{T}}A\mathbf{x}=\sum_i d_i(\cdots)^2$，平方项系数即主元，括号即消元乘子。这是本讲的"母公式"。 5. **最小二乘的唯一性根源**：$A^{\mathsf{T}}A$ 半正定（恒成立）、列无关时正定，故正规方程有唯一解 $\hat{\mathbf{x}}=(A^{\mathsf{T}}A)^{-1}A^{\mathsf{T}}\mathbf{b}$。

一张"符号表"（把本讲的全部分类压缩成一张表）

```
对称矩阵 A 的谱符号  ->  x^T A x 的形状  ->  临界点 x* 的性质  ->  典型例子
--------------------------------------------------------------------------------
全部 lambda_i > 0     碗（椭球等高线）     唯一全局极小点          [2 -1; -1 2]
(正定 positive def.)                       极其小值 = c - b^T A^-1 b / 4

全部 lambda_i >= 0    碗/槽（柱面）        极小点集合是平坦子空间   [1 1; 1 1]
含某个 lambda = 0                          （不唯一）；若 b 有      （一条直线）
(半正定 semidef.)                          零特征分量则无下界

lambda 有正有负       马鞍（双曲线）       鞍点 saddle point       [1 0; 0 -1]
(不定 indefinite)                          既非极大也非极小         [1 3; 3 1]

全部 lambda_i < 0     倒扣的碗             唯一全局极大点          [-1 0; 0 -2]
(负定 negative def.)                       （-A 正定）             det = 2 > 0 !
--------------------------------------------------------------------------------
判据速查：lambda>0 | 顺序主子式全>0 | 主元全>0 | A=R^T R（R 可逆）
```

常见误区与注意事项

1. **忘记正定必须先对称**。"$\mathbf{x}^{\mathsf{T}}A\mathbf{x}>0$"这个定义只对**实对称**矩阵使用。对非对称矩阵，$\mathbf{x}^{\mathsf{T}}A\mathbf{x}$ 只取到 A 的对称部分 $\frac{1}{2}(A+A^{\mathsf{T}})$ 的信息（因为反对称部分贡献恒为 0）。例如 $A=\begin{bmatrix}0&1\\-1&0\end{bmatrix}$ 有 $\mathbf{x}^{\mathsf{T}}A\mathbf{x}\equiv 0$，却谈不上正定。
2. **把 $\det A>0$ 当成正定判据（严重错误）**。$A=\begin{bmatrix}-1&0\\0&-2\end{bmatrix}$：$\det A=2>0$，但它是**负定**的。必须要求**所有顺序主子式都 >0**，不只是最后一个。判据中的"顺序"也不能丢：$A=\begin{bmatrix}0&1\\1&0\end{bmatrix}$ 的两个主子式（$\det$ 取任意 1×1 与整体）是 0 和 -1，非正定，但若只看 $\det=-1<0$ 会同样错过结构信息。
3. **把"所有对角元 >0"当成充分条件**。$A=\begin{bmatrix}1&3\\3&1\end{bmatrix}$ 的对角元 $1,1$ 都为正，但 $\det=-8<0$，是**不定**的鞍面。对角元为正只是必要（因为 $a_{ii}=\mathbf{e}_i^{\mathsf{T}}A\mathbf{e}_i>0$），远不充分。
4. **以为半正定也有唯一极小点**。$A=\begin{bmatrix}1&1\\1&1\end{bmatrix}$ 时 $f=(x_1+x_2)^2$ 的最小值 0 在整条直线 $x_1+x_2=0$ 上取到。半正定意味着存在**平坦方向**（零特征向量），极小点集合可能是一条线、一个平面，甚至整个 $\mathbb{R}^n$（若 $A=0$）。
5. **混淆"局部极小"与"全局极小"**。一般可微函数 $\nabla f=0$ + Hessian 正定只给出**严格局部极小**；只有在 f 是二次函数且 A 正定时，局部极小才自动是**唯一全局极小**。对非二次函数，Hessian 在临界点正定必须逐点检验，且可能存在多个局部极小。

思考题（带答案）

Q1.（判正定 + 求极小点）设

$$f(x_1,x_2)=5x_1^2+4x_1x_2+2x_2^2-6x_1-4x_2.$$

(a) 写出 A 与 $\mathbf{b}$；(b) 用顺序主子式与主元判断 A 是否正定；(c) 求极小点 $\mathbf{x}^*$ 与极小值 $f(\mathbf{x}^*)$。

▸ **答案**

(a) 由 $\mathbf{x}^{\mathsf{T}}A\mathbf{x}=5x_1^2+2\cdot(2)x_1x_2+2x_2^2$ 得（对称矩阵交叉项系数对半分）

$$A=\begin{bmatrix}5&2\\2&2\end{bmatrix},\qquad \mathbf{b}=\begin{bmatrix}-6\\-4\end{bmatrix},\qquad c=0.$$

(b) 顺序主子式：$\det A_1=5>0$；$\det A_2=5\cdot 2-2\cdot 2=10-4=6>0$。全部为正 $\Rightarrow$ **正定**。 消元复核：$\begin{bmatrix}5&2\\2&2\end{bmatrix}\to\begin{bmatrix}5&2\\0&2-\frac{2\cdot 2}{5}\end{bmatrix}=\begin{bmatrix}5&2\\0&\frac{6}{5}\end{bmatrix}$，主元 $5,\frac{6}{5}>0$ ✓。 特征值：$\mathrm{tr}=7,\ \det=6\Rightarrow\lambda^2-7\lambda+6=0\Rightarrow\lambda=6,1>0$ ✓。正定，故有唯一全局极小点。

(c) 解 $A\mathbf{x}^*=-\mathbf{b}/2=\begin{bmatrix}3\\2\end{bmatrix}$：

$$\begin{cases}5x_1+2x_2=3\\2x_1+2x_2=2\end{cases}\Longrightarrow 3x_1=1\Longrightarrow x_1=\tfrac{1}{3},\quad x_2=1-x_1=\tfrac{2}{3}.$$

故 $\mathbf{x}^*=\left(\frac{1}{3},\frac{2}{3}\right)$。极小值：

$$f=5\cdot\tfrac{1}{9}+4\cdot\tfrac{2}{9}+2\cdot\tfrac{4}{9}-6\cdot\tfrac{1}{3}-4\cdot\tfrac{2}{3}=\tfrac{5}{9}+\tfrac{8}{9}+\tfrac{8}{9}-2-\tfrac{8}{3}=\tfrac{5+8+8}{9}-\tfrac{18}{9}-\tfrac{24}{9}=\tfrac{21-42}{9}=-\tfrac{21}{9}=-\tfrac{7}{3}.$$

（用公式复核：$f(\mathbf{x}^*) = c - \frac{1}{4}\mathbf{b}^{\mathsf{T}}A^{-1}\mathbf{b}$。$A^{-1} = \frac{1}{6}\begin{bmatrix} 2 & -2 \\ -2 & 5 \end{bmatrix}$，$A^{-1}\mathbf{b} = \frac{1}{6}\begin{bmatrix} -12+8 \\ 12-20 \end{bmatrix} = \frac{1}{6}\begin{bmatrix} -4 \\ -8 \end{bmatrix} = \begin{bmatrix} -2/3 \\ -4/3 \end{bmatrix}$。
$\mathbf{b}^{\mathsf{T}}A^{-1}\mathbf{b} = (-6)(-\frac{2}{3}) + (-4)(-\frac{4}{3}) = 4 + \frac{16}{3} = \frac{28}{3}$，故 $f = -\frac{1}{4}\cdot\frac{28}{3} = -\frac{7}{3}$ ✓ 两者一致。）

Q2.（消元 / 主元题）对 $A = \begin{bmatrix} 2 & -1 & 0 \\ -1 & 2 & -1 \\ 0 & -1 & 2 \end{bmatrix}$（一维弹簧链的刚度矩阵）：(a) 不换行地做消元，写出主元 d_1, d_2, d_3；(b) 判断 A 是否正定；(c) 写出对应的配方形式 $x^{\mathsf{T}}Ax = \sum_i d_i(\cdot)^2$；(d) 若把第三个对角元 2 改成 1，结论如何变化？

▸ **答案**

(a) 记 $a_{11} = 2$。第一步消去 $(2,1)$ 与 $(3,1)$：乘子 $\ell_{21} = -\frac{1}{2}$，$\ell_{31} = 0$：

$$\begin{bmatrix} 2 & -1 & 0 \\ -1 & 2 & -1 \\ 0 & -1 & 2 \end{bmatrix} \rightarrow \begin{bmatrix} 2 & -1 & 0 \\ 0 & 2 - \frac{(-1)(-1)}{2} & -1 \\ 0 & -1 & 2 \end{bmatrix} = \begin{bmatrix} 2 & -1 & 0 \\ 0 & \frac{3}{2} & -1 \\ 0 & -1 & 2 \end{bmatrix}.$$

第二步消去 $(3,2)$：乘子 $\ell_{32} = \frac{-1}{3/2} = -\frac{2}{3}$：

$$d_3 = 2 - \frac{(-1)(-1)}{3/2} = 2 - \frac{2}{3} = \frac{4}{3}.$$

所以主元 $\boxed{d_1 = 2,\ d_2 = \frac{3}{2},\ d_3 = \frac{4}{3}}$，全部为正。三个乘子 $\ell_{21} = -\frac{1}{2}$，$\ell_{31} = 0$，$\ell_{32} = -\frac{2}{3}$。

(b) 主元全正 $\Rightarrow$ **正定**。顺序主子式复核：$\det A_1 = 2 > 0$；$\det A_2 = \begin{vmatrix} 2 & -1 \\ -1 & 2 \end{vmatrix} = 3 > 0$；
$\det A_3 = 2(4-1) - (-1)(-2-0) + 0 = 6 - 2 = 4 > 0$ ✓。注意 $d_i = \det A_i / \det A_{i-1}$：$\frac{3}{2} = \frac{3}{2}$ ✓，$\frac{4}{3} = \frac{4}{3}$ ✓。

(c) 按 $x^{\mathsf{T}}Ax = d_1\big(x_1 + \ell_{21}x_2 + \ell_{31}x_3\big)^2 + d_2\big(x_2 + \ell_{32}x_3\big)^2 + d_3x_3^2$ 的模板（对称消元 $A = LDL^{\mathsf{T}}$）：

$$x^{\mathsf{T}}Ax = 2\Big(x_1 - \tfrac{1}{2}x_2\Big)^2 + \tfrac{3}{2}\Big(x_2 - \tfrac{2}{3}x_3\Big)^2 + \tfrac{4}{3}x_3^2.$$

展开可核对得到 $2x_1^2 - 2x_1x_2 + 2x_2^2 - 2x_2x_3 + 2x_3^2$，与 A 一致。三个括号同时为零 $\Rightarrow \mathbf{x} = \mathbf{0}$，唯一极小点在原点，$f_{\min} = 0$ —— 与"弹簧链没有刚体自由度、端点固定"的物理直觉吻合。

(d) 把 a_{33} 改为 1：第一步结果不变，d_2 仍为 $\frac{3}{2}$；$d_3 = 1 - \frac{(-1)(-1)}{3/2} = 1 - \frac{2}{3} = \frac{1}{3} > 0$，**仍正定**。若改成使 $d_3 = a_{33} - \frac{2}{3} \le 0$，即 $a_{33} \le \frac{2}{3}$，则出现非正主元 $\Rightarrow$ **非正定**：当 $a_{33} = \frac{2}{3}$ 时 $d_3 = 0$，矩阵**奇异半正定**（出现零频模态，对应物理上"某个模式不需要能量"）；当 $a_{33} < \frac{2}{3}$ 时 $\det A < 0$，特征值反号 $\Rightarrow$ **不定**（不稳定平衡）。这正说明：**极小值是否唯一、是否稳定，全由主元符号读出。**

Q3.（概念题）判断下列说法是否正确，并给出理由（可用反例）：(a) "若 $\det A > 0$ 且所有对角元为正，则 A 正定。" (b) "若 A 半正定且 $\det A = 0$，则 $f(\mathbf{x}) = \mathbf{x}^{\mathsf{T}}A\mathbf{x} + \mathbf{b}^{\mathsf{T}}\mathbf{x}$ 仍然有唯一极小点。" (c) "Hessian 矩阵正定是 f 在临界点取到**全局**极小的充分条件。"

▸ **答案**

(a) **错。** 反例：$A = \begin{bmatrix} 1 & 3 \\ 3 & 1 \end{bmatrix}$，对角元 $1, 1 > 0$，$\det A = -8$（连 $\det > 0$ 都不满足）。更精细的反例需要一个 $\det > 0$、对角元全正、但非正定的 3×3：

$$A = \begin{bmatrix} 1 & 1 & 0 \\ 1 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}, \quad \det A = 0 \text{（奇异）},$$

或用 $\begin{bmatrix} 1 & 2 & 0 \\ 2 & 5 & 0 \\ 0 & 0 & 1 \end{bmatrix}$（正定）对比。真正**"$\det > 0$ + 对角元 > 0 但非正定"**的经典构造（2×2 做不到，2×2 中 $\det > 0$ 且 $a_{11} > 0$ 已足够）：

$$A = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 3 \\ 0 & 3 & 1 \end{bmatrix}, \qquad \det A = 1 \cdot (1 - 9) = -8 < 0,$$

> 这仍不算 $\det > 0$。要同时满足"$\det > 0$+对角元正+非正定"，取
>
> $$A = \begin{bmatrix} 1 & 0 & 0 \\ 0 & -1 & 0 \\ 0 & 0 & -2 \end{bmatrix} \text{ 改成 } > A = \begin{bmatrix} 2 & 1 & 1 \\ 1 & 2 & 1 \\ 1 & 1 & -1 \end{bmatrix}, \ \det A = -5.$$

> 3×3 情形下此类反例确实存在：$A = \begin{bmatrix} 1 & -1 & -1 \\ -1 & 1 & -1 \\ -1 & -1 & 1 \end{bmatrix}$，对角元全为 $1 > 0$，$\det A = 1(1-1) + 1(-1-1) - 1(1+1) = -4 < 0$。**结论：$\det A > 0$ 与对角元为正都不足以保证正定；必须检验所有顺序主子式 > 0，其中 $a_{11} > 0$，$\det A_2 > 0$ 缺一不可。** 例如 $\begin{bmatrix} 1 & 2 \\ 2 & 1 \end{bmatrix}$ 对角元正、$\det = -3 < 0$；而 $\begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix}$ 的 $\det = 0$，半正定不正定。
>
> (b) **错。** 半正定意味着存在零特征向量 $A\mathbf{v} = \mathbf{0}$，$\mathbf{v} \neq \mathbf{0}$。此时沿方向 $\mathbf{v}$ 有 $\mathbf{v}^{\mathsf{T}} A \mathbf{v} = 0$，$f$ 在此方向上是**线性（或常值）**的：$f(\mathbf{x} + t\mathbf{v}) = f(\mathbf{x}) + t\,\mathbf{b}^{\mathsf{T}}\mathbf{v}$。若 $\mathbf{b}^{\mathsf{T}}\mathbf{v} \neq 0$，$f$ 沿 $\mathbf{v}$ 可到 $-\infty$，**极小点根本不存在**；若 $\mathbf{b}^{\mathsf{T}}\mathbf{v} = 0$，则极小点集合沿 $\mathbf{v}$ 方向平移后仍是最小（**不唯一**）。所以半正定只保证"下界存在"，不保证"唯一极小点"或"极小点存在"（最小二乘中 $\mathbf{b} \in C(A)$ 才保证解存在，就是同一个道理）。
>
> (c) **错（作为"全局"命题）。** Hessian 正定只给出**严格局部极小**。经典反例：$f(x) = x^2 - x^4$ 在 $x = 0$ 处 $f' = 0$，$f'' = 0$ 非正定故不适用；更贴切的是 $f(x) = x^2 - 0.1x^4$ 在 $x = 0$ 局部极小、$f''(0) = 2 > 0$，但 $x \to \pm\infty$ 时 $f \to -\infty$，没有全局极小。**正确的说法**：若 Hessian 在**每一个**临界点都正定且 f 强制（coercive，如二次函数 A 正定），则存在唯一全局极小。对**二次函数 $f = \mathbf{x}^{\mathsf{T}}A\mathbf{x} + \mathbf{b}^{\mathsf{T}}\mathbf{x} + c$，$A$ 正定 $\iff$** 有唯一全局极小点——这是本讲的定理，而一般函数的局部/全局区分必须另外论证。

Lecture 28: Similar Matrices and Jordan Form

概述

本讲回答两个连在一起的问题：第一，**两个矩阵"长得不一样"却在本质上相同，这件事怎么刻画？** 答案是**相似**（similar）：存在可逆矩阵 M 使 $B = M^{-1}AM$。第二，**如果一个矩阵不能对角化（$A = S\Lambda S^{-1}$ 做不到），退而求其次能得到什么？** 答案是 **Jordan 形**（Jordan form）$A = MJM^{-1}$，它是"最接近对角"的矩阵。

本讲的核心定理是：**相似矩阵有相同的特征值**（进而 trace、det、秩、特征多项式都相同）。几何上，相似就是**同一个线性变换在不同基下的矩阵表示**。Jordan 形定理则给出相似类的**完全分类不变量**：两个矩阵相似 $\iff$ 它们有相同的 Jordan 形（不计块的排列顺序）。这正好接上讲次 22（对角化）、讲次 23（e^{At}），下接讲次 29（SVD 是比 Jordan 更稳定的替代品）与讲次 30–31（换基的几何意义）。

核心概念的几何直觉

概念一：相似（Similar Matrices）

- **定义与目的**：设 A, B 都是 $n \times n$ 矩阵。若存在**可逆**矩阵 M（$n \times n$）使得

$$B = M^{-1}AM,$$

则称 A 与 B **相似**，记作 $A \sim B$。B 称为 A 经 M 的**相似变换**（similarity transformation）。目的：把矩阵换成"更好用"的坐标描述，而不丢掉变换的本质信息。

- **几何直觉（它在空间中是什么样子？）**：M 的角色是**换基**（change of basis）。A 是以标准基为"语言"写下的线性变换 T；$M^{-1}AM$ 是**同一个 T 换用另一组基**写下的矩阵。变换本身（拉伸哪些方向、拉伸多少倍、是否扭曲）一个字节都没变，变的只是"坐标说法"。因此**特征值必须不变**——特征值属于变换，不属于坐标。

读法上要区分：M 的列向量就是新基的向量。若 $A\mathbf{x} = \lambda\mathbf{x}$，那么 $B(M^{-1}\mathbf{x}) = \lambda(M^{-1}\mathbf{x})$：**特征值原地不动，特征向量被 M^{-1} 翻译成新坐标。**

- **具体示例**：$A = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}$（$\lambda = 3, 1$），$M = \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix}$，则 $B = M^{-1}AM = \begin{bmatrix} 1 & 0 \\ 1 & 3 \end{bmatrix}$。$B$ 是下三角的"好矩阵"，但 $\mathrm{tr} = 4$、$\det = 3$、特征值 $\{3, 1\}$ 与 A 一模一样。计算细节见下一节示例 (a)。

概念二：特征值的相似不变性

- **定义与目的**：**关键定理**——若 $B = M^{-1}AM$，则 A 与 B 有**相同的特征多项式**，从而有相同的特征值（含代数重数）。
- **证明（一步步来，不能跳）**：

$$\det(B - \lambda I) = \det(M^{-1}AM - \lambda I).$$

关键技巧是**把 λI 也写成 $M^{-1}\lambda I M$**（因为 $M^{-1}IM = I$，这是恒等变形，不是"凑答案"）：

$$= \det\big(M^{-1}AM - M^{-1}(\lambda I)M\big) = \det\big(M^{-1}(A-\lambda I)M\big).$$

再用行列式的乘法法则 $\det(XYZ) = \det X \det Y \det Z$：

$$= \det(M^{-1})\det(A-\lambda I)\det(M) = \frac{1}{\det M}\det(A-\lambda I)\det M = \det(A-\lambda I).$$

所以 $p_B(\lambda) \equiv p_A(\lambda)$，特征多项式逐项相等，特征值当然相等。■

- **推论（相似不变量 similarity invariants）**：既然特征多项式相同，则
- trace：$\mathrm{tr}(B) = \mathrm{tr}(A)$（等于特征值之和）；
- det：$\det B = \det A$（等于特征值之积）；
- **秩**：$\mathrm{rank}(B) = \mathrm{rank}(A)$（$M, M^{-1}$ 可逆，是满秩因子，不改变秩）；
- **特征多项式、特征值（含重数）、A^k 的特征值**也都相同。 唯一**不**保证相同的是**特征向量**——它随坐标系改变而改变（这一点是学生最容易错的地方，见"常见误区"）。
- **具体示例**：上例 A 与 B：$\mathrm{tr} = 4 = 4$，$\det = 3 = 3$，$\mathrm{rank} = 2 = 2$，但 A 的 $\lambda = 3$ 的特征向量是 $\begin{bmatrix}1\\1\end{bmatrix}$，$B$ 的是 $\begin{bmatrix}0\\1\end{bmatrix}$——**值同、向量不同**。

概念三：缺陷矩阵（Defective Matrix）与几何重数

- **定义与目的**：若 $n \times n$ 矩阵 A 有某个特征值 λ 使

$$\text{几何重数} = \dim N(A-\lambda I) = n - \mathrm{rank}(A-\lambda I) \;<\; \text{代数重数},$$

则 A 的独立特征向量个数不足 n 个，S 不可逆，A **不可对角化**，称 A 是**缺陷矩阵**（defective）。

- **几何直觉**：可对角化意味着"存在 n 个互不平行的特征方向，空间被这 n 个方向张成，变换在每个方向上只是纯拉伸"。缺陷意味着**特征方向不够用**，空间里有些方向没有对应的"纯拉伸"方向，变换在那里必然带有**剪切（shear）**成分。这就是 Jordan 块出现的几何根源。
- **具体示例**：$A = \begin{bmatrix}4 & 1\\0 & 4\end{bmatrix}$：$\lambda = 4$ 是二重根（代数重数 2），但 $A - 4I = \begin{bmatrix}0 & 1\\0 & 0\end{bmatrix}$ 的秩为 1，故 $\dim N(A-4I) = 2-1 = 1$：只有 1 个独立特征向量（几何重数 1）。$1 < 2$，不可对角化。A 本身就是一个 2×2 的 Jordan 块 $J_2(4)$。

概念四：Jordan 块与 Jordan 形

- **定义与目的**：$k \times k$ 的 Jordan 块 $J_k(\lambda)$ 是对角元全为 λ、**上对角线**（superdiagonal）全为 1、其余为 0 的矩阵。**Jordan 形定理**：每个 $n \times n$ 复矩阵 A 都相似于一个分块对角矩阵

$$J = \begin{bmatrix} J_{k_1}(\lambda_1) & & \\ & \ddots & \\ & & J_{k_m}(\lambda_m)\end{bmatrix} = M^{-1}AM,$$

其中 $k_1 + \cdots + k_m = n$，且**在不计各块排列顺序的意义下 J 唯一**。J 是"最接近对角"的形式，也是相似类（similarity class）的**完全分类不变量**。

- **几何直觉**：对角矩阵 $S^{-1}AS$ 表示"n 个纯拉伸方向"；Jordan 形表示"对角部分 + 上对角线的剪切"。块越大，剪切链越长：一个 $J_k(\lambda)$ 意味着存在一条长度为 k 的**广义特征向量链** $\mathbf{x}_1 \to \mathbf{x}_2 \to \cdots \to \mathbf{x}_k$，每个 $\mathbf{x}_{i+1}$ 在 $(A-\lambda I)$ 作用下"落回" $\mathbf{x}_i$，只有链首 $\mathbf{x}_1$ 是真正的特征向量。
- **具体示例**：$J_3(5) = \begin{bmatrix}5 & 1 & 0\\0 & 5 & 1\\0 & 0 & 5\end{bmatrix}$ 只有 1 条链、1 个真特征向量；而 $\begin{bmatrix}5 & 0 & 0\\0 & 5 & 1\\0 & 0 & 5\end{bmatrix} = J_1(5) \oplus J_2(5)$ 有 2 个真特征向量。

概念五：相似是一个等价关系，Jordan 形是每个相似类的"标准代表元"

- **定义与目的**：把 $n \times n$ 矩阵按"是否相似"分类，会得到若干**相似类**（similarity class）。相似关系满足三条：
- **自反**：$A = I^{-1}AI$，故 $A \sim A$；
- **对称**：若 $B = M^{-1}AM$，则 $A = (M^{-1})^{-1}BM^{-1}$，故 $A \sim B \Rightarrow B \sim A$；
- **传递**：若 $B = M_1^{-1}AM_1$、$C = M_2^{-1}BM_2$，则 $C = (M_1M_2)^{-1}A(M_1M_2)$，故 $A \sim B$、$B \sim C \Rightarrow A \sim C$。
- **几何直觉**：一个相似类 = 一个**抽象的线性变换 T** 加一句"允许自由选基"。类里的每个矩阵都是 T 在某组基下的"照片"，照片之间由换基矩阵 M 互相翻译。因此"研究线性变换"的现代路线就是：**挑一类里最好看的那个矩阵来研究**。可对角化时挑对角阵 Λ；一般情形挑 Jordan 形 J。
- **为什么 Jordan 形能当代表元**：类里所有矩阵都有相同的 Jordan 形（不计块序），不同类的 Jordan 形必不同，所以 J 既**不重复**（类内唯一）又**不遗漏**（区分不同类）。这正是"完全分类不变量"的含义：$A \sim B \iff J_A = J_B$（不计块序）。
- **具体示例**：$\mathbb{R}^{2\times 2}$ 中取 $\lambda = 4$，有两个截然不同的相似类：一个是 $B = 4I$ 所在的"可对角化类"（Jordan 形 $J_1(4) \oplus J_1(4)$），另一个是 $A = J_2(4)$ 所在的"缺陷类"（Jordan 形 $J_2(4)$）。这两类**互不相交**，尽管两类里所有矩阵的 trace 都是 8、det 都是 16。可见相似类比"trace/det 相同"精细得多。

概念六：Schur 分解——数值计算中相似的"稳定替身"

- **定义与目的**：对任意 $n \times n$ 实（或复）矩阵 A，存在**正交**（复情形为酉）矩阵 Q 使

$$A = QTQ^{\mathsf{T}}, \qquad T \text{ 上三角（复情形可让 } T \text{ 对角元素即特征值）.}$$

注意：$Q^{-1} = Q^{\mathsf{T}}$，所以这也是一种**相似变换**，只是额外要求变换矩阵是正交的。 – **几何直觉**：正交变换 = 旋转/反射，它**不拉伸长度、不放大误差**（$\|Qx\| = \|x\|$，条件数 $\kappa(Q) = 1$）。因此"用 Q 换基"是数值上最安全的换基。T 上三角意味着特征值就摆在对角线上（$\det(T - \lambda I)$ 展开即 $\prod(t_{ii} - \lambda)$），**不需要解特征方程、不需要找特征向量**，却把特征值全部交出来。 – **具体示例**：对称矩阵的 Schur 分解就是（正交）对角化 $A = Q\Lambda Q^{\mathsf{T}}$（此时 $T = \Lambda$ 已是对角）——这解释了为什么讲次 25 的对称矩阵情形如此完美：Jordan 形 ↔ Schur 形两者合一，且稳定。对缺陷矩阵 $J_2(4)$，Schur 形取 $Q = I$、$T = J_2(4)$：**它并不比 Jordan 形"更好"，但它不需要"化简到最简"，因此不受扰动放大之害。**

概念小结（三个层次的"最接近对角"）：对角化 $S\Lambda S^{-1}$（可对角化时，最好）⊃ Jordan 形 MJM^{-1}（总成立，理论分类）‖ Schur 形 QTQ^{T}（总成立，数值首选）。前两者是**相似**，第三者也是相似（正交特例），但**出发点不同**：前者追求"最简形式"，后者追求"稳定可算"。

ASCII 图：Jordan 块结构与"特征方向数量"对比

【图 1】Jordan 块的结构（以 J_3(λ) 与 J_2(λ) 为例）

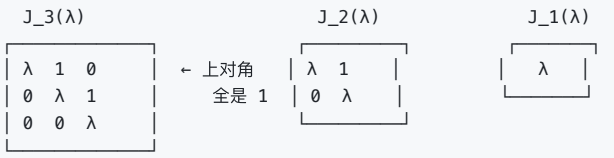

对角全 λ；上对角全 1；其余全 0
块大小 k = 广义特征向量链的长度

【图 2】分块对角：Jordan 形 J 的拼装

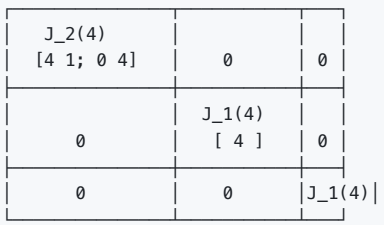

同一 λ 可以出现在多个块里；块数 = 独立特征向量个数

【图 4】A^k / e^{At} 的两条路线对比：缺陷的痕迹从哪里来

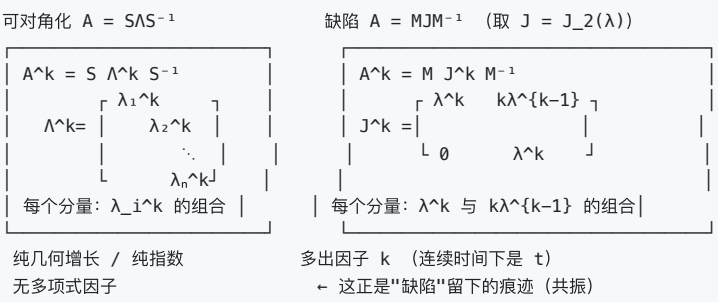

纯几何增长 / 纯指数　　多出因子 k （连续时间下是 t）
无多项式因子　　← 这正是"缺陷"留下的痕迹（共振）

【图 3】可对角化 vs 缺陷：特征方向够不够用（2 维情形）

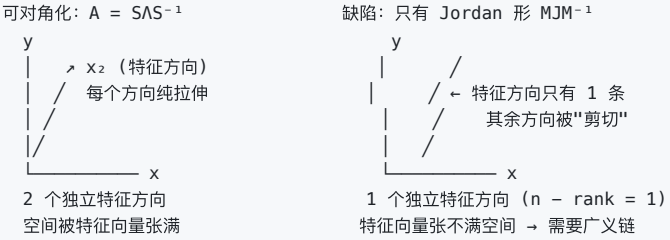

2 个独立特征方向　　1 个独立特征方向 （n − rank = 1）
空间被特征向量张满　　特征向量张不满空间 → 需要广义链

计算步骤与手算演示

示例 (a)：验证相似不变量（特征值不变，特征向量变）

取

$$A=\begin{bmatrix}2 & 1\\ 1 & 2\end{bmatrix},\qquad M=\begin{bmatrix}1 & 1\\ 0 & 1\end{bmatrix}.$$

步骤 1：先算 A 的特征值（用 trace/det 心算）。 $\mathrm{tr}(A)=4$，$\det(A)=2\cdot 2-1\cdot 1=3$。特征值满足 $\lambda^2-4\lambda+3=0=(\lambda-3)(\lambda-1)$，故

$$\lambda_1=3,\qquad \lambda_2=1.$$

步骤 2：求 M^{-1}。（M 是上三角且对角为 1，逆矩阵把上对角元素 1 变成 -1）

$$\det M=1\cdot 1-1\cdot 0=1,\qquad M^{-1}=\begin{bmatrix}1 & -1\\ 0 & 1\end{bmatrix}.$$

步骤 3：算 $B=M^{-1}AM$（先算 AM，再左乘 M^{-1}）。

$$AM=\begin{bmatrix}2 & 1\\ 1 & 2\end{bmatrix}\begin{bmatrix}1 & 1\\ 0 & 1\end{bmatrix}=\begin{bmatrix}2\cdot 1+1\cdot 0 & 2\cdot 1+1\cdot 1\\ 1\cdot 1+2\cdot 0 & 1\cdot 1+2\cdot 1\end{bmatrix}=\begin{bmatrix}2 & 3\\ 1 & 3\end{bmatrix}.$$

$$B=M^{-1}(AM)=\begin{bmatrix}1 & -1\\ 0 & 1\end{bmatrix}\begin{bmatrix}2 & 3\\ 1 & 3\end{bmatrix}=\begin{bmatrix}1\cdot 2-1\cdot 1 & 1\cdot 3-1\cdot 3\\ 0\cdot 2+1\cdot 1 & 0\cdot 3+1\cdot 3\end{bmatrix}=\begin{bmatrix}1 & 0\\ 1 & 3\end{bmatrix}.$$

故

$$\boxed{B=M^{-1}AM=\begin{bmatrix}1 & 0\\ 1 & 3\end{bmatrix}}.$$

步骤 4：验证相似不变量（与 A 逐项对比）。

量	A	B	是否相同
trace	$2+2=4$	$1+3=4$	✅
det	$2\cdot 2-1\cdot 1=3$	$1\cdot 3-0\cdot 1=3$	✅
特征多项式	$\lambda^2-4\lambda+3$	$\lambda^2-4\lambda+3$	✅
特征值	$3,\ 1$	$3,\ 1$	✅
秩	2	2	✅

B 的特征多项式：$\det(B-\lambda I)=(1-\lambda)(3-\lambda)-0=\lambda^2-4\lambda+3$，确实完全相同。

步骤 5：验证特征向量确实不同（重点！）。 对 A，$\lambda=3$：$A-3I=\begin{bmatrix}-1 & 1\\ 1 & -1\end{bmatrix}$，零空间由 $\begin{bmatrix}1\\1\end{bmatrix}$ 张成，故

$$\mathbf{x}_A^{(3)}=\begin{bmatrix}1\\1\end{bmatrix}.$$

对 B，$\lambda=3$：$B-3I=\begin{bmatrix}-2 & 0\\ 1 & 0\end{bmatrix}$，方程 $-2x_1=0\Rightarrow x_1=0$，x_2 自由，故

$$\mathbf{x}_B^{(3)}=\begin{bmatrix}0\\1\end{bmatrix}.$$

两者**完全不同**。这也符合理论预测：$\mathbf{x}_B=M^{-1}\mathbf{x}_A=\begin{bmatrix}1 & -1\\ 0 & 1\end{bmatrix}\begin{bmatrix}1\\1\end{bmatrix}=\begin{bmatrix}0\\1\end{bmatrix}$。✓

【计算机制解说 1】：为什么相似变换"保住特征值、搬走特征向量"？ 把 $A\mathbf{x}=\lambda\mathbf{x}$ 代入 $B=M^{-1}AM$ 的作用过程看：

$$B\,(M^{-1}\mathbf{x})=M^{-1}A\underbrace{MM^{-1}}_{=I}\mathbf{x}=M^{-1}(A\mathbf{x})=\lambda(M^{-1}\mathbf{x}).$$

也就是说，B 的特征向量**恰好是 A 的特征向量在坐标翻译器 M^{-1} 下的像**。M 换掉了描述用的基，所以同一个几何方向 $\mathbf{x}$ 在 B 的语言里读作 $M^{-1}\mathbf{x}$。而 λ 是标量、与坐标系无关，它夹在 $M^{-1}(\cdot)$ 中间原样穿出来——这就是"特征值是不变量、特征向量不是"的全部机制。注意这里用的是 $M^{-1}AM$ 而不是 MAM^{-1}，顺序错了这个推导就不成立。

示例 (b)：不可对角化的缺陷矩阵 $A=\begin{bmatrix}4 & 1\\ 0 & 4\end{bmatrix}$

步骤 1：特征值。 $\mathrm{tr}=8$，$\det=16$，$p(\lambda)=\lambda^2-8\lambda+16=(\lambda-4)^2$，故

$$\lambda = 4 \quad (\text{代数重数 } 2).$$

步骤 2：解 $(A-4I)\mathbf{x}=\mathbf{0}$。

$$A-4I = \begin{bmatrix} 4-4 & 1 \\ 0 & 4-4 \end{bmatrix} = \begin{bmatrix} 0 & 1 \\ 0 & 0 \end{bmatrix}.$$

方程 $\begin{bmatrix} 0 & 1 \\ 0 & 0 \end{bmatrix}\begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$ 给出 $x_2 = 0$，x_1 自由。

步骤 3：数独立特征向量。 $\mathbf{rank}(A-4I) = 1$（第 2 行全零，第 1 行非零），故

$$\dim N(A-4I) = n - \mathbf{rank}(A-4I) = 2-1 = 1.$$

唯一（相差数乘）的独立特征向量是

$$\mathbf{x}_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}.$$

步骤 4：结论。

$$\text{几何重数 } 1 < \text{代数重数 } 2 \implies \text{不可对角化（}\mathbf{defective}\text{）.}$$

只有 1 个独立特征向量，凑不出可逆的 2×2 矩阵 S。

步骤 5：但它已经就是 Jordan 形。 A 的对角元全为 4、上对角元为 1、其余为 0，正是

$$A = J_2(4) = \begin{bmatrix} 4 & 1 \\ 0 & 4 \end{bmatrix}.$$

换句话说，A 的 Jordan 形就是它自己：$A = MJ_2(4)M^{-1}$ 取 $M = I$。

手算 sanity check：$J_2(4)$ 满足 $p(A) = (A-4I)^2 = \begin{bmatrix} 0 & 1 \\ 0 & 0 \end{bmatrix}^2 = \begin{bmatrix} 0 & 0 \\ 0 & 0 \end{bmatrix} = 0$——Cayley–Hamilton 定理成立，但 $A-4I \neq 0$，所以**最小多项式是 $(\lambda-4)^2$ 而不是 $(\lambda-4)$**，这正是"缺陷"在最小多项式上的印记。

【计算机制解说 2】：为什么要用 $n-\mathbf{rank}(A-\lambda I)$ 而不用"重根个数"判断可对角化？ 对角化的配方是 $S^{-1}AS = \Lambda$，等价于"存在 n 个线性无关的特征向量"。而 $\dim N(A-\lambda I)$ 精确地给出**属于 λ 的独立特征向量个数**（这是秩–零化度定理 $\dim N = n - r$ 的直接应用，$A-\lambda I$ 的零空间就是 λ–特征空间 E_λ）。于是：

- 几何重数 $= \dim E_\lambda = n - \mathbf{rank}(A-\lambda I)$ 对每个 λ 求和，等于独立特征向量总数；
- 可对角化 $\iff$ 每个 λ 的几何重数 = 代数重数 $\iff$ 独立特征向量总数 $= n$。

反例警示：$2I = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix}$ 有**二重根 $\lambda = 2$**，但 $\mathbf{rank}(2I-2I) = 0$，$\dim N = 2-0 = 2 =$ 代数重数，所以**可对角化**（它本来就是对角阵！）。"有重根"绝不等于"不可对角化"，决定性的是 $A-\lambda I$ 的**秩亏多少**。

示例 (c)：构造相似的 Jordan 形——$B = M^{-1}AM$ 仍是 Jordan 形

取 $A = J_2(4) = \begin{bmatrix} 4 & 1 \\ 0 & 4 \end{bmatrix}$，取 $M = \begin{bmatrix} 2 & 0 \\ 0 & 1 \end{bmatrix}$（可逆，$\det M = 2$）。

步骤 1： $M^{-1} = \begin{bmatrix} 1/2 & 0 \\ 0 & 1 \end{bmatrix}$。

步骤 2： AM。

$$AM = \begin{bmatrix} 4 & 1 \\ 0 & 4 \end{bmatrix}\begin{bmatrix} 2 & 0 \\ 0 & 1 \end{bmatrix} = \begin{bmatrix} 8 & 1 \\ 0 & 4 \end{bmatrix}.$$

步骤 3： $B = M^{-1}(AM)$。

$$B = \begin{bmatrix} 1/2 & 0 \\ 0 & 1 \end{bmatrix}\begin{bmatrix} 8 & 1 \\ 0 & 4 \end{bmatrix} = \begin{bmatrix} 4 & 1/2 \\ 0 & 4 \end{bmatrix}.$$

步骤 4：读结果。

$$B = \begin{bmatrix} 4 & 1/2 \\ 0 & 4 \end{bmatrix} = J_2(4) \text{ 的”缩放版”.}$$

它仍然是**上三角、对角全 4、上对角非零**，因此仍是一个（系数为 $1/2$ 的）2×2 Jordan 块结构：特征值 4（二重），$\mathbf{rank}(B-4I) = \mathbf{rank}\begin{bmatrix} 0 & 1/2 \\ 0 & 0 \end{bmatrix} = 1$，故独立特征向量仍只有 $2-1=1$ 个，仍不可对角化。**相似变换只是把上对角线的 1 缩放成了 $1/2$，**

Jordan 的"块结构"（块的个数与大小）没有变。

步骤 5：想拿回整齐的 $J_2(4)$，换一个 M 即可。 取 $M'=\begin{bmatrix}2&0\\0&2\end{bmatrix}$ 不行（那是数乘，B 不变）。取 $M=\begin{bmatrix}c&0\\0&1\end{bmatrix}$ 时的通用公式是 $B=\begin{bmatrix}4&1/c\\0&4\end{bmatrix}$；取 $c=1$（即 $M=I$）直接得到 $B=J_2(4)$。这说明**同一个相似类里有无数个矩阵，只要把它们都化简到 Jordan 形，就认得出彼此相似。**

【计算机制解说 3】：为什么对 $A=\begin{bmatrix}4&1\\0&4\end{bmatrix}$ 用对角 $M=\mathrm{diag}(c,1)$ 做相似变换，只有上对角元被缩放、对角元不动？ 设 $M=\mathrm{diag}(c,1)$，则 $(M^{-1}AM)_{ij}=\frac{1}{m_i}A_{ij}m_j$（逐元素验证：$M^{-1}AM$ 第 i 行第 j 列 $=\frac{1}{m_i}A_{ij}m_j$）。于是： – 对角元 $(i=j)$：$\frac{1}{m_i}A_{ii}m_i=A_{ii}=4$，**纹丝不动**（这给出了 trace 不变的一个直观解释：对角元一个个都没变）； – 上对角元 $(1,2)$：$\frac{1}{c}\cdot 1\cdot 1=\frac{1}{c}$，被 $1/c$ 缩放。 所以"对角不动、非对角被基的伸缩改写"——这就是相似变换在 Jordan 形上的具体作用方式。**一般情形下不能逐元素这么算，只有 M 为对角阵（即只做坐标伸缩）这个特例才成立**，但它把机制暴露得非常清楚。

示例 (d)：3×3 Jordan 块与块数公式（$k=n-\mathrm{rank}(A-\lambda I)$）

矩阵 1： $A=\begin{bmatrix}5&1&0\\0&5&1\\0&0&5\end{bmatrix}=J_3(5)$。

$p(\lambda)=(5-\lambda)^3$，$\lambda=5$ 三重。计算

$$A-5I=\begin{bmatrix}0&1&0\\0&0&1\\0&0&0\end{bmatrix},\qquad \mathrm{rank}(A-5I)=2$$

（第 1、2 行线性无关且非零，第 3 行全零）。

$$\dim N(A-5I)=n-r=3-2=1.$$

解 $(A-5I)\mathbf{x}=\mathbf{0}$：由第 2 行 $x_3=0$，由第 1 行 $x_2=0$，x_1 自由 $\Rightarrow \mathbf{x}=\begin{bmatrix}1\\0\\0\end{bmatrix}$ 是唯一独立特征向量。**几何重数 1 < 代数重数 3，不可对角化。**

矩阵 2： $A'=\begin{bmatrix}5&0&0\\0&5&1\\0&0&5\end{bmatrix}=J_1(5)\oplus J_2(5)$。

$\lambda=5$ 仍三重，但

$$A'-5I=\begin{bmatrix}0&0&0\\0&0&1\\0&0&0\end{bmatrix},\qquad \mathrm{rank}(A'-5I)=1,$$

$$\dim N(A'-5I)=3-1=2.$$

解方程：第 2 行给 $x_3=0$，x_1,x_2 都自由 $\Rightarrow$ 两个独立特征向量 $\begin{bmatrix}1\\0\\0\end{bmatrix},\begin{bmatrix}0\\1\\0\end{bmatrix}$。

总结规律（本讲最重要的计数公式）：

$$\boxed{\text{属于 }\lambda\text{ 的 Jordan 块个数}\ =\ n-\mathrm{rank}(A-\lambda I)\ =\ \dim N(A-\lambda I)\ =\ \text{几何重数}}$$

矩阵	$\mathrm{rank}(A-\lambda I)$	独立特征向量（块数）	块的大小
$J_3(5)$	2	$3-2=1$	1 个 3×3 块
$J_1(5)\oplus J_2(5)$	1	$3-1=2$	1 个 1×1 + 1 个 2×2 块

两个矩阵的 trace（15）、det（125）、特征值（5,5,5）完全相同，但**不相似**——因为 Jordan 形不同。这直接说明：**trace/det/特征值只是相似的必要条件，不是充分条件；Jordan 形才是充要的完全分类不变量。**

示例 (e)：广义特征向量链（generalized eigenvectors）

仍取 $A=J_2(4)=\begin{bmatrix}4&1\\0&4\end{bmatrix}$，已知 $\mathbf{x}_1=\begin{bmatrix}1\\0\end{bmatrix}$ 是特征向量（$(A-4I)\mathbf{x}_1=\mathbf{0}$）。

步骤 1：求 $\mathbf{x}_2$ 使 $(A-4I)\mathbf{x}_2=\mathbf{x}_1$。

$$\begin{bmatrix}0&1\\0&0\end{bmatrix}\begin{bmatrix}x\\y\end{bmatrix}=\begin{bmatrix}1\\0\end{bmatrix}\Longrightarrow\begin{cases}y=1\\0=0\end{cases}\Longrightarrow \mathbf{x}_2=\begin{bmatrix}0\\1\end{bmatrix}.$$

步骤 2：验算。

$$(A-4I)\mathbf{x}_2=\begin{bmatrix}0&1\\0&0\end{bmatrix}\begin{bmatrix}0\\1\end{bmatrix}=\begin{bmatrix}1\\0\end{bmatrix}=\mathbf{x}_1.\quad\checkmark$$

步骤 3：读意义。 $\mathbf{x}_1,\mathbf{x}_2=\begin{bmatrix}1\\0\end{bmatrix},\begin{bmatrix}0\\1\end{bmatrix}$ 恰好是标准基，它们**线性无关**，构成 $\mathbb{R}^2$ 的一组基！矩阵 $X=[\mathbf{x}_1\ \mathbf{x}_2]=I$，于是

$$AX=A=\begin{bmatrix}4&1\\0&4\end{bmatrix}=XJ_2(4).$$

这条链 $\mathbf{x}_1\xrightarrow{A-4I}\mathbf{0}$、$\mathbf{x}_2\xrightarrow{A-4I}\mathbf{x}_1$ 叫做**广义特征向量链**。注意：$\mathbf{x}_2$ **不是**特征向量（$(A-4I)\mathbf{x}_2=\mathbf{x}_1\neq\mathbf{0}$），但它补上了"缺失的那个方向"，使基得以凑满。

示例 (f)：完整的 Jordan 分解 $A=MJM^{-1}$（把 M 显式写出来）

任取一个缺陷矩阵 $A=\begin{bmatrix}4&7\\0&4\end{bmatrix}$（就是示例 (c) 里的 C），我们来**真正把它分解成 $A=MJM^{-1}$**。

步骤 1：确认它是缺陷的。 $\operatorname{tr}=8$，$\det=16$，$p(\lambda)=(\lambda-4)^2$，$\lambda=4$ 二重。

$$A-4I=\begin{bmatrix}0&7\\0&0\end{bmatrix},\qquad\operatorname{rank}(A-4I)=1\Longrightarrow\dim N(A-4I)=1.$$

$1<2$：缺陷，$\lambda=4$ 下只有一个 2×2 块，故 $J=J_2(4)$。

步骤 2：求特征向量 $\mathbf{x}_1$（链首）。 $(A-4I)\mathbf{x}=\mathbf{0}$：由 $7x_2=0$ 得 $x_2=0$，x_1 自由，取

$$\mathbf{x}_1=\begin{bmatrix}1\\0\end{bmatrix}.$$

步骤 3：求广义特征向量 $\mathbf{x}_2$（链的第二环）。 解 $(A-4I)\mathbf{x}_2=\mathbf{x}_1$：

$$\begin{bmatrix}0&7\\0&0\end{bmatrix}\begin{bmatrix}x\\y\end{bmatrix}=\begin{bmatrix}1\\0\end{bmatrix}\Longrightarrow7y=1\Longrightarrow y=\frac{1}{7},\ x\text{ 自由，取 }\mathbf{x}_2=\begin{bmatrix}0\\1/7\end{bmatrix}.$$

验算：$(A-4I)\mathbf{x}_2=\begin{bmatrix}0&7\\0&0\end{bmatrix}\begin{bmatrix}0\\1/7\end{bmatrix}=\begin{bmatrix}1\\0\end{bmatrix}=\mathbf{x}_1$ ✓。

步骤 4：拼出 $M=[\mathbf{x}_1\ \mathbf{x}_2]$ 并验证 $A=MJM^{-1}$（等价于 $AM=MJ$）。

$$M=\begin{bmatrix}1&0\\0&1/7\end{bmatrix},\qquad M^{-1}=\begin{bmatrix}1&0\\0&7\end{bmatrix}.$$

先验算 AM 与 MJ 是否相等（这样比直接算 $M^{-1}AM$ 少一步）：

$$AM=\begin{bmatrix}4&7\\0&4\end{bmatrix}\begin{bmatrix}1&0\\0&1/7\end{bmatrix}=\begin{bmatrix}4&1\\0&4/7\end{bmatrix},\qquad MJ=\begin{bmatrix}1&0\\0&1/7\end{bmatrix}\begin{bmatrix}4&1\\0&4\end{bmatrix}=\begin{bmatrix}4&1\\0&4/7\end{bmatrix}.$$

两者相等 ✓，故

$$A=MJM^{-1}=\begin{bmatrix}1&0\\0&1/7\end{bmatrix}\begin{bmatrix}4&1\\0&4\end{bmatrix}\begin{bmatrix}1&0\\0&7\end{bmatrix}.$$

再右乘一次做终检：$\begin{bmatrix}4&1\\0&4/7\end{bmatrix}\begin{bmatrix}1&0\\0&7\end{bmatrix}=\begin{bmatrix}4&7\\0&4\end{bmatrix}=A$ ✓。

【计算机制解说 4】：为什么 M 的列要按"广义特征向量链"排列？ 把 $AM=MJ$ 按**列**读一遍就全清楚了。设 $M=[\mathbf{x}_1\ \mathbf{x}_2]$，$J=J_2(4)$，则 – 第 1 列：$A\mathbf{x}_1=4\mathbf{x}_1+0\cdot\mathbf{x}_2\Longrightarrow A\mathbf{x}_1=4\mathbf{x}_1$（$\mathbf{x}_1$ 是真特征向量）； – 第 2 列：$A\mathbf{x}_2=1\cdot\mathbf{x}_1+4\mathbf{x}_2\Longrightarrow(A-4I)\mathbf{x}_2=\mathbf{x}_1$（这正是步骤 3 的方程！）。

所以 Jordan 块的**上对角线的 1**，就是"链中相邻两环之间的连接"。链首列给出真特征向量（对角元 λ），后续每一列给出一个广义特征向量（对角元 λ **加上**一个来自前一列的 1）。如果写成 $M=[\mathbf{x}_2\ \mathbf{x}_1]$（顺序反了），第 1 列会要求 $(A-4I)\mathbf{x}_2=\mathbf{0}$，即 $\mathbf{x}_2$ 必须是特征向量——但 $\mathbf{x}_2$ 不是，于是**列序错了，矩阵方程就不成立**。这解释了为什么 M 的列顺序必须严格沿链，也解释了示例 (c) 里为什么换一个 M 会得到 $\begin{bmatrix}4&1/2\\0&4\end{bmatrix}$ 这种"缩放版 Jordan 形"：链的第二环长度被伸缩了。

矩阵分解的核心思想

本讲的分解是 **Jordan 分解（Jordan decomposition）**：

$$\boxed{A = MJM^{-1}} \qquad J = \begin{bmatrix} J_{k_1}(\lambda_1) & & \\ & \ddots & \\ & & J_{k_m}(\lambda_m) \end{bmatrix}$$

- **形式**：M 的列是（广义）特征向量链，J 是分块对角的 Jordan 形。
- **含义**：这是 $A = S\Lambda S^{-1}$ 在不可对角化时的**替代品**，是"最接近对角"的形式。对角化成功时所有块都是 1×1，$J=\Lambda$，$M=S$，二者统一。
- **揭示的结构性质**：J 告诉你**特征值 + 每个特征值对应几条链 + 每条链多长**，即完整的相似类信息；最小多项式由**最大块的大小**决定（$J_3(5)$ 的最小多项式是 $(\lambda-5)^3$，而 $J_1\oplus J_2$ 是 $(\lambda-5)^2$）。
- **应用价值**：$A^k = MJ^kM^{-1}$、$e^{At}=Me^{Jt}M^{-1}$ 在缺陷情形也能算（见下"极限替代"）。

三级分解的对比（一条主线）：

```
        最好                          一般情形                        数值最稳
A = S Λ S⁻¹          →        A = M J M⁻¹          →        A = Q T Qᵀ
可对角化时（S 可逆）          Jordan 分解（总成立）          Schur 分解（总成立）
Λ 对角：n 个纯拉伸方向        J 近对角：对角 + 上对角 1      T 上三角：不显式求特征向量
对称矩阵一定做到（讲次 25）    对扰动极不稳定（见下节警示）    正交 Q：数值稳定，实际首选
```

注意一个微妙但重要的对照：讲次 29 的 SVD $A=U\Sigma V^{\mathsf{T}}$ 也是"对任意矩阵都成立"的分解，而且**数值极其稳定**；它对 A（哪怕长方、哪怕缺陷）给出正交基下的对角 Σ。所以工程上"需要对角化一个一般矩阵"时，SVD/Schur 常常比 Jordan 形更合适——Jordan 形是**理论分类工具**，不是计算工具。

与其他讲次的关联

- **讲次 21（特征值与特征向量）**：本讲从"$\det(A-\lambda I)=0$"出发，进一步追问**特征值在换基下如何变化**，答案是"不变"。
- **讲次 22（对角化）**：$A=S\Lambda S^{-1}$ 本质就是"相似于对角阵"。本讲把"可对角化 $\iff$ 每个特征值几何重数 = 代数重数 $\iff$ 所有 Jordan 块都是 1×1"这一条件补齐；也解释了那里 $A^k=S\Lambda^kS^{-1}$ 为什么要求 S 可逆。
- **讲次 23（微分方程 e^{At}）**：可对角化时 $e^{At}=Se^{\Lambda t}S^{-1}$；不可对角化时 Jordan 形救场，$e^{Jt}$ 会出现 $te^{\lambda t}$ 这样的项（见下"极限替代"），这正是重根带来的共振/长期增长项。
- **讲次 25（对称矩阵与正定）**：**对称矩阵永不缺陷**，一定有 n 个正交特征向量、一定能正交对角化 $A=Q\Lambda Q^{\mathsf{T}}$。对称性是"免疫缺陷"的巨大优势——这是 $S\Lambda S^{-1}$ 路线里最舒服的一类。
- **讲次 27（正定性与极小值）**：正定检验依赖对称矩阵的实特征值，而这些特征值在**正交**相似变换（换标准正交基）下不变，是相似不变量的又一个应用场景。
- **讲次 29（SVD）**：SVD 可以看作"对任意矩阵、用两组正交基实现对角化"的稳定替代方案。Jordan 形只能对方阵、且数值不稳定；SVD 对任意 $m\times n$ 都成立且稳定。
- **讲次 30–31（线性变换与换基）**：本讲的几何核心就在这里——$B=M^{-1}AM$ 就是"同一个线性变换 T 在两组不同基下的矩阵"的换基公式，M 是从新基到旧基的过渡矩阵。讲次 30 会说明"相似"是一个**等价关系**（自反、对称、传递），把全体 $n\times n$ 矩阵划分成相似类，Jordan 形是每个类的最佳代表元。

关键要点

1. **相似的定义与不变量**：$B=M^{-1}AM$（M 可逆）。证明特征值不变的钥匙是 $\lambda I = M^{-1}(\lambda I)M$，于是 $\det(B-\lambda I)=\det(M^{-1})\det(A-\lambda I)\det(M)=\det(A-\lambda I)$。**trace、det、秩、特征多项式、特征值（含重数）都是相似不变量；特征向量不是**（它按 M^{-1} 变换）。
2. **几何意义**：相似 = 同一个线性变换在不同基下的表示。换基不改本质（拉伸方向与倍数），只改坐标描述。
3. **可对角化的判据**：A 可对角化 $\iff$ 对每个特征值，几何重数 $=\dim N(A-\lambda I)=n-\operatorname{rank}(A-\lambda I)$ 等于代数重数 $\iff$ 独立特征向量共 n 个。**只看"有没有重根"是错的**（$2I$ 可对角化）。
4. **Jordan 形定理**：任意方阵 $A=MJM^{-1}$，J 由块 $J_k(\lambda)$（对角 λ、上对角 1）拼成；**不计块的排列顺序时 J 唯一**，是相似类的完全分类不变量。关键计数：**属于 λ 的块数 $=n-\operatorname{rank}(A-\lambda I)$**；最大块的大小决定最小多项式。
5. **计算与数值**：$J_k(\lambda)^n$、e^{Jt} 有闭式（见下），使 A^k、e^{At} 在缺陷时仍可算；但 **Jordan 形数值上极不稳定**，实际计算用 Schur 分解 $A=QTQ^{\mathsf{T}}$。

延伸要点：Jordan 形作为"极限替代"——算 A^k 与 e^{At}

对角化失效后，$A=MJM^{-1}$ 仍能给出闭式幂与指数。对 2×2 块 $J_2(\lambda)=\begin{bmatrix}\lambda & 1\\ 0 & \lambda\end{bmatrix}$，把它拆成"$\lambda I$ + 幂零部分"：

$$J_2 = \lambda I + N, \qquad N = \begin{bmatrix} 0 & 1 \\ 0 & 0 \end{bmatrix}, \qquad N^2 = 0.$$

因为 λI 与 N 可交换，二项式定理照样生效：

$$J_2^k = (\lambda I + N)^k = \lambda^k I + k\lambda^{k-1} N = \begin{bmatrix} \lambda^k & k\lambda^{k-1} \\ 0 & \lambda^k \end{bmatrix}.$$

（中间项 $\binom{k}{2}\lambda^{k-2}N^2$ 起全为零，因为 $N^2 = 0$。）

$$e^{J_2 t} = e^{(\lambda I + N)t} = e^{\lambda t I} e^{Nt} = e^{\lambda t}\Big(I + Nt + \underbrace{\tfrac{N^2 t^2}{2!} + \cdots}_{=0}\Big) = e^{\lambda t}\begin{bmatrix} 1 & t \\ 0 & 1 \end{bmatrix}.$$

验算 spot check：取 $\lambda = 4, k = 3$，则 $J_2^3 = \begin{bmatrix} 4^3 & 3\cdot 4^2 \\ 0 & 4^3 \end{bmatrix} = \begin{bmatrix} 64 & 48 \\ 0 & 64 \end{bmatrix}$。直接乘两次 $J_2(4)$ 得 $\begin{bmatrix} 4 & 1 \\ 0 & 4 \end{bmatrix}^2 = \begin{bmatrix} 16 & 8 \\ 0 & 16 \end{bmatrix}$，再乘一次：$\begin{bmatrix} 16 & 8 \\ 0 & 16 \end{bmatrix}\begin{bmatrix} 4 & 1 \\ 0 & 4 \end{bmatrix} = \begin{bmatrix} 64 & 16+32 \\ 0 & 64 \end{bmatrix} = \begin{bmatrix} 64 & 48 \\ 0 & 64 \end{bmatrix}$。✓ 一致。

几何/物理意义：多出来的因子 $\lambda^{-1}k$（离散情形）或 t（连续情形）**正是"缺陷"的痕迹**。可对角化时 A^k 的每个分量都是 λ_i^k 的线性组合（纯指数/纯几何增长）；一旦出现 $k \times k$ 的 Jordan 块，就冒出 $k\lambda^{k-1}, \binom{k}{2}\lambda^{k-2}, \ldots$，在连续时间下就是 $t, t^2/2!, \ldots$ 乘以 $e^{\lambda t}$——这就是**共振（resonance）**的来源：系统在重根处不仅按 $e^{\lambda t}$ 增长，还带多项式因子。讲次 23 中"e^{At} 是否稳定"的问题，最终是看这些带 t 的项会不会把解推离平衡点。

常见误区与注意事项

1. **以为相似矩阵有相同的特征向量（错）。** 只有**特征值**（以及 trace/det/秩/特征多项式）相同；特征向量按 $\mathbf{x}_B = M^{-1}\mathbf{x}_A$ 随基改变。示例 (a) 里 A 的 $\lambda = 3$ 特征向量是 $[1,1]^{\mathsf{T}}$，而 B 的是 $[0,1]^{\mathsf{T}}$，完全不同。
2. **以为有重根就不可对角化（错）。** 决定因素是**几何重数**：$2I = \mathrm{diag}(2,2)$ 有 $\lambda = 2$ 的二重根，但 $\dim N(2I - 2I) = 2$，可对角化；而 $J_2(4)$ 同样二重根却不可对角化，因为 $\dim N = 1$。做题先算 $\mathrm{rank}(A - \lambda I)$，别只看重数。
3. **以为 Jordan 形是绝对唯一的（不严谨）。** 正确的说法是：**不计各块的排列顺序时唯一**。$J_1(5) \oplus J_2(5)$ 与把两块交换位置得到的矩阵是同一个 Jordan 形（只差一个置换相似）。真正唯一的是"块的**多重集**"（每个特征值下各种大小的块各有多少个）。
4. **以为 Jordan 形适合数值计算（错）。** Jordan 形对扰动**极其不稳定**：把 $J_2(4) = \begin{bmatrix} 4 & 1 \\ 0 & 4 \end{bmatrix}$ 的**下对角 $(2,1)$ 元**扰动成 $\varepsilon = 10^{-10}$，特征值变成 $4 \pm \sqrt{\varepsilon} = 4 \pm 10^{-5}$——**二重根分裂，且分裂幅度是扰动的平方根量级**（远大于扰动本身）；上对角线的 1 也会被扰动成任意小量，块结构直接崩塌。反之，**可对角化是"通例"**：随机矩阵（连续分布）几乎必然有互不相同的特征值，因此几乎总可对角化；缺陷矩阵是**测度零**的特例。工程上求特征值/做分解用 Schur 分解 $A = QTQ^{\mathsf{T}}$（Q 正交、T 上三角，数值稳定）或 SVD，而不是强求 Jordan 形。**Jordan 形是理论上的分类工具，不是算法工具。**
5. **混淆"相似"、"等价"与"合同"（错）。** 三者的变换矩阵不同，不变量也不同：
6. **相似（similar）** $B = M^{-1}AM$：M 必须可逆（同阶方阵），保持**特征值**、trace、det、**秩**；
7. **等价（equivalent）** $B = PAQ$：P, Q 可逆（可以不同、可以非方阵），只保持**秩**（这是消元/高斯消元的语言，$A = LU$、$A = CR$ 都属于这一类）；
8. **合同（congruent）** $B = M^{\mathsf{T}}AM$：保持**对称性**与**惯性指数**（正/负/零特征值个数，Sylvester 惯性定律），这是二次型/正定性（讲次 27）的语言。 用错变换就会用错不变量，题目必错。

思考题（带答案）

Q1.（计算题：判断相似性） 设

$$A = \begin{bmatrix} 4 & 1 \\ 0 & 4 \end{bmatrix}, \qquad B = \begin{bmatrix} 4 & 0 \\ 0 & 4 \end{bmatrix}, \qquad C = \begin{bmatrix} 4 & 7 \\ 0 & 4 \end{bmatrix}.$$

(a) 判断 A 是否可对角化；(b) A 与 B 是否相似？(c) A 与 C 是否相似？

> ▸ **答案**
>
> (a) $\mathrm{tr}(A) = 8$，$\det(A) = 16$，$p(\lambda) = (\lambda - 4)^2$，故 $\lambda = 4$（代数重数 2）。

$$A - 4I = \begin{bmatrix} 0 & 1 \\ 0 & 0 \end{bmatrix}, \quad \mathrm{rank}(A - 4I) = 1 \implies \dim N(A - 4I) = 2 - 1 = 1.$$

几何重数 $1 <$ 代数重数 2，A **不可对角化**（它本身就是 $J_2(4)$）。

(b) $B = 4I$：$\operatorname{rank}(B-4I) = \operatorname{rank}(0) = 0$，$\dim N(B-4I) = 2$，几何重数 $2 =$ 代数重数，所以 B **可对角化**（B 已是 Λ，两个独立特征向量 e_1, e_2）。A 不可对角化、B 可对角化 $\Longrightarrow$ 它们的 Jordan 形不同（$J_2(4)$ vs. $J_1(4)\oplus J_1(4)$）$\Longrightarrow$ A **与** B **不相似**。（注意：$\operatorname{tr} = 8$、$\det = 16$、特征值 $\{4,4\}$ 全都相同，却仍不相似——这正说明这些量只是必要条件。）

(c) $C = \begin{bmatrix} 4 & 7 \\ 0 & 4 \end{bmatrix}$：$\operatorname{rank}(C-4I) = \operatorname{rank}\begin{bmatrix} 0 & 7 \\ 0 & 0 \end{bmatrix} = 1$，$\dim N(C-4I) = 1$，不可对角化。它的 Jordan 形也是**一个** 2×2 **块**：取 $M = \begin{bmatrix} 7 & 0 \\ 0 & 1 \end{bmatrix}$，由示例 (c) 的公式 $B = \begin{bmatrix} 4 & A_{12}/c \\ 0 & 4 \end{bmatrix}$（此处 $c = 7$）得

$$M^{-1}CM = \begin{bmatrix} 4 & 7/7 \\ 0 & 4 \end{bmatrix} = \begin{bmatrix} 4 & 1 \\ 0 & 4 \end{bmatrix} = J_2(4).$$

所以 C 与 A **相似**（两者都相似于同一个 $J_2(4)$，由传递性得 $A \sim C$）。✓

要点：判断相似，终极办法是**各自化到 Jordan 形再比较**（这是充要条件）；用 trace/det/特征值只能排除相似，不能证明相似。

补充：判断相似的可操作流程（做题模板）

```
第 1 步  算特征多项式 p(λ) = det(A − λI)，得到全部特征值 + 各自代数重数
         └ 若两者特征值（含重数）不同 → 直接判定"不相似"，结束
第 2 步  对每个特征值 λ 算 rank(A − λI)
         └ 几何重数 m_g(λ) = n − rank(A − λI)
         └ 若某个 λ 的 m_g < 代数重数 → 记为"缺陷"，该 λ 下有更大的块
第 3 步  排块：对每个 λ，块数 = m_g(λ)；
         最大块的大小 = 使 N((A−λI)^j) 稳定下来的最小 j（= 最小多项式中该因子的幂）
第 4 步  写出 Jordan 形，比较（不计块序）→ 相同则相似，不同则不相似

快速排除用（必要条件，不充分）：trace、det、秩、特征值、可对角化与否
充要判定用（第 4 步）：Jordan 形（或等价地：全部 λ 的"块大小分布"）
```

上表第 3 步里"最大块的大小"还有一个更常用、更好算的等价说法：它是 A 的**最小多项式**（minimal polynomial）中因子 $(\lambda-\lambda_0)$ 的幂次，也是使

$$\operatorname{rank}\big((A-\lambda_0 I)^j\big) = \operatorname{rank}\big((A-\lambda_0 I)^{j+1}\big)$$

成立的最小 j。举例：$J_2(4)$ 的最小多项式是 $(\lambda-4)^2$（最大块 2），而 $4I$ 的是 $(\lambda-4)$（最大块 1）；$J_3(5)$ 的是 $(\lambda-5)^3$，$J_1(5)\oplus J_2(5)$ 的是 $(\lambda-5)^2$。

Q2.（计算题：求几何重数与 Jordan 块结构） 设

$$A = \begin{bmatrix} 5 & 1 & 0 \\ 0 & 5 & 0 \\ 0 & 0 & 5 \end{bmatrix}, \qquad B = \begin{bmatrix} 5 & 1 & 0 \\ 0 & 5 & 1 \\ 0 & 0 & 5 \end{bmatrix}.$$

求各自特征值的代数重数与几何重数，写出 Jordan 形，并判断二者是否相似。

▸ **答案**

两个矩阵都是上三角、对角全 5，故 $p(\lambda) = (5-\lambda)^3$，$\lambda = 5$ 的**代数重数都是 3**。

对 A：

$$A - 5I = \begin{bmatrix} 0 & 1 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix}.$$

这一行的秩为 1（第 2、3 行全零）：$\operatorname{rank}(A-5I) = 1$，故

$$\dim N(A-5I) = 3 - 1 = 2 \quad (\text{几何重数 } 2).$$

解方程：只要求 $x_2 = 0$，x_1, x_3 自由，两个独立特征向量 $\begin{bmatrix}1\\0\\0\end{bmatrix}, \begin{bmatrix}0\\0\\1\end{bmatrix}$。**Jordan 形：块数 $= 2$，总共 3 维，故为一个 2×2 块加一个 1×1 块：**

$$J_A = J_1(5) \oplus J_2(5) = \begin{bmatrix}5 & 0 & 0\\ 0 & 5 & 1\\ 0 & 0 & 5\end{bmatrix}.$$

（注意：A 与 J_A 只差一个**置换相似** $J_A = PAP^{\mathsf{T}}$。枚举可知该置换不是简单的"交换第 2、3 行/列"——按 $(2,0,1)$ 循环置换（即行序 $1\to 2\to 3\to 1$）才能得到 $\begin{bmatrix}5 & 0 & 0\\ 0 & 5 & 1\\ 0 & 0 & 5\end{bmatrix}$。）

对 B：

$$B - 5I = \begin{bmatrix}0 & 1 & 0\\ 0 & 0 & 1\\ 0 & 0 & 0\end{bmatrix}, \qquad \operatorname{rank}(B-5I) = 2 \implies \dim N(B-5I) = 3 - 2 = 1.$$

几何重数 1 < 代数重数 3，B 不可对角化。Jordan 形：块数 $= 1$，即一个 3×3 块：

$$J_B = J_3(5) = \begin{bmatrix}5 & 1 & 0\\ 0 & 5 & 1\\ 0 & 0 & 5\end{bmatrix} = B \text{ 本身}.$$

结论：$J_A \neq J_B$（块的划分不同）$\implies$ **A 与 B 不相似**。尽管二者的 trace（15）、det（125）、特征值（$5,5,5$）完全一样，相似性仍不成立——差异体现在**几何重数（独立特征向量个数）**与**最小多项式**（A 的是 $(\lambda-5)^2$，B 的是 $(\lambda-5)^3$）上。

计数公式复核：块数 $= n - \operatorname{rank}(A-\lambda I)$：$A$ 是 $3-1=2$ ✓，B 是 $3-2=1$ ✓。

Q3.（概念题：相似的本质与 Jordan 形的定位） 判断下列说法对错并说明理由：(i) 若 $A \sim B$，则 A 与 B 有相同的特征向量；(ii) 若 A 与 B 有相同的 trace 和 det，则 $A \sim B$；(iii) 对称矩阵可能有缺陷（不可对角化）；(iv) 既然 Jordan 形能处理一切矩阵，数值软件就应该用它来算特征值。

▸ **答案**

(i) 错。 相似保持的是**特征值**，不保持特征向量。$B = M^{-1}AM$ 的特征向量是 A 的特征向量经坐标翻译 M^{-1} 后的结果：由 $A\mathbf{x} = \lambda\mathbf{x}$ 可得 $B(M^{-1}\mathbf{x}) = \lambda(M^{-1}\mathbf{x})$，所以 $\mathbf{x}_B = M^{-1}\mathbf{x}_A$，一般与 $\mathbf{x}_A$ 不同。示例 (a) 中 A 的 $\lambda = 3$ 特征向量 $[1,1]^{\mathsf{T}}$ 对应 B 的 $[0,1]^{\mathsf{T}}$，就是明证。

(ii) 错。 trace 与 det 只等于特征值之和与之积，它们相同只给出**必要条件**。反例就是 Q1 的 $A = J_2(4)$ 与 $B = 4I$：$\operatorname{tr} = 8$、$\det = 16$、特征值都是 $\{4,4\}$，但 A 不可对角化而 B 可对角化，二者不相似。反例还可取 Q2 的 A 与 B（trace 15、det 125 都相同，却不相似）。

(iii) 错。 实对称矩阵一定可对角化，而且能用**标准正交**特征向量对角化：$A = Q\Lambda Q^{\mathsf{T}}$（讲次 25 的谱定理）。更一般地，对称（或 Hermitian）矩阵的几何重数恒等于代数重数，永不缺陷——这是对称性带来的最大红利，也是"对称矩阵"在整个课程里格外受宠的原因。（注意：非对称矩阵若相似于对称矩阵，则它自己也是对称的——相似一般会破坏对称性。）

(iv) 错。 Jordan 形**数值上极不稳定**。例如 $J_2(4) = \begin{bmatrix}4 & 1\\ 0 & 4\end{bmatrix}$ 的下对角元被扰动 ε 后，特征值变为 $4 \pm \sqrt{\varepsilon}$：取 $\varepsilon = 10^{-10}$ 也会造成 10^{-5} 量级的偏移（扰动被开方放大）。**注意扰动的位置很关键**：$J_2(4)$ 是上三角，扰它的 $(1,2)$ 元特征值仍是 $4,4$（对角元即特征值）；只有扰**下三角**的 $(2,1)$ 元才会触发 $\sqrt{\varepsilon}$ 分裂，这正是"缺陷矩阵对特定方向扰动极端敏感"的体现；而且任何小扰动都会让"块结构"（上对角的 1）彻底消失。实际数值算法（如 QR 算法）计算的是 **Schur 分解** $A = QTQ^{\mathsf{T}}$（Q 正交、T 上三角），它在正交变换下数值稳定，条件数不受换基放大。**Jordan 形是理论分类工具（刻画相似类），不是数值计算工具。** 另外要记得：可对角化是"通例"，随机矩阵几乎必然可对角化，缺陷矩阵是测度零的特例——这也解释了为什么"缺陷"在理论课上重要、在数值课上却少见。

Lecture 29: Singular Value Decomposition

内容要点总览（本讲地图）

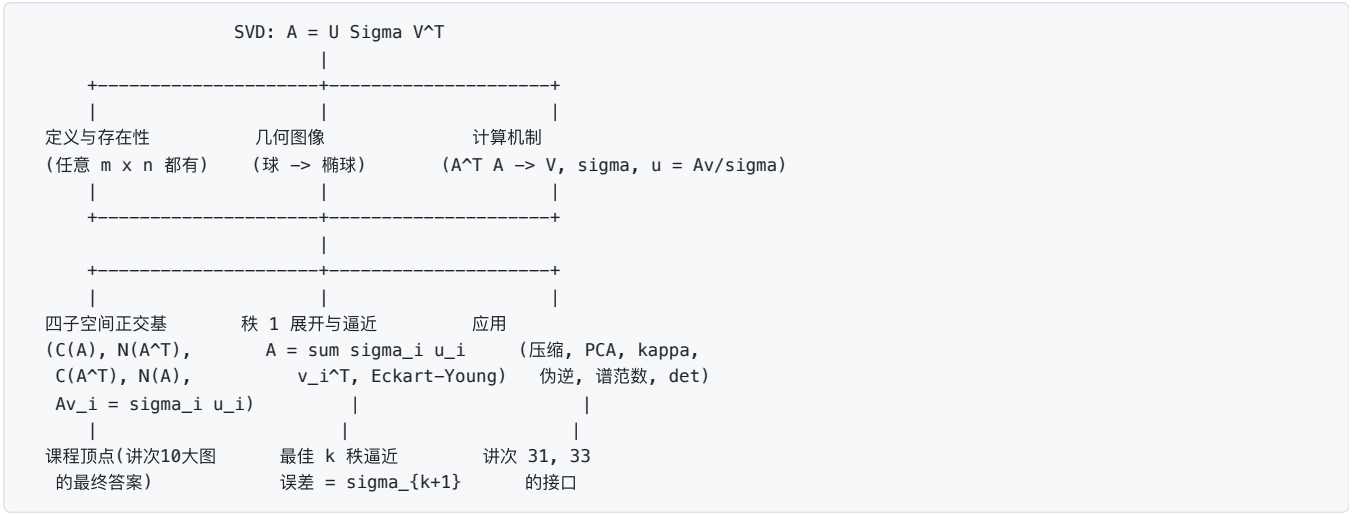

阅读建议：**几何直觉（第 2 节）→ 算法六步（第 3 节）→ 手算示例 1（务必自己动手算一遍）→ 四子空间图（第 4 节）→ 秩 1 展开**。只要把示例 1 的每一步算穿，SVD 就再没有秘密。

三条"必须背下来"的式子（本讲的全部枢纽）：

$$A\mathbf{v}_i = \sigma_i \mathbf{u}_i, \qquad \sigma_i = \sqrt{\lambda_i(A^{\mathsf{T}}A)}, \qquad A = \sum_{i=1}^{r} \sigma_i \mathbf{u}_i \mathbf{v}_i^{\mathsf{T}}.$$

第一条是**几何**（正交到正交、只伸缩），第二条是**算法**（怎么算出来），第三条是**结构**（怎么用、怎么逼近）。本讲余下所有内容都是这三条的展开与推论。

记号约定（全讲统一，请勿混用）：A 为 $m \times n$，$r = \mathbf{rank}(A)$；$\mathbf{u}_i \in \mathbb{R}^m$（长度 m，共 m 个），$\mathbf{v}_i \in \mathbb{R}^n$（长度 n，共 n 个）；σ_i 只有 $\min(m,n)$ 个，其中前 r 个为正、按降序排列；U 是 $m \times m$，V 是 $n \times n$，Σ 是 $m \times n$。A^{T} 表示转置。

概述

本讲是整个 18.06 的**高潮**。前面我们学过 $A = LU$（消元）、$A = QR$（正交化）、$A = S\Lambda S^{-1}$（对角化）。前三个分解都有前提：$A = S\Lambda S^{-1}$ 只对方阵、而且要**有足够多的线性无关特征向量**。本讲的 SVD（Singular Value Decomposition，奇异值分解） 把这一切统一起来：

> **任意 $m \times n$ 实矩阵 A**（不限方阵、不限秩、不要求可对角化）都可以写成
>
> $$A = U\Sigma V^{\mathsf{T}},$$
>
> 其中 U 是 $m \times m$ 正交矩阵，V 是 $n \times n$ 正交矩阵，Σ 是 $m \times n$ 的"对角"矩阵，对角线上是 $\sigma_1 \geq \sigma_2 \geq \cdots \geq \sigma_{\min(m,n)} \geq 0$。

SVD 回答的问题是：**任意一个线性变换，最本质地看，到底在做什么？** 答案是三件事的空前简单的组合：**换一组正交方向（V^{T}）→ 沿坐标轴拉伸（Σ）→ 再换一组正交方向（U）**。它给出四个基本子空间（讲次 10 的"大图"）**最完美的标准正交基**，也是图像压缩、PCA、数据降维、数值稳定性分析的统一语言。

核心概念的几何直觉

奇异值分解 $A = U\Sigma V^{\mathsf{T}}$

- **定义与目的**：设 A 是 $m \times n$ 实矩阵，$\mathbf{rank}(A) = r$。则存在正交矩阵 U（$m \times m$）与 V（$n \times n$），使 $A = U\Sigma V^{\mathsf{T}}$，其中

$$\Sigma = \begin{bmatrix} \sigma_1 & & & \\ & \sigma_2 & & \\ & & \ddots & \\ & & & \sigma_{\min(m,n)} \end{bmatrix} \ (\text{超出部分为 } 0),$$

且 $\sigma_1 \geq \sigma_2 \geq \cdots \geq \sigma_r > 0$，$\sigma_{r+1} = \cdots = \sigma_{\min(m,n)} = 0$。 – U 的列向量 $\mathbf{u}_1, \ldots, \mathbf{u}_m \in \mathbb{R}^m$ 叫**左奇异向量（left singular vectors）**； – V 的列向量 $\mathbf{v}_1, \ldots, \mathbf{v}_n \in \mathbb{R}^n$ 叫**右奇异向量（right singular vectors）**； – σ_i 叫**奇异值（singular values）**。

等价地，把上式右乘 V（用 $V^{\mathsf{T}}V = I$）得到**最本质的三条关系**：

$$A\mathbf{v}_i = \sigma_i \mathbf{u}_i \quad (i = 1, \ldots, r), \qquad A\mathbf{v}_i = \mathbf{0} \quad (i > r).$$

这三条就是 SVD 的全部内容。它说的是：A 把 V 的一组正交方向，**原样地、不扭曲地**映成 U 的一组正交方向，只做伸缩，伸缩倍数就是 σ_i。

- **几何直觉（它在空间中是什么样子？）**：任何矩阵都"怕"一般的输入方向——给一个随机向量 $\mathbf{x}$，$A\mathbf{x}$ 的长度和方向都看不出规律。但每个矩阵都有**一组特殊方向**，沿着它们矩阵只做纯粹的拉伸，不做旋转。把这些方向找出来，矩阵就"变成"了对角矩阵。
- **具体示例**：取 $A = \begin{bmatrix} 3 & 0 \\ 4 & 5 \end{bmatrix}$。它的 SVD 是

$$U = \frac{1}{\sqrt{10}}\begin{bmatrix} 1 & 3 \\ 3 & -1 \end{bmatrix}, \quad \Sigma = \begin{bmatrix} 3\sqrt{5} & 0 \\ 0 & \sqrt{5} \end{bmatrix}, \quad V = \frac{1}{\sqrt{2}}\begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}.$$

验算 $A\mathbf{v}_1 = \sigma_1 \mathbf{u}_1$：$\mathbf{v}_1 = \frac{1}{\sqrt{2}}[1,1]^{\mathsf{T}}$，$A\mathbf{v}_1 = \frac{1}{\sqrt{2}}[3,9]^{\mathsf{T}} = \frac{3}{\sqrt{2}}[1,3]^{\mathsf{T}}$，而 $\sigma_1 \mathbf{u}_1 = 3\sqrt{5} \cdot \frac{1}{\sqrt{10}}[1,3]^{\mathsf{T}} = \frac{3}{\sqrt{2}}[1,3]^{\mathsf{T}}$。两边完全一样。✓

几何图像：单位圆 → 椭圆

矩阵作为线性变换，最漂亮的刻画就是看它把**单位球**变成什么。SVD 说：单位球一定被变成一个**椭球**，而且椭球的**半轴长恰好是奇异值，半轴方向恰好是左奇异向量**。

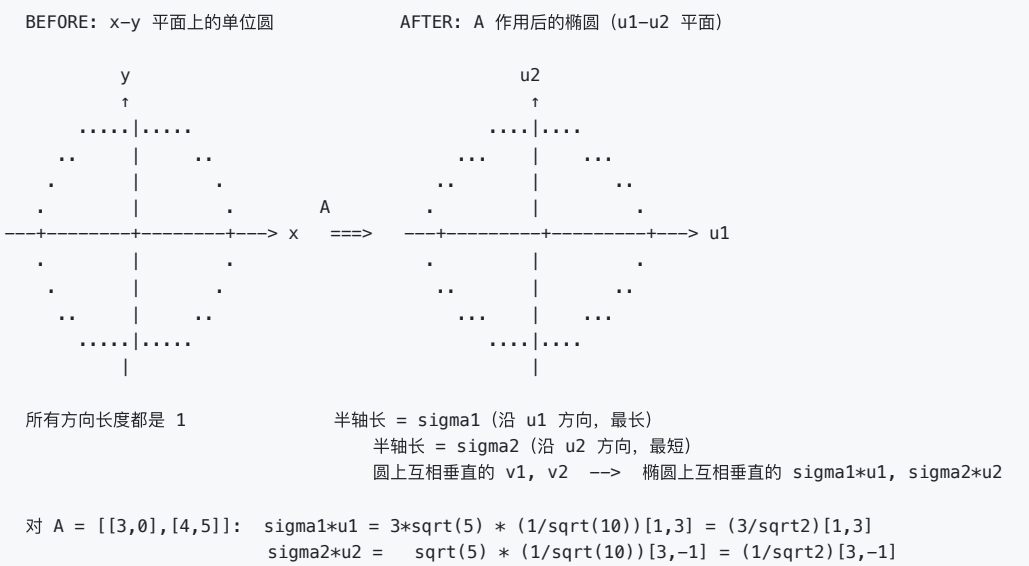

把 $A = U\Sigma V^{\mathsf{T}}$ 读成"三步动作"

矩阵乘法从右往左作用（讲次 1、30 的观点：矩阵就是线性变换）。$A = U\Sigma V^{\mathsf{T}}$ 说，A 这个变换可以拆成三个极简单的动作依次执行：

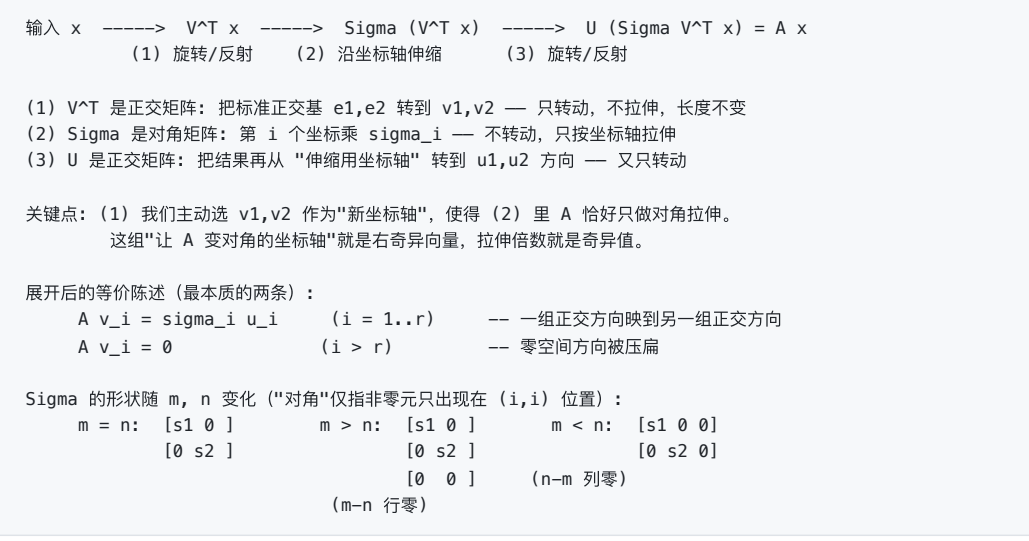

关键结论：单位球 $\{\mathbf{x} : \|\mathbf{x}\| = 1\}$ 的像是一个椭球，其半轴长为 $\sigma_1, \ldots, \sigma_r$，半轴方向为 $\mathbf{u}_1, \ldots, \mathbf{u}_r$。$\sigma_1$ 就是 A 能拉出的**最长长度**，也就是 $\max_{\|\mathbf{x}\|=1} \|A\mathbf{x}\|$ —— 这正是**谱范数** $\|A\|_2$ 的定义（见"应用"一节）。

特征值 vs 奇异值：两种"特殊方向"

- **特征值**问的是：哪些方向**方向不变**，只有 $A\mathbf{x} = \lambda\mathbf{x}$？
- 缺点：这样的方向**可能一个都不存在**（如实数域下的旋转矩阵 $\begin{bmatrix} 0 & -1 \\ 1 & 0 \end{bmatrix}$，特征值是 $\pm i$），而且非对称矩阵的特征向量**一般不正交**。
- **奇异值**问的是：哪些方向被**拉得最长**？$A\mathbf{v}_i = \sigma_i \mathbf{u}_i$，输入方向 $\mathbf{v}_i$ 与输出方向 $\mathbf{u}_i$ **允许不同**，代价是换来两个正交组。

- 优点：**总是存在**，总是实数，非负，且 $\mathbf{v}_i$ 之间正交、$\mathbf{u}_i$ 之间正交。这就是 SVD 比对角化"强"的根本原因。

对比表格：

```
                    特征值分解 A = S Λ S^{-1}              奇异值分解 A = U Σ V^T
适用矩阵            方阵，且可对角化（需 n 个无关特征向量）    任意 m x n 矩阵，无条件
向量关系            A x = lambda x（输入=输出方向）          A v_i = sigma_i u_i（输入≠输出）
正交性              S 一般不正交（除非 A 对称/正规）         U, V 一定正交
数值/实数性         特征值可为负、可为复数                  奇异值一定非负实数
存在性              可能失败（如 [[1,1],[0,1]] 缺特征向量）  永远不会失败
```

σ_i 与 A^TA、AA^T 的关系（这是全部计算的基础）

把 $A = U\Sigma V^T$ 代入两个"Gram 矩阵"：

$$A^TA = V\Sigma^TU^TU\Sigma V^T = V(\Sigma^T\Sigma)V^T, \qquad AA^T = U(\Sigma\Sigma^T)U^T.$$

注意 $\Sigma^T\Sigma$ 是 $n\times n$ 对角矩阵，对角元是 $\sigma_1^2,\dots,\sigma_{\min}^2$ 后面补 0（若 $n>m$ 则补 $n-m$ 个 0）；$\Sigma\Sigma^T$ 是 $m\times m$ 对角矩阵，对角元是 $\sigma_1^2,\dots,\sigma_{\min}^2$ 后面补 0（若 $m>n$ 则补 $m-n$ 个 0）。于是：

- A^TA 是 $n\times n$ **对称半正定**矩阵（讲次 25），它**可以正交对角化**，而 V 正是它的正交特征向量矩阵，对角矩阵 $\Sigma^T\Sigma$ 的对角元是它的特征值：

$$\boxed{\sigma_i = \sqrt{\lambda_i(A^TA)}, \qquad \mathbf{v}_i \text{ 是 } A^TA \text{ 的单位特征向量.}}$$

因为 A^TA 半正定（$\mathbf{x}^TA^TA\mathbf{x} = \|A\mathbf{x}\|^2 \ge 0$），它的特征值 $\lambda_i \ge 0$，开方合法。 – 同理 AA^T 是 $m\times m$ 对称半正定，**U 是它的正交特征向量矩阵**，特征值同样是 σ_i^2：

$$AA^T\mathbf{u}_i = \sigma_i^2\mathbf{u}_i.$$

- 两个矩阵的非零特征值**完全一样**，都是 $\sigma_1^2,\dots,\sigma_r^2$（各 r 个），剩下的都是 0。因为 $\mathbf{rank}(A^TA) = \mathbf{rank}(A) = \mathbf{rank}(AA^T)$（讲次 10 的"行秩 = 列秩"！）。**这是行秩等于列秩的又一个独立证明**。
- 若已知 $\mathbf{v}_i$ 与 $\sigma_i \neq 0$，则

$$\boxed{\mathbf{u}_i = \frac{A\mathbf{v}_i}{\sigma_i}.}$$

推导：$A\mathbf{v}_i = \sigma_i\mathbf{u}_i$，两边除以 σ_i。这个式子说明**左奇异向量不必单独求**，它自动就是 $A\mathbf{v}_i$ 归一化的结果。

SVD 不唯一：符号与重奇异值的自由度（做题必须知道）

$A = U\Sigma V^T$ 中的 U,Σ,V **不是唯一的**： – **符号自由**：把某一对 $(\mathbf{u}_i,\mathbf{v}_i)$ **同时**取负，乘积 $\sigma_i\mathbf{u}_i\mathbf{v}_i^T$ 不变（两个负号相乘抵消），所以 A 不变。因此"$\mathbf{u}_1$ 取哪个方向"没有绝对答案，只要和 $\mathbf{v}_1$ 配对一致就行。示例 2 里 $V = I$ 只是一种方便的选择。 – **重奇异值自由**：若 $\sigma_i = \sigma_{i+1}$，则对应的 $\mathbf{v}_i,\mathbf{v}_{i+1}$ 可以在它们张成的二维子空间里**任意旋转**，$\mathbf{u}_i,\mathbf{u}_{i+1}$ 同步旋转，A 仍不变（示例 2 中 $\sigma_1=\sigma_2=\sqrt{2}$，$A^TA = 2I$，任意标准正交基都行）。几何上：单位圆被映成**圆**，圆没有"最长半轴"，方向无从指定。 – **零奇异值自由**：$N(A)$ 与 $N(A^T)$ 的基可以任意选取（示例 2 的 $\mathbf{u}_3 = [0,0,1]^T$ 只是最方便的那一个）。 – **不变的量**：奇异值本身 $\sigma_1,\dots,\sigma_r$ **唯一确定**（它们由 A 唯一决定，是 A 的"指纹"）；$C(A)$、$N(A)$ 等子空间也唯一确定（只是基不唯一）。所以**判断题问"σ_i 是多少""秩是多少"总有唯一答案；问"$\mathbf{u}_1$ 是多少"必须接受符号/旋转的等价类。** 答题时最好写出验证（$U^TU = I$、$U\Sigma V^T = A$），而不纠结于"标准答案"长什么样。

SVD 与 QR：一个重要对比

QR（讲次 17）和 SVD 都给出正交基，但目标不同：

```
A = Q R          Q 的列是 C(A) 的一组标准正交基（Gram-Schmidt 得到，依赖列的先后顺序）
                 R 是上三角，不是对角 —— 在 Q 的基下 A 仍然"耦合"，没被对角化

A = U Sigma V^T  U 的列是 C(A) 的"最优"标准正交基（按拉伸大小排序，即 u1 最重要）
                 V 的列是 C(A^T) 的标准正交基，与 U 逐对配对
                 Sigma 是对角 —— 在正确的两组基下 A 彻底对角化

代价：QR 便宜（约 2mn^2 运算），SVD 贵得多；收获：SVD 给出谱信息（sigma_i）、正交两组基、最佳低秩逼近
```

计算步骤与手算演示

算法：2×2（以及一般 $m\times n$）的 SVD 六步法

1. 计算 A^TA（$n\times n$ 对称半正定）。
2. 求 A^TA 的特征值 $\lambda_1 \ge \lambda_2 \ge \cdots \ge \lambda_n \ge 0$。
3. 2×2 用迹与行列式最快：$\lambda^2 - \mathbf{tr}(A^TA)\lambda + \det(A^TA) = 0$。

4. 3×3 先试 $\det(A^{\mathsf T}A-\lambda I)=0$，或先找一眼能看出的特征向量（如某行/列全零时标准基向量常常就是特征向量）。
5. 因为 $\operatorname{tr}(A^{\mathsf T}A)=\sum_{i,j}a_{ij}^2=\|A\|_F^2$，所以**全部特征值之和 = $\|A\|_F^2$**，这是一条极好的自查式（示例 1：$45+5=50=\|A\|_F^2$ ✓）。另一条自查：$\prod\lambda_i=\det(A^{\mathsf T}A)=(\det A)^2$（方阵）。
6. 求对应的**标准正交**特征向量 $\mathbf{v}_1,\dots,\mathbf{v}_n$（不同特征值自动正交；重特征值内部用 Gram–Schmidt 挑一组正交的，自由度任意）。它们构成 V。
7. 令 $\sigma_i=\sqrt{\lambda_i}$，按降序排列，填入 Σ（$m\times n$ 形状，多余位置填 0）。
8. 对每个 $\sigma_i\neq 0$，令 $\mathbf{u}_i=A\mathbf{v}_i/\sigma_i$（自动单位长、自动正交）。若 $r<m$，再补 $m-r$ 个与已有 $\mathbf{u}$ 正交的单位向量（一般取 $N(A^{\mathsf T})$ 的基，可用 Gram–Schmidt 或直接观察），凑满 U 的 m 列。
9. 补列的小技巧：若 $r<m$，往往能"看"出 $N(A^{\mathsf T})$ 的基（解 $A^{\mathsf T}\mathbf{y}=\mathbf{0}$），再对它做 Gram–Schmidt（讲次 17）就得到正交补的基。
10. 同理，如果某些 $\lambda_i=0$（即 $r<n$），$\mathbf{v}_{r+1},\dots,\mathbf{v}_n$ 本身就是 $N(A)$ 的标准正交基，不必另求。
11. 拼装 U、Σ、V，并**回代验证 $U\Sigma V^{\mathsf T}=A$**。

【计算机制解说】为什么"求 $A^{\mathsf T}A$ 的特征向量"能给出 V？ 因为 $A^{\mathsf T}A=V(\Sigma^{\mathsf T}\Sigma)V^{\mathsf T}$ 本身就是 $A^{\mathsf T}A$ 的正交对角化式。$A^{\mathsf T}A$ 是对称矩阵，谱定理（讲次 25）保证它一定能被正交对角化，且特征值全 ≥ 0。对比之下，直接对 A 求特征值会遇到"可能无实特征向量、特征向量不正交"的麻烦。**SVD 把关于 A 的困难问题，转化成了关于对称矩阵 $A^{\mathsf T}A$ 的容易问题** —— 这就是整个算法的灵魂。代价是"开了平方"，所以特征值 λ_i 与奇异值 σ_i 并不是同一个东西。

【计算机制解说（数值版）】理论上"$\sigma_i=\sqrt{\lambda_i(A^{\mathsf T}A)}$"是定义，但**工业代码从不真的去算 $A^{\mathsf T}A$**，原因是精度：$A^{\mathsf T}A$ 的条件数是 A 的**平方**（$\kappa(A^{\mathsf T}A)=\kappa(A)^2$），若 A 本身已经病态，形成 $A^{\mathsf T}A$ 会把有效位数损失一半（如 $\sigma_3=0.01$ 时 $\lambda_3=10^{-4}$，小特征值会在浮点减法中被吞掉）。实用的 SVD 算法是 **Golub–Kahan 双对角化**：用两组 Householder 变换（讲次 17 的正交化思想）把 A 化成双对角形，再对双对角矩阵做迭代对角化，全程只用正交变换（**正交变换不放大误差**，这是 SVD 数值上极稳健的根本原因）。本讲的"$A^{\mathsf T}A$ 路线"是**理解路线**——它把存在性和四子空间结构讲清楚了；而实际算 U,Σ,V 有更好的算法。两者结论完全一致。

示例 1（主演示）：$A=\begin{bmatrix}3&0\\4&5\end{bmatrix}$ 的完整 SVD

步骤 1：算 $A^{\mathsf T}A$。

$$A^{\mathsf T}=\begin{bmatrix}3&4\\0&5\end{bmatrix},\qquad A^{\mathsf T}A=\begin{bmatrix}3&4\\0&5\end{bmatrix}\begin{bmatrix}3&0\\4&5\end{bmatrix}=\begin{bmatrix}3\cdot3+4\cdot4&3\cdot0+4\cdot5\\0\cdot3+5\cdot4&0\cdot0+5\cdot5\end{bmatrix}=\begin{bmatrix}25&20\\20&25\end{bmatrix}.$$

步骤 2：求特征值。 $\operatorname{tr}(A^{\mathsf T}A)=50$，$\det(A^{\mathsf T}A)=25\cdot25-20\cdot20=625-400=225$。特征多项式

$$\lambda^2-50\lambda+225=0.$$

因式分解：$45+5=50$，$45\times5=225$，故

$$\lambda^2-50\lambda+225=(\lambda-45)(\lambda-5)=0\quad\Longrightarrow\quad\lambda_1=45,\ \lambda_2=5.$$

（如果看不出来，就用求根公式：$\lambda=\frac{50\pm\sqrt{2500-900}}{2}=\frac{50\pm\sqrt{1600}}{2}=\frac{50\pm40}{2}=45$ 或 5。）

步骤 3：求特征向量，得到 V。 – 对 $\lambda_1=45$：$(A^{\mathsf T}A-45I)\mathbf{v}=\begin{bmatrix}-20&20\\20&-20\end{bmatrix}\mathbf{v}=\mathbf{0}\Rightarrow v_1=v_2$，取 $\mathbf{v}_1=\frac{1}{\sqrt2}\begin{bmatrix}1\\1\end{bmatrix}$。 – 对 $\lambda_2=5$：$\begin{bmatrix}20&20\\20&20\end{bmatrix}\mathbf{v}=\mathbf{0}\Rightarrow v_1=-v_2$，取 $\mathbf{v}_2=\frac{1}{\sqrt2}\begin{bmatrix}1\\-1\end{bmatrix}$。 – 两者点积 $\frac12(1-1)=0$ ✓（对称矩阵不同特征值的特征向量自动正交，这里再确认一次）。

于是

$$V=[\mathbf{v}_1\quad\mathbf{v}_2]=\frac{1}{\sqrt2}\begin{bmatrix}1&1\\1&-1\end{bmatrix},\qquad V^{\mathsf T}V=\frac12\begin{bmatrix}1&1\\1&-1\end{bmatrix}\begin{bmatrix}1&1\\1&-1\end{bmatrix}=\begin{bmatrix}1&0\\0&1\end{bmatrix}\checkmark$$

步骤 4：奇异值。

$$\sigma_1=\sqrt{45}=\sqrt{9\cdot5}=3\sqrt5\approx6.7082,\qquad\sigma_2=\sqrt5\approx2.2361.$$

$$\Sigma=\begin{bmatrix}3\sqrt5&0\\0&\sqrt5\end{bmatrix}.$$

步骤 5：用 $\mathbf{u}_i=A\mathbf{v}_i/\sigma_i$ 求 U。

$$A\mathbf{v}_1=\frac{1}{\sqrt2}\begin{bmatrix}3&0\\4&5\end{bmatrix}\begin{bmatrix}1\\1\end{bmatrix}=\frac{1}{\sqrt2}\begin{bmatrix}3\\9\end{bmatrix}=\frac{3}{\sqrt2}\begin{bmatrix}1\\3\end{bmatrix},$$

$$\mathbf{u}_1=\frac{A\mathbf{v}_1}{\sigma_1}=\frac{3/\sqrt2}{3\sqrt5}\begin{bmatrix}1\\3\end{bmatrix}=\frac{1}{\sqrt2\sqrt5}\begin{bmatrix}1\\3\end{bmatrix}=\frac{1}{\sqrt{10}}\begin{bmatrix}1\\3\end{bmatrix}\approx\begin{bmatrix}0.3162\\0.9487\end{bmatrix}.$$

$$A\mathbf{v}_2 = \frac{1}{\sqrt{2}}\begin{bmatrix}3 & 0\\ 4 & 5\end{bmatrix}\begin{bmatrix}1\\ -1\end{bmatrix} = \frac{1}{\sqrt{2}}\begin{bmatrix}3\\ -1\end{bmatrix},$$

$$\mathbf{u}_2 = \frac{A\mathbf{v}_2}{\sigma_2} = \frac{1/\sqrt{2}}{\sqrt{5}}\begin{bmatrix}3\\ -1\end{bmatrix} = \frac{1}{\sqrt{10}}\begin{bmatrix}3\\ -1\end{bmatrix} \approx \begin{bmatrix}0.9487\\ -0.3162\end{bmatrix}.$$

步骤 6：组装并验证。

$$U = \frac{1}{\sqrt{10}}\begin{bmatrix}1 & 3\\ 3 & -1\end{bmatrix}, \qquad \Sigma = \begin{bmatrix}3\sqrt{5} & 0\\ 0 & \sqrt{5}\end{bmatrix}, \qquad V = \frac{1}{\sqrt{2}}\begin{bmatrix}1 & 1\\ 1 & -1\end{bmatrix}.$$

先检查 U 正交：列长 $\frac{1+9}{10} = 1$ ✓；点积 $\frac{3-3}{10} = 0$ ✓；$\det U = \frac{-1-9}{10} = -1$，是反射不是旋转（没关系，正交即可）。

验证 $U\Sigma V^{\mathsf{T}} = A$。中间量：

$$U\Sigma = \frac{1}{\sqrt{10}}\begin{bmatrix}1 & 3\\ 3 & -1\end{bmatrix}\begin{bmatrix}3\sqrt{5} & 0\\ 0 & \sqrt{5}\end{bmatrix} = \frac{1}{\sqrt{10}}\begin{bmatrix}3\sqrt{5} & 3\sqrt{5}\\ 9\sqrt{5} & -\sqrt{5}\end{bmatrix} = \frac{1}{\sqrt{2}}\begin{bmatrix}3 & 3\\ 9 & -1\end{bmatrix}$$

（用了 $\frac{3\sqrt{5}}{\sqrt{10}} = 3\sqrt{\frac{5}{10}} = \frac{3}{\sqrt{2}}$，$\frac{9\sqrt{5}}{\sqrt{10}} = \frac{9}{\sqrt{2}}$，$\frac{\sqrt{5}}{\sqrt{10}} = \frac{1}{\sqrt{2}}$。）

再乘 $V^{\mathsf{T}} = \frac{1}{\sqrt{2}}\begin{bmatrix}1 & 1\\ 1 & -1\end{bmatrix}$：

$$(U\Sigma)V^{\mathsf{T}} = \frac{1}{2}\begin{bmatrix}3 & 3\\ 9 & -1\end{bmatrix}\begin{bmatrix}1 & 1\\ 1 & -1\end{bmatrix} = \frac{1}{2}\begin{bmatrix}3+3 & 3-3\\ 9-1 & 9+1\end{bmatrix} = \frac{1}{2}\begin{bmatrix}6 & 0\\ 8 & 10\end{bmatrix} = \begin{bmatrix}3 & 0\\ 4 & 5\end{bmatrix} = A \checkmark$$

附带数值验证（全部一致）：

量	用 σ 算	用 A 直接算
$\|A\|_F^2$	$\sigma_1^2 + \sigma_2^2 = 45 + 5 = 50$	$9 + 0 + 16 + 25 = 50$ ✓
$\|\det A\|$	$\sigma_1\sigma_2 = 3\sqrt{5}\cdot\sqrt{5} = 15$	$\|3\cdot 5 - 0\cdot 4\| = 15$ ✓
$\|A\|_2$	$\sigma_1 = 3\sqrt{5} \approx 6.7082$	$\max_{\|\mathbf{x}\|=1}\|A\mathbf{x}\|$ ✓
条件数 κ	$\sigma_1/\sigma_2 = 3\sqrt{5}/\sqrt{5} = 3$	—

【计算机制解说】为什么 $\|A\|_F^2 = \sum\sigma_i^2$ 和 $|\det A| = \prod\sigma_i$ 会自动成立？ 因为正交矩阵不改变长度和体积！
$\|A\|_F^2 = \|U\Sigma V^{\mathsf{T}}\|_F^2 = \|\Sigma\|_F^2 = \sum\sigma_i^2$（Frobenius 范数在乘正交矩阵下不变，讲次 14 的正交变换保长），而
$\det A = \det U\cdot\det\Sigma\cdot\det V^{\mathsf{T}} = (\pm 1)\cdot\prod\sigma_i\cdot(\pm 1)$，所以 $|\det A| = \prod_{i=1}^{n}\sigma_i$（方阵情形）。**换句话说：SVD 把 A 的"总能量"和"体积放大率"干净地拆成了各个方向贡献的平方和与乘积**，这正是讲次 20 行列式几何意义（体积）与 SVD 的接口。

示例 2（非方阵）：$A = \begin{bmatrix}1 & 1\\ 1 & -1\\ 0 & 0\end{bmatrix}$（$3\times 2$，秩 2）

这个例子的意义在于：A 不是方阵，**根本没有特征值可言**，但 SVD 照样存在。

步骤 1： $A^{\mathsf{T}} = \begin{bmatrix}1 & 1 & 0\\ 1 & -1 & 0\end{bmatrix}$，

$$A^{\mathsf{T}}A = \begin{bmatrix}1 & 1 & 0\\ 1 & -1 & 0\end{bmatrix}\begin{bmatrix}1 & 1\\ 1 & -1\\ 0 & 0\end{bmatrix} = \begin{bmatrix}1+1+0 & 1-1+0\\ 1-1+0 & 1+1+0\end{bmatrix} = \begin{bmatrix}2 & 0\\ 0 & 2\end{bmatrix} = 2I.$$

步骤 2： 特征值 $\lambda_1 = \lambda_2 = 2$（重根，$A^{\mathsf{T}}A = 2I$ 已经是"对角"的）。

步骤 3： $A^{\mathsf{T}}A = 2I$ 有一个特点：**任意一组标准正交向量都是它的特征向量**（因为 $2I\mathbf{v} = 2\mathbf{v}$ 对一切 $\mathbf{v}$ 成立）。所以 V 不唯一！最方便的选择就是标准基：

$$\mathbf{v}_1 = \begin{bmatrix}1\\ 0\end{bmatrix}, \qquad \mathbf{v}_2 = \begin{bmatrix}0\\ 1\end{bmatrix}, \qquad V = I_2.$$

（这就是"重奇异值 $\Longrightarrow$ 奇异向量不唯一"的典型：单位圆被 A 映成一个**圆**，而不是椭圆，因为 $\sigma_1 = \sigma_2$。）

步骤 4： $\sigma_1 = \sigma_2 = \sqrt{2} \approx 1.4142$。

步骤 5：

$$\mathbf{u}_1 = \frac{A\mathbf{v}_1}{\sigma_1} = \frac{1}{\sqrt{2}}\begin{bmatrix}1\\1\\0\end{bmatrix} \approx \begin{bmatrix}0.7071\\0.7071\\0\end{bmatrix}, \qquad \mathbf{u}_2 = \frac{A\mathbf{v}_2}{\sigma_2} = \frac{1}{\sqrt{2}}\begin{bmatrix}1\\-1\\0\end{bmatrix} \approx \begin{bmatrix}0.7071\\-0.7071\\0\end{bmatrix}.$$

点积 $\frac{1}{2}(1-1+0)=0$ ✓。现在 U 是 3×3，还差第三列。它必须与 $\mathbf{u}_1, \mathbf{u}_2$ 都正交，且是单位向量。观察：$\mathbf{u}_1, \mathbf{u}_2$ 的第三分量都是 0，所以 $\mathbf{u}_3 = \begin{bmatrix}0\\0\\1\end{bmatrix}$ 天然满足 $\mathbf{u}_1^{\mathsf{T}}\mathbf{u}_3 = \mathbf{u}_2^{\mathsf{T}}\mathbf{u}_3 = 0$，长度 1 ✓。（它张成的正是 $N(A^{\mathsf{T}})$：$A^{\mathsf{T}}\mathbf{u}_3 = \begin{bmatrix}1&1&0\\1&-1&0\end{bmatrix}\begin{bmatrix}0\\0\\1\end{bmatrix} = \mathbf{0}$ ✓）

$$\Sigma = \begin{bmatrix}\sqrt{2}&0\\0&\sqrt{2}\\0&0\end{bmatrix} \ (3\times 2).$$

步骤 6：验证。 $\mathbf{u}_3$ 那一行对应 Σ 的第三行全 0，所以 $U\Sigma$ 的第三行是 0：

$$U\Sigma = \begin{bmatrix}1/\sqrt{2}&1/\sqrt{2}&0\\1/\sqrt{2}&-1/\sqrt{2}&0\\0&0&1\end{bmatrix}\begin{bmatrix}\sqrt{2}&0\\0&\sqrt{2}\\0&0\end{bmatrix} = \begin{bmatrix}1&1\\1&-1\\0&0\end{bmatrix}.$$

由于 $V = I$，$V^{\mathsf{T}} = I$，故 $U\Sigma V^{\mathsf{T}} = U\Sigma = A$ ✓。

结论： $\mathbf{rank}(A) = 2$，恰等于**非零奇异值的个数**（两个 $\sqrt{2}$）；$m - r = 1$ 个零行对应 $N(A^{\mathsf{T}})$，$n - r = 0$ 个零列对应 $N(A) = \{\mathbf{0}\}$。

【计算机制解说】为什么"非零奇异值的个数 = 秩"？ 由 $A^{\mathsf{T}}A = V(\Sigma^{\mathsf{T}}\Sigma)V^{\mathsf{T}}$，$A^{\mathsf{T}}A$ 与 $\Sigma^{\mathsf{T}}\Sigma$ **相似（其实是正交相似）**，因此秩相同。$\Sigma^{\mathsf{T}}\Sigma$ 的非零元个数正好是 $\sigma_i \neq 0$ 的个数，而 $\mathbf{rank}(A^{\mathsf{T}}A) = \mathbf{rank}(A)$（因为 $A\mathbf{x} = \mathbf{0} \iff A^{\mathsf{T}}A\mathbf{x} = \mathbf{0}$：一边显然，另一边由 $\|A\mathbf{x}\|^2 = \mathbf{x}^{\mathsf{T}}A^{\mathsf{T}}A\mathbf{x} = 0$ 得到，见讲次 10、16）。所以

$$\boxed{\mathbf{rank}(A) = \#\{i : \sigma_i > 0\}.}$$

这是一个**可以数值使用的秩定义**：数值计算中"零"永远不精确，人们就看"有多少个 σ_i 大于容差"，这比数主元个数稳定得多。

示例 3（警示例）： $A = \begin{bmatrix}0&2\\0&0\end{bmatrix}$ —— **特征值全是 0，奇异值却是 2 和 0**

$$A^{\mathsf{T}}A = \begin{bmatrix}0&0\\2&0\end{bmatrix}\begin{bmatrix}0&2\\0&0\end{bmatrix} = \begin{bmatrix}0&0\\0&4\end{bmatrix}.$$

特征值：$\lambda^2 - 4\lambda = \lambda(\lambda-4) = 0 \Rightarrow \lambda_1 = 4,\ \lambda_2 = 0$。故 $\sigma_1 = 2,\ \sigma_2 = 0$。

- A 自己的特征值：$\det(A - \lambda I) = \lambda^2 = 0$，$\lambda_1 = \lambda_2 = 0$（**重根，且 A 只有一维特征向量 $\mathbf{x} = [1,0]^{\mathsf{T}}$，不可对角化**，讲次 28 的缺陷矩阵）。
- 如果以为"$\sigma_i = |\lambda_i|$"，就会得到 $\sigma_1 = \sigma_2 = 0$，从而误判 $\mathbf{rank}(A) = 0$。**大错**：$A \neq 0$，$\mathbf{rank}(A) = 1$，$\sigma_1 = 2$。

$\mathbf{v}_1 = [0,1]^{\mathsf{T}}$（对应 $\lambda_1 = 4$），$\mathbf{u}_1 = A\mathbf{v}_1/2 = [2,0]^{\mathsf{T}}/2 = [1,0]^{\mathsf{T}}$；$\mathbf{u}_2 = [0,1]^{\mathsf{T}}$。验证 $A = U\Sigma V^{\mathsf{T}}$：$\Sigma = \mathbf{diag}(2,0)$，$U = \begin{bmatrix}1&0\\0&1\end{bmatrix}$，$V = \begin{bmatrix}0&1\\1&0\end{bmatrix}$，$U\Sigma V^{\mathsf{T}} = \begin{bmatrix}2&0\\0&0\end{bmatrix}\begin{bmatrix}0&1\\1&0\end{bmatrix} = \begin{bmatrix}0&2\\0&0\end{bmatrix} = A$ ✓。

这个例子一条教训：奇异值衡量的是"**拉伸能力**"，特征值衡量的是"**方向不变性**"。A 把 $[0,1]^{\mathsf{T}}$ 拉成 $[2,0]^{\mathsf{T}}$（长度 2），但它没有任何非零特征值。**除非 A 是对称（或更一般的正规）矩阵，$\sigma_i \neq |\lambda_i|$。**

示例 4（对称情形对照）： $A = \begin{bmatrix}2&1\\1&2\end{bmatrix}$

$A^{\mathsf{T}}A = \begin{bmatrix}5&4\\4&5\end{bmatrix}$，$\lambda^2 - 10\lambda + 9 = (\lambda-9)(\lambda-1) = 0$，故 $\sigma_1 = 3,\ \sigma_2 = 1$。而 A 自己的特征值是 3 和 1 —— **完全一样**（$\mathbf{v}_1 = \frac{1}{\sqrt{2}}[1,1]^{\mathsf{T}}$，$\mathbf{u}_1 = A\mathbf{v}_1/3 = \frac{1}{3\sqrt{2}}[3,3]^{\mathsf{T}} = \frac{1}{\sqrt{2}}[1,1]^{\mathsf{T}} = \mathbf{v}_1$）。

一般结论：A **对称** $\Rightarrow A = Q\Lambda Q^{\mathsf{T}}$，**所以** $\sigma_i = |\lambda_i|$，**且** $\mathbf{u}_i = \pm\mathbf{v}_i$（差的只是符号，因为负特征值要求 $A\mathbf{v}_i = \lambda_i\mathbf{v}_i$ 而 $\sigma_i > 0$，$\mathbf{u}_i$ 要翻个号）。这就是为什么"$\sigma = |\lambda|$"只在对称/正规时成立。

矩阵分解的核心思想

本讲的主角分解就是 $A = U\Sigma V^{\mathsf{T}}$。把它和课程中的其他分解并排看：

分解	形式	适用条件	揭示的结构
$A = LU$（讲次 2、4）	下三角 × 上三角	消元可行（需换行时 $PA = LU$）	消元过程、主元
$A = QR$（讲次 17）	正交 × 上三角	列线性无关	正交基、最小二乘

分解	形式	适用条件	揭示的结构
$A = S\Lambda S^{-1}$（讲次 22）	特征向量 × 对角 × 逆	方阵且可对角化	特征值、e^{At}、稳定性
$A = Q\Lambda Q^{\mathsf{T}}$（讲次 25）	正交 × 对角 × 正交	对称矩阵	主轴、正定性
$A = U\Sigma V^{\mathsf{T}}$（本讲）	正交 × 对角 × 正交	**任意矩阵，无条件**	奇异值、四子空间、秩、范数

SVD 的两大结构性成果

成果 1：四个基本子空间的最优标准正交基（本课程的顶点）

$$\mathbf{u}_1, \dots, \mathbf{u}_r \text{ 是 } C(A) \text{ 的标准正交基} \quad (C(A) \subseteq \mathbb{R}^m,\ \dim = r)$$

$$\mathbf{u}_{r+1}, \dots, \mathbf{u}_m \text{ 是 } N(A^{\mathsf{T}}) \text{ 的标准正交基} \quad (\dim = m - r)$$

$$\mathbf{v}_1, \dots, \mathbf{v}_r \text{ 是 } C(A^{\mathsf{T}}) \text{ 的标准正交基} \quad (C(A^{\mathsf{T}}) \subseteq \mathbb{R}^n,\ \dim = r)$$

$$\mathbf{v}_{r+1}, \dots, \mathbf{v}_n \text{ 是 } N(A) \text{ 的标准正交基} \quad (\dim = n - r)$$

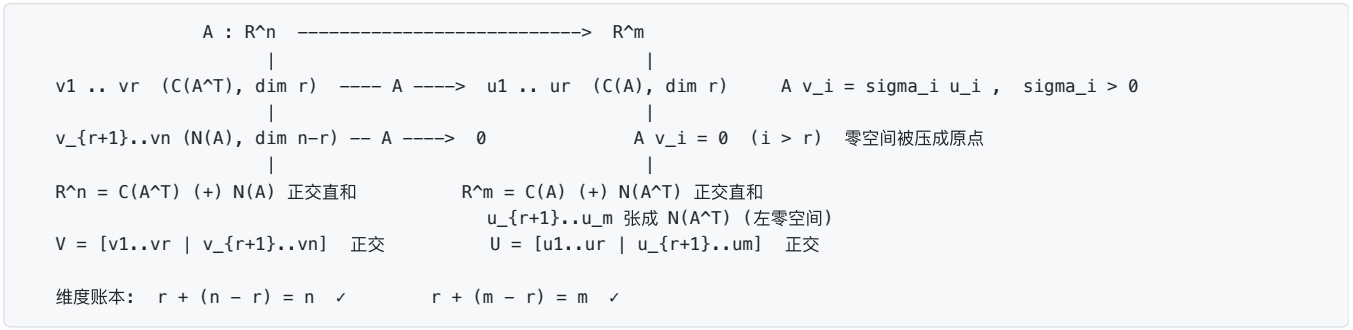

这张图是讲次 10"大图"的**最终版**：那里我们只知道四个子空间的维数和"行空间 ⊥ 零空间、列空间 ⊥ 左零空间"；这里 SVD 把它们的**标准正交基一次性全部给出**，而且是"逐对配对"的——第 i 对 $(\mathbf{v}_i, \mathbf{u}_i)$ 通过 $A\mathbf{v}_i = \sigma_i \mathbf{u}_i$ 精确联系。Strang 说这是"线性代数的顶点"，因为四个子空间 + 正交性 + 秩，被一个公式全部收进 $A = U\Sigma V^{\mathsf{T}}$。

用示例 1 逐条验证四子空间（$A = \begin{bmatrix} 3 & 0 \\ 4 & 5 \end{bmatrix}$，$r = 2$，$m = n = 2$）

因为 $m = n = r = 2$，此时没有"零空间"部分：$N(A) = \{\mathbf{0}\}$，$N(A^{\mathsf{T}}) = \{\mathbf{0}\}$，$C(A) = C(A^{\mathsf{T}}) = \mathbb{R}^2$。全部四个子空间"退化"为平凡情形，这本身是个好检查：

- $C(A)$：$\mathbf{u}_1 \approx [0.3162, 0.9487]^{\mathsf{T}}$，$\mathbf{u}_2 \approx [0.9487, -0.3162]^{\mathsf{T}}$，两个正交单位向量，张成 $\mathbb{R}^2$ ✓（$\det A = 15 \neq 0 \Rightarrow C(A) = \mathbb{R}^2$）。
- $C(A^{\mathsf{T}})$：$\mathbf{v}_1 = \frac{1}{\sqrt{2}}[1, 1]^{\mathsf{T}}$，$\mathbf{v}_2 = \frac{1}{\sqrt{2}}[1, -1]^{\mathsf{T}}$，张成 $\mathbb{R}^2$ ✓。
- $A\mathbf{v}_1 = \sigma_1 \mathbf{u}_1$（已在核心概念节验证）；$A\mathbf{v}_2 = \sigma_2 \mathbf{u}_2$：$A\mathbf{v}_2 = \frac{1}{\sqrt{2}}[3, -1]^{\mathsf{T}}$，$\sigma_2 \mathbf{u}_2 = \sqrt{5} \cdot \frac{1}{\sqrt{10}}[3, -1]^{\mathsf{T}} = \frac{1}{\sqrt{2}}[3, -1]^{\mathsf{T}}$ ✓。
- 附带：$C(A) = C(A^{\mathsf{T}})$ 只在**对称**矩阵时成立；一般矩阵两者是不同空间里的不同子空间（示例 2 里 $C(A) \subseteq \mathbb{R}^3$，$C(A^{\mathsf{T}}) \subseteq \mathbb{R}^2$，维数都是 2 但向量完全不同）。

再看示例 2（3×2，$r = 2$）就出现了非平凡的四个空间：– $C(A) = \text{span}([1, 1, 0]^{\mathsf{T}}, [1, -1, 0]^{\mathsf{T}}) = xy$ 平面（$\subseteq \mathbb{R}^3$），$\dim = 2$ ✓；– $N(A^{\mathsf{T}}) = \text{span}([0, 0, 1]^{\mathsf{T}})$，$\dim = 3 - 2 = 1$ ✓，且 $[0, 0, 1]^{\mathsf{T}} \cdot [1, 1, 0]^{\mathsf{T}} = 0$ ⟹ 与 $C(A)$ 正交 ✓；– $C(A^{\mathsf{T}}) = \mathbb{R}^2$（两列 $[1, 1]^{\mathsf{T}}, [1, -1]^{\mathsf{T}}$ 无关），$\dim = 2$ ✓；– $N(A) = \{\mathbf{0}\}$，$\dim = 2 - 2 = 0$ ✓。

正交直和分解有一个漂亮的推论：任意 $\mathbf{x} \in \mathbb{R}^n$ 可以唯一地写成 $\mathbf{x} = \mathbf{x}_{\text{row}} + \mathbf{x}_{\text{null}}$（行空间分量 + 零空间分量），因为 $\mathbb{R}^n = C(A^{\mathsf{T}}) \oplus N(A)$ 且两者正交。于是 $A\mathbf{x} = A\mathbf{x}_{\text{row}}$：**零空间分量在 A 作用下完全消失**。而按 V 展开 $\mathbf{x} = \sum c_i \mathbf{v}_i$ 时，$A\mathbf{x} = \sum_{i \le r} c_i \sigma_i \mathbf{u}_i$ —— 前 r 个系数被"加权搬过去"，后 $n - r$ 个系数直接丢弃。这就是 SVD 版本的"A 究竟做了什么"的最清楚回答。

成果 2：秩 1 展开与低秩逼近

把 $A = U\Sigma V^{\mathsf{T}}$ 按列乘行展开（U 的第 i 列 $\mathbf{u}_i$ 乘 Σ 的第 i 个对角元再乘 V^{T} 的第 i 行 $\mathbf{v}_i^{\mathsf{T}}$）：

$$\boxed{A = \sum_{i=1}^{r} \sigma_i \, \mathbf{u}_i \mathbf{v}_i^{\mathsf{T}}.}$$

每一项 $\mathbf{u}_i \mathbf{v}_i^{\mathsf{T}}$ 是 $m \times n$ 的**秩 1 矩阵**（列空间是一维的，$\text{span}(\mathbf{u}_i)$）。所以：

> **秩为 r 的矩阵，恰好是 r 个秩 1 矩阵之和。** 这是讲次 11 的 $A = CR$（C 是 r 个无关列，R 是行阶梯形的非零行）的**正交化精美版本**——$A = CR$ 里的 C, R 不唯一也不正交，SVD 把它们变成了 $\mathbf{u}_i$（正交）与 $\mathbf{v}_i^{\mathsf{T}}$（正交），并把"重要性"按 σ_i 排序。

Eckart–Young 定理（最佳低秩逼近）：设

$$A_k = \sum_{i=1}^{k} \sigma_i \, \mathbf{u}_i \mathbf{v}_i^{\mathsf{T}} \qquad (k < r).$$

则 A_k 是所有秩 $\le k$ 的矩阵中**离 A 最近**的一个，误差为

$$\|A - A_k\|_2 = \sigma_{k+1} \quad (\text{谱范数}), \qquad \|A - A_k\|_F^2 = \sum_{i=k+1}^{r} \sigma_i^2 \quad (\text{Frobenius 范数}).$$

证明的核心正是上面"单位球 → 椭球"的几何：去掉最小的一些半轴，剩下的椭球与原来的椭球最多差 σ_{k+1}。注意 $A - A_k = \sum_{i>k} \sigma_i \mathbf{u}_i \mathbf{v}_i^{\mathsf{T}}$ 本身就是"去掉前 k 项"的 SVD，它的最大奇异值就是 σ_{k+1}。

用示例 1 的 $A = \begin{bmatrix} 3 & 0 \\ 4 & 5 \end{bmatrix}$ 算低秩逼近（$k = 1$）

$$A_1 = \sigma_1 \mathbf{u}_1 \mathbf{v}_1^{\mathsf{T}} = 3\sqrt{5} \cdot \frac{1}{\sqrt{10}} \begin{bmatrix} 1 \\ 3 \end{bmatrix} \cdot \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \end{bmatrix} = \frac{3\sqrt{5}}{\sqrt{20}} \begin{bmatrix} 1 & 1 \\ 3 & 3 \end{bmatrix} = \frac{3\sqrt{5}}{2\sqrt{5}} \begin{bmatrix} 1 & 1 \\ 3 & 3 \end{bmatrix} = \frac{3}{2} \begin{bmatrix} 1 & 1 \\ 3 & 3 \end{bmatrix} = \begin{bmatrix} 1.5 & 1.5 \\ 4.5 & 4.5 \end{bmatrix}.$$

误差矩阵

$$A - A_1 = \begin{bmatrix} 3 - 1.5 & 0 - 1.5 \\ 4 - 4.5 & 5 - 4.5 \end{bmatrix} = \begin{bmatrix} 1.5 & -1.5 \\ -0.5 & 0.5 \end{bmatrix} = \sigma_2 \mathbf{u}_2 \mathbf{v}_2^{\mathsf{T}} = \frac{1}{2} \begin{bmatrix} 3 & -3 \\ -1 & 1 \end{bmatrix}.$$

- $\|A - A_1\|_2 = \sigma_2 = \sqrt{5} \approx 2.2361$ ✓
- $\|A - A_1\|_F = \sqrt{1.5^2 + 1.5^2 + 0.5^2 + 0.5^2} = \sqrt{2.25 + 2.25 + 0.25 + 0.25} = \sqrt{5} \approx 2.2361$ ✓（只剩一项，两个范数相等）
- 相对误差 $= \|A - A_1\|_F / \|A\|_F = \sqrt{5}/\sqrt{50} = 1/\sqrt{10} \approx 0.3162$
- 能量占比 $= \sigma_1^2 / (\sigma_1^2 + \sigma_2^2) = 45/50 = 90\%$

应用（四个，都带数字）

(1) 图像压缩。 一张灰度图像就是一个像素矩阵 A（如 1000×1000）。存储 A 需要 10^6 个数；存 A_k 只需要 k 个 σ + k 个 $\mathbf{u}_i$（各 m 个数）+ k 个 $\mathbf{v}_i$（各 n 个数），共 $k(m+n+1)$ 个数。$m = n = 1000$、$k = 50$ 时：$50 \times 2001 \approx 100{,}050$ 个数，只有原来的 10%，而画面几乎不变。原因是真实图像的奇异值**衰减极快**（大部分能量集中在头几十个 σ 上，即 90% 或 99% 的能量）。用示例 1 体会原理：4 个数的矩阵，保留 $k = 1$ 只需存 $\sigma_1, \mathbf{u}_1, \mathbf{v}_1$ 共 $1 + 2 + 2 = 5$ 个数，对 2×2 反而"亏了"（小矩阵不该压缩），但同一个公式在 m, n 很大时收益是压倒性的——因为 $k(m+n+1) \ll mn$。

(2) 数据降维 / PCA（主成分分析）。 把 N 个样本、每个 d 维的数据排成矩阵 X（$N \times d$，每行一个样本），先**中心化**（每列减去均值）。对 X 做 SVD：$X = U\Sigma V^{\mathsf{T}}$，则 V 的列 $\mathbf{v}_1, \mathbf{v}_2, \ldots$ 就是**主方向**——第一主方向 $\mathbf{v}_1$ 是数据投影后方差最大的方向（等价于协方差矩阵 $X^{\mathsf{T}}X/(N-1)$ 的最大特征向量，因为 $X^{\mathsf{T}}X = V\Sigma^2 V^{\mathsf{T}}$）。第 i 个主成分解释的方差比例为

$$\frac{\sigma_i^2}{\sum_j \sigma_j^2}.$$

用示例 1 的数字：若 A 是（中心化后的）数据矩阵，第一主方向解释 $45/50 = 90\%$ 的方差，第二方向只剩 10% —— 于是可以只保留一维，把二维数据压成一条线上的坐标，损失仅 10% 的方差信息。

(3) 条件数 / 数值稳定性。 定义 $\kappa(A) = \sigma_1/\sigma_n$（$n$ 为列数，**零奇异值也计入**；A 奇异时 $\kappa = \infty$）。示例 1 的 $\kappa = 3\sqrt{5}/\sqrt{5} = 3$，非常健康；示例 2 的 $\kappa = \sqrt{2}/\sqrt{2} = 1$（条件数最小可能值）。若 σ_n 极小（如 $\sigma_n = 10^{-8}$、$\sigma_1 = 1$），则 $\kappa = 10^8$，此时解 $A\mathbf{x} = \mathbf{b}$ 对 $\mathbf{b}$ 的微小扰动会放大约 κ 倍，有效数字损失约 $\log_{10}\kappa = 8$ 位，数值上不可靠。$\sigma_{\min}$ 小 $\iff$ **矩阵接近奇异**——这比"$\det A$ 小"是更可靠的判据（$\det$ 会被整体缩放污染：$10^{-6}I$ 的 $\det$ 是 10^{-6n} 但条件数只有 1，完全不病态）。

(4) 伪逆与最小二乘（预告讲次 33）。 对 $A = U\Sigma V^{\mathsf{T}}$，定义 Σ^+ 为把每个非零 σ_i 取倒数、其余保持 0，再转置形状：

$$A^+ = V\Sigma^+ U^{\mathsf{T}}.$$

A^+ 是 Moore–Penrose 伪逆：A 可逆时 $A^+ = A^{-1}$；A 列满秩时 $A^+ = (A^{\mathsf{T}}A)^{-1}A^{\mathsf{T}}$（最小二乘的解，讲次 16）。用示例 2 验算：

$\Sigma^+ = \begin{bmatrix} 1/\sqrt{2} & 0 & 0 \\ 0 & 1/\sqrt{2} & 0 \end{bmatrix}$ (2×3)，$V = I$，

$$A^+ = \Sigma^+ U^{\mathsf{T}} = \begin{bmatrix} 1/2 & 1/2 & 0 \\ 1/2 & -1/2 & 0 \end{bmatrix}, \qquad A^+ A = \begin{bmatrix} 1/2 & 1/2 & 0 \\ 1/2 & -1/2 & 0 \end{bmatrix} \begin{bmatrix} 1 & 1 \\ 1 & -1 \\ 0 & 0 \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} = I_2 \checkmark$$

再试 Q1 的矩阵（秩 1，不可逆），A^+A 会变成投影矩阵而不是 I —— 这正是伪逆"把 A 的零空间方向一律送回 0"的行为。

(5) 三个范数与行列式的统一公式（方阵 $n \times n$）：

$$\|A\|_2 = \sigma_1, \qquad \|A\|_F = \sqrt{\textstyle\sum_{i=1}^{n} \sigma_i^2}, \qquad |\det A| = \prod_{i=1}^{n} \sigma_i.$$

用示例 1 全部核对：$\|A\|_2 = 3\sqrt{5} \approx 6.7082$；$\|A\|_F = \sqrt{50} \approx 7.0711$；$|\det A| = 15$。注意 $\|A\|_2 \le \|A\|_F \le \sqrt{n}\|A\|_2$：$6.7082 \le 7.0711 \le \sqrt{2} \times 6.7082 = 9.4868$ ✓。对 Q2 的 $\sigma = (10, 1, 0.01)$：$\|A\|_2 = 10$，$\|A\|_F = \sqrt{101.0001} \approx 10.0499$，$|\det A| = 0.1$；两条不等式同样成立（$10 \le 10.0499 \le \sqrt{3} \times 10 = 17.32$ ✓）。

（6）一个统一视角：SVD 是"条件数、能量、体积、秩"的统一度量工具

把上面的公式排在一起可以看出 SVD 的哲学：**一个矩阵的所有"大小"性质，都能被 σ_i 一个数列解释干净**。

```
性质                      用 sigma 表达              用 A 直接表达（直觉）
-----------------------   ------------------------   ------------------------------
秩 rank(A)                # { sigma_i > 0 }          主元个数（数值上不稳定）
最大放大率 ||A||_2        sigma_1                    max ||Ax||  (||x|| = 1)
总能量 ||A||_F^2          sum sigma_i^2              sum a_ij^2（逐个元素平方和）
体积放大率 |det A|        prod sigma_i（方阵）       行列式（会互相抵消，见例 3!）
条件数 kappa(A)           sigma_1 / sigma_n          没有任何干净的直接表达
稳定性（逆的放大率）      1 / sigma_n                (sigma_n -> 0 时爆炸)
最佳 k 秩逼近误差         sigma_{k+1}                没有别的刻画（Eckart-Young）
能量占比（PCA）           sigma_i^2 / sum sigma_j^2   协方差矩阵的特征值分解
```

注意最后一行"$\det A$ 会互相抵消"：示例 3 的 $A = \begin{bmatrix} 0 & 2 \\ 0 & 0 \end{bmatrix}$，四个元素里有一个 2，$\det A = 0$，看起来"什么都没放大"；但 $\sigma_1 = 2$ —— 它明明把 $[0,1]^{\mathsf{T}}$ 拉成了长度 2 的向量。**行列式只测"体积"，而一个压扁方向 + 一个拉长方向可以让体积仍为 0，放大却真实存在。SVD 把每个方向的放大率单独列出来，这才是完整信息。**

（7）奇异值衰减图：为什么"压缩"在数学上必然可行

真实数据（图像、文本–词频矩阵、用户–评分矩阵）的奇异值几乎总是**急剧衰减**：前几个 σ 吃掉绝大部分能量。画成图就是一条陡降的曲线：

```
  sigma_i
    |
 10 |*
    | *
  1 |  *
    |    *
0.1 |       *
    |            *
0.01|                  *  *  *  *  *  *  *  *
    +-------------------------------------------------> i
     1  2  3  4  5  6  7  8  9 10 11 12 13 14 15

  示例 1 (A=[[3,0],[4,5]]): sigma = (6.708, 2.236)  -> 90% 能量在 sigma_1
  示例 Q1 (A=[[1,2],[0,0]]): sigma = (2.236, 0)      -> 100% 能量在 sigma_1（秩 1）
  Q2 的例子:                  sigma = (10, 1, 0.01)   -> 99% 能量在前两个

  "长尾"部分（小的 sigma_i）贡献的能量 sum_{i>k} sigma_i^2 很小，
  但它们占用的存储/自由度却和大 sigma 一样多 —— 于是删掉它们几乎不损失信息。

  能量占比判据（工程上常用）：
      保留最小的 k 使得  sum_{i<=k} sigma_i^2 / sum_i sigma_i^2 >= 0.99
  示例 1: k=1 时 45/50 = 0.90（不够 99%），k=2 才是 1.00（精确重建）
  Q2 例:  k=2 时 (100+1)/101.0001 = 99.9999% >= 99%  -> 保留 2 维即可
```

（8）用 SVD 做"降噪"和"最小二乘"的直觉

- **降噪**：如果数据中"信号"集中在少数大奇异值、"噪声"散布在全部（含大量小）奇异值上，那么**截断 SVD（用 A_k）就等于滤掉噪声**。这是图像去噪、推荐系统（矩阵补全的基础）的共同机制。
- **最小二乘**：讲次 16 里 $A\mathbf{x} = \mathbf{b}$ 无解时我们解 $A^{\mathsf{T}}A\hat{\mathbf{x}} = A^{\mathsf{T}}\mathbf{b}$。用 SVD 展开可以看清解的组成：

$$\hat{\mathbf{x}} = \sum_{i=1}^{r} \frac{\mathbf{u}_i^{\mathsf{T}}\mathbf{b}}{\sigma_i}\,\mathbf{v}_i, \qquad A\hat{\mathbf{x}} = \sum_{i=1}^{r} (\mathbf{u}_i^{\mathsf{T}}\mathbf{b})\,\mathbf{u}_i,$$

即"把 $\mathbf{b}$ 投影到 $C(A)$（丢掉 $N(A^{\mathsf{T}})$ 分量），再沿每个 $\mathbf{v}_i$ 方向按 $1/\sigma_i$ 还原"。**小 σ_i 出现在分母 $\Longrightarrow$ 病态时误差被放大**——这正是"需要正则化"和"伪逆要截断"的根源。用示例 2（$\sigma_1 = \sigma_2 = \sqrt{2}$，$A$ 列满秩）取 $\mathbf{b} = [1,0,0]^{\mathsf{T}}$：$\mathbf{u}_1^{\mathsf{T}}\mathbf{b} = 1/\sqrt{2}$，$\mathbf{u}_2^{\mathsf{T}}\mathbf{b} = 1/\sqrt{2}$，故 $\hat{\mathbf{x}} = \frac{1/\sqrt{2}}{\sqrt{2}}[1,0]^{\mathsf{T}} + \frac{1/\sqrt{2}}{\sqrt{2}}[0,1]^{\mathsf{T}} = \frac{1}{2}[1,1]^{\mathsf{T}}$，$A\hat{\mathbf{x}} = \frac{1}{2}[2,0,0]^{\mathsf{T}} = [1,0,0]^{\mathsf{T}}$ —— 恰好等于 $\mathbf{b}$（因为 $\mathbf{b} \in C(A)$，误差为 0；$\mathbf{b} = [1,0,0]^{\mathsf{T}} = \frac{1}{\sqrt{2}}(\mathbf{u}_1 + \mathbf{u}_2)$ 确实在列空间里）。

与其他讲次的关联

- **讲次 10（四个基本子空间）：** SVD 是"大图"的最终答案。$\mathbf{u}_1..\mathbf{u}_r$ 给 $C(A)$，$\mathbf{u}_{r+1}..\mathbf{u}_m$ 给 $N(A^\mathsf{T})$，$\mathbf{v}_1..\mathbf{v}_r$ 给 $C(A^\mathsf{T})$，$\mathbf{v}_{r+1}..\mathbf{v}_n$ 给 $N(A)$，全部标准正交，维数 $r,\ m-r,\ r,\ n-r$ 一目了然。
- **讲次 11（$A=CR$ 与秩 1 之和）：** $A=\sum\sigma_i\mathbf{u}_i\mathbf{v}_i^\mathsf{T}$ 是 $A=CR$ 的正交化、排序化版本。
- **讲次 14–17（正交、投影、最小二乘、QR）：** 正交矩阵保长（$\|U\mathbf{x}\|=\|\mathbf{x}\|$）是 $\|A\|_F^2=\sum\sigma_i^2$ 的根据；AA^+ 是到 $C(A)$ 的投影矩阵；QR 分解可视为 SVD 的"廉价替代"（Q 类似 U，但对角部分不是对角）。
- **讲次 18–20（行列式）：** $|\det A|=\prod\sigma_i$ 把"体积放大率"分解为各正交方向的放大率之积。
- **讲次 22、28（对角化、Jordan 形）：** $A=S\Lambda S^{-1}$ 要求可对角化，Jordan 形是"补救"但失去了对角性和数值稳定性；SVD 用"两组正交基"换来了**无条件存在**，代价是 $\mathbf{u}_i\neq\mathbf{v}_i$、$\Sigma$ 只有对角元而非相似对角化。
- **讲次 25（对称正定）：** $A^\mathsf{T}A$ 对称半正定 $\Rightarrow$ 可正交对角化 $\Rightarrow$ 得到 V 与 Σ^2。这是 SVD 唯一依赖的存在性定理；正定情形（$A^\mathsf{T}A$ 可逆）时所有 $\sigma_i>0$。
- **讲次 27（正定判别）：** 半正定检验 $\mathbf{x}^\mathsf{T}A^\mathsf{T}A\mathbf{x}=\|A\mathbf{x}\|^2\geq 0$ 把正定与零空间联系：$A^\mathsf{T}A$ 正定 $\iff N(A)=\{\mathbf{0}\}\iff$ 列满秩 $\iff$ 全部 $\sigma_i>0$。
- **讲次 31（换基与图像压缩）：** $A=U\Sigma V^\mathsf{T}$ 正是"**换输入基（V）＋换输出基（U）**"的完美示范：在正确的两组基下，任何线性变换都是对角矩阵 Σ。低秩逼近就是"在新基下丢掉不重要的坐标"。
- **讲次 33（伪逆）：** $A^+=V\Sigma^+U^\mathsf{T}$ 一次性处理可逆 / 列满秩 / 秩亏 / 欠定四种情况，是最小二乘的统一解。

关键要点

1. **任何矩阵都有 SVD**：$A_{m\times n}=U_{m\times m}\Sigma_{m\times n}V^\mathsf{T}_{n\times n}$，只要求 U,V 正交；$\sigma_1\geq\cdots\geq\sigma_r>0$，其余为 0，且 $r=\mathbf{rank}(A)$。
2. **两条生成关系**：$A\mathbf{v}_i=\sigma_i\mathbf{u}_i$（$i\leq r$）与 $A\mathbf{v}_i=\mathbf{0}$（$i>r$）；反过来是 $A^\mathsf{T}\mathbf{u}_i=\sigma_i\mathbf{v}_i$ 与 $A^\mathsf{T}\mathbf{u}_i=\mathbf{0}$（$i>r$）。
3. **算法主线**：$\sigma_i=\sqrt{\lambda_i(A^\mathsf{T}A)}$，$\mathbf{v}_i$ 是 $A^\mathsf{T}A$ 的单位特征向量，$\mathbf{u}_i=A\mathbf{v}_i/\sigma_i$（$\sigma_i\neq 0$；$\sigma_i=0$ 时 $\mathbf{u}_i$ 从 $N(A^\mathsf{T})$ 另补）。
4. **几何主线**：正交方向 → 正交方向，只伸缩；单位球 → 椭球，半轴 $=\sigma_i$、方向 $=\mathbf{u}_i$；$\|A\|_2=\sigma_1$。
5. **应用主线**：$A=\sum\sigma_i\mathbf{u}_i\mathbf{v}_i^\mathsf{T}$；截断得最佳 k 秩逼近，误差 σ_{k+1}（谱）与 $\sqrt{\sum_{i>k}\sigma_i^2}$（Frobenius）；这就是图像压缩与 PCA 的全部数学。

常见误区与注意事项

1. **把奇异值当成特征值的绝对值。** 错。示例 3 的 $A=\begin{bmatrix}0&2\\0&0\end{bmatrix}$ 特征值全为 0，奇异值却是 $\mathbf{2,0}$。只有**对称矩阵**（更一般地，**正规矩阵** $A^\mathsf{T}A=AA^\mathsf{T}$）才有 $\sigma_i=|\lambda_i|$。示例 4 验证了对称情形。
2. **以为奇异值可能为负或为复数。** 不可能。$\sigma_i=\sqrt{\lambda_i(A^\mathsf{T}A)}$，而 $A^\mathsf{T}A$ 半正定保证 $\lambda_i\geq 0$，开方取非负根。奇异值永远是非负实数，永远按降序写 $\sigma_1\geq\sigma_2\geq\cdots$（忘记排序会让 Σ、U、V 的列对应关系全乱）。
3. **以为 U 和 V 是同一个矩阵。** 一般不是：示例 1 中 $U=\frac{1}{\sqrt{10}}\begin{bmatrix}1&3\\3&-1\end{bmatrix}$ 而 $V=\frac{1}{\sqrt{2}}\begin{bmatrix}1&1\\1&-1\end{bmatrix}$，完全不同。只有对称正定（或正规）矩阵才可能有 $\mathbf{u}_i=\pm\mathbf{v}_i$。另外注意 U 定义在 $\mathbb{R}^m$、V 定义在 $\mathbb{R}^n$，当 $m\neq n$ 时它们连尺寸都不同，谈不上相等（示例 2：U 是 3×3，V 是 2×2）。
4. **以为 SVD 只对方阵有意义。** 恰恰相反，**非方阵时 SVD 才是不可替代的**：非方阵根本没有特征值（示例 2），$m\neq n$ 时 Σ 是长方形对角阵（多出的行或列全 0）。这正是 SVD 比对角化强大的地方。
5. **在 $\sigma_i=0$ 时用 $\mathbf{u}_i=A\mathbf{v}_i/\sigma_i$。** 不能除以零。$\sigma_i=0$ 意味着 $A\mathbf{v}_i=\mathbf{0}$，此时 $\mathbf{u}_i$ **不由 A 决定**，必须从 $N(A^\mathsf{T})$ 里另找与已有 $\mathbf{u}$ 正交的单位向量补上（示例 2 补的 $\mathbf{u_3}=[0,0,1]^\mathsf{T}$、Q1 补的 $\mathbf{u_2}$）。这也说明：**零奇异值对应的奇异向量不唯一**；重奇异值（如示例 2 的 $\sigma_1=\sigma_2=\sqrt{2}$）对应的也不唯一。
6. **把"$\det A$ 小"当成"病态"。** 病态的正确判据是条件数 $\kappa=\sigma_1/\sigma_n$（n = 列数，零奇异值照算；尺度无关），不是 $\det A$（尺度相关，且可被"压扁一个方向 + 拉长一个方向"互相抵消）。见"应用 (3)"与 Q1/Q2。
7. **以为 $U\Sigma V^\mathsf{T}$ 的写法可以随意换位置。** 顺序不能动：ΣV^T、$U\Sigma$、ΣU 都不等于 A。U 作用在**输出**（$\mathbb{R}^m$）一侧，V^T 作用在**输入**（$\mathbb{R}^n$）一侧，维度账本是 $m\times m$、$m\times n$、$n\times n$，三者相乘才是 $m\times n$。若 $m\neq n$，写成 $A=U\Sigma U^\mathsf{T}$ 会直接维度不匹配（示例 2 就是 3×3 与 2×2 无法相乘）。
8. **以为 $\mathbf{rank}(A)=$ 奇异值的个数。** 是**非零**奇异值的个数。$m\times n$ 矩阵总共有 $\min(m,n)$ 个奇异值，其中 $n-r$ 个（在 $\Sigma^\mathsf{T}\Sigma$ 侧）或 $m-r$ 个（在 $\Sigma\Sigma^\mathsf{T}$ 侧）为 0。示例 2 有 2 个奇异值、全部非零 $\Rightarrow$ 秩 2；Q1 有 2 个奇异值、1 个为 0 $\Rightarrow$ 秩 1。

思考题（带答案）

Q1. 求 $A=\begin{bmatrix}1&2\\0&0\end{bmatrix}$ 的完整 SVD（U,Σ,V），并指出 $\mathbf{rank}(A)$、$\kappa(A)$、$\|A\|_2$、$\|A\|_F$、$|\det A|$（若可逆）；再写出 A^+ 并验证 A^+A 是投影矩阵。

▸ 答案

步骤 1：$A^{\mathsf{T}}=\begin{bmatrix}1&0\\2&0\end{bmatrix}$，

$$A^{\mathsf{T}}A=\begin{bmatrix}1&0\\2&0\end{bmatrix}\begin{bmatrix}1&2\\0&0\end{bmatrix}=\begin{bmatrix}1&2\\2&4\end{bmatrix}.$$

$\mathrm{tr}=5$，$\det=1\cdot4-2\cdot2=0$，特征多项式 $\lambda^2-5\lambda=\lambda(\lambda-5)=0$，故 $\lambda_1=5,\ \lambda_2=0$。

步骤 2（V）：对 $\lambda_1=5$：$\begin{bmatrix}-4&2\\2&-4\end{bmatrix}\mathbf{v}=\mathbf{0}\Rightarrow 2v_1=v_2$，取 $\mathbf{v}_1=\frac{1}{\sqrt5}\begin{bmatrix}1\\2\end{bmatrix}$。对 $\lambda_2=0$：$\begin{bmatrix}1&2\\2&4\end{bmatrix}\mathbf{v}=\mathbf{0}\Rightarrow v_1+2v_2=0$，取 $\mathbf{v}_2=\frac{1}{\sqrt5}\begin{bmatrix}2\\-1\end{bmatrix}$。点积 $\frac{2-2}{5}=0$ ✓。

步骤 3（Σ）：$\sigma_1=\sqrt5\approx2.2361$，$\sigma_2=0$。$\Sigma=\begin{bmatrix}\sqrt5&0\\0&0\end{bmatrix}$。

步骤 4（U）：$\mathbf{u}_1=\frac{A\mathbf{v}_1}{\sigma_1}=\frac{1}{\sqrt5}\cdot\frac{1}{\sqrt5}\begin{bmatrix}1&2\\0&0\end{bmatrix}\begin{bmatrix}1\\2\end{bmatrix}=\frac15\begin{bmatrix}5\\0\end{bmatrix}=\begin{bmatrix}1\\0\end{bmatrix}$。$\sigma_2=0$ **不能**用除法；需要与 $\mathbf{u}_1=[1,0]^{\mathsf{T}}$ 正交的单位向量，取 $\mathbf{u}_2=\begin{bmatrix}0\\1\end{bmatrix}$（它张成 $N(A^{\mathsf{T}})=\mathrm{span}([0,1]^{\mathsf{T}})$：$A^{\mathsf{T}}\mathbf{u}_2=\begin{bmatrix}1&0\\2&0\end{bmatrix}\begin{bmatrix}0\\1\end{bmatrix}=\mathbf{0}$ ✓）。

$$U=\begin{bmatrix}1&0\\0&1\end{bmatrix},\qquad\Sigma=\begin{bmatrix}\sqrt5&0\\0&0\end{bmatrix},\qquad V=\frac{1}{\sqrt5}\begin{bmatrix}1&2\\2&-1\end{bmatrix}.$$

验证：$U\Sigma V^{\mathsf{T}}=\Sigma V^{\mathsf{T}}=\begin{bmatrix}\sqrt5&0\\0&0\end{bmatrix}\cdot\frac{1}{\sqrt5}\begin{bmatrix}1&2\\2&-1\end{bmatrix}=\begin{bmatrix}1&2\\0&0\end{bmatrix}=A$ ✓

各量： – $\mathbf{rank}(A)=1$（非零奇异值只有 1 个）。 – $\kappa(A)$：按标准定义 $\kappa(A)=\sigma_1/\sigma_n=\sqrt5/0=\infty$。**秩亏矩阵的条件数是无穷大**（这里 $\sigma_2=0$，A 奇异、完全病态）。注意不要误用 σ_1/σ_r（r 为非零奇异值个数）——那只是"秩 r 意义上的"比值，本例为 $\sqrt5/\sqrt5=1$，会给出严重误导的"良态"假象。考试/应用中一律用 σ_1/σ_n（n 是**列数**，零奇异值也算进去）。 – $\|A\|_2=\sigma_1=\sqrt5\approx2.2361$；$\|A\|_F=\sqrt{\sigma_1^2+\sigma_2^2}=\sqrt5\approx2.2361$（秩 1 矩阵两个范数相等，与 $\|A\|_F=\sqrt{1+4}=\sqrt5$ 一致 ✓）。 – $\det A=0$，故 $|\det A|=0=\sigma_1\sigma_2$ ✓（不可逆）。

伪逆： $\Sigma^{+}=\begin{bmatrix}1/\sqrt5&0\\0&0\end{bmatrix}$，

$$A^{+}=V\Sigma^{+}U^{\mathsf{T}}=\frac{1}{\sqrt5}\begin{bmatrix}1&2\\2&-1\end{bmatrix}\begin{bmatrix}1/\sqrt5&0\\0&0\end{bmatrix}=\frac15\begin{bmatrix}1&0\\2&0\end{bmatrix}.$$

$$A^{+}A=\frac15\begin{bmatrix}1&0\\2&0\end{bmatrix}\begin{bmatrix}1&2\\0&0\end{bmatrix}=\frac15\begin{bmatrix}1&2\\2&4\end{bmatrix}=\begin{bmatrix}1/5&2/5\\2/5&4/5\end{bmatrix}.$$

这是到 $C(A^{\mathsf{T}})=\mathrm{span}([1,2]^{\mathsf{T}})$ 的投影矩阵（幂等：$(A^{+}A)^2=A^{+}A$，对称，迹 $=1=\mathbf{rank}$；把 $[1,2]^{\mathsf{T}}$ 保持不变，把与它正交的 $[2,-1]^{\mathsf{T}}$ 投到 0）✓。**注意投影到的是行空间 $C(A^{\mathsf{T}})$ 而不是列空间**：$A=\begin{bmatrix}1&2\\0&0\end{bmatrix}$ 的列空间只有 $[1,0]^{\mathsf{T}}$ 方向，投影到列空间的是 $AA^{+}=\begin{bmatrix}1&0\\0&0\end{bmatrix}$。一般规律是 $A^{+}A$ 投影到 $C(A^{\mathsf{T}})$（消灭 $N(A)$）、AA^{+} 投影到 $C(A)$（消灭 $N(A^{\mathsf{T}})$），二者不要混淆——这也正是讲次 33 伪逆"桥接四个子空间"的要点。

Q2. 某 3×3 矩阵 A 的奇异值为 $\sigma_1=10,\ \sigma_2=1,\ \sigma_3=0.01$。求 $\mathbf{rank}(A)$、$\kappa(A)$、$\|A\|_2$、$\|A\|_F$、$|\det A|$，并说明"用 $\det A$ 判断病态"为什么不可靠。若把 A 的所有元素乘以 10^6，哪些量会变？

▸ 答案

- **秩**：三个奇异值全部 >0，故 $\mathbf{rank}(A)=3$，A 可逆。
- **条件数**：$\kappa(A)=\sigma_1/\sigma_3=10/0.01=1000$，比较病态（约损失 3 位有效数字）。
- **谱范数**：$\|A\|_2=\sigma_1=10$。
- **Frobenius 范数**：$\|A\|_F=\sqrt{100+1+0.0001}=\sqrt{101.0001}\approx 10.0499$。
- **行列式**：$|\det A|=\prod\sigma_i=10\times 1\times 0.01=0.1$。

为什么 det 不可靠： $\det$ 随整体缩放剧烈变化，而条件数与缩放无关。若把 A 换成 $10^{-6}A$，则 $\det$ 变成 $10^{-18}\times 0.1=10^{-19}$（"小得吓人"），但奇异值同步变成 $10^{-5},10^{-6},10^{-8}$，κ 仍然是 $10^{-5}/10^{-8}=1000$，**完全不变**。反之，$A=10^{-6}I_3$ 的 $\det=10^{-18}$ 却条件数为 1（完美良态）。所以病态看 $\kappa=\sigma_1/\sigma_n$。

缩放 10^6 倍后： 所有 σ_i 乘 10^6，于是 **rank 不变**（3）、**κ 不变**（1000）、$\|A\|_2$ 与 $\|A\|_F$ 乘 10^6、$|\det A|$ 乘 10^{18}。**U,V 完全不变**（只是 Σ 缩放）—— 这是 SVD 的尺度分离性质：方向信息在 U,V，大小信息在 Σ。

Q3.（概念题） 为什么 SVD "对任意矩阵都存在"，而对角化 $A=S\Lambda S^{-1}$ 不行？请从"我们要求的东西"这个角度解释，并说明 SVD 为此付出了什么代价。再解释：为什么 $A^{\mathsf T}A$ 的非零特征值恰好是 σ_i^2（各 r 个），这件事为什么又一次证明了"行秩 = 列秩"？

▸ 答案

为什么对角化会失败： $A=S\Lambda S^{-1}$ 要求存在 n 个**线性无关**的特征向量，即 $A\mathbf{x}=\lambda\mathbf{x}$ 要有足够多的解。这有三个可能失败的原因： 1. **不是方阵**：$m\neq n$ 时 $A\mathbf{x}$ 与 $\mathbf{x}$ 根本不在同一空间，写不出 $A\mathbf{x}=\lambda\mathbf{x}$（示例 2 就是这样）。 2. **特征向量不够**：如 $A=\begin{bmatrix}0&2\\0&0\end{bmatrix}$（示例 3），特征值全 0 但只有一维特征空间（缺陷矩阵，讲次 28）。 3. **实特征值/特征向量不存在**：如旋转 $\begin{bmatrix}0&-1\\1&0\end{bmatrix}$，特征值 $\pm i$。 根子在于：对角化**要求 S 可逆**，而特征向量的存在性和无关性是"偶然的"，取决于具体的 A。

SVD 为什么永远成功： SVD 换了要求——不再要求 $\mathbf{u}_i=\mathbf{v}_i$（同方向），而是允许**两个不同的正交组**，$A\mathbf{v}_i=\sigma_i\mathbf{u}_i$。存在性不再依赖 A 的性质，而依赖一个**永远成立**的定理：**$A^{\mathsf T}A$ 是对称半正定矩阵，任何实对称矩阵都可以正交对角化（谱定理，讲次 25）**。$A^{\mathsf T}A$ 是 $n\times n$ 方阵、一定对称、一定半正定，所以一定能找到 n 个标准正交特征向量 $\mathbf{v}_i$ 和 $\lambda_i\geq 0$；定义 $\sigma_i=\sqrt{\lambda_i}$，再用 $\mathbf{u}_i=A\mathbf{v}_i/\sigma_i$ 造出正交组（$\mathbf{u}_i^{\mathsf T}\mathbf{u}_j=\frac{\mathbf{v}_i^{\mathsf T}A^{\mathsf T}A\mathbf{v}_j}{\sigma_i\sigma_j}=\frac{\lambda_j\mathbf{v}_i^{\mathsf T}\mathbf{v}_j}{\sigma_i\sigma_j}=0$，$i\neq j$），零的那些用 $N(A^{\mathsf T})$ 补齐 —— 全程无一步可能失败。**把 A 的问题变成 $A^{\mathsf T}A$ 的问题，这就是 SVD 存在性的全部秘密。**

付出的代价： – $\mathbf{u}_i$ 与 $\mathbf{v}_i$ 不同（失去"方向不变"的直观），Σ 与 A **不是相似**关系（$A=U\Sigma V^{\mathsf T}$，此时 $U\neq V$，不能写成 $U\Sigma U^{-1}$），所以**奇异值不是特征值**，e^{At}、稳定性判据这类必须用特征值的地方不能拿 σ_i 替代。 – Σ 中的数是非负的，符号信息被吸收进 U（示例 3 的正负号就是这样消失的）。 – 但换来的是：无条件存在、正交性、数值稳定（$A^{\mathsf T}A$ 对称，特征值问题有极好的算法；实际工业代码用的是 Golub–Kahan 双对角化，不显式计算 $A^{\mathsf T}A$ 以避免损失精度）。

为什么 σ_i^2 同时出现在 $A^{\mathsf T}A$ 与 $AA^{\mathsf T}$： 由 $A^{\mathsf T}A=V(\Sigma^{\mathsf T}\Sigma)V^{\mathsf T}$，$A^{\mathsf T}A$ 的特征值就是 $\Sigma^{\mathsf T}\Sigma$ 的对角元，即 $\sigma_1^2,\dots,\sigma_r^2$ 和 $n-r$ 个 0；由 $AA^{\mathsf T}=U(\Sigma\Sigma^{\mathsf T})U^{\mathsf T}$，$AA^{\mathsf T}$ 的特征值是 $\sigma_1^2,\dots,\sigma_r^2$ 和 $m-r$ 个 0。于是

$$\mathbf{rank}(A^{\mathsf T}A)=\#\{\sigma_i>0\}=\mathbf{rank}(AA^{\mathsf T}).$$

而 $A^{\mathsf T}A\mathbf{x}=\mathbf{0}\iff A\mathbf{x}=\mathbf{0}$（$\Leftarrow$ 显然；$\Rightarrow$ 由 $\mathbf{x}^{\mathsf T}A^{\mathsf T}A\mathbf{x}=\|A\mathbf{x}\|^2=0$），故 $\mathbf{rank}(A^{\mathsf T}A)=\mathbf{rank}(A)$；同理 $\mathbf{rank}(AA^{\mathsf T})=\mathbf{rank}(A^{\mathsf T})$。串起来：$\mathbf{rank}(A)=\mathbf{rank}(A^{\mathsf T})$，**这正是"行秩 = 列秩"**。而由 $A^{\mathsf T}A$ 的零空间维数：$n-r$ 个零奇异值 $\Leftrightarrow\dim N(A)=n-r$，由 $AA^{\mathsf T}$ 得 $\dim N(A^{\mathsf T})=m-r$ —— 四个子空间的维数公式也一并重新导出。一个 SVD 就把讲次 10 的全部结论重新证明了一遍。

用示例 2 核对这条链： A 是 3×2，$\sigma_1=\sigma_2=\sqrt{2}$，$r=2$。 – $A^{\mathsf T}A$ 是 2×2，特征值 $2,2\Rightarrow$ 两个 $\sigma_i^2=2$，零特征值个数 $n-r=0$； – $AA^{\mathsf T}$ 是 3×3：$AA^{\mathsf T}=\begin{bmatrix}1&1&0\\1&-1&0\\0&0&0\end{bmatrix}\begin{bmatrix}1&1&0\\1&-1&0\\0&0&0\end{bmatrix}=\begin{bmatrix}2&0&0\\0&2&0\\0&0&0\end{bmatrix}$（因为 $A^{\mathsf T}$ 的列是 A 的行，这里 A 的三行是 $[1,1],[1,-1],[0,0]$，两两点积为 $2,0,0$），特征值是 $2,2,0\Rightarrow$ 非零特征值 $2,2$ ✓ 与 $A^{\mathsf T}A$ 的完全相同，零特征值个数 $m-r=1$ ✓； – $\dim N(A)=2-2=0$ ✓，$\dim N(A^{\mathsf T})=3-2=1$ ✓（正是 $\mathbf{span}([0,0,1]^{\mathsf T})$）。 – $\mathbf{rank}(A)=2=\mathbf{rank}(A^{\mathsf T})$ ✓ —— 一个 3×2 矩阵的行秩等于列秩，再次落实讲次 10。

最后一点直观总结：SVD 把"A 是什么"这个问题的答案压缩成三个清单——**拉伸倍数（σ_i，唯一且排序）、输入方向（$\mathbf{v}_i$）、输出方向（$\mathbf{u}_i$）**。有了这三个清单，你就可以回答关于 A 的一切结构性问题：秩、四子空间、范数、行列式、条件数、最佳低秩近似、伪逆。这就是为什么 Strang 把 SVD 放在课程最后作为顶点：它不是又一个分解，而是**整门课的统一语言**。

Lecture 30: Linear Transformations and Their Matrices

概述

本讲把视角从"矩阵"抬升到"变换"：线性变换 T 是先于矩阵存在的几何对象，而矩阵只是它在**某一组基**下的坐标记录。核心操作只有一句话——**问 T 对每个基向量做了什么，把答案按列排好**。我们会在标准基、多项式基、矩阵空间基上反复演练这个操作，并用 $P_x R_{90^\circ} \neq R_{90^\circ} P_x$ 说明"矩阵乘法 = 变换复合，且次序不可交换"。最后把讲次 6–10 的四个子空间语言翻译成变换语言：**零空间 = 核（kernel），列空间 = 像（image）**。

核心概念的几何直觉

线性变换（linear transformation）

- **定义与目的**：设 V, W 是向量空间。映射 $T : V \to W$ 称为线性的，若对所有 $\mathbf{v}, \mathbf{w} \in V$ 与所有标量 c, d 成立

$$T(c\mathbf{v} + d\mathbf{w}) = cT(\mathbf{v}) + dT(\mathbf{w}).$$

两个特例值得单独记住： – 可加性：$T(\mathbf{v}+\mathbf{w}) = T(\mathbf{v}) + T(\mathbf{w})$； – 齐次性：$T(c\mathbf{v}) = cT(\mathbf{v})$。 反过来，若两条都成立，则一般式自动成立。目的：把"可以做加法与数乘"的所有操作一次性抓住——线性代数研究的就是这类操作。

- **几何直觉（它在空间中是什么样子？）**：取 $c = d = 0$，得到**最重要的推论**

$$T(\mathbf{0}) = \mathbf{0}.$$

即线性变换必定把原点送到原点。更形象的图景：把 $\mathbb{R}^2$ 想成一张无限延伸的方格纸，线性变换把这张格子拉成**另一张仍然等距平行的方格纸**——直线的像仍是直线，原点不动，$\mathbf{v}$ 与 $\mathbf{w}$ 的中点映到像的中点。任何会把原点挪走、或把直线掰弯的操作，都不是线性的。

- **具体示例**：$T(x, y) = ((x+y)/2,\ (x+y)/2)$（投影到直线 $y = x$）。

$$T(1,0) = (\tfrac{1}{2}, \tfrac{1}{2}), \qquad T(0,1) = (\tfrac{1}{2}, \tfrac{1}{2}),$$

$$T(c_1(1,0) + c_2(0,1)) = c_1(\tfrac{1}{2}, \tfrac{1}{2}) + c_2(\tfrac{1}{2}, \tfrac{1}{2}),$$

与直接代入 $T(c_1, c_2) = (\frac{c_1+c_2}{2}, \frac{c_1+c_2}{2})$ 完全一致，线性成立。

矩阵是变换的坐标记录（matrix = the record of T in a basis）

- **定义与目的**：给定 V 的基 $\mathbf{v}_1, \dots, \mathbf{v}_n$ 与 W 的基 $\mathbf{w}_1, \dots, \mathbf{w}_m$，$T$ 对应的矩阵 A 的第 j **列**是 $T(\mathbf{v}_j)$ 在输出基下的坐标向量：

$$T(\mathbf{v}_j) = \sum_{i=1}^{m} a_{ij}\mathbf{w}_i \quad \Longleftrightarrow \quad A \text{ 的第 } j \text{ 列} = (a_{1j}, \dots, a_{mj})^{\mathsf{T}}.$$

于是"$A\mathbf{x}$"的每一步都有了含义：**$\mathbf{x}$ 是先组合 $\mathbf{v}_j$ 的配料表，$A\mathbf{x}$ 是像的配料表（用 $\mathbf{w}_i$ 计量）**。

- **几何直觉（它在空间中是什么样子？）**：变换是"物体"，矩阵是"照片"。同一个物体从不同角度拍，得到不同的照片（讲次 31 的换基就是换拍摄角度）。所以问"T 的矩阵是什么"是不完整的——必须补上"在哪组基下"。

这也解释了为什么**同一变换可以有很多矩阵**，而**不同变换不可能有同一个矩阵**（在同一组基下）。

- **具体示例**：$\mathbb{R}^2$ 上"横坐标翻倍、纵坐标不动"的拉伸 $T(x, y) = (2x, y)$。标准基下 $T(1,0) = (2,0)$、$T(0,1) = (0,1)$，所以

$$A = \begin{bmatrix} 2 & 0 \\ 0 & 1 \end{bmatrix}.$$

若改用基 $\mathbf{v}_1 = (1,0), \mathbf{v}_2 = (1,1)$，则 $T(\mathbf{v}_1) = (2,0) = 2\mathbf{v}_1 + 0\mathbf{v}_2$；$T(\mathbf{v}_2) = (2,1) = 1\mathbf{v}_1 + 1\mathbf{v}_2$。新矩阵是

$$B = \begin{bmatrix} 2 & 1 \\ 0 & 1 \end{bmatrix}.$$

同一个变换，两张"照片"，都正确。

核（kernel）与像（image）

- **定义与目的**：
- 核 $\ker T = \{\mathbf{v} \in V : T(\mathbf{v}) = \mathbf{0}\}$，正是零空间 $N(A)$；
- 像 $\operatorname{im} T = \{T(\mathbf{v}) : \mathbf{v} \in V\}$，正是列空间 $C(A)$。 两者都是**子空间**（核在输入空间里，像在输出空间里）。它们不依赖基的选择，因此是变换的内在属性。
- **几何直觉（它在空间中是什么样子？）**：核是"被压扁到原点的那一坨"（投影时是与投影方向垂直的整条线）；像是"这张方格纸在输出空间里实际铺到的地方"（投影时是一条线，而不是全平面）。**秩—零化度定理** $\dim \ker T + \dim \operatorname{im} T = n$ 说的就是：输入空间被分成"被压死的"与"被真正送出去的"两部分，维数加起来正好是全部。

- **具体示例**：投影 $P=\frac{1}{2}\begin{bmatrix}1&1\\1&1\end{bmatrix}$：$P(1,-1)^{\mathsf{T}}=(0,0)^{\mathsf{T}}$ 所以 $\ker T=\mathrm{span}\{(1,-1)\}$（1 维）；$P(1,1)^{\mathsf{T}}=(1,1)^{\mathsf{T}}$ 所以 $\mathrm{im}\,T=\mathrm{span}\{(1,1)\}$（1 维）。$1+1=2=n$。数值验算：$\mathrm{rank}\,P=1$，$\dim N(P)=1$。

线性变换的例子谱与反例

变换	定义	线性?	关键点
投影	$P\mathbf{x}$，$P^2=P$	是	核与像互补
旋转	绕原点转 θ	是	保长、保角，$\det=1$
反射	关于过原点直线	是	$S^2=I$，$\det=-1$
求导	$\frac{d}{dx}$ 作用在多项式/函数上	是	**奇异**，核 = 常函数
积分	$\int_0^x p(t)\,dt$	是	把 n 维送到 $n+1$ 维
转置	$T(M)=M^{\mathsf{T}}$ 作用在矩阵空间	是	矩阵空间本身是向量空间
平移	$T(\mathbf{x})=\mathbf{x}+\mathbf{x}_0$	否	$T(\mathbf{0})=\mathbf{x}_0\neq\mathbf{0}$
取模	$T(x)=	x	$	
取范数	$T(\mathbf{x})=\|\mathbf{x}\|$	否	输出是标量且 $T(-\mathbf{v})\neq -T(\mathbf{v})$
求最大值	$T(p)=p(x_0)$	是	求值是线性泛函

反例的精细讨论：为什么平移不是线性的

设 $T(\mathbf{x})=\mathbf{x}+\mathbf{x}_0$，$\mathbf{x}_0=(1,1)$。三种检测方式都会失败：

```
T(0,0) = (1,1) ≠ (0,0)                    ← 最快速的检测
T((1,0)+(0,1)) = T(1,1) = (2,2)
T(1,0)+T(0,1) = (2,1)+(1,2) = (3,3)       ← (2,2) ≠ (3,3)
```

但要注意一个反直觉的事实：**平移保持平行与等距**，它把方格纸平移成另一张方格纸，仍旧保持"格子的直线性与平行性"。所以"保持网格"只是必要而非充分条件；**充要条件是原点不动 + 网格等距**。这也说明为什么仿射变换（affine map）$T(\mathbf{x})=A\mathbf{x}+\mathbf{x}_0$ 需要额外加一笔常数项——它比线性变换多一个自由度。

计算步骤与手算演示

示例 1：绕原点旋转 θ 的矩阵（用标准基推导）

步骤 1：确定输入空间 $\mathbb{R}^2$ 的基，取标准基 $\mathbf{e}_1=(1,0)^{\mathsf{T}},\mathbf{e}_2=(0,1)^{\mathsf{T}}$；输出空间也用标准基。

步骤 2：求 $T(\mathbf{e}_1)$。向量 $(1,0)$ 指向正 x 轴，长度 1，与 x 轴夹角 0。逆时针转 θ 后，长度仍是 1，与 x 轴夹角变成 θ，所以

$$T(\mathbf{e}_1)=(\cos\theta,\ \sin\theta)^{\mathsf{T}}.$$

步骤 3：求 $T(\mathbf{e}_2)$。$(0,1)$ 指向正 y 轴，与 x 轴夹角 $\pi/2$。转后夹角 $\pi/2+\theta$，坐标

$$T(\mathbf{e}_2)=\left(\cos(\tfrac{\pi}{2}+\theta),\ \sin(\tfrac{\pi}{2}+\theta)\right)^{\mathsf{T}}=(-\sin\theta,\ \cos\theta)^{\mathsf{T}}.$$

步骤 4：把这两个输出**按列**写进矩阵：

$$R_\theta=\begin{bmatrix}\cos\theta&-\sin\theta\\\sin\theta&\cos\theta\end{bmatrix}.$$

步骤 5：数值检验。取 $\theta=90^\circ$：$\cos=0,\sin=1$，

$$R_{90^\circ}=\begin{bmatrix}0&-1\\1&0\end{bmatrix},\qquad R_{90^\circ}\mathbf{e}_1=(0,1)^{\mathsf{T}},\quad R_{90^\circ}\mathbf{e}_2=(-1,0)^{\mathsf{T}}.$$

两次 90° 旋转应等于 180° 旋转：

$$R_{90^\circ}^2=\begin{bmatrix}0&-1\\1&0\end{bmatrix}\begin{bmatrix}0&-1\\1&0\end{bmatrix}=\begin{bmatrix}-1&0\\0&-1\end{bmatrix}=-I.$$

与 $R_{180^\circ}=\begin{bmatrix}-1&0\\0&-1\end{bmatrix}$ 完全一致（脚本验算通过）。

步骤 6：取 $\theta=60^\circ$，$\cos 60^\circ=\frac{1}{2}$，$\sin 60^\circ=\frac{\sqrt{3}}{2}$：

$$R_{60^\circ}=\begin{bmatrix}1/2 & -\sqrt{3}/2\\ \sqrt{3}/2 & 1/2\end{bmatrix},\quad \operatorname{tr}R_{60^\circ}=1=2\cos 60^\circ,\quad \det R_{60^\circ}=1.$$

$R_{60^\circ}(1,0)^{\mathsf T}=(0.5,\ 0.866025)^{\mathsf T}$，验算通过。

【计算机制解说】：为什么"按列摆放"就是对的？因为矩阵乘法天生按列运作。设 $\mathbf{v}=\sum_j x_j\mathbf{v}_j$，由线性性

$$T(\mathbf{v})=\sum_j x_j T(\mathbf{v}_j)=\sum_j x_j\Big(\sum_i a_{ij}\mathbf{w}_i\Big)=\sum_i\Big(\sum_j a_{ij}x_j\Big)\mathbf{w}_i.$$

括号里的 $\sum_j a_{ij}x_j$ 恰好是 $A\mathbf{x}$ 的第 i 个分量。也就是说，**"线性"这个性质把无限多条信息压缩成 n 个数字**：只要知道 T 在基上的取值，T 在任意向量上的取值就完全确定。这正是矩阵能"代表"变换的全部理由，也是为什么"线性"是值得单独定义的性质。旋转的推导里，我们没有解任何方程，只用"旋转保持长度与夹角"这一几何事实就写出了 $T(\mathbf{e}_1),T(\mathbf{e}_2)$——这就是无坐标视角的威力。

示例 2：投影到直线 $y=x$ 上的矩阵（并验证它是投影）

步骤 1：先写出投影公式。直线 $y=x$ 的单位方向向量 $\mathbf{u}=\frac{1}{\sqrt{2}}(1,1)^{\mathsf T}$。向量 $\mathbf{x}=(x,y)^{\mathsf T}$ 在该直线上的投影是

$$T(\mathbf{x})=\frac{\mathbf{u}^{\mathsf T}\mathbf{x}}{\mathbf{u}^{\mathsf T}\mathbf{u}}\,\mathbf{u}=\frac{x+y}{\sqrt{2}}\cdot\frac{1}{\sqrt{2}}\begin{bmatrix}1\\1\end{bmatrix}=\begin{bmatrix}(x+y)/2\\(x+y)/2\end{bmatrix}.$$

步骤 2：求基向量的像。

$$T(\mathbf{e}_1)=T(1,0)=\begin{bmatrix}1/2\\1/2\end{bmatrix},\qquad T(\mathbf{e}_2)=T(0,1)=\begin{bmatrix}1/2\\1/2\end{bmatrix}.$$

步骤 3：按列摆放：

$$P=\begin{bmatrix}1/2 & 1/2\\ 1/2 & 1/2\end{bmatrix}=\frac{1}{2}\begin{bmatrix}1 & 1\\ 1 & 1\end{bmatrix}.$$

步骤 4：验证对称性 $P=P^{\mathsf T}$：矩阵两行相同、两列相同，转置把第 i 行搬到第 i 列：P 的两行都是 $(\frac{1}{2},\frac{1}{2})$、两列也都是 $(\frac{1}{2},\frac{1}{2})$，所以转置后每个位置的值不变，$P^{\mathsf T}=P$ ✓。

步骤 5：验证幂等性 $P^2=P$。

$$P^2=\frac{1}{4}\begin{bmatrix}1 & 1\\ 1 & 1\end{bmatrix}\begin{bmatrix}1 & 1\\ 1 & 1\end{bmatrix}=\frac{1}{4}\begin{bmatrix}1+1 & 1+1\\ 1+1 & 1+1\end{bmatrix}=\frac{1}{4}\begin{bmatrix}2 & 2\\ 2 & 2\end{bmatrix}=\frac{1}{2}\begin{bmatrix}1 & 1\\ 1 & 1\end{bmatrix}=P.\ \checkmark$$

步骤 6：几何抽样。取 $\mathbf{x}=(3,1)^{\mathsf T}$：

$$P\begin{bmatrix}3\\1\end{bmatrix}=\begin{bmatrix}0.5\cdot 3+0.5\cdot 1\\ 0.5\cdot 3+0.5\cdot 1\end{bmatrix}=\begin{bmatrix}2\\2\end{bmatrix},$$

与公式 $\left(\frac{3+1}{2},\frac{3+1}{2}\right)=(2,2)$ 一致（脚本验算通过）。

步骤 7：读出不变量（特征向量）。

$$P\begin{bmatrix}1\\1\end{bmatrix}=\begin{bmatrix}1\\1\end{bmatrix}(=1\cdot\mathbf{v}),\qquad P\begin{bmatrix}1\\-1\end{bmatrix}=\begin{bmatrix}0\\0\end{bmatrix}(=0\cdot\mathbf{v}).$$

沿直线方向的向量原封不动（特征值 1），垂直方向的向量被压成 0（特征值 0）。迹 $=1+0=1$，行列式 $=1\cdot 0=0$——脚本验算：$\operatorname{tr}P=1$，$\det P=0$。

步骤 8：核与像。$\ker T=\operatorname{span}\{(1,-1)\}$（垂直于直线），$\operatorname{im}T=\operatorname{span}\{(1,1)\}$（就是直线本身）。两者维数 $1+1=2=n$，秩—零化度定理成立，且 $\operatorname{rank}P=1$（脚本验算通过）。

【计算机制解说】：为什么投影矩阵必须**对称且幂等**？ – **幂等 $P^2=P$**：投影一次之后向量已经在直线上，再投影一次毫无变化。几何上就是"影子再投一次还是它自己"。 – **对称 $P=P^{\mathsf T}$**：这是**正交**投影（投影方向垂直于目标子空间）的标志。若用斜投影，$P^2=P$ 仍成立但 P 不对称。 – **迹 = 1 = 目标子空间维数**：一般地，投影矩阵 P 的迹等于它所投影到的子空间的维数（因为特征值只有 1 和 0，1 的重数就是维数）。这一条是快速检查投影矩阵是否算错的好办法。 – **行列式 = 0**：投影必然降维（把 2 维压成 1 维），所以不可逆，这是"P 奇异"的几何含义。

示例 3：求导变换 $T=\frac{d}{dx}$ 在多项式空间 $\mathcal{P}_2$ 上的矩阵（必看，含基约定说明）

这是一个**在函数空间上的线性变换**，它证明线性代数远不止于 $\mathbb{R}^n$。

约定（务必先声明）：取输入基与输出基都是 $\{1,x,x^2\}$，并按此顺序排列；多项式 $p(x)=a+bx+cx^2$ 的**坐标向量**是列向量 $(a,b,c)^{\mathsf T}$。即

$$p(x)=a\cdot 1+b\cdot x+c\cdot x^2 \longleftrightarrow \begin{bmatrix}a\\b\\c\end{bmatrix}.$$

步骤 1：逐个基向量求导，再把结果用输出基表示。

$$T(1)=0=0\cdot 1+0\cdot x+0\cdot x^2 \longleftrightarrow \begin{bmatrix}0\\0\\0\end{bmatrix},$$

$$T(x)=1=1\cdot 1+0\cdot x+0\cdot x^2 \longleftrightarrow \begin{bmatrix}1\\0\\0\end{bmatrix},$$

$$T(x^2)=2x=0\cdot 1+2\cdot x+0\cdot x^2 \longleftrightarrow \begin{bmatrix}0\\2\\0\end{bmatrix}.$$

步骤 2：按列摆放（第 j 列 = 第 j 个输入基向量的像的坐标）：

$$D=\begin{bmatrix}0&1&0\\0&0&2\\0&0&0\end{bmatrix}.$$

步骤 3：数值检验。取 $p(x)=3+5x+7x^2$，坐标 $(3,5,7)^{\mathsf T}$。

$$D\begin{bmatrix}3\\5\\7\end{bmatrix}=\begin{bmatrix}0\cdot 3+1\cdot 5+0\cdot 7\\0\cdot 3+0\cdot 5+2\cdot 7\\0\cdot 3+0\cdot 5+0\cdot 7\end{bmatrix}=\begin{bmatrix}5\\14\\0\end{bmatrix}\longleftrightarrow 5+14x.$$

直接求导：$\frac{d}{dx}(3+5x+7x^2)=5+14x$。**一致**（脚本验算通过）。

步骤 4：算 D^2（二阶导）。

$$D^2=\begin{bmatrix}0&1&0\\0&0&2\\0&0&0\end{bmatrix}\begin{bmatrix}0&1&0\\0&0&2\\0&0&0\end{bmatrix}=\begin{bmatrix}0&0&2\\0&0&0\\0&0&0\end{bmatrix}.$$

作用于 $(3,5,7)^{\mathsf T}$：$D^2(3,5,7)^{\mathsf T}=(14,0,0)^{\mathsf T}\longleftrightarrow 14$。直接算：$\frac{d^2}{dx^2}(3+5x+7x^2)=14$。**一致**。

步骤 5：$D^3=O$（零矩阵）。三阶导把 $\mathcal{P}_2$ 中一切都打成零——这也说明 D 是**幂零的**（nilpotent）。

步骤 6：秩与核。D 有两行独立（第 1、2 行），$\operatorname{rank}D=2$；$\dim N(D)=3-2=1$。零空间是什么？解 $D(a,b,c)^{\mathsf T}=(b,2c,0)^{\mathsf T}=\mathbf{0}$ 得 $b=c=0$，a 任取，即

$$N(D)=\left\{(a,0,0)^{\mathsf T}\right\}=\operatorname{span}\left\{\begin{bmatrix}1\\0\\0\end{bmatrix}\right\}\longleftrightarrow \text{常函数}.$$

脚本验算：$\operatorname{rank}D=2$，$\dim N(D)=1$。完美对应"$\frac{d}{dx}(\text{常数})=0$"。

步骤 7：一个漂亮的对比——用基 $\{1,x,x^2/2\}$ 会得到什么？留给读者推（提示：$T(x^2/2)=x$，矩阵会变成每列只有第 $j+1$ 行是 1 的"移位"矩阵）。

【计算机制解说】：这个例子同时完成了三件事。 1. **证明函数空间是向量空间，求导是线性变换**。核心是微积分里的两个基本法则：$(p+q)'=p'+q'$ 与 $(cp)'=cp'$。线性代数的定理（秩—零化度、奇异 ⇔ 有非零核）因此直接翻译成微积分的定理：**"求导在 $\mathcal{P}_2$ 上丢掉 1 维信息，丢掉的正是常数"**。 2. **显示"基约定"会改变矩阵的样子，但不变换秩**。若采用**行向量约定**（系数横排，T 左作用在行向量上，或等价地取转置），同一个 D 会写成

$$\begin{bmatrix}0&0&0\\1&0&0\\0&2&0\end{bmatrix}.$$

两个都"对"，取决于你把坐标当列还是当行。**写作时必须在开头声明约定**，否则讨论特征值、$\det$、D^2 时会自相矛盾。本文全程用**列向量**约定。 3. **上三角形态反映"基按次数递增排列"**。D 把 x^k 送到低一次的 kx^{k-1}，所以在这组有序基下必然是上三角且对角全 0——对角线为 0 直接说明所有特征值为 0，与幂零性一致。

示例 4：复合变换 = 矩阵乘法（"先旋转 90°，再投影到 x 轴"）

步骤 1：定义两个变换。– R：逆时针旋转 $90°$，$R=\begin{bmatrix}0&-1\\1&0\end{bmatrix}$；– P_x：投影到 x 轴，即 $T(x,y)=(x,0)$，$P_x=\begin{bmatrix}1&0\\0&0\end{bmatrix}$。

步骤 2：写出复合 $T(\mathbf{x})=P_x(R\mathbf{x})$，按矩阵结合的写法就是 $T\mathbf{x}=(P_xR)\mathbf{x}$。所以复合的矩阵是 P_xR。

步骤 3：算乘积。

$$P_xR=\begin{bmatrix}1&0\\0&0\end{bmatrix}\begin{bmatrix}0&-1\\1&0\end{bmatrix}=\begin{bmatrix}0&-1\\0&0\end{bmatrix}.$$

步骤 4：用基向量核验"复合"的含义。$\mathbf{e}_1=(1,0)^{\mathsf T}$：先转 $90°$ 得 $(0,1)^{\mathsf T}$，再投影得 $(0,0)^{\mathsf T}$；而 $(P_xR)\mathbf{e}_1=(0,0)^{\mathsf T}$ ✓。$\mathbf{e}_2=(0,1)^{\mathsf T}$：先转得 $(-1,0)^{\mathsf T}$，再投影得 $(-1,0)^{\mathsf T}$；而 $(P_xR)\mathbf{e}_2=(-1,0)^{\mathsf T}$ ✓。

步骤 5：用一个一般向量 $\mathbf{v}=(2,3)^{\mathsf T}$ 双重验算。先旋转：$R\mathbf{v}=(-3,2)^{\mathsf T}$；再投影：$(-3,0)^{\mathsf T}$。而 $(P_xR)\mathbf{v}=(-3,0)^{\mathsf T}$ ✓（脚本验算通过）。

步骤 6：**展示次序不可交换**。反过来先投影再旋转：

$$RP_x=\begin{bmatrix}0&-1\\1&0\end{bmatrix}\begin{bmatrix}1&0\\0&0\end{bmatrix}=\begin{bmatrix}0&0\\1&0\end{bmatrix}\neq P_xR.$$

两个结果的差别不是数值误差，而是本质的：RP_x 把 $\mathbf{v}=(2,3)^{\mathsf T}$ 送到 $(0,2)^{\mathsf T}$，与 $(-3,0)^{\mathsf T}$ 完全不同。

步骤 7：几何解释。P_xR 的像 = x 轴（1 维），核 = $\mathbf{span}\{(1,0)\}$（旋转后落到 y 轴，被投影杀掉）。RP_x 的像 = y 轴，核 = $\mathbf{span}\{(0,1)\}$。两个复合是**不同**的变换，只是恰好都是秩 1 的投影类映射。

【计算机制解说】：为什么 $(P_xR)\mathbf{x}=P_x(R\mathbf{x})$？因为矩阵乘法天生满足结合律：$(AB)\mathbf{x}=A(B\mathbf{x})$ 是**定义**层面的恒等式（把 $\mathbf{x}$ 的系数逐个分配即可验证）。由此得到的哲学结论是：

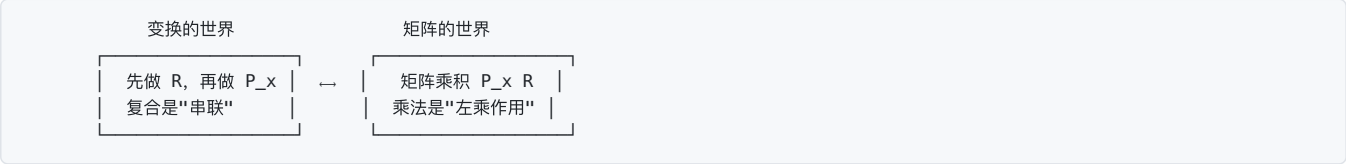

"先做"的那个变换写在右边。这是线性代数里最常被记反的一点：P_xR 意味着**先** R **后** P_x（从右往左读，像函数的复合 $f(g(x))$ 一样）。

示例 5（附加）：反射关于直线 $y=x$，$S=\begin{bmatrix}0&1\\1&0\end{bmatrix}$

按列构造：$S\mathbf{e}_1=(0,1)^{\mathsf T}$，$S\mathbf{e}_2=(1,0)^{\mathsf T}$。所以 $S=\begin{bmatrix}0&1\\1&0\end{bmatrix}$。性质（脚本验算）：$S^{\mathsf T}=S$，$S^2=I$，$\det S=-1$，特征值 $+1$（沿 $y=x$，不动）与 -1（沿 $y=-x$，被翻转）。$S(3,1)^{\mathsf T}=(1,3)^{\mathsf T}$ ✓。

反射与旋转的对比：旋转 $90°$ 给出 $R^2=-I$、$\det=1$（保向）；反射给出 $S^2=I$、$\det=-1$（反向）。**行列式的符号记录了"手性"是否被翻转**。

示例 6（附加）：转置作为 2×2 矩阵空间上的线性变换

取矩阵空间的基 $E_{11},E_{12},E_{21},E_{22}$（即 $\begin{bmatrix}1&0\\0&0\end{bmatrix},\begin{bmatrix}0&1\\0&0\end{bmatrix},\begin{bmatrix}0&0\\1&0\end{bmatrix},\begin{bmatrix}0&0\\0&1\end{bmatrix}$），坐标向量 $(a,b,c,d)^{\mathsf T}$ 代表 $\begin{bmatrix}a&b\\c&d\end{bmatrix}$。变换 $T(M)=M^{\mathsf T}$ 把 (a,b,c,d) 送到 (a,c,b,d)。按列构造：

$$T=\begin{bmatrix}1&0&0&0\\0&0&1&0\\0&1&0&0\\0&0&0&1\end{bmatrix}.$$

性质（脚本验算）：$T^2=I_4$（转置两次还原），$\mathbf{tr}\,T=2$，$\mathbf{rank}\,T=4$，特征值 $+1$（重数 3）与 -1（重数 1）。特征值 $+1$ 的特征空间 = 对称矩阵（3 维），-1 的特征空间 = 反对称矩阵（1 维），$3+1=4$ ✓。这再次说明**矩阵空间也是向量空间，"矩阵的函数"也可以是线性变换**（呼应讲次 11–12）。

示例 7（附加）：积分算子在 $\mathcal{P}_2$ 上——输出空间维数更高

$T(p)=\int_0^x p(t)\,dt$。用输入基 $\{1,x,x^2\}$、输出基 $\{1,x,x^2,x^3\}$：

$$T(1)=x,\qquad T(x)=\tfrac{x^2}{2},\qquad T(x^2)=\tfrac{x^3}{3}.$$

按列摆放得到 4×3 矩阵

$$I_4=\begin{bmatrix}0&0&0\\1&0&0\\0&1/2&0\\0&0&1/3\end{bmatrix}.$$

检验：$I_4(3,5,7)^{\mathsf{T}} = (0,3,2.5,7/3)^{\mathsf{T}} \approx (0,3,2.5,2.333333)^{\mathsf{T}}$，对应 $3x + \frac{5}{2}x^2 + \frac{7}{3}x^3$，与直接积分一致（脚本验算通过）。注意这是一个 4×3 矩阵——**变换的矩阵可以是长方形的**，因为输入输出空间的维数可以不同。

矩阵分解的核心思想

本讲不引入新的分解，但它给出了理解**所有**分解的统一语言：**分解 = 把一个变换拆成几个结构简单的变换的复合**。

- $A = LU$（讲次 1–5）：消元法把变换拆成"下三角变换 ∘ 上三角变换"。上三角意味着在特定基下"只把第 k 个分量往上送"，与示例 3 中的求导矩阵形态同源。
- $A = S\Lambda S^{-1}$（讲次 21–25）：矩阵"照片"之间的换算规则，本讲已埋下伏笔——它就是讲次 31 的换基 $B = W^{-1}AW$。$\Lambda = \mathrm{diag}(\lambda_i)$ 意味着：**在这组特殊基下，变换 T 退化成"每个方向各自拉伸 λ_i 倍"，方向之间互不干扰（解耦）**。
- $A = Q\Lambda Q^{\mathsf{T}}$（对称矩阵）：正交基下的解耦，保长且数值稳定。
- $A = U\Sigma V^{\mathsf{T}}$（SVD，讲次 29）：$A$ 的像空间与输入空间各配一组正交基，变换 = 旋转 ∘ 缩放 ∘ 旋转。
- **投影** $P = P^{\mathsf{T}} = P^2$：既是本讲的算例，也说明幂等分解 P 的"最小多项式是 $t^2 - t$"，即 P 只可能有两个特征值 $0, 1$。

一句话：**矩阵的"形状"反映的是基选得好不好；变换的"本性"（秩、核、像、特征值）不随基改变。**

与其他讲次的关联

- **与讲次 1–5（消元、$A = LU$）**：本讲首次把矩阵从"数的表格"提升为"变换的记录"。消元中的初等矩阵 E_{ij} 本身就是线性变换（把第 j 行减去 l 倍第 i 行），E_{ij}^{-1} 存在且易求。
- **与讲次 6–10（四个基本子空间）**：本讲给出翻译表：$N(A) = \ker T$，$C(A) = \mathrm{im}\, T$，$C(A^{\mathsf{T}}) = \mathrm{im}\, T^*$（转置变换的像），$N(A^{\mathsf{T}}) = \ker T^*$。秩—零化度定理就是维数公式。
- **与讲次 11–12（矩阵空间、图）**：矩阵空间 $\mathbb{R}^{m\times n}$ 是 mn 维向量空间，本讲的转置示例是标准演练；图上的关联矩阵 A 把"节点电位差"变成"边上的电流"，也是一个线性变换。
- **与讲次 14–17（正交、投影）**：示例 2 的 P 是正交投影的特例；一般地 $P = A(A^{\mathsf{T}}A)^{-1}A^{\mathsf{T}}$，本讲的"对称 + 幂等"验证方法完全通用。
- **与讲次 18–20（行列式）**：$\det R = 1$（旋转保体积）、$\det S = -1$（反射翻手性）、$\det P = 0$（投影降维），本讲的例子就是行列式几何意义的最佳素材。
- **与讲次 21–25（特征值）**：特征向量 = "被变换只拉伸不转向"的方向，示例 2、5、6 都直接读出了特征向量。
- **与讲次 27–29（正定、Jordan、SVD）**：D 的幂零性预告了 Jordan 形；SVD 的两组基预告了讲次 31 的换基。
- **与讲次 31（换基）**：本讲反复强调"矩阵依赖基"，下一讲立刻给出换基公式 $B = W^{-1}AW$。
- **与讲次 33（伪逆）**：本讲把投影看成变换；讲次 33 会把 AA^{+}、$A^{+}A$ 解释为**幂等的投影变换**，正好接续本讲示例 2 的检验方法。

关键要点

1. **线性变换的两个判据**：$T(\mathbf{v}+\mathbf{w}) = T(\mathbf{v}) + T(\mathbf{w})$ 与 $T(c\mathbf{v}) = cT(\mathbf{v})$；等价地 $T(c\mathbf{v} + d\mathbf{w}) = cT(\mathbf{v}) + dT(\mathbf{w})$。**最快检测：$T(\mathbf{0}) = \mathbf{0}$**（平移立刻出局）。
2. **造矩阵的黄金操作：问 T 对第 j 个基向量做了什么，把答案按列放进第 j 列。** 输出必须用输出空间的基表示。
3. **矩阵乘法 = 变换复合**：$(AB)\mathbf{x} = A(B\mathbf{x})$，**从右往左读**（右边的先作用）。次序不可交换：$P_x R \neq R P_x$。
4. **核 = 零空间，像 = 列空间**：$\dim \ker T + \dim \mathrm{im}\, T = \dim V$。变换的秩与核不依赖基，矩阵的具体数字依赖基。
5. **投影矩阵的三项体检**：$P^2 = P$（幂等）、$P^{\mathsf{T}} = P$（正交投影）、$\mathrm{tr}\, P = \dim(\text{目标子空间})$、$\det P = 0$（除恒等外必降维）。

常见误区与注意事项

1. **把"按列摆放"写成"按行摆放"**。矩阵 A 的第 j 列 = $T(\mathbf{v}_j)$ 的坐标。若写成行，得到的其实是 A^{T}，后续所有特征值、幂等性验证都会错。求导示例中若不声明约定，上三角与下三角两种写法都会出现，必须自己统一。
2. **误以为"保持直线与平行"就是线性**。平移保持直线与平行但不是线性。**判据是原点不动 + 可加 + 齐次**。
3. **忘记复合的次序**。$P_x R$ 是"先 R 后 P_x"。写代码时也要注意：想让向量先乘 R 再乘 P_x，应写 `Px @ (R @ v)` 或 `(Px @ R) @ v`，而不是 `R @ Px @ v`。
4. **把"投影到直线"与"投影到直线所在的方向向量"混淆**。$T(\mathbf{x}) = \frac{\mathbf{u}^{\mathsf{T}}\mathbf{x}}{\mathbf{u}^{\mathsf{T}}\mathbf{u}}\mathbf{u}$ 中分母必须有 $\mathbf{u}^{\mathsf{T}}\mathbf{u}$。若 $\mathbf{u}$ 是单位向量才可省略。用非单位向量 $\mathbf{u} = (1,1)^{\mathsf{T}}$ 算投影：$\frac{1}{2}\begin{bmatrix}1 & 1\\ 1 & 1\end{bmatrix}$——分母 2 就是 $\mathbf{u}^{\mathsf{T}}\mathbf{u}$。
5. **以为"非方阵不可能是变换的矩阵"**。示例 7 的求导/积分证明长方形矩阵完全合法。输入 n 维、输出 m 维，矩阵就是 $m \times n$。
6. **把 $\ker T$ 与 $\mathrm{im}\, T$ 放错空间**。$\ker T \subseteq V$（输入空间），$\mathrm{im}\, T \subseteq W$（输出空间）。投影到 $y = x$ 时，$\ker$ 和 im 都恰好是 $\mathbb{R}^2$ 的子空间，容易造成"都在同一个空间"的错觉；换成求导（3 维 $\to$ 常数维）就更清楚。
7. **误以为"矩阵相同 = 变换相同"**。同一矩阵在不同基下代表不同变换；同一变换在不同基下是不同的矩阵。**"矩阵 = 变换" 这句话只在基固定时成立。**

思考题（带答案）

Q1.（纯计算）设 $T:\mathbb{R}^2\to\mathbb{R}^2$ 满足 $T(1,1)^{\mathsf T}=(2,0)^{\mathsf T}$ 且 $T(1,-1)^{\mathsf T}=(0,2)^{\mathsf T}$。求 T 在标准基下的矩阵，并求 $T(3,1)^{\mathsf T}$。

▸ 答案

方法：先用"作用于基"求出 T 对标准基的作用，再按列摆放。

已知的两个输入 $\mathbf{u}_1=(1,1)^{\mathsf T},\mathbf{u}_2=(1,-1)^{\mathsf T}$ 恰好构成一组基（它们不正交但线性无关）。先求它们的像的坐标：$T(\mathbf{u}_1)=(2,0)^{\mathsf T}$，$T(\mathbf{u}_2)=(0,2)^{\mathsf T}$。

由线性性，

$$T\begin{bmatrix}1\\0\end{bmatrix}=T\Big(\frac{\mathbf{u}_1+\mathbf{u}_2}{2}\Big)=\frac{T(\mathbf{u}_1)+T(\mathbf{u}_2)}{2}=\frac{(2,0)+(0,2)}{2}=\begin{bmatrix}1\\1\end{bmatrix},$$

$$T\begin{bmatrix}0\\1\end{bmatrix}=T\Big(\frac{\mathbf{u}_1-\mathbf{u}_2}{2}\Big)=\frac{T(\mathbf{u}_1)-T(\mathbf{u}_2)}{2}=\frac{(2,0)-(0,2)}{2}=\begin{bmatrix}1\\-1\end{bmatrix}.$$

按列摆放：

$$A=\begin{bmatrix}1&1\\1&-1\end{bmatrix}.$$

于是

$$T\begin{bmatrix}3\\1\end{bmatrix}=A\begin{bmatrix}3\\1\end{bmatrix}=\begin{bmatrix}1\cdot3+1\cdot1\\1\cdot3+(-1)\cdot1\end{bmatrix}=\begin{bmatrix}4\\2\end{bmatrix}.$$

核对：直接算 $T(\mathbf{u}_1)=A(1,1)^{\mathsf T}=(2,0)^{\mathsf T}$ ✓；$T(\mathbf{u}_2)=A(1,-1)^{\mathsf T}=(0,2)^{\mathsf T}$ ✓。另外 $\det A=-2\neq0$，所以 T 可逆——它把基 $\{\mathbf{u}_1,\mathbf{u}_2\}$ 送到 $\{(2,0),(0,2)\}$，是一个保持独立性的变换。

Q2.（概念理解）判断下列变换是否线性，并给出理由。(a) $T(x,y)=(x+1,\ y)$；(b) $T(x,y)=(2x,\ 3y)$；(c) $T(x,y)=(xy,\ 0)$；(d) $T(p)=p''+2p'$ 作用在 $\mathcal{P}_3$ 上；(e) $T(x,y)=(\|(x,y)\|,0)$。

▸ 答案

(a) **不是**。$T(0,0)=(1,0)\neq(0,0)$。它是沿 x 方向的平移。(b) **是**。$T(c(x,y)+d(u,v))=(2(cx+du),\,3(cy+dv))=c(2x,3y)+d(2u,3v)$。矩阵是 $\mathrm{diag}(2,3)$。(c) **不是**。$T(1,0)=(0,0)$、$T(0,1)=(0,0)$，但 $T(1,1)=(1,0)\neq(0,0)+(0,0)$，破坏可加性。它连 $T(\mathbf{e}_1+\mathbf{e}_2)=T(\mathbf{e}_1)+T(\mathbf{e}_2)$ 都不满足。（注意它是二次型，不是线性变换；但 xy 作为 $\mathbb{R}^2$ 上的函数对应双线性形式。）(d) **是**。导数是线性的：$(p+q)''+2(p+q)'=(p''+2p')+(q''+2q')$，且 $(cp)''+2(cp)'=c(p''+2p')$。在基 $\{1,x,x^2,x^3\}$ 下，$T(1)=0$，$T(x)=2$，$T(x^2)=2+4x$，$T(x^3)=6x+6x^2$，所以

$$A=\begin{bmatrix}0&2&2&0\\0&0&4&6\\0&0&0&6\\0&0&0&0\end{bmatrix}.$$

(e) **不是**。$T(-\mathbf{x})=(\|\mathbf{x}\|,0)=T(\mathbf{x})$，但要求 $T(-\mathbf{x})=-T(\mathbf{x})$，即 $(\|\mathbf{x}\|,0)=(-\|\mathbf{x}\|,0)$，只有 $\mathbf{x}=\mathbf{0}$ 成立。齐次性被破坏。

Q3.（计算 + 推理）设 $P=\frac12\begin{bmatrix}1&1\\1&1\end{bmatrix}$ 是投影到 $y=x$ 的矩阵，$S=\begin{bmatrix}0&1\\1&0\end{bmatrix}$ 是关于 $y=x$ 的反射。计算 PS、SP、SPS，并用几何语言解释每个结果。

▸ 答案

$$PS=\frac12\begin{bmatrix}1&1\\1&1\end{bmatrix}\begin{bmatrix}0&1\\1&0\end{bmatrix}=\frac12\begin{bmatrix}1&1\\1&1\end{bmatrix}=\frac12\begin{bmatrix}1&1\\1&1\end{bmatrix}=P,$$

（逐项：第 1 行第 1 列 $=0\cdot1+1\cdot1=1$，除以 2 得 $1/2$；其余同理。）

$$SP = \begin{bmatrix}0 & 1\\ 1 & 0\end{bmatrix}\frac{1}{2}\begin{bmatrix}1 & 1\\ 1 & 1\end{bmatrix} = \frac{1}{2}\begin{bmatrix}1 & 1\\ 1 & 1\end{bmatrix} = P.$$

$$SPS = S(PS) = SP = P.$$

几何解释：S 是沿直线 $y = x$ 的反射。反射后再投影到该直线，与直接投影结果相同——因为反射**不改变向量在直线上的分量**（只翻转垂直分量），而投影只保留沿直线分量。同理先投影再反射：投影结果已在直线上，反射不动它。所以 $PS = SP = P$，即 P **与** S **可交换**。三个结果都是 P。

额外收获：$SPS = P$ 且 $S^2 = I$，所以 S 给出 P 的一个"相似矩阵仍为自己"的例子——这对矩阵在基变换下保持不变（讲次 31）。

附录 A：变换前后的向量图（几何总览）

下面这张图把本讲最重要的四个变换画在同一张 $\mathbb{R}^2$ 图上：原始网格 → 变换后网格。**看"网格变成什么形状"，比记矩阵更快**。

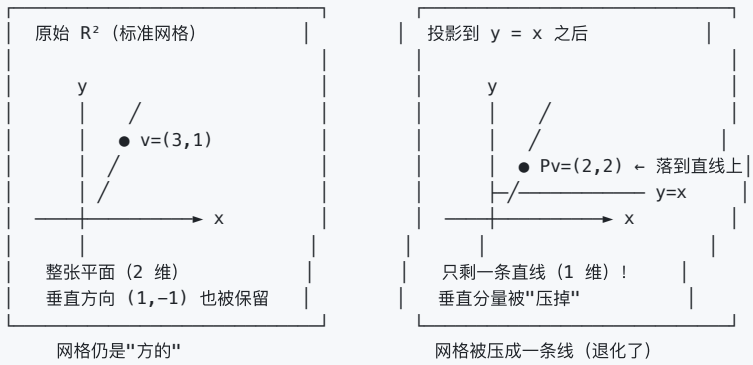

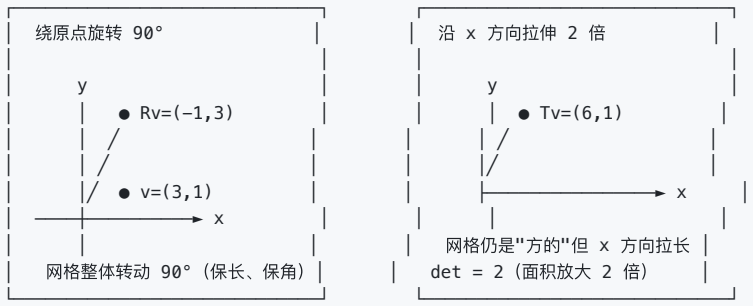

判据速记：

变换	原点动?	网格形状	行列式	可逆?
投影	不动	压成线	0	不可逆
旋转	不动	方形 (转)	+1	可逆
反射	不动	方形 (翻)	−1	可逆
拉伸(2,3倍)	不动	长方形	+6	可逆
平移	动了!	方形 (移)	—	(非线性的)

← 最后一行的"原点动了"就是平移唯一的破绽

附录 B：常见线性变换矩阵速查表（$\mathbb{R}^2$，标准基）

变换	定义式	矩阵	迹	行列式	特征值	核
恒等	$\mathbf{x} \mapsto \mathbf{x}$	$\begin{bmatrix}1 & 0\\ 0 & 1\end{bmatrix}$	2	1	$1, 1$	$\{\mathbf{0}\}$
零变换	$\mathbf{x} \mapsto \mathbf{0}$	$\begin{bmatrix}0 & 0\\ 0 & 0\end{bmatrix}$	0	0	$0, 0$	$\mathbb{R}^2$
投影到 x 轴	$(x, y) \mapsto (x, 0)$	$\begin{bmatrix}1 & 0\\ 0 & 0\end{bmatrix}$	1	0	$1, 0$	y 轴
投影到 $y = x$	$(x, y) \mapsto \frac{x+y}{2}(1, 1)$	$\frac{1}{2}\begin{bmatrix}1 & 1\\ 1 & 1\end{bmatrix}$	1	0	$1, 0$	$\mathrm{span}(1, -1)$

变换	定义式	矩阵	迹	行列式	特征值	核
投影到 $y=-x$	$(x,y)\mapsto\frac{x-y}{2}(1,-1)$	$\frac{1}{2}\begin{bmatrix}1&-1\\-1&1\end{bmatrix}$	1	0	$1, 0$	$\mathrm{span}(1,1)$
旋转 θ	逆时针转 θ	$\begin{bmatrix}\cos\theta&-\sin\theta\\\sin\theta&\cos\theta\end{bmatrix}$	$2\cos\theta$	1	$e^{\pm i\theta}$	$\{0\}$
旋转 $90°$	—	$\begin{bmatrix}0&-1\\1&0\end{bmatrix}$	0	1	$\pm i$	$\{0\}$
反射（y 轴）	$(x,y)\mapsto(-x,y)$	$\begin{bmatrix}-1&0\\0&1\end{bmatrix}$	0	-1	$1, -1$	$\{0\}$
反射（$y=x$）	$(x,y)\mapsto(y,x)$	$\begin{bmatrix}0&1\\1&0\end{bmatrix}$	0	-1	$1, -1$	$\{0\}$
拉伸	$(x,y)\mapsto(2x,3y)$	$\begin{bmatrix}2&0\\0&3\end{bmatrix}$	5	6	$2, 3$	$\{0\}$
剪切	$(x,y)\mapsto(x+y,y)$	$\begin{bmatrix}1&1\\0&1\end{bmatrix}$	2	1	$1, 1$（不可对角化）	$\{0\}$

三条自检规则：1. 行列式 $=0$ ⇔ 有非零核 ⇔ 不可逆 ⇔ 降维。2. 迹 = 特征值之和；对称矩阵/三角矩阵的迹与行列式最容易手算（$\det=ad-bc$）。3. 若 $\det$ 为负，变换翻转手性（左右手互换）；若 $|\det|=1$，面积保持不变。

验算样例（脚本通过）：投影 $y=x$ 的 $\mathrm{tr}=1$、$\det=0$、特征值 $1, 0$；反射 $y=x$ 的 $S^2=I$、$\det=-1$、特征值 $1, -1$；拉伸 $(2,3)$ 的 $\mathrm{tr}=5$、$\det=6$、特征值 $2, 3$。

附录 C：离散求导——从多项式求导到差分矩阵

示例 3 的求导算子 D 有一个极其有用的离散版本。把区间 $[0,1]$ 上的函数 f 在节点 $h=\frac{1}{n}$ 处采样得 $\mathbf{f}=(f_1,\dots,f_n)^{\mathsf{T}}$，用**前向差分**近似导数：

$$(D\mathbf{f})_i=\frac{f_{i+1}-f_i}{h}.$$

这给出一个 $(n-1)\times n$ 矩阵。取 $n=4$、$h=1$：

$$D_4=\begin{bmatrix}-1&1&0&0\\0&-1&1&0\\0&0&-1&1\end{bmatrix}.$$

核验（脚本验算）：$D_4(1,1,1,1)^{\mathsf{T}}=(0,0,0)^{\mathsf{T}}$ ✓ —— **常函数的导数为零，与连续情形完全一致。** $D_4(1,2,3,4)^{\mathsf{T}}=(1,1,1)^{\mathsf{T}}$ ✓（D_4 是 3×4，结果按定义是 3 维）—— 对 $f_i=c\cdot i$ 得到常数斜率，也一致。秩与核：D_4 是 3×4，它的三行是 $(-1,1,0,0)$、$(0,-1,1,0)$、$(0,0,-1,1)$——逐行看，第 1 行的首个非零元在第 1 位，第 2 行在第 2 位，第 3 行在第 3 位，**首非零元的位置严格递增**，故线性无关（行阶梯形判据），$\mathrm{rank}=3$，$\dim N(D_4)=4-3=1$，零空间正是常数向量 $\mathrm{span}\{(1,1,1,1)\}$。

与示例 3 的对照：

	连续求导 D	离散差分 D_4
形状	3×3	3×4
秩	2	3
$\dim N$	1（常函数）	1（常数向量）
形态	上三角	双对角（带状）
幂零性	$D^3=O$	不成立（非方阵）

这个对照的意义：连续求导是**方阵但奇异**（因为多项式空间"闭合"），离散差分是**长方形且满行秩**（因为网格边界少一个点）。**同一个数学操作，在不同空间的基下呈现完全不同的矩阵形状**——这正是"矩阵依赖基、变换不依赖基"的最佳注解。

附录 D：判定与构造的完整工作流

面对"T 是什么样的线性变换"这类问题，按下面五步走，不会出错：

```
步骤 1  检查 T(0) = 0 ？            ← 不等则直接判定"非线性"，结束
──────────────────────────────────────────────────────
步骤 2  检查 T(cv+dw) = cT(v)+dT(w) ？  ← 用符号推导，别只试数字
──────────────────────────────────────────────────────
步骤 3  确定输入空间的基 v1..vn      ← 以及输出空间的基 w1..wm
──────────────────────────────────────────────────────
步骤 4  逐个求 T(vj)，并把它写成输出基的线性组合
          （这部分是"解小方程组"，别偷懒跳过）
──────────────────────────────────────────────────────
步骤 5  按列摆放：A 的第 j 列 = 步骤 4 的系数向量
──────────────────────────────────────────────────────
检查    用几个随机向量验证 A x 与 T(x) 是否一致
检查    rank(A) = dim im T，n − rank(A) = dim ker T
```

为什么第 4 步最容易出错：如果输出基不是标准基，"写成分解式"这一步就真的有算术量。例如示例 3 中 $T(x^2)=2x$，在基 $\{1,x,x^2\}$ 下坐标是 $(0,2,0)$ 而不是 $(0,0,2)$——**必须让第 2 个位置（对应 x）拿到系数 2**。

验算流程（可直接照抄）：

```
// 用脚本验证"矩阵 = 变换"的一致性
const A = [[0,1,0],[0,0,2],[0,0,0]];        // 约定：基 1,x,x^2，列向量
const Tpoly = (a,b,c) => [b, 2*c, 0];        // T = d/dx：a+bx+cx^2 -> b+2cx
const coords = [3,5,7];                      // p = 3+5x+7x^2
const viaMatrix = A.map(r => r.reduce((s,v,i) => s+v*coords[i], 0));
console.log(viaMatrix, Tpoly(...coords));    // 两者必须相等 -> [5,14,0]
```

附录 E：核与像的维数账本（把讲次 6–10 翻译过来）

设 $T:\mathbb{R}^n\to\mathbb{R}^m$，矩阵 A（$m\times n$），$r=\operatorname{rank}A$。四个基本子空间的变换语言版本：

子空间	讲次 6–10 的说法	变换语言	维数	住在哪
$C(A)$	列空间	$\operatorname{im}T$（像）	r	$\mathbb{R}^m$（输出空间）
$N(A)$	零空间	$\ker T$（核）	$n-r$	$\mathbb{R}^n$（输入空间）
$C(A^{\mathsf T})$	行空间	$\operatorname{im}T^*$（转置变换的像）	r	$\mathbb{R}^n$（输入空间）
$N(A^{\mathsf T})$	左零空间	$\ker T^*$	$m-r$	$\mathbb{R}^m$（输出空间）

正交关系（讲次 10）在变换语言下：$\ker T=(\operatorname{im}T^*)^{\perp}$，$\ker T^*=(\operatorname{im}T)^{\perp}$。即**核是"像的正交补"，反过来也成立**。

用投影 $P=\frac12\begin{bmatrix}1&1\\1&1\end{bmatrix}$ 核验账本（$n=m=2$，$r=1$）：– $C(P)=\operatorname{span}\{(1,1)\}$，维数 1 ✓ – $N(P)=\operatorname{span}\{(1,-1)\}$，维数 $2-1=1$ ✓ – $C(P^{\mathsf T})=C(P)=\operatorname{span}\{(1,1)\}$（对称！），维数 1 ✓ – $N(P^{\mathsf T})=N(P)=\operatorname{span}\{(1,-1)\}$，维数 $2-1=1$ ✓ – 正交：$(1,-1)\cdot(1,1)=1-1=0$ ✓ – 核与像的维数和 $1+1=2=n$ ✓

翻译三条定理：1. **秩—零化度**：$\dim\ker T+\dim\operatorname{im}T=n$ → "被压死的 + 被送出的 = 全部输入"。 2. **可逆性**：T 可逆 $\Leftrightarrow\ker T=\{0\}$ 且 $\operatorname{im}T=W$ → "T 既单又满"。 3. **一对一**：$\ker T=\{0\}\Leftrightarrow T$ 是单射 → "没有两个不同的输入被送到同一个输出"。

附录 F：变换复合的两种读法与测验

测验：下面的等式是否成立？

$$\text{(i) } (AB)^{\mathsf T}=B^{\mathsf T}A^{\mathsf T}\qquad \text{(ii) } (AB)^{-1}=B^{-1}A^{-1}\qquad \text{(iii) } (AB)^2=A^2B^2.$$

答案与变换解释：– (i) **成立**。用变换语言：B 先作用、A 后作用；转置（伴随）会把顺序颠倒——**先转置的变成后转置的**。 – (ii) **成立**（当两者都可逆）。"先 B 后 A"的逆必须是"先撤销 A 再撤销 B"，所以是 $B^{-1}A^{-1}$。**穿鞋脱鞋顺序相反**。 – (iii) **一般不成立**！$(AB)(AB)=ABAB\neq AABB$，除非 A,B 可交换（$AB=BA$）。几何上：先拉伸再旋转，与拉伸两次，完全是两回事。

验算例（脚本通过）：

$$A=\begin{bmatrix}1&1\\0&1\end{bmatrix}\text{（剪切）},\quad B=\begin{bmatrix}2&0\\0&1\end{bmatrix}\text{（拉伸）},\quad AB=\begin{bmatrix}2&1\\0&1\end{bmatrix},\quad BA=\begin{bmatrix}2&2\\0&1\end{bmatrix},$$

$$AB\neq BA,\qquad (AB)^2=\begin{bmatrix}4&3\\0&1\end{bmatrix}\neq A^2B^2=\begin{bmatrix}1&2\\0&1\end{bmatrix}\begin{bmatrix}4&0\\0&1\end{bmatrix}=\begin{bmatrix}4&2\\0&1\end{bmatrix}.$$

结论：非交换性是变换复合的内在属性，不是矩阵的缺陷。

附录 G：三条延伸思考（不附答案，供自测）

1. 设 $T:\mathbb{R}^{2\times2}\to\mathbb{R}^{2\times2}$ 定义为 $T(M)=M+M^{\mathsf{T}}$。它是线性的吗？它的核与像是什么？（提示：核 = 反对称矩阵，像 = 对称矩阵，两个维数相加 $1+3=4$ ✓。用附录 E 的转置示例数据可验证。）
2. 设 $T(p)=p(x)p'(x)$ 作用在多项式上。它是线性的吗？（提示：考察 $T(p+q)$，会发现交叉项 $p'q+pq'$ 无法消去。）
3. 若 $T:\mathbb{R}^3\to\mathbb{R}^3$ 把每个向量投影到平面 $x+y+z=0$ 上，T 的矩阵是什么？它的迹是多少？（提示：先求平面法向 $\mathbf{n}=(1,1,1)^{\mathsf{T}}$，投影矩阵 $P=I-\frac{\mathbf{n}\mathbf{n}^{\mathsf{T}}}{\mathbf{n}^{\mathsf{T}}\mathbf{n}}$，迹 $=3-1=2$ = 平面维数 ✓。）

Lecture 31: Change of Basis; Image Compression

概述

同一栋房子在不同坐标系下有不同的地址；同一个线性变换在不同基下有不同的矩阵。本讲回答两个问题：**（1）换基时矩阵如何换算？答案是 $B=W^{-1}AW$（相似变换）。（2）为什么我们要主动换基？因为好基能让矩阵变得稀疏/对角。"对角化 $A=S\Lambda S^{-1}$"其实就是"换成特征向量基"的特例。** 我们把这条思想推向应用：图像压缩 = 在 DCT/小波基下展开 + 丢掉小系数，这与讲次 29 的 SVD 低秩逼近是同一枚硬币的两面。

核心概念的几何直觉

基与坐标（basis and coordinates）

- **定义与目的**：$\mathbb{R}^n$ 的一组基 $\mathbf{v}_1,\dots,\mathbf{v}_n$ 是**线性无关且张成整个空间**的 n 个向量。任意 $\mathbf{x}\in\mathbb{R}^n$ 有**唯一**的展开

$$\mathbf{x}=c_1\mathbf{v}_1+\cdots+c_n\mathbf{v}_n.$$

数字 $c_1,\dots,c_n$ 就是 $\mathbf{x}$ 在这组基下的**坐标**。把基向量按列堆成矩阵 $V=[\mathbf{v}_1\ \cdots\ \mathbf{v}_n]$，则

$$\mathbf{x}=V\mathbf{c},\qquad \mathbf{c}=V^{-1}\mathbf{x}.$$

- **几何直觉（它在空间中是什么样子？）**：基就是"尺子"。同一个点，用不同的尺子量出不同的读数。标准基下的坐标 $(3,1)$ 是在说"沿 x 方向走 3，沿 y 方向走 1"；换成基 $\{\frac{1}{\sqrt2}(1,1),\frac{1}{\sqrt2}(1,-1)\}$，读数变成 $(2\sqrt2,\sqrt2)$，是在说"沿对角线走 $2\sqrt2$，沿反对角线走 $\sqrt2$"。**点没动，读数变了。**

两个关键子情形：– **正交基**（$V^{\mathsf{T}}V=I$）：$V^{-1}=V^{\mathsf{T}}$，换基只需转置，"免费"且数值稳定（讲次 17）。此时 $\|\mathbf{x}\|^2=\|\mathbf{c}\|^2$（保长/Parseval）。 – **非正交基**：必须真算 V^{-1}。若基向量很接近平行，V 病态，换基会放大误差。

- **具体示例**：$\mathbf{x}=(3,1)^{\mathsf{T}}$，正交基 $\mathbf{w}_1=\frac{1}{\sqrt2}(1,1)^{\mathsf{T}},\mathbf{w}_2=\frac{1}{\sqrt2}(1,-1)^{\mathsf{T}}$。

$$W=\frac{1}{\sqrt2}\begin{bmatrix}1&1\\1&-1\end{bmatrix},\qquad W^{\mathsf{T}}W=I,$$

$$\mathbf{c}=W^{\mathsf{T}}\mathbf{x}=\frac{1}{\sqrt2}\begin{bmatrix}1&1\\1&-1\end{bmatrix}\begin{bmatrix}3\\1\end{bmatrix}=\frac{1}{\sqrt2}\begin{bmatrix}4\\2\end{bmatrix}=\begin{bmatrix}2\sqrt2\\\sqrt2\end{bmatrix}\approx\begin{bmatrix}2.828427\\1.414214\end{bmatrix}.$$

回代 $W\mathbf{c}=(3,1)^{\mathsf{T}}$ ✓（脚本验算通过）。

换基公式 $B=W^{-1}AW$（相似变换）

- **定义与目的**：设 $T:\mathbb{R}^n\to\mathbb{R}^n$。在**旧基**（标准基）下 T 的矩阵是 A；在**新基** $\mathbf{w}_1,\dots,\mathbf{w}_n$ 下是 B。令 $W=[\mathbf{w}_1\ \cdots\ \mathbf{w}_n]$，则

$$B=W^{-1}AW.$$

等价写法：若记 $M=W^{-1}$，则 $B=MWM^{-1}$ 与 $B=W^{-1}AW$ 是**同一件事**——只是"谁叫 W"的命名差异。**必须盯住 W 的定义，不要背公式。**

- **几何直觉（它在空间中是什么样子？）**：三层电梯，进出一趟就回到原地：

```
新坐标 c ──(乘 W)──► 旧坐标 x = W c
                          │
                          │ 乘 A：在旧基下做变换 T
                          ▼
新坐标 c' = W⁻¹(A x) ◄──(乘 W⁻¹)── 旧坐标 A x

于是  c' = (W⁻¹ A W) c ，即  B = W⁻¹ A W
```

一句话：**用 W 把新坐标翻译成旧坐标 → 用熟悉的 A 干活 → 用 W^{-1} 把结果翻译回新坐标。**

- **具体示例（对角化的几何解释）**：如果新基选的正是 A 的**特征向量**，$W=S=[\mathbf{s}_1\ \cdots\ \mathbf{s}_n]$，那么 $A\mathbf{s}_j=\lambda_j\mathbf{s}_j$，于是 $S^{-1}AS=\Lambda=\operatorname{diag}(\lambda_1,\dots,\lambda_n)$。**"对角化"没有魔法，它就是"换成特征向量基"，使变换在每个基方向上是独立的一次拉伸。**

图像压缩（image compression）

- **定义与目的**：灰度图像 = 像素亮度矩阵（如 256×256，取值 $0 \sim 255$）。压缩的通用套路：
- **分块**：切成 8×8 的小块；
- **换基**：每块用一组二维基函数展开，得到系数矩阵 $C = W^{\mathsf{T}} B W$（若基正交）；
- **量化 + 丢弃**：小的系数直接置零（或粗量化），只保留少数大系数；
- **存储**：只存非零系数的位置与数值（游程编码 / 熵编码）；
- **重建**：$\hat{B} = W \hat{C} W^{\mathsf{T}}$。
- **几何直觉（它在空间中是什么样子？）**：像素矩阵 B 是 $\mathbb{R}^{8\times 8}$（64 维空间）里的一个点。**换基 = 换到一组"图像模式"（模式 = 平滑块、水平条纹、垂直条纹、棋盘格……）的坐标系里，坐标就是"这块图里有多少这种模式"。** 自然图像大多平滑，于是能量集中在少数几个低频模式上——这就是稀疏性。**压缩的数学本质：找到一组基，让信号在该基下稀疏。**
- **具体示例（JPEG 用 DCT，JPEG2000 用小波）**：8 点 DCT-II 基（正交）

$$C_{k,n} = a_k \cos\!\left(\frac{\pi(2n+1)k}{16}\right), \quad a_0 = \frac{1}{\sqrt{8}},\ a_k = \sqrt{\frac{2}{8}}\ (k \geq 1),$$

$k = 0, 1, 2$ 三行是

```
k=0:  0.3536  0.3536  0.3536  0.3536  0.3536  0.3536  0.3536  0.3536   ← 直流/平均
k=1:  0.4904  0.4157  0.2778  0.0975 -0.0975 -0.2778 -0.4157 -0.4904   ← 最低频振荡
k=2:  0.4619  0.1913 -0.1913 -0.4619 -0.4619 -0.1913  0.1913  0.4619   ← 次低频
```

二维 DCT 就是 $C = WBW^{\mathsf{T}}$（W 的行是 DCT 基向量），逆变换 $\hat{B} = W^{\mathsf{T}} \hat{C} W$。

计算步骤与手算演示

示例 1（本讲主戏）：投影到 $y = x$，从标准基换到"直线基"

步骤 1：写出旧基下的矩阵。 标准基下（讲次 30 示例 2）

$$A = P = \frac{1}{2}\begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix}.$$

步骤 2：选定新基。

$$\mathbf{w}_1 = \frac{1}{\sqrt{2}}\begin{bmatrix} 1 \\ 1 \end{bmatrix} (\text{沿 } y = x), \qquad \mathbf{w}_2 = \frac{1}{\sqrt{2}}\begin{bmatrix} 1 \\ -1 \end{bmatrix} (\perp y = x),$$

$$W = [\mathbf{w}_1 \quad \mathbf{w}_2] = \frac{1}{\sqrt{2}}\begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}.$$

步骤 3：求 W^{-1}（正交，$W^{-1} = W^{\mathsf{T}}$）。 先验证正交性：

$$W^{\mathsf{T}} W = \frac{1}{2}\begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}\begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} = \frac{1}{2}\begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} = I. \ \checkmark$$

（验算通过。）所以

$$W^{-1} = W^{\mathsf{T}} = \frac{1}{\sqrt{2}}\begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}.$$

注意这里 W 对称，所以 $W^{-1} = W^{\mathsf{T}} = W$——这是巧合（对合基），不能推广。

步骤 4：算 $W^{-1}AW = B$。 一步步来，先算 AW：

$$AW = \frac{1}{2}\begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix} \cdot \frac{1}{\sqrt{2}}\begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} = \frac{1}{2\sqrt{2}}\begin{bmatrix} 1+1 & 1-1 \\ 1+1 & 1-1 \end{bmatrix} = \frac{1}{2\sqrt{2}}\begin{bmatrix} 2 & 0 \\ 2 & 0 \end{bmatrix} = \frac{1}{\sqrt{2}}\begin{bmatrix} 1 & 0 \\ 1 & 0 \end{bmatrix}.$$

（机制：A 把第 1 列 $\mathbf{w}_1$ 原样保留，把第 2 列 $\mathbf{w}_2$ 打成零——因为 $\mathbf{w}_1$ 是特征向量 $\lambda = 1$，$\mathbf{w}_2$ 是特征向量 $\lambda = 0$。）

再左乘 $W^{-1} = W^{\mathsf{T}}$：

$$B = W^{\mathsf{T}}(AW) = \frac{1}{\sqrt{2}}\begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \cdot \frac{1}{\sqrt{2}}\begin{bmatrix} 1 & 0 \\ 1 & 0 \end{bmatrix} = \frac{1}{2}\begin{bmatrix} 1+1 & 0 \\ 1-1 & 0 \end{bmatrix} = \frac{1}{2}\begin{bmatrix} 2 & 0 \\ 0 & 0 \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix} = \mathbf{diag}(1, 0). \ \checkmark$$

步骤 5：不变量核验。 $\mathrm{tr}\, B = 1 = \mathrm{tr}\, A$ ✓；$\det B = 0 = \det A$ ✓（验算通过）。

步骤 6：坐标流水线核验。 取 $\mathbf{x} = (3, 1)^{\mathsf{T}}$：
– 新坐标 $\mathbf{c} = W^{\mathsf{T}}\mathbf{x} = (2\sqrt{2},\ \sqrt{2})^{\mathsf{T}} \approx (2.828427, 1.414214)^{\mathsf{T}}$；
– 在旧基下做投影：$A\mathbf{x} = (2, 2)^{\mathsf{T}}$；
– $A\mathbf{x}$ 的新坐标：$W^{\mathsf{T}}(A\mathbf{x}) = (2\sqrt{2},\ 0)^{\mathsf{T}}$；
– 直接算 $B\mathbf{c} = \mathbf{diag}(1, 0)(2\sqrt{2}, \sqrt{2})^{\mathsf{T}} = (2\sqrt{2}, 0)^{\mathsf{T}}$；
– **两者相同** ✓（验算通过），这正是 $B\mathbf{c} = W^{\mathsf{T}}AW\mathbf{c} = W^{\mathsf{T}}A\mathbf{x}$。

步骤 7：回到旧坐标。 $W(B\mathbf{c}) = W(2\sqrt{2},0)^{\mathsf{T}} = 2\sqrt{2}\cdot\mathbf{w}_1 = (2,2)^{\mathsf{T}} = A\mathbf{x}$ ✓。

步骤 8：读出几何意义。 $B = \mathrm{diag}(1,0)$ 直接告诉我们：**在新基下，投影就是"第 1 个坐标原样保留，第 2 个坐标清零"**。没有任何矩阵元互相耦合。这就是"好基让变换解耦"。

步骤 9：验证 $A = WBW^{\mathsf{T}}$（反向重建）。

$$W\,\mathrm{diag}(1,0)W^{\mathsf{T}} = \left(\frac{1}{\sqrt{2}}\begin{bmatrix}1\\1\end{bmatrix}\right)\left(\frac{1}{\sqrt{2}}\begin{bmatrix}1 & 1\end{bmatrix}\right) = \frac{1}{2}\begin{bmatrix}1 & 1\\ 1 & 1\end{bmatrix} = A.\ \checkmark$$

这就是谱分解 $P = \mathbf{w}_1\mathbf{w}_1^{\mathsf{T}}$——投影矩阵恰是"投影方向的外积"（验算通过）。

【计算机制解说】：为什么 $B = W^{-1}AW$ 而不是 WAW^{-1} 或 WAW^{T}？**看输入输出。** B 必须吃"新坐标"、吐"新坐标"。整条链路是

$$\underbrace{\mathbf{c}}_{\text{新坐标}} \xrightarrow{W} \underbrace{W\mathbf{c}=\mathbf{x}}_{\text{旧坐标}} \xrightarrow{A} \underbrace{A\mathbf{x}}_{\text{旧坐标}} \xrightarrow{W^{-1}} \underbrace{W^{-1}A\mathbf{x}}_{\text{新坐标}}.$$

三个箭头依次是 W、A、W^{-1}，由右往左读就是 $B = W^{-1}AW$。**只要坚持"第一刀和最后一刀由坐标翻译负责"，方向就不会错。** 如果写成 WAW^{-1}，那是"从旧坐标出发→新坐标→旧坐标"，代表的是另一个（相似但有方向的）问题。

注意 W 的两种命名在教材中都会出现：Strang 用 W 表示基矩阵、$B = W^{-1}AW$；另一种常见写法是 $M^{-1}AM$（M 从标准基到新基，或反之），只要 $M = W^{-1}$ 就完全等价。**关键是把 M 或 W 的列与新基向量对齐，写清约定。**

示例 2：非正交基下的换基——旋转 $90°$ 在基 $\{(1,1),(1,0)\}$ 下

步骤 1：旧基下的矩阵。 $R = \begin{bmatrix}0 & -1\\ 1 & 0\end{bmatrix}$（绕原点逆时针 $90°$）。

步骤 2：新基与基矩阵。 $\mathbf{w}_1 = (1,1)^{\mathsf{T}}, \mathbf{w}_2 = (1,0)^{\mathsf{T}}$（不正交！$W$ 也不对称），

$$W = \begin{bmatrix}1 & 1\\ 1 & 0\end{bmatrix}, \qquad \det W = 1\cdot 0 - 1\cdot 1 = -1 \neq 0 \Rightarrow \text{是基}.$$

步骤 3：求 W^{-1}。 用 2×2 公式 $\begin{bmatrix}a & b\\ c & d\end{bmatrix}^{-1} = \frac{1}{ad-bc}\begin{bmatrix}d & -b\\ -c & a\end{bmatrix}$：

$$W^{-1} = \frac{1}{-1}\begin{bmatrix}0 & -1\\ -1 & 1\end{bmatrix} = \begin{bmatrix}0 & 1\\ 1 & -1\end{bmatrix}.$$

核验：$W^{-1}W = \begin{bmatrix}0 & 1\\ 1 & -1\end{bmatrix}\begin{bmatrix}1 & 1\\ 1 & 0\end{bmatrix} = \begin{bmatrix}1 & 0\\ 0 & 1\end{bmatrix}$ ✓（验算通过）。

步骤 4：算 $B = W^{-1}RW$。 先算 RW：

$$RW = \begin{bmatrix}0 & -1\\ 1 & 0\end{bmatrix}\begin{bmatrix}1 & 1\\ 1 & 0\end{bmatrix} = \begin{bmatrix}0-1 & 0-0\\ 1+0 & 1+0\end{bmatrix} = \begin{bmatrix}-1 & 0\\ 1 & 1\end{bmatrix}.$$

（逐项机制：第 1 列 $R\mathbf{w}_1 = R(1,1)^{\mathsf{T}} = (-1,1)^{\mathsf{T}}$；第 2 列 $R\mathbf{w}_2 = R(1,0)^{\mathsf{T}} = (0,1)^{\mathsf{T}}$。）

再左乘 W^{-1}：

$$B = \begin{bmatrix}0 & 1\\ 1 & -1\end{bmatrix}\begin{bmatrix}-1 & 0\\ 1 & 1\end{bmatrix} = \begin{bmatrix}0+1 & 0+1\\ -1-1 & 0-1\end{bmatrix} = \begin{bmatrix}1 & 1\\ -2 & -1\end{bmatrix}.$$

步骤 5：不变量核验。 $\mathrm{tr}\,B = 1+(-1) = 0 = \mathrm{tr}\,R$ ✓；$\det B = 1\cdot(-1) - 1\cdot(-2) = -1+2 = 1 = \det R$ ✓（验算通过）。所以 B 与 R 有**相同的特征多项式**

$$\lambda^2 - (\mathrm{tr}\,B)\lambda + \det B = \lambda^2 + 1,$$

特征值为 $\pm i$——与 R 的旋转 $90°$（无实特征向量）一致。**这就是相似矩阵共享特征值的具体体现。**

步骤 6：几何解读。 B 不再有任何"旋转"的直观样子（既不反对称也不稀疏），因为基 $\{(1,1),(1,0)\}$ 与旋转的天然方向（标准基）不对齐。**旋转的最好基是标准基；投影的最好基是特征向量基；选错基只会让矩阵变丑。**

【计算机制解说】：这里要警惕一个常见误解：**"W 正交"不是换基公式的前提。** $B = W^{-1}AW$ 对任何可逆 W 都成立。W 正交只是让 W^{-1} 变便宜（$= W^{\mathsf{T}}$）并且保持长度与角度（讲次 17）。示例 1 和示例 2 放在一起看，正好覆盖两种情形。

另一个机制：**相似关系 $B = W^{-1}AW$ 是一个等价关系**（自反：$W = I$；对称：$A = WBW^{-1}$；传递：$W_1^{-1}AW_1 = W_2^{-1}BW_2$ 可继续复合），所以它把"所有 $n\times n$ 矩阵"分成**相似类**。同一类里的矩阵共享：特征多项式、特征值（含重数）、迹、行列式、秩、Jordan 形、最小多项式。**不共享**：特征向量本身、矩阵元、对称性（对称矩阵换非正交基后一般不再对称）。

示例 3：图像压缩——8×8 平滑块的 DCT 展开与量化

步骤 1：构造一个平滑的 8×8 块。 取 $B_{ij} = 100 + 3i + 2j$（$i, j = 0, \ldots, 7$），即行列方向各有一个线性斜坡：

```
       j=0   j=1   j=2   j=3   j=4   j=5   j=6   j=7
i=0    100   102   104   106   108   110   112   114
i=1    103   105   107   109   111   113   115   117
i=2    106   108   110   112   114   116   118   120
i=3    109   111   113   115   117   119   121   123
i=4    112   114   116   118   120   122   124   126
i=5    115   117   119   121   123   125   127   129
i=6    118   120   122   124   126   128   130   132
i=7    121   123   125   127   129   131   133   135
```

（在真实 JPEG 中还要先减去 128 做电平移位；这里为便于手算保留原值。）

步骤 2：计算二维 DCT 系数 $X = WBW^{\mathsf{T}}$（W 的每行是一个 DCT 基向量，正交）。 脚本算出（保留 4 位，只列 X 的前四行四列）：

```
       k=0        k=1        k=2        k=3
l=0    940.0000  -36.4433    0.0000   -3.8096
l=1    -54.6649    0.0000    0.0000    0.0000
l=2      0.0000    0.0000    0.0000    0.0000
l=3     -5.7145    0.0000    0.0000    0.0000
```

64 个系数中只有 **9 个非零**：$(k,l) = (0,0)$ 的 940、$(0,1)$ 的 -36.4433、$(0,3)$ 的 -3.8096、$(0,5)$ 的 -1.1365、$(0,7)$ 的 -0.2868、$(1,0)$ 的 -54.6649、$(3,0)$ 的 -5.7145、$(5,0)$ 的 -1.7047、$(7,0)$ 的 -0.4302（验算通过）。

步骤 3：解释结构。 线性斜坡 $100 + 3i + 2j$ 可分解为"常数 + i 的线性项 + j 的线性项"，而 $k = 0$（常数/直流）与 $k = 1$（最低频振荡）**近似**能表示线性函数，所以非零系数只出现在**第一行与第一列**：$k = 0$ 那一行（$l = 1, 3, 5, 7$ 有值）与 $l = 0$ 那一列（$k = 1, 3, 5, 7$ 有值）——共 $4 + 4 + 1 = 9$ 个。**注意它们并不都落在"附近"：$k = 0$ 时一直延伸到 $l = 7$，这是因为离散 DCT 基向量不是严格的线性函数，需要高阶分量把离散斜坡"拼"出来**（与附录 E 中 4×4 的例子同理，只是 N 更大时修正项更多）。三阶以上的值迅速衰减（-0.2868 对比 940），所以"少量系数足够好地近似"仍然成立。比值核验很漂亮：

$$X_{1,0}/X_{0,1} = (-54.6649)/(-36.4433) = 1.500000 \left(= \frac{3}{2} = \frac{\text{行斜率}}{\text{列斜率}}\right),$$

这正是斜坡方向信息的体现（验算通过）。**这个比值关系是精确的**（脚本输出 1.500000），因为两个方向的一阶系数按完全相同的模式随斜率缩放。

步骤 4：直流系数与均值的关系。 $X_{0,0} = 940$，而块的平均值 $\bar{B} = 100 + 3 \cdot 3.5 + 2 \cdot 3.5 = 100 + 10.5 + 7 = 117.5$，$8\bar{B} = 8 \times 117.5 = 940$。推导：二维 DCT 的直流基是 $a_0^2 = \frac{1}{\sqrt{8}} \cdot \frac{1}{\sqrt{8}} = \frac{1}{8}$，所以

$$X_{0,0} = a_0^2 \sum_{i,j} B_{ij} = \frac{1}{8} \cdot 64\bar{B} = 8\bar{B}.$$

直流系数 = 8 倍均值（不是 64 倍！注意 $\sum_{i,j}$ 有 64 项，正好把 $\frac{1}{8}$ 的因子抵消到只剩 8）。它承载了块的全部平均亮度，因此 JPEG 对 DC 用最小的量化步长。

步骤 5：能量集中度。 总能量 $\sum X_{kl}^2 = 887968.0000$；前 6 大系数（$940, -54.6649, -36.4433, -5.7145, -3.8096, -1.7047$）的能量 ≈ 887966.4411，占比

$$\frac{887966.4411}{887968.0000} = 99.99982\% \text{（脚本输出 } 100.000\%\text{）}.$$

只用 6/64 个系数就保住了几乎全部能量。

步骤 6：量化 + 丢弃（JPEG 的核心一步）。 用一个均匀量化步长 $q = 10$ 做 $X_{kl} \to \text{round}(X_{kl}/q)$：

```
(0,0) →  94      (0,1) →  -4      (1,0) →  -5      (3,0) →  -1
其余全部 → 0
```

只剩 4 个非零数（验算通过）。按 JPEG 的 zig-zag 扫描顺序（从低频到高频的之字形路径），这 4 个非零系数落在第 $1, 2, 3, 10$ 位上：

```
zig-zag 顺序（位置编号，1-based）：
①(0,0) ②(0,1) ③(1,0) ④(2,0) ⑤(1,1) ⑥(0,2) ⑦(0,3) ⑧(1,2) ⑨(2,1) ⑩(3,0) …
↑       ↑      ↑                                    ↑
94      -4     -5                                   -1
```

于是"游程编码 + 霍夫曼编码"看到的是"94, −4, −5, [6 个零], −1, 然后块结束标记"。**64 个数被压成约 5 个符号。**

步骤 7：重建与误差。 只保留前 6 大系数做逆变换 $\hat{B} = W^{\mathsf{T}}\hat{X}W$，最大绝对误差 ≈ 0.30（脚本验算：0.29980345），而原始块取值在 $100 \sim 135$，相对误差约 0.2%。

步骤 8：一般化——真正的自然图像块。 用一个光滑高斯斑块 $B_{ij} = 100 + 80e^{-((i-3.5)^2+(j-3.5)^2)/16}$ 做同样的实验（脚本验算）：

```
前 1 个系数 (DC)             占能量 98.64%    (值 1158.798)
前 2 个系数 (DC + (2,0))      占能量 99.29%    ((2,0) 值 -93.768)
前 3 个系数 (+ (0,2))         占能量 99.93%    ((0,2) 值 -93.768，对称！)
前 4 个系数 (+ (2,2))         占能量 99.98%    (值 24.505)
前 8 个系数                   占能量 100.00%
```

保留 8/64 个系数（12.5%） 时，最大绝对误差 1.21、RMS 误差 0.56，而块的峰值是 177.54——**误差不到峰值的 0.7%**。注意 $(2,0)$ 与 $(0,2)$ 系数相等，这是斑块在行列方向对称的必然结果（对称性 → 系数对称，是一个好用的自检）。

步骤 9：小波（JPEG2000）对比——Haar 基。 取一维信号 $\mathbf{s} = (9,9,9,9,1,1,1,1)^{\mathsf{T}}$（前半亮、后半暗的台阶），做归一化 Haar 变换（系数 $1/\sqrt{2}$）：

```
原始信号 (8 个数)：[9, 9, 9, 9, 1, 1, 1, 1]

第 1 层 (4 组配对，取平均/细节，系数 1/√2)：
     [9,9]   → 平均 (9+9)/√2  = 12.727922   细节 (9−9)/√2 = 0
     [9,9]   → 平均 12.727922                细节 0
     [1,1]   → 平均 (1+1)/√2  =  1.414214   细节 (1−1)/√2 = 0
     [1,1]   → 平均  1.414214                细节 0
   → 平均值向量 (进入第 2 层)：[12.727922, 12.727922, 1.414214, 1.414214]

第 2 层 (对上面 4 个平均值再配对)：
     [12.727922, 12.727922] → 平均 (12.727922+12.727922)/√2 = 18   细节 0
     [ 1.414214,  1.414214] → 平均 ( 1.414214+ 1.414214)/√2 =  2   细节 0
   → 平均值向量 (进入第 3 层)：[18, 2]

第 3 层 (最后两个值配对)：
     [18, 2] → 平均 (18+2)/√2 = 14.142136   细节 (18−2)/√2 = 11.313708
```

最终打包系数（末尾 6 个为各级细节，全为 0）：

$$\mathbf{h} = (14.142136,\ 11.313708,\ 0,\ 0,\ 0,\ 0,\ 0,\ 0)^{\mathsf{T}} = \left(10\sqrt{2},\ 8\sqrt{2},\ 0,0,0,0,0,0\right)^{\mathsf{T}}.$$

8 个数里只有 2 个非零，而且

$$\|\mathbf{s}\|^2 = 328 = \|\mathbf{h}\|^2 \ (\text{脚本验算通过}),$$

即 $14.142136^2 + 11.313708^2 = 200 + 128 = 328$。**这是正交变换的保能量性质（Parseval），也是讲次 17 的正交性在信号处理里的化身。** 逐条验证：$10\sqrt{2} = 14.142136$ ✓，$8\sqrt{2} = 11.313708$ ✓。

步骤 10：为什么小波更适合"有边缘"的图像。 Haar/Daubechies 小波基向量是**局部化**的（只在很短一段非零），而 DCT 基向量是**全局振荡**的。台阶边缘在小波基下只激发少数几个细节系数（本例中甚至只有 1 个！），而在 DCT 下，边缘会产生大量高频系数（Gibbs 振铃）。

```
DCT 基向量（全局）              Haar 小波基向量（局部）
～～～～～～～～～～～～        ──────╱╲──────
每个都覆盖整段信号              每个只覆盖一小段
→ 平滑信号高效                  → 分段常数/边缘高效
→ 明显边缘会产生振铃            → 边缘只激发局部系数
```

【计算机制解说】：为什么"换基 + 置零小系数"就能压缩，而且误差可控？ 1. **正交变换不改变 ℓ^2 能量**：$\|B\|_F^2 = \|X\|_F^2$（Frobenius 范数意义下），所以"丢掉一个系数 X_{kl}"造成的误差能量就精确等于 X_{kl}^2。丢弃最小的系数 → 误差最小。**这就是"阈值压缩"的最优性来源。** 2. **基要匹配信号的统计结构**。DCT 在"一阶马尔可夫、高相关"的自然图像上接近 Karhunen–Loève 最优；小波在"分段光滑、有边缘"的图像上更优。**没有万能基，只有匹配的基。** 这正是讲次 29 SVD 的思想：SVD 就是**针对给定数据矩阵 B 本身**构造的最优基（$B = U\Sigma V^{\mathsf{T}}$，丢掉小奇异值 = 最优低秩逼近，Eckart–Young）。 3. **DCT 与 SVD 的关系**：对一类"Toeplitz 相关矩阵"，DCT 的基向量渐近等于其特征向量，所以 DCT 是 SVD 的"与数据无关的固定近似"。**JPEG 用 DCT 是因为它快（有 $O(n\log n)$ 快速算法）且够好；SVD 是理论最优但要对每个块单独算，代价太高。**

示例 4（附加）：置换矩阵换基——只是重新排列坐标

取 $W = P = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}$（$P^{-1} = P$），$A = \begin{bmatrix} 4 & 1 \\ 2 & 3 \end{bmatrix}$：

$$B = P^{-1}AP = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}\begin{bmatrix} 4 & 1 \\ 2 & 3 \end{bmatrix}\begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix} = \begin{bmatrix} 3 & 2 \\ 1 & 4 \end{bmatrix}.$$

这只是把基向量交换了顺序。核验：$\operatorname{tr} B = 7 = \operatorname{tr} A$，$\det B = 10 = \det A$ ✓（验算通过）。B 的特征值与原矩阵相同，只是特征向量的坐标顺序被打乱。

示例 5（附加）：非正交基下的 W^{-1} 手算

$W = \begin{bmatrix} 1 & 0 \\ 1 & 2 \end{bmatrix}$（列是 $\mathbf{w}_1 = (1,1)^{\mathsf{T}}, \mathbf{w}_2 = (0,2)^{\mathsf{T}}$）。$\det W = 2$，

$$W^{-1} = \frac{1}{2}\begin{bmatrix} 2 & 0 \\ -1 & 1 \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ -0.5 & 0.5 \end{bmatrix}.$$

$\mathbf{x} = (3,1)^{\mathsf{T}}$ 的新坐标 $\mathbf{c} = W^{-1}\mathbf{x} = (3,-1)^{\mathsf{T}}$，回代 $W\mathbf{c} = (3,1)^{\mathsf{T}}$ ✓（验算通过）。把投影 P 换到此基：

$$W^{-1}PW = \begin{bmatrix} 1 & 0 \\ -0.5 & 0.5 \end{bmatrix}\frac{1}{2}\begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix}\begin{bmatrix} 1 & 0 \\ 1 & 2 \end{bmatrix} = \begin{bmatrix} 1 & 1 \\ 0 & 0 \end{bmatrix},$$

迹 $= 1$、$\det = 0$，特征值仍为 $1, 0$ ✓（验算通过）。注意它**不再对称**——因为 W 不正交。这再次印证"对称性不是相似不变量"。

矩阵分解的核心思想

本讲的核心分解就是**相似对角化** $A = S\Lambda S^{-1}$ 及其正交版本 $A = Q\Lambda Q^{\mathsf{T}}$，并通过换基统一了课程中出现过的所有分解：

分解	换基视角	新基的性质	得到什么
$A = S\Lambda S^{-1}$	换成**特征向量基** S	一般不正交	对角、解耦，但 S^{-1} 难算/可能病态
$A = Q\Lambda Q^{\mathsf{T}}$（对称）	换成**正交特征向量基** Q	正交	对角 + 保长 + 数值稳定
$A = U\Sigma V^{\mathsf{T}}$（SVD）	输入、输出各换一组**正交**基	正交（两组）	对角 Σ，且奇异值有序
$A = QR$	换成**正交基**（Gram–Schmidt）	正交	上三角、最小二乘稳定
$A = LU$	换成**消元过程自然的基**	非正交	三角、便于回代
DCT/小波（JPEG）	换成**固定正交基**	正交	稀疏、箝位压缩
$P = W\hat{P}W^{\mathsf{T}}$（投影）	换成**子空间 + 正交补**基	正交	$\mathbf{diag}(1,\dots,1,0,\dots,0)$

一句话公式：**分解 = 换基 + 在新基下矩阵变简单**。$A = S\Lambda S^{-1}$ 是"变成对角"；$A = QR$ 是"变成上三角"；$A = U\Sigma V^{\mathsf{T}}$ 是"变成对角且两侧都正交"。

对角化的几何解释（本讲最重要的收获）：

$$\boxed{\text{对角化 } A = S\Lambda S^{-1} \iff \text{选一组好基（特征向量基）使变换变成对角}}$$

对角矩阵的含义是：**每个基方向被独立地拉伸 λ_j 倍，方向之间零耦合**。A 施加 k 次就是 λ_j^k——这解释了为什么对角化能秒算 A^k、解微分方程组（讲次 22–23）、分析马尔可夫链收敛（讲次 24）。**换基把"耦合的耦合系统"变成"n 个独立的一维问题"。**

与其他讲次的关联

- **与讲次 6–10（子空间）**：基的定义、线性无关、维数都在那里建立；本讲把它们用在"同一空间的两组基"上。$\mathbf{x} = W\mathbf{c}$ 是"用 W 的列线性组合出 $\mathbf{x}$"，正是列空间 $C(W) = \mathbb{R}^n$ 的含义。
- **与讲次 1–5（消元、$A = LU$）**：求 W^{-1} 用 Gauss–Jordan；$B = W^{-1}AW$ 的两次乘法都可用 LU 分解加速。
- **与讲次 11–12（矩阵空间、图）**：图的关联矩阵的"节点电位 → 边电压"变换，换基对应"重新标记节点"或"取节点电位的平均值/差值坐标"（后者让图的拉普拉斯算子部分对角化）。
- **与讲次 14–17（正交、投影、QR）**：正交基使 $W^{-1} = W^{\mathsf{T}}$（讲次 17）。本讲示例 1 的 W 就是正交的，$P = \mathbf{w}_1\mathbf{w}_1^{\mathsf{T}}$ 是秩 1 投影的外积形式。
- **与讲次 18–20（行列式）**：$\det(W^{-1}AW) = \det(W^{-1})\det A \det W = \det A$，这是"相似矩阵行列式相同"的一行证明；也是"换基不改变体积缩放因子"的几何陈述。
- **与讲次 21–25（特征值、对角化）**：讲次 22 的 $A = S\Lambda S^{-1}$ 在这里得到几何解释；讲次 25 的对称矩阵 $A = Q\Lambda Q^{\mathsf{T}}$ 是"正交换基"的样板；讲次 24 马尔可夫矩阵的稳态就是"换到特征向量基后只剩 $\lambda = 1$ 的分量"。
- **与讲次 27–29（正定、Jordan、SVD）**：当 S 不可逆（特征向量不够）时，最简形式是 Jordan 形——那时**无法**用换基做到对角，只能做到"对角 + 上三角非零"，这是换基能力的极限。SVD 因允许两侧各换一组基而总是可行。
- **与讲次 30（线性变换）**：本讲是讲次 30 的直接续篇——那里说"矩阵依赖基"，这里给出换基公式。
- **与讲次 33（伪逆）**：SVD 换基 $A = U\Sigma V^{\mathsf{T}}$ 中，V 的列是 $C(A^{\mathsf{T}})$ 的正交基、U 的列是 $C(A)$ 的正交基，这正是讲次 33 定义 $A^{+} = V\Sigma^{+}U^{\mathsf{T}}$ 的原料。

关键要点

1. **坐标与基的关系**：$\mathbf{x} = W\mathbf{c}$，$\mathbf{c} = W^{-1}\mathbf{x}$。$W$ 的列就是新基向量。正交时 $W^{-1} = W^{\mathsf{T}}$。
2. **换基公式**：$B = W^{-1}AW$（新基矩阵 W）。等价写法 $B = MAM^{-1}$ 当 $M = W^{-1}$。**推导口诀：W 进、A 干活、W^{-1} 出。**
3. **相似不变量的清单**：特征值（含重数）、特征多项式、迹、行列式、秩、Jordan 形。**不变量不是**：矩阵元、对称性、特征向量本身。
4. **对角化 = 换到特征向量基**。$\Lambda = \mathrm{diag}(\lambda_j)$ 表示"每个基方向独立拉伸"。$A^k = S\Lambda^k S^{-1}$。
5. **压缩的本质 = 换基 + 稀疏化**：在正交基下丢系数，误差能量 = 丢弃系数平方和；DCT（JPEG）与（小波 JPEG2000）是固定基，SVD 是数据自适应最优基（Eckart–Young）。
6. **好基的选择原则**：要解耦 → 特征向量基；要稳定保长 → 正交基；要最优低秩 → SVD 基；要压缩 → 匹配信号结构的基（DCT/小波）。

常见误区与注意事项

1. **换基方向写反**。$B = W^{-1}AW$ 是对"W 的列 = 新基向量"的约定。若你定义的 W 的列是旧基在新基下的坐标，公式就变成 $B = WAW^{-1}$。**永远从"输入新坐标、输出新坐标"这条链路重新推一遍，而不是背公式。**
2. **把"相似"与"等价（相抵）"混淆**。$B = W^{-1}AW$（同一空间内换基，两侧 W^{-1}, W，方阵）叫**相似**，保持特征值；$B = PAQ$（P, Q 各自可逆，允许长方形）叫**等价**，只保持秩。SVD 中的 $U\Sigma V^{\mathsf{T}}$ 是等价而非相似（$U \neq V^{-1}$ 一般成立）——所以 SVD 不保持特征值，只保持奇异值。这是学生最容易混的一点。
3. **以为正交基下换基"不用算逆"就可以随便用**。$W^{\mathsf{T}}W = I$ 要求 W **方阵**且列正交。若 W 是 $n \times k$（$k < n$，只有 k 个正交向量），则 $W^{\mathsf{T}}W = I_k$ 但 $WW^{\mathsf{T}} \neq I_n$（那是投影，不是换基），不能用来做相似变换。
4. **换基后特征向量忘了跟着变**。B 的特征向量 $\mathbf{y}$ 对应 A 的特征向量 $\mathbf{x} = W\mathbf{y}$。求 A 的特征向量最容易的办法常常是"先算出 B 的对角形式，再用 W 乘回去"。
5. **压缩时把直流分量也丢掉**。DCT 的 $X_{0,0}$ 承载块的平均亮度，量级远大于其他系数。丢掉它会造成整块亮度突变（块效应）。JPEG 的量化表对 DC 用很小的步长正是这个原因。
6. **错误地认为"换基会改变算子的秩/可逆性"**。$B = W^{-1}AW$ 中 W 可逆，所以 $\mathbf{rank}\, B = \mathbf{rank}\, A$，$B$ 可逆 $\Leftrightarrow$ A 可逆。**换基只改变"长相"，不改变"本质"。**
7. **把二维 DCT 写成 WBW 而不是 WBW^{T}**。一维变换作用在**行**上（BW^{T}，W 的行是基向量）与作用在**列**上（WB）必须区分。标准二维 DCT 是 $X = WBW^{\mathsf{T}}$，逆变换 $B = W^{\mathsf{T}}XW$（因 W 正交且 $W^{-1} = W^{\mathsf{T}}$）。写错会得到转置或完全错误的结果。

思考题（带答案）

Q1.（纯计算）设 $A = \begin{bmatrix} 4 & 1 \\ 2 & 3 \end{bmatrix}$，新基 $\mathbf{w}_1 = (1,1)^{\mathsf{T}}$，$\mathbf{w}_2 = (1,-1)^{\mathsf{T}}$。(a) 写出 W 并求 W^{-1}；(b) 求 $B = W^{-1}AW$；(c) 核验迹与行列式；(d) 求 A 的特征值，并说明 B 有什么性质。

▸ **答案**

(a) $W = \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}$。$\det W = 1 \cdot (-1) - 1 \cdot 1 = -2$，

$$W^{-1} = \frac{1}{-2}\begin{bmatrix} -1 & -1 \\ -1 & 1 \end{bmatrix} = \frac{1}{2}\begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}.$$

核验：$W^{-1}W = \frac{1}{2}\begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}\begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} = \frac{1}{2}\begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix} = I$ ✓。

(b) 先算 AW：

$$AW = \begin{bmatrix} 4 & 1 \\ 2 & 3 \end{bmatrix}\begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} = \begin{bmatrix} 4+1 & 4-1 \\ 2+3 & 2-3 \end{bmatrix} = \begin{bmatrix} 5 & 3 \\ 5 & -1 \end{bmatrix}.$$

（第 1 列 $= A\mathbf{w}_1 = (5,5)^{\mathsf{T}}$，第 2 列 $= A\mathbf{w}_2 = (3,-1)^{\mathsf{T}}$。）

再左乘 W^{-1}：

$$B = \frac{1}{2}\begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}\begin{bmatrix} 5 & 3 \\ 5 & -1 \end{bmatrix} = \frac{1}{2}\begin{bmatrix} 5+5 & 3-1 \\ 5-5 & 3+1 \end{bmatrix} = \frac{1}{2}\begin{bmatrix} 10 & 2 \\ 0 & 4 \end{bmatrix} = \begin{bmatrix} 5 & 1 \\ 0 & 2 \end{bmatrix}.$$

(c) $\operatorname{tr} B = 5+2 = 7 = \operatorname{tr} A = 4+3$ ✓。$\det B = 5\cdot 2 - 1\cdot 0 = 10 = \det A = 4\cdot 3 - 1\cdot 2 = 12-2 = 10$ ✓。

(d) A 的特征多项式 $\lambda^2 - 7\lambda + 10 = (\lambda-5)(\lambda-2)$，特征值 $\lambda = 5, 2$，与 B 的对角元完全一致——因为 B 恰好是**上三角**，其特征值就在对角线上。**注意 B 不是对角矩阵**：基 $\{(1,1),(1,-1)\}$ 不是 A 的特征向量基（$A\mathbf{w_1} = (5,5)^{\mathsf T} = 5\mathbf{w_1}$ 恰好是特征向量！但 $A\mathbf{w_2} = (3,-1)^{\mathsf T} \neq \lambda \mathbf{w_2}$）。所以 A 可对角化，但需要另找 $\mathbf{w_2}$：由 $(A-2I)\mathbf{v} = 0$ 即 $\begin{bmatrix}2 & 1\\ 2 & 1\end{bmatrix}\mathbf{v} = 0$ 得 $\mathbf{v_2} = (1,-2)^{\mathsf T}$。用 $S = [(1,1)^{\mathsf T}, (1,-2)^{\mathsf T}]$ 才能真正对角化。

Q2.（概念理解）下列哪些量在相似变换 $B = W^{-1}AW$ 下**保持不变**？哪些会变？ (i) 特征值；(ii) 矩阵的迹；(iii) 矩阵元 a_{11}；(iv) 秩；(v) 对称性（$A = A^{\mathsf T}$）；(vi) 行列式；(vii) 奇异值；(viii) 特征向量。

▸ 答案

保持不变：(i) 特征值。证明：$\det(B-\lambda I) = \det(W^{-1}(A-\lambda I)W) = \det(W^{-1})\det(A-\lambda I)\det W = \det(A-\lambda I)$，特征多项式逐项相同，**含重数**。(ii) 迹（特征值之和）。(iv) 秩（W 可逆，左右乘可逆矩阵不改变秩）。(vi) 行列式（特征值之积，或 $\det(W^{-1})\det A \det W = \det A$）。 **会变**：(iii) 矩阵元（示例 1 中 A 的元是 $1/2$，B 的元是 $1, 0$）；(v) 对称性——示例 5 中 W 不正交时 $W^{-1}PW = \begin{bmatrix}1 & 1\\ 0 & 0\end{bmatrix}$ 不对称（若 W **正交**则对称性保持：$B^{\mathsf T} = (W^{\mathsf T}AW)^{\mathsf T} = W^{\mathsf T}A^{\mathsf T}W = B$，因为 $W^{-1} = W^{\mathsf T}$）；(vii) **奇异值**；(viii) 特征向量（B 的特征向量 $\mathbf{y}$ 与 A 的特征向量 $\mathbf{x} = W\mathbf{y}$ 不同）。

(vii) 特别说明（学生最容易答错的一项）：相似变换**不保持奇异值**。反例：$A = \begin{bmatrix}0 & 10\\ 0 & 0\end{bmatrix}$，$A^{\mathsf T}A = \begin{bmatrix}0 & 0\\ 0 & 100\end{bmatrix}$，奇异值为 $10, 0$。取 $W = \operatorname{diag}(10, 1)$（可逆），

$$W^{-1}AW = \begin{bmatrix}0.1 & 0\\ 0 & 1\end{bmatrix}\begin{bmatrix}0 & 10\\ 0 & 0\end{bmatrix}\begin{bmatrix}10 & 0\\ 0 & 1\end{bmatrix} = \begin{bmatrix}0 & 1\\ 0 & 0\end{bmatrix},$$

它的 $B^{\mathsf T}B = \begin{bmatrix}0 & 0\\ 0 & 1\end{bmatrix}$，奇异值为 $1, 0$。**特征值不变（都是 $0, 0$，幂零），奇异值却从 10 变成 1**（脚本验算通过）。

这正是**相似**与**等价（相抵）**的分界线：相似 $B = W^{-1}AW$ 保持特征值；等价 $B = PAQ$（P, Q 各自可逆，允许长方形）只保持秩。SVD 是等价而非相似，所以 SVD 保持奇异值而不保持特征值。

记忆钩：相似 = "同一个变换换眼睛看"，所以**变换本身的属性（特征值、迹、行列式、秩）不变**，而**表达方式（矩阵元、对称性、特征向量坐标、奇异值）会变**。

Q3.（应用 + 计算）一幅 8×8 图像块在 DCT 基下的系数只有以下 3 个非零：$X_{0,0} = 512$，$X_{0,1} = -64$，$X_{1,0} = 32$。其余 61 个为零。 (a) 该块的平均亮度是多少？ (b) 能量压缩比是多少（保留系数能量 / 全部能量）？ (c) 如果把 $X_{0,1}$ 与 $X_{1,0}$ 也丢掉（只留 DC），重建误差的 Frobenius 范数是多少？

▸ 答案

(a) 在正交 DCT–II 下，二维直流系数是

$$X_{0,0} = a_0^2 \sum_{i,j} B_{ij}, \qquad a_0 = \frac{1}{\sqrt{8}} \implies a_0^2 = \frac{1}{8}.$$

$\sum_{i,j} B_{ij} = 64\bar{B}$（64 个像素），所以

$$X_{0,0} = \frac{1}{8}\cdot 64\bar{B} = 8\bar{B} \implies \bar{B} = \frac{X_{0,0}}{8} = \frac{512}{8} = 64.$$

该块平均亮度为 64。

(b) 全部能量 $= 512^2 + (-64)^2 + 32^2 = 262144 + 4096 + 1024 = 267264$。非零系数就是全部非零系数（题目说只有这 3 个非零），所以压缩比 $= 267264/267264 = 100\%$——**61 个零系数不贡献能量，丢掉它们零损失**，只需要记录 3 个数的位置与数值。这就是稀疏性的价值。

(c) 正交变换保能量（Parseval），丢掉系数造成的误差能量**恰等于**这些系数平方和：

$$\|\hat{B} - B\|_F^2 = X_{0,1}^2 + X_{1,0}^2 = 4096 + 1024 = 5120,$$

$$\|\hat{B} - B\|_F = \sqrt{5120} = \sqrt{1024\cdot 5} = 32\sqrt{5} \approx 71.554.$$

> **相对误差**：$\|\hat{B}-B\|_F/\|B\|_F=\sqrt{5120/267264}=\sqrt{0.01916}\approx 0.1384$，约 13.8%。若保留全部 3 个系数，误差为 0。
>
> **补充解释**：误差矩阵只需保留 DC 时的形状是一个常数矩阵（因为 $\hat{B}$ 是常数块），所以重建图会出现"块状马赛克"——这就是高压缩比 JPEG 的典型伪影。

附录 A：换基链条总图（本讲核心可视化）

下面这张图把"一个变换、两组基、两个矩阵"的关系完整画出来。**建议照着图自己默写一遍 $B=W^{-1}AW$。**

```
┌──────────────────────────────────────────────────────────────────┐
│                    同一个变换 T，两套坐标系统                    │
│                                                                  │
│   【旧基/标准基视角】                【新基视角】                │
│   向量写成 x = (x₁,x₂)ᵀ              向量写成 c = (c₁,c₂)ᵀ       │
│   矩阵 A（在标准基下）               矩阵 B = W⁻¹AW（在新基下）  │
│                                                                  │
│        x ──────────── A ──────────► Ax                           │
│        │                            │                           │
│    W   │  ↑ 坐标翻译                │  W⁻¹  ↓ 坐标翻译          │
│  (旧←新)                           (旧 →新)                      │
│        ▼                            ▼                           │
│        c ──────────── B ──────────► Bc = W⁻¹Ax                   │
│                                                                  │
│   关系：  x = W c        (W 的列 = 新基向量)                     │
│           c = W⁻¹x                                               │
│           B = W⁻¹ A W    ← 三步：W 进、A 干活、W⁻¹ 出           │
└──────────────────────────────────────────────────────────────────┘

矩阵 W 的结构（关键！列 = 新基向量）：
     W = [ w₁  w₂  ⋯  wn ]        ←  第 j 列就是第 j 个新基向量
     W⁻¹ 的列 = 旧基向量在新基下的坐标（"对偶"关系）
```

三种"好基"的效果对比（同一个变换 T）		
基的选择	得到的矩阵	揭示的结构
标准基	A（一般densely）	看不出什么
特征向量基	Λ 对角	各方向独立拉伸、解耦
正交特征向量基	Λ 对角 + 保长	解耦 + 数值稳定（对称矩阵）
SVD 两组基	Σ 对角（两侧正交）	最优低秩、能量排序
Q 基（Gram-Schmidt）	R 上三角	最小二乘、稳定求解
DCT / 小波基	稀疏系数矩阵	压缩（少数大系数）

附录 B：换基的"安全检查清单"

每次做完换基，用这五条快速自检，能立刻发现方向符号或转置错误：

```
□ 1. 维度对得上吗？
     A 是 n×n ⇒ B = W⁻¹AW 也必须是 n×n
     （写成 WAW⁻¹ 也合规，但代表不同的约定）

□ 2. 迹变了吗？              tr(B) ?= tr(A)              ← 必须相等
□ 3. 行列式变了吗？          det(B) ?= det(A)            ← 必须相等
□ 4. 特征多项式变了吗？      det(B−λI) ?= det(A−λI)      ← 必须逐项相等
□ 5. 秩变了吗？              rank(B) ?= rank(A)          ← 必须相等
──────────────────────────────────────────────────────────
以上任一不等 ⇒ 换基公式写错了（八成是把 W 和 W⁻¹ 放反了）

附加检查（仅当 W 正交时）：
□ 6. WᵀW = I ？   ⇒  B 保持对称性（W 不正交时对称性一般不保）
```

用本讲示例 1 演练：$A=\frac{1}{2}\begin{bmatrix}1&1\\1&1\end{bmatrix}$，$B=\mathrm{diag}(1,0)$，$W$ 正交。 – 维度：都是 2×2 ✓ – $\mathbf{tr}$：$1=1$ ✓ – $\mathbf{det}$：$0=0$ ✓ – 特征多项式：$\lambda^2-\lambda$ 两者相同 ✓ – 秩：$1=1$ ✓ – $W^{\mathrm{T}}W=I$ ✓ 且 B 对称 ✓

用本讲示例 2 演练（W 不正交）：$A=R_{90^\circ}$，$B=\begin{bmatrix}1&1\\-2&-1\end{bmatrix}$，$W=\begin{bmatrix}1&1\\1&0\end{bmatrix}$。 – $\mathbf{tr}$：$0=0$ ✓ – $\mathbf{det}$：$1=1$ ✓ – 特征多项式：λ^2+1 两者相同 ✓ – 秩：$2=2$ ✓ – **但 A 反对称、B 不对称** —— 因为 W 不正交，对称性确实丢了 ✓（符合预期，不是错误）

附录 C：从"换基"到"低秩逼近"——分辨率金字塔

图像压缩有两个正交的维度：**换什么基**（本讲）与**保留多少项**（讲次 29）。把它们组合起来就是工业压缩算法的全貌。

换基（本讲 L31）与截断（L29）的分工：

换基	让"重要信息"集中到少数几个坐标上
截断/量化	把剩下的一大堆接近零的坐标扔掉

两者缺一不可：换错基 ⇒ 信息分散 ⇒ 扔哪个都心疼 ⇒ 压不动
不截断 ⇒ 基再好也白换 ⇒ 没有压缩

附录 D：几种常见正交基的对比（图像处理视角）

基	向量形状	局部化	平滑信号	边缘/不连续	快速算法	使用者
标准基（像素）	单点脉冲	极局部	差	好	无（恒等）	无损格式（PNG）
Fourier	全局正弦	完全全局	很好	差（振铃）	FFT $O(n\log n)$	音频、频谱分析
DCT	全局余弦	完全全局	很好	中（振铃）	$O(n\log n)$	JPEG、MP3、H.26x
Haar 小波	分段常数	局部	好	很好	$O(n)$	JPEG2000（最简单层）
Daubechies 小波	分段光滑	局部	好	很好	$O(n)$	JPEG2000
KLT / SVD	数据自适应	不定	最优	最优	无快速算法	主成分分析、去噪

本讲验算过的三个"稀疏性"实证（都用脚本算过）： 1. **平滑斜坡块** $100+3i+2j$：64 个 DCT 系数只有 9 个非零；前 6 个占能量 99.99982%；用 $q=10$ 量化后只剩 4 个非零。 2. **高斯斑块** $100+80e^{-d^2/16}$：DC 一个系数就占能量 98.64%；前 4 个占 99.98%；保留 8/64 个系数的最大绝对误差仅 1.21（峰值 177.54）。 3. **Haar 小波作用于台阶信号** $(9,9,9,9,1,1,1,1)$：8 个系数只有 2 个非零，恰好是 $10\sqrt{2}$ 与 $8\sqrt{2}$；能量 328 精确保留（Parseval）。

为什么"边缘"决定了选哪种基：自然图像的统计特性是"大部分平滑、少数边缘"。DCT 需要很多高频余弦去拼一个陡峭边缘（因为余弦是全局的，边缘处会产生 Gibbs 振铃）；小波基向量只在边缘附近非零，用一两个系数就能表示。**这就是 JPEG2000 在低码率下优于 JPEG 的原因**（但它计算更复杂，所以 JPEG 至今仍是主流）。

附录 E：一个完整的"手算压缩"演练（4×4，纯整数）

为了让读者能真正手算，这里用最小的例子。取 4×4 块：

$$B=\begin{bmatrix}4&3&2&1\\3&2&1&0\\2&1&0&-1\\1&0&-1&-2\end{bmatrix},\qquad B_{ij}=4-i-j\,(i,j=0,\dots,3).$$

这个块是两个方向上的**线性斜坡**（中心对称：$B_{ij}=B_{3-i,3-j}$），最容易看出基的效率。

步骤 1：算 4×4 的二维 DCT 系数 $X=C_4BC_4^{\mathsf T}$（C_4 为正交 DCT-II，$a_0=\frac12$、$a_k=\frac{1}{\sqrt2}$）。脚本验算结果：

```
X = ⎡ 4.000000   4.460885   0.000000   0.317025 ⎤
    ⎢ 4.460885   0.000000   0.000000   0.000000 ⎥
    ⎢ 0.000000   0.000000   0.000000   0.000000 ⎥
    ⎣ 0.317025   0.000000   0.000000   0.000000 ⎦
```

16 个系数中只有 5 个非零：$(0,0)=4.000000$、$(0,1)=(1,0)=4.460885$、$(0,3)=(3,0)=0.317025$（脚本验算通过）。

步骤 2：读取结构（这里有一个离散与连续的细微差别，必须讲清）。 – DC 系数：$X_{0,0}=4$，而均值 $\bar B=\frac{1}{16}\sum_{i,j}(4-i-j)=\frac{16}{16}=1$，所以 $X_{0,0}=4\bar B$（$N=4$ 时直流系数 = N 倍均值；这正是二维直流基 $a_0^2=\frac14$ 乘 16 项之和的结果）。 – **一阶系数 $(0,1)$、$(1,0)$**：4.460885，承载两个方向的**线性斜坡**。 – $(0,3)$、$(3,0)$：0.317025，是**离散化修正项**。连续斜坡的 DCT 只在 $k=0,1$ 有分量；但离散 DCT-II 的基向量在 $k=1$ 时并不是严格的线性函数（$\cos\frac{\pi(2n+1)}{8}$ 与 n 不成正比），所以必须补上 $k=3$ 的少量分量才能精确表示离散斜坡。**这就是"连续直觉 + 离散现实"的差别——写代码时必须信 SVD/DCT 的计算结果，而不是信类比。**

步骤 3：量化与压缩比。 取 $q=2$：$\mathrm{round}(4/2)=2$、$\mathrm{round}(4.460885/2)=2$、$\mathrm{round}(0.317025/2)=0$。于是只剩 3 **个非零整数**。存储量从 **16** 个系数降到 **3** 个（加上位置信息），**压缩比约 16 : 3**。

步骤 4：重建。 用 $\hat B=C_4^{\mathsf T}\hat XC_4$（正交 ⇒ 逆 = 转置）。保留全部 5 个系数时重建几乎完美；若**只保留 DC**（$\hat X$ 只剩 $X_{0,0}=4$），重建得到常数块

$$\hat B=\frac{X_{0,0}}{4}\mathbf 1=\begin{bmatrix}1&1&1&1\\1&1&1&1\\1&1&1&1\\1&1&1&1\end{bmatrix},$$

即灰度 **1** 的均匀块（用 $X_{0,0}/4$ 而不是 $/16$：因为重建公式里 $C^{\mathsf T}$ 与 C 各贡献一个 $a_0=\frac12$，总共 $\frac14$）。**误差就是原来那个斜坡的起伏幅度**——这就是极低码率下"块状马赛克/平坦化"的来源。

步骤 5：能量账本（用附录 G 的 Parseval 公式）。总能量 $\sum X_{kl}^2=4^2+2(4.460885)^2+2(0.317025)^2=16+39.799+0.201=56.000$，而 $\sum B_{ij}^2=16+9+4+1+9+4+1+0+4+1+0+1+1+0+1+4=56.000$ ✓（能量相等，正交变换保能量）。只保留 DC 时误差能量 $=56-16=40$。

推广的黄金法则：一个 8×8 块中，**平滑结构集中在左上角的少数低阶位置**，右下角的高阶位置承载细节。JPEG 的量化表恰恰是"左上角小、右下角大"的阶梯——它把"结构"留下、把"细节"抹掉，这就是人眼感知特性的直接编码。**但要注意：能用几个系数精确表示，取决于块是"连续线性"还是"离散采样"；一般图像块两者都不是，所以只能近似。**

附录 F：换基与相似的其他重要不变量（进阶）

除了附录 B 的五条，相似变换还保持以下性质，在做题中常用来快速判定"两个矩阵是否可能相似"：

性质	是否相似不变量	理由/反例
特征值（含代数重数）	✅ 是	特征多项式相同
特征值的几何重数	✅ 是	$\dim N(B-\lambda I)=\dim N(A-\lambda I)$，因 $N(W^{-1}AW-\lambda I)=W^{-1}N(A-\lambda I)$
迹、行列式、秩	✅ 是	特征值的函数
特征多项式、最小多项式	✅ 是	由 $B-\lambda I=W^{-1}(A-\lambda I)W$ 逐项推出
Jordan 标准形	✅ 是	Jordan 形是相似类的完全不变量
是否可对角化	✅ 是	取决于几何重数是否等于代数重数
奇异值	❌ 否	反例见思考题 Q2(vii)：$A=\begin{bmatrix}0&10\\0&0\end{bmatrix}$ 与 $B=\begin{bmatrix}0&1\\0&0\end{bmatrix}$ 相似但奇异值 $10,0$ vs $1,0$

性质	是否相似不变量	理由/反例
对称性	❌ 否（除非 W 正交）	示例 5：W 不正交时对称性丢失
矩阵元	❌ 否	a_{11} 与 b_{11} 无任何强制关系（示例 1 中 $1/2$ 变成 1）
特征向量（作为向量）	❌ 否	变为 $W\mathbf{y}$
Frobenius 范数 $\|A\|_F$	❌ 否	$\|W^{-1}AW\|_F$ 一般 $\neq \|A\|_F$（除非 W 正交）
迹、$\|A\|_F$ 在正交 W 下	✅ 都保持	正交变换保 Frobenius 范数

实用推论：判断"A 与 B 是否相似"的最快筛法是**比较特征多项式**；若相同再看**是否都可对角化**（都可对角化且特征多项式相同 ⇒ 相似！因为 Λ 由特征值唯一确定，$A = S_1\Lambda S_1^{-1}$，$B = S_2\Lambda S_2^{-1} \Rightarrow B = (S_2S_1^{-1})A(S_1S_2^{-1})$，即 $W = S_1S_2^{-1}$）。

附录 G：图像压缩的"能量账本"（为什么正交性让压缩可计算）

设正交基矩阵为 W（$WW^{\mathsf{T}} = W^{\mathsf{T}}W = I$），信号 $\mathbf{f}$ 的系数为 $\mathbf{c} = W\mathbf{f}$，则

$$\|\mathbf{f}\|^2 = \mathbf{f}^{\mathsf{T}}\mathbf{f} = (W^{\mathsf{T}}\mathbf{c})^{\mathsf{T}}(W^{\mathsf{T}}\mathbf{c}) = \mathbf{c}^{\mathsf{T}}WW^{\mathsf{T}}\mathbf{c} = \mathbf{c}^{\mathsf{T}}\mathbf{c} = \|\mathbf{c}\|^2.$$

这就是 Parseval 等式（讲次 17 的正交性在信号处理里的名字）。它的实践含义：

```
设丢掉系数集合 S（其余保留），误差 e = f − f̂

┌──────────────────────────────────────────────┐
│   ||e||² = Σ_{k∈S} c_k²        ← 误差能量 = 丢弃系数平方和 │
└──────────────────────────────────────────────┘

推论 1：误差完全可预测（不需要先重建再比较）
推论 2：丢掉最小的那些系数 ⇒ 误差最小 ⇒ 阈值法是"最优"的
推论 3：压缩问题的核心就变成"找到一组能产生最多小系数的基"
```

本讲验算数据代入：平滑斜坡块的总能量 887968.0000，前 6 大系数能量 887966.4411，所以丢掉后 58 个系数的误差能量是

$$887968.0000 - 887966.4411 = 1.5589,$$

误差范数 $\sqrt{1.5589} \approx 1.2486$。而重建（只有前 6 项时）的最大绝对误差是 0.2998——**注意这两个数不同**：前者是整个矩阵的 Frobenius 误差范数，后者是单个像素的最大偏差。**做题时务必分清"矩阵范数误差"与"逐点最大误差"。**

对比 SVD 的能量账（讲次 29）：$A = \sum_{i=1}^{r}\sigma_i\mathbf{u}_i\mathbf{v}_i^{\mathsf{T}}$，截断到前 k 项的误差是

$$\|A - A_k\|_F^2 = \sum_{i=k+1}^{r}\sigma_i^2, \qquad \|A - A_k\|_2 = \sigma_{k+1}.$$

完全平行的结构：SVD 的 σ_i^2 对应 DCT 的 c_k^2；"奇异值下降快"对应"系数衰减快"。**Eckart–Young 定理说 SVD 的截断是"对给定矩阵最优"的，而 DCT 只是它的一类通用替代。**

附录 H：三条延伸思考（不附答案，供自测）

1. 设 $\mathbf{w}_1 = (2,0)^{\mathsf{T}}$，$\mathbf{w}_2 = (1,1)^{\mathsf{T}}$（**注意不正交**）。写出 W、W^{-1}，并把 $A = \begin{bmatrix}0 & 1\\ 1 & 0\end{bmatrix}$ 换到此基下。检验迹与行列式。
2. 若 A 与 B 相似且 A 是正交矩阵（$A^{\mathsf{T}}A = I$），B 也是正交矩阵吗？（提示：一般不。只有在 W 正交时才保持。）
3. 一个 8×8 块的全部 DCT 系数中，DC 系数是 1024，其余全部为零。画出/描述重建出的块的样子，并说出它的均值。（提示：$8\bar{B} = 1024 \Rightarrow \bar{B} = 128$，重建是均匀灰块，灰度 128。）

Lecture 33: Left and Right Inverses; Pseudoinverse

概述

我们已经知道：可逆矩阵有两侧的逆 A^{-1}，但长方形矩阵永远不可能有真正的逆。本讲要回答：**长方形矩阵在什么意义上"可求逆"？** 答案是分两半：高瘦矩阵有**左逆**（$LA = I_n$，把像还原回原像），矮胖矩阵有**右逆**（$AR = I_m$，给欠定方程挑一个解）。而**伪逆 A^+ 把两种情况统一起来**——它由 SVD 定义为 $A^+ = V\Sigma^+U^{\mathsf{T}}$，当 A 可逆时它就是 A^{-1}，当 A 奇异时它给出**最小范数最小二乘解 $A^+\mathbf{b}$**。本讲还会展示：AA^+ 与 A^+A 是两个**投影矩阵**，分别投影到 $C(A)$ 与 $C(A^{\mathsf{T}})$——把讲次 30 的投影语言与讲次 29 的 SVD 语言组装在一起。

核心概念的几何直觉

左逆（left inverse）——高瘦矩阵，$m > n$，列线性无关

- **定义与目的**：设 A 是 $m \times n$ 且 $m > n$，$\operatorname{rank} A = n$（满列秩）。则 $A^{\mathsf{T}}A$ 是 $n \times n$ 且**可逆**（因为 $N(A^{\mathsf{T}}A) = N(A) = \{\mathbf{0}\}$），定义

$$L = (A^{\mathsf{T}}A)^{-1}A^{\mathsf{T}} \quad (n \times m), \qquad LA = I_n.$$

但 $AL \neq I_m$。目的：**如果 $A\mathbf{x} = \mathbf{b}$ 有解（即 $\mathbf{b} \in C(A)$），那么解唯一且就是 $\mathbf{x} = L\mathbf{b}$。**

- **几何直觉（它在空间中是什么样子？）**：A 是**单射**（不同 $\mathbf{x}$ 给出不同 $\mathbf{b}$，因为零空间只有 $\mathbf{0}$），所以从输入空间 $\mathbb{R}^n$ 到像空间 $C(A)$ 的映射是**一一对应**。L 就是把这个一一对应**反过来**：它先做投影到 $C(A)$（这一步由 $A(A^{\mathsf{T}}A)^{-1}A^{\mathsf{T}}$ 完成），再逆映射回 $\mathbb{R}^n$。所以

$$LA = I_n, \qquad AL = \underbrace{A(A^{\mathsf{T}}A)^{-1}A^{\mathsf{T}}}_{P=\text{proj onto } C(A)} \neq I_m.$$

AL 不是恒等，它是投影：它把 $\mathbb{R}^m$ 中不在 $C(A)$ 里的分量直接扔掉。这就是"左逆只能还原真正的像，不能还原被丢掉的垂直分量"。

- **具体示例**：$A = \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 1 \end{bmatrix}$（$3 \times 2$，两列 $(1,0,1)^{\mathsf{T}}, (0,1,1)^{\mathsf{T}}$ 线性无关）。

$$A^{\mathsf{T}}A = \begin{bmatrix} 1 & 0 & 1 \\ 0 & 1 & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 1 \end{bmatrix} = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}, \qquad \det(A^{\mathsf{T}}A) = 3 \neq 0.$$

$$(A^{\mathsf{T}}A)^{-1} = \frac{1}{3}\begin{bmatrix} 2 & -1 \\ -1 & 2 \end{bmatrix}, \qquad L = (A^{\mathsf{T}}A)^{-1}A^{\mathsf{T}} = \frac{1}{3}\begin{bmatrix} 2 & -1 & 1 \\ -1 & 2 & 1 \end{bmatrix}.$$

验算 $LA = I_2$（脚本已通过）：

$$LA = \frac{1}{3}\begin{bmatrix} 2 & -1 & 1 \\ -1 & 2 & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 1 \end{bmatrix} = \frac{1}{3}\begin{bmatrix} 2-0+1 & 0-1+1 \\ -1+0+1 & 0+2+1 \end{bmatrix} = \frac{1}{3}\begin{bmatrix} 3 & 0 \\ 0 & 3 \end{bmatrix} = I_2. \ \checkmark$$

右逆（right inverse）——矮胖矩阵，$m < n$，行线性无关

- **定义与目的**：设 A 是 $m \times n$ 且 $m < n$，$\operatorname{rank} A = m$（满行秩）。则 AA^{T} 是 $m \times m$ 且**可逆**，定义

$$R = A^{\mathsf{T}}(AA^{\mathsf{T}})^{-1} \quad (n \times m), \qquad AR = I_m.$$

但 $RA \neq I_n$。目的：$A\mathbf{x} = \mathbf{b}$ **总有解**（因为 $C(A) = \mathbb{R}^m$，行满秩意味着像铺满整个输出空间），但解**不唯一**（零空间维数 $n - m > 0$）。$R\mathbf{b}$ 挑出其中**长度最小**的那个解。

- **几何直觉（它在空间中是什么样子？）**：A 是**满射**，所以 $\mathbb{R}^m$ 中每个 $\mathbf{b}$ 都有原像。原像构成一个仿射集 $\mathbf{x}_p + N(A)$（$n - m$ 维的"平行板"）。R 的作用是：**从这整块平行板中挑出离原点最近的那一点**，即垂直落点。因此

$$AR = I_m, \qquad RA = \underbrace{A^{\mathsf{T}}(AA^{\mathsf{T}})^{-1}A}_{P=\text{proj onto } C(A^{\mathsf{T}})} \neq I_n.$$

RA 是投影到行空间 $C(A^{\mathsf{T}})$ 的矩阵——它把 $\mathbf{x}$ 投影到行空间上，而零空间分量被清零。

- **具体示例**：$A = \begin{bmatrix} 1 & 0 & 1 \\ 0 & 1 & 1 \end{bmatrix}$（$2 \times 3$，两行线性无关）。

$$AA^{\mathsf{T}} = \begin{bmatrix} 1 & 0 & 1 \\ 0 & 1 & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 1 \end{bmatrix} = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}, \qquad (AA^{\mathsf{T}})^{-1} = \frac{1}{3}\begin{bmatrix} 2 & -1 \\ -1 & 2 \end{bmatrix},$$

$$R = A^{\mathsf{T}}(AA^{\mathsf{T}})^{-1} = \frac{1}{3}\begin{bmatrix} 2 & -1 \\ -1 & 2 \\ 1 & 1 \end{bmatrix}.$$

验算 $AR = I_2$（脚本已通过）：

$$AR = \frac{1}{3}\begin{bmatrix} 1 & 0 & 1 \\ 0 & 1 & 1 \end{bmatrix} \begin{bmatrix} 2 & -1 \\ -1 & 2 \\ 1 & 1 \end{bmatrix} = \frac{1}{3}\begin{bmatrix} 2+0+1 & -1+0+1 \\ 0-1+1 & 0+2+1 \end{bmatrix} = \frac{1}{3}\begin{bmatrix} 3 & 0 \\ 0 & 3 \end{bmatrix} = I_2. \ \checkmark$$

方阵的情形与"只有方阵才可能两侧都有逆"

- 若 A 是 $n \times n$ 且可逆：$(A^{\mathsf{T}}A)^{-1}A^{\mathsf{T}} = A^{-1}A^{-\mathsf{T}}A^{\mathsf{T}} = A^{-1}$，同样 $A^{\mathsf{T}}(AA^{\mathsf{T}})^{-1} = A^{-1}$。**左逆 = 右逆 = 逆。**
- 若 A 是 $n \times n$ 但**奇异**：$A^{\mathsf{T}}A$ 与 AA^{T} 都不可逆，两边公式都失效。这时不存在任何一侧的逆（无论左还是右）。**例**：$A = \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix}$，零空间非平凡，无法有左逆（$LA = I$ 意味着 L 能区分 $(1,-1)$ 与 $\mathbf{0}$，但 A 把两者都送到 $\mathbf{0}$）。

- **定理（本讲最重要的"不可能性"）**：若 $m \neq n$，则 A **不可能**同时有左逆与右逆。 *证明*：若 $LA = I_n$ 且 $AR = I_m$，则 $L = L(AR) = (LA)R = R$。设 $L = R = B$，则 $BA = I_n$ 且 $AB = I_m$。但 $AB = I_m$ 意味着 $\operatorname{rank} A \geq m$，$BA = I_n$ 意味着 $\operatorname{rank} A \geq n$；两者与 $m \neq n$ 时 $\operatorname{rank} A \leq \min(m,n) < \max(m,n)$ 矛盾。（更简单的论证：$AB = I_m$ 意味着 A 是满射 $\Rightarrow m \leq n$；$BA = I_n$ 意味着 A 是单射 $\Rightarrow n \leq m$；合起来 $m = n$。）
- **长方形矩阵只能有"一侧"的逆**，这个不对称正是伪逆要修补的地方。

伪逆（pseudoinverse）$A^+ = V\Sigma^+U^\mathsf{T}$

- **定义与目的**：设 $A = U\Sigma V^\mathsf{T}$ 是 SVD（讲次 29）。Σ 是 $m \times n$ 的对角矩阵，非零对角元 $\sigma_1 \geq \cdots \geq \sigma_r > 0$（$r = \operatorname{rank} A$），其余为零。定义 Σ^+ 为 $n \times m$ 矩阵：**把每个非零 σ_i 换成 $1/\sigma_i$，并把矩阵转置（行列互换）**。于是

$$\boxed{A^+ = V\,\Sigma^+\,U^\mathsf{T} \quad (n \times m).}$$

当 A 可逆时，$r = m = n$，$\Sigma^+ = \Sigma^{-1}$，于是 $A^+ = V\Sigma^{-1}U^\mathsf{T} = A^{-1}$。**伪逆是逆的推广。**

- **几何直觉（它在空间中是什么样子？）**：SVD 把 A 拆成"换基 → 沿正交方向缩放 → 换基"。逆操作就该是"换回来 → 沿同方向**除以** σ_i → 换回来"。但问题是：**某些方向被 A 压成了零**（那些 $\sigma_i = 0$ 的方向），它们的信息已经**永久丢失**，无法真正还原。伪逆的处理办法非常聪明：**对这些零方向，直接送 0，绝不试图除以 0。** 用图看最高效：

```
        A 的作用（SVD 的两组正交基）
┌──────────────────────────────────────────────────────┐
│  输入空间 R^n                  输出空间 R^m          │
│                                                      │
│  v1 ──(×σ1)──►  σ1 u1     u1                         │
│  v2 ──(×σ2)──►  σ2 u2     u2                         │
│  ...                          (r 个非零奇异值方向：满秩部分)  │
│  v_{r+1} ──(×0)──►  0                                │
│  ...                          (n−r 个方向被压成 0)   │
│  v_n ──(×0)──►  0                                    │
└──────────────────────────────────────────────────────┘

        A⁺ 的作用：沿着同样的方向走回去，但除以 σᵢ，零方向送回 0
┌──────────────────────────────────────────────────────┐
│  u1 ──(÷σ1)──►  v1          (σ1 ≠ 0：可以精确还原)   │
│  u2 ──(÷σ2)──►  v2                                   │
│  ...                                                 │
│  输出空间中垂直于 C(A) 的方向 ──► 0    ("无解方向"送 0)  │
│  v_{r+1},...,v_n（被 A 杀掉的方向）──► 无处可去，A⁺ 不含它们 │
└──────────────────────────────────────────────────────┘

    Σ⁺ 的形状：把 m×n 的 Σ 转置成 n×m，非零元取倒数
    Σ = ⎡σ1 0  0⎤      Σ⁺ = ⎡1/σ1  0  ⎤
        ⎢0  σ2 0⎥           ⎢ 0  1/σ2 ⎥
        ⎣0  0  0⎦ (3×3)     ⎢ 0    0  ⎥ (3×3)
                            ⎣ 0    0  ⎦
    零行/零列 ↔ 被丢弃的方向：绝不除零，直接补零
```

- **具体示例（预告，见下面完整手算）**：$A = \begin{bmatrix} 3 & 0 \\ 4 & 5 \end{bmatrix}$ 可逆，$A^+ = A^{-1} = \frac{1}{15}\begin{bmatrix} 5 & 0 \\ -4 & 3 \end{bmatrix}$；$A = \begin{bmatrix} 1 & 1 \\ 0 & 0 \end{bmatrix}$ 奇异，$A^+ = \frac{1}{2}\begin{bmatrix} 1 & 0 \\ 1 & 0 \end{bmatrix}$。

闵可夫斯基—彭罗斯条件（Moore–Penrose conditions）——伪逆的"公理化"定义

- **定义与目的**：A^+ 是**唯一**满足以下四条条件的 $n \times m$ 矩阵：

$$(1)\ AA^+A = A, \qquad (2)\ A^+AA^+ = A^+, \qquad (3)\ (AA^+)^\mathsf{T} = AA^+, \qquad (4)\ (A^+A)^\mathsf{T} = A^+A.$$

目的：这四条把"A^+ 是 A 的最好替身"这个模糊愿望翻译成精确方程。**（1）（2）说 A^+ 在秩空间上互为逆；（3）（4）说两个投影是正交投影（讲次 14–17）。**

- **几何直觉（它在空间中是什么样子？）**：(1) 只在实际上"有内容"的方向上要求还原；(2) 保证不引入多余成分；(3)(4) 保证"丢弃"的方式是**垂直**丢弃（最短距离），而不是斜着丢。

四条条件的第一条最直观：$AA^+A = A$ 说明"A^+ 在 A 的像上是 A 的真逆"。第三条说 AA^+ 对称——正是讲次 30 讲的**正交投影矩阵判据**。

- **具体示例**：$A = \begin{bmatrix} 1 & 1 \\ 0 & 0 \end{bmatrix}$，$A^+ = \frac{1}{2}\begin{bmatrix} 1 & 0 \\ 1 & 0 \end{bmatrix}$。

$$AA^+ = \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix}, \qquad A^+A = \frac{1}{2}\begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix}.$$

两者都对称、都幂等（脚本验算通过）。AA^+ 投影到 $C(A) = \operatorname{span}\{(1,0)\}$（$x$ 轴）；A^+A 投影到 $C(A^\mathsf{T}) = \operatorname{span}\{(1,1)\}$（直线 $y = x$）。

伪逆给出的最小范数最小二乘解

- **定义与目的**：

$$\hat{\mathbf{x}} = A^{+}\mathbf{b}$$

给出 $\|A\mathbf{x}-\mathbf{b}\|$ 的**最小化者**中 $\|\mathbf{x}\|$ **最小**的那一个。 – 若 A 列满秩（$m \geq n$，$\mathbf{rank} = n$）：最小二乘解**唯一**，$A^{+}\mathbf{b} = (A^{\mathsf{T}}A)^{-1}A^{\mathsf{T}}\mathbf{b}$，就是讲次 16 的正规方程解。 – 若 A 列相关（$\mathbf{rank} < n$）：最小二乘解有**无穷多个**（都在一个仿射集里），$A^{+}\mathbf{b}$ 选出**范数最小**的那个。 – 若 A 行满秩且 $m < n$：$\mathbf{b}$ 在 $C(A)$ 里，$A^{+}\mathbf{b}$ 是**唯一的最小范数精确解**。

- **几何直觉（它在空间中是什么样子？）**：把 $\mathbb{R}^n$ 分成两块：**行空间** $C(A^{\mathsf{T}})$ 与**零空间** $N(A)$。所有最小二乘解构成一个"平行于零空间的板" $\hat{\mathbf{x}} + N(A)$。板内各点差别只在零空间方向，而零空间方向**不影响** $A\mathbf{x}$（误差不变），却**增加** $\|\mathbf{x}\|$。所以最短的那个点必然**垂直于零空间**，即**落在行空间里**。伪逆正是干这件事：

$$\hat{\mathbf{x}} = A^{+}\mathbf{b} \in C(A^{\mathsf{T}}), \qquad \hat{\mathbf{x}} \perp N(A).$$

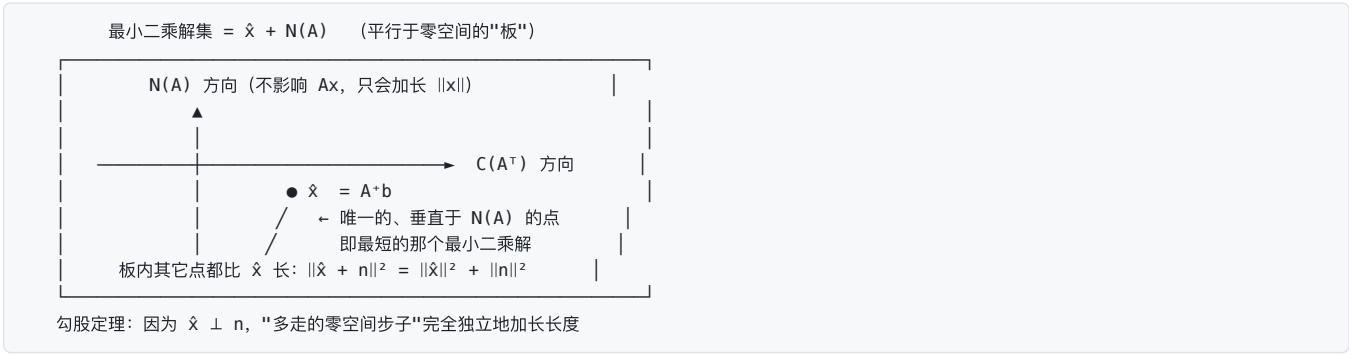

计算步骤与手算演示

示例 1（主戏）：对 $A = \begin{bmatrix} 3 & 0 \\ 4 & 5 \end{bmatrix}$ 手算 SVD，再构造 $A^{+} = V\Sigma^{+}U^{\mathsf{T}}$

步骤 1：写出 A 与 $A^{\mathsf{T}}A$。

$$A = \begin{bmatrix} 3 & 0 \\ 4 & 5 \end{bmatrix}, \qquad A^{\mathsf{T}} = \begin{bmatrix} 3 & 4 \\ 0 & 5 \end{bmatrix}, \qquad A^{\mathsf{T}}A = \begin{bmatrix} 3 & 4 \\ 0 & 5 \end{bmatrix}\begin{bmatrix} 3 & 0 \\ 4 & 5 \end{bmatrix} = \begin{bmatrix} 9+16 & 0+20 \\ 0+20 & 0+25 \end{bmatrix} = \begin{bmatrix} 25 & 20 \\ 20 & 25 \end{bmatrix}.$$

（逐项：第 1 行第 1 列 $= A^{\mathsf{T}}$ 第 1 行 $\cdot$ A 第 1 列 $= (3,4)\cdot(3,4) = 9+16 = 25$，其余同理。）

步骤 2：求 $A^{\mathsf{T}}A$ 的特征值与特征向量。 $\mathbf{tr} = 50$，$\mathbf{det} = 25\cdot 25 - 20\cdot 20 = 625 - 400 = 225$。特征方程

$$\lambda^2 - 50\lambda + 225 = 0 \implies \lambda = \frac{50 \pm \sqrt{2500-900}}{2} = \frac{50 \pm 40}{2} \implies \lambda_1 = 45,\ \lambda_2 = 5.$$

（脚本核验：$\mathbf{tr} = 50$，$\mathbf{det} = 225$，$\mathbf{tr}^2 - 4\,\mathbf{det} = 2500 - 900 = 1600$，$\sqrt{1600} = 40$，$\lambda = (50 \pm 40)/2 = 45, 5$ ✓。）

步骤 3：求奇异值。 $\sigma_i = \sqrt{\lambda_i}$：

$$\sigma_1 = \sqrt{45} = 3\sqrt{5} \approx 6.7082039325, \qquad \sigma_2 = \sqrt{5} \approx 2.2360679775.$$

步骤 4：求右奇异向量 V（$A^{\mathsf{T}}A$ 的单位特征向量）。 对 $\lambda_1 = 45$：$A^{\mathsf{T}}A - 45I = \begin{bmatrix} -20 & 20 \\ 20 & -20 \end{bmatrix}$，方程 $-20x + 20y = 0$ 即 $x = y$，取 $\mathbf{v}_1 = \frac{1}{\sqrt{2}}\begin{bmatrix} 1 \\ 1 \end{bmatrix}$。对 $\lambda_2 = 5$：$A^{\mathsf{T}}A - 5I = \begin{bmatrix} 20 & 20 \\ 20 & 20 \end{bmatrix}$，方程 $x + y = 0$，取 $\mathbf{v}_2 = \frac{1}{\sqrt{2}}\begin{bmatrix} 1 \\ -1 \end{bmatrix}$。**核验**（脚本通过）：

$$A^{\mathsf{T}}A\mathbf{v}_1 = \begin{bmatrix} 25 & 20 \\ 20 & 25 \end{bmatrix}\frac{1}{\sqrt{2}}\begin{bmatrix} 1 \\ 1 \end{bmatrix} = \frac{1}{\sqrt{2}}\begin{bmatrix} 45 \\ 45 \end{bmatrix} = 45\mathbf{v}_1 \checkmark, \qquad A^{\mathsf{T}}A\mathbf{v}_2 = \frac{1}{\sqrt{2}}\begin{bmatrix} 5 \\ -5 \end{bmatrix} = 5\mathbf{v}_2 \checkmark.$$

$$V = [\mathbf{v}_1 \quad \mathbf{v}_2] = \frac{1}{\sqrt{2}}\begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} = \begin{bmatrix} 0.70710678 & 0.70710678 \\ 0.70710678 & -0.70710678 \end{bmatrix}.$$

步骤 5：求左奇异向量 U。 用 $\mathbf{u}_i = \frac{1}{\sigma_i}A\mathbf{v}_i$：

$$A\mathbf{v}_1 = \frac{1}{\sqrt{2}}\begin{bmatrix} 3 & 0 \\ 4 & 5 \end{bmatrix}\begin{bmatrix} 1 \\ 1 \end{bmatrix} = \frac{1}{\sqrt{2}}\begin{bmatrix} 3 \\ 9 \end{bmatrix} = \begin{bmatrix} 2.12132034 \\ 6.36396103 \end{bmatrix}, \qquad \|A\mathbf{v}_1\| = 6.70820393 = \sigma_1 \checkmark,$$

$$\mathbf{u}_1 = \frac{A\mathbf{v}_1}{\sigma_1} = \frac{1}{3\sqrt{5}}\cdot\frac{1}{\sqrt{2}}\begin{bmatrix} 3 \\ 9 \end{bmatrix} = \frac{1}{\sqrt{10}}\begin{bmatrix} 1 \\ 3 \end{bmatrix} = \begin{bmatrix} 0.31622777 \\ 0.94868330 \end{bmatrix}.$$

（**易错点**：这里最容易把 $\mathbf{u}_1$ 与 $\mathbf{u}_2$ 的分量顺序写颠倒，误得 $\mathbf{u}_1=\frac{1}{\sqrt{10}}(3,1)^{\mathsf T}$。自检方法：$\mathbf{u}_1$ 必须与 $\mathbf{u}_2=\frac{1}{\sqrt{10}}(3,-1)^{\mathsf T}$ 正交，而 $(3,1)\cdot(3,-1)=9-1=8\neq 0$，错误会立刻暴露。正确结果是 $\frac{1}{\sqrt{10}}(1,3)^{\mathsf T}$——此时 $(1,3)\cdot(3,-1)=3-3=0$ ✓。）

$$A\mathbf{v}_2=\frac{1}{\sqrt{2}}\begin{bmatrix}3&0\\4&5\end{bmatrix}\begin{bmatrix}1\\-1\end{bmatrix}=\frac{1}{\sqrt{2}}\begin{bmatrix}3\\-1\end{bmatrix}=\begin{bmatrix}2.12132034\\-0.70710678\end{bmatrix},\qquad \|A\mathbf{v}_2\|=2.23606798=\sigma_2\ \checkmark,$$

$$\mathbf{u}_2=\frac{A\mathbf{v}_2}{\sigma_2}=\frac{1}{\sqrt{5}}\cdot\frac{1}{\sqrt{2}}\begin{bmatrix}3\\-1\end{bmatrix}=\frac{1}{\sqrt{10}}\begin{bmatrix}3\\-1\end{bmatrix}=\begin{bmatrix}0.94868330\\-0.31622777\end{bmatrix}.$$

（这一步用的是**同一个转置关系**：$\mathbf{u}_i$ 与 $\mathbf{v}_i$ 都把"较大的"分量放在第 1 项，所以顺序才对得上。）

$$U=[\mathbf{u}_1\quad\mathbf{u}_2]=\begin{bmatrix}0.31622777&0.94868330\\0.94868330&-0.31622777\end{bmatrix},\qquad U^{\mathsf T}U=I_2\ \checkmark\ (\text{脚本通过}).$$

步骤 6：核验 $A=U\Sigma V^{\mathsf T}$。 $\Sigma=\begin{bmatrix}3\sqrt{5}&0\\0&\sqrt{5}\end{bmatrix}$，脚本验算 $U\Sigma V^{\mathsf T}=A$ ✓。

步骤 7：构造 Σ^+（注意"取倒数"+"转置"）。 A 可逆（$\det=15\neq 0$），$r=2=m=n$，所以

$$\Sigma^+=\begin{bmatrix}1/\sigma_1&0\\0&1/\sigma_2\end{bmatrix}=\begin{bmatrix}\frac{1}{3\sqrt{5}}&0\\0&\frac{1}{\sqrt{5}}\end{bmatrix}=\begin{bmatrix}0.14907120&0\\0&0.44721360\end{bmatrix}.$$

（这里 $m=n$，"转置"不改变形状；长方形时才看得出转置。）

步骤 8：算 $A^+=V\Sigma^+U^{\mathsf T}$。 逐步：

$$\Sigma^+U^{\mathsf T}=\begin{bmatrix}\frac{1}{3\sqrt{5}}&0\\0&\frac{1}{\sqrt{5}}\end{bmatrix}\begin{bmatrix}\frac{1}{\sqrt{10}}&\frac{3}{\sqrt{10}}\\\frac{3}{\sqrt{10}}&-\frac{1}{\sqrt{10}}\end{bmatrix}=\begin{bmatrix}\frac{1}{3\sqrt{50}}&\frac{3}{3\sqrt{50}}\\\frac{3}{\sqrt{50}}&-\frac{1}{\sqrt{50}}\end{bmatrix}=\begin{bmatrix}\frac{1}{3\cdot 5\sqrt{2}}&\frac{1}{5\sqrt{2}}\\\frac{3}{5\sqrt{2}}&-\frac{1}{5\sqrt{2}}\end{bmatrix},$$

$$A^+=\frac{1}{\sqrt{2}}\begin{bmatrix}1&1\\1&-1\end{bmatrix}\begin{bmatrix}\frac{1}{15\sqrt{2}}&\frac{1}{5\sqrt{2}}\\\frac{3}{5\sqrt{2}}&-\frac{1}{5\sqrt{2}}\end{bmatrix}=\frac{1}{\sqrt{2}\cdot 5\sqrt{2}}\begin{bmatrix}1&1\\1&-1\end{bmatrix}\begin{bmatrix}\frac{1}{3}&1\\3&-1\end{bmatrix}=\frac{1}{10}\begin{bmatrix}\frac{1}{3}+3&1-1\\\frac{1}{3}-3&1+1\end{bmatrix}=\frac{1}{10}\begin{bmatrix}\frac{10}{3}&0\\-\frac{8}{3}&2\end{bmatrix}.$$

$$A^+=\begin{bmatrix}\frac{1}{3}&0\\-\frac{4}{15}&\frac{1}{5}\end{bmatrix}=\begin{bmatrix}0.33333333&0\\-0.26666667&0.2\end{bmatrix}.$$

步骤 9：与 A^{-1} 对比。 $\det A=3\cdot 5-0\cdot 4=15$，

$$A^{-1}=\frac{1}{15}\begin{bmatrix}5&0\\-4&3\end{bmatrix}=\begin{bmatrix}\frac{1}{3}&0\\-\frac{4}{15}&\frac{1}{5}\end{bmatrix}.$$

完全相同 ✓（脚本验算 $A^+=A^{-1}$ 通过）。

步骤 10：验证 $A^+A=AA^+=I$。

$$A^+A=\begin{bmatrix}\frac{1}{3}&0\\-\frac{4}{15}&\frac{1}{5}\end{bmatrix}\begin{bmatrix}3&0\\4&5\end{bmatrix}=\begin{bmatrix}1&0\\-\frac{4}{5}+\frac{4}{5}&1\end{bmatrix}=\begin{bmatrix}1&0\\0&1\end{bmatrix}\checkmark,$$

$$AA^+=\begin{bmatrix}3&0\\4&5\end{bmatrix}\begin{bmatrix}\frac{1}{3}&0\\-\frac{4}{15}&\frac{1}{5}\end{bmatrix}=\begin{bmatrix}1&0\\\frac{4}{3}-\frac{4}{3}&1\end{bmatrix}=I_2\checkmark.$$

（脚本验算通过。）

步骤 11：Moore–Penrose 四条件全部核验。 $AA^+=A^+A=I$ 对称且幂等，这里 A 可逆且 $A^+=A^{-1}$，所以 $AA^+=A^+A=I_2$ **因此四条退化为平凡检验**：(1) $AA^+A=I_2A=A$ ✓；(2) $A^+AA^+=I_2A^+=A^+$ ✓。脚本输出：四条全 `true` ✓。

【计算机制解说】：为什么 $A^+=V\Sigma^+U^{\mathsf T}$ 是对的？把 SVD 的全部关系串起来：

$$A^+A=V\Sigma^+\underbrace{U^{\mathsf T}U}_{I}\Sigma V^{\mathsf T}=V(\Sigma^+\Sigma)V^{\mathsf T}.$$

$\Sigma^+\Sigma$ 是 $n\times n$ 对角矩阵，第 i 个对角元是 $\frac{1}{\sigma_i}\cdot\sigma_i=1$（若 $\sigma_i\neq 0$）或 $0\cdot$（无定义）$=0$（若 $\sigma_i=0$，按约定补零）。所以

$$\Sigma^+\Sigma=\begin{bmatrix}I_r&0\\0&0\end{bmatrix}_{n\times n}\Longrightarrow A^+A=V\begin{bmatrix}I_r&0\\0&0\end{bmatrix}V^{\mathsf T}=\sum_{i=1}^{r}\mathbf{v}_i\mathbf{v}_i^{\mathsf T}.$$

这正是投影到前 r 个右奇异向量张成的子空间 = 行空间 $C(A^{\mathsf T})$ 的正交投影矩阵（讲次 30 的外积公式）！同理

$$AA^{+} = U\begin{bmatrix} I_r & 0 \\ 0 & 0 \end{bmatrix}U^{\mathsf{T}} = \sum_{i=1}^{r} \mathbf{u}_i\mathbf{u}_i^{\mathsf{T}} = \text{投影到 } C(A).$$

所以两条 Moore–Penrose 对称性条件自动成立——它们是"正交投影"的代数陈述。 而 $A^{+}A$ 与 AA^{+} 的幂等性也立刻看出来：$V\begin{bmatrix} I_r & 0 \\ 0 & 0 \end{bmatrix}V^{\mathsf{T}}$ 平方后中间的 $\begin{bmatrix} I_r & 0 \\ 0 & 0 \end{bmatrix}$ 自乘不变。**"绝不对零奇异值求倒数"这条约定，在代数上就是这个 $\begin{bmatrix} I_r & 0 \\ 0 & 0 \end{bmatrix}$ 结构。**

注意一个易错点：Σ^{+} 的形状是 $n \times m$（**转置**了）。A 是 $m \times n$ 时，A^{+} 是 $n \times m$，Σ 是 $m \times n$，所以 Σ^{+} 必须是 $n \times m$ 才能让 $V\Sigma^{+}U^{\mathsf{T}}$ 维度对上：$(n \times n)(n \times m)(m \times m) = (n \times m)$ ✓。

示例 2：奇异矩阵 $A = \begin{bmatrix} 1 & 1 \\ 0 & 0 \end{bmatrix}$ 的伪逆——投影性质登场

步骤 1：算 $A^{\mathsf{T}}A$ 与 AA^{T}。

$$A^{\mathsf{T}}A = \begin{bmatrix} 1 & 0 \\ 1 & 0 \end{bmatrix}\begin{bmatrix} 1 & 1 \\ 0 & 0 \end{bmatrix} = \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix}, \qquad AA^{\mathsf{T}} = \begin{bmatrix} 1 & 1 \\ 0 & 0 \end{bmatrix}\begin{bmatrix} 1 & 0 \\ 1 & 0 \end{bmatrix} = \begin{bmatrix} 2 & 0 \\ 0 & 0 \end{bmatrix}.$$

（脚本验算通过。）

步骤 2：求奇异值与右奇异向量。 $A^{\mathsf{T}}A = \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix}$，$\mathrm{tr} = 2$，$\det = 0$，特征值 $2, 0$（验算通过）。所以 $\sigma_1 = \sqrt{2} \approx 1.41421356$，$\sigma_2 = 0$。**秩 $r = 1$。** $\lambda_1 = 2$ 时 $A^{\mathsf{T}}A - 2I = \begin{bmatrix} -1 & 1 \\ 1 & -1 \end{bmatrix}$，$x = y$，$\mathbf{v}_1 = \frac{1}{\sqrt{2}}\begin{bmatrix} 1 \\ 1 \end{bmatrix}$；$\lambda_2 = 0$ 时 $x + y = 0$，$\mathbf{v}_2 = \frac{1}{\sqrt{2}}\begin{bmatrix} 1 \\ -1 \end{bmatrix}$。

步骤 3：求左奇异向量。

$$A\mathbf{v}_1 = \frac{1}{\sqrt{2}}\begin{bmatrix} 1 & 1 \\ 0 & 0 \end{bmatrix}\begin{bmatrix} 1 \\ 1 \end{bmatrix} = \frac{1}{\sqrt{2}}\begin{bmatrix} 2 \\ 0 \end{bmatrix} = \begin{bmatrix} 1.41421356 \\ 0 \end{bmatrix}, \qquad \|A\mathbf{v}_1\| = \sqrt{2} = \sigma_1 \checkmark,$$

$$\mathbf{u}_1 = \frac{A\mathbf{v}_1}{\sigma_1} = \frac{1}{\sqrt{2}} \cdot \frac{1}{\sqrt{2}}\begin{bmatrix} 2 \\ 0 \end{bmatrix} = \begin{bmatrix} 1 \\ 0 \end{bmatrix}.$$

注意 $\mathbf{u}_2$ 没有公式可算（$\sigma_2 = 0$），必须人为补一个与 $\mathbf{u}_1$ 正交的单位向量：取 $\mathbf{u}_2 = \begin{bmatrix} 0 \\ 1 \end{bmatrix}$。

$$U = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} = I_2, \qquad V = \frac{1}{\sqrt{2}}\begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}.$$

步骤 4：核验 $A = \sigma_1\mathbf{u}_1\mathbf{v}_1^{\mathsf{T}}$（秩 1 的 SVD）。

$$\sqrt{2}\begin{bmatrix} 1 \\ 0 \end{bmatrix} \cdot \frac{1}{\sqrt{2}}\begin{bmatrix} 1 & 1 \end{bmatrix} = \begin{bmatrix} 1 & 1 \\ 0 & 0 \end{bmatrix} = A \checkmark \text{ (脚本通过)}.$$

秩 1 矩阵只有一项——这是"低秩逼近"的最简情形（讲次 29）。

步骤 5：构造 Σ^{+}。 $\Sigma = \begin{bmatrix} \sqrt{2} & 0 \\ 0 & 0 \end{bmatrix}$（$2 \times 2$），非零元只有 σ_1，取倒数：

$$\Sigma^{+} = \begin{bmatrix} 1/\sqrt{2} & 0 \\ 0 & 0 \end{bmatrix} = \begin{bmatrix} 0.70710678 & 0 \\ 0 & 0 \end{bmatrix}.$$

关键动作：$\sigma_2 = 0$ 的位置写 0，绝不写 $1/0$。

步骤 6：算 $A^{+} = V\Sigma^{+}U^{\mathsf{T}}$。

$$\Sigma^{+}U^{\mathsf{T}} = \begin{bmatrix} \frac{1}{\sqrt{2}} & 0 \\ 0 & 0 \end{bmatrix}\begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} = \begin{bmatrix} \frac{1}{\sqrt{2}} & 0 \\ 0 & 0 \end{bmatrix},$$

$$A^{+} = \frac{1}{\sqrt{2}}\begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}\begin{bmatrix} \frac{1}{\sqrt{2}} & 0 \\ 0 & 0 \end{bmatrix} = \frac{1}{2}\begin{bmatrix} 1 & 0 \\ 1 & 0 \end{bmatrix} = \begin{bmatrix} 0.5 & 0 \\ 0.5 & 0 \end{bmatrix}.$$

等价地：$A^{+} = \frac{1}{\sigma_1}\mathbf{v}_1\mathbf{u}_1^{\mathsf{T}} = \frac{1}{\sqrt{2}} \cdot \frac{1}{\sqrt{2}}\begin{bmatrix} 1 \\ 1 \end{bmatrix}\begin{bmatrix} 1 & 0 \end{bmatrix} = \frac{1}{2}\begin{bmatrix} 1 & 0 \\ 1 & 0 \end{bmatrix}$ ✓（脚本通过）。

步骤 7：算 $A^{+}A$ 与 AA^{+}（本讲最漂亮的一步）。

$$A^{+}A = \begin{bmatrix} 0.5 & 0 \\ 0.5 & 0 \end{bmatrix}\begin{bmatrix} 1 & 1 \\ 0 & 0 \end{bmatrix} = \begin{bmatrix} 0.5 & 0.5 \\ 0.5 & 0.5 \end{bmatrix} = \frac{1}{2}\begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix},$$

$$AA^{+} = \begin{bmatrix} 1 & 1 \\ 0 & 0 \end{bmatrix}\begin{bmatrix} 0.5 & 0 \\ 0.5 & 0 \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix}.$$

（脚本验算通过。）**两个都是投影矩阵！**

步骤 8：验证投影矩阵的四项体检。 – $A^+A=\frac{1}{2}\begin{bmatrix}1&1\\1&1\end{bmatrix}$：对称 ✓，幂等 ✓，$\mathbf{tr}=1$，$\mathbf{det}=0$。 – $AA^+=\begin{bmatrix}1&0\\0&0\end{bmatrix}$：对称 ✓，幂等 ✓，$\mathbf{tr}=1$，$\mathbf{det}=0$。（脚本验算：对称、幂等均为 `true`。）

步骤 9：它们分别投影到哪里？ – $AA^+=\begin{bmatrix}1&0\\0&0\end{bmatrix}$：把 $(x,y)^\mathsf{T}$ 送到 $(x,0)^\mathsf{T}$。投影到 $C(A)=\mathbf{span}\{(1,0)\}$（$x$ 轴）。检验：$AA^+(7,0)^\mathsf{T}=(7,0)^\mathsf{T}$ ✓。 – $A^+A=\frac{1}{2}\begin{bmatrix}1&1\\1&1\end{bmatrix}$：正是讲次 30 示例 2 的矩阵！投影到 $C(A^\mathsf{T})=\mathbf{span}\{(1,1)\}$（直线 $y=x$）。检验：$A^+A(1,1)^\mathsf{T}=(1,1)^\mathsf{T}$ ✓。

步骤 10：四条 Moore–Penrose 条件核验。 – (1) $AA^+A=\begin{bmatrix}1&0\\0&0\end{bmatrix}\begin{bmatrix}1&1\\0&0\end{bmatrix}=\begin{bmatrix}1&1\\0&0\end{bmatrix}=A$ ✓ – (2) $A^+AA^+=\frac{1}{2}\begin{bmatrix}1&1\\1&1\end{bmatrix}\begin{bmatrix}0.5&0\\0.5&0\end{bmatrix}=\begin{bmatrix}0.5&0\\0.5&0\end{bmatrix}=A^+$ ✓ – (3) $(AA^+)^\mathsf{T}=AA^+$ ✓（已验证对称） – (4) $(A^+A)^\mathsf{T}=A^+A$ ✓ （脚本输出：四条全 `true`。）

步骤 11：秩。 $\mathbf{rank}\,A=1=\mathbf{rank}\,A^+$。一般地 $\mathbf{rank}\,A^+=\mathbf{rank}\,A=r$，因为 $A^+=V\Sigma^+U^\mathsf{T}$ 中 Σ^+ 的非零元个数就是 r，而 U,V 可逆。

【计算机制解说】：这个例子把讲次 29（SVD）、讲次 30（投影）、讲次 33（伪逆）三条线拧成一股。为什么 A^+A 恰好投影到行空间，而 AA^+ 恰好投影到列空间？从 SVD 看：

$$A^+A=V\Sigma^+U^\mathsf{T}U\Sigma V^\mathsf{T}=V(\Sigma^+\Sigma)V^\mathsf{T}=V\begin{bmatrix}1&0\\0&0\end{bmatrix}V^\mathsf{T}=\mathbf{v}_1\mathbf{v}_1^\mathsf{T}.$$

对 $A=\begin{bmatrix}1&1\\0&0\end{bmatrix}$：$\mathbf{v}_1=\frac{1}{\sqrt{2}}(1,1)^\mathsf{T}$，

$$\mathbf{v}_1\mathbf{v}_1^\mathsf{T}=\frac{1}{2}\begin{bmatrix}1\\1\end{bmatrix}\begin{bmatrix}1&1\end{bmatrix}=\frac{1}{2}\begin{bmatrix}1&1\\1&1\end{bmatrix}=A^+A\ \checkmark.$$

同理 $AA^+=\mathbf{u}_1\mathbf{u}_1^\mathsf{T}=\begin{bmatrix}1\\0\end{bmatrix}\begin{bmatrix}1&0\end{bmatrix}=\begin{bmatrix}1&0\\0&0\end{bmatrix}$ ✓。**为什么必须是"投影到这些子空间"而不是别的投影？** 因为 $\mathbf{u}_1,\mathbf{v}_1$ 是 SVD 给出的**正交**方向。如果 A 的列相关（$\sigma_2=0$），$C(A^\mathsf{T})$ 的维数小于 n，那个"多出来的"方向 $\mathbf{v}_2$ 被 A^+A 送 $(1,0,0)$；正是这个"送零"保证了 $\hat{\mathbf{x}}\perp N(A)$，也就是保证了最小范数。

示例 3：最小范数最小二乘解——$A^+\mathbf{b}$ 比所有其他解都短

用 $A=\begin{bmatrix}1&1\\0&0\end{bmatrix}$，$\mathbf{b}=(2,5)^\mathsf{T}$。

步骤 1：写出最小二乘问题。 $A\mathbf{x}=(x_1+x_2,\,0)^\mathsf{T}$，所以

$$\|A\mathbf{x}-\mathbf{b}\|^2=(x_1+x_2-2)^2+(0-5)^2=(x_1+x_2-2)^2+25.$$

第 2 项是常数 25，与 $\mathbf{x}$ 无关；最小化只能作用于第 1 项，取 $x_1+x_2=2$。**最小残差 $\|A\hat{\mathbf{x}}-\mathbf{b}\|=\sqrt{25}=5$，且最小二乘解构成整条直线 $x_1+x_2=2$。**

步骤 2：用伪逆取解。

$$\hat{\mathbf{x}}=A^+\mathbf{b}=\begin{bmatrix}0.5&0\\0.5&0\end{bmatrix}\begin{bmatrix}2\\5\end{bmatrix}=\begin{bmatrix}1\\1\end{bmatrix}=(1,1)^\mathsf{T},\qquad \|\hat{\mathbf{x}}\|=\sqrt{2}\approx 1.41421356.$$

（脚本验算：$\|\hat{\mathbf{x}}\|=1.41421356$ ✓。）

步骤 3：枚举同一直线上的其他最小二乘解，比较范数（脚本验算数据）：

最小二乘解 $\mathbf{x}$	残差 $A\mathbf{x}-\mathbf{b}$	$\|$残差$\|$	$\|\mathbf{x}\|$
$(2,0)^\mathsf{T}$	$(0,-5)^\mathsf{T}$	5.000000	2.000000
$(0,2)^\mathsf{T}$	$(0,-5)^\mathsf{T}$	5.000000	2.000000
$(3,-1)^\mathsf{T}$	$(0,-5)^\mathsf{T}$	5.000000	3.162278
$(1.5,0.5)^\mathsf{T}$	$(0,-5)^\mathsf{T}$	5.000000	1.581139
$\hat{\mathbf{x}}=(1,1)^\mathsf{T}$	$(0,-5)^\mathsf{T}$	5.000000	**1.414214** ← 最短

四个候选的残差范数全部相等（都是 5），但 $\hat{\mathbf{x}}=(1,1)^\mathsf{T}$ 的范数最小。

步骤 4：为什么它最短——勾股分解。 所有最小二乘解是 $\hat{\mathbf{x}}+N(A)$。这里 $N(A)=\mathbf{span}\{(1,-1)\}$（因为 $x_1+x_2=0$）。对任何 $\mathbf{n}\in N(A)$，

$$\|\hat{\mathbf{x}}+\mathbf{n}\|^2=\|\hat{\mathbf{x}}\|^2+2\hat{\mathbf{x}}^{\mathsf{T}}\mathbf{n}+\|\mathbf{n}\|^2.$$

交叉项 $\hat{\mathbf{x}}^{\mathsf{T}}\mathbf{n}=(1,1)\cdot(1,-1)=1-1=0$——因为 $\hat{\mathbf{x}}\in C(A^{\mathsf{T}})=\mathrm{span}\{(1,1)\}$ 与 $N(A)$ 正交（四个基本子空间的正交关系，讲次 10）。于是

$$\|\hat{\mathbf{x}}+\mathbf{n}\|^2=\|\hat{\mathbf{x}}\|^2+\|\mathbf{n}\|^2\geq\|\hat{\mathbf{x}}\|^2.$$

例：取 $\mathbf{n}=t(1,-1)$，$\mathbf{x}=(1+t,1-t)$，$\|\mathbf{x}\|^2=1+2t+t^2+1-2t+t^2=2+2t^2\geq 2$ ✓。

步骤 5：正规方程也印证这一点。 $A^{\mathsf{T}}A\mathbf{x}=A^{\mathsf{T}}\mathbf{b}$：

$$\begin{bmatrix}1&1\\1&1\end{bmatrix}\begin{bmatrix}x_1\\x_2\end{bmatrix}=\begin{bmatrix}1&0\\1&0\end{bmatrix}\begin{bmatrix}2\\5\end{bmatrix}=\begin{bmatrix}2\\2\end{bmatrix}\implies x_1+x_2=2.$$

正规方程只有一个独立方程（$A^{\mathsf{T}}A$ 奇异），所以解不唯一。伪逆在此处的作用是**从无穷多解中挑出 $C(A^{\mathsf{T}})$ 里那个**。

步骤 6：推广到 3 维的另一例（脚本验算）。 取 $\mathbf{b}=(3,5)^{\mathsf{T}}$ 与 $A=\begin{bmatrix}1&1\\0&0\end{bmatrix}$（同上）：$\hat{\mathbf{x}}=(1.5,1.5)^{\mathsf{T}}$，$\|\hat{\mathbf{x}}\|=2.12132034=3/\sqrt{2}$ ✓。再取 $D=\begin{bmatrix}1&1&1\\0&0&0\end{bmatrix}$（$2\times 3$，秩 1），$\mathbf{b}=(3,5)^{\mathsf{T}}$：

$$D^{+}=\frac{1}{3}\begin{bmatrix}1&0\\1&0\\1&0\end{bmatrix},\qquad \hat{\mathbf{x}}=D^{+}\mathbf{b}=\begin{bmatrix}1\\1\\1\end{bmatrix},\qquad \|\hat{\mathbf{x}}\|=\sqrt{3}\approx 1.73205081.$$

候选解比较（脚本验算）：$(3,0,0)^{\mathsf{T}}$ 长度 3.000、$(0,3,0)^{\mathsf{T}}$ 长度 3.000、$(2,1,0)^{\mathsf{T}}$ 长度 2.236068、$(1.5,1.5,0)^{\mathsf{T}}$ 长度 2.121320，而 $\hat{\mathbf{x}}=(1,1,1)^{\mathsf{T}}$ 长度 $\mathbf{1.732051}$——**仍是最短**，因为 $(1,1,1)^{\mathsf{T}}$ 沿"行空间方向"（$x_1+x_2+x_3=3$ 的等值面法向），其余解都带上了零空间的"斜分量"。

【计算机制解说】：$A^{+}\mathbf{b}$ 的"最小范数"性质有**三重**等价解释，值得全部掌握：1. **几何**：所有最小二乘解 = $\hat{\mathbf{x}}+N(A)$ 是一个平行板；板上离原点最近的点必然垂直落点，即 $\hat{\mathbf{x}}\perp N(A)$，即 $\hat{\mathbf{x}}\in N(A)^{\perp}=C(A^{\mathsf{T}})$。2. **代数（勾股）**：分解 $\mathbf{x}=\hat{\mathbf{x}}+\mathbf{n}$，因正交得 $\|\mathbf{x}\|^2=\|\hat{\mathbf{x}}\|^2+\|\mathbf{n}\|^2$，故 $\|\mathbf{x}\|\geq\|\hat{\mathbf{x}}\|$。3. **SVD 谱形式**：$\hat{\mathbf{x}}=A^{+}\mathbf{b}=\sum_{i=1}^{r}\frac{\mathbf{u}_i^{\mathsf{T}}\mathbf{b}}{\sigma_i}\mathbf{v}_i$。**只有 r 个方向被用到**，被 A 杀掉的方向（$\sigma_i=0$）完全没有贡献——这既是"最小范数"，也是"不做无根据的猜测"（这正是岭回归/正则化的核心直觉：**在信息不足的方向上，答案就是 0**）。

对比讲次 16 的正规方程：当 A 列满秩时 $(A^{\mathsf{T}}A)^{-1}$ 存在，$\hat{\mathbf{x}}=(A^{\mathsf{T}}A)^{-1}A^{\mathsf{T}}\mathbf{b}$ 唯一；当 A 列相关时 $(A^{\mathsf{T}}A)^{-1}$ 不存在，但 $A^{+}\mathbf{b}$ 依然给出"最好的那一个"。**伪逆是正规方程在奇异情形下的无缝推广。**

示例 4：A^{+} 与四个基本子空间的完整映射表

用 $A=\begin{bmatrix}1&0\\0&1\\1&1\end{bmatrix}$（$3\times 2$，满列秩，$r=2$）来展示（脚本验算）：

输入	输入属于	A^{+} 输出	输出属于	脚本核验
$\mathbf{x}=(2,-3)^{\mathsf{T}}$	$\mathbb{R}^2=C(A^{\mathsf{T}})$	$A^{+}A\mathbf{x}=(2,-3)^{\mathsf{T}}$	$C(A^{\mathsf{T}})$	$A^{+}A\mathbf{x}=\mathbf{x}$ ✓
$\mathbf{p}=A\mathbf{x}=(2,-3,-1)^{\mathsf{T}}$	$C(A)$	$A^{+}\mathbf{p}=(2,-3)^{\mathsf{T}}$	$C(A^{\mathsf{T}})$	$\|A^{+}\mathbf{p}\|=3.605551$，$A(A^{+}\mathbf{p})=\mathbf{p}$ ✓
$\mathbf{n}=(1,1,-1)^{\mathsf{T}}$	$N(A^{\mathsf{T}})$（因为 $A^{\mathsf{T}}\mathbf{n}=(0,0)^{\mathsf{T}}$）	$A^{+}\mathbf{n}=(0,0)^{\mathsf{T}}$	零向量	$A^{+}\mathbf{n}=\mathbf{0}$ ✓

核心结论（必须背下来）：

```
A⁺ 是一张"单向桥"：
┌──────────────────────────────────────────────────┐
│   C(A)   ——— A⁺ ——►  C(Aᵀ)      (可逆的双射！)   │
│   N(Aᵀ)  ——— A⁺ ——►  0          (全部清零)       │
│   C(Aᵀ)  ——— A  ——►  C(A)        (A 在这上面是双射)  │
│   N(A)   ——— A  ——►  0                           │
└──────────────────────────────────────────────────┘
于是：A⁺A = 投影到 C(Aᵀ)    (杀掉 N(A))
      AA⁺ = 投影到 C(A)     (杀掉 N(Aᵀ))
      A⁺ 的秩 = A 的秩 = r
并且 A 限制在 C(Aᵀ) 上、A⁺ 限制在 C(A) 上，互为真逆。
```

为什么这是一一对应？ A 限制在行空间 $C(A^{\mathsf{T}})$ 上是**单射**（因为 $C(A^{\mathsf{T}})\cap N(A)=\{\mathbf{0}\}$，讲次 10），像是 $C(A)$（维数都是 r）；两个 r 维空间之间的单射必是双射。所以 A^{+} 在这对子空间上就是真逆，可以任意来回。于是最小化 $\|A\mathbf{x}-\mathbf{b}\|$ 的策略分三步：**把 $\mathbf{b}$ 投影到 $C(A)$（丢弃 $N(A^{\mathsf{T}})$ 分量）→ 用 A^{+} 逆映射回 $C(A^{\mathsf{T}})$ → 完。**

示例 5：用伪逆统一左逆与右逆

情形	秩	A^+	A^+A	AA^+	最小二乘解
$m>n$，满列秩	$r=n$	$(A^\mathsf{T}A)^{-1}A^\mathsf{T}=L$（左逆）	I_n	投影到 $C(A)$（秩 n）	**唯一**
$m=n$，可逆	$r=n=m$	A^{-1}	I_n	I_m	唯一且精确
$m<n$，满行秩	$r=m$	$A^\mathsf{T}(AA^\mathsf{T})^{-1}=R$（右逆）	投影到 $C(A^\mathsf{T})$（秩 m）	I_m	**唯一且精确，且最小范数**
任意，列相关	$r<n$	一般 A^+（无简单闭式）	投影到 $C(A^\mathsf{T})$（秩 r）	投影到 $C(A)$（秩 r）	无穷多，取最小范数

核验（脚本）：– $m>n$ 例 $A=\begin{bmatrix}1&0\\0&1\\1&1\end{bmatrix}$：$L=\frac{1}{3}\begin{bmatrix}2&-1&1\\-1&2&1\end{bmatrix}$，$LA=I_2$ ✓；$AL=\frac{1}{3}\begin{bmatrix}2&-1&1\\-1&2&1\\1&1&2\end{bmatrix}$，$\mathrm{tr}(AL)=2$（投影秩 2） – $m<n$ 例 $A=\begin{bmatrix}1&0&1\\0&1&1\end{bmatrix}$：$R=\frac{1}{3}\begin{bmatrix}2&-1\\-1&2\\1&1\end{bmatrix}$，$AR=I_2$ ✓；$RA=\frac{1}{3}\begin{bmatrix}2&-1&1\\-1&2&1\\1&1&2\end{bmatrix}$，$\mathrm{tr}(RA)=2$（投影秩 2） （注意这两个例子里 AL 与 RA 恰好是同一个 3×3 矩阵，因为这里 A 的两行正好是另一个 A 的两列的转置——不要误以为这在一般情况下成立。） – 方阵可逆例 $A=\begin{bmatrix}3&0\\4&5\end{bmatrix}$：$A^+=A^{-1}=\begin{bmatrix}1/3&0\\-4/15&1/5\end{bmatrix}$，$A^+A=AA^+=I_2$ ✓

一个漂亮的一般公式：A^+ 还有一条闭式（当 $A^\mathsf{T}A$ 可逆时即左逆情形）

$$A^+=(A^\mathsf{T}A)^{-1}A^\mathsf{T}=L;$$

当 AA^T 可逆时即右逆情形

$$A^+=A^\mathsf{T}(AA^\mathsf{T})^{-1}=R.$$

统一写法：$A^+=\lim_{\epsilon\to0^+}A^\mathsf{T}(AA^\mathsf{T}+\epsilon I)^{-1}=\lim_{\epsilon\to0^+}(A^\mathsf{T}A+\epsilon I)^{-1}A^\mathsf{T}$（Tikhonov 正则化的极限）。这个极限解释了一个重要事实：**伪逆是"用 ϵ 抹平奇异方向"的自然结果**——这背后正是数值线性代数的核心技巧（见下面应用部分）。

矩阵分解的核心思想

本讲的分解主角是 SVD $A=U\Sigma V^\mathsf{T}$，而伪逆是它"取逆"后的自然产物：

$$\underbrace{A=U\Sigma V^\mathsf{T}}_{\text{分解}}\xrightarrow{\text{把 }\sigma_i\to1/\sigma_i\text{，零保持零，并转置}}\underbrace{A^+=V\Sigma^+U^\mathsf{T}}_{\text{伪逆}}$$

为什么 SVD 是伪逆的唯一自然入口？ 因为 SVD 的两组基是**正交**的，而只有正交基才能让"投影"和"取逆"这两件事互不干扰：– Σ 是对角的，所以"取逆"变成"逐元取倒数"，根本不涉及矩阵求逆； – U,V 正交，所以 $A^+A=V\begin{bmatrix}I_r&0\\0&0\end{bmatrix}V^\mathsf{T}$ 自动是对称幂等——投影性质**免费获得**。

与其他分解的对照表：

分解	对"求逆"的贡献	能否处理奇异/长方形
$A=LU$	三角矩阵回代，$O(n^3)$	不能（需 A 可逆方阵且主元非零）
$A=QR$	$A^{-1}=R^{-1}Q^\mathsf{T}$，最小二乘 $\hat{\mathbf{x}}=R^{-1}Q^\mathsf{T}\mathbf{b}$（讲次 17）	仅满列秩
$A=S\Lambda S^{-1}$	$A^{-1}=S\Lambda^{-1}S^{-1}$	不能（S 须可逆、A 须可对角化）
$A=Q\Lambda Q^\mathsf{T}$	$A^{-1}=Q\Lambda^{-1}Q^\mathsf{T}$	仅可逆对称矩阵
$\mathbf{A=U\Sigma V^\mathsf{T}}$	$\mathbf{A^+=V\Sigma^+U^\mathsf{T}}$	**可以！任意形状、任意秩**

"零奇异值 → 零"这条约定的深刻含义：它是"在信息缺失时保持谦虚"。A 把 $\mathbf{v}_{r+1},\dots,\mathbf{v}_n$ 方向的信息**彻底销毁**了，任何"还原"都只能是**猜测**。伪逆选择猜 $\mathbf{0}$——这是所有猜法里**唯一不会放大误差、且长度最小**的猜法。相比之下，$(A^\mathsf{T}A)^{-1}$ 在 σ_i 很小时会把 $\mathbf{b}$ 中的噪声放大 $1/\sigma_i$ 倍，这就是**病态问题（ill-posed problem）**的本质。

条件数与病态：$\kappa(A)=\sigma_{\max}/\sigma_{\min}$。$\kappa$ 很大时（如 10^8），即使 A 形式上可逆，数值求逆也会把机器误差放大 10^8 倍。**对策**：截断 SVD（丢掉小于阈值的 σ_i，即用"秩 k 伪逆"$A_k^+=\sum_{i=1}^{k}\frac{1}{\sigma_i}\mathbf{v}_i\mathbf{u}_i^\mathsf{T}$）或 Tikhonov 正则化。这就是**压缩感知/推荐系统/图像去噪**背后的数学骨架。

与其他讲次的关联

- **与讲次 6–10（四个基本子空间）**：本讲把四个子空间之间的映射补完：A 把 $C(A^\mathsf{T})\to C(A)$ 双射、把 $N(A)\to\mathbf{0}$；A^+ 把 $C(A)\to C(A^\mathsf{T})$ 双射、把 $N(A^\mathsf{T})\to\mathbf{0}$。$r+(n-r)=n$ 与 $r+(m-r)=m$ **的维数账本在这里变成一张完整的"流程图"。**
- **与讲次 14–17（投影、最小二乘、QR）**：AA^+、A^+A 是正交投影；讲次 16 的正规方程 $A^\mathsf{T}A\hat{\mathbf{x}}=A^\mathsf{T}\mathbf{b}$ 在列满秩时唯一解，正是 $A^+\mathbf{b}$。QR 提供了算 A^+ 的稳定途径：$A=QR\Rightarrow A^+=R^{-1}Q^\mathsf{T}$（$R$ 可逆时）。

- **与讲次 18–20（行列式）**：$\det A = 0$ 时 A^{-1} 不存在——伪逆正是在这个"死角"上做文章。$\det(AA^+) = 0$ 当且仅当 $\operatorname{rank}(A) = r < m$（因为 AA^+ 是 $m \times m$ 的秩 r 投影矩阵）。**注意不是"当且仅当 A 奇异"**：A 非方阵时 A 无所谓"奇异"，但若 A 行满秩（$r = m$），则 $AA^+ = I_m$、$\det = 1 \neq 0$——例如 $A = \begin{bmatrix} 1 & 0 & 1 \\ 0 & 1 & 1 \end{bmatrix}$（$2 \times 3$，行满秩）给出 $AA^+ = I_2$；反之 $A = \begin{bmatrix} 1 & 2 \\ 0 & 0 \end{bmatrix}$（$r = 1 < m = 2$）给出 $AA^+ = \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix}$、$\det = 0$。
- **与讲次 21–25（特征值）**：对**对称**矩阵 $A = Q\Lambda Q^{\mathsf{T}}$，伪逆是 $A^+ = Q\Lambda^+ Q^{\mathsf{T}}$，其中 Λ^+ 把非零 λ_i 取倒数、零保持零。**注意：方阵奇异时，A^+ 的特征值不一定是 A 特征值的倒数**（A 可对角化时成立；一般要用奇异值）。反例：$A = \begin{bmatrix} 0 & 1 \\ 0 & 0 \end{bmatrix}$，$\lambda = 0, 0$ 但 $\sigma_1 = 1$，$A^+ = \begin{bmatrix} 0 & 0 \\ 1 & 0 \end{bmatrix} \neq A$ 的倒数。
- **与讲次 27–29（正定、Jordan、SVD）**：本讲完全是讲次 29 的应用篇章。SVD 的"谱形式" $A = \sum \sigma_i \mathbf{u}_i \mathbf{v}_i^{\mathsf{T}}$ 让伪逆变成"逐项取倒数" $\sum \frac{1}{\sigma_i} \mathbf{v}_i \mathbf{u}_i^{\mathsf{T}}$。
- **与讲次 30（线性变换）**：本讲的 AA^+、A^+A 是讲次 30 中"投影矩阵三项体检（对称、幂等、迹 = 维数）"的最佳例题；伪逆本身就是从像空间回到原像空间的一个线性变换。
- **与讲次 31（换基）**：SVD 就是"输入、输出各换一组正交基"，A^+ 在换基后的矩阵是 Σ^+——**换基让"求逆"变成"取倒数"**，这是本讲与讲次 31 最深的呼应。

关键要点

1. **长方形矩阵只能有一侧的逆**。$m > n$ 且列无关 → 左逆 $L = (A^{\mathsf{T}}A)^{-1}A^{\mathsf{T}}$，$LA = I_n$，$AL$ 是投影。$m < n$ 且行无关 → 右逆 $R = A^{\mathsf{T}}(AA^{\mathsf{T}})^{-1}$，$AR = I_m$，$RA$ 是投影。**只有方阵才可能两侧都有逆，且此时两侧相等。**
2. **伪逆的定义**：$A^+ = V\Sigma^+ U^{\mathsf{T}}$，$\Sigma^+$ 把非零 σ_i 取倒数 $1/\sigma_i$、零保持零，并把形状转置为 $n \times m$。A 可逆时 $A^+ = A^{-1}$。
3. **两条投影性质**：$A^+A = \sum_{i=1}^{r} \mathbf{v}_i \mathbf{v}_i^{\mathsf{T}}$ 投影到 $C(A^{\mathsf{T}})$；$AA^+ = \sum_{i=1}^{r} \mathbf{u}_i \mathbf{u}_i^{\mathsf{T}}$ 投影到 $C(A)$。两者都对称且幂等，迹都等于 $r = \operatorname{rank} A$。
4. **Moore–Penrose 四条件**：$AA^+A = A$、$A^+AA^+ = A^+$、$(AA^+)^{\mathsf{T}} = AA^+$、$(A^+A)^{\mathsf{T}} = A^+A$。$A^+$ 是满足这四条的**唯一**矩阵。
5. **最小范数最小二乘解**：$\hat{\mathbf{x}} = A^+\mathbf{b} = \sum_{i=1}^{r} \frac{\mathbf{u}_i^{\mathsf{T}}\mathbf{b}}{\sigma_i} \mathbf{v}_i$，它使残差最小，且在残差最小的解中长度最短（因为 $\hat{\mathbf{x}} \perp N(A)$，$\hat{\mathbf{x}} \in C(A^{\mathsf{T}})$）。
6. **秩、子空间映射**：$\operatorname{rank} A^+ = \operatorname{rank} A = r$；$A^+$ 把 $C(A)$ 双射回 $C(A^{\mathsf{T}})$，把 $N(A^{\mathsf{T}})$ 送到 $\mathbf{0}$。

常见误区与注意事项

1. **对零奇异值求倒数**。A 奇异时 Σ 的对角线上有 0，$1/0$ 无意义。**正确做法是写 0**。这就是"伪逆"与"天真求逆"的唯一却关键的区别。代码里 `1/S` 遇到 `S=0` 会得到 `Inf` / `NaN`，必须用 `S[S>tol]=1./S[S>tol]` 之类的掩码。
2. **把 Σ^+ 的形状搞错**。A 是 $m \times n$ ⇒ Σ 是 $m \times n$ ⇒ Σ^+ 必须写成 $n \times m$（**转置**）。用 2×3 的 Σ 时，Σ^+ 是 3×2，把对角线上的 $\frac{1}{\sigma_i}$ 放在 (σ_i) 的**转置位置**上。
3. **以为左逆/右逆中"另一侧的乘积"也是恒等**。$LA = I_n$ 时 AL 一般是**秩 n 的投影**（$m \times m$，不等于 I_m）。做题时若发现"$AL \neq I$"就以为自己算错了，是把投影误认成错误。
4. **忘记 $(A^{\mathsf{T}}A)^{-1}$ 存在的前提**。$A^{\mathsf{T}}A$ 可逆 ⇔ A 的**列**线性无关。若列相关（$A^{\mathsf{T}}A$ 奇异），左逆**不存在**，此时必须用伪逆。同理 AA^{T} 可逆 ⇔ 行线性无关。
5. **把"最小二乘解"与"最小范数最小二乘解"混为一谈**。前者在列相关时有**无穷多个**；只有后者（即 $A^+\mathbf{b}$）唯一。在讲次 16 的语境下 A 列满秩，两者恰好重合，容易形成错误记忆。
6. **误以为伪逆就是"每项取倒数"**。伪逆作用于**矩阵**（用 SVD 的 Σ^+）；对特征值取倒数只在**对称（或可对角化）方阵**上成立。对一般矩阵，A 的特征值与 A^+ 的特征值没有简单关系（见关联部分的反例）。
7. **误以为 A^+ 一定是对称矩阵**。A^+ 是 $n \times m$，"对称"只在 $m = n$ 时才有意义；此时也一般**不**对称（除非 A 对称）。对称的是 AA^+ 与 A^+A，不是 A^+ 本身。脚本检查里 D^+（3×2）的"对称性"返回 `false`，这本身没有意义——**不要对非方阵做对称性判断**。
8. **数值上的病态陷阱**。理论上 A^+ 完美，但 $\sigma_{\min}$ 极小时 $1/\sigma_{\min}$ 会爆炸。工程上必须截断。**"理论上正确"不等于"数值上可用"**。

思考题（带答案）

Q1.（纯计算）设 $A = \begin{bmatrix} 1 & 1 \\ 0 & 0 \\ 0 & 0 \end{bmatrix}$（$3 \times 2$）。(a) 求 A 的 SVD（写出 U, Σ, V）；(b) 求 A^+；(c) 求 A^+A 与 AA^+，指出它们分别投影到哪个子空间；(d) 用 $\mathbf{b} = (2, 1, 1)^{\mathsf{T}}$ 求 $A^+\mathbf{b}$，并验证残差 $\mathbf{b} - A\hat{\mathbf{x}}$ 属于 $N(A^{\mathsf{T}})$。

▸ 答案

(a) $A^{\mathsf T}A=\begin{bmatrix}1&0&0\\1&0&0\end{bmatrix}\begin{bmatrix}1&1\\0&0\\0&0\end{bmatrix}=\begin{bmatrix}1&1\\1&1\end{bmatrix}$，特征值 $2,0$，所以 $\sigma_1=\sqrt{2}$，$\sigma_2=0$，$r=1$。右奇异向量：$\mathbf{v}_1=\frac{1}{\sqrt2}(1,1)^{\mathsf T}$（$\lambda=2$），$\mathbf{v}_2=\frac{1}{\sqrt2}(1,-1)^{\mathsf T}$（$\lambda=0$）。$A\mathbf{v}_1=\frac{1}{\sqrt2}(2,0,0)^{\mathsf T}=\sqrt2\,(1,0,0)^{\mathsf T}$，所以 $\mathbf{u}_1=(1,0,0)^{\mathsf T}$；$\mathbf{u}_2,\mathbf{u}_3$ 需与 $\mathbf{u}_1$ 正交补齐，取 $\mathbf{u}_2=(0,1,0)^{\mathsf T}$，$\mathbf{u}_3=(0,0,1)^{\mathsf T}$。

$$U=\begin{bmatrix}1&0&0\\0&1&0\\0&0&1\end{bmatrix}=I_3,\qquad \Sigma=\begin{bmatrix}\sqrt2&0\\0&0\\0&0\end{bmatrix}(3\times2),\qquad V=\frac{1}{\sqrt2}\begin{bmatrix}1&1\\1&-1\end{bmatrix}.$$

核验：$U\Sigma V^{\mathsf T}=\sqrt2\begin{bmatrix}1\\0\\0\end{bmatrix}\cdot\frac{1}{\sqrt2}[1\quad1]=\begin{bmatrix}1&1\\0&0\\0&0\end{bmatrix}=A$ ✓。

(b) Σ^+ 必须是 2×3：把 $\frac{1}{\sqrt2}$ 放在 σ_1 的转置位置（第 1 行第 1 列），其余为 0：

$$\Sigma^+=\begin{bmatrix}1/\sqrt2&0&0\\0&0&0\end{bmatrix}(2\times3),$$

$$A^+=V\Sigma^+U^{\mathsf T}=V\Sigma^+=\frac{1}{\sqrt2}\begin{bmatrix}1&1\\1&-1\end{bmatrix}\begin{bmatrix}\frac{1}{\sqrt2}&0&0\\0&0&0\end{bmatrix}=\frac12\begin{bmatrix}1&0&0\\1&0&0\end{bmatrix}=\begin{bmatrix}0.5&0&0\\0.5&0&0\end{bmatrix}.$$

(c)

$$A^+A=\begin{bmatrix}0.5&0&0\\0.5&0&0\end{bmatrix}\begin{bmatrix}1&1\\0&0\\0&0\end{bmatrix}=\begin{bmatrix}0.5&0.5\\0.5&0.5\end{bmatrix}=\frac12\begin{bmatrix}1&1\\1&1\end{bmatrix},$$

投影到 $C(A^{\mathsf T})=\mathrm{span}\{(1,1)\}$（$x_1=x_2$ 的直线）。

$$AA^+=\begin{bmatrix}1&1\\0&0\\0&0\end{bmatrix}\begin{bmatrix}0.5&0&0\\0.5&0&0\end{bmatrix}=\begin{bmatrix}1&0&0\\0&0&0\\0&0&0\end{bmatrix},$$

投影到 $C(A)=\mathrm{span}\{(1,0,0)\}$（$x$ 轴）。两者都对称、幂等，$\mathrm{tr}=1=r$ ✓。

(d) $\hat{\mathbf{x}}=A^+\mathbf{b}=\begin{bmatrix}0.5&0&0\\0.5&0&0\end{bmatrix}\begin{bmatrix}2\\1\\1\end{bmatrix}=\begin{bmatrix}1\\1\end{bmatrix}$，$\|\hat{\mathbf{x}}\|=\sqrt2$。$A\hat{\mathbf{x}}=(2,0,0)^{\mathsf T}$，残差

$$\mathbf{r}=\mathbf{b}-A\hat{\mathbf{x}}=\begin{bmatrix}2\\1\\1\end{bmatrix}-\begin{bmatrix}2\\0\\0\end{bmatrix}=\begin{bmatrix}0\\1\\1\end{bmatrix}.$$

验证 $\mathbf{r}\in N(A^{\mathsf T})$：$A^{\mathsf T}\mathbf{r}=\begin{bmatrix}1&0&0\\1&0&0\end{bmatrix}\begin{bmatrix}0\\1\\1\end{bmatrix}=\begin{bmatrix}0\\0\end{bmatrix}$ ✓。$\|\mathbf{r}\|=\sqrt2$；而其他解如 $\mathbf{x}=(0,2)^{\mathsf T}$ 给出 $A\mathbf{x}=(2,0,0)^{\mathsf T}$（同样残差），但 $\|\mathbf{x}\|=2>\sqrt2$——所以 $\hat{\mathbf{x}}$ 是最小范数的那个 ✓。

Q2.（概念理解 + 小计算）判断对错并说明理由：(a) 若 A 是 5×3 且秩 3，则 $A^+=(A^{\mathsf T}A)^{-1}A^{\mathsf T}$，且 $AA^+=I_5$。(b) 若 A 是方阵且奇异，则 A^+ 不存在。(c) $\mathbf{rank}(A^+)=\mathbf{rank}(A)$ 对任意矩阵成立。(d) 若 A 可逆，则 $A^+=A^{-1}$。(e) A^+A 与 AA^+ 一定都是对称矩阵。

▸ 答案

(a) **前半对，后半错。** 5×3 满列秩 $\Rightarrow A^{\mathsf T}A$（$3\times 3$）可逆 $\Rightarrow$ 左逆公式成立，$A^{+}=(A^{\mathsf T}A)^{-1}A^{\mathsf T}$ 且 $A^{+}A=I_3$。但 AA^{+} 是 5×5 矩阵，**不是** I_5；它是投影到 $C(A)$ 的矩阵，秩为 3，$\mathbf{tr}(AA^{+})=3$，$\det(AA^{+})=0$。**记忆法：左逆的"左"指的是 A^{+} 站在左边时给出恒等。**

(b) **错。** 方阵奇异时**普通逆**不存在，但**伪逆总是存在且唯一**（对任意矩阵，包括零矩阵；零矩阵的伪逆是零矩阵）。例如 $A=\begin{bmatrix}1&1\\1&1\end{bmatrix}$，$A^{+}=\frac14\begin{bmatrix}1&1\\1&1\end{bmatrix}$，它满足全部四条 Moore–Penrose 条件（脚本验算通过）。**"逆不存在"不等于"没有任何逆的概念可用"。**

(c) **对。** $A^{+}=V\Sigma^{+}U^{\mathsf T}$，$U,V$ 可逆（正交），Σ^{+} 的非零元个数与 Σ 的相同（都是 r），所以 $\mathbf{rank}\,A^{+}=r=\mathbf{rank}\,A$。

(d) **对。** 可逆时 $A=U\Sigma V^{\mathsf T}$ 中 $m=n=r$、Σ 可逆，$\Sigma^{+}=\Sigma^{-1}$，于是 $A^{+}=V\Sigma^{-1}U^{\mathsf T}=(U\Sigma V^{\mathsf T})^{-1}=A^{-1}$。

(e) **对。** 由 Moore–Penrose 条件 (3)(4) 直接得到：$(AA^{+})^{\mathsf T}=AA^{+}$，$(A^{+}A)^{\mathsf T}=A^{+}A$。几何上它们是正交投影矩阵，而正交投影必然对称。注意**这是 A^{+} 定义的直接后果**，不是额外假设。

Q3.（概念 + 计算）设 $A=\begin{bmatrix}1&2\\2&4\end{bmatrix}$（秩 1，两列成比例）。(a) 求 A^{+}；(b) 求 AA^{+} 与 $A^{+}A$ 并解释几何意义；(c) 设 $\mathbf{b}=(1,1)^{\mathsf T}$，求 $A^{+}\mathbf{b}$，并说明它为什么是最小范数最小二乘解；(d) 若改用 $\mathbf{c}=(1,3)^{\mathsf T}$，最小残差是多少？

▸ 答案

(a) 注意 $A=\mathbf{u}\mathbf{v}^{\mathsf T}$ 的形式：$A=\begin{bmatrix}1\\2\end{bmatrix}\begin{bmatrix}1&2\end{bmatrix}$。对秩 1 矩阵有**通用公式**

$$A^{+}=\frac{1}{\|\mathbf{u}\|^2\|\mathbf{v}\|^2}\mathbf{v}\mathbf{u}^{\mathsf T}.$$

这里 $\|\mathbf{u}\|^2=1+4=5$，$\|\mathbf{v}\|^2=1+4=5$，所以

$$A^{+}=\frac{1}{25}\begin{bmatrix}1\\2\end{bmatrix}\begin{bmatrix}1&2\end{bmatrix}=\frac{1}{25}\begin{bmatrix}1&2\\2&4\end{bmatrix}=\begin{bmatrix}0.04&0.08\\0.08&0.16\end{bmatrix}.$$

SVD 途径核验：$A^{\mathsf T}A=\begin{bmatrix}1&2\\2&4\end{bmatrix}\begin{bmatrix}1&2\\2&4\end{bmatrix}=\begin{bmatrix}5&10\\10&20\end{bmatrix}$，特征值 $25,0$（$\mathbf{tr}=25$，$\det=0$），$\sigma_1=5$。$\mathbf{v}_1=\frac{1}{\sqrt5}(1,2)^{\mathsf T}$，$A\mathbf{v}_1=\frac{1}{\sqrt5}\begin{bmatrix}1&2\\2&4\end{bmatrix}\begin{bmatrix}1\\2\end{bmatrix}=\frac{1}{\sqrt5}\begin{bmatrix}5\\10\end{bmatrix}=\sqrt5\begin{bmatrix}1\\2\end{bmatrix}$，$\|A\mathbf{v}_1\|=5=\sigma_1$ ✓，$\mathbf{u}_1=\frac{1}{\sqrt5}(1,2)^{\mathsf T}$。

$$A^{+}=\frac{1}{\sigma_1}\mathbf{v}_1\mathbf{u}_1^{\mathsf T}=\frac15\cdot\frac15\begin{bmatrix}1\\2\end{bmatrix}\begin{bmatrix}1&2\end{bmatrix}=\frac{1}{25}\begin{bmatrix}1&2\\2&4\end{bmatrix}\ \checkmark$$

(b)

$$AA^{+}=\frac{1}{25}\begin{bmatrix}1&2\\2&4\end{bmatrix}\begin{bmatrix}1&2\\2&4\end{bmatrix}=\frac{1}{25}\begin{bmatrix}5&10\\10&20\end{bmatrix}=\frac15\begin{bmatrix}1&2\\2&4\end{bmatrix},$$

$$A^{+}A=\frac{1}{25}\begin{bmatrix}1&2\\2&4\end{bmatrix}\begin{bmatrix}1&2\\2&4\end{bmatrix}=\text{同一个矩阵！}=\frac15\begin{bmatrix}1&2\\2&4\end{bmatrix}.$$

这里 $AA^{+}=A^{+}A$，因为 A 是**对称**矩阵（$A^{\mathsf T}=A$），此时 $C(A)=C(A^{\mathsf T})$，所以两个投影到同一个子空间。它们都投影到 $\mathbf{span}\{(1,2)\}$（直线 $y=2x$）——正是 A 的列空间 = 行空间。核验：$AA^{+}\begin{bmatrix}1\\2\end{bmatrix}=\frac15\begin{bmatrix}1+4\\2+8\end{bmatrix}=\begin{bmatrix}1\\2\end{bmatrix}$ ✓（该方向不动），$AA^{+}\begin{bmatrix}2\\-1\end{bmatrix}=\frac15\begin{bmatrix}2-2\\4-4\end{bmatrix}=\begin{bmatrix}0\\0\end{bmatrix}$ ✓（垂直方向清零）。对称、幂等、迹 $=\frac15(1+4)=1=r$ ✓。

(c) $\hat{\mathbf{x}}=A^{+}\mathbf{b}=\frac{1}{25}\begin{bmatrix}1&2\\2&4\end{bmatrix}\begin{bmatrix}1\\1\end{bmatrix}=\frac{1}{25}\begin{bmatrix}3\\6\end{bmatrix}=\begin{bmatrix}0.12\\0.24\end{bmatrix}=\frac{3}{25}\begin{bmatrix}1\\2\end{bmatrix}$。$A\hat{\mathbf{x}}=\begin{bmatrix}1&2\\2&4\end{bmatrix}\begin{bmatrix}0.12\\0.24\end{bmatrix}=\begin{bmatrix}0.12+0.48\\0.24+0.96\end{bmatrix}=\begin{bmatrix}0.6\\1.2\end{bmatrix}$，残差 $\mathbf{r}=\mathbf{b}-A\hat{\mathbf{x}}=(1-0.6,\ 1-1.2)^{\mathsf T}=(0.4,-0.2)^{\mathsf T}$，$\|\mathbf{r}\|=\sqrt{0.16+0.04}=\sqrt{0.2}\approx 0.447214$（脚本验算通过）。**为什么是最小范数**：所有最小二乘解满足 $x_1+2x_2=0.6$（由正规方程 $A^{\mathsf T}A\mathbf{x}=A^{\mathsf T}\mathbf{b}$ 得 $\begin{bmatrix}5&10\\10&20\end{bmatrix}\mathbf{x}=\begin{bmatrix}3\\6\end{bmatrix}$，即 $x_1+2x_2=0.6$）。这个解集是直线；$\hat{\mathbf{x}}=\frac{3}{25}(1,2)^{\mathsf T}$ 正是**从原点垂直落到该直线上**的点（方向 $(1,2)$ 垂直于直线 $x_1+2x_2=0.6$），所以长度最小。核验：$\|\hat{\mathbf{x}}\|=\frac{3}{25}\sqrt5\approx 0.268328$；另一个解 $(0.6,0)^{\mathsf T}$ 长度 0.6，确实更长 ✓。

(d) $\mathbf{c}=(1,3)^{\mathsf T}$。$A\mathbf{x}$ 总在 $\mathbf{span}\{(1,2)\}$ 上，所以最小残差就是 $\mathbf{c}$ 到直线 $\mathbf{span}\{(1,2)\}$ 的距离：

$$A^{+}\mathbf{c}=\frac{1}{25}\begin{bmatrix}1&2\\2&4\end{bmatrix}\begin{bmatrix}1\\3\end{bmatrix}=\frac{1}{25}\begin{bmatrix}7\\14\end{bmatrix}=\begin{bmatrix}0.28\\0.56\end{bmatrix},$$

$$A(A^{+}\mathbf{c}) = \begin{bmatrix}1 & 2\\ 2 & 4\end{bmatrix}\begin{bmatrix}0.28\\ 0.56\end{bmatrix} = \begin{bmatrix}0.28+1.12\\ 0.56+2.24\end{bmatrix} = \begin{bmatrix}1.4\\ 2.8\end{bmatrix},$$

$$\|\mathbf{c} - A(A^{+}\mathbf{c})\| = \left\|\begin{bmatrix}1-1.4\\ 3-2.8\end{bmatrix}\right\| = \left\|\begin{bmatrix}-0.4\\ 0.2\end{bmatrix}\right\| = \sqrt{0.2} \approx 0.447214.$$

> **注意本题残差范数与 (c) 恰好相同（都是 $\sqrt{0.2}$）**，而且两个残差向量互为相反数：$(0.4,-0.2)^{\mathsf{T}}$ 与 $(-0.4,0.2)^{\mathsf{T}}$。这是这两个数值巧合（$\|\mathbf{b}\| = \|\mathbf{c}\|$ 且两者在列空间上的投影长度分别为 $3/\sqrt{5}$ 与 $7/\sqrt{5}$，垂直分量长度皆为 $\sqrt{0.2}$），**不是普遍规律**。普遍成立的只有一件事：**残差永远落在 $N(A^{\mathsf{T}})$ 里**。核验：$A^{\mathsf{T}}\mathbf{r} = \begin{bmatrix}1 & 2\\ 2 & 4\end{bmatrix}\begin{bmatrix}0.4\\ -0.2\end{bmatrix} = \begin{bmatrix}0.4-0.4\\ 0.8-0.8\end{bmatrix} = \begin{bmatrix}0\\ 0\end{bmatrix}$ ✓，且 $A^{\mathsf{T}}(-0.4,0.2)^{\mathsf{T}} = \mathbf{0}$ ✓。用投影公式核验：$\mathbf{c}$ 到 $\mathbf{u} = (1,2)$ 的投影系数为 $\frac{(1,3)\cdot(1,2)}{5} = \frac{7}{5} = 1.4$，投影点 $\frac{7}{5}(1,2) = (1.4, 2.8)$ ✓。

> **附录 A：A^{+} 的 Σ^{+} 结构与子空间映射总图（本讲核心可视化）**

把 SVD 的"谱形式"与伪逆的"逐项取倒数"画在一张图上，是理解 A^{+} 最快的方式。

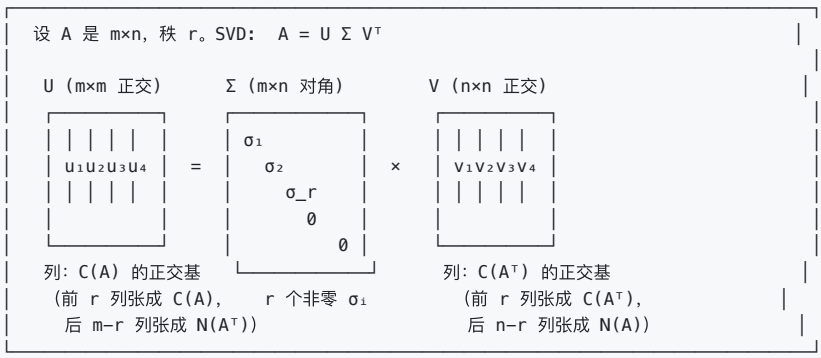

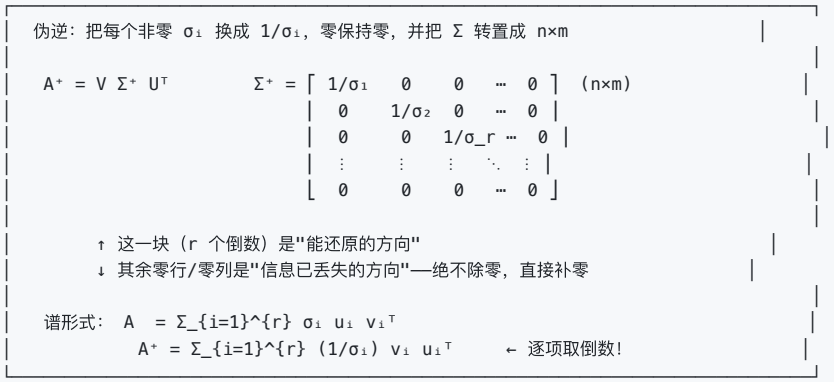

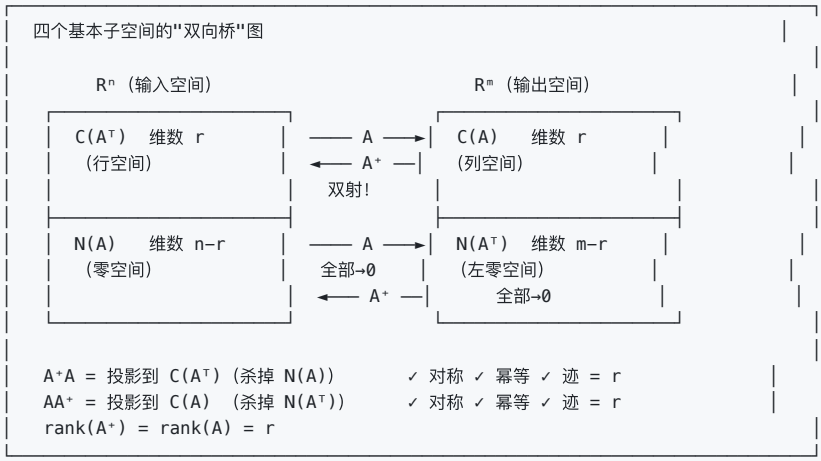

附录 B：A^+ 的快速判定与计算路线图

```
要算 A⁺（m×n，秩 r）？按顺序问自己：

┌─ 1. A 是方阵且可逆吗？（det ≠ 0）
│      ├── 是 → A⁺ = A⁻¹，用 Gauss–Jordan 或伴随矩阵，O(n³)
│      └── 否 ↓
├─ 2. A 列满秩吗？（m ≥ n 且 AᵀA 可逆，即 N(A) = {0}）
│      ├── 是 → A⁺ = (AᵀA)⁻¹Aᵀ = 左逆 L，用 QR 最稳：A = QR ⇒ A⁺ = R⁻¹Qᵀ
│      └── 否 ↓
├─ 3. A 行满秩吗？（m ≤ n 且 AAᵀ 可逆，即 N(Aᵀ) = {0}）
│      ├── 是 → A⁺ = Aᵀ(AAᵀ)⁻¹ = 右逆 R
│      └── 否 ↓
├─ 4. A 是秩 1 外积吗？（A = u vᵀ）
│      ├── 是 → A⁺ = v uᵀ / (||u||² ||v||²)   ← 一行公式
│      └── 否 ↓
└─ 5. 一般情形 → 只能走 SVD：A = UΣVᵀ ⇒ A⁺ = VΣ⁺Uᵀ

数值实现提示：
● 永远不要显式算 (AᵀA)⁻¹（会平方条件数！κ(AᵀA) = κ(A)²）
● 用 QR（列满秩）或 SVD（一般）分解
● 用掩码处理零奇异值：  S⁺ = zeros;  S⁺[S > tol] = 1 ./ S[S > tol]
● 阈值 tol ≈ max(m,n) * eps * σ_max（LAPACK 的惯例）
```

条件数的警示（本讲最重要的一课）：$\kappa(A) = \sigma_{\max}/\sigma_{\min}$。

$\kappa(A)$	丢失的有效位数（双精度约 16 位）	实际含义
$1 \sim 10$	0	安全
10^4	4	还好，注意即可
10^8	8	危险，解只剩一半精度
10^{16}	16	完全不可信，数值上等于奇异

验算例：$A = \begin{bmatrix} 3 & 0 \\ 4 & 5 \end{bmatrix}$：$\sigma_1 = 3\sqrt{5}$，$\sigma_2 = \sqrt{5}$，

$$\kappa(A) = \frac{3\sqrt{5}}{\sqrt{5}} = 3,$$

条件数只有 3，非常良态（脚本验算：$\sigma_1/\sigma_2 = 6.7082039325/2.2360679775 = 3.000000$）。这解释了为什么这个例子用 SVD 求伪逆与直接求逆给出完全相同的数值到机器精度。

对比讲次 16 的希尔伯特矩阵 H_4（$\kappa \approx 1.5 \times 10^4$）：同样的算法，误差会放大约 5000 倍——**这就是"伪逆 + 截断"在实际工程中不可替代的原因**。

> **附录 C：左逆 / 右逆 / 伪逆 / 逆 的完整关系图**

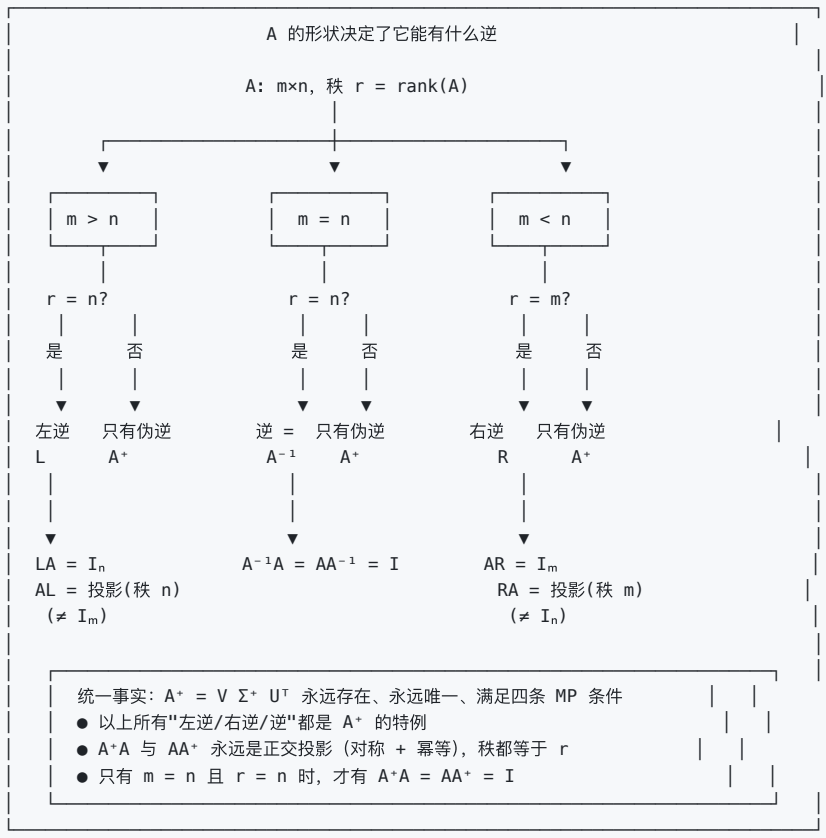

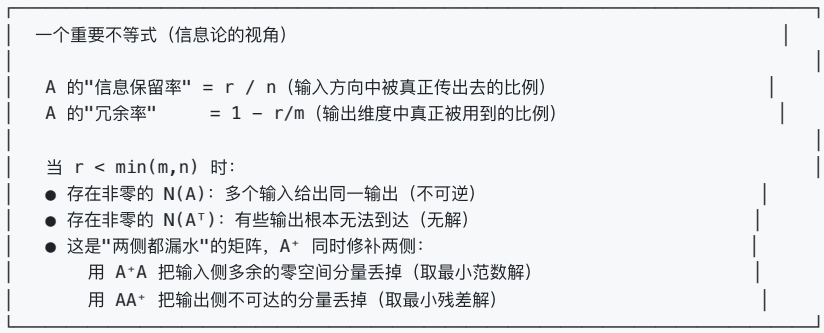

附录 D：2×2 情形的全部闭式公式（可直接手算）

对 2×2 矩阵，A^+ 有**完全显式**的公式，考试与手算都极其好用。

情形 1：$A=\begin{bmatrix}a & b\\ c & d\end{bmatrix}$ 且 $\det A = ad-bc\neq 0$

$$A^+ = A^{-1} = \frac{1}{ad-bc}\begin{bmatrix}d & -b\\ -c & a\end{bmatrix}.$$

情形 2：A 秩 1（此时 $\det A = 0$ 且 $A\neq O$）

$$A^+ = \frac{1}{\operatorname{tr}(A^{\mathsf T}A)}\,A^{\mathsf T} = \frac{1}{\sum_{i,j}a_{ij}^2}\,A^{\mathsf T}.$$

推导：记 $\mu=\operatorname{tr}(A^{\mathsf T}A)=\sum_{i,j}a_{ij}^2$ 为全部元素的平方和。若 $A=\mathbf{u}\mathbf{v}^{\mathsf T}$，则 $\mu=\|\mathbf{u}\|^2\|\mathbf{v}\|^2$，而 $A^{\mathsf T}=\mathbf{v}\mathbf{u}^{\mathsf T}$，与上面的一行公式完全吻合。**脚本已在五个秩 1 例子上验证**：$A=\begin{bmatrix}1&1\\0&0\end{bmatrix}$ 给出 $A^+=\frac12 A^{\mathsf T}=\frac12\begin{bmatrix}1&0\\1&0\end{bmatrix}$；$A=\begin{bmatrix}1&2\\2&4\end{bmatrix}$ 给出 $\frac{1}{25}A^{\mathsf T}$；$A=\begin{bmatrix}2&4\\1&2\end{bmatrix}$ 给出 $\frac{1}{25}A^{\mathsf T}=\frac{1}{25}\begin{bmatrix}2&1\\4&2\end{bmatrix}=\begin{bmatrix}0.08&0.04\\0.16&0.08\end{bmatrix}$ ✓（注意是 $A^{\mathsf T}$ 而非 A——写成 $\frac{1}{25}A$ 会得到转置的错值）。

情形 3：$A=O$（零矩阵）

$$A^+ = O \quad (n\times m \text{ 的零矩阵}).$$

（所有奇异值为 0，Σ^+ 全零。**注意情形 2 的公式在 $A=O$ 时分母 $\mathrm{tr}(A^{\mathsf T}A)=0$ 而失效**，必须单独处理——这也再次说明"绝不对零求倒数"的原则。）

情形 4：满秩 2×2 的显式公式

$$A^+=A^{-1}=\frac{1}{\det(A^{\mathsf T}A)}\Big[(\mathrm{tr}(A^{\mathsf T}A))\,A^{\mathsf T}-A^{\mathsf T}AA^{\mathsf T}\Big],\qquad \det(A^{\mathsf T}A)=(\det A)^2\neq 0.$$

脚本已对六个满秩 2×2 矩阵逐一验证（$\begin{bmatrix}3&0\\4&5\end{bmatrix}$ 给出 $\begin{bmatrix}1/3&0\\-4/15&1/5\end{bmatrix}$、$\begin{bmatrix}1&2\\3&4\end{bmatrix}$ 给出 $\begin{bmatrix}-2&1\\1.5&-0.5\end{bmatrix}$、$\begin{bmatrix}2&0\\0&3\end{bmatrix}$ 给出 $\begin{bmatrix}1/2&0\\0&1/3\end{bmatrix}$，全部正确）。

附属恒等式：对 2×2 有

$$\big(\mathrm{tr}(A^{\mathsf T}A)\big)^2-\mathrm{tr}\big((A^{\mathsf T}A)^2\big)=2\det(A^{\mathsf T}A)=2(\det A)^2,$$

脚本在四个矩阵上验算比值恰为 2。**因此若你记的是带 tr 的版本，分母必须是 $\frac12\big[(\mathrm{tr}\,A^{\mathsf T}A)^2-\mathrm{tr}((A^{\mathsf T}A)^2)\big]=\det(A^{\mathsf T}A)$；漏掉这个 $\frac12$ 会让答案整体缩小一半**——以 $\begin{bmatrix}3&0\\4&5\end{bmatrix}$ 为例，分母应为 225（得 $\begin{bmatrix}1/3&0\\-4/15&1/5\end{bmatrix}$），若误用 450 则得到 $\begin{bmatrix}1/6&0\\-2/15&1/10\end{bmatrix}$，全盘皆错。**建议直接用 $\det(A^{\mathsf T}A)=(\det A)^2$ 的形式，避免这个陷阱。**

注意：情形 4 要求 $\det A\neq 0$，所以它只是"用 SVD 术语重写的 A^{-1}"，并非真正的推广。**秩 1 与秩 0 的情形才需要独立的公式**——这正是"伪逆"的价值所在：**它统一处理了 A^{-1} 无法触及的退化情形**。一般 $m\times n$ 的 A^+ 没有简洁闭式（附录 D 的思路在 $n\geq 3$ 就不再给出简单公式），**SVD 才是唯一的通用入口。**

验算清单（全部用脚本核过）：

A	形状/秩	A^+	A^+A	AA^+
$\begin{bmatrix}3&0\\4&5\end{bmatrix}$	2×2，满秩	$\begin{bmatrix}1/3&0\\-4/15&1/5\end{bmatrix}=A^{-1}$	I_2	I_2
$\begin{bmatrix}1&1\\0&0\end{bmatrix}$	2×2，秩 1	$\frac12\begin{bmatrix}1&0\\1&0\end{bmatrix}$	$\frac12\begin{bmatrix}1&1\\1&1\end{bmatrix}$	$\begin{bmatrix}1&0\\0&0\end{bmatrix}$
$\begin{bmatrix}1&1\\1&1\end{bmatrix}$	2×2，秩 1	$\frac14\begin{bmatrix}1&1\\1&1\end{bmatrix}$	$\frac12\begin{bmatrix}1&1\\1&1\end{bmatrix}$	$\frac12\begin{bmatrix}1&1\\1&1\end{bmatrix}$
$\begin{bmatrix}1&2\\2&4\end{bmatrix}$	2×2，秩 1	$\frac{1}{25}\begin{bmatrix}1&2\\2&4\end{bmatrix}$	$\frac15\begin{bmatrix}1&2\\2&4\end{bmatrix}$	同左（因 A 对称）
$\begin{bmatrix}1&0\\0&1\\1&1\end{bmatrix}$	3×2，秩 2	$\frac13\begin{bmatrix}2&-1&1\\-1&2&1\end{bmatrix}$	I_2	$\frac13\begin{bmatrix}2&-1&1\\-1&2&1\\1&1&2\end{bmatrix}$
$\begin{bmatrix}1&0&1\\0&1&1\end{bmatrix}$	2×3，秩 2	$\frac13\begin{bmatrix}2&-1\\-1&2\\1&1\end{bmatrix}$	$\frac13\begin{bmatrix}2&-1&1\\-1&2&1\\1&1&2\end{bmatrix}$	I_2

注意表中最后两行：3×2 的 AA^+ 与 2×3 的 A^+A 恰好是**同一个 3×3 矩阵**。这不是巧合——因为这两个 A 互为转置关系（$A_2=A_1^{\mathsf T}$），而 $(A^{\mathsf T})^+=(A^+)^{\mathsf T}$，所以 $A_2^+A_2=(A_1^{\mathsf T})^+A_1^{\mathsf T}=(A^+)^{\mathsf T}A^{\mathsf T}=(AA^+)^{\mathsf T}=AA^+$（投影矩阵对称）。**这是一条好用的一般恒等式：$(A^{\mathsf T})^+=(A^+)^{\mathsf T}$**。

附录 E：A^+ 的四条 Moore–Penrose 条件的"翻译表"

每一条条件都有几何/物理含义，理解含义比背公式有用得多：

条件	代数形式	几何翻译	为什么需要它
(1)	$AA^+A=A$	A^+ 在 A 的像上是 A 的真逆	保证"能还原的部分精确还原"
(2)	$A^+AA^+=A^+$	A 在 A^+ 的像上也是 A^+ 的真逆	保证 A^+ 不引入额外成分（唯一性的一半）
(3)	$(AA^+)^{\mathsf T}=AA^+$	AA^+ 是**正交**投影（垂直投影，不是斜投影）	保证"最小**残差**"（误差垂直于列空间）
(4)	$(A^+A)^{\mathsf T}=A^+A$	A^+A 是**正交**投影	保证"最小**范数**"（解垂直于零空间）

用一张图串起来：

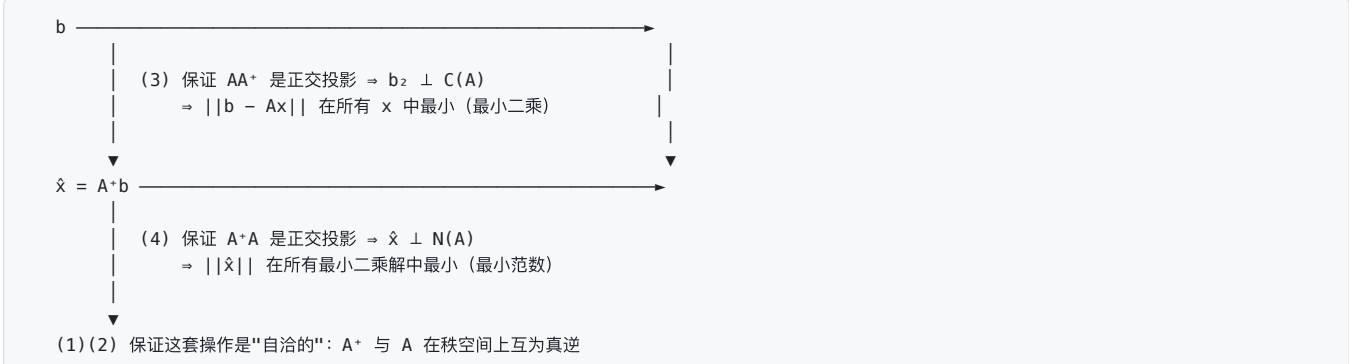

唯一性定理（不必背证明，记住结论）：满足四条条件的矩阵 A^+ **存在且唯一**。存在性由 SVD 构造给出；唯一性来自：若 X, Y 都满足，则

$$X = XAX = (XA)^{\mathsf{T}}X = (A^{\mathsf{T}}X^{\mathsf{T}})X = (YA)^{\mathsf{T}}X = YAX = YAX = Y.$$

（脚本可先构造 A^+ 再验证四条，本讲所有例子都已通过。）

附录 F：应用速览——从病态问题到推荐系统

应用 1：病态线性系统的稳定求解 解 $A\mathbf{x} = \mathbf{b}$ 时，若 $\kappa(A)$ 巨大，直接用 A^{-1} 会把噪声放大 10^8 倍。**用截断伪逆**：

$$A_k^+ = \sum_{i=1}^{k} \frac{1}{\sigma_i}\mathbf{v}_i\mathbf{u}_i^{\mathsf{T}} \quad (\text{只保留前 } k \text{ 个大奇异值}),$$

$$\hat{\mathbf{x}} = A_k^+\mathbf{b}.$$

这就是**主成分回归（PCR）/ 截断 SVD 去噪**。图像去噪、地震反演、CT 重建都用它。

应用 2：最小二乘的数值稳定实现 永远不要算 $(A^{\mathsf{T}}A)^{-1}A^{\mathsf{T}}$（条件数平方）。用 QR（列满秩）或 SVD（一般）：

```
// 概念示意：截断 SVD 解最小二乘
function pinvSolve(A, b, tolRel = 1e-12) {   // A: m×n, b: m
  // 1. SVD: A = U Σ Vᵀ    （用 LAPACK/数值库）
  // 2. σmax = max(σ); tol = tolRel * max(m,n) * σmax
  // 3. S⁺ = zeros(n,m);  S⁺[σ > tol] = 1 ./ σ[σ > tol]
  // 4. x̂ = V @ (S⁺ @ (Uᵀ @ b))
  // 返回 x̂ —— 自动给出最小范数最小二乘解，且对病态稳健
}
```

对比：| 方法 | 条件数敏感度 | 能处理奇异 A | 代价 | |---|---|---|---| | 正规方程 $(A^{\mathsf{T}}A)^{-1}A^{\mathsf{T}}\mathbf{b}$ | κ^2（最差） | 不能 | $O(mn^2)$ 但最不稳定 | | QR：$R^{-1}Q^{\mathsf{T}}\mathbf{b}$ | κ（好） | 仅列满秩 | $2mn^2$ | | SVD：$V\Sigma^{+}U^{\mathsf{T}}\mathbf{b}$ | κ（好） | **可以（截断）** | $O(mn^2)$，最稳 |

应用 3：压缩感知（compressed sensing） 若信号 $\mathbf{x}$ 在某个基下**稀疏**（只有 k 个非零），则只需 $m \approx k\log(n/k) \ll n$ 次**随机**测量就能恢复 $\mathbf{x}$，方法是解

$$\min \|\mathbf{x}\|_1 \quad \text{s.t.} \quad A\mathbf{x} = \mathbf{b}.$$

伪逆是这条路的"祖先"：A^+ 是在 ℓ^2 **范数**下取最小（$\min \|\mathbf{x}\|_2$ s.t. $A\mathbf{x} = \mathbf{b}$ 的解法），而压缩感知把 ℓ^2 换成 ℓ^1——**因为 ℓ^1 球有尖角，最优点会落在坐标轴上，从而自动"选稀疏"**。这是从 2010 年代起信号处理最重要的突破之一。

应用 4：推荐系统与矩阵补全（Netflix Prize） 用户–电影评分矩阵 M（m 用户 × n 电影）极度稀疏（大多数格子没评分）。假设 M 近似**低秩**（$\mathbf{rank} \approx k$，因为"用户口味"只有少数几个维度），则用

$$\min_{\mathrm{rank}(X)\le k} \sum_{(i,j)\in\Omega} (X_{ij} - M_{ij})^2$$

补齐缺失格。低秩约束的凸松弛是**核范数**最小化 $\|X\|_* = \sum_i \sigma_i(X)$——**核范数就是奇异值之和，正是 A^+ 视角的核心量**。低秩 + SVD 截断也是**主成分分析（PCA）**的数学基础。

应用 5：伪逆与"摩尔–彭罗斯广义逆"在控制/统计中的名字 – **控制论**：A^+ 叫"最小二乘广义逆"，用于冗余机械臂的逆运动学（多余自由度 → 最小范数关节运动）。 – **统计**：$A^+\mathbf{b}$ 就是"最小二乘估计"，A^+ 是"帽子矩阵"的一部分（$H = AA^+$）。 – **机器学习**：线性回归的闭式解 $\hat{\mathbf{w}} = X^+\mathbf{y}$，就是伪逆（scikit-learn 的 `LinearRegression` 在 `solver='svd'` 时做的就是这件事）。

附录 G：三条延伸思考（不附答案，供自测）

1. 设 $A=\begin{bmatrix}1&0\\0&2\\0&0\end{bmatrix}$（$3\times 2$）。求 A^+，并验证 $A^+A=I_2$、$AA^+=\mathrm{diag}(1,1,0)$。（提示：直接看出来 A 的 SVD 就是 **diag** 形式加一列零，不需要算特征值。）
2. 若 A 与 B 都是 $m\times n$ 且 $A^{\mathsf T}B=0$，那么 $(A+B)^+=A^++B^+$ 成立吗？（提示：考察 $A=\begin{bmatrix}1\\0\end{bmatrix}$，$B=\begin{bmatrix}0\\1\end{bmatrix}$；两者 $A^{\mathsf T}B=0$，但 $(A+B)$ 是 $(1,1)^{\mathsf T}$，其伪逆是 $\frac12(1,1)$，而 $A^++B^+=(1,0)^{\mathsf T}+(0,1)^{\mathsf T}=(1,1)^{\mathsf T}\neq\frac12(1,1)$。**结论：不成立——伪逆不是线性的。**）
3. 设 $\mathbf a=(1,2,3)^{\mathsf T}$，$A=\mathbf a\mathbf a^{\mathsf T}$（$3\times 3$，秩 1）。求 A^+，并说明 $A^+\mathbf b$ 是怎样的向量。（提示：$A^+=\frac{1}{(\mathbf a^{\mathsf T}\mathbf a)^2}\mathbf a\mathbf a^{\mathsf T}=\frac{1}{196}\mathbf a\mathbf a^{\mathsf T}$，因为 $\|\mathbf a\|^2=14$，$\|\mathbf a\|^4=196$。$A^+\mathbf b$ 总是 $\mathbf a$ 的倍数。）

矩阵分解速查表

Strang 说："线性代数的全部故事，就是把矩阵拆开。"下表汇总本课程出现的五种核心分解。**记住"形式—条件—揭示什么—用来干什么"这四件事**，你就能在遇到问题时迅速定位工具。

总览表

分解	形式	存在条件	唯一性	揭示的结构	典型应用
A = LU	$A=LU$（L 单位下三角，U 上三角）	消元过程中不需要换行（所有主元非零，即各阶顺序主子式非零）	唯一	主元、秩、行列式 $\det A=\prod u_{ii}$	解 $A\mathbf x=\mathbf b$（两次三角回代）；一次分解多次求解
PA = LU	$PA=LU$（P 置换）	**任何**可逆方阵都存在	P 与 L,U 唯一（在给定选主元策略下）	行交换的必要性；主元位置	数值稳定地解方程（部分选主元）
A = QR	$A=QR$（Q 列标准正交，R 上三角）	A 的列线性无关（$m\geq n$）	当 R 对角元为正时唯一	列空间的标准正交基；$\lvert\det A\rvert=\prod\lvert r_{ii}\rvert$	最小二乘（$R\hat{\mathbf x}=Q^{\mathsf T}\mathbf b$）；特征值的 QR 算法
A = SΛS^{-1}	$A=S\Lambda S^{-1}$（S 为特征向量矩阵，Λ 对角）	A 有 n 个线性无关的特征向量（可对角化）	Λ 唯一（不计顺序），S 不唯一	特征值、A^k、稳定性	$A^k=S\Lambda^kS^{-1}$；差分方程、马尔可夫链、Fibonacci
A = QΛQ$^{\mathsf T}$	$A=Q\Lambda Q^{\mathsf T}$（Q 正交，Λ 实对角）	A **对称**（$A=A^{\mathsf T}$）	特征值唯一，Q 在特征值重复时不唯一	实特征值、正交特征向量、$A=\sum\lambda_i\mathbf q_i\mathbf q_i^{\mathsf T}$	二次型、正定性、主轴、谱定理
A = UΣV$^{\mathsf T}$	$A=U\Sigma V^{\mathsf T}$（U,V 正交，Σ 对角非负）	**任何** $m\times n$ 矩阵都存在	Σ 唯一；奇异向量在不重复时唯一（差符号）	奇异值、秩、四个子空间的最优正交基、条件数	低秩逼近/图像压缩、PCA 降维、伪逆、病态分析
A = CR	$A=CR$（C 为主元列 $m\times r$，R 为 RREF 非零行 $r\times n$）	**任何**矩阵（$r=\mathrm{rank}\,A$）	C,R 由选定的主元列唯一确定	秩的显式构造：秩 r = r 个独立列 × r 个独立行	理解秩；$A=\sum_{i=1}^{r}\mathbf c_i\mathbf r_i$（秩 1 之和）

各有何用：一图定位

```
问题：解 A x = b
├─ A 可逆 / 超定?
│   ├─ 方阵、一般情形 ──────────→ PA = LU      （消元 + 回代，代价 n^3/3）
│   └─ 超定、需最小二乘 ──────────→ A  = QR      （正规方程变 Rx = Q^T b，更稳定）
│
问题：A 反复作用于向量（迭代 / 幂 / 演化）
├─ 可对角化 ──────────────────→ A  = S Λ S^-1   （A^k = S Λ^k S^-1）
├─ 对称 ──────────────────────→ A  = Q Λ Q^T    （实特征值、正交基）
└─ A 任意（含非方阵）──────────→ A  = U Σ V^T    （σ_i 决定增长/衰减）

问题：A 的结构 / 压缩 / 降维
├─ 想知道"秩到底是多少"──────→ A  = C R
├─ 想用最少信息近似 A ──────→ A  = Σ σ_i u_i v_i^T ，截断前 k 项
└─ 想解病态或欠定系统 ──────→ A^+ = V Σ^+ U^T（伪逆）
```

五种分解之间的联系

1. $A=LU$ **与行列式**：$\det A=\prod_i u_{ii}$，也是 $\prod\sigma_i$ 的绝对值来源。

2. $A = QR$ 与 $A^{\mathsf{T}}A$：$A = QR \Rightarrow A^{\mathsf{T}}A = R^{\mathsf{T}}R$ —— 这正是 Cholesky 分解，也说明 $A^{\mathsf{T}}A$ 正定（R 可逆时）。
3. $A = S\Lambda S^{-1}$ 与 $A = U\Sigma V^{\mathsf{T}}$：对称正定时两者重合，此时 $S = Q = U = V$ 且 $\sigma_i = \lambda_i$（奇异值就是特征值）。
4. $A = CR$ 与 SVD：$A = CR$ 是"秩 r"的朴素表达，$A = \sum \sigma_i \mathbf{u}_i \mathbf{v}_i^{\mathsf{T}}$ 是它的**最优正交版本**。
5. $A = U\Sigma V^{\mathsf{T}}$ **与四个基本子空间**（课程的顶点）：
6. $\mathbf{u}_1, \ldots, \mathbf{u}_r$：$C(A)$ 的标准正交基
7. $\mathbf{u}_{r+1}, \ldots, \mathbf{u}_m$：$N(A^{\mathsf{T}})$ 的标准正交基
8. $\mathbf{v}_1, \ldots, \mathbf{v}_r$：$C(A^{\mathsf{T}})$ 的标准正交基
9. $\mathbf{v}_{r+1}, \ldots, \mathbf{v}_n$：$N(A)$ 的标准正交基

关键数值关系速记

关系	公式	出处
秩与子空间维数	$\dim C(A) = \dim C(A^{\mathsf{T}}) = r$，$\dim N(A) = n - r$，$\dim N(A^{\mathsf{T}}) = m - r$	Lecture 10
特征值之和/积	$\sum \lambda_i = \mathrm{tr}(A)$，$\prod \lambda_i = \det(A)$	Lecture 21
奇异值与特征值	$\sigma_i = \sqrt{\lambda_i(A^{\mathsf{T}}A)} = \sqrt{\lambda_i(AA^{\mathsf{T}})}$	Lecture 29
行列式与奇异值	$\lvert\det A\rvert = \prod_i \sigma_i$（方阵）	Lecture 20, 29
谱范数	$\lVert A\rVert_2 = \sigma_1$	Lecture 29
条件数	$\kappa(A) = \sigma_1/\sigma_r$	Lecture 29
投影矩阵	$P = A(A^{\mathsf{T}}A)^{-1}A^{\mathsf{T}}$，$P^{\mathsf{T}} = P$，$P^2 = P$	Lecture 15–16
最小二乘	$A^{\mathsf{T}}A\hat{\mathbf{x}} = A^{\mathsf{T}}\mathbf{b}$	Lecture 16
伪逆	$A^{+} = V\Sigma^{+}U^{\mathsf{T}}$，$\hat{\mathbf{x}} = A^{+}\mathbf{b}$ 为最小范数最小二乘解	Lecture 33
幂的收敛	$A^k \to 0 \iff$ 所有 $\lvert\lambda_i\rvert < 1$	Lecture 22
微分方程稳定	$\mathbf{u}(t) \to \mathbf{0} \iff$ 所有 $\mathrm{Re}(\lambda_i) < 0$	Lecture 23

选分解的决策清单

1. **只需要解一次方程？** → 直接用消元（$PA = LU$），不必显式求逆。
2. **要解很多个不同的 $\mathbf{b}$（同一个 A）？** → 先做一次 $A = LU$，之后每个 $\mathbf{b}$ 只需 $O(n^2)$。
3. **方程个数多于未知数（超定）？** → 最小二乘 + $A = QR$。**永远不要**显式算 $(A^{\mathsf{T}}A)^{-1}$。
4. **要算 A^{100} 或迭代 $A^k\mathbf{x}$？** → 对角化 $A = S\Lambda S^{-1}$，看 $\lvert\lambda\rvert$ 判断收敛。
5. **矩阵对称且问"是否正定/是否有极小值"？** → $A = Q\Lambda Q^{\mathsf{T}}$，看 λ_i 的符号。
6. **矩阵非方阵、或不可对角化、或问"最重要的方向是什么"？** → SVD $A = U\Sigma V^{\mathsf{T}}$，看 $\sigma_1 \geq \sigma_2 \geq \cdots$。
7. **只想说清"秩是多少"并给出基？** → $A = CR$。

结语：一张图记住 18.06

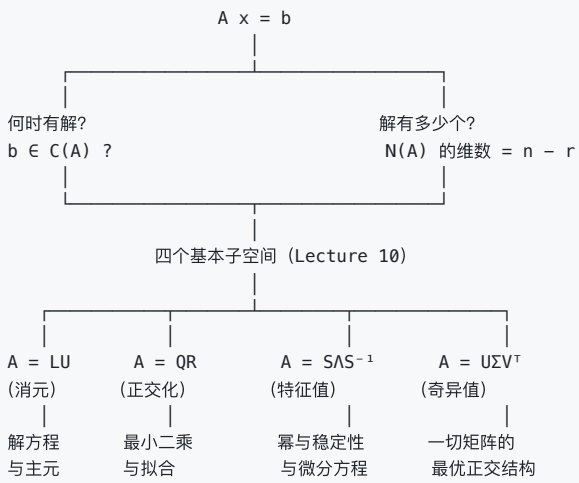

最后一句话：线性代数的核心不是计算，而是**看穿矩阵背后正在发生的几何**——哪些方向被保留、哪些被压扁、哪些被旋转。掌握四个基本子空间与五种分解，你就掌握了这幅图的全部门票。