Stanford EE364a《Convex Optimization I》学习笔记

> **课程**：Stanford EE364a *Convex Optimization I*（主页明示与 **CME364a** 为同一门课） **课程主页**：web.stanford.edu/class/ee364a **讲义页**：web.stanford.edu/class/ee364a/lectures.html **教材**：Boyd & Vandenberghe, *Convex Optimization*, Cambridge University Press, 2004；官方免费 PDF bv_cvxbook.pdf（714 页，2024-02 生成版本） **讲义全集**：bv_cvxslides.pdf（2023 年后改版，署名 Boyd / Vandenberghe / Parth Nobel） **先修（官方口径）**：线性代数（"as in EE263" 水平）+ 概率；基础 Python（课程只用 CVXPY） **考核（抓取日主页公开）**：作业 10% + 期中 25% + 期末 65%，主页注明"权重为近似值、保留调整权" **视频**：课堂录像经 CGOE 提供，**仅限选课学生**；公开替代品见第 1.8 节 **材料抓取日期**：2026-11-01（全部事实以此日抓取到的公开文本为准） **免责**：考核比例、考试范围、授课教师、教室时间**每学期都可能变**，正式选课前请以课程当学期主页为准；本笔记中标"推断"处为我基于材料的合理外推，不是官方陈述。

1.1 一句话定位
1.2 这门课训练的三件"手艺"
1.3 先修：真正需要什么
1.4 考核与课程政策（抓取日公开信息）
1.5 讲义地图（这是本笔记的骨架）
1.6 与相邻课程的关系
1.7 学习节奏（推断，非官方）
1.8 材料可得性与缺口（诚实清单）
2.1 动机：为什么先学"语言"而不是"算法"
2.2 定义：标准形式
2.3 三类问题：为什么凸性是分水岭
2.4 定理：凸问题的局部最优即全局最优
2.5 几何直觉：水平集、上境图、支撑超平面
2.6 例题：四个一维问题（讲义 4.5）
2.7 常见误区
3.1 动机：先看"能走的地方"长什么样
3.2 定义链：仿射 → 凸 → 锥
3.3 标准凸集清单（讲义 2.2）
3.4 半正定锥：本课程最重要的集合
3.5 几何直觉：为什么"凸"是可计算性的分界线
3.6 例题
3.7 常见误区
4.1 动机：怎样"造"出凸集
4.2 保凸运算总表
4.3 锥、广义不等式与对偶锥
4.4 分离与支撑超平面
4.5 例题
4.6 常见误区
5.1 动机
5.2 定义与三个等价判据
5.3 例子表（讲义 3.3–3.5）
5.4 保凸运算（讲义 3.2，本节是全课程最实用的表）
5.5 上境图与 Jensen：两个"翻译器"
5.6 例题
5.7 常见误区
6.1 动机：把"函数"变成"一族线性下界"
6.2 定义与 Fenchel 不等式
6.3 共轭函数表（必须能默写）
6.4 共轭与对偶的关系（通往第 12 章的桥）
6.5 拟凸函数（quasiconvex）
6.6 对数凸（log-concave）与对数凸密度
6.7 例题
6.8 常见误区
7.1 动机：不可微的地方恰恰最重要
7.2 定义
7.3 例子（必须熟）

7.4 最优性条件
7.5 次梯度法
7.6 次梯度与对偶：一个高频技巧
7.7 例题
7.8 常见误区
8.1 动机
8.2 定义
8.3 最优性判据（可微情形，讲义 4.11）
8.4 四种等价变换
8.5 拟凸优化与多目标（讲义 4.2.5、4.7）
8.6 例题
8.7 常见误区
9.1 动机
9.2 五个族（讲义 4.3–4.6）
9.2.1 线性规划 LP
9.2.2 二次规划 QP
9.2.3 二次约束二次规划 QCQP
9.2.4 二阶锥规划 SOCP
9.2.5 半定规划 SDP
9.2.6 几何规划 GP
9.3 层级关系图
9.4 例题
9.5 常见误区
10.1 动机
10.2 三条规则（讲义 4.43）
10.3 常用原子（CVXPY）
10.4 五个最常见的"非 DCP"与改写
10.5 CVXPY 骨架
10.6 例题
10.7 常见误区
11.1 动机
11.2 一般框架（讲义 4.40）
11.3 三种主流松弛
11.3.1 Boolean LP
11.3.2 MaxCut 的 SDP 松弛（经典）
11.4 松弛的三条使用原则
11.5 例题
11.6 常见误区
12.1 动机
12.2 构造（不要求凸！）
12.3 弱对偶与强对偶
12.4 几何解释
12.5 例题：四个必会例子（讲义 5.4–5.7）
12.6 鞍点解释
12.7 常见误区
13.1 动机
13.2 KKT 条件（讲义 5.18–5.21）
13.3 充分性与必要性
13.4 敏感性：乘子就是价格（讲义 5.23–5.25）
13.5 例题
13.6 择一定理（theorems of alternatives）
13.7 常见误区
14.1 动机
14.2 范数逼近
14.3 正则化：从 Tikhonov 到 Lasso
14.4 鲁棒逼近（讲义 6.4）
14.5 例题
14.6 常见误区
15.1 动机
15.2 MLE 的凸性判据（讲义 7.2）
15.3 假设检验（讲义 7.3）
15.4 实验设计（讲义 7.5）
15.5 例题
15.6 常见误区
16.1 动机
16.2 极值体积椭球（讲义 8.2–8.4）
16.3 中心（讲义 8.5）
16.4 分类与 SVM（讲义 8.6）
16.5 选址（讲义 8.7）
16.6 例题
16.7 常见误区
17.1 动机
17.2 三个基本假设
17.3 梯度下降与步长
17.4 最速下降（steepest descent）
17.5 牛顿法
17.6 例题

17.7 常见误区
18.1 动机
18.2 等式约束牛顿法（讲义 10.1–10.3）
18.3 对数障碍与中心路径（讲义 11.2–11.4）
18.4 障碍法（讲义 11.3）
18.5 复杂度（讲义 11.25–11.30）
18.6 Phase I：找初始可行点
18.7 广义不等式（讲义 11.6）
18.8 例题
18.9 常见误区
19.1 动机：为什么要"分而治之"
19.2 增广拉格朗日
19.3 三行迭代（scaled form）
19.4 收敛性与停止准则
19.5 ρ 的调节（实践中最重要的事）
19.6 例题：ADMM 解 Lasso
19.7 与其他方法的关系（一张图看清）
19.8 常见误区
20.1 动机
20.2 SVM：从几何到对偶
20.3 Lasso：三种解法与选择
20.4 几何规划：电路尺寸与功率控制
20.5 控制：LQR、MPC 与 LMI
20.6 电路：从 Elmore 延迟到主导时间常数
20.7 常见误区
21.1 与 18.06 线性代数：五个直接接口
21.2 与 18.100A 实分析：严谨性的来源
21.3 与 CS229：从概率模型到凸问题
21.4 与 CS336：优化器视角的对照
22.1 能力清单（能打勾才算学会）
22.2 自测题（12 题，答案在后）
22.3 答案
22.4 如果只有三天
23.1 课程与讲义
23.2 教材
23.3 扩展材料（EE364b，本笔记第 7、19 章来源）
23.4 工具与公开视频
23.5 明确不可得（不要浪费时间找）
23.6 事实与推断的边界（诚实说明）

第 1 章 课程概览与学习路线

1.1 一句话定位

EE364a 教的不是"如何调一个优化器"，而是**如何把一个工程/统计问题翻译成凸问题，并从对偶与 KKT 里读出结构**。它有三个不可分割的部分：

部分	对应讲义	你应当获得的能力
建模（Modeling）	2–4、6–8 章	判断一个问题是否凸；若不是，能否松弛成凸
理论（Theory）	2–5 章	用对偶给出下界、用 KKT 验证最优、用敏感性解释乘子
算法（Algorithms）	9–11 章	知道内点法为何是多项式时间、牛顿法为何二次收敛

主页的课程目标（Objectives）原文把这三点写成了四条：识别应用中的凸问题、掌握"对计算有用"的理论、彻底理解求解过程、具备在自己的研究里使用这些方法的能力。

1.2 这门课训练的三件"手艺"

1. **识别（recognition）**：看到 $\min \|Ax-b\|_2 + \lambda\|x\|_1$、看到 $\min \max_i (a_i^\top x - b_i)$、看到"用椭球包住一堆点"，能立刻说出它属于 LP / QP / SOCP / SDP 中的哪一类。
2. **改写（reformulation）**：同一个问题有十种写法，只有一种在数值上稳、在 DCP 规则下合法。第 9、10 章几乎全部在练这个。
3. **读解（interpretation）**：解出来只是开始。$\lambda_i^\star$ 的符号与量级告诉你哪条约束在"卡"你、放松一单位要付多少钱（第 13 章的敏感性公式 $p^\star(u) \approx p^\star - \lambda^{\star\top} u$）。

> **一个重要的事实**：这门课**不讲**次梯度演算、邻近算子、分布式优化、随机梯度。讲义最后一页（12.5）明确列出这些"未覆盖、在 EE364b 讲"的主题。本笔记第 7、19 章为补足这些缺口而写，并明确标注来源为 EE364b，不与 EE364a 的考试范围混淆。

1.3 先修：真正需要什么

你需要的	具体到什么程度	本目录对应笔记
线性代数	正定性、特征分解、SVD、四个基本子空间、Schur 补	MIT 18.06 笔记（Lecture 16/17 最小二乘、27 正定、29 SVD）

你需要的	具体到什么程度	本目录对应笔记
概率	条件分布、期望、高斯/拉普拉斯密度、大数定律级别的直觉	CS229 笔记 前四讲
多元微积分	梯度、Hessian、链式法则、Taylor 展开	MIT 18.100A 笔记 的导数章节
Python	会写函数、会用 numpy 数组	无（CVXPY 教程即可）

主页说"接触过数值计算、优化、应用领域有帮助但非必需，应用会保持简单"——这句话是真的：教材第 6–8 章的应用例子都可以用 10 行 CVXPY 复现。

1.4 考核与课程政策（抓取日公开信息）

项目	公开内容	备注
作业	每周一次，周五 23:59 截止（从第二周开始）；另有 Homework 0（含开学前的背景调查）	通过 Gradescope 提交，细节在 Ed 讨论区
迟交	每人**一天**迟交额度（Homework 0 除外）	主页原文
作业评分	每题按 $\{0, 1, 2\}$ 三档打分	主页原文
合作	允许并鼓励小组讨论，但必须自己写	主页原文
期中	第 4 周随堂；**覆盖第 1–4 章 + DCP**	主页原文
期末	线下，3 小时	具体日期见当学期主页
权重	作业 10%、期中 25%、期末 65%	主页注明"近似、可调整"
LLM 政策	**允许**在作业中使用，但"用课程没教过的记号/概念写出的解答会被严厉扣分"	主页原文

> 上面没有写"教授姓名与具体日期"，因为这两项在主页上属于"当学期"信息（授课教师、教室、考试日期每年换）。抓取日主页显示该学期由 Logan Bell 与 Nikhil Devanathan 授课、Stephen Boyd 列于页首；**下一学期未必相同**。不要把这些当成课程常量来背。

1.5 讲义地图（这是本笔记的骨架）

讲义按教材章节编号组织，共 14 个 PDF（`lectures/` 目录下的主题级 PDF，不是"每讲一个文件"）：

PDF	页数	对应教材	主题	建议投入
`intro.pdf`	19	§1	数学优化、最小二乘、LP、凸优化的历史与定位	0.5 天
`sets.pdf`	25	§2.1–2.2	凸集、锥、半正定锥	1 天
`functions.pdf`	44	§3	凸函数、保凸运算、共轭、拟凸	2 天
`problems.pdf`	68	§4	标准形式、LP/QP/SOCP/SDP、等价变换、DCP、GP、多目标	3 天
`duality.pdf`	40	§5	Lagrange 对偶、Slater、KKT、敏感性、择一定理	2.5 天
`approx.pdf`	26	§6	范数逼近、正则化、鲁棒逼近	1.5 天
`stat.pdf`	26	§7	MLE、假设检验、实验设计	1.5 天
`geom.pdf`	22	§8	椭球、中心、分类、选址	1 天
`num-lin-alg.pdf`	24	附录 B/C	flop 计数、BLAS、块消去	0.5 天
`unconstrained.pdf`	41	§9	梯度法、最速下降、牛顿法、自和谐	2 天
`equality.pdf`	27	§10	等式约束牛顿法、不可行起点	1.5 天
`barrier.pdf`	44	§11	对数障碍、中心路径、复杂度、Phase I	2 天
`circuits.pdf`	47	应用	VLSI 连线/晶体管尺寸（GP 与 SDP）	选读
`conclusions.pdf`	8	§12	总结、未覆盖主题、相关课程	0.5 天

另有 4 份专题讲义（`examples.pdf`、`stoch_prog.pdf`、`chance_constr.pdf`、`filters.pdf`）与 CVXPY 教程，属于加分材料。

> **注**：网传"EE364a 每讲一个 PDF、形如 `/lectures/lecture01.pdf`"的说法在 2026-11-01 已不成立——我逐一探测过 `lecture01..20.pdf`、`lect1..20.pdf`、`l1..20.pdf` 等命名，全部 404；`lectures/` 目录的开放索引里只有上面列出的主题级 PDF。因此本笔记按**教材章**而非"讲"来组织。

1.6 与相邻课程的关系

课程	关系	差异
EE263（线性动力系统）	官方认定的先修	EE263 给你线性代数与最小二乘的"工程手感"，EE364a 把它升级为约束优化

课程	关系	差异
CS229（机器学习）	应用侧最强互补	CS229 从概率模型推出损失；EE364a 告诉你这个损失函数凸不凸、对偶长什么样、约束怎么加
CS336（从零构建 LLM）	优化器侧的对照	CS336 关心 Adam/AdamW 这类一阶随机方法在非凸深度网络上的实际行为；EE364a 关心凸情形下的**最优性证书**与**收敛率理论**
EE364b（凸优化 II）	直接后继	次梯度、邻近/近端方法、ADMM、分布式、随机优化
CME307 / CS261 / EE364m	平行理论课	线性与锥优化、算法与复杂度、凸性数学（讲义 12.6 列出）

一句话概括：**EE263 教你算，CS229 教你为什么这样建模，EE364a 教你"这个模型能不能可靠地求解"以及"解出来的乘子在说什么"。**

1.7 学习节奏（推断，非官方）

官方没有公开逐讲进度表（讲义页只给整本 PDF）。下面的节奏是我按讲义页数与依赖关系排的**推断**建议，仅供自学安排：

- **第 1 周**：`intro` + `sets`。把"凸集 = 对凸组合封闭"变成条件反射。
- **第 2 周**：`functions`。重点是**保凸运算**与**共轭**，这两件事决定了你后面能不能读懂对偶。
- **第 3 周**：`problems` 前半（标准形式、LP/QP/SOCP/SDP）。此时开始写 CVXPY。
- **第 4 周**：`problems` 后半（DCP、GP、多目标）；对照期中范围（1–4 章 + DCP）自测。
- **第 5 周**：`duality`。**这是整门课的重心**，不要赶。
- **第 6 周**：`approx` + `stat`。把 Lasso、logistic 回归、实验设计串起来。
- **第 7 周**：`geom` + `unconstrained`。
- **第 8 周**：`equality` + `barrier`。手推一次 m/t 与牛顿步数上界。

1.8 材料可得性与缺口（诚实清单）

材料	状态（2026-11-01）	说明
课程主页 / 讲义页	✅ 可访问	静态 HTML，无登录
讲义 PDF（14 个主题 + 4 个专题）	✅ 可下载	`lectures/` 目录开放索引
教材全文 PDF	✅ 可下载	714 页，6.6 MB
作业题目	❌ **不公开**	主页只给 Gradescope 与 Ed 链接（需登录）；`homework.html`、`hw0.pdf` 等路径均 404

材料	状态（2026-11-01）	说明
作业解答	❌ 不公开	教材习题解答需教师身份向作者申请
期中/期末真题	❌ 不公开	站内无 exam 页
课堂录像	⚠️ 仅选课学生	CGOE 平台，需注册
公开视频替代	✅	Boyd 的 Convex Optimization Short Course（含 slides、marimo notebook、视频）；CVX101（注册后访问）

给自学者的推论：没有作业题与真题，就必须自己造题。本笔记第 22 章的自测题是为此设计的；更好的做法是把教材每章末尾的习题当作作业（教材 PDF 内含全部习题，解答不在公开材料里，但题面足够）。

第 2 章 优化的语言：从工程问题到标准形式

2.1 动机：为什么先学"语言"而不是"算法"

一个工程问题在变成可计算的东西之前，只是一段自然语言："在功率不超过 P 的前提下，让吞吐量尽量大"。优化的第一步不是写代码，而是**选定变量、目标、约束**这三样东西。选错的代价极高：同一个物理问题，"功率"和"信噪比"作为变量会给出一个凸问题和一个非凸问题。

2.2 定义：标准形式

$$\begin{aligned} \textbf{minimize} \quad & f_0(x) \\ \textbf{subject to} \quad & f_i(x) \le 0, \quad i = 1, \dots, m \\ & h_i(x) = 0, \quad i = 1, \dots, p \end{aligned}$$

- $x \in \mathbb{R}^n$：**优化变量**（optimization variable）
- f_0：**目标函数**（objective / cost）
- f_i：**不等式约束函数**；h_i：**等式约束函数**
- **定义域** $\mathcal{D} = \bigcap_i \operatorname{dom} f_i \cap \bigcap_i \operatorname{dom} h_i$
- **可行点**（feasible）：$x \in \mathcal{D}$ 且满足全部约束；可行集记为 X
- **最优值** $p^\star = \inf\{f_0(x) \mid x \text{ feasible}\}$；约定 $p^\star = +\infty$ 表示不可行，$p^\star = -\infty$ 表示无下界
- **最优解**：可行且 $f_0(x) = p^\star$ 的 x；最优解集记 X_{opt}

> **关键区分**：$p^\star$ 是**下确界**，不一定取到。$f_0(x) = 1/x$ 在 $x > 0$ 上 $p^\star = 0$ 但无最优解——这正是 18.100A 里"$\inf$ 存在、$\min$ 不存在"的翻版。合上笔记想一想：为什么凸性 + 闭 + 有界下水平集能保证取到？

2.3 三类问题：为什么凸性是分水岭

类别	目标/约束	全局最优	最坏复杂度（直觉）
LP（线性规划）	全为仿射	一定	多项式（内点法），实际极快
凸优化	f_0, f_i 凸，h_i 仿射	一定（局部即全局）	多项式（内点法 + 自和谐）
非线性/组合优化	一般	一般只能局部最优	NP-hard 常见（如 Boolean LP）

讲义 `intro.pdf` 用一张"问题谱系"图表达同一件事：越往右越一般、越难；凸优化是"能保证全局最优"的最一般边界。

2.4 定理：凸问题的局部最优即全局最优

定理（讲义 4.9–4.10） 若标准形式问题中 f_0, f_i 凸、h_i 仿射，则任一局部最优解都是全局最优解。

证明思路（反证 + 凸组合）：设 x 局部最优但存在可行 y 使 $f_0(y) < f_0(x)$。取 $z = \theta y + (1-\theta)x$，$\theta = \frac{R}{2\|y-x\|_2} \in (0, 1/2)$。可行集的凸性给出 z 可行；$\|z - x\|_2 = R/2 < R$ 落在局部邻域内；凸性给出

$$f_0(z) \le \theta f_0(y) + (1-\theta) f_0(x) < f_0(x),$$

与局部最优矛盾。□

这个证明只用到了"可行集凸 + 目标凸"，所以对任意凸集上的凸函数都成立。

2.5 几何直觉：水平集、上境图、支撑超平面

- **水平集**（sublevel set）$S_\alpha = \{x \mid f_0(x) \le \alpha\}$。凸函数的水平集是凸集；反过来不成立（拟凸函数，见第 6 章）。
- **上境图**（epigraph）$\mathbf{epi}\, f = \{(x, t) \mid f(x) \le t\}$。$f$ 凸 $\iff$ $\mathbf{epi}\, f$ 凸——这条等价把"函数凸性"变成了"集合凸性"，是后面把问题改写成"上境图形式"的依据。
- **最优性**：在最优点，$-\nabla f_0(x^\star)$ 定义了可行集 X 在 $x^\star$ 处的一个**支撑超平面**（supporting hyperplane）。这是 KKT 条件的几何原型。

2.6 例题：四个一维问题（讲义 4.5）

对 $n=1, m=p=0$ 的情形，判断 $p^\star$ 与最优解：

f_0	定义域	$p^\star$	最优解
$1/x$	$x>0$	0	**不存在**（$x\to\infty$）
$-\log x$	$x>0$	$-\infty$	无（无下界）
$x\log x$	$x>0$	$-1/e$	$x=1/e$
x^3-3x	$\mathbb{R}$	$-\infty$	无；但 $x=1$ 是**局部**最优

最后一行是全课程最重要的反例：**非凸问题里"局部最优"毫无意义**。$x=1$ 局部最优（$f=-2$），但全局可以到 $-\infty$。

2.7 常见误区

1. **"$p^\star$ 一定取到"** —— 错。下确界不等于最小值；工程上"最优解不存在"往往意味着模型缺约束（比如没加功率上界）。
2. **"目标函数凸就够了"** —— 错。约束也必须凸（等式必须仿射），否则可行集可能非凸，局部最优不再全局。
3. **"不可行就是代码写错了"** —— 不一定。不可行是**问题的性质**，应当用 Phase I 或对偶证书去诊断（第 18 章）。
4. **"变量取得越多模型越准"** —— 反了。变量越多，越难看出结构、越难满足 DCP、数值条件越差。第 9 章的等价变换常常是**减变量**。

第 3 章 凸集：可行域的形状

3.1 动机：先看"能走的地方"长什么样

优化问题的解一定落在可行集里。如果可行集是凸的，任何"从两端各取一点连线"的操作都还在集合内——这正是第 2.4 节证明的引擎。所以判断一个问题凸不凸，**第一步是看可行集**。

3.2 定义链：仿射 → 凸 → 锥

概念	定义	一句话
仿射集（affine set）	过任意两点的**整条直线**仍在集合内： $x_1, x_2 \in C,\ \theta \in \mathbb{R} \Rightarrow \theta x_1 + (1-\theta)x_2 \in C$	线性方程组的解集 $\{x \mid Ax = b\}$
凸集（convex set）	过任意两点的**线段**仍在集合内： $x_1, x_2 \in C,\ 0 \le \theta \le 1 \Rightarrow \theta x_1 + (1-\theta)x_2 \in C$	没有"凹口"
凸锥（convex cone）	对**锥组合**封闭：$x_1, x_2 \in C,\ \theta_1, \theta_2 \ge 0 \Rightarrow \theta_1 x_1 + \theta_2 x_2 \in C$	凸 + 对非负缩放封闭
凸组合（convex combination）	$\sum_i \theta_i x_i,\ \theta_i \ge 0,\ \sum_i \theta_i = 1$	权重非负且归一
凸包（convex hull） $\mathbf{conv}\, S$	S 中点的所有凸组合之集	包含 S 的**最小**凸集

> **必须背下来的一个反例**：凸锥一定包含原点（取 $\theta_1 = \theta_2 = 0$），凸集不必。仿射集是"凸 + 对任意缩放封闭"。三者是严格的包含关系：仿射集 $\subset$ 凸集，凸锥 $\subset$ 凸集，但仿射集与凸锥互不包含（除非都是 $\{0\}$ 或整个空间）。

3.3 标准凸集清单（讲义 2.2）

集合	定义	凸性依据
超平面（hyperplane）	$\{x \mid a^\top x = b\},\ a \ne 0$	仿射集，故凸
半空间（halfspace）	$\{x \mid a^\top x \le b\}$	单个线性不等式
欧氏球	$B(x_c, r) = \{x \mid \|x - x_c\|_2 \le r\} = \{x_c + ru \mid \|u\|_2 \le 1\}$	范数的三角不等式
椭球（ellipsoid）	$\{x \mid (x-x_c)^\top P^{-1}(x-x_c) \le 1\},\ P \in \mathbb{S}^n_{++}$	仿射像 + 单位球
范数球	$\{x \mid \|x - x_c\| \le r\}$	任意范数都行，不限于 2–范数
范数锥	$\{(x, t) \mid \|x\| \le t\}$	对锥组合封闭
多面体（polyhedron）	$\{x \mid Ax \preceq b,\ Cx = d\}$	有限个半空间/超平面的交
单纯形（simplex）	$\mathbf{conv}\{v_0, \dots, v_k\},\ v_i - v_0$ 线性无关	凸包
半正定锥	$\mathbb{S}^n_+ = \{X \in \mathbb{S}^n \mid X \succeq 0\}$	见下

3.4 半正定锥：本课程最重要的集合

$$\mathbb{S}_+^n = \{X \in \mathbb{S}^n \mid z^\top X z \geq 0,\ \forall z \in \mathbb{R}^n\}$$

凸性证明（一行）：若 $X, Y \succeq 0$，则对任意 z 与 $\theta \in [0,1]$，

$$z^\top(\theta X + (1-\theta)Y)z = \theta\, z^\top X z + (1-\theta)\, z^\top Y z \geq 0.$$

几何直觉：$\mathbb{S}^n$ 是 $n(n+1)/2$ 维向量空间；$\mathbb{S}_+^n$ 是其中的一个**尖锥**（pointed cone），顶点在 0，边界由 $\det X = 0$ 的"曲面"构成。$n=2$ 时它就是三维空间里的冰淇淋锥（$x \geq 0,\ y \geq 0,\ xy \geq z^2$ 的旋转体）。

两个必须分清的记号：

- $X \succeq 0$：半正定（允许奇异），对应 $\mathbb{S}_+^n$；
- $X \succ 0$：正定（必须可逆），对应**开**锥 $\mathbb{S}_{++}^n$，它是 $\mathbb{S}_+^n$ 的内部。

3.5 几何直觉：为什么"凸"是可计算性的分界线

1. **凸集上的线性函数**：在凸集上最小化线性函数，最优解一定在**边界**；若凸集是多面体，则在**顶点**（这是 LP 单纯形法的几何基础）。
2. **分离**：两个不交的凸集总能被一张超平面分开（第 4.5 节）。非凸集做不到——这正是 SVM 需要"凸化"的原因。
3. **投影**：到凸集的欧氏投影**唯一**；到非凸集可能多点甚至不连续。算法里所有"投影算子"的良好性质都来自凸性。

3.6 例题

例 3.1（椭球是有界凸集） 设 $P \succ 0$，令 $A = P^{1/2}$（对称正定矩阵的唯一对称平方根）。则

$$\{x \mid (x-x_c)^\top P^{-1}(x-x_c) \leq 1\} = \{x_c + Au \mid \|u\|_2 \leq 1\}.$$

证明：令 $u = A^{-1}(x - x_c)$，则 $(x-x_c)^\top P^{-1}(x-x_c) = u^\top A A^{-1} A\, u = \|u\|_2^2$。于是集合是单位球在可逆线性映射 A 下的像再加平移，凸性由"凸集在仿射映射下的像仍凸"得到（第 4 章）。□

例 3.2（$\succeq$ 与 $\geq$ 的陷阱） 集合 $\{x \in \mathbb{R}^2 \mid x_1 x_2 \geq 1,\ x_1 > 0\}$ 是凸的吗？

答：是。做变量替换 $y_i = \log x_i$，集合变成 $\{y \mid y_1 + y_2 \geq 0\}$——一个半空间。这类"对数变换把乘积约束变成线性约束"的技巧是几何规划（第 9.6 节）的全部秘密。

例 3.3（单纯形是"概率向量的推广"） 标准单纯形 $\{x \mid x \succeq 0,\ \mathbf{1}^\top x = 1\}$ 的顶点是 $e_1, \dots, e_n$，任意点都是顶点的凸组合——这就是"凸包"最直白的实例，也是 LP 里"混合策略"、"投资组合权重"的可行域。

3.7 常见误区

1. **"凸集的并还是凸集"** —— 错。两个不交线段的并集不是凸集。保凸的是**交**，不是并（并的凸包才凸）。
2. **"凸集一定包含原点"** —— 错，只有**锥**才必然包含原点。
3. **"$\{x \mid x^\top P x \le 1\}$ 总是椭球"** —— 错。$P \succeq 0$ 但奇异时，集合是**无界的柱体**（在 $\ker P$ 方向上无限延伸），不是椭球。写 CVXPY 时若用 `cp.quad_form(x, P) <= 1` 而 P 奇异，DCP 会直接拒绝。
4. **"开集/闭集不影响凸性判断"** —— 凸性确实不要求闭，但**最优解是否存在**要求闭 + 下有界（Weierstrass）。$\{x \mid x > 0\}$ 凸但 $\min x$ 无解。

第 4 章 保凸运算、锥与分离定理

4.1 动机：怎样"造"出凸集

标准清单只有十来个集合，工程问题里的可行域却是千变万化的。真正的工具是**保凸运算**：从已知凸集出发，用保持凸性的操作生成新凸集。会做这件事，等于会做 80% 的建模。

4.2 保凸运算总表

运算	结论	典型用法
交（intersection）	任意多个凸集之交仍凸	多面体 = 半空间之交；LMI 可行域
仿射像 / 原像	C 凸 $\Rightarrow \{Ax+b \mid x \in C\}$ 凸；$\{x \mid Ax+b \in C\}$ 凸	椭球 = 球之像；等式约束消元
和（Minkowski sum）	$C_1 + C_2 = \{x+y\}$ 凸	鲁棒优化中的不确定集
笛卡尔积	$C_1 \times C_2$ 凸	多期决策变量
投影	凸集到部分坐标的投影仍凸	消去辅助变量（第 8 章）
透视像（perspective image）	$\{x \mid (x,t) \in C,\ t>0\}$ 凸（若 C 是凸锥）	线性分式规划
凸包	$\mathbf{conv}\, S$ 恒凸（S 任意）	松弛（第 11 章）

4.3 锥、广义不等式与对偶锥

真锥（proper cone）K 需满足：凸、闭、实心（solid，有内点）、尖（pointed，$K \cap (-K) = \{0\}$）。有了真锥就能定义**广义不等式**：

$$x \preceq_K y \iff y - x \in K, \qquad x \prec_K y \iff y - x \in \operatorname{int} K.$$

锥 K	$\preceq_K$ 的含义	出现场景
$\mathbb{R}^n_+$	逐分量 $\leq$	LP、资源约束
$\mathbb{S}^n_+$	矩阵不等式 $X \preceq Y$	SDP、LMI、控制
二阶锥 $\mathcal{Q}^n = \{(x,t) \mid \|x\|_2 \leq t\}$	"锥序"	SOCP、鲁棒 LP
$\mathbb{R}^n_+$ 的对偶	自身（自对偶）	—

对偶锥（dual cone）：$K^* = \{y \mid x^\top y \geq 0,\ \forall x \in K\}$。三个必记事实：

1. K^* 恒为凸锥（即使 K 不凸）。
2. $\mathbb{R}^n_+$、$\mathbb{S}^n_+$、$\mathcal{Q}^n$ 都是**自对偶**的（$K^* = K$）。
3. 范数锥 $K = \{(x,t) \mid \|x\| \leq t\}$ 的对偶是 $\{(y,s) \mid \|y\|_* \leq s\}$，其中 $\|\cdot\|_*$ 是对偶范数（$\ell_1 \leftrightarrow \ell_\infty$，$\ell_2 \leftrightarrow \ell_2$）。

> **为什么对偶锥重要**：第 12 章的对偶问题里，乘子必须落在对偶锥中（$\lambda \succeq_{K^*} 0$）。$\mathbb{S}^n_+$ 自对偶，所以 SDP 的乘子是半正定矩阵——这一条直接推出"SDP 的对偶还是 SDP"。

4.4 分离与支撑超平面

分离超平面定理（separating hyperplane theorem）：若 C, D 是非空凸集且 $C \cap D = \varnothing$，则存在 $a \neq 0, b$ 使

$$a^\top x \leq b \ \forall x \in C, \qquad a^\top x \geq b \ \forall x \in D.$$

支撑超平面定理：凸集 C 的任一边界点 x_0 处存在支撑超平面 $\{x \mid a^\top x = a^\top x_0\}$，且 $a^\top x \leq a^\top x_0$ 对所有 $x \in C$ 成立。

推论（法锥）：若 $x^\star$ 是 $\min_{x \in C} f(x)$ 的解，则 $-\nabla f(x^\star) \in N_C(x^\star)$，其中

$$N_C(x) = \{g \mid g^\top (y - x) \leq 0,\ \forall y \in C\}$$

是 C 在 x 处的**法锥**（normal cone）。这正是第 2.5 节"支撑超平面"的定量版本，也是 KKT 条件的几何母体：**最优 = 目标梯度被可行集的法锥"顶住"**。

4.5 例题

例 4.1（LMI 可行域是凸的） 设 $A_i \in \mathbb{S}^n$，集合

$$\{x \in \mathbb{R}^m \mid A_0 + x_1 A_1 + \cdots + x_m A_m \succeq 0\}$$

是凸集。*证明*：它是仿射映射 $x \mapsto A_0 + \sum x_i A_i$ 下 $\mathbb{S}^n_+$ 的原像，而 $\mathbb{S}^n_+$ 凸、仿射原像保凸。□

这个集合叫**线性矩阵不等式**（LMI）可行域，是控制与 SDP 的标准语言（第 20.4 节）。

例 4.2（证明 $\mathbb{S}^n_+$ 自对偶） 需证：$X \succeq 0 \iff \operatorname{tr}(XY) \geq 0 \ \forall Y \succeq 0$。

必要性：$Y \succeq 0$ 可写 $Y = \sum_k y_k y_k^\top$，则 $\operatorname{tr}(XY) = \sum_k y_k^\top X y_k \geq 0$。*充分性*：若 $X \not\succeq 0$，取特征向量 v（$\lambda < 0$）与 $Y = vv^\top \succeq 0$，则 $\operatorname{tr}(XY) = v^\top X v = \lambda < 0$，矛盾。□

例 4.3（投影到半正定锥） 给定对称 $A = U\Lambda U^\top$，$\min_{X \succeq 0} \|X - A\|_F^2$ 的解是 $X^\star = U\Lambda_+ U^\top$，$\Lambda_+$ 为把负特征值截断为 0。这个算子（特征值阈值化）是所有 SDP 一阶算法的内循环，也是"低秩近似"的来源。

4.6 常见误区

1. **"两个凸集的并的凸包可以用一次交表示"** —— 不能。凸包需要 $\operatorname{conv}(C \cup D) = \{\theta x + (1-\theta) y\}$，是**新变量 + 联合约束**，不是交。
2. **"分离定理对任意两个不交集合成立"** —— 错，凸性是本质条件。两个交错的非凸集合无法被超平面分开。
3. **"$\preceq_K$ 和逐分量 $\leq$ 一样"** —— 只在 $K = \mathbb{R}^n_+$ 时一样。$\mathbb{S}^n_+$ 的 $\preceq$ 是矩阵序，$X \preceq Y$ 与"每个元素都小"完全无关。
4. **"法锥就是约束的梯度张成的锥"** —— 只在约束是光滑流形时近似成立。对多面体，法锥是**活跃约束梯度生成的锥**（锥包，不是线性张成）。

第 5 章 凸函数：目标与约束的形状

5.1 动机

凸集保证可行域"没有洞"，凸函数保证目标"没有假谷"。两者合起来才有第 2.4 节的结论。更重要的是：**凸函数的二阶信息（Hessian）处处半正定**，这让牛顿法有了可证明的二次收敛性（第 17 章）。

5.2 定义与三个等价判据

$f : \mathbb{R}^n \to \mathbb{R}$ 凸，若 $\operatorname{dom} f$ 凸且

$$f(\theta x+(1-\theta)y)\le\theta f(x)+(1-\theta)f(y),\qquad \forall x,y\in\operatorname{dom}f,\ 0\le\theta\le1.$$

判据	条件	用途
零阶（定义）	Jensen 不等式对两点成立	验证定义、证明不等式
一阶	$f(y)\ge f(x)+\nabla f(x)^{\top}(y-x)$	"梯度给出全局下估计"——对偶理论的根基
二阶	$\nabla^2 f(x)\succeq 0$ 对一切 $x\in\operatorname{dom}f$	实际计算中最常用

严格凸：上式对 $x\neq y,\ 0<\theta<1$ 取严格不等号。**强凸**（strongly convex，m–强凸）：$\nabla^2 f(x)\succeq mI$，$m>0$。强凸 $\Rightarrow$ 严格凸 $\Rightarrow$ 凸，反之都不成立（e^x 严格凸但不强凸；x^4 严格凸但 $f''(0)=0$）。

5.3 例子表（讲义 3.3–3.5）

凸函数	定义域	备注
$ax+b$	$\mathbb{R}$	既凸又凹（仿射）
e^{ax}	$\mathbb{R}$	对任意 a
x^{α}	$x>0$	$\alpha\ge1$ 或 $\alpha\le0$
$\lvert x\rvert^{p}$	$\mathbb{R}$	$p\ge1$
$\max\{0,x\}$（ReLU）	$\mathbb{R}$	逐点最大
$\lVert x\rVert_p$	$\mathbb{R}^n$	任意范数
$\max_i x_i$	$\mathbb{R}^n$	逐点最大
$\log\sum_i e^{x_i}$（log-sum-exp）	$\mathbb{R}^n$	"soft max"，第 5.6 节
$x^{\top}Px+2q^{\top}x+r$	$\mathbb{R}^n$	凸 $\iff P\succeq0$
$\log\det X$	$X\succ0$	凹函数
$\lambda_{\max}(X)$	$\mathbb{S}^n$	凸（谱范数）
$-\log\det X$、$\operatorname{tr}(X^{-1})$	$X\succ0$	凸
$-\sum x_i\log x_i$（负熵）	$x\succ0$	凹函数

扩展值延拓（extended-value extension）$\tilde f(x)=f(x)$（$x\in\operatorname{dom}f$），$+\infty$（否则）。好处：把"定义域凸"这一条并入凸性不等式，写证明时少一半话。

5.4 保凸运算（讲义 3.2，本节是全课程最实用的表）

运算	结论	陷阱
非负加权和	$w_1 f_1 + w_2 f_2$ 凸（$w_i \geq 0$）	系数为负立刻失效
仿射复合	$f(Ax+b)$ 凸	只需 f 凸
逐点最大 / 上确界	$\max_i f_i$、$\sup_y f(x,y)$ 凸	这是"最坏情况"建模的标准工具
标量复合	$h(g(x))$ 凸，若 g 凸、h 凸且**非降**	h 非单调时结论失效：e^{-x} 中 $h=\exp$ 凸增、$g=-x$ 仿射，仍凸；但 $g=x^2$、$h=\sqrt{\cdot}$ 凹增时需另判
矢量复合	$h(g_1,\dots,g_k)$ 凸，若 h 凸且对每个分量非降、g_i 凸	混合凹凸分量时要用"扩展值复合规则"
部分最小化	$g(x)=\inf_y f(x,y)$ 凸，若 f 在 (x,y) 上联合凸且 C 凸	这是消去变量、得到对偶函数的统一框架
透视	$g(x,t)=t\,f(x/t)$ 凸（$t>0$）	分式规划、CVaR

> **必背的一条**：**逐点最大保凸，逐点最小不保凸**。$\min\{f_1,f_2\}$ 一般是凹的（若 f_i 凸）。工程上"取最坏情况"总是安全的（凸），"取最好情况"往往把问题变难。

5.5 上境图与 Jensen：两个"翻译器"

- $\mathbf{epi}\, f=\{(x,t)\mid f(x)\leq t\}$ 是凸集 $\iff$ f 凸。于是"$\min f_0(x)$ s.t. 约束"可以改写成"$\min t$ s.t. $(x,t)\in \mathbf{epi}\, f_0$，约束"——**上境图形式**（epigraph form），是理解"为什么 LP 能表达 $\|x\|_\infty$"的关键。
- **Jensen 不等式**（多点版）：$f(\sum \theta_i x_i)\leq \sum \theta_i f(x_i)$，$\theta_i\geq 0, \sum\theta_i=1$。它在概率论里的形态是 $f(\mathbb{E}X)\leq \mathbb{E}f(X)$，CS229 里 EM 算法的下界推导用的就是它。

5.6 例题

例 5.1（log-sum-exp 的凸性，两种证法） $f(x)=\log\sum_{i=1}^n e^{x_i}$。

证法一（二阶）：令 $z_i=e^{x_i}/\sum_j e^{x_j}$（即 softmax，$z\succ 0, \mathbf{1}^\top z=1$），可算得

$$\nabla^2 f(x)=\mathbf{diag}(z)-zz^\top.$$

对任意 v：$v^\top(\mathbf{diag}(z)-zz^\top)v=\sum_i z_i v_i^2-(\sum_i z_i v_i)^2=\mathbf{Var}_z(v)\geq 0$。□

证法二（逐点最大）：$\log\sum_i e^{x_i}=\sup_{z\in\Delta} z^\top x$，其中 Δ 是概率单纯形。逐点上确界保凸。□

证法二顺便给出了一个重要对偶关系：**log-sum-exp 是线性函数在单纯形上的支撑函数**，它的共轭就是单纯形的指示函数（第 6.3 节）。

例 5.2（$x^\top Px$ 的凸性） $f(x)=x^\top Px$，$\nabla^2 f = 2P$。故 f 凸 $\iff$ $P\succeq 0$。若 P 不定，f 是鞍面（有正有负曲率），任何基于"梯度为零"的算法都只能找到鞍点。

例 5.3（复合规则的失败案例） $f(x)=\sqrt{1+x^2}$ 凸吗？$h(u)=\sqrt{u}$ 是凹增，$g(x)=1+x^2$ 凸，凹增复合凸——规则不适用。直接算：$f''(x)=(1+x^2)^{-3/2}>0$，确实凸。**规则给不出结论时，回到二阶导数。**

5.7 常见误区

1. **"两个凸函数之差还是凸"** —— 错，这是非凸的头号来源（x^2-y^2）。DC 规划（difference of convex）专门处理这种结构。
2. **"凸函数的倒数/乘积"** —— 都不保凸。$1/x$ 在 $x>0$ 凸，$1/f$ 一般不凸。
3. **"$\nabla^2 f\succeq 0$ 在某点成立就是凸函数"** —— 错，必须**处处**成立。
4. **"强凸 = Hessian 可逆"** —— 错。强凸要求一致下界 mI；Hessian 处处可逆但特征值趋于 0（如 x^4）不是强凸，梯度法的线性收敛率也就不成立。

第 6 章 共轭函数、拟凸性与对数凸

6.1 动机：把"函数"变成"一族线性下界"

一阶条件说：凸函数在每点都有一个全局线性下估计 $f(x)+g^\top(y-x)$。**共轭函数问的是反问题**：给定斜率 y，最好的那条线性下界能抬多高？

6.2 定义与 Fenchel 不等式

$$f^*(y)=\sup_{x\in\operatorname{dom} f}\big(y^\top x-f(x)\big)$$

- **f^* 总是凸的**（逐点上确界，一族仿射函数之 sup），**无论 f 是否凸**。
- **Fenchel 不等式**：$f(x)+f^*(y)\geq x^\top y$，对任意 x,y。等号成立 $\iff$ $y\in\partial f(x)$（f 凸时）。
- **二次共轭**：$f^{**}\leq f$ 恒成立；若 f 凸且闭（下半连续），则 $f^{**}=f$。所以"取两次共轭"是**凸化 + 闭化**算子。

6.3 共轭函数表（必须能默写）

$f(x)$	$f^*(y)$	定义域
$f(x)=ax+b$	$-b$，若 $y=a$；$+\infty$ 否则	$\{a\}$
$\frac{1}{2}x^\top Qx$（$Q\succ 0$）	$\frac{1}{2}y^\top Q^{-1}y$	$\mathbb{R}^n$
$\|x\|$	0，若 $\|y\|_*\le 1$；$+\infty$ 否则	对偶范数单位球
$\|x\|_1$	0，若 $\|y\|_\infty\le 1$；$+\infty$ 否则	$[-1,1]^n$
$I_C(x)$（C 的指示函数）	$\sup_{x\in C} y^\top x$（C 的支撑函数）	$\mathbb{R}^n$
$\log\sum_i e^{x_i}$	$\sum_i y_i\log y_i$（相对熵，负值），若 $y\in\Delta$；$+\infty$ 否则	单纯形
$-\sum_i \log x_i$（$x\succ 0$）	$-\sum_i \log(-y_i)-n$	$y\prec 0$
$\frac{1}{2}\|x\|_2^2$	$\frac{1}{2}\|y\|_2^2$	$\mathbb{R}^n$

> 验证方法：解 $\nabla_x(y^\top x-f(x))=0$ 得到 $x^*(y)$，代回即得 $f^*(y)$。若最优 x 不存在（y 落在值域外），$f^*=+\infty$。

6.4 共轭与对偶的关系（通往第 12 章的桥）

对 $\min f_0(x)$ s.t. $Ax\preceq b$，对偶函数为

$$g(\lambda)=\inf_x\left(f_0(x)+\lambda^\top(Ax-b)\right)=-f_0^*(-A^\top\lambda)-b^\top\lambda.$$

所以"写对偶"有两套等价做法：直接对 x 求下确界，或者查共轭表 + 做变量代换。后者在 f_0 是范数、指示函数、log-sum-exp 时快得多。这也解释了为什么第 6 章要放在对偶之前。

6.5 拟凸函数（quasiconvex）

定义：f 拟凸 $\iff$ 所有水平集 $S_\alpha=\{x\mid f(x)\le\alpha\}$ 是凸集。

性质	内容
与凸的关系	凸 $\Rightarrow$ 拟凸；反之不成立（$\|x\|$ 拟凸，$\sqrt{\|x\|}$ 拟凸但非凸）
一阶条件	可微 f 拟凸 $\iff$ $f(y)\le f(x)\Rightarrow\nabla f(x)^\top(y-x)\le 0$
运算	非负加权**最大值**保拟凸；**和**不保拟凸
求解	**二分法**（bisection）：对每个 α 解一个凸可行性问题 $\{f(x)\le\alpha\}$

二分法伪代码（讲义 4.2.5 的思路）：

```
给定 l <= p*, u >= p*, 容差 eps
while u - l > eps:
    alpha = (l+u)/2
    解凸可行性问题：是否存在 x 使 f0(x) <= alpha 且 x 可行
    if 可行: u = alpha        # 最优值不超过 alpha
    else:    l = alpha
return u
```

代价是 $\lceil \log_2((u-l)/\epsilon) \rceil$ 次凸可行性求解。这条思路在工程上极有用：**只要水平集能被凸表示，问题就可解**，不必要求目标本身凸。

6.6 对数凸（log-concave）与对数凸密度

f 对数凹（log-concave） $\iff$ $f(x) > 0$ 且 $\log f$ 凹。要点：

- 对数凹 $\Rightarrow$ 拟凹（水平集凸）；
- 高斯、拉普拉斯、均匀、指数、Beta、Dirichlet 的密度都是对数凹的——这解释了为什么它们的 MLE 往往是凸问题（第 15 章）；
- **对数凹性对乘积、卷积、边缘化封闭**——这是统计建模里"为什么高斯这么好用"的深层原因。

6.7 例题

例 6.1 求 $f(x) = -\log x$（$x > 0$）的共轭。 $y^\top x - f(x) = yx + \log x$，对 x 求导：$y + 1/x = 0 \Rightarrow x^\star = -1/y$（要求 $y < 0$）。代回得 $f^*(y) = -\log(-y) - 1$。$\mathbf{dom}\, f^* = \{y < 0\}$。□

例 6.2 求 $f(x) = \|x\|_2$ 的共轭。 $f^*(y) = \sup_x (y^\top x - \|x\|_2)$。由 Cauchy–Schwarz，$y^\top x \le \|y\|_2 \|x\|_2$，故上确界为 0（当 $\|y\|_2 \le 1$，取 $x = 0$ 附近方向对齐）或 $+\infty$（当 $\|y\|_2 > 1$，沿 $x = ty$ 令 $t \to \infty$）。结论：$f^* = I_{\{y : \|y\|_2 \le 1\}}$。□

例 6.3 判断 $f(x_1, x_2) = x_1^2 / x_2$（$x_2 > 0$）的凸性与拟凸性。 这是**透视函数**（perspective）：$f = t\, g(x/t)$ 形式，$g(u) = u^2$ 凸，故 f 凸。它的水平集 $\{x_1^2 \le \alpha x_2\}$ 是二阶锥（旋转 45°），凸——与"凸 $\Rightarrow$ 拟凸"一致。这个函数是 CVaR、Sharpe 比、二阶锥规划的常客。

6.8 常见误区

1. **"只有凸函数才有共轭"** —— 错。任何函数都能取共轭，且 f^* 恒凸。对非凸 f，f^{**} 是 f 的**凸闭包**（最大的凸下估计）。
2. **"f^* 的定义域总是全空间"** —— 错。$f(x) = -\log x$ 的共轭只在 $y < 0$ 有限；f^* 的定义域恰好是 f 的**次梯度取值集合**。
3. **"拟凸 = 凸"** —— 差得远。拟凸问题一般**非凸**，只能靠二分法 + 凸可行性，不能直接用内点法一步求解。

4. **"共轭就是拉格朗日对偶函数"** —— 不完全是。对偶函数是**共轭 + 仿射项**（见 6.4 节公式）；把两者混为一谈会在推导符号时出错。

第 7 章 次梯度与不可微凸分析（EE364b 内容，EE364a 不考）

> **章节定位**：EE364a 的讲义不设次梯度专章，讲义 12.5 把"subgradient calculus"明确列为 EE364b 的内容。但读对偶、读 ℓ_1 问题、读 KKT 的非光滑版本都绕不开它，所以本章作为**补丁**存在。来源：EE364b subgradients slides。考试范围请以课程主页为准，本章大概率**不在** EE364a 期中/期末范围内。

7.1 动机：不可微的地方恰恰最重要

$\|x\|_1$ 在 0 不可微，而 ℓ_1 的稀疏性正来自 0 点的"尖角"；$\max_i f_i$ 在交点不可微，而最坏情况优化正发生在交点；对偶函数 $g(\lambda)$ 几乎总是不可微的（它是仿射函数族的逐点下确界）。**如果只会梯度，这些问题的 KKT 条件根本写不出来。**

7.2 定义

g 是 f 在 x 处的**次梯度**（subgradient），若

$$f(y) \geq f(x) + g^T(y - x), \qquad \forall y.$$

所有次梯度的集合 $\partial f(x)$ 称为**次微分**（subdifferential）。

- f 凸 $\Rightarrow$ $\partial f(x)$ 是**非空闭凸集**（可能无界）；
- f 在 x 可微 $\Rightarrow$ $\partial f(x) = \{\nabla f(x)\}$；
- $g \in \partial f(x) \iff$ 仿射函数 $f(x) + g^T(y-x)$ 是 f 的**全局下估计** $\iff$ $(g, -1)$ 支撑 $\mathbf{epi}\, f$ 于 $(x, f(x))$。

7.3 例子（必须熟）

$f(x)$	$\partial f(x)$
$\lvert x\rvert$	$\mathbf{sign}(x)$（$x \neq 0$）；$[-1, 1]$（$x = 0$）
$\|x\|_2$	$\{g \mid \|g\|_2 \leq 1\}$（$x = 0$）；$\{x/\|x\|_2\}$（$x \neq 0$）
$\max_i f_i(x)$	$\mathbf{conv}\{\nabla f_i(x) \mid i \in \mathcal{A}(x)\}$，$\mathcal{A}$ 为活跃集

$I_C(x)$（指示函数）	$N_C(x)$（法锥）
$\lambda_{\max}(X)$	$\{vv^\top \mid v$ 是最大特征值对应的单位特征向量$\}$
$f(x)=\sum_i \lvert x_i\rvert$（$\ell_1$）	逐分量取 $[-1,1]$ 或 ± 1

7.4 最优性条件

定理：$x^\star$ 最小化凸 $f \iff 0 \in \partial f(x^\star)$。

对有约束问题 $\min_{x\in C} f(x)$：$0 \in \partial f(x^\star) + N_C(x^\star)$，即 $-\nabla f(x^\star) \in N_C(x^\star)$——第 4.4 节的法锥条件。**KKT 就是这条式子在"C 由不等式描述"时的展开。**

7.5 次梯度法

$$x^{(k+1)} = x^{(k)} - \alpha_k\, g^{(k)}, \qquad g^{(k)} \in \partial f(x^{(k)})$$

关键警告：$-g^{(k)}$ **不是**下降方向。次梯度法不保证目标单调下降，只能保证"最优值追踪"：

$$f_{\text{best}}^{(k)} - f^\star \;\le\; \frac{RG}{\sqrt{k}}, \qquad R \ge \|x^{(0)} - x^\star\|_2,\; G \ge \|g\|_2.$$

步长选择（三选一）：

策略	形式	性质
常数步长	$\alpha_k = \alpha$	收敛到 $f^\star + O(\alpha G^2)$ 的邻域，不精确收敛
衰减步长	$\alpha_k = \alpha/\sqrt{k}$	次线性收敛 $O(1/\sqrt{k})$
不可求和但趋于 0	$\alpha_k \to 0,\ \sum \alpha_k = \infty$	收敛（理论上最优，实践中难调）
Polyak 步长	$\alpha_k = \dfrac{f(x^{(k)}) - f^\star}{\|g^{(k)}\|^2}$	需知道 $f^\star$；实际用估计值

7.6 次梯度与对偶：一个高频技巧

对 $\min f_0(x)$ s.t. $f_i(x) \le 0$，对偶函数 $g(\lambda) = \inf_x L(x,\lambda)$。若 $x^\star(\lambda)$ 是 L 的一个极小点，则

$$\nabla_\lambda g(\lambda) = f(x^\star(\lambda)) \quad (\text{约束违反向量})$$

即**对偶函数的次梯度就是原问题的约束违反量**。这让"对偶上升"（dual ascent）成为可能：
$\lambda^{(k+1)} = [\lambda^{(k)} + \alpha_k f(x^{(k)})]_+$。ADMM（第 19 章）正是这条思路的增广版本。

7.7 例题

例 7.1（ℓ_2 正则化的次微分条件） 解 $\min_x \frac{1}{2}\|Ax-b\|_2^2+\lambda\|x\|_1$。最优性条件：

$$0 \in A^\top(Ax-b)+\lambda\,\partial\|x\|_1 \iff \begin{cases} (A^\top(b-Ax))_i = \lambda\ \mathrm{sign}(x_i), & x_i \neq 0 \\ |(A^\top(b-Ax))_i| \le \lambda, & x_i = 0 \end{cases}$$

这正是坐标下降软阈值（soft-thresholding）公式的来源：$x_i \leftarrow S_{\lambda/\|a_i\|^2}(z_i)$，
$S_\tau(z)=\mathrm{sign}(z)\max\{|z|-\tau,0\}$。

例 7.2（为什么 $|x|$ 的尖角产生稀疏） $\partial|x|$ 在 0 是一个**区间** $[-1,1]$。这意味着在 0 点，"梯度为零"的条件有一个区间的容差：只要 λ 落在 $[-|c|,|c|]$ 里，$x=0$ 就是最优。**一个点对应一个区间**，于是大量坐标被"压"到 0。

7.8 常见误区

1. **"次梯度是下降方向"** —— 错，这是初学者最容易犯的错。次梯度法的正确写法是追踪 f_{best}。
2. **"∂f 总是单点"** —— 错，只有在可微点才单点。
3. **"非凸函数也有非空次微分"** —— 错。非凸函数在多数点的次微分是**空集**（不存在全局下估计的仿射函数）。
4. **"$0\in\partial f$ 是必要条件但不是充分条件"** —— 对凸函数它是**充要**的；对非凸函数连必要条件都不是（在不可微点）。

第 8 章 凸优化问题：标准形式与等价变换

8.1 动机

"凸问题"的标准定义只有三行，但工程上拿到的问题几乎从来不长这个样子。**等价变换**（equivalence transformations）是把任意写法变成标准形式的合法手术——它必须满足：两个问题的最优解可以互相构造、最优值相同。

8.2 定义

$$\begin{aligned} \textbf{minimize} \quad & f_0(x) \\ \textbf{subject to} \quad & f_i(x) \le 0,\ i=1,\dots,m \\ & a_i^\top x = b_i,\ i=1,\dots,p \end{aligned}$$

为**凸优化问题**，当且仅当 $f_0, f_1, \dots, f_m$ 都是凸函数，**等式约束必须是仿射的**（这是硬性要求：$x^2 = 1$ 不是凸约束，因为它的解集 $\{-1, 1\}$ 不凸）。

可行集 $X = \{x \mid f_i(x) \le 0,\ a_i^\top x = b_i\}$ 是 m 个凸集与 p 个超平面的交，故凸。

8.3 最优性判据（可微情形，讲义 4.11）

x 是凸问题最优解 $\iff$ x 可行且

$$\nabla f_0(x)^\top (y - x) \ge 0, \qquad \forall y \in X.$$

三个特例（都是考试高频）：

情形	条件	解释
无约束	$\nabla f_0(x) = 0$	梯度为零
等式约束 $Ax = b$	$\exists \nu:\ Ax = b,\ \nabla f_0(x) + A^\top \nu = 0$	梯度落在 $A^\top$ 的行空间里
非负象限 $x \succeq 0$	$x \succeq 0;\ \nabla f_0(x) \succeq 0;\ x_i > 0 \Rightarrow (\nabla f_0)_i = 0$	互补松弛的雏形

最后一行的读法很值得玩味：**要么变量在边界（$x_i = 0$，梯度可以正），要么变量在内点（梯度必须为零）**。这正是 KKT 互补松弛 $\lambda_i x_i = 0$ 的几何来源。

8.4 四种等价变换

变换	做法	何时用
上境图形式	引入 t，$\min t$ s.t. $f_0(x) \le t$	把"最小化任意凸函数"变成"最小化线性函数 + 凸约束"；LP 表达 $\|x\|_\infty$ 靠它
引入松弛变量	$f_i(x) \le 0 \Rightarrow f_i(x) + s_i = 0,\ s_i \ge 0$	把不等式变等式（LP 标准形）
消去等式约束	$Ax = b$ 的通解 $x = x_0 + Fz$，代入	变量从 n 降到 $n - \mathbf{rank}\, A$；数值上更稳
引入新变量/拆解	$x = x^+ - x^-$，$\|x_i\| \le t_i$ 等	把绝对值和分段线性"线性化"

> **等价性的判据**：变换后的问题必须能**反向构造**原问题的解。若只是"松弛"（可行域变大），那是第 11 章的内容，不叫等价变换。

8.5 拟凸优化与多目标（讲义 4.2.5、4.7）

- **拟凸问题**：目标拟凸、约束凸。不能一步求解，用 6.5 节的二分法：每次解一个凸可行性问题。

- **多目标**（multicriterion）：$\mathbf{min}\ (\mathbf{w.r.t.}\ \mathbb{R}^2_+)\ (f_1, f_2)$。做法是**标量化**：$\min w_1 f_1 + w_2 f_2$（$w \succ 0$），扫 w 得到**帕累托前沿**（Pareto frontier）。讲义 4.7 的例子正是"误差 vs 正则项"的权衡曲线——也就是 Lasso 的 regularization path。

8.6 例题

例 8.1（ℓ_1 回归写成 LP） $\min \|Ax-b\|_1$。引入 $t \in \mathbb{R}^m$：

$$\min\ \mathbf{1}^\top t \quad \text{s.t.} \quad -t \le Ax - b \le t.$$

这是纯 LP，变量 (x, t)。**注意**：加变量并不"浪费"，它把非光滑目标变成了光滑约束，内点法反而更快。

例 8.2（分段线性凸函数） $f(x) = \max_{i=1,\dots,k}(a_i^\top x + b_i)$。上境图形式：$\min t$ s.t. $a_i^\top x + b_i \le t$，$i = 1..k$。k 条约束，纯 LP。

例 8.3（消去等式约束的数值收益） $\min \|Ax-b\|_2^2$ s.t. $Cx = d$。直接解 KKT 系统是 $(n+p)\times(n+p)$ 的；消元后变成 $n-p$ 维无约束最小二乘。当 p 接近 n 时，后者快一个数量级。这条"消元优先"的原则在第 17、18 章的牛顿法实现里反复出现。

8.7 常见误区

1. **"等式约束可以是非线性的，只要两边都凸"** —— 错。$f(x) = g(x)$ 一般等价于 $f(x) \le g(x)$ 且 $f(x) \ge g(x)$，两个凸约束的方向相反，可行集通常是曲面（非凸）。
2. **"等价变换会改变最优值"** —— 不会，但会改变**条件数**与**稀疏结构**，从而改变求解时间。
3. **"变量越少越好"** —— 不一定。例 8.1 增加了 m 个变量，却让问题从非光滑变成 LP。
4. **"$p^\star$ 有限就一定有最优解"** —— 仍需闭性/有界性条件。$\min e^x$ 在 $\mathbb{R}$ 上 $p^\star = 0$ 但取不到。

第 9 章 标准问题族：LP / QP / QCQP / SOCP / SDP / GP

9.1 动机

现实中的凸问题 95% 落在五六个"标准族"里。识别出族属，你就立刻知道：该用哪个 solver、复杂度大概多少、对偶长什么样、能不能写成 DCP。

9.2 五个族（讲义 4.3–4.6）

9.2.1 线性规划 LP

$$\min\ c^\top x + d \quad \text{s.t.} \quad Gx \preceq h,\ Ax = b$$

- 可行集是**多面体**；最优解（若存在）在顶点；
- 对偶仍是 LP（第 12 章）：$\max\ -h^\top\lambda - b^\top\nu$ s.t. $G^\top\lambda + A^\top\nu + c = 0,\ \lambda \succeq 0$。

9.2.2 二次规划 QP

$$\min\ \tfrac{1}{2}x^\top Px + q^\top x + r \quad \text{s.t.} \quad Gx \preceq h,\ Ax = b, \qquad P \in \mathbb{S}^n_+$$

- $P \succ 0$ 时严格凸，最优解唯一；$P \succeq 0$ 奇异时可能多解或无界；
- **P 不定时不是凸问题**（这是 CVXPY 报 "problem does not follow DCP rules" 的最常见原因之一）。

9.2.3 二次约束二次规划 QCQP

$$\min\ \tfrac{1}{2}x^\top P_0 x + q_0^\top x + r_0 \quad \text{s.t.} \quad \tfrac{1}{2}x^\top P_i x + q_i^\top x + r_i \le 0, \quad P_i \succeq 0$$

每个约束都是一个椭球的内部（或外部，看符号）。

9.2.4 二阶锥规划 SOCP

$$\min\ f^\top x \quad \text{s.t.} \quad \|A_i x + b_i\|_2 \le c_i^\top x + d_i, \quad i = 1, \dots, m$$

约束是**二阶锥**（冰淇淋锥）与仿射集的交。SOCP 的三个经典用途：

(a) 鲁棒 LP。约束 $a_i^\top x \le b_i$ 中 a_i 不确定，$a_i \in \mathcal{E}_i = \{\bar a_i + P_i u \mid \|u\|_2 \le 1\}$。要求"对所有 u 成立"：

$$\bar a_i^\top x + \|P_i^\top x\|_2 \le b_i.$$

推导：$\sup_{\|u\|\le 1}(P_i u)^\top x = \|P_i^\top x\|_2$。**一个不确定约束换来了一个 SOC 约束**——这就是"鲁棒性有代价，但代价是凸的"。

(b) 分段线性凸函数：$\sum_i \max(0, a_i^\top x + b_i)$，上境图 + SOCP/LP。

(c) 范数逼近：$\min \|Ax - b\|_2$ 本身就是 SOCP（$\|Ax-b\|_2 \le t$）。

9.2.5 半定规划 SDP

$$\min\ \operatorname{tr}(CX) \quad \text{s.t.} \quad \operatorname{tr}(A_i X) = b_i,\ X \succeq 0$$

或等价的"不等式形式"：$\min c^\top x$ s.t. $A_0 + \sum x_i A_i \preceq 0$（LMI 形式）。

两个必会例子：

最小最大特征值：$\min \lambda_{\max}(A(x)) \iff \min t$ s.t. $tI - A(x) \succeq 0$。

LMI 可行性：$\{x \mid A(x) \preceq 0\}$ 是凸集（第 4.5 节），这是控制里"找 Lyapunov 函数"的标准形式。

9.2.6 几何规划 GP

单项式（monomial）：$c x_1^{a_1} \cdots x_n^{a_n}$，$c > 0$，$x_i > 0$。 **正项式**（posynomial）：单项式之和。

GP 的标准形式：$\min f_0(x)$ s.t. $f_i(x) \le 1$，$h_i(x) = 1$，f_i 正项式、h_i 单项式。**关键变换** $y_i = \log x_i$：

$$f(x) = \sum_k c_k \prod_i x_i^{a_{ik}} \implies \log f(e^y) = \log \sum_k \exp\left(\log c_k + \sum_i a_{ik} y_i\right)$$

右边是 **log-sum-exp**（凸！），约束 $\log f_i \le 0$ 变成凸约束。所以 **GP 是"变量替换后的凸问题"**，不是"看起来像多项式的问题"。

9.3 层级关系图

```
        SDP  ⊃  SOCP  ⊃  QCQP  ⊃  QP  ⊃  LP
                  ⊃  LP
```

- LP ⊂ QP（取 $P = 0$）
- QP ⊂ QCQP（取 $P_0 = P$，无二次约束）
- QCQP ⊂ SOCP（把 $x^\top P x$ 用 Cholesky 因子写成 $\|P^{1/2}x\|^2$，再对每个约束配一个 SOC）
- SOCP ⊂ SDP（$\|u\|_2 \le t \iff \begin{bmatrix} tI & u \\ u^\top & t \end{bmatrix} \succeq 0$，Schur 补）

层级越靠右，表达力越强、单步求解越贵。**建模时的正确策略是"够用就好"**：能用 LP 就别写 SOCP，因为 LP 的求解器成熟几个数量级。

9.4 例题

例 9.1（Chebyshev 中心 → LP） 在多面体 $P = \{x \mid a_i^\top x \le b_i\}$ 内找最大内切球，半径为 r：$a_i^\top x_c + r\|a_i\|_2 \le b_i$ 对所有 i。目标是 $\max r$——这是 LP（变量 x_c, r 线性出现，$\|a_i\|_2$ 是常数）。

例 9.2（最小体积外包椭球 → SDP/凸） 给定点集 $\{x_1, \dots, x_m\}$，求最小体积椭球 $E = \{x \mid \|Ax + b\|_2 \le 1\}$。体积 $\propto \det A^{-1}$，目标 $\min \log\det A^{-1}$（凸），约束 $\|Ax_i + b\|_2 \le 1$（SOC）。整体是**凸问题**（严格说不是标准 SDP，因为目标是对数行列式，但属于"可解的凸问题"）。

例 9.3（投资组合 → QP） $\min x^\top \Sigma x$ s.t. $\mathbf{1}^\top x = 1$，$\mu^\top x \ge r_{\min}$，$x \succeq 0$。$\Sigma \succeq 0$ 时是 QP。**注意**：$x \succeq 0$（禁止做空）是让这个问题从"有解析解"变成"需要 QP 求解器"的唯一原因。

9.5 常见误区

1. **"含 $\|Ax+b\|_2$ 的问题都是 SOCP"** —— 若它出现在**目标**里且是平方形式 $\|Ax+b\|_2^2$，那是 QP（若 A 满列秩）；若出现在约束里的**右边**、或需要开方，才要小心 DCP 的凹凸性。
2. **"GP 只能用正项式"** —— 约束可以取倒数变成 ≤ 1 形式；目标若为**最大化**正项式则是凹问题，取 $1/f$ 变凸。
3. **"$P\succeq 0$ 的 QP 一定好解"** —— 还需要规模与稀疏性。$n=10^4$ 的稠密 QP 在内点法下要分解 $10^4\times 10^4$ 矩阵，代价 $O(n^3)\approx 10^{12}$，必须用一阶方法或利用结构。
4. **"SDP 松弛总是紧的"** —— 错。松弛是否紧取决于问题结构（第 11 章），很多组合问题的 SDP 松弛有非零间隙。

第 10 章 DCP：让"凸"可以被程序检查

10.1 动机

你写出 $\sqrt{x+1}\le y$，它等价于 $x+1\le y^2,\ y\ge 0$——但 CVXPY 会直接拒绝 `cp.sqrt(x+1) <= y`，因为 `sqrt` 是**凹**的，左边凹、右边仿射不满足 DCP。这不是 CVXPY 笨，而是**凸性不可判定**：一般地判断一个表达式是否凸是 NP-hard 的。DCP 用一套**语法规则**换取可判定性：宁可拒绝一些合法的凸写法，也不接受一个无法验证的写法。

10.2 三条规则（讲义 4.43）

一个问题是 **DCP**（disciplined convex program），当且仅当：

1. **目标**：`minimize` 一个**凸**标量表达式，或 `maximize` 一个**凹**标量表达式；
2. **不等式约束**：`凸表达式 <= 凹表达式`（或反过来 `>=`）；
3. **等式约束**：`仿射表达式 == 仿射表达式`。

表达式的曲率由**原子函数**（atoms）的曲率 + **组合规则**推出：

组合	条件	结果曲率
$f=g+h$	两者同曲率	同
$f=\alpha g$	$\alpha\ge 0$	同 g
$f=\alpha g$	$\alpha\le 0$	反
$f=h(g)$	h 凸**非降**，g 凸	凸

组合	条件	结果曲率
$f = h(g)$	h 凸非增，g 凹	凸
$f = h(g)$	h 凹非降，g 凹	凹
$f = h(g)$	h 凹非增，g 凸	凹
其他组合	—	未知（拒绝）

10.3 常用原子（CVXPY）

凸（convex）	凹（concave）
`cp.norm(x, p)`、`cp.norm1`、`cp.norm_inf`	`cp.sqrt(x)`（$x \geq 0$）
`cp.sum_squares(x)`、`cp.quad_form(x,P)`（$P \succeq 0$）	`cp.log(x)`、`cp.log_det(X)`
`cp.max(x)`、`cp.maximum(a,b)`	`cp.min(x)`、`cp.minimum(a,b)`
`cp.abs(x)`、`cp.pos(x)`	`cp.neg(x)`、`cp.entr(x)`（$-x\log x$）
`cp.exp(x)`、`cp.log_sum_exp(x)`	`cp.geo_mean(x)`、`cp.harmonic_mean(x)`
`cp.lambda_max(X)`、`cp.norm(X, 'nuc')`	`cp.lambda_min(X)`

完整的原子表在 DCP 工具页 与 CVXPY 文档里。

10.4 五个最常见的"非 DCP"与改写

原写法	为什么不行	改写
`cp.sqrt(x) <= y`	左凹右仿射	`x <= y**2`，`y >= 0`（若 y 是仿射或凹）
`cp.inv_pos(x) <= y`	凸 <= 仿射（可以！）	实际上 `inv_pos` 是凸，合法；真正的坑是 `y <= 1/x`
`x**2 / y <= t`（$y > 0$）	分子分母都含变量	用 `cp.quad_over_lin(x, y) <= t`（凸原子）
`cp.norm(x) <= cp.norm(y)`	凸 <= 凸	无法表达（除非能化成 $x = Az$）
`cp.exp(-x) <= t`	凸 <= 仿射，合法	但若写成 `t >= cp.exp(-x)` 且已知 $x \geq 0$，等价于 $-x \leq \log t$，更稳

10.5 CVXPY 骨架

```
import cvxpy as cp
import numpy as np

n, m = 100, 40
np.random.seed(0)
A = np.random.randn(m, n); b = np.random.randn(m)

x = cp.Variable(n)
t = cp.Variable()
# Lasso: min ||Ax-b||_2 + lam*||x||_1
lam = 0.1
prob = cp.Problem(cp.Minimize(cp.norm(A @ x - b, 2) + lam * cp.norm1(x)))
prob.solve(solver=cp.CLARABEL, verbose=False)
print(prob.status, prob.value, x.value[:3])
```

四个必查项：

1. `prob.status`：`OPTIMAL` / `INFEASIBLE` / `UNBOUNDED` / `OPTIMAL_INACCURATE`。**永远不要只看 `prob.value`**。
2. `prob.solver_stats`：迭代次数、求解时间，用于判断规模是否合适。
3. `constraint.dual_value`：对偶变量（第 12 章），SDP 的对偶是矩阵。
4. **DPP 规则**：用了 `cp.Parameter` 时，表达式必须满足 disciplined parametrized programming，否则每次 `solve` 都会重编译。规则：参数只能以**仿射**方式出现在"参数–变量"双仿射结构中。

10.6 例题

例 10.1（把"最大化的最小值"写对） $\max_x \ \min_i(a_i^\top x + b_i)$。引入 t，变成 $\max t$ s.t. $t \le a_i^\top x + b_i$ 对所有 i。约束是 `仿射 >= 变量`（凹 >= 仿射？t 是仿射）——`t <= affine` 合法（仿射 <= 仿射）。这是 LP。

例 10.2（几何平均的 DCP 陷阱） 最大化 $\prod x_i^{1/n}$（$x \succ 0$）。直接写 `cp.prod(x)**(1/n)` 会被拒。正确写法：`cp.geo_mean(x)`（凹原子），或取对数变成 $\frac{1}{n}\sum \log x_i$（凹）。**取对数是万能的：它把乘积变和、把幂变线性。**

例 10.3（条件数约束不可 DCP） $\min \|Ax-b\|_2$ s.t. $\kappa(A) \le 10$。条件数是 A 的非凸函数，无法直接写。工程近似：约束 $\sigma_{\max}(A) \le 10\sigma_{\min}(A)$ 也不是 DCP；常见替代是加正则项 $\|x\|_2^2$ 或对 A 的扰动做鲁棒化（第 9.2.4 节）。

10.7 常见误区

1. **"CVXPY 拒绝 = 问题非凸"** —— 错。可能只是**写法**不满足 DCP 语法（例：$\sqrt{}$、$\log$ 的位置）。先用数学手算凹凹凸凸，再考虑改写。

2. "`cp.quad_form(x, P)` **只要 P 对称就行**" —— 要求 $P \succeq 0$（凸）或 $P \preceq 0$（凹）。数值上 `P` 有负特征值 10^{-12} 级时会报错，需先做 `(P+P.T)/2` 与特征值截断。
3. "`x >= 0` **与** `x >> 0` **一样**" —— 前者逐分量非负，后者是**半正定**（只对矩阵变量有意义）。
4. **"求解成功就是对的"** —— `OPTIMAL_INACCURATE` 常见于一阶 solver（SCS）在大规模问题上，此时约束违反可能远超你的容忍度，务必检查 `prob.constraints[i].violation()`。

第 11 章 松弛：非凸问题的凸外壳

11.1 动机

$z \in \{0,1\}^q$、$x^\top Q x$ 带不定 Q、$\mathbf{rank}(X) \le k$——这三样东西让问题瞬间 NP-hard。但它们都有**凸外壳**（convex hull）或**凸下估计**。松弛给出的是**下界**（对最小化问题），而下界在工程上往往已经很有用：它告诉你"再优化也不可能低于这个值"。

11.2 一般框架（讲义 4.40）

原问题 $\min h(x)$ s.t. $x \in C$。构造：

- 凸函数 $\hat{h}$ 使 $\hat{h}(x) \le h(x)$ 对所有 x 成立（**逐点下估计**）；
- 凸集 $\hat{C} \supseteq C$（通常是 $\mathbf{conv}\, C$）。

则**松弛问题** $\min \hat{h}(x)$ s.t. $x \in \hat{C}$ 的最优值 $\hat{p}^\star \le p^\star$。

11.3 三种主流松弛

类型	做法	例子
LP 松弛	整数变量放松为区间	Boolean LP：$z \in \{0,1\}^q \to z \in [0,1]^q$
半定松弛（SDP relaxation）	把 $xx^\top$ 提升为 $X \succeq 0$，丢掉秩约束	MaxCut、传感器网络定位
拉格朗日松弛	把难约束乘上乘子并入目标	带耦合约束的选址/调度

11.3.1 Boolean LP

$$\min c^\top (x,z) \quad \text{s.t.} \quad F(x,z) \preceq g,\ A(x,z) = b,\ z \in \{0,1\}^q$$

LP 松弛把 $z \in \{0,1\}^q$ 换成 $0 \le z_i \le 1$。它的最优值是原问题的下界；若松弛解恰好是 0/1，则**松弛是紧的**，直接得到原问题最优解。

11.3.2 MaxCut 的 SDP 松弛（经典）

最大化 $\sum_{(i,j)\in E}\frac{1-x_ix_j}{2}$，$x_i\in\{-1,1\}$。令 $X=xx^\top$，则 $X\succeq 0$、$\mathbf{diag}(X)=1$、$\mathbf{rank}(X)=1$。**丢掉秩约束**得到 SDP：

$$\max \sum_{(i,j)\in E}\frac{1-X_{ij}}{2} \quad \text{s.t.} \quad X\succeq 0,\ \mathbf{diag}(X)=\mathbf{1}.$$

松弛后用随机取整（Goemans–Williamson）：取 $X^{1/2}$ 的行向量 v_i，随机超平面 r，令 $x_i=\mathbf{sign}(r^\top v_i)$。这是"松弛 + 取整"的教科书范例，近似比 0.878。

11.4 松弛的三条使用原则

1. **先看松弛是否紧**：若松弛解满足被丢掉的结构（整数性、秩），则直接结束。
2. **紧不了就取整 + 局部改进**：取整后必须**修复可行性**（投影回 C），再在附近做局部搜索。
3. **用对偶做下界证书**：松弛的对偶最优值同时给出"离最优还有多远"的证明（第 12 章的对偶间隙）。

11.5 例题

例 11.1（ℓ_0 的凸替代） $\min \|Ax-b\|_2^2+\gamma\|x\|_0$（$\|\cdot\|_0$ 是非凸的计数）。最佳凸下估计是 ℓ_1 范数：在 $\|x\|_\infty\le 1$ 的盒子上，$\|x\|_1$ 是 $\|x\|_0$ 的凸包。这就是 Lasso 是"ℓ_0 问题最紧凸松弛"的确切含义（在一定条件下）。

例 11.2（秩约束） $\min \|X\|_*$（核范数）s.t. $\mathcal{A}(X)=b$ 是"最小秩矩阵补全"的凸松弛（核范数 = 奇异值之和 = 谱范数的对偶）。矩阵补全（推荐系统）就靠这个。

11.6 常见误区

1. **"松弛最优值就是原问题最优值"** —— 只有紧松弛才成立。一般 $\hat{p}^\star<p^\star$，间隙可能很大。
2. **"取整后一定可行"** —— 不一定。Boolean LP 取整后可能违反 $F(x,z)\preceq g$，需要修复步骤。
3. **"松弛越紧越好"** —— 越紧通常越贵。工程上是"下界质量 vs 求解时间"的权衡。
4. **"ℓ_1 总能恢复稀疏解"** —— 需要 RIP/不相干性等条件；强相关设计矩阵下 ℓ_1 会选错变量。

第 12 章 Lagrange 对偶：下界、证书与价格

12.1 动机

对偶给了三样东西，每一样都不可替代：

1. **下界**：哪怕原问题解不出来，对偶也能给出 $p^\star$ 的下界（用于证明"已经最优"或"还差多少"）；
2. **证书**：对偶可行 + 目标相等 = 最优性证明，不需要知道 $p^\star$；
3. **价格**：乘子 $\lambda_i^\star$ 是"放松第 i 条约束一单位，目标能改善多少"的价格（第 13 章）。

12.2 构造（不要求凸！）

Lagrange 函数：

$$L(x,\lambda,\nu)=f_0(x)+\sum_{i=1}^{m}\lambda_i f_i(x)+\sum_{i=1}^{p}\nu_i h_i(x)$$

对偶函数：

$$g(\lambda,\nu)=\inf_{x\in\mathcal{D}}L(x,\lambda,\nu)$$

三条基本性质：

1. g 是**凹**函数（仿射函数族关于 (λ,ν) 的逐点下确界）；
2. **下界性质**：若 $\lambda\succeq 0$，则 $g(\lambda,\nu)\le p^\star$；
3. g 可以取 $-\infty$（当 L 在 x 上无下界）。

下界性质的证明（两行）：设 $\tilde{x}$ 可行、$\lambda\succeq 0$。则 $\lambda_i f_i(\tilde{x})\le 0$、$\nu_i h_i(\tilde{x})=0$，故 $L(\tilde{x},\lambda,\nu)\le f_0(\tilde{x})$；又 $g\le L(\tilde{x},\cdot)$。对所有可行 $\tilde{x}$ 取下确界即得 $g\le p^\star$。□

对偶问题：

$$\max_{\lambda,\nu}\ g(\lambda,\nu)\quad\text{s.t.}\quad\lambda\succeq 0$$

这是**凸问题**（最大化凹函数），无论原问题是否凸。

12.3 弱对偶与强对偶

- **弱对偶**：$d^\star\le p^\star$ 恒成立（包括 $p^\star=-\infty$ 或 $d^\star=+\infty$ 的退化情形）。
- **对偶间隙**：$p^\star-d^\star\ge 0$。
- **强对偶**：$p^\star=d^\star$。

什么时候强对偶成立?

条件	结论	备注
Slater 条件	凸问题 + 存在**严格可行点**（$f_i(x)<0\ \forall i$，$Ax=b$）$\Rightarrow$ 强对偶，且对偶最优**取到**	讲义 5.12
Slater 的加强版	可把 $\mathbf{int}\,\mathcal{D}$ 换成相对内部 $\mathbf{relint}\,\mathcal{D}$；**线性不等式不必严格**	讲义 5.12
仿射约束（LP）	只要原问题或对偶有一方可行，$p^\star=d^\star$	讲义 5.14
QP（$P\succ 0$）	**总是**强对偶（只要原问题可行）	讲义 5.15
一般非凸问题	一般**不成立**，间隙可正	整数规划的对偶间隙就是它

> **Slater 的直觉**：严格可行点意味着可行集有"内点"，几何上保证了对偶的支撑超平面能真正"贴住"最优值而不留缝。LP 的可行集没有内点（是多面体），所以 Slater 对线性约束放宽——这正是 LP 总有强对偶的原因。

12.4 几何解释

把可行点的 $(\text{约束值}, \text{目标值})$ 画成 $\mathcal{G}=\{(f_1(x),f_0(x))\mid x\in\mathcal{D}\}\subset\mathbb{R}^2$（单约束情形）。$p^\star$ 是 $\mathcal{G}$ 在 $f_1\le 0$ 部分的**最低点**；$g(\lambda)$ 是用斜率 $-\lambda$ 的直线去"托" $\mathcal{G}$ 得到的截距。**强对偶成立 $\iff$ 在最优处存在一条支撑线**；非凸的 $\mathcal{G}$ 有凹陷时，支撑线托不到最低点，间隙出现。

12.5 例题：四个必会例子（讲义 5.4–5.7）

（a）最小范数解 $\min x^\top x$ s.t. $Ax=b$。 $L=x^\top x+\nu^\top(Ax-b)$，
$\nabla_x L=2x+A^\top\nu=0\Rightarrow x=-\frac{1}{2}A^\top\nu$。代回：

$$g(\nu)=-\tfrac{1}{4}\nu^\top AA^\top\nu-b^\top\nu.$$

对偶是**无约束凹二次**最大化，令梯度为零：$-\frac{1}{2}AA^\top\nu-b=0\Rightarrow\nu^\star=-2(AA^\top)^{-1}b$，回代得 $x^\star=A^\top(AA^\top)^{-1}b$——**伪逆解**。对偶推导与直接求导给出同一答案，这是一个极好的自检。

（b）标准形 LP $\min c^\top x$ s.t. $Ax=b,\ x\succeq 0$。

$$L=-b^\top\nu+(c+A^\top\nu-\lambda)^\top x\ \Rightarrow\ g(\lambda,\nu)=\begin{cases}-b^\top\nu, & A^\top\nu-\lambda+c=0\\ -\infty, & \text{otherwise}\end{cases}$$

对偶：$\max -b^\top\nu$ s.t. $A^\top\nu+c\succeq 0$（把 $\lambda\succeq 0$ 消掉）。**注意对偶变量 ν 无符号约束**——等式约束的乘子可正可负。

（c）QP $\min x^\top Px$ s.t. $Ax\preceq b$（$P\succ 0$）：

$$g(\lambda) = -\tfrac{1}{4}\lambda^\top A P^{-1} A^\top \lambda - b^\top \lambda, \qquad \text{dual: } \max\ g(\lambda)\ \text{s.t. } \lambda \succeq 0.$$

（d）二次目标 + 单一等式约束 $\min \frac{1}{2}\|x\|_2^2$ s.t. $\mathbf{1}^\top x = 1$。$L = \frac{1}{2}\|x\|_2^2 + \nu(\mathbf{1}^\top x - 1)$，$\nabla_x L = x + \nu\mathbf{1} = 0 \Rightarrow x = -\nu\mathbf{1}$。代回：

$$g(\nu) = \tfrac{1}{2}n\nu^2 - n\nu^2 - \nu = -\tfrac{1}{2}n\nu^2 - \nu.$$

对偶是**一维**凹二次，$\nu^\star = -1/n$，$g(\nu^\star) = \frac{1}{2n}$；回代得 $x_i = 1/n$，$p^\star = \frac{1}{2n}$——**与直接求导一致**。对偶把 n 维问题压成 1 维，这是它最实用的价值之一。

12.6 鞍点解释

强对偶 $\iff$ 存在鞍点 $(x^\star, \lambda^\star, \nu^\star)$：

$$L(x^\star, \lambda, \nu) \le L(x^\star, \lambda^\star, \nu^\star) \le L(x, \lambda^\star, \nu^\star), \qquad \forall x,\ \lambda \succeq 0.$$

读法：$x^\star$ 是 L 关于 x 的极小点，$(\lambda^\star, \nu^\star)$ 是 L 关于乘子的极大点。**原始问题 = $\min_x \max_{\lambda\succeq 0} L$，对偶问题 = $\max_{\lambda\succeq 0} \min_x L$**，弱对偶就是"min–max 不等式"：$\max\min \le \min\max$。强对偶 = 等号成立 = 可以交换次序。这个视角直接推出原始–对偶算法（第 19 章的 ADMM 就是对偶上升 + 增广）。

12.7 常见误区

1. **"对偶问题一定是凸的，所以原问题也凸"** —— 错。对偶恒凸，与原始凸性无关；非凸问题的对偶也是凸的，只是可能有间隙。
2. **"强对偶总能成立"** —— 错。Slater 需要**严格可行点**；若可行集是低维的（如 $\{x \mid x_1^2 + x_2^2 \le 0\}$ 只有原点），严格可行点不存在，需用加强版或直接验证。
3. **"$\lambda_i^\star > 0$ 说明约束 i 一定活跃"** —— 方向反了：**互补松弛**说 $\lambda_i^\star f_i(x^\star) = 0$，所以 $\lambda_i^\star > 0 \Rightarrow f_i(x^\star) = 0$（活跃）；反过来活跃不蕴含 $\lambda_i > 0$（可能退化）。
4. **"对偶最优一定取到"** —— 不一定。$d^\star$ 可能只是上确界。Slater 条件同时保证了对偶最优**取到**。

第 13 章 KKT 条件与敏感性分析

13.1 动机

KKT 是"最优性"的可计算形式：它把"$x^\star$ 是最优解"翻译成一组**方程 + 不等式 + 互补条件**。工程上它的三大用途：

1. **验证**：solver 给出解后，检查 KKT 残差；
2. **推导算法**：内点法就是把互补松弛松弛成 $-\lambda_i f_i(x) \le 1/t$；

3. **解释**：乘子就是影子价格。

13.2 KKT 条件（讲义 5.18–5.21）

对标准形式问题（f_i, h_i 可微，f_i 凸、h_i 仿射），若强对偶成立，则 $x^\star, (\lambda^\star, \nu^\star)$ 满足：

原始可行：	$f_i(x^\star) \le 0, \quad h_i(x^\star) = 0$
对偶可行：	$\lambda^\star \succeq 0$
平稳性（**stationarity**）：	$\nabla f_0(x^\star) + \sum_i \lambda_i^\star \nabla f_i(x^\star) + \sum_i \nu_i^\star \nabla h_i(x^\star) = 0$
互补松弛（**complementary slackness**）：	$\lambda_i^\star f_i(x^\star) = 0, \quad i = 1, \dots, m$

互补松弛的三种读法：

- 若 $\lambda_i^\star > 0$，则约束 i 活跃（$f_i(x^\star) = 0$）；
- 若 $f_i(x^\star) < 0$，则 $\lambda_i^\star = 0$（不活跃的约束不起作用）；
- 二者可以都不成立吗？不能——这就是"互补"的含义。

13.3 充分性与必要性

情形	KKT 的地位
凸问题 + Slater	KKT 是**充要**条件：任何满足 KKT 的点都是最优对
凸问题，Slater 不成立	KKT 仍是**必要**条件（在约束品性成立时），但不保证对偶最优取到
非凸问题	KKT 只是**必要**条件；满足 KKT 的点可能是局部最优或鞍点

证明思路（充分性）：由 f_i 凸、$\lambda_i^\star \ge 0$ 得 $L(x, \lambda^\star, \nu^\star)$ 是 x 的凸函数；平稳性说明 $x^\star$ 是其极小点，故 $L(x^\star, \cdot) \le L(x, \cdot)$ 对所有 x。再用互补松弛与可行性把 $L(x^\star, \cdot)$ 压到 $f_0(x^\star)$、把 $L(x, \cdot)$ 抬到 $f_0(x)$，得 $f_0(x^\star) \le f_0(x)$。□

13.4 敏感性：乘子就是价格（讲义 5.23–5.25）

考虑扰动问题：$f_i(x) \le u_i$，$h_i(x) = v_i$，最优值记 $p^\star(u, v)$。

全局敏感性（只需弱对偶，不需可微）：

$$p^\star(u, v) \;\ge\; p^\star(0, 0) - u^\top \lambda^\star - v^\top \nu^\star.$$

局部敏感性（若 $p^\star$ 在 $(0, 0)$ 可微）：

$$\lambda_i^\star = -\frac{\partial p^\star}{\partial u_i}(0, 0), \qquad \nu_i^\star = -\frac{\partial p^\star}{\partial v_i}(0, 0).$$

读法：把约束 i 放松一单位（$u_i = 1$），最优值**最多**下降 $\lambda_i^\star$。所以：

- $\lambda_i^\star$ 大：这条约束很"贵"，值得投入资源去放松它（加预算、加带宽）；
- $\lambda_i^\star = 0$：这条约束不紧，放松它没有收益。

> **这就是"影子价格"（shadow price）**。在电力市场、云资源定价、生产计划里，$\lambda^\star$ 直接就是报价。第 20 章的应用会反复用到这个解释。

13.5 例题

例 13.1（最大熵 → 均匀分布） $\min \sum_i x_i \log x_i$ s.t. $\mathbf{1}^\top x = 1$，$x \succeq 0$。

KKT：$L = \sum x_i \log x_i + \nu(\mathbf{1}^\top x - 1) - \sum \lambda_i x_i$。平稳性：$\log x_i + 1 + \nu - \lambda_i = 0$。若 $x_i > 0$ 则 $\lambda_i = 0$，得 $x_i = e^{-\nu - 1}$（对所有正分量相同）。由 $\sum x_i = 1$ 得 $x_i = 1/n$（全正，故 $\lambda = 0$ 全部成立）。□

例 13.2（不等式 QP 的显式解） $\min \frac{1}{2} x^\top Q x$ s.t. $a^\top x \le b$，$Q \succ 0$。

- 若 $a^\top Q^{-1} a$ 足够小使无约束解 $x = 0$ 可行（即 $0 \le b$），则 $\lambda^\star = 0$，$x^\star = 0$；
- 否则约束活跃，$\lambda^\star = \dfrac{b}{a^\top Q^{-1} a}$（由 $a^\top x^\star = b$ 与 $x^\star = -\lambda Q^{-1} a$ 联立），$x^\star = -\dfrac{b}{a^\top Q^{-1} a} Q^{-1} a$。

这个两分支结构（活跃/不活跃）就是**有效集方法**（active-set method）的雏形：猜一个活跃集，解等式约束子问题，检查乘子符号，不对就换集合。

例 13.3（敏感性的一次实操） 生产计划：$\max\ 3x_1 + 2x_2$ s.t. $x_1 + x_2 \le 4$（工时），$x_1 + 3x_2 \le 6$（原料），$x \succeq 0$。解 LP 得 $x^\star = (3, 1)$，$p^\star = 11$。工时约束的乘子 $\lambda_1^\star = 1.25$，原料约束 $\lambda_2^\star = 0.75$。**含义**：多一小时工时，利润最多增加 1.25；多一单位原料，最多增加 0.75。若加班成本是 1 元/小时，值得加班；若原料涨价 1 元/单位，不值得多买。

13.6 择一定理（theorems of alternatives）

讲义第 5.8 节给出 Farkas 引理等"二者必居其一"的结论，其价值在于**不可行性证书**：

> 系统 $\{Ax \preceq b\}$ 与 $\{\lambda \succeq 0,\ A^\top \lambda = 0,\ b^\top \lambda < 0\}$ 恰有一个可行。

所以当 solver 报 "infeasible" 时，理论上存在一个 λ 作为**证书**。实践中 solver 返回的 `prob.constraints` 对偶值若满足上述关系，就可以确信不可行（第 18 章的 Phase I 用的就是这个思想）。

13.7 常见误区

1. **"KKT 满足就是全局最优"** —— 只在凸问题成立。非凸时可能是鞍点（例：$\min x^3$ 在 $x = 0$ 处梯度为零）。

2. **"等式约束的乘子必须非负"** —— 错。ν 自由（因为 $h_i = 0$ 可写成 $h_i \le 0$ 与 $-h_i \le 0$，两个乘子合并后符号任意）。
3. **"互补松弛是 $\lambda_i + f_i = 0$"** —— 是**乘积**为零：$\lambda_i f_i = 0$。
4. **"敏感性公式给出精确值"** —— 只在可微且扰动足够小时是**局部**近似。约束结构改变（活跃集变化）后公式失效。

第 14 章 近似与拟合：ℓ_p、正则化与鲁棒性

14.1 动机

"拟合一条曲线"听起来像统计学，实际上是**选择范数**的工程决策。范数决定了：异常值有多大影响、解是否稀疏、问题属于 LP 还是 QP。教材第 6 章把这件事系统化：**逼近（approximation）→ 正则化（regularization）→ 鲁棒化（robustness）** 三层递进。

14.2 范数逼近

基本形式：$\min_x \|Ax - b\|$，$\|\cdot\|$ 是 $\mathbb{R}^m$ 上任一范数。

范数	等价形式	解的性质	求解器
ℓ_2	最小二乘	光滑、解析解 $A^\dagger b$	QR / Cholesky
ℓ_1	LP：$\min \mathbf{1}^\top t$ s.t. $-t \preceq Ax - b \preceq t$	**对异常值稳健**，残差稀疏	LP
ℓ_∞	LP：$\min t$ s.t. $-\mathbf{1}t \preceq Ax - b \preceq \mathbf{1}t$	只看最大偏差（Chebyshev 逼近）	LP
Huber	QP/SOCP	小残差二次、大残差线性	QP

罚函数（penalty）视角：$\min \sum_i \phi(r_i)$，$r = Ax - b$。

- $\phi(u) = u^2$：最小二乘；
- $\phi(u) = |u|$：ℓ_1；
- Huber：$\phi(u) = u^2$（$|u| \le M$），$2M|u| - M^2$（$|u| > M$）——在 M 处一阶连续可微，是"既想要二次的平滑、又想要线性的稳健"的标准折中；
- deadzone-linear：$\phi(u) = \max(0, |u| - a)$——允许 a 以内的误差完全不计。

14.3 正则化：从 Tikhonov 到 Lasso

双目标：$\min\ (\|Ax - b\|, \|x\|)$（关于 $\mathbb{R}^2_+$ 的 Pareto 最优）。 **标量化**：$\min \|Ax - b\| + \gamma\|x\|$ 或 $\min \|Ax - b\|^2 + \delta\|x\|^2$。

正则项	名称	解的形式	效果
$\|x\|_2^2$	Tikhonov / 岭回归（ridge）	$x^\star = (A^\top A + \delta I)^{-1} A^\top b$	收缩、稳定、处理共线性
$\|x\|_1$	ℓ_1 正则（文献常称 Lasso）	无解析解，软阈值/坐标下降	**稀疏**、变量选择
$\|Dx\|_1$	全变差（TV）	分段常数	去噪保边
$\|x\|_\infty$	—	均匀收缩	少见但可 LP 表达

> **术语说明**：EE364a 讲义把 ℓ_1 正则化称作 "regularized approximation"（6.3 节），"Lasso" 是统计学文献的叫法。两者指同一个问题：$\min \frac{1}{2}\|Ax-b\|_2^2 + \lambda\|x\|_1$。

为什么 ℓ_1 产生稀疏（几何）：ℓ_1 球的"角"在坐标轴上。以 ℓ_1 球为约束去逼近 $\{x : Ax = b\}$，最优点倾向于落在角上——即部分坐标为 0。ℓ_2 球是圆的，没有角，所以只收缩不置零。

14.4 鲁棒逼近（讲义 6.4）

当 A 有误差时，两种建模：

随机（stochastic）：$A = \bar{A} + U$，U 随机，$\min \mathbb{E}\|(A)x - b\|_2^2$。若 $\mathbb{E}U = 0$、$\mathbb{E}[U^\top U]$ 已知，可化为

$$\min \ \|\bar{A}x - b\|_2^2 + \|P^{1/2}x\|_2^2$$

（P 由 U 的二阶矩给出）——**又变回岭回归**！这说明"鲁棒化"与"正则化"在数学上是同一件事的两面。

最坏情况（worst-case）：$A \in \mathcal{A} = \{\bar{A} + U : \|U\|_2 \le \rho\}$，$\min \sup_{A\in\mathcal{A}} \|Ax - b\|_2$。可化为 SOCP：

$$\min \ \|\bar{A}x - b\|_2 + \rho\|x\|_2.$$

这个式子的读法：$\rho\|x\|_2$ 是"为不确定性付的保险费"。ρ 越大，解越"小"（越保守）。

14.5 例题

例 14.1（Huber 拟合 vs 最小二乘） 42 个点、2 个离群点，用仿射模型 $f(t) = \alpha + \beta t$。最小二乘被离群点拉偏；Huber（M 取残差中位数的若干倍）几乎不受影响。**结论**：模型没变、数据没变，只换罚函数，稳健性完全不同。

例 14.2（ℓ_1 vs ℓ_2 的稀疏性） 取 $A \in \mathbb{R}^{100\times 200}$（欠定），真实 x 只有 5 个非零。$\min \|x\|_2$ s.t. $Ax = b$ 给出**稠密**解（所有坐标都非零）；$\min \|x\|_1$ 给出**稀疏**解，且在很多随机模型下能精确恢复支撑集（压缩感知的核心结论）。EE364a 只讲"能解"，恢复条件（RIP 等）属于更专门的课程。

例 14.3（TV 去噪） $\min \frac{1}{2}\|x - y\|_2^2 + \lambda\|Dx\|_1$，$D$ 是一阶差分矩阵。解是**分段常数**信号——它能保留阶跃边缘，而 ℓ_2 平滑会把边缘糊掉。

14.6 常见误区

1. **"最小二乘是唯一选择"** —— 它只在噪声是高斯时是 MLE（第 15 章）。重尾噪声下 ℓ_1 才是 MLE。
2. **"ℓ_1 正则一定给稀疏解"** —— 需要 λ 足够大（超过某个阈值），且设计矩阵列不相关。$\lambda \to 0$ 时解趋于最小二乘（稠密）。
3. **"Huber 是凸的所以好算"** —— 凸但不二次，需 QP/SOCP；直接用 IRLS（迭代重加权最小二乘）也能收敛，但收敛率是线性的。
4. **"鲁棒化一定更差"** —— 在最坏情况模型下它是最优的；在真实分布接近高斯时它确实损失一点效率。这是"最坏情况 vs 平均情况"的经典权衡。

第 15 章 统计估计：MLE、检验与实验设计

15.1 动机

统计建模给出**似然函数**，凸优化负责回答"这个似然能不能可靠地最大化"。这一章的价值在于：它把 CS229 里的 MLE 从"用梯度上升跑一下"升级为"证明它是凸的、写出对偶、判断唯一性"。

15.2 MLE 的凸性判据（讲义 7.2）

给定观测 y、参数 x，**对数似然** $l(x) = \log p_x(y)$。

> **MLE 是凸问题 $\iff$ $l(x)$ 关于 x 凹（对固定的 y）。**

易混点：这与"$p_x(y)$ 关于 y 是对数凹密度"**完全不同**。前者是"参数维度的凹性"，后者是"数据维度的形状"。讲义专门用一句话警告这一点。

噪声模型	负对数似然	等价问题
高斯 $\mathcal{N}(0, \sigma^2)$	$\frac{1}{2\sigma^2}\sum(a_i^\top x - y_i)^2 + \text{const}$	最小二乘（QP）
拉普拉斯（尺度 a）	$\frac{1}{a}\sum\lvert a_i^\top x - y_i\rvert + \text{const}$	ℓ_1 回归（LP）
均匀 $[-a, a]$	0（可行）或 $+\infty$	可行性问题（LP）
逻辑斯蒂（ Bernoulli）	$\sum \log(1 + e^{a_i^\top x + b}) - \sum y_i(a_i^\top x + b)$	逻辑回归（凸，光滑）

逻辑回归为什么凸：$-\log(1 + e^u)$ 关于 u 凹且非降/非增的组合规则给出 l 凹；也可直接算 Hessian $\sum p_i(1 - p_i)a_i a_i^\top \succeq 0$。

15.3 假设检验（讲义 7.3）

似然比检验：$H_0 : x = x_0$ vs $H_1 : x = x_1$，判决规则 $\Lambda(y) = \dfrac{p_{x_1}(y)}{p_{x_0}(y)} \gtrless \eta$。

Chernoff 界：$\mathbb{P}(\text{误判}) \le e^{-\max\{\dots\}}$，其中指数由**矩生成函数**的对数给出：

$$\mathbb{P}(X \ge t) \le \exp\big(-st + \log \mathbb{E} e^{sX}\big), \qquad s > 0.$$

最优检测器设计：给定虚警率上界 α，最小化漏检率。这是个**凸问题**（在随机化检测器的单纯形上），因为似然比的对数是线性的、约束是线性的。

> 这一节的实用价值：它告诉你"设计一个检测器"可以写成凸问题，而不是只能凭直觉调阈值。

15.4 实验设计（讲义 7.5）

场景：m 次测量 $y_i = a_i^\top x + v_i$，要选 a_i（实验条件）以最小化参数估计的方差。

估计的协方差 $\Sigma = \big(\sum_i a_i a_i^\top\big)^{-1}$（高斯噪声、单位方差）。三种经典准则：

准则	目标	凸性
A–最优	$\min \operatorname{tr} \Sigma$	凸（$\operatorname{tr}((\sum a_i a_i^\top)^{-1})$ 关于 $\sum a_i a_i^\top$ 凸）
D–最优	$\min \log\det \Sigma$	凸（$\log\det$ 凹，取负）
E–最优	$\min \lambda_{\max}(\Sigma)$	凸（SDP）

关键技巧：令 $X = \sum_i \lambda_i a_i a_i^\top$，约束是"$X$ 在一个半正定锥的可表示子集里"，然后用 SDP 求解。**实验设计是 SDP 在统计学里最漂亮的应用。**

15.5 例题

例 15.1（ logistic 回归的 MLE 是凸的，但可能无解） 若数据**完全可分**（存在超平面把两类完全分开），MLE 的 $\|x\| \to \infty$，最优值取不到。这不是数值问题，是**模型问题**——需要加 ℓ_2 正则（等价于高斯先验的 MAP）。

例 15.2（Laplace 噪声 → 中位数） 一维情形 $y_i = x + v_i$，$v_i \sim$ Laplace。MLE 是 $\min \sum |y_i - x|$，解是**样本中位数**。高斯噪声下解是样本均值。**一个范数的选择，对应一个统计量的选择。**

例 15.3（Poisson 回归） $y_i \sim \mathrm{Poisson}(\exp(a_i^\top x))$。负对数似然 $\sum \exp(a_i^\top x) - \sum y_i a_i^\top x$ 是凸的（指数凸 + 线性）。所以计数数据的回归也是凸问题。

15.6 常见误区

1. **"所有 MLE 都是凸的"** —— 错。混合模型、含隐变量的模型（如 GMM）的似然通常非凸，EM 只能找局部最优。
2. **"似然凹 ⇒ 最优解唯一"** —— 需要**严格**凹。逻辑回归在可分数据上凹但不严格，解不唯一甚至不存在。
3. **"检验问题总是凸的"** —— 单参数简单假设下是；复合假设 + 非凸损失时不是。
4. **"D-最优 = 最小化方差"** —— D-最优最小化**行列式**（几何平均意义上的体积），不是迹。两者的最优设计一般不同。

第 16 章 几何问题：椭球、中心、分类与选址

16.1 动机

几何直觉是凸优化最好的应用场：几乎所有"用简单形状包住复杂形状"的问题都是凸的。这一章也是 SVM 的正式出场（讲义 8.6）。

16.2 极值体积椭球（讲义 8.2–8.4）

Löwner–John 椭球（最小体积外包椭球）：给定凸集 C，找 $E \supseteq C$ 使体积最小。参数化 $E = \{x \mid \|Ax+b\|_2 \le 1\}$，$A \succ 0$：

$$\min \ \log\det A^{-1} \quad \text{s.t.} \quad \sup_{x \in C} \|Ax+b\|_2 \le 1.$$

对有限点集 $C = \{x_1, \dots, x_m\}$，约束变成 $\|Ax_i + b\|_2 \le 1$（m 个 SOC 约束）——**凸问题**。

最大内切椭球：$E = \{Bu + d \mid \|u\|_2 \le 1\} \subseteq C$，$\max \log\det B$。对多面体 $C = \{x \mid a_i^\top x \le b_i\}$：

$$\|Ba_i\|_2 + a_i^\top d \le b_i, \qquad i = 1, \dots, m.$$

推导：$\sup_{\|u\|\le 1} a_i^\top (Bu + d) = \|B^\top a_i\|_2 + a_i^\top d = \|Ba_i\|_2 + a_i^\top d$（$B$ 对称）。

Löwner–John 定理（讲义 8.4）：n 维凸体 C 的最小体积外包椭球满足 $E \subseteq nC$（即放大 n 倍可覆盖）。这条定理给出了"用椭球近似凸体"的最坏情况保证。

16.3 中心（讲义 8.5）

中心	定义	求解
Chebyshev 中心	最大内切球的球心	LP：$\max r$ s.t. $a_i^\top x_c + r\|a_i\|_2 \le b_i$

中心	定义	求解
最大体积内切椭球中心	上述 $d^\star$	凸问题（SOCP/锥）
解析中心（analytic center）	$\max \sum \log(b_i - a_i^\top x)$	无约束凸问题（障碍函数）

为什么关心中心：内点法的初始点、切平面法的"最深切"方向、VLSI 布局的对称点，都需要一个"在集合内部且远离边界"的点。Chebyshev 中心是其中最便宜的（一个 LP）。

16.4 分类与 SVM（讲义 8.6）

硬间隔 SVM：给定线性可分数据 (x_i, y_i)，$y_i \in \{-1, +1\}$，找超平面 $w^\top x + b = 0$ 使间隔最大：

$$\min \ \tfrac{1}{2}\|w\|_2^2 \quad \text{s.t.} \quad y_i(w^\top x_i + b) \geq 1,\ i = 1, \dots, m.$$

这是 QP（$P = I$，线性约束）。**间隔 = $2/\|w\|_2$**，最大化间隔 = 最小化 $\|w\|_2$。

软间隔 SVM：允许违反，引入松弛 $\xi_i \geq 0$：

$$\min \ \tfrac{1}{2}\|w\|_2^2 + \gamma \sum_i \xi_i \quad \text{s.t.} \quad y_i(w^\top x_i + b) \geq 1 - \xi_i,\ \xi_i \geq 0.$$

对偶（第 12 章）给出只依赖**内积**的形式，于是可以用核函数 $K(x_i, x_j)$ 替换 $x_i^\top x_j$——这就是"核技巧"的全部数学内容。**注意**：核化后的问题是 QP，规模 m（样本数），不是 n（特征数）；m 很大时要用分解算法（SMO）。

罚项的选择：把 $\gamma \sum \xi_i$ 换成 $\gamma \sum \xi_i^2$（并用 $\xi_i \geq 0$）得到另一个凸 QP——两者的对偶不同，ℓ_1 版本的解更稀疏（支持向量更少）。**两者都是凸的**，选择取决于你要稀疏还是平滑。

16.5 选址（讲义 8.7）

m 个需求点 p_i，选一个设施位置 x 使总距离最小：

距离	目标	问题类型	解的性质
欧氏 $\|x - p_i\|_2$	$\sum \|x - p_i\|_2$	SOCP	几何中位数（Weber 点）
平方 $\|x - p_i\|_2^2$	$\sum \|x - p_i\|_2^2$	QP	重心（解析解）
ℓ_1	$\sum_i \sum_j \lvert x_j - p_{ij}\rvert$	LP	逐坐标中位数
ℓ_∞	$\max_i \|x - p_i\|_\infty$	LP	最小包围盒中心

这张表是"范数选择 = 建模决策"的最佳例证：同一个物理问题，四种范数给出四个不同的答案，且都能高效求解。

16.6 例题

例 16.1（Chebyshev 中心的对偶解释） 对多面体 P，Chebyshev 中心的 LP 对偶给出"最紧的 $n+1$ 个约束"的凸组合——几何上，最大的内切球由**恰好 $n+1$ 个面**同时接触（一般位置下）。这解释了几何直觉与代数对偶的一致性。

例 16.2（硬间隔 vs 软间隔） 若数据线性可分，硬间隔有解；若不可分，硬间隔**不可行**（solver 报 infeasible）。软间隔永远可行（取 ξ 足够大），代价是 γ 的调节。**工程上永远用软间隔**——这是"模型必须对数据的不完美有容忍度"的数学表达。

16.7 常见误区

1. **"最小体积椭球是 SDP"** —— 它是**凸问题**但目标含 $\log\det$，严格说属于"可解的凸锥问题"，CVXPY 里用 `cp.log_det` 直接写即可（solver 内部转成锥形式）。
2. **"SVM 的间隔是 $\|w\|$"** —— 是 $2/\|w\|$。约束 $y_i(w^\top x_i + b) \geq 1$ 把两个支撑超平面的距离固定为 $2/\|w\|$。
3. **"核化后仍然解 n 维问题"** —— 核化后变量是 m 维的 α（样本权重），n 只通过核矩阵出现。
4. **"ℓ_∞ 选址就是取平均"** —— 它最小化**最大**距离，解是最小包围盒的中心，与平均无关。

第 17 章 无约束极小化：梯度法与牛顿法

17.1 动机

第 17、18 章回答"怎么真的算出来"。核心结论只有一句：**牛顿法在凸问题上既快又可靠，内点法 = 牛顿法 + 障碍函数**。但在 n 很大或 Hessian 太贵时，梯度法/最速下降仍是唯一选择。

17.2 三个基本假设

假设	含义	作用
凸 + 二次可微	$\nabla^2 f(x) \succeq 0$	局部即全局
m–强凸	$\nabla^2 f(x) \succeq mI$	唯一解；梯度法线性收敛
L–光滑	$\|\nabla^2 f(x) - \nabla^2 f(y)\|_2 \leq L\|x-y\|_2$	保证步长选择有效；牛顿法二次收敛

条件数 $\kappa = L/m$ 是"问题有多难"的度量。$\kappa = 1$ 时梯度法一步到位；$\kappa = 10^6$ 时梯度法要 10^6 量级的迭代，牛顿法只要几十步。

17.3 梯度下降与步长

$$x^{(k+1)} = x^{(k)} - \alpha_k \nabla f(x^{(k)})$$

回溯线搜索（backtracking line search，Armijo 条件）：

```
给定 x, 梯度 g, 参数 a in (0,0.5), b in (0,1)
t = 1
while f(x - t*g) > f(x) - a*t*||g||^2:
    t = b*t
return t
```

收敛率（讲义 9.3）：

- 仅 L–光滑：$f(x^{(k)}) - p^\star \le \dfrac{L\|x^{(0)} - x^\star\|_2^2}{2k}$，即 $O(1/k)$，达到 ϵ 精度需 $O(1/\epsilon)$ 步；
- m–强凸 + L–光滑：$f(x^{(k)}) - p^\star \le c^k\big(f(x^{(0)}) - p^\star\big)$，$c = 1 - m/L$（精确线搜索下约 $1 - \kappa^{-1}$），即**线性收敛**，$O(\kappa \log(1/\epsilon))$ 步。

17.4 最速下降（steepest descent）

梯度法其实是"在 ℓ_2 范数下的最速下降"。换一个范数，方向就变：

$$\Delta x_{\text{sd}} = \arg\min\{\nabla f(x)^\top v \mid \|v\| = 1\}$$

- $\|\cdot\|_2$：$\Delta x = -\nabla f / \|\nabla f\|_2$（就是梯度法）；
- $\|\cdot\|_1$：沿**最违反的坐标**走（坐标下降的味道）；
- 二次范数 $\|v\|_P$：$\Delta x = -P^{-1}\nabla f$——**牛顿法就是取 $P = \nabla^2 f(x)$ 的最速下降**。

这个视角极其重要：牛顿法不是"另一个算法"，而是"用 Hessian 定义了正确的几何"。条件数问题本质上是"欧氏几何与问题几何不匹配"。

17.5 牛顿法

牛顿步：解 $\nabla^2 f(x)\Delta x_{\text{nt}} = -\nabla f(x)$，更新 $x^+ = x + t\Delta x_{\text{nt}}$。

牛顿减量（Newton decrement）：

$$\lambda(x) = \big(\nabla f(x)^\top \nabla^2 f(x)^{-1} \nabla f(x)\big)^{1/2}$$

性质：

- $\lambda(x)^2/2$ 是 $f(x) - \inf_y \hat f(y)$ 的估计（$\hat f$ 是二次近似）；
- **停止准则**：$\lambda(x)^2/2 \le \epsilon$；

- 牛顿步在 Hessian 范数下的长度就是 $\lambda(x)$。

收敛性（讲义 9.25）：

- **阻尼牛顿阶段**（$\|\nabla f\|_2 \geq \eta$）：每步至少下降 γ，最多 $(f(x^{(0)}) - p^\star)/\gamma$ 步；
- **二次收敛阶段**（$\|\nabla f\|_2 < \eta$）：步长恒为 1，误差按平方缩小——**有效数字每步翻倍**。

自和谐（self-concordance）：$|f'''(x)| \leq 2f''(x)^{3/2}$。它的价值是给出**不依赖未知常数**、**仿射不变**的复杂度界，是内点法多项式时间证明的基础（第 18 章）。

17.6 例题

例 17.1（logistic 回归的牛顿法） $f(w) = \sum_i \log(1 + e^{-y_i w^\top x_i}) + \frac{\gamma}{2}\|w\|_2^2$。

- 梯度：$-\sum_i y_i x_i \sigma(-y_i w^\top x_i)$，$\sigma(u) = 1/(1+e^{-u})$；
- Hessian：$\sum_i \sigma_i(1-\sigma_i) x_i x_i^\top + \gamma I \succ 0$（$\gamma > 0$ 保证强凸）；
- 每次迭代解一个 $n \times n$ 线性系统，$O(n^3)$；$n = 10^3$ 时毫秒级，$n = 10^6$ 时必须用 L-BFGS 或随机方法。

例 17.2（为什么梯度法在病态问题上慢） $f(x) = \frac{1}{2}(x_1^2 + \kappa x_2^2)$，$\kappa = 10^4$。梯度法的收敛率 $1 - 1/\kappa$，需约 $10^4 \log(1/\epsilon)$ 步；牛顿法 1 步（二次函数）。**这不是常数因子的差距，是量级的差距。**

17.7 常见误区

1. **"牛顿法总是比梯度法快"** —— 每步贵 $O(n^3)$ vs $O(n)$。$n = 10^5$ 时一次牛顿步可能比一万次梯度步还贵。
2. **"牛顿法有全局收敛保证"** —— 只有加**线搜索/信赖域**后才有；裸牛顿法可能发散（尤其起点远离最优）。
3. **"步长取 1 就是牛顿法"** —— 阻尼牛顿法在远离最优时步长会小于 1，这是它能全局收敛的关键。
4. **"收敛率里的 L, m 可以估出来"** —— 一般估不出，所以实践中用回溯线搜索 + 牛顿减量做停止准则，而不是用理论界。

第 18 章 等式约束、内点法与复杂度

18.1 动机

真实问题几乎都有约束。等式约束可以消元或用 KKT 系统处理；不等式约束则需要"把边界变成一道墙"——**障碍函数**（barrier）。内点法的美妙之处在于：它把"组合式"的活跃集选择（2^m 种可能）转化成了**连续路径跟踪**。

18.2 等式约束牛顿法（讲义 10.1–10.3）

$$\min f(x) \quad \text{s.t.} \quad Ax = b$$

牛顿步由 KKT 系统给出：

$$\begin{bmatrix} \nabla^2 f(x) & A^\top \\ A & 0 \end{bmatrix} \begin{bmatrix} \Delta x_{\text{nt}} \\ w \end{bmatrix} = \begin{bmatrix} -\nabla f(x) \\ 0 \end{bmatrix}$$

两种解法：

方法	做法	代价
消元法	取 A 的零空间基 F（$AF = 0$），令 $\Delta x = F\Delta x_f$，化归无约束	需 F，$O(n^3)$ 一次 + 每步 $O(n_f^3)$
KKT 直接解	解 $(n+p)\times(n+p)$ 的对称不定系统	稀疏时用 LDL$^\intercal$，可利用结构

不可行起点牛顿法（infeasible start）：允许 $Ax \neq b$，用残差 $r = Ax - b$ 驱动，$\|r\|$ 单调下降。优点：不需要初始可行点；缺点：中间迭代不可行，某些应用（如实时控制）不能接受。

残差与步长的关系：$r^+ = r + A\Delta x_{\text{nt}} = r$（若 Δx 来自上式）。所以不可行起点法要用**修正的**系统：

$$\begin{bmatrix} \nabla^2 f(x) & A^\top \\ A & 0 \end{bmatrix} \begin{bmatrix} \Delta x \\ w \end{bmatrix} = \begin{bmatrix} -\nabla f(x) \\ -r \end{bmatrix}$$

此时 $r^+ = (1-t)r$，线性收敛到可行。

18.3 对数障碍与中心路径（讲义 11.2–11.4）

$$\min f_0(x) \quad \text{s.t.} \quad f_i(x) \le 0,\ Ax = b$$

用**对数障碍**近似指示函数 $I_-(u)$：

$$\phi(x) = -\sum_{i=1}^{m} \log\big(-f_i(x)\big), \qquad \min\ t f_0(x) + \phi(x) \quad \text{s.t.} \quad Ax = b$$

参数 $t > 0$ 控制"墙"的陡峭程度。t 越大，解越接近真正的最优。

中心路径：$x^\star(t)$，$t > 0$。三个关键事实：

1. $x^\star(t)$ 对每个 t 唯一（$tf_0 + \phi$ 严格凸）；
2. **对偶间隙恰为 m/t**：$f_0(x^\star(t)) - p^\star \le m/t$；
3. 路径是光滑曲线，$t \to \infty$ 时趋于最优解。

> **m/t 这个数是内点法的灵魂**：它给了**可计算的停止准则**——不需要知道 $p^\star$，只需 $m/t < \epsilon$。这是内点法优于单纯形法的理论根源之一。

18.4 障碍法（讲义 11.3）

```
给定严格可行 x, t := t0 > 0, mu > 1, 容差 eps
repeat
  1. 中心化：从 x 出发，用牛顿法最小化 t*f0 + phi，s.t. Ax=b
  2. 更新：x := x*(t)
  3. 停止：若 m/t < eps 则退出
  4. 增大：t := mu * t
```

参数选择的经验（讲义 11.3 的数值实验）：

参数	常用值	影响
μ	10–20（实用），理论分析常用 $1+1/\sqrt{m}$	μ 大 → 外层少、内层多；总步数对 μ 不敏感（U 形曲线）
$t^{(0)}$	1 或按 m/gap 估	太小则前期浪费，太大则首次中心化困难
停止	$m/t < \epsilon$	直接控制绝对精度

18.5 复杂度（讲义 11.25–11.30）

外层迭代次数：

$$\left\lceil \frac{\log\left(m/(t^{(0)}\epsilon)\right)}{\log \mu} \right\rceil$$

内层（每次中心化的牛顿步数，用自和谐分析）：

$$\#\text{Newton} \;\le\; \frac{m(\mu - 1 - \log\mu)}{\gamma} + c$$

总步数：

$$N \le \left\lceil \frac{\log(m/(t^{(0)}\epsilon))}{\log \mu} \right\rceil \left(\frac{m(\mu - 1 - \log\mu)}{\gamma} + c \right)$$

其中 γ, c 只依赖牛顿算法的参数（线搜索常数），**不依赖问题数据**。这就是"多项式时间"的确切含义：$N = O(\sqrt{m}\log(1/\epsilon))$ 量级（对 μ 优化后）。

实践数字（讲义 12.3）：内点法通常 **20–80 步**收敛。理论与实践的差距来自最坏情况界极保守。

18.6 Phase I：找初始可行点

障碍法需要**严格可行**起点。Phase I 的做法：引入 s，

$$\min s \quad \text{s.t.} \quad f_i(x) \le s, \quad Ax = b$$

若最优 $s^\star < 0$，则原问题严格可行；否则不可行（或只有边界可行点）。

18.7 广义不等式（讲义 11.6）

对锥约束 $f_i(x) \preceq_{K_i} 0$，障碍函数换成**锥的对数障碍**：

锥	障碍函数
$\mathbb{R}^m_+$	$-\sum \log(-u_i)$
$\mathbb{S}^m_+$	$-\log\det(-U)$
二阶锥 $\mathcal{Q}^m$	$-\log(t^2 - \|u\|_2^2)$

参数自和谐 ν：LP 是 m，SDP 是 m（矩阵维数），SOCP 是 m（锥的维数）。对偶间隙变成 ν/t。这解释了"为什么 SDP 每步都贵"：ν 更大，需要更多外层迭代。

18.8 例题

例 18.1（LP 的障碍法手算） $\min c^\top x$ s.t. $Ax \preceq b$。障碍问题 $\min tc^\top x - \sum \log(b_i - a_i^\top x)$。一阶条件：

$$tc - \sum_i \frac{a_i}{b_i - a_i^\top x} = 0 \implies tc = A^\top \lambda, \quad \lambda_i = \frac{1}{b_i - a_i^\top x} > 0.$$

于是 $x^\star(t)$ 满足 $A^\top\lambda = tc$ 且 $\lambda_i(b_i - a_i^\top x) = 1$——**互补松弛被"软化"成 $= 1$**。这正是"内点法 = 把互补松弛放松一个 $1/t$"的精确表述。

例 18.2（为什么不能把 t 一开始就设得极大） 若 $t = 10^{12}$，障碍问题的 Hessian 条件数极差（$\sim t$），牛顿法在数值上会失败。**逐步增大 t（warm start）是内点法数值稳定的关键**，也是"路径跟踪"这个名字的由来。

18.9 常见误区

1. **"内点法一定比单纯形法快"** —— 小规模 LP 上单纯形法常常更快；内点法的优势在规模大、稀疏、需要高精度时。
2. **"障碍法不需要可行起点"** —— 需要**严格**可行点。没有就用 Phase I 或不可行起点法。
3. **"m/t 是上界所以取 t 越大越好"** —— 上界是准的，但 t 太大会破坏数值条件（例 18.2）。
4. **"内点法给出精确最优解"** —— 给出的是 ϵ–最优，ϵ 由 m/t 控制。要求精确解（如整数解）必须另做取整/修复。

第 19 章 ADMM 与一阶方法（EE364b 内容，EE364a 不考）

> **章节定位**：ADMM 不在 EE364a 讲义里（讲义 12.5 把 distributed/一阶方法列为 EE364b 内容）。但它在工程实践中的使用频率极高（大规模 Lasso、分布式统计、图像重建），且是"对偶 + 增广"思想最漂亮的落地，故作为扩展章。来源：EE364b ADMM slides。

19.1 动机：为什么要"分而治之"

内点法每步要分解 $n \times n$ 矩阵，代价 $O(n^3)$。当 $n = 10^6$ 且问题有"块结构"（数据分片、多智能体、图上的局部耦合）时，我们宁愿用**很多次便宜的一阶迭代**换一次昂贵的分解。

ADMM 解决的标准形式：

$$\min_{x,z} \; f(x) + g(z) \quad \text{s.t.} \quad Ax + Bz = c$$

其中 f, g 各自"好处理"（f 光滑、g 有简单的近端算子如 ℓ_1 软阈值），但耦合约束让它们不能独立求解。

19.2 增广拉格朗日

普通拉格朗日 L_ρ 加上二次罚：

$$L_\rho(x, z, y) = f(x) + g(z) + y^\top (Ax + Bz - c) + \frac{\rho}{2}\|Ax + Bz - c\|_2^2$$

为什么加二次项：普通对偶上升要求 f, g 严格凸或解唯一，否则会震荡；二次项让增广问题**强凸**，从而对偶上升稳定。代价是 L_ρ 不再对 (x, z) 可分离——ADMM 的解法是**交替**最小化。

19.3 三行迭代（scaled form）

令 $u = y/\rho$（缩放对偶变量），则：

$$\begin{aligned}
x^{(k+1)} &= \arg\min_x \left(f(x) + \frac{\rho}{2}\|Ax + Bz^{(k)} - c + u^{(k)}\|_2^2 \right) \\
z^{(k+1)} &= \arg\min_z \left(g(z) + \frac{\rho}{2}\|Ax^{(k+1)} + Bz - c + u^{(k)}\|_2^2 \right) \\
u^{(k+1)} &= u^{(k)} + Ax^{(k+1)} + Bz^{(k+1)} - c
\end{aligned}$$

三个子问题的性质：

- x–更新：通常是**光滑强凸**问题，用一次牛顿/GD 或闭式解；
- z–更新：是 g 的**近端算子**（proximal operator）。$g = \lambda\|\cdot\|_1$ 时就是软阈值 $S_{\lambda/\rho}$；

- u–更新：对偶上升，累积原始残差。

19.4 收敛性与停止准则

定理（凸、f, g 闭真、ADMM 有解）：$x^{(k)} \to x^\star$、$z^{(k)} \to z^\star$、$y^{(k)} \to y^\star$。收敛率一般无保证（可能很慢），但实践良好。

两个残差：

$$r^{(k)} = Ax^{(k)} + Bz^{(k)} - c \ \text{（原始残差）}, \qquad s^{(k)} = \rho A^\top B(z^{(k)} - z^{(k-1)}) \ \text{（对偶残差）}$$

停止准则：$\|r^{(k)}\|_2 \le \epsilon^{\text{pri}}$ 且 $\|s^{(k)}\|_2 \le \epsilon^{\text{dual}}$，其中

$$\epsilon^{\text{pri}} = \sqrt{n}\,\epsilon^{\text{abs}} + \epsilon^{\text{rel}} \max\{\|Ax^{(k)}\|, \|Bz^{(k)}\|, \|c\|\}$$

（对偶阈值类似）。这是 Boyd 等人 2011 年综述里的标准写法。

19.5 ρ 的调节（实践中最重要的事）

现象	诊断	调整
原始残差大、对偶残差小	迭代"不够快地把 $Ax + Bz$ 拉回 c"	增大 ρ
对偶残差大、原始残差小	对偶变量更新太慢	减小 ρ
两者都大	问题尺度没做好	先归一化数据

自适应 ρ：每若干步检查 $\|r\|/\|s\|$，若比值 > 10 则 $\rho \leftarrow 2\rho$（同时 $u \leftarrow u/2$），若 < 0.1 则 $\rho \leftarrow \rho/2$（$u \leftarrow 2u$）。这是工程上的默认做法。

19.6 例题：ADMM 解 Lasso

$$\min_x \ \tfrac{1}{2}\|Ax - b\|_2^2 + \lambda\|x\|_1 \iff \min_{x,z} \ \tfrac{1}{2}\|Ax - b\|_2^2 + \lambda\|z\|_1 \quad \text{s.t.} \quad x - z = 0$$

- x–更新：$\min \frac{1}{2}\|Ax - b\|_2^2 + \frac{\rho}{2}\|x - z + u\|_2^2$，闭式解 $(A^\top A + \rho I)^{-1}(A^\top b + \rho(z - u))$。**关键**：$A^\top A + \rho I$ 只分解一次，之后每步只是回代。
- z–更新：$S_{\lambda/\rho}(x + u)$，逐元素，$O(n)$。
- u–更新：$u \mathrel{+}= x - z$。

这个结构解释了 ADMM 为何适合大规模问题：**贵的分解只做一次**，之后每步 $O(n)$ 或 $O(nnz(A))$。

19.7 与其他方法的关系（一张图看清）

```
对偶上升   ──加二次罚──▶  增广拉格朗日   ──交替最小化──▶  ADMM
   │                          │
   │                          └── 乘子法（method of multipliers，联合最小化）
   │
次梯度法（第 7 章）

近端梯度 / ISTA ──加速──▶ FISTA（Nesterov 动量，O(1/k^2)）
```

- **近端梯度**（proximal gradient）：$\min f(x)+g(x)$，f 光滑、g 有近端算子。迭代 $x^+ \leftarrow \mathbf{prox}_{\alpha g}(x-\alpha\nabla f(x))$。
- **ADMM vs 近端梯度**：ADMM 处理"f 与 g 通过线性约束耦合"，近端梯度处理"$f+g$ 直接相加"。前者适合分布式，后者适合单机。

19.8 常见误区

1. **"ADMM 比内点法精度高"** —— 反了。ADMM typically 只到 $10^{-4}\sim 10^{-6}$ 的相对精度；高精度要用内点法或精化步骤。
2. **"ρ 有理论最优值"** —— 没有通用公式，只能自适应或网格搜索。
3. **"ADMM 对非凸问题也收敛"** —— 只在很弱的意义上（收敛到稳定点），不保证全局最优。
4. **"交替最小化 = 联合最小化"** —— 不等价。ADMM 收敛的是交替版本；联合版本（乘子法）每步更贵但收敛更快。

第 20 章 应用专题：SVM、Lasso、GP、控制与电路

20.1 动机

这一章把前面所有零件装成机器。选这五个应用是有理由的：它们分别代表了**分类（QP/SOCP）**、**稀疏估计（LP/QP + 一阶算法）**、**工程设计的对数变换（GP）**、**系统约束（LMI/SDP）**、**物理结构的凸化（GP/SDP）**。

20.2 SVM：从几何到对偶

原始问题（软间隔）：

$$\min_{w,b,\xi}\ \tfrac{1}{2}\|w\|_2^2+\gamma \mathbf{1}^\top\xi \quad \text{s.t.}\quad y_i(w^\top x_i+b)\ge 1-\xi_i,\ \xi_i\ge 0$$

对偶推导要点：对 ξ_i 的不等式用乘子 $\alpha_i \geq 0$，对 $y_i(w^\top x_i + b) - 1 + \xi_i \geq 0$ 用 α_i；消去 w, b, ξ 得

$$\max_{\alpha} \ \mathbf{1}^\top \alpha - \tfrac{1}{2}\alpha^\top Y X X^\top Y \alpha \quad \text{s.t.} \quad 0 \leq \alpha_i \leq \gamma, \ y^\top \alpha = 0$$

三个可读出的结构：

1. 只有 $\alpha_i > 0$ 的样本（**支持向量**）影响解；
2. $w = \sum_i \alpha_i y_i x_i$——解是样本的线性组合（表示定理）；
3. 目标只含内积 $x_i^\top x_j$ → 换成 $K(x_i, x_j)$ 即得**核 SVM**。

核的选择：线性核（高维稀疏文本）、多项式核、RBF 核（$\exp(-\gamma\|x - x'\|^2)$，万能但需调 γ）。**注意**：核矩阵必须半正定，否则对偶不是凸问题——这是"合法核"的定义。

20.3 Lasso：三种解法与选择

$$\min_x \ \tfrac{1}{2}\|Ax - b\|_2^2 + \lambda \|x\|_1$$

方法	每步代价	适用	精度
坐标下降（coordinate descent）	$O(nnz(A))$	单机、$n \leq 10^5$	高（10^{-10}）
近端梯度 / FISTA	$O(nnz(A))$，需知道 $\|A\|_2^2$	大规模、矩阵–free	中（10^{-4}）
ADMM	一次分解 + $O(nnz)$	分布式、可分片	中
内点法	$O(n^3)$	中小规模、需高精度	高

坐标下降的更新（第 7 章例 7.1 的直接应用）：

$$x_j \leftarrow \frac{S_\lambda\left(\sum_i a_{ij}(b_i - \sum_{k \neq j} a_{ik} x_k)\right)}{\sum_i a_{ij}^2}$$

其中 $S_\lambda(z) = \mathrm{sign}(z)\max\{|z| - \lambda, 0\}$。**注意**：$\lambda$ 的尺度要与 $\sum_i a_{ij}^2$（列的平方和）匹配，否则不同列的收缩强度不一致。

正则化路径（regularization path）：λ 从大到小扫，用 warm start，整条路径的代价约等于求解单点的几倍。这是"用凸优化做模型选择"的标准做法。

20.4 几何规划：电路尺寸与功率控制

例 20.1（VLSI 连线/晶体管尺寸，讲义 `circuits.pdf`） Elmore 延迟模型下，延迟是 RC 树的函数；在 $R \propto 1/W$、$C \propto W$ 的模型里，延迟对 W 是**正项式**，于是"最小化最大延迟 s.t. 面积约束"是 GP。变量替换 $W_i = e^{y_i}$ 后变成凸问题。

例 20.2（无线功率控制） 要求每条链路的 SINR 不低于 γ_i：

$$\frac{G_{ii}p_i}{\sum_{j\neq i}G_{ij}p_j+n_i}\geq\gamma_i \iff p_i\geq\gamma_i G_{ii}^{-1}\Big(\sum_{j\neq i}G_{ij}p_j+n_i\Big)$$

右边是 p 的**正项式**（系数正、指数为正整数），约束可写成 posynomial ≤ 1 的形式——**GP**。最小化总功率 $\sum p_i$ 也是 posynomial。经典结论：可行时存在唯一的**最小功率解**，可用 GP 求出。

> **为什么这类问题"看起来非凸"却可解**：因为变量都是正的、约束是"多项式不等式"。取对数后，乘法变加法、幂变线性——**凸性是被对数变换"藏起来"的**。

20.5 控制：LQR、MPC 与 LMI

（a）无约束 LQR：$\min\sum_t(x_t^\top Qx_t+u_t^\top Ru_t)$ s.t. $x_{t+1}=Ax_t+Bu_t$。这是**无约束 QP**（变量是所有 x_t,u_t），有 Riccati 方程的解析解。EE364a 不推导 Riccati，但要知道它属于 QP。

（b）MPC（模型预测控制）：加上 $u_{\min}\preceq u_t\preceq u_{\max}$、$x_t\in\mathcal{X}$，立刻变成**带约束 QP**（每步在线求解）。这是凸优化在工业界最大规模的应用之一（化工、自动驾驶）。

（c）LMI / Lyapunov：找 $P\succ 0$ 使 $A^\top P+PA\prec 0$（连续时间稳定性）。这是 **LMI 可行性问题**（对 P 线性、半正定约束），可用 SDP 求解。加入性能指标后变成"最小化 γ s.t. LMI"，即 H_∞ 综合。参考 LMI 书（Boyd 等，免费）。

（d）鲁棒控制：不确定参数 $\delta\in\Delta$ 时，要求 LMI 对所有 δ 成立——用"仿射依赖 + 顶点枚举"或"鲁棒 LMI"（引入松弛变量），仍是凸的。

20.6 电路：从 Elmore 延迟到主导时间常数

问题	模型	凸形式
连线尺寸（wire sizing）	Elmore 延迟 = 电阻电容的乘积和	GP
晶体管尺寸	延迟 ≈ 正项式	GP
主导时间常数最小化	$\lambda_{\max}(G^{-1}C)$	SDP（广义特征值最小化）
布局（placement）	二次或 ℓ_1 连线长度	QP / LP

主导时间常数：$C\dot{v}=-G(v-1)$，收敛速度由 $\lambda_{\max}(G^{-1}C)$ 决定。最小化它：$\min t$ s.t. $G^{-1}C\preceq tI$ $\iff$ $C\preceq tG$（$G\succ 0$）——**广义特征值约束，SDP**。

20.7 常见误区

1. **"SVM 的 γ 越大越好"** —— γ 大 → 间隔约束松 → 欠拟合；γ 小 → 过拟合。必须交叉验证。
2. **"Lasso 的 λ 有解析最优值"** —— 没有。用交叉验证、BIC 或稳定性选择。

3. **"GP 只能处理多项式"** —— 处理的是**正系数单项式/正项式**，且变量必须为正。含负系数的问题不是 GP。
4. **"MPC 一定在线可解"** —— 约束多、horizon 长时 QP 会很大；需要显式 MPC（离线算分段仿射律）或 ADMM/一阶方法（嵌入式部署）。

第 21 章 与已有笔记的衔接

动机：这门课的价值只有在接上你已有的知识之后才会显现。18.06 给你矩阵语言，18.100A 给你严谨性，CS229 给你概率建模，CS336 给你优化器的工程直觉——EE364a 是把这四样东西缝起来的那根线。本章逐条列出缝合点，方便复习时跳回去看。

21.1 与 18.06 线性代数：五个直接接口

EE364a 的哪个地方	用到的 18.06 内容	对应笔记位置
半正定锥、$x^\top P x \geq 0$	对称矩阵特征分解、正定性判据	18.06 Lecture 27「正定矩阵与极小值」
最小二乘、伪逆 $A^\dagger b$	投影、正规方程、$A = QR$	同上 Lecture 16–17
最小体积椭球、SVD 低秩近似	$A = U\Sigma V^\top$、奇异值	同上 Lecture 29
KKT 系统的块消去	分块矩阵求逆、Schur 补	同上 Lecture 11（逆矩阵）与 27（Schur 补思想）
核 SVM、特征值阈值化	内积、特征子空间	同上 Lecture 29

一条具体的连接：第 18 章的 KKT 系统

$$\begin{bmatrix} H & A^\top \\ A & 0 \end{bmatrix}$$

在 $H \succ 0$ 时可消去 Δx，得到 $AH^{-1}A^\top w = -AH^{-1}g$——这个 $AH^{-1}A^\top$ 就是 **Schur 补**。18.06 里"分块消元"的技巧在这里变成了"约束优化的一步"。

21.2 与 18.100A 实分析：严谨性的来源

EE364a 的说法	分析学的严格版本	为什么重要
"$p^\star$ 存在"	闭集 + 下有界 + 下半连续 ⇒ 由 Weierstrass 型论证取到极小	决定"最优解"是否有意义
"$\mathbf{int}\,\mathcal{D}$"	拓扑内部；Slater 的加强版用**相对内部 relint**	低维可行集（如只有边界）时不能滥用

EE364a 的说法	分析学的严格版本	为什么重要
"$\sup_x L$"	上确界可能不取到（$\sup \neq \max$）	对偶最优可能不存在
"对偶间隙 ≥ 0"	由 $\inf \sup \geq \sup \inf$ 得到	弱对偶是 min–max 不等式
收敛率 $O(1/k)$	ϵ–N 语言	把"收敛"变成可验证的界

18.100A 笔记 里"$\inf$ 存在但不取到"的例子（如 $\{1/n\}$）与第 2.2 节的 $f_0 = 1/x$ 是同一件事。**建议**：每当你写"最优解存在"时，先问自己"闭吗？有界吗？"

21.3 与 CS229：从概率模型到凸问题

CS229 的主题	EE364a 的升级	笔记位置
线性回归的 MLE → 最小二乘	证明高斯噪声下负对数似然是 QP；Laplace 噪声下变 LP	CS229 L2（MLE）、本笔记第 15.2 节
岭回归 / Lasso	正则化的凸性、稀疏性的几何解释、正则化路径	CS229 L5（正则化）、本笔记第 14.3 节
SVM 的对偶与 KKT	完整推导、Slater 条件、核化的合法性（核矩阵半正定）	CS229 L7（Kernels/SVM）、本笔记第 16.4、20.2 节
EM 的 Jensen 下界	Jensen 不等式是凸性的直接推论；EM 的 M 步常是凸问题	CS229 L8、本笔记第 5.5 节
逻辑回归	凸性证明（Hessian $\succeq 0$）+ 牛顿法实现	CS229 L3、本笔记第 17.6 节

一句话总结这次衔接：CS229 告诉你"为什么用这个损失"，EE364a 告诉你"这个损失对应的优化问题有多难、怎么解、解的性质是什么"。

21.4 与 CS336：优化器视角的对照

CS336 的实践	EE364a 的理论对照	差异的本质
Adam / AdamW	凸情形下有收敛保证的一阶方法（GD/SGD）	深度网络非凸，Adam 的"保证"只是经验性的
weight decay	ℓ_2 正则（Tikhonov）	在凸问题里 weight decay = 强凸化，保证唯一解；在神经网络里它影响的是优化动力学
学习率 warmup / 衰减	步长规则 α_k（第 7.5、17.3 节）	凸问题的步长有理论最优（$1/L$）；非凸只能调

CS336 的实践	EE364a 的理论对照	差异的本质
梯度裁剪	次梯度有界假设 $\|g\| \le G$	收敛界 $RG/\sqrt{k}$ 显式依赖 G——这是裁剪的理论动机之一
混合精度 / 条件数	条件数 $\kappa = L/m$ 决定迭代次数	病态问题在凸与非凸里都难，但凸情形能量化

一个诚实的提醒：EE364a 的收敛率理论**不能**直接搬到 LLM 训练上（非凸、随机、非光滑、大规模）。它的价值是给你"什么情况下优化是可靠的"这一基准，以及读懂优化文献所需的语言。

第 22 章 复习清单与自测题

动机：没有公开作业题与真题（见第 23.5 节），就必须自己出题。本章先给一份能力清单（知道自己会不会），再给 12 道自测题（知道自己差在哪）。建议先合上答案做一遍，再对照。

22.1 能力清单（能打勾才算学会）

#	能力	对应章节	自检方式
1	给定集合，判断是否凸、是否锥	3	用定义做两点的凸组合
2	写出 $\mathbb{S}^n_+$ 的凸性证明	3.4	一行 $z^\top(\theta X + (1-\theta)Y)z$
3	用保凸运算"造"出给定可行域	4.2	说出用了哪几条运算
4	判断一个函数凸/凹/都不是	5	二阶条件 + 复合规则
5	默写共轭函数表	6.3	遮住右列自测
6	把问题写成 LP/QP/SOCP/SDP	9	上境图 + 松弛变量
7	判断 DCP 合法性并改写	10	手算曲率
8	写出对偶函数并化简	12	先直接求 inf，再用共轭表验算
9	验证 KKT、解释乘子	13	检查四条 + 敏感性公式
10	判断强对偶是否成立	12.3	Slater / LP / QP 三种情形
11	设计松弛并说明下界	11	$\hat{h} \le h$、$\hat{C} \supseteq C$
12	手推牛顿步与牛顿减量	17.5	解 $H\Delta x = -g$
13	写出障碍法的对偶间隙与停止准则	18.3	$m/t < \epsilon$
14	说出梯度法/牛顿法/内点法/ADMM 的适用边界	17–19	看规模、精度、结构

22.2 自测题（12 题，答案在后）

Q1. $f(x,y)=x^2/y$，$\operatorname{dom} f=\{(x,y)\mid y>0\}$。判断凸性并说明理由。

Q2. 集合 $S=\{x\in\mathbb{R}^2\mid x_1^2+x_1x_2+x_2^2\le 1\}$ 是凸的吗?

Q3. 写出标准形 LP $\min c^\top x$ s.t. $Ax=b,\ x\succeq 0$ 的 Lagrange 对偶问题，并说明对偶变量的符号约束。

Q4. 问题 $\min x_1^2+x_2^2$ s.t. $x_1+x_2\ge 2$ 的强对偶是否成立？乘子是多少？它的经济学解释是什么?

Q5. 为什么 $x^2=1$ 不能写成凸约束？如果一定要在凸优化框架里处理，怎么办?

Q6. 解释为什么 $\min\|x\|_1$ s.t. $Ax=b$ 倾向于给出稀疏解（用几何语言，不用代数）。

Q7. 牛顿法在什么条件下二次收敛？为什么远离最优时不能直接用步长 1?

Q8. 内点法的对偶间隙为什么恰好是 m/t？这个结论的实用价值是什么?

Q9. 写出多面体 $P=\{x\mid a_i^\top x\le b_i,\ i=1..m\}$ 的 Chebyshev 中心的优化问题，并说明它属于哪一类。

Q10. $f(x)=\log\sum_{i=1}^n e^{x_i}$ 的共轭函数是什么？由此说明它与 softmax 的关系。

Q11. 某 LP 的最优解处第一条约束的乘子是 $\lambda_1^\star=3$。把该约束右端从 0 放松到 0.1，最优值大约变化多少？这个估计什么时候会失效?

Q12. 梯度法在 $f(x)=\frac12 x^\top Qx$（$Q\succ 0$，$\lambda_{\max}/\lambda_{\min}=10^4$）上需要多少步才能把误差降到 10^{-6}？牛顿法呢?

22.3 答案

A1. 凸。它是透视函数：$f(x,y)=y\cdot g(x/y)$，$g(u)=u^2$ 凸，透视保凸（第 5.4 节）。也可直接算 Hessian：

$$\nabla^2 f=\frac{2}{y^3}\begin{bmatrix}y^2 & -xy\\ -xy & x^2\end{bmatrix}=\frac{2}{y^3}\begin{bmatrix}y\\ -x\end{bmatrix}\begin{bmatrix}y & -x\end{bmatrix}\succeq 0.$$

A2. 凸。二次型矩阵 $Q=\begin{bmatrix}1 & 1/2\\ 1/2 & 1\end{bmatrix}$ 的特征值为 $3/2, 1/2$，均正，故 $Q\succ 0$，S 是椭球（第 3.3 节）。**陷阱**：若矩阵不定（如 $x_1^2-x_2^2\le 1$），S 是双曲线围成的非凸区域。

A3. 对偶：

$$\max\ -b^\top\nu\quad\text{s.t.}\quad A^\top\nu+c\succeq 0.$$

推导见第 12.5(b) 节：$L=-b^\top\nu+(c+A^\top\nu-\lambda)^\top x$，对 x 的下确界有限要求 $c+A^\top\nu-\lambda=0$，再由 $\lambda\succeq 0$ 得 $A^\top\nu+c\succeq 0$。**ν 无符号约束**（等式约束的乘子自由），而 λ（不等式乘子）必须非负。这是最常见的符号错误来源。

A4. 成立（QP，$P=I\succ 0$，且 Slater 成立：$x=(1,1)$ 严格可行）。KKT：$2x+\lambda(-1,-1)^\top=0$（把约束写成 $2-x_1-x_2\le 0$），得 $x_1=x_2=\lambda/2$；约束活跃给出 $x_1+x_2=2$，故 $x^\star=(1,1)$，$\lambda^\star=2$。**解释**：约束右端从 2 增到 $2+u$，最优值下降约 $2u$——"放松一单位约束省 2 单位目标"。

A5. 因为解集 $\{-1,1\}$ 不是凸集（两点的凸组合 0 不在集合内），而凸约束的可行集必须凸。处理方式：(a) 松弛为 $-1\le x\le 1$（得到下界，第 11 章）；(b) 若问题是"选一个"，用整数规划（非凸）；(c) 若 $x^2=1$ 是范数约束的一部分，改成 $\|x\|_2=1$ 后仍非凸，只能松弛为 $\|x\|_2\le 1$。

A6. ℓ_1 球 $\{x\mid \|x\|_1\le 1\}$ 在坐标轴方向有**尖角**（顶点），而 ℓ_2 球是光滑的。约束 $Ax=b$ 是一个仿射子空间；把 ℓ_1 球从原点"吹大"直到第一次碰到该子空间时，接触点极可能落在**顶点或低维面**上——顶点意味着某些坐标为 0。ℓ_2 球没有顶点，接触点是光滑点，故解稠密。

A7. 条件：(a) 迭代进入 $\|\nabla f(x)\|_2<\eta$ 的邻域（η 由 m,L 决定）；(b) $\nabla^2 f$ 在邻域内 L–Lipschitz；(c) 步长取 $t=1$。此时 $\|\nabla f(x^+)\|_2\le \frac{L}{2m^2}\|\nabla f(x)\|_2^2$，误差平方缩小。远离最优时二次近似不可靠，步长 1 可能**增大**目标，所以要用回溯线搜索（第 17.3 节）。

A8. 在中心路径上，$x^\star(t)$ 满足 $tf_0+\phi$ 的平稳性。可以证明 $f_0(x^\star(t))-p^\star\le m/t$（讲义 11.4 的推导核心：用 KKT 与 $\lambda_i=-1/(tf_i)$ 构造对偶可行点）。**实用价值**：给出**不需要知道 $p^\star$** 的停止准则 $m/t<\epsilon$，这是内点法可工程化的关键。

A9.

$$\max\ r\quad \text{s.t.}\quad a_i^\top x_c+r\|a_i\|_2\le b_i,\ i=1,\dots,m$$

变量 $(x_c,r)\in\mathbb{R}^{n+1}$，约束线性、目标线性——LP（第 16.3 节）。注意 $\|a_i\|_2$ 是常数（由数据给出），不是变量，所以这不是 SOCP。

A10. $f^*(y)=\sum_i y_i\log y_i$，若 $y\in\Delta=\{y\succ 0,\mathbf{1}^\top y=1\}$；否则 $+\infty$。因为 $f(x)=\sup_{y\in\Delta} y^\top x$（线性函数在单纯形上的最大值），其共轭就是单纯形的指示函数（第 6.3、5.6 节）。**与 softmax 的关系**：f 的梯度正是 softmax，共轭的定义域是概率单纯形——两者互为"梯度映射"。

A11. 最优值**最多**下降 $3\times 0.1=0.3$（用 $p^\star(u)\ge p^\star(0)-\lambda^{\star\top}u$）。**失效条件**：扰动大到**活跃集改变**（原本不活跃的约束变活跃，或反之），此时 $\lambda^\star$ 不再是对该扰动的导数；或 $p^\star(u)$ 在 $u=0$ 不可微。

A12. 条件数 $\kappa=10^4$，强凸+光滑下梯度法误差按 $(1-1/\kappa)^k$ 衰减，需 $k\approx\kappa\log(1/\epsilon)=10^4\times 13.8\approx 1.4\times 10^5$ 步。牛顿法对二次函数**一步**精确收敛（$H=Q$，二次模型精确）。**结论**：差 5 个数量级，这就是为什么内点法（每步用牛顿）能取代一阶方法。

22.4 如果只有三天

1. **第一天**：第 3、5、6 章 + 默写共轭表。目标：看到函数能立刻判断凸性。
2. **第二天**：第 9、12、13 章。目标：写出对偶、验证 KKT、解释乘子。
3. **第三天**：第 17、18 章 + 第 22.2 节自测。目标：说清牛顿法与内点法的复杂度来源。

第 23 章 参考来源

> 全部链接于 2026–11–01 抓取/核验。标 ⚠️ 者为不可得或需权限。

23.1 课程与讲义

材料	URL	状态
课程主页（EE364a = CME364a）	https://web.stanford.edu/class/ee364a/	✅ 200，含考核/先修/政策
讲义页	https://web.stanford.edu/class/ee364a/lectures.html	✅ 200
讲义全集（2023 改版）	https://web.stanford.edu/~boyd/cvxbook/bv_cvxslides.pdf	✅ 2.5 MB
讲义全集（2023 前旧版）	https://web.stanford.edu/~boyd/cvxbook/bv_cvxslides_original.pdf	✅
`intro.pdf`	https://web.stanford.edu/class/ee364a/lectures/intro.pdf	✅ 19 页
`sets.pdf`	https://web.stanford.edu/class/ee364a/lectures/sets.pdf	✅ 25 页
`functions.pdf`	https://web.stanford.edu/class/ee364a/lectures/functions.pdf	✅ 44 页
`problems.pdf`	https://web.stanford.edu/class/ee364a/lectures/problems.pdf	✅ 68 页
`duality.pdf`	https://web.stanford.edu/class/ee364a/lectures/duality.pdf	✅ 40 页
`approx.pdf`	https://web.stanford.edu/class/ee364a/lectures/approx.pdf	✅ 26 页
`stat.pdf`	https://web.stanford.edu/class/ee364a/lectures/stat.pdf	✅ 26 页
`geom.pdf`	https://web.stanford.edu/class/ee364a/lectures/geom.pdf	✅ 22 页
`num-lin-alg.pdf`	https://web.stanford.edu/class/ee364a/lectures/num-lin-alg.pdf	✅ 24 页
`unconstrained.pdf`	https://web.stanford.edu/class/ee364a/lectures/unconstrained.pdf	✅ 41 页
`equality.pdf`	https://web.stanford.edu/class/ee364a/lectures/equality.pdf	✅ 27 页
`barrier.pdf`	https://web.stanford.edu/class/ee364a/lectures/barrier.pdf	✅ 44 页
`circuits.pdf`	https://web.stanford.edu/class/ee364a/lectures/circuits.pdf	✅ 47 页
`conclusions.pdf`	https://web.stanford.edu/class/ee364a/lectures/conclusions.pdf	✅ 8 页
`examples.pdf`	https://web.stanford.edu/class/ee364a/lectures/examples.pdf	✅ 24 页
专题：随机规划 / 机会约束 / 滤波器	`lectures/stoch_prog.pdf`、`chance_constr.pdf`、`filters.pdf`	✅

23.2 教材

材料	URL	状态
教材主页	https://web.stanford.edu/~boyd/cvxbook/	✅
全书 PDF（714 页）	https://web.stanford.edu/~boyd/cvxbook/bv_cvxbook.pdf	✅ 6.6 MB
LMI 书（控制应用）	https://web.stanford.edu/~boyd/lmibook/lmibook.pdf	✅ 1.2 MB

> **注意**：`https://www.stanford.edu/~boyd/cvxbook/bv_cvxslides.pdf`（带 `www`）在抓取日返回 **403**；去掉 `www` 的 `web.stanford.edu` 版本可用。讲义页上的链接用的是 `www` 形式，直接点击可能失败——这是一个真实存在的坑。

23.3 扩展材料（EE364b，本笔记第 7、19 章来源）

材料	URL
EE364b 讲义页	https://web.stanford.edu/class/ee364b/lectures.html
次梯度（slides）	https://web.stanford.edu/class/ee364b/lectures/subgradients_slides.pdf
次梯度（notes）	https://web.stanford.edu/class/ee364b/lectures/subgradients_notes.pdf
次梯度法（slides）	https://web.stanford.edu/class/ee364b/lectures/subgrad_method_slides.pdf
ADMM（slides）	https://web.stanford.edu/class/ee364b/lectures/admm_slides.pdf

23.4 工具与公开视频

材料	URL	备注
CVXPY	https://www.cvxpy.org/	课程唯一支持的建模工具
CVXPY 教程	https://www.cvxpy.org/tutorial/index.html	讲义页推荐
DCP 工具	https://dcp.stanford.edu	交互式判断表达式曲率
Boyd 短课程（含视频/notebook）	https://web.stanford.edu/~boyd/papers/cvx_short_course.html	公开替代品
CVX101（Stanford Online）	https://online.stanford.edu/courses/soe-yeecvx101-convex-optimization	需注册

材料	URL	备注
EE364b（后继课程）	https://web.stanford.edu/class/ee364b/	ADMM/次梯度/分布式

23.5 明确不可得（不要浪费时间找）

材料	探测结果
作业题 PDF	`homework.html`、`hw0.pdf`、`homework/hw1.pdf` 等均 **404**；题目只在 Gradescope/Ed（需登录）
作业解答	不公开；教材习题解答需教师身份向作者申请
期中/期末真题	站内无 exam 页面，**404**
逐讲 PDF（`lecture01.pdf` 形式）	系统性探测（`lectureN` / `lectN` / `lN` / `slidesN` / `cvx_N`，N=1..20）全部 **404**
课堂录像	CGOE，仅选课学生；主页无公开视频链接

23.6 事实与推断的边界（诚实说明）

内容	性质
考核比例 10/25/65、期中范围 1–4 章 + DCP、迟交政策、LLM 政策	**主页原文**（2026-11-01），但可能每学期调整
授课教师、教室、上课时间、考试日期	**主页原文**，属"当学期"信息，**不可当常量引用**
讲义页数、教材章节号、章节标题	直接来自 PDF 与教材目录
"内点法 20–80 步"	讲义 12.3 原文
各章"建议投入天数"、"三天复习路线"	**推断**（我按页数与依赖关系排的）
"ADMM 通常只到 $10^{-4} \sim 10^{-6}$ 精度"	工程经验值，**非**讲义原文
核 SVM 的 SMO、Goemans–Williamson 0.878	领域常识，非本课程讲义内容

本笔记基于 Stanford EE364a 公开讲义与 Boyd & Vandenberghe 教材写成，用于自学。所有课程政策以课程当学期主页为准。