UC Berkeley CS70《离散数学与概率论》学习笔记

> **课程**：CS70 — Discrete Mathematics and Probability Theory，UC Berkeley，Fall 2026 **授课**：Josh Hug、Manuel Sabin ｜ 讲座时间：周二/周四 15:30–17:00，Li Ka Shing 245 **官方主页**：https://www.eecs70.org/ **资料基础**：本笔记以 CS70 官方**公开讲义 Notes** 为核心依据 —— Fall 2026 现行 Notes（Note 0–7，已随学期发布）以及 Berkeley 官方归档的完整 Notes 体系（Fall 2020 / Spring 2021，Note 0–22）。课程主页的讲座日程、Quiz 安排、评分政策亦已核对。 **版权与用途声明**：官方材料 © UC Berkeley / CS70 课程组，受版权保护。本文档是**自学整理笔记**：按 Fall 2026 讲次顺序重新组织内容，讲解、证明书写、示例构造均为原创中文表述，**未逐字翻译或转载任何官方讲义**。所有数值算例均经脚本验算。 **使用方法**：每讲先读「概述」把握定位，再读「核心概念的直观解释」建立直觉，然后**动手把「完整证明与推导」在纸上重写一遍**，最后用「思考题」自测。CS70 的官方学习建议是：*"study the notes until you were able to comfortably reproduce all of the proofs"* —— 能默写证明，才算真正掌握。

课程概览

一、这门课到底在教什么？

CS70 是伯克利计算机科学专业的**数学基础核心课**，它不教编程，教的是**计算机科学背后的数学思维方式**。课程的官方定位写得很直白：目标是培养 **mathematical maturity（数学成熟度）**，即在面对一个从未见过的命题时，你知道该从哪个角度切入、用哪种证明技巧、写下什么样的严格论证。

课程内容分为**两大模块，各 14 个子主题**（官方原文 "Each half has fourteen subtopics"）：

模块一：离散数学 (Discrete Mathematics)	模块二：概率论 (Probability Theory)
Propositional Logic（命题逻辑）	Counting（计数）
Direct Proofs（直接证明）	Probability Foundations（概率公理基础）
Proof Techniques（证明技巧）	Combinatorial Proofs（组合证明）
Induction（归纳法）	Conditional Probability & Bayes（条件概率与贝叶斯）
Modular Arithmetic（模运算）	Independence & Combination of Events（独立性与事件组合）
CRT（中国剩余定理）	Random Variables & Discrete Distributions（随机变量与离散分布）
RSA（RSA 公钥密码）	Expectations & Linearity（期望与线性性）
Polynomials（多项式）	Joint Distributions & Independence of RVs（联合分布）
Secret Sharing & ECCs（秘密共享与纠错码）	Variance & Covariance（方差与协方差）
Graphs（图论）	Concentration Inequalities（集中不等式）
Graph Induction（图上的归纳法）	Continuous Probability & Distributions（连续概率）
Stable Matching（稳定匹配）	Gaussian Distribution & CLT（高斯分布与中心极限定理）
Countability（可数性）	Markov Chains & Conditional Expectation（马尔可夫链与条件期望）
Computability（可计算性）	（最后一讲随学期调整）

为什么是这个顺序？ 这不是任意排列，而是一条严格的逻辑链：

```
【离散数学模块】—— 从「怎么证明」到「什么不能被证明」

证明工具箱          §L00–L03   直接证明 → 命题逻辑 → 逆否/反证/分情形 → 归纳法
      │                          （没有这套工具，后面的一切都无法书写）
      ▼
数论与密码          §L04–L06   模运算 → 欧几里得/FLT/CRT → RSA
      │                          （同余语言 → 逆元与快速幂 → 真实工业级加密）
      ▼
代数与编码          §L07–L08   多项式 → 秘密共享 & 纠错码
      │                          （多项式插值：从「点唯一确定多项式」出发）
      ▼
图与匹配            §L09–L11   图论 → 平面图/欧拉/树 → 稳定匹配
      │                          （离散结构的建模语言 + 算法正确性证明）
      ▼
极限与不可能        §L12–L13   可数性 → 可计算性
                                 （对角线方法 → 停机问题不可判定）

【概率论模块】—— 从「怎么数」到「怎么预测」

计数与测度          §L14–L15   计数 → 概率公理
      │                          （把「随机」装进集合论框架）
      ▼
信息更新            §L16–L18   组合证明 → 条件概率/贝叶斯 → 独立性
      │                          （观察到证据后如何修正信念）
      ▼
随机变量            §L19–L22   随机变量 → 期望线性性 → 联合分布 → 方差协方差
      │                          （把「随机」压缩成数字，再用线性性绕开相关性）
      ▼
极限定理            §L23–L25   集中不等式 → 连续分布 → 高斯与 CLT
      │                          （为什么大量独立随机性必然「聚拢」成钟形）
      ▼
动态随机过程        §L26       马尔可夫链与条件期望
                                 （无记忆的演化：稳态、吸收、首步分析）
```

二、两个模块各自的核心思想

模块一的一句话总结：离散数学研究"能被有限步骤验证的真理"。 它的主线是**证明技巧的进化**：直接证明遇到困难 → 换逆否命题 → 再不行就反证 → 涉及"所有自然数"就上归纳 → 涉及"无穷"就上对角线方法。每引入一种新技巧，都是因为旧技巧在某类问题上碰壁。而模运算、多项式、图论这三块"具体数学"，则是证明技巧的**练兵场**，同时也各自通向真实应用（RSA、纠错码、稳定匹配）。

模块二的一句话总结：概率论研究"在信息不完全时如何做出可辩护的判断"。 它的主线是**抽象层级的递进**：先是事件（集合）→ 然后是随机变量（函数）→ 然后是数字特征（期望、方差）→ 最后是极限定理（大量随机性的宏观规律）。每一步都用上一层的工具，而**期望的线性性**（L20）是整门课最锋利的"免费午餐"：它不需要独立性，却能让你绕开所有复杂的联合分布计算。

三、学习方法建议（结合 CS70 的考核机制）

CS70 的考核方式很特殊：**每周五 Quiz + 期中 + 期末，且按"主题通过制"（topic-based pass/fail）评分**。每个主题在 Quiz 上出现一次；没通过可以在期中/期末再考一次。这意味着：

1. **不要攒着学**。每个主题只有一次（最多两次）机会，必须当周掌握。
2. **证明要能默写**。官方明确建议"把笔记读到能舒服地复现所有证明"。本笔记的每一讲都给出「证明策略 → 逐步推导 → 证明机制解说」三段式，正是为了让你能内化证明的**生成过程**，而不只是记住结论。
3. **区分"看懂"和"会写"**。看懂一个证明只需被动接受逻辑；会写一个证明需要你主动决定用什么技巧、基础情形取什么、归纳假设假设什么。本笔记每讲的「思考题」用来检验后者。
4. **留意「常见误区」小节**。CS70 的失分大多不是不会，而是踩了固定的坑（忘了基础情形、混淆 $P(A \mid B)$ 与 $P(B \mid A)$、把互斥当独立……）。这些坑在每讲末尾被明确列出。
5. **把交叉引用当作复习线索**。CS70 的考点经常跨主题（例如"用期望线性性证明哈希的 $O(1)$ 查找"），本笔记每讲的「与其他讲次的关联」小节专门标出这些纽带。

四、本笔记的结构

- 按 Lecture 0 → Lecture 26 顺序排列，与 Fall 2026 官方讲座日程严格对齐。
- 每一讲采用**固定八段式**：概述 → 核心概念的直观解释 → 完整证明与推导 → 与经典问题的联系 → 与其他讲次的关联 → 关键要点 → 常见误区与注意事项 → 思考题（带答案）。
- 文档末尾附 **「核心定理与证明技巧速查表」**，按证明技巧、数论与密码、代数与编码、图论与匹配、可计算性、计数与概率、随机变量与极限定理七大类别速查。

> 📌 **关于讲次编号**
>
> 本笔记的讲次编号（Lecture 0–26）遵循 **Fall 2026 官方日程**。官方 Notes 的编号与之**并不一致**（例如 Fall 2026 的 Lecture 0 "Direct Proofs" 对应 Note 0 与 Note 1 两份笔记；Lecture 11 "Stable Matching" 对应官方 Note 12）。阅读官方 Note 时请以**主题名**而非编号为准。

Lecture 0: Direct Proofs（直接证明）

概述

本讲是整门 CS70 的**起点**：在学会任何数学内容之前，先要弄清楚"什么才算真正证明了一个命题"。我们从"为什么实验验证不足以确立数学真理"这个问题出发，先补齐集合与数学记号这套通用语言（集合运算、$\mathbb{N}/\mathbb{Z}/\mathbb{Q}/\mathbb{R}$、$\in$ / $\subseteq$、幂集、笛卡尔积、量词 $\forall/\exists$ 及其否定），再引入第一种证明技巧 —— **直接证明 (Direct Proof)**：假设前件、逐步推导、得到后件。本讲用直接证明拿下三条与整除性 (divisibility) 相关的定理，并且通过"数字和被 9 整除 $\iff$ n 被 9 整除"这个完整例子，说明**命题与其逆命题是两件事**、而**证明等价（$\iff$）必须双向各证一次**。这一讲确立的语言规范（量词、集合、整除）会一路用到 RSA、编码与可数性。

核心概念的直观解释

数学证明 (Mathematical Proof)

- **定义**：一个证明是**有限步的逻辑推导 (logical deductions)** 序列，它从我们无条件接受的公理 (axioms / postulates) 出发，每一步都由逻辑规则从前面的陈述必然推出，最终得到待证命题。
- **直观解释（"它是什么意思？"）**：证明像一段**没有分支、没有循环、没有未定义操作的代码**。每一行要么是"公理/已知事实"，要么是"由上一行经某条逻辑规则得到"。读完最后一行，你就被**强制**接受了结论 —— 你没有"相信"的自由，因为每一步都不给歧义留位置。这也解释了为什么证明与计算机有深刻的历史联系：一百年前对"证明"这个概念的探索（形式化、可机械检验）直接催生了计算机的发明。
- **为什么"实验"不够**：考虑计算机科学中最典型的待证命题：(1) 程序 P 是否**对每一个输入**都停机？(2) 程序 P 是否**对每一个 x** 都输出 $f(x)$？这两个命题都涉及**无限多个输入**。你测试了 10^9 个 x 都通过，命题依然可能在第 10^9+1 个输入上崩掉 —— 你只证明了"10^9 个特例成立"，而没有证明"全部成立"。证明的价值恰恰在于：**用有限的手段，担保无限多个情形。**

一层更细的结构：公理 → 定义 → 引理 → 定理

- **公理 (axiom / postulate)**：我们**不加证明就接受**的起点陈述。"总得从某处开始"——数学不能无限地"为什么"下去。
- **定义 (definition)**：给新对象或新记号赋予精确含义的约定，例如"$a \mid b$ 当且仅当存在整数 q 使 $b = aq$"。定义**不是**需要证明的命题，它是在**制造词汇**。本课程用 $:=$ 表示"定义为"，例如 $q := 6$ 表示把 q 定义成 6。
- **引理 (lemma)**：为证明某个更大的定理而准备的**辅助结果**。写长证明时把关键步骤抽成引理，就像把长程序拆成子函数：好读、好复用、好检查。定理 0.2 的证明中，"$10 \equiv 1 \pmod 9$"这类事实就是引理式的零件。
- **定理 (theorem)**：希望"对外发布"的主要结论。引理与定理的分界线并不严格，有些引理（如 L05 的欧几里得引理）比它服务的定理更有名。
- **直观解释**：把证明想象成一栋楼。**公理是地基**（不能往下问了），**定义是砖块的规格**（规定什么叫"整除"、什么叫"子集"），**引理是预制构件**，**定理是交付的成品**，而**逻辑推导是施工过程** —— 每一道工序都必须用规格允许的材料。
- **一个纪律**：当你写下某一步却讲不清它的依据时，**那一步就不是证明的一部分**，而是一个洞。先回去把它补成"依据：某定义 / 某代数律 / 已证结果"，再往下写。

一个震撼的小例子（本讲反复使用的"证据陷阱"）

考虑命题 $(\forall n \in \mathbb{N})\ n^2+n+41$ 是质数。手工代几个值：

n	0	1	2	3	4	5	6	$\cdots$	39
n^2+n+41	41	43	47	53	61	71	83	$\cdots$	1601
是否质数	是	是	是	是	是	是	是	是	是

从 $n=0$ 一直算到 $n=39$，**四十个连续值全部是质数**。任何人都会开始相信这个命题。但

$$n = 40: \quad 40^2+40+41 = 1600+40+41 = 1681 = 41 \times 41 = 41^2,$$

1681 是合数。所以命题为**假**。（顺带：$n=41$ 时 $41^2+41+41 = 1763 = 41\times 43$，也失败。）这说明：**再多的一致证据也不能代替证明**，而**一个反例 (counterexample) 就能推翻全称命题**。请把这两个数字记住：$1681 = 41^2$。

集合 (Set) 与集合记号

- **定义**：集合是**良定义的对象汇集**（"well defined" 指：对任意对象，都能明确回答它是否属于该集合）。成员叫元素 (element) 或成员 (member)。若 x 是 A 的元素写 $x \in A$，否则 $x \notin A$。
- **集合相等与外延公理 (axiom of extensionality)**：$A = B$ **当且仅当**它们元素完全相同。**顺序与重复都不算数**：

$$\{\text{red}, \text{white}, \text{blue}\} = \{\text{blue}, \text{white}, \text{red}\} = \{\text{red}, \text{white}, \text{white}, \text{blue}\}.$$

- **描述法**：$\mathbb{Q} = \left\{ \frac{a}{b} \;\middle|\; a, b \in \mathbb{Z},\ b \neq 0 \right\}$，读作"所有分子为整数、分母为非零整数的分数构成的集合"。
- **具体示例**：$A = \{2, 3, 5, 7, 11\}$ 是前五个质数；$2 \in A$，$4 \notin A$，$|A| = 5$。

- **基数 (cardinality)**：$|A|$ 是元素个数。$|\varnothing| = 0$，其中 $\varnothing$ 是唯一的**空集 (empty set)**（也写作 $\{\}$）。**注意区分**：$\varnothing \neq \{\varnothing\}$ —— 前者元素个数为 0，后者有一个元素（那个元素恰好是空集）。
- **子集 (subset) 与真子集 (proper subset)**：若 A 的每个元素都在 B 中，写 $A \subseteq B$（也写 $B \supseteq A$，B 是 A 的超集）。若 $A \subseteq B$ 且 $A \neq B$（即 B 中至少有一个元素不在 A 中），写 $A \subset B$ 或 $A \subsetneq B$。

三条基本性质：$\varnothing \subseteq B$ 对**任何** B 成立；$\varnothing \subset A$ 对**任何非空** A 成立；$A \subseteq A$ 对任何 A 成立。

- **具体示例**：取 $B = \{1,2,3,4,5\}$。则 $\{1,2,3\} \subseteq B$ 且 $\{1,2,3\} \subset B$；而 $\{1,2,3,4,5\} \subseteq B$ 但**不是** B 的真子集（差别就在"$A \neq B$"这一个条件上）。

集合运算：交、并、差

- **定义**：$A \cap B = \{x \mid x \in A \text{ 且 } x \in B\}$；$A \cup B = \{x \mid x \in A \text{ 或 } x \in B\}$（这里的"或"是**包含式**的：在 A、在 B、或两边都在，都算）；$B \setminus A = \{x \in B \mid x \notin A\}$（相对补 / 集合差）。若 $A \cap B = \varnothing$ 则称 A 与 B **不相交 (disjoint)**。
- **直观解释**：$\cap$ 是"两个名单的公共部分"，$\cup$ 是"两个名单的合并去重"（正因为去重，$|A \cup B|$ 一般**不等于** $|A| + |B|$），$\setminus$ 是"从 B 的名单里划掉 A 的人"。
- **具体例**：$A = \{1,2,3,4\}$，$B = \{3,4,5\}$，$C = \{1,5,6\}$。则 $A \cap B = \{3,4\}$，$A \cup B = \{1,2,3,4,5\}$，$A \setminus B = \{1,2\}$，$B \setminus A = \{5\}$。取 A 为全体正偶数、B 为全体正奇数：$A \cap B = \varnothing$，$A \cup B = \mathbb{Z}^+$（这是 $\mathbb{Z}$ 的一个**划分**）。
- **易验算的性质**：$A \cup B = B \cup A$，$A \cap B = B \cap A$，$A \cup \varnothing = A$，$A \cap \varnothing = \varnothing$，$A \setminus A = \varnothing$，$A \setminus \varnothing = A$，$\varnothing \setminus A = \varnothing$。

几个"人人都在用"的数集与结构

- **定义**：$\mathbb{N} = \{0,1,2,3,\ldots\}$（本课程**约定 0 是自然数**）；$\mathbb{Z} = \{\ldots,-2,-1,0,1,2,\ldots\}$；$\mathbb{Q} = \{a/b \mid a,b \in \mathbb{Z}, b \neq 0\}$；$\mathbb{R}$ 是全体实数；$\mathbb{C}$ 是全体复数；$\mathbb{Z}^+ = \{1,2,3,\ldots\}$ 是正整数。
- **闭包 (closure)**：$\mathbb{Z}$ 对**加法与乘法**封闭（两个整数相加、相乘仍是整数），$\mathbb{N}$ 也对加法与乘法封闭。**但两者都对减法不封闭**（$0 - 3 = -3 \notin \mathbb{N}$），$\mathbb{Z}$ 对除法也不封闭（$3/2 \notin \mathbb{Z}$）—— 这正是后面引入 $\mathbb{Q}$ 的动机。这个"闭包"事实在本讲的证明里会被**明确引用**，请留意。
- **幂集 (power set)**：$\mathcal{P}(S) = \{T \mid T \subseteq S\}$，即 S 的**全部子集**构成的集合。若 $|S| = k$，则 $|\mathcal{P}(S)| = 2^k$。**为什么是 2^k？** 构造一个子集时，S 中每个元素都要独立地做一次二元选择："要它"或"不要它"；k 次独立选择共 2^k 种结果，且不同选择给出不同子集（外延公理），所有子集也都由此产生。这个"每个元素独立二选一"的思路，之后在 L14 计数中会被正式化为**乘法法则**，在 L15 中变成"样本空间大小 2^k"。
- **具体示例**：$S = \{1,2,3\}$，$|S| = 3$，故 $|\mathcal{P}(S)| = 2^3 = 8$：

$$\mathcal{P}(S) = \{\varnothing,\ \{1\},\ \{2\},\ \{3\},\ \{1,2\},\ \{1,3\},\ \{2,3\},\ \{1,2,3\}\}.$$

注意 $\{1\} \subseteq \{1,2,3\}$（子集关系），而 $\{1\} \in \mathcal{P}(S)$（元素关系）—— **同一个对象在这两个句子里扮演的角色完全不同。** – **笛卡尔积 (Cartesian product)**：$A \times B = \{(a,b) \mid a \in A,\ b \in B\}$，元素是**有序对**。"有序"很重要：$(1,u) \neq (u,1)$，且 $(1,2) \neq (2,1)$。 – **具体例**：$A = \{1,2,3\}$，$B = \{u,v\}$，则

$$A \times B = \{(1,u),(1,v),(2,u),(2,v),(3,u),(3,v)\}, \qquad |A \times B| = 3 \times 2 = 6.$$

$\mathbb{N} \times \mathbb{N} = \{(0,0),(1,0),(0,1),(1,1),(2,0),\ldots\}$ 是全体自然数对；它可以按"对角线"枚举（下面第 5 节会看到，这个枚举技巧在 L12 可数性里是关键工具）。

求和与求积记号 (Sigma and Pi notation)

- **定义**：$\sum_{i=m}^{n} f(i) = f(m) + f(m+1) + \cdots + f(n)$；$\prod_{i=m}^{n} f(i) = f(m) \cdot f(m+1) \cdots f(n)$。例如 $\sum_{i=1}^{n} i = 1 + 2 + \cdots + n$，$\prod_{i=1}^{n} i = n!$。
- **具体例**：$\sum_{i=5}^{7} i^2 = 5^2 + 6^2 + 7^2 = 25 + 36 + 49 = 110$。$\prod_{i=1}^{10} i = 10! = 3{,}628{,}800$。
- **为什么要它**：本讲定理只处理三位数（$n = 100a + 10b + c$），所以可以手写。要把它推广到任意位数的 n，就必须用 $\sum$ 把 n 写成 $n = \sum_{i=0}^{k-1} a_i 10^i$ —— 记号是为了让**推广**成为可能。

量词 (Quantifiers)：∀ 与 ∃

- **定义**：**全称量词 (universal quantifier)** $\forall$ 读作"对所有"；**存在量词 (existential quantifier)** $\exists$ 读作"存在"。写法 $(\forall n \in \mathbb{N})\, P(n)$、$(\exists x \in \mathbb{Z})\, P(x)$。当论域 (universe) 明确时可省略：$\exists x\, (x \text{ lays eggs})$。
- **直观解释**：量词是"把无数个单句一次性打包"的装置。$(\forall n \in \mathbb{N})(n^2 + n + 41$ 是质数$)$ 这个句子，等价于同时断言 $0^2 + 0 + 41$ 是质数、$1^2 + 1 + 41$ 是质数、$2^2 + 2 + 41$ 是质数……**无穷多句**。而 $(\exists x \in \mathbb{Z})(x < 2 \wedge x^2 = 4)$ 只是说：在整数里**至少找得到一个**满足条件的 x（取 $x = -2$ 即可，命题为真）。
- **谓词 (predicate)**：像"$n^2 + n + 41$ 是质数"这样**带自由变量**的句子叫谓词或命题式 (propositional formula)：它本身**没有真假**，但把变量替换成一个具体值后就变成有真假的命题。$n = 1$ 时得"43 是质数"（真）；$n = 40$ 时得"1681 是质数"（假）。**量词的作用就是把谓词"封口"成命题。**
- **有限论域可以消掉量词**：若论域 $U = \{1,2,3,4\}$，那么

$$(\exists x \in U)\, P(x) \ \equiv\ P(1) \vee P(2) \vee P(3) \vee P(4), \qquad (\forall x \in U)\, P(x) \ \equiv\ P(1) \wedge P(2) \wedge P(3) \wedge P(4).$$

也就是说：**存在 = 一堆"或"，全称 = 一堆"与"**。这个对应关系是下一讲德摩根定律能"搬"到量词上的根本原因。但注意：在**无限**论域（如 $\mathbb{N}$）里这招失效 —— 你无法写下无穷长的合取式。

- **嵌套量词不交换（本讲先埋下伏笔）**：比较

$$(\forall x \in \mathbb{Z})(\exists y \in \mathbb{Z})(y > x) \qquad \text{与} \qquad (\exists y \in \mathbb{Z})(\forall x \in \mathbb{Z})(y > x).$$

第一句说"给定任意整数，总能找到比它更大的整数"——**真**（取 $y = x + 1$）。第二句说"存在一个整数比所有整数都大"——**假**（不存在最大整数）。两句话只差量词顺序，真假相反。本讲记下这个现象，L01 会给出系统处理它的工具（量词否定律）。

整除性 (Divisibility)、奇偶性与有理/无理数

- **整除的定义**：对整数 a, b，称 a **整除** b（记 $a \mid b$）**当且仅当**存在整数 q 使得 $b = aq$。例如 $2 \mid 10$，因为取 $q = 5$ 得 $10 = 5 \cdot 2$；$7 \mid (-21)$，因为取 $q = -3$ 得 $-21 = 7 \cdot (-3)$。

- **直观解释**：$a \mid b$ 的意思是"用 a 去量 b，能量尽、不留余数"。**注意 $a \mid b$ 是一个关于"存在性"的命题**，不是一次除法运算；证明 $a \mid b$ 的标准动作是**把那一个整数 q 显式地造出来**（或指出它存在）。
- **几个必须精确的点**：
- 记号方向：$a \mid b$ 是"a 整除 b"（a 是除数），**不是 $b \mid a$**。
- $a \mid b$ 与分数 b/a 是两回事：$6 \mid 0$ 成立（$0 = 6 \cdot 0$），但 $0/6$ 与 "$6/0$" 都不是这里讨论的对象。
- 关于 $a = 0$：$0 \mid 0$ 成立（$0 = q \cdot 0$ 对**任何** q 都成立，比如 $q = 7$），但 $0 \mid b$ 对 $b \neq 0$ 一律不成立。本讲的定理都取 $a \neq 0$ 的情形，避免这个退化 (degenerate) 情况。
- **整除不能拆到因子上去**（本讲最重要的反例之一）：$6 \mid (2 \cdot 3)$ 显然成立（$2 \cdot 3 = 6$），但 $6 \nmid 2$ 且 $6 \nmid 3$。所以"$a \mid bc \Rightarrow a \mid b$ 或 $a \mid c$"是**假**命题。可是同样的形式在 a **是质数** 时会变成真命题 —— 这就是 L05 里欧几里得引理 (Euclid's Lemma) 的内容，也是 RSA 正确性的基石。
- **质数 (prime)**：自然数 $p \geq 2$ 若只能被 1 和它自身整除，则称 p 是质数。
- **奇偶性**：n 是**偶数**当且仅当 $2 \mid n$，即存在 $k \in \mathbb{Z}$ 使 $n = 2k$；n 是**奇数**当且仅当存在 $k \in \mathbb{Z}$ 使 $n = 2k + 1$。**注意"奇数"的定义用的是 $2k + 1$ 而非"非偶数"**——两者等价，但前者在做代数变形时更好用（L02 证明"若 n 奇数则 n^3 奇数"、证明 $\sqrt{2}$ 无理性时都靠这个形式）。
- **有理数 (rational) 与无理数 (irrational)**：能写成两个整数之比 a/b（$b \neq 0$）的数叫有理数；否则叫无理数。例如 $2/3,\ 3/5,\ 9/16$ 都是有理数；$\sqrt{3}$、$\sqrt{2}$、π 是无理数。特别地：$\mathbb{R} \setminus \mathbb{Q}$ **就是**全体无理数构成的集合 —— 这是"集合差"记号最漂亮的一次应用。

直接证明 (Direct Proof)

- **定义 / 一般形式**：待证命题形如 $(\forall x)\ P(x) \Rightarrow Q(x)$。**直接证明**的做法是：对**任意**（generic，即不假任何特殊性质）的 x **假设 $P(x)$ 成立**，然后通过一串保持"必然性"的推导，最终**得到 $Q(x)$**。

```
直接证明 (Direct Proof) 的五步流程
============================================================

 目标：证明  P ==> Q

 (1) "Assume P."          <-- 假设前件成立（不是假设结论！）
          |
          v
 (2) 展开定义              <-- 把 P 翻译成"存在某个见证对象"的语句
          |                     例：  a|b  -->  存在整数 q1 使 b = q1*a
          v
 (3) 代数/逻辑变形          <-- 等值变形、代入、整理
          |
          v
 (4) 凑出 Q 的定义形状      <-- 关键一步：把结果写成 "Q 所要求的形式"
          |                     例：  b+c = (q1+q2)*a  -->  形状 b = (整数)*a
          v
 (5) "Therefore Q."        <-- 结论，并说明 Q 的定义已被满足
 ============================================================
```

- **直观解释**：直接证明像**从已知条件出发开一条单行道**，一路不许掉头、不许分岔，终点必须是结论。它不需要任何"灵光一现"的假设（这与反证法、逆否证明不同），代价是有时路不好找 —— 本讲的三条定理恰好都是"路很清楚"的情形。
- **两个致命的纪律**：
- **绝不能把待证结论当前提**。后面（L02）会看到那个著名的假证明"$-2 = 2$"：假设 $-2 = 2$，两边平方得 $4 = 4$（为真），于是宣称命题成立。错误在于他证的是 $P \Rightarrow \mathbf{True}$，而这不是 P。
- **"任意"必须是真正的任意**。证明里**不能**假设 a, b, c 取任何特定值（例如"令 $a = 3$"）；正因为没有做这种假设，结论才对**所有** $a, b, c \in \mathbb{Z}$ 成立 —— 这一步就是量词 ∀ 的落地方式，下面的定理 0.1 会明确点出它。

完整证明与推导（核心）

定理 0.1（整除性的可加性）：对任意 $a, b, c \in \mathbb{Z}$，若 $a \mid b$ 且 $a \mid c$，则 $a \mid (b + c)$。

先把它翻译成量词形式：令 $P(x, y)$ 表示"$x \mid y$"。则定理说的是

$$(\forall a, b, c \in \mathbb{Z})\ \big(P(a, b) \wedge P(a, c)\big) \implies P(a, b + c).$$

证明策略：**直接证明**。理由：待证命题是 $P \Rightarrow Q$ 形式；而且前件 P 本身就是一个"存在性"断言（存在整数 q_1, q_2），一旦把这两个**见证对象 (witness)** 取出来，剩下的就是把 $b + c$ 整理成"某个整数乘以 a"的形状 —— 而这只需要初中的分配律。没有任何理由绕道反证或逆否。

逐步推导：

1. **假设前件**：设 $a, b, c \in \mathbb{Z}$ 是**任意**整数，并假设 $a \mid b$ 且 $a \mid c$。
2. **展开定义**（依据：整除的定义）：由 $a \mid b$，存在整数 q_1 使 $b = q_1 a$；由 $a \mid c$，存在整数 q_2 使 $c = q_2 a$。
3. **相加**（依据：等式两边可相加）：$b + c = q_1 a + q_2 a$。
4. **提取公因子**（依据：分配律）：$q_1 a + q_2 a = (q_1 + q_2)\, a$。
5. **验证见证对象的合法性**（依据：$\mathbb{Z}$ 对加法封闭）：$q_1, q_2 \in \mathbb{Z}$，故 $q_1 + q_2 \in \mathbb{Z}$。
6. **收尾**（依据：整除的定义，取 $q := q_1 + q_2$）：我们已找到整数 q 使 $b + c = qa$，故 $a \mid (b + c)$。$\blacksquare$

量词在哪里？ 证明的第 1 步只说"a, b, c 是任意整数"，**从始至终没有指定任何具体数值**。正因为对每个 a, b, c 都成立，我们才得到了 $(\forall a, b, c \in \mathbb{Z})$ 的结论。这就是直接证明"免费"处理全称量词的方式：**一次推导，覆盖所有实例**。

【证明机制解说】：整条证明的"引擎"只有一句话 —— **两个"a 的倍数"相加仍是"a 的倍数"**。第 4 步的分配律是唯一的技术动作，第 5 步的闭包检查是最容易被学生省略、也最容易被扣分的一步（没有它，"$q_1 + q_2$ 是整数"就只是感觉，不是证明）。请养成习惯：**每造出一个新对象，就检查它是否还在允许的集合里。**

把这个机制做一次"微观慢放"：取 $a = 7$ 做具体实例，观察证明的每一步在做什么。

步骤	一般形式	具体实例（$a=7,\ b=21,\ c=35$）
假设	$a \mid b$，$a \mid c$	$7 \mid 21$（$q_1 = 3$），$7 \mid 35$（$q_2 = 5$）
展开	$b = q_1 a$，$c = q_2 a$	$21 = 3 \times 7$，$35 = 5 \times 7$
相加	$b + c = q_1 a + q_2 a$	$21 + 35 = 56$
提公因子	$b + c = (q_1 + q_2) a$	$56 = (3 + 5) \times 7 = 8 \times 7$
闭包	$q_1 + q_2 \in \mathbb{Z}$	$3 + 5 = 8 \in \mathbb{Z}$ ✓
结论	$a \mid (b + c)$	$7 \mid 56$，商 $q = 8$ ✓

注意上表**右侧只是用来理解机制，不能写进证明**。证明必须对"任意"的 a, b, c 说话；一旦在证明里写下"取 $a = 7$"，你证的就不再是定理，而只是一个例子。

推论 0.1（减法版本，同法可证）：对任意 $a, b, c \in \mathbb{Z}$，若 $a \mid b$ 且 $a \mid c$，则 $a \mid (b - c)$。

证明：完全照抄定理 0.1 的推导，只把第 3 步改为 $b - c = q_1 a - q_2 a = (q_1 - q_2) a$；$\mathbb{Z}$ 对减法同样封闭，故 $q_1 - q_2 \in \mathbb{Z}$，于是 $a \mid (b - c)$。■

推论 0.2（倍数版本）：对任意 $a, b \in \mathbb{Z}$ 与任意 $k \in \mathbb{Z}$，若 $a \mid b$ 则 $a \mid (kb)$。

证明：设 $b = qa$（$q \in \mathbb{Z}$），则 $kb = k(qa) = (kq)a$，且 $kq \in \mathbb{Z}$，故 $a \mid (kb)$。■

定理 0.1 的逆命题是假的（反例）：把定理 0.1 的箭头掉头，得到"若 $a \mid (b + c)$，则 $a \mid b$ 且 $a \mid c$"。取 $a = 3,\ b = 1,\ c = 2$：$b + c = 3$，确实 $3 \mid 3$；但 $3 \nmid 1$（$1 = 3q$ 无整数解），也不需要用 c 就能反驳。所以**"整除性可以拆回两个加数"是错的**。同理，取 $a = 2,\ b = 6,\ c = 7$：$2 \mid 6$，$b + c = 13$ 是奇数，$2 \nmid 13$ —— 这说明定理 0.1 的**两个前提缺一不可**：只保留 $a \mid b$ 而丢掉 $a \mid c$，结论就失效了。

定理 0.2（数字和法判定 9 的倍数）：设 $0 < n < 1000$ 是整数。若 n 的各位数字之和能被 9 整除，则 n 能被 9 整除。

先把它翻译成量词形式：

$$(\forall n \in \mathbb{Z}^+)\left(n < 1000 \implies \big(n \text{ 的数字和能被 } 9 \text{ 整除} \implies n \text{ 能被 } 9 \text{ 整除}\big)\right).$$

证明策略：**直接证明 + 按位展开 (positional expansion)**。难点在于"数字和"和"n 本身"看起来是两样东西，没有明显联系。破局点是：$n = 100a + 10b + c$ 而数字和是 $a + b + c$，两者只差 $99a + 9b$ —— **而 99 和 9 都是 9 的倍数**。所以只要把数字和写成 $9k$，再加 $99a + 9b$ 就能"凑出"n。这是本讲最值得记住的**证据变形技巧**。

逐步推导：设 n 的十进制写法为 $n = \overline{abc}$，即

$$n = 100a + 10b + c, \qquad a, b, c \in \{0, 1, \ldots, 9\}.$$

（若 $n \geq 100$ 则 $a \neq 0$；若 $n < 100$ 则可取 $a = 0$，此时把 n 看作"补零的三位数"，数字和仍是 $a + b + c$。约定 n 的三位数字记号只是**书写上的方便**，不是对结论的限制 —— 见本节末尾的推广讨论。）

1. **假设前件**：假设 n 的数字和能被 9 整除，即 $9 \mid (a + b + c)$。
2. **展开定义**（依据：整除的定义）：存在 $k \in \mathbb{Z}$ 使

$$a + b + c = 9k. \tag{0.1}$$

1. **两边同时加上 $99a + 9b$**（依据：等式两边加同一个数仍是等式）：

$$a + b + c + 99a + 9b = 9k + 99a + 9b.$$

1. **左边合并同类项**（依据：交换律、结合律）：

$$a + b + c + 99a + 9b = (a + 99a) + (b + 9b) + c = 100a + 10b + c = n.$$

1. **右边提取 9**（依据：分配律）：

$$9k + 99a + 9b = 9\,(k + 11a + b).$$

1. **合并 3–5 步**：$n = 9(k + 11a + b)$。
2. **验证见证对象**（依据：$\mathbb{Z}$ 对加法与乘法封闭）：$k, a, b \in \mathbb{Z}$，故 $k + 11a + b \in \mathbb{Z}$。
3. **收尾**：存在整数 $q = k + 11a + b$ 使 $n = 9q$，故 $9 \mid n$。■

三个可手算的算例：

n	a, b, c	数字和 $a + b + c$	$k = (a + b + c)/9$	$q = k + 11a + b$	验算 $9q$
378	$3, 7, 8$	18	2	$2 + 33 + 7 = 42$	$9 \times 42 = 378$ ✓

		数字和			验算
837	$8,3,7$	18	2	$2+88+3=93$	$9\times 93=837$ ✓
999	$9,9,9$	27	3	$3+99+9=111$	$9\times 111=999$ ✓

再看一个**数字和不能被 9 整除**的对照：372 的数字和是 $3+7+2=12$，$12 \bmod 9=3$，而 $372 \bmod 9=3$ —— 两者余数相同（这正是 $n \equiv a+b+c \pmod 9$ 的雏形）。定理只处理"余数为 0"的情形。（$372 \div 9=41.\overline{3}$，确实不整除。）

【证明机制解说】：本证明的全部秘密在于**选择加什么**。我们要用数 $a+b+c$（假设它是 9 的倍数）去控制 $100a+10b+c$，二者相差 $99a+9b$。为什么会想到加 $99a+9b$? 因为 $100-1=99$、$10-1=9$，而 $9 \mid 99$、$9 \mid 9$ —— **10 的幂与 1 同余于模 9**。所以本证明其实是"$10^i \equiv 1 \pmod 9$"这一事实的三位数特例。这个视角会在 L04 模运算里被正式化，并立刻给出对**任意位数**都成立的推广：

$$n=\sum_{i=0}^{k-1} a_i 10^i \equiv \sum_{i=0}^{k-1} a_i \cdot 1^i=\sum_{i=0}^{k-1} a_i \pmod 9.$$

关于条件 $0<n<1000$：这个上界**不是为了结论成立**（结论对一切正整数都对），而只是为了让证明只需三个字母 a,b,c 就能写完。要处理任意位数，就必须用第 1 节的求和记号并把"逐位相加"的过程形式化 —— 那是 L03 归纳法的任务（对位数做归纳）。

定理 0.3（定理 0.2 的逆定理 / Converse）：设 $0<n<1000$ 是整数。若 n 能被 9 整除，则 n 的各位数字之和能被 9 整除。

证明策略：仍是**直接证明**，而且几乎是定理 0.2 的"倒着走"。注意**不要**误以为"逆定理自动成立"——本讲最后会给出一个逆定理不成立的例子。这里的逆定理之所以能证，是因为定理 0.2 的推导链**每一步都是等值变形**（两边加同一个数、合并同类项、提取公因子），因此可以反向阅读。凡是"可逆的推导链"，双向都能证；凡是不可逆的（例如两边平方），就只能证单向。

逐步推导：沿用同样的记号 $n=100a+10b+c$。

1. **假设前件**：假设 $9 \mid n$。
2. 由定义，存在 $l \in \mathbb{Z}$ 使 $n=9l$，即 $100a+10b+c=9l$。
3. **把 $100a+10b$ 改写成 $99a+9b+a+b$**（依据：$100a=99a+a$，$10b=9b+b$）：

$$99a+9b+(a+b+c)=9l.$$

1. **移项**：$a+b+c=9l-99a-9b$。
2. **提取 9**：$a+b+c=9\,(l-11a-b)$。
3. **验证见证对象**：$l,a,b \in \mathbb{Z}$，故 $k:=l-11a-b \in \mathbb{Z}$。
4. **收尾**：存在整数 k 使 $a+b+c=9k$，故 $9 \mid (a+b+c)$。■

算例（把定理 0.3 走一遍）：取 $n=981$。已知 $981=9\times 109$，故 $l=109$。$a=9,b=8,c=1$。则 $k=l-11a-b=109-99-8=2$，于是 $a+b+c=9\times 2=18$。验算：$9+8+1=18$，且 $18 \div 9=2$ ✓。

定理 0.2 与 0.3 合起来 = 等价性：

$$9 \mid n \iff 9 \mid (n \text{ 的数字和}), \qquad (0<n<1000).$$

这条"双向都要证"的纪律是本讲的核心教训：要证 $P \iff Q$，就**分别**证 $P \Rightarrow Q$ 与 $Q \Rightarrow P$，绝不允许用"同理可证"或"反过来也一样"糊过去 —— 因为"反过来"未必成立。

为什么两条证明的推导链完全对称？ 关键在于它们共享**同一个恒等式**。把三位数写开：

```
恒等式 （两个定理的共同引擎）
============================================================
  n  =  100a + 10b + c
     =  (99a + a) + (9b + b) + c          <-- 拆开百位、十位
     =  99a + 9b + (a + b + c)            <-- 把 "数字和" 单独拎出来
     =  9(11a + b) + (a + b + c)          <-- 99a+9b 已是 9 的倍数
------------------------------------------------------------
 于是   n = 9*(11a+b) + S ,   其中 S := a + b + c  是数字和
------------------------------------------------------------
 定理 0.2 :  S = 9k   ==>  n = 9*(11a+b) + 9k = 9*(11a+b+k)  ==>  9|n
 定理 0.3 :  n = 9l   ==>  9*(11a+b) + S = 9l  ==>  S = 9*(l-11a-b)  ==>  9|S
============================================================
同一个恒等式，向右读得到定理 0.2，向左读得到定理 0.3。
"n 与 S 相差一个 9 的倍数"  ==>  n 和 S 要么同时被 9 整除，要么同时不被 9 整除。
```

这个图示值得记住：**两个方向的证明之所以对称，不是因为运气，而是因为中间的变换是可逆的**。凡是"n 与 S 只差 9 的倍数"这种结构的命题，双向都会自动成立。反之，像"$x=y \Rightarrow x^2=y^2$"（平方不可逆）就只能单向。

命题与逆命题为什么不等价（反例集）

一个命题与其逆命题（converse）一般**不是**同一件事。下面三个反例都做了验算，请逐个核实：

1. **整除的"不可拆"**：$6 \mid (2\times 3)$ 为真，但 $6 \mid 2$ 为假。这里 P 是"$6 \mid 2$ 且 $6 \mid 3$"，Q 是"$6 \mid 6$"；$P \Rightarrow Q$ 真而 $Q \Rightarrow P$ 假。
2. **定理 0.1 的逆**：$3 \mid (1+2)$ 为真，但 $3 \mid 1$ 为假。

3. **数字和法则换模数就崩**：对 9 有 $9 \mid n \iff 9 \mid$ 数字和。但换 11 就不行：$n=29$ 的数字和是 $2+9=11$，$11 \mid 11$ 成立，而 $29 \div 11 = 2.\overline{636}$，$11 \nmid 29$。（在 $1 \le n < 1000$ 中共有 164 个这样的反例。）这条既说明"逆命题不自动成立"，也说明**定理的模数 9 是本质的**，不是随便挑的。

定理 0.4（集合相等的标准证法：双向包含）：设 A, B, C 是任意集合，则

$$A \cup (B \cap C) \;=\; (A \cup B) \cap (A \cup C).$$

证明策略：双向包含 (mutual inclusion)。集合相等没有"代数运算"可以直接算，唯一的武器是外延公理给出的等价刻画：

$$A = B \quad\Longleftrightarrow\quad (A \subseteq B) \;\wedge\; (B \subseteq A).$$

所以我们把它拆成两个命题：**（$\subseteq$ 方向）** 每个 $x \in A \cup (B \cap C)$ 都属于 $(A \cup B) \cap (A \cup C)$；**（$\supseteq$ 方向）** 反过来也成立。这种证明叫**元素追踪 (element chasing)**：固定一个元素 x，把"x 属于某集合"翻译成关于"$x \in A,\ x \in B,\ x \in C$"的布尔条件，然后用逻辑等价变形。

逐步推导：

第一部分：$A \cup (B \cap C) \subseteq (A \cup B) \cap (A \cup C)$。 取任意 $x \in A \cup (B \cap C)$。（依据：并集定义）于是有两种情形：

- **情形 1**：$x \in A$。则 $x \in A \cup B$（并集定义）且 $x \in A \cup C$（并集定义），故 $x \in (A \cup B) \cap (A \cup C)$（交集定义）。
- **情形 2**：$x \in B \cap C$。则 $x \in B$ 且 $x \in C$。由 $x \in B$ 得 $x \in A \cup B$；由 $x \in C$ 得 $x \in A \cup C$；故 $x \in (A \cup B) \cap (A \cup C)$。

两种情形都得到目标结论（依据：$A \cup (B \cap C) = \{x \mid x \in A \vee x \in B \cap C\}$，恰好穷尽所有可能），所以该方向成立。

第二部分：$(A \cup B) \cap (A \cup C) \subseteq A \cup (B \cap C)$。 取任意 $x \in (A \cup B) \cap (A \cup C)$。则 $x \in A \cup B$ 且 $x \in A \cup C$。分两种情形：

- **情形 1**：$x \in A$。则 $x \in A \cup (B \cap C)$，完成。
- **情形 2**：$x \notin A$。由 $x \in A \cup B$ 与 $x \notin A$，必有 $x \in B$；由 $x \in A \cup C$ 与 $x \notin A$，必有 $x \in C$。于是 $x \in B \cap C$，从而 $x \in A \cup (B \cap C)$，完成。

（情形 1、2 覆盖一切可能，故该方向成立。）

由两个方向同时成立，依据外延公理得 $A \cup (B \cap C) = (A \cup B) \cap (A \cup C)$。■

用有限论域把证明"看穿"：取 $A = \{1,2,3\}$，$B = \{2,3,4\}$，$C = \{3,5\}$，论域 $U = \{1,2,3,4,5,6\}$。逐元素验证：

```
A = {1,2,3}   B = {2,3,4}   C = {3,5}        BnC = {3}

  x | x∈A | x∈B | x∈C || x∈BnC | x∈Au(BnC) || x∈AuB | x∈AuC | x∈(AuB)n(AuC)
 ---+------+------+-----++-------+-----------++-------+-------+----------------
  1 |  Y   |  N   |  N  ||   N   |     Y     ||   Y   |   Y   |       Y
  2 |  Y   |  Y   |  N  ||   N   |     Y     ||   Y   |   Y   |       Y
  3 |  Y   |  Y   |  Y  ||   Y   |     Y     ||   Y   |   Y   |       Y
  4 |  N   |  Y   |  N  ||   N   |     N     ||   Y   |   N   |       N
  5 |  N   |  N   |  Y  ||   N   |     N     ||   N   |   Y   |       N
  6 |  N   |  N   |  N  ||   N   |     N     ||   N   |   N   |       N

结论: 两列的 Y/N 完全一致 ==> 两个集合相等  (验证: 左 = {1,2,3}, 右 = {1,2,3})
```

注意第 4 行是"信息量最大"的一行：$x=4$ 时 $x \in A \cup B$ 为真但 $x \notin A \cup C$，所以右式为假 —— 这说明**第二个方向不是白证的**：$(A \cup B)$ 会引入 B 独有的元素，而把它与 $(A \cup C)$ 相交恰好把这些"只属于 B"的元素筛掉。同样第 5 行筛掉"只属于 C"的元素。$A \cup (B \cap C)$ 与 $(A \cup B) \cap (A \cup C)$ 之所以相等，本质就是"B 与 C 至少一个成立"（∨）与"B 成立 **并且** C 成立"（∧）在**分配律**下的关系：本证明其实是逻辑分配律 $P \vee (Q \wedge R) \equiv (P \vee Q) \wedge (P \vee R)$ 的集合版本。L01 会用真值表证明这条逻辑分配律。

【证明机制解说】：双向包含证明的两个方向常常**难度不对称**。这里 $\subseteq$ 方向是"分情形 + 直接放大"（把 $B \cap C$ 拆成 B 和 C，分别送进两个并集），$\supseteq$ 方向则必须用**反设**（"假设 $x \notin A$"）才能逼出 $x \in B$ 与 $x \in C$。更常用的判据是：$\supseteq$ 方向若直接推不动，就试着**否定 A** —— 因为 $x \in A \cup B$ 且 $x \notin A$ 是榨出 $x \in B$ 的唯一出路。这个"反设一个条件"的手法在 L02 的逆否证明里会成为主力。

反例（说明"只证一个方向"会闹笑话）：判断"$A \cup (B \cap C) = (A \cup B) \cap C$ 是否成立？"取 $A = \{1,2,3\}$，$B = \{2,3,4\}$，$C = \{3,5\}$。左边 $= \{1,2,3\} \cup \{3\} = \{1,2,3\}$；右边 $= \{1,2,3,4\} \cap \{3,5\} = \{3\}$。二者不等 —— 左边含 $1,2$，右边不含。但注意 $A \cup (B \cap C) = \{1,2,3\} \supseteq \{3\} =$ 右边，所以**一个方向居然是真的**。假如你只验证了 $\supseteq$，就会错误地宣布相等。**这就是"必须双向"的活证据。**

小结：集合等式的三种武器

- **元素追踪（最通用）**：双向包含，把 $\in$ 翻译成布尔条件。定理 0.4 用的就是它。
- **套用已知逻辑律**：若已知逻辑等价式 $P \vee (Q \wedge R) \equiv (P \vee Q) \wedge (P \vee R)$，则只要把 P 读作"$x \in A$"等，集合等式就"自动"成立。注意这仍然需要说明"两个方向都能走"，只是逻辑律本身已经双向。
- **把集合相等改写成元素条件的等价**：外延公理给出的是 $A = B \iff \forall x\,(x \in A \iff x \in B)$。所以最干净的一句话式证明是：对任意 x，

$$x \in A \cup (B \cap C) \iff x \in A \vee x \in (B \cap C) \iff x \in A \vee (x \in B \wedge x \in C)$$

$$\iff (x \in A \vee x \in B) \wedge (x \in A \vee x \in C) \iff x \in (A \cup B) \wedge x \in (A \cup C) \iff x \in (A \cup B) \cap (A \cup C).$$

这串 $\iff$ 的每一步都是定义或逻辑分配律，**每一步都可逆**，所以它同时完成了两个包含方向。考试时写这一串足以得分，但**初学者建议先老老实实写双向**，把元素追踪的手感练出来。

与经典问题的联系

（1）程序正确性与"无限多输入"的验证问题 → L13 停机问题

本讲开篇的两个命题——"程序 P 对所有输入停机"、"程序 P 对所有 x 都输出 $f(x)$"——是**程序验证 (program verification)** 的雏形。工程上我们做的是"测试":跑一批输入,看是否通过。这只能排除反例,不能确立全称命题。CS70 后半程会用**对角线方法**证明更强、也更冷酷的结论:存在根本无法由任何程序判定的命题(停机问题,L13)。而这一切的出发点就是本讲这句话:**全称命题的真伪与"跑过多少测试"无关。**

(2) "数字和 $\bmod 9$"是校验和 (checksum) 思想的原型

定理 0.2/0.3 的推广形式 $n \equiv \sum_i a_i \pmod 9$ 说明:**一个数的全部信息可以被"压缩"成几位数字的和,而模 9 的值不变**。这正是**校验位 (check digit)** 的原理:在数据末尾附上一个由全体数字算出的冗余位,接收方重算一遍就能发现传输错误。真实系统里用得更多的是"加权"版本,例如**国际标准书号 ISBN-10** 的校验位用模 11 加权和(权重 $10, 9, \dots, 1$)计算,并把余数 10 记作字符 `X`;单一数字写错或相邻两位写反,都可以被检出。注意这里的教学价值不在算法细节,而在于本讲建立的**建模路径**:定义一个"由诸位数字确定、且对 n 的某个模值不变量",再证明它与 n 的整除性等价 —— 即"定理 0.2 + 定理 0.3 的双向"。

(3) 整除性语言 = RSA 的语法基础 → L04–L06

本讲只用到整除的定义 $b = aq$,但整条数论主线都在这个定义上生长:同余 $a \equiv b \pmod m$ 就是 $m \mid (a-b)$;最大公约数 $\gcd(a,b)$ 是"同时整除 a, b 的最大者";欧几里得算法靠的是 $\gcd(a,b) = \gcd(b, a \bmod b)$(L05);费马小定理与 RSA 的解密正确性(L06)本质上是在证明"某个整除关系成立"。本讲的定理 0.1(可加性)与推论 0.2(可乘性)就是之后所有整除运算的**合法性依据**。

(4) 集合与量词语言 = 程序规范与数据库查询

前置条件 (precondition) / 后置条件 (postcondition) 是集合语言:$\{x \in \mathbb{Z} \mid x > 0\}$ 就是"输入必须满足的条件"这个集合。数据库的 `SELECT ... WHERE` 与 `EXISTS` 子查询,直接对应 $\exists$ 与 $\forall$ 以及本讲的集合运算:`UNION` 是 $\cup$,`INTERSECT` 是 $\cap$,`MINUS` 是 $\setminus$,`NOT EXISTS` 对应量词否定律。**把 SQL 查询翻译成量词命题、再取否定,是发现"为什么这个查询返回了非预期的行"的最快方法。**

(5) 集合的"对角枚举" → L12 可数性

$\mathbb{N} \times \mathbb{N}$ 可以按对角线排成一列:$(0,0), (1,0), (0,1), (2,0), (1,1), (0,2), \dots$(先按 $a+b$ 递增,同一个 $a+b$ 内按 a 递增)。这个"在二维网格里排成一条线"的技巧,就是 L12 证明 $\mathbb{N} \times \mathbb{N}$ 可数所用的方法;而"幂集 $|\mathcal{P}(S)| = 2^k$ 严格大于 $|S|$"这个有限情形的直觉,会在无限情形被强化为**康托定理**:没有任何集合与自己的幂集等势。

与其他讲次的关联

- **L01 (Propositional Logic,命题逻辑)**:本讲的定理陈述全部采用"$P \Rightarrow Q$"的形式,而证明就是"用逻辑规则把 P 推到 Q"。L01 会给出这套规则本身:真值表、德摩根定律、蕴涵的等价形式 $P \Rightarrow Q \equiv \neg P \vee Q$。特别地,本讲在定理 0.4 里隐式用到的**逻辑分配律** $P \vee (Q \wedge R) \equiv (P \vee Q) \wedge (P \vee R)$ 与德摩根定律,L01 会用真值表逐条证明。
- **L02 (Proof Techniques II,逆否 / 反证 / 分情形 / 鸽笼)**:本讲反复强调的"逆命题 $Q \Rightarrow P$ 与原命题 $P \Rightarrow Q$ 不等价",是 L02 的**入场券**。正因为不等价,我们才不能靠"反过来"证定理;但 L02 会给出一个合法替代品 —— **逆否 (contrapositive)** $\neg Q \Rightarrow \neg P$,它与原命题**等价**。更巧的是:定理 0.3 的证明链是**可逆的**,所以它顺带给出了"¬(数字和可被 9 整除) $\Rightarrow$ ¬(n 可被 9 整除)"的逆否证明。此外本讲定理 0.4 的 $\supseteq$ 方向已用到"反设 $x \notin A$"的分情形手法,与 L02 的分情形证明同源。
- **L03 (Induction,归纳法)**:本讲定理 0.2 的条件 $0 < n < 1000$ 只是**记号上的方便**(只需三位)。要把它推广到"任意位数 $n = \sum_{i=0}^{k-1} a_i 10^i$",必须对位数 k 做归纳 —— 这正是 L03 的第一个标准范例(对数的位数或对 n 归纳,逐步剥离末位数字)。同样的模式会在 L03 证明"每个大于 1 的自然数都有质因数"(本讲第 3 节提到的引理)时再次出现。
- **L04 (Modular Arithmetic,模运算)**:本讲的按位展开技巧的"正确语言"是同余。$10 \equiv 1 \pmod 9$ 一句话就蕴含了定理 0.2 与 0.3 两件事,而且对任意位数直接成立。L04 还会把"$a \mid b \iff b \equiv 0 \pmod a$"确立为标准转写,让整除命题变成同余命题。
- **L05–L06 (Euclid/FLT/CRT → RSA)**:本讲的反例"$6 \mid (2 \cdot 3)$ 但 $6 \nmid 2$ 且 $6 \nmid 3$"是理解**欧几里得引理**的靶子:当 a 换成质数 p 时,"$p \mid bc \Rightarrow p \mid b$ 或 $p \mid c$"才成立。RSA 的正确性证明($m^{ed} \equiv m$)就依赖这类"从整除因子中把 p 逼出来"的推理。
- **L12 (Countability,可数性)**:本讲"有限集 $|S| = k \Rightarrow |\mathcal{P}(S)| = 2^k$"这条计数事实,在无限情形会升格为对"等势 (equinumerous)"的讨论;而 $\mathbb{N} \times \mathbb{N}$ 的对角枚举则是 $\mathbb{Q}$ 可数、$\mathbb{R}$ 不可数(对角线论证)的技术前奏。
- **L14–L15 (Counting → Probability Foundations)**:"构造子集 = 对每个元素做一次独立二选一"这一条,是 L14 乘法法则的原型;而 L15 把随机试验的样本空间定义为一个集合 Ω、事件定义为 Ω 的子集 $\mathcal{F}$,本讲的 $\cup / \cap / \setminus$ 就直接变成了"或事件 / 与事件 / 补事件"。

关键要点

1. **证明的定义**:证明是**从公理出发的有限步逻辑推导**,每一步都必须有依据(定义、代数运算、已知结果、闭包)。它的全部价值在于**用有限手段担保无限多个情形**;测试与举例只是证据 (evidence),永远不是证明。记住反例数字 $1681 = 41^2$:$n^2 + n + 41$ 在前 40 个自然数上全是质数,仍不是恒质数。
2. **直接证明的模板**:`Assume P` → 展开定义 → 代数变形 → 凑出 Q 的形状 → 检查见证对象仍属合法集合(闭包) → `Therefore Q`。**永远不要假设你想证的东西**,也**永远不要偷偷假设具体数值**——正是"任意"才换来 $\forall$。
3. **整除证明的两把钥匙**:把 $a \mid b$ 翻译成 $b = qa$("存在一个 q",造出来就算证完);把 $a \mid (b \pm c)$ 和 $a \mid kb$ 当作标准零件使用(定理 0.1 与推论 0.1、0.2)。**整除不能拆到因子**:$6 \mid 6$ 不代表 $6 \mid 2$ 或 $6 \mid 3$(换成质数才成立)。
4. **等价命题(⟺)必须双向证**:定理 0.2(数字和 $\Rightarrow 9 \mid n$)与定理 0.3($9 \mid n \Rightarrow$ 数字和)合起来才给出"$9 \mid n \iff$ 数字和可被 9 整除"。**原命题与逆命题不等价**:$6 \mid (2 \cdot 3)$、$3 \mid (1+2)$、29 的数字和可被 11 整除却 $11 \nmid 29$,三个反例都说明这一点。
5. **集合相等 = 双向包含**:$A = B \iff (A \subseteq B \wedge B \subseteq A)$。证法是**元素追踪**:固定任意 x,把 $x \in \cdot$ 翻译成布尔条件,再分情形(或反设某个否定条件)推进。**只证一个方向是错的**(本讲的 $A \cup (B \cap C) \supseteq (A \cup B) \cap C$ 就是"单向真、整体假"的陷阱)。量词方面:**$\exists$ 是广义的 $\vee$,$\forall$ 是广义的 $\wedge$**,且嵌套量词**不可交换**。

常见误区与注意事项

1. **把"验证了很多例子"当成证明。** n^2+n+41 在 $n=0,\dots,39$ 上全部为质数，却在 $n=40$ 崩掉（$1681=41^2$）。凡是"∀"开头的命题，举例只能推翻它（一个反例），永远不能确立它。
2. **把逆命题当原命题用。** 读到"$a\mid b\Rightarrow a\mid b+c$"就自动使用"$a\mid b+c\Rightarrow a\mid b$"。$3\mid(1+2)$ 但 $3\nmid 1$。**箭头方向是有信息的，不能想当然掉头。**
3. **只证一个包含方向就宣布集合相等。** $A\cup(B\cap C)\subseteq(A\cup B)\cap C$ 在 $A=\{1,2,3\},B=\{2,3,4\},C=\{3,5\}$ 上成立，但两边并不相等（左边有 $1,2$，右边没有）。**两个方向都要写，且要写清"由外延公理"收尾。**
4. **混淆 $\in$ 与 $\subseteq$。** $\{1\}\subseteq\{1,2,3\}$（左边是子集），但 $\{1\}\in\mathcal{P}(\{1,2,3\})$（左边是元素）。同样地 $\varnothing\neq\{\varnothing\}$：前者 $|\varnothing|=0$，后者 $|\{\varnothing\}|=1$，且 $\varnothing\in\{\varnothing\}$ 而 $\varnothing\subsetneq\{\varnothing\}$。
5. **忘了检查"见证对象"是否在允许的集合里。** 定理 0.1 的第 5 步"$q_1,q_2\in\mathbb{Z}\Rightarrow q_1+q_2\in\mathbb{Z}$"、定理 0.2 第 7 步"$k+11a+b\in\mathbb{Z}$"、定理 0.3 第 6 步"$l-11a-b\in\mathbb{Z}$"——这些看似显然的句子**必须写出来**，因为"封闭性"是结论成立的必要条件。（$\mathbb{N}$ 对减法不封闭就是一个立刻失效的例子：$0-3\notin\mathbb{N}$。）
6. **否定量词时不翻转、或把蕴涵的否定写错。** $\neg(\forall x\,P(x))$ 是 $\exists x\,\neg P(x)$（**不是** $\forall x\,\neg P(x)$）；更常见的错误是把 $\neg(\forall x)(P(x)\Rightarrow Q(x))$ 写成 $(\forall x)(P(x)\Rightarrow\neg Q(x))$，正确形式是 $(\exists x)(P(x)\wedge\neg Q(x))$（"有一个反例 x：前提成立而结论不成立"）。L01 第 3 节会专门训练这一点。
7. **用"显然""易得"跳过关键推导。** 特别地，**不要**在证明中无意引用尚未证明的东西（例如用"$a\mid b\Rightarrow a\mid kb$"却不展开定义），也不要像 L02 那个假证明一样**除以零**（$x=y\Rightarrow x-y=0$）或**对不等式两边平方**（$-2\le 1$ 但 $4\not\le 1$）。

思考题（带答案）

Q1.（计算） (a) 取 $n=837$，用定理 0.2 的按位展开式 $n=9(k+11a+b)$ 验证 $9\mid 837$，写出 k 与最终商 q。(b) 取 $n=372$，说明为什么定理 0.2 不能用来断言 $9\mid 372$，并给出 $372 \bmod 9$。(c) 判断真假并说明："若 $11\mid n$ 的数字和，则 $11\mid n$（$0<n<1000$）"。

> ▸ **答案**
>
> (a) $n=837=\overline{837}$，故 $a=8,\ b=3,\ c=7$，数字和 $a+b+c=18$，于是 $k=18/9=2$。代入
>
> $$q=k+11a+b=2+11\times 8+3=2+88+3=93,$$
>
> 于是 $9q=9\times 93=837=n$ ✓。（验算：$837\div 9=93$ 整除。）
>
> (b) 372 的数字和是 $3+7+2=12$，而 $12\div 9=1.\overline{3}$，**不能被 9 整除**，所以定理 0.2 的前提不满足，不能用它。实际计算：$372=9\times 41+3$，故 $372 \bmod 9=3$。注意此时**数字和与 n 模 9 同余**（$12 \bmod 9=3$），这个更强的现象要等 L04 用同余语言才能精确表述。
>
> (c) **假。** 反例 $n=29$：数字和 $2+9=11$，$11\mid 11$ 成立；但 $29=11\times 2+7$，$11\nmid 29$。原因见定理 0.2 的机制解说：对 9 有效，是因为 $10\equiv 1\pmod 9$；对 11 则 $10\equiv -1\pmod{11}$，所以正确的 11 规则是**交错和**（从右往左交替加减各位数字），不是简单数字和。29 的交错和是 $9-2=7$，$11\nmid 7$，与 $11\nmid 29$ 一致 ✓。

Q2.（证明） (a) 用直接证明证明：对任意 $a,b\in\mathbb{Z}$ 与任意 $k\in\mathbb{Z}$，若 $a\mid b$ 则 $a\mid(kb)$。(b) 证明：对任意 $a,b\in\mathbb{Z}$，若 $a\mid b$ 且 $b\mid a$ 且 $a,b>0$，则 $a=b$。(c) 在 (b) 中去掉条件 $a,b>0$，命题还成立吗？

> ▸ **答案**
>
> (a) 直接证明。假设 $a\mid b$。由定义，存在整数 q 使 $b=qa$。两边同乘 k：$kb=k(qa)=(kq)a$（依据：乘法结合律、交换律）。由于 $k,q\in\mathbb{Z}$ 且 $\mathbb{Z}$ 对乘法封闭，$kq\in\mathbb{Z}$。故存在整数 $q':=kq$ 使 $kb=q'a$，即 $a\mid(kb)$。■
>
> (b) 直接证明。假设 $a\mid b$ 且 $b\mid a$，$a,b>0$。由 $a\mid b$，存在 $q_1\in\mathbb{Z}$ 使 $b=q_1a$；由 $b\mid a$，存在 $q_2\in\mathbb{Z}$ 使 $a=q_2b$。代入得
>
> $$a=q_2b=q_2(q_1a)=(q_1q_2)\,a,$$
>
> 即 $a(1-q_1q_2)=0$。因为 $a>0$（故 $a\neq 0$），必须 $q_1q_2=1$。整数乘积为 1 只有两种可能：$q_1=q_2=1$ 或 $q_1=q_2=-1$。再由 $b=q_1a$ 与 $a,b>0$ 知 $q_1=b/a>0$，故排除 $q_1=-1$，得 $q_1=1$，即 $b=a$。■
>
> **关键一步是"$a\neq 0$ 才能约掉 a"** —— 这正是"不要除以零/不要忘记讨论零"的纪律（L02 的"$1=2$"假证明就错在这一步）。
>
> (c) **不成立。** 反例 $a=3,\ b=-3$：$3\mid(-3)$（$-3=(-1)\cdot 3$）且 $(-3)\mid 3$（$3=(-1)\cdot(-3)$），但 $a\neq b$。此时 $q_1=q_2=-1$，正是被正数条件排除的那一支。所以 $a,b>0$ 这个条件**不可省**。

Q3.（集合与反例） (a) 用双向包含证明 $A\setminus(B\cup C)=(A\setminus B)\cap(A\setminus C)$。(b) 取 $A=\{1,2,3,4\},B=\{2,3,4\},C=\{3,4,5\}$ 逐元素验证。(c) 定理 0.1 的逆命题是否成立？给出反例。

▸ 答案

(a) 记 $L = A \setminus (B \cup C)$，$R = (A \setminus B) \cap (A \setminus C)$。

$L \subseteq R$：取任意 $x \in L$。由集合差定义，$x \in A$ 且 $x \notin B \cup C$。由 $x \notin B \cup C$ 知 $x \notin B$ 且 $x \notin C$（若 x 在任一者中，就会在并集中）。于是 $x \in A$ 且 $x \notin B$ 给出 $x \in A \setminus B$；$x \in A$ 且 $x \notin C$ 给出 $x \in A \setminus C$。两者合并得 $x \in R$。

$R \subseteq L$：取任意 $x \in R$。则 $x \in A \setminus B$ 且 $x \in A \setminus C$，故 $x \in A$，且 $x \notin B$，且 $x \notin C$。既然 x 既不在 B 也不在 C，就不在 $B \cup C$ 中。于是 $x \in A$ 且 $x \notin B \cup C$，即 $x \in L$。

由外延公理，$L = R$。■

（机制要点） "$x \notin B \cup C \iff (x \notin B \wedge x \notin C)$" 正是**德摩根定律** $\neg(P \vee Q) \equiv \neg P \wedge \neg Q$ 的集合版本；这也解释了为什么右边是 $\cap$ 而不是 $\cup$。

(b) $A = \{1,2,3,4\}$，$B \cup C = \{2,3,4,5\}$，故 $L = A \setminus \{2,3,4,5\} = \{1\}$。另一方面 $A \setminus B = \{1\}$，$A \setminus C = \{1,2\}$，故 $R = \{1\} \cap \{1,2\} = \{1\}$。二者相等 ✓。（可再检查 $x = 2$：$2 \in A$ 且 $2 \in B$，故 $2 \notin L$ 且 $2 \notin A \setminus B$，故 $2 \notin R$ —— 一致。）

(c) **不成立。** 定理 0.1 的逆命题是"若 $a \mid (b+c)$，则 $a \mid b$ 且 $a \mid c$"。反例：$a = 3,\ b = 1,\ c = 2$。则 $b + c = 3$，$3 \mid 3$ 为真；但 $1 = 3q$ 无整数解，故 $3 \nmid 1$，逆命题为假。另一个更容易记的反例：$a = 6,\ b = 2,\ c = 4$，则 $6 \mid 6$ 但 $6 \nmid 2$（且 $6 \nmid 4$）。**结论：原命题真不蕴含逆命题真。**

Lecture 1: Propositional Logic & Proof Techniques（命题逻辑与证明技巧）

概述

上一讲我们已经在使用"若 P 则 Q"这样的句式来写证明，但还没检查过这些句式本身是什么意思。本讲补上这一层地基：先把**命题 (proposition)** 与逻辑联结词 $\neg, \wedge, \vee, \Rightarrow, \iff$ 精确定义好（全部用真值表刻画），再讨论追溯每个定理"藏在哪个逻辑形式里"，最后处理数学语言中最容易出错的部分 —— **量词 (quantifier)** 的辖域、嵌套顺序敏感性，以及**否定的机械法则**。本讲的三根支柱是：**蕴涵 $P \Rightarrow Q$ 只在 P 真 Q 假时为假**（因此前件为假时"空洞真"）、**$P \Rightarrow Q \equiv \neg Q \Rightarrow \neg P$ 但 $P \Rightarrow Q \not\equiv Q \Rightarrow P$**、**$\neg$ 穿过 $\forall/\exists$ 时量词必须翻转**。这些不是"语言游戏"：L02 的逆否证明、L03 的归纳法框架、乃至 L13 停机问题的否定式都直接建立在本讲的改写规则之上。

核心概念的直观解释

命题 (Proposition)

- **定义**：命题是一个**有确定真假的陈述句**（"a statement which is either true or false"）。它的真假是客观的，不依赖说话人、不依赖语境、不依赖"程度"。
- **直观解释**：判断一句话是不是命题，只问一个问题 —— **"它有没有一个确定的是非答案？"** 有就是命题（哪怕我们暂时不知道答案），没有就不是。这里是几个边界案例：

语句	是命题吗?	理由
$\sqrt{3}$ 是无理数	是	确定真（真值为 T）
$1 + 1 = 5$	是	确定假（真值为 F）
Julius Caesar 在十岁生日早餐吃了两个鸡蛋	是	虽然我们无从查证，但历史上那一刻的事实是确定的，故它有确定真值
$2 + 2$	否	这不是一个陈述句，只是一个表达式，没有真值
$x^2 + 3x = 5$	否	x 是什么？未定；只有代入具体的 x 后才变成命题
Schwarzenegger 经常吃西兰花	否	"经常"有多经常？模糊词使真假无定义
Henry VIII 不受欢迎	否	"不受欢迎"是程度问题，无确定分界

- **关键区分**：$x^2 + 3x = 5$ **不是**命题，但一旦**用量词封口**，它就变成命题：
- $(\exists x \in \mathbb{R})(x^2 + 3x = 5)$ —— **真**。移项得 $x^2 + 3x - 5 = 0$，判别式 $\Delta = 3^2 - 4 \cdot 1 \cdot (-5) = 9 + 20 = 29 > 0$，故有两个实根 $x = \dfrac{-3 \pm \sqrt{29}}{2} \approx 1.193$ 与 -4.193。
- $(\exists x \in \mathbb{Z})(x^2 + 3x = 5)$ —— **假**。两个根都**不是整数**（$\sqrt{29}$ 是无理数），而整数里 $x^2 + 3x$ 恒为整数，5 也是整数，但逐一检查 $x = -5, \ldots, 1$ 都得不到 5（$x = -1$ 给 -2，$x = 1$ 给 4，$x = 2$ 给 10）。
- $(\forall x \in \mathbb{R})(x^2 + 3x = 5)$ —— **假**（取 $x = 0$ 得 $0 \neq 5$）。

这三句话的谓词完全相同，只因**量词与论域不同**就产生不同的真值 —— 这解释了本讲第 2 节的动机：**量词是让谓词变命题的装置，而论域是它的一部分**。 – **"这句话是假的"为什么不是命题？** 因为它**自指 (self-reference)**：如果它为真，则按它自己的话它是假的；如果它为假，则它是真的。两个方向都撞上矛盾，所以它**没有**一致的真值可分配。这类句子叫**悖论 (paradox)**，是形式化系统必须排除的对象（L13 会看到这背后是哥德尔式自指的力量）。 – **"真实但未知"仍是命题**：命题的定义只要求真值**存在**，不要求**我们已知**。例如"π 的十进制展开中数字 7 出现无穷多次"是命题（真值确定，虽然至今无人证明），而"7 出现了很多次"不是命题（"很多"模糊）。

逻辑联结词：与 / 或 / 非

设 P, Q 是代表命题的变量（例如 P 表示"3 是奇数"）。含变量的这类表达式叫**命题形式 (propositional form)**。

- **合取 (Conjunction)**：$P \wedge Q$（"P 且 Q"）—— **仅当 P 与 Q 都**真时为真。

- **析取 (Disjunction)**：$P \vee Q$（"P 或 Q"）—— **只要 P 与 Q 至少一个**为真就为真。注意这是**包含式或 (inclusive or)**：P 和 Q 都真时 $P \vee Q$ 也为真，与日常语言中"要汤还是沙拉"的排他式或不同。数学与计算机中的"或"一律是包含式的（C/Java 的 `||`、Python 的 `or` 都是）。
- **否定 (Negation)**：$\neg P$（"非 P"）—— P 为假时为真。
- **真值表 (Truth table)**：列出所有输入组合与对应输出。这和函数表完全一样，只是变量取布尔值。n 个变量的真值表有 2^n 行。
- **排中律 (law of the excluded middle)**：对任何命题 P，要么 P 真，要么 $\neg P$ 真，**没有第三种可能**。因此 $P \vee \neg P$ 恒真。
- **重言式 (tautology) 与矛盾式 (contradiction)**：**无论**变量取何真值组合都为真的命题形式叫重言式（如 $P \vee \neg P$）；恒假的叫矛盾式（如 $P \wedge \neg P$）。注意 $P \wedge \neg P$ 永假不是因为 P 特殊，而是因为在任何一行里 P 与 $\neg P$ 必然一真一假，合取就必然有一个假。
- **具体示例**：令 P 表示"3 是奇数"（T），Q 表示"4 是奇数"（F），R 表示"$4+5=49$"（F）。则 $P \wedge R = \mathbf{T} \wedge \mathbf{F} = \mathbf{F}$；$P \vee R = \mathbf{T} \vee \mathbf{F} = \mathbf{T}$；$\neg Q = \neg \mathbf{F} = \mathbf{T}$。

完整真值表（本讲第一个必背 ASCII 表）

```
基本联结词真值表（四个输入行 = 所有可能）
=====================================================================
  P   Q  ||  P ∧ Q  |  P ∨ Q  |  P ⇒ Q  |  P ⟺ Q  |  ¬P
==========++=========+=========+==========+==========+======
  T   T  ||    T    |    T    |    T     |    T     |   F
  T   F  ||    F    |    T    |    F     |    F     |   F
  F   T  ||    F    |    T    |    T     |    F     |   T
  F   F  ||    F    |    F    |    T     |    T     |   T
=====================================================================
  ∧ : 全真才真 (AND, 交集思维)      ⇒ : 只有 T→F 那行为假 (最反直觉)
  ∨ : 有真就真 (OR, 并集思维)       ⟺ : 两列同值才真 (等价 / 同真同假)
  ¬ : 取反                          ¬(P ∨ Q) 见下方德摩根定律
=====================================================================
读法速记:  ∧ 像乘法(0 吸收),  ∨ 像加法(1 吸收),  ¬ 是 1−x
        T=1, F=0 时:  P∧Q = P*Q,  P∨Q = P+Q−P*Q,  ¬P = 1−P
```

蕴涵 (Implication)：$P \Rightarrow Q$

- **定义**：$P \Rightarrow Q$ 读作"P 蕴涵 Q""若 P 则 Q"。"$P \Rightarrow Q$ **为假，当且仅当 P 真而 Q 假**"，其余三行全为真。P 叫**前件 / 假设 (hypothesis / antecedent)**，Q 叫**后件 / 结论 (conclusion / consequent)**。
- **直观解释（"它是什么意思？")**：$P \Rightarrow Q$ 不是"断言 P 成立"，而是**一条"承诺"**："只要 P 成立，Q 就一定成立。"要"毁约"必须真的出现"P 成立但 Q 不成立"的情形；如果你**从未**让 P 成立（前件为假），那这条承诺根本没有被触发，谈不上违约，于是它算"守住了"。
- **日常类比**：
- "如果你站在雨里，你就会淋湿。" 这句话**唯一**的假情形是"你站在雨里却没淋湿"。
- "如果你通过了这门课，你会拿到证书。" 唯一的假情形是"通过了却没拿到证书"；如果你根本没通过，无论拿没拿到证书，这句话都不算假。
- 反面类比（说明$P \Rightarrow Q$ 与因果无关）："若 $1+1=3$，则月亮是奶酪做的"在数学上也是**真**的 —— 数学只看真值组合，不追究"因果机制"。
- **空洞真 (vacuously true)**：当前件 P 为假时，整个蕴涵为真，这种"白白为真"的情形叫**空洞真**。因此下列句子在数学上都是**真命题**（虽然说起来荒唐）：
- "如果猪会飞，那么马会读书。"（前件假 ⇒ 真）
- "如果 14 是奇数，那么 $1+2=18$。"（14 是偶数 ⇒ 前件假 ⇒ 真）
- "如果 4 是奇数，那么 3 是奇数。"（4 是奇数 $\Rightarrow$ 3 是奇数）—— 前件假，故为真。
- **具体示例**：令 P = "3 是奇数"（T），Q = "4 是奇数"（F），R = "6 是偶数"（T）。则 $P \Rightarrow R$ 为 T（T 蕴涵 T）；$Q \Rightarrow P$ 为 T（**空洞真**，因为 Q 假）；$R \Rightarrow P$ 为 T。又因为 $P \Rightarrow R$ 与 $R \Rightarrow P$ 都真，所以 $P \iff R$ 为 T。
- $(P \Rightarrow Q) \equiv (\neg P \vee Q)$：把真值表最后两列一比即可看出二者**每一行都相同**。这个等价式是化简/计算蕴涵的"工程手册"：把蕴涵翻译成"或"，就能直接用德摩根定律等工具处理。它的直观读法是："要么前件不成立，要么后件成立 —— 反正不许出现'前件成立而后件不成立'。"
- **同一个蕴涵的六种说法**（数学题里全都会出现，必须能互相翻译）：

说法	形式
若 P，则 Q	if P, then Q
P 蕴涵 Q	P implies Q
Q 若 P	Q if P
P 仅当 Q	P only if Q
P 是 Q 的**充分条件**	P is sufficient for Q
Q 是 P 的**必要条件**	Q is necessary for P
除非**非** P，否则 Q	Q unless not P

最容易读错的是"仅当"："P only if Q" **不是** $Q \Rightarrow P$，而是 $P \Rightarrow Q$。记忆法：`only if` 直接修饰后件 Q，意思是"Q 是唯一允许的出口"，即"P 成立时 Q 必须成立"，也就是 $P \Rightarrow Q$。同理"P 是充分条件"（有 P 就够）与"Q 是必要条件"（没 Q 就不行）都是 $P \Rightarrow Q$ 的换装说法。

双条件 (Biconditional)：$P \iff Q$

- **定义**：$P \iff Q$ 表示"P 当且仅当 Q"（"P iff Q"），定义为 $(P \Rightarrow Q) \wedge (Q \Rightarrow P)$。它**当且仅当 P 与 Q 真值相同**时为真。
- **直观解释**：$P \iff Q$ 是"两句同生共死"：要么同真，要么同假。它是数学中"等价 (equivalent)"的正式写法，也是"当一个定理可以双向使用"的标志。
- **具体示例**：P = "3 是奇数"（T），R = "6 是偶数"（T），二者真值相同，故 $P \iff R$ 为 T。（注意 3 与 6 之间没有因果关系，$P \iff R$ 只说二者真值一致。）
- **一个必须记住的等式**：$P \iff Q \equiv (P \Rightarrow Q) \wedge (Q \Rightarrow P) \equiv (\neg P \vee Q) \wedge (\neg Q \vee P)$。这就是 L00 中"证等价要双向各证一次"的逻辑根据。

命题的三种"变体"：逆否 / 逆 / 否

给定蕴涵 $P \Rightarrow Q$：

名称	形式	与原命题的关系
原命题 (original)	$P \Rightarrow Q$	——
逆否命题 (contrapositive)	$\neg Q \Rightarrow \neg P$	**逻辑等价**（真值表逐行相同）
逆命题 (converse)	$Q \Rightarrow P$	**不等价**（可能一真一假）
否命题 (inverse)	$\neg P \Rightarrow \neg Q$	**不等价**；但它与逆命题互为逆否，所以 $\textbf{inverse} \equiv \textbf{contrapositive of converse}$

- **直观解释**：**逆否**是"把箭头掉头、并同时给两端都加否定"，两个动作**互相抵消**了信息，所以意思不变（"没淋湿 ⇒ 没站在雨里"与原句同义）。**逆命题**只掉头不加否定，**凭空多要了一个承诺**（"淋湿了 ⇒ 一定站在雨里"，可你有可能是被泼的）。**否命题**只加否定不掉头，同样是"换了话题"。
- **具体例子**：原句"若你通过了这门课，则你收到了证书。"
- 逆否："若你**没有收到**证书，则你**没有通过**这门课。"（同义，真值相同）
- 逆命题："若你收到了证书，则你通过了这门课。"（**不等价**：可能有人拿到了参与证书却未通过）
- 否命题："若你**没有通过**这门课，则你**没有收到**证书。"（也不等价）
- **具体示例（数字版）**：原命题"若 n 能被 4 整除，则 n 是偶数"（真）。
- 逆否："若 n 是奇数，则 n 不能被 4 整除"（真，与原命题等价）。
- 逆命题："若 n 是偶数，则 n 能被 4 整除"（**假**，反例 $n = 2$：2 是偶数但 $4 \nmid 2$；$n = 6, 10$ 同理）。
- 否命题："若 n **不能**被 4 整除，则 n 是**奇数**"（**假**，同样反例 $n = 2$：前件真而结论假）。

德摩根定律 (De Morgan's Laws)

- **定义**：$\neg(P \wedge Q) \equiv (\neg P \vee \neg Q)$，$\neg(P \vee Q) \equiv (\neg P \wedge \neg Q)$。
- **直观解释（"为什么是反直觉的？"）**：否定"两个都成立"**不需要**两个都失败 —— 只要**有一个**失败就够了（于是 $\vee$）；否定"至少一个成立"则需要**两个都**失败（于是 $\wedge$）。**注意连接词翻转：$\wedge$ 与 $\vee$ 互换。** 忘记翻转是学生最经典的错误之一。
- **日常类比（有画面感的版本）**："我周末既交作业又打扫房间"这个承诺被打破，只需要满足"没交作业"**或**"没打扫房间"其中之一，不需要两件都没做。反过来，我说"我周末会交作业或者打扫房间"，要证明我食言，你必须同时确认"作业没交"**且**"房间没扫"。
- **旧金山类比**：U = 全体居民。A = "戴眼镜的人"，B = "戴帽子的人"。$\overline{A \cup B}$（既不戴眼镜也不戴帽子）$= \overline{A} \cap \overline{B}$（不戴眼镜的人 与 不戴帽子的人 的交）✓。而 $\overline{A \cap B}$（不是"两者都戴"的人）$= \overline{A} \cup \overline{B}$（不戴眼镜的，或 不戴帽子的）✓ —— 一个"只戴眼镜"的居民证明了这个集合**远大于**"两样都不戴"的人。

逻辑等价式家族（分配律、结合律、交换律……）

这些定律让命题形式可以像代数式一样"化简"。下表中的每一条都用穷举真值表验算通过（P, Q, R 的全部 8 种组合）：

名称	定律
交换律 (commutativity)	$P \wedge Q \equiv Q \wedge P$；$P \vee Q \equiv Q \vee P$
结合律 (associativity)	$(P \wedge Q) \wedge R \equiv P \wedge (Q \wedge R)$；$(P \vee Q) \vee R \equiv P \vee (Q \vee R)$
分配律 (distributivity)	$P \wedge (Q \vee R) \equiv (P \wedge Q) \vee (P \wedge R)$；$P \vee (Q \wedge R) \equiv (P \vee Q) \wedge (P \vee R)$
幂等律 (idempotence)	$P \wedge P \equiv P$；$P \vee P \equiv P$
吸收律 (absorption)	$P \wedge (P \vee Q) \equiv P$；$P \vee (P \wedge Q) \equiv P$
双重否定 (double negation)	$\neg(\neg P) \equiv P$
德摩根	见上
蕴涵转或	$(P \Rightarrow Q) \equiv (\neg P \vee Q)$
逆否等价	$(P \Rightarrow Q) \equiv (\neg Q \Rightarrow \neg P)$
双条件展开	$(P \iff Q) \equiv (P \Rightarrow Q) \wedge (Q \Rightarrow P) \equiv (\neg P \vee Q) \wedge (\neg Q \vee P)$
假言三段论 (hypothetical syllogism)	$\big((P \Rightarrow Q) \wedge (Q \Rightarrow R)\big) \Rightarrow (P \Rightarrow R)$

- **具体示例（用定律化简）**：验证 $\neg(P \Rightarrow Q) \equiv P \wedge \neg Q$。

$$\neg(P \Rightarrow Q) \equiv \neg(\neg P \vee Q) \equiv \neg(\neg P) \wedge \neg Q \equiv P \wedge \neg Q.$$

第一步用"蕴涵转或"，第二步用德摩根（注意 ∨ 翻成 ∧），第三步用双重否定。**结论很重要：否定一个蕴涵不得到蕴涵，而得到一个合取** —— "若 P 则 Q"的反面是"P 成立**并且** Q 不成立"（即"存在一个反例"），**不是**"若 P 则非 Q"。这是本讲最值钱的一条改写。

谓词 (Predicate / Propositional Formula)

- **定义**：含自由变量的陈述，代入具体值后成为命题，例如"n^2+n+41 是质数"是含变量 n 的谓词。记作 $P(n)$、$P(x,y)$。
- **直观解释**：谓词是"命题的模板"或"布尔值函数"：$P: U \to \{\mathrm{T},\mathrm{F}\}$。$P(1)$ 就是"43 是质数"（T），$P(40)$ 就是"1681 是质数"（F，因为 $1681 = 41^2$）。**谓词本身没有真值，只有"在某个输入上的真值"。**

量词 (Quantifiers)

- **定义**：**全称量词** (universal quantifier) $(\forall x \in U)\,P(x)$ 表示"对论域 U 中的**每一个** x，$P(x)$ 都成立"；**存在量词** (existential quantifier) $(\exists x \in U)\,P(x)$ 表示"论域 U 中**至少存在一个** x 使 $P(x)$ 成立"。**论域** (universe) U 是变量允许取值的集合，是量词命题的一部分（换论域可以改变真值）。论域明确时省略：$\exists x\,(x \text{ lays eggs})$。
- **直观解释**：量词是把谓词"批量封口"的装置，也是为什么"$x^2+3x=5$"不是命题而"$(\exists x \in \mathbb{R})(x^2+3x=5)$"是命题 —— 后者有一个明确的论域，且被量词封死了自由变量。
- **"some" 在数学里就等于 "at least one"**："有些哺乳动物会下蛋"正式化为 $(\exists x \in \text{mammals})(x \text{ lays eggs})$。数学的"存在"**不暗示稀有或唯一**：只说至少一个。
- **无限论域下的重要限制**：在**有限**论域 $U=\{1,2,3,4\}$ 下，

$$(\exists x \in U)\,P(x) \equiv P(1) \vee P(2) \vee P(3) \vee P(4), \qquad (\forall x \in U)\,P(x) \equiv P(1) \wedge P(2) \wedge P(3) \wedge P(4).$$

也就是说 ∃ = 一大堆 ∨，∀ = 一大堆 ∧。但在**无限**论域（如 $\mathbb{N}$、$\mathbb{Z}$）里，你无法写下无穷长的合取/析取式，量词就成了**不可消除的**基本装置。这一条对应关系是后面量词否定律的根源。 – **具体示例（"有界"与"无界"的分水岭，强烈建议背下来）**：

命题	真值	说明
$(\exists x \in \mathbb{Z})(x<2 \wedge x^2=4)$	T	取 $x=-2$：$-2<2$ 且 $4=4$ ✓
$(\forall x \in \{1,2,3,4\})(x^2>10)$	F	$x=1$ 时 $1>10$ 假
$(\exists x \in \{1,2,3,4\})(x^2>10)$	T	$x=4$ 时 $16>10$ ✓
$(\forall n \in \mathbb{N})(n^2+n+41$ 是质数$)$	F	$n=40$ 时 $1681=41^2$、$n=41$ 时 $1763=41\times43$
$(\forall x \in \mathbb{Z})(\exists y \in \mathbb{Z})(y>x)$	T	取 $y=x+1$ 即可
$(\exists y \in \mathbb{Z})(\forall x \in \mathbb{Z})(y>x)$	F	等价于"存在最大整数"，而整数无上界

- **具体示例（$U=\{1,2,3,4\}$ 上 $P(x) :=$ "$x^2>10$" 的四联对比）**：

```
量化命题与其否定在 U = {1,2,3,4} 上的真值  (P(x) := "x² > 10")
=================================================================
  x   |  x²  |  P(x)     ||  说明
 -----+------+-----------++-----------------------------------------
  1   |  1   |   F       ||  P(1) 假  -->  这就是 ∀x P(x) 的反例
  2   |  4   |   F       ||
  3   |  9   |   F       ||
  4   | 16   |   T       ||  P(4) 真  -->  这就是 ∀x ¬P(x) 的反例
=================================================================
  ∃x P(x)        = T        (因为 P(4) 真)
  ∀x P(x)        = F        (因为 P(1) 假)
  ¬(∀x P(x))     = T        <==>  ∃x ¬P(x) = T   (P(1) 假)   一致 ✓
  ∀x ¬P(x)       = F        (因为 P(4) 真)
  ¬(∃x P(x))     = F        <==>  ∀x ¬P(x) = F                一致 ✓
=================================================================
 两对量词否定律在这个例子上都对上了；下面给出一般证明。
```

嵌套量词：顺序不能交换

- **现象**：$(\forall x)(\exists y)P(x,y)$ 与 $(\exists y)(\forall x)P(x,y)$ 是**不同的命题**，前者一般不蕴含后者。
- **直观解释（"同一个人 vs 每次不同的人"）**：考虑
- **(A)** \(\forall t \in T)(\exists p \in P)\;(\text{\}p在时刻tExtra close brace or missing open brace：每次我坐地铁，**都有人**被刺（**可以是每次不同的人**）。
- **(B)** \(\exists p \in P)(\forall t \in T)\;(\text{\}p在时刻tExtra close brace or missing open brace：**存在某个人 Joe**，每次我坐地铁，**都是 Joe** 被刺。

(B) 蕴含 (A)（若 Joe 每次都被刺，当然每次"有人"被刺），但 (A) 不蕴含 (B)（可能是轮流被刺的不同人）。(B) 是强得多的断言。 – **另一个直观解释（"每个人都有母亲" vs "有一个人是所有人的母亲"）**： – \((\forall x \in \text{people})(\exists y \in \text{people})(\text{\}y是xExtra close brace or missing open brace —— **真**：每个人都各自有一个母亲（母亲随 x 变化）。 – \((\exists y \in \text{people})(\forall x \in \text{people})(\text{\}y是xExtra close brace or missing open brace —— **假**（荒谬）：要求存在一个人是**所有人**的母亲。 – **具体示例（数学版）**：$(\forall x \in \mathbb{Z})(\exists y \in \mathbb{Z})(x<y)$ 为**真**（对每个 x 取 $y=x+1$，"见证 y 依赖 x"）；而 $(\exists y \in \mathbb{Z})(\forall x \in \mathbb{Z})(x<y)$ 为**假**（它等价于"存在最大整数"，但不存在）。**判据：若 ∃ 在内层，那么见证对象 y 通常依赖于外层的 x；一旦把 ∃ 提到外层，y 就必须"一次性对所有 x 生效"，这是一个严苛得多的要求。** – **注意 ∃∀ ⇒ ∀∃ 是单向的**：$(\exists y)(\forall x)P(x,y) \Rightarrow (\forall x)(\exists y)P(x,y)$ 恒真（同一个 y 通吃所有 x，当然对每个 x 也存在这样的 y）；反过来不成立。上面"母亲"的例子就是这个单向箭头的最好注解：∃∀ 假而 ∀∃ 真。

"至少 / 至多 / 恰好"三个数量的量化写法

- **至少三个不同的 x 满足 P**（论域 $\mathbb{Z}$）：

$$\exists x\,\exists y\,\exists z\,\big(x\neq y\wedge y\neq z\wedge z\neq x\wedge P(x)\wedge P(y)\wedge P(z)\big).$$

四个条件缺一不可：三个不等式保证**互不相同**，三个 $P(\cdot)$ 保证**都满足**。

- **至多三个不同的 x 满足 P**，写法一：

$$\exists x\,\exists y\,\exists z\,\forall d\,\big(P(d)\Rightarrow(d=x\vee d=y\vee d=z)\big).$$

读作"存在三个候选者 x,y,z，使得任何满足 P 的 d 都必是其中之一"。（注意这里没要求 x,y,z 互异：如果实际只有 2 个解，我们可以让 $x=y$ 来"凑数"。）

- **至多三个**，写法二（等价的"反证式"表达）：

$$\forall x\,\forall y\,\forall v\,\forall z\,\Big(\big(x\neq y\wedge y\neq v\wedge v\neq x\wedge x\neq z\wedge y\neq z\wedge v\neq z\big)\Rightarrow\neg\big(P(x)\wedge P(y)\wedge P(v)\wedge P(z)\big)\Big).$$

读作"任取四个**两两不同**的数，它们不可能**全都**满足 P"。这个写法完全等价，但它把"至多"说成了"不存在四个互异解"，并且已经用上了本讲的改写技巧 $\neg(P\wedge Q\wedge R\wedge S)\equiv\neg P\vee\neg Q\vee\neg R\vee\neg S$（德摩根推广）。

- **恰好三个**：把"至少三个"**且**"至多三个"两个式子用 $\wedge$ 连起来即可。**这是"恰好 = 至少 + 至多"的标准套路**，在 L14 计数中会反复出现。
- **具体示例**：$U=\{1,2,3\}$，$P(x):=$ "x 是奇数"。U 中奇数有 $1,3$ 两个。故"至少三个互异奇数"为**假**（个数 $2<3$）；"至多三个"为**真**（个数 $2\le 3$）；"恰好三个"为**假**。再把 U 换成 $\{1,2,3,5\}$：奇数 $1,3,5$ 共三个，于是"至少三个"**真**、"至多三个"**真**、"恰好三个"**真**。

完整证明与推导（核心）

定理 1.1（德摩根定律，真值表证明）：对任意命题 P,Q，

$$\neg(P\wedge Q)\equiv(\neg P\vee\neg Q),\qquad\neg(P\vee Q)\equiv(\neg P\wedge\neg Q).$$

证明策略：**真值表证明 (proof by truth table)**。命题形式的逻辑等价就是"真值表逐行相同"，而变量只有 P,Q 两个，共 $2^2=4$ 种取值组合，穷举即可。**为什么选这个策略?** 因为逻辑等价的定义本身就是"对所有真值指派，两边的值相同"，而这里真值指派**只有有限多种**。要小心的是：这种"穷举证明"只适用于**变量个数有限**的情形 —— 一旦出现量词（如 $\forall x$），论域可能无限，真值表就失效了（这正是量词否定律需要"逻辑论证 + 语义论证"而非真值表的原因）。

逐步推导（第一定律 $\neg(P\wedge Q)\equiv\neg P\vee\neg Q$）：

```
定理 (第一德摩根律)  ¬(P ∧ Q) ≡ (¬P ∨ ¬Q)
=================================================================
 行 |  P  |  Q  |  P∧Q  | ¬(P∧Q)  ||  ¬P  |  ¬Q  | ¬P∨¬Q  | 两侧相同?
====+=====+=====+=======+=========++======+======+========+===========
  1 |  T  |  T  |   T   |    F    ||  F   |  F   |   F    |    ✓
  2 |  T  |  F  |   F   |    T    ||  F   |  T   |   T    |    ✓
  3 |  F  |  T  |   F   |    T    ||  T   |  F   |   T    |    ✓
  4 |  F  |  F  |   F   |    T    ||  T   |  T   |   T    |    ✓
=================================================================
 第 5 列 (¬(P∧Q)) 与第 8 列 (¬P∨¬Q) 在全部 4 行都相同
 ==> 由逻辑等价的定义, 两式逻辑等价   ∎
=================================================================
观察: P∧Q 只在第 1 行为真, 故 ¬(P∧Q) 只在第 1 行为假;
       ¬P∨¬Q 也只在第 1 行为假 (那时 ¬P=¬Q=F)。
      "唯一的假行"重合   ==> 等价。
```

逐步推导（第二定律 $\neg(P\vee Q)\equiv\neg P\wedge\neg Q$）：

```
定理 (第二德摩根律)  ¬(P ∨ Q) ≡ (¬P ∧ ¬Q)
=================================================================
 行 |  P  |  Q  |  P∨Q  | ¬(P∨Q)  ||  ¬P  |  ¬Q  | ¬P∧¬Q  | 两侧相同?
====+=====+=====+=======+=========++======+======+========+===========
  1 |  T  |  T  |   T   |    F    ||  F   |  F   |   F    |    ✓
  2 |  T  |  F  |   T   |    F    ||  F   |  T   |   F    |    ✓
  3 |  F  |  T  |   T   |    F    ||  T   |  F   |   F    |    ✓
  4 |  F  |  F  |   F   |    T    ||  T   |  T   |   T    |    ✓
=================================================================
 第 5 列与第 8 列在全部 4 行相同   ==>   逻辑等价   ∎
观察: P∨Q 只在第 4 行为假, 故 ¬(P∨Q) 只在第 4 行为真;
       ¬P∧¬Q 也只在第 4 行为真。 两边"唯一的真行"重合。
```

（推广版，三个变量）：$\neg(P\wedge Q\wedge R)\equiv\neg P\vee\neg Q\vee\neg R$。证明只需把 $Q\wedge R$ 当作一个整体先用一次第一定律，再用结合律与一次第一定律：

$$\neg\big(P\wedge(Q\wedge R)\big)\equiv\neg P\vee\neg(Q\wedge R)\equiv\neg P\vee(\neg Q\vee\neg R)\equiv\neg P\vee\neg Q\vee\neg R.$$

【证明机制解说】：德摩根定律的"机制"是一个**双重翻转**：$\neg$ 进入括号时，(i) 把 $\wedge$ 与 $\vee$ **互换**，(ii) 给每个原子命题**分别**加 $\neg$。为什么必然互换？因为"全部成立"的失效条件是"有任一失败"（$\wedge\to\vee$），而"存在成立"的失效条件是"全部失败"（$\vee\to\wedge$）。**记忆口诀：否定进门，与或换位，逐个加非。** 后面的量词否定律是这同一条口诀的"量词版"：把 $\forall$ 看成广义 $\wedge$、$\exists$ 看成广义 $\vee$，则 $\neg\forall$ 变成 $\exists\neg$，$\neg\exists$ 变成 $\forall\neg$ —— **形式完全相同**。

定理 1.2（量词否定律）：设 $P(x)$ 是论域 U 上的谓词，则

$$\neg\big(\forall x \in U\big)P(x) \;\equiv\; \big(\exists x \in U\big)\neg P(x), \qquad \neg\big(\exists x \in U\big)P(x) \;\equiv\; \big(\forall x \in U\big)\neg P(x).$$

证明策略：**语义论证 (semantic argument)**，必要时对**有限**论域再用真值表/逻辑等价做穷举验证。理由是：真值表证明要求变量取值有限，而 U 可能是无限的（$\mathbb{Z}$、$\mathbb{N}$），所以必须给出一般论证。一般论证的骨架是**双重否定 + 排中律**：命题"$\neg(\forall x)P(x)$"为真 $\iff$ "$(\forall x)P(x)$"为假 $\iff$ 不是所有 x 都满足 P $\iff$ 至少有一个 x 不满足 $\iff$ $(\exists x)\neg P(x)$。

逐步推导（以第一式为例，走"双向因此等价"）：

1. **方向 $\Rightarrow$**：假设 $\neg\big(\forall x \in U\big)P(x)$ 为真，即"并非所有 x 都满足 P"。（依据：排中律）对任意给定的 x，$P(x)$ 要么真要么假；既然"所有 x 都满足 P"是假的，那么**不可能**每个 x 都满足 P。因此**至少存在**某个 x 使 $P(x)$ 为假，即 $\neg P(x)$ 为真。所以 $\big(\exists x \in U\big)\neg P(x)$ 为真。
2. **方向 $\Leftarrow$**：假设 $\big(\exists x \in U\big)\neg P(x)$ 为真，取定这样一个 x_0，则 $P(x_0)$ 为假。（依据：全称量词的定义）若 $(\forall x)P(x)$ 为真，则特别地 $P(x_0)$ 应为真，与上一步矛盾。故 $\neg(\forall x)P(x)$ 为真。
3. 两个方向都成立，故二者逻辑等价。第二式同法（对偶地交换 $\forall/\exists$ 与"真/假"的角色）。$\blacksquare$

有限论域上的穷举验证（把 $U=\{1,2,3,4\}$、$P(x):=$"$x^2>10$" 代入）：

命题	计算过程	真值
$\exists x\,P(x)$	$P(1)\vee P(2)\vee P(3)\vee P(4) = \mathrm{F}\vee\mathrm{F}\vee\mathrm{F}\vee\mathrm{T}$	T
$\forall x\,P(x)$	$P(1)\wedge P(2)\wedge P(3)\wedge P(4) = \mathrm{F}\wedge\cdots$	F
$\neg(\forall x\,P(x))$	$\neg\mathrm{F}$	T
$\exists x\,\neg P(x)$	$\neg P(1)\vee\cdots = \mathrm{T}\vee\mathrm{T}\vee\mathrm{T}\vee\mathrm{F}$	T
$\forall x\,\neg P(x)$	$\neg P(1)\wedge\cdots = \mathrm{T}\wedge\mathrm{T}\wedge\mathrm{T}\wedge\mathrm{F}$	F
$\neg(\exists x\,P(x))$	$\neg\mathrm{T}$	F

第四行与第三行相同、第六行与第五行相同 —— 定律在具体例子上完全对上 ✓。

逐步推导（"¬ 往内推"的机械过程，多重量词）：设 $P(x,y)$ 是二元谓词，要把 $\neg(\forall x)(\exists y)P(x,y)$ 的否定推到底：

$$\neg(\forall x)(\exists y)P(x,y) \;\equiv\; (\exists x)\,\neg\big((\exists y)P(x,y)\big) \;\equiv\; (\exists x)(\forall y)\,\neg P(x,y).$$

注意量词在每一步都"翻转"：$\forall \to \exists$、$\exists \to \forall$。这个"逐个吃进去"的策略把复杂否定拆成小步 —— 每次只处理最外层的一个量词。

具体示例（"所有质数都是奇数"的否定，本讲必考类型）：

- **原命题**：$(\forall p \in \mathbf{Primes})(p$ 是奇数$)$。形式化：$(\forall p)\big(\mathbf{Prime}(p) \Rightarrow \mathbf{Odd}(p)\big)$。
- **否定（机械推）**：

$$\neg(\forall p)\big(\mathbf{Prime}(p) \Rightarrow \mathbf{Odd}(p)\big) \equiv (\exists p)\,\neg\big(\mathbf{Prime}(p) \Rightarrow \mathbf{Odd}(p)\big) \equiv (\exists p)\big(\mathbf{Prime}(p) \wedge \neg\,\mathbf{Odd}(p)\big).$$

关键一步用的是定理 1.1 附近的改写 $\neg(P \Rightarrow Q) \equiv P \wedge \neg Q$ —— 否定穿过蕴涵**不会**留下蕴涵。 – **自然语言读法**："存在一个质数，它不是奇数"（即"存在偶质数"）。 – **真值**：由于 $p=2$ 是质数且为偶数，这个否定命题是**真**的，所以**原命题"所有质数都是奇数"是假**的。反例只有 2 一个（2 是唯一的偶质数）。 – **对照最常见的错误写法**：$(\forall p)(\mathbf{Prime}(p) \Rightarrow \neg\,\mathbf{Odd}(p))$，读作"所有质数都是偶数"—— 这**不是**原命题的否定（原命题假而它也是假，二者不对立）。**错误根源：忘记"否定蕴涵得到合取"**。

另一个例子（"每个偶数 n 都使 n^2+n+41 为质数"的否定）：

- 原命题：$(\forall n \in \mathbb{Z})\big(\mathbf{Even}(n) \Rightarrow \mathbf{Prime}(n^2+n+41)\big)$。
- 否定：$(\exists n \in \mathbb{Z})\big(\mathbf{Even}(n) \wedge \neg\,\mathbf{Prime}(n^2+n+41)\big)$，即"存在一个偶数 n 使 n^2+n+41 是合数"。
- **真值**：**真**，取 $n=40$（偶数）：$40^2+40+41 = 1681 = 41^2$ 是合数。故原命题为**假**。这正是 L00 那个"证据陷阱"的正式化写法 —— 它的否定就是"存在反例"。

定理 1.3（逆否律 / Contrapositive）：对任意命题 P, Q，$(P \Rightarrow Q) \equiv (\neg Q \Rightarrow \neg P)$。

证明策略：**真值表证明**（也可用逻辑等价链）。这里两种都展示，因为真值表给出"确信"，等价链给出"为什么"。

逐步推导（真值表）：

```
定理（逆否律）（P ⇒ Q）≡（¬Q ⇒ ¬P）   附：顺带看逆命题/否命题为何不等价
================================================================================
 行 |  P  |  Q  | P⇒Q | Q⇒P | ¬P⇒¬Q | ¬Q⇒¬P || P⇐⇒Q | 备注
====+=====+=====+=====+=====+=======+=======++======+============================
  1 |  T  |  T  |  T  |  T  |   T   |   T   ||   T  | 都真
  2 |  T  |  F  |  F  |  T  |   T   |   F   ||   F  | 唯一"原命题为假"的行
  3 |  F  |  T  |  T  |  F  |   F   |   T   ||   F  | 原命题空洞真；逆命题假
  4 |  F  |  F  |  T  |  T  |   T   |   T   ||   T  | 都空洞真
================================================================================
 第 4 列（P⇒Q）  与第 7 列（¬Q⇒¬P）逐行相同      ==> 逻辑等价 ✓
 第 4 列（P⇒Q）  与第 5 列（Q⇒P）   第2,3行不同  ==> 不等价 ✗
 第 4 列（P⇒Q）  与第 6 列（¬P⇒¬Q）第2,3行不同  ==> 不等价 ✗
================================================================================
 记忆：逆否 = "掉头 + 双否定"，两个动作相互抵消 ==> 等价
       逆   = "只掉头"                          ==> 换了个命题
       否   = "只否定"                          ==> 也换了个命题
================================================================================
```

逐步推导（逻辑等价链，只用已证定律）：

$$(P \Rightarrow Q) \;\equiv\; (\neg P \vee Q) \;\equiv\; (Q \vee \neg P) \;\equiv\; (\neg(\neg Q) \vee \neg P) \;\equiv\; (\neg Q \Rightarrow \neg P).$$

四步的依据依次是：蕴涵转或；∨ 交换律；双重否定 $\neg(\neg Q) \equiv Q$；蕴涵转或（反向读）。**整条链条每一步都是等价，所以可以正向、反向随便读** —— 这就是"逆否证明合法"的严格理由。

【证明机制解说】：逆否律的深层含义是：**$P \Rightarrow Q$ 其实是一个关于"禁止某个组合"的声明**：它禁止"P 真 Q 假"。$\neg Q \Rightarrow \neg P$ 禁止的组合是"$\neg Q$ 真 $\neg P$ 假"，即"Q 假 P 真" —— **同一条禁令的两种说法**。所以二者当然等价。反观逆命题 $Q \Rightarrow P$，它禁止的是"Q 真 P 假"，这是**另一条**禁令；否命题 $\neg P \Rightarrow \neg Q$ 禁止"P 假 Q 真"，这又是**第三条**。一个蕴涵只对应一条禁令，逆否是它的同义改写，而逆/否是别的禁令，因此可能一真一假。真值表第 2、3 行就是这两种情况的"活标本"：第 2 行 P 真 Q 假使原命题假而逆命题真；第 3 行 P 假 Q 真使原命题真而逆命题假。

反例（条件不可省：把"逆否等价"误用成"逆等价"）：设 $P(n)$ = "$4 \mid n$"，$Q(n)$ = "$2 \mid n$"。

- **原命题** $(\forall n \in \mathbb{Z}^+)(P(n) \Rightarrow Q(n))$：若 $4 \mid n$ 则 $2 \mid n$ —— **真**（$n = 4k = 2(2k)$，而 $2k \in \mathbb{Z}$；这就是 L00 定理 0.1 的推论 0.2）。
- **逆否命题** $(\forall n)(\neg Q(n) \Rightarrow \neg P(n))$：若 n 是奇数则 $4 \nmid n$ —— **真**（奇数不可能被 4 整除），与原命题等价 ✓。
- **逆命题** $(\forall n)(Q(n) \Rightarrow P(n))$：若 n 是偶数则 $4 \mid n$ —— **假**，反例 $n = 2$（2 是偶数，$4 \nmid 2$）。$n = 6, 10$ 同样是反例。
- **否命题** $(\forall n)(\neg P(n) \Rightarrow \neg Q(n))$：若 $4 \nmid n$ 则 n 是奇数 —— **假**，同一批反例 $n = 2, 6, 10$。

为什么这个反例值得记住：它证明"$P \Rightarrow Q$ 为真"**完全不蕴含** "$Q \Rightarrow P$ 为真"。所以当你证完一个定理，**你不能顺手把结论当条件用**。反过来，只有当你打算用**逆否证明**时，你才有资格把 $P \Rightarrow Q$ 替换成 $\neg Q \Rightarrow \neg P$ —— 因为那是被真值表逐行验证过的等价，而不是"想当然掉头"。

与经典问题的联系

（1）逻辑等价改写的工业价值：形式验证与 SAT 求解器

定理 1.1 的德摩根定律、$\neg(P \Rightarrow Q) \equiv P \wedge \neg Q$、量词否定律，是**自动定理证明**与 **SAT/SMT 求解器**的"编译规则"。任何硬件电路规范都要先被翻译成布尔公式，再用**否定范式 (NNF, negation normal form)** 或 **合取范式 (CNF)** 化简；把 ¬ 推到原子命题上的过程，用的就是本讲的改写规则（沿途把 ∧/∨ 互换、把 ∀/∃ 翻转）。工业界验证 CPU 流水线、缓存一致性协议、甚至密码协议实现时，前端做的第一件事就是把规范否定掉，然后交给 SAT 求解器搜索一个满足赋值的"反例"（counterexample）—— 这正好就是本讲"否定一个全称命题 = 断言存在反例"的机械化版本。本讲和 L00 强调的"一个反例推翻全称命题"在这里变成了一个可执行的算法。

（2）$P \Rightarrow Q \equiv \neg P \vee Q$：把蕴涵变成算术

取 $\mathbf{T} = 1, \mathbf{F} = 0$，则 ∧ 变成乘法、$\neg P$ 变成 $1 - P$，于是

$$P \Rightarrow Q \;\equiv\; \neg P \vee Q \;\longleftrightarrow\; (1 - P) + Q - (1 - P)Q \;=\; 1 - P + PQ.$$

这个从布尔到整数的翻译（把"与"当乘法、"非"当 $1 - x$）是 **代数正规形 (ANF, algebraic normal form)** 与 **布尔多项式** 的起点。密码学里把 S 盒（S-box）表示成 $\mathbb{F}_2$ 上的多项式，靠的就是这个"布尔 = 模 2 算术"的视角。而一旦进入模 2 的世界，你就已经站在 L04 模运算的门口了：$P \vee Q$ 在 $\mathbb{F}_2$ 上写成 $P + Q + PQ$，$P \oplus Q$（异或）写成 $P + Q$。

（3）真值表 + 穷举：所有"穷举验证"的原型

定理 1.1 的证明方式是"$2^2 = 4$ 行全部检查"。这个思路的规模化就是**模型检验 (model checking)**：状态空间有限时（例如一个 32 位寄存器的取值空间虽大但有限），系统地枚举所有状态以验证性质。L14 的计数工具正是用来**估计状态空间大小**的 —— 若变量个数是 n，真值表有 2^n 行；这解释了为什么"暴力穷举逻辑"在 n 大时会爆炸（组合爆炸），也解释了为什么我们需要更聪明的证明技巧（L02 的逆否、反证，L03 的归纳，L04 以后的数论结构）。**"有限可以穷举、无限必须推理"是本讲与 L00 共享的主旋律。**

（4）量词与数据库/程序规范

程序的后置条件通常是量词命题，例如"对每一个输入 x，输出 y 都满足 $y^2 \le x < (y+1)^2$"。当测试发现"程序不满足规范"时，**规范的否定**给出了失败的形状：$(\exists x)\,\neg(\cdots)$，即"存在某个输入使输出不满足条件" —— 这个 x 就是调试时你要找的**最小反例 (minimal counterexample)**。把"测试失败"翻译成规范的否定式，是写正确测试用例的第一步。同时注意：**量词顺序在规范里是承重的**。"对每个请求，存在一个服务器处理它"（$O(1)$ 负载均衡的目标形态）与"存在一个服务器处理所有请求"是完全不同的保证 —— 后者是灾难，前者是正常。这个区分在 L20 讲哈希与负载均衡（balls-in-bins）时会被反复使用。

（5）逆否与"证明不存在"

逆否律给了我们一种**把"不存在"命题改写成"存在"命题**的入口（或反过来）。L00 提到证明"某物不存在"很难；L02 会系统利用 $\neg Q \Rightarrow \neg P$ 来绕开这种困难：想证"n 是奇数 $\Rightarrow d$ 是奇数"，改证"d 是偶数 $\Rightarrow n$ 是偶数"，后者是**构造性**的（把倍数显式写出来）。而 L13 的停机问题本质上是在证明"不存在能判定停机的程序"，其反证结构的最后一步就是本讲这个改写：把"对所有程序 P 都有……"的否定翻译成"存在一个程序 P 使……不成立"。

与其他讲次的关联

- **L00（Direct Proofs，直接证明）**：L00 的每一条定理陈述都用到了本讲的蕴涵。L00 反复强调的"原命题与逆命题不等价"在本讲被真值表**逐行坐实**：表中第 2、3 行给出 $P \Rightarrow Q$ 与 $Q \Rightarrow P$ 真值不同的两行。同时 L00 定理 0.4 的集合等式 $A \cup (B \cap C) = (A \cup B) \cap (A \cup C)$ 正是本讲**逻辑分配律** $P \vee (Q \wedge R) \equiv (P \vee Q) \wedge (P \vee R)$ 的集合版本，而集合差恒等式 $A \setminus (B \cup C) = (A \setminus B) \cap (A \setminus C)$ 就是**德摩根第二定律**。
- **L02（Proof Techniques II，逆否 / 反证 / 分情形 / 鸽笼）**：本讲的逆否律是 L02 整个"逆否证明"技巧的许可证。L02 的第一个例子"若 n 是奇数且 $d \mid n$，则 d 是奇数"就是改成逆否"若 d 是偶数则 n 是偶数"来证的。L02 的反证法还要用到本讲的排中律（"若命题不假则必真"）与 $\neg(P \Rightarrow Q) \equiv P \wedge \neg Q$（反证时假设的是"前提成立且结论不成立"）。**没有本讲的改写规则，L02 的全部技巧都无法表述。**
- **L03（Induction，归纳法）**：归纳法的证明模板是 $(\forall n \in \mathbb{N}) P(n)$，其"归纳步骤"本身是一个蕴涵 $P(n) \Rightarrow P(n+1)$。要理解"为什么只需证基础情形与归纳步骤就能覆盖无限多个 n"，必须先接受全称量词与蕴涵的组合语义。此外 L03 的一个常见失分点是"漏掉基础情形"，其逻辑本质就是：只有 $\forall n\,(P(n) \Rightarrow P(n+1))$ 而没有 $P(0)$，整个命题不成立（"$P(0)$ 是链条的第一环"）。
- **L04（Modular Arithmetic，模运算）**：本讲把 $\mathbf{T}/\mathbf{F}$ 映射到 $1/0$，并用 $P \vee Q = P + Q - PQ$ 说明"布尔运算在算术里长什么样"。L04 会把算术限制到模 m 的世界，其中最重要的特例是模 2（$\mathbb{F}_2$）：此时 $P \vee Q \equiv P + Q + PQ$、$P \oplus Q \equiv P + Q \pmod 2$ —— 逻辑与模运算是同一件事的两种语言。L00 中"数字和 $\bmod 9$"的定理也会在此获得统一表述。
- **L05–L06（Euclid/FLT/CRT → RSA）**：RSA 的安全性论述大量依赖量词命题，例如"不存在（除非 $a \equiv 0 \pmod p$）使 $ax \equiv 0 \pmod p$ 的 x"。写这类命题的**否定式**（"假设存在这样的 x，导出矛盾"）就是在用本讲的量词否定律，其技术形态是 L02 的反证法。
- **L13（Computability，可计算性与停机问题）**：停机问题的陈述"$(\forall P, x)$，判定器 H 都输出正确答案"被否定后变成"$(\exists P, x)$ 使 H 给出错误答案"，然后通过对角线构造造出那个反例。这个"否定全称命题 → 寻找反例 → 构造反例"的三步，就是本讲量词否定律的最深刻应用。
- **L20（Expectations & Linearity，期望与线性性）**：L20 中用期望线性性分析 balls-in-bins 负载均衡时，关键论证是"对每个球，都存在很多箱可选"（$\forall$ 球 $\exists$ 空箱）与"存在一个球落在某个箱"的区分 —— 这类规范的正确表述完全依赖本讲对量词顺序的敏感度训练。

关键要点

1. **命题五联表必须默写**：$\wedge$ 全真才真、$\vee$ 有真就真、$\neg$ 取反、$\Rightarrow$ **只在 T→F 时为假**、$\iff$ 同值才真。记住：$\Rightarrow$ 的四行中有**三行是真的**，"假"只留给"前件真后件假"这一种情形。前件为假时整个蕴涵**空洞真 (vacuously true)** —— 这不是数学家的怪癖，而是"承诺未被触发即未违约"的语义必然。
2. **两个"翻译键"必须刻进肌肉记忆**：$P \Rightarrow Q \equiv \neg P \vee Q$（把蕴涵变成或），$\neg(P \Rightarrow Q) \equiv P \wedge \neg Q$（否定蕴涵得到**合取**，即"存在反例"）。前者用于化简，后者用于反证与量词否定。**绝不**把 $\neg(P \Rightarrow Q)$ 写成 $P \Rightarrow \neg Q$。
3. **三种变体的地位完全不同：逆否 $\neg Q \Rightarrow \neg P$ 与原命题等价**（放心把证明改成逆否来写）；**逆 $Q \Rightarrow P$ 与否 $\neg P \Rightarrow \neg Q$ 与原命题不等价**（各自是另一个命题，可能一真一假）。数值记忆：原命题"$4 \mid n \Rightarrow 2 \mid n$"真，而逆命题"$2 \mid n \Rightarrow 4 \mid n$"假（$n = 2$）。
4. **德摩根口诀：否定进门，与或换位，逐个加非。** $\neg(P \wedge Q) \equiv \neg P \vee \neg Q$，$\neg(P \vee Q) \equiv \neg P \wedge \neg Q$。同一口诀的**量词版**：$\neg\forall x\, P(x) \equiv \exists x\, \neg P(x)$、$\neg\exists x\, P(x) \equiv \forall x\, \neg P(x)$ —— **量词必须翻转**，而"$\neg(\forall x)(P(x) \Rightarrow Q(x))$"的正确否定是"$(\exists x)(P(x) \wedge \neg Q(x))$"（一个反例：前提真、结论假）。
5. **量词顺序是承重的**：$(\forall x)(\exists y)$ 一般**不**能换成 $(\exists y)(\forall x)$。前者允许"见证 y 依赖 x"（每个人各自有母亲 —— 真），后者要求"一个 y 通吃所有 x"（一个人是所有人的母亲 —— 假）。反向的单向箭头 $(\exists y)(\forall x) \Rightarrow (\forall x)(\exists y)$ 恒成立。

常见误区与注意事项

1. **把"或"当排他式。** 数学与编程里的 $\vee$ 是**包含式**：P 和 Q 都真时 $P \vee Q$ 仍为真。若真要表达"二者恰有其一"，必须写 $(P \vee Q) \wedge \neg(P \wedge Q)$（即异或 $P \oplus Q$）。
2. **把"P only if Q"读成 $Q \Rightarrow P$。** 正确翻译是 $P \Rightarrow Q$。同理"P 是 Q 的充分条件"与"Q 是 P 的必要条件"都是 $P \Rightarrow Q$；只有"P 是 Q 的必要条件"才是 $Q \Rightarrow P$。
3. **否定蕴涵时留下蕴涵。** 把"所有质数都是奇数"的否定写成"所有质数都是偶数"（即 $(\forall p)(\mathrm{Prime}(p) \Rightarrow \neg\mathrm{Odd}(p))$），这是**错的**；正确否定是 $(\exists p)(\mathrm{Prime}(p) \wedge \neg\mathrm{Odd}(p))$，读作"存在一个非奇数的质数"，由 $p = 2$ 使其为真。
4. **否定量词时不翻转，或只翻一部分。** $\neg(\forall x)(\exists y)P(x,y)$ 的正确形式是 $(\exists x)(\forall y)\neg P(x,y)$ —— **每一个**量词都翻转，且 $\neg$ 推到最内层。只写 $(\exists x)(\exists y)\neg P(x,y)$ 或漏翻内层都是错的。
5. **混淆逆命题与逆否命题。** 这是 CS70 最普遍的失分点。逆否要"掉头 **且** 两端都加否定"，逆命题"只掉头"。真值表上逆否与原命题**逐行相同**、逆命题在第 2、3 行不同 —— 背下这两行的位置比背口诀更可靠。
6. **在无限论域上滥用真值表证明。** "用真值表证明量词否定律"严格来说只对**有限**论域有效（把 $\forall$ 展开成有限个 $\wedge$）。要证一般情形必须给出本讲定理 1.2 那样的语义论证（用排中律与量词定义）。**真值表证明的适用范围是有限变量，不是"任何逻辑命题"**。
7. **忘记论域 (universe) 是量词命题的一部分。** $(\forall x)(x^2 \geq x)$ 在 $\mathbb{Z}$ 上为**真**，但在 $\mathbb{R}$ 上为**假**（取 $x = 0.5$：$0.25 < 0.5$）。论域变了，真值就变了 —— 写命题时论域必须明确（或由上下文无歧义地确定）。

思考题（带答案）

Q1.（计算 / 真值表） 令 P 表示"3 是奇数"（T），Q 表示"4 是奇数"（F），R 表示"$4 + 5 = 49$"（F）。求下列各式的真值，并说明用到的规则：(a) $P \wedge R$；(b) $P \vee R$；(c) $\neg Q$；(d) $Q \Rightarrow P$；(e) $\neg(P \Rightarrow R)$；(f) $(P \vee Q) \wedge \neg(P \wedge Q)$。

▸ **答案**

先列出真值：$P=\mathbf{T}$，$Q=\mathbf{F}$，$R=\mathbf{F}$。

(a) $P\wedge R=\mathbf{T}\wedge\mathbf{F}=\mathbf{F}$（合取：全真才真，$R$ 假故假）。

(b) $P\vee R=\mathbf{T}\vee\mathbf{F}=\mathbf{T}$（析取：有真就真）。

(c) $\neg Q=\neg\mathbf{F}=\mathbf{T}$。

(d) $Q\Rightarrow P=\mathbf{F}\Rightarrow\mathbf{T}=\mathbf{T}$（**空洞真**：前件假，承诺未被触发）。

(e) 用 $\neg(P\Rightarrow R)\equiv P\wedge\neg R$：$P\wedge\neg R=\mathbf{T}\wedge\mathbf{T}=\mathbf{T}$。也可直接算：$P\Rightarrow R=\mathbf{T}\Rightarrow\mathbf{F}=\mathbf{F}$，故其否定为 T ✓。

这里有一个极好的陷阱练习：错误写法 $P\Rightarrow\neg R$ 在本行也给出 $\mathbf{T}\Rightarrow\mathbf{T}=\mathbf{T}$，**碰巧等于正确答案**。所以只看当前赋值无法分辨对错 —— 必须把两种形式放到**全部四行**上比对：

P	R	$\neg(P\Rightarrow R)$（正确）	$P\Rightarrow\neg R$（错误）	一致?
T	T	F	F	✓
T	F	T	T	✓（本题情形）
F	T	F	T	✗
F	F	F	T	✗

有两行不一致，所以 $P\Rightarrow\neg R$ **不是** $\neg(P\Rightarrow R)$ 的等价形式。这提醒："**逻辑等价**"**必须在所有真值指派上验证**，单点验证毫无说服力（这正是 L00"举例不能代替证明"的同一道理）。

(f) $P\vee Q=\mathbf{T}\vee\mathbf{F}=\mathbf{T}$；$P\wedge Q=\mathbf{T}\wedge\mathbf{F}=\mathbf{F}$，故 $\neg(P\wedge Q)=\mathbf{T}$；于是 $(P\vee Q)\wedge\neg(P\wedge Q)=\mathbf{T}\wedge\mathbf{T}=\mathbf{T}$。这就是**异或**：$P$ 与 Q 恰有一个为真时得 T（此处 P 真 Q 假，符合）。

Q2.（量词与否定） (a) 把"存在一个整数 k 既不是偶数也不是奇数"用符号写出，并判断真假（论域 $\mathbb{Z}$）。(b) 写出"所有质数都是奇数"的**否定**，用符号与自然语言两种形式，并给出反例。(c) 判断 $(\forall x\in\mathbb{Z})(\exists y\in\mathbb{Z})(y>x)$ 与 $(\exists y\in\mathbb{Z})(\forall x\in\mathbb{Z})(y>x)$ 的真假，说明二者为何不同。

▸ **答案**

(a) 记 $E(x)$ = "x 是偶数"，$O(x)$ = "x 是奇数"。命题为

$$(\exists k\in\mathbb{Z})\ \big(\neg E(k)\wedge\neg O(k)\big).$$

假。 理由：对任意整数 k，由带余除法 $k=2q$ 或 $k=2q+1$（$q\in\mathbb{Z}$），即 k 非偶即奇。所以 $\neg E(k)\wedge\neg O(k)$ 对任何 k 都不成立，存在命题为假。**注意这里用到了本讲"有限/无限论域"之外的一个关于 $\mathbb{Z}$ 的结构事实**（每个整数模 2 只有两个余数）—— 这正是 L04 模运算的雏形。

(b) 原命题：$(\forall p\in\mathbb{Z})\big(\mathrm{Prime}(p)\Rightarrow\mathrm{Odd}(p)\big)$。

否定（机械推两步）：

$$\neg(\forall p)\big(\mathrm{Prime}(p)\Rightarrow\mathrm{Odd}(p)\big)\equiv(\exists p)\,\neg\big(\mathrm{Prime}(p)\Rightarrow\mathrm{Odd}(p)\big)\equiv(\exists p)\big(\mathrm{Prime}(p)\wedge\neg\,\mathrm{Odd}(p)\big).$$

自然语言："**存在一个质数不是奇数**"（即存在偶质数）。**反例** $p=2$：2 是质数（只能被 1 与 2 整除），而 $2=2\times1$ 是偶数。故原命题**假**，其否定**真**。补充事实：2 是唯一的偶质数（任何更大的偶数 $2m$（$m>1$）都能被 2 整除，故非质数）。

(c) 第一式 $(\forall x)(\exists y)(y>x)$：**真**。对任意整数 x，取 $y=x+1$，则 $y>x$ ✓。（注意这个 y **依赖于** x，这正是 $\exists$ 在内层的特征。）

第二式 $(\exists y)(\forall x)(y>x)$：**假**。它断言存在整数 y 大于**所有**整数，等价于"$\mathbb{Z}$ 有最大元"。若这样的 y 存在，取 $x=y+1$（仍是整数），则 $x>y$，与"y 大于所有 x"矛盾。故不存在这样的 y。

二者不同的根源：内层 $\exists$ 的见证对象可以随外层变量变化（"每人有自己的 y"），而外层 $\exists$ 的见证必须**一次性对所有 x 有效**（"一个 y 服务所有人"，这是强得多的要求）。一般地 $(\exists y)(\forall x)P\Rightarrow(\forall x)(\exists y)P$ 恒真，反之不然 —— 本题正是"反之不然"的实例。

Q3.（证明与反例） (a) 用逻辑等价链证明 $\neg(P\iff Q)\equiv(P\wedge\neg Q)\vee(\neg P\wedge Q)$。(b) 设 $P(n)$ = "$4\mid n$"，$Q(n)$ = "$2\mid n$"，对 $n=2$ 与 $n=4$ 分别列出原命题、逆命题、否命题、逆否命题的真值，并指出哪些与原命题一致（n 为整数）。(c) 为什么"用真值表证明量词否定律"严格来说不够？给出一个论域使该做法失效。

▸ **答案**

(a) 用 $P \iff Q \equiv (P \Rightarrow Q) \wedge (Q \Rightarrow P)$ 逐层化简：

$$\neg(P \iff Q) \equiv \neg\big[(P \Rightarrow Q) \wedge (Q \Rightarrow P)\big] \equiv \neg(P \Rightarrow Q) \vee \neg(Q \Rightarrow P)$$

（依据：**德摩根第一定律**，注意 $\wedge$ 翻成 $\vee$）

$$\equiv (P \wedge \neg Q) \vee (Q \wedge \neg P)$$

（依据：$\neg(P \Rightarrow Q) \equiv P \wedge \neg Q$，用两次）

$$\equiv (P \wedge \neg Q) \vee (\neg P \wedge Q)$$

（依据：$\vee$ 交换律，把后一项的两个合取项换序）。■

验证（用真值表快速核对）：$P \iff Q$ 在 $P = Q$ 时为 T（第 1、4 行），故 $\neg(P \iff Q)$ 只在第 2、3 行为 T。而 $(P \wedge \neg Q) \vee (\neg P \wedge Q)$：第 2 行 P 真 Q 假给出 T；第 3 行 P 假 Q 真给出 T；第 1、4 行为 F。**逐行一致 ✓**。（这正是"异或"的另一个写法：$P \oplus Q$。）

(b) 四条命题在每个 n 上的真值（已验算）：

n	P: $4 \mid n$	Q: $2 \mid n$	原 $P \Rightarrow Q$	逆 $Q \Rightarrow P$	否 $\neg P \Rightarrow \neg Q$	逆否 $\neg Q \Rightarrow \neg P$
2	F	T	T（空洞真）	F	F	T
4	T	T	T	T	T	T
6	F	T	T（空洞真）	F	F	T
10	F	T	T（空洞真）	F	F	T

与原命题一致的只有逆否命题（$2, 4, 6, 10$ 上全都一致）。逆命题与否命题在 $n = 2, 6, 10$ 上与原命题相反 —— 它们**不等价**。

结论：全体正整数上，原命题"$(\forall n)(4 \mid n \Rightarrow 2 \mid n)$"真，其逆否也真，但逆命题"$(\forall n)(2 \mid n \Rightarrow 4 \mid n)$"假（反例 $n = 2$）、否命题"$(\forall n)(4 \nmid n \Rightarrow 2 \nmid n)$"也假（同样 $n = 2$）。**这就是"逆否放假、逆否可换、逆/否不可换"的可核对证据。**

(c) 真值表证明的合法性来自"逻辑等价 = 对所有真值指派取值相同"，而当命题含**量词**时，"所有真值指派"是对**论域中的每个元素**展开的。若论域是**无限**的，就没有有限的真值表可写 —— 你会得到无穷多行。更重要的是，同一份"表"也不能覆盖**所有可能的论域**。

例如：$P(x)$ = "$x^2 > 10$"，取论域 $U = \{1, 2, 3, 4\}$ 时，4 行的表就能验证 $\neg(\forall x P(x)) \equiv \exists x \neg P(x)$（本讲正文已做）。但取 $U = \mathbb{N}$（无限）时，$\neg(\forall n\, P(n))$ 与 $\exists n \neg P(n)$ 都涉及无穷多实例，**没有任何有限表格能穷举**。所以定律的一般证明必须走定理 1.2 的语义论证（用排中律 + 量词定义）；真值表只能作为**有限情形的验证与直觉来源**。

具体的论域反例（说明"有限验证"会误导）：若有人在 $U = \{1, 2, 3, 4\}$ 上验证了某个量词等式就宣布它普遍成立，那么换成 $U = \{4\}$ 时，$\forall x P(x)$ 为 T，而 $\neg(\forall x \neg P(x))$ 也可能是 T —— 各种"边界形状"会变（空论域、单元素论域、无限论域）。**在无限论域上，唯一可靠的办法是回到定义做逻辑推理。**

Lecture 2: Proof Techniques II（证明技巧进阶）

概述

上一讲（L01）我们把命题逻辑的真值表语言建立起来，并学会了最基础的**直接证明 (Direct Proof)**：要证 $P \Rightarrow Q$，就假设 P 成立，一路推导出 Q。但很多命题用直接证明几乎无从下手——比如"若 n 是奇数，则 n 的每个因子都是奇数"，假设了"n 是奇数"之后我们手上其实什么结构都没有，无法往下走。

本讲补齐证明工具箱的第二层：**逆否证明 (Proof by Contraposition)**、**反证法 (Proof by Contradiction)**、**分情形证明 (Proof by Cases)**，并顺带引入本课程最常用的计数工具之一 **鸽笼原理 (Pigeonhole Principle)**。最后官方 Note 3 用一整节讨论**写证明时的常见错误**（Common Errors），这批"错误证明"是本讲最有价值的部分：它们示范的不是怎么证对，而是**怎么一眼看穿哪里证错了**。

至此，L00–L03 四讲构成完整的"证明工具箱"：直接证明 → 命题逻辑 → 逆否/反证/分情形 → 归纳法。后续 L04 起的数论、L09 起的图论、L12 的可数性、L13 的停机问题，全部依赖这一讲的技巧。

核心概念的直观解释

概念一：逆否证明 (Proof by Contraposition)

- **定义**：设待证命题为 $P \Rightarrow Q$。**逆否命题 (contrapositive)** 是 $\neg Q \Rightarrow \neg P$。逆否证明的做法就是：假设 $\neg Q$ 成立，推导出 $\neg P$ 成立，从而完成对 $P \Rightarrow Q$ 的证明。
- **直观解释（"它是什么意思？"）**：把蕴含 $P \Rightarrow Q$ 想象成一条单行道——"凡是走 P 这条路的人都必然到 Q"。逆否说的是"凡是没到 Q 的人，一定没走 P"，这显然是同一件事的换一种说法。它**不是**在说"没走 P 的人一定没到 Q"（那是**否命题 (inverse)** $\neg P \Rightarrow \neg Q$，与原命题不等价）。
- **为什么合法**：因为 $P \Rightarrow Q$ 与 $\neg Q \Rightarrow \neg P$ 是**逻辑等价**的（真值表完全相同），所以证明了后者就等于证明了前者。这里**完全没有用到矛盾**，只是在陈述一件等价的事实——这一点是本讲最容易被混淆的地方，后面会专门展开。
- **具体示例**：命题"若 n 是奇数，则 $n+1$ 是偶数"。直接证：设 $n = 2m+1$，则 $n+1 = 2m+2 = 2(m+1)$，偶数 ✓。逆否证：设 $n+1$ 不是偶数（即 $n+1$ 是奇数，$n+1 = 2t+1$），则 $n = 2t$，是偶数，即 n 不是奇数 ✓。两条路都通，但第二条路只用了"奇偶的定义"，不需要对 n 做任何化简。

概念二：鸽笼原理 (Pigeonhole Principle)

- **定义**：设 n, k 为正整数。把 n 个物体放进 k 个盒子。若 $n > k$，则至少有一个盒子里装了多于一个物体。
- **直观解释**：n 只鸽子要住进 k 个鸽笼，笼子比鸽子少，必然有两只鸽子被迫挤在同一个笼子里。名字就来自这个画面（"pigeon" + "hole"）。
- **关键性质（务必记住）**：这条定理的结论**与物体怎么摆放完全无关**（regardless of the configuration）。无论摆放方案多么刁钻、多么"刻意避开重复"，只要 $n > k$，重复就必然存在。正是这一点让它能给出反直觉的结论：我们不需要知道任何一只鸽子的具体位置，就能断言重复存在。
- **具体示例**：13 个人分配到 12 个月份（把"人"当鸽子、"出生月份"当盒子）。$13 > 12$，所以至少有两个人同月出生。我们完全不知道是哪两个人、是哪个月，但存在性是确定的。
- **加强形式（实用版）**：把 n 个物体放进 k 个盒子，则至少有一个盒子装有 $\lceil n/k \rceil$ 个或更多物体。例如 $n = 13, k = 12$ 给出 $\lceil 13/12 \rceil = 2$；$n = 10, k = 3$ 给出 $\lceil 10/3 \rceil = 4$（3 个盒子装 10 个东西，必有一个装 ≥ 4 个）。这个形式在很多题目里比原始版本好用得多。

概念三：反证法 (Proof by Contradiction / reductio ad absurdum)

- **定义**：要证命题 P。做法是假设 $\neg P$，从 $\neg P$ 出发经过合法推导得到某个 R 又得到 $\neg R$，即推出矛盾 $R \wedge \neg R$，从而断定 P 必为真。
- **直观解释**：反证法是"把命题暂时当成假的，看看世界会烂成什么样"。如果假设它为假会让整个逻辑体系崩溃（同时推出 R 和 $\neg R$），那只能是假设错了，命题为真。拉丁语 *reductio ad absurdum* 直译是"归约到荒谬"。
- **形式化依据**：反证法证明的是 $\neg P \Rightarrow (\neg R \wedge R)$。而 $\neg R \wedge R \equiv \mathbf{False}$，所以 $\neg P \Rightarrow \mathbf{False}$。这个蕴含式的逆否命题是 $\mathbf{True} \Rightarrow P$，即 P 为真。**注意这里用到了一条在 L01 学过的逻辑定律：命题非真即假，不存在第三种可能（排中律 / law of excluded middle）**。这正是反证法"黑白分明"世界观的来源。
- **具体示例**：用反证法证明"$\sqrt{2}$ 不是有理数"（见后文完整证明）。假设它是有理数，写成分式 $\sqrt{2} = a/b$（最简），能推出 a, b 都为偶数，与"最简"直接打架。

概念四：引理 (Lemma)

- **定义**：在一项较大证明中充当辅助工具的、独立的子命题，称为引理。引理本身也需要证明。
- **直观解释**：引理之于定理，就像**子程序 (subroutine) 之于主程序**。一个长证明如果一次写完，读者读到最后已经忘了前面假设了什么；拆成若干命名清晰的引理，每块都能单独检查、单独复用。
- **具体示例**："若 a^2 是偶数，则 a 是偶数"就是这样一个引理——它在"$\sqrt{2}$ 是无理数"的证明里被**用了两次**，本身也值得单独记住。设计引理时应当尽量做得**通用**（general），这样才可能被其他证明重复使用。
- **定理与引理的分界**：并不清晰。通常一条命题是"定理"还是"引理"，取决于作者想让外界"导出"哪一条——定理是面向外部世界的成果，引理是局部使用的工具。但也有引理比它服务的定理更出名（例如可计算性理论里的 Pumping Lemma）。

概念五：分情形证明 (Proof by Cases / Case Analysis)

- **定义**：当无法直接判断几种可能情形中哪一种成立、但确知**至少有一种成立**时，可以分别对每一种情形证明同一个结论；所有情形都证完，总体结论即成立。
- **直观解释**：就像"不知道今天是不是周末，那就分'是工作日'和'是休息日'两种情形各写一份计划"——只要两种情形的计划都可行，无论今天实际是哪天，计划都能用。
- **两个必要条件（极易出错）**：
- **穷尽 (exhaustive)**：所有情形合起来必须覆盖全部可能。遗漏一种情形，证明就漏了一个洞。
- **互斥 (mutually exclusive)**：通常要求情形之间不重叠，否则同一个对象被证两遍——这不算错，只是啰嗦；但若重叠部分用了互相矛盾的假设，就会出问题。最干净的做法是让情形构成一个**划分 (partition)**。
- **具体示例**：证明"对任意整数 m，$m(m+1)$ 是偶数"。分两种情形：m 是偶数 → $m(m+1)$ 含因子 m，偶；m 是奇数 → 则 $m+1$ 是偶数，$m(m+1)$ 含因子 $m+1$，偶。两种情形穷尽且互斥（按奇偶二分），结论成立。

概念六：非构造性证明 (Non-constructive Proof)

- **定义**：证明了"某个对象 X 存在"，但没有（也无法）明确指出 X 究竟是哪一个的证明。
- **直观解释**：这听起来像作弊——"我知道那里有一个东西，但我不告诉你是啥"。但在数学上它完全合法：存在量词 $\exists$ 只要求"至少有一个"，并不要求证据被显式给出。本讲的分情形证明就会产出一个著名的非构造性存在性证明。
- **具体示例**：定理"存在无理数 x, y 使得 x^y 是有理数"。证明把所有可能情形都覆盖了，但读者走到最后仍不知道 x, y 到底是 $\sqrt{2}, \sqrt{2}$ 还是 $\sqrt{2}^{\sqrt{2}}, \sqrt{2}$。有趣的是，事后我们知道 $\sqrt{2}^{\sqrt{2}} \approx 1.6325$ 确实是无理数（Gelfond–Schneider 定理，远超本课程范围），所以真正成立的是情形 (b)；但**证明本身并不需要知道这一点**。

完整证明与推导（核心）

一、逆否证明为什么合法（逻辑地基）

定理 2.1（逆否等价）：对任意命题 P, Q，有 $P \Rightarrow Q \;\equiv\; \neg Q \Rightarrow \neg P$。

证明策略：用真值表直接枚举。这是"元层面"的陈述，其证明只能是穷举所有取值组合。

逐步推导：把 P, Q 的所有真假组合列出，分别计算 $P \Rightarrow Q$ 与 $\neg Q \Rightarrow \neg P$ 的真值。

```
 P     Q    |  P=>Q  |  ~Q  |  ~P  |  ~Q=>~P  |  两列是否相同
------------+--------+------+------+----------+----------------
 T     T    |   T    |   F  |   F  |    T     |      同
 T     F    |   F    |   T  |   F  |    F     |      同
 F     T    |   T    |   F  |   T  |    T     |      同
 F     F    |   T    |   T  |   T  |    T     |      同
```

第 2 列与第 6 列逐行相同，故两个命题逻辑等价。■

【证明机制解说】：注意第 1、2 行——P 为真时，$P \Rightarrow Q$ 的真假完全由 Q 决定；而逆否命题在 $\neg Q$ 为真（即第 2 行）时正确地把 P 判为假。换句话说，逆否命题把"P 真 Q 假"这个唯一的反例场景，翻译成了"$\neg Q$ 真 $\neg P$ 假"这同一个场景。两个命题共享同一个反例集合，因此同真同假。

必须区分：逆否命题 vs. 逆命题 vs. 否命题

名称	形式	与原命题 $P \Rightarrow Q$ 是否等价
原命题 (original)	$P \Rightarrow Q$	——
逆否命题 (contrapositive)	$\neg Q \Rightarrow \neg P$	**等价 ✓**
逆命题 (converse)	$Q \Rightarrow P$	不等价 ✗
否命题 (inverse)	$\neg P \Rightarrow \neg Q$	不等价 ✗

一个具体例子说明逆命题为什么不等价：设 P 是"n 能被 4 整除"，Q 是"n 能被 2 整除"。原命题成立；逆命题"n 能被 2 整除则 n 能被 4 整除"在 $n = 6$ 处失败。

逆否证明与反证法的严格区别（本讲最重要的一条）

这是一个高频混淆点，必须讲透。

维度	逆否证明	反证法
待证目标	$P \Rightarrow Q$（蕴含式）	任意命题 P
假设什么	只假设 $\neg Q$	假设 $\neg P$（若 P 是蕴含式 $P_0 \Rightarrow Q_0$，则假设 $P_0 \wedge \neg Q_0$）
推出什么	直接推出 $\neg P$	推出某个 R 以及 $\neg R$，形成矛盾
依赖哪条逻辑	只需逆否等价（真值表可验）	必须依赖排中律（非真即假）
是否出现"荒谬"	**不出现**——全程都是正常的正向推导	必然出现——最后一步是 $R \wedge \neg R$

所以：**逆否证明不是反证法的一个特例，它是"换一条等价的路走"，而反证法是"把假设推向自我毁灭"。** 判断标准很简单：如果你的证明最后写下的是"这与 $\neg Q$ 的假设矛盾"或"这证明了 $\neg P$"，那是逆否证明；如果你最后写下的是"R 且 $\neg R$，矛盾"，那才是反证法。

二、逆否证明实战：奇数与因子

定理 2.2（官方 Note 3 的 Theorem 3.1）：设 n 为正整数，$d \mid n$。若 n 为奇数，则 d 为奇数。

证明策略：用**逆否证明**。理由是：直接证明只能假设"n 是奇数"，而 n 是奇数这件事对因子 d 没有任何可操作的代数结构（$n = 2m+1$，$d \mid n$ 只给出 $n = d\ell$，无从下手）。反过来假设"d 是偶数"则立刻得到 $d = 2k$ 这个可以代入的表达式。**当一个命题的否定假设能给出更强的代数结构时，就选逆否。**

逐步推导：

1. 先写出逆否命题：$\neg Q$ 是"d 不是奇数"即"d 是偶数"；$\neg P$ 是"n 不是奇数"即"n 是偶数"。故逆否命题为：**若 d 是偶数，则 n 是偶数**。（这一步必须在证明开头显式做出来，否则读者不知道你在证什么。）
2. 采用逆否证明：假设 d 是偶数。
3. 由"偶数"的定义，存在整数 k 使 $d = 2k$。
4. 由 $d \mid n$ 的定义，存在整数 ℓ 使 $n = d\ell$。
5. 把 (3) 代入 (4)：$n = d\ell = (2k)\ell = 2(k\ell)$。
6. 因整数对乘法封闭，$k\ell \in \mathbb{Z}$，故 $n = 2(k\ell)$ 满足"偶数"的定义，即 n 是偶数。
7. 我们已从 $\neg Q$ 推出 $\neg P$。由逆否等价（定理 2.1），原命题 $P \Rightarrow Q$ 成立。■

【证明机制解说】：整个证明的"灵光一现"在第 3 步——把"d 是偶数"翻译成一个**可以代入的等式 $d = 2k$**。这之后全是代换与封闭性，几乎不需要思考。这也解释了为什么逆否方向更好走：偶数条件天然携带一个因子 2，可以乘进 $d\ell$ 里；而"n 是奇数"携带的是 $n = 2m+1$ 这个加 1 的式子，因子 d 藏在 n 的分解中，加 1 结构对它毫无帮助。

顺带得到的更强结论：把上述论证中"2"换成任意正整数 t，可得到"若 $t \mid n$ 则 $t \mid d$"——这正是"因子传递性"的雏形，在 L04 的模运算里会以"若 $a \equiv b \pmod m$ 且 $d \mid m$ 则 $a \equiv b \pmod d$"的形式再次出现。

三、鸽笼原理及其逆否证明

定理 2.3（鸽笼原理 Pigeonhole Principle，官方 Note 3 的 Theorem 3.2）：设 n, k 为正整数。把 n 个物体放入 k 个盒子。若 $n > k$，则至少有一个盒子含有多个物体。

证明策略：用**逆否证明**。原因是：命题的结论是"至少有一个盒子有 ≥ 2 个物体"，这个存在性断言在直接证明中没有起点（你无法"假设 $n > k$ 然后指向某个盒子"）。而它的否定"**每个**盒子都至多含 1 个物体"是一个全称断言，非常方便利用——直接对物体总数计数即可。

逐步推导：

1. 写出逆否命题。$\neg Q$：没有任何盒子含多个物体，即**每个盒子至多含 1 个物体**。$\neg P$：物体数不多于盒子数，即 $n \leq k$。故逆否命题为："若每个盒子至多含 1 个物体，则 $n \leq k$。"
2. 假设每个盒子至多含 1 个物体。
3. 设有 k 个盒子 $B_1, \ldots, B_k$，记盒子 B_i 中的物体数为 c_i。由假设，$c_i \leq 1$ 对每个 i 成立。
4. 所有物体都在某个盒子里，故 $n = c_1 + c_2 + \cdots + c_k$。
5. 于是 $n = \sum_{i=1}^{k} c_i \leq \sum_{i=1}^{k} 1 = k$，即 $n \leq k$。
6. 由逆否等价，原命题成立：$n > k \Rightarrow$ 至少一个盒子含多个物体。$\blacksquare$

【证明机制解说】：整个证明只用了一步实质运算——第 5 步的求和上界。它的力量来自一个朴素事实：**在"每盒至多 1 个"的约束下，容器能装下的物体总数有一个硬上界 k**。当供给 n 超过容量 k，约束必然被打破。注意这个论证对**配置完全无感**：无论怎么摆，第 3 步的 $c_i \leq 1$ 和第 4 步的求和恒等式都成立。这就是"与配置无关"的技术含义。

应用一（官方例子）：旧金山的头发

- 建模：把旧金山居民看作"鸽子"，把"某人头上的头发根数"看作"盒子编号"。
- 已知数据：一个人头上的头发数平均约 100000，可以合理确定**没有人的头发超过 500000 根**。于是可能的头发数只有 $0, 1, 2, \ldots, 500000$ 共 500001 个取值——这就是盒子数 $k = 500001$。
- 旧金山人口（截至 2024 年）超过 800000——这就是鸽子数 $n = 800000$。
- 因为 $800000 > 500001$，由鸽笼原理：**旧金山至少有两个人的头发根数完全相同**。
- 注意这个论证的"反直觉"之处：它完全没有告诉我们那个数字是多少、那两个人是谁。它只是断言重复必然存在。（脚本验算：$\lceil 800000/500001 \rceil = 2$，确认结论。）

应用二（补充）：13 个人的生日月份

- 建模：13 个人 = 13 只鸽子；12 个月份 = 12 个盒子。
- $13 > 12$，由鸽笼原理：**至少有两个人的出生月份相同**。
- 这不是概率陈述——不是"很可能"，而是**必然**。这是鸽笼原理最容易被误解的地方：它给出的是确定性结论，不需要任何独立性假设。概率方法要到 L14–L15 才登场。
- 加强形式给出更强结论：至少有一个月份含有 $\lceil 13/12 \rceil = 2$ 个人；若问 100 个人分到 9 个"盒子"，则至少有一个盒子含 $\lceil 100/9 \rceil = 12$ 个人。

应用三（补充）：5 个整数中必有两个之差被 4 整除

- 任取 5 个整数 $a_1, \ldots, a_5$。
- "盒子"= 模 4 的余数，只有 4 个盒子：$0, 1, 2, 3$。鸽子 $n = 5 > 4 = k$。
- 于是必有两个整数落在同一个余数盒子里，即 $a_i \equiv a_j \pmod 4$，从而 $4 \mid (a_i - a_j)$。
- 算例验算：取 $\{3, 11, 7, 19, 26\}$，模 4 余数依次为 $3, 3, 3, 3, 2$。前四个都落在盒子 3 中：$3 - 11 = -8$、$3 - 7 = -4$、$3 - 19 = -16$、$11 - 7 = 4$、$11 - 19 = -8$、$7 - 19 = -12$，全部被 4 整除 ✓（脚本已核验）。

注意：鸽笼原理有一个"阈值"性质——$n > k$ 这个条件是**不可省的**。若 $n \leq k$，则完全可以把物体一一分开摆放，使得每个盒子恰好至多 1 个。例如 $n = k = 12$：12 个人可以分别出生在 12 个不同月份，没有重复。这就是"去掉 $n > k$ 条件命题失效"的反例。

四、反证法实战（一）：质数有无穷多个

定理 2.4（Euclid，官方 Note 3 的 Theorem 3.3）：质数有无穷多个。

证明策略：用**反证法**。为什么不用直接证明？因为"无穷多个"是一个**否定性断言**——等价于"不存在最大的质数""不存在一个包含全部质数的有限列表"。要正面构造出无穷多个质数并逐一展示，是做不到的；但假设"只有有限多个"，我们手上就得到了一个**有限的、可枚举的完整列表**，而完整列表可以被"乘积加一"这个操作攻击。**凡是要证明"某物不存在"（不存在最大的质数 / 不存在满足 $\sqrt{2} = a/b$ 的整数 a, b），反证法就是首选。**

先陈述引理（Lemma 3.1）：每个大于 1 的自然数要么是质数，要么有质因子。

（官方把这个引理的证明推后到讲归纳法的 Note 4——事实上 Theorem 4.7"每个 $n > 1$ 可写成质数之积"用强归纳证明后，本引理只是它的直接推论。见 L03 的思考题 Q3。）

逐步推导（主定理）：

1. 反证法：假设定理为假，即质数**只有有限多个**，设有 k 个。
2. 于是可以把它们全部列举出来：$p_1, p_2, \ldots, p_k$。（这一步是反证法的全部收益——"有限"意味着"可以写完"。）
3. **构造** $q := p_1 p_2 \cdots p_k + 1$，即"所有质数之积再加一"。
4. 断言 q **不可能是质数**。理由：$q = p_1 p_2 \cdots p_k + 1 > p_i$ 对每个 $i = 1, \ldots, k$ 都成立（因为乘积 $p_1 \cdots p_k \geq p_i$，加 1 后严格更大；注意 $k \geq 2$、$p_1 = 2$ 时乘积至少为 2）。所以 q 严格大于列表中的每一个质数；而按假设这个列表**已经包含了全部质数**，因此 q 不在其中，q 不是质数。
5. 引用引理：$q > 1$ 且 q 不是质数，故 q 有质因子 p。把它记为断言 R。
6. 因为 $p_1, \ldots, p_k$ 是全部质数，而 p 是质数，所以 p 必等于某个 p_i。
7. 于是 $p \mid p_i$，从而 p 整除 $r := p_1 p_2 \cdots p_k$。

8. 又由第 5 步 $p \mid q$。由整除的线性性（L00 已证：$a \mid b$ 且 $a \mid c \Rightarrow a \mid (b-c)$），得 $p \mid (q-r)$。
9. 但 $q - r = (p_1 p_2 \cdots p_k + 1) - p_1 p_2 \cdots p_k = 1$。故 $p \mid 1$。
10. 一个整除 1 的正整数只能是 1，故 $p = 1$。但 1 不是质数——这与第 5 步"p 是质数"（断言 R）直接冲突。这是 $\neg R$。
11. 于是 $R \wedge \neg R$ 成立，矛盾。故假设为假，质数有无穷多个。■

【证明机制解说】：Euclid 这个证明的精髓在第 3 步的构造 $q = (\text{全部质数之积}) + 1$。**加 1 是全部魔法所在**：它保证 q 除以列表中任何一个质数都余 1，因此 q 的每一个质因子都**不可能**出现在那份"完整"的列表里。于是"完整列表"这个假设自我否定——列表既是完整的，又漏掉了 p。这正是反证法最漂亮的收束方式：**不是我们构造出矛盾，而是被假设出来的对象自己拆掉了自己的地基。**

重要澄清（高频误解）：q 本身**不一定**是质数。脚本验算：

k	质数列表	$q = p_1 \cdots p_k + 1$	q 是否质数	q 的最小质因子
1	2	$2 + 1 = 3$	是	3
2	2,3	$6 + 1 = 7$	是	7
3	2,3,5	$30 + 1 = 31$	是	31
4	2,3,5,7	$210 + 1 = 211$	是	211
5	2,3,5,7,11	$2310 + 1 = 2311$	是	2311
6	2,3,5,7,11,13	$30030 + 1 = 30031$	否	59（$30031 = 59 \times 509$）

$k = 6$ 时 q 是合数，但证明依然完全有效：我们**不需要** q 是质数，只需要它有一个质因子，而 59 确实不在列表 $\{2, 3, 5, 7, 11, 13\}$ 中——矛盾照样成立。把"q 是质数"当成证明的一部分，是学生最常见的错误之一。

五、反证法实战（二）：$\sqrt{2}$ 是无理数（引理嵌套）

定理 2.5（官方 Note 3 的 Theorem 3.4）：$\sqrt{2}$ 是无理数。

证明策略：用**反证法**，并且**嵌套一层引理**。先说第二点：引理 2.6 本身也是一条蕴含式，"若 a^2 偶则 a 偶"。它最自然的证法是**逆否**（假设 a 是奇数，写出 $a = 2t + 1$，则 $a^2 = 4t^2 + 4t + 1$ 是奇数）。所以本定理的完整结构是：**反证法（主）→ 逆否证明（引理）**——两种技巧上下叠放。这种"引理套在定理里、引理自己换一种技巧"的分层结构，是数学写作的标准做法，也是本讲最值得学习的形式。

引理 2.6（Lemma 3.2）：若 a^2 是偶数，则 a 是偶数。

引理 2.6 的逐步推导（逆否证明）：

1. 逆否命题：若 a 不是偶数（即 a 是奇数），则 a^2 不是偶数（即 a^2 是奇数）。
2. 假设 a 是奇数，则由定义存在整数 t 使 $a = 2t + 1$。
3. 两边平方：$a^2 = (2t+1)^2 = 4t^2 + 4t + 1 = 2(2t^2 + 2t) + 1$。
4. 因 $2t^2 + 2t \in \mathbb{Z}$（整数对加法和乘法封闭），上式说明 a^2 形如 $2(\text{整数}) + 1$，即 a^2 是奇数。
5. 由逆否等价，引理成立。■

（脚本验算 $a = 1, 3, 5, 7, 9$：$a^2 = 1, 9, 25, 49, 81$，全部为奇数 ✓。）

定理 2.5 的逐步推导（反证法）：

1. 反证法：假设 $\sqrt{2}$ 是**有理数**。
2. 由有理数的定义，存在整数 a 与 $b \neq 0$ 使 $\sqrt{2} = a/b$，并且我们可以要求这个分式**已经约到最简**（a, b 除 1 外没有公因子）。把这个"互质"事实记为断言 R。
3. 由 $x = y \Rightarrow x^2 = y^2$，得 $2 = a^2/b^2$。
4. 两边乘以 b^2：$a^2 = 2b^2$。
5. 因 b 是整数，b^2 是整数，故 $a^2 = 2b^2$ 是偶数（偶数定义）。
6. 应用引理 2.6：a 是偶数。故存在整数 c 使 $a = 2c$。
7. 代入第 4 步：$2b^2 = a^2 = (2c)^2 = 4c^2$，两边除以 2 得 $b^2 = 2c^2$。
8. 因 c 是整数，c^2 是整数，故 b^2 是偶数。再次应用引理 2.6：b 是偶数。
9. 于是 a 与 b 都是偶数，它们共享公因子 2。这否定了断言 R。记作 $\neg R$。
10. 我们既有 R（第 2 步），又有 $\neg R$（第 9 步），矛盾。故 $\sqrt{2}$ 不是有理数，即 $\sqrt{2}$ 是无理数。■

【证明机制解说】：全部力量集中在第 2 步的"约到最简"。这一步看似只是书写习惯，实际上**是证明的关键杠杆**——它把我们想要的性质（"不存在"）编码成了一个可被攻击的假设 R。之后的推导是双轨同步的：奇偶性从 a^2 传染到 a，又从 b^2 传染到 b，两条轨道在第 9 步汇合，把公因子 2 亮出来。这说明**"最简分式"的约定本身就含有信息**：它不是无成本的规范性要求，而是一条可以被推出的性质所反驳的假设。

反例（说明"最简"条件不可省）：如果去掉"a, b 互质"这个要求，证明立刻失效。例如写 $\sqrt{2} = \frac{2\sqrt{2}}{2}$ 或者用 $a = 2\sqrt{2}$ 这类非整数——但更直接的例证是：$a = 2, b = \sqrt{2}$ 时 $a^2 = 4 = 2b^2$ 成立，a 是偶数，但 b 根本不在整数范围内，"b 是偶数"这个结论无从谈起。**没有"整数 + 互质"这两条约束，"两个都是偶数"就完全推不出来。**

六、分情形证明实战：无理数的无理数次幂可以是有理数

定理 2.7（官方 Note 3 的 Theorem 3.5）：存在无理数 x, y，使得 x^y 是有理数。

证明策略：用**分情形证明**。为什么？因为待证命题带**存在量词** $\exists x \exists y$，只需给出**一对** (x, y) 即可；而自然的第一猜想 $x = y = \sqrt{2}$ 是否奏效，取决于 $\sqrt{2}^{\sqrt{2}}$ 到底是不是有理数——这是一个我们**无法在本课程范围内判定**的问题。分情形证明的精妙之处在于：**我们不必知道答案，只要把两种可能都走一遍，两条路都能通向结论即可。**

逐步推导：

1. 取 $x = \sqrt{2}$，$y = \sqrt{2}$。（两者都是无理数，由定理 2.5。）
2. 对 $\sqrt{2}^{\sqrt{2}}$ 分两种情形。由于"有理"与"非有理"穷尽且互斥，必有一种成立：
3. (a) $\sqrt{2}^{\sqrt{2}}$ 是有理数；
4. (b) $\sqrt{2}^{\sqrt{2}}$ 是无理数。
5. **情形 (a)**：假设 $\sqrt{2}^{\sqrt{2}}$ 是有理数。取 $x = \sqrt{2}$，$y = \sqrt{2}$。此时 x, y 都是无理数，而 $x^y = \sqrt{2}^{\sqrt{2}}$ 按情形假设是有理数。结论成立。✓
6. **情形 (b)**：假设 $\sqrt{2}^{\sqrt{2}}$ 是无理数。原先的猜想的两个数不奏效了，但我们**手上多了一个新的无理数** $\sqrt{2}^{\sqrt{2}}$。于是改取

$$x = \sqrt{2}^{\sqrt{2}}, \qquad y = \sqrt{2}.$$

两者都是无理数（x 由情形假设，y 由定理 2.5）。计算

$$x^y = \left(\sqrt{2}^{\sqrt{2}}\right)^{\sqrt{2}} = \sqrt{2}^{\sqrt{2}\cdot\sqrt{2}} = \sqrt{2}^{\,2} = 2,$$

其中第二个等号用到指数律 $(x^y)^z = x^{yz}$（本课程把它作为公理接受），最后一个等号用 $(\sqrt{2})^2 = 2$。而 $2 = 2/1$ 当然是有理数。结论成立。✓ 5. 因为情形 (a) 与 (b) 必有一种成立，且两种情形下结论都已证明，故定理成立。■

【证明机制解说】：这里有两个层次值得体会。

第一层是**"用假设奖励自己"**。在情形 (b) 中，我们并不知道 $\sqrt{2}^{\sqrt{2}}$ 是否真是无理数；但情形 (b) 的**假设**恰好告诉我们它是。于是我们可以"免费"使用这个新无理数作为底数。这就是分情形证明的典型手法：**假设本身就是资源**。

第二层是**非构造性**。走完整个证明，我们仍然不知道真正的 (x, y) 是哪一对。情形 (a) 说"如果是 $\sqrt{2}, \sqrt{2}$ 就行"，情形 (b) 说"如果不是，那就换 $\sqrt{2}^{\sqrt{2}}, \sqrt{2}$"——证明告诉我们**必然存在一对**，但不指示是哪一对。这在逻辑上完全合法（$\exists$ 只要求存在性），在实践中也是一种重要的思维方式：**可以不构造而先证明存在**。

补充数值事实（脚本验算）：$\sqrt{2}^{\sqrt{2}} \approx 1.632526919$。事实上 Gelfond–Schneider 定理（1934）告诉我们 $\sqrt{2}^{\sqrt{2}}$ **确实是**无理数，所以真正成立的是情形 (b)，答案里的 $(x, y) = (\sqrt{2}^{\sqrt{2}}, \sqrt{2})$。但请注意：**这个"事后真相"不是本证明的一部分**，本证明也不需要它。

七、分情形证明的适用判据小结

什么时候该用分情形？经验判据是：**当你手上的假设信息不足以直接推出结论，而某个"二分（或 k 分）"能把情况拆成若干各自都容易处理的分支时。** 三个正例：

- $m(m+1)$ 是偶数 → 按 m 的奇偶二分（因为奇偶性决定了哪个因子含 2）。
- $\sqrt{2}^{\sqrt{2}}$ 是否有理 → 二分（因为两种情形的假设各自给出不同的可用资源）。
- 两色定理的归纳步骤（见 L03）→ 按"共享边界是不是新增的那条线"二分（因为两条边界的处理依据完全不同：一条靠归纳假设，一条靠构造）。

两条硬性检查（写完分情形证明后必须自问）：

1. 我列的情形**覆盖了所有可能**吗？（穷尽性）
2. 有没有哪个对象同时落在两个情形里、而我在这两个情形中推出了互相冲突的结论？（互斥性——若情形不互斥但结论一致则无害，若冲突则整个证明作废）

与经典问题的联系

本讲的四件工具在后续工程问题里有非常直接的下游用途。

（一）鸽笼原理 → 哈希冲突必然性（承 L20 的哈希与负载均衡）

哈希表把 n 个键映射到 k 个桶。若 $n > k$，鸽笼原理立刻断言：**必然存在两个不同的键映射到同一个桶**。这不是实现缺陷，而是数学必然——任何哈希函数都无法避免。这条结论是 L20 讨论"链地址法 (chaining)""开放寻址""期望链长 $\approx n/k$"的出发点：既然冲突不可消除，工程上就只能转而控制**冲突的分布**（让每个桶的期望负载为 n/k，并用集中不等式 L23 证明真实负载不会偏离期望太多）。请注意这里的分工：本讲的鸽笼原理给的是**确定性**的下界结论，L20 的期望分析给的是**概率性**的分布刻画，两者互补。

（二）反证法 → 不可满足性与不可判定性（预告 L12、L13）

"不存在"型命题是反证法的主场。后续两个最重要的"不存在"定理都靠它：

- **L12 可数性**：证明"实数集不可数"——假设存在一个把 $\mathbb{N}$ 到 $\mathbb{R}$ 的完整列举，用对角线法构造出一个不在列表中的实数，矛盾。（注意与 Euclid 证明的**结构同构**：都是"假设有一个完整列表，然后造出一个逃出列表的对象"。）
- **L13 可计算性**：证明"停机问题不可判定"——假设存在判定程序 H，构造一个在 H 判定为停机时故意不停机的程序，让 H 作用在自己身上，得到矛盾。

（三）逆否证明 → 算法正确性中的"逆否式"推理（贯穿全课程）

很多算法性质的证明都以逆否形式出现。例如 L05 费马小定理的应用中，"若 a 不是 p 的倍数则 $a^{p-1} \equiv 1$"的逆否形式"若 $a^{p-1} \not\equiv 1$ 则 $p \mid a$"，正是 Miller–Rabin 素性测试判定"a 是一个见证 (witness)，p 必为合数"的逻辑依据。RSA（L06）中"若 m 与 N 不互质则解密失败"的逆否"解密始终成功则 m 与 N 互质"也是同一套路。

（四）非构造性证明 → 概率方法（预告 L15、L23）

"证明存在但不必指出是哪一个"这种思维在概率方法中被推到极致：为了证明某个组合对象存在，我们**随机**选一个对象，证明"选到好对象的概率 > 0"。概率大于零 $\Rightarrow$ 好对象存在——这正是一种非构造性的存在性证明。本讲的定理 2.7 是这一整套思想的雏形。

与其他讲次的关联

- **与 L00（直接证明）**：本讲的三种技巧都是直接证明的**变体或补充**。逆否证明在形式上是"对 $\neg Q \Rightarrow \neg P$ 做一次直接证明"；反证法在推出矛盾前的所有步骤都是直接推导；分情形证明则是对每个分支各做一次直接证明。所以 L00 的直接证明功夫是地基，本讲只是教你**如何选入口**。
- **与 L01（命题逻辑）**：本讲的合法性完全依赖 L01 的两条成果——(i) 真值表方法（用于验证 $P \Rightarrow Q \equiv \neg Q \Rightarrow \neg P$）；(ii) 排中律 $P \vee \neg P$（反证法"黑白分明"的依据）。**如果 L01 没学扎实，本讲就变成了背套路。**
- **与 L03（归纳法）**：本讲的两个引理（"每个 $n > 1$ 有质因子"、以及更一般的算术基本定理）在 L03 用**强归纳**正式证明。换句话说，本讲的 Euclid 证明是**借用**了一个尚未证明的引理——这在数学写作中完全合法（可以引用"将在后续证明的结果"），但你自己写证明时要意识到这个依赖方向。同时，L03 的"$\forall n, 3 \mid n^3 - n$"在线性推导上与本讲的 Theorem 2.2 同型。
- **与 L04–L05（模运算、Euclid/FLT/CRT）**：定理 2.2（$t \mid d$ 的传递结构）是 L04 同余语言中"$a \equiv b \pmod m$ 且 $d \mid m \Rightarrow a \equiv b \pmod d$"的整数版本。Euclid 算法（L05）的终止性证明则同时用到"最小性论证"（一种隐式的分情形/反证混合）与不变式。
- **与 L12–L13（可数性、可计算性）**：本讲应用一里"假设完整列表 → 造出逃逸对象 → 矛盾"的模式，将在 L12 的对角线论证与 L13 的停机问题证明中被复用两次，是整门课最重要的证明骨架之一。
- **与 L14–L15（计数、概率公理）**：鸽笼原理是"计数论证给出确定性结论"的最简范例；到了 L15，同样的计数思想会被升级为**等可能样本空间上的概率**。此外，L18（容斥）中的"至少有一个事件发生"的计数，其逻辑起点就是鸽笼式的"反过来数每个盒子至多多少"。

关键要点

1. **一图记住三种技巧的入口选择**：

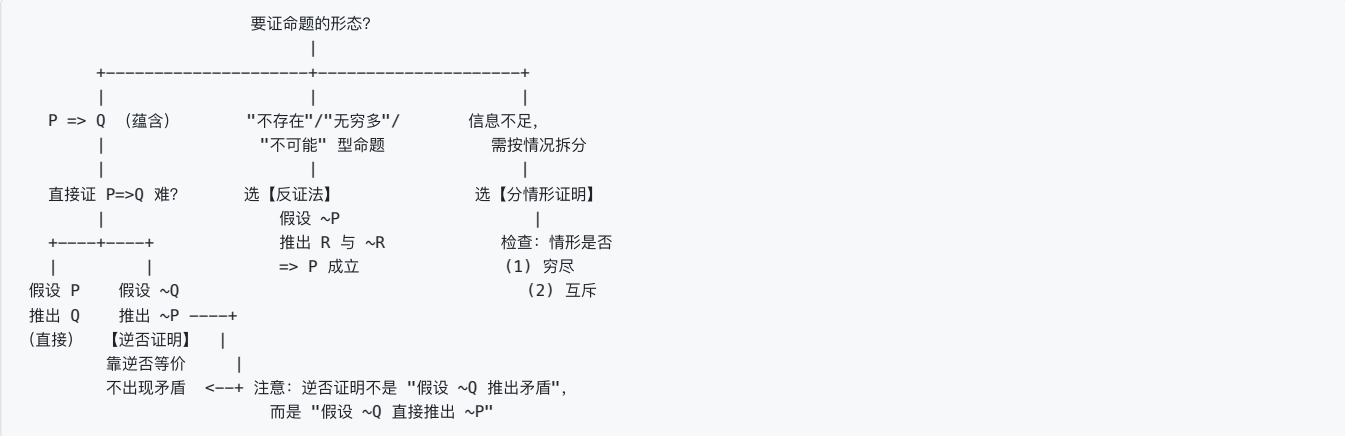

1. **$P \Rightarrow Q$ 的等价物只有逆否 $\neg Q \Rightarrow \neg P$**。逆命题 $Q \Rightarrow P$ 与否命题 $\neg P \Rightarrow \neg Q$ 都**不**等价于原命题。想清楚这一条，反证法与逆否法的区别就自动化开了。
2. **反证法的收尾必须显式写出 $R \wedge \neg R$**。只写"故假设不成立"是不够的——读者需要看到矛盾的两半分别在哪一步出现（在 Euclid 证明里是"p 是质数"与"$p = 1$"；在 $\sqrt{2}$ 证明里是"a, b 互质"与"a, b 都是偶数"）。
3. **鸽笼原理的威力来自"与配置无关"**：$n > k$ 就必然有重复，不需要知道任何摆放细节，也不需要任何概率假设。加强形式 $\lceil n/k \rceil$ 在具体题目中比原版更好用。
4. **分情形证明的两条硬指标：穷尽、互斥**。另外，分情形可以产出**非构造性**结论——证明"存在"却不指明"是哪个"，这在数学上完全合法。
5. **把长证明拆成引理**，就像把长程序拆成子程序。引理要写得尽量**通用**，才可能被重复使用（引理 2.6 在同一证明里被用了两次）。

常见误区与注意事项

误区 1：假设了自己要证的东西（"循环论证"）

官方 Note 3 的第一个错误证明：

> Claim 3.1. $-2 = 2$。 **"证明"**：假设 $-2 = 2$。两边平方得 $(-2)^2 = 2^2$，即 $4 = 4$，这是真的。故 $-2 = 2$。♠

错在哪：第一步就假设了待证结论。设 $P \equiv$ "$-2 = 2$"，这个"证明"实际建立的是 $P \Rightarrow \mathbf{True}$，而 $P \Rightarrow \mathbf{True}$ 是**恒真**的（任何命题都能推出真命题），它跟证明 P 完全是两码事。用 L01 的真值表语言说：$P \Rightarrow \mathbf{True}$ 这一列全是 T，与 P 的真假无关。

附带错误：平方**不是单射**。$x^2 = y^2$ 只能推出 $x = y$ 或 $x = -y$，推不出 $x = y$。这一步"从 $x^2 = y^2$ 推 $x = y$"忽略负号，是同一个错误的另一半。

误区 2：除以零

官方第二个错误证明：

> Claim 3.2. $1 = 2$。 **"证明"**：设整数 x, y 满足 $x = y$。则
>
> $$x^2 - xy = x^2 - y^2 \quad (\text{因 } x = y)$$
> $$x(x - y) = (x + y)(x - y)$$
> $$x = x + y \quad (\text{两边除以 } x - y)$$
> $$x = 2x.$$
>
> 取 $x = y = 1$ 即得 $1 = 2$。♠

错在哪：第三个等式**两边除以了 $x - y$**，而在本题设定下 $x = y$，所以 $x - y = 0$。**除以零不是良定义的运算**（在 L04 的模运算语言里我们会说得更精确：0 在任何模数下都没有乘法逆元，所以"约掉 0"从来没有合法性）。前两个等式其实完全正确，错误精确地发生在第三个等号处。

注：这份"证明"的前两步本身还有个讽刺之处——$x^2 - xy = x^2 - y^2$ 在 $x = y$ 时两边都等于 0，这一步是真的但完全空洞；真正被判死刑的是除法。

误区 3：对负数"开方"或"平方"时忽略符号

官方第三个错误证明：

> Claim 3.3. $4 \le 1$。 **"证明"**：我们知道 $-2 \le 1$。两边平方得 $4 \le 1$。♠

错在哪：平方不保持不等号方向。$a \le b$ 推不出 $a^2 \le b^2$。这里 $-2 \le 1$ 为真，但 $(-2)^2 = 4 > 1 = 1^2$。根本原因是平方函数在 $\mathbb{R}$ 上**不是单调的**：它在 $(-\infty, 0]$ 上递减、在 $[0, \infty)$ 上递增，所以跨过 0 的两个数无法比较平方后的大小。

官方给的检验问题：若 $a \le b$，是否必然有 $|a| \le |b|$？**不是**。反例：$a = -2, b = 1$，此时 $a \le b$ 成立，但 $|a| = 2 > 1 = |b|$（脚本验算确认）。这也正是本讲要求的"去掉某条件命题失效"的具体反例。

相关的第三课：不等式两边乘以负数会翻转方向。例如 $-2 < 5$ 两边乘 -1 得 $2 > -5$（注意方向从 $<$ 变成 $>$）。学生常在心里把它当成"乘 -1 只是变号"，忘了同时翻方向。

误区 4：把逆否证明说成反证法（或反之）

"我们假设 d 是偶数……于是 n 是偶数。矛盾，故原命题成立"——这是错的写法！定理 2.2 的证明里从头到尾**没有出现任何矛盾**：我们只是从 $\neg Q$ 推到了 $\neg P$，然后引用逆否等价就结束了。把这一过程描述成"矛盾"会让读者去找那个根本不存在的 $R \wedge \neg R$。

反过来，把 $\sqrt{2}$ 的证明写成"用逆否证明"也是错的：$\sqrt{2}$ 是无理数**不是一个蕴含式**，它没有"前件"和"后件"，根本谈不上逆否命题。

误区 5：把"q 是质数"当成 Euclid 证明的一步

Theorem 2.4 的证明只需要 q 有一个**不在原列表中的质因子**，完全不需要 q 本身是质数。$k = 6$ 时 $q = 30031 = 59 \times 509$ 就是现成的反例（脚本验算）。如果你的证明写了"q 是质数，矛盾"，那么在第 6 步就写不下去了。

误区 6：分情形证明遗漏情形，或情形之间不互斥

- 遗漏：证明"$m(m+1)$ 是偶数"时只讨论 m 是偶数的情形，就漏掉了 m 是奇数的一半（用 L01 的话说，这是把 $P \vee \neg P$ 的排中律丢掉了）。
- 不互斥且假设冲突：在某个有重叠的划分里，两个情形可能对重叠部分给出互相矛盾的假设（例如一边假设"$x \ge 0$"、一边假设"$x \le 0$"却仍声称情形互斥），此时证明无效。
- 正确的写法是：**在证明开头显式说明"以下情形构成一个划分"**，让读者一眼看到穷尽性与互斥性。

误区 7：用"显然""易得"跳步

官方 Note 3 §5 明确提醒：写下一步之前先想清楚这一步的依据是什么。如果说不清为什么这步成立，那就是在跳步（making a leap），必须回去补。一条理由只有在满足"**(1) 它是对的，(2) 读者会自动同意它是对的**"时才可以不加证明地写出。例如"因 a 是整数，$2a^2 + 2a$ 是整数"这一步通常可以省略中间推理（整数加法与乘法封闭），但如果读者群体不确定，就该展开。

思考题（带答案）

Q1.（纯计算） 用鸽笼原理回答：

(a) 一个班有 25 名学生，每人取一个 1 到 4 之间的整数作为编号。证明必有两人的编号相同，并指出至少有多少人共享同一个编号。 (b) 把 100 个球放进 9 个盒子，至少有一个盒子含多少个球？ (c) 在旧金山头发问题中，若已知旧金山人口为 800000，而"头发数"的盒子数改为 400000，结论还成立吗？为什么？

> ▸ **答案**
>
> **(a)** 25 名学生 = 25 只鸽子；编号取值 $\{1, 2, 3, 4\}$ = 4 个盒子。因为 $25 > 4$，由鸽笼原理必有两人的编号相同。加强形式给出至少一个编号被 $\lceil 25/4 \rceil = 7$ 人共享。（脚本验算：$\lceil 25/4 \rceil = 7$ ✓。）
>
> **(b)** 加强形式：至少一个盒子含 $\lceil 100/9 \rceil = \lceil 11.11\ldots \rceil = 12$ 个球。（脚本验算确认 12。）
>
> **(c)** 依然成立，而且结论更强。盒子数从 500001 降到 400000，鸽子数 800000 仍然大于它，故仍有两人头发数完全相同；并且加强形式给出至少有一个头发数被 $\lceil 800000/400000 \rceil = 2$ 人共享。要点在于：**鸽笼原理只关心 $n > k$，盒子的具体数量不影响定性结论，只影响加强形式给出的下界数值。**

Q2.（概念理解） 判断下列推理使用的是直接证明、逆否证明、反证法还是分情形证明，并说明判断依据。

(a) "设 a, b 为整数且 ab 为奇数。假设 a 是偶数，则 $a = 2k$，于是 $ab = 2kb$ 是偶数，与 ab 为奇数矛盾。故 a 是奇数。" (b) "设 a, b 为整数且 ab 为奇数。假设 a 是偶数，则 $a = 2k$，于是 $ab = 2kb$ 是偶数，即 ab 不是奇数。故若 ab 是奇数则 a 不是偶数，即 a 是奇数。" (c) "对任意整数 m，$m(m+1)$ 是偶数：若 m 偶，则 $m(m+1)$ 含因子 m，偶；若 m 奇，则 $m+1$ 偶，$m(m+1)$ 含因子 $m+1$，偶。"

> ▸ **答案**
>
> **(a)** 反证法。判断依据：最后出现了显式的矛盾"ab 是偶数"与"ab 是奇数"（即 $R \wedge \neg R$）。注意它的假设是**整个命题的否定**：待证命题是"a 是奇数"，反证法假设"a 是偶数"（即 $\neg P$）。
>
> **(b)** 逆否证明。判断依据：**全程没有出现矛盾**，推导的终点是"ab 不是奇数"（即 $\neg Q$），然后引用逆否等价收尾。它的假设是 $\neg Q$（"ab 不是奇数"，这里以"a 是偶数"的形式给出），推出 $\neg P$。
>
> **（a）与（b）的数学内容几乎一样，但逻辑结构不同**——这正是本讲要区分的核心。(a) 用了排中律，(b) 没有。
>
> **(c)** 分情形证明。判断依据：证明按 m 的奇偶性把全体整数分成两个分支，且这两个分支穷尽（每个整数非奇即偶）且互斥（不可能既奇又偶）。每支内部都是一次直接证明。

Q3.（证明能力） 设 n 为整数。证明：若 n^2 是奇数，则 n 是奇数。（要求：分别用逆否证明和反证法各写一遍，并指出两个版本在哪一步分道扬镳。）

> ▸ **答案**
>
> **版本一：逆否证明**
>
> 逆否命题为："若 n 不是奇数（即 n 是偶数），则 n^2 不是奇数（即 n^2 是偶数）。"
>
> 1. 假设 n 是偶数。则存在整数 k 使 $n = 2k$。
> 2. 两边平方：$n^2 = 4k^2 = 2(2k^2)$。
> 3. 因 $2k^2 \in \mathbb{Z}$，故 n^2 是偶数，即 n^2 不是奇数。
> 4. 由逆否等价，原命题成立。■
>
> **版本二：反证法**
>
> 1. 反证：假设"若 n^2 是奇数则 n 是奇数"为假。即假设 n^2 是奇数**且** n 不是奇数（n 是偶数）。 —— 注意这里是蕴含式取反，按 L01 的 $\neg(P \Rightarrow Q) \equiv P \wedge \neg Q$，必须同时假设前件为真、后件为假。
> 2. 由 n 是偶数，存在整数 k 使 $n = 2k$。
> 3. 于是 $n^2 = 4k^2 = 2(2k^2)$ 是偶数。这是断言 R（"n^2 是偶数"）。
> 4. 但第 1 步给出 n^2 是奇数，即 $\neg R$。
> 5. 于是 $R \wedge \neg R$，矛盾。故原命题成立。■
>
> **两者在哪里分道扬镳**：第 1 步。
>
> - 逆否版本只假设 $\neg Q$（"n 是偶数"），然后**正向推**出 $\neg P$（"n^2 是偶数"），推完就结束，用等价性收尾。
> - 反证法版本必须假设 $P \wedge \neg Q$，即**还要额外带上 P（"n^2 是奇数"）**，这个多余的假设最后被用来制造矛盾。
>
> **由此可见一个实用结论：当待证命题是蕴含式时，反证法比逆否证明多扛了一个假设 P，通常更长、更笨重。所以对蕴含式，优先试逆否。**只有当命题不是蕴含式（如"$\sqrt{2}$ 是无理数"、"质数有无穷多个"）时，反证法才是唯一选择。

Lecture 3: Induction（归纳法）

概述

前两讲（L00 直接证明、L01 命题逻辑、L02 逆否/反证/分情形）解决的都是**单个命题**的证明问题。但 CS70 里绝大多数命题不是关于一个数、而是关于**无穷多个自然数**的：$\forall n \in \mathbb{N}, P(n)$。逐一验证不可能——自然数有无穷多个，而人只能写有限步。

本讲引入的 **数学归纳法 (Mathematical Induction)** 就是解决这类问题的核心工具：**用有限的手段论证无穷多的情形**。它的第二个形态 **强归纳法 (Strong Induction)** 把归纳假设从"$P(k)$ 成立"加强为"$P(0), P(1), \ldots, P(k)$ 全部成立"，从而能处理"n 依赖多个更小的情形"的问题。本讲还给出归纳法与**递归 (Recursion)** 的对应关系——这正是归纳法能用来证明**递归程序正确性**的原因，也是 CS70 里"数学"与"计算机科学"最直接的接口。

L03 是"证明工具箱"（L00–L03）的最后一块，也是后面每一个算法正确性证明的模板：L05 的 Euclid 算法、L06 的 RSA 解密正确性、L08 的 Berlekamp–Welch 纠错、L09–L10 的图论（树的边数、握手引理）、L11 的 Gale–Shapley 稳定匹配、L14 的组合恒等式、L20 的期望线性性，全部依赖归纳法。

核心概念的直观解释

概念一：数学归纳法 (Mathematical Induction)

- **定义**：要证明 $\forall n \in \mathbb{N},\ P(n)$，只需完成两件事：
- **基础情形 (Base Case)**：证明 $P(0)$（或某个适当的起始值 n_0）为真。
- **归纳步骤 (Inductive Step)**：对任意 $k \geq 0$，证明 $P(k) \Rightarrow P(k+1)$。其中"假设 $P(k)$ 成立"这一条叫做 **归纳假设 (Induction Hypothesis, IH)**。 两步都完成后，由**数学归纳法公理 (axiom of mathematical induction)** 断言 $\forall n \in \mathbb{N}, P(n)$。
- **直观解释（多米诺骨牌）**：把 $P(0), P(1), P(2), \ldots$ 想象成排成一列的多米诺骨牌。

- **基础情形** = 你伸手推倒第 0 张牌。
- **归纳步骤** = 牌与牌之间的距离排得足够近，保证第 k 张倒下时必然撞倒第 $k+1$ 张。这一步与"牌实际倒没倒"无关——它是一条关于**排列方式**的静态事实。
- **结论** = 第 0 张倒下引发连锁反应，全部倒下。 三个要素缺一不可：只推倒第 0 张而牌距太远（$P(k) \not\Rightarrow P(k+1)$），链条断在第一格；牌距排得再好而没人推第一张（漏掉基础情形），一张都不会倒。
- **具体示例**：证明 $1+3+5+\cdots+(2n-1)=n^2$。基础情形 $n=1$：左边 $=1$，右边 $=1$。归纳步骤：假设 $1+3+\cdots+(2k-1)=k^2$，则加上第 $k+1$ 个奇数 $2k+1$ 得 $k^2+2k+1=(k+1)^2$，正是 $n=k+1$ 时的结论。两步齐备，全部 $n \geq 1$ 成立。

概念二：良序原理 (Well-Ordering Principle) —— 归纳法的合法性来源

- **定义**：$\mathbb{N}$ 的每一个**非空**子集都有一个**最小元素**。
- **直观解释**：自然数是从 0 开始、一格一格往上的，不能无限向下走。所以任何一堆自然数里总能揪出最小的那个。（对比：整数集 $\mathbb{Z}$ 和正有理数集 $\mathbb{Q}_{>0}$ 都**不**满足良序原理——$\mathbb{Z}$ 没有最小元，$\{1, 1/2, 1/3, \ldots\}$ 没有最小元。）
- **它如何为归纳法背书（必须会写这段论证）**： 设我们已经证明了 $P(0)$，也证明了 $\forall k,\ P(k) \Rightarrow P(k+1)$。**反证**：假设结论不成立，即存在自然数 n 使 $P(n)$ 为假。 考虑集合 $S := \{n \in \mathbb{N} : P(n) \text{ 为假}\}$，即"所有反例"的集合。由假设 S 非空，故由**良序原理**，S 有最小元素，记作 m。 由于 $P(0)$ 为真，$m \neq 0$，所以 $m \geq 1$，从而 $m-1 \in \mathbb{N}$。 由 m 的**最小性**，$m-1 \notin S$，即 $P(m-1)$ 为真。 但归纳步骤说 $\forall k,\ P(k) \Rightarrow P(k+1)$；取 $k=m-1$ 得 $P(m-1) \Rightarrow P(m)$，故 $P(m)$ 为真。 这与 $P(m)$ 为假（$m \in S$）矛盾。 所以 S 必须是空集，即不存在反例，$\forall n \in \mathbb{N},\ P(n)$ 成立。
- **具体示例（应用同一论证模式）**：证明"每个大于 1 的整数都有质因子"。设反例集非空，取最小反例 m；若 m 是质数则它就是自己的质因子，矛盾；否则 $m=ab$ 且 $1<a<m$，由 m 的最小性 a 有质因子，而该质因子也整除 m，矛盾。这个"取最小反例"的套路与上面的论证完全同构，是本课程反复出现的证明骨架。

概念三：强归纳法 (Strong Induction)

- **定义**：要证明 $\forall n \geq n_0,\ P(n)$：
- **基础情形**：证明 $P(n_0)$（有时候需要证明**多个**基础情形，例如 $P(n_0), P(n_0+1), \ldots$）。
- **归纳假设（强化版）**：对任意 $k \geq n_0$，假设 $P(n_0), P(n_0+1), \ldots, P(k)$ **全部**为真，即 $\bigwedge_{i=n_0}^{k} P(i)$。
- **归纳步骤**：在 (2) 的假设下证明 $P(k+1)$。
- **直观解释**：多米诺版的说法是——简单归纳依赖"第 k 张撞倒第 $k+1$ 张"（只用到紧邻的前一张）；强归纳依赖"第 n_0 到第 k 张全部倒下时，第 $k+1$ 张必然倒下"（用到前面所有牌）。
- **逻辑等价性（重要）**：**强归纳与简单归纳在证明能力上完全等价**，强归纳能证的简单归纳都能证，反之亦然。直观理由：如果简单归纳的链条真的成立了，那么第 0 张倒下会依次撞倒第 1、2、…、k 张，等到要处理第 $k+1$ 张时，前面所有牌都已经倒了——这正是强归纳假设的内容。形式化的说法：令 $Q(n) := P(0) \wedge P(1) \wedge \cdots \wedge P(n)$，则"对 P 的强归纳"等价于"对 Q 的简单归纳"。
- **那为什么还要用它？** 因为强归纳的归纳假设**更强**，所以**用起来更省力**。官方给的比喻很贴切：螺丝刀和电动螺丝刀——它们能完成的**任务集合相同**，但后者**用起来轻松得多**。典型场景是"n 的结论依赖某个比 n 小但不一定等于 $n-1$ 的量"（例如 $n=ab$，a, b 都可能远小于 n），此时简单归纳的 $P(k)$ 根本不够用。
- **具体示例**：证明每个 $n \geq 12$ 可写成 $4x+5y$。归纳步骤要处理 $n=k+1$，但唯一的出路是回退到 $n-4$（即 $k-3$），这不是 k，简单归纳假设 $P(k)$ 完全使不上力；而强归纳假设允许我们使用 $P(k-3)$（只要 $k-3 \geq 12$）。详见后文。

概念四：强化归纳假设 (Strengthening the Induction Hypothesis)

- **定义**：当"直觉上更弱"的目标命题 $P(n)$ 用归纳法证不动时，转而证明一个**更强但更有结构**的命题 $P'(n)$（满足 $P'(n) \Rightarrow P(n)$）。由于待证更强，归纳假设也更强，归纳步骤反而更容易完成。
- **直观解释**：这是归纳法最反直觉的一点——**证一个更强的命题反而更容易**。原因在于 $P(n)$ 太"模糊"（例如只说"是平方数"而不说"是哪一个平方数"），归纳假设携带的信息量不足以推出 $P(k+1)$。强化后的 $P'(n)$ 把结构写清楚了（"恰好等于 n^2"），于是 $k^2+(2k+1)=(k+1)^2$ 一步到位。
- **代价与收益**：代价是你**必须多证一些东西**（P' 比 P 强），收益是归纳假设变得**可用**。实践中判断是否需要强化的信号是：**归纳步骤卡住了，卡住的位置恰好是"缺少关于 k 的精确信息"**。
- **具体示例**：目标"前 n 个奇数之和是完全平方数"证不动；强化为"前 n 个奇数之和 $=n^2$"后立刻证通。另一个例子：目标 $\sum_{i=1}^{n} 1/i^2 \leq 2$ 证不动；强化为 $\sum_{i=1}^{n} 1/i^2 \leq 2 - 1/n$ 后证通。两例详见后文。

概念五：归纳法与递归 (Recursion) 的对应

- **定义**：**递归**是用自身定义自身的函数定义方式：$F(n)$ 的值由 F 在更小参数上的值决定，并配以基础值。例如 $F(0)=0,\ F(1)=1,\ F(n)=F(n-1)+F(n-2)$。
- **直观解释**：归纳法"自底向上爬"（从 $P(0)$ 爬到 $P(n)$），递归"自顶向下拆"（把 $F(n)$ 拆成更小的 F）。两者是**同一个数学事实的两面**：递归定义之所以良定义（不会无限向下递归），依据正是良序原理；递归程序的正确性证明，结构上就是一次归纳（通常是强归纳，因为递归调用可能落在任意更小的参数上）。
- **具体示例**：递归的 `F(n) = F(n-1) + F(n-2)` 对应归纳中的"用 $P(k-1)$ 和 $P(k-2)$ 推 $P(k)$"。这就是为什么递归程序的正确性几乎总要靠**强归纳**来证。

完整证明与推导（核心）

一、归纳法第一例：前 n 个自然数之和

定理 3.1（官方 Note 4 的 Theorem 4.1）：$\forall n \in \mathbb{N},\ \sum_{i=0}^{n} i = \frac{n(n+1)}{2}$。

证明策略：用**简单归纳法**，对变量 n 做归纳。为什么需要归纳？因为命题对无穷多个 n 都要成立，而验证前几个值是不够的。

为什么"验证前几项"不够：官方的 n^2-n+41 反例

官方在引入归纳法之前先用一个**警告性例子**说明"检查前几项"的不可靠：考虑命题 $\forall n \in \mathbb{N},\ n^2 - n + 41$ 是质数。

脚本验算结果：

n	$n^2 - n + 41$	是否质数
0	41	是
1	41	是
2	43	是
3	47	是
10	131	是
20	421	是
30	911	是
39	1523	是
40	1601	是
41	**1681**	**否！$1681 = 41 \times 41$**

也就是说，$n = 0, 1, 2, \ldots, 40$ **全部**给出质数（整整 41 个连续的成功案例！），但 $n = 41$ 时立刻崩溃：$41^2 - 41 + 41 = 41^2 = 1681$ 是合数。这个例子的教训是：**有限次验证永远无法排除无穷多个情形中的反例**。归纳法的价值就在于它用一个有限的论证（基础情形 + 归纳步骤）覆盖了所有的 n。

逐步推导：

记 $P(n)$ 为命题 $\displaystyle\sum_{i=0}^{n} i = \frac{n(n+1)}{2}$。我们对 n 做归纳。

1. **基础情形 $(n = 0)$**：左边 $= \displaystyle\sum_{i=0}^{0} i = 0$（空和到 0 即只有 $i = 0$ 这一项，值为 0）；右边 $= \dfrac{0 \cdot 1}{2} = 0$。左边 = 右边 ✓，故 $P(0)$ 成立。
2. **归纳假设 (IH)**：对某个任意的 $k \geq 0$，假设 $P(k)$ 成立，即

$$\sum_{i=0}^{k} i = \frac{k(k+1)}{2}.$$

注意这里 k 是**任意的但固定的**——我们不能取 k 为具体数字（如 $k = 5$），否则证明只能覆盖那一个值。

1. **归纳步骤**：证明 $P(k+1)$，即证明 $\displaystyle\sum_{i=0}^{k+1} i = \frac{(k+1)(k+2)}{2}$。推导如下：

$$\begin{aligned}
\sum_{i=0}^{k+1} i &= \left(\sum_{i=0}^{k} i\right) + (k+1) && \text{（把最后一项 } i = k+1 \text{ 拆出来；加法结合律）} \\
&= \frac{k(k+1)}{2} + (k+1) && \text{（代入归纳假设 IH）} \\
&= \frac{k(k+1) + 2(k+1)}{2} && \text{（通分，} k+1 = \tfrac{2(k+1)}{2}\text{）} \\
&= \frac{(k+1)(k+2)}{2} && \text{（提取公因子 } k+1\text{）}
\end{aligned}$$

末行正是 $P(k+1)$ 的右边。故 $P(k) \Rightarrow P(k+1)$。

1. **结论**：由数学归纳法原理，$\forall n \in \mathbb{N},\ P(n)$ 成立。■

【证明机制解说】：这个证明的**唯一关键步骤是第 3 步的第一个等号**——把 $\sum_{i=0}^{k+1} i$ 拆成 $\left(\sum_{i=0}^{k} i\right) + (k+1)$。这个"**拆出最后一项**"的动作是几乎所有求和型归纳证明的起手式：它把新命题 $P(k+1)$ 的左边改写成"归纳假设能处理的部分 + 剩下的一项"。若不拆，$\sum_{i=0}^{k+1} i$ 与 $\sum_{i=0}^{k} i$ 之间就没有任何可用的桥。第二个等号则是**归纳假设唯一被用到的地方**，也是整个证明的"动力输入口"。

算例验算（脚本已核）：

n	$\sum_{i=0}^{n} i$（直接累加）	$n(n+1)/2$（公式）	一致?
0	0	0	✓
1	1	1	✓
2	3	3	✓
3	6	6	✓
5	15	15	✓
8	36	36	✓

二、归纳法第二例：$n^3 - n$ 被 3 整除

定理 3.2（官方 Note 4 的 Theorem 4.2）：对所有 $n \in \mathbb{N}$，$n^3 - n$ 被 3 整除。

证明策略：用**简单归纳法**。官方采用**纯代数分解**的路线（不显式分情形），我们先把官方路线写全；随后**额外补充一条分情形的路线**，以展示"同一命题、两种归纳步骤写法"，也回应"为什么这个命题天然与模 3 相关"。

逐步推导（官方代数路线）：

记 $P(n)$ 为命题 $3 \mid (n^3 - n)$。我们对 n 做归纳。

1. **基础情形 $(n = 0)$**：$P(0)$ 断言 $3 \mid (0^3 - 0)$，即 $3 \mid 0$。按整除的定义（$a \mid b$ 当且仅当存在整数 q 使 $b = aq$），取 $q = 0$ 得 $0 = 3 \cdot 0$，故成立。（**注意**：非零整数都整除 0，这一点是定义直接给出的，不是"显然"。）
2. **归纳假设 (IH)**：对某个任意的 $k \geq 0$，假设 $P(k)$ 成立，即 $3 \mid (k^3 - k)$。按定义，这等价于存在整数 q 使得

$$k^3 - k = 3q.$$

（**把整除翻译成一个等式，是这类证明的必备动作**——整除本身不能参与代数运算，等式才能。）

1. **归纳步骤**：证明 $P(k+1)$，即 $3 \mid ((k+1)^3 - (k+1))$。从 $(k+1)^3$ 的二项式展开出发：

$$\begin{aligned}
(k+1)^3 - (k+1) &= k^3 + 3k^2 + 3k + 1 - (k+1) && (\text{展开 } (k+1)^3 = k^3 + 3k^2 + 3k + 1) \\
&= k^3 + 3k^2 + 3k - k && (\text{消去 } +1 \text{ 与 } -1) \\
&= (k^3 - k) + 3k^2 + 3k && (\text{重新分组，目的：凑出 } k^3 - k) \\
&= 3q + 3(k^2 + k) && (\text{代入 IH：} k^3 - k = 3q) \\
&= 3\left(q + k^2 + k\right) && (\text{提取公因子 } 3)
\end{aligned}$$

因 q, k 都是整数，$q + k^2 + k \in \mathbb{Z}$（整数对加法与乘法封闭）。故 $(k+1)^3 - (k+1)$ 是 3 的整数倍，即 $3 \mid ((k+1)^3 - (k+1))$，$P(k+1)$ 成立。

1. **结论**：由归纳法原理，$\forall n \in \mathbb{N},\ 3 \mid (n^3 - n)$。■

【证明机制解说】：关键是第三个等号处的"**凑项**"：把 $k^3 + 3k^2 + 3k - k$ 重新分组为 $(k^3 - k) + (3k^2 + 3k)$。这不是随意的变形——它精确地把表达式切成两块：第一块 $(k^3 - k)$ 正是归纳假设能处理的形式，第二块 $3k^2 + 3k$ 天然含因子 3，不需要任何假设。**"把目标表达式拆成'归纳假设形式' + '显然成立部分'"是代数型归纳证明的通用套路**，与本讲定理 3.1 中"拆出最后一项"是同一思想。

补充路线（分情形，展示命题与模 3 的内在联系）：

注意到 $n^3 - n = n(n-1)(n+1)$，即**三个连续整数之积**。这个因式分解立刻解释了命题：三个连续整数中必有一个被 3 整除（把"被 3 除的余数"当盒子只有 3 个，连续三个数落进去，鸽笼原理的加强形式给出必有 $\lceil 3/3 \rceil = 1$ 个余数为 0——更直接地说，余数按 $0, 1, 2$ 循环）。于是归纳步骤可以这样写：

归纳步骤（分情形版）：要证 $3 \mid ((k+1)^3 - (k+1))$。按 $(k+1) \bmod 3$ 的取值分三种情形（**穷尽且互斥**，因为任何整数模 3 的余数只能是 $0, 1, 2$）：

- **情形 (i)**：$k + 1 \equiv 0 \pmod 3$。则 $3 \mid (k+1)$，而 $(k+1)^3 - (k+1) = (k+1)\left[(k+1)^2 - 1\right]$ 含因子 $k+1$，故 $3 \mid ((k+1)^3 - (k+1))$ ✓。
- **情形 (ii)**：$k + 1 \equiv 1 \pmod 3$。则 $k \equiv 0 \pmod 3$，故 $3 \mid k$。而 $(k+1)^3 - (k+1) = k(k+1)(k+2)$ 含因子 k ✓。
- **情形 (iii)**：$k + 1 \equiv 2 \pmod 3$。则 $k + 2 \equiv 1 + 2 = 3 \equiv 0 \pmod 3$，故 $3 \mid (k+2)$。而 $(k+1)^3 - (k+1) = k(k+1)(k+2)$ 含因子 $k+2$ ✓。

（**注意**：这条路线其实**没有用到归纳假设**——它是对所有 n 直接成立的事实：$n(n-1)(n+1)$ 中必有一个是 3 的倍数。这提示我们：遇到整除型命题时，先试试因式分解，可能一步就能绕开归纳。但作为展示"归纳步骤如何与分情形结合"的范例，它非常典型——L03 后面定理 3.6、3.7 的归纳步骤都要分情形。）

算例验算（脚本已核，$n = 0$ 到 8）：

n	$n^3 - n$	$n^3 - n \bmod 3$	$n \bmod 3$
0	0	0	0
1	0	0	1
2	6	0	2
3	24	0	0
4	60	0	1
5	120	0	2
6	210	0	0
7	336	0	1
8	504	0	2

代数恒等式验算：$(k+1)^3 - (k+1) = (k^3 - k) + 3k^2 + 3k$ 对 $k = 0, 1, 2, 3, 4, 5$ 逐一核对：$(0,0), (6,6), (24,24), (60,60), (120,120), (210,210)$，两边完全一致 ✓。

三、归纳法第三例：两色定理（几何命题的归纳证明）

背景：**四色定理 (Four Color Theorem)** 断言任何地图都能用 4 种颜色着色，使相邻（共享**非平凡边界**——不止一个点）的国家颜色不同。它从 1852 年提出后困扰数学界百余年，多份"证明"被提交又被推翻，直到 1976 年才由 Appel 与 Haken 给出**计算机辅助证明**。本讲证明它的一个**简化版本**：如果"地图"是矩形被若干**直线**划分而成，那么 **2 种颜色就够了**。

定理 3.3（官方 Note 4 的 Theorem 4.3）：设 $P(n)$ 表示命题"任何形如上述（矩形被 n 条直线分割）的地图都是两色可着色的"。则 $\forall n \in \mathbb{N},\ P(n)$ 成立。

证明策略：用**简单归纳法**，归纳变量是直线数 n。这里的难点不是代数，而是**几何对象的"减一"操作**：给定一个 $n = k+1$ 条线的地图，我们要先"删掉一条线"退回到 k 条线的地图，对后者用归纳假设，再把线放回去并**修补着色**。这类"构造性的减一 → 修补"是几何归纳证明的标准范式。

逐步推导：

1. **基础情形 $(n = 0)$**：没有直线时，整个矩形就是一个区域，用单一颜色涂满即可。$P(0)$ 成立。✓
2. **归纳假设 (IH)**：对某个任意的 $k \geq 0$，假设 $P(k)$ 成立，即任何被 k 条直线分割的地图都能两色着色。
3. **归纳步骤**：证明 $P(k+1)$。任取一张被 $k+1$ 条直线 $\ell_1, \ldots, \ell_{k+1}$ 分割的地图 M。
4. **删除一条线**：从 M 中去掉最后一条线 ℓ_{k+1}，得到地图 M'，它只被 k 条直线分割。
5. **应用归纳假设**：由 IH，M' 存在一个合法的两色着色（红 / 蓝），即任意两个共享边界的区域颜色不同。
6. **观察"翻转不变性"**：给定一个合法着色，如果把**所有**区域的红蓝互换（红 $\to$ 蓝，蓝 $\to$ 红），得到的仍然是一个合法着色。理由：合法性只要求"相邻区域颜色**不同**"，而互换保持了"不同"这个关系（红蓝互换是一一对应的双射）。同理，**只对地图的某一部分**翻转颜色，只要翻转的部分与未翻转部分之间没有"相邻"跨越，就仍然合法。
7. **放回 ℓ_{k+1} 并修补**：把 ℓ_{k+1} 放回。这条直线把整个矩形分成两个半平面 H^+ 与 H^-。规则是：H^- 一侧的所有区域**保持** M' 中的颜色不动，H^+ 一侧的所有区域**红蓝互换**。
8. **验证合法性**：任取两个共享非平凡边界的区域 A, B，检查它们颜色是否不同。按共享边界落在哪条线上分两种情形（**穷尽且互斥**——每条直线要么是 ℓ_{k+1}，要么是前 k 条之一）：
9. **情形 1：共享边界落在直线 ℓ_{k+1} 上**。此时 A, B 分别位于 H^+ 与 H^-（因为 ℓ_{k+1} 是它们的分界）。在 M' 中 A, B 属于同一区域（被 ℓ_{k+1} 切开之前是一块），颜色相同，设为红。放回后，H^- 侧的保持红，H^+ 侧的翻转为蓝。两者颜色不同 ✓。
10. **情形 2：共享边界落在前 k 条直线中的某条上**。此时 A, B 在 M' 中就已经是相邻的不同区域（删掉 ℓ_{k+1} 并不改变它们之间的这条边界）。由 IH，它们在 M' 的着色中颜色不同。放回 ℓ_{k+1} 后需要检查翻转有没有破坏这一点。关键在于：A, B 的共享边界是一条**不落在 ℓ_{k+1} 上**的线段，除端点外它完全位于 ℓ_{k+1} 的某一侧，因此 A 与 B 落在 ℓ_{k+1} 的**同一侧**，于是它们**要么同被翻转、要么同不被翻转**。红蓝互换是一一对应的双射，"颜色不同"这一关系在"两边同时互换"下保持不变，故 A, B 颜色仍然不同 ✓。
11. **结论**：由归纳法原理，$\forall n \in \mathbb{N},\ P(n)$ 成立。■

ASCII 图示（两色定理的归纳步骤）：

```
用最小规模看机制：矩形先被 1 条水平线 l1 分成上下两块 (k=1)
  +---------------------------+   由 IH 得到的一个合法两色着色：
  |            R              |     上块 R，下块 B（跨 l1 颜色不同 ✓）
  |                           |
  |===========================|   <-- l1 (水平线)
  |                           |
  |            B              |
  +---------------------------+

                       |  现在放回第 (k+1) 条线 l2 (竖直线)，
                       |  规则：l2 左侧颜色不动，右侧 R<->B 翻转
                       v

  +--------------+--------------+
  |      R       #      B      |   跨 l2: R 与 B 不同 ✓
  |              #             |
  |==============#=============|   <-- l1
  |              #             |
  |      B       #      R      |   跨 l2: B 与 R 不同 ✓
  +--------------+--------------+
                 ^
            l2 (第 (k+1) 条线)

四对相邻检查：
  上左/上右 跨 l2 : R vs B  ✓      下左/下右 跨 l2 : B vs R  ✓
  上左/下左 跨 l1 : R vs B  ✓      上右/下右 跨 l1 : B vs R  ✓
=> 全部相邻区域颜色不同，两色着色合法
```

手工核对 $(k = 1 \to 2)$：M' 是 $k = 1$ 条线的地图，着色为上 R、下 B（脚本验证：$n = 1$ 时区域数 $= 2$）。放回 ℓ_2 后，左侧保持 (R, B)，右侧翻转为 (B, R)。四个区域两两相邻关系全部满足"不同色"，构造成功。这也是归纳步骤在最小规模上的自检。

算例（n 条一般位置直线的区域数与着色）：n 条直线若两两相交且无三条共点，把平面分成 $\dfrac{n(n+1)}{2} + 1$ 个区域：

n	区域数 $\frac{n(n+1)}{2}+1$	两色可着?
0	1	✓（单色）
1	2	✓
2	4	✓
3	7	✓（奇数个区域也可以两色）
4	11	✓

	区域数	两色可着?
5	16	✓

（脚本已核。）**注意一个常见误解**：区域数是奇数（如 $n=3$ 时 7 个区域）**不构成障碍**。两色定理只要求"相邻区域颜色不同"，不要求两种颜色数量相等，也不要求区域数与颜色数有任何整除关系。

【证明机制解说】：整个证明的"灵光一现"是那句看似平淡的观察——**"合法着色在红蓝全局互换后仍是合法着色"**。这条性质之所以有用，是因为它给了我们一个**自由度**：我们可以对地图的任意"独立部分"单独翻转而保持合法性。于是"删线 → 着色 → 放线 → 翻转一侧"这四步就能把 k 条线的解**升级**为 $k+1$ 条线的解。这个手法的本质是：**归纳步骤不需要从零构造 $n+1$ 的解，只需要把 n 的解"修补"成 $n+1$ 的解**。几乎所有几何归纳证明（以及后续图论中的树、平面图定理）都遵循这个"删一点/删一边 → 修补"的模式。

为什么这是四色定理的简化版：一般地图中，一个国家（区域）可以有**任意多**个邻国，因此"删掉一个国家、补色"的自由度不够；而直线划分的结构保证了每个区域都是凸的，被一条线切开恰好产生两块，且"翻转一侧"这个全局操作总是有效。四色定理的困难恰恰在于这种全局修补策略在一般地图上失效。

四、强化归纳假设：两个范例

（A）第一个范例：前 n 个奇数之和

尝试一（失败的证明）：

> **目标**：对所有 $n \geq 1$，前 n 个奇数之和是一个**完全平方数 (perfect square)**。 **基础情形 $(n=1)$**：第一个奇数是 1，$1 = 1^2$ 是完全平方数 ✓。 **归纳假设**：假设前 k 个奇数之和是完全平方数，设为 m^2。 **归纳步骤**：第 $k+1$ 个奇数是 $2k+1$。由 IH，前 $k+1$ 个奇数之和为 $m^2 + 2k + 1$。**卡住了**——$m^2 + 2k + 1$ 为什么必须是完全平方数？我们只知道 m 是某个整数，与 k 之间**没有任何已知关系**，无法判断 $m^2 + 2k + 1$ 是不是平方数。

诊断：归纳假设太"弱"——它只说"是平方数"，没有告诉我们**是哪个**平方数。信息量不足，无法推进到 $k+1$。

先做小规模计算，寻找结构：

n	前 n 个奇数	和	是否平方数	等于 n^2?
1	1	1	$1 = 1^2$	✓
2	1+3	4	$4 = 2^2$	✓
3	1+3+5	9	$9 = 3^2$	✓
4	1+3+5+7	16	$16 = 4^2$	✓
5	1+3+5+7+9	25	$25 = 5^2$	✓
6	加到 11	36	$36 = 6^2$	✓

（脚本已核到 $n=8$：和为 64。）小规模计算揭示了一个**比原命题更强的结构**：和不只是"某个平方数"，而是**恰好等于 n^2**。这就给出了强化的方向。

定理 3.4（官方 Note 4 的 Theorem 4.4）：对所有 $n \geq 1$，前 n 个奇数之和等于 n^2。

证明策略：用**简单归纳法**，但证明的是**强化后**的命题（把"是完全平方数"精确化为"等于 n^2"）。强化后归纳假设携带了 k 的精确信息，$k^2 + (2k+1)$ 就能用完全平方公式直接收口。

逐步推导：

1. **基础情形 $(n=1)$**：第一个奇数是 1，而 $1 = 1^2$ ✓。
2. **归纳假设 (IH)**：假设前 k 个奇数之和 $= k^2$，即 $1 + 3 + 5 + \cdots + (2k-1) = k^2$。
3. **归纳步骤**：第 $k+1$ 个奇数是 $2(k+1) - 1 = 2k+1$。由 IH，

$$1 + 3 + \cdots + (2k-1) + (2k+1) = k^2 + (2k+1).$$

而右边正是**完全平方公式**的展开式：

$$k^2 + 2k + 1 = (k+1)^2.$$

故前 $k+1$ 个奇数之和 $= (k+1)^2$，$P(k+1)$ 成立。 4. **结论**：由归纳法原理，对所有 $n \geq 1$，前 n 个奇数之和 $= n^2$。■

【证明机制解说】：对比两次尝试的归纳步骤：失败的版本卡在 $m^2 + 2k + 1$（m 与 k 无关，无从下手）；成功版本一步得到 $k^2 + (2k+1) = (k+1)^2$。差别**完全在于归纳假设携带了多少信息**。这就是"强化假设"的核心机制：**待证命题越具体，归纳假设就越有力**。请注意逻辑上的微妙之处——我们证明了一个**更强**的命题（"等于 n^2"），它蕴含原来的弱命题（"是平方数"），所以原命题也顺带得证。**"证更强的命题"不是绕路，而是唯一可行的路。**

（B）第二个范例：平方倒数和的上界

尝试一（失败的证明）：

> **目标**：对所有 $n \geq 1$，$\sum_{i=1}^{n} \frac{1}{i^2} \leq 2$。 **归纳假设**：假设 $\sum_{i=1}^{k} 1/i^2 \leq 2$。 **归纳步骤**：要证 $\sum_{i=1}^{k} 1/i^2 + \frac{1}{(k+1)^2} \leq 2$。由 IH，左边 $\leq 2 + \frac{1}{(k+1)^2}$。**卡住了**——$2 + \frac{1}{(k+1)^2} > 2$，超出了我们要证的上界。

诊断：IH 只说"≤ 2"，但 ≤ 2 这个界**太松**。必须追问：$\sum_{i=1}^{k} 1/i^2$ 有可能**恰好等于 2** 吗？如果可以，那加上正项 $\frac{1}{(k+1)^2}$ 就必然超过 2，证明无救。脚本验算显示实际部分和远小于 2：

n	$\sum_{i=1}^{n} 1/i^2$	$2 - 1/n$	上界是否成立
1	1.000000	1.000000	✓（取等）
2	1.250000	1.500000	✓
3	1.361111	1.666667	✓
5	1.463611	1.800000	✓
10	1.549768	1.900000	✓
12	1.564977	1.916667	✓

（真正的极限是 $\pi^2/6 \approx 1.644934$，也远小于 2；但这需要 L24 之后的级数工具。）同时我们看到一个更强的、带"余量"的上界正在成立：$\sum_{i=1}^{n} 1/i^2 \le 2 - 1/n$。这正是强化的方向——**把固定界 2 换成一个随 n 收紧的界 $2 - 1/n$，从而为下一步留出空间**。

定理 3.5（官方 Note 4 的 Theorem 4.5）：对所有 $n \ge 1$，$\displaystyle\sum_{i=1}^{n} \frac{1}{i^2} \le 2 - \frac{1}{n}$。

证明策略：用**简单归纳法 + 强化归纳假设**。强化的作用是要制造"余量"：IH 给出 $\sum_{i=1}^{k} 1/i^2 \le 2 - 1/k$，而我们要证的是 $\le 2 - \frac{1}{k+1}$。两者之差 $-\frac{1}{k}$ 与 $-\frac{1}{k+1}$ 恰好留下足够的空间容纳新增的 $+\frac{1}{(k+1)^2}$。

逐步推导：

1. **基础情形 $(n=1)$**：左边 $= \displaystyle\sum_{i=1}^{1} \frac{1}{i^2} = 1$；右边 $= 2 - \frac{1}{1} = 1$。故 $1 \le 1$ ✓。
2. **归纳假设 (IH)**：假设 $\displaystyle\sum_{i=1}^{k} \frac{1}{i^2} \le 2 - \frac{1}{k}$。
3. **归纳步骤**：由 IH，

$$\sum_{i=1}^{k+1} \frac{1}{i^2} = \sum_{i=1}^{k} \frac{1}{i^2} + \frac{1}{(k+1)^2} \le \left(2 - \frac{1}{k}\right) + \frac{1}{(k+1)^2} = 2 - \frac{1}{k} + \frac{1}{(k+1)^2}.$$

于是要证目标 $2 - \frac{1}{k+1}$，只需证

$$2 - \frac{1}{k} + \frac{1}{(k+1)^2} \le 2 - \frac{1}{k+1}. \qquad (\star)$$

下面完成这个代数验证（官方留作练习）：

$$\begin{aligned}
(\star) &\iff -\frac{1}{k} + \frac{1}{(k+1)^2} \le -\frac{1}{k+1} && \text{（两边同时减去 } 2\text{）} \\
&\iff \frac{1}{k+1} + \frac{1}{(k+1)^2} \le \frac{1}{k} && \text{（移项）} \\
&\iff \frac{(k+1)+1}{(k+1)^2} \le \frac{1}{k} && \text{（左边通分：} \tfrac{1}{k+1} = \tfrac{k+1}{(k+1)^2}\text{）} \\
&\iff \frac{k+2}{(k+1)^2} \le \frac{1}{k} \\
&\iff k(k+2) \le (k+1)^2 && \text{（两边同乘正数 } k(k+1)^2 > 0\text{，不等号方向不变）} \\
&\iff k^2 + 2k \le k^2 + 2k + 1 && \text{（两边展开）} \\
&\iff 0 \le 1 && \text{（恒真）}
\end{aligned}$$

最后一行恒成立，故 $(\star)$ 成立，归纳步骤完成。 4. **结论**：由归纳法原理，对所有 $n \ge 1$，$\sum_{i=1}^{n} 1/i^2 \le 2 - 1/n$ 成立。作为推论，$\sum_{i=1}^{n} 1/i^2 \le 2 - 1/n < 2$，原命题也成立。■

总代价验算（脚本已核 $k = 1$ 到 8）：不等式 $2 - \frac{1}{k} + \frac{1}{(k+1)^2} \le 2 - \frac{1}{k+1}$ 在每一处都成立，等价的移项形式 $\frac{1}{k} - \frac{1}{(k+1)^2} \ge \frac{1}{k+1}$ 亦全部成立（例如 $k = 8$：左边 $0.112654 \ge$ 右边 0.111111 ✓）。注意 k 越小余量越大（$k = 1$ 时左边 0.75 远大于右边 0.5），**"余量随 n 递减但始终为正"**正是强化形式 $2 - 1/n$ 被选中的原因。

【证明机制解说】：两个强化范例的机制完全同构：**原命题的界太"钝"，无法吸收归纳步骤新增的量；强化后的命题提供一个"恰好够用"的收紧界，把新增量吃掉。**判断是否需要强化、以及该强化成什么形式，靠的是**先算几个小规模数值看趋势**（范例 A 看到 $1, 4, 9, 16, 25$ 认出 n^2；范例 B 看到部分和远低于 2，于是尝试带 $1/n$ 的余量）。这个"**小规模计算 → 发现结构 → 强化命题**"的工作流是数学研究中的真实做法，不是考试技巧。

五、简单归纳 vs. 强归纳：两个必证定理

定理 3.6（官方 Note 4 的 Theorem 4.6 / Postage Stamp Problem）：对每个自然数 $n \ge 12$，存在 $x, y \in \mathbb{N}$ 使 $n = 4x + 5y$。

背景：这就是**邮票问题 (Postage Stamp Problem)**——用 4 分和 5 分两种邮票，支付任意 ≥ 12 分的邮资。它也等价于硬币找零问题。

证明策略：用**强归纳法**，并且**需要四个基础情形**。为什么必须强归纳？因为归纳步骤里 $k+1$ 要回退到 $(k+1) - 4 = k - 3$，这不是 k，简单归纳假设（只有 $P(k)$）完全帮不上忙。为什么需要四个基础情形？因为归纳步骤对 $k + 1 \ge 16$ 才有效（要求回退目标 ≥ 12），所以 $n = 12, 13, 14, 15$ 这"前四个"必须手工验证，归纳链条从这里起步。

逐步推导：

1. **基础情形 $(n=12)$**：$12=4\cdot 3+5\cdot 0$，取 $(x,y)=(3,0)$ ✓。
2. **基础情形 $(n=13)$**：$13=4\cdot 2+5\cdot 1$，取 $(x,y)=(2,1)$ ✓。
3. **基础情形 $(n=14)$**：$14=4\cdot 1+5\cdot 2$，取 $(x,y)=(1,2)$ ✓。
4. **基础情形 $(n=15)$**：$15=4\cdot 0+5\cdot 3$，取 $(x,y)=(0,3)$ ✓。
5. **归纳假设 (IH，强归纳)**：固定任意 $k\geq 15$，假设命题对所有满足 $12\leq n\leq k$ 的 n 都已成立。（注意这里假设的是**一整段区间**，而不只是单个 k。）
6. **归纳步骤**：证明 $n=k+1$ 的情形。因为 $k\geq 15$，故 $k+1\geq 16$，从而 $(k+1)-4=k-3\geq 12$。于是 $k-3$ 落在归纳假设的覆盖范围 $[12,k]$ 内（它 ≥ 12 且 $\leq k$），由 IH 存在 $x',y'\in\mathbb{N}$ 使

$$k-3=(k+1)-4=4x'+5y'.$$

两边同时加 4：

$$k+1=4x'+5y'+4=4(x'+1)+5y'.$$

取 $x=x'+1\in\mathbb{N}$，$y=y'\in\mathbb{N}$，即得 $k+1=4x+5y$，$P(k+1)$ 成立。 7. **结论**：由强归纳法原理，对所有 $n\geq 12$，存在 $x,y\in\mathbb{N}$ 使 $n=4x+5y$。■

【证明机制解说】：这个证明有两个机制要点。

第一，为什么必须强归纳。 归纳步骤唯一可用的回退路径是"给 n 减 4"（因为要凑出一个 4 分邮票）。$n=k+1$ 时回退到 $k-3$。简单归纳只给你 $P(k)$——它说的是 k 能被表示，而 k 与 $k-3$ 之间没有直接的加减 4 关系（$k-(k-3)=3\neq 4$），因此 $P(k)$ **完全无用**。强归纳假设覆盖了整段 $[12,k]$，$k-3$ 就在其中。**判据很清晰：归纳步骤回退的距离不是 1 时，就该用强归纳。**

第二，为什么恰好是 4 个基础情形。 归纳步骤的适用条件是"回退目标 ≥ 12"，即 $n-4\geq 12\iff n\geq 16$。所以 $n=12,13,14,15$ 无法由归纳步骤得到，必须作为基础情形手工验证（四个都恰好需要）。这也解释了为什么门槛偏偏是 12 而不是别的：**$12,13,14,15$ 这四连整数恰好能被 $4,5$ 表示，而它们的共同点是"$n \bmod 4$ 取遍 $0,1,2,3$"**——见下表。若把门槛降到 11，$n=11$ 只有 $11=4+7$（7 不是 5 的倍数）、$11=8+3$、$11=11$ 这三种拆法，都失败，故 11 不可表示。所以 12 是**最小可行门槛**。

算例验算（$n=12$ 到 20，脚本已核）：

n	全部 $4x+5y$ 表示	用定理 3.6 的算法（反复减 4 到 $[12,15]$）得到的解
12	$4\cdot 3+5\cdot 0$	$4\cdot 3+5\cdot 0$
13	$4\cdot 2+5\cdot 1$	$4\cdot 2+5\cdot 1$
14	$4\cdot 1+5\cdot 2$	$4\cdot 1+5\cdot 2$
15	$4\cdot 0+5\cdot 3$	$4\cdot 0+5\cdot 3$
16	$4\cdot 4+5\cdot 0$	$4\cdot 4+5\cdot 0$（减 4 一次）
17	$4\cdot 3+5\cdot 1$	$4\cdot 3+5\cdot 1$（减 4 一次）
18	$4\cdot 2+5\cdot 2$	$4\cdot 2+5\cdot 2$（减 4 一次）
19	$4\cdot 1+5\cdot 3$	$4\cdot 1+5\cdot 3$（减 4 一次）
20	$4\cdot 5+5\cdot 0$，$4\cdot 0+5\cdot 4$	$4\cdot 5+5\cdot 0$（减 4 两次）

由证明直接得到一个算法与一个上界：定理 3.6 的证明过程本身就是构造性算法——"反复给 n 减 4，直到落在 $\{12,13,14,15\}$，套用对应的基础解，然后每减一次 4 就给 x 加 1"。由于最终落点的 y 值最多是 3（$n=15$ 时 $y=3$），而 x 的累加不影响 y，故**该算法使用的 5 分邮票数永远不会超过 3 张**。脚本对 $n=12$ 到 200 全量验证：最大 $y=3$（出现在 $n=15$），且每个 n 的表示都正确 ✓。

定理 3.7（官方 Note 4 的 Theorem 4.7）：每个自然数 $n>1$ 都可写成**一个或多个质数之积**。

证明策略：用**强归纳法**，归纳变量 n，起始于 $n=2$。归纳步骤需要**分情形**（$k+1$ 是质数 / 不是质数）。为什么必须强归纳？当 $k+1$ 是合数时，它可以写成 $k+1=xy$，其中 x,y 都**远小于** $k+1$（例如 $42=6\times 7$）。我们要用到 $P(6)$ 和 $P(7)$，而 $P(7)$ 根本不是 $P(k)$（这里 $k=41$，$P(41)$ 是"41 是质数"）——简单归纳提供的假设对此毫无帮助。

逐步推导：

记 $P(n)$ 为命题"n 可以写成质数之积"。证明对所有 $n\geq 2$ 成立。

1. **基础情形 $(n=2)$**：2 本身是质数，故它是"一个质数之积"（乘积中只有一项）。$P(2)$ 成立 ✓。（**注意**：这里"一个或多个质数"允许只有一项，正是为了容纳质数本身。）
2. **归纳假设 (IH，强归纳)**：假设 $P(n)$ 对所有 $2\leq n\leq k$ 成立（$k\geq 2$）。
3. **归纳步骤**：证明 $P(k+1)$，即 $k+1$ 可写成质数之积。分两种情形（**穷尽且互斥**：按质数定义，$k+1$ 要么是质数，要么不是）：
4. **情形 1：$k+1$ 是质数**。则 $k+1$ 本身就是"一个质数之积"，取乘积只含一项即可。$P(k+1)$ 成立 ✓。
5. **情形 2：$k+1$ 不是质数**。按合数的定义，存在正整数 x,y 满足

$$k+1=xy,\qquad 1<x,y<k+1.$$

```
由于 $x, y < k+1$ 且都 $> 1$，故 $2 \le x \le k$ 且 $2 \le y \le k$——**两者都落在归纳假设的覆盖范围内**。
由 IH，$x$ 可写成质数之积 $x = q_1 q_2 \cdots q_s$，$y$ 可写成质数之积 $y = r_1 r_2 \cdots r_t$（各 $q_i, r_j$ 都是质数）。
于是
```

$$k+1 = xy = q_1 q_2 \cdots q_s \cdot r_1 r_2 \cdots r_t,$$

```
即 $k+1$ 也是质数之积。$P(k+1)$ 成立 ✓。
```

1. **结论**：由强归纳法原理，每个 $n > 1$ 都可写成质数之积。■

【证明机制解说】：这个证明的机制是"**分情形 + 强归纳**的配合"。分情形把"最坏的情况"隔离出来：情形 1（$k+1$ 质数）是一步收口的平凡情形；情形 2（合数）才是需要归纳假设的地方。而强归纳的必要性在情形 2 暴露无遗——分解出的 x, y 是**任意的小于 $k+1$ 的数**，不是 k。看官方给的例子：$k+1 = 42 = 6 \times 7$，此时我们要用 $P(6)$ 与 $P(7)$，而简单归纳在 $k = 41$ 时只允许假设 $P(41)$ 成立——"41 是质数"这条信息对分解 42 毫无用处。

算例验算（脚本已核）：

n	质数分解	说明
2	2	基础情形，单项
6	2×3	合数，$x=2, y=3$ 都用 IH
7	7	质数，单项
42	$2 \times 3 \times 7$	由 $42 = 6 \times 7$，用 $P(6), P(7)$
97	97	质数，单项
100	$2 \times 2 \times 5 \times 5$	由 $100 = 10 \times 10$，递归到底
1681	41×41	由 $1681 = 41 \times 41$（呼应"$n^2 - n + 41$"反例）

顺带补上 L02 的欠账：定理 3.7 直接蕴含 L02 里被借用的引理"每个大于 1 的自然数要么是质数，要么有质因子"——若 n 是质数则前半成立；若 n 不是质数，定理 3.7 给出 $n = q_1 \cdots q_s$（$s \ge 2$），取 q_1 即为 n 的质因子。**这就是 L02 的 Euclid 证明所依赖的那个引理的正式来源。**

六、强归纳的第三个应用：递归程序正确性（二分查找）

背景：`findWord(W, D)` 在字典 D 中查找单词 W。若 D 只有 1 页，直接暴力查找；否则取出中间页的第一个词 W'：若 W 排在 W' 之前，递归到前半本，否则递归到后半本。（D 有偶数 $2m$ 页时，定义中间页为第 $m+1$ 页，从而两个半本都严格小于原尺寸。）

```
findWord(W, D):
    前置条件: W 是单词, D 是字典的子集且至少有 1 页
    后置条件: 返回 W 的定义, 或返回 "W not found"

    if (D 恰好有 1 页):                    # 基础情形
        在 D 上暴力查找 W
        若找到, 返回其定义; 否则返回 "W not found"

    // 递归情形
    W' = D 的中间页上的第一个单词
    if (W 排在 W' 之前):
        return findWord(W, D 的前半本)
    else:
        return findWord(W, D 的后半本)
```

定理 3.8（官方 Note 4 §4 Example 2）：`findWord()` 是正确的，即若 W 在 D 中，它返回 W 的定义；若 W 不在 D 中，它返回"W not found"。

证明策略：用**强归纳法**，对 D 的页数 n 做归纳。

为什么必须用强归纳？ 因为递归调用的参数不是 $n-1$，而是**两个半本之一的页数**，它可能是 $\lceil n/2 \rceil$ 或 $\lfloor n/2 \rfloor$——远小于 n，且与 $n-1$ 无关。简单归纳的 $P(k)$ 只覆盖 $n = k$，无法为"$n-1$ 页的半本"或更小的半本背书。（脚本验算：1000 页的字典只需 10 次折半就到 1 页，可见递归深度远小于 n——这正是强归纳必需、而简单归纳力所不及的直接体现。）

逐步推导：

1. **基础情形 ($n = 1$)**：若 D 只有 1 页，算法走基础分支，在该页上暴力查找 W。W 若在 D 中则必然在这一页上，被找到并返回定义；若不在，则返回"W not found"。与后置条件完全一致 ✓。
2. **归纳假设 (IH，强归纳)**：假设 `findWord()` 对所有页数 $1 \le n \le k$ 的输入都是正确的。
3. **归纳步骤**：证明页数 $n = k+1$ 时正确。此时 $k+1 \ge 2$，算法不走基础分支，而是算出中间页的第一个词 W'。
4. 因字典按字典序排列，比较 W 与 W' 就能判定 W 可能在哪一半：若 $W < W'$，则 W 只可能在前半本；否则 W 只可能在后半本（**这一步的正确性依赖字典已排序这一前提，属于前置条件**）。
5. 算法在相应的半本上递归调用。按中间页的定义（偶数页取第 $m+1$ 页），两个半本的页数都 $\le \lceil (k+1)/2 \rceil \le k$（对 $k \ge 1$）——**严格小于 $k+1$，故落在归纳假设的覆盖区间 $[1, k]$ 内**。
6. 由 IH，该递归调用返回正确答案（找到定义，或报告未找到）。

7. 算法直接 `return` 该递归调用的返回值，因此 $n = k+1$ 时输出也正确。

8. **结论**：由强归纳法原理，`findWord()` 对所有页数都正确。■

【证明机制解说】：这是归纳法用于**程序正确性证明**的模板，值得记住其结构：

- **基础情形** 对应程序的**递归基 (base case)** / 终止分支。
- **归纳假设** 对应"**递归调用返回正确结果**"这一信任声明——在证明里我们**不需要**展开递归调用的内部执行过程，只需引用 IH。
- **归纳步骤** 对应"**把子问题的正确性组合成原问题的正确性**"，即除了递归调用之外的**所有**代码路径。
- **良序原理** 保证递归**必然终止**（页数严格递减，不可能无限下降），因此"信任递归调用"不是循环论证。

用这个模板去读任何递归算法的正确性证明，结构都是一样的：**找到衡量问题规模的量（这里是页数 n）→ 证明每次递归该量严格减小 → 对基础情形验证 → 用 IH 处理递归调用 → 把返回值组装成答案**。

七、递归与归纳：Fibonacci 数列

定义（Fibonacci 数列）：递归定义为

$$F(0) = 0, \qquad F(1) = 1, \qquad F(n) = F(n-1) + F(n-2) \quad (n \geq 2).$$

直观来源（Fibonacci 的兔子问题，1202 年）：从一对兔子开始，每个月每对成年兔生一对新兔，新生兔从第二个月起具备生育能力。设 $F(n)$ 为第 n 个月的兔子对数。第 n 个月时，能生育的是上个月就已经存在的 $F(n-2)$ 对，它们各生一对新兔，故新增 $F(n-2)$ 对；加上原有的 $F(n-1)$ 对，得 $F(n) = F(n-1) + F(n-2)$。

算例验算（脚本已核）：

n	0	1	2	3	4	5	6	7	8	9	10	11	12	13
$F(n)$	0	1	1	2	3	5	8	13	21	34	55	89	144	233

（比值 $F(13)/F(12) = 1.618056$，逼近黄金比 $\phi = 1.618034$；真实增长率约为 ϕ^n。）

命题（官方练习）：$F(n) \geq 2^{(n-1)/2}$ 对所有 $n \geq 3$ 成立。（这给出指数增长的一个下界。）

为什么需要两个基础情形：归纳步骤要用 $F(k+1) = F(k) + F(k-1)$，同时需要 $P(k)$ 与 $P(k-1)$。取 $k = 3$ 时要 $P(2)$——但 $P(2)$ 不成立（$F(2) = 1 < 2^{1/2} \approx 1.414$）。所以必须从 $n = 3$ 和 $n = 4$ 两个基础情形起步，让归纳步骤覆盖 $k \geq 4$。

证明：

1. **基础情形 $(n = 3)$**：$F(3) = 2 \geq 2^{(3-1)/2} = 2^1 = 2$ ✓。
2. **基础情形 $(n = 4)$**：$F(4) = 3 \geq 2^{(4-1)/2} = 2^{1.5} \approx 2.828$ ✓。
3. **归纳假设**：假设对 k 和 $k-1$（$k \geq 4$）有 $F(k) \geq 2^{(k-1)/2}$ 与 $F(k-1) \geq 2^{(k-2)/2}$。
4. **归纳步骤**：

$$F(k+1) = F(k) + F(k-1) \geq 2^{(k-1)/2} + 2^{(k-2)/2} = 2^{(k-2)/2}\left(2^{1/2} + 1\right) > 2^{(k-2)/2} \cdot 2 = 2^{k/2} = 2^{((k+1)-1)/2}.$$

故 $P(k+1)$ 成立。（关键不等式是 $2^{1/2} + 1 \approx 2.414 > 2$。） 5. **结论**：$F(n) \geq 2^{(n-1)/2}$ 对所有 $n \geq 3$ 成立 ✓。

脚本验算：$n = 3$ 到 15 全部满足（如 $n = 10$：$55 \geq 22.627$ ✓）。中间不等式的数值：$2^{(k-2)/2} + 2^{(k-3)/2} \geq 2^{(k-1)/2}$ 在 $k = 5$ 到 12 上全部成立（例如 $k = 8$：$13.657 \geq 11.314$ ✓）。

递归实现与效率

```
// 版本一：直接照抄递归定义
function F(n):
    if n = 0 then return 0
    if n = 1 then return 1
    else return F(n-1) + F(n-2)

// 版本二：迭代（把尾递归改成循环）
function F2(n):
    if n = 0 then return 0
    if n = 1 then return 1
    a = 1
    b = 0
    for k = 2 to n do:
        temp = a
        a = a + b
        b = temp
    return a
```

版本一的调用次数（脚本已核）：

n	0	1	2	3	4	5	6	7	8	9	10
$F(n)$	0	1	1	2	3	5	8	13	21	34	55

	0	1	2	3	4	5	6	7	8	9	10
调用次数	1	1	3	5	9	15	25	41	67	109	177

可以看到调用次数**超过** $F(n)$（例如 $n=10$ 时 $177>55$），几乎呈指数增长——用归纳可以证明调用次数 $\geq F(n)$。这是"重复子问题被反复重算"的经典例子。**版本二**只需 $n-1$ 次循环迭代，是线性时间：`a, b` 始终保存相邻两个 Fibonacci 数，循环不变式"第 k 轮结束时 $(b,a)=(F(k-1),F(k))$"可用归纳证明，从而 $F_2(n)=F(n)$。

这正是归纳法与编程的分工：递归定义了"是什么"，归纳法证明了"为什么对"。 迭代版本的循环不变式、递归版本的调用次数下界、以及"$F_2=F$"的等价性，全都靠归纳法。

与经典问题的联系

（一）归纳法 → 算法正确性证明（贯穿 L05–L11）

本讲 §六 的 `findWord` 证明给出了"归纳证明递归程序"的完整模板。它在后续讲次中的直接复用：

- **L05 Euclid 算法**：证明 $\gcd(a,b)$ 在递归调用中保持不变（用归纳），并证明算法终止（余数严格递减，b 每次变小，由良序原理终止）。
- **L06 RSA 解密正确性**：证明 $m^{ed}\equiv m \pmod N$，其中要用到"快速幂 (fast exponentiation)"的归纳正确性与 FLT/CRT。
- **L08 Berlekamp–Welch 纠错解码**：证明在错误数 $\leq e$ 时解码唯一，归纳结构出现在"多项式次数与根的个数"的计数中。
- **L11 Gale–Shapley 稳定匹配**：证明算法终止（每轮至少一次求婚不可重复，求婚总数有上界 n^2）与输出稳定（分情形证明没有阻塞对）。

（二）强归纳 → 唯一分解与数论基础（L04–L05）

定理 3.7（质数分解存在性）是**算术基本定理**的一半。有了它，L04 的模运算、L05 的欧几里得算法与费马小定理才能建立在稳固的整数结构之上。请注意它的证明策略值得反复体会：**"存在性"用强归纳（把 n 拆成更小的 a,b），"唯一性"则要靠 Euclid 引理（$p\mid ab\Rightarrow p\mid a$ 或 $p\mid b$，其证明需要 L05 的 Bézout 等式）**。本讲只给出存在性，唯一性要到 L05 才补齐。

（三）鸽笼 + 归纳 → 组合计数与概率（L14–L20）

- **L14 计数**：二项式系数 $\binom{n}{k}$ 的 Pascal 递推 $\binom{n}{k}=\binom{n-1}{k-1}+\binom{n-1}{k}$ 正是"归纳式"的，二项式定理的证明就是一次归纳。
- **L20 期望线性性**：$\mathbb{E}[\sum X_i]=\sum\mathbb{E}[X_i]$ 对任意有限个随机变量成立，标准证法是对变量个数 n 做归纳。
- **L20 哈希与负载均衡**：与 L02 的鸽笼原理衔接——鸽笼给出"冲突必然存在"的确定性结论，而负载均衡分析给出"每个桶的期望负载 $=n/k$"的概率刻画。

（四）强化归纳假设 → 一般化的数学研究技能

"先算小规模、发现结构、证明强化命题"这个工作流在后面反复出现： – **L23 集中不等式**：切尔诺夫界 (Chernoff bound) 的推导先证一个带有可调参数 t 的**更强**界（moment generating function 版本），再优化 t 得到最终形式——这就是"强化以获得自由度"的典型。 – **L26 马尔可夫链**：稳态分布的存在性证明中，常常需要把"收敛"强化为"带速率的收敛"（几何收敛），否则归纳步骤无法推进。

与其他讲次的关联

- **与 L00–L02（证明工具箱）**：归纳法把前四讲的所有技巧**全部打包进归纳步骤**。本讲定理 3.2 的归纳步骤是一次**代数直接证明**；定理 3.3（两色定理）的归纳步骤是一次**分情形证明**（情形 1/情形 2）；定理 3.7 的归纳步骤也是分情形；而"归纳法合法性"的论证（良序原理那段）本身是一次**反证法**。**所以归纳法不是第五种孤立技巧，而是"用一个有限证明封装无穷多个证明"的元技巧。**
- **与 L01（命题逻辑）**：归纳法依赖 L01 的全称量词 $\forall$ 与蕴含 $\Rightarrow$ 的精确语义。"$P(k)\Rightarrow P(k+1)$ 对任意 k" 中的"任意"必须理解为全称量词，否则就会出现"漏掉 $k=1$"这类漏洞（见下节"所有马同色"的分析）。此外，定理 3.7 归纳步骤的两种情形互斥穷尽，其合法性来自 $P\vee\neg P$（排中律）。
- **与 L02（逆否/反证/分情形）**：良序原理证明归纳法合法性的那段论证，本质上是**反证法 + 取最小反例**。而 L02 借用的引理"每个 $n>1$ 要么是质数要么有质因子"，在本讲定理 3.7 处被正式证明并偿还——**注意这个依赖方向：L02 的定理 2.4（质数无穷多）在逻辑上依赖 L03 的定理 3.7**。这在课程安排上是完全正常的，但你自己写证明时要清楚"我引用了哪个还没证的结果"。
- **与 L04（模运算）**：定理 3.2 的"$3\mid n^3-n$"在 L04 会被重述为 $n^3\equiv n \pmod 3$，并能用费马小定理（L05）的 $n^p\equiv n \pmod p$ 一步得到（取 $p=3$）。**同一命题在更高层的工具下会变得平凡**——这是学习数学的一条重要经验。
- **与 L09–L10（图论、树与平面图）**：树的性质 $|E|=|V|-1$、握手引理 $\sum_v \deg(v)=2|E|$、平面图的欧拉公式 $V-E+F=2$ 全部用归纳法证明，且都是"删一个顶点/边然后修补"的模式——与本讲定理 3.3 的两色定理证明**机制完全相同**。
- **与 L12–L13（可数性、可计算性）**：L12 中"每个自然数都能被某个图灵机编码"的论证、L13 中"程序与输入配对枚举"的构造，都依赖自然数的良序性与编码的归纳性质。

关键要点

1. **归纳法三件套 + 多米诺模板**：

```
 P(0)                P(k) => P(k+1)                结论: 全部倒下
  |                        |                          |
  v                        v                          v
+---+  +---+  +---+  +---+  +---+  +---+         推倒第0张 (基础情形)
| P0|  | P1|  | P2|  | P3|  |...|  | Pn|         牌距够近 (归纳步骤)
+---+  +---+  +---+  +---+  +---+  +---+
  ^      ^      ^      ^
  |      |      |      |
 推倒    被撞倒 被撞倒 被撞倒  ......  连锁反应覆盖所有 n

必须同时具备:
(A) 基础情形: P(0) 成立            —— 否则一张都不倒
(B) 归纳步骤: forall k, P(k)=>P(k+1) —— 否则链条断在 k 处
(C) 良序原理: 保证不存在"反例集合的最小元" —— 合法性的终极依据
```

1. **证明骨架模板（照这个格式写，阅卷不会扣分）**：

```
定理: forall n >= n0, P(n).
证明: 我们对 n 做 [简单/强] 归纳.
  Base Case (n = n0):  [逐一验证 P(n0) 成立, 写出两边相等]
                       [若需多个基础情形, 全部列出: n0, n0+1, ...]
  Induction Hypothesis: 假设对任意 k >= n0, P(k) 成立.
                       [强归纳: 假设 P(n0),...,P(k) 全部成立.]
  Inductive Step: 证明 P(k+1).
                       [关键动作: 把 P(k+1) 的目标式拆成
                        "IH 能处理的部分" + "剩下的部分"]
                       [注明在哪一步用了 IH]
                       [若回退距离 != 1, 改用强归纳; 若需拆分情况, 显式声明
                        "以下情形穷尽且互斥"]
                       [收口: 得出 P(k+1) 成立]
  Conclusion: 由 [强] 归纳法原理, forall n >= n0, P(n).  QED
```

1. **基础情形不是形式主义**。漏掉基础情形会证出"所有马颜色相同"这样的荒谬结论；而基础情形的**个数**由归纳步骤的**适用门槛**决定（定理 3.6 需要四个，Fibonacci 下界需要两个）。
2. **归纳步骤回退距离 $\neq 1$ 时必须用强归纳**。判据：如果你在归纳步骤里要用 $P(k-3)$、$P(x)$（x 远小于 k）、或两个半本的 P，就换成"假设 $P(n_0), \ldots, P(k)$ 全部成立"。强归纳与简单归纳**证明能力等价**，只是**更好用**。
3. **归纳假设太弱时，去证一个更强的命题**。信号是"归纳步骤卡住、缺少关于 k 的精确信息"。强化前先**手算 $n = 1, 2, 3, 4, 5$ 的值，观察结构**（范例 A 由 $1, 4, 9, 16, 25$ 认出 n^2；范例 B 由部分和远小于 2 想到带 $1/n$ 的余量）。
4. **归纳法 = 递归的数学影子**。递归定义靠良序原理保证良定义；递归程序的正确性证明结构是"基础情形 ↔ 递归基、IH ↔ 信任递归调用、归纳步骤 ↔ 组装返回值"。**归纳法就是"分治 (divide and conquer)"正确性的语言**。

常见误区与注意事项

误区 1（本讲头号陷阱）："所有马颜色相同"——归纳步骤在 $n = 1$ 处失效

这是 Pólya 流传下来的经典伪证，也是 CS70 最著名的归纳法陷阱。

> **Theorem（伪）**：所有的马都是同一种颜色。 **"证明"**：对马的数量 n 做归纳。记 $P(n)$ 为"任意 n 匹马都是同一种颜色"。 **基础情形 $(n = 1)$**：一匹马显然是同一种颜色 ✓。 **归纳假设**：假设 $P(n)$ 对某个 $n \geq 1$ 成立。 **归纳步骤**：考虑 $n+1$ 匹马 $\{h_1, h_2, \ldots, h_{n+1}\}$。把最后一匹排除，对前 n 匹 $\{h_1, \ldots, h_n\}$ 用归纳假设，得出它们同色。同理，对后 n 匹 $\{h_2, \ldots, h_{n+1}\}$ 用归纳假设，得出它们也同色。这两组的"中间马"$\{h_2, \ldots, h_n\}$ 属于两个集合的**交集**，因此它们既与 h_1 同色、又与 h_{n+1} 同色，故全部 $n+1$ 匹马同色。由归纳法原理，所有马同色。♠

错在哪：归纳步骤声称证明的是 $\forall n \geq 1,\ P(n) \Rightarrow P(n+1)$。但**这个蕴含式对 $n = 1$ 是假的**。

仔细看 $n = 1$ 时的情形：要证 $P(2)$，即两匹马 $\{h_1, h_2\}$ 同色。按"证明"的做法： – 前 $n = 1$ 匹是 $\{h_1\}$ —— 由 $P(1)$ 得出"$\{h_1\}$ 中所有马同色"✓（这句话是**空洞真 (vacuously true)** 的，一匹马当然与自己同色）。 – 后 $n = 1$ 匹是 $\{h_2\}$ —— 由 $P(1)$ 得出"$\{h_2\}$ 中所有马同色"✓（同样空洞）。 – 关键一步：**"中间马" $\{h_2, \ldots, h_n\} = \{h_2, \ldots, h_1\} = \varnothing$，交集是空的！**

空交集里没有任何一匹马，所以**无法把 h_1 的颜色传递给 h_2**。整个论证依赖"存在一匹同时属于两个集合的马"作为颜色传递的桥梁，而 $n = 1$ 时这座桥不存在。

脚本验算交集大小：$\{h_1, \ldots, h_n\} \cap \{h_2, \ldots, h_{n+1}\} = \{h_2, \ldots, h_n\}$，元素个数为 $\max(0, n-1)$。

n	交集大小	传递是否可行
1	0	**否——桥梁缺失，$P(1) \Rightarrow P(2)$ 为假**
2	1	可以（$\{h_2\}$ 作桥）
3	2	可以
n	$n-1 \geq 1$	可以

所以正确的诊断是：基础情形 $P(1)$ 是真的，$n \geq 2$ 时的归纳步骤也是真的，唯独 $P(1) \Rightarrow P(2)$ 这一步是假的。 归纳链条从第 1 格到第 2 格就断了，所以 $P(2)$ 从未被建立，$P(3)$ 起全部落空。

从这个陷阱学到的三条教训：

1. **归纳步骤必须对"每一个" k 成立**。写成 $\forall k \geq 1,\ P(k) \Rightarrow P(k+1)$——只要有一个 k 失效，整个链条就断。检查时要把**最小的那个 k** 单独拿出来想清楚。
2. **"空洞真"是小规模情形的常见伪装**。$P(1)$ 的成立毫不费力（一匹马自比），恰恰因为它是空的，它不携带任何可用于 $n = 2$ 的信息。
3. **修补方案**：如果归纳步骤对 $n \geq 2$ 才有效，必须把基础情形补到 $n = 2$（即手工验证"两匹马同色"）——但这一步显然做不到（两匹马可以颜色不同），所以**正确的结论是这个定理本身为假，而不是证明写法需要修补**。这个区分很重要：有些时候是证明错了，有些时候是命题错了。

误区 2：只证归纳步骤，不证基础情形

漏掉基础情形的后果不是"证明不完整"，而是**归纳链条根本没有起点**。用"所有马同色"的例子做思想实验：即使归纳步骤完全正确，若从 $n = 1$ 起就不验证，$P(1)$ 无从建立，$P(2), P(3), \ldots$ 全部无法推出。**用多米诺的话说：牌距排得再完美，没有第一推，一张都不会倒。**考试里漏写基础情形是标准的扣分点。

误区 3：把归纳假设当成已证事实，或反过来"重复证明"

- 错误写法："归纳假设：对任意 k，$P(k)$ 成立。" —— 这是**把要证的东西直接假设了**（循环论证）。正确写法必须强调 k 是**任意的但固定的一个值**："假设对某个任意的 $k \geq 0$，$P(k)$ 成立。"
- 另一种错误：在归纳步骤里重新从头证明 $P(k)$。归纳假设是**给定**的，不需要证明，只需要**使用**。

误区 4：该用强归纳时用了简单归纳

定理 3.6 若用简单归纳：归纳假设只有 $P(k)$，要说"$k+1 = k-3+4$"，可 $P(k)$ 说的是 k 能被表示，与 $k-3$ 无关，论证完全断掉。定理 3.7 若用简单归纳：$42 = 6 \times 7$ 需要 $P(6)$ 与 $P(7)$，而 $k = 41$ 时简单归纳只给 $P(41)$（"41 是质数"），毫无帮助。`findWord` 若用简单归纳：递归调用的参数是两个半本的页数（可能远小于 k），$P(k)$ 覆盖不到。

判据（重复一遍）：归纳步骤需要的回退目标不是 k 本身时，就必须用强归纳。

误区 5：基础情形的个数想当然

三种典型误判： – **该多反而少**：定理 3.6 需要 4 个基础情形（$12, 13, 14, 15$），因为归纳步骤只在 $n \geq 16$ 时可用。Fibonacci 下界需要 2 个（$n = 3, 4$），因为归纳步骤要用 $P(k)$ 与 $P(k-1)$ 两条假设，起点必须给足两条。 – **该少反而多**：写了不必要的基础情形不算错，但会浪费时间、且可能掩盖"归纳步骤其实覆盖了它"这个事实。 – **判据：看归纳步骤的适用门槛**。归纳步骤要求"回退目标 $\geq$ 某阈值"时，阈值到第一次能用归纳步骤的那个数之间**全部**都要手工验证。

误区 6：归纳变量选错

"对 n 做归纳"里的 n 必须是**命题中那个会变化的、且所有量都能向它归约的参数**。例如证明"n 条直线把平面分成 $n(n+1)/2 + 1$ 个区域"时，归纳变量应是**直线数**，不是区域数、也不是交点数。选错变量的典型症状是：归纳步骤里发现"$k+1$ 的情形"与"k 的情形"之间找不到构造性联系。

误区 7：把"验证前几项"当成证明

本讲的 $n^2 - n + 41$ 是最有力的警告：它连续 41 个值（$n = 0$ 到 40）都是质数，$n = 41$ 时崩溃。**任何有限次验证都不能排除无穷多个情形中的反例。** 归纳法之所以必要，就是它用一个有限论证（两步）覆盖了无穷多情形。反过来说——**如果你只打算验证有限个 n，那就不叫证明，叫测试**（这也正是 L13 停机问题、L12 可数性所强调的"有限手段 vs 无穷对象"主题的雏形）。

误区 8：在归纳步骤中悄悄改变了命题

强化归纳假设是合法且常用的技巧（本讲定理 3.4、3.5），但必须做到两点：(i) **明确写出强化后的命题 $P'(n)$**，并说明 $P'(n) \Rightarrow P(n)$；(ii) **基础情形与归纳步骤都是针对 P' 的**。常见错误是"归纳假设用了强化版，结论却写回原版"，导致归纳步骤证的不是同一个命题——这在逻辑上等同于把归纳链条中途换掉了。

思考题（带答案）

Q1.（纯计算） 用归纳法验证下列数值事实，并写出对应的公式。

(a) 计算 $1^2 + 2^2 + \cdots + n^2$ 在 $n = 1, 2, 3, 4, 5$ 的值，验证公式 $\frac{1}{6}n(n+1)(2n+1)$。 (b) 计算 $F(10)$ 与递归版本 `F(10)` 的调用次数，验证"调用次数 $\geq F(n)$"。 (c) 验证 $n = 12$ 到 20 每一个都能写成 $4x + 5y$，并给出每种表示。

▸ **答案**

(a) 脚本验算：

n	平方和（直接累加）	$\frac{1}{6}n(n+1)(2n+1)$
1	1	$\frac{1}{6}\cdot 1\cdot 2\cdot 3 = 1$
2	$1+4=5$	$\frac{1}{6}\cdot 2\cdot 3\cdot 5 = 5$
3	$5+9=14$	$\frac{1}{6}\cdot 3\cdot 4\cdot 7 = 14$
4	$14+16=30$	$\frac{1}{6}\cdot 4\cdot 5\cdot 9 = 30$
5	$30+25=55$	$\frac{1}{6}\cdot 5\cdot 6\cdot 11 = 55$

全部一致 ✓。归纳步骤的关键动作是拆出最后一项：
$\frac{1}{6}k(k+1)(2k+1)+(k+1)^2 = \frac{1}{6}(k+1)\left[k(2k+1)+6(k+1)\right] = \frac{1}{6}(k+1)(2k^2+7k+6) = \frac{1}{6}(k+1)(k+2)(2k+3)$，正是 $n=k+1$ 的公式。

(b) $F(10)=55$；递归版本 `F(10)` 的调用次数为 177。$177 \geq 55$ ✓。（完整表格见正文 §七：调用次数为 $1,1,3,5,9,15,25,41,67,109,177$，$n$ 从 0 到 10。）

(c) 见下表（脚本验算，全部正确）：

n	表示
12	$4\cdot 3+5\cdot 0$
13	$4\cdot 2+5\cdot 1$
14	$4\cdot 1+5\cdot 2$
15	$4\cdot 0+5\cdot 3$
16	$4\cdot 4+5\cdot 0$
17	$4\cdot 3+5\cdot 1$
18	$4\cdot 2+5\cdot 2$
19	$4\cdot 1+5\cdot 3$
20	$4\cdot 5+5\cdot 0$（也可 $4\cdot 0+5\cdot 4$）

Q2.（概念理解） 判断下列说法是否正确，并说明理由。

(a) 强归纳法能证明一些简单归纳法**无法**证明的命题。(b) 定理 3.6（$n \geq 12$ 可写成 $4x+5y$）可以用简单归纳法证明，只要把基础情形从 1 个改成 4 个。(c) 在"所有马同色"的伪证中，错误出在基础情形 $P(1)$ 上。(d) 用归纳法证明 $\forall n \geq 1$：前 n 个奇数之和是完全平方数时，"强化归纳假设"意味着我们证明了一个更强的命题，所以这个证明比原命题难。

▸ **答案**

(a) 错误。 强归纳与简单归纳在**证明能力上完全等价**——强归纳能证的简单归纳也能证，反之亦然。形式上，令 $Q(n) := P(0) \wedge P(1) \wedge \cdots \wedge P(n)$，则"对 P 的强归纳"就等价于"对 Q 的简单归纳"。直观上，简单归纳的链条如果成立，第 0 张牌会依次撞倒 1 到 k 张，所以处理第 $k+1$ 张时前面所有牌都倒了——这正是强归纳假设。强归纳的优势是**更好用**（假设更强，证明更省力），不是**更强**。

(b) 错误。 改成 4 个基础情形**不足以**救活简单归纳。定理 3.6 的归纳步骤要从 $n=k+1$ 回退到 $k-3$，而简单归纳的假设只有 $P(k)$——它讲的是 k 可表示，与 $k-3$ 之间没有"减 4"的关系，用不上。**要解决的是归纳假设太弱，而非基础情形太少。**（顺带说：多补基础情形在一般情况下也没用，因为归纳步骤本身对 $n \geq 16$ 依然是断的。正确做法是改用强归纳。）

(c) 错误。 $P(1)$ 是**真的**（一匹马当然与自己同色，这是空洞真）。真正出错的是归纳步骤在 $n=1$ 处：从 $\{h_1,\ldots,h_n\}$ 与 $\{h_2,\ldots,h_{n+1}\}$ 的**交集** $\{h_2,\ldots,h_n\}$ 传递颜色，而 $n=1$ 时该交集为**空集**（脚本验算：交集大小 $=\max(0,n-1)=0$），没有"中间马"充当桥梁，因此 $P(1) \Rightarrow P(2)$ **为假**。归纳链条在第 1 格到第 2 格之间断裂。

(d) 错误（结论对但理由不对）。 强化归纳假设确实意味着证明一个更强的命题，但这**不代表更难**——恰恰相反，强化的目的是让**归纳假设携带更多信息**，从而使归纳步骤**更容易**完成。范例：目标"是完全平方数"时，归纳假设只说"是某个 m^2"，m 与 k 无关，无法推出 m^2+2k+1 是平方数；强化为"恰好等于 k^2"后，$k^2+(2k+1)=(k+1)^2$ 一步到位。**"证更强的命题反而更容易"是归纳法的核心反直觉之处**，其代价仅仅是你必须确认强命题确实蕴含原命题。

Q3.（证明能力） 用**强归纳法**证明：每个大于 1 的自然数要么是质数，要么有质因子。

（提示：这是 L02 的 Euclid 证明所借用的引理，请把它的正式证明补上，并指出它与定理 3.7 的关系。）

▸ **答案**

记 $P(n)$ 为命题"n 要么是质数，要么有质因子"。证明对所有 $n \geq 2$ 成立。

证明：用强归纳法对 n 做归纳。

基础情形 ($n = 2$)：2 是质数，故 $P(2)$ 成立 ✓。

归纳假设 (IH)：假设 $P(n)$ 对所有 $2 \leq n \leq k$ 成立（$k \geq 2$）。

归纳步骤：证明 $P(k+1)$。分两种情形（穷尽且互斥：$k+1$ 要么是质数，要么不是）：

- **情形 1：$k+1$ 是质数**。则 $P(k+1)$ 由"是质数"这一半直接成立 ✓。
- **情形 2：$k+1$ 不是质数**。由质数定义的否定，$k+1$ 有除 1 和自身之外的因子，即存在正整数 a 满足 $1 < a < k+1$ 且 $a \mid (k+1)$。也就是说存在 b 使 $k+1 = ab$，其中 $1 < a < k+1$。于是 $2 \leq a \leq k$，落在 IH 的覆盖区间内。由 IH 应用于 a，有两种子情形：
- 若 a 是质数，则 a 本身就是 $k+1$ 的一个质因子，$P(k+1)$ 成立 ✓。
- 若 a 不是质数，则由 IH，a 有质因子 p。因为 $p \mid a$ 且 $a \mid (k+1)$，由整除的传递性（L00）得 $p \mid (k+1)$，故 p 是 $k+1$ 的质因子，$P(k+1)$ 成立 ✓。

结论：由强归纳法原理，每个 $n > 1$ 要么是质数，要么有质因子。■

与定理 3.7 的关系：本引理是定理 3.7（"每个 $n > 1$ 可写成质数之积"）的**直接推论，也是它的弱化版**。事实上定理 3.7 更强——它不仅断言"有质因子"，还断言可以把 n 完整分解为质数之积。反过来，从定理 3.7 出发证本引理只需一句话：若 n 不是质数，定理 3.7 给出 $n = q_1 q_2 \cdots q_s$（$s \geq 2$），取 q_1 即为质因子。

关于证明顺序的说明：L02 的 Theorem 2.4（质数有无穷多个）在证明中引用了这条引理，而本讲（L03）才正式证明它。**这在数学写作中完全合法**（可以引用"将在后续证明的结果"），但你自己写证明时应当意识到这个依赖方向，避免出现真正的循环依赖。

注：本引理的证明还可以更直接——不用分情形，只对 a 用 IH 即可（若 a 质数取自身，否则取 a 的质因子）。之所以写出两种子情形，是为了展示"分情形 + 强归纳"的完整配合格式，这在定理 3.7 的证明中同样出现。

Lecture 4: Modular Arithmetic（模运算）

概述

本讲引入整门 CS70 后半段离散数学模块的「通用语言」：**模运算 (modular arithmetic)**。核心问题是：当我们需要把数字限制在一个固定的小范围 $\{0, 1, \ldots, m-1\}$ 内做运算（密码学要控制密钥长度、纠错码要限制符号表大小）时，加、减、乘这些运算还能不能正常进行？本讲证明**可以**（定理 5.1），并指出**除法不行**——除非引入乘法逆元。本讲的证明技巧以**直接证明**与**反证法（鸽笼/双射论证）**为主，它为下一讲的欧几里得算法、费马小定理与中国剩余定理铺好语言，最终通向 Lecture 6 的 RSA。

核心概念的直观解释

同余（Congruence）

- **定义**：设 m 为正整数。对任意两个整数 a, b，称 a 与 b **模 m 同余** (congruent modulo m)，记作

$$a \equiv b \pmod{m} \iff m \mid (a - b),$$

即 $a - b$ 是 m 的整数倍。注意这里的 $\equiv$ 是一个**二元关系**，不是等式；它的两边可以相差任意多个 m。

- **直观解释（"它是什么意思？"）**：同余在说「**只看余数，不管倍数**」。a 与 b 同余，意思是它们除以 m 后落在同一个「格子」里。一个等价的、更贴近计算的写法是

$$a \equiv b \pmod{m} \iff a \bmod m = b \bmod m.$$

（右式的「$a \bmod m$」是指 a 除以 m 的**最小非负余数**，取值落在 $\{0, 1, \ldots, m-1\}$。）

- **具体示例**：$29 \equiv 5 \pmod{12}$，因为 $12 \mid (29 - 5) = 24$；同时 $29 \bmod 12 = 5 = 5 \bmod 12$。又如 $13 \equiv 3 \pmod{5}$（$13 - 3 = 10$ 是 5 的倍数）。同余还允许右侧是负数：$22 \equiv -2 \pmod{12}$，因为 $22 - (-2) = 24$ 是 12 的倍数。这三种写法 $29 \equiv 5$、$29 \equiv 17$、$29 \equiv -7 \pmod{12}$ 描述的是**同一件事**。

时钟算术（Clock Arithmetic）

- **定义**：把整数集合按模 m 折叠成一个「表盘」，表盘上有 m 个刻度 $0, 1, \ldots, m-1$；超出刻度范围的数就「绕回去」。$m = 12$ 就是钟表，$m = 7$ 就是星期。
- **直观解释**：如果你在下午 1 点问「13 小时后是几点」，你会答「凌晨 2 点」而不是「14 点」——因为你自动做了 $1 + 13 = 14 \equiv 2 \pmod{12}$。同理从下午 2 点起，任意**整数倍**的 12 小时之后都还是下午 2 点（$2 + 24 \equiv 2$）；而 25 小时之后是 3 点，因为「24 小时回到原地」之后只多走了 $25 \bmod 12 = 1$ 小时。
- **具体示例**：$m = 7$ 时，如果今天是周二（记作 2），那么 100 天后是周几？$100 = 7 \times 14 + 2$，所以 $100 \equiv 2 \pmod{7}$，$2 + 2 = 4$，即**周四**。这个「绕圈」的图景就是模运算之所以能压缩数值范围的全部理由。

```
            模 12 的「时钟」：加法就是沿圆周走步数

                    0 (12)
                11          1
              10              2
              9                3
               8              4
                  7          5
                       6

  从 2 出发走 25 步：  25 mod 12 = 1，等价于只走 1 步 --> 落到 3
  从 2 出发走 24 步：  24 mod 12 = 0，等价于不动    --> 仍是 2

            模 7 的「星期盘」：0=周日, 1=周一, ..., 6=周六
                    0
                6       1
              5           2
                4       3
   从 2（周二）走 100 步：100 mod 7 = 2 --> 走到 4（周四）
```

剩余类（Residue Classes）与 $\mathbb{Z}_m$

- **定义**：对固定的 m，把全体整数按「与 i 同余」分组，得到

$$[i]_m = \{z \in \mathbb{Z} : z = qm + i \text{ 对某个整数 } q\}, \qquad i = 0, 1, \ldots, m-1.$$

这 m 个集合称为**模 m 的剩余类 (residue classes modulo m)**，它们的全体记作 $\mathbb{Z}_m$（也常写作 $\mathbb{Z}/m\mathbb{Z}$）。

- **直观解释（"它是什么意思？"）**：$\mathbb{Z}_m$ 就是把整条数轴「卷成一圈」后得到的 m 个点。每个类都用其中唯一的、落在 $\{0, \ldots, m-1\}$ 里的元素作**标准代表元 (canonical representative)**。于是「在模 m 下计算」就等于「只在代表元上计算」。
- **具体示例**：$m = 12$ 时，与 0 同余的类是 $\{\ldots, -36, -24, -12, 0, 12, 24, 36, \ldots\}$（所有 12 的倍数）；与 1 同余的类是 $\{\ldots, -35, -23, -11, 1, 13, 25, 37, \ldots\}$；与 2 同余的类是 $\{\ldots, -34, -22, -10, 2, 14, 26, 38, \ldots\}$。**恰好有 12 个这样的类，而且每个整数属于且只属于其中一个**——这就是后面「m 个类构成一个划分」的含义。

用 $m = 5$ 看得更清楚：

```
  数轴上的整数被模 5 折成 5 个「抽屉」：

  ... -10 -9  -8  -7  -6  -5  -4  -3  -2  -1   0   1   2   3   4   5   6   7 ...
        |   |   |   |   |   |   |   |   |   |   |   |   |   |   |   |   |   |
        v   v   v   v   v   v   v   v   v   v   v   v   v   v   v   v   v   v
  [0]  -10  -5   0   5  ...       (5 的倍数)
  [1]   -9  -4   1   6  ...
  [2]   -8  -3   2   7  ...
  [3]   -7  -2   3  ...
  [4]   -6  -1   4  ...

  每一个整数恰好落在一个抽屉里；5 个抽屉互不相交，并起来是全部 Z。
```

等价关系（Equivalence Relation）

- **定义**：集合 S 上的二元关系 $\sim$ 若满足以下三条，则称其为**等价关系 (equivalence relation)**：
- **自反性 (reflexivity)**：$\forall a \in S,\ a \sim a$；
- **对称性 (symmetry)**：$\forall a, b \in S,\ a \sim b \Rightarrow b \sim a$；
- **传递性 (transitivity)**：$\forall a, b, c \in S,\ a \sim b \ \wedge\ b \sim c \Rightarrow a \sim c$。
- **直观解释**：「等价关系」就是「某种意义下相同」。它把集合切成互不相交的**等价类 (equivalence classes)**，而每个元素恰好属于一个类。同余正是这样一个关系——这正是 $\mathbb{Z}_m$ 能成为「m 个抽屉」的根本原因。
- **具体示例**：模 4 下，$7 \sim 7$（自反）；$7 \sim 3 \Rightarrow 3 \sim 7$（对称，因为 $4 \mid (7-3)$ 与 $4 \mid (3-7)$ 等价）；$7 \sim 3$ 且 $3 \sim 11 \Rightarrow 7 \sim 11$（传递，$11 - 7 = 4$）。三个性质都在下面的定理 4.0 中被证明。

快速幂 / 反复平方（Exponentiation by Repeated Squaring）

- **定义**：计算 $x^y \bmod m$（y 可能是上千比特的大整数）。**朴素做法**是连乘 y 次；**反复平方**做法利用 y 的二进制展开，把 y 不断除以 2，递归深度只有 y 的比特数 $n = \lceil \log_2(y+1) \rceil$。
- **直观解释**：连乘 y 次的代价随 y 的大小**指数增长**，而反复平方的代价随 y 的**位数**线性增长。y 有 1000 比特（约 10^{301}）时，前者需要 10^{301} 次乘法——宇宙热寂也算不完；后者只需约 1000 次。这是 RSA 能在口袋里跑起来的第二个技术前提（第一个是下一讲的扩展欧几里得）。
- **具体示例**：算 $3^{11} \bmod 7$。$11 = 8 + 2 + 1 = (1011)_2$。只需先算出 $3^1, 3^2, 3^4, 3^8$（每一步把上一步的结果平方），再挑出 11 的二进制里为 1 的位相乘：$3^{11} = 3^8 \cdot 3^2 \cdot 3^1 \equiv 2 \cdot 2 \cdot 3 = 12 \equiv 5 \pmod 7$。

乘法逆元（Multiplicative Inverse）

- **定义**：设 $\gcd(x, m) = 1$。若整数 y 满足

$$x \cdot y \equiv 1 \pmod{m},$$

则称 y 为 x 模 m 的乘法逆元 (multiplicative inverse modulo m)，记作 $x^{-1} \bmod m$。若不存在这样的 y，则说 x 模 m 不可逆。 – **直观解释**：在实数里「除以 x」等于「乘以 $1/x$」；这里 $1/x$ 的角色由 x^{-1} 扮演。逆元一旦存在就是**唯一**的（模 m），所以「除以 x」在模 m 下有了确定的意义。**但逆元不一定存在**——这是模运算与中学算术最剧烈的分歧点。 – **具体示例**：$x=8,\ m=15$：$2\cdot 8=16\equiv 1 \pmod{15}$，所以 $8^{-1}\equiv 2$。反过来 $x=12,\ m=15$：把 $12a \bmod 15$ 依次列出得到周期序列 $12,9,6,3,0,12,9,6,\ldots$，**数字 1 永远不出现**，所以 12 模 15 没有逆元。注意这句话的两层「怪事」：一是**非零数也可能没有逆元**（实数里只有 0 没有逆元）；二是**非零数的乘法表中出现了 0**（$12\cdot 5=60\equiv 0 \pmod{15}$，而实数里任何非零数的乘法表都不含 0）。

完整证明与推导（核心）

定理 4.0（同余是等价关系）：对任意正整数 m，关系 $a\equiv b \pmod{m}$ 是 $\mathbb{Z}$ 上的等价关系。

证明策略：直接证明。三条性质都只需把定义 $m \mid (a-b)$ 翻译成「存在整数 k 使 $a-b=km$」，然后对 k 做代数操作——这正是 Lecture 0 里「整除性证明」的标准套路。

逐步推导：

1. **自反性**：取任意 $a\in\mathbb{Z}$。$a-a=0=0\cdot m$，故 $m\mid(a-a)$，即 $a\equiv a \pmod{m}$。（依据：整除的定义，0 是 m 的 0 倍。）
2. **对称性**：设 $a\equiv b \pmod{m}$，即存在整数 k 使 $a-b=km$。两边取负得 $b-a=(-k)m$，而 $-k$ 仍是整数，故 $m\mid(b-a)$，即 $b\equiv a \pmod{m}$。
3. **传递性**：设 $a\equiv b$ 且 $b\equiv c \pmod{m}$，即存在整数 k_1,k_2 使 $a-b=k_1m$、$b-c=k_2m$。两式相加：

$$a-c=(a-b)+(b-c)=k_1m+k_2m=(k_1+k_2)m.$$

由于 $k_1+k_2\in\mathbb{Z}$，得 $m\mid(a-c)$，即 $a\equiv c \pmod{m}$。■

【证明机制解说】：这三条性质之所以成立，是因为「$m\mid(a-b)$」把问题**降维**成了「$a-b$ 属于集合 $m\mathbb{Z}$」——而 $m\mathbb{Z}=\{km : k\in\mathbb{Z}\}$ 这个集合对取负、求和都封闭（它是 $\mathbb{Z}$ 的一个**子群**）。更一般地：**任何把一个群映射到子群上的「同态」都给出等价关系**。传递性是三者中唯一的「合成」步骤，也是后面一切运算律的真正来源。

定理 5.1（同余与加乘相容 / 运算的良定义性）：若 $a\equiv c \pmod{m}$ 且 $b\equiv d \pmod{m}$，则

$$a+b\equiv c+d \pmod{m}, \qquad a\cdot b\equiv c\cdot d \pmod{m}.$$

证明策略：直接证明（对两部分各做一次）。关键是把四条同余关系全部翻译成**不带模号的整数等式**：$c=a+km$、$d=b+\ell m$，然后算出 $c+d$ 与 cd，观察它们与 $a+b$、ab 的差是否恰为 m 的倍数。**官方 Note 5 只写了加法部分并把乘法留作习题，这里把两部分都补全。**

逐步推导（加法部分）：

1. 由假设 $a\equiv c \pmod{m}$，按定义存在整数 k 使 $c=a+km$。
2. 由假设 $b\equiv d \pmod{m}$，存在整数 ℓ 使 $d=b+\ell m$。
3. 相加：$c+d=(a+km)+(b+\ell m)$。（依据：代入步骤 1、2 的表达式。）
4. 整理：$c+d=a+b+(k+\ell)m$。（依据：整数加法的交换律与结合律。）
5. 移项：$(c+d)-(a+b)=(k+\ell)m$，而 $k+\ell$ 是整数。
6. 由整除定义 $m\mid\big[(c+d)-(a+b)\big]$，按同余定义即为 $a+b\equiv c+d \pmod{m}$。□

逐步推导（乘法部分）：

1. 同前，$c=a+km$、$d=b+\ell m$。
2. 相乘：$cd=(a+km)(b+\ell m)$。（依据：代入。）
3. 展开：$cd=ab+a\ell m+bkm+k\ell m^2$。（依据：分配律。）
4. 提取公因子 m：$cd=ab+m\,(a\ell+bk+k\ell m)$。（依据：因式分解。）
5. 括号里的 $a\ell+bk+k\ell m$ 是整数（整数对加减乘封闭）。
6. 故 $m\mid(cd-ab)$，即 $a\cdot b\equiv c\cdot d \pmod{m}$。■

【证明机制解说】：这个证明的核心只有一句话——**「同余差 m 的倍数」这件事在加法与乘法下会自我繁殖**。加法时倍数线性相加；乘法时倍数乘上别的整数，仍然是 m 的倍数。注意第 3 步展开后出现的 m^2 项也带着 m，这不是巧合：它说明 $m\mathbb{Z}$ 不仅是加法子群，还是环 $\mathbb{Z}$ 的**理想 (ideal)**。这个性质正是「模运算可以做任意多次加、减、乘」这一事实的代数根基。

关于「良定义性 (well-definedness)」的重要说明：

定理 5.1 的真正意义不是「两个同余式可以相加」，而是：

> 在 $\mathbb{Z}_m$ 上定义 $[a]_m+[b]_m:=[a+b]_m$、$[a]_m\cdot[b]_m:=[a\cdot b]_m$ 时，**结果不依赖于我们为每个等价类挑选了哪个代表元**。

如果没有这个定理，上述定义就是一句空话：因为 $[2]_{12}$ 的代表元可以是 2，也可以是 14、-10、38；我们凭什么保证「$[2]+[1]$」用 $2+1$ 算出 3，而用 $14+1$ 算出 15，两者代表的是同一个类？定理 5.1 恰好保证了 $15\equiv 3 \pmod{12}$，所以两种选法结果一致。**任何「通过代表元定义类之间的运算」的构造，都必须先过这一关**——这就是数学里「良定义性检验」的标准范式，后面 Lecture 7 用多项式插值定义秘密共享、Lecture 8 定义有限域上的编码，都要重复同样的检验。

推论 4.1（中途归约律）：在只含加、减、乘的任意算术表达式中，可以把任意中间结果先模 m 再继续计算，最终结果不变。

证明：对表达式的结构做归纳（Lecture 3 的结构归纳思想）。基础情形是单个变量或常量，归约后同余不变。归纳步骤：设两个子表达式的值 u, v 分别同余于其归约值 u', v'，则由定理 5.1 得 $u+v \equiv u'+v'$ 与 $uv \equiv u'v'$；减法同理（因为 $u - v \equiv u' - v'$ 可由定理 5.1 先对 $-v \equiv -v'$ 用一次，再对加法用一次得到）。■

具体算例（中途归约）：计算 $(13+11)\cdot 18 \bmod 7$。

$$\begin{aligned}(13+11)\cdot 18 &\equiv (6+4)\cdot 4 && (13\equiv 6,\ 11\equiv 4,\ 18\equiv 4 \pmod 7)\\ &= 10\cdot 4\\ &\equiv 3\cdot 4 && (10\equiv 3 \pmod 7)\\ &= 12\\ &\equiv 5 \pmod 7 && (12\equiv 5 \pmod 7)\end{aligned}$$

脚本验算：$(13+11)\times 18 = 432$，$432 \bmod 7 = 5$。**两条路殊途同归，且第二条路全程没让中间结果超过 12** ——这就是归约的实际价值：把大数运算变成小数运算。

引理 4.2（有限集上「有左逆」即双射）：设 A 是有限集，$f : A \to A$。若存在函数 $g : A \to A$ 使 $\forall x \in A,\ g(f(x)) = x$，则 f 是双射。

证明策略：直接证明，先证单射再证满射。这是 Lecture 2「有限集上单射即满射」的精确形式化，也是定理 5.2 中「乘以 x 是双射」这一断言的独立论证方式。

逐步推导：

1. **f 是单射**：设 $f(x) = f(x')$。两边同施 g 得 $g(f(x)) = g(f(x'))$。
2. 由 g 的定义 $g(f(x)) = x$、$g(f(x')) = x'$，故 $x = x'$。单射得证。
3. **f 是满射**：单射意味着 A 中 $|A|$ 个元素映射到 $|A|$ 个**互不相同**的像，故 f 的值域大小恰为 $|A|$。
4. 而值域 $\subseteq A$ 且 $|A|$ 有限，大小相同的子集只能是 A 本身，故值域 $= A$，即 f 满射。
5. 单射 + 满射 = 双射。■

【证明机制解说】：这里「有限性」是**关键且不可省**的。在无限集上，单射不必是满射（例如 $f(n) = n+1$ 在 $\mathbb{N}$ 上是单射但值域漏掉了 0）。所以 CS70 里凡是写「一一 $\Rightarrow$ 满」，都必须先确认集合有限——Lecture 5 的费马小定理、Lecture 14 的计数双射都依赖这个前提。把这条引理套用到定理 5.2 上：$A = \mathbb{Z}_m$（有限），$f([a]) = [ax]_m$，而「x 可逆」提供的正好是那个 $g([b]) = [bx^{-1}]_m$。**两条路径（鸽笼原理 / 左逆引理）结论一致，只是叙述的抽象层级不同。**

反例 4.1（除法不能自由进行）：定理 5.1 对除法**没有**对应结论。取 $m = 6$，$a = 2\cdot 3$、$c = 2\cdot 0$：

$$2\cdot 3 = 6 \equiv 0 \equiv 2\cdot 0 \pmod 6,$$

即 $2\cdot 3 \equiv 2\cdot 0 \pmod 6$ 成立，但

$$3 \not\equiv 0 \pmod 6 \quad (\text{因为 } 6 \nmid 3).$$

所以「从 $2\cdot 3 \equiv 2\cdot 0$ 消去 2」这一步是**非法**的。更直白地写：$2x \equiv 2y \pmod 6$ 推不出 $x \equiv y \pmod 6$。失灵的根源是 $\gcd(2,6) = 2 > 1$，即 2 在模 6 下没有乘法逆元。下面的消去律（推论 4.3）会精确标出什么时候可以消。

定理 5.2（逆元存在性）：设 m, x 为正整数且 $\gcd(m, x) = 1$。则 x 在模 m 下有乘法逆元，且该逆元模 m 唯一。

证明策略：**反证法 + 鸽笼原理（双射论证）**。官方 Note 5 的思路是：考虑 m 个数 $0, x, 2x, \ldots, (m-1)x$。先证这 m 个数**两两不同余**（用反证法，并由 $\gcd(m, x) = 1$ 推出矛盾），于是它们是 $\mathbb{Z}_m$ 上的一次**一一映射 (bijection)**；再数一数「只有 m 个不同的余数」这一事实，就逼出「1 一定出现在这个序列里」，那个位置就是逆元。选择这个策略的原因是：**我们手里唯一的信息是「互质」这个乘法性质，而反证法能把「互质」转化为「整除的排除条件」，这是整除语言最好用的地方。**

逐步推导：

1. 构造序列 $T = \{0\cdot x,\ 1\cdot x,\ 2\cdot x,\ \ldots,\ (m-1)\cdot x\}$，共 m 个整数（可能有重复的数值，但作为「带索引的项」有 m 项）。
2. **断言**：这 m 项模 m **两两不同余**。
3. **用反证法证明断言**：假设存在 a, b 满足 $0 \le b < a \le m-1$（即 $a \neq b$）但

$$ax \equiv bx \pmod m.$$

1. 移项得 $(a-b)x \equiv 0 \pmod m$，按定义即存在整数 k 使

$$(a-b)\,x = k\,m. \tag{4.1}$$

1. 由 $\gcd(m, x) = 1$ 知 m 与 x **不含任何大于 1 的公因子**。式 (4.1) 说明 m 整除乘积 $(a-b)x$，而 m 与 x 互质，故 m 必须整除 $a-b$。（这一步的严格依据是「欧几里得引理」：$\gcd(m, x) = 1$ 且 $m \mid xz \Rightarrow m \mid z$；它在 Lecture 5 用扩展欧几里得算法给出完整证明。这里先引用。）
2. 但 $1 \le a - b \le m-1$（由 $0 \le b < a \le m-1$），所以 $a-b$ 落在 1 与 $m-1$ 之间，**不可能**是 m 的正倍数，也非 0。
3. 这就与步骤 5 矛盾。断言得证。（依据：反证法。）
4. 断言说明「乘以 x」这个映射 $f([a]_m) = [ax]_m$ 是**一一的 (one-to-one)**。
5. 而定义域与陪域都是**有限集** $\mathbb{Z}_m$（大小 m），一一映射在一一对应的有限集上必然是**满射 (onto)**——这正是 Lecture 2 里「有限集上一一即满」的鸽笼原理直接推论（m 只鸽子放进 m 个笼子且不重合，则每个笼子恰好一只）。
6. 于是 $1 \in \mathbb{Z}_m$ 必是某个 $[ax]_m$ 的像：存在唯一（模 m）的 a 使 $ax \equiv 1 \pmod m$。
7. 这个 $a \bmod m$ 就是 x 的乘法逆元；由唯一性（步骤 10 的「唯一」）知逆元模 m 唯一。■

【证明机制解说】：整个证明是「**带索引的 m 个数 + 两两不同余 $\Rightarrow$ 恰好铺满 $\mathbb{Z}_m$**」这一鸽笼原理的标准用法。请特别注意**索引与数值的区别**：$0, x, \ldots, (m-1)x$ 有 m 个**索引**，它们映射到最多 m 个**余数**；「不同余」说明映射是单射，于是 m 个索引必然覆盖全部 m 个余数，一个不漏。这个「单射 + 有

限 + 定义域陪域等势 ⇒ 双射」的三步曲在本课程里反复出现：Lecture 5 证明费马小定理、Lecture 8 证明有限域结构、Lecture 14 做计数双射，用的都是同一招。

定理 5.2 的补集（必要性：$\gcd(m,x)=1$ 不可省）：若 $\gcd(m,x)=d>1$，则 x 在模 m 下**没有**乘法逆元。

证明策略：反证法。假设逆元存在，写出对应的（非模的）整除方程，然后从公因子 d 出发制造矛盾——即把「$d>1$」逼到「$d\mid 1$」这个不可能。

逐步推导：

1. 假设存在整数 a 使 $ax\equiv 1 \pmod m$。
2. 按定义，存在整数 k 使 $ax-1=km$，即

$$ax-km=1. \tag{4.2}$$

1. 设 $d=\gcd(m,x)>1$。由定义 $d\mid m$ 且 $d\mid x$。
2. 于是 $d\mid ax$（因为 $d\mid x$）且 $d\mid km$（因为 $d\mid m$）。
3. d 整除 $(ax-km)$。（依据：Lecture 0 中「若 d 整除两数则整除其差」。）
4. 由式 (4.2)，$d\mid 1$。
5. 但 $d>1$ 是正整数，不可能整除 1。矛盾。

故假设不成立，x 模 m 无逆元。■

【证明机制解说】：这个证明之所以只有五行却很有力，是因为它揭示了一个**不变量**：在模 m 下，凡是「能表示成 $ax+bm$ 形式的整数」，**一定都被 $\gcd(x,m)$ 整除**。逆元存在要求 1 能被这样表示，那就必须 $\gcd(x,m)=1$。这句话下一讲会被正面用出来（Bézout 等式：$\gcd(x,m)$ 本身总能写成 $ax+bm$），从而把「互质」与「可逆」彻底等价起来。**注意 $\gcd(m,x)=1$ 是充要条件，不是充分条件**——这是本讲最容易写错的地方。

具体算例（可逆与不可逆）：

x	m	$\gcd(x,m)$	逆元 $x^{-1} \bmod m$	验算
8	15	1	2	$2\cdot 8=16\equiv 1 \pmod{15}$
12	35	1	3	$3\cdot 12=36\equiv 1 \pmod{35}$
3	7	1	5	$5\cdot 3=15\equiv 1 \pmod 7$
12	15	3	不存在	序列 $12,9,6,3,0,\dots$ 中 1 永不出现
2	4	2	不存在	$2a \bmod 4\in\{0,2\}$，永不为 1

推论 4.3（消去律 / Cancellation Law）：设 $\gcd(c,m)=1$。若 $ca\equiv cb \pmod m$，则 $a\equiv b \pmod m$。

证明策略：构造性 + 直接证明。既然 c 可逆，就把两边同乘 c^{-1}——这正是「模运算里的除法」。存在性由定理 5.2 保证，所以这一步合法。

逐步推导：

1. 由 $\gcd(c,m)=1$ 及定理 5.2，存在整数 c^{-1} 使 $cc^{-1}\equiv 1 \pmod m$。
2. 两边同乘 c^{-1}：$c^{-1}(ca)\equiv c^{-1}(cb) \pmod m$。（依据：定理 5.1 的乘法部分——同余式两端可同乘一个整数。）
3. 左端 $c^{-1}ca\equiv (c^{-1}c)a\equiv 1\cdot a=a \pmod m$。（依据：结合律 + 逆元定义 + 定理 5.1。）
4. 右端同理 $\equiv b \pmod m$。
5. 由传递性得 $a\equiv b \pmod m$。■

反例 4.2（消去律的条件不可省）：取 $c=2,\ m=6$，则 $\gcd(2,6)=2>1$。此时 $2\cdot 1\equiv 2 \pmod 6$ 且 $2\cdot 4=8\equiv 2 \pmod 6$，所以 $2\cdot 1\equiv 2\cdot 4 \pmod 6$，但 $1\not\equiv 4 \pmod 6$。**「消去 c」这一步是否合法，完全取决于 $\gcd(c,m)$ 是否等于 1。**

补充：快速幂算法的正确性（归纳证明，官方 Note 5 的习题）

命题：对 $y\geq 0$，算法 `mod-exp(x,y,m)` 返回 $x^y \bmod m$，其中 $m>1$。

证明策略：对 y 做**强归纳 (strong induction)**（Lecture 3）。之所以用强归纳而非普通归纳，是因为递归调用发生在 $y \operatorname{div} 2=\lfloor y/2\rfloor$ 上，它比 $y-1$ 小得多且不连续，强归纳假设「所有小于 y 的值都正确」才能覆盖。

逐步推导：

1. **基础情形 $y=0$**：算法返回 1，而 $x^0=1\equiv 1 \pmod m$。正确。
2. **归纳假设**：设对所有 $0\leq z<y$ 及任意 x，`mod-exp(x,z,m)` 返回 $x^z \bmod m$。
3. **归纳步骤**：设 $y>0$，令 $a=\lfloor y/2\rfloor$，则 $y\in\{2a,2a+1\}$。
4. 算法计算 $z=$ `mod-exp(x, a, m)`。因 $a<y$，由归纳假设 $z\equiv x^a \pmod m$。
5. **情形 $y=2a$（偶数）**：算法返回 $z\cdot z \bmod m$。而 $z^2\equiv (x^a)^2=x^{2a}=x^y \pmod m$。（依据：定理 5.1 + 幂的乘法律。）
6. **情形 $y=2a+1$（奇数）**：算法返回 $x\cdot z\cdot z \bmod m$。而 $xz^2\equiv x\,(x^a)^2=x^{2a+1}=x^y \pmod m$。
7. 两种情形都返回 $x^y \bmod m$，故 $P(y)$ 成立。由强归纳，命题对所有 $y\geq 0$ 成立。■

复杂度：每次递归把 y 换成 $\lfloor y/2\rfloor$，故递归深度等于 y 的比特数 n；每次调用只做常数次乘法与取模，故总代价 $O(n)$ 次算术运算。**朴素连乘需要 y 次运算，本例中 y 可达 2^n-1，即指数级差距。**

具体算例（完整手算两次快速幂）：

算例 A：$3^{11} \bmod 7$。先列表做好平方（每行是上一行结果的平方再取模）：

步骤	计算	结果
3^1	基础	3
3^2	$3^2 = 9$，$9 \bmod 7$	2
3^4	$2^2 = 4$，$4 \bmod 7$	4
3^8	$4^2 = 16$，$16 \bmod 7$	2

现在 $11 = 8 + 2 + 1$（二进制 1011），故

$$3^{11} \equiv 3^8 \cdot 3^2 \cdot 3^1 \equiv 2 \cdot 2 \cdot 3 = 12 \equiv 5 \pmod 7.$$

脚本验算：$3^{11} = 177147$，$177147 \bmod 7 = 5$。✔

算例 B：$5^{13} \bmod 11$（$13 = 8 + 4 + 1$，二进制 1101）：

步骤	计算	结果
5^1	基础	5
5^2	$25 \bmod 11$	3
5^4	$3^2 = 9$，$9 \bmod 11$	9
5^8	$9^2 = 81$，$81 \bmod 11 = 81 - 77$	4

$$5^{13} \equiv 5^8 \cdot 5^4 \cdot 5^1 \equiv 4 \cdot 9 \cdot 5 = 180 \equiv 180 - 176 = 4 \pmod{11}.$$

脚本验算：$5^{13} = 1220703125$，$1220703125 \bmod 11 = 4$。✔

算例 C（定理 5.1 的加乘同余）：$a = 14,\ b = 25,\ m = 12$（官方 Note 5 的例子）。 – $a \equiv 2 \pmod{12}$（$14 = 1 \cdot 12 + 2$），$b \equiv 1 \pmod{12}$（$25 = 2 \cdot 12 + 1$）。 – 加法：$a + b = 39 \equiv 3$；先归约再算 $2 + 1 = 3$。✔（$39 = 3 \cdot 12 + 3$） – 乘法：$ab = 350$；$350 = 29 \cdot 12 + 2$，故 $\equiv 2$；先归约再算 $2 \cdot 1 = 2$。✔ – 减法：$a - b \equiv 2 - 1 = 1$；直接算 $14 - 25 = -11$，$-11 + 12 = 1$。✔

算例 D（模 7 的完整乘法表与逆元速查）：把 $i \cdot j \bmod 7$ 全部列出，可以直接「看出」每个非零元素的逆元。

```
模 7 乘法表 (i * j mod 7)
    j=0  1  2  3  4  5  6
i=0 |  0  0  0  0  0  0  0
  1 |  0  1  2  3  4  5  6
  2 |  0  2  4  6  1  3  5
  3 |  0  3  6  2  5  1  4
  4 |  0  4  1  5  2  6  3
  5 |  0  5  3  1  6  4  2
  6 |  0  6  5  4  3  2  1

观察 1：除第 0 行/列外，每一行都是 {1,2,3,4,5,6} 的一个排列
      --> 这正是定理 5.2 的「双射」结论的可视化
观察 2：数字 1 出现的位置即逆元对：
      1^-1=1, 2^-1=4, 3^-1=5, 4^-1=2, 5^-1=3, 6^-1=6
观察 3：第 0 行/列中 0 之外还出现别处，说明模 7 是「域」般干净
      （因为 7 是质数）；而模 15 时 12*5=0 会破坏这个整齐性
```

脚本验算：上表每一行都独立用程序生成比对，$2 \cdot 4 = 8 \equiv 1$、$3 \cdot 5 = 15 \equiv 1 \pmod 7$ 均成立。✔

与经典问题的联系

（一）密码学与 RSA（Lecture 6 的主题）

RSA 的全部运算都发生在 $\mathbb{Z}_N$（$N = pq$，p, q 是上千比特的质数）里：加密是 $E(x) \equiv x^e \pmod N$，解密是 $D(y) \equiv y^d \pmod N$。要让这套方案跑起来，必须有：

1. **定理 5.1** 保证「先乘再取模」与「先取模再乘」等价——否则每次幂运算的中间结果会膨胀到天文数字；
2. **快速幂** 把 $x^e \bmod N$ 的代价从 e 次乘法降到 $O(\log e)$ 次；
3. **定理 5.2** 保证解密指数 $d \equiv e^{-1} \bmod (p-1)(q-1)$ 存在（因为 e 被特意选成与 $(p-1)(q-1)$ 互质）。

（二）纠错码（Lecture 8）

纠错码需要在有限字母表上做线性代数（例如 GF(256)），也就是在一个大小为 2^8 的「有限域」上做加减乘除。其中的除法正是本讲的乘法逆元；而 「每个非零元都可逆」这一性质（本讲在质数模数下证明的定理 5.2）正是**域 (field)** 的定义要件。

（三）不引入逆元的后果：为什么「模运算不能随便约分」是个安全问题

很多初学者把 $ax \equiv ay \pmod m$ 直接约掉 a。在 RSA 参数下这是致命的：m 是合数（$N = pq$），许多 a 与 N 不互质，消去律失效。本讲的推论 4.3 给出了**唯一合法约分的判据**：先检查 $\gcd(a, m) = 1$。

与其他讲次的关联

- **承接 Lecture 0（直接证明）**：定理 4.0 与定理 5.1 的加法部分都是典型的「展开定义 → 代数操作 → 回到定义」的直接证明；「$d \mid a$ 且 $d \mid b \Rightarrow d \mid (a \pm b)$」这一工具在 Lecture 0 已备好，本讲只是反复调用。
- **承接 Lecture 2（鸽笼原理/有限集上一一即满）**：定理 5.2 的存在性证明完全依赖「有限集上单射 $\Rightarrow$ 满射」。若没有 Lecture 2 的这条引理，我们就只能证明「这 m 个数互不相同」，无法断言「1 一定出现」。
- **承接 Lecture 3（归纳法）**：推论 4.1 对表达式结构做归纳、快速幂正确性对指数 y 做强归纳，都是 Lecture 3 技巧的直接应用。
- **通向 Lecture 5（欧几里得算法、FLT、CRT）**：本讲留下了两个「欠账」——(a) 证明定理 5.2 时引用了「$\gcd(m,x)=1$ 且 $m \mid xz \Rightarrow m \mid z$」；(b) 说「逆元唯一且可计算」但没有给出算法。Lecture 5 的扩展欧几里得算法一次还清这两笔账，并给出 $x^{-1} \bmod m$ 的具体求法。同讲的费马小定理还提供 $a^{-1} \equiv a^{p-2} \pmod p$ 这条质数模数下的捷径。
- **通向 Lecture 6（RSA）**：x^e 与 y^d 的计算 = 本讲快速幂；$d \equiv e^{-1} \bmod (p-1)(q-1)$ 的合法性 = 本讲定理 5.2。Lecture 6 的解密正确性证明依赖 Lecture 5 的费马小定理。
- **通向 Lecture 7–8（多项式与秘密共享/纠错码）**：秘密共享要在有限域上解多项式方程组，而「有限域」的构造就是把 $\mathbb{Z}_p$（p 为质数）这个结构中本讲的运算律完整继承下来。
- **通向 Lecture 20（哈希与负载均衡）**：哈希函数的「模 m 映射到 m 个桶」正是剩余类划分；「模质数」比「模合数」分布更均匀的原因，也可从本讲 $\mathbb{Z}_p$ 的结构整齐性（乘法表每行是排列）看出端倪。

关键要点

1. **同余的定义与两种等价视角**：$a \equiv b \pmod m \iff m \mid (a-b) \iff a \bmod m = b \bmod m$。前者用于**证明**（代数操作方便），后者用于**计算**（数值归约方便）。
2. **定理 5.1 是全部模运算的合法性基础**：加、减、乘在模 m 下自由进行、中途可任意归约；这条定理的实质是**良定义性**——类运算不依赖代表元。
3. **除法必须换成乘逆元**。$a \equiv b \pmod m$ 与 $ca \equiv cb \pmod m$ 之间**只有**在 $\gcd(c,m)=1$ 时才可互相推导；这是消去律（推论 4.3），不是普遍规律。
4. **逆元存在当且仅当 $\gcd(x,m)=1$（充要条件）**：存在性由鸽笼/双射论证（定理 5.2），必要性由「$d \mid ax - km = 1$ 而 $d > 1$」的矛盾得出。逆元存在时模 m 唯一。
5. **快速幂把指数代价从 $O(y)$ 降到 $O(\log y)$**：利用 $x^{2a} = (x^a)^2$ 与 $x^{2a+1} = x(x^a)^2$，递归深度 = 指数比特数。这是 RSA 可行的技术支柱之一。
6. **黄金法则**：在模 m 下，你**可以**随便约简**加减乘**的中途结果，但**绝不可以**在没有检查 $\gcd$ 的情况下约简**除/约分**。

常见误区与注意事项

1. **把「有余数」与「同余」混为一谈**。`a mod m` 是一个**数**（落在 $\{0,\dots,m-1\}$）；$a \equiv b \pmod m$ 是一个**命题**（真/假）。写作时不要出现「$29 \bmod 12 \equiv 5 \pmod{12}$」这种把两者混写的表达式。
2. **忘记模运算中除法需要逆元存在**。看到 $ax \equiv ay \pmod m$ 就想约掉 a 是最高频错误。反例：$2 \cdot 1 \equiv 2 \cdot 4 \pmod 6$ 但 $1 \not\equiv 4 \pmod 6$。**正确做法**：先算 $\gcd(a,m)$；只有为 1 时才可约。
3. **认为「非零数必有逆元」**。12 在模 15 下非零却不可逆。实数里「只有 0 不可逆」的直觉在模运算中**完全失效**，因为 $\mathbb{Z}_m$ 仅在 m 为质数时才是域。
4. **把定理 5.2 的条件记成充分条件**。$\gcd(m,x)=1$ 是**充要条件**；漏写「且」或错写成「若 $\gcd > 1$ 则……无逆元」都算对，但正说成「$\gcd = 1$ 时可能有也可能没有逆元」就错了——一定有，且唯一。
5. **快速幂把 $y \operatorname{div} 2$ 写成 $y/2$**。当 y 是奇数时 $y/2$ 不是整数，取整方向必须是**向下取整** $\lfloor y/2 \rfloor$；相应地奇偶分支的那次「多乘一个 x」不能漏。
6. **定理 5.1 的乘法证明漏掉 m^2 项**。展开 $(a+km)(b+\ell m)$ 时必须写出四项，$k\ell m^2$ 虽小但**必须显式说明它也是 m 的倍数**，否则「$m \mid (cd - ab)$」的结论缺一步依据。
7. **负数的取模**。$-11 \bmod 12$ 在数学约定下是 1（最小非负余数），而某些编程语言的 `%` 会给出 -11。写证明时以**数学约定**（$0 \le r \le m-1$）为准。

思考题（带答案）

Q1.（计算题） 求 $7^{203} \bmod 11$。（要求写出反复平方的中间表，不要直接给结果。）

▸ **答案**

先建立 7 的 2 的幂次表（每步平方取模）：

幂	计算	结果 mod 11
7^1	—	7
7^2	$49 = 4\cdot 11 + 5$	5
7^4	$5^2 = 25 = 2\cdot 11 + 3$	3
7^8	$3^2 = 9$	9
7^{16}	$9^2 = 81 = 7\cdot 11 + 4$	4
7^{32}	$4^2 = 16 = 11 + 5$	5
7^{64}	$5^2 = 25$	3
7^{128}	$3^2 = 9$	9

$203 = 128 + 64 + 8 + 2 + 1 = (11001011)_2$（校验：$128+64+8+2+1 = 203$ ✔）。

$$7^{203} \equiv 7^{128}\cdot 7^{64}\cdot 7^{8}\cdot 7^{2}\cdot 7^{1} \equiv 9\cdot 3\cdot 9\cdot 5\cdot 7 \pmod{11}.$$

逐步归约：$9\cdot 3 = 27 \equiv 5$；$5\cdot 9 = 45 \equiv 1$；$1\cdot 5 = 5$；$5\cdot 7 = 35 \equiv 2 \pmod{11}$。

答案：$7^{203} \equiv 2 \pmod{11}$。（脚本验算：$7^{203} \bmod 11 = 2$ ✔）

注意这里出现了一个可做交叉验证的规律：$7^{32} \equiv 5 \equiv 7^2 \pmod{11}$，说明 7 的幂在模 11 下的**最小正周期是 10**（脚本列出 $7^1, \dots, 7^{10}$ 为 $7, 5, 2, 3, 10, 4, 6, 9, 8, 1$，到第 10 次才回到 1）。于是 $203 \bmod 10 = 3$，$7^{203} \equiv 7^3 \equiv 2 \pmod{11}$ ✔。这个「周期恰为 $p-1$（或它的因子）」的现象，正是 Lecture 5 费马小定理 $a^{p-1} \equiv 1 \pmod{p}$ 的实例。

Q2.（概念/证明题） 判断下列命题真假，为真者给出证明，为假者给出反例：

(a) 若 $a \equiv b \pmod{m}$ 且 $c \equiv d \pmod{m}$，则 $a - c \equiv b - d \pmod{m}$。(b) 若 $a \equiv b \pmod{m}$，则 $2a \equiv 2b \pmod{2m}$。(c) 若 $x^2 \equiv y^2 \pmod{p}$（p 为质数），则 $x \equiv y \pmod{p}$ 或 $x \equiv -y \pmod{p}$。(d) 若 $ax \equiv ay \pmod{m}$ 且 $a \not\equiv 0 \pmod{m}$，则 $x \equiv y \pmod{m}$。

▸ **答案**

(a) 真。 由 $a \equiv b$ 得 $m \mid (a-b)$；由 $c \equiv d$ 得 $m \mid (c-d)$。于是 $m \mid \big[(a-b)-(c-d)\big] = \big[(a-c)-(b-d)\big]$，即 $a - c \equiv b - d \pmod{m}$。（也可以说：先由对称性得 $-c \equiv -d$，再用定理 5.1 的加法部分。）

(b) 真。 $a \equiv b \pmod{m}$ 意味着存在整数 k 使 $a - b = km$。两边乘 2：$2a - 2b = 2km = k(2m)$，故 $2m \mid (2a - 2b)$，即 $2a \equiv 2b \pmod{2m}$。这是定理 5.1 的一个「模数也一起放大」的变体，注意**模数必须同步放大**才成立。

(c) 真。 $x^2 \equiv y^2 \pmod{p}$ 推出 $x^2 - y^2 \equiv 0$，即 $(x-y)(x+y) \equiv 0 \pmod{p}$，也就是 $p \mid (x-y)(x+y)$。由欧几里得引理（p 为质数且 $p \mid uv \Rightarrow p \mid u$ 或 $p \mid v$），得 $p \mid (x-y)$ 或 $p \mid (x+y)$，即 $x \equiv y$ 或 $x \equiv -y \pmod{p}$。**注意：结论里的「或」是真析取——两者可以同时成立**（当 $p = 2$ 或 $x \equiv y \equiv 0$ 时）；而且这个结论对**合数模数失效**：$m = 8$ 时 $1^2 = 1$、$3^2 = 9 \equiv 1 \pmod{8}$，但 $3 \not\equiv \pm 1 \pmod{8}$（$3 \not\equiv 1$，$3 \not\equiv 7$）。

(d) 假。 反例：$m = 6$，$a = 2$，$x = 1$，$y = 4$。则 $a \not\equiv 0 \pmod{6}$（$2 \not\equiv 0$），$2 \cdot 1 = 2$、$2 \cdot 4 = 8 \equiv 2 \pmod{6}$，故 $ax \equiv ay$；但 $1 \not\equiv 4 \pmod{6}$。**根源**：$\gcd(a, m) = \gcd(2, 6) = 2 > 1$，消去律（推论 4.3）不适用。「$a \not\equiv 0$」远不足以推出可消去——正确的条件是 $\gcd(a, m) = 1$。

Q3.（概念题） 定理 5.2 的证明中，为什么要考察 $0, x, 2x, \dots, (m-1)x$ 这 m 个数，而不是 $1, x, 2x, \dots, (m-1)x$ 这 $m-1$ 个数？如果只取 $m-1$ 个数，鸽笼原理那一步还能用吗？

▸ **答案**

关键在于鸽笼原理要求**定义域集合与陪域集合大小相同**。

陪域是 $\mathbb{Z}_m$，大小恰好为 m。要让「单射 $\Rightarrow$ 满射」这一步成立，定义域的大小必须**正好是 m**：

- 若取 m 个数 $0, x, \dots, (m-1)x$：它们两两不同余 $\Rightarrow$ m 个互不相同的余数落在 m 个格子里 $\Rightarrow$ **恰好用尽所有格子** $\Rightarrow$ 1 必在其中，逆元存在。✔
- 若只取 $m-1$ 个数 $1, x, \dots, (m-1)x$：即使能证明它们两两不同余，也只是说「有 $m-1$ 个不同的余数落在 m 个格子里」，**还剩一个格子空着**——而那唯一空着的格子完全可能就是 $\{1\}$。此时我们只知道 $\{1\}$ 可能被命中，无法确定。✘

另外一个附带的便利是：加上 $0 \cdot x = 0$ 这一项，序列的第 0 项恰好覆盖了余数 0，使得「m 个数两两不同余」直接等价于「$\{0, 1, \dots, m-1\}$ 的完全排列」，从而「乘以 x 是 $\mathbb{Z}_m$ 上的双射」这一结论可以一句话说出（这正是官方 Note 5 脚注里提到的等价表述）。

引申：这个「必须凑齐 m 个」的细节在 Lecture 5 证明费马小定理时会再次出现——那里考察的是 $a, 2a, \dots, (p-1)a$（共 $p-1$ 个数，不含 0），恰好对应集合 $S = \{1, \dots, p-1\}$（大小也是 $p-1$），同样凑齐了数量才得到「S' 是 S 的排列」这一关键结论。

Lecture 5: Euclid, FLT, CRT（欧几里得算法、费马小定理、中国剩余定理）

概述

本讲把 Lecture 4 留下的三笔账一次结清，并补齐模运算的全部工具链。核心问题有三个：(1) 怎么**高效**地算 $\gcd(x,y)$，并顺带求出 Bézout 系数 a,b 使 $ax+by=\gcd(x,y)$——由此得到求模逆元的算法；(2) 整数的质因数分解为什么**存在且唯一**（算术基本定理）；(3) 一组同余方程何时有唯一解、如何**构造**（中国剩余定理）。最后证明**费马小定理**，它刻画了「模质数下幂运算的周期性」，是 Lecture 6 RSA 解密正确性的直接依据。证明技巧上，本讲的主线是**强归纳 + 构造性证明 + 双射计数**。

核心概念的直观解释

最大公约数（Greatest Common Divisor, gcd）

- **定义**：对自然数 x,y（不全为 0），$\gcd(x,y)$ 是**同时整除 x 与 y 的最大正整数**。若 $\gcd(x,y)=1$，称 x 与 y **互质** (relatively prime / coprime)。
- **直观解释**：「用同一把尺子同时量尽两根棍子，这把尺子最长能多长」。更一般地，$\gcd$ 是「两个数的公共度量单位」——这正是欧几里得算法最初的工程背景：把设计图的长度按比例放大时，需要找到能同时整除所有尺寸的长度单位。
- **具体示例**：$\gcd(30,24)=6$（$30=2\cdot3\cdot5$，$24=2^3\cdot3$，公共部分 $2\cdot3=6$）；$\gcd(16,10)=2$；$\gcd(35,12)=1$（$35=5\cdot7$，$12=2^2\cdot3$ 无公共因子）。约定 $\gcd(x,0)=x$，因为 0 被任何数整除。
- **注意区分**：$\gcd$ 取**公共因子的最大者**，lcm（最小公倍数）取**公共倍数的**最小者。两者满足 $\gcd(x,y)\cdot\operatorname{lcm}(x,y)=xy$。

Bézout 等式与 Bézout 系数（Bézout's Identity）

- **定义**：设 $d=\gcd(x,y)$。存在整数 a,b（可正可负可零）使

$$ax+by=d.$$

这里的 a,b 称为 Bézout 系数 (Bézout coefficients)。**注意这是普通的整数等式，不是同余式**。

- **直观解释**：$\gcd$ 不只是「公共因子的最大值」，它还是**所有形如 $ax+by$ 的整数组合中最小的那个正数**。换句话说，我们要的不是「找最大公因子」，而是「用 x 和 y 的整数线性组合去凑出尽可能小的正数」——能凑出的最小正数**恰好**就是 $\gcd$。这正是扩展欧几里得算法（以及它更直观的「列等式相减」手工版本）的设计动机。
- **具体示例**：$1=\gcd(35,12)=(-1)\cdot35+3\cdot12$，所以 $a=-1,b=3$ 是一组合法的 Bézout 系数。又如 $2=\gcd(16,10)=2\cdot16+(-3)\cdot10$。

扩展欧几里得算法（Extended Euclid's Algorithm）

- **定义**：在欧几里得算法「反复做带余除法」的基础上，**在递归回溯 (unwinding) 时同步维护系数**，使每次返回都满足 $d=ax+by$。
- **直观解释**：欧几里得算法告诉你「d 是多少」，扩展版额外告诉你「d 怎么用 x,y 拼出来」。它之所以能顺手做到，是因为**带余除法本身就是一次线性组合的初等变换**：$x \bmod y = x-\lfloor x/y\rfloor\cdot y$。
- **具体示例**：$x=35,\ y=12$，算法返回 $(d,a,b)=(1,-1,3)$，验证 $-1\cdot35+3\cdot12=-35+36=1$ ✔。因为 $d=1$，从这里立刻读出 $3\cdot12\equiv1\pmod{35}$，即 $12^{-1}\equiv3\pmod{35}$。

算术基本定理（Fundamental Theorem of Arithmetic, FTA）

- **定义**：每个正整数 $n>1$ 都可以写成质数之积 $n=p_1p_2\cdots p_k$，且这种写法在**不计次序**的意义下**唯一**。
- **直观解释**：质数是整数的「化学元素」——每个整数都有唯一的「分子式」。存在性（每个数都能分解）靠**强归纳**（Lecture 3）；唯一性（分解不会有两种本质不同的结果）靠**欧几里得算法的推论**（本讲）。这是一个很深的联系：**整除的唯一性来源于带余除法的唯一性**。
- **具体示例**：$12=2\cdot2\cdot3$，任何其他分解都只是 $2,2,3$ 的重排（如 $2\cdot3\cdot2$、$3\cdot2\cdot2$）。$360=2^3\cdot3^2\cdot5$ 是唯一分解。

中国剩余定理（Chinese Remainder Theorem, CRT）

- **定义**：设 $n_1,\dots,n_k$ **两两互质**，$N=\prod_{i=1}^{k}n_i$。则对任意给定的 $a_1,\dots,a_k$，同余方程组

$$x\equiv a_1\pmod{n_1},\quad x\equiv a_2\pmod{n_2},\quad\dots,\quad x\equiv a_k\pmod{n_k}$$

在模 N 下有**唯一解**。其构造式为

$$x\equiv\sum_{i=1}^{k}a_ib_i\pmod{N},\qquad b_i=\frac{N}{n_i}\left(\left(\frac{N}{n_i}\right)^{-1}\bmod n_i\right).$$

该定理最早见于公元 3 世纪中国数学家**孙子**（Sunzi）的著作，故得名。

- **直观解释（坐标视角）**：把「一个数 x 模 N」想象成「一个 k 维向量 $(x\bmod n_1,\dots,x\bmod n_k)$」。CRT 说这个对应是**双射 (bijection)**：模 N 的每个数对应唯一一个「坐标组」，反之亦然。而每个 b_i 就是第 i 个坐标轴上的**基向量 (basis vector)**——它在自己的方向上是 1（即 $b_i\equiv1\pmod{n_i}$），在所有其他方向上都是 0（即 $b_i\equiv0\pmod{n_j}$，$j\neq i$）。于是要组装出目标向量 $(a_1,\dots,a_k)$，只需令 $x=\sum_i a_ib_i$ 即可。
- **具体示例**：「今有物不知其数，三三数之剩二，五五数之剩三，七七数之剩二」即 $x\equiv2\pmod3$、$x\equiv3\pmod5$、$x\equiv2\pmod7$。取 $N=105$，解得 $x=23$（验算见下文）。23 在 $[0,104]$ 内是唯一解，通解为 $23+105t$。

费马小定理（Fermat's Little Theorem, FLT）

- **定义**：设 p 是**质数**，$a\in\{1,2,\dots,p-1\}$（等价地：$\gcd(a,p)=1$）。则

$$a^{p-1}\equiv1\pmod{p}.$$

等价形式：对任意整数 a，$a^p \equiv a \pmod p$（这个形式不要求 $\gcd(a,p)=1$）。

- **直观解释**：在模质数 p 的乘法世界里，任何非零元素的幂都是**周期性**的，而且这个周期**总是 $p-1$ 的因子**（不一定恰为 $p-1$，例如模 11 时 7 的周期是 10，而 $10^2=100\equiv 1$ 的周期是 2）。FLT 就是把 Lecture 4 的乘法表「每一行都是排列」这一观察**乘积化**的结果。
- **具体示例**：$p=11,\ a=2$：$2^{10}=1024=93\cdot 11+1$，故 $2^{10}\equiv 1 \pmod{11}$ ✔。$p=7,\ a=3$：$3^6=729=104\cdot 7+1$，故 $3^6\equiv 1\pmod 7$ ✔。
- **条件不可省的反例**：取 $m=4$（合数）、$a=2$。$m-1=3$，而 $2^3=8\equiv 0 \pmod 4 \neq 1$。所以「$a^{m-1}\equiv 1 \pmod m$」**对合数 m 一般不成立**，FLT 的「p 是质数」这一条无法删除。

模逆元的三种求法（本讲串联总结）

方法	适用条件	代价	本讲位置
暴力枚举 $ax\equiv 1$	任意 m，仅演示用	$O(m)$	Lecture 4 定理 5.2
扩展欧几里得	$\gcd(x,m)=1$	$O(\log m)$	本讲第 1 节
费马小定理 $x^{-1}\equiv x^{p-2}$	$m=p$ 为质数	$O(\log p)$（用快速幂）	本讲第 4 节

完整证明与推导（核心）

定理 6.1（欧几里得算法的不变量）：设 $x\geq y>0$，则

$$\gcd(x,y)=\gcd(y,\ x \bmod y).$$

证明策略：**集合相等法**（直接证明）。不直接比较两个「最大数」，而是证明**两个公约数集合完全相同**——既然集合相同，其最大元素当然相同。这是处理 $\gcd$ 类命题的标准降维手法：把「最大」这个序性质转化为「集合相等」这个逻辑性质。证明需要两个方向：正向与反向各用一次「整除的线性封闭性」（$d\mid u\wedge d\mid v\Rightarrow d\mid(u\pm v)$，来自 Lecture 0）。

逐步推导：

1. 设 $x=qy+r$，其中 $q=\lfloor x/y\rfloor$ 是整数，$r=x \bmod y$ 满足 $0\leq r<y$。（依据：带余除法的存在唯一性。）
2. **（⇒ 方向）** 设 d 是 x 与 y 的任一公约数，即 $d\mid x$、$d\mid y$。
3. 由 $d\mid y$ 得 $d\mid qy$。（依据：若 d 整除某数，则整除其任意整数倍。）
4. 由 $d\mid x$ 且 $d\mid qy$，得 $d\mid(x-qy)$，即 $d\mid r$。（依据：Lecture 0 的整除线性性。）
5. 于是 d 同时整除 y 与 r，即 d 是 y 与 $x \bmod y$ 的公约数。
6. **（⇐ 方向）** 反过来，设 d 是 y 与 r 的任一公约数，即 $d\mid y$、$d\mid r$。
7. 由 $d\mid y$ 得 $d\mid qy$（同上）。
8. 由 $d\mid qy$ 且 $d\mid r$，得 $d\mid(qy+r)$，即 $d\mid x$。（依据：整除线性性 + $x=qy+r$。）
9. 于是 d 同时整除 x 与 y，即 d 是 x 与 y 的公约数。
10. 步骤 2–5 与 6–9 合起来说明：**$\{x,y\}$ 的公约数集合 $=\{y,x \bmod y\}$ 的公约数集合**。
11. 两个相等的正整数集合当然有相同的最大元素，故 $\gcd(x,y)=\gcd(y,x \bmod y)$。∎

【证明机制解说】：整个证明的「灵光一现」在第 4 步——**把 r 写成 $x-qy$**。这一步把「余数」这个看似只能通过除法定义的对象，翻译成了 x 与 y 的**整数线性组合**，于是「整除封闭性」这把万能钥匙就能插入锁孔。反向（第 8 步）用的是同一个组合的加法形式 $x=qy+r$。**两个方向合起来才叫「公约数集合相同」**：只证一个方向，只能得到集合包含关系，无法推出最大元相等。这个「互推对称性」是本讲后续所有证明（包括 Bézout 等式）的骨架。

具体算例（官方 Note 6 的 gcd 序列）：

```
gcd(16, 10)
  = gcd(10, 16 mod 10 = 6)      16 = 1*10 + 6
  = gcd( 6, 10 mod  6 = 4)      10 = 1*6  + 4
  = gcd( 4,  6 mod  4 = 2)       6 = 1*4  + 2
  = gcd( 2,  4 mod  2 = 0)       4 = 2*2  + 0
  = 2                           第二个参数为 0，返回第一个参数

另一例（Fibonacci 型最坏情形）：
gcd(1071, 462)
  = gcd(462, 1071 mod 462 = 147)    1071 = 2*462 + 147
  = gcd(147,  462 mod 147 =  21)     462 = 3*147 +  21
  = gcd( 21,  147 mod  21 =   0)     147 = 7*21  +   0
  = 21
```

算法（递归形式）：

```
algorithm gcd(x, y)          // 要求 x >= y >= 0, x > 0
    if y = 0 then return(x)
    else return(gcd(y, x mod y))
```

定理 6.2（欧几里得算法的正确性）：上述算法对任意满足 $x\geq y\geq 0$、$x>0$ 的自然数输入，都正确返回 $\gcd(x,y)$。

证明策略：**对第二个参数 y 做强归纳**（Lecture 3）。之所以选 y 而不是 x：递归调用是 $\gcd(y, x \bmod y)$，它的第二个参数是 $x \bmod y$，而定理 6.1 保证了 $x \bmod y < y$——**归纳变量严格递减的方向正好由算法自身保证**。之所以用强归纳而非普通归纳：递归调用一次就从 y 跳到 $x \bmod y$，中间可能跨过很多值，普通归纳的假设（只覆盖 $y-1$）不够用。

逐步推导：

1. 对每个 $y \geq 0$ 定义命题 $P(y)$：**对所有满足 $x \geq y$ 且 $x > 0$ 的整数 x，算法 `gcd(x,y)` 正确返回 $\gcd(x, y)$**。
2. **基础情形 $y = 0$**：算法走 `if` 分支返回 x。而 $\gcd(x, 0) = x$（0 被一切数整除，故公约数集合就是 x 的因子集合，最大者为 x），且输入要求 $x > 0$ 保证 x 是合法返回值。故 $P(0)$ 成立。
3. **归纳假设**：设 $y > 0$，并假设 $P(z)$ 对所有 $0 \leq z < y$ 成立。
4. **归纳步骤**：$y > 0$，算法走 `else` 分支，返回 `gcd(y, x mod y)`。
5. 令 $r = x \bmod y$。由带余除法 $0 \leq r < y$，故 r 落在归纳假设的覆盖范围内。
6. 检查递归调用的输入合法性：调用 `gcd(y, r)` 要求「第一个参数 $\geq$ 第二个」且「第一个参数 > 0」。由 $r < y$ 得 $y \geq r$ ✔；由 $y > 0$ 得第一个参数为正 ✔。故归纳假设 $P(r)$ 适用（取该命题中的「x」为 y）。
7. 于是递归调用正确返回 $\gcd(y, r) = \gcd(y, x \bmod y)$。
8. 由定理 6.1，$\gcd(y, x \bmod y) = \gcd(x, y)$。
9. 所以 `else` 分支返回的值等于 $\gcd(x, y)$，$P(y)$ 成立。
10. 由强归纳原理，$P(y)$ 对所有 $y \geq 0$ 成立，算法正确。■

【证明机制解说】：这个正确性证明有一个特别优雅的地方：**算法与证明是同一件事的两种语言**。算法通过「把 (x, y) 换成 $(y, x \bmod y)$」让数值下降；证明通过「把 $P(y)$ 换成 $P(x \bmod y)$」让归纳变量下降。定理 6.1 保证两者的下降终点一致（第二个参数为 0）。这类「递归算法 + 强归纳正确性」的组合模式在 CS70 里反复出现：Lecture 3 的汉诺塔、Lecture 6 的模幂、Lecture 11 的 Gale–Shapley 终止性都同构。**请特别注意第 6 步**——检查递归调用的输入是否满足算法前提，这是很多学生写正确性证明时漏掉的一环；漏了它，归纳假设就无从落地。

定理 6.3（欧几里得算法复杂度：$O(\log x)$ 次递归调用）：

命题：在 $\gcd(x, y)$ 的计算中，**每两次递归调用**，第一个（较大的）参数至少缩小一半。

证明策略：**分情形讨论（case analysis）**。直接证明「一次调用就减半」是**假的**（反例：$x = 100, y = 99$ 时第一次调用后第一个参数变成 99，几乎没减），所以必须看两步。分界点选在 y 与 $x/2$ 的大小关系上。

逐步推导：

1. 考虑调用 $\gcd(x, y)$，其中 $x \geq y \geq 0$，$x > 0$。
2. **情形 1：$y \leq x/2$**。
3. 第一次递归调用是 $\gcd(y, x \bmod y)$，其第一个参数为 y，已满足 $y \leq x/2$。
4. 第二次递归调用将其变成 $\gcd(x \bmod y,\ y \bmod (x \bmod y))$，第一个参数为 $x \bmod y < y \leq x/2$。
5. 故两次调用后第一个参数 $< x/2$。（严格来说，一次调用后就已 $< x$ 至少缩半。）
6. **情形 2：$x \geq y > x/2$**。
7. 此时 $x = 1 \cdot y + (x - y)$，故 $x \bmod y = x - y$。（依据：因为 $y > x/2 > 0$ 且 $x < 2y$，商的整数部分只能是 1。）
8. 于是 $x \bmod y = x - y < x - x/2 = x/2$。（依据：$y > x/2$。）
9. 第一次递归调用 $\gcd(y, x \bmod y)$ 的第一个参数是 $y < x$；第二次递归调用 $\gcd(x \bmod y, \cdot)$ 的第一个参数是 $x \bmod y < x/2$。
10. 故两次调用后第一个参数 $< x/2$。
11. 两种情形都给出「每两次调用第一个参数减半」。
12. 设 n 为 x 的比特数，即 $x < 2^n$。每两次调用使第一个参数至少除以 2，故至多 $2n$ 次调用后第一个参数变为 0，递归终止（第一个参数始终是非负整数，不可能无限减半）。
13. 每次调用只做一次整数比较和一次 `mod` 运算，在「算术运算计为常数时间」的模型下，总代价为 $O(n) = O(\log x)$。■

反例（说明为什么必须看两步）：取 $x = 1000,\ y = 999$。第一次调用得到 $\gcd(999, 1)$，第一个参数从 1000 只降到 999——**几乎没减**。但再看一步：$\gcd(1, 0)$，第一个参数降到 $1 < 500$。所以「单步减半」为假，「两步减半」为真。这个「最坏情形」正是相邻 Fibonacci 数对：递归次数最少下降模式的极端例子，可证明调用次数约为 $\log_\varphi x$（φ 为黄金比），与我们的 $O(\log x)$ 上界一致。

【证明机制解说】：情形 2 的关键推理是**「$y > x/2$ 迫使商为 1，从而余数就是差值 $x - y$」**。这是一个把「取值范围假设」转化为「具体代数表达式」的典型技巧：一旦写出 $x \bmod y = x - y$，减半的结论就一目了然。请体会这里的分界点为什么选 $x/2$ 而不是别的：若 $y \leq x/2$，减半来自 y 本身；若 $y > x/2$，减半来自 $x - y$。**两条路保证无论 y 落在哪个区间，两步内必减半。** 这种「互补区间覆盖」是算法分析中最常见的分情形设计。

扩展欧几里得算法（Extended Euclid）

目标：求三元组 (d, a, b) 使 $d = \gcd(x, y)$ 且 $d = ax + by$。

```
algorithm extended-gcd(x, y)        // 要求 x >= y >= 0, x > 0
    if y = 0 then return (x, 1, 0)          // 基础情形: d = x = 1*x + 0*y
    else
        (d, a, b) := extended-gcd(y, x mod y)
        return (d, b, a - (x div y) * b)    // 关键回代公式
```

为什么这个回代公式是对的？（推导）

1. 递归调用返回 (d, a, b)，满足

$$d = ay + b\,(x \bmod y). \tag{5.1}$$

1. 把恒等式 $x \bmod y = x - \lfloor x/y \rfloor\, y$ 代入 (5.1)：

$$d = ay + b\,(x - \lfloor x/y \rfloor\, y).$$

1. 展开并按 x, y 重新合并同类项：

$$d = b\,x + \big(a - \lfloor x/y \rfloor\, b\big)\, y. \tag{5.2}$$

1. 我们希望返回 $d = Ax + By$。对照 (5.2) 中 x 与 y 的系数，只需取

$$A = b, \qquad B = a - \lfloor x/y \rfloor\, b.$$

1. 这正是算法最后一行 `return (d, b, a - (x div y) * b)` ——公式不是猜出来的，是把 $x \bmod y$ 展开后比对系数得到的。 □

定理 6.4（扩展欧几里得算法的正确性）：对任意 $x \geq y \geq 0$、$x > 0$，`extended-gcd(x,y)` 返回 (d, a, b) 且 $d = \gcd(x, y)$、$d = ax + by$。

证明策略：**对 y 做强归纳**，与定理 6.2 完全同构。第一部分（d 的正确性）直接借用定理 6.1/6.2；第二部分（系数的正确性）用上面的代数推导。

逐步推导：

1. 命题 $Q(y)$：对一切满足 $x \geq y$、$x > 0$ 的 x，`extended-gcd(x,y)` 返回 (d, a, b) 满足 $d = \gcd(x, y)$ 且 $d = ax + by$。
2. **基础情形 $y = 0$**：返回 $(x, 1, 0)$。$d = x = \gcd(x, 0)$ ✔，且 $1 \cdot x + 0 \cdot 0 = x = d$ ✔。$Q(0)$ 成立。
3. **归纳假设**：设 $y > 0$，$Q(z)$ 对所有 $0 \leq z < y$ 成立。
4. **归纳步骤**：算法递归调用 `extended-gcd(y, x mod y)`。令 $r = x \bmod y$，则 $0 \leq r < y$ 且 $y \geq r$、$y > 0$，输入合法，由 $Q(r)$ 得返回 (d, a, b) 满足

$$d = \gcd(y, r) \quad \text{且} \quad d = ay + br.$$

1. **d 的部分**：由定理 6.1，$\gcd(y, r) = \gcd(x, y)$，故 $d = \gcd(x, y)$ ✔。
2. **系数的部分**：由第 4 步的 $d = ay + br$ 与 $r = x - \lfloor x/y \rfloor y$，代入展开得

$$d = ay + b\,(x - \lfloor x/y \rfloor y) = bx + \big(a - \lfloor x/y \rfloor b\big) y.$$

1. 取 $A = b$、$B = a - \lfloor x/y \rfloor b$，则 $d = Ax + By$ ✔，恰是算法返回的后两个分量。
2. 故 $Q(y)$ 成立；由强归纳，$Q(y)$ 对所有 $y \geq 0$ 成立。■

完整手算算例 1：$x = 16,\ y = 10$（官方 Note 6 的例子）

先记录每一步的商 $q = \lfloor x/y \rfloor$：

调用	x	y	$q = \lfloor x/y \rfloor$	$x \bmod y$
1	16	10	1	6
2	10	6	1	4
3	6	4	1	2
4	4	2	2	0
5	2	0	—	基础情形

回溯过程（每一步用 $A = b,\ B = a - qb$）：

返回层	输入 (x, y)	q	递归得到 (d, a, b)	返回 $(d,\ b,\ a - qb)$	验证 $Ax + By$
5（基础）	$(2, 0)$	—	—	$(2,\ 1,\ 0)$	$1 \cdot 2 + 0 \cdot 0 = 2$ ✔
4	$(4, 2)$	2	$(2, 1, 0)$	$(2,\ 0,\ 1 - 2 \cdot 0 = 1)$	$0 \cdot 4 + 1 \cdot 2 = 2$ ✔
3	$(6, 4)$	1	$(2, 0, 1)$	$(2,\ 1,\ 0 - 1 \cdot 1 = -1)$	$1 \cdot 6 - 1 \cdot 4 = 2$ ✔
2	$(10, 6)$	1	$(2, 1, -1)$	$(2,\ -1,\ 1 - 1 \cdot (-1) = 2)$	$-1 \cdot 10 + 2 \cdot 6 = 2$ ✔
1	$(16, 10)$	1	$(2, -1, 2)$	$(2,\ 2,\ -1 - 1 \cdot 2 = -3)$	$2 \cdot 16 - 3 \cdot 10 = 2$ ✔

最终返回 $(d, a, b) = (2, 2, -3)$，即 $2 = 2 \cdot 16 - 3 \cdot 10$。因为 $\gcd(16, 10) = 2 \neq 1$，这里**不能**读出逆元（10 模 16 不可逆）。

完整手算算例 2：$x = 35,\ y = 12$（读出逆元）

调用	x	y	q	$x \bmod y$
1	35	12	2	11
2	12	11	1	1

调用				
3	11	1	11	0
4	1	0	—	基础

回溯：

返回层	输入 (x,y)	q	递归得 (d,a,b)	返回	验证
4（基础）	$(1,0)$	—	—	$(1,\ 1,\ 0)$	$1\cdot1+0\cdot0=1$ ✔
3	$(11,1)$	11	$(1,1,0)$	$(1,\ 0,\ 1-11\cdot0=1)$	$0\cdot11+1\cdot1=1$ ✔
2	$(12,11)$	1	$(1,0,1)$	$(1,\ 1,\ 0-1\cdot1=-1)$	$1\cdot12-1\cdot11=1$ ✔
1	$(35,12)$	2	$(1,1,-1)$	$(1,\ -1,\ 1-2\cdot(-1)=3)$	$-1\cdot35+3\cdot12=1$ ✔

返回 $(d,a,b)=(1,-1,3)$，即 $1=(-1)\cdot35+3\cdot12$。由此读出：$3\cdot12\equiv1\pmod{35}$，所以 $12^{-1}\equiv3\pmod{35}$。（脚本验算 $3\cdot12=36=35+1\equiv1$ ✔）

完整手算算例 3：$x=1071,\ y=462$（大一点的数，读不出逆元）

调用	x	y	q	$x \bmod y$
1	1071	462	2	147
2	462	147	3	21
3	147	21	7	0
4	21	0	—	基础

回溯：$(21,1,0)\to(21,0,1)\to(21,1,-3)\to(21,-3,7)$。

最终 $21=(-3)\cdot1071+7\cdot462$。验算：$7\cdot462=3234$，$3\cdot1071=3213$，$3234-3213=21$ ✔。（脚本验算通过。）$\gcd(1071,462)=21\neq1$，故 462 模 1071 不可逆。

```
扩展欧几里得「手工列等式相减版」（无需递归，更适合手算）
目标：找 x,y 的整数组合等于 gcd。从一个显然的等式出发，不断相减：

  x = 1071, y = 462
  ( 1)*1071 + ( 0)*462 = 1071        <- 等式 A
  ( 0)*1071 + ( 1)*462 =  462        <- 等式 B
  A − 2B: ( 1)*1071 + (−2)*462 =  147    (1071 − 2*462 = 147)
  B − 3*(上式): (−3)*1071 + (7)*462 =  21    (462 − 3*147 = 21)
                ^^^^^^^^^^^^^^^^^^^^ 右边 = 21 = gcd  --> 停

系数变化 (1,−2) 再 (−3,7) 与递归版完全一致；每一步右端就是余数序列。
```

用扩展欧几里得求模逆元（算法与算例）

方法：要求 $x^{-1} \bmod m$（前提 $\gcd(x,m)=1$），运行 `extended-gcd(m, x)` 得到

$$\gcd(m,x)=1=a\,m+b\,x.$$

对两边取模 m：$am\equiv0$，故 $bx\equiv1\pmod{m}$，即

$$\boxed{x^{-1}\equiv b \bmod m}$$

（若 b 为负，加上若干个 m 使其落入 $\{0,\dots,m-1\}$。）

算例 A：求 $12^{-1} \bmod 35$。上面已算出 $1=(-1)\cdot35+3\cdot12$，故 $x^{-1}\equiv3\pmod{35}$。

算例 B：解 $8x\equiv9\pmod{15}$（官方 Note 6 例子）。先求 $8^{-1} \bmod 15$：注意 $2\cdot8=16=15+1\equiv1$，故 $8^{-1}\equiv2$。两边乘 2：$x\equiv18\equiv3\pmod{15}$。验算：$8\cdot3=24=15+9\equiv9$ ✔。**解唯一模 15。**

算例 C：解 $5x\equiv7\pmod{11}$。$\gcd(5,11)=1$，逆元存在。由 $9\cdot5=45=4\cdot11+1$，得 $5^{-1}\equiv9$。故 $x\equiv7\cdot9=63=5\cdot11+8\equiv8\pmod{11}$。验算：$5\cdot8=40=3\cdot11+7\equiv7$ ✔。（脚本验算通过。）

算例 D：$2^{-1} \bmod 9$。$5\cdot2=10=9+1\equiv1$，故 $2^{-1}\equiv5$。验算 $2\cdot5=10\equiv1$ ✔。对照：$2^{-1} \bmod 4$ **不存在**，因为 $\gcd(2,4)=2>1$。

算术基本定理（Fundamental Theorem of Arithmetic）

先证明一个关键引理（官方 Note 6 的 Claim），它是唯一性证明的唯一工具。

引理 6.5（欧几里得引理 / 互质消因子）：设 x,y,z 为正整数且 $\gcd(x,y)=1$。若 $x\mid yz$，则 $x\mid z$。

证明策略：构造性证明 + 直接证明。把「互质」升级为「存在 Bézout 系数」，于是可以把 z 写成两项之和，而这两项都被 x 整除。选这个策略是因为：**「互质」本身只给了一个否定性信息（没有大于 1 的公因子），无法直接用；扩展欧几里得把它变成了肯定性的等式 $1=ax+by$，从此可做代数操作。**

逐步推导：

1. 由 $\gcd(x,y)=1$ 及扩展欧几里得算法（定理 6.4，取 $x \geq y$ 的情形；若 $y > x$ 则调换角色），存在整数 a, b 使

$$ax + by = 1.$$

1. 两边同乘 z：

$$z = axz + byz. \tag{5.3}$$

1. $x \mid axz$：因为 $axz = x \cdot (az)$，而 az 是整数。
2. $x \mid byz$：由假设 $x \mid yz$，而 $byz = b \cdot (yz)$ 是 yz 的整数倍。
3. 由整除线性性（Lecture 0），$x \mid (axz + byz)$。
4. 由式 (5.3)，$axz + byz = z$，故 $x \mid z$。■

【证明机制解说】：这个引理是整个数论里「**把不可操作的条件变成可操作的等式**」的典范。它的全部力量来自 Bézout 系数：一旦 1 被表示成 x, y 的组合，乘上 z 后 z 就被劈成两半，其中一半显然被 x 整除（axz），另一半由假设被 x 整除（byz），于是 z 本身被 x 整除。**再强调一次：Bézout 等式的存在性（扩展欧几里得）是整条推理的前提。**

反例（为什么 $\gcd(x,y)=1$ 不可省）：取 $x=4,\ y=6$（$\gcd=2>1$）、$z=2$。此时 $x \mid yz$ 吗？$yz=12$，$4 \mid 12$ ✔。但 $x \mid z$ 吗？$4 \mid 2$ ✘。引理失效，根源正是 $\gcd(4,6)=2>1$。

算术基本定理（FTA）：每个正整数 $n > 1$ 可表示为质数之积 $n = p_1 p_2 \cdots p_k$，且该表示**不计次序唯一**。

证明策略：分成**存在性**与**唯一性**两部分。

- **存在性**：**强归纳**（Lecture 3 已证，此处回顾思路）。对 n 做强归纳：若 n 本身是质数，取 $k=1$、$p_1=n$；若 n 是合数，写 $n=uv$ 且 $1<u,v<n$，由归纳假设 u, v 各有质数分解，把两个分解拼接起来即得 n 的分解。强归纳是必需的，因为 u, v 都可能远小于 $n-1$。**归纳终止**：规模严格下降且下界为 2，不可能无限下降。
- **唯一性**：反证法/逐项消去法，用引理 6.5。

唯一性证明的逐步推导：

1. 设 n 有两种质数分解

$$n = p_1 p_2 \cdots p_k = q_1 q_2 \cdots q_\ell,$$

其中所有 p_i, q_j 都是质数（各自可以重复）。

1. **不失一般性设 $k \leq \ell$**。（若 $k > \ell$，把两个分解的角色对调即可——这一步只是让后面「左边先处理完」的叙述方便。）
2. 目标：证明 $k = \ell$，且 $\{p_1, \ldots, p_k\}$ 作为多重集合与 $\{q_1, \ldots, q_\ell\}$ 相同。
3. 处理 p_1。因为 $p_1 \mid n = q_1 q_2 \cdots q_\ell$。
4. **分情形**：
5. **情形 (i)**：p_1 等于某个 q_j（$1 \leq j \leq \ell$）。那么把 p_1 与 q_j 配对，两边同除以 p_1，问题规模减 1。
6. **情形 (ii)**：$p_1 \neq q_j$ 对所有 $1 \leq j \leq \ell$。由于 p_1 与每个 q_j 都是**质数**且不相等，它们除 1 外无公因子，故 $\gcd(p_1, q_j) = 1$ 对每个 j 成立。
7. 对情形 (ii) 逐次应用引理 6.5：
8. 由 $p_1 \mid q_1 (q_2 \cdots q_\ell)$ 且 $\gcd(p_1, q_1) = 1$，得 $p_1 \mid q_2 q_3 \cdots q_\ell$；
9. 再对 $\gcd(p_1, q_2) = 1$ 用一次引理，得 $p_1 \mid q_3 \cdots q_\ell$；
10. 如此反复，最终得 $p_1 \mid q_\ell$。
11. 但 q_ℓ 是**质数**，它的大于 1 的正因子只有自身，故 $p_1 = q_\ell$（注意 $p_1 \neq 1$，因为 1 不是质数）。
12. 所以无论如何，p_1 都等于某个 q_j。把这一对消去：两边同除以 p_1（等式仍成立），得到

$$p_2 p_3 \cdots p_k = q_1 \cdots q_{j-1}\, q_{j+1} \cdots q_\ell.$$

1. **重复**上述论证处理 p_2，再处理 p_3，直到 p_k。
2. 全部配对完毕后，左边变成 1，右边剩下 $\ell - k$ 个质数之积：

$$1 = q_{j_1} q_{j_2} \cdots q_{j_{\ell-k}}.$$

1. 每个质数 ≥ 2，故若 $\ell - k \geq 1$，右边 $\geq 2 > 1$，矛盾。因此 $\ell - k = 0$，即 $k = \ell$。
2. 同时，第 4–9 步的配对过程为每个 p_i 指定了一个**唯一**匹配的 q_j，且不同 p_i 匹配不同 q_j（因为被匹配过的 q_j 已从右端移除）。这说明 $\{p_1, \ldots, p_k\}$ 是 $\{q_1, \ldots, q_\ell\}$ 的一个重排。■

【证明机制解说】：唯一性证明的精妙处在于**引理 6.5 让我们能一次「吃掉」一个质数**。如果没有它，我们只能得到「$p_1 \mid q_1 q_2 \cdots q_\ell$」，而「$p_1$ 是质数故必整除某个 q_j」这一步看似显然、实则**正是需要证明的东西**（它就是引理 6.5 的推论）。第 6 步的连用引理把「整除一个乘积」逐步降级为「整除单个质数」，这个过程有时被称为**「逐个剥离」**。另外请注意第 11 步的收尾方式：不是去比较两边的「质数个数」，而是**让一边归约为 1，用「质数 ≥ 2」制造数量矛盾**——这比逐个配对更干净，也自动给出了 $k = \ell$。

具体算例（分解与唯一性）：

n	分解	校验
12	$2\cdot 2\cdot 3$	$4\cdot 3=12$ ✔
360	$2^3\cdot 3^2\cdot 5$	$8\cdot 9\cdot 5=360$ ✔
1071	$3^2\cdot 7\cdot 17$	$9\cdot 7\cdot 17=1071$ ✔
462	$2\cdot 3\cdot 7\cdot 11$	$2\cdot 3=6$，$6\cdot 7=42$，$42\cdot 11=462$ ✔

由后两行立刻可见 $\gcd(1071,462)=3\cdot 7=21$，与欧几里得算法的结果一致 ✔。**这也是「质因数分解求 gcd」与「欧几里得算法求 gcd」两条路的对照——注意前者在 x,y 是大数时反而更慢（分解很难），这正是 RSA 安全性的来源。**

中国剩余定理（Chinese Remainder Theorem, CRT）

第一步：先证 $k=2$ 的情形（官方 Note 6 的 Claim）

定理 6.6（CRT，$k=2$）：设 $\gcd(n_1,n_2)=1$。则对任意整数 a_1,a_2，同余方程组

$$x\equiv a_1 \pmod{n_1},\qquad x\equiv a_2 \pmod{n_2}$$

在模 n_1n_2 下有**唯一解**。

证明策略：**构造性证明（存在性）+ 直接证明（唯一性）**。存在性部分用扩展欧几里得提供的 $1=c_1n_1+c_2n_2$，然后「猜」出解 $x=a_1c_2n_2+a_2c_1n_1$——这个猜测的构造逻辑是：**每一项都设计成「在一个模数下自动消失、在另一个模数下自动变成 a_i」**。唯一性部分用整除论证。

逐步推导（存在性）：

1. 由 $\gcd(n_1,n_2)=1$ 及扩展欧几里得，存在整数 c_1,c_2 使

$$c_1n_1+c_2n_2=1. \tag{5.4}$$

1. **构造候选解**：

$$x:=a_1c_2n_2+a_2c_1n_1.$$

1. **验证 $x\equiv a_1 \pmod{n_1}$**：由 (5.4) 移项得 $c_2n_2=1-c_1n_1$，代入：

$$x=a_1(1-c_1n_1)+a_2c_1n_1=a_1+(a_2-a_1)c_1n_1.$$

1. 右端第二项含因子 n_1，故 $\equiv 0 \pmod{n_1}$；于是 $x\equiv a_1 \pmod{n_1}$ ✔。
2. **验证 $x\equiv a_2 \pmod{n_2}$**：完全对称。由 (5.4) 得 $c_1n_1=1-c_2n_2$，代入：

$$x=a_1c_2n_2+a_2(1-c_2n_2)=a_2+(a_1-a_2)c_2n_2\equiv a_2 \pmod{n_2}. \tag{✔}$$

1. 故 x 是方程组的解。**存在性得证。**

逐步推导（唯一性）：

1. 设 x,x' 都是解，即 $x\equiv x'\equiv a_1 \pmod{n_1}$ 且 $x\equiv x'\equiv a_2 \pmod{n_2}$。
2. 由传递性（Lecture 4 定理 4.0），$x\equiv x' \pmod{n_1}$ 且 $x\equiv x' \pmod{n_2}$，即 $n_1\mid(x-x')$ 且 $n_2\mid(x-x')$。
3. 把 $x-x'$ 写成 n_1t。由 $n_2\mid n_1t$ 与 $\gcd(n_2,n_1)=1$，引理 6.5 给出 $n_2\mid t$，即 $t=n_2s$，故 $x-x'=n_1n_2s$。
4. 因此 $n_1n_2\mid(x-x')$，即 $x\equiv x' \pmod{n_1n_2}$。
5. 换言之，在 $\{0,1,\dots,n_1n_2-1\}$ 内至多有一个解。结合第 6 步的存在性，**恰有一个解**，记为 $x \bmod n_1n_2$。■

【证明机制解说】：存在性构造的设计思想可以用「**指示函数**」来概括：c_2n_2 这个因子对模 n_1 来说是 1（因为 $c_2n_2\equiv 1$），对模 n_2 来说是 0（因为它含因子 n_2）。所以 $a_1c_2n_2$ 项「只在模 n_1 的世界里发声」，而 $a_2c_1n_1$ 项「只在模 n_2 的世界里发声」；把两项相加，声音互不干扰，正好拼出目标。这就是官方 Note 6 所说的「**基向量 (basis vectors)**」视角——把 $k=2$ 推广到 k 个模数，只需为每个方向造一个「在自己方向上为 1、在别的方向上为 0」的向量。

第二步：推广到 k 个模数

定理 6.7（中国剩余定理 CRT，完整形式）：设 $n_1,n_2,\dots,n_k$ **两两互质**（即 $\gcd(n_i,n_j)=1$ 对一切 $i\neq j$），令 $N=\prod_{i=1}^{k}n_i$。则对任意整数 $a_1,\dots,a_k$，同余方程组

$$x\equiv a_i \pmod{n_i}\qquad (i=1,\dots,k)$$

在模 N 下有唯一解。且解可显式构造为

$$x\equiv\sum_{i=1}^{k}a_ib_i \pmod{N},\qquad \text{其中}\quad b_i=M_iy_i,\quad M_i=\frac{N}{n_i},\quad y_i=M_i^{-1}\bmod n_i.$$

证明策略（两种视角）：

- **视角一（迭代 / 归纳）**：先用 $k=2$ 版本解出前两个方程，得到一个唯一的 $a_{12} \bmod n_1n_2$；于是前两个方程被**等价地压缩**成单个方程 $x\equiv a_{12} \pmod{n_1n_2}$。注意 n_1n_2 仍与 $n_3,\dots,n_k$ 全部互质（由两两互质推出），所以问题规模从 k 降到 $k-1$，可以一直迭代到只剩一个方程。这是**对 k 做归纳**的证明。
- **视角二（构造 / 基向量）**：直接为每个 i 构造基向量 b_i，使得

$$b_i \equiv \begin{cases} 1 \pmod{n_i}, \\ 0 \pmod{n_j}\ (j \neq i), \end{cases}$$

然后令 $x = \sum_i a_i b_i$。这是**构造性证明**。

逐步推导（视角二，完整构造性存在性证明）：

1. 固定 i。令 $M_i = N/n_i = \prod_{j \neq i} n_j$。
2. **M_i 与 n_i 互质**：因为 M_i 是除 n_i 外所有 n_j 的乘积，而每个 n_j 都与 n_i 互质，由引理 6.5 反复使用可知 $\gcd(M_i, n_i) = 1$。
3. 因此由定理 5.2，M_i 在模 n_i 下有逆元 $y_i := M_i^{-1} \bmod n_i$，满足 $M_i y_i \equiv 1 \pmod{n_i}$。
4. **定义基向量 $b_i := M_i y_i$**，并验证它的两条性质：
5. **对模 n_i**：$b_i = M_i y_i \equiv 1 \pmod{n_i}$ ✔（依据：逆元定义）。
6. **对模 n_j（$j \neq i$）**：$M_i = \prod_{l \neq i} n_l$ 中**含因子** n_j（因为 $j \neq i$ 且 j 在指标集里），故 $n_j \mid M_i$，从而 $b_i = M_i y_i \equiv 0 \pmod{n_j}$ ✔。
7. **构造解 $x := \sum_{i=1}^{k} a_i b_i$**。（依据：这是「目标向量的线性组合」。）
8. **验证**：固定任意 i。对 x 取模 n_i：

$$x = a_i b_i + \sum_{j \neq i} a_j b_j \equiv a_i \cdot 1 + \sum_{j \neq i} a_j \cdot 0 = a_i \pmod{n_i}.$$

第一个 $\equiv$ 用了定理 5.1（同余式可相加、可乘常数）与步骤 4 的两条性质。故 x 满足第 i 个方程；由于 i 任意，x 满足全部 k 个方程。**存在性得证。** □

逐步推导（唯一性）：

1. 设 x, x' 都是解。对每个 i，$x \equiv a_i \equiv x' \pmod{n_i}$，故 $n_i \mid (x - x')$。
2. 于是 $(x - x')$ 被 $n_1, \ldots, n_k$ **逐一整除**。由于这些 n_i **两两互质**，反复应用引理 6.5 可得 $N = n_1 n_2 \cdots n_k \mid (x - x')$。具体做法是对 $i = 2, \ldots, k$ 归纳：已有 $n_1 \cdots n_{i-1} \mid u$（$u = x - x'$，$i = 2$ 时由 $n_1 \mid u$ 立得），又 $n_i \mid u$ 且 $\gcd(n_1 \cdots n_{i-1}, n_i) = 1$，故 $n_1 \cdots n_i \mid u$。
3. 故 $x \equiv x' \pmod{N}$，即在模 N 意义下解唯一。■

反例（两两互质不可省）：取 $n_1 = 4$，$n_2 = 6$，$\gcd(4, 6) = 2 > 1$。考虑方程组

$$x \equiv 1 \pmod{4}, \qquad x \equiv 2 \pmod{6}.$$

若 $x \equiv 1 \pmod{4}$ 则 x 是奇数；若 $x \equiv 2 \pmod{6}$ 则 x 是偶数。矛盾，**无解**。（脚本穷举 $0 \le x < 12$（$= \operatorname{lcm}(4, 6)$）确认无解 ✔。）这说明 CRT 的「两两互质」不是装饰性条件——它既保证解存在，也保证解唯一。

完整手算算例：孙子问题 $x \equiv 2 \pmod{3}$，$x \equiv 3 \pmod{5}$，$x \equiv 2 \pmod{7}$

这里 $n_1 = 3$，$n_2 = 5$，$n_3 = 7$ 两两互质，$N = 3 \cdot 5 \cdot 7 = 105$。

第 1 步：算各 M_i 与逆元 y_i

i	n_i	a_i	$M_i = N/n_i$	$M_i \bmod n_i$	$y_i = M_i^{-1} \bmod n_i$	$b_i = M_i y_i$
1	3	2	35	$35 \bmod 3 = 2$	2（因 $2 \cdot 2 = 4 \equiv 1$）	$35 \cdot 2 = 70$
2	5	3	21	$21 \bmod 5 = 1$	1	$21 \cdot 1 = 21$
3	7	2	15	$15 \bmod 7 = 1$	1	$15 \cdot 1 = 15$

第 2 步：验证基向量性质

```
b1 = 70:  70 mod 3 = 1  ✔   70 mod 5 = 0  ✔   70 mod 7 = 0  ✔
b2 = 21:  21 mod 3 = 0  ✔   21 mod 5 = 1  ✔   21 mod 7 = 0  ✔
b3 = 15:  15 mod 3 = 0  ✔   15 mod 5 = 0  ✔   15 mod 7 = 1  ✔

（这正是「第 i 个方向上为 1，其余方向为 0」的坐标基）

解方程组的结构：
   x ≡ a1*b1 + a2*b2 + a3*b3  (mod 105)
     = 2*70  + 3*21  + 2*15
     = 140   + 63    + 30
     = 233
   x ≡ 233 mod 105 = 233 − 210 = 23
```

第 3 步：验证解

$$23 \bmod 3 = 2 \text{ ✔} \qquad 23 \bmod 5 = 3 \text{ ✔} \qquad 23 \bmod 7 = 2 \text{ ✔}$$

（$23 = 7 \cdot 3 + 2$；$23 = 4 \cdot 5 + 3$；$23 = 3 \cdot 7 + 2$。）

第 4 步：穷举交叉验证（脚本对 $0 \le x < 105$ 逐一检查，只有 $x = 23$ 满足全部三个条件 ✔）。通解为 $x = 23 + 105t$（$t \in \mathbb{Z}$）。

算例 2（$k = 2$）：解 $x \equiv 1 \pmod{4}$、$x \equiv 2 \pmod{5}$。$\gcd(4, 5) = 1$，$N = 20$。

- $4^{-1} \bmod 5$：$4 \cdot 4 = 16 \equiv 1 \pmod{5}$，故 $c_1 = 4$；$5^{-1} \bmod 4$：$5 \equiv 1 \pmod{4}$，故 $c_2 = 1$。
- 按定理 6.6 的构造 $x = a_1 c_2 n_2 + a_2 c_1 n_1 = 1 \cdot 1 \cdot 5 + 2 \cdot 4 \cdot 4 = 5 + 32 = 37$。

- $x \bmod 20 = 17$。验证：$17 \bmod 4 = 1$ ✔，$17 \bmod 5 = 2$ ✔。

算例 3（用 CRT 加速大数幂运算）：想算 $3^{100} \bmod 35$。因 $35 = 5 \cdot 7$（互质），先分别在模 5 与模 7 下用费马小定理：

- 模 5：$3^4 \equiv 1$，$100 \bmod 4 = 0$，故 $3^{100} \equiv 1 \pmod 5$。
- 模 7：$3^6 \equiv 1$，$100 \bmod 6 = 4$，故 $3^{100} \equiv 3^4 = 81 \equiv 4 \pmod 7$。
- 现在解 $x \equiv 1 \pmod 5$、$x \equiv 4 \pmod 7$：$N = 35$，$M_1 = 7$，$7^{-1} \bmod 5 = 3$（$7 \cdot 3 = 21 \equiv 1$），$b_1 = 21$；$M_2 = 5$，$5^{-1} \bmod 7 = 3$（$5 \cdot 3 = 15 \equiv 1$），$b_2 = 15$。
- $x = 1 \cdot 21 + 4 \cdot 15 = 21 + 60 = 81 \equiv 81 - 70 = 11 \pmod{35}$。
- 验证：$11 \bmod 5 = 1$ ✔，$11 \bmod 7 = 4$ ✔。**答案 $3^{100} \equiv 11 \pmod{35}$。**（脚本直接算 $3^{100} \bmod 35 = 11$ ✔）

这个技巧的意义：CRT 让你把一个「模大合数」的难题拆成几个「模小质数」的简单题，做完再拼回去。这既是 Lecture 8 里「多项式求值可以并行化」的思想源头，也是 RSA 实现中「用 CRT 加速解密（把模 N 的运算拆成模 p 和模 q 的两个运算，速度提升约 4 倍）」的原理。

费马小定理（Fermat's Little Theorem, FLT）

定理 6.8（费马小定理）：设 p 是质数，$a \in \{1, 2, \ldots, p-1\}$。则

$$a^{p-1} \equiv 1 \pmod p.$$

证明策略：关键引理（乘法是排列）+ 双计数式的乘积比较。先把 Lecture 4 定理 5.2 的「乘以 x 是 $\mathbb{Z}_m$ 上的双射」这一结论搬到 $S = \{1, 2, \ldots, p-1\}$ 上，得到「$a \cdot 1, a \cdot 2, \ldots, a \cdot (p-1)$ 是 S 的一个排列」；然后**用两种方式计算同一个乘积**：直接算得 $(p-1)!$，用排列算得 $a^{p-1}(p-1)!$，两者必须相等；最后两边乘 $(p-1)!$ 的逆元消掉它。这个策略之所以有效，是因为**「集合相同」这一信息比「逐一对应」更强，能直接给出乘积等式。**

引理 6.9（关键引理）：设 p 是质数，$a \in \{1, \ldots, p-1\}$。则集合

$$S' = \{\, a \cdot 1 \bmod p,\ a \cdot 2 \bmod p,\ \ldots,\ a \cdot (p-1) \bmod p \,\}$$

与 $S = \{1, 2, \ldots, p-1\}$ **完全相同**（只是一个重排）。

逐步推导（引理 6.9）：

1. 因为 p 是质数，$a \in \{1, \ldots, p-1\}$ 意味着 $p \nmid a$，即 $\gcd(a, p) = 1$。（依据：p 的因子只有 1 与 p。）
2. 由 Lecture 4 定理 5.2 的证明（其中的「两两不同余」断言），序列 $0, a, 2a, \ldots, (p-1)a$ 模 p **两两不同余**。
3. 特别地，$a, 2a, \ldots, (p-1)a$ 这 $p-1$ 项模 p 也两两不同余。
4. **没有一项 $\equiv 0$**：若 $ka \equiv 0 \pmod p$（$1 \le k \le p-1$），则 $p \mid ka$；由 $\gcd(a, p) = 1$ 与引理 6.5 得 $p \mid k$，但 $1 \le k \le p-1 < p$，矛盾。
5. 于是这 $p-1$ 个余数**互不相同**，且**全部落在 $S = \{1, \ldots, p-1\}$ 内**（既非 0，取值又在 $0..p-1$ 之间）。
6. S 只有 $p-1$ 个元素，而我们有 $p-1$ 个互不相同且落在 S 内的余数——由鸽笼原理（Lecture 2），它们**恰好取遍 S 的每个元素一次**。
7. 故 $S' = S$，$\{a \bmod p,\ 2a \bmod p, \ldots, (p-1)a \bmod p\}$ 是 $\{1, 2, \ldots, p-1\}$ 的一个**排列 (permutation)**。■

逐步推导（定理 6.8）：

1. 记 $S = \{1, 2, \ldots, p-1\}$，$S' = \{a \cdot k \bmod p : k \in S\}$。由引理 6.9，$S' = S$。
2. **方法一**：把 S 的全部元素相乘，按定义就是阶乘：

$$\prod_{s \in S} s = 1 \cdot 2 \cdots (p-1) = (p-1)!. \tag{5.5}$$

1. **方法二**：把 S' 的全部元素相乘。S' 的元素依次是 $a \cdot k \bmod p$（$k = 1, \ldots, p-1$），故

$$\prod_{s' \in S'} s' \equiv \prod_{k=1}^{p-1} (ak) = a^{p-1} \cdot \prod_{k=1}^{p-1} k = a^{p-1}(p-1)! \pmod p. \tag{5.6}$$

（依据：定理 5.1，可以把每个因子先模 p 再相乘；a 出现 $p-1$ 次提出来。）

1. 因为 $S = S'$ **是同一个集合**，两个乘积是同一个整数（在模 p 下），于是

$$(p-1)! \equiv a^{p-1}(p-1)! \pmod p. \tag{5.7}$$

1. **消去 $(p-1)!$**：因为 p 是质数，$1, 2, \ldots, p-1$ 每一个都与 p 互质。由引理 6.5 反复应用，$\gcd((p-1)!, p) = 1$（任何 p 的质因子若整除 $(p-1)!$，就必须整除某个 $k \le p-1$，但那些 k 都小于 p 且非零，矛盾）。
2. 由 Lecture 4 定理 5.2，$(p-1)!$ 在模 p 下可逆；两边同乘其逆元（也就是用消去律，推论 4.3）：

$$a^{p-1} \equiv 1 \pmod p. \tag{5.8}$$

■

【证明机制解说】：这个证明最漂亮的地方是**用两种方式数同一个量**（乘积的两种算法），这在组合数学里叫**双计数 (double counting)**，本课程 Lecture 16 会专门讲这个技巧。这里「两种方式」分别是：－ 按 S 的定义直接乘 $\Rightarrow (p-1)!$；－ 按 $S' = S$ 把每个元素写成 ak 的形式再乘 $\Rightarrow a^{p-1}(p-1)!$。

由于两式的对象是**同一个集合的乘积**，它们必须相等。**整个定理的力量全部来自引理 6.9 的「S' 就是 S 本身」**——如果只有「S' 与 S 一一对应」而没有「相等」，这个乘积比较就不成立。

第 6 步的消去也值得细看：它又一次用到了「质数 ⇒ 一切 $1 \le k < p$ 都可逆」，这是 Lecture 4 定理 5.2 与 Lecture 5 引理 6.5 的合体应用。

FLT 的两个必要条件的反例

(1) p 必须是质数。 取 $m = 4$、$a = 2$。$m - 1 = 3$，而

$$2^3 = 8 = 2 \cdot 4 \equiv 0 \pmod 4 \neq 1.$$

再看 $m = 6$、$a = 2$：$2^5 = 32 = 5 \cdot 6 + 2 \equiv 2 \neq 1 \pmod 6$（这里 $\gcd(2, 6) = 2 > 1$）。更值得注意的是 $m = 8,\ a = 3$（此时 $\gcd(3, 8) = 1$，a 是可逆的）：$3^7 = 2187 \equiv 3 \pmod 8$（因为 $3^2 = 9 \equiv 1$，故 $3^{2k} \equiv 1$，$3^7 = 3^6 \cdot 3 \equiv 3$）。仍然是 $3 \neq 1$。**这说明即使 a 可逆，合数模数下 FLT 依然失效。**

(2) a 必须与 p 互质。 在质数模数下，$1 \le a \le p - 1$ 已自动保证 $\gcd(a, p) = 1$。但若允许 a 是 p 的倍数（如 $a \equiv 0$），结论显然变成 $0^{p-1} \equiv 0 \neq 1$。**所以 FLT 的完整前提是：p 质数 且 $\gcd(a, p) = 1$。**（这正是「等价形式 $a^p \equiv a \pmod p$ 对任意 a 成立」——当 $p \mid a$ 时两边都是 0，所以那个形式不需要互质条件；考试中若题目没给 $\gcd$ 条件，请用 $a^p \equiv a$ 的形式。）

推论 6.10（FLT 求逆元）：设 p 是质数，$a \in \{1, \dots, p - 1\}$。则

$$a^{-1} \equiv a^{p-2} \pmod p.$$

证明：由 FLT，$a^{p-1} = a \cdot a^{p-2} \equiv 1 \pmod p$。按逆元定义（Lecture 4），$a^{p-2}$ 就是 a 的乘法逆元；由逆元唯一性，$a^{-1} \equiv a^{p-2} \pmod p$。■

推论 6.11（幂的周期律）：设 p 质数、$\gcd(a, p) = 1$，则对任意整数 $k \ge 0$，

$$a^k \equiv a^{\,k \bmod (p-1)} \pmod p.$$

证明：写 $k = q(p - 1) + r$（$0 \le r < p - 1$）。则 $a^k = (a^{p-1})^q \cdot a^r \equiv 1^q \cdot a^r = a^r \pmod p$。■

算例（FLT 计算逆元与幂）：

- $p = 7$，$a = 3$：$3^{-1} \equiv 3^5 \pmod 7$。算 $3^5 = 243 = 34 \cdot 7 + 5 \equiv 5$。对照 Lecture 4 表里 $3^{-1} = 5$ ✔。
- $p = 11$，$a = 2$：$2^{-1} \equiv 2^9 \pmod{11}$。$2^{10} \equiv 1$，故 $2^9 \equiv 2^{10} \cdot 2^{-1} \equiv 1 \cdot 6 = 6$（$2 \cdot 6 = 12 \equiv 1$）。故 $2^{-1} \equiv 6$ ✔。
- $p = 11$，$a = 7$：求 $7^{203} \bmod 11$。$203 \bmod 10 = 3$，故 $7^{203} \equiv 7^3 = 343 = 31 \cdot 11 + 2 \equiv 2 \pmod{11}$ ✔。（与 Lecture 4 思考题 Q1 的结果一致。）
- $p = 13$，$a = 3$：$3^{12} = 531441$，$531441 \bmod 13 = 1$ ✔（脚本验算）。

与经典问题的联系

（一）RSA 公钥密码（Lecture 6）

RSA 的完整数据流正是本讲三条主线的合体：

1. Bob 选两个大质数 p, q，令 $N = pq$，选 e 与 $(p-1)(q-1)$ 互质。**私钥** $d \equiv e^{-1} \bmod (p-1)(q-1)$ 由**扩展欧几里得算法**高效算出（本讲第 1 节）。
2. Alice 发送 $E(x) \equiv x^e \bmod N$；Bob 解密 $D(y) \equiv y^d \bmod N$。两次幂运算都用 Lecture 4 的**快速幂**，代价 $O(\log N)$ 次乘法。
3. **解密正确性** $x^{ed} \equiv x \pmod N$ 的证明依赖**费马小定理**：由 $ed \equiv 1 \pmod{(p-1)(q-1)}$ 写成 $ed = 1 + k(p-1)(q-1)$，则
4. 若 $p \nmid x$，FLT 给 $x^{p-1} \equiv 1$，故 $x^{ed} = x\,(x^{p-1})^{k(q-1)} \equiv x \pmod p$；
5. 若 $p \mid x$，两边都是 $0 \equiv 0 \pmod p$。对 q 同理，最后由 CRT 的**唯一性**把「模 p 相等」与「模 q 相等」合成「模 $pq = N$ 相等」。
6. **质数生成**用费马小定理的推广（Miller–Rabin 素性测试）快速筛出大质数。

（二）大数运算的并行化 / 加速（CRT 的工程价值）

RSA 的 C 实现（如 OpenSSL）普遍使用 CRT 加速：解密时不算 $y^d \bmod N$，而是分别算 $y^{d \bmod (p-1)} \bmod p$ 与 $y^{d \bmod (q-1)} \bmod q$，再用 CRT 把两个结果拼起来。因为两个子运算都在 $N/2$ 位（数量级）的数上进行，总代价约为原来的 $1/4$。**这正是本讲 CRT 构造式在工业代码里的直接落地。**

（三）哈希与一致性哈希

把哈希值对 m 取模分桶时，若 m 是合数（如 2^k），低位比特的分布会暴露规律；选质数 m 则能借助本讲 $\mathbb{Z}_p$ 结构的「整齐性」（乘法表每行是排列）获得更好的散列性质。

（四）快速幂 + FLT 做素性测试

若 n 是质数，则对一切 a 有 $a^{n-1} \equiv 1 \pmod n$。反之，若发现某个 a 使 $a^{n-1} \not\equiv 1$，则 n **必定**是合数（这用到了逆否命题，Lecture 2）。这就是 Miller–Rabin 素性测试的起点——**注意它只是「合数的证据」，不是「质数的证明」**（存在 Carmichael 数，如 $561 = 3 \cdot 11 \cdot 17$，能骗过所有与它互质的 a）。这条「用随机测试换确定性结论」的路线，是 Lecture 23 集中不等式要定量分析的对象。

与其他讲次的关联

- **承接 Lecture 0（直接证明与整除性）**：定理 6.1 的两个方向都只用「$d \mid u \wedge d \mid v \Rightarrow d \mid (u \pm v)$」这一条；引理 6.5 的最后一步「$x \mid (axz + byz)$」用的也是它。整除线性性是本讲最频繁调用的工具。
- **承接 Lecture 2（鸽笼原理、有限集上单射即满射）**：引理 6.9 的第 6 步（$p - 1$ 个互异余数落在 $p - 1$ 个格子里 ⇒ 恰好铺满）就是鸽笼原理的应用；它直接来自 Lecture 4 定理 5.2 的同一技术。
- **承接 Lecture 3（强归纳）**：定理 6.2（gcd 正确性）与定理 6.4（扩展 gcd 正确性）都对第二个参数做**强归纳**；算术基本定理的存在性部分也是对 n 做强归纳。三处都体现了 Lecture 3 强调的「归纳变量必须严格下降」这一要点。
- **承接 Lecture 4（模运算与逆元）**：本讲几乎每一步都在用 Lecture 4 的三件工具：定理 5.1（同余可加可乘）、定理 5.2（$\gcd = 1 \Leftrightarrow$ 可逆）、消去律（推论 4.3）。**CRT 的构造本质上就是「用逆元造基向量」，FLT 的证明本质上是「用双射比较乘积」。** 上一讲欠下的两笔账（欧几里得引理、逆元的算法）在本讲第 1 节全部还清。

- **通向 Lecture 6（RSA）**：三条线汇聚——扩展欧几里得算 d、快速幂算 x^e 与 y^d、FLT + CRT 证解密正确性。
- **通向 Lecture 7–8（多项式、秘密共享与纠错码）**：把 $\mathbb{Z}_p$（p 为质数）推广为有限域 $\mathrm{GF}(q)$ 后，多项式插值（Lecture 7 的 Lagrange 插值）与 Reed–Solomon 码（Lecture 8）才有意义；CRT 的「坐标视角」则是 Lecture 8 中「用多个模数并行编码」的原型。
- **通向 Lecture 12（可数性）**：算术基本定理给出的「质数是整数的唯一原子」这一图景，在 Lecture 12 证明「质数有无穷多个」以及「代数数可数」时会被再次召唤。
- **通向 Lecture 14、16（计数与组合证明）**：定理 6.8 的证明就是一次**双计数**，而 Lecture 16 会用同样的手法证明一批组合恒等式（如 Vandermonde 恒等式）。
- **通向 Lecture 23（集中不等式 / 大数定律）**：Miller–Rabin 这类随机化素性测试是「随机算法的错误概率随重复次数指数衰减」的第一个实例，Lecture 23 的 Chernoff 界会给出定量的分析工具。

关键要点

1. **欧几里得算法的不变量**：$\gcd(x, y) = \gcd(y, x \bmod y)$。证明方式不是比较「最大数」，而是证明**两个公约数集合相同**（双向包含）。递归深度 $O(\log x)$，因为**每两次调用第一个参数至少减半**（分 $y \le x/2$ 与 $y > x/2$ 两种情形）。
2. **扩展欧几里得 = gcd + Bézout 系数**，核心回代公式 $A = b,\ B = a - \lfloor x/y \rfloor b$。它的推导只用了恒等式 $x \bmod y = x - \lfloor x/y \rfloor y$，**不是猜出来的**。正确性对第二个参数做强归纳。
3. **Bézout 等式是数论证明的万能钥匙**：引理 6.5（$x \mid yz$ 且 $\gcd(x, y) = 1 \Rightarrow x \mid z$）由它推出，而引理 6.5 又支撑了算术基本定理的唯一性、CRT 的唯一性、FLT 的消去步骤。**推论链：扩展欧几里得 → Bézout → 引理 6.5 → FTA/CRT/FLT。**
4. **模逆元的算法**：跑 `extended-gcd(m,x)` 得 $1 = am + bx$，则 $x^{-1} \equiv b \pmod m$（负数要加上若干 m）。质数模数下还有捷径 $a^{-1} \equiv a^{p-2} \pmod p$。
5. **CRT 的坐标视角**：$b_i = M_i(M_i^{-1} \bmod n_i)$ 是「第 i 个坐标轴上的基向量」（$b_i \equiv 1 \pmod{n_i}$，$b_i \equiv 0 \pmod{n_j}$），解 $x = \sum_i a_i b_i$。**存在性靠构造，唯一性靠「$N \mid x - x'$」**。两两互质不可省（$n_1 = 4, n_2 = 6$ 时可能无解）。
6. **FLT 的条件必须记全**：p **质数** 且 $\gcd(a, p) = 1$，结论 $a^{p-1} \equiv 1 \pmod p$（等价形式 $a^p \equiv a$ 对任意 a 成立）。对合数失效：$m = 4, a = 2$ 时 $2^3 \equiv 0 \neq 1$。证明的核心是「$a \cdot 1, \ldots, a \cdot (p-1)$ 是 $\{1, \ldots, p-1\}$ 的排列」+ 双计数比较乘积 + 用 $(p-1)!$ 的逆元消去。

常见误区与注意事项

1. **把「公约数集合相同」只证一个方向**。定理 6.1 的证明**必须两个方向都写**：只证「$d \mid x, y \Rightarrow d \mid y, x \bmod y$」只说明新集合包含旧集合（反向包含未证），无法推出两个集合的最大元相等。
2. **认为「一次递归调用就减半」**。反例 $x = 1000, y = 999$：一次调用后第一个参数是 999，几乎没减。**必须论证「两次调用减半」**，并且要用到 $y > x/2 \Rightarrow x \bmod y = x - y$ 这一步。
3. **归纳正确性时忘记验证递归调用的输入合法性**。定理 6.2 第 6 步必须检查「$y \ge x \bmod y$ 且 $y > 0$」才能让归纳假设落地。漏掉这一步，证明就断了。
4. **把 Bézout 等式当成同余式**。$d = ax + by$ 是**普通的整数等式**，a, b 可以是负数（如 $1 = -1 \cdot 35 + 3 \cdot 12$）。不要写出「$d \equiv ax + by \pmod m$」这类混淆。
5. **扩展欧几里得的回代公式记错顺序**。返回的是 $(d,\ b,\ a - \lfloor x/y \rfloor b)$，**第一个系数换成原来的 b**、第二个系数换成 $a - qb$。混淆 a 与 b 的位置是最常见的实现 bug。
6. **FLT 条件写漏**。写成「对任意 m 与 a，$a^{m-1} \equiv 1 \pmod m$」是严重错误。正确版本：p **质数**、$\gcd(a, p) = 1$。反例：$m = 4, a = 2$ 时 $2^3 \equiv 0$；$m = 8, a = 3$ 时 $3^7 \equiv 3$（即使 a 可逆也不成立，因为 m 不是质数）。
7. **CRT 漏掉「两两互质」**。CRT 的前提是**两两互质 (pairwise coprime)**，比「$\gcd(n_1 n_2 \cdots n_{k-1}, n_k) = 1$」更强也更常用。反例：$n_1 = 4, n_2 = 6$ 时 $x \equiv 1 \pmod 4$ 与 $x \equiv 2 \pmod 6$ 无解。
8. **CRT 的两个表述漏洞**：一是漏掉「两两互质」前提（反例：$n_1 = 4, n_2 = 6$ 时 $x \equiv 1 \pmod 4$ 与 $x \equiv 2 \pmod 6$ 无解）；二是把唯一性说成「解唯一」而非「**模 N 唯一**」——方程组实际有无穷多解 $x = x_0 + Nt$，唯一的只是它在模 N 下的剩余类。
9. **取整方向与「唯一」的含义**：$x \bmod y = x - \lfloor x/y \rfloor y$ 必须是**向下取整**（$x = 7, y = 2$ 时 $\lfloor 7/2 \rfloor = 3$，$7 - 3 \cdot 2 = 1$ ✔）。另外算术基本定理的「唯一」指**多重集合相同**：$12 = 2 \cdot 2 \cdot 3$ 与 $2 \cdot 3 \cdot 2$ 是同一个分解（重排），而 $12 = 2 \cdot 6$ 根本不合法（6 不是质数）。

思考题（带答案）

Q1.（计算题） 用扩展欧几里得算法求 $\gcd(240, 46)$，写出完整的商序列与回溯表，给出 a, b 使 $a \cdot 240 + b \cdot 46 = \gcd(240, 46)$，并由此求出 $46^{-1} \bmod 240$（若不存在请说明理由）。

▸ 答案

带余除法链：

调用	x	y	$q=\lfloor x/y\rfloor$	$x \bmod y$
1	240	46	5	10
2	46	10	4	6
3	10	6	1	4
4	6	4	1	2
5	4	2	2	0
6	2	0	—	基础

校验：$240=5\cdot46+10$ ✔；$46=4\cdot10+6$ ✔；$10=1\cdot6+4$ ✔；$6=1\cdot4+2$ ✔；$4=2\cdot2+0$ ✔。故 $\gcd(240,46)=2$。

回溯表（公式：返回 $(d,\ b,\ a-qb)$）：

层	输入 (x,y)	q	递归得 (d,a,b)	返回 (d,A,B)	验证 $Ax+By$
6（基础）	$(2,0)$	—	—	$(2,1,0)$	$1\cdot2=2$ ✔
5	$(4,2)$	2	$(2,1,0)$	$(2,\ 0,\ 1-2\cdot0=1)$	$0\cdot4+1\cdot2=2$ ✔
4	$(6,4)$	1	$(2,0,1)$	$(2,\ 1,\ 0-1\cdot1=-1)$	$1\cdot6-1\cdot4=2$ ✔
3	$(10,6)$	1	$(2,1,-1)$	$(2,\ -1,\ 1-1\cdot(-1)=2)$	$-1\cdot10+2\cdot6=2$ ✔
2	$(46,10)$	4	$(2,-1,2)$	$(2,\ 2,\ -1-4\cdot2=-9)$	$2\cdot46-9\cdot10=2$ ✔
1	$(240,46)$	5	$(2,2,-9)$	$(2,\ -9,\ 2-5\cdot(-9)=47)$	$-9\cdot240+47\cdot46=2$ ✔

最终结果：$d=2$，$a=-9$，$b=47$，即

$$2=(-9)\cdot240+47\cdot46.$$

验算：$47\cdot46=2162$，$9\cdot240=2160$，$2162-2160=2$ ✔。

求 $46^{-1} \bmod 240$：因为 $\gcd(240,46)=2\neq1$，**46 模 240 没有乘法逆元**。（这与 Lecture 4 的必要性定理一致：$d=2>1$ 的直接推论。）注意不能因为「$b=47$ 算出来了」就误以为它是逆元——$47\cdot46=2162\equiv2\pmod{240}$，得到的是 2 而不是 1。

顺带可以读出：由 $2=-9\cdot240+47\cdot46$，两边除以 2 得 $1=(-9)\cdot120+47\cdot23$，故 $23^{-1}\equiv47\pmod{120}$。验算 $23\cdot47=1081=9\cdot120+1$ ✔。

Q2.（证明题） 设 x,y 为正整数，$g=\gcd(x,y)$，$L=\operatorname{lcm}(x,y)$。证明 $gL=xy$。

▸ **答案**

证明策略：用算术基本定理（本讲定理）把两边都写成质数幂的形式，逐质数比对指数。也可以只用整除论证，但用 FTA 最清晰。

逐步推导（FTA 视角）：

1. 设 x, y 的质因数分解为

$$x = \prod_p p^{\alpha_p}, \qquad y = \prod_p p^{\beta_p},$$

其中 p 遍历所有质数，指数 $\alpha_p, \beta_p \geq 0$（不在 x 中出现的质数取指数 0）。由 FTA，这种表示唯一。

1. 由 $\gcd$ 与 lcm 的定义（取每个质数的**最小/最大**指数）：

$$g = \gcd(x, y) = \prod_p p^{\min(\alpha_p, \beta_p)}, \qquad L = \operatorname{lcm}(x, y) = \prod_p p^{\max(\alpha_p, \beta_p)}.$$

1. 对每个质数 p 计算 gL 中 p 的指数：

$$\min(\alpha_p, \beta_p) + \max(\alpha_p, \beta_p) = \alpha_p + \beta_p.$$

（依据：两数中较小者加较大者等于两数之和——对任意两个实数都成立。）

1. 而 xy 中 p 的指数是 $\alpha_p + \beta_p$。
2. 故 gL 与 xy 的质因数分解**逐质数指数相同**，由 FTA 的唯一性得

$$gL = xy. \qquad \blacksquare$$

逐步推导（只用整除的独立证明，作为交叉验证）：

1. 记 $x = gx'$、$y = gy'$，则 $\gcd(x', y') = 1$。（依据：若 x', y' 有公因子 $d > 1$，则 gd 也是 x, y 的公因子，与 g 的最大性矛盾。）
2. **断言** $L = gx'y'$。验证 L 是公倍数：$L/x = gx'y'/(gx') = y'$ 是整数 ✔；$L/y = gx'y'/(gy') = x'$ 是整数 ✔。
3. 再验证最小性：设 M 是 x, y 的任一公倍数。则 $M = xs = gx's$，又 $M = yt = gy't$。故 $gx's = gy't$，即 $x's = y't$。
4. 由 $\gcd(x', y') = 1$ 与 $y' \mid x's$，用引理 6.5 得 $y' \mid s$，写 $s = y'u$。于是 $M = gx'y'u = Lu$，故 $L \mid M$。
5. 所以 L 是「整除一切公倍数」的公倍数，即最小公倍数（任何更小的公倍数 M 都会被 L 整除，故 $M \geq L$）。断言成立。
6. 于是 $gL = g \cdot gx'y' = (gx')(gy') = xy$。$\blacksquare$

算例校验：$x = 1071 = 3^2 \cdot 7 \cdot 17$，$y = 462 = 2 \cdot 3 \cdot 7 \cdot 11$。$g = 3 \cdot 7 = 21$。$L = 2 \cdot 3^2 \cdot 7 \cdot 11 \cdot 17 = 2 \cdot 9 \cdot 7 \cdot 11 \cdot 17 = 23562$。验证 $gL = 21 \cdot 23562 = 494802$，而 $xy = 1071 \cdot 462 = 494802$ ✔。

Q3.（概念/构造题） 解同余方程组 $x \equiv 1 \pmod 3$、$x \equiv 4 \pmod 5$、$x \equiv 5 \pmod 7$。要求给出完整的 CRT 构造过程（列出每个基向量），用穷举验算你的答案，并说明在 $[0, 104]$ 内解是否唯一。

▸ 答案

$n_1=3,\ n_2=5,\ n_3=7$，两两互质，$N=105$。目标 $a=(1,4,5)$。

第 1 步：算基向量

i	n_i	a_i	$M_i=N/n_i$	$M_i \bmod n_i$	$y_i=M_i^{-1} \bmod n_i$	$b_i=M_iy_i$
1	3	1	35	$35 \bmod 3=2$	2（$2\cdot 2=4\equiv 1$）	70
2	5	4	21	$21 \bmod 5=1$	1	21
3	7	5	15	$15 \bmod 7=1$	1	15

第 2 步：验证基向量

$b_1=70$：$70 \bmod 3=1$ ✔，$70 \bmod 5=0$ ✔，$70 \bmod 7=0$ ✔。$b_2=21$：$21 \bmod 3=0$ ✔，$21 \bmod 5=1$ ✔，$21 \bmod 7=0$ ✔。$b_3=15$：$15 \bmod 3=0$ ✔，$15 \bmod 5=0$ ✔，$15 \bmod 7=1$ ✔。

第 3 步：组装解

$$x\equiv\sum_i a_ib_i=1\cdot 70+4\cdot 21+5\cdot 15=70+84+75=229 \pmod{105}.$$

$229=2\cdot 105+19$，故 $x\equiv 19 \pmod{105}$。

第 4 步：验证

- $19 \bmod 3=1$ ✔（$19=6\cdot 3+1$）
- $19 \bmod 5=4$ ✔（$19=3\cdot 5+4$）
- $19 \bmod 7=5$ ✔（$19=2\cdot 7+5$）

穷举交叉验证：脚本对 $0\le x<105$ 逐一检查三个条件，唯一命中的是 $x=19$ ✔。

唯一性说明：由 CRT 的唯一性部分，在 $\{0,1,\dots,104\}$ 内**恰有一个**解（就是 19）。在全体整数范围内解有无穷多个，形如 $x=19+105t$（$t\in\mathbb{Z}$）；它们构成**同一个模 105 剩余类**，所以说「模 N 唯一」。**注意唯一性依赖两两互质**：这里 $3,5,7$ 两两互质，唯一性成立；若换成 $n_1=4,n_2=6$（$\gcd=2$），唯一性就可能失效甚至无解。

额外观察：由于每个 b_i 都是 $M_i=N/n_i$ 的倍数，而 a_i 只影响第 i 个坐标，改变 a_1 从 1 到 2 只会让解增加 $b_1=70$（模 105 下即 70）。这与「坐标基向量」的直觉完全一致：**调整某一维坐标，只在那一维上产生位移。**

Lecture 6: RSA（RSA 公钥密码）

概述

本讲把前五讲积累的模运算工具箱——欧几里得算法、费马小定理 (Fermat's Little Theorem)、中国剩余定理 (Chinese Remainder Theorem)——一次性投入一个真实且有巨大历史影响的工程问题：**如何让两个从未见过面的人在不安全信道上安全通信**。答案是 RSA 公钥密码体制 (public-key cryptosystem)，由 Rivest、Shamir、Adleman 于 1970 年代提出。

本讲的核心是一个**正确性定理**：$D(E(x))\equiv x \pmod N$。它的证明出奇地短，但用到了全部关键零件：$ed\equiv 1 \pmod{(p-1)(q-1)}$ 的分解、费马小定理、以及「分别验证模 p 与模 q、再合并」这一 CRT 式思路。证明中最需要小心的是 $\gcd(x,N)\neq 1$ 的边界情形——此时费马小定理的前提不成立，必须单独处理。

本讲还讨论**为什么安全**（依赖大整数分解的困难性，且这不是一个已被证明的定理，而是一个被广泛相信的假设）以及**为什么教科书式 RSA 直接拿来用是不安全的**（确定性加密 + 可乘性）。

核心概念的直观解释

密码学的基本舞台

- **定义**：设 Alice 想在不安全信道（如互联网）上把消息 x（写作比特串，视作整数）发送给 Bob。Alice 对 x 施加**加密函数 (encryption function)** E，把 $E(x)$ 发出去；Bob 收到后施加**解密函数 (decryption function)** D，恢复 x，即要求 $D(E(x))=x$。信道上还坐着一个窃听者 Eve（"sniffer"），她能看到 $E(x)$。
- **直观解释（"它是什么意思？"）**：把消息想象成写在一张明信片上的内容。Eve 是邮局里偷看明信片的人。加密就是把内容写进一个**数字锁箱**：任何人都能把箱子锁上（因为锁是公开的），但只有 Bob 手里那把钥匙能打开。Eve 可以随便拿走一万个锁好的箱子，也砸不开。
- **具体示例**：Alice 要发 $x=13$。她查到 Bob 的公开信息 $(N,e)=(55,3)$，算出 $E(13)=13^3 \bmod 55=52$，把 52 发出去。Bob 用自己的私钥 $d=27$ 算出 $52^{27} \bmod 55=13$，拿到消息。Eve 只看到 52。

私钥密码 vs 公钥密码

- **定义**：**私钥密码体制 (private-key protocol)** 要求 Alice 与 Bob **事先见面**，共同约定一本秘密密码本（这本书同时扮演 E 与 D 的角色）。**公钥密码体制 (public-key protocol)** 中，每个人持有一对密钥：**公钥 (public key)** 全世界都能查，**私钥 (private key)** 只有本人知道。Alice 用 **Bob 的公钥**加密，Bob 用**自己的私钥**解密。
- **直观解释**：私钥体制像两个人共享同一把抽屉钥匙：要共享，就得先见一面把钥匙递过去——可是如果两人隔着半个地球，递钥匙的通道本身可能就是不安全的。公钥体制解决的是**密钥分发难题 (key distribution problem)**。注意这里有一层看似矛盾的地方：Eve 和 Bob 都能看到 $E(x)$，凭什么 Bob 能解密而 Eve 不能？答案在于 Bob 手里有 Eve 没有的**额外信息**（p,q,d），所以两人并不对称。

- **具体示例**：一个班 100 人要两两私密通信。私钥体制需要 $\binom{100}{2} = 4950$ 把共享密钥，且每把都要安全送达。公钥体制每人只需生成一对密钥，公开 100 个公钥即可，任何人都能从公开目录取用。

单向函数 (one-way function)

- **定义**：一个函数 f 称为单向的，如果**正向计算容易**（多项式时间可算），但**逆向求值困难**（已知 $y = f(x)$ 求 x 无已知高效算法）。RSA 中候选的单向函数是 $f(x) = x^e \bmod N$。
- **直观解释**：把一摞纸撕成碎片很容易，把碎片拼回去极难；把两种颜料混成一种颜色很容易，把混合色拆回两种原色极难。注意这里"容易/困难"是**计算复杂度**意义上的，不是"理论上不可能"——碎纸片理论上都能拼回去，只是组合太多。
- **具体示例**：取 $N = 55, e = 3$。正向：$13 \mapsto 13^3 \bmod 55 = 52$，两个乘法搞定。逆向：已知 52，要找出满足 $x^3 \equiv 52 \pmod{55}$ 的 x。最笨的办法是把 $x = 0, 1, \ldots, 54$ 全试一遍（55 次）。当 N 有 512 比特时，$N \approx 10^{154}$，试遍是不可能的。

模幂运算与快速幂的必要性

- **定义**：$E(x) \equiv x^e \pmod{N}$，$D(y) \equiv y^d \pmod{N}$。计算 $x^y \bmod N$ 的**反复平方法 (repeated squaring)** 在讲次 4 已给出：把 y 按二进制展开，递归地算 $x^{\lfloor y/2 \rfloor}$，再平方并按需乘一个 x。
- **直观解释**：不要把 x 乘 $y - 1$ 次（y 可能有 10^{154} 那么大，宇宙寿命也乘不完）。快速幂利用"平方能把指数翻倍"这一点，把代价从**指数级降到线性于 y 的比特数**：算 $x^{2^{512}}$ 只需要 512 次平方，而不是 2^{512} 次乘法。
- **具体示例**：算 $52^{27} \bmod 55$。$27 = 11011_2$，只需 4 次平方 + 4 次乘法（共 8 次模乘），而不是 26 次乘法。

欧拉函数 (Euler's totient function) 与欧拉定理

- **定义**：对正整数 n，$\varphi(n)$ 表示 $\{1, 2, \ldots, n\}$ 中与 n **互质**的整数个数。当 $N = pq$（$p \neq q$ 为质数）时，$\varphi(N) = (p-1)(q-1)$。**欧拉定理 (Euler's theorem)**：若 $\gcd(a, N) = 1$，则 $a^{\varphi(N)} \equiv 1 \pmod{N}$。
- **直观解释**：$\varphi(N)$ 数的是模 N 的乘法世界里"有逆元"的元素个数——即模 N 的**可逆元群 (group of units)** 的大小。欧拉定理说：在这个群里，任何元素的 $\varphi(N)$ 次幂都回到单位元 1。费马小定理正是 $N = p$（质数）、$\varphi(p) = p - 1$ 的特例，所以欧拉定理是费马小定理的推广。
- **具体示例**：$N = 55 = 5 \cdot 11$。$\varphi(55) = 4 \cdot 10 = 40$。与 55 互质的数有 $1, 2, 3, 4, 6, 7, 8, 9, 12, \ldots$，共 40 个。取 $a = 13$：$13^{40} \bmod 55 = 1$。但取 $a = 5$（$\gcd(5, 55) = 5 \neq 1$）：$5^{40} \bmod 55 = 45 \neq 1$——**条件不可省**。

数字锁 (digital lock)

- **定义**：RSA 的核心机制是 Bob 构造一个"只能用自己的钥匙打开的公开锁"。锁本身 = 公钥 (N, e)；钥匙 = 私钥 d。
- **直观解释**：这解释了为什么 RSA 表面上看不可能是对的。Eve 和 Bob 都能拿到 $E(x)$，看似同一起跑线；但 Bob 额外持有 (p, q)，从而能算出 d。Eve 想算出 d，就得先分解 N 拿到 p, q——这是她与 Bob 唯一的、也是决定性的差距。
- **具体示例**：Bob 选 $p = 5, q = 11$，算出 $N = 55$，公开 $(55, 3)$，锁就挂出去了。私钥 $d = 27$ 锁在抽屉里。Eve 知道 55，也知道 55 = 5 × 11（小数字好分解），所以她**真的能**攻破这个小例子——这正是为什么实际中 N 要有几百比特。

完整证明与推导（核心）

定理 6.1（RSA 正确性 / RSA Correctness）：设 $p \neq q$ 为质数，$N = pq$，e 满足 $\gcd(e, (p-1)(q-1)) = 1$，$d \equiv e^{-1} \pmod{(p-1)(q-1)}$。定义 $E(x) \equiv x^e \pmod{N}$，$D(y) \equiv y^d \pmod{N}$。则对**每一个** $x \in \{0, 1, \ldots, N-1\}$，

$$D(E(x)) \equiv (x^e)^d \equiv x \pmod{N}.$$

证明策略：直接用**分情形证明 (proof by cases)**，配合费马小定理。思路分三步：

1. 用 d 的定义把指数 ed 写成 $1 + k(p-1)(q-1)$，于是 $x^{ed} - x$ 可以**提出公因子** x；
2. 证明 $x^{ed} - x$ 同时被 p 与 q 整除。这里**必须分两种情形**：$p \nmid x$ 时用费马小定理，$p \mid x$ 时因为 x 本身就是因子而"平凡成立"；
3. 用 p, q 为质数这一事实，从"被 p 整除且被 q 整除"推出"被 $pq = N$ 整除"。

选这个策略的理由：费马小定理只在模**质数**且底数与模数互质时成立，而我们的目标是模**合数** $N = pq$。把合数拆成两个质数分别处理，是把已知工具接到新问题上的标准手法（也是 CRT 的精神）。

逐步推导：

第 1 步：把指数改写成方便的形式。

因为 d 是 e 模 $(p-1)(q-1)$ 的逆元，由逆元定义

$$ed \equiv 1 \pmod{(p-1)(q-1)}. \tag{6.1}$$

按同余的定义，存在整数 k 使得

$$ed = 1 + k(p-1)(q-1). \tag{6.2}$$

这里的 k 是**非负整数**：因为 $e, d \geq 1$ 所以 $ed \geq 1$，故 $k(p-1)(q-1) = ed - 1 \geq 0$；又 $(p-1)(q-1) > 0$，所以 $k \geq 0$。

于是对任意整数 x：

$$x^{ed} - x = x^{1 + k(p-1)(q-1)} - x = x \cdot x^{k(p-1)(q-1)} - x = x\left(x^{k(p-1)(q-1)} - 1\right). \tag{6.3}$$

第 2 步：证明 $x\left(x^{k(p-1)(q-1)} - 1\right)$ 被 p 整除。

情形 A：$p \nmid x$（x 不是 p 的倍数）。

此时 $x \not\equiv 0 \pmod p$。因为 p 是质数，模 p 的非零元素全都与 p 互质，即 $\gcd(x,p)=1$。费马小定理（定理 6.4，见下）给出

$$x^{p-1} \equiv 1 \pmod p.$$

两边同时取 $k(q-1)$ 次幂：

$$\left(x^{p-1}\right)^{k(q-1)} = x^{(p-1)\cdot k(q-1)} = x^{k(p-1)(q-1)} \equiv 1^{k(q-1)} \equiv 1 \pmod p.$$

（这一步用的是"同余式可以两边同时乘方"：若 $u \equiv v \pmod p$，则 $u^m \equiv v^m \pmod p$，对 $m \geq 0$ 归纳可证。当 $k=0$ 时 $k(q-1)=0$，$x^0=1$，断言同样成立。）

于是 $x^{k(p-1)(q-1)} - 1 \equiv 1 - 1 \equiv 0 \pmod p$。这个因子被 p 整除，所以整个乘积 $x\left(x^{k(p-1)(q-1)}-1\right)$ 也被 p 整除。

情形 B：$p \mid x$（x 是 p 的倍数）。

此时 (6.3) 的右边**显含因子 x**，而 x 本身被 p 整除，所以整个表达式被 p 整除。这里完全不需要费马小定理——这正是证明最需要小心的"边界情形"。

两种情形穷尽了所有 x，因此 $x^{ed}-x$ 恒被 p 整除。

第 3 步：对 q 做完全对称的论证。

把上面每一步中的 p 换成 q、把 $p-1$ 换成 $q-1$，逐字成立（$x^{k(p-1)(q-1)} = \left(x^{q-1}\right)^{k(p-1)}$，故情形 A 中用费马小定理模 q；情形 B 中 $q \mid x$ 时同样平凡）。结论：$x^{ed}-x$ 也被 q 整除。

第 4 步：合并到模 N。

$p \mid (x^{ed}-x)$ 且 $q \mid (x^{ed}-x)$，其中 $p \neq q$ 均为质数，所以 $x^{ed}-x$ 是 p 的倍数也是 q 的倍数。因为 $p \neq q$ 均为质数，pq 的质因数分解就是 $p \cdot q$，所以 $pq \mid (x^{ed}-x)$。

（这一步靠的是**唯一分解 / 质数性质**：若 $\gcd(p,q)=1$，$p \mid m$ 且 $q \mid m$，则 $pq \mid m$。证明：$m = pa$，又 $q \mid pa$，而 $\gcd(q,p)=1$，由欧几里得引理 $q \mid a$，所以 $a = qb$，$m = pqb$。）

即 $x^{ed} - x \equiv 0 \pmod N$，也就是 $(x^e)^d \equiv x \pmod N$。这正是 (6.1) 所想证的，定理成立。■

【证明机制解说】：这个证明最关键的一步是 (6.3) 的**因式分解** $x^{ed}-x = x\left(x^{k(p-1)(q-1)}-1\right)$。为什么必须提出公因子 x？因为费马小定理有前提 $\gcd(x,p)=1$，当 x 是 p 的倍数时这个前提失效。而"提出 x"这一手恰好让 $p \mid x$ 的情形自动成立——这就是所谓**"免费"地覆盖了边界情形**。

第二个关键点是**从模 p 与模 q 拼回模 N**。我们从来没有直接计算 $x^{ed} \bmod N$（指数 ed 可能有几百比特，直接算毫无直觉），而是分别在两个质数模下验证一个**整除性陈述**，最后靠 "p, q 互质 $\Rightarrow$ 乘积整除" 合并。这就是中国剩余定理的核心思想，只不过这里用的是它在整除语言下的等价形式。

第三个值得品味的地方是：整个证明**只用到 $ed \equiv 1 \pmod{(p-1)(q-1)}$ 这一条关于 d 的信息**，没有用到 d 具体是多少。这意味着任何满足 $ed \equiv 1 \pmod{(p-1)(q-1)}$ 的 d 都能工作——例如 $d=27$ 和 $d=67$ 都是合法的私钥（$3 \cdot 67 = 201 \equiv 1 \pmod{40}$）。CS70 约定取 $1 \leq d < (p-1)(q-1)$ 的那个代表元以保证唯一性。

证明的整体决策结构（ASCII 图）

下面这张图把整个证明的"分支树"画出来。它清楚显示：**每个 x 都要在两个质数模下各走一次二分支，共 4 条路径**，而每一条路径的最后一步都是"p 与 q 都整除 $\Rightarrow$ N 整除"。

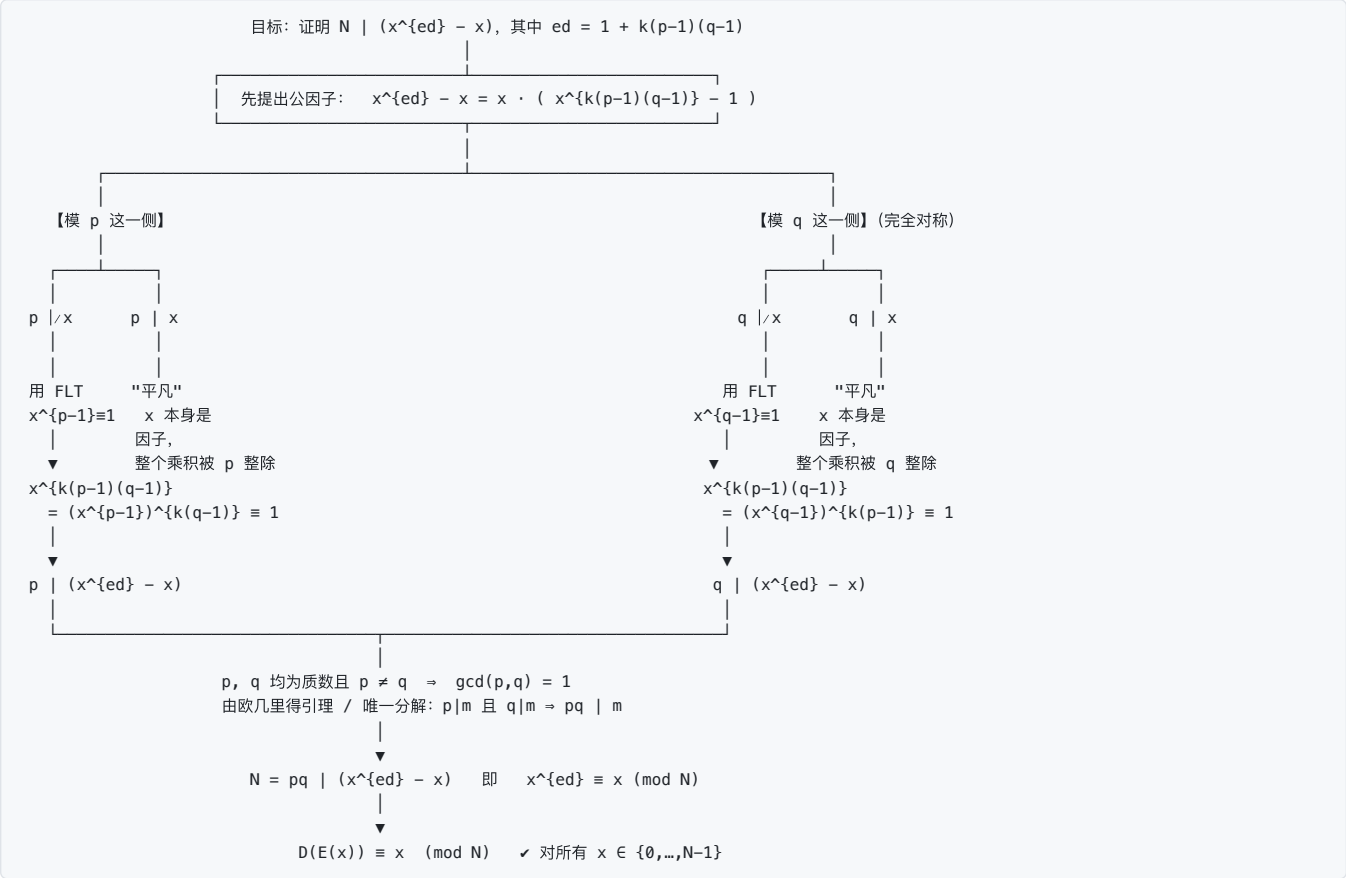

图中要注意的一点：**FLT 用于"底数与模互质"的那一支，另一支靠因式分解里显含的因子 x 平凡解决**。这就是定理 6.1 与定理 6.5 共享的骨架——区别只在于前者用"整除"语言、后者用"同余 + CRT 唯一性"语言收尾。

定理 6.2（欧拉定理 / Euler's Theorem）：设 N 为正整数，a 为整数且 $\gcd(a, N) = 1$。则

$$a^{\varphi(N)} \equiv 1 \pmod{N}.$$

证明策略：用**双射 + 乘积相等 (bijection and product comparison)** 的手法——这正是费马小定理证明的推广。核心观察是：把可逆元集合整体乘以 a，得到的还是同一个集合（只是元素次序被打乱），所以"两个集合的所有元素之积"相等。

逐步推导：

令 $U = \{r \in \{1, 2, \ldots, N\} : \gcd(r, N) = 1\}$，按定义 $|U| = \varphi(N)$。注意 $N \notin U$（除非 $N = 1$，此处假设 $N \geq 2$），且 $1 \in U$。

第一步：定义映射 $\mu : U \to U$，$\mu(r) = ar \bmod N$（取 1 到 N 之间的代表元）。验证它是 U 到 U 的映射（良定义）。

设 $r \in U$。则 $\gcd(a, N) = 1$ 且 $\gcd(r, N) = 1$。若质数 $s \mid \gcd(ar, N)$，则 $s \mid ar$ 且 $s \mid N$；因 s 为质数，$s \mid a$ 或 $s \mid r$。若 $s \mid a$ 则 $s \mid \gcd(a, N) = 1$，矛盾；若 $s \mid r$ 则 $s \mid \gcd(r, N) = 1$，矛盾。故 $\gcd(ar, N) = 1$。又 $\gcd$ 在模 N 下不变（$r' \equiv r \pmod{N} \Rightarrow \gcd(r', N) = \gcd(r, N)$），所以 $\mu(r) \in U$。

第二步：证明 μ 是单射。

设 $\mu(r_1) = \mu(r_2)$，即 $ar_1 \equiv ar_2 \pmod{N}$。由讲次 5 的结论，$\gcd(a, N) = 1$ 时 a 有模 N 的乘法逆元 a^{-1}。两边乘 a^{-1} 得 $r_1 \equiv r_2 \pmod{N}$，即 $r_1 = r_2$（两者都在 $\{1, \ldots, N\}$ 内）。

第三步：由有限集上的单射推出双射，再比较乘积。

U 是有限集，单射 $\mu : U \to U$ 必为双射。因此 $\{\mu(r) : r \in U\}$ 作为多重集与 U 完全相同，两边元素的乘积在模 N 下相等：

$$\prod_{r \in U} (ar) \equiv \prod_{r \in U} r \pmod{N} \quad \Longrightarrow \quad a^{\varphi(N)} \prod_{r \in U} r \equiv \prod_{r \in U} r \pmod{N}.$$

第四步：约掉 $\prod_{r \in U} r$。

每个 $r \in U$ 都有模 N 的逆元，所以乘积 $P = \prod_{r \in U} r$ 也有逆元 $P^{-1} \bmod N$（有限个可逆元之积仍可逆，归纳可证）。两边乘 P^{-1}：

$$a^{\varphi(N)} \equiv 1 \pmod{N}. \quad \blacksquare$$

【证明机制解说】：和费马小定理的证明是同一台机器，只是把"模质数的非零元素 $\{1, \ldots, p-1\}$"换成了"所有可逆元 U"。两个证明都用同一个技巧：**用一个乘法动作把集合置换到自己身上，然后比较整体乘积**。这个技巧在群论里叫"拉格朗日定理"的证明，在 CS70 里你只需要记住这个置换 + 乘积的模式。

系理 6.3（$\varphi(pq) = (p-1)(q-1)$）：若 $p \neq q$ 为质数，则 $\varphi(pq) = (p-1)(q-1)$。

证明：在 $\{1, 2, \ldots, pq\}$ 中，与 pq 不互质的数恰好是被 p 或 q 整除的数。被 p 整除的有 q 个（$p, 2p, \ldots, qp$），被 q 整除的有 p 个（$q, 2q, \ldots, pq$），两者交集是被 pq 整除的数，只有 pq 本身，共 1 个。由容斥原理，

$$|\{x : p \mid x \text{ 或 } q \mid x\}| = q + p - 1.$$

所以

$$\varphi(pq) = pq - (p+q-1) = pq - p - q + 1 = (p-1)(q-1). \quad \blacksquare$$

定理 6.4（费马小定理 / Fermat's Little Theorem，讲次 5 回顾）：设 p 为质数，$a \in \{1, 2, \ldots, p-1\}$。则

$$a^{p-1} \equiv 1 \pmod{p}.$$

证明策略：与定理 6.2 同一手法，但集合取 $\{1, \ldots, p-1\}$，并注意到 $a, 2a, \ldots, (p-1)a \bmod p$ 正好是这个集合的一个置换。

逐步推导：

第一步：$a, 2a, \ldots, (p-1)a$ 在模 p 下两两不同，且都不为 0。

若 $ia \equiv ja \pmod{p}$ 且 $1 \le i < j \le p-1$，则 $p \mid (j-i)a$。因为 p 是质数且 $p \nmid a$（$1 \le a \le p-1$），必有 $p \mid (j-i)$。但 $0 < j - i < p$，不可能。所以互不相同。又 $p \nmid ia$（$p \nmid i$ 且 $p \nmid a$），故模 p 不为 0。

第二步：$S = \{1, \ldots, p-1\}$ 与 $S' = \{a, 2a, \ldots, (p-1)a \bmod p\}$ 作为集合相同。

S' 是 S 中 $p-1$ 个互不相同的非零元素构成的子集，而 $|S| = p-1$，所以 $S' = S$（只是次序不同）。

第三步：比较两边所有元素之积。

$$\prod_{i=1}^{p-1} i \equiv (p-1)! \pmod{p}, \qquad \prod_{i=1}^{p-1} (ia) \equiv a^{p-1}(p-1)! \pmod{p}.$$

因为集合相同，两式左边相等模 p，故 $(p-1)! \equiv a^{p-1}(p-1)! \pmod{p}$。

第四步：约掉 $(p-1)!$。

$(p-1)!$ 的每个因子都在 $\{1, \ldots, p-1\}$ 中，都与 p 互质，所以 $(p-1)!$ 可逆。两边乘其逆元得 $a^{p-1} \equiv 1 \pmod{p}$。$\blacksquare$

定理 6.5（RSA 正确性的 CRT 证明）：在定理 6.1 的设定下，$x^{ed} \equiv x \pmod{N}$。

证明策略：不用"整除"语言，而是**显式地在模 p 与模 q 下分别算出同余式，再用中国剩余定理的唯一性把两个解合并**。这比利诱解法更贴近 CRT 的"坐标视角"。

逐步推导：

第一步：模 p 下计算。

$$x^{ed} = x^{1 + k(p-1)(q-1)} = x \cdot \left(x^{q-1}\right)^{k(p-1)} = x \cdot \left(x^{p-1}\right)^{k(q-1)}. \tag{6.4}$$

- 若 $x \not\equiv 0 \pmod{p}$：由费马小定理 $x^{p-1} \equiv 1 \pmod{p}$，故 $\left(x^{p-1}\right)^{k(q-1)} \equiv 1$，于是 $x^{ed} \equiv x \pmod{p}$。
- 若 $x \equiv 0 \pmod{p}$：(6.4) 最左端 x^{ed} 含因子 x，故 $x^{ed} \equiv 0 \equiv x \pmod{p}$，**直接观察即得**。

所以恒有 $x^{ed} \equiv x \pmod{p}$。

第二步：对称地，$x^{ed} \equiv x \pmod{q}$。

第三步：合并。 记 a_1 为 $x \bmod p$，a_2 为 $x \bmod q$。同余方程组

$$y \equiv a_1 \pmod{p}, \qquad y \equiv a_2 \pmod{q}$$

由中国剩余定理（$\gcd(p, q) = 1$）在模 $pq = N$ 下有**唯一解**。而 $y \equiv x^{ed}$ 与 $y \equiv x$ 都满足这个方程组，故它们在模 N 下相等：

$$x^{ed} \equiv x \pmod{N}. \quad \blacksquare$$

【证明机制解说】：这个证明把 CRT 的"唯一性"当成了武器。注意它其实**没有构造**解，只是说"两个候选解满足同一个模 p 同余与同一个模 q 同余，所以必然相同"——唯一性就是用来做这种"等号传递"的。对 $x = 15$ 这个具体例子（情形 $p \mid x$、$q \nmid x$）验算：$x^{ed} = 15^{81}$，$15^{81} \bmod 5 = 0 = 15 \bmod 5$（平凡情形），$15^{81} \bmod 11 = 4 = 15 \bmod 11$（费马情形）。用 CRT 从 $(0 \bmod 5, 4 \bmod 11)$ 重建，在 0 到 54 中唯一满足的是 15。两个同余条件被同时满足的唯一 y 就是 15 本身。

反例 6.6（$\gcd(x, N) \neq 1$ 时费马小定理的前提确实会失效）

定理 6.1 的证明之所以要分两种情形，是因为"若 x 是 p 的倍数则 $x^{p-1} \equiv 1 \pmod{p}$"这句话**是假的**。取 $p = 5$：$x = 5$ 时 $5^4 = 625$，而 $625 \bmod 5 = 0 \neq 1$。所以情形 B 不能归约到情形 A，必须靠"提出公因子 x"独立处理。

同理，欧拉定理（定理 6.2）的条件 $\gcd(a, N) = 1$ 也不可省。取 $N = 55, a = 5$：$\varphi(55) = 40$，而 $5^{40} \bmod 55 = 45 \neq 1$。把 $\gcd$ 条件去掉，欧拉定理就崩了。

反例 6.7（e 必须与 $\varphi(N)$ 互质）

RSA 要求 e 与 $(p-1)(q-1)$ 互质，因为解密密钥 d 定义为 e 的模 $\varphi(N)$ 逆元，而逆元**存在当且仅当互质**（讲次 5 定理）。取 $p = 5, q = 11$，$\varphi(N) = 40$，若误取 $e = 5$：$\gcd(5, 40) = 5 \neq 1$，$5d \bmod 40$ 的取值只能落在 $\{0, 5, 10, 15, 20, 25, 30, 35\}$ 里，**永远取不到 1**，所以不存在任何 d。

更糟的是，加密本身还会变得不可逆。取 $x = 2$：$E(2) = 2^5 \bmod 55 = 32$。在 $d = 1, 2, \ldots, 39$ 中逐一验算 $32^d \bmod 55$，**没有任何一个 d 能还原出 2**。同理 $x = 3$：$E(3) = 3^5 \bmod 55 = 23$，同样**无 d 可解**。所以 e 的选择不是"看起来差不多就行"，互质是硬性要求。

与经典问题的联系

问题实际背景

Alice 和 Bob 想在不安全信道上私密通信，且**从未见过面**（无法预先共享密钥）。Eve 可以监听并截获所有密文 $E(x)$。目标是：即使 Eve 拿到了 $E(x)$、公钥 (N,e)、以及任意多条其他密文，她也无法得知 x。

数学建模

RSA 把这个问题建模成模算术中的一个"可逆但不可逆向求值"的映射：

角色	持有的信息	公开程度
Bob	大质数 p,q；$N=pq$；$\varphi(N)=(p-1)(q-1)$；e；$d\equiv e^{-1}\pmod{\varphi(N)}$	只公开 (N,e)；p,q,d 严格保密
Alice	Bob 的公钥 (N,e)、消息 $x\in\{1,\dots,N-1\}$	明文 x 保密
Eve	(N,e)、密文 $y=E(x)$	——

方案设计

1. **密钥生成 (key generation)**：
2. 随机选取两个大质数 $p\neq q$（实际各约 512 比特），令 $N=pq$。
3. 计算 $\varphi(N)=(p-1)(q-1)$。
4. 选取 e 使 $\gcd(e,\varphi(N))=1$（常用 $e=3$ 或 $e=65537$）。
5. 用扩展欧几里得算法计算 $d\equiv e^{-1}\pmod{\varphi(N)}$。
6. **公开** (N,e)，**销毁** $p,q,\varphi(N)$ 的痕迹，**保密** d。
7. **加密**：$E(x)\equiv x^e\pmod N$（用快速幂）。
8. **解密**：$D(y)\equiv y^d\pmod N$（用快速幂）。

完整通信流程（ASCII 图）

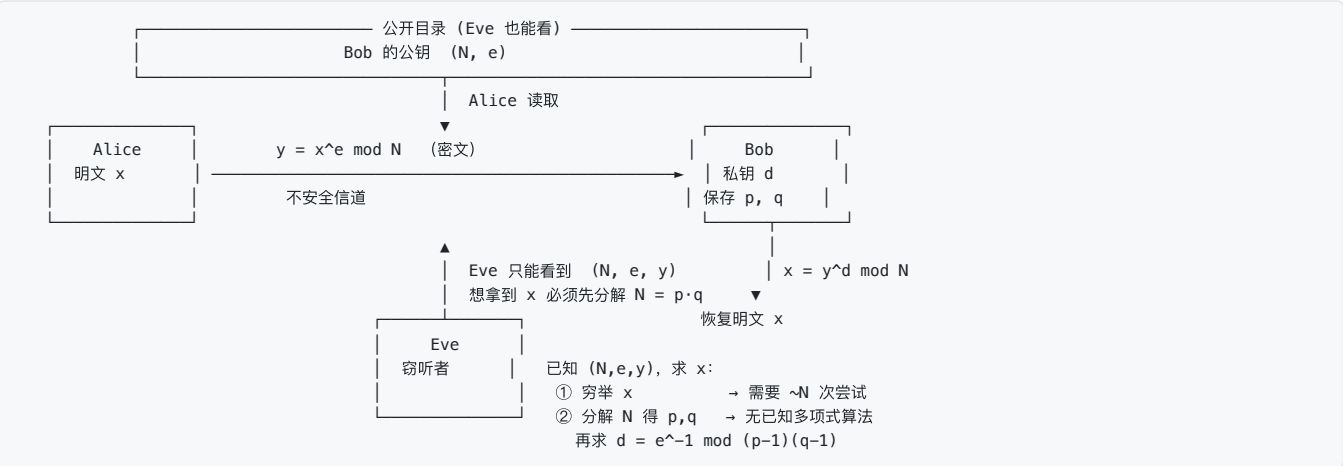

完整小数字手算演示（官方 Note 的算例，逐步展开）

取 $p=5$，$q=11$。

第一步：算 N 与 $\varphi(N)$。

$$N=5\times 11=55,\qquad \varphi(N)=(5-1)(11-1)=4\times 10=40.$$

第二步：选 e。 取 $e=3$。检查 $\gcd(3,40)=1$ ✔。

第三步：算 $d\equiv 3^{-1}\pmod{40}$。 用扩展欧几里得算法：

$$40=13\times 3+1\quad\Longrightarrow\quad 1=40-13\times 3\quad\Longrightarrow\quad -13\times 3\equiv 1\pmod{40}.$$

所以 $d\equiv -13\equiv 40-13=27\pmod{40}$。**验算**：$3\times 27=81$，$81\bmod 40=1$ ✔。

Bob 的公钥是 $(55,3)$，私钥 $d=27$。

第四步：加密 $x=13$。

$$13^2=169,\qquad 169\bmod 55=169-3\times 55=169-165=4.$$

$$13^3=13^2\times 13=169\times 13=2197,\qquad 2197\bmod 55=2197-39\times 55=2197-2145=52.$$

所以 $y=E(13)=52$。Alice 把 52 发出去。

第五步：解密 $y=52$，算 $52^{27}\bmod 55$（用反复平方法）。

27 的二进制是 11011_2。按从低位到高位扫描：

步骤	当前位	结果累乘器 `res`	平方基底 `base`
初值	——	1	52
1	1	$1\times 52=52$	$52^2=2704\equiv 2704-49\times 55=9$
2	1	$52\times 9=468\equiv 468-8\times 55=28$	$9^2=81\equiv 81-55=26$
3	0	28（不变）	$26^2=676\equiv 676-12\times 55=16$
4	1	$28\times 16=448\equiv 448-8\times 55=8$	$16^2=256\equiv 256-4\times 55=36$
5	1	$8\times 36=288\equiv 288-5\times 55=13$	（已用尽位数）

得到 $D(52)=13$，正是原始消息 x ✔。

第六步：验证全消息空间。 对 $x=0,1,2,\dots,54$ **全部 55 个值**逐一验算 $D(E(x))$，结果**全部等于 x**，无反例。几个含边界情形的例子：

x	$\gcd(x,55)$	$y=x^3 \bmod 55$	$y^{27} \bmod 55$	是否等于 x	对应证明分支
0	55	0	0	✔	$p\mid x$ 且 $q\mid x$（双平凡）
1	1	1	1	✔	一般情形
5	5	15	5	✔	$p\mid x$，$q\nmid x$
10	5	10	10	✔	$p\mid x$，$q\nmid x$
11	11	11	11	✔	$q\mid x$，$p\nmid x$
15	5	20	15	✔	$p\mid x$，$q\nmid x$
22	11	33	22	✔	$q\mid x$，$p\nmid x$
25	5	5	25	✔	$p\mid x$，$q\nmid x$
33	11	22	33	✔	$q\mid x$，$p\nmid x$
44	11	44	44	✔	$q\mid x$，$p\nmid x$
54	1	54	54	✔	一般情形

注意 $x=15$ 时 $E(15)=20$ 而 $E(25)=5$——加密可以"乱序"，解密仍然准确。这直观地显示了 E 是**整个 $\{0,1,\dots,54\}$ 上的双射**，包括那些与 55 不互质的元素。（注意 E 不是 $\mathbb{Z}/55$ 的加法群同态，也不是乘法群 $(\mathbb{Z}/55)^*$ 上的置换——它是定义域和值域都为整个 $\mathbb{Z}/55$ 的双射，把 $\gcd(x,55)\neq 1$ 的那些点也一并映射到别的点上。）

第七步：$ed=81=1+k(p-1)(q-1)$ 中的 k。

$$k=\frac{ed-1}{(p-1)(q-1)}=\frac{81-1}{40}=2.$$

所以 $ed=1+2\times 4\times 10=81$，与定理 6.1 第 1 步的形式一致。

为什么安全：依赖大整数分解的困难性

RSA 的安全性建立在这样一个**基本假设 (basic assumption)** 上：

> 已知 N、e 与 $y\equiv x^e \pmod N$，不存在求 x 的高效算法。

Eve 的两条已知攻击路线：

1. **穷举 x**：对每个候选 x 检查 $x^e\equiv y \pmod N$ 是否成立。需要约 N 次尝试。当 N 是 512 比特的数（$N\approx 2^{512}\approx 1.34\times 10^{154}$）时完全不可行。
2. **分解 N**：先求出 p,q，再算 $\varphi(N)=(p-1)(q-1)$，再算 $d=e^{-1}\bmod\varphi(N)$，就得到私钥。这条路线需要**高效地把 N 分解为质因数**，而这一问题被广泛相信对大整数**没有多项式时间算法**。

必须强调：**RSA 的安全性没有被形式化证明**。它依赖两个假设：(i) 攻破 RSA 本质上等价于分解 N；(ii) 分解 N 是困难的。两者都是"被广泛相信"而非"已被证明"。

这里有一个**极具讽刺意味也极具启发性**的对比：**判定一个数是否质数有高效算法**（$O((\log n)^k)$，多项式于比特数），**但已知 n 是合数却找不到它的因子**。RSA 的全部可行性就架在这个区分上——Bob 能高效造出 $N=pq$，但没人能高效拆开它。

质数如何生成

- **质数定理 (Prime Number Theorem)**：令 $\pi(n)$ 表示不超过 n 的质数个数。对所有 $n\geq 17$，

$$\pi(n)\geq\frac{n}{\ln n},\qquad \text{且}\quad \lim_{n\to\infty}\frac{\pi(n)}{n/\ln n}=1.$$

- **怎么用**：取 $n=2^{512}$，则 2^{512} 以下大约 $\frac{2^{512}}{512\ln 2}$ 个数是质数，比例约 $\frac{1}{512\ln 2}\approx\frac{1}{355}$。也就是说**每 355 个 512 比特的数里就有一个质数**。所以 Bob 只需随机抽 512 比特的奇数，做素性测试，平均试约 355 个就能找到一个质数——快得可以忽略不计。

- $n \geq 17$ 时 $\pi(n) \geq n/\ln n$ 这个下界是个"够用就好"的粗糙界限：实际 $\pi(100) = 25 > 100/\ln 100 \approx 21.7$，$\pi(1000) = 168 > 144.8$，$\pi(10000) = 1229 > 1085.7$，$\pi(100000) = 9592 > 8685.9$。定理只说 $n/\ln n$ 是下界，并不声称它精确（$\pi(n)$ 通常更大）。

e 的选取：为什么常用 65537

e 的选取要同时满足：$\gcd(e, \varphi(N)) = 1$，且 e 的二进制表示里 1 的个数尽量少（快速幂的乘法次数正比于 1 的个数）。

- $e = 3$：只有 2 个 1，最快。但小指数有额外风险：实际实现中若不做填充，当 x 很小时 $x^3 < N$ 可能成立，于是 $x^3 \bmod N = x^3$ 原样保留，攻击者直接在整数上开立方根就恢复了 x（这就是"低指数攻击"）。
- $e = 65537 = 2^{16} + 1$：二进制是 10000000000000001_2，只有 2 个 1，所以快速幂只需 16 次平方 + 1 次乘法，几乎和 $e = 3$ 一样快；同时 65537 本身是质数，只要 $p - 1$ 与 $q - 1$ 都不是 65537 的倍数（正常随机选大质数时几乎必然如此），就自动有 $\gcd(65537, \varphi(N)) = 1$。这是当今最通行的选择。

实用考虑：快速幂与运行代价

RSA 里 Alice 与 Bob 各自只需要做两件非平凡的事：

1. Bob 找两个大质数（用素性测试 + 随机采样，如上）。
2. Alice 算 $x^e \bmod N$，Bob 算 $y^d \bmod N$（用反复平方法）。

代价分析：$e, d < N$，故 e, d 的比特数为 $O(\log N)$；反复平方的乘法次数是 $O(\log N)$；每次乘法是 $O(\log N)$ 比特的数相乘，用小学竖式乘法需 $O((\log N)^2)$ 次位运算（CS170 会讲更快的算法）。所以总代价

$$O(\log N) \times O((\log N)^2) = O((\log N)^3).$$

这是关于 $\log N$ 的多项式——所以哪怕 N 有几百比特，任何袖珍计算设备都能在瞬间完成加密解密。而 Eve 要做的分解，被认为需要远超全世界所有最先进计算机联合起来的算力。

教科书 RSA 为什么不安全（必须加随机填充）

上面的方案被称为**教科书 RSA (textbook RSA)**——它证明了数学上的可逆性，但**作为密码系统是不安全的**，有两个致命缺陷：

缺陷 1：确定性加密 (deterministic encryption)。 同一明文 x 永远加密成同一个密文 $x^e \bmod N$。于是 Eve 不需要解密也能获得信息：她可以预先建一张"常见明文 → 密文"的表（例如所有可能的"是/否"、所有小额转账金额、所有人的名字）。看到密文，查表即得明文。这违反现代密码学要求的**语义安全性 (semantic security)**。

缺陷 2：可乘性 (multiplicative malleability)。 因为 E 就是模 N 的幂运算，它保持乘法结构：

$$E(x_1) \cdot E(x_2) \equiv x_1^e \cdot x_2^e = (x_1 x_2)^e \equiv E(x_1 x_2) \pmod{N}.$$

验算（$N = 55, e = 3$）：

x_1	x_2	$E(x_1)$	$E(x_2)$	$E(x_1)E(x_2) \bmod 55$	$E(x_1 x_2 \bmod 55)$
13	7	52	13	16	$E(91 \bmod 55) = E(36) = 16$
2	3	8	27	51	$E(6) = 51$
4	9	9	14	16	$E(36) = 16$

这个性质让攻击者**在不知道明文的情况下伪造出有意义的新密文**：给定 $E(x)$，他能构造 $E(2x) = E(x) \cdot E(2)$。在拍卖、转账等场景里这是灾难性的——攻击者可以把"转账 100 元"的密文改成"转账 200 元"的密文，而收方解密后完全无法察觉。

解法：加密前对明文做随机化的**填充 (padding)**——在明文里混入足够长的随机比特（如 OAEP），使得 (i) 同一明文的两次加密产生不同密文，破坏确定性；(ii) 明文结构被随机数掩盖，破坏可乘性的可利用性。填充后的方案才叫 PKCS#1、RSA-OAEP，是实际部署的版本。

与其他讲次的关联

- **讲次 4（Modular Arithmetic，模运算）**：RSA 的加密 $x^e \bmod N$ 与解密 $y^d \bmod N$ 完全建立在同余语言上。讲次 4 的"乘法次序无关、可以随时约减"是我们在第 2 步里把 x^{ed} 拆成 $\left(x^{p-1}\right)^{k(q-1)}$ 并逐层约减 $(p-1)$ 次幂的依据；讲次 4 的**反复平方法 (mod-exp)** 则是 RSA 能实用的全部技术基础，本讲的 52^{27} 手算表格就是用它的 5 步跟踪。此外，讲次 4 的"x 有模 m 逆元 $\iff \gcd(m, x) = 1$"直接决定了 e 必须与 $\varphi(N)$ 互质。
- **讲次 5（Euclid, FLT, CRT）**：
- **扩展欧几里得算法 (Extended Euclid)** 是计算 $d \equiv e^{-1} \pmod{(p-1)(q-1)}$ 的工具。本讲 $d = 27$ 的求法就是 $\gcd(3, 40) = 1 = 40 - 13 \times 3$，读出 $b = -13 \equiv 27$。
- **费马小定理 (FLT)** 是定理 6.1 第 2 步情形 A 的唯一工具，也是定理 6.5 第一步的依据。
- **中国剩余定理 (CRT)** 在定理 6.5 里以"唯一性"的面目出现；讲次 5 的"基向量"视角（$b_1 \equiv (1 \bmod p, 0 \bmod q)$）正好解释了为什么模 p 与模 q 上各满足一个同余就能唯一确定模 pq 的解。本讲里 $\varphi(pq) = (p-1)(q-1)$ 的证明则用了讲次 5/14 的容斥计数。
- 讲次 5 的**唯一分解 / 欧几里得引理**（$p \mid ab, p$ 质数 $\Rightarrow p \mid a$ 或 $p \mid b$）在定理 6.1 第 4 步"p, q 互质 $\Rightarrow pq \mid m$"中发挥作用。
- **讲次 3（Induction，归纳法）**：定理 6.2 第 4 步"有限个可逆元之积仍可逆"以及"同余式两边可同时乘方"都靠对个数做简单归纳。
- **讲次 2（Proof Techniques II，分情形/反证）**：定理 6.1 的核心结构就是**分情形证明**（$p \mid x$ vs $p \nmid x$），而 φ 的存在性讨论与唯一性论证（定理 6.5 第三步）用的是**反证/唯一性论证**。
- **讲次 7（Polynomials，多项式）**：多项式上的单向函数构造（如 $P(x)$ 求根困难）与 RSA 共享同一套"正向易、逆向难"的设计哲学；本讲末尾提到的**随机填充**之所以能破坏确定性，靠的正是下一讲的"用有限域上的随机点定义对象"的思想。

- **讲次 20（Expectations & Linearity，哈希与负载均衡）**：本讲的"随机采样质数、平均试 355 个成功"正是"随机化算法 + 期望分析"的典型应用，其期望值计算与讲次 20 的期望线性性一脉相承。

关键要点

1. **密钥生成三步**：$N = pq$（$p \neq q$ 为大质数）→ $\varphi(N) = (p-1)(q-1)$ → 取 $\gcd(e, \varphi(N)) = 1$，算 $d \equiv e^{-1} \pmod{\varphi(N)}$。公钥 (N, e) 公开，p, q, d 保密。
2. **加解密**：$E(x) \equiv x^e \pmod{N}$，$D(y) \equiv y^d \pmod{N}$。正确性的形式化陈述是 $(x^e)^d \equiv x \pmod{N}$ 对**所有** $x \in \{0, \ldots, N-1\}$ 成立。
3. **正确性证明的黄金链条**：$ed \equiv 1 \pmod{(p-1)(q-1)}$ $\Rightarrow$ $ed = 1 + k(p-1)(q-1)$ $\Rightarrow$ 提出公因子 x 得 $x^{ed} - x = x\left(x^{k(p-1)(q-1)} - 1\right)$ $\Rightarrow$ 分情形证它被 p 整除（$p \nmid x$ 用 FLT；$p \mid x$ 靠 x 本身是因子）$\Rightarrow$ 对称得被 q 整除 $\Rightarrow$ $pq = N$ 整除它。
4. **边界情形的处理口诀**："**能被费马就费马，不能费马就提因子**"。$\gcd(x, N) \neq 1$ 时费马小定理前提失效，靠因式分解中显含的 x 平凡解决。
5. **安全性的确切边界**：RSA 的安全性**未被证明**，它依赖"分解大整数是困难的"这一广泛相信但未证明的假设。有高效**素性测试**，但没有已知的高效**分解**算法——RSA 就架在这个不对称上。
6. **教科书 RSA 必须加填充**：确定性（同明文同密文 $\Rightarrow$ 字典攻击）与可乘性（$E(x_1)E(x_2) = E(x_1x_2)$ $\Rightarrow$ 密文可被篡改）是两个必须靠随机填充修补的结构性缺陷。

常见误区与注意事项

1. **误以为"定理对所有 x 成立"就无需求证边界情形**。官方 Note 特别把消息空间写作"除 0 和 1 之外的模 N 的数"（因为 0 与 1 加密后就是自己，不承载信息），但定理 7.1 的陈述是**对所有** $x \in \{0, 1, \ldots, N-1\}$，且证明确实覆盖了 0 与 1（$x = 0$：$p \mid 0$ 且 $q \mid 0$，两分支都走情形 B）。不要把"消息集合"与"定理成立的范围"混为一谈。
2. **把费马小定理的条件写漏**。费马小定理是"对**质数** p 和 $a \in \{1, \ldots, p-1\}$ 有 $a^{p-1} \equiv 1 \pmod{p}$"，**不是**对所有模数成立，也**不是**对任意 a 成立（$a \equiv 0 \pmod{p}$ 时 $a^{p-1} \equiv 0$）。RSA 证明中 $p \mid x$ 的情形正是这个条件失效的地方。
3. **忘记"e 必须与 $\varphi(N)$ 互质"是硬要求**。d 定义为 e 的模 $\varphi(N)$ **逆元**，而逆元存在当且仅当 $\gcd(e, \varphi(N)) = 1$。取 $e = 5, \varphi(N) = 40$ 时，$5d \bmod 40$ 永远取不到 1，且加密变得不可逆（$E(2) = 32$ 在任何 d 下都解不回 2）。
4. **把 $\varphi(N)$ 与 $N-1$ 混淆**。$\varphi(N) = (p-1)(q-1) = N - p - q + 1$，比 $N-1$ 小得多（$N = 55$ 时是 40 而不是 54）。d 是模 $\varphi(N)$ 的逆元，不是模 N 的，也不是模 $N-1$ 的。写成 $\bmod (N-1)$ 会导致解密失败。
5. **误把"d 唯一"理解成"d 只有一个数值"**。d 只在**模** $\varphi(N)$ 意义下唯一。$N = 55$ 时 $d = 27$ 与 $d = 67$ 都是合法私钥（$3 \times 67 = 201 \equiv 1 \pmod{40}$）。实现中取 $1 \leq d < \varphi(N)$ 的代表元只是为了确定化。
6. **认为"N 公开所以 p, q 也就暴露了"**。N 公开**不等于**分解可行。对 512 比特的 p, q，N 有约 1024 比特，而分解被认为没有多项式时间算法。同时要注意 p 与 q **不能太接近**（见下一条）——否则有专门的快速分解法。
7. **忽略 p 与 q 的选取细节**。若 p 与 q 太接近，**费马分解法 (Fermat factorization)** 会瞬间拆开 N：它利用 $N = pq = \left(\frac{p+q}{2}\right)^2 - \left(\frac{p-q}{2}\right)^2$，从 $a = \lceil \sqrt{N} \rceil$ 起逐一测试 $a^2 - N$ 是否为完全平方。差额越小，需要的步数越少（约 $\frac{(\sqrt{q}-\sqrt{p})^2}{2}$ 步）。实测：$p = 1000003, q = 1000033$（差 30）时费马法**第 0 步**就成功；而 $p = 3, q = 1000003$ 时需约 498270 步才拆开。所以 RSA 实现必须保证 $|p - q|$ 足够大（通常要求 p, q 长度相同但差值也很大），同时还要避开"$p-1$ 或 $q-1$ 只有小质因子"的弱质数。

思考题（带答案）

Q1. 取 $p = 7$，$q = 13$，$e = 5$。(a) 求 N 与 $\varphi(N)$；(b) 求私钥 d；(c) 对 $x = 10$ 完成一次加密与解密，逐步写出中间值；(d) 验证 $x = 14$ 的情况（注意 $14 = 2 \times 7$，是 p 的倍数），说明定理 6.1 的哪个分支在处理它。

▸ **答案**

（a）$N = 7 \times 13 = 91$，$\varphi(N) = (7-1)(13-1) = 6 \times 12 = 72$。

（b）检查 $\gcd(5, 72) = 1$ ✔。用扩展欧几里得：

$$72 = 14 \times 5 + 2, \qquad 5 = 2 \times 2 + 1.$$

回代：$1 = 5 - 2 \times 2 = 5 - 2(72 - 14 \times 5) = 29 \times 5 - 2 \times 72$。

所以 $29 \times 5 \equiv 1 \pmod{72}$，即 $d = 29$。验算：$5 \times 29 = 145 = 2 \times 72 + 1$，$145 \bmod 72 = 1$ ✔。

（c）加密 $x = 10$：

$$10^2 = 100 \equiv 100 - 91 = 9 \pmod{91}, \qquad 10^5 = 10^4 \cdot 10 = 9^2 \cdot 10 = 81 \times 10 = 810.$$

$$810 \bmod 91 = 810 - 8 \times 91 = 810 - 728 = 82.$$

所以 $y = E(10) = 82$。

解密：$82^{29} \bmod 91$。按 $29 = 11101_2$ 逐位计算：

位	`res`	`base`
初值	1	82
1	82	$82^2 = 6724 \equiv 6724 - 73 \times 91 = 6724 - 6643 = 81$
0	82	$81^2 = 6561 \equiv 6561 - 72 \times 91 = 6561 - 6552 = 9$
1	$82 \times 9 = 738 \equiv 738 - 8 \times 91 = 10$	$9^2 = 81$
1	$10 \times 81 = 810 \equiv 82$	$81^2 \equiv 9$
1	$82 \times 9 = 738 \equiv 10$	——

得到 $D(82) = 10 = x$ ✔。（顺带观察：这里 E 与 D 在同一条循环里都出现了 10 和 82 的往返，因为 e 与 d 的角色在这个小模数下意外地"对称"，纯属巧合，不要当成一般性质。）

（d）$x = 14$：$\gcd(14, 91) = 7$，所以 14 是 $p = 7$ 的倍数但不是 $q = 13$ 的倍数。

$E(14) = 14^5 \bmod 91$。$14^2 = 196 \equiv 196 - 2 \times 91 = 14$（有趣：$14$ 在模 91 下是平方不动点）。所以 $14^5 = 14^4 \cdot 14 = 14 \cdot 14 = 196 \equiv 14$。$y = 14$。

$D(14) = 14^{29} \bmod 91 = 14^{28} \cdot 14$。因为 $14^2 \equiv 14$，$14^{28} = (14^2)^{14} \equiv 14^{14} \equiv \cdots \equiv 14$，故 $14^{29} \equiv 14 \cdot 14 = 196 \equiv 14$ ✔。

在定理 6.1 的证明中，处理模 $p = 7$ 的部分走**情形 B**（$p \mid x$，靠 (6.3) 中显含的因子 x 平凡成立）；处理模 $q = 13$ 的部分走**情形 A**（$q \nmid x$，且 $\gcd(14, 13) = 1$，用费马小定理 $14^{12} \equiv 1 \pmod{13}$，进而 $14^{k(p-1)(q-1)} = 14^{k \cdot 6 \cdot 12} = (14^{12})^{6k} \equiv 1 \pmod{13}$）。这正是本讲强调的"一个 x 可能在一个质数模下走情形 A、在另一个下走情形 B"的典型例子。

Q2. 有人提出一个"简化版 RSA"：取 $N = pq$ 后，不用 $\varphi(N) = (p-1)(q-1)$，而是直接令 $d \equiv e^{-1} \pmod{N-1}$。请用 $p = 5, q = 11, e = 3$ 构造一个具体的失败例子，并解释这个方案在哪个环节崩掉。

▸ **答案**

$N = 55$，$N - 1 = 54$。取 $e = 3$，$\gcd(3, 54) = 3 \neq 1$，所以 $e = 3$ 在这个方案下**连 d 都算不出来**——第一个崩掉的环节就是"逆元不存在"。

为了看清错误不只是"选错 e"，换 $e = 5$。$\gcd(5, 54) = 1$ ✔，求逆：$54 = 10 \times 5 + 4$，$5 = 1 \times 4 + 1$，回代 $1 = 5 - 4 = 5 - (54 - 10 \times 5) = 11 \times 5 - 54$。所以 $d = 11$。

现在取 $x = 2$ 加密：$2^5 = 32$，$y = 32$。解密：$32^{11} \bmod 55$。

$$32^2 = 1024 \equiv 1024 - 18 \times 55 = 1024 - 990 = 34.$$

$$32^4 \equiv 34^2 = 1156 \equiv 1156 - 21 \times 55 = 1156 - 1155 = 1.$$

$$32^8 \equiv 1.$$

$$32^{11} = 32^8 \cdot 32^2 \cdot 32^1 \equiv 1 \times 34 \times 32 = 1088.$$

$$1088 \bmod 55 = 1088 - 19 \times 55 = 1088 - 1045 = 43 \neq 2.$$

解密失败，得到 43 而不是 2。

根因：定理 6.1 的证明**只在 $ed \equiv 1 \pmod{(p-1)(q-1)}$ 时才把指数写成 $1 + k(p-1)(q-1)$**，从而让 $x^{k(p-1)(q-1)} \equiv 1 \pmod{p}$（费马）与 $\equiv 1 \pmod{q}$（费马）成立。这里 $p - 1 = 4$ 与 $q - 1 = 10$ 必须同时整除 $k\varphi$，所以 φ 必须是 $\operatorname{lcm}(4, 10) = 20$ 的倍数；$(p-1)(q-1) = 40$ 是满足这一点的一个方便选择，而 **$N - 1 = 54$ 不是 4 的倍数**（$54 = 4 \times 13 + 2$）。$ed - 1 = 5 \times 11 - 1 = 54$ 不被 4 整除，所以 $x^{54} \not\equiv 1 \pmod{5}$，模 p 那一半的证明直接失效。

（事实上，任何 φ 的倍数都能工作，例如 $\operatorname{lcm}(p-1, q-1) = 20$ 也行；$(p-1)(q-1)$ 只是因为好算而被采用。但 $N - 1$ 一般不是 lcm 的倍数。）

Q3. 攻击者 Eve 截获了 Bob 公钥 $(N, e) = (55, 3)$ 下同一个明文 x 的**两次**密文，分别是 $y_1 = 52$ 与 $y_2 = 8$。已知 x 是 $\{2, 3, \ldots, 54\}$ 中的某个整数。(a) 判断这两次密文是否可能来自同一个明文，并说明这是教科书 RSA 的什么缺陷；(b) 如果 $x_1 = 13$ 对应 $y_1 = 52$，且 Eve 还截获了另一条密文 y_3，她能伪造出 $E(x_1^2)$ 吗？给出具体计算。

> ▸ **答案**
>
> (a) E 是**确定性函数**：同一个 x 永远给出同一个 $x^e \bmod N$。所以若 $y_1 \neq y_2$，它们**不可能**来自同一个明文。进一步，Eve 可以建一张完全字典：把 $x = 2, \ldots, 54$ 全部加密一遍，得到 53 个密文；一旦收到任何密文，直接查表得明文。这是教科书 RSA 的**确定性加密 (deterministic encryption)** 缺陷。
>
> 在这个小例子上字典是可行的（$N = 55$ 只有 55 种可能），但在实际场景中即使 x 的空间很大，只要明文空间是**低熵**的（如"是/否"、金额、姓名），字典攻击同样有效。这就是为什么必须加随机填充。
>
> (b) 利用**可乘性**：$E(x_1) \cdot E(x_1) \equiv x_1^e \cdot x_1^e = (x_1^2)^e \equiv E(x_1^2) \pmod N$。
>
> $$E(13)^2 = 52^2 = 2704, \qquad 2704 \bmod 55 = 2704 - 49 \times 55 = 2704 - 2695 = 9.$$
>
> 所以 Eve 不需要知道 $x_1 = 13$（虽然这里她查表就能知道），直接算出 $\boxed{9}$ 就是 $E(13^2 \bmod 55) = E(169 \bmod 55) = E(4)$ 的密文。
>
> 验证：$E(4) = 4^3 = 64 \equiv 64 - 55 = 9$ ✔，与 $52^2 \bmod 55 = 9$ 完全一致。
>
> 这意味着 Eve 能把"密文 52"变换成"密文 9"，即把消息 13 篡改成消息 4（因为 $169 \equiv 4 \pmod{55}$），而 Bob 解密 9 得到 4 时**完全无法察觉密文被改动过**。这正是必须用认证加密或随机填充消解的结构性漏洞。

Lecture 7: Polynomials（多项式）

概述

前六讲我们处理的都是**单个数字**的模算术：x 的逆元、$a^{p-1} \bmod p$、$N = pq$ 的分解。本讲把视角抬高一维——研究**函数**：多项式 (polynomial)。核心问题是：一个多项式有多少个根？需要多少个点的取值才能把它完全钉死？

答案是两个极其简洁的定理：**次数为 d 的非零多项式最多有 d 个根**，以及**$d+1$ 个横坐标互不相同的点唯一确定一个次数不超过 d 的多项式**。第二定理的构造性证明叫**拉格朗日插值 (Lagrange interpolation)**。

真正让这两个定理"活"起来的，是把它搬到**有限域 (finite field)** $\mathbb{F}_p$ 上。在实数上这些性质早就熟悉；但在只有 p 个元素的有限域上，同样的代数结论竟然原封不动地成立——这一"神奇事实"是下一讲秘密共享 (secret sharing) 与纠错码 (error-correcting codes) 的全部基础。

本讲最容易踩的两个坑是：(1) 在 $\mathbb{Z}_m$ 上 m 不是质数时，两个定理**全都失效**（例如模 8 下 x^3 有 4 个根）；(2) 在 $\mathbb{F}_p$ 上，**多项式函数**与**多项式**不是一回事：x^p 与 x 作为函数完全相同，但作为多项式不同。次数不超过 $p-1$ 时两者才一一对应。

核心概念的直观解释

多项式 (polynomial) 与次数 (degree)

- **定义**：单变量多项式是形如

$$p(x) = a_d x^d + a_{d-1} x^{d-1} + \cdots + a_1 x + a_0$$

的表达式，其中**系数 (coefficients)** a_i 取自某个数系（实数、有理数、复数，或本讲重点 $\mathbb{F}_p$）。若 $a_d \neq 0$，则称 p 的**次数 (degree)** 为 d，记 $\deg p = d$，a_d 称为**首项系数 (leading coefficient)**。零多项式 $p(x) \equiv 0$ 的次数不做定义（或约定为 $-\infty$），这是后面几个定理都要单独排除它的原因。 – **直观解释（"它是什么意思？"）**：多项式是"**最听话的函数**"。它由一个有限的信息清单完全决定——只要给我那 $d+1$ 个系数，我就能算出它在**任意**输入上的取值，无论输入是 0、1000 还是 10^{100}。更惊人的是反过来：只要给我**有限个点**的取值（具体说是 $d+1$ 个），我也能反推出整个系数清单。对比一下：一个任意的函数 $f : \mathbb{R} \to \mathbb{R}$ 需要无穷多条信息才能描述；而多项式只需要 $d+1$ 个数字。这就是下一讲秘密共享的立足点——把秘密编码成多项式的一个系数，然后只分发**点**。 – **具体示例**：$p(x) = 5x^3 + 2x + 1$。它的次数 $d = 3$，系数为 $a_3 = 5$，$a_2 = 0$，$a_1 = 2$，$a_0 = 1$。注意**缺失的项系数为 0**，"次数是 3"并不意味着 3 个系数都非零。这个元素在 $x = 2$ 处的取值是 $5 \cdot 8 + 2 \cdot 2 + 1 = 45$。

根 (root)

- **定义**：a 是 $p(x)$ 的根，如果 $p(a) = 0$。
- **直观解释**：根就是曲线与 x 轴的交点。d 次曲线可以上下起伏很多次，但**它只有 d 次机会穿过 x 轴**——除非它压根就是零多项式 $y = 0$（那条与 x 轴重合的直线，有无穷多个"根"）。这正是"非零"这个条件不可省的原因。
- **具体示例**：$p(x) = x^2 - 4$ 是 2 次多项式，根是 2 与 -2，正好 2 个，达到上界。$q(x) = x^2 + 1$ 在 $\mathbb{R}$ 上一个根都没有（上界不紧，定理只说"最多"，没说"恰好"）。但在 $\mathbb{F}_5$ 上，q 有根 2 和 3（因为 $2^2 + 1 = 5 \equiv 0$，$3^2 + 1 = 10 \equiv 0$）——**同一个多项式在不同域上的根完全不同**，这是本讲反复出现的重要现象。

多项式相等：两种截然不同的含义

- **定义**：**系数意义下的相等**：两个多项式相等，当且仅当**逐项系数相等**（同次项系数全同）。**函数意义下的相等**：两个多项式相等，当且仅当对定义域中**每一个 x** 都有相同的取值。在 $\mathbb{R}$ 上，这两种含义恰好等价。在有限域 $\mathbb{F}_p$ 上，**它们不等价**。
- **直观解释**：这是本讲最重要的观念分水岭。在 $\mathbb{R}$ 上定义域有无穷多个元素，"处处相同"是很难满足的条件；在 $\mathbb{F}_p$ 上定义域只有 p 个元素，"处处相同"只是 p 个等式——**弱得多**。所以函数相等只能"压住"那些被 p 个点全部覆盖掉的多项式。
- **具体示例**：在 $\mathbb{F}_7$ 上，把 $x = 0, 1, \ldots, 6$ 全代进去，x^7 与 x 的取值分别是 $0, 1, 2, 3, 4, 5, 6$ 与 $0, 1, 2, 3, 4, 5, 6$——**完全一样**（这正是费马小定理的推论）。但 x^7 的次数是 7 而 x 的次数是 1，作为多项式它们显然不同。$x^7 - x$ 是 $\mathbb{F}_7$ 上**次数为 7 但有 7 个根**的多项式，恰好触到上界（且说明了为什么上界必须是 d

而不是 $p-1$）。

有限域 (finite field) $\mathbb{F}_p$

- **定义**：设 m 为正整数。我们说在 $\mathbb{Z}_m$ 上"能做域运算"，如果加、减、乘、除（除零以外）全都封闭。这成立**当且仅当 m 是质数**。此时记作 $\mathbb{F}_m$ 或 $GF(m)$（Galois Field，伽罗瓦域）。域 (field) 是一组满足特定公理的集合，这些公理正是让多项式性质成立的全部基础。
- **直观解释**：多项式理论的所有证明**只用到一件事**：你能对任意两个元素做加减乘除，只要不除以零。所以真正需要的不是"实数"这个具体数系，而是"能做四则运算"这个抽象结构。$\mathbb{R}$、$\mathbb{Q}$、$\mathbb{C}$ 都满足；$\mathbb{Z}_p$（p 质数）也满足，因为讲次 4/5 已证 $\mathbb{Z}_p$ 中每个非零元都有乘法逆元。但 $\mathbb{Z}_8$ 不满足——2 没有逆元——于是所有定理立即崩塌。
- **具体示例**：$\mathbb{F}_5$ 上的除法：要算 $\frac{3}{2}$，先求 $2^{-1} \bmod 5 = 3$（因为 $2\times 3 = 6 \equiv 1$），所以 $\frac{3}{2} = 3\times 3 = 9 \equiv 4 \pmod 5$。验算：$2\times 4 = 8 \equiv 3$ ✔。在 $\mathbb{F}_7$ 上 $\frac{1}{2} = 4$（$2\times 4 = 8 \equiv 1$），$\frac{1}{-1} = -1 \equiv 6$。

系数表示与取值表示

- **定义**：用 $d+1$ 个系数 $(a_0, a_1, \ldots, a_d)$ 来指定一个次数不超过 d 的多项式，叫**系数表示 (coefficient representation)**；用它在 $d+1$ 个点上的取值 $(y_0, y_1, \ldots, y_d)$（对应 $x = 0, 1, \ldots, d$）来指定，叫**取值表示 (value representation)**。
- **直观解释**：同一个对象的两套"坐标系"。系数表示适合做加法、乘法、求导；取值表示适合做逐点运算（想算 $p\cdot q$ 在某点的值？直接两个值相乘即可，不用展开多项式）。两者之间的转换：系数 → 取值靠**代入求值**（$O(d^2)$ 或更快）；取值 → 系数靠**拉格朗日插值**。这正是下一讲里"分享秘密 / 恢复秘密"两步的代数形式。
- **具体示例**：$\mathbb{F}_7$ 上次数不超过 2 的多项式共 $7^3 = 343$ 个（3 个系数各 7 种取值），由在 $x = 0, 1, 2$ 三点的取值也恰好是 $7^3 = 343$ 种可能。两套表示的数量一致，暗示了它们之间存在一一对应——这就是插值定理的计数版"预告"。

拉格朗日基多项式 (Lagrange basis polynomial)

- **定义**：给定两两不同的 $x_1, \ldots, x_{d+1}$，定义

$$\Delta_i(x) = \prod_{j\neq i} \frac{x - x_j}{x_i - x_j}.$$

- **直观解释**：Δ_i 是一个"**开关函数**"（在数学上叫指示函数）：它在 x_i 处取 1，在所有其他 x_j（$j\neq i$）处取 0。想构造一个在点 x_i 上取指定值 y_i 的多项式？只要把开关 Δ_i 乘以 y_i 再加起来。**这些开关只依赖于 $x_1, \ldots, x_{d+1}$ 的位置，与目标值 y_i 完全无关**——所以可以事先把开关造好，反复使用。这和 CRT 中的"基向量" b_i（在方向 i 上取 1、其他方向取 0）是同一个思想。
- **具体示例**：取 $x_1 = 1, x_2 = 2, x_3 = 3$（$d+1 = 3$）。则

$$\Delta_2(x) = \frac{(x-1)(x-3)}{(2-1)(2-3)} = \frac{(x-1)(x-3)}{-1} = -(x-1)(x-3) = -x^2 + 4x - 3.$$

代入检验：$\Delta_2(1) = -1 + 4 - 3 = 0$ ✔，$\Delta_2(2) = -4 + 8 - 3 = 1$ ✔，$\Delta_2(3) = -9 + 12 - 3 = 0$ ✔。

完整证明与推导（核心）

定理 7.1（多项式除法定理 / Polynomial Division）：设 $p(x)$ 是次数为 d 的多项式，$q(x)$ 是次数 $\le d$ 的多项式且 $q \not\equiv 0$。则存在唯一的多项式对 $(q'(x), r(x))$ 使得

$$p(x) = q'(x)q(x) + r(x), \qquad \deg r < \deg q.$$

q' 称为**商 (quotient)**，r 称为**余式 (remainder)**。

证明策略：这是一个**构造性证明**——用长除法（小学竖式除法的多项式版本）显式地把 q' 与 r 造出来，再论证唯一性。构造过程每一步都**消掉当前最高次项**，所以必然终止。

逐步推导（先看一个完整的算例）：

用 $p(x) = x^3 + x^2 - 1$ 除以 $q(x) = x - 1$。

第 1 步：p 的最高次项是 x^3，q 的最高次项是 x。商里要放 x^2，因为 $x^2\cdot(x-1) = x^3 - x^2$。

$$p(x) - x^2(x-1) = (x^3 + x^2 - 1) - (x^3 - x^2) = 2x^2 - 1.$$

第 2 步：剩 $2x^2 - 1$，最高次项 $2x^2$。商里放 $2x$，因为 $2x(x-1) = 2x^2 - 2x$。

$$(2x^2 - 1) - 2x(x-1) = (2x^2 - 1) - (2x^2 - 2x) = 2x - 1.$$

第 3 步：剩 $2x - 1$，最高次项 $2x$。商里放 2，因为 $2(x-1) = 2x - 2$。

$$(2x - 1) - 2(x-1) = (2x - 1) - (2x - 2) = 1.$$

第 4 步：剩余的 1 的次数 $0 < \deg q = 1$，停止。

把三步合并：

$$p(x) = x^2(x-1) + 2x(x-1) + 2(x-1) + 1 = (x^2 + 2x + 2)(x-1) + 1.$$

所以商 $q'(x) = x^2 + 2x + 2$，余式 $r(x) = 1$。

验算：$(x^2 + 2x + 2)(x-1) = x^3 + 2x^2 + 2x - x^2 - 2x - 2 = x^3 + x^2 - 2$，再加 1 得 $x^3 + x^2 - 1$ ✔。

用熟悉的竖式写法：

```
          X^2 + 2X + 2          <- 商 q'(x)
        ┌──────────────────────
X - 1 │ X^3 + X^2 + 0X - 1    <- 被除数 p(x)（补上缺失的 0X 项）
        X^3 - X^2               <- 减去 X^2·(X-1)
        ──────────
              2X^2 + 0X         <- 差 2X^2 - 1 的 0X 是占位
              2X^2 - 2X         <- 减去 2X·(X-1)
              ─────────
                    2X - 1      <- 差
                    2X - 2      <- 减去 2·(X-1)
                    ──────
                         1      <- 余式 r(x) = 1，次数 0 < 1
```

一般情形的构造：初始化 $r \leftarrow p$，$q' \leftarrow 0$。只要 $\deg r \geq \deg q$，设 r 的首项为 cx^e（$e = \deg r$）、q 的首项为 bx^f（$f = \deg q \leq e$）。令单项式 $t(x) = \frac{c}{b}x^{e-f}$（$\frac{c}{b}$ 在域中存在，因为 $b \neq 0$），做

$$q' \leftarrow q' + t, \qquad r \leftarrow r - t \cdot q.$$

这样 r 的 x^e 项被精确消成 0，所以新的 $\deg r < e$，**严格下降**。因为次数是非负整数，过程必然在有限步后使 $\deg r < \deg q$ 而终止。

唯一性：设 $p = q_1'q + r_1 = q_2'q + r_2$，其中 $\deg r_1, \deg r_2 < \deg q$。相减得

$$(q_1' - q_2')q = r_2 - r_1.$$

若 $q_1' \neq q_2'$，则左边是次数 $\geq \deg q$ 的非零多项式（域上多项式乘积的次数等于次数之和，因为首项系数之积不为零）；而右边次数 $< \deg q$。矛盾。故 $q_1' = q_2'$，进而 $r_1 = r_2$。∎

【证明机制解说】：关键在于**域**这个条件——每一步都要除以 q 的首项系数 b，这要求 b 可逆。在 $\mathbb{Z}_8$ 上除不尽就会卡住（比如试图用 $2x+1$ 除 x^2 时系数 $\frac{1}{2}$ 不存在）。第二个关键是**次数严格下降**这个"进度度量"，它保证构造终止——和讲次 5 中欧几里得算法的"余数严格变小"是同一个套路。

定理 7.2（因式定理 / Factor Theorem）：设 $P(x)$ 为多项式，r 为常数。则

$$(x - r) \mid P(x) \quad \Longleftrightarrow \quad P(r) = 0.$$

证明策略：**双向证明**（等价命题要证两个方向）。充分性（⇐）用定理 7.1 的带余除法：除以 $x - r$ 得到的余式次数 < 1，所以是常数 c，再把 $x = r$ 代进去求出 c。必要性（⇒）直接代入。

逐步推导：

(⇒) 设 $(x - r) \mid P(x)$，即存在多项式 Q 使 $P(x) = (x - r)Q(x)$。代入 $x = r$：

$$P(r) = (r - r) \cdot Q(r) = 0 \cdot Q(r) = 0. \qquad \checkmark$$

(⇐) 设 $P(r) = 0$。用 $x - r$（次数 1，$\leq \deg P$）作除数，由定理 7.1 存在商 Q 与余式 R 使

$$P(x) = (x - r)Q(x) + R(x), \qquad \deg R < \deg(x - r) = 1.$$

$\deg R < 1$ 意味着 R 是常数，记 $R(x) = c$。代入 $x = r$：

$$P(r) = (r - r)Q(r) + c = c.$$

由假设 $P(r) = 0$ 得 $c = 0$，即 $R \equiv 0$。于是 $P(x) = (x - r)Q(x)$，即 $(x - r) \mid P(x)$。∎

若 P 的次数为 $d \geq 1$ 且首项系数为 a_d，则由 $P = (x - r)Q$ 比较首项系数知 Q 的次数恰为 $d - 1$、首项系数为 a_d。

【证明机制解说】：这个引理是**根定理的发动机**。它把"求值等于零"（一个数值事实）翻译成"有一个线性因子"（一个代数结构事实）。有了这个翻译，我们就可以**反复提取因子**：每找到一个根就砍掉一次次数。这正是下面定理 7.3 归纳证明的机制。

反例（在非域上定理失效）：定理 7.2 的证明**依赖定理 7.1 的带余除法**，而带余除法在 $\mathbb{Z}_m$（m 非质数）上可能失败。取 $m = 8$，$P(x) = x^3$，$r = 2$。$P(2) = 8 \equiv 0 \pmod 8$，所以 2 是根。但是否有 $(x - 2) \mid x^3$ 在 $\mathbb{Z}_8[x]$ 中？若 $x^3 = (x - 2)Q(x)$，则 Q 必须是次数 2 的多项式 $ax^2 + bx + c$。展开得 $ax^3 + (b - 2a)x^2 + (c - 2b)x - 2c$。比较系数：$a = 1$；$b - 2a = 0 \Rightarrow b = 2$；$c - 2b = 0 \Rightarrow c = 4$；最后 $-2c = -8 \equiv 0 \pmod 8$ ✔ 竟然成立。所以这次因式分解碰巧还能做——但下面的反例会说明在 $\mathbb{Z}_8$ 上根定理整体崩掉。

定理 7.3（有限根定理 / Degree-Root Bound）：设 $\mathbb{F}$ 为任意域（$\mathbb{R}$、$\mathbb{Q}$、$\mathbb{C}$ 或 $\mathbb{F}_p$），$P(x)$ 是 $\mathbb{F}$ 上**非零**的、次数为 d 的多项式。则 P 在 $\mathbb{F}$ 中**最多有 d 个根**。

证明策略：**对次数 d 做（弱）归纳**。为了把归纳跑起来，先证一个辅助命题（Claim A）说明"差不多取到上界"的多项式能**完全因式分解**；然后用它推出根数的上界。

逐步推导：

Claim A：若 $P(x)$ 是次数为 $d \geq 1$ 的多项式，且 $a_1, \ldots, a_d$ 是 P 的 d 个**两两不同**的根，则存在常数 $c \neq 0$ 使

$$P(x) = c(x - a_1)(x - a_2) \cdots (x - a_d).$$

Claim A 的证明（对 d 归纳）：

- **基础情形 $d=1$**：$P(x)=a_1'x+a_0$ 且 $a_1'\neq 0$。设 a_1 是它的根，则 $0=P(a_1)=a_1'a_1+a_0$，所以 $a_0=-a_1'a_1$，于是 $P(x)=a_1'x-a_1'a_1=a_1'(x-a_1)$，即 $c=a_1'\neq 0$ 的形式。✔

（若约定基础情形为 $d=0$：次数为 0 的多项式是常数 $c\neq 0$，它没有根，Claim A 的前提"有 $d=0$ 个不同根"平凡满足，而 $P=c$ 正是空乘积形式。两种约定都可以，下面用 $d\geq 1$ 的版本，更直观。）

- **归纳假设**：对某个 $d\geq 1$，任何次数为 d、有 d 个不同根的多项式都能写成首项系数乘以全体线性因子之积。
- **归纳步骤**：设 P 次数为 $d+1$，有 $d+1$ 个两两不同的根 $a_1,\dots,a_{d+1}$。取 a_{d+1}：由因式定理（定理 7.2），$P(x)=(x-a_{d+1})Q(x)$，其中 Q 的次数为 $(d+1)-1=d$。

现在证明 $a_1,\dots,a_d$ 都是 Q 的根。对每个 $i\leq d$：

$$0=P(a_i)=(a_i-a_{d+1})Q(a_i).$$

因为各根**两两不同**，$a_i\neq a_{d+1}$，所以 $a_i-a_{d+1}\neq 0$。在**域**中非零元可逆，两边乘 $(a_i-a_{d+1})^{-1}$ 得 $Q(a_i)=0$。✔

于是 Q 是次数为 d 的多项式，有 d 个两两不同的根 $a_1,\dots,a_d$。由**归纳假设**，$Q(x)=c(x-a_1)\cdots(x-a_d)$，其中 c 是 Q 的首项系数（非零）。代回：

$$P(x)=(x-a_{d+1})\cdot c(x-a_1)\cdots(x-a_d)=c(x-a_1)\cdots(x-a_d)(x-a_{d+1}).\qquad\checkmark$$

由 Claim A 推出定理 7.3：Claim A 处理的是"**恰好** d 个根"的情形，而定理 7.3 要处理的是"**任意多个**根"的一般情形，所以不能直接套用。下面改用**因式定理 + 对次数归纳**，这是最顺的路径。

对 d 归纳证明"次数为 d 的非零多项式至多有 d 个根"。

- **基础情形 $d=0$**：非零常数 c 处处不为零，根数 $=0\leq 0$。✔
- **归纳假设**：次数为 d 的非零多项式至多有 d 个根。
- **归纳步骤**：设 P 次数为 $d+1$。若 P 无根，根数 $0\leq d+1$ ✔。否则取一个根 r，由因式定理 $P(x)=(x-r)Q(x)$，$\deg Q=d$。

设 a 是 P 的任意根，即 $0=P(a)=(a-r)Q(a)$。因为**域中没有零因子**（$uv=0\Rightarrow u=0$ 或 $v=0$；等价说法：非零元可逆），所以 $a=r$ 或 $Q(a)=0$。因此 P 的根集 $\subseteq\{r\}\cup\{Q$ 的根$\}$。由归纳假设 Q 至多有 d 个根，所以 P 的根数至多 $d+1=\deg P$。■

【证明机制解说】：整个证明的支点是**域没有零因子**这一条性质：$(a-r)Q(a)=0$ 时必有一边为零。在 $\mathbb{Z}_8$ 上这句话就假了——$2\cdot 4=8\equiv 0$，而 $2\neq 0$、$4\neq 0$。这一个漏洞会让整座大厦倒塌（见下面的反例）。另一处同样重要的是**归纳假设的用法**：从 P 剥掉一个线性因子，得到一个次数更小、根更少的 Q，把问题交给归纳假设。

反例 7.4（在非域 $\mathbb{Z}_8$ 上根定理彻底失效）

在 $\mathbb{Z}_8$ 上看 $P(x)=x^3$。它的次数是 3，按定理 7.3 应有至多 3 个根。实际检查 $x=0,1,\dots,7$：

x	0	1	2	3	4	5	6	7
$x^3 \bmod 8$	0	1	0	3	0	5	0	7
是否根	✔		✔		✔		✔	

4 个根：$\{0,2,4,6\}$。这比次数 3 还多，直接违反定理 7.3；插值定理（定理 7.6）也随之失效（存在性、唯一性都不成立）。

根因：$\mathbb{Z}_8$ 中 $2\cdot 4=8\equiv 0$，存在**零因子 (zero divisor)**。无法在 $\mathbb{Z}_8$ 里补出一个"域"来救这个定理——虽然确实存在含 8 个元素的域，但它**不是** $\mathbb{Z}_8$，而是一个更复杂的构造（$\mathbb{F}_2$ 上的一次扩域）。这说明 p 为质数这个条件是**本质的**，不是技术上的便利。

反例 7.5（根定理的上界不可放宽）

在 $\mathbb{F}_7$ 上取 $P(x)=x(x-1)(x-2)=x^3-3x^2+2x$，次数 $d=3$。代入得根 $\{0,1,2\}$，恰好 3 个，**正好触到上界**——所以"至多 d 个"不能改进为"至多 $d-1$ 个"。

更极端的是 $P(x)=x^7-x$ 在 $\mathbb{F}_7$ 上。对 $x=0,1,\dots,6$，由费马小定理 $x^7\equiv x\pmod 7$，所以 $P(x)\equiv 0$ **对全部 7 个元素成立**，即有 7 个根。而 $\deg(x^7-x)=7$，上界 $d=7$ 依然成立——**这个例子恰好说明了为什么上界的形式是 d 而不是 $p-1$**。

下面这张图直观地对比了"在 $\mathbb{R}$ 上"与"在 $\mathbb{F}_7$ 上"同一个次数上界的含义：

```
(A) 实数域 R 上：d 次曲线的"根"= 与 x 轴的交点，至多 d 个
    P(x) = (1/2)x^2 − (1/2)x + 1          （算例 A 的结果）
      y
      |        *                    * = 数据点 (1,1),(2,2),(3,4)
    4 |                 ●
      |               /   \
    2 |      ●      /       \
      |    /    \ /            \
    1 ●——        ●               \
      └──┬──┬──┬──┬──┬──┬──→ x
         1  2  3  4  5  6
    P(4) = 7（插值外推）；在 R 上 P 无实根（判别式 1−8 = −7 < 0）

(B) 有限域 F_7 上：定义域只有 7 个孤立点，"曲线"退化成 7 个孤立坐标
    P(x) = 4x^2 + 3x + 1                （算例 B：同一个三点表的 F_7 版本）
      y
    6 |
    5 |
    4 |        ●              ●          ● = 非零取值
    3 |
    2 |           ●                 ●
    1 | ●      ●
    0 |_____________________________○_______  x
        0   1   2   3   4   5   6
       P 的取值表：( 1,  1,  2,  4,  0,  4,  2 )
                     ↑   ↑              ↑
                   x=0  x=1           x=4 ← 唯一的根
    ○ = 根 P(4) = 4·16 + 3·4 + 1 = 77 ≡ 77 − 77 = 0 (mod 7)
    注意：同一个多项式在 R 上（算例 A）判别式 1−8 = −7 < 0，一个实根都没有；
          在 F_7 上却有一个根 x = 4。数根必须指明"在哪个域中数"。

(C) 根个数与次数的关系（F_7，次数 d ≤ 6）
    d 次非零多项式：最多 d 个根          ← 定理 7.3
    x(x−1)(x−2) : d=3, 根={0,1,2}       恰 3 个 = 上界（紧）
    x^7 − x     : d=7, 根={0,1,...,6}   恰 7 个 = 上界（紧）
    x^2 + 1 在 F_5 上 : d=2, 根={2,3}    恰 2 个（对比：R 上 0 个根）
    x^3 在 Z_8 上     : d=3, 根={0,2,4,6}  4 个 > 3 ✗ 非域!
```

定理 7.6（插值定理 / Lagrange Interpolation）：给定 $d+1$ 对数据

$$(x_1, y_1), (x_2, y_2), \ldots, (x_{d+1}, y_{d+1}),$$

其中 $x_1, \ldots, x_{d+1}$ **两两不同**（都在同一个域 $\mathbb{F}$ 中），则**存在唯一**的一个次数**不超过** d 的多项式 $P(x)$ 满足 $P(x_i) = y_i$（$1 \le i \le d+1$）。

证明策略：**存在性用构造性证明**（把多项式显式写出来并验证），**唯一性用反证法 + 根定理**。选这个策略的理由是：存在性有一条非常干净的代数路径（基函数法），而唯一性几乎"免费"地由定理 7.3 得到。

逐步推导（第一部分：存在性）

第 1 步：先解一个"最简单的"特例。

假设目标取值是 $y_1 = 1$ 而 $y_2 = y_3 = \cdots = y_{d+1} = 0$。这时我们要的多项式是什么？观察

$$q(x) = (x - x_2)(x - x_3) \cdots (x - x_{d+1}).$$

x 出现了 d 次，所以 $\deg q = d$ ✔。当 $j \ge 2$ 时，$q(x_j)$ 的乘积里含有因子 $(x_j - x_j) = 0$，所以 $q(x_j) = 0$ ✔。而

$$q(x_1) = (x_1 - x_2)(x_1 - x_3) \cdots (x_1 - x_{d+1}) \neq 0,$$

因为每个因子 $x_1 - x_j \neq 0$（x_i 两两不同），而域中没有零因子。所以 $q(x_1)$ 可逆，我们可以把它"归一化"：

$$P(x) = \frac{q(x)}{q(x_1)}.$$

这满足 $P(x_1) = 1$ 与 $P(x_j) = 0$（$j \ge 2$）✔。

小算例：给定 $(1,1), (2,0), (3,0)$。则 $q(x) = (x-2)(x-3) = x^2 - 5x + 6$，$q(x_1) = q(1) = (1-2)(1-3) = 2$。所以 $P(x) = \frac{x^2 - 5x + 6}{2}$。检验：$P(1) = \frac{1-5+6}{2} = \frac{2}{2} = 1$ ✔，$P(2) = \frac{4-10+6}{2} = \frac{0}{2} = 0$ ✔，$P(3) = \frac{9-15+6}{2} = \frac{0}{2} = 0$ ✔。

第 2 步：把这个特例推广到任意一个指标 i。

把"第 1 个点取 1、其余取 0"换成"第 i 个点取 1、其余取 0"，定义

$$\boxed{\Delta_i(x) = \frac{\prod_{j \neq i}(x - x_j)}{\prod_{j \neq i}(x_i - x_j)}}$$

分母 $\prod_{j \neq i}(x_i - x_j)$ 是**非零常数**（x 一个都不出现，全由 x_k 构成；且每个因子非零，无零因子故乘积非零），所以这个除法合法。由构造：

$$\Delta_i(x_k) = \begin{cases} 1 & k = i \\ 0 & k \neq i \end{cases} \quad \text{即} \quad \Delta_i(x_k) = \delta_{ik} \ \text{(Kronecker delta)}.$$

每个 Δ_i 的次数恰好是 d（分子是 d 个一次因式之积）。这些 Δ_i 称为**拉格朗日基多项式**。

第 3 步：线性组合得到一般解。

$$\boxed{P(x)=\sum_{i=1}^{d+1} y_i\,\Delta_i(x).}$$

验证：P 是 $d+1$ 个次数 $\le d$ 的多项式之和，故 $\deg P\le d$ ✔。代入 $x=x_k$：

$$P(x_k)=\sum_{i=1}^{d+1} y_i\Delta_i(x_k)=y_k\cdot 1+\sum_{i\neq k} y_i\cdot 0=y_k. \qquad \checkmark$$

存在性证毕。

逐步推导（第二部分：唯一性）

反设存在**另一个**次数 $\le d$ 的多项式 $Q(x)\neq P(x)$ 满足 $Q(x_i)=y_i$ 对全部 i。考虑差

$$R(x)=P(x)-Q(x).$$

R 是次数 $\le d$ 的多项式。因为 $P\neq Q$ 作为多项式不同，R **不是**零多项式（次数 $\le d$ 的多项式的系数逐一相减，不全为零）。于是 R 有确定的次数 $\deg R=d'\le d$。

另一方面，对每个 $i\in\{1,\dots,d+1\}$：

$$R(x_i)=P(x_i)-Q(x_i)=y_i-y_i=0.$$

所以 R 有 $d+1$ 个**两两不同**的根 $x_1,\dots,x_{d+1}$。

由**定理 7.3**（有限根定理），次数为 $d'\le d$ 的非零多项式至多有 $d'\le d$ 个根。但 R 有 $d+1>d\ge d'$ 个根，**矛盾**。

所以不存在这样的 Q，P 唯一。■

【证明机制解说】：两个部分各有各的巧妙。

存在性的核心是"**先解最简单的情形再线性叠加**"。这个套路在数学里到处出现（CRT 的基向量、线性代数里"标准基 + 坐标"、傅里叶级数里的正交基）。拉格朗日基 Δ_i 就是"取值空间"里的一组标准基：Δ_i 是"第 i 个坐标为 1、其余为 0"的单位向量。$P=\sum y_i\Delta_i$ 就是"以 $(y_1,\dots,y_{d+1})$ 为坐标的线性组合"。注意 Δ_i **只依赖 $x_1,\dots,x_{d+1}$，不依赖 y_i**——所以可以预先造好基，之后任意调整系数即可。

唯一性的核心是"**把两个候选解相减，得到一个根太多的小多项式**"。R 有 $d+1$ 个根但次数 $\le d$，违反根定理，故 R 只能是零多项式——而零多项式就意味着 $P=Q$。这是一个标准的"**反证 + 计数**"论证：把"存在两个不同解"的假设转化成"存在一个违反已知界的对象"。

为什么这个定理如此重要：它说的恰是"$d+1$ 个点唯一确定一个 d 次多项式"。认定这句话有三重含义：（i）**信息量恰好匹配**——$d+1$ 个点的取值（$d+1$ 个域元素）与 $d+1$ 个系数一一对应；（ii）**任意 d 个点都不够**（有多个候选多项式），$d+1$ **个点就够**（唯一）；（iii）这个"够与不够"的临界点正是下一讲Shamir **秘密共享**的门限 k：分发 n 份，任意 k 份可恢复、任意 $k-1$ 份零信息。

完整手算插值算例 A（官方 Note 的算例，实数域）

求过 $(1,1),(2,2),(3,4)$ 的次数 ≤ 2 多项式（$d=2$，$d+1=3$ 个点）。

基多项式：

$$\Delta_1(x)=\frac{(x-2)(x-3)}{(1-2)(1-3)}=\frac{(x-2)(x-3)}{(-1)(-2)}=\frac{(x-2)(x-3)}{2}=\frac{1}{2}x^2-\frac{5}{2}x+3.$$

$$\Delta_2(x)=\frac{(x-1)(x-3)}{(2-1)(2-3)}=\frac{(x-1)(x-3)}{(1)(-1)}=\frac{(x-1)(x-3)}{-1}=-x^2+4x-3.$$

$$\Delta_3(x)=\frac{(x-1)(x-2)}{(3-1)(3-2)}=\frac{(x-1)(x-2)}{(2)(1)}=\frac{(x-1)(x-2)}{2}=\frac{1}{2}x^2-\frac{3}{2}x+1.$$

组合：

$$P(x)=1\cdot\Delta_1(x)+2\cdot\Delta_2(x)+4\cdot\Delta_3(x).$$

逐项累加（先按 x^2,x^1,x^0 分组）：

- x^2 项：$\frac{1}{2}+2\cdot(-1)+4\cdot\frac{1}{2}=\frac{1}{2}-2+2=\frac{1}{2}$
- x^1 项：$-\frac{5}{2}+2\cdot 4+4\cdot(-\frac{3}{2})=-\frac{5}{2}+8-6=-\frac{1}{2}$
- x^0 项：$3+2\cdot(-3)+4\cdot 1=3-6+4=1$

$$\boxed{P(x)=\frac{1}{2}x^2-\frac{1}{2}x+1.}$$

验算：$P(1)=\frac{1}{2}-\frac{1}{2}+1=1$ ✔；$P(2)=2-1+1=2$ ✔；$P(3)=\frac{9}{2}-\frac{3}{2}+1=3+1=4$ ✔。

顺带观察：$P(0)=1$，$P(4)=8-2+1=7$。插值把一个离散的三点表变成了可以预测第四点、第五点的连续模型——这正是"多项式是最听话的函数"的含义。

完整手算插值算例 B（同一组点的 $\mathbb{F}_7$ 版本）

仍然求过 $(1,1),(2,2),(3,4)$。注意这三个点在 $\mathbb{F}_7$ 中的横坐标互不相同，且 $4<7$，所以数据合法。

基多项式（除法 = 乘以逆元）：$\mathbb{F}_7$ 中 $2^{-1}=4$（$2\times4=8\equiv1$），$(-1)^{-1}=6$（$-1\equiv6$，$6\times6=36\equiv1$）。

$$\Delta_1(x)=\frac{(x-2)(x-3)}{2}=4(x-2)(x-3)=4(x^2-5x+6)=4x^2-20x+24\equiv4x^2+x+3\pmod 7.$$

（$-20\equiv-20+21=1$，$24\equiv24-21=3$。）

$$\Delta_2(x)=\frac{(x-1)(x-3)}{-1}=6(x-1)(x-3)=6(x^2-4x+3)=6x^2-24x+18\equiv6x^2+4x+4\pmod 7.$$

（$-24\equiv-24+28=4$，$18\equiv18-14=4$。）

$$\Delta_3(x)=\frac{(x-1)(x-2)}{2}=4(x-1)(x-2)=4(x^2-3x+2)=4x^2-12x+8\equiv4x^2+2x+1\pmod 7.$$

（$-12\equiv-12+14=2$，$8\equiv1$。）

组合：$P(x)=1\cdot\Delta_1+2\cdot\Delta_2+4\cdot\Delta_3$。

- x^2：$4+2\cdot6+4\cdot4=4+12+16=32\equiv32-28=4$
- x^1：$1+2\cdot4+4\cdot2=1+8+8=17\equiv17-14=3$
- x^0：$3+2\cdot4+4\cdot1=3+8+4=15\equiv15-14=1$

$$\boxed{P(x)=4x^2+3x+1\text{ 在 }\mathbb{F}_7\text{ 上.}}$$

验算：$P(1)=4+3+1=8\equiv1$ ✔；$P(2)=16+6+1=23\equiv23-21=2$ ✔；$P(3)=36+9+1=46\equiv46-42=4$ ✔。在 $\mathbb{F}_7$ 上的完整取值表是 $(1,1,2,4,0,4,2)$——注意 $x=4$ 处取 0，即 4 是这个多项式在 $\mathbb{F}_7$ 上的根，而它在 $\mathbb{Q}$ 上的根是 $\frac{1\pm\sqrt{-7}}{4}$（非有理数）。**同一个"系数模式"的插值多项式在不同域上有完全不同的根结构**。

完整手算插值算例 C（教科书式的三点算例，$(0,1),(1,2),(2,5)$）

$d=2$，三个横坐标 $0,1,2$ 两两不同。

基多项式：分母分别是 $(0-1)(0-2)=2$、$(1-0)(1-2)=-1$、$(2-0)(2-1)=2$。

$$\Delta_1(x)=\frac{(x-1)(x-2)}{2},\qquad\Delta_2(x)=\frac{x(x-2)}{-1}=-x(x-2),\qquad\Delta_3(x)=\frac{x(x-1)}{2}.$$

组合：

$$P(x)=1\cdot\frac{(x-1)(x-2)}{2}+2\cdot[-x(x-2)]+5\cdot\frac{x(x-1)}{2}.$$

逐项展开：

$$=\frac{x^2-3x+2}{2}-2(x^2-2x)+\frac{5(x^2-x)}{2}=\frac{x^2-3x+2}{2}-2x^2+4x+\frac{5x^2-5x}{2}.$$

按次合并：x^2 项 $\frac12-2+\frac52=1$；x^1 项 $-\frac32+4-\frac52=0$；x^0 项 $\frac22=1$。所以

$$\boxed{P(x)=x^2+1.}$$

验算：$P(0)=1$ ✔；$P(1)=1+1=2$ ✔；$P(2)=4+1=5$ ✔。$P(3)=10$。

（**重要提醒**：这组数据常被误算成 $1+\frac12x+\frac32x^2$——代入 $x=1$ 得 $1+0.5+1.5=3\neq2$，**是错的**。请务必自己代回原数据检验，这是插值题唯一可靠的验算方式。）

$\mathbb{F}_7$ 版本：$\mathbb{F}_7$ 中 $2^{-1}=4$，$(-1)^{-1}=6$。

$$\Delta_1=4(x-1)(x-2)=4x^2+2x+1,\quad\Delta_2=6x(x-2)=6x^2+2x,\quad\Delta_3=4x(x-1)=4x^2+3x.$$

（验算 $\Delta_2=6(x^2-2x)=6x^2-12x\equiv6x^2+2x$，减 $12\equiv$ 加 2 ✔。）

$$P=1\cdot\Delta_1+2\cdot\Delta_2+5\cdot\Delta_3=(4+12+20)x^2+(2+4+15)x+1=36x^2+21x+1\equiv x^2+1\pmod 7.$$

（$36\equiv1$，$21\equiv0$ ✔。）在 $\mathbb{F}_7$ 上的完整取值表是 $(1,2,5,3,3,5,2)$，对 $x=0,1,2$ 分别给出 $1,2,5$ ✔。

有限域上的多项式函数：不唯一的表示

在 $\mathbb{F}_p$ 上，一个"函数"$f:\mathbb{F}_p\to\mathbb{F}_p$ 可以用很多个不同的多项式来"实现"。最经典的例子是：由费马小定理，对**每一个** $x\in\mathbb{F}_p$ 有

$$x^p\equiv x\pmod p,$$

所以 $P(x)=x^p$ 与 $Q(x)=x$ 作为**函数**完全相同，但作为**多项式**不同（次数 p vs 1）。

那么什么时候函数与多项式一一对应？答案是加上次数限制：

命题 7.7：在 $\mathbb{F}_p$ 上，次数**不超过** $p-1$ 的多项式与函数 $f:\mathbb{F}_p\to\mathbb{F}_p$ 之间存在**一一对应**。

证明：$\mathbb{F}_p$ 中的元素是 $x_1=0,x_2=1,\dots,x_p=p-1$，共 p 个，两两不同。由插值定理 7.6（取 $d=p-1$，则 $d+1=p$ 个点），任给一组函数值 $(y_0,\dots,y_{p-1})$ 存在**唯一**的次数 $\le p-1$ 的多项式取到这些值。而函数的个数是 p^p，次数 $\le p-1$ 的多项式的个数是 p^p（p 个系数各 p 种取值），两者相等，且映射满射 + 单射，故为双射。■

推论：$\mathbb{F}_p$ 上**任何**函数 f 都可以用唯一一个次数 $\le p-1$ 的多项式表示。而且任何次数 $\ge p$ 的多项式都可以通过反复减去 $c\cdot(x^p-x)x^m$ 来**降低次数**而不改变函数取值，最终归约到次数 $\le p-1$ 的唯一代表元。

具体示例（$\mathbb{F}_7$ 上）：x^7-x 作为函数恒为零，作为多项式次数为 7。更一般的例子：$P(x)=x^8+2x$ 在 $\mathbb{F}_7$ 上与哪个 ≤ 6 次多项式相同？因为 $x^7\equiv x$，所以 $x^8=x\cdot x^7\equiv x\cdot x=x^2$，于是 $P(x)\equiv x^2+2x \pmod 7$ 作为函数。次数从 8 降到 2。

Schwartz–Zippel 引理（有限域上多项式相等的概率界）

在 $\mathbb{F}_p$ 上，如果两个多项式 $P\neq Q$（作为多项式不同）但次数都不大，那么"随机取一个点恰好撞上它们相等"的概率很小。这就是 Schwartz–Zippel 引理：

引理 7.8（Schwartz–Zippel）：设 $\mathbb{F}$ 为域，$P,Q\in\mathbb{F}[x]$ 为两个**不同**的多项式，且 $\deg P,\deg Q\le d$。从 $\mathbb{F}$ 中**均匀随机**取一个元素 r，则

$$\Pr_{r\in\mathbb{F}}[P(r)=Q(r)]\le\frac{d}{|\mathbb{F}|}.$$

在 $\mathbb{F}_p$ 上即 $\Pr[P(r)=Q(r)]\le\frac{d}{p}$。

证明思路：令 $R(x)=P(x)-Q(x)$。因为 $P\neq Q$，R **不是**零多项式；又 $\deg R\le\max(\deg P,\deg Q)\le d$（实际次数记作 $d'\le d$）。事件 "$P(r)=Q(r)$ "恰好等价于 "r 是 R 的根"。

由有限根定理（定理 7.3），R 在 $\mathbb{F}$ 中最多有 d' 个根。在有限域 $\mathbb{F}_p$ 上，r 均匀分布在 p 个元素中，每个元素被抽中的概率是 $\frac{1}{p}$。于是

$$\Pr[R(r)=0]=\frac{|\{R\text{ 的根}\}|}{p}\le\frac{d'}{p}\le\frac{d}{p}.\qquad\blacksquare$$

具体示例一（$\mathbb{F}_5$）：取 $P(x)=x^2+1$，$Q(x)=x^2$，$d=2$。$P-Q=1$ 是常数，无根，所以 $\Pr[P(r)=Q(r)]=0\le\frac{2}{5}$ ✔（界不紧，但正确）。

取 $P(x)=x^2$，$Q(x)=1$，$P-Q=x^2-1=(x-1)(x+1)$。在 $\mathbb{F}_5$ 上根为 $x=1$ 与 $x=4$（因为 $-1\equiv4$），共 2 个。所以 $\Pr=\frac{2}{5}$，正好取到界 $\frac{d}{p}=\frac{2}{5}$ ✔（界的紧致性示例）。

具体示例二（$\mathbb{F}_7$，与算例 B 同一个多项式）：取 $P(x)=4x^2+3x+1$（算例 B 的结果），$Q(x)=x+1$，$d=2$。则 $P-Q=4x^2+2x=2x(2x+1)$。在 $\mathbb{F}_7$ 上根为 $x=0$ 与 $2x+1=0$，即 $x=-2^{-1}=-4\equiv3$。共 2 个根，所以

$$\Pr_{r\in\mathbb{F}_7}[P(r)=Q(r)]=\frac{2}{7}=\frac{d}{p}.$$

恰好取到界 ✔。逐点核对：P 在 $\mathbb{F}_7$ 上取值 $(1,1,2,4,0,4,2)$，$Q(x)=x+1$ 取值 $(1,2,3,4,5,6,0)$，在 $x=0$（都取 1）与 $x=3$（都取 4）处相等，其余处不等 ✔。

这个引理的用途：它是**多项式恒等式检验 (polynomial identity testing)** 的基础。若你想确认两个复杂表达式是否相等（比如判断某个电路实现是否正确），不必展开成系数；只需在随机点上求值。若结果不等，则必定不等；若结果相等，则它们**很可能**是同一个多项式——出错概率不超过 d/p。把 p 取大就能把错误率压到任意小。这正是下一讲的 Berlekamp–Welch 纠错解码算法的思想源头。

与经典问题的联系

问题实际背景：门限秘密共享 (threshold secret sharing)

冷战时期，美国总统授权在极端紧急情况下使用核武器，以避免因无法及时与总统商议而延误反击。一个显然的治理要求是：**不能让任何一个人单独掌握发射密码**。设想政府规定，至少 $k>1$ 名高级官员达成一致才能发起核打击。我们要设计一个方案，同时满足：

1. 任意 k 名官员**汇集各自的信息后**可以算出密码并发动打击；
2. 任意 $k-1$ 名或更少的官员，**即使把信息全部凑在一起**也**得不到密码的任何信息**。注意这里说的"任何信息"非常强：他们不应知道密码是奇是偶、是不是质数、能否被某个数整除、甚至最低有效位是什么。

数学建模

设共有 n 名官员，编号 1 到 n，密码（秘密）是自然数 s。取一个大于 n 且大于 s 的质数 q，全程在 $\mathrm{GF}(q)=\mathbb{F}_q$ 上工作。（$\mathbb{F}_q$ 而不是 $\mathbb{R}$ 有两个关键好处：秘密的候选值**有限**，所以可以精确量化"零信息"；并且所有运算都是整数模运算，**没有浮点误差**。）

随机选取一个**次数为 $k-1$** 的多项式

$$P(x)=a_{k-1}x^{k-1}+\cdots+a_1x+s,$$

其中常数项**就是**秘密 $s=P(0)$，其余 $k-1$ 个系数 $a_1,\dots,a_{k-1}$ **均匀随机**选取。这 $k-1$ 个随机系数是"牺牲信息 (sacrificial information)"，它们的唯一作用是把秘密藏起来。

然后分发**份额 (shares)**：第 i 位官员拿到 $P(i)$。

方案正确性证明

性质 1：任意 k 名官员可以恢复 s。

k 名官员手上共有 k 个点 $(i_1,P(i_1)),\dots,(i_k,P(i_k))$，横坐标两两不同。由**插值定理** 7.6（取 $d=k-1$，$d+1=k$），存在**唯一**一个次数 $\le k-1$ 的多项式经过这 k 个点。而 P 就是这样一个多项式，所以它就是唯一解。官员们用**拉格朗日插值**显式地算出这个多项式，然后求 $P(0)=s$。

用"表示转换"的话说：k 个份额恰好构成 P 的一个**取值表示**，插值把取值表示转成**系数表示**，而系数表示里直接可以看到常数项 s。

性质 2：任意 $k-1$ 名（或更少）官员得不到关于 s 的任何信息。

设有 $k-1$ 名官员，他们知道点 $(i_1,y_1),\dots,(i_{k-1},y_{k-1})$，想求 $P(0)=s$。

对秘密的**任意**一个候选值 $b\in\mathbb{F}_q$（共 q 种可能），考虑扩充点集

$$(0,b),(i_1,y_1),\dots,(i_{k-1},y_{k-1}).$$

这共有 $1+(k-1)=k$ 个点，且横坐标 $0, i_1, \dots, i_{k-1}$ **两两不同**（因为各 $i_j \geq 1$ 而 0 不在其中，i_j 之间也不同）。由插值定理 7.6，存在**唯一**一个次数 $\leq k-1$ 的多项式经过这 k 个点。

也就是说：**每一个可能的秘密值 b 都恰好对应一个与官员们已知份额完全相容的次数 $k-1$ 多项式**。官员们看到的 $k-1$ 个份额，对 q 个可能的 s 值**完全对称**——没有任何一个 b 比其他更"合理"。所以他们的信息**与零信息不可区分**：对 s 的后验分布就是均匀分布。

用"表示"的话说：官员们的信息与 q 个不同的取值表示相容，每个对应一个可能的秘密值。

一个完整的秘密共享算例（$\mathbb{F}_7$）

设秘密 $s=1$，$n=5$ 名官员，门限 $k=3$。取质数 $q=7$（满足 $7>s=1$ 且 $7>n=5$）。

随机选取次数 $k-1=2$ 的多项式，其常数项必须是 $s=1$。假定随机系数选为 $a_2=3$、$a_1=5$：

$$P(x)=3x^2+5x+1 \pmod 7.$$

分发份额:

官员 i	1	2	3	4	5
份额 $P(i) \bmod 7$	$3+5+1=9\equiv 2$	$12+10+1=23\equiv 2$	$27+15+1=43\equiv 1$	$48+20+1=69\equiv 6$	$75+25+1=101\equiv 3$

（验算：$9-7=2$；$23-21=2$；$43-42=1$；$69-63=6$；$101-98=3$ ✔）

恢复：官员 3、4、5 集合。 他们拿到 $(3,1),(4,6),(5,3)$。

构造拉格朗日基（$\mathbb{F}_7$ 中 $2^{-1}=4$，$(-1)^{-1}=6$）：

$$\Delta_3(x)=\frac{(x-4)(x-5)}{(3-4)(3-5)}=\frac{(x-4)(x-5)}{(-1)(-2)}=\frac{(x-4)(x-5)}{2}=4(x-4)(x-5).$$

$$\Delta_4(x)=\frac{(x-3)(x-5)}{(4-3)(4-5)}=\frac{(x-3)(x-5)}{(1)(-1)}=6(x-3)(x-5).$$

$$\Delta_5(x)=\frac{(x-3)(x-4)}{(5-3)(5-4)}=\frac{(x-3)(x-4)}{(2)(1)}=4(x-3)(x-4).$$

组合：

$$P(x)=1\cdot\Delta_3(x)+6\cdot\Delta_4(x)+3\cdot\Delta_5(x).$$

三人在 $x=0$ 处求 $P(0)$（不必展开全部系数）。注意每个基函数在 $x=0$ 的值：

- $\Delta_3(0)=4\cdot(0-4)(0-5)=4\cdot(-4)(-5)=4\cdot 20=80\equiv 80-77=3 \pmod 7$
- $\Delta_4(0)=6\cdot(0-3)(0-5)=6\cdot(-3)(-5)=6\cdot 15=90\equiv 90-84=6 \pmod 7$
- $\Delta_5(0)=4\cdot(0-3)(0-4)=4\cdot(-3)(-4)=4\cdot 12=48\equiv 48-42=6 \pmod 7$

$$P(0)=1\cdot 3+6\cdot 6+3\cdot 6=3+36+18=57\equiv 57-56=1 \pmod 7.$$

恢复出 $s=1$ ✔。也可以完整展开验证：三人恢复的 P 在 $\mathbb{F}_7$ 上的取值表是 $(1,2,2,1,6,3,6)$，与真实的 $3x^2+5x+1$ 逐点相同 ✔。

"少于 k 人一无所知"的具体演示。 官员 1 和 5 集合，拿到 $(1,2)$ 与 $(5,3)$。他们知道 $P(x)=a_2x^2+a_1x+s$，于是知道两个方程：

$$P(1)=a_2+a_1+s=2, \qquad P(5)=25a_2+5a_1+s\equiv 4a_2+5a_1+s=3 \pmod 7.$$

两个方程、三个未知数——**解不出唯一解**。更精确地说，对秘密的每个候选 $s=0,1,\dots,6$，都能补出一个唯一的相容多项式：

猜测的 s	0	1	2	3	4	5	6
补出的多项式在 $x=2$ 处的值	4	2	0	5	3	1	6

七个 s 值对应七个**互不相同**的、与已知份额完全相容的候选多项式。两人**无法从份额中区分**哪个 s 是真的，所以"两个官员合起来"与"一个官员单独"对 s 的信息量**完全一样**——这正是门限方案要求的强安全性。

与后续内容的联系

- 插值定理是**纠错码 (error-correcting codes)** 的基石。下一讲的 Reed–Solomon 码就是把消息编码成一个多项式在各点的取值，用 n 个符号传 k 个消息符号；即使信道把部分符号搞错（不只是丢失，而是错误成别的值），只要错误数控制在阈值内，接收方仍能用 **Berlekamp–Welch 算法**恢复原消息——其核心正是"找两个多项式，用插值和根定理夹逼出真相"。
- Schwartz–Zippel 引理（引理 7.8）用在**多项式恒等式检验**和**随机化算法**中，也是概率方法（讲次 23 的集中不等式）的一个优雅应用。

与其他讲次的关联

- **讲次 4（Modular Arithmetic，模运算）**：有限域 $\mathbb{F}_p$ 的加、减、乘、除全部是讲次 4 的模运算。$\mathbb{F}_p$ 之所以能叫"域"，正是因为讲次 4/5 证明了 $\mathbb{Z}_p$ 中每个非零元都有乘法逆元。拉格朗日插值在 $\mathbb{F}_p$ 上的实现就是"除以 x_i-x_j"= "乘以 $(x_i-x_j)^{-1} \bmod p$"，本讲算例 B 中 $2^{-1}=4$、$(-1)^{-1}=6$ 就是这个道理。
- **讲次 5（Euclid, FLT, CRT）**：
- **费马小定理 (FLT)** 直接给出 $x^p\equiv x \pmod p$，这是"$\mathbb{F}_p$ 上多项式函数不唯一（x^p 与 x 相同）"以及"x^p-x 有 p 个根"的唯一依据，也是命题 7.7 中"次数 $\geq p$ 的多项式可降次"的机制。

- **中国剩余定理 (CRT)** 与拉格朗日插值在结构上是**同一件事**：CRT 的基向量 b_i（在方向 n_i 上取 1、其他方向取 0）与拉格朗日基 Δ_i（在 x_i 处取 1、其他点取 0）是一模一样的"指示函数"思想，解都是 $\sum a_i b_i$ 与 $\sum y_i \Delta_i$ 形式的线性组合。官方 Note 也明确指出 Lagrange 插值"should remind you of the Chinese Remainder Theorem"。
- **扩展欧几里得算法**是求 $(x_i - x_j)^{-1} \bmod p$ 的工具，没有它就写不出 Δ_i。
- **讲次 3（Induction，归纳法）**：定理 7.3（有限根定理）的证明是对次数 d 的**弱归纳**；Claim A 的证明也是归纳。归纳假设的用法是"剥掉一个线性因子后，把次数小 1 的问题交回去"。
- **讲次 2（Proof Techniques II，反证/分情形）**：插值定理的**唯一性**部分用**反证法**（假设存在第二个多项式，导出矛盾）；有限根定理在推导"根数 $\le d$"时用了**分情形**（有根 / 无根）。
- **讲次 6（RSA，RSA 加密）**：两个讲次共享"**单向结构**"的设计哲学——RSA 用"正向做幂容易、逆向求离散对数/分解困难"，本讲用"给定系数求值容易（$O(d)$ 次乘加）、给定取值求系数需要 $d+1$ 个点（少了就不唯一）"。本讲末尾提到的**随机填充**与 Schwartz–Zippel 的"随机取点检验"都用同一招：**引入随机性把确定性的结构漏洞堵住**。
- **讲次 8（Secret Sharing & ECC，秘密共享与纠错码）**：本讲的插值定理、根定理、Schwartz–Zippel 引理在下一讲被**直接使用**——Shamir 秘密共享 = 插值定理；Reed–Solomon 码 = 取值表示 + 插值；Berlekamp–Welch 解码 = 根定理 + 线性代数。可以说本讲是下一讲的全部数学预备。
- **讲次 14（Counting，计数）**：本讲"$\mathbb{F}_p$ 上过 $d-k$ 个点的次数 $\le d$ 多项式有 p^{k+1} 个"这张计数表，用的是**逐层自由选择**这一基本计数原理；"任意 k 名官员可恢复、$k-1$ 名不可"的论证也用到了"每个秘密候选值对应唯一多项式"的双射计数。

关键要点

1. **有限根定理**：在**域**上，次数为 d 的**非零**多项式**至多**有 d 个根。两个条件都不可省——"非零"（零多项式处处为零）与"域"（$\mathbb{Z}_8$ 上 x^3 有 4 个根）。上界**紧**：$\mathbb{F}_7$ 上 $x(x-1)(x-2)$ 恰有 3 个根，$x^7 - x$ 恰有 7 个根。
2. **因式定理**：$(x-r) \mid P(x) \iff P(r) = 0$。这是从"求值"跳到"代数结构"的桥，也是根定理归纳证明的发动机。
3. **插值定理**：$d+1$ 个横坐标互不相同的点**存在且唯一**确定一个次数 $\le d$ 的多项式。存在性由拉格朗日基 $\Delta_i(x) = \prod_{j \ne i} \frac{x - x_j}{x_i - x_j}$ 构造性给出，$P = \sum_i y_i \Delta_i$；唯一性由"差多项式有 $d+1$ 个根但次数 $\le d$，矛盾"给出。
4. **域 vs 非域的分界线是"没有零因子"**。所有证明只用到"加、减、乘、除（非零）"四则运算封闭这一条。$\mathbb{Z}_p$（p 质数）、$\mathbb{Q}$、$\mathbb{R}$、$\mathbb{C}$ 都可以；$\mathbb{Z}_8$、$\mathbb{N}$、$\mathbb{Z}$ 都不行（$\mathbb{Z}$ 上还有别的失效原因：$\frac{1}{2}$ 不存在，$y = x/2$ 类型的插值多项式无法表示）。
5. **函数 ≠ 多项式（在有限域上）**。$\mathbb{F}_p$ 上 x^p 与 x 作为函数完全相同、作为多项式不同。**加上"次数 $\le p-1$"这个限制后，函数与多项式一一对应**（命题 7.7）——这是"用 $d+1$ 个点指定 d 次多项式"能成立而不引起歧义的根本原因。
6. Schwartz–Zippel：若 $P \ne Q$ 且 $\deg P, \deg Q \le d$，则随机 r 满足 $P(r) = Q(r)$ 的概率 $\le d/p$。这是"随机点上求值检验多项式相等"的可靠性保证。

常见误区与注意事项

1. **忘记"非零"条件**。零多项式 $P(x) \equiv 0$ 有**无穷多个根**（在 $\mathbb{R}$ 上）、p 个根（在 $\mathbb{F}_p$ 上），完全不受"至多 d 个根"的约束。在写根定理和插值唯一性证明时必须明确"$P \ne Q$ 所以 $P - Q$ 是**非零**多项式"。若两个多项式确实相等，差是零多项式，这个论证立刻失效——而这恰恰就是唯一性想要证明的结论，所以论证的逻辑顺序不能反。
2. **把"至多 d 个根"读成"恰有 d 个根"**。定理只是**上界**。在 $\mathbb{R}$ 上 x^2+1 是 0 个根；在 $\mathbb{F}_p$ 上很多多项式根数远少于次数。另外，$x^2 - 4$ 在 $\mathbb{R}$ 上有 2 个根（2 与 -2），但在 $\mathbb{F}_5$ 上 $x^2 - 4 = x^2 + 1$ 的根是 2 与 3（$3^2 = 9 \equiv 4$，$4 - 4 = 0$ ✔；等等，$3^2 - 4 = 5 \equiv 0$ ✔）——**同一个系数模式在不同域上根完全不同**，数根时必须指明在哪个域中数。
3. **误以为插值定理对任意 m 的 $\mathbb{Z}_m$ 都成立**。定理要求系数取自**域**。在 $\mathbb{Z}_8$ 上，x^3 有 4 个根，于是"过 4 个点（含 $0, 2, 4, 6$）的唯一 3 次多项式"这一断言直接崩掉（x^3 与零多项式在 $0, 2, 4, 6$ 上取值全同，但它们是不同的多项式）。**m 必须是质数**。
4. **把 $\mathbb{Z}_m$ 与 $\mathbb{F}_m$ 混为一谈**。官方 Note 特别强调：虽然存在含 8 个元素的域（记作 $\mathbb{F}_8$ 或 $GF(8)$），但它**不是** $\mathbb{Z}_8$。$\mathbb{Z}_8$ 无法嵌入任何更大的域中让根定理"复活"。看到 $\mathbb{F}_m$ 时，先确认 m 是质数。
5. **混淆"系数表示相等"与"函数相等"**。x^7 与 x 在 $\mathbb{F}_7$ 上处处取值相同，但它们是**两个不同的多项式**（次数不同），在系数意义下绝不相等。做多项式运算（相加、相乘、比较次数、判断整除）时必须用系数观点；只有在讨论"取值表"时才用函数观点。判断两者是否可能相等时，先看次数是否都 $\le p-1$。
6. **插值从不回代验算**。这是最容易丢分的地方。任何插值结果都应当把 x_i 逐个代回去检查是否等于 y_i。典型例子：$(0,1), (1,2), (2,5)$ 的正确答案是 $P(x) = x^2 + 1$，但很容易算成 $1 + \frac{1}{2}x + \frac{3}{2}x^2$（代入 $x = 1$ 得 $3 \ne 2$，立刻暴露错误）。**代回验算是插值题唯一可靠的检查方式**。
7. **在模运算中把"除法"当成普通除法**。$\mathbb{F}_p$ 上 $\frac{1}{2}$ 不是 0.5，而是 $2^{-1} \bmod p$（$\mathbb{F}_7$ 上是 4，$\mathbb{F}_5$ 上是 3）。写拉格朗日基时把分母 $\prod(x_i - x_j)$ 直接搬到实数上算，结果会完全错。正确做法：先算出分母的**模 p 值**，再乘它的**模 p 逆元**。
8. **忽略"x_i 必须两两不同"**。这是插值定理的硬性前提。取 $(0,1)$ 与 $(0,2)$ 两点，要求同一个多项式在 $x = 0$ 处同时取 1 和 2——连**存在性**都没有（在 $\mathbb{F}_7$ 上逐一遍历 343 个次数 ≤ 2 的多项式，满足这两点的个数是 0）。前提不满足时，唯一性自然更谈不上。

思考题（带答案）

Q1. （纯计算）在 $\mathbb{F}_7$ 上求过 $(0,3), (1,0), (2,3)$ 的次数 ≤ 2 的多项式，用拉格朗日插值逐步写出三个基多项式与最终系数，并代入三个点验算。

▸ 答案

$d=2$，三个点 $(x_1,y_1)=(0,3)$，$(x_2,y_2)=(1,0)$，$(x_3,y_3)=(2,3)$，横坐标两两不同 ✔。

$\mathbb{F}_7$ 中需要的逆元：$2^{-1}=4$（$2\times4=8\equiv1$），$(-1)^{-1}=6$（$6\times6=36\equiv1$），$(-2)\equiv5$，$5^{-1}=3$（$5\times3=15\equiv1$）。

基多项式：

$$\Delta_1(x)=\frac{(x-1)(x-2)}{(0-1)(0-2)}=\frac{(x-1)(x-2)}{(-1)(-2)}=\frac{x^2-3x+2}{2}=4(x^2-3x+2)=4x^2-12x+8\equiv4x^2+2x+1.$$

（$-12\equiv2$，$8\equiv1$。）

$$\Delta_2(x)=\frac{(x-0)(x-2)}{(1-0)(1-2)}=\frac{x(x-2)}{-1}=6(x^2-2x)=6x^2-12x\equiv6x^2+2x.$$

$$\Delta_3(x)=\frac{(x-0)(x-1)}{(2-0)(2-1)}=\frac{x(x-1)}{2}=4(x^2-x)=4x^2-4x\equiv4x^2+3x.$$

快速自检基函数（这是必须做的一步）：$\Delta_1(0)$ 应为 1，$\Delta_1(1)$ 应为 0，$\Delta_1(2)$ 应为 0。

- $\Delta_1(0)=1$ ✔；$\Delta_1(1)=4+2+1=7\equiv0$ ✔；$\Delta_1(2)=16+4+1=21\equiv0$ ✔
- $\Delta_2(0)=0$ ✔；$\Delta_2(1)=6+2=8\equiv1$ ✔；$\Delta_2(2)=24+4=28\equiv0$ ✔
- $\Delta_3(0)=0$ ✔；$\Delta_3(1)=4+3=7\equiv0$ ✔；$\Delta_3(2)=16+6=22\equiv1$ ✔

组合 $P=3\Delta_1+0\cdot\Delta_2+3\Delta_3$（注意 $y_2=0$，中间那项整个消失）：

- x^2 项：$3\cdot4+3\cdot4=12+12=24\equiv24-21=3$
- x^1 项：$3\cdot2+3\cdot3=6+9=15\equiv15-14=1$
- x^0 项：$3\cdot1+0=3$

$$\boxed{P(x)=3x^2+x+3 \text{ 在 } \mathbb{F}_7 \text{ 上.}}$$

代回验算：

- $P(0)=3$ ✔（要求 3）
- $P(1)=3+1+3=7\equiv0$ ✔（要求 0）
- $P(2)=3\cdot4+2+3=12+5=17\equiv17-14=3$ ✔（要求 3）

三点全部通过，答案正确。（顺带：$P(3)=27+3+3=33\equiv5$。）

Q2. （概念 / 证明）在 $\mathbb{Z}_8$ 上，$P(x)=x^3$ 有 4 个根，违反根定理。请具体指出定理 7.3 的证明在**哪一步**、因为**哪一条性质失效**而崩溃；然后说明为什么"m 是质数"这个条件在本讲的框架里是不可替代的。

▸ 答案

崩溃点定位。 定理 7.3 的归纳步骤是这样的：取 P 的一个根 r，由因式定理写成 $P(x)=(x-r)Q(x)$；设 a 是 P 的任意根，则

$$0=P(a)=(a-r)Q(a)\quad\Longrightarrow\quad a=r \text{ 或 } Q(a)=0. \tag{$*$}$$

这一步（$*$）在 $\mathbb{Z}_8$ 上失效：它要求"**域没有零因子**"，即 $uv=0\Rightarrow u=0$ 或 $v=0$。

在 $\mathbb{Z}_8$ 上取 $P(x)=x^3$，$r=2$（$P(2)=8\equiv0$）。因式分解得 $x^3=(x-2)(x^2+2x+4)$（在 $\mathbb{Z}_8[x]$ 中展开：$x^3+2x^2+4x-2x^2-4x-8=x^3-8\equiv x^3$ ✔），即 $Q(x)=x^2+2x+4$。

现在取 $a=4$（也是 P 的根，$4^3=64=8\times8\equiv0$）。代入：

$$(a-r)Q(a)=(4-2)\cdot(16+8+4)=2\cdot28=56=8\times7\equiv0 \pmod 8.\ \checkmark$$

但 $a-r=2\neq0 \pmod 8$，且 $Q(4)=28\equiv4\neq0 \pmod 8$。**两边都不是零，乘积却是零**——这就是 $\mathbb{Z}_8$ 中的**零因子**（$2\cdot4=8\equiv0$）。于是 $(*)$ 的"或"分不出来，$a=4$ 这个根**不被 r 或 Q 的根覆盖**，归纳假设无法接手，证明链条断裂。

核对 4 个根：$x=0,2,4,6$ 时 $x^3 \bmod 8=0,0,0,0$（$2^3=8$，$4^3=64=8\cdot8$，$6^3=216=8\cdot27$）。次数 3 的多项式有 4 个根，定理的上界被突破。

"m 必须为质数"为何不可替代。 整条证明链用的性质可以归纳成一条：**"可逆性 $\Leftrightarrow$ 非零"**。具体在三处出现：

1. **因式定理（定理 7.2）** 依赖带余除法（定理 7.1），而带余除法每一步要除以除数的首项系数——在 $\mathbb{Z}_8$ 上 $\frac{1}{2}$、$\frac{1}{4}$ 之类根本不存在。
2. **零因子不存在**（上面 $(*)$ 那一步）。
3. **拉格朗日基的分母 $\prod_{j\neq i}(x_i-x_j)$ 可逆**——在 $\mathbb{Z}_8$ 上，x_i-x_j 可能取 $2,4,6$ 这些没有逆元的值，插值公式直接写不出来。

三条性质都由同一条定理保证：**$\mathbb{Z}_m$ 中 x 有乘法逆元 $\Longleftrightarrow$ $\gcd(m,x)=1$**（讲次 4/5）。这只在 m 为质数时对所有非零 x 成立。所以"m 为质数"不是技术便利，而是这个代数体系的**公理级前提**。

官方 Note 特别指出：$\mathbb{Z}_8$ **不能**被嵌入某个更大的域来修补——$\mathbb{Z}_8$ 中的零因子关系（$2\cdot4=0$）在任何保持运算的嵌入下都会保留，而域里不许有零因子。确实存在含 8 个元素的域 $\mathbb{F}_8$，但它的运算**不是**模 8 运算（它是在 $\mathbb{F}_2$ 上加一个不可约多项式做扩域得到的，元素不能等同于 $\{0,\dots,7\}$ 配模 8 加法乘法）。所以正确的表述是：要含 8 个元素的域，得另建一个；不能把 $\mathbb{Z}_8$ "补成"域。

Q3. （概念 / 计数）在 $\mathbb{F}_7$ 上，次数 ≤ 2 的多项式共 $7^3 = 343$ 个。(a) 过给定的 1 个点、2 个点、3 个（横坐标互不相同的）点的次数 ≤ 2 多项式各有多少个？(b) 解释这张计数表如何"改写"成插值定理的一个证明；(c) 如果放宽到次数 ≤ 3，过 3 个点又有多少个？并说明为什么这个数字与 (a) 中过 3 个点的答案不同。

▸ **答案**

(a) **过 3 个点：恰好 1 个。** 这就是插值定理（$d=2$，$d+1=3$）的直接结论。在 $\mathbb{F}_7$ 上暴力枚举 343 个多项式，过 $(0,1),(1,2),(2,5)$ 的**只有一个**：x^2+1（即系数 $a_2=1, a_1=0, a_0=1$）。

过 2 个点：恰好 $m=7$ 个。 论证：设已知 $(x_1,y_1),(x_2,y_2)$，再任取第三个横坐标 x_3（与前者都不同）。对 y_3 的 **7 种**可能取值，由插值定理各存在唯一一个过三点的次数 ≤ 2 多项式；且 y_3 不同则多项式必不同（若多项式相同，它在 x_3 处的值就唯一确定，矛盾）。所以过两点的多项式个数 $=7$。

具体枚举（取 $(0,1),(1,3)$ 为例，在 $\mathbb{F}_7$ 上）：得到 7 个多项式，系数 (a_2,a_1,a_0) 为 $(0,2,1),(1,1,1),(2,0,1),(3,6,1),(4,5,1),(5,4,1),(6,3,1)$。可以检验它们的 a_0 全是 1（因为都过 $(0,1)$），而 a_2 取遍 $0..6$，a_1 随之确定。

过 1 个点：恰好 $m^2=49$ 个。 论证：对 y_2,y_3 的 $7\times 7=49$ 种取值组合，各唯一确定一个多项式；不同的 (y_2,y_3) 给出不同的多项式；反之每个过该点的多项式都在 x_2,x_3 处有某组取值，所以恰好 49 个。（直接枚举 $\mathbb{F}_7$ 上过 $(2,5)$ 的次数 ≤ 2 多项式，个数确为 49 ✔。）

一般计数表（$\mathbb{F}_m$ 上次数 $\le d$ 的多项式）：

已知点数	多项式个数
$d+1$	1
d	m
$d-1$	m^2
⋮	⋮
$d-k$	m^{k+1}
⋮	⋮
0	m^{d+1}

直觉：每少一个点，就多一个"自由维度"，每个维度有 m 种取值。$d+1$ 个系数需要 $d+1$ 个约束才能钉死；只有 $d-k$ 个约束时，还剩 $k+1$ 个自由度。

(b) **这张表蕴含插值定理。** 特别是"过 $d+1$ 个点恰好 1 个"这一行，同时给出了**存在性**与**唯一性**：

- **存在性**：计数不为 0 就说明至少有一个解。（注意这张表本身是用插值定理推出来的，所以它在逻辑上是"用定理解释计数"。但反过来也可以独立地建立计数：从系数角度，$d+1$ 个点的约束构成 $d+1$ 个线性方程，可以用线性代数直接证明系数矩阵可逆——那正是下一讲用范德蒙德矩阵给出的另一种插值证明。）
- **唯一性**：计数恰好为 1 就说明不可能有两个解。

更精确的"改写"路径是这样：先在系数空间里证明"给定 $d+1$ 个横坐标互不相同的点，取值映射 $\mathbb{F}^{d+1}\to\mathbb{F}^{d+1}$ 是**线性双射**"（矩阵是范德蒙德矩阵，行列式 $\prod_{i<j}(x_j-x_i)\neq 0$，因为域无零因子）。双射立刻给出存在性与唯一性，也顺带给出计数。这条路径完全避开了拉格朗日基的构造，是下一讲要用的"线性代数版"插值证明。

(c) **次数 ≤ 3、过 3 个点：恰好 7 个。** 用表中"已知点数 $=d-k$ 对应个数 m^{k+1}"的规则：这里 $d=3$、已知点数 $=3$，解得 $k=0$，所以个数 $=m^{k+1}=7^1=7$。

从系数角度直接数也对：次数 ≤ 3 的多项式有 4 个系数 (a_3,a_2,a_1,a_0)，共 $7^4=2401$ 个；3 个点给出 3 个约束，还剩 $4-3=1$ 个自由度，每个自由度有 7 种取值，所以个数是 7。

（精确枚举确认：在 $\mathbb{F}_7$ 上遍历 $7^4=2401$ 个次数 ≤ 3 的多项式，过 $(0,1),(1,2),(2,5)$ 的恰有 7 个。）

为什么与 (a) 中过 3 个点的答案（1 个）不同？ 因为**次数上界变了**。插值定理说的是"$d+1$ 个点唯一确定次数 $\le d$ 的多项式"——**点的个数与次数上界是配套的**。

- 当 $d=2$：3 个点恰好是 $d+1$，信息量**刚好够**，所以唯一（1 个）。
- 当 $d=3$：3 个点只有 $d=3<d+1=4$ 个，信息量**不够**，还剩 1 个自由度，所以有 7 个候选（其中恰好一个是那个唯一的 2 次多项式 x^2+1，其余 6 个是把 x^2+1 换成三次项不同、但在三个点上"碰巧"也取到这些值的多项式）。

这正好是"**次数界限不可放宽**"的另一面：**放松次数上界会让唯一性失效**，而**收紧次数上界会让存在性失效**。举例：在 $\mathbb{F}_7$ 上过 $(0,1),(1,2),(2,5)$ 的次数 ≤ 1 多项式有 0 个（遍历 49 条直线，没有一条同时过这三点——它们不共线）。所以：

次数上界	过这 3 个点的多项式个数
≤ 1	0（**存在性失效**，点不共线）
≤ 2	1（**恰好唯一**，插值定理的临界情形）
≤ 3	7（**唯一性失效**，多一个自由度）

只有次数上界**恰好等于 $d=$**（点数 -1）时，存在性与唯一性才同时成立。这正是下一讲 Shamir 秘密共享选择"$k-1$ 次多项式、分发 n 份"的原因：k 份是临界点，k 份够，$k-1$ 份不够。

Lecture 8: Secret Sharing & Error-Correcting Codes（秘密共享与纠错码）

概述

本讲把讲次 7 建立的多项式工具用到两个看似不同、实则同源的问题上：**秘密共享 (Secret Sharing)** —— 如何把一个秘密拆成 n 份，使任意 k 份能拼回秘密，而任意 $k-1$ 份对秘密一无所知；以及**纠错码 (Error-Correcting Codes)** —— 如何在有噪声的信道上传输消息，使接收方在部分信息被擦除 (erasure) 或被篡改 (corruption) 之后仍能还原原文。两个问题的共同钥匙只有一句话：**次数不超过 d 的多项式由 $d+1$ 个点唯一确定，而少于 $d+1$ 个点则什么都确定不了**。本讲主要使用四套技术：正确性靠插值的唯一性；安全性靠「对每个猜测值都能构造出恰好一条相容曲线」的构造性论证；纠错能力靠汉明距离 (Hamming distance) 加三角不等式；而 Berlekamp–Welch 译码把「枚举错误位置」这一指数级搜索转化为解一个线性方程组。本讲也是课程从"数论与密码"过渡到"代数与编码"的收口之处：讲次 9–11 将切换到完全不同的建模语言——图论。

核心概念的直观解释

门限方案（(n,k) threshold scheme） – **定义**：把秘密 s 分配给 n 个参与方，使得 (1) 任意 k 个参与方合起来可以唯一确定 s；(2) 任意 $k-1$ 个或更少的参与方合起来**不能获得关于 s 的任何信息**。第二条中的"任何信息"是**信息论**意义下的：他们关于 s 的后验分布与先验分布完全相同。 – **直观解释（"它是什么意思？"）**：想象一只需要多把钥匙同时插入才能打开的保险箱。k 是"门限"：低于门限什么都做不了，达到门限则一把不多不少刚好够。现实类比是冷战时期的核发射授权——没有任何单个人应该掌握发射码，但也不能要求全体官员都到场，否则在突袭下根本来不及反击。 – **具体示例**：$n=5, k=3$ 时，"官员 1、3、4 三人凑齐"能算出秘密；"官员 1、3 两人凑齐"无论怎么交换信息、怎么联合计算，都与单独一个人知道的完全一样多。注意 (2) 比"算不出来"强得多：它还包括"看不出 s 是奇数还是偶数""看不出 s 是否素数""看不出 s 的最低有效位"等等。

Shamir 秘密共享（Shamir's Secret Sharing） – **定义**：设 q 是大于 n 且大于 s 的素数，在有限域 (finite field) $GF(q)$（也写作 $\mathbb{F}_q$）上工作。随机选取一个次数**恰好为 $k-1$** 的多项式

$$P(x) = s + a_1 x + a_2 x^2 + \cdots + a_{k-1} x^{k-1} \pmod{q},$$

其中常数项**固定为秘密 $P(0)=s$**，而 $a_1, \dots, a_{k-1}$ 从 $GF(q)$ 中**独立均匀随机**抽取。第 i 个参与方拿到份额 (share) $(i, P(i))$，$i = 1, 2, \dots, n$。 – **直观解释（"它是什么意思？"）**：秘密藏在曲线的**截距**上，而 $k-1$ 个随机系数是"陪衬噪声"。k 个点像 k 颗钉子，把曲线钉死，截距随之暴露；$k-1$ 颗钉子钉不住一条曲线——它还能上下自由摆动，而摆动的一个自由度恰好就是截距。每个随机系数都是一件"牺牲品"：它主动吸收掉一部分不确定性，让秘密本身保持未知。另一种等价的说法是线性代数的：$k-1$ 个方程解不出 k 个未知数，总有一个自由度；刻意保留的那个自由度就是秘密。 – **具体示例**：$q=11, n=5, k=3, s=5$，取 $P(x) = 5 + 2x + 3x^2 \pmod{11}$。份额是 $(1,10), (2,10), (3,5), (4,6), (5,2)$。任意 3 份都能反解出 $P(0)=5$；任意 2 份（比如 $(1,10)$ 与 $(3,5)$）对 $s'=0, 1, \dots, 10$ 这 11 个猜测值都各自对应一条独有的相容抛物线，因此这 2 份数据与 s 的取值在信息论上完全独立。

擦除错误（erasure error）与一般错误（general error） – **定义**：擦除错误指某些"包"在传输中**丢失**，接收方知道是**哪些位置**丢了（包有编号头部）；一般错误指某些字符被**篡改**了，接收方收到的字符数与发送的一样多，但**不知道哪些位置被改**。 – **直观解释（"它是什么意思？"）**：前者像寄一摞明信片，路上丢了两张，收件人一看编号就知道第 2、6 张没到；后者像有人偷偷把明信片上的字改了，收件人手上张数齐全，却分不清哪几行是假的。显然"不知道错误位置"要困难得多。 – **具体示例**：n 个字符的消息要防 k 个丢失，只需多发 k 个冗余字符（共 $n+k$ 个）；但要防 k 个篡改，必须多发 $2k$ 个冗余字符（共 $n+2k$ 个）。这个两倍代价不是实现上的偷懒，而是距离理论给出的硬下界（见定理 8.3 与反例）。

码字、消息、以及"冗余"的确切含义 – **定义**：**消息 (message)** 是用户交给我们、不一定含冗余的原始数据串；**码字 (codeword)** 是实际被发送、按构造含有冗余的串。**编码 (encoding)** 是一张从消息集合到码字集合的单射。 – **直观解释（"它是什么意思？"）**：消息是"你想说的话"，码字是"你实际写在信纸上的字"。多出来的部分是**故意的重复**，专门用来在丢字或被改字时救场。 – **具体示例**：$GF(7)$ 上消息 $(1,1,1)$（3 个符号）对应码字 $(3,0,6,0,3)$（5 个符号），冗余 2 个符号，可抗 $e=1$ 个一般错误。

汉明距离（Hamming distance）与最小距离（minimum distance） – **定义**：对两个长度 L 的字符串 $\vec{s} = (s_1, \dots, s_L)$ 与 $\vec{r} = (r_1, \dots, r_L)$，

$$d(\vec{s}, \vec{r}) = \sum_{i=1}^{L} \mathbf{1}(r_i \neq s_i),$$

即两个串在多少个坐标上不同（$\mathbf{1}(\cdot)$ 是"条件成立取 1，否则取 0"的指示函数）。所有码字两两距离中的**最小值**称为该码的最小距离

$$d_{\min} = \min_{\vec{m} \neq \vec{m}'} d\big(\vec{c}(\vec{m}), \vec{c}(\vec{m}')\big).$$

- **直观解释（"它是什么意思？"）**：把每个码字想象成空间中的一颗星球，距离就是"改几个字符能从一颗星球飞到另一颗"。星球之间离得越远，噪声要"漂移"很久才能把人骗到隔壁星球。$d_{\min}=1$ 意味着原始消息集合毫无防护；$d_{\min}$ 越大防护越强。汉明距离满足三条公理：非负性、对称性、三角不等式 $d(\vec{a},\vec{c}) \le d(\vec{a},\vec{b}) + d(\vec{b},\vec{c})$——第三条第是纠错能力证明的全部依据。
- **具体示例**：消息集合 $\{00, 01, 10, 11\}$ 的最小距离是 1（00 与 01 只差一位）——收到 $0?$ 无法判断原来是 00 还是 01，零防护。对比重复码 $\{000, 111\}$，最小距离是 3：收到 001 可以断定原码字是 000（距离 1），因为到 111 的距离是 2，更远。

Reed–Solomon 码（Reed–Solomon code） – **定义**：取素数 q，消息为 $\vec{m} = (m_0, m_1, \dots, m_{k-1}) \in GF(q)^k$，把它解释为次数 $< k$ 的多项式 $P(x) = m_0 + m_1 x + \cdots + m_{k-1} x^{k-1}$ 的**系数表示 (coefficient representation)**。选定 n 个互不相同的求值点 $\alpha_1, \dots, \alpha_n \in GF(q)$，码字就是 P 的**值表示 (value representation)**

$$\vec{c}(\vec{m}) = \big(P(\alpha_1), P(\alpha_2), \dots, P(\alpha_n)\big).$$

发送的是 $\vec{c}$，不是 $\vec{m}$。 – **直观解释（"它是什么意思？"）**：编码不过是"把系数形式的曲线画在 n 个刻度上"，解码则是"用一堆点重新拟合曲线"。如果只有一两个点被涂歪，曲线整体形状仍然明显可辨——这正是冗余的来源。系数表示与值表示的互相转换（前者靠求值，后者靠插值）是讲次 7 已经建立好的两种视角。 – **具体示例**：$GF(7)$ 上取 $k=3$、求值点 $1,2,3,4,5$，消息 $(1,1,1)$ 即 $P(x) = 1 + x + x^2$，求值得码字 $(3,0,6,0,3)$（检验 $P(3) = 1+3+9 = 13 \equiv 6$）。

错误定位多项式（error-locator polynomial） – **定义**：设实际发生错误的位置集合为 $\{e_1, \dots, e_t\}$（$t \le e$），定义

$$E(x)=\prod_{j=1}^{t}(x-e_j).$$

它是次数恰为 t 的多项式，根恰好是全部错误位置。在算法中我们把它的次数统一写成 e，即取首一形式 $E(x)=x^{e}+b_{e-1}x^{e-1}+\cdots+b_1x+b_0$；当 $t<e$ 时再乘以任意一个 $e-t$ 次首一多项式补足次数（这不影响任何论证，只影响"解是否唯一"）。 – **直观解释（"它是什么意思？"）**：它是错误的"通缉令"——虽然接收方还不知道谁犯了错，但可以把这个通缉令**符号化**地写出来，把它当成未知对象一起列进方程。解方程的过程会顺便把通缉令上的名字填上。这就是 Berlekamp–Welch 的精妙之处：**不求位置，把位置当未知数解**。 – **具体示例**：在 $GF(7)$ 上若只在第 1 个坐标出错，则 $E(x)=x-1=x+6$，$E(1)=0$，而 $E(2)=1$、$E(5)=4$ 都非零。

Berlekamp–Welch 译码（Berlekamp–Welch decoding） – **定义**：给定 n 个接收值 $r_1,\dots,r_n$，其中最多 e 个被篡改，且 $n\ge k+2e$。构造辅助多项式 $Q(x):=P(x)E(x)$，其次数 $\le(k-1)+e=k+e-1$。对每个 i 列出方程

$$Q(i)=r_iE(i),\qquad i=1,2,\dots,n,$$

这是关于 Q 与 E 的系数的线性方程组：$k+e$ 个未知数（Q 的系数）加 e 个未知数（E 的 $b_0,\dots,b_{e-1}$，首项系数已归一为 1），合计 $k+2e\le n$ 个未知数，n 条方程。解出后用多项式长除法还原 $P(x)=Q(x)/E(x)$，并对错误位置用 P 重新求值。 – **直观解释（"它是什么意思？"）**：只要 i 没出错，$P(i)=r_i$，于是 $Q(i)=P(i)E(i)=r_iE(i)$；只要 i 出错了，$E(i)=0$，于是左右两边都是 0。**无论出错与否，这个方程都成立**——这就是把未知的错误位置"吸收"进方程组的技巧。原来要靠枚举 $\binom{n}{e}$ 种错误位置（指数级），现在只需解一次线性方程组（多项式时间）。 – **具体示例**：见后文完整算例——$GF(7)$、$k=3$、$n=5$、$e=1$、接收串 $(2,0,6,0,3)$ 时解出 $Q=x^3+6$、$E=x+6=x-1$，长除法得 $P=x^2+x+1$，并定位出错误在第 1 位。

完整证明与推导（核心）

定理 8.1（Shamir 方案的正确性）：设 $q>n$ 为素数，$s\in GF(q)$，P 是 $GF(q)$ 上次数为 $k-1$、常数项为 s 的多项式。任意 k 个参与方 $i_1<\cdots<i_k$（$1\le i_j\le n$）出示各自的份额 $(i_j,P(i_j))$，则可从这些份额唯一确定 P，从而恢复 $s=P(0)$。

证明策略：直接证明，并引用讲次 7 的插值唯一性（Property 2）。之所以能直接引用，是因为 $GF(q)$ 是一个**域 (field)**：加、减、乘以及"除以非零元"四条运算都封闭；而讲次 7 关于两个多项式性质的证明只用到这四条运算。

逐步推导： 1. 设 $Q(x)$ 是任意一个次数 $\le k-1$ 且满足 $Q(i_j)=P(i_j)$（$j=1,\dots,k$）的多项式。**依据**：定义。 2. 令 $D(x):=P(x)-Q(x)$。**依据**：代数运算。 3. D 的次数 $\le k-1$，且 $D(i_j)=P(i_j)-Q(i_j)=0$ 对 $j=1,\dots,k$ 成立，即 D 至少有 k 个互不相同的根。**依据**：第 1、2 步与"根"的定义。 4. 由讲次 7 的 Property 1（非零的次数 d 多项式至多有 d 个根）：若 D 非零，则其次数至少为 k，与第 3 步矛盾。故 $D\equiv 0$，即 $Q=P$。**依据**：Property 1。 5. 于是过这 k 个点的次数 $\le k-1$ 多项式**唯一**，就是 P。**依据**：第 4 步。 6. 具体地，参与方可以用 Lagrange 插值显式写出

$$P(x)=\sum_{j=1}^{k}P(i_j)\,\Delta_j(x),\qquad \Delta_j(x)=\prod_{\ell\neq j}\frac{x-i_\ell}{i_j-i_\ell},$$

其中每个分母 $i_j-i_\ell\not\equiv 0\pmod q$（各 i 互不相同），故其在 $GF(q)$ 中的乘法逆元存在。**依据**：讲次 7 的 Lagrange 插值公式 + 讲次 5 的逆元存在性（q 为素数 $\Rightarrow$ 每个非零元可逆）。 7. 令 $x=0$ 得 $s=P(0)=\sum_{j=1}^{k}P(i_j)\Delta_j(0)$，秘密被唯一恢复。**依据**：第 5、6 步。

【证明机制解说】：整个正确性的重量全部压在"次数 $\le k-1$ 的非零多项式至多 $k-1$ 个根"这一条上。k 个点提供了 k 个约束，超过任何非零低次多项式所能拥有的根数上限，于是"两条候选曲线之差"这条曲线被逼成零曲线。这就是所谓的**"自由度刚好用完"**：k 个未知系数被 k 个方程锁死，没有留下一丝摇摆空间。

反例（条件不可省）：如果只有 $k-1$ 个点，唯一性立即崩塌。在 $GF(11)$ 上取 $k=3$、份额 $(1,10)$ 与 $(3,5)$：对 $s'=0$，经过 $(0,0),(1,10),(3,5)$ 的插值多项式是 $P'(x)=5x+5x^2$；对 $s'=7$，经过 $(0,7),(1,10),(3,5)$ 的是 $P'(x)=7+3x$。两条曲线都过这两个已知点，却给出不同的秘密——所以 $k-1$ 个点确实无法确定 $P(0)$。更一般地（见定理 8.2），每个 $s'\in GF(11)$ 都恰好对应一条相容曲线。

定理 8.2（Shamir 方案的安全性：信息论意义下的零泄露）：在 Shamir 方案中，任意 $k-1$ 个（或更少）参与方的份额与秘密 s 在信息论上相互独立。更精确地说：对任意固定的份额集合 $S=\{(i_1,y_1),\dots,(i_{k-1},y_{k-1})\}$（$i_j$ 互不相同且落在 $1,\dots,n$ 内）以及任意猜测值 $s'\in GF(q)$，都存在**唯一**一个次数 $\le k-1$ 的多项式 P'，使得

$$P'(0)=s'\quad\text{且}\quad P'(i_j)=y_j\ \ (j=1,\dots,k-1).$$

证明策略：构造性证明（存在性）+ 引用唯一性。策略选择的关键在于：要证"得不到任何信息"，不能只说"算不出来"（那是计算复杂度，不是信息论事实），必须证明**每一种可能的秘密值都与其他观测数据一样兼容**。所以要为每个 s' 显式造出一条曲线，并数清楚候选曲线的总数没有减少。

逐步推导： 1. 固定 S，另加一个虚拟的"第 k 个点" $(0,s')$。**依据**：构造。 2. 这 k 个点的横坐标 $0,i_1,\dots,i_{k-1}$ 两两不同（因为 $i_j\ge 1$ 且各 i_j 互不相同）。**依据**：方案设定 $1\le i_j\le n$。 3. 由讲次 7 的 Property 2，存在**唯一**的次数 $\le k-1$ 的多项式 P' 经过这 k 个点。**依据**：插值唯一性。 4. P' 与实际被使用的曲线 P 在参与方所知的 $k-1$ 个点上**取值完全重合**：$P'(i_j)=y_j=P(i_j)$。**依据**：第 1、3 步。 5. 对每个 $s'\in GF(q)$（共 q 个值）执行第 1–4 步，得到 q 条曲线。它们两两不同：若 $s'\neq s''$，则 P' 与 P'' 在 $x=0$ 处取值不同，故不是同一个多项式。**依据**：第 3、4 步。 6. 因此，参与方观测到的 $k-1$ 个份额与 q 个候选秘密值中的每一个都**同等相容**：数据无法排除任何一个候选，也无法偏好任何一个候选。用条件概率的语言（讲次 17–18）说，若秘密的先验是均匀的，则

$$\Pr[\text{秘密}=s'\mid\text{观测到 }S]=\frac{1}{q}=\Pr[\text{秘密}=s'],$$

后验等于先验，即条件分布与边缘分布相同——按定义这就是**相互独立**，信息量为 0 比特。**依据**：第 4、5 步 + 条件概率定义。 7. 特别地，攻击者无法判断 s 的奇偶性、是否为素数、最低有效位、是否被某个数整除——因为这些量都是 s 的确定性函数，而 s 的后验分布是均匀的。**依据**：第 6 步。 8. 对比第 k 个参与方加入时：候选集合从 q 个坍缩到恰好 1 个，信息量从 0 比特跃升为满额 $\log_2 q$ 比特。这个"突变"正是门限之所以尖锐的原因。**依据**：第 3、5 步。

【证明机制解说】：这个证明的"灵光一现"是把"不知道"翻译成"**兼容性对称**"。直觉说法是"$k-1$ 个点钉不住曲线"，而严格的数学化做法是：把待猜的秘密当作第 k 个点，然后**求助于插值的存在唯一性**，得到一一对应

$$GF(q)\text{ 中的 }q\text{ 个秘密值}\ \longleftrightarrow\ q\text{ 条相容曲线}\ \longleftrightarrow\ q\text{ 个候选“值表示”}.$$

如果可能候选只有 3 个而不是 q 个，攻击者就获得了约 $\log_2(q/3)$ 比特信息；正因为候选数恰为 q（没有变少），信息量才恰好是 0 比特。这也顺带解释了为什么必须工作在**有限域**上：只有在有限域里候选数才是有限的 q 个，才能精确地断言"候选数没有减少"；若在实数域上做同样的方案，候选曲线有无限多条，"候选数是否减少"就无法量化。此外，有限域保证所有算术是精确整数运算，不会像浮点插值那样出现数值不稳定。

定理 8.3（距离 → 检错、纠错、纠擦除能力）：设某编码方案的最小距离为 d，记 $t=\lfloor (d-1)/2 \rfloor$。则：(a) 若传输中被修改的坐标数 $\le t$，接收方可以**唯一地**恢复原码字（纠错能力）；(b) 若传输中被修改的坐标数 $\le d-1$，接收方可以**检测出**"出了错"（检错能力）；(c) 若被擦除的坐标数 $\le d-1$，接收方可以**唯一地**恢复原码字（抗擦除能力）。

证明策略：反证法 + 汉明距离的三角不等式。核心是"球不相交"。

逐步推导（(a) 纠错）：1. 设接收串为 $\vec{r}$，真实码字为 $\vec{c}$，且 $d(\vec{r},\vec{c}) \le t$。**依据**：问题设定。 2. 反设还存在另一个不同的码字 $\vec{c}'$ 也满足 $d(\vec{r},\vec{c}') \le t$。**依据**：反证假设。 3. 由三角不等式，$d(\vec{c},\vec{c}') \le d(\vec{c},\vec{r}) + d(\vec{r},\vec{c}') \le t + t = 2t$。**依据**：三角不等式与第 1、2 步。 4. 又由 $t=\lfloor (d-1)/2 \rfloor$ 得 $2t \le d-1 < d$。**依据**：取整估计。具体地：若 $d=2e+1$，则 $t=e$，$2t=2e=d-1$；若 $d=2e$，则 $t=e-1$，$2t=2e-2=d-2$。 5. 第 3、4 步合起来给出 $d(\vec{c},\vec{c}') < d$，与 d 是**最小**距离（任意两个不同码字的距离都 $\ge d$）矛盾。**依据**：最小距离的定义。 6. 故这样的 $\vec{c}'$ 不存在，$\vec{c}$ 是唯一与 $\vec{r}$ 距离 $\le t$ 的码字——"最近码字译码 (nearest-codeword decoding)"的输出唯一，且正是真实码字。**依据**：第 5 步。

逐步推导（(b) 检错）：1. 设 $d(\vec{r},\vec{c}) \le d-1$，且反设 $\vec{r}$ 本身恰好也是一个码字 $\vec{c}'$（即 $d(\vec{r},\vec{c}')=0$）。**依据**：反证假设。 2. 则 $d(\vec{c},\vec{c}') \le d(\vec{c},\vec{r}) + d(\vec{r},\vec{c}') \le (d-1)+0 = d-1 < d$。**依据**：三角不等式。 3. 与最小距离定义矛盾。故 $\vec{r}$ 不可能是合法码字（除非真的没出错）。接收方一旦发现"收到的串不是合法码字"，就能断定有错。**依据**：第 2 步。

逐步推导（(c) 抗擦除）：1. 设擦除掉 $\ell \le d-1$ 个坐标后，有**两个**不同码字 $\vec{c} \ne \vec{c}'$ 都与剩余数据相容。**依据**：反证假设。 2. 相容意味着它们在所有未被擦除的坐标上取值相同，所以它们不同的坐标必然都落在被擦除的 ℓ 个位置里。**依据**：相容的定义。 3. 于是 $d(\vec{c},\vec{c}') \le \ell \le d-1 < d$，与最小距离定义矛盾。**依据**：第 2 步。 4. 故相容码字唯一。**依据**：第 3 步。 5. 反过来这个界也是紧的：若 $\ell \ge d$，则可取一对距离恰为 d 的码字，擦掉那 d 个差异坐标，剩余数据同时与两者相容，译码必然歧义。**依据**：最小距离的定义与紧性构造。

【证明机制解说】：这就是"**汉明球**"图像：以每个码字为球心、半径 t 画球（球内是全部与球心距离 $\le t$ 的串）。若两个球有公共点 $\vec{r}$，则两个球心的距离 $\le 2t < d$，与最小距离冲突。所以半径 $t=\lfloor (d-1)/2 \rfloor$ 的球两两**不相交**；接收串落在哪个球里就判给哪个球心，绝不会撞车。反过来半径再大一点球就必然重叠，纠错就不再唯一。这也立刻给出三个能力的"汇率"：d 个距离单位可换 $d-1$ 个检错、$\lfloor (d-1)/2 \rfloor$ 个纠错、$d-1$ 个纠擦除。

反例（条件不可省）：$d=2$（例如 $GF(7)$ 上长度 4、$k=3$ 的 RS 码，或弱化的重复码）时 $t=\lfloor 1/2 \rfloor = 0$：**一个错误都纠不了**。接收串 $\vec{r}=(0,1)$ 与 $\vec{c}=(0,0)$、$\vec{c}'=(1,1)$ 的距离都是 1，解码器彻底茫然。这正是为什么"$n=k+2e-1$ 就够"的猜想是错的：把码长从 $n+2e$ 降到 $n+2e-1$，最小距离从 $2e+1$ 降到 $2e$，纠错半径就从 e 掉到 $e-1$。

定理 8.4（Reed–Solomon 码的最小距离）：取码字长度 n、消息长度 k（即多项式次数 $<k$）、求值点 $\alpha_1,\dots,\alpha_n$ 互不相同，则 $d_{\min}=n-k+1$。

证明策略：双向夹逼。下界（$\ge$）用反证法 + Property 1；上界（$\le$）用**显式构造**一对距离恰为 $n-k+1$ 的码字。

逐步推导（下界）：1. 取两个不同的消息 $\vec{m} \ne \vec{m}'$，对应多项式 $P \ne P'$，次数都 $\le k-1$。**依据**：编码是单射，且消息 $\leftrightarrow$ 系数一一对应。 2. $D(x)=P(x)-P'(x)$ 是非零多项式，次数 $\le k-1$。**依据**：$P \ne P'$，差的次数不超过两者次数之最大值。 3. 由 Property 1，D 在 $GF(q)$ 中至多有 $k-1$ 个根。**依据**：讲次 7 的 Property 1。 4. 因此 $P(\alpha_i) \ne P'(\alpha_i)$ 至少在 $n-(k-1)=n-k+1$ 个求值点上成立（至多有 $k-1$ 个求值点可能"撞车"）。**依据**：第 3 步 + n 个求值点互不相同。 5. 即 $d(\vec{c}(\vec{m}),\vec{c}(\vec{m}')) \ge n-k+1$ 对任意一对不同消息成立，故 $d_{\min} \ge n-k+1$。**依据**：最小距离定义。

逐步推导（上界）：6. 构造 $P(x) := \prod_{j=1}^{k-1}(x-\alpha_j)$，其系数取自 $GF(q)$，次数恰为 $k-1 \le k-1$，故它是合法消息对应的多项式；再取 $P'(x) := 0$（即全零消息）。**依据**：构造（注意 $k=1$ 时该乘积为空积，取 $P(x)\equiv 1$，此时 $n-k+1=n$，与第 8 步结论一致）。 7. P 与 P' 在每个 α_j（$j \le k-1$）处取值相同：$P(\alpha_j)=0=P'(\alpha_j)$。**依据**：第 6 步。 8. 而对 $j>k-1$，$\alpha_j \notin \{\alpha_1,\dots,\alpha_{k-1}\}$，故 $P(\alpha_j) \ne 0 = P'(\alpha_j)$——两者不同。所以在 n 个坐标中恰有 $n-(k-1)=n-k+1$ 个坐标不同，即

$$d\big(\vec{c}(\vec{m}_P),\vec{c}(\vec{m}_{P'})\big) = n-k+1.$$

依据：第 6、7 步。 9. 最小距离是最小的那一对，故 $d_{\min} \le n-k+1$。**依据**：第 8 步。 10. 第 5 步与第 9 步合起来：$d_{\min}=n-k+1$。**依据**：双向夹逼。

与官方 Note 参数化的对照：官方记消息长 n_0、码字长 n_0+2k_0、要纠 k_0 个错误，对应本笔记的 $k=n_0$、$n=n_0+2k_0$、$e=k_0$。于是 $d_{\min}=n-k+1=2k_0+1$，与官方 Note 的定理（"把 n 个消息字符编成 $n+2k$ 长码字的 RS 码，最小距离为 $2k+1$"）完全一致。由定理 8.3(a)，$2k_0+1$ 的距离恰好能纠 $\lfloor 2k_0/2 \rfloor = k_0$ 个错误，冗余量分毫不差。

【证明机制解说】：这个定理的全部魔法只有一句：**"两个不同的低次多项式不能在许多点上相等"**。次数 $<k$ 的曲线彼此至多相交 $k-1$ 次，所以只要采样点够多，任意两条不同曲线对应的码字就必然在至少 $n-k+1$ 个刻度上分歧。第 6–8 步那个"让 P' 取零多项式、让 P 恰好在 $k-1$ 个求值点取零"的构造说明这个界**能被达到**；而定理断言的是**最坏的那对**也有 $n-k+1$。这正是 RS 码被称为 **MDS 码 (Maximum Distance Separable，可达最大距离可分码)** 的原因：在给定 n 与 k 时，没有任何码能做得更好（这是 Singleton 界 $d \le n-k+1$ 的等号情形）。

定理 8.5（Berlekamp–Welch 译码的正确性）：工作于 $GF(q)$，$q>n$。设消息长度 k、码字长度 n、$n \ge k+2e$。接收值为 $r_1,\dots,r_n$，真实码字来自次数 $<k$ 的多项式 P，且实际错误数 $t \le e$。设 (Q',E') 是线性方程组 $Q(i)=r_iE(i)$（$i=1,\dots,n$）的**任意**一组解，其中 Q' 次数 $\le k+e-1$、E' 是首一且次数恰为 e 的非零多项式。则 E' 整除 Q'，且 $Q'/E'=P$。

证明策略：先说明方程组的**相容性**（显式给出一组解），再证明**商唯一**。商唯一的关键杠杆是"两条次数都 $\le n-1$ 的多项式若在 n 个点上相等则恒等"——这是讲次 7 唯一性定理的第三次露面，只不过这次用在乘积 $Q'E$ 与 QE' 上。得到恒等之后才敢做除法。

逐步推导：1. （相容性）令 $E(x)=\prod_{j=1}^{t}(x-e_j)\cdot g(x)$，其中 g 是任意的次数为 $e-t$ 的首一多项式（$t=e$ 时取 $g\equiv 1$；$t<e$ 时可取 $g(x)=x^{e-t}$），这样 E 是首一 e 次多项式。再令 $Q(x)=P(x)E(x)$，其次数 $\le (k-1)+e = k+e-1$。**依据**：构造。 2. 对每个 i：若 i 不是错误位置，则 $r_i=P(i)$，于是 $Q(i)=P(i)E(i)=r_iE(i)$；若 i 是错误位置，则 $E(i)=0$，于是 $Q(i)=P(i)\cdot 0=0=r_i\cdot 0=r_iE(i)$。两种情况都满足方程。**依据**：$E$ 的根恰好包含全部错误位置。 3. 故第 1 步的 (Q,E) 是一组解，方程组**必有解**（相容），解集非空。**依据**：第 2 步。 4. （规模核算）未知数个数：Q 的系数 $a_0,\dots,a_{k+e-1}$ 共 $k+e$ 个；E 的系数 $b_0,\dots,b_{e-1}$ 共 e 个（x^e 的系数固定为 1，不是未知数）。合计 $k+2e$ 个；方程数 n。由条件 $n \ge k+2e$，未知数不多于方程数。**依据**：定义 + 条件。 5. 设 (Q',E') 是任意一组解，于是 $Q'(i)=r_iE'(i)$ 对所有 i 成立；同时 $Q(i)=r_iE(i)$ 也成立。**依据**：第 2 步与"(Q',E') 是解"。 6. 把第一式乘 $E(i)$、第二式乘 $E'(i)$，两边都等于 $r_iE(i)E'(i)$，故

$$Q'(i)E(i) = Q(i)E'(i), \qquad i = 1, 2, \ldots, n.$$

依据：代数运算（$GF(q)$ 中乘法交换）。 7. 考虑多项式 $A(x) := Q'(x)E(x)$ 与 $B(x) := Q(x)E'(x)$。次数上：$\deg A \le (k+e-1)+e = k+2e-1 \le n-1$，同理 $\deg B \le n-1$。**依据**：次数相加 + 条件 $n \ge k+2e$。 8. $A-B$ 的次数 $\le n-1$，却在 n 个互不相同的点 $1, 2, \ldots, n$ 上取零（第 6 步），故 $A-B$ 至少有 n 个根；由 Property 1（次数 $\le n-1$ 的**非零**多项式至多 $n-1$ 个根）得 $A-B \equiv 0$，即

$$Q'(x)E(x) = Q(x)E'(x) \quad \text{对一切 } x \in GF(q).$$

依据：讲次 7 的 Property 1。 9. 代入 $Q = P \cdot E$：$Q'(x)E(x) = P(x)E(x)E'(x)$。移项得 $E(x)\big(Q'(x) - P(x)E'(x)\big) = 0$。**依据**：代数运算。 10. $GF(q)$ 上的多项式环是**整环 (integral domain)**——两个非零多项式之积非零（没有零因子）——且 E 首一故非零，于是由消去律得

$$Q'(x) - P(x)E'(x) \equiv 0, \qquad \text{即} \quad Q'(x) = P(x)E'(x).$$

> **依据**：整环消去律。

1. 第 10 步同时说明 E' 整除 Q'，且 $Q'(x)/E'(x) = P(x)$。**依据**：整除的定义。
2. 于是无论线性方程组给出哪一组解，长除法 Q'/E' 得到的**一定是 P**；再用 $P(i)$ 覆盖 r_i，即得无错的原消息。**依据**：第 11 步 + 定理 8.4 的编码定义。

【证明机制解说】：官方 Note 提出的疑问是"方程组会不会有假解 (spurious solution)"。第 8 步是整条链子的关键关节：**"n 个点锁死次数 $\le n-1$ 的多项式"**。注意第 8 步的结论比"在某 n 个点上取值相等"强得多——它说 **$Q'E$ 与 QE' 作为多项式恒等**。只有升级到恒等，第 10 步才敢做除法。同时也要看清定理的边界：它只保证**商**唯一，不保证 (Q', E') 唯一。当 $t < e$ 时（尤其当根本没有错误时），E 可以乘上任意补次因子，解构成一整族；但每一族成员的商都等于同一个 P。

反例（条件 $n \ge k+2e$ 不可省）：在 $GF(7)$ 上取 $k=3$、$e=1$、$n = k+2e-1 = 4$，求值点 $1, 2, 3, 4$。取两条消息

$$P_0(x) = 0 \quad (\text{码字 } 0,0,0,0), \qquad P_1(x) = x^2 - 3x + 2 \equiv x^2 + 4x + 2 \pmod 7.$$

P_1 的码字为 $(P_1(1), P_1(2), P_1(3), P_1(4)) = (0, 0, 2, 6)$，与 P_0 的码字距离为 2（正是 $n-k+1 = 2$）。现在令接收串 $\vec{r} = (0, 0, 2, 0)$：

$$d(\vec{r}, \vec{c}_0) = 1 \le e = 1, \qquad d(\vec{r}, \vec{c}_1) = 1 \le e = 1.$$

两个码字都落在半径 1 的纠错球内，**译码结果不唯一**：$P(0) = 0$ 与 $P(0) = 2$ 两个秘密都说得通。这正说明"$n < k+2e$ 时无法唯一译码"，冗余必须加倍。同样地，$k = 1, e = 1, n = 1$（码字长 2）时码字为 (m, m)，距离 2，接收串 $(0, 1)$ 与 $(0, 0)$、$(1, 1)$ 的距离都是 1，同样歧义。

与经典问题的联系

问题一：核发射授权（秘密共享的原始动机） 20 世纪 50–60 年代，美国总统艾森豪威尔批准了在极端紧急情况下由高级军官动用核武器的指令。这里的关键约束是双重的：**既不能让任何一个人单独掌握发射码**，也不能要求所有官员都到场（否则在突袭下无法及时反击）。数学建模：设官员数 n、门限 k，秘密 s 是发射码（$GF(q)$ 中的一个数，$q > s$ 且 $q > n$）。方案设计即 Shamir 方案：随机取 $a_1, \ldots, a_{k-1}$，公开"曲线次数为 $k-1$"这一事实，给第 i 人发 $P(i)$，销毁全部 a_j。正确性由定理 8.1 保证（k 人 Lagrange 插值 $\to P(0) = s$）；安全性由定理 8.2 保证（$k-1$ 人的后验分布等于先验）。今日的同类应用包括**密钥托管 (key escrow)**、**多重签名钱包**、**公司主密钥分权保管**、以及**安全多方计算 (secure multiparty computation)** 中的输入分片。

问题二：从"完整性/认证"转向"冗余/容错"——与 RSA 的分工 讲次 6 的 RSA 解决的是**机密性**（别人看不懂）与**完整性/认证**（别人改不了而不被发现，靠哈希与签名）。本讲解决的是另一类问题：**我不阻止你改，但我改得回来**。二者的分工是密码学与编码理论的分工： – RSA 假设信道上的对手有计算能力但无无穷算力，用**计算困难性**换取安全； – 纠错码假设信道会无心或有意地篡改至多 e 个符号，用**冗余**换取容错，并且这个容错是**无条件**的——定理 8.3 与 8.4 不依赖任何计算假设，连算力无限的对手也无法击穿。

一个典型的真实系统会两者并用：先用 RSA 签名保证"这是真的发送者"（认证），再用 RS 码保证"即使路上被划伤 30% 也能读出"（容错）。

问题三：真实世界里的 Reed–Solomon 码 – **光盘与二维码**：CD/DVD/Blu-ray 与 QR 码都用 RS 码对抗划痕、污渍与手指印。QR 码的四个纠错等级 L/M/Q/H 分别能恢复约 7%/15%/25%/30% 的码字，物理上等价于选择不同的 e。 – **深空与卫星通信**：Voyager 1/2 的图片传输用了与卷积码级联的 RS 码；卫星电视、DVB 标准、DSL 与电缆调制解调器均含 RS 码。经典参数 RS(255,223) 在 $GF(2^8)$ 上工作：码字 255 字节、消息 223 字节、最小距离 33，可纠 $\lfloor 32/2 \rfloor = 16$ 个字节错误。 – **数据中心与分布式存储**：把文件切成 k 块并生成 $n-k$ 块冗余（RS 纠删码），任意 k 块即可重建（即本讲的擦除情形），比三副本方案节省大量存储。Facebook 的 f4 系统、Azure 的 LRC 都是这类设计。 – **RAID-6 与并行计算**：双校验盘本质上是一个允许两块"擦除"的编码；RS 码还被用于加速并行计算中的"慢节点 (straggler)"容错。 – **二维码的实际编码流程**：数据字节 $\to$ RS 码字 $\to$ 按掩模图案铺到方阵上。解码时先读定位图形，再按 Reed–Solomon 纠错；若错误数超过纠错能力，二维码会直接报告"无法识别"而不是给出错误结果——这正是定理 8.3(b) 的检错能力在起作用。

数值对照（本讲算例与真实参数的关系）：本笔记用 $GF(7)$、$GF(11)$ 只是为了能手算，所有结构在 $GF(2^8)$ 或 $GF(2^{32})$ 上一字不改。唯一变化是"逆元怎么算"：小域可以试除或查表，大域用扩展欧几里得算法（讲次 5）。条件 $q > n+2e$ 在真实系统中从来不是瓶颈：n 最大不过几千，$q = 2^8 = 256$ 或 2^{32} 都远远够用。**注意**：$GF(2^{32})$ 是一个域但不是 $\mathbb{Z}_{2^{32}}$；直接对 2^{32} 取模的算术会失去域结构（2^{32} 不是素数），讲次 7 的 Property 1 会失效——真实实现使用的是多项式基下的 $GF(2^{32})$ 算术，这属于 Math 114 / EE229B 的内容。

与其他讲次的关联

- **讲次 7（Polynomials）**：本讲的两个"发动机"——Property 1（次数 d 的非零多项式至多 d 个根）与 Property 2（$d+1$ 个点唯一确定次数 $\le d$ 的多项式）——直接来自 L07。定理 8.1 是 Property 2 的推论；定理 8.3、8.4、8.5 全部依赖 Property 1。L07 的**系数表示 / 值表示**对偶也正是 RS 码的定义本身：系数表示 $\to$ 值表示是编码，值表示 $\to$ 系数表示是译码。另外 L07 已给出 Shamir 方案的雏形，本讲把它补上了**严格的安全性证明**。
- **讲次 4（Modular Arithmetic）**：整个方案在 $\mathbb{Z}_q$ 上做加法与乘法，份额与恢复值都是同余类；"所有算术 mod q"这句话就是 L04 的语言。
- **讲次 5（Euclid, FLT, CRT）**：Lagrange 插值公式里的每个分母 $i_j - i_\ell$ 都要求逆元，其存在性来自 L05 的"q 素数 $\Rightarrow$ 每个非零元可逆"；实际计算逆元用扩展欧几里得。$\Delta_j(x)$ 的构造（分子乘上"除自己以外所有 $(x - x_\ell)$"）与中国剩余定理中"单位分解"的构造思路完全同构——L07 的 Note 明确点出了这一类比。

- **讲次 6（RSA）**：对照学习最有价值：RSA 用"单向函数 + 计算困难性"保护**不可读性**，纠错码用"高最小距离 + 冗余"保护**可恢复性**。两者都建立在模运算与有限域之上，但安全性假设的类型完全不同。
- **讲次 9、10（Graphs / Graphs II）**：官方 Note 开篇即指出纠错码有两大流派——**代数码**（基于有限域上的多项式，本讲主题）与**组合码**（基于图论）。L09–L10 的图论正是组合码的语言；L10 将讨论的超立方体 (hypercube) 与一般图会在"低密度奇偶校验码 (LDPC)"等构造中再次出场。
- **讲次 11（Stable Matching）**：与本讲同为"算法 + 正确性证明"的范式：Gale–Shapley 要证"算法终止"与"输出稳定"，本讲要证"插值唯一"与"译码正确"。两者都示范了"先设计能跑的算法，再用数学证明它给出的答案是唯一正确的"这一 CS70 核心方法论。
- **讲次 13（Computability）与算法复杂度**：Berlekamp–Welch 的最大卖点是把"枚举 $\binom{n}{e}$ 个错误位置"这一**指数时间**搜索替换为一次**多项式时间**的线性方程组求解。这是"同一问题的不同表述导致截然不同复杂度"的标准案例。若允许 e 超过 $\lfloor (d-1)/2 \rfloor$，一般的最小距离译码问题是 NP 难的——这属于 L13 讨论的"困难/不可行"图景。
- **讲次 14（Counting）与讲次 19（Random Variables）**：安全性论证里要数"有多少条候选曲线"，答案是 q 条（L14 的乘法原理：k 个系数各 q 种取值，被 $k-1$ 个点约束后还剩 q 种）；若把 s 视为均匀随机变量，则份额 $(Y_1, \ldots, Y_{k-1})$ 与 s 独立，这正是 L19 的独立性语言。
- **讲次 17、18（Conditional Probability & Bayes / Independence）**：定理 8.2 的结论可以精确表述为"s 与任意 $k-1$ 个份额**相互独立**"（L18 的主题）；用 L17 的贝叶斯公式会说"后验 = 先验"。这是"零泄露"最严格的说法。

关键要点

1. **一句话抓住 Shamir**：秘密是曲线在 $x=0$ 处的**截距**，份额是曲线在其他点上的**取值**。k 个点钉死曲线 $\rightarrow$ 截距暴露；$k-1$ 个点收敛不住曲线 $\rightarrow$ 截距可自由滑动 q 个位置。
2. **正确性靠 Property 2，安全性靠"兼容性对称"**。证明安全性时不能只说"算不出来"，必须对**每一个**猜测值 s' 构造一条过 $(0, s')$ 与已知 $k-1$ 点的曲线，从而证明候选集合大小恒为 q（没有变小），信息量为 0 比特。
3. **距离是编码的通用"货币"**：d 个距离单位可换 $d-1$ 个检错、$\lfloor (d-1)/2 \rfloor$ 个纠错、$d-1$ 个纠擦除。因此**纠错比擦除贵一倍**：擦除只要 $n \geq k+e$，纠错要 $n \geq k+2e$。
4. **Reed–Solomon 是 MDS 码**：$d_{\min} = n-k+1$，在 n, k 固定时达到 Singleton 上界。下界只用到"两条次数 $< k$ 的曲线至多相等 $k-1$ 次"；上界靠 $P(x) = \prod_{j=1}^{k-1}(x-\alpha_j)$ 与零多项式这一对显式构造。
5. **Berlekamp–Welch 的核心恒等式**：$Q(i) = r_i E(i)$ 对**出错与不出错的位置同时成立**。这一个恒等式把 n 条方程、$k+2e$ 个未知数（Q 的 $k+e$ 个系数 + E 的 e 个系数）摆上台面。因为 $t < e$ 时 E 可任意补因子，**解 (Q', E') 可以不唯一，但商 Q'/E' 永远唯一**（定理 8.5）。

常见误区与注意事项

1. **把"$k-1$ 人无信息"误解成"计算上算不出来"**。这是**信息论**层面的结论：对 $k-1$ 人而言秘密的后验分布仍然均匀，与先验一模一样，就算给他们无限算力也得不到任何东西。反过来，若只实现了"计算上困难"（例如用哈希保护秘密），那就不满足本讲的门限定义，也不是 Shamir 方案。
2. **忘记"q 必须是素数"（更一般地，必须是域的阶）**。若在 $\mathbb{Z}_8$ 这样的合数环上做插值，Property 1 直接失效：$x^3 \equiv 0 \pmod 8$ 有 $x = 0, 2, 4, 6$ 四个根，一个三次多项式竟然有 4 个根，唯一性论证全面崩塌（详见讲次 7 的 Note 脚注）。同理，Lagrange 公式中的除法要求分母可逆，而 $\mathbb{Z}_m$ 中 m 为合数时并非所有非零元都可逆。特别注意 $GF(2^{32})$ 与 $\mathbb{Z}_{2^{32}}$ 不是一回事。
3. **混淆"擦除"与"错误"的冗余代价**。擦除知道位置，k 个擦除只需 k 个额外符号；错误不知道位置，k 个错误需要 $2k$ 个额外符号。若把两者混为一谈，就会设计出看似"够用"、实则无法唯一译码的方案——定理 8.3 与两个反例都说明了这一点。
4. **把"最小距离"算成"平均距离"或"最大距离"**。$d_{\min}$ 是**最坏那对**码字的距离，它决定了保证能纠多少错；某对码字距离很大毫无用处。反过来，也不能因为"大多数码字对离得很远"就宣称纠错能力强。
5. **在 Berlekamp–Welch 里误以为 (Q, E) 一定唯一**，于是看到"无错"情形下解出一整族解就以为算法错了。正确理解是：无错时真实的 E 完全不确定（没有错误位置需要标记），补的额外根可以任取，所以 (Q', E') 有一族；但任何一组解的商都等于 P（定理 8.5 第 10–11 步）。**算法的输出是 P，不是 E。**
6. **忘记 $E(x)$ 的首一约定**。本讲取 E 为**首一**多项式，即把 x^e 的系数固定为 1 而不作为未知数，这样未知数才恰好是 e 个（$b_0, \ldots, b_{e-1}$），总数才是 $k+2e$。若把 x^e 的系数也当未知数，未知数就会比不等式所允许的多 1，论证会显得"解不出来"。
7. **误用"次数恰好 $k-1$"与"次数至多 $k-1$"**。Shamir 方案要求曲线次数**恰好** $k-1$（最高次系数非零），否则实际门限会降到 $k-1$；而 Reed–Solomon 的译码只关心"次数 $\leq k-1$"，因为消息的最高系数可以恰好为 0。这两个约定必须在同一篇推导中保持一致。
8. **纠错与检错不能同时达到上界**。定理 8.3 说 d 能纠 $\lfloor (d-1)/2 \rfloor$ 个错，也能检 $d-1$ 个错，但**不能同时**要求"纠 t 个错并且检 $t+1$ 个错"之外的更强保证；经典结论是 $(d \geq 2t+s+1)$ 才能同时纠 t 个错并检 s 个错。混用两个界会得出过强的结论。

思考题（带答案）

Q1.（纯计算） 在 $GF(11)$ 上取 $k=3$、$s=5$，多项式 $P(x) = 5 + 2x + 3x^2$。份额为 $P(1), \ldots, P(5)$。(a) 算出 5 个份额。(b) 用份额 2、3、4 通过 Lagrange 插值在 $x=0$ 处求值，恢复 s（写出每个基函数在 0 处的值）。(c) 若只有份额 2、4 两份，攻击者能否排除 $s'=0$ 这个猜测？请给出具体的相容曲线。

▸ **答案**

(a) 逐个代入（全部 mod 11）：– $P(1)=5+2+3=10$ – $P(2)=5+4+12=21\equiv 10$ – $P(3)=5+6+27=38\equiv 5$（$38-33=5$） – $P(4)=5+8+48=61$，$61-55=6$ – $P(5)=5+10+75=90$，$90-88=2$

份额为 $(1,10),(2,10),(3,5),(4,6),(5,2)$。（脚本对全部 10 个三元子集做 Lagrange 恢复，结果都是 $P(0)=5$，验证通过。）

(b) 用份额 2、3、4，即点 $(2,10),(3,5),(4,6)$，求 $x_0=0$ 处的

$$\Delta_j(0)=\prod_{\ell\neq j}\frac{0-i_\ell}{i_j-i_\ell}.$$

- $\Delta_2(0)=\dfrac{(0-3)(0-4)}{(2-3)(2-4)}=\dfrac{(-3)(-4)}{(-1)(-2)}=\dfrac{12}{2}$。注意 $12\equiv 1$，$2^{-1}\equiv 6\pmod{11}$（因 $2\times 6=12\equiv 1$），故 $\Delta_2(0)\equiv 1\times 6=6$。
- $\Delta_3(0)=\dfrac{(0-2)(0-4)}{(3-2)(3-4)}=\dfrac{8}{-1}\equiv 8\times 10=80\equiv 80-77=3$。
- $\Delta_4(0)=\dfrac{(0-2)(0-3)}{(4-2)(4-3)}=\dfrac{6}{2}\equiv 6\times 6=36\equiv 36-33=3$。

于是

$$s\equiv 10\cdot 6+5\cdot 3+6\cdot 3=60+15+18=93,\qquad 93-88=5\pmod{11}.$$

恢复出 $s=5$，与 $P(0)=5+0+0=5$ 一致。

校验基函数：$\Delta_2(0)+\Delta_3(0)+\Delta_4(0)=6+3+3=12\equiv 1\pmod{11}$，这是"常值多项式 $P\equiv 1$ 的插值系数之和为 1"的必然结果，可用来检查算术。

(c) 不能排除。对任意猜测 $s'\in GF(11)$，三点 $(0,s'),(2,10),(4,6)$ 的横坐标两两不同，由 Property 2 存在唯一的次数 ≤ 2 多项式经过它们。以 $s'=0$ 为例，设 $P'(x)=a_0+a_1x+a_2x^2$，则

$$a_0=0,\quad a_0+2a_1+4a_2=10,\quad a_0+4a_1+16a_2=6\pmod{11}.$$

因为 $16\equiv 5\pmod{11}$，第三式即 $4a_1+5a_2=6$。前两式化为 $2a_1+4a_2=10$ 与 $4a_1+5a_2=6$。第一式乘 2 得 $4a_1+8a_2=20\equiv 9$，与第二式相减得 $3a_2=3$，故 $a_2=1$；代回得 $2a_1+4=10\Rightarrow 2a_1=6\Rightarrow a_1=3$。所以

$$P'(x)=3x+x^2,\qquad P'(0)=0,\ P'(2)=6+4=10,\ P'(4)=12+16=28\equiv 6.$$

可见份额 $(2,10),(4,6)$ 与"秘密为 0"完全相容。事实上 11 个候选值各对应一条唯一的相容曲线（脚本已逐个列出）。

Q2.（概念/证明） 有人提出一个"简化版"方案：选一条**次数为 $k-1$ 但常数项强制为 0** 的随机曲线 P（即 $P(0)=0$），再把秘密 s 作为整条曲线的**公共平移量**，即实际份额为 $\tilde P(x)=P(x)+s$ 在第 i 点的值。请指出这个方案在门限方案的两条性质中的哪一条上失败，并给出具体的攻击。

▸ **答案**

它满足性质 (1)（k 人可恢复：$\tilde P$ 的次数仍是 $k-1$，k 个点定曲线，$\tilde P(0)=P(0)+s=s$），但**严重违反性质 (2)**。

最清晰的失败情形取 $k=2$：此时 $P(x)=ax$，$\tilde P(x)=ax+s$。两人（或一人拿两份）得到 $\tilde P(i_1),\tilde P(i_2)$，联立

$$i_1a+s=\tilde P(i_1),\qquad i_2a+s=\tilde P(i_2)$$

是 2 个方程 2 个未知数。在 $i_1\neq i_2$ 时系数行列式 $i_1-i_2\neq 0$，故 (a,s) 被**唯一确定**——秘密仅用 $k-1=1$ 个"额外条件"就被算出来了，门限被击穿。

更根本的问题在于对定理 8.2 的破坏：安全性证明要求对每个猜测 s' 都存在一条过 $(0,s')$ 与已知点的曲线，且**候选曲线总数必须等于 q** 才能得到"零信息"。本方案把曲线族用"常数项为 0"这一额外约束压到只剩 $q^{k-1}\cdot q$ 种组合中的一部分，一旦"未知自由度"的核算与随机性来源不匹配，攻击者就利用约束发起攻击（如上面的联立）。例如取 $k=2$，两条份额实际上就是两个方程——自由度被彻底用光。

教训：$k-1$ 个随机系数必须**全部独立均匀随机**，且 $P(0)$ 必须是曲线中唯一"非随机"的部分；任何额外约束（常数项为 0、系数满足某个线性关系、系数取自小子集）都会缩小候选集合、泄露信息。

Q3.（计算 + 概念） 在 $GF(7)$ 上，消息长度 $k=3$（P 次数 ≤ 2），码字长度 $n=5$，求值点为 $1,2,3,4,5$。真实多项式 $P(x)=x^2+x+1$，码字为 $(3,0,6,0,3)$。设第 1 个坐标被篡改为 2，接收串 $r=(2,0,6,0,3)$。(a) 写出 Berlekamp–Welch 的 5 个方程并解出 Q,E。(b) 做长除法得 P，并说明错误位置。(c) 若实际上**没有**任何错误（$r=(3,0,6,0,3)$），方程组会给出多少解？请说明为什么这不影响译码。

▸ **答案**

(a) 取 $e=1$：$Q(x)=a_0+a_1x+a_2x^2+a_3x^3$（次数 $\le k+e-1=3$，4 个系数），$E(x)=x+b_0$（首一，1 个未知数）。方程 $Q(i)=r_iE(i)$ 即 $a_0+a_1i+a_2i^2+a_3i^3=r_i(i+b_0)$，把含 b_0 的项移到左边：

$$a_0+a_1i+a_2i^2+a_3i^3-r_ib_0=r_ii.$$

逐一代入（$r=(2,0,6,0,3)$，全 mod 7）：- $i=1$：$a_0+a_1+a_2+a_3-r_1b_0=r_1$，即 $a_0+a_1+a_2+a_3+5b_0=2$（因 $-r_1=-2\equiv5$）。- $i=2$：$r_2=0$ 使 b_0 项消失，$a_0+2a_1+4a_2+8a_3$；$8\equiv1$，右端为 0。即 $a_0+2a_1+4a_2+a_3=0$。- $i=3$：$r_3=6$，故 $-6b_0\equiv1\cdot b_0$；$i^3=27\equiv6$；右端 $r_3\cdot3=18\equiv4$。即 $a_0+3a_1+2a_2+6a_3+b_0=4$。- $i=4$：$r_4=0$，$i^2=16\equiv2$，$i^3=64\equiv1$，右端 0。即 $a_0+4a_1+2a_2+a_3=0$。- $i=5$：$r_5=3$，$-3\equiv4$；$i^2=25\equiv4$，$i^3=125\equiv6$；右端 $3\times5=15\equiv1$。即 $a_0+5a_1+4a_2+6a_3+4b_0=1$。

解该 5×5 线性方程组（脚本用模 7 高斯消元逐行验证）得

$$a_3=1,\quad a_2=0,\quad a_1=0,\quad a_0=6,\quad b_0=6.$$

于是 $Q(x)=x^3+6$，$E(x)=x+6=x-1$。

(b) 因为 $E(1)=1+6=7\equiv0$，错误位置是 $e_1=1$（与"第 1 个字符被改"一致）。长除法：

$$P(x)=\frac{Q(x)}{E(x)}=\frac{x^3+6}{x-1}=x^2+x+1\pmod 7.$$

校验：$(x-1)(x^2+x+1)=x^3-1\equiv x^3+6$ ✓。于是 $P(1)=1+1+1=3$，用 3 覆盖被篡改的 2，恢复原消息 $(3,0,6)$，即字母 d,a,g。

(c) 若 $r=(3,0,6,0,3)$（无错），同样的方程组秩只有 4（脚本验证），b_0 成为自由变量，解为**一整族**：

$$a_3=1,\qquad a_2=a_1=1+b_0,\qquad a_0=b_0,\qquad b_0\in GF(7)\text{ 任取}$$

（即 $Q(x)=(x+b_0)(x^2+x+1)$，共 7 组解）。对每个 b_0 做长除法：

$$\frac{(x+b_0)(x^2+x+1)}{x+b_0}=x^2+x+1$$

恒成立（只要 $E'=x+b_0$ 非零，而 $b_0\in GF(7)$ 恒有常数项 b_0 使 $E'\not\equiv0$），所以 P 总是被正确恢复。**结论**：(Q',E') 不唯一，但商唯一——这正是定理 8.5 所断言的。

（顺带一个勘误提醒：归档 Note 在此处把无错情形的解印成 $a_0=1$。把 $a_0=1$ 代回方程组可发现只有 $b_0=1$ 时 5 个方程才全部成立；按方程组回代的正确关系是 $a_0=b_0$。本笔记以回代结果为准。）

```
图 8.1  Shamir 秘密共享 (GF(11), n=5, k=3, s=5, P(x)=5+2x+3x^2)
================================================================
   份额分布（x 为参与方编号，y 为份额值）

   y
  10 |  o(1,10)  o(2,10)
   9 |
   8 |
   7 |
   6 |                      o(4,6)
   5 |     s(0,5)                o(3,5)
   4 |
   3 |
   2 |                             o(5,2)
   1 |
   0 +----+----+----+----+----+----+----> x
      0    1    2    3    4    5
      ^
      秘密 s = P(0) = 5    （这条曲线的"截距"就是秘密）

  任意 3 个 o  -> 曲线被钉死 -> 读出截距 5        （定理 8.1）
  任意 2 个 o  -> 曲线仍可自由摆动               （定理 8.2）
                  截距可以是 0..10 中任何一个：
                  s'=0  -> P'(x)=0+5x+5x^2
                  s'=5  -> P'(x)=5+2x+3x^2   <-- 真身
                  s'=7  -> P'(x)=7+3x
                  ...  共 11 条，全部相容
================================================================
```

```
图 8.2  擦除 vs 错误：为什么纠错要付双倍冗余
============================================================
【擦除 erasure】接收方知道"洞"在哪，只需补上洞的个数
  发送  c1 c2 c3 c4 c5 c6
  接收  c1 -- c3 c4 c5 --       知道位置 2 和 6 丢了
        ^^ 洞有编号，等价于已知 x=2, x=6 而不知 y
  代价：k 个擦除  ->  多发 k 个符号   (码长 >= 消息长 + k)
        要求 d >= k+1                 (定理 8.3(c))

【错误 error】接收方收到同样多的符号，但不知哪几个是假的
  发送  c1 c2 c3 c4 c5 c6
  接收  r1 r2 r3 r4 r5 r6       其中至多 k 个 r_i != c_i，位置未知
        ?  ?  ?  ?  ?  ?          每个位置都可能是"洞"或"真值"
  代价：k 个错误  ->  多发 2k 个符号  (码长 >= 消息长 + 2k)
        要求 d >= 2k+1                (定理 8.3(a) 与 8.4)

  直觉：一个错误有两种解释（值被改了 / 位置算错了），
        纠错必须在"两个都可能是真码字"的情形之间做出唯一裁决，
        这就要求码字之间的距离比擦除情形再宽一倍。
============================================================
```

```
图 8.3  汉明球：最小距离 d 如何决定纠错能力
================================================================
码字空间（每颗 * 是一个码字；相邻两 * 的最短距离 d = 5，本例 t=2）

      ( . . . . . )               ( . . . . . )
     (  半径 t=2   )             (  半径 t=2   )
      (   的球     )             (   的球     )
       (          )               (          )
        *   o o                     *   o o
       o  *  o                     o  *  o
        o o                         o o
          \                         /
           \   球心距离 d >= 2t+1    /
            \                       /
             +---- 若两球相交 --------+
               则球心距离 <= 2t = 4 < d = 5  ==>  矛盾!
               所以半径 t = floor((d-1)/2) 的球两两不交
               接收串落在哪个球里 -> 判给该球心（唯一译码）

  d = 5:  t = 2  (纠 2 个错；检 4 个错；抗 4 个擦除)
  d = 4:  t = 1  (纠 1 个错；检 3 个错)
  d = 2:  t = 0  (一个错都纠不了，只能检出 1 个错)
  d = 1:  毫无防护（消息集合本身就处于这个状态）
================================================================
```

```
图 8.4  Reed-Solomon 译码 = 用点重拟合曲线（GF(7), k=3, n=5, e=1）
====================================================================
  y
  6 |                 x  <- 真码字 P(3)=6
  5 |
  4 |
  3 |  * (1,3) <-- 真值           x(5,3)
  2 |  X  <-- 被篡改为 2
  1 |
  0 |        x(2,0)    x(4,0)
    +----+----+----+----+----> i
      1    2    3    4    5

  Berlekamp-Welch 两步走：
  (1) 解线性方程组 Q(i) = r_i * E(i)（i=1..5，5 个方程 5 个未知数）
        -> Q(x) = x^3 + 6 ,  E(x) = x + 6 = x - 1
        E 的根 x = 1  ==>  错误位置 e_1 = 1
  (2) 长除法 P = Q / E = (x^3+6)/(x-1) = x^2 + x + 1
        -> P(1) = 3 覆盖掉 X(1,2)，还原原始消息 (3,0,6)
====================================================================
```

```
图 8.5  为什么 n < k+2e 会失败 (GF(7), k=3, e=1, n=4 反例)
================================================================
 两条消息的码字（求值点 1,2,3,4）：

   P0 = 0           码字 c0 = (0, 0, 0, 0)
   P1 = x^2+4x+2    码字 c1 = (0, 0, 2, 6)
                              ^^^^^^^^^^^
                    距离 d(c0,c1) = 2  =  n-k+1 = 4-3+1

 接收串 r = (0, 0, 2, 0)

   d(r, c0) = 1   <=  e = 1     --> 译码为 P0，秘密 = P0(0) = 0
   d(r, c1) = 1   <=  e = 1     --> 译码为 P1，秘密 = P1(0) = 2

  两个码字都在半径 1 的球内！译码结果不唯一，秘密无法确定。
  ==> 冗余必须加倍：n >= k + 2e   （本反例 n = k+2e-1 = 4）
================================================================
```

附加算例（对照官方 Note 的擦除例子，$GF(7)$，$n=4$，$k=2$）：消息 $m_1=3, m_2=1, m_3=5, m_4=0$，唯一的三次多项式为 $P(x)=x^3+4x^2+5$。校验：$P(1)=1+4+5=10\equiv 3$，$P(2)=8+16+5=29\equiv 1$，$P(3)=27+36+5=68\equiv 5$（$68-63=5$），$P(4)=64+64+5=133\equiv 0$（$133-133=0$）✓。多发 2 个冗余字符：$P(5)=125+100+5=230\equiv 6$（$230-224=6$），$P(6)=216+144+5=365\equiv 1$（$365-364=1$）。码字为 $(3,1,5,0,6,1)$。若第 2、6 个包被丢弃，接收方拿到点 $(1,3),(3,5),(4,0),(5,6)$，四个点足以（$n=4$）重建 P；脚本用 Lagrange 基函数验证重建出的系数恰为 $(5,0,4,1)$，即 $P(x)=x^3+4x^2+5$ ✓。这同时演示了定理 8.3(c)：$d_{\min}=6-4+1=3$，可抗 $d-1=2$ 个擦除，恰好覆盖本例的 2 个丢失。

附加算例（Berlekamp–Welch 的另一个参数组合，$GF(7)$，消息长 4、$e=1$、码长 6）：用上面同一个 $P(x)=x^3+4x^2+5$，码字 $(3,1,5,0,6,1)$，设第 1 个字符被从 3 篡改为 2，接收串 $r=(2,1,5,0,6,1)$。此时 Q 的次数 $\le k+e-1=4$，共 5 个系数，加上 b_0 共 6 个未知数、6 条方程（方阵）。脚本解出

$$Q(x)=2+5x+3x^2+3x^3+x^4,\qquad E(x)=x+6=x-1.$$

逐点校验 $Q(i)=r_iE(i)$：$i=1$ 时 $Q(1)=2+5+3+3+1=14\equiv 0$，$r_1E(1)=2\times 0=0$ ✓；$i=2$ 时 $Q(2)=2+10+12+24+16=64\equiv 1$，$r_2E(2)=1\times 1=1$ ✓；$i=5$ 时 $Q(5)=2+25+75+375+625=1102$，$1102 \bmod 7=3$（$7\times 157=1099$），$r_5E(5)=6\times 4=24\equiv 3$ ✓。长除法

$$\frac{Q(x)}{E(x)}=\frac{x^4+3x^3+3x^2+5x+2}{x-1}=x^3+4x^2+0x+5,$$

> **余式为零 ✓，恢复出 $P(x)=x^3+4x^2+5$，与原多项式一致；错误位置 $e_1=1$。**

Lecture 9: Graphs（图论基础）

概述

本讲引入整门课最重要的一种**离散建模语言**：图 (graph)。互联网的页面链接、大脑的神经元连接、城市的道路网、社交网络里"谁认识谁"——这些表面上毫不相干的系统，抽掉细节之后都是同一批数学对象：一组顶点加一组边。本讲分两步走。第一步给出图的正式定义（无向图、有向图、简单图、多重图）以及一整套基础术语（邻接、度、路径、环、连通性、连通分量、距离、二分图、完全图、补图），并用**握手引理** $\sum_{v\in V}\deg(v)=2|E|$ 展示"双计数 (double counting)"这一证明技巧的威力。第二步回到图论的历史起点——**柯尼斯堡七桥问题**，给出并完整证明**欧拉定理**：一个连通无向图存在欧拉回路，当且仅当每个顶点的度都是偶数。这个定理是"充要条件"证明的典范：必要性用"进出配对"的巧思，充分性用构造性算法加归纳法，两种风格截然不同的论证在同一个命题上汇合。

核心概念的直观解释

无向图（undirected graph） – **定义**：一个无向图是序对 $G=(V,E)$，其中 V 是**顶点集 (vertex set)**，E 是**边集 (edge set)**。E 中每个元素都是 V 的一个**二元子集** $\{u,v\}$（$u\neq v$），表示 u 与 v 之间有一条边。 – **直观解释（"它是什么意思？"）**：顶点是"东西"，边是"关系"。关系的本质特征是**对称**：如果"你在我的通讯录里"和"我在你的通讯录里"是同一件事，那就该用无向图。现实类比：双向街道、握手、婚姻关系、"两人互相认识"。 – **具体示例**：住户路网图 $G_3=(\{1,2,3,4\},\{\{1,2\},\{2,3\},\{1,4\},\{4,3\}\})$：顶点是房子，边是直接相连的道路。

图论最初的抽象：从柯尼斯堡到 K_4 形状 – **定义**：1736 年欧拉 (Leonhard Euler) 处理柯尼斯堡 (Königsberg，今俄罗斯加里宁格勒) 七桥问题时，做的正是"抽象"这一步：把每块陆地（两岸 A,D、两岛 B,C）换成一个小圆圈，把每座桥换成一条线段，于是问题从"城市地图"变成"能否一笔画完所有线段并回到起点"。 – **直观解释（"它是什么意思？"）**：这是计算机科学中**抽象 (abstraction)** 这一核心思想的最早范例——丢掉长度、位置、形状，只保留"谁和谁相连"。抽掉之后剩下的正是图。 – **具体示例**：柯尼斯堡的抽象图有顶点集 $V=\{A,B,C,D\}$，边集（多重集）为 $\{\{A,B\},\{A,B\},\{A,C\},\{B,C\},\{B,D\},\{B,D\},\{C,D\}\}$，共 7 条边。

有向图（directed graph） – **定义**：有向图 $G=(V,E)$ 中，边集 $E\subseteq V\times V$ 是**有序对**的集合（笛卡尔积 $U\times V=\{(u,v):u\in U,\ v\in V\}$）。边 (u,v) 带箭头，从 u 指向 v。 – **直观解释（"它是什么意思？"）**：有向边是**单向街道**：$u\to v$ 存在并不意味着 $v\to u$ 存在。现实类比："Alex 认识 Bridget 但 Bridget 不认识 Alex"（单向的"认识"）、网页 A 链接到网页 B、任务 A 必须在任务 B 之前完成。 – **具体示例**：$V=\{1,2,3,4\}$、$E=\{(1,2),(1,3),(1,4)\}$ 是一个有向图：$(1,2)\in E$ 但 $(2,1)\notin E$。 – **与无向图的关系**：若无向图的边 $\{u,v\}$ 理解为"两个方向都有"，则无向图恰是满足"$(u,v)\in E\iff(v,u)\in E$"的有向图；书写时对无向图去掉箭头，并把有序对写成集合 $\{u,v\}$。

相邻、邻居、度（adjacency, neighborhood, degree） – **定义**：若 $\{u,v\}\in E$，则称 u 与 v **相邻 (adjacent)**，互为**邻居 (neighbor)**，也说边 $e=\{u,v\}$ **关联 (incident)** 于 u 和 v。顶点 u 的**度 (degree)** 定义为

$$\deg(u) = \big|\{v \in V : \{u, v\} \in E\}\big|,$$

即与 u 相连的边的条数（在简单图中也就是邻居的个数）。度为 0 的顶点叫**孤立顶点 (isolated vertex)**。 – **直观解释（"它是什么意思？"）**：度就是"一个人认识多少个人"。孤立顶点是"谁都不认识的隐士"。在通信网络里，度就是"这台路由器有几根线"。 – **具体示例**：路网图 G_3 中 $\deg(1) = 2$（连到 2 和 4），$\deg(2) = 2$，$\deg(3) = 2$，$\deg(4) = 2$。若再加一个不与任何人相连的房子 5，则 $\deg(5) = 0$，5 是孤立顶点，且 G_3 变成不连通。 – **有向图的两种度**：**入度 (in-degree)** 是"从别人指向 u 的边数"，**出度 (out-degree)** 是"从 u 指向别人的边数"。在"u 认识 v"的社会网络里，入度 = 有多少人认识你（知名度），出度 = 你认识多少人（交际广度）。

自环（self-loop）、简单图（simple graph）、多重图（multigraph） – **定义**：边 $\{u, u\}$（或 (u, u)）叫**自环**。"一对顶点之间最多一条边"且"没有自环"的图叫**简单图**。允许一对顶点之间有多条边（**重边 / 平行边, parallel edges**）的图叫**多重图 (multigraph)**。 – **直观解释（"它是什么意思？"）**：自环是"自己认识自己"，在大多数建模场景中没有信息量。重边是"两地之间有不止一条路/桥"——柯尼斯堡恰好是这种情况（A 与 B 之间有两座桥，B 与 D 之间也有两座）。 – **具体示例**：本课程（以及 Berkeley 官方 Note）**默认不考虑自环，也默认两条顶点之间至多一条边**；遇到真有多重边的情形（如七桥问题），就把重边**塌缩 (collapse)** 成一条边。这个约定非常重要：它让"$\deg(u) = |\{v : \{u, v\} \in E\}|$"这个定义在简单图中自洽（既等于邻居数，也等于关联边数）。

路径、游走、环、回路（path, walk, cycle, tour） – **定义**：设 $G = (V, E)$ 无向。一条**游走 (walk)** 是顶点序列 $v_1, v_2, \dots, v_k$ 使得每对相邻的 v_i, v_{i+1} 之间有边（顶点可以重复）。若 $v_1, \dots, v_k$ **互不相同**，则称为**路径 (path)**（很多教材也写作 "simple path"，与允许重复的 walk 相对）。一条**环 (cycle / circuit)** 是 $v_1, \dots, v_n$ 互不相同且 $\{v_n, v_1\} \in E$ 的序列。起点与终点相同的游走叫**巡游 (tour)**。 – **直观解释（"它是什么意思？"）**：walk 是"随便溜达"（可以来回踱步），path 是"不重复经过同一栋房子的行进路线"，cycle 是"绕一圈回到出发点且中途不重复"。 – **具体示例**：在路网 G_3 中，$1 \to 2 \to 1 \to 4 \to 3$ 是 walk（顶点 1 出现了两次）；$1 \to 2 \to 3$ 是 path；$1 \to 2 \to 3 \to 4 \to 1$ 是 cycle（长度 4）。注意 $1 \to 4 \to 3 \to 2 \to 1$ 是同一个环的另一种走法。

连通性与连通分量（connectivity, connected component） – **定义**：无向图 G 称为**连通的 (connected)**，如果任意两个不同顶点之间都存在一条 path。不是连通的图称为**不连通的**。任何图都能唯一分解为若干**连通分量 (connected component)**：把顶点集划分成若干块 $V_1, \dots, V_k$，每块内部的顶点互相连通，块与块之间没有边。 – **直观解释（"它是什么意思？"）**：连通 = "从任何一个房子都能开车到任何别的房子"。连通分量 = "一个个互相隔绝的孤岛"。在设计路网时你绝不希望出现孤立顶点或隔绝的小区，因为那样有的人永远到不了别处。 – **具体示例**：G_3 是连通的（从 1 可以到 2、3、4）。若在原图上加顶点 5 且不与任何顶点相连，则图不连通，连通分量是 $V_1 = \{1, 2, 3, 4\}$ 与 $V_2 = \{5\}$。官方 Note 给出的例子则分成三块：$V_1 = \{1, 2, 3\}$、$V_2 = \{4\}$、$V_3 = \{5, 6, 7\}$。

距离（distance） – **定义**：两顶点 u, v 之间的**距离 (distance)** 是从 u 到 v 的最短 path 的**边数**。若不连通，则距离定义为 ∞。 – **直观解释（"它是什么意思？"）**：距离就是"最少走几条路"。在互联网中它对应"最少经过几跳 (hop)"，这正是路由协议最关心的量。 – **具体示例**：在 $G_3 = \{1\text{–}2, 2\text{–}3, 1\text{–}4, 4\text{–}3\}$ 中，从 1 出发的距离分别是 $d(1,1) = 0$、$d(1,2) = 1$、$d(1,4) = 1$、$d(1,3) = 2$（$1 \to 4 \to 3$ 或 $1 \to 2 \to 3$，都是 2 条边）。

二分图（bipartite graph） – **定义**：图 $G = (V, E)$ 是二分图，若顶点集可以划分为两个部分 $V = L \cup R$（$L \cap R = \varnothing$），且**每条边都从 L 跨到 R**，即 $E \subseteq L \times R$（等价地，L 内部与 R 内部都没有边）。 – **直观解释（"它是什么意思？"）**：二分图是"两个阵营"的结构：同一阵营的人互不相识，只跟对面阵营有往来。现实类比：求职者与岗位、学生与课程、男与女（在纯异性社交模型中）、以及电路中的"开关"与"被控制的线"。 – **具体示例**：$K_{3,3}$（张三户人家与三口井，每家都要连到每口井，但人家之间、井之间不连边）是二分图：$L = \{\text{三户人家}\}$，$R = \{\text{三口井}\}$，$|E| = 9$。另一个例子是**偶数长度的环 C_6**，而**奇数长度的环 C_5**（五边形）**不是**二分图（脚本用贪心二染色验证：C_6 可二染色，C_5 不可）。 – **一个重要等价刻画**（L10 会正式证明）：**一个图是二分图，当且仅当它不含奇数长度的环**。直观理由：沿着环交替染色，若要回到起点时颜色一致，环长必须是偶数。

完全图（complete graph） – **定义**：无向完全图 $K_n = (V, E)$ 满足 $|V| = n$ 且 $E = \{\{v_i, v_j\} : v_i \neq v_j,\ v_i, v_j \in V\}$——任意两个不同顶点之间都恰好有一条边。有向完全图则要求对每对 $u \neq v$ 同时有 $(u, v) \in E$ 与 $(v, u) \in E$。 – **直观解释（"它是什么意思？"）**：完全图是"关系最密集"的图：没有任何两个人是陌生人。它是"最大连通性"的极端，但代价是边数爆炸。 – **具体示例**：K_2 有 1 条边、K_3 有 3 条边（三角形）、K_4 有 6 条边、K_5 有 10 条边。一般地 $|E(K_n)| = \binom{n}{2} = \frac{n(n-1)}{2}$（证明见定理 9.2）。每个顶点的度都是 $n - 1$。K_5 有 5 个顶点 10 条边——这个数字在 L10 证明"K_5 不可平面"时会再次出现。

补图（complement） – **定义**：简单图 $G = (V, E)$ 的**补图** $\overline{G} = (V, \overline{E})$ 与原图共享顶点集，边集为 $\overline{E} = \{\{u, v\} : u \neq v,\ \{u, v\} \notin E\}$，即"原本不相邻的点对在新图中相邻"。 – **直观解释（"它是什么意思？"）**：补图把"陌生人网络"变成"熟人网络"，反之亦然。它在"顶点覆盖 / 独立集 / 团"这组概念之间搭起一对一的翻译（G 中的独立集恰好是 $\overline{G}$ 中的团）。 – **具体示例**：K_4 的补图没有边（$\overline{K_4}$ 是 4 个孤立顶点）。路 $P_4 = \{1\text{–}2, 2\text{–}3, 3\text{–}4\}$ 的补图边集为 $\{\{1,3\}, \{1,4\}, \{2,4\}\}$，度数分别是 $2, 1, 1, 2$（脚本验证）。C_5 的补图仍是 C_5（自补）。

树（tree，预告） – **定义**：一个图是**树 (tree)**，若它**连通且无环 (connected and acyclic)**。官方 Note 还给出了三个等价刻画：连通且有 $n - 1$ 条边（$n = |V|$）；连通但删去任意一条边就变得不连通；无环但添加任意一条新边就会产生环。**根树 (rooted tree)** 还指定一个特别的顶点叫**根 (root)**，最底层没有子节点的顶点叫**叶 (leaf)**，中间的叫**内部节点 (internal node)**，从根到叶的最长路径长度叫树的**深度 (depth)**。树的第 k **层 (level)** 是与根相距恰好 k 条边的顶点集合。 – **直观解释（"它是什么意思？"）**：树是"**刚好够用**"的连通图——不连通的图不能用，而比树多一条边就一定有多余的环（冗余）。现实类比：公司组织架构图、家谱、细菌分裂的世代图（根是一个细菌，每一层是一次分裂）、二叉搜索树。在通信网络设计中，树是"用最少线路把所有城市连起来"的方案（最小生成树）。 – **具体示例**：$V = \{1, 2, 3\}$、$E = \{\{1,2\}, \{2,3\}, \{1,3\}\}$（三角形）**不是**树（有环）；去掉任意一条边，例如得 $E = \{\{1,2\}, \{2,3\}\}$，这就是一棵树：连通、无环、有 $3 - 1 = 2$ 条边。官方 Note 中的 15 节点完全二叉树深度为 3，根在第 0 层，第 3 层是全部 8 个叶节点。L10 会给出树的等价刻画的完整证明（对顶点数用强归纳，并需要处理"删掉一个顶点后图分裂成多个连通分量"的情形——这正是强归纳而非弱归纳的原因）。

同构（isomorphism，一句话说明） – **定义**：两个图 $G = (V, E)$ 与 $G' = (V', E')$ **同构**，若存在一个双射 $f : V \to V'$，使得 $\{u, v\} \in E \iff \{f(u), f(v)\} \in E'$。同构的图"结构完全相同"，只是顶点被重新命名、画法不同而已。 – **直观解释（"它是什么意思？"）**：同构是"换名字不换结构"。官方 Note 说"前两个图画法不同但其实是同一个图"，说的正是同构。**注意**：平面上画图时线条的交叉只是画法，不代表结构差异。 – **具体示例**：$1\text{–}2\text{–}3$ 与 $a\text{–}b\text{–}c$ 同构（$f(1) = a, f(2) = b, f(3) = c$）。而 $1\text{–}2\text{–}3$（3 个顶点的路）与三角形 $1\text{–}2, 2\text{–}3, 3\text{–}1$ 不通过同构——前者边数 2、后者边数 3，边的数量是同构不变量。

完整证明与推导（核心）

定理 9.1（握手引理 Handshake Lemma）：对任意无向图 $G = (V, E)$（允许自环与重边时需按惯例计度，简单图情形结论相同），

$$\sum_{v \in V} \deg(v) = 2\,|E|.$$

证明策略：**双计数 (double counting)**——用两种不同的方式数同一个量，从而得到等式。这里的"同一个量"是**关联关系**的个数，即"顶点—边"的关联对 (v, e)（其中 e 关联于 v）的总数。为什么选这个策略？因为左边"按顶点分组数"、右边"按边分组数"，两种分组方式数的是同一批对象，等式自动成立。

逐步推导： 1. 定义关联对集合 $S = \{(v, e) : v \in V,\ e \in E,\ v \text{ 是 } e \text{ 的一个端点}\}$。**依据**：定义（构造一个用于双计数的对象）。 2. **按顶点数**：对每个固定的 $v \in V$，与 v 关联的边恰好有 $\deg(v)$ 条，所以 v 贡献 $\deg(v)$ 个关联对。对所有 v 求和得

$$|S| = \sum_{v \in V} \deg(v).$$

依据：度的定义（度为关联于该顶点的边的条数）。 3. **按边数**：对每条固定的边 $e = \{u, v\}$（$u \neq v$，简单图情形），它恰好有**两个**端点，所以 e 贡献 2 个关联对——(u, e) 与 (v, e)。对所有边求和得

$$|S| = \sum_{e \in E} 2 = 2\,|E|.$$

依据：边的定义（每条边恰有 2 个端点）。 4. 第 2 步与第 3 步数的是**同一个集合** S，故两边相等：$\sum_{v \in V} \deg(v) = 2|E|$。**依据**：第 2、3 步 + 等式的传递性。

【证明机制解说】：双计数的全部力量来自一个朴素想法——**同一个东西数两遍不会数出两个不同的答案**。这里的"巧思"是选对了计数对象：不是直接数度数，而是把"顶点与边的关联"作为砖块。每一块砖在"按顶点分组"时被算一次，在"按边分组"时被算一次，2 与 $\deg(v)$ 就是这样自然浮现的。若试图用归纳法逐个加边，也能证明，但会繁琐得多——这正是"选对策略"的价值。

反例（外观上的"违反者"）与自环的说明：若图中有自环 $e = \{u, u\}$，它在"按边数"时仍被算作 2 个关联对（约定自环对一个顶点的度贡献 2）。例如 $V = \{1\}$，$E = \{\{1, 1\}\}$：$\deg(1) = 2$，$\sum \deg = 2 = 2 \cdot 1 = 2|E|$ ✓。若错误地把自环只算 1 度，引理就会被"违反"——这提醒我们：**引理的正确性依赖于度的定义与计数约定的一致**。本课程默认无自环，所以不会有这个麻烦。

推论 9.1.1（奇度顶点个数为偶数）：任意无向图中，度数为奇数的顶点个数是偶数。

证明策略：直接证明 + 模 2 分析（奇偶性论证）。

逐步推导： 1. 由定理 9.1，$\sum_{v \in V} \deg(v) = 2|E|$，右边是**偶数**。**依据**：握手引理。 2. 把 V 分成 V_{odd}（奇度顶点）与 V_{even}（偶度顶点）。**依据**：分类。 3. $\sum_{v \in V} \deg(v) = \sum_{v \in V_{\text{odd}}} \deg(v) + \sum_{v \in V_{\text{even}}} \deg(v)$，其中第二个和是偶数（偶数之和为偶数）。**依据**：奇偶性。 4. 由第 1、3 步，$\sum_{v \in V_{\text{odd}}} \deg(v)$ 必为偶数（偶数减去偶数为偶数）。**依据**：整数奇偶性。 5. 一个整数之和为偶数，当且仅当其中的奇数项个数为偶数（每一对奇数相加为偶数）。故 $|V_{\text{odd}}|$ 是偶数。**依据**：第 4 步 + 奇偶性论证。

【证明机制解说】：这个推论是"**奇偶性是全局约束**"的漂亮示范：单个顶点的度可以随便是奇是偶，但全图的奇度顶点个数被锁成偶数。"存在性"式的应用极为有用：**要证明某个度序列不可能实现，只要看奇度顶点个数是否为奇**。

反例（推论的应用）：5 个人的握手次数能否恰好是 $0, 1, 2, 3, 4$？不能。理由有两个层次： – 直接理由：$0 + 1 + 2 + 3 + 4 = 10$ 是偶数，奇偶性检查**通过**了——所以这一条单独不够，必须再挖一层。 – 真正的理由：设握手次数为 0 的人是 A，握手次数为 4 的人是 B。B 与其余 4 人全都握过手，特别是 B 与 A 握过手，于是 $\deg(A) \geq 1$，与 $\deg(A) = 0$ 矛盾。（脚本穷举了 5 个顶点、10 条可能边的全部 $2^{10} = 1024$ 种图，度序列为 $(0, 1, 2, 3, 4)$ 的图**一个都没有**。）这个反例同时提醒我们：**奇偶性只是必要条件，不是充分条件**——判定度序列是否可实现需要更强的工具（如 Erdoš–Gallai 定理）。

定理 9.2（完全图的边数）：$|E(K_n)| = \dfrac{n(n-1)}{2}$，且 K_n 中每个顶点的度为 $n - 1$。

证明策略：双计数（两条路径都可以，此处用边的双计数）+ 与握手引理交叉验证。

逐步推导： 1. 在 K_n 中，每个顶点 v 与其他 $n - 1$ 个顶点都相邻，故 $\deg(v) = n - 1$。**依据**：完全图的定义。 2. 由握手引理，$\sum_v \deg(v) = 2|E|$。**依据**：定理 9.1。 3. 左边 $= \sum_{v \in V} (n - 1) = n(n - 1)$。**依据**：第 1 步 + 有 n 个顶点。 4. 因此 $2|E| = n(n-1)$，即 $|E| = \frac{n(n-1)}{2} = \binom{n}{2}$。**依据**：第 2、3 步。 5. **验证**：$n = 2, 3, 4, 5, 10$ 时分别得 $1, 3, 6, 10, 45$（脚本验算通过），与前面手数 K_3、K_4、K_5 的结果一致。**依据**：代入。

【证明机制解说】：这里用握手引理"反解"边数是图论中极常用的套路：**当每个顶点的度都容易知道时，边数可以由度和除以 2 得到**。（L10 证明超立方体有 $n2^{n-1}$ 条边时用的正是同一招：2^n 个顶点、每个度 n，故 $|E| = n2^n/2 = n2^{n-1}$。）换个角度看，$\binom{n}{2}$ 也可以用"从 n 个顶点中选 2 个组成一条边"的组合计数直接得到——两条路径的一致性本身就是定理 9.1 的一个侧面。

定理 9.3（欧拉定理 Euler's Theorem, 1736）：一个无向图 $G = (V, E)$ 存在**欧拉回路 (Eulerian tour)**——即经过每条边恰好一次并回到出发点的闭游走——**当且仅当** G 是**偶度图 (even degree graph)**（每个顶点的度都是偶数）且**连通（允许孤立顶点例外）**。

证明策略：这是一个"当且仅当"命题，两个方向必须用完全不同的策略： – **必要性（⇒）**用**直接证明 + 配对论证**：G 有欧拉回路 ⇒ 偶度 + 连通。理由：回路这一"行走过程"本身就是一本证据簿，只要把每个顶点处被走过的边两两配对即可。 – **充分性（⇐）**用**构造性算法 + 归纳法**：偶度 + 连通 ⇒ 有欧拉回路。理由：光说"存在"不够有说服力，我们要给出一个能真正跑出来的算法（Hierholzer 思路的 $\textbf{FIND TOUR}$ + $\textbf{SPLICE}$），再对边数做归纳证明它的正确性。

逐步推导（必要性，第一部分：连通性）： 1. 设 G 有欧拉回路 T，即 T 是一条经过 E 中每条边恰好一次的闭游走。**依据**：假设。 2. 每个**非孤立**顶点 v（即 $\deg(v) \geq 1$）至少关联一条边，而这条边必在 E 中，故必被 T 走过，所以 v 出现在 T 的顶点序列中。**依据**：欧拉回路经过所有边。 3. 于是任意两个非孤立顶点 u, v 都出现在同一条游走 T 上，沿着 T 从 u 走到 v 的那一段就是一条连接它们的 path（去掉可能的绕行后即是）。故 G 在非孤立顶点之间连通。**依据**：第 2 步 + 连通性定义。 4. 孤立顶点（$\deg = 0$）不关联任何边，自然不与任何顶点连通，故"允许孤立顶点例外"这一措辞是必需的。**依据**：孤立顶点定义。

逐步推导（必要性，第二部分：偶度）： 1. 固定任意顶点 v。T 作为闭游走，**每一次经过 v 都是"进来一条边、出去一条边"**（包括起点的首次离开与终点的最后一次进入，它们配对）：把游走按时间顺序写出来，每当 T 沿一条边进入 v，紧接着就必须沿另一条边离开 v。**依据**：游走的定义（相邻顶点间有边）+ 闭游走性质。 2. 把每一次这样的"进入边 + 离开边"配成一对。因为 T **每条边只走一次**，每对中的两条边互不相同；而 T **经过所有边**，所以 v 关联的每条边都被配进某一对，一不多一不少。**依据**：欧拉回路的定义。 3. 起点 s 处的配对要小心处理：首次离开 s 的那条边在它之前没有"进入边"。但闭游走必然**回到** s，于是把"首次离开 s 的边"与"最后一次进入 s 的边"配成一对（若 $|E| = 0$ 则 s 是孤立顶点，$\deg(s) = 0$ 是偶数，无需配对）。**依据**：闭游走的定义。 4. 于是 v 关联的全部边被分成若干**两两不相交的二元组**，故关联边数是偶数。在简单图中关联边数等于 $\deg(v)$，于是 $\deg(v)$ 为偶数。**依据**：第 1–3 步。 5. v 是任意的，所以 G 中每个顶点的度都是偶数，G 是偶度图。**依据**：第 4 步。 6. **（柯尼斯堡的应用）** 七桥图的度数为 $\deg(A) = 3, \deg(B) = 5, \deg(C) = 3, \deg(D) = 3$（脚本数出度为 $3, 5, 3, 3$，度和 $14 = 2 \times 7$ ✓），四个顶点全是奇度。由必要性方向，**不存在欧拉回路**，所以"走遍七座桥恰好一次并回到起点"不可能。这就回答了 1736 年的问题。**依据**：第 5 步。

逐步推导（充分性：构造性算法 + 归纳）：1. **子程序 $\textbf{FIND TOUR}(G, s)$**：从顶点 s 出发，每一步任选一条**尚未走过**的、与当前顶点关联的边，沿它走到下一个顶点；重复直到当前顶点**没有未走过的关联边**（"卡住"）为止。**依据**：算法定义（贪心游走）。 2. **断言（$\textbf{FIND TOUR}$ 一定在 s 处卡住）**：设游走在顶点 v 处卡住。对任意 $v \neq s$，游走的每一次"进入 v"都消耗一条关联边，而游走的每一步"离开 v"也消耗一条；由第 1 步的走法，游走是"进去一次、出来一次"地交替经过 v，所以游走结束时，v 处被走过的关联边数是**奇数**（最后停在 v 时只进未出）。但 G 是偶度图，$\deg(v)$ 是偶数，偶数减奇数 $=$ 奇数 > 0，故 v 处**至少还有一条未走过的边**，与"卡住"矛盾。因此 $v \neq s$ 不可能，游走只能在 s 处卡住。**依据**：偶度假设 + 奇偶性论证。 3. **$\textbf{FIND TOUR}$ 的产物**：它返回一条从 s 出发、以 s 结束的**闭游走**（即 G 的一个 tour），但**未必是欧拉回路**——因为可能还剩没走过的边。**依据**：第 2 步。 4. **拼接子程序 $\textbf{SPLICE}(T, T_1, \ldots, T_k)$**：输入若干条**边不相交**的 tour，其中 T 与每一条 T_i 都共享至少一个顶点。输出一条单一 tour T'，走遍 $T, T_1, \ldots, T_k$ 的全部边：做法是**沿 T 走，每当走到一个与某条 T_i 相交的顶点 s_i 时，就先绕道把 T_i 从 s_i 完整走一圈回到 s_i，然后继续沿 T 前进**。**依据**：算法定义。 5. **递归算法 $\textbf{EULER}(G, s)$**：先算 $T = \textbf{FIND TOUR}(G, s)$；再把 T 的边从 G 中删去，得到若干连通分量 $G_1, \ldots, G_k$；对每个 G_i 取"T 上第一个与 G_i 相交的顶点"为 s_i；递归调用 $\textbf{EULER}(G_i, s_i)$；最后输出 $\textbf{SPLICE}\big(T, \textbf{EULER}(G_1, s_1), \ldots, \textbf{EULER}(G_k, s_k)\big)$。**依据**：算法定义。 6. **递归的合法性**：删去 T 的边后，每个顶点损失的度恰好是它在 T 上被走过的关联边数，而由第 2 步的论证那是**偶数**；偶度减偶度仍是偶度。故每个 G_i 都是偶度图。又 G_i 由连通分量定义本身是连通的。所以归纳假设可以应用。此外每删去 T 至少一条边，故 G_i 的边数严格小于 G 的边数。**依据**：第 2 步 + 连通分量定义。 7. **T 与每个 G_i 确实相交**：G 连通，G_i 中的顶点 w 与 s 之间有一条 path，这条 path 必在某处离开"完全由 T 上顶点构成的部分"而进入 G_i，其跨越边必是 T 的边（因为 G_i 之外的边都被 T 吸收了），故交点存在。于是 s_i 有定义，$\textbf{SPLICE}$ 的前提满足。**依据**：连通性 + 第 5 步。 8. **归纳基础**：$m = 0$（没有边）时无 tour 可找，命题空洞成立。**依据**：基础情形的平凡性。 9. **归纳假设**：对边数 $\leq m$ 的所有偶度连通（允许孤立顶点）图，$\textbf{EULER}$ 输出欧拉回路。**依据**：强归纳假设。 10. **归纳步骤**：设 G 有 $m+1$ 条边。由第 5 步，G_i 的边数都 $\leq m$，故由归纳假设 $\textbf{EULER}(G_i, s_i)$ 输出 G_i 的欧拉回路。由第 4 步，$\textbf{SPLICE}$ 把这些 tour 与 T 拼成一条走遍"T 的边 $\cup$ 所有 G_i 的边 $= G$ 的全部边"的单一 tour，且每条边恰好走一次，起点终点都是 s。这就是 G 的欧拉回路。**依据**：第 4、5、9 步。 11. 由归纳原理，对任意边数的偶度连通图，$\textbf{EULER}(G, s)$ 都输出欧拉回路。充分性得证。**依据**：第 8–10 步。 12. 必要性（第 1–6 步与连通性部分）与充分性（第 1–11 步）合起来给出"当且仅当"。**依据**：双向。

【证明机制解说】：这个定理的两个方向展现了两种截然不同的数学风格。**必要性是"记账"**：欧拉回路是一份审计日志，凡是进入的必被离开，账目必然平衡，所以度数为偶——完全不需要构造任何东西。**充分性是"搭积木"**：先找一条小回路（$\textbf{FIND TOUR}$），再看剩下什么（偶度图的剩余部分仍偶度），然后把小回路拼进大回路（$\textbf{SPLICE}$），对规模归纳。$\textbf{FIND TOUR}$ 一定回到起点这一断言（第 2 步）是全证明的枢纽：**它把"偶度"这一全局条件翻译成"游走无法停在中途"这一局部事实**——因为停在中途要求该顶点有奇数条已走过的边，而它的总度数是偶数，于是必然还剩未走过的边可走。$\textbf{SPLICE}$ 的机制则是一个"**绕道**"：走到交叉点 s_i，先把支路 T_i 绕完回到 s_i，再接着走主干，就像旅游时在某地插入一段一日游。

图 9.1（拼接机制的 ASCII 示意）：

```
图 9.1  欧拉定理充分性的"拼接"机制（SPLICE）
============================================================
 原图 G（偶度图，每个顶点度数为偶数）：
          2
         / \
        1---3      <- 三角形 T1 = 1->2->3->1
         \ /
          4---5    <- 三角形 T2 = 1->4->5->1
         /
        1

 步骤 1: FIND TOUR(G, 1) 随便走，假设先走三角形 T1
          得到 T = 1 -> 2 -> 3 -> 1           （仍未覆盖 T2）

 步骤 2: 从 G 中删去 T 的边，剩下的图是 T2（连通分量 G1），
         T 与 G1 的交点是 1（即 s1 = 1）

 步骤 3: SPLICE(T, T1) —— 沿 T 走，走到交点上"绕道"
         1 -> 2 -> 3 -> 1       （走完 T）
                        |
                        +--> 在此绕道走 T2:  1 -> 4 -> 5 -> 1
                        |
         得到 T' = 1 -> 2 -> 3 -> 1 -> 4 -> 5 -> 1
         每条边恰好一次，起点终点都是 1  ==>  欧拉回路!

 若是另一种走法（FIND TOUR 先走 T2），结果对称：
         T'' = 1 -> 4 -> 5 -> 1 -> 2 -> 3 -> 1
         同样是一条合法欧拉回路（脚本已验证两者都合法）
============================================================
```

定理 9.4（欧拉路径 Eulerian path 的判定）：无向图 G 存在**欧拉路径**——经过每条边恰好一次、但**不要求回到起点**的游走——当且仅当 G 的奇度顶点个数恰好是 $\mathbf{0}$ 或 $\mathbf{2}$；且所有边都位于同一个连通分量内。

证明策略：把"路径"情形**归约**到"回路"情形（添加一条虚拟边），再用定理 9.3。这是数学中极其常用的"把新问题变形成已解决问题"的思路。

逐步推导：1. （$\Leftarrow$，$\mathbf{0}$ 个奇度顶点）此时 G 是偶度图，由定理 9.3 存在欧拉回路，而欧拉回路当然是欧拉路径（闭的路径也是路径）。**依据**：定理 9.3。 2. （$\Leftarrow$，恰好 2 个奇度顶点）设奇度顶点为 $u \neq v$。若 u 与 v 之间已有一条边，则不能直接添边；正确做法是把问题建立在"**添加一条新边 $\{u, v\}$（可以是重边）得到 G'**"上。**依据**：构造。 3. G' 中 u, v 的度各加 1 变成偶数，其余顶点度数不变（仍为偶数），故 G' 是偶度图。又 G' 连通（由"所有边在同一连通分量"的假设加上新边），由定理 9.3 存在欧拉回路 T'。**依据**：定理 9.3。 4. 把 T' 中的虚拟边 $\{u, v\}$ 删掉：T' 是一条闭游走，删去其中那一步就得到一条从 v 到 u（或反向）的游走 T，它经过 G' 中除虚拟边外的每条边恰好一次（G 中的每条边都被 T' 走过一次，且虚拟边不在 G 中），即 G 的欧拉路径。**依据**：第 3 步。 5. （$\Rightarrow$）反过来，设 G 有欧拉路径 T，从 a 走到 b（$a \neq b$ 时不闭，$a = b$ 时即欧拉回路）。对任意 $v \notin \{a, b\}$：T 每次进入 v 必离开 v，配对论证给出 $\deg(v)$ 为偶数。对 a：T 有一次"只出不进"（起点），其余进出配对，所以 $\deg(a)$ 为**奇**；同理 $\deg(b)$ 为奇。若 $a = b$（闭游走），配对论证给出所有度数为偶，即 0 个奇度顶点。**依**

据：定理 9.3 必要性的配对论证。 6. 故奇度顶点个数恰为 2（当 $a \neq b$）或 0（当 $a = b$），只能是这两种情形。**依据**：第 5 步。 7. 连通性要求同定理 9.3：欧拉路径经过所有边，故所有非孤立顶点都在同一个连通分量里。**依据**：定理 9.3 必要性第一部分。 8. 第 1–4 步与第 5–7 步合起来给出"当且仅当"。**依据**：双向。

【证明机制解说】：这个归约的"灵光一现"是**虚拟边**：不要求回到起点，等价于"要求回到起点但允许走一条实际上不存在的边"。奇度顶点恰好是 a 与 b——游走的两个"半截端点"，因此把 a, b 用手搭起来（虚拟边）就补成回路。这也解释了推论 9.1.1（奇度顶点个数为偶）在欧拉语境下的意义：奇度顶点必定"成对出现"，因为一条不闭的游走恰好有两个端点。

反例（条件不可省）： – **有 2 个奇度顶点：有欧拉路径，无欧拉回路。** 取"房子图" H：$V = \{1,2,3,4,5\}$，$E = \{\{1,2\},\{2,3\},\{3,4\},\{4,1\},\{2,5\},\{4,5\}\}$（四边形顶上加个尖顶，尖顶连到 2 和 4）。度数为 $\deg(1)=2, \deg(2)=3, \deg(3)=2, \deg(4)=3, \deg(5)=2$——恰有 2 个奇度顶点（2 和 4）。故**无**欧拉回路（不是偶度图），但**有**欧拉路径。一条合法的走法是

$$2 \to 3 \to 4 \to 1 \to 2 \to 5 \to 4$$

（脚本逐边校验：6 条边全部用到、每条恰好一次、起点 2 终点 4 不闭合 ✓）。另一条对称的走法是 $2 \to 5 \to 4 \to 3 \to 2 \to 1 \to 4$，也合法。 – **不连通但偶度：仍无欧拉回路。** 取两个不相交的三角形 $\{1,2,3\}$ 与 $\{4,5,6\}$，两个图都是偶度（每个顶点度 2）但整个图不连通，无论从哪出发都无法一次走完两组边。这说明定理 9.3 中"连通"这一条件**不可省**。 – **连通但奇度：无欧拉回路。** 七桥图连通、有 7 条边，但四个顶点全为奇度（$3,5,3,3$），故无欧拉回路；也**无**欧拉路径（奇度顶点 4 个，不是 0 或 2）——所以"走遍七桥恰好一次（不要求回到起点）"同样做不到。脚本用 Hierholzer 算法与穷举逻辑双重确认：柯尼斯堡图既无欧拉回路也无欧拉路径。

与经典问题的联系

问题一：柯尼斯堡七桥问题（图论的诞生） – **实际背景**：普鲁士柯尼斯堡城中有普列戈利亚河 (Pregel)，把城市分成两岸 A、D 与两座岛 B、C；七座桥连接这些陆地。市民晚饭后散步时热衷于挑战："能不能走一条路线，把七座桥每座恰好走一次，并回到出发点？" – **数学建模**：把每块陆地抽象成一个顶点，每座桥抽象成一条边，得到多重图 $V = \{A, B, C, D\}$，E 为 7 条边的多重集。 – **求解**：由定理 9.3 的必要性方向，欧拉回路存在要求所有度为偶。实际度数为 $\deg(A)=3$、$\deg(B)=5$、$\deg(C)=3$、$\deg(D)=3$，全为奇数。故**不存在**这样的路线。1736 年欧拉给出的正是这个不可能性证明，他也因此被认为是图论的创始人。 – **意义**：这是"**用不变量回答可行性问题**"的最早范例：不去尝试所有路线（$7! = 5040$ 种走法可以硬试），而是找到一个与走法无关的不变量（度的奇偶性），一击判定。这种思路在后来的算法理论中反复出现。

问题二：一笔画谜题与投递路线（中国邮递员问题） – **一笔画 (one-stroke drawing)**：给定一个图形，能否不抬笔、不重复地画完所有线条？这正是"是否存在欧拉路径"的问题，答案由定理 9.4 给出：奇度顶点数必须是 0 或 2。这是小学奥数题背后真正的数学。 – **中国邮递员问题 (Chinese Postman Problem)**：邮递员要走过他负责的每条街道至少一次并回到邮局，如何走最短？若街区的图是偶度图，答案就是欧拉回路（每条街恰好走一次，没有浪费）。若有 $2k$ 个奇度顶点，则必须重复走一些街道；最优解等价于在奇度顶点之间找一组最短的配对路径（最小权匹配），把图"补"成偶度图。这是欧拉定理在运筹学中的直接延伸。 – **扫地机器人 / 除雪车路线规划**：同一类问题的工业版本：希望每条通道都被覆盖至少一次且总路程最小。

问题三：网络与互联网中的图论语言 – **路由**：互联网可以建模成图，节点是路由器，边是链路。"从源到目标能不能送达"就是连通性问题；"最少经过几跳"就是距离问题（本讲定义）；路由协议（如 OSPF）计算的就是加权图上的最短路径。 – **最小生成树与网络设计**：要让 n 个城市都能互相通信且总造价最低，需要一棵生成树，其边数是 $n-1$——正是 K_n 的边数 $\binom{n}{2}$ 中的一小部分。L10 会给出树的四种等价刻画并证明"连通 + 无环 $\iff$ 连通 + $n-1$ 条边"。 – **社交网络分析**：顶点是人、边是"互相认识"。度分布刻画影响力，连通分量刻画社群，二分图刻画"两类主体之间的关系"（如用户—商品二部图，是推荐系统的标准模型）。 – **de Bruijn 图与序列生成**（官方 Note 的练习题，属于 L10 前的预告）：2^n 位循环序列使每个长度 n 的 0/1 串恰好作为连续子串出现一次，这样的序列可由 de Bruijn 图中的**欧拉回路**生成——因为 de Bruijn 图是有向图，定理 9.3 需修改为"每个顶点的入度 $=$ 出度"（官方 Note 明确指出了这一修改）。这是欧拉定理从无向图推广到有向图的标准做法。

问题四：作为"组合码"的图论（与 Lecture 8 的呼应） L08 指出纠错码有两大流派：基于有限域多项式的**代数码**（Reed–Solomon）与基于图论的**组合码**。图论在这里的角色是：把"码字"看成图的子集，用图的连通性、围长、度分布等结构性质来保证码的最小距离。低密度奇偶校验码 (LDPC) 与图码 (graph code) 都是这一流派的现代产物。L08 与 L09 因此是一对"同一目标、两种语言"的姊妹讲。

与其他讲次的关联

- **讲次 0（直接证明 / 集合与记号）**：本讲的图定义完全建立在集合语言上：V 是集合，E 是 V 的二元子集构成的集合，有向图的 $E \subseteq V \times V$ 用的是笛卡尔积。集合的并与、交、差、子集关系是后续所有图论表述的基础。
- **讲次 2（证明技巧 II：反证法、分情形、极端原理）**：握手引理的推论（奇度顶点个数为偶）的反例分析用了"抓极端值"（取度最大的 4 与度最小的 0）的极端原理；定理 9.3 必要性中对"起点特殊"的分情形处理，也是 L02 技巧的直接应用。
- **讲次 3（归纳法与强归纳）**：定理 9.3 充分性的 `EULER` 算法是**强归纳**的典型范例——删去一条回路后可能得到**多个**连通分量，必须分别对每一个更小的图使用归纳假设，弱归纳在这里不够用。L10 将继续用归纳证明"树 = 连通无环 = 连通且有 $n-1$ 条边"与欧拉公式 $v + f = e + 2$。
- **讲次 7、8（多项式与编码）**：L07 的系数表示/值表示对偶与 L08 的 Reed–Solomon 码是"代数码"路线；本讲的图是 L08 提到的"组合码"路线的语言。两条路线在官方 Note 的同一段话里被并列提出，本讲正是那条岔路的入口。
- **讲次 10（Graphs II）**：直接延续本讲。L10 将讨论平面图与欧拉公式 $v + f = e + 2$、树（连通无环，含 $n-1$ 条边）、超立方体（2^n 个顶点、每个度 n、$n2^{n-1}$ 条边，其边数证明正是握手法则的又一次应用）、以及五色定理与 Kuratowski 定理。本讲的"完全图 K_n"与"二分图"在 L10 立刻派上用场：K_5 与 $K_{3,3}$ 正是两个最小的非平面图。
- **讲次 11（Stable Matching）**：Gale–Shapley 算法处理的是**二分图**上的匹配问题——一边是求职者、一边是岗位，边表示"可接受"。本讲的二分图定义与度数概念（"每个求职者的偏好表长度就是他在图中的度"）是 L11 建模的直接前提。
- **讲次 12、13（可数性与可计算性）**：本讲的图是**有限**图；L12 将讨论无限集合的大小。图上的算法（如"是否存在欧拉回路"）是**多项式时间可判定**的，而 L13 将给出**不可判定**的问题（停机问题）；L10 提到的"判定图是否同构"则至今没有已知多项式算法。这三讲共同刻画出"可判定 / 难判定 / 不可判定"的谱系。
- **讲次 14、16（计数与组合证明）**：$\binom{n}{2}$ 条边、连通图的生成树计数（Cayley 公式 n^{n-2}）都是双计数与双射证明的经典素材；本讲定理 9.1 与 9.2 已经是"双计数"的最简演练。

关键要点

1. **图 = 顶点集 + 边集**。无向边是二元子集 $\{u, v\}$，有向边是有序对 (u, v)；本课程默认**简单图**（无自环、无重边），遇到七桥这类多重边情形就把重边塌缩掉（但柯尼斯堡的度数必须按 7 条桥来数）。
2. **握手引理 $\sum_{v \in V} \deg(v) = 2|E|$ 是双计数的第一课**：数"顶点—边关联对"这个集合，按顶点数得到 $\sum \deg$，按边数得到 $2|E|$。推论：**奇度顶点个数必为偶数**。
3. **欧拉定理（有回路）**：连通（孤立顶点可例外）$+$ 所有度为偶 $\iff$ 存在经过每条边恰好一次的闭游走。
4. 必要性：回路中"每次进入必离开"，把边配对，故度为偶。
5. 充分性：$\textbf{FIND TOUR}$（必回到起点）$+$ $\textbf{SPLICE}$（在交点绕道）$+$ 对边数强归纳。
6. **欧拉路径（不必回到起点）**：奇度顶点个数恰为 0 或 2。证明靠"添加一条虚拟边把两个奇度端点接上"归约到回路情形。
7. **术语要精确区分**：walk（可重复顶点）$\supsetneq$ path（顶点互不相同）；tour（首尾相同）$\supsetneq$ cycle（首尾相同且中途不重复）；连通 $\neq$ 完全图（连通只要求"能走到"，完全图要求"直接相连"）。

常见误区与注意事项

1. **把"度"与"邻居数"在多重图中混为一谈**。在简单图中二者相等，所以定义可以写成 $\deg(u) = |\{v : \{u, v\} \in E\}|$；但在多重图（如柯尼斯堡）中，度是**关联边的条数**（B 的度是 5，而 B 只有 3 个邻居 A, C, D）。若用邻居数当度，七桥问题的整个论证就错了。
2. **忘记欧拉定理里的"连通"条件**。所有顶点度数为偶**不足以**保证欧拉回路：两个不相交的三角形都是偶度图，却没有一条游走能覆盖两者的所有边。正确的陈述是"连通**且**偶度"（孤立顶点若不关联任何边可以忽略，因为它本来就在所有边之外）。
3. **把必要性和充分性搞反**。"度为偶"是欧拉回路的**充要**条件；"奇度顶点 $\leqslant 2$"是欧拉路径的**充要**条件。常见错误是把"存在欧拉路径"误当成"存在欧拉回路"，于是把房子图（2 个奇度顶点）误判为有欧拉回路。判定的标准流程是：先数奇度顶点个数——0 个 $\to$ 回路（也顺带有路径），2 个 $\to$ 只有路径，≥ 4 个 $\to$ 两者都没有（如柯尼斯堡）。
4. **把"一笔画"误解为"每条边恰好一次"以外的含义**。一笔画允许**顶点**重复经过，只禁止**边**重复。若误以为顶点也不能重复，问题就变成了"是否存在哈密顿路径"，那是完全不同的（且困难得多、L10 之后才涉及）问题。欧拉（边）与哈密顿（顶点）是图论中一对著名的"看起来一样、难度天差地别"的问题。
5. **在 $\textbf{FIND TOUR}$ 的论证里忘记"起点特殊"这一分情形**。对 $v \neq s$，游走停在 v 意味着已走过奇数条关联边（进多出少一次）；但对起点 s，游走"从 s 出发"也算作一次"只出不进"，必须把首次离开与最后一次进入配成一对才能让论证成立。漏掉这个细节是最常见的证明漏洞。
6. **混淆"环 cycle"与"回路 tour"的用词**。本讲中 cycle 指**顶点互不相同**的闭合结构（简单环）；tour 是允许顶点重复的闭游走。**欧拉回路是 tour 而不是 cycle**——它必然重复经过顶点（例如 G3 上的 $1 \to 4 \to 3 \to 2 \to 1$ 经过 4 个顶点各一次，看似像 cycle，但在"8 字形"图上 $1 \to 2 \to 3 \to 1 \to 4 \to 5 \to 1$ 把顶点 1 走了三次，这就绝不是一个 cycle）。**"顶点可以重复"正是欧拉回路能走遍所有边的代价**：如果额外要求顶点也不能重复，问题就变成了哈密顿回路（见误区 4），难度完全不同。
7. **把 K_n 的边数记成 $n(n-1)$**。那是**有向**完全图的边数（每条无向边对应两条有向边）。无向完全图的边数是 $n(n-1)/2$，也就是握手引理给的结果；每个顶点的度是 $n-1$ 而不是 n。
8. **图示中的交叉不代表不连通或错误**。在平面上画图时，两条边在纸上"交叉"只是画法问题，不代表图中有交点这个顶点——这与 L10 的"平面图"概念直接相关：K_4 可以画成有交叉的样子，但它其实是平面图（能换一种画法消除交叉）。

思考题（带答案）

Q1.（纯计算） 某小镇的街区图 G 有顶点 $V = \{a, b, c, d, e, f\}$，边集为

$$E = \{\{a, b\}, \{a, c\}, \{b, c\}, \{b, d\}, \{c, d\}, \{d, e\}, \{d, f\}, \{e, f\}\}.$$

(a) 写出每个顶点的度数，并验证握手引理。(b) 判断 G 是否有欧拉回路；若没有，是否有欧拉路径？(c) 给出 G 中一条从 a 到 e 的最短路径及其长度，并给出一个包含 d 的环。

> **答案**
>
> (a) 逐个数（脚本验证）：– $\deg(a) = 2$（连 b, c） – $\deg(b) = 3$（连 a, c, d） – $\deg(c) = 3$（连 a, b, d） – $\deg(d) = 4$（连 b, c, e, f） – $\deg(e) = 2$（连 d, f） – $\deg(f) = 2$（连 d, e）
>
> 度和 $= 2 + 3 + 3 + 4 + 2 + 2 = 16$，边数 $|E| = 8$，$2|E| = 16$ ✓，握手引理成立。
>
> (b) 奇度顶点是 b 与 c，恰好 **2 个**。故**没有**欧拉回路（不是偶度图），但**有**欧拉路径（由定理 9.4，2 个奇度顶点 + 连通）。图是连通的：$a\text{–}b\text{–}d\text{–}e$ 与 $a\text{–}c\text{–}d\text{–}f$ 覆盖全部顶点。一条合法的欧拉路径从 b 到 c：
>
> $$b \to a \to c \to b \to d \to e \to f \to d \to c$$
>
> 逐边检查（8 条边各一次）：$\{b, a\}, \{a, c\}, \{c, b\}, \{b, d\}, \{d, e\}, \{e, f\}, \{f, d\}, \{d, c\}$ — 恰好用完全部 8 条边且每条一次 ✓。起点 b、终点 c 都是奇度顶点，符合定理 9.4。
>
> (c) 从 a 到 e 的最短路径：$a \to b \to d \to e$，长度 3。检查是否更短：a 的邻居只有 b, c，都不是 e，故长度 ≥ 2；长度为 2 要求存在 $a \to x \to e$，而 e 的邻居只有 d, f，a 与它们都不相邻，故不存在；所以最短长度是 3（也可写 $a \to c \to d \to e$）。
>
> 含 d 的环：$b \to c \to d \to b$（三角形），或 $d \to e \to f \to d$（三角形）。两者都满足"顶点互不相同且首尾有边"的 cycle 定义。

Q2.（概念/证明） (a) 证明：任意无向图中，度数为奇数的顶点个数是偶数。(b) 用这一结论说明"不可能存在一个 7 个顶点的无向简单图，其中 6 个顶点的度分别是 $1, 2, 3, 4, 5, 6$，而第 7 个顶点的度是 10"。

▸ **答案**

(a) 由握手引理 $\sum_{v\in V}\deg(v)=2|E|$，右端为偶数。把和拆成奇度项与偶度项：偶度项之和为偶数，故奇度项之和必为偶数。若奇度顶点的个数为奇数，则这些奇数之和为奇数（奇数个奇数相加为奇数），矛盾。故奇度顶点个数为偶数。∎

(b) 设 7 个顶点度数分别为 $1,2,3,4,5,6,10$。其中的奇数有 $1,3,5$——共 **3 个**，是奇数。由 (a)，这在任何无向图中都不可能。∎

（更直接的独立理由：$n=7$ 个顶点的简单图中，每个顶点最多与其余 6 个顶点相连，故 $\deg\le 6$，度数 10 本身就超出上限。这两个理由互不依赖，都能各自击破该构造。）

Q3.（概念 + 反例构造） 下面三个图都被宣称"有欧拉回路"，请逐个判断真伪并说明理由；对为假的，指出是哪个条件失效，并判断它是否有欧拉路径。 (i) 单个顶点 $V=\{1\}$，$E=\varnothing$。 (ii) $V=\{1,2,3,4,5,6\}$，$E=\{\{1,2\},\{2,3\},\{3,1\},\{4,5\},\{5,6\},\{6,4\}\}$。 (iii) $V=\{1,2,3,4\}$，$E=\{\{1,2\},\{2,3\},\{1,4\},\{4,3\}\}$（即路网图 G_3）。

▸ **答案**

(i) **有（平凡地有）**。$\deg(1)=0$ 是偶数，顶点 1 是孤立顶点。按"允许孤立顶点例外"的连通性要求，这个图满足条件；"长度为 0 的空游走"就是它的欧拉回路（经过每条边恰好一次——因为没有边需要经过）。这正是定理 9.3 中"孤立顶点例外"这一措辞要处理的情形。

(ii) **没有**。度为 $\deg(1)=\deg(2)=\deg(3)=2$、$\deg(4)=\deg(5)=\deg(6)=2$，所有顶点都是偶度 ✓；但图**不连通**——它分成两个连通分量 $\{1,2,3\}$ 与 $\{4,5,6\}$，之间没有任何边。从任一顶点出发只能走完所在分量的三角形，无法一次走遍全部 6 条边。**无欧拉路径**（欧拉路径同样要求所有边在同一连通分量内）。这个反例说明定理 9.3 中"连通"条件不可省。

(iii) **有**。度为 $\deg(1)=2,\deg(2)=2,\deg(3)=2,\deg(4)=2$，全为偶度且图连通。一条具体的欧拉回路是

$$1\to 4\to 3\to 2\to 1$$

（脚本逐边校验：4 条边全部用到、每条恰好一次、闭合 ✓）。另一条对称走法是 $1\to 2\to 3\to 4\to 1$，也合法。注意：**FIND TOUR** 从 1 出发若先选边 $\{1,2\}$，就会得到第二条回路，说明欧拉回路**不唯一**——定理只断言存在性，不断言唯一性。

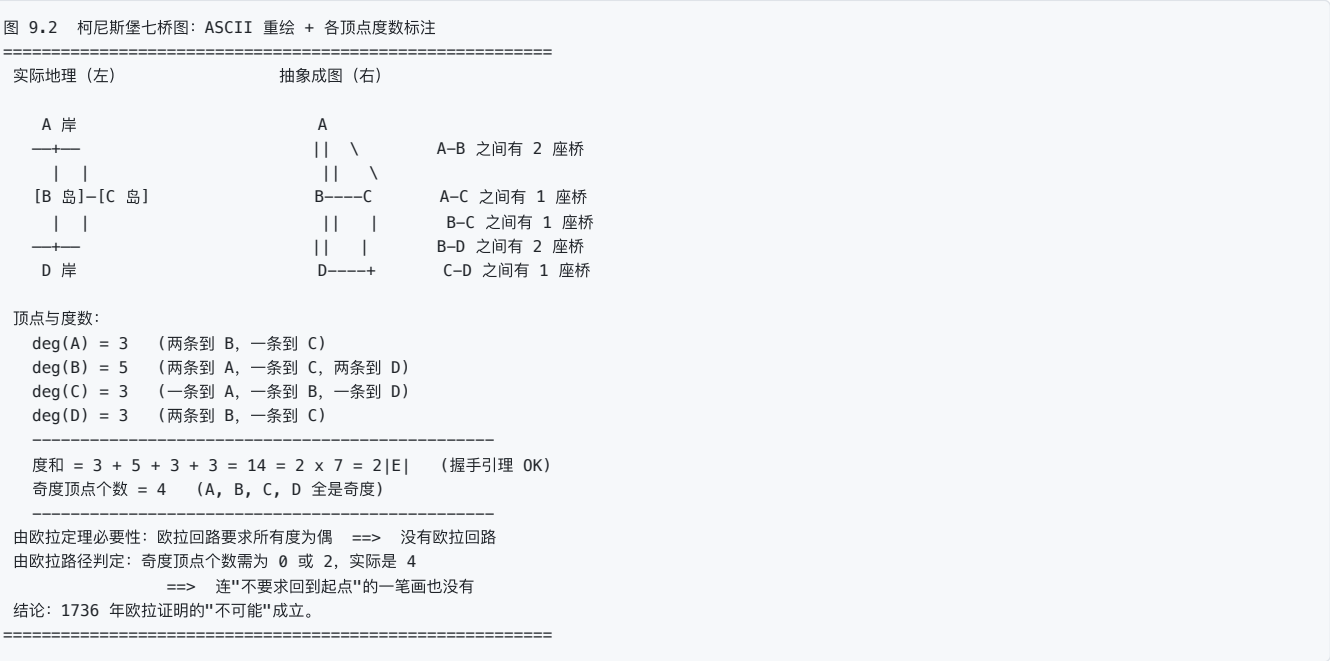

```
图 9.3  欧拉回路 / 欧拉路径 / 两者皆无：三类小图对照
============================================================
【第一类】全偶度 + 连通  ==>  有欧拉回路  (定理 9.3)
   G3 = 四边形                          "8 字形" (两个三角形共顶点)
       1 ----- 2                              2
       |       |                             / \
       |       |                            1---3
       4 ----- 3                             \ /
                                              4---5
   度数: 1:2 2:2 3:2 4:2                   度数: 1:4 2:2 3:2 4:2 5:2
   欧拉回路举例:                           欧拉回路举例:
     1->4->3->2->1                            1->2->3->1->4->5->1
   (4 条边各一次, 闭合)                    (6 条边各一次, 闭合)
   <-- 注意这是 SPLICE 的实战: 先把三角形 1-2-3-1 走成主干,
       到达交点 1 后绕道走三角形 1-4-5-1

【第二类】恰 2 个奇度顶点 + 连通  ==>  只有欧拉路径  (定理 9.4)
   房子图 H: 边集 = {1-2, 2-3, 3-4, 4-1, 2-5, 4-5}
   即四边形 1-2-3-4 加上"尖顶"5, 5 连到 2 和 4。
    (注意 2 与 4 不相邻、1 与 3 不相邻—它们是四边形的对角)

            5
           / \
          /   \
         2     4
         | \ / |
         |  X  |
         | / \ |
         1     3
   真正的边: 1-2, 2-3, 3-4, 4-1 (四边形), 2-5, 4-5 (尖顶)
   度数: 1:2 2:3 3:2 4:3 5:2   <-- 奇度顶点是 2 和 4
   欧拉路径举例: 2->3->4->1->2->5->4     (6 条边各一次, 不闭合)
   没有欧拉回路 (2 个奇度顶点)!

【第三类】>= 4 个奇度顶点  ==>  两者皆无
   柯尼斯堡七桥图 (见 图 9.2): 4 个奇度顶点
============================================================
```

```
图 9.4  FIND TOUR 为什么一定回到起点 (偶度图, 起点 s=1)
============================================================
  步骤追迹 (三角形 1-2-3-1, 每个顶点度都是 2)

  时刻    当前顶点    已走过的关联边数          能否卡住?
  ------------------------------------------------------------
   t=0      1        1 (只出不进: 边1-2)       不能 (还有边 1-3 没走)
   t=1      2        2 (进 1-2, 出 2-3)        不能
   t=2      3        2 (进 2-3, 出 3-1)        不能
   t=3      1        2 (进 3-1, 回到起点)      无未走边 -> 停在 s=1 ✓

  对 v != s 的一般论证:
     游走每"进入 v"就消耗 1 条边, 每"离开 v"又消耗 1 条;
     若停在 v != s, 则进入次数 = 离开次数 + 1,
     故已走过的关联边数 = 2k+1 (奇数),
     而 deg(v) 是偶数 => 剩余未走的边数 = 偶数 - 奇数 = 奇数 > 0
     => 不可能卡住 => 只能停在起点 s。
  这就是"偶度"这一全局条件如何变成"回得来"这一局部事实。
============================================================
```

附加算例（度数与握手引理的三次演练） 1. K_5：$n=5$ 个顶点，每个度 $5-1=4$（偶），度和 $=5\times4=20$，故 $|E|=20/2=10=\binom{5}{2}$ ✓（脚本验证）。注意 K_5 是偶度图（$n=5$ 为奇数时 K_n 的度 $n-1$ 为偶），而且显然连通，所以 K_5 **有欧拉回路**——事实上 K_5 的 10 条边可以一笔画完。这也说明"有欧拉回路"与"是平面图"是两件毫不相干的事（K_5 在 L10 中将被证明**不可平面**）。 2. K_4：$n=4$，每个度 3（奇），4 个奇度顶点，度和 $=4\times3=12$，$|E|=6$ ✓。奇度顶点 4 个 ≥4，故 K_4 既无欧拉回路也无欧拉路径（脚本用 Hierholzer 逻辑确认）。 3. $K_{3,3}$：二分图，$|V|=6$、$|E|=9$，每个顶点度都是 3（奇），度和 $=6\times3=18=2\times9$ ✓。6 个奇度顶点，无欧拉路径。 4. C_6（六边形环）：$|V|=6$、$|E|=6$，每个度 2，度和 $=12=2\times6$ ✓，无奇度顶点，有欧拉回路（就是沿着环走一圈）。而 C_5（五边形）：每个度 2，$|V|=5$、$|E|=5$，度和 $10=2\times5$ ✓，也有欧拉回路。注意 C_6 是二分图而 C_5 不是（脚本用贪心二染色验证），但**两者都有欧拉回路**——再次说明"二分"与"欧拉"是彼此独立的性质。

附加算例（反例：奇偶性检查通过、但图仍不存在） Q2 的反例提醒我们奇偶性只是必要条件。更经典的例子是度序列 $(3,3,3,1)$（4 个顶点）：奇度顶点有 4 个（偶数，奇偶性检查通过），$3+3+3+1=10$ 是偶数，看似可行。但最大度是 3，说明某个顶点与所有其他 3 个顶点都相连——于是其余 3 个顶点各自至少有 1 度来自它，其中度数为 1 的那个顶点度数记为 1 恰好用掉，而另外两个度数为 3 的顶点除了连到最大度顶点之外，还各需 2 度，它们之间最多只有 1 条边（简单图），共可获得 1 度，达不到 2 度——矛盾。故该度序列不可实现（脚本穷举 4 个顶点、6 条可能边的全部 $2^6=64$ 种图，实现数为 0）。**结论**：判定度序列可实现性需要 Erdoš–Gallai 或 Havel–Hakimi 之类的算法，握手引理提供的只是第一个筛子。

附加算例（同构不变量：一个小实验） 上面提到"同构的图必有相同的边数与度序列"。反过来不成立：取 $V=\{1,2,3,4,5,6\}$，

$$G_a:\ \{1\text{–}2,\ 2\text{–}3,\ 3\text{–}1,\ 3\text{–}4,\ 4\text{–}5,\ 5\text{–}6,\ 6\text{–}4\}\quad(\text{两个三角形用边 } 3\text{–}4 \text{ 相连}),$$

$$G_b:\{1-2,\ 2-3,\ 3-4,\ 4-1,\ 1-5,\ 5-6,\ 6-2\}\quad(\text{四边形 }1-2-3-4\text{ 加路径 }1-5-6-2).$$

两者都有 6 个顶点、7 条边，度和都是 14 ✓，但**环结构完全不同**：脚本枚举出 G_a 只有长度 3 的环（两个三角形，三角形之间那条边 $3-4$ 是**桥 (bridge)**——删掉它图就分裂成两块），而 G_b 没有任何三角形，只有两个长度 4 的环与一个长度 6 的环。由于"存在长度为 3 的环"在同构下必须保持，G_a 与 G_b **不同构**。这说明**边数与度序列不是完整的同构不变量**，判断同构需要更精细的工具（这也引出了"图同构问题"这一著名的算法难题，与 L13 的可计算性讨论呼应）。

附加算例（欧拉定理在四类小图上的判定汇总）

图	$\lvert V\rvert$	$\lvert E\rvert$	度序列	奇度个数	连通?	欧拉回路	欧拉路径
K_3（三角形）	3	3	$(2,2,2)$	0	是	有	有
K_4	4	6	$(3,3,3,3)$	4	是	无	无
K_5	5	10	$(4,4,4,4,4)$	0	是	有	有
$K_{3,3}$	6	9	$(3,3,3,3,3,3)$	6	是	无	无
C_5（五边形）	5	5	$(2,2,2,2,2)$	0	是	有	有
C_6（六边形）	6	6	$(2,\dots,2)$	0	是	有	有
路网图 G_3	4	4	$(2,2,2,2)$	0	是	有	有
8 字形	5	6	$(4,2,2,2,2)$	0	是	有	有
房子图 H	5	6	$(2,3,2,3,2)$	2	是	无	有
两个分离三角形	6	6	$(2,\dots,2)$	0	否	无	无
柯尼斯堡七桥	4	7	$(3,5,3,3)$	4	是	无	无
单顶点无边	1	0	(0)	0	是（空）	有（平凡）	有

（表中所有"$\lvert E\rvert$、度和、奇度个数、是否有回路/路径"均由脚本逐项验算：每一行的度和都等于 $2\lvert E\rvert$ ✓，回路/路径判定与欧拉定理和定理 9.4 完全一致。注意"两个分离三角形"这一行是**度全偶但不连通**的关键反例；"柯尼斯堡"这一行是**连通但 4 个奇度**的关键反例。）

> **附加算例（柯尼斯堡的"放松版"：如果拆掉一座桥会怎样？） 设从柯尼斯堡图中删去 A 到 B 之间的一座桥。则度变为 $\deg(A)=2$、$\deg(B)=4$、$\deg(C)=3$、$\deg(D)=3$，度和 $=12=2\times 6$ ✓（现在有 6 条边）。奇度顶点是 C 与 D，恰好 2 个，故按定理 9.4，此时存在欧拉路径（从 C 到 D 或反向）但仍无欧拉回路。若再拆掉 C 到 D 的那座桥，则度数变为 $(2,4,2,2)$，全偶且连通，于是存在欧拉回路了——七桥问题会变成"可以办到"。这组小实验直观展示了欧拉定理的判定边界：问题的答案完全由一个不变量（度的奇偶性）决定，与具体的桥长、地形、走法都无关。**

Lecture 10: Graphs II（图论进阶）

概述

上一讲把「图」抽象成了对象与关系的数学模型，并用度数论证解决了柯尼斯堡七桥问题（Eulerian tour）。本讲要回答一个更"几何"的问题：**一个图画在纸上，最少需要多少"交点"？** 这就是平面性（planarity）问题。核心工具是欧拉公式 $V-E+F=2$，由它推出的两条边数上界 $E\le 3V-6$ 与 $E\le 2V-4$ 将一举证明 K_5 与 $K_{3,3}$ 不能无交叉地画在平面上。

本讲的第二个主题是「图上的归纳法（Graph Induction）」——这是 Fall 2026 日程中与 Stable Matching 并列的独立主题（Quiz 5 会考）。它的困难之处在于：**删掉一个顶点后图可能不再连通**，于是归纳假设没法直接用在整体上，必须改用强归纳（strong induction）或在每个连通分量上分别归纳。这一节我们把「树的边数是 $V-1$」这个命题完整证穿，作为图归纳的范式。

第三个主题是三类重要图：完全图（complete graph）K_n、树（tree）、超立方体（hypercube）Q_n。它们分别代表"极大连通 / 极小连通 / 兼顾鲁棒与稀疏"三种设计哲学，也是后续计数、概率、算法课程里反复出现的对象。

核心概念的直观解释

平面图（Planar Graph）

- **定义**：若图 $G=(V,E)$ 能够画在平面上，使得任意两条边只在**公共端点**处相交（除了端点之外没有任何交叉点），则称 G 是平面图。这样的画法称为 G 的一个平面嵌入（planar embedding）。
- **直观解释（"它是什么意思？"）**：把顶点想成图钉，边想成绷紧的橡皮筋。平面图就是"你能把图钉钉在木板上，用橡皮筋按边连接，且橡皮筋彼此不相碰"的图。关键在于：**平面性是图自身的性质，不是某一张画法的性质。** 一张画得有交叉的图完全可能是平面图——只要存在**某种**画法没有交叉就行。类比：一件衣服"能不能熨平"取决于布料本身，而不取决于你随手揉成一团的样子。
- **具体示例**：K_4（4 个顶点的完全图）如果画成"正方形 + 两条对角线"，交叉 1 次；但把第 4 个顶点放到三角形内部，从它连三条边到三个顶点，就完全没有交叉。所以 K_4 是平面图（而且 $E=6=3\cdot 4-6$，恰好取到上界）。反之，K_5 无论怎么画都必然有交叉——这是本讲要证的第一个硬结论。

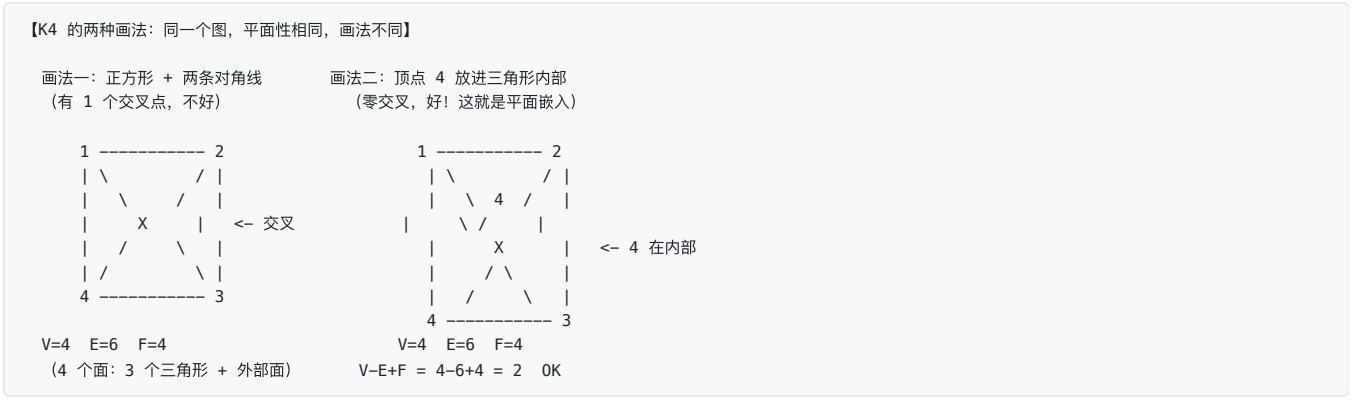

面（Face）与外部面（Outer Face）

- **定义**：给定平面图的一个无交叉画法，平面被这些边分割成的连通区域称为**面**；其中唯一无界的那个面称为**外部面（outer face）**，其余为内部面。面数记作 F。一个面的**边数**（sides）s_i 是沿该面边界顺时针走一圈经过的边数；若一条边两侧是同一个面（这样的边称为**桥 (bridge)**），它会被重复计数。
- **直观解释**：面就是"地图上的国家"。外部面是"包围整个地图的海洋"。一个国家如果只有一座桥与外面相连，那么这座桥在这个国家的边境上要走**两次**（进去再出来），所以 s_i 是"走一圈的步数"而不是"不同边的条数"。
- **具体示例**：三角形 K_3 的平面画法把平面分成 2 块：三角形内部（1 个面，3 条边）和外部（1 个面，3 条边），所以 $F=2$，两个面的 s_i 都是 3，总和 $6=2E=2\cdot 3$。而一棵 4 个顶点的星形树（一个中心连 3 个叶子）完全不分割平面，只有 1 个外部面，它走一圈要经过每条边两次：$s_1=2E=6$，$F=1$。

欧拉公式（Euler's Formula）

- **定义**：对任意**连通**平面图，设顶点数 V、边数 E、面数 F（含外部面），则

$$V-E+F=2.$$

- **直观解释（"它是什么意思？"）**：这是一个"会计恒等式"。每加一条边，要么多消耗一个顶点（V 与 E 同增，差不变），要么把某个面一分为二（F 与 E 同增，差不变）。所以 $V-E+F$ 在"建图"过程中始终不变，而空图（$V=1,E=0,F=1$）时为 2。历史上古希腊人知道它对多面体成立却证不出来——因为他们试图对多面体做归纳，但"多面体减去一个顶点"不再是多面体。欧拉的洞察是：**必须把定理推广到平面图这个更大的类，归纳法才能施展。**
- **具体示例**：立方体（Q_3）的平面画法：$V=8$，$E=12$，$F=6$（6 个正方形面），$8-12+6=2$ ✓。正八面体：$V=6,E=12,F=8$，$6-12+8=2$ ✓（八面体与立方体互为对偶，V 与 F 恰好互换）。

细分（Subdivision）与库拉托夫斯基定理（Kuratowski's Theorem）

- **定义**：把图 G 的某条边 $e=\{u,v\}$ 替换成一条经过新顶点 w 的长度为 2 的路径 $\{u,w\},\{w,v\}$，称为对 e 做一次**细分**。反复细分得到的图叫 G 的一个**细分图**。
- **直观解释**：细分就是"在橡皮筋中间多钉一颗图钉、把橡皮筋折一下"。它不改变图能否被画平的结论（多一个拐弯不会制造或消除本质的交叉），因此"是否含有 K_5 或 $K_{3,3}$ 的细分"就成了非平面性的判据。
- **具体示例**：把 K_5 的一条边细分一次，得到 $V=6,E=11$ 的图。它满足 $E\le 3V-6$（$11\le 12$），看起来"通过了平面性检测"，但它依然是**非平面**的——因为它含有 K_5 的细分。

树（Tree）

- **定义**：连通且无环（acyclic，不含任何 cycle）的无向图称为树。
- **直观解释（"它是什么意思？"）**：树是"最小连通"的图——刚好够把所有顶点串起来，一条多余的边都没有。它是通信网络里最省线的拓扑：路由表最简单（任意两点间只有唯一一条路径，不会绕圈），代价是**毫无冗余**——断一条边就断成两半。类比：树像一棵没有环的分叉家族树，也像"只能用最少的桥把若干岛屿全部连通"的方案。
- **具体示例**：$V=4$ 的树必有 $E=3$ 条边。星形树 $K_{1,3}$（中心连 3 个叶子）、路径 P_4（一条链）、以及"Y 形"都是树；而 K_4 不是树（有环），C_4（4 环）不是树（有环），"两个不相连的点"不是树（不连通）。

超立方体（Hypercube）Q_n

- **定义**：n 维超立方体 Q_n 的顶点集为 $V=\{0,1\}^n$（所有 n 位二进制串）；两个顶点 x,y **相邻当且仅当它们恰好有一个坐标不同**（即汉明距离 (Hamming distance) 为 1）。
- **直观解释（"它是什么意思？"）**：把每个 n 位串看成一个网络节点的"地址"，只有一位不同（比如 00110 与 00111）的节点之间才有直连线路。这样每个节点只需 n 条线路（度数低、布线成本小），但任意两个节点之间的距离最多 n（走 n 步逐位翻转即可到达），所以**又很"扁"又很"通"**。这正是 1980 年代 Thinking Machines 公司 Connection Machine 采用 20 维超立方体连接百万处理器的原因：完全图要 10^{12} 根线，超立方体只要约 $2^{20}\cdot 20/2\approx 10^7$ 根。
- **具体示例**：Q_1 就是一条边（$0-1$）；Q_2 是一个正方形（$00,01,11,10$）；Q_3 是普通立方体的骨架图，$V=8$，每个顶点度数 3，$E=12$。

图上的归纳法（Graph Induction）

- **定义/范式**：对图的某个参数（通常是顶点数 n 或边数 m）做归纳：先证基础情形，再取 $n+1$ 个顶点的图 G，**删掉一个顶点 v** 得到 G'，对 G' 用归纳假设，最后把 v 加回去、分析它带来多少边/面。

- **直观解释**：图归纳的危险在于**删点会破坏连通性**。G' 可能裂成 t 个连通分量 $G'_1, \dots, G'_t$，这时归纳假设对 G' 整体无效（它不连通），必须**分别**对每个分量用——而且分量顶点数都严格小于 n，所以要用**强归纳**（假设对所有 $1 \le n \le k$ 成立），而不是弱归纳。
- **具体示例**：G 是一条路径 $1-2-3-4$。删掉中间的顶点 2，G' 裂成 $\{1\}$ 和 $\{3,4\}$ 两个分量；删掉端点 4，G' 仍是连通的路径 $1-2-3$。前者必须强归纳，后者弱归纳即可。这个例子说明"删点位置"决定了证明难度——归纳证明里必须把两种情形都覆盖。

完整证明与推导（核心）

定理 10.1（欧拉公式，Euler's Formula）：对任何连通平面图 $G=(V,E)$，在其任意无交叉画法下都有

$$V - E + F = 2,$$

其中 F 为面数（含外部面）。

证明策略：对**边数 e** 做（强）归纳。选边数而不是顶点数，是因为"加一条边"对 (V,E,F) 的影响有两种清晰形态：要么新增一个顶点（V 和 E 同时 $+1$），要么把某个面劈成两个（F 和 E 同时 $+1$）。两种情况下 $V-E+F$ 都保持不变。这就是官方 Note 采用的路径：**先处理树的情形（$F=1, E=V-1$），再对非树图删掉圈上的一条边，用归纳假设回推。**

逐步推导：

1. **基础情形 $E=0$**：此时图只有一个孤立顶点 $V=1$；平面没有被分割，只有 1 个面 $F=1$。于是 $V-E+F=1-0+1=2$ ✓。（注：$E=0$ 的连通图只能是单点，否则不连通。这个问题还能更宽松地处理：$E=1$ 时 $V=2, F=1$，$2-1+1=2$ ✓，也直接可验。）
2. **归纳假设**：设对所有满足 $E' \le m$ 的连通平面图，$V'-E'+F'=2$ 成立。
3. **归纳步骤**：取连通平面图 G 有 $E=m+1$ 条边。分两种情形。

情形 A：G 是树。 树的定义就是连通无环。 – 先证"树不分割平面，故 $F=1$"：设树有一个**环**，则平面被分成至少 2 个面；反之，若 $F \ge 2$，则平面被边分割出至少一个闭合的"围墙"，围墙本身就是环。更直接地看：树中每条边都是桥 (bridge)，桥两侧是同一个面，所以整棵树只贡献 1 个面。（用 10.2 的引理也可以严格推出：树叶幂 $\sum s_i = 2E = 2(V-1)$，若 $F \ge 2$ 则 $\sum s_i \ge 3F$……这一步绕远了，我们用"树无环 $\iff F=1$"这个更朴素的事实即可。） – 再证"树有 $E=V-1$"：这是**定理 10.9**，将在本小节后面用强归纳完整证明。 – 代入：$V-E+F = V-(V-1)+1 = 2$ ✓。

情形 B：G 不是树。 那么 G 含有一个环 C。 – 取环 C 上的任意一条边 e，从 G 中删除它，得到 $G^- = G-e$。 – **G^- 仍连通**：因为 e 属于环 C，删掉后 e 的两个端点仍可通过环 C 的其余部分连通，其余顶点之间的路径最多绕一下环，依然存在。 – **G^- 的边数为 m**，故归纳假设适用于它：$V(G^-)-E(G^-)+F(G^-)=2$，即 $V-(E-1)+F(G^-)=2$。 – **$F(G^-)=F-1$**：这是关键的一步。边 e 是环 C 的一部分，e 的两侧是两个**不同**的面（沿 e 一侧走环 C 的一部分、另一侧走 C 的其余部分，两条都不含 e，故它们在 G^- 中都是通路，把两侧分开）。删除 e 后，这两个面合并成一个面，面数恰好减 1。（与之对比：若 e 是桥，两侧是同一个面，删掉它面数不变——这正是情形 A 的机制。） – 代入：$V-(E-1)+(F-1) = V-E+F = 2$。由归纳假设左边等于 2，故 $V-E+F=2$ ✓。

1. **结论**：两种情形都成立，由强归纳，定理对一切连通平面图成立。■

【证明机制解说】：整个证明的"灵魂"是**找到不变量并证明它在两种局部操作下不变**。$V-E+F$ 是拓扑学中**欧拉示性数**的雏形：删掉环上的一条边，"一条边 + 一个面"同时消失，E 与 F 各减 1，和不变；删掉桥，"一条边"消失而面不变，这正是树的特征。更深刻的一层是**为什么必须推广到平面图**：多面体的面是"多边形"，删掉一条边后可能不再是多面体，归纳法无以为继；而平面图对删除封闭，可以自由地做"删边"操作。这就是笔记里说的"定理太弱导致归纳失败"的经典案例。

反例（条件不可省）：欧拉公式**只对连通图成立**。看两个孤立的顶点：$V=2, E=0, F=1$，则 $V-E+F=3 \ne 2$。一般地，若连通分量数为 C，则正确的公式是

$$V - E + F = 1 + C.$$

（验证：两个孤立点 $C=2$：$2-0+1=3=1+2$ ✓；一个三角形加上一个孤立点 $V=4, E=3, F=2, C=2$：$4-3+2=3=1+2$ ✓。）这正是官方 Note 末尾追问的"What happens when the graph is not connected?"的答案。

引理 10.2（面的边数双计数）：对任何平面图（不必连通），设各面的边数为 $s_1, \dots, s_F$，则

$$\sum_{i=1}^{F} s_i = 2E.$$

证明策略：双计数 (double counting)。分别从"面"和"边"两个方向数同一个量：所有面包围边的"出现次数"总和。

逐步推导：

1. 从**面**这边数：面 i 沿边界走一圈经过 s_i 条边，所以总和为 $\sum_{i=1}^{F} s_i$。
2. 从**边**这边数：任取一条边 e，它把平面分成左右两侧（这两侧各自属于某个面）。如果 e 不是桥，两侧是两个不同的面，e 在左边那个面的绕行中被数一次、在右边那个面的绕行中再被数一次，共贡献 2；如果 e 是桥，两侧是同一个面，绕行这个面时 e 会被走两次（进去、出来），同样贡献 2。
3. 所以每条边在总和里恰好贡献 2，总计 $2E$。两个计数结果相等，即 $\sum_{i=1}^{F} s_i = 2E$。■

【证明机制解说】：双计数是 CS70 最简单也最万能的技巧之一（讲次 16 会用它对组合恒等式做组合证明）。这里的关键观察是"桥也被数两次"——如果把桥误当成只数一次，就会错误地得到 $\sum s_i = 2E - (\text{桥数})$，后面的所有不等式都会崩掉。

定理 10.3（平面图的边数上界 I）：设 G 是**简单**（无平行边、无自环）连通平面图，且 $V \ge 3$。则

$$E \le 3V - 6.$$

证明策略：利用"每个面至少由 3 条边围成"，把 $\sum s_i = 2E$ 变成关于 F 的下界，再代入欧拉公式消去 F，得到只含 E 与 V 的不等式。

逐步推导：

1. **每个面至少 3 条边**。因为 G 是简单图，不存在"两条边围成一个面"的情形（那需要两个顶点之间有多条平行边，或者自环）；也不存在"一条边围成一个面"（自环）。在连通且 $E \geq 2$（从而 $V \geq 3$）的情况下，每个面的边界至少需要一个长度 ≥ 3 的闭环，故

$$s_i \geq 3 \quad \text{对一切 } i = 1, \ldots, F.$$

1. 由引理 10.2 与上式：

$$2E = \sum_{i=1}^{F} s_i \geq \sum_{i=1}^{F} 3 = 3F \quad \Longrightarrow \quad F \leq \frac{2E}{3}.$$

1. 由欧拉公式 $F = 2 - V + E$。代入上一步：

$$2 - V + E \leq \frac{2E}{3} \quad \Longrightarrow \quad E - \frac{2E}{3} \leq V - 2 \quad \Longrightarrow \quad \frac{E}{3} \leq V - 2 \quad \Longrightarrow \quad E \leq 3V - 6. \qquad \blacksquare$$

【证明机制解说】：这个证明的"灵光一现"是**不等式方向的匹配**：我们要 E 的**上界**，所以需要 F 的**上界**；而 $2E = \sum s_i \geq 3F$ 给出的正是 $F \leq 2E/3$。链条是：简单图 $\Rightarrow$ 面足够"厚"（$s_i \geq 3$）$\Rightarrow$ 面数被边数压住 $\Rightarrow$ 边数被顶点数压住。这也解释了为什么平面图是**稀疏**的：1000 个顶点的连通图最多可以有约 5×10^5 条边，但平面图被限制在 $999 \sim 2994$ 条之间（$V - 1 \leq E \leq 3V - 6$）。

定理 10.4（K_5 非平面）：5 个顶点的完全图 K_5 不是平面图。

证明策略：反证法 + 定理 10.3 的定量上界。假设 K_5 是平面图，则在它身上必须满足 $E \leq 3V - 6$；但把具体数字代进去会得到一个假的不等式。

逐步推导：

1. K_5 有 $V = 5$ 个顶点；每对顶点之间都有边，故 $E = \binom{5}{2} = 10$。
2. 假设 K_5 是平面图。K_5 是简单图且 $V = 5 \geq 3$，故定理 10.3 适用，必须有 $E \leq 3V - 6 = 3 \cdot 5 - 6 = 9$。
3. 但 $E = 10 > 9$，矛盾。
4. 因此 K_5 不是平面图。$\blacksquare$

另一个更"物理"的写法（直接数面）：假设 K_5 画平了，由欧拉公式 $F = E - V + 2 = 10 - 5 + 2 = 7$。每个面至少 3 条边，故 $\sum s_i \geq 3 \cdot 7 = 21$；但 $\sum s_i = 2E = 20$。$21 > 20$，矛盾。两种叙述本质相同，后者更直观地暴露"面太多、边不够分"。

```
【反证法的两条路线，用 K5 走一遍】

 K5: V=5, E=C(5,2)=10, 每个顶点度数 = 4

 +-------------------------------------------------------------+
 | 路线甲（边数上界）:                                          |
 |   假设平面 => 必须 E <= 3V-6                                  |
 |   3*5-6 = 9  而 E = 10                                        |
 |   10 <= 9 ?  FALSE                                            |
 |   => 矛盾，K5 非平面                                          |
 +-------------------------------------------------------------+
 | 路线乙（直接数面）:                                          |
 |   假设平面 => F = E-V+2 = 10-5+2 = 7                          |
 |   每个面 >= 3 条边 => sum(s_i) >= 3*7 = 21                    |
 |   但 sum(s_i) = 2E = 20                                       |
 |   21 <= 20 ?  FALSE                                           |
 |   => 矛盾，K5 非平面                                          |
 +-------------------------------------------------------------+
 | 路线丙（"5 个邻居"的几何论证，教材外的等价说法）:            |
 |   任取顶点 v，它在平面上有 4 个邻居 a,b,c,d。                 |
 |   画一个以 v 为心的"星"：这 4 个邻居绕 v 的圆周排列。         |
 |   a 与 c 之间的边、b 与 d 之间的边，必有一条被"逼"到          |
 |   圆环的另一侧，从而与另一条相交 —— 除非 v 在外部面边界上。  |
 |   但 K5 里每个顶点地位相同，不可能所有顶点都在外部面边界上。 |
 +-------------------------------------------------------------+

 K3,3 的对应版本（必须换用 2V-4 型上界）:
   V=6, E=3*3=9, 二分图 => 无三角形 => 每个面 >= 4 条边
   假设平面 => F = 9-6+2 = 5
   sum(s_i) >= 4*5 = 20  但 sum(s_i) = 2E = 18
   20 <= 18 ?  FALSE   => 矛盾，K3,3 非平面
   即 E=9 > 2V-4 = 8

 K3,3 的 ASCII 画法（三座房子 H1,H2,H3 / 三口井 W1,W2,W3）:
     H1        H2        H3
      \  \  /  |  \  /  /
       \  \/   |   \/  /
        \ /\   |   /\ /
         X  \  |  /  X      <- 9 条边全部跨组，画在平面上必有交叉
        / \  \ | /  / \
       /   \  \|/  /   \
     W1        W2        W3
   度数列：H1,H2,H3 各为 3；W1,W2,W3 各为 3。
   sum(deg) = 6*3 = 18 = 2E  => E = 9  OK（握手引理自检通过）
```

定理 10.5（平面图的边数上界 II：二分图情形）：设 G 是**简单连通二分平面图**，且 $V \geq 3$，则

$$E \leq 2V - 4.$$

证明策略：与定理 10.3 同样的双计数路线，但把"每个面至少 3 条边"加强为"**每个面至少 4 条边**"。这一步来自二分图的结构性质：**二分图不含奇数长度的环**。

逐步推导：

1. **二分图无奇环**。设 G 的二部划分为 $V = L \cup R$，所有边都在 L 与 R 之间。沿任意一个环走一圈，每经过一条边就从一个部分换到另一个部分，所以走 k 步回到起点要求 k 是偶数。故所有环长度为偶数。
2. **每个面至少 4 条边**。面 i 的边界是一个闭环（长度为 s_i）。若 $s_i = 3$，就存在一个长度为 3 的环——即三角形，与二分图无奇环矛盾。若 $s_i \leq 2$，如前所述需要平行边或自环，简单图不允许。因此

$$s_i \geq 4 \quad \text{对一切 } i.$$

1. 由引理 10.2：

$$2E = \sum_{i=1}^{F} s_i \geq 4F \quad \Longrightarrow \quad F \leq \frac{E}{2}.$$

1. 代入欧拉公式 $F = 2 - V + E$：

$$2 - V + E \leq \frac{E}{2} \quad \Longrightarrow \quad \frac{E}{2} \leq V - 2 \quad \Longrightarrow \quad E \leq 2V - 4. \qquad \blacksquare$$

【证明机制解说】：与定理 10.3 相比，这里只是把常数 3 换成 4，但效果是上界从斜率 3 降到斜率 2，**收紧了整整一个常数倍**。这展示了平面图理论的一个方法论：**图的结构限制（二分性、无三角性、最小环长 girth）越强，边数上界越紧**。一般地，若平面图的最小环长为 g，则 $E \leq \frac{g}{g-2}(V-2)$。

定理 10.6（$K_{3,3}$ 非平面）：完全二分图 $K_{3,3}$ 不是平面图。

证明策略：$K_{3,3}$ 的 $V = 6, E = 9$，代入 -6 型上界会发现它**通过了**检测（$9 \leq 3 \cdot 6 - 6 = 12$）。所以必须换用二分图的 $2V - 4$ 上界。

逐步推导：

1. $K_{3,3}$ 的顶点分为两组各有 3 个（题面里的"三座房子、三口井"），组间所有 $3 \times 3 = 9$ 条边都存在，组内无边。故 $V = 6$，$E = 9$。
2. $K_{3,3}$ 显然是二分图（取两个组作为二部划分即可），且是简单图，$V = 6 \geq 3$。
3. 假设 $K_{3,3}$ 是平面图，则由定理 10.5 必须有 $E \leq 2V - 4 = 2 \cdot 6 - 4 = 8$。
4. 但 $E = 9 > 8$，矛盾。
5. 因此 $K_{3,3}$ 不是平面图。$\blacksquare$

为什么 $K_{3,3}$ 躲过了第一个检测？ 因为"三座房子三口井"的图里**没有三角形**——任何三角形都意味着两座房子之间有边，或两口井之间有边，这在 $K_{3,3}$ 中都不存在。没有三角形 $\Rightarrow$ 每个面至少 4 条边 $\Rightarrow$ 可以用更强的上界。这就是官方 Note 说的 "we must think a little harder"。

定理 10.7（库拉托夫斯基定理，Kuratowski's Theorem，1930）：一个图是平面图，**当且仅当**它不含 K_5 的细分，也不含 $K_{3,3}$ 的细分。

陈述与直觉说明（本讲只要求陈述，不要求完整证明）：

- **"含"的精确含义**：图 G 中存在 5 个（或 6 个）顶点，它们之间由**互不相交**（除端点外没有公共顶点）的路径相连，且连接方式与 K_5（或 $K_{3,3}$）一致。这些路径可以是单条边，也可以是长链。换句话说，把 K_5 或 $K_{3,3}$ 的每条边"拉长"成一条路径后，得到的图作为子图出现在 G 里。
- **一个方向显然**：如果 G 含有 K_5 或 $K_{3,3}$ 的细分，则 G 非平面。因为细分不改变平面性（拉长一条边只是多插几个顶点，既不制造也不能消除本质交叉），而 K_5、$K_{3,3}$ 本身非平面（定理 10.4、10.6）。把非平面子图"嵌"进更大的图里，只会更糟。
- **另一个方向才是深水区**：若 G 不含这两个细分，则 G 可以画在平面上。这个方向的证明需要处理"极大平面图""3-连通分解""桥"等一系列结构，篇幅远超本讲范围（官方 Note 明确说 "The other direction … is difficult"）。可以记住的直觉是：**非平面性只有两个"根源"**，一切非平面图都只是这两个根源的"膨胀"。
- **应用示例**：4 维超立方体 Q_4（$V = 16, E = 32$）是非平面的——它包含 $K_{3,3}$ 的细分。注意 Q_4 通过了 -6 型检测（$32 \leq 42$），所以这里也**必须**用库拉托夫斯基定理或二分图上界（$32 > 2 \cdot 16 - 4 = 28$，后者一步就够，见算例 4）。反过来，Q_3（立方体）是平面的，恰好是"临界"情形：$E = 12 = 2 \cdot 8 - 4$。

定理 10.8（树的四个等价刻画）：对 $n = |V| \geq 1$ 的图 $G = (V, E)$，以下四条等价：

1. G 连通且无环；
2. G 连通且有 $n - 1$ 条边；
3. G 连通，且删去任意一条边都会使 G 不连通（**极小连通**）；
4. G 无环，且添加任意一条新边（连接两个原不相邻的顶点）都会产生一个环（**极大无环**）。

```
【等价刻画的循环证明链：只需证一圈，四条命题就全部等价】

    (1) 连通 + 无环
         |
         |  对顶点数 n 做强归纳（定理 10.9）
         |  删点后可能裂成 t 个分量 => 必须强归纳！
         v
    (2) 连通 + 恰好 n-1 条边
         |
         |  若删边 e 后仍连通，它至少要有 n-1 条边（引理 10.11）
         |  但它只有 n-2 条边 => 矛盾
         v
    (3) 连通 + 删任一边即断（极小连通）
         |
         |  无环：有环则可删环上一边而不失连通，与(3)矛盾
         |  加边成环：u,v 间原有路径 P，加 {u,v} 后 P+{u,v} 是环
         v
    (4) 无环 + 加任一边成环（极大无环）
         |
         |  若不连通，取两个分量中的 u,v 加边 {u,v}
         |  u,v 之间原本无路径 => 加边不生环，与(4)矛盾
         v
    (1) 连通 + 无环          （回路闭合，四条命题两两等价）

  口诀：连通无环  <=>  边数 = V-1  <=>  极小连通  <=>  极大无环
```

证明链条（(1)⟹(2)⟹(3)⟹(4)⟹(1)）：

- **(1)⟹(2)**：这是**定理 10.9**，下面用强归纳完整证明。
- **(2)⟹(3)**：设 G 连通且有 $n-1$ 条边。任取一条边 e，若删去 e 后 $G-e$ 仍连通，则由下面的**引理 10.11**（连通图至少 $n-1$ 条边），$G-e$ 至少要有 $n-1$ 条边；但 $G-e$ 只有 $n-2$ 条边，矛盾。故删去任意一条边都会不连通。
- **(3)⟹(4)**：先证 G 无环：若 G 含环，则环上任取一条边 e，删去后环上其余顶点仍连通，且环外顶点可通过环上顶点中转，故 $G-e$ 仍连通，与 (3) 矛盾。再证"加边必成环"：设在新加入的边 $\{u,v\}$ 之前，u,v 本来不相邻。由 (3) 的连通性，G 中存在 u 到 v 的路径 P；加入 $\{u,v\}$ 后 $P\cup\{u,v\}$ 构成一个环 ✓。
- **(4)⟹(1)**：已知无环，只需证连通。若 G 不连通，取两个不同分量中的顶点 u,v（此时 $\{u,v\}$ 不是已有的边），加入边 $\{u,v\}$ 后 u,v 之间本来没有任何路径，因此不可能产生环，与 (4) 的"加边必成环"矛盾。故 G 连通。■

定理 10.9（树有 $n-1$ 条边）：若 $G=(V,E)$ 是 n 个顶点的连通无环图，则 $|E|=n-1$。**这是本讲"图上的归纳法"的范式证明。**

证明策略：对**顶点数 n** 做**强归纳**。为什么必须强归纳？因为删掉一个顶点 v 后，$G'=G-v$ 可能裂成 $t\geq 2$ 个连通分量，我们要**同时**对每个分量用归纳假设，而这些分量的顶点数各不相同、都小于 n——只有强归纳（"对所有 $1\leq n\leq k$ 成立"）才允许这么做。这正是官方练习里强调的 *"Note that this requires strong induction!"*

逐步推导：

1. **基础情形 $n=1$**：G 只有一个顶点、没有边（自环不允许），故 $|E|=0=n-1$ ✓。
2. **归纳假设**：设对一切 $1\leq n\leq k$，任何 n 个顶点的连通无环图都有 $n-1$ 条边。
3. **归纳步骤（$n=k+1$）**：取 G 为 $k+1$ 个顶点的连通无环图。任取一个顶点 v，令 $G'=G-v$（删去 v 及其所有关联边）。
4. **G' 仍然无环**：删点删边不可能创造出新的环，这是"无环"的单调性质。
5. 但 **G' 可能不连通**。设 G' 的连通分量为 $G'_1,\dots,G'_t$（注意 $t\geq 0$：若 $k=0$ 则 G' 为空图）。
6. **分情形讨论**：
7. **情形 A（$t=1$，即 G' 连通）**：G' 有 k 个顶点、连通无环，由归纳假设 $|E(G')|=k-1$。现在看 v 在 G 中的度数：若 $\deg(v)\geq 2$，取 v 的两个邻居 a,b。由于 G' 连通，G' 中存在 a 到 b 的路径 P，于是 $P\cup\{v,a\}\cup\{v,b\}$ 是 G 中的一个环，与无环矛盾。故 $\deg(v)\leq 1$。又 G 连通且 $k+1\geq 2$，故 $\deg(v)\geq 1$。于是 $\deg(v)=1$，$|E|=|E(G')|+1=(k-1)+1=k=n-1$ ✓。
8. **情形 B（$t\geq 2$，G' 不连通）**：设分量为 $G'_1,\dots,G'_t$，顶点数分别为 $n_1,\dots,n_t$，有 $n_1+\cdots+n_t=k$，且每个 $n_i\leq k-1<k+1=n$。每个 G'_i 都是连通无环图，故由**强归纳假设**（对每个 i 分别使用！）

$$|E(G'_i)|=n_i-1.$$

```
求和得 $|E(G')| = \sum_{i=1}^t (n_i-1) = k - t$。
```

- **关键：v 必须与每个分量都有边相连。** 否则若某个分量 G'_i 中的顶点与 v 没有边相连，则在 G 中该分量与"v 及其余部分"无法连通，与 G 连通矛盾。故 v 至少有 t 条边伸出，即 $\deg(v)\geq t$。
- **且 $\deg(v)=t$ 精确成立。** 若 $\deg(v)>t$，则由抽屉原理，v 与某个分量 G'_i 之间存在两条边 $\{v,a\}$ 与 $\{v,b\}$（a,b 在同一个分量中，$a\neq b$）。由于 G'_i 连通，其中存在 a 到 b 的路径 P；于是 $P\cup\{v,a\}\cup\{v,b\}$ 构成 G 中的一个环，与无环矛盾。故 $\deg(v)=t$。
- 于是 $|E|=|E(G')|+t=(k-t)+t=k=n-1$ ✓。
- 两种情形都得到 $|E|=n-1$，由强归纳，命题对一切 $n\geq 1$ 成立。■

【证明机制解说】：这个证明是"图归纳"的教科书级范例，值得记住三个要点。 – **第一，删点之后必须考虑连通性变化。** 情形 A 与情形 B 的区别不是技术细节，而是证明的实质：连通的 G' 只需一次归纳，不连通的 G' 需要对每个分量各用一次归纳。 – **第二，强归纳不是"更保险"，而是"必需的"。** 情形 B 中我们同时调用 t

次归纳假设，作用的规模 $n_1,\dots,n_t$ 都小于 n 但彼此不等；弱归纳的假设 $P(n-1)$ 完全用不上。 – **第三，"无环"这一条件在情形 B 中被用了两次。** 一次证明 G' 无环从而归纳假设可用，一次证明 $\deg(v)=t$（不能多连）。去掉无环条件，命题就假（K_4 连通、4 个顶点、$6\neq 3$ 条边），所以这些地方一步都不能省。

引理 10.10（叶子引理，Leaf Lemma）：任何 $n\geq 2$ 个顶点的树至少有**两个**度数为 1 的顶点（称为叶子 (leaf)）。

证明策略：反证法 + 握手引理（handshake lemma，讲次 9：$\sum_v \deg(v)=2E$）+ 定理 10.9 的 $E=V-1$。核心是一个**计数下界与上界的冲突**。

逐步推导：

1. 设树 T 有 $n=|V|\geq 2$ 个顶点、$E=n-1$ 条边（定理 10.9）。
2. 由握手引理：$\sum_{v\in V}\deg(v)=2E=2n-2$。
3. 适由连通性（$n\geq 2$），每个顶点度数 ≥ 1（没有孤立点）。
4. **先证至少有一个叶子**：反设所有顶点度数 ≥ 2，则 $\sum_v \deg(v)\geq 2n>2n-2$，与第 2 步矛盾。故至少存在一个度数为 1 的顶点。
5. **再证至少有两个叶子**：反设叶子**恰好只有一个**，设为 u（$\deg(u)=1$），其余 $n-1$ 个顶点度数都 ≥ 2。则

$$\sum_v \deg(v)\ \geq\ 1+2(n-1)=2n-1\ >\ 2n-2,$$

与第 2 步矛盾。 6. 故叶子数 ≥ 2（其实还可以用"路径的两个端点都是叶子"给出一个更构造性的证明：从任意顶点出发沿最长路径走到尽头，两个尽头都必须是叶子）。■

【证明机制解说】：证明的"灵光"是把"叶子太少"翻译成"度数总和太大"，再与握手引理给出的精确值 $2n-2$ 对撞。注意 $n\geq 2$ 不可省：$n=1$ 的单点树度数为 0，不是叶子（也没有两个叶子）。另外，这个引理是归纳法证明树命题时的"抓手"——很多关于树的归纳证明都选择**删掉一个叶子的邻居**或**删掉叶子**来做归纳步骤。

引理 10.11（连通图至少有 $n-1$ 条边）：任何 n 个顶点的连通无向图至少有 $n-1$ 条边。

证明策略：对顶点数 n 做归纳（这里可以用较弱的归纳，因为可以精心选择删点位置——但在情形 B 中仍需对分量分别归纳，所以本质上是强归纳）。

逐步推导：

1. **基础情形 $n=1$**：0 条边，$0=n-1$ ✓。
2. **归纳假设**：设对所有 $\leq k$ 个顶点的连通图，边数 $\geq$ 顶点数 -1。
3. **归纳步骤（$n=k+1$）**：取连通图 G，n 个顶点。任取 v，令 $G'=G-v$，其连通分量为 $G'_1,\dots,G'_t$，顶点数 $n_1,\dots,n_t$，$\sum n_i=k$。
4. 由强归纳假设，$|E(G'_i)|\geq n_i-1$，故 $|E(G')|\geq k-t$。
5. 由 G 连通，v 与每个分量至少有一条边（理由同定理 10.9 情形 B），故 $\deg(v)\geq t$。
6. 于是 $|E|=|E(G')|+\deg(v)\geq (k-t)+t=k=n-1$ ✓。■

（这条引理正是定理 10.8 中 (2)⟹(3) 所依赖的事实，也是官方练习第 3 题。）

引理 10.12（超立方体的顶点数与边数）：n 维超立方体 Q_n 有 2^n 个顶点、度数均为 n、共 $n2^{n-1}$ 条边。

证明策略：顶点数用"逐位独立选择"的乘法原理（讲次 14 的计数）；边数用两种方法——**方法一：握手引理**（每个顶点度数为 n，每条边被数两次）；**方法二：递归定义 + 归纳**。

逐步推导：

1. **顶点数**：$V=\{0,1\}^n$，每一位有 2 种取法，n 位独立，故 $|V|=2^n$。
2. **度数**：固定 $x\in\{0,1\}^n$，与 x 相邻的顶点必须"恰好一位不同"，而这一位可以是 n 个位置中的任意一个；选定位置 i 后，邻居唯一确定为"把 x 的第 i 位翻转"。n 个位置给出 n 个不同的邻居，故 $\deg(x)=n$。
3. **边数（方法一，握手引理）**：$\sum_x \deg(x)=2^n\cdot n=2E$，故 $E=n2^{n-1}$。
4. **边数（方法二，递归）**：Q_n 由两个 $(n-1)$ 维子立方体（0–子立方体与 1–子立方体）构成：把 Q_{n-1} 的每个顶点 x 复制成 $0x$ 与 $1x$，再加上 2^{n-1} 条"跨接边"$\{0x,1x\}$。于是

$$E(n)=2E(n-1)+2^{n-1},\qquad E(1)=1.$$

断言 $E(n)=n2^{n-1}$。验证归纳：基础情形 $n=1$：$1\cdot 2^0=1$ ✓。归纳步骤：若 $E(n-1)=(n-1)2^{n-2}$，则

$$E(n)=2(n-1)2^{n-2}+2^{n-1}=(n-1)2^{n-1}+2^{n-1}=n2^{n-1}.\qquad\blacksquare$$

【证明机制解说】：两个证明平分秋色。方法一是"全局计数"（用度数对称性一步到位），方法二是"结构递归"（用自相似性），后者在分析递归算法、分治法复杂度时是标准套路。注意方法二中跨接边数恰好是 2^{n-1}（Q_{n-1} 的顶点数），这是"两位子立方体一一对应"的直接结果。

定理 10.13（Q_n 是二分图，且直径恰为 n）：对一切 $n\geq 1$，Q_n 是二分图；并且任意两个顶点之间的距离等于它们的汉明距离，故直径（diameter，任意两点间距离的最大值）为 n。

证明策略：**构造性染色 + 归纳**。用汉明距离的**奇偶性**给顶点染两色——这正是官方 Note 说的"每个环都是偶长度 ⟹ 二分图"。

逐步推导（二分性）：

1. 定义映射 $\chi:\{0,1\}^n\to\{0,1\}$ 为 $\chi(x)=\left(\sum_{i=1}^n x_i\right)\bmod 2$，即"$x$ 中 1 的个数的奇偶性"（也就是 x 到全零串 0^n 的汉明距离的奇偶性）。
2. 设 x,y 相邻，则它们恰好有一位不同，于是 $\chi(x)\neq\chi(y)$（翻转一位必然改变 1 的个数的奇偶性）。
3. 取 $L=\{x:\chi(x)=0\}$，$R=\{x:\chi(x)=1\}$，则 $V=L\dot\cup R$ 且每条边都跨在 L,R 之间——按定义 Q_n 是二分图 ✓。
4. **归纳版的论证**（对应官方 Note 的递归定义）：Q_1 是一条边，显然是二分图。设 Q_{n-1} 可二分染色，把它复制成两份，一份染色不变（作为 0–子立方体），另一份**颜色全部取反**（作为 1–子立方体）；子立方体内部按假设合法，跨接边 $\{0x,1x\}$ 两端颜色恰好相反（因为取反了），也合法。故 Q_n 可二染色，即二分图 ✓。

5. **顺带得到"环长全为偶"**：在二分图中沿边行走必然在两个部分之间交替，回到起点所需的步数必为偶数。

逐步推导（距离与直径）：

1. **上界**：设 x, y 的汉明距离为 d（有 d 位不同）。逐位翻转这 d 个坐标，得到一条从 x 到 y 的长度为 d 的路径，故 $\mathbf{dist}(x, y) \le d$。
2. **下界**：每走一条边只能改变**一位**，所以走 k 步最多改变 k 位；要改变 d 位至少需要 d 步，故 $\mathbf{dist}(x, y) \ge d$。
3. 合并得 $\mathbf{dist}(x, y) = d =$ 汉明距离。
4. **直径**：两个顶点间汉明距离最大为 n（例如 $\mathbf{0}^n$ 与 $\mathbf{1}^n$），故 $\mathbf{diam}(Q_n) = n$。
5. **对照完全图**：K_{2^n} 的直径是 1，但度数高达 $2^n - 1$、边数高达 $\binom{2^n}{2} \approx 2^{2n-1}$。超立方体用 n 的度数换来了 $\log_2$ 级别的直径 n——这是"网络拓扑设计"里最经典的时间/空间权衡。■

【证明机制解说】：二分性证明的关键是**找到一个"势函数"**（这里是奇偶性），使得每条边都让势函数变号。这种技巧在后面讲 Markov 链的周期性、随机游走的二部性时会反复出现。归纳版本的关键技巧是**"复制 + 一半取反"**——用旧结构的染色给新结构染色，跨接边自动合法。

算例总汇（下面 6 个小图逐个数 V, E, F，逐个验算欧拉公式；数值全部经脚本核算）：

```
【算例 1：单点树】            【算例 2：2 点树】
    *                          * ---- *
 V=1  E=0  F=1                V=2  E=1  F=1
 V-E+F = 1-0+1 = 2  OK        V-E+F = 2-1+1 = 2  OK
  (F=1：平面未被分割)（F=1：一条边不围出封闭区域）

【算例 3：4 点星形树】        【算例 4：三角形 K3】
     *                           1
     |                         /   \
 *---*---*                     2-----3
 V=4  E=3  F=1                 V=3  E=3  F=2
 V-E+F = 4-3+1 = 2  OK         V-E+F = 3-3+2 = 2  OK
  (树的 E=V-1 ✓)               (2 个面：内部三角形 + 外部面)
                               sum(s_i) = 3+3 = 6 = 2E  OK

【算例 5：正方形 + 一条对角线】    【算例 6：K2,3（二分平面图）】
  1 -------- 2                        a       b
  |        / |                        \     / \
  |      /   |                         \   /   \
  |    /     |                          c       d
  3 -------- 4                           \     /
                                           \   /
  V=4  E=5  F=3                            (e)
  V-E+F = 4-5+3 = 2  OK
  F=3：两个三角形 + 外部面      V=5  E=6  F=3
  3F=9 <= 2E=10  OK               V-E+F = 5-6+3 = 2  OK
  E=5 <= 3V-6=6  OK               E=6 <= 3V-6=9  OK
                                  E=6 <= 2V-4=6  OK（取等号！）

【算例 7：立方体 Q3（V=8,E=12,F=6）】
       000 ---------- 001
       /|             /|
    010 ---------- 011 |
      | |            | |
      | 100 --------|-101
      |/             |/
    110 ---------- 111
  V=8  E=12  F=6   (6 个正方形面)
  V-E+F = 8-12+6 = 2  OK
  sum(s_i) = 6*4 = 24 = 2E  OK
  3F=18 <= 2E=24  OK ；4F=24 <= 2E=24 取等（二分图，每面恰好 4 边）
  E=12 <= 3V-6=18  OK ；E=12 <= 2V-4=12 取等（二分平面图临界情形）
```

```
【四个"取等 / 越界"的判据对照表（脚本已核）】

 图       V    E    3V-6   E<=3V-6?   2V-4   E<=2V-4?   平面?
 ------------------------------------------------------------------
 K3       3    3     3      OK       2       NO       YES
 K4       4    6     6      OK(等)   4       NO       YES
 K5       5   10     9      NO       6       NO       NO  <-- 上界击倒
 K2,3     5    6     9      OK       6       OK(等)   YES
 K3,3     6    9    12      OK       8       NO       NO  <-- 换用二分上界击倒
 Q3       8   12    18      OK      12       OK(等)   YES
 Q4      16   32    42      OK      28       NO       NO  <-- 二分上界击倒
 K6       6   15    12      NO       8       NO       NO
 ------------------------------------------------------------------
 结论：E<=3V-6 与 E<=2V-4 都是"必要条件"。
       NO  => 一定非平面（可以据此下结论）
       OK  => 什么也不能说，必须另找论据（库拉托夫斯基定理等）

 注意：2V-4 那一列只对"二分图"有约束力。
       K3、K4、K5、K6 都不是二分图（含三角形），
       它们该列的 "NO" 不构成任何推论——
       定理 10.5 的前提"G 是二分图"不满足，无从谈起。
       K5 只被 3V-6 那一列击倒；K3,3 / Q4 才是被 2V-4 击倒的。
```

反例与边界情形总汇（这些是本节最容易被忽略的部分）：

- **反例 1（$E \le 3V-6$ 是必要条件，不是充分条件）**：把 K_5 的一条边细分一次，得到 G：$V=6$，$E=11$，而 $3V-6=12$，故 $11 \le 12$ 成立——G **通过**了边数检测。但 G 含有 K_5 的细分，由库拉托夫斯基定理，G **非平面**。所以 $E \le 3V-6$ **不能**用来证明平面性。同理，把 $K_{3,3}$ 的一条边细分一次：$V=7, E=10$，$2V-4=10$，恰好取等号，检测"通过"，但它含 $K_{3,3}$ 的细分，仍非平面。**上界只能用来否定平面性，不能用来肯定平面性。**
- **反例 2（必须 $V \ge 3$ 且为简单图）**：单点树 $V=1, E=0$ 时 $3V-6=-3<0=E$，不等式反向；两点一条边 $V=2, E=1$ 时 $3V-6=0<1$。此外，柯尼斯堡七桥图有多重边（A, B 之间两座桥），此时"每个面至少 3 条边"不成立（两条平行边可以围出一个 2 边面），$E \le 3V-6$ 的推导整条链就断了。
- **反例 3（"$3F \le 2E$"中的等号条件）**：$3F \le 2E$ 对 K_4 取等号（$F=4, E=6$：$12 \le 12$），对 Q_3 也取等号（$F=6, E=12$：$18 \le 24$ 不取等）。取等号意味着每个面恰好是三角形，这样的平面图叫**极大平面图 (maximal planar graph)**，K_4、正四面体都是。极大平面图在顶点数 $V \ge 3$ 时恰好有 $E=3V-6$ 条边。
- **反例 4（强归纳不可换成弱归纳）**：定理 10.9 的情形 B 中，删点后可能裂成多个分量，规模各不相同。若用弱归纳（只假设 $P(k)$），对规模 $n_i < k$ 的分量完全无法调用假设，证明立即断链。

与经典问题的联系

（1）芯片布线与 PCB 单层布线（平面性的工程含义）。在印刷电路板 (PCB) 的单层布线中，导线不能交叉（交叉就短路）。因此"这个连接关系图能不能单层布通"就是**平面性判定**问题。K_5 非平面意味着：如果 5 个元件要两两直连，单层布线做不到，必须打孔换层（多层板）或引入跳线。库拉托夫斯基定理给出了一个**结构性判据**：只要找到 K_5 或 $K_{3,3}$ 的细分，就可以断言"必须换层"。工程上的实用算法（如 Hopcroft–Tarjan 的线性时间平面性测试）本质上就是它的算法化版本。

（2）互联网拓扑与"平面图不够用"。路由器网络的物理布线大体平面，但逻辑连接（IP 链路）常常非平面——因为长距离链路会"跨越"中间节点。$E \le 3V-6$ 告诉我们：**平面结构最多只能提供约 3 倍顶点数的边**，这远不足以支撑互联网的高连通需求。所以真实网络必须"非平面化"，代价是布线复杂度（交叉、跳线、光纤绕行）。这也解释了为什么数据中心网络要用超立方体、胖树 (fat-tree)、Butterfly 这类非平面但对高度数友好的拓扑。

（3）Connection Machine 与超立方体拓扑。1980 年代 Thinking Machines 的 Connection Machine 要把 100 万台处理器连起来。完全图需要 $\binom{10^6}{2} \approx 5 \times 10^{11}$ 根线（官方 Note 说约 10^{12} 量级），完全不可行；20 维超立方体 Q_{20} 每个处理器只连 20 个邻居，边数约 $20 \cdot 2^{19} \approx 10^7$，而任意两台处理器通信最多中转 20 跳。这就是引理 10.12 与定理 10.13 的直接工程价值：**度数为 n、直径为 n、边数 $n2^{n-1}$** 的精确公式让设计者能精确算成本。

（4）树与最小生成树 / 路由 / 二叉搜索树。树"连通且无环"的等价刻画（定理 10.8）说明它有**唯一路径**性质，这让路由变得极简（不用防环，不需要复杂的路由协议）。计算机网络中的生成树协议 (Spanning Tree Protocol) 就是在物理网络里选出一棵生成树来转发帧，避免广播风暴。另一方面，树没有冗余，所以需要"鲁棒性"时要在树上加边形成环。二叉搜索树 (BST) 是**有根树**：根在顶部，深度 d 是最长根到叶路径长度，第 k 层是与根距离为 k 的顶点集合——查找代价正比于深度，而随机 BST 的期望深度分析要用到讲次 20 的期望线性性。

（5）四条颜色定理与频段分配（对偶与着色）。平面图还有一个漂亮的**对偶 (duality)** 结构：在平面图 G 的每个面上放一个"对偶顶点"，两个面共享一条边就在对偶图中连一条边，得到 G^*；$(G^*)^* = G$。"给政治地图染色使相邻国家异色"因此等价于"给平面图的顶点染色使相邻顶点异色"。四色定理说平面图只需 4 种颜色；官方 Note 证明的是较弱的版本（定理 5.4，五色定理），思路是对顶点数归纳：先证明存在度数 ≤ 5 的顶点（用 $E \le 3V-6$：若所有顶点度 ≥ 6 则 $E \ge 3V > 3V-6$，矛盾），删掉它、递归染色、再把它放回并用"可换色的连通分量"技巧找一个没用过的颜色。**频段分配**是它的直接应用：把发射台想成顶点，位置太近（会干扰）就连一条边；如果干扰图是平面的，四色定理保证 4 个频段即可无冲突分配。

（6）de Bruijn 序列与 Euler 定理（承上讲）。2^n 位的循环串若每个 n 位子串恰好出现一次，就叫 de Bruijn 序列。构造方法是：在顶点集 $\{0,1\}^{n-1}$ 上造有向图，每个顶点 $a_1 \cdots a_{n-1}$ 有两条出边（右移补 0 或补 1）。每个顶点入度 $=$ 出度 $=2$，由讲次 9 的**有向版 Euler 定理**（把"所有顶点偶度"改成"每个顶点入度 = 出度"）该图必有欧拉环游，沿环游读出的位就是 de Bruijn 序列。这个例子说明：**Euler 定理 + 一个巧妙的建模 = 一个组合对象的构造性存在证明。**

与其他讲次的关联

- **讲次 9（Graphs，图论基础）**：本讲的起点是讲次 9 的语言——顶点、边、度、路径、环、连通分量、二部图。**握手引理** $\sum_v \deg(v) = 2E$ 在引理 10.10（叶子引理）与引理 10.12（超立方体边数）中被用了两次；**有向版 Euler 定理**在 de Bruijn 序列的应用中直接复用（只把条件从"所有顶点偶度"改成"每个顶点入度 = 出度"）；**二部图**概念在本讲升级成了"无奇环"的等价刻画，并由此得到更紧的 $E \le 2V-4$。

- **讲次 3（Induction，归纳法与强归纳）**：本讲是讲次 3 的技巧在图论上的**主战场**。欧拉公式定理 10.1 是**对边数归纳**；树有 $n-1$ 条边（定理 10.9）与连通图至少 $n-1$ 条边（引理 10.11）是**对顶点数的强归纳**，且"删点后裂成多个分量"正是讲次 3 中"弱归纳不够用、必须强归纳"的最典型场景。超立方体的边数递推 $E(n)=2E(n-1)+2^{n-1}$ 也是标准归纳。
- **讲次 2（Proof Techniques II，逆否/反证/分情形）**：K_5 与 $K_{3,3}$ 非平面都是**反证法**（假设平面 $\Rightarrow$ 必须满足边数上界 $\Rightarrow$ 具体数字矛盾）；$E \le 3V-6$ 的"必要非充分"是**逆命题不成立**的经典素材；树的等价刻画用**循环式证明**（(1)⇒(2)⇒(3)⇒(4)⇒(1)）展示"多条命题等价"的标准证法。
- **讲次 14（Counting，计数）**：K_n 的边数 $\binom{n}{2}=n(n-1)/2$ 是组合数最直接的应用；Q_n 的顶点数 $2^n=|\{0,1\}^n|$ 用的是乘法原理；引理 10.2 的 $\sum s_i = 2E$ 与握手引理都是**双计数**，与讲次 16（Combinatorial Proofs）的双计数/双射思想同源。
- **讲次 12（Countability，可数性）**：$\{0,1\}^n$ 与 2^n 的联系将在讲次 12 扩展到 $\{0,1\}^\infty$；对角化论证的核心正是"所有 n 位串可以编号"这一事实。此外"平面图稀疏 $\Rightarrow$ 可数"这类论证在讲次 12/13 会以更抽象的形式出现。
- **讲次 11（Stable Matching，稳定匹配）**：稳定匹配的实例天然是**完全二分图** $K_{n,n}$ 加上两侧的偏好序；本讲建立的二分图语言（$E \le 2V-4$ 那一套）为讲次 11 提供词汇，而讲次 11 的 Gale–Shapley 算法则给出"二分图上的完美匹配（perfect matching）"这一概念的具体算法化实例。
- **讲次 20（Expectations & Linearity，期望与线性性）**：超立方体上的随机游走、Q_n 中随机两点距离的期望，都会用到本讲的"距离 = 汉明距离"结论与期望线性性；图论中的平均度数 $\bar{d}=2E/V$ 也是线性性推导的常客。
- **讲次 26（Markov Chains，马尔可夫链）**：Q_n 的二分性（定理 10.13）会导致其上的随机游走具有**周期性**（周期 2），这正是 Markov 链周期性理论中最标准的例子。

关键要点

1. **欧拉公式是平面图理论的"能量守恒"**：连通平面图满足 $V-E+F=2$（含外部面）；不连通时是 $V-E+F=1+C$（C 为连通分量数）。证明靠"删圈上的边使 E 与 F 各减 1、删桥使只有 E 减 1"的不变量论证。
2. **两条上界及其适用范围**：简单平面图 $V \ge 3$ 时 $E \le 3V-6$；若还是二分图则 $E \le 2V-4$。推导的公共骨架是 $\sum_{i=1}^{F} s_i = 2E \ge (\text{最小面长}) \cdot F$，其中最小面长在一般图是 3、在二分图是 4。
3. **非平面性的两把锤子**：K_5 用 $E=10>3\cdot 5-6=9$ 击倒；$K_{3,3}$ 用 $E=9>2\cdot 6-4=8$ 击倒（注意它**通过**了 -6 型检测）。库拉托夫斯基定理进一步说：K_5 与 $K_{3,3}$ 的细分是**唯一的两个非平面性根源**。
4. **树的等价刻画记成一句口诀**："连通无环 $\iff$ 连通且边数 $=V-1$ $\iff$ 极小连通（删任一边即断） $\iff$ 极大无环（加任一边成环）"。树的叶子引理：$V \ge 2$ 的树至少有两个叶子（用 $\sum \deg = 2(V-1)$ 反证）。
5. **图归纳的三条铁律**：对顶点数或边数归纳；**删点后可能不连通**，必须对每个连通分量分别归纳；因此要用**强归纳**而非弱归纳。此外"删什么"是证明的艺术——删叶子、删环上的边、删度 ≤ 5 的顶点，各有各的用处。
6. **超立方体 Q_n 的四个公式**：$V=2^n$、$\deg = n$、$E=n2^{n-1}$、直径 $=n$；且它是二分图（按 1 的个数的奇偶性染色 / 归纳地"复制 + 一半取反"）。

常见误区与注意事项

1. **把"这张画法有交叉"当成"这个图非平面"**。平面性是**存在性**性质：只要有**某一种**无交叉画法就够。K_4 的"正方形 + 两条对角线"有 1 个交叉，但 K_4 明明是平面图。判断非平面必须用**证明**（边数上界或库拉托夫斯基），不能靠"我画不出来"。
2. **忘记外部面**。欧拉公式里的 F 包含无界的那个面。K_4 的面数是 4（3 个内部三角形 $+$ 1 个外部面），不是 3；三角形 K_3 是 2 不是 1；单点图是 1 不是 0。漏掉外部面会让 $V-E+F$ 全部算错 1。
3. **把必要条件当充分条件**。$E \le 3V-6$ 是平面性的**必要**条件：K_5 的细分（$V=6, E=11 \le 12$）满足不等式却非平面。同理 $K_{3,3}$ 满足 -6 型不等式（$9 \le 12$）却非平面——这正是为什么必须发展 -4 型上界。**上界只能用来证明"非平面"，不能用来证明"平面"。**
4. **忽略定理的前提条件**。$E \le 3V-6$ 需要"简单图（无平行边、无自环）、连通、$V \ge 3$"三个条件；$E \le 2V-4$ 还需加上"二分图"。柯尼斯堡七桥图有多重边，就是一个被排除的实例。$V=1,2$ 时不等式本身不成立（$3V-6$ 是负数）。
5. **图归纳中错误地使用弱归纳**。删掉一个顶点后 G' 可能裂成 t 个连通分量，归纳假设要同时作用于这些大小不一的分量。弱归纳只能说"$P(k) \Rightarrow P(k+1)$"，根本调不动。这是"图上的归纳法"最核心的考点。
6. **混淆超立方体的度数与直径**。Q_n 的度数（邻居数）是 n，直径（最远距离）也是 n，两者数值恰好相同，但**含义完全不同**：度数决定布线成本，直径决定通信延迟。Q_3 每个顶点连 3 条线，最远也要走 3 跳——数值相等，概念不可混。
7. **把 $3F \le 2E$ 无条件使用**。它的推导依赖"每个面至少 3 条边"，而这需要简单图 + 至少 3 条边。树的情形下 $F=1$ 而 $2E$ 可能很小（$V=2$ 时 $3F=3>2=2E$），不等式根本不成立。

思考题（带答案）

Q1. 设 G 是连通平面**简单**图，$V=9$，每个顶点的度数都是 4。请判断这样的 G 是否存在；若存在，求面数 F；并回答"G 可能是二分图吗"。

▸ 答案

第一步，算边数。 由握手引理 $\sum_v \deg(v) = 2E$：$9 \cdot 4 = 36 = 2E$，故 $E = 18$。

第二步，检验平面性必要条件。 $3V - 6 = 3 \cdot 9 - 6 = 21$，而 $E = 18 \le 21$ ✓，没有矛盾，所以**不能排除**存在性（若要断言存在，需要实际给出画法；这里只报"未发现矛盾"）。

第三步，求面数。 如果 G 是平面图，由欧拉公式 $F = E - V + 2 = 18 - 9 + 2 = 11$。

第四步，判断能否是二分图。 若是二分图，则必须满足 $E \le 2V - 4 = 2 \cdot 9 - 4 = 14$；但 $E = 18 > 14$。**矛盾**，故 G **不可能**是二分图。（另一个角度：4–正则图若是二分图，则两侧大小相等，$V = 9$ 是奇数，直接矛盾。）

验算（`node -e` 输出）：$9 \cdot 4 = 36$，$E = 18$，$F = 18 - 9 + 2 = 11$，$3V - 6 = 21$，$2V - 4 = 14$，$18 > 14$。

Q2. 证明：若树 T 有 $n \ge 2$ 个顶点，则 T 中至少有两个叶子；并说明为什么这条结论在 $n = 1$ 时失效。

▸ 答案

证明。 由树有 $E = n - 1$ 条边（定理 10.9）。由握手引理：

$$\sum_{v \in V(T)} \deg(v) = 2E = 2n - 2. \tag{$*$}$$

由连通性与 $n \ge 2$，每个顶点度数 ≥ 1。

先证至少 1 个叶子：若所有顶点 $\deg \ge 2$，则 $\sum_v \deg(v) \ge 2n > 2n - 2$，与 $(*)$ 矛盾。

再证至少 2 个叶子：反设恰好只有 1 个叶子 u（$\deg(u) = 1$），其余 $n - 1$ 个顶点度数均 ≥ 2。则

$$\sum_v \deg(v) \ge 1 + 2(n-1) = 2n - 1 > 2n - 2,$$

再次与 $(*)$ 矛盾。故叶子数 ≥ 2。$\blacksquare$

$n = 1$ 时失效的原因：此时 $(*)$ 给出 $\sum \deg = 0$，唯一的顶点度数为 0（孤立点），而叶子定义为"度数为 1 的顶点"，所以根本没有叶子；同时连通性也推不出"度数 ≥ 1"（单点没有边）。所以 $n \ge 2$ 这个条件不可省。**注意**：这个证明同时依赖定理 10.9（$E = n - 1$），若顺序上先讲叶子引理，也可以改用"从任意顶点出发走最长简单路径，两端点必是叶子"的构造性证明绕开它。

Q3. 判断正误并说明理由：「超立方体 Q_4 是二分图，所以它是平面图。」

▸ 答案

错误。 二分性与平面性是**互相独立**的性质，谁也不能推出谁。

- Q_4 确实是二分图：按"1 的个数的奇偶性"染色即可（定理 10.13），或用递归地"复制 + 一半取反"。
- 但 Q_4 **不是**平面图。用二分图的边数上界检验：$V = 2^4 = 16$，$E = 4 \cdot 2^3 = 32$，而 $2V - 4 = 2 \cdot 16 - 4 = 28$。$32 > 28$，矛盾，故 Q_4 非平面。
- 换个角度：Q_4 含 $K_{3,3}$ 的细分，由库拉托夫斯基定理也非平面。

顺带一提：题目若换成 Q_3，则 $V = 8, E = 12$，$2V - 4 = 12$，恰好取等号，Q_3（立方体）**是**平面图——它是"二分平面图里边数达到理论上界"的极端例子。可见同一族图里，$n = 3$ 平面而 $n = 4$ 就非平面了。

验算：Q_4：$E = 4 \cdot 8 = 32$，$2 \cdot 16 - 4 = 28$，$32 > 28$；Q_3：$E = 3 \cdot 4 = 12$，$2 \cdot 8 - 4 = 12$，取等。

Q4（**图归纳专练**）：请说明"证明任何 n 个顶点的连通图至少有 $n - 1$ 条边"时，为什么必须用强归纳，并写出删掉顶点 v 后图裂成 t 个连通分量时归纳步骤的关键式子。

▸ 答案

为什么必须强归纳：删去 v 后，$G' = G - v$ 可能裂成 $t \geq 2$ 个连通分量 $G'_1, \ldots, G'_t$，顶点数分别是 $n_1, \ldots, n_t$，满足 $n_1 + \cdots + n_t = n - 1$ 且每个 $n_i \leq n - 2 < n$。我们需要**同时**对每个分量使用归纳假设。弱归纳只能提供 $P(n-1)$ 这一个假设，而 n_i 取遍从 1 到 $n-2$ 的各种值，够不着；强归纳提供 $\forall 1 \leq n' \leq n-1,\ P(n')$，正好覆盖。

关键式子：

1. 对每个分量用强归纳假设：$|E(G'_i)| \geq n_i - 1$，求和得

$$|E(G')| \;=\; \sum_{i=1}^{t} |E(G'_i)| \;\geq\; \sum_{i=1}^{t} (n_i - 1) \;=\; (n-1) - t.$$

1. 由 G 连通，v 与每个分量之间至少有一条边，故 $\deg(v) \geq t$。
2. 相加：

$$|E(G)| = |E(G')| + \deg(v) \;\geq\; \big((n-1) - t\big) + t \;=\; n - 1.$$

即任何 n 个顶点的连通图至少有 $n-1$ 条边。■

小规模验算（穷举 $n = 1..5$ 全部图，求连通所需最少边数）：$0, 1, 2, 3, 4$，恰为 $n-1$，与结论一致。

补充：同样的"分量分解"手法在**定理 10.9**（树有 $n-1$ 条边）里还需要多一步——证明 $\deg(v) = t$ 而不能大于 t（否则 v 与某个分量之间的两条边plus分量内的路径会造出环）。这正是"无环"条件在归纳步骤中真正起作用的地方。

Lecture 11: Stable Matching（稳定匹配）

概述

本讲研究一个"看起来简单、实则深刻"的现实问题：**n 个求职者与 n 个岗位，双方各自有一份偏好排序，如何配对才算"好"？** 直觉上的"好"有很多版本（最大化第一志愿人数？最小化最后志愿人数？平均幸福度最高？），本讲选定的标准是**稳定性 (stability)**：不存在一对男女，他们没被配在一起，却**双方都更愿意**跟对方在一起。这样的双方称为**不稳定对 (instability)**，官方 Note 里叫**流氓对 (rogue couple)**。

核心结果是 Gale–Shapley 的**提出–拒绝算法 (Propose-and-Reject Algorithm，1962)**：它必然终止、必然产出一个完美匹配、且该匹配必然稳定。更进一步（本讲最精彩的部分）：**算法总是对"提出方"最有利**——若由男生提出，则每个男生都得到他在**所有稳定匹配中能拿到的最好对象**；而女生则恰恰得到**所有稳定匹配中最差的对象**。这个"性别不平等"的结论直接对应现实中住院医师匹配 (Residency Match) 的制度设计：谁有资格提申请，谁就在制度上占优。

本讲的证明技巧极具教学价值：**三重反证 + 一个关键归纳引理（Improvement Lemma）+ 良序原理 (Well-Ordering Principle)**。它是讲次 2（反证法）与讲次 3（归纳法）在算法分析上的第一次真正实战。

核心概念的直观解释

稳定匹配问题的数学建模（Stable Matching Problem）

- **定义**：给定两个**不相交**的集合 $M = \{m_1, \ldots, m_n\}$（男士/申请者/提出方候选）与 $W = \{w_1, \ldots, w_n\}$（女士/医院/接收方），以及
- 每个 $m \in M$ 对 W 的一个**严格全序**偏好 $\succ_m$（即 W 的一个排列，从最喜欢到最不喜欢）；
- 每个 $w \in W$ 对 M 的一个**严格全序**偏好 $\succ_w$。

一个**匹配 (matching)** 是 $M \cup W$ 上的一个配对：每个 m 至多配一个 w，每个 w 至多配一个 m。若所有人都被配上，则称**完美匹配 (perfect matching)**。形式上完美匹配是一个双射 $\mu : M \to W$。 – **直观解释（"它是什么意思？"）**：这是一张**完全二分图** $K_{n,n}$（讲次 9、10 的语言），每条边上还刻着两个人的"心理价签"。任务是从 $n!$ 个可能的完美匹配中，挑出"没有私奔动机"的那一个。类比：给 n 对男女安排相亲结果，要求"事后没有任何一对男女会互相说'早知道我们俩凑一对更好'"。 – **具体示例**：$n = 3$，三个岗位 Approximation Inc.、Basis Co.、Control Corp. 与三位申请者 Anita、Bridget、Christine。偏好表（越靠左越喜欢）：

岗位	第 1 志愿	第 2 志愿	第 3 志愿
Approximation Inc. (App)	Anita	Bridget	Christine
Basis Co. (Bas)	Bridget	Anita	Christine
Control Corp. (Con)	Anita	Bridget	Christine

申请者	第 1 志愿	第 2 志愿	第 3 志愿
Anita	Basis Co. (Bas)	Approximation Inc. (App)	Control Corp. (Con)
Bridget	Approximation Inc. (App)	Basis Co. (Bas)	Control Corp. (Con)
Christine	Approximation Inc. (App)	Basis Co. (Bas)	Control Corp. (Con)

注意这里的偏好是**严格**的（没有并列）。严格性是后面"最优性唯一"结论的必要前提——若允许并列，"每个男士的配偶唯一确定"就不一定成立了。

不稳定对 / 流氓对（Instability / Rogue Couple）

- **定义**：在完美匹配 μ 中，若 m 与 w **没有**被配在一起（$\mu(m) \neq w$），但**同时**满足

$$w \succ_m \mu(m) \quad \text{且} \quad m \succ_w \mu(w),$$

即 m 更喜欢 w 而不是自己当前的配偶、w 也更喜欢 m 而不是自己当前的配偶，则称 (m, w) 是一个**不稳定对**（官方 Note 的用词是 rogue couple）。

一个匹配是**稳定匹配 (stable matching)**，当且仅当它是完美匹配且不含任何不稳定对。 – **直观解释（"它是什么意思？"）**：稳定 = "没人有私奔的动机"。注意它是**双向**的：只要有一方不愿意，"私奔"就办不成，这不算不稳定。用官方 Note 的话说：不稳定的匹配会真的崩掉——流氓申请者可以撕毁已签的 offer，流氓岗位可以解雇已录用的人去雇更喜欢的那位，结果"一个岗位空了、一个无辜的人被炒了"。稳定性的目标是：让所有人都情愿遵守最终结果。 – **具体示例（在 $n = 3$ 例子上检验）**： – 匹配 $\mu_1 = \{(App, \text{Christine}), (Bas, \text{Bridget}), (Con, \text{Anita})\}$ 是**不稳定**的。检验 (App, Anita)：App 当前配 Christine，而 App 更喜欢 Anita（第 1 志愿 vs 第 3 志愿）；Anita 当前配 Con，而 Anita 更喜欢 App（第 2 志愿 vs 第 3 志愿）。**双方都更愿意**，于是 (App, Anita) 是不稳定对。（同理 $(App, \text{Bridget})$ 也是。） – 匹配 $\mu_2 = \{(App, \text{Bridget}), (Bas, \text{Anita}), (Con, \text{Christine})\}$ 是**稳定**的。有人会问：App 明明更喜欢 Anita 啊？但 Anita 当前配的是她的**第一志愿** Bas，她不会为了 App 而离开，所以 (App, Anita) 不构成不稳定对。同理 Con 与 Christine 都配了自己的最后志愿，但他们更喜欢的对象都不愿意要他们，所以依然稳定。 – **脚本验算**（下面的完整代码会给出）：对 μ_1 检测出不稳定对 $[(App, Anita), (App, Bridget)]$，对 μ_2 与算法输出均检测出**零个**不稳定对。

提出–拒绝算法（Propose-and-Reject / Gale–Shapley Algorithm）

- **定义**：算法按"天 (day)"离散推进：
- **每天上午**：每个**尚未被任何女士保留 offer** 的男士，向自己名单上"还没拒绝过他的最靠前的那位女士"提出申请。
- **每天下午**：每位女士收集上午收到的所有申请，加上自己手上已有的 offer，从中挑出**最喜欢的那一个**回"也许（maybe）"（即把手上的 offer 换成这一个），对**其余所有**申请回"不（no）"，即拒绝。
- **每天傍晚**：每位被拒绝的男士，把该女士从自己名单上划掉（该女士从此不会再收到这位男士的申请）。
- 当**某一天没有任何申请被拒绝**时循环结束：所有女士手上都有 offer，大家接受，算法终止。
- **直观解释（"它是什么意思？"）**：这是一场"逐步降低标准"的相亲大会。**男士方只会越来越将就**（被拒一次，名单就少一个，剩下的选择只会更差）；**女士方只会越来越挑剔**（手上的 offer 只会越来越好）。两者"从两头向中间靠"，最终在某个点上恰好相遇——这个相遇点就是稳定匹配。官方 Note 把这个观察总结成 Observation 4.1，并由 **Improvement Lemma（改进引理）** 严格化。
- **具体示例**：见下一节的完整伪代码与逐日手算表。

最优性（Optimality）：最优对象 / 最优匹配

- **定义 11.1（岗位 J 的最优对象）**：在 J 的偏好表上，**所有稳定匹配中能与 J 配对的最靠前的那位申请者**，称为 J 的最优对象（optimal candidate）。若一个稳定匹配使**每个**岗位都配上它的最优对象，就称它是**岗位最优匹配（job/employer-optimal matching）**。
- **定义 11.2（申请者 C 的最优岗位）**：对称地，C 的偏好表上所有稳定匹配中能与 C 配对的最靠前的那个岗位，称为 C 的最优岗位（optimal job）；相应地有**申请者最优匹配（candidate-optimal matching）**。
- **定义 11.3（最差对象 / pessimal）**：同理可定义**岗位最差对象（pessimal candidate）**为 J 在所有稳定匹配中能配到的最靠后的一位。若每个申请者都配上她的最差岗位，则该匹配是**申请者最差匹配（candidate-pessimal matching）**。
- **直观解释**：注意"最优对象"不是"第一志愿"！第一志愿可能根本不现实（对方看不上你，任何稳定匹配里都配不到）。最优性是**在稳定性的约束下取上确界**——一个"条件最优"的概念。这一点是官方 Note 特别提醒的："the notion of *best partner* can be a bit fuzzy if we are not careful."
- **具体示例（$n = 4$ 的官方例子）**：岗位 1,2,3,4 与申请者 A,B,C,D，偏好如下。

岗位	第 1	第 2	第 3	第 4
1	A	B	C	D
2	A	D	C	B
3	A	C	B	D
4	A	B	C	D

申请者	第 1	第 2	第 3	第 4
A	1	3	2	4
B	4	3	2	1
C	2	3	1	4
D	3	4	2	1

这个实例**恰有两个**稳定匹配（下面的脚本穷举 $4! = 24$ 个匹配逐一验证过）：

$$S = \{(1, A), (2, D), (3, C), (4, B)\}, \qquad T = \{(1, A), (2, C), (3, D), (4, B)\}.$$

岗位 2 的第一志愿是 A，但**不存在**任何稳定匹配把 2 与 A 配在一起（穷举确认）——因为 A 在岗位 2 身上只排第 3，而别的岗位（1 和 3）都更喜欢 A，把 2 与 A 硬配会制造不稳定对。所以岗位 2 的**最优对象**是 D。在 S 中每个岗位都拿到自己在该实例中的最优对象，故 S 是岗位最优匹配；T 则是申请者最优匹配（A 拿到最优岗位 1，B 拿到最优岗位 4，C 拿到最优岗位 2，D 拿到最优岗位 3）。

良序原理（Well-Ordering Principle）

- **定义**：若 $S \subseteq \mathbb{N}$ 且 $S \neq \varnothing$，则 S 有最小元素。

- **直观解释**：这是"自然数集上一定存在**第一**个反例"的保证。它和归纳法**等价**：归纳法的有效性正依赖于自然数有良序。反证法里那句熟悉的 "suppose day k is the first day such that..." 之所以合法，正是因为有良序原理；而整数集 $\mathbb{Z}$（有负无穷）、实数集 $\mathbb{R}$、非负实数集 $[0,\infty)$ 都**不满足**良序原理（例如 $\{n\in\mathbb{Z}:n<0\}$ 没有最小元素，$(0,1]$ 作为非负实数的子集没有最小元素）。
- **具体示例**：$S_1=\{5,2,11,7,8\}$ 最小元是 2；$S_2=$ 全体奇数，最小元是 1；$S_3=$ 全体质数，最小元是 2。三个都有最小元，符合良序原理。反例：$\{n\in\mathbb{Z}:n$ 是负数$\}$ 没有最小元，所以 $\mathbb{Z}$ 不满足良序原理。

室友问题（Roommates Problem）——为什么"两类对象"不可省

- **定义**：$2n$ 个人两两配对成室友，每个人对**其余 $2n-1$ 人**有偏好序。这里没有"两类"之分，任何人都可能与任何人配对。
- **直观解释**：稳定匹配问题的"两类性（gender / two types）"看起来只是一个无关紧要的叙述设定，其实是**本质性**的。室友问题是一个"同类"问题，它**不一定有稳定匹配**。这解释了为什么任何"稳定匹配一定存在"的证明都**必须**用到两类性——也解释了为什么不能天真地认为"把不稳定对配起来、重复，最终必然稳定"（那个论证如果成立，就能套用到室友问题上，而室友问题会给出反例）。
- **具体示例（$2n=4$ 的反例，脚本已穷举验证）**：四人 A,B,C,D（D 视为"谁都可以"，官方表格中 D 那一行是全破折号）。

人	第 1	第 2	第 3
A	B	C	D
B	C	A	D
C	A	B	D
D	—	—	—

全部 3 种配对方式都会出现不稳定对：

```
配对方式                不稳定对          判定
--------------------------------------------------
{(A,B), (C,D)}         (B,C)            不稳定
{(A,C), (B,D)}         (A,B)            不稳定
{(A,D), (B,C)}         (A,C)            不稳定
--------------------------------------------------
结论：该室友问题实例没有稳定匹配。
（对比：稳定匹配问题中，Gale-Shapley 保证一定存在稳定匹配。）
```

完整证明与推导（核心）

算法完整伪代码

```
算法：PROPOSE-AND-REJECT（男士提出、女士保留的版本）

输入：n 位男士 M = {m_1,...,m_n},
       n 位女士 W = {w_1,...,w_n},
       每位男士 m 的偏好表 pref_m（W 的排列),
       每位女士 w 的偏好表 pref_w（M 的排列)。
输出：一个完美匹配 mu: M -> W。

 1  for each m in M:  next[m] <- 1          # next[m] 指向 m 的下一个申请目标（1-based)
 2  for each m in M:  free[m] <- true       # 是否"手上没有 offer 被保留"
 3  for each w in W:  held[w] <- NIL        # 女士 w 当前手上保留的 offer（来自哪位男士)
 4
 5  while 存在 m 使得 free[m] = true:       # 只要还有人要提申请
 6      # ---------- 上午：提出 ----------
 7      for each m with free[m] = true:
 8          if next[m] <= n:
 9              w <- pref_m[next[m]]        # 名单上最靠前、尚未拒绝过他的女士
10              next[m] <- next[m] + 1
11              m 向 w 提出申请
12
13      # ---------- 下午：保留 / 拒绝 ----------
14      rejected <- 空集
15      for each w in W 收到申请:
16          candidates <- {刚才向 w 申请的男士} ∪ ({held[w]} 若非 NIL)
17          best <- candidates 中在 pref_w 里最靠前的那位
18          for each c in candidates, c != best:
19              rejected <- rejected ∪ {c}          # w 拒绝 c
20          held[w] <- best                          # 保留最好的这一个
21
22      # ---------- 傍晚：划名单 ----------
23      for each m in rejected:
24          free[m] <- true                         # 被拒者明天继续提申请
25          # m 的名单事实上已通过 next[m] 前进而"划掉"了 w
26      for each m not in rejected:
27          free[m] <- false                        # 被保留者明天不再提申请
28
29  # ---------- 终止：某天无人被拒 ----------
30  return mu: for each w in W, mu(held[w]) <- w
```

逐日手算演示（$n = 3$，官方 $n = 3$ 例子；全部数据经脚本复算）

偏好表重抄一遍（越靠左越喜欢)：

```
男士（岗位）偏好                女士（申请者）偏好
------------------------------------------------------------
App : Anita > Bridget > Chris   Anita   : Bas > App > Con
Bas : Bridget > Anita > Chris   Bridget : App > Bas > Con
Con : Anita > Bridget > Chris   Chris   : App > Bas > Con
------------------------------------------------------------
```

```
【第 1 天】
 上午提出: App -> Anita       (App 的第 1 志愿)
           Bas -> Bridget     (Bas 的第 1 志愿)
           Con -> Anita       (Con 的第 1 志愿)
 下午处理:
           Anita 收到 {App, Con}。Anita 偏好 Bas > App > Con,
             两者中她最喜欢 App  => 保留 App, 拒绝 Con。
           Bridget 收到 {Bas}     => 保留 Bas (无人可拒)。
           Chris 收到 {}          => 手上仍为空。
 傍晚划名单: Con 划掉 Anita。
 当前状态: Anita - App (保留)    Bridget - Bas (保留)    Chris -  (空)

【第 2 天】
 上午提出: Con -> Bridget     (Con 划掉 Anita 后的下一个志愿)
 下午处理: Bridget 已有 Bas (保留), 新收到 Con。
           Bridget 偏好 App > Bas > Con, 在 {Bas, Con} 中取 Bas
           => 保留 Bas, 拒绝 Con。
 傍晚划名单: Con 划掉 Bridget。
 当前状态: Anita - App   Bridget - Bas   Chris -  (空)

【第 3 天】
 上午提出: Con -> Chris       (Con 划掉 Anita、Bridget 后的下一个志愿)
 下午处理: Chris 手上为空, 收到 {Con} => 保留 Con。
 傍晚: 本日无人被拒 => **算法终止**。
 当前状态: Anita - App   Bridget - Bas   Chris - Con

【输出匹配】 mu = {(App, Anita), (Bas, Bridget), (Con, Christine)}
【稳定性检验】 脚本穷举全部 6 对 (m,w) 检查, 不稳定对 = 0 个 => 稳定 ✓
【提议总数】 5 次 <= n^2 = 9 ✓
```

第 4 个算例：官方 $n = 4$ 最优性例子（2 天就结束）

```
偏好表: 男士 1,2,3,4; 女士 A,B,C,D
  1 : A > B > C > D        A : 1 > 3 > 2 > 4
  2 : A > D > C > B        B : 4 > 3 > 2 > 1
  3 : A > C > B > D        C : 2 > 3 > 1 > 4
  4 : A > B > C > D        D : 3 > 4 > 2 > 1

【第 1 天】
  上午: 1->A, 2->A, 3->A, 4->A      (四人第 1 志愿全是 A! )
  下午: A 收到 {1,2,3,4}。A 偏好 1 > 3 > 2 > 4
        => 保留 1, 拒绝 2, 3, 4。
  当前状态: A - 1 (保留); B, C, D 手上为空。

【第 2 天】
  上午: 2->D, 3->C, 4->B            (各自划掉 A 后的下一志愿)
  下午: D 收 {2} => 保留 2;  C 收 {3} => 保留 3;  B 收 {4} => 保留 4。
        本日无人被拒 => **终止**。
  输出:  mu = {(1,A), (2,D), (3,C), (4,B)}

【相较】 穷举 24 个完美匹配, 稳定匹配恰好 2 个:
        S = {(1,A),(2,D),(3,C),(4,B)}   <- 算法输出 (岗位最优)
        T = {(1,A),(2,C),(3,D),(4,B)}   <- 申请者最优
        本次提议总数 7 次 <= 4^2 = 16 ✓
        S 与 T 中每个岗位/每位申请者拿到的都是各自在稳定匹配下的最优,
        但注意 S != T, 说明"岗位最优"与"申请者最优"一般不能同时达到。
```

定理 11.1（终止性，Termination）：提出–拒绝算法一定终止。

证明策略：**计数 + 单调性**。算法每一"天"（一轮）若不停机，则当天必有至少一位男士被拒；而每位男士最多被拒 n 次（名单上只有 n 位女士，被拒一次就划掉一个）。所以总拒绝次数 $\le n^2$，轮数 $\le n^2$。

逐步推导：

1. **假设第 d 天算法没有终止。** 按终止条件（某天无人被拒），这说明第 d 天至少有一位男士被拒。
2. 每位被拒的男士，当天傍晚把自己名单上刚被拒的那位女士划掉（代码里是 `next[m]` 前进一位）。
3. 每位男士名单上**总共只有 n 个女士**，所以每位男士**一生最多被拒 n 次**。
4. **所有男士一生最多被拒 $n \cdot n = n^2$ 次。**
5. 而**每运行一天（未终止）至少消耗一次拒绝**。因此算法的天数 $\le n^2$，必然在有限步内终止。■

【证明机制解说】：这个证明是"**有界递减的势函数**"的标准范式。定义势函数 $\Phi =$ "所有男士名单上尚未被拒的女士总数"，则 Φ 初值为 n^2，每轮至少减 1，且永不为负，故只能运行有限轮。这个技巧在算法分析中无处不在（讲次 5 的欧几里得算法终止性用的是同型论证：余数严格递减）。注意这里用的是**弱界**：实际上总提议次数通常远小于 n^2，本讲两个例子分别只用了 5 次和 7 次。

引理 11.2（改进引理，Improvement Lemma）：若某男士 m 在第 k 天向女士 w 提出了申请，则在**此后每一天**（包括第 k 天），w 手上保留的 offer 都来自一位她**至少同样喜欢**于 m 的男士（即 w 手中的对象在偏好序上从不下降）。

证明策略：**对天数 i 做归纳**（$i \geq k$）。这是全讲最关键的引理，后面所有定理都靠它。核心机制是"**offer 不会爆炸**"——女士手上的 offer 只要不被她自己拒掉就会一直保留，所以她的"保底选项"永不消失。

逐步推导：

1. **基础情形（$i = k$）**：第 k 天 w 至少收到了 m 的申请。算法规定 w 在下午"从所有收到的申请（加上手上的）中挑最喜欢的保留"。因此她在第 k 天结束时保留的那位，要么就是 m，要么是一位她比 m 更喜欢的男士。两种情况下她保留下来的都"至少不差于 m" ✓。
2. **归纳假设**：设第 i 天（$i \geq k$）w 手上保留着一位男士 m'，且 m' 在她看来至少不差于 m（形式上 $m' \succ_w m$ 或 $m' = m$）。
3. **归纳步骤（从 i 到 $i+1$）**：
4. 因为 w **没有**拒绝 m'（m' 正是她手上保留的），m' 在第 $i+1$ 天**不会**向别人提申请（代码逻辑：只有被拒者才在下一天继续行动），而是**继续向 w 提出**（offer 不能撤回、也不会过期）。
5. 所以第 $i+1$ 天 w 收到的申请集合中**包含 m'**。
6. 她在下午从"包含 m' 的集合"中挑最喜欢的，故选中的那位至少不差于 m'，从而（由归纳假设）至少不差于 m。
7. 故第 $i+1$ 天 w 手上的对象"至少不差于 m" ✓。
8. 由归纳法，引理对一切 $i \geq k$ 成立。■

（引理的另一个证法：良序原理版） 假设引理不成立，则存在**第一个**反例日 $i > k$，那天 w 手上要么空、要么是一位比 m 差的男士 m^*。看第 $i-1$ 天：她手上有一位 m'，且 m' 至少不差于 m。由"offer 不撤回"，m' 在第 i 天仍然向 w 提出，所以 w 在第 i 天至少有 m' 这个选项，她挑出的最好选项必然至少不差于 m'，从而至少不差于 m，与"是反例日"矛盾。这里的"第一个反例日"之所以存在，正是良序原理；而"存在第一个反例 $\Longrightarrow$ 矛盾"这个推理模式**本质上就是归纳法**——我们证的是 $\neg(\exists i,\, \neg(P(i) \Rightarrow P(i+1)))$，再由排中律得到 $\forall i,\, P(i) \Rightarrow P(i+1)$。

【证明机制解说】：**这是全讲最重要的一条引理**，因为后面三个定理（完美匹配、稳定性、最优性）**全部**只靠它。它的作用是给女士方提供了一个"**不可撤销的保底**"：一旦某位男士向你提过申请，你从此就再也不会拿到比他更差的人。因此女士的幸福度沿时间**单调不减**。反过来，男士的处境沿时间**单调不增**（被拒后名单变短，剩下的选择只会更差）。官方 Note 把这个对称性形容为"两方面从两头向中间靠拢，最终必须相遇"——这个"相遇点"就是稳定匹配。**特别注意"offer 不会爆炸/不能撤回"的作用**：如果允许岗位撤回 offer，w 的保底就会消失，整条链立刻崩塌。

定理 11.3（完美匹配，Perfect Matching）：提出–拒绝算法终止时，每个男士与每位女士都被配上（匹配是完美的）。

证明策略：**反证法**（假设有男士落单，导出"女士数 $<$ 男士数"的计数矛盾），关键工具是引理 11.2。

逐步推导：

1. 反设算法终止时存在一位**单身男士 m**（m 没有任何女士配给他）。
2. 算法终止意味着 m 已经**用完了**自己的名单：他向 n 位女士**全部**提出过申请，并且**全部**被拒绝。（因为算法只有在某位男士被拒后才会让他继续提申请；他能走完整张名单，说明每一位都拒绝了他。）
3. **对这 n 位女士中的每一位 w 使用引理 11.2**：w 拒绝过 m，所以"w 在 m 向她提出的那一天起，手上一直保留着一位至少不差于 m 的男士"。特别地，**在算法终止时**，w 手上的那位男士 $\neq m$（因为 w 若手上有 m，就不会"拒绝"他）。
4. 于是算法终止时，n 位女士**每一位**手上都有一位**不是 m** 的男士。这些男士**两两不同**（一位男士同一时刻只能被一位女士保留），所以至少需要 n 位**除 m 之外**的男士。
5. 加上单身汉 m 自己，男士总数至少是 $n+1$。
6. 但题目假设男士恰好有 n 位，矛盾。
7. 故不存在单身男士。对称地（同构论证）也不存在单身女士，因此输出的是一个**完美匹配**。■

【证明机制解说】：第 3 步是"**引理的杠杆点**"：m 向所有人提过申请**这个事实**，通过引理转化成"n 位女士都手握一个比 m 更好的候选人"**这个更强的结论**。第 4 步的"两两不同"也不可省——一位男士不可能同时被两位女士保留（算法规定他一次只向一位女士提申请，被保留后就不再行动）。**另一种等价说法**：由定理 11.1 知道算法终止时"当天无人被拒"，而若有男士落单他第二天还会提申请（名单未用完），矛盾。这个更简单的论证依赖"名单用完 $\Longrightarrow$ 该男士一定被所有人拒过"这一步，本质上与上面是同一套计数。

定理 11.4（稳定性，Stability）：提出–拒绝算法输出的匹配一定是稳定的。

证明策略：**直接证明 + 反证法**。思路取自官方 Note："**从男士的视角**"证明任何男士都不可能是流氓对的一员。取定最终匹配中的一对 (m, w)，假设 m 更喜欢另一位女士 w^*，只需证 w^* 不愿意跟 m 走（即 w^* 更满意自己的最终对象）——那么 (m, w^*) 就不是流氓对。

逐步推导：

1. 设算法输出的匹配为 μ。任取 μ 中的一对 (m, w)，设 m 在偏好表上更喜欢某位女士 $w^* \neq w$（即 $w^* \succ_m w$）。
2. **m 一定向 w^* 提过申请。** 理由：w^* 在 m 的名单上排在 w **之前**；算法中男士严格按名单**从上往下**提出申请，所以 m 向 w 提出申请之前，必定已经向 w^* 提出过。
3. **对 w^* 使用改进引理（引理 11.2）**：在第 k 天（m 向 w^* 提出申请的那天）之后的每一天，w^* 手上都保留着一位至少不差于 m 的男士。特别地，**在算法终止时**（也就是最终匹配 μ 中），w^* 的配偶 $\mu(w^*)$ 满足

$$\mu(w^*) \succeq_{w^*} m,$$

即 w^* 对最终配偶的喜欢程度**不低于**对 m 的喜欢程度。 4. 因为偏好是**严格**的且 $m \neq \mu(w^*)$（m 已经配给了 w），实际上有 $\mu(w^*) \succ_{w^*} m$，即 w^* **更喜欢**自己的最终配偶，而不愿意跟 m 走。 5. 所以 (m, w^*) **不构成**流氓对。由于 (m, w) 与 w^* 都是任取的，任何男士都不可能参与流氓对。 6. 因此 μ 中不存在流氓对，μ 是稳定匹配。■

【证明机制解说】：证明的"灵光一现"是"**只从一个方向证**"。要证"没有流氓对"，需要排除 $M \times W$ 中所有未配对的组合，工作量看似很大；但官方 Note 指出：**只要从男士视角证明"任何男士都不是流氓对的成员"，整个匹配就稳定了**——因为流氓对必须**同时**包含一位男士和一位女士，男士全部"清白"，就没有流氓对。而"男

士清白"这件事恰好由改进引理一步锁死：**你更喜欢的女士，一定是在你遇到现任之前就遇到过你，而她从此再也不会看上比你差的人。** 这里再次用到了"offer 不能撤回"。

定理 11.5（岗位最优性，Gale–Shapley 定理之一）：提出–拒绝算法（男士提出）输出的匹配是**岗位最优匹配**——即对每位男士 m，他得到的配偶 $w = \mu(m)$ 是在**所有稳定匹配**中 m 能配到的最优对象。等价地：**m 的最优对象就是算法给他的那一位**。

证明策略：先用一条**关键引理**（引理 11.5a，即"拒绝过即永不可能"）把"拒绝"这一事件的**永久后果**锁死，再用**反证法 + 良序原理**完成最优性论证。引理 11.5a 是全部关键，先证它。

引理 11.5a（关键引理："拒绝过 ⟹ 任何稳定匹配中都配不到"）：若女士 w 在算法运行过程中**拒绝过**男士 m，则在**任何**稳定匹配中，w 都不会与 m 配对。

引理 11.5a 的证明（反证法 + 改进引理 + 构造流氓对）：

1. 设 w 在第 k 天拒绝了 m。按算法，第 k 天下午 w 手上保留的是某位男士 $m^\dagger$，满足

$$m^\dagger \succ_w m. \tag{$\star$}$$

（$m^\dagger$ 可能是当天的某位新申请者，也可能是她原来手上那位；无论哪种，她优先于 m。） 2. **由改进引理（引理 11.2）**，从第 k 天起 w 手上的对象只会越来越好，所以算法终止时 w 的最终配偶 $\mu(w)$ 满足

$$\mu(w) \succeq_w m^\dagger \succ_w m. \tag{$\star\star$}$$

也就是说：**w 的最终对象严格优于 m。** 3. 反设存在一个**稳定匹配** S，其中 w 与 m 配对，即 $S(w) = m$。 4. 设 S 中 $m^\dagger$ 的配偶是 $S(m^\dagger) = w'$，即 $\{(m, w), (m^\dagger, w'), \dots\} \subseteq S$。（注意 $w' \neq w$，因为 $S(w) = m$。） 5. **证明 $m^\dagger$ 更喜欢 w 而不是 w'。** 回忆算法中男士严格按名单**从上往下**提出申请，被拒一次就划掉一位。$m^\dagger$ 在第 k 天向 w 提出了申请，说明 w 之前的所有女士**都已经拒绝过** $m^\dagger$。 – 现在问：w' 在 $m^\dagger$ 的名单上排在 w 之前还是之后？ – 反设 $w' \succ_{m^\dagger} w$（w' 排在 w 前面）。那么 $m^\dagger$ 会**先**向 w' 提出申请。若 w' 保留了 $m^\dagger$，则 $m^\dagger$ 就停在 w' 那里、永远不会向 w 提出——与"$m^\dagger$ 在第 k 天向 w 提出"矛盾。若 w' 拒绝了 $m^\dagger$，则由引理 11.5a 的**论证结构本身**（这正是我们要证的引理，但可以在这里用**更弱的形式**：由第 2 步的同类推理，w' 拒绝 $m^\dagger$ 意味着 w' 在算法中的最终对象 $\mu(w') \succ_{w'} m^\dagger$），$w'$ 在任何稳定匹配中都配不到 $m^\dagger$——特别地 $S(w') \neq m^\dagger$，与 $S(m^\dagger) = w'$ 矛盾。 – 两种情况都矛盾，故

$$w \succ_{m^\dagger} w'. \tag{$\dagger$}$$

1. **构造流氓对**：由 $(\star)$ 有 w 更喜欢 $m^\dagger$ 而非 m（她在 S 中的配偶）；由 $(\dagger)$ 有 $m^\dagger$ 更喜欢 w 而非 w'（他在 S 中的配偶）。而 S 中 w 与 m、$m^\dagger$ 与 w' 各自配对。于是 $(m^\dagger, w)$ 是 S 中的**流氓对**，与 S **稳定**矛盾。
2. 故不存在这样的稳定匹配 S，即**凡是拒绝过 m 的女士，在任何稳定匹配中都配不到 m**。■

（引理 11.5a 的绕行证法，避免自引用）：第 5 步中"若 w' 拒绝了 $m^\dagger$"那一支用到了引理自身，属于循环论证。绕开的办法是**改用良序原理做整体反证**：设 (m, w) 是"被 w 拒绝过、却仍出现在某个稳定匹配中"这一现象里**算法天数最早**的一例（第 k 天），则 $m^\dagger$ 在 w 处停留的时间不晚于第 k 天，而对 $m^\dagger$ 与 w' 的同类现象若存在也必须在更早的日子发生（否则 $m^\dagger$ 不会留在 w 处）——与"最早"矛盾。这就是官方 Note 在定理 11.5 与定理 11.2 中反复使用的"**取最早一天 + 良序原理**"的标准手法；具体细节可以按定理 11.5 主证明的第 2、5 步照搬。

引理 11.5a 的直观解读：拒绝是"终局裁决"，不是"暂时搁置"。 一位女士一旦对某位男士说了 no，她的处境从此只会变好（改进引理），所以她永远不可能回过头去觉得"当初其实该接受他"。这是"offer 不能撤回 + 女士总挑最喜欢"两条算法规则的合力。**去掉任何一条，引理立刻失效**——这也是为什么官方 Note 在算法描述里特意强调 *"a job can't withdraw an offer once an offer is made"*。

逐步推导（定理 11.5 主证明）：

1. 反设算法输出的匹配**不是**岗位最优的。那么至少存在一天，某位男士被自己的**最优对象**拒绝了。（若从未发生过这种事，则每位男士最终要么配到自己的最优对象、要么配到比它更好的——但"比最优对象更好"就是"也在某稳定匹配中能配到"，与"最优"的定义矛盾。）
2. **取最早的这样一天，记为第 k 天**（良序原理保证"最早"存在）。在第 k 天，男士 m 被女士 w^*（他的最优对象）拒绝，w^* 转而保留了男士 m^*（即 w^* 更喜欢 m^*）。
3. **w^* 更喜欢 m^***：这是第 k 天的事实——她在 {含 m 的申请集合} 中挑了 m^*，故

$$m^* \succ_{w^*} m. \tag{a}$$

1. **由最优对象的定义**，存在一个**稳定匹配** T，其中 m 与 w^* 配在一起。设 T 中 m^* 的配偶是 w'（即 $\{(m, w^*), (m^*, w'), \dots\} \subseteq T$）。
2. **关键一步：m^* 最喜欢 w^* 至少不差于 w'。** 因为第 k 天是**第一次**有男士被自己的最优对象拒绝，所以在第 k 天之前（含第 k 天之前的所有日子），**m^* 没有**被自己的最优对象拒绝过。而 m^* 在第 k 天向 w^* 提出了申请——这意味着 **w^* 排在 m^* 的最优对象之前或就是它**（男士按名单从上往下提申请，既然他把申请递到了 w^*，说明他此前的所有申请都已被拒，而他的最优对象还没拒绝过他，故最优对象只能是 w^* 或比 w^* 更靠后）。既然 w' 是 m^* 在某个稳定匹配中的配偶，w' 至多只能是 m^* 的最优对象，所以

$$w^* \succeq_{m^*} w'. \tag{b}$$

又因偏好严格且 $w^* \neq w'$（w^* 在 T 中配给 m，而 $m \neq m^*$），实际上 $w^* \succ_{m^*} w'$。 6. **于是 (m^*, w^*) 在 T 中是流氓对**：由 (a) w^* 更喜欢 m^* 而非 m（她在 T 中的配偶），由 (b) m^* 更喜欢 w^* 而非 w'（他在 T 中的配偶）；而且他们在 T 中并未配在一起。这与 T 的**稳定性**矛盾。 7. 矛盾说明第 k 天这样的日子不存在，即算法**从不**让任何男士被自己的最优对象拒绝。由第 1 步的逆否，算法输出的是岗位最优匹配。■

【证明机制解说】：证明有两处关键的"灵光"。 – **第一处**：用良序原理选"**最早**的那一天"。这个"最早"的性质被用在第 5 步——因为此前没有更早的同类事件，m^* 这个"配角"才能被推出"w^* 是他的最优对象或更好"。如果换成"任取一天"，这一步立刻失效。 – **第二处**：把"m^* 在第 k 天向 w^* 提出申请"翻译成"w^* 在 m^* 名单上的位置不劣于其最优对象"。这条翻译依赖男士严格按名单顺序申请这一算法细节。 – **第三处（结构上的）**：证明是"**用自己的算法行为去污染任何声称更优的稳定匹配**"。这是算法最优性证明的经典套路：假定存在一个"更好的"解 T，然后从算法运行轨迹里抠出一对"私奔者"来摧毁 T。

定理 11.6（性别不平等：岗位最优 ⟹ 申请者最差）：若一个匹配是**岗位最优**的，则它同时也是**申请者最差 (candidate-pessimal)** 的。特别地，提出–拒绝算法（男士提出）输出的匹配是申请者最差匹配。

证明策略：**反证法**。设 T 是岗位最优匹配。假设存在另一个稳定匹配 S，其中某位女士 C 配到了比在 T 中**更好**的岗位（即 T 不是申请者最差的），导出 S 不稳定。

逐步推导：

1. 设 T 是岗位最优匹配（由定理 11.5，它就是算法输出）。取 T 中的一对 (J, C)。
2. 反设存在**稳定匹配** S，其中 C 与某个岗位 J^* 配对，且 J^* 在 C 的偏好表上**比 J 更靠前**（即 C 认为 S 比 T 好）。设 S 中 J 的配偶是 C'，即 $\{(J^*, C), (J, C'), \ldots\} \subseteq S$。
3. 由 T 的**岗位最优性**（定理 11.5），岗位 J 在**任何**稳定匹配中能配到的最优对象就是 C。既然 S 也是稳定匹配、J 在 S 中配的是 C'，必有

$$C \succeq_J C',$$

即 J 更喜欢 C 而不是 C'（严格地，$C \succ_J C'$，因为 $C \neq C'$）。 4. 另一方面，由第 2 步的假设，C 更喜欢 J 而不是 J^*：$J \succ_C J^*$。 5. 于是 (J, C) 在 S 中构成**流氓对**：双方都更愿意跟对方在一起，而他们在 S 中并未配对。这与 S **稳定**矛盾。 6. 矛盾说明不存在比 T 中更好的稳定匹配让 C 受益，即 T 使每位女士都拿到她在所有稳定匹配中的最差岗位。故岗位最优匹配一定是申请者最差匹配。■

推论 11.7（岗位最优匹配唯一）：**岗位最优匹配是唯一的**——即"让每位男士都配上自己的最优对象"这个匹配作为一个集合被唯一确定。等价地：提出–拒绝算法输出的那个匹配，是**唯一**的岗位最优匹配。

证明：对每位男士 m，由定义 11.1，他的最优对象 $\mathbf{opt}(m)$ 是**唯一确定**的一位女士（偏好是严格全序，且"在所有稳定匹配中能与 m 配对的最靠前者"这个集合非空——至少算法输出的那个稳定匹配给了一位）。于是映射 $m \mapsto \mathbf{opt}(m)$ 是唯一确定的。由定理 11.5，算法输出 μ 满足 $\mu(m) = \mathbf{opt}(m)$ 对一切 m；任何其他岗位最优匹配 S 也必须满足 $S(m) = \mathbf{opt}(m)$ 对一切 m，故 $S = \mu$（作为 $M \to W$ 的映射完全一致）。**岗位最优匹配唯一** ✓。对称地，**申请者最优匹配也唯一**。■

重要澄清（一个常见的过度推广）：上述唯一性**只**说明"岗位最优"这**一个**稳定匹配唯一，它**不**意味着"每个男士在所有稳定匹配中的配偶都相同"——**后者是错的**。官方 $n = 4$ 例子就是现成的反例：

```
【稳定匹配 S 与 T 中，男士 2 与 3 的配偶不同】

  岗位最优匹配 S = {(1,A), (2,D), (3,C), (4,B)}
  申请者最优匹配 T = {(1,A), (2,C), (3,D), (4,B)}
                        ~~~      ~~~
  岗位 1：S 中配 A，T 中配 A   -> 相同
  岗位 2：S 中配 D，T 中配 C   -> **不同！**
  岗位 3：S 中配 C，T 中配 D   -> **不同！**
  岗位 4：S 中配 B，T 中配 B   -> 相同

  结论：只有"岗位最优"这一个特殊匹配被唯一确定；
        一般的稳定匹配中，同一位男士完全可能拿到不同的配偶。
        正确的不变性质是"稳定匹配集构成一个格 (lattice)"：
        任意两个稳定匹配之间，不存在"男士 2 在 S 更好而在 T 更差、
        同时男士 3 反之"这样的交叉—偏好序在稳定匹配集上是
        同调变化的（S 与 T 的差异是"协调地"转移）。
```

反例（存在多个稳定匹配 + 稳定匹配不唯一）

验证方法论（本讲全部数值算例都用这套脚本复算，可直接运行）：

```
// 保存为 gs.js，用 `node gs.js` 运行
// P：提出方偏好（P[m] = 接收方的有序列表）；Q：接收方偏好（Q[w] = 提出方的有序列表）
// 返回 eng：接收方 -> 提出方 的匹配
function gs(P, Q) {
  const free = Object.keys(P), next = {}, eng = {};
  for (const m of free) next[m] = 0;
  while (free.length) {
    const m = free.shift();                    // 取一位待提出者
    const w = P[m][next[m]++];                 // 向他名单上下一个未拒绝过他的对象提出
    if (!(w in eng)) { eng[w] = m; }           // 对方空手 => 先留住
    else {
      const cur = eng[w];                      // 对方已有现任
      if (Q[w].indexOf(m) < Q[w].indexOf(cur)) { eng[w] = m; free.push(cur); }  // 换人
      else free.push(m);                       // 被拒，明天继续
    }
  }
  return eng;
}

// 稳定性检验：穷举所有未配对的有序对，找流氓对
function rogueCouples(P, Q, eng) {
  const mateOf = {};
  for (const w in eng) mateOf[eng[w]] = w;
  const bad = [];
  for (const m of Object.keys(P))
    for (const w of Object.keys(Q)) {
      if (mateOf[m] === w) continue;                                  // 已配在一起，跳过
      const mWantsW = P[m].indexOf(w) < P[m].indexOf(mateOf[m]);      // 他更想要她
      const wWantsM = Q[w].indexOf(m) < Q[w].indexOf(eng[w]);         // 她也更想要他
      if (mWantsW && wWantsM) bad.push([m, w]);                       // 双向 => 流氓对
    }
  return bad;
}

// 穷举全部完美匹配，筛出所有稳定匹配
function* perms(a) {
  if (a.length <= 1) { yield a; return; }
  for (let i = 0; i < a.length; i++) {
    const rest = a.slice(0, i).concat(a.slice(i + 1));
    for (const p of perms(rest)) yield [a[i], ...p];
  }
}
function allStable(P, Q) {
  const ms = Object.keys(P), ws = Object.keys(Q), S = [];
  for (const p of perms(ws)) {
    const e = {}; ms.forEach((m, i) => e[p[i]] = m);
    if (rogueCouples(P, Q, e).length === 0) S.push(e);
  }
  return S;
}
```

脚本跑出的关键数据（本讲所有数字的来源）：

```
实例                                    GS 输出            天数   提议数   流氓对   稳定匹配数
------------------------------------------------------------------------------------------
官方 n=3 例子                           {Anita:App,
                                         Bridget:Bas,
                                         Christine:Con}       3     5      0        2
官方 n=4 最优性例子                     {(1,A),(2,D),
                                           (3,C),(4,B)}       2     7      0        2
自造 3x3 思考题 Q1 实例                 {(1,b),(2,a),
                                           (3,c)}             5     7      0        1
2x2 反例（男士提出）                    {(1,a),(2,b)}       1     2      0        2
2x2 反例（女士提出，cand->job）         {(1,b),(2,a)}       1     2      0        2
------------------------------------------------------------------------------------------
随机压力测试：n=3 随机偏好表 400 组
   - GS 输出不稳定的次数：0
   - GS 输出非"提出方最优"的次数：0    （与穷举出的所有稳定匹配逐一比对）
   - 存在多于 1 个稳定匹配的实例数：106 / 400（约 27%）
------------------------------------------------------------------------------------------
```

反例 A：2×2 实例，恰有两个稳定匹配。 偏好如下：

男士	第 1	第 2		女士	第 1	第 2
1	a	b		a	2	1
2	b	a		b	1	2

两个完美匹配**都是稳定的**：

- $\mu = \{(1,a),(2,b)\}$：1 拿到第 1 志愿 a，2 拿到第 1 志愿 b。检验未配对的 $(1,b)$：1 的偏好是 $a \succ_1 b$，他**更**喜欢现任 a 而非 b，所以 1 没有动机。检验 $(2,a)$：2 的偏好是 $b \succ_2 a$，他更喜欢现任 b。所以**无流氓对** ✓。
- $\mu' = \{(1,b),(2,a)\}$：检验 $(1,a)$：1 更喜欢 a（$a \succ_1 b$）—— 1 有意愿；但 a 更喜欢 2（$2 \succ_a 1$），a 的现任正是 2，所以 a **不愿意**，$(1,a)$ 不构成流氓对。检验 $(2,b)$：2 更喜欢 b（$b \succ_2 a$）—— 2 有意愿；但 b 更喜欢 1（$1 \succ_b 2$），b 的现任正是 1，所以 b **不愿意**。故**无流氓对** ✓。

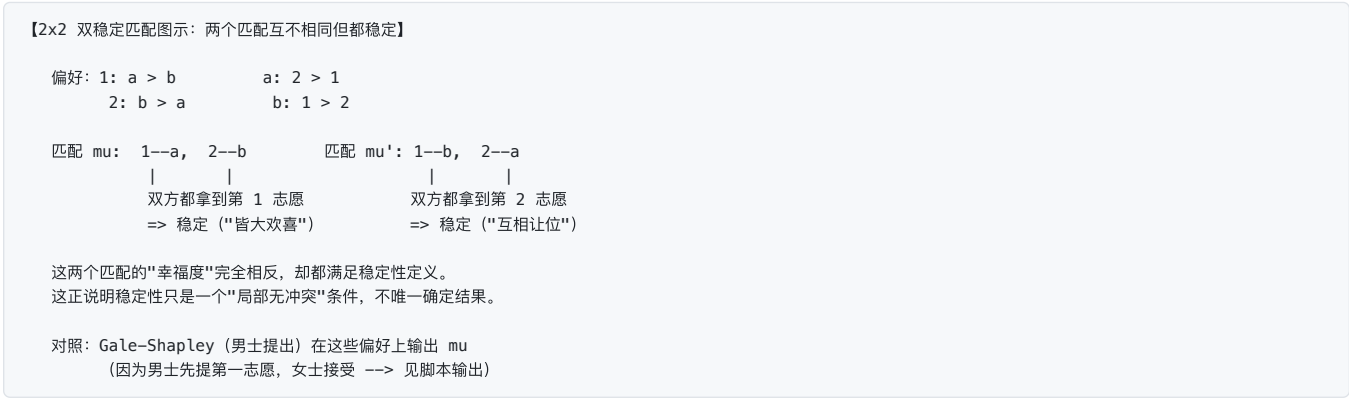

- **脚本穷举确认**：$2! = 2$ 个完美匹配中恰有 2 个稳定匹配，即**两个都稳定**。这直接反驳"稳定匹配唯一"的直觉。
- **另一层的反例**：官方 $n = 4$ 例子与 $n = 3$ 官方例子也都各有**两个**稳定匹配（脚本穷举 $4! = 24$、$3! = 6$ 逐一验证）：
- $n = 3$：$\{(App, Anita), (Bas, Bridget), (Con, Christine)\}$ 与 $\{(App, Bridget), (Bas, Anita), (Con, Christine)\}$。
- $n = 4$：$\{(1,A),(2,D),(3,C),(4,B)\}$ 与 $\{(1,A),(2,C),(3,D),(4,B)\}$。

反例 B：室友问题（同类配对）可能完全没有稳定匹配。 见"核心概念的直观解释"中的四人表格，3 种配对全都不稳定。**这告诉我们：稳定匹配的存在性证明必须用到"两类对象"这一结构**——Gale–Shapley 算法恰恰是一个构造性的存在性证明，但它对室友问题无从下手（因为没有"提出方/接收方"的划分）。

反例 C：天真算法"迭代地配好流氓对"不终止/不收敛。 若从任意匹配出发，发现流氓对就把它们配到一起、重复，直觉上"流氓对数量会减少"。但这是**错误的**：配好一对会**打散**原来两对，可能**创造出新的**流氓对。官方 Note 通过室友问题这个反例说明这个推理不可靠（因为在室友问题上，若该推理有效就会推出"室友问题总有稳定解"，而事实相反）。在稳定匹配问题上，这条路径也**不能**用来说明存在性——正确路线是 Gale–Shapley。

与经典问题的联系

（1）住院医师匹配（The Residency Match）：本讲最真实的落地案例。 20 世纪初，美国医学住院医师项目（residency programs）成为医院廉价劳动力的来源，岗位数逐渐超过毕业生数，竞争激烈。医院竞相**提前发 offer**：到 1940 年代中期，offer 已经提前到医学院**三年级**，有的医院甚至考虑发给**二年级**学生。美国医学会 (AMA) 出手禁止医学院在四年级前公布成绩单与推荐信。结果医院改用"**短引信 offer (short fuse offer)**"——只给学生**几小时**决定，以便被拒后还能找替补。这种恶性竞争最终促成了 1950 年代初的**全国住院医师匹配计划 (National Residency Matching Program, NRMP)**：医院给住院医师排序、住院医师给医院排序，由中心化系统统一配对。

关键细节：NRMP 最初用的配对**并不稳定**；**直到 1952 年**才换用提出–拒绝算法，从此产出稳定匹配。这是一个"**用数学建模修正制度缺陷**"的经典案例。2012 年，Lloyd Shapley 与 Alvin Roth 因把提出–拒绝算法推广到更复杂的市场设计（包括医学院匹配、肾移植配对、公立学校择校）而获得**诺贝尔经济学奖**。某种意义上，Roth 的核心贡献正是**实证地论证稳定性是市场能长期存活的关键**：不稳定的匹配系统会被参与者"用脚投票"（撕毁 offer、私下另谈）而崩溃。

（2）问题的严格形式化（把现实搬到数学里）：n 家医院 $\leftrightarrow W$（接收方），n 位申请者 $\leftrightarrow M$（提出方），医院对申请者的偏好 $\succ_w$ 来自笔试/面试评分，申请者对医院的偏好 $\succ_m$ 来自地理位置/声誉/薪资。**完整性假设**：每个人对所有异性都有严格偏好序（不允许"我只想去某几家"）。这在现实中并不总是成立（有人宁可不去任何医院也不去某家差的医院），但 CS70 的模型做了这个简化——这是本讲模型的一个**已知局限**。

（3）临床心理学中的"匹配"（The Match）与稳定的实际价值。在 NRMP 里，稳定性意味着**任何一对学生–医院都不会同时后悔**。如果匹配不稳定，学生 A 和医院 H 会私下谈成协议，导致另一个学生被"挤出"、另一个岗位空缺——市场出现"震荡"。稳定性恰恰消除了这种震荡。因此 NRMP 的匹配结果一旦公布，参与者**没有动机去违反**。这就是官方 Note 强调的 "we want everyone to be happy enough that they all want to follow through on their final accepted offers."

（4）谁提出，谁占优：制度设计的伦理含义（本讲最重要的现实教训）。 定理 11.5 与 11.6 合起来说的是：**提出方拿到所有稳定匹配中最好的结果，接收方拿到最差的**。因此 NRMP 的制度史就有了深刻含义： – **直到 1990 年代之前**，NRMP 一直是**医院提出**——于是匹配结果是**医院最优**（医院得利、学生吃亏）。 – **1990 年代角色反转**，改为**学生提出**——于是匹配结果变成**学生最优**。 – 官方 Note 特别点出一个**次序性教训**：角色反转之所以可能，**正是因为整套流程早已在计算机内部运行**——现实世界里让医院"不占优"的制度根本不可能被采纳（医院谈判力远强于学生）。所以**先让自动化匹配系统上线、再在系统内部反转角色**，是唯一可行的改良路径。官方 Note 的原话大意是：一个非医院最优的自动匹配系统在当初根本不会被采用，那样的话"实习生最优"就永远只是空想。

（5）其他应用：Sperner 引理/校园择校（school choice，纽约、波士顿公立学校择校系统在 2000 年代改用学生提出的延迟接受算法）、肾脏交换（kidney exchange，Roth 团队）、以及更一般的"**延迟接受 (Deferred Acceptance)**"框架。所有这些都是 Gale–Shapley 的直接后代。

（6）算法复杂度与现实规模。算法最坏情况 $O(n^2)$ 次提议，对 NRMP 的规模（每年约 4 万申请者、数千个项目，规模不对称——属于"多对一"的医院/申请者模型，是 Gale–Shapley 的直接推广）完全可以秒解。这也解释了为什么这个 1962 年的算法至今仍在生产环境中服役。

与其他讲次的关联

- **讲次 2（Proof Techniques II，反证/逆否/分情形）**：本讲的三大证明（完美匹配、稳定性、最优性）**全部是反证法**，尤其是最优性证明（定理 11.5）的最干净写法就是"反设算法不是最优 $\Rightarrow$ 存在最早的被拒日 k $\Rightarrow$ 用最早性推出 m^* 的最优对象位置 $\Rightarrow$ 在 T 中构造出流氓对 $\Rightarrow$ 矛盾"。这是讲次 2 的反证法在算法领域最漂亮的范例。

- **讲次 3（Induction，归纳法与强归纳）+ 良序原理**：**改进引理（引理 11.2）是对"天数"的归纳**，是全讲的技术支柱；官方 Note 还给出了它的**良序原理版证明**，并明确指出"良序原理 $\iff$ 归纳法"，反证法里的 "first counterexample" 正是良序原理的直接应用。本讲的定理 11.5 也是"良序原理 + 归纳"的混合体。
- **讲次 9（Graphs，图论基础）与讲次 10（Graphs II）**：稳定匹配问题的实例天然是**完全二分图 $K_{n,n}$ 加边上的偏好序**；"匹配"就是讲次 9 的匹配概念，"完美匹配"要求每个顶点度数为 1 的边覆盖全部顶点。讲次 10 的二分图语言与 $E \le 2V-4$ 之类结论虽不直接用于本讲，但为讨论"匹配存在性"提供了图形直觉。
- **讲次 14（Counting，计数）**：完美匹配总数为 $n!$（男士的 n 个配偶的全排列），本讲脚本对 $n=4$ 穷举 24 个、对 $n=3$ 穷举 6 个来寻找全部稳定匹配；"总提议次数 $\le n^2$"也是简单的计数上界。$n!$ 与 n^2 的对比（指数级搜索空间 vs 平方级算法）是"算法为何重要"的最直观教材。
- **讲次 20（Expectations & Linearity，期望与线性性）**：一个经典后续问题是"Gale–Shapley 的期望提议次数是多少"（随机偏好模型下约为 $n \ln n$），其分析正是期望线性性的应用——这是 CS70 概率部分与稳定匹配的一个自然接口。
- **讲次 26（Markov Chains & Conditional Expectation，马尔可夫链与条件期望）**：延迟接受算法可以被看成"状态 = 当前保留关系"的确定性/随机过程；对随机偏好下的匹配过程做马尔可夫分析，会用到讲次 26 的工具。
- **讲次 5（Euclid, FLT, CRT）**："**势函数每轮严格递减 $\Rightarrow$ 有限步终止**"这一终止性证明模板，与本讲终止性证明（定理 11.1）完全同型：欧几里得算法用余数递减，本讲用"未拒绝的名单项数"递减。

关键要点

1. **稳定性 = 无流氓对**：不存在未配对的 (m, w) 使双方都更愿意跟对方在一起。注意是**双向**条件——只要一方不愿意，就不构成不稳定。稳定性不唯一确定匹配：同一组偏好可以有**多个**稳定匹配。
2. **Gale–Shapley 三条基本性质**：① 一定终止（每轮至少一次拒绝，总提议数 $\le n^2$）；② 终止时是**完美匹配**（否则男士数 $\ge n+1$，矛盾）；③ 输出**稳定匹配**（由改进引理，从男士视角出发一步锁死）。
3. **改进引理是全讲的枢纽**：一旦男士 m 向女士 w 提过申请，w 此后手上的 offer **永不差于** m。它成立的物理基础是"**offer 不会爆炸、不能被撤回**"。完美匹配、稳定性、最优性三个定理**全部**只用它。
4. **Gale–Shapley 定理（最优性）**：提出方拿到**所有稳定匹配中最好的对象**（岗位最优 / 男士最优），接收方拿到**最差的**（申请者最差）。**谁提出，谁得利。** 想让申请者占优，就把算法改成申请者提出。
5. **良序原理 = 归纳法的孪生兄弟**：反证时"取第一个反例"之所以合法，靠的是 $\mathbb{N}$ 的良序性。定理 11.5 的"取最早的被拒日 k"是整个证明的关键支点，去掉"最早"证明就断。
6. **两类性不可省**：室友问题（同类配对）可以没有稳定匹配（四人反例，3 种配对全不稳定）。所以任何"稳定匹配必存在"的证明都必须用到"男士/女士两类"的结构。

常见误区与注意事项

1. **把"稳定"误解为"幸福"**。稳定匹配**不**保证大家都拿到第一志愿。官方 $n=3$ 例子的稳定匹配里，Control Corp. 和 Christine 都配到了自己的**最后志愿**，但仍是稳定的——因为那些他们更喜欢的对象都不愿意要他们。稳定性是"**没有共同改善空间**"，不是"人人满意"。
2. **忘记稳定性是双向的**。检验 (m, w) 是否流氓对时**必须同时**看两边。官方 $n=3$ 的稳定匹配里，App 明明更喜欢 Anita，但 Anita 已经配了第一志愿 Bas，不愿换——所以不是流氓对。
3. **把必要条件当充分条件（最优性方向）**。"m 在算法中得到了对象 w"不意味着"m 的第一志愿 w^* 也可以配给他"。存在**任何**稳定匹配都配不到的组合（$n=4$ 例中岗位 2 与 A 就配不到，"最优对象"必须**在所有稳定匹配的范围内**取，而不是在整张偏好表上取）。
4. **声称"稳定匹配唯一"**。2×2、$n=3$、$n=4$ 三个例子都各有**两个**稳定匹配（脚本穷举确认）。同时也要小心相反的错误：**不是**所有稳定匹配都对双方同等好——岗位最优匹配与申请者最优匹配在 $n=4$ 例中是不同的两个匹配（$S \neq T$）。
5. **忽视偏好严格性**。若允许"并列"（弱偏好序），"男士最优匹配中每位男士的配偶唯一确定"就未必成立，稳定性定义也需要修正为"不存在双方都觉得对方**严格更好**的对"。CS70 模型里偏好是严格全序，别把它当小事。
6. **搞错算法细节导致证明失效**。三个具体细节都不能改：① 男士必须**严格按名单从上往下**提申请（稳定性证明与最优性证明都依赖它）；② 女士手上的 offer **不能撤回、不会过期**（改进引理依赖它）；③ 女士必须**保留最喜欢的那个**而不是先到先得（否则改进引理不成立）。把任一条改掉，本讲的结论都可能崩。
7. **误用"迭代配好流氓对"来证明存在性**。这个天真算法的推理不成立：配好一对会打散两对，可能**创造新的**流氓对，不能保证单调改善。官方用室友问题这个反例说明该推理不可靠（它若成立会推出室友问题总有稳定解，而事实相反）。

思考题（带答案）

Q1（纯计算题）：对下面这个 $n=3$ 实例，手算 Gale–Shapley（男士提出）的逐日过程，给出最终匹配、总提议次数，并验证稳定性。

男士	第 1	第 2	第 3		女士	第 1	第 2	第 3
1	a	b	c		a	2	1	3
2	b	a	c		b	1	3	2
3	a	b	c		c	1	2	3

▸ 答案

第 1 天：上午 `1->a`、`2->b`、`3->a`（每人都是第 1 志愿）。 下午：a 收到 $\{1,3\}$，按 a 的偏好 $2 \succ_a 1 \succ_a 3$，两者中更喜欢 1，故**保留 1，拒绝 3**；b 收到 $\{2\}$，保留 2；c 手上为空。 傍晚：3 划掉 a。

第 2 天：只有被拒的 3 行动：`3->b`（3 的第 2 志愿）。被保留的 1、2 不行动。 下午：b 已有 2，新收 3；b 的偏好 $1 \succ_b 3 \succ_b 2$，在 $\{2,3\}$ 中更喜欢 3，故**保留 3，拒绝 2**。 傍晚：2 划掉 b。

第 3 天：只有 2 行动：`2->a`（2 的第 2 志愿）。 下午：a 已有 1，新收 2；a 的偏好 $2 \succ_a 1 \succ_a 3$，在 $\{1,2\}$ 中更喜欢 2，故**保留 2，拒绝 1**。 傍晚：1 划掉 a。

第 4 天：只有 1 行动：`1->b`（1 的第 2 志愿）。 下午：b 已有 3，新收 1；b 的偏好 $1 \succ_b 3 \succ_b 2$，在 $\{1,3\}$ 中更喜欢 1，故**保留 1，拒绝 3**。 傍晚：3 划掉 b。

第 5 天：只有 3 行动：`3->c`（3 的第 3 志愿）。 下午：c 手上为空，收到 $\{3\}$，保留 3。本日**无人被拒 ⇒ 终止**。

```
【逐日状态表（脚本复算，完全一致）】

天  上午提出              下午保留结果              当日被拒
------------------------------------------------------------
1   1->a, 2->b, 3->a    a:1  b:2  c:-            3
2   3->b                a:1  b:3  c:-            2
3   2->a                a:2  b:3  c:-            1
4   1->b                a:2  b:1  c:-            3
5   3->c                a:2  b:1  c:3             (无人被拒 => 终止)
------------------------------------------------------------
输出 mu = {a-2, b-1, c-3}   即 {(1,b), (2,a), (3,c)}
```

输出匹配：$\mu = \{(1,b),(2,a),(3,c)\}$。 **总提议次数**：$3+1+1+1+1 = 7$ 次 $\le n^2 = 9$ ✓。 **天数**：5 天。

稳定性验证（穷举 $3 \times 3 = 9$ 个有序对，只需检查未配对的 6 对）： – $(1,a)$：1 更喜欢 a（$a \succ_1 b$）；但 a 的现任是 2，且 $2 \succ_a 1$，a 不愿意 ⇒ 非流氓对。 – $(1,c)$：1 更喜欢自己的现任 b，不算。 – $(2,b)$：2 更喜欢 b（$b \succ_2 a$）；但 b 的现任是 1，且 $1 \succ_b 3 \succ_b 2$，b 不愿意 ⇒ 非流氓对。 – $(2,c)$：2 更喜欢 a，不算。 – $(3,a)$：3 更喜欢 a（$a \succ_3 b \succ_3 c$）；但 a 更喜欢 2，不愿意 ⇒ 非流氓对。 – $(3,b)$：3 更喜欢 b；但 b 更喜欢 1，不愿意 ⇒ 非流氓对。

无一构成流氓对 ⇒ μ 稳定 ✓。

值得注意的两点： 1. 男士 1 更想跟 a（他的第 1 志愿），但 a 更喜欢 2——所以 1 只能拿第 2 志愿。这是"最优对象 $\neq$ 第一志愿"的又一例证。 2. 这个实例**只有唯一一个稳定匹配**（脚本穷举 $3! = 6$ 个完美匹配，稳定者恰 1 个）。对照组：官方 $n = 3$ 例子有 2 个、2×2 反例也有 2 个——**稳定匹配的数量取决于偏好表，可以是 1 也可以是多个**。

脚本验算结果：`final {"a":"2","b":"1","c":"3"}`（即 1–b, 2–a, 3–c），5 天，总提议 7 次，不稳定对 0 个，稳定匹配数 1。与本手算完全一致。

Q2（概念/证明题）：请完整证明**改进引理**，并说明如果允许"岗位在发出 offer 后可以撤回"，该引理的哪一步会失效、后续哪个定理首先崩掉。

▸ 答案

引理陈述：若男士 m 在第 k 天向女士 w 提出申请，则对每个 $i \ge k$，第 i 天结束时 w 手上保留的 offer 来自一位她至少不差于 m 的男士。

证明（对 i 做归纳）：

- **基础情形 $i = k$**：w 当天至少收到 m 的申请；她在下午"从全部候选（收到的 + 手上的）中挑最喜欢的一个"。故选中的那位至少不差于 m ✓。
- **归纳假设**：第 i 天结束时 w 手上保留着 m'，且 m' 至少不差于 m。
- **归纳步骤**：m' 未被 w 拒绝，所以在第 $i+1$ 天**不会**另投他人，而是**继续向 w 提出**。于是 w 在第 $i+1$ 天的候选集合中包含 m'；她挑最喜欢的一个，结果至少不差于 m'，由归纳假设至少不差于 m ✓。
- 由归纳法，$\forall i \ge k$ 成立。■

若允许岗位撤回 offer：失效的是**归纳步骤**——"m' 在第 $i+1$ 天**仍然**向 w 提出"这一步不再成立。m' 可能因为自己找到了更好的候选人而撤回。这样 w 的候选集合中可能不再含有 m'，她的保底消失，w 手上对象就可能变得**比 m 差**，引理立刻崩掉。

崩掉的连锁反应（按依赖顺序）： 1. **首先崩的是定理 11.4（稳定性）**：它的证明第 3 步"对 w^* 使用改进引理"直接依赖引理，引理没了，证明断链。事实上可以构造出"允许撤回 ⟹ 输出不稳定"的例子（在 $n = 3$ 官方例子上，若医院 App 被 Bas 拒绝后撤回对 Anita 的 offer，结果可能改变）。 2. **接着崩的是定理 11.3（完美匹配）**：其证明同样依赖引理把"m 被所有人拒过"转化成"n 位女士都握着别人"。 3. **再崩定理 11.5（最优性）**：它靠"m^* 更想 w^*"这一步推理，其中用到 m^* 的最优对象判断，间接依赖引理。

所以"offer 不会爆炸"（no exploding offers）看起来是个工程细节，实际上是整个理论的承重墙。 这也正是官方 Note 在算法描述里特意加括号强调 "This is just a way for us to virtually model that there are no 'exploding offers' and a job can't withdraw an offer once an offer is made." 的原因——现实中的 NRMP 制度之所以必须禁止"短引信 offer"，数学上的理由就在这里。

Q3（概念/反例题）：请给出一个 2×2 的例子说明"稳定匹配不唯一"，并回答：在这个例子里，男士提出的 Gale–Shapley 与女士提出的 Gale–Shapley 分别输出哪个匹配？这印证了本讲哪一条定理？

▸ 答案

实例（偏好表）：

男士	第 1	第 2		女士	第 1	第 2
1	a	b		a	2	1
2	b	a		b	1	2

两个完美匹配都稳定（穷举 $2! = 2$ 个，稳定性检验均通过）：

- $\mu = \{(1,a),(2,b)\}$：1 拿到第 1 志愿、2 拿到第 1 志愿 ⇒ 无人有动机离开 ⇒ 稳定。
- $\mu' = \{(1,b),(2,a)\}$：双方都拿到第 2 志愿。检验 $(1,a)$：1 更愿意，但 a 更喜欢 2（$2 \succ_a 1$），不愿换 ⇒ 非流氓对。检验 $(2,b)$：2 更愿意，但 b 更喜欢 1（$1 \succ_b 2$），不愿换 ⇒ 非流氓对。故**稳定** ✓。

男士提出的 GS：第 1 天 `1->a`、`2->b`，a 收 $\{1\}$ 保留 1、b 收 $\{2\}$ 保留 2，**无人被拒 ⇒ 终止**，输出 $\mu = \{(1,a),(2,b)\}$。 **女士提出的 GS**（把角色对调，女士提出、男士保留）：第 1 天 `a->2`、`b->1`，双方直接被接受，输出 $\mu'' = \{(1,b),(2,a)\}$，正是 μ'。

印证的定理： – **定理 11.5（岗位最优性）**：男士提出时输出 μ，每个男士都拿到自己在两个稳定匹配中的**最优**对象（1 在 μ 中拿到 a、在 μ' 中只能拿 b，故 a 更优；2 同理）。✓ – **定理 11.6（岗位最优 ⟹ 申请者最差）**：μ 中 a 拿到 1、而 a 的最优岗位是 2（在 μ' 中），所以 μ 对女士确实**最差**；反之女士提出输出的 μ' 对男士最差。✓ – **同时印证"稳定匹配可以不唯一"**（本讲反例 A）：同一组偏好下有 2 个稳定匹配，"谁提出"决定了算法落在哪一个。

一句话总结：稳定匹配集合可能有多个元素，而 Gale–Shapley **不是随机地**选一个——它系统性地落到"**对提出方最有利**"的那一端。

脚本验算：男士提出 → `{"a":"1","b":"2"}`；女士提出 → `{"1":"b","2":"a"}`；穷举 2 个匹配，稳定匹配数 = 2。

Q4（进阶/易错点）：（判断题）"若某位男士 m 在算法结束时配到了女士 w，则 w 就是 m 偏好表上的第一志愿，或者 m 的第一志愿把 m 拒绝过。" 请判断并说明。

▸ 答案

正确。 这两条正好穷尽了所有可能。

论证：设 m 的第一志愿是 w_1（即 w_1 在 m 的名单上排第 1）。

- 若 m 最终配到 w_1，则第一种情况成立。
- 若 m 最终配到的 $w \neq w_1$，则由改进引理（引理 11.2）：m **一定**向 w_1 提过申请（男士按名单从上往下提，w_1 是第一个，只要 m 被配到别的女士，m 必然已经走过 w_1），而在算法终止时 m 配给 w 说明 w_1 **没有**保留 m（否则 m 就永远停在 w_1 那里了），即 w_1 **拒绝过** m。第二种情况成立。

所以命题为真。**更有力的推论**：由本讲定理 11.4 的证明机制可以推得更强的事实——m 最终配到的 w **不是"第一志愿"**时，w_1 **"最终手上有比 m 更好的人"**（改进引理），这也解释了为什么 m 拿不到 w_1 不是"算法不好"，而是稳定性本身的硬约束：把 m 与 w_1 硬配会制造出流氓对。

注意易错点：不要把命题反过来问成"若 w_1 拒绝过 m，则 m 一定配不到 w_1"——**这个也成立**（拒绝意味着 w_1 的最终对象不差于 m，且严格更好，因为 m 最终配给了别人），但它是**另一条命题**，证明需要走改进引理 + 终止时 w_1 手上的对象 $\neq m$。这条看似更强的命题其实就是 Q2 讨论的"w 拒绝过 m ⟹ 任何稳定匹配中 w 都配不到 m"这一关键引理的一个特例，它也是最优性论证的核心。

Lecture 12: Countability（可数性）

概述

本讲回答一个听上去像哲学、实际上是计算机科学地基的问题：**无穷也有大小之分吗？** 答案是肯定的，而且这个区分恰恰决定了一门学科的存在性——如果所有无穷都一样大，那么"存在无法被任何程序解决的问题"这句话就无从谈起。我们先把"两个集合一样大"这件事严格定义为**存在双射 (bijection)**，然后证明 $\mathbb{N}$、$\mathbb{Z}$、$\mathbb{N}\times\mathbb{N}$、$\mathbb{Q}$、$\{0,1\}^*$、$\mathbb{N}[x]$ 全都一样大（都是**可数 (countable)** 的），而 $\mathbb{R}$、$\mathcal{P}(\mathbb{N})$ 严格更大（**不可数 (uncountable)**）。关键的技巧只有一个：**对角线论证 (diagonalization)**。它在本讲打倒实数，在下一讲（Lecture 13）会以完全相同的手势打倒一切通用停机判定程序。

本讲是 Fall 2026 序列中「极限与不可能」模块（L12–L13）的第一讲，紧接在图与匹配（L09–L11）之后；它是一个转折点——此前所有讲次都在教"怎么证明某件事成立"，从本讲开始我们学习"怎么证明某件事**不可能**成立"。

核心概念的直观解释

基数 (Cardinality, $|A|$)

- **定义**：集合 A 的基数 $|A|$ 是它的"元素个数"。对有限集，$|A|$ 就是一个自然数；对无限集，$|A|$ 是一个**无穷基数**（本讲只区分"可数"与"不可数"两档，并证明 $\mathcal{P}(A)$ 总比 A 高一档）。
- **直观解释（"它是什么意思？"）**：基数是"衡量集合大小"的尺子。麻烦在于，量有限集时我们可以真的去数，量无限集时"数到完"这个动作永远做不完。所以我们需要一把**不需要数完就能比较**的尺子——这就是双射。它的思想来自幼儿园：两个班里谁的人多？不必点名报数，让两个班的小朋友两两牵手，牵完之后若没人落单，就是一样多。
- **具体示例**：$A = \{a,b,c\}$ 与 $B = \{1,2,3\}$ 之间可以建立 $a \leftrightarrow 1$、$b \leftrightarrow 2$、$c \leftrightarrow 3$，所以 $|A| = |B| = 3$。而 $A = \{a,b,c\}$ 与 $B = \{1,2\}$ 之间无论怎么牵，A 里总有一个人落单，所以 $|A| > |B|$。

单射 (Injection/One-to-one)、满射 (Surjection/Onto)、双射 (Bijection)

- **定义**：设 $f: A \to B$ 是函数（A 叫**定义域 (domain)**，B 叫**陪域/范围 (range)**）。
- f 是**单射**：不同输入给不同输出，即 $x \neq y \Rightarrow f(x) \neq f(y)$；等价地 $f(x) = f(y) \Rightarrow x = y$。
- f 是**满射**：B 中每个元素都被打到，即 $(\forall y \in B)(\exists x \in A)\, f(x) = y$。
- f 是**双射**：既是单射又是满射。
- **直观解释**：单射 = "不撞车"（没有两个输入共享一个输出）；满射 = "全覆盖"（输出端没有漏掉的元素）；双射 = "完美配对"（一一对应）。这三者的关系可以用三个小图刻在脑子里：

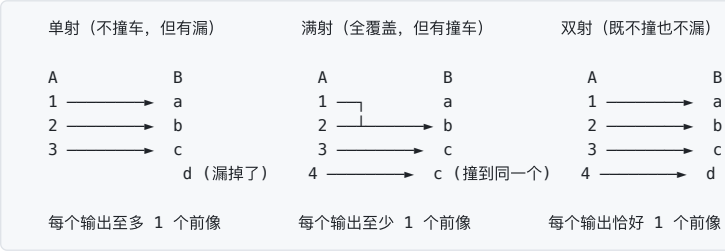

- **具体示例**：$f: \{1,2,3\} \to \{a,b,c,d\}$，$1 \mapsto a, 2 \mapsto b, 3 \mapsto c$ 是单射但不是满射（d 没人映射过来）。$g: \{1,2,3,4\} \to \{a,b,c\}$，$1 \mapsto a, 2 \mapsto b, 3 \mapsto c, 4 \mapsto c$ 是满射但不是单射（c 被撞了两次）。$h: \{1,2,3\} \to \{a,b,c\}$ 恒等配对才是双射。注意一个有限集上的铁律：若 $|A| = |B|$ 有限，则"单射 $\iff$ 满射 $\iff$ 双射"；**但这条铁律对无限集失效**，这正是本讲所有反直觉现象的根源。

等势 (Same cardinality)

- **定义**：$|A| = |B|$ **当且仅当**存在一个双射 $f: A \to B$。
- **直观解释（"它是什么意思？"）**：这是我们给无穷集量身定制的"大小相等"定义。为什么不能用"包含关系"来定义大小？因为我们被迫二选一：要么接受一个会导致自相矛盾的"大小"概念，要么接受"真子集可以和自己一样大"。数学选择了后者，因为它逻辑上完全自洽。类比：一盏灯每隔一半时间闪一次——$[0,1]$ 秒内闪了无穷多次，但闪的次数和 $[0,2]$ 秒内闪的次数是"一样多"的（都是可数无穷），尽管第二个时间段在时间长度上是第一个的两倍。**"多"这个词用在无穷上时，必须换成"能否配对"。**
- **具体示例**：$\mathbb{N} \subsetneq \mathbb{Z}$（$\mathbb{Z}$ 多了所有负数和更"多"的符号），但我们马上会给出一个显式双射，所以 $|\mathbb{N}| = |\mathbb{Z}|$。

可数集 (Countable set)

- **定义**：集合 S 是**可数**的，若 S 是有限集，或存在双射 $f: S \to \mathbb{N}$（等价地：存在双射 $f: \mathbb{N} \to S$，也等价地：可以把 S 的元素排成一个序列 $a_0, a_1, a_2, \ldots$，使每个元素恰好出现一次）。
- **直观解释**："可数"的字面意思是"**能被自然数编号**"，而不是"能被数完"。S 可数 $\iff$ 我们可以给 S 中每个元素贴上一个独一无二的门牌号 $0, 1, 2, 3, \ldots$，既不重号也不漏号。想象一个无限长的寄存柜走廊，每个柜子有一个编号；S 可数就是说 S 的元素恰好能一个萝卜一个坑地塞满这排柜子。
- **具体示例**：$\{a,b,c\}$ 可数（有限，$|S| = 3$，与 $\{0,1,2\}$ 双射）；$\mathbb{N}$ 可数（恒等映射 $f(n) = n$）；$\mathbb{Z}$ 可数（马上给公式）；$\mathbb{R}$ 不可数（本讲后半段证明）。

> **重要澄清**：**可数 $\neq$ 有限**。$\mathbb{N}$ 是无限集，但它是可数的（最标准的可数集）。「可数」的反面是「不可数」，不是「无限」。同时注意 CS70 采用的这个定义把有限集也算作可数——这和某些教材把"可数"专指"可数无限"（countably infinite）不同，读英文材料时留意。

两种证明"等势"的策略

- **定义/事实**：设 A, B 是集合。
- 若存在单射 $f: A \to B$，则 $|A| \leq |B|$。
- **Cantor–Bernstein 定理 (Cantor–Bernstein Theorem)**：若 $|A| \leq |B|$ 且 $|B| \leq |A|$（即存在两个方向的单射），则存在双射 $h: A \to B$，即 $|A| = |B|$。该定理的证明技巧性较强，CS70 只引用不证。
- **直观解释**：这是一条极其实用的"夹逼"路线。直接造双射有时很难（因为要同时保证不撞车和全覆盖），但造两个单射往往容易得多（每个单射只需管一件事）。于是标准套路变成：**先证 $|A| \leq |B|$，再证 $|B| \leq |A|$，收工。** 我们在证明 $|\mathbb{Q}| = |\mathbb{N}|$ 时正是这么做的（$|\mathbb{N}| \leq |\mathbb{Q}|$ 因为 $\mathbb{N} \subseteq \mathbb{Q}$ 是平凡的；难的只有 $|\mathbb{Q}| \leq |\mathbb{N}|$）。
- **具体示例**：要证 $|\mathbb{Q}| = |\mathbb{N}|$，只需造一个单射 $\mathbb{Q} \to \mathbb{N}$；$\mathbb{N} \to \mathbb{Q}$ 的恒等嵌入自动给出反向单射。这正是下面定理 12.4 的做法。

完整证明与推导（核心）

定理 12.1：$|\mathbb{N}| = |\mathbb{Z}|$。也就是说，尽管 $\mathbb{Z}$ 比 $\mathbb{N}$ 多出无穷多个负数，二者**一样大**。

证明策略：构造性证明。我们不去数，而是直接写出一个 $f: \mathbb{N} \to \mathbb{Z}$，然后分别验证它单射、满射。这个证明的价值在于它示范了无穷基数比较的标准流程：**写出公式 → 验证单射 → 验证满射 → 引用定义得等势**。选这个策略是因为公式可以显式写出，而显式双射是最强的"等势证书"。

逐步推导：

第一步（构造）：定义 $f: \mathbb{N} \to \mathbb{Z}$ 为

$$f(x) = \begin{cases} \dfrac{x}{2}, & x \text{ 为偶数} \\ -\dfrac{x+1}{2}, & x \text{ 为奇数} \end{cases}$$

用列举的方式看它就是

$$0 \mapsto 0, \quad 1 \mapsto -1, \quad 2 \mapsto 1, \quad 3 \mapsto -2, \quad 4 \mapsto 2, \quad 5 \mapsto -3, \quad 6 \mapsto 3, \dots$$

直观上就是"从 0 出发左右横跳"：$0, 1, -1, 2, -2, 3, -3, \dots$。注意 $f(124) = 62$（124 偶数，$124/2 = 62$）。

第二步（验证单射）：设 $f(x) = f(y)$。观察公式：x 偶数时 $f(x) \geq 0$，x 奇数时 $f(x) < 0$（因为 $-(x+1)/2 \leq -1$）。既然 $f(x) = f(y)$ 是同一个数，它不可能既非负又负，所以 x 与 y 必同奇偶。

- 若 x, y 都是偶数：由 $f(x) = f(y)$ 得 $x/2 = y/2$，两边乘 2 得 $x = y$。
- 若 x, y 都是奇数：由 $f(x) = f(y)$ 得 $-(x+1)/2 = -(y+1)/2$，两边乘 -2 得 $x + 1 = y + 1$，故 $x = y$。

两种情况都推出 $x = y$，所以 f 是单射。

第三步（验证满射）：任取 $y \in \mathbb{Z}$，需要找到前像。

- 若 $y \geq 0$：取 $x = 2y$（这是自然数）。因为 $2y$ 是偶数，$f(2y) = 2y/2 = y$。所以 y 有前像 $2y$。
- 若 $y < 0$：取 $x = -2y - 1$。因为 $y < 0$ 时 $-2y \geq 2$，所以 $x = -2y - 1 \geq 1$ 是奇数，也是自然数；则 $f(x) = -(x+1)/2 = -(-2y - 1 + 1)/2 = -(-2y)/2 = y$。所以 y 有前像 $-2y - 1$。

两种情况都找到前像，所以 f 是满射。

第四步（收口）：f 既单射又满射，故为双射。由"等势"的定义，$|\mathbb{N}| = |\mathbb{Z}|$。■

【证明机制解说】：核心的"灵光一现"是**用奇偶性充当"符号位"**。要枚举 $\mathbb{Z}$，我们面对的难题是 $\mathbb{Z}$ 有两个方向（正、负）而 $\mathbb{N}$ 只有一个方向（递增）。解决办法是给每个 $n \in \mathbb{N}$ 分配"往哪边走"的任务：偶数步向右，奇数步向左。这不是把 $\mathbb{Z}$"压扁"成 $\mathbb{N}$（那需要无穷时间），而是给每个整数发一个**唯一的编号**，编号本身是有限的。还要注意第三步给出的前像公式 $x = 2y$（$y \geq 0$）与 $x = -2y - 1$（$y < 0$）正是 f 的**逆函数** f^{-1}，它满足 $f^{-1}(f(x)) = x$。

反例（如果适用）：若把 f 改成"先枚举所有非负整数，再枚举所有负整数"，即 $f(x) = x/2$（x 偶）、$f(x) = -(x-1)/2$（x 奇）——这看上去也对，但它得到的是 $0, 0, -1, 1, -2, 2, \dots$，其中 0 被撞了两次（$x = 0$ 与 $x = 1$ 都映到 0），于是**不是单射**。这个失败版本说明：横跳时必须让正负两侧"错开"，否则原点会被重复计算。

定理 12.2：$\mathbb{N} \times \mathbb{N} = \{(i, j) : i, j \in \mathbb{N}\}$ 可数。

证明策略：构造性证明，核心是**对角线枚举 (diagonal enumeration)**，也叫**反对角线枚举**。朴素想法"先枚举第一行 $(0,0), (0,1), (0,2), \dots$，再枚举第二行"会失败——因为第一行就永远枚举不完，第二行永远轮不到。这暴露了本讲最重要的一个陷阱：**"给每个元素编号"和"在有限时间内列出所有元素"是两件完全不同的事**。对角线枚举绕过这个陷阱的办法是：按 $i + j$ 的大小分组，每一组只有**有限**个元素，先枚举有限组，再进下一组。

逐步推导：

第一步（分壳）：把 $\mathbb{N} \times \mathbb{N}$ 按"反对角线" $s = i + j$ 分成一层层的**壳 (shell)**：

$$S_s = \{(i, j) : i + j = s\}, \qquad |S_s| = s + 1.$$

$s = 0$ 时壳里 1 个元素，$s = 1$ 时 2 个，$s = 2$ 时 3 个……**每个壳都是有限的**。这是整个构造的支点。

第二步（壳内定序，壳间递增）：规定枚举顺序为——先枚举 S_0，再枚举 S_1，再 S_2，……；同一壳内按 j 从小到大（即 i 从大到小）。这样得到：

```
        j=0     j=1     j=2     j=3     j=4     j=5   ...
      ┌───────┬───────┬───────┬───────┬───────┬───────┐
i=0   │   0   │   2   │   5   │   9   │  14   │  20   │
      ├───────┼───────┼───────┼───────┼───────┼───────┤
i=1   │   1   │   4   │   8   │  13   │  19   │  27   │
      ├───────┼───────┼───────┼───────┼───────┼───────┤
i=2   │   3   │   7   │  12   │  18   │  26   │  37   │
      ├───────┼───────┼───────┼───────┼───────┼───────┤
i=3   │   6   │  11   │  17   │  25   │  36   │  50   │
      ├───────┼───────┼───────┼───────┼───────┼───────┤
i=4   │  10   │  16   │  24   │  35   │  49   │  66   │
      ├───────┼───────┼───────┼───────┼───────┼───────┤
i=5   │  15   │  23   │  34   │  48   │  65   │  85   │
      └───────┴───────┴───────┴───────┴───────┴───────┘

单元格填的是「该格子被枚举到的序号」。沿反对角线读：
  s=0:  (0,0)                                  -> 0                                  共 1 个
  s=1:  (1,0) (0,1)                            -> 1, 2                               共 2 个
  s=2:  (2,0) (1,1) (0,2)                      -> 3, 4, 5                            共 3 个
  s=3:  (3,0) (2,1) (1,2) (0,3)                -> 6, 7, 8, 9                         共 4 个
  s=4:  (4,0) (3,1) (2,2) (1,3) (0,4)          -> 10, ... , 14                       共 5 个
  s=5:  ...                                                                          共 6 个

移动方向示意（一条条斜线扫过左上三角）：
  ┌─────┬─────┬─────┬─────┬─────┬─────┐
  │  ↘  │     │     │     │     │     │      ← 每一条斜线 = 一个壳 = 有限个格子
  │     │  ↘  │     │     │     │     │        扫完一条再扫下一条
  │     │     │  ↘  │     │     │     │
  │     │     │     │  ↘  │     │     │
  └─────┴─────┴─────┴─────┴─────┴─────┘
```

第三步（壳内起始序号）：前 s 个壳（$s = 0, 1, \dots, s-1$）共有 $\sum_{t=0}^{s-1}(t+1) = \frac{s(s+1)}{2}$ 个元素。所以壳 S_s 的第一个元素（即 $(s, 0)$）的序号是 $\frac{s(s+1)}{2}$。

第四步（配对函数）：壳 S_s 内，$(i, j) = (s - j, j)$ 排在第 j 个（从 0 数），因此

$$\boxed{\pi(i,j)=\frac{(i+j)(i+j+1)}{2}+j}$$

这就是 Cantor 配对函数 (Cantor pairing function)。逐项验证：

$$\pi(0,0)=0,\ \pi(1,0)=1,\ \pi(0,1)=2,\ \pi(2,0)=3,\ \pi(1,1)=4,\ \pi(0,2)=5.$$

再验证几个表里的数：$\pi(3,4)=\frac{7\cdot 8}{2}+4=28+4=32$；$\pi(4,3)=\frac{7\cdot 8}{2}+3=31$；$\pi(0,5)=\frac{5\cdot 6}{2}+5=20$；$\pi(5,0)=\frac{5\cdot 6}{2}+0=15$。全部与上表一致。

第五步（验证单射）：设 $\pi(i,j)=\pi(i',j')=z$。令 $s=i+j$、$s'=i'+j'$。由定义 $z=\frac{s(s+1)}{2}+j$ 且 $0\le j\le s$，所以

$$\frac{s(s+1)}{2}\le z<\frac{s(s+1)}{2}+(s+1)=\frac{(s+1)(s+2)}{2}.$$

即 z 落在区间 $\left[\frac{s(s+1)}{2},\frac{(s+1)(s+2)}{2}\right)$ 内。这些区间随 s 递增且两两不交（相邻区间端点相接：$\frac{(s+1)(s+2)}{2}$ 正是下一个区间的左端），所以 z 唯一确定 s，即 $s=s'$。既得 $s=s'$，由 $\frac{s(s+1)}{2}+j=\frac{s(s+1)}{2}+j'$ 立刻得 $j=j'$。再由 $i=s-j$、$i'=s'-j'$ 得 $i=i'$。故 $(i,j)=(i',j')$，π 是单射。

第六步（验证满射）：任取 $z\in\mathbb{N}$。取唯一的 s 使 $\frac{s(s+1)}{2}\le z<\frac{(s+1)(s+2)}{2}$（这样的 s 存在且唯一，因为区间划分了整个 $\mathbb{N}$：$s=0$ 覆盖 $z=0$，$s=1$ 覆盖 $z=1,2$，$s=2$ 覆盖 $z=3,4,5$，……）。令 $j=z-\frac{s(s+1)}{2}$，则 $0\le j\le s$，令 $i=s-j\ge 0$。于是 $i,j\in\mathbb{N}$ 且 $\pi(i,j)=z$。故 π 是满射。

第七步（收口）：$\pi:\mathbb{N}\times\mathbb{N}\to\mathbb{N}$ 是双射，故 $|\mathbb{N}\times\mathbb{N}|=|\mathbb{N}|$。■

【证明机制解说】：对角线枚举的全部智慧浓缩成一句话——**"把无穷切成可数多个有限块"**。行优先扫描之所以失效，是因为它有一个"永远跨不过去的有限步"（第一行无穷长）；而反对角线每一块长度都是有限的 $s+1$，任何一块都能在有限步内扫完，于是虽然总数无穷，但"编号"这个动作对每个元素都在有限步内完成。**这里的"有限"是逐元素的有限，不是整体的有限**——这正是 FORMAT_SPEC 特别警告的易错点：不要因为列不完就说不可数。

反向地，π 的逆也值得记下来（后面做题常用）：给定 z，令 $s=\left\lfloor\frac{\sqrt{8z+1}-1}{2}\right\rfloor$，则 $(i,j)=\left(s-\left(z-\frac{s(s+1)}{2}\right),\ z-\frac{s(s+1)}{2}\right)$。验算：$z=20\Rightarrow s=5, j=20-15=5, i=0$，得 $(0,5)$ ✓；$z=15\Rightarrow s=5, j=0, i=5$，得 $(5,0)$ ✓；$z=100\Rightarrow s=13, j=100-91=9, i=4$，得 $(4,9)$ ✓（表中第 4 行第 9 列确实排在第 100 位附近）。

定理 12.3：设 $A_0,A_1,A_2,\ldots$ 是一列可数集（可数**多个**可数集），则 $\bigcup_{i\in\mathbb{N}}A_i$ 也可数。特别地，**有限个**可数集的并也可数。

证明策略：构造性证明 + 复用定理 12.2。技术上的关键是把"第 i 个集合的第 j 个元素"看成一对 (i,j)，然后把定理 12.2 的反对角线枚举直接搬过来。但有一个障碍必须先处理：**不同的 A_i 可能互相重叠**，同一个元素会被数到多次，这样得到的映射就不是单射了。解决办法是"第一次出现才算"——**取每个元素首次出现的位置**。

逐步推导：

第一步（把每个 A_i 排成序列）：因为每个 A_i 可数，可以对每个 i 固定一个满射 $g_i:\mathbb{N}\to A_i$（若 A_i 有限，就让 g_i 在某个位置之后重复最后一个元素，或视为部分定义；这不影响结论）。于是 $A_i=\{g_i(0),g_i(1),g_i(2),\ldots\}$——**"可数"的定义在这里被兑现成了"有序列"**，这是全部构造的起点。

第二步（铺成二维表）：把整个并集想象成一张无穷大的表格，第 i 行是 A_i 的枚举：

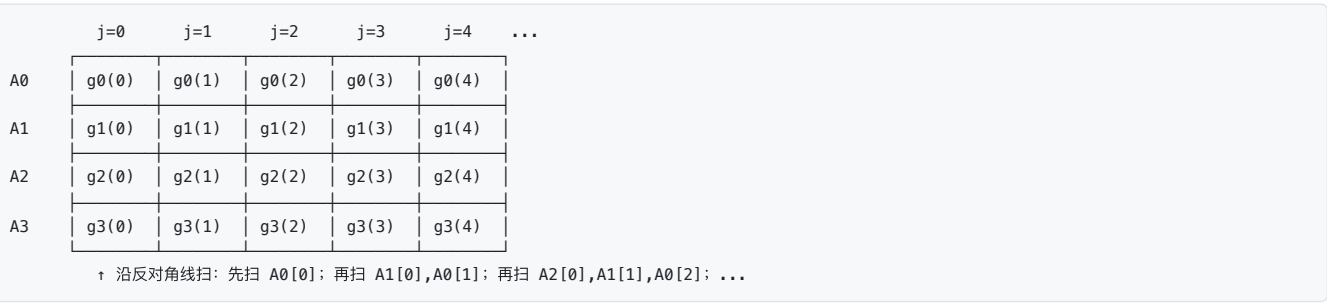

第三步（对角线扫描顺序）：按定理 12.2 的顺序访问表格单元格：依 $i+j$ 递增，同一反对角线上 j 从小到大。访问顺序是

$$A_0[0];\quad A_1[0],A_0[1];\quad A_2[0],A_1[1],A_0[2];\quad A_3[0],A_2[1],A_1[2],A_0[3];\ \ldots$$

第四步（去除重复）：按上述顺序走一遍，**只保留首次见到的元素**，之后重复出现的一律跳过。设去重后得到的序列为

$$b_0,b_1,b_2,b_3,\ldots$$

第五步（验证这是到 $\mathbb{N}$ 的双射）：

- **每个元素都出现**：任取 $x\in\bigcup_i A_i$，则存在某个 i 使 $x\in A_i$，从而 $x=g_i(j)$ 对某个 j 成立（因为 g_i 满射）。于是 x 出现于表格第 i 行第 j 列的格子里，而反对角线扫描**迟早会访问这个格子**（格子 (i,j) 在第 $i+j=\text{const}$ 条对角线上，前面的对角线只有有限条、每条只有有限格）。既然 x 出现过，去重后的序列里就一定有它。
- **每个元素只出现一次**：去重规则保证序列中任意两项不相等。
- **每一项都确实属于并集**：显然。

因此 $b_0,b_1,b_2,\ldots$ 是 $\bigcup_i A_i$ 的一个**无重复无遗漏的枚举**，即存在双射 $\mathbb{N}\to\bigcup_i A_i$（把 n 映到 b_n）。故并集可数。■

【证明机制解说】：这个定理是"无穷也有算术"的第一次真正兑现——它说 $\aleph_0+\aleph_0+\aleph_0+\cdots=\aleph_0$（可数多个可数无穷相加仍是可数无穷）。它的全部工作就是把**两个无穷压成一个**：一维的 i（集合下标）和另一个一维的 j（集内下标）被反对角线编织成单个维度。这个"编织"动作是本讲后面处理 $\mathbb{Q}$、字符串、多项式的**通用机器**。

反例（如果适用）：定理要求"可数多个可数集"。如果是**不可数多个**可数集，结论就**不再成立**。具体例子：对每个实数 $r \in [0,1]$，取单点集 $\{r\}$——每个 $\{r\}$ 是可数的（有限），但 $\bigcup_{r\in[0,1]}\{r\} = [0,1]$ 不可数。所以"可数多个"这个条件是本质的，不能省。

定理 12.4：有理数集 $\mathbb{Q} = \left\{\frac{a}{b} : a, b \in \mathbb{Z},\ b \neq 0\right\}$ 可数。

证明策略：用 Cantor–Bernstein 夹逼，只造一个单射。具体路线：先证 $|\mathbb{N}| \le |\mathbb{Q}|$（平凡），再证 $|\mathbb{Q}| \le |\mathbb{N}|$——办法是把 $\mathbb{Q}$ 嵌入 $\mathbb{Z}\times\mathbb{Z}$，再用定理 12.2 型枚举。**为什么不直接造双射？** 因为有理数有重复表示（$\frac{1}{2} = \frac{2}{4} = \frac{3}{6}$），直接枚举必然撞车，造双射反而麻烦。单射就足够了，这正是 Cantor–Bernstein 定理的用武之地。

逐步推导：

第一步（反向的平凡单射）：$\mathbb{N} \subseteq \mathbb{Q}$（每个自然数 n 就是 $n/1$），故恒等嵌入 $\mathbb{N} \to \mathbb{Q}$ 是单射，于是 $|\mathbb{N}| \le |\mathbb{Q}|$。这一步不需要任何技巧。

第二步（把有理数交给整数对）：任取 $q \in \mathbb{Q}$，q 至少有一种表示 $q = a/b$，其中 $a, b \in \mathbb{Z}$、$b \neq 0$。把分子分母同乘 -1 可得 $b > 0$ 的表示；再把分子分母同除 $\gcd(a,b)$ 可得**最简表示 (lowest terms)**，即 $\gcd(a,b) = 1$、$b > 0$。于是

$$q \longmapsto (a,b) \in \mathbb{Z}\times\mathbb{Z}_{>0} \subseteq \mathbb{Z}\times\mathbb{Z}$$

其中 (a,b) 是 q 的**唯一**最简表示。**唯一性是关键**：$q = a/b = a'/b'$ 且两组都最简时必有 $a = a', b = b'$（由整数唯一分解，或由 $\gcd$ 的整除论证）。所以这个映射是**单射**。

第三步（$\mathbb{Z}\times\mathbb{Z}$ 可数）：$\mathbb{Z}$ 可数（定理 12.1），$\mathbb{Z}\times\mathbb{Z}$ 就是两个可数集做配对。用**螺旋枚举 (spiral enumeration)** 显式展开它：

螺旋路径（从原点出发，一圈比一圈大）：

```
                    ┌──────────────────────────┐
                    │ 19  18  17  16  15  14  13│
                    │ 20   5   4   3   2  11  12│
                    │ 21   6   0   1  10  27 ...│   ← 中心是 (0,0)
                    │ 22   7   8   9  25  26 ...│
                    │ 23  24  33  32  31  30  29│
                    └──────────────────────────┘
```

对应坐标（与官方 Note 的编号完全一致）：

```
  0:(0,0)   1:(1,0)   2:(1,1)   3:(0,1)   4:(-1,1)  5:(-1,0)
  6:(-1,-1) 7:(0,-1)  8:(1,-1)  9:(2,-1)  10:(2,0)  11:(2,1)
 12:(2,2)  13:(1,2)  14:(0,2)  15:(-1,2) 16:(-2,2) 17:(-2,1)
 18:(-2,0) 19:(-2,-1) 20:(-2,-2) ...
```

每个 $(a,b) \in \mathbb{Z}\times\mathbb{Z}$ 恰好占据螺旋上的一个位置（因为螺旋是逐圈向外、每圈穷尽该圈所有格子，不重不漏），所以"位置编号"是一个双射 $\sigma : \mathbb{Z}\times\mathbb{Z} \to \mathbb{N}$，$\mathbb{Z}\times\mathbb{Z}$ 可数。

第四步（复合出单射）：定义 $f : \mathbb{Q} \to \mathbb{N}$ 为

$$f(q) = \sigma\big(q \text{ 的最简表示 } (a,b)\big).$$

这是"单射 ∘ 单射"，从而是单射。

- **它是良定义的**：q 的最简表示唯一，所以 $f(q)$ 不依赖表示的选择。这一步必须写出来，否则证明有漏洞。
- **它是单射**：若 $f(q_1) = f(q_2)$，则 $\sigma(a_1,b_1) = \sigma(a_2,b_2)$，由 σ 单射得 $(a_1,b_1) = (a_2,b_2)$，于是 $q_1 = a_1/b_1 = a_2/b_2 = q_2$。

因此 $|\mathbb{Q}| \le |\mathbb{N}|$。

第五步（夹逼收口）：已有 $|\mathbb{N}| \le |\mathbb{Q}|$ 与 $|\mathbb{Q}| \le |\mathbb{N}|$，由 Cantor–Bernstein 定理存在双射 $\mathbb{Q} \to \mathbb{N}$，故 $|\mathbb{Q}| = |\mathbb{N}|$，$\mathbb{Q}$ 可数。■

用反对角线（而非螺旋）写出 $\mathbb{Q}$ 的显式枚举：如果不想绕道 Cantor–Bernstein，也可以直接在 $\mathbb{Z}\times\mathbb{Z}_{>0}$ 上做反对角线，并跳过非最简的格子。按"壳" $s = |a| + b$ 从小到大，壳内 a 从小到大：

```
壳 s=1:  (0,1)                                                  →  0/1
壳 s=2:  (-1,1)  (0,2)  (1,1)                                   → -1/1, (0/2 跳过), 1/1
壳 s=3:  (-2,1) (-1,2) (0,3) (1,2) (2,1)                        → -2/1, -1/2, (0/3 跳), 1/2, 2/1
壳 s=4:  (-3,1)(-2,2)(-1,3)(0,4)(1,3)(2,2)(3,1)                 → -3/1, (跳过), -1/3, (跳), 1/3, (跳), 3/1
壳 s=5:  (-4,1)(-3,2)(-2,3)(-1,4)(0,5)(1,4)(2,3)(3,2)(4,1)      → -4/1, -3/2, -2/3, -1/4, (跳), 1/4, 2/3, 3/2, 4/1
...
去重后前 19 个有理数（跳过 gcd≠1 的格子）：
  0/1, -1/1, 1/1, -2/1, -1/2, 1/2, 2/1, -3/1, -1/3, 1/3,
  3/1, -4/1, -3/2, -2/3, -1/4, 1/4, 2/3, 3/2, 4/1
```

注意 $\frac{3}{4}$ 出现在壳 $s = 7$（$(-3,1)\ldots(3,1)$ 里的 $(3,4)$），位置比较靠后——这正是"有理数看起来比自然数多得多"的量化体现：**虽然一样多，但编号有稀疏**。我们还可以数一数密度：在螺旋的 $0 \sim 199$ 号位置中共有 67 个格子的最简表示合法（$b > 0$ 且 $\gcd(a,b) = 1$），比例约 $1/3$。

【证明机制解说】：核心洞察是**"约分去重"让单射成为可能**。$\mathbb{Q}$ 之所以看起来很"大"（任何两个自然数之间都有无穷多个有理数，即**稠密 (dense)**），是因为我们在用"序"的眼光看它——在 $\le$ 这个序下 $\mathbb{Q}$ 无处不密。但基数用的是"配对"的眼光，与序无关。一旦允许打乱顺序，稠密性就不再是障碍。这和 Lecture 14 要讲的计数问题形成有趣对照：**序上的稠密 ≠ 基数上的更大**。

反例（如果适用）：若跳过约分这一步，映射 $q \mapsto \sigma(a,b)$ 会**不是**单射：$\frac{1}{2}$ 与 $\frac{2}{4}$ 会映到不同位置，同一个有理数被数两次，这时的枚举不构成双射（虽然仍可"去重"补救，但那正是我们上面用反对角线版本做的事）。**"良定义"是这类构造中最容易翻车的环节**。

定理 12.5：所有有限长二进制串的集合 $\{0,1\}^* = \{\varepsilon, 0, 1, 00, 01, 10, 11, 000, \ldots\}$ 可数（ε 表示**空串 (empty string)**，即长度为 0 的唯一串）。

证明策略：直接构造双射。"按长度递增、同长度内按字典序"给出一个显式列表，再把列表下标当作编号。**为什么这个定理至关重要？** 因为一台程序本质上就是一个有限长的比特串，所以"所有程序"这个集合可数。下一讲的停机问题证明将整个儿建立在这一点上：程序可数，因此可以排成 $P_0, P_1, P_2, \ldots$，于是可以做对角线。

逐步推导：

第一步（分块）：按长度把 $\{0,1\}^*$ 分成

$$L_\ell = \{\text{所有长度为 } \ell \text{ 的二进制串}\}, \qquad |L_\ell| = 2^\ell.$$

$L_0 = \{\varepsilon\}$，$L_1 = \{0, 1\}$，$L_2 = \{00, 01, 10, 11\}$，$L_3 = \{000, 001, \ldots, 111\}$。**每一块都有限**（这一点与定理 12.2 完全同构）。

第二步（块内定序、块间递增）：先列 L_0，再列 L_1，再 L_2，……；同一块内按二进制数值（即字典序）从小到大。得到列表

$$\varepsilon,\ 0,\ 1,\ 00,\ 01,\ 10,\ 11,\ 000,\ 001,\ 010,\ 011,\ 100,\ 101,\ 110,\ 111,\ 1000, \ldots$$

第三步（写出编号公式）：第 ℓ 块之前（长度 0 到 $\ell-1$）共有 $\sum_{k=0}^{\ell-1} 2^k = 2^\ell - 1$ 个串。所以对长度 ℓ、二进制值为 v（$0 \le v < 2^\ell$）的串 s，

$$\mathrm{idx}(s) = \left(2^\ell - 1\right) + v, \qquad \ell = |s|.$$

逐项验证：$\mathrm{idx}(\varepsilon) = 2^0 - 1 + 0 = 0$ ✓；$\mathrm{idx}(0) = 2^1 - 1 + 0 = 1$ ✓；$\mathrm{idx}(1) = 2^1 - 1 + 1 = 2$ ✓；$\mathrm{idx}(00) = 2^2 - 1 + 0 = 3$ ✓；$\mathrm{idx}(11) = 2^2 - 1 + 3 = 6$ ✓；$\mathrm{idx}(111) = 2^3 - 1 + 7 = 14$ ✓；$\mathrm{idx}(1000) = 2^4 - 1 + 8 = 23$ ✓（长度 ≤ 3 的串共 15 个，占编号 $0 \sim 14$，所以 1000 从 15 开始，是长度 4 的第 9 个，$15 + 8 = 23$ ✓）。

第四步（验证双射）：每个串恰属于一个 L_ℓ，在块内有唯一序号 v，故 idx 有唯一值（单射）；反过来，每个 $z \in \mathbb{N}$ 唯一确定 $\ell = \lfloor \log_2(z+1) \rfloor$ 与 $v = z - (2^\ell - 1)$，从而唯一确定一个串（满射）。故 idx 是双射，$\{0,1\}^*$ 可数。■

【证明机制解说】：这个证明的手法值得单独记住——**"按长度分块，每块有限，块间递增"**。它是"反对角线"的变体：反对角线按 $i + j$ 分层，这里按 $|s|$ 分层，两者都满足"无穷多个有限块"这一条件。凡是集合能按某个"规模参数"分层、且每层只有有限个元素，这个集合就可数。$\mathbb{N} \times \mathbb{N}$、$\{0,1\}^*$、$\mathbb{N}[x]$、所有程序、所有证明——全都是这一个模板。

推广：同样的构造给出**任意有限字母表 Σ 上的有限串集 Σ^* 可数**（只需把字母表编号，再把串看成 $|\Sigma|$ 进制数）。特别地**三元串集 $\{0,1,2\}^*$ 可数**，这是下一个定理的零件。

反例（如果适用）：注意区分 $\{0,1\}^*$（**有限长**串，可数）与 $\{0,1\}^\infty$（**无限长**二进制串，即从 $\mathbb{N}$ 到 $\{0,1\}$ 的函数全体，等价于 $\mathcal{P}(\mathbb{N})$，**不可数**）。两者的差别只在"长度是否有限"，但基数差了整整一级。这是初学者最容易混的一对概念，务必记牢：**"每个元素有限"不等于"整体有限"，也不等于"整体可数"——$\{0,1\}^*$ 每个元素有限而整体仍可数，$\{0,1\}^\infty$ 每个元素无限且整体不可数。**

定理 12.6：所有以自然数为系数的多项式之集 $\mathbb{N}[x]$ 可数。进一步，所有**代数数 (algebraic number)**（即某个非零整系数多项式的根）之集可数。

证明策略：构造单射 $\mathbb{N}[x] \to \{0,1,2\}^*$ 再用定理 12.5。编码器的设计要点是"**可唯一解码**"：我们要把一串自然数（系数）编码成一个不含歧义的串，用分隔符 2 来标记边界（因为 $0, 1$ 已经在二进制里用掉了，只有 2 能当分隔符）。

逐步推导：

第一步（编码方案）：设 $p(x) = a_d x^d + \cdots + a_1 x + a_0$，其中 $a_k \in \mathbb{N}$。把每个系数 a_k 写成二进制串 $B(a_k)$（约定 $B(0)$ 为空串，即"没有 1 和 0 写出来"；或者更省事地直接写 0），然后用 2 把这些二进制串**从高次到常数**串起来，得到三元串

$$f(p) = B(a_d)\ 2\ B(a_{d-1})\ 2\ \cdots\ 2\ B(a_0).$$

第二步（算例，与官方 Note 一致）：取 $p(x) = 5x^5 + 2x^4 + 7x^3 + 4x + 6$，系数向量（从高次到常数）是 $(5, 2, 7, 0, 4, 6)$。二进制分别是

$$5 \to 101, \quad 2 \to 10, \quad 7 \to 111, \quad 0 \to 0, \quad 4 \to 100, \quad 6 \to 110.$$

串起来（把零系数也保留，使位置信息不丢）：

$$f(p) = 101\,2\,10\,2\,111\,2\,0\,2\,100\,2\,110 = 10121021112021002110.$$

注意官方 Note 不加零系数（它直接忽略 0 系数），得到 101210211121002110。两种约定都能用，只要**前后一致**：区别在于"零系数是否占位"。**本项目采用保留零系数的版本**，因为解码时位置即幂次，不必另外记次数，更不易出错。

第三步（验证单射 —— 关键在可唯一解码）：给定编码串，按字符 2 切分（2 只作分隔符，绝不出现在系数内部，因为二进制只用 $0, 1$），得到若干块 $B(a_d), B(a_{d-1}), \ldots, B(a_0)$；每块按二进制读回一个自然数。于是**原多项式被唯一还原**（块的个数给出次数 d，块的顺序给出从高次到低次，各块的值给出系数）。因此若 $f(p) = f(q)$，切分与读回后得到相同的系数序列，从而 $p = q$，f 是单射。

第四步（落回可数）：由定理 12.5 的推广，$\{0,1,2\}^*$ 可数，存在双射 $h : \{0,1,2\}^* \to \mathbb{N}$。复合 $h \circ f : \mathbb{N}[x] \to \mathbb{N}$ 是单射，故 $|\mathbb{N}[x]| \le |\mathbb{N}|$。又 $\mathbb{N} \subseteq \mathbb{N}[x]$（把自然数 n 当常数多项式），故 $|\mathbb{N}| \le |\mathbb{N}[x]|$。由 Cantor–Bernstein 得 $|\mathbb{N}[x]| = |\mathbb{N}|$，$\mathbb{N}[x]$ 可数。■

第五步（代数数可数）：设整系数多项式 $p \neq 0$ 的次数为 d，则 p 至多有 d 个（复）根，从而**至多有限个实根**。令 $\mathcal{A}$ 为所有代数数之集，

$$\mathcal{A} = \bigcup_{p \in \mathbb{Z}[x],\, p \neq 0} \{\, r \in \mathbb{R} : p(r) = 0 \,\}.$$

这是**可数多个有限集**之并（因为 $\mathbb{Z}[x]$ 可数，与 $\mathbb{N}[x]$ 同理——把每个整数写成带符号的二进制即可编码），而每个有限集可数。由定理 12.3，$\mathcal{A}$ 可数。■

【证明机制解说】：这里出现了本讲最有价值的思维方式——**为了证明可数，不必写出显式枚举，只要给出一个可唯一解码的编码 (encoding) 即可**。编码本质上是一个单射，而单射足以（配合 Cantor–Bernstein）确定基数。这个思想的威力在第五步爆发：我们根本不知道代数数有哪些、有多少，但我们知道**每个代数数都是某个可数集合族里的有限集的一员**，于是它可数。**"可数多个有限集的并"**是一个可以反复套用的公式。

反例（如果适用）：编码必须保证可唯一解码，否则单射性会崩。如果把系数直接拼在一起不加分隔符，$p(x)=5x^2+2x+7$ 的系数 $(5,2,7)$ 及 $(52,7)$、$(5,27)$ 都会编码成同一个串 **10127**，f 就不是单射了。**分隔符 2 的作用不是装饰，而是防止歧义。**

定理 12.7（Cantor 定理）：设 A 是任意集合，$\mathcal{P}(A)=\{T:T\subseteq A\}$ 是它的**幂集 (power set)**。则

$$|A|<|\mathcal{P}(A)|.$$

特别地 $|\mathbb{N}|<|\mathcal{P}(\mathbb{N})|$：自然数的子集比自然数"多"得多。

证明策略：反证法 + 对角线论证。这是一个**通用的、不依赖 A 是否可数的**证明。要证 $|A|<|\mathcal{P}(A)|$，需证两件事：$|A|\le|\mathcal{P}(A)|$（容易，用单元素子集）和**不存在满射 (onto) $A\to\mathcal{P}(A)$**（这才是难点）。而"不存在满射"的标准打法就是：假设有满射 f，**构造一个被 f 漏掉的集合 D**，与满射矛盾。

逐步推导：

第一步（先看有限情形，建立直觉）：$|S|=k$ 时 $|\mathcal{P}(S)|=2^k$。理由：每个子集 $T\subseteq S$ 对应一个 k 位比特串（**特征向量 (characteristic vector)**），第 i 位为 1 表示 S 的第 i 个元素在 T 里。例如 $S=\{1,2,3\}$，共 $2^3=8$ 个子集：

```
比特串    子集          比特串    子集
 000   →  {}            100   →  {1}
 001   →  {3}           101   →  {1,3}
 010   →  {2}           110   →  {1,2}
 011   →  {2,3}         111   →  {1,2,3}
  （约定第 1 位对应元素 1，第 3 位对应元素 3）
 $2^k$ 的来历：每一位独立二选一（在/不在），共 $\underbrace{2\times2\times\cdots\times2}_{k}=2^k$ 种
```

（注：表中位串的书写顺序与"第 i 位对应第 i 个元素"的约定不必逐字对应，只要选取一种固定约定即可。这里的约定是**从右往左**读位。）有限情形下 $2^k>k$ 对所有 $k\ge0$ 成立（$k=0$ 时 $1>0$；$k\ge1$ 时可由归纳或由 $2^k\ge k+1$ 证明）。但**这不能推出无穷情形**——我们必须用对角线。

第二步（$|A|\le|\mathcal{P}(A)|$）：映射 $a\mapsto\{a\}$ 把 A 单射地映入 $\mathcal{P}(A)$（不同的 a 给出不同的单元素集），所以 $|A|\le|\mathcal{P}(A)|$。

第三步（假设满射，准备打对角线）：为引出矛盾，假设存在**满射** $f:A\to\mathcal{P}(A)$。为了直观，先取 $A=\mathbb{N}$，把 f 想成一张无穷表：第 n 行是集合 $f(n)\subseteq\mathbb{N}$ 的特征向量（$a_{n,k}=1$ 表示 $k\in f(n)$，0 表示 $k\notin f(n)$）：

```
          k=0   k=1   k=2   k=3   k=4   k=5  ...
        ┌─────┬─────┬─────┬─────┬─────┬─────┐
f(0)    │  1  │  0  │  0  │  1  │  0  │  0  │   ← 即 f(0) = {0,3}
        ├─────┼─────┼─────┼─────┼─────┼─────┤
f(1)    │  0  │  0  │  0  │  0  │  0  │  0  │   ← 即 f(1) = {}
        ├─────┼─────┼─────┼─────┼─────┼─────┤
f(2)    │  1  │  0  │  1  │  0  │  0  │  0  │   ← 即 f(2) = {0,2}
        ├─────┼─────┼─────┼─────┼─────┼─────┤
f(3)    │  0  │  1  │  0  │  1  │  1  │  0  │   ← 即 f(3) = {1,3,4}
        ├─────┼─────┼─────┼─────┼─────┼─────┤
f(4)    │  1  │  1  │  1  │  0  │  1  │  0  │   ← 即 f(4) = {0,1,2,4}
        ├─────┼─────┼─────┼─────┼─────┼─────┤
 ...    │ ... │ ... │ ... │ ... │ ... │ ... │
        └─────┴─────┴─────┴─────┴─────┴─────┘
          \     \     \     \     \
           \     \     \     \     \      ← 对角线上的格子 (k,k)
            a₀₀=1 a₁₁=0 a₂₂=1 a₃₃=1 a₄₄=1
```

第四步（构造"反骨集合" D）：定义

$$\boxed{D=\{a\in A:a\notin f(a)\}}$$

即 D 由所有**不属于自己像**的元素组成。在特征向量的语言里，D 的特征向量就是"把对角线上每一位取反"得到的那一行：

```
对角线上读出的位串（a₀₀ a₁₁ a₂₂ a₃₃ a₄₄ ...）  =  1 0 1 1 1 ...
逐位取反                                          =  0 1 0 0 0 ...
↓
D 的特征向量 = 0 1 0 0 0 ...  ⇒  D = {1}      （在此示例中）
```

第五步（$D\in\mathcal{P}(A)$）：D 是 A 的子集（它的定义就是从 A 里筛元素），所以 $D\in\mathcal{P}(A)$。**这一步看似废话，但它保证了 D 是一个"合法的候选像"，从而下一步的"没被映到"才构成对满射的否定。**

第六步（D 不在 f 的像中 —— 核心矛盾）：假设 D 在像中，即存在 $a^*\in A$ 使 $f(a^*)=D$。考察 a^* 是否属于 D，只有两种可能，且**两种都矛盾**：

- **情形 A：$a^*\in D$**。由 D 的定义（D 中元素的定义就是"不属于自己的像"），$a^*\in D$ 意味着 $a^*\notin f(a^*)$。但已假设 $f(a^*)=D$，所以 $a^*\notin D$。矛盾。
- **情形 B：$a^*\notin D$**。即 $a^*\notin f(a^*)$。但 D 的定义正是**把所有满足 $a\notin f(a)$ 的 a 收进来**，所以 a^* 应当属于 D。矛盾。

两种情形都矛盾，所以"D 在像中"这个假设是假的，即 $D\notin f(A)$。

第七步（收口）：$D\in\mathcal{P}(A)$ 且 $D\notin f(A)$，说明 f 不是满射。这与"f 是满射"的假设矛盾。既然任何函数 $f:A\to\mathcal{P}(A)$ 都不可能满射，就不存在双射 $A\to\mathcal{P}(A)$，故 $|A|\ne|\mathcal{P}(A)|$。结合第二步的 $|A|\le|\mathcal{P}(A)|$，得 $|A|<|\mathcal{P}(A)|$。■

【证明机制解说】：D 的定义 $D=\{a:a\notin f(a)\}$ 是整个证明的灵魂，它的构造思想可以用一句话概括：**"让 D 在第 a^* 个问题上与 $f(a^*)$ 唱反调。"** 由于 D 被设计为"处处与自己的候选人不同"，它就不可能等于任何 $f(a)$。这是一个**自指式 (self-referential)** 的构造——它用 f 的像去定义一个新的、必然不在该像中的对

象。这正是说谎者悖论（"这句话是假的"）的数学化身，也正是下一讲停机问题证明的同一招。特别值得注意：这个证明**没有任何地方用到 A 可数**，它对一切集合成立。所以"无穷有很多层"是集合论的普遍现象：$\mathbb{N}, \mathcal{P}(\mathbb{N}), \mathcal{P}(\mathcal{P}(\mathbb{N})), \ldots$ 一层严格大于一层。

反例（如果适用）：D 的定义必须是"$a \notin f(a)$"而**不是**"$a \in f(a)$"。若取 $E = \{a : a \in f(a)\}$，这个构造**不能**推出矛盾：假设 $E = f(a^*)$，那么"$a^* \in E$"与"$a^* \in f(a^*)$"是**同一句话**，两种情形自我一致，得不到矛盾。所以"取反"是本质的。这个反例精确地说明了为什么对角线必须**翻转**对角元素。

定理 12.8：闭区间 $[0,1]$ 上的实数集不可数，从而 $\mathbb{R}$ 也不可数。

证明策略：反证法 + 对角线论证。假设 $[0,1]$ 可数，则有一个完整列表 $f(0), f(1), f(2), \ldots$。我们把每个数写成无穷小数，**读对角线**得到一串数字，**逐位改动**得到一个新数 s，证明 $s \in [0,1]$ 但不在列表里。与定理 12.7 的结构完全一样，只是"集合的特征向量"换成了"无穷小数的数字序列"。

逐步推导：

第一步（唯一表示的技术准备）：实数的小数表示**不唯一**：$0.4999\ldots = 0.5$（因为 $0.4999\ldots = \frac{4}{10} + \frac{9}{100} + \frac{9}{1000} + \cdots = 0.4 + \frac{9/100}{1-1/10} = 0.4 + 0.1 = 0.5$），同理 $0.999\ldots = 1$。为了消除歧义，我们**规定统一使用"不以 9 结尾"的表示**：

$$x \in [0,1] \quad \Longrightarrow \quad x = 0.d_1 d_2 d_3 \ldots \text{ 且数字序列 } (d_k) \text{ 中不含”从某位起全是 } 9\text{”}。$$

（等价的说法是"不以连续的 9 结尾"或"没有末尾全 9"。）在这个约定下，(d_k) 与 x **一一对应**。这条约定是整个证明能站住的地基，绝不能省。

第二步（反证假设）：假设 $[0,1]$ 可数，则存在双射 $f : \mathbb{N} \to [0,1]$（若只是单射而非满射，用"可数"定义配一个满射即可；我们用满射 f，因为证明只需满射不成立）。把列表按上述规范表示写出来：

```
          第1位   第2位   第3位   第4位   第5位   第6位 ...          （小数点后）
        ┌───────┬───────┬───────┬───────┬───────┬───────┐
f(0)    │   5   │   2   │   1   │   4   │   9   │   3   │  ...   = 0.521493...
        ├───────┼───────┼───────┼───────┼───────┼───────┤
f(1)    │   1   │   4   │   1   │   6   │   2   │   9   │  ...   = 0.141629...
        ├───────┼───────┼───────┼───────┼───────┼───────┤
f(2)    │   9   │   4   │   7   │   8   │   2   │   7   │  ...   = 0.947827...
        ├───────┼───────┼───────┼───────┼───────┼───────┤
f(3)    │   5   │   3   │   0   │   9   │   8   │   1   │  ...   = 0.530981...
        ├───────┼───────┼───────┼───────┼───────┼───────┤
f(4)    │   2   │   7   │   3   │   1   │   4   │   1   │  ...   = 0.273141...
        ├───────┼───────┼───────┼───────┼───────┼───────┤
 ...    │  ...  │  ...  │  ...  │  ...  │  ...  │  ...  │
        └───────┴───────┴───────┴───────┴───────┴───────┘
            \       \       \       \       \       \
             d₁¹     d₂²     d₃³     d₄⁴     d₅⁵     d₆⁶     ← 对角线元素（i 行第 i 位）

  对角线读出来：  5 4 7 9 4 1 ...
  记作 r = 0.547941...    （它本身也是一个 [0,1] 中的实数）
```

（上式记号 $d_i^{(i)}$ 表示"列表第 i 个数的小数第 i 位"。）

第三步（构造 s：逐位变形）：定义新数 $s = 0.s_1 s_2 s_3 \ldots$，其第 k 位为

$$\boxed{s_k = (d_k^{(k)} + 2) \bmod 10}$$

也就是把对角线每一位 d 换成 $(d+2) \bmod 10$。在本例中

$$d^{(1..6)} = 5,4,7,9,4,1 \implies s_{1..6} = 7,6,9,1,6,3 \implies s = 0.769163\ldots$$

第四步（s 是合法的 $[0,1]$ 中的数，且规范表示无歧义）：

- 每个 $s_k \in \{0,1,\ldots,9\}$，所以 s 是合法小数。
- **s 不以 9 结尾吗？** 这正是选择"加 2"而非"加 1"的原因。若某个 k 满足 $d_k^{(k)} = 9$，则 $s_k = (9+2) \bmod 10 = 1 \neq 9$；若 $d_k^{(k)} = 0$，则 $s_k = 2 \neq 9$。更一般地，$(d+2) \bmod 10 \neq 9$ 当且仅当 $d \neq 7$；也就是说只有当对角位是 7 时 s_k 才可能是 9。**但这可能连续发生吗？** 为保证万无一失，官方给的替代方案更干净：**把每位换成 $\{1,2,\ldots,8\}$ 中的某个数**，例如 $s_k = (d_k^{(k)} \bmod 8) + 1$。这样 $s_k \in \{1,\ldots,8\}$，**永远不为 0 或 9**，于是既不可能"末尾全 9"、也不可能"末尾全 0"，s 的规范表示无任何歧义。本例中 $d = 5,4,7,9 \Rightarrow s = 6,5,8,2 \Rightarrow s = 0.6582\ldots$。

我们同时给出两种规则的验算（都保证 $s_k \neq d_k^{(k)}$）：

对角线位 d	0	1	2	3	4	5	6	7	8	9
规则一 $(d+2) \bmod 10$	2	3	4	5	6	7	8	9	0	1
规则二 $(d \bmod 8) + 1$	1	2	3	4	5	6	7	8	1	2

两种规则下均有 $s_k \neq d$（逐行核对即可），这是后一步的要害。

第五步（s 不在列表中 —— 核心矛盾）：假设 s 在列表中，即存在 $n \in \mathbb{N}$ 使 $f(n) = s$。考察两人的**第 $n+1$ 位**（注意：列表第 n 个数记作 $f(n)$，它的第 $n+1$ 位就是 $d_{n+1}^{(n+1)}$）：

- 一方面，$f(n) = s$ 作为同一个数，其规范表示应当相同，故 $f(n)$ 的第 $n+1$ 位等于 s_{n+1}。
- 另一方面，由构造 $s_{n+1} = (d_{n+1}^{(n+1)} + 2) \bmod 10 \neq d_{n+1}^{(n+1)}$，即 $s_{n+1} \neq f(n)$ 的第 $n+1$ 位。

两者矛盾，所以 $s \neq f(n)$。但 n 是任意的（上面论证对每个 n 都成立），所以 s 不等于列表中任何一个数，即 $s \notin f(\mathbb{N})$。

第六步（收口）：$s \in [0,1]$（第四步）但 $s \notin f(\mathbb{N})$，故 f 不是满射。这推翻了"存在双射 $\mathbb{N} \to [0,1]$"的假设，所以 $[0,1]$ 不可数。

第七步（$\mathbb{R}$ 不可数）：因为 $[0,1] \subseteq \mathbb{R}$，若 $\mathbb{R}$ 可数则其子集 $[0,1]$ 也可数（子集可数：只需把 $\mathbb{R}$ 的枚举限制在 $[0,1]$ 上并去重），这与第六步矛盾。故 $\mathbb{R}$ 不可数。

■

【证明机制解说】：整个证明的"灵光一现"是**把"函数在一点上的值"换成"数字在一位上的值"**。定理 12.7 里我们比较的是"集合 D 与 $f(a^*)$ 在元素 a^* 上是否一致"，这里我们比较的是"数 s 与 $f(n)$ 在小数第 $n+1$ 位上是否一致"。抽象结构完全一样：**把 $\mathbb{N}$ 当作索引集合，把每个候选对象当作一个"无穷长的信息序列"（比特串或数字串），然后沿着索引 k 修改第 k 项，使新对象在第 k 项上与候选 k 不同。** 这就是"对角线方法"的统一定义，也是 Lecture 13 停机问题证明的骨架。

反例（如果适用）：为什么把同样的论证用在 $\mathbb{Q}$ 上会失败？ 假设有人试图证明 $\mathbb{Q}\cap[0,1]$ 不可数，照抄上面的构造：取列表 $f(0), f(1), \dots$（现在都是有理数），读对角线、改位得到 q。**这个论证不成立**，因为改位后的 q 未必是有理数——有理数的小数展开必须是**最终循环的 (eventually periodic)**，而随意改动对角位几乎必然破坏循环性，于是 $q\notin\mathbb{Q}\cap[0,1]$，我们**没能**构造出一个"应该在列表中却不在"的元素，矛盾链条从中间断开。这精确地说明了：对角线论证要求**构造出的新对象落在原集合内**。对 $\mathbb{R}$ 成立，是因为"任意数字序列都定义一个实数"；对 $\mathbb{Q}$ 不成立。**这也从反面印证了：$\mathbb{Q}$ 确实可数，它不是漏网之鱼。**

定理 12.9：Cantor 集 C（在 $[0,1]$ 中反复挖去中间三分之一后剩下的一切点）不可数，且与 $[0,1]$ 等势。由此可推出**超越数 (transcendental number) 存在**，且"绝大多数"实数是超越数。

证明策略：构造性证明的变体。先用**三进制 (ternary)** 表示刻画 C，得到一个极其简洁的描述（C = 三进制只用 0 和 2 的数），再构造一个从 C 到 $[0,1]$ 的满射。既然 $[0,1]$ 不可数，被它满射投影的 C 也不可数。

逐步推导：

第一步（Cantor 集的构造与"长度归零"的错觉）：从 $[0,1]$ 开始，第 1 次挖去开区间 $\left(\frac{1}{3},\frac{2}{3}\right)$，剩 $[0,\frac{1}{3}]\cup[\frac{2}{3},1]$，总长 $\frac{2}{3}$；第 2 次再对剩下的两段各挖中间三分之一，剩 4 段，总长 $\frac{2}{3}\cdot\frac{2}{3}=\frac{4}{9}$；第 n 次后总长

$$\left(\frac{2}{3}\right)^n \xrightarrow{n\to\infty} 0.$$

具体数值：$n=1$ 时 0.666667，$n=2$ 时 0.444444，$n=3$ 时 0.296296，$n=5$ 时 0.131687，$n=10$ 时 0.017342，$n=20$ 时约 3.007×10^{-4}。挖去的总长度是 $\sum_{k\ge1}\frac{2^{k-1}}{3^k}=1$。

- **容易得出的错误结论**："长度变成了 0，所以 Cantor 集是空的。"
- **正确的结论**：长度（**测度 (measure)**）为 0 **不等于**空集。Cantor 集非空（例如 $\frac{1}{3},\frac{2}{3},\frac{1}{9},\frac{1}{27}$ 等所有区间端点都在里面），而且它不含任何非平凡区间（是**完全不连通的**），但**它的基数与整个 $[0,1]$ 一样大**。这是"测度小"与"基数小"完全无关的经典范例。

第二步（三进制刻画）：三进制（trits 取值 $\{0,1,2\}$）下：– $[0,1]$ 中每个数写成 $0.t_1t_2t_3\dots$（同样约定不用全 2 结尾的歧义表示；端点需特殊处理，例如把 $\frac{1}{3}$ 写成 $0.0\overline{2}$ 而不是 0.1，把 $\frac{2}{3}$ 写成 0.2）。– 第 1 次挖掉的中间三分之一 $\left(\frac{1}{3},\frac{2}{3}\right)$ 恰好是首位为 1 的数，即 $0.1xxx\dots$。– 第 2 次挖掉的是 $0.01xxx\dots$ 与 $0.21xxx\dots$，即第二位为 1 的数。– 第 3 次挖掉第三位为 1 的数……第 n 次挖掉第 n 位为 1 的数。

于是**被挖去的点 = 三进制展开中至少有一位为 1 的点**，剩下的正是

$$\boxed{C=\{x\in[0,1]:\ x\text{ 有一个只含 }0,2\text{ 的三进制展开}\}}$$

逐项验算两个"意外"的点：– $\frac{1}{4}$：$\frac{1}{4}=0.\overline{02}_3=0.020202\dots_3$（用等比级数验算：$2\cdot3^{-2}+2\cdot3^{-4}+2\cdot3^{-6}+\dots=\frac{2/9}{1-1/9}=\frac{2/9}{8/9}=\frac{1}{4}$ ✓）。数字只有 0 和 2，所以 $\frac{1}{4}\in C$。– $\frac{3}{10}$：0.3 的三进制展开为 $0.02200220022002\dots_3$，同样只含 0 和 2，所以 $\frac{3}{10}\in C$。

第三步（构造从 C 到 $[0,1]$ 的满射 f）：对 $x\in C$，取它只含 $0,2$ 的三进制展开 $x=0.t_1t_2t_3\dots_3$，把**每个数字除以 2**（即 $0\mapsto0$，$2\mapsto1$），得到二进制小数

$$f(x)=0.\frac{t_1}{2}\frac{t_2}{2}\frac{t_3}{2}\dots_2.$$

例如 $x=0.0220_3\mapsto f(x)=0.0110_2$。

第四步（f 是满射）：任取 $y\in[0,1]$，取它的二进制展开 $y=0.b_1b_2b_3\dots_2$（$b_k\in\{0,1\}$）。把每位乘以 2 得到三进制数 $x=0.(2b_1)(2b_2)(2b_3)\dots_3$，其数字只含 $0,2$，故 $x\in C$，且 $f(x)=y$。所以 f 是满射。（f 不是单射——例如 $0.20\overline{2}_3$ 与 0.22_3 会映到同一个二进制数——但**满射足够**，因为我们只需要"C 至少和 $[0,1]$ 一样大"。）

第五步（收口 C 不可数）：$f:C\to[0,1]$ 满射，故 $|C|\ge|[0,1]|$。又 $C\subseteq[0,1]$，故 $|C|\le|[0,1]|$。由 Cantor–Bernstein，$|C|=|[0,1]|=|\mathbb{R}|$，C 不可数。■

第六步（超越数存在 —— 非构造性存在性证明的漂亮范例）：

- **定义**：实数 r 是**代数数 (algebraic)**，若它是某个非零整系数多项式的根；否则叫**超越数 (transcendental)**。
- **代数数可数**：这是定理 12.6 第五步的结论。
- **实数不可数**：这是定理 12.8 的结论。
- **于是**：若不存在超越数，则 $\mathbb{R}$ = 代数数之集，而右边可数、左边不可数，矛盾。所以**必然存在超越数**。更强地：$\mathbb{R}\setminus\mathcal{A}$ 不可数（因为可数集从不可数集中挖掉后仍不可数），即**几乎所有的实数都是超越数**。

这个证明的非构造性值得大书一笔：它**没有给出任何一个具体的超越数**。它只是把两个可数性事实摆在一起，就断定"一定有"。数学史上，Liouville 在 1844 年构造出第一个超越数，Hermite 在 1873 年证明 e 超越，Lindemann 在 1882 年证明 π 超越——这些具体构造都很困难。但**基数论证告诉我们，这样的数遍地都是，多到"随便扔一根针都能扎中一个"**。更妙的是：此时此刻，你能说出名字的每一个具体实数（$\sqrt{2}$、e、π、$\ln2$、γ……）几乎都是"例外"，而剩下的那个不可数的汪洋大海里的数，我们连命名都做不到——因为名字本身只是有限长的字符串，总共只有可数多个！**名字可数，实数不可数，所以绝大多数实数永远无法被命名。** 这是本讲最富哲学意味的结论。

【证明机制解说】：Cantor 集这一段展示了"三进制/二进制转换"作为证明工具的威力：**把"几何的挖洞过程"翻译成"数字的限制条件"**，几何难题立刻变成字符串问题，而字符串问题我们已经有现成的可数性/不可数性工具（定理 12.5、12.7）。这种"换一种表示让问题变形"的手法，与 Lecture 4–6 里"把同余问题换成模 p 的域上运算"、Lecture 7–8 里"把秘密共享换成多项式插值"是同一种数学品味。

与经典问题的联系

1. 为什么计算机科学家必须关心无穷的大小：问题的层次

本讲的直接动机是：**我们想知道"问题"是否比"程序"多**。设 $\mathcal{F}$ 是所有函数 $g:\{0,1\}^*\to\{0,1\}$ 之集（每个函数代表一个"判定问题"：给定输入串，返回 yes/no）。

- **程序是可数的**：一台程序（无论是 Python、C 还是图灵机）最终都表示为**有限长的比特串**。由定理 12.5，所有有限比特串之集 $\{0,1\}^*$ 可数。程序是 $\{0,1\}^*$ 的一个子集，故程序可数。
- **函数是不可数的**：每个函数 $g:\{0,1\}^*\to\{0,1\}$ 由它在一列穷尽的输入 $\varepsilon,0,1,00,01,\ldots$ 上的取值唯一确定，即由一条**无穷比特串**确定。所有无穷比特串之集 $\{0,1\}^\infty$ 与 $\mathcal{P}(\mathbb{N})$ 一一对应，由定理 12.7 不可数。故 $\mathcal{F}$ 不可数。
- **结论（鸽笼式论证）**：设 $\mathcal{P}$ 为所有程序之集，$\mathcal{F}$ 为所有判定问题之集。每个程序至多计算**一个**函数（确定型程序的行为完全由源码决定），于是有一个从 $\mathcal{P}$ 到 $\mathcal{F}$ 的**函数** $\mathbf{sem}:\mathcal{P}\to\mathcal{F}$（把程序映到它计算的函数）。因为 $|\mathcal{P}|=\aleph_0<|\mathcal{F}|$，$\mathbf{sem}$ **不可能满射**（满射要求 $|\mathcal{P}|\geq|\mathcal{F}|$）。所以**必有函数不属于任何程序的像**——即**存在不可计算的问题 (uncomputable problem)**。

ASCII 图景：

```
text 程序集 P（可数）  函数集 F（不可数）
┌─┐ ┌──────────────────────────────┐
│P0│── sem ──────────────────────► │ f0 = sem(P0) │
│P1│── sem ──────────────────────► │ f1 = sem(P1) │
│P2│── sem ──────────────────────► │ f2 = sem(P2) │
│P3│── sem ──────────────────────► │ f3 │
│...│                              │ f* ← 没有任何程序映到这里│
└─┘ └─┘                          └──────────────────────────┘
 可数多个起点
```

想象"用可数多个飞镖去打不可数多个靶子"—无论怎么扔，靶子都打不完。 这是一次**用计数（可数性）证明存在性**的示范：我们连那个不可计算的函数长什么样都不知道，却知道它一定存在。与定理 12.9 证明超越数存在的手法完全同构。

2. 计数器论证 vs. 构造性论证：两种"证明不可能"的路径

- **计数路线（本讲）**：证明"程序可数、问题不可数"，得到**存在**不可计算的问题，但指不出是哪一个。
- **对角线路线（下一讲）**：直接构造（或指出）一个具体的不可计算问题——**停机问题**——并给出它不可计算的反证法证明。 两条路线互相印证：计数路线说明"不可计算"是常态（不可计算的函数占了压倒性多数），对角线路线则把其中一个抓出来示众。**把这两条合起来看，你就明白"计算机不能做所有事"不是工程局限，而是数学定理。**

3. 编码与压缩：为什么"可数"是一把尺子

定理 12.5–12.6 的编码技术（把结构映射为串、把串映射为自然数）在工程上就是**序列化 (serialization)**： – Cantor **配对函数** $\pi(i,j)=\frac{(i+j)(i+j+1)}{2}+j$ 是"把二维坐标压成一维下标"的标准手法。它在实际代码里就是"用一个大整数编码一个二维键"（常见于把 (x,y) 坐标存进单一整型键做哈希）。 – **多项式编码**（系数二进制 + 分隔符 2）就是"把一个结构体序列化成字节流"的思想雏形。 – 一个自然的**信息论直觉**：既然 $\mathbb{N}$、$\mathbb{Z}$、$\mathbb{Q}$、$\mathbb{N}[x]$ 全部可数，它们之间可以互相编码、互相解码，从而**没有哪一个"信息量更大"**。而 $\mathbb{R}$ 不可数，意味着实数带的信息量严格更多——这与 Lecture 23 之后（集中不等式、连续分布）要面对的"连续型随机变量无法用有限比特精确表示"这一事实同源。

4. 与编译器和程序分析的联系

编译器会做各种静态分析（判断代码里某变量是否可达、某循环是否有副作用）。本讲 + 下一讲告诉我们：**这类分析的"完全版本"必然不可判定**（下一讲将用"归约"精确证明）。工程上的应对不是追求完美，而是：(a) 保守近似（能判定的子类判定，其余一律报"不确定/不安全"）；(b) 加超时（模拟 k 步，超了就放弃）。理解"为什么不可能完美"是理解"为什么工程上要这样妥协"的前提。

与其他讲次的关联

- **与 Lecture 0–L03（证明工具箱）**：本讲的证明方法全部来自前面。定理 12.1 是**直接证明 + 分情形**（按奇偶、按正负分类）；定理 12.7、12.8 是**反证法 (proof by contradiction)**——这是 L02 "证明技巧 II" 里学的技巧第一次被用于"证明不可能"；定理 12.3 的"每个元素迟早被访问到"隐含使用了 L00 关于"前 k 条对角线只有有限多格"的**有限性推理**；定义与量词（"f 是满射 $\iff(\forall y\exists x)f(x)=y$"）的设置则直接来自 L01 的**命题逻辑与谓词逻辑**。可以说：**前面每一讲都在为这一讲磨刀。**
- **与 Lecture 3（Induction）**：定理 12.5 中"$\{0,1\}^*$ 的枚举不重不漏"以及 $\{0,1\}^\infty$ 与 $\mathcal{P}(\mathbb{N})$ 的对应，背后的"按长度分层"结构在形式上就是 L03 归纳法的分块思想（把无限过程切成无限多个有限步骤，每步可验证）。定理 12.2 中"前 s 个壳共有 $\frac{s(s+1)}{2}$ 个元素"的求和公式在课堂上通常由 L03 的归纳法证明。
- **与 Lecture 4–L06（模运算、Euclid、RSA）**：定理 12.4 依赖**最大公约数**与**最简表示的唯一性**——这直接是 L05 "欧几里得算法"的内容。更重要的一层联系：L04–L06 表面上研究有限结构（模 m 的剩余类只有 m 个），但 RSA 的**明文空间**是 $\{0,1\}^*$ 的有界片段。正是因为明文是有限串（可数），"给每个消息编号"这件事才有意义。
- **与 Lecture 7–L08（Polynomials / Secret Sharing）**：定理 12.6 把多项式当作可编码对象，而"一个次数 d 的非零多项式至多有 d 个根"（**代数基本定理 (Fundamental Theorem of Algebra)** 的弱形式）是 L07 秘密共享方案正确性的基石。同一事实在这里被用来证明"代数数可数"：多项式可数 + 每个多项式有限个根 $\Longrightarrow$ 根的总集可数。
- **与 Lecture 9–L10（Graphs）**：图也可以被编码成有限串（顶点数、邻接矩阵按位列出），所以**所有有限图的集合可数**——这是把定理 12.5 的模板再一次套用。反过来说，如果允许图有可数无穷多个顶点，"所有图之集"就不可数了。这与 L10 中的超立方体（n 维立方体图是有限图）形成对照。
- **与 Lecture 11（Stable Matching）**：Gale–Shapley 算法是一个**总是终止**的程序，所以它计算的函数是可计算的。Stable Matching 的存在性证明（"算法终止时配对照一定是稳定的"）与停机问题形成反差：前者保证终止，后者的核心正是"终止与否不可判定"。
- **与 Lecture 13（Computability）**：这是本讲最直接的衔接。下一讲会：
- 用定理 12.5（程序可数）把程序排成 $P_0,P_1,P_2,\ldots$；
- 用定理 12.7 的对角线技巧（"翻转对角元素"）证明停机问题不可判定；
- 用"程序可数 vs 函数不可数"（本讲第 1 条经典联系）说明"不可计算的函数多得是"。
- **与 Lecture 14（Counting）及之后**：可数性是"无穷版的计数"。L14 教**有限集**的计数法则（乘法法则、容斥、双射计数），本讲证明 $|\mathbb{N}|=|\mathbb{Q}|$ 的"约分去重"与 L14 的"双射计数"是同一件事在无穷上的推广。此外，L14 的计数结论（如 $\binom{n}{k}$）在 L15 概率公理中用来计算等可能样本空间的大小，那里的样本空间都是**有限**

的——本讲正好说明了"为什么概率论默认样本空间有限或可数"（不可数样本空间上"等可能"没有定义）。

关键要点

1. **等势的定义是双射，可数是"能用自然数编号"**：$|A|=|B| \iff$ 存在双射 $A\to B$；S 可数 $\iff S$ 有限或存在双射 $\mathbb{N}\to S$。**不要用包含关系判断无穷集的大小**——$\mathbb{N}\subsetneq\mathbb{Z}$ 但 $|\mathbb{N}|=|\mathbb{Z}|$，无穷集可以和自己的真子集等势（$|\mathbb{N}|=|2\mathbb{N}|$）；可数**不等于**有限，也不要求"列完"，只要求每个元素被赋予**有限**的编号且编号不重不漏。这两条定义是本讲一系列反直觉结论（而非矛盾）的根源。
2. **对角线枚举的模板**：把无穷集切成**可数多个有限块**（按 $i+j$ 分层、按串长分层、按 $|a|+b$ 分壳），块间递增、块内定序。这一个模板通吃 $\mathbb{N}\times\mathbb{N}$、$\{0,1\}^*$、$\mathbb{Q}$、$\mathbb{N}[x]$、所有程序、所有证明。**别用"行优先"扫描，第一行永远扫不完。**
3. **Cantor 定理：$|A|<|\mathcal{P}(A)|$ 对一切集合成立**。核心是 $D=\{a\in A:a\notin f(a)\}$：构造一个"处处与自己的候选人唱反调"的对象，使它必然不在任何满射的像中。取"$\notin$"而非"$\in$"是本质的。
4. **Cantor–Bernstein 定理是最实用的夹逼工具**：要证 $|A|=|B|$，只需两个方向的单射。用它可以把"造双射"降级成"造单射"，从而允许"良定义 + 单射"的两步验证（定理 12.4、12.6 全靠这一招）。
5. **两个层次的无穷，与桥向 L13 的结论**：$|\mathbb{N}|=|\mathbb{Z}|=|\mathbb{Q}|=|\mathbb{N}\times\mathbb{N}|=|\{0,1\}^*|=|\mathbb{N}[x]|=\aleph_0$（可数）；$|\mathbb{R}|=|[0,1]|=|\mathcal{P}(\mathbb{N})|=|\{0,1\}^\infty|=2^{\aleph_0}=\mathfrak{c}$（不可数），且 $\aleph_0<\mathfrak{c}$。**程序可数、函数不可数 ⇒ 存在不可计算的函数。**

常见误区与注意事项

1. **用包含关系代替双射来比较无穷集的大小**。"$\mathbb{Z}$ 比 $\mathbb{N}$ 多了无穷多个负数，所以更大"——错。显式双射 $f(x)=x/2$（偶）、$f(x)=-(x+1)/2$（奇）已经证明二者等势。**判断无穷集大小只看能否配对，不看谁包含谁。**
2. **把"可数"理解成"能列完"或"很小"**。$\mathbb{Q}$ 在数轴上**稠密 (dense)**（任意两个有理数间还有有理数），看起来"到处都是"，但可数；$\mathbb{N}\times\mathbb{N}$ 看起来是二维的、比 $\mathbb{N}$"大一个维度"，也可数。**"看起来稀疏/稠密/高维"都不是判据，"列不完"也不是不可数的证据。**
3. **把"每个元素有限"误当成"整体有限"或"整体可数"**。$\{0,1\}^*$ 中每个串长度有限，且整体可数（这两件事一致但需要证明）；$\{0,1\}^\infty$ 中每个串长度无限，整体不可数。**"有限长"这个词修饰的是元素，不是集合。**
4. **对角线论证忘了确认新构造的对象属于原集合**。在 $\mathbb{R}$ 上改对角位得到的新数一定是实数（所以论证成立）；在 $\mathbb{Q}$ 上改对角位得到的新数**未必**是有理数（所以论证失败）。**每次用对角线，都必须检查"我造出来的东西还在集合里吗？"**
5. **忘了处理小数的双重表示**。$0.4999\ldots=0.5$、$0.999\ldots=1$。若不做规范约定（统一用"不以 9 结尾"的表示，或把新数限制在 $\{1,\ldots,8\}$ 内），"s 与 $f(n)$ 第 $n+1$ 位不同 $\Rightarrow s\neq f(n)$"这一步就会站不住。
6. **造单射时忘了验证"良定义"与"可唯一解码"**。定理 12.4 中 \(f(q)=\sigma(\text{\\q<u>Extra close brace or missing open brace</u>，必须说明最简表示**唯一**（否则 $f(q)$ 会因表示选择而不同）；定理 12.6 的编码必须能**唯一解码**——去掉分隔符 2 就会让 f 失去单射性（$(5,2,7)$、$(5,27)$、$(52,7)$ 编码撞车）。此外还要留意定理 12.3 的条件是"**可数**多个"：不可数多个可数集的并可以不可数（$\bigcup_{r\in[0,1]}\{r\}=[0,1]$），用之前先确认下标集合 I 可数。

思考题（带答案）

Q1. 定义 $f:\mathbb{N}\to\mathbb{Z}$ 为 $f(x)=\frac{x}{2}$（x 偶数）、$f(x)=-\frac{x+1}{2}$（x 奇数）。请（a）写出 $f(0),\ldots,f(10)$；（b）求 $f(124)$；（c）求 $f^{-1}(-7)$、$f^{-1}(50)$、$f^{-1}(-50)$。

> ▸ **答案**
>
> （a）x 从 0 到 10：偶数 $0,2,4,6,8,10$ 分别映到 $0,1,2,3,4,5$；奇数 $1,3,5,7,9$ 分别映到 $-\frac{2}{2}=-1,-\frac{4}{2}=-2,-\frac{6}{2}=-3,-\frac{8}{2}=-4,-\frac{10}{2}=-5$。所以序列是
>
> $$0,\ -1,\ 1,\ -2,\ 2,\ -3,\ 3,\ -4,\ 4,\ -5,\ 5.$$
>
> （和"从 0 出发左右横跳"的直观一致。）
>
> （b）124 是偶数，$f(124)=124/2=62$。
>
> （c）逆函数为 $f^{-1}(y)=2y$（$y\geq 0$）、$f^{-1}(y)=-2y-1$（$y<0$）。– $f^{-1}(-7)$：$y=-7<0$，$f^{-1}(-7)=-2\cdot(-7)-1=14-1=13$。核对：$13$ 是奇数，$f(13)=-\frac{14}{2}=-7$ ✓ – $f^{-1}(50)$：$y=50\geq 0$，$f^{-1}(50)=100$。核对：$f(100)=50$ ✓ – $f^{-1}(-50)$：$y=-50<0$，$f^{-1}(-50)=100-1=99$。核对：99 是奇数，$f(99)=-\frac{100}{2}=-50$ ✓
>
> **脚本验算输出**：`f(0..10)=0,-1,1,-2,2,-3,3,-4,4,-5,5`；`f(124)=62`；`preimage of -7 = 13, of 50 = 100, of -50 = 99`；在 $[-200,200]$ 上逐点验证 f 为双射通过。

Q2. 计算 Cantor 配对函数 $\pi(i,j)=\frac{(i+j)(i+j+1)}{2}+j$：（a）求 $\pi(3,4)$、$\pi(4,3)$、$\pi(0,5)$、$\pi(5,0)$；（b）若 $\pi(i,j)=20$，求 (i,j)；（c）若 $\pi(i,j)=100$，求 (i,j)；（d）解释为什么 $\pi(3,4)\neq\pi(4,3)$ 对"$\mathbb{N}\times\mathbb{N}$ 可数"的证明是必要的。

▸ 答案

（a）逐个代入：– $\pi(3,4)$：$s=3+4=7$，$\frac{7\cdot 8}{2}+4=28+4=\mathbf{32}$。– $\pi(4,3)$：$s=7$，$\frac{7\cdot 8}{2}+3=28+3=\mathbf{31}$。– $\pi(0,5)$：$s=5$，$\frac{5\cdot 6}{2}+5=15+5=\mathbf{20}$。– $\pi(5,0)$：$s=5$，$\frac{5\cdot 6}{2}+0=\mathbf{15}$。

（b）求 s 使 $\frac{s(s+1)}{2}\le 20<\frac{(s+1)(s+2)}{2}$：$\frac{5\cdot 6}{2}=15\le 20<21=\frac{6\cdot 7}{2}$，所以 $s=5$。则 $j=20-15=5$，$i=s-j=0$。故 $(i,j)=(0,5)$。

（c）$\frac{13\cdot 14}{2}=91\le 100<105=\frac{14\cdot 15}{2}$，所以 $s=13$。$j=100-91=9$，$i=13-9=4$。故 $(i,j)=(4,9)$。

（d）π 要成为**双射**（而不只是满射），它必须把不同的格子送到不同的编号；若 $\pi(3,4)=\pi(4,3)$，则 $(3,4)$ 与 $(4,3)$ 两个格子共用一个编号，编号就不再是"每个格子恰好一个门牌号"，于是不能构成 $\mathbb{N}\times\mathbb{N}$ 与 $\mathbb{N}$ 的双射，只能得到一个满射 $\mathbb{N}\to\mathbb{N}\times\mathbb{N}$（方向还反了）。更实质地说：**单射性保证了"去重"不必要**，也保证了枚举不重不漏；若只满射不单射，我们仍能证明可数（因为满射 $\mathbb{N}\to S$ 已足以说明 $|S|\le|\mathbb{N}|$，可用 Cantor–Bernstein），但证明会多绕一步。而 π 的设计（同一 s 内按 j 递增）恰好让 $\pi(3,4)=32$、$\pi(4,3)=31$ 自动错开。

脚本验算输出：`pair(3,4)=32, pair(4,3)=31, pair(0,5)=20, pair(5,0)=15`；`unpair(20)=[0,5], unpair(15)=[5,0], unpair(100)=[4,9]`；在 $0\le i,j\le 19$ 的 400 个格子上无碰撞，且 $z=0..399$ 上逆函数逐点校验正确。

Q3. 判断并说明理由（$[0,1]$ 的循环小数/规范表示请沿用正文约定）：

（a）"$\mathbb{R}$ 不可数，所以 $\mathbb{R}\setminus\mathbb{Q}$（无理数）不可数。"（b）"$\mathbb{Q}$ 可数，所以 $\mathbb{Q}\cap[0,1]$ 也可数。"（c）"$\{0,1\}^\infty$ 不可数，所以 $\{0,1\}^*$（有限串）也不可数。"（d）"因为 $\mathbb{Q}$ 稠密，所以 $\mathbb{Q}$ 不可数。"

▸ 答案

（a）**正确**。反证：若 $\mathbb{R}\setminus\mathbb{Q}$ 可数，则 $\mathbb{R}=(\mathbb{R}\setminus\mathbb{Q})\cup\mathbb{Q}$ 是两个可数集之并，由定理 12.3（有限个/可数个可数集之并可数）得 $\mathbb{R}$ 可数，与定理 12.8 矛盾。所以无理数不可数。（顺带得到：**代数数可数 + 无理数不可数 $\Longrightarrow$ 超越数不可数**，即定理 12.9 第六步的加强版。）

（b）**正确**。可数集的任何子集都可数：若 $h:\mathbb{N}\to\mathbb{Q}$ 是无重复无遗漏的枚举，则把 h 限制在 $\{n:h(n)\in[0,1]\}$ 上（保序地重新编号）即得 $[0,1]\cap\mathbb{Q}$ 的枚举。（正式地：$|\mathbb{Q}\cap[0,1]|\le|\mathbb{Q}|\le|\mathbb{N}|$。）

（c）**错误**。恰恰相反，$\{0,1\}^*$ 可数（定理 12.5）。这里混淆了"元素长度无限"和"集合不可数"。"不可数"的 $\{0,1\}^\infty$ 与"可数"的 $\{0,1\}^*$ 之间只差"长度是否有限"这一个字，但基数差整整一级。记住正文的判据：$\{0,1\}^\infty$ 与 $\mathcal{P}(\mathbb{N})$ 一一对应，故不可数；$\{0,1\}^*$ 可被"按长度分块、块内按字典序"不重不漏地列举，故可数（$\mathbf{idx}(s)=(2^{|s|}-1)+v$）。

（d）**错误**。稠密是关于**序**的性质（任意两个有理数之间还有有理数），基数大小是关于**能否配对**的性质，两者互不蕴含。$\mathbb{Q}$ 既稠密又可数（定理 12.4）。反过来的例子也存在：整数集在 $\mathbb{R}$ 中不稠密（如 $(0.1,0.9)$ 中没有整数），但 $\mathbb{Z}$ 可数——所以稠密与可数性完全是两条独立的轴。**这也解释了为什么"看起来到处都是"不能作为不可数的证据**。

脚本验算佐证：反对角线枚举的前 19 个有理数为 `0/1, −1/1, 1/1, −2/1, −1/2, 1/2, 2/1, −3/1, −1/3, 1/3, 3/1, −4/1, −3/2, −2/3, −1/4, 1/4, 2/3, 3/2, 4/1`（跳过所有 $\gcd\neq 1$ 的格子后无重复）；$3/4$ 在壳 $s=7$ 出现，说明"稀疏"并不妨碍可数。

Lecture 13: Computability（可计算性）

概述

上一讲（Lecture 12）我们证明了**程序可数、函数不可数**，从而知道"存在无法由任何程序计算的问题"。但那个证明是**非构造性**的：它指不出到底是哪一个问题不可计算。本讲补上这一刀——我们把一个具体的、日常到不能再日常的问题抓出来示众：**停机问题 (the Halting Problem)**。给定程序 P 与输入 x，能否判断 $P(x)$ 最终会不会停下来？Turing 在 1936 年证明：**不能**，而且不是"还没找到算法"，是**数学上不存在**这样的算法。整个证明只用两样工具：（1）**自指 (self-reference)**——程序本身也是字符串，可以作为另一个程序的输入；（2）**对角线论证**——和上一讲打倒实数用的是同一个手势。最后我们把这一招推广成两项通用技术：**可判定 vs. 可识别 (decidable vs. recognizable)** 的区分，以及**归约 (reduction)**。

核心概念的直观解释

自指 (Self-Reference)

- **定义**：一个陈述、程序或公式如果**指向自身**（引用自己的内容、自己的代码、或自己的编号），就称为自指的。
- **直观解释（"它是什么意思？"）**：自指是"照镜子"。日常语言里它产生悖论（"这句话是假的"）；在计算机里它产生**强大的构造能力**（程序可以分析自己）。为什么计算机里自指是合法的？因为**程序和数据在物理上是同一种东西**——都是比特串。一台计算机不区分"这是一段代码"还是"这是一份数据"，区别只在**如何解释 (interpret)** 这串比特。所以完全可以把一个程序的源码当作另一个程序的输入传给对方，甚至可以把它传给它自己。
- **具体示例**：`Halt(P, x)` 中把 P 当数据传入；`Halt(P, P)` 中把 P 同时当程序和输入。这一步"看起来很怪"但完全合法，因为 P 是一个比特串，字符串当然可以作为字符串的输入。

Quine（自打印程序）

- **定义**：一个**不读取任何输入**、运行后**输出自己的完整源代码**的程序，称为 quine。（名字来自逻辑学家 Willard Van Orman Quine。）
- **直观解释**：如果一段程序能输出自己，那么"程序的代码"和"程序产生的数据"之间就没有了界限。用自然语言可以做出这个魔术：`text 版本 1（失败）： 指令：打印下面这句话： "打印下面这句话：" 输出： 打印下面这句话： ✗ 少了引号那一行，输出 ≠ 指令本身（指令有两行，输出只有一行） 版本 2（失败）： 指令： 把下面这句话打印两次： "把下面这句话打印两次：" 输出： 把下面这句话打印两次： 把下面这句话打印两次： ✗ 长度对了，但第二行缺引号 版本 3（成功）： 指令： 把下面这句话打印两次，第二次带引号： "把下面这句话打印两次，第二次带引号：" 输出： 把下面这句话打印两次，第二次带引号： "把下面这句话打印两次，第二次带引号：" ✓ 输出与指令逐字相同！`关键在版本 3 的措辞："第二次带引号"。它让程序**同时**输出"自己的指令部分"和"自己的数据部分"，两者拼起来恰好是完整的自己。

- **具体示例（真正的伪代码 quine）**：官方 Note 给的极简伪代码是 `text (Quine "s") (s "s")` 含义：程序 Quine 接收一个字符串 s，输出 (s "s") 这个调用式本身（把 s 当程序跑在 s 自己身上）。 执行 (Quine "Quine"): Quine 收到 s = "Quine"，于是输出 (Quine "Quine") —正是刚才那条指令！ 这就是"自打印"的最小骨架：程序里**没有写死自己的源码**，而是写了一个"把自己名字代入自己"的**模板**，代入后恰好生成自己。

递归定理 (Recursion Theorem)

- **定义**：设 $P(x, y)$ 是任意程序。则存在程序 $Q(x)$，使得对一切 x，

$$Q(x) = P(x, Q),$$

其中第二个参数传入的是 Q **自身的描述**（源码）。 – **直观解释**：递归定理说**任何程序都可以被改造成"有自我意识"的版本**——它在运行时能拿到自己的源码，就像人在做决定时能"想到自己正在思考"。它是 quine 存在性的通用保证：取 $P(x, y) = y$（忽略 x 直接输出 y），则 $Q(x) = Q$，即 Q 输出自己的源码 = quine。所以"任何编程语言里都能写 quine"不是巧合，而是定理。 – **具体示例**：上面那个 `(Quine "s") / (s "s")` 就是递归定理的一个具体实现：它把"要打印的字符串"作为参数 s 传进来，输出的 `(s "s")` 就是"s 跑在 s 自己身上"。Q 的行为依赖于自己的描述，这正是 $Q(x) = P(x, Q)$ 的形式。

停机问题 (The Halting Problem)

- **定义**：**停机问题**是如下判定问题：给定程序 P 的源码与输入 x，判断 P 在 x 上运行是否会在有限步内终止（halts），还是会永远运行下去（loops）。
- **直观解释**：这是编译器最想要的能力——如果编译器能预知"这段代码会不会死循环"，它就能警告程序员。这也是数学家最想要的能力——很多数学猜想（如哥德巴赫猜想）都可以改写成"某程序是否停机"，从而"判断停机"等价于"证明数学定理"。但 Turing 证明这个能力**根本不可能存在**：没有任何程序能对所有 (P, x) 都给出正确答案。
- **具体示例**：有些程序明显停机（`x = 3+4` 一行就结束），有些明显不停机（`while(true){}`）。真正难的是那些"行为复杂"的程序（比如"搜索最小的奇完全数，找到就停"——至今无人知道它会不会停）。**停机问题的不可判定性说的是：不存在一个通用算法同时搞定所有情况**，而不是"所有判断都做不到"（详见常见误区第 1 条）。

可判定 (Decidable) 与 可识别 (Recognizable)

- **定义**：设 $L \subseteq \{0,1\}^*$ 是一个语言（问题）。记 $\bar{L} = \{0,1\}^* \setminus L$ 为它的**补集 (complement)**。
- L 是**可判定的 (decidable)**：存在程序 M，对**每个**输入 $w \in \{0,1\}^*$，$M(w)$ 都在**有限步内终止**，且输出 yes 当 $w \in L$、输出 no 当 $w \notin L$。（M 是 L 的**判定器 (decider)**，永远给正确答案，从不死循环。）
- L 是**可识别的 (recognizable)**（又称**递归可枚举 / recursively enumerable**）：存在程序 M，使得对每个 w：若 $w \in L$，则 $M(w)$ **在有限步内终止并输出 yes**；若 $w \notin L$，则 $M(w)$ **可以永远运行下去**（也可以输出 no，但不作要求）。
- **直观解释（"它是什么意思？"）**：把判定问题想成"验票"。**可判定** = 有一个尽职的验票员，任何票给他，他都当场给出"真/假"，绝不含糊。**可识别** = 有一个"半尽职"的验票员：票是真的他一定认出来（等一会儿总会有结果）；票是假的，他可能永远举着票看下去，不给你任何答复。所以可识别是更弱的要求：**它只保证"能确认 yes"，不保证"能确认 no"**。
- **具体示例**：$L_{\text{HALT}} = \{\langle P, x\rangle : P(x) \text{ 停机}\}$。直觉上它**可识别**：拿到 $\langle P, x\rangle$ 就用模拟器一步步跑 $P(x)$；若它真停机，跑有限步后我们就看到了，立刻输出 yes。但它**不可判定**（稍后证明），而且它的**补贴 $\bar{L}_{\text{HALT}}$ 根本不可识别**。

归约 (Reduction)

- **定义**：设 A, B 是两个问题。若"给定能解 B 的算法，我能构造出解 A 的算法"，则称 A **归约到** B，记 $A \leq B$（读作"A 不比 B 难多少"）。
- **直观解释**：这是**"难度传递"**。它的用法有两种方向，务必要分清：
- **正向用**：若 $A \leq B$ 且 A 可解，则 B 可解（"简单问题归约到难问题，难问题也简单了"——这是证明**可解性**的方向）。
- **反向用（本讲的主力）**：若 $A \leq B$ 且 A **不可解**，则 B **也不可解**（"连简单问题都搞不定，难问题更别想"——这是证明**不可解性**的方向）。具体地说：**假设 B 有判定器，用它当子程序构造出 A 的判定器，这就矛盾了。**
- **具体示例**：本讲会证明"通用停机问题 $\leq$ 简单停机问题（P 是否在输入 0 上停机）"，从而用"通用停机问题不可判定"推出"简单停机问题也不可判定"。

完整证明与推导（核心）

定理 13.1（说谎者悖论与 Barber 悖论：自指的悖论结构）

定理 13.1：下列两个陈述都是**自指悖论 (self-referential paradox)**：它们既不能为真，也不能为假。

- **说谎者悖论 (Liar's Paradox)**：$S =$"这句话是假的。"
- **Barber 悖论 (Barber's Paradox)**：某村唯一的理发师宣布 $B =$"我给且只给所有不给自己刮胡子的人刮胡子。"

证明策略：分情形穷举 + 反证。每个悖论都只有两种可能（真/假，或刮/不刮），逐一分析，得出两种情形都导回自己的反面。这个证明的意义**不在于它有多难，而在于它把"自指如何制造矛盾"的机械结构暴露出来**——下一节我们会把这个结构逐字搬进程序世界。

逐步推导：

第一步（先看一个"不是悖论"的自指句）："所有克里特岛人都是说谎者"，说这话的人正是一个克里特岛人。这句**不是真悖论**：若它为真，则该克里特人在说谎，于是它为假——**这是一条有效的反驳**，说明它只能是假。而它为假时毫无矛盾（"并非所有克里特岛人都说谎"完全合理）。所以它只排除了一种情形，不构成循环。

第二步（说谎者悖论的真悖论性）：令 $S =$"S 是假的"。

- **情形 A：S 为真**。既然 S 为真，那么 S 所断言的内容就是事实；而 S 断言的内容正是"S 是假的"。所以 S 为假。这是一个矛盾（S 既真又假）。
- **情形 B：S 为假**。既然 S 为假，那么 S 所断言的内容不成立；而 S 断言的是"S 是假的"，其否定是"S 是真的"。所以 S 为真。这也是矛盾（S 既假又真）。

两种情形都矛盾，所以 S **既不能为真也不能为假**。用真值表把机制摊开（$T(S)$ 表示"S 为真"）：

```
┌──────────────┬──────────────────────────────┬──────────────┬──────────────┐
│ 假设         │ 由该假设得到的事实           │ 事实的后果   │ 结论         │
├──────────────┼──────────────────────────────┼──────────────┼──────────────┤
│ T(S) = 真    │ S 的内容"¬T(S)"成立          │ T(S) = 假    │ 矛盾         │
│ T(S) = 假    │ S 的内容"¬T(S)"不成立        │ T(S) = 真    │ 矛盾         │
└──────────────┴──────────────────────────────┴──────────────┴──────────────┘
        ↑ 两种假设都被自己的推论反驳 ⇒ 无解（不是"很难判断"，而是"没有真值可赋"）
```

一句话：T(S) 的真值方程是 T(S) = ¬T(S) —没有任何布尔值能满足它。

第三步（Barber 悖论）：村中只有一位理发师 b，且他宣布 B ="我给且只给**所有不给自己刮胡子的人**刮胡子"。换成一个精确的数学命题：对村中每个男人 m，

$$b \text{ 给 } m \text{ 刮胡子} \iff m \text{ 不给自己刮胡子}. \qquad (\star)$$

现在问：b 给自己刮胡子吗？同样只有两种情形：

- **情形 A：b 给自己刮胡子**。取 $m = b$ 代入 $(\star)$ 的左端——左端成立（b 给 b 刮）。由 $(\star)$ 知右端也必须成立，即"b 不给自己刮胡子"。矛盾。
- **情形 B：b 不给自己刮胡子**。取 $m = b$ 代入 $(\star)$ 的右端——右端成立（b 不给自己刮）。由 $(\star)$ 知左端也必须成立，即"b 给自己刮胡子"。矛盾。

两种情形都矛盾。用表格摊开：

```
┌──────────────────────┬──────────────────────────────────┬──────────────────┐
│ 假设                 │ 由理发师的公告 (⋆) 推出          │ 结论             │
├──────────────────────┼──────────────────────────────────┼──────────────────┤
│ b 给自己刮胡子       │ 因为"给自己刮"，所以 b ∉ {不自己刮的人} │                  │
│                      │ 但 (⋆) 说 b 只给 {不自己刮的人} 刮 ⇒ b 不给自己刮 │ 矛盾 │
├──────────────────────┼──────────────────────────────────┼──────────────────┤
│ b 不给自己刮胡子     │ 那么 b ∈ {不自己刮的人}          │                  │
│                      │ 但 (⋆) 说 b 给所有 {不自己刮的人} 刮 ⇒ b 给自己刮 │ 矛盾 │
└──────────────────────┴──────────────────────────────────┴──────────────────┘
   两行都被推翻 ⇒ 满足 (⋆) 的理发师不存在（现实中的出路：村里没有这样的理发师，
   或理发师的公告本身就是假的。矛盾落在"公告为真"这个假设上。）
```

第四步（抽象出共同结构）：两个悖论是同一个方程的两个化身。令 $f(x)$ 表示"x 的自我指涉谓词"（"x 是假的" / "x 给自己刮胡子"），悖论就来自

$$f(b) \iff \neg f(b) \quad (\text{对自己}).$$

任何布尔值代入都失败。**而这个方程正是下一节对角线论证要用的东西**：它在程序世界的替身是"$P(P)$ 停机 $\iff$ $P(P)$ 不停机"。

【证明机制解说】：自指悖论的"灵光"在于**让一个对象谈论自己**。这一招为什么在语言里产生悖论、在数学里产生定理（下一节）？区别在于：语言允许"这句话是假的"这样自由的自指；而在形式化系统里，自指必须通过**编码 (encoding)** 实现——把"关于某个对象的话"编码成一个对象，再让对象引用该编码。Turing 的洞察就是：**程序本身就是比特串，所以"程序分析程序"、"程序分析自己"都是合法操作**。于是语言层面的悖论在程序层面变成了定理。

反例（如果适用）：把 Barber 的公告改成"我给**所有**村里人刮胡子"（去掉"不给自己刮胡子的人"这个限定），矛盾立刻消失：b 给自己刮胡子，完全自洽。同样，把说谎者句改成"这句话是**真的**"，方程变成 $T(S) = T(S)$，任何真值都满足，不产生矛盾。**"自指"本身不是悖论的来源；"自指 + 取反/否定自身"才是。**

定理 13.2（停机问题不可判定）

定理 13.2：不存在程序 `TestHalt`，使得对**一切**程序 P 与一切输入 x，

$$\texttt{TestHalt}(P, x) = \begin{cases} \text{"yes"}, & \text{若 } P(x) \text{ 停机} \\ \text{"no"}, & \text{若 } P(x) \text{ 死循环} \end{cases}$$

即停机问题**不可判定 (undecidable)**。

证明策略：反证法 + 对角线论证（自指）。假设 `TestHalt` 存在；用它写一个"唱反调"的程序 `Turing`：喂它自己，若命中"停机"就故意死循环，若命中"死循环"就停机。最后考察 `Turing(Turing)` ——两种情形都矛盾。**这个证明与上一讲定理 12.7（Cantor 定理）结构完全同构**：那里的"候选人 $f(a)$"换成"程序 P_n"，"翻转对角元素"换成"把停机行为取反"。

逐步推导：

第一步（反证假设）：假设存在满足定理所述行为的程序 `TestHalt`。注意它的定义域是**所有的** (P, x) 对，且必须**总是终止**并给出正确答案（这正是 Lecture 12 里"可判定"的意义）。

第二步（合法性检查：为什么 P 可以当输入）：P 是一台程序的源码，它是一个有限长的比特串。输入 x 也是一个比特串。所以 $x := P$ 完全合法，"P 跑在 P 上"是一个百分之百有定义的问题。**这一步是自指得以可能的物理基础**（程序即数据），本讲开头已经强调，这里正式用上：`TestHalt(P, P)` 是有意义的调用。

第三步（构造唱反调的程序）：定义

```
Turing(P):
    if TestHalt(P, P) = "yes" then
        loop forever          ← P 在自身上停机，我偏偏死循环
    else
        halt                  ← P 在自身上死循环，我偏偏停机
```

这就是"处处与自己的候选人唱反调"。它构造完成的前提仅仅是第一步的假设（`TestHalt` 可用作子程序）。

第四步（把 `Turing` 喂给自己）：考察 `Turing(Turing)`。注意 `Turing` 自己也是一台程序，所以把 `Turing` 作为 `Turing` 的输入是合法的。它**要么停机要么不停机**，只有两种可能：

- **情形 A：`Turing(Turing)` 停机。** `Turing` 的代码里只有两处能停机：一是 `else halt` 分支，二是 `TestHalt` 本身返回。既然 `Turing(Turing)` 停机，它执行的一定是 `else halt` 分支，而这条分支被走到**当且仅当** `TestHalt(Turing, Turing)` 返回了 `"no"`。但 `TestHalt` 的语义规定它返回 `"no"` 意味着 `Turing(Turing)` 死循环。**所以 `Turing(Turing)` 应当死循环——与"它停机"矛盾。**
- **情形 B：`Turing(Turing)` 不停机。** `Turing` 的两个分支中，`else halt` 会立即停机，所以不停机只能来自 `loop forever` 分支，而这条分支被走到**当且仅当** `TestHalt(Turing, Turing)` 返回了 `"yes"`。但 `TestHalt` 的语义规定返回 `"yes"` 意味着 `Turing(Turing)` 停机。**所以 `Turing(Turing)` 应当停机——与"它不停机"矛盾。**

两种情形都矛盾。用图把调用关系画清楚：

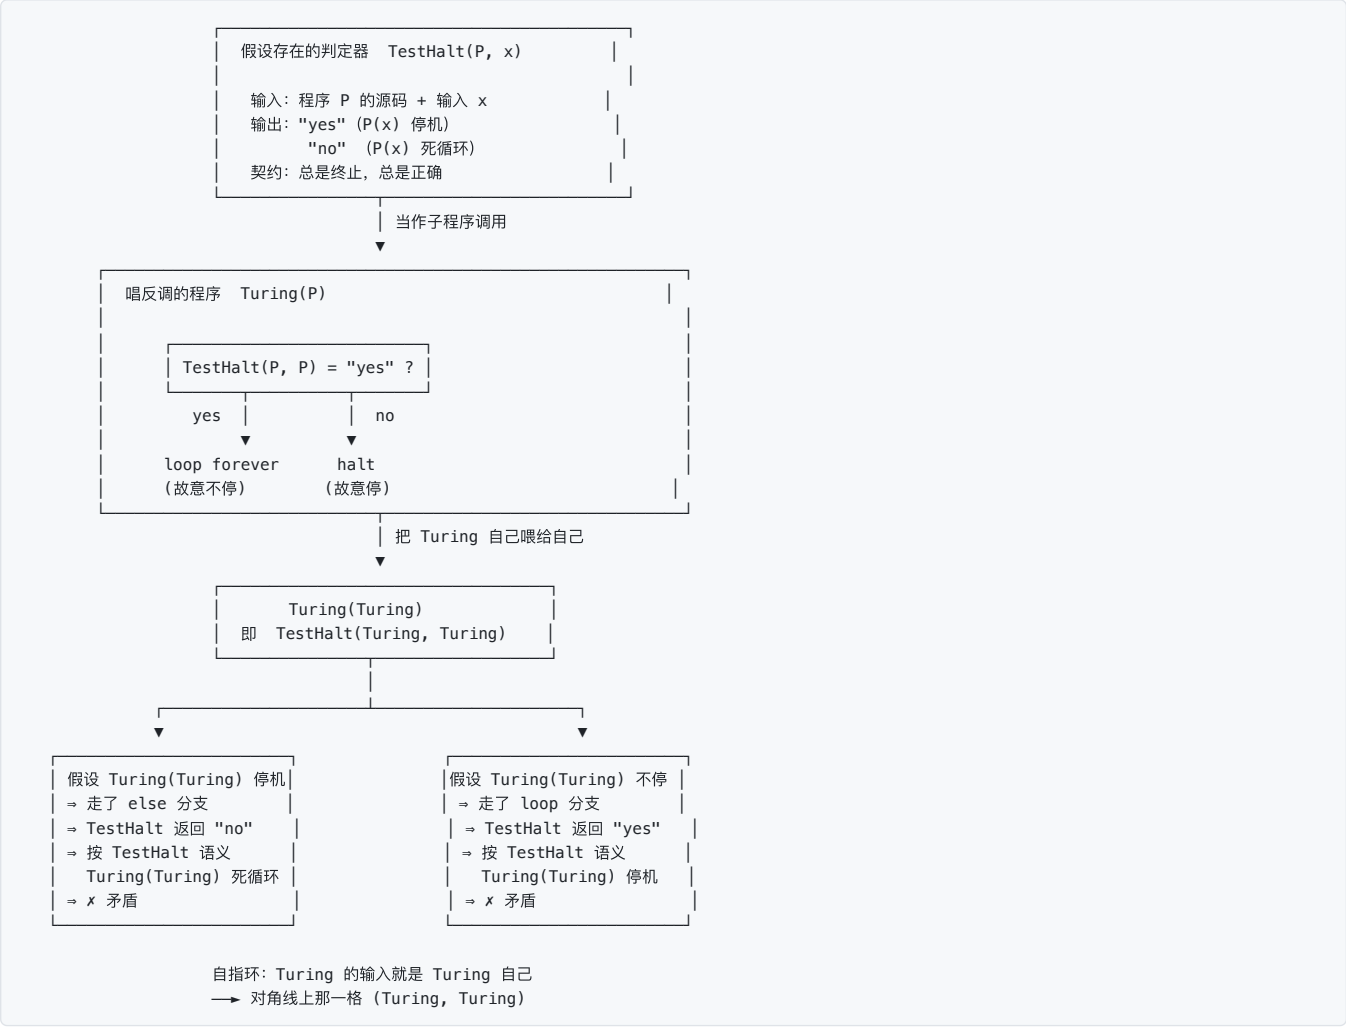

第五步（收口）：两种可能都矛盾，说明构造 `Turing` 的前提——"`TestHalt` 存在"——是假的。故不存在能对所有 (P, x) 正确判定停机的程序，停机问题不可判定。■

【证明机制解说】：这个证明的全部力量来自**"让程序吃自己"**。请注意它和定理 13.1 的对应关系：说谎者句说"我是假的"，`Turing` 说"如果我说我停，我就不停；如果我说我不停，我就停"。两者都构造了一个满足 $X = \neg X$ 的对象，从而无解。与 Cantor 定理的对应更精确：

Cantor 定理（Theorem 12.7）	停机问题（Theorem 13.2）
假设满射 $f : \mathbb{N} \to \mathcal{P}(\mathbb{N})$，列出所有子集	假设判定器 `TestHalt`，列出所有程序 $P_0, P_1, \ldots$
读对角线：$k \in f(k)$ 吗？	读对角线：P_n 在 P_n 上停机吗？
翻转：令 $D = \{k : k \notin f(k)\}$	翻转：令 `Turing(P)` 的行为与 $P(P)$ 相反
D 不在像中 ⟹ 矛盾	`Turing` 不在列表中 ⟹ 矛盾

特别强调：这不是"我们还没找到算法"。定理说的是**不存在**这样的算法——它是对**所有可能的程序**（包括未来任何人能想出的任何程序）的否定。这个区别是"存在性证明"与"不可能性证明"的区别，也是数学最有力的地方：它一劳永逸地关上了一扇门，让后人不必徒劳地寻找。**上一讲的计数论证已经告诉我们这样的结果是必然的（程序可数、函数不可数），本讲则把具体是哪一个抓了出来。**

反例（如果适用）：试图用"加超时"绕过不可判定性是**无效的**。定义 `TestHaltBounded(P,x,k)`：跑 $P(x)$ 至多 k 步，若停机返回 `"yes"`，否则返回 `"don't know"`。这是**可判定**的、完全合法的程序，但它**没有**解决停机问题——它在死循环的情形只能说 `"don't know"`，而不是 `"no"`。想把它变成判定器就必须在"跑了

k 步还没停"时断言"永远不停"，而这个断言正是不可判定的核心。**任何"有限等待"方案都只能得到"可识别"，得不到"可判定"。**

定理 13.2 的延伸：对角化方法的统一视角

到这里我们已经见过三次"对角线"，它们是**同一个技巧的三件外衣**。把三者的结构并排放在一起，你会看到一个完全一致的模板：

```
┌──────────────┬──────────────────────┬──────────────────────┬──────────────────────────┐
│              │  Cantor 定理         │  R 不可数            │  停机问题不可判定        │
│              │  |A| < |P(A)|        │  (定理 12.8)         │  (定理 13.2)             │
├──────────────┼──────────────────────┼──────────────────────┼──────────────────────────┤
│ 被列举的对象 │  子集 T ⊆ A          │  实数 x ∈ [0,1]      │  程序 P_i                │
├──────────────┼──────────────────────┼──────────────────────┼──────────────────────────┤
│ 表格的形状   │  第 n 行 = f(n) 的   │  第 n 行 = f(n) 的   │  第 n 行 = P_n 在各输入  │
│              │  特征向量 a_{n,k}    │  小数各位 d_k^{(n)}  │  上的停机行为 (H/L)      │
├──────────────┼──────────────────────┼──────────────────────┼──────────────────────────┤
│ 对角线读法   │  a_{n,n}: n ∈ f(n)?  │  d_n^{(n)}           │  P_n 在 P_n 上停机吗?    │
├──────────────┼──────────────────────┼──────────────────────┼──────────────────────────┤
│ "翻转"规则   │  令 n ∈ D ⟺ n ∉ f(n) │  s_n = d_n^{(n)} ± 1 │  Turing(P) 的行为与      │
│              │                      │  (或取 {1..8} 中异值)│  P(P) 的停机性【相反】   │
├──────────────┼──────────────────────┼──────────────────────┼──────────────────────────┤
│ 新对象的身份 │  D ⊆ A，是合法子集   │  s ∈ [0,1]，是合法实数 │  Turing 是合法程序     │
│ (关键!)      │                      │                      │                          │
├──────────────┼──────────────────────┼──────────────────────┼──────────────────────────┤
│ 矛盾         │  D 不在 f 的像中     │  s 不在列表中        │  Turing 不在 P_0,P_1,... │
│              │  ⇒ f 不满射          │  ⇒ 列表不全          │  中 ⇒ TestHalt 不存在    │
├──────────────┼──────────────────────┼──────────────────────┼──────────────────────────┤
│ 结论         │  |A| < |P(A)|        │  R 不可数            │  停机问题不可判定        │
└──────────────┴──────────────────────┴──────────────────────┴──────────────────────────┘
```

同一句话概括三次使用：

```
┌──────────────────────────────────────────────────────────────────────┐
│  ① 把对象排成无穷表（第 n 行对应"候选 n"）                           │
│  ② 沿对角线取 a_{n,n}，按规则【改动】它，造出一个新对象 X            │
│  ③ 验证 X 依然是"合法成员"          ← 最容易漏的一步，也是成败所在   │
│  ④ X 在第 n 项上与候选 n 处处不同 ⇒ X 不在表中 ⇒ 表必不完整 ⇒ 矛盾   │
└──────────────────────────────────────────────────────────────────────┘
```

三者的差别只在"第 ③ 步能不能过"：

- Cantor 定理：D 由 A 的元素按条件筛出来，必然是 A 的子集 → 通过 ✓
- R 不可数 ：任意数字序列都定义一个实数（先做无歧义约定） → 通过 ✓
- 停机问题 ：Turing 的伪代码合法，它确实是一台程序 → 通过 ✓
- 反面对照 Q ：改对角位得到的数未必是有理数 → 失败 ✗
  （正因如此，Q 可数，它不是不可数集）

这个统一视角的价值：以后遇到任何"证明存在性/不可能性"的题目，先问自己——"能不能把候选对象排成表？能不能沿对角线造一个处处不同的新对象？这个新对象还在原来的集合里吗？" 三个问题都答"能"，对角线论证就能用。

定理 13.3（简单停机问题不可判定：归约示范）

定理 13.3：简单停机问题 (Easy Halting Problem) ——"给定程序 P，判断 P 在输入 0 上是否停机"——同样**不可判定**。

证明策略：归约。这里的直觉是："如果不让它自指（只问输入 0，不问任意输入如 P 自己），停机问题会不会变简单？"答案是不会。证明路线是**反向用归约**：假设简单停机问题可判定，则用它构造出通用停机问题的判定器；而通用停机问题已被证明不可判定，矛盾。这个证明的价值在于它是**归约模板的第一个完整示范**——后面所有"X 不可判定"的证明都照这个模子刻。

逐步推导：

第一步（陈述假设）：假设存在程序 `TestEasyHalt`，满足

$$\texttt{TestEasyHalt}(P) = \begin{cases} \text{"yes"}, & \text{若 } P(0) \text{ 停机} \\ \text{"no"}, & \text{若 } P(0) \text{ 死循环} \end{cases}$$

第二步（构造辅助程序 P'）：给定任意的程序 P 与输入 x，构造一个新程序

```
P'(y):
    return P(x)        ← 完全忽略自己的输入 y，把 P 和 x 硬编码(hard-wire)进去
```

也就是说，P' 把 P 和 x 的**源码/取值写死在自己的代码里**（这是合法的：程序源码是有限串，可以嵌进另一段源码里），并在被调用时执行 $P(x)$。

第三步（关键的等价性）：断言

$$P'(0) \text{ 停机} \quad \Longleftrightarrow \quad P(x) \text{ 停机.}$$

证明：P' 忽略输入（无论收到什么都执行同样的 `return P(x)`），所以 $P'(0)$ 的执行轨迹与 $P(x)$ **逐字相同**。因此前者停机当且仅当后者停机。**这一条是整个归约的支点，缺了它归约就断了。**

第四步（用简单判定器解通用问题）：定义

```
Halt(P, x):
    P' = (构造如上: P'(y) { return P(x) })
    return TestEasyHalt(P')
```

正确性：由第三步，`TestEasyHalt(P')` 返回 `"yes"` $\iff$ $P'(0)$ 停机 $\iff$ $P(x)$ 停机。所以 `Halt` 正是通用停机问题的判定器，并且它总是终止（因为 `TestEasyHalt` 总是终止）。

第五步（矛盾收口）：`Halt` 的存在与定理 13.2 直接冲突。故第一步的假设为假，`TestEasyHalt` 不存在，简单停机问题不可判定。■

归约的方向示意：

```
我们要证「简单停机问题」不可判定
     |
     |  反向归约：把已知不可判定的问题搬过来
     ▼
┌──────────────────────────────────────────────────────┐
│  若 TestEasyHalt 存在                                 │
│      ⇒ 可由它构造 Halt（通用停机判定器）  ← 归约的核心一步  │
│      ⇒ 通用停机问题可判定                              │
│  但通用停机问题【已证不可判定】(定理 13.2)              │
│      ⇒ 矛盾 ⇒ TestEasyHalt 不存在                     │
└──────────────────────────────────────────────────────┘

注意"难度传递"的方向:
     Halt(P,x)  ⟶  P'(y): return P(x)  ⟶  TestEasyHalt(P')
      (任意输入)        (归一旦硬编码)        (只问输入 0)
 既然"任意输入"能归约到"只问输入 0"，说明后者并不比前者简单。
```

【证明机制解说】：归约的"灵光"是**"硬编码"（hard-wiring）**。**`TestEasyHalt` 只能问"P 在 0 上停不停"，而我们想问"P 在 x 上停不停"。解决办法是把 x 编进程序本身**，让新程序对任何输入都表现得像"P 跑在 x 上"，于是"P 在 x 上停机"这个问题被**翻译成了**"P' 在 0 上停机"。这是计算机科学里最基本的手法之一：**参数化 (parameterization)——把变元固定到代码里，换取形式上的匹配**。想通这一点，后面所有不可判定性证明都变得机械：**只需设计一个"硬编码转换器"，让难问题的新输入变成易问题能接受的输入。**

反例（如果适用）：注意归约的方向**不能反**。我们证明了"通用停机 $\leq$ 简单停机"，从而推出"简单停机不可判定"。若反过来只证明"简单停机 $\leq$ 通用停机"（这当然成立），**什么也得不出**——因为把一个不可判定问题归约到一个不可判定问题上，或者把一个可判定问题归约到一个不可判定问题上，都不产生关于后者难度的信息。**"$A \leq B$ 且 A 不可判定 $\Rightarrow$ B 不可判定"是唯一可用的形式**，方向搞反是归约证明中最常见的致命错误。

定理 13.4（停机问题可识别但不可判定；补集不可识别）

定理 13.4：令 $L_{\mathbf{HALT}} = \{\langle P, x\rangle : P(x) \text{ 停机}\}$。

- (a) $L_{\mathbf{HALT}}$ **是可识别的，但不可判定**。
- (b) 若语言 L 与它的补集 $\bar{L}$ **都可识别**，则 L **可判定**。
- (c) 因此 $\overline{L_{\mathbf{HALT}}} = \{\langle P, x\rangle : P(x) \text{ 死循环}\}$ **不可识别**（否则与 (a)(b) 矛盾）。

证明策略：(a) 用**模拟器**给出可识别性（构造性证明），不可判定性直接引用定理 13.2。(b) 是**并行运行 (dovetailing)** 技巧，是本讲最重要的通用工具之一：把两个半判定器交错着跑，因为两个方向必有一个会终止，所以整体必然终止。(c) 是 (b) 的逆否应用。

逐步推导：

(a) 第一步（可识别性：模拟器给出 yes）：构造

```
RecognizeHalt(P, x):
    simulate P on x       ← 一步一步地跑，永不设步数上限
    if it halts then
        output "yes"      ← 只要 P(x) 真的停机，这里必被执行
```

正确性分析： – 若 $\langle P, x\rangle \in L_{\mathbf{HALT}}$（$P(x)$ 停机），则模拟在**有限步**后结束，程序输出 `"yes"` 并终止 ✓ – 若 $\langle P, x\rangle \notin L_{\mathbf{HALT}}$（$P(x)$ 死循环），则模拟**永远运行下去**，从不输出 `"no"` —— 这**违反**判定器的要求（判定器必须终止并给正确答案），但**符合**识别器的要求（识别器对不在语言中的输入无义务）✓

所以 $L_{\mathbf{HALT}}$ 可识别。

(a) 第二步（不可判定性）：假设 $L_{\mathbf{HALT}}$ 可判定，则存在判定器 `D`，它在所有输入上终止且正确判定 $P(x)$ 是否停机——这正是定理 13.2 中被证明不存在的 `TestHalt`。矛盾。故 $L_{\mathbf{HALT}}$ 不可判定。

(b) 第一步（陈述假设）：设 L 与 $\bar{L}$ 都可识别，M_L 是 L 的识别器，$M_{\bar{L}}$ 是 $\bar{L}$ 的识别器。按定义： – 若 $w \in L$，则 $M_L(w)$ 在有限步内停机并输出 `"yes"`（$M_{\bar{L}}(w)$ 可能永远跑下去）。 – 若 $w \in \bar{L}$，则 $M_{\bar{L}}(w)$ 在有限步内停机并输出 `"yes"`（$M_L(w)$ 可能永远跑下去）。

(b) 第二步（构造并行判定器）：

```
DecideL(w):
    for k = 1, 2, 3, ... :
        run M_L(w) for k steps        ← 交错地推进两侧
        if it output "yes" then return "yes"
        run M_Lbar(w) for k steps
        if it output "yes" then return "no"
    ← 永远不会真的到达"无路可走"的状态
```

关键设计意图：**不要"先跑 M_L 跑到底、跑不完再跑 $M_{\bar{L}}$"**——那样如果 M_L 死循环就永远轮不到 $M_{\bar{L}}$。正确做法是**每一轮给两侧各分配有限步数，并把轮数 k 递增**。这样两台机器都被无限多次地推进（这个技巧叫 **dovetailing（燕尾交织）**），任何一台一旦停下就会被立刻发现。

(b) 第三步（正确性：必在有限步内终止）：任取 w。因为 $L \cup \bar{L} = \{0,1\}^*$，必有 $w \in L$ 或 $w \in \bar{L}$，两者恰有一成立。

- **若 $w \in L$**：$M_L(w)$ 在某个有限步数 T 内停机输出 `"yes"`。当循环进行到 $k \geq T$ 时，`run M_L(w) for k steps` 会真的跑到 $M_L(w)$ 的历史终点（因为前面各轮的步数已经累计推进过；在 dovetailing 实现中把每轮步数累加，或直接用 k 步的全新模拟并缓存已完成的机器状态）。于是判定器输出 `"yes"` 并终止。**答案正确**。
- **若 $w \in \bar{L}$**：同理，$M_{\bar{L}}(w)$ 在有限步 T' 内输出 `"yes"`，判定器在某轮 $k \geq T'$ 输出 `"no"` 并终止。**答案正确**。

两种情形都在有限步内终止并给出正确答案，所以 `DecideL` 是 L 的**判定器**，L 可判定。

（实现细节说明：为了让"跑 k 步"真的线性推进，通常把每台机器实现成带状态保存的**逐步模拟器**：维护一个"已经推进的步数"计数器，第 k 轮把 M_L 多推进一步、把 $M_{\bar{L}}$ 多推进一步。这样第 k 轮结束时两台机器都恰好推进了 k 步，且没有重复计算。这个实现是标准做法，此处只需把握"交错推进、两侧都不被饿死"这一要点。）

(c)（补集不可识别）：反证。若 $\overline{L_{\mathbf{HALT}}}$ 可识别，则由 (a) 第一步 $L_{\mathbf{HALT}}$ 也可识别，于是由 (b) 得 $L_{\mathbf{HALT}}$ 可判定，与 (a) 第二步矛盾。故 $\overline{L_{\mathbf{HALT}}}$ 不可识别。■

表格总结 $L_{\mathbf{HALT}}$ 与 $\overline{L_{\mathbf{HALT}}}$ 的地位：

```
┌──────────────────────────────────┬──────────────┬──────────────┐
│                                  │  L_HALT      │  L_HALT 的补 │
├──────────────────────────────────┼──────────────┼──────────────┤
│ 可识别 (recognizable)            │     ✓        │     ✗        │
│ 可判定 (decidable)               │     ✗        │     ✗        │
│ 存在「总是终止并正确」的程序      │     ✗        │     ✗        │
│ 存在「说 yes 时一定对」的程序     │     ✓        │     ✗        │
└──────────────────────────────────┴──────────────┴──────────────┘

为什么补集不可识别（直觉版）：
  要确认 (P,x) 死循环，你必须证明「它永远不停」——
  而任何有限的模拟都只说明「到目前还没停」，永远推不出「永远不停」。
  这与围棋里"确认某方必胜"需要看完整棵博弈树是同一类困难。
```

【证明机制解说】：(b) 的"并行运行"技巧之所以重要，是因为它给出了**"可识别 + 补集可识别 = 可判定"这条升级通道**。它的证明只需要一个观察：**两个"半个判定器"合起来就是一个完整的判定器**，因为"是"与"否"两侧总有一侧的机器会终止。这个观察把"判定"这个强要求分解成两个弱要求，非常实用：要证某语言可判定，你可以分别写两个识别器（一个认 yes、一个认 no），然后用 dovetailing 粘起来。反过来，(c) 给出了一个**证明"不可识别"的通用手段**：若要证 $\bar{L}$ 不可识别，只需证 L 可识别但不可判定。这个"逆否用法"在后面做题时反复出现。

反例（如果适用）：**"交错推进"不能省成"轮流跑到底"**。若把 `DecideL` 写成

```
DecideL_wrong(w):
    run M_L(w) until it halts      ← 若 M_L 死循环，就永远卡在这里
    if output "yes" then return "yes"
    run M_Lbar(w) until it halts
    if output "yes" then return "no"
```

那么当 $w \in \bar{L}$ 而 $M_L(w)$ 恰好死循环时，程序**永远卡在第一行**，尽管 $M_{\bar{L}}$ 早就能给出答案。**并行（交错）与串行（顺序）在这里有天壤之别**：交错保证了"两侧都被无限推进"，串行则让一侧可能永久饿死。这是本讲最容易写错的一处代码。

定理 13.5（归约方法：更多不可判定问题）

定理 13.5：下列问题都**不可判定**：

1. **输出 0 问题**：给定程序 Q 与输入 x，判断 $Q(x)$ 是否（在停机的前提下）输出 0。
2. **输出任意内容问题**：给定程序 Q，判断它是否**曾经输出过任何东西**。
3. **等价性问题**：给定两台程序 Q_1, Q_2，判断它们是否对**所有**输入产生相同输出（即 $Q_1 \equiv Q_2$）。
4. 更一般地，任何 A，只要通用停机问题可归约到 A（即 HALT $\leq A$），都不可判定。

证明策略：全部用**归约模板**：设 A 待证，"假设 A 有判定器 → 构造 HALT 的判定器 → 与定理 13.2 矛盾"。核心工作只有一个：为每个 A 设计合适的**硬编码转换器**，把任意 (P, x) 变成一个 A 能接受的输入，且变换后的"A-性质"恰好等价于"$P(x)$ 停机"。

逐步推导：

（1）输出 0 问题：假设有判定器 `OutputsZero(Q, x)`（正确判定 $Q(x)$ 是否输出 0；若 $Q(x)$ 不停机，按约定它不输出 0，故判定器返回 `"no"`）。构造

```
Halt(P, x):
    Q' = ( Q'(y) { P(x); return 0 } )    ← 先跑 P(x)（可能死循环），停了就返回 0
    return OutputsZero(Q', 0)
```

正确性分析：– 若 $P(x)$ 停机：Q' 执行完 $P(x)$ 后返回 0，所以 Q' 输出 0，`OutputsZero` 返回 `"yes"` ✓ – 若 $P(x)$ 死循环：Q' 卡在执行 $P(x)$ 上，**永远到不了 `return 0`**，所以 Q' 不输出任何东西，更没有输出 0，`OutputsZero` 返回 `"no"`（由 `OutputsZero` 的判定器契约，它必须终止并回答）✓

于是 `Halt` 是通用停机判定器，矛盾。故 `OutputsZero` 不存在。

（2）输出任意内容问题：假设有判定器 `OutputsAnything(Q)`。构造

```
Halt(P, x):
    Q' = ( Q'(y) { P(x); print "hello" } )
    return OutputsAnything(Q')
```

若 $P(x)$ 停机，Q' 打印 `"hello"`（输出过东西）；若 $P(x)$ 死循环，Q' 从不打印。故 `OutputsAnything(Q')` 恰好回答 $P(x)$ 是否停机。矛盾。

（3）等价性问题：设 `Z` 是"无论输入什么都立刻死循环"的程序：

```
Z(y):
    loop forever
```

假设有判定器 `Equiv(Q1, Q2)`。构造

```
Halt(P, x):
    Q' = ( Q'(y) { P(x); return 1 } )     ← 注意：P(x) 停机时 Q' 返回 1
    return not Equiv(Q', Z)
```

正确性分析： – 若 $P(x)$ 停机：Q' 对**所有**输入 y 都先跑完 $P(x)$ 再返回 1，即 Q' 是一个"处处返回 1 的终止程序"。而 `Z` 处处死循环，从不返回。两者行为不同，所以 **`Equiv(Q',Z)` = 假**，取反得 `"yes"` ✓ – 若 $P(x)$ 死循环：Q' 对**所有**输入都死在 $P(x)$ 上，与 `Z` 的行为**完全一致**（两者处处不停机、处处无输出），所以 **`Equiv(Q',Z)` = 真**，取反得 `"no"` ✓

于是 `Halt` 是通用停机判定器，矛盾。这里 Q' 的输入 y 被完全忽略（这叫**忽略输入 (ignoring input)**），是为了让"Q' 与 Z 是否处处相同"这个全称性质能被 $P(x)$ 的停机性完全决定。

（4）一般化：以上三例的模板完全相同，可以抽象成一句话：**找到一个"从 (P,x) 到 A 的实例"的可计算变换，使得变换后的实例落在 A 中 $\iff$ $P(x)$ 停机。**这个变换在可计算性理论里叫**多一归约 (many-one reduction)**。掌握模板后，看到任何"程序的性质"问题，第一反应应该是：**能不能把一个已知的坏性质硬编码进去?**

```
归约模板总结（背下来）

  已知不可判定：   HALT
      │
      │ ① 假设目标问题 A 有判定器 D_A
      │ ② 设计转换器 f：(P,x) ↦ (A 的一个实例)   ← 硬编码 P、x
      │ ③ 证明等价性：f(P,x) ∈ A  ⟺  P(x) 停机
      │ ④ 写出 HALT 的判定器：D_HALT(P,x) = D_A(f(P,x))
      │ ⑤ 与 HALT 不可判定矛盾 ⇒ A 不可判定

  每个 A 的不同之处只在于第 ② 步的那段"硬编码代码"怎么写。
```

【证明机制解说】：归约方法把"证明不可判定"从**智力挑战**降级为**工程任务**。你不用再设计新的对角线论证（那需要灵光），只需机械地设计一个转换器。这是可计算性理论（以及复杂性理论中证明 NP-难）中最核心的思维模式。**判定"两个程序等价"不可判定这一点尤其重要**——它是编译器"优化"的根本障碍：编译器无法在一般情况下判断"我的优化会不会改变程序行为"，所以所有实际优化都是**保守的**（只在能证明等价时才动手）。

反例（如果适用）：归约必须保证转换器**自身是可计算的**，否则论证无效。例如，"设 Q' = 若 $P(x)$ 停机则返回 0，否则返回 1"这种把整个停机问题答案直接写进程序的做法**不是可计算的转换**（你无法算出该答案是哪一个）。合法的转换只能是"把 P 和 x 的源码嵌进去"，让 Q' 在**运行时**才去执行 $P(x)$。区分"编译时算出来"与"运行时算出来"，是归约证明的关键纪律。

定理 13.6（Gödel 不完全性定理：经由停机问题的证明）

定理 13.6（Gödel 不完全性定理，1930/1931）：任何**足够强**以形式化算术的形式系统 F，若**一致 (consistent)**，则**不完全 (incomplete)**：存在一条关于自然数的真命题 S，在 F 中既不能证明 S，也不能证明 $\neg S$。

证明策略：反证法 + 归约到停机问题。假设算术**既一致又完全**，则对任意 (P,x)，命题"$P(x)$ 停机"要么可证要么其否定可证。**因为证明是有限二进制串，全体证明可数**（这正是 Lecture 12 定理 12.5 的用武之地），所以可以逐个枚举所有证明、机械地检查它是否证明了目标命题。于是得到一个停机问题的判定器——矛盾。

逐步推导：

第一步（Gödel 式的自指骨架，Gödel 编号）：先看最强的那个想法：构造一条语句

$$S(F) = \text{"这句话在 } F \text{ 中不可证明。"}$$

两种情形： – **情形 A：$S(F)$ 可证。**既然 F 的推理规则可靠（推出的都是真命题——这里需要 F **一致**），$S(F)$ 就是真的，即"$S(F)$ 不可证"。所以 $S(F)$ 既在 F 中可证、又（作为真命题）不可证，矛盾 ⇒ F **不一致**。 – **情形 B：$S(F)$ 不可证。**那么 $S(F)$ 所断言的内容成立，即 $S(F)$ 是**真命题**；而它不可证。于是 F 中存在真而不可证的命题 ⇒ F **不完全**。

于是"要么不一致、要么不完全"。**要把这个骨架变成定理，就必须真的造出 $S(F)$**——这需要一套把"符号、公式、证明"都编码成自然数的机制（**Gödel 编号 (Gödel numbering)**），使"x 是命题 y 的一个证明"成为算术里的一条可判定的陈述。这是 Gödel 原始证明中最艰苦的技术部分，CS70 只做骨架介绍。

第二步（用停机问题绕开 Gödel 编号 —— 更简洁的证明）：我们换个路子，直接反证。假设 F 既一致又完全。

第三步（把停机写成算术命题）：固定 P 与 x，定义命题

$$S_{P,x} = \text{"程序 } P \text{ 在输入 } x \text{ 上停机。"}$$

关键观察：**$S_{P,x}$ 可以写成纯算术的语言**。具体形式是

$$S_{P,x} \equiv \exists z \left(z \text{ 编码了 } P \text{ 在 } x \text{ 上的一段合法停机执行序列} \right).$$

为什么可以？因为"P 在 x 上执行一步"是一个极其机械、完全确定的操作（读当前状态、按转移规则改状态）。把所有中间状态按顺序列出来，拼成一个长长的二进制串 z，那么"z 是一段合法的执行序列、以停机状态结尾"这件事，就可以用**纯算术的加减乘除、逻辑联结词与量词**逐位检验（"第 i 段编码的状态与第 $i+1$ 段编码的状态符合 P 的转移规则"）。这个 z 就是**见证 (witness)**：$S_{P,x}$ 的真假由"是否存在这样的 z"决定。

第四步（用完全性造判定器）：由第三步，每个 $S_{P,x}$ 都是算术命题，故（因其真假有定）它或真或假。由"F 完全"的假设，**必存在 F 中 $S_{P,x}$ 的证明，或 F 中 $\neg S_{P,x}$ 的证明**（二者恰有其一，因为"F 一致"排除了两者都有）。又由"F 一致"，只有真的那个才会有证明，所以：

> 找到一个 $S_{P,x}$ 的证明 $\iff$ $S_{P,x}$ 为真 $\iff$ $P(x)$ 停机；找到一个 $\neg S_{P,x}$ 的证明 $\iff$ $S_{P,x}$ 为假 $\iff$ $P(x)$ 死循环。

第五步（枚举证明 —— 这里用上 Lecture 12 的可数性）：证明是**有限的二进制串**（一串符号序列，按约定编码成比特）。由 Lecture 12 定理 12.5，所有有限串之集可数，故**所有可能的证明可数**，可以排成一列 $q_0, q_1, q_2, \ldots$。而且"q 是否是 $S_{P,x}$ 的一个合法证明"是**机械可检验**的（逐行核对推理规则、核对最后一行是否是目标命题）——这是"证明与计算之间的深刻联系"的直接体现。

第六步（程序 `Search`）：

```
Search(P, x):
    for every proof q:                    ← 枚举可数多个证明
        if q is a proof of S_{P,x}     then output "yes"
        if q is a proof of ¬S_{P,x}    then output "no"
```

正确性：由第四步，两种证明**必有一种存在**，所以 `Search` 迟早找到它并终止（枚举过程在有限步内到达那个证明）。因此 `Search` 是**通用停机问题的判定器**。

第七步（收口）：`Search` 的存在与定理 13.2 矛盾。所以初始假设"F 既一致又完全"为假——**足够强的形式系统不可能既一致又完全**。■

两种证明的对照：

Gödel 原始证明	经由停机问题的证明（本讲）
需构造 S(F)="我不可证"	不需要构造自指语句本身
需 Gödel 编号（技术重）	只需"把执行序列编码成整数"（直觉自然）
一万象：逻辑自身	一万象：可计算性
核心工具：自指	核心工具：自指 + 可数性（定理 12.5）+ 归约

两者都指向同一句话：足够强的系统里，总有些真理逃出证明之外。

【证明机制解说】：这个证明是**整门课"讲次之间互相咬合"的最佳例证**。它同时用到了：Lecture 12 的**可数性**（证明只有可数多个，才能枚举）、Lecture 12 的**编码思想**（把执行序列编码成整数 z）、Lecture 13 的**停机问题不可判定**（最终的矛盾来源）、以及 Lecture 13 的**归约模板**（"若能搜索证明就能解停机 $\Rightarrow$ 矛盾"）。特别值得品味的是"**见证 z**"这一步：它把"P 是否停机"这个看似关于**过程**的问题，化归成了"**存在**一个有限的证据"这个关于**算术存在量词**的问题。**把动态的过程静态化成有限的证据链**，是可计算性理论里最有威力的翻译术。

反例（如果适用）：定理不适用于"太弱"的系统。例如只含等式公理、不含乘法的系统无法表达足够的算术，"完全性"就可能成立。同时注意定理的结论是**析取式**（"要么不一致，要么不完全"），而不是"一定不完全"——一个实际系统可能选择"不完全但一致"（这是我们所期望的，算术就是这样），但理论上不能排除某个系统"完全但不一致"（那样的系统毫无价值，因为从假命题可以推出一切，包括它的否定）。**不要把定理的结论误读成"算术是不一致的"或"算术是完全的"。**

与经典问题的联系

1. 编译器优化与静态分析的极限

编译器最想做的三件事，全都撞在不可判定性上：– **"这段代码有死循环吗？"** —— 停机问题本身，不可判定（定理 13.2）。– **"这两个函数语义相同吗？我能把调用 f 优化成调用 g 吗？"** —— 等价性问题，不可判定（定理 13.5(3)）。– **"这个程序是病毒吗？"** —— 需要判断"程序是否执行了某些危险行为"，可归约到停机/输出类问题，不可判定。

工程上的应对完全是被定理逼出来的：– **保守近似**：只做"能证明安全"的优化（如常量折叠、死代码消除在局部可判定），其余一律不动。这保证**优化不会改变程序语义**（可证明的正确性），代价是放过很多优化机会。– **加超时/步数上限**：把不可判定问题降级为可判定问题——`TestHaltBounded(P,x,k)` 是可判定的，但它在"k 步内没停"时只能说 `"don't know"`。这正是"可识别但不可判定"在工程上的落地形态：**能确认 yes，不能确认 no**。– **领域限制**：对语法做限制（如禁止 `goto`、强制结构化控制流）使某些性质变得可判定。这把"不可判定"变成"在一个受约束的子语言上可判定"，是程序分析（如抽象解释）的核心策略。– **"是否有过输出" vs. "输出什么"**：定理 13.5(2) 说"是否曾输出过任何东西"都不可判定——这直接解释了为什么编译器的**副作用分析**（判断函数有没有 I/O）不能做到完美，只能保守估计。

2. 与"证明检查 vs. 证明搜索"的联系（自动定理证明）

定理 13.6 的证明揭示了一个极其重要的不对称：– **证明检查是容易的**：给定一个候选证明 q 和命题 S，"q 是不是 S 的合法证明"可以机械地、在正比于 $|q|$ 的时间内验证。– **证明搜索是困难的**：从零找到那个证明 q，可能需要无穷的时间（`Search` 会一直跑下去，直到碰巧找到）。

这个不对称是**自动定理证明 (automated theorem proving)** 与**交互式证明助手 (proof assistant，如 Coq / Lean)** 存在的全部理由。后者让人类提供"证明在哪里"的高层线索，机器负责机械地检查——**把不可判定的搜索工作交给人，把可判定的检查工作交给机器**。这也解释了为什么数学论文的验证比数学定理的发现容易得多。更进一步，这个不对称还通向**交互式证明系统 (interactive proof systems)** 和**零知识证明 (zero-knowledge proof)**——"验证比生成容易"正是现代密码学协议设计的杠杆（与 Lecture 6 的 RSA 中"加密容易、解密需要私钥"形成呼应）。

3. 与"压缩"和"信息"的联系

定理 13.2 的证明依赖于"程序即数据"（程序是有限串，可以作为输入）。这个同一性也是信息压缩理论的基础：任何可计算的过程都可以被编码成一个有限描述。Lecture 12 已证明程序可数、函数不可数，从而**存在无法被任何有限程序描述的"随机"对象**——这正是 Kolmogorov 复杂性理论中"不可压缩串"存在的理由。CS70 只擦边，但方向已经指明：**可计算性 = 可压缩性 = 有限描述的能力**。

4. 与算法正确性证明的联系（Gale–Shapley 的对照）

Lecture 11 的 Gale–Shapley 算法是一个**总是终止**的程序，且它终止后的输出（稳定匹配）可以被证明正确。这类"构造性存在性证明"（先写算法，再证它停机且正确）在本讲形成了鲜明的对照：停机问题的意义在于**不是所有程序都能享有这种保证**。一个实用推论：当你写下一个新算法时，"它是否对每个输入都终止"这件事，**不能指望有通用工具帮你自动验证**，必须靠人给出数学论证（如势函数/递减量）。**这是 Lecture 11 教"证明算法终止"、以及 L03 归纳法在算法分析中反复出现的根本原因。**

与其他讲次的关联

- **与 Lecture 12（Countability）**：本讲是 L12 的直接续章，三处咬合极其具体：
- **程序可数**：L12 定理 12.5 证明 $\{0,1\}^*$ 可数，而程序就是有限比特串，所以程序可排成 $P_0, P_1, P_2, \ldots$——这是停机问题对角表的前提。
- **函数不可数**：L12 定理 12.7 的 Cantor 定理给出 $|\mathbb{N}| < |\mathcal{P}(\mathbb{N})| = |\{0,1\}^\infty|$，从而函数比程序多，保证不可计算问题的存在。
- **同一个对角线手势**：L12 定理 12.7 的 $D = \{a : a \notin f(a)\}$ 与本讲 `Turing(P)` 的"行为与 $P(P)$ 相反"是同一构造；L12 定理 12.8 的"翻转对角位"也是同一构造。
- **证明可数性是关键零件**：定理 13.6 第六步"枚举所有证明"直接用 L12 定理 12.5。
- **与 Lecture 1（Propositional Logic）**：说谎者悖论的分析（定理 13.1）本质上是**命题逻辑**里"一个命题不能既真又假"这一基本原则的应用。"Every statement is either true or false"（排中律）与"不能同时为真为假"（矛盾律）在本讲被用来排除所有情形，从而暴露悖论。此外"x 是 S 的证明"这种谓词化表述也依赖 L01 的量化语言。
- **与 Lecture 2（Proof Techniques II）**：定理 13.2、13.3、13.5 全部是**反证法 (proof by contradiction)**，且定理 13.5 系列还用了**逆否推理**（"若 $A \le B$ 且 A 不可判定，则 B 不可判定"）。L02 教的"分情形"在定理 13.1 中被用来穷举"真/假"两种情形。
- **与 Lecture 3（Induction）**：定理 13.4(b) 的 dovetailing 论证中"第 k 轮推进 k 步，以及"某个有限 T 之后必然触发"的推理，都是 L03 建立的**"无限过程由无限多个有限阶段组成"**这一直觉的延续——与 L12 定理 12.2、12.3 的"按有限块分层"是同一思维。
- **与 Lecture 4–L06（Modular Arithmetic / RSA）**：RSA 的安全性依赖于**单向性**（加密容易、无密钥解密难），而本讲的不可判定性是更深一层的"不可能"：不是"计算上困难"，而是"数学上不存在算法"。两者构成了"密码学困难性"与"可计算性不可能性"的对比。另外，定理 13.6 中"把执行序列编码成整数"的技术，与 L04–L06 中"把信息编码成模 m 的剩余类"是同一种"用数字表示结构"的手法。
- **与 Lecture 7–L08（Polynomials / Secret Sharing / ECC）**：多项式插值给出的是**构造性的存在性证明**（"一定存在唯一的次数 $\le t-1$ 的多项式穿过给定点，而且可以显式算出来"）；Berlekamp–Welch 译码算法的正确性也建立在"多项式根数不超过次数"这一可判定的代数事实上。把这些与本讲的"定理 13.6 是非构造性的不可能性证明"并置，可以看清数学证明的两种气质。
- **与 Lecture 9–L10（Graphs）**：图论中的许多问题（如"某个图是否可 3-着色"）是**可判定**的（有限搜索空间）；但图灵机停机问题不可判定。更有意思的是，**"给定图灵机 M，判断它是否会访问某个特定状态"** 也可归约到停机问题，从而不可判定——这说明"在无限状态空间中做可达性分析"是不可能有通用算法的。这与 L09–L10 中在**有限图**上做 BFS/DFS 可达性（总是可判定、且是多项式时间）形成鲜明对照：**有限 vs. 无限的差别，就是可判定 vs. 不可判定的差别。**
- **与 Lecture 11（Stable Matching）**：Gale–Shapley 是一个**被证明终止**的算法（存在性证明是构造性的）。本讲的范畴与它正好互补：停机问题告诉我们，不存在通用方法判定任意程序是否终止，所以 **L11 那种"为算法找势函数证明终止"的人工工作是不可避免的。**
- **与 Lecture 14（Counting）及之后**：定理 13.6 的关键一步是"所有证明可数"，这用的是 L12 而非 L14。但本讲与 L14 有一个方法论上的共同点：**都是"把对象编码成有限串/整数"的技术。**L14 的计数法则（乘法法则、双射计数）在有限集上枚举对象，本讲在可数集上枚举对象——后者是前者的无穷版。
- **与 Lecture 15+（Probability）**：一个值得记住的母题——**不可判定性意味着"随机化"不能解决一切。**L15 之后我们会看到随机化算法（如 L20 的哈希、L23 的集中不等式）如何用随机性换取效率；但停机问题不可判定是**确定性结论**，随机算法也救不了它（随机算法也是一个程序，它的终止性同样受定理 13.2 约束）。

关键要点

1. **自指是引擎**：程序即数据（有限比特串），所以"程序吃自己"合法。这是 quine、递归定理、说谎者悖论、Barber 悖论、停机问题证明的**共同物理基础**。构造自指矛盾的通式是让对象满足 $X = \neg X$（"$P(P)$ 停机 $\iff$ $P(P)$ 不停机"），这种方程**无解**。
2. **停机问题不可判定**（定理 13.2）：不存在程序对所有 (P, x) 正确判定停机。证明是**反证 + 对角线**：假设 `TestHalt`，构造 `Turing(P)` = "与 $P(P)$ 的停机性相反"，则 `Turing(Turing)` 两种情形都矛盾。**这是"不存在性"证明，不是"困难"或"尚未解决"。**
3. **可识别是比可判定更弱的要求**：可判定 = 总是终止且总正确；可识别 = 只在 yes 时保证终止并答对，no 时可能死循环。L_{HALT} **可识别但不可判定**（模拟器给出 yes；不可判定性引用定理 13.2）。
4. **"可识别 + 补集可识别 = 可判定"**（定理 13.4b）：把两个半判定器用 **dovetailing（交错推进）** 并行跑起来，因为两侧必有一侧终止，所以整体必终止。由此得 $\overline{L_{\text{HALT}}}$ **不可识别**。注意**必须交错，不能串行**（串行会让一侧永久饿死）。
5. **归约模板**（定理 13.5）：证 A 不可判定，就假设 A 有判定器，设计一个**可计算的硬编码转换器**把 (P, x) 变成 A 的实例，使得"转换后的实例 $\in A$ $\iff$ $P(x)$ 停机"，从而解出停机问题，矛盾。**方向绝不能反**："$A \le B$ 且 A 不可判定 $\Rightarrow$ B 不可判定"。
6. **Gödel 不完全性定理可以经由停机问题证明**（定理 13.6）：若算术既一致又完全，则"$P(x)$ 停机"这个算术命题必有证明或反证；而证明可数（L12 定理 12.5）、可机械检验，于是枚举所有证明就得到停机判定器，矛盾。**足够强的形式系统不可能既一致又完全。**

常见误区与注意事项

1. **把"停机问题不可判定"误读成"我们无法判断任何程序是否停机"。大错。** 不可判定指的是**不存在一个通用算法处理所有输入**。事实上：

2. `x = 3+4` 显然停机（我们一眼就看出）；
3. `while(true){}` 显然不停机；
4. 对于每个**固定**的程序 P，命题"P 停机与否"本身是有确定答案的（要么真要么假），只是没有一个算法能对所有 P 统一给出答案。 类比：不存在一个通式解所有五次方程（Abel–Ruffini），但 $x^5 - 1 = 0$ 的解我们完全知道。**"没有通用方法" ≠ "每个个案都无法判断"。**
5. **把自指当成"作弊"或"不合法的构造"**。把程序当输入接收是完全合法的操作，因为程序就是比特串。"程序 P 跑在 P 自己身上"和"字符串 s 出现在字符串 s 里"一样自然。若不接受这一点，就等于否认可编程性本身（编译器必须能把源码当数据读取）。**拒绝自指就破坏了整个证明的基础，而自指恰恰是完全正当的。**
6. **混淆可判定与可识别**。$L_{\mathbf{HALT}}$ 可识别（模拟器），但**不可判定**。区别在于：识别器的"no"答案是**不可信的**——它可能是"永远不回答"，而不是"回答 no"。做题时看到"程序对 $w \notin L$ 会死循环"，要立刻意识到这只是**识别器**而非判定器。
7. **在补集论证中把"并行"写成"串行"**。`DecideL` 必须**交错推进**两个机器（第 k 轮各推进 k 步）。若写成"先把 M_L 跑到底，再跑 $M_{\bar{L}}$"，则当 M_L 死循环时会永久卡住，即使 $M_{\bar{L}}$ 能给出答案。**dovetailing 的要点是"两侧都不被饿死"。**
8. **归约中忘了证明"转换器可计算"，或把归约方向搞反**。前半句：像"令 Q' 为：若 $P(x)$ 停机则返回 0，否则死循环"这样的描述在**元语言**里看似构造了 Q'，但**真正构造 Q'** 需要一个能判断 $P(x)$ 是否停机的过程，那正是我们要证不存在的东西；合法写法是把 P 和 x 的**源码嵌入** Q'，让 Q' **运行时**执行 $P(x)$——**转换器本身必须是一个能写出来的程序**。后半句：要证 B 不可判定，必须把**已知不可判定的** A 归约到 B（$A \leq B$，即"若 B 可解则 A 可解"）；若写成"若 A 可解则 B 可解"，什么也得不出来。**记忆法：把"不可判定性"从已知处搬向未知处。**
9. **把 Gödel 不完全性定理的结论读成"算术是不一致的"，或把"停机"与"输出"混为一谈**。前者的结论是**析取**："要么不一致，要么不完全"；对算术这类我们相信一致的系统，结论落在"不完全"上（**存在真而不可证的命题**），误读成"什么都不能证明"或"数学不可靠"都是过度解读。后者：$L_{\mathbf{HALT}}$ 可识别（跑下去看到它停就知道了），但"$Q(x)$ 是否输出 0"甚至"Q 是否曾输出任何东西"都**不可判定**（定理 13.5(1)(2)）——因为后者的"no"需要断言"永远不输出"，比"某时刻停下来"强得多。**"能确认发生"与"能确认永不发生"是两个不同难度的问题。**

思考题（带答案）

Q1. 设 `TestHalt(P, x)` 是假设存在的停机判定器。请（a）逐行写出 `Turing(P)` 的伪代码；（b）对下面这个具体的小程序 `Foo` 分析 `Turing(Foo)` 的行为，说明它为什么与 `Foo` 的行为相反；（c）说明 `Turing(Turing)` 为什么必然矛盾。

```
Foo(y):
    halt            ← 无论输入什么都立刻停机
```

▸ **答案**

（a）伪代码：

```
Turing(P):
    if TestHalt(P, P) = "yes" then
        loop forever
    else
        halt
```

（b） `Foo` 是一个无论输入什么都立刻停机的程序。特别地， `Foo(Foo)` 停机（它忽略输入，直接 `halt`）。于是：

- `TestHalt(Foo, Foo)` 返回 `"yes"`（因为 `Foo(Foo)` 确实停机）；
- `Turing(Foo)` 进入 `if` 分支，执行 `loop forever`，**不停机**。

而 `Foo(Foo)` **停机**。所以 `Turing(Foo)` 的行为（不停机）与 `Foo(Foo)` 的行为（停机）**恰好相反** ✓ 这正是 `Turing` 的设计目标："处处与自己的候选人唱反调"。

反过来，若取 `Bar(y) { loop forever }`（处处死循环），则 `Bar(Bar)` 死循环， `TestHalt(Bar,Bar)` 返回 `"no"`， `Turing(Bar)` 走 `else halt`，**停机**——而 `Bar(Bar)` 不停机，**依然相反** ✓

（c） `Turing` 自己也是一台程序，所以 `Turing(Turing)` 有定义，且它**要么停机要么不停机**：

- **若 `Turing(Turing)` 停机**： `Turing` 的 `if` 分支会 `loop forever`，所以能停机只能是走了 `else halt`，即 `TestHalt(Turing,Turing)` 返回 `"no"`。但按 `TestHalt` 的语义， `"no"` 表示 `Turing(Turing)` **死循环**——与假设"它停机"矛盾。
- **若 `Turing(Turing)` 不停机**：能不停机只能是走了 `if` 分支的 `loop forever`，即 `TestHalt(Turing,Turing)` 返回 `"yes"`。但按语义 `"yes"` 表示 `Turing(Turing)` **停机**——与假设"它不停机"矛盾。

两种情形都矛盾，故 "`TestHalt` 存在" 这个假设是假的。

数值/逻辑验算输出（脚本模拟判定器契约）：

```
simulate(haltsEarly, 0, 10) = {"steps":5,"verdict":"halts"}
simulate(loopsForever, 0, 10) = {"steps":10,"verdict":"still running (unknown)"}
=> 前者肯定说 yes；后者永远不会说 no，只会一直跑下去
```

以及"与候选人相反"的逐行核对：对 5 个假想程序 $P_0 .. P_4$，把它们的对角行为 $P_n(P_n)$ 取反得到 `Turing` 的行为序列 `L H L L L`，与每一行 P_n 的对角元逐一比较，**全部不同**（`DIFFERS`），从而 `Turing` 的行为不可能是任何 P_n 的行为。

Q2. 判断正误并说明理由：

（a）"停机问题不可判定，所以没有任何程序能判断任何特定程序是否停机。"（b）"L_{HALT} 可识别，所以我们可以写一个程序，对死循环的输入最终输出 no。"（c）"若 L 可识别，则 $\bar{L}$ 也可识别。"（d）"既然我们把通用停机问题归约到了简单停机问题，说明简单停机问题比通用停机问题更难。"

▸ **答案**

（a）**错误**。不可判定指的是"**不存在通用算法处理所有 (P, x)**"，而不是"每个个案都判断不了"。对固定的具体程序，停机与否是有确定答案的，而且往往能手算：`x=3+4` 显然停机，`while(true){}` 显然不停机。另外注意一个有趣的推论：**对每个固定的 P，"P 是否在 0 上停机"这个命题是真或假的，所以逻辑上存在一个"打印 yes"或"打印 no"的常数程序正确地回答它**——但这是**非构造性的**：我们不知道是哪一个，而且这一族常数程序不是**单一算法**（不存在能对任意 P 给出正确常数程序的可计算映射）。判定器的要求是"存在一个程序，对所有输入都正确"，这比"对每个输入分别存在一个正确程序"强得多。

（b）**错误**（这正是可识别与可判定的分界）。L_{HALT} 的识别器只是**模拟器**：它一步一步跑 $P(x)$，若停机就输出 yes。当 $P(x)$ 死循环时，模拟器**永远运行下去，从不输出 no**——它没有"最终输出 no"的能力，因为要输出 no 就必须证明"永远不停"，而任何有限的模拟都只能说明"到现在为止还没停"。要真能对死循环输出 no，那就成了判定器，与定理 13.2 矛盾。

（c）**错误**。L_{HALT} 可识别，但由定理 13.4(c)，$\overline{L_{\mathrm{HALT}}}$ **不可识别**。正确的定理是**反方向的**：若 L 与 $\bar{L}$ **都**可识别，则 L **可判定**（定理 13.4b）。所以"可识别"对补集不封闭。直觉：可识别只保证能确认 yes；确认 no 可能是补集的识别器的活儿，而补集的识别器未必存在。

（d）**错误**（结论不能这么下）。归约 $A \le B$ 的意义是"A **不比** B **难**"（A 的难度不超过 B）。这里是把"通用停机"归约到"简单停机"，即 HALT $\le$ EasyHalt，意思是"通用停机不比简单停机难"；等价的说法是"**简单停机至少和通用停机一样难**"。所以简单停机问题**不比**通用停机问题更难，两者**难度相同**——这正是不可判定性得以传递的原因。注意方向：难度的**下界**从 HALT 传向 EasyHalt，不是从上往下传"更难"。若把关系读成"EasyHalt 更难"，就把不等号方向弄反了。

脚本验算佐证（补集论证的 dovetailing）：

```
race('inL',100)    = {"t":3,"answer":"yes (x∈L)"}      ← M_L 在第 3 步终止
race('notInL',100) = {"t":7,"answer":"no (x∉L)"}       ← M_Lbar 在第 7 步终止
=> 两者必有一个在有限步内回答，所以并行跑必然终止且答案正确
```

以及归约的硬编码等价性：

```
P(42) = halt | P'(anything) = P(42) = halt halt
=> P'(0) halts iff P(42) halts, 故 EasyHalt(P') 能回答 Halt(P,42)
```

Q3. 用归约证明："给定程序 Q 与输入 x，判断 $Q(x)$ 是否**恰好**输出 0" 不可判定。要求写出（a）假设的判定器 `OutputsZero` 的契约；（b）从 (P, x) 到 Q' 的硬编码转换器；（c）停机性等价性的分析；（d）矛盾如何收口。

▸ **答案**

（a）**假设的判定器契约**：假设存在程序 `OutputsZero(Q, x)`，它**总是终止**，且

$$\texttt{OutputsZero}(Q,x)=\begin{cases}\text{"yes"}, & \text{若 } Q(x) \text{ 停机且最终输出 } 0\\ \text{"no"}, & \text{若 } Q(x) \text{ 停机但输出不为 } 0, \text{ 或 } Q(x) \text{ 永不停止（因而无输出）}\end{cases}$$

注意契约必须明确覆盖"$Q(x)$ 死循环"这一情形（约定为 `"no"`），否则它就不是一个全定义的判定器。

（b）**硬编码转换器**：给定任意 (P,x)，构造

```
Q'(y):
    P(x)              ← 先执行 P(x)；若它死循环，就永远停在这里
    return 0          ← 只有 P(x) 停机后才会执行到这一行
```

P 与 x 被**硬编码**进 Q' 的代码（合法：它们的源码是有限串；Q' 的输入 y 被完全忽略）。这个构造是**可计算的**：把 P 与 x 的源码文本插入模板即可，不需要预先知道 $P(x)$ 是否停机。

（c）**等价性分析**：

- **若 $P(x)$ 停机**：Q' 执行完 $P(x)$ 后到达 `return 0`，于是 $Q'(y)$ 对任何 y 都停机并输出 0。所以 `OutputsZero(Q', 0)` 返回 `"yes"` ✓
- **若 $P(x)$ 死循环**：Q' 永久卡在 `P(x)` 这一行，**永不输出任何东西**，当然也不输出 0。所以 `OutputsZero(Q', 0)` 返回 `"no"` ✓

两种情况合起来：

$$\texttt{OutputsZero}(Q',0)=\text{"yes"} \iff P(x) \text{ 停机.}$$

（d）**收口**：定义

```
Halt(P, x):
    Q' = ( Q'(y) { P(x); return 0 } )
    return OutputsZero(Q', 0)
```

由 (c)，`Halt` 对每个 (P,x) 都终止（因为 `OutputsZero` 总是终止）且给出正确答案，即 `Halt` 是通用停机问题的判定器。但定理 13.2 已证明这样的程序不存在。矛盾。故假设 (a) 为假，`OutputsZero` 不存在，"$Q(x)$ 是否恰好输出 0" 不可判定。■

要点提醒：转换器必须是**可计算的**（"把 P 与 x 的源码嵌进去"可以机械完成），而**不是**"先判断 $P(x)$ 停不停机再决定 Q' 的代码"（那需要停机判定器本身）。这是归约证明中最容易失手的地方。

同类推广（脚本验算的判定器行为）：

```
outputsZero(M1,0,50) = true     (M1 在第 4 步输出 0)
outputsZero(M2,0,50) = undefined  (M2 输出 1，不停机场景则永不返回)
```

⇒ 判定"输出是否为 0"在带步数上限的模拟下也只是"能确认 yes"，这正与"不可判定 + 可识别"的分界一致。

Lecture 14: Counting（计数）

概述

本讲是课程从"确定性推理"跨入"不确定性推理"的桥梁。上一讲（讲次 13）我们用对角化证明停机问题不可判定；从本讲开始，我们要问的问题变了：掷一枚公平硬币 1000 次，恰好出现 500 次正面的概率是多少？答案是大约 2.5%；而恰好 1000 次正面的概率小到可以当作"不可能"。但在能够计算、估计这些概率之前，**我们必须先学会数数**——因为在一个结果等可能的样本空间里，概率就是"有利结果数 ÷ 总结果数"，概率计算直接退化为计数问题（这一点在讲次 15 会被正式确立）。

本讲的技术主线是：先把"有多少种"这个问题翻译成"结构 + 规则的组合"，再从**两条最基本的规则**（乘法法则与和法则）出发，系统构建出排列、组合、二项式系数、星棒法、容斥原理这一整套工具，并且用**双射（bijection）**和**双计数（double counting）**给出组合式的证明——这种"同一个故事用两种视角讲"的证明风格，将在讲次 16 被专门展开。

核心概念的直观解释

计数（Counting）

- **定义**：给定一个有限集合 A，计数就是要确定 $|A|$，即 A 中元素的个数。这里的"集合"可以是一组牌、一串硬币结果、一堆把球放进箱子的方案，等等。
- **直观解释（"它是什么意思？"）**：计数的核心思想是**把"有多少"变成"结构与规则的组合"**。我们很少真的去一个个列出来数（对 $|A|=2{,}598{,}960$ 的一手扑克牌根本数不过来），而是识别出生成这些对象的"过程"——这个过程的每一步有多少种选择，然后把这些选择数**组合**起来。就像工厂流水线：如果每道工序的产品数量只取决于上一道的产出量，整条线的产量就是一个连乘积。
- **具体示例**：一副 52 张牌中抽 5 张，一共多少种不同的手牌？我们不数牌，而是发现"抽牌"这个过程的每一步选择数依次是 $52, 51, 50, 49, 48$，再除以"同一手牌的重复计数次数" $5!$，得到 $2{,}598{,}960$。

第零法则：双射（Zeroth Rule of Counting / Bijection）

- **定义**：若集合 A 与集合 B 之间存在一个**双射** $f: A \to B$（既是单射又是满射，即存在可逆的一对映射），则 $|A| = |B|$。

- **直观解释（"它是什么意思？"）**：这是"计数"这件事的**真正心脏**。它说的是：要数一个难数的集合，你完全可以**换一个同样大小但好数的集合**去数。把"选水果沙拉"翻译成"安排 0 和 1 的二进制串"，就是这一法则最漂亮的应用。它也是讲次 12（可数性）中"两个集合等势"思想的有限版本——只不过在有限世界里，双射直接保证基数相等，不需要讨论"能不能列完"。
- **具体示例**：$\{1,2,3\}$ 的子集共有 8 个，而长度为 3 的 0/1 串也恰好有 8 个；把子集 S 映射到串 (b_1,b_2,b_3)，其中 $b_j=1 \iff j\in S$，这是一个双射，所以两边数目相同。

第一法则 / 乘法法则（First Rule of Counting / Product Rule）

- **定义**：若一个对象由 k 个相继的选择步骤构成，第 1 步有 n_1 种选法，且**对第 1 步的每一种选法**第 2 步都有 n_2 种选法，且对前两步的每一种选法第 3 步都有 n_3 种选法……一直到第 k 步有 n_k 种选法，则能这样造出的不同对象总数为 $n_1\times n_2\times\cdots\times n_k$。
- **直观解释（"它是什么意思？"）**：注意定义里那句啰嗦的"对每一种选法都有 n_2 种选法"——这才是关键：**后续步骤的选择数不能依赖于前面具体选了什么**，只能依赖于"已经选了"。这就像一张管辖区域图：无论你走到哪一层，每一层的扇出（branching factor）都是固定的。整个决策过程形成一棵**决策树（decision tree）**，从根到叶的路径与"造出的对象"一一对应，所以对象总数 = 叶子数 = 各层扇出之积。
- **具体示例**：先选上衣（3 件），再选裤子（2 条），再选鞋（4 双），则搭配数是 $3\times2\times4=24$。但若"第 2 步有几条裤子可穿"取决于"第 1 步选了哪件上衣"（比如某件上衣不能配某条裤子），乘法法则**在这么粗的粒度下就不适用了**，必须先重新划分情形（这在"常见误区"一节会详细展开）。

和法则（Sum Rule）

- **定义**：若集合 A 被划分为若干**两两不相交（pairwise disjoint）**的部分 $A_1,A_2,\dots,A_m$，即 $A=A_1\cup A_2\cup\cdots\cup A_m$ 且 $A_i\cap A_j=\emptyset$ 对一切 $i\neq j$ 成立，则

$$|A|=|A_1|+|A_2|+\cdots+|A_m|.$$

- **直观解释（"它是什么意思？"）**：乘法法则管"步骤串联"（每一步都要做），和法则管"情形并列"（只发生其中一种）。用分情形证明时（讲次 2 的分情形证明），我们实际上一直在用和法则——只要各情形**互不重叠**。所以和法则真正的技术含量不在公式，而在"**互不相交**"这四个字。
- **具体示例**：1 到 20 中能被 4 整除的数有 5 个（$\{4,8,12,16,20\}$），能被 6 整除的数有 3 个（$\{6,12,18\}$），但两者之并**不是** $5+3=8$ 个，因为 12 被数了两次，实际只有 7 个。修正公式就是容斥原理（本讲 §5）。

第二法则 / 除法法则（Second Rule of Counting / Division Rule）

- **定义**：设 A 是"有序对象"的集合，B 是相应的"无序对象"的集合。若存在一个 m**–对–1** 的函数 $f:A\to B$（即每个 B 中元素恰好有 m 个 A 中元素映射到它），则 $|B|=|A|/m$。
- **直观解释（"它是什么意思？"）**：先"假装顺序重要"把有序对象数出来，再除以"每个无序对象被重复数的次数"。可以想象成往抽屉里放东西：每个无序结果对应一个抽屉，每个抽屉里恰好装着 m 个有序结果，那么抽屉数就是 $|A|/m$。**前提极其重要**：每个抽屉里的东西必须一样多。CS70 官方 Note 10 把它称作"第二法则"（本讲沿用它），而把上面那条"互不相交才能相加"称作和法则；两者名称容易混淆，读者只要记住内容即可。
- **具体示例**：从 5 张牌中"有序地"取 2 张有 $5\times4=20$ 种；同一个 2 张牌的手牌被数了 $2!=2$ 次，所以手牌数 $=20/2=10=\binom{5}{2}$。

排列（Permutation）与组合（Combination）

- **定义**：设 S 是 n 元集合。S 的 k**–排列**是从 S 中取 k 个**不同**元素排成一个有序序列，其数目记作 $P(n,k)$；S 的 k**–组合**是从 S 中取 k 个不同元素组成一个**集合**（无序），其数目记作 $\binom{n}{k}$。
- **直观解释（"它是什么意思？"）**：排列关心"顺序"，组合不关心。发牌时"先发到 ♠A 再发到 ♥K"与"先 ♥K 再 ♠A"是同一手牌，但作为**发牌序列**是两个不同的结果。这两个量的差别恰好是"同一组 k 个东西内部有多少种排列方式"，即 $k!$。
- **具体示例**：$n=5,k=2$：$P(5,2)=5\times4=20$，$\binom{5}{2}=20/2=10$。$n=52,k=5$：$P(52,5)=311{,}875{,}200$，$\binom{52}{5}=2{,}598{,}960$。

星棒法（Stars and Bars）

- **定义**：方程 $x_1+x_2+\cdots+x_k=n$ 的**非负整数解**的个数为 $\binom{n+k-1}{k-1}$。
- **直观解释（"它是什么意思？"）**：把 n 个"星"（★）和 $k-1$ 根"棒"（`|`）排成一行。棒是 k 个变量之间的**分隔符**：第一根棒左边有几颗星，就是 x_1 的值；第 $i-1$ 根与第 i 根棒之间有 x_i 颗星；最后一根棒右边是 x_k。于是"一个解"与"一个含 n 颗星、$k-1$ 根棒的序列"构成双射，数序列就是"从 $n+k-1$ 个位置中选 $k-1$ 个放棒"。
- **具体示例**：$x_1+x_2+x_3=6$ 的串 `★★|★|★★★` 对应 $(2,1,3)$；串 `|★★★★|★★` 对应 $(0,4,2)$（允许某个箱子为空）；串 `★★★★★★||` 对应 $(6,0,0)$。三种都是合法的多重集。

四种采样情形（Four Sampling Schemes）的对照

Note 10 的骨架实际上是一张 2×2 的表：**有放回 / 无放回** 与 **有序 / 无序** 两个维度交叉，得到四类基本的计数对象。把它们列在一起，是为了让读者看到"同一个方法论（第一法则 → 除法法则 / 双射）如何产出全部四个公式"：

采样方式	顺序	计数对象	公式	典型场景
无放回	有序	k–排列	$P(n,k)=\dfrac{n!}{(n-k)!}$	一副 52 张牌依次发 5 张，记录顺序
无放回	无序	k–子集	$\binom{n}{k}=\dfrac{n!}{k!(n-k)!}$	一手 5 张扑克牌
有放回	有序	长 k 的序列	n^k	掷 k 次 n 面骰；k 次抛硬币
有放回	无序	k–多重集	$\binom{n+k-1}{k}$	选 5 个水果（只看种类数）

值得强调：**右下角那一格是唯一不能靠"乘一乘、除一除"得到答案的**，它必须通过第零法则（双射）翻译成"从 $n+k-1$ 个位置里选 k 个"，也就是星棒法。Note 10 特意把这一格放在最后并大费周章地用二进制串来建模，正是要说明：**当乘除法则失灵时，换视角（双射）是唯一出路**。这张表也是讲次 15 的入场券——Note 13 一开篇就说"随机实验就是从 n 元集合 S 中有放回/无放回地抽 k 个元素，其可能结果恰好就是上一讲数过的那些对象"，因此讲次 15 的样本空间大小直接抄这张表的右列。

（自检） 用 $n=3, k=2$ 的小规模手工核对：4 种情形依次给出 $P(3,2)=6$（$12,13,21,23,31,32$）、$\binom{3}{2}=3$（$\{1,2\},\{1,3\},\{2,3\}$）、$3^2=9$（$11,12,13,21,22,23,31,32,33$）、$\binom{3+2-1}{2}=\binom{4}{2}=6$（多重集 $11,12,13,22,23,33$）。三与六、三与九之间的差异必须能一一对上元素名，这是检验自己是否真懂了这四个公式的试金石。

完整证明与推导（核心）

定理 14.1（第一法则 / 乘法法则）：设造一个对象需要相继做 k 个选择，第 i 步的选择数恒为 n_i（与前面具体选了什么无关，只与"已经选了"有关），则这样造出的不同对象总数为 $n_1 n_2 \cdots n_k$。

证明策略：对步数 k 做**归纳法**（讲次 3 的工具），同时用**决策树叶子计数**作为几何直观。选归纳法是因为命题本身就是"对一切 k 成立"的形式，且 $k+1$ 步的情形可以自然地拆成"前 k 步"+"最后一步"，这正是归纳法的标准适用形态。

逐步推导：

- **基础情形 $k=1$**：只有一步，对象与第一步的选择一一对应，因此对象数为 n_1，而乘积 n_1 也等于 n_1。命题成立。
- **归纳假设**：设对任意 $k \geq 1$，k 步过程的对象数恰为 $n_1 n_2 \cdots n_k$。
- **归纳步骤**：考虑 $k+1$ 步过程。把每个对象的"前 k 步"看成一个**部分对象**；由归纳假设，部分对象共有 $N_k := n_1 n_2 \cdots n_k$ 个。
- 对每一个部分对象 p，按题设，第 $k+1$ 步有恰好 n_{k+1} 种选法（题设保证这个数目不依赖 p 是什么）。于是每个部分对象向下"分叉"出恰好 n_{k+1} 个完整对象。
- 由**和法则**，把全体部分对象的贡献相加：由于不同的部分对象所生成的完整对象互不相同（前 k 步就不同），这些 N_k 组之间两两不相交，故

$$\#\{\text{完整对象}\} = \underbrace{n_{k+1} + n_{k+1} + \cdots + n_{k+1}}_{N_k \text{ 项}} = N_k \cdot n_{k+1} = n_1 n_2 \cdots n_k n_{k+1}.$$

- 由归纳原理，命题对一切 $k \geq 1$ 成立。■

另一种等价视角（决策树 / 笛卡尔积）：把第 i 步的选择集合记作 C_i，$|C_i| = n_i$。则"造出的对象"的集合与笛卡尔积 $C_1 \times C_2 \times \cdots \times C_k$ 存在自然双射（对象 $\mapsto$ 它每一步的选择序列）。由第零法则，两类对象数目相同；而笛卡尔积的基数由定义即为 $|C_1| \cdot |C_2| \cdots |C_k|$。这正是决策树中"叶子数 = 各层扇出之积"的代数版本。

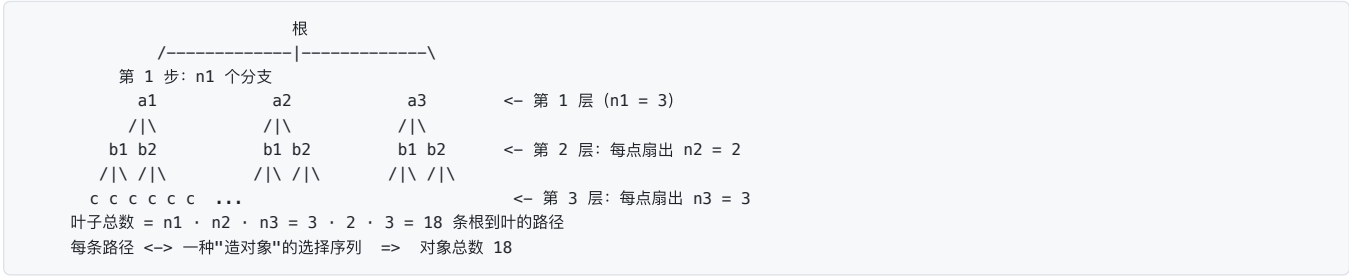

【证明机制解说】：整个证明的"灵光一现"在于**把"造对象"看成"走路径"**。一旦建立了"对象 ↔ 根到叶路径"的双射，计数就变成了纯粹的树结构算术：一棵每层扇出分别固定为 $n_1, \ldots, n_k$ 的树，其叶子数是各层扇出之积。归纳法的归纳步骤则把这棵"宽树"递归地看成"先造一棵 k 层的树，再给每个叶子挂 n_{k+1} 个孩子"——递归结构与乘积结构同构，这是所有乘法型组合恒等式的共同底色。

反例（说明"选择数必须不依赖前序选择"不可省）：设要从 $\{1,2,3\}$ 中选两个不同的数，第 1 步有 3 种选法。若天真地认为"第 2 步也总有 3 种选法"，就会得到 $3 \times 3 = 9$；但正确的无重复选法只有 $3 \times 2 = 6$ 种（$12,13,21,23,31,32$）。问题在于：第 2 步的"可选项"是 $\{1,2,3\} \setminus \{\text{第 1 步选的}\}$，其大小**依赖于第 1 步的具体选择**（虽然总是 2，但**集合本身**变了）。乘法法则允许"数目相同"，要求的是"对每一个前序选择，后续选择**数目**都一样"——本反例中数目确实都是 2，所以 $3 \times 2 = 6$ 正确；而把第 2 步写成 3 则是彻底无视了"不能重复"这个约束。**更危险的情形**是数目本身都不同：见下一个反例。

定理 14.0（第二法则 / 除法法则）：设 A, B 是有限集，$f : A \to B$ 满足：对每个 $b \in B$，$|f^{-1}(b)| = m$（同一个 m，与 b 无关），则 $|B| = |A|/m$。

证明策略：**双计数（double counting）**——把 $|A|$ 用两种方式算出来。选择这个策略是因为命题本身就是关于"两套计数系统之间的关系"，双计数是最自然、也最不容易出错的路子。

逐步推导：

- 一方面，A 是全体有序对象，由定义 $|A|$ 就是有序对象的数目。
- 另一方面，按像点 $b \in B$ 把 A 分块：$A = \bigcup_{b \in B} f^{-1}(b)$。由于每个元素在 f 下只有一个像，不同 b 对应的原像集**互不相交**（若 $a \in f^{-1}(b_1) \cap f^{-1}(b_2)$，则 $f(a)$ 同时等于 b_1 与 b_2，矛盾）。
- 由**和法则**，$|A| = \sum_{b \in B} |f^{-1}(b)|$。
- 代入题设 $|f^{-1}(b)| = m$，得 $|A| = \sum_{b \in B} m = m \cdot |B|$。
- 两边同除以 m（$m \geq 1$，因为每个 b 至少有一个原像；若 $B = \emptyset$ 则 $A = \emptyset$，结论平凡）得 $|B| = |A|/m$。■

【证明机制解说】：这个证明把"能不能除"的问题转化成了**"每个原像集是否等大"**的问题。注意它的结构：**用和法则把 $|A|$ 按纤维（fiber）展开，再要求每个纤维等大**——于是"求和"变成"乘法"，除法才被允许。一旦纤维大小不齐（水果沙拉的情形：纤维大小从 1 到 30 不等），和法则仍然是对的（$\sum_b |f^{-1}(b)| = |A|$ 恒成立），但"求和"无法坍缩成"乘以常数"，除法法则就失效了。所以**除法法则的真正前提不是"顺序不重要"，而是"纤维等大"**。

定理 14.2（组合数公式 / 除法法则）：对 $0 \le k \le n$，

$$\binom{n}{k} = \frac{P(n,k)}{k!} = \frac{n(n-1)\cdots(n-k+1)}{k!} = \frac{n!}{k!\,(n-k)!}.$$

证明策略：**双计数 + 除法法则**。先用第一法则数出"有序"版本 $P(n,k)$（这个容易），再构造一个 $k!$–对–1 的映射到"无序"版本，然后除以 $k!$。选这个策略是因为"有序版"天然适配乘法法则，而"有序"与"无序"之间的桥梁就是一个可显式写出的映射。

逐步推导：

- **第 1 步：数有序的**。要形成一个由 S 中 k 个**不同**元素组成的有序序列：第 1 位有 n 种选法；无论第 1 位选了谁，剩下的 $n-1$ 个元素都可以放在第 2 位，故第 2 位有 $n-1$ 种选法；依此类推，第 i 位（从 1 开始编号）有 $n-i+1$ 种选法。由第一法则（定理 14.1）：

$$P(n,k) = n(n-1)(n-2)\cdots(n-k+1) = \frac{n!}{(n-k)!}.$$

- **第 2 步：构造"有序 → 无序"的映射**。定义 f 把每个有序序列 $(a_1,\dots,a_k)$ 映到它作为集合 $\{a_1,\dots,a_k\}$。因为序列里的元素互不相同，这个集合恰好有 k 个元素，是一个合法的 k 元子集，所以 f 确实把"有序对象"映到"无序对象"。
- **第 3 步：验证每个原像恰有 $k!$ 个元素**。固定一个 k 元子集 T。所有满足 $f(\text{序列}) = T$ 的序列，就是把 T 的 k 个元素排成一列的全体排列。k 个不同元素的全排列数由第一法则为 $k!$（第 1 位 k 选，第 2 位 $k-1$ 选，……，第 k 位 1 选），即 $|f^{-1}(T)| = k!$。**关键点**：这个数目对每个 T 都相同，与 T 具体是什么无关——除法法则的前提在此得到满足。
- **第 4 步：套用除法法则**。f 是 $k!$–对–1 的，$|A| = P(n,k)$，$|B| =$ 无序对象数 $= \binom{n}{k}$。于是

$$\binom{n}{k} = \frac{|A|}{k!} = \frac{n!}{k!\,(n-k)!}. \qquad \blacksquare$$

- **数值校验**：$n=52, k=5$：$P(52,5) = 52\times51\times50\times49\times48 = 311{,}875{,}200$，除以 $5! = 120$ 得 $\binom{52}{5} = 2{,}598{,}960$。（脚本验算：$\binom{52}{5} = 2598960$ ✓）

补充：为什么下降乘积恰好是 $n!/(n-k)!$ 而不是别的。把定理 14.1 用在排列上，得到 $P(n,k) = n(n-1)\cdots(n-k+1)$，共 k 个因子。把它改写：

$$n(n-1)\cdots(n-k+1) = \frac{n(n-1)\cdots(n-k+1)\cdot\underbrace{(n-k)(n-k-1)\cdots1}_{(n-k)!}}{(n-k)!} = \frac{n!}{(n-k)!}.$$

这里我们看到"为什么是递减相乘、为什么恰好 k 个因子"：第 i 个位置（$i = 1,\dots,k$）的可用元素个数是 $n-(i-1)$，因为前面已经用掉了 $i-1$ 个**互不相同**的元素。**"互不相同"这一条是递减的根源**：若允许重复，可用元素个数就恒为 n，乘积退化为 n^k。这也顺带回答了"为什么 $\binom{n}{k}$ 的分母是 $k!(n-k)!$"：分子 $n!$ 是全部 n 个元素的全排列数，除以 $k!$（同一手牌内部的顺序）再除以 $(n-k)!$（没被选中的那些元素的顺序——在"排列 k 个元素"的原始问题里它们根本没有位置，但 $P(n,k) = n!/(n-k)!$ 的推导把它们"虚拟地排列"了，所以要在分母里除回来）。

【证明机制解说】：这个证明的灵魂是**"先数有序，再除以 $k!$"**。它把"难数的无序对象"约化为"好数的有序对象"，代价只是"要能算出每个无序对象被重复数了几次"。两个必须检查的地方：(1) 每个 k 元子集**恰好**对应 $k!$ 个有序序列（不是"至少"或"至多"）；(2) 这个 $k!$ 对**所有**子集都一样。若把"选 5 个不同元素"换成"取 5 个允许重复的元素"（即多重集），第二个条件就崩了：$(5,0,0)$ 这个多重集只对应 1 个有序序列，而 $(4,1,0)$ 对应 5 个（见下面的反例）。这正是为什么多重集需要星棒法而不是简单除法。

反例（除法法则的前提不可省）：有无限多的苹果、香蕉、橘子，要选 5 个水果做沙拉（只看种类数量，不看顺序）。天真做法：有序取法有 $3^5 = 243$ 种，除以"每个无序结果对应多少个有序序列"。**但除数不是常数**：若沙拉是 5 个香蕉，只有 1 个有序序列 `BBBBB`；若是 4 个香蕉 + 1 个苹果，则有 5 个有序序列（`ABBBB`，`BABBB`，`BBABB`，`BBBAB`，`BBBB A`）。243 无法被任何单一的 m 整除得到正确答案。正确做法是星棒法：$x_1+x_2+x_3 = 5$ 的非负解数 $= \binom{5+3-1}{3-1} = \binom{7}{2} = 21$。（脚本验算：$\binom{7}{5} = 21$，且按"箱大小分布"暴力分类后各分布对应的有序序列数分别为 $1, 5, 10, 20, 30, \dots$，各不相同 ✓）

定理 14.3（二项式定理 / Binomial Theorem）：对一切 $n \in \mathbb{N}$，

$$(x+y)^n = \sum_{k=0}^{n} \binom{n}{k} x^k y^{n-k}.$$

证明策略：**组合式证明（combinatorial proof）**——不靠代数恒等式变形，而是"把等号两边的项都解释成同一个东西的计数"。这里两边数的都是"展开 $(x+y)^n$ 时得到的项"。

逐步推导：

- 把左边写成 n 个因子的连乘：$(x+y)(x+y)\cdots(x+y)$，并把它们标记为 $f_1, f_2, \dots, f_n$。
- 展开时，我们从**每个**因子 f_i 中恰好取出一个字母（x 或 y），然后把取出的 n 个字母相乘，得到一个单项式；最后把**所有**这样的乘积相加。
- 由第一法则，取法总数为 $\underbrace{2\times2\times\cdots\times2}_{n} = 2^n$，恰好对应展开式的 2^n 个单项式（未合并同类项时）。
- 现在固定 k，考察形如 $x^k y^{n-k}$ 的单项式：它由"从 k 个因子里取 x、从其余 $n-k$ 个因子里取 y"产生。反过来，只要**指定哪 k 个因子贡献 x**，这个单项式就被完全确定。
- 因此 $x^k y^{n-k}$ 在合并同类项前的出现次数 = 从 $\{f_1,\dots,f_n\}$ 中选 k 个因子的方案数 $= \binom{n}{k}$（定理 14.2）。
- 合并同类项即得 $(x+y)^n = \sum_{k=0}^{n} \binom{n}{k} x^k y^{n-k}$。$\blacksquare$
- **小规模验证**：$n=2$ 时展开得 $x^2 + xy + yx + y^2$，其中 x^2 来自"两个因子都取 x"（$\binom{2}{2} = 1$ 种），xy 型项来自"一个取 x 一个取 y"（$\binom{2}{1} = 2$ 种：xy 和 yx），y^2 来自 $\binom{2}{0} = 1$ 种。合并得 $x^2 + 2xy + y^2$ ✓。
- **小规模验证**：$n=3$ 时 $\sum_{k=0}^{3}\binom{3}{k} = 1+3+3+1 = 8 = 2^3$ ✓。

【证明机制解说】：组合式证明与代数证明的最大区别在于"**每一项都有故事**"。$\binom{n}{k}$ 在这里不是"某个公式算出来的数"，而是"在 n 个因子里挑 k 个贡献 x 的方案数"。一旦接受了这个解释，很多恒等式就不需要算了，直接"讲故事"即可——本讲后面四条恒等式全部沿用这个套路。

定理 14.4（组合恒等式四则）：

(a) **对称性**：$\binom{n}{k} = \binom{n}{n-k}$。

证明策略：构造**显式双射**。

逐步推导：定义 f 把每个 k 元子集 $S \subseteq \{1,\dots,n\}$ 映到它的补集 $\bar{S} = \{1,\dots,n\} \setminus S$。因为 $|\bar{S}| = n-k$，所以 f 确实把 k 元子集映到 $(n-k)$ 元子集。它是单射（$\bar{S}$ 唯一确定 S）也是满射（任何 $(n-k)$ 元子集 T 都是 $\bar{T}$ 的像，且 $\bar{T}$ 是 k 元）。故 f 是双射，由第零法则两边数目相等。■

(b) **Pascal 法则**：$\binom{n}{k} = \binom{n-1}{k-1} + \binom{n-1}{k}$。

证明策略：**固定一个元素，分"含它 / 不含它"两种情形**，再用和法则（两部分互不相交）。

逐步推导：设 $S = \{1,\dots,n\}$，特别关注元素 n。把 S 的全部 k 元子集按"是否包含 n"分成两类：

- **含 n 的**：选定 n 后，还需从剩下的 $n-1$ 个元素中选出 $k-1$ 个，方案数 $\binom{n-1}{k-1}$。
- **不含 n 的**：全部 k 个元素都来自 $\{1,\dots,n-1\}$，方案数 $\binom{n-1}{k}$。

这两类**互不相交**（一个含 n 一个不含），且并起来正好是全部 k 元子集，故由和法则总数 $= \binom{n-1}{k-1} + \binom{n-1}{k}$。■

数值校验：$n=6, k=3$：$\binom{6}{3} = 20$，$\binom{5}{2} + \binom{5}{3} = 10 + 10 = 20$ ✓（脚本验算）。

(c) **行和**：$\displaystyle\sum_{k=0}^{n} \binom{n}{k} = 2^n$。

证明策略：给出**两种**证明——代数式（二项式定理代入）与**双射式**（子集 ↔ 比特串）。

逐步推导（代数式）：在定理 14.3 中取 $x=1, y=1$，得 $(1+1)^n = \sum_{k=0}^{n} \binom{n}{k} 1^k 1^{n-k} = \sum_{k=0}^{n} \binom{n}{k}$，左边是 2^n。■

逐步推导（双射式，更贴近"计数"本意）：左边 $\sum_k \binom{n}{k}$ 按定义是"大小恰为 k 的子集的个数"对 k 求和；由于不同大小 k 的子集互不相交，由和法则，左边 $=$ S 的**全部子集**（任意大小）的个数。右边：把每个子集 $T \subseteq S$ 对应到一个 n 比特串 $(b_1,\dots,b_n)$，规定 $b_j = 1 \iff j \in T$。这是一个双射（给定串能唯一还原 T，给定 T 能唯一写出串），而 n 比特串共有 2^n 个（每位 2 种选择，第一法则）。由第零法则，全体子集数 $= 2^n$。■

小规模验证：$S = \{1,2,3\}$，$n=3$。8 个子集为 $\emptyset, \{1\}, \{2\}, \{3\}, \{1,2\}, \{1,3\}, \{2,3\}, \{1,2,3\}$，对应的 3 比特串依次为 $000, 100, 010, 001, 110, 101, 011, 111$。左边 $= \binom{3}{0} + \binom{3}{1} + \binom{3}{2} + \binom{3}{3} = 1+3+3+1 = 8$ ✓。

(d) **交错和**：$\displaystyle\sum_{k=0}^{n} (-1)^k \binom{n}{k} = 0$（对 $n \geq 1$）。

证明策略：代数式（二项式定理代入 $x=-1, y=1$）+ 组合式（偶子集与奇子集之间的**符号反转双射**）。

逐步推导（代数式）：在定理 14.3 中取 $x=-1, y=1$，得 $\sum_{k=0}^{n} \binom{n}{k} (-1)^k 1^{n-k} = (-1+1)^n = 0^n = 0$（$n \geq 1$）。■

逐步推导（组合式，直接证明）：左边 $= \#\{\text{偶大小子集}\} - \#\{\text{奇大小子集}\}$。设 S 非空，固定元素 $a \in S$。定义映射 $\varphi(T) = T \triangle \{a\}$（对称差，即"含 a 就去掉，不含就加入"）。φ 把偶大小子集映到奇大小子集（大小改变 ± 1，奇偶性翻转），且 φ 是自身的逆（$\varphi(\varphi(T)) = T$），因此是**双射**。由第零法则，偶子集与奇子集**一样多**，两者之差为 0。■

数值校验：$n=4$：$\binom{4}{0} - \binom{4}{1} + \binom{4}{2} - \binom{4}{3} + \binom{4}{4} = 1 - 4 + 6 - 4 + 1 = 0$ ✓（脚本对 $n = 1,\dots,10$ 全部验证为 0）。

(e)〔补充〕**曲棍球棒恒等式（Hockey-stick Identity）**：对 $0 \leq k < n$，

$$\binom{n}{k+1} = \binom{n-1}{k} + \binom{n-2}{k} + \cdots + \binom{k}{k}.$$

证明策略：**按"最小元素是谁"分情形**（和法则），这是 Note 10 给出的组合式证明。

逐步推导：左边数的是 $\{1,\dots,n\}$ 的大小为 $k+1$ 的子集 X。对每个这样的 X，记 $m = \min X$ 为它的最小元素。按 m 的取值把全体 X 分类：

- $m=1$：还需从 $\{2,\dots,n\}$ 中选 k 个，方案数 $\binom{n-1}{k}$；
- $m=2$：还需从 $\{3,\dots,n\}$ 中选 k 个，方案数 $\binom{n-2}{k}$；
- $m=3$：方案数 $\binom{n-3}{k}$；
- ……
- $m=n-k$：还需从 $\{n-k+1,\dots,n\}$ 中选 k 个（恰好 k 个元素，只能全选），方案数 $\binom{k}{k} = 1$。

最小元素不可能超过 $n-k$，因为要选出 $k+1$ 个互不相同的元素。各类互不相交（最小元素不同），由和法则即得右式。■

数值校验：$n=6, k=2$：$\binom{5}{2} + \binom{4}{2} + \binom{3}{2} + \binom{2}{2} = 10+6+3+1 = 20$，而 $\binom{6}{3} = 20$ ✓。

定理 14.5（星棒法 / Stars and Bars）：设 $k \geq 1$，$n \geq 0$。方程

$$x_1 + x_2 + \cdots + x_k = n, \qquad x_i \in \mathbb{Z}_{\geq 0}$$

的非负整数解的个数为

$$\binom{n+k-1}{k-1} = \binom{n+k-1}{n}.$$

证明策略：**构造双射**，把"解"翻译成"符号串"。这正是第零法则的教科书级应用——原问题看起来和"数集合"完全不同，但换个视角就能用已知工具解决。

逐步推导：

- **把解编码成串**。给定一个解 $(x_1,\dots,x_k)$，写下一行由 n 个 ★ 和 $k-1$ 个 `|` 组成的串，规则是：先写 x_1 个 ★，再写 1 个 `|`，再写 x_2 个 ★，再写 1 个 `|`，……，写 x_k 个 ★ 收尾。因为 $\sum_i x_i = n$，串中恰好有 n 个 ★；因为分隔符是 $k-1$ 个，串长为 $n+k-1$。
- **验证这是双射**。给定这样的串，反过来读：数第一根 `|` 之前的 ★ 个数就是 x_1，第 $i-1$ 与第 i 根 `|` 之间（对 $i=2,\dots,k-1$）的 ★ 个数是 x_i，最后一根 `|` 之后的 ★ 个数是 x_k（可能是 0）。由此唯一还原出 $(x_1,\dots,x_k)$，且它自动满足 $\sum_i x_i = n$、$x_i \ge 0$。因此"解"与"串"一一对应。
- **数串**。只需决定"$n+k-1$ 个位置中，哪 $k-1$ 个位置放 `|`"，其余位置自动都是 ★。选择时不能重复选同一位置（无放回），且选位置的**顺序无关**（先选位置 3 再选位置 7 与反过来结果同一串），所以方案数是组合数

$$\binom{n+k-1}{k-1}.$$

- 由第零法则，解的个数就等于这个组合数。由定理 14.2 的对称性 $\binom{n+k-1}{k-1} = \binom{n+k-1}{(n+k-1)-(k-1)} = \binom{n+k-1}{n}$。■

变体（要求 $x_i \ge 1$ 即每个变量至少为 1）：令 $y_i = x_i - 1 \ge 0$，则 $\sum_i y_i = n-k$。于是解的个数为 $\binom{(n-k)+k-1}{k-1} = \binom{n-1}{k-1}$。**注意**：这个公式要求 $n \ge k$，否则无解（个数为 0），而 $\binom{n-1}{k-1}$ 在 $n<k$ 时按约定也为 0，公式仍然自洽。另一种等价视角：$x_i \ge 1$ 意味着"第一根棒之前至少有 1 颗星、相邻棒之间至少 1 颗星、最后一根棒之后至少 1 颗星"，即把 $k-1$ 根棒插进 n 颗星之间的 $n-1$ 个**空隙**里，每处最多插一根，方案数正是 $\binom{n-1}{k-1}$。

```
n = 6, k = 3 的编码示例（3 个变量，需要 2 根棒）：

★ ★ | ★ | ★ ★ ★      <->  (x1, x2, x3) = (2, 1, 3)
| ★ ★ ★ ★ | ★ ★      <->  (x1, x2, x3) = (0, 4, 2)   [x1 为 0 也合法]
★ ★ ★ ★ ★ ★ | |      <->  (x1, x2, x3) = (6, 0, 0)   [两个箱子为空也合法]

串长 = n + (k-1) = 6 + 2 = 8；只需挑 2 个位置放 "|"
解的个数 = C(8, 2) = C(n+k-1, k-1) = C(6+3-1, 3-1) = 28
```

数值校验：$\binom{8}{2} = 28$。$n=10, k=5$：非负解数 $\binom{14}{4} = 1001$（脚本暴力枚举得 1001 ✓）；正解数 $\binom{9}{4} = 126$（暴力枚举得 126 ✓）。$n=10, k=3$：非负解 $\binom{12}{2} = 66$，正解 $\binom{9}{2} = 36$ ✓（脚本均验证）。

【证明机制解说】：星棒法的关键一步是**选择"用什么符号编码"**。原问题是"给 k 个变量分配总数 n"，看起来和组合数毫无关系；但把分配方案写成一串 ★ 与 `|` 之后，"分配方案"就变成了"在固定长度串中选若干个位置"，立刻落回定理 14.2 的射程。这也是 CS70 反复强调的方法论：**计数问题的困难往往不在算，而在找对视角**。注意 Note 10 用 0 表示元素、用 1 表示分隔符，与本文的 ★/`|` 是同一个双射，只是记号不同。

定理 14.6（容斥原理 / Principle of Inclusion–Exclusion）：设 $A_1, A_2, \dots, A_n$ 是同一个有限全集 U 的任意子集，则

$$\left|\bigcup_{i=1}^{n} A_i\right| = \sum_{k=1}^{n} (-1)^{k-1} \sum_{\substack{S \subseteq \{1,\dots,n\} \\ |S|=k}} \left|\bigcap_{i \in S} A_i\right|.$$

写成展开式更直观：

$$|A_1 \cup \cdots \cup A_n| = \sum_i |A_i| - \sum_{i<j} |A_i \cap A_j| + \sum_{i<j<k} |A_i \cap A_j \cap A_k| - \cdots + (-1)^{n-1} |A_1 \cap \cdots \cap A_n|.$$

三个集合的特例（$n=3$）：

$$|A \cup B \cup C| = |A| + |B| + |C| - |A \cap B| - |A \cap C| - |B \cap C| + |A \cap B \cap C|.$$

证明策略：**"逐元素计次"证明（元素计数法）**。Note 10 特意避开了标准的"对 n 归纳"，改用组合式论证，理由是后者更直接地揭示了"为什么要交替加减"。核心思路是：不去数集合，而是**固定一个元素，数它在右式里被算了多少次**，并证明这个次数恰好是 1（在并集里的元素）或 0（不在并集里的元素）。

逐步推导：

- **情形 1**：$a \notin A_1 \cup \cdots \cup A_n$。此时对一切 i 都有 $a \notin A_i$，于是对任何子集 $S \subseteq \{1,\dots,n\}$，$\bigcap_{i \in S} A_i$ 也不含 a（因为它被每个 A_i 排除）。所以 a 在右式中的每一项都不被计入，贡献为 0。这与左边"a 不在并集中"一致。
- **情形 2**：$a \in A_1 \cup \cdots \cup A_n$。定义**指标集**

$$M = \{\, i \in \{1,\dots,n\} : a \in A_i \,\}, \qquad m := |M| \ge 1.$$

即"包含 a 的那些集合"的下标。 – 由定义，$a \in \bigcap_{i \in S} A_i \iff S \subseteq M$（且 $S \neq \emptyset$）。若 S 里含有不在 M 中的下标 j，则 $a \notin A_j$，交集自然不含 a。 – 因此 a 在右式中被计入的次数为

$$\sum_{k=1}^{m} (-1)^{k-1} \sum_{\substack{S \subseteq M \\ |S|=k}} 1 = \sum_{k=1}^{m} (-1)^{k-1} \binom{m}{k}.$$

第一个等号用到"内层求和就是在数 M 的 k 元子集个数"，即 $\binom{m}{k}$。 – 由定理 14.4(d)（交错和为零）：$\sum_{k=0}^{m} (-1)^k \binom{m}{k} = 0$，把 $k=0$ 项（等于 1）移过去得

$$\sum_{k=1}^{m} (-1)^{k-1} \binom{m}{k} = 1.$$

所以 a 被计入**恰好 1 次**。 – **合并**：不在并集中的元素贡献 0，在并集中的元素贡献 1，故右式之和恰等于 $\left|\bigcup_i A_i\right|$。■

【证明机制解说】：这个证明最漂亮的地方是**把集合问题转化成"每个元素的权重"问题**。右式的交替加减不是随便凑出来的系数，而是"让每个被数了 m 次的元素，最后净计数恰为 1"的**唯一配方**。这也解释了为什么符号必须是 $-+-+\cdots$：因为 $\sum_{k=1}^{m} (-1)^{k-1} \binom{m}{k} = 1$ 对一切 $m \ge 1$ 成立，而与 m 无关——**容斥公式对所**

有元素"一视同仁"，不需要知道任何元素的 m 是多少。这个"交错和恒为 1"的现象与定理 14.4(c)、14.4(d) 是同一枚硬币的两面。

具体算例（容斥）：1 到 100 中能被 2、3 或 5 整除的数的个数

设 $U=\{1,2,\dots,100\}$，A_2,A_3,A_5 分别为其中能被 2、3、5 整除的数。则 $|A_d|=\lfloor 100/d\rfloor$，且 $|A_d\cap A_{d'}|=\lfloor 100/\mathrm{lcm}(d,d')\rfloor$。

- 单个：$|A_2|=\lfloor 100/2\rfloor=50$，$|A_3|=33$，$|A_5|=20$。
- 两两交集：$|A_2\cap A_3|=\lfloor 100/6\rfloor=16$，$|A_2\cap A_5|=\lfloor 100/10\rfloor=10$，$|A_3\cap A_5|=\lfloor 100/15\rfloor=6$。
- 三重交集：$|A_2\cap A_3\cap A_5|=\lfloor 100/30\rfloor=3$（即 $30,60,90$）。
- 代入三集公式：

$$|A_2\cup A_3\cup A_5|=(50+33+20)-(16+10+6)+3=103-32+3=74.$$

- **脚本验算**：直接循环 $i=1..100$ 判断 `i%2===0 || i%3===0 || i%5===0` 计数得 74 ✓，与公式完全一致。同理对 1 到 1000：暴力计数 734，公式 $\lfloor 1000/2\rfloor+\lfloor 1000/3\rfloor+\lfloor 1000/5\rfloor-\lfloor 1000/6\rfloor-\lfloor 1000/10\rfloor-\lfloor 1000/15\rfloor+\lfloor 1000/30\rfloor=500+333+200-166-100-66+33=734$ ✓。

容斥的"两集"图景：

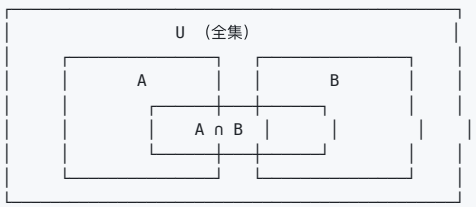


```
|A| + |B| 时：A∩B 内的元素被数了 2 次，A\B 与 B\A 内各被数 1 次
减去 |A∩B| 后：A∩B 内净计数 2 − 1 = 1  ✓
若有第三个集合，三重交集在 +A+B+C 中被数 3 次，
在 −AB−AC−BC 中被减 3 次 => 净 0 次，必须再 +ABC 补回 1 次
```

应用：用容斥重证错排公式（Derangements）

定义 14.1（错排 / Derangement）：设 $\pi=(\pi_1,\dots,\pi_n)$ 是 $\{1,\dots,n\}$ 的一个排列。若指标 i 满足 $\pi_i=i$，称 i 为 π 的一个**不动点（fixed point）**。没有不动点的排列称为**错排**，其数目记作 D_n。

直观背景（"它是什么意思？"）：n 个学生交作业，老师随机打乱后发回。排列 π 中 π_i 表示"第 i 个学生拿到的作业编号"。学生 i 拿回自己作业 $\iff \pi_i=i$。D_n 就是"**没有一个人拿到自己作业**"的发法数。一个自然的问题是：平均有多少人拿到自己的作业？本讲先把 D_n 算出来，讲次 20（期望的线性性）会几行给出答案：平均值恰好是 1，与 n 无关。

用容斥求 D_n：令 A_i = "第 i 个位置是不动点"的全部排列的集合，即 $A_i=\{\pi:\pi_i=i\}$。

- $|A_i|=(n-1)!$：固定 $\pi_i=i$，其余 $n-1$ 个元素任意排列。
- 更一般地，对 $|S|=k$，$\left|\bigcap_{i\in S}A_i\right|=(n-k)!$：固定这 k 个位置，其余 $n-k$ 个元素任意排列。
- 这样的 k 元下标集有 $\binom{n}{k}$ 个，所以由容斥

$$|A_1\cup\cdots\cup A_n|=\sum_{k=1}^{n}(-1)^{k-1}\binom{n}{k}(n-k)!=\sum_{k=1}^{n}(-1)^{k-1}\frac{n!}{k!}.$$

- "至少有一个不动点"的排列数为 $|A_1\cup\cdots\cup A_n|$，故

$$D_n=n!-\sum_{k=1}^{n}(-1)^{k-1}\frac{n!}{k!}=n!\sum_{k=0}^{n}\frac{(-1)^k}{k!}.$$

- **数值校验**：$D_1=0$，$D_2=1$（唯一的错排 $(2,1)$），$D_3=2$（$(2,3,1)$ 与 $(3,1,2)$），$D_4=9$，$D_5=44$，$D_6=265$，$D_7=1854$（脚本按公式 $n!\sum_{k=0}^{n}(-1)^k/k!$ 与按递推 $D_n=(n-1)(D_{n-1}+D_{n-2})$ 两种方式算出的 $n=1..10$ 序列完全一致 ✓）。
- **有趣推论**：$D_n/n!=\sum_{k=0}^{n}(-1)^k/k!\to e^{-1}\approx 0.36788$。脚本给出的序列 $D_3/3!=0.3333$，$D_5/5!=0.3667$，$D_8/8!=0.367882$，$D_{10}/10!=0.367879$ 迅速收敛到 $1/e$。也就是说：**无论 n 多大，"没有一个人拿到自己作业"的概率约为 36.8%**。

（补充）错排的递推式及组合证明：可以只用双射得到**不用容斥**的递推

$$D_n=(n-1)\,(D_{n-1}+D_{n-2}),\qquad n\ge 3,$$

边界 $D_1=0, D_2=1$。**逐步推导**：在错排 π 中考察 $\pi_n=j\in\{1,\dots,n-1\}$（$j=n$ 不可能，否则 n 是不动点），共 $n-1$ 种选择，这就是乘子 $(n-1)$ 的来源。固定 j 后分两种情形：

- **情形 1：$\pi_j=n$**。此时 j 与 n 互换，剩下 $\{1,\dots,n\}\setminus\{j,n\}$ 这 $n-2$ 个元素上的限制恰好是"错排"条件（每个元素都不能映到自己），故方案数 D_{n-2}。
- **情形 2：$\pi_j\neq n$**。此时可以"把 j 看成新的 n"：在集合 $\{1,\dots,j-1,j+1,\dots,n\}$（把 j 换成标签 n）上，限制是"任何元素都不能映到自己"，这恰好是一一对应的 D_{n-1} 个错排。方案数 D_{n-1}。

两类都乘以 $n-1$ 种 j，相加得递推式。脚本验证：由 $D_1=0,D_2=1$ 递推得 $0,1,2,9,44,265,1854,14833,133496,1334961$，与闭式完全一致 ✓。

计数中的常见陷阱（具体反例集）

1. **双重计数（overcounting）**：把 $|A_1 \cup A_2|$ 写成 $|A_1| + |A_2|$ 而漏掉 $|A_1 \cap A_2|$。具体反例：掷一个骰子，$A = \{\text{偶数}\} = \{2,4,6\}$，$B = \{x \geq 4\} = \{4,5,6\}$。$(|A| + |B|)/6 = 6/6 = 1$，即"必然事件"——荒谬。正确的 $|A \cup B| = 3 + 3 - 2 = 4$，概率 $= 4/6 = 2/3$（脚本验算 ✓）。作为对照，$A = \{\text{偶数}\}$ 与 $C = \{\text{奇数}\}$ 确实互斥，$|A \cup C| = 3 + 3 = 6$ 正确——**互斥性不是装饰，是前提**。
2. **把无序当有序 / 把有序当无序**：从 52 张牌中抽 5 张，若误用有序计数 $P(52,5) = 311{,}875{,}200$ 作为样本空间大小（见讲次 15 的用法），则计算概率时分子分母的计数方式必须一致；如果分子是按"手牌（无序）"数出来的，就会得到小 $5! = 120$ 倍的错误答案。**黄金法则：分子分母必须用同一种计数约定。**
3. **误用除法法则（除数不是常数）**：本讲定理 14.2 的反例——水果沙拉问题中每个多重集对应的有序序列数从 1 到 30 不等，$3^5/m$ 无解。必须改用星棒法。
4. **星棒法忘记"非负 / 正"的差别**：$x_1 + x_2 + x_3 = 10$ 的非负解数是 $\binom{12}{2} = 66$；而"每个变量至少为 1"的解数是 $\binom{9}{2} = 36$。两者差 30，脚本暴力枚举分别为 66 与 36 ✓。若题目说"分给 3 个小朋友每人至少一颗糖"，却用了非负公式，就会多算 30 种。
5. **星棒法误用于"上界约束"问题**：星棒法处理的是**无上界**的非负整数解。若要求 $x_i \leq 5$，直接套 $\binom{n+k-1}{k-1}$ 会把 $x_i = 8$ 这种非法解算进去。正确做法是先算无约束解数，再用容斥减去"某个 $x_i \geq 6$"的解（令 $y_i = x_i - 6$，变回无约束问题）。
6. **乘法法则用于"有依赖的步骤"**：如"从 $\{1,2,3\}$ 中不重复地取 2 个数"，若写成 3×3 得 9，忽略了"第 2 步不能取已取的数"。

本讲全部关键数值的集中验算表（全部由 node 脚本跑出，供自查）

量	表达式	数值
$P(52,5)$	$52 \cdot 51 \cdot 50 \cdot 49 \cdot 48 = 52!/47!$	$311{,}875{,}200$
$\binom{52}{5}$	$P(52,5)/5!$	$2{,}598{,}960$
$4\binom{13}{5}$	4×1287	$5{,}148$
$\binom{3+5-1}{5}$	3 类水果取 5 个（多重集）	21
$\binom{6+3-1}{3-1}$	$x_1 + x_2 + x_3 = 6$ 非负解	28
$\binom{10+5-1}{5-1}$	$x_1 + \cdots + x_5 = 10$ 非负解	1001
$\binom{10-1}{5-1}$	同上有正解（$x_i \geq 1$）	126
$\binom{10+3-1}{3-1}$	$x_1 + x_2 + x_3 = 10$ 非负解	66
$\binom{10-1}{3-1}$	同上正解	36
$\sum_{k=0}^{10}\binom{10}{k}$	2^{10}	1024
$\sum_{k\in[2,5]}\binom{k}{2}$	曲棍球棒，$=\binom{6}{3}$	20
IE count	$103 - 32 + 3$ vs 暴力	$74 = 74$
D_4, D_5, D_6, D_7	错排数	$9, 44, 265, 1854$
$D_{10}/10!$	$\to 1/e$	0.367879
骰子陷阱	$	A\cup B

与经典问题的联系

（1）哈希表与负载均衡（讲次 20 的前置）：把 m 个球投入 n 个箱子、球与箱都可区分，所有投法的总数是 n^m（第一法则：每个球独立地有 n 种落点）。这是"随机哈希"的标准模型：m 个键被哈希到 n 个槽位。"某槽位为空"的方案数是 $(n-1)^m$，"两个给定键碰撞"的方案数是 n（它们落入同一槽位，剩下 $m-2$ 个球自由）$= n^{m-1}$。一旦给这些方案配上均匀概率（讲次 15），就能算出碰撞概率——讲次 20 会用期望的线性性直接给出"期望碰撞对数 $= \binom{m}{2}/n$"。以 $m = 1000$ 个键、$n = 10^6$ 个槽位为例，期望碰撞对数 $= \binom{1000}{2}/10^6 = 499500/10^6 = 0.4995$（脚本验算 ✓）——这正是"生日悖论"在哈希中的化身。

（2）随机化素性测试（讲次 6 RSA 的配套）：RSA 需要生成大素数 p, q。Miller–Rabin 之类的随机化测试对合数输入错误输出"素数"的失败概率极低。要**计算或界定**这个失败概率，第一步是把测试的所有随机选择建模成一个有限样本空间并**数出其中的坏选择个数**——这正是本讲的组合计数（以及讲次 23 的 union bound）的用武之地。Note 13 所举的典型陈述"这个随机素性测试算法在输入为合数时输出 prime 的概率至多一万亿分之一"，其分子分母都是计数结果。

（3）纠错码与秘密共享（讲次 7–8）：Reed–Solomon 码的纠错能力论证需要数"通过 k 个点的不超过 $k-1$ 次多项式有多少个"。多项式由它在 k 个点的取值唯一确定（讲次 7 的插值定理），这一"唯一性"本质上是把"多项式"与"k 元组"建立双射；而 Berlekamp–Welch 译码的正确性论证则用到"若两个次数 $\leq k-1$ 的多项式在 $\geq k$ 个点相同则恒等"——数点、数自由度，全是计数。

（4）稳定匹配（讲次 11）：Gale–Shapley 算法运行时间的分析需要统计"提议"的总次数上界为 n^2（因为每一对 (m,w) 至多提议一次）；"至多一次"这个断言本身就是对 $n \times n$ 个有序对的计数。配对方案的潜在总数是 $n!$（n 个人与 n 个人的完美匹配数），这解释了为什么不能靠枚举找稳定匹配。

（5）可计算性与对角化（讲次 12–13）：可数性的核心工具是"把集合与 $\mathbb{N}$ 或其子集建立双射"，即本讲的第零法则在无限世界的推广；停机问题的证明又用到"把程序编码成字符串/整数"的编码计数。理解有限双射是理解无限双射的第一步。

与其他讲次的关联

- **讲次 3（归纳法）**：定理 14.1（乘法法则）的证明就是对步数 k 做归纳，基础情形 $k = 1$ 与归纳步骤的结构与讲次 3 的模板完全一致。若只证归纳步骤而漏掉基础情形，$k = 1$ 的正确性就无从谈起。
- **讲次 12（可数性）与讲次 13（可计算性）**：第零法则（双射保基数）是讲次 12 中"等势"概念的有限版本；讲次 12 用它证明 $|\mathbb{N}| = |\mathbb{Z}| = |\mathbb{Q}|$，而讲次 13 用"不存在双射"证明停机问题不可判定。本讲则用它把"数水果沙拉"化为"数二进制串"。

- **讲次 15（概率基础）**：本讲的直接下游。当样本空间是**等概率**的（uniform）时，概率公式退化为 $\Pr[A] = |A|/|\Omega|$，于是"算概率"就是"算两个计数结果之商"。Note 13 中"掷 4 次硬币恰好 2 次正面"要算 $\binom{4}{2}/2^4$，葫芦概率要算 $13\binom{4}{3}\cdot 12\binom{4}{2}/\binom{52}{5}$——全部依赖本讲的组合数。
- **讲次 16（组合证明）**：本讲定理 14.3–14.6 已经大量使用组合式证明与双计数，讲次 16 会把"同一个集合用两种方法计数"提升为独立的证明方法论（含双计数恒等式、双射技巧与生成函数思想的雏形）。
- **讲次 19（随机变量）与讲次 20（期望的线性性）**：二项分布的概率质量函数 $\Pr[X=k]=\binom{n}{k}p^k(1-p)^{n-k}$ 直接来自本讲的"选 k 个位置放正面"计数；讲次 20 用错排的 D_n 与容斥的结果计算"拿到自己作业的人数的期望恰为 1"。
- **讲次 23（集中不等式）**：Chernoff 界的推导需要计数"偏差超过阈值的比特串有多少个"，即对 $\sum_k \binom{n}{k}$ 这类和做精细估计；本讲的二项式定理与行和恒等式是起点。
- **讲次 5（Euclid / FLT / CRT）**：容斥算例中"能被 d 与 d' 同时整除"要求 $\operatorname{lcm}(d,d')$，而 $\operatorname{lcm}(a,b)=ab/\gcd(a,b)$，把本讲的容斥算例与讲次 5 的 $\gcd$ 工具连接起来。
- **讲次 0–2（证明工具箱）**：反证法、分情形、构造性证明在本讲中反复出现；分情形证明之所以合法，正是因为各情形互不相交、可用和法则相加——**和法则是"分情形"的计数版本**。

关键要点

1. **第零法则是一切的地基**：A 与 B 之间存在双射 $\Rightarrow |A|=|B|$。数不出来的东西，就找一个能数出来的东西与之双射。"编码成 ★ 与 `|` 的串"是这一思想的招牌应用。
2. **乘法法则（第一法则）要求"后续选择数不依赖前序具体选择"**；它对应决策树的叶子数 = 各层扇出之积。**和法则要求各部分互不相交**；不互斥时必须用容斥而不是直接相加。
3. **先数有序，再除以 $k!$**：$\binom{n}{k}=P(n,k)/k!=n!/(k!(n-k)!)$。能除的前提是"每个无序对象对应的有序对象数**恰好相同**且等于 $k!$"。多重集不满足此前提，故必须改用星棒法。
4. **二项式定理 $\sum_k \binom{n}{k}x^k y^{n-k}$ 是组合恒等式的母机**：代 $x=y=1$ 得 $\sum_k\binom{n}{k}=2^n$（子集总数）；代 $x=-1,y=1$ 得 $\sum_k(-1)^k\binom{n}{k}=0$（偶子集数 = 奇子集数）。Pascal 法则 $\binom{n}{k}=\binom{n-1}{k-1}+\binom{n-1}{k}$ 则是"固定一个元素，看含不含它"。
5. **星棒法**：$x_1+\cdots+x_k=n$（$x_i\ge 0$）的解数 $=\binom{n+k-1}{k-1}$；若要求 $x_i\ge 1$，令 $y_i=x_i-1$ 化为 $\binom{n-1}{k-1}$。**两者不可混用。**
6. **容斥原理** $\left|\bigcup_i A_i\right|=\sum_k(-1)^{k-1}\sum_{|S|=k}\left|\bigcap_{i\in S}A_i\right|$，其正确性的本质是"任意被 $m\ge 1$ 个集合包含的元素，净计数为 $\sum_{k=1}^{m}(-1)^{k-1}\binom{m}{k}=1$"——**与 m 无关**，所以公式对全体元素统一成立。
7. **错排** $D_n=n!\sum_{k=0}^{n}(-1)^k/k!\approx n!/e$，且 $D_n=(n-1)(D_{n-1}+D_{n-2})$。$D_n/n!\to 1/e\approx 0.3679$。"没有人拿到自己作业"的概率几乎恒为 36.8%。

常见误区与注意事项

1. **滥用除法法则**：看见"顺序不重要"就想去除以某个数。必须先验证"每个无序对象对应的有序对象数是否相同"。水果沙拉（多重集）中从 1 到 30 不等，除法法则彻底失效。**判断标准：先问"有没有重复元素"**——一旦允许重复，$k!$ 就不再是常数。
2. **把乘法法则用在"数目依赖于前序选择"的地方**：若第 2 步有多少种选择取决于第 1 步**具体**选了哪个（不只是"已经选了"这个事实），乘法法则的连乘形式不适用，必须先分情形。经典错误："从 $\{1,\dots,n\}$ 中取两个不同元素，有 $n\times n$ 种"（应为 $n(n-1)$）。
3. **容斥中漏项，尤其是漏掉三重交集**：三集合公式必须凑齐 7 项（3 个单 + 3 个两两 + 1 个三重）。只写 $|A|+|B|+|C|-|A\cap B|-|A\cap C|-|B\cap C|$ 会**少算**三重交集里的元素（它们被多减了 1 次）。用 $2,3,5$ 整除的算例自查：$103-32=71\neq 74$，差的正是 $|A_2\cap A_3\cap A_5|=3$。
4. **星棒法搞错"非负 / 正"以及"有没有上界"**：非负用 $\binom{n+k-1}{k-1}$，正用 $\binom{n-1}{k-1}$，差一个"先给每个变量各扣 1"。有上界（如 $x_i\le 5$）时星棒法本身不够，必须叠加容斥。$n=10,k=3$ 的两个数值 66 与 36 差 30，务必记住这个对照。
5. **分子分母计数约定不一致**：概率计算中，若分母用无序手牌数 $\binom{52}{5}$，分子也必须按无序数；若分母用有序 $P(52,5)$，分子也必须有序列。混用会造成 $5!=120$ 倍的错误——同花概率 $5148/2598960\approx 0.001981$（正确）与按有序约定误算的结果有天壤之别。
6. **把 $\binom{n}{k}$ 的 $n<k$ 或 $k<0$ 当作有定义**：约定上 $\binom{n}{k}=0$（当 $k<0$ 或 $k>n$）。Pascal 法则、星棒法变体（$n<k$ 时正解数为 0）都依赖这个约定保持自洽。写代码验算时若用"循环乘 k 项"的实现，$k>n$ 会算出 0 但 $k<0$ 可能出错，需要显式处理。
7. **混淆"排列"与"组合"的中文语感**：中文里"选 5 个"既可指有序也可指无序。做题时先明确问自己：**交换两个元素的先后，是否得到"同一个结果"？** 是则用组合，否则用排列。

思考题（带答案）

Q1.（计算题） 一位咖啡店老板有 4 种糖浆口味（香草、焦糖、榛果、肉桂），无限供应。他要调制 6 杯饮料，每杯恰好加 1 泵糖浆。若只关心"每种口味各用了几泵"（即只看 4 元组 (x_1,x_2,x_3,x_4)），共有多少种配方？若要求**每种口味至少用 1 泵**，又有多少种？进一步，若老板规定**香草最多用 2 泵**（其他不限），有多少种？

▸ 答案

设 $x_1+x_2+x_3+x_4=6$，$x_i\ge 0$。

(a) 非负解：$k=4$ 个变量，$n=6$，由星棒法

$$\binom{n+k-1}{k-1}=\binom{6+4-1}{4-1}=\binom{9}{3}=84.$$

(b) 正解（$x_i\ge 1$）：令 $y_i=x_i-1\ge 0$，则 $\sum y_i=6-4=2$，解数

$$\binom{2+4-1}{4-1}=\binom{5}{3}=10.$$

（也可用 $\binom{n-1}{k-1}=\binom{5}{3}=10$ ✓ 两种算法一致。）

(c) 带约束 $x_1\le 2$：星棒法不能直接用，用容斥。设 $A=\{x_1\ge 3\}$，则

$$|A|=\#\{x_1'+x_2+x_3+x_4=6-3=3,\ x_i\ge 0\}=\binom{3+4-1}{4-1}=\binom{6}{3}=20.$$

故 $x_1\le 2$ 的解数 $=84-20=64$。

验算提示：用脚本对 $x_1+\cdots+x_4=6$ 四重循环暴力枚举，$\binom{9}{3}=84$、正解 10、$x_1\le 2$ 的解数 64 三者均可直接核对（注：暴力枚举时正解需要每层从 1 起循环）。

Q2.（证明题） 用组合式论证证明：对 $n\ge 1$，

$$\sum_{k=1}^{n} k\binom{n}{k}=n\cdot 2^{n-1}.$$

▸ 答案

证明策略：双计数——把等式两边都解释成"从 n 个人中选出若干人并指定其中一位当组长"的方案数。

逐步推导：

- **右边视角**：先选组长（n 种），再决定其余 $n-1$ 人各自"进/不进这个小组"（每人 2 种），共 $n\cdot 2^{n-1}$ 种。
- **左边视角**：先决定小组的**规模**为 k，即从 n 人里选 k 人：$\binom{n}{k}$ 种；再在这 k 人里指定组长：k 种。对 $k=1,\dots,n$ 求和得 $\sum_{k=1}^{n} k\binom{n}{k}$。
- 两种视角数的是**同一个集合**（所有"非空小组 + 一名组长"的配置），故相等。■

推论：若把小组规模的均匀取值范围（期望）视作 $\sum_k k\binom{n}{k}/\sum_k\binom{n}{k}=n2^{n-1}/2^n=n/2$，即"随机选一个子集，其平均大小是 $n/2$"——这与直觉一致（每个元素独立地以 $1/2$ 概率入选）。

代数验算：$n=4$：左边 $=1\cdot 4+2\cdot 6+3\cdot 4+4\cdot 1=4+12+12+4=32$；右边 $=4\cdot 2^3=32$ ✓。（脚本对 $\binom{4}{k}$ 行 $1,4,6,4,1$ 核对无误。）

Q3.（概念理解题） 下面这段"证明"错在哪里？请指出并给出正确的数值。

命题：从 1 到 100 中随机取一个整数，它能被 2、3 或 5 整除的概率是 $\frac{50}{100}+\frac{33}{100}+\frac{20}{100}=1.03>1$，所以……

"修正"：既然超过 1 了，那说明这些事件几乎覆盖了所有数，概率约为 1。

▸ 答案

错误有两处：

1. **直接相加不互斥的事件**（核心错误）。三个事件 A_2,A_3,A_5 **并不两两互斥**：例如 30 同时被 $2,3,5$ 整除，6 同时被 $2,3$ 整除。$|A_2|+|A_3|+|A_5|=103$ 是把交集里的元素重复计数后的结果。只有当事件**互斥**时才有 $\Pr[A\cup B]=\Pr[A]+\Pr[B]$。用和法则的前提就是"部分互不相交"。
2. **用 "> 1" 推出 "约为 1" 是无效推理**。概率超过 1 说明计算出了错，而不是说明"几乎必然"；这是数学上的自相矛盾信号（$\Pr\le 1$ 是公理），必须回头修正计算。

正确计算：用容斥原理

$$|A_2\cup A_3\cup A_5|=(50+33+20)-(16+10+6)+3=74,$$

所以 $\Pr=74/100=0.74$。脚本暴力枚举 $i=1..100$ 得计数 74，与公式一致 ✓。

对照的反例（真互斥情形）：若把事件换成 $A=\{$能被 2 整除$\}$ 与 $C=\{$能被 3 整除但不被 2 整除$\}$，这两个事件互斥，$|A|+|C|=50+17=67$ 就是正确的并集大小。（$1..100$ 中能被 3 整除的有 33 个，其中偶数 16 个，故奇数且被 3 整除的有 $33-16=17$ 个。）

要点：看到"把这些数加起来"就条件反射地检查**互斥性**；不互斥就走容斥。这是 CS70 概率部分最高频的失分点之一，讲次 15 会再次以 $\Pr[A\cup B]\le\Pr[A]+\Pr[B]$（union bound）的形式强调。

Lecture 15: Probability Foundations（概率基础）

概述

从讲次 0 到讲次 13，本课程处理的几乎全是"**必然**"：若 p 是素数且 $\gcd(a,p)=1$ 则 $a^{p-1}\equiv 1$；若图连通则有生成树；停机问题不可判定。但从本讲开始，我们转向"**不确定**"：掷一枚硬币不知道结果；哈希函数把键放到哪个槽位不可预知；网络上什么时候来一个请求也无法事先断言。**概率论就是对不确定性进行定量推理的语言**。

本讲的任务不是马上算各种概率，而是把语言的地基打稳：先定义**随机实验**与**样本空间** Ω，再把**事件**定义为 Ω 的子集，然后为每个样本点赋一个概率值。Note 13 采用的是"**逐点赋概率**"的路线：先规定每个样本点 ω 的概率 $\Pr[\omega]$（非负、总和为 1），再把事件的概率定义为"其中所含样本点的概率之和"。这条路线的代价很小、收益很大——本讲后面所有例子（硬币、骰子、扑克、球与箱、生日悖论、蒙提霍尔）都可以只用这一个定义 + 讲次 14 的计数工具完全算穿。

本讲的另一个重点是**破除直觉陷阱**：结果未必等可能（掷两枚硬币的"0/1/2 个正面"不是等概率的）、不互斥的事件不能直接相加、蒙提霍尔的"换门"确实更优。Note 13 结尾的总结只有四句话——**样本空间是什么？每个样本点的概率是多少？事件是哪个子集？把事件里的样本点概率加起来**——而本讲的全部内容都在演示如何一丝不苟地执行这四步。

核心概念的直观解释

随机实验（Random Experiment）

- **定义**：一个**随机实验**是指结果在实验前不能确定、但在相同条件下可以重复进行的实验；其一般形式是"从 n 元集合 S 中抽取 k 个元素"，抽取方式由"有放回 / 无放回"与"有序 / 无序"两个维度决定（正好是讲次 14 的那张四格表）。
- **直观解释（"它是什么意思？"）**：关键在"**可重复**"这三个字。如果一次实验无法重做，那么"概率"就没有操作性含义（Note 13 举的第 5 条典型陈述——"2030 年前北加州有 30% 概率发生 8.0 级地震"——就属于这类：它缺少一个可重复的随机实验作为载体，因此"几乎是空洞的"）。相反，"掷 4 次硬币"是标准的随机实验：条件可控、可以重做一亿次、每次的结果集合固定。
- **具体示例**：掷 4 次硬币，$S=\{H,T\}$，有放回地抽 $k=4$ 个元素，因此可能结果共 $2^4=16$ 个。样本点 $HTHT$ 表示"正、反、正、反"这一具体序列。

样本空间（Sample Space）与样本点（Sample Point）

- **定义**：随机实验的一个**样本点（sample point）** ω 是该实验的一个可能结果；**样本空间**（记作 Ω）是全体可能结果的集合，即所有样本点的集合。
- **直观解释（"它是什么意思？"）**：样本空间就是"**事先把所有可能发生的事都列出来**"的那张清单。它的元素个数由讲次 14 的计数法则给出。注意 Ω 是一个**集合**，样本点是它的**元素**；这个层次区分是整个概率论的基本功。
- **必须掌握的多个例子**（后面每个都会真正用到）：

实验	样本空间 Ω	$\lvert\Omega\rvert$
掷 1 枚硬币	$\{H,T\}$	2
掷 n 枚硬币（或 1 枚掷 n 次）	所有长度 n 的 H/T 串	2^n
掷 2 枚硬币，只记"正面个数"	$\{0,1,2\}$	3（**但不等概率！**见后文反例）
掷 1 枚骰子	$\{1,2,3,4,5,6\}$	6
掷 2 枚骰子	$\{(i,j):1\le i,j\le 6\}$	36
洗一副 52 张牌	52 张牌的所有排列	$52!$
发 5 张扑克牌（不看顺序）	52 张牌的全体 5 元子集	$\binom{52}{5}=2{,}598{,}960$
m 个（可区分）球投入 n 个（可区分）箱	$\{(b_1,\dots,b_m):1\le b_i\le n\}$	n^m
n 个人的生日	n 个生日的序列	365^n
蒙提霍尔游戏	三元组 (i,j,k)，i 奖品门、j 初选门、k 主持人开门	12

- **具体示例（球与箱）**：20 个**有标号**的球投入 10 个**有标号**的箱，样本空间 $\Omega=\{(b_1,\dots,b_{20}):1\le b_i\le 10\}$，其中 b_i 表示"第 i 个球落入哪个箱"。$|\Omega|=10^{20}$（第一法则：每个 b_i 有 10 种选择，共 20 个分量）。把球与箱都视为可区分的是关键建模决定：若球不可区分，样本空间大小就变成 $\binom{20+10-1}{10-1}$（星棒法）——**但那不是"随机投球"的正确模型**，因为"20 个球全挤在 1 号箱"与"每箱 2 个"在物理上绝非等可能，而星棒法的每个多重集却是等权的。这是全课程最重要的建模分岔口之一（详见反例部分）。

事件（Event）

- **定义**：一个**事件** A 就是样本空间的一个**子集**，$A\subseteq\Omega$。事件 A 发生 $\iff$ 实验的实际结果 ω 落在 A 中，即 $\omega\in A$。
- **直观解释（"它是什么意思？"）**：事件不是"某件模糊的事情"，而是一组**被允许的具体结果**的集合。把"恰好 2 次正面"翻译成集合，就是把所有恰好含 2 个 H 的串挑出来。这与讲次 1 的**命题逻辑**在结构上完全同构——这不是巧合，而是同一套布尔代数的两种外衣：

事件语言	集合运算	逻辑语言（讲次 1）
A 或 B 发生	$A\cup B$	$p\vee q$
A 且 B 发生	$A\cap B$	$p\wedge q$
A 不发生	$\bar A=\Omega\setminus A$	$\neg p$
不可能事件	$\emptyset$	恒假
必然事件	Ω	恒真
A 发生则 B 发生	$A\subseteq B$	$p\Rightarrow q$
A、B 不能同时发生	$A\cap B=\emptyset$	p,q 互斥

因此讲次 1 的 De Morgan 定律在这里原样重现：

$$\overline{A\cup B}=\bar A\cap\bar B,\qquad \overline{A\cap B}=\bar A\cup\bar B.$$

用自然语言念出来就是："A 或 B 都没发生 $\iff$ 两者各自都没发生"。 – **具体示例**：掷 4 次公平硬币，Ω 是 16 个长度 4 的 H/T 串。 – $A=$「恰好 2 个正面」$=\{HHTT,HTHT,HTTH,THHT,THTH,TTHH\}$，$|A|=\binom{4}{2}=6$。 – $B=$「4 次全同」$=\{HHHH,TTTT\}$，$|B|=2$。 – $A\cap B=\emptyset$（恰好 2

个正面不可能与 4 次全同时发生），即 A 与 B **互斥**（disjoint / mutually exclusive）。 – $\bar{B}$ = 「不是 4 次全同」= $\Omega \setminus \{HHHH, TTTT\}$，$|\bar{B}| = 16 - 2 = 14$。由补集法则可直接得 $\Pr[\bar{B}] = 1 - 2/16 = 7/8$。

概率空间（Probability Space）与概率公理（Kolmogorov Axioms）

- **定义（逐点赋概率版，Note 13 的路线）**：一个**概率空间**是样本空间 Ω 加上一个函数 $\Pr : \Omega \to \mathbb{R}$，对每个样本点 ω 指定概率 $\Pr[\omega]$，满足
- **非负性（Non-negativity）**：$0 \le \Pr[\omega] \le 1$ 对一切 $\omega \in \Omega$；
- **归一性（Total one）**：$\sum_{\omega \in \Omega} \Pr[\omega] = 1$。

对任意事件 $A \subseteq \Omega$，定义

$$\Pr[A] = \sum_{\omega \in A} \Pr[\omega].$$

- **定义（公理化版，柯尔莫哥洛夫公理 Kolmogorov Axioms）**：更现代的写法是把 $\Pr$ 定义在**事件**上，要求
- **非负性**：$\Pr[A] \ge 0$ 对一切事件 $A \subseteq \Omega$；
- **归一性**：$\Pr[\Omega] = 1$；
- **可数可加性（countable additivity）**：若 $A_1, A_2, A_3, \ldots$ **两两不相交**（$A_i \cap A_j = \emptyset$ 对 $i \ne j$），则

$$\Pr\left[\bigcup_{i \ge 1} A_i\right] = \sum_{i \ge 1} \Pr[A_i].$$

在**有限**样本空间（本讲及后续大部分讲次的舞台）中，第三条只需对有限个互斥事件成立，而它恰好等价于"逐点赋概率 + 事件概率 = 所含样本点概率之和"。 – **直观解释（"它是什么意思？"）**：三条公理是"概率该有的样子"的最小约定。**非负性**说概率不能是负数；**归一性**说"总得发生点什么"，所有可能性加起来正好是 1；**可数可加性**说"如果两组结果不可能同时出现，那么'出现其中任意一个'的概率就是两者概率之和"——这条最强、也最有用，本讲后面所有性质（$\Pr[\emptyset] = 0$、补集法则、单调性、并的法则、union bound）都是从它推出来的。把这个"把概率质量分配到样本点上、事件取和"的图景记住，后面几讲的推导都会变成顺理成章的代数。 – **具体示例（均匀分配）**：若 $|\Omega| = N$，最省事的赋概率方式是**均匀（uniform）**：$\Pr[\omega] = 1/N$ 对一切 ω。掷 4 次公平硬币：$N = 16$，每个样本点概率 $1/16$。掷两枚公平骰子：$N = 36$，每个样本点概率 $1/36$。

古典概型 / 等概率样本空间（Uniform Probability Space）

- **定义**：若 Ω 有限、$|\Omega| = N$，且每个样本点等概率 $\Pr[\omega] = 1/N$，则对任意事件 A，

$$\Pr[A] = \frac{|A|}{|\Omega|} = \frac{|A|}{N}.$$

- **直观解释（"它是什么意思？"）**：这是**把概率问题彻底降维成计数问题**的公式。它解释了为什么讲次 14 的每一件工具（排列、组合、星棒法、容斥）在概率论里都会立刻派上用场：只要样本空间是均匀的，"算概率"就是"数两次、做一次除法"。Note 13 的原话是"for uniform spaces, computing probabilities reduces to counting sample points"。
- **具体示例**：掷两枚公平骰子，事件 A = 「点数和 ≥ 10」。手工枚举：$(4,6), (5,5), (5,6), (6,4), (6,5), (6,6)$，共 $|A| = 6$，故 $\Pr[A] = 6/36 = 1/6$。事件 B = 「至少有一个 6」：11 个样本点（$6 + 6 - 1$：第一枚为 6 的 6 个，第二枚为 6 的 6 个，重复算了一次 $(6,6)$），$\Pr[B] = 11/36 \approx 0.3056$。（脚本暴力枚举 36 个样本点验证 $|A| = 6$、$|B| = 11$ ✓）

生日悖论的图景：为什么 23 人就够？（概率随 n 增长的形状）

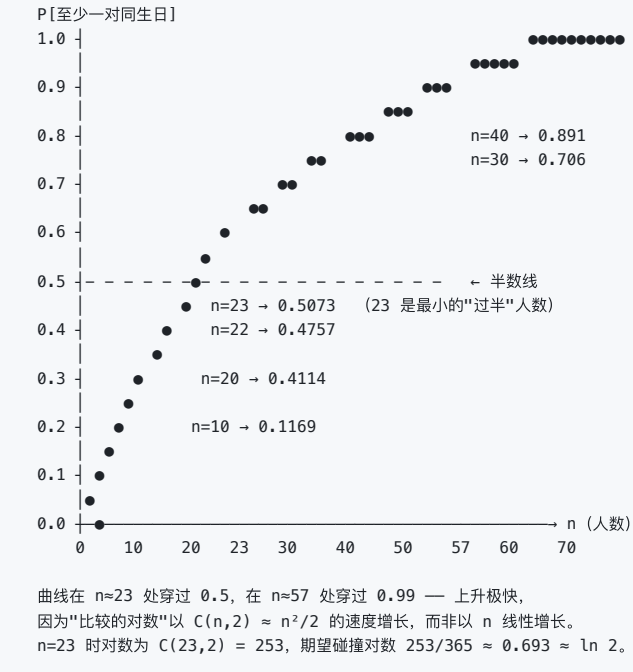

曲线在 n≈23 处穿过 0.5，在 n≈57 处穿过 0.99 —— 上升极快，
因为"比较的对数"以 C(n,2) ≈ n²/2 的速度增长，而非以 n 线性增长。
n=23 时对数为 C(23,2) = 253，期望碰撞对数 253/365 ≈ 0.693 ≈ ln 2。

⚠️ **关键警告：$|A|/|\Omega|$ 只对均匀空间成立。** 这是 Note 13 反复强调的坑，本讲后面会用一个具体反例把它讲透。

样本空间与事件的图景（以"掷 4 次公平硬币"为例）

```
样本空间 Ω = 全部 16 个长度 4 的 H/T 串（每个样本点概率 1/16，均匀）

┌──────────────────────────────────────────────────────┐
│  HHHH   HHHT   HHTH   HHTT   HTHH   HTHT   HTTH   HTTT  │
│  ────   ────   ────   ▓▓▓▓   ────   ▓▓▓▓   ▓▓▓▓   ────  │
│  THHH   THHT   THTH   THTT   TTHH   TTHT   TTTH   TTTT  │
│  ────   ▓▓▓▓   ▓▓▓▓   ────   ▓▓▓▓   ────   ────   ────  │
│                                                      │
│  ▓▓▓▓ = 事件 A「恰好 2 个正面」的样本点，|A| = C(4,2) = 6      │
│  ──── = A 的补集 Ā 中的样本点，|Ā| = 16 − 6 = 10              │
│                                                      │
│  另有事件 B「4 次全同」= {HHHH, TTTT}，|B| = 2                 │
│  A ∩ B = ∅ （互斥：恰好 2 个正面 与 4 次全同 不能同时发生）      │
│  故 P[A ∪ B] = P[A] + P[B] = 6/16 + 2/16 = 8/16 = 1/2        │
│       ← 这里可以直接相加，因为 A ∩ B = ∅（互斥许可证）          │
└──────────────────────────────────────────────────────┘

若把 Ω 粗化成 Ω' = {0,1,2,3,4}（只记正面个数），则各点概率为
1/16, 4/16, 6/16, 4/16, 1/16 ——  并不相等！
=> 对 Ω' 不能使用 P[A] = |A|/|Ω'|   （这正是本讲的核心陷阱）
```

完整证明与推导（核心）

定理 15.1（由公理推出的基本性质）：设 $(\Omega, \Pr)$ 是概率空间。则：

- (a) $\Pr[\emptyset] = 0$；
- (b) **补集法则**：$\Pr[\bar{A}] = 1 - \Pr[A]$；
- (c) **单调性**：若 $A \subseteq B$，则 $\Pr[A] \le \Pr[B]$；
- (d) **并的法则**：$\Pr[A \cup B] = \Pr[A] + \Pr[B] - \Pr[A \cap B]$，特别地 $\Pr[A \cup B] \le \Pr[A] + \Pr[B]$；
- (e) **布尔不等式 / Union Bound**：$\Pr\left[\bigcup_{i=1}^{n} A_i\right] \le \sum_{i=1}^{n} \Pr[A_i]$。

证明策略：**全部从可数可加性出发，通过"把目标集合拆成互不相交的碎块"来实现**。这套手法是概率论里的"分情形证明"：只要能造出一组两两不相交的事件把目标事件**恰好**覆盖，可加性就直接给出等式。选这个策略而不是"从直觉出发"，是因为公理化证明的价值恰恰在于**每一步都能指出用了哪条公理**——这正是排除"直觉错误"的唯一可靠机制。

逐步推导 (a)：$\Pr[\emptyset] = 0$。

- 由归一性，$\Pr[\Omega] = 1$。
- 把 Ω 写成 $\Omega = \Omega \cup \emptyset \cup \emptyset \cup \cdots$。这里出现的集合是 $\Omega, \emptyset, \emptyset, \ldots$，它们**两两不相交**（$\emptyset$ 与任何集合都不相交，$\Omega \cap \emptyset = \emptyset$ ✓）。
- 对这可数多个两两不相交的事件应用**可数可加性**：

$$\Pr[\Omega] = \Pr[\Omega] + \Pr[\emptyset] + \Pr[\emptyset] + \cdots$$

- 等号左边是 1（归一性）。把 $\Pr[\Omega] = 1$ 移到左边得 $0 = \Pr[\emptyset] + \Pr[\emptyset] + \cdots$。由**非负性**，右边每一项 ≥ 0；一串非负数之和为 0，只能是每一项都为 0。故 $\Pr[\emptyset] = 0$。■
- **（有限情形的更简写法）**：若只在有限可加性下工作，取互斥的 $A_1 = \Omega$、$A_2 = \emptyset$，则 $\Omega \cup \emptyset = \Omega$，由可加性 $\Pr[\Omega] = \Pr[\Omega] + \Pr[\emptyset]$，即得 $\Pr[\emptyset] = 0$。

逐步推导 (b)：补集法则 $\Pr[\bar{A}] = 1 - \Pr[A]$。

- 记 $\bar{A} = \Omega \setminus A$ 为 A 的补集。
- **拆块**：$\Omega = A \cup \bar{A}$，且 $A \cap \bar{A} = \emptyset$（一个元素不可能既在 A 里又不在 A 里），两者**互斥**。
- 由可加性，$\Pr[\Omega] = \Pr[A] + \Pr[\bar{A}]$。
- 由归一性 $\Pr[\Omega] = 1$，移项即得 $\Pr[\bar{A}] = 1 - \Pr[A]$。■
- **附带结论**：由非负性，$\Pr[\bar{A}] \ge 0$，故 $\Pr[A] \le 1$。这就把"概率不超过 1"从"显然"变成了"可证"。

逐步推导 (c)：单调性，若 $A \subseteq B$ 则 $\Pr[A] \le \Pr[B]$。

- **拆块**：把 B 切成两块：$B = A \cup (B \setminus A)$。由于 $A \subseteq B$，A 中的元素都在 B 中，且 $B \setminus A$ 装的是"在 B 中但不在 A 中"的元素，两块**互斥**（$A \cap (B \setminus A) = \emptyset$），并起来正好是 B。
- 由可加性，$\Pr[B] = \Pr[A] + \Pr[B \setminus A]$。
- 由非负性，$\Pr[B \setminus A] \ge 0$，故 $\Pr[B] \ge \Pr[A]$。■
- **注意**：这里的论证与 (b) 完全同构——**补集法则只是单调性论证在 $B = \Omega$ 时的特例**（此时 $B \setminus A = \bar{A}$，$\Pr[\Omega] = \Pr[A] + \Pr[\bar{A}]$）。

逐步推导 (d)：并的法则 $\Pr[A \cup B] = \Pr[A] + \Pr[B] - \Pr[A \cap B]$。

- **拆块（关键一步）**：把 $A \cup B$ 拆成三块互不相交的部分：

$$A \cup B = (A \setminus B) \cup (A \cap B) \cup (B \setminus A).$$

逐一检查互斥性：$A \setminus B$ 中的元素不在 B 中，故与 $A \cap B$、$B \setminus A$ 都不相交；$A \cap B$ 与 $B \setminus A$ 也不相交（后者不在 A 中）。检查覆盖性：$A \cup B$ 中任一元素要么同时在 A 与 B 中（中间那块），要么在 A 不在 B（左边那块），要么在 B 不在 A（右边那块）。三种情形穷尽且不重叠。 – 由可加性：

$$\Pr[A \cup B] = \Pr[A \setminus B] + \Pr[A \cap B] + \Pr[B \setminus A]. \tag{$*$}$$

- 另一方面，同样地 $A = (A \setminus B) \cup (A \cap B)$（互斥），故 $\Pr[A] = \Pr[A \setminus B] + \Pr[A \cap B]$，即 $\Pr[A \setminus B] = \Pr[A] - \Pr[A \cap B]$。同理 $\Pr[B \setminus A] = \Pr[B] - \Pr[A \cap B]$。
- 把这两个表达式代回 $(*)$：

$$\Pr[A \cup B] = \big(\Pr[A] - \Pr[A \cap B]\big) + \Pr[A \cap B] + \big(\Pr[B] - \Pr[A \cap B]\big) = \Pr[A] + \Pr[B] - \Pr[A \cap B]. \quad \blacksquare$$

- **不等式的部分**：由非负性 $\Pr[A \cap B] \geq 0$，故 $\Pr[A \cup B] \leq \Pr[A] + \Pr[B]$。**等号成立 $\iff \Pr[A \cap B] = 0$**，最常见的充分条件是 $A \cap B = \emptyset$（互斥）。
- **具体算例**：掷两枚公平骰子，$A =$「点数和 ≥ 10」$= \{(4,6),(5,5),(5,6),(6,4),(6,5),(6,6)\}$，$B =$「至少有一个 6」$= \{(1,6),(2,6),(3,6),(4,6),(5,6),(6,6),(6,1),(6,2),(6,3),(6,4),(6,5)\}$。
- $\Pr[A] = 6/36$，$\Pr[B] = 11/36$。
- $A \cap B = \{(4,6),(5,6),(6,4),(6,5),(6,6)\}$，$|A \cap B| = 5$，$\Pr[A \cap B] = 5/36$。（脚本枚举验证：交集确有 5 个样本点 ✓）
- 于是 $\Pr[A \cup B] = 6/36 + 11/36 - 5/36 = 12/36 = 1/3$。（脚本验算 ✓）
- **若误用"直接相加"**，会得到 $17/36 \approx 0.472$，比正确值 $1/3 \approx 0.333$ 大出 $5/36$——多出来的正是被重复计入的交集。
- **对照（真互斥情形）**：$A =$「点数和为 2」$= \{(1,1)\}$ 与 $B =$「点数和为 12」$= \{(6,6)\}$ 互斥，$\Pr[A \cup B] = 1/36 + 1/36 = 2/36 = 1/18$，此时直接相加**正确**。**互斥不是装饰，它是"直接相加"的许可证。**

逐步推导 (e)：Union Bound（布尔不等式 / Boole's Inequality）

$$\Pr\left[\bigcup_{i=1}^{n} A_i\right] \leq \sum_{i=1}^{n} \Pr[A_i].$$

证明策略：**对 n 做归纳，归纳步骤用 (d)**。也可以只用"逐步吸收重叠"的构造性论证。选归纳法的理由是 (d) 恰好是 $n = 2$ 的版本，归纳可以把一般 n 归约到两次一组。**注意这条不等式的重大意义：它不需要任何独立性、不需要任何互斥性、不需要任何分布假设**——正因为如此"无脑好用"，它成了后面讲次 23（集中不等式）里最常用的工具。

逐步推导：

- **基础情形 $n = 1$**：$\Pr[A_1] \leq \Pr[A_1]$，成立（等号）。
- **基础情形 $n = 2$**：这正是 (d) 的不等式形式：$\Pr[A_1 \cup A_2] = \Pr[A_1] + \Pr[A_2] - \Pr[A_1 \cap A_2] \leq \Pr[A_1] + \Pr[A_2]$。
- **归纳假设**：设对 n 个事件成立，即 $\Pr[\bigcup_{i=1}^{n} A_i] \leq \sum_{i=1}^{n} \Pr[A_i]$。
- **归纳步骤**：令 $C = \bigcup_{i=1}^{n} A_i$。则 $\bigcup_{i=1}^{n+1} A_i = C \cup A_{n+1}$。对这两个事件用 (d)：

$$\Pr\left[\bigcup_{i=1}^{n+1} A_i\right] = \Pr[C \cup A_{n+1}] \leq \Pr[C] + \Pr[A_{n+1}] \leq \sum_{i=1}^{n} \Pr[A_i] + \Pr[A_{n+1}] = \sum_{i=1}^{n+1} \Pr[A_i],$$

第二个不等号用了归纳假设。由归纳原理，命题对一切 $n \geq 1$ 成立。$\blacksquare$ – **（另一种视角：丢重叠）**：$\bigcup_i A_i = A_1 \cup (A_2 \setminus A_1) \cup (A_3 \setminus (A_1 \cup A_2)) \cup \cdots$。这组集合两两不相交（每一步都扣掉了前面所有的并），且并起来仍是 $\bigcup_i A_i$。由可加性，$\Pr[\bigcup_i A_i] = \sum_i \Pr[A_i \setminus (A_1 \cup \cdots \cup A_{i-1})]$。由单调性，$A_i \setminus (\cdots) \subseteq A_i$，故 $\Pr[A_i \setminus (\cdots)] \leq \Pr[A_i]$。逐项放缩即得 union bound。这个视角更直接地说明了"不等号来自哪里"：**我们把重叠的部分减掉了，因此放缩方向是 $\leq$。** – **具体算例（union bound 的实用性）**：掷 4 次公平骰子，设 $A_i =$「第 i 次掷出 6」，$i = 1, \ldots, 4$。则

$$\Pr[\text{至少一次 } 6] = 1 - \Pr[\text{一次都没有 } 6] = 1 - \left(\frac{5}{6}\right)^4 = 1 - \frac{625}{1296} = \frac{671}{1296} \approx 0.5177.$$

union bound 给出 $\leq 4 \times \frac{1}{6} = \frac{2}{3} \approx 0.667$ —— 上界只差约 15 个百分点，而且是**几乎零成本的估计**。当 n 很大、精确计算不可能时，这类粗略但正确的界往往正是算法分析所需要的。 – **具体算例（小概率事件的控制）**：设有 10 个"坏事件"，每个概率 $4^{-10} = 1/1{,}048{,}576 \approx 9.54 \times 10^{-7}$。union bound 给出

$$\Pr[\text{至少一个坏事件}] \leq 10 \times 4^{-10} \approx 9.54 \times 10^{-6},$$

即不到十万分之一。（脚本验算：$4^{-10} = 9.5367 \times 10^{-7}$，乘 10 得 9.5367×10^{-6} ✓）这正是 Note 13 开头"随机素性测试失败概率至多一万亿分之一"这类陈述的证明范式。

【证明机制解说】：定理 15.1 的五条性质共享一个**统一的证明模板**，值得单独记住：

```
        要证 P[X] 的某个关系
                │
                ▼
① 把 X 拆成两两不相交的碎块 X = X1 ⊎ X2 ⊎ ... ⊎ Xm
      （最常用的两块拆法：X = A ⊎ (X \ A)）
                │
                ▼
② 用可数可加性：   P[X] = P[X1] + P[X2] + ... + P[Xm]
                │
                ▼
③ 用非负性 / 归一性 把式子收拾成想要的形式
      （P[∅]=0、补集法则、单调性、并的法则全部由此而来）

唯一"柔性"的一步是放缩：若某块 ⊆ 另一集合，由单调性可替换成更大的量
      —— union bound 就是这样把"互斥才可加"升级成"永远可加（代价是不等式）"
```

这个模板的价值在于：**它让"概率直觉"变得可审计**。任何关于概率的等式或不等式，都可以拆回到"我在哪一步假设了互斥？我在哪一步做了放缩？"——蒙提霍尔问题的种种错误解答，本质上都是在第 ① 步就把不是碎块的东西当成碎块加了。

反例（本讲最重要的一条）：结果不等可能时的陷阱

> **"掷两枚公平硬币，正面个数只能是 0、1、2 三种，所以每种的概率是 $1/3$。"**

这个推理错在哪？ 它把"$|\Omega| = 3$ 且 $\Pr = |A|/|\Omega|$"当成了**无条件**成立的公式。但 $|A|/|\Omega|$ **只在样本空间均匀时才成立**。用这个"样本空间" $\Omega' = \{0, 1, 2\}$ 时，三个样本点**并不等可能**：正确概率是

$$\Pr[0] = \frac{1}{4}, \qquad \Pr[1] = \frac{1}{2}, \qquad \Pr[2] = \frac{1}{4}.$$

正确的做法是把样本空间取细：$\Omega = \{HH, HT, TH, TT\}$，$|\Omega| = 4$，**每个样本点概率 $1/4$（此时才均匀）**。则事件「恰好 1 个正面」$= \{HT, TH\}$ **含两个**样本点，故 $\Pr[1] = 2/4 = 1/2$。注意 HT 与 TH 是**不同的样本点**——只要硬币是可区分的（或等价地，掷两次有先后顺序），"先正后反"和"先反后正"就是两个不同的结果。

为什么错答案看起来很合理？ 因为"$0, 1, 2$"是三个数，$1/3$ 看起来"对称"。但**对称只应该发生在等可能的结构里**：把结果粗化成"正面个数"时，我们丢掉了"是哪一枚硬币出的正面"这一信息，而三个粗化结果的**内部结构并不一样大**（0 和 2 各含 1 个细结果，1 含 2 个）。这正是讲次 14 星棒法反例的同构问题——那里是"每个多重集对应的有序序列数不一样"，这里是"每个粗化结果对应的样本点数不一样"。**粗化必须保证每个粗块含同样多的细结果，否则均匀性立刻丢失。**

一般化（n 枚硬币）：掷 n 枚硬币，Ω 是 2^n 个长度 n 的串，均匀分布。事件「恰好 k 个正面」由 $\binom{n}{k}$ 个串组成（讲次 14：选 k 个位置放 H），所以

$$\Pr[\text{恰好 } k \text{ 个正面}] = \frac{\binom{n}{k}}{2^n}.$$

$n = 2$：$\binom{2}{0}/4 = 1/4$、$\binom{2}{1}/4 = 1/2$、$\binom{2}{2}/4 = 1/4$ ✓ 与上面一致。**这就是 $1/3$ 错答案的正确答案。**

定理 15.2（非均匀硬币的二项概率 / 伯努利试验）：设硬币有 $\Pr[H] = p$、$\Pr[T] = 1 - p$，独立地掷 n 次。则对任意 $0 \le r \le n$，

$$\Pr[\text{恰好 } r \text{ 个正面}] = \binom{n}{r} p^r (1-p)^{n-r}.$$

证明策略：拆成互斥的样本点，逐点赋概率再求和。这里"逐点赋概率"的具体形式是"把每一步的概率相乘"，Note 13 特意提醒：**这一步在本讲尚未被严格证明（它需要讲次 18 的独立性概念），当前先作为例子中"就是这么做乘法"的操作性规则使用。**

逐步推导：

- 样本空间 Ω 是全部 2^n 个长度 n 的 H/T 串，$|\Omega| = 2^n$（第一法则）。
- **单个序列的概率**：考虑一个恰好含 r 个 H、$n - r$ 个 T 的序列，比如 $HHTHT\cdots$。把"掷第 i 次"看成第 i 步选择，概率 p 或 $1 - p$ 与前面几次的结果无关，故该序列的概率是 r 个 p 与 $n - r$ 个 $(1 - p)$ 的乘积：

$$\Pr[\text{该序列}] = p^r (1-p)^{n-r}.$$

关键：这个值与序列中 H 的"位置"完全无关，只与 r 有关。 – **数有多少个这样的序列**：恰好含 r 个 H 的串的个数 = 从 n 个位置中选出 r 个放 H = $\binom{n}{r}$（讲次 14）。 – **求和**：这些序列彼此互斥（一次实验只能产生一个序列），事件「恰好 r 个正面」正是它们的并，由可加性：

$$\Pr[\text{恰好 } r \text{ 个正面}] = \sum_{\text{这些序列}} p^r (1-p)^{n-r} = \binom{n}{r} p^r (1-p)^{n-r}. \quad \blacksquare$$

- **具体算例（Note 13 的 $p = 2/3$，$n = 4$）**：
- $\Pr[HHHH] = (2/3)^4 = 16/81$；$\Pr[TTHH] = (1/3)^2 (2/3)^2 = 4/81$。
- 事件 $A =$「4 次全同」$= \{HHHH, TTTT\}$，两样本点互斥：

$$\Pr[A] = \left(\tfrac{2}{3}\right)^4 + \left(\tfrac{1}{3}\right)^4 = \frac{16}{81} + \frac{1}{81} = \frac{17}{81} \approx 0.2099.$$

（脚本验算：$(2/3)^4 + (1/3)^4 = 0.20987654\ldots = 17/81$ ✓）

- 事件 $B =$「恰好 2 个正面」：每个这样的序列概率 $(2/3)^2(1/3)^2 = 4/81$，共 $\binom{4}{2} = 6$ 个，

$$\Pr[B] = 6 \cdot \frac{4}{81} = \frac{24}{81} = \frac{8}{27} \approx 0.2963.$$

（脚本验算：$6 \times (2/3)^2 \times (1/3)^2 = 0.296296\ldots = 8/27$ ✓）

- **自检（全分布五种取值的概率之和应为 1）**：五种取值分别是

$$k=0:\ \left(\tfrac{1}{3}\right)^4 = \frac{1}{81}, \quad k=1:\ 4\cdot\tfrac{2}{3}\cdot\left(\tfrac{1}{3}\right)^3 = \frac{8}{81}, \quad k=2:\ 6\cdot\left(\tfrac{2}{3}\right)^2\left(\tfrac{1}{3}\right)^2 = \frac{24}{81},$$
$$k=3:\ 4\cdot\left(\tfrac{2}{3}\right)^3\cdot\tfrac{1}{3} = \frac{32}{81}, \quad k=4:\ \left(\tfrac{2}{3}\right)^4 = \frac{16}{81}.$$

五项之和 $= (1+8+24+32+16)/81 = 81/81 = 1$ ✓（脚本逐项验算：$0.012346, 0.098765, 0.296296, 0.395062, 0.197531$，和 $=1$ ✓）。**这个"和为 1"不是巧合

$$\sum_{r=0}^{n} \binom{n}{r} p^r (1-p)^{n-r} = \big(p + (1-p)\big)^n = 1^n = 1.$$

也就是说，"所有可能的正面个数"构成了一个合法的概率分布，其总质量恰为 1——**归一性在这里自动成立，这是二项式定理给我们的免费保证**。

【证明机制解说】：这个定理示范了**概率计算的"四步流程"**（Note 13 结尾总结的那四步）：

1. **样本空间是什么？** $\Omega =$ 全部 2^n 个 H/T 串。
2. **每个样本点的概率是多少？** $p^r(1-p)^{n-r}$，其中 r 是该串中 H 的个数。
3. **事件是哪个子集？** 恰好 r 个正面的全部串，共 $\binom{n}{r}$ 个。
4. **把事件里的样本点概率加起来。** 因为有 $\binom{n}{r}$ 个**等概率**的样本点，求和退化成乘法。

第 4 步之所以能"退化成乘法"，关键在第 2 步发现"所有含 r 个 H 的串概率相同"——这是用**讲次 14 的组合计数**去替代**逐项求和**的桥梁。

定理 15.3（Pascal 恒等式的概率证明）：$\binom{n}{r} = \binom{n-1}{r-1} + \binom{n-1}{r}$。

证明策略：**条件分解 / 首次结果分情形**——把事件按"第 1 次掷出的是 H 还是 T"拆成互斥的两块，两块的概率之和必须等于原概率。这与讲次 14 的"固定一个元素、分含它/不含它"是同一个证明骨架的概率版。

逐步推导：

- 设掷 n 枚公平硬币，考虑事件「恰好 r 个正面」，其概率为 $\binom{n}{r}/2^n$。
- 按**第一次**的结果分情形：
- **第 1 次是 H**（概率 $1/2$）：剩下 $n-1$ 次中需要恰好 $r-1$ 个 H，其概率为 $\binom{n-1}{r-1}/2^{n-1}$。
- **第 1 次是 T**（概率 $1/2$）：剩下 $n-1$ 次中需要恰好 r 个 H，其概率为 $\binom{n-1}{r}/2^{n-1}$。
- 两个情形互斥且穷尽，故两块概率相加等于总的：

$$\frac{\binom{n}{r}}{2^n} = \frac{1}{2}\cdot\frac{\binom{n-1}{r-1}}{2^{n-1}} + \frac{1}{2}\cdot\frac{\binom{n-1}{r}}{2^{n-1}} = \frac{\binom{n-1}{r-1} + \binom{n-1}{r}}{2^n}.$$

- 两边同乘 2^n 即得 Pascal 恒等式。■
- **数值校验**：$n=6, r=3$：左边 $\binom{6}{3} = 20$，右边 $\binom{5}{2} + \binom{5}{3} = 10 + 10 = 20$ ✓（脚本验算）。

【证明机制解说】：这是"**同一个恒等式，可以有代数证明、组合证明、概率证明三种外衣**"的范例。概率版本的独特价值在于：它把 Pascal 三角形递推解释成"**多掷一枚硬币会怎样**"，从而让人看到二项式系数不只是数数结果，而是"概率质量如何从第 n 层流到第 $n+1$ 层"的守恒律。讲次 16 会把这类技巧系统化。

与经典问题的联系

（1）扑克牌：一手 5 张牌是葫芦（Full House）的概率

- **问题背景**：扑克牌去掉大小王共 52 张，分 4 种花色（suit，各 13 张）、13 个点数（rank）。一手 5 张牌中，若"某点数出现 3 次、另一点数出现 2 次"，称为**葫芦（Full House）**，例如 $7\heartsuit 7\spadesuit 7\diamondsuit K\clubsuit K\heartsuit$。
- **数学建模**：样本空间 $\Omega =$ 52 张牌的全体 5 元子集（**不考虑发牌顺序**——因为"手牌"本身是一组牌，顺序无关）。由讲次 14，

$$|\Omega| = \binom{52}{5} = 2{,}598{,}960.$$

洗牌充分时每个 5 元子集等可能，故 Ω 是**均匀**样本空间。 – **数有利结果**（分四步，每步用乘法法则）： 1. **选三点数的点数**：$\binom{13}{1} = 13$ 种。 2. **选这 3 张牌的花色**：从该点数的 4 种花色中选 3 种，$\binom{4}{3} = 4$ 种。 3. **选二点数的点数**：剩下的 12 个点数中选 1 个，$\binom{12}{1} = 12$ 种。 4. **选这 2 张牌的花色**：从该点数的 4 种花色中选 2 种，$\binom{4}{2} = 6$ 种。 由乘法法则（四步相互独立、选择数不依赖前序具体选择），有利结果数为

$$13 \times \binom{4}{3} \times 12 \times \binom{4}{2} = 13 \times 4 \times 12 \times 6 = 3744.$$

- **概率**：

$$\Pr[\text{葫芦}] = \frac{3744}{2{,}598{,}960} = \frac{3744}{2598960} \approx 0.0014406.$$

（脚本验算：$3744/2598960 = 0.001440576230\ldots$，约 0.144%，即大约每 694 手出现一次 ✓） – **对照：同花（Flush）**。同花是"5 张牌花色相同"，其数目为 $4\binom{13}{5} = 4 \times 1287 = 5148$，概率

$$\Pr[\text{同花}] = \frac{5148}{2598960} = 0.00198079\ldots \approx 0.198\%,$$

与 Note 13 所引的"约千分之二（2 in 1000）"完全吻合 ✓（脚本验算）。**注意葫芦比同花更稀有**（$0.144\% < 0.198\%$），这与扑克牌规则里葫芦的牌型更大是一致的。 – **对照：两对（Two Pair）**（用于确认建模方式的一致性）：$\binom{13}{2}\binom{4}{2}^2 \cdot 11 \cdot 4 = 78 \times 36 \times 44 = 123{,}552$，概率 $= 123552/2598960 \approx 0.04754$ ✓（脚本验算）。 – **建模要点**：全部计数都基于"**无序手牌**"。若改用有序发牌序列（$|\Omega| = P(52,5) = 311{,}875{,}200$），分子也必须是"葫芦的发牌序列数"，即每一种葫芦手牌都可以按 $5!$ 种顺序发出，故为 $3744 \times 5! = 449{,}280$。比值 $449280/311875200 = 0.0014406$ 与上面的结果**完全相同**——这说明**只要分子分母用同一种约定，答案就不变**，但混用约定就会差 $5! = 120$ 倍。**坚持分子分母用同一种约定**（本讲"常见误区"第 3 条）。

（2）球与箱（Balls and Bins）：负载均衡的数学模型

- **问题背景**：一个分布式系统有 n 台服务器（processor），m 个作业（job）各自被**独立且均匀随机**地指派给一台服务器。问"某台服务器闲置""没有任何服务器被压垮"这类事件的概率。
- **数学建模**：把作业看成**可区分的球**（因为作业 1 和作业 2 是不同的任务），服务器看成**可区分的箱**（服务器 1 和服务器 2 不同）。样本空间

$$\Omega = \{(b_1, \ldots, b_m) : 1 \le b_i \le n\}, \qquad |\Omega| = n^m.$$

均匀分布：每个 b_i 独立均匀地取 $[n]$ 中一个值。 – **算例（Note 13 的配置）**：20 个球投入 10 个箱，$|\Omega| = 10^{20}$。事件 $A =$「1 号箱为空」：所有 20 个球都必须落在其余 9 个箱中，方案数 9^{20}，故

$$\Pr[A] = \frac{9^{20}}{10^{20}} = \left(\frac{9}{10}\right)^{20} = \left(1 - \frac{1}{10}\right)^{20} \approx 0.12158.$$

（脚本验算：$(0.9)^{20} = 0.121576654\ldots$ ✓，即约 12.16%） – 事件 $B =$「1 号箱至少有一个球」$= \bar{A}$，由**补集法则**（定理 15.1(b)）

$$\Pr[B] = 1 - \Pr[A] \approx 0.87842.$$

（脚本验算：$1 - 0.121576654 = 0.878423345$ ✓，约 87.84%）——注意这里**必须**用补集法则而非"至少一个"的直接计数，因为"至少一个"要分 20 种情形（恰有 1 个、恰有 2 个……），而补集只有一种情形。**"至少一个"看到就想到补集**，这是概率计算里最省力的经验法则之一。 – **一般公式**：m 个球、n 个箱，

$$\Pr[1\text{ 号箱为空}] = \left(\frac{n-1}{n}\right)^m = \left(1 - \frac{1}{n}\right)^m.$$

- **特例还原（重要）**：球与箱是比掷硬币、掷骰子更**一般**的模型：
- 掷 3 次公平硬币 $\cong$ $m = 3$ 个球、$n = 2$ 个箱（箱 = $\{H, T\}$）。
- 掷 2 枚公平骰子 $\cong$ $m = 2$ 个球、$n = 6$ 个箱（箱 = $\{1, \ldots, 6\}$）。
- n 个人的生日 $\cong$ $m = n$ 个球、$n = 365$ 个箱（见下）。
- **下游连接**：讲次 20 会用**期望的线性性**从球与箱模型推出"期望碰撞对数 $= \binom{m}{2}/n$""最大负载 $\approx \frac{\ln n}{\ln \ln n}$"等结论；讲次 23 会用 Chernoff 界证明"最大负载超过某阈值"的概率极小。**球与箱是整条随机算法分析链的起点。**
- **哈希应用的具体数字**：若用 $n = 10^6$ 个槽位存 $m = 1000$ 个键，期望碰撞对数 $= \binom{1000}{2}/10^6 = 499500/10^6 = 0.4995$（脚本验算 ✓）——即平均大约会发生半次碰撞。这个"$\binom{m}{2}/n$"的形式与生日悖论完全同源。

（3）生日悖论（Birthday Paradox）

- **问题背景**：一个 n 人的房间里，至少有两个人生日相同的概率是多少？直觉说"一年 365 天，得有一两百人才可能撞上"——但正确答案是 $n = 23$ 时就超过一半。这被称为"悖论"，不是因为逻辑矛盾，而是因为它**违背直觉**。
- **数学建模**：把每个人看成一个球，365 个日期看成 365 个箱；假设每个人的生日独立均匀地落在 365 天中（**忽略闰年与真实出生日期的不均匀性**，这是必要的建模简化）。样本空间 $\Omega =$ n 个生日的序列，$|\Omega| = 365^n$，均匀分布。
- **变量设定**：设 $A =$「至少有一对人生日相同」，我们算它的补集 $\bar{A} =$「所有人的生日两两不同」。
- **数 $\bar{A}$**：第一个人的生日有 365 种，第二个必须与第一个不同，有 364 种，第三个有 363 种，……，第 n 个人有 $365 - n + 1$ 种。这是讲次 14 的**无放回有序抽样**（第一法则）：

$$|\bar{A}| = 365 \times 364 \times \cdots \times (365 - n + 1) = \frac{365!}{(365-n)!}.$$

- **概率**：

$$\Pr[\bar{A}] = \frac{365 \times 364 \times \cdots \times (365 - n + 1)}{365^n}, \qquad \Pr[A] = 1 - \frac{365 \times 364 \times \cdots \times (365 - n + 1)}{365^n}.$$

- **数值表（脚本验算）**：

n（人数）	$\Pr[\bar{A}]$（全不同）	$\Pr[A]$（至少一对相同）
10	0.883052	0.116948

（人数）	（全不同）	（至少一对相同）
20	0.588562	0.411438
22	0.524305	**0.475695**
23	0.492703	**0.507297**
30	0.293684	0.706316
40	0.108768	0.891232
50	0.029626	0.970374
57	0.009878	**0.990122**
60	0.005877	0.994123
70	0.000840	0.999160

阈值结论：$n=22$ 时 $\Pr[A]=0.4757<1/2$，$n=23$ 时 $\Pr[A]=0.5073>1/2$。所以 23 **是使"至少一对同生日"概率超过一半的最小人数**（脚本逐 n 搜索验证：最小的 n 为 23 ✓）。$n=57$ 时已超过 99%，$n=70$ 时超过 99.9%。 – **为什么"需要 183 人"的直觉是错的？** 直觉的推理是："每个人的生日和我的相同概率是 $1/365$，所以要有约 $365/2=183$ 人，才有超过一半的机会找到'和我同生日'的人。" 这个推理本身**没有错**，但它回答的是**另一个问题**——"有没有人和**我**同生日"。而生日悖论问的是"**任意两个人**之间有没有同生日"，比较的是**所有** $\binom{n}{2}$ **对**，而不是"我与其余 $n-1$ 人"这 $n-1$ 对。 – 当 $n=23$ 时，对数达到 $\binom{23}{2}=\frac{23\times22}{2}=253$ 对（脚本验算 ✓），远大于 $23-1=22$ 对。这 253 对中只要有**一对**撞上就够了，而每对撞上的概率约 $1/365$，期望碰撞对数 $=253/365\approx0.693$（脚本验算 ✓）。0.693 这个量级恰好解释了"约一半"的概率（虽然碰撞数的期望与"至少一次"的概率不是同一个量，但数量级上给出了正确直觉；精确关系是 $\Pr[A]\approx1-e^{-\binom{n}{2}/365}$，代入 $\binom{23}{2}/365=0.693$ 得 $1-e^{-0.693}=1-0.5=0.5$，与精确值 0.5073 相当接近）。 – 反过来，"找和我同生日的人"需要 $n\approx253$ 人（因为要看 $n-1$ 对，每对 $1/365$，需要 $n-1\approx365\ln2\approx253$）——脚本验证：$n=183$ 时"至少一对相同"的概率已经是 1.00000000（精确到 8 位），而"有人和我同生日"在 $n=183$ 时只有 $1-(364/365)^{182}\approx0.3931$；脚本逐 n 搜索得到"有人和我同生日"概率首次超过 $1/2$ 的 n 是 254（$n=253$ 时为 0.4991），而 $365\ln2\approx252.999$ 给出的渐近估计与此吻合。**两个问题的答案相差一个数量级（23 对 254），这正是"悖论"的来源。** – **下游连接**：生日悖论是**哈希碰撞**与**密码学攻击**的基础。若一个哈希函数输出 b 比特（2^b 个可能值），那么只需约 $2^{b/2}$ 次随机取样就有约 50% 的概率找到碰撞（**生日攻击**）——这解释了为什么哈希摘要必须取 256 比特而不只是 128 比特来抵御碰撞攻击。

（4）蒙提霍尔问题（Monty Hall Problem）

- **问题背景**：1970 年代一档游戏节目里，主持人 Monty Hall（Note 13 把他的助手称为 Carol）向参赛者展示三扇门，其中一扇门后是汽车，另两扇门后是山羊。参赛者先选一扇门（不打开）。随后 Carol **知道奖品在哪**，因此**总能**打开另一扇后面是山羊的门。此时参赛者可以坚持原选择，或换到剩下那扇未开的门。问：换门是否更有利？
- **直觉答案（错的）**："只剩两扇门，奖品在其中的概率各是 $1/2$，所以换不换都一样。"——**这是本讲最著名的直觉陷阱。**
- **正确的概率建模**：把游戏到"参赛者做最终决定"为止的结果描述成三元组 (i,j,k)，其中 $i,j,k\in\{1,2,3\}$ 分别表示：奖品的门 i、参赛者初选的门 j、Carol 打开的门 k。**不是所有三元组都可能**：例如 $(1,2,1)$ 不可能，因为 Carol **从不**打开奖品门。
- **三条建模假设**（必须明确写出，否则概率无定义）：
- 奖品**等可能**地在三扇门后：$\Pr[i=d]=1/3$，$d=1,2,3$；
- 参赛者初始**等可能**地选任意一扇门：$\Pr[j=d]=1/3$；
- 若参赛者**恰好**选中了奖品门（$i=j$），此时 Carol 有两扇山羊门可选，她**等可能**地选其中一扇（注：Note 13 指出，实际上无论 Carol 怎么选，最终结论不变）。
- **样本点计数**：以 i 为第一层、j 为第二层、k 由 (i,j) 决定为第三层的树结构。当 $i\neq j$ 时，山羊门只有一扇可开，Carol **无选择**；当 $i=j$ 时，Carol 有 2 个选择。因此
- **类型 I（$i\neq j$）**：$3\times2=6$ 个样本点，每个概率 $\frac{1}{3}\times\frac{1}{3}\times1=\frac{1}{9}$；
- **类型 II（$i=j$）**：$3\times1\times2=6$ 个样本点，每个概率 $\frac{1}{3}\times\frac{1}{3}\times\frac{1}{2}=\frac{1}{18}$。
- 共 12 个样本点（脚本枚举验证：恰好 12 个 ✓）。
- **归一性自检**：$6\times\frac{1}{9}+6\times\frac{1}{18}=\frac{6}{9}+\frac{6}{18}=\frac{2}{3}+\frac{1}{3}=1$ ✓（脚本求和的浮点结果为 1.0000000000000002，即 1 ✓）。**这个自检很重要**：如果概率没配好，和不会是 1，必须回头检查假设。
- **换门策略的胜率**：设 $W=$「参赛者换门后获胜」。换门后，参赛者最终选择的是"既不是 j 也不是 k 的那扇门"。分析：
- 若 $i\neq j$（类型 I），Carol 被迫打开唯一那扇山羊门 k，于是"第三扇门"就是奖品门 i。换门**必胜**。
- 若 $i=j$（类型 II），Carol 打开一扇山羊门，换门后必然换到另一扇山羊门。换门**必败**。
- 因此 W 恰由全部 6 个类型 I 样本点组成：

$$\Pr[W]=6\times\frac{1}{9}=\frac{6}{9}=\frac{2}{3}.$$

（脚本枚举：换门获胜的 6 个样本点总概率 $= 0.6666667$ ✓；200 万次蒙特卡洛模拟的换门胜率 $= 0.66669$ ✓）

- **坚持策略的胜率**：坚持意味着最终结果就是初选 j，而 $\Pr[j=i]=1/3$，故

$$\Pr[\text{坚持获胜}]=\frac{1}{3}.$$

（脚本枚举：坚持获胜的 6 个类型 II 样本点总概率 $= 0.3333333$ ✓） – **结论**：$2/3 > 1/3$，**换门把胜率翻倍**（从 $1/3$ 提高到 $2/3$）。 – **直观论证（Note 13 的图景）**：参赛者初选时有 $1/3$ 的机会选对，因此**另外两扇门合计**有 $2/3$ 的机会藏着奖品。Carol 打开一扇山羊门，只是把"另外两扇门"这个 $2/3$ 的**整体概率**全部转移到了剩下的那一扇上（因为她**绝不会**打开奖品门，所以她开的那扇门概率必定为 0）。所以： – 初选门：仍然 $1/3$； – Carol 打开的门：0； – 剩下那扇：$1 - 1/3 - 0 = 2/3$。 – **常见错误答案的剖析**： – **错误 1："只剩两扇门，所以各 $1/2$。"** 这假设了"两扇剩余门等可能"，但 Carol 的开门**不是随机的**——她**故意**避开奖品门。这个"有信息的选择"破坏了对称性。**等价地**：如果把三扇门换成 100 扇门，参赛者选 1 扇，Carol 打开 98 扇山羊门，只留下 1 扇，此时"换门胜率 $99/100$"是显然的；$1/2$ 的说法在 100 门版本下荒谬到无法辩护，这正是它在 3 门版本下不易被察觉的原因：**差异被小数字掩盖了**。 – **错误 2："Carol 的开门改变了所有门的概率。"** 不，**她只改变了**未选门中那扇"被留下来的门"的概率。初选门是 $1/3$ 的概率在她开门后**不变**，因为她的行为受规则约束（绝不会碰初选门）。 – **错误 3："既然 Carol 总是能开门，她开门没有提供任何信息。"** 恰恰相反：她**能**开门这件事在所有情况下都成立，但她**开了哪一扇**携带着信息。若奖品在门 1 而参赛者选了门 2，Carol **只能**开门 3；这个约束本身就是信号。 – **一个可复制的模拟脚本（伪代码）**：

```
wins_switch = 0 重复 N 次: prize = random({1,2,3}) pick = random({1,2,3}) goats = {1,2,3} \ {prize, pick} # Carol 可开的门 open = random(goats) # 若 pick==prize 则 goats 有 2 个元素 switch = the unique door in {1,2,3} \ {pick, open} if switch == prize: wins_switch += 1 输出 wins_switch / N # 期望 ≈ 2/3
```

本讲用 $N = 2{,}000{,}000$ 跑出的结果是 0.66669，与理论值 $2/3$ 吻合 ✓。

与其他讲次的关联

- **讲次 1（命题逻辑）**：事件运算与命题逻辑**结构完全同构**——并 = 或、交 = 且、补 = 非、$\emptyset$ = 恒假、Ω = 恒真。讲次 1 的 De Morgan 定律 $\overline{A \cup B} = \bar{A} \cap \bar{B}$ 在事件语言里原样成立。概率计算的很多错误（比如 union bound 的误用）本质上是命题逻辑的推理错误。
- **讲次 2（证明技巧 II）与讲次 3（归纳法）**：union bound 的证明是对事件个数 n 的**归纳**；(d) 并的法则的证明是"分情形 + 可加性"，正是讲次 2 分情形证明的概率版本；本讲五条性质的统一模板（拆成互斥碎块 → 可加性 → 非负性）是讲次 2"逆否/反证/分情形"工具箱在概率语境的移植。
- **讲次 4–6（模运算、Euclid/FLT/CRT、RSA）**：Note 13 开头列举的典型概率陈述之一"随机化素性测试对合数输入错误输出 prime 的概率至多一万亿分之一"，是 RSA 密钥生成（讲次 6）必须依赖的保证。要界定这种失败概率，第一步就是把算法的随机位建模成有限样本空间并**计数坏随机串**——本讲的框架 + 讲次 14 的计数工具 + union bound 三者合用。
- **讲次 7–8（多项式、秘密共享与纠错码）**：Shamir 秘密共享（讲次 8）说"少于 k 个份额不泄露任何信息"，其陈述本身就是概率陈述（对所有可能的秘密取值，观察到的份额分布相同）；Berlekamp–Welch 译码的正确性需要"坏点位置恰好被插值条件排除"这类事件概率为 0 的论证。多项式插值的唯一性（讲次 7）是把"样本空间"缩小到"次数 $< k$ 的多项式"的依据。
- **讲次 9–11（图论、稳定匹配）**：本讲末端的可区分性建模（球与箱的"球与箱都可区分"）与讲次 11 中"配对方案的计数"同源；随机图（讲次 10 提及的 $G_{n,p}$ 模型）的样本空间正是"全部 $2^{\binom{n}{2}}$ 个图的集合"，其大小来自讲次 14 的组合数。
- **讲次 12–13（可数性、可计算性）**：讲次 13 用**对角化**证明停机问题不可判定，本讲则第一次转向"不确定性的定量推理"，是课程从"必然"到"或然"的分水岭。可数可加性中的"可数"一词直接沿用讲次 12 的可数集概念。
- **讲次 14（计数）**：本讲的**直接上游**。样本空间的大小 $2^n, 6^2, \binom{52}{5}, n^m, 365^n$ 全部由讲次 14 的第一法则给出；事件的大小（恰好 k 个正面、葫芦的数目、生日两两不同的数目）全部由排列/组合/乘法法则给出。Note 13 明确说"随机实验的可能结果恰好就是上一讲数过的那些对象"，本讲的四格表（有放回/无放回 × 有序/无序）直接沿用。
- **讲次 16（组合证明）**：定理 15.3 用概率方法重证 Pascal 恒等式，是"概率证明组合恒等式"的第一个例子，讲次 16 会系统化"双计数 / 双射 / 概率"三种证明路线。
- **讲次 17–18（条件概率与贝叶斯、独立性与事件组合）**：本讲中"Carol 知道奖品在哪"这一**信息**在本讲尚未被形式化；讲次 17 会用条件概率 $\Pr[A \mid B]$ 把"在已知 Carol 开了门 3 的条件下，换门获胜的概率"精确写成 $2/3$，并彻底解释"信息如何更新概率"。本讲中"把每步概率相乘"这一操作（Note 13 两次强调"未经证明"）将在讲次 18 由**独立性**给出严格依据。
- **讲次 19–20（随机变量、期望的线性性）**：生日悖论中"期望碰撞对数 $= \binom{n}{2}/365$"、哈希中"期望碰撞对数 $= \binom{m}{2}/n$"将在讲次 20 用期望的线性性一行推出；本讲讲过的"平均有多少学生拿到自己作业"（讲次 14 的错排问题）也将在讲次 20 得到答案 1。
- **讲次 23（集中不等式）**:union bound 是本讲留给讲次 23 的**最重要遗产**——它不需要独立性、不需要互斥性，因此可以用来把"每个坏事件的概率都很小"聚合成"至少一个坏事件发生的概率很小"，这是 Chernoff 界与随机算法分析的起点。

关键要点

1. **概率计算四步流程（务必背下来）**：① 样本空间是什么（实验 + 全部可能结果）？② 每个样本点的概率是多少？③ 关心的事件是哪个子集？④ 把事件内样本点的概率**逐点相加**。Note 13 结尾特别指出：**遇到任何概率问题都回到这四步**，连专业研究者忘记它时也会写出错误的"证明"。
2. **概率公理三条**：非负性 $\Pr[A] \geq 0$；归一性 $\Pr[\Omega] = 1$；可数可加性（两两不相交时 $\Pr[\bigcup_i A_i] = \sum_i \Pr[A_i]$）。本讲所有性质都是这三条的推论，其中**可数可加性是唯一"强"公理**。
3. **拆互斥碎块是万能模板**：$\Pr[\emptyset] = 0$、补集法则 $\Pr[\bar{A}] = 1 - \Pr[A]$、单调性、并的法则 $\Pr[A \cup B] = \Pr[A] + \Pr[B] - \Pr[A \cap B]$ 全部由"把目标集合拆成互斥部分 + 可加性 + 非负性"推出。**看到"至少一个"就想到补集。**
4. **$\Pr[A] = |A|/|\Omega|$ 只对均匀（等概率）样本空间成立**。这是本讲最高频的陷阱。"正面个数 $0/1/2$ 各 $1/3$"是错的，正确值是 $1/4, 1/2, 1/4$——因为"1 个正面"含两个样本点 HT 与 TH。
5. **直接相加需要互斥许可**：$\Pr[A \cup B] = \Pr[A] + \Pr[B]$ **当且仅当** $A \cap B = \emptyset$。一般不互斥时要用并的法则减掉 $\Pr[A \cap B]$；连交集都算不出来时，用 union bound $\Pr[\bigcup_i A_i] \leq \sum_i \Pr[A_i]$（无需互斥、无需独立）。
6. **二项概率** $\Pr[\text{恰好 } r \text{ 个正面}] = \binom{n}{r} p^r (1-p)^{n-r}$：$\binom{n}{r}$ 来自讲次 14 的"选 r 个位置放正面"，$p^r(1-p)^{n-r}$ 是单个序列的概率（与位置无关），两者相乘是因为这 $\binom{n}{r}$ 个序列**等概率且互斥**。整个分布之和为 1（二项式定理）。

7. **经典数值（全部脚本验算）**：$\binom{52}{5}=2{,}598{,}960$；$\Pr[\text{葫芦}]=3744/2598960\approx 0.001441$；$\Pr[\text{同花}]\approx 0.001981$；生日悖论 $n=23$ 时 $\Pr\approx 0.5073>1/2$（$n=22$ 时 $0.4757<1/2$），$n=57$ 时 >0.99；球与箱（$m=20,n=10$）$\Pr[1\text{ 号箱空}]=0.9^{20}\approx 0.1216$；蒙提霍尔换门胜率 $=2/3$、坚持 $=1/3$。

常见误区与注意事项

1. **把非均匀样本空间当均匀用（最经典的陷阱）**：用"正面个数"$\{0,1,2\}$ 作样本空间并断言每个概率 $1/3$。**判断方法**：问自己"这三个结果真的等可能吗？"、"能不能把每个结果拆成若干'细结果'，各细结果的个数是否一样多？"。0 与 2 各含 1 个细结果，1 含 2 个——**不齐，所以不均匀**。
2. **不互斥却直接相加**：$\Pr[A\cup B]=\Pr[A]+\Pr[B]$ 只对 $A\cap B=\emptyset$ 成立。骰子例子：$A=$「和 ≥ 10」（$\Pr=6/36$）与 $B=$「至少一个 6」（$\Pr=11/36$）**不互斥**（交集 5 个样本点），直接相加得 $17/36\approx 0.472$，正确值是 $1/3\approx 0.333$。**这类错误在 CS70 考试中是最高频失分点之一**，且与讲次 23 的 union bound 极易混淆：union bound 是**不等式**（上界），不是等式。
3. **把 $|A|/|\Omega|$ 的分子分母用不同计数约定**：分母用无序手牌数 $\binom{52}{5}$，分子却按有序序列数葫芦，结果差 $5!=120$ 倍。**统一约定**：要么全无序、要么全有序。
4. **把"至少一个"硬算而不取补集**：$\Pr[\text{至少一个 }6]$ 若按"恰好 1 个、恰好 2 个、……"硬算，要处理 m 种情形；取补集只需数"一个都没有"这一种。球与箱里 $\Pr[1\text{ 号箱至少一个球}]=1-0.9^{20}$ 是最干净的写法。
5. **忘记明确假设，导致概率无定义**：Note 13 强调，概率陈述必须绑定一个概率空间。"蒙提霍尔"必须写明三条假设（奖品均匀、初选均匀、Carol 在有两个选择时均匀）；若把第 3 条改成"Carol 偏爱开编号小的门"，**换门的总胜率仍然是 $2/3$**（Note 13 已注明），但每个具体样本点的概率会变——这说明**不是所有假设都影响最终答案，但所有假设都必须先写清楚**才能算。同理，"2030 年前有 30% 概率发生 8.0 级地震"若不指明概率空间，就"几乎是空洞的"。
6. **混淆"独立"与"互斥"**：本讲还用不到独立性（那是讲次 18 的内容），但必须避免把两者搞混。**互斥**是"不能同时发生"（$A\cap B=\emptyset$，此时 $\Pr[A\cap B]=0$）；**独立**是"一个发生不改变另一个的概率"（$\Pr[A\cap B]=\Pr[A]\Pr[B]$）。两个正概率的互斥事件**绝不独立**（因为 $\Pr[A]\Pr[B]>0=\Pr[A\cap B]$）。Note 13 两次强调"我们这里只是把概率相乘，这**并不总是**允许的"——正是为了避免读者把"独立才能相乘"误当成普遍真理。
7. **把"粗化样本空间"当作等价变形**：从 $\{HH,HT,TH,TT\}$ 粗化到 $\{0,1,2\}$ **改变**了概率结构（均匀 → 不均匀）。除非每个粗块含相同的细结果数，否则不能对粗化空间用 $|A|/|\Omega|$。这与讲次 14"除法法则要求每个纤维等大"是**同一个定理的两种表述**。

思考题（带答案）

Q1.（计算题） 掷一枚均匀的六面骰子 3 次（每次独立）。(a) 三次点数**全不相同**的概率是多少？(b) 三次点数中**至少有两个相同**的概率是多少？(c) 三次点数之和**恰好为 6** 的概率是多少？

▸ **答案**

样本空间 $\Omega=\{(d_1,d_2,d_3):1\leq d_i\leq 6\}$，$|\Omega|=6^3=216$，**均匀分布**。

(a) 全不相同：由讲次 14 的无放回有序抽样（第一法则），有利结果数 $=6\times 5\times 4=120$。

$$\Pr[\text{全不同}]=\frac{120}{216}=\frac{5}{9}\approx 0.5556.$$

（这是生日悖论在 $n=3$、365 天的迷你版本：$\frac{6\cdot 5\cdot 4}{6^3}$。）

(b) 至少两个相同：用**补集法则**（定理 15.1(b)），事件是 (a) 的补集（三次点数中"至少两个相同" $\Longleftrightarrow$ "不全不同"）：

$$\Pr[\text{至少两个相同}]=1-\frac{5}{9}=\frac{4}{9}\approx 0.4444.$$

(c) 和恰为 6：先数有利结果。设三次点数为 (d_1,d_2,d_3)，$d_i\geq 1$，$d_1+d_2+d_3=6$。令 $x_i=d_i-1\geq 0$，则 $x_1+x_2+x_3=3$。由**星棒法**（讲次 14 定理 14.5），非负解数为

$$\binom{3+3-1}{3-1}=\binom{5}{2}=10.$$

但要注意 $d_i\leq 6$ 的上界约束在这里**自动满足**（因为 $d_1+d_2+d_3=6$ 且各 $d_i\geq 1$，所以每个 $d_i\leq 6-1-1=4\leq 6$），无需容斥修正。于是

$$\Pr[\text{和为 }6]=\frac{10}{216}=\frac{5}{108}\approx 0.0463.$$

手动核对这 10 个解：按"三个数的多重集"分类：$\{1,1,4\}$ 有 $\frac{3!}{2!1!}=3$ 个排列、$\{1,2,3\}$ 有 $3!=6$ 个排列、$\{2,2,2\}$ 有 $\frac{3!}{3!}=1$ 个排列。共 $3+6+1=10$ ✓，与星棒法一致。

一个必须澄清的要点：星棒法数的是**有序解**——方程 $x_1+x_2+x_3=3$ 中三个变量是**带标签**的（x_1 对应第一次掷骰，x_2 对应第二次……），所以 $(x_1,x_2,x_3)=(0,0,3)$ 与 $(3,0,0)$ 是**两个不同的解**，它们对应 $(d_1,d_2,d_3)=(1,1,4)$ 与 $(4,1,1)$ 两种不同的掷骰结果。这正是本题需要的：**骰子有先后顺序，所以掷骰结果是有序三元组**。相反，若问的是"三次点数的**多重集**有多少种满足和为 6"，答案只是 3（$\{1,1,4\},\{1,2,3\},\{2,2,2\}$）——**两者相差 7，又是上一讲反复强调的"有序 vs 无序"之别**。做题时必须先确认问题问的是哪一种。

验算：脚本三重循环枚举 216 个结果，分别计数"三个数全不同"、"至少两个相同"、"和为 6"三种情况，得 120、96、10，与上述完全一致（$120/216=5/9$，$96/216=4/9$，$10/216=5/108$ ✓）。注意 $120+96=216$ ✓，恰好互补，与 (a)(b) 互为补集的结论一致。

Q2.（概念理解题） 某"证明"如下，请指出错误所在并给出正确结论。

命题：掷两枚公平硬币，正面个数为 0、1、2 的三种情况完全对称，故每种的概率都是 $1/3$。

推论：因此"至少出现一个正面"的概率是 $2/3$。

▸ 答案

错误 1（根本错误）：三个结果不等可能，不能用 $|A|/|\Omega|$。 公式 $\Pr[A] = |A|/|\Omega|$ 的前提是样本空间**均匀**（每个样本点等概率）。把样本空间取成"正面个数" $\Omega' = \{0,1,2\}$ 时，三个样本点**并非等概率**。

错误 2："完全对称"的说法混淆了两个不同的对称性。 真正对称的是"硬币的正反面"（H 与 T 互换），而不是"正面个数"。在细样本空间 $\Omega = \{HH, HT, TH, TT\}$ 中，H 与 T 的互换给出双射 $HH \leftrightarrow TT$、$HT \leftrightarrow TH$，因此 $\Pr[0] = \Pr[2]$。但它**不说** $\Pr[1]$ 等于 $\Pr[0]$——因为 $HT \leftrightarrow TH$ 把"1 个正面"这个块**映到它自己**（块内互换），不涉及 0 或 2。

正确计算：用细样本空间 $\Omega = \{HH, HT, TH, TT\}$，$|\Omega| = 4$，均匀（每个 $1/4$）。– $\Pr[0] = |\{TT\}|/4 = 1/4$； – $\Pr[1] = |\{HT, TH\}|/4 = 2/4 = 1/2$； – $\Pr[2] = |\{HH\}|/4 = 1/4$。– 自检：$1/4 + 1/2 + 1/4 = 1$ ✓（而 $1/3 \times 3 = 1$ 也"自检通过"，这正是这个错误难以察觉的原因——**归一性不能作为正确性的检验**，很多错误分布也满足归一性）。

推论的正确答案：「至少一个正面」$= \{HT, TH, HH\}$，$\Pr = 3/4$。**不是 $2/3$。**

推广（n 枚硬币）：$\Pr[\text{恰好 } k \text{ 个正面}] = \binom{n}{k}/2^n$。$n = 2$ 时给出 $1/4, 1/2, 1/4$；若 $n = 3$，则是 $1/8, 3/8, 3/8, 1/8$——**分布形状随 n 变化**（$n = 4$ 为 $1/16, 4/16, 6/16, 4/16, 1/16$）。所以"正面个数"的三种（或 $n+1$ 种）结果**从来不**是等可能的（只有 $n = 1$ 时两个结果等可能），这一点必须牢记。脚本验算：$n = 4$ 时 $\sum_k \binom{4}{k}/16 = (1+4+6+4+1)/16 = 1$ ✓。

要点：看到"看起来对称所以等可能"的论证，**立刻问"对称性到底把哪块映到哪块"**。对称性只能推出"被对称操作连起来的两个块概率相等"，不能推出"所有块概率相等"。

Q3.（证明题） 用概率方法证明：对 $n \geq 1$，

$$\sum_{k=0}^{n} \binom{n}{k} = 2^n.$$

▸ 答案

证明策略：同一个事件用两种方法算概率（双计数 / 双计算）。选这个策略的理由：左边是"按子集大小分类计数"，右边是"每位独立二选一计数"，把它们绑在一起的最自然桥梁就是"掷 n 枚公平硬币，并研究事件 Ω（必然事件）"。

逐步推导：

- 设掷 n 枚公平硬币。样本空间 Ω 是全体 2^n 个长度 n 的 H/T 串，均匀分布，每个样本点概率 $1/2^n$。
- **计算方式一（按 k 分类，即左边）**：把 Ω 按"正面个数 k"分成 $n+1$ 块 $E_k =$「恰好 k 个正面」，$k = 0, 1, \ldots, n$。这些块**两两不相交**且并起来是 Ω（任一串的正面个数唯一）。由可数可加性 + 归一性：

$$1 = \Pr[\Omega] = \sum_{k=0}^{n} \Pr[E_k].$$

由定理 15.2，$\Pr[E_k] = \binom{n}{k}/2^n$（均匀硬币 $p = 1/2$）。因此

$$1 = \sum_{k=0}^{n} \frac{\binom{n}{k}}{2^n} = \frac{1}{2^n} \sum_{k=0}^{n} \binom{n}{k}.$$

- **两边同乘 2^n**：$\sum_{k=0}^{n} \binom{n}{k} = 2^n$。■
- **自检（$n = 4$）**：$\binom{4}{0} + \binom{4}{1} + \binom{4}{2} + \binom{4}{3} + \binom{4}{4} = 1 + 4 + 6 + 4 + 1 = 16 = 2^4$ ✓（脚本验算）。

另一条纯粹的计数路线（双射）：$\binom{n}{k}$ 数的是 n 元集合 S 的 k 元子集，左边数的是**全部子集**（按大小分类求和）；右边的 2^n 数的是 n 比特的 0/1 串。映射 $T \mapsto (b_1, \ldots, b_n)$（$b_j = 1 \iff j \in T$）是双射（第零法则，讲次 14）。故两边相等。

这个练习的意义：它示范了讲次 14 提到的"**同一个故事讲两遍**"的证明风格在概率语境下的样子——**"必然事件概率为 1"就是一座免费的桥**，只要能用两种方式把 $\Pr[\Omega]$ 展开，就得到一条恒等式。同类技巧还能推出 $\sum_k k\binom{n}{k} = n2^{n-1}$（用 $\mathbb{E}[\text{正面个数}]$ 的两种算法，讲次 20）与 $\sum_k \binom{n}{k}^2 = \binom{2n}{n}$（讲次 16）。

Lecture 16: Combinatorial Proofs（组合证明）

概述

上一讲（L14 计数）教会我们**算数**：给一个具体场景，用第一法则（乘法原理）、第二法则（有序除以重复倍数）、容斥原理把答案算出来。本讲要反过来做一件更有意思的事：**证明关于计数的恒等式本身**。

组合证明（combinatorial proof）的核心主张是：一个等式之所以成立，往往不是因为代数运算恰好凑上了，而是因为**等式两边在数同一批东西**。我们可以数两次（double counting），也可以在两批东西之间架一座桥（bijection）。这种证明的价值在于它**不依赖任何代数技巧**——你不需要知道 $\sum_k \binom{n}{k}^2$ 怎么化简，只要找到一个能把两边都解释清楚的故事。

本讲在课程中的位置很关键：它是 L14 计数与 L15 概率公理的自然延续（"均匀样本空间下，概率 = 计数 / 总数"），同时又是 L17 条件概率与 L18 独立性、L19 随机变量的**论证工具**——二项分布的 $\binom{n}{k}p^k(1-p)^{n-k}$、Vandermonde 恒等式在联合分布中的反复出现，都要靠本讲的技巧来解释和推导。

核心概念的直观解释

组合证明（Combinatorial Proof） – **定义**：组合证明是指**不通过代数变形**，而是通过给出所计数量的一种或两种**组合解释（combinatorial interpretation）**，来建立恒等式 $L = R$ 的证明。形式上有两大范式：**双计数（double counting）**与**双射（bijection）**。 – **直观解释（"它是什么意思？"）**：代数证明像是在验算收据上的加法；组合证明则像是在讲一个故事，然后说"这个故事从两个角度听，得到两个不同的数字，但故事本身只有一个，所以两个数字必然相等"。可以把等式理解成一句**双关语**：左边是一种读法，右边是另一种读法，说的是同一件事。 – **具体示例**：$\binom{n}{k} = \binom{n}{n-k}$。代数上就是 $\frac{n!}{k!(n-k)!} = \frac{n!}{(n-k)!k!}$，两边长得一样，没什么可证。但组合解释是：**从 n 个人里选 k 个人去开会**，等价于**从 n 个人里选 $n-k$ 个人不去开会**。同一个"选择"用两种说法描述，因此两种说法的个数相等。

双计数（Double Counting / Counting in Two Ways） – **定义**：设 S 是某个有限集合。若能用两种互不相同的、各自无重无漏的方法分别数出 $|S|$，得到表达式 E_1 与 E_2，则必定有 $E_1 = E_2$。这类证明中，**两边数的是同一个集合 S**。 – **直观解释（"它是什么意思？"）**：想象一间教室，我们可以**按行数**（每行人数相加），也可以**按列数**（每列人数相加）。无论怎么数，教室里的人数是同一个人数。这就是"同一个量的两种记账方式"。 – **具体示例**：数矩阵中"1"的个数。若矩阵第 i 行有 r_i 个 1，第 j 列有 c_j 个 1，则 $\sum_i r_i = \sum_j c_j$。这个平凡的事实正是握手引理的骨架（见后文）。

双射（Bijection） – **定义**：函数 $f : A \to B$ 称为**双射（bijection）**，若它既**单射（injective，一对一）**（$a \neq a' \Rightarrow f(a) \neq f(a')$）又**满射（surjective，映上）**（$\forall b \in B, \exists a \in A, f(a) = b$）。此时 $|A| = |B|$。 – **直观解释（"它是什么意思？"）**：双射就是**完美配对**。假设有两个班的同学要结对写信，规则是"每人只写一封、每人只收一封"。如果这个规则能公平地执行完毕，两个班的人数必定相同。**单射**保证没有两个人写给同一个人（不会重复占用），**满射**保证没有人收不到信（不会漏掉）。少检查任何一条，结论都不成立。 – **具体示例**：把 $\{1,2,3\}$ 的**子集**与**长度为 3 的 0/1 串**配对：子集 $S \mapsto$ 向量 (x_1, x_2, x_3)，其中 $x_i = 1$ 当且仅当 $i \in S$。$\varnothing \leftrightarrow 000$，$\{1,3\} \leftrightarrow 101$。$8$ 个子集刚好配 8 个位串，因为 $2^3 = 8$。

"要数的对象"（The Objects Being Counted） – **定义**：组合证明的成败，几乎完全取决于你**把什么定义为被数的对象**。所谓对象可以是一个集合、一个有序对、一个带标记的配置，甚至是一个"过程"。 – **直观解释（"它是什么意思？"）**：这是组合证明最需要创造力、也最容易出错的一步。有时候恒等式右边看起来像一个莫名其妙的乘积 $n2^{n-1}$，直到你说出"我数的是**（子集，子集中的某个元素）**这样的 $n2^{n-1}$ 个对"，一切才豁然开朗。**对象定义错了，后面的论证再流畅也是错的。** – **具体示例**：恒等式 $\sum_{k=0}^{n} k\binom{n}{k} = n2^{n-1}$。如果试图把左边的 $k\binom{n}{k}$ 理解成"先选 k 个元素，再从里面选一个"，那么左边的对象是"（k 元子集，其中一个元素）"。右边 $n2^{n-1}$ 必须能被解释成同样的一批对——事实证明可以：先定那个特殊元素（n 种），再把剩下 $n-1$ 个元素任意决定是否加入（2^{n-1} 种）。**同一个对象集合，两条构造路径。**

均匀样本空间中的概率（Probability on a Uniform Sample Space） – **定义**：若样本空间 Ω 有限且每个样本点概率相同，则该概率空间称为**均匀的（uniform）**，此时对任意事件 A，$\Pr[A] = \dfrac{|A|}{|\Omega|}$。 – **直观解释（"它是什么意思？"）**：均匀空间里，"求概率"退化成了"数数再除一除"。这是 L15 反复强调的范式：**均匀 + 计数 = 概率**。组合证明在这里的用途是：它不用（也无法）算出 $|A|$ 的具体数字，却能**证明两个概率相等**，或把 $\Pr[A]$ 化成一个已知的计数表达式。 – **具体示例**：抛 n 枚公平硬币，恰好 r 个正面。Ω 有 2^n 个位串，每个概率 2^{-n}；事件"恰有 r 个正面"就是"位串中恰有 r 个 1"的集合，其大小是 $\binom{n}{r}$。所以 $\Pr[\text{恰 } r \text{ 个正面}] = \binom{n}{r}/2^n$。这个推导的**全部工作在于计数，而不在于概率论**。

组合恒等式（Combinatorial Identity） – **定义**：形如"两个含 $\binom{\cdot}{\cdot}$ 的表达式恒相等"的命题，如 $\sum_k \binom{n}{k} = 2^n$、$\binom{n}{k} = \binom{n-1}{k-1} + \binom{n-1}{k}$。 – **直观解释（"它是什么意思？"）**：每个恒等式背后都藏着一个**关于集合的等式**。本讲的核心哲学可以浓缩成一句话：

> **等式两边的差 = 两个集合的差。**

也就是说，若 $L = R$，则必定存在集合 S_L, S_R 使 $L = |S_L|, R = |S_R|$，且 $S_L = S_R$（双计数情形）或 $|S_L| = |S_R|$（双射情形）。找不到这两个集合，就没有组合证明。 – **具体示例**：$\sum_{k=0}^{n} \binom{n}{k} = 2^n$ 中，左边的集合是"全体子集按大小分组的并"，右边的集合是"全体 n 位 0/1 串"，二者通过"子集 ↔ 特征向量"完美配对。

完整证明与推导（核心）

定理 16.1（对称性 / Symmetry）： 对任意整数 $0 \le k \le n$，

$$\binom{n}{k} = \binom{n}{n-k}.$$

证明策略：**双射证明**。目标是建立从「n 元集合的 k 元子集全体」到「n 元集合的 $(n-k)$ 元子集全体」的一个显式双射。最自然的候选是**取补集（complementation）**。之所以选这个策略，是因为代数证明在这里毫无信息量（两边写开后字面相同），而双射可以顺便告诉我们"为什么"。

逐步推导： 1. 设 S 是任意一个 n 元集合，令 $\mathcal{A} = \{X \subseteq S : |X| = k\}$，$\mathcal{B} = \{Y \subseteq S : |Y| = n-k\}$。由 L14 的定义，$|\mathcal{A}| = \binom{n}{k}$，$|\mathcal{B}| = \binom{n}{n-k}$。我们只需证明 $|\mathcal{A}| = |\mathcal{B}|$。 2. 定义映射 $f : \mathcal{A} \to \mathcal{B}$ 为 $f(X) = S \setminus X$（**取补集**）。 3. **验证 f 确实落在 $\mathcal{B}$ 中**：若 $|X| = k$ 且 $|S| = n$，则 $|S \setminus X| = n - k$，故 $f(X) \in \mathcal{B}$。映射良定义。 4. **验证 f 单射**：设 $f(X_1) = f(X_2)$，即 $S \setminus X_1 = S \setminus X_2$。对两边同时在 S 中取补集，由"补集的补集是自身"（$S \setminus (S \setminus X) = X$）得 $X_1 = X_2$。故 f 单射。 5. **验证 f 满射**：任取 $Y \in \mathcal{B}$，取 $X = S \setminus Y$。因为 $|Y| = n - k$，所以 $|X| = k$，即 $X \in \mathcal{A}$；且 $f(X) = S \setminus (S \setminus Y) = Y$。故 f 满射。 6. 由 4、5，f 是双射，于是 $|\mathcal{A}| = |\mathcal{B}|$，即 $\binom{n}{k} = \binom{n}{n-k}$。■

【证明机制解说】：这个证明的"灵光一现"是把"选 k 个人"**重新描述**为"把 $n-k$ 个人留在外面"。计数上这两种描述给出不同的表达式，但描述的是同一个选择行为。注意单射的证明用到了一个隐藏的代数事实：**取补操作是自逆的（an involution）**，即 $f \circ f = \mathrm{id}$。凡是一个自逆的映射，必然是双射——这是组合证明中一个可反复使用的"快捷通道"。以后遇到 $f^{-1} = f$ 的情形，单射与满射可以一次证完。

反例（如果适用）：若把双射改成"从 X 中去掉最小元素"，即 $g(X) = X \setminus \{\min X\}$，映射 $\mathcal{A} \to \mathcal{B}$ 就不成立。例如 $n = 3, k = 2$：$\mathcal{A} = \{\{1,2\},\{1,3\},\{2,3\}\}$，$g$ 的像分别是 $\{2\},\{3\},\{3\}$。像集只有 2 个元素，而定义域有 3 个元素，**g 不是单射**，更不是满射（$\{1\}$ 不在像中）。这说明"我构造了一个映射"离"我构造了一个双射"还差着单射与满射两步验证。

定理 16.2（Pascal 法则 / Pascal's Rule）： 对任意 $1 \le k \le n-1$，

$$\binom{n}{k} = \binom{n-1}{k-1} + \binom{n-1}{k}.$$

证明策略：**双计数**。左边直接数「n 元集合的 k 元子集」。右边则**按某个特定元素是否被选中来分类**，把同一批子集拆成两类分别数。之所以选双计数而非双射，是因为等式右边是"和"的形式——**和式天然对应于分类（分情形）**，这是判断该用哪种范式的一条经验法则。

逐步推导： 1. 设 S 是 n 元集合，特别地固定一个元素 $a \in S$。令 $\mathcal{A} = \{X \subseteq S : |X| = k\}$，则 $|\mathcal{A}| = \binom{n}{k}$，这就是等式的左边。 2. **按 a 是否属于 X 分类**。这两类互不相交（a 要么在 X 里要么不在），且合起来覆盖全部 $\mathcal{A}$（划分）。因此

$$|\mathcal{A}| = |\{X \in \mathcal{A} : a \in X\}| + |\{X \in \mathcal{A} : a \notin X\}|.$$

1. **第一类（含 a）**：X 含有 a，还需要从 $S \setminus \{a\}$ 这个 $n-1$ 元集合中再选 $k-1$ 个元素。由 L14 第二法则，数目为 $\binom{n-1}{k-1}$。
2. **第二类（不含 a）**：X 不含 a，故 X 的 k 个元素全部取自 $S \setminus \{a\}$。数目为 $\binom{n-1}{k}$。
3. 相加即得 $\binom{n}{k} = \binom{n-1}{k-1} + \binom{n-1}{k}$。$\blacksquare$

【证明机制解说】：Pascal 法则就是**杨辉三角（Pascal's triangle）**的生成规则：每个数等于它左肩与右肩两数之和。组合证明揭示了这条规则的"物理意义"——它说的是"**任何一次选择，都可以按'某个特定对象是否入选'剖成两半**"。同一技巧可以递归使用，就得到了二项式系数的全部递推结构。注意这个证明**必须避免**用代数展开（$\frac{(n-1)!}{(k-1)!(n-k)!} + \frac{(n-1)!}{k!(n-k-1)!} = \cdots$），那样做虽然正确，却丢掉了本讲想让你掌握的思想。

反例（如果适用）：分类必须是**划分**。若把"X 含 a"与"X 含 b"（$b \neq a$）当作两类，则它们会重叠（X 可以同时含 a, b），相加就重复计数了。正确的划分只能靠"是/否"这样的二分。

定理 16.3（子集总数）： 对任意 $n \geq 0$，

$$\sum_{k=0}^{n} \binom{n}{k} = 2^n.$$

证明策略：先用**双计数**给出核心解释，再顺带给出**双射**视角（子集 ↔ 0/1 串）。这里要特别注意：这个恒等式也可以由二项式定理取 $a = b = 1$ 秒得（见下文定理 16.6），但**代数捷径不等于组合解释**——本定理的价值恰在于把 2^n 从一个"乘出来的数"变成"数出来的数"。

逐步推导： 1. **左边在数什么**：设 S 为 n 元集合。$\binom{n}{k}$ 是 S 的 k 元子集个数。这些子集按大小 $k = 0, 1, \ldots, n$ **分类**后相加，恰好数出 S 的**全体子集（任意大小）**。记 $\mathcal{P}(S) = \{X : X \subseteq S\}$，则

$$\sum_{k=0}^{n} \binom{n}{k} = |\mathcal{P}(S)|.$$

1. **右边在数什么**：构造映射 $\varphi : \mathcal{P}(S) \to \{0,1\}^n$。先把 S 的元素任意排成 $s_1, \ldots, s_n$，定义

$$\varphi(X) = (x_1, \ldots, x_n), \quad x_i = \begin{cases} 1, & s_i \in X, \\ 0, & s_i \notin X. \end{cases}$$

称为 X 的**特征向量（characteristic vector / indicator vector）**。 3. **φ 单射**：假设 $\varphi(X) = \varphi(X')$。对每个 i，$s_i \in X \iff x_i = 1 \iff s_i \in X'$。故 X 与 X' 含完全相同的元素，$X = X'$。 4. **φ 满射**：任给 $(x_1, \ldots, x_n) \in \{0,1\}^n$，令 $X = \{s_i : x_i = 1\}$。显然 $X \subseteq S$ 且 $\varphi(X) = (x_1, \ldots, x_n)$。 5. 由 3、4，$\varphi$ 是双射，因此 $|\mathcal{P}(S)| = |\{0,1\}^n|$。 6. **数位串**：长度为 n 的 0/1 串，每一位有 2 种选择，且每一位的选择相互独立（第 i 位的可选值不因前 $i-1$ 位的取值而改变——**这一点正是 L14 第一法则的适用前提，必须明说**）。由乘法原理，$|\{0,1\}^n| = 2^n$。 7. 合并 1 与 6，得 $\sum_{k=0}^{n} \binom{n}{k} = 2^n$。$\blacksquare$

【证明机制解说】：本证明的关键动作是**把"集合"翻译成"字符串"**。集合这种对象不好直接乘，但字符串的每一位天然对应一次二选一，乘法原理立刻可用。这个"翻译"后来反复出现：L14 里水果沙拉的多重集被翻成 0/1 串；L19 里二项分布被翻成"正面位置的选择"；L21 里随机变量独立性被翻成"联合分布等于边缘分布之积"。**遇到难数的对象，先问：它能编码成什么串？**

算例验证（$n = 3$）：全体子集共 $2^3 = 8$ 个。按大小分组：

```
子集                特征向量      大小 k
-----------------   ----------   ------
∅                   0 0 0        0
{1}                 1 0 0        1
{2}                 0 1 0        1
{3}                 0 0 1        1
{1,2}               1 1 0        2
{1,3}               1 0 1        2
{2,3}               0 1 1        2
{1,2,3}             1 1 1        3
-----------------   ----------   ------
|{k 元子集}|:  C(3,0)=1, C(3,1)=3, C(3,2)=3, C(3,3)=1
左 边 求 和:  1 + 3 + 3 + 1 = 8
右 边 计 数:  2^3 = 8            ✓
```

定理 16.4（Vandermonde 恒等式 / Vandermonde's Identity）： 对任意非负整数 m, n, r，

$$\sum_{k=0}^{r} \binom{m}{k}\binom{n}{r-k} = \binom{m+n}{r}.$$

特别地，取 $m = n = r$，得到**最漂亮的特例**：

$$\sum_{k=0}^{n}\binom{n}{k}^2=\binom{2n}{n}.$$

证明策略：**双计数**。这是全讲最值得反复品味的例子。想法是用一个**两类人群（男生 / 女生）**的模型：从 n 个男生、n 个女生中选 n 个人。一种数法是"直接数"；另一种数法是"**按选中了几个男生分类**"。之所以能这样做，是因为"选 n 个人"这件事既可以整体看成一次选择，也可以分解成"男生部分 + 女生部分"两步——**分解的维度就是求和指标 k**。

逐步推导（先证特例，再推广）： 1. 设男生集合 M 满足 $|M|=n$，女生集合 W 满足 $|W|=n$，且 $M\cap W=\varnothing$。总人数 $2n$。设 $\mathcal{S}$ 为从 $M\cup W$ 中选 n 个人（不分性别）的全体方案。 2. **数法一（直接数）**：$|\mathcal{S}|=\binom{2n}{n}$。这就是等式右边。 3. **数法二（按性别分类）**：对每个方案，记录其中男生的个数 k。可能的 k 取值是 $0,1,\dots,n$（因为一共只选 n 个人，男生不可能超过 n 个）。这些类别**互不相交**（一个方案的男生数唯一），且**并起来是 $\mathcal{S}$**（任何方案都有确定的男生数），所以构成一个划分。 4. **第 k 类怎么数**：先选 k 个男生（$\binom{n}{k}$ 种），再选 $n-k$ 个女生（$\binom{n}{n-k}$ 种）。由于男生部分与女生部分的选择**互不影响**（两个集合不相交，选谁做男生和选谁做女生是彼此独立的决定），乘法原理适用，第 k 类有 $\binom{n}{k}\binom{n}{n-k}$ 个方案。 5. **求和**：$|\mathcal{S}|=\sum_{k=0}^{n}\binom{n}{k}\binom{n}{n-k}$。 6. 由定理 16.1（对称性），$\binom{n}{n-k}=\binom{n}{k}$，于是 $|\mathcal{S}|=\sum_{k=0}^{n}\binom{n}{k}^2$。 7. 两种数法数的是同一个 $\mathcal{S}$，故 $\sum_{k=0}^{n}\binom{n}{k}^2=\binom{2n}{n}$。■ 8. **推广到一般 Vandermonde**：只需把男生数改成 m、女生数改成 n、要选的人数改成 r。同样的论证一字不改给出 $\sum_{k=0}^{r}\binom{m}{k}\binom{n}{r-k}=\binom{m+n}{r}$。（注意 k 的上限由 $\binom{m}{k}=0$（当 $k>m$）与 $\binom{n}{r-k}=0$（当 $r-k>n$）自动处理，写成 $\sum_{k=0}^{r}$ 或 $\sum_{k}$ 都对。）■

【证明机制解说】：这是双计数最经典的样板，值得把三个动作背下来： – **动作一**：把等式右边 $\binom{m+n}{r}$ 认作"从一个 $m+n$ 元的**合并池**里选 r 个"。 – **动作二**：把左边每一项 $\binom{m}{k}\binom{n}{r-k}$ 认作"从两个**子池**里分别选 k 个和 $r-k$ 个"。 – **动作三**：求和指标 k 就是"**把合并池拆成子池的方式**"。左边按 k 分类穷尽了所有可能，右边则不在乎 k 是多少。

换句话说：**左边是"先分性别再选人"，右边是"先选人不问性别"。** 结果当然一样。

反例（如果适用）：注意 $\sum_{k}\binom{n}{k}^2=\binom{2n}{n}$ **不能**随手推广到三次方。例如有人会猜 $\sum_{k}\binom{n}{k}^3=\binom{3n}{n}$，但脚本验算给出：

n	$\sum_k\binom{n}{k}^3$	$\binom{3n}{n}$	相等?
1	2	3	否
2	10	15	否
3	56	84	否
4	346	495	否

为什么不能推广？因为在双计数的故事里，$\binom{3n}{n}$ 要求把 $3n$ 个人分成 3 组，而左边的 $\binom{n}{k}^3$ 只对应"三组各选 k 个"，**三组选出的总数是 $3k$ 而不是固定的 n**——左右两边数的根本不是同一批对象。这就是"**两个集合的差**"没对上的典型症状。真正对的三次方版本（Dixon 恒等式等）形式要复杂得多，远非本讲范围。

逐项算例（$n=4$）：

k	$\binom{4}{k}$	$\binom{4}{k}^2$
0	1	1
1	4	16
2	6	36
3	4	16
4	1	1
和		**70**

而 $\binom{8}{4}=70$。相合。✓

一般式的逐项算例（$m=3,n=4,r=4$）：

k	$\binom{3}{k}$	$\binom{4}{4-k}$	乘积
0	1	$\binom{4}{4}=1$	1
1	3	$\binom{4}{3}=4$	12
2	3	$\binom{4}{2}=6$	18
3	1	$\binom{4}{1}=4$	4
4	0	$\binom{4}{0}=1$	0
和			**35**

而 $\binom{3+4}{4}=\binom{7}{4}=35$。相合。✓

ASCII 分类示意（双计数的"两种数法"）：

```
       S = 从 4 男 + 4 女 中选 4 人        (n = 4, 共 8 人)

数法一（不分性别，直接数）：  C(8,4) = 70
┌──────────────────────────────────────────────┐
│  从 {男1 男2 男3 男4 女1 女2 女3 女4} 中任取 4 人      │
└──────────────────────────────────────────────┘
                          ‖  同一个集合 S  ‖
┌──────────────────────────────────────────────┐
│  数法二（按"选中几个男生" k 分类，各类互不相交）       │
│                                              │
│   k = 0 :  选 0 男 + 4 女   →  C(4,0)·C(4,4) = 1·1 = 1│
│   k = 1 :  选 1 男 + 3 女   →  C(4,1)·C(4,3) = 4·4 =16│
│   k = 2 :  选 2 男 + 2 女   →  C(4,2)·C(4,2) = 6·6 =36│
│   k = 3 :  选 3 男 + 1 女   →  C(4,3)·C(4,1) = 4·4 =16│
│   k = 4 :  选 4 男 + 0 女   →  C(4,4)·C(4,0) = 1·1 = 1│
│                                              │
│   合计 = 1 + 16 + 36 + 16 + 1 = 70                   │
└──────────────────────────────────────────────┘
      ∴  sum_k C(4,k)^2 = C(8,4) = 70        ✓
```

定理 16.5（子集元素总数）： 对任意 $n \geq 1$，

$$\sum_{k=0}^{n} k\binom{n}{k} = n\,2^{n-1}.$$

证明策略：**双计数**。难点不在计算，而在**定义被数的对象**。左边的求和指标 k 提示我们：对象里必须携带一个"大小为 k 的子集"和一个介于 1 与 k 之间的东西。最自然的读法是"（子集，子集里的一个元素）"这样的**有序对**。右边 $n2^{n-1}$ 则要求另一种构造同样这批对的路径。这是"创造力定义对象"的最典型案例。

逐步推导： 1. **定义对象集合**：令

$$T = \{(X, x) : X \subseteq S,\ x \in X\},$$

其中 S 是固定的 n 元集合。也就是说，T 的元素是"**一个子集 X，外加 X 中指定的一个元素 x**"。注意 (X, x) 是有序对：X 相同而 x 不同时，是不同的对象。
2. **数法一（按子集大小分类）**：对固定的 k，满足 $|X| = k$ 的子集有 $\binom{n}{k}$ 个；对每个这样的 X，元素 x 有 k 种选法。于是这一类的对象数是 $k\binom{n}{k}$。对 $k = 0, 1, \ldots, n$ 求和（这些类互不相交，因为 $|X|$ 唯一）：

$$|T| = \sum_{k=0}^{n} k\binom{n}{k}.$$

1. **数法二（先挑特殊元素）**：反着来。**先定 x**：x 可以是 S 中任意一个元素，共 n 种选法。**再定 X**：X 必须包含 x，而 S 中剩下的 $n-1$ 个元素各自**独立地**决定"加入 X"或"不加入 X"——每个元素 2 种选择，共 2^{n-1} 种。由乘法原理，

$$|T| = n \cdot 2^{n-1}.$$

1. 两种数法数同一个 T，故 $\sum_{k=0}^{n} k\binom{n}{k} = n2^{n-1}$。■

【证明机制解说】：这个证明最有教育意义的地方是**它没有做任何计算**——没有化简阶乘，没有配对技巧，只有两次"讲故事"。特别是数法二的**顺序反转**：左边是"先选大集合再选小元素"，右边是"先选小元素再决定大集合"。**交换两个决定的先后次序，往往就是双计数证明的整个内容。** 请把这个模式记牢：凡是等式出现"$\binom{n}{k}$ 乘以 k"（或除以 k 再乘回来），都可以试试"（集合，其中元素）"这种带标记的对象。

逐项算例（$n = 4$）：

k	$k\binom{4}{k}$
0	0
1	4
2	12
3	12
4	4
和	32

而 $4 \cdot 2^{4-1} = 4 \cdot 8 = 32$。相合。✓ 另一个直观校验：$|T|$ 也等于"所有子集的大小之和"。$n = 4$ 时子集大小之和为 $0 \cdot 1 + 1 \cdot 4 + 2 \cdot 6 + 3 \cdot 4 + 4 \cdot 1 = 0 + 4 + 12 + 12 + 4 = 32$；用对称性看，$2^4 = 16$ 个子集的平均大小是 2，$16 \times 2 = 32$。一致。

反例（如果适用）：若误以为 $\sum_k k\binom{n}{k} = n2^n$（把指数写成 n 而非 $n-1$），则 $n = 3$ 时左边 $= 0 + 3 + 6 + 3 = 12$，右边 $= 3 \cdot 8 = 24$，**不成立**。错误根源是数法二里"剩下的 $n-1$ 个元素"被误当成"剩下的 n 个元素"；因为 x 已经确定在 X 里，它对 X 的其余部分不再有自由度。这类"指数该是 n 还是 $n-1$"的混淆在 CS70 的计数题中极为常见。

定理 16.6（二项式定理 / Binomial Theorem）： 对任意 $n \in \mathbb{N}$，

$$(a+b)^n=\sum_{k=0}^{n}\binom{n}{k}a^k b^{n-k}.$$

证明策略：**双计数（把展开过程当作一次计数过程）**。注意这里的"集合"是**展开式中出现的 2^n 个项（带位置标记）**。这是一个把代数对象"组合化"的示范：展开式不是一个符号游戏，而是在数"从 n 个括号里各取一个字母"的方案数。

逐步推导： 1. 把 $(a+b)^n$ 写成 n 个因子的乘积 $f_1 f_2 \cdots f_n$，其中每个 $f_i=(a+b)$。给因子**编号** $1,2,\dots,n$——这个编号是证明的关键，它让"哪个 a 来自哪个括号"变得可区分。 2. 用分配律展开：每一轮乘法都从当前因子里挑一个字母（a 或 b）出来。因为每个 f_i 有 2 种取法，且第 i 个因子的取法**不因前 $i-1$ 个因子的取法而改变**（每个 f_i 永远是 $(a+b)$，内容不变），由乘法原理，展开式共有 2^n 个**带位置标记**的乘积项。 3. 在这 2^n 个项中，按"**挑了多少个 a**"来分类。设挑了 k 个 a、$n-k$ 个 b，则由幂的乘法法则，这一项的值为 $a^k b^{n-k}$。所以每个这样的项都贡献一个 $a^k b^{n-k}$。 4. **数一数有多少项落入"k 个 a"这一类**：这等价于从 n 个编号因子 $\{1,\dots,n\}$ 中选出哪 k 个出 a；一旦选定，其余因子全部出 b。选择方案数是 $\binom{n}{k}$。（这里没有重复也没有遗漏：每个方案唯一决定一个项，每个项也唯一决定一个方案，这是一个**双射**。） 5. 因此 $a^k b^{n-k}$ 在展开式中（合并同类项后）恰好出现 $\binom{n}{k}$ 次，系数即为 $\binom{n}{k}$。 6. 对所有 $k=0,\dots,n$ 求和：$(a+b)^n=\sum_{k=0}^{n}\binom{n}{k}a^k b^{n-k}$。■

【证明机制解说】：步骤 1 的"给因子编号"看似多余，实则不可或缺。若不给因子编号，$(a+b)^2$ 展开成 a^2, ab, ba, b^2 就无法区分 ab 与 ba——实际上是先把它们当不同项（4 个），再按指数分类合并（ab 与 ba 合成 $2ab$，系数 2，即 $\binom{2}{1}$）。**"先数带标记的，再按等价类归并"** 是 L14 第二法则的思想，在这里以一个更精致的形式重现。

算例： $(a+b)^3=\binom{3}{0}a^0b^3+\binom{3}{1}ab^2+\binom{3}{2}a^2b+\binom{3}{3}a^3=b^3+3ab^2+3a^2b+a^3$。系数 $1,3,3,1$ 正是杨辉三角第 3 行。$(a+b)^4$ 系数为 $1,4,6,4,1$（由 Pascal 法则从上一行得到：$1;\ 1+3,\ 3+3,\ 3+1;\ 1$）。

推论（交替和为零 / Corollary 10.1）： $\displaystyle\sum_{k=0}^{n}(-1)^k\binom{n}{k}=0$（$n\ge 1$）。

代数证明：在定理 16.6 中取 $a=-1, b=1$，得 $(1-1)^n=0=\sum_{k=0}^{n}\binom{n}{k}(-1)^k\cdot 1^{n-k}$。■

组合证明：设 S 为 n 元集合。考虑用两种方法数 S 的**奇数元子集个数与偶数元子集个数之差**。 1. 形式上，令 $E=\#\{\text{偶数元子集}\}$，$O=\#\{\text{奇数元子集}\}$。则 $E-O=\sum_k(-1)^k\binom{n}{k}$（$k$ 为偶数时 $(-1)^k=+1$，奇数时 -1）。故恒等式等价于 $E=O$。 2. **构造双射**：固定元素 $s_n\in S$，定义 $\sigma(X)=X\triangle\{s_n\}$（**对称差**，即"$s_n$ 在则删去，不在则加入"）。这个操作把子集大小改变 1（$|X|$ 增减 1），因此它在奇偶性之间来回切换。 3. **σ 是自逆的**：$\sigma(\sigma(X))=X$（对同一个元素做两次"切换"等于没做），所以 σ 是双射。 4. 由于 σ 把偶数元子集一一配给奇数元子集，$E=O$，故 $E-O=0$。■

【机制解说】：这个证明的巧妙之处在于**避免了对 n 的奇偶分类讨论**。注意 σ 会给 $\varnothing$ 配到 $\{s_n\}$（大小 0 ↔ 1），给 $\{s_n\}$ 配回 $\varnothing$，完美闭环。$n=1$ 时：$E=1$（$\varnothing$），$O=1$（$\{s_1\}$），差为 0。$n=3$ 时：$E=\binom{3}{0}+\binom{3}{2}=1+3=4$，$O=\binom{3}{1}+\binom{3}{3}=3+1=4$，差为 0。✓ 注意 $n=0$ 时 $\sum_k(-1)^k\binom{0}{k}=1\neq 0$，所以推论要求 $n\ge 1$——**条件不能省**。

定理 16.7（曲棍球棒恒等式 / Hockey-stick Identity）： 对任意 $0\le k\le n-1$，

$$\binom{n}{k+1}=\binom{k}{k}+\binom{k+1}{k}+\cdots+\binom{n-1}{k}=\sum_{i=k}^{n-1}\binom{i}{k}.$$

证明策略：**双计数**。左边数「n 元集合 $S=\{1,\dots,n\}$ 的 $(k+1)$ 元子集」。右边则换一个**构造过程**：不直接说"我要选哪些"，而是**先决定"选出的集合中编号最小的元素是谁"**，再补全其余元素。这个"按最小元素分类"是组合证明里的一把常用钥匙。

逐步推导： 1. 令 $\mathcal{A}=\{X\subseteq\{1,\dots,n\}:|X|=k+1\}$，则 $|\mathcal{A}|=\binom{n}{k+1}$（左边）。 2. 对每个 $X\in\mathcal{A}$，它有一个**最小的编号元素** $\min X$。不同的 X 可能共享同一个最小元，但**每个 X 的最小元唯一**，因此"按 $\min X$ 分类"是一个划分。 3. **$\min X$ 能取哪些值？** 若令 $j=\min X$，则 X 中剩下 k 个元素都必须严格大于 j（因为 j 是最小的），所以必须 $n-j\ge k$，即 $j\le n-k$。也就是说 $j\in\{1,2,\dots,n-k\}$。**这个上限 $n-k$（而不是 n）绝不能漏掉**——它正是"还要留出 k 个更大的元素"这一约束的体现。 4. **若 $\min X=j$，有多少个这样的 X？** 剩下 k 个元素必须从 $\{j+1,j+2,\dots,n\}$ 中选，该集合有 $n-j$ 个元素，故有 $\binom{n-j}{k}$ 个方案。 5. **换元整理**：令 $i=n-j$。当 j 从 1 递增到 $n-k$ 时，i 从 $n-1$ 递减到 k。于是

$$|\mathcal{A}|=\sum_{j=1}^{n-k}\binom{n-j}{k}=\sum_{i=n-1}^{k}\binom{i}{k}=\sum_{i=k}^{n-1}\binom{i}{k}.$$

这正是恒等式右边。■ 6. **另一种同样漂亮的"最大元素"版本**：也可以按**最大元素 $\max X$** 分类。若 $\max X=i$（此时 i 至少为 $k+1$，因为还需 k 个更小的元素），其余 k 个元素从 $\{1,\dots,i-1\}$ 的 $i-1$ 元集合中选，方案数 $\binom{i-1}{k}$；令 $t=i-1$ 得 $\sum_{t=k}^{n-1}\binom{t}{k}$，与步骤 5 完全一致，且这次换元是"顺向"的、更不容易搞错。两条路径殊途同归。**推荐用最大元素版本，它的上下限天然对齐。**

【证明机制解说】：这个恒等式得名于它在杨辉三角上的形状——沿对角线求和，和为拐角处那个数，像一根曲棍球棒：

```
杨辉三角（行 n，列 k）       曲棍球棒：  sum_{i=k}^{n-1} C(i,k) = C(n,k+1)
k=0   1   2   3   4   5
n=0       1
n=1       1   1
n=2       1   2   1
n=3       1   3   3   1
n=4       1   4   6   4   1
n=5       1   5  10  10   5   1
n=6       1   6  15  20  15   6   1

取 k = 2 的竖列：  C(2,2)=1, C(3,2)=3, C(4,2)=6, C(5,2)=10, C(6,2)=15
沿此列从上往下累加（i = 2..6）：
      1
      1 + 3      = 4
      1 + 3 + 6  = 10
      1+3+6+10   = 20
      1+3+6+10+15 = 35
这些和 4, 10, 20, 35 落在竖列右边一列：
      C(4,3)=4, C(5,3)=10, C(6,3)=20, C(7,3)=35   ✓
∴  sum_{i=2}^{6} C(i,2) = C(7,3) = 35
```

算例（$n=7, k=2$）：$\binom{2}{2}+\binom{3}{2}+\binom{4}{2}+\binom{5}{2}+\binom{6}{2}=1+3+6+10+15=35$，而 $\binom{7}{3}=35$。相合。✓

一般性的直接校验（脚本验证结果）：

n	k	$\sum_{i=k}^{n-1}\binom{i}{k}$	$\binom{n}{k+1}$
5	1	$1+2+3+4=10$	$\binom{5}{2}=10$
6	2	$1+3+6+10=20$	$\binom{6}{3}=20$
7	3	$1+4+10+20=35$	$\binom{7}{4}=35$
4	2	$1+3=4$	$\binom{4}{3}=4$

四行全部相合。✓（核算时把 i 的上限 $n-1$ 用足；中间列最容易漏掉最后一项。）

反例（如果适用）：曲棍球棒恒等式的求和**必须从 $i=k$ 开始**。若误写成从 $i=1$ 开始，则当 $k\geq 2$ 时会引入一堆 $\binom{i}{k}=0$（不存在的组合数）或错误项。例如 $k=2, n=7$：从 $i=1$ 起算会得到 $\binom{1}{2}+\binom{2}{2}+\binom{3}{2}+\cdots$，其中 $\binom{1}{2}$ 按惯例取 0 尚可，但若误按 $\binom{1}{2}=1$（把"从 1 个东西里选 2 个"算成 1）就会得到 $36\neq 35$。**组合数的边界约定 $\binom{n}{k}=0$（$k>n$ 或 $k<0$）在组合证明中必须严格遵守。**

定理 16.8（握手引理，组合证明视角 / Handshake Lemma）：对任意有限无向图 $G=(V,E)$，

$$2|E|=\sum_{v\in V}\deg(v).$$

其中 $\deg(v)$ 是与 v 关联的边数。

证明策略：**双计数**。这不是一个恒等式的"计算"，而是本讲哲学在**图论领域**的直接移植。被数的对象是**（顶点，与该顶点关联的边）这样的有序对**集合 T。之所以选双计数，是因为这两边本质上就是"按行数 vs 按列数"的关系，代数证明反而绕远。

逐步推导：1. 定义对象集合

$$T=\{(v,e): v\in V,\ e\in E,\ v \text{ 是 } e \text{ 的一个端点}\}.$$

即"一条边和一个碰在它上面的顶点"组成的对。注意每条边有恰好 2 个端点（无向图，不含自环；含自环时端点需要按重数计），因此 T 的每个元素都可以形象地理解为"**边在某个端点处的'一头'**"。 2. **数法一（按边分组）**：每条边 $e=\{u,v\}$ 贡献两个对：(u,e) 与 (v,e)。因此 $|T|=2|E|$。 3. **数法二（按顶点分组）**：顶点 v 参与的边数恰好是它的度数 $\deg(v)$，因此顶点 v 贡献 $\deg(v)$ 个对，$|T|=\sum_v \deg(v)$。 4. 两种数法数同一个 T，故 $2|E|=\sum_v\deg(v)$。■

【证明机制解说】：这个证明告诉你**组合证明不只是组合数学的专利**。只要你能把某个量写成"一个集合的大小"，并找到两种数法，无论对象是子集、是排列、是图的边，方法都通用。事实上，定理 16.5 的证明与握手引理在结构上**完全同构**：那里的 T 是"（子集，其中元素）"，这里的 T 是"（顶点，关联边）"；那里按子集大小分类等价于这里按顶点分类。**认出"同构的证明骨架"是提高数学成熟度的关键一步。**

推论： 任何有限无向图中，**奇度顶点的个数必为偶数**。 – **证明**：$\sum_v\deg(v)=2|E|$ 是偶数。设奇度顶点集为 V_{odd}，则 $\sum_{v\in V_{\text{odd}}}\deg(v)=2|E|-\sum_{v\notin V_{\text{odd}}}\deg(v)$。右边两项都是偶数（$2|E|$ 显然；偶度顶点的度数和是偶数之和，仍为偶数），所以左边是偶数。而左边是 $|V_{\text{odd}}|$ 个奇数之和，奇数个奇数之和为奇数，偶数个奇数之和为偶数。故 $|V_{\text{odd}}|$ 必为偶数。■ – **具体例**：一个三角形（K_3）每个顶点度数为 2（偶数），奇度顶点数 0。一条路径 $1-2-3$ 的度数为 $1,2,1$，奇度顶点是 $\{1,3\}$，共 2 个（偶数）。**能否画出一个恰有 3 个奇度顶点的图？** 不能——这正是推论的内容。这直接解释了为什么"一笔画（欧拉路径）"问题中，起终点必须成对出现。

与经典问题的联系

一、均匀样本空间 + 计数 = 概率

L15 已经确立了这个范式：若 Ω 有限且均匀，则 $\Pr[A]=|A|/|\Omega|$。本讲的组合论证在此处提供了**不用暴力枚举**的推导力量。核心工具是下面这个由定理 16.6 直接得到的结论（官方 Note 13 的推导完全依赖计数）。

> **命题（二项分布的组合推导）**：抛一枚正面概率为 p 的硬币 n 次，恰好得到 r 个正面的概率为
>
> $$\Pr[\text{恰 } r \text{ 个正面}] = \binom{n}{r} p^r (1-p)^{n-r}.$$

推导（纯组合）：1. 样本空间 Ω 是全部长度 n 的 H/T 序列，$|\Omega| = 2^n$（定理 16.3 的位串计数）。2. 事件"恰有 r 个正面"就是"序列中恰有 r 个位置是 H"。**选择哪些位置是 H 的方案数就是 $\binom{n}{r}$**（定理 16.6 步骤 4 的同一计数）。所以该事件含 $\binom{n}{r}$ 个样本点。3. 每个"恰有 r 个正面"的样本点概率都是 $p^r(1-p)^{n-r}$（这就是 L15 中对样本点概率的**定义**方式，L17 会用乘法法则给出它的严格理由）。4. 由可加性，$\Pr[\cdot] = \binom{n}{r} \cdot p^r(1-p)^{n-r}$。■

具体算例：$n = 4, p = 2/3$，求恰有 2 个正面的概率。– 计数部分：$\binom{4}{2} = 6$。– 单个样本点概率：$(2/3)^2(1/3)^2 = 4/81$。– 所以 $\Pr = 6 \times 4/81 = 24/81 = 8/27 \approx 0.2963$。– 脚本验算：$24/81 = 8/27$。✓

二、扑克牌同花（Flush）——概率即是计数之比

52 张牌取 5 张（无序、不放回），样本空间大小 $\binom{52}{5} = 2{,}598{,}960$（L14 第二法则）。事件"同花"= 5 张同花色。每种花色 13 张，取 5 张有 $\binom{13}{5} = 1287$ 种；4 种花色，且不同花色的 5 张手牌互不相交（**这正是一个划分，所以可以直接相加**），总数 $4\binom{13}{5} = 5148$。因此

$$\Pr[\text{同花}] = \frac{4\binom{13}{5}}{\binom{52}{5}} = \frac{5148}{2598960} \approx 0.00198 \approx \frac{2}{1000}.$$

脚本验算：$4\binom{13}{5}/\binom{52}{5} = 0.00198079\ldots$ ✓（官方 Note 13 给出的正是约 0.002。）

三、生日悖论（Birthday Paradox）——用补集 + 不放回序列计数

n 个人的生日序列构成样本空间 $\Omega = \{1, \ldots, 365\}^n$，$|\Omega| = 365^n$（有放回、有序）。令 $\overline{A}$ 为"所有人都不同生日"的事件，则 $\overline{A}$ 是从 365 天中取 n 天作**有序**排列（不放回）的方案集，$|\overline{A}| = 365 \cdot 364 \cdots (365 - n + 1)$。于是

$$\Pr[A] = 1 - \frac{365 \cdot 364 \cdots (365 - n + 1)}{365^n}.$$

脚本验算：$n = 23$ 时 $\Pr[A] \approx 0.5073 > 50\%$；$n = 60$ 时 $\Pr[A] \approx 0.9941 > 99\%$。✓ 这个例子的教学价值在于："至少一对相同"用补集数远比正面数容易，而"取补集"本身就是一个双射（$\overline{A} \leftrightarrow A$ 通过 $X \mapsto \Omega \setminus X$），正是定理 16.1 的同一思想。

四、球与箱（Balls and Bins）——负载均衡的计数模型

把 m 个**有标号**的球投入 n 个**有标号**的箱，样本空间 $\Omega = \{(b_1, \ldots, b_m) : 1 \le b_i \le n\}$，$|\Omega| = n^m$（有放回有序）。事件"1 号箱为空"就是"每个球都落进其余 $n-1$ 个箱"，方案数 $(n-1)^m$，故

$$\Pr[1 \text{ 号箱空}] = \left(\frac{n-1}{n}\right)^m = \left(1 - \frac{1}{n}\right)^m.$$

脚本验算：$m = 20, n = 10$ 时 $\Pr \approx 0.12$，故"1 号箱非空"≈ 0.88。✓ 这个模型在 L20（期望与线性性）、L23（集中不等式）会被反复使用：把"每个作业随机发给一台处理器"建模成投球，就能回答"是否会出现某台处理器过载"。**注意这里的计数依赖"球有标号"**——如果球无标号，样本空间就变成多重集，计数公式完全不同（见 L14 第三法则 $\binom{n+k-1}{k}$）。

五、Monty Hall —— 样本空间的树形计数

这个经典悖论的纠错关键，恰恰是**老老实实地把样本空间数清楚**。用三元组 (i, j, k) 表示（奖品门 i、选手初选门 j、主持人开的门 k），合法样本点共 12 个：– **$i \neq j$ 型（6 个）**：此时主持人别无选择（不能开 i，不能开 j），k 被唯一确定，每个概率 $\frac{1}{3} \cdot \frac{1}{3} \cdot 1 = \frac{1}{9}$。– **$i = j$ 型（6 个）**：此时主持人有两个非奖品门可选，按假设各 $\frac{1}{2}$，每个概率 $\frac{1}{3} \cdot \frac{1}{3} \cdot \frac{1}{2} = \frac{1}{18}$。

校验总概率：$6 \cdot \frac{1}{9} + 6 \cdot \frac{1}{18} = \frac{6}{9} + \frac{6}{18} = 1$。✓

换门策略的胜率：换门获胜 $\iff$ 选手初选不是奖品门 $\iff i \neq j$，即那 6 个概率为 $\frac{1}{9}$ 的样本点。故 $\Pr[W] = 6 \cdot \frac{1}{9} = \frac{2}{3}$。而坚持原选仅 $\frac{1}{3}$。

脚本验算：$(1/9)/(1/6) = 2/3$，$(1/18)/(1/6) = 1/3$。✓ 这个计算会在 L17 用贝叶斯法则重做一遍，作为"教科书式"与"贝叶斯式"两种解法的对照。

与其他讲次的关联

- **与 L14（Counting）**：本讲的每个定理都建立在 L14 的两条法则上。定理 16.4 的"男生女生分别选"用**第一法则（乘法原理）**；定理 16.6 的"先数带标记的、再按等价类归并"用**第二法则**；定理 16.4 的特殊情形 $\sum_k \binom{n}{k}^2 = \binom{2n}{n}$ 是 L14"多重集计数 $\binom{n+k-1}{k}$"之外，另一个必须掌握的经典封闭形式。
- **与 L15（Probability Foundations）**：L15 给出 $\Pr[A] = |A|/|\Omega|$（均匀空间）与"事件 = 子集"。本讲则提供**计算 $|A|$ 与 $|\Omega|$ 的手段**。你在 L15 看到的 $\Pr[\text{恰 } 2\,\mathbf{H} \text{ in } 4] = \binom{4}{2}/2^4 = 6/16 = 3/8$，其背后正是定理 16.3（$|\Omega| = 2^4$）与定理 16.6 步骤 4（$|A| = \binom{4}{2}$）。
- **与 L17（Conditional Probability & Bayes）**：条件概率的定义式 $\Pr[A \mid B] = \Pr[A \cap B]/\Pr[B]$ 在**均匀空间**下退化为纯计数比 $|A \cap B|/|B|$。本讲的组合论证因此可以直接搬到条件概率里：例如"已知第一次抽到 A，第二次也是 A"的概率 $= \frac{4 \cdot 3}{4 \cdot 51} / \frac{4}{52}$ 的每步都是一个计数论证。L17 还会用贝叶斯法则重做 Monty Hall。
- **与 L18（Independence & Combination of Events）**：定义独立性需要 $\Pr[A \cap B] = \Pr[A]\Pr[B]$。**"乘法法则在什么条件下合法"**这个问题，本讲在定理 16.6 的步骤 2 已经给出了原型答案（每一步的可选数不因前序选择而改变）；L18 会把它正式化为"独立性"。本讲的**容斥原理**（L14 定理）也会在 L18 以概率形式重现。
- **与 L19（Random Variables）**：二项分布的 PMF $p_X(k) = \binom{n}{k} p^k (1-p)^{n-k}$ 就是本讲"均匀计数 + 加权"的产物。理解 $\binom{n}{k}$ 从哪来（选择哪些位置是成功），是理解二项分布的前提。
- **与 L20（Expectations & Linearity）**：定理 16.5（$\sum_k k\binom{n}{k} = n2^{n-1}$）有一个概率版本：若 $X \sim \mathbf{Binomial}(n, 1/2)$，则 $\mathbb{E}[X] = \sum_k k\binom{n}{k}2^{-n} = n/2$。L20 会用**期望线性性**（把 X 拆成 n 个指示变量之和）**一行**证完，与本讲的组合双计数互为映证。而定理 16.5 的 $T = \{(X, x)\}$ 与 L20 里 $X = \sum_i \mathbb{1}_i$ 是同一

个故事的两种讲法。

- **与 L09/L10（Graphs）**：定理 16.8（握手引理）是 L09 图论基础的核心工具，也是 L10 讨论欧拉路径（一笔画）存在性判据的前提。奇度顶点个数为偶数这个推论，正是欧拉路径存在性定理的一半。
- **与 L14 的容斥原理**（同一讲）：容斥原理的证明本身就是**双计数**——它数的是"元素 a 在右端被数了几次"。设 a 属于 m 个集合，则被数次数为 $\sum_{k=1}^{m}(-1)^{k-1}\binom{m}{k}=1$（由本讲交替和推论）。这个"数被数了几次"的技巧在 CS70 中反复出现，值得单独记住。
- **与 L07/L08（Polynomials & ECC）**：二项式定理（定理 16.6）是多项式系数的基础，也是 L08 讨论 Reed–Solomon 纠错码时"错误多项式"展开的工具。

关键要点

1. **组合证明的两大范式，先分清楚再动手**：
2. **双计数（double counting）**：同一个集合，两种数法。适合处理**含求和号**的恒等式（右边是"和" ⇒ 对应"分类"）。
3. **双射（bijection）**：两个集合，一个显式配对。适合处理**两边各是一个组合数**的恒等式（如 $\binom{n}{k}=\binom{n}{n-k}$）。**双射必须验证单射与满射两条**，缺一不可。
4. **核心哲学：等式两边的差 = 两个集合的差。** 找不到"两边各在数什么"，就没有组合证明。
5. **组合证明的思考框架（四步法）**：
6. **第一步：识别两边在数什么。** 左边 $\binom{n}{k}$ 通常数"n 元集合的 k 元子集"；左边的和式通常数"按某种特征分类后的并集"。
7. **第二步：确定（常常是创造性地定义）"要数的对象"。** 这是最难也最关键的一步。遇到"$\binom{n}{k}$ 乘以 k"，试试 **（子集，其中元素）对**；遇到"$\binom{m}{k}\binom{n}{r-k}$"，试试 **（从两个池子里分别取）**；遇到"求和指标 $i\le n-k$"，试试 **（集合的最小元素）**。**对象定义错了，后面全错。**
8. **第三步：验证两种数法都无重、无漏。** 分类必须是**划分**（两两不交、并集为全体）；用乘法法则时必须验证**每一步的可选数不因前序选择而改变**。
9. **第四步：若是双射，验证单射与满射。** 若 $f\circ f=\mathrm{id}$（自逆），两条可以一次证完。
10. **必须能默写的六条恒等式**：

恒等式	组合解释（一句话）	范式
$\binom{n}{k}=\binom{n}{n-k}$	选谁去 = 选谁不去	双射（取补集）
$\binom{n}{k}=\binom{n-1}{k-1}+\binom{n-1}{k}$	按某特定元素是否入选分类	双计数
$\sum_{k=0}^{n}\binom{n}{k}=2^n$	子集 ↔ 0/1 串	双射 / 双计数
$\sum_k\binom{m}{k}\binom{n}{r-k}=\binom{m+n}{r}$	分池子选 vs 合并池选	双计数
$\sum_{k=0}^{n}k\binom{n}{k}=n2^{n-1}$	数（子集，其中元素）对	双计数
$\sum_{i=k}^{n-1}\binom{i}{k}=\binom{n}{k+1}$	按最小（或最大）元素分类	双计数

1. **概率中的组合论证 = 均匀样本空间 + 计数。** 记住三件套：**样本空间是什么 → 每个样本点概率多少 → 事件对应哪些样本点**。$\Pr[\text{恰 } r \text{ 个正面}]=\binom{n}{r}/2^n$ 与 $\Pr[\text{同花}]=4\binom{13}{5}/\binom{52}{5}$ 都是这条范式的直接产物。
2. **组合证明是"跨领域"的工具。** 握手引理 $2|E|=\sum_v \deg v$ 的证明与 $\sum_k k\binom{n}{k}=n2^{n-1}$ 的证明在结构上完全同构（都是"数同一个（对象，附属物）对的集合"）。**认出同构的证明骨架**比记住单个证明更有价值。
3. **交替和 $\sum_k(-1)^k\binom{n}{k}=0$（$n\ge 1$）也可纯组合证明**：用"对称差翻转一个固定元素"的对合 $\sigma(X)=X\triangle\{s_n\}$，把偶数元子集与奇数元子集一一配对。注意 $n=0$ 时不成立（和为 1），**条件 $n\ge 1$ 不能省**。

常见误区与注意事项

1. **把有序当无序（或反之）。** $\binom{n}{k}$ 数的是**无序的** k 元子集；若被数的对象天生带顺序（如"第一次抽到谁、第二次抽到谁"），就必须用 $n(n-1)\cdots(n-k+1)$ 而不是 $\binom{n}{k}$。**典型错误**：算"两枚骰子点数相同"时把 $|\Omega|=\binom{6}{2}=15$ 当成样本空间（正确答案是 $6/36=1/6$；若用无序样本空间 15 个，点数相同只有 6 个，得到 $6/15=2/5$，**完全错误**）——因为无序样本空间**不是均匀的**（$(1,1)$ 与 $(1,2)$ 出现概率不同）。
2. **"数了两次但两次数的对象其实不同"**。这是本讲最隐蔽的错误。定理 16.4 的反例就是它：$\sum_k\binom{n}{k}^3$ 与 $\binom{3n}{n}$ 看起来形似，但前者数的对象要求"三组各选 k 个（总数 $3k$）"，后者要求"总共选 n 个"——**对象不同，等式必假**。用脚本验算即可立刻发现（$n=2$ 时 $10\ne 15$）。
3. **双射只证了单射（或只证了满射）**。例如"从 k 元子集中去掉最小元素"这个映射看起来"几乎"是双射，实际上既非单射也非满射（$n=3,k=2$ 时 $\{1,2\}$ 与 $\{2,3\}$ 都映到含 3 的那个集合模式）。**有限集合上单射与满射互相蕴含（$|A|=|B|$ 时），但在你还不知道该证什么之前，必须两条都检查。**
4. **用乘法法则时未验证"每步的选择数与前序选择无关"**。L14 第一法则的**前提条件**：对**每一种**前 $i-1$ 步的选择，第 i 步都恰好有 n_i 种选择。反例见 L14 的"水果沙拉"问题：3^5 个有序结果按无序结果分组时，每组大小从 1（五根香蕉）到 5（四根香蕉一个苹果）不等，**不能除以常数**，第二法则失效。**用乘法前先问：这个数依赖于前面的选择吗？**
5. **把"和"当成"加"而不检查是否构成划分**。$\sum_k\binom{n}{k}$ 能这样加，是因为"k 元子集"对不同的 k 互不相交。反之，若把"含 a 的子集"与"含 b 的子集"相加，就不构成划分（会重复计入同时含 a,b 的子集）。**每次写 $\sum$ 时都要问：这些类两两不交吗？合起来是全体的吗？**
6. **在双计数中忘记排除退化情形**。定理 16.7 中 $\min X$ 的上限是 $n-k$ 而非 n（因为还要留出 k 个更大的元素）。定理 16.5 中"剩下的元素"是 $n-1$ 个而非 n 个（因为 x 已经固定入选），导致指数是 $n-1$ 而不是 n。**边界条件通常就是错误藏身之处，写完 $\sum$ 的上限和指数后一定要用小 n 验算一遍。**
7. **在均匀样本空间判据上出错。$\Pr[A]=|A|/|\Omega|$ 只在均匀空间成立**。偏硬币（$p\ne 1/2$）抛 n 次时，各序列概率不同（$p^r(1-p)^{n-r}$），**不能**简单地用"有利序列数 / 总序列数"，必须对样本点概率加权求和。这一点在 L17 会成为核心。

思考题（带答案）

Q1.（纯计算） 用 Vandermonde 恒等式计算 $\displaystyle\sum_{k=0}^{5}\binom{5}{k}\binom{7}{4-k}$，并写出逐项分解。

> ▸ **答案**
>
> 由定理 16.4，取 $m=5, n=7, r=4$：
>
> $$\sum_{k=0}^{5}\binom{5}{k}\binom{7}{4-k}=\binom{12}{4}.$$
>
> 逐项：
>
k	$\binom{5}{k}$	$\binom{7}{4-k}$	乘积
0	1	$\binom{7}{4}=35$	35
1	5	$\binom{7}{3}=35$	175
2	10	$\binom{7}{2}=21$	210
3	10	$\binom{7}{1}=7$	70
4	5	$\binom{7}{0}=1$	5
5	1	$\binom{7}{-1}=0$	0
和			**495**
>
> 而 $\binom{12}{4}=495$。相合。✓
>
> 注意 $k=5$ 时 $\binom{7}{-1}=0$（按边界约定），所以上限写成 5 或 4 都一样。**组合解释**：从 5 个男生与 7 个女生中选 4 个人，按"选了几个男生"分类。

Q2.（概念理解 / 证明） 证明 $\displaystyle\sum_{k=0}^{n}\binom{n}{k}k^2=n(n+1)2^{n-2}$（$n\geq 1$）。提示：定义合适的"要数的对象"。

> ▸ **答案**
>
> **证明策略**：双计数。左边出现 $k\cdot\binom{n}{k}$ 再乘 k，提示对象应携带**两个（可以相同）被标记的元素**，或者携带**一个有序的标记对**。
>
> **对象定义**：令
>
> $$T=\{(X,x,y): X\subseteq S,\ x\in X,\ y\in X\},$$
>
> 其中 S 是 n 元集合，x,y **可以相同**（有序对，允许重复），且都必须在 X 中。
>
> **数法一（按 $|X|=k$ 分类）**：固定 k，X 有 $\binom{n}{k}$ 种；x 有 k 种、y 有 k 种选法，独立，共 k^2 种。于是 $|T|=\sum_{k=0}^{n}k^2\binom{n}{k}$。
>
> **数法二（按 x,y 是否相同分情形）**：– **情形 A：$x=y$**。选 x（n 种），再决定 X 是否包含其余 $n-1$ 个元素中的每一个（2^{n-1} 种）。共 $n2^{n-1}$ 个。这正好是定理 16.5。 – **情形 B：$x\neq y$**。先选有序对 (x,y)：x 有 n 种、y 有 $n-1$ 种，共 $n(n-1)$ 种。再决定 X 是否包含其余 $n-2$ 个元素（2^{n-2} 种）。（注意 x,y 都必须已经在 X 里，所以它们两个不是自由选择的。）共 $n(n-1)2^{n-2}$ 个。
>
> **合并**：
>
> $$|T|=n2^{n-1}+n(n-1)2^{n-2}=n2^{n-2}\big(2+(n-1)\big)=n(n+1)2^{n-2}.$$
>
> 两种数法数同一个 T，故
>
> $$\sum_{k=0}^{n}k^2\binom{n}{k}=n(n+1)2^{n-2}.\qquad\blacksquare$$
>
> **验算（$n=4$）**：左边 $=0+1^2\cdot 4+2^2\cdot 6+3^2\cdot 4+4^2\cdot 1=0+4+24+36+16=80$；右边 $=4\cdot 5\cdot 2^2=80$。相合。✓
>
> **（顺带指出另一种验算路径）**：若 $X\sim\mathrm{Binomial}(n,1/2)$，则 $\mathbb{E}[X^2]=\sum_k k^2\binom{n}{k}2^{-n}=\frac{n(n+1)}{4}$。当 $n=4$：$\mathbb{E}[X^2]=80/16=5=\frac{4\cdot 5}{4}$。✓ 与 $\mathrm{Var}(X)=\mathbb{E}[X^2]-\mathbb{E}[X]^2=5-4=1=n\cdot\frac{1}{2}\cdot\frac{1}{2}$ 一致（L22 会给出方差公式）。

Q3.（概念理解 / 找错误） 下面这个"证明"错在哪里？

待证：$\sum_{k=1}^{n} k\binom{n}{k} = n2^n$。 **"证明"**：考虑从 n 个人中选出一个委员会（任意大小），再从委员会中选出一名主席。选委员会有 2^n 种（定理 16.3），选主席有 n 种……所以总数是 $n2^n$。另一方面，若委员会有 k 人，则有 $\binom{n}{k}$ 个委员会、k 个主席人选，故总数为 $\sum_k k\binom{n}{k}$。两边相等。

▸ 答案

错误在于：对"选主席有 n 种"这一步的两次计数不一致，导致两次数的对象其实不同。

拆开看： – **左边数的对象**是 $T = \{(X, x) : X \subseteq S,\ x \in X\}$ —— **主席必须属于委员会**。 – **右边（"$n2^n$"）数的对象**是 $T' = \{(X, x) : X \subseteq S,\ x \in S\}$ —— 主席可以是**任何**人，**不需要**在委员会里。

这两个集合不相等：$|T|$ 中 x 由 X 决定（必须入选），$|T'|$ 中 x 与 X 无关（X 可以是空集，此时"主席不在委员会里"）。所以 $|T| \neq |T'|$。

正确做法（定理 16.5）：选定主席 x 后（n 种），**剩下的 $n-1$ 个人**各自独立决定是否加入委员会（2^{n-1} 种），因为 x 已经在里面了，它没有自由度。故 $|T| = n2^{n-1}$，**不是 $n2^n$**。

数值反例：$n = 3$。 – 正确的左边：$1\cdot 3 + 2\cdot 3 + 3\cdot 1 = 3 + 6 + 3 = 12$。 – 错误的右边：$n2^n = 3\cdot 8 = 24$。 – 若用错误的"证明"，还会推出荒谬结论：$n = 1$ 时左边 $= 1$，右边 $= 2$。$1 \neq 2$，**命题本身是假的。**

教训：写双计数证明时，必须逐字核对**两次数的是不是同一个集合**。特别是"剩下的元素有几个"这类细节（n 还是 $n-1$）以及"某个元素是否被约束在子集内"，是这类错误的绝对高发区。**用 $n = 1$ 或 $n = 2$ 过一遍是最便宜的检测手段。**

Q4.（证明） 用组合论证证明**容斥原理只数一次**这一关键步骤：若元素 a 属于 m 个集合 $A_1, \ldots, A_n$，则它在

$$\sum_{k=1}^{n} (-1)^{k-1} \sum_{S \subseteq \{1,\ldots,n\},\ |S|=k} \left| \bigcap_{i \in S} A_i \right|$$

中被数了恰好 1 次。

▸ 答案

证明策略：双计数（数"a 被数了几次"）＋ 本讲的交替和恒等式。

逐步推导： 1. 设 $M = \{i \in \{1,\ldots,n\} : a \in A_i\}$，$|M| = m \geq 1$（因为 a 至少在某个集合里）。 2. 对任一子集 $S \subseteq \{1,\ldots,n\}$，$a \in \bigcap_{i\in S} A_i$ 当且仅当 S 中每个 i 都满足 $a \in A_i$，即 $S \subseteq M$。若 $S \not\subseteq M$（存在某个 $i \in S$ 而 $i \notin M$），则 $a \notin A_i$，所以 a 不被 $\bigcap_{i\in S} A_i$ 计入。 3. 因此 a 被右端计数的次数为

$$N(a) = \sum_{k=1}^{n} (-1)^{k-1} \#\{S \subseteq M : |S| = k\} = \sum_{k=1}^{m} (-1)^{k-1} \binom{m}{k}.$$

（求和上限从 n 缩到 m，因为 M 中只有 m 个元素，$k > m$ 时不存在大小 k 的子集。） 4. 由本讲的交替和推论 $\sum_{k=0}^{m} (-1)^k \binom{m}{k} = 0$（$m \geq 1$），得

$$\sum_{k=1}^{m} (-1)^{k-1} \binom{m}{k} = -\left[\sum_{k=0}^{m} (-1)^k \binom{m}{k} - \binom{m}{0}\right] = -(0 - 1) = 1.$$

1. 故 $N(a) = 1$：属于并集的每个元素 a 在右端被**恰好数一次**。■

【机制解说】：这一步是 L14 容斥原理证明的核心（官方 Note 把 Corollary 10.1 也就是交替和恒等式直接用作它的最后一步）。整个论证的结构是**双重双计数**：容斥原理本身是"两种数法数 $|A_1 \cup \cdots \cup A_n|$"，而验证它正确的方式是"数每个元素被数了几次"。**"数被数的次数"（counting the countings）是组合证明中的高级技巧，值得单独记住。**

验算（$m = 3$）：$N(a) = \binom{3}{1} - \binom{3}{2} + \binom{3}{3} = 3 - 3 + 1 = 1$。✓ **验算（$m = 4$）**：$4 - 6 + 4 - 1 = 1$。✓

Lecture 17: Conditional Probability & Bayes（条件概率与贝叶斯）

概述

L15 建立了概率的公理框架，L16 提供了计数的武器。但两者都默认一件事：**我们只知道事件本身，不知道任何额外信息**。本讲要问的是：**当一条新信息（证据）到手后，概率应该如何修正？**

答案是**条件概率**（conditional probability）$\Pr[A \mid B] = \Pr[A \cap B] / \Pr[B]$，它的直观含义是"把样本空间 Ω 缩小到 B，然后在 B 里重新归一化"。由条件概率可以推出三件互相缠绕的工具：**乘法法则（乘积法则 / product rule）**把交集的概率拆成一串条件概率的乘积；**全概率法则（law of total probability）**按划分把无条件概率拆成加权平均；**贝叶斯法则（Bayes' rule）**把条件方向翻转，用"原因→结果"的概率反推"结果→原因"的概率。最后一条是机器学习、信号处理、医疗诊断、垃圾邮件过滤乃至司法推理的数学基础。

本讲在课程中的位置：它是 L15 概率公理的第一次实质性扩展，是 L18（独立性、事件组合）的直接铺垫（独立性就是把 $\Pr[A \mid B] = \Pr[A]$ 写成对称形式），也是 L19（随机变量）、L21（联合分布）、L26（条件期望、马尔可夫链）的必备语言。**"条件化"是概率论中最重要的一把刀**，本讲要把它磨透。

核心概念的直观解释

条件概率（Conditional Probability） – **定义**：设 $A, B \subseteq \Omega$ 是同一概率空间中的事件，且 $\Pr[B] > 0$。则在 B 发生的条件下 A 发生的**条件概率**定义为

$$\Pr[A \mid B] = \frac{\Pr[A \cap B]}{\Pr[B]}.$$

读作"给定 B 时 A 的概率"。注意 $\Pr[B] = 0$ 时该式无定义（不允许"条件在不可能事件上"）。 – **直观解释（"它是什么意思？"）**：这是**样本空间的缩减（shrinking the sample space）**。原来我们在整个 Ω 上谈概率；一旦知道 B 已经发生，所有 $\omega \notin B$ 的可能性都被排除，世界只剩下 B。但 B 内部原有的概率之和 $\Pr[B]$ 一般小于 1，不能直接当概率用（公理要求全空间概率为 1），所以必须把每个样本点的概率**放大 $1/\Pr[B]$ 倍**，重新归一化。 – **关键术语**：$\Pr[A \cap B]$ 是**联合概率（joint probability）**——"A 与 B 同时发生"；$\Pr[A \mid B]$ 是**条件概率**。**这两个量不同**，且相差一个因子 $\Pr[B]$。混淆它们是 CS70 最高频的失分点之一。

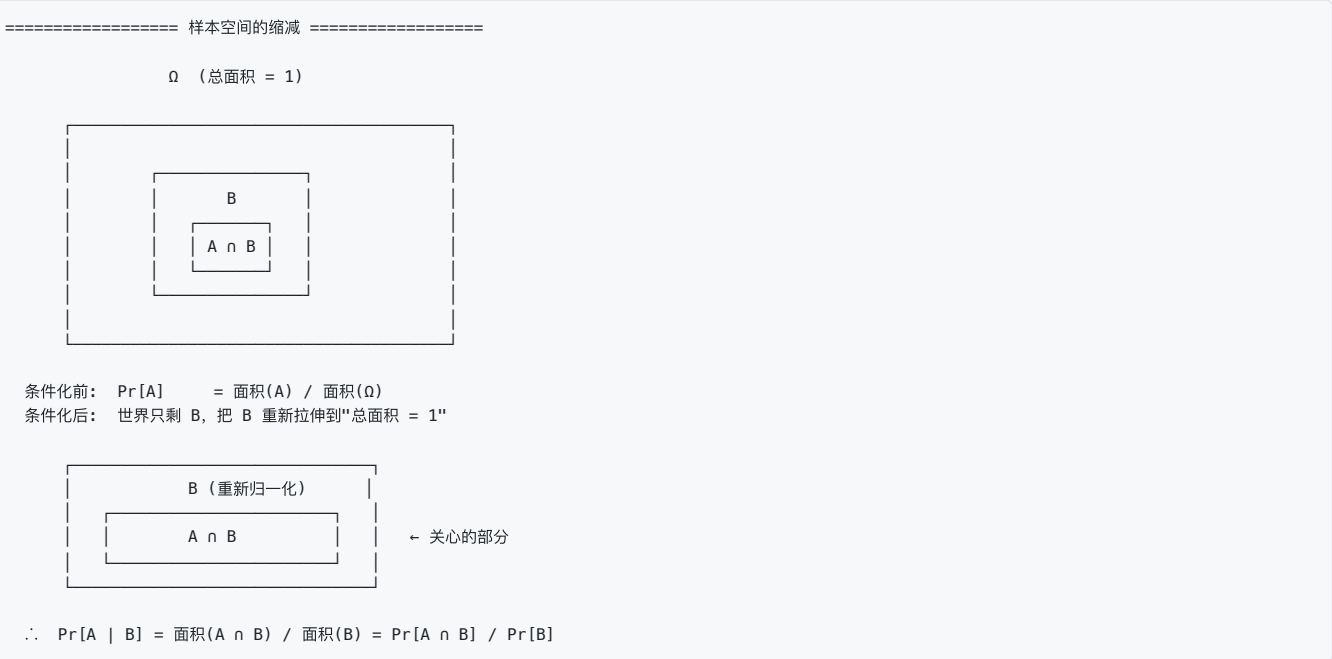

- **具体示例（两枚骰子）**：掷两枚公平骰子，$\Omega = \{(i,j) : 1 \le i,j \le 6\}$，$|\Omega| = 36$，均匀。设 B = "点数和为 8"，A = "至少有一枚是 3"。
- $B = \{(2,6),(3,5),(4,4),(5,3),(6,2)\}$，$|B| = 5$。
- $A \cap B = \{(3,5),(5,3)\}$，$|A \cap B| = 2$。
- $\Pr[A \mid B] = \frac{2/36}{5/36} = \frac{2}{5} = 0.4$。
- 脚本验算：$|B| = 5$，$|A \cap B| = 2$，比值 0.4。✓ 注意 $\Pr[A] = 11/36 \approx 0.3056$，"和为 8"这条信息**提高**了"出现 3"的概率（正相关）。

乘法法则（Product Rule / Chain Rule） – **定义**：对任意事件 A, B，$\Pr[A \cap B] = \Pr[A]\,\Pr[B \mid A] = \Pr[B]\,\Pr[A \mid B]$（当相应的条件概率有意义时）。更一般地，$\Pr\left[\bigcap_{i=1}^{n} A_i\right] = \Pr[A_1]\Pr[A_2 \mid A_1]\Pr[A_3 \mid A_1 \cap A_2]\cdots\Pr\left[A_n \mid \bigcap_{i=1}^{n-1} A_i\right]$。 – **直观解释（"它是什么意思？"）**：这是**逐步走路径**的技巧。要求一件事**同时**发生，就把它拆成"先发生第一步，再在第一步已发生的前提下发生第二步……"。概率论里没有"同时"，只有"序贯"。想象一棵决策树：一条从根到叶的路径的概率等于沿途各边条件概率的乘积。 – **具体示例**：从 52 张牌中连抽 2 张（不放回），求两张都是 A 的概率。设 A_1 = "第 1 张是 A"，A_2 = "第 2 张是 A"。

$$\Pr[A_1 \cap A_2] = \Pr[A_1]\Pr[A_2 \mid A_1] = \frac{4}{52} \times \frac{3}{51} = \frac{12}{2652} = \frac{1}{221} \approx 0.004525.$$

脚本验算：$12/2652 = 0.00452489\ldots$，且 $\Pr[A_2 \mid A_1] = 3/51 = 1/17 \approx 0.0588 < \Pr[A_2] = 1/13 \approx 0.0769$。✓

全概率法则（Law of Total Probability） – **定义**：设 $B_1, \ldots, B_n$ 是样本空间 Ω 的一个**划分（partition）**，即 $B_1 \cup \cdots \cup B_n = \Omega$ 且 $B_i \cap B_j = \varnothing$（$i \neq j$）。则对任意事件 A，

$$\Pr[A] = \sum_{i=1}^{n} \Pr[A \cap B_i] = \sum_{i=1}^{n} \Pr[A \mid B_i]\,\Pr[B_i].$$

- **直观解释（"它是什么意思？"）**：这是**分情形（divide into cases）**策略的概率版本。想知道"A 会不会发生"，就先把世界按某个分类标准切成几块（$B_1, \ldots, B_n$），在每一块里分别算 A 的概率，再按各块的"大小"（$\Pr[B_i]$）做**加权平均**。特别地，$n = 2$ 时就是 $\Pr[A] = \Pr[A \mid B]\Pr[B] + \Pr[A \mid B^c]\Pr[B^c]$。
- **具体示例（网球比赛）**：你要和随机选出的对手 X 或 Y 比赛。已知 $\Pr[A \mid B_X] = 0.7$（对 X 胜率）、$\Pr[A \mid B_Y] = 0.3$（对 Y 胜率）、$\Pr[B_X] = 0.6$、$\Pr[B_Y] = 0.4$。则由全概率法则

$$\Pr[A] = 0.7 \times 0.6 + 0.3 \times 0.4 = 0.42 + 0.12 = 0.54.$$

脚本验算：0.54。✓ 注意这个 0.54 **不是** $(0.7 + 0.3)/2 = 0.5$——加权平均必须用真实的权重（这里是 $0.6/0.4$ 而非 $0.5/0.5$）。

贝叶斯法则（Bayes' Rule） – **定义**：对事件 A, B 且 $\Pr[A] > 0, \Pr[B] > 0$，

$$\Pr[B \mid A] = \frac{\Pr[A \mid B]\,\Pr[B]}{\Pr[A]}.$$

若 $B_1, \ldots, B_n$ 是 Ω 的划分，则对每个 i：

$$\Pr[B_i \mid A] = \frac{\Pr[A \mid B_i]\,\Pr[B_i]}{\sum_{j=1}^{n} \Pr[A \mid B_j]\,\Pr[B_j]}.$$

- **直观解释（"它是什么意思？"）**：贝叶斯法则解决一个**方向问题**。在实践中，我们往往只知道"**从原因推结果的概率**"（生病 → 检测阳性的概率、垃圾邮件 → 含某词的概率），但真正想知道的是"**从结果反推原因的概率**"（检测阳性 → 真的生病了的概率、含某词 → 是垃圾邮件的概率）。贝叶斯法则就是把后者用前者表达出来的唯一桥梁。原式中的分母 $\Pr[A]$ 之所以能算出来，正是因为全概率法则。
- **术语**（务必记住，L18 之后会反复出现）：
- **先验（prior）** $\Pr[B]$：看到证据之前，我们对 B 的信念。
- **似然（likelihood）** $\Pr[A \mid B]$：若 B 为真，观察到证据 A 的可能性有多大。
- **后验（posterior）** $\Pr[B \mid A]$：看到证据 A 之后，修正过的信念。
- 一句话口诀：**后验 ∝ 似然 × 先验**（分母只是归一化常数）。
- **具体示例**：见下方完整算例，那里会看到"$\Pr[\text{病} \mid \text{阳性}] \approx 9\%$ 而 $\Pr[\text{阳性} \mid \text{病}] = 99\%$"这种令人震惊的落差。

最大似然估计与最大后验估计（MLE vs MAP） – **定义**：设数据 A 已观测，参数取值 $B_1, \dots, B_n$。 – **最大似然估计（Maximum Likelihood Estimate, MLE）**：选使**似然**最大的参数：$\hat{B}_{\text{MLE}} = \arg\max_i \Pr[A \mid B_i]$。 – **最大后验估计（Maximum A Posteriori, MAP）**：选使**后验**最大的参数：$\hat{B}_{\text{MAP}} = \arg\max_i \Pr[B_i \mid A] = \arg\max_i \Pr[A \mid B_i]\Pr[B_i]$（分母与 i 无关，可丢弃）。 – **直观解释（"它是什么意思？"）**：MLE 是"**只信数据**"——哪种原因最能解释我看到的证据，就选哪个。MAP 是"**数据 + 先验**"——还要考虑"这种原因本身常见不常见"。**当先验均匀（所有 $\Pr[B_i]$ 相等）时，两者完全一致**，因为此时乘上同一个常数不改变谁最大。 – **具体示例**：见下文"两个罐子"算例，其中 MAP 与 MLE 的分歧阈值是 $\Pr[B_1] > 5/9$。

独立（Independence，预告） – **定义**：事件 A, B 称为**独立（independent）**，若 $\Pr[A \cap B] = \Pr[A]\Pr[B]$。当 $\Pr[B] > 0$ 时等价于 $\Pr[A \mid B] = \Pr[A]$。 – **直观解释（"它是什么意思？"）**：**知道 B 发生，不改变你对 A 的信念**。条件化前后概率不变，就是"无关"。注意独立性**不是**"互斥"——互斥事件（$A \cap B = \varnothing$）在 $\Pr[A], \Pr[B] > 0$ 时是**强烈负相关**的（知道 B 发生就排除了 A）。 – **具体示例**：抛一枚公平硬币三次，A = "第 1 次正面"，B = "第 2 次正面"。$\Pr[A \mid B] = 1/2 = \Pr[A]$，独立。而 A = "第 1 次正面"，C = "第 1 次是反面"：$\Pr[A \mid C] = 0 \neq 1/2$，不独立（且互斥）。**独立性将在 L18 展开，包括"两两独立但不相互独立"的经典陷阱。**

完整证明与推导（核心）

定理 17.1（条件概率仍是合法的概率测度）： 固定事件 B 且 $\Pr[B] > 0$。定义映射 $\Pr[\cdot \mid B] : 2^{\Omega} \to \mathbb{R}$ 为 $\Pr[A \mid B] = \Pr[A \cap B] / \Pr[B]$。则 $\Pr[\cdot \mid B]$ 满足概率的三条公理：

1. **非负性（Non-negativity）**：对任意 $A \subseteq \Omega$，$\Pr[A \mid B] \geq 0$。
2. **规范性与可加性（Normalization & Additivity）**：$\Pr[\Omega \mid B] = 1$；且对任意**互不相交**的事件 $A_1, A_2, \dots$，$\Pr[\bigcup_i A_i \mid B] = \sum_i \Pr[A_i \mid B]$。

证明策略：**直接证明（把定义代进去，逐条核对）**。之所以选这个策略，是因为命题本身就是"某个构造满足某组公理"的验证型命题。证明的意义不只是"这道题会做"，而是回答了一个更根本的问题：**为什么条件概率要这样定义？** 因为它必须是**唯一**能让"限制在 B 上的概率"仍然合法的定义。

逐步推导：

（公理 1） 对任意 A，$\Pr[A \cap B] \geq 0$（公理的非负性），且 $\Pr[B] > 0$，故商 ≥ 0。✓

（公理 2 前半：规范性）

$$\Pr[\Omega \mid B] = \frac{\Pr[\Omega \cap B]}{\Pr[B]} = \frac{\Pr[B]}{\Pr[B]} = 1. \qquad \checkmark$$

（公理 2 后半：可加性） 设 $A_1, A_2, \dots$ 两两不交，即 $A_i \cap A_j = \varnothing$（$i \neq j$）。1. 先看它们与 B 相交后的集合：$(A_i \cap B) \cap (A_j \cap B) = A_i \cap A_j \cap B = \varnothing$。所以 $\{A_i \cap B\}_i$ 也是两两不交的。 2. 于是对原空间用可加性：$\Pr[\bigcup_i (A_i \cap B)] = \sum_i \Pr[A_i \cap B]$。 3. 另一方面，$(\bigcup_i A_i) \cap B = \bigcup_i (A_i \cap B)$（分配律）。 4. 因此

$$\Pr\left[\bigcup_i A_i \mid B\right] = \frac{\Pr[(\bigcup_i A_i) \cap B]}{\Pr[B]} = \frac{\Pr[\bigcup_i (A_i \cap B)]}{\Pr[B]} = \frac{\sum_i \Pr[A_i \cap B]}{\Pr[B]} = \sum_i \Pr[A_i \mid B]. \qquad \checkmark$$

1. 三条公理全部满足，故 $\Pr[\cdot \mid B]$ 是 Ω 上的一个合法概率测度。■

【证明机制解说】：步骤 1 是唯一需要动脑的地方——它说明"与 B 取交集"这个操作**保持不交性**。这是整个证明的枢纽：正因为不交性被保持，才能把原空间的可加性"搬运"到条件空间。至于**唯一性**：假设我们希望"限制在 B 上的概率"既满足公理、又与原概率在 B 内部各事件的**相对比例**保持一致（即 $A_1, A_2 \subseteq B$ 时 $\frac{\Pr[A_1 \mid B]}{\Pr[A_2 \mid B]} = \frac{\Pr[A_1]}{\Pr[A_2]}$），那么任何这样的测度 Q 必须满足 $Q(A) = c \cdot \Pr[A]$（对 $A \subseteq B$），由 $Q(B) = 1$ 定出 $c = 1/\Pr[B]$。**所以定义 $\Pr[A \mid B] = \Pr[A \cap B] / \Pr[B]$ 不是任意约定，而是被这三条要求逼出来的唯一选择。** 这一点官方 Note 是用"若不除以 $\Pr[B]$，则 $\sum_{\omega \in B} \Pr[\omega \mid B] = \Pr[B] < 1$，不满足归一化"来说明的——完全等价的说法。

定理 17.2（乘法法则 / Product Rule，链式形式）： 对任意事件 $A_1, \dots, A_n$ 且 $\Pr\left[\bigcap_{i=1}^{n-1} A_i\right] > 0$，

$$\Pr\left[\bigcap_{i=1}^{n} A_i\right] = \Pr[A_1] \cdot \Pr[A_2 \mid A_1] \cdot \Pr[A_3 \mid A_1 \cap A_2] \cdots \Pr\left[A_n \,\middle|\, \bigcap_{i=1}^{n-1} A_i\right].$$

特别地，$n = 2$ 时 $\Pr[A \cap B] = \Pr[A]\Pr[B \mid A] = \Pr[B]\Pr[A \mid B]$。

证明策略：**数学归纳法（induction on n）**。这是 L03 归纳法的标准应用场景：命题天然带有参数 n，且"n 个事件的交集"可以写成"前 $n-1$ 个的交集"与"第 n 个事件"的两事件交集，从而套用 $n = 2$ 的基础情形。**为什么不用双计数或双射？** 因为这里不涉及任何"数对象"，而是一个**结构性的恒等式**，归纳是它的自然语言。

逐步推导：

（基础情形 $n = 1$） 命题退化为 $\Pr[A_1] = \Pr[A_1]$，恒真。✓

（基础情形 $n=2$，同时也是直接计算） 由条件概率定义，$\Pr[A_2 \mid A_1] = \dfrac{\Pr[A_1 \cap A_2]}{\Pr[A_1]}$。两边乘 $\Pr[A_1]$（且 $\Pr[A_1] > 0$ 保证除法合法）得

$$\Pr[A_1 \cap A_2] = \Pr[A_1]\Pr[A_2 \mid A_1].$$

交换 A_1, A_2 的角色（同样要求 $\Pr[A_2] > 0$）得 $\Pr[A_1 \cap A_2] = \Pr[A_2]\Pr[A_1 \mid A_2]$。两个表达式相等，正说明 $\Pr[A]\Pr[B \mid A] = \Pr[B]\Pr[A \mid B]$——这正是贝叶斯法则的雏形。✓

（归纳步骤） 设对某个 $n \geq 3$，命题对 $n-1$ 个事件成立（**归纳假设**）：

$$\Pr\left[\bigcap_{i=1}^{n-1} A_i\right] = \Pr[A_1] \cdot \Pr[A_2 \mid A_1] \cdots \Pr\left[A_{n-1} \,\middle|\, \bigcap_{i=1}^{n-2} A_i\right].$$

1. 记 $C = \bigcap_{i=1}^{n-1} A_i$。由题设 $\Pr[C] > 0$。
2. 对**两个**事件 A_n 与 C 用基础情形：

$$\Pr\left[\bigcap_{i=1}^{n} A_i\right] = \Pr[A_n \cap C] = \Pr[A_n \mid C]\Pr[C] = \Pr\left[A_n \,\middle|\, \bigcap_{i=1}^{n-1} A_i\right] \cdot \Pr\left[\bigcap_{i=1}^{n-1} A_i\right].$$

1. 代入归纳假设替换 $\Pr[C]$：

$$\Pr\left[\bigcap_{i=1}^{n} A_i\right] = \Pr\left[A_n \,\middle|\, \bigcap_{i=1}^{n-1} A_i\right] \cdot \Pr[A_1] \cdot \Pr[A_2 \mid A_1] \cdots \Pr\left[A_{n-1} \,\middle|\, \bigcap_{i=1}^{n-2} A_i\right].$$

1. 这正是 n 个事件的链式公式。由归纳法，命题对所有 $n \geq 1$ 成立。■

【证明机制解说】：这个证明的"机制"是**把长链条缩短一格**。链式法则之所以对任意 n 成立，是因为"交集"这个运算在结构上是**可结合的**：$\bigcap_{i=1}^{n} A_i = A_n \cap \left(\bigcap_{i=1}^{n-1} A_i\right)$。凡是遇到这种"可结合 + 带参数的恒等式"，归纳法几乎总是对的工具。

条件不能省：若 $\Pr\left[\bigcap_{i=1}^{n-1} A_i\right] = 0$，链条后半段的条件概率无定义，公式失去意义。**具体反例**：$n=2$，取 $A_1 = \varnothing$。则 $\Pr[A_1] = 0$，$\Pr[A_2 \mid A_1]$ 无定义；而 $\Pr[A_1 \cap A_2] = 0$。虽然"$0 = 0 \cdot \Pr[A_2 \mid A_1]$"在形式上还能凑出正确数值，但条件概率本身不存在，推导链是断的。

典型应用（Monty Hall 的交集概率）：设 C_i = "选手选门 i"，P_i = "奖品在门 i"，H_i = "主持人开门 i"。求 $\Pr[C_1 \cap P_2 \cap H_3]$。 – $\Pr[C_1] = 1/3$（选手随机选）。 – $\Pr[P_2 \mid C_1] = 1/3$（奖品位置与选手选择独立）。 – $\Pr[H_3 \mid C_1 \cap P_2] = 1$：主持人不能开门 1（选手已选）、不能开门 2（那里有奖品），只剩门 3。 – 由链式法则：$\Pr[C_1 \cap P_2 \cap H_3] = \frac{1}{3} \cdot \frac{1}{3} \cdot 1 = \frac{1}{9}$。

对照：若错误地"把三个概率直接相乘"，会写成 $\frac{1}{3} \cdot \frac{1}{3} \cdot \Pr[H_3]$，而 $\Pr[H_3] = 1/3$，得到 $\frac{1}{27}$——**错了 3 倍**。原因正是忽略了条件：$\Pr[H_3] = 1/3$ 是无条件的，而这里需要的是 $\Pr[H_3 \mid C_1 \cap P_2]$。这个对比是"条件概率不是可选项"最有力的说明。

定理 17.3（全概率法则 / Law of Total Probability）：设 $B_1, \ldots, B_n$ 是 Ω 的一个划分（$B_i \cap B_j = \varnothing$ 对 $i \neq j$，且 $\bigcup_{i=1}^{n} B_i = \Omega$）。则对任意事件 A，

$$\Pr[A] = \sum_{i=1}^{n} \Pr[A \cap B_i] = \sum_{i=1}^{n} \Pr[A \mid B_i]\,\Pr[B_i].$$

（第二个等号要求 $\Pr[B_i] > 0$ 对所有 i；若某个 $\Pr[B_i] = 0$，则对应的 $\Pr[A \mid B_i]$ 无定义，但该项在第一个求和中本就为 0，可安全省略。）

证明策略：**直接证明（把 A 按划分拆成不交并，再用可加性）**。核心是集合论恒等式加一条概率公理。之所以说这是"直接证明"而非归纳，是因为无论 n 是多少，论证格式完全相同。

逐步推导： 1. **拆 A**：由 $B_1 \cup \cdots \cup B_n = \Omega$，

$$A = A \cap \Omega = A \cap \left(\bigcup_{i=1}^{n} B_i\right) = \bigcup_{i=1}^{n} (A \cap B_i),$$

其中第二步用的是分配律（L00 集合运算）。 2. **验证这些块两两不交**：对 $i \neq j$，

$$(A \cap B_i) \cap (A \cap B_j) = A \cap (B_i \cap B_j) = A \cap \varnothing = \varnothing,$$

因为 $B_i \cap B_j = \varnothing$。所以 $\{A \cap B_i\}_{i=1}^{n}$ 是一族**两两不交**的集合。 3. **用可加性**：既然 A 是这些不交块的不交并，由概率的可加性公理（L15 的核心公理，本讲定理 17.1 也再次验证了它在条件化后保持），

$$\Pr[A] = \Pr\left[\bigcup_{i=1}^{n} (A \cap B_i)\right] = \sum_{i=1}^{n} \Pr[A \cap B_i].$$

1. **换成条件概率形式**：对每个满足 $\Pr[B_i] > 0$ 的 i，由条件概率定义 $\Pr[A \cap B_i] = \Pr[A \mid B_i]\Pr[B_i]$（这等价于定理 17.2 的两事件情形）。代入即得

$$\Pr[A] = \sum_{i=1}^{n} \Pr[A \mid B_i]\,\Pr[B_i]. \qquad \blacksquare$$

【证明机制解说】：整个证明只有一步不太显然：**步骤 2 的不交性**。为什么"B_i 两两不交"能推出"$A \cap B_i$ 两两不交"？因为与固定集合 A 取交**不会**让两个不交的集合重新重叠——交运算只会让集合变小。这与定理 17.1 步骤 1 是同一个观察的两种应用。**"取交保持不交性"是概率论中使用频率最高的集合论事实之一。**

$n=2$ 的常见形式（最常用！）：

$$\Pr[A] = \Pr[A \mid B]\Pr[B] + \Pr[A \mid B^c]\Pr[B^c].$$

因为 $\{B, B^c\}$ 永远是一个划分。官方 Note 中的疾病检测、网球比赛、双罐取球全都用这个二划分形式。

具体算例（双罐取球的一部分）：罐 1 中白色球占 $2/5$，罐 2 中白色球占 $1/2$，随机等概率选罐再取一球。则"取到白球"的概率为

$$\Pr[f] = \Pr[f \mid B_1]\Pr[B_1] + \Pr[f \mid B_2]\Pr[B_2] = \frac{2}{5}\times\frac{1}{2} + \frac{1}{2}\times\frac{1}{2} = \frac{2}{10} + \frac{1}{4} = \frac{4}{20} + \frac{5}{20} = \frac{9}{20} = 0.45.$$

脚本验算：$2/5 \times 0.5 + 1/2 \times 0.5 = 0.45 = 9/20$。✓

反例（划分必须完整，否则公式失效）：在上面的双罐问题里，若**漏掉罐 2**（只计算 $\Pr[f \mid B_1]\Pr[B_1] = 2/10$），就会把 $\Pr[f]$ 严重低估为 $2/10 = 0.2$（正确值是 0.45）。更糟的是，用它做贝叶斯更新会得到

$$\Pr[B_1 \mid f] = \frac{2/10}{2/10} = 1,$$

即"必然来自罐 1"——一个荒谬的结论（正确答案是 $4/9 \approx 0.444$）。这清楚地说明：**全概率法则的分母必须是"穷尽所有互斥情形"的和。漏掉任何一种情形，整个贝叶斯更新就崩了。** 脚本验算对比：漏项版本给出 1.0，正确版本给出 $4/9 = 0.4444\ldots$。✓

另一个反例（划分中的块必须互斥）：若把 B_1 = "取到白球"，B_2 = "取到小球"当作划分（这两个事件可以同时发生），则 $\Pr[B_1] + \Pr[B_2]$ 可能超过 1，求和会重复计数。**"划分"两个字里的"互斥"和"穷尽"两条要求同等重要。**

定理 17.4（贝叶斯法则 / Bayes' Rule）： 设 A, B 是事件，$\Pr[A] > 0, \Pr[B] > 0$。则

$$\Pr[B \mid A] = \frac{\Pr[A \mid B]\ \Pr[B]}{\Pr[A]}.$$

更一般地，设 $B_1, \ldots, B_n$ 是 Ω 的划分且各 $\Pr[B_i] > 0$，则对每个 i：

$$\Pr[B_i \mid A] = \frac{\Pr[A \mid B_i]\ \Pr[B_i]}{\sum_{j=1}^{n} \Pr[A \mid B_j]\ \Pr[B_j]}.$$

证明策略：直接证明（两次套用条件概率定义 + 一次全概率法则）。这个"定理"实际上没有独立的新内容——它是乘法法则与全概率法则的直接组合。把它单列为定理，是因为**它在应用中的地位极高**，值得作为一个可独立调用的公式。

逐步推导： 1. 由条件概率定义（用于 $\Pr[B \mid A]$）：$\Pr[B \mid A] = \dfrac{\Pr[B \cap A]}{\Pr[A]}$。 2. 由乘法法则（定理 17.2，交换角色）：$\Pr[B \cap A] = \Pr[A \mid B]\Pr[B]$。 3. 代入步骤 1：$\Pr[B \mid A] = \dfrac{\Pr[A \mid B]\Pr[B]}{\Pr[A]}$。这是**基本形式**，其中 $\Pr[A]$ 需要另外算。✓ 4. **一般形式**：用全概率法则（定理 17.3）把分母展开，

$$\Pr[A] = \sum_{j=1}^{n} \Pr[A \mid B_j]\Pr[B_j],$$

代入步骤 3 即得

$$\Pr[B_i \mid A] = \frac{\Pr[A \mid B_i]\Pr[B_i]}{\sum_{j=1}^{n} \Pr[A \mid B_j]\Pr[B_j]}. \qquad \blacksquare$$

1. **用以核验的一个好习惯**：分母 $\Pr[A]$ 与 i 无关，所以各后验 $\Pr[B_i \mid A]$ 之和为

$$\sum_i \Pr[B_i \mid A] = \frac{\sum_i \Pr[A \mid B_i]\Pr[B_i]}{\sum_j \Pr[A \mid B_j]\Pr[B_j]} = 1.$$

这提供了免费的自检：所有候选原因的后验概率必须加起来等于 1。 如果你算出来是 0.8 或 1.3，一定哪里错了（通常是漏了划分中的某一项，或把 $\Pr[A \mid B_i]$ 与 $\Pr[B_i \mid A]$ 弄混）。

【证明机制解说】：贝叶斯法则的"机制"可以记成三步口诀：

```
========== 贝叶斯更新的三步流程 ==========

        先验 Pr[B]  ──────────────────────┐
                                          │
        似然 Pr[A|B] ─────────────────────┼──→ 相乘 ──→ 联合 Pr[A ∩ B]
                                          │                (未归一化的后验)
                                          │                    │
                                          │                    ▼
        分母 Pr[A] = Σ_j Pr[A|B_j]Pr[B_j]  ──────────→ 归一化 (除以 Pr[A])
                                                               │
                                                               ▼
                                                        后验 Pr[B|A]

   口诀：  后验  ∝  似然 × 先验
           归一化常数 = Pr[A] = 所有 "似然 × 先验" 之和
```

要强调的核心问题：贝叶斯法则处理的**方向翻转**问题。现实中我们容易测量的是 $\Pr[\text{阳性} \mid \text{患病}]$（临床试验能设计出来），而临床真正需要的是 $\Pr[\text{患病} \mid \text{阳性}]$（拿到阳性报告后我到底有多大概率生病）。这两个数字**可以相差一个数量级**，见下文算例。**这就是"检察官谬误（prosecutor's fallacy）"的数学根源。**

错误方向的反例（$\Pr[A \mid B] \neq \Pr[B \mid A]$）： – 取 A = "检测阳性"，B = "患病"。设患病率 $\Pr[B] = 1/1000$，灵敏度 $\Pr[A \mid B] = 0.99$，特异度 $= 0.99$（即假阳性率 1%）。脚本验算： – $\Pr[A] = 0.001 \times 0.99 + 0.999 \times 0.01 = 0.00099 + 0.00999 = 0.01098$。 – $\Pr[B \mid A] = 0.00099/0.01098 = 0.09016\ldots \approx 9.02\%$。 – 而 $\Pr[A \mid B] = 99\%$。 – **两个数相差约 11 倍。** 把后者当成前者，就是 11 倍的错误（实际应用中足以让一个人做出完全错误的医疗决定）。 – **极端反例**：把患病率降到百万分之一（10^{-6}），并让检测更准（灵敏度与特异度都是 0.999）。脚本验算：$\Pr[B \mid A] = 0.000998\ldots \approx 0.0998\%$。也就是说，**即使检测准确率 99.9%，对一个百万人中才有一例的疾病，阳性报告只意味着约千分之一的患病概率。** 这个结果近乎反直觉，但它完全正确：假阳性的绝对数量（约 999 人/百万）远超真阳性（约 1 人/百万）。**贝叶斯法则不是"更精确的计算"，它是防止直觉犯错的唯一工具。**

定理 17.5（均匀空间下的条件概率退化为计数比）： 若概率空间均匀（$|\Omega| = N$ 且每个样本点概率 $1/N$），则对任意事件 A, B 且 $B \neq \varnothing$，

$$\Pr[A \mid B] = \frac{|A \cap B|}{|B|}.$$

证明策略：**直接证明**。这条命题是 L16 与 L17 之间的**桥梁**：它说明条件概率在均匀情形下就是"在缩小的样本空间 B 里做计数"。之所以值得单列，是因为它把 L16 的全部组合技巧直接搬到了条件概率中。

逐步推导： 1. 由均匀性，$\Pr[A \cap B] = |A \cap B|/N$，$\Pr[B] = |B|/N$。 2. 代入定义：$\Pr[A \mid B] = \dfrac{|A \cap B|/N}{|B|/N} = \dfrac{|A \cap B|}{|B|}$（$N$ 约掉）。■ 3. **注意**：$B \neq \varnothing$ 保证 $|B| > 0$，即 $\Pr[B] > 0$，条件概率有定义。

【证明机制解说】：这一步看似平凡，但它是**大量 CS70 条件概率题的实际解法**。N 被约掉这个事实说明：**在均匀空间里，条件化不需要重新算总样本空间的大小，只需要在 B 内部数**。这正是"样本空间缩减"的精确含义。

算例（球与箱）：$m = 4$ 个有标号球投入 $n = 3$ 个有标号箱，均匀空间，$|\Omega| = 3^4 = 81$。设 A = "1 号箱为空"，B = "2 号箱为空"。 1. **方法一（直接计数）**：$A \cap B$ = "1、2 号箱都空" = "4 个球全在 3 号箱"，只有 1 个样本点。$|B|$ = "4 个球都在 2、3 号箱" $= 2^4 = 16$。故 $\Pr[A \mid B] = 1/16 = 0.0625$。 2. **方法二（定义式）**：$\Pr[A] = (2/3)^4 = 16/81$（"1 号箱为空"= 每球都落进另两个箱），$\Pr[B] = 16/81$，$\Pr[A \cap B] = 1/81$（全落 3 号箱），故

$$\Pr[A \mid B] = \frac{1/81}{16/81} = \frac{1}{16}.$$

1. **脚本暴力枚举**（$3^4 = 81$ 种情形全跑一遍）：总数 81，$|B| = 16$，$|A \cap B| = 1$，$\Pr[A \mid B] = 0.0625$。✓
2. **解读**：$\Pr[A] = 16/81 \approx 0.1975$，而 $\Pr[A \mid B] = 0.0625$。知道 2 号箱空了，**大大降低**了 1 号箱也空的概率（因为球挤到更少的箱子里去了，"2 号也空着"这件事本身就暗示"球集中"）。这叫**负相关（negatively correlated）**。

与经典问题的联系

一、医学检验悖论（Medical Test Paradox）——本讲最重要的算例

问题设置：某疾病在人群中的患病率（**先验**）为 $1/1000$。检验的**灵敏度（sensitivity）**为 99%（患者中 99% 检出阳性），**特异度（specificity）**为 99%（健康人中 99% 检出阴性，即**假阳性率**为 1%）。问：一个人检测阳性，他真正患病的概率是多少?

数学建模：设 D = "患病"，$\overline{D}$ = "健康"，$+$ = "检测阳性"，$-$ = "检测阴性"。已知

$$\Pr[D] = 0.001, \quad \Pr[+ \mid D] = 0.99, \quad \Pr[+ \mid \overline{D}] = 0.01.$$

要求 $\Pr[D \mid +]$。

求解（贝叶斯法则）： 1. **算分母（全概率法则）**：

$$\Pr[+] = \Pr[+ \mid D]\Pr[D] + \Pr[+ \mid \overline{D}]\Pr[\overline{D}] = 0.99 \times 0.001 + 0.01 \times 0.999.$$

逐项：$0.99 \times 0.001 = 0.00099$（真阳性路径）；$0.01 \times 0.999 = 0.00999$（假阳性路径）。

$$\Pr[+] = 0.00099 + 0.00999 = 0.01098.$$

1. **算后验**：

$$\Pr[D \mid +] = \frac{\Pr[+ \mid D]\Pr[D]}{\Pr[+]} = \frac{0.00099}{0.01098} = 0.0901639\ldots \approx 9.02\%.$$

1. **脚本验算**：$0.00099/0.01098 = 0.09016393\ldots$；自然频率版本（$10$ 万人中 100 名患者，真阳性 99 例，健康者 99900 人产生假阳性 999 例，阳性总数 1098，比例 $99/1098 = 9.0164\%$）与公式法一致。✓

为什么只有 9%？（自然频率树状图）

```
========== 10 万人接受检测（自然频率树） ==========

                    100,000 人
                        │
          ┌─────────────┴─────────────┐
          │                           │
      患病 0.1%                    健康 99.9%
       100 人                      99,900 人
          │                           │
      ┌───┴───┐                   ┌───┴───┐
      │       │                   │       │
  阳性 99%  阴性 1%           阳性 1%    阴性 99%
   99 人     1 人             999 人    98,901 人
  (真阳性)                   (假阳性)
      └───────┬─────────────────┘
              ▼
        阳性总人数 = 99 + 999 = 1,098 人
              │
      其中真患病者占比 = 99 / 1,098 = 9.02%   ← 后验

  关键对比:
     Pr[+ | D]  = 99/100    = 99%      (灵敏度，医生从说明书上看到的)
     Pr[D | +]  = 99/1098   ≈  9.02%   (后验，病人真正想知道的)
                        ↑ 相差约 11 倍!
```

解释"为什么"：疾病的**稀有性**（先验极低）把天平压向了假阳性。虽然检测本身很准（每 100 个健康人只有 1 个误报），但健康人的**基数**是患者的约 1000 倍，所以假阳性的**绝对数量**（999）是真阳性（99）的约 10 倍。**后验概率取决于"路径的绝对大小"（似然 × 先验），而不只是似然。** 这也是为什么对稀有病的筛查必须用高特异度检测，且阳性结果通常需要复查确认。

先验的影响（脚本验算的对照表）：固定灵敏度 $=$ 特异度 $=\mathbf{0.99}$，只改先验：

患病率（先验）	检测阳性后的后验
0.1%（1/1000）	9.02%
1%	50.00%
5%	83.90%
10%	91.67%
50%	99.00%

（全部经脚本验算。）**同一份检测报告，在不同先验下含义完全不同。** 这就是"先验"在贝叶斯框架中不可或缺的原因，也是"只看似然"的 MLE 在稀有事件上会犯大错的原因。

二、官方 Note 的检验算例：5% 患病率、90% 灵敏度、80% 特异度

设置：$\Pr[A]=0.05$（患病人群占比），$\Pr[B\mid A]=0.9$（患者 90% 阳性），$\Pr[B\mid \overline{A}]=0.2$（健康人 20% 阳性，即假阳性率 20%，特异度 80%）。

推导：1. **分母**：$\Pr[B]=\Pr[B\mid A]\Pr[A]+\Pr[B\mid \overline{A}]\Pr[\overline{A}]=0.9\times 0.05+0.2\times 0.95=0.045+0.19=0.235$。2. **后验**：$\Pr[A\mid B]=\dfrac{0.045}{0.235}=\dfrac{45}{235}=\dfrac{9}{47}\approx 0.1915$。3. **脚本验算**：$0.045/0.235=0.19148936\ldots=9/47$。✓ 4. **解读**：先验 5% 被更新到约 19%——**上升了约 4 倍但远不是"几乎确定"**。这次"只有" 19% 的原因同样是假阳性（0.19 vs 真阳性 0.045，比值约 4.2）。这个例子告诉我：**灵敏度高不代表后验高；关键在于"似然比" $\frac{\Pr[B\mid A]}{\Pr[B\mid \overline{A}]}=\frac{0.9}{0.2}=4.5$ 与先验的乘积。**

三、双罐取球（Bayes + 全概率 + MAP/MLE）

设置：两个罐子（官方 Note 中的图示：罐 1 含 2 白 3 黑，罐 2 含 1 白 1 黑）。等概率选一个罐子，再均匀随机取一球。取到白球（记作 f），问：来自罐 1 的概率是多少?

常见的错误直觉："总共有 3 个白球，其中 2 个在罐 1，所以答案是 $2/3$。" **错在哪里**：这个推理**只数了球，没有数概率**——它忽略了"罐 2 只有 2 个球，而罐 1 有 5 个球"，即罐 2 的白球**更"浓缩"**，被取到的概率更高。

正确解法（贝叶斯 + 全概率）：1. 已知 $\Pr[f\mid B_1]=2/5$，$\Pr[f\mid B_2]=1/2$，$\Pr[B_1]=\Pr[B_2]=1/2$。2. 分母（全概率法则）：$\Pr[f]=\frac{2}{5}\times\frac{1}{2}+\frac{1}{2}\times\frac{1}{2}=\frac{2}{10}+\frac{1}{4}=\frac{9}{20}=0.45$。3. 后验：$\Pr[B_1\mid f]=\dfrac{(2/5)(1/2)}{9/20}=\dfrac{2/10}{9/20}=\dfrac{4}{9}\approx 0.4444$。4. **脚本验算**：$(2/10)/(9/20)=0.44444\ldots=4/9$。✓ 确实是 $4/9$ 而不是 $2/3$ —— 直觉错在"样本点的权重"。5. **自检**：$\Pr[B_2\mid f]=1-4/9=5/9$。两个后验之和为 1。✓

MLE vs MAP（同一算例）：– MLE（只看似然，假设先验均匀）：$\Pr[f\mid B_1]=0.4<\Pr[f\mid B_2]=0.5$，故 $\hat{B}_{\text{MLE}}=B_2$（罐 2 更能产生白球）。– MAP（乘上先验）：先验均匀时 $\Pr[f\cap B_1]=0.2<\Pr[f\cap B_2]=0.25$，故 $\hat{B}_{\text{MAP}}=B_2$，与 MLE 一致。– **先验非均匀的情形**：若 $\Pr[B_1]=p$，则

$$\Pr[f\cap B_1]=\frac{2}{5}p,\qquad \Pr[f\cap B_2]=\frac{1}{2}(1-p).$$

令前者大于后者：$\frac{2}{5}p>\frac{1}{2}(1-p)\Rightarrow 0.4p>0.5-0.5p\Rightarrow 0.9p>0.5\Rightarrow p>\frac{5}{9}$。**脚本验算**：阈值 $=0.5/0.9=0.5555\ldots=5/9$；取 $p=0.6$ 得 $\Pr[f\cap B_1]=0.24>\Pr[f\cap B_2]=0.2$，MAP 翻转为 B_1；取 $p=0.5$（均匀）得 $0.2<0.25$，MAP 为 B_2。✓ – **结论**：**当 $\Pr[B_1]>5/9$ 时，MAP 选罐**

1，而 MLE 永远选罐 2（因为 MLE 不看先验）。 这是"先验如何压倒数据"的最清晰示例。实践中的一般原则：**有可靠的先验就用 MAP，先验不可靠或数据量很大（似然会主导）时用 MLE。**

四、Monty Hall 用贝叶斯重做

设置：选手选门 1，主持人开了门 3（露出山羊）。求奖品在门 2 的条件概率 $\Pr[P_2 \mid C_1 \cap H_3]$。

求解： 1. **三个候选原因** $\{P_1, P_2, P_3\}$ 构成一个划分（奖品必在某一门后），各先验 $\Pr[P_i] = 1/3$。 2. **似然**（在选手已选门 1 的前提下）： – 若奖品在门 1（$\Pr[P_1 \mid C_1] = 1/3$），主持人可在门 2、3 中任选，$\Pr[H_3 \mid C_1 \cap P_1] = 1/2$。 – 若奖品在门 2，主持人不能开门 1（选手选了）、不能开门 2（有奖品），只能开门 3，$\Pr[H_3 \mid C_1 \cap P_2] = 1$。 – 若奖品在门 3，主持人绝不能开门 3，$\Pr[H_3 \mid C_1 \cap P_3] = 0$。 3. **分母（全概率法则）**：

$$\Pr[C_1 \cap H_3] = \Pr[C_1]\left[\Pr[P_1 \mid C_1]\cdot\tfrac{1}{2} + \Pr[P_2 \mid C_1]\cdot 1 + \Pr[P_3 \mid C_1]\cdot 0\right] = \frac{1}{3}\left(\frac{1}{6} + \frac{1}{3}\right) = \frac{1}{3}\cdot\frac{1}{2} = \frac{1}{6}.$$

（用联合概率核对：$\Pr[C_1 \cap P_1 \cap H_3] = \frac{1}{3}\cdot\frac{1}{3}\cdot\frac{1}{2} = \frac{1}{18}$，$\Pr[C_1 \cap P_2 \cap H_3] = \frac{1}{3}\cdot\frac{1}{3}\cdot 1 = \frac{1}{9}$，二者之和 $\frac{1}{18} + \frac{2}{18} = \frac{3}{18} = \frac{1}{6}$。✓） 4. **后验**：

$$\Pr[P_2 \mid C_1 \cap H_3] = \frac{1/9}{1/6} = \frac{2}{3}, \qquad \Pr[P_1 \mid C_1 \cap H_3] = \frac{1/18}{1/6} = \frac{1}{3}.$$

1. **脚本验算**：$(1/9)/(1/6) = 0.6667$，$(1/18)/(1/6) = 0.3333$。✓ 自检：$2/3 + 1/3 = 1$。✓
2. **与 L16 的树形计数法对照**：L16 是通过枚举 12 个样本点、按 $i \neq j$ / $i = j$ 两类求和得到 $\frac{6}{9} = \frac{2}{3}$；这里是**在给定证据下重新分配概率质量**。两种方法结果一致——**条件概率不是新数学，它只是把"数样本点"换成了"按权重重新归一化"，后者在样本空间庞大或不可枚举时是唯一可行的办法。**

五、其他经典场景

- **连抽两张 A（乘法法则）**：见核心概念部分的算例，$\Pr = \frac{4}{52}\cdot\frac{3}{51} = \frac{1}{221}$。注意 $\Pr[A_2 \mid A_1] = 3/51 < \Pr[A_2] = 1/13$——**不放回抽样导致负相关。**
- **同花概率（乘法法则的另一条路径）**：$\Pr[\text{红心同花}] = \frac{13}{52}\cdot\frac{12}{51}\cdot\frac{11}{50}\cdot\frac{10}{49}\cdot\frac{9}{48}$，再乘 4 得全同花概率。这与 L16 的 $\frac{4\binom{13}{5}}{\binom{52}{5}}$ 完全一致（脚本验算 0.00198079）。**两条路径互为验算。**
- **三骰子赌局（全概率 + 容斥）**：选一个数字，掷三枚骰子，至少一枚出现该数字则赢。$\Pr[\text{赢}] = 1 - (5/6)^3 = 1 - 125/216 = 91/216 \approx 0.4213$（用补集算最方便）。脚本暴力枚举 216 种结果：91 种获胜，$91/216 = 0.42129629\ldots$。✓ 赌场声称的"$3 \times 1/6 = 50\%$"是错的（把不互斥事件当互斥），正确值 42.13%，赌场占了便宜。**这个例子会在 L18 用容斥原理系统地重做。**
- **生日悖论中的条件视角**：已知有 n 个人，求"某两人的生日相同"的概率——不多说，L16 已给出 $1 - \frac{365\cdots(365-n+1)}{365^n}$。
- **垃圾邮件过滤（朴素贝叶斯）**：$\Pr[\text{垃圾} \mid \text{含"中奖"}] = \frac{\Pr[\text{含"中奖"}\mid\text{垃圾}]\Pr[\text{垃圾}]}{\Pr[\text{含"中奖"}]}$。这正是本讲公式的工业级应用：先验来自历史邮件统计，似然来自词频统计，后验是过滤决策的分数。**"朴素"之处在于它假设各词条件独立**（L18 的内容）。

与其他讲次的关联

- **与 L15（Probability Foundations）**：条件概率的定义直接建构在 L15 的公理体系上。本讲定理 17.1 就是把 L15 的三条公理**逐条搬进缩小的样本空间 B**，确认它仍是一个合法概率空间。**没有 L15 的"事件 = 子集、概率 = 可加测度"，条件概率无从定义。**
- **与 L16（Combinatorial Proofs）**：定理 17.5 是本讲与 L16 的接口——均匀空间下 $\Pr[A \mid B] = |A \cap B|/|B|$，于是 L16 的全部组合论证（双计数、双射）都能直接用来算条件概率。反过来说，L16 中"取补集"的双射也解释了为什么 $\Pr[A^c \mid B] = 1 - \Pr[A \mid B]$。
- **与 L18（Independence & Combination of Events）**：本讲的乘积法则与独立性的关系是：$\Pr[A \cap B] = \Pr[A]\Pr[B]$ 成立 $\iff$ $\Pr[A \mid B] = \Pr[A]$ $\iff$ A 与 B 独立。L18 会把独立性给成正式定义，并讨论**两两独立但不相互独立**（用抛两次硬币的 A, B, C 例子）、**条件独立 ≠ 独立**等高阶陷阱。L18 还会把 L14/L16 的容斥原理改写成概率形式，用于处理 L17 已经出现的"三骰子赌局"这类并集问题。
- **与 L19（Random Variables & Discrete Distributions）**：二项分布的构造依赖本讲：$\Pr[\text{恰 } r \text{ 个正面}] = \binom{n}{r}p^r(1-p)^{n-r}$ 之所以成立，是因为我们**假设各次抛掷独立**，从而 $\Pr[\text{某个特定含 } r \text{ 个正面的序列}] = p^r(1-p)^{n-r}$（L15 是直接"定义"了这个样本点概率，本讲用乘法法则**证明了**这样定义与独立性一致）。
- **与 L20/L21（Expectations；Joint Distributions）**：L21 会用**条件分布** $p_{X|Y}(x \mid y) = \frac{p_{X,Y}(x,y)}{p_Y(y)}$ 定义随机变量的条件化——这是本讲的直接推广（事件 → 随机变量取值）。L26 的**条件期望** $\mathbb{E}[X \mid Y]$ 与**马尔可夫链的转移概率** $P_{ij} = \Pr[X_{t+1} = j \mid X_t = i]$ 全都是条件概率。
- **与 L22（Variance & Covariance）**：条件期望会导出**全期望法则**（law of total expectation）$\mathbb{E}[X] = \sum_i \mathbb{E}[X \mid B_i]\Pr[B_i]$——与本讲定理 17.3 完全平行。**"按划分分情形"是贯穿 L17–L26 的统一技巧。**
- **与 L23（Concentration Inequalities）**：切尔诺夫界（Chernoff bound）的推导会用到"$\Pr[X \geq a] = \Pr[e^{tX} \geq e^{ta}]$"这类变换，其核心仍是条件化的思想（把事件限定在尾部）。而证明中反复出现 $\Pr[A \mid B] \leq \Pr[A]/\Pr[B]$ 这类估计。
- **与 L13（Computability）/L12（Countability）**：这些讲次讨论"不可判定"与"不可数"的硬边界，本讲讨论的是**在信息不完全下如何做出最优（贝叶斯意义下）判断**——这是 CS70 从"什么是可计算的"过渡到"什么是可合理相信的"的转折点。
- **与 L02（Proof Techniques II）**：本讲大量使用"分情形"（定理 17.3 的划分）与"取补集"（$\Pr[A] = 1 - \Pr[A^c]$）。**证明技巧层面，本讲没有新工具；新的是"概率质量必须归一化"这一约束下如何组织这些技巧。**

关键要点

1. **条件概率的定义与三大推论**：

名称	公式	用途
定义	$\Pr[A \mid B] = \dfrac{\Pr[A \cap B]}{\Pr[B]}$	已知 B 求 A
乘法法则	$\Pr[A \cap B] = \Pr[A]\Pr[B \mid A]$	求交集；链式推广到 n 个事件

名称	公式	用途
全概率法则	$\Pr[A]=\sum_i \Pr[A \mid B_i]\Pr[B_i]$	分母；分情形加权平均
贝叶斯法则	$\Pr[B \mid A]=\dfrac{\Pr[A \mid B]\Pr[B]}{\Pr[A]}$	方向翻转；后验 $\propto$ 似然 × 先验

记忆锚点：定义是"除以 $\Pr[B]$"；乘法法则是"定义式移项"；全概率法则是"按划分切块再相加"；贝叶斯法则是"乘法法则 + 全概率法则"。**四条公式只有一条是新的（定义），其余全是组合。**

1. **样本空间缩减是唯一正确的直觉**。条件化 = "世界只剩 B" + "把 B 拉伸到总面积 1"。这个图像能一句话解释为什么必须除以 $\Pr[B]$（不除的话 B 内部概率和只有 $\Pr[B]<1$，不满足归一化公理）。
2. **贝叶斯法则的核心用途是翻转方向**：$\Pr[\text{原因} \mid \text{证据}] \leftarrow \Pr[\text{证据} \mid \text{原因}]$。现实中最容易测的是似然（临床试验、词频统计），最想要的是后验（诊断、分类）。**先验（罕见的疾病、常见的垃圾邮件）会极大地放大似然的误导性。**
3. **MLE vs MAP 一句话区分**：$\hat{B}_{\text{MLE}}=\arg\max \Pr[A \mid B_i]$（只信数据），$\hat{B}_{\text{MAP}}=\arg\max \Pr[A \mid B_i]\Pr[B_i]$（数据 + 先验）。**先验均匀时二者一致**；先验差距足够大时，MAP 可以完全无视似然的排序（双罐例中阈值 $\Pr[B_1]>5/9$）。
4. **自检的两条"免费验算"**：
5. **划分自检**：所有候选原因的后验必须加起来为 1，即 $\sum_i \Pr[B_i \mid A]=1$。这能立刻逮住"划分漏项"的错误。
6. **量级自检**：若先验很小时后验却接近 1，几乎肯定是漏掉了假阳性路径（分母少了一项）。**先验 × 似然比 $\gg 1$ 才是后验高的条件。**
7. **数值计算的三条黄金率**：
8. 分母 $\Pr[A]$ **一定**要由全概率法则算出，不能凭空假设。
9. 用**自然频率**（10 万人中有多少）代替小数，能大幅减少直觉错误——疾病检测例子中 $99/(99+999)$ 比 $0.00099/0.01098$ 直观得多。
10. 先写联合概率（似然 × 先验）的**每一项**，最后再除以总和。**逐项写出"路径大小"是避免漏项的机械办法。**

常见误区与注意事项

1. **混淆 $\Pr[A \mid B]$ 与 $\Pr[B \mid A]$（检察官谬误 / Prosecutor's Fallacy）**。这是本讲的头号错误，也是最严重的错误，因为它会导致司法与医疗上的灾难性判断。
2. **具体数值反例**：$\Pr[\text{阳性} \mid \text{患病}]=99\%$，而 $\Pr[\text{患病} \mid \text{阳性}]=9.02\%$（患病率 $1/1000$、特异度 99%）。**两者相差约 11 倍。**
3. **检察官谬误的经典形态**："DNA 匹配概率是百万分之一，所以被告无辜的概率只有百万分之一。"——**错了**。在 1000 万人口的数据库中，无辜者匹配率百万分之一意味着期望约有 10 个无辜者也会匹配，因此 $\Pr[\text{有罪} \mid \text{匹配}] \approx \frac{1}{1+10} \approx 9\%$（脚本验算：$0.0909$）。若匹配率降到十亿分之一，则假阳性期望约 0.01，$\Pr[\text{有罪} \mid \text{匹配}] \approx 99\%$（脚本验算：$0.9901$）。**同一个"匹配率"，在不同数据库规模下含义完全不同。**
4. **防范方法**：写公式前先明确"我要求的是谁在竖线左边、谁在右边"，并用 $\Pr[A \mid B]\Pr[B]=\Pr[A \cap B]=\Pr[B \mid A]\Pr[A]$ 做一次交叉验算。
5. **把条件概率算成了联合概率（忘记除以 $\Pr[B]$）**。这是最"机械"的错误。
6. **具体数值反例**：两枚骰子，已知和为 8，求"至少有一枚 3"的概率。正确答案是 $\Pr[A \mid B]=|A \cap B|/|B|=2/5=0.4$。若误答 $|A \cap B|/|\Omega|=2/36=0.0556$，就少了 7.2 倍；若误答 $\Pr[A]=11/36=0.3056$，也没有回答"已知和为 8"这个问题。**脚本验算：$|B|=5$，$|A \cap B|=2$，$|A|=11$，三个数字必须分清。**
7. **防范方法**：每个条件概率题**第一句话就写下** $\Pr[\cdot \mid \cdot]=\frac{\Pr[\cdot \cap \cdot]}{\Pr[\cdot]}$ 的骨架，再把数字填进去。
8. **把不互斥事件当互斥（滥用 $\Pr[A \cup B]=\Pr[A]+\Pr[B]$）**。
9. **具体数值反例**：三枚骰子，至少一枚出现指定数字。错误算法 $3 \times 1/6=1/2$；正确答案 $1-(5/6)^3=91/216 \approx 0.4213$。若按错误算法推广到六枚骰子会得到 $6 \times 1/6=1$（"必然获胜"），显然荒谬。**脚本验算：$91/216=0.42129629\ldots$。**
10. **防范方法**：求并集概率优先考虑**补集**（$1-\Pr[\text{全部不发生}]$，当各事件独立时最省事）或**容斥原理**（L14/L18）。互斥才可以直接相加。
11. **在条件概率中错误地"缩小样本空间"**（把 $\Pr[A \mid B]$ 当作"在 B 里重新数，但忘了权重"）。
12. **具体数值反例**：双罐取球，错误直觉"3 个白球中 2 个在罐 1，故答案是 $2/3$"。正确答案 $4/9 \approx 0.4444$。**错因是罐 1 有 5 个球而罐 2 只有 2 个球，罐 2 的白球被抽中的概率更高**——样本点的权重不同，不能只数个数。
13. **防范方法**：样本空间缩减只在**均匀**空间下等价于纯计数（定理 17.5）。若非均匀，必须用 $\Pr[A \cap B]/\Pr[B]$ 的加权形式。
14. **划分不完整（全概率法则漏情形）**。
15. **具体数值反例**：双罐取球中只算罐 1 那一项，得 $\Pr[f]=0.2$（正确 0.45），进而得 $\Pr[B_1 \mid f]=1$（正确 $4/9$）——**荒谬的确定性结论。**
16. **防范方法**：写完划分 $\{B_1,\ldots,B_n\}$ 后**立刻验证** $\sum_i \Pr[B_i]=1$ 且 B_i 两两不交。做完贝叶斯更新后再验证 $\sum_i \Pr[B_i \mid A]=1$。
17. **把独立与互斥混为一谈**。
18. 互斥：$A \cap B=\varnothing$，故 $\Pr[A \cap B]=0$，在 $\Pr[A],\Pr[B]>0$ 时 $\Pr[A \mid B]=0 \neq \Pr[A]$ —— **互斥事件（几乎）永远不独立，且是极端负相关。**
19. 独立：$\Pr[A \cap B]=\Pr[A]\Pr[B]$，通常 $A \cap B \neq \varnothing$ —— **独立事件通常可以同时发生。**
20. **具体例子**：抛一枚公平硬币，A = "正面"，B = "反面"。$\Pr[A \cap B]=0 \neq \frac{1}{2} \cdot \frac{1}{2}=\frac{1}{4}$，**互斥但不独立**。反之掷两次骰子，"第一次是 1"与"第二次是 1"独立（$\frac{1}{36}=\frac{1}{6} \cdot \frac{1}{6}$）但不互斥（可以都发生）。**"独立"讲的是概率的乘法关系，"互斥"讲的是集合的交集为空——两个完全不同的概念。**
21. **忽略条件独立性 ≠ 独立性（预告 L18）**。两个事件在无条件意义下可能不独立，但在给定某个条件下却独立（反之亦然）。例如某疾病的两种症状在人群中相关（都因同一个病引起），但在"已确诊患该病"的条件下可能独立。**在贝叶斯网络与朴素贝叶斯分类器中，这个区别是模型假设的核心。**

思考题（带答案）

Q1.（纯计算） 掷两枚公平硬币。已知至少有一枚是正面，求两枚都是正面的概率。

▸ 答案

设 A = "两枚都是正面" $=\{HH\}$，B = "至少一枚正面" $=\{HH, HT, TH\}$。均匀样本空间 $\Omega=\{HH,HT,TH,TT\}$，$|\Omega|=4$。

$$\Pr[A\mid B]=\frac{\Pr[A\cap B]}{\Pr[B]}=\frac{|A\cap B|/4}{|B|/4}=\frac{1}{4}\Big/\frac{3}{4}=\frac{1}{3}.$$

脚本验算：$(1/4)/(3/4)=0.3333\ldots$。✓

为什么不是 $1/2$? 这是本讲最经典的陷阱。Ω 有四个等可能样本点，知道"至少一枚正面"后，世界只剩 3 个样本点（HH, HT, TH），其中只有 1 个是 HH，故是 $1/3$。

为什么很多人答 $1/2$? 因为他们错误地把"已知至少一枚正面"当成了"**已知第一枚是正面**"（后者确实给出 $\Pr[\text{两枚都正}\mid\text{第一枚正}]=1/2$）。**两条信息不同，答案就不同。** 这个对比是"条件必须读准"的最好教材。

推广（两孩问题）：一个家庭有两个孩子，"已知至少一个是男孩，求两个都是男孩"的概率是 $1/3$；但"已知老大是男孩，求两个都是男孩"的概率是 $1/2$。**脚本验算：前者 $1/3$（3 种情形中 1 种），后者 $1/2$（B 打头的 2 种情形中 1 种）。**

Q2.（纯计算，疾病检测的变体） 某病患病率 1%。检测灵敏度 99%，特异度 99%。某人检测阳性，求他患病的概率。

▸ 答案

设 D = 患病，$+$ = 阳性。 – 先验：$\Pr[D]=0.01$，$\Pr[\overline{D}]=0.99$。 – 似然：$\Pr[+\mid D]=0.99$，$\Pr[+\mid\overline{D}]=0.01$。

第一步（全概率法则算分母）：

$$\Pr[+]=0.99\times0.01+0.01\times0.99=0.0099+0.0099=0.0198.$$

第二步（贝叶斯）：

$$\Pr[D\mid+]=\frac{0.0099}{0.0198}=0.5=50\%.$$

脚本验算：$0.01\times0.99/(0.01\times0.99+0.99\times0.01)=0.5$。✓

重要观察：当**患病率恰好等于假阳性率**（都是 1%）时，真阳性路径与假阳性路径大小完全相同（都是 0.0099），后验恰为 50%。对比患病率 $1/1000$ 时的 9.02%，可以看到：**后验对先验极度敏感。** 下表（已脚本验算）总结了灵敏度与特异度都固定为 99% 时的情形：

先验患病率	后验 $\Pr[D\mid+]$
0.1%	9.02%
1%	50.00%
5%	83.90%
10%	91.67%
50%	99.00%

自然频率检验（10 万人）：患者 1000 人 → 真阳性 990；健康者 99000 人 → 假阳性 990；阳性总数 1980；比例 $990/1980=50\%$。✓

结论：**同一份检测报告在不同人群中的意义完全不同**——这就是为什么对高危人群筛查比对全人群普查更有价值（先验高 → 后验高）。

Q3.（概念理解 / 找错误） 下面的推理错在哪里?

"某罕见病患病率 $1/1000000$。检测灵敏度 99.9%、特异度 99.9%。张先生检测阳性，医生说'您患病的概率是 99.9%'。"

▸ 答案

错误：医生把似然 $\Pr[+\mid D]$ 当成了后验 $\Pr[D\mid+]$。这是检察官谬误的医学版本。

正确计算： – 先验：$\Pr[D]=10^{-6}$，$\Pr[\overline{D}]=1-10^{-6}$。 – 似然：$\Pr[+\mid D]=0.999$，$\Pr[+\mid\overline{D}]=0.001$（假阳性率）。 – 分母：$\Pr[+]=0.999\times10^{-6}+0.001\times(1-10^{-6})\approx0.999\times10^{-6}+0.000999\approx0.00099999\ldots$ – 后验：

$$\Pr[D\mid+]=\frac{0.999\times10^{-6}}{0.999\times10^{-6}+0.001\times(1-10^{-6})}\approx0.000998=0.0998\%.$$

脚本验算：$0.000998\ldots$，即约 0.1%（不是 99.9%；两者相差约 1000 倍）。

自然频率解释（1 亿人）： – 患者约 100 人 → 真阳性约 $99.9\approx100$ 人。 – 健康者约 99,999,900 人 → 假阳性约 $99{,}999.9\approx100{,}000$ 人。 – 阳性总数约 100,100 人，其中真患者只占约 $1/1000$。

为什么? 因为病太罕见了——健康人的数量是患者的约一百万倍，即使假阳性率只有千分之一，假阳性的**绝对数量**也是真阳性的约一千倍。**后验取决于"路径的绝对大小"（似然 × 先验），而不是似然的单独数值。**

注意（一点补充，避免矫枉过正）：这个计算假设"随机从全人群中抽一个人做检测"。若张先生**因为出现了症状才去检测**，那么他的**先验**就应该是"有该症状者中患此病的比例"，而不是全人群患病率——那个先验会高得多。**贝叶斯的结论依赖于先验的选择；先验错了，后验也会错。** 这也是"医生说 99.9% 是错的、说 0.1% 也可能是错的"的原因：关键在于**用对了哪个先验**。

Q4.（证明） 证明：若 $\Pr[A]>0$ 且 $\Pr[B]>0$，则 A 与 B 独立 $\iff \Pr[A\mid B]=\Pr[A]$。并说明为什么这个等价在 $\Pr[B]=0$ 时不成立。

> ▸ 答案
>
> **证明策略**：双向蕴含，两个方向都是"定义式移项"。**（⇒）方向用定义，（⇐）方向用乘法法则。**
>
> **（⇒）设 A 与 B 独立**，即 $\Pr[A\cap B]=\Pr[A]\Pr[B]$。因为 $\Pr[B]>0$，可以除以 $\Pr[B]$：
>
> $$\Pr[A\mid B]=\frac{\Pr[A\cap B]}{\Pr[B]}=\frac{\Pr[A]\Pr[B]}{\Pr[B]}=\Pr[A]. \qquad \checkmark$$
>
> **（⇐）设 $\Pr[A\mid B]=\Pr[A]$**。由条件概率的定义，
>
> $$\frac{\Pr[A\cap B]}{\Pr[B]}=\Pr[A].$$
>
> 两边乘 $\Pr[B]>0$，得 $\Pr[A\cap B]=\Pr[A]\Pr[B]$，即 A 与 B 独立。✓
>
> 由对称性（交换 A,B 并注意 $\Pr[A]>0$），同样可证 $\Pr[B\mid A]=\Pr[B]$ 也是等价的。■
>
> **为什么 $\Pr[B]=0$ 时不成立？** 两方面的原因： 1. $\Pr[A\mid B]$ **根本无定义**——定义式要求除以 $\Pr[B]$，不能除以零。所以"$\Pr[A\mid B]=\Pr[A]$"这句话在 $\Pr[B]=0$ 时连**是否为真**都谈不上。 2. **集合论/测度论的微妙之处**：若 $\Pr[B]=0$，则无论 $\Pr[A\cap B]$ 是多少（只能为 0，因为 $A\cap B\subseteq B$），独立性条件 $\Pr[A\cap B]=\Pr[A]\Pr[B]$ 都退化为 $0=0$，**恒真**。也就是说：**在独立性定义下，任何零概率事件都与所有事件"独立"，但这并不意味着它在直觉上"无关"。**
>
> **具体例子**：抛一枚公平硬币两次。令 $B=\varnothing$（空事件，$\Pr[B]=0$），$A=\{HH\}$。则 $\Pr[A\cap B]=0=\Pr[A]\cdot 0$，按定义独立。但"在 B 发生的前提下 A 的概率"这一说法毫无意义（B 不可能发生）。
>
> **结论与防范**：独立性定义（乘积形式）在 $\Pr[B]=0$ 时仍然良定义并有意义，而条件概率的等价形式（$\Pr[A\mid B]=\Pr[A]$）只在正概率时可用。**两者不可互换使用，务必记住条件 $\Pr[B]>0$。** 这也是 CS70 官方 Note 在陈述"独立性 $\iff$ 条件概率不变"时明确要求 $\Pr[B]>0$ 的原因。

Lecture 18: Independence & Combination of Events（独立性与事件组合）

概述

到目前为止，我们讨论的都是一次实验、一个事件。但计算机系统里的"坏事情"几乎从来不是单一事件：一个分布式系统可能因为"某台机器宕机"**或**"网络丢包"**或**"磁盘写满"**而失效；一次哈希表的查找失败，可能是**"第 1 对元素撞车"**或**"第 2 对元素撞车"**或……因此本讲要回答的核心问题是：**当复杂事件是由若干简单事件经"且"（交 $\bigcap_i A_i$）与"或"（并 $\bigcup_i A_i$）组合出来时，如何计算它的概率？**

一般的答案很悲观——计算 $\Pr[\bigcap_i A_i]$ 和 $\Pr[\bigcup_i A_i]$ 在最坏情况下需要知道 2^n 个量，毫不比直接枚举样本空间便宜。本讲给出两类"可计算"的情形：**独立性 (independence)** 让交运算简化为乘法，**容斥原理 (Inclusion–Exclusion)** 与**并集上界 (Union Bound)** 让并运算可以被精确刻画或被安全地放大。最后，我们要澄清 CS70 中最经典的一组混淆：**不交 (disjoint) 与独立 (independent) 完全不是一回事**。

核心概念的直观解释

独立事件 (Independent Events)

- **定义**：设 $A,B\subseteq\Omega$ 是同一概率空间中的两个事件。称 A 与 B **独立 (independent)**，当且仅当
$$\Pr[A\cap B]=\Pr[A]\cdot\Pr[B].$$
- **直观解释（"它是什么意思？"）**：独立的意思是"**知道 B 是否发生，不会改变你对 A 的判断**"。用条件概率的语言说：若 $\Pr[B]>0$，则 A,B 独立当且仅当 $\Pr[A\mid B]=\Pr[A]$。

现实类比：连续抛一枚公平硬币，前十次都是反面，并不让第十一次更可能是正面——硬币**没有记忆**。反面则是摸牌：如果前十张牌全是红色（红心或方块），那么剩下的牌堆里红色只剩 16 张、黑色还有 26 张，下一张是红色的概率变成 $16/42=8/21\approx 0.381$，而不是原来的 $1/2$。牌堆**有记忆**，所以前后两次摸牌**不独立**。

- **为什么选用乘积形式？** 条件概率的形式 $\Pr[A\mid B]=\Pr[A]$ 有一个技术上的不便：它要求 $\Pr[B]>0$，否则 $\Pr[A\mid B]$ 根本没有定义。而乘积形式 $\Pr[A\cap B]=\Pr[A]\Pr[B]$ 在 $\Pr[B]=0$ 时也完全良定义（两边都是 0）。因此**乘积形式是定义，条件概率形式是（在正概率条件下的）等价刻画**，而不是反过来。
- **具体示例（最底层的积木）**：抛两枚公平硬币。样本空间 $\Omega=\{HH,HT,TH,TT\}$，每个样本点概率 $1/4$。令 A = "第一枚是 H"，B = "第二枚是 H"。则 $\Pr[A]=\Pr[B]=1/2$，且 $A\cap B=\{HH\}$，$\Pr[A\cap B]=1/4=\frac{1}{2}\cdot\frac{1}{2}$。故 A,B 独立。整个概率论里所有的"独立"直觉，最终都要能在这两枚硬币上算穿。

相互独立 (Mutual Independence)

- **定义**：事件 $A_1,\dots,A_n$ **相互独立**，当且仅当**对每一个大小 $|I|\geq 2$ 的子集 $I\subseteq\{1,\dots,n\}$ 都有**
$$\Pr\left[\bigcap_{i\in I}A_i\right]=\prod_{i\in I}\Pr[A_i].$$
- **直观解释**：注意"每一个子集"这个措辞——**不是**只要求整体乘积成立，而是要求**所有规模 ≥ 2 的子集**都成立。n 个事件一共给出 2^n-n-1 个约束（去掉 $|I|=0$ 的 1 个和 $|I|=1$ 的 n 个，它们都是恒等式、不构成约束）。
- **等价定义（另一个常用形式）**：$A_1,\dots,A_n$ 相互独立，当且仅当对每个 i，无论 B_i 取 A_i 还是取补集 $\overline{A_i}$，都有

$$\Pr[B_1 \cap \cdots \cap B_n] = \prod_{i=1}^{n} \Pr[B_i].$$

这个形式给出 2^n 个约束，其中恰好有 $n+1$ 个是被其余约束蕴含的（多余的），所以两个定义等价。

- **具体示例**：抛 n 次公平硬币，"第 i 次是 H" 这 n 个事件相互独立。故"前三次全是 H"的概率是 $\frac{1}{2}\cdot\frac{1}{2}\cdot\frac{1}{2}=\frac{1}{8}$，与样本空间直接计数得到的 $1/8$ 一致——这其实反过来**验证了**我们在建立概率空间时把每个样本点赋权 2^{-n} 是自洽的。

不交 / 互斥 (Disjoint / Mutually Exclusive)

- **定义**：事件 A, B **不交（互斥）**，当且仅当作为**集合**它们没有公共元素：

$$A \cap B = \emptyset \quad \Longleftrightarrow \quad \Pr[A \cap B] = 0.$$

一族事件 $A_1, \ldots, A_n$ 互斥，指对一切 $i \neq j$ 都有 $A_i \cap A_j = \emptyset$。

- **直观解释**：不交说的是"**这两件事不可能同时发生**"，是一个集合论/逻辑层面的陈述；独立说的是"**知道一件是否发生不改变另一件的概率**"，是一个概率数值层面的陈述。**两者之间没有蕴含关系**，这正是下一节要重点算穿的东西。生活类比：不交 ="今天下雨"与"今天不下雨"（不可能同时）；独立 ="今天下雨"与"我在北京抛硬币得到正面"（互不影响，但可以同时发生）。
- **具体示例**：掷一枚公平骰子，$A=\{1,2\}$，$B=\{3,4\}$。这是不交的：$\Pr[A\cap B]=0$。而 $\Pr[A]\Pr[B]=\frac{1}{3}\cdot\frac{1}{3}=\frac{1}{9}\neq 0$，所以它们**不独立**。

条件独立 (Conditional Independence)

- **定义**：给定事件 C（$\Pr[C]>0$），称 A 与 B **在给定 C 下条件独立**，当且仅当

$$\Pr[A \cap B \mid C] = \Pr[A \mid C] \cdot \Pr[B \mid C].$$

等价地，把条件概率展开：$\Pr[A \mid B \cap C] = \Pr[A \mid C]$（当 $\Pr[B\cap C]>0$）——"在已知 C 的圈子里，B 的发生不再改变 A 的概率"。

- **直观解释**：条件独立是"**在一个更小的世界 C 里重新审视独立性**"。它和原始独立性是两件不同的事，因为把样本空间缩小到 C 之后，事件之间的统计关系可能被彻底改写（原本独立的两件事，可能在给定 C 之后变得完全绑定；反之亦然）。
- **具体示例（预告反例）**：抛两枚公平硬币，令 C = "两枚结果相同"。在 C 内部，样本空间只剩 $\{HH, TT\}$，各占一半。此时"第一枚是 H"与"第二枚是 H"**不再独立**——知道第一枚是 H 就**必然**知道第二枚也是 H。

相关性 (Correlation)

- **定义**：若一对事件**不**独立，就称它们**相关 (correlated)**。特别地，若 $\Pr[A \mid B] > \Pr[A]$（等价地 $\Pr[B \mid A] > \Pr[B]$），称 A, B **正相关 (positively correlated)**；若 $\Pr[A \mid B] < \Pr[A]$，称它们**负相关 (negatively correlated)**。
- **直观解释**：正相关 = "一件事发生让另一件事更可能发生"（例如"轮胎漏气"与"车开不动"）；负相关 = "一件事发生让另一件事更不可能发生"（例如"牌堆里前几张都是红"与"下一张是红"）。

并集上界 (Union Bound / Boole 不等式)

- **定义**：对任意事件 $A_1, \ldots, A_n$（**不需要任何独立性假设**），

$$\Pr\left[\bigcup_{i=1}^{n} A_i\right] \leq \sum_{i=1}^{n} \Pr[A_i].$$

- **直观解释**：把各个 $\Pr[A_i]$ 加起来只会**高估**并集的概率，因为交叠部分的样本点被重复计入了。粗糙，但在算法分析里极其实用——它是"至少有一个坏事件发生"的第一道防线，而且**完全不需要知道事件之间的相关结构**。

完整证明与推导（核心）

定理 18.1（独立性的条件概率刻画）：设 $\Pr[B]>0$。则 A 与 B 独立 $\Longleftrightarrow \Pr[A\mid B]=\Pr[A]$。对称地，若 $\Pr[A]>0$，则 A 与 B 独立 $\Longleftrightarrow \Pr[B\mid A]=\Pr[B]$。

证明策略：双向蕴含，两边都只需把条件概率的定义代进去做代数变形（直接证明）。关键在于说明这不是两个不同的定义，而是同一个条件的两种写法。

逐步推导：

（$\Rightarrow$）假设 $\Pr[A\cap B]=\Pr[A]\Pr[B]$。由条件概率定义（讲次 17 的定义 17.1），

$$\Pr[A\mid B]=\frac{\Pr[A\cap B]}{\Pr[B]}=\frac{\Pr[A]\Pr[B]}{\Pr[B]}=\Pr[A],$$

最后一步用了 $\Pr[B]>0$ 从而可以约分。

（$\Leftarrow$）假设 $\Pr[A\mid B]=\Pr[A]$。由定义 $\Pr[A\mid B]=\dfrac{\Pr[A\cap B]}{\Pr[B]}$，两边同乘 $\Pr[B]>0$ 得

$$\Pr[A\cap B]=\Pr[A]\cdot\Pr[B],$$

这正是独立的定义。

对称那一半：只需在上面的论证中把 A, B 互换，并注意 $\Pr[A\cap B]=\Pr[B\cap A]$ 以及 $\Pr[A]>0$ 的条件。

【证明机制解说】：这个定理的全部内容就是"**除法**"——独立性的乘积形式里，$\Pr[B]$ 扮演了归一化因子的角色。条件概率的定义 $\Pr[A\mid B]=\Pr[A\cap B]/\Pr[B]$ 本质上是在做"把 B 内部的总概率重新缩放成 1"这件事；当 $A\cap B$ 在 B 里占的比例恰好等于 A 在整个 Ω 里占的比例时，缩放没有改变任何东西，这就是独立。反过来，当 $\Pr[B]=0$ 时缩放因子是 $0/0$，无法定义条件概率，所以**定义必须选乘积形式**。

反例（条件不可省）：若去掉 $\Pr[B]>0$，"$\Pr[A\mid B]=\Pr[A]$ 蕴含独立"就失效了——因为左边压根没有定义，命题连陈述都构不成。这不是吹毛求疵：在连续概率（讲次 24）中，单个点的事件概率为 0 是家常便饭。

定理 18.2（乘积法则 / 链式法则，Product Rule / Chain Rule）：对任意事件 $A_1,\dots,A_n$，

$$\Pr\left[\bigcap_{i=1}^{n}A_i\right]=\Pr[A_1]\cdot\Pr[A_2\mid A_1]\cdot\Pr[A_3\mid A_1\cap A_2]\cdots\Pr\left[A_n\mid\bigcap_{i=1}^{n-1}A_i\right].$$

当 $A_1,\dots,A_n$ 相互独立时，右端每个条件概率 $\Pr[A_i\mid\bigcap_{j<i}A_j]$ 都等于 $\Pr[A_i]$，于是化简为纯粹的产品：

$$\Pr\left[\bigcap_{i=1}^{n}A_i\right]=\prod_{i=1}^{n}\Pr[A_i].$$

证明策略：对事件个数 n 做**归纳法 (induction)**。用归纳法的原因是：链式法则天然是"层层剥壳"的结构——把最后一个事件 A_n 从交集中拆出来，剩下的部分正好是 $n-1$ 个事件的交集，形状完全一样。这与讲次 3 中"归纳法处理参数为 n 的递归结构"完全同构。

逐步推导：

基础情形：$n=1$ 时命题是 $\Pr[A_1]=\Pr[A_1]$，恒真。

归纳假设：设对 $n-1$ 个事件命题成立，即

$$\Pr\left[\bigcap_{i=1}^{n-1}A_i\right]=\Pr[A_1]\cdot\Pr[A_2\mid A_1]\cdots\Pr\left[A_{n-1}\mid\bigcap_{i=1}^{n-2}A_i\right].$$

归纳步骤：把 $\bigcap_{i=1}^{n}A_i$ 看作两个事件的交：事件 A_n 与事件 $B:=\bigcap_{i=1}^{n-1}A_i$。由条件概率的定义 $\Pr[A_n\mid B]=\Pr[A_n\cap B]/\Pr[B]$（此处需 $\Pr[B]>0$），两边同乘 $\Pr[B]$ 得

$$\Pr\left[\bigcap_{i=1}^{n}A_i\right]=\Pr[A_n\cap B]=\Pr\left[A_n\mid\bigcap_{i=1}^{n-1}A_i\right]\cdot\Pr\left[\bigcap_{i=1}^{n-1}A_i\right].$$

再把归纳假设代入右端第二个因子：

$$\Pr\left[\bigcap_{i=1}^{n}A_i\right]=\Pr\left[A_n\mid\bigcap_{i=1}^{n-1}A_i\right]\cdot\Pr[A_1]\cdot\Pr[A_2\mid A_1]\cdots\Pr\left[A_{n-1}\mid\bigcap_{i=1}^{n-2}A_i\right].$$

这正是命题中 n 的情形（各项顺序可以随意交换，乘法可交换）。归纳完成。

【证明机制解说】：链式法则的"灵光一现"在于**不要试图一次算完整个交集**，而是把它拆成"第一步怎么走、在已走第一步的前提下第二步怎么走、……"。这把一个高维计数问题降成了一条**决策路径**：只要每一步的条件概率好算，整条路径的概率就是它们的乘积。这和讲次 14 的"第一/第二计数法则"（把选择过程拆成有序的步骤）是同一个思想在概率里的化身。

反例（独立条件的必要性）：回到 $A=$"第一张牌是 A"、$B=$"第二张牌是 A"（52 张牌无放回抽 2 张）。$\Pr[A]=\frac{4}{52}=\frac{1}{13}$，$\Pr[B]=\frac{1}{13}$。若错误地套用乘积形式（以为独立），会得到 $\Pr[A\cap B]=\frac{1}{169}\approx 0.00592$；而由条件概率算：

$$\Pr[A\cap B]=\Pr[A]\cdot\Pr[B\mid A]=\frac{4}{52}\cdot\frac{3}{51}=\frac{12}{2652}=\frac{1}{221}\approx 0.004525.$$

两者不等，$1/221<1/169$，说明"第一张是 A"这个信息**降低**了第二张是 A 的概率（负相关）。**链式法则永远成立，乘积形式只在独立时才成立。**

定理 18.3（不交 + 正概率 $\Rightarrow$ 不独立）：设 $\Pr[A]>0$ 且 $\Pr[B]>0$。若 A 与 B 不交（即 $A\cap B=\emptyset$），则 A 与 B 一定**不独立**。

证明策略：反证法 / 直接比较数值。这是本讲最重要的"一句话洞察"，因为它是学生在考试中最高频的失分点。

逐步推导：

1. 由 $A\cap B=\emptyset$，交集的概率为 $\Pr[A\cap B]=\Pr[\emptyset]=0$（概率公理：空集的概率为 0，见讲次 15）。
2. 由假设 $\Pr[A]>0$ 与 $\Pr[B]>0$，乘积 $\Pr[A]\Pr[B]>0$。
3. 于是 $\Pr[A\cap B]=0\neq\Pr[A]\Pr[B]>0$。
4. 按定义 18.1，A 与 B 不独立。■

【证明机制解说】：证明只有三行，但结论极具反直觉性，所以值得反复咀嚼。它的机制是：**不交是一个"极端强"的负相关**——不但知道 B 发生改变了 A 的概率，而是把它变成了 0。所以不交不是"独立的一种"，恰恰是"最不独立的一种"。只有在退化的边界情形下（$\Pr[A]=0$ 或 $\Pr[B]=0$）两者才能共存：此时交集概率 0 与乘积 0 相等，独立性成立但空洞无物。

反例 / 数值对照（骰子）：掷一枚公平骰子，$A=\{1,2\}$，$B=\{3,4\}$。

量	值	说明
$\Pr[A]$	$2/6=1/3$	集合大小 2，均匀分布
$\Pr[B]$	$2/6=1/3$	集合大小 2
$\Pr[A\cap B]$	0	A,B 不交

量	值	说明
$\Pr[A]\Pr[B]$	$1/9 \approx 0.1111$	若独立应等于这个数
结论	$0 \neq 1/9$	**不交 ⇒ 不独立**

再看一个更有代入感的例子：$A=\{1,2\}$ 与 $\bar{A}=\{3,4,5,6\}$。$\Pr[A]=1/3$，$\Pr[\bar{A}]=2/3$，乘积 $2/9\approx 0.2222$，而 $\Pr[A\cap\bar{A}]=0$。同样是"不交故不独立"。

定理 18.4（容斥原理的概率形式，Inclusion–Exclusion）：设 $A_1,\dots,A_n$ 是同一概率空间中的事件。则

$$\Pr\left[\bigcup_{i=1}^{n} A_i\right] = \sum_{k=1}^{n} (-1)^{k-1} \sum_{S\subseteq\{1,\dots,n\},\,|S|=k} \Pr\left[\bigcap_{i\in S} A_i\right].$$

写成展开式，$n=2$ 时 $\Pr[A\cup B]=\Pr[A]+\Pr[B]-\Pr[A\cap B]$；$n=3$ 时

$$\Pr[A\cup B\cup C]=\Pr[A]+\Pr[B]+\Pr[C]-\Pr[A\cap B]-\Pr[A\cap C]-\Pr[B\cap C]+\Pr[A\cap B\cap C].$$

证明策略：**逐样本点双计数 / 指示变量配平**。要证"两个数相等"，最稳的办法是证明"对每个样本点 ω，两边把 ω 的贡献算得一样多"。这正是讲次 14 中容斥原理证明的翻版：那里数的是集合的元素个数，这里数的是概率质量。

逐步推导：

1. 固定任意样本点 $\omega\in\Omega$。设立方体 $r(\omega)=|\{i : \omega\in A_i\}|$，即 ω 落在多少个事件里。
2. 左端：$\omega\in\bigcup_i A_i$ 当且仅当 $r(\omega)\geq 1$。故左端在 ω 处的"贡献"是 $P[\omega]\cdot\mathbf{1}[r\geq 1]$。
3. 右端：ω 落在 $\bigcap_{i\in S}A_i$ 中当且仅当 $S\subseteq\{i:\omega\in A_i\}$，这样的 S 有 $\binom{r}{k}$ 个大小为 k 的。所以右端在 ω 处的贡献是

$$P[\omega]\cdot\sum_{k=1}^{r}(-1)^{k-1}\binom{r}{k}.$$

1. 用二项式定理的配对恒等式：$\sum_{k=0}^{r}(-1)^k\binom{r}{k}=(1-1)^r=0$，故

$$\sum_{k=1}^{r}(-1)^{k-1}\binom{r}{k}=\binom{r}{0}-0=1.$$

1. 于是当 $r\geq 1$ 时右端在 ω 处的贡献恰为 $P[\omega]\cdot 1$，与左端相等；当 $r=0$ 时两边贡献都是 0。逐点相等，故总和相等。■

【证明机制解说】：容斥原理看起来像"加了又减、减了又加"的杂技，但机制其实非常朴素：**每个样本点的"被计入次数"必须配平成 1（在并集里）或 0（在并集外）**。第 4 步的二项式恒等式 $\sum_k(-1)^k\binom{r}{k}=0$（$r\geq 1$）就是配平用的砝码。这也解释了为什么符号必须是交错的正负。

n=3 的完整算例（拉斯维加斯骰子游戏）：你选一个 1 到 6 之间的数字，掷三枚公平骰子；只要你的数字出现在**至少一枚**骰子上就赢。赌场声称胜率是 50%，理由是"每枚骰子命中概率 $1/6$，三枚加起来 $3\times 1/6=1/2$"。

这个算法错在把**不交**当成默认前提：三枚骰子可以同时命中，样本点被重复计数。用容斥修正：

$$\Pr[A_1\cup A_2\cup A_3]=3\cdot\frac{1}{6}-3\cdot\frac{1}{36}+\frac{1}{216}=\frac{108-18+1}{216}=\frac{91}{216}\approx 0.4213.$$

其中 A_i = "第 i 枚骰子是所选数字"；由于骰子之间**相互独立**，$\Pr[A_i\cap A_j]=(1/6)^2=1/36$、$\Pr[A_1\cap A_2\cap A_3]=1/216$。

交叉验证（互补技巧）：$\Pr[\text{一枚都不中}]=(5/6)^3=125/216$，故胜率 $=1-125/216=91/216$。两种算法完全吻合（脚本验算：$91/216=0.421296$，$1-(5/6)^3=0.421296$）。

赌场"掷六枚必胜"的推理错得更离谱：$6\times 1/6=1$ 只说明"和式 ≥ 1"，而真实概率是 $1-(5/6)^6\approx 0.6651$。这直接预告了 Union Bound 的存在——**概率之和只能当上界**。

容斥的代价：n 个事件需要枚举全部 2^n-1 个非空子集。$n=60$ 时这是 10^{18} 量级，完全不可行。好消息是容斥的**交错和是单调收敛的**：第一项（$\sum\Pr[A_i]$）是上界，减掉两两交后是下界，再加回来又是上界…… 每一步都在逼近真值。所以实践中常常只取前一两项。

定理 18.5（Union Bound / Boole 不等式）：对任意概率空间中的任意事件 $A_1,\dots,A_n$，

$$\Pr\left[\bigcup_{i=1}^{n}A_i\right]\leq\sum_{i=1}^{n}\Pr[A_i].$$

证明策略：对 n 做**归纳法**。用归纳法而不是"引用容斥"是因为：容斥是对精确值的等式，而 Union Bound 是一个**不等式**，归纳证的每一步都只需要"扔掉了非负的修正项"，干净利落，而且不需要 $\Pr$ 是均匀的、不需要独立性、不需要任何额外假设。

逐步推导：

基础情形：$n=1$ 时命题是 $\Pr[A_1]\leq\Pr[A_1]$，成立。

归纳假设：设对 $n-1$ 个事件有 $\Pr[\bigcup_{i=1}^{n-1}A_i]\leq\sum_{i=1}^{n-1}\Pr[A_i]$。

归纳步骤：由容斥（$n=2$ 的形式），

$$\Pr\left[\bigcup_{i=1}^{n} A_i\right] = \Pr\left[\bigcup_{i=1}^{n-1} A_i\right] + \Pr[A_n] - \Pr\left[\left(\bigcup_{i=1}^{n-1} A_i\right) \cap A_n\right].$$

最后那个交集的概率 ≥ 0，把它丢掉只会让右端**变大**，故

$$\Pr\left[\bigcup_{i=1}^{n} A_i\right] \leq \Pr\left[\bigcup_{i=1}^{n-1} A_i\right] + \Pr[A_n] \leq \sum_{i=1}^{n-1} \Pr[A_i] + \Pr[A_n] = \sum_{i=1}^{n} \Pr[A_i],$$

中间一步用了归纳假设。归纳完成。■

【证明机制解说】：Union Bound 的全部内容就是"**把负项扔掉**"。容斥告诉我们并集 $=$ 和 $-$ 两两交 $+$ 三三交 $-\cdots$，而 Union Bound 只保留第一项。它的价值不在于精确，而在于**普适**：在算法分析里我们常常既不知道事件是否独立、也不愿意枚举 2^n 个子集，此时一个"绝对安全的高估"往往已经足够说明问题（比如证明"失败概率 $< 1/100$ 需要多少个哈希函数"）。

反例 / 松紧度演示（生日问题，呼应讲次 15）：设一屋子有 $n = 23$ 人，令 $A_{\{i,j\}}$ = "第 i, j 人同生日"。则"存在一对同生日" $= \bigcup_{\{i,j\}} A_{\{i,j\}}$。

- Union Bound 路线：$\Pr[\exists \text{ 同生日}] \leq \sum_{\{i,j\}} \Pr[A_{\{i,j\}}] = \binom{23}{2} \cdot \frac{1}{365} = \frac{253}{365} \approx 0.6932$。不需要独立性。
- 互补 + 独立性路线：$\Pr[\text{无人同生日}] = \prod_{i=0}^{22} \frac{365-i}{365}$，故 $\Pr[\exists] \approx 0.5073$。

Union Bound 给出的 0.6932 比真值 0.5073 高出一截，但已经把"够呛"这件事说清楚了。要拿到精确值则必须用互补 + 乘积，这需要**独立性**。

反例 18.1（两两独立 $\neq$ 相互独立）—— CS70 必考经典

这是本讲的"镇讲之宝"。**命题**：存在三个事件 A, B, C，其中**每一对**都独立（两两独立，pairwise independent），但三者**不**相互独立。

构造：抛两枚公平硬币，样本空间 $\{HH, HT, TH, TT\}$，各概率 $1/4$。定义

- A：第一枚是 H；
- B：第二枚是 H；
- C：两枚结果**相同**（都是 H，或都是 T），即 $C = \{HH, TT\}$。

逐步推导（完整算出所有概率）：

1. 单个事件的概率：

$$\Pr[A] = |\{HH, HT\}|/4 = 1/2, \qquad \Pr[B] = |\{HH, TH\}|/4 = 1/2, \qquad \Pr[C] = |\{HH, TT\}|/4 = 1/2.$$

1. 两两交集（逐个枚举，不做任何"想当然"）：

$$A \cap B = \{HH\} \Rightarrow \Pr[A \cap B] = 1/4, \quad A \cap C = \{HH\} \Rightarrow \Pr[A \cap C] = 1/4, \quad B \cap C = \{HH\} \Rightarrow \Pr[B \cap C] = 1/4.$$

1. 与乘积比较：

$$\Pr[A]\Pr[B] = \tfrac{1}{4} = \Pr[A \cap B] \checkmark, \qquad \Pr[A]\Pr[C] = \tfrac{1}{4} = \Pr[A \cap C] \checkmark, \qquad \Pr[B]\Pr[C] = \tfrac{1}{4} = \Pr[B \cap C] \checkmark.$$

所以 A, B, C **两两独立**。

1. 但三重交集：$A \cap B \cap C = \{HH\}$，故

$$\Pr[A \cap B \cap C] = \frac{1}{4} = 0.25, \qquad \Pr[A]\Pr[B]\Pr[C] = \frac{1}{8} = 0.125.$$

$0.25 \neq 0.125$，所以 A, B, C **不相互独立**。

1. 用条件概率看更刺激：$\Pr[C \mid A \cap B] = \dfrac{\Pr[A \cap B \cap C]}{\Pr[A \cap B]} = \dfrac{1/4}{1/4} = 1$。也就是说，**一旦知道前两枚都是 H，C 就必然发生**——条件概率被"炸"到了 1，而边缘概率只有 $1/2$。

概率表（可直接背诵）：

```
样本空间 Ω = {HH, HT, TH, TT}，每点概率 1/4

  ω   |  A(第1枚H) | B(第2枚H) | C(两枚相同) | 概率
------+------------+-----------+-------------+------
  HH  |     1      |     1     |      1      | 1/4
  HT  |     1      |     0     |      0      | 1/4
  TH  |     0      |     1     |      0      | 1/4
  TT  |     0      |     0     |      1      | 1/4
------+------------+-----------+-------------+------
  边缘 |   2/4=1/2  |   2/4=1/2 |    2/4=1/2  |  1

两两检查（3 个条件全部成立）：
  Pr[A∩B] = 1/4 = Pr[A]·Pr[B] = 1/4   ✓
  Pr[A∩C] = 1/4 = Pr[A]·Pr[C] = 1/4   ✓
  Pr[B∩C] = 1/4 = Pr[B]·Pr[C] = 1/4   ✓
三重检查（1 个条件失败）：
  Pr[A∩B∩C] = 1/4  ≠  Pr[A]·Pr[B]·Pr[C] = 1/8   ✗
```

【证明机制解说】：为什么两两独立不蕴含相互独立？因为"两两独立"给出的条件是 3 个（对 $n=3$ 是 $\binom{3}{2}=3$ 个），而相互独立要求的是 $2^3-3-1=4$ 个条件——**少了一个**。这多出来的第 4 个条件正是三重交集那一条，而它恰恰是最容易被忽略、也最容易被 C 这种"定义在 A,B 组合之上"的事件破坏的。构造的精髓在于：让 C 完全由 A,B 决定（$C=\{A=B\}$），于是 C 与每个单独的事件都"看不出关联"（因为单看一枚硬币无法判断是否相同），但一旦两枚都看到，C 就毫无悬念。

推广：这个构造可以推广到 n 个事件（如 n 枚硬币的奇偶性构造），它们仍然两两独立（甚至任意 $n-1$ 个都独立），但全体不独立。所以"两两独立"与"相互独立"之间的鸿沟可以任意大。

反例 18.2（条件独立与独立互不蕴含）—— 高频考点

这里有两个方向，都必须掌握。

方向一：独立 $\not\Rightarrow$ 条件独立。

沿用上面的两枚硬币，令 C = "两枚结果相同"。我们已经知道 $A=$"第一枚 H"与 $B=$"第二枚 H"是**独立**的（$\Pr[A\cap B]=1/4=1/2\cdot 1/2$）。但在给定 C 之下：

$$\Pr[A\cap B\mid C]=\frac{\Pr[A\cap B\cap C]}{\Pr[C]}=\frac{1/4}{1/2}=\frac{1}{2},$$

$$\Pr[A\mid C]\cdot\Pr[B\mid C]=\frac{\Pr[A\cap C]}{\Pr[C]}\cdot\frac{\Pr[B\cap C]}{\Pr[C]}=\frac{1/4}{1/2}\cdot\frac{1/4}{1/2}=\frac{1}{2}\cdot\frac{1}{2}=\frac{1}{4}.$$

$\frac{1}{2}\neq\frac{1}{4}$，所以 **$A,B$ 在给定 C 下不条件独立**。直观：C 是"把两枚硬币绑在一起"的胶水，一旦知道两枚相同，两枚的结果就完全同步了。**独立性可以被"多加一个条件"摧毁。**

方向二：条件独立 $\not\Rightarrow$ 独立。

这也叫"**辛普森式混合 (mixture)**"现象。设想有两台出厂时被焊接死的硬币机：

- 以 $1/2$ 的概率选中"全 H 机"：两枚硬币**必定**都出 H；
- 以 $1/2$ 的概率选中"全 T 机"：两枚硬币**必定**都出 T。

令 C = "选中的是全 H 机"，$\Pr[C]=1/2$。令 A = 第一枚出 H，B = 第二枚出 H。

1. 条件独立检查：给定 C（全 H 机），A 与 B 都必然发生，$\Pr[A\mid C]=\Pr[B\mid C]=1$，$\Pr[A\cap B\mid C]=1$，故 $1=1\cdot 1$ ✓。同理在给定 $\bar{C}$（全 T 机）下 A,B 的概率都是 0，条件独立也成立。
2. 但**边缘**上它们绝不独立：$\Pr[A]=\frac{1}{2}\cdot 1+\frac{1}{2}\cdot 0=\frac{1}{2}$，同理 $\Pr[B]=\frac{1}{2}$，而

$$\Pr[A\cap B]=\tfrac{1}{2}\cdot 1+\tfrac{1}{2}\cdot 0=\frac{1}{2}\neq\frac{1}{4}=\Pr[A]\Pr[B].$$

事实上 $\Pr[B\mid A]=1\neq 1/2=\Pr[B]$，$A$ 发生**完全决定**了 B。所以 A,B 条件独立（在 C 与 $\bar{C}$ 下都成立）却**不独立**。

【证明机制解说】：两个方向的机制可以统一理解——**独立是关于"一个固定概率空间"的性质，条件独立是关于"该空间的一个子集"的性质**。把空间切成片之后，每一片里的统计关系可以完全不同于整体（方向二：每片内部都独立，混合起来就强相关）；把空间缩小之后，原本无关的变量也可能被同一个条件"连坐"（方向一：整体独立，到了片内就绑死）。这与讲次 17 中"条件概率是换了一个样本空间看问题"的观点一脉相承。

与经典问题的联系

1. 纠错码与网络传输：需要多少冗余包？（呼应讲次 8 的 Berlekamp–Welch）

设我们要把 n 个数据包编码成 $n+k$ 个包，使得收到**任意** n 个即可重建原始数据（讲次 8 的多项式插值 + Berlekamp–Welch 纠错机制）。现实中丢包是随机的：设每个包独立地以概率 p 丢失。则收到的包数 $X\sim\mathrm{Bin}(n+k,\,1-p)$（这正是讲次 19 要讲的二项分布；这里先借用），成功解码的概率是

$$\Pr[X\geq n]=\sum_{i=n}^{n+k}\binom{n+k}{i}(1-p)^i p^{\,n+k-i}.$$

例如 $n=10$、$p=0.1$ 时，脚本验算给出：$k=3$ 时为 0.965839，$k=5$ 时为 0.997750，$k=8$ 时已达 0.999979。**"每个包丢失是独立事件"这个假设，正是让我们能把 $n+k$ 次伯努利试验的概率乘起来的关键**——没有独立性，这个和式根本无法写出闭式。

2. 哈希与负载均衡：碰撞概率的安全上界

把 m 个键哈希到 n 个桶。令 $A_{\{i,j\}}$ = "第 i,j 个键落到同一桶"，$\Pr[A_{\{i,j\}}]=1/n$。则

$$\Pr[\text{存在碰撞}]\leq\binom{m}{2}\cdot\frac{1}{n},$$

这是纯粹的 Union Bound，**不需要假设哈希值之间独立**（只需要每对均匀，这由哈希函数的性质保证）。$m=20,n=365$ 时上界是 $\binom{20}{2}/365=190/365\approx 0.5205$，真实值（生日模型）是 0.4114——上界只高估了 0.11，却省掉了全部 109 项容斥计算。

3. 系统可靠性：至少一种故障发生

设系统有 n 种故障模式，第 i 种发生的概率为 $\Pr[A_i]$。系统失效 $=\bigcup_i A_i$。工程上常做两件事：

- **上界**（保守估计，用于安全论证）：$\Pr[\text{失效}]\leq\sum_i\Pr[A_i]$，不需要独立性。
- **精确值**（当各故障模式独立时，例如互为冗余的独立部件）：$\Pr[\text{正常}]=1-\Pr[\text{失效}]=\prod_i(1-\Pr[A_i])$。这就是"**串联系统的可靠性是各部件可靠性之积**"的来源：n 个可靠性各为 $1-\epsilon$ 的独立部件串联，整体可靠性只有 $(1-\epsilon)^n\approx e^{-n\epsilon}$——**指数衰减**。这也解释了为什么"至少一次命中"型问题（$1-(1-p)^m$）总

是指数逼近 1。

4. 数据库与算法分析：Union Bound 的"坏事件"范式

算法分析的标准套路是：定义一族"坏事件" $A_1, \dots, A_m$（例如"第 i 个随机位取到了不利值"），然后说

$$\Pr[\text{算法失败}] = \Pr\left[\bigcup_i A_i\right] \le \sum_i \Pr[A_i] \le m \cdot \max_i \Pr[A_i].$$

只要 $m \cdot \max_i \Pr[A_i] < 1$，就证明了**存在**一个好的随机选择（这是"概率方法"的核心论式，与讲次 13 的存在性论证同源）。Union Bound 在这里的不可替代性在于：它**不需要任何独立性假设**——而算法里的事件往往高度相关（比如同一个哈希函数导致的多个坏事件）。

与其他讲次的关联

- **讲次 17（条件概率与贝叶斯）**：本讲完全建立在条件概率的定义 $\Pr[A \mid B] = \Pr[A \cap B] / \Pr[B]$、乘积法则以及全概率法则之上。定理 18.1（独立的两种刻画等价）就是对讲次 17 定义的直接代数变形；链式法则（定理 18.2）则是把讲次 17 的 $\Pr[A \cap B] = \Pr[A]\Pr[B \mid A]$ 推广到 n 个事件。反过来，讲次 17 的贝叶斯推断在**条件独立假设**下才可计算（朴素贝叶斯的"朴素"二字就是指"给定类别后特征条件独立"）。
- **讲次 14（计数）**：容斥原理 $\left|\bigcup A_i\right| = \sum_k (-1)^{k-1} \sum_{|S|=k} \left|\bigcap_{i \in S} A_i\right|$ 在那里是**计数**等式，本讲把它逐项换成概率 $\Pr[\bigcap_{i \in S} A_i]$ 得到概率形式（定理 18.4），证明机制（每个样本点的计入次数配平为 1）完全相同。此外，"每个特定 $HH\cdots H$ 序列的概率是 $p^k(1-p)^{n-k}$、共有 $\binom{n}{k}$ 个这样的序列"这一即将在讲次 19 用到的推理，正是讲次 14 的组合计数 + 本讲的独立乘积法则的合体。
- **讲次 15（概率公理）**：概率公理给出了 $\Pr[\emptyset] = 0$（定理 18.3 用到）、可加性以及生日悖论的互补技巧 $\Pr[A] = 1 - \Pr[\bar{A}]$。本讲把讲次 15 中"生日悖论"从一次性技巧提升为系统方法：**求"至少一个"就取补集，补集在独立时分解为乘积**。
- **讲次 19（随机变量与离散分布）**：本讲是讲次 19 的直接前置。定义"随机变量 X, Y 独立"就是"对所有 a, b，事件 $X = a$ 与 $Y = b$ 独立"，即 $\Pr[X = a, Y = b] = \Pr[X = a]\Pr[Y = b]$；而二项分布的 PMF $\binom{n}{k}p^k(1-p)^{n-k}$ 的推导，其核心正是**这 n 次试验相互独立**导致的乘积化简。
- **讲次 20（期望与线性性）**：独立性在期望的乘法法则中再次出现——$\mathbb{E}[XY] = \mathbb{E}[X]\mathbb{E}[Y]$ 需要独立（而 $\mathbb{E}[X+Y] = \mathbb{E}[X] + \mathbb{E}[Y]$ 不需要）。同时，本讲"至少一次命中"的互补技巧 $\Pr[\text{命中}] = 1 - (1-p)^m$ 与讲次 20 中几何分布的期望 $1/p$ 是同一个现象的两面。
- **讲次 22（方差与协方差）**：不相关（$\mathrm{Cov}(X, Y) = 0$）与独立的关系，正是本讲"两两独立 $\neq$ 相互独立"在随机变量层面的翻版——不相关比独立弱得多，讲次 22 会给出具体的反例。
- **讲次 23（集中不等式）**：Union Bound 是"最粗糙的集中不等式"，它将被 Markov 不等式（讲次 23）与 Chernoff 界逐步加强。但 Union Bound 至今仍不可替代，因为它**不需要独立同分布假设**。
- **讲次 24（连续概率）**：定理 18.1 中"$\Pr[B] > 0$"这个技术条件在连续情形会全面爆发——单个点的概率为 0，条件概率必须用密度重新定义，这使得**乘积形式成为唯一可用的独立性定义**。

关键要点

1. **独立的定义是乘积形式**：$A \perp B \iff \Pr[A \cap B] = \Pr[A]\Pr[B]$。条件概率形式 $\Pr[A \mid B] = \Pr[A]$ 只在 $\Pr[B] > 0$ 时等价；选乘积形式是为了在概率为零的事件上照样良定义。
2. **相互独立要求"所有子集"**：n 个事件需要 $2^n - n - 1$ 个条件，其中**包括**全体三三、四四……交集。两两独立（$\binom{n}{2}$ 个条件）**严格弱于**相互独立——两枚硬币 + "两枚相同"就是最优美的反例（$\Pr[A \cap B \cap C] = 1/4 \neq 1/8$）。
3. **不交与独立是正交的概念**：不交是集合层面的 $A \cap B = \emptyset$，独立是概率层面的乘积等式。**若 $\Pr[A], \Pr[B] > 0$ 且 $A \cap B = \emptyset$，则二者一定不独立**；反之，两个正概率的事件若独立，则它们必定**相交**（因为 $\Pr[A \cap B] > 0$）。这是 CS70 最高频的混淆点。
4. **并集两板斧**：精确计算用**容斥**（交错和，$2^n - 1$ 项，代价高但精确）；只要上界就用 Union Bound $\Pr[\bigcup A_i] \le \sum \Pr[A_i]$（一项搞定，无需独立性）。求"至少一个"时优先考虑**互补技巧** $1 - \Pr[\text{全不发生}]$，独立时补集概率分解为乘积。
5. **条件独立与独立互不蕴含**：独立可被"多给一个条件"摧毁（两枚硬币 + $C =$ 两枚相同）；条件独立也可以在混合模型下掩盖边缘强相关（全 H 机 / 全 T 机）。讨论"独立"时必须**明确是在哪个概率空间（是否给定 C）里谈**。

常见误区与注意事项

1. **把不交当成独立**。这是最致命的错误。$A \cap B = \emptyset$ 时 $\Pr[A \cup B] = \Pr[A] + \Pr[B]$（可加性），但这**不意味着** $\Pr[A \cap B] = \Pr[A]\Pr[B]$；恰恰相反，正概率的不交事件是**负相关到极致**的。判据一句话：**不交的事件，除了退化的零概率情形，一定不独立。**
2. **只检查"总额"不检查"所有子集"**。很多同学验证三个事件独立时只算 $\Pr[A \cap B \cap C] = \Pr[A]\Pr[B]\Pr[C]$，就宣布相互独立。**错！** 必须同时检查全部 $\binom{3}{2} = 3$ 个两两条件与 1 个三重条件。反例 18.1 的 $\Pr[A \cap B \cap C] = 1/4$ 与 $\Pr[A]\Pr[B]\Pr[C] = 1/8$ 不符只是"三重不成立"；也存在"三重成立但某个两两不成立"的构造。
3. **把边际概率的乘积当成联合概率（或反过来）**。$\Pr[A]\Pr[B]$ 与 $\Pr[A \cap B]$ 是两个数，只有在独立时才相等。用链式法则时应写成 $\Pr[A]\Pr[B \mid A]$，不要图省事直接乘 $\Pr[A]\Pr[B]$。讲次 18 的摸牌例子：$\Pr[\text{两张 A}] = \frac{4}{52} \cdot \frac{3}{51} = \frac{1}{221} \approx 0.004525$，而不是 $\frac{1}{169} \approx 0.005917$。
4. **误以为 Union Bound 需要独立**。Union Bound 对**任意**事件都成立，这正是它在算法分析里不可替代的原因。相反，容斥公式里出现的 $\Pr[A_i \cap A_j]$ 若被替换成 $\Pr[A_i]\Pr[A_j]$，**那就偷偷用了独立性假设**——赌场把 $3 \times \frac{1}{6}$ 当答案、把两两交当 $\frac{1}{36}$，前半句错、后半句对，但混在一起就错了（正确结果是 $91/216$ 而非 $1/2$）。
5. **认为"独立"是事件自身的属性**。独立是**一对（或一族）事件相对于一个概率空间**的关系，还可以相对一个条件 C 而改变。同一个 A, B 在 Ω 上独立、在给定 C 下不独立，这是常态而非矛盾。
6. **混淆"条件独立"与"独立"的适用场合**。朴素贝叶斯分类器假设"给定类别标签后特征条件独立"，这是**条件**独立而非一般独立——如果误当成一般独立去算 $\Pr[\text{特征}]$，结果会严重偏差。

7. **忘记 $\Pr[A \mid B]$ 与 $\Pr[B \mid A]$ 不对称**。相关性定义中 $\Pr[A \mid B] > \Pr[A]$ 与 $\Pr[B \mid A] > \Pr[B]$ 是等价的（可由 $\Pr[B \mid A] = \frac{\Pr[A|B]}{\Pr[A]} \Pr[B]$ 推出），但**数值上**两者通常不等。不要把"方向"搞混。

思考题（带答案）

Q1. 抛三枚公平硬币。令 A = "至少出现一个 H"，B = "恰好出现两个 H"。判断 A 与 B 是否独立，并给出完整计算。

> ▸ **答案**
>
> 样本空间有 $2^3 = 8$ 个等概率样本点。
>
> - $\bar{A} = \{TTT\}$，故 $\Pr[A] = 1 - 1/8 = 7/8 = 0.875$。
> - "恰好两个 H"的样本点有 $\binom{3}{2} = 3$ 个：$\{HHT, HTH, THH\}$，故 $\Pr[B] = 3/8 = 0.375$。
> - $A \cap B = B$（因为恰好两个 H 一定至少有一个 H），故 $\Pr[A \cap B] = \Pr[B] = 3/8 = 0.375$。
> - 而 $\Pr[A]\Pr[B] = \frac{7}{8} \cdot \frac{3}{8} = \frac{21}{64} \approx 0.328125$。
>
> 因为 $0.375 \neq 0.328125$，**A 与 B 不独立**。直观上 B 蕴含 A，是**正相关**：$\Pr[A \mid B] = 1 > 7/8 = \Pr[A]$。（脚本验算：$\Pr[A \cap B] = 0.375$，乘积 0.328125。）

Q2. 设 $\Pr[A] = 0.4$、$\Pr[B] = 0.5$ 且 A, B 独立。求：(a) $\Pr[A \cup B]$；(b) $\Pr[A \mid B]$；(c) $\Pr[\bar{A} \cap \bar{B}]$；(d) 若已知 C 满足 $\Pr[C] = 0.25$ 且 C 与 A, B 都独立，求 $\Pr[A \cap B \mid C]$。

> ▸ **答案**
>
> (a) 独立给出 $\Pr[A \cap B] = 0.4 \times 0.5 = 0.2$，故 $\Pr[A \cup B] = 0.4 + 0.5 - 0.2 = \mathbf{0.7}$。
>
> (b) $\Pr[A \mid B] = \Pr[A] = \mathbf{0.4}$（独立的定义性刻画）。
>
> (c) $\bar{A} \cap \bar{B} = \overline{A \cup B}$（De Morgan），故 $\Pr[\bar{A} \cap \bar{B}] = 1 - 0.7 = \mathbf{0.3}$。（也可直接用 $\bar{A}, \bar{B}$ 独立：$0.6 \times 0.5 = 0.3$，两者一致。）
>
> (d) 注意题目给的是 C 与 A、C 与 B 独立，但这**不蕴含** $A \cap B$ 与 C 独立，所以不能直接写 $\Pr[A \cap B \mid C] = \Pr[A \cap B] = 0.2$。稳妥做法是化简：
>
> $$\Pr[A \cap B \mid C] = \frac{\Pr[A \cap B \cap C]}{0.25},$$
>
> 而这需要知道 A, B, C 的联合结构，**题目信息不足**。若额外假设 $A \cap B$ 与 C 独立，则答案为 $\mathbf{0.2}$。这道题刻意提醒：**"每个单独事件都与 C 独立"不等于"可数组合也与 C 独立"**。

Q3. 抛两枚公平硬币。令 A = "第一枚是 H"，B = "第二枚是 H"，C = "至少有一枚是 H"。计算 $\Pr[A \cap B \mid C]$ 与 $\Pr[A \mid C]\Pr[B \mid C]$，并判断 A, B 在给定 C 下是否条件独立；再判断 A, B 本身是否独立。比较两个结论说明了什么。

> ▸ **答案**
>
> 样本空间 $\{HH, HT, TH, TT\}$，各 $1/4$。$C = \{HH, HT, TH\}$，$\Pr[C] = 3/4$。
>
> - $\Pr[A \cap B \mid C] = \dfrac{\Pr[HH]}{\Pr[C]} = \dfrac{1/4}{3/4} = \dfrac{1}{3} \approx 0.3333$。
> - $\Pr[A \mid C] = \dfrac{\Pr[A \cap C]}{\Pr[C]} = \dfrac{2/4}{3/4} = \dfrac{2}{3}$；同理 $\Pr[B \mid C] = \dfrac{2}{3}$；乘积 $= \dfrac{4}{9} \approx 0.4444$。
>
> $\frac{1}{3} \neq \frac{4}{9}$，故 **$A, B$ 在给定 C 下不条件独立**（脚本验算：$\Pr[C] = 0.75$，$\Pr[A \cap B \mid C] = 0.333333$，$\Pr[A \mid C]\Pr[B \mid C] = 0.444444$）。
>
> 而 **A, B 本身独立**：$\Pr[A \cap B] = 1/4 = \frac{1}{2} \cdot \frac{1}{2}$。
>
> **结论**：独立（$\frac{1}{4} = \frac{1}{4}$）与条件独立（$\frac{1}{3} \neq \frac{4}{9}$）是两个独立的命题，本例同时展示了"独立但不条件独立"。原因是 C 剔除了 TT 这个对称分支，破坏了 Ω 上的对称性，使两枚硬币产生了"至少一个要出 H"的耦合。

Q4（证明题）. 证明：若 $A_1, \ldots, A_n$ 相互独立，则对任意 $1 \le i \le n$ 与任意 $I \subseteq \{1, \ldots, n\} \setminus \{i\}$，有 $\Pr[A_i \mid \bigcap_{j \in I} A_j] = \Pr[A_i]$。

> ▸ **答案**
>
> 设 $\Pr[\bigcap_{j \in I} A_j] > 0$。由条件概率定义，
>
> $$\Pr\left[A_i \mid \bigcap_{j \in I} A_j\right] = \frac{\Pr\left[A_i \cap \bigcap_{j \in I} A_j\right]}{\Pr\left[\bigcap_{j \in I} A_j\right]}.$$
>
> 分子是集合 $I \cup \{i\}$ 上所有事件的交集，由**相互独立的定义**（对**任意**子集成立）可写成 $\Pr[A_i] \cdot \Pr[\bigcap_{j \in I} A_j]$。代回：
>
> $$\Pr\left[A_i \mid \bigcap_{j \in I} A_j\right] = \frac{\Pr[A_i] \cdot \Pr\left[\bigcap_{j \in I} A_j\right]}{\Pr\left[\bigcap_{j \in I} A_j\right]} = \Pr[A_i]. \qquad \blacksquare$$
>
> **关键点**：证明中"对任意子集成立"这一条件是**必需的**。如果只有两两独立，那么当 $|I| \ge 2$ 时，$\bigcap_{j \in I} A_j$ 的大小 ≥ 3，两两独立**不能**保证 $\Pr[A_i \cap \bigcap_{j \in I} A_j] = \Pr[A_i] \prod_{j \in I} \Pr[A_j]$。反例 18.1 中取 i 对应 C、$I = \{A, B\}$：$\Pr[C \mid A \cap B] = 1 \neq 1/2 = \Pr[C]$，正是因为三重条件不成立。

Lecture 19: Random Variables & Discrete Distributions（随机变量与离散分布）

概述

前四讲我们把概率当成"事件的语言"：样本空间 Ω、事件（子集）、概率公理、条件概率、独立性。但真实问题问的往往不是一个"是/否"，而是一个**数**：n 次抛硬币里有几个正面？弃置重排的作业有几份回到本人手上？掷到第一个 6 需要几次？一页论文有几个 typo？本讲的核心动作是把这些"数"形式化为**随机变量 (random variable)**，并给出它最关键的观念转变——

> **随机变量不是变量，而是函数**：$X : \Omega \to \mathbb{R}$，把每个样本点映射成一个实数。随机性不在 X 里，而在"哪个样本点被抽到"里。

一旦接受了这个定义，我们就可以谈**分布 (distribution)**——即 X 取每个值的概率，把它们做成一张表或一张柱状图，接下来就能谈期望（讲次 20）、联合分布（讲次 21）、方差（讲次 22）、集中不等式（讲次 23）。本讲要建立四个"积木级"的离散分布：**伯努利 (Bernoulli)**、**二项 (Binomial)**、**几何 (Geometric)**、**泊松 (Poisson)**。它们后面会反复出现，值得像记乘法表一样记牢。

核心概念的直观解释

随机变量 (Random Variable, RV)

- **定义**：定义在样本空间 Ω 上的随机变量是一个**函数** $X : \Omega \to \mathbb{R}$，它为每个样本点 $\omega \in \Omega$ 指定一个实数 $X(\omega)$。
- **直观解释（"它是什么意思？"）**：教材自己都承认"随机变量"这个名字是misnomer（**用词不当**）：它既不随机（X 作为函数是完全确定的），也不是变量（它不会自己变动）。真正随机的是**实验的结果** ω。可以这样类比：X 是一台"测量仪"，ω 是被测量的工件；仪器本身没有随机性，随机的是送进来的工件。另一类比：X 是旅馆房号表——每位客人都被分配一个房间号，房间号是确定的映射，随机的是"今天来了哪位客人"。
- **具体示例（本讲的标准例子，$n = 2$ 与 $n = 4$）**：抛两枚公平硬币，样本空间 $\Omega = \{HH, HT, TH, TT\}$。令 X = "正面个数"，则

$$X(HH) = 2, \quad X(HT) = 1, \quad X(TH) = 1, \quad X(TT) = 0.$$

注意 X 把 4 个样本点映射到 3 个不同的值——**多个样本点可以映到同一个值**，这正是"分布"要把它们合并求和的原因。若抛 4 枚硬币，则 Ω 有 16 个点，$X(HTTH) = 3$，$X(HTHT) = 2$，等等。

离散随机变量 (Discrete RV) 与分布 (Distribution / PMF)

- **定义**：若 X 的取值集合 $\{X(\omega) : \omega \in \Omega\}$ 是**有限集或可数无限集**，称 X 为离散随机变量。X 的**分布 (distribution)** 是数对的集合

$$\{(a,\ \Pr[X = a]) : a \in A\}, \qquad A = \{X(\omega) : \omega \in \Omega\}.$$

这些概率通常记作 $p_X(a) = \Pr[X = a]$，称为**概率质量函数 (probability mass function, PMF)**。

- **直观解释**：分布就是"X 取各个值分别有多大可能"的清单。它是 X 的**完整**概率刻画——知道分布就知道关于 X 的一切概率信息。分布的图像是一条**柱状图 (bar diagram)**：横轴是 X 的取值 a，a 处柱子的高度是 $\Pr[X = a]$。
- **关键细节（为什么 $X = a$ 是合法事件）**：因为 X 是函数，对每个实数 a，集合

$$\{\omega \in \Omega : X(\omega) = a\} = X^{-1}(a)$$

是 Ω 的一个子集，因此按讲次 15 的定义它就是一个**事件**，我们可以堂而皇之地写 $\Pr[X = a]$。这一点看似平凡，却是整个理论的合法性来源：**没有"X 是函数"这个定义，$\Pr[X = a]$ 就无从谈起。** – **PMF 的两条性质**：取值 $a \neq a'$ 的事件 $\{X = a\}$ 与 $\{X = a'\}$ **不交**；所有 $\{X = a\}$ 的并恰好是 Ω。也就是说，这族事件构成了 Ω 的一个**划分 (partition)**。因此

$$\text{(i) } p_X(a) \geq 0 \text{ 对一切 } a; \qquad \text{(ii) } \sum_{a \in A} p_X(a) = 1.$$

反之，任何满足这两条的数列都是某个离散随机变量的 PMF。**验证这两条，是检查"X 是随机变量"的合法性证明。** – **具体示例**：抛 4 枚公平硬币，X = 正面个数。分布为

a	0	1	2	3	4
$\Pr[X = a]$	$1/16$	$4/16$	$6/16$	$4/16$	$1/16$

验算：$\frac{1+4+6+4+1}{16} = 1$ ✓。这就是 Ω 的 16 个样本点按"正面个数"归并成 5 类的过程。

"随机变量是函数"的映射图示（本讲最关键的图）

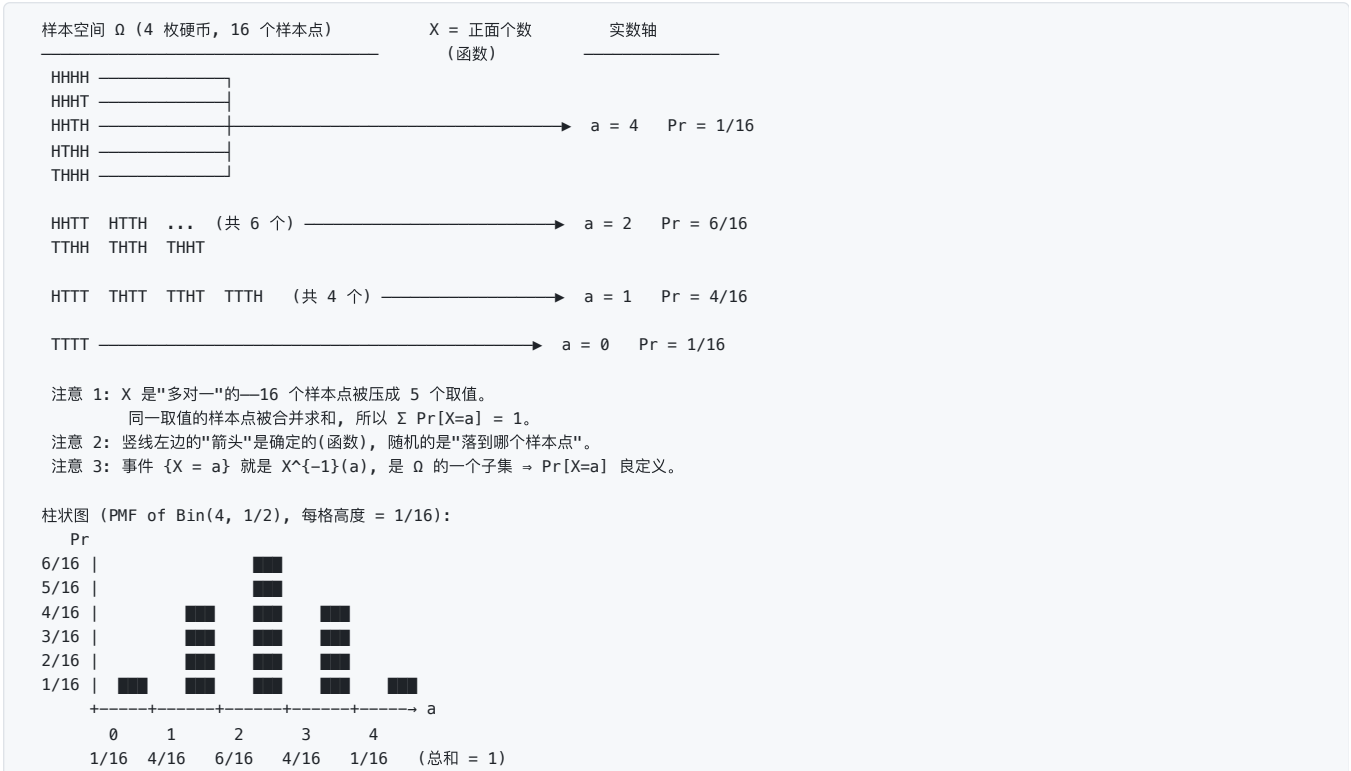

伯努利分布 (Bernoulli Distribution)

- **定义**：若 X 只取 $\{0,1\}$ 两个值，且

$$\Pr[X=1]=p,\qquad \Pr[X=0]=1-p,\qquad 0\le p\le 1,$$

则称 X 服从参数为 p 的伯努利分布，记作 $X\sim \mathrm{Ber}(p)$。 – **直观解释**：这是"一次试验成功与否"的最简模型——抛一次硬币、检查一个包是否丢失、一个比特是否翻转。取值为 1 的事件叫"成功 (success)"，取值为 0 的叫"失败"。 – **为什么它是所有计数型分布的积木**：X 只数"一件事发生没发生"，所以它是**指示随机变量 (indicator random variable)**：$X=\mathbf{1}[A]$，其中 A 是那个"成功"事件。把 n 个指示变量加起来，就得到"n 次试验中成功了几次"——这正是二项分布。 – **一个极其有用的恒等式**：对指示变量，$\mathbb{E}[X]=1\cdot\Pr[X=1]+0\cdot\Pr[X=0]=\Pr[X=1]$。**指示变量的期望就是它所指示事件的概率**。这一句话会在讲次 20 支撑起线性性期望的全部应用。 – **具体示例**：掷公平骰子，$X=\mathbf{1}[\text{点数为 }6]$，则 $X\sim\mathrm{Ber}(1/6)$。

二项分布 (Binomial Distribution)

- **定义**：设进行 n 次**相互独立**的伯努利试验（每次成功概率同为 p，即独立同分布，i.i.d.），令 X 为成功总次数。则 X 取值 $0,1,\dots,n$，且

$$\Pr[X=k]=\binom{n}{k}p^k(1-p)^{n-k},\qquad k=0,1,\dots,n.$$

记作 $X\sim\mathrm{Bin}(n,p)$。

- **直观解释**：伯努利是"一次"，二项是"n 次的成功**计数**"。它出现得极其频繁：n 个包中丢失的个数、n 次网络请求中失败的次数、n 个比特中翻转的个数。
- **具体示例**：抛 3 次公平硬币，X = 正面数。$\Pr[X=0]=\binom{3}{0}/8=1/8$，$\Pr[X=1]=3/8$，$\Pr[X=2]=3/8$，$\Pr[X=3]=1/8$（脚本验算：$0.1250, 0.3750, 0.3750, 0.1250$，和为 1）。
- **参数与统计量（预告讲次 20/22）**：$\mathbb{E}[X]=np$（讲次 20 用指示变量 + 线性性一行搞定），$\mathrm{Var}(X)=np(1-p)$（讲次 22）。

几何分布 (Geometric Distribution)

- **定义**：反复独立地抛一枚正面概率为 p 的硬币，令 X 为**首次出现正面所需的抛掷次数**。则 $X\in\{1,2,3,\dots\}$，且

$$\Pr[X=k]=(1-p)^{k-1}p,\qquad k=1,2,3,\dots$$

记作 $X\sim\mathrm{Geo}(p)$。

- **直观解释**：几何分布是"**等待时间**"的分布——等多久才中奖、等多少轮系统才出故障、重传多少次包才送达、抽多少次样本才找到一个满足条件的人。它出现的频率和二项分布一样高，只是问的问题从"总共几次"变成了"要等几次"。
- **具体示例**：$p=0.3$ 时 $\Pr[X=1..6]=0.3000, 0.2100, 0.1470, 0.1029, 0.0720, 0.0504$——每往后一步恰好乘以 $1-p=0.7$。这是**几何衰减**，也是它得名的原因。

- **期望（预告讲次 20）**：$\mathbb{E}[X] = 1/p$。直觉："每次抛掷期望贡献 p 个正面，所以要抛 $1/p$ 次才凑够 1 个正面。"$\mathbf{Var}(X) = (1-p)/p^2$（讲次 22）。

泊松分布 (Poisson Distribution)

- **定义**：若随机变量 X 取值 $0, 1, 2, \ldots$ 且

$$\Pr[X = k] = \frac{\lambda^k}{k!} e^{-\lambda}, \qquad k = 0, 1, 2, \ldots,\ \lambda > 0,$$

则称 X 服从参数为 λ 的泊松分布，记作 $X \sim \mathbf{Pois}(\lambda)$。

- **直观解释**：泊松分布是"**稀有事件计数**"的分布。设想在某个连续区域（一段时间、一块面积、一页纸）里，事件以恒定的平均密度 λ 随机发生，并且**不重叠子区域中的发生相互独立**；那么该区域内的发生次数就近似服从 $\mathbf{Pois}(\lambda)$。典型场景：盖革计数器的放射性衰变点击、电话交换机收到的拨错号码、染色体的交叉互换、一小时内出生的婴儿数、一页论文里的 typo 数。它的美妙之处在于：**一个数 λ 就完全确定了整个分布**。
- **具体示例**：$\lambda = 1$ 时 $\Pr[X=0] = e^{-1} \approx 0.3679$，$\Pr[X=1] \approx 0.3679$，$\Pr[X=2] \approx 0.1839$，$\Pr[X=5] = e^{-1}/120 \approx 0.003066$（即约"每 326 页才有 1 页写错 5 个 typo"）。
- **参数与统计量**：$\mathbb{E}[X] = \lambda$，$\mathbf{Var}(X) = \lambda$（本讲完整证明 $\mathbb{E}[X] = \lambda$；方差预告讲次 22）。

随机变量的独立性 (Independence of Random Variables)

- **定义**：同一概率空间上的随机变量 X, Y 称为**独立**，当且仅当对所有取值 a, b，事件 $\{X = a\}$ 与 $\{Y = b\}$ 都独立。等价地

$$\Pr[X = a,\ Y = b] = \Pr[X = a] \cdot \Pr[Y = b], \qquad \forall a, b.$$

多个随机变量的**相互独立**类似定义（对所有取值组合成立）。 – **直观解释**：这就是讲次 18 的独立性定义**逐事件地搬运**到随机变量上：把 X, Y 的所有"取值事件"两两拿出来，要求它们独立。因为 $\{X = a\}$ 与 $\{Y = b\}$ 构成各自的划分，所以"所有 a, b 都成立"这个条件是最强的可能要求。 – **具体示例**：独立抛两枚硬币，$X = \mathbf{1}$[第一枚是 H]、$Y = \mathbf{1}$[第二枚是 H]。则 $\Pr[X=1, Y=1] = 1/4 = \frac{1}{2} \cdot \frac{1}{2}$，其余三种组合同理。$X, Y$ 独立。**一列独立同分布的指示变量 $\{I_1, \ldots, I_n\}$ 常缩写为 i.i.d.（independent and identically distributed）**，是概率论中使用频率最高的短语之一。

随机变量的函数 (Functions of Random Variables)

- **定义**：设 X 是 Ω 上的随机变量，$g : \mathbb{R} \to \mathbb{R}$。则 $Y = g(X)$ 也是 Ω 上的随机变量，定义为

$$Y(\omega) = g(X(\omega)), \qquad \omega \in \Omega.$$

它的分布由"**枚举 + 合并**"给出：

$$\Pr[Y = y] = \sum_{x:\, g(x) = y} \Pr[X = x].$$

- **直观解释**：对 X **做变换**（平方、取绝对值、取对数、四舍五入……）得到的仍是随机变量，因为我们只是给测量仪后面又接了一台后处理器。求 Y 的分布不需要回到 Ω——只要在 X 的分布表上，把映到同一个 y 的那些 x 的概率**加起来**即可。事件层面的表述是 $\{Y = y\} = \{X \in g^{-1}(y)\}$（呼应讲次 16 官方 Note "Functions of Random Variables"）。
- **具体示例**：$X \sim \mathbf{Bin}(3, 0.5)$，令 $Y = X^2$。X 取值 $0, 1, 2, 3$ 概率 $0.125, 0.375, 0.375, 0.125$。$Y$ 取值 $0, 1, 4, 9$：$\Pr[Y=0] = 0.125$，$\Pr[Y=1] = 0.375$，$\Pr[Y=4] = 0.375$，$\Pr[Y=9] = 0.125$。本例中 $x \mapsto x^2$ 在非负整数上一一对应，所以概率原封不动。（脚本验算：由 X 的分布合并得到 $\{0:0.125, 1:0.375, 4:0.375, 9:0.125\}$。）
- **注意**：$Y = g(X)$ 与 X **几乎从不独立**（除非 g 是常函数）。这是随机变量层面的"相关"，是讲次 22 中协方差的入口。

完整证明与推导（核心）

定理 19.1（二项分布的 PMF 推导）：设 X 为 n 次独立同分布伯努利试验（每次成功概率 p）中成功的总次数。则对 $k = 0, 1, \ldots, n$，

$$\Pr[X = k] = \binom{n}{k} p^k (1-p)^{n-k}.$$

证明策略："**分组 + 计数 + 乘积法则**"**三步走**。核心洞察是把事件 $\{X = k\}$ 按"正面的**位置**"拆成互斥的若干块，每块内部概率相同（由独立性），块的个数由讲次 14 的组合计数给出。这是"讲次 14 计数 × 讲次 18 独立性"的第一次合体，也是后续所有"计数型分布"推导的模板。

逐步推导：

1. **把样本点写成序列**。n 次试验的样本点是一个长度 n 的序列 $\omega = (\omega_1, \ldots, \omega_n) \in \{H, T\}^n$，共 2^n 个。$X(\omega)$ 就是序列中 H 的个数。
2. **刻画事件 $\{X = k\}$**。$\{X = k\}$ 是那些"恰好含 k 个 H"的序列的集合。例如 $n = 3, k = 2$ 时是 $\{HHT, HTH, THH\}$，共 3 个。

3. **数出序列个数**。选"哪 k 个位置是 H"：在 n 个位置中选 k 个，共 $\binom{n}{k}$ 种方式（讲次 14 的第一/第三计数法则）。其余 $n-k$ 个位置自动是 T。故恰好有 $\binom{n}{k}$ 个这样的序列。
4. **每个这样的序列概率相同，都是 $p^k(1-p)^{n-k}$**。以 $HHT\cdots T$（前 k 个 H、后 $n-k$ 个 T）为例，用讲次 18 的**独立乘积法则**：

$$\Pr[\omega_1=H,\omega_2=H,\dots,\omega_k=H,\omega_{k+1}=T,\dots,\omega_n=T]=\underbrace{p\cdots p}_{k\text{个}}\cdot\underbrace{(1-p)\cdots(1-p)}_{n-k\text{个}}=p^k(1-p)^{n-k}.$$

对任意其他"含 k 个 H"的序列，乘法因子的内容只是**顺序**不同，乘积不变（乘法可交换），所以概率全都一样。 5. **合并**。这 $\binom{n}{k}$ 个序列互不相交，且并起来恰好是 $\{X=k\}$。由概率的**可加性**（讲次 15 公理），

$$\Pr[X=k]=\sum_{\omega\in\{X=k\}}\Pr[\omega]=\binom{n}{k}\cdot p^k(1-p)^{n-k}.\qquad\blacksquare$$

【证明机制解说】：整个证明的"灵光一现"是**先按位置分块，再发现块内概率全等**——这一步是独立性送的大礼。如果各次试验不独立（例如无放回抽样），"每个序列概率相同"就不成立，这个论证立刻失效（那时要用超几何分布）。第 5 步的"合并"也很关键：**可加性只在互斥事件上用**，而"含 k 个 H"的不同序列当然互斥（一个序列不可能同时有两个不同的 H 位置集合）。

副产品：二项式定理的概率证明。 由于 $\{X=0\},\dots,\{X=n\}$ 构成 Ω 的划分，必有 $\sum_{k=0}^{n}\Pr[X=k]=1$，即

$$\sum_{k=0}^{n}\binom{n}{k}p^k(1-p)^{n-k}=1.$$

令 $a=p$、$b=1-p$，这正是讲次 14 中用组合双计数证明过的二项式定理 $(a+b)^n=\sum_k\binom{n}{k}a^kb^{n-k}$。**我们用一个概率论证重新证明了它**——这是一次漂亮的"概率方法证代数恒等式"。（脚本验算：$n=10,p=0.3$ 时各概率之和 $=1.00000000$。）

反例（独立条件不可省）：设一箱 $N=10$ 个球，5 黑 5 白，**无放回**抽 $n=3$ 个，令 Y = 抽到的黑球数。若误用二项分布 $\mathrm{Bin}(3,0.5)$，会得到 $\Pr[Y=0]=\Pr[Y=3]=1/8=0.125$；真实分布是**超几何分布**

$$\Pr[Y=k]=\frac{\binom{5}{k}\binom{5}{3-k}}{\binom{10}{3}},$$

即 $k=0,1,2,3$ 分别对应 $\frac{1}{12},\frac{5}{12},\frac{5}{12},\frac{1}{12}\approx 0.0833,0.4167,0.4167,0.0833$。两两比较可见 Bin 低估了两端、高估了中间（0.125 vs 0.0833）。**"每次试验成功概率恒为 p"和"试验间独立"缺一不可。**

定理 19.2（几何分布是合法 PMF）：设 $0<p\le 1$，$X\sim\mathrm{Geo}(p)$，即 $\Pr[X=k]=(1-p)^{k-1}p$（$k\ge 1$）。则

$$\sum_{k=1}^{\infty}\Pr[X=k]=\sum_{k=1}^{\infty}(1-p)^{k-1}p=1.$$

证明策略：**提取公因子 + 几何级数求和**。这看似只是"检查定义合法性"的技术步骤，实则非常重要：**任何一个声称是 PMF 的公式，都必须先证明它求和为 1**，否则整个分布是虚构的。我们会用同样的手法在定理 19.4 检验泊松分布。

逐步推导：

1. 把常数 p 提到求和号外：

$$\sum_{k=1}^{\infty}(1-p)^{k-1}p=p\sum_{k=1}^{\infty}(1-p)^{k-1}.$$

1. 令 $r=1-p$。注意 $0\le r<1$（因为 $p>0$），且求和从 r^0 开始：

$$\sum_{k=1}^{\infty}(1-p)^{k-1}=\sum_{j=0}^{\infty}r^j,$$

这里做了下标替换 $j=k-1$。 3. 用几何级数公式 $\sum_{j=0}^{\infty}r^j=\dfrac{1}{1-r}$（$|r|<1$，来自讲次 8 的多项式/级数工具，也可由 $(1-r)(1+r+\cdots+r^m)=1-r^{m+1}$ 令 $m\to\infty$ 得到）：

$$p\cdot\frac{1}{1-(1-p)}=p\cdot\frac{1}{p}=1.\qquad\blacksquare$$

1. **顺带得到一个极其常用的尾部公式**：$X>n$ 意味着前 n 次全是反面，故

$$\Pr[X>n]=(1-p)^n,\qquad n\ge 0.$$

等价地 $\Pr[X\ge i]=(1-p)^{i-1}$（注意 $X\ge i$ 就是"前 $i-1$ 次全失败"）。这个公式是几何分布一切漂亮性质的源头。

【证明机制解说】：$p\sum_j(1-p)^j$ 里那个 $1/(1-(1-p))=1/p$ 的化简，把"无穷多项的调和"压缩成了一个 p 的倒数。**这也是为什么 p 越小、X 越"容易"取大值**——$r=1-p$ 越大，几何级数越"慢"收敛，尾部越肥。脚本验算：$p=0.3$ 时 $\sum_{k=1}^{500}(0.7)^{k-1}\cdot 0.3=1.0000000000$；$p=0.7$ 时同样为 1.0000000000。

反例（$p=0$ 的边界）：公式要求 $p>0$。若 $p=0$，则 $(1-p)^{k-1}p\equiv 0$，求和为 $0\ne 1$，**不是合法的 PMF**，几何分布不存在——当然，"永远等不到正面"的随机变量也不是离散的合法等待时间（它在源 Note 的范围内被排除）。这提醒我们：**几何级数公式 $1/(1-r)$ 在 $r=1$ 时失效**，而 $p=0$ 恰使 $r=1$。

定理 19.3（几何分布的无记忆性，Memorylessness）：设 $X \sim \mathrm{Geo}(p)$，$n, m \geq 0$。则

$$\Pr[X > n+m \mid X > n] = \Pr[X > m] = (1-p)^m.$$

证明策略：**直接用条件概率定义 + 定理 19.2 第 4 步的尾部公式**。这是"条件概率在几何分布上化腐朽为神奇"的标准范例，只需三行。

逐步推导：

1. 由条件概率定义（讲次 17），（注意需 $\Pr[X > n] > 0$，即 n 有限且 $p > 0$）

$$\Pr[X > n+m \mid X > n] = \frac{\Pr[\{X > n+m\} \cap \{X > n\}]}{\Pr[X > n]}.$$

1. **简化分子**：若 $X > n+m$，则因为 $m \geq 0$ 必有 $X > n+m \geq n$，所以事件 $\{X > n+m\}$ **蕴含** $\{X > n\}$，即 $\{X > n+m\} \cap \{X > n\} = \{X > n+m\}$。于是

$$\Pr[X > n+m \mid X > n] = \frac{\Pr[X > n+m]}{\Pr[X > n]}.$$

1. **代入尾部公式** $\Pr[X > n] = (1-p)^n$、$\Pr[X > n+m] = (1-p)^{n+m}$：

$$\Pr[X > n+m \mid X > n] = \frac{(1-p)^{n+m}}{(1-p)^n} = (1-p)^m = \Pr[X > m]. \qquad \blacksquare$$

1. **数值验证**（脚本）：$p = 0.3$ 时 $\Pr[X > 8 \mid X > 5] = (0.7)^8/(0.7)^5 = (0.7)^3 = 0.343000$，而 $\Pr[X > 3] = 0.343000$，完全吻合。$p = 0.4$、$(n, m) = (10, 5)$ 时两边同为 0.077760。

【证明机制解说】：无记忆性的物理含义是"**过去不影响未来**"。已经失败了 n 次，并不让成功的概率变大（不会"该轮到我了"——这叫**赌徒谬误 (gambler's fallacy)**）；等待时间从任何时刻看都"重新开始"。数学上它之所以成立，是因为 $\Pr[X > n] = (1-p)^n$ 是**指数形式**，除法时指数相减，n 被干净地消掉。任何具有"乘法型尾部"的分布都有无记忆性；反过来可以证明，**在取值为非负整数的分布中，只有几何分布具有无记忆性**（连续情形下则只有指数分布，见讲次 24——几何分布正是它的离散类比）。

反例（别的分布没有无记忆性）：设 X 在 $\{1, 2, 3, 4, 5, 6\}$ 上均匀（掷骰子）。$\Pr[X > 4] = 2/6 = 1/3$，但 $\Pr[X > 7 \mid X > 4] = 0/(1/3) = 0 \neq \Pr[X > 3] = 1/2$。**"已经等了很久"在均匀分布下确实意味着"快到了"**，但几何分布下不成立。混淆这两者是极常见的错误。

定理 19.4（泊松分布是合法 PMF，且期望为 λ）：设 $\lambda > 0$，$\Pr[X = k] = \dfrac{\lambda^k}{k!} e^{-\lambda}$（$k = 0, 1, 2, \ldots$）。则

$$\text{(i)} \sum_{k=0}^{\infty} \Pr[X = k] = 1; \qquad \text{(ii)} \ \mathbb{E}[X] = \sum_{k=0}^{\infty} k \cdot \Pr[X = k] = \lambda.$$

证明策略：两个部分都靠**泰勒级数** $e^{\lambda} = \sum_{j \geq 0} \lambda^j / j!$。(i) 是把常数 $e^{-\lambda}$ 提出来直接套泰勒公式；(ii) 的关键技巧是**把 k 与 $k!$ 约掉**——$k \cdot \frac{\lambda^k}{k!} = \lambda \cdot \frac{\lambda^{k-1}}{(k-1)!}$，于是求和又变成一次泰勒展开。这个"约掉一个因子把参数降一阶"的手法在泊松与二项分布的矩计算中会反复使用。

逐步推导：

(i) 归一性。

$$\sum_{k=0}^{\infty} \frac{\lambda^k}{k!} e^{-\lambda} = e^{-\lambda} \sum_{k=0}^{\infty} \frac{\lambda^k}{k!} = e^{-\lambda} \cdot e^{\lambda} = 1,$$

中间用了 $e^x = 1 + x + \frac{x^2}{2!} + \frac{x^3}{3!} + \cdots$ 在 $x = \lambda$ 处的展开（讲次 8 的多项式工具 / 微积分基本事实）。脚本验算：$\lambda = 1, 2, 3, 5$ 时级数（截断到 $k = 60$）之和均为 1.000000000000。

(ii) 期望。

1. $k = 0$ 项为 0，从 $k = 1$ 开始：

$$\mathbb{E}[X] = \sum_{k=0}^{\infty} k \cdot \frac{\lambda^k}{k!} e^{-\lambda} = \sum_{k=1}^{\infty} k \cdot \frac{\lambda^k}{k!} e^{-\lambda}.$$

1. 用 $k/k! = k/(k \cdot (k-1)!) = 1/(k-1)!$，并把一个 λ 提出来：

$$= \lambda e^{-\lambda} \sum_{k=1}^{\infty} \frac{\lambda^{k-1}}{(k-1)!}.$$

1. 下标替换 $j = k - 1$：$\sum_{k=1}^{\infty} \frac{\lambda^{k-1}}{(k-1)!} = \sum_{j=0}^{\infty} \frac{\lambda^j}{j!} = e^{\lambda}$。
2. 故 $\mathbb{E}[X] = \lambda e^{-\lambda} \cdot e^{\lambda} = \lambda$。$\blacksquare$

【证明机制解说】：这里最值得记住的是 **"k 约掉 $k!$ 的一阶"** 这个动作。它有一个漂亮的一般化：$\mathbb{E}[X(X-1)] = \lambda^2$（同法可算，脚本验算 $\mathrm{Pois}(3)$ 的 $\mathbb{E}[X(X-1)]$ 对应 $\mathrm{Var} = 3.000000$），再配合 $\mathrm{Var}(X) = \mathbb{E}[X(X-1)] + \mathbb{E}[X] - \mathbb{E}[X]^2$ 立刻得到 $\mathrm{Var}(X) = \lambda^2 + \lambda - \lambda^2 = \lambda$。**泊松分布是"均值等于方差"的分布**，这是从数据判断"是否泊松"的一个经验判据。

反例 / 边界（λ 的角色）：$\lambda \le 0$ 时公式无意义（$\lambda = 0$ 时退化，$\lambda < 0$ 时概率为负）。另外注意 λ 不是"上界"也不是"最大取值"：$\mathbf{Pois(3)}$ 取到 $k = 8$ 的概率仍有 0.0081，柱子分布从 0 一直延伸到无穷，只是尾部极快地衰减。它的峰值在 $k = \lfloor \lambda \rfloor$ 附近（$\mathbf{Pois(3)}$ 的峰值是 $k = 2$ 与 $k = 3$，两者都是 0.224042）。

定理 19.5（泊松分布是二项分布的极限）：设 $\lambda > 0$ 为固定常数，$X_n \sim \mathbf{Bin}\left(n, \frac{\lambda}{n}\right)$。则对每个固定的 $k = 0, 1, 2, \ldots$，

$$\Pr[X_n = k] = \binom{n}{k}\left(\frac{\lambda}{n}\right)^k\left(1 - \frac{\lambda}{n}\right)^{n-k} \longrightarrow \frac{\lambda^k}{k!}e^{-\lambda} \qquad (n \to \infty).$$

证明策略：把三项因子拆开，分别求极限。核心是识别出表达式中"随 n 变化的三块"：(a) 一个趋近 1 的梯形乘积，(b) $e^{-\lambda}$ 的经典极限，(c) 一个趋近 1 的幂。每一块都是讲次 12 极限思想（或微积分标准极限）的应用。由于 k 固定、$n \to \infty$，可以放心地对每一项单独取极限。

逐步推导：

1. **写出 PMF 并整理**。固定 k，设 $n \ge k$，$p = \lambda/n$：

$$\Pr[X_n = k] = \binom{n}{k}\left(\frac{\lambda}{n}\right)^k\left(1 - \frac{\lambda}{n}\right)^{n-k} = \frac{n!}{k!\,(n-k)!} \cdot \frac{\lambda^k}{n^k} \cdot \left(1 - \frac{\lambda}{n}\right)^{n-k}.$$

1. **把因子归成三组**：

$$\Pr[X_n = k] = \frac{\lambda^k}{k!} \cdot \underbrace{\left[\frac{n!}{(n-k)!} \cdot \frac{1}{n^k}\right]}_{\text{(A)}} \cdot \underbrace{\left(1 - \frac{\lambda}{n}\right)^{n}}_{\text{(B)}} \cdot \underbrace{\left(1 - \frac{\lambda}{n}\right)^{-k}}_{\text{(C)}}.$$

验证一下：$\text{(B)} \cdot \text{(C)} = \left(1 - \frac{\lambda}{n}\right)^{n-k}$，与第 1 步一致 ✓；$\frac{\lambda^k}{k!} \cdot \text{(A)} = \frac{n!}{k!(n-k)!} \cdot \frac{\lambda^k}{n^k}$，也对 ✓。

1. **求 (A) 的极限**。展开 $n!/(n-k)! = n(n-1)(n-2)\cdots(n-k+1)$（共 k 个因子）：

$$\frac{n!}{(n-k)!} \cdot \frac{1}{n^k} = \frac{n}{n} \cdot \frac{n-1}{n} \cdot \frac{n-2}{n} \cdots \frac{n-k+1}{n} = \prod_{j=0}^{k-1}\left(1 - \frac{j}{n}\right) \longrightarrow 1 \cdot 1 \cdots 1 = 1.$$

因为 k 固定，$j/n \to 0$ 对每个 $j \in \{0, \ldots, k-1\}$ 成立。

1. **求 (B) 的极限**：这是标准极限

$$\left(1 - \frac{\lambda}{n}\right)^{n} \longrightarrow e^{-\lambda} \qquad (n \to \infty),$$

即讲次 20 会反复用到的 $\left(1 + \frac{c}{n}\right)^n \to e^c$（取 $c = -\lambda$）。

1. **求 (C) 的极限**：k 固定，故指数 $-k$ 固定，而底数 $1 - \lambda/n \to 1$：

$$\left(1 - \frac{\lambda}{n}\right)^{-k} \longrightarrow (1 - 0)^{-k} = 1.$$

1. **合并**：

$$\Pr[X_n = k] \longrightarrow \frac{\lambda^k}{k!} \cdot 1 \cdot e^{-\lambda} \cdot 1 = \frac{\lambda^k}{k!}e^{-\lambda}. \qquad \blacksquare$$

【证明机制解说】：这个定理解释了泊松分布**为什么叫"稀有事件分布"**：把一整段时间切成 n 个极小的片段，每片成功概率是 λ/n（很小），一共 n 片（很多），而"期望成功总数" $n \cdot (\lambda/n) = \lambda$ 固定。**"大 n、小 p、$np = \lambda$ 固定"** 就是泊松分布的诞生条件。三块因子中，(A) 承担"不放回修正"，(B) 制造 $e^{-\lambda}$，(C) 是无关紧要的尾巴修正——三者都趋近有限极限，所以收敛成立。

数值验证（收敛速度）：取 $\lambda = 3$：

n	$\Pr[X=0]$	$\Pr[X=1]$	$\Pr[X=2]$	$\Pr[X=3]$	$\Pr[X=4]$
10	0.028248	0.121061	0.233474	0.266828	0.200121
100	0.047553	0.147070	0.225153	0.227474	0.170606
1000	0.049563	0.149137	0.224154	0.224379	0.168284
100000	0.049785	0.149359	0.224043	0.224045	0.168034
Pois(3)	**0.049787**	**0.149361**	**0.224042**	**0.224042**	**0.168031**

$n = 10$ 时误差已只有约 1% 量级，$n = 1000$ 时小数点后四位全对。**这个极限的实用性很强**：当 n 大、p 小时用泊松近似二项，能把 $\binom{n}{k}$ 与 $(1-p)^{n-k}$ 两个难算的因子换成一个简单的 $e^{-\lambda}$。

反例（np 不固定的失效）：定理要求 $np \to \lambda$ 是**固定常数**。若 p 不随 n 变小（比如固定 $p = 0.5$），则 $np \to \infty$，二项分布不会收敛到任何固定泊松分布——它会向正态分布靠拢（讲次 25 的中心极限定理）。**泊松极限是"稀有事件"的极限，不是"大样本"的通用极限。**

定理 19.6（独立泊松随机变量之和仍是泊松）：设 $X \sim \mathbf{Pois}(\lambda)$ 与 $Y \sim \mathbf{Pois}(\mu)$ **独立**，则

$$X+Y\sim \mathrm{Pois}(\lambda+\mu).$$

证明策略：**分情形 + 卷积 + 二项式定理**。要求 $X+Y=k$，就必须穷举 X 取 $0,1,\dots,k$ 的全部情形（这是一个划分），然后用独立性把 $\Pr[X=j,Y=k-j]$ 拆成乘积，最后识别出二项式定理。

逐步推导：

1. 对事件 $\{X+Y=k\}$ 按 X 的取值分情形（互斥且穷尽）：

$$\Pr[X+Y=k]=\sum_{j=0}^{k}\Pr[X=j,\,Y=k-j].$$

1. 由**独立性**（讲次 18 定义）$\Pr[X=j,Y=k-j]=\Pr[X=j]\Pr[Y=k-j]$：

$$=\sum_{j=0}^{k}\frac{\lambda^{j}}{j!}e^{-\lambda}\cdot\frac{\mu^{k-j}}{(k-j)!}e^{-\mu}.$$

1. 提出公因子 $e^{-(\lambda+\mu)}$，并**凑出二项式系数**（分子分母同乘 $k!$）：

$$=e^{-(\lambda+\mu)}\sum_{j=0}^{k}\frac{\lambda^{j}\mu^{k-j}}{j!\,(k-j)!}=e^{-(\lambda+\mu)}\cdot\frac{1}{k!}\sum_{j=0}^{k}\frac{k!}{j!\,(k-j)!}\lambda^{j}\mu^{k-j}=e^{-(\lambda+\mu)}\cdot\frac{1}{k!}\sum_{j=0}^{k}\binom{k}{j}\lambda^{j}\mu^{k-j}.$$

1. 括号里正是**二项式定理** $(a+b)^k=\sum_{j=0}^{k}\binom{k}{j}a^{j}b^{k-j}$ 在 $a=\lambda,b=\mu$ 处的值：

$$=e^{-(\lambda+\mu)}\frac{(\lambda+\mu)^{k}}{k!}.\qquad\blacksquare$$

1. **推广**：由归纳法，若 $X_1,\dots,X_n$ 相互独立且 $X_i\sim\mathrm{Pois}(\lambda_i)$，则 $\sum_i X_i\sim\mathrm{Pois}(\sum_i\lambda_i)$。

【证明机制解说】：这个证明是"**卷积 (convolution)**"的标准形状：要得到和的分布，就把联合分布沿"和为定值"的对角线求和。第 3 步"凑二项式系数"是最漂亮的一手——**泊松的两项相乘后天然长出二项式的骨架**，因为 $\frac{1}{j!(k-j)!}=\frac{1}{k!}\binom{k}{j}$。数值验证（脚本）：把 $\mathrm{Pois}(2)$ 与 $\mathrm{Pois}(3)$ 做卷积，得到的 $k=0..6$ 值为 $0.006738, 0.033690, 0.084224, 0.140374, 0.175467, 0.175467, 0.146223$，与直接算 $\mathrm{Pois}(5)$ 完全相同。

反例（独立条件不可省）：若 $X=Y$（完全相关，$X\sim\mathrm{Pois}(3)$），则 $X+Y=2X$ 只取偶数，$\Pr[X+Y=1]=0$，而 $\mathrm{Pois}(6)$ 给出 $\Pr=6e^{-6}\approx 0.0149$。**"和仍是泊松"完全依赖独立性。**

与经典问题的联系

1. 纠错码与网络：需要多少冗余包？（讲次 8 的应用）

把 n 个数据包编码成 $n+k$ 个，通过 RS 码/Berlekamp–Welch 使得接收任意 n 个即可重建（讲次 8）。若每个包独立地以概率 p 丢失，收到的包数 $X\sim\mathrm{Bin}(n+k,\,1-p)$，成功解码概率

$$\Pr[X\ge n]=\sum_{i=n}^{n+k}\binom{n+k}{i}(1-p)^{i}p^{\,n+k-i}.$$

脚本验算（$n=10,p=0.1$）：$k=3$ 时 0.965839，$k=5$ 时 0.997750，$k=8$ 时 0.999979，$k=10$ 时 0.999999。要让成功率 ≥ 0.99，$k=5$ 就够了。**"每个包丢失是独立伯努利试验"这个建模假设，直接给出了可计算的答案**——这正是二项分布存在的意义。

2. 哈希与负载均衡：空桶数（讲次 20 的伏笔）

把 m 个球独立均匀地扔进 n 个桶。令 Y 为空桶数。Y 的分布"horrible to contemplate"（源 Note 的原话），但它在后面（讲次 20/23）将被轻松处理：把 Y 写成指示变量之和，用线性性期望得到 $\mathbb{E}[Y]=n\big(1-\frac{1}{n}\big)^{m}$，再配合切比雪夫/切尔诺夫（讲次 23）证明空桶数高度集中在 n/e 附近。这里先记住单个桶为空是一个 $\mathrm{Ber}((1-1/n)^m)$。脚本验算：$n=m=1000$ 时 $\mathbb{E}[Y]=367.695$，而 $n/e=367.879$。

3. 排队论与网络流量：泊松到达

设呼叫以平均速率 λ 每分钟随机到达，且不重叠时间区间内的到达独立（这是"泊松过程"的两条公理）。把一分钟切成 n 个极短区间，每区间到达概率约 λ/n，则由定理 19.5，一分钟内的呼叫数 $\sim\mathrm{Pois}(\lambda)$。由此立刻可以算"交换机过载"的概率 $\Pr[X>C]=\sum_{k>C}\frac{\lambda^{k}}{k!}e^{-\lambda}$——这是容量规划的基本公式。泊松分布的"均值 = 方差"性质还告诉我们：**流量越平均（方差小），所需的缓冲越少**。

4. 论文校对的"至少一页有 5 个 typo"

设每页 typo 数 $\sim\mathrm{Pois}(1)$（平均一页一个）。则单页恰有 5 个 typo 的概率是

$$\Pr[X=5]=\frac{1^{5}}{5!}e^{-1}=\frac{1}{120e}\approx 0.0030657\approx\frac{1}{326.19}.$$

200 页的论文中"至少有一页恰好 5 个 typo"的概率，用**互补技巧 + 独立性**：

$$\Pr[\exists\text{ 某一页恰有 }5\text{ 个 typo}]=1-\left(1-\frac{1}{120e}\right)^{200}\approx 0.458858.$$

（脚本验算：0.458858；用近似 $1-e^{-200q}$ 得 0.458348。）接近一半！这个反直觉的结果说明：**稀有事件乘以大量机会，就不再稀有**——这正是生日悖论（讲次 15）的同一个机制。

5. 期望等待时间与重传协议

网络上一次包传输成功的概率是 p，则重传次数 $X \sim \text{Geo}(p)$，$\mathbb{E}[X] = 1/p$（讲次 20 严格证明）。若 $p = 0.3$，平均要传 3.33 次（脚本验算：数值求和得 3.333333，与 $1/p$ 一致）。无记忆性（定理 19.3）还给出一个重要工程结论：**"已经失败了很多次"不改变下一次成功的概率**，所以重传策略不应该根据"历史失败次数"来调整退避窗口之外的任何参数——历史是无关信息。

与其他讲次的关联

- **讲次 15（概率公理）**：随机变量的定义建立在"样本点 + 样本点概率"之上；$\Pr[X = a]$ 之所以合法，是因为 $\{X = a\}$ 是 Ω 的子集；PMF 求和为 1 是 $\{X = a\}$ 构成 Ω 的**划分** + 概率可加性的直接推论。4 枚硬币 $(1, 4, 6, 4, 1)/16$ 的分布表就是讲次 15 均匀样本空间的直接归并。
- **讲次 17（条件概率与贝叶斯）**：几何分布的无记忆性（定理 19.3）是条件概率定义的直接应用；泊松分布的"稀有事件"解释用的是"把时间分段 + 条件独立"的贝叶斯式建模。反过来，讲次 17 提到的朴素贝叶斯里"给定类别后特征条件独立"这一假设，正是在随机变量层面的条件独立。
- **讲次 18（独立性与事件组合）**：本讲的独立性定义（$\Pr[X = a, Y = b] = \Pr[X = a]\Pr[Y = b]$）是把讲次 18 的事件独立性**逐取值**搬运过来；二项分布的 PMF 推导完全靠讲次 18 的**独立乘积法则**（每个序列概率 $p^k(1-p)^{n-k}$）；几何分布的合法性验证靠几何级数；泊松是二项的极限（定理 19.5）。Union Bound 与互补技巧则在本讲的"至少一页"算例中再次出场。
- **讲次 14（计数）**：二项分布里 $\binom{n}{k}$ 就是"从 n 个位置中选 k 个放 H"的组合计数（第一/第三计数法则）；超几何分布（定理 19.1 的反例）用的是自然数分解式计数；定理 19.5 中 $\binom{n}{k}$ 的极限处理用到 $\binom{n}{k} = n!/(k!(n-k)!)$ 的展开。**"计数 × 独立性 = 分布"是本讲的主旋律。**
- **讲次 16（组合证明 / 官方 Note "Functions of Random Variables"）**：$Y = g(X)$ 的分布由 $\Pr[Y = y] = \sum_{x:g(x)=y} \Pr[X = x]$ 给出，事件层面即 $\{Y = y\} = \{X \in g^{-1}(y)\}$；同时，"随机变量的函数仍是随机变量"是官方 Note 16 的起点，并直接引出 $\mathbb{E}[f(X)] = \sum_x f(x)p_X(x)$（所谓 LOTUS），是讲次 20 的核心工具。
- **讲次 20（期望与线性性）**：本讲已经把期望的定义、指示变量 $\mathbb{E}[\mathbf{1}[A]] = \Pr[A]$、以及 $X \sim \text{Bin}(n,p) \Rightarrow \mathbb{E}[X] = np$ 的口径埋好。讲次 20 会用**线性性期望**把二项、几何、空桶数等期望一行算出（几何期望还有一条漂亮的"首抛分情形"方程 $E = p \cdot 1 + (1-p)(1+E)$）。
- **讲次 21（联合分布与随机变量独立性）**：本讲已给出联合分布 $\Pr[X = a, Y = b]$ 与边缘分布 $\Pr[X = a] = \sum_b \Pr[X = a, Y = b]$ 的定义；讲次 21 会深入一般 n 元联合分布与独立性判定。
- **讲次 22（方差与协方差）**：本讲预告了各分布的方差（Bin: $np(1-p)$，Geo: $(1-p)/p^2$，Pois: λ）；$\mathbb{E}[X(X-1)] = \lambda^2$ 这类"阶乘矩"技巧在讲次 22 全面展开。$Y = X^2$ 与 X 不独立、不相关却非独立的例子，将是讲次 22 的重点。
- **讲次 23（集中不等式）**：泊松分布的尾部（$\Pr[X \geq c\lambda]$ 随 c 指数衰减）与二项分布的尾部将由切尔诺夫界定量；"均值 = 方差"的性质让切比雪夫界在泊松上表现良好。
- **讲次 24（连续概率与指数分布）**：几何分布是**指数分布 (Exponential distribution)** 的离散类比——两者都具备无记忆性，且"非负整数上只有几何、非负实数上只有指数具备无记忆性"。
- **讲次 25（正态分布与 CLT）**：泊松分布随 λ 增大趋于对称的"钟形"（源 Note 图 2 的观察），正是中心极限定理的体现；$X_1 + \cdots + X_n \sim \text{Pois}(n\lambda)$ 标准化后将收敛到标准正态。

关键要点

1. **随机变量是函数**，$X : \Omega \to \mathbb{R}$。随机的是 ω，不是 X。$\{X = a\}$ 是 Ω 的子集，所以 $\Pr[X = a]$ 良定义；不同 a 的 $\{X = a\}$ 构成 Ω 的划分，故 $\sum_a p_X(a) = 1$ 且 $p_X(a) \geq 0$。
2. **判据：任何 PMF 必须先验证"非负 + 求和为 1"**。几何分布靠几何级数 $\sum_{k \geq 1}(1-p)^{k-1}p = p \cdot \frac{1}{1-(1-p)} = 1$；泊松靠泰勒级数 $e^{-\lambda}\sum_k \lambda^k/k! = e^{-\lambda}e^{\lambda} = 1$。**没有这一步，分布就是空头支票。**
3. **二项 PMF 的推导模板**："先数位置（$\binom{n}{k}$），再算单个序列的概率（$p^k(1-p)^{n-k}$，用独立乘积法则），最后相加（互斥可加）"。提取出的副产品 $\sum_k \binom{n}{k}p^k(1-p)^{n-k} = 1$ 是二项式定理的概率证明。
4. **四个分布的定位一句话**：伯努利 = 一次成功与否（$\mathbb{E} = p$）；二项 = n 次里成功几次（$\mathbb{E} = np$）；几何 = 首次成功要等几次（$\mathbb{E} = 1/p$，无记忆 $\Pr[X > n+m \mid X > n] = \Pr[X > m]$）；泊松 = 稀有事件在单位区域里发生几次（$\mathbb{E} = \text{Var} = \lambda$，是 $\text{Bin}(n, \lambda/n)$ 在 $n \to \infty$ 时的极限）。
5. **独立性在两个层面都要会写**：事件层面 $\Pr[A \cap B] = \Pr[A]\Pr[B]$（讲次 18），随机变量层面 $\Pr[X = a, Y = b] = \Pr[X = a]\Pr[Y = b]$ 对所有 a, b（本讲）。二项分布的推导、泊松可加性（定理 19.6）都**必须**用到它。
6. **求 $g(X)$ 的分布就是"枚举 + 合并"**：$\Pr[Y = y] = \sum_{x:g(x)=y} \Pr[X = x]$。别想着回到 Ω 去数样本点，在 X 的分布表上做归并即可。

常见误区与注意事项

1. **把随机变量当"变量"来解方程**。X 是函数，$X = 3$ 是一个**事件**（Ω 的子集），"解 $X = 3$"没有意义。$X + Y$ 也是函数，$(X+Y)(\omega) = X(\omega) + Y(\omega)$，"随机变量等式"必须逐样本点成立。
2. **写出 PMF 却不验证求和为 1**。例如把"取值为 $1, 2, \ldots$ 且 $\Pr[X = k] = c \cdot (1-p)^k$"当成几何分布——这个式子求和是 $c(1-p)/p$，需要 $c = p/(1-p)$ 才合法。**几何分布的指数是 $k-1$，不是 k**，这是最常见的差一错误；写成 $(1-p)^k p$ 会让总和变成 $1-p$ 而非 1。
3. **二项分布的"独立同分布"两个条件都要**。无放回抽样（超几何）不独立；各次成功概率不同（泊松二项）也不同分布。定理 19.1 的反例给出数值证据：$\text{Bin}(3, 0.5)$ 的 $\Pr[Y = 0] = 0.125$ 与真实超几何的 0.0833 明显不同。
4. **误用无记忆性、陷入赌徒谬误**。"我已经连续抛了 10 次反面，下一次该正面了"——对独立硬币**完全错误**。$\Pr[\text{第 } 11 \text{ 次} = H] = 1/2$。无记忆性 $\Pr[X > n+m \mid X > n] = \Pr[X > m]$ 正是这个事实的严格表述。但要小心：**无记忆性只对几何/指数分布成立**，骰子等待时间（均匀分布）不满足。
5. **把泊松分布的 λ 当成"最大可能取值"或"上界"**。λ 只是均值；$\text{Pois}(3)$ 取到 8 的概率还有 0.0081。它的支撑集是整个 $\{0, 1, 2, \ldots\}$。
6. **误用"和的分布"的可加性**。$X + Y \sim \text{Pois}(\lambda + \mu)$ 要求 X, Y **独立且都是泊松**；若 $X = Y$ 则 $2X$ 不是泊松。同理，两个二项相加 $\text{Bin}(n,p) + \text{Bin}(m,p) \sim \text{Bin}(n+m,p)$ 要求 p **相同**且独立——p 不同时结果不是二项分布。

7. **混淆 $\mathbb{E}[g(X)]$ 与 $g(\mathbb{E}[X])$**。$\mathbb{E}[X^2] \neq (\mathbb{E}[X])^2$（差别正是方差），$\mathbb{E}[1/X] \neq 1/\mathbb{E}[X]$。这是讲次 20 起反复强调的坑，在本讲建立 $Y = X^2$ 的分布时就要有意识：$X \sim \text{Bin}(3, 0.5)$ 时 $\mathbb{E}[X^2] = 3$ 而 $(\mathbb{E}[X])^2 = 1.5^2 = 2.25$（脚本验算：$3$ 与 2.25）。
8. **忘记 $\Pr[X = a]$ 是对每个取值都要给出的完整清单**。只写 $\Pr[X = 1] = p$ 而不写 $\Pr[X = 0] = 1 - p$，分布就没写完。同样，说"X 是伯努利"必须同时交代参数 p。

思考题（带答案）

Q1（纯计算）. 反复独立抛一枚正面概率 $p = 0.2$ 的硬币，令 X 为首次出现正面所需的次数。求：(a) $\Pr[X = 3]$；(b) $\Pr[X \leq 3]$；(c) $\Pr[X > 5]$；(d) $\mathbb{E}[X]$ 与 $\text{Var}(X)$；(e) $\Pr[X > 8 \mid X > 3]$。

> ▸ **答案**
>
> $X \sim \text{Geo}(0.2)$。
>
> (a) $\Pr[X = 3] = (1 - 0.2)^2 \cdot 0.2 = 0.8^2 \cdot 0.2 = 0.64 \cdot 0.2 = \mathbf{0.128}$。
>
> (b) $\Pr[X \leq 3] = 1 - \Pr[X > 3] = 1 - 0.8^3 = 1 - 0.512 = \mathbf{0.488}$。（脚本验算：$0.488000$。）
>
> (c) $\Pr[X > 5] = 0.8^5 = \mathbf{0.32768}$。
>
> (d) $\mathbb{E}[X] = 1/p = 1/0.2 = \mathbf{5}$；$\text{Var}(X) = (1 - p)/p^2 = 0.8/0.04 = \mathbf{20}$。
>
> (e) 由**无记忆性**（定理 19.3），$\Pr[X > 8 \mid X > 3] = \Pr[X > 5] = 0.8^5 = \mathbf{0.32768}$。也可以硬算：$\frac{0.8^8}{0.8^3} = 0.8^5$，完全一致。**注意"已经等了 3 次"没有让成功更近**。

Q2（纯计算）. 某网络节点在 1 秒内收到的包数 $X \sim \text{Pois}(3)$。求：(a) $\Pr[X = 0]$；(b) $\Pr[X \geq 2]$；(c) 若把观察时间延长到 2 秒，且两秒内的到达由两个独立的 $\text{Pois}(3)$ 叠加而成，求这 2 秒内至少收到 2 个包的概率；(d) 该分布的均值与方差。

> ▸ **答案**
>
> (a) $\Pr[X = 0] = \dfrac{3^0}{0!} e^{-3} = e^{-3} \approx \mathbf{0.049787}$。
>
> (b) $\Pr[X \geq 2] = 1 - \Pr[X = 0] - \Pr[X = 1] = 1 - e^{-3} - 3e^{-3} = 1 - 4e^{-3} \approx 1 - 4(0.049787) = \mathbf{0.800852}$。（脚本验算：$0.800852$。）
>
> (c) 由定理 19.6，两秒内的总到达数 $Y \sim \text{Pois}(3 + 3) = \text{Pois}(6)$。$\Pr[Y \geq 2] = 1 - e^{-6} - 6e^{-6} = 1 - 7e^{-6} \approx 1 - 7(0.0024788) = \mathbf{0.982649}$。
>
> (d) $\mathbb{E}[X] = \lambda = \mathbf{3}$，$\text{Var}(X) = \lambda = \mathbf{3}$（泊松分布均值等于方差；脚本验算 $\text{Pois}(3)$ 的数值均值与方差均为 3.000000）。

Q3（概念/证明）. 设 $X \sim \text{Bin}(n, p)$。请写出 $\mathbb{E}[X]$ 的定义式并说明它为什么"难以直接计算"，然后指出讲次 20 会用什么方法绕过它（只要求指出思路，不需要完成计算）。

> ▸ **答案**
>
> 定义式是
>
> $$\mathbb{E}[X] = \sum_{k=0}^{n} k \binom{n}{k} p^k (1 - p)^{n-k}.$$
>
> **难点**：这个和式含二项式系数，直接求和需要用 $k\binom{n}{k} = n\binom{n-1}{k-1}$ 这类组合恒等式（讲次 14 的工具）配合二项式定理，推导繁琐；若是多个随机变量的和（例如"空桶数"），其**分布本身**就几乎写不出来，更谈不上从定义式求和。
>
> **讲次 20 的思路**：把计数型随机变量写成**指示变量之和**，然后用**线性性期望** $\mathbb{E}[\sum_i I_i] = \sum_i \mathbb{E}[I_i]$（**不需要独立性**）。对二项分布，令 $I_i = \mathbf{1}[\text{第 } i \text{ 次试验成功}]$，则 $X = \sum_{i=1}^{n} I_i$，而 $\mathbb{E}[I_i] = \Pr[I_i = 1] = p$，于是
>
> $$\mathbb{E}[X] = \sum_{i=1}^{n} \mathbb{E}[I_i] = np,$$
>
> 一行搞定。（脚本验算：$\text{Bin}(20, 0.3)$ 的数值均值 $= 6.000000 = np$。）

Q4（反例辨析）. 设 X 在 $\{-1, 0, 1\}$ 上均匀取值，令 $Y = X^2$。请计算 $\mathbb{E}[XY]$ 与 $\mathbb{E}[X]\mathbb{E}[Y]$，判断 X, Y 是否不相关；再直接检查 X, Y 是否独立。这个例子说明了什么？

▸ **答案**

（脚本验算：$\mathbb{E}[X]=0$，$\mathbb{E}[Y]=2/3\approx 0.666667$，$\mathbb{E}[XY]=0$。）

- X 在 $\{-1,0,1\}$ 上均匀，故 $\mathbb{E}[X]=\frac{-1+0+1}{3}=0$。
- $Y=X^2$ 取 $0,1,1$，故 $\mathbb{E}[Y]=\frac{0+1+1}{3}=\frac{2}{3}$。
- $XY=X^3$ 取 $-1,0,1$，故 $\mathbb{E}[XY]=0$。
- 于是 $\mathbb{E}[XY]=0=\mathbb{E}[X]\mathbb{E}[Y]$，即 $\mathrm{Cov}(X,Y)=0$，X 与 Y **不相关**（uncorrelated）。

但**它们绝不独立**：取 $a=1,b=1$。$\Pr[X=1,Y=1]=\Pr[X=1]=1/3$（因为 $X=1\Rightarrow Y=1$），而 $\Pr[X=1]\Pr[Y=1]=\frac{1}{3}\cdot\frac{2}{3}=\frac{2}{9}\approx 0.2222$。$1/3\neq 2/9$，故事件 $\{X=1\}$ 与 $\{Y=1\}$ 不独立，从而 X,Y **不独立**。

结论：**不相关是比独立弱得多的条件**。$Y=X^2$ 显然"完全由 X 决定"，却因为 X 的对称性使协方差恰好为零。这正是讲次 18"两两独立 $\neq$ 相互独立"在随机变量层面的翻版，讲次 22 会正式给出协方差的定义与这个反例的完整分析。

Lecture 20: Expectations & Linearity（期望与线性性）

概述

上一讲（Lecture 19）我们定义了随机变量 (random variable) 并给出了它的**分布 (distribution)**，即完整的信息载体 $\{(a,\Pr[X=a])\}$。但完整的分布往往既算不出来、也不好看懂：20 个学生随机交换作业时固定点的分布，原则上要枚举 $20!\approx 2.4\times 10^{18}$ 个样本点。本讲的目标是用一个**数字摘要**代替整个分布，这个摘要就是**期望 (expectation)**。

本讲的核心工具是**指示随机变量 (indicator random variable)** 与**期望的线性性 (linearity of expectation)**。核心结论只有一句话：$\mathbb{E}[X+Y]=\mathbb{E}[X]+\mathbb{E}[Y]$，而且**完全不需要 X 与 Y 独立**。这条"免费午餐"是整门 CS70 后半段最有用的技术：把一个"全局复杂"的随机量（总碰撞数、最大负载、集齐优惠券的次数）拆成许多"局部简单"的指示变量之和，逐项求期望再相加。本讲将用它一次性拿下三大经典应用：**二项分布的期望**、**收集者问题 (coupon collector)**、**哈希与负载均衡 (hashing / load balancing)**。

核心概念的直观解释

期望（Expectation / Expected Value / Mean / Average）

- **定义**：设 X 是取值集合为 A 的离散随机变量。X 的期望定义为

$$\mathbb{E}[X]\;=\;\sum_{a\in A} a\cdot\Pr[X=a].$$

也就是说：**把每个可能取值乘上它发生的概率，再把所有项加起来**。等价地，用下标 $f(x)$ 表示概率质量函数时写作 $\mathbb{E}[X]=\sum_x x\,f(x)$。

- **直观解释（"它是什么意思？"）**：期望是**概率加权的平均值**。它回答的问题不是你这一次实验会得到什么，而是"如果我把这套实验重复成千上万次，平均下来每个结果是多少"。三种等价的心理图像：
- **长期平均**：掷一枚公平硬币，正面记 $+1$、反面记 -1。单次结果永远是 ± 1，但掷 10^6 次后把结果平均，会稳定在 0 附近——这个 0 就是期望。这就是 Lecture 23 大数定律要精确化的直觉。
- **物理质心**：把概率分布想象成一块木板，在位置 a 处放上质量 $\Pr[X=a]$。整块木板的**重心**（平衡点）恰好在 $x=\mathbb{E}[X]$ 处。这就是官方 Note 中那个"木制剪影的重心"图景：质量大的地方把平衡点拉过去。
- **加权平均的推广**：普通平均是每个取值权相等（各 $1/n$）；期望允许不同取值有不同的权重，权重就是概率，且权重之和必须为 1。
- **具体示例**：掷一枚公平骰子，X 是朝上的点数。X 以概率 $1/6$ 取 $1,2,\dots,6$，于是

$$\mathbb{E}[X]=\frac{1}{6}(1+2+3+4+5+6)=\frac{21}{6}=\frac{7}{2}=3.5.$$

- **注意一：期望不必是 X 实际可能取到的值。** 上例中 X 永远取不到 3.5——骰子没有面朝上写着 3.5。期望是分布的"平衡点"，而平衡点可以落在两个支撑点中间。这与"最大值"、"众数"这类必须取到的统计量截然不同。
- **注意二：期望可能不存在（为无穷）。** 官方 Note 有一条技术注记：定义式里的级数必须**绝对收敛**，即 $\sum_a |a|\Pr[X=a]<\infty$，期望才良定义。反例：设 X 以概率 2^{-k} 取值 2^k（$k=1,2,3,\dots$）。先验证这是合法分布：$\sum_{k\ge 1}2^{-k}=1$ ✔。但

$$\mathbb{E}[X]=\sum_{k\ge 1}2^k\cdot 2^{-k}=\sum_{k\ge 1}1=+\infty.$$

这个随机变量每次取到的都是有限的数，但期望是无穷大——这正是"圣彼得堡悖论"类赌博的形态。本讲后续的所有结论都默认涉及的期望存在且有限。

指示随机变量（Indicator Random Variable）

- **定义**：设 A 是概率空间中的事件。A 的**指示随机变量 (indicator r.v.)** 定义为

$$I_A(\omega)=\begin{cases}1, & \omega\in A \quad (\text{即 } A \text{ 发生}),\\ 0, & \omega\notin A \quad (\text{即 } A \text{ 不发生}).\end{cases}$$

- **直观解释（"它是什么意思？"）**：指示变量是"把'是/否'翻译成'1/0'"的开关。它是一个货真价实的随机变量（函数 $I_A:\Omega\to\{0,1\}\subseteq\mathbb{R}$），因而可以做加法、可以被求期望。它的期望算起来简单到近乎无脑：

$$\mathbb{E}[I_A] = 0 \cdot \Pr[I_A = 0] + 1 \cdot \Pr[I_A = 1] = \Pr[I_A = 1] = \Pr[A].$$

这个观察看似平凡，却是整讲威力的来源。 原因在于：把一个"数数"型随机量写成指示变量之和后，求期望就退化成"把一堆概率加一加"——概率往往比分布好算得多。

- **具体示例**：掷一枚公平骰子，$A =$"点数不小于 5"。则 I_A 以概率 $2/6$ 取 1，以概率 $4/6$ 取 0，$\mathbb{E}[I_A] = \Pr[A] = 1/3$。你不需要写出"$I_A$ 的分布"以外的任何东西。

更典型的例子：设 X_n 表示 n 个学生随机交换作业后拿到自己作业的人数（即随机排列的**固定点 (fixed point)** 个数）。X_n 的分布极其难算，但我们可以把它写成

$$X_n = I_1 + I_2 + \cdots + I_n, \qquad I_i = \begin{cases} 1, & \text{第 } i \text{ 个学生拿回自己的作业,} \\ 0, & \text{否则.} \end{cases}$$

于是 $\mathbb{E}[X_n] = \sum_i \mathbb{E}[I_i] = \sum_i \Pr[\text{学生 } i \text{ 拿回自己的作业}] = \sum_i \frac{1}{n} = n \cdot \frac{1}{n} = 1$。**无论 n 多大，期望固定点个数恒为 1。**

期望的线性性（Linearity of Expectation）

- **定义（陈述）**：对**同一个概率空间**上的任意两个随机变量 X, Y，以及任意常数 $c \in \mathbb{R}$，

$$\mathbb{E}[X + Y] = \mathbb{E}[X] + \mathbb{E}[Y], \qquad \mathbb{E}[cX] = c\mathbb{E}[X].$$

- **直观解释（"它是什么意思？"）**：期望是"以概率为权重的求和"，而求和本身是线性的。既然 $\sum_\omega$ 可以逐项拆开、常数可以提出，那么先取期望再相加、和先相加再取期望，结果必然一样。

但真正让这条定理"不平凡"的是它的**附带条件为零**：它**不要求 $X \perp Y$**，不要求同分布，不要求有限取值，甚至允许两个变量是同一个变量（$\mathbb{E}[X + X] = 2\mathbb{E}[X]$）。对比一下：Lecture 19 学过的"独立事件才有的乘法法则"需要独立性，而这里的加法法则什么都不需要。这是概率论里罕见的"免费午餐"。

- **具体示例**：两枚骰子的点数之和 $X = Y_1 + Y_2$。单枚骰子 $\mathbb{E}[Y_1] = \mathbb{E}[Y_2] = 7/2$。于是不用算 X 的分布（那需要 11 项加和），直接得 $\mathbb{E}[X] = 7/2 + 7/2 = 7$。若用定义硬算：$\mathbb{E}[X] = 2 \cdot \frac{1}{36} + 3 \cdot \frac{2}{36} + \cdots + 12 \cdot \frac{1}{36} = 7$（脚本验算 ✔），费时数倍。

调和数（Harmonic Number）

- **定义**：$H_n = \sum_{i=1}^{n} \frac{1}{i} = 1 + \frac{1}{2} + \frac{1}{3} + \cdots + \frac{1}{n}$，约定 $H_0 = 0$。
- **直观解释**：它是"倒数之和"，增长极慢——大约与 $\ln n$ 同阶。收集者问题的答案恰好是 nH_n，所以 H_n 的估计直接决定答案的量级。
- **具体示例**：$H_1 = 1$，$H_2 = 1.5$，$H_3 = \frac{11}{6} \approx 1.8333$，$H_{10} \approx 2.92897$（脚本精确值 2.9289682539682538），$H_{100} \approx 5.18738$，$H_{1000} \approx 7.48547$。

精确的夹逼（用积分比较，见后文推导）：$\ln n < H_n < \ln n + 1$。更精细的近似是 $H_n \approx \ln n + \gamma$，其中 $\gamma \approx 0.5772156649$ 是**欧拉常数 (Euler's constant)**。数值验证：$n = 10$ 时 $\ln 10 + \gamma = 2.3026 + 0.5772 = 2.8798$ 对比真值 2.9290；$n = 100$ 时 $\ln 100 + \gamma = 5.1824$ 对比真值 5.1874 —— 随 n 增大越来越准。

指示变量分解的"总一分"结构可以画成这样（以"m 个球投 n 个箱，数空箱数"为例）：

```
全局难算的量:  Y = "有多少个箱子是空的"
──────────────────────────────────────────────────────────
Y =  I_1  +  I_2  +  I_3  + ... +  I_n
     │       │       │              │
     │       │       │              └─ I_n = 1 若箱 n 为空, 否则 0
     │       │       └──────────────── I_3 = 1 若箱 3 为空, 否则 0
     │       └──────────────────────── I_2 = 1 若箱 2 为空, 否则 0
     └──────────────────────────────── I_1 = 1 若箱 1 为空, 否则 0

每个 I_j 只看"一个箱子", 完全不管别的箱子 → 期望好算:
     E[I_j] = Pr[箱 j 为空] = (1 − 1/n)^m

线性性把 n 个局部期望加回来 (不需要各 I_j 独立!):
     E[Y] = E[I_1] + ... + E[I_n] = n (1 − 1/n)^m
──────────────────────────────────────────────────────────
同一个招式换个"拆分单位"就得到别的结果:
     • 拆成"每个球" → E[箱 1 里的球数] = m/n
     • 拆成"每个键对"→ E[碰撞对数] = C(m,2) / n
     • 拆成"每个阶段"→ E[集齐券的盒数] = n H_n     (见下图)
```

如下是把"集齐 n 张券所需的总盒数"切成 n 个阶段（这是收集者问题的分解图，取 $n = 7$）：

```
时间轴（每格 = 买一盒谷物，格子里写的是抽到的券号；n = 7）

盒号:   1   2   3   4   5   6   7   8   9  10  11  12  13  14  15
券号:   3   3   7   7   7   1   7   4   4   7   2   7   7   5   6
阶段:   1   1   2   2   2   3   3   4   4   4   5   5   5   6   7
        ^       ^           ^       ^           ^           ^   ^

每个 ^ 标记"抽到一张新券"的那一盒 —— 它同时终结上一阶段、开启下一阶段。
未被标记的格子抽到的是"重券"（已经在手里的券），它们只是把当前阶段拉长。
第 1 段末尾的 ^（盒1，券3）是全新；第 2 段末尾的 ^（盒3，券7）也是全新；
而盒 4、5 的券 7 则是重券 —— 它们把第 3 段从 1 盒拉长到了 3 盒。

阶段 i | 覆盖盒号 | 开始时已集齐 | 剩下没见过 |  p_i  |  X_i
-------+----------+--------------+------------+-------+-----
   1   |   1      |      0 种    |    7 种    |  7/7  |   1
   2   |  2 – 3   |      1 种    |    6 种    |  6/7  |   2
   3   |  4 – 6   |      2 种    |    5 种    |  5/7  |   3
   4   |  7 – 8   |      3 种    |    4 种    |  4/7  |   2
   5   |  9 – 11  |      4 种    |    3 种    |  3/7  |   3
   6   | 12 – 14  |      5 种    |    2 种    |  2/7  |   3
   7   | 15       |      6 种    |    1 种    |  1/7  |   1
-------+----------+--------------+------------+-------+-----
校验:  T = X_1+...+X_7 = 1+2+3+2+3+3+1 = 15 = 买盒总数 ✔

X_i ~ Geometric(p_i)，其中 p_i = (n − i + 1)/n
期望: E[T] = sum_i 1/p_i = 7(1/7+1/6+1/5+1/4+1/3+1/2+1/1) = 7 H_7 ≈ 18.15
一般: E[T] = n H_n ≈ n ln n
```

球的投箱模型（Balls and Bins）

- **定义**：把 m 个球**独立地、均匀随机地**投入 n 个箱子，即每个球独立地以概率 $1/n$ 落入任意指定的箱子。样本空间大小 n^m，每个样本点概率 n^{-m}。
- **直观解释**：这是概率论里最万能的"建模母版"。哈希（键=球，表槽=箱）、负载均衡（作业=球，处理器=箱）、收集者问题（买到的卡片=球，n 种卡片=箱）、生日悖论（人=球，365 天=箱）全都是它的换皮。
- **具体示例**："第 1 个箱子恰好有 k 个球"这一事件的概率是 $\binom{m}{k}(1/n)^k(1-1/n)^{m-k}$，即 $\mathrm{Bin}(m, 1/n)$ ——把"球是否落入箱 1"看成抛 m 次偏置硬币。

LOTUS（无意识统计学家定律，Law of the Unconscious Statistician）

- **定义**：对随机变量 X 与函数 g，

$$\mathbb{E}[g(X)] = \sum_{x} g(x)\,\Pr[X = x].$$

- **直观解释**：要求 $\mathbb{E}[g(X)]$，你**不必要**先把 $g(X)$ 的分布算出来。直接拿 X 的分布在 g 的值域上"按 g 的取值分组"相加即可。它叫"无意识"定律，是因为使用者常常在没意识到自己用了它的情况下就这么算了。
- **具体示例**：骰子 X，求 $\mathbb{E}[X^2]$。用 LOTUS：$\mathbb{E}[X^2] = \frac{1}{6}(1+4+9+16+25+36) = \frac{91}{6} \approx 15.1667$（脚本验算 ✔）。若先求 X^2 的分布：X^2 以 $1/6$ 取 1，$1/6$ 取 4，…，其实结果一样，但多绕了一圈。

完整证明与推导（核心）

本讲的核心证明有五组：**期望的样本点求和式**、**线性性**、**二项分布的期望（两种算法对比）**、**独立则乘积期望可乘**、以及**收集者问题与空箱期望的指示变量分解**。

定理 20.1（期望的两种等价写法）：设 X 是概率空间 $(\Omega, \Pr)$ 上的离散随机变量。则

$$\mathbb{E}[X] = \sum_{a \in A} a \cdot \Pr[X = a] \;=\; \sum_{\omega \in \Omega} X(\omega) \cdot \Pr[\omega].$$

其中 A 是 X 的取值集合。

证明策略：**双计数 / 交换求和次序**。第一种写法按"X 的取值"分组，第二种写法按"样本点"分组。两者是对同一些项做了不同的分组方式，可以用"把每个 $a \cdot \Pr[X=a]$ 中的 $\Pr[X=a]$ 展开成若干 $\Pr[\omega]$ 之和"来打通。选择这个策略，是因为后面证明线性性时，样本点形式能让 $(X+Y)(\omega) = X(\omega) + Y(\omega)$ 这一步变得毫无障碍。

逐步推导：

- 第一步：由定义，$\Pr[X=a]$ 是把所有满足 $X(\omega) = a$ 的样本点概率加起来，即 $\Pr[X=a] = \sum_{\omega:\, X(\omega)=a} \Pr[\omega]$。（依据：概率的可加性 + $\{X=a\}$ 是事件。）
- 第二步：代入定义式：

$$\mathbb{E}[X] = \sum_{a \in A} a \cdot \Big(\sum_{\omega:\, X(\omega)=a} \Pr[\omega] \Big).$$

- 第三步：把外层乘数 a 移入内层求和：$= \sum_{a \in A} \sum_{\omega:\, X(\omega)=a} a \cdot \Pr[\omega]$。（依据：分配律。）
- 第四步：在内层，ω 满足 $X(\omega) = a$，所以 a 可以换成 $X(\omega)$：$= \sum_{a \in A} \sum_{\omega:\, X(\omega)=a} X(\omega) \cdot \Pr[\omega]$。

- 第五步：**关键一步**。因为 X 是**函数**，每个 $\omega \in \Omega$ 属于**恰好一个**事件 $\{X = a\}$。所以"先按 a 分组、组内遍历 ω"与"直接遍历所有 ω"加起来的是同一批项，每项恰好出现一次：

$$= \sum_{\omega \in \Omega} X(\omega) \cdot \Pr[\omega]. \qquad \blacksquare$$

【证明机制解说】：整个证明的"灵光一现"在第五步，而它的合法性完全依赖于"X 是函数"这一事实——正因为 X 给每个 ω **唯一**指定了一个值，事件族 $\{\{X = a\}\}_{a \in A}$ 才构成 Ω 的一个**划分**。如果 X 不是函数（比如一个 ω 对应两个 a），第四步到第五步就会出现重复计数，等式立刻崩塌。这也解释了官方 Note 反复提醒的"随机变量既不随机也不是变量，它是一个函数"——这条性质的第一次真正派上用场就是这里。

另外要留意：样本点形式虽然让**证明**方便，但一般不适合**计算**，因为 $|\Omega|$ 常常是天文数字（$20!$ 级别）。计算的活还是要交给定义式或线性性。

定理 20.2（指示随机变量的期望）：对任意事件 A，$\mathbb{E}[I_A] = \Pr[A]$。

证明策略：直接证明。只需把 I_A 的定义代进期望定义式，0 项自动消失。

逐步推导：

- 第一步：I_A 只取 $0, 1$ 两个值，故 $\mathbb{E}[I_A] = \sum_{a \in \{0,1\}} a \Pr[I_A = a]$。
- 第二步：$= 0 \cdot \Pr[I_A = 0] + 1 \cdot \Pr[I_A = 1] = \Pr[I_A = 1]$。（依据：$0$ 乘以任何数得 0。）
- 第三步：事件 $\{I_A = 1\}$ 与事件 A 是同一个集合（$I_A(\omega) = 1 \iff \omega \in A$），故 $\Pr[I_A = 1] = \Pr[A]$。$\blacksquare$

【证明机制解说】：这是全讲最短的证明，却也是最该背下来的一条。它的价值在于把"求期望"这个看起来需要完整分布的操作，**降级为"求一个概率"**。后面所有指示变量技巧都是这条定理的流水线作业。

定理 20.3（期望的线性性，Linearity of Expectation）：对同一概率空间上的任意随机变量 X, Y 与任意常数 c，

$$\mathbb{E}[X + Y] = \mathbb{E}[X] + \mathbb{E}[Y], \qquad \mathbb{E}[cX] = c\,\mathbb{E}[X].$$

证明策略：**直接证明 + 交换求和次序**（严格说是把有限和拆项）。关键是使用定理 20.1 的**样本点形式**，因为在样本点层面 $(X + Y)(\omega) = X(\omega) + Y(\omega)$ 是逐点成立的实数等式，而定义式层面 $\Pr[X + Y = s]$ 却需要卷积，非常难拆。**这正是选择样本点形式的理由。**

逐步推导：

- 第一步：反复用定理 20.1 的样本点形式。

$$\mathbb{E}[X + Y] = \sum_{\omega \in \Omega} (X + Y)(\omega) \cdot \Pr[\omega].$$

- 第二步：按随机变量加法的定义，$(X + Y)(\omega) = X(\omega) + Y(\omega)$。（依据：随机变量的加法是逐点定义的，与函数的加法相同。）

$$= \sum_{\omega \in \Omega} \big(X(\omega) + Y(\omega)\big) \cdot \Pr[\omega].$$

- 第三步：把每个乘积拆成两项。

$$= \sum_{\omega \in \Omega} X(\omega) \Pr[\omega] + \sum_{\omega \in \Omega} Y(\omega) \Pr[\omega].$$

（依据：$\sum_\omega (a_\omega + b_\omega) = \sum_\omega a_\omega + \sum_\omega b_\omega$，即加法对求和的分配律。**这一步不涉及任何概率论假设。**）

- 第四步：两个和分别就是 $\mathbb{E}[X]$ 与 $\mathbb{E}[Y]$（再用一次定理 20.1），故 $\mathbb{E}[X + Y] = \mathbb{E}[X] + \mathbb{E}[Y]$。
- 第五步（数乘部分）：$\mathbb{E}[cX] = \sum_\omega (cX)(\omega) \Pr[\omega] = \sum_\omega c \cdot X(\omega) \Pr[\omega] = c \sum_\omega X(\omega) \Pr[\omega] = c\,\mathbb{E}[X]$。（依据：常数可以从求和中提出。）$\blacksquare$

【证明机制解说】：请仔细回看上面的推导，**从头到尾没有出现"独立"这两个字，也没有出现任何形如 $\Pr[A \cap B] = \Pr[A] \Pr[B]$ 的式子。** 这不是遗漏，而是本质：线性性是**纯代数**的事实，它只依赖"期望 = 逐点加权求和"这一表达形式，而加权求和天然是线性的。独立性是一条**乘积**法则（$\Pr[A \cap B] = \Pr[A] \Pr[B]$），它管的是交集、是乘法；期望的线性性管的是并集、是加法。**两者属于不同的运算通道，不要混为一谈。**

一个容易被忽略但很能说明问题的推论：取 $Y = X$（同一个随机变量），得 $\mathbb{E}[2X] = \mathbb{E}[X] + \mathbb{E}[X] = 2\mathbb{E}[X]$。这里 X 与 X **当然不独立**（它和自己的相关系数是 1），线性性照样成立。这就是"不需要独立"的最干净证据。

定理 20.4（线性性推广到 n 个随机变量）：对任意随机变量 $X_1, \ldots, X_n$ 与常数 $c_1, \ldots, c_n$，

$$\mathbb{E}\Big[\sum_{i=1}^{n} c_i X_i\Big] = \sum_{i=1}^{n} c_i\,\mathbb{E}[X_i].$$

证明策略：**对 n 做归纳法 (induction)**。因为定理 20.3 已经给出两个变量的情形，正好可以作为归纳步骤的"引擎"；基础情形 $n = 1$ 平凡。选归纳法而不用"直接展开求和"是为了让每一步的依据都落在已证结论上，避免重复劳动。

逐步推导：

- **基础情形 $n = 1$**：$\mathbb{E}[c_1 X_1] = c_1 \mathbb{E}[X_1]$，由定理 20.3 的数乘部分直接成立。✔
- **归纳假设**：设命题对 $n - 1$ 个随机变量成立，即 $\mathbb{E}\big[\sum_{i=1}^{n-1} c_i X_i\big] = \sum_{i=1}^{n-1} c_i \mathbb{E}[X_i]$。
- **归纳步骤**：把 n 项拆成"前 $n - 1$ 项之和"加"第 n 项"。令 $S = \sum_{i=1}^{n-1} c_i X_i$，则

$$\mathbb{E}\Big[\sum_{i=1}^{n} c_i X_i\Big] = \mathbb{E}[S + c_n X_n] \overset{\text{定理 } 20.3}{=} \mathbb{E}[S] + \mathbb{E}[c_n X_n].$$

- 再用一次归纳假设处理 $\mathbb{E}[S]$，用定理 20.3 的数乘部分处理 $\mathbb{E}[c_n X_n]$：

$$= \sum_{i=1}^{n-1} c_i \mathbb{E}[X_i] + c_n \mathbb{E}[X_n] = \sum_{i=1}^{n} c_i \mathbb{E}[X_i]. \qquad \blacksquare$$

【证明机制解说】：注意归纳步骤里 $\mathbb{E}[S + c_n X_n]$ 用定理 20.3 时，S 与 X_n 是**任意**两个随机变量（可能是相关的、可能是同一个），定理 20.3 依然无条件适用——这就是为什么归纳能一路推下去而不需要任何额外假设。若线性性需要独立性，归纳步骤就必须假设 $S \perp X_n$，而 S 是前 $n-1$ 项的混合，"S 与 X_n 独立"远比"每个 X_i 两两独立"更强，定理也就大幅削弱了。

反例（条件不可省的另一面）：既然加法不需要独立性，那"乘法也线性"是不是也成立？即 $\mathbb{E}[XY] = \mathbb{E}[X]\mathbb{E}[Y]$？**不成立**。取 $X \sim \text{Bernoulli}(1/2)$，令 $Y = X$（同一个变量）。则 $XY = X^2 = X$，$\mathbb{E}[XY] = \mathbb{E}[X] = 1/2$，而 $\mathbb{E}[X]\mathbb{E}[Y] = (1/2)^2 = 1/4$。$1/2 \neq 1/4$（脚本验算 ✔）。同理 $\mathbb{E}[1/X] \neq 1/E[X]$：取 X 以概率 $1/2$ 取 1、概率 $1/2$ 取 2，则 $\mathbb{E}[1/X] = \frac{1}{2}\cdot 1 + \frac{1}{2}\cdot\frac{1}{2} = \frac{3}{4}$，而 $1/\mathbb{E}[X] = 1/1.5 = \frac{2}{3}$，两者不等。**线性性只管"和差与常数倍"，绝不可越界用到乘积、倒数、平方上。**

定理 20.5（二项分布的期望）：设 $X \sim \text{Bin}(n, p)$，则 $\mathbb{E}[X] = np$。

证明策略：**指示变量分解 + 线性性**（主算法）；同时给出**定义式直接求和**作为对照算法，用"繁琐程度"凸显线性性的价值。这是本讲的旗舰例子。

逐步推导（算法一：指示变量法，3 行）：

- 第一步：把"抛 n 次硬币数正面"这件事重新叙述为"数 n 次伯努利试验中成功的次数"，从而写成

$$X = I_1 + I_2 + \cdots + I_n, \qquad I_i = \begin{cases} 1, & \text{第 } i \text{ 次抛掷为正面,} \\ 0, & \text{否则.} \end{cases}$$

为什么这个等式成立？因为左边的 $X(\omega)$ 是"序列 ω 中正面的个数"，右边的 $\sum_i I_i(\omega)$ 恰好是"对每个位置检查一次，是正面就记 1"，两者数的是同一批东西。这与定理 20.1 第五步"X 是函数"式的推理同源。 – 第二步：$\mathbb{E}[I_i] = \Pr[\text{第 } i \text{ 次为正面}] = p$。（依据：定理 20.2。） – 第三步：$\mathbb{E}[X] = \sum_{i=1}^{n} \mathbb{E}[I_i] = \sum_{i=1}^{n} p = np$。（依据：定理 20.4。）$\blacksquare$

逐步推导（算法二：定义式直接求和，作为对照）：

- 第一步：由 Lecture 19 的结论，$\Pr[X = k] = \binom{n}{k} p^k (1-p)^{n-k}$，于是

$$\mathbb{E}[X] = \sum_{k=0}^{n} k \binom{n}{k} p^k (1-p)^{n-k}.$$

- 第二步：$k = 0$ 项为 0，从 $k = 1$ 起求和。利用**吸收恒等式 (absorption identity)** $k\binom{n}{k} = n\binom{n-1}{k-1}$：

$$\mathbb{E}[X] = \sum_{k=1}^{n} n \binom{n-1}{k-1} p^k (1-p)^{n-k}.$$

- 第三步：提出一个 p，并把 p^{k-1}、$(1-p)^{(n-1)-(k-1)}$ 重新配对；令 $j = k - 1$：

$$\mathbb{E}[X] = np \sum_{j=0}^{n-1} \binom{n-1}{j} p^j (1-p)^{(n-1)-j}.$$

- 第四步：右端的和恰好是 $\text{Bin}(n-1, p)$ 全部概率之和，由归一性等于 1（这本身是二项式定理的一个概率证明）。故 $\mathbb{E}[X] = np$。$\blacksquare$

数值对照：$n = 5, p = 0.3$。算法二求和：$\sum_{k=0}^{5} k\binom{5}{k} 0.3^k 0.7^{5-k} = 1.5000000000$；算法一：$np = 1.5$。脚本验算完全一致 ✔。

【证明机制解说】：算法一的关键在于**换一个"记账方式"**。原来的记法是"先按正面的总个数分组，再数每组有多少样本点"——这需要 $\binom{n}{k}$，于是要跟阶乘搏斗。新的记法是"按位置逐个数"——每个位置贡献一个 $0/1$，期望就是它的概率。**换个记账方式，同一个量就从"需要组合恒等式"变成"只需要把 n 个 p 加起来"。** 这也是官方 Note 说"用定义会更难"的确切含义：不是不能做，而是做完之后你还得额外证明一个组合恒等式。

值得强调的是，算法一**根本不需要 I_i 之间独立**。这里 $I_1, \ldots, I_n$ 确实独立（因为硬币抛掷独立），但即使不独立（比如从有限总体里不放回抽样，对应超几何分布），$\mathbb{E}[X] = np$ 这部分推导仍然成立——当然那时 X 不再是二项分布。这正是线性性的"免费午餐"性质的又一次体现。

定理 20.6（LOTUS，无意识统计学家定律）：设 X 是取值集合为 $\mathcal{X}$ 的离散随机变量，$g : \mathcal{X} \to \mathbb{R}$ 为任意函数。则

$$\mathbb{E}[g(X)] = \sum_{x \in \mathcal{X}} g(x) \Pr[X = x].$$

证明策略：**按 g 的取值分组求和**（本质上是一次"划分式"双计数）。选这个策略是因为 g 未必是单射，多个 x 可能映到同一个 y，所以必须先按 y 把 x 归类。

逐步推导：

- 第一步：令 $Y = g(X)$。由随机变量的复合定义，Y 是同一概率空间上的随机变量，$Y(\omega) = g(X(\omega))$。
- 第二步：求 Y 的分布。事件 $\{Y = y\}$ 等价于 $\{X \in g^{-1}(y)\}$，其中 $g^{-1}(y) = \{x : g(x) = y\}$。故

$$\Pr[Y = y] = \sum_{x:\, g(x) = y} \Pr[X = x].$$

注意：当 $g^{-1}(y)=\varnothing$ 时该和为 0，无碍。 – 第三步：代入期望定义式：

$$\mathbb{E}[Y]=\sum_{y} y\,\Pr[Y=y]=\sum_{y} y\sum_{x:\,g(x)=y}\Pr[X=x].$$

- 第四步：把 y 移入内层，并在内层把 y 换成 $g(x)$（因为内层所有 x 都满足 $g(x)=y$）：

$$=\sum_{y}\sum_{x:\,g(x)=y} g(x)\Pr[X=x].$$

- 第五步：每个 $x\in\mathcal{X}$ 落在**恰好一个**集合 $g^{-1}(y)$ 中，所以即"遍历所有 y 与其原像"等价于"直接遍历所有 x"，每项不重不漏：

$$=\sum_{x\in\mathcal{X}} g(x)\Pr[X=x]. \qquad \blacksquare$$

【证明机制解说】：这个证明与定理 20.1 的第五步是**同一个招式**：用集合族的"划分"性质把双重求和压成单重求和。区别只在于，定理 20.1 划分的是样本空间 Ω（按 X 的取值），这里划分的是 X 的取值集合 $\mathcal{X}$（按 g 的取值）。**"找一个划分"是概率论求和化简的通用套路**，后面证明卷积公式时还会见到第三次。

LOTUS 的实际价值：它把 $\mathbb{E}[X^2]$、$\mathbb{E}[X(X-1)]$、$\mathbb{E}[e^{tX}]$ 这类量变成"直接在 X 的分布上求和"，完全绕开求 $g(X)$ 的分布。Lecture 21–22 计算方差时会反复使用 $\mathbb{E}[X^2]=\sum_x x^2\Pr[X=x]$。

定理 20.7（独立的随机变量，乘积期望可乘）：若 $X\perp Y$（独立），则 $\mathbb{E}[XY]=\mathbb{E}[X]\,\mathbb{E}[Y]$。**反之不成立。**

证明策略：**直接证明 + 分离双重求和**。核心是使用**联合分布 (joint distribution)** 与独立性的定义 $\Pr[X=a,Y=b]=\Pr[X=a]\Pr[Y=b]$，把二重和拆成两个一重和的乘积。

逐步推导：

- 第一步：对函数 $g(a,b)=ab$ 使用 LOTUS 的二维版本（或直接用 $\mathbb{E}[XY]=\sum_{a,b} ab\Pr[X=a,Y=b]$，这本身可由定理 20.1 的样本点形式逐点推出）：

$$\mathbb{E}[XY]=\sum_{a}\sum_{b} ab\,\Pr[X=a,Y=b].$$

- 第二步：**关键一步**——用独立性把联合概率分解：

$$=\sum_{a}\sum_{b} ab\,\Pr[X=a]\Pr[Y=b].$$

- 第三步：把 $a\Pr[X=a]$ 与 $b\Pr[Y=b]$ 分离。注意 $\Pr[X=a]$ 与内层指标 b 无关，可提出内层：

$$=\sum_{a} a\Pr[X=a]\cdot\Big(\sum_{b} b\Pr[Y=b]\Big).$$

- 第四步：内层就是 $\mathbb{E}[Y]$（与 a 无关的常数），提出外层：

$$=\Big(\sum_{a} a\Pr[X=a]\Big)\cdot\mathbb{E}[Y]=\mathbb{E}[X]\,\mathbb{E}[Y]. \qquad \blacksquare$$

【证明机制解说】：第三步的分离之所以能成功，全靠第二步的分解把 $\Pr[X=a,Y=b]$ 变成了"只含 a 的因子 × 只含 b 的因子"。这是**可分离性 (separability)** 的标准用法：二重和若能写成 $u_a v_b$ 的形式，就能拆成两个一重和的乘积。请把这条与定理 20.3 的证明对照——那里我们**没有**做任何分解，而是**逐点相加**。两个证明的形状完全不同，因为它们处理的运算不同（加法 vs 乘法）。

反例（反之不成立）：存在 X,Y 不独立但 $\mathbb{E}[XY]=\mathbb{E}[X]\mathbb{E}[Y]$。取 X 在 $\{-1,0,1\}$ 上均匀分布，令 $Y=|X|$。

- Y 完全由 X 决定（$X=1\Rightarrow Y=1$），显然**不独立**。
- $\mathbb{E}[X]=\frac{1}{3}(-1)+\frac{1}{3}(0)+\frac{1}{3}(1)=0$。
- $\mathbb{E}[Y]=\frac{1}{3}(1)+\frac{1}{3}(0)+\frac{1}{3}(1)=\frac{2}{3}$。
- $\mathbb{E}[XY]=\mathbb{E}[X\cdot|X|]=\frac{1}{3}(-1)+\frac{1}{3}(0)+\frac{1}{3}(1)=0$。

于是 $\mathbb{E}[XY]=0=0\cdot\frac{2}{3}=\mathbb{E}[X]\mathbb{E}[Y]$ 成立，但 X 与 Y 不独立（脚本验算 ✔）。逐格检查也能看出：$\Pr[X=0,Y=0]=\frac{1}{3}$，而 $\Pr[X=0]\Pr[Y=0]=\frac{1}{3}\cdot\frac{1}{3}=\frac{1}{9}\neq\frac{1}{3}$。

结论：$\mathbb{E}[XY]=\mathbb{E}[X]\mathbb{E}[Y]$ 是独立的**必要不充分**条件的"影子"——它是独立性的一个**推论**，不是等价刻画（等价刻画要靠 Lecture 22 的协方差/相关性，且即便 $\mathrm{Cov}=0$ 也仍不等价于独立）。

定理 20.8（收集者问题，Coupon Collector）：设有 n 种优惠券，每买一盒谷物随机得到其中一种（均匀、独立）。设 T 为集齐全部 n 种所需盒数。则

$$\mathbb{E}[T]=nH_n=n\Big(1+\frac{1}{2}+\cdots+\frac{1}{n}\Big)\approx n\ln n.$$

证明策略：**指示变量分解的升级版——按"阶段"分解 (staged decomposition)**。T 不能直接写成 n 个指示变量之和（它是"次数"而非"计数"），但可以写成 n 个**几何随机变量**之和，每个阶段是一个独立的"等第一次成功"过程。然后对各阶段用几何分布的期望 $1/p$，最后用线性性相加。

逐步推导：

- **第一步：划分阶段。** 定义"第 i 阶段"为：已经集齐了 $i-1$ 种不同的券之后，从那一刻起，直到第一次买到**第 i 种新券**为止所购买的盒数。令 X_i 为该阶段消耗的盒数。因为一条完整的购买记录被这些阶段首尾相接地切成 n 段，故

$$T = X_1 + X_2 + \cdots + X_n.$$

（$i=1$ 时"已有 0 种"，第一盒必然是新的，故 $X_1 = 1$ 必然发生。）

- **第二步：确定各阶段的成功概率。** 进入第 i 阶段时已有 $i-1$ 种不同的券，此时还有 $n-(i-1) = n-i+1$ 种是"新的"。每次买盒独立均匀，所以买到新券的概率为

$$p_i = \frac{n-i+1}{n}.$$

具体列出 $n=10$ 时的 p_i：$p_1 = 1,\ p_2 = 0.9,\ p_3 = 0.8,\ p_4 = 0.7,\ p_5 = 0.6,\ p_6 = 0.5,\ p_7 = 0.4,\ p_8 = 0.3,\ p_9 = 0.2,\ p_{10} = 0.1$。

- **第三步：识别几何分布。** 在阶段 i 内的每一次购买，都可看作一次"成功概率 p_i"的伯努利试验，且各次独立。X_i 就是"直到首次成功所需的试验次数"，故

$$X_i \sim \text{Geometric}(p_i), \qquad \mathbb{E}[X_i] = \frac{1}{p_i} = \frac{n}{n-i+1}.$$

（依据：Lecture 19 关于几何分布的结论 $\mathbb{E}[X] = 1/p$，可由尾和公式 $\mathbb{E}[X] = \sum_{i\ge 1} \Pr[X \ge i] = \sum_{i\ge 1}(1-p)^{i-1} = 1/p$ 得出。）

- **第四步：用线性性相加。** 注意各 X_i **之间并不独立**吗？其实各阶段面对的是同一批券的状态，但因为每个阶段的成功概率只取决于"已集齐的种类数"（这是确定性的 $i-1$，不随机），阶段的划分是**确定性的**，所以每个 X_i 的分布确实就是 $\text{Geometric}(p_i)$，而且**线性性连独立性都不需要**，可以直接相加：

$$\mathbb{E}[T] = \sum_{i=1}^{n} \mathbb{E}[X_i] = \sum_{i=1}^{n} \frac{n}{n-i+1} = n \sum_{j=1}^{n} \frac{1}{j} = nH_n,$$

最后一步做了换元 $j = n-i+1$（当 i 从 1 走到 n，j 从 n 走到 1，恰好遍历 $1,\dots,n$）。

- **第五步：估计调和数。** 用积分比较（见下）得 $\ln n < H_n < \ln n + 1$，故

$$n\ln n \;<\; \mathbb{E}[T] \;<\; n(\ln n + 1).$$

更精细的近似是 $H_n \approx \ln n + \gamma$（$\gamma \approx 0.5772$），给出 $\mathbb{E}[T] \approx n(\ln n + \gamma)$。■

调和数夹逼的推导：对 $x \in [k, k+1]$ 有 $\frac{1}{k+1} \le \frac{1}{x} \le \frac{1}{k}$。在 $[k,k+1]$ 上积分得 $\frac{1}{k+1} \le \int_k^{k+1} \frac{dx}{x} \le \frac{1}{k}$。对 $k = 1,\dots,n-1$ 求和：

$$\sum_{k=1}^{n-1} \frac{1}{k+1} \;\le\; \int_1^n \frac{dx}{x} \;\le\; \sum_{k=1}^{n-1} \frac{1}{k} \quad\Longrightarrow\quad H_n - 1 \le \ln n \le H_{n-1} < H_n.$$

即 $\ln n < H_n$；另一侧用 $\int_1^{n+1} \frac{dx}{x} = \ln(n+1)$ 与右不等式得 $H_n \le 1 + \ln n$。合起来即 $\ln n < H_n < \ln n + 1$ ✔（数值校验：$n=1000$ 时 $6.9078 < 7.4855 < 7.9078$ ✔）。

脚本验算（必做）：理论值 $\mathbb{E}[T] = nH_n$ 与 Monte Carlo 模拟（每种 n 跑 2×10^5 次实验）：

n	理论 nH_n	模拟均值	相对误差
5	11.4167	11.407	0.08%
10	29.2897	29.284	0.02%
20	71.9548	71.964	0.01%
50	224.9603	225.095	0.06%

另有 $n=100$ 时 $nH_{100} = 518.7378$，而 $n(\ln n + \gamma) = 518.24$，近似极好（官方 Note 也给出"约 518 盒"）✔。

$n=10$ 的**逐阶段累积期望表**（脚本精确计算）：

阶段 i	已有券数	$p_i = (n-i+1)/n$	$\mathbb{E}[X_i] = 1/p_i$	累积 $\sum_{j\le i}\mathbb{E}[X_j]$
1	0	1.000	1.0000	1.0000
2	1	0.900	1.1111	2.1111
3	2	0.800	1.2500	3.3611
4	3	0.700	1.4286	4.7897
5	4	0.600	1.6667	6.4563
6	5	0.500	2.0000	8.4563
7	6	0.400	2.5000	10.9563
8	7	0.300	3.3333	14.2897
9	8	0.200	5.0000	19.2897
10	9	0.100	10.0000	29.2897

注意这个表的"形状"：**期望消耗几乎全部集中在最后几个阶段**——集齐 9 种只花了约 19.29 盒，而最后一种还要再等 10 盒。这种"末尾长尾"是所有收集类任务的通用规律。

【证明机制解说】：收集者问题的分解与二项分布的分解**形状相同、通道不同**：二项分布是"n 个指示变量**计数**相加"，收集者是"n 个几何变量**时长**相加"。共同点是——都在找"把总时间/总量切成确定性小片"的划分方式。这里的关键洞察是：**虽然券的种类是随机的，但"已集齐 $i-1$ 种"这个阶段标签是确定性的**，因此每段的成功概率固定为 p_i，几何分布的结论可以原样套用。如果阶段划分本身依赖随机结果（比如"直到某张特定券出现为止"），这个分解就会失效。

定理 20.9（空箱数目的期望）：把 m 个球独立均匀地投入 n 个箱。设 Y 为空箱个数，则

$$\mathbb{E}[Y] = n\Big(1-\frac{1}{n}\Big)^m.$$

特别地，当 $m=n$ 时 $\mathbb{E}[Y] = n(1-1/n)^n \approx n/e \approx 0.368n$。

证明策略：**指示变量分解 + 线性性**——这是"把全局复杂量拆成局部简单量之和"的教科书示范。直接求 Y 的分布是灾难性的（官方 Note 说"这个分布可怕到难以想象"），但期望可以一行搞定。

逐步推导：

- 第一步：为每个箱子配一个指示变量：

$$Y = I_1 + I_2 + \cdots + I_n, \qquad I_j = \begin{cases} 1, & \text{第 } j \text{ 个箱子为空,} \\ 0, & \text{否则.} \end{cases}$$

为什么这个等式恒成立？对任何样本点 ω，"空箱个数"就是"在 n 个箱子里逐一检查、是空箱就记 1 的分值之和"。这与定理 20.1 第五步的"函数性"论证同构。 – 第二步：求单个期望。第 j 箱为空 $\iff$ **所有** m 个球都躲开了它。每个球躲开第 j 箱的概率是 $1-1/n$，且各球独立，故

$$\mathbb{E}[I_j] = \Pr[I_j = 1] = \Big(1-\frac{1}{n}\Big)^m.$$

（依据：定理 20.2 + 独立事件乘积法则。这里**确实**用到了球的独立性——因为要算的是一个交事件的概率——这与前面"线性性不需要独立"并不矛盾：独立性的需求出现在"算单个指示变量的期望"这一步，而不是"把期望加起来"那一步。） – 第三步：线性性求和：

$$\mathbb{E}[Y] = \sum_{j=1}^{n} \mathbb{E}[I_j] = n\Big(1-\frac{1}{n}\Big)^m. \qquad \blacksquare$$

- 第四步（$m=n$ 时的渐近）：由标准极限 $(1+c/n)^n \to e^c$（取 $c=-1$）得 $(1-1/n)^n \to 1/e$，故 $\mathbb{E}[Y] \approx n/e \approx 0.368n$。官方 Note 提醒这个近似对小 n 也很好用：$n=20$ 时 $(1-1/20)^{20} \approx 0.3585$，已经离 $1/e \approx 0.3679$ 不远。

数值验算：

$n=m$	$n(1-1/n)^n$	n/e	模拟均值
10	3.4868	3.679	3.484
100	36.603	36.788	36.615
1000	367.695	367.879	367.574

（模拟 2×10^4 次，脚本验证 ✔。"投 1000 个球进 1000 个箱，期望约 368 个空箱"与官方 Note 完全一致。）

推论：非空箱数的期望为 $n - \mathbb{E}[Y] = n\big[1-(1-1/n)^n\big]$。$n=m=10$ 时是 $10-3.4868 = 6.5132$ 个非空箱——也就是说，投 10 个球进 10 个箱，平均有 3.5 个箱子白白空着。

定理 20.10（哈希碰撞数的期望）：设 m 个键独立均匀地哈希到 n 个槽位。设 C 为**发生碰撞的无序键对**数目（即落在同一槽位的键对）。则

$$\mathbb{E}[C] = \binom{m}{2}\cdot\frac{1}{n} = \frac{m(m-1)}{2n}.$$

特别地，当 $m=n$ 时 $\mathbb{E}[C] = \frac{n(n-1)}{2n} = \frac{n-1}{2}$。

证明策略：**按"对"（pair）做指示变量**。C 是"键对"的函数而非"键"的函数，所以指示变量要下在**对**上。这体现了指示变量技巧的灵活性：你可以自由选择"用什么单位来分解"。

逐步推导：

- 第一步：把 $\binom{m}{2}$ 个键对任意编号为 $1,2,\ldots,\binom{m}{2}$。令 C_i 表示"第 i 个键对的两个键落在同一槽位"这一事件，取

$$C = \sum_{i=1}^{\binom{m}{2}} I_{C_i}.$$

- 第二步：对任意一个固定键对（比如键 u 与键 v），求 $\Pr[C_i]$。先看键 u 落在哪一槽（任意，无约束），再看键 v：v 独立均匀地落在 n 个槽中，恰有一个槽与 u 相同，故

$$\mathbb{E}[I_{C_i}] = \Pr[C_i] = \frac{1}{n}.$$

- 第三步：线性性求和：

$$\mathbb{E}[C] = \sum_{i=1}^{\binom{m}{2}} \frac{1}{n} = \binom{m}{2} \cdot \frac{1}{n} = \frac{m(m-1)}{2n}. \qquad \blacksquare$$

数值验算：$m = n = 10$ 时 $\mathbb{E}[C] = \frac{10 \cdot 9}{2 \cdot 10} = 4.5$；$m = n = 100$ 时 49.5；$m = n = 1000$ 时 499.5（脚本 ✔）。一般地 $\mathbb{E}[C] = \frac{n-1}{2} \approx n/2$：**哪怕把 n 个键塞进 n 个槽，平均也只有约 $n/2$ 对碰撞**——碰撞的数量与"表的规模"同阶，而不是与"可能的对数 $\binom{n}{2}$"同阶。这是后面负载均衡分析能有好结果的根本原因。

【证明机制解说】：这里有一个非常值得警惕的细节——**各个 I_{C_i} 绝不独立**。若键对 (u,v) 碰撞且 (v,w) 碰撞，则 (u,w) 必然碰撞（三个键同槽），这是一条强相关的推理链。**但我们完全不需要它们独立**，因为线性性无条件成立。这就是"免费午餐"在本讲中最闪耀的一次应用：相关性强到极致，期望照样可以直接相加。如果这里错以为"需要独立"，整条路就走不通了。

哈希的容量问题（哈希表能存多少键）：设碰撞概率容忍度为 $\varepsilon \in (0,1)$，问最多能存多少键使"无碰撞"概率 $\geq 1-\varepsilon$？

- **思路一：联合界 (union bound)。** 令 A 为"至少存在一对碰撞"，则 $A = \bigcup_{i=1}^{\binom{m}{2}} C_i$。由 Lecture 18 的联合界 $\Pr[\bigcup_i C_i] \leq \sum_i \Pr[C_i]$，

$$\Pr[A] \leq \binom{m}{2} \frac{1}{n} \leq \frac{m^2}{2n}.$$

要 $\Pr[A] \leq \varepsilon$，只需 $\frac{m^2}{2n} \leq \varepsilon$，即 $m \leq \sqrt{2\varepsilon n}$。取 $\varepsilon = 1/2$ 得 $m \leq \sqrt{n}$。**结论：要让"无碰撞"以高概率成立，哈希表大小需约为待存集合大小的平方。**

- **思路二：精确计算 + 对数近似。** 无碰撞 $\iff$ m 个球落入 m 个**不同**的箱。计数有利样本点：第 1 个球有 n 种选择，第 2 个球有 $n-1$ 种（不能与第 1 个同箱），……，第 m 个球有 $n-m+1$ 种。故

$$\Pr[\text{无碰撞}] = \frac{n(n-1)\cdots(n-m+1)}{n^m} = \prod_{i=1}^{m-1}\left(1 - \frac{i}{n}\right).$$

取对数（合法：$\ln$ 可逆且单调）：

$$\ln \Pr[\text{无碰撞}] = \sum_{i=1}^{m-1} \ln\left(1 - \frac{i}{n}\right) \approx -\sum_{i=1}^{m-1} \frac{i}{n} = -\frac{m(m-1)}{2n} \approx -\frac{m^2}{2n},$$

其中用了泰勒展开 $\ln(1-x) = -x - \frac{x^2}{2} - \frac{x^3}{3} - \cdots \approx -x$（对小的 x）。于是

$$\Pr[\text{无碰撞}] \approx e^{-m^2/(2n)}.$$

要 $e^{-m^2/(2n)} \geq 1-\varepsilon$，即 $\frac{m^2}{2n} \leq \ln\frac{1}{1-\varepsilon}$，故

$$m \leq \sqrt{2\ln\tfrac{1}{1-\varepsilon}} \cdot \sqrt{n}.$$

$\varepsilon = 1/2$ 时系数为 $\sqrt{2\ln 2} = \sqrt{1.38629} = 1.1774$，即 $m \approx 1.177\sqrt{n}$。$\varepsilon = 1/20$ 时系数 $\sqrt{2\ln(20/19)} = \sqrt{0.10259} = 0.3203$，即 $m \approx 0.32\sqrt{n}$。

数值验算（脚本精确枚举）：

n	$1.177\sqrt{n}$	精确临界 m_0（使 $\Pr[\text{无碰撞}] \geq 1/2$ 的最大 m）
365	22.49	22
1000	37.22	37
10^6	1177.00	1177

与官方 Note 的表完全吻合。另：生日悖论对应的正是 $n = 365$ 的情形——精确算得 $\Pr[\text{至少一对同生日}]$ 在 $m = 23$ 时为 $0.5073 > 1/2$，$m = 60$ 时为 $0.9941 > 0.99$ ✔。直觉上"$23/365 \approx 6\%$"完全错，因为**碰撞是成对事件，对数是 $\binom{m}{2} \sim m^2/2$，随 m 平方增长**。

临界值 $m_0 = O(\sqrt{n})$ 不可改进：既然精确式也给出 $m \approx 1.177\sqrt{n}$，联合界给出的 $O(\sqrt{n})$ 阶就是**最优阶**——存在碰撞的概率本质上是 $\Theta(m^2/n)$，这是"$\binom{m}{2}$ 个对数 × 每对 $1/n$"结构的必然结果。这也再次印证 $\mathbb{E}[C] = \binom{m}{2}/n$ 这条期望公式的深刻：**碰撞数量的期望就是那个"本质上决定一切"的量。**

负载均衡（Load Balancing）：$m = n$ 个作业随机指派到 n 个处理器，求最小 k 使 $\Pr[\text{最大负载} \geq k] \leq 1/2$。

证明策略："**不问难题，先问简单题**"——不直接分析"最大负载"这个依赖全部 n 个箱子的复杂事件 A_k，而是先分析**单个箱子**的负载事件 $A_k(j) = \{\text{第 } j \text{ 箱负载} \geq k\}$，再用**联合界**把单个箱子的结论搬回全局。这个"换问题"的思路是工程概率论的核心美学。

逐步推导（粗界）：

- 第一步：把目标拆解。注意 $A_k = \bigcup_{j=1}^{n} A_k(j)$（只要存在某个箱子负载 $\geq k$，最大负载就 $\geq k$）。由联合界，

$$\Pr[A_k] \leq \sum_{j=1}^{n} \Pr[A_k(j)] = n \cdot \Pr[A_k(1)].$$

最后一步用了**对称性**：n 个箱子完全同构。 – 第二步：**归约到"只需单箱概率小到 $1/(2n)$"**。若能让 $\Pr[A_k(1)] \leq \frac{1}{2n}$，则 $\Pr[A_k] \leq n \cdot \frac{1}{2n} = \frac{1}{2}$ ✔。 – 第三步：**再次使用联合界**，这次用在"哪些球在箱 1 里"。若箱 1 有 $\geq k$ 个球，则**存在**某个含 k 个球的集合 S 使 S 中所有球都落在箱 1。故 $\{A_k(1)\} \subseteq \bigcup_{|S|=k} B_S$，其中 $B_S = \{\text{所有 } S \text{ 中球都落进箱 1}\}$。于是

$$\Pr[A_k(1)] \le \Pr\Big[\bigcup_{|S|=k} B_S\Big] \le \sum_{|S|=k} \Pr[B_S] = \binom{n}{k}\cdot\frac{1}{n^k}.$$

（最后一个等式：每个 B_S 是 k 个确定球同落箱 1，概率为 $(1/n)^k$；共有 $\binom{n}{k}$ 个 S。） – 第四步：化简并用 Stirling 估计。注意

$$\binom{n}{k}\frac{1}{n^k} = \frac{n(n-1)\cdots(n-k+1)}{k!}\cdot\frac{1}{n^k} \le \frac{1}{k!}.$$

要 $\Pr[A_k(1)] \le \frac{1}{2n}$，只需 $\frac{1}{k!} \le \frac{1}{2n}$，即 $k! \ge 2n$。用 Stirling 近似 $\ln k! \approx k\ln k - k$（更精确的写法是 $\ln k! \ge k\ln k - k$），令其 $\approx \ln(2n)$，解得

$$k \approx \frac{\ln n}{\ln\ln n}.$$

- **第五步（更紧的界）。** 用二项分布的精确表达：

$$\Pr[A_k(1)] = \sum_{j=k}^{n}\binom{n}{j}\Big(\frac{1}{n}\Big)^j\Big(1-\frac{1}{n}\Big)^{n-j} \le \sum_{j=k}^{n}\binom{n}{j}\frac{1}{n^j} \le \sum_{j=k}^{n}\Big(\frac{e}{j}\Big)^j \le 2\Big(\frac{e}{k}\Big)^k,$$

其中第三步用了标准估计 $\binom{n}{j} \le (ne/j)^j$，并把 $(1-1/n)^{n-j} \le 1$ 丢掉（丢掉只会放大上界，是合法的"松绑"）；第四步把所有项按几何级数（公比 $\le e/k$，要求 $k \ge 2e$）放大。于是要 $\Pr[A_k(1)] \le \frac{1}{2n}$，只需

$$\Big(\frac{e}{k}\Big)^k \le \frac{1}{4n}.$$

两边取对数：$k(\ln k - 1) \ge \ln(4n)$。数表验算：

n	10	20	50	100	500	1000	10^4	10^5	10^6
满足 $(e/k)^k \le \frac{1}{4n}$ 的最小 k	6	6	7	7	8	8	9	10	11
$\ln(4n)$	3.69	4.38	5.30	5.99	7.60	8.29	10.60	12.90	15.20
$\frac{2\ln n}{\ln\ln n}$	5.52	5.46	5.74	6.03	6.80	7.15	8.30	9.42	10.52

更简单的可读估计是 $k \approx \ln(4n)$（对 $n \ge 405$ 就够用）；n 极大时用 $k \approx \frac{2\ln n}{\ln\ln n}$ 更贴切。■

数值验算与界有多松：对 $n = 1000$，界给出 $k \le 8$；Monte Carlo 模拟（2×10^4 次）显示 $\Pr[\text{最大负载} \ge k]$ 为

k	6	7	8	9
模拟 $\Pr[\max \ge k]$	0.4435	0.0760	0.0098	0.0011

即真实临界值约为 $k = 6$（$\Pr[\max \ge 6] = 0.4435 \le 1/2$，故 $\Pr[\max \le 5] = 0.5565 \ge 1/2$），而我们的上界给出的是 $k \le 8$。**界是保守的（诚实但偏松）**，因为推导中用了两次联合界 + 一次 Stirling + 一次几何级数放大，每步都往"更安全"的方向走。模拟的均值也是佐证：$n = 1000$ 时最大负载均值 5.515，中位数 5，95 分位 7——**所有值都远小于 $\ln n \approx 6.9$ 的粗估量级，更远小于 n。**

工程结论（官方 Note 的"卖点"）：美国人口约 3.5 亿。寄出 3.5 亿封地址完全随机的广告邮件，则**以至少 $1/2$ 的概率，全国没有任何一个人收到超过约十来封。**这就是"随机化 + 事后容忍波动"相对于"中心化精确调度"的威力：**零通信开销，最坏负载只是 $\Theta(\ln n/\ln\ln n)$。**

与经典问题的联系

1. 哈希表（Hash Table）的容量设计

- **实际背景**：哈希表把键从大宇宙 U（比如全美 2.5 亿人名）映射到小表 T（n 个槽），冲突的键挂在同一槽的链表里。$\textsc{Delete}$ 与 $\textsc{Member}$ 的耗时正比于链表长度，所以链长（= 负载）是性能命脉。
- **数学建模**：把"哈希函数打乱输入"建模为**随机函数**——每个键独立均匀地落到某个槽。这就是球的投箱模型。
- **方案设计与正确性**：若要求"无冲突"以概率 $\ge 1-\varepsilon$ 成立，则 $m \le \sqrt{2\ln\frac{1}{1-\varepsilon}}\sqrt{n} = O(\sqrt{n})$（定理 20.10 之后的分析），且这个 $O(\sqrt{n})$ 阶是**紧的**（生日悖论现象）。实践中不这么用——因为负载均衡分析告诉我们，**即使 $m = n$，最大链长也只有 $\Theta(\ln n/\ln\ln n)$**，于是"允许冲突 + 链表/开放寻址"的方案远比"把表放大到 n^2"经济。
- **期望的用处**：定理 20.10 直接给出 $\mathbb{E}[\text{碰撞对数}] = \binom{m}{2}/n$，用一个**两行的计算**替代了原本需要对所有 n^m 种落点计数的工作。

2. 分布式系统的负载均衡（Load Balancing）与"随机复用"

- **实际背景**：m 个作业、n 个处理器，精确均分需要中心调度器或大量通信，代价高昂。
- **数学建模**：每个作业独立均匀随机选处理器，即投箱模型。
- **方案与保证**：不通信，最大负载以至少 $1/2$ 概率不超过 k_0，其中 k_0 由 $(e/k)^k \le 1/(4n)$ 定出，对 $n = 10^6$ 只有 $k_0 = 11$，对 $n = 10^9$ 也只有十几。
- **推广视野**：CS70 官方 Note 指出这是**随机复用 (stochastic multiplexing)** 的雏形——"潜在需求总量巨大，但实际同时到达的需求是随机的"，因此可以超售资源。官方提到 EECS 122/168 与 EECS 126 会深入展开。这就是"概率让你可以不为最坏情况买单"的工程哲学。

3. 纠错码的冗余量选择（与 Lecture 19 的呼应）

- **实际背景**：把 n 个包编成 $n+k$ 个包，使收到任意 n 个即可重建原数据（Lecture 8 的纠错码）。
- **数学建模**：若每个包独立地以概率 p 丢失，则收到的包数 $X \sim \text{Bin}(n+k, 1-p)$。
- **方案设计**：成功解码概率为 $\Pr[X \ge n] = \sum_{i=n}^{n+k}\binom{n+k}{i}(1-p)^i p^{n+k-i}$。给定 n, p，选 k 使该概率 ≥ 0.99。

- **本讲的作用**：一旦用定理 20.5 知道 $\mathbb{E}[X] = (n+k)(1-p)$，就能立刻反推需要多少冗余：要让期望收到数至少 n，需 $(n+k)(1-p) \geq n$，即 $k \geq \frac{np}{1-p}$——**一步给出 k 的尺度**，剩下的精调交给 Lecture 23 的集中不等式（切尔诺夫界）来做。

4. 算法分析中的"期望时间复杂度"

- 大量随机化算法（随机快排、哈希、随机游走采样）的复杂度都是以"指示变量 + 线性性"的方式分析的：把"比较次数"拆成"每一对元素是否被比较"，把"访问次数"拆成"每个位置是否被访问"。本讲的定理 20.2 与定理 20.10 是这套方法论的模板。

与其他讲次的关联

- **承接 Lecture 14（计数）/ Lecture 15（概率公理）**：期望定义里的 $\sum_a a \Pr[X=a]$ 是"加权计数"；定理 20.8 的 $\binom{n}{k}$ 与定理 20.10 的 $\binom{m}{2}$ 直接来自 Lecture 14 的组合计数。定理 20.1 证明中"事件族 $\{X=a\}$ 构成样本空间的划分"用的正是 Lecture 15 建立的可加性公理。
- **承接 Lecture 18（独立性与事件组合）**：定理 20.9 中算 $\Pr[\text{第 } j \text{ 箱为空}] = (1-1/n)^m$ 用的是 Lecture 18 的**独立事件乘积法则**；哈希容量分析的第一步用的正是 Lecture 18 的**联合界 (union bound)** $\Pr[\bigcup A_i] \leq \sum \Pr[A_i]$。请注意区分：联合界用在这一步是"事件层面"，线性性用在期望求和是"随机变量层面"，**两条通道互不干涉**。
- **承接 Lecture 19（随机变量与离散分布）**：本讲是 Lecture 19 的直接延续——19 讲回答"X 的分布是什么"，20 讲回答"如何用一个数概括它"。定理 20.5 用的 $\mathbf{Bin}(n,p)$ 分布、定理 20.8 用的 $\mathbf{Geometric}(p)$ 期望 $1/p$（含尾和公式 $\mathbb{E}[X] = \sum_{i \geq 1} \Pr[X \geq i]$），都在 Lecture 19 与配套 Note（Note 19）中建立。
- **通向 Lecture 21（联合分布与随机变量独立性）**：定理 20.7 的证明已经**提前使用了联合分布** $\Pr[X=a, Y=b]$ 与独立性的乘法分解，Lecture 21 将把这两个概念正式体系化，并给出卷积公式处理"独立随机变量之和"的分布。
- **通向 Lecture 22（方差与协方差）**：Theorem 20.7 中那个"$\mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y]$"的量正是**协方差**；Lecture 22 会证明 $\mathbf{Var}(X+Y) = \mathbf{Var}(X) + \mathbf{Var}(Y) + 2\,\mathbf{Cov}(X,Y)$，并指出**方差相加需要独立，而期望相加不需要**——这个对比正是本讲最需要记住的分界线。
- **通向 Lecture 23（集中不等式）**：本讲反复出现"期望不等于典型值"的伏笔（骰子期望 3.5 取不到；随机游走 $\mathbb{E}[S_n] = 0$ 但粒子跑得远）。官方 Note 明确说"期望有多典型"是后续要回答的重要问题——Lecture 23 的马尔可夫界 $\Pr[X \geq a] \leq \mathbb{E}[X]/a$ 只需期望就能给出**最粗**的集中保证，切比雪夫界则需要 Lecture 22 的方差。
- **回连 Lecture 4–6（数论与密码）**：哈希函数"模 m 归约到槽位"正是 Lecture 4 的剩余类语言；"为什么模质数分布更均匀"也来自 $\mathbb{Z}_p$ 结构的整齐性。

关键要点

1. **期望 = 概率加权的平均值 = 分布的质心**。定义式 $\mathbb{E}[X] = \sum_a a \Pr[X=a]$，等价的样本点式 $\mathbb{E}[X] = \sum_\omega X(\omega)\Pr[\omega]$。**期望不必是 X 能取到的值**（骰子 3.5），也**可能不存在**（绝对收敛是前提）。
2. **指示变量定律 $\mathbb{E}[I_A] = \Pr[A]$ 是全部技巧的引擎**。凡是"数某种东西有多少个"的随机量，都先努力写成 $\sum_i I_i$ 的形式；写出来后求期望就等于把一串概率加起来。
3. **线性性无条件成立**：$\mathbb{E}[\sum_i c_i X_i] = \sum_i c_i \mathbb{E}[X_i]$，**不需要任何独立性**。这是整门课最锋利的免费午餐。相应地，**它只管加法与常数倍**：$\mathbb{E}[XY] \neq \mathbb{E}[X]\mathbb{E}[Y]$、$\mathbb{E}[1/X] \neq 1/\mathbb{E}[X]$、$\mathbb{E}[g(X)] \neq g(\mathbb{E}[X])$（凸性不等式是另一回事）。
4. **$\mathbb{E}[XY] = \mathbb{E}[X]\mathbb{E}[Y]$ 需要独立，且反向不成立**。反过来，$\mathbf{Cov}(X,Y) = 0$ 也不能推出独立（Lecture 22）。
5. **三大应用的具体公式必须能默写**：
6. 二项分布 $\mathbb{E}[\mathbf{Bin}(n,p)] = np$（指示变量 3 行 vs 定义式代数一套）；
7. 收集者问题 $\mathbb{E}[T] = nH_n \approx n\ln n$（按阶段分解成 n 个几何变量）；
8. 投箱模型 $\mathbb{E}[\text{空箱}] = n(1-1/n)^m \approx ne^{-m/n}$，$\mathbb{E}[\text{碰撞对}] = \binom{m}{2}/n$，哈希容量 $m \approx 1.177\sqrt{n}$，最大负载 $\Theta(\ln n / \ln\ln n)$。
9. **黄金法则："全局难算 ⇒ 拆成局部之和（指示变量），再逐项求期望"**。拆分的单位（球、箱、键对、阶段）可以自由选择，选得好就两行解决，选不好就寸步难行。

常见误区与注意事项

1. **以为线性性需要独立性。** 这是最高频、最致命的误解。$\mathbb{E}[X+Y] = \mathbb{E}[X] + \mathbb{E}[Y]$ 对**任意** X, Y 成立，包括 $Y = X$、包括强相关的变量。把"线性性"和"乘法法则"分清楚：**加法通道免费，乘法通道收费（要用独立来付费）**。
2. **把线性性滥用到了乘积上。** 看到 $\mathbb{E}[(X_1 + \cdots + X_n)^2]$ 就写成 $(\mathbb{E}[X_1] + \cdots + \mathbb{E}[X_n])^2$ —— 错。展开平方后交叉项 $\mathbb{E}[X_i X_j]$ 需要 Lecture 22 的工具（独立时才 $= \mathbb{E}[X_i]\mathbb{E}[X_j]$）。
3. **期望当作"必然值"。** 骰子的期望是 3.5，但它一次都取不到；美国人均收入是中位数收入的两倍，但"平均人"不存在。**期望是长期平均/质心，不是典型值。** 判"某个取值会不会出现"必须看分布（支撑集），不能看期望。
4. **忘记期望可能发散。** 在写 $\mathbb{E}[X] = \sum_a a \Pr[X=a]$ 并做代数变形前，先确认绝对收敛。反例见"注意二"中的 X 以 2^{-k} 取 2^k。
5. **以为 $\mathbb{E}[g(X)] = g(\mathbb{E}[X])$。** 即"期望可以穿过函数"。这只有在 g 是**仿射函数**（$g(x) = ax + b$）时才成立——这恰恰就是线性性的内容。对 $g(x) = x^2$、$g(x) = 1/x$、$g(x) = e^x$ 一律不成立。取 X 均匀在 $\{1,2\}$：$\mathbb{E}[X^2] = 2.5$，$(\mathbb{E}[X])^2 = 2.25$。
6. **在求"指示变量的期望"时误以为也要用到变量独立性。** 恰恰相反：算 $\mathbb{E}[I_j] = 1 - \Pr[\text{所有球躲开第 } j \text{ 箱}]$ 时用的是**球**之间的独立性（交事件概率分解），以及联合界那样的"和事件"上界。把"哪一步需要独立"与"哪一步不需要"对齐，是本章最需要练的手感。
7. **调和数的量级记错。** H_n 是 $\Theta(\ln n)$，不是 $\Theta(\log_2 n)$（差一个常数因子 $\ln 2$），更不是 $\Theta(n)$。收集者问题的期望是 $n\ln n$ 而不是 n^2 或 $n\log_2 n$。**这个 $\ln$ vs $\log_2$ 的差别在 CS 语境里经常被忽略**，但代进公式会差 $\ln 2 \approx 0.693$ 倍。
8. **把最大化/最小化与期望交换。** $\mathbb{E}[\max_j L_j] \geq \max_j \mathbb{E}[L_j]$ 一般**严格大于**（$n = 1000$ 时单箱期望是 1，但最大负载期望约 5.5）。**"平均的最大" ≠ "最大的平均"**，分析最大负载时必须走联合界那条路。

思考题（带答案）

Q1.（计算题） 把 10 个球独立均匀地投入 10 个箱。求：(a) 空箱数的期望；(b) 非空箱数的期望；(c) 发生碰撞的**无序球对**数目的期望；(d) 第 1 个箱恰好有 3 个球的概率；(e) 第 1 个箱与第 2 个箱都为空箱的概率。

> **答案**
>
> **(a)** 由定理 20.9，$n = m = 10$：
>
> $$\mathbb{E}[Y] = 10\left(1 - \frac{1}{10}\right)^{10} = 10 \times 0.9^{10} = 10 \times 0.3486784401 = 3.486784401.$$
>
> 脚本复核：$10 \cdot 0.9^{10} = 3.486784401$ ✔。
>
> **(b)** $\mathbb{E}[\text{非空}] = n - \mathbb{E}[Y] = 10 - 3.486784401 = 6.513215599$。脚本 ✔。
>
> **(c)** 由定理 20.10：$\binom{10}{2} \cdot \frac{1}{10} = \frac{45}{10} = 4.5$。脚本 ✔。
>
> **(d)** "第 1 箱有 3 个球"服从 $\mathbf{Bin}(10, 0.1)$：
>
> $$\Pr = \binom{10}{3}(0.1)^3(0.9)^7 = 120 \times 0.001 \times 0.4782969 = 0.057395628.$$
>
> **(e)** 记 E_1 ="箱 1 空"、E_2 ="箱 2 空"。这两个事件**不独立**（一个球不进箱 1 会略微提高它进箱 2 的机会），但可以直接算交事件：每个球同时躲开箱 1 和箱 2 的概率是 $8/10 = 0.8$，10 个球独立，故
>
> $$\Pr[E_1 \cap E_2] = 0.8^{10} = 0.1073741824.$$
>
> 若误按独立算：$\Pr[E_1]\Pr[E_2] = 0.9^{20} = 0.1215766546$ —— **两者不等，再次说明"事件独立"不能想当然**。这里的事件层面需要交事件；而在期望层面，$\mathbb{E}[I_{E_1} + I_{E_2}] = 2 \times 0.9^{10} = 0.6973568802$ **照旧成立**，无论它俩是否独立。这就是本讲的分界线。

Q2.（概念/证明题） 判断下列命题真假，为真者给出证明，为假者给出反例：

(a) 若 X, Y 是同一概率空间上的随机变量且 $\mathbb{E}[X+Y] = \mathbb{E}[X] + \mathbb{E}[Y]$，则 $X \perp Y$。

(b) 若 $X \perp Y$，则 $\mathbb{E}[X^2Y^2] = \mathbb{E}[X^2]\mathbb{E}[Y^2]$。

(c) 若 $\mathbb{E}[XY] = \mathbb{E}[X]\mathbb{E}[Y]$，则 $X \perp Y$。

(d) 对任意随机变量 X 与任意 $n \geq 1$，$\mathbb{E}[X^n] \geq (\mathbb{E}[X])^n$ 恒成立。

> **答案**
>
> **(a) 假。** 线性性**从不**蕴含独立性。最简反例：$X = Y \sim \mathrm{Bernoulli}(1/2)$。$\mathbb{E}[X+Y] = 1$，而 $\mathbb{E}[X] + \mathbb{E}[Y] = 1/2 + 1/2 = 1$，等式成立；但 $\Pr[X=1, Y=1] = 1/2$ 而 $\Pr[X=1]\Pr[Y=1] = 1/4$，故不独立。**根源**：线性性是加法通道的恒等式，独立性是乘法通道的性质，前者不可能推出后者。
>
> **(b) 真。** 因为 $X \perp Y$ 推出 $g(X) \perp h(Y)$ 对任意函数 g, h 成立（独立性是"事件层面"的性质，取原像后仍是独立的事件对：$\{g(X) = u\} = \{X \in g^{-1}(u)\}$、$\{h(Y) = v\} = \{Y \in h^{-1}(v)\}$，它们的交概率按 X, Y 的独立性分解）。取 $g(x) = x^2$、$h(y) = y^2$，再由定理 20.7 得 $\mathbb{E}[X^2Y^2] = \mathbb{E}[X^2]\mathbb{E}[Y^2]$。
>
> **(c) 假。** 反例：X 在 $\{-1, 0, 1\}$ 上均匀，$Y = |X|$（本讲定理 20.7 后的反例）。前面已验算：$\mathbb{E}[XY] = 0 = \mathbb{E}[X]\mathbb{E}[Y]$，但 $\Pr[X=0, Y=0] = 1/3 \neq 1/9 = \Pr[X=0]\Pr[Y=0]$。**结论**：$\mathbb{E}[XY] = \mathbb{E}[X]\mathbb{E}[Y]$（"不相关"）比独立**严格弱**。
>
> **(d) 假。** 平方情形就已被推翻：X 在 $\{1, 2\}$ 上均匀，$\mathbb{E}[X^2] = 2.5$，$(\mathbb{E}[X])^2 = 1.5^2 = 2.25$，$2.5 \geq 2.25$ 恰好成立——但这只是巧合。取 X 以概率 0.99 取 0、概率 0.01 取 100：$\mathbb{E}[X] = 1$，故 $(\mathbb{E}[X])^2 = 1$；而 $\mathbb{E}[X^2] = 0.01 \times 10000 = 100 \geq 1$ 依然成立。**问题出在奇数 n 与负值**：取 X 在 $\{-1, 1\}$ 上均匀，$n = 3$：$\mathbb{E}[X^3] = \frac{1}{2}(-1) + \frac{1}{2}(1) = 0$，而 $(\mathbb{E}[X])^3 = 0$，仍相等；再取 X 以 0.1 概率取 1、0.9 概率取 0：$\mathbb{E}[X] = 0.1$，$(\mathbb{E}[X])^3 = 0.001$，$\mathbb{E}[X^3] = 0.1 \geq 0.001$ 成立。**真正的反例**取 X 在 $\{-2, 1\}$ 上均匀：$\mathbb{E}[X] = -0.5$，故 $(\mathbb{E}[X])^3 = -0.125$；而 $\mathbb{E}[X^3] = \frac{1}{2}(-8) + \frac{1}{2}(1) = -3.5$。于是 $-3.5 \not\geq -0.125$，**命题为假**。
>
> 正确的方向是**詹森不等式 (Jensen's inequality)**：当 g 为**凸函数**且 n 为偶数时（$g(x) = x^n$ 凸），$\mathbb{E}[g(X)] \geq g(\mathbb{E}[X])$ 成立；n 为奇数时 x^n 非凸，命题失效。所以 (d) 的错在于把"某类 n"当成"全部 n"。

Q3.（概念题） 在收集者问题的推导中，各 X_i 是否独立？这个问题的答案会影响 $\mathbb{E}[T] = nH_n$ 的正确性吗？请说明理由，并举一个"各阶段变量相关"的具体观察。

▸ 答案

答：各 X_i 不独立（至少不是全部独立），但这完全不影响结果。

为什么不影响：定理 20.4 已经证明 $\mathbb{E}[\sum_i X_i] = \sum_i \mathbb{E}[X_i]$ **不需要任何独立性假设**。我们唯一需要的事实是"每个 X_i 的**边缘分布**是 $\text{Geometric}(p_i)$"——因为进入第 i 阶段时已集齐的种类数 $i-1$ 是**确定的**（由阶段定义锁定），所以每次购买买到新券的概率恒为 $p_i = (n-i+1)/n$，且各次购买独立，X_i 就是"等首次成功的次数"。**边缘分布确定 + 线性性无条件**，两步就够了。

为什么它们确实相关：一个直观的观察是"阶段的长度互相约束"。例如 $n=2$ 时，$T = X_1 + X_2$，$X_1 = 1$ 必然，$X_2 \sim \text{Geometric}(1/2)$，$\mathbb{E}[T] = 1+2 = 3$。验证独立性：若 X_1, X_2 独立，则 $\Pr[X_2 = 1 \mid X_1 = 1] = \Pr[X_2 = 1] = 1/2$ 应当成立；这里恰好还是 $1/2$（因为 X_1 退化成常数，常数与任何变量独立），所以 $n=2$ 看不出问题。看 $n=3$：$X_2 \sim \text{Geom}(2/3)$、$X_3 \sim \text{Geom}(1/3)$。用**购买记录的形态**来观察相关性：如果第 2 阶段耗了很长时间（X_2 很大），说明彩票机反复吐出那 1 张旧券，那么在 X_2 结束的那个时刻，第 3 阶段面对的仍是"2 张旧券 + 1 张新券"，X_3 的**条件分布**并未改变——真正相关的地方在于**联合分布的结构**：给定 X_2 的取值会确定 X_3 阶段的**起始时刻**（时间轴上的位置），而阶段长度之间存在"读同一串随机数"的耦合（所有阶段共享同一条购买序列的不同区段，区段长度的划分依赖于前面的结果）。严格地说，$X_1, \ldots, X_n$ 的**联合分布并不等于各自几何分布的乘积**；只有**边缘分布**才是几何的。

要点：这个题目考的是"**要什么、用什么**"的分离。我们要的是**期望之和**，需要的原料仅是"**各变量的期望**"；而期望只需要各变量的**边缘分布**。独立性是"联合分布**等于**边缘分布之积"这样一个**远强得多**的要求，我们从未需要它。**这正是本讲"免费午餐"的最佳练习场**：如果考试时误以为"必须先证明独立"，这题就会卡住或算错。

Lecture 21: Joint Distributions & Independence of RVs（联合分布与随机变量独立性）

概述

到目前为止，我们每次只盯住一个随机变量。但真实问题里的随机量从来不是孤立的：抛两枚骰子时要知道"第一枚"和"两枚之和"如何联动；哈希表里要问"某一对键是否碰撞"和"另一对键是否碰撞"是否相关；随机游走要看"这一步往哪走"和"当前位置"的关系。

本讲引入**联合分布 (joint distribution)**，它是描述多个随机变量"共同行为"的**完整**信息载体；并由它引出两个关键操作：**边缘化 (marginalization)** —— 从联合分布"投影"回单个变量（信息只减不增）；以及**独立性 (independence)** —— 联合分布能否分解为边缘分布之积。本讲还专门处理**独立随机变量之和**的分布，得到**卷积 (convolution)** 公式，并证明两条漂亮的结构性结论：$\text{Bin}(n,p) + \text{Bin}(m,p) = \text{Bin}(n+m,p)$ 与 $\text{Pois}(\lambda_1) + \text{Pois}(\lambda_2) = \text{Pois}(\lambda_1+\lambda_2)$。最后以**随机游走 (random walk)** 为例，展示如何把线性性（Lecture 20）与这些新工具合起来算出 $\mathbb{E}[S_n] = 0$ 与 $\mathbb{E}[S_n^2] = n$，并预告 Lecture 22 的方差可加性。

核心概念的直观解释

联合分布（Joint Distribution）

- **定义**：设 X, Y 是同一概率空间 $(\Omega, \Pr)$ 上的两个离散随机变量，取值集合分别为 A, B。(X, Y) 的**联合分布**是

$$p_{X,Y}(a,b) = \Pr[X = a,\ Y = b], \qquad a \in A,\ b \in B.$$

它是"二维的"分布：不但告诉你 X 取各值的概率、Y 取各值的概率，还告诉你**它们如何同时取值**。X, Y 都取实数值时，$p_{X,Y}$ 可以看作一个二维数组（矩阵），行标是 a、列标是 b、格子里是 $\Pr[X=a, Y=b]$。

- **直观解释（"它是什么意思？"）**：如果单个随机变量的分布是"一张成绩单"，那联合分布就是"一张成绩单的**所有科目对照表**"。只看单科（边缘）你会以为两科互不相干，看到对照表才发现"数学好的人物理也好"。**联合分布是"完整的"，单个变量的分布是它的一个"影子"。**

另一个有用的图景：把概率想象成撒在平面上的沙子，每个点 (a,b) 上堆着质量 $\Pr[X=a, Y=b]$，总质量 1。联合分布描述的是**整片沙堆**，边缘分布只是"把沙子分别投影到 x 轴和 y 轴上"得到的两条影子。

- **具体示例（$n=4$ 次抛硬币）**：设 X 为正面数，Y 为反面数。因为 $X + Y = 4$，所以 $\Pr[X=a, Y=b] = 0$ 除非 $a+b=4$；而当 $a+b=4$ 时 $\Pr[X=a, Y=4-a] = \binom{4}{a}/16$。这就是一个"退化的"联合分布——两个变量完全不独立（Y 由 X 唯一决定），联合分布在平面上是一条斜线，不是整张网格。

边缘分布（Marginal Distribution）

- **定义**：给定 X, Y 的联合分布，X 的**边缘分布**通过对 Y 的一切取值求和得到：

$$p_X(a) = \Pr[X = a] = \sum_{b \in B} \Pr[X = a,\ Y = b].$$

同理 $p_Y(b) = \sum_{a \in A} \Pr[X = a,\ Y = b]$。

- **直观解释**："边缘"这个名词来自**表格**：把联合分布写成二维表格，把每行加起来写在表格右缘、每列加起来写在表格下缘，得到的就是边缘分布（row sums 和 column sums）。这也是"边缘"一词的字面来源——它们写在表格的**边**上。
- **具体示例**：抛两枚公平硬币，X 是第一枚的结果（$0/1$），Y 是第二枚（$0/1$）。联合表格每格都是 $1/4$。行和：$1/4 + 1/4 = 1/2$；列和同理也是 $1/2$。边缘分布是 $\Pr[X=0] = \Pr[X=1] = 1/2$。
- **关键警告：边缘分布不能还原联合分布。** 这是本讲最需要记住的一条——**边缘化是"投影"，投影会丢信息，而且丢的信息无法找回**。同一个边缘分布可以对应**很多**不同的联合分布（下文有完整反例）。在"沙堆"图景里：两个不同形状的沙堆可以有完全相同的两条影子。因此，"我分别知道了 X 和 Y 的分布"与"我知道了 (X,Y) 的分布"是**天壤之别**的两件事。

独立性（Independence of Random Variables）

- **定义**：同一概率空间上的随机变量 X, Y 称为**独立 (independent)**，如果对**所有** $a \in A,\ b \in B$，

$$\Pr[X = a,\, Y = b] = \Pr[X = a] \cdot \Pr[Y = b].$$

记作 $X \perp Y$。等价说法：**事件 $X = a$ 与事件 $Y = b$ 对一切 a, b 都独立**（这正是 Lecture 18 的"事件独立性"逐对地施加到所有"水平截口"上）。

- **直观解释（"它是什么意思？"）**：独立意味着"**知道一个变量的值，不会改变对另一个变量的信念**"。用条件概率写就是：对所有使 $\Pr[Y = b] > 0$ 的 b，$\Pr[X = a \mid Y = b] = \Pr[X = a]$。在"沙堆"图景里，独立意味着整片沙堆的形状是**两个一维剖面的张量积**——从任何角度看都是同一套轮廓。
- **表格判据（考试最常用）**：把联合分布写成表格，算出行和（边缘 p_X）与列和（边缘 p_Y）。**独立性成立 $\iff$ 每一个格子的值都等于"该行行和 × 该列列和"。**只要找到一个格子不满足，就不独立。**找一个格子通常就够了**——这正是"反例"的标准造法。
- **具体示例**：下面这个 2×2 表格（$p = 0.3$ 的抛硬币型）

$X \backslash Y$	0	1	行和 p_X
0	0.49	0.21	0.70
1	0.21	0.09	0.30
列和 p_Y	0.70	0.30	1.00

检查左上角：0.49 与 $0.70 \times 0.70 = 0.49$ 相等 ✔；右上角：0.21 与 $0.70 \times 0.30 = 0.21$ 相等 ✔；其余两格同理 ✔。**故独立。**

联合分布表（Joint Distribution Table）

- **定义/形式**：把 $\Pr[X = a, Y = b]$ 排成一个二维表，行的边上写行和（X 的边缘），列的边上写列和（Y 的边缘），右下角写总和 1。
- **直观解释**：这是本讲最重要的"手算工具"。判独立、算边缘、算 $\mathbb{E}[XY]$ 都在同一张表上完成，不需要任何额外记号。
- **具体示例**：见下方 ASCII 图示与定理 21.5。

相互独立（Mutual Independence）与 i.i.d.

- **定义（两个变量）**：如上。
- **定义（多个变量）**：$X_1, \ldots, X_n$ **相互独立** (mutually independent)，如果对**每个子集** $S \subseteq \{1, \ldots, n\}$ 与每个取值组合 $(a_i)_{i \in S}$，

$$\Pr\left[\bigwedge_{i \in S} X_i = a_i\right] = \prod_{i \in S} \Pr[X_i = a_i].$$

- **直观解释（"它是什么意思？"）**：**注意"两两独立"不等于"相互独立"！** 定义要求**每一个子集**都分解，而不仅仅是每一对。三变量时，"两两独立"只覆盖了 $\binom{3}{2} = 3$ 个二元子集，"相互独立"还额外要求三元子集 $\{1, 2, 3\}$ 也分解。存在三个随机变量两两独立但整体不独立的例子（见思考题 Q3）。
- **具体示例（i.i.d.）**：设 $I_1, \ldots, I_n$ 是 n 次抛硬币中"第 i 次为正面"的指示变量，每次成功概率都是 p。它们**独立且同分布 (independent and identically distributed, i.i.d.)**。这个短语在后续所有课程里都会高频出现——它是概率论里最标准的工作假设。

卷积（Convolution）

- **定义**：设 X, Y 独立。则 $Z = X + Y$ 的分布为

$$p_Z(z) = \Pr[Z = z] = \sum_x p_X(x)\, p_Y(z - x),$$

求和范围是所有使得 $p_X(x) > 0$ 且 $p_Y(z - x) > 0$ 的 x。这个求和形式称为 p_X 与 p_Y 的**卷积**。

- **直观解释**："要让 $X + Y = z$，就枚举 X 取什么值 x、于是 Y 必须取 $z - x$"。把所有互斥的可能加起来。**注意：没有独立性的话，这一步写不出来**——因为需要用 $\Pr[X = x, Y = z - x] = \Pr[X = x] \Pr[Y = z - x]$ 才能把联合概率拆成边缘概率之积。
- **具体示例**：两枚骰子之和。X, Y 各自均匀于 $\{1, \ldots, 6\}$。$p_Z(7) = \sum_{x=1}^{6} \frac{1}{6} \cdot p_Y(7 - x) = \sum_{x=1}^{6} \frac{1}{6} \cdot \frac{1}{6} = \frac{6}{36} = \frac{1}{6}$，因为对每个 $x \in \{1, \ldots, 6\}$ 都有 $7 - x \in \{1, \ldots, 6\}$（共 6 项）。而 $p_Z(2) = \frac{1}{6} \cdot p_Y(1) = \frac{1}{36}$（只有 $x = 1$ 一项）。

随机游走（Random Walk）

- **定义**：设 $X_1, X_2, \ldots$ 是 i.i.d. 的随机变量，$\Pr[X_i = +1] = \Pr[X_i = -1] = \frac{1}{2}$。定义

$$S_0 = 0, \qquad S_n = X_1 + X_2 + \cdots + X_n.$$

$\{S_n\}$ 称为**（对称）随机游走 (symmetric random walk)**。 – **直观解释**：一个醉汉站在数轴的 0 点上，每秒独立地以 $1/2$ 概率向右走一步、$1/2$ 概率向左走一步。S_n 是他 n 秒后的位置。这就是 n 次抛硬币的等价表述（正面记为 $+1$、反面记为 -1）。 – **具体示例**：$n = 4$ 时的可能位置只有 $S_4 \in \{-4, -2, 0, 2, 4\}$，因为 4 步中向右的步数 h 决定 $S_4 = 2h - 4$。分布为

$$\Pr[S_4 = -4] = \tfrac{1}{16},\ \Pr[S_4 = -2] = \tfrac{4}{16},\ \Pr[S_4 = 0] = \tfrac{6}{16},\ \Pr[S_4 = 2] = \tfrac{4}{16},\ \Pr[S_4 = 4] = \tfrac{1}{16}.$$

（脚本枚举 $2^4 = 16$ 条路径验证 ✔。）

LOTUS 的二维版本

- **定义**：对随机变量 X, Y 与函数 g，$\mathbb{E}[g(X, Y)] = \sum_a \sum_b g(a, b) \Pr[X = a, Y = b]$。
- **直观解释**：不要求 $g(X, Y)$ 的分布，直接在联合分布上加权求和。Lecture 20 的 LOTUS 是它的特例（g 只依赖一个变量）。
- **具体示例**：$\mathbb{E}[XY] = \sum_a \sum_b ab \Pr[X = a, Y = b]$ —— Lecture 20 定理 20.7 就是这样起步的。

完整证明与推导（核心）

定理 21.1（边缘化公式）：设 X, Y 有联合分布 $p_{X,Y}$。则

$$p_X(a) = \sum_{b \in B} p_{X,Y}(a,b), \qquad p_Y(b) = \sum_{a \in A} p_{X,Y}(a,b).$$

证明策略：**划分 + 可加性**。固定 a，把事件 $\{X = a\}$ 按 Y 的取值切成互不相交的小块，再用概率的可加性把这些小块的联合概率加起来。

逐步推导：

- 第一步：固定 $a \in A$，考虑事件 $\{X = a\}$。它是 Ω 的子集。
- 第二步：**按 Y 的取值对 $\{X = a\}$ 做划分**：

$$\{X = a\} = \bigsqcup_{b \in B} \{X = a,\, Y = b\}.$$

为什么这确实是**不交并**？两个方面： – **两两不交**：若 $\omega \in \{X = a, Y = b_1\} \cap \{X = a, Y = b_2\}$ 且 $b_1 \neq b_2$，则 $Y(\omega)$ 同时等于 b_1 和 b_2，与 Y 是**函数**（每个样本点只有一个值）矛盾。 – **并起来等于左边**：任取 $\omega \in \{X = a\}$，$Y(\omega)$ 必是 B 中某个值 b，故 $\omega \in \{X = a, Y = b\}$，落在某个小块里。 – 第三步：对不交并使用有限可加性（Lecture 15 的概率公理）：

$$\Pr[X = a] = \sum_{b \in B} \Pr[X = a,\, Y = b].$$

- 第四步：把 $\Pr[X = a]$ 认作 $p_X(a)$，右边认作 $p_{X,Y}(a,b)$ 的和，即得结论。对 Y 完全对称。■

【证明机制解说】：这个证明的骨架与 Lecture 20 定理 20.1 的第五步**完全同源**：核心都是"**函数性 ⇒ 划分 ⇒ 可加性**"。随机变量是函数，所以给定另一个变量的取值后，样本空间被切成一族互不相交的切片；求出每片的质量再相加，就得到边缘。**"找一个划分"这个套路在概率论里已经出现了三次**（定理 20.1、定理 20.6 LOTUS、本定理），值得作为通用工具记住。

定理 21.2（独立性的等价刻画）：对同一概率空间上的随机变量 X, Y，以下三条**等价**：

1. $X \perp Y$（即 $\Pr[X = a, Y = b] = \Pr[X = a]\Pr[Y = b]$ 对所有 a, b 成立）；
2. 对所有满足 $\Pr[Y = b] > 0$ 的 b 与所有 a，$\Pr[X = a \mid Y = b] = \Pr[X = a]$；
3. 对所有满足 $\Pr[X = a] > 0$ 的 a 与所有 b，$\Pr[Y = b \mid X = a] = \Pr[Y = b]$。

证明策略：**循环等价证明 (cyclic equivalence)**：$1 \Rightarrow 2 \Rightarrow 3 \Rightarrow 1$。选这个策略是因为每条蕴含都是一次简单的代数变形，循环一圈就把三条串成一个等价类（Lecture 1–2 学的证明技巧的直接应用）。

逐步推导：

- $1 \Rightarrow 2$：设 $\Pr[Y = b] > 0$。由条件概率定义（Lecture 17）与假设 1：

$$\Pr[X = a \mid Y = b] = \frac{\Pr[X = a,\, Y = b]}{\Pr[Y = b]} = \frac{\Pr[X = a]\Pr[Y = b]}{\Pr[Y = b]} = \Pr[X = a].$$

- $2 \Rightarrow 3$：由 2 得 $\Pr[X = a, Y = b] = \Pr[X = a \mid Y = b]\Pr[Y = b] = \Pr[X = a]\Pr[Y = b]$ 对一切 a 及 $\Pr[Y = b] > 0$ 的 b 成立。设 $\Pr[X = a] > 0$，两边除以 $\Pr[X = a]$ 得 $\Pr[Y = b \mid X = a] = \Pr[Y = b]$ ✔。（若 $\Pr[X = a] = 0$ 该条件概率本就无定义，属平凡情形。）
- $3 \Rightarrow 1$：设 $\Pr[X = a] > 0$。由 3 得 $\Pr[X = a, Y = b] = \Pr[Y = b \mid X = a]\Pr[X = a] = \Pr[Y = b]\Pr[X = a]$ ✔。若 $\Pr[X = a] = 0$，则该 a 对应的所有联合概率为 0，等式两边同为 0，仍成立。■

【证明机制解说】：这条定理的价值在于把"独立性"从一个**看起来无法验证的全局条件**（"对**所有** a, b"）变成一句可操作的直觉：**"知道 Y 不会改变对 X 的看法"**。考试里判独立，最方便的还是**表格判据**（逐格比较 $p_{X,Y}(a,b)$ 与行和×列和）；而理解"独立性 = 条件概率不变"则是做**证明题**时的抓手。

反例（条件"对所有 a, b"不可弱化）：定义要求**每一格**都满足 $p_{X,Y}(a,b) = p_X(a)p_Y(b)$，只验证其中一格（或一列）是不够的。下面这张表里，格子 $(0,1)$ 恰好"碰巧"满足，但其余格全部不满足：

$X \backslash Y$	0	1	行和 p_X
0	0.30	0.10	0.40
1	0.20	0.40	0.60
列和 p_Y	0.50	0.50	1.00

- 格子 $(0,0)$：实际 0.30，行和 × 列和 $= 0.40 \times 0.50 = 0.20$ ✘
- 格子 $(1,0)$：实际 0.20，$0.60 \times 0.50 = 0.30$ ✘
- 格子 $(1,1)$：实际 0.40，$0.60 \times 0.50 = 0.30$ ✘
- **仅仅**格子 $(0,1)$ 恰好相等：$0.10 = 0.40 \times 0.50$ ✔

一个格子相等推不出独立（脚本验算：$\mathbb{E}[X] = 0.6$、$\mathbb{E}[Y] = 0.5$、$\mathbb{E}[XY] = 0.40$，$\mathbb{E}[X]\mathbb{E}[Y] = 0.30$，故 $\mathrm{Cov} = +0.1 \neq 0$——独立时协方差必须为 0）。

更进一步：**在任何表中，"只差一整列"都不可能。** 固定一行 a^*，记 $\pi = \Pr[X = a^*]$、$c_b = \Pr[Y = b]$、$q_b = \Pr[X = a^* \mid Y = b]$（$c_b > 0$）。由全概率公式，$\pi = \sum_b q_b c_b$ 且 $\sum_b c_b = 1$。若 $q_b = \pi$ 对所有 $b \neq b^*$ 成立，则

$$\pi = \pi(1 - c_{b^*}) + q_{b^*} c_{b^*} \implies q_{b^*} = \pi,$$

即最后一列被迫自动满足。**所以偏差最少要出现在两个格子上**（思考题 Q4 有 "2×3 表中一整列满足、其余不满足"的具体例子）。

【这里的正确心态】：判独立时**先算清行和与列和，再逐格对照**；不要因为"某个格子对了"或"某一列对了"就下结论。定义里的"对所有 (a,b)"是一条**全局条件**；好消息是**找到任意一个反例格就可以立刻判定不独立**，所以实际判题往往几秒钟就够。

定理 21.3（独立随机变量之和的卷积公式）：设 $X \perp Y$ 为离散随机变量，$Z = X + Y$。则对每个 z，

$$p_Z(z) = \sum_x p_X(x)\, p_Y(z-x).$$

证明策略：**划分 + 独立性分解**。先按"X 取什么值"把事件 $\{Z=z\}$ 切开（划分套路第三次登场），再用独立性把每个切片的联合概率拆成边缘概率之积。

逐步推导：

- 第一步：固定 z，对事件 $\{Z=z\} = \{X+Y=z\}$ 按 X 的取值做划分：

$$\{X+Y=z\} = \bigsqcup_x \{X=x,\, Y=z-x\}.$$

- **不交**：不同的 x 给出不同的 $\{X=x\}$，互斥。
- **并起来等于左边**：若 ω 使 $X(\omega)+Y(\omega)=z$，令 $x=X(\omega)$，则 $Y(\omega)=z-x$，故 ω 落在 x 对应的那块里。
- 注意：对某些 x，$\{X=x, Y=z-x\}$ 可能是空集（当 $z-x \notin B$），此时概率为 0，不影响求和。
- 第二步：可加性给出

$$\Pr[Z=z] = \sum_x \Pr[X=x,\, Y=z-x].$$

- 第三步：**用独立性分解每一项**（这是唯一用到独立性的地方）：

$$\Pr[X=x,\, Y=z-x] = \Pr[X=x]\cdot\Pr[Y=z-x] = p_X(x)\, p_Y(z-x).$$

- 第四步：合并得 $p_Z(z) = \sum_x p_X(x) p_Y(z-x)$。$\blacksquare$

【证明机制解说】：请务必指出"独立性用在哪一步"——**只在第三步**。第一步的划分与第二步的可加性对**任意**（哪怕是强相关的）X, Y 都成立。这意味着一个重要的推广：

$$p_{X+Y}(z) = \sum_x \Pr[X=x,\, Y=z-x] \quad \text{（总成立）}, \qquad \text{（独立时才）} = \sum_x p_X(x) p_Y(z-x).$$

对不独立的变量，"$X+Y$ 的分布"仍然可以写成联合分布的和——**联合分布永远够用，独立性只是让你能用边缘分布代替联合分布**。这是本讲的核心思想：**联合分布是万能钥匙，独立性是一把省事的备用钥匙。**

反例（去掉独立性，公式失效）：取 $X \sim \text{Bernoulli}(1/2)$，$Y = X$（完全不独立）。则 $Z = X+Y = 2X$，故 $\Pr[Z=0] = \Pr[Z=2] = \frac{1}{2}$、$\Pr[Z=1]=0$。若强行套卷积公式（用边缘分布 $p_X = p_Y$ 都均匀于 $\{0,1\}$）：

$$\sum_x p_X(x) p_Y(1-x) = p_X(0)p_Y(1) + p_X(1)p_Y(0) = \tfrac{1}{4} + \tfrac{1}{4} = \tfrac{1}{2}.$$

而真实的 $\Pr[Z=1]=0$。**公式给出 $1/2$，真值是 0 —— 差得离谱。** 原因就在于 $\Pr[X=0,Y=1] = \Pr[X=1,Y=0] = 0$，而边缘乘积给出 $1/4$，独立性假设在第三步把真实的 0 换成了 $1/4$。（脚本验算：Z 的分布为 $\{0:0.5, 2:0.5\}$ ✔。）

定理 21.4（二项分布对参数 n 可加）：设 $X \sim \text{Bin}(n,p)$ 与 $Y \sim \text{Bin}(m,p)$ **独立**（注意概率参数 p 必须相同）。则

$$X + Y \sim \text{Bin}(n+m, p).$$

证明策略：**卷积 + 范德蒙德恒等式 (Vandermonde's identity)**。由于两个分布都带 $\binom{n}{k}$ 形式，卷积会产生 $\sum_j \binom{n}{j}\binom{m}{k-j}$，这正是范德蒙德恒等式的左边。

逐步推导：

- 第一步：用卷积公式（定理 21.3）。X 取值 $0,\dots,n$，Y 取值 $0,\dots,m$，两者独立：

$$\Pr[X+Y=k] = \sum_j \binom{n}{j} p^j (1-p)^{n-j} \cdot \binom{m}{k-j} p^{k-j}(1-p)^{m-(k-j)}.$$

- 第二步：把 p 的指数合并（$j + (k-j) = k$），把 $(1-p)$ 的指数合并（$(n-j)+(m-k+j) = n+m-k$），并把它们提出求和号（与 j 无关）：

$$= p^k (1-p)^{n+m-k} \sum_j \binom{n}{j}\binom{m}{k-j}.$$

- 第三步：**关键一步——范德蒙德恒等式**。$\sum_j \binom{n}{j}\binom{m}{k-j} = \binom{n+m}{k}$。这条恒等式可以用 Lecture 16 的**双计数**证明：从 n 个红球与 m 个蓝球共 $n+m$ 个球中选 k 个，按"选了几个红球"分类，选 j 个红球有 $\binom{n}{j}$ 种、$k-j$ 个蓝球有 $\binom{m}{k-j}$ 种，对 j 求和即得。

$$= p^k (1-p)^{n+m-k} \binom{n+m}{k}.$$

- 第四步：这恰是 $\mathbf{Bin}(n+m,p)$ 的概率质量函数。■

数值验算：$n=2,\ m=3,\ p=0.3$。用卷积直接算 $p_{X+Y}(k)$，与 $\mathbf{Bin}(5,0.3)$ 的公式逐项比对：

k	0	1	2	3	4	5
卷积结果	0.16807	0.36015	0.30870	0.13230	0.02835	0.00243
$\mathbf{Bin}(5,0.3)$	0.16807	0.36015	0.30870	0.13230	0.02835	0.00243

八位小数完全一致（脚本验算 ✔）。$p=0.5,\ n=2,\ m=3$ 时也是精确匹配：卷积得到
$\{0:0.03125,\ 1:0.15625,\ 2:0.3125,\ 3:0.3125,\ 4:0.15625,\ 5:0.03125\}=\binom{5}{k}/32$ ✔。

直观解释：$\mathbf{Bin}(n,p)$ 是"抛 n 次偏置硬币数正面"。先抛 n 次、独立地再抛 m 次，总共抛了 $n+m$ 次——所以结果当然是 $\mathbf{Bin}(n+m,p)$。**证明的价值不在结论（结论显然），而在于演示卷积 + 范德蒙德这套机械；以及警示 p 必须相同。**

反例（p 不同则结论失效）：$X\sim\mathbf{Bin}(1,1/2)$、$Y\sim\mathbf{Bin}(1,1)$（即 $Y\equiv 1$）独立。则 $X+Y$ 取值 $\{1,2\}$，$\Pr[X+Y=1]=\frac12$、$\Pr[X+Y=2]=\frac12$。若以为 $X+Y\sim\mathbf{Bin}(2,p)$，无论取 $p=1/2$（得 $\Pr[=0]=1/4\neq 0$）还是 $p=1$（得 $\Pr[=1]=0\neq 1/2$）都不对。**$X+Y$ 根本不是二项分布。** 它的分布实际上是 $\mathbf{Bernoulli}(1/2)$ 平移 $+1$。

定理 21.5（泊松分布对参数 λ 可加）：设 $X\sim\mathbf{Pois}(\lambda)$ 与 $Y\sim\mathbf{Pois}(\mu)$ 独立。则

$$X+Y\sim\mathbf{Pois}(\lambda+\mu).$$

证明策略：**卷积 + 二项式定理**。卷积产生 $\sum_j \frac{\lambda^j}{j!}\frac{\mu^{k-j}}{(k-j)!}$，提出 $\frac{1}{k!}$ 后正好是 $(\lambda+\mu)^k$ 的二项式展开。

逐步推导：

- 第一步：用卷积公式（两者取值都是 $0,1,2,\ldots$，上界取到 k 即可，因为 $z-x<0$ 时 $p_Y=0$）：

$$\Pr[X+Y=k]=\sum_{j=0}^{k}\frac{\lambda^j}{j!}e^{-\lambda}\cdot\frac{\mu^{k-j}}{(k-j)!}e^{-\mu}.$$

- 第二步：把 $e^{-\lambda}e^{-\mu}=e^{-(\lambda+\mu)}$ 提出；为了凑出二项式定理的形式，在求和号内乘除 $\frac{k!}{k!}$：

$$=e^{-(\lambda+\mu)}\cdot\frac{1}{k!}\sum_{j=0}^{k}\frac{k!}{j!\,(k-j)!}\lambda^j\mu^{k-j}.$$

- 第三步：注意 $\frac{k!}{j!(k-j)!}=\binom{k}{j}$，故内层求和恰是**二项式定理**（Lecture 14 的组合证明中已用过）：

$$\sum_{j=0}^{k}\binom{k}{j}\lambda^j\mu^{k-j}=(\lambda+\mu)^k.$$

- 第四步：合并得

$$\Pr[X+Y=k]=e^{-(\lambda+\mu)}\frac{(\lambda+\mu)^k}{k!},$$

这正是 $\mathbf{Pois}(\lambda+\mu)$ 的概率质量函数。■

数值验算：$\lambda=1.5,\ \mu=2.5$（和 $=4$）。卷积逐项与 $\mathbf{Pois}(4)$ 比对：

k	0	1	2	3	4	5	6	7
卷积结果	0.018316	0.073263	0.146525	0.195367	0.195367	0.156293	0.104196	0.059540
$\mathbf{Pois}(4)$	0.018316	0.073263	0.146525	0.195367	0.195367	0.156293	0.104196	0.059540

九位小数完全一致（脚本验算 ✔）。

直观解释：泊松分布描述"某段时间内稀有事件发生的次数"，参数 λ 是**发生率**。若两个独立的稀有事件源分别以 λ、μ 的频率发生，把它们合并起来看，总发生率显然是 $\lambda+\mu$——而且合并后仍是"稀有事件计数"，所以仍是泊松分布。用 Lecture 19 的"泊松是二项分布的极限"语言：$\mathbf{Bin}(n,\lambda/n)$ 与 $\mathbf{Bin}(m,\mu/m)$ 独立，和为 $\mathbf{Bin}(n+m,\cdot)$ 型（p 不同，严格说不是二项，但极限上给出 $\mathbf{Pois}(\lambda+\mu)$），与定理 21.5 一致。

归纳推广：若 $X_i\sim\mathbf{Pois}(\lambda_i)$ 相互独立，则 $\sum_{i=1}^{n}X_i\sim\mathbf{Pois}(\sum_{i=1}^{n}\lambda_i)$。证明用对 n 的归纳法：基础情形 $n=1$；归纳步骤把 $\sum_{i=1}^{n-1}X_i$（由归纳假设服从 $\mathbf{Pois}(\sum_{i<n}\lambda_i)$，且与 X_n 独立）与 X_n 用定理 21.5 合并。

定理 21.6（随机游走：期望与平方期望）：设 $S_n=\sum_{i=1}^{n}X_i$，X_i 独立且 $\Pr[X_i=1]=\Pr[X_i=-1]=\frac12$。则

$$\mathbb{E}[S_n]=0,\qquad \mathbb{E}[S_n^2]=n.$$

证明策略：**第一部分用线性性（无需独立）；第二部分用"展开平方 + 交叉项为零"**，其中交叉项 $\mathbb{E}[X_iX_j]=0$ 需要用到**独立性**（并且第 20 讲定理 20.7 的乘积法则也需要它）。这个"哪里需要独立"的分界线正是本讲要传达的核心手艺。

逐步推导（第一部分：$\mathbb{E}[S_n]=0$）：

- 第一步：$\mathbb{E}[X_i] = \frac{1}{2}\cdot(+1) + \frac{1}{2}\cdot(-1) = 0$。
- 第二步：线性性（Lecture 20 定理 20.4）：$\mathbb{E}[S_n] = \sum_{i=1}^{n}\mathbb{E}[X_i] = \sum_{i=1}^{n} 0 = 0$。

注意：**这一步不需要独立性**。也可以完全不用线性性，用**对称性**论证：把每条路径 $\omega = (x_1, \dots, x_n)$ 与它的"镜像" $\omega' = (-x_1, \dots, -x_n)$ 配对，两者概率相同（因为 $\Pr[X_i = \pm 1]$ 对称）而 $S_n(\omega') = -S_n(\omega)$，于是 $\mathbb{E}[S_n] = 0$。**对称性论证的优势是"零计算"，但只在分布对称时可用；线性性更通用。**

逐步推导（第二部分：$\mathbb{E}[S_n^2] = n$）：

- 第一步：展开平方：

$$S_n^2 = \Big(\sum_{i=1}^{n} X_i\Big)^2 = \sum_{i=1}^{n} X_i^2 + 2\sum_{i<j} X_i X_j.$$

- 第二步：用线性性（**这一步仍然不需要独立**，因为只是把和拆开）：

$$\mathbb{E}[S_n^2] = \sum_{i=1}^{n}\mathbb{E}[X_i^2] + 2\sum_{i<j}\mathbb{E}[X_i X_j].$$

- 第三步：第一项。X_i 只取 ± 1，故 $X_i^2 = 1$ **恒成立**（对所有样本点），于是 $\mathbb{E}[X_i^2] = 1$。

这里有一个重要提醒：如果按 LOTUS 算，$\mathbb{E}[X_i^2] = \frac{1}{2}(1)^2 + \frac{1}{2}(-1)^2 = 1$，结果相同。但**不要**把 $\mathbb{E}[X_i^2]$ 误写成 $(\mathbb{E}[X_i])^2 = 0$ —— 那是 Lecture 20 反复警告的 $\mathbb{E}[g(X)] \neq g(\mathbb{E}[X])$ 陷阱。 – 第四步：第二项。对 $i \neq j$，因 $X_i \perp X_j$，由定理 20.7（乘积期望可乘）得

$$\mathbb{E}[X_i X_j] = \mathbb{E}[X_i]\mathbb{E}[X_j] = 0 \cdot 0 = 0.$$

直接用定义也可以：$X_i X_j = +1$ 当且仅当两步同向，概率为 $\frac{1}{2}$（两种情况 $++$ 或 $--$，各 $\frac{1}{4}$）；$X_i X_j = -1$ 当且仅当两步反向，概率也是 $\frac{1}{2}$（$+-$ 或 $-+$，各 $\frac{1}{4}$）。于是

$$\mathbb{E}[X_i X_j] = \tfrac{1}{2}(1) + \tfrac{1}{2}(-1) = 0.$$

这条"直接用定义"的算路**同样用到了独立性**——因为 $\Pr[X_i = 1, X_j = 1] = \frac{1}{4} = \Pr[X_i = 1]\Pr[X_j = 1]$ 才是那个 $\frac{1}{4}$ 的来源。 – 第五步：代入。等式里共有 $\binom{n}{2}$ 个交叉项，每项为 0：

$$\mathbb{E}[S_n^2] = \sum_{i=1}^{n} 1 + 2\sum_{i<j} 0 = n + 0 = n. \qquad \blacksquare$$

数值验算（脚本穷举 2^n 条路径）：

n	S_n 的分布	$\mathbb{E}[S_n^2]$	$\sqrt{\mathbb{E}[S_n^2]}$	$\mathbb{E}[\lvert S_n\rvert]$
2	$\{-2:\frac{1}{4},\ 0:\frac{1}{2},\ 2:\frac{1}{4}\}$	2.000	1.414	1.0000
3	$\{-3:\frac{1}{8},\ -1:\frac{3}{8},\ 1:\frac{3}{8},\ 3:\frac{1}{8}\}$	3.000	1.732	1.5000
4	$\{-4:\frac{1}{16},\ -2:\frac{4}{16},\ 0:\frac{6}{16},\ 2:\frac{4}{16},\ 4:\frac{1}{16}\}$	4.000	2.000	1.5000
5	$\{-5:\frac{1}{32},\ -3:\frac{5}{32},\ -1:\frac{10}{32},\ 1:\frac{10}{32},\ 3:\frac{5}{32},\ 5:\frac{1}{32}\}$	5.000	2.236	—
10	二项平移	10.000	3.162	2.4609

全部与定理 21.6 一致（脚本验算 ✔）。

【证明机制解说】：这个证明最值得学的是"**哪些步骤需要什么**"的分层：

1. **展开平方、把求和拆开** —— 只用线性性，**不需要独立**；
2. **把 $\mathbb{E}[X_i X_j]$ 拆成 $\mathbb{E}[X_i]\mathbb{E}[X_j]$** —— **必须用独立**；
3. **$X_i^2 = 1$** —— 只用 X_i 的值域，连分布都不需要。

如果去掉独立性会怎样？ 假设 $X_2 = X_1$（第二步完全复制第一步，不独立）。则 $S_2 = 2X_1$，$S_2^2 = 4$，$\mathbb{E}[S_2^2] = 4 \neq 2$。**定理 21.6 的结论 n 严重失效。** 差别全部来自交叉项：这里 $\mathbb{E}[X_1 X_2] = \mathbb{E}[X_1^2] = 1 \neq 0$，于是 $\mathbb{E}[S_2^2] = 1 + 1 + 2\cdot 1 = 4$ ✔。**这就是"交叉项是否为零"的巨大威力，它正是 Lecture 22 协方差概念要精确刻画的量。**

关于 $\mathbb{E}[\lvert S_n\rvert]$ 的重要警告：既然 $\mathbb{E}[S_n^2] = n$，能不能推出 $\mathbb{E}[\lvert S_n\rvert] = \sqrt{n}$？**不能！** 因为 $\sqrt{\cdot}$ 是**凹函数**，由詹森不等式，$\mathbb{E}[\lvert S_n\rvert] = \mathbb{E}[\sqrt{S_n^2}] \leq \sqrt{\mathbb{E}[S_n^2]} = \sqrt{n}$，方向是 $\leq$ 而不是 $=$（等号仅在 $\lvert S_n\rvert$ 为常数时成立）。数值验证：$n = 4$ 时 $\sqrt{\mathbb{E}[S_n^2]} = 2.000$，而 $\mathbb{E}[\lvert S_4\rvert] = 1.5000$；$n = 10$ 时 3.162 对 2.4609；$n = 2$ 时 1.414 对 1.0000。**$\mathbb{E}[\lvert S_n\rvert]$ 总是严格更小。** 正确的解读是：$\mathbb{E}[S_n^2]$ 是"**典型偏离量级的平方**"的一个方便的替代指标，我们要说"粒子通常离原点约 $\sqrt{n}$"，严格化要靠 Lecture 23–25 的集中不等式与中心极限定理。

定理 21.7（方差对独立随机变量可加，Lecture 22 预告）：若 $X \perp Y$，则

$$\mathrm{Var}(X + Y) = \mathrm{Var}(X) + \mathrm{Var}(Y).$$

证明策略：**直接用定义 + 展开**（$\mathrm{Var}(Z) = \mathbb{E}[Z^2] - (\mathbb{E}[Z])^2$），把交叉项单独挑出来，然后指出它恰是 $\mathrm{Cov}(X, Y)$ 并因独立而为零。

逐步推导：

- 第一步：由 Lecture 16/22 的公式 $\mathbf{Var}(Z)=\mathbb{E}[Z^2]-(\mathbb{E}[Z])^2$（这里先借用，Lecture 22 会正式证明）：

$$\mathbf{Var}(X+Y)=\mathbb{E}\big[(X+Y)^2\big]-\big(\mathbb{E}[X+Y]\big)^2.$$

- 第二步：展开平方并用线性性（**不需要独立**）：

$$\mathbb{E}\big[(X+Y)^2\big]=\mathbb{E}[X^2]+2\mathbb{E}[XY]+\mathbb{E}[Y^2],\qquad \big(\mathbb{E}[X+Y]\big)^2=(\mathbb{E}[X]+\mathbb{E}[Y])^2.$$

- 第三步：相减并整理：

$$\mathbf{Var}(X+Y)=\big(\mathbb{E}[X^2]-\mathbb{E}[X]^2\big)+\big(\mathbb{E}[Y^2]-\mathbb{E}[Y]^2\big)+2\big(\mathbb{E}[XY]-\mathbb{E}[X]\mathbb{E}[Y]\big).$$

- 第四步：认出前两个括号是 $\mathbf{Var}(X)$ 与 $\mathbf{Var}(Y)$，第三个括号是**协方差** $\mathbf{Cov}(X,Y)$：

$$\mathbf{Var}(X+Y)=\mathbf{Var}(X)+\mathbf{Var}(Y)+2\,\mathbf{Cov}(X,Y).$$

- 第五步：由 $X\perp Y$ 与定理 20.7，$\mathbf{Cov}(X,Y)=\mathbb{E}[XY]-\mathbb{E}[X]\mathbb{E}[Y]=0$，故 $\mathbf{Var}(X+Y)=\mathbf{Var}(X)+\mathbf{Var}(Y)$。■

【证明机制解说】——为什么这里需要独立，而期望相加不需要?

这是本讲与 Lecture 20 之间最重要的对比，值得单独展开：

	期望	方差
可加性	$\mathbb{E}[X+Y]=\mathbb{E}[X]+\mathbb{E}[Y]$	$\mathbf{Var}(X+Y)=\mathbf{Var}(X)+\mathbf{Var}(Y)$
是否需要独立	**不需要**（无条件成立）	**需要**（不独立时有 $+2\,\mathbf{Cov}(X,Y)$）
根本原因	期望是**一次**加权平均，加法在其中是**线性**的	方差含**平方**，展开后产生**交叉项** $2\mathbb{E}[XY]$，而乘法在概率里**需要独立才能分解**

一句话：加法在期望里是"原生"的线性运算，在方差里却要先经过平方（非线性），于是被迫产生乘积项；而乘积项的处理需要独立。 这也解释了为什么 Lecture 20 的"免费午餐"是有边界的——它免费的是**一阶**矩，而二阶矩要付独立性的"费"。

反例（不独立时方差不可加）：$X\sim\mathbf{Bernoulli}(1/2)$，$Y=X$。则 $\mathbf{Var}(X)=\mathbf{Var}(Y)=\frac14$，但 $X+Y=2X$，$\mathbf{Var}(2X)=4\,\mathbf{Var}(X)=1$（用 $\mathbf{Var}(cX)=c^2\,\mathbf{Var}(X)$）。而 $\mathbf{Var}(X)+\mathbf{Var}(Y)=\frac12$。$1\neq\frac12$，差额正是 $2\,\mathbf{Cov}(X,X)=2\,\mathbf{Var}(X)=\frac12$ ✔。

数值算例（协方差非零但两变量都"正常"）：X 为第一枚骰子、Y 为两枚骰子之和。前面算过 $\mathbb{E}[X]=3.5$、$\mathbb{E}[Y]=7$、$\mathbb{E}[XY]=27.4167$，故

$$\mathbf{Cov}(X,Y)=27.4167-3.5\times7=27.4167-24.5=2.9167=\frac{35}{12}.$$

同时 $\mathbf{Var}(X)=\frac{35}{12}$、$\mathbf{Var}(Y)=\frac{35}{6}$，故

$$\mathbf{Var}(X+Y)=\frac{35}{12}+\frac{35}{6}+2\cdot\frac{35}{12}=14.5833.$$

独立验算：$X+Y=2X+Z$（Z 为第二枚骰子，与 X 独立），故 $\mathbf{Var}(X+Y)=4\,\mathbf{Var}(X)+\mathbf{Var}(Z)=4\cdot\frac{35}{12}+\frac{35}{12}=14.5833$ ✔（脚本验算一致）。

定理 21.8（n 个独立同分布随机变量之和的方差）：若 $X_1,\dots,X_n$ 相互独立且同分布，则

$$\mathbf{Var}\left(\sum_{i=1}^{n}X_i\right)=n\,\mathbf{Var}(X_1),\qquad \sigma\left(\sum_{i=1}^{n}X_i\right)=\sqrt{n}\,\sigma(X_1).$$

证明策略：**归纳法**，归纳步骤用定理 21.7。注意归纳步骤还要求"前 $n-1$ 项之和 与 X_n 独立"，这由**相互独立**保证（相互独立蕴含任意分组后的和与剩余变量独立）。

逐步推导：

- 基础情形 $n=1$：平凡。
- 归纳假设：对 $n-1$ 成立。
- 归纳步骤：令 $T_{n-1}=\sum_{i=1}^{n-1}X_i$。由相互独立性，$T_{n-1}\perp X_n$。于是

$$\mathbf{Var}\left(\sum_{i=1}^{n}X_i\right)=\mathbf{Var}(T_{n-1}+X_n)\overset{\text{定理 21.7}}{=}\mathbf{Var}(T_{n-1})+\mathbf{Var}(X_n)\overset{\text{归纳}}{=}(n-1)\,\mathbf{Var}(X_1)+\mathbf{Var}(X_1)=n\,\mathbf{Var}(X_1).$$

取平方根并用 $\sigma=\sqrt{\mathbf{Var}}$ 得 $\sigma=\sqrt{n}\,\sigma(X_1)$。■

【证明机制解说】：对照 Lecture 20 的 n 个变量版本 $\mathbb{E}[\sum X_i]=\sum\mathbb{E}[X_i]$（现在不需要同分布、不需要独立），这里的方差版本**同时要求独立与同分布**（独立是为了可加性，同分布是为了让每项都是同一个 $\mathbf{Var}(X_1)$）。这条差异的具体后果非常重要：

$$\mathbb{E}\Big[\sum X_i\Big]=n\mu\quad\text{线性增长},\qquad \sigma\Big(\sum X_i\Big)=\sqrt{n}\,\sigma\quad\text{只有 }\sqrt{n}\text{ 增长}.$$

也就是说，**"平均值的散布"比"平均值的量级"小得多**——这正是大数定律与中心极限定理的引擎。以随机游走为例：n 步后位置的典型量级是 $\sqrt{n}$（不是 n）。$n=10^4$ 步后，醉汉离原点的距离通常只有约 100 步。

反例（同分布必需）：若 $\mathbf{Var}(X_1)\neq\mathbf{Var}(X_2)$，则一般 $\mathbf{Var}(X_1+X_2)=\mathbf{Var}(X_1)+\mathbf{Var}(X_2)$ 仍然成立（**可加性只要求独立**），但写成 $2\,\mathbf{Var}(X_1)$ 就错了。**"同分布"只在把求和化简为 $n\,\mathbf{Var}(X_1)$ 时才需要。** 独立 + 不同分布时正确的形式是 $\mathbf{Var}(\sum X_i)=\sum\mathbf{Var}(X_i)$。

与经典问题的联系

1. 哈希表中"碰撞事件之间是否独立"

- **实际背景**：Lecture 20 分析 m 个键哈希到 n 个槽时，用指示变量 I_{C_i} 数碰撞对数。
- **联合分布视角**：各个 C_i 是同一概率空间上**强相关**的事件（若 (u,v) 与 (v,w) 都碰撞，则 (u,w) 必然碰撞）。它们的联合分布**不是**边缘分布之积。
- **为什么仍然可行**：Lecture 20 的线性性不需要独立。但**若要算** $\mathbf{Var}(C)$（Lecture 23 的切比雪夫界需要它），就必须认真处理这些相关性——这正是 Lecture 22 协方差矩阵的用武之地。"独立性和线性性的边界"在哈希分析里体现得最清楚。

2. 纠错码中的"包丢失"建模（与 Lecture 8 / Lecture 19 呼应）

- **实际背景**：把 n 个包编成 $n+k$ 个包，收到任意 n 个即可重建。
- **数学建模**：设第 i 个包的丢失指示变量为 $L_i \sim \mathbf{Bernoulli}(p)$，且 $L_1, \ldots, L_k$ 相互独立（信道无记忆）。则收到的包数为 $\sum_i (1-L_i) \sim \mathbf{Bin}(n+k, 1-p)$——**定理 21.4** 直接把"$n+k$ 个独立伯努利之和"识别为二项分布。
- **方案设计**：$\mathbf{Pr}[\text{成功}] = \mathbf{Pr}[\sum_i (1-L_i) \geq n]$。若进一步设各包的丢失概率**不同**（$L_i \sim \mathbf{Bernoulli}(p_i)$，独立但不同分布），就得到**泊松二项分布 (Poisson binomial)**——此时定理 21.4 不再适用，但定理 21.7 的"独立即可加"仍然成立，$\mathbf{Var} = \sum p_i(1-p_i)$。

3. 分布式系统中"多台服务器的故障计数"

- **实际背景**：n 台服务器，第 i 台在单位时间内发生故障的次数服从 $\mathbf{Pois}(\lambda_i)$。
- **数学建模**：若各服务器故障过程独立，则总故障次数由**定理 21.5** 得 $\mathbf{Pois}(\sum \lambda_i)$。
- **用途**：这解释了为什么运维指标里"集群总事件率"是一个有意义的单一数字——只要各源独立，总计数仍然是同一族分布，参数直接相加。若源之间相关（比如同一机房断电），则此结论失效，必须回到联合分布。

4. 随机游走与"布朗运动 / 扩散"

- **实际背景**：气体分子在液体中的位移、股票价格的微小波动、网络包的往返时间抖动，都常被建模为随机游走。
- **数学结论**：$\mathbb{E}[S_n] = 0$、$\mathbf{Var}(S_n) = n$（定理 21.6 与 21.8），即位置分布集中在 0 附近、宽度约 $\sqrt{n}$。这就是"**扩散尺度是 $\sqrt{\text{时间}}$**"这一物理定律的离散版本。
- **进一步**：Lecture 25 的中心极限定理会把 $S_n/\sqrt{n}$ 的分布精确收敛到标准正态——那个著名的钟形曲线最早就是从随机游走的二项分布里冒出来的（De Moivre–Laplace 定理）。

5. 两枚骰子之和的完整分布表（本讲的"基础算例"）

把 36 个等概率样本点按和分类，得到教科书式的对称三角形分布：

```
两枚公平骰子之和 Z = X + Y 的分布  (分母恒为 36)

计数
 6 |                        ##
 5 |                     ## ## ##
 4 |                  ## ## ## ## ##
 3 |               ## ## ## ## ## ## ##
 2 |            ## ## ## ## ## ## ## ## ##
 1 |         ## ## ## ## ## ## ## ## ## ## ##
   +-------------------------------------------------
     2  3  4  5  6  7  8  9 10 11 12   <- z = X+Y
    (1)(2)(3)(4)(5)(6)(5)(4)(3)(2)(1)  <- 组合数

概率:  1/36, 2/36, 3/36, 4/36, 5/36, 6/36, 5/36, 4/36, 3/36, 2/36, 1/36
验算:  sum = (1+2+3+4+5+6+5+4+3+2+1)/36 = 36/36 = 1   ✔
E[Z] = sum z * P[Z=z] = 252/36 = 7   (= 3.5 + 3.5)      ✔
Var(Z) = Var(X)+Var(Y) = 35/12 + 35/12 = 35/6 ≈ 5.8333 ✔ (独立, 用定理21.7)
```

这张表是**卷积公式（定理 21.3）最直观的体现**：格子 (x,y) 的作用就是往 $z = x+y$ 那条反对角线上加 1。下面再看一张完整的**联合分布表**（含边缘和）来说明"表格判据"的用法：

```
X = 第一枚骰子的点数,  Y = 两枚骰子之和   (只展示 Y 从 2 到 7 的列, 概率分母 36)

     Y=2  Y=3  Y=4  Y=5  Y=6  Y=7 | 行和 p_X
X=1   1    1    1    1    1    1  |   6/36 = 1/6
X=2   0    1    1    1    1    1  |   6/36 = 1/6
X=3   0    0    1    1    1    1  |   6/36 = 1/6
X=4   0    0    0    1    1    1  |   6/36 = 1/6
X=5   0    0    0    0    1    1  |   6/36 = 1/6
X=6   0    0    0    0    0    1  |   6/36 = 1/6
-----------------------------------+-----------
列和 p_Y  1/36 2/36 3/36 4/36 5/36 6/36 |   总和 = 1

独立性检查 (取格子 X=6, Y=2):
     实际 p_{X,Y}(6,2) = 0/36 = 0
     行和 × 列和 = (1/6) × (1/36) = 1/216 ≈ 0.00463
     0 ≠ 0.00463  ==>  X 与 Y 不独立  ✔ (由 X=6 可推出 Y>=7, 完全约束)

对照: 若 Y = 第二枚骰子 (与 X 独立), 则每格都等于 1/36 = (1/6)(1/6), 判据全部通过
```

6. 二项分布的"合并"在 A/B 测试中的意义

- **实际背景**：把用户随机分成两组做实验，A 组 n 人转化 X 人，B 组 m 人转化 Y 人。
- **数学结论**：若两组转化率相同都是 p 且相互独立，则 $X+Y \sim \mathbf{Bin}(n+m,p)$（定理 21.4）。**这就是"两组可以合并估计基准转化率"的数学依据。** 反之，若两组的 p 不同（存在处理效应），则定理 21.4 失效——这正是 A/B 测试里"必须检验显著差异"的根源。

与其他讲次的关联

- **承接 Lecture 18（独立性与事件组合）**：随机变量的独立性**就是**"对所有 (a,b)，事件 $X=a$ 与事件 $Y=b$ 独立"（定理 21.2）。Lecture 18 建立的 $\Pr[A\cap B]=\Pr[A]\Pr[B]$ 是本讲全部推导的基本零件；Lecture 18 的**联合界**（用于哈希容量与负载均衡）与本讲的联合分布是同一批对象上的两种工具：前者只用一个边际不等式，后者用完整表。
- **承接 Lecture 19（随机变量与离散分布）**：$\mathbf{Bernoulli}$、$\mathbf{Bin}$、$\mathbf{Geometric}$、$\mathbf{Pois}$ 的定义与 PMF 都来自 Lecture 19。定理 21.4 与 21.5 是这些分布在"独立求和"运算下的封闭性；Lecture 19 的 i.i.d. 概念是本讲随机游走定义的前提。
- **承接 Lecture 20（期望与线性性）**：**本讲是 Lecture 20 的直接续篇。**定理 21.6 的第一部分（$\mathbb{E}[S_n]=\mathbf{0}$）纯用 Lecture 20 的线性性；定理 21.7 的推导中反复出现 Lecture 20 的 $\mathbb{E}[XY]=\mathbb{E}[X]\mathbb{E}[Y]$（定理 20.7）。Lecture 20 反复强调的"线性性不需要独立"，与本讲"乘积期望可乘需要独立"形成**最关键的对照**——请把这两条并排记在笔记上。
- **通向 Lecture 22（方差与协方差）**：定理 21.7 推导中浮现的 $\mathbf{Cov}(X,Y)=\mathbb{E}[XY]-\mathbb{E}[X]\mathbb{E}[Y]$ 就是 Lecture 22 的主角。Lecture 22 会证明 $\mathbf{Cov}$ 具有**双线性 (bilinear)**：$\mathbf{Cov}(\sum a_iX_i,\sum b_jY_j)=\sum_{i,j}a_ib_j\,\mathbf{Cov}(X_i,Y_j)$，从而得到一般公式 $\mathbf{Var}(\sum X_i)=\sum_i\mathbf{Var}(X_i)+2\sum_{i<j}\mathbf{Cov}(X_i,X_j)$ ——**定理 21.6 中那些为零的交叉项，正是这个公式的特例**。Lecture 22 还会给出相关系数 $\mathbf{Corr}\in[-1,1]$ 并强调"$\mathbf{Cov}=0$ 不推出独立"（本讲的反例 $Y=|X|$ 正是这个论断的样本）。
- **通向 Lecture 23（集中不等式）**：随机游走 "$\mathbb{E}[S_n]=0$、$\mathbf{Var}(S_n)=n$" 立即给出切比雪夫界 $\Pr[|S_n|\ge t\sqrt{n}]\le 1/t^2$ ——**位置的集中尺度确实是 $\sqrt{n}$**。Lecture 23 的切尔诺夫界会把二项分布之和的尾概率压到指数级小，是 $\Pr[\text{解码成功}]$ 这类工程估算的工具。
- **通向 Lecture 25（高斯分布与 CLT）**：本讲的随机游走是 CLT 的入门模型。S_n 的分布就是 $\mathbf{Bin}(n,1/2)$ 的平移缩放；当 $n\to\infty$，$\frac{S_n}{\sqrt{n}}$ 的分布趋近标准正态 $\mathcal{N}(0,1)$。
- **回连 Lecture 14 / Lecture 16（计数与组合证明）**：定理 21.4 第三步的**范德蒙德恒等式** $\sum_j\binom{n}{j}\binom{m}{k-j}=\binom{n+m}{k}$ 用 Lecture 16 的**双计数**证明（按"从 n 个红球里选了几个"分类数从 $n+m$ 个球里选 k 个）；定理 21.5 第三步用的**二项式定理**也是 Lecture 14/16 的结论。

关键要点

1. **联合分布 $p_{X,Y}(a,b)=\Pr[X=a,Y=b]$ 是完整信息；边缘分布 $p_X(a)=\sum_b p_{X,Y}(a,b)$ 是它的投影。投影丢信息，且不可逆 —— 不同的联合分布可以有完全相同的边缘分布（反例见思考题 Q1）。**
2. **判独立用表格：每一格 $\overset{?}{=}$ 行和 × 列和。** 找到一个格子不等即可判定不独立。等价表述：$\Pr[X=a\mid Y=b]=\Pr[X=a]$ 对一切 (a,b) 成立（定理 21.2）。**条件是对所有 (a,b)，不可弱化。**
3. **卷积是为独立随机变量之和准备的：$p_{X+Y}(z)=\sum_x p_X(x)p_Y(z-x)$，独立性用在"把联合概率拆成边缘之积"这一步。**不独立时该公式失效，但仍可用 $p_{X+Y}(z)=\sum_x\Pr[X=x,Y=z-x]$（联合分布永远有效）。
4. **两条分布封闭性必须背下来：$\mathbf{Bin}(n,p)+\mathbf{Bin}(m,p)=\mathbf{Bin}(n+m,p)$（$p$ 必须相同）；$\mathbf{Pois}(\lambda_1)+\mathbf{Pois}(\lambda_2)=\mathbf{Pois}(\lambda_1+\lambda_2)$（$\lambda$ 直接相加）。**
5. **"独立"这条分界线：$\mathbb{E}[X+Y]=\mathbb{E}[X]+\mathbb{E}[Y]$ 不需要独立；$\mathbf{Var}(X+Y)=\mathbf{Var}(X)+\mathbf{Var}(Y)$ 需要独立**（否则多出 $+2\,\mathbf{Cov}(X,Y)$）；**$\mathbb{E}[XY]=\mathbb{E}[X]\mathbb{E}[Y]$ 需要独立**（且反向不成立）。**一阶矩免费，二阶矩收费。**
6. **随机游走的两条基准结论：$\mathbb{E}[S_n]=0$、$\mathbf{Var}(S_n)=\mathbb{E}[S_n^2]=n$、$\sigma(S_n)=\sqrt{n}$。位置的典型量级是 $\sqrt{n}$，不是 n。** 但**不要**由此推出 $\mathbb{E}[|S_n|]=\sqrt{n}$（凹函数方向相反）。

常见误区与注意事项

1. **混淆"边缘分布相同"与"联合分布相同"。** 分别知道 p_X 和 p_Y **不足以**确定 $p_{X,Y}$。这是本讲最重要的概念分界。任何"因为 X 和 Y 各自的分布是这样，所以它们的联合分布是那样"的推理都是错的——**必须额外有独立性或其它结构假设**。
2. **把"独立"与"不相关/互斥"混为一谈。** 三个不同的概念：
3. **互斥 (disjoint)**：$X=a$ 与 $Y=b$ 不能同时发生（$\Pr[X=a,Y=b]=0$）。互斥的两个**非退化**事件必然**不独立**（因为 $0\neq\Pr[X=a]\Pr[Y=b]>0$）。
4. **不相关 (uncorrelated)**：$\mathbb{E}[XY]=\mathbb{E}[X]\mathbb{E}[Y]$，等价于 $\mathbf{Cov}(X,Y)=0$。这是**弱**条件。
5. **独立 (independent)**：$p_{X,Y}=p_Xp_Y$ 逐格成立。这是**强**条件，蕴含不相关，反之不然（X 均匀于 $\{-1,0,1\}$、$Y=|X|$ 即反例）。
6. **卷积公式用错范围。** $p_Z(z)=\sum_x p_X(x)p_Y(z-x)$ 中的 x 要遍历**所有**可能值，但只有同时满足 "$p_X(x)>0$" 与 "$z-x$ 在 Y 的值域内" 的项非零。忘掉 Y 的支撑集限制会多算；**用 Y 的支撑集限制 x 的取值范围**（两枚骰子之和：$z=2$ 只有 $x=1$；$z=7$ 有 $x=1,\dots,6$）。
7. **以为 p 不同也能合并二项分布。** $\mathbf{Bin}(n,p)+\mathbf{Bin}(m,q)=\mathbf{Bin}(n+m,\cdot)$ 只在 $p=q$ 时成立。$p\neq q$ 时 $X+Y$ 甚至不是二项分布（见定理 21.4 后的反例）。同理，泊松的 λ 可以不同（结论照样成立），但二项的 p 不行——**这两条不要记混**。
8. **把 $\mathbb{E}[S_n^2]=n$ 误读为"$\mathbb{E}[|S_n|]=\sqrt{n}$"。** 由 Jensen 只有 $\mathbb{E}[|S_n|]\le\sqrt{n}$（$n=4$：$\mathbf{1.5}$ vs $\mathbf{2.0}$）。平方根是凹的，期望不能穿过凹函数。
9. **用"两两独立"代替"相互独立"。** 多变量时，"对每个二元子集分解"**弱于**"对每个子集分解"。做 n 个变量之和的方差（定理 21.8）时，归纳步骤要求"前 $n-1$ 项之和 与 X_n 独立"，这条**仅靠两两独立是不够的**（实际上对和与单个变量独立而言两两独立确实不够，需要更强的条件）。
10. **忘记条件概率的"分母为零"情形。** 在 $\Pr[X=a\mid Y=b]=\Pr[X=a]$ 这个刻画里，必须限定 $\Pr[Y=b]>0$；否则条件概率本身没有定义。定理 21.2 的证明中已明确写出这一限定。

11. **把"随机变量之和的分布"与"随机变量之和"当成同一个对象。** 定理 21.7（方差可加）讨论的是 $\mathbf{Var}(X+Y)$，而定理 21.3（卷积）讨论的是 $X+Y$ 的**分布**。前者只需二阶矩，后者要完整 PMF。**问题问什么，就用什么工具。**

思考题（带答案）

Q1.（计算题） 下面的两张联合分布表都有相同的边缘分布。请填出两张表的边缘分布，验证它们相同，并分别计算 $\mathbb{E}[XY]$、$\mathbf{Cov}(X,Y)$，指出哪一张是独立的。

表 A	$Y=0$	$Y=1$		表 B	$Y=0$	$Y=1$
$X=0$	0.1	0.2		$X=0$	0.2	0.1
$X=1$	0.4	0.3		$X=1$	0.3	0.4

▸ 答案

边缘分布：

- 表 A：行和 $p_X(0)=0.1+0.2=0.3$，$p_X(1)=0.4+0.3=0.7$；列和 $p_Y(0)=0.1+0.4=0.5$，$p_Y(1)=0.2+0.3=0.5$。
- 表 B：行和 $p_X(0)=0.2+0.1=0.3$，$p_X(1)=0.3+0.4=0.7$；列和 $p_Y(0)=0.2+0.3=0.5$，$p_Y(1)=0.1+0.4=0.5$。

两张表的边缘分布完全相同：$p_X=(0.3,0.7)$、$p_Y=(0.5,0.5)$ ✔（脚本验算）。

期望与协方差（脚本验算）：

	$\mathbb{E}[X]$	$\mathbb{E}[Y]$	$\mathbb{E}[XY]$	$\mathbb{E}[X]\mathbb{E}[Y]$	$\mathbf{Cov}$
表 A	0.7	0.5	$0.1\cdot0\cdot0+0.2\cdot0\cdot1+0.4\cdot1\cdot0+0.3\cdot1\cdot1=0.30$	0.35	-0.05
表 B	0.7	0.5	$0.2\cdot0+0.1\cdot0+0.3\cdot0+0.4\cdot1=0.40$	0.35	$+0.05$

独立性判定（逐格比较 $p_{X,Y}$ 与行和 × 列和，行和×列和均为 $0.3\times0.5=0.15$ 或 $0.7\times0.5=0.35$）：

- 表 A：格子 $(0,0)$ 是 0.1，而 $0.3\times0.5=0.15\neq0.1$ ✗ → **不独立**（且 $\mathbf{Cov}<0$，负相关）。
- 表 B：格子 $(0,0)$ 是 0.2，而 $0.15\neq0.2$ ✗ → **也不独立**（且 $\mathbf{Cov}>0$，正相关）。

两张表都不独立！ 若要有独立的例子，须取 $0.15/0.15/0.35/0.35$（此时每格都等于行和×列和）。本小题的要点是：**同样的边缘分布 $(0.3,0.7)$ 与 $(0.5,0.5)$，可以配出至少三种完全不同的联合分布（协方差 -0.05、$+0.05$、0）**，这就是"边缘不能还原联合"的定量演示。

Q2.（计算题） 设 $X\sim\mathbf{Pois}(2)$ 与 $Y\sim\mathbf{Pois}(3)$ 独立，$Z=X+Y$。求 $\Pr[Z=3]$（分别用卷积公式与 $\mathbf{Pois}(5)$ 公式算，验证一致）、$\mathbb{E}[Z]$、$\mathbf{Var}(Z)$。

▸ 答案

用卷积公式（定理 21.3）：

$$\Pr[Z=3]=\sum_{j=0}^{3}\frac{2^j}{j!}e^{-2}\cdot\frac{3^{3-j}}{(3-j)!}e^{-3}=e^{-5}\sum_{j=0}^{3}\frac{2^j3^{3-j}}{j!(3-j)!}.$$

逐项计算：

j	2^j	3^{3-j}	$j!$	$(3-j)!$	项值 $=2^j3^{3-j}/(j!(3-j)!)$
0	1	27	1	6	$27/6=4.5$
1	2	9	1	2	$18/2=9$
2	4	3	2	1	$12/2=6$
3	8	1	6	1	$8/6\approx1.3333$

和为 $4.5+9+6+1.3333=20.8333=125/6$。故

$$\Pr[Z=3]=e^{-5}\cdot\frac{125}{6}=\frac{125}{6e^5}.$$

数值：$e^{-5}=0.006737947$，$125/6=20.833333$，乘积 $=0.140373895$。

用 $\mathbf{Pois}(5)$ 公式（定理 21.5 保证 $Z\sim\mathbf{Pois}(5)$）：

$$\Pr[Z=3]=\frac{5^3}{3!}e^{-5}=\frac{125}{6}e^{-5}=0.140373895.$$

两者完全一致 ✔（脚本验算：$\mathbf{Pois}(1.5)+\mathbf{Pois}(2.5)=\mathbf{Pois}(4)$ 的表格也逐项吻合）。

期望与方差：$\mathbb{E}[Z]=\lambda_1+\lambda_2=2+3=5$；$\mathbf{Var}(Z)=5$（泊松分布的方差等于其参数，Lecture 19 结论）。也可分开验：$\mathbf{Var}(X)+\mathbf{Var}(Y)=2+3=5$，与定理 21.7 一致 ✔。

验证卷积的数值：$j=0$ 到 3 的项相加得 20.8333；也可以直接算 $e^{-5}\sum_j\frac{\binom{3}{j}2^j3^{3-j}}{3!}\cdot\frac{3!}{j!(3-j)!}$… 更简洁的是注意到 $\sum_{j=0}^{3}\frac{2^j3^{3-j}}{j!(3-j)!}=\frac{1}{3!}\sum_j\binom{3}{j}2^j3^{3-j}=\frac{(2+3)^3}{6}=\frac{125}{6}$ —— 这正是定理 21.5 证明中"凑二项式定理"的那一步。

Q3.（概念/证明题） (a) 设 X, Y 独立。证明：对任意函数 g, h，$g(X)$ 与 $h(Y)$ 也独立。

(b) 举出三个随机变量 X, Y, Z，使它们**两两独立**但**不相互独立**；并说明这为什么意味着"两两独立"不能替代"相互独立"。

> ▸ **答案**
>
> **(a)** 设 u, v 为任意实数。需要证明 $\Pr[g(X)=u,\ h(Y)=v] = \Pr[g(X)=u]\Pr[h(Y)=v]$。
>
> - 第一步：把事件写成原像：
>
> $$\{g(X)=u\} = \{X \in g^{-1}(u)\} = \bigsqcup_{x:\, g(x)=u} \{X=x\}, \qquad \{h(Y)=v\} = \bigsqcup_{y:\, h(y)=v} \{Y=y\}.$$
>
> - 第二步：两个事件取交，得到
>
> $$\{g(X)=u,\ h(Y)=v\} = \bigsqcup_{x:\, g(x)=u}\ \bigsqcup_{y:\, h(y)=v} \{X=x,\ Y=y\}.$$
>
> - 第三步：用可加性 + 独立性（**只在这一步用独立**）：
>
> $$\Pr[g(X)=u, h(Y)=v] = \sum_{x:g(x)=u}\ \sum_{y:h(y)=v} \Pr[X=x]\Pr[Y=y].$$
>
> - 第四步：分离双重求和（可分离性，与 Lecture 20 定理 20.7 第三步同招）：
>
> $$= \Big(\sum_{x:g(x)=u} \Pr[X=x]\Big)\Big(\sum_{y:h(y)=v} \Pr[Y=y]\Big) = \Pr[g(X)=u]\Pr[h(Y)=v]. \qquad \blacksquare$$
>
> **注**：这条结论非常实用——它说明独立性对**函数变换封闭**，因此 $\mathbb{E}[X^2Y^2] = \mathbb{E}[X^2]\mathbb{E}[Y^2]$（Lecture 20 思考题 Q2(b)），以及"X 与 Y 独立 $\Rightarrow e^{tX}$ 与 e^{tY} 独立"（Lecture 25 矩母函数的基石）。
>
> **(b) 经典构造**：抛**两枚独立公平硬币**，记结果为 $A, B \in \{0,1\}$（$0=$ 反、$1=$ 正），定义
>
> $$X = A, \qquad Y = B, \qquad Z = A \oplus B \quad (\text{异或，即模 } 2 \text{ 加}).$$
>
> - X 与 Y **独立**：由构造直接成立（两枚独立硬币）。
> - X 与 Z **独立**：逐值检查。X 均匀于 $\{0,1\}$，Z 也均匀于 $\{0,1\}$（因为 $A \oplus B$ 在四种等概率结果中取 0 两次、取 1 两次）。四个格子：
> $\Pr[X=0, Z=0] = \Pr[A=0, B=0] = 1/4$，而 $\Pr[X=0]\Pr[Z=0] = \frac{1}{2}\cdot\frac{1}{2} = \frac{1}{4}$ ✔；
> $\Pr[X=0, Z=1] = \Pr[A=0, B=1] = 1/4 = \frac{1}{2}\cdot\frac{1}{2}$ ✔；其余两格同理 ✔。**独立。**
> - Y 与 Z **独立**：由对称性同理 ✔。
> - X, Y, Z **不相互独立**：看三元事件 $\{X=0, Y=0, Z=1\}$。它要求 $A=0, B=0$ 同时 $A \oplus B = 1$，即 $0 \oplus 0 = 1$，矛盾，故概率为 0。而 $\Pr[X=0]\Pr[Y=0]\Pr[Z=1] = \frac{1}{2}\cdot\frac{1}{2}\cdot\frac{1}{2} = \frac{1}{8} \neq 0$ ✘。**不相互独立。**
>
> **为什么重要**：定理 21.8（n 个变量之和的方差可加）的归纳步骤需要"前 $n-1$ 项之和 与 X_n 独立"。在两两独立但非相互独立的情形下，这个条件可能失效——例如上例中 $X+Y$ 与 Z **不独立**（事实上 Z 由 X, Y 完全决定，$X+Y+Z$ 恒为偶数），若把三个变量当成独立来算方差，会得到错误答案。**做多变量问题时，"相互独立"是你要书面确认的假设。**

Q4.（概念题） 一张 2×2 的联合分布表中，如果**只有一列**满足 $\Pr[X=a \mid Y=b] = \Pr[X=a]$（即只有一个 b 满足），能否据此断定独立？

(a) 从"行和归一性"角度说明：在 X 二值时，"恰好只有一列满足"这种情形**根本不可能存在**。

(b) 请给出一个 2×3 表的例子，其中**整整一列**满足条件、另外两列都不满足，并逐格验证它不独立。

▸ 答案

答：不能据此断定独立。

(a) 2×2（以及一切 X 二值的表）的关键约束：设 $X\in\{0,1\}$，记 $\pi=\Pr[X=1]$、$c_b=\Pr[Y=b]$、$q_b=\Pr[X=1\mid Y=b]$（限定 $c_b>0$）。由全概率公式与边缘化（定理 21.1），

$$\pi=\sum_b q_b\,c_b,\qquad \sum_b c_b=1.$$

若"只有 b^* 这一列不满足"，即 $q_b=\pi$ 对所有 $b\neq b^*$ 成立，代入得

$$\pi=\pi\Big(\sum_{b\neq b^*}c_b\Big)+q_{b^*}c_{b^*}=\pi(1-c_{b^*})+q_{b^*}c_{b^*}\implies q_{b^*}c_{b^*}=\pi c_{b^*}\implies q_{b^*}=\pi.$$

最后一步因 $c_{b^*}>0$ 可约。**故最后一列被迫满足。** 逻辑上这是"加权平均等于 π，而除一项外的所有项都等于 π ⇒ 剩下一项也必须等于 π"。

用 2×2 的具体数字看：$c=0.5$、$\pi=0.6$，若 $q_0=0.6$，则 $0.6=0.6\times 0.5+q_1\times 0.5$，解出 $q_1=0.6$ ✔。**没有自由度留给"只错一列"。**

(b) 2×3 反例（整列满足、另两列不满足）：

$X\backslash Y$	0	1	2	行和 p_X
0	0.10	0.05	0.25	0.40
1	0.15	0.20	0.25	0.60
列和 p_Y	0.25	0.25	0.50	1.00

条件概率检查（$\pi=\Pr[X=1]=0.60$）：

列 b	$p_{X,Y}(1,b)$	$c_b=p_Y(b)$	$q_b=p_{X,Y}(1,b)/c_b$	与 $\pi=0.60$ 比较
0	0.15	0.25	0.60	✔ 满足
1	0.20	0.25	0.80	✘ 不满足
2	0.25	0.50	0.50	✘ 不满足

正好是"**一列满足、两列不满足**"，与 (a) 的结论一致（$|B|=3$ 时才有这个空间）。

逐格验证（行和 × 列和）：$0.40\times 0.25=0.10$、$0.40\times 0.25=0.10$、$0.40\times 0.50=0.20$、$0.60\times 0.25=0.15$、$0.60\times 0.25=0.15$、$0.60\times 0.50=0.30$。对照实际值：

- $(0,0)$：$0.10=0.10$ ✔
- $(0,1)$：$0.05\neq 0.10$ ✘
- $(0,2)$：$0.25\neq 0.20$ ✘
- $(1,0)$：$0.15=0.15$ ✔
- $(1,1)$：$0.20\neq 0.15$ ✘
- $(1,2)$：$0.25\neq 0.30$ ✘

第 0 列的两个格子都对（独立），另两列的四个格子都错 ⇒ 不独立。 这也印证了"一个（或一整列）格子相等推不出独立"。

脚本验算：$\mathbb{E}[X]=0.60$、$\mathbb{E}[Y]=1.25$、$\mathbb{E}[XY]=0.70$、$\mathbb{E}[X]\mathbb{E}[Y]=0.75$，$\mathrm{Cov}=-0.05\neq 0$ —— 确认不独立 ✔。

(c) 两边都至少三值的最简反例（每格都不对，更"彻底"）：

$X\backslash Y$	0	1	行和
0	0.20	0.05	0.25
1	0.10	0.30	0.40
2	0.10	0.25	0.35
列和	0.40	0.60	1.00

期望的乘积为 $0.25\times 0.40=0.10$、$0.25\times 0.60=0.15$、$0.40\times 0.40=0.16$、$0.40\times 0.60=0.24$、$0.35\times 0.40=0.14$、$0.35\times 0.60=0.21$，与实际值 $0.20/0.05/0.10/0.30/0.10/0.25$ **全部不等** ⇒ 不独立。脚本验算：$\mathbb{E}[X]=1.10$、$\mathbb{E}[Y]=0.60$、$\mathbb{E}[XY]=0.80$、$\mathbb{E}[X]\mathbb{E}[Y]=0.66$，$\mathrm{Cov}=+0.14\neq 0$ ✔。

结论与正确的省力规则：定理 21.2 的条件"对所有 (a,b)"有一条**内在冗余**：

- 若**除一列以外的所有列**都满足 $q_b=\pi$，则剩下那列被归一性强行带动（见 (a) 的推导）。
- 因此偏差**至少出现在两个格子上**；只有当 $|A|,|B|\geq 3$ 时才能构造出"多列同时偏离"的完整反例。

正确的省力规则：验证独立性时，可以先检查 $|B|-1$ 列，最后一列可以省掉（因为它自动成立）。**但前提是你已经确信其余列全部通过**——顺序不能颠倒。求稳的做法：直接算行和与列和，逐格对照，永不失手。

Lecture 22: Variance & Covariance（方差与协方差）

概述

L20 我们学会了**期望 (Expectation)**，并反复使用它的**线性性 (Linearity of Expectation)**：无论随机变量是否独立，$\mathbb{E}[X+Y]=\mathbb{E}[X]+\mathbb{E}[Y]$ 总成立。但期望只回答"分布的重心在哪"，对"分布有多散"一言不发。本讲补上第二个数字特征——**方差 (Variance)**，它度量随机变量到均值的平均平方距离；再补上第三个——**协方差 (Covariance)**，它度量两个随机变量同向/反向变化的程度。

本讲的核心技术是：把"到均值的平方距离"展开、用期望线性性逐项处理。这条工具链会给出一个关键结论——**独立随机变量之和的方差等于方差之和**。请特别留意它与 L20 的对照：期望的可加性**不需要**独立，方差的可加性**需要**独立。这是本讲最重要的教学点，也是概率论里最常被误用的一条。

方差还是下一讲 L23 的燃料：切比雪夫不等式、弱大数定律都要靠 $\mathbf{Var}$ 才能写出来；而"独立和的方差线性增长、标准差只按 $\sqrt{n}$ 增长"这一事实，正是"分布向均值集中"的最初迹象。

核心概念的直观解释

概念一：为什么期望不够——"重心"与"散度"是两个独立的信息

- **定义（问题陈述）**：设 X 是随机变量。$\mathbb{E}[X]$ 只给出分布的**位置 (location)**，不给出**尺度/散布 (spread)**。
- **直观解释（"它是什么意思？"）**：两个人平均月薪都是 1 万元，但一个人每月固定 1 万，另一个人 11 个月拿 0 元、12 月拿 12 万——平均一样，风险完全不同。金融、算法分析、物理里都关心"波动有多大"，而不只是"平均水平是多少"。**期望是分布的重心（平衡点），方差是分布的转动惯量（对波动的抵抗力）。**
- **具体示例（必须用分布表对比）**：

取值 x	$\Pr[X=x]$	$\Pr[Y=x]$
0	1	$1/2$
$+100$	0	$1/4$
-100	0	$1/4$

X 是"恒为 0"的退化变量（确定型），Y 是"以 $1/2$ 概率取 ± 100"的变量（脚本验算）：

$$\mathbb{E}[X]=0, \qquad \mathbb{E}[Y]=\tfrac{1}{2}(100)+\tfrac{1}{2}(-100)=0.$$

两者期望完全相同（都是 0），但分布天差地别：X 永远不动，Y 有一半时间跑到 ± 100。如果只报告"期望为 0"，你完全无法区分这两种情况。再看一例：Z 以 $1/2$ 取 ± 1，也有 $\mathbb{E}[Z]=0$，但"波动"明显比 Y 小两个数量级。所以我们需要一个把"偏离均值多少"量化出来的数字。

同一个均值 0 下的三种"形状"（柱状图：柱子长度正比于取值概率）：

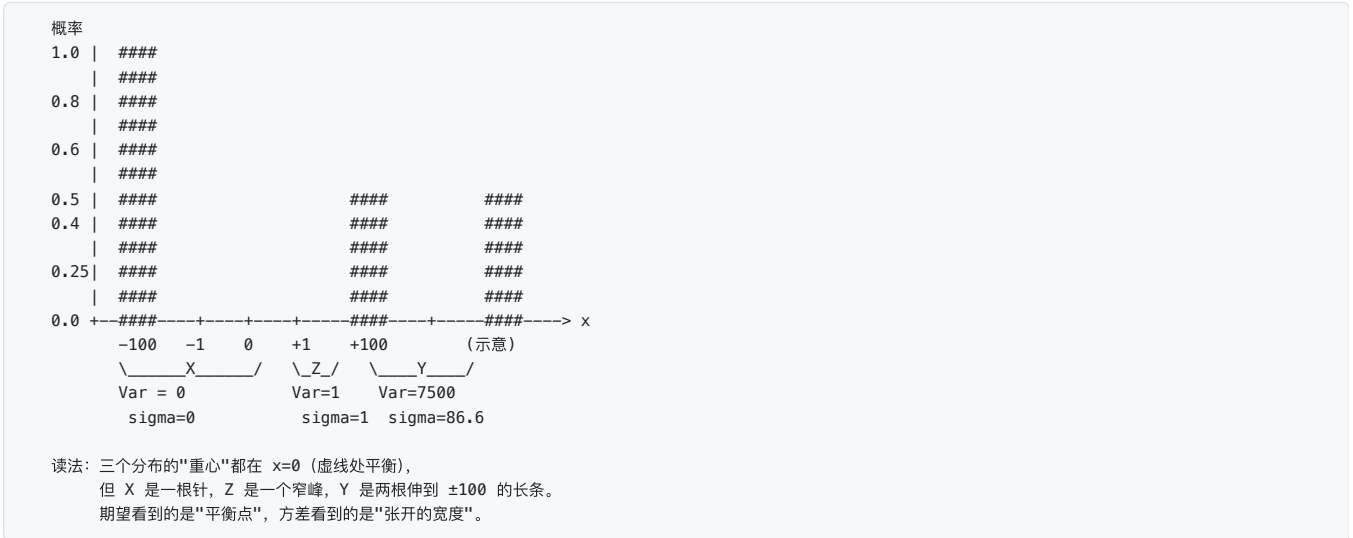

方差按定义算出的三个值（$\mathbf{0}$、$\mathbf{1}$、$\mathbf{7500}$）恰好把"针 / 窄峰 / 长条"这三种形状严格区分开了。

概念二：方差 (Variance)

- **定义**：设随机变量 X 的期望为 $\mu=\mathbb{E}[X]$，则

$$\mathbf{Var}(X)=\mathbb{E}\left[(X-\mu)^2\right].$$

等价地（定理 22.1）$\mathbf{Var}(X)=\mathbb{E}[X^2]-\mu^2=\mathbb{E}[X^2]-(\mathbb{E}[X])^2$。 – **直观解释**："到均值的**平均平方距离**"。先算每个取值离均值多远（$X-\mu$），平方掉正负号，再按概率加权平均。为什么平方而不用绝对值 $|X-\mu|$？三个理由： 1. **可微**：x^2 处处可导，$|x|$ 在 0 处有尖角，后面做优化（例如 L25 的最小二乘/CLT 的矩计算）时会碍事； 2. **与内积结构一致**：$\mathbb{E}[XY]$ 是随机变量空间上的内积，平方距离 $\mathbb{E}[(X-Y)^2]$ 就是内积诱导的范数平方，于是协方差、相关系数、Cauchy–

Schwarz 全都自然出现； 3. **代数可展开**：$(X-\mu)^2 = X^2 - 2\mu X + \mu^2$，能直接用期望线性性逐项拆开，而 $|X-\mu|$ 不能。 – **具体示例**：上面的分布表。对 X（恒为 0）：$\mathbf{Var}(X) = \mathbb{E}[(0-0)^2] = 0$。对 Y：

$$\mathbf{Var}(Y) = \tfrac{1}{2}(100-0)^2 + \tfrac{1}{4}(-100-0)^2 + \tfrac{1}{4}(0-0)^2 = \tfrac{1}{2}\cdot 10000 + \tfrac{1}{4}\cdot 10000 + \tfrac{1}{4}\cdot 0 = 7500.$$

对 Z（± 1 各 $1/2$）：$\mathbf{Var}(Z) = 1$。三个变量期望都是 0，方差依次为 $0, 1, 7500$——方差成功地区分了它们。

概念三：标准差 (Standard Deviation)

- **定义**：$\sigma(X) = \sqrt{\mathbf{Var}(X)}$。注意 $\sigma \geq 0$。
- **直观解释（"它是什么意思？"）**：方差把量纲平方了。若 X 的单位是"米"，则 $\mathbf{Var}(X)$ 的单位是"平方米"，说"波动的平方米是 7500"很别扭。**开平方后方差的单位回到"米"，与 X 同量纲，可以直接和 X 的数值比较**——这正是不等式 $\mathbb{E}[|S_n|] \leq \sqrt{\mathbb{E}[S_n^2]}$ 那类"把平方距离翻译回距离"的做法的动机。
- **具体示例**：上例中 $\sigma(Y) = \sqrt{7500} \approx 86.6$。这意味着 Y 的典型偏离在 ± 86.6 量级——比 ± 100 略小（因为有时取 0）。而 $\sigma(Z) = 1$，$\sigma(X) = 0$。
- **命名记号**：本笔记统一用 $\mu_X = \mathbb{E}[X]$、$\sigma_X = \sigma(X) = \sqrt{\mathbf{Var}(X)}$。当只有一个变量时简写为 μ, σ。

概念四：协方差 (Covariance)

- **定义**：$\mathbf{Cov}(X,Y) = \mathbb{E}\left[(X-\mu_X)(Y-\mu_Y)\right] = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y]$。
- **直观解释（"它是什么意思？"）**：把两个变量各自的"偏离量"乘起来。若 X 偏大时 Y 也倾向偏大，则 $(X-\mu_X)(Y-\mu_Y)$ 多为正，期望为正；若 X 偏大时 Y 倾向偏小（"跷跷板关系"），乘积多为负，协方差为负；若两者没有系统的同向/反向关系，正负项互相抵消，协方差接近 0。**协方差就是"同向变化"的量化。**
- **具体示例**：设 X 均匀取 $\{-1, 0, 1\}$，令 $Y = X$。则同向完全同步，$\mathbf{Cov}(X,X) = \mathbf{Var}(X) = 2/3 > 0$（脚本验算：$\mathbb{E}[X] = 0$，$\mathbb{E}[X^2] = 2/3$）。再令 $Y = -X$，则 $\mathbf{Cov}(X,-X) = -2/3 < 0$。最后令 $Y = X^2$，我们会精确算出 $\mathbf{Cov}(X,Y) = 0$——尽管 Y 由 X 完全决定！这个反例是本讲的重点，见后文。

概念五：相关系数 (Correlation)

- **定义**：$\rho_{X,Y} = \mathbf{Corr}(X,Y) = \dfrac{\mathbf{Cov}(X,Y)}{\sigma_X \sigma_Y}$（要求 $\sigma_X > 0, \sigma_Y > 0$）。
- **直观解释**：协方差受量纲影响——把 X 的单位从"米"换成"厘米"，协方差放大 100 倍，但"关联强度"根本没变。除以两个标准差正好把量纲消掉，得到一个**无量纲的、恒在 $[-1,1]$ 内的数**。它度量的是两个变量的**线性 (linear)** 关联程度，不是任意关联程度。

完整证明与推导（核心）

一、方差的两种形式等价

定理 22.1（方差的计算公式）：对任意随机变量 X（期望存在），记 $\mu = \mathbb{E}[X]$，则

$$\mathbf{Var}(X) = \mathbb{E}\left[(X-\mu)^2\right] = \mathbb{E}[X^2] - \mu^2.$$

证明策略：**直接证明 + 代数展开**。这是最典型的"展开平方、用期望线性性逐项处理"的套路。之所以能把期望"拆进去"，是因为 μ 是**常数**（不是随机变量），所以 $\mathbb{E}[\mu X] = \mu\mathbb{E}[X]$、$\mathbb{E}[\mu^2] = \mu^2$ 都对。

逐步推导：

1. 从定义出发：$\mathbf{Var}(X) = \mathbb{E}\left[(X-\mu)^2\right]$。（依据：定义）
2. 展开括号内的平方：$(X-\mu)^2 = X^2 - 2\mu X + \mu^2$。（依据：代数恒等式）
3. 代入并利用期望线性性拆成三项：

$$\mathbf{Var}(X) = \mathbb{E}\left[X^2 - 2\mu X + \mu^2\right] = \mathbb{E}[X^2] - 2\mu\,\mathbb{E}[X] + \mathbb{E}[\mu^2].$$

（依据：期望线性性 $\mathbb{E}[aU + bV + c] = a\mathbb{E}[U] + b\mathbb{E}[V] + c$） 4. 处理后两项。因为 μ 是常数：$\mathbb{E}[\mu X] = \mu\mathbb{E}[X]$，且 $\mathbb{E}[\mu^2] = \mu^2$。又 $\mathbb{E}[X] = \mu$，故 $-2\mu\mathbb{E}[X] = -2\mu^2$，于是

$$\mathbf{Var}(X) = \mathbb{E}[X^2] - 2\mu^2 + \mu^2.$$

1. 合并：$\mathbf{Var}(X) = \mathbb{E}[X^2] - \mu^2 = \mathbb{E}[X^2] - (\mathbb{E}[X])^2$。$\blacksquare$

【证明机制解说】：整个证明的"灵光一现"只有一处——**注意到 μ 是常数**。一旦把 μ 当成常数而不是随机变量，期望线性性就可以毫无顾虑地穿过它，三项分别处理。这也是本讲所有方差/协方差代数运算的通用套路：**凡是只含单个变量的期望的表达式，全部当常数处理。**

两种形式的取舍：定义形式 $\mathbb{E}[(X-\mu)^2]$ 直观但要在知道 μ 之后再算一遍加权和；公式形式 $\mathbb{E}[X^2] - \mu^2$ 只需算两个原始矩 $\mathbb{E}[X]$ 与 $\mathbb{E}[X^2]$。**注意高频错误：$\mathbb{E}[X^2]$ 与 $(\mathbb{E}[X])^2$ 完全不同**——例如 $X \sim \mathbf{Ber}(1/2)$ 时 $\mathbb{E}[X^2] = 1/2$ 而 $(\mathbb{E}[X])^2 = 1/4$。

二、方差非负，且为 0 当且仅当变量几乎必然为常数

定理 22.2（方差为零的刻画）：对任意随机变量 X，$\mathbf{Var}(X) \geq 0$；且 $\mathbf{Var}(X) = 0$ 当且仅当存在常数 c 使得 $\Pr[X = c] = 1$。

证明策略：**直接证明 + 非负项求和**。关键观察是：$(X(\omega)-\mu)^2$ 对**每一个**样本点 ω 都 ≥ 0，而期望是这些非负数以非负概率 $P(\omega)$ 加权求和，故必然 ≥ 0。至于反向，"加权非负数之和为 0"意味着每个正项前面的权重必须是 0。

逐步推导：

1. 对任意 $\omega \in \Omega$，实数的平方非负，故 $(X(\omega)-\mu)^2 \geq 0$。

2. 期望的定义是 $\mathbb{E}[(X-\mu)^2] = \sum_{\omega\in\Omega}(X(\omega)-\mu)^2\,P(\omega)$。这是**有限个（或可数个）非负项乘非负权重之和**，故 ≥ 0。这就证明了 $\mathbf{Var}(X)\geq 0$。（依据：定义 + 每项非负）
3. 反向（⇐）：若 $\Pr[X=c]=1$，则 $\mu=\mathbb{E}[X]=c$，于是对每个 ω 都有 $(X(\omega)-c)^2=0$（在概率为 1 的集合上），故 $\mathbf{Var}(X)=0$。
4. 反向（⇒）：设 $\mathbf{Var}(X)=0$。第 2 步的和式中每项 $(X(\omega)-\mu)^2P(\omega)\geq 0$，总和为 0 迫使每一项都为 0。因此对每个满足 $P(\omega)>0$ 的 ω，都有 $(X(\omega)-\mu)^2=0$，即 $X(\omega)=\mu$。也就是说，概率为 1 的集合上 X 恒等于 μ，取 $c=\mu$ 即得。■

【证明机制解说】：这条定理看似"显然"，但它的证明模式非常重要——**"非负随机变量期望为 0 ⟹ 该随机变量几乎必然为 0"**。这个模式在后面反复出现：它是 Markov 不等式的基础，也是证明"两个随机变量几乎必然相等"（比如 $\mathbf{Corr}=1$ 时 $Y=aX+b$）的标准手法。

术语说明："几乎必然 (almost surely / with probability 1)"表示命题在一个概率为 1 的集合上成立，允许在一个概率为 0 的集合上失效。CS70 的样本空间通常有限，此时"$\Pr[X=c]=1$"就等价于"所有正概率的样本点都取 c"。

三、缩放与平移：$\mathbf{Var}(cX)=c^2\,\mathbf{Var}(X)$ 与 $\mathbf{Var}(X+c)=\mathbf{Var}(X)$

定理 22.3（方差的缩放与平移法则）：对任意随机变量 X 与常数 $a,b\in\mathbb{R}$，

$$\mathbf{Var}(aX+b)=a^2\,\mathbf{Var}(X).$$

特别地：$\mathbf{Var}(cX)=c^2\,\mathbf{Var}(X)$（**注意平方，不是 c**）与 $\mathbf{Var}(X+b)=\mathbf{Var}(X)$（平移不变）。

证明策略：**直接证明 + 定理 22.1 的公式形式**。想法是：先算出 $aX+b$ 的期望，再用 $\mathbb{E}[(aX+b)^2]-(\mathbb{E}[aX+b])^2$ 展开。选择公式形式而非定义形式，是因为 $aX+b$ 的分布要在知道 X 分布之后才能写出来，而公式形式只需要两个矩。

逐步推导：

1. 由期望线性性，$\mu_{aX+b}=\mathbb{E}[aX+b]=a\mathbb{E}[X]+b=a\mu_X+b$。（依据：期望线性性；注意 a,b 是常数，方向与缩放无关）
2. 计算二阶矩：

$$\mathbb{E}\left[(aX+b)^2\right]=\mathbb{E}\left[a^2X^2+2abX+b^2\right]=a^2\mathbb{E}[X^2]+2ab\,\mathbb{E}[X]+b^2.$$

（依据：代数展开 + 期望线性性） 3. 代入 $\mathbf{Var}(aX+b)=\mathbb{E}\left[(aX+b)^2\right]-(\mathbb{E}[aX+b])^2$：

$$\mathbf{Var}(aX+b)=a^2\mathbb{E}[X^2]+2ab\mu_X+b^2-(a\mu_X+b)^2.$$

1. 展开右边括号：$(a\mu_X+b)^2=a^2\mu_X^2+2ab\mu_X+b^2$。
2. 相减，$2ab\mu_X$ 与 b^2 恰好抵消：

$$\mathbf{Var}(aX+b)=a^2\mathbb{E}[X^2]-a^2\mu_X^2=a^2\left(\mathbb{E}[X^2]-\mu_X^2\right)=a^2\,\mathbf{Var}(X).\ \blacksquare$$

1. 取 $b=0$ 得 $\mathbf{Var}(cX)=c^2\,\mathbf{Var}(X)$；取 $a=1$ 得 $\mathbf{Var}(X+b)=\mathbf{Var}(X)$。

【证明机制解说】：这里最妙的不是代数，而是**抵消的必然性**。平移 $+b$ 把整个分布搬走，各点到新均值的距离当然不变；缩放 $\times a$ 把每个偏离量放大 $|a|$ 倍，平方后就是 a^2 倍。所以 $\mathbf{Var}$ 对平移"免疫"、对缩放"平方响应"，这两条其实可以先由直觉猜出来，再用代数验证。

反例（高频错误必须亲眼看到）：$\mathbf{Var}(cX)\neq c\,\mathbf{Var}(X)$——**除非 $c\in\{0,1\}$**。脚本验算：X 为公平骰子点数，$\mathbf{Var}(X)=35/12\approx 2.9167$。取 $c=3$：正确的 $\mathbf{Var}(3X)=9\cdot 2.9167=26.25$，而错误的 $3\cdot 2.9167=8.75$ 差了三倍。直觉上：把分布拉宽 3 倍，波动不是变 3 倍，而是（按平方度量）变 9 倍；按标准差度量才是变 3 倍（$\sigma(3X)=3\sigma(X)$，**标准差是"线性缩放"的，方差是"平方缩放"的**）。

四、独立随机变量之积的期望（引理）

定理 22.4（独立变量的乘积期望）：若 X,Y 独立，则 $\mathbb{E}[XY]=\mathbb{E}[X]\,\mathbb{E}[Y]$。

证明策略：**直接证明 + 二重和拆项（分离变量）**。独立性的定义就是 $\Pr[X=a,Y=b]=\Pr[X=a]\Pr[Y=b]$，把这个等式代进 $\mathbb{E}[XY]$ 的联合和式，再把二重和因式分解成两个单重和之积。

逐步推导：

1. 由期望的定义（对联合分布求和）：

$$\mathbb{E}[XY]=\sum_a\sum_b ab\,\Pr[X=a,Y=b].$$

（依据：LOTUS 的两变量版本，或 $\mathbb{E}[XY]$ 的联合定义——见 L21） 2. 用独立性把联合概率换成乘积：$\Pr[X=a,Y=b]=\Pr[X=a]\Pr[Y=b]$。这是**整个证明唯一用到独立性的地方**。 3. 于是

$$\mathbb{E}[XY]=\sum_a\sum_b ab\,\Pr[X=a]\Pr[Y=b].$$

1. **分离变量**：$ab\,\Pr[X=a]\Pr[Y=b]=\big(a\Pr[X=a]\big)\big(b\Pr[Y=b]\big)$。注意这是"关于 a 的因子"乘"关于 b 的因子"，所以二重和可以拆成两个单重和的乘积：

$$\mathbb{E}[XY]=\left(\sum_a a\,\Pr[X=a]\right)\left(\sum_b b\,\Pr[Y=b]\right)=\mathbb{E}[X]\,\mathbb{E}[Y].\ \blacksquare$$

【证明机制解说】：关键一步是**因式分解**。二重和 $\sum_a\sum_b f(a)g(b)$ 只有在被加项能完整拆成"只含 a"与"只含 b"两部分之积时才能分离；而独立性恰好提供了这个拆分。一旦不独立，$\Pr[X=a,Y=b]$ 里 a 与 b 纠缠在一起，因式分解就崩了——**这就是"方差可加需要独立"的根源**。

反例（条件不可省）：取 $X \sim \mathrm{Ber}(1/2)$，$Y = X$（完全不独立）。则 $\mathbb{E}[XY] = \mathbb{E}[X^2] = \mathbb{E}[X] = 1/2$，而 $\mathbb{E}[X]\mathbb{E}[Y] = 1/4$。两者不等。这就是官方 Note 强调的一点：$X$ 与 X 不独立，所以 $\mathbb{E}[X^2] \neq (\mathbb{E}[X])^2$。

五、独立随机变量之和的方差可加

定理 22.5（方差的可加性）：若 X, Y 独立，则

$$\mathrm{Var}(X+Y) = \mathrm{Var}(X) + \mathrm{Var}(Y).$$

证明策略：**直接证明 + 公式形式 + 定理 22.4**。展开 $\mathbb{E}[(X+Y)^2] - (\mathbb{E}[X+Y])^2$，把交叉项 $2(\mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y])$ 单独拎出来，再用独立性把它判为 0。

逐步推导：

1. 记 $\mu_X = \mathbb{E}[X]$，$\mu_Y = \mathbb{E}[Y]$。由期望线性性，$\mathbb{E}[X+Y] = \mu_X + \mu_Y$。
2. 用定理 22.1 的公式形式（取 $X+Y$ 为新变量）：

$$\mathrm{Var}(X+Y) = \mathbb{E}\left[(X+Y)^2\right] - \left(\mathbb{E}[X+Y]\right)^2.$$

1. 展开二阶矩：$(X+Y)^2 = X^2 + 2XY + Y^2$，故 $\mathbb{E}[(X+Y)^2] = \mathbb{E}[X^2] + 2\mathbb{E}[XY] + \mathbb{E}[Y^2]$。（依据：期望线性性）
2. 展开均值的平方：$(\mu_X + \mu_Y)^2 = \mu_X^2 + 2\mu_X\mu_Y + \mu_Y^2$。
3. 相减并按变量归组：

$$\mathrm{Var}(X+Y) = \underbrace{\left(\mathbb{E}[X^2] - \mu_X^2\right)}_{=\mathrm{Var}(X)} + \underbrace{\left(\mathbb{E}[Y^2] - \mu_Y^2\right)}_{=\mathrm{Var}(Y)} + \underbrace{2\left(\mathbb{E}[XY] - \mu_X\mu_Y\right)}_{=2\,\mathrm{Cov}(X,Y)}.$$

1. 由独立性（定理 22.4），$\mathbb{E}[XY] = \mu_X\mu_Y$，所以最后一项 $2\,\mathrm{Cov}(X,Y) = 0$。
2. 于是 $\mathrm{Var}(X+Y) = \mathrm{Var}(X) + \mathrm{Var}(Y)$。■

推论 22.5.1（n 个独立变量）：若 $X_1, \ldots, X_n$ 两两独立（或整体独立），则

$$\mathrm{Var}\left(\sum_{i=1}^{n} X_i\right) = \sum_{i=1}^{n} \mathrm{Var}(X_i).$$

特别地，若它们**独立同分布 (i.i.d.)**，则 $\mathrm{Var}\left(\sum X_i\right) = n\,\mathrm{Var}(X_1)$，从而 $\sigma\left(\sum X_i\right) = \sqrt{n}\,\sigma(X_1)$。

【证明机制解说】：整个证明的结构是"展开 → 分组 → 用独立性杀掉交叉项"。请记住第 5 步的分组结果——它其实已经给出了**一般形式的方差公式**（定理 22.9），独立只是让交叉项消失的特例。这就是为什么后文要引入协方差：它把"不独立时的修正量"显式命名出来了。

⚠ **本讲最核心的教学点：期望线性性 vs. 方差可加性的对比**

这两条性质看起来很像，条件却完全不同，混用会直接导致错误答案。

维度	期望	方差
和的可加性	$\mathbb{E}[X+Y] = \mathbb{E}[X] + \mathbb{E}[Y]$	$\mathrm{Var}(X+Y) = \mathrm{Var}(X) + \mathrm{Var}(Y)$
需要独立吗?	**完全不需要**	**需要**（或至少 $\mathrm{Cov}(X,Y)=0$）
一般情形	恒成立	$\mathrm{Var}(X+Y) = \mathrm{Var}(X) + \mathrm{Var}(Y) + 2\,\mathrm{Cov}(X,Y)$
常数缩放	$\mathbb{E}[cX] = c\,\mathbb{E}[X]$（线性）	$\mathrm{Var}(cX) = c^2\,\mathrm{Var}(X)$（平方）
常数平移	$\mathbb{E}[X+c] = \mathbb{E}[X] + c$（会变）	$\mathrm{Var}(X+c) = \mathrm{Var}(X)$（不变）

为什么期望这么"强"？因为期望线性性是**逐项求和**的重新排列，纯粹是分配律，与各项之间的概率关联毫无关系。**为什么方差这么"弱"**？因为方差本质上是**二阶量**，展开后必然出现 XY 这样的交叉项，而交叉项处理不了两个变量一起取值时的相关性。用一句可背的话总结：**"期望永远可加；方差要独立才可加；标准差不满足任何可加性。"**

反例（不独立时方差可加性失效）：取 $X \sim \mathrm{Ber}(1/2)$，$Y = X$，则 $X+Y = 2X$，$\mathrm{Var}(X+Y) = \mathrm{Var}(2X) = 4\,\mathrm{Var}(X) = 4 \cdot 1/4 = 1$。但 $\mathrm{Var}(X) + \mathrm{Var}(Y) = 1/4 + 1/4 = 1/2 \neq 1$。（脚本验算：$\mathbb{E}[(2X)^2] = 4 \cdot 1/2 = 2$，$\mathbb{E}[2X] = 1$，故 $\mathrm{Var} = 2 - 1 = 1$ ✓）注意：这里 $\mathrm{Cov}(X,X) = \mathrm{Var}(X) = 1/4$，代入一般公式得 $1/4 + 1/4 + 2 \cdot 1/4 = 1$，完全吻合。

六、协方差的定义、等价形式与双线性

定理 22.6（协方差两形式等价）：对随机变量 X, Y，

$$\mathrm{Cov}(X,Y) = \mathbb{E}\left[(X - \mu_X)(Y - \mu_Y)\right] = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y].$$

证明策略：与定理 22.1 完全同构——**展开乘积、用期望线性性**。

逐步推导：

1. 从定义出发，展开括号内的乘积：

$$(X - \mu_X)(Y - \mu_Y) = XY - \mu_Y X - \mu_X Y + \mu_X\mu_Y.$$

1. 取期望，对四项分别用线性性（μ_X, μ_Y 是常数）：

$$\mathrm{Cov}(X,Y) = \mathbb{E}[XY] - \mu_Y\mathbb{E}[X] - \mu_X\mathbb{E}[Y] + \mu_X\mu_Y.$$

1. 代入 $\mathbb{E}[X] = \mu_X$、$\mathbb{E}[Y] = \mu_Y$：

$$\mathrm{Cov}(X,Y) = \mathbb{E}[XY] - \mu_Y\mu_X - \mu_X\mu_Y + \mu_X\mu_Y = \mathbb{E}[XY] - \mu_X\mu_Y. \blacksquare$$

推论 22.6.1（三条基本性质）：

1. $\mathrm{Cov}(X,X) = \mathbb{E}[X^2] - \mathbb{E}[X]^2 = \mathrm{Var}(X)$。（把 $Y = X$ 代入）
2. $\mathrm{Cov}(X,Y) = \mathrm{Cov}(Y,X)$。（两形式都是对称的）
3. $\mathrm{Cov}(X,c) = 0$ 对任意常数 c 成立。（$\mathbb{E}[Xc] - \mathbb{E}[X]\mathbb{E}[c] = c\mathbb{E}[X] - c\mathbb{E}[X] = 0$）——**常数与任何变量"不相关"**。

定理 22.7（协方差的双线性 / Bilinearity）：对任意随机变量 $X_1,\dots,X_n$ 与 $Y_1,\dots,Y_m$，以及常数 $a_1,\dots,a_n$ 与 $b_1,\dots,b_m$，

$$\mathrm{Cov}\left(\sum_{i=1}^{n} a_iX_i,\ \sum_{j=1}^{m} b_jY_j\right) = \sum_{i=1}^{n}\sum_{j=1}^{m} a_ib_j\,\mathrm{Cov}(X_i,Y_j).$$

证明策略：**直接证明 + 期望线性性**。注意这里**不需要任何独立性假设**！双线性是协方差最强的代数性质，也是它比方差好用的原因。

逐步推导：

1. 先化简两个线性组合的期望。由期望线性性，$\mathbb{E}\left[\sum_i a_iX_i\right] = \sum_i a_i\mu_{X_i}$，同理对右边。
2. 用公式形式展开：

$$\mathrm{Cov}\left(\sum_i a_iX_i, \sum_j b_jY_j\right) = \mathbb{E}\left[\left(\sum_i a_iX_i\right)\left(\sum_j b_jY_j\right)\right] - \left(\sum_i a_i\mu_{X_i}\right)\left(\sum_j b_j\mu_{Y_j}\right).$$

1. 把两个和式相乘展开成二重和（分配律）：

$$\left(\sum_i a_iX_i\right)\left(\sum_j b_jY_j\right) = \sum_i\sum_j a_ib_jX_iY_j, \qquad \left(\sum_i a_i\mu_{X_i}\right)\left(\sum_j b_j\mu_{Y_j}\right) = \sum_i\sum_j a_ib_j\mu_{X_i}\mu_{Y_j}.$$

1. 取期望（线性性），两项的差就是每个 (i,j) 配对的差之和：

$$\mathrm{Cov}\left(\sum_i a_iX_i, \sum_j b_jY_j\right) = \sum_i\sum_j a_ib_j\left(\mathbb{E}[X_iY_j] - \mu_{X_i}\mu_{Y_j}\right).$$

1. 括号内正是 $\mathrm{Cov}(X_i,Y_j)$，故结论成立。$\blacksquare$

【证明机制解说】：双线性之所以"免费"，是因为协方差的定义本身就是**期望这个线性泛函作用在乘积上**。期望线性性允许我们把 $\sum$ 自由拖进拖出，于是协方差对每个参数都是线性的。作为特例，取 $n=2, m=1, X_1=X, X_2=Y, Y_1=Z, a_1=a, a_2=b$，得到课堂上最常用的形式：

$$\mathrm{Cov}(aX+bY, Z) = a\,\mathrm{Cov}(X,Z) + b\,\mathrm{Cov}(Y,Z).$$

与内积的类比：Cov 在随机变量空间上扮演的角色完全类似内积：对称（性质 2）、双线性（定理 22.7）、"自内积"是 $\mathrm{Var}(\cdot)\geq 0$（性质 1 + 定理 22.2）。唯一不同的是 $\mathrm{Cov}(X,X)=0$ 只说明 X 几乎必然是常数，而不是说 $X=0$——所以严格来说它是**半内积 (semi-inner product)**。这个类比直接解释了相关系数为什么天然落在 $[-1,1]$（内积的 Cauchy–Schwarz 不等式）。

七、独立 ⇒ 协方差为 0，但反之不成立（本讲最重要的反例）

定理 22.8（独立推出零协方差）：若 X, Y 独立，则 $\mathrm{Cov}(X,Y) = 0$。

证明：把定理 22.4（$\mathbb{E}[XY] = \mathbb{E}[X]\mathbb{E}[Y]$）代入 $\mathrm{Cov}(X,Y) = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y]$ 即得。$\blacksquare$

定理 22.8 的逆不成立——完整反例

反例构造：设 X 在 $\{-1,0,1\}$ 上均匀分布（每个取值概率 $1/3$），令 $Y = X^2$。则 $\mathrm{Cov}(X,Y) = 0$，但 X, Y **不独立**——因为 Y 完全由 X 决定，X 也几乎完全由 Y 决定。

逐步推导：

1. 写出 X 的分布：$\Pr[X=-1] = \Pr[X=0] = \Pr[X=1] = 1/3$。
2. 由 $Y = X^2$ 得到 Y 的分布：$X = \pm 1$ 时 $Y = 1$，$X = 0$ 时 $Y = 0$。故

$$\Pr[Y=1] = \Pr[X=1] + \Pr[X=-1] = \tfrac{1}{3} + \tfrac{1}{3} = \tfrac{2}{3}, \qquad \Pr[Y=0] = \Pr[X=0] = \tfrac{1}{3}.$$

1. 算三个矩：

$$\mathbb{E}[X] = \tfrac{1}{3}(-1) + \tfrac{1}{3}(0) + \tfrac{1}{3}(1) = 0,$$

$$\mathbb{E}[Y] = \tfrac{2}{3}(1) + \tfrac{1}{3}(0) = \tfrac{2}{3},$$

$$\mathbb{E}[XY] = \mathbb{E}[X\cdot X^2] = \mathbb{E}[X^3] = \tfrac{1}{3}(-1)^3 + \tfrac{1}{3}(0)^3 + \tfrac{1}{3}(1)^3 = 0.$$

1. 代入：$\mathrm{Cov}(X,Y) = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y] = 0 - 0\cdot\tfrac{2}{3} = 0$。**协方差确实为 0**。（脚本验算通过）
2. 检验独立性。列出联合分布表：

$X\backslash Y$	0	1	行和（X 的边缘）
-1	0	$1/3$	$1/3$
0	$1/3$	0	$1/3$
1	0	$1/3$	$1/3$
列和（Y 的边缘）	$1/3$	$2/3$	1

若独立，则每格都应有 $\Pr[X=x]\Pr[Y=y]$。但例如

$$\Pr[X=0,Y=0]=\tfrac{1}{3}\quad\text{而}\quad\Pr[X=0]\Pr[Y=0]=\tfrac{1}{3}\cdot\tfrac{1}{3}=\tfrac{1}{9},$$

两者相差 3 倍。**故 X,Y 不独立。** ■ 6. 更直观的检验：独立要求"知道 X 的取值后 Y 的分布不变"。但这里一旦知道 $X=0$，就必然有 $Y=0$（$\Pr[Y=0\mid X=0]=1$）；而事先 $\Pr[Y=0]=1/3$。条件分布被彻底改变了，这正是不独立的定义性特征。

直觉解释（为什么会有这种"幽灵"）：协方差捕捉的是**线性**同向性。$Y=X^2$ 中 X 与 Y 的关系是**抛物线形的、完全确定的但非线性的**：$X=-1$ 与 $X=+1$ 都给出同一个 $Y=1$，两侧的贡献 $(X-\mu_X)(Y-\mu_Y)$ 分别为 $(-1)(1/3)$ 与 $(+1)(1/3)$，一正一负完美抵消。所以"关联很强"和"协方差很大"是两件事——**协方差为 0 只说"没有线性关联"，绝不说"没有关联"**。

术语：$\mathrm{Cov}(X,Y)=0$ 时称 X,Y **不相关 (uncorrelated)**。上面的反例精确说明了：**不相关 $\neq$ 独立**。反方向（独立 $\Rightarrow$ 不相关）则由定理 22.8 保证成立。

协方差正负的散点示意（每点代表一个等概率样本，虚线为各自均值）：

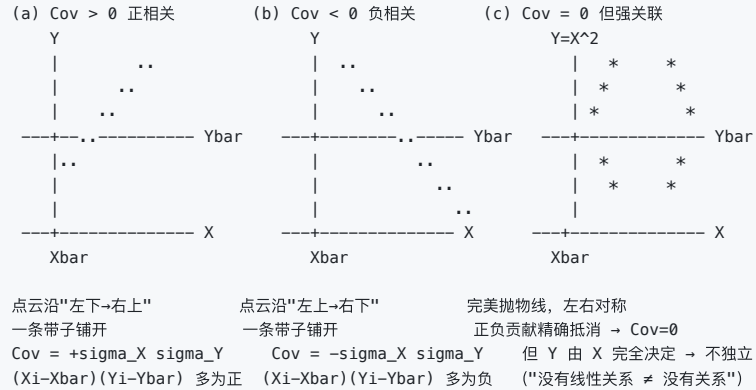

读法：**协方差只看"点云沿哪条斜线铺开"，看不到抛物线这类弯曲的规律**。(c) 图是本讲最重要的图景——它解释了为什么 $\mathrm{Cov}=0$ 不能推出独立。

八、一般形式的方差：含协方差项的完整公式

定理 22.9（方差的一般公式）：对任意随机变量 $X_1,\dots,X_n$（**不需要独立**），

$$\mathrm{Var}\left(\sum_{i=1}^{n}X_i\right)=\sum_{i=1}^{n}\mathrm{Var}(X_i)+2\sum_{1\le i<j\le n}\mathrm{Cov}(X_i,X_j).$$

证明策略：**直接证明 + 双线性**。把 $\mathrm{Var}\left(\sum X_i\right)$ 写成 $\mathrm{Cov}\left(\sum_i X_i,\sum_j X_j\right)$，然后直接套用定理 22.7 的双线性把二重和展开，最后把 $i=j$ 的对角项与 $i\neq j$ 的交叉项分开。

逐步推导：

1. 关键改写：$\mathrm{Var}(U)=\mathrm{Cov}(U,U)$（定理 22.6.1 性质 1）。取 $U=\sum_{i=1}^{n}X_i$：

$$\mathrm{Var}\left(\sum_{i=1}^{n}X_i\right)=\mathrm{Cov}\left(\sum_{i=1}^{n}X_i,\ \sum_{j=1}^{n}X_j\right).$$

1. 取全部系数为 1，由双线性（定理 22.7）：

$$=\sum_{i=1}^{n}\sum_{j=1}^{n}\mathrm{Cov}(X_i,X_j).$$

1. 把二重和按 $i=j$ 与 $i\neq j$ 拆开：

$$=\underbrace{\sum_{i=1}^{n}\mathrm{Cov}(X_i,X_i)}_{\text{对角项}}+\underbrace{\sum_{i\neq j}\mathrm{Cov}(X_i,X_j)}_{\text{交叉项}}.$$

1. 对角项：$\mathrm{Cov}(X_i,X_i)=\mathrm{Var}(X_i)$。（依据：定理 22.6.1 性质 1）
2. 交叉项：由对称性 $\mathrm{Cov}(X_i,X_j)=\mathrm{Cov}(X_j,X_i)$，故 $\sum_{i\neq j}$ 中每一对无序对 $\{i,j\}$（$i<j$）都出现两次，贡献 $2\,\mathrm{Cov}(X_i,X_j)$：

$$\sum_{i\neq j}\mathrm{Cov}(X_i,X_j)=2\sum_{1\le i<j\le n}\mathrm{Cov}(X_i,X_j).$$

1. 合并即得结论。■

推论 22.9.1（两变量情形）：$\mathrm{Var}(X+Y)=\mathrm{Var}(X)+\mathrm{Var}(Y)+2\,\mathrm{Cov}(X,Y)$。当 X,Y 独立时 $\mathrm{Cov}(X,Y)=0$，退化为定理 22.5。

推论 22.9.2（独立时交叉项全部消失）：若 $X_1,\dots,X_n$ **两两独立**，则所有 $i\neq j$ 的 $\mathrm{Cov}(X_i,X_j)=0$（定理 22.8），于是

$$\mathrm{Var}\left(\sum_{i=1}^{n}X_i\right)=\sum_{i=1}^{n}\mathrm{Var}(X_i).$$

【证明机制解说】：定理 22.9 是本讲的"总纲"——它把前面所有结论统一了。方差的"可加性"从来不是无条件成立的，而是**交叉项恰好为零**这一特殊情形。独立性只是保证交叉项为零的**充分条件之一**（另一个更弱的充分条件是"两两不相关"）。记住这个层级关系：

```
一般情形:  Var(sum Xi) = sum Var(Xi) + 2 * sum_{i<j} Cov(Xi,Xj)
                           |
                           | 若所有 Cov(Xi,Xj)=0（两两不相关）
                           v
不相关情形: Var(sum Xi) = sum Var(Xi)
                           |
                           | 若 Xi 两两独立（更强，蕴含不相关）
                           v
独立情形:   Var(sum Xi) = sum Var(Xi)      <-- 最常用，但条件最强
```

反向的箭头**不存在**：不相关推不出独立（本节反例），所以"交叉项为零"是个比独立更弱的条件。工程上常直接验证不相关（只需算 $\mathbb{E}[XY]$），比验证独立（要算整个联合分布）容易得多。

九、必算的分布方差（含完整推导）

1. 伯努利分布 $\mathrm{Ber}(p)$：$\mathrm{Var}(X)=p(1-p)$

设 $X\in\{0,1\}$ 且 $\Pr[X=1]=p$。则 $\mathbb{E}[X]=p$。

关键观察：因为 X 只取 0 和 1，所以 $X^2=X$——对**每一个**样本点都成立（$0^2=0$，$1^2=1$）。于是

$$\mathbb{E}[X^2]=\mathbb{E}[X]=p.$$

代入公式形式：

$$\mathrm{Var}(X)=\mathbb{E}[X^2]-(\mathbb{E}[X])^2=p-p^2=p(1-p).$$

验算：$p=0.5$ 时 $\mathrm{Var}=0.25$；$p=0.3$ 时 0.21；$p=0.1$ 时 0.09。（脚本验算通过）**注意 $p(1-p)$ 在 $p=1/2$ 处取最大值 $1/4$**——这个事实在 L23 估计硬币偏差时会直接决定样本量上界。

⚠ **高频错误**：$\mathbb{E}[X^2]=\mathbb{E}[X]=p$ **只对 0/1 变量成立**。一般地 $\mathbb{E}[X^2]\neq\mathbb{E}[X]$（例如公平骰子 $\mathbb{E}[X]=3.5$ 而 $\mathbb{E}[X^2]=91/6\approx15.17$）。

2. 二项分布 $\mathrm{Bin}(n,p)$：$\mathrm{Var}(X)=np(1-p)$

设 X 为 n 次独立抛硬币（正面概率 p）中的正面数。写成**指示变量之和**：

$$X=I_1+I_2+\cdots+I_n,\qquad I_i=\begin{cases}1, & \text{第 } i \text{ 次为正面}\\ 0, & \text{否则}\end{cases}$$

逐步推导：

1. 每个 I_i 是 $\mathrm{Ber}(p)$，故 $\mathbb{E}[I_i]=p$，$\mathrm{Var}(I_i)=p(1-p)$。（依据：上一条）
2. 由期望线性性（**不需要独立**），$\mathbb{E}[X]=\sum_{i=1}^{n}\mathbb{E}[I_i]=np$。（依据：L20 期望线性性）
3. $I_1,\dots,I_n$ **相互独立**，因为它们分别由 n 次互相独立的抛硬币决定。于是由推论 22.5.1：

$$\mathrm{Var}(X)=\sum_{i=1}^{n}\mathrm{Var}(I_i)=\sum_{i=1}^{n}p(1-p)=np(1-p).\ \blacksquare$$

验算：$n=10$：$p=0.5\to2.5$；$p=0.3\to2.1$；$p=0.1\to0.9$。脚本用二项分布直接枚举 $k=0..n$ 算 $\mathbb{E}[X^2]-\mathbb{E}[X]^2$，三个值全部吻合。

对比：最大可能值 vs. 标准差。X 最大能到 n，而 $\sigma(X)=\sqrt{np(1-p)}\le\sqrt{n}/2$。当 $p=1/2$ 时 $\sigma=\sqrt{n}/2$，即"典型波动"只有 n 的 $\frac{1}{2\sqrt{n}}$ 倍——n 越大，相对波动越小。这正是"分布向均值集中"的定量表达。

3. 几何分布 $\mathrm{Geo}(p)$：$\mathrm{Var}(X)=\dfrac{1-p}{p^2}$

设 X 为"首次成功所需的试验次数"（每次成功概率 p），即 $\Pr[X=k]=(1-p)^{k-1}p$，$k=1,2,3,\dots$。已知 $\mathbb{E}[X]=1/p$。

推导思路一（官方 Note 的"拆一个再递归"法）：设 G 为"首次成功前的失败次数"，则 $G\sim\mathrm{Geo}_0$ 且 $X=G+1$。

1. 先算 G 的一阶矩。对 G 用全期望（对第一次试验分情形）：
2. 第一次就成功（概率 p）：$G=0$；

3. 第一次失败（概率 $1-p$）：浪费一次，此后"重新开始"，故 $G = 1 + G'$，其中 G' 与 G 同分布。 因此 $\mathbb{E}[G] = p\cdot 0 + (1-p)\,(1+\mathbb{E}[G]) = (1-p) + (1-p)\mathbb{E}[G]$，解得 $\mathbb{E}[G] = \frac{1-p}{p}$，故 $\mathbb{E}[X] = 1 + \frac{1-p}{p} = \frac{1}{p}$ ✓。
4. 再算二阶矩。同样分情形，但这次 G^2 在"重来"时要展开 $(1+G')^2 = 1 + 2G' + G'^2$：

$$\mathbb{E}[G^2] = p\cdot 0 + (1-p)\,\big(\mathbb{E}[1 + 2G' + G'^2]\big) = (1-p)\,\big(1 + 2\mathbb{E}[G] + \mathbb{E}[G^2]\big).$$

1. 移项：$\mathbb{E}[G^2] - (1-p)\mathbb{E}[G^2] = (1-p)\,(1 + 2\mathbb{E}[G])$，即

$$p\,\mathbb{E}[G^2] = (1-p)\left(1 + \frac{2(1-p)}{p}\right) = (1-p)\cdot\frac{p + 2 - 2p}{p} = \frac{(1-p)(2-p)}{p}.$$

1. 故 $\mathbb{E}[G^2] = \frac{(1-p)(2-p)}{p^2}$，于是

$$\mathrm{Var}(G) = \frac{(1-p)(2-p)}{p^2} - \left(\frac{1-p}{p}\right)^2 = \frac{(1-p)(2-p) - (1-p)^2}{p^2} = \frac{(1-p)\big[(2-p) - (1-p)\big]}{p^2} = \frac{1-p}{p^2}.$$

1. 因为 $X = G + 1$ 只是平移，由定理 22.3 的平移不变性，$\mathrm{Var}(X) = \mathrm{Var}(G) = \dfrac{1-p}{p^2}$。■

推导思路二（直接求和）：也可以用 $\mathbb{E}[X^2] = \sum_{k\ge 1} k^2(1-p)^{k-1}p$，对几何级数 $\sum_{k\ge 1} k^2 r^{k-1} = \frac{1+r}{(1-r)^3}$（$|r|<1$，两次求导得到）代入 $r = 1-p$：

$$\mathbb{E}[X^2] = p\cdot\frac{1 + (1-p)}{p^3} = \frac{2-p}{p^2}, \qquad \mathrm{Var}(X) = \frac{2-p}{p^2} - \frac{1}{p^2} = \frac{1-p}{p^2}.$$

两条路结果一致。

验算：$p = 0.5 \to \mathrm{Var} = 2$（$\mathbb{E}[X] = 2$）；$p = 0.25 \to 12$（$\mathbb{E} = 4$）；$p = 0.3 \to 7.7778$；$p = 0.1 \to 90$（$\mathbb{E} = 10$）。脚本对 $k = 1..2\times 10^5$ 暴力求和，全部吻合。

注意：注意 $\mathbb{E}[X] = 1/p$ 而 $\mathrm{Var}(X) \approx 1/p^2$，故 $\sigma(X) \approx 1/p = \mathbb{E}[X]$——**几何分布的标准差与均值同量级**，这是典型的"重尾/高离散"分布。对比伯努利：$\sigma \le 0.5$ 而 $\mu \le 1$，也是同量级。相反，二项分布在 n 大时 $\sigma = \Theta(\sqrt{n})$ 远小于 $\mu = \Theta(n)$。

4. 泊松分布 $\mathrm{Pois}(\lambda)$：$\mathrm{Var}(X) = \lambda$

设 $\Pr[X = k] = e^{-\lambda}\dfrac{\lambda^k}{k!}$，$k = 0, 1, 2, \ldots$，已知 $\mathbb{E}[X] = \lambda$。

逐步推导（用递归/微分技巧）：

1. 计算 $\mathbb{E}[X(X-1)]$。注意 $k(k-1)$ 在 $k = 0, 1$ 时为 0，故求和可从 $k = 2$ 开始：

$$\mathbb{E}[X(X-1)] = \sum_{k=2}^{\infty} k(k-1)\,e^{-\lambda}\frac{\lambda^k}{k!} = \lambda^2 e^{-\lambda}\sum_{k=2}^{\infty}\frac{\lambda^{k-2}}{(k-2)!}.$$

（依据：$\frac{k(k-1)}{k!} = \frac{1}{(k-2)!}$，并抽出两个 λ 因子） 2. 令 $j = k - 2$，内层和变成 $\sum_{j\ge 0}\frac{\lambda^j}{j!} = e^{\lambda}$（指数函数的泰勒级数）。 3. 于是 $\mathbb{E}[X(X-1)] = \lambda^2 e^{-\lambda}e^{\lambda} = \lambda^2$。 4. 由 $\mathbb{E}[X(X-1)] = \mathbb{E}[X^2] - \mathbb{E}[X]$ 得

$$\mathbb{E}[X^2] = \lambda^2 + \lambda.$$

1. 代入公式形式：

$$\mathrm{Var}(X) = \mathbb{E}[X^2] - (\mathbb{E}[X])^2 = (\lambda^2 + \lambda) - \lambda^2 = \lambda. \;\blacksquare$$

验算：$\lambda = 1 \to \mathrm{Var} = 1$；$\lambda = 3 \to 3$；$\lambda = 7 \to 7$。脚本对 $k = 0..60$ 求和完全吻合。

标志性特征：泊松分布的期望与方差相等，都等于 λ。这是识别泊松分布的"指纹"——若实测数据算出样本均值与样本方差差很多，就说明泊松模型不合适（这在排队论、保险索赔次数建模中是标准的检验手法）。**注意不要混淆方向**：$\mathbb{E}[X] = \mathrm{Var}(X)$ 是泊松的**必要特征而非充分特征**，别的分布也可能碰巧相等。

5. 有限均匀分布 $\mathrm{Uniform}\{1, \ldots, n\}$：$\mathrm{Var}(X) = \dfrac{n^2 - 1}{12}$

设 X 在 $\{1, 2, \ldots, n\}$ 上均匀，$\Pr[X = i] = 1/n$。已知 $\mathbb{E}[X] = \frac{n+1}{2}$。

逐步推导：

1. 先算二阶矩：

$$\mathbb{E}[X^2] = \sum_{i=1}^{n} i^2\cdot\frac{1}{n} = \frac{1}{n}\sum_{i=1}^{n} i^2.$$

1. 使用**平方和公式**（本课程 L03 归纳法的经典练习）：

$$\sum_{i=1}^{n} i^2 = \frac{n(n+1)(2n+1)}{6}.$$

1. 代入：

$$\mathbb{E}[X^2] = \frac{(n+1)(2n+1)}{6}.$$

1. 用公式形式：

$$\mathrm{Var}(X)=\frac{(n+1)(2n+1)}{6}-\left(\frac{n+1}{2}\right)^2=\frac{(n+1)(2n+1)}{6}-\frac{(n+1)^2}{4}.$$

1. 通分（公分母 12）并抽出公因子 $(n+1)$：

$$=\frac{2(n+1)(2n+1)-3(n+1)^2}{12}=\frac{(n+1)\left[2(2n+1)-3(n+1)\right]}{12}=\frac{(n+1)(4n+2-3n-3)}{12}.$$

1. 化简括号内：$4n+2-3n-3=n-1$。故

$$\mathrm{Var}(X)=\frac{(n+1)(n-1)}{12}=\frac{n^2-1}{12}.\ \blacksquare$$

验算（脚本通过）：

n	直接枚举 $\mathbb{E}[X^2]-\mathbb{E}[X]^2$	公式 $\frac{n^2-1}{12}$	$\sigma=\sqrt{\mathrm{Var}}$
1	0	0	0
2	0.25	0.25	0.5
6	2.916667	2.916667	1.7078
10	8.25	8.25	2.8723
100	833.25	833.25	28.8661

$n=1$ 时 $\mathrm{Var}=0$ 完全合理（退化为常数变量，呼应定理 22.2）；$n=2$（均匀取 $1,2$）等价于 $\mathrm{Ber}(1/2)$ 平移 $+1$，方差 $1/4=(n^2-1)/12=(4-1)/12$ ✓。

推论 22.10（公平骰子）：$n=6$ 时 $\mathbb{E}[X]=7/2$，$\mathrm{Var}(X)=35/12\approx 2.9167$，$\sigma\approx 1.7078$。脚本另算 $\mathbb{E}[X^2]=91/6\approx 15.1667$，$91/6-49/4=182/12-147/12=35/12$ ✓。

与二项分布的量级对比（重要）：均匀分布时 $\sigma=\sqrt{\frac{n^2-1}{12}}\approx\frac{n}{\sqrt{12}}\approx 0.289n$，与**最大值 n 同阶**；而 $\mathrm{Bin}(n,1/2)$ 时 $\sigma=\frac{\sqrt{n}}{2}$，与 n **差一个 $\sqrt{n}$ 因子**。所以当 n 很大时，二项分布"紧贴均值"，而均匀分布"铺满整个取值范围"。这说明：**同样的取值范围不意味着同样的集中程度**。

6. 补充算例：对称随机游走 S_n

设 $S_n=X_1+\cdots+X_n$，其中 $X_i=\pm 1$ 各以概率 $1/2$ 取值且相互独立。已知 $\mathbb{E}[S_n]=0$。

逐步推导：

1. $\mathrm{Var}(X_i)=\mathbb{E}[X_i^2]-(\mathbb{E}[X_i])^2=1-0=1$。（因为 $X_i^2=1$ 恒成立）
2. $X_1,\ldots,X_n$ 独立，由推论 22.5.1：$\mathrm{Var}(S_n)=\sum_{i=1}^n 1=n$。
3. 故 $\mathbb{E}[S_n^2]=\mathrm{Var}(S_n)=n$，$\sigma(S_n)=\sqrt{n}$。

验算：$n=1,4,10$ 时枚举全部 2^n 条路径，得到 $\mathbb{E}[S_n^2]=1,4,10$ ✓。

解释：n 步之后"偏离原点的距离"典型值是 $\sqrt{n}$。走 10000 步只走开 100 步左右——这是**扩散 (diffusion)** 现象的数学内容，和物理里布朗运动的位置均方位移正比于时间同源。**注意不能写成 $\mathbb{E}[|S_n|]=\sqrt{n}$**（脚本验算 $n=4$ 时 $\mathbb{E}[|S_4|]=1.5$ 而 $\sqrt{\mathbb{E}[S_4^2]}=2$）。由 Jensen 不等式 / Cauchy–Schwarz 只有 $\mathbb{E}[|S_n|]\le\sqrt{\mathbb{E}[S_n^2]}=\sqrt{n}$。

7. 补充算例：随机排列的不动点数

设 X_n 为 n 元随机排列中不动点的个数（L20 的"作业本发回给本人"问题）。已知 $\mathbb{E}[X_n]=1$。

写成指示变量之和 $X_n=I_1+\cdots+I_n$，其中 $I_i=1$ 表示"位置 i 是不动点"。**注意 I_i 之间不独立**（若 $n-1$ 个位置都是不动点，最后一个也必然是不动点），所以**不能直接用方差可加**。

逐步推导：

1. 对角项：$\mathrm{Var}(I_i)$。$I_i\sim\mathrm{Ber}(1/n)$，因为 i 是随机排列的不动点的概率是 $1/n$（i 映射到 n 个位置中的任意一个，等概率）。故

$$\mathrm{Var}(I_i)=\mathbb{E}[I_i^2]-\mathbb{E}[I_i]^2=\frac{1}{n}-\frac{1}{n^2}.$$

1. 交叉项：对 $i\neq j$，$\mathbb{E}[I_iI_j]=\Pr[I_i=1\wedge I_j=1]=\frac{1}{n(n-1)}$。理由：固定 $i\mapsto i$ 后，j 的像在剩下 $n-1$ 个位置中均匀选取，恰为 j 的概率是 $\frac{1}{n-1}$。
2. 于是

$$\mathrm{Cov}(I_i,I_j)=\frac{1}{n(n-1)}-\frac{1}{n}\cdot\frac{1}{n}=\frac{n-(n-1)}{n^2(n-1)}=\frac{1}{n^2(n-1)}>0.$$

协方差为正——不动点事件是"聚集"的，一个位置不动会让另一个位置更可能也不动。 4. 用定理 22.9 的一般公式：

$$\mathrm{Var}(X_n)=n\left(\frac{1}{n}-\frac{1}{n^2}\right)+2\binom{n}{2}\frac{1}{n^2(n-1)}=\left(1-\frac{1}{n}\right)+\frac{n(n-1)}{1}\cdot\frac{1}{n^2(n-1)}.$$

1. 化简第二项：$\frac{n(n-1)}{n^2(n-1)}=\frac{1}{n}$。故

$$\mathrm{Var}(X_n)=1-\frac{1}{n}+\frac{1}{n}=1.$$

验算：$n=3,4,5,6$ 时枚举全部 $n!$ 个排列，$\mathbb{E}[X_n]=\mathbb{E}[X_n^2]=1$，$\mathrm{Var}=1$，**与 n 无关**。（脚本验算通过：$n=6$ 时 720 个排列，$\mathbb{E}[X^2]=2.000000$，$\mathrm{Var}=1.000000$）

意义：期望是 1、方差也是 1，都与 n 无关。所以即使 n 是几百万，不动点数也基本在 1 附近的小范围内波动——**"几乎不会有很多人拿到自己的作业本"**。这个例子的教学价值还在于：**它必须用含协方差的一般公式，因为 I_i 不独立**。如果用 $n\,\mathrm{Var}(I_1)=1-1/n$ 就错了（差 $1/n$）。

十、相关系数：ρ 的界与"线性"的精确含义

定理 22.11（相关系数的界）：设 $\sigma_X>0,\sigma_Y>0$，令

$$\rho_{X,Y}=\mathrm{Corr}(X,Y)=\frac{\mathrm{Cov}(X,Y)}{\sigma_X\sigma_Y}.$$

则 $-1\le\rho_{X,Y}\le+1$。

证明策略：**标准化 + 非负期望**。把 X,Y 各自标准化（减均值、除标准差）得到 $\tilde X,\tilde Y$，它们都满足均值为 0、方差为 1。然后利用 $\mathbb{E}[(\tilde X-\tilde Y)^2]\ge0$ 与 $\mathbb{E}[(\tilde X+\tilde Y)^2]\ge0$ 这两个"显然非负"的量，夹出 $\mathbb{E}[\tilde X\tilde Y]$ 的上下界。这正是 Cauchy–Schwarz 不等式在概率空间上的初等证明。

逐步推导：

1. 定义标准化变量 $\tilde X=\dfrac{X-\mu_X}{\sigma_X}$，$\tilde Y=\dfrac{Y-\mu_Y}{\sigma_Y}$。（依据：$\sigma_X,\sigma_Y>0$ 保证可除）
2. 算矩：由定理 22.3 的缩放平移法则，

$$\mathbb{E}[\tilde X]=0,\qquad \mathrm{Var}(\tilde X)=\frac{\mathrm{Var}(X)}{\sigma_X^2}=1,\qquad \mathbb{E}[\tilde X^2]=\mathrm{Var}(\tilde X)=1.$$

同理 $\mathbb{E}[\tilde Y]=0$，$\mathbb{E}[\tilde Y^2]=1$。 3. 因为平方非负，$\mathbb{E}\left[(\tilde X-\tilde Y)^2\right]\ge0$。展开（期望线性性）：

$$0\le\mathbb{E}[\tilde X^2]+\mathbb{E}[\tilde Y^2]-2\mathbb{E}[\tilde X\tilde Y]=1+1-2\mathbb{E}[\tilde X\tilde Y]=2-2\mathbb{E}[\tilde X\tilde Y].$$

1. 于是 $\mathbb{E}[\tilde X\tilde Y]\le1$。
2. 同理，$\mathbb{E}\left[(\tilde X+\tilde Y)^2\right]\ge0$ 展开得 $0\le2+2\mathbb{E}[\tilde X\tilde Y]$，即 $\mathbb{E}[\tilde X\tilde Y]\ge-1$。
3. 合并：$-1\le\mathbb{E}[\tilde X\tilde Y]\le1$。
4. 最后把 $\mathbb{E}[\tilde X\tilde Y]$ 翻译回去。由双线性（定理 22.7）与 $\mathbb{E}[\tilde X]=\mathbb{E}[\tilde Y]=0$：

$$\mathbb{E}[\tilde X\tilde Y]=\mathrm{Cov}(\tilde X,\tilde Y)=\frac{\mathrm{Cov}(X,Y)}{\sigma_X\sigma_Y}=\rho_{X,Y}.$$

（依据：$\mathrm{Cov}(aX+b,cY+d)=ac\,\mathrm{Cov}(X,Y)$，这里 $a=1/\sigma_X,c=1/\sigma_Y$，平移不改变协方差） 8. 故 $-1\le\rho_{X,Y}\le1$。■

【证明机制解说】：证明的巧妙之处是**用两个"必然非负"的平方期望把目标量夹住**。$\mathbb{E}[(\tilde X-\tilde Y)^2]\ge0$ 给上界，$\mathbb{E}[(\tilde X+\tilde Y)^2]\ge0$ 给下界，而两个式子里的 $\mathbb{E}[\tilde X\tilde Y]$ 都是同一个量。这个"对称夹逼"是 Cauchy–Schwarz 的标准初等证法。**标准化这一步不能省**：如果不除以 σ，$\mathbb{E}[(X-Y)^2]\ge0$ 只会给出 $\mathrm{Cov}\le\frac{\sigma_X^2+\sigma_Y^2}{2}$，界里还带着量纲。

推论 22.11.1（等号成立 $\Leftrightarrow$ 完全线性）：$\rho_{X,Y}=+1$ 当且仅当 $\mathbb{E}[(\tilde X-\tilde Y)^2]=0$，即 $\tilde X=\tilde Y$ 几乎必然，即 $Y=\frac{\sigma_Y}{\sigma_X}X+\left(\mu_Y-\frac{\sigma_Y}{\sigma_X}\mu_X\right)$ 几乎必然——**Y 是 X 的斜率为正的仿射函数**。同理 $\rho_{X,Y}=-1$ 当且仅当 $Y=aX+b$（$a<0$）几乎必然。

「度量线性关联」的精确含义：由推论 22.11.1，$|\rho|=1$ 正是"存在精确的线性关系"。反过来 $\rho=0$ 只排除线性关系：$Y=X^2$ 的反例中 $\rho=0$ 却有完美的非线性关系。所以

> **ρ 度量的是"在最小二乘意义下用一条直线解释 Y 的能力"，不是"两个变量的关联强度"。**

工程实践中的补充：ρ^2 恰好是线性回归的**决定系数 (R^2)**——即用 X 的最优线性预测器去预测 Y 时，能消掉的方差比例。这一点把相关系数与 L20 的"条件期望是最优预测器"（$Y=X^2$ 时 $\mathbb{E}[Y\mid X]=X^2$ 完全预测，但线性预测器做不到）联系起来，也再次说明 ρ 的非线性盲区。

与经典问题的联系

1. 负载均衡与哈希（L20 的应用，方差视角）

L20 用期望线性性分析了"m 个球随机投入 n 个箱子"的问题：单个箱子的球数 $X\sim\mathrm{Bin}(m,1/n)$，$\mathbb{E}[X]=m/n$。现在方差给出更强的信息：

$$\mathrm{Var}(X)=m\cdot\frac{1}{n}\left(1-\frac{1}{n}\right)\approx\frac{m}{n},\qquad\sigma(X)\approx\sqrt{\frac{m}{n}}.$$

为什么这个式子重要？ 它说明单个箱子的负载"典型地"只偏离均值约 $\sqrt{m/n}$。当 $m=n$（球数与箱数相同，即哈希表的负载因子为 1）时，$\mathbb{E}[X]=1$，$\sigma(X)\approx1$——**负载集中在一个很小的范围内**。这就是哈希表能在 $O(1)$ 期望时间内完成查找的定量依据：不是因为"每个箱子恰好一个球"（那几乎不可能），而是因为**方差小到让严重超载成为极稀有事件**。

各箱子之间的负载是负相关的（一个箱子多装一个球，其他箱子就少一个），所以用定理 22.9 分析最大值时需要小心处理交叉项；工程上通常改用 L23 的切尔诺夫界 + 联合界来做。这正是 L20（期望）→ L22（方差）→ L23（集中不等式）的推理链条。

2. 随机化算法的性能波动

随机化算法（如随机快排、随机化的最小割算法 Karger、随机化的素数判定 Miller–Rabin）的运行时间或错误概率本身是随机变量。报告 $\mathbb{E}[T]$ 是不够的：

- 如果 $\mathbf{Var}(T)$ 很小，那么"算法通常真的很快"——$\mathbb{E}[T]$ 是有意义的承诺；
- 如果 $\mathbf{Var}(T)$ 很大（例如期望线性但方差是 $O(n^2)$），那么"平均快"可能只是少数极快实例拉低了均值，实际使用中经常体验到很慢。

判据：由切比雪夫不等式（L23），$\Pr\left[|T-\mathbb{E}[T]| \geq k\sigma_T\right] \leq 1/k^2$。所以只要方差可控，"一次运行接近期望"就是**高概率**事件。本讲提供的工具（方差可加、协方差）正是估计 $\mathbf{Var}(T)$ 的唯一途径。

3. 金融与风险：为什么两个收益率都是 10% 的组合不一样

设两种资产的收益率 R_1, R_2，都满足 $\mathbb{E}[R_i]=0.1$、$\sigma_i=0.2$。若等权投资，组合收益率 $R=\frac{1}{2}R_1+\frac{1}{2}R_2$。由定理 22.9：

$$\mathbf{Var}(R)=\tfrac{1}{4}\mathbf{Var}(R_1)+\tfrac{1}{4}\mathbf{Var}(R_2)+\tfrac{1}{2}\mathbf{Cov}(R_1,R_2)=\tfrac{1}{4}(0.04)+\tfrac{1}{4}(0.04)+\tfrac{1}{2}\mathbf{Cov}.$$

- 若 $\rho=0$（不相关）：$\mathbf{Var}(R)=0.02$，$\sigma_R\approx 0.1414$——**风险从 20% 降到 14.1%**，这就是**分散化 (diversification)** 的数学内容。
- 若 $\rho=1$（完全同向）：$\mathbf{Var}(R)=\frac{1}{4}(0.04)+\frac{1}{4}(0.04)+\frac{1}{2}(0.04)=0.04$，$\sigma_R=0.2$——**分散化完全无效**。
- 若 $\rho=-1$（完全反向）：$\mathbf{Cov}(R_1,R_2)=\rho\sigma_1\sigma_2=-0.04$，故 $\mathbf{Var}(R)=0.01+0.01+\frac{1}{2}(-0.04)=0.02-0.02=0$——**风险被完全消除**（这是完美的对冲）。

结论：期望相同、波动相同、甚至个股风险相同，组合风险却可以从 0 到 20% 任意变化——**唯一起作用的是协方差**。这条推理是 Markowitz 现代投资组合理论（1990 年诺贝尔经济学奖）最核心的一步，而它在数学上不过是定理 22.9 的一个特例。

4. 误差传播与测量

物理实验里若 X 由若干独立测量 $X_1,\dots,X_n$ 相加得到，则 $\sigma_X^2=\sum\sigma_{X_i}^2$——**方差相加而标准差不相加**。这是"误差以平方和方式合成"这一实验物理学惯例的来源：两次独立的、标准差各为 σ 的测量，其和的误差是 $\sqrt{2}\sigma$ 而非 2σ。

与其他讲次的关联

- **与 L19（随机变量与离散分布）**：本讲的方差是定义在 L19 的随机变量之上的二阶特征；均匀、伯努利、二项、几何、泊松五个分布的方差不外乎是把 L19 的分布律代进 $\mathbb{E}[X^2]-(\mathbb{E}[X])^2$。L19 给出的 PMF 表是本讲所有算例的输入。
- **与 L20（期望与线性性）**：本讲最核心的对照就是与 L20 的期望线性性对比。**期望 $\mathbb{E}[X+Y]=\mathbb{E}[X]+\mathbb{E}[Y]$ 无条件成立，而方差必须独立**；定理 22.4（$\mathbb{E}[XY]=\mathbb{E}[X]\mathbb{E}[Y]$ 需要独立）正是两者的分水岭。同时本讲大量复用 L20 的"指示变量分解"技巧（二项分布、随机排列不动点）。
- **与 L21（联合分布与随机变量独立性）**：协方差只能靠联合分布定义——$\mathbb{E}[XY]=\sum_a\sum_b ab\,\Pr[X=a,Y=b]$ 就是 L21 的联合 PMF 上的求和。定理 22.4 的证明直接调用了 L21 的独立性定义 $\Pr[X=a,Y=b]=\Pr[X=a]\Pr[Y=b]$。而"协方差为 0 但不独立"的反例，本质上是在说"联合分布不含线性信息，但含非线性信息"，这与 L21 强调的"联合分布比边缘分布携带更多信息"完全呼应。
- **与 L23（集中不等式）**：本讲是下一讲的全部燃料。切比雪夫不等式 $\Pr[|X-\mu|\geq t]\leq \mathbf{Var}(X)/t^2$ 把方差直接翻译成"偏离概率的上界"；弱大数定律的证明依赖"$\mathbf{Var}(\bar{X}_n)=\sigma^2/n$"，而这个等式正是定理 22.3（$\mathbf{Var}(\frac{1}{n}S_n)=\frac{1}{n^2}\mathbf{Var}(S_n)$，注意是 $\frac{1}{n^2}$！）与推论 22.5.1 的合成。**没有方差的独立可加性，就没有大数定律。**
- **与 L03（归纳法）**：均匀分布方差用到的平方和公式 $\sum_{i=1}^{n} i^2=\frac{n(n+1)(2n+1)}{6}$ 正是 L03 归纳法章节的经典练习；本讲把它当作已知引理使用。
- **与 L14/L16（计数与组合证明）**：随机排列不动点算例中，$\binom{n}{2}$ 的交叉项计数、$\Pr[I_i=1]=1/n$、$\Pr[I_iI_j=1]=\frac{1}{n(n-1)}$ 全是在数排列（L14 的计数原理）。$\mathbb{E}[X]=\mathbb{E}[X^2]=1$ 这个"巧合"本身是组合数学中著名的"错排问题"的概率表述。
- **与 L25（正态分布与 CLT）**：本讲"独立和的方差线性增长、标准差按 $\sqrt{n}$ 增长"是 CLT 的前奏。CLT 进一步说：标准化后的 $(\bar{X}_n-\mu)/(\sigma/\sqrt{n})$ 的**分布形状**收敛到标准正态——而它需要的输入恰是本讲的 μ 与 σ^2。
- **与 L26（马尔可夫链）**：协方差结构在马尔可夫链的混合时间分析中也出现（相邻时间步状态的相关性衰减速度决定收敛速率）。

关键要点

1. **方差的两个形式**：$\mathbf{Var}(X)=\mathbb{E}[(X-\mu)^2]=\mathbb{E}[X^2]-\mu^2$。前者是定义（"平均平方距离"），后者是计算捷径。**永远不要混淆 $\mathbb{E}[X^2]$ 与 $(\mathbb{E}[X])^2$。**
2. **缩放与平移**：$\mathbf{Var}(aX+b)=a^2\,\mathbf{Var}(X)$。方差对平移免疫、对缩放**平方**响应；标准差则线性响应：$\sigma(aX+b)=|a|\sigma(X)$。
3. **可加性的条件（黄金法则）**：期望可加**无条件**；方差可加**需要独立**（或至少两两不相关）。一般公式是 $\mathbf{Var}(\sum X_i)=\sum\mathbf{Var}(X_i)+2\sum_{i<j}\mathbf{Cov}(X_i,X_j)$，独立只是让交叉项消失。
4. **五个必背方差**：$\mathbf{Ber}(p)\to p(1-p)$；$\mathbf{Bin}(n,p)\to np(1-p)$；$\mathbf{Geo}(p)\to\frac{1-p}{p^2}$；$\mathbf{Pois}(\lambda)\to\lambda$；$\mathbf{Uniform}\{1,\dots,n\}\to\frac{n^2-1}{12}$。其中泊松的"期望 = 方差"是它的指纹。
5. **协方差三句话**：$\mathbf{Cov}(X,X)=\mathbf{Var}(X)$；$\mathbf{Cov}$ 双线性且**不需要独立**（这是它比方差好用的原因）；独立 $\Rightarrow \mathbf{Cov}=0$，但 $\mathbf{Cov}=0 \not\Rightarrow$ 独立（$Y=X^2$ 反例）。
6. **相关系数**：$\rho=\frac{\mathbf{Cov}}{\sigma_X\sigma_Y}\in[-1,1]$，$|\rho|=1$ 当且仅当 Y 是 X 的仿射函数。它只度量**线性**关联，$\rho=0$ 不代表"无关"。

常见误区与注意事项

1. **把 $\mathbf{Var}(cX)$ 写成 $c\,\mathbf{Var}(X)$。** 这是最高频的错误。正确是 $c^2\,\mathbf{Var}(X)$。**记忆锚点**：$\mathbf{Var}$ 是"平方距离"，缩放 c 倍后距离放大 $|c|$ 倍，平方就是 c^2 倍。验算：公平骰子 $\mathbf{Var}(X)=35/12$，$\mathbf{Var}(3X)=9\cdot 35/12=26.25\neq 3\cdot 35/12=8.75$。
2. **把 $\mathbb{E}[X^2]$ 与 $(\mathbb{E}[X])^2$ 混为一谈。** $X\sim\mathbf{Ber}(1/2)$：$\mathbb{E}[X^2]=1/2$，$(\mathbb{E}[X])^2=1/4$。**唯一能让它们相等的情形是方差为 0（X 几乎必然为常数）。**

3. **不加验证地使用 $\mathbf{Var}(X+Y)=\mathbf{Var}(X)+\mathbf{Var}(Y)$。** 必须确认独立（或不相关）。反例：$X=Y\sim\mathbf{Ber}(1/2)$ 时右边是 $1/2$ 而实际是 1。**每次写下这条等式前，先问自己："它们独立吗？"**
4. **误以为协方差为 0 就等于独立。** X 均匀取 $\{-1,0,1\}$、$Y=X^2$ 时 $\mathbf{Cov}(X,Y)=0$ 但 $\Pr[X=0,Y=0]=1/3\neq 1/9$，明显不独立。**协方差只探测线性关系。**
5. **在 Cov 与 Var 之间乱用"期望的线性性"。** 期望线性性对**任何**线性组合成立，但不能推广到乘积：$\mathbb{E}[XY]\neq\mathbb{E}[X]\mathbb{E}[Y]$（除非独立），更不能推广到方差：$\mathbf{Var}(X+Y)\neq\mathbf{Var}(X)+\mathbf{Var}(Y)$（除非不相关）。**"线性性"这个名字只属于期望。**
6. **忘记方差零/协方差零中的"几乎必然"限定词。** 严格陈述是"$\mathbf{Var}(X)=0\iff\Pr[X=c]=1$"，而不是"$\iff X$ 恒为常数"。在无限样本空间上这个区别是实质性的（例如 X 在 $[0,1]$ 上取值，$\Pr[X=1/2]=1$ 且其余点概率为 0）。
7. **在估计量分析中把 $\mathbf{Var}(\frac{1}{n}S_n)$ 写成 $\frac{1}{n}\mathbf{Var}(S_n)$。** 正确是 $\frac{1}{n^2}\mathbf{Var}(S_n)=\frac{\sigma^2}{n}$（注意 $a=1/n$，所以要平方）。**漏掉这个平方会导致方差随 n 不收敛的错误结论，直接毁掉大数定律的证明。**
8. **把标准差当作可加的量。** $\sigma(X+Y)=\sqrt{\sigma_X^2+\sigma_Y^2}$（独立时），**不是** $\sigma_X+\sigma_Y$。只有方差线性可加。

思考题（带答案）

Q1.（纯计算） 设随机变量 X 的分布为 $\Pr[X=0]=0.2$，$\Pr[X=1]=0.3$，$\Pr[X=2]=0.5$。求 $\mathbb{E}[X]$、$\mathbf{Var}(X)$、$\sigma(X)$，并求 $\mathbf{Var}(3X-4)$。

> ▸ **答案**
>
> **第一步，算期望**：
>
> $$\mathbb{E}[X]=0(0.2)+1(0.3)+2(0.5)=0+0.3+1.0=1.3.$$
>
> **第二步，算二阶矩**（LOTUS：$\mathbb{E}[g(X)]=\sum_x g(x)\Pr[X=x]$）：
>
> $$\mathbb{E}[X^2]=0^2(0.2)+1^2(0.3)+2^2(0.5)=0+0.3+2.0=2.3.$$
>
> **第三步，用公式形式**：
>
> $$\mathbf{Var}(X)=2.3-(1.3)^2=2.3-1.69=0.61.$$
>
> **第四步，标准差**：$\sigma(X)=\sqrt{0.61}\approx 0.7810$。
>
> **第五步，缩放平移**：$\mathbf{Var}(3X-4)=3^2\,\mathbf{Var}(X)=9\times 0.61=5.49$。（平移 -4 不影响方差）
>
> **校验**：用定义形式直接算。$\mu=1.3$，偏离量为 $-1.3,-0.3,0.7$，平方为 $1.69,0.09,0.49$：
>
> $$\mathbf{Var}(X)=0.2(1.69)+0.3(0.09)+0.5(0.49)=0.338+0.027+0.245=0.61\ \checkmark$$
>
> **注意**：若误写 $\mathbf{Var}(3X-4)=3\cdot 0.61=1.83$，或漏掉平移影响写成 $9\cdot 0.61+16$，都是错的。

Q2.（概念/证明） 设 X,Y 独立，$\mathbf{Var}(X)=4$，$\mathbf{Var}(Y)=9$。求 $\mathbf{Var}(2X-3Y+5)$。若改为 $\mathbf{Cov}(X,Y)=2$（不再独立），结果如何？

> ▸ **答案**
>
> **独立情形**：先用定理 22.3 处理系数，再用独立性。
>
> $$\mathbf{Var}(2X-3Y+5)=2^2\,\mathbf{Var}(X)+(-3)^2\,\mathbf{Var}(Y)=4\cdot 4+9\cdot 9=16+81=97.$$
>
> **推导依据**：把 $2X$ 与 $-3Y$ 看成两个独立变量（$X\perp Y\Rightarrow 2X\perp -3Y$），由定理 22.5 方差可加：$\mathbf{Var}(2X+(-3Y))=\mathbf{Var}(2X)+\mathbf{Var}(-3Y)$，再用 $\mathbf{Var}(aX)=a^2\,\mathbf{Var}(X)$。注意 $(-3)^2=9$，**负号在平方后消失**——这是与期望最明显的差别（$\mathbb{E}[2X-3Y+5]=2\mathbb{E}[X]-3\mathbb{E}[Y]+5$，负号保留）。常数 $+5$ 不影响方差。
>
> **不独立情形**：由定理 22.9 的推论，
>
> $$\mathbf{Var}(2X-3Y+5)=\mathbf{Var}(2X)+\mathbf{Var}(-3Y)+2\,\mathbf{Cov}(2X,-3Y).$$
>
> 由双线性，$\mathbf{Cov}(2X,-3Y)=2\cdot(-3)\,\mathbf{Cov}(X,Y)=-6\cdot 2=-12$。故
>
> $$=16+81+2(-12)=97-24=73.$$
>
> **结论**：正协方差（X 大时 Y 也大）而系数符号相反（$+2X$ 与 $-3Y$）时，组合的方差**变小**——这正是"对冲"的数学内容。若 $\mathbf{Cov}(X,Y)=-2$，则 $\mathbf{Cov}(2X,-3Y)=+12$，方差变成 $97+24=121$，反而放大。

Q3.（概念理解） 判断下列命题真假并说明理由：

(a) 若 $\mathbf{Cov}(X,Y)=0$，则 X,Y 独立。(b) 若 $\mathbf{Var}(X)=0$，则 X 是常数随机变量（即存在 c 使 $\Pr[X=c]=1$）。(c) 若 X,Y 独立，则 $\mathbf{Var}(X-Y)=\mathbf{Var}(X)+\mathbf{Var}(Y)$。(d) $\mathbf{Var}(X)\le\mathbb{E}[X^2]$ 对一切 X 成立。

▸ 答案

(a) **假。** 独立 $\Rightarrow$ 协方差为 0，但反之不成立。反例：X 均匀取 $\{-1,0,1\}$，$Y=X^2$。已算出 $\mathbb{E}[X]=0$、$\mathbb{E}[Y]=2/3$、$\mathbb{E}[XY]=\mathbb{E}[X^3]=0$，故 $\mathrm{Cov}(X,Y)=0$。但 $\Pr[X=0,Y=0]=1/3$ 而 $\Pr[X=0]\Pr[Y=0]=1/9$，不独立。

(b) **真。** 这正是定理 22.2。证明要点：$\mathrm{Var}(X)=\sum_\omega (X(\omega)-\mu)^2P(\omega)$ 是**非负项之和**，等于 0 迫使每个正概率点都满足 $X(\omega)=\mu$，取 $c=\mu$。

(c) **真。** 由定理 22.9：$\mathrm{Var}(X-Y)=\mathrm{Var}(X)+\mathrm{Var}(-Y)+2\,\mathrm{Cov}(X,-Y)$。由缩放法则 $\mathrm{Var}(-Y)=(-1)^2\,\mathrm{Var}(Y)=\mathrm{Var}(Y)$；由双线性 $\mathrm{Cov}(X,-Y)=-\,\mathrm{Cov}(X,Y)$，而独立性给出 $\mathrm{Cov}(X,Y)=0$。故 $\mathrm{Var}(X-Y)=\mathrm{Var}(X)+\mathrm{Var}(Y)$。**记住：减法与加法在方差上完全一样，因为符号被平方抹平了。**（对比 $\mathbb{E}[X-Y]=\mathbb{E}[X]-\mathbb{E}[Y]$，符号是保留的。）

(d) **真。** 因为 $\mathrm{Var}(X)=\mathbb{E}[X^2]-(\mathbb{E}[X])^2\le\mathbb{E}[X^2]$，只需 $(\mathbb{E}[X])^2\ge 0$。等号成立当且仅当 $\mathbb{E}[X]=0$（此时方差与二阶矩相等，例如对称随机游走的 S_n）。

Q4.（进阶） 设 $X_1,\dots,X_n$ 独立同分布，$\mathbb{E}[X_i]=\mu$，$\mathrm{Var}(X_i)=\sigma^2$。记样本均值 $\bar X=\frac{1}{n}\sum_{i=1}^n X_i$。求 $\mathbb{E}[\bar X]$ 与 $\mathrm{Var}(\bar X)$，并解释 $\mathrm{Var}(\bar X)=\sigma^2/n$ 的直观含义。若 X_i 只是**两两不相关**（不独立），结论是否仍然成立?

▸ 答案

期望：由期望线性性（**不需独立**），

$$\mathbb{E}[\bar X]=\frac{1}{n}\sum_{i=1}^n\mathbb{E}[X_i]=\frac{1}{n}\cdot n\mu=\mu.$$

即 $\bar X$ 是 μ 的**无偏估计量 (unbiased estimator)**。

方差：$\mathrm{Var}(\bar X)=\mathrm{Var}\left(\frac{1}{n}S_n\right)=\frac{1}{n^2}\mathrm{Var}(S_n)$（定理 22.3，注意 $\frac{1}{n^2}$）。由独立性（推论 22.5.1），$\mathrm{Var}(S_n)=\sum\mathrm{Var}(X_i)=n\sigma^2$。故

$$\mathrm{Var}(\bar X)=\frac{n\sigma^2}{n^2}=\frac{\sigma^2}{n}.$$

直观含义：方差随 n **线性衰减**，标准差按 $1/\sqrt{n}$ 衰减。也就是说，**样本量翻四倍才能把估计的典型误差减半**。这就是"精度来之不易"的定量表述：要把误差缩小 10 倍，需要 100 倍的样本。$n\to\infty$ 时 $\mathrm{Var}(\bar X)\to 0$，加上定理 22.2（方差为 0 即几乎必然是常数），就得到 $\bar X$ 向 μ 集中——这正是 L23 弱大数定律的证明骨架。

两两不相关情形：结论**仍然成立**。因为 $\mathrm{Var}(S_n)=\sum_i\mathrm{Var}(X_i)+2\sum_{i<j}\mathrm{Cov}(X_i,X_j)$，只需所有交叉项 $\mathrm{Cov}(X_i,X_j)=0$ 即可，而这正是"两两不相关"（比独立更弱）。所以 **大数定律只需要不相关，不需要独立**——这是一个常见但不必要的加强假设。（反过来说：若 $\mathrm{Cov}(X_i,X_j)>0$ 全都为正，例如"每次测量都受同一个缓慢漂移的系统误差影响"，则交叉项会累积成 $O(n^2)$ 量级，$\mathrm{Var}(\bar X)$ 可能**不收敛到** 0，平均就不能消除误差。这是"系统性偏差无法靠增加样本量解决"的数学解释。）

Lecture 23: Concentration Inequalities（集中不等式）

概述

本讲回答一个贯穿全课程的问题：**知道期望之后，随机变量偏离期望很远的概率有多大?** L22 的方差给出了"典型偏离"的尺度，本讲把它翻译成**严格的概率上界**。

本讲的三个主角是层层递进的不等式：**马尔可夫不等式 (Markov's Inequality)** 只用期望、要求变量非负；**切比雪夫不等式 (Chebyshev's Inequality)** 额外用了方差，条件更弱、界更紧；**切尔诺夫界 (Chernoff Bound)** 用"矩生成函数"这一技巧把上界从多项式衰减 (polynomial decay) 提升到指数衰减 (exponential decay)，代价是要求变量独立且有界。最后用切比雪夫证明**弱大数定律 (Weak Law of Large Numbers)**：大量独立重复实验的平均值收敛到期望。

本讲最深刻的方法论是：**集中不等式不依赖精确分布，只需要期望、方差这类"少量信息"，却给出适用于整个分布族的强结论。** 这是"用信息换普适性"的典范，也是随机化算法能够给出可靠性保证的根本原因——我们无法穷举随机算法的所有随机选择，但可以用集中不等式断言"坏事件极其稀有"。

核心概念的直观解释

概念一：为什么需要"不依赖精确分布"的界

- **问题设定**：设 $X\sim\mathrm{Bin}(n,1/2)$。要知道 $\Pr[X\ge 0.6n]$，最精确的做法是直接求和

$$\Pr[X\ge 0.6n]=\sum_{k=\lceil 0.6n\rceil}^{n}\binom{n}{k}\frac{1}{2^n}.$$

但这个和式没有封闭形式，n 很大时也难算。更糟的是：实际应用中我们**经常连分布都不知道**——只知道"平均每台服务器 10 个请求"，但请求数的分布可能是泊松、可能是二项、也可能是个从未见过的分布。 – **直观解释（"它是什么意思？"）**：集中不等式说："我不需要知道你的分布长什么样。只要告诉我均值（和方差），我就能保证你的极端值不会太常见。" 这就像只知道一个班平均分是 70 分，就能断言"不可能有超过 1/3 的人考到 90 分以上"——具体分数分布完全不需要知道。 – **基本权衡**：信息越少，界越松。马尔可夫只用 $\mathbb{E}[X]$，界往往极松（有时甚至超过 1，变成废界）；切比雪夫用了 $\mathrm{Var}(X)$，界变紧；切尔诺夫用了"独立性 + 有界性 + 全部矩"，界最紧。**没有免费的午餐：更强的结论需要更强的假设。** – **具体示例**：$n=1000$ 次公平抛硬币，实测 $\Pr[X\ge 600]\approx 1.36\times 10^{-10}$。马尔可夫给 0.833（差了 10^{10} 倍，几乎无用），切比雪夫给 0.025（好一些），切尔诺夫给 8.3×10^{-5}（已是同一量级的粗糙估计）。**三个界都正确，但实用价值天差地别。**

概念二：马尔可夫不等式 (Markov's Inequality)

- **定义**：设 X 是非负随机变量（即 $X(\omega)\ge 0$ 对一切 $\omega\in\Omega$），期望有限。则对任意常数 $c>0$，

$$\Pr[X \geq c] \leq \frac{\mathbb{E}[X]}{c}.$$

- **直观解释**："**不可能所有人都高于平均分。**" 更具体地说：在分数非负的前提下，至多一半的人能达到平均分的两倍（取 $c = 2\mathbb{E}[X]$ 得 $\Pr[X \geq 2\mathbb{E}[X]] \leq 1/2$）。这个结论**不需要知道分布**，只需要"分数非负"。
- **跷跷板图景（官方 Note 的绝妙类比）**：把概率分布想象成放在支点 $\mu = \mathbb{E}[X]$ 上的跷跷板。我们想求"支点右侧 $k\mu$ 之外最多占多少概率质量"。要让 $k\mu$ 处的质量 m_2 尽可能大，就必须在支点左侧尽量远处放质量 m_1 来平衡它——而 $X \geq 0$ 恰恰限制了最远处只能到 0。力矩平衡给出：$m_1 \cdot (\mu - 0) = m_2 \cdot (k\mu - \mu)$，即 $m_1 = (k-1)m_2$；又 $m_1 + m_2 = 1$（总概率），解得 $m_2 = 1/k$。**这正是马尔可夫界 $\Pr[X \geq k\mu] \leq 1/k$。**
- **具体示例**：X 以 0.3 概率取 5、以 0.7 概率取 0。则 $\mathbb{E}[X] = 1.5$。取 $c = 5$：界给 $\Pr[X \geq 5] \leq 1.5/5 = 0.3$，而实际值恰为 0.3——**界是紧的（取到等号）**。换 $c = 3$：界给 $1.5/3 = 0.5$，实际 $\Pr[X \geq 3] = 0.3 \leq 0.5$（松了）。
- **局限**：① **必须非负**，否则结论可能完全失效（见后文反例）；② 只用了一阶信息，界通常很松；③ 当 $c < \mathbb{E}[X]$ 时界 > 1，是**空洞界 (vacuous)**，不提供任何信息。

概念三：切比雪夫不等式 (Chebyshev's Inequality)

- **定义**：设 X 的期望 $\mu = \mathbb{E}[X]$、方差有限。则对任意常数 $c > 0$，

$$\Pr\left[|X - \mu| \geq c\right] \leq \frac{\mathbf{Var}(X)}{c^2}.$$

- **直观解释**："偏离均值 k 个标准差的概率不超过 $1/k^2$。" 取 $c = k\sigma$ 即得**推论 23.2**：$\Pr[|X - \mu| \geq k\sigma] \leq 1/k^2$。例如偏离 2 个标准差以上的概率 $\leq 1/4$；偏离 3 个标准差以上 $\leq 1/9 \approx 11\%$。**这是"标准差 = 分布的宽度"这一说法的严格版本。**
- **为什么比马尔可夫强**：因为多了方差信息。而方差的本质是**二阶矩**——"偏离的平方"这一新随机变量的均值。**用二阶信息去控制偏离，效果自然比一阶信息好得多。**
- **具体示例（同一例子对比）**：n 次公平抛硬币，X 为正面数，$\mu = n/2$，$\mathbf{Var}(X) = n/4$。问 $\Pr[X \geq \frac{3}{4}n]$：
- 马尔可夫：$\Pr[X \geq \frac{3}{4}n] \leq \dfrac{n/2}{3n/4} = \dfrac{2}{3}$——**与 n 无关**，n 再大也不改善。
- 切比雪夫：注意 $\{X \geq \frac{3}{4}n\} \subseteq \{|X - \frac{n}{2}| \geq \frac{n}{4}\}$，故

$$\Pr\left[X \geq \tfrac{3}{4}n\right] \leq \Pr\left[\left|X - \tfrac{n}{2}\right| \geq \tfrac{n}{4}\right] \leq \frac{n/4}{(n/4)^2} = \frac{4}{n}.$$

$n=10\to0.4$；$n=100\to0.04$；$n=1000\to0.004$—**随 n 衰减到 0**。（脚本验算：实际值分别为 5.47×10^{-2}、2.82×10^{-7}、$6.74\time

- **注意事件包含的转换**：$\{X \geq \frac{3}{4}n\}$ 是单尾事件，而切比雪夫管的是双尾事件 $\{|X - \mu| \geq c\}$。必须先用 $\{X \geq a\} \subseteq \{|X - \mu| \geq a - \mu\}$（当 $a > \mu$ 时）放大成双尾才能套用。**这一步常被学生漏掉。**

概念四：切尔诺夫界 (Chernoff Bound)——进阶但必备的工具

- **说明（重要）**：CS70 归档官方 Note 17（Fall 2020 / Spring 2021）**并未包含切尔诺夫界**。但它是 CS70 课程体系中分析随机化算法与负载均衡的标准工具（在哈希与负载均衡的讲义、以及后续算法课中反复出现），因此本节作为**进阶补充**呈现，所有推导都自洽给出。
- **定义（上尾，精确形式）**：设 $X_1, \ldots, X_n$ 为**独立的** $\{0,1\}$ 随机变量，$X = \sum_{i=1}^{n} X_i$，$\mu = \mathbb{E}[X]$。则对任意 $\delta > 0$，

$$\Pr\left[X \geq (1+\delta)\mu\right] \leq \left(\frac{e^{\delta}}{(1+\delta)^{1+\delta}}\right)^{\mu}.$$

- **定义（简化形式，最常用）**：对 $0 < \delta < 1$，

$$\Pr\left[X \geq (1+\delta)\mu\right] \leq e^{-\mu\delta^2/3}, \qquad \Pr\left[X \leq (1-\delta)\mu\right] \leq e^{-\mu\delta^2/2}.$$

- **直观解释（"它是什么意思？"）**：右端是**指数衰减**。切比雪夫给的是 $O(1/\delta^2)$ 这种**多项式衰减**，而切尔诺夫给 $e^{-c\mu\delta^2}$——当 μ 很大时这两者相差天文数字。直觉上，切尔诺夫之所以强，是因为它偷偷用掉了**所有阶的矩**（通过 $\mathbb{E}[e^{tX}]$），而不仅仅是前两阶。
- **代价**：需要**独立性**（切比雪夫只需要方差，甚至只需要两两不相关）。所以切尔诺夫和切比雪夫不是"谁替代谁"的关系，而是**假设强度与结论强度之间的又一次权衡**。
- **具体示例（同一例子三方对比）**：$n = 1000$ 次公平抛硬币，问 $\Pr[X \geq 600]$（即 $\delta = 0.2$）：

方法	上界	与真值 1.36×10^{-10} 的差距
精确枚举	1.3642×10^{-10}	——
马尔可夫	0.8333	大 6.1×10^{9} 倍（近乎无用）
切比雪夫	0.025	大 1.8×10^{8} 倍
切尔诺夫（精确形式）	8.331×10^{-5}	大 6.1×10^{5} 倍
切尔诺夫（$e^{-\mu\delta^2/3}$）	1.273×10^{-3}	大 9.3×10^{6} 倍
霍夫丁（$e^{-2n\epsilon^2}$，$\epsilon = 0.1$）	2.061×10^{-9}	大 15 倍

关键观察：马尔可夫和切比雪夫的界在 n 增大时下降太慢；切尔诺夫第一次让界与真值处于同一个"指数尺度"上。这才是它在算法分析中不可替代的原因。

概念五：弱大数定律 (Weak Law of Large Numbers, WLLN)

- **定义**：设 $X_1, X_2, \dots$ 是**独立同分布 (i.i.d.)** 的随机变量序列，公共期望 $\mathbb{E}[X_i] = \mu$、公共方差 $\mathbf{Var}(X_i) = \sigma^2 < \infty$。记 $S_n = X_1 + \cdots + X_n$。则对任意 $\epsilon > 0$,

$$\Pr\left[\left|\frac{1}{n}S_n - \mu\right| < \epsilon\right] \to 1 \quad (n \to \infty).$$

等价形式：$\Pr\left[\left|\frac{S_n}{n} - \mu\right| \geq \epsilon\right] \to 0$。也就是"样本均值依概率收敛于期望"，记作 $\frac{S_n}{n} \xrightarrow{P} \mu$。 – **直观解释**："**大量独立重复实验的平均值收敛到期望。**" 抛一万次硬币，正面比例几乎必然接近 1/2；工厂抽检一万件产品，次品率几乎必然接近真实次品率。**这条定律是我们把"概率"理解为"长期频率"的合法性来源**——参见 L15 用频率公理化概率时，实际上已经默认了这条定律；本讲第一次把它**证出来**。 – **"弱"在哪里**：弱大数定律说的是"对每个固定的 ϵ，n 足够大时偏离 ϵ 的概率很小"——**允许在无穷序列中出现无限多次偏离**，只要越来越稀有。强 (strong) 大数定律断言"以概率 1 存在某个有限时刻之后再也不偏离"，是更强的结论（需要更高级的工具，超出本课程）。 – **具体示例**：设 X_i 为抛硬币指示变量（正面概率 0.5），$\mu = 0.5$，$\sigma^2 = 0.25$。则 $\mathbf{Var}(S_n/n) = 0.25/n$。取 $\epsilon = 0.05$：

$$\Pr\left[\left|\tfrac{S_n}{n} - 0.5\right| \geq 0.05\right] \leq \frac{0.25}{n(0.05)^2} = \frac{100}{n}.$$

$n = 500$ 时界为 0.2；$n = 5000$ 时为 0.02；$n = 50000$ 时为 0.002。**要保证偏离 ≤ 0.05 的概率不超过 0.05，$n \geq 2000$ 就够了。**（脚本验算：实际值在 $n = 500$ 时只有 2.83×10^{-2}，因此这个界很保守但完全正确。）注意 $\sigma(S_n/n) = \sqrt{0.25/n}$：$n = 100$ 时 0.05，$n = 10000$ 时 0.005——**标准差按 $1/\sqrt{n}$ 收窄**，这是下一讲 CLT 的核心图景。

完整证明与推导（核心）

一、马尔可夫不等式（两种证明）

定理 23.1（马尔可夫不等式 / Markov's Inequality）：设 X 是非负随机变量（$X(\omega) \geq 0$ 对一切 $\omega \in \Omega$），且 $\mathbb{E}[X]$ 有限。则对任意常数 $c > 0$,

$$\Pr[X \geq c] \leq \frac{\mathbb{E}[X]}{c}.$$

证明策略（证法一：按取值分拆期望）：直接证明 + 不等式放缩。核心想法是"**只保留大值那一部分的贡献**"——把期望的求和分成"$a \geq c$"与"$a < c$"两段，丢掉后者的非负贡献（这是唯一允许放缩的地方），再把前一段里每个 a 换成更小的 c，从而把 a 从求和里提出来。

逐步推导（证法一）：

1. 记 A 为 X 的取值集合，X 非负意味着 $A \subseteq [0, \infty)$。由期望定义：

$$\mathbb{E}[X] = \sum_{a \in A} a \Pr[X = a].$$

1. 把求和拆成两段：

$$\mathbb{E}[X] = \sum_{a \in A,\, a < c} a \Pr[X = a] \;+\; \sum_{a \in A,\, a \geq c} a \Pr[X = a].$$

1. 因为 X 非负，第一段中每一项 $a \Pr[X = a] \geq 0$，故可以丢掉第一段**缩小**右边的值：

$$\mathbb{E}[X] \geq \sum_{a \geq c} a \Pr[X = a].$$

这是唯一用到非负性的地方。 若 X 可取负值，第一段是负的，丢掉它会**增大**右边，后面的推理全线崩塌。 4. 在保留的那一段里，每个 $a \geq c$，把 a 替成更小的 c 继续缩小：（依据：$a \geq c$，概率非负）

$$\mathbb{E}[X] \geq \sum_{a \geq c} c \Pr[X = a] = c \sum_{a \geq c} \Pr[X = a] = c \Pr[X \geq c].$$

1. 移项除以 $c > 0$：$\Pr[X \geq c] \leq \dfrac{\mathbb{E}[X]}{c}$。■

逐步推导（证法二：指示变量，更"巧妙"）：这一证法出自官方 Note，值得单独记住。

1. 定义指示变量（indicator random variable）

$$\mathbb{1}\{X \geq c\} = \begin{cases} 1, & X \geq c \\ 0, & X < c \end{cases}$$

它是随机变量，且 $\mathbb{E}\left[\mathbb{1}\{X \geq c\}\right] = \Pr[X \geq c]$（指示变量的期望等于对应事件的概率，见 L20）。 2. **核心不等式**：对**每一个** $\omega \in \Omega$，都有

$$X(\omega) \geq c\,\mathbb{1}\{X(\omega) \geq c\}.$$

验证：若 $X(\omega) < c$，右边是 $c \cdot 0 = 0 \leq X(\omega)$（这里有赖于 $X \geq 0$！）；若 $X(\omega) \geq c$，右边是 $c \cdot 1 = c \leq X(\omega)$ ✓。 3. 两边取期望。因为不等式逐点成立，且 $P(\omega) \geq 0$ 是权重，求和保持不等号：

$$\mathbb{E}[X] \geq c\,\mathbb{E}\left[\mathbb{1}\{X \geq c\}\right] = c \Pr[X \geq c].$$

1. 除以 $c > 0$ 即得。■

【证明机制解说】：两种证法的心跳是同一句话——**"用 c 代替所有大于等于 c 的取值，并把小于 c 的部分整个丢掉"**。因为 $X \geq 0$，丢掉小值只会让总和变小，所以不等式方向是安全的。证法二的妙处在于把"分拆求和"这个操作压缩成了一个逐点不等式 $X \geq c\mathbb{I}\{X \geq c\}$；这个"指示变量下界"的套路会在广义马尔可夫、切尔诺夫界里反复出现，是概率论里最通用的放缩模板。**请记住这个模板：找一个"只在事件发生时取正值"的下界随机变量。**

紧性讨论（界何时取到等号）：马尔可夫不等式是**紧的**。构造：固定 $k > 1$，令

$$\Pr[X = k\mu] = \frac{1}{k}, \qquad \Pr[X = 0] = 1 - \frac{1}{k}.$$

则 $\mathbb{E}[X] = k\mu \cdot \frac{1}{k} = \mu$，而 $\Pr[X \geq k\mu] = \frac{1}{k} = \frac{\mathbb{E}[X]}{k\mu}$——**取到等号**。（脚本验算：$k = 2, 4, 10$ 时两边分别等于 $0.5, 0.25, 0.1$ ✓）

跷跷板推导（为什么是 $1/k$）：设支点在 μ，质量 m_2 集中在 $k\mu$、质量 m_1 集中在 0（非负性允许的最左端）。

1. 力矩平衡：$m_1 \cdot \mu = m_2 \cdot (k\mu - \mu) = m_2(k-1)\mu$，故 $m_1 = (k-1)m_2$。
2. 总质量归一：$m_1 + m_2 = 1$，代入得 $(k-1)m_2 + m_2 = km_2 = 1$，故 $m_2 = 1/k$。
3. 即 $\Pr[X \geq k\mu] \leq 1/k$。脚本验算：$k = 2 \to m_2 = 1/2$，$m_1 = 1/2$；$k = 5 \to m_2 = 0.2$，$m_1 = 0.8$；$k = 10 \to m_2 = 0.1$，$m_1 = 0.9$。**两组质量之和恒为 1** ✓。

反例（非负性不可省）：马尔可夫不等式要求 $X \geq 0$，去掉这个条件命题就**失效**。

构造：$\Pr[X = -10] = 0.9$，$\Pr[X = 100] = 0.1$。则 $\mathbb{E}[X] = 0.9(-10) + 0.1(100) = -9 + 10 = 1$。取 $c = 50$：

- 左边：$\Pr[X \geq 50] = 0.1$；
- 右边：$\mathbb{E}[X]/c = 1/50 = 0.02$。

$0.1 \leq 0.02$ **是假的**——马尔可夫不等式彻底失效。（脚本验算通过）再看一个更极端的：$\Pr[X = -100] = 0.5$，$\Pr[X = 1] = 0.5$，则 $\mathbb{E}[X] = -49.5$，取 $c = 0.5$ 时右边是 -99，一个**负数**不可能上界一个概率。根因很清楚：证明第 3 步丢掉负数项时方向反了。

教益：任何形如"$\Pr[X \geq c] \leq (\text{某均值})/c$"的论断，都默认了非负性。要处理一般变量，必须改用绝对值形式（定理 23.2）。

二、广义马尔可夫不等式（处理任意变量）

定理 23.2（广义马尔可夫不等式 / Generalized Markov）：设 Y 是**任意**随机变量（不要求非负），期望有限。则对任意常数 $c > 0$ 与 $r > 0$，

$$\Pr\left[|Y| \geq c\right] \leq \frac{\mathbb{E}\left[|Y|^r\right]}{c^r}.$$

证明策略：**化归**。把定理 23.1 用到非负随机变量 $|Y|^r$ 上。关键观察是 $|Y|^r \geq 0$ 自动成立（绝对值非负 + $r > 0$），所以非负性条件被"免费"满足了。

逐步推导：

1. 对每个 ω，考虑量 $|Y(\omega)|^r$。因为 $|Y(\omega)| \geq 0$ 且 $r > 0$，有 $|Y(\omega)|^r \geq 0$。（依据：正数的正数次幂非负）
2. 套用"指示变量下界"模板。先做一个两步放缩：

$$|Y|^r \;\geq\; |Y|^r \mathbb{I}\{|Y| \geq c\} \;\geq\; c^r \mathbb{I}\{|Y| \geq c\}.$$

第一处：当 $|Y| < c$ 时指示为 0，左边 ≥ 0 = 右边 ✓；当 $|Y| \geq c$ 时指示为 1，两边都是 $|Y|^r$ ✓。第二处：在事件 $\{|Y| \geq c\}$ 上 $|Y|^r \geq c^r$；在事件外两边都是 0 ✓。 **注意：若 $r < 0$，第二处不等号方向会反过来**（因为 $x \mapsto x^r$ 在 $r < 0$ 时递减），所以 $r > 0$ 是必需的。 3. 取期望（逐点不等式 + 非负权重）：

$$\mathbb{E}\left[|Y|^r\right] \;\geq\; c^r\, \mathbb{E}\left[\mathbb{I}\{|Y| \geq c\}\right] \;=\; c^r \Pr\left[|Y| \geq c\right].$$

1. 除以 $c^r > 0$：$\Pr[|Y| \geq c] \leq \frac{\mathbb{E}[|Y|^r]}{c^r}$。■

【证明机制解说】：这是**"选取合适的 r 来定制界"**的典范。不同的 r 给出不同的界，我们可以在具体问题里挑最好的那个：

- $r = 1$：$\Pr[|Y| \geq c] \leq \mathbb{E}[|Y|]/c$——用一阶绝对矩；
- $r = 2$：$\Pr[|Y| \geq c] \leq \mathbb{E}[Y^2]/c^2$——用二阶矩，**取 $Y = X - \mu$ 就是切比雪夫不等式**；
- 一般 r：用 r 阶矩。r 越大，若高阶矩增长不快（例如指数尾分布），界越紧。

这个**"用高阶矩换更紧的尾界"**的思路，正是切尔诺夫界"用无穷阶矩（即 $\mathbb{E}[e^{tX}]$）"的思想雏形。**一句话概括：马尔可夫不等式是一个模板，r 是旋钮。**

小算例：Y 均匀取 $\{-1, 0, 1\}$。$\mathbb{E}[|Y|] = 2/3$，$\mathbb{E}[|Y|^2] = 2/3$，$\mathbb{E}[|Y|^3] = 2/3$。取 $c = 1$：三个 r 都给出界 $2/3$，而实际 $\Pr[|Y| \geq 1] = 2/3$——**取到等号**。取 $c = 2$：界为 $(2/3)/4 = 1/6$，实际 $\Pr[|Y| \geq 2] = 0$ ✓。取 $c = 0.5$：界为 $(2/3)/0.25 = 2.667 > 1$——**空洞界**，说明 c 太小时不等式毫无信息。（脚本验算通过）

三、切比雪夫不等式

定理 23.3（切比雪夫不等式 / Chebyshev's Inequality）：设随机变量 X 的期望 $\mathbb{E}[X] = \mu$ 与方差 $\mathbf{Var}(X)$ 均有限。则对任意常数 $c > 0$，

$$\Pr\left[|X - \mu| \geq c\right] \leq \frac{\mathbf{Var}(X)}{c^2}.$$

证明策略（证法一：化归到马尔可夫）：**构造性化归**。定义新变量 $Y = (X - \mu)^2$，它**天然非负**，于是可以套用马尔可夫不等式。关键观察是"$|X - \mu| \geq c$"与"$(X - \mu)^2 \geq c^2$"是**同一个事件**——绝对值和平方只是把偏离量做了单调变换，事件本身没变。

逐步推导（证法一）：

1. 定义 $Y = (X - \mu)^2$。对每个 ω，$Y(\omega) = (X(\omega) - \mu)^2 \geq 0$，故 Y 非负 ✓。

2. 算 Y 的期望：$\mathbb{E}[Y] = \mathbb{E}\left[(X-\mu)^2\right] = \mathbf{Var}(X)$。（依据：方差的定义）
3. **事件等价**：对每个 ω，$|X(\omega)-\mu| \geq c \iff (X(\omega)-\mu)^2 \geq c^2$（因为两边都非负，平方是 $[0,\infty)$ 上的严格增函数）。故

$$\mathbf{Pr}[|X-\mu| \geq c] = \mathbf{Pr}[Y \geq c^2].$$

1. 对非负变量 Y 与阈值 $c^2 > 0$ 套用马尔可夫不等式（定理 23.1）：

$$\mathbf{Pr}[Y \geq c^2] \leq \frac{\mathbb{E}[Y]}{c^2} = \frac{\mathbf{Var}(X)}{c^2}.$$

1. 合并第 3、4 步即得结论。■

逐步推导（证法二：广义马尔可夫，一行完事）：取 $Y = X-\mu$，注意 $|Y|^2 = (X-\mu)^2$，故 $\mathbb{E}[|Y|^2] = \mathbf{Var}(X)$。对 Y 用定理 23.2（取 $r=2$）直接得到结论。■

【证明机制解说】：切比雪夫不等式的全部内容就是"**把偏离量平方，然后对它用马尔可夫**"。这一步转换之所以合法，是因为平方在非负数上是**单调**的——事件"偏离超过 c"与事件"平方偏离超过 c^2"完全一致。请务必体会：**这不是一个深奥的证明，而是一个精妙的化归**。它的力量来自马尔可夫不等式的普适性：只要我们能造出一个非负变量，就能控制它。

推论 23.3.1（以标准差为单位）：设 $\sigma = \sqrt{\mathbf{Var}(X)} > 0$。则对任意 $k > 0$，

$$\mathbf{Pr}\left[|X-\mu| \geq k\sigma\right] \leq \frac{1}{k^2}.$$

证明：在定理 23.3 中取 $c = k\sigma$，右端为 $\mathbf{Var}(X)/(k^2\sigma^2) = \sigma^2/(k^2\sigma^2) = 1/k^2$。■

具体数值：

k	界 $1/k^2$	含义
1	1	空洞界（没有信息）
2	0.25	偏离 2 个标准差以上至多 1/4
3	0.111	至多约 11%
4	0.0625	至多 6.25%
10	0.01	至多 1%

紧性讨论：切比雪夫**不能**在一般情况下取到等号（这与马尔可夫不同），但对某些 c 可以。取 $X = \pm c$ 各以概率 $1/2$：$\mu = 0$，$\mathbf{Var}(X) = c^2$，$\mathbf{Pr}[|X| \geq c] = 1$，而界是 $c^2/c^2 = 1$——**取到等号**。再取 X 均匀取 $\{-1, 0, 1\}$、$c = 1$：$\mu = 0$，$\mathbf{Var}(X) = 2/3$，$\mathbf{Pr}[|X| \geq 1] = 2/3$，界是 $(2/3)/1 = 2/3$——**也取到等号**。（脚本验算通过）但取 $c = 1.5$ 时界为 $(2/3)/2.25 \approx 0.296$ 而实际概率为 0——**松了**。所以切比雪夫是"逐点紧"但"整体不紧"。

反例式对比（界有多松）：$n = 1000$ 次公平抛硬币，$\mathbf{Pr}[X \geq 600] = 1.3642 \times 10^{-10}$，切比雪夫的界 0.025 大了 1.8×10^8 倍。**这不说明切比雪夫错，只说明它在 n 大时不够用**——要用切尔诺夫。

四、切尔诺夫界（矩生成函数机制）

定理 23.4（切尔诺夫界，上尾 / Chernoff Bound）：设 $X_1, \ldots, X_n$ **相互独立**，每个 $X_i \in \{0,1\}$，$\mathbf{Pr}[X_i = 1] = p_i$。记 $X = \sum_{i=1}^n X_i$，$\mu = \mathbb{E}[X] = \sum_{i=1}^n p_i$。则对任意 $\delta > 0$，

$$\mathbf{Pr}\left[X \geq (1+\delta)\mu\right] \leq \left(\frac{e^{\delta}}{(1+\delta)^{1+\delta}}\right)^{\mu}.$$

定理 23.5（下尾）：在同样假设下，对任意 $\delta \in (0,1)$，

$$\mathbf{Pr}\left[X \leq (1-\delta)\mu\right] \leq \left(\frac{e^{-\delta}}{(1-\delta)^{1-\delta}}\right)^{\mu}.$$

证明策略：化归到马尔可夫 + 参数优化。三步走：① 对**任意** $t > 0$，事件 $\{X \geq a\}$ 等价于 $\{e^{tX} \geq e^{ta}\}$；② e^{tX} 恒为正，于是可以套用马尔可夫不等式，得到 $\mathbf{Pr}[X \geq a] \leq e^{-ta}\,\mathbb{E}[e^{tX}]$；③ 用独立性把 $\mathbb{E}[e^{tX}]$ 分解成乘积并逐项放缩，最后**对 t 取下确界**得到最好的界。

逐步推导（上尾）：

1. 对任意 $t > 0$，$\{X \geq a\} \iff \{tX \geq ta\} \iff \{e^{tX} \geq e^{ta}\}$。（依据：$x \mapsto tx$ 与 $x \mapsto e^x$ 都是严格增函数）
2. $e^{tX} > 0$ 恒成立，故可对非负变量 e^{tX} 与阈值 $e^{ta} > 0$ 用马尔可夫不等式（定理 23.1）：

$$\mathbf{Pr}[X \geq a] = \mathbf{Pr}\left[e^{tX} \geq e^{ta}\right] \leq \frac{\mathbb{E}\left[e^{tX}\right]}{e^{ta}} = e^{-ta}\,\mathbb{E}\left[e^{tX}\right]. \qquad (*)$$

1. **计算矩生成函数 (moment generating function)** $\mathbb{E}[e^{tX}]$。由 $X_1, \ldots, X_n$ 独立，$e^{tX_1}, \ldots, e^{tX_n}$ 也独立（独立变量的函数仍独立），故

$$\mathbb{E}\left[e^{tX}\right] = \mathbb{E}\left[\prod_{i=1}^n e^{tX_i}\right] = \prod_{i=1}^n \mathbb{E}\left[e^{tX_i}\right].$$

（依据：定理 22.4 的推广——独立变量之积的期望等于期望之积） 4. 逐项计算。X_i 只取 0 或 1，故 $e^{tX_i} = 1$ 当 $X_i = 0$、$= e^t$ 当 $X_i = 1$：

$$\mathbb{E}\left[e^{tX_i}\right] = (1-p_i)\cdot 1 + p_i \cdot e^t = 1 + p_i(e^t - 1).$$

1. 用基本不等式 $1 + x \le e^x$（对一切实数 x 成立，脚本验算：$x = 0.1 \to 1.1 \le 1.105$；$x = 1 \to 2 \le 2.718$；$x = 2 \to 3 \le 7.389$ ✓）放缩：

$$\mathbb{E}\left[e^{tX_i}\right] = 1 + p_i(e^t - 1) \le e^{\,p_i(e^t-1)}.$$

1. 连乘回去：

$$\mathbb{E}\left[e^{tX}\right] \le \prod_{i=1}^{n} e^{\,p_i(e^t-1)} = \exp\left((e^t-1)\sum_{i=1}^{n} p_i\right) = e^{\,\mu(e^t-1)}.$$

1. 代入 $(*)$ 式：

$$\Pr[X \ge a] \le e^{-ta+\mu(e^t-1)}. \qquad (\forall t > 0)$$

1. **对 t 优化**（这是"参数优化"的关键一步）。设 $a = (1+\delta)\mu$。把右端写成 $e^{g(t)}$，其中 $g(t) = -t(1+\delta)\mu + \mu(e^t - 1) = \mu\left(e^t - 1 - (1+\delta)t\right)$。对 t 求导：$g'(t) = \mu\left(e^t - (1+\delta)\right)$，令其为 0 得驻点 $t^\star = \ln(1+\delta)$。
2. 二阶导 $g''(t) = \mu e^t > 0$，故 $t^\star$ 是极小点，给出最紧的界。代入 $g(t^\star)$：

$$g(t^\star) = \mu\left((1+\delta) - 1 - (1+\delta)\ln(1+\delta)\right) = \mu\left(\delta - (1+\delta)\ln(1+\delta)\right).$$

1. 因此

$$\Pr[X \ge (1+\delta)\mu] \le \exp\left(\mu\left[\delta - (1+\delta)\ln(1+\delta)\right]\right) = \left(\frac{e^\delta}{(1+\delta)^{1+\delta}}\right)^{\mu}. \blacksquare$$

【证明机制解说】：整个证明的精髓是第 1 步的"**指数化**"。直接对 X 用马尔可夫是没用的（X 不是非负？其实是，但 $\Pr[X \ge a] \le \mu/a$ 太松）。指数化之所以有效，是因为**指数把"和"变成"积"**：$e^{t\sum X_i} = \prod e^{tX_i}$，而独立性恰好允许我们把乘积的期望拆开。**如果 X_i 不独立，第 3 步立刻崩掉**——这就是切尔诺夫需要独立性的确切原因。第 8 步的"对 t 优化"则是把所有合法 t 的界取最小的那个；由于 g 是凸函数，极小点可以解析求出，于是得到一个闭式指数。

一句话记住机制：马尔可夫 + 指数变换 + 独立性 + 对 t 求极小 = 指数衰减的尾界。

简化形式的推导：

1. 上尾：先证一个纯代数不等式。对 $0 < \delta < 1$，有

$$\delta - (1+\delta)\ln(1+\delta) \le -\frac{\delta^2}{3}.$$

（证明思路：两边在 $\delta = 0$ 处相等且都是 0，比较导数即可；也可借助 $\ln(1+\delta)$ 的泰勒展开 $\delta - \frac{\delta^2}{2} + \frac{\delta^3}{3} - \cdots$）代入第 10 步得

$$\Pr[X \ge (1+\delta)\mu] \le e^{-\mu\delta^2/3}.$$

1. 下尾：同理可证 $-\delta - (1-\delta)\ln(1-\delta) \le -\frac{\delta^2}{2}$（$0 < \delta < 1$），于是

$$\Pr[X \le (1-\delta)\mu] \le e^{-\mu\delta^2/2}. \blacksquare$$

数值校验（脚本验算，n 次公平抛硬币，$p = 1/2$，$\mu = n/2$）：

n	δ	精确 $\Pr[X \ge (1+\delta)\mu]$	精确形式界	$e^{-\mu\delta^2/3}$	界是否有效
100	0.2	2.8444×10^{-2}	0.3909	0.5134	✓
1000	0.2	1.3642×10^{-10}	8.331×10^{-5}	1.2726×10^{-3}	✓

注意到一个重要现象：$n = 100$ 时切比雪夫的界 0.25 比切尔诺夫的界 0.3909 更紧！这是因为 $e^{-\mu\delta^2/3}$ 在 μ 小时衰减不够快，而 $\mathrm{Var}/(\delta\mu)^2 = 1/(4\delta^2\mu)$ 里有 $1/\mu$ 因子。**所以不能说"切尔诺夫永远优于切比雪夫"**：μ 小时切比雪夫可能更好，μ 大时切尔诺夫压倒性胜出（$n = 1000$ 时切尔诺夫比切比雪夫紧 300 倍，且差距随 n 指数扩大）。**选择界的正确做法是比较两者的指数增长率，而不是背"谁更强"。**

指数增长率对比（脚本验算，$n = 1000$，$\delta = 0.2$）：

```
在同一例子 (n=1000 次公平硬币, 问 P[X >= 600]) 上比较三个界的"指数尺度"

方法                    上界              ln(上界)      相对真值的倍数
------------------------------------------------------------------
精确枚举            1.3642e-10       -22.715           1
马尔可夫            8.3333e-01        -0.182        6.1e+09
切比雪夫            2.5000e-02        -3.689        1.8e+08
切尔诺夫(简化)      1.2726e-03        -6.667        9.3e+06
切尔诺夫(精确)      8.3311e-05        -9.393        6.1e+05
霍夫丁               2.0612e-09       -20.000           15
------------------------------------------------------------------
要点: 马尔可夫与切比雪夫的 ln(界) 只随 n 缓慢变化 (多项式衰减),
      切尔诺夫的 ln(界) 正比于 -mu*delta^2 = -n*0.02 (线性, 即指数衰减)。
      这就是"指数尾界"与"多项式尾界"的本质差别。
------------------------------------------------------------------
```

霍夫丁界 (Hoeffding's Bound)（补充）：对独立有界变量 $X_i \in [a_i, b_i]$，

$$\Pr\left[\left|\frac{1}{n}\sum_{i=1}^{n} X_i - \mu\right| \geq \epsilon\right] \leq 2\exp\left(-\frac{2n^2\epsilon^2}{\sum_{i=1}^{n}(b_i - a_i)^2}\right).$$

对 $\{0,1\}$ 变量（$b_i - a_i = 1$）简化为 $2e^{-2n\epsilon^2}$。脚本验算：$n = 1000$、$\epsilon = 0.1$ 时 $e^{-2\cdot 1000\cdot 0.01} = 2.061 \times 10^{-9}$，与真值 1.364×10^{-10} 只差 15 倍——**这是本表中最好的界**，而且它连 μ 都不需要知道！它在 CS70 之外的算法课程中是标准工具。

五、弱大数定律

定理 23.6（弱大数定律 / Weak Law of Large Numbers）：设 $X_1, X_2, \ldots$ 是 i.i.d. 随机变量，公共期望 $\mathbb{E}[X_i] = \mu$，公共方差 $\mathbf{Var}(X_i) = \sigma^2 < \infty$。记 $S_n = X_1 + \cdots + X_n$。则对任意 $\epsilon > 0$，

$$\Pr\left[\left|\frac{1}{n}S_n - \mu\right| \geq \epsilon\right] \leq \frac{\sigma^2}{n\epsilon^2} \xrightarrow[n\to\infty]{} 0,$$

从而 $\Pr\left[\left|\frac{1}{n}S_n - \mu\right| < \epsilon\right] \to 1$。也就是说，样本均值 $\frac{1}{n}S_n$ **依概率收敛 (converges in probability)** 到 μ。

证明策略：**直接证明 + 切比雪夫不等式**。整个证明只有两个动作：① 算出样本均值这个新随机变量的期望与方差；② 对它套切比雪夫不等式。之所以选切比雪夫而不是别的，是因为我们**只知道 μ 和 σ^2** 这两个信息——切比雪夫恰好只需要这两个。

逐步推导：

1. **样本均值的期望**。由期望线性性（**不需要独立性**）：

$$\mathbb{E}\left[\frac{1}{n}S_n\right] = \frac{1}{n}\sum_{i=1}^{n}\mathbb{E}[X_i] = \frac{1}{n}\cdot n\mu = \mu.$$

即样本均值是 μ 的**无偏估计 (unbiased estimator)**：它平均而言正好落在目标上。 2. **样本均值的方差**。分三步：

- 由缩放法则 $\mathbf{Var}(aX) = a^2\,\mathbf{Var}(X)$（取 $a = 1/n$，**注意平方**）：

$$\mathbf{Var}\left(\frac{1}{n}S_n\right) = \frac{1}{n^2}\mathbf{Var}(S_n).$$

- 由方差的独立可加性（定理 22.5 的推广）：

$$\mathbf{Var}(S_n) = \sum_{i=1}^{n}\mathbf{Var}(X_i) = n\sigma^2.$$

- 合并：

$$\mathbf{Var}\left(\frac{1}{n}S_n\right) = \frac{1}{n^2}\cdot n\sigma^2 = \frac{\sigma^2}{n}.$$

这是整个证明的核心等式：方差随 n **线性衰减**，标准差按 $1/\sqrt{n}$ 衰减。 3. **套用切比雪夫不等式**。对随机变量 $\frac{1}{n}S_n$（其期望为 μ、方差为 σ^2/n），取 $c = \epsilon > 0$：

$$\Pr\left[\left|\frac{1}{n}S_n - \mu\right| \geq \epsilon\right] \leq \frac{\mathbf{Var}\left(\frac{1}{n}S_n\right)}{\epsilon^2} = \frac{\sigma^2}{n\epsilon^2}.$$

1. **取极限**。σ^2 与 ϵ 都是固定常数，故 $n \to \infty$ 时 $\frac{\sigma^2}{n\epsilon^2} \to 0$。
2. **转换为"接近"的概率**。由补事件：

$$\Pr\left[\left|\frac{1}{n}S_n - \mu\right| < \epsilon\right] = 1 - \Pr\left[\left|\frac{1}{n}S_n - \mu\right| \geq \epsilon\right] \geq 1 - \frac{\sigma^2}{n\epsilon^2} \xrightarrow[n\to\infty]{} 1. \blacksquare$$

【证明机制解说】：证明的"灵光一现"是第 2 步——**方差的 $\frac{1}{n^2}$ 因子与独立可加性带来的 n 因子相抵，留下 $\frac{\sigma^2}{n}$**。这个 $\frac{1}{n}$ 是全部魔力的来源：

```
为什么平均能消除随机性?
------------------------------------------------------------
求和 S_n      :  均值 = n*mu        (增长 n 倍)
                 方差 = n*sigma^2   (增长 n 倍)
                 => 标准差 = sqrt(n)*sigma  (只增长 sqrt(n) 倍)
------------------------------------------------------------
相减看"信号/噪声"比:
   信号 (均值)   ~ n
   噪声 (标准差) ~ sqrt(n)
   比值          ~ sqrt(n)  -> 无穷大
------------------------------------------------------------
取平均 (1/n)S_n :
                 均值 = mu          (不变，信号锁定在 mu)
                 方差 = sigma^2/n   (衰减到 0)
                 => 标准差 = sigma/sqrt(n)  -> 0，噪声被压平
------------------------------------------------------------
```

与 L15 概率定义的关系（重要）：L15 把概率公理化时，我们默认了"概率 = 长期频率"这一解释，但**当时没有证明它**。弱大数定律补上了这个证明：取 $X_i = \mathbb{1}\{\text{第 } i \text{ 次试验中事件 } A \text{ 发生}\}$，则 $\mathbb{E}[X_i] = \Pr[A] = p$，$\mathrm{Var}(X_i) = p(1-p)$，而 $\frac{1}{n}S_n$ 就是**观测到的频率**。定理 23.6 断言这个频率依概率收敛到 p。**所以"概率可以定义为大量重复实验的频率极限"不是一条公理假设，而是一条可证的定理。** 这为整个频率学派概率论提供了合法性。

注意"方差有限"这一条件：证明假定了 $\sigma^2 < \infty$。若方差无穷（例如柯西分布），弱大数定律**仍然成立**（可以用截断技巧证明），但本课程的工具不够，需要更高级的数学。**不要把"方差有限"当成定理的必要条件**——它只是这个证明的必要条件。

与经典问题的联系

应用一：估计硬币的偏差（随机化算法可靠性的原型）

问题设定：有一枚硬币，真实偏差 p 未知。抛 n 次，观测到 S_n 次正面，用频率 $\hat{p} = \frac{1}{n}S_n$ 估计 p。问：**n 要多大，才能保证 $\hat{p}$ 与 p 的差距不超过 ϵ?**

第一步：明确"保证"的含义（这是本问题的关键一步）。我们**永远无法绝对保证** $|\hat{p} - p| \le \epsilon$！因为 S_n 可以取 0 到 n 的任何值，无论 p 是多少，都存在"n 次全是正面"（概率 $p^n > 0$）导致 $\hat{p} = 1$，"n 次全是反面"（概率 $(1-p)^n > 0$）导致 $\hat{p} = 0$ 的情形。**只要概率为正，就不能说"绝不会发生"。**

所以必须放松要求：改为要求"以高概率接近"，即给定**误差容限** $\epsilon \in (0,1)$ 与**置信参数** $\delta \in (0,1)$，要求

$$\Pr\left[|\hat{p} - p| \le \epsilon\right] \ge 1 - \delta.$$

用一句话说：**"我愿意容忍 ϵ 的误差，也愿意接受 δ 的失败概率；请给我一个够大的 n。"** 这是所有随机化算法可靠性论证的标准框架——**从"绝对正确"退到"高概率正确"**。

第二步：数学建模。设 $X_i = \mathbb{1}\{\text{第 } i \text{ 次抛掷为正面}\}$，则 X_i 独立同分布、$\mathbb{E}[X_i] = p$、$\mathrm{Var}(X_i) = p(1-p)$，且 $\hat{p} = \frac{1}{n}S_n$。由应用前的推导，

$$\mathbb{E}[\hat{p}] = p, \qquad \mathrm{Var}(\hat{p}) = \frac{p(1-p)}{n}.$$

第三步：用切比雪夫给出样本复杂度。取 $c = \epsilon$：

$$\Pr\left[|\hat{p} - p| \ge \epsilon\right] \le \frac{\mathrm{Var}(\hat{p})}{\epsilon^2} = \frac{p(1-p)}{n\epsilon^2}.$$

要让它 $\le \delta$，只需

$$n \ge \frac{p(1-p)}{\epsilon^2 \delta}.$$

第四步：去掉对未知 p 的依赖（关键技巧）。上式右边含未知的 p。但我们知道 $p(1-p)$ 在 $p = 1/2$ 处取最大值 $1/4$（用微积分：$\frac{d}{dp}p(1-p) = 1 - 2p$，令其为 0 得 $p = 1/2$；或配方 $p(1-p) = 1/4 - (p - 1/2)^2 \le 1/4$）。因此**只要取最坏情况的上界**：

$$n \ge \max_{p \in (0,1)} \frac{p(1-p)}{\epsilon^2\delta} = \frac{1}{4\epsilon^2\delta}.$$

这个 n 对一切未知的真值 p 都够用——这才是"不依赖精确分布"的真正含义：**我们不需要知道 p，只需要知道"$p(1-p) \le 1/4$"这一先验事实。**（这与 L22 中"伯努利方差最大值为 1/4"完全对应。）

具体数值（脚本验算）：

ϵ	δ	所需 $n \ge \frac{1}{4\epsilon^2\delta}$	达到的置信度
0.1	0.05	500	95%
0.1	0.01	2500	99%
0.05	0.05	2000	95%
0.01	0.05	50000	95%

核实 $\epsilon = 0.1, \delta = 0.05$ 的 $n = 500$：界给出 $\frac{p(1-p)}{500 \cdot 0.01} \le \frac{0.25}{5} = 0.05 = \delta$ ✓（脚本验算通过）。而真值（取最坏的 $p = 1/2$）是 $\Pr[|\hat{p} - 0.5| \ge 0.05] = 2.83 \times 10^{-2}$，**远小于 0.05**——切比雪夫的界相当保守，但也相当安全。（对比 $n = 100$：界为 1.0，即完全空洞；真值为 0.271。可见 n 太小时界毫无用处。）

第五步：现实意义（为什么这条结论惊人）。考虑"估计美国人口中民主党人的比例"：把每个人看作一次抛硬币，p 是真实比例。上面的计算说：**要保证误差 ≤ 0.1、置信度 $\ge 95\%$，抽 500 人就够了。**

注意 n 与总人口无关！ 美国有 3 亿多人，抽 500 人就够；人口变成 10 亿，还是 500 人。这解释了为什么民调机构只调查一两千人就能对几亿人做出有意义的预测。**根本原因**：$\hat{p}$ 的方差是 $\frac{p(1-p)}{n}$，只含样本量 n，与总体大小 N 无关（前提是"有放回"抽样，即每次独立地从全体中抽人）。

应用二：估计一般期望（蒙特卡洛方法）

问题推广：要估计的不再是 $0/1$ 事件的概率，而是任意分布的期望。例如"估计美国人的平均财富 μ"。

方案设计：从**未知分布**中独立抽样 $X_1, \ldots, X_n$（每个人的财富就是一个样本），用样本均值

$$\hat{\mu} = \frac{1}{n}\sum_{i=1}^{n} X_i$$

估计 μ。由应用一的推导，$\mathbb{E}[\hat{\mu}] = \mu$，$\mathbf{Var}(\hat{\mu}) = \frac{\sigma^2}{n}$（其中 $\sigma^2 = \mathbf{Var}(X_i)$）。切比雪夫给出

$$\Pr\left[|\hat{\mu} - \mu| \geq \epsilon\right] \leq \frac{\sigma^2}{n\epsilon^2}.$$

注意实际用到的假设很弱：只需要 X_i **独立、同期望、同方差。连"同分布"都不是必需的**（只需要相同的 μ 与 σ^2）。

关键改动：用相对误差。财富问题里 μ 可能很大（几万美元），绝对误差 ϵ 没有意义——误差 1000 美元对平均财富 2 万美元是 5%，对 20 万美元只是 0.5%。所以改成**相对误差** $\epsilon\mu$：

$$\Pr\left[|\hat{\mu} - \mu| \geq \epsilon\mu\right] \leq \frac{\sigma^2}{n(\epsilon\mu)^2} = \frac{1}{n\epsilon^2} \cdot \frac{\sigma^2}{\mu^2}.$$

要让它 $\leq \delta$，需要

$$n \geq \frac{\sigma^2}{\mu^2} \cdot \frac{1}{\epsilon^2\delta} = \frac{\mathrm{CV}^2}{\epsilon^2\delta},$$

其中 $\mathrm{CV} = \sigma/\mu$ 是**变异系数 (coefficient of variation)**。**结论：相对误差所需的样本量由变异系数决定，与 μ 的绝对大小无关。** 这是蒙特卡洛方法的理论基础。

具体数值（脚本验算）：取 $\mu=$20{,}000。假设人口中有一位财富$50亿的人，人口N=3.25\times10^8$。则

$$\sigma^2 \geq \frac{(50 \times 10^9)^2}{325 \times 10^6} \approx 7.69 \times 10^{12}.$$

（理由：方差至少要把这一个极端值的贡献计入，即 $\frac{1}{N}(x_{\max} - \mu)^2$）

于是 $\mathrm{CV}^2 = \frac{7.69 \times 10^{12}}{(2 \times 10^4)^2} \approx 19{,}250$。取 $\epsilon = 0.1$、$\delta = 0.05$：

$$n \geq \frac{19250}{0.01 \times 0.05} = 3.85 \times 10^7.$$

需要三千八百五十万个样本！ 对比应用一里只需 500 个样本——差 7 万多倍。

为什么？根本原因在于重尾 (heavy tail)：一旦总体中存在极富有的人，σ^2/μ^2 就爆炸。**均匀抽样无法解决这个问题**：样本里几乎不可能抽到亿万富翁（概率 $\approx n/N$），因此估计值会系统性偏低；而要让它有像样的概率被抽中，n 就得大到不可接受。这是**统计估计的根本困难，不是切比雪夫界太松造成的**——即使用精确分布计算也一样。**"随机抽样对重尾分布失效"是蒙特卡洛方法的真实局限。** 实际做法是分层抽样 (stratified sampling) 或重要性抽样 (importance sampling)，或者干脆用中位数代替均值。

应用三：负载均衡与哈希（切尔诺夫界的经典应用）

问题实际背景：把 m 个作业随机分派给 n 台处理器（或把 m 个球随机投入 n 个箱子、把 m 个键哈希到 n 个槽位）。**我们要保证"没有哪台处理器过载"**。

数学建模：设 X_i 为第 i 台处理器收到的作业数。对每个作业，它落在第 i 台的概率是 $1/n$，故

$$X_i \sim \mathrm{Bin}\left(m, \frac{1}{n}\right), \qquad \mathbb{E}[X_i] = \frac{m}{n}, \qquad \mathbf{Var}(X_i) = m \cdot \frac{1}{n}\left(1 - \frac{1}{n}\right).$$

下面取 $m = n$（**最经典的情形**：球数与箱数相同），此时 $\mathbb{E}[X_i] = 1$。

目标：找一个 k，使得**至少有一台处理器负载达到 k** 的概率不超过 $1/2$。记 $A_k(i) = \{X_i \geq k\}$。

方案设计：联合界 (Union Bound) + 切尔诺夫界。

1. **联合界**（官方 Note 18 的做法；它的概率版本由 L18 的容斥/并集界给出）："存在某台过载"是各 $A_k(i)$ 的并集，故

$$\Pr\left[\bigcup_{i=1}^{n} A_k(i)\right] \leq \sum_{i=1}^{n} \Pr[A_k(i)] = n \Pr[A_k(1)].$$

（依据：$\Pr[A \cup B] \leq \Pr[A] + \Pr[B]$，即 L18 的并集界 / Union Bound） 2. **单台过载概率的切尔诺夫界**。$X_1 \sim \mathrm{Bin}(n, 1/n)$，$\mu = 1$。对 $k > 1$ 取 $\delta = k - 1$（即 $k = (1+\delta)\mu$），由定理 23.4：

$$\Pr[X_1 \geq k] \leq \left(\frac{e^{k-1}}{k^k}\right) \leq \left(\frac{e}{k}\right)^k$$

（第二个不等号用 $e^{k-1} \leq e^k$ 与 k^k 相除得到；官方 Note 18 用 $\binom{n}{j} \leq (ne/j)^j$ 与几何级数求和得到形如 $2(e/k)^k$ 的界，二者本质相同。为简单起见我们用 $\left(\frac{e}{k}\right)^k$。） 3. **合并**：$\Pr[\text{存在过载}] \leq n\left(\frac{e}{k}\right)^k$。要它 $\leq \frac{1}{2}$，只需（更保守地）取

$$\left(\frac{e}{k}\right)^k \leq \frac{1}{4n}. \qquad (\star)$$

1. **求解 k**。对 $(\star)$ 两边取对数：$k(\ln e - \ln k) \leq -\ln(4n)$，即 $k \ln k - k \geq \ln(4n)$。用**粗放的斯特林近似** $\ln k! \approx k \ln k - k$，条件变成 $\ln k! \gtrsim \ln(4n)$，即 $k! \gtrsim 4n$。官方 Note 18 用的是化简版 $k! \geq 2n$（对 n 个箱子做联合界时目标为 $1/(2n)$ 的变体），结论都是

$$k \approx \frac{\ln n}{\ln \ln n}.$$

正确性结论：取 k_0 为满足 $(\star)$ 的最小整数，则**以概率至少 $1/2$，最大负载不超过 k_0**。

具体数值（脚本验算）：

n（= 球数 = 箱数）	k_0（满足 $(\star)$ 的最小 k）	$k! \geq 2n$ 的最小 k	$\frac{\ln n}{\ln\ln n}$
10^3	8	7	3.57
10^5	10	9	4.71
10^6	11	10	5.26
10^8	13	12	6.32
3.5×10^8	14	13	6.60

官方 Note 的著名"彩蛋"：设美国总人口约 3.5 亿。寄出 3.5 亿封垃圾邮件，每封随机填一个美国地址。则**以概率至少 $1/2$，没有任何人收到超过大约一打（约 12 封）**！上表 $n = 3.5 \times 10^8$ 对应的 $k_0 = 14 \approx$ "一打"。这个例子生动说明了 $\frac{\ln n}{\ln\ln n}$ 增长得多么缓慢——人口翻了 10^5 倍（从 10^3 到 10^8），最大负载只从 8 涨到 13。

为什么这个结论重要：

- 它证明**随机哈希是好的**：即使完全不做任何协调，随机分派就能让最大负载只有 $O(\log n / \log\log n)$，而平均负载是 1。**"随机化可以替代中心化调度"**，这是分布式系统（一致性哈希、负载均衡器、布谷鸟哈希）的理论基石。
- 它是 L20（期望）→ L22（方差）→ L23（集中不等式）链条的终点：L20 只能算出 $\mathbb{E}[X_i] = 1$（"平均每台 1 个作业"），完全不能排除"某台有 100 个"；只有切尔诺夫界才能给出"最大值约 11"这种**关于最大值的**（而非平均值的）保证。
- **注意切尔诺夫在这里不可替代**：若用切比雪夫，$\Pr[X_1 \geq k] \leq \frac{1}{(k-1)^2}$，联合界给 $n/(k-1)^2 \leq 1/2$，解得 $k \approx \sqrt{2n}$——**是多项式而非对数**！$n = 3.5 \times 10^8$ 时切比雪夫给出 $k \approx 26000$，与真实的 14 相差三个数量级。**这就是指数尾界与多项式尾界在工程上的实际差距。**

与其他讲次的关联

- **与 L15（概率公理）**：L15 建立概率公理体系时，"概率 = 长期频率"只是一个直觉解释，并未证明。本讲的弱大数定律（定理 23.6）**证明了**它：$X_i = \mathbb{1}\{A \text{ 在第 } i \text{ 次发生}\}$ 时，$\frac{1}{n}S_n$ 依概率收敛到 $\Pr[A]$。这是频率学派概率论合法性的来源，也是本讲与 L15 之间最重要的关联。
- **与 L18（独立性与事件组合）**：马尔可夫不等式的指示变量证法、以及负载均衡应用里的**联合界 (Union Bound)** $\Pr[\bigcup A_i] \leq \sum \Pr[A_i]$，都直接来自 L18 的事件组合工具。没有联合界，就无法从"单台处理器的负载界"推广到"最大负载的界"。
- **与 L19（随机变量与离散分布）**：本讲所有算例都建立在 L19 的分布之上——公平硬币的 $X \sim \text{Bin}(n, 1/2)$、负载均衡的 $X_i \sim \text{Bin}(n, 1/n)$、指示变量的 $\text{Ber}(p)$。应用三里"$X_1 \sim \text{Bin}(n, 1/n)$"这一步就是把"$n$ 个球独立落入第 1 个箱子"识别为二项分布。
- **与 L20（期望与线性性）**：马尔可夫不等式只用到 $\mathbb{E}[X]$，是期望信息的极限使用案例；弱大数定律证明的第 1 步（$\mathbb{E}[\frac{1}{n}S_n] = \mu$）纯靠期望线性性，**不需要独立**；而切尔诺夫界中 $\mathbb{E}[e^{tX}] = \prod \mathbb{E}[e^{tX_i}]$ 则用了 L20/L21 的独立变量乘积期望法则。
- **与 L21（联合分布与独立性）**：切尔诺夫界要求 X_i **相互独立**（证明第 3 步拆乘积），这是 L21 独立性定义在尾界分析中的直接应用；"估计一般期望"中"X_i 只需独立同期望同方差"也是 L21 独立性概念的精度练习。
- **与 L22（方差与协方差）**：本讲是 L22 的直接延续与兑现。切比雪夫不等式就是"把 Var 翻译成概率界"；弱大数定律的关键等式 $\text{Var}(\frac{1}{n}S_n) = \frac{\sigma^2}{n}$ 用到了 L22 的**缩放法则**（注意是 $\frac{1}{n^2}$ 而非 $\frac{1}{n}$）与**独立可加性**（定理 22.5）。**没有 L22，本讲一行都写不出来。**
- **与 L25（正态分布与 CLT）**：本讲的弱大数定律说"$\frac{1}{n}S_n$ 集中在 μ 附近，标准差按 $\sigma/\sqrt{n}$ 缩小"，但**没有说集中后的形状**。中心极限定理补上这一块：标准化后的 $\frac{S_n - n\mu}{\sigma\sqrt{n}}$ 的分布收敛到标准正态 $\mathcal{N}(0,1)$。CLT 的输入恰是本讲的 μ 与 σ^2，而它的输出是远比切比雪夫精确的尾概率估计（例如 $n = 1000$ 时 CLT 能给出 $\Pr[X \geq 600] \approx 10^{-10}$ 量级的准确估计）。
- **与 L14/L16（计数与组合证明）**：切尔诺夫界的原始推导用到了 $\binom{n}{k} \leq (ne/k)^k$ 这类组合不等式（负载均衡应用中官方 Note 正是这样做的），而这属于 L14 的计数技巧与 L16 的组合不等式范畴。
- **与 L03（归纳法）**：官方 Note 18 里负载均衡的界 $2(e/k)^k$ 是通过**"几何级数求和"**得到的，而几何级数求和公式的严格证明正是 L03 归纳法的练习。

关键要点

1. **马尔可夫不等式**：$X \geq 0$、$c > 0$ 时 $\Pr[X \geq c] \leq \frac{\mathbb{E}[X]}{c}$。**条件"非负"不可省，否则命题失效**（反例：$X = -10$ 概率 0.9、$X = 100$ 概率 0.1，取 $c = 50$ 时 $0.1 \not\leq 0.02$）。直觉是"不可能所有人都高于平均分"（取 $c = 2\mathbb{E}[X]$ 得 $\Pr \leq 1/2$）。界是**紧的**（$X = k\mu$ 概率 $1/k$）。
2. **广义马尔可夫**：$\Pr[|Y| \geq c] \leq \frac{\mathbb{E}[|Y|^r]}{c^r}$（$r > 0$，$Y$ 可任意）。**r 是可调的旋钮**：r 越大用越高阶的矩，界可能越紧。$r = 2$、取 $Y = X - \mu$ 就得到切比雪夫。
3. **切比雪夫不等式**：$\Pr[|X - \mu| \geq c] \leq \frac{\text{Var}(X)}{c^2}$；推论形式 $\Pr[|X - \mu| \geq k\sigma] \leq \frac{1}{k^2}$。**证明机制是把偏离量平方后用马尔可夫**——不是新技巧，而是精妙的化归。
4. **切尔诺夫界**：独立 $\{0,1\}$ 变量之和，$\Pr[X \geq (1+\delta)\mu] \leq \left(\frac{e^\delta}{(1+\delta)^{1+\delta}}\right)^\mu$，简化版 $e^{-\mu\delta^2/3}$（上尾，$0 < \delta < 1$）与 $e^{-\mu\delta^2/2}$（下尾）。**证明机制：马尔可夫 + 指数化 e^{tX} + 独立性拆乘积 + 对 t 求极小**。代价是需要独立性和有界性，收益是**指数衰减**。
5. **弱大数定律**：i.i.d.、μ、$\sigma^2 < \infty$ 时 $\Pr[|\frac{1}{n}S_n - \mu| \geq \epsilon] \leq \frac{\sigma^2}{n\epsilon^2} \to 0$。**核心等式是 $\text{Var}(\frac{1}{n}S_n) = \frac{\sigma^2}{n}$**（注意 $\frac{1}{n^2}$ 因子与 $n\sigma^2$ 相抵）。它将"概率 = 长期频率"从公理假设升级为定理。
6. **样本复杂度黄金公式**：估计硬币偏差到误差 ϵ、置信度 $1-\delta$，只需 $n \geq \frac{1}{4\epsilon^2\delta}$（与总体大小**无关**）。$(\epsilon, \delta) = (0.1, 0.05)$ 对应 $n = 500$。
7. **界的强弱有量级差异**：马尔可夫/切比雪夫是**多项式衰减**，切尔诺夫/霍夫丁是**指数衰减**。负载均衡的例子中，切比雪夫给 $k \approx \sqrt{2n}$，切尔诺夫给 $k \approx \frac{\ln n}{\ln\ln n}$，$n = 3.5 \times 10^8$ 时分别是 26000 与 14。

常见误区与注意事项

1. **对可能取负值的随机变量使用马尔可夫不等式。** 这是最严重的错误。反例：$\Pr[X=-10]=0.9$、$\Pr[X=100]=0.1$，$\mathbb{E}[X]=1$，取 $c=50$ 时马尔可夫给 $0.1 \le 0.02$，**假。使用前必须先确认 $X \ge 0$**；若不然，改用广义马尔可夫（对 $|Y|$ 或 $(X-\mu)^2$）。
2. **忘记单尾事件必须先放大成双尾才能用切比雪夫。** 切比雪夫只能控制 $\{|X-\mu| \ge c\}$。要界 $\Pr[X \ge a]$（$a>\mu$），必须先写 $\{X \ge a\} \subseteq \{|X-\mu| \ge a-\mu\}$，再用 $c=a-\mu$。**漏掉这一步会得到错误的 c。** 例如界 $\Pr[X \ge \frac{3}{4}n]$ 时 c 是 $\frac{n}{4}$，不是 $\frac{3n}{4}$。
3. **把 $\mathrm{Var}(\frac{1}{n}S_n)$ 写成 $\frac{1}{n}\mathrm{Var}(S_n)$。** 正确是 $\frac{1}{n^2}\mathrm{Var}(S_n)=\frac{\sigma^2}{n}$。**漏掉平方会让方差变成 σ^2（与 n 无关），大数定律就不成立了。** 这是 L22 缩放法则 $\mathrm{Var}(cX)=c^2\mathrm{Var}(X)$ 的直接应用。
4. **以为界越小的方法永远越好，而不比较衰减量级。** 数值上：$n=1000$、$\delta=0.2$ 时切比雪夫给 0.025，切尔诺夫（简化版）给 1.27×10^{-3}——切尔诺夫赢。但 $n=100$ 时切比雪夫给 0.25，切尔诺夫给 0.5134——**切比雪夫反而更紧**！所以必须看**渐近趋势**（μ 大时指数界才压倒性胜出），而不是套用"切尔诺夫总更好"的口号。
5. **把"高概率保证"读成"绝对保证"。** 弱大数定律说的是"依概率收敛"：对每个 $\epsilon>0$，偏离概率趋于 0。它**不保证"n 足够大后永远不会偏离"**（那是强大数定律，且也需要以概率 1 而非必然）。应用一中"n 次全正面"的概率 $p^n>0$，永远存在——只是越来越小。
6. **在应用一中要求"绝对保证 $|\hat{p}-p| \le \epsilon$"而算出无穷大的 n。** 只要 $p \in (0,1)$，无论 n 多大，$\Pr[\hat{p}=1]=p^n>0$ 且 $\Pr[\hat{p}=0]=(1-p)^n>0$。**必须从一开始就把要求放松为"置信度 $1-\delta$"**，否则问题无解。
7. **在变异系数公式里把 ϵ 当成绝对误差。** "估计一般期望"中用的是**相对误差** $\epsilon\mu$，所以 $n \ge \frac{\sigma^2}{\mu^2}\cdot\frac{1}{\epsilon^2\delta}$ 里的 ϵ 是相对量。若误用绝对误差会得到完全不同的（且随 μ 变化的）n。
8. **把"不相关"当成切尔诺夫的前提。** 切尔诺夫界第 3 步 $\mathbb{E}[e^{tX}]=\prod\mathbb{E}[e^{tX_i}]$ **必须要** X_i 独立（不是不相关）。反例：取 $X_1=X_2=\cdots=X_n$ 的同一枚硬币（完全相关），$\mu=n/2$，则 $\Pr[X \ge 0.6n] \approx 1/2$（要么全对要么全错），而切尔诺夫界给出 $e^{-n\cdot0.02/3}\to0$——**界是完全错误的**。这与 L22 的教训一脉相承：**乘积期望的拆分需要独立，不是不相关。**
9. **忘记马尔可夫界可能超过 1（空洞界）。** 当 $c<\mathbb{E}[X]$ 时 $\mathbb{E}[X]/c>1$，不等式虽然正确但毫无信息。切比雪夫同理：$c<\sigma$ 时 $1/k^2>1$。**报告界之前先检查它是否 ≤ 1**，否则等于什么都没说。

思考题（带答案）

Q1.（纯计算） 设 X 是非负随机变量，$\mathbb{E}[X]=10$。

(a) 用马尔可夫不等式给出 $\Pr[X \ge 40]$ 的上界。(b) 若额外知道 $\mathrm{Var}(X)=4$，用切比雪夫给出 $\Pr[X \ge 40]$ 的上界，并比较哪个更好。(c) 若 X 实际服从 $\mathrm{Pois}(10)$，用马尔可夫与切比雪夫分别给出 $\Pr[X \ge 40]$ 的界。

> ▸ **答案**
>
> **(a)** 直接套马尔可夫（$X \ge 0$ 已给定，$c=40>0$）：
>
> $$\Pr[X \ge 40] \le \frac{10}{40} = \frac{1}{4} = 0.25.$$
>
> **(b)** 切比雪夫管的是双尾事件，先放大：$\{X \ge 40\} \subseteq \{|X-10| \ge 30\}$（因为 $40-10=30$）。故
>
> $$\Pr[X \ge 40] \le \Pr[|X-10| \ge 30] \le \frac{\mathrm{Var}(X)}{30^2} = \frac{4}{900} \approx 0.00444.$$
>
> **比较**：切比雪夫的界 0.00444 比马尔可夫的 0.25 好约 56 倍。原因是切比雪夫额外用了方差信息，且此处 $\sigma=2$ 很小（分布很集中），偏离 30（$=15\sigma$）是极稀有事件。
>
> **注意**：不能直接用切比雪夫而跳过"双尾放大"这一步——切比雪夫的原式是 $\Pr[|X-\mu| \ge c]$，不能直接套在 $\Pr[X \ge 40]$ 上。
>
> **(c)** 泊松分布 $\mathrm{Pois}(10)$：$\mu=10$，$\mathrm{Var}(X)=10$（泊松特征，见 L22）。因为 $k=40$ 时可取 $c=30$：
>
> - 马尔可夫：$\Pr[X \ge 40] \le 10/40 = 0.25$（与 (a) 相同，**马尔可夫只用均值，所以不管分布是什么，界都一样**）；
> - 切比雪夫：$\Pr[X \ge 40] \le \frac{10}{900} \approx 0.0111$。
>
> **对比 (b)**：这里方差是 10（而非 4），所以切比雪夫的界从 0.00444 退化到 0.0111。**这说明方差越大界越松——方差信息确实被用上了。** 而马尔可夫在两种情况下给出相同的界，因为它对分布完全不敏感。
>
> **延伸**：泊松分布的实际尾概率由直接求和可得 $\Pr[X \ge 40] = 7.34\times10^{-13}$（脚本验算），两个界都远松于真值（马尔可夫松了 3.4×10^{11} 倍，切比雪夫松了 1.5×10^{10} 倍）——这正是"只用低阶矩的代价"。若要用切尔诺夫处理泊松尾，需要先把它写成独立指示变量之和（泊松可分解为 $n\to\infty$ 的二项极限，或用 $\mathbb{E}[e^{tX}]=e^{\lambda(e^t-1)}$ 的矩生成函数直接做指数化），才能拿到指数级的界。

Q2.（概念/证明） 证明：若 X 是非负随机变量，则对任意 $c>0$，$\Pr[X \ge c] \le \frac{\mathbb{E}[X]}{c}$。（要求写出完整的逐步推导，并明确指出哪一步用到了非负性。）

▸ 答案

证法一（按取值分拆）：

1. 设 A 为 X 的取值集合，由 $X \geq 0$ 知 $a \geq 0$ 对一切 $a \in A$ 成立。由期望定义：

$$\mathbb{E}[X] = \sum_{a \in A} a \Pr[X = a].$$

1. 把求和按 a 与 c 的大小分拆：

$$\mathbb{E}[X] = \underbrace{\sum_{a<c} a \Pr[X=a]}_{\text{记为 } S_<} + \underbrace{\sum_{a \geq c} a \Pr[X=a]}_{\text{记为 } S_\geq}.$$

1. **关键一步（唯一用非负性处）**：因为每个 $a \geq 0$ 且 $\Pr[X=a] \geq 0$，故 $S_<$ 的每一项都 ≥ 0，所以 $S_< \geq 0$。丢掉它得到

$$\mathbb{E}[X] = S_< + S_\geq \geq S_\geq.$$

若 X 可取负值，$S_<$ 可能是负数，丢掉它会使不等式反向，证明彻底失效。 这就是为什么定理必须假定 $X \geq 0$。

1. 在 $S_\geq$ 中，每个 $a \geq c$，故 $a \Pr[X=a] \geq c \Pr[X=a]$（概率非负）。于是

$$S_\geq = \sum_{a \geq c} a \Pr[X=a] \geq \sum_{a \geq c} c \Pr[X=a] = c \sum_{a \geq c} \Pr[X=a] = c \Pr[X \geq c].$$

1. 串起来：$\mathbb{E}[X] \geq c \Pr[X \geq c]$。两边除以 $c > 0$ 得 $\Pr[X \geq c] \leq \frac{\mathbb{E}[X]}{c}$。■

证法二（指示变量，一行心法）：对每个 ω，

$$X(\omega) \geq c \mathbb{1}\{X(\omega) \geq c\}$$

（分两种情况验证：$X < c$ 时右边为 0，依赖 $X \geq 0$；$X \geq c$ 时右边为 $c \leq X$）。取期望得 $\mathbb{E}[X] \geq c\Pr[X \geq c]$，除以 c 即得。■

要点总结：非负性在两个地方起作用——① 丢掉小值段是安全的；② 指示变量下界在 $X < c$ 时给出 $X \geq 0$。两者本质上是同一件事。

Q3.（应用/计算） 某随机化算法单次运行有 $1/4$ 的概率失败。为了让"失败率不超过 1%"以置信度 99% 成立（即用切比雪夫保证估计的失败率 $|\hat{p} - p| \leq 0.01$ 的概率 ≥ 0.99），需要独立运行多少次？若改用切尔诺夫界，需要多少次？

▸ 答案

建模：设 $X_i = \mathbb{1}\{\text{第 } i \text{ 次运行失败}\}$，则 X_i 独立、$p = 1/4$、$\sigma^2 = p(1-p) = 3/16 = 0.1875$。$\hat{p} = \frac{1}{n} S_n$。

用切比雪夫：目标 $\Pr[|\hat{p} - p| \geq \epsilon] \leq \delta$，其中 $\epsilon = 0.01$，$\delta = 0.01$。由 $n \geq \frac{p(1-p)}{\epsilon^2 \delta}$：

$$n \geq \frac{0.1875}{(0.01)^2 \times 0.01} = \frac{0.1875}{10^{-6}} = 187{,}500.$$

即需要 18.75 万次运行。

用切尔诺夫（上尾 + 下尾）：$\mu = np = 0.25n$，ϵ 是相对误差 $\delta_{\text{rel}} = \epsilon/p = 0.01/0.25 = 0.04$。用简化形式两边同时界：

$$\Pr[|\hat{p} - p| \geq 0.01] \leq e^{-\mu\delta_{\text{rel}}^2/3} + e^{-\mu\delta_{\text{rel}}^2/2} \leq 2e^{-\mu(0.04)^2/3} = 2e^{-0.25n \cdot 0.0016/3} = 2e^{-n \cdot 1.333 \times 10^{-4}}.$$

要它 ≤ 0.01：$e^{-n \cdot 1.333 \times 10^{-4}} \leq 0.005$，即 $n \cdot 1.333 \times 10^{-4} \geq \ln 200 \approx 5.298$，得

$$n \geq \frac{5.298}{1.333 \times 10^{-4}} \approx 39{,}740.$$

即需要约 3.97 万次运行。

比较：切尔诺夫比切比雪夫少用约 4.7 倍的样本。这是因为切尔诺夫利用了"X_i 独立 + 有界（$0/1$）"这两个额外信息，得到指数衰减而非 $1/n$ 衰减。

注意几点： – 切尔诺夫需要**独立**性；若各次运行之间存在相关性（例如共享同一份随机种子），上界失效。 – 这里 $p = 1/4$ 已知（无需像估计硬币偏差那样去最大化 $p(1-p)$）。若 p 未知，切比雪夫用 $p(1-p) \leq 1/4$ 给出 $n \geq \frac{1/4}{0.01^2 \cdot 0.01} = 250{,}000$——比已知 p 时多 $1/3$。 – 两种方法都保证"高概率"而非"必然"。**这正是随机化算法分析的现实：我们买的是概率保证，不是确定性保证。**

Q4.（进阶概念） 判断真假并说明理由：

(a) 若 X_i 两两不相关（但不必独立），切尔诺夫界仍然成立。 (b) 弱大数定律的证明中，$\mathbf{Var}(\frac{1}{n}S_n) = \frac{\sigma^2}{n}$ 这一步需要 X_i 独立。 (c) 马尔可夫不等式对 $\mathbf{Bin}(n, 1/2)$ 给出的 $\Pr[X \geq \frac{3}{4}n]$ 的上界与 n 无关。 (d) 若 $\Pr[X \geq c] \leq \mathbb{E}[X]/c$ 对某个非负 X 与所有 $c > 0$ 成立且都取等号，则 X 必须是两点分布。

▸ 答案

(a) 假。 切尔诺夫界的证明第 3 步用了 $\mathbb{E}[\prod e^{tX_i}] = \prod \mathbb{E}[e^{tX_i}]$，这需要 $e^{tX_1}, \dots, e^{tX_n}$ 独立，即 $X_1, \dots, X_n$ 独立。**不相关远远不够**——它只能保证一阶交叉矩的性质，管不住 $\mathbb{E}[e^{tX}]$ 这种指数型函数。反例：$X_1 = \cdots = X_n$ 同为一枚硬币（完全相关，甚至方差都相同），实际 $\Pr[X \geq 0.6n] \approx 1/2$，而切尔诺夫界给 $e^{-n \cdot 0.02/3} \to 0$，完全错误。**这与 L22 的教训一致：$\mathbb{E}[XY] = \mathbb{E}[X]\mathbb{E}[Y]$ 需要独立，不相关不够。**

(b) 真（在这个证明的写法下）。 由定理 22.9 的一般公式：

$$\mathrm{Var}(S_n) = \sum_i \mathrm{Var}(X_i) + 2\sum_{i<j} \mathrm{Cov}(X_i, X_j).$$

要得到 $\mathrm{Var}(S_n) = n\sigma^2$，必须让所有交叉项为零。**"两两不相关"（比独立弱）就已经足够**——所以严格说，这一步需要的是"不相关"，而独立是它的充分条件。i.i.d. 假设自动给出了不相关。**更精确的说法是：弱大数定律只需要两两不相关，独立是不必要的加强。**

(c) 真。 因为 $\mathbb{E}[X] = \frac{n}{2}$，马尔可夫给出 $\Pr[X \geq \frac{3}{4}n] \leq \frac{n/2}{3n/4} = \frac{2}{3}$——**$n$ 恰好约掉了**。（脚本验算：$n = 10, 100, 1000$ 时界都是 0.6667，而真值分别为 5.47×10^{-2}、2.82×10^{-7}、6.74×10^{-59}。）这正是马尔可夫的局限：只用一阶信息，无法察觉"分布越来越集中"这一现象。切比雪夫给 $4/n$，随 n 衰减——**这就是"多用一个信息"的价值。**

(d) 真（在两点分布的前提下再加上取等号的条件）。 取 c 略小于某个取值时取等号，可推出 X 只可能在 0 与某个单点上有质量。严格论证：若存在两个不同的正概率取值 $0 < a_1 < a_2$，则取 $c \in (a_1, a_2)$ 时有 $\Pr[X \geq c] = \Pr[X = a_2]$，而
$\mathbb{E}[X] \geq a_2 \Pr[X = a_2] + a_1 \Pr[X = a_1] > a_2 \Pr[X = a_2] = a_2 \Pr[X \geq c] > c \Pr[X \geq c]$，**严格不等**，与取等号矛盾。故至多一个正概率的正取值，加上 0 最多两点。（这也呼应了跷跷板推导中"两端集中"的极值构型。）

Lecture 24: Continuous Probability & Distributions（连续概率与分布）

概述

到目前为止我们处理的一切概率对象都是**离散的 (discrete)**：样本空间 Ω 要么有限、要么可数无限，随机变量只能取有限或可数个值，分布用概率质量函数 (PMF, probability mass function) $\Pr[X = a]$ 描述。但现实世界里我们想建模的量往往**天然连续**：粒子在盒子里的位置、某个事件发生的时刻、顾客到达的间隔、放射性原子衰变的时间、针落下时与桌缝的夹角。本讲把离散概率的整套工具箱搬到连续世界：**点概率让位给密度 (density)，求和让位给积分**，而其余的一切（期望、方差、线性性、独立性）几乎原封不动地搬过来。

本讲的技术核心只有一条：**连续情形下必须放弃"给每个样本点赋概率"这一想法**（因为那必然导致所有点概率为 0），改为给**区间**赋概率。由此引出概率密度函数 (PDF) 与累积分布函数 (CDF) 这对孪生概念，并导出三类最重要的连续分布中的两个：**连续均匀分布 (continuous uniform)** 与**指数分布 (exponential)**。第三个（正态分布）留给下一讲。

核心概念的直观解释

连续概率空间 (Continuous Probability Space) 与"点概率为 0"的观念转变

- **定义**：考虑"命运之轮"实验：轮盘周长 ℓ，无偏地旋转并记录指针停下的位置。样本空间是实数区间 $\Omega = [0, \ell]$。对任意 $0 \leq a < b \leq \ell$，定义

$$\Pr\left[[a, b]\right] = \frac{\text{区间长度}}{\text{总长度}} = \frac{b - a}{\ell}.$$

即**概率正比于长度**。

- **直观解释（"它是什么意思？"）**：先看能不能照抄离散做法。把轮盘离散化成 m 个等距刻度 $\Omega_m = \{0, \frac{\ell}{m}, \frac{2\ell}{m}, \dots, \frac{(m-1)\ell}{m}\}$，每个刻度概率 $1/m$，这完全没问题。现在让 $m \to \infty$。如果试图给每个 $\omega \in [0, \ell]$ 赋一个**正**概率 $p > 0$，那么因为 $[0, \ell]$ 中有**不可数**多个实数，全部概率之和会是 ∞，违反总概率为 1。所以只能让每个点概率都是 0。可是如果所有样本点概率都是 0，我们还怎么给事件赋概率？答案是：**离散情形里"事件 = 样本点的集合，概率 = 逐点概率之和"这条路线在连续情形彻底走不通**，必须改为把**区间**当作基本事件。

类比：把概率想象成"质量"。离散情形是一堆小石子（每颗有确定质量）；连续情形是一条连续的金属棒，**某一点的"质量"毫无意义**（质量为零），有意义的是**一段区间的质量**。密度就是"每单位长度的质量"。

- **具体示例**：取 $\ell = 1$，则 $\Pr[X \in [0.25, 0.75]] = 0.5$，$\Pr[X \in [0, 0.1]] = 0.1$。取 $\ell = 10$，则 $\Pr[X \in [2, 5]] = (5 - 2)/10 = 0.3$（已用脚本验算）。
- **关键推论：概率为 0 的事件不一定不可能发生。** 对每个具体的 $x \in [0, \ell]$，$\Pr[X = x] = 0$。但 X 终究会取到**某个**值，而 $\Pr[X \in [0, \ell]] = 1$。这说明"概率为 0"与"不可能"在连续世界是两个不同的概念。技术上，这是因为概率的**可数可加性 (countable additivity)** 只对**可数并**成立：

$$\Pr\left[\bigcup_{n=1}^{\infty} A_n\right] = \sum_{n=1}^{\infty} \Pr[A_n] \quad \text{（可数并）},$$

而对**不可数并**没有这条性质。$\{X = x\}$ 这些零概率事件有不可数多个，把它们并起来可以凑出概率为 1 的大事件——这在离散世界是绝不会发生的。另一条推论：端点无关紧要，$\Pr[a < X < b] = \Pr[a \leq X \leq b]$，因为两端各自贡献 0。

概率密度函数 (Probability Density Function, PDF)

- **定义**：实值随机变量 X 的概率密度函数是一个函数 $f : \mathbb{R} \to \mathbb{R}$，满足
- **非负性**：$f(x) \geq 0$ 对一切 $x \in \mathbb{R}$；
- **总积分为 1**：$\displaystyle\int_{-\infty}^{\infty} f(x)\,dx = 1$。

并且 X 的分布由 f 通过积分给出：

$$\Pr[a \le X \le b] = \int_a^b f(x)\,dx \quad \text{对一切 } a < b.$$

- **直观解释（"它是什么意思？"）**：f 扮演的角色相当于离散情形的**直方图 (histogram)**：它告诉你"概率在实数轴上哪里密集、哪里稀疏"。**但 $f(x)$ 本身不是概率！** 它是"**单位长度的概率**"（probability per unit length）。真正对应概率的是**面积**：

$$\Pr[x \le X \le x + dx] = \int_x^{x+dx} f(z)\,dz \approx f(x)\,dx.$$

也就是说 $f(x)\,dx$ 才近似是"落在 x 附近极小邻域"的概率。这也是记号 $f(x)dx$ 里那个 dx 的真正用途——它不是装饰，它是量纲。

- **具体示例（f 可以大于 1，这必须牢记）**：取 $[0, \ell]$ 上的均匀分布，密度是常数 c。由归一化条件

$$1 = \int_0^{\ell} c\,dx = c\ell \implies c = \frac{1}{\ell}.$$

若取 $\ell = \frac{1}{2}$，则 $f(x) = 1/(\frac{1}{2}) = 2$ 在 $[0, \frac{1}{2}]$ 上，**大于 1**。再取 $\ell = 0.1$，则 $f(x) = 10$。所以"密度 ≤ 1"完全是错的直觉（它是离散 PMF 习惯的错误移植）。密度大只说明"在这一点附近概率的**堆积速度**快"，只要它堆得快、范围窄，总面积仍可以是 1。

累积分布函数 (Cumulative Distribution Function, CDF)

- **定义**：连续随机变量 X 的累积分布函数是

$$F(x) = \Pr[X \le x] = \int_{-\infty}^{x} f(z)\,dz.$$

反过来，在 F 可导处有 $f(x) = F'(x)$，即 $f = \dfrac{dF}{dx}$。

- **直观解释**：CDF 是"从左往右累积的面积"，它是一个**单调不减、右连续、$\lim_{x\to-\infty} F(x) = 0$、$\lim_{x\to\infty} F(x) = 1$** 的函数。对概率密度做**微分**得到密度、对密度做**积分**得到 CDF，两者是一对互逆运算——这正好对应离散情形里"PMF 与 CDF 的差分/求和"关系。
- **从离散过渡过来的自然路径**：把实数轴切成宽 dx 的小格 $x_k = k\,dx$（$k \in \mathbb{Z}$）。则 $\Pr[x_k < X \le x_k + dx] \approx f(x_k)\,dx$，于是

$$F(x_i) = \Pr[X \le x_i] \approx \sum_{j \le i} f(x_j)\,dx.$$

右边是一个**黎曼和 (Riemann sum)**。令 $dx \to 0$，求和就变成积分 $F(x) = \int_{-\infty}^{x} f(z)dz$。**"求和换积分"这条口号的全部内容就在这里**。

- **具体示例（指数分布）**：$X \sim \mathrm{Exp}(\lambda)$ 时 $F(x) = 1 - e^{-\lambda x}$（$x \ge 0$）。取 $\lambda = 2$：$F(0.5) = 1 - e^{-1} = 0.63212056$，$F(1) = 0.86466472$，$F(1.5) = 0.95021293$，$F(2) = 0.98168436$（脚本验算）。可以看到 F 迅速逼近 1——等待时间几乎不可能很长。

连续随机变量的期望与方差

- **定义**：设连续随机变量 X 的密度为 f。

$$\mathbb{E}[X] = \int_{-\infty}^{\infty} x f(x)\,dx, \qquad \mathrm{Var}(X) = \mathbb{E}\big[(X - \mathbb{E}[X])^2\big] = \mathbb{E}[X^2] - \mathbb{E}[X]^2,$$

其中 $\mathbb{E}[X^2] = \int_{-\infty}^{\infty} x^2 f(x)\,dx$。

- **直观解释**：离散情形 $\mathbb{E}[X] = \sum_a a \Pr[X = a]$，连续情形把"取值 a 的概率 $\Pr[X = a]$"换成"落在 x 附近的概率 $f(x)dx$"，求和换成积分：$\sum a\ \Pr[X = a] \to \int x f(x) dx$。这就是**"加权平均重心"**在连续世界的版本。表达式 $\mathbb{E}[X^2] - \mathbb{E}[X]^2$ 中的 $\mathbb{E}[X]^2$ 是 $(\mathbb{E}[X])^2$（先求期望再平方），**不是 $\mathbb{E}[X^2]$**——这是讲次 22 就强调过的经典陷阱，连续情形同样适用。
- **具体示例对齐**：均匀分布 $U[2, 6]$ 的期望是 $(2+6)/2 = 4$，方差是 $(6-2)^2/12 = 16/12 \approx 1.3333$（脚本数值积分核对：$4.000000$ 与 1.333333）。

连续均匀分布 (Continuous Uniform Distribution)

- **定义**：X 在区间 $[a, b]$（$a < b$）上**均匀分布**，记为 $X \sim U[a, b]$，密度为

$$f(x) = \begin{cases} \dfrac{1}{b-a}, & a \le x \le b, \\ 0, & \text{其他}. \end{cases}$$

于是对任意子区间 $[c, d] \subseteq [a, b]$ 有 $\Pr[X \in [c, d]] = \dfrac{d-c}{b-a}$——**概率只看长度比例**。

- **直观解释**：概率只看**长度比例**，不看位置。"每一段等长的区间概率相同"——这就是"均匀"的全部含义。类比：往一条均匀的线段上随机撒一个点。
- **具体示例**：$U[0, 10]$ 上 $\Pr[X \in [2, 5]] = 3/10 = 0.3$；$\Pr[X \in [0, 1]] = 0.1$；$\Pr[X = 2] = 0$ 但 $X = 2$ 是可能发生的。

指数分布 (Exponential Distribution)

- **定义**：对参数 $\lambda > 0$，若连续随机变量 X 的密度为

$$f(x) = \begin{cases} \lambda e^{-\lambda x}, & x \ge 0, \\ 0, & x < 0, \end{cases}$$

则称 X 服从参数 λ 的**指数分布**，记 $X \sim \mathrm{Exp}(\lambda)$。

- **直观解释**：指数分布是**几何分布的连续时间版本**。几何分布描述"抛硬币直到第一次正面所需的**次数**"；指数分布描述"等待某个事件发生所需的**时间**"。参数 λ 是**单位时间的事件发生率 (rate)**。它在真实世界出现得极其频繁：顾客到达间隔、放射性衰变时间、机器无故障运行时间、电话通话时长——只要事件以恒定速率

随机发生，等待时间就是指数的。

- **具体示例**：设 $\lambda = 2$（平均每单位时间发生 2 次），则 $\mathbb{E}[X] = 0.5$，$\mathbf{Var}(X) = 0.25$，$\Pr[X > 1] = e^{-2} = 0.13533528$。若某客服平均每 20 分钟接到一个电话（$\lambda = 1/20$，单位：分钟），则等下一个电话超过 15 分钟的概率是 $e^{-15/20} = 0.472367$，超过 30 分钟的概率是 $e^{-30/20} = 0.223130$（脚本验算）。

联合密度 (Joint Density) 与独立性

- **定义**：两个连续随机变量 X, Y 的**联合密度**是函数 $f : \mathbb{R}^2 \to \mathbb{R}$，满足 $f(x,y) \geq 0$ 且

$$\int_{-\infty}^{\infty}\int_{-\infty}^{\infty} f(x,y)\,dx\,dy = 1,$$

且 $\Pr[a \leq X \leq b,\ c \leq Y \leq d] = \displaystyle\int_c^d \int_a^b f(x,y)\,dx\,dy$。

- **直观解释**：$f(x,y)$ 是"**单位面积的概率**"。类比：$\Pr[x \leq X \leq x+dx,\ y \leq Y \leq y+dy] \approx f(x,y)\,dx\,dy$。边缘密度由**积分掉另一个变量**得到：$f_X(x) = \int_{-\infty}^{\infty} f(x,y)\,dy$——这正是离散情形"对另一个变量求和得到边缘 PMF"的积分版。
- **独立性 (Independence)**：连续随机变量 X, Y 独立，当且仅当对一切 $a \leq b, c \leq d$，

$$\Pr[a \leq X \leq b,\ c \leq Y \leq d] = \Pr[a \leq X \leq b] \cdot \Pr[c \leq Y \leq d].$$

等价地，联合密度分解为边缘密度之积：$f(x,y) = f_X(x) f_Y(y)$。

- **具体示例（三角形上的联合密度）**：设 (X,Y) 在三角形 $T = \{(x,y) : x \geq 0, y \geq 0, x+y \leq 1\}$ 上均匀分布。三角形面积是 $1/2$，故联合密度 $f(x,y) = 2$ 在 T 上、否则为 0。总积分 $\int_0^1 \int_0^{1-x} 2\,dy\,dx = \int_0^1 2(1-x)dx = 1$ ✓。边缘密度 $f_X(x) = \int_0^{1-x} 2\,dy = 2(1-x)$（$0 \leq x \leq 1$），它**不是常数**，所以 X 不是 $U[0,1]$。期望 $\mathbb{E}[X] = \int_0^1 x \cdot 2(1-x)dx = 2(\frac{1}{2} - \frac{1}{3}) = \frac{1}{3}$（蒙特卡洛 2×10^6 次抽样得 0.33370，接受率 0.4998，与理论 $\frac{1}{2}$ 一致）。

完整证明与推导（核心）

定理 24.1（连续均匀分布的期望与方差）：设 $X \sim U[a,b]$。则

$$\mathbb{E}[X] = \frac{a+b}{2}, \qquad \mathbf{Var}(X) = \frac{(b-a)^2}{12}.$$

证明策略：直接证明——从期望与方差的定义出发，把 $f(x) = 1/(b-a)$ 代进去做两项多项式积分。选择这个策略是因为均匀分布的密度是常数，积分是全课程中最干净的一类，正好用来把"定义怎么落地"演示清楚。先做特例 $[0, \ell]$（对应官方 Note 的 $\mathbb{E}[X] = \ell/2$、$\mathbf{Var}(X) = \ell^2/12$），再平移缩放得到一般 $[a,b]$。

逐步推导：

先取特例 $X \sim U[0,\ell]$，$f(x) = 1/\ell$ 在 $[0,\ell]$，其余为 0。

第 1 步（期望）：由定义，

$$\mathbb{E}[X] = \int_{-\infty}^{\infty} x f(x)\,dx = \int_0^{\ell} x \cdot \frac{1}{\ell}\,dx = \frac{1}{\ell} \cdot \frac{x^2}{2}\Big|_0^{\ell} = \frac{1}{\ell} \cdot \frac{\ell^2}{2} = \frac{\ell}{2}.$$

第 2 步（二阶矩）：

$$\mathbb{E}[X^2] = \int_0^{\ell} x^2 \cdot \frac{1}{\ell}\,dx = \frac{1}{\ell} \cdot \frac{x^3}{3}\Big|_0^{\ell} = \frac{\ell^2}{3}.$$

第 3 步（方差）：用 $\mathbf{Var}(X) = \mathbb{E}[X^2] - \mathbb{E}[X]^2$，

$$\mathbf{Var}(X) = \frac{\ell^2}{3} - \left(\frac{\ell}{2}\right)^2 = \frac{\ell^2}{3} - \frac{\ell^2}{4} = \frac{4\ell^2 - 3\ell^2}{12} = \frac{\ell^2}{12}.$$

第 4 步（推广到 $[a,b]$）。直接把 $[a,b]$ 上的密度 $1/(b-a)$ 代进去重做一遍积分，比对"平移缩放"更不容易出错：

$$\mathbb{E}[X] = \frac{1}{b-a}\int_a^b x\,dx = \frac{1}{b-a} \cdot \frac{b^2-a^2}{2} = \frac{(b-a)(b+a)}{2(b-a)} = \frac{a+b}{2},$$

$$\mathbb{E}[X^2] = \frac{1}{b-a}\int_a^b x^2\,dx = \frac{1}{b-a} \cdot \frac{b^3-a^3}{3} = \frac{b^2+ab+a^2}{3},$$

$$\mathbf{Var}(X) = \frac{b^2+ab+a^2}{3} - \left(\frac{a+b}{2}\right)^2 = \frac{4(b^2+ab+a^2) - 3(a^2+2ab+b^2)}{12} = \frac{b^2-2ab+a^2}{12} = \frac{(b-a)^2}{12}.$$

代数细节核对：$(b^3-a^3)/(b-a) = b^2+ab+a^2$ ✓；$4(b^2+ab+a^2) - 3(a^2+2ab+b^2) = b^2-2ab+a^2 = (b-a)^2$ ✓。

脚本验算（Simpson 数值积分，10^5 段；把 $[a,b]$ 代进公式与数值结果对照）：

分布	数值 $\mathbb{E}[X]$	公式 $(a+b)/2$	数值 Var	公式 $(b-a)^2/12$
$U[0,1]$	0.500000	0.5	0.083333	$1/12 = 0.083333$
$U[0,10]$	5.000000	5	8.333333	$100/12 = 8.333333$
$U[-2,3]$	0.500000	0.5	2.083333	$25/12 = 2.083333$
$U[2,6]$	4.000000	4	1.333333	$16/12 = 1.333333$

【证明机制解说】：这个证明没有技巧，全部价值在于**把定义用熟**。请注意三件事：(1) 期望的积分可以只在 f 非零的区间上做（其余被积函数是 0）；(2) 方差永远走 $\mathbb{E}[X^2]-\mathbb{E}[X]^2$ 这条短路，因为直接对 $(x-\mu)^2 f(x)$ 展开积分反而更麻烦；(3) 结果中 $1/12$ 这个因子不直观，但**方差正比于 ℓ^2** 这一点完全符合直觉——区间拉长一倍，波动放大到四倍（因为标准差正比于长度，即 $\sigma=(b-a)/\sqrt{12}$）。用 $U[0,10]$ 对照 $U[0,1]$：前者方差是后者的 100 倍，正是 10^2。

反例（说明"密度的值"绝不能当作概率）：$U[0,1/2]$ 的密度恒为 $2>1$。若把 $f(x)$ 读成"概率"，就会得出"X 落在 0.1 这一点的概率是 2"这种荒谬结论。真相是 $\Pr[X=0.1]=0$。同理 $U[0,0.1]$ 的密度是 10。**判据只有一个：$\int f=1$，而不是 $\max f\le 1$。**

定理 24.2（指数分布是合法的概率密度）：设 $\lambda>0$，$f(x)=\lambda e^{-\lambda x}$（$x\ge 0$），$f(x)=0$（$x<0$）。则 f 满足 PDF 的两条公设，特别地

$$\int_{-\infty}^{\infty} f(x)\,dx=\int_0^{\infty}\lambda e^{-\lambda x}\,dx=1,$$

且 $\Pr[X>t]=e^{-\lambda t}$（$t\ge 0$）。

证明策略：直接证明，用初等原函数 $e^{-\lambda x}$ 与反常积分的极限。关键在于"λ 恰好是被自动定出来的归一化常数"。

逐步推导：

第 1 步（非负性）：$\lambda>0$ 且 $e^{-\lambda x}>0$ 对一切实数 x 成立，故 $x\ge 0$ 时 $f(x)=\lambda e^{-\lambda x}>0$；$x<0$ 时 $f(x)=0$。所以 $f\ge 0$ ✓。

第 2 步（总积分）：因 $x<0$ 段被积函数为 0，

$$\int_{-\infty}^{\infty} f(x)\,dx=\int_0^{\infty}\lambda e^{-\lambda x}\,dx=\lambda\cdot\left[-\frac{1}{\lambda}e^{-\lambda x}\right]_0^{\infty}=\lambda\cdot\left(0-\left(-\frac{1}{\lambda}\right)\right)=\lambda\cdot\frac{1}{\lambda}=1.$$

这里用到 $\lim_{x\to\infty}e^{-\lambda x}=0$（$\lambda>0$）与 $e^0=1$。

第 3 步（尾概率）：对 $t\ge 0$，

$$\Pr[X>t]=\int_t^{\infty}\lambda e^{-\lambda x}\,dx=\left[-e^{-\lambda x}\right]_t^{\infty}=0+e^{-\lambda t}=e^{-\lambda t}.$$

第 4 步（CDF）：由第 3 步，$\Pr[X\le t]=1-\Pr[X>t]=1-e^{-\lambda t}$（$t\ge 0$）；$t<0$ 时 $F(t)=0$。

[证明机制解说]：注意"归一化常数 λ"并不是外加的——**指数分布的参数同时承担了两个角色**：它既是衰减率（CDF 的形状参数），又是使总面积为 1 的归一化因子。这不是巧合：$\int_0^{\infty}e^{-\lambda x}dx=1/\lambda$，所以要让面积为 1 就必须乘上 λ。这也是为什么"λ 是速率"这个解释成立：速率越大，密度曲线越"瘦高"，质量越集中在 0 附近。

反例 / 注意点：λ 与概率 p 不同，**不受 $\lambda\le 1$ 约束**。$\lambda=10$ 完全合法（此时 $f(0)=10$，密度大于 1，又是"密度不是概率"的一例）。几何分布的参数 p 必须 ≤ 1，而指数分布的 λ 可以是任意正数——这正是"连续化"带来的自由度（因为 λ 的量纲是 $1/$时间）。

定理 24.3（指数分布的均值与方差）：设 $X\sim\mathrm{Exp}(\lambda)$，$\lambda>0$。则

$$\mathbb{E}[X]=\frac{1}{\lambda},\qquad \mathrm{Var}(X)=\frac{1}{\lambda^2}.$$

证明策略：分部积分 (integration by parts)，两次。选择分部积分的理由是：被积函数形如"多项式 × 指数"，把指数部分拿去当 dv 积分后，多项式次数就降一次，两轮之后指数积分回到总积分本身，从而闭合。

逐步推导：

第 1 步（$\mathbb{E}[X]$）。取 $u=x$、$dv=\lambda e^{-\lambda x}dx$，则 $du=dx$、$v=-e^{-\lambda x}$。分部积分公式 $\int u\,dv=uv-\int v\,du$ 给出

$$\mathbb{E}[X]=\int_0^{\infty}x\cdot\lambda e^{-\lambda x}dx=\underbrace{\Big[-xe^{-\lambda x}\Big]_0^{\infty}}_{=:A}+\int_0^{\infty}e^{-\lambda x}dx.$$

第 2 步（计算边界项 A）：在 $x=0$ 处 $-xe^{-\lambda x}=0$；在 $x\to\infty$ 处，$xe^{-\lambda x}\to 0$（指数衰减快于任何多项式增长——洛必达法则可得）。故 $A=0-0=0$。

第 3 步（完成期望）：

$$\mathbb{E}[X]=0+\left[-\frac{1}{\lambda}e^{-\lambda x}\right]_0^{\infty}=\frac{1}{\lambda}.$$

直觉核对：若平均每秒发生 2 次（$\lambda=2$），平均等待 0.5 秒 ✓。$\lambda=3$ 时平均等 $1/3$ ✓（脚本数值：0.333333）。

第 4 步（$\mathbb{E}[X^2]$）。取 $u=x^2$、$dv=\lambda e^{-\lambda x}dx$，则 $du=2x\,dx$、$v=-e^{-\lambda x}$：

$$\mathbb{E}[X^2]=\Big[-x^2e^{-\lambda x}\Big]_0^{\infty}+\int_0^{\infty}2xe^{-\lambda x}dx.$$

边界项同样为 0（$x^2e^{-\lambda x}\to 0$）。

第 5 步（把二阶梯矩归约到一阶）：注意 $\int_0^{\infty}2xe^{-\lambda x}dx=\frac{2}{\lambda}\int_0^{\infty}\lambda xe^{-\lambda x}dx=\frac{2}{\lambda}\mathbb{E}[X]$。于是

$$\mathbb{E}[X^2]=\frac{2}{\lambda}\cdot\frac{1}{\lambda}=\frac{2}{\lambda^2}.$$

第 6 步（方差）：

$$\mathrm{Var}(X)=\mathbb{E}[X^2]-\mathbb{E}[X]^2=\frac{2}{\lambda^2}-\frac{1}{\lambda^2}=\frac{1}{\lambda^2}.$$

脚本验算（对 $\lambda\in\{0.5,1,2,3\}$ 用 Simpson 数值积分在 $[0,60]$ 上算）：

λ	$\int f$	数值 $\mathbb{E}[X]$	$1/\lambda$	数值 Var	$1/\lambda^2$
0.5	1.00000000	2.000000	2	4.000000	4
1	1.00000000	1.000000	1	1.000000	1
2	1.00000000	0.500000	0.5	0.250000	0.25
3	1.00000000	0.333333	1/3	0.111111	1/9

另外单独核对分部积分的中间量：$\int_0^\infty x e^{-2x}dx = 0.250000 = 1/\lambda^2$ ✓，$\int_0^\infty x^2 e^{-2x}dx = 0.250000 = 2/\lambda^3$ ✓。

【证明机制解说】：这个证明的"灵光一现"在第 5 步——**不要把 $\int 2xe^{-\lambda x}dx$ 重新分部积分一遍，而要认出它就是 $\frac{2}{\lambda}$ 倍的 $\mathbb{E}[X]$**。这种"把新积分归约到已知积分"的手法在概率论里反复出现（下一讲算正态分布的方差时会再次用到，那里归约到的是高斯积分）。同时请注意一个漂亮的结构：$\mathrm{Var}(X) = 1/\lambda^2 = (\mathbb{E}[X])^2$，即**指数分布的标准差恰等于它的均值**。这是一种非常特殊的"波动与均值同量级"的性质，与均匀分布（标准差正比于区间长）形成对照。

定理 24.4（无记忆性 Memorylessness）：设 $X \sim \mathbf{Exp}(\lambda)$，$s, t \geq 0$。则

$$\Pr[X > s+t \mid X > s] = \Pr[X > t] = e^{-\lambda t},$$

且这个条件概率与 s **无关**。

证明策略：直接证明——用条件概率定义把条件概率展开成分式，再用定理 24.2 的尾概率公式 $e^{-\lambda t}$，指数律会自动消掉 s。这条推导只有三行，但它是整讲最重要的性质。

逐步推导：

第 1 步（条件概率定义）：设 $s \geq 0$，则 $\Pr[X > s] = e^{-\lambda s} > 0$，条件概率良定义：

$$\Pr[X > s+t \mid X > s] = \frac{\Pr\left[(X > s+t) \cap (X > s)\right]}{\Pr[X > s]}.$$

第 2 步（化简分子）。因为 $s + t \geq s$，事件 $\{X > s+t\}$ 蕴含 $\{X > s\}$（尾事件的**嵌套性**），故交事件就等于 $\{X > s+t\}$：

$$\Pr\left[(X > s+t) \cap (X > s)\right] = \Pr[X > s+t] = e^{-\lambda(s+t)}.$$

第 3 步（相除）：

$$\Pr[X > s+t \mid X > s] = \frac{e^{-\lambda(s+t)}}{e^{-\lambda s}} = e^{-\lambda(s+t)+\lambda s} = e^{-\lambda t} = \Pr[X > t].$$

第 4 步（"与 s 无关"的含义）：上式右端不含 s。所以"已经等了 s 分钟"这件事**完全没有**改变"还需要再等超过 t 分钟"的概率。若把剩余等待时间记为 $R = X - s$（在 $\{X > s\}$ 条件下），则 $R \sim \mathbf{Exp}(\lambda)$，与 X 同分布——**系统在时刻 s "重新开始"，就像什么都没发生过**。

第 5 步（与几何分布的平行）。讲次 19 的几何分布 $G(p)$ 有一条完全平行的性质：对整数 $s, t \geq 0$，

$$\Pr[Y > s+t \mid Y > s] = \frac{(1-p)^{s+t}}{(1-p)^s} = (1-p)^t = \Pr[Y > t].$$

脚本验算：$p = 0.3$，$s = 3$，$t = 2$：$(1-p)^5/(1-p)^3 = 0.49000000 = (1-p)^2$ ✓。

第 6 步（连续化验证：指数分布是几何分布的极限）。设每 δ 秒做一次试验，每次成功概率 $p = \lambda\delta$（"成功率正比于时间片长度"，对应恒定速率 $\lambda = p/\delta$）。则在 t 秒内做 $k = t/\delta$ 次试验，从未成功的概率是 $(1-p)^k = (1-\lambda\delta)^{t/\delta}$。令 $\delta \to 0$：

$$(1-\lambda\delta)^{t/\delta} \longrightarrow e^{-\lambda t},$$

这正是指数分布的尾概率。脚本验算（$\lambda = 2$，$t = 1.5$，目标 $e^{-3} = 0.04978707$）：$\delta = 0.1$ 给 0.03518437，$\delta = 0.01$ 给 0.04829602，$\delta = 0.001$ 给 0.04963773，$\delta = 0.0001$ 给 0.04977213——**收敛清楚可见**。

第 7 步（脚本验算无记忆性本身，$\lambda = 2$）：

s	t	$\Pr[X > s+t \mid X > s]$ 数值	$\Pr[X > t] = e^{-\lambda t}$
1	2	0.0183156389	0.0183156389
3	0.5	0.3678794412	0.3678794412
10	5	0.0000453999	0.0000453999

【证明机制解说】：证明的全部力量来自**尾事件的嵌套性**：$\{X > s+t\} \subseteq \{X > s\}$，所以交事件可以直接化简。这一步之所以能成功，本质上是因为指数函数的乘法性质 $e^{-\lambda(s+t)} = e^{-\lambda s}e^{-\lambda t}$——**"无记忆"就是"指数律"**。反过来看，如果想让一个取值于 $[0, \infty)$ 的连续分布满足 $\Pr[X > s+t \mid X > s] = \Pr[X > t]$，解函数方程 $g(s+t) = g(s)g(t)$ 会逼出 $g(t) = e^{-\lambda t}$，**所以指数分布是唯一具有无记忆性的连续分布**（离散情形里对应地，几何分布是唯一的无记忆分布）。

反例（无记忆性不是普遍规律）：设 $X \sim U[0, 10]$，则 $\Pr[X > 8 \mid X > 7] = \frac{2/10}{3/10} = \frac{2}{3}$，而 $\Pr[X > 1] = 0.9$。**均匀分布有记忆**：已经等过去的每一分钟都在"消耗"剩余的等待时间。同理，人的寿命、灯泡寿命（会老化）都有记忆；而无记忆性恰恰是"元件不会老化、故障随机发生"的数学刻画。若一个"已用 10 年的灯泡"与"全新灯泡"在未来一年内损坏的概率相同，则该灯泡的寿命模型就是指数分布。

定理 24.5（期望的线性性对连续情形成立）：设 X, Y 是连续随机变量（**可以相关**），$a, b \in \mathbb{R}$。则

$$\mathbb{E}[aX + bY] = a\,\mathbb{E}[X] + b\,\mathbb{E}[Y].$$

证明策略：直接证明，把 $\mathbb{E}[aX+bY]$ 写成二重积分，用积分的线性性把 a,b 提出来、把二重积分拆成两个。选择这个策略是为了展示"离散情形的证明一字不改地平移过来"。

逐步推导：

第 1 步（用联合密度写期望）。设 (X,Y) 的联合密度为 f，则

$$\mathbb{E}[aX+bY]=\int_{-\infty}^{\infty}\int_{-\infty}^{\infty}(ax+by)f(x,y)\,dx\,dy.$$

第 2 步（拆成两项）：

$$=a\int_{-\infty}^{\infty}\int_{-\infty}^{\infty}xf(x,y)\,dx\,dy+b\int_{-\infty}^{\infty}\int_{-\infty}^{\infty}yf(x,y)\,dx\,dy.$$

第 3 步（还原边缘密度）：由 $f_X(x)=\int_{-\infty}^{\infty}f(x,y)dy$ 与 $f_Y(y)=\int_{-\infty}^{\infty}f(x,y)dx$，

$$=a\int_{-\infty}^{\infty}xf_X(x)\,dx+b\int_{-\infty}^{\infty}yf_Y(y)\,dy=a\,\mathbb{E}[X]+b\,\mathbb{E}[Y].$$

第 4 步（**注意：全程没有用到独立性**）。第 1 步只用到"(X,Y) 有联合密度"，第 3 步只用到边缘密度的定义。**线性性对任意相关的 (X,Y) 都成立**，这一点与讲次 20 的离散版本完全一致。真正需要独立性的公式是方差可加（$\mathbf{Var}(X+Y)=\mathbf{Var}(X)+\mathbf{Var}(Y)$，讲次 22），或期望的乘法分解（$\mathbb{E}[XY]=\mathbb{E}[X]\mathbb{E}[Y]$）。

【证明机制解说】：这条定理是连续概率里最实用的工具，因为它把"算一个复杂量的期望"降级成"算若干个简单量的期望之和"。它会在下一讲 CLT 的应用（置信区间、二项近似、负载均衡）以及 Buffon 投针的第二种证明里反复出场。

定理 24.6（独立连续随机变量的联合密度分解）：设连续随机变量 X,Y 独立，边缘密度分别为 f_X,f_Y。则联合密度满足

$$f(x,y)=f_X(x)\,f_Y(y)\quad\text{对一切 }x,y\in\mathbb{R}.$$

证明策略：直接证明，用"小方块"把独立性的定义（区间形式）转写成密度形式，再取极限。关键在于**两边都除以 $dx\,dy$**。

逐步推导：

第 1 步（小方块近似）：由联合密度的意义，

$$f(x,y)\,dx\,dy\approx\Pr[x\le X\le x+dx,\ y\le Y\le y+dy].$$

第 2 步（用独立性拆开）：由 X,Y 独立的定义（区间事件独立），

$$\Pr[x\le X\le x+dx,\ y\le Y\le y+dy]=\Pr[x\le X\le x+dx]\cdot\Pr[y\le Y\le y+dy].$$

第 3 步（两边换成密度）：

$$=\big(f_X(x)\,dx\big)\cdot\big(f_Y(y)\,dy\big)=f_X(x)f_Y(y)\,dx\,dy.$$

第 4 步（相除取极限）：把第 1 步与第 3 步的 $f(x,y)dxdy\approx f_X(x)f_Y(y)dxdy$ 两边除以 $dx\,dy>0$，并令 $dx,dy\to0$，得到 $f(x,y)=f_X(x)f_Y(y)$。

【证明机制解说】：这条定理的价值在于**把独立性检查变成一次因式分解**：看到联合密度能拆成"只含 x 的因子 × 只含 y 的因子"，就能立刻断定独立。用它一秒判定：三角形上均匀分布的密度 $f(x,y)=2\cdot\mathbf{1}\{x\ge0,y\ge0,x+y\le1\}$ **不能**因式分解（因为指示函数里 $x+y\le1$ 把两个变量纠缠在一起），所以那个例子里的 X,Y **不独立**；而矩形 $[a,b]\times[c,d]$ 上均匀分布的密度 $=\frac{1}{b-a}\cdot\frac{1}{c-d}$ 是常数乘积，**独立**。

定理 24.7（Buffon 投针 Buffon's Needle）：在画有间距为 d 的平行线的木板上随机投掷一根长为 $L\le d$ 的针。则针与某条线相交的概率为

$$\Pr[\text{相交}]=\frac{2L}{\pi d}.$$

特别地取 $L=d$ 时 $\Pr[\text{相交}]=2/\pi$。

证明策略：几何概率 (geometric probability)——把随机投掷翻译成两个连续随机变量 (Y,Θ) 的联合密度，把"相交"这个几何条件写成不等式 $Y\le\frac{L}{2}\cos\Theta$，然后在二维区域上积分。选择这个策略是因为它示范了**"全概率=面积比例"**这一几何思路，并且顺带给出一个估计 π 的算法。

逐步推导：

第 1 步（选随机变量）。针的落位完全由两个量决定：– Y = 针的中点到最近一条平行线的距离，取值于 $[0,d/2]$；– Θ = 针与**竖直方向**的夹角，取值于 $[-\pi/2,\pi/2]$。

第 2 步（联合密度）。"完全随机地投掷"意味着 (Y,Θ) 在矩形 $[0,d/2]\times[-\pi/2,\pi/2]$ 上均匀分布，且 Y 与 Θ 独立。该矩形面积为 $\frac{d}{2}\cdot\pi=\frac{\pi d}{2}$，故

$$f(y,\theta)=\frac{1}{\pi d/2}=\frac{2}{\pi d},\qquad(y,\theta)\in\Big[0,\tfrac{d}{2}\Big]\times\Big[-\tfrac{\pi}{2},\tfrac{\pi}{2}\Big].$$

第 3 步（归一化验证）：

$$\int_{-\pi/2}^{\pi/2}\int_0^{d/2}\frac{2}{\pi d}\,dy\,d\theta=\int_{-\pi/2}^{\pi/2}\frac{2}{\pi d}\cdot\frac{d}{2}\,d\theta=\int_{-\pi/2}^{\pi/2}\frac{1}{\pi}d\theta=\frac{1}{\pi}\cdot\pi=1.\ \checkmark$$

第 4 步（把"相交"写成几何条件）。针的一个端点到中点的竖直位移是 $\frac{L}{2}\cos\Theta$（这个公式对 $|\Theta|\le\pi/2$ 保证余弦非负，所以不会出现符号问题）。于是

$$\text{针与线相交}\iff Y\le\frac{L}{2}\cos\Theta.$$

第 5 步（积分）：

$$\Pr[\text{相交}] = \int_{-\pi/2}^{\pi/2}\int_{0}^{(L/2)\cos\theta} \frac{2}{\pi d}\, dy\, d\theta = \frac{2}{\pi d}\int_{-\pi/2}^{\pi/2} \frac{L}{2}\cos\theta\, d\theta = \frac{L}{\pi d}\int_{-\pi/2}^{\pi/2}\cos\theta\, d\theta.$$

第 6 步（初等积分）：

$$\int_{-\pi/2}^{\pi/2}\cos\theta\, d\theta = \sin\theta\Big|_{-\pi/2}^{\pi/2} = 1-(-1) = 2.$$

故

$$\Pr[\text{相交}] = \frac{L}{\pi d}\cdot 2 = \frac{2L}{\pi d}.$$

第 7 步（脚本验算）。取 $L = d = 1$：解析值 $2/\pi = 0.6366197724$；Simpson 数值积分 $\int_{-\pi/2}^{\pi/2}\frac{1}{\pi}\cos\theta\, d\theta = 0.6366197724$ ✓。蒙特卡洛投针 2×10^6 次：相交比例 0.63673（理论 0.636620），反推 $\hat\pi = 2N/C = 3.1410$ ✓。取 $L=1, d=2$：$2L/(\pi d) = 1/\pi = 0.318310$ ✓。

第 8 步（估计 π 的算法）。设投掷 n 次、其中 C 次相交，则由大数定律（讲次 23）$\hat p = C/n \to 2L/(\pi d)$，故

$$\hat\pi = \frac{2Ln}{Cd}.$$

用切比雪夫不等式可以把 n 定到"以 $1-\delta$ 的把握使 $|\hat p - p| \le \epsilon$"（讲次 23 的标准套路）。

第 9 步（第二种证明：指示变量 + 期望线性性）。设 X 为单位长针的相交次数（0 或 1），故 $\mathbb{E}[X] = \Pr[X=1]$，我们要证它等于 $2/\pi$。把一根单位长针切成 m 段等长小段，则 $X = I_1 + \cdots + I_m$（I_i 为第 i 段是否相交的指示变量），由线性性

$$\mathbb{E}[X] = \sum_{i=1}^{m}\mathbb{E}[I_i] = m\,\mathbb{E}[I_1] \implies \mathbb{E}[I_1] = \frac{1}{m}\mathbb{E}[X] = (\text{该段长度})\cdot\mathbb{E}[X].$$

把若干段首尾用可旋转关节连起来得到"面条 (noodle)"，则**任意形状面条的期望相交次数 = 总长度 $\times\mathbb{E}[X]$**。现在取一个**直径为 1 的圆**（周长 π）：它必定与水平线恰好相交两次（对任何竖直平移都成立），所以它的相交次数恒为 2（这不是期望，是必然值）。于是

$$\pi\cdot\mathbb{E}[X] = 2 \implies \mathbb{E}[X] = \Pr[X=1] = \frac{2}{\pi}.$$

【证明机制解说】：第一种证明的核心是**"把所有随机性参数化为少数几个连续变量，然后一次积分"**——这是所有几何概率问题的模板。第二种证明（Buffon 面条）的核心是**期望线性性 + 构造一个"每次相交次数恒定"的形状**。第二步是真正的灵感：**用圆把未知量 $\mathbb{E}[X]$ 反解出来**，因为圆的答案我们不需要任何计算就知道（永远是 2）。这展示了线性性最强大的用法：**不需要独立性，只需要"能把量拆成线性组合"**。

与经典问题的联系

（1）随机算法与几何概率：用投针估 π。 这是蒙特卡洛方法 (Monte Carlo method) 的祖师爷。实际问题（18 世纪 Buffon 提出的"投针求 π"）→ 数学建模（(Y,Θ) 的联合均匀密度）→ 方案设计（投 n 次，数相交次数 C，输出 $2Ln/(Cd)$）→ 正确性证明（定理 24.7 给出 $\mathbb{E}[C/n] = 2L/(\pi d)$，大数定律（讲次 23）给出 $C/n \to 2L/(\pi d)$）→ 复杂度/精度（切比雪夫或 CLT（讲次 25）定 n）。同一套"随机采样估计确定量"的思想今天用于积分、渲染、金融定价、机器学习。

（2）负载均衡与排队论：指数分布刻画到达间隔。 若请求以恒定速率 λ 随机到达（泊松过程 Poisson process），则**相邻两次到达的间隔服从 $\mathbf{Exp}(\lambda)$**，且**无记忆性**意味着"我们是否需要立刻扩容"不取决于"上一个请求是多久之前来的"。这直接解释了为什么排队论里 M/M/1 等模型的推导能如此干净：无记忆性让系统状态只需记录"当前队列长度"，而不需要记录历史。这正是讲次 26 马尔可夫性质的连续版本。

（3）可靠性工程：寿命模型。 若元件失效率恒定（不老化），则寿命 $\sim\mathbf{Exp}(\lambda)$。$\mathbb{E}[\text{寿命}] = 1/\lambda$ 给出平均无故障时间 (MTTF)。工程上常把 λ 视为"每小时的故障率"（如 $\lambda = 10^{-5}$/小时），则 MTTF $= 10^5$ 小时 ≈ 11.4 年。

（4）哈希与随机化的连续视角。 讲次 20 讨论的哈希负载均衡用的是离散方法（指示变量 + 线性性）。连续版本是把"球落进箱子的比例"用连续密度近似，进而用 CLT 得到"最大负载 $\approx$ 均值 $+3\sqrt{\text{均值}}$"这类结论（见讲次 25）。

（5）与后续马尔可夫链的接口。 连续时间马尔可夫链 (CTMC) 的"在每个状态停留的时间"服从指数分布，而无记忆性正是让"状态转移"成为可能的数学基础：如果停留时间有记忆，那么"下一步往哪走"就必须依赖已停留多久，状态就不再是充分的。

与其他讲次的关联

- **讲次 15（概率公理 Probability Foundations）**：那里定义了概率空间 $(\Omega,\mathcal{F},\Pr)$ 的三条公理，其中**可数可加性**是公理之一。本讲正是靠"可数可加性只对可数并成立"来解释"不可数多个零概率事件之并可以是概率 1 的事件"，从而让"点概率为 0 但事件可能发生"在公理体系内自洽。
- **讲次 19（随机变量与离散分布 Random Variables & Discrete Distributions）**：几何分布 $G(p)$ 是**指数分布的离散原型**，本讲的定理 24.4 第 5–6 步把两者的无记忆性形式逐项对照，并显式取 $\delta\to0$ 的极限 $\lim_{\delta\to0}(1-\lambda\delta)^{t/\delta} = e^{-\lambda t}$ 建立"连续化"的桥梁。几何分布的期望 $1/p$ 也对应指数分布的 $1/\lambda$。
- **讲次 20（期望与线性性 Expectations & Linearity）**：$\mathbb{E}[aX+bY] = a\mathbb{E}[X]+b\mathbb{E}[Y]$ 在连续情形的证明（定理 24.5）与讲次 20 的离散证明结构完全一致，唯一的改动是"求和换积分、PMF 换 PDF"；Buffon 投针的第二种证明（定理 24.7 第 9 步）正是讲次 20"指示变量 + 线性性"手法的连续应用。
- **讲次 21（联合分布与随机变量独立性 Joint Distributions & Independence of RVs）**：本讲的联合密度（定义于"核心概念的直观解释"一节）就是讲次 21 离散联合 PMF 的积分版本；定理 24.6 的 $f(x,y) = f_X(x)f_Y(y)$ 是讲次 21"独立 $\iff$ PMF 分解"的连续对应物，边缘化（$\int$ 掉一个变量）对应讲次 21 的边缘求和。
- **讲次 22（方差与协方差 Variance & Covariance）**：$\mathbf{Var}(X) = \mathbb{E}[X^2] - \mathbb{E}[X]^2$ 这一恒等式（连续版本见本讲定义）在讲次 22 已用离散形式证明过一次；证明过程只用期望线性性，因此对连续情形一字不改地成立。方差可加需要独立（或至少不相关），本讲明确划出这条边界。

- **讲次 23（集中不等式 Concentration Inequalities）**：本讲只给出连续分布及其期望方差，尚未讨论"样本均值波动多大"；切比雪夫不等式与（弱）大数定律是讲次 23 的成果，它们被本讲用来论证"投针估 π 一定会成功"以及给出所需投掷次数的保守估计。下一讲会用一个更强的结论（CLT）取代这里的粗略估计。
- **讲次 25（高斯分布与中心极限定理 Gaussian Distribution & CLT）**：本讲建立的三类连续分布中最重要的一类（正态）留到下一讲；CLT 的陈述必须使用本讲的 PDF/CDF/期望/方差语言，而"独立正态之和仍是正态"的证明要用到本讲的联合密度与独立密度分解。
- **讲次 26（马尔可夫链与条件期望 Markov Chains & Conditional Expectation）**：本讲定理 24.4 的**无记忆性**就是讲次 26 **马尔可夫性质**的"时间连续版"：马尔可夫性质说"给定现在，未来与过去条件独立"，无记忆性说"给定已等待 s，剩余等待时间的分布与 s 无关"。两者是同一个"遗忘性"直觉在不同数学框架下的呈现。
- **讲次 14（计数 Counting）与讲次 16（组合证明 Combinatorial Proofs）**："把面积/长度按比例分配"这一几何概率思想可以视为计数原理的连续化，而 Buffon 面条证明（把针切成 m 段再用线性性）本质上是用**离散分解 + 极限**去解决连续问题。

关键要点

1. **连续情形的三句口号**：点概率让位给区间概率；PMF 让位给 PDF；求和让位给积分。具体地 $\Pr[X=a]=0$、$\Pr[a\le X\le b]=\int_a^b f$、$\mathbb{E}[X]=\int x f(x)dx$。
2. **$f(x)$ 不是概率**。它是"单位长度的概率"，$f(x)dx$ 才是（近似）概率。$f(x)$ 可以大于 1：$U[0,\frac{1}{2}]$ 的密度是 2，$U[0,0.1]$ 的密度是 10，$\mathrm{Exp}(10)$ 在 0 处密度是 10。唯一判据是 $\int_{-\infty}^{\infty} f=1$。
3. **"概率为 0"不等于"不可能"**。连续情形每个单点概率都是 0，但不可数多个零概率事件之并可以有概率 1——可数可加性只管可数并。
4. **两个核心分布的闭式结果**：
5. 均匀 $U[a,b]$：$\mathbb{E}=(a+b)/2$，$\mathrm{Var}=(b-a)^2/12$，密度 $1/(b-a)$。
6. 指数 $\mathrm{Exp}(\lambda)$：PDF $\lambda e^{-\lambda x}$、CDF $1-e^{-\lambda x}$、$\Pr[X>t]=e^{-\lambda t}$、$\mathbb{E}=1/\lambda$、$\mathrm{Var}=1/\lambda^2$，且**标准差 = 均值**。
7. **无记忆性 = 指数律**。$\Pr[X>s+t\mid X>s]=\Pr[X>t]$ 之所以成立，全靠 $e^{-\lambda(s+t)}=e^{-\lambda s}e^{-\lambda t}$ 与尾事件的嵌套性；反之，解函数方程 $g(s+t)=g(s)g(t)$ 会逼出 $g(t)=e^{-\lambda t}$，故指数分布是唯一无记忆的连续分布。它是讲次 19 几何分布的无记忆性在 $\delta\to 0$ 下的极限。
8. **期望线性性在连续情形同样免费**：$\mathbb{E}[aX+bY]=a\mathbb{E}[X]+b\mathbb{E}[Y]$ 对**任意**（可以强相关）的 X,Y 成立，因为证明只用积分的线性性与边缘密度定义。要额外的独立性才能用的公式是方差可加。

常见误区与注意事项

1. **把 $f(x)$ 当作 $\Pr[X=x]$**。最典型的表现是看到 $U[0,1/2]$ 密度为 2 就慌乱，或者把 $f(x)$ 直接乘进求和式算期望。正确读法是"$f(x)$ 是密度，$f(x)dx$ 才是概率"，且**密度没有上界 1**。
2. **认为 $\Pr[X=x]=0$ 就意味着 $X=x$ 不可能**。这是把离散直觉硬搬到连续。正确理解："概率 0"与"不可能"在连续世界不等价，因为可数可加性只对可数并成立；$[0,\ell]=\bigcup_x[x,x]$ 是不可数并。
3. **算方差时把 $\mathbb{E}[X]^2$ 当成 $\mathbb{E}[X^2]$**。$\mathrm{Var}(X)=\mathbb{E}[X^2]-\mathbb{E}[X]^2$ 里后者是"先求期望、再平方"，与"先平方、再求期望"完全不同。指数分布里 $\mathbb{E}[X^2]=2/\lambda^2$ 而 $\mathbb{E}[X]^2=1/\lambda^2$，混淆会得到错误的 $2/\lambda^2$。
4. **把积分上下限照抄成 $[-\infty,\infty]$ 而不看密度的支撑**。$U[a,b]$ 的积分实际只在 $[a,b]$ 上做，$\mathrm{Exp}(\lambda)$ 的积分只在 $[0,\infty)$ 上做。忘记截断会导致把常数密度 $1/(b-a)$ 积分到无穷而得到 ∞。
5. **以为"无记忆性"是等待时间的一般性质**。均匀分布、正态分布、Gamma 分布（整数形状参数 ≥ 2）都**有记忆**。用 $U[0,10]$ 的具体反例检验：$\Pr[X>8\mid X>7]=2/3\neq 0.9=\Pr[X>1]$。
6. **在连续化时把参数范围搞错**。几何分布的参数 p 必须满足 $p\le 1$，而指数分布的速率 λ 可以任意大（$\lambda>0$）。反过来，把几何分布的 p 直接当成 λ 会得到错误的量纲（p 无量纲，λ 的量纲是 $1/$时间）。
7. **要求期望线性性附带独立性条件**。线性性**从不**需要独立性；需要独立性的是 $\mathbb{E}[XY]=\mathbb{E}[X]\mathbb{E}[Y]$ 与 $\mathrm{Var}(X+Y)=\mathrm{Var}(X)+\mathrm{Var}(Y)$。这条误区在 Buffon 面条证明里会直接导致思路卡死（"两根针的相交指示变量难道独立吗？"——根本不重要）。

思考题（带答案）

Q1.（纯计算） 设 $X\sim U[-2,3]$，$Y\sim\mathrm{Exp}(2)$，X 与 Y 独立。计算：(a) $\Pr[X\in[0,2]]$；(b) $\Pr[X>2\mid X>1]$；(c) $\mathbb{E}[3X-4Y]$；(d) $\Pr[Y>1\mid Y>0.5]$；(e) $\mathrm{Var}(X)$ 与 $\mathrm{Var}(Y)$。

▸ **答案**

(a) $U[-2,3]$ 的密度是 $1/(3-(-2))=1/5$。故

$$\Pr[X\in[0,2]]=\frac{2-0}{3-(-2)}=\frac{2}{5}=0.4.$$

(b) 均匀分布**有记忆**，直接算：

$$\Pr[X>2\mid X>1]=\frac{\Pr[X>2]}{\Pr[X>1]}=\frac{(3-2)/5}{(3-1)/5}=\frac{1/5}{2/5}=\frac{1}{2}=0.5.$$

（注意 $\neq\Pr[X>1]=0.4$，所以确实有记忆。）

(c) 由线性性（无需独立性）：

$$\mathbb{E}[X]=\frac{-2+3}{2}=0.5,\qquad \mathbb{E}[Y]=\frac{1}{2}=0.5.$$

故 $\mathbb{E}[3X-4Y]=3(0.5)-4(0.5)=1.5-2=-0.5$。

(d) 指数分布**无记忆**，所以

$$\Pr[Y>1\mid Y>0.5]=\Pr[Y>0.5]=e^{-2\times0.5}=e^{-1}=0.36787944.$$

（数值核对：$e^{-2\cdot1}/e^{-2\cdot0.5}=e^{-2}/e^{-1}=e^{-1}$ ✓。）

(e) $\mathbf{Var}(X)=\frac{(3-(-2))^2}{12}=\frac{25}{12}=2.083333$；$\mathbf{Var}(Y)=\frac{1}{2^2}=0.25$。（脚本 Simpson 数值积分核对：$\mathbf{Var}(X)$ 数值 2.083333 ✓，$\mathbf{Var}(Y)$ 数值 0.250000 ✓。）

Q2.（概念/证明） 证明：若连续随机变量 X 取值于 $[0,\infty)$ 且满足无记忆性

$$\Pr[X>s+t\mid X>s]=\Pr[X>t]\quad\text{对一切 }s,t\geq0,$$

且 X 的尾函数 $g(t):=\Pr[X>t]$ 连续，则必有 $g(t)=e^{-\lambda t}$ 对某个 $\lambda>0$，即 $X\sim\mathbf{Exp}(\lambda)$。

▸ **答案**

证明策略：把无记忆性翻译成函数方程 $g(s+t)=g(s)g(t)$，再解这个方程。关键是先证明 g **单调不增**，从而可以取对数，把乘法方程变成加法方程（柯西方程），最后用连续性定出线性解。

逐步推导：

第 1 步（把条件概率展开）。$X\geq0$ 保证 $\Pr[X>s]>0$ 对一切 $s\geq0$ 成立（且 g 严格正：见第 3 步）。由尾事件嵌套 $\{X>s+t\}\subseteq\{X>s\}$，

$$g(s+t)=\Pr[X>s+t]=\Pr[X>s+t\mid X>s]\cdot\Pr[X>s]=\Pr[X>t]\cdot\Pr[X>s]=g(t)\,g(s).$$

故 g 满足**函数方程** $g(s+t)=g(s)g(t)$ 对一切 $s,t\geq0$。

第 2 步（g 单调不增）。由 X 取值于 $[0,\infty)$，$\{X>t'\}\subseteq\{X>t\}$ 对 $t'\geq t$，故 $g(t')\leq g(t)$。又 $g(0)=\Pr[X>0]=1$。

第 3 步（$g>0$）。若存在 t_0 使 $g(t_0)=0$，则对一切 $t\geq t_0$ 有 $g(t)=0$。由 $g(0)=1$ 与 g 单调，这允许"跳到 0 后永远为 0"的解（对应"有界支撑"的分布）。要排除它，用 X 的无记忆性本身：设 t_1 是 g 第一次取 0 的下确界。若 $t_1<\infty$，取 $s=t_1/2$，则 $g(t_1)=g(t_1/2)^2$，而 $g(t_1)=0$ 要求 $g(t_1/2)=0$，与 t_1 的定义（下确界）矛盾。故 $g(t)>0$ 对一切 $t\geq0$。（这正是"无记忆性排除有界支撑"的机制：**有界支撑的分布如 $U[0,10]$ 会因为 $g(10)=0$ 而在 $t=10$ 处破坏相乘关系**。）

第 4 步（取对数）。定义 $h(t)=\ln g(t)$，良定义（$g>0$）且 $h(0)=0$。由第 1 步取对数得**柯西方程 (Cauchy equation)**：

$$h(s+t)=h(s)+h(t)\quad\text{对一切 }s,t\geq0.$$

第 5 步（解柯西方程）。由 h 连续（g 连续）且单调不增，可得存在常数 c 使 $h(t)=ct$。理由是标准的：先由归纳得 $h(nt)=nh(t)$ 对正整数 n，再对有理数 $q=m/n$ 得 $h(q)=qh(1)$，最后用连续性把有理逼近推广到一切实数。

第 6 步（定符号）。因 g 单调不增且 $g(0)=1$，故 $g(t)\leq1$，即 $h(t)\leq0$，于是 $c\leq0$。令 $\lambda:=-c\geq0$。若 $\lambda=0$ 则 $g\equiv1$，即 $\Pr[X=\infty]=1$，与"X 是实值随机变量且 $\Pr[X<\infty]=1$"矛盾。故 $\lambda>0$，从而

$$g(t)=e^{-\lambda t}\implies F(t)=1-e^{-\lambda t}\implies X\sim\mathbf{Exp}(\lambda).$$

证明机制解说：全证明只有两个"灵光一现"：(i) 把条件概率展开成**乘法函数方程** $g(s+t)=g(s)g(t)$；(ii) 认识到 $g>0$ 所以可以对数化，从而把乘法问题变成加法问题。这是"化归"的典范：指数函数是唯一满足 $g(s+t)=g(s)g(t)$ 的连续函数，所以**无记忆性等价于指数分布**。

Q3.（概念/反例） 判断下列陈述真假并说明理由：(a) "若 $\Pr[A]=0$，则 $A=\emptyset$。" (b) "若连续随机变量 X 的密度在 $x=0$ 处满足 $f(0)=5$，则 $\Pr[X=0]=5$。" (c) "两个连续随机变量 X,Y 满足 $\mathbf{cov}(X,Y)=0$，则它们独立。" (d) "若 $g(x)=f(x)$ 在除有限个点外处处相等，则 g 与 f 导出同一个概率分布。"

▸ 答案

(a) **假。** 取 $X \sim U[0,1]$，$A = \{X = 0.5\} \neq \emptyset$（$0.5$ 确实是 X 可能取的值），但 $\Pr[A] = 0$。连续概率里"零概率"与"空事件"是两回事：$\Pr$ 只对**可数并**可加，而单点事件有不可数多个，它们的并 $\{X \in [0,1]\}$ 概率为 1。**注意区分**："零概率"在离散情形等价于"不可能"（因为样本点可数，零概率点之并仍零概率），在连续情形不等价。

(b) **假（且荒谬）。** $\Pr[X = 0] = 0$ 对任何连续随机变量成立（连续分布没有原子）。$f(0) = 5$ 只说明"落在 0 附近每单位长度的概率是 5"，即 $\Pr[0 \le X \le 0.01] \approx 0.05$。密度可以任意大：$U[0, 0.1]$ 的密度处处是 10，$\mathbf{Exp}(10)$ 在 0 处密度是 10。

(c) **假。** 不相关 $\not\Rightarrow$ 独立（讲次 22 已给出离散反例）。连续反例：取 $X \sim U[-1,1]$，$Y = X^2$。则 $\mathbb{E}[X] = 0$，$\mathbb{E}[XY] = \mathbb{E}[X^3] = 0$（奇函数在对称区间上积分为 0），故 $\mathbf{cov}(X,Y) = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y] = 0$。但 Y **完全由** X **决定**（知道 X 就精确知道 Y），显然不独立。**正确方向**是"独立 $\Rightarrow$ 不相关"（当二阶矩存在时）。

(d) **真。** 因为概率由积分给出：$\Pr[a \le X \le b] = \int_a^b f$，而积分对**零测集**（有限个点、甚至可数多个点）的改动不敏感。所以 f 只在有限个点上与 g 不同不影响任何事件的概率。**推论**：连续分布没有唯一的密度函数，密度是"几乎处处 (almost everywhere)"意义下确定的。这也是为什么"$f(x) = \Pr[X = x]$"这种想法从一开始就不对——连 f 的逐点值都不是唯一确定的量。

Q4.（多个分布的图形对照） 下面这张 ASCII 图刻画了 $U[0,1]$、$\mathbf{Exp}(1)$、$\mathbf{Exp}(2)$ 的密度形状。请据此回答：为什么 $U[0,1]$ 的方差（$1/12 \approx 0.0833$）比 $\mathbf{Exp}(1)$ 的方差（1）小得多，尽管两者的"平均高度"看起来相近?

```
f(x)
2.0 |*
    |*
1.6 |*  .                       <- Exp(2): lambda*e^{-2x}, f(0)=2
    |*  .  .
1.2 |*   .   ..                 <- Exp(1): lambda*e^{-x},  f(0)=1
    |*    .     ...._
0.8 |*     .          ----______
    |*      .                   <- U[0,1]: f(x)=1 on [0,1], 0 elsewhere
0.4 |*______.____,_______-------
    |*      .    |
0.0 +*------+----+--------------> x
    0      1    2    3    4
    |<-- 均匀分布的全部质量挤在宽度 1 内 -->|

面积恒等式：int f = 1 对三条曲线都成立
U[0,1]   : 底 1 x 高 1  = 1
Exp(1)   : 长尾，质量拖到无穷远
Exp(2)   : 更陡更尖，但尾巴更短
```

▸ 答案

关键在**质量的"摊开程度"不同**，而方差的本质就是"质量离均值多远"。

- $U[0,1]$：均值 $\mu = 0.5$，质量全部集中在 $[0,1]$ 这个**宽度为 1** 的区间内，故标准差 $\sigma = 1/\sqrt{12} = 0.2887 \le 0.5$，永远不超过半宽。事实上 $\Pr[|X - \mu| > 0.5] = 0$——**均匀分布是"最集中"的分布**（在固定支撑长度的分布中，均匀分布方差最大，但对 $[0,1]$ 与 $\mathbb{R}_+$ 这个比较而言它显然最窄）。
- $\mathbf{Exp}(1)$：均值 $\mu = 1$，但**长尾拖到无穷**。计算 $\Pr[X > 3] = e^{-3} = 0.0498 \approx 5\%$ 的质量落在 3 之外，$\Pr[X > 5] = 0.0067$。这些"极远"的样本贡献了巨大的 $(x - \mu)^2$（如 $x = 5$ 贡献 $(4)^2 = 16$）。别忘了一个漂亮的事实：指数分布的标准差 $=$ 均值 $= 1$，即 $\sigma/\mu = 1$，而均匀分布的 $\sigma/\mu = 0.2887/0.5 = 0.577$。**变异系数 (coefficient of variation)** 正是这个比值。
- $\mathbf{Exp}(2)$：$\mu = 0.5$，$\sigma = 0.5$，形状与 $\mathbf{Exp}(1)$ "自相似"（只是横轴压缩 2 倍），所以方差是 $\mathbf{Exp}(1)$ 的 $1/4$。

为什么视觉上"平均高度接近"却方差差 12 倍? 因为 $U[0,1]$ 的"高"来自**窄底**（底宽 1、高 1），$\mathbf{Exp}(1)$ 的"高"来自**长尾换面积**（$f(0) = 1$ 但底延伸到无穷）。把面积归一化到 1 之后，**同样的"高度"配不同长度的"底"，得到的离散程度完全不同**。离散类比：一个取 $\{0,1\}$ 各 $1/2$ 的分布方差是 0.25，而一个取 $\{0, 100\}$ 各 $1/2$ 的分布方差是 2500——两者的"高度"（PMF 值）都是 $1/2$，但尺度差 100 倍，方差差 10^4 倍。

脚本对照表：

分布	$\mathbb{E}$	Var	σ	σ/μ
$U[0,1]$	0.5	0.083333	0.2887	0.577
$U[0,10]$	5	8.333333	2.887	0.577
$\mathbf{Exp}(1)$	1	1	1	1
$\mathbf{Exp}(2)$	0.5	0.25	0.5	1

结论：Var 是**尺度敏感**的量（量纲是单位平方），比较不同分布时最好同时看 σ/μ 这个无量纲比值。

Lecture 25: Gaussian Distribution & CLT（高斯分布与中心极限定理）

概述

上一讲我们建立了连续概率的框架，并认识了两个分布：均匀分布与指数分布。本讲要介绍第三个、也是**在应用中压倒性最重要**的连续分布：**正态分布（normal distribution）**，又称**高斯分布（Gaussian distribution）**。它由两个参数刻画——均值 μ 与方差 σ^2——密度是一条关于 $x=\mu$ 对称的"钟形曲线"。

但正态分布真正的主角地位来自本讲的核心定理：**中心极限定理 (Central Limit Theorem, CLT)**。它说：**任意**独立同分布的随机变量之和，只要均值与方差有限，标准化之后都收敛到标准正态分布。也就是说，不论原始分布长什么样（均匀、指数、二项、骰子、高度偏斜……），**把它们加起来、平均起来，形状一律变成钟形**。原分布的全部信息只剩下两个数：均值 μ 与方差 σ^2。

这是整个课程"从特殊到普遍"最震撼的一步：讲次 23 的大数定律只告诉我们"样本均值趋于 μ"，CLT 则告诉我们"围绕 μ 的**波动**长什么样、有多大"——误差量级是 $\sigma/\sqrt{n}$，且形状是正态。本讲末尾还会讲清 CLT 的**边界**：需要有限方差、需要（近似）独立、n 要够大、而且它说的是"**均值的分布**"而非"数据本身"。

核心概念的直观解释

正态分布 / 高斯分布 (Normal / Gaussian Distribution)

- **定义**：对任意 $\mu\in\mathbb{R}$ 与 $\sigma>0$，若连续随机变量 X 的概率密度为

$$f(x)=\frac{1}{\sqrt{2\pi\sigma^2}}\exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right),$$

则称 X 服从参数为 μ,σ^2 的**正态分布**，记作 $X\sim\mathcal{N}(\mu,\sigma^2)$。特别地，$\mu=0,\sigma=1$ 时称为**标准正态分布 (standard normal)**，记为 $\mathcal{N}(0,1)$。

- **直观解释（"它是什么意思？"）**：把 $f(x)$ 拆成三块看。
- **指数里的 $-(x-\mu)^2/(2\sigma^2)$**：这是**钟形**的来源。随着 $|x-\mu|$ 增大，$(x-\mu)^2$ 二次增长，$e^{-(\cdot)}$ 极速衰减，所以曲线在两侧迅速贴近 0。二次型是"惩罚偏离均值"的最自然方式（类比：最小二乘、误差平方和）。
- **$x=\mu$ 是唯一的峰值点**，且曲线关于 $x=\mu$ **左右对称**（因为 $(x-\mu)^2$ 是 $x-\mu$ 的偶函数）。
- **分母里的 σ**：σ 越大，指数衰减越慢，钟形越"胖"；σ 越小越"瘦高"。而前面的系数 $1/\sqrt{2\pi\sigma^2}$ 正是为让总面积为 1 而设的归一代价：**σ 变大 $\Rightarrow$ 峰变矮、范围变宽，面积不变**。峰高恰好是 $f(\mu)=1/\sqrt{2\pi\sigma^2}\approx 0.4/\sigma$。

现实类比：正态分布是"**大量微小独立扰动之叠加**"的模型。Berkeley 蚊子的体重（受无数基因与环境微扰共同决定）、物理实验的观测误差（无数仪器与环境误差叠加）、某地成年男性身高（同理）——都近似正态。这不奇怪，因为它正是 CLT 的结论。

- **具体示例**：$X\sim\mathcal{N}(0,1)$ 时 $f(0)=1/\sqrt{2\pi}=0.398942$（脚本验算）。$X\sim\mathcal{N}(2,4)$（即 $\mu=2,\sigma=2$）时峰值在 $x=2$、峰高 $=1/\sqrt{2\pi\cdot 4}=0.199471$，恰为标准正态峰高的一半。

标准化 (Standardization)

- **定义**：若 $X\sim\mathcal{N}(\mu,\sigma^2)$，定义

$$Z=\frac{X-\mu}{\sigma},$$

则 $Z\sim\mathcal{N}(0,1)$（见定理 25.2）。反过来，若 $Z\sim\mathcal{N}(0,1)$，则 $X=\sigma Z+\mu\sim\mathcal{N}(\mu,\sigma^2)$。

- **直观解释**：标准化 = "**先把原点平移到均值处（减去 μ），再把长度单位换成标准差（除以 σ）**"。做完这两步，一切正态分布都变成同一条曲线 $\mathcal{N}(0,1)$。生活类比：把不同学科的成绩换算成"离班级平均几个标准差"，就得到可比的 z 分数 (z-score)。
- **具体示例**：设 $X\sim\mathcal{N}(70,100)$（$\mu=70$ 分，$\sigma=10$ 分）。则 $X=85$ 对应 $z=(85-70)/10=1.5$，即"高于平均 1.5 个标准差"。于是

$$\Pr[X\le 85]=\Pr[Z\le 1.5].$$

这就是为什么统计书里只需要一张标准正态表：**把问题约化到 $\mathcal{N}(0,1)$ 之后，所有正态分布共用同一张表。**

68–95–99.7 法则（经验法则 Empirical Rule）

- **内容**：若 $X\sim\mathcal{N}(\mu,\sigma^2)$，则

区间	概率（脚本验算）	近似口诀
$\mu\pm 1\sigma$	$\Pr[\lvert Z\rvert\le 1]=0.682690$	$\approx 68\%$
$\mu\pm 2\sigma$	$\Pr[\lvert Z\rvert\le 2]=0.954500$	$\approx 95\%$
$\mu\pm 3\sigma$	$\Pr[\lvert Z\rvert\le 3]=0.997300$	$\approx 99.7\%$
$\mu\pm 0.6745\sigma$	$\Pr[\lvert Z\rvert\le 0.6745]=0.500007$	中央 50%
$\mu\pm 1.96\sigma$	$\Pr[\lvert Z\rvert\le 1.96]=0.950004$	中央 95%（置信区间用）
$\mu\pm 2.576\sigma$	$\Pr[\lvert Z\rvert\le 2.576]=0.990005$	中央 99%

- **直观解释**：注意**单侧**与**双侧**的区别：$\Pr[Z\le 1]=0.841345$（单侧 84%），但 $\Pr[|Z|\le 1]=0.682690$（双侧 68%）。另外记一个常用数：$\Pr[Z>1.96]\approx 0.025$，所以"均值 ± 1.96 个标准差"正好夹住中央 95% 的质量。为什么要 1.96 而不是 2？因为 2 给出 95.45%（少了一点），要精确 95% 需把半宽放宽到 1.96σ。

- **具体示例**：$X \sim \mathcal{N}(70, 100)$（$\sigma = 10$）。则 $\Pr[60 \le X \le 80] \approx 68.3\%$，$\Pr[50 \le X \le 90] \approx 95.5\%$，$\Pr[40 \le X \le 100] \approx 99.7\%$。若某天有人考了 102 分，那已经超出 3 个标准差（$z = 3.2$），$\Pr[Z > 3.2] \approx 0.0007$——"千年一遇"，值得怀疑是不是卷子有问题（这正是 p 值/异常检测的思想）。

为什么正态分布无处不在?

- **答案**：因为它是**"大量微小独立扰动之和"的极限分布**。设一个量 $X = \sum_{i=1}^{n} Y_i$，其中每个 Y_i 是"一个小扰动"（同分布、独立，$\mathbb{E}[Y_i] = \mu_i$、$\mathrm{Var}(Y_i) = \sigma_i^2$）。只要 n 大且没有单个 Y_i 支配总和，X 的分布就接近正态，参数是 $\mu = \sum \mu_i$、$\sigma^2 = \sum \sigma_i^2$。**原分布的形状被彻底"洗掉"**，只剩一阶矩与二阶矩。
- **直观解释**：这也是为什么"误差"在科学中普遍正态：一次测量误差是许多独立微小误差之和；身高、体重、血压、考试成绩是许多独立微小遗传与环境因素之和。
- **具体示例（骰子之和）**：单枚骰子是**离散均匀**分布（完全不像钟形），但脚本验算表明 n 枚骰子之和与正态的最大点偏差随 n 迅速缩小：

n	均值 $3.5n$	标准差 $\sqrt{35n/12}$	与正态的最大点偏差
1	3.5	1.7078	0.08666
2	7	2.4152	0.01364
5	17.5	3.8188	0.00327
10	35	5.4006	0.00118
30	105	9.3541	0.00023

$n = 1$ 时偏差 0.087（很不像），$n = 30$ 时只有 0.00023（几乎一样）。 而且 $n = 1$ 的骰子是"平的"，正态近似根本不成立；$n = 2$ 是三角形；$n = 3$ 已经明显像钟了。

中心极限定理 (Central Limit Theorem, CLT)

- **定义 / 陈述**：设 $X_1, X_2, \ldots$ 是**独立同分布** (i.i.d.) 的随机变量序列，$\mathbb{E}[X_i] = \mu$、$\mathrm{Var}(X_i) = \sigma^2$ 都有限且 $\sigma^2 > 0$。记 $S_n = \sum_{i=1}^{n} X_i$。则标准化和

$$\frac{S_n - n\mu}{\sigma\sqrt{n}} \xrightarrow{d} \mathcal{N}(0,1) \quad (n \to \infty),$$

这里的 $\xrightarrow{d}$ 表示**依分布收敛** (convergence in distribution)。等价地，对任意常数 $c \in \mathbb{R}$，

$$\Pr\left[\frac{S_n - n\mu}{\sigma\sqrt{n}} \le c\right] \longrightarrow \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{c} e^{-x^2/2}\, dx = \Phi(c).$$

- **等价形式（更常用）**：样本均值 $\bar{X}_n = S_n/n$ 满足

$$\frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \xrightarrow{d} \mathcal{N}(0,1), \qquad \text{即} \qquad \bar{X}_n \approx \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right).$$

注意这两个式的分母不同：和 S_n 的波动是 $\sigma\sqrt{n}$，均值的波动是 $\sigma/\sqrt{n}$。$\bar{X}_n$ 的均值与方差我们早就知道（分别是 μ 与 σ^2/n，讲次 20 与 22）；CLT 的新信息是**"分布形状变成正态"**。

- **直观解释（"它是什么意思？"）**：**误差量级 $\sigma/\sqrt{n}$。** 这是全文最重要的一个量。想让估计精度提高一倍，样本量要增加到 4 倍（因为 $\sqrt{n}$）。想让精度提高 10 倍，要 100 倍样本量。这条"开根号定律"支配着所有抽样调查、蒙特卡洛模拟、A/B 测试的成本预算。
- **具体示例**：一枚公平骰子 $\mu = 3.5$、$\sigma = \sqrt{35/12} = 1.707825$。掷 $n = 100$ 次，则 $\bar{X} \approx \mathcal{N}(3.5, 0.029168)$，标准差 $\sigma/\sqrt{100} = 0.170783$。所以"100 次掷骰子平均值落在 3.5 ± 0.335 内"的概率约 95%（$1.96\sigma/\sqrt{n} = 0.33473$）。脚本用 2×10^4 次独立实验模拟，实测 95% 置信区间覆盖率为 0.9515——与理论 0.95 吻合。

CLT 与大数定律 (LLN) 的对比

- **大数定律（讲次 23）**：$\dfrac{S_n}{n} \to \mu$（依概率），即**"均值收敛到 μ"**。它只说"会靠近"，不说"多近、以什么形状靠近"。
- **中心极限定理（本讲）**：$\dfrac{S_n - n\mu}{\sigma\sqrt{n}} \xrightarrow{d} \mathcal{N}(0,1)$，即**"偏离的尺度与形状"**。它给出 $\bar{X}_n$ 的**波动量级** $\sigma/\sqrt{n}$ 与**波动的分布形状** $\mathcal{N}$。
- **类比**：LLN 说"箭最终会射中靶心附近的某个点"；CLT 说"箭的散布服从二维正态，散布半径正比于 $1/\sqrt{n}$、并精确告诉你命中环数的概率"。**LLN 是 CLT 的"粗糙版"**：由 CLT 可以推出 LLN（因为 $\sigma/\sqrt{n} \to 0$，正态分布的质量越来越集中在 0 附近），但反过来不行。

连续性修正 (Continuity Correction)

- **问题**：CLT 的极限分布是**连续**的正态，而被近似的对象（如二项分布 $B(n,p)$）是**离散**的。直接代入会产生系统性偏差。
- **修正规则**：把离散点 k 看作连续区间 $[k - \frac{1}{2}, k + \frac{1}{2}]$（"把每个整数摊成一个宽度 1 的小柱"）。于是

$$\Pr[X \le k] \approx \Phi\left(\frac{k + 0.5 - n\mu}{\sigma}\right), \quad \Pr[X \ge k] \approx 1 - \Phi\left(\frac{k - 0.5 - n\mu}{\sigma}\right),$$

$$\Pr[a \le X \le b] \approx \Phi\left(\frac{b + 0.5 - n\mu}{\sigma}\right) - \Phi\left(\frac{a - 0.5 - n\mu}{\sigma}\right).$$

- **具体示例（脚本验算，$n = 30, p = 0.5$，$\mu = 15$，$\sigma = \sqrt{7.5} = 2.738613$）**：

目标量	精确值	无修正	有修正
$\Pr[X=15]$	0.144464	0.145673（密度法）	—
$\Pr[X\le 15]$	0.572232	$\Phi(0)=0.500000$ ✗	$\Phi(0.5/\sigma)=0.572434$ ✓
$\Pr[10\le X\le 20]$	0.957226	0.932111	0.955390

注意无修正在 $\Pr[X\le 15]$ 上错得离谱（0.500 vs 真实 0.572），因为 $\Pr[X\le 15]$ 在对称情况下恰好卡在中点，非常敏感。修正后误差降到 0.0002。再看 $n=100, p=0.4$（$\mu=40, \sigma=4.8990$）：$\Pr[35\le X\le 45]$ 精确 0.738573，有修正 0.738428 ✓，无修正 0.692566（误差 0.046）。**结论：连续性修正是"便宜且必要"的改进，务必加上。**

置信区间 (Confidence Interval)

- **构造**：设 $X_1,\dots,X_n$ i.i.d.，均值 μ、方差 σ^2。由 CLT，$\Pr[-1.96\le \frac{\bar X-\mu}{\sigma/\sqrt n}\le 1.96]\approx 0.95$。把不等式对 μ 解出来：

$$\Pr\left[\bar X-\frac{1.96\sigma}{\sqrt n}\le\mu\le\bar X+\frac{1.96\sigma}{\sqrt n}\right]\approx 0.95.$$

区间 $\left[\bar X-\frac{1.96\sigma}{\sqrt n},\ \bar X+\frac{1.96\sigma}{\sqrt n}\right]$ 称为 μ 的 **95% 置信区间**。

- **确切含义（必须说清）**：μ 是一个**固定的未知常数**（不是随机变量）；随机的是**区间的两个端点**。所以这句话的意思是：**"如果把这个实验（抽 n 个样本、算出这个区间）重复无数次，那么其中约 95% 的区间会盖住真值 μ。"** 这是一个关于**整个程序 (procedure)** 的长期频率保证，而不是关于某一次具体区间的概率断言。
- **常见误读**：
- ✗ "μ 落在本次区间内的概率是 95%。" —— 对固定的一次实验，μ 要么在区间里、要么不在，没有概率可言（频率学派解释下）。
- ✗ "95% 的数据落在区间内。" —— 数据落在 $\bar X\pm 1.96\sigma/\sqrt n$ 内的比例远小于 95%：这个半宽是**均值**的波动量级（$\sigma/\sqrt n$），不是**数据**的波动量级（σ）。真正含 95% 数据的是 $\bar X\pm 1.96\sigma$（宽 $\sqrt n$ 倍）。
- ✗ "区间越宽越有把握，所以干脆取 100% 置信。" —— 置信区间宽度与置信度是一对权衡；100% 置信需要区间是整个实数轴，毫无信息量。
- ⚠ 反向陷阱："样本量增加 4 倍只能把半宽减半，所以不值得多做实验。" —— 半宽是 $\sigma/\sqrt n$，$n\to 4n$ 恰使半宽减半。这个"减半"在精度敏感的场景（如药品审批）往往正是必须付的代价；错的是以为 $n\to 2n$ 就能减半。
- **具体示例**：单骰子 $\sigma=1.707825$。脚本验算 95% 置信区间半宽随 n 的收缩：

n	半宽 $1.96\sigma/\sqrt n$
100	0.33473
400	0.16737
1000	0.10585
10000	0.03347

n 从 100 到 10000（×100），半宽从 0.3347 降到 0.0335（÷10）——正是 $\sqrt{100}=10$ 的开根号定律。

CLT 的证明思路（矩生成函数 / 特征函数）

- **工具**：**矩生成函数 (Moment Generating Function, MGF)** $M_X(t)=\mathbb{E}[e^{tX}]$，或**特征函数 (characteristic function)** $\varphi_X(t)=\mathbb{E}[e^{itX}]$（后者总存在，前者可能发散）。核心事实：**分布被特征函数唯一确定，且依分布收敛 $\iff$ 特征函数逐点收敛。**
- **为什么选这个策略**：因为独立性让和的 MGF 变成乘积：$M_{X+Y}(t)=M_X(t)M_Y(t)$（离散情形由 $\mathbb{E}[e^{t(X+Y)}]=\mathbb{E}[e^{tX}]\mathbb{E}[e^{tY}]$ 得到，用到独立性）。**"求和 → 求积"是把 n 个变量的问题压成 n 次方的关键。**
- **步骤概要**（下一节给出可计算的详细版本）：标准化后 $Z_n=\sum_i(X_i-\mu)/(\sigma\sqrt n)$，则 $\log M_{Z_n}(t)=n\log M_{(X-\mu)/\sigma}(t/\sqrt n)$。把 $\log M$ 在 0 附近做 Taylor 展开，一次项为 0（因为中心化后均值为 0）、二次项为 $t^2/2$（因为二次项系数是方差，标准化后方差为 1），于是 $n\log M(t/\sqrt n)\to nt^2/(2n)=t^2/2$，即 $M_{Z_n}(t)\to e^{t^2/2}$。而 $e^{t^2/2}$ 正是 $\mathcal N(0,1)$ 的 MGF。**证毕。**
- **本课定位**：官方 Note 只给出 CLT 的陈述与直觉，完整的解析证明（含上述 Taylor 展开的严格余项控制、以及"特征函数唯一决定分布"）超出本课范围。但**机制的核心**——"一次项消失、二次项来自方差、n 次方恰好把 $1/n$ 抵消掉，留下 $e^{t^2/2}$"——是完全可以讲清楚的，下面给出脚本可验证的版本。

独立正态之和仍是正态 (Sum of Independent Normals)

- **定理**：设 $X\sim\mathcal N(\mu_X,\sigma_X^2)$、$Y\sim\mathcal N(\mu_Y,\sigma_Y^2)$ **独立**，$a,b\in\mathbb R$。则

$$Z=aX+bY\sim\mathcal N\left(a\mu_X+b\mu_Y,\ a^2\sigma_X^2+b^2\sigma_Y^2\right).$$

特别地，$a=b=1$ 时 $X+Y\sim\mathcal N(\mu_X+\mu_Y,\sigma_X^2+\sigma_Y^2)$：**均值相加、方差相加。** – **直观解释**：正态族在"独立相加"下**闭包 (closed)**——这是它极其好用的原因（类比：讲次 19 的二项分布是伯努利分布之和，也闭包；正态是它的连续对应）。注意方差前的系数是 a^2,b^2（平方），因为方差是二次量。 – **具体示例**：$X\sim\mathcal N(1,4)$、$Y\sim\mathcal N(-1,9)$ 独立，则 $X+Y\sim\mathcal N(0,13)$，即均值 0、标准差 $\sqrt{13}=3.605551$。脚本用 Box–Muller 生成 4×10^5 对样本，得 $\mathbb{E}[X+Y]=-0.0079$、$\mathrm{Var}(X+Y)=13.0441$——与 $(0,13)$ 吻合。

完整证明与推导（核心）

定理 25.1（高斯积分：正态密度是合法的 PDF）：$\int_{-\infty}^{\infty}e^{-x^2/2}\,dx=\sqrt{2\pi}$。从而对任意 μ,σ，$\int_{-\infty}^{\infty}\frac{1}{\sqrt{2\pi\sigma^2}}e^{-(x-\mu)^2/(2\sigma^2)}dx=1$。

证明策略：**极坐标技巧 (polar coordinates trick)**。选择这个策略的理由很实际：$e^{-x^2/2}$ 没有初等原函数，所以一维直接积分走不通。但**平方之后变成二重积分**，被积函数 $e^{-(x^2+y^2)/2}$ 只依赖半径 $r=\sqrt{x^2+y^2}$，在极坐标下**分离变量**，两个方向各自都变得好算。这是数学中最著名的"绕道"之一。

逐步推导：

第 1 步（平方，升维）。设 $I=\int_{-\infty}^{\infty}e^{-x^2/2}dx$。则

$$I^2=\left(\int_{-\infty}^{\infty}e^{-x^2/2}dx\right)\left(\int_{-\infty}^{\infty}e^{-y^2/2}dy\right)=\int_{-\infty}^{\infty}\int_{-\infty}^{\infty}e^{-(x^2+y^2)/2}\,dx\,dy.$$

这一步的依据是**Fubini 定理**：$e^{-(x^2+y^2)/2}>0$，非负函数的二重积分等于两个一维积分的乘积（也可直接看作把两个独立的一维积分合并成平面上的积分）。

第 2 步（换极坐标）。令 $x=r\cos\theta$、$y=r\sin\theta$，$r\in[0,\infty)$、$\theta\in[0,2\pi)$。此时

$$x^2+y^2=r^2,\qquad dx\,dy=r\,dr\,d\theta.$$

注意那个关键的 Jacobi 因子 r—它不是装饰，正是它让径向积分可算。

第 3 步（分离变量）：

$$I^2=\int_0^{2\pi}\int_0^{\infty}e^{-r^2/2}\,r\,dr\,d\theta=\left(\int_0^{2\pi}d\theta\right)\left(\int_0^{\infty}re^{-r^2/2}\,dr\right).$$

第 4 步（算两个一维积分）。– 角度部分：$\int_0^{2\pi}d\theta=2\pi$。– 径向部分：令 $u=r^2/2$，则 $du=r\,dr$，故

$$\int_0^{\infty}re^{-r^2/2}dr=\int_0^{\infty}e^{-u}du=\Big[-e^{-u}\Big]_0^{\infty}=1.$$

数值核对：Simpson 在 $[0,40]$ 上算得 1.0000000000 ✓。

第 5 步（开方）：

$$I^2=2\pi\cdot1=2\pi\implies I=\sqrt{2\pi}=2.5066282746.$$

数值核对：Simpson 在 $[-40,40]$ 上算 $\int e^{-x^2/2}dx=2.5066282746$ ✓，与 $\sqrt{2\pi}$ 完全一致。顺带 $\int e^{-x^2}dx=\sqrt{\pi}=1.7724538509$ ✓。

第 6 步（一般 μ,σ）。令 $x=\mu+\sigma y$，则 $dx=\sigma\,dy$、$(x-\mu)^2/(2\sigma^2)=y^2/2$，所以

$$\int_{-\infty}^{\infty}\frac{1}{\sqrt{2\pi\sigma^2}}e^{-(x-\mu)^2/(2\sigma^2)}dx=\frac{1}{\sqrt{2\pi\sigma^2}}\cdot\sigma\int_{-\infty}^{\infty}e^{-y^2/2}dy=\frac{\sigma\sqrt{2\pi}}{\sqrt{2\pi\sigma^2}}=1.\ \checkmark$$

数值核对：$\frac{1}{\sqrt{2\pi}}\int e^{-x^2/2}dx=1.0000000000$ ✓。

第 7 步（非负性校验）。$e^{\text{任意实数}}>0$，系数 $1/\sqrt{2\pi\sigma^2}>0$，故 $f(x)>0$ 处处成立 ✓。两条 PDF 公设都满足，f 确实是一个概率密度。

【证明机制解说】：这个证明的"灵光一现"是**"平方升维 + 极坐标"**。为什么必须绕道？因为 $\int e^{-x^2/2}dx$ 的困难在于被积函数虽然简单，其原函数却不是初等函数（误差函数 erf 不是初等函数）。平方之后 x 与 y **对称出现**，而极坐标恰好把这个对称性利用起来：$x^2+y^2=r^2$ 让指数变成纯粹的 r 的函数，Jacobi 因子 r 又恰好凑出一个完美可积的形式。这个技巧会在任何涉及"正态归一化"的地方反复出现——例如"独立正态之和仍是正态"的旋转对称证明（见定理 25.4）、以及二维正态的协方差结构。

定理 25.2（标准化定理）：若 $X\sim\mathcal{N}(\mu,\sigma^2)$，则 $Y=\dfrac{X-\mu}{\sigma}\sim\mathcal{N}(0,1)$。

证明策略：直接证明——**用 CDF 做变量替换**。选择 CDF 而不是密度的理由：CDF 方法不需要背"密度如何变换"的公式（那需要 Jacobi 因子），它只需要把事件 $\{Y\le b\}$ 翻译回 X 的语言，然后在 X 的密度上积分。

逐步推导：

第 1 步（把事件翻译回去）。对 $a<b$，

$$a\le Y\le b\iff a\le\frac{X-\mu}{\sigma}\le b\iff\sigma a+\mu\le X\le\sigma b+\mu.$$

这里用到 $\sigma>0$（不等号方向不变）。

第 2 步（换成 X 的密度积分）：

$$\Pr[a\le Y\le b]=\Pr[\sigma a+\mu\le X\le\sigma b+\mu]=\int_{\sigma a+\mu}^{\sigma b+\mu}\frac{1}{\sqrt{2\pi\sigma^2}}e^{-(x-\mu)^2/(2\sigma^2)}dx.$$

第 3 步（换元 $x=\sigma y+\mu$）。此时 $dx=\sigma\,dy$，$x-\mu=\sigma y$，积分限从 $[\sigma a+\mu,\sigma b+\mu]$ 变成 $[a,b]$：

$$=\frac{1}{\sqrt{2\pi\sigma^2}}\int_a^b e^{-(\sigma y)^2/(2\sigma^2)}\cdot\sigma\,dy=\frac{\sigma}{\sqrt{2\pi\sigma^2}}\int_a^b e^{-y^2/2}dy=\frac{1}{\sqrt{2\pi}}\int_a^b e^{-y^2/2}dy.$$

第 4 步（读出结论）。右端恰是 $\mathcal{N}(0,1)$ 密度在 $[a,b]$ 上的积分。因这对一切 $a<b$ 成立，故 $Y\sim\mathcal{N}(0,1)$。

第 5 步（逆命题）。若 $Y\sim\mathcal{N}(0,1)$ 且 $X=\sigma Y+\mu$，同样的换元（反向走一遍）给出 $X\sim\mathcal{N}(\mu,\sigma^2)$。

【证明机制解说】：**"平移 + 缩放"是正态分布的自同构 (automorphism)**。这两种操作把正态族映到自身，所以整个族只有一个"本质形态" $\mathcal{N}(0,1)$。这就是"只需要一张标准正态表"的数学依据。请注意第 3 步中 σ 从换元里冒出来、恰好抵消分母里的 $\sqrt{\sigma^2}$——这不是巧合，而是为让归一化在缩放后仍成立所必需的（密度是"每单位长度的概率"，长度单位放大 σ 倍，密度就要除以 σ）。

反例 / 注意点：这个"平移 + 缩放不变性"**不是所有分布都有**。以均匀分布为例，$U[0,1]$ 经过 $X \mapsto \sigma X + \mu$ 变成 $U[\mu, \mu+\sigma]$，**仍然是均匀分布**（也是闭包的），但形变后不再是同一个分布（除非 $\sigma = 1$ 且 $\mu = 0$）。指数分布更惨：$\mathbf{Exp}(1)$ 经过 $Y \mapsto \sigma Y$ 变成 $\mathbf{Exp}(1/\sigma)$，**形状仍然是同一条曲线的压缩**（缩放闭包），但**平移会彻底破坏它**：$Y + c$（$c > 0$）不再是任何指数分布，因为它的支撑变成了 $[c, \infty)$、在 0 附近密度为 0。也就是说，**指数族只有缩放闭包、没有平移闭包；正态族两者都有。** 这个对称性上的巨大差异正是正态分布"特殊"的地方之一。整篇 CLT 存在的意义就是解释这种特殊性。

定理 25.3（正态分布的均值与方差）：若 $X \sim \mathcal{N}(\mu, \sigma^2)$，则 $\mathbb{E}[X] = \mu$、$\mathbf{Var}(X) = \sigma^2$。

证明策略：先在**标准情形** $\mathcal{N}(0,1)$ 上做（利用奇偶性把一阶矩免费拿下，用分部积分把二阶矩归约到高斯积分），再用定理 25.2 的标准化 + 期望线性性与方差的性质搬到一般情形。选择这个策略是因为**对称性能省掉大量计算**——这是数学中的通用省力法。

逐步推导：

第 1 步（标准情形，期望）。设 $Z \sim \mathcal{N}(0,1)$：

$$\mathbb{E}[Z] = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} x e^{-x^2/2} dx.$$

把积分从 0 拆开：$\int_{-\infty}^{0} + \int_{0}^{\infty}$。作变量替换 $x \mapsto -x$ 在负半轴上：$e^{-(-x)^2/2} = e^{-x^2/2}$、$dx \mapsto -dx$、积分限 $(-\infty, 0) \to (\infty, 0)$，于是

$$\int_{-\infty}^{0} x e^{-x^2/2} dx = \int_{\infty}^{0} (-x) e^{-x^2/2} (-dx) = -\int_{0}^{\infty} x e^{-x^2/2} dx.$$

两部分**恰好抵消**（被积函数 $x e^{-x^2/2}$ 是**奇函数**，在对称区间上积分为 0）：

$$\mathbb{E}[Z] = \frac{1}{\sqrt{2\pi}} \left(-\int_{0}^{\infty} x e^{-x^2/2} dx + \int_{0}^{\infty} x e^{-x^2/2} dx \right) = 0.$$

第 2 步（标准情形，二阶矩）。由 $\mathbb{E}[Z] = 0$，

$$\mathbf{Var}(Z) = \mathbb{E}[Z^2] = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} x^2 e^{-x^2/2} dx.$$

用分部积分：取 $u = x$、$dv = x e^{-x^2/2} dx$，则 $du = dx$、$v = -e^{-x^2/2}$。于是

$$\int_{-\infty}^{\infty} x^2 e^{-x^2/2} dx = \underbrace{\left[-x e^{-x^2/2} \right]_{-\infty}^{\infty}}_{=0\text{（指数衰减压倒多项式）}} + \int_{-\infty}^{\infty} e^{-x^2/2} dx = \sqrt{2\pi} \quad \text{（定理 25.1）}.$$

故

$$\mathbf{Var}(Z) = \frac{1}{\sqrt{2\pi}} \cdot \sqrt{2\pi} = 1.$$

第 3 步（一般情形，期望）。由定理 25.2，$Z = (X - \mu)/\sigma \sim \mathcal{N}(0,1)$，故 $\mathbb{E}[Z] = 0$。由期望线性性（讲次 20、讲次 24 定理 24.5），

$$0 = \mathbb{E}\left[\frac{X - \mu}{\sigma} \right] = \frac{\mathbb{E}[X] - \mu}{\sigma} \implies \mathbb{E}[X] = \mu.$$

第 4 步（一般情形，方差）。由 $\mathbf{Var}(Z) = 1$ 与 $\mathbf{Var}(aX + b) = a^2 \mathbf{Var}(X)$，

$$1 = \mathbf{Var}\left(\frac{X - \mu}{\sigma} \right) = \frac{\mathbf{Var}(X)}{\sigma^2} \implies \mathbf{Var}(X) = \sigma^2.$$

第 5 步（参数命名的闭环）。这解释了记号 $\mathcal{N}(\mu, \sigma^2)$ 里两个参数**正是**均值与方差；也解释了为什么 σ 控制"宽度"：由切比雪夫不等式（讲次 23），constant fraction 的质量落在 $\mu \pm 2\sigma$ 内（实际 95.45%，远好于切比雪夫给的 $\geq 75\%$）。

【证明机制解说】：两个"省力技巧"值得记住：– **奇偶性**：$\mathcal{N}(0,1)$ 的密度是偶函数，故 $x \cdot f(x)$ 是奇函数，对称区间积分为 0。**对称分布的中心就是它的均值**——证明只需一行。 – **升降阶归约**：把 $\int x^2 e^{-x^2/2} dx$ 分部积分后**恰好变回高斯积分** $\int e^{-x^2/2} dx$，而后者已在定理 25.1 算出。这与讲次 24 中"把 $\int x^2 \lambda e^{-\lambda x} dx$ 归约到 $\mathbb{E}[X]$"是同一招。**看到"多项式 × 指数"的积分，先想分部积分降阶。**

反例（对称不等于正态）：$\mathcal{N}(0,1)$ 的对称性只用来算均值，**不能**反过来说"对称的分布就是正态"。例如 $X = 2B - 1$，其中 $B \sim \mathbf{Bernoulli}(1/2)$，则 X 在 $\{-1, +1\}$ 上对称、$\mathbb{E}[X] = 0$，但它显然是离散的两点分布，与正态毫无关系。另一个反例：密度 $f(x) = \frac{1}{2} e^{-|x|}$（Laplace 分布）关于 0 对称且连续，均值也是 0、方差是 2，但它**在 0 处是尖峰（不可导）**，概率质量比正态更集中在中心、尾部更重（指数尾而非高斯尾）。所以要做正态的假设，**必须检验尾部的薄厚**，光看对称是不够的。

定理 25.4（独立正态之和仍是正态，标准情形的旋转对称证明）：设 X, Y i.i.d. $\mathcal{N}(0,1)$，$a, b \in \mathbb{R}$。则 $Z = aX + bY \sim \mathcal{N}(0, a^2 + b^2)$。

证明策略：**利用联合密度的旋转对称性 (rotational symmetry)**。选择这个策略的理由：定理 25.1 用的极坐标技巧告诉我们 $\mathcal{N}(0,1)$ 的二变量联合密度只依赖半径，因此**对平面上的旋转不变**。而 $aX + bY$ 的分布通过"半平面被旋转成竖直半平面"就直接读出来——完全不需要算卷积积分。

逐步推导：

第 1 步（写出联合密度）。X, Y 独立且各自 $\mathcal{N}(0,1)$，由定理 24.6（连续情形的独立密度分解），

$$f(x, y) = f_X(x) f_Y(y) = \frac{1}{\sqrt{2\pi}} e^{-x^2/2} \cdot \frac{1}{\sqrt{2\pi}} e^{-y^2/2} = \frac{1}{2\pi} e^{-(x^2+y^2)/2}.$$

第 2 步（旋转对称性）。上式**只依赖** $x^2 + y^2$（即 (x, y) 到原点的距离平方），因此对任何绕原点的旋转 T，

$$f(T(x,y)) = f(x,y) \implies \Pr[(X,Y) \in A] = \Pr[(X,Y) \in T(A)] \quad \text{对任意区域 } A.$$

数值佐证：极坐标下的总质量 $2\pi\int_0^\infty re^{-r^2/2}dr = 2\pi\cdot 1 = 6.2831853072$ ✓（脚本验算），与 2π 一致。

第 3 步（把事件写成半平面）。对任意 $t\in\mathbb{R}$，

$$\Pr[Z\le t] = \Pr[aX+bY\le t] = \Pr[(X,Y)\in A],\qquad A := \{(x,y) : ax+by\le t\}.$$

A 是**半平面**，其边界直线 $ax+by=t$ 到原点的距离是

$$d = \frac{|t|}{\sqrt{a^2+b^2}}.$$

第 4 步（把半平面旋转成"竖直"的）。平面上的旋转可以把任何过原点的直线转到竖直方向，因此把 A 旋转成

$$T(A) = \left\{(x,y) : x \le \frac{t}{\sqrt{a^2+b^2}}\right\}.$$

——这个新区域是"直线 $x = t/\sqrt{a^2+b^2}$ 左侧"的半平面，且**到原点的距离完全相同**（都是 d，这正是旋转保持距离的体现）。

第 5 步（用旋转不变性读出分布）。由第 2 步，

$$\Pr[Z\le t] = \Pr[(X,Y)\in A] = \Pr[(X,Y)\in T(A)] = \Pr\left[X \le \frac{t}{\sqrt{a^2+b^2}}\right] = \Pr\left[\sqrt{a^2+b^2}\,X \le t\right].$$

第 6 步（结论）。上式对**一切** $t\in\mathbb{R}$ 成立，故 Z 与 $\sqrt{a^2+b^2}\,X$ **同分布**。而由定理 25.2 的缩放性质，$\sqrt{a^2+b^2}\,X \sim \mathcal{N}(0, a^2+b^2)$。故

$$Z = aX+bY \sim \mathcal{N}(0, a^2+b^2).$$

【证明机制解说】：这个证明的"灵光一现"是**把"线性组合"转化为"距离"**。关键是意识到：$aX+bY\le t$ 描述的是"点 (X,Y) 落在某条直线的一侧"，而这条直线的**位置**完全由它到原点的距离决定；由于联合密度只关心"点离原点多远"，**旋转不改变任何概率**，于是任意方向的半平面都与"竖直半平面"等价。几何直觉：**二维标准正态是一团各向同性的云雾**，你从任何角度看它都一模一样，所以只落在某个方向的投影分量必然是标准正态（按投影长度缩放）。

推论 25.1（一般情形的相加公式）：设 $X\sim\mathcal{N}(\mu_X,\sigma_X^2)$、$Y\sim\mathcal{N}(\mu_Y,\sigma_Y^2)$ 独立，$a,b\in\mathbb{R}$。则

$$Z = aX+bY \sim \mathcal{N}\left(a\mu_X+b\mu_Y,\ a^2\sigma_X^2+b^2\sigma_Y^2\right).$$

证明：由标准化定理，$Z_1=(X-\mu_X)/\sigma_X$ 与 $Z_2=(Y-\mu_Y)/\sigma_Y$ 是**独立**的标准正态（独立性由"独立随机变量的函数仍独立"保证）。把 $X=\mu_X+\sigma_XZ_1$、$Y=\mu_Y+\sigma_YZ_2$ 代入：

$$Z = a(\mu_X+\sigma_XZ_1)+b(\mu_Y+\sigma_YZ_2) = \underbrace{(a\mu_X+b\mu_Y)}_{\text{常数}} + \underbrace{(a\sigma_XZ_1+b\sigma_YZ_2)}_{=:Z'}.$$

由定理 25.4，$Z'\sim\mathcal{N}(0,a^2\sigma_X^2+b^2\sigma_Y^2)$。再由定理 25.2 的"加常数"性质，$Z=\mu+Z'\sim\mathcal{N}(\mu,\sigma^2)$，其中 $\mu=a\mu_X+b\mu_Y$、$\sigma^2=a^2\sigma_X^2+b^2\sigma_Y^2$。■

特例（方差可加）：取 $a=b=1$，得

$$X+Y\sim\mathcal{N}(\mu_X+\mu_Y,\ \sigma_X^2+\sigma_Y^2).$$

脚本验算：$X\sim\mathcal{N}(1,4)$、$Y\sim\mathcal{N}(-1,9)$，理论 $X+Y\sim\mathcal{N}(0,13)$、$\sigma=\sqrt{13}=3.605551$。用 Box–Muller 生成 4×10^5 对独立样本：样本均值 -0.0079（理论 0），样本方差 13.0441（理论 13）✓。

反例（去掉独立性，结论立刻失效）：取 $Y=-X$，其中 $X\sim\mathcal{N}(0,1)$。则 $X+Y=0$ 恒等于 0——这是**退化**的"分布"（全部质量在 0），而不是 $\mathcal{N}(0,1+1)=\mathcal{N}(0,2)$。所以"方差相加"**必须**要独立性（准确地说，需要不相关；而独立是充分的）。

定理 25.5（CLT 的矩生成函数证明思路）：设 $X_1,X_2,\dots$ i.i.d.，$\mathbb{E}[X_i]=\mu$、$\mathrm{Var}(X_i)=\sigma^2\in(0,\infty)$。令 $Y_i=(X_i-\mu)/\sigma$（故 $\mathbb{E}[Y_i]=0$、$\mathrm{Var}(Y_i)=1$），$Z_n=\frac{1}{\sqrt{n}}\sum_{i=1}^n Y_i$。则对每个固定的 t，

$$M_{Z_n}(t) = \mathbb{E}\left[e^{tZ_n}\right] \longrightarrow e^{t^2/2},$$

而 $e^{t^2/2}$ 是 $\mathcal{N}(0,1)$ 的矩生成函数。由"矩生成函数在 0 的邻域内收敛 $\Rightarrow$ 依分布收敛"（Levy 连续性定理的 MGF 版本），即得 $Z_n\xrightarrow{d}\mathcal{N}(0,1)$。

证明策略：**把"和"变成"积"，再做 Taylor 展开取极限**。选择这个策略的理由：Z_n 是 n 个独立项之和，其 MGF 是 n 个 MGF 的**乘积**——一个指数级的对象被压成一个 n 次方。然后唯一需要的信息只是 M_Y 在 0 附近的**二阶展开**：一次项被中心化杀掉、二次项就是方差。n 次方恰好与 $1/\sqrt{n}$ 的缩放配合，把 $1/n$ 消掉。

逐步推导：

第 1 步（中心化与标准化）。令 $Y_i=(X_i-\mu)/\sigma$。则

$$\mathbb{E}[Y_i] = \frac{\mathbb{E}[X_i]-\mu}{\sigma} = 0,\qquad \mathrm{Var}(Y_i) = \frac{\mathrm{Var}(X_i)}{\sigma^2} = 1.$$

记公共 MGF 为 $M(t):=\mathbb{E}[e^{tY_i}]$（下标相同，因为同分布）。

第 2 步（和的 MGF = MGF 的积）。因为 Y_i 独立且 $Z_n=\frac{1}{\sqrt{n}}\sum_i Y_i$，

$$M_{Z_n}(t) = \mathbb{E}\left[\exp\left(\frac{t}{\sqrt{n}}\sum_{i=1}^n Y_i\right)\right] = \mathbb{E}\left[\prod_{i=1}^n e^{(t/\sqrt{n})Y_i}\right] \overset{\text{(i)}}{=} \prod_{i=1}^n \mathbb{E}\left[e^{(t/\sqrt{n})Y_i}\right] \overset{\text{(ii)}}{=} \left[M\left(\frac{t}{\sqrt{n}}\right)\right]^n.$$

其中 (i) 用独立性（独立随机变量之积的期望等于期望之积），(ii) 用同分布。**"和 → 积"这一步是整个证明的支点。**

第 3 步（对数化，把 n 次方变成乘法）：

$$\log M_{Z_n}(t) = n \log M\left(\frac{t}{\sqrt{n}}\right).$$

第 4 步（M 的 Taylor 展开）。把 $M(s)$ 在 $s=0$ 附近展开：

$$M(s) = \mathbb{E}[e^{sY}] = \mathbb{E}\left[1 + sY + \frac{s^2Y^2}{2} + O(s^3)\right] = 1 + s\,\mathbb{E}[Y] + \frac{s^2}{2}\mathbb{E}[Y^2] + O(s^3) = 1 + \frac{s^2}{2} + O(s^3).$$

关键：一次项系数是 $\mathbb{E}[Y]=0$（中心化的功劳），二次项系数是 $\frac{1}{2}\mathbb{E}[Y^2] = \frac{1}{2}\mathrm{Var}(Y) = \frac{1}{2}$（标准化的功劳：方差为 1）。

第 5 步（对 $\log$ 展开）。由 $\log(1+u) = u - u^2/2 + O(u^3)$，取 $u = s^2/2 + O(s^3)$：

$$\log M(s) = \frac{s^2}{2} + O(s^3).$$

这是"二阶项的来源"：它不来自任何复杂计算，就是"方差为 1"这一条信息。

第 6 步（代入 $s = t/\sqrt{n}$ 并取极限）：

$$\log M_{Z_n}(t) = n\left(\frac{(t/\sqrt{n})^2}{2} + O\left(\frac{t^3}{n^{3/2}}\right)\right) = n \cdot \frac{t^2}{2n} + O\left(\frac{t^3}{\sqrt{n}}\right) = \frac{t^2}{2} + O\left(\frac{t^3}{\sqrt{n}}\right) \longrightarrow \frac{t^2}{2}.$$

注意"n 次方恰好把 $1/n$ 消掉"——这是全证明最漂亮的一步：为什么归一化因子必须是 $\sqrt{n}$ 而不是 n？因为多乘一个 $t/\sqrt{n}$ 会带来 $1/n$ 的平方衰减，而 n 次方正好补回线性增长，留下常数 $t^2/2$。**若错误地用 n 归一化，$n\log M(t/n) \to 0$，得到的是退化分布；若用 $n^{1/4}$ 归一化，则对数发散。**（可由脚本核对：对 Y 取标准化 Bernoulli $=\pm 1$，$M(s)=\cosh s$，$\log\cosh s = s^2/2 - s^4/12 + O(s^6)$。脚本验算 $t=0.1$ 时 $\log\cosh(0.1) = 0.0049916888$ 与 $t^2/2 - t^4/12 = 0.0049916667$ 只差 2.2×10^{-8} ✓；$t=0.5$ 时 $\log\cosh(0.5) = 0.1201145070$ 与 $t^2/2 - t^4/12 = 0.1197916667$ 相差 0.0003 ✓。另外 $\log\cosh(t)/t^2 \to 1/2$：脚本在 $t=10^{-4}$ 处得 $\log\cosh(t)/t^2 = 0.50000000$ ✓。）

第 7 步（从 MGF 收敛到依分布收敛）：

$$M_{Z_n}(t) \to e^{t^2/2} \implies Z_n \xrightarrow{d} \mathcal{N}(0,1).$$

这一步用的是 **Levy 连续性定理**：若 MGF（或特征函数）在 $t=0$ 的一个邻域内逐点收敛到某个在 0 处连续的函数，则相应的分布依分布收敛到该极限 MGF 所对应的分布。而 $e^{t^2/2}$ 正是 $\mathcal{N}(0,1)$ 的 MGF（可由 $\int e^{tx}\frac{1}{\sqrt{2\pi}}e^{-x^2/2}dx = e^{t^2/2}$ 配完全平方得到）。

第 8 步（还原到 S_n）。$Z_n = \frac{1}{\sqrt{n}}\sum_i \frac{X_i-\mu}{\sigma} = \frac{S_n - n\mu}{\sigma\sqrt{n}}$，故定理得证。

【证明机制解说】：整个证明只有**三次"化归"**：1. **中心化**让一次项消失（否则会有漂移项 $n s\,\mathbb{E}[Y]$ 发散）；2. **标准化**让二次项恰好是 $1/2$（否则极限里会出现 $\sigma^2 t^2/2$，得到 $\mathcal{N}(0,\sigma^2)$，尺度失控）；3. $\sqrt{n}$ **归一化**让 n 次方与 $1/n$ 严丝合缝地抵消。这三步合起来解释了 CLT 为什么必须长成定理陈述里的那个样子。**注意证明中从未用到原始分布的具体形状**——只用到了 $\mathbb{E}[Y]=0$ 与 $\mathbb{E}[Y^2]=1$ 两个数。这就是"所有痕迹都被洗掉"的数学根源。**什么会破坏它？** 只要 $\mathbb{E}[Y^2]=\infty$（方差无穷，如 Cauchy 分布），第 4 步的 Taylor 展开就无从谈起，$M(s)$ 在 0 处甚至不可导/不存在（Cauchy 的 MGF 对所有 $t\neq 0$ 都发散），整个机制崩掉。这正是下一节反例的机理。

反例（Cauchy 分布：CLT 彻底失效）：设 $X_1, X_2, \ldots$ i.i.d. 服从**标准柯西分布 (standard Cauchy)**，密度

$$f(x) = \frac{1}{\pi(1+x^2)}, \qquad x \in \mathbb{R}.$$

这个密度很漂亮（钟形！关于 0 对称！），但它的**尾太厚**：$\Pr[|X|>t] \approx \frac{2}{\pi t}$，衰减只有 $1/t$（正态是 $e^{-t^2/2}$）。因此

$$\int_{-\infty}^{\infty} |x| f(x)\,dx = \frac{2}{\pi}\int_0^{\infty} \frac{x}{1+x^2}dx = \infty \quad \text{（对数发散）},$$

所以 $\mathbb{E}[|X|]=\infty$，**均值与方差都不存在**，CLT 的前提被直接违反。

更惊人的是：**样本均值 $\bar{X}_n$ 永远服从标准 Cauchy，与 n 无关**（可由特征函数 $\varphi(t)=e^{-|t|}$ 验证：$\varphi_{\bar{X}_n}(t) = \varphi(t/n)^n = e^{-n|t|/n} = e^{-|t|}$）。所以 $\bar{X}_n$ 的分布**根本不向任何东西集中**，更别说正态。

脚本验算（2×10^5 次实验，统计 $\Pr[|\bar{X}_n| \le 1]$）：

n	实测 $\Pr[\lvert\bar{X}_n\rvert \le 1]$	Cauchy 理论值	若 CLT 成立应为 $\Pr[\lvert Z\rvert \le 1] = 0.6827$
1	0.4999	0.5	0.6827
10	0.4997	0.5	0.6827
100	0.5000	0.5	0.6827
1000	0.4986	0.5	0.6827

n 从 1 增到 1000（增了 1000 倍），答案纹丝不动 $=0.5$。 这就是"重尾分布下 CLT 失效"的直观：**偶尔出现一个巨大到荒谬的样本（$|X|>10^6$ 的概率仍有 6×10^{-7}），它一旦出现就把前面 $n-1$ 个样本的平均值全部推翻**——均值的波动不会因为 n 增大而变小，因为最大样本的量级与 n 同阶增长。

反例（强相关：CLT 也需要"独立"）：设 $X_i = X$ 对所有 i（完全相关，每个都是同一个随机变量），则 $\bar{X}_n = X$ 恒成立，分布**完全不随 n 变化**，绝不会趋于一个尖峰（更不会正态）。若 X 不是正态，CLT 的结论就是错的。这说明"独立同分布"里的"独立"不可省。（弱相关情形的推广如 m-依赖序列、混合条件可以在附加假设下恢复 CLT，但要有额外条件。）

与经典问题的联系

（1）用正态近似算二项概率。 二项分布 $B(n,p)$ 是 n 个独立 $\text{Bernoulli}(p)$ 之和，$\mu = np$、$\sigma^2 = np(1-p)$。由 CLT，

$$B(n,p) \approx \mathcal{N}\big(np,\ np(1-p)\big),$$

配上连续性修正（见前文公式）精度极高。**脚本验算（$n = 1000, p = 0.5$，$\mu = 500$，$\sigma = \sqrt{250} = 15.811388$，用对数组合数精确计算）**：

目标量	精确值	CLT + 连续性修正	CLT 无修正
$\Pr[X \le 520]$	0.90261684	$\Phi(20.5/\sigma) = 0.90260414$（误差 1.3×10^{-5}）	0.89704835
$\Pr[490 \le X \le 510]$	0.49333996	0.49336006	—

经验判据：$np \ge 10$ 且 $n(1-p) \ge 10$ 时近似通常够用（这条判据的实质是"均值至少离边界 3 个标准差左右"，让正态尾部不至于伸到 0 或 n 以外）。脚本用"与正态的 L_1 距离"量化了这条判据：

n	p	np	L_1 距离	最大点偏差
1	0.5	0.5	0.03212	0.01606
2	0.5	1	0.14908	0.06419
5	0.5	2.5	0.04701	0.01118
10	0.5	5	0.02381	0.00622
30	0.5	15	0.00770	0.00121
100	0.5	50	0.00235	0.00020
10	0.1	1	0.20980	0.10740
50	0.1	5	0.09419	0.01798
200	0.1	20	0.04787	0.00422

两个独立信息：(i) n 增大，L_1 距离单调下降；(ii) **在相同的 n 下，p 靠近 0.5 时近似好得多**（$n = 10$：$p = 0.5$ 时 $L_1 = 0.0238$，$p = 0.1$ 时 $L_1 = 0.2098$，差近 9 倍）。原因是 $p = 0.1$ 时分布**高度偏斜**（右尾长、左边被 0 顶住），需要更大的 n 才能"洗掉"偏斜。

（2）置信区间与民意调查的样本量设计。 这是 CLT 在工程与社会统计中最广泛的应用。问题背景：估计某候选人支持率 p。数学建模：抽 n 人，$X_i \sim \text{Bernoulli}(p)$，$\bar{X} = \hat{p}$，$\sigma^2 = p(1-p)$。方案设计：由 CLT，$\hat{p} \approx \mathcal{N}(p, p(1-p)/n)$，故 95% 置信区间 $\hat{p} \pm 1.96\sqrt{p(1-p)/n}$。**最重要的一步是用 $p(1-p) \le 1/4$ 做最坏情况界定**（因为 $p(1-p)$ 在 $p = 1/2$ 处取最大值 $1/4$），于是半宽 $\le 1.96 \cdot \frac{1}{2\sqrt{n}} = \frac{0.98}{\sqrt{n}}$。

脚本验算的样本量表（95% 半宽，单位：百分点）：

p	$n = 100$	$n = 1000$	$n = 10000$
0.5	9.800	3.099	0.980
0.1	5.879	1.859	0.588

实践中的经典经验："$n = 1000$ 给出 $\pm 3\%$ 的误差"——正是 $0.98/\sqrt{1000} = 3.10$ 个百分点。而要把误差压到 $\pm 1\%$，需要 $n = (0.98/0.01)^2 \approx 9604 \approx 10^4$，即**样本量要增加到原来的 10 倍**（精度提高 3 倍，样本量提高 9 倍，又是开根号定律）。**注意这个半宽与总体大小几乎无关**（因子是 $\sqrt{(N-n)/(N-1)}$，当 $N \gg n$ 时接近 1）——这是"全国抽 1500 人就能估全国支持率"的原因。

下面这张 ASCII 图把"n 增大时 $B(n, 0.5)$ 逐步变成钟形"画在一起。脚本把每个柱子画成高度正比于 $\Pr[X = k]$（归一化到同一尺度），并把 $n = 30$ 的正态近似曲线叠在下面作对照：

```
 PMF
0.50 |#
     |#
0.40 |#                      n=1  : 两个等高的柱子
     |#                      max|exact-normal| = 0.01606
0.00 +--+------------------> k=0,1
       0  1

 PMF
0.50 |   #                   n=2  : 三角形（三个柱子）
0.25 |#     #                max|exact-normal| = 0.06419  <- 最不像!
0.00 +--+--+--> k=0,1,2
       0  1  2

 PMF
0.32 |   #                   n=5  : 已经是圆顶，但仍不够宽
0.16 | #     #                max|exact-normal| = 0.01118
0.00 +-+--+--+--+--+->
       0  1  2  3  4  5

 PMF
0.25 |    ###                 n=10 : 很像钟了
0.12 |  #     #               max|exact-normal| = 0.00622
0.00 +-+--+--+--+--+--+--+--+-> k
       0  1  2 ... 8  9 10

 PMF
0.15 |      #####             n=30 : 与正态几乎不可分辨
     |    ##     ##           max|exact-normal| = 0.00121
0.00 +--+--+--+--+--+--+--+--+--+--> k
       .. 10 15 20 25 30
            ^mu=15, sd=2.7386

  正态参照曲线 (n=30, mu=15, sd=2.7386):
     f(15) = 1/(sd*sqrt(2pi)) = 0.14567
     68% 区间 [12.26, 17.74]   95% 区间 [9.52, 20.48]

  关键读数:
    L1 距离  n=1: 0.03212  n=2: 0.14908  n=5: 0.04701
             n=10: 0.02381 n=30: 0.00770 n=100: 0.00235
    注意 n=2 比 n=1 更"不像"正态 —— 收敛不是单调的,
    但 n>=5 之后 L1 距离稳定下降。
    同样 n=10 但 p=0.1 时 L1 = 0.20980 (比 p=0.5 差近 9 倍):
    "偏离 0.5 越远，需要的 n 越大" —— 偏斜是近似的大敌。
```

（3）算法与负载均衡：最大负载的分析。 把 n 个球随机投入 m 个箱子（如哈希表、分布式分片），某个固定箱子里的球数 $\sim B(n, 1/m)$，均值 $\mu = n/m$、方差 $\approx n/m$。由 CLT，该箱负载 $\approx \mathcal{N}(n/m, n/m)$，于是**最大负载约为 $\mu + \Theta(\sqrt{\mu \log m})$**（$\log m$ 因子来自对 m 个箱子做 union bound，讲次 18）。脚本对"$\mu + 3\sigma$"的粗略上界：

n	m	μ	σ	$\mu + 3\sigma$	相对 μ 的倍数
10^4	100	100	9.9499	129.85	1.299
10^4	1000	10	3.1607	19.48	1.948
10^6	1000	1000	31.607	1094.8	1.095

结论：负载越重（μ 越大），相对偏差 $3\sigma/\mu = 3/\sqrt{\mu}$ 越小（1.095 vs 1.948）。这就是**"大表比小表更均衡"**的定量版本；也解释了为什么要用"两选择哈希 (power of two choices)"：让每个球在两个随机箱子中选负载小的那个，可以把最大负载从 $\Theta(\log n / \log\log n)$ 降到 $\Theta(\log\log n)$。

（4）估计 π、蒙特卡洛积分的误差界。 讲次 24 的 Buffon 投针用切比雪夫定投掷次数，得到极保守的界；用 CLT 则可以得到 $\hat{p} \approx \mathcal{N}(p, p(1-p)/n)$，从而给出**"误差以 95% 把握不超过 $1.96\sqrt{p(1-p)/n}$"**这类实用的误差棒。所有蒙特卡洛方法的误差分析都走这一条路。

（5）测量误差与 χ^2/t 检验的前置知识。 物理实验的"观测误差"被建模为"大量独立微小误差之和"，故正态；这就是最小二乘法 (least squares) 与线性回归的理论依据（讲次 20 讨论过 LLSE，其最优性依赖正态假设下的条件期望等于线性函数——见讲次 20"MMSE for Jointly Gaussian"）。

与其他讲次的关联

- **讲次 23（集中不等式 Concentration Inequalities）**：那里的大数定律 (LLN) 说 $\bar{X}_n \to \mu$，本讲的 CLT 是它的"精细化升级"——LLN 给"收敛"，CLT 给"收敛的速率与形状"。切比雪夫不等式（讲次 23）在 σ^2/n 已知时给 $\Pr[|\bar{X} - \mu| \geq \epsilon] \leq \sigma^2/(n\epsilon^2)$（多项式衰减、极保守）；CLT 给的是高斯尾 $2\Phi(-\epsilon\sqrt{n}/\sigma)$（指数衰减、精确）。**对比这两个界，就能看出 CLT 的威力。**同时，CLT 的 MGF 证明直接使用了讲次 19 就引入的期望与独立性。
- **讲次 20（期望与线性性 Expectations & Linearity）**：CLT 中"$\mathbb{E}[\bar{X}_n] = \mu$、$\mathrm{Var}(\bar{X}_n) = \sigma^2/n$"这两个矩计算完全来自讲次 20 与讲次 22（期望线性性 + 方差可加需要独立）；而定理 25.3 的证明直接调用期望线性性把 $X = \mu + \sigma Z$ 的均值搬过来。
- **讲次 19（随机变量与离散分布 Random Variables & Discrete Distributions）**：二项分布 $B(n, p)$ 定义为 n 个独立伯努利之和，这正是 CLT 最常见的应用对象；本讲的连续性修正就是"把二项这个离散分布摊成连续的正态"。另外，讲次 19 的几何分布、讲次 24 的指数分布是"重尾/轻尾"对照实验中不可或缺的样

本。

- **讲次 21（联合分布与独立性 Joint Distributions & Independence of RVs）**：定理 25.4（独立正态之和）的证明第一步就用"独立 $\iff$ 联合密度 = 边缘密度之积"，而这个对应关系是从讲次 21 的离散版本通过讲次 24 定理 24.6 搬到连续情形的。旋转对称性论证则完全是**联合密度**这一工具的直接应用。
- **讲次 22（方差与协方差 Variance & Covariance）**：$\mathbf{Var}(X+Y)=\mathbf{Var}(X)+\mathbf{Var}(Y)+2\,\mathbf{cov}(X,Y)$，在独立（或至少不相关）时协方差项消失——这是推论 25.1 中"$\sigma^2=a^2\sigma_X^2+b^2\sigma_Y^2$"的来源，也是"$\sigma^2/n$"这个均值的方差的来源。
- **讲次 24（连续概率与分布 Continuous Probability & Distributions）**：本讲完全建立在讲次 24 的语言之上——PDF 的定义与归一化条件（定理 25.1 就是在验证它）、CDF 与变量替换技巧（定理 25.2）、期望方差的积分定义（定理 25.3）、联合密度与独立性分解（定理 25.4）。此外"指数分布是几何分布的连续极限"这一对应关系，与本讲"二项分布在 CLT 下趋近正态"是同一类"离散 → 连续"的极限思想。
- **讲次 18（独立性与事件组合 Independence & Combination of Events）**：负载均衡应用的"对 m 个箱子做 union bound"直接来自讲次 18 的并集上界；而 CLT 给出的单箱尾概率与之相乘，是"集中不等式 + union bound"的标准组合拳。
- **讲次 26（马尔可夫链与条件期望 Markov Chains & Conditional Expectation）**：CLT 用于马尔可夫链会产生"马尔可夫链的中心极限定理"（$\sqrt{n}$ 尺度上的正态波动），讲次 26 只讲时间比例 $\frac{1}{n}\sum_m \mathbf{1}\{X_m=i\}$ 的收敛（LLN 版本），而本讲的工具是那个结论的下一层精细化。同时讲次 26 的条件期望是"CLT 应用中证明某些量不相关"的常用手段。
- **讲次 14（计数 Counting）**：二项系数 $\binom{n}{k}$ 的精确计算（用于脚本验算中的精确值）是本讲所有"精确 vs 近似"对照表的基准，而 $\log\binom{n}{k}$ 的 Stirling 近似也与正态近似的指数部分直接对应。

关键要点

1. **正态分布的两个参数就是均值与方差**：$X\sim\mathcal{N}(\mu,\sigma^2)$ 时 $\mathbb{E}[X]=\mu$、$\mathbf{Var}(X)=\sigma^2$；峰在 $x=\mu$、峰高 $\approx 0.4/\sigma$。
2. **标准化是万能钥匙**：$Z=(X-\mu)/\sigma\sim\mathcal{N}(0,1)$，故 $\Pr[X\le a]=\Phi\big(\frac{a-\mu}{\sigma}\big)$——一切正态计算都约化到 Φ 一张表。
3. **68–95–99.7**：$\Pr[|Z|\le 1]=0.6827$、≤ 2 给 0.9545、≤ 3 给 0.9973；中央 95% 需 1.96 个标准差。
4. **CLT 的公式与误差量级**：$\dfrac{S_n-n\mu}{\sigma\sqrt{n}}\xrightarrow{d}\mathcal{N}(0,1)$，等价地 $\bar{X}_n\approx\mathcal{N}(\mu,\sigma^2/n)$。**波动量级 $\sigma/\sqrt{n}$，精度翻倍需样本量翻四倍。**
5. **CLT 与大数定律的分工**：LLN 说"均值收敛（位置）"，CLT 说"波动的尺度与形状（$\sigma/\sqrt{n}$ 与正态）"。CLT 更强，能推出 LLN。
6. **CLT 证明的机制三件套**：中心化（杀一次项）+ 标准化（二次项 $=1/2$）+ $\sqrt{n}$ 归一化（让 n 次方与 $1/n$ 抵消），极限 MGF 为 $e^{t^2/2}$。全程只用 $\mathbb{E}[Y]=0$ 与 $\mathbb{E}[Y^2]=1$，**不用原始分布的形状**——这正是"痕迹被洗掉"的原因。
7. **用 CLT 必须加连续性修正**：$\Pr[X\le k]\approx\Phi\big(\frac{k+0.5-np}{\sqrt{np(1-p)}}\big)$。$n=30,p=0.5$ 时无修正的 $\Pr[X\le 15]$ 给 0.500，而有修正给 0.572，精确值 0.572。
8. **CLT 的四个前提/边界**：(i) 有限方差（Cauchy 反例）；(ii) 独立（或弱相关）；(iii) n 够大（偏斜分布要更大，经验判据 $np\ge 10$ 且 $n(1-p)\ge 10$）；(iv) 它说的是**均值的分布**趋近正态，**不是数据本身**。

常见误区与注意事项

1. **把"数据的分布"当成正态。** CLT 说的是"**样本均值的分布**"趋近正态，绝不是"原始数据趋近正态"。一枚骰子的结果永远是六个点上的均匀分布（n 再大也不会变成钟形）；变成钟形的是"n 枚骰子的平均"。骰子之和的例子很清楚：$n=1$ 时最大偏差 0.087（仍是很平的），$n=30$ 时才 0.00023。**同理，"身高近似正态"和"掷骰子难以近似正态"两种说法并不矛盾——前者本身就是许多微小扰动之和。**
2. **用 CLT 而忘记连续性修正。** $\Pr[X\le 15]$ 在 $n=30,p=0.5$ 时无修正给 0.5、真实值 0.572，**误差 7 个百分点**。规则很简单：离散量 k 一律换成 $k\pm 0.5$。
3. **置信区间解释成"μ 有 95% 概率在区间内"。** 正确的说法是关于**程序**的：重复实验无数次，约 95% 的区间会盖住固定的 μ。μ 是常数不是随机变量，谈它本身的概率没有意义。
4. **置信区间半宽用错标准差。** 半宽是 $1.96\sigma/\sqrt{n}$（**均值**的波动），而"含 95% 数据"的区间是 $\bar{X}\pm 1.96\sigma$（**单次观测**的波动），后者宽 $\sqrt{n}$ 倍。$n=100$ 时两者差 10 倍，误用会严重低估不确定性。**记忆锚点：涉及"均值"就除 $\sqrt{n}$，涉及"单个数据"就不除。**
5. **以为 n 增大误差线性减小。** 误差是 $\sigma/\sqrt{n}$，是**开根号**的：n 增 100 倍，误差只减 10 倍（脚本：骰子 $n=100\to 10000$，半宽 $0.3347\to 0.0335$）。设计实验预算时最常见的低估就发生在这里。
6. **忽略"有限方差"这个前提。** Cauchy 分布密度也是钟形、也对称、也以 0 为中心，看起来"应该"满足 CLT，但 $\mathbb{E}[|X|]=\infty$，样本均值永远是 Cauchy 本身（脚本实测 $\Pr[|\bar{X}_n|\le 1]$ 在 $n=1$ 到 1000 之间恒为 0.5，完全不动）。**"看起来像钟形"和"服从正态/满足 CLT"是两回事**：判据是尾部的厚度，不是形状的好看程度。
7. **把"独立"当成可有可无的技术条件。** 完全相关时（$X_i\equiv X$）$\bar{X}_n=X$，分布根本不随 n 变化。要求"独立同分布"里的**独立**不是保守，而是必要的。现实数据（时间序列、聚类抽样）往往有相关性，此时 CLT 需要额外条件才能救回来。
8. **在高度偏斜、n 又小时硬套 CLT。** 脚本的 L_1 表显示：$n=10,p=0.1$（$np=1$）时 $L_1=0.2098$，最大点偏差 0.1074——近似极差；而 $n=200,p=0.1$（$np=20$）时降到 0.0479。**偏斜分布的"有效 n"要按 np 与 $n(1-p)$ 中较小的那个来估，而不是按 n 本身。**
9. **把 1.96 与 2 混用而不看精度需求。** $\pm 2\sigma$ 给 95.45%，1.96σ 给 95.00%，2.576σ 给 99%。在 n 很大时这 0.45 个百分点的差异会显著影响样本量预算（$(1.96/2)^2=0.96$，即 4% 的样本量差异）。

思考题（带答案）

Q1.（纯计算） 设 X 服从二项分布 $B(n=100,p=0.4)$。(a) 写出用 CLT 近似的均值和标准差。(b) 用 CLT + 连续性修正估计 $\Pr[X\le 45]$、$\Pr[X=40]$、$\Pr[35\le X\le 45]$。(c) 与脚本算出的精确值 0.868910、0.081219、0.738573 比较误差。(d) 若要求 $\Pr[X\le 45]$ 的估计误差不超过 0.005，n 是否已足够?

▸ **答案**

(a) X 是 100 个独立 $\mathrm{Bernoulli}(0.4)$ 之和，$\mu = np = 40$，$\sigma^2 = np(1-p) = 100 \times 0.4 \times 0.6 = 24$，$\sigma = \sqrt{24} = 4.898979$。

(b) 用 Φ（脚本用 Abramowitz–Stegun 近似，精度 $\sim 10^{-7}$）：– $\Pr[X \le 45]$：连续性修正把 45 换成 45.5，

$$\Pr[X \le 45] \approx \Phi\left(\frac{45.5 - 40}{4.898979}\right) = \Phi(1.122676) = 0.869214.$$

- $\Pr[X = 40]$：把单点摊成 $[39.5, 40.5]$，

$$\Pr[X = 40] \approx \Phi\left(\frac{40.5 - 40}{4.898979}\right) - \Phi\left(\frac{39.5 - 40}{4.898979}\right) = \Phi(0.102062) - \Phi(-0.102062) = 0.081293.$$

- $\Pr[35 \le X \le 45]$：

$$\approx \Phi\left(\frac{45.5 - 40}{4.898979}\right) - \Phi\left(\frac{34.5 - 40}{4.898979}\right) = \Phi(1.122676) - \Phi(-1.122676) = 0.738428.$$

(c) **误差表**：

目标量	精确值（脚本）	CLT+修正	绝对误差
$\Pr[X \le 45]$	0.868910	0.869214	0.00030
$\Pr[X = 40]$	0.081219	0.081293	0.00007
$\Pr[35 \le X \le 45]$	0.738573	0.738428	0.00015

三个误差都在 10^{-4} 量级，说明 $np = 40$、$n(1-p) = 60$ 都远大于 10，CLT 在这个参数下极好用。作为对照，若无连续性修正：$\Pr[35 \le X \le 45] \approx \Phi(5/4.899) - \Phi(-5/4.899) = 0.692566$，误差 0.046，**把修正加上就把误差降了 300 倍**。

(d) 误差 $0.0003 \ll 0.005$，**已经足够**。若想更保守：误差 $\sim 1/(\sigma\sqrt{2\pi})$ 量级的"点质量"误差，或直接看 §（1）的 L_1 表——$np \ge 10$ 且 $n(1-p) \ge 10$ 是经验充分条件，本例两个数分别是 40 与 60，远超门槛。

Q2.（概念/证明） 设 $X_1, \ldots, X_n$ i.i.d. 且 $\mathbb{E}[X_i] = \mu$、$\mathrm{Var}(X_i) = \sigma^2 \in (0, \infty)$。用 CLT 证明**弱大数定律**：对任意 $\epsilon > 0$，$\Pr[|\bar{X}_n - \mu| > \epsilon] \to 0$。

▸ **答案**

证明策略：从 CLT 的标准化量出发，把大偏差事件 $\{|\bar{X}_n-\mu|>\epsilon\}$ 等价地写成 $\{|Z_n|>\epsilon\sqrt{n}/\sigma\}$，再用标准正态的尾概率随阈值增大而趋于 0。也就是说，**用"分布收敛 + 极限分布无原子"推出"概率收敛"**。

逐步推导：

第 1 步（标准化）。由 CLT，

$$Z_n:=\frac{\bar{X}_n-\mu}{\sigma/\sqrt{n}}=\frac{S_n-n\mu}{\sigma\sqrt{n}}\xrightarrow{d}\mathcal{N}(0,1).$$

第 2 步（事件等价改写）。$\sigma>0$、$\sqrt{n}>0$，故

$$|\bar{X}_n-\mu|>\epsilon\iff\left|\frac{\bar{X}_n-\mu}{\sigma/\sqrt{n}}\right|>\frac{\epsilon\sqrt{n}}{\sigma}\iff|Z_n|>c_n,\qquad c_n:=\frac{\epsilon\sqrt{n}}{\sigma}.$$

注意 $c_n\to\infty$（因为 $\sqrt{n}$ 增长）。

第 3 步（用极限分布的 CDF 表示）。因 $\mathcal{N}(0,1)$ 的 CDF Φ 在 $\pm c_n$ 处连续，依分布收敛给出

$$\Pr[|Z_n|\le c_n]=\Pr[Z_n\le c_n]-\Pr[Z_n<-c_n]\longrightarrow\Phi(c_n)-\Phi(-c_n).$$

（更严谨地说：对每个固定 c，$\Pr[Z_n\le c]\to\Phi(c)$；这里 $c_n\to\infty$ 依赖 n，需要用 Slutsky/连续映射或用下面第 4 步的直接估计。）

第 4 步（直接估计，避免依赖 n 的阈值）。取任意固定的大 $M>0$，把事件拆开：

$$\Pr[|Z_n|>c_n]\le\Pr[|Z_n|>M]\quad\text{（当 }c_n\ge M\text{、即 }n\ge\sigma^2M^2/\epsilon^2\text{ 时成立）}.$$

再由 CLT 与 Φ 的连续性，

$$\limsup_{n\to\infty}\Pr[|Z_n|>c_n]\le\lim_{n\to\infty}\Pr[|Z_n|>M]=2(1-\Phi(M)).$$

因为 M 可以取任意大，而 $2(1-\Phi(M))\to0$（$M\to\infty$），故

$$\limsup_{n\to\infty}\Pr[|Z_n|>c_n]\le0\implies\lim_{n\to\infty}\Pr[|\bar{X}_n-\mu|>\epsilon]=0.$$

第 5 步（说明与讲次 23 的差别）。讲次 23 用切比雪夫直接给 $\Pr[|\bar{X}_n-\mu|>\epsilon]\le\frac{\sigma^2}{n\epsilon^2}$（对一切 n 成立，不需 CLT，但界很松）；本证明给出的是"**极限为 0 且误差以高斯尾速度衰减**"。例如 $\epsilon\sqrt{n}/\sigma=3$ 时，CLT 给 ≈0.0027，而切比雪夫给 $\le1/9=0.111$，相差 40 倍。

证明机制解说：这个证明体现了"**分布收敛 ⇒ 概率收敛到常数**"这一常用套路。核心观察是：$\mathcal{N}(0,1)$ 的质量全部集中在有限区间内，所以当阈值 $c_n\to\infty$ 时，$|Z_n|>c_n$ 的概率必然趋于 0。**注意 $\sqrt{n}$ 在这里起了决定性作用**：如果误差量级不是 $\sigma/\sqrt{n}$ 而是常数，c_n 就不会趋于无穷，结论立刻消失。**这也再次说明 CLT 严格强于 LLN**。

Q3.（概念/反例） 下面的 ASCII 图给出标准正态密度并标注了 68–95–99.7 分区，以及三条对照曲线。请回答：(a) 从图中读出 $\Pr[Z>2]$ 约为多少？(b) 为什么 $\mathcal{N}(0,1)$ 在 $|x|>5$ 处的密度已经小到 1.5×10^{-7} 却仍**不能**直说"$|Z|>5$ 不可能"？(c) 若某数据集报告"均值 100、标准差 10、有一个观测值 160"，用图中信息判断这个值有多异常。

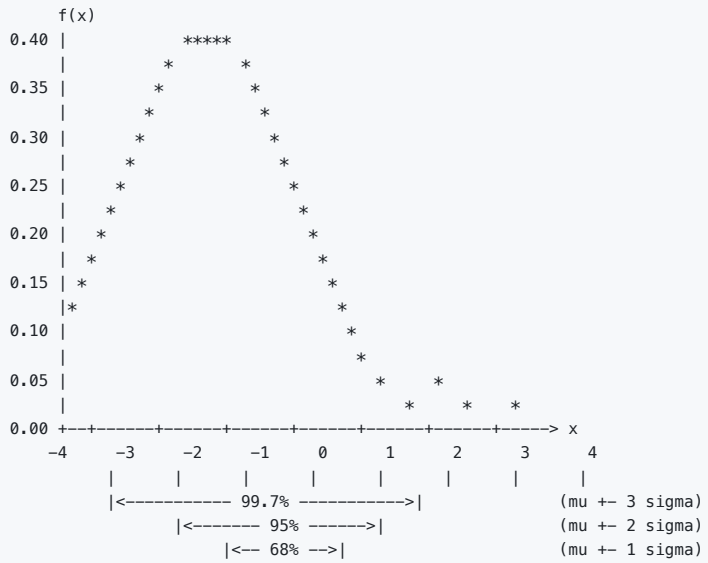


```
峰高 = 1/sqrt(2*pi) = 0.398942  在 x=0
1 sigma 半宽处 f(1) = 0.241971
2 sigma 半宽处 f(2) = 0.053991
3 sigma 半宽处 f(3) = 0.004432
5 sigma 半宽处 f(5) = 1.4867e-6   (已经很小，但 P[|Z|>5]=5.7e-7 仍非 0)
拐点(inflection) 恰在 x = +-1 (二阶导为零处)

对照: Laplace(0,1) 密度 0.5*e^{-|x|} (更尖、尾更重，方差 2)
      U[-sqrt(3),sqrt(3)] (同方差 1, 平顶, 有紧支撑)
```

▸ **答案**

(a) $\Pr[Z>2]=1-\Phi(2)=1-0.977250=0.022750$（脚本验算）。即**约 2.3%**，双侧 $\Pr[|Z|>2]=0.0455$。图中 2σ 以外两侧共约 4.5%。

(b) 因为**"密度很小"与"概率为零"是两件事**，而且"不可能"在连续世界只能由"事件是空集"或"落在密度支撑之外"来保证。 – $\Pr[|Z|>5]=2(1-\Phi(5))=5.73\times10^{-7}$（即约**一百七十五万分之一**）。它**不是 0**：正态密度的支撑是整个 $\mathbb{R}$，任何实数都有正密度。 – 由讲次 24 的教训：连续分布中**单个点**的概率才是 0。$\{|Z|>5\}$ 是**区间**（不可数多个点），概率由积分 $\int_{|x|>5} f$ 给出，只要积分区间长度非零且密度正，概率就正。 – 所以正确的说法是"$|Z|>5$ 是**极小概率事件**（1 百万分之 0.57）"，而不是"不可能"。类似地 6σ 的概率是 2×10^{-9}（约**十亿分之二**）——依然不是 0，这也解释了为什么"6σ 事件"在现实中被当作重大异常信号而不是绝对禁忌。

(c) $z=(160-100)/10=6$，即**偏离 6 个标准差**。由图/表中 3σ 已含 99.7%，6σ 处 $\Pr[|Z|>6]=2\times10^{-9}$。在正态假设下这是一个"约**十亿分之二**"的事件。结论（要小心措辞）：**在正态模型下，遇到 6σ 观测的概率极小，因此更有可能是模型本身有问题**——比如 – 标准差被低估（真实 σ 是 20 而非 10，则 $z=3$，0.27%，仍罕见但没那么离谱）； – 分布是重尾的（如 Cauchy/厚尾分布），"6σ"在那里一点也不罕见； – 存在数据录入错误、单位错误（可能是 160 应为 16.0）； – 或者这是一次真正值得报告的新发现。 **这正是"异常检测"与"p 值"的逻辑**：不是"6σ 不可能"，而是"在既定模型下它太不可能，所以我们优先怀疑模型"。

Q4.（概念/多反例） 判断真假并说明：(a) "若 X,Y 都服从正态分布，则 $X+Y$ 服从正态分布。" (b) "若 X 的密度关于 0 对称且 $\mathbb{E}[X]=0$，则 X 近似正态。" (c) "CLT 成立时，$\bar{X}_n$ 的分布与 X 的分布形状无关，只通过 μ,σ^2 影响 $\bar{X}_n$。"

▸ **答案**

(a) **假（缺少独立性）。** 反例：取 $X\sim\mathcal{N}(0,1)$、$Y=-X$。则 Y 也是 $\mathcal{N}(0,1)$（正态关于 0 对称，$-$ 幂等），但 $X+Y=0$ 是退化分布（全部质量在 0），不是任何非退化正态。**正确定理（推论 25.1）要求 X,Y 独立**（更弱地说，需要联合正态或至少不相关）。这是本讲最容易被漏掉的条件。

(b) **假。** 对称 + 均值为 0 远不足以刻画正态。三个反例： – $X=2B-1$，$B\sim\text{Bernoulli}(1/2)$：离散两点分布，对称、均值 0，与正态毫无关系。 – **Laplace 分布** $f(x)=\frac{1}{2}e^{-|x|}$：连续、对称、均值 0、方差 2，但**在 $x=0$ 不可导（尖峰）**，尾部是指数衰减（比高斯尾重得多）。图注里已画出这条对照曲线。 – **Kurtosis 证据**：正态的四阶累积量 $\kappa_4=0$，而 Laplace 的 $\kappa_4=3$。**"对称"只约束奇阶矩，"像不像正态"要靠尾部的薄厚（四阶矩）。** 更极端的：Cauchy 分布同样对称、均值不存在，尾部厚到没有矩。

(c) **真（这正是 CLT 的要点），但要精确表述。** 标准化后的 $\frac{S_n-n\mu}{\sigma\sqrt{n}}$ 的极限分布是**同一个 $\mathcal{N}(0,1)$**，与原分布形状无关。原分布的全部影响**只通过 μ 与 σ^2 两个数**进入（一个定位置、一个定尺度），其余高阶矩（偏度、峰度等）只影响**收敛速度**（例如 Berry–Esseen 界正比于 $\mathbb{E}|Y|^3$），不影响极限。脚本证据：n 枚骰子之和（离散、平顶）在 $n=30$ 时与正态的最大点偏差仅 0.00023；n 个 $U[0,1]$ 之和（连续、有紧支撑）在 $n=12$ 时也已很接近（CDF 对照：模拟 $\Pr[Z\le-2]=0.0223$ vs 正态 0.0228，$\Pr[Z\le2]=0.9777$ vs 0.9772）。**唯一的例外是重尾（方差无穷）——那时 CLT 本身不成立**，这恰好再次说明"有限方差"是不容删的前提。

Lecture 26: Markov Chains & Conditional Expectation（马尔可夫链与条件期望）

概述

前几讲的随机变量都是"一次性"的：抛一次硬币、掷一次骰子、抽一次样。但真实系统几乎都是**随时间演化**的：网页浏览者从一个链接跳到下一个链接、赌徒的资产一分一分地变化、机器的状态在"正常/故障"之间切换。本讲研究这类**随机过程 (random process)** 中最基本的一类：**有限马尔可夫链 (finite Markov chain)**。

马尔可夫链的全部精髓是一句话：**未来只取决于现在，与过去无关（马尔可夫性质 (Markov property)）**。这条"健忘"假设看似极强，但它覆盖了大量真实系统，而且让所有计算都变成**矩阵代数**（转移矩阵 P）与**线性方程组**（平衡方程、首步方程）。

本讲要回答四类问题： 1. **长期行为**：链跑很久后，处于各状态的时间比例是多少？答案由**平稳分布 (stationary distribution)** π 给出，满足 $\pi P = \pi$。 2. **吸收概率**：从状态 i 出发，最终被某个吸收态吸收的概率是多少？用**首步分析 (first-step analysis)** 列方程组。 3. **吸收时间**：期望多少步被吸收？同样是首步方程。 4. **条件期望**：如何在只掌握部分信息时给出最优估计，以及如何用**全期望公式**把复杂期望"分而治之"。

最后两项（首步分析与条件期望）本质上是同一个工具的两种面貌：**首步方程就是一次条件期望展开**。

核心概念的直观解释

随机过程与状态 (Random Process and State)

- **定义**：**随机过程**是一族带时间下标的随机变量 $\{X_n : n = 0, 1, 2, \ldots\}$。**状态空间 (state space)** $\mathcal{X}$ 是 X_n 所有可能取值的集合。本课只讨论**有限**情形，即 $\mathcal{X} = \{1, 2, \ldots, K\}$（有时用 $\{0, 1, \ldots, K-1\}$ 或 $\{A, B, C, \ldots\}$）。X_n 称为过程在**时刻/步 (step)** n 的**状态 (state)**。
- **直观解释**：把 X_n 想成"游戏在第 n 步所处的位置"。状态空间是"所有可能站的位置"，随机过程是"位置的随机游走轨迹"。
- **具体示例**：$\mathcal{X} = \{\text{晴}, \text{阴}, \text{雨}\}$，$X_n$ = 第 n 天的天气。或 $\mathcal{X} = \{0, 1, \ldots, 100\}$，$X_n$ = 赌徒在第 n 局的资金。

马尔可夫链 (Markov Chain) 与马尔可夫性质 (Markov Property)

- **定义**：设状态空间 $\mathcal{X} = \{1, \ldots, K\}$。给定**初始分布 (initial distribution)** π_0（$\pi_0(i) \geq 0$、$\sum_i \pi_0(i) = 1$）与**转移概率矩阵 (transition probability matrix)** P（$K \times K$，$P(i,j) \geq 0$、$\sum_j P(i,j) = 1$），定义随机序列 $\{X_n\}$ 为

$$\Pr[X_0 = i] = \pi_0(i), \qquad \Pr[X_{n+1} = j \mid X_n = i,\ X_{n-1}, \ldots, X_0] = P(i,j) \quad (\forall n \geq 0).$$

第二条即**马尔可夫性质**：给定当前状态 $X_n = i$，下一状态的条件分布**不依赖**更早的历史 $X_{n-1}, \ldots, X_0$。等价地

$$\Pr[X_{n+1} = j \mid X_n = i,\ X_{n-1}, \ldots, X_0] = \Pr[X_{n+1} = j \mid X_n = i] = P(i,j).$$

- **直观解释（"它是什么意思？"）**：链是**健忘 (amnesic)** 的。以两状态链（$\mathcal{X} = \{0, 1\}$，参数 $a \in [0, 1]$）为例：若在状态 0，就抛一枚正面概率为 a 的硬币，正面则跳到 1、反面则留在 0；若在状态 1，同样抛这枚硬币，正面则跳到 0、反面则留在 1。**"它是从状态 0 待了很久才跳到 1 的，还是刚跳进状态 0 的"，对下一步毫无影响**——因为在状态 0 时它总是抛同样一枚硬币。
- 现实类比：**醉汉走路**——他下一步往哪走只看他现在站在哪，不记得自己是怎么走到这里的。**天气**——明天是否下雨只取决于今天（在这个简化模型里），不取决于前天的天气。**棋子位置**——国际象棋的局面（棋子的完整配置）是马尔可夫的：从当前局面出发，未来只由规则和当前局面决定，与走到这个局面的历史无关。**注意这一点很微妙**："棋子的位置"不够（要知道"这个兵是否还没走过"，所以状态必须是**完整局面**）——**选对状态空间是建模马尔可夫链的关键难点**。
- **具体示例（两状态链，$a = 0.3$）**：

$$P = \begin{pmatrix} 1-a & a \\ a & 1-a \end{pmatrix} \overset{a=0.3}{=} \begin{pmatrix} 0.7 & 0.3 \\ 0.3 & 0.7 \end{pmatrix}.$$

注意这条链是完全对称的（两条对角元都是 $1-a$、两条非对角元都是 a），所以由对称性，长期来看它状态 0 与状态 1 各占一半时间。脚本模拟 10^6 步得状态 0 的时间比例 0.49983，与理论 0.5 吻合。

作为**对照**，另一条**非对称**的两状态链

$$P' = \begin{pmatrix} 0.7 & 0.3 \\ 0.4 & 0.6 \end{pmatrix}$$

（从 0 跳到 1 的概率是 0.3，从 1 跳到 0 的概率是 0.4——**两个方向不一样**）。它的长期时间比例不再是各半，而是解 $\pi P' = \pi$ 得到的 $\pi = (\frac{4}{7}, \frac{3}{7}) = (0.571429, 0.428571)$。脚本验算 $\pi P' = \pi$ ✓（幂迭代 P'^{50} 的两行都等于 $(4/7, 3/7)$ ✓），且 2×10^6 步模拟的时间比例是 0.57091 ✓。**这两条链必须严格区分**：本讲后面凡涉及 $(1-2a)^n$ 这类闭式，都只对**对称**链成立。

转移矩阵 (Transition Matrix) 与状态转移图 (State Transition Diagram)

- **定义**：$P_{ij} = P(i,j) = \Pr[X_{n+1} = j \mid X_n = i]$。$P$ 必须满足

$$P_{ij} \geq 0 \ \ \forall i, j, \qquad \sum_{j=1}^{K} P_{ij} = 1 \ \ \forall i.$$

满足第二条的矩阵称为**行随机矩阵 (row-stochastic matrix)**——**每一行**的和为 1（不是每一列！）。 – **直观解释**：第 i 行描述"从 i 出发，下一步去哪儿"的完整概率分布。**行和为 1 是"必须走到某个地方"的必然结果。**状态转移图则把 P 画成有向图：$P_{ij} > 0$ 时从 i 画一条指向 j 的箭头，并在箭头旁标注概率（或"等概率"）。 – **具体示例（2×2）**：上面的两状态链，图如下。

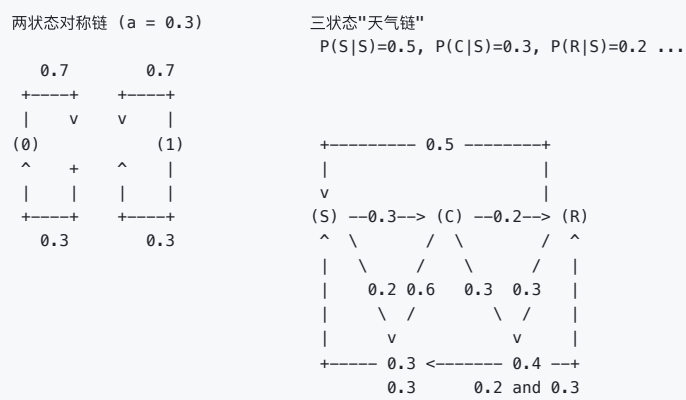

行随机性检查:
  两状态: 行0: 0.7+0.3 = 1 ✓   行1: 0.3+0.7 = 1 ✓
  天气链: 行S: 0.5+0.3+0.2 = 1 ✓
           行C: 0.2+0.6+0.2 = 1 ✓
           行R: 0.3+0.3+0.4 = 1 ✓
注意: 每行和为 1, 但每列和不要求为 1!
  两状态链列和: 0.7+0.3 = 1.0 （这条对称链碰巧是 1，但对角线一下的
  非对称链 P'=[[0.7,0.3],[0.4,0.6]] 列和是 0.7+0.4=1.1 ≠ 1，完全正常）

t 步转移概率 (t-step Transition Probability) 与 Chapman–Kolmogorov 方程

- **定义**：$P^{(n)}(i,j) := \Pr[X_n = j \mid X_0 = i]$，即从 i 出发走 n 步后到 j 的概率。
- **定理（Chapman–Kolmogorov）**：$P^{(n)} = P^n$（**矩阵的 n 次幂**）。
- **直观解释**："走 n 步的概率 = 矩阵连乘 n 次"。为什么？因为"从 i 经中间点 k 到 j"的概率是 $P(i,k)P(k,j)$，对所有可能的中间点 k 求和，正是矩阵乘法的定义。**"对所有中间状态求和"就是矩阵乘法的全部内容**——这是本讲最实用的一个认识。
- **具体示例（t 步转移概率）**：对**对称**链 $P = \begin{pmatrix} 1-a & a \\ a & 1-a \end{pmatrix}$，脚本直接乘得（$a = 0.3$）

$$P^2 = \begin{pmatrix} 0.58 & 0.42 \\ 0.42 & 0.58 \end{pmatrix},$$

逐项核对：$P^2(0,0) = 0.7 \times 0.7 + 0.3 \times 0.3 = 0.49 + 0.09 = 0.58$ ✓；$P^2(0,1) = 0.7 \times 0.3 + 0.3 \times 0.7 = 0.21 + 0.21 = 0.42$ ✓。 此外有闭式 $P^n = \begin{pmatrix} \frac{1}{2} + \frac{1}{2}(1-2a)^n & \frac{1}{2} - \frac{1}{2}(1-2a)^n \\ \frac{1}{2} - \frac{1}{2}(1-2a)^n & \frac{1}{2} + \frac{1}{2}(1-2a)^n \end{pmatrix}$。用 $n = 2$ 核对：$a = 0.3$ 时 $\frac{1}{2} + \frac{1}{2}(0.4)^2 = 0.5 + 0.08 = 0.58$ ✓（与直接相乘一致）。脚本验算 $P^n(0,0)$：$n = 1$:0.700000、$n = 2$:0.580000、$n = 3$:0.532000、$n = 4$:0.512800、$n = 5$:0.505120——清楚地向 0.5 收敛。

对**非对称**链 $P' = \begin{pmatrix} 0.7 & 0.3 \\ 0.4 & 0.6 \end{pmatrix}$ 则没有这个对称闭式，脚本直接乘得

$$(P')^2 = \begin{pmatrix} 0.61 & 0.39 \\ 0.52 & 0.48 \end{pmatrix},$$

核对：$(P')^2(0,0) = 0.7 \times 0.7 + 0.3 \times 0.4 = 0.49 + 0.12 = 0.61$ ✓；$(P')^2(0,1) = 0.7 \times 0.3 + 0.3 \times 0.6 = 0.21 + 0.18 = 0.39$ ✓。**把这两个 P^2 放在一起对比，就能看出"对称性"带来的差别（0.58 vs 0.61）——它们不是同一个矩阵。**

状态的分类：可达、互通、不可约

- **可达 (Accessible)**：若存在 $n \geq 0$ 使 $P^n(i,j) > 0$，则称 j 从 i **可达**，记 $i \to j$。在状态图上即"存在一条从 i 到 j 的有向路径"。
- **互通 (Communicate)**：若 $i \to j$ 且 $j \to i$，则称 i 与 j **互通**，记 $i \leftrightarrow j$。互通是状态空间上的**等价关系**（自反、对称、传递），因此把状态划分成**等价类 (communicating classes)**。
- **不可约 (Irreducible)**：若**所有**状态两两互通（即整个状态图是**一个强连通分量**），则称链**不可约**。
- **直观解释**：不可约 = "**从任何地方都能到任何地方**"。它是"长期行为唯一"的关键条件：如果链卡在两个互不往来的区域里，长期比例就取决于你从哪里出发，谈不上"唯一"。
- **具体示例**：上面的两状态链在 $0 < a < 1$ 时不可约（$0 \to 1$（概率 $a > 0$）、$1 \to 0$（概率 $a > 0$））；而 $a = 0$ 时 $P = I$，$0 \not\to 1$，**可约 (reducible)**。

常返与瞬态 (Recurrent vs Transient)；周期与非周期 (Periodic vs Aperiodic)

- **常返 (Recurrent)**：从 i 出发，以概率 1 **无限多次**回到 i 的状态。
- **瞬态 (Transient)**：从 i 出发，只有**有限多次**回到 i 的概率为正（即"有可能再也不回来"）的状态。有限链中，常返态等价于"访问次数期望为 ∞"，瞬态等价于"访问次数期望有限"。
- **周期 (Period)**：对不可约链，定义

$$d(i) := \gcd\{n > 0 : P^n(i,i) > 0\},$$

即"所有能回到 i 的步数的最大公约数"。可以证明 $d(i)$ 与 i 无关（记公共值为 d）。$d = 1$ 时称链**非周期 (aperiodic)**，否则称**周期为 d (periodic with period d)**。
– **直观解释**：周期性的意思是"链**按固定的节拍**振荡"。最经典的例子是 $a = 1$ 的两状态链：它每步必然切换状态，$0 \to 1 \to 0 \to 1 \to \cdots$，所以从 0 出发只能在

偶数步回到 0，$d(0)=\gcd\{2,4,6,\ldots\}=2$。这时 $\Pr[X_n=0]$ 在 1 与 0 之间来回跳，**不收敛**。 – **具体示例（周期 vs 非周期）**： – $a=1$（周期 2）：$\Pr[X_n=0]$ 依次为 $1,0,1,0,1,0,\ldots$（$n=0..5$，脚本验算）——**振荡，不收敛**。 – $a\in(0,1)$（非周期）：$d(0)=\gcd\{1,2,3,\ldots\}=1$，且 $\Pr[X_n=0]\to 1/2$——**收敛**。 – 天气链（三状态）：$P^2(S,S)=0.37>0$ 且 $P^3(S,S)>0$，故 $d(S)=\gcd\{2,3,\ldots\}=1$，非周期 ✓。

```
周期的陷阱: a = 1 的两状态链
   Pr[X_n = 0]
    1 |#   #   #   #        <- 偶数步必然在状态 0
      |   #   #   #   #
    0 +---+---+---+---+---> n
      0   1   2   3   4
   没有极限！"时间比例"却仍然存在:
     前 n 步里状态 0 出现约一半 -> 时间比例 = 1/2
   这就是"时间平均"与"分布收敛"的区别:
     定理 26.3 (时间比例):  只要不可约, 1/n*sum 1{Xm=i} -> pi(i)   [周期无所谓]
     定理 26.4 (分布收敛):  还需要非周期, Pr[Xn=i] -> pi(i)        [周期会破坏]
```

平稳分布 (Stationary / Invariant Distribution)

- **定义**：概率向量 $\pi=(\pi(1),\ldots,\pi(K))$（$\pi(i)\ge 0$、$\sum_i\pi(i)=1$）若满足**平衡方程组 (balance equations)**

$$\pi=\pi P,\quad \text{即}\quad \pi(j)=\sum_{i=1}^{K}\pi(i)P(i,j)\ \ \forall j,$$

则称 π 为链（或 P）的**平稳分布（不变分布，invariant distribution）**。 – **直观解释（"它是什么意思？"）**：π 是"**驻留比例**"——链跑很久之后，处于各状态的时间比例收敛到 π。它也是"**流动的平衡**"：从每个状态 i 流出到 j 的"概率流量" $\pi(i)P(i,j)$，对所有 i 求和后恰好等于流进 j 的量 $\pi(j)$。类比：一个装满水的水池，各区域的水位都不再变化——不是因为没有流动，而是**流入 = 流出**。 – **矩阵语言**：$\pi P=\pi$ 说明 π 是 P 的**左特征向量**、对应**特征值 1**（转置一下：π 是 P^T 对应特征值 1 的右特征向量）。行随机矩阵必有特征值 1（因为 $P\mathbf{1}=\mathbf{1}$，故 1 是 P 的特征值），所以**平稳分布总是存在**（有限维、概率向量约束下），但**不一定唯一**。 – **具体示例（三状态天气链）**：设

$$P=\begin{pmatrix}0.5 & 0.3 & 0.2\\ 0.2 & 0.6 & 0.2\\ 0.3 & 0.3 & 0.4\end{pmatrix}\quad (S=\text{晴},C=\text{阴},R=\text{雨}).$$

解 $\pi P=\pi$ 与归一化条件，得

$$(\pi_S,\pi_C,\pi_R)=\left(\frac{9}{28},\frac{3}{7},\frac{1}{4}\right)=(0.321429,\ 0.428571,\ 0.250000).$$

脚本验算：πP 的每个分量与 π 逐位相同（误差 $<10^{-8}$）✓；用 10^6 步模拟的时间比例为 $(0.32124, 0.42863, 0.25014)$ ✓。

吸收态 (Absorbing State) 与吸收马尔可夫链 (Absorbing Markov Chain)

- **定义**：状态 i 是**吸收态**，若 $P(i,i)=1$（一旦进入就永远出不来，图中是一个只有自环、没有出边的点）。若链中至少有一个吸收态，且从任何状态出发都能以正概率到达某个吸收态，则称此为**吸收马尔可夫链**。
- **直观解释**：吸收态是"**游戏结束**"的状态：破产、通关、被淘汰。吸收链是**可约**的（吸收态无法回到其他状态），因此它的长期行为不适用平稳分布理论，而要用**首步分析**算"被吸收的概率"与"期望吸收时间"。
- **具体示例**：赌徒破产中的 $0与$M$；棋盘上的"将死"；迷宫里的出口。

首步分析 (First-Step Analysis)

- **定义**：设 $h(i)$ 是"从状态 i 出发、最终被某个目标集合 A 吸收的概率"。则对一切 $i\notin A\cup B$（A 为"成功"吸收集、B 为"失败"吸收集）

$$h(i)=\sum_j P(i,j)\,h(j),\qquad h(i)=1\ (i\in A),\qquad h(i)=0\ (i\in B).$$

类似地，设 $t(i)$ 是"从 i 出发被吸收所需的**期望步数**"，则

$$t(i)=0\ (i\in A\cup B),\qquad t(i)=1+\sum_j P(i,j)\,t(j)\ (i\notin A\cup B).$$

- **直观解释**："**先走一步，然后递归**"。这一步之后你有几种可能（按 $P(i,j)$ 分布），进入状态 j 之后问题就**一模一样地重来一遍**（这就是马尔可夫性质！），所以是 $h(j)$。因为已经花掉了一步，所以期望时间的方程里有个 $+1$。**这是"分而治之 + 动态规划"在概率里的化身**：把"从 i 出发"的问题归约成"从 j 出发"的更小问题。
- **为什么叫"首步"**：我们**只看第一步**，剩下的全部打包进 $h(j)$。这就是它能变成线性方程组的原因——未知量只有 $h(\cdot)$ 本身，方程是"未知量的线性组合 = 已知常数"。
- **具体示例（两次连续正面）**：反复抛公平硬币直到出现连续两次正面。状态 S（开始）、T（上次是反面）、H（上次是正面但还没连续两次）、E（成功，吸收）。$t(S)=6$（见下面的完整推导与脚本验算）。

条件期望 (Conditional Expectation)

- **定义**：设 X,Y 是离散随机变量。

$$\mathbb{E}[X\mid Y=y]=\sum_x x\,\Pr[X=x\mid Y=y]=\sum_x x\,\frac{\Pr[X=x,Y=y]}{\Pr[Y=y]}\quad(\Pr[Y=y]>0).$$

把 y 换成随机变量 Y，就得到 $\mathbb{E}[X \mid Y]$——**它是一个随机变量**（是 Y 的函数）。 – **直观解释（"它是什么意思？"）**：**"知道 Y 之后，对 X 的最优猜测"**。不知道 Y 时最优猜测是 $\mathbb{E}[X]$（一个数）；观测到 $Y=y$ 后，$\Pr[X=x]$ 被**修正**为 $\Pr[X=x \mid Y=y]$，在这个新分布下的期望就是新猜测 $\mathbb{E}[X \mid Y=y]$。所以 $\mathbb{E}[X \mid Y]$ 是**"随观测值变化的最优猜测"**。 – 类比：估计一个箱子里球重量的平均值。若不知道是哪只箱子，就报全体平均 $\mathbb{E}[X]$；若知道是哪只箱子（$Y=y$），就报那只箱子的平均 $\mathbb{E}[X \mid Y=y]$。整个"按箱子取值的猜测表"就是随机变量 $\mathbb{E}[X \mid Y]$。 – 最优性的严格表述（讲次 20）：$\mathbb{E}[X \mid Y]$ 是在所有 Y 的函数 $g(Y)$ 中使均方误差 $\mathbb{E}[(X-g(Y))^2]$ 最小的那个，即 MMSE；几何上它是 X 在"Y 的函数构成的空间"上的**正交投影**。 – **具体示例**：抛两枚公平硬币，X = 正面数，Y = 第一枚的结果（0 或 1）。则 $\mathbb{E}[X \mid Y=0]=0+\frac{1}{2}=0.5$，$\mathbb{E}[X \mid Y=1]=1+\frac{1}{2}=1.5$。所以 $\mathbb{E}[X \mid Y]$ 是一个**两值的随机变量**：$Y=0$ 时取 0.5、$Y=1$ 时取 1.5，各以 $1/2$ 概率。注意 $\mathbb{E}\big[\mathbb{E}[X \mid Y]\big]=0.5\cdot 0.5+0.5\cdot 1.5=1=\mathbb{E}[X]$ ✓——这就是全期望公式。

全期望公式（Law of Total Expectation / Tower Property / Smoothing）

- **定义**：对任意随机变量 X, Y（只要期望存在），

$$\mathbb{E}[X]=\sum_{y}\mathbb{E}[X \mid Y=y]\,\Pr[Y=y]=\mathbb{E}\big[\mathbb{E}[X \mid Y]\big].$$

- **直观解释**：**"分组平均再平均"**。把样本按 Y 的取值分成若干组，在每组内部求平均，然后按各组的"大小"（概率权重）加权，得到总体平均。类比：算全国平均身高 → 先算各省平均，再按各省人口加权。**同样可以先按"第一步走到哪里"分组，这就把全期望公式与首步分析连起来了。**
- **具体示例**：Y 均匀取 $\{1,2,3,4\}$，给定 $Y=y$ 时 $X\sim B(y,\frac{1}{2})$。则 $\mathbb{E}[X \mid Y=y]=y/2$，故

$$\mathbb{E}[X]=\sum_{y=1}^{4}\frac{y}{2}\cdot\frac{1}{4}=\frac{1}{4}\cdot\frac{1+2+3+4}{2}=\frac{1}{4}\cdot 5=1.25.$$

脚本蒙特卡洛 5×10^5 次得 1.2515 ✓（与解析 1.25 吻合）。

完整证明与推导（核心）

定理 26.1（n 步分布：$\pi_n=\pi_0 P^n$）：设链的初始分布为 π_0（行向量），则 X_n 的分布为

$$\pi_n=\pi_0 P^n,\quad n\ge 0.$$

特别地，若 $\pi_0(i)=1$（从 i 确定出发），则 $\pi_n(j)=P^n(i,j)=\Pr[X_n=j \mid X_0=i]$。

证明策略：**对 n 做归纳 + 用马尔可夫性质把路径概率因式分解**。选择这个策略是因为"链的联合分布"天然按时间顺序条件分解（这正是马尔可夫性质给的东西），分解完再对所有中间状态求和，求和就是矩阵乘法。

逐步推导：

第 1 步（写出**路径概率**的因式分解）。对任意状态序列 $i_0,i_1,\dots,i_n$，用条件概率的链式法则：

$$\Pr[X_0=i_0,X_1=i_1,\dots,X_n=i_n]=\Pr[X_0=i_0]\prod_{k=1}^{n}\Pr[X_k=i_k \mid X_0=i_0,\dots,X_{k-1}=i_{k-1}].$$

由马尔可夫性质，每个条件概率只需看前一项：

$$=\pi_0(i_0)\,P(i_0,i_1)\,P(i_1,i_2)\cdots P(i_{n-1},i_n).$$

第 2 步（边缘化到 X_n）。对所有 $i_0,\dots,i_{n-1}$ 求和（i_n 固定）：

$$\Pr[X_n=i_n]=\sum_{i_0,\dots,i_{n-1}}\pi_0(i_0)P(i_0,i_1)\cdots P(i_{n-1},i_n).$$

第 3 步（认出这是矩阵乘法）。最强的做法是**对 n 归纳**。 – **基础情形 $n=1$**：

$$\pi_1(j)=\Pr[X_1=j]=\sum_i\Pr[X_0=i]\Pr[X_1=j \mid X_0=i]=\sum_i\pi_0(i)P(i,j)=(\pi_0P)(j).\ \checkmark$$

- **归纳步骤**：设 $\pi_n=\pi_0P^n$。则

$$\pi_{n+1}(j)=\Pr[X_{n+1}=j]=\sum_i\Pr[X_n=i]\Pr[X_{n+1}=j \mid X_n=i]=\sum_i\pi_n(i)P(i,j)=(\pi_nP)(j)=(\pi_0P^{n+1})(j).$$

关键：第二个等号处用到马尔可夫性质——$\Pr[X_{n+1}=j \mid X_n=i]$ 与更早的历史无关，所以只要知道 X_n 的**边缘**分布就能算 X_{n+1} 的分布。**这就是"马尔可夫链的分布演化完全由当前分布决定"**的含义。

第 4 步（结论）：由归纳原理，$\pi_n=\pi_0P^n$ 对一切 $n\ge 0$ 成立。取 $\pi_0=e_i$（第 i 个单位向量，即从 i 确定出发），得 $\pi_n(j)=(e_iP^n)(j)=P^n(i,j)$ ✓。

第 5 步（脚本验算）。两状态**对称**链 $a=0.3$（$P=\begin{pmatrix}0.7&0.3\\0.3&0.7\end{pmatrix}$）：$\pi_0=(\frac{1}{2},\frac{1}{2})$ 时 π_n 恒为 $(\frac{1}{2},\frac{1}{2})$（因为它是平稳分布）；$\pi_0=(1,0)$ 时

$$\pi_1=(0.7,0.3),\ \pi_2=(0.58,0.42),\ \pi_3=(0.532,0.468),\ \pi_4=(0.5128,0.4872),\ \pi_5=(0.50512,0.49488).$$

与 $\frac{1}{2}+\frac{1}{2}(1-2a)^n=0.5+0.5\cdot 0.4^n$ 逐个一致（$0.70,0.58,0.532,0.5128,0.50512$ ✓）。**收敛速度由 $|1-2a|$ 决定**：$a=0.1$ 时 $|1-2a|=0.8$，$n=10$ 误差 5.37×10^{-2}、$n=50$ 误差 7.14×10^{-6}；$a=0.49$ 时 $|1-2a|=0.02$，$n=10$ 误差已是 5.12×10^{-18}（**几乎瞬间混合**）；$a=0.01$ 时 $|1-2a|=0.98$，$n=50$ 误差仍高达 0.182（**混合极慢**）。

【证明机制解说】：证明的"灵光一现"是把**路径概率拆成"初始分布 × 一串转移概率"**，然后对所有中间状态求和。而"对所有中间状态求和"这个操作**恰好就是矩阵乘法的定义**，所以概率问题自动翻译成矩阵代数。请注意第 3 步归纳中用到马尔可夫性质的方式：**我们不需要知道 X_n 从哪里来，只需要知道它在哪**。若过程有记忆

（例如 X_{n+1} 依赖 X_n 和 X_{n-1}），π_{n+1} 就无法由 π_n 单独确定，整个矩阵框架会立刻崩溃。**这也是建模时"状态必须包含所有相关历史"的原因。**

定理 26.2（平稳分布的不动点刻画）：$\pi_n = \pi_0$ 对一切 $n \geq 0$ 成立 $\iff$ π_0 是平稳分布（即 $\pi_0 P = \pi_0$）。

证明策略：双向蕴含的直接证明。

逐步推导：

第 1 步（$\Rightarrow$）。若 $\pi_n = \pi_0$ 对一切 $n \geq 0$，则特别地 $\pi_1 = \pi_0$。而由定理 26.1，$\pi_1 = \pi_0 P$，故 $\pi_0 P = \pi_0$，即 π_0 满足平衡方程，是平稳分布。

第 2 步（$\Leftarrow$）。设 $\pi_0 P = \pi_0$。则 $\pi_1 = \pi_0 P = \pi_0$。再用归纳：若 $\pi_n = \pi_0$，则

$$\pi_{n+1} = \pi_n P = \pi_0 P = \pi_0.$$

由归纳原理，$\pi_n = \pi_0$ 对一切 $n \geq 0$ 成立。

【证明机制解说】：这条定理把"**分布不随时间变化**"翻译成了"**π 是 P 的特征值 1 的左特征向量**"。所以"求平稳分布"就是"**求特征值 1 的特征向量（再归一化）**"——一个纯粹的线性代数问题。**注意"平稳"不是说链不动**（它可能每步都在跳），而是说**分布**不动：流出的量与流入的量恰好平衡。

定理 26.3（不可约有限链的时间比例收敛与平稳分布的唯一性）：设有限马尔可夫链不可约、转移矩阵 P。则对**任意**初始分布 π_0，存在唯一的平稳分布 π，且对每个状态 i

$$\lim_{n\to\infty} \frac{1}{n} \sum_{m=0}^{n-1} \mathbf{1}\{X_m = i\} = \pi(i),$$

这个极限以概率 1 成立（也依概率成立）。

证明策略：**用"返回时间"给平稳分布一个构造性定义**，再用大数定律（讲次 23）把时间比例算出来，最后验证它满足平衡方程。严格的完整证明（含耦合论证）超出本课范围，但下面给出五个步骤的完整论证骨架——它是"直觉上为什么成立"的最清楚的路径。

逐步推导：

第 1 步（用返回时间构造 π）。固定状态 i，设 $\pi_0(i) = 1$（从 i 出发），令 $T(i)$ 为**首次返回 i 所需步数**（$T(i) \geq 1$）。定义

$$\pi(i) := \frac{1}{\mathbb{E}[T(i)]}.$$

直观：访问 i 的间隔平均是 $\mathbb{E}[T(i)]$ 步，长程来看"平均每 $\mathbb{E}[T(i)]$ 步访问一次 i"，所以时间比例是 $1/\mathbb{E}[T(i)]$。**脚本验证**（天气链）：$\mathbb{E}[T(S)] = 1/\pi_S = 28/9 = 3.111111$（模拟 3.1084 ✓）、$\mathbb{E}[T(C)] = 7/3 = 2.333333$（模拟 2.3316 ✓）、$\mathbb{E}[T(R)] = 4$（模拟 3.9894 ✓）。

第 2 步（所有状态都常返）。有限链中至少有一个状态常返（若全为瞬态，则总访问次数有限，但链有无穷多步，矛盾）。设 i 常返。对任意其他状态 j，由不可约性，从 i 出发有正概率 $p > 0$ **在返回 i 之前先访问 j**（否则从 i 永远到不了 j）。每次访问 i 都独立地以概率 p 触发一次"访问 j"（马尔可夫性质！），而 i 被访问无限多次，故 j 也被访问无限多次——**所有状态都常返**。类比：以 $p > 0$ 的概率抛正面抛无限多次，必然见到无限多个正面（讲次 19 的几何分布/Borel–Cantelli 直觉）。

第 3 步（时间比例 = $1/\mathbb{E}[T(i)]$）。设 $T_1, T_2, T_3, \ldots$ 是连续访问 i 之间的间隔。由马尔可夫性质，**每次进入 i 后过程"重新开始"**，故 $T_1, T_2, \ldots$ 独立同分布。由（强）大数定律（讲次 23），

$$\frac{T_1 + \cdots + T_k}{k} \longrightarrow \mathbb{E}[T_1] \quad \text{（依概率）} \quad \Longrightarrow \quad \frac{k}{T_1 + \cdots + T_k} \longrightarrow \frac{1}{\mathbb{E}[T_1]} = \pi(i).$$

左端的含义正是"到第 k 次访问为止的访问频率 $\approx$ 时间比例"。

第 4 步（$\pi(i) > 0$ 且时间比例之和为 1）。时间比例非负、加起来必须等于 1（因为链总在**某个**状态），故不可能所有 $\pi(i)$ 都为 0，即至少有一个 $\pi(i) > 0$。再由第 2 步的论证（"访问 i 无限多次 $\Rightarrow$ 访问每个 j 无限多次"），$\pi(j) > 0$ 对一切 j 成立。

第 5 步（π 满足平衡方程）。链在长 n 步中访问 j 大约 $n\pi(j)$ 次。设 i 是某个状态。每次访问 j 之后有概率 $P(j,i)$ **紧接着**访问 i，所以"先 j 后 i"这种相邻对出现约 $n\pi(j)P(j,i)$ 次。而"在 i 的访问"总次数等于"任意 j 之后紧接着 i"的次数之和：

$$n\pi(i) \approx \sum_j n\pi(j)P(j,i) \implies \pi(i) = \sum_j \pi(j)P(j,i),$$

即 $\pi = \pi P$。**平衡方程证明完毕。**

第 6 步（唯一性）。设 ν 是另一个平稳分布，取 $\pi_0 = \nu$。则 $\Pr[X_n = i] = \nu(i)$ 对一切 n 恒成立，故时间比例序列 $\frac{1}{n}\sum_m \mathbf{1}\{X_m = i\}$ 的期望恒为 $\nu(i)$。由第 3 步该序列收敛到 $\pi(i)$，而"收敛 + 有界（取值在 $[0,1]$）"蕴含期望也收敛到 $\pi(i)$（严谨论证：对任意 $\epsilon > 0$，当 n 充分大时 $\Pr[|Y_n - \pi(i)| \leq \epsilon] \geq 1 - \epsilon$，于是 $\mathbb{E}[|Y_n - \pi(i)|] \leq \epsilon(1-\epsilon) + \epsilon \leq 2\epsilon$，再对一切 $m \geq n$ 成立），故 $\nu(i) = \pi(i)$。**平稳分布唯一。**

【证明机制解说】：这条定理最深刻的地方是"**平稳分布 = 访问频率 = $1/\mathbb{E}[$返回时间$]$**" 这个三重等价。它把"代数对象 π"（特征向量）与"概率对象"（时间比例）与"几何对象"（返回时间的倒数）打通了。**注意本定理只要求不可约，不要求非周期**——时间比例对周期链照样收敛（因为"分摊到长期"把振荡抹平了）。这正是下面定理 26.4 与非周期的分水岭。

定理 26.4（非周期链的分布收敛）：设有限链不可约、非周期（即某个状态的周期为 1，由定理 26.3 的讨论知所有状态的周期都为 1）。则

$$\Pr[X_n = i] \longrightarrow \pi(i) \quad \text{对一切 } i, \text{ 当 } n \to \infty,$$

其中 π 是唯一的平稳分布。

证明策略：**耦合论证 (coupling argument)**——构造两条独立的链，一条从平稳分布 π 出发、一条从任意初始分布 π_0 出发，证明它们**在有限时间内以概率 1 "相遇"**，相遇之后"粘在一起"（couple）走。于是从 π_0 出发的那条链的分布最终与从 π 出发的相同，即趋于 π。

逐步推导：

第 1 步（周期为 1 蕴含"最终连续可达"）。令 $S(i)=\{n>0:P^n(i,i)>0\}$。若 $\gcd S(i)=1$，则可证**存在整数 $n(i)$ 使得 $\{n(i),n(i)+1,n(i)+2,\dots\}\subseteq S(i)$**（即"从某个时刻起，每个步数都能回到 i"）。理由：$\gcd S(i)=1$ 时存在 $a,b\in S(i)$ 且 $\gcd\{a,b\}=1$；用扩展欧几里得（讲次 5）得整数 m,n 使 $ma+nb=1$；取 $k=m^-a+n^-b$，则 k 与 $k+1$ 都在 $S(i)$；于是任何 $n\geq k^2$ 都可以写成 $n=(a'-b')k+b'(k+1)$（$b'\in\{0,\dots,k-1\}$）的形式，从而 $n\in S(i)$。 – **具体示例**：天气链的状态 E（借用官方例子）满足 $S(E)=\{4,5,6,\dots\}$，$n(E)=4$。脚本对天气链验证：$P^n(S,S)>0$ 对一切 $n\geq 2$ 成立。

第 2 步（所有状态的周期都是 1）。设 $d(i)=1$。对任意 j，由不可约性存在 a 步 $j\to i$ 与 b 步 $i\to j$。于是从 j 出发可走 $a+n(i)+b$ 步回到 j，也可以走 $a+n(i)+1+b$ 步回到 j（先 $j\to i$、再 $i\to i$ 走 $n(i)$ 或 $n(i)+1$ 步、再 $i\to j$）。两个**连续整数**都在 $S(j)$ 里，故 $\gcd S(j)\mid 1$，即 $d(j)=1$。

第 3 步（存在统一的"汇合时刻"）。固定状态 i。对每个 j 由不可约性存在 $m(j,i)$ 使 $P^{m(j,i)}(j,i)>0$。由第 1 步，$P^n(j,j)>0$ 对一切 $n\geq n(j)$。故对 $n\geq n(j)+m(j,i)$，

$$P^n(j,i)\geq P^{n-m(j,i)}(j,j)\cdot P^{m(j,i)}(j,i)>0.$$

取 $k:=\max_j\{n(j)+m(j,i)\}$，则**从任何状态 j 出发，走恰好 k 步到达 i 的概率都严格为正**。记这个概率的下界为 $p:=\min_j P^k(j,i)>0$。

第 4 步（两条独立链在 k 步后以概率 $\geq p$ 相遇）。设 X_n 从 π 出发（于是 $\Pr[X_n=i]=\pi(i)$ 对一切 n）、Z_n 从任意 π_0 出发，两条链**独立**。则

$$\Pr[X_k=i,\ Z_k=i]=\pi(i)\cdot P^k(\cdot,i\mid\pi_0)\geq\pi(i)\cdot p>0.$$

（更精细的做法：把 Z 的初始分布分解到各状态，用 $\min_j P^k(j,i)\geq p$。）总之，**在时刻 k，"两条链都在 i"有正概率**。若没遇上，再过 k 步又有一个独立的正概率 p，如此反复：设 $\tau=\min\{n\geq 0:X_n=Z_n\}$，则

$$\Pr[\tau>km]\leq(1-p)^m\longrightarrow 0\quad(m\to\infty).$$

所以它们几乎必然在有限时间内相遇。

第 5 步（粘合）。定义第三条链

$$Y_n:=\begin{cases}Z_n, & n<\tau,\\ X_n, & n\geq\tau.\end{cases}$$

即"**跟着 Z 走，直到撞上 X，之后就永远贴着 X 走**"。由马尔可夫性质与强马尔可夫性，Y_n **仍然是转移矩阵为 P、初始分布为 π_0 的马尔可夫链**（在 τ 时刻 $Y_\tau=X_\tau$，从那里往后复制 X 的走向，因为 X 本身是 P–链）。

第 6 步（收尾）。因为 $\Pr[X_n\neq Y_n]=\Pr[\tau>n]\to 0$，故对任意 i，

$$|\Pr[X_n=i]-\Pr[Y_n=i]|\leq\Pr[X_n\neq Y_n]\longrightarrow 0.$$

而 $\Pr[X_n=i]=\pi(i)$ 对一切 n 成立（X 从平稳分布出发），故 $\Pr[Y_n=i]\to\pi(i)$。但 Y_n 与 Z_n **同分布**（同一个 P、同一个 π_0），所以 $\Pr[Z_n=i]\to\pi(i)$。**这对任意初始分布 π_0 成立，定理得证。**

【证明机制解说】：耦合论证的"灵光一现"是**让两条独立的链赛跑，然后强行把它们粘起来**。这解决了两个技术困难：(i) 直接比较 π_0P^n 与 π 需要控制矩阵幂的收敛，很难；(ii) 耦合把"分布收敛"变成"**两条轨道相遇的概率**"，而后者只需一个下界 $p>0$ 加上反复尝试。**注意哪里用到了非周期**：第 1 步需要"从某个时刻起每一步都能回到 i"，这正是 $d(i)=1$ 给的。若 $d=2$（如 $a=1$ 的两状态链），从 0 到 0 只能在偶数步，两条链在奇偶相位不同时**永远不能同时落在 i**，耦合失败——这就是周期链 $\Pr[X_n=i]$ 不收敛的机制。

反例（周期性破坏收敛）：取两状态链 $a=1$，即 $P=\begin{pmatrix}0&1\\1&0\end{pmatrix}$。它**不可约**（$0\leftrightarrow 1$）、**有唯一平稳分布 $\pi=(\frac12,\frac12)$**（脚本验算 $\pi P=\pi$ ✓），**时间比例也收敛到 $\frac12$**。但取 $\pi_0=(1,0)$，则 $\Pr[X_n=0]$ 依次为 $1,0,1,0,1,0,\dots$，**永不收敛**（脚本验算 $n=0..5$ 得到 $1,0,1,0,1,0$）。所以定理 26.4 的"非周期"条件**不可删**——这是"不可约 + 有唯一平稳分布"**还不够**的一个漂亮反例。

反例（可约链平稳分布不唯一）：取 $P=\begin{pmatrix}0.5&0.5&0\\0.5&0.5&0\\0&0&1\end{pmatrix}$（状态 $\{1,2,3\}$）。状态 3 吸收，$\{1,2\}$ 是一个闭的互通类，$1,2$ 到不了 3、3 也到不了 $1,2$，故链**可约**。于是

$$\pi^{(1)}=(\tfrac12,\tfrac12,0),\qquad\pi^{(2)}=(0,0,1)$$

都是平稳分布，而且它们的**任意凸组合** $\pi=t\pi^{(1)}+(1-t)\pi^{(2)}$（$t\in[0,1]$）也都是平稳分布——**无穷多个**。脚本验算：$\pi^{(1)}P=\pi^{(1)}$ ✓、$\pi^{(2)}P=\pi^{(2)}$ ✓、$(0.3,0.3,0.4)P=(0.3,0.3,0.4)$ ✓。**这说明"不可约"是"平稳分布唯一"的必要条件。** 直观上，从 1 出发你永远到不了 3，长期时间比例是 $(1/2,1/2,0)$；从 3 出发是 $(0,0,1)$——长期行为依赖初始条件，谈不上唯一。

定理 26.5（首步分析：吸收概率）：设 $A,B\subseteq\mathcal{X}$ 不交，$h(i)$ 为"从 i 出发、在进入 B 之前先进入 A 的概率"。则 h 是下述线性方程组的**唯一**解：

$$h(i)=1\ (i\in A),\qquad h(i)=0\ (i\in B),\qquad h(i)=\sum_{j\in\mathcal{X}}P(i,j)h(j)\ (i\notin A\cup B).$$

证明策略：**全期望公式 + 马尔可夫性质**。选择这个策略是因为"第一步走到哪里"给出了一个天然的分组（partition）：事件"先从 A 而非 B 被吸收"可以按第一步的去向 j 分成互不相交的若干份，于是全期望/全概率公式直接可用。

逐步推导：

第 1 步（边界条件）。若 $i\in A$，则在"进入 A 之前先进入 A"是必然事件（已经在了），故 $h(i)=1$。若 $i\in B$，同理 $h(i)=0$。

第 2 步（按第一步分组）。对 $i\notin A\cup B$，设事件 E_i = "从 i 出发先进入 A 而非 B"。按第一步落点 j 做划分：$\{X_1=j\}$ 两两不交、并起来是整个样本空间（因为链一定要走一步到某处）。由全概率公式，

$$h(i) = \Pr[E_i] = \sum_{j \in \mathcal{X}} \Pr[E_i \mid X_1 = j] \cdot \Pr[X_1 = j] = \sum_j \Pr[E_i \mid X_1 = j]\, P(i,j).$$

第 3 步（用马尔可夫性质化简条件概率）。关键一步：**给定 $X_1 = j$，"从 i 出发先进入 A"这件事与 $X_0 = i$ 无关，等价于"从 j 出发先进入 A"**。形式化地：

$$\Pr[E_i \mid X_1 = j] = \Pr[E_j] = h(j).$$

依据：马尔可夫性质说"给定现在，未来与过去独立"；而已知 $X_1 = j$ 时"未来是否先撞 A"完全由从 j 出发的演化决定。**这正是"首步分析"这个名字的由来：只看第一步，其余打包成 $h(j)$。**

第 4 步（合并）：

$$h(i) = \sum_j P(i,j) h(j), \quad i \notin A \cup B.$$

第 5 步（唯一性）。这是一个 $|\mathcal{X} \setminus (A \cup B)|$ 个未知量的线性方程组。在吸收链中，从每个非吸收态出发以正概率到达吸收态（即"瞬态"部分没有闭的互通类），可以证明该方程组的系数矩阵 $I - Q$（Q 为限制在非吸收态上的子矩阵）**可逆**，因为 $\sum_{m \geq 0} Q^m = (I-Q)^{-1}$ 收敛（$Q^m \to 0$，瞬态部分最终会离开）。故解**唯一**，即 h 被完全确定。

第 6 步（**完整算例：赌徒破产 Gambler's Ruin**）。赌徒从 $$m出发，每局以概率p赢$1、以概率q=1−p输$1，直到资金达到0（破产）或M（成功）。状态 n\in{0,1,\dots,M}，0与M吸收。设\alpha(n)=〃从n出发最终赢到M$ 而非输光"的概率，则

$$\alpha(n) = q\,\alpha(n-1) + p\,\alpha(n+1)\ (0 < n < M), \qquad \alpha(0) = 0, \quad \alpha(M) = 1.$$

解这个递推（用特征方程法）： – 试探解 $\alpha(n) = \lambda^n$（无常数项时递推是齐次的）。代入得 $\lambda^n = q\lambda^{n-1} + p\lambda^{n+1}$，两边除 λ^{n-1}：$\lambda = q + p\lambda^2$，即 $p\lambda^2 - \lambda + q = 0$。用求根公式，

$$\lambda = \frac{1 \pm \sqrt{1 - 4pq}}{2p}.$$

因为 $4pq = 4p(1-p)$，而 $1-4p+4p^2 = (1-2p)^2$，所以 $\sqrt{1-4pq} = \sqrt{(1-2p)^2} = |1-2p|$。在 $p<1/2$ 的常见情形下 $1-2p>0$，故 $\sqrt{1-4

$$\lambda_1 = \frac{1-(1-2p)}{2p} = \frac{2p}{2p} = 1, \qquad \lambda_2 = \frac{1+(1-2p)}{2p} = \frac{2-2p}{2p} = \frac{1-p}{p} = \frac{q}{p}.$$

即

$$\lambda_1 = 1, \qquad \lambda_2 = \rho := \frac{q}{p}.$$

快速自检：两根之积应为 $q/p = \rho$（韦达定理，常数项/首项系数），而 $1\cdot\rho = \rho$ ✓；两根之和应为 $1/p$，而 $1+\frac qp = \frac{p+q}{p} = \f

- 通解 $\alpha(n) = a + b\rho^n$。代入边界条件：

$$\alpha(0) = a + b = 0 \implies b = -a; \qquad \alpha(M) = a + b\rho^M = 1 \implies a(1-\rho^M) = 1 \implies a = \frac{1}{1-\rho^M}.$$

- 故

$$\boxed{\alpha(n) = \frac{1-\rho^n}{1-\rho^M}, \qquad \rho = \frac{q}{p}\ (p \neq q).}$$

- **$p = q = 1/2$ 的情形**：此时 $\rho = 1$，上面的公式是 $0/0$。回到递推 $\alpha(n) = \frac12 \alpha(n-1) + \frac12 \alpha(n+1)$，即 $\alpha(n+1) - \alpha(n) = \alpha(n) - \alpha(n-1)$：差分为常数，故 α 是**线性**的，配上边界条件得 $\alpha(n) = n/M$。
- **脚本验算（$p = 0.4$，$\rho = 1.5$，$M = 5$）**：公式给出 $\alpha(0) = 0$、$\alpha(1) = 0.075829$、$\alpha(2) = 0.189573$、$\alpha(3) = 0.360190$、$\alpha(4) = 0.616114$、$\alpha(5) = 1$；**直接解线性方程组（Gauss 消元）得到完全相同的六个数** ✓；且递推自检 $q\alpha(n-1) + p\alpha(n+1)$ 对 $n = 1,2,3,4$ 逐项复现 $\alpha(n)$ ✓。公平情形 $p = q = 0.5$ 同样验算：$n/M = 0, 0.2, 0.4, 0.6, 0.8, 1$，与直接解方程一致 ✓；蒙特卡洛 3×10^5 次实验从 $n = 2$ 出发，实测胜率 0.3998（理论 0.4）✓。
- **赌场的算例（官方数值，脚本验算）**：$p = 0.48$、$M = 100$、起始 $10：

$$\alpha(10) = \frac{1-\rho^{10}}{1-\rho^{100}}, \qquad \rho = \frac{0.52}{0.48} = \frac{13}{12} \approx 1.083333.$$

脚本得 $\alpha(10)\approx4.0983\times10^{-4}$。于是赌场对每位这样的赌客的期望收益是

$$(1 - 4.1 \times 10^{-4}) \times \$10 - 4.1 \times 10^{-4} \times \$990 \approx \$9.60.$$

对比"一局定胜负"的赌客：赌场期望收益只有 $0.52\times\$10-0.48\times\$10 = \$0.40$。**"不推你的运气（don't push your luck）"的含义在这里**：赌徒因为"想多

【证明机制解说】：首步分析的"灵光一现"是第 3 步：`Pr[E_i | X_1 = j] = h(j)`。**这一步把"从 i 出发的整个未来"替换成"从 j 出发的同一个问题"**——这正是马尔可夫性质的内容（未来只依赖现在 $X_1=j$，不依赖过去 $X_0=i$）。剩下的一切都是线性代数。请注意两个常见错误：(i) **漏掉边界条件**：不代入 $\alpha(0)=0,\alpha(M)=1$ 就只能得到"带两个自由常数的通解"，无法定出 α；(ii) **误以为 n 很大时能用稳态代替**：这是**吸收链**，没有平稳分布（可约！），必须解方程。

反例（漏掉边界条件的后果）：仍以赌徒破产为例。若忘记 $\alpha(0)=0$、$\alpha(M)=1$，只拿到通解 $\alpha(n)=a+b\rho^n$。此时若错误的"对称性论证"给出 $\alpha(n)=n/M$（只在 $p=1/2$ 时才对），在 $p=0.4$ 时会得到 $\alpha(2)=0.4$，**而正确值是 0.189573**——错了一倍多。再看极端情形：$p=0.4$、$M=100$ 时 $\alpha(10)=4.1\times10^{-4}$，而"线性猜测" $\alpha(10)=0.1$，**差了 244 倍。边界条件承载了全部的非线性信息**，绝不能丢。

定理 26.6（首步分析：期望吸收时间）：设 $t(i)$ 为从 i 出发到进入吸收集 A 的期望步数。则

$$t(i)=0\ (i\in A),\qquad t(i)=1+\sum_j P(i,j)\,t(j)\ (i\notin A).$$

证明策略：全期望公式（把期望按第一步分组）+ 线性性。选择这个策略的理由：期望的线性性让"已经走了一步"与"剩下的期望步数"可以直接相加。

逐步推导：

第 1 步（边界）。$i\in A$ 时已经到达，需 0 步，故 $t(i)=0$。

第 2 步（按第一步分组）。设 T_i 为从 i 出发到进入 A 的步数。则 $T_i=1+T_{X_1}$（走一步到 X_1，再走 T_{X_1} 步）。用全期望公式按 X_1 分组：

$$t(i)=\mathbb{E}[T_i]=\mathbb{E}\big[1+T_{X_1}\big]=1+\sum_j \Pr[X_1=j]\cdot\mathbb{E}[T_{X_1}\mid X_1=j]=1+\sum_j P(i,j)t(j).$$

关键：$\mathbb{E}[T_{X_1}\mid X_1=j]=t(j)$，又是马尔可夫性质。

第 3 步（**完整算例 A：五状态链的命中时间**）。考虑下面的五状态链（网页浏览模型的变体，状态 A,B,C,D,E）：

$$P=\begin{pmatrix} 0 & 1/2 & 0 & 1/2 & 0\\ 0 & 0 & 1 & 0 & 0\\ 1 & 0 & 0 & 0 & 0\\ 1/3 & 1/3 & 0 & 0 & 1/3\\ 0 & 1/2 & 1/2 & 0 & 0 \end{pmatrix}.$$

设 $\beta(i)$ 为从 i 出发首次到达 E 的期望步数。首步方程为

$$\beta(A)=1+\tfrac12\beta(B)+\tfrac12\beta(D),\quad \beta(B)=1+\beta(C),\quad \beta(C)=1+\beta(A),$$

$$\beta(D)=1+\tfrac13\beta(A)+\tfrac13\beta(B)+\tfrac13\beta(E),\quad \beta(E)=0.$$

逐步求解（代入消元，手动可追踪）：– 由第三式 $\beta(C)=1+\beta(A)$；代入第二式：$\beta(B)=1+(1+\beta(A))=2+\beta(A)$。– 代入第四式：$\beta(D)=1+\tfrac13\beta(A)+\tfrac13(2+\beta(A))+0=1+\tfrac23+\tfrac13\beta(A)+\tfrac13\beta(A)=\tfrac53+\tfrac23\beta(A)$。– 代入第一式：

$$\beta(A)=1+\tfrac12(2+\beta(A))+\tfrac12\big(\tfrac53+\tfrac23\beta(A)\big)=1+1+\tfrac12\beta(A)+\tfrac56+\tfrac13\beta(A)=\tfrac{17}{6}+\tfrac56\beta(A).$$

```
故 $\beta(A) - \tfrac56\beta(A) = \tfrac16\beta(A) = \tfrac{17}{6}$，得 $\beta(A) = 17$。
```

- 回代：$\beta(B)=19$、$\beta(C)=18$、$\beta(D)=\tfrac53+\tfrac{34}{3}=13$、$\beta(E)=0$。
- **脚本验算**：把 $\beta=(17,19,18,13,0)$ 代回五条方程，逐条精确成立 ✓。蒙特卡洛模拟 2×10^5 次（从各状态出发）：$\beta(A)=17.0297$、$\beta(B)=19.0260$、$\beta(C)=18.0219$、$\beta(D)=13.0948$ ✓。
- **注意直觉核对**：$\beta(C)=18>\beta(B)=19$? 不对——$\beta(B)=19$ 确实大于 $\beta(C)=18$，因为 B 必须先走到 C 再走 $\beta(C)$ 步，多一步。同理 $\beta(C)=18\approx\beta(A)+1=18$ ✓，$\beta(B)=19=\beta(C)+1$ ✓。这些"差一步"的关系是检验解是否合理的快速方法。

第 4 步（**完整算例 B：两次连续正面**）。反复抛公平硬币直到出现 HH。状态 S（开始）、T（上次反面）、H（上次正面、还没连两个）、E（成功）。转移：$S\to T$ 或 H（各 $1/2$）；$T\to T$ 或 H（各 $1/2$）；$H\to T$ 或 E（各 $1/2$）；$E\to E$。首步方程：

$$\beta(S)=1+\tfrac12\beta(T)+\tfrac12\beta(H),\quad \beta(T)=1+\tfrac12\beta(T)+\tfrac12\beta(H),$$

$$\beta(H)=1+\tfrac12\beta(T)+\tfrac12\beta(E),\quad \beta(E)=0.$$

注意 $\beta(S)=\beta(T)$（两者的转移分布完全相同，首步方程一样）。故设 $\beta(T)=x$、$\beta(H)=y$：

$$x=1+\tfrac12x+\tfrac12y\implies \tfrac12x-\tfrac12y=1\implies x-y=2.$$

$$y=1+\tfrac12x\implies y=1+\tfrac12x.$$

代入：$x-(1+\tfrac12x)=2\implies\tfrac12x=3\implies x=6$，$y=1+3=4$。故 $\beta(T)=6$、$\beta(S)=6$、$\beta(H)=4$、$\beta(E)=0$。– **脚本验算**：代入逐条成立 ✓；蒙特卡洛 5×10^5 次实测平均步数 5.9999（理论 6）✓。– **直觉核对**：$\beta(H)=4<\beta(T)=6$ 合理——已经在"上次是正面"时更接近成功。$\beta(S)=6=\beta(T)$ 也合理——第一步总要抛一次，把 S 变成 T 或 H。

第 5 步（**完整算例 C：掷骰子直到相邻两次和为 8**）。状态 S（开始）、$1,\dots,6$（上次掷出的点数）、E（成功，相邻两次和为 8）。若在状态 i 且下一次掷出 j 使得 $i+j=8$，则进入 E；否则新状态是 j。首步方程：

$$\beta(S)=1+\frac{1}{6}\sum_{i=1}^{6}\beta(i),\qquad \beta(i)=1+\sum_{j:\,i+j\neq 8}\frac{1}{6}\beta(j).$$

由对称性（$\beta(2)=\cdots=\beta(6)$? **不成立！**），要小心。由对称性，只有 1 是特殊的（因为 $1+7=8$ 但 7 不是骰子面，所以从状态 1 出发**永远不可能**在下一次就成功）。其余 $2,\dots,6$ 各自都有一个"致命"的对手点数（$6,5,4,3,2$），结构完全相同，故 $\beta(2)=\cdots=\beta(6)=:\gamma$。又 $\beta(1)=\beta(S)$（从状态 1 出发，下一次掷出 j 之后的新状态就是 j，与从 S 出发一样；而 1 不可能立刻成功）。于是方程化为两个未知量：

$$\beta(S)=1+\frac{1}{6}\big[\beta(S)+5\gamma\big]=1+\frac{1}{6}\beta(S)+\frac{5}{6}\gamma,$$
$$\gamma=1+\frac{1}{6}\big[\beta(S)+4\gamma\big]=1+\frac{1}{6}\beta(S)+\frac{2}{3}\gamma.$$

- 第一式：$\frac{5}{6}\beta(S)=1+\frac{5}{6}\gamma\implies\beta(S)=\frac{6}{5}+\gamma$。
- 第二式：$\frac{1}{3}\gamma=1+\frac{1}{6}\beta(S)\implies\gamma=3+\frac{1}{2}\beta(S)$。
- 代入：$\gamma=3+\frac{1}{2}(\frac{6}{5}+\gamma)=3+\frac{3}{5}+\frac{1}{2}\gamma=\frac{18}{5}+\frac{1}{2}\gamma\implies\frac{1}{2}\gamma=\frac{18}{5}\implies\gamma=\frac{36}{5}=7.2$。
- 于是 $\beta(S)=\frac{6}{5}+\frac{36}{5}=\frac{42}{5}=8.4$。
- **脚本验算**：$\gamma=7.2$、$\beta(S)=8.4$，代回两条方程精确成立 ✓；蒙特卡洛 5×10^5 次实测 8.3990（理论 8.4）✓。

第 6 步（**完整算例 D：梯子问题**）。20 级梯子，从地面（第 0 级）出发，每步以概率 p 上升一级、以概率 $1-p$ **摔回地面**。设 $\beta(i)$ 为从第 i 级到顶端（第 20 级）的期望步数：

$$\beta(i)=1+(1-p)\beta(0)+p\,\beta(i+1),\quad i=0,\dots,19;\qquad \beta(20)=0.$$

解法（差分方程）：试探 $\beta(i)=a+b\lambda^i$。代入并匹配系数：– 常数部分：$a=1+(1-p)(a+b)+pa$，整理得 $b=-(1-p)^{-1}$（因为 $(1-p)b+1=0$）。– 指数部分：$\lambda^i=p\lambda^{i+1}\implies\lambda=p^{-1}$。故 $\beta(i)=a-(1-p)^{-1}p^{-i}$。用边界条件 $\beta(20)=0$ 定出 $a=(1-p)^{-1}p^{-20}$，所以

$$\boxed{\beta(i)=\frac{p^{-20}-p^{-i}}{1-p}},\qquad \beta(0)=\frac{p^{-20}-1}{1-p}.$$

- **脚本验算**：$p=0.9$ 时 $\beta(0)=\frac{0.9^{-20}-1}{0.1}=72.2526$（官方给 ≈72 ✓）；$p=0.8$ 时 $\beta(0)=428.6809$（官方给 ≈429 ✓）；顺带 $p=0.95$ 时 $\beta(0)=35.7902$。
- **注意这个结果有多恐怖**：成功率从 0.9 降到 0.8（只降 10%），期望步数从 72 涨到 429（**涨了近 6 倍**）。原因是 p^{-20} 对 p **极度敏感**：$(0.8)^{-20}/(0.9)^{-20}=(0.9/0.8)^{20}=1.125^{20}\approx10.5$。**这是"高成功率系统的鲁棒性"的定量教训**：单步可靠性上的一点点退步会在需要连续成功的任务上被指数放大。相比之下，"一口气爬上"的概率是 $p^{20}=0.9^{20}=0.1216$（$p=0.9$）与 $0.8^{20}=0.0115$（$p=0.8$）——差 10.5 倍，与期望步数的放大倍数一致。
- **另一面**：为什么摔回地面的惩罚这么严重？因为 $\beta(0)$ 出现在**每一条**方程里（20 个方程）——一次失手就归零，这让状态 0 成为"超级吸收陷阱"。若改成"每次后退一级"（更温和的惩罚），期望步数会是 $\Theta(n^2/p)$ 量级（随机游走），而不是指数级。

第 7 步（**完整算例 E：赌徒破产的期望时间**）。对同一个赌徒问题，设 $\beta(n)$ 为从 $$n出发到M达到0或M$"的期望步数：

$$\beta(n)=1+q\beta(n-1)+p\beta(n+1)\ (0<n<M),\qquad \beta(0)=\beta(M)=0.$$

解法要点（非齐次线性递推）：先找一个特解，再加齐次通解。试探 $\beta(n)=\alpha n$：代入得 $\alpha n=1+\alpha n-\alpha+2p\alpha$，故需 $1-\alpha+2p\alpha=0$，即 $\alpha=(1-2p)^{-1}$，特解 $\beta_{\text{part}}(n)=n(1-2p)^{-1}$。齐次方程 $\beta(n)=q\beta(n-1)+p\beta(n+1)$ 的两个解是 $\beta=1$ 与 $\beta=\rho^n$（$\rho=q/p$，与吸收概率的推导同一特征方程）。故

$$\beta(n)=\frac{n}{1-2p}+a+b\rho^n.$$

- 边界 $\beta(0)=0$ 给 $a+b=0$，即 $b=-a$。
- 边界 $\beta(M)=0$ 给 $\frac{M}{1-2p}+a(1-\rho^M)=0$，即 $a=-\frac{M(1-2p)^{-1}}{1-\rho^M}$。
- 故

$$\boxed{\beta(n)=\frac{n}{1-2p}-\frac{M}{1-2p}\cdot\frac{1-\rho^n}{1-\rho^M}},\qquad \rho=\frac{q}{p}.$$

- **$p=1/2$ 的极限**：$1-2p=0$ 使公式发散，需重新解。此时递推为 $\beta(n)=1+\frac{1}{2}\beta(n-1)+\frac{1}{2}\beta(n+1)$，即二阶差分 $\beta(n+1)-2\beta(n)+\beta(n-1)=-2$，故 β 是**凹二次函数**。配上边界条件 $\beta(n)=n(M-n)$。
- **脚本验算（$p=0.4$，$M=5$）**：公式给 $\beta=(0,3.104265,5.260664,5.995261,4.597156,0)$；**直接解 6 元线性方程组（Gauss 消元）逐位一致** ✓。公平情形 $p=0.5$：公式 $n(M-n)$ 给 $(0,4,6,6,4,0)$，与直接解方程一致 ✓；蒙特卡洛 3×10^5 次从 $n=2$ 出发实测 5.9977（理论 6）✓。
- **直觉核对**：$p=0.4$（劣势）时 $\beta(2)=5.26<\beta(3)=6.00$——**从 $3出发反而要等更久**？这看起来反直觉，其实合理：从$3出发时，离M=5只差2步、离破产差3步，但因为劣势，它有较大概率先**往下漂**到2,1甚至破产（较快结束），也有较小概率慢慢往上爬到5（较慢）。**在两个吸收态之间，期望时间不是单调的**：它由**最快的吸收路径**主导，而不是**距离**。对称情形p=0.5时\beta(n)=n(M−n)在两端为0$、中间最大，形状是抛物线 ✓。

【证明机制解说】：这五个算例展示了同一套机械流程： 1. **识别状态**（含"上次结果"这类记忆压缩成的状态，如 T/H、上次点数）； 2. **写首步方程**（对每个非吸收态写一行，右边是"1（时间）或 0（概率）$+\sum_j P(i,j)(\cdot)$"）； 3. **利用对称性降维**（骰子例把 6 个未知量降成 2 个；两次正面例把 4 个降成 2 个）； 4. **代入消元或差分方程求解**； 5. **回代验算每条原方程**。 **最关键的是第 1 步**：马尔可夫链的建模难点从来不是解方程，而是**选对状态**。第 5 步（骰子例）之所以需要"上次点

数"作为状态，是因为"相邻两次和为 8"依赖历史；第 4 步（两次正面）需要区分"上次是 T 还是 H"；而"已经连续多少个正面"只用到 2 个，因为到 2 个就终止了。**状态空间就是"记忆的压缩表示"**，多一个维度会让方程数爆炸，少一个维度会让马尔可夫性质失效。

定理 26.7（全期望公式 Law of Total Expectation）：设 X, Y 离散随机变量，$\mathbb{E}[|X|] < \infty$。则

$$\mathbb{E}[X] = \sum_y \mathbb{E}[X \mid Y = y]\ \Pr[Y = y] = \mathbb{E}\big[\mathbb{E}[X \mid Y]\big].$$

证明策略：直接证明——把 $\mathbb{E}[X \mid Y = y]$ 的定义代入，交换求和次序，再用全概率公式（或直接看出内层求和等于 $\Pr[X = x]$）。选择这个策略是因为它只用到定义，名副其实的"一行证明"。

逐步推导：

第 1 步（写出定义）：

$$\mathbb{E}[X \mid Y = y] = \sum_x x\ \Pr[X = x \mid Y = y] = \sum_x x\ \frac{\Pr[X = x, Y = y]}{\Pr[Y = y]}.$$

第 2 步（代入右边并化简）：

$$\sum_y \mathbb{E}[X \mid Y = y] \Pr[Y = y] = \sum_y \left(\sum_x x \frac{\Pr[X = x, Y = y]}{\Pr[Y = y]} \right) \Pr[Y = y] = \sum_y \sum_x x\ \Pr[X = x, Y = y].$$

第 3 步（交换求和次序，用 Fubini/Tonelli）：

$$\sum_y \sum_x x\ \Pr[X = x, Y = y] = \sum_x x \sum_y \Pr[X = x, Y = y].$$

这一步需要绝对收敛：由 $\mathbb{E}[|X|] = \sum_x |x| \Pr[X = x] < \infty$，对 y 求和是绝对收敛的（更直接地，$\sum_y \sum_x |x| \Pr[X = x, Y = y] = \mathbb{E}|X| < \infty$）。**这就是定理里"$\mathbb{E}[|X|] < \infty$"这一条件的用处。**

第 4 步（认出边缘分布）：

$$\sum_y \Pr[X = x, Y = y] = \Pr[X = x] \quad \text{（边缘化 / 全概率公式）}.$$

第 5 步（收尾）：

$$\sum_x x\ \Pr[X = x] = \mathbb{E}[X]. \ \blacksquare$$

第 6 步（等价的"塔性质"形式）。$\mathbb{E}[X \mid Y]$ 是 Y 的函数，记 $g(Y) := \mathbb{E}[X \mid Y]$。则

$$\mathbb{E}[g(Y)] = \sum_y g(y) \Pr[Y = y] = \sum_y \mathbb{E}[X \mid Y = y] \Pr[Y = y] = \mathbb{E}[X].$$

即 $\mathbb{E}\big[\mathbb{E}[X \mid Y]\big] = \mathbb{E}[X]$——这叫**塔性质 (tower property)**，或**平滑性 (smoothing)**。它也可以迭代：$\mathbb{E}\big[\mathbb{E}[X \mid Y, Z] \big| Y\big] = \mathbb{E}[X \mid Y]$（对更粗的信息取条件，会"抹平"细节）。

【证明机制解说】：这个证明的全部内容就是"**分组加权平均 = 总体平均**"。技术要点只有两个：一是**交换求和次序需要绝对收敛**（这就是那个有限期望条件），二是**内层求和认出边缘分布**。请注意这条公式的威力：它把"算一个复杂期望"分解成"**先固定 Y，在条件世界内算期望（通常简单），再对 Y 加权平均**"。**首步分析（定理 26.5、26.6）就是取 $Y = X_1$（第一步的落点）的特例**——所以首步方程 $t(i) = 1 + \sum_j P(i,j) t(j)$ 中的那个求和，正是全期望公式里的 $\sum_j \Pr[X_1 = j] \mathbb{E}[T_i \mid X_1 = j]$。

定理 26.8（条件期望的基本性质）：设 X, Y, Y_1, Y_2 是随机变量，$a_1, a_2 \in \mathbb{R}$，h 是任意函数。 – **(a) 线性性**：$\mathbb{E}[a_1 Y_1 + a_2 Y_2 \mid X] = a_1 \mathbb{E}[Y_1 \mid X] + a_2 \mathbb{E}[Y_2 \mid X]$。 – **(b) 取出已知量 (factoring known values)**：$\mathbb{E}[h(X) Y \mid X] = h(X)\, \mathbb{E}[Y \mid X]$。 – **(c) 平滑性**：$\mathbb{E}\big[\mathbb{E}[Y \mid X]\big] = \mathbb{E}[Y]$（即定理 26.7）。 – **(d) 独立性**：若 Y 与 X 独立，则 $\mathbb{E}[Y \mid X] = \mathbb{E}[Y]$（**右边是常数**）。

证明策略：用条件期望的定义直接验证 (a)、(b)（逐点对每个 $X = x$ 验证）；(c) 已在定理 26.7 证明；(d) 把独立性代入条件概率定义。另一种更漂亮的证法（讲次 20 用的）是**正交投影刻画**：$\mathbb{E}[Y \mid X]$ 是 Y 在"X 的函数空间"上的正交投影，即对一切 ϕ 有 $\mathbb{E}\big[(Y - \mathbb{E}[Y \mid X])\phi(X)\big] = 0$；由这个刻画可以一行证明 (a) 与 (b)。

逐步推导（用定义逐点验证）：

(a) 固定 x 且 $\Pr[X = x] > 0$。条件分布本身是概率分布，故它对 Y 的期望满足线性性（讲次 20 的期望线性性）：

$$\mathbb{E}[a_1 Y_1 + a_2 Y_2 \mid X = x] = a_1 \mathbb{E}[Y_1 \mid X = x] + a_2 \mathbb{E}[Y_2 \mid X = x].$$

因这对每个 x 成立，作为 X 的函数逐点相等，故随机变量相等。

(b) 固定 x。由于 $h(x)$ 在此条件世界里是**常数**，

$$\mathbb{E}[h(X) Y \mid X = x] = h(x)\, \mathbb{E}[Y \mid X = x].$$

逐点成立，故 $\mathbb{E}[h(X) Y \mid X] = h(X) \mathbb{E}[Y \mid X]$。**直观**：在已知 $X = x$ 的世界里，$h(X) = h(x)$ 是"已知的"，可以当作常数提出来。

(c) 定理 26.7。

(d) 固定 x。若 $Y \perp X$，则 $\Pr[Y = y \mid X = x] = \Pr[Y = y]$，故

$$\mathbb{E}[Y \mid X = x] = \sum_y y \Pr[Y = y \mid X = x] = \sum_y y \Pr[Y = y] = \mathbb{E}[Y].$$

与 x 无关，故 $\mathbb{E}[Y \mid X] = \mathbb{E}[Y]$（常数）。

脚本 / 数值算例（官方原题的完整演算）：设 X, Y, Z i.i.d.，均值 $1/2$、二阶矩 $1/3$（例如 $U[0,1]$）。求 $\mathbb{E}[(Y+2X)^2 \mid X]$。

逐步展开（每步都标注依据）：

$$\mathbb{E}[(Y+2X)^2 \mid X] = \mathbb{E}\left[Y^2 + 4X^2 + 4XY \mid X\right]$$

$$= \mathbb{E}[Y^2 \mid X] + 4\,\mathbb{E}[X^2 \mid X] + 4\,\mathbb{E}[XY \mid X] \quad \text{（(a) 线性性）}$$

$$= \mathbb{E}[Y^2] + 4X^2 + 4X\,\mathbb{E}[Y \mid X] \quad \text{（(d) 独立 + (b) 取出已知量）}$$

$$= \mathbb{E}[Y^2] + 4X^2 + 4X\,\mathbb{E}[Y] \quad \text{（(d) 再用一次独立性）}$$

$$= \frac{1}{3} + 4X^2 + 2X \quad \text{（代入 } \mathbb{E}[Y^2] = 1/3,\ \mathbb{E}[Y] = 1/2\text{）}.$$

- **注意这个答案是一个随机变量**（X 的函数），这正是条件期望的本质。
- **一致性检验（塔性质）**：$\mathbb{E}\left[\frac{1}{3} + 4X^2 + 2X\right] = \frac{1}{3} + 4 \cdot \frac{1}{3} + 2 \cdot \frac{1}{2} = \frac{1}{3} + \frac{4}{3} + 1 = \frac{8}{3} \approx 2.666667$。脚本对 $X, Y \sim U[0,1]$ 直接蒙特卡洛算 $\mathbb{E}[(Y+2X)^2]$：2.6655 ✓（吻合）。
- **为什么不能"直接算"**：$Z := (Y+2X)^2$ 关于 X 的**条件分布**很难写出来（Z 是 Y 与 X 的混合），所以 $\sum_z z \Pr[Z = z \mid X = x]$ 这条路几乎走不通。而用性质 (a)(b)(d) 只需要**矩信息**（$\mathbb{E}[Y]$、$\mathbb{E}[Y^2]$），完全绕开了条件分布。**这是条件期望性质的最大价值。**

脚本 / 数值算例（对称性技巧）：设 X, Y, Z i.i.d.，证明

$$\mathbb{E}[Y \mid Y + X + Z] = \frac{1}{3}(Y + X + Z).$$

- **推导**：由 X, Y, Z **完全对称**（交换任意两个不改变联合分布），条件期望 $\mathbb{E}[Y \mid S]$、$\mathbb{E}[X \mid S]$、$\mathbb{E}[Z \mid S]$（其中 $S := Y + X + Z$）三者必须**相等**（因为它们在业务上扮演完全相同的角色）。记公共值为 V。则由线性性，

$$3V = \mathbb{E}[Y \mid S] + \mathbb{E}[X \mid S] + \mathbb{E}[Z \mid S] = \mathbb{E}[Y + X + Z \mid S] = \mathbb{E}[S \mid S] = S.$$

```
故 $V = S/3$。
```

- **数值 / 逻辑核对**：$\mathbb{E}\left[\frac{Y+X+Z}{3}\right] = \frac{1}{3}(\mathbb{E}Y + \mathbb{E}X + \mathbb{E}Z) = \mathbb{E}[Y]$（由线性性），与塔性质一致 ✓。
- **注意这个证明的美妙之处**：它**完全不需要知道 X, Y, Z 的具体分布**！只要"i.i.d. + 矩存在"就够。这是**对称性论证**的典范：当问题在某个置换群下不变时，对称的未知量必然相等，一条方程就解出全部。

脚本 / 数值算例（优惠券收集器，呼应讲次 20）：有 n 种优惠券，每次随机独立地抽到一种，求集齐全部 n 种所需的期望次数 $\mathbb{E}[T]$。 – **条件期望解法（分而治之）**：设已经收集到 k 种，记 T_k 为"从 k 种到 $k+1$ 种"所需次数。抽一次落在已有的 k 种里的概率是 k/n，落在新种类的概率是 $1 - k/n = (n-k)/n$。所以 $T_k \sim G\left(\frac{n-k}{n}\right)$（几何分布，讲次 19），故

$$\mathbb{E}[T_k] = \frac{1}{(n-k)/n} = \frac{n}{n-k}.$$

- 由线性性（这是关键：**不需要 T_k 之间独立**！它们确实不独立，但线性性不需要），

$$\mathbb{E}[T] = \sum_{k=0}^{n-1} \mathbb{E}[T_k] = \sum_{k=0}^{n-1} \frac{n}{n-k} = n \sum_{j=1}^{n} \frac{1}{j} = n\,H_n.$$

- **脚本验算**：$n = 6$ 时 $\mathbb{E}[T] = 6H_6 = 6 \times 2.45 = 14.7$，蒙特卡洛 2×10^5 次实测 14.7222 ✓；$n = 20$ 时 $20H_{20} = 71.954793$，实测 72.0133 ✓；$n = 3$ 时 $3H_3 = 5.5$；$n = 10$ 时 $10H_{10} = 29.289683$。
- **这里的"条件期望"体现在哪**：$\mathbb{E}[T_k] = n/(n-k)$ 本身就是"给定当前已收集 k 种"这个条件下的期望（条件世界里的几何分布），而总期望靠线性性相加。**注意 T_k 之间不独立**（收集到哪些种类会影响后续），但线性性照样可用——这是"条件期望 + 线性性"组合拳的典型。

脚本 / 数值算例（随机和 Random Sum）：设 N 是取非负整数的随机变量，$Y_1, Y_2, \ldots$ i.i.d. 且与 N 独立，$X = \sum_{i=1}^{N} Y_i$（$N = 0$ 时 $X = 0$）。则

$$\mathbb{E}[X] = \mathbb{E}[N]\,\mathbb{E}[Y_1].$$

证明：用全期望公式，按 N 分组：

$$\mathbb{E}[X] = \sum_{n \geq 0} \mathbb{E}[X \mid N = n] \Pr[N = n] = \sum_{n \geq 0} \mathbb{E}\left[\sum_{i=1}^{n} Y_i\right] \Pr[N = n] = \sum_{n \geq 0} n\,\mathbb{E}[Y_1] \Pr[N = n] = \mathbb{E}[Y_1] \sum_{n \geq 0} n \Pr[N = n] = \mathbb{E}[Y_1]\mathbb{E}[N].$$

这里 $\mathbb{E}[\sum_{i=1}^{n} Y_i] = n\mathbb{E}[Y_1]$ 用期望线性性（**不需要 Y_i 独立**，但求和项数 n 是固定的常数，所以是有限和，线性性直接可用）。

脚本验算：取 $N \sim \text{Poisson}(3)$（$\mathbb{E}[N] = 3$），$Y_i \sim \text{Exp}(1)$（$\mathbb{E}[Y_i] = 1$）。则 $\mathbb{E}[X] = 3 \times 1 = 3$。蒙特卡洛 4×10^5 次实测 2.9987 ✓。另一个：$N \sim \text{Poisson}(2)$，$Y \sim \text{Exp}(1)$，则 $\mathbb{E}[X] = 2$，实测 2.0034 ✓。

脚本 / 数值算例（几何分布的期望，用首步/条件期望）：$Y \sim G(p)$（首次成功所需次数）。用首步分析：h = 从"还没成功"状态到成功的期望步数，

$$h = 1 + (1-p)h + p\cdot 0 \implies ph = 1 \implies h = \frac{1}{p}.$$

脚本验算（$p = 0.3$）：$1/p = 3.333333$，蒙特卡洛 4×10^5 次实测 3.3324 ✓。这与讲次 19 用求和 $\sum_{k\ge 1} k(1-p)^{k-1}p$ 得到的结果一致，而首步法**只用一行**。**这正是首步分析的价值**：它把"无穷级数求和"换成"一元一次方程"。

反例（两条性质容易混淆：$\mathbb{E}[XY \mid X] = X\mathbb{E}[Y \mid X]$ 而非 $X\mathbb{E}[Y]$）：若 Y 与 X **不独立**，则 $\mathbb{E}[Y \mid X]$ 是 X 的函数、会随 X 变化，**不能**替换成常数 $\mathbb{E}[Y]$。具体数值：设 $X \sim U[0,1]$，给定 $X = x$ 时 $Y \sim U[0,x]$。则 $\mathbb{E}[Y \mid X] = X/2 \neq 1/4 = \mathbb{E}[Y]$。若误用 $\mathbb{E}[Y] = 1/4$ 去算 $\mathbb{E}[XY \mid X]$，会得到 $X/4$；而正确结果是 $X \cdot (X/2) = X^2/2$。两者在 $X = 1$ 处差 2 倍。**记忆口诀：(b) 只允许把"X 的函数"提出来；"Y 的期望"只有在独立时才能变成常数（性质 (d)）。**

与经典问题的联系

（1）PageRank：把网页图变成随机游走。 这是马尔可夫链最重要的现代应用。**问题实际背景**：如何给网页排序？**数学建模**：把网页看作状态、把链接看作有向边，浏览者从当前页等概率地点击出链之一，这就是一个马尔可夫链。**方案设计**：解平衡方程 $\pi P = \pi$、$\sum_i \pi_i = 1$，得到的 π 就是PageRank——"长期来看浏览者停留在各页面的时间比例"。**正确性证明**：由定理 26.3，只要链不可约（网页图强连通）就有唯一平稳分布，且时间比例收敛到它。**实际修正**：真实网页图**不**强连通（有悬挂节点、有孤立子图），所以 Google 的原始做法是加"**阻尼/随机跳转 (damping / teleportation)**"：以概率 $\alpha \approx 0.85$ 跟随链接、以 $1-\alpha$ 等概率跳到**任意**网页。修正后的矩阵 $P' = \alpha P + (1-\alpha)\frac{1}{K}\mathbf{1}\mathbf{1}^T$ 使**所有元素严格为正**，从而一定不可约且非周期（因为 $P'(i,i) > 0$ 对一切 i），唯一平稳分布与收敛性都得到保证。**这个技巧体现了"用数学假设去补救模型缺陷"的工程智慧。**

官方的小例子（五状态网页浏览链，脚本验算）：把上面的五状态链看作网页 $A, \dots, E$，平衡方程的解是

$$(\pi_A, \pi_B, \pi_C, \pi_D, \pi_E) = \frac{1}{39}(12, 9, 10, 6, 2) = (0.307692,\ 0.230769,\ 0.256410,\ 0.153846,\ 0.051282).$$

脚本验算：πP 逐位等于 π（两边同乘 39 后是 $12, 9, 10, 6, 2$，完全一致）✓；$\sum \pi_i = 1$ ✓；用 P^{200} 的第 0 行做幂迭代，得到 $(0.30769231, 0.23076923, 0.25641026, 0.15384615, 0.05128205)$，乘 39 后正好是 $(12, 9, 10, 6, 2)$ ✓。**排名是 A, C, B, D, E**——这正是 "PageRank 可以用解平衡方程来确定"的完整演示。

（2）赌徒破产与风险管理的数学化。 **背景**：赌场游戏（或保险、投资、工程冗余设计）。**建模**：随机游走 + 两个吸收壁。**方案**：解首步方程得 $\alpha(n) = \frac{1-\rho^n}{1-\rho^M}$、$\beta(n) = \frac{n}{1-2p} - \frac{M}{1-2p}\cdot\frac{1-\rho^n}{1-\rho^M}$。**结论**：即使每局胜率是 48%（只差 2 个百分点），起始 $10想赢到$100的概率只有4.1\times10^{-4}。**这给出了一条可迁移的工程洞见**：在"负漂移 + 吸收壁"的系统中，**延长博弈时间会指数级放大劣势**。同一数学模型直接用于：(i) **保险精算** $\alpha(10)\approx4.0983\times10^{-4}$，单客期望收益$9.60（对比一局定胜负的0.40）。

（3）算法分析：哈希/随机游走中的命中时间与覆盖时间。 **背景**：随机图上的搜索、覆盖问题。**建模**：随机游走在图上（如 d 维超立方体、d-正则图）。**结论**：不可约 + 非周期 + 平稳分布 π 的链上，"从 i 到 j 的期望命中时间"与"返回时间"有定量关系（$\mathbb{E}[\text{返回 } i] = 1/\pi(i)$，脚本对天气链验证：$1/\pi = (3.111111, 2.333333, 4.000000)$，模拟 $(3.1084, 2.3316, 3.9894)$ ✓）。**"混合时间 (mixing time)"** 则是 $\Pr[X_n = i]$ 收敛到 $\pi(i)$ 的速度，由 $|1-2a|$ 这类"第二大特征值"控制（脚本：$a = 0.49$ 时 $n = 10$ 误差已达 5×10^{-18}，而 $a = 0.01$ 时 $n = 50$ 误差还有 0.182）。**这直接决定了随机算法的采样代价。**

（4）首步分析与动态规划。 **背景**：任意"带随机性的决策/终止问题"。**联系**：首步方程 $h(i) = \sum_j P(i,j)h(j)$ 与**动态规划的 Bellman 方程**在形式上完全一致——"当前值 = 立即回报 + 折扣后的未来期望值"（本讲的链无折扣，但把 P 换成 γP 就得到折扣情形）。**因此本讲的方法直接迁移到马尔可夫决策过程 (MDP) 与强化学习。**

（5）可靠性工程：系统失效时间。 **背景**：一个系统由若干部件组成，部件独立地随机失效。**建模**：系统状态 = "哪些部件还完好"。**方案**：在状态图上标出"失效状态"，用首步方程求**平均失效时间 (MTTF)**。**两部件串联/并联的简单情形**：串联系统任一部件失效即失效，期望寿命可解析；并联系统需全部失效才失效，期望寿命由部件的失效分布（若为指数分布，讲次 24 的无记忆性让状态转移变得马尔可夫！）决定。**这解释了为什么"指数寿命 + 马尔可夫链"是可靠性分析的标准组合。**

与其他讲次的关联

- **讲次 15–19（概率公理 → 随机变量 → 离散分布）**：本讲的状态转移概率 $P(i,j)$ 本质上是条件概率（讲次 17），马尔可夫性质是用条件概率语言陈述的；初始分布 π_0 就是讲次 19 的 PMF；首步分析里的几何分布期望 $1/p$（两次正面前的等待、几何例子）直接引用讲次 19 的结论；本讲的算例"两次连续正面"的 $\beta(S) = 6$ 可以通过讲次 19 的几何分布来交叉验证（期望 $1/p$ 的串联）。
- **讲次 20（期望与线性性 Expectations & Linearity）**：全期望公式（定理 26.7）的证明只用到期望的定义与 Fubini 换序；而"分而治之"的另一半武器——**期望线性性**——在每一条首步分析算例中都被反复使用（例如 $\beta(A) = 1 + \frac{1}{2}\beta(B) + \frac{1}{2}\beta(D)$ 中把"1 步"与"后续期望"相加，靠的是线性性）。优惠券收集器用一个"线性性 + 条件期望"的组合拳解决，正是讲次 20 主题的延伸。
- **讲次 21（联合分布与独立性 Joint Distributions & Independence of RVs）**：条件期望 $\mathbb{E}[X \mid Y]$ 的定义需要联合分布 $\mathbf{Pr}[X = x, Y = y]$ 与条件分布 $\mathbf{Pr}[X = x \mid Y = y]$，这些概念完全来自讲次 21；性质 (d)（独立时 $\mathbb{E}[Y \mid X] = \mathbb{E}[Y]$）就是讲次 21 独立性定义的直接推论。
- **讲次 22（方差与协方差 Variance & Covariance）**：本讲的期望分析（平均步数）由讲次 22 的方差视角补全；更重要的是讲次 22 的 $\mathbf{Var}(X+Y)$ 公式与首步分析结合可以给出"吸收时间的方差"（在首步方程两侧再取一次条件期望即可，得到 $\mathbb{E}[T^2]$ 的方程组）。
- **讲次 23（集中不等式 Concentration Inequalities）**：定理 26.3 与定理 26.4 的证明中，第 3 步"用大数定律把时间平均"直接引用讲次 23 的（强）大数定律；"访问无限多次"的论证本质是 Borel–Cantelli 型论证，与讲次 23 的切尔诺夫界/Law of Large Numbers 是同一思想家族。**本讲是把讲次 23 的极限定理用在"相关序列"（马尔可夫链）上的第一个例子。**
- **讲次 24（连续概率与分布 Continuous Probability & Distributions）**：讲次 24 定理 24.4 的**无记忆性**与"指数分布是几何分布的连续极限"在本讲的马尔可夫性质那里找到了解释——无记忆性正是"迈入状态后重新开始"。若把本讲的时间离散改为连续、并把停留时间取为指数分布，就得到**连续时间马尔可夫链 (CTMC)**；讲次 24 的指数分布是它的必要构件。
- **讲次 25（高斯分布与中心极限定理 Gaussian Distribution & CLT）**：本讲只给出了时间比例 $\frac{1}{n}\sum_m \mathbf{1}\{X_m = i\}$ 的**LLN 型**收敛（定理 26.3）；CLT 型的精细化结论（$\sqrt{n}$ 尺度上的正态波动，即**马尔可夫链的中心极限定理**）需要讲次 25 的工具。而在定理 26.3 第 6 步的唯一性论证中，"收敛 + 有界 $\Rightarrow$ 期望收敛"的论证用的是讲次 23 的极限论证。

- **讲次 5（欧几里得、费马小定理、中国剩余定理 Euclid, FLT, CRT）**：定理 26.4 第 1 步"$\gcd S(i)=1$ 蕴含某个时刻后全部步数可达"的证明**恰恰使用了扩展欧几里得算法**（把 1 写成 $ma+nb$，从而由 $a,b\in S(i)$ 构造两个连续可达步数）。这是数论工具在概率论里的漂亮出场。
- **讲次 4（模运算 Modular Arithmetic）与讲次 9–10（图论 Graphs）**：马尔可夫链的状态转移图就是讲次 9–10 的**有向图**，"不可约 $\iff$ 状态图是单个强连通分量"直接把概率问题翻译成图论的连通性问题；周期性 $d(i)=\gcd\{n:P^n(i,i)>0\}$ 与图上的"回路长度的 gcd"是同一个概念。
- **讲次 18（独立性与事件组合 Independence & Combination of Events）**：在零概率事件（如 $P^n(i,i)=0$ 的"永不返回"）的处理上需要谨慎；而"访问 j 无限多次"的论证（每次访问 i 独立地以概率 p 触发）用到了事件独立性的直觉，这正是讲次 18 的主题。

关键要点

1. **马尔可夫性质 = 无记忆性**：$\Pr[X_{n+1}=j\mid X_n=i,X_{n-1},\dots,X_0]=P(i,j)$。**未来只依赖现在。建模的第一难点是选对状态**（要把所有相关历史压缩进状态，例如"上次的点数""是否已连续两次正面"）。
2. P **是行随机矩阵**：$P_{ij}\ge 0$、$\sum_j P_{ij}=1$（**每行**和为 1；列和不必为 1）。n 步转移概率由矩阵幂给出：Chapman–Kolmogorov 方程 $P^{(n)}=P^n$，n 步分布 $\pi_n=\pi_0P^n$。
3. **平稳分布 π 由平衡方程刻画**：$\pi=\pi P$（π 是 P 对应特征值 1 的左特征向量），且 $\sum_i\pi_i=1$。π **的三重身份**：特征向量 / 长期时间比例 / $1/\mathbb{E}[$返回时间$]$。
4. **平稳分布唯一性的条件**：**不可约** 保证存在且唯一（定理 26.3），且时间比例从任意初始分布都收敛到它。**非周期**是"$\Pr[X_n=i]$ 本身收敛"（定理 26.4）所额外需要的。可约链可以有**无穷多个**平稳分布（例：$P=\begin{pmatrix}1&0\\0&1\end{pmatrix}$ 时任意分布都平稳）。
5. **首步分析 = 全期望公式 + 马尔可夫性质**：吸收概率 $h(i)=\sum_j P(i,j)h(j)$（非吸收态），边界 $h(A)=1$、$h(B)=0$；期望时间 $t(i)=1+\sum_j P(i,j)t(j)$，边界 $t($吸收$)=0$。**永远别忘了边界条件**——它们承载了全部的非线性信息。
6. **赌徒破产的两个闭式公式**（$0<n<M$，$\rho=q/p$）：
7. 达到 M 的概率：$\alpha(n)=\dfrac{1-\rho^n}{1-\rho^M}$（$p\ne q$），$\alpha(n)=\dfrac{n}{M}$（$p=q$）。
8. 期望步数：$\beta(n)=\dfrac{n}{1-2p}-\dfrac{M}{1-2p}\cdot\dfrac{1-\rho^n}{1-\rho^M}$（$p\ne q$），$\beta(n)=n(M-n)$（$p=q$）。
9. **全期望公式（塔性质）**：$\mathbb{E}[X]=\sum_y\mathbb{E}[X\mid Y=y]\Pr[Y=y]=\mathbb{E}\big[\mathbb{E}[X\mid Y]\big]$，条件是 $\mathbb{E}[|X|]<\infty$（保证可换序）。**它是"分而治之"的引擎**：先固定 Y 算条件期望（通常简单），再对 Y 加权平均。首步分析就是取 $Y=X_1$ 的特例。
10. **条件期望的四条性质**：线性性、取出已知量 $\mathbb{E}[h(X)Y\mid X]=h(X)\mathbb{E}[Y\mid X]$、平滑性 $\mathbb{E}[\mathbb{E}[Y\mid X]]=\mathbb{E}[Y]$、独立性 $\mathbb{E}[Y\mid X]=\mathbb{E}[Y]$。**注意 $\mathbb{E}[X\mid Y]$ 是随机变量，不是数。**
11. **对称性论证**：i.i.d. 的 X,Y,Z 满足 $\mathbb{E}[Y\mid X+Y+Z]=\frac{1}{3}(X+Y+Z)$——只需一步"三者条件期望相等 + 线性性"，**不需要知道具体分布**。

常见误区与注意事项

1. **把状态选错，导致马尔可夫性质失效。** 例如"数一堆硬币里正面个数"的同时想知道"是否连续两次正面"——那就必须把"上次结果"放进状态。又如国际象棋：**"棋子的位置"不是马尔可夫状态**（还要知道"这个兵/车是否动过"用于易位），必须用**完整局面**。**判据**：如果两个不同的历史在同一个"状态"下会导致不同的未来分布，那这个"状态"就不是马尔可夫状态。
2. **混淆"行随机"与"列随机"。** P 的**每一行**和为 1（从 i 出发必须去某处）。列和一般不是 1（两状态链的列和是 1.1，完全正常）。相应地，初始分布 π_0 是**行向量**、$\pi_n=\pi_0P^n$（左乘），而平衡方程是 $\pi=\pi P$（也是左乘）。把 π 写成列向量去算 $\pi=P\pi$ 会得到"P 的右特征向量"，那是**另一个对象**（对应列随机的矩阵）。
3. **以为"不可约 + 有唯一平稳分布"就足以保证 $\Pr[X_n=i]$ 收敛。** $a=1$ 的两状态链 $P=\begin{pmatrix}0&1\\1&0\end{pmatrix}$ 不可约、有唯一平稳分布 $(\frac{1}{2},\frac{1}{2})$，但 $\Pr[X_n=0]$ 是 $1,0,1,0,\dots$ **振荡不收敛**（脚本验算 $n=0..5$）。必须加上**非周期**。区分清楚两条定理：**时间比例收敛只要不可约**（定理 26.3）；**分布本身收敛还要非周期**（定理 26.4）。
4. **平静稳分布当成"唯一"的。** 可约链可以有**无穷多个**平稳分布。反例：$P=\begin{pmatrix}1&0\\0&1\end{pmatrix}$（**任意**分布都平稳）；$P=\begin{pmatrix}0.5&0.5&0\\0.5&0.5&0\\0&0&1\end{pmatrix}$（$(\frac{1}{2},\frac{1}{2},0)$、$(0,0,1)$ 及其任意凸组合都平稳，脚本验算全部通过）。**只有在不可约时，平稳分布才唯一。**
5. **写首步方程时漏掉边界条件或漏掉那个 $+1$。** 漏边界：赌徒破产会退化成"$\alpha(n)=n/M$"这种只在公平硬币下成立的错误答案（$p=0.4$、$M=100$、$n=10$ 时真值 4.1×10^{-4}，线性猜测 0.1，错 244 倍）。漏 $+1$：期望**时间**方程必须有 $+1$（已经走了一步），而期望**概率**方程**不能**有 $+1$。**记忆口诀：时间 +1，概率不加。**
6. **在吸收链上套用"平稳分布"。** 吸收链是**可约**的（吸收态出不去），它的长期行为不是"收敛到平稳分布"，而是"以某个概率落到某个吸收态"。此时只能用首步分析。**从一个吸收链的转移矩阵强行解 $\pi P=\pi$ 会得到不唯一甚至误导的结果**（例如全都落在吸收态上）。
7. **把条件期望当成常数（或把 $\mathbb{E}[Y\mid X]$ 写成 $\mathbb{E}[Y]$）。** $\mathbb{E}[Y\mid X]$ 是**随机变量**。只有独立时（性质 d）才能换成常数 $\mathbb{E}[Y]$。反例：$X\sim U[0,1]$、给定 $X=x$ 时 $Y\sim U[0,x]$，则 $\mathbb{E}[Y\mid X]=X/2$（随 X 变化），而 $\mathbb{E}[Y]=1/4$。
8. **在使用"取出已知量"时把 Y 的因子也提出来。** 性质 (b) 只允许把 X **的函数** $h(X)$ 提出来：$\mathbb{E}[h(X)Y\mid X]=h(X)\mathbb{E}[Y\mid X]$。**不能**把只含 Y 的式子提出去，也不能在非独立时把 $\mathbb{E}[Y]$ 提出来。
9. **忘记全期望公式要求有限期望。** $\mathbb{E}[X]=\sum_y\mathbb{E}[X\mid Y=y]\Pr[Y=y]$ 需要 $\mathbb{E}[|X|]<\infty$ 才能交换求和次序。对重尾分布（如 X 为 Cauchy 型，$\mathbb{E}|X|=\infty$）这条公式会失效（出现 $\infty-\infty$）。
10. **把"时间比例的收敛"和"分布收敛"混为一句"链会收敛到平稳分布"。** 要分三层说：(i) **不可约** $\Rightarrow$ 唯一平稳分布 + 时间比例收敛；(ii) **不可约 + 非周期** $\Rightarrow$ 分布 $\Pr[X_n=i]$ 收敛；(iii) **可约** $\Rightarrow$ 以上都不保证（时间比例依赖初始分布；平稳分布可能不唯一）。

思考题（带答案）

Q1.（纯计算：平稳分布） 考虑三状态链（状态 $\{1,2,3\}$）

$$P=\begin{pmatrix}0.5 & 0.3 & 0.2\\ 0.2 & 0.6 & 0.2\\ 0.3 & 0.3 & 0.4\end{pmatrix}.$$

(a) 验证它是行随机矩阵。(b) 计算 P^2。(c) 解平衡方程求唯一平稳分布 π。(d) 从状态 1 出发，长期来看处于状态 2 的时间比例是多少？(e) 从状态 2 出发，平均多少步后第一次回到状态 2？(f) 该链是否非周期？

> **答案**
>
> (a) 行和：第 1 行 $0.5+0.3+0.2=1$ ✓；第 2 行 $0.2+0.6+0.2=1$ ✓；第 3 行 $0.3+0.3+0.4=1$ ✓。所有元素 ≥ 0 ✓。是行随机矩阵。（列和分别是 $1.0, 1.2, 0.8$，**不需要**为 1。）
>
> (b)
>
> $$P^2=\begin{pmatrix}0.3700 & 0.3900 & 0.2400\\ 0.2800 & 0.4800 & 0.2400\\ 0.3300 & 0.3900 & 0.2800\end{pmatrix}$$
>
> 逐项核对第一行：$P^2(1,1)=0.5\cdot 0.5+0.3\cdot 0.2+0.2\cdot 0.3=0.25+0.06+0.06=0.37$ ✓；
> $P^2(1,2)=0.5\cdot 0.3+0.3\cdot 0.6+0.2\cdot 0.3=0.15+0.18+0.06=0.39$ ✓；
> $P^2(1,3)=0.5\cdot 0.2+0.3\cdot 0.2+0.2\cdot 0.4=0.1+0.06+0.08=0.24$ ✓。脚本直接矩阵相乘给出完全相同的三个矩阵行 ✓。
>
> (c) 平衡方程 $\pi P=\pi$ 写成分量形式（三个方程中只有两个独立）：
>
> $$\pi_1=0.5\pi_1+0.2\pi_2+0.3\pi_3,\qquad \pi_2=0.3\pi_1+0.6\pi_2+0.3\pi_3,$$
>
> $$\pi_1+\pi_2+\pi_3=1.$$
>
> 由第二式：$\pi_2=0.3\pi_1+0.6\pi_2+0.3(1-\pi_1-\pi_2)=0.3\pi_1+0.6\pi_2+0.3-0.3\pi_1-0.3\pi_2=0.3\pi_2+0.3$，故 $0.7\pi_2=0.3$，即
>
> $$\pi_2=\frac{3}{7}=0.428571.$$
>
> 代入第一式（用 $\pi_3=1-\pi_1-\pi_2$）：$0.5\pi_1=0.2\pi_2+0.3\pi_3=0.2\pi_2+0.3-0.3\pi_1-0.3\pi_2=0.3-0.3\pi_1-0.1\pi_2$，故
> $0.8\pi_1=0.3-0.1\cdot\frac{3}{7}=\frac{21}{70}-\frac{3}{70}=\frac{18}{70}$，即
>
> $$\pi_1=\frac{18}{70}\cdot\frac{10}{8}=\frac{18}{56}=\frac{9}{28}=0.321429.$$
>
> 最后 $\pi_3=1-\frac{9}{28}-\frac{3}{7}=1-\frac{9}{28}-\frac{12}{28}=\frac{7}{28}=\frac{1}{4}=0.25$。**脚本验算**：$\pi P=(0.32142857, 0.42857143, 0.25000000)=\pi$ ✓；$\sum\pi_i=1$ ✓；用 P^{200} 幂迭代得 $0.32142857, 0.42857143, 0.25000000$ ✓；10^6 步模拟的时间比例 $(0.32124, 0.42863, 0.25014)$ ✓。**答案：$\pi=\left(\frac{9}{28},\frac{3}{7},\frac{1}{4}\right)$。**
>
> (d) 由定理 26.3，**时间比例不依赖初始分布**（这正是"不可约 ⇒ 平稳分布唯一"的含义），所以答案为 $\pi_2=\frac{3}{7}\approx 0.428571$。（脚本模拟从各状态出发的时间比例都收敛到同一组值 ✓。）
>
> (e) 由 $\pi(i)=1/\mathbb{E}[T(i)]$（定理 26.3 第 1 步），
>
> $$\mathbb{E}[\text{返回状态 }2]=\frac{1}{\pi_2}=\frac{7}{3}=2.333333.$$
>
> 脚本模拟从状态 2 出发的返回时间平均为 2.3316 ✓（另两个：$1/\pi_1=28/9=3.111111$，模拟 3.1084 ✓；$1/\pi_3=4$，模拟 3.9894 ✓）。
>
> (f) **非周期**。理由：$P^2(1,1)=0.37>0$（两步可以回到自己）且 $P^3(1,1)>0$（例如 $1\to 2\to 3\to 1$，概率 $0.3\cdot 0.2\cdot 0.3=0.018>0$），所以 $\{n>0: P^n(1,1)>0\}\supseteq\{2,3\}$，其 gcd 必为 1。由定理 26.4，$d(i)$ 对所有状态相同，故 $d=1$，链非周期。于是 $\Pr[X_n=i]\to\pi(i)$ ✓（脚本：P^{200} 的第 0 行已完全收敛到 π）。

Q2.（首步分析：完整赌徒破产） 一枚硬币正面概率 $p=0.4$，反面概率 $q=0.6$。赌徒起始有 $2，每局赢$1（概率p）或输$1（概率q），游戏在资金达到$0或$5时停止。$(a)$写出首步方程组。$(b)$解出$n$最终赢到$5的概率\alpha(n)（给出全部五个非吸收态的值）。(c)解出期望步数\beta(n)。(d)验证\alpha满足原方程组。(e)若硬币公平（p=0.5$），答案变成什么？

▸ **答案**

(a) 状态 $n \in \{0,1,2,3,4,5\}$，0 与 5 吸收。

$$\alpha(n) = q\,\alpha(n-1) + p\,\alpha(n+1)\ (0<n<5), \qquad \alpha(0)=0,\ \alpha(5)=1.$$

$$\beta(n) = 1 + q\,\beta(n-1) + p\,\beta(n+1)\ (0<n<5), \qquad \beta(0)=\beta(5)=0.$$

(b) 令 $\rho = q/p = 0.6/0.4 = 1.5$，由定理 26.5 的公式

$$\alpha(n) = \frac{1-\rho^{n}}{1-\rho^{5}}.$$

逐个计算（脚本验算，且与直接 Gauss 消元解方程组逐位一致）：

$$\alpha(0)=0,\quad \alpha(1)=0.075829,\quad \alpha(2)=0.189573,\quad \alpha(3)=0.360190,\quad \alpha(4)=0.616114,\quad \alpha(5)=1.$$

中间量：$\rho^{2}=2.25$、$\rho^{3}=3.375$、$\rho^{4}=5.0625$、$\rho^{5}=7.59375$。故

$$\alpha(2) = \frac{1-2.25}{1-7.59375} = \frac{-1.25}{-6.59375} = 0.189573\ \checkmark$$

结论：起始 $$2只有约19\%的机会赢到$5，尽管起始资金处于中点位置——**这就是2$ 个百分点劣势的威力**。

(c) 由定理 26.6 的公式（$\rho=1.5$，$1-2p=0.2$）：

$$\beta(n) = \frac{n}{0.2} - \frac{5}{0.2}\cdot\frac{1-\rho^{n}}{1-\rho^{5}} = 5n - 25\cdot\frac{1-\rho^{n}}{1-\rho^{5}}.$$

注意 $\frac{1-\rho^{n}}{1-\rho^{5}} = \alpha(n)$，所以 $\beta(n) = 5n - 25\,\alpha(n)$。逐个：

$$\beta(0)=0,\quad \beta(1)=5-25(0.075829)=3.104265,\quad \beta(2)=10-25(0.189573)=5.260664,$$

$$\beta(3)=15-25(0.360190)=5.995261,\quad \beta(4)=20-25(0.616114)=4.597156,\quad \beta(5)=0.$$

脚本验算：直接解 6 元线性方程组得到完全相同的六个值 ✓。 **注意 β 不是单调的**：$\beta(2)=5.26 < \beta(3)=6.00$。原因是期望步数由"多快撞上**任一**吸收壁"决定：从 $$3出发时，虽然离成功更近，但同时也有很大机会往下漂到$2,$1甚至$0——而这些〃向下〃的路径本身也很快结束，导致〃从3 出发既可能快速破产也可能缓慢成功"，综合起来期望反而更大。

(d) 验证（脚本逐条验算通过）：

$$q\alpha(1)+p\alpha(3) = 0.6(0.075829)+0.4(0.360190) = 0.045497+0.144076 = 0.189573 = \alpha(2)\ \checkmark$$

$$q\alpha(0)+p\alpha(2) = 0+0.4(0.189573) = 0.075829 = \alpha(1)\ \checkmark$$

$$q\alpha(2)+p\alpha(4) = 0.6(0.189573)+0.4(0.616114) = 0.113744+0.246446 = 0.360190 = \alpha(3)\ \checkmark$$

$$q\alpha(3)+p\alpha(5) = 0.6(0.360190)+0.4(1) = 0.216114+0.4 = 0.616114 = \alpha(4)\ \checkmark$$

脚本对 $n=1,2,3,4$ 全部核对通过；蒙特卡洛 3×10^{5} 次从 $$2出发实测胜率与理论0.1896$ 一致。

(e) $p=q=0.5$ 时 $\rho=1$，公式退化为

$$\alpha(n) = \frac{n}{M} \implies \alpha = (0, 0.2, 0.4, 0.6, 0.8, 1),$$

$$\beta(n) = n(M-n) \implies \beta = (0, 4, 6, 6, 4, 0).$$

脚本验算：直接解方程组得到同样的两组数 ✓；蒙特卡洛 3×10^{5} 次从 $$2出发实测胜率0.3998（理论0.4）✓、平均步数5.9977（理论6）✓。**对比可见**：公平硬币下起始$2有40\%机会赢到$5；而p=0.4时只有18.96\%——**10个百分点的胜率下降（从50\%到40\%$）使成功率降了一半多**。

Q3.（概念 + 反例） 判断真假并说明理由：(a) "不可约且非周期的有限链，从任意初始分布出发，$\Pr[X_n=i]$ 都收敛到平稳分布 $\pi(i)$。" (b) "有限链的平稳分布总是存在。" (c) "若 $\pi P=\pi$，则 $\pi_n=\pi$ 对一切 $n\ge 0$。" (d) "首步方程 $\alpha(i)=\sum_j P(i,j)\alpha(j)$ 与 $\beta(i)=1+\sum_j P(i,j)\beta(j)$ 的区别只在于后者多了个 1，所以两者可以同时用同一套边界条件求解。" (e) "条件期望 $\mathbb{E}[X\mid Y]$ 是一个数。"

▸ **答案**

(a) **真。** 这正是定理 26.4 的内容（不可约保证 π 存在且唯一，非周期保证分布本身收敛）。**脚本证据**：三状态天气链 P^{200} 的任一行都已等于 $\pi=(\frac{9}{28},\frac{3}{7},\frac{1}{4})$，与初始分布无关。**注意**：若去掉"非周期"，命题变假——$P=\begin{pmatrix}0&1\\1&0\end{pmatrix}$ 不可约、有唯一 $\pi=(\frac{1}{2},\frac{1}{2})$，但 $\pi_0=(1,0)$ 时 $\Pr[X_n=0]=1,0,1,0,\ldots$ 不收敛（脚本验算）✓。

(b) **真。** 理由：行随机矩阵必有特征值 1（因为 $P\mathbf{1}=\mathbf{1}$，故 $\mathbf{1}$ 是右特征向量），因此 P^T 也有特征值 1，取对应的特征向量 $\nu\neq 0$ 使 $\nu P=\nu$。把 ν 的坐标取绝对值、归一化（ν 可能含负分量，但可以证明存在**非负**的特征向量：用 $P^n(i,j)\geq 0$ 与 Markov–Kakutani 不动点定理，或更初等地用**幂迭代的极限点**——考虑 $\frac{1}{n}\sum_{m=0}^{n-1}\pi_0 P^m$ 的收敛子列），即得到一个概率向量 π 满足 $\pi P=\pi$。**脚本示例**：恒等链 $P=I$ 时**任意**分布都是平稳分布（无穷多个）；可约链 $P=\begin{pmatrix}0.5&0.5&0\\0.5&0.5&0\\0&0&1\end{pmatrix}$ 有 $(\frac{1}{2},\frac{1}{2},0)$ 与 $(0,0,1)$ 两个，以及它们的任意凸组合——脚本验证三者都满足 $\pi P=\pi$ ✓。**所以"存在"总是成立，"唯一"才需要不可约。**

(c) **真。** 这就是定理 26.2（⇐ 方向）：若 $\pi P=\pi$，则 $\pi_1=\pi P=\pi$，再由 $\pi_{n+1}=\pi_n P=\pi P=\pi$ 归纳得一切 n。**注意**：π_n 的记号是"X_n 的分布"，所以 $\pi_n=\pi$ 的意思是"分布不随时间变化"，而不是"链不动"。例如天气链的 $\pi=(\frac{9}{28},\frac{3}{7},\frac{1}{4})$ 是平稳分布，但链**每步都在随机跳**（P 的对角元不是 1）。

(d) **假（两部分都需纠正）。** 两点： – **第一，边界条件不同。**α 是**概率**：$\alpha(i)=1$（$i\in A$）、$\alpha(i)=0$（$i\in B$）。β 是**期望步数**：$\beta(i)=0$（i 是**任何**吸收态，无论成功还是失败，因为"已经到了，还需 0 步"）。**在赌徒破产里，α 在两端取 0 和 1，而 β 在两端都取 0**——完全不同。 – **第二，那个 $+1$ 不是可有可无的形式差别。**它对应"无论如何都先走了一步"这一物理事实（期望的线性性）。若在概率方程里加 $+1$，就会算出大于 1 的"概率"（在赌徒破产里，$\alpha(2)$ 会变成 $1+0.6\alpha(1)+0.4\alpha(3)$，数值上破坏 $\alpha\leq 1$）。 **正确说法**：两者的**递推结构**相同（都是 $\sum_j P(i,j)(\cdot)$），但**边界条件**与**是否有常数项**都不同，因此必须分别列、分别解。**记忆口诀：概率 = 加权平均（无常数），时间 = 1 + 加权平均。**

(e) **假。** $\mathbb{E}[X\mid Y]$ 是**随机变量**（Y 的函数）：对每个 $Y=y$ 给出一个数 $\mathbb{E}[X\mid Y=y]$，所以它是随观测变化的量。反例：X = 抛两枚硬币的正面数，Y = 第一枚的结果。则 $\mathbb{E}[X\mid Y=0]=0.5$、$\mathbb{E}[X\mid Y=1]=1.5$——**两个不同的值**，所以 $\mathbb{E}[X\mid Y]$ 是一个两值随机变量，而不是一个数。只有 $\mathbb{E}[\mathbb{E}[X\mid Y]]=\mathbb{E}[X]$（塔性质）才是一个数。类似地：$\mathbb{E}[X\mid Y]$ 在 Y 与 X 独立时**才**退化为常数 $\mathbb{E}[X]$（性质 d）。

Q4.（条件期望：对称性与分而治之） (a) 设 $X_1,\ldots,X_n$ i.i.d.，$S=\sum_{i=1}^n X_i$。用对称性求 $\mathbb{E}[X_1\mid S]$。(b) 设 $N\sim\mathrm{Poisson}(\lambda)$ 与序列 $Y_1,Y_2,\ldots$（i.i.d.，均值 μ）独立，$X=\sum_{i=1}^N Y_i$。用全期望公式求 $\mathbb{E}[X]$。(c) n 种优惠券，每次等概率抽到一种，用条件期望求集齐全部的期望次数，并给出 $n=6$ 的数值。

▸ 答案

(a) **对称性论证**。由 $X_1, \dots, X_n$ **可交换 (exchangeable)**（i.i.d. 蕴含任意置换后联合分布不变），对每个 k，

$$\mathbb{E}[X_k \mid S] = \mathbb{E}[X_1 \mid S]$$

（因为条件在 S 上时，置换下标不改变任何东西——S 在置换下不变）。记公共值 $V := \mathbb{E}[X_1 \mid S]$。则

$$nV = \sum_{k=1}^{n} \mathbb{E}[X_k \mid S] = \mathbb{E}\left[\sum_{k=1}^{n} X_k \,\middle|\, S\right] = \mathbb{E}[S \mid S] = S,$$

其中第二步用条件期望的**线性性**（定理 26.8(a)），第三步用 $\sum_k X_k = S$，最后一步用"已知 S 时 S 是常数"。故

$$\mathbb{E}[X_1 \mid S] = \frac{S}{n} = \frac{X_1 + \cdots + X_n}{n}.$$

一致性检验：$\mathbb{E}\left[\frac{S}{n}\right] = \frac{1}{n} \cdot n\mathbb{E}[X_1] = \mathbb{E}[X_1]$ ✓（塔性质）。**这个结果不需要知道 X_i 的分布**——只要 i.i.d. 就够。取 $n = 3$ 就是官方例子 $\mathbb{E}[Y \mid X+Y+Z] = \frac{1}{3}(X+Y+Z)$。

(b) 用全期望公式按 N 分组（**注意 N 与 Y_i 独立**，且 $N = 0$ 时 $X = 0$）：

$$\mathbb{E}[X] = \sum_{n \geq 0} \mathbb{E}[X \mid N = n] \Pr[N = n] = \sum_{n \geq 0} \mathbb{E}\left[\sum_{i=1}^{n} Y_i\right] \Pr[N = n].$$

内层期望：因为 n 是**固定的常数**（已经条件在 $N = n$ 上了），由期望线性性

$$\mathbb{E}\left[\sum_{i=1}^{n} Y_i\right] = \sum_{i=1}^{n} \mathbb{E}[Y_i] = n\mu.$$

（**注意这里不需要 Y_i 之间的独立性**——有限个随机变量之和的期望总是等于期望之和。） 故

$$\mathbb{E}[X] = \sum_{n \geq 0} n\mu \Pr[N = n] = \mu \sum_{n \geq 0} n \Pr[N = n] = \mu\, \mathbb{E}[N] = \lambda\mu.$$

脚本验算：$N \sim \text{Poisson}(3)$、$Y \sim \text{Exp}(1)$ 时 $\mathbb{E}[X] = 3$，蒙特卡洛 4×10^5 次实测 2.9987 ✓；$N \sim \text{Poisson}(2)$ 时 $\mathbb{E}[X] = 2$，实测 2.0034 ✓。**这个公式（Wald 等式）的漂亮之处**：完全不需要 N 的具体分布，只要它的均值。

(c) 设 T_k = 从"已有 k 种"到"有 $k+1$ 种"所需的抽取次数（$k = 0, 1, \dots, n-1$）。 – **条件世界内的分布**：已知已有 k 种时，每次抽取落在"新种类"的概率是 $p_k = \frac{n-k}{n}$（**且与历史无关**，因为每次抽取独立均匀）。所以 $T_k \sim G(p_k)$（几何分布，讲次 19），这里的关键观察是：**每次抽取是否命中新种类是独立的伯努利试验，且命中概率在所有"当前有 k 种"的状态下都相同**——这正是马尔可夫性质的应用。 – **条件期望**：由讲次 19 的几何分布期望 $\mathbb{E}[G(p)] = 1/p$，

$$\mathbb{E}[T_k] = \frac{1}{p_k} = \frac{n}{n-k}.$$

（也可用首步分析一行得到：$t = 1+(1-p_k)t \Rightarrow t = 1/p_k$。）

- **合并（线性性）**：

$$\mathbb{E}[T] = \mathbb{E}\left[\sum_{k=0}^{n-1} T_k\right] = \sum_{k=0}^{n-1} \frac{n}{n-k} = n \sum_{j=1}^{n} \frac{1}{j} = n\, H_n.$$

注意 $T_0,T_1,\dots,T_{n-1}$ 并不独立（例如"在 k 阶段抽到了哪些种类"会影响后续阶段的构成），但**期望线性性不需要独立性**——这是关键一步，也是"用条件

- **数值（$n = 6$）**：$H_6 = 1 + \frac{1}{2} + \frac{1}{3} + \frac{1}{4} + \frac{1}{5} + \frac{1}{6} = 2.45$，故

$$\mathbb{E}[T] = 6 \times 2.45 = 14.7.$$

脚本蒙特卡洛 2×10^5 次实测 14.7222 ✓。其余：$n=3 \Rightarrow 3H_3 = 5.5$；$n=10 \Rightarrow 29.289683$；$n=20 \Rightarrow 71.9547$

- **渐近**：$H_n \approx \ln n + \gamma$（$\gamma \approx 0.5772$ 为欧拉常数），故 $\mathbb{E}[T] \approx n \ln n$——**"集齐 n 种需要约 $n \ln n$ 次"**，这个 $\Theta(n \log n)$ 量级在算法分析（覆盖问题、随机撒点覆盖、图的随机游走覆盖时间）中反复出现。

核心定理与证明技巧速查表

本表按**类别**汇总全课程的关键定义、定理、公式与证明策略。建议在考前用它做"回忆式自测"：遮住右列，先自己复述定理的**条件**（最容易失分的地方）与**证明的关键一步**，再对照。

一、证明技巧（Lecture 0–3）

1.1 五类证明策略的适用场景

策略	目标形式	做法	什么时候用
直接证明 (Direct Proof)	$P \Rightarrow Q$	假设 P，逐步推导出 Q	从假设出发能自然地"算出"结论时
逆否证明 (Contraposition)	$P \Rightarrow Q$	假设 $\neg Q$，推导出 $\neg P$	假设 P 太弱、$\neg Q$ 信息更丰富时（如"若 n^2 是偶数则 n 是偶数"）
反证法 (Contradiction)	P（任意命题）	假设 $\neg P$，推出 $R \wedge \neg R$	结论是"不存在""不可能""无理数"等**否定性**命题时
分情形 (Proof by Cases)	P	把 P 的假设域划分为**穷尽且互斥**的若干情形，逐一证明	假设信息不足以直接推导时（如带绝对值、按奇偶/模 k 分类）
构造性证明 (Constructive)	$\exists x\, P(x)$	显式给出一个 x 并验证 $P(x)$	存在性命题，且能找到显式对象时
非构造性存在性	$\exists x\, P(x)$	证明"若不存在则矛盾"，但不给出 x	找不到显式对象，或不需要知道具体对象时（如 $\sqrt{2}^{\sqrt{2}}$ 的有理性）

1.2 逻辑等价式（真值表可验证）

名称	等价式
逆否等价	$P \Rightarrow Q \;\equiv\; \neg Q \Rightarrow \neg P$
蕴涵的析取形式	$P \Rightarrow Q \;\equiv\; \neg P \vee Q$
双条件分解	$P \Leftrightarrow Q \;\equiv\; (P \Rightarrow Q) \wedge (Q \Rightarrow P)$
De Morgan（合取）	$\neg(P \wedge Q) \;\equiv\; \neg P \vee \neg Q$
De Morgan（析取）	$\neg(P \vee Q) \;\equiv\; \neg P \wedge \neg Q$
分配律	$P \wedge (Q \vee R) \equiv (P \wedge Q) \vee (P \wedge R)$；$P \vee (Q \wedge R) \equiv (P \vee Q) \wedge (P \vee R)$
排中律 / 矛盾律	$P \vee \neg P \equiv \mathbf{T}$；$P \wedge \neg P \equiv \mathbf{F}$

⚠ **不等价**：$P \Rightarrow Q$ 与**逆命题** $Q \Rightarrow P$ 不等价；与**否命题** $\neg P \Rightarrow \neg Q$ 不等价。（后两者彼此等价，但与原命题无关。）

1.3 量词及其否定

$$\neg \forall x\, P(x) \equiv \exists x\, \neg P(x), \qquad \neg \exists x\, P(x) \equiv \forall x\, \neg P(x)$$

量词顺序不可交换：$\forall x \exists y\, P(x,y) \not\equiv \exists y \forall x\, P(x,y)$。强的是后者。

⚠ **带蕴涵的量词否定**：$\neg \forall x\, (P(x) \Rightarrow Q(x)) \equiv \exists x\, (P(x) \wedge \neg Q(x))$（"所有质数都是奇数"的否定是"存在一个偶质数"，不是"所有质数都不是奇数"）。

1.4 归纳法

数学归纳法（简单归纳）：若 1. **基础情形**：$P(0)$（或 $P(1)$）成立； 2. **归纳步骤**：$\forall k \geq 0,\ P(k) \Rightarrow P(k+1)$；

则 $\forall n \geq 0,\ P(n)$ 成立。

强归纳法：若 1. $P(0)$ 成立； 2. $\forall k \geq 0,\ \big(P(0) \wedge P(1) \wedge \cdots \wedge P(k)\big) \Rightarrow P(k+1)$；

则 $\forall n \geq 0,\ P(n)$ 成立。

合法性的根源：自然数的**良序原理**（Well-Ordering Principle）—— 任何非空自然数子集有最小元。若命题有反例，取**最小**反例 n，则 $P(n-1)$ 成立，与归纳步骤给出的 $P(n)$ 成立矛盾。

归纳法三件套（写作模板）：

```
定理：∀n ≥ n₀, P(n)。
证明（对 n 归纳）：
  基础情形（n = n₀）：[验证 P(n₀)，写出具体计算]
  归纳步骤：假设 P(k) 成立（归纳假设）。要证 P(k+1)。
      P(k+1) 的左端
    = [把 P(k+1) 拆成 P(k) 的部分 + 新增项]   ← 关键第一步
    = [代入归纳假设]
    = [代数化简到 P(k+1) 的形式]              ← 目标明确
  故 P(k) ⇒ P(k+1)。
  由归纳法，∀n ≥ n₀, P(n)。 ∎
```

何时必须用强归纳：当 $P(k+1)$ 的证明需要用到 $P(j)$（j 远小于 k）时。典型场景： – **整数分解为质数之积**（因子 $a, b < k+1$） – $n \geq 12$ **可写成** $4x + 5y$（需要 $P(n-4)$） – **图论中删点后图不连通**（需要强归纳或在每个连通分量上归纳）

经典陷阱：归纳法伪证。"所有马颜色相同"的伪证中，归纳步骤从 k 到 $k+1$ 时把 $k+1$ 匹马分成两个大小为 k 的子集，声称它们共享一匹马从而颜色相同——但 $k = 1$ 时两个子集各只有 1 匹马，**交集为空**，无法传递。教训：**归纳步骤必须对所有** $k \geq$ **基础情形都成立**。

二、数论与密码（Lecture 4–6）

2.1 同余与模运算

概念	定义 / 性质
同余	$a \equiv b \pmod{m} \iff m \mid (a-b)$
等价关系	同余满足自反、对称、传递；$\mathbb{Z}$ 被划分为 m 个等价类
加减乘保同余	$a \equiv c$ 且 $b \equiv d \pmod{m} \Rightarrow a+b \equiv c+d$，$ab \equiv cd \pmod{m}$
除法（危险）	$ab \equiv ac \pmod{m}$ 不能直接推出 $b \equiv c$
消去律	若 $\gcd(c,m)=1$ 且 $ca \equiv cb \pmod{m}$，则 $a \equiv b \pmod{m}$
乘法逆元	$x^{-1} \bmod m$ 满足 $x \cdot x^{-1} \equiv 1 \pmod{m}$

逆元存在定理：x 在模 m 下有乘法逆元 $\iff \gcd(x,m)=1$。

证明策略（逆元存在性）：考察 $x\cdot 0, x\cdot 1, \dots, x\cdot(m-1)$ 这 m 个数。若 $\gcd(x,m)=1$，它们在模 m 下**两两不同**（否则 $x(i-j)\equiv 0$ 而 $\gcd(x,m)=1$ 迫使 $m \mid (i-j)$，但 $|i-j|<m$，只能 $i=j$）。m 个不同的值填满 m 个余数类，其中必有一个是 1，故逆元存在。

快速幂（反复平方）：把指数写成二进制，$x^n = \prod_{b_i=1} x^{2^i}$。复杂度 $O(\log n)$ 次模乘（朴素做法需 $O(n)$ 次）。

2.2 欧几里得算法

$$\gcd(x,y) = \gcd(y,\ x \bmod y), \qquad \gcd(x,0)=x.$$

证明策略：证明两个集合 $\{d : d \mid x,\ d \mid y\}$ 与 $\{d : d \mid y,\ d \mid x \bmod y\}$ **完全相等**（互相包含），因此最大元相同。

复杂度：每**两次**递归调用第一个参数至少减半（因为 $x \bmod y < y$ 且 $x \bmod y \le x-y$），故 $O(\log x)$ 次调用。

扩展欧几里得（Bézout）：求出 $d=\gcd(x,y)$ 及整数 a,b 使

$$ax + by = d.$$

求逆元：若 $\gcd(x,m)=1$，由 $ax+bm=1$ 得 $x^{-1} \equiv a \pmod{m}$。

2.3 费马小定理与中国剩余定理

费马小定理（FLT）：对**质数** p 与任意 a 满足 $\gcd(a,p)=1$（即 $a \not\equiv 0$）：

$$a^{p-1} \equiv 1 \pmod{p}.$$

证明策略：关键引理 —— $a\cdot 1, a\cdot 2, \dots, a\cdot(p-1) \pmod{p}$ 是 $\{1,2,\dots,p-1\}$ 的一个**排列**。于是两组数的乘积同余：

$$a^{p-1}(p-1)! \equiv (p-1)! \pmod{p} \implies a^{p-1} \equiv 1 \pmod{p}.$$

（引理成立的理由：若 $ai \equiv aj \pmod{p}$，由 p 是质数且 $a \not\equiv 0$ 可消去 a，得 $i \equiv j$；$p-1$ 个不同的非零余数正好填满全部非零余数类。）

⚠ **条件不可省**：FLT 对**合数模**不成立（$m=4, a=2$：$2^3 = 8 \equiv 0 \not\equiv 1$）；且要求 $a \not\equiv 0 \pmod{p}$。

FLT 的推论（求逆元）：$a^{-1} \equiv a^{p-2} \pmod{p}$。

中国剩余定理（CRT）：若 $m_1, \dots, m_k$ **两两互质**，$M = m_1 m_2 \cdots m_k$，则同余方程组

$$x \equiv a_1 \pmod{m_1},\ \dots,\ x \equiv a_k \pmod{m_k}$$

在模 M 下有**唯一解**。

构造性求解：令 $M_i = M/m_i$，$y_i \equiv M_i^{-1} \pmod{m_i}$，则

$$x \equiv \sum_{i=1}^{k} a_i M_i y_i \pmod{M}.$$

验证机制：模 m_j 时，和式中除第 j 项外都含因子 M_i（$i \neq j$）从而 $\equiv 0$，而第 j 项 $\equiv a_j M_j y_j \equiv a_j \pmod{m_j}$。

唯一性：若 x, x' 都是解，则每个 $m_i \mid (x-x')$；两两互质 $\Rightarrow M \mid (x-x')$。

2.4 RSA

密钥生成：1. 选两个大质数 $p \neq q$，令 $N=pq$；2. $\phi(N)=(p-1)(q-1)$；3. 选 e 满足 $\gcd(e,\phi(N))=1$；4. 计算 $d \equiv e^{-1} \pmod{\phi(N)}$。

公钥 (N,e)，**私钥** (N,d)（p,q 必须销毁）。

加解密：$E(x) = x^e \bmod N$；$D(y) = y^d \bmod N$。

正确性定理：$D(E(x)) = (x^e)^d \equiv x \pmod{N}$ 对所有 $x \in \{0,\dots,N-1\}$ 成立。

证明策略：由 $ed \equiv 1 \pmod{\phi(N)}$ 得 $ed = 1 + k(p-1)(q-1)$。分两种情形：
- $\gcd(x,N)=1$：由欧拉定理 $x^{\phi(N)} \equiv 1$，故 $x^{ed} = x \cdot (x^{\phi(N)})^k \equiv x$。
- $\gcd(x,N) \neq 1$：此时 x 是 p 或 q 的倍数（$N=pq$）。分别验证模 p 与模 q 同余于 x（用 FLT 处理非零的那个模），再由 CRT 得模 $N=pq$ 同余于 x。

安全性基础：破解需要分解 N；已知最好的分解算法是亚指数时间，无多项式时间算法。

教科书 RSA 的缺陷（必须加 padding）： – **确定性**：相同明文恒得相同密文，可被字典攻击。 – **可乘性**：$E(x_1)E(x_2) \equiv E(x_1x_2) \pmod N$，可被选择明文攻击伪造。 – **小指数攻击**、共模攻击等。

质数生成：由**素数定理** $\pi(n) \approx n/\ln n$，n 附近的质数密度约为 $1/\ln n$。随机取奇数 + 素性测试（Miller–Rabin）即可高效生成。

三、代数与编码（Lecture 7–8）

3.1 多项式

定理	内容
带余除法 / 因子定理	$(x-r) \mid P(x) \iff P(r)=0$
根的上界	次数为 d 的**非零**多项式最多有 d 个根
插值定理	给定 $d+1$ 个 x_i 两两不同的点，**存在唯一**次数 $\le d$ 的多项式经过它们
Schwartz–Zippel	两个不同的次数 $\le d$ 多项式在随机点 $r \in \mathbb{F}_p$ 上取值相等的概率 $\le d/p$

根定理的证明机制：对次数归纳。若 $P(r)=0$，由带余除法 $P(x)=(x-r)Q(x)+c$，代入 $x=r$ 得 $c=P(r)=0$，故 $P(x)=(x-r)Q(x)$，$\deg Q = d-1$。任何其他根 $r' \neq r$ 必满足 $Q(r')=0$，由归纳假设 Q 最多 $d-1$ 个根。

插值的存在性（Lagrange 构造）：

$$\Delta_i(x) = \prod_{j \neq i} \frac{x-x_j}{x_i-x_j}, \qquad \Delta_i(x_j)=\delta_{ij}, \qquad P(x)=\sum_{i=1}^{d+1} y_i \Delta_i(x).$$

唯一性（反证）：若 $P_1 \neq P_2$ 都经过这 $d+1$ 个点，则 P_1-P_2 是次数 $\le d$ 的非零多项式却有 $d+1$ 个根，违反根定理。

⚠ **有限域上的重要区别**：在 $\mathbb{Z}_p$ 上，**不同多项式可以定义同一个函数**（如 $x^p \equiv x$，由 FLT）。因此"多项式相等"（系数逐项相等）与"作为函数相等"不同。**但次数 $\le p-1$ 的多项式由函数值唯一确定**（否则差多项式次数 $\le p-1$ 却在 p 个点上全为 0，超过根的上界）。

3.2 秘密共享与纠错码

(n,k) 门限秘密共享（Shamir 方案）：选随机多项式 P，$\deg P = k-1$，$P(0)=s$（秘密）；第 i 人得 $(i, P(i))$，$i=1,\dots,n$。

- **正确性**：任意 k 个份额由插值定理唯一确定 P，取 $P(0)$ 即得 s。
- **安全性**：任意 $k-1$ 个份额**不泄露 s 的任何信息**。论证：对任意猜测 s'，都存在一个经过这 $k-1$ 个点且常数项为 s' 的次数 $\le k-1$ 多项式（k 个约束、k 个系数，可解）。故这 $k-1$ 个份额与 s 的取值**在信息论上独立**。

汉明距离与纠错能力：码的最小距离 d 满足

$$\text{可纠正} \left\lfloor \frac{d-1}{2} \right\rfloor \text{个错误}, \qquad \text{可检测 } d-1 \text{ 个错误}.$$

证明机制：若收到的串 y 与两个不同码字 c_1, c_2 的距离都 $\le t$，则 $d(c_1,c_2) \le 2t < d$，矛盾（三角不等式）。

Reed–Solomon 码：消息 $m_0,\dots,m_{k-1}$ 视为次数 $<k$ 的多项式 P 的系数，码字为 $(P(\alpha_1),\dots,P(\alpha_n))$（$\alpha_i$ 两两不同）。

最小距离：两个不同的次数 $<k$ 多项式最多在 $k-1$ 个点相等，故码字至少在 $n-k+1$ 个坐标不同，即 $d=n-k+1$。

Berlekamp–Welch 译码（$n \ge k+2e$，最多 e 个错误）：1. 引入**错误位置多项式** $E(x)=\prod_{i\in\text{error}}(x-\alpha_i)$，$\deg E \le e$（取首一）。 2. 令 $Q(x)=P(x)E(x)$，$\deg Q \le k-1+e$。 3. 对每个 i：$Q(\alpha_i)=y_iE(\alpha_i)$，这是关于 Q, E 的**系数**的线性方程（在正确的点上成立；在错误的点上不一定成立）。 4. 未知量个数 $\le (k+e)+(e+1)$，方程个数 $=n \ge k+2e+1$，解出 Q, E。 5. $P(x)=Q(x)/E(x)$（多项式除法）。

⚠ **条件**：$n<k+2e$ 时无法保证唯一译码。

四、图论与匹配（Lecture 9–11）

4.1 图论基本事实

概念 / 定理	内容
握手引理	$\sum_{v\in V}\deg(v)=2\lvert E\rvert$。推论：**奇度顶点个数为偶数**
完全图 K_n	$\lvert V\rvert=n$，$\lvert E\rvert=\binom{n}{2}$，$\deg(v)=n-1$
欧拉回路判定	连通图有欧拉回路 $\iff$ **每个顶点度为偶**
欧拉路径判定	连通图有欧拉路径 $\iff$ 恰有 0 **或** 2 个奇度顶点
欧拉公式（平面图）	连通平面图：$V-E+F=2$（F 含外部面）
平面图边数上界	简单平面图 $V \ge 3$：$E \le 3V-6$；若还二分：$E \le 2V-4$

概念 / 定理	内容
非平面判定	K_5：$10 > 3\cdot 5 - 6 = 9$ ✓；$K_{3,3}$：$9 > 2\cdot 6 - 4 = 8$ ✓

握手引理的证明（双重计数）：按顶点数"顶点—边"关联对，得 $\sum_v \deg v$；按边数同一些对，每边贡献 2，得 $2|E|$。同一集合两种数法，故相等。

欧拉回路充分性的构造：从任一点出发，沿未用边走到不能走为止（因每点剩余度为偶，必然回到起点，形成一个回路）。若仍有未用边，由图的**连通性**，存在回路外的边与已走回路共享顶点，从共享点出发走一个新的回路，再把两个回路在该点"拼接"成一个大回路。重复直到用尽所有边。

欧拉公式的证明（对边数归纳）：若图是树，$E = V - 1$，$F = 1$，得 $V - E + F = V - (V-1) + 1 = 2$ ✓。若图含环，删去环上一条边：E 减 1，F 减 1（两个相邻面合并），$V - (E-1) + (F-1) = V - E + F$ 不变。反复删边直到成树。

平面图边数上界的证明：设每个面的边界长度为 $\ell_i \geq 3$，则 $\sum_i \ell_i = 2E$（每条边被两个面共享），故 $3F \leq 2E$。代入 $V - E + F = 2$（即 $F = 2 - V + E$）：$3(2 - V + E) \leq 2E \Rightarrow E \leq 3V - 6$。二分图无三角形，每个面 ≥ 4 条边，同理得 $E \leq 2V - 4$。

⚠ **方向性**：$E \leq 3V - 6$ 是平面的**必要**条件，**不充分**（满足不等式仍可能非平面）。

4.2 树

树的核心等价刻画（V 个顶点的图）：

```
(i)   G 是树（连通且无环）
(ii)  G 连通且有 V−1 条边
(iii) G 无环且有 V−1 条边
(iv)  任意两顶点间恰好有一条简单路径
(v)   G 连通，但删去任一条边后不连通（极小连通）
(vi)  G 无环，但添加任一条边都产生环（极大无环）
```

证明链条（关键步骤）：– $(i) \Rightarrow (ii)$：对顶点数归纳。树有叶子（$\deg = 1$，证明：若所有度 ≥ 2 则 $\sum \deg \geq 2V$，由握手引理 $E \geq V$，但连通图 $E \geq V - 1$ 且无环图 $E \leq V - 1$，故 $E = V - 1$，此时若所有度 ≥ 2 则 $\sum \deg = 2V - 2$ 要求恰有两个度 1 顶点）。删去一个叶子得 $V - 1$ 个顶点的树，由归纳假设它有 $(V-1) - 1$ 条边，加回删掉的边得 $V - 1$ 条。– $(ii) \Rightarrow (iii)$：若连通且有 $V - 1$ 条边但含环，删去环上一边仍连通且有 $V - 2$ 条边，但连通图至少 $V - 1$ 条边，矛盾。– $(iii) \Rightarrow (i)$：若无环有 $V - 1$ 条边，设它有 c 个连通分量，每个分量是树，总边数 $= V - c = V - 1$，故 $c = 1$，连通。

4.3 稳定匹配（Gale—Shapley）

不稳定对（blocking pair）：(m, w) 未配对，但 m 更喜欢 w 且 w 更喜欢 m。 **稳定匹配**：不存在不稳定对的完美匹配。

Gale—Shapley 提出–拒绝算法：

```
初始化：所有男女均未匹配，每个男士的"下一个追求对象"指针指向其偏好表首位。
while 存在未匹配且未向所有女士提过议的男士 m:
    w ← m 尚未提过议的最偏好的女士
    m 向 w 提出
    if w 未匹配:
        w 接受 m
    else:
        m' ← w 当前的伴侣
        if w 更喜欢 m 而不是 m':
            w 接受 m，拒绝 m'（m' 变回未匹配）
        else:
            w 拒绝 m（m 保持未匹配）
```

三个正确性定理： 1. **终止性**：每轮至少一次拒绝；总提议次数 $\leq n^2$，有限。 2. **完美匹配**：结束时不可能有单身者。若男士 m 单身，他已向所有女士提过议且全被拒；每个拒绝他的女士最终都匹配给了她更喜欢的男士，故需要 n 个不同的男士与之配对，但除去 m 只有 $n - 1$ 个男士，矛盾。 3. **稳定性**（反证）：设 (m, w) 是不稳定对，m 的配偶是 w'，w 的配偶是 m'。因 m 更喜欢 w 而 w' 是最终配偶，m 必然曾向 w 提过议并被 w 拒绝。w 只在她已有更喜欢的伴侣时才拒绝，故 w 更喜欢 m' 而不是 m——与 (m, w) 是不稳定对（w 更喜欢 m）矛盾。

最优性定理（Gale—Shapley）：算法产出的是**对提出方最优**的稳定匹配——每个男士得到他在任何稳定匹配中可能得到的最好配偶；相应地，每个女士得到最差的。

关键引理（最优性的全部基础）：**若女士 w 曾拒绝男士 m，则 w 在任何稳定匹配中都不会与 m 配对。** *证明思路*：w 拒绝 m 时她已有一个更喜欢的 m'。在该稳定匹配中：若 w 与 m 配对，则 m' 必与某个 w' 配对。需证 (m', w) 构成不稳定对：w 更喜欢 m'（已知），且 m' 更喜欢 w 而非 w'——这需要归纳论证"m' 只在被更喜欢的女士拒绝时才退而求其次"。由此得矛盾。

推论：**所有稳定匹配中每个男士的配偶相同**（男士最优稳定匹配唯一）；女士侧同理。**但不同的稳定匹配可以给女士不同结果**。

⚠ **重要事实**：稳定匹配**不必唯一**；算法的输出取决于谁是提出方（提出方占优）。这在现实中（住院医师匹配）有伦理含义。

五、可数性与可计算性（Lecture 12—13）

5.1 可数性

集合	可数?	依据
$\mathbb{N}$, $\mathbb{Z}$, $\mathbb{Q}$	可数	存在显式双向枚举

集合	可数?	依据
$\mathbb{N}\times\mathbb{N}$	**可数**	对角线枚举
有限个/可数个数可数集的并	**可数**	归约到 $\mathbb{N}\times\mathbb{N}$
所有有限字符串 $\{0,1\}^*$	**可数**	按长度、再按字典序
所有程序（按任意语言）	**可数**	程序是有限字符串
$\mathbb{R}$	**不可数**	对角线论证
$\mathcal{P}(\mathbb{N})$	**不可数**	Cantor 定理
所有函数 $f:\{0,1\}^\infty\to\{0,1\}$	**不可数**	与 $\mathcal{P}(\mathbb{N})$ 等势

定义：A 可数 $\iff$ A 有限，或存在双射 $f:\mathbb{N}\to A$（即 A 可被排成一个序列 $a_0,a_1,a_2,\ldots$）。

关键双射：– $\mathbb{Z}$：$f(n)=\begin{cases}n/2 & n\text{ 偶}\\ -(n+1)/2 & n\text{ 奇}\end{cases}$ 给出 $0,-1,1,-2,2,\ldots$ – $\mathbb{N}\times\mathbb{N}$：按 $i+j$ 递增的对角线枚举；配对函数 $\pi(i,j)=\frac{(i+j)(i+j+1)}{2}+j$。

Cantor 定理：对任意集合 A，$|A|<|\mathcal{P}(A)|$。

证明（对角线）：显然 $|A|\le|\mathcal{P}(A)|$（$a\mapsto\{a\}$ 单射）。假设存在满射 $f:A\to\mathcal{P}(A)$，构造

$$D=\{a\in A:a\notin f(a)\}.$$

$D\subseteq A$ 故 $D\in\mathcal{P}(A)$。由 f 满射，存在 d 使 $f(d)=D$。问：$d\in D$？ – 若 $d\in D$，由 D 定义 $d\notin f(d)=D$，矛盾。 – 若 $d\notin D$，则 $d\in f(d)=D$，矛盾。 故满射不存在，$|A|\neq|\mathcal{P}(A)|$。∎

$\mathbb{R}$ 不可数（对角线）：假设 $\mathbb{R}$ 可数，则 $[0,1)$ 可数，列出其小数展开 $x_1,x_2,x_3,\ldots$。构造 y，其第 n 位小数 $=(x_n$ 的第 n 位小数 $+1)\bmod 10$。则 y 与每个 x_n 至少在第 n 位不同，故 y 不在列表中，矛盾。（技术细节：避开以全 9 结尾的展开以避免 $0.4999\ldots=0.5$ 的歧义，这不会影响论证。）

超越数存在性（非构造性）：代数数（整系数多项式的根）可数（每个多项式由有限个整数系数确定，可数多个多项式，每个有限个根）；而 $\mathbb{R}$ 不可数。故存在**不是**代数数的实数（超越数）。注意这个证明**不告诉我们任何具体的超越数**。

通往可计算性的桥梁：程序可数（有限字符串），而函数不可数，故**绝大多数函数不可计算**——这是"用计数论证不可能性"的范式。

5.2 可计算性与停机问题

停机问题：给定程序 P 与输入 x，判定 $P(x)$ 是否终止。

定理：停机问题**不可判定（undecidable）**。

证明（反证 + 自指）：假设存在判定器 `Halt(P, x)`，总能在有限时间内正确返回"停机"或"不停机"。构造

```
Turing(P):
    if Halt(P, P) == "停机":
        while true: pass      # 故意死循环
    else:
        return                # 停机
```

考虑 `Turing(Turing)`： – 若 `Halt(Turing, Turing)` 返回"停机"，则 `Turing(Turing)` 进入死循环——**不停机**，与判定器输出矛盾。 – 若返回"不停机"，则 `Turing(Turing)` 立即返回——**停机**，同样矛盾。

两分支皆矛盾，故 `Halt` 不存在。∎

关键洞察：程序本身是字符串，可以作为另一个程序的输入——**自指由此构造出来**。这与 Cantor 对角线论证、$\mathbb{R}$ 不可数论证是**同一个技巧**：

对角化实例	"行"	"列"	构造的"反例"
Cantor 定理	元素 a	子集 $f(a)$	$D=\{a:a\notin f(a)\}$
$\mathbb{R}$ 不可数	列表中的实数 x_n	第 n 位小数	y 的第 n 位 $=x_n$ 第 n 位 $+1$
停机问题	程序 P	输入 P	`Turing(Turing)`

可判定 vs 可识别： – **可判定（decidable）**：存在程序对**所有**输入都终止，且正确输出 yes/no。 – **可识别（recognizable / semi-decidable）**：存在程序在答案为 yes 时终止并输出 yes；答案为 no 时可能永远运行。

定理：停机问题是**可识别但不可判定**的。 – *可识别*：模拟器 `Sim(P,x)` 直接运行 $P(x)$；若终止则输出 yes。若 $P(x)$ 不停机，模拟器也不停机——这符合可识别的定义。 – *不可判定*：已证。

补集论证（通用技巧）：若 L 与 $\bar{L}$ 都可识别，则 L 可判定。 *证明*：设 M_1 识别 L，M_2 识别 $\bar{L}$。构造 M：在输入 x 上**并行交替**模拟 $M_1(x)$ 与 $M_2(x)$ 的步骤。x 必属于 L 或 $\bar{L}$ 之一，故其中一个必然终止并给出答案，M 据此输出。M 对所有输入终止，故 L 可判定。∎

推论：停机问题的补集**不可识别**（否则停机问题就可判定了）。

归约（Reduction）模式：要证问题 A 不可判定，证明"若能判定 A，就能判定停机问题"。典型例子：判定"程序 P 在输入 x 上是否输出 0"、判定"两个程序是否对所有输入行为相同"。

⚠️ **常见误解**："停机问题不可判定"**不**意味着我们无法判断任何具体程序是否停机——很多程序显然停机。不可判定指的是**不存在一个统一的算法**处理所有程序–输入对。

六、计数与概率基础（Lecture 14–18）

6.1 计数法则

法则	公式
乘法法则（第一法则）	依次有 $n_1, \dots, n_k$ 种选择 $\Rightarrow$ $n_1 n_2 \cdots n_k$ 种
和法则（第二法则）	集合划分为**不交**部分 $\Rightarrow$ 总数 = 各部分之和
互补法则	$\lvert A\rvert = \lvert U\rvert - \lvert \bar{A}\rvert$
排列	$P(n,k) = \dfrac{n!}{(n-k)!}$
组合	$\dbinom{n}{k} = \dfrac{n!}{k!(n-k)!}$
星棒法（非负解）	$x_1 + \cdots + x_k = n$，$x_i \geq 0$ 的解数 $= \dbinom{n+k-1}{k-1}$
星棒法（正解）	$x_i \geq 1$ 的解数 $= \dbinom{n-1}{k-1}$
容斥（2 集）	$\lvert A \cup B\rvert = \lvert A\rvert + \lvert B\rvert - \lvert A \cap B\rvert$
容斥（3 集）	$\lvert A \cup B \cup C\rvert = \lvert A\rvert + \lvert B\rvert + \lvert C\rvert - \lvert A \cap B\rvert - \lvert A \cap C\rvert - \lvert B \cap C\rvert + \lvert A \cap B \cap C\rvert$

组合数的关键论证：$\binom{n}{k}$ 的分子 $n(n-1)\cdots(n-k+1)$ 数的是**有序排列**；每个 k 元子集被数了 $k!$ 次（其内部的排列数），故除以 $k!$ 得子集数。

星棒法的双射：把解 $(x_1, \dots, x_k)$ 映射到"x_1 个星、1 个棒、x_2 个星、1 个棒、……、x_k 个星"的序列。这是双射，序列总数 $= \binom{n+k-1}{k-1}$。

容斥的一般形式（指示函数证明）：

$$\mathbb{1}_{A_1 \cup \cdots \cup A_n} = 1 - \prod_{i=1}^{n} (1 - \mathbb{1}_{A_i}) = \sum_{\emptyset \neq S \subseteq [n]} (-1)^{|S|+1} \mathbb{1}_{\bigcap_{i \in S} A_i}.$$

两边取期望（即求和），即得容斥公式。

6.2 组合恒等式

$$\binom{n}{k} = \binom{n}{n-k}$$

$$\binom{n}{k} = \binom{n-1}{k-1} + \binom{n-1}{k} \quad (\text{Pascal 法则})$$

$$\sum_{k=0}^{n} \binom{n}{k} = 2^n, \qquad \sum_{k=0}^{n} (-1)^k \binom{n}{k} = 0$$

$$\sum_{k=0}^{n} \binom{n}{k}^2 = \binom{2n}{n}$$

$$\sum_{k=0}^{n} k \binom{n}{k} = n 2^{n-1}$$

$$\sum_{k} \binom{m}{k} \binom{n}{r-k} = \binom{m+n}{r} \quad (\text{Vandermonde})$$

$$(x+y)^n = \sum_{k=0}^{n} \binom{n}{k} x^k y^{n-k} \quad (\text{二项式定理})$$

证明策略一览：

恒等式	策略	要数的对象
$\binom{n}{k} = \binom{n}{n-k}$	双射	k 元子集 $\leftrightarrow$ 其补集（$(n-k)$ 元子集）
Pascal 法则	双计数	n 元集的 k 元子集：分"含特定元素 a"与"不含 a"两类
$\sum_k \binom{n}{k} = 2^n$	双射	子集 $\leftrightarrow$ 长度 n 的 0/1 串
$\sum_k \binom{n}{k}^2 = \binom{2n}{n}$	双计数	n 男 n 女中选 n 人：直接数 vs 按男生个数分类
$\sum_k k\binom{n}{k} = n2^{n-1}$	双计数	"（子集，子集内一个元素）"这样的对
Vandermonde	双计数	m 个红球 n 个蓝球中选 r 个：按红球个数分类
二项式定理	双计数	$(x+y)^n$ 展开时每项选 x 或 y 的方式数

组合证明的方法论：1. 识别等式两边**各自在数什么**；2. **创造性地定义**要数的集合（常常是"对"或"带标记的对象"）；3. 验证两种数法**无重、无漏**；4. 若是双射，必须同时验证**单射**与**满射**。

6.3 概率公理与基本性质

概率空间 $(\Omega, \mathcal{F}, \Pr)$：$\Omega$ 样本空间（所有结果），事件 $A \subseteq \Omega$。

Kolmogorov 三公理：1. **非负性**：$\Pr[A] \geq 0$；2. **归一性**：$\Pr[\Omega] = 1$；3. **可数可加性**：两两不交的事件 $\Rightarrow \Pr[\bigcup_i A_i] = \sum_i \Pr[A_i]$。

由公理推出的性质（全部可证）：

性质	公式	证明要点
空集概率	$\Pr[\emptyset] = 0$	Ω 与 $\emptyset$ 不交且并集为 Ω
补集	$\Pr[\bar{A}] = 1 - \Pr[A]$	A 与 $\bar{A}$ 不交且并为 Ω
单调性	$A \subseteq B \Rightarrow \Pr[A] \leq \Pr[B]$	$B = A \cup (B \setminus A)$，不交并
并（容斥起点）	$\Pr[A \cup B] = \Pr[A] + \Pr[B] - \Pr[A \cap B]$	拆成三个不交部分
Union Bound	$\Pr[\bigcup_i A_i] \leq \sum_i \Pr[A_i]$	对 n 归纳；**不需要独立/互斥**

⚠ **最容易失分的点**：只有 **互斥（disjoint）** 时才有 $\Pr[A \cup B] = \Pr[A] + \Pr[B]$。

均匀概率空间（古典概型）：$|\Omega| = n$，每个结果等可能 $\Rightarrow \Pr[A] = |A|/n$。

⚠ **陷阱**："掷两枚硬币"的结果**不是** {0 个正面, 1 个正面, 2 个正面} 三种等可能——"1 个正面"含 HT 与 TH 两个结果。正确的样本空间是 $\{HH, HT, TH, TT\}$，故 $\Pr[1 \text{ 正面}] = 1/2$ 而非 $1/3$。

6.4 条件概率与贝叶斯

$$\Pr[A \mid B] = \frac{\Pr[A \cap B]}{\Pr[B]} \quad (\Pr[B] > 0)$$

直观：已知 B 发生，样本空间从 Ω **缩减**到 B，重新归一化。

乘法法则：$\Pr[A \cap B] = \Pr[A \mid B]\Pr[B] = \Pr[B \mid A]\Pr[A]$ **链式法则**：$\Pr[A_1 \cap \cdots \cap A_n] = \Pr[A_1]\Pr[A_2 \mid A_1] \cdots \Pr[A_n \mid A_1 \cap \cdots \cap A_{n-1}]$

全概率法则：若 $B_1, \ldots, B_n$ 是 Ω 的划分，则

$$\Pr[A] = \sum_{i=1}^{n} \Pr[A \mid B_i]\Pr[B_i].$$

贝叶斯法则：

$$\Pr[B \mid A] = \frac{\Pr[A \mid B]\Pr[B]}{\Pr[A]} = \frac{\Pr[A \mid B]\Pr[B]}{\sum_i \Pr[A \mid B_i]\Pr[B_i]}$$

- $\Pr[B]$ = 先验（prior）
- $\Pr[A \mid B]$ = 似然（likelihood）
- $\Pr[B \mid A]$ = 后验（posterior）

疾病检测算例（必背结论）：患病率 $1/1000$，灵敏度 99%，特异度 99%：

$$\Pr[\text{病} \mid +] = \frac{0.99 \times 0.001}{0.99 \times 0.001 + 0.01 \times 0.999} = \frac{0.00099}{0.01098} \approx 9\%.$$

为什么这么低：假阳性（$0.01 \times 999 \approx 10$ 人）远远多于真阳性（≈ 1 人）。

MAP vs MLE：$\hat{\theta}_{\text{MAP}} = \arg\max_\theta \Pr[\text{data} \mid \theta]\Pr[\theta]$；$\hat{\theta}_{\text{MLE}} = \arg\max_\theta \Pr[\text{data} \mid \theta]$。先验均匀时二者一致。

⚠ **高频错误**：混淆 $\Pr[A \mid B]$ 与 $\Pr[B \mid A]$（**检察官谬误**）。上面的算例中 $\Pr[+ \mid \text{病}] = 99\%$ 而 $\Pr[\text{病} \mid +] \approx 9\%$，差了十倍以上。

6.5 独立性与事件组合

独立：$A \perp B \iff \Pr[A \cap B] = \Pr[A]\Pr[B] \iff \Pr[A \mid B] = \Pr[A]$。

相互独立：$A_1, \ldots, A_n$ 相互独立要求**所有**子集 $S \subseteq [n]$ 满足 $\Pr\left[\bigcap_{i \in S} A_i\right] = \prod_{i \in S} \Pr[A_i]$。

⚠ **两两独立 $\not\Rightarrow$ 相互独立**（经典反例）：掷两枚硬币，A = 第一枚正面，B = 第二枚正面，C = 两枚相同。– $\Pr[A] = \Pr[B] = \Pr[C] = 1/2$；– 两两独立：$\Pr[A \cap B] = 1/4$，$\Pr[A \cap C] = 1/4$，$\Pr[B \cap C] = 1/4$ ✓；– 但 $\Pr[A \cap B \cap C] = \Pr[HH] = 1/4 \neq 1/8 = \Pr[A]\Pr[B]\Pr[C]$ ✗。

⚠ **不交 vs 独立**（最经典的混淆）：– **不交**：$A \cap B = \emptyset$（集合层面）。– **独立**：$\Pr[A \cap B] = \Pr[A]\Pr[B]$（概率层面）。– 若 A, B 不交且 $\Pr[A], \Pr[B] > 0$，则它们一定不独立（$0 \neq \Pr[A]\Pr[B] > 0$）。

条件独立：$\Pr[A \cap B \mid C] = \Pr[A \mid C]\Pr[B \mid C]$。**条件独立不蕴含独立，独立也不蕴含条件独立。**

互补技巧（求"至少一个"）：

$$\Pr[\text{至少一个 } A_i] = 1 - \Pr[\text{全不发生}] \overset{\text{独立}}{=} 1 - \prod_i (1 - \Pr[A_i]).$$

七、随机变量、期望、方差与极限定理（Lecture 19–26）

7.1 离散分布速查

分布	PMF	参数	$\mathbb{E}[X]$	$\mathrm{Var}(X)$	典型场景
伯努利 $\mathrm{Ber}(p)$	$\Pr[X=1]=p,\ \Pr[X=0]=1-p$	$p\in[0,1]$	p	$p(1-p)$	单次成败（指示变量）
二项 $\mathrm{Bin}(n,p)$	$\binom{n}{k}p^k(1-p)^{n-k}$	$n\in\mathbb{N},p$	np	$np(1-p)$	n 次独立试验的成功数
几何 $\mathrm{Geo}(p)$	$(1-p)^{k-1}p,\ k\ge 1$	$p\in(0,1]$	$\frac{1}{p}$	$\frac{1-p}{p^2}$	首次成功所需试验次数
泊松 $\mathrm{Pois}(\lambda)$	$\frac{\lambda^k}{k!}e^{-\lambda},\ k\ge 0$	$\lambda>0$	λ	λ	单位时间稀有事件数
离散均匀	$\Pr[X=i]=\frac{1}{n},\ i\in\{1..n\}$	n	$\frac{n+1}{2}$	$\frac{n^2-1}{12}$	掷骰子

泊松是二项分布的极限：$n\to\infty,\ p\to 0,\ np\to\lambda$ 时 $\mathrm{Bin}(n,p)\to\mathrm{Pois}(\lambda)$。

几何分布的无记忆性：$\Pr[X>n+m\mid X>n]=\Pr[X>m]$。

7.2 连续分布速查

分布	PDF	参数	$\mathbb{E}[X]$	$\mathrm{Var}(X)$	CDF
连续均匀 $U[a,b]$	$\frac{1}{b-a},\ x\in[a,b]$	$a<b$	$\frac{a+b}{2}$	$\frac{(b-a)^2}{12}$	$\frac{x-a}{b-a}$
指数 $\mathrm{Exp}(\lambda)$	$\lambda e^{-\lambda x},\ x\ge 0$	$\lambda>0$	$\frac{1}{\lambda}$	$\frac{1}{\lambda^2}$	$1-e^{-\lambda x}$
正态 $\mathcal{N}(\mu,\sigma^2)$	$\frac{1}{\sqrt{2\pi\sigma^2}}e^{-\frac{(x-\mu)^2}{2\sigma^2}}$	$\mu\in\mathbb{R},\sigma>0$	μ	σ^2	无初等闭式

连续情形的关键观念：– $\Pr[X=x]=0$ 对每个单点成立（概率为 0 不等于不可能）。– $f(x)$ 不是概率；$\Pr[X\in[x,x+dx]]\approx f(x)\,dx$。$f(x)$ 可以大于 1。– $\mathbb{E}[X]=\int x f(x)\,dx$；$\mathrm{Var}(X)=\int(x-\mu)^2 f(x)dx=\mathbb{E}[X^2]-\mu^2$。

指数分布的无记忆性（几何分布的连续类比）：

$$\Pr[X>s+t\mid X>s]=e^{-\lambda t}=\Pr[X>t].$$

正态分布的 68–95–99.7 法则：$\Pr[|X-\mu|\le\sigma]\approx 68\%$，$\le 2\sigma\approx 95\%$，$\le 3\sigma\approx 99.7\%$。

独立正态之和：$X\sim\mathcal{N}(\mu_1,\sigma_1^2)$，$Y\sim\mathcal{N}(\mu_2,\sigma_2^2)$ 独立 $\Rightarrow X+Y\sim\mathcal{N}(\mu_1+\mu_2,\sigma_1^2+\sigma_2^2)$。

7.3 期望与方差的核心工具

期望的定义：$\mathbb{E}[X]=\sum_a a\Pr[X=a]$（离散）；$\mathbb{E}[X]=\int x f(x)dx$（连续）。

期望的线性性（最重要的工具）：

$$\mathbb{E}\left[\sum_i X_i\right]=\sum_i\mathbb{E}[X_i].$$

⚠ **不需要独立性！** 这是全课程最有用的"免费午餐"。

LOTUS（无意识统计学家定律）：$\mathbb{E}[g(X)]=\sum_x g(x)\Pr[X=x]$。

乘积的期望：$X\perp Y\Rightarrow\mathbb{E}[XY]=\mathbb{E}[X]\mathbb{E}[Y]$。（反向不成立。）

指示变量的威力：$\mathbb{E}[\mathbb{I}_A]=\Pr[A]$。把复杂的"全局量"分解为简单的"局部指示变量之和"，是线性性应用的核心招式。

三大经典应用：

应用	分解方式	结果
二项分布期望	$X=\sum_{i=1}^n X_i,\ X_i\sim\mathrm{Ber}(p)$	$\mathbb{E}[X]=np$
优惠券收集	$T=\sum_{i=1}^n T_i,\ T_i\sim\mathrm{Geo}(\frac{n-i+1}{n})$	$\mathbb{E}[T]=nH_n\approx n\ln n$
哈希碰撞 / 空箱	对每对/每箱用指示变量	碰撞数 $\binom{n}{2}\frac{1}{n}$；空箱数 $n(1-\frac{1}{n})^n\approx\frac{n}{e}$

方差的定义与等价形式：

$$\mathrm{Var}(X)=\mathbb{E}[(X-\mathbb{E}X)^2]=\mathbb{E}[X^2]-(\mathbb{E}[X])^2.$$

方差的性质：

$$\mathrm{Var}(aX+b)=a^2\,\mathrm{Var}(X),\qquad \mathrm{Var}(X+Y)\overset{X\perp Y}{=}\mathrm{Var}(X)+\mathrm{Var}(Y).$$

⚠ **对比记忆**：期望线性性**不需要**独立；方差可加性**需要**独立（或至少不相关）。

协方差：

$$\mathrm{Cov}(X,Y) = \mathbb{E}[(X-\mathbb{E}X)(Y-\mathbb{E}Y)] = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y].$$

- **双线性**：$\mathrm{Cov}(aX+bY, Z) = a\,\mathrm{Cov}(X,Z) + b\,\mathrm{Cov}(Y,Z)$；
- $\mathrm{Cov}(X,X) = \mathrm{Var}(X)$；
- **独立 $\Rightarrow \mathrm{Cov}=0$，但反之不成立**（反例：$X$ 均匀取 $\{-1,0,1\}$，$Y=X^2$；$\mathbb{E}[X]=0$，$\mathbb{E}[XY]=\mathbb{E}[X^3]=0$，故 $\mathrm{Cov}=0$，但 Y 完全由 X 决定）。

一般方差公式：

$$\mathrm{Var}\left(\sum_i X_i\right) = \sum_i \mathrm{Var}(X_i) + 2\sum_{i<j}\mathrm{Cov}(X_i,X_j).$$

相关系数：$\rho_{X,Y} = \dfrac{\mathrm{Cov}(X,Y)}{\sigma_X\sigma_Y} \in [-1,1]$，度量**线性**相关程度。

7.4 联合分布与独立性

联合 PMF：$p_{X,Y}(a,b) = \Pr[X=a, Y=b]$；$\sum_{a,b} p_{X,Y}(a,b) = 1$。**边缘 PMF**：$p_X(a) = \sum_b p_{X,Y}(a,b)$。⚠ 边缘分布**不能**还原联合分布（信息丢失）。

随机变量独立：$X \perp Y \iff \Pr[X=a, Y=b] = \Pr[X=a]\Pr[Y=b]$ 对所有 a, b。

独立和的卷积：$Z = X+Y$ 时 $p_Z(z) = \sum_x p_X(x) p_Y(z-x)$。

闭包性质：$-\ \mathrm{Bin}(n,p) + \mathrm{Bin}(m,p) \sim \mathrm{Bin}(n+m,p)$；$-\ \mathrm{Pois}(\lambda_1) + \mathrm{Pois}(\lambda_2) \sim \mathrm{Pois}(\lambda_1+\lambda_2)$；$-\ \mathcal{N}(\mu_1,\sigma_1^2) + \mathcal{N}(\mu_2,\sigma_2^2) \sim \mathcal{N}(\mu_1+\mu_2, \sigma_1^2+\sigma_2^2)$。

7.5 集中不等式

马尔可夫不等式：$X \geq 0$，$t > 0 \Rightarrow$

$$\Pr[X \geq t] \leq \frac{\mathbb{E}[X]}{t}.$$

证明：对每个 ω，$t\,\mathbb{1}_{X\geq t}(\omega) \leq X(\omega)$；取期望得 $t\Pr[X\geq t] \leq \mathbb{E}[X]$。

切比雪夫不等式：

$$\Pr[|X - \mathbb{E}[X]| \geq t] \leq \frac{\mathrm{Var}(X)}{t^2}.$$

证明：对 $(X-\mu)^2 \geq 0$ 应用马尔可夫不等式，取 t^2。

切尔诺夫界（$X = \sum_{i=1}^n X_i$，独立伯努利，$\mu = \mathbb{E}[X]$）：

$$\Pr[X \geq (1+\delta)\mu] \leq \left(\frac{e^\delta}{(1+\delta)^{1+\delta}}\right)^\mu \leq e^{-\mu\delta^2/3} \quad (0<\delta<1),$$

$$\Pr[X \leq (1-\delta)\mu] \leq e^{-\mu\delta^2/2} \quad (0<\delta<1).$$

证明机制：对任意 $t>0$，$\Pr[X\geq a] = \Pr[e^{tX} \geq e^{ta}] \leq e^{-ta}\mathbb{E}[e^{tX}]$（马尔可夫）；独立性使 $\mathbb{E}[e^{tX}] = \prod_i \mathbb{E}[e^{tX_i}]$；最后对 t 优化。

三个界的强度对比（$n=1000$ 次公平硬币，$\Pr[X\geq 600]$，即 $\mu=500$、$\delta=0.2$）：

方法	上界数值	说明
真实值	1.36×10^{-10}	用二项分布精确计算
切比雪夫	$\dfrac{\mathrm{Var}(X)}{t^2} = \dfrac{250}{100^2} = 0.025$	用了方差，比马尔可夫好但仍很松
切尔诺夫（紧形式）	$\left(\frac{e^{0.2}}{1.2^{1.2}}\right)^{500} \approx 8.3\times10^{-5}$	指数级衰减
切尔诺夫（简化形式）	$e^{-500\cdot0.04/3} \approx 1.3\times10^{-3}$	更松但形式简单，常用
马尔可夫	$\dfrac{500}{600} \approx 0.83$	只用了期望，几乎无用

定性结论：**切尔诺夫 ≫ 切比雪夫 ≫ 马尔可夫**——用的信息越多（期望 → 方差 → 全部分布结构），界越紧，衰减从多项式变成指数。

> ⚠ **不要背成"切尔诺夫任何时候都最强"**：上表是 $n=1000$ 的大样本情形。当 n 较小而 δ 不小（如 $n=100, \delta=0.2$）时，切比雪夫给出 0.25，反而**优于**切尔诺夫的 0.39。切尔诺夫的优势是**渐近的**：它让上界随 n **指数**衰减，而切比雪夫只让上界按 $1/n$ 多项式衰减。选界时要看具体参数，而非套用排名。

弱大数定律（WLLN）：$X_1,\ldots,X_n$ 独立同分布，$\mathbb{E}[X_i]=\mu$，$\mathrm{Var}(X_i)=\sigma^2<\infty$，则对任意 $\epsilon>0$：

$$\Pr\left[\left|\frac{1}{n}\sum_{i=1}^n X_i - \mu\right| \geq \epsilon\right] \leq \frac{\sigma^2}{n\epsilon^2} \xrightarrow{n\to\infty} 0.$$

证明：$\mathbb{E}[\bar{X}_n] = \mu$（线性性），$\mathbf{Var}(\bar{X}_n) = \sigma^2/n$（独立性 + 方差可加），代入切比雪夫。

样本复杂度（估计硬币偏差）：为使 $\Pr[|\hat{p} - p| \geq \epsilon] \leq \delta$，切比雪夫给出 $n \geq \frac{1}{4\epsilon^2\delta}$；切尔诺夫给出 $n = O\left(\frac{\log(1/\delta)}{\epsilon^2}\right)$（对 δ 是指数级更优）。

7.6 中心极限定理

CLT：$X_1, X_2, \ldots$ 独立同分布，$\mathbb{E}[X_i] = \mu$，$\mathbf{Var}(X_i) = \sigma^2 < \infty$，则

$$\frac{\sum_{i=1}^{n} X_i - n\mu}{\sigma\sqrt{n}} \xrightarrow{d} \mathcal{N}(0,1),$$

即 $\bar{X}_n \approx \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right)$（$n$ 充分大时）。

与 LLN 的对比：LLN 说"均值收敛到 μ"；CLT 进一步说"波动的**形状**是正态的，尺度是 $\sigma/\sqrt{n}$"。

CLT 的适用条件与陷阱：
- 需要**有限方差**（Cauchy 分布无方差，CLT 失效）；
- 需要**独立同分布**（或满足一定条件的弱相关），强相关时失效；
- 是**渐进**结论，n 不够大时近似很差（原始分布偏斜时尤甚）；
- 二项的正态近似经验判据：$np \geq 10$ 且 $n(1-p) \geq 10$；
- **不能**把 CLT 用于"数据本身的分布"——趋近正态的是**均值的分布**。

置信区间：$\bar{X} \pm z_{\alpha/2}\frac{\sigma}{\sqrt{n}}$；95% 对应 $z \approx 1.96$。正确解读：**重复抽样时，约 95% 的区间会覆盖真值**（而不是"真值有 95% 概率落在本次区间内"）。

7.7 马尔可夫链与条件期望

马尔可夫性质（无记忆性）：

$$\Pr[X_{t+1} = j \mid X_t = i, X_{t-1}, \ldots, X_0] = \Pr[X_{t+1} = j \mid X_t = i] = P_{ij}.$$

转移矩阵 P：$P_{ij} \geq 0$，$\sum_j P_{ij} = 1$（行随机）。t 步转移：$P^{(t)} = P^t$。

状态分类：
- **可达 / 互通 / 不可约（irreducible）**：所有状态两两互通；
- **常返（recurrent）vs 瞬态（transient）**；
- **周期（periodic）vs 非周期（aperiodic）**。

平稳分布（stationary distribution）：$\pi P = \pi$，$\sum_i \pi_i = 1$。**存在唯一性**：有限、不可约、非周期的链有唯一平稳分布，且从任意初始分布收敛到它。

求解示例（2 状态）：$P = \begin{pmatrix} 0.7 & 0.3 \\ 0.4 & 0.6 \end{pmatrix}$，由 $\pi_1 = 0.7\pi_1 + 0.4\pi_2$ 与 $\pi_1 + \pi_2 = 1$ 解得 $\pi = \left(\frac{4}{7}, \frac{3}{7}\right)$。

首步分析（first-step analysis）：设 h_i 为从状态 i 出发的某目标概率（或期望量），则

$$h_i = \sum_j P_{ij} h_j \quad (\text{配边界条件}), \qquad t_i = 1 + \sum_j P_{ij} t_j \quad (\text{期望步数}).$$

赌徒破产问题：每次以概率 p 赢 1 元、$q = 1-p$ 输 1 元；起始 i 元，目标 N 元。最终赢到 N 元的概率

$$h_i = \begin{cases} \dfrac{1 - (q/p)^i}{1 - (q/p)^N} & p \neq \frac{1}{2} \\ \dfrac{i}{N} & p = \frac{1}{2} \end{cases}$$

（递推 $h_i = p h_{i+1} + q h_{i-1}$，边界 $h_0 = 0$，$h_N = 1$。）

条件期望：$\mathbb{E}[X \mid Y = y] = \sum_x x \Pr[X = x \mid Y = y]$；$\mathbb{E}[X \mid Y]$ 是**随机变量**。

全期望公式（重期望 / 塔性质）：

$$\mathbb{E}[X] = \sum_y \mathbb{E}[X \mid Y = y] \Pr[Y = y] = \mathbb{E}\big[\mathbb{E}[X \mid Y]\big].$$

证明：

$$\sum_y \mathbb{E}[X \mid Y = y] \Pr[Y = y] = \sum_y \sum_x x \frac{\Pr[X = x, Y = y]}{\Pr[Y = y]} \Pr[Y = y] = \sum_x x \sum_y \Pr[X = x, Y = y] = \mathbb{E}[X].$$

条件期望的性质：线性性；$\mathbb{E}[g(Y)X \mid Y] = g(Y)\mathbb{E}[X \mid Y]$（"把已知的提出来"）。

应用：条件期望是计算复杂期望的"分而治之"利器——先按某个变量分层，逐层计算，再按各层概率加权。典型用于随机和、几何分布期望、优惠券收集、首步分析。

八、跨讲次的高频陷阱总清单

1. **逆命题 ≠ 原命题**（L0–L1）：$P \Rightarrow Q$ 与 $Q \Rightarrow P$ 无关。**逆否**才是等价的。
2. **归纳法漏掉基础情形**（L3）：只有归纳步骤不能推出任何结论。
3. **归纳步骤的隐蔽漏洞**（L3）：如"所有马同色"伪证中两个子集交集为空。
4. **模运算中乱用除法**（L4）：$ab \equiv ac \pmod{m} \not\Rightarrow b \equiv c$，除非 $\gcd(a, m) = 1$。
5. **逆元存在条件**（L4–L5）：x 模 m 可逆 $\iff \gcd(x, m) = 1$；0 永远不可逆。
6. **FLT 的条件**（L5）：只对**质数** p 且 $a \not\equiv 0 \pmod{p}$ 成立。

7. **多项式"函数相等"≠"多项式相等"**（L7）：有限域上不同多项式可定义同一函数（x^p vs x）。
8. **$E \le 3V - 6$ 不充分**（L10）：满足不等式不保证平面。
9. **真子集可以等势**（L12）：$\mathbb{N} \subsetneq \mathbb{Z}$ 但 $|\mathbb{N}| = |\mathbb{Z}|$。"可数"不等于"有限"。
10. **$\Pr[A \cup B] = \Pr[A] + \Pr[B]$ 需互斥**（L15）：不互斥时必须减去 $\Pr[A \cap B]$。
11. **结果不等可能时不能用 $|A|/|\Omega|$**（L15）：掷两枚硬币的"1 个正面"。
12. **混淆 $\Pr[A \mid B]$ 与 $\Pr[B \mid A]$**（L17）：疾病检测算例差十倍以上（检察官谬误）。
13. **不交 ≠ 独立**（L18）：不交且概率为正 $\Rightarrow$ **不**独立。
14. **两两独立 ≠ 相互独立**（L18）：两枚硬币 + "两枚相同"的经典反例。
15. **独立 ≠ 条件独立**（L18）：两个方向都不成立。
16. **期望线性性不需要独立，方差可加需要独立**（L20–L22）：最常见的对比记忆点。
17. **$\mathrm{Var}(cX) = c^2 \mathrm{Var}(X)$**（L22）：不是 c。
18. **$\mathrm{Cov} = 0 \not\Rightarrow$ 独立**（L22）：$Y = X^2$ 但 X 对称。
19. **$\mathbb{E}[XY] = \mathbb{E}[X]\mathbb{E}[Y] \not\Rightarrow$ 独立**（L20）。
20. **连续情形 PDF 不是概率**（L24）：$f(x)$ 可以大于 1；$\Pr[X = x] = 0$ 不代表不可能。
21. **CLT 需要有限方差与（近似）独立同分布**（L25）：Cauchy 分布下失效；且 CLT 说的是**均值**趋近正态，不是数据本身。
22. **首步分析别忘边界条件**（L26）：没有边界条件的递推方程有无穷多解。
23. **平稳分布存在 ≠ 唯一**（L26）：可约链可能有无穷多平稳分布；周期链不收敛到平稳分布。
24. **停机问题不可判定 ≠ 无法判断任何程序**（L13）：不存在**统一算法**，具体程序常常很容易判断。